

Fundamentos e Formulação da Análise Multivariada

Departamento de Estatística e Matemática Aplicada/CC/UFC

Laboratório de Inovação em Estatística - StatLab

Grupo de pesquisa de Inovação em Estatística e Ciência de Dados

Versão Preliminar
- Em Elaboração -



Índice

Informações Legais e Declaração de Uso de Inteligência Artificial	23
Direitos Autorais e Uso da Obra	23
Declaração sobre o Uso de Ferramentas de Inteligência Artificial	23
Prefácio	24
Identificação da Disciplina	26
EMENTA	26
OBJETIVO GERAL	26
OBJETIVOS ESPECÍFICOS	26
CONTEÚDO PROGRAMÁTICO	27
Módulo I – Fundamentos Matemáticos e Geométricos da Análise Multivariada	27
Módulo II – Fundamentos Probabilísticos e Inferenciais da Análise Multivariada	27
Módulo III – Formulação Matemática e Estatística das Técnicas Multivariadas	27
METODOLOGIA	28
AVALIAÇÃO	28
CRITÉRIOS DE AVALIAÇÃO	28
BIBLIOGRAFIA BÁSICA	29
BIBLIOGRAFIA COMPLEMENTAR	29
I Módulo I — Fundamentos Matemáticos e Geométricos da Análise Multivariada	30
1 Vetores e representação dos dados multivariados	31
1.1 Escalares, vetores e matrizes	32
1.1.1 Vetor-coluna, vetor-linha e transposição	35
1.2 Natureza das variáveis e representação	36
1.3 O espaço $\mathbb{R}^p$	37
1.4 Representação matricial de um conjunto de dados	40
1.4.1 Representações por linhas e por colunas	42
1.5 Operações elementares com vetores	43
1.5.1 Soma e subtração	43
1.5.2 Multiplicação por escalar	44
1.5.3 Combinações lineares	46

1.6	Produto interno, norma, ângulo e distância euclidiana	47
1.6.1	Produto interno euclidiano	48
1.6.2	Norma euclidiana	49
1.6.3	Desigualdade de Cauchy–Schwarz	51
1.6.4	Ângulo entre vetores	54
1.6.5	Distância euclidiana	56
1.6.6	Desigualdade triangular	58
1.6.7	Produto externo	60
1.7	Síntese do capítulo	62
2	Álgebra matricial aplicada	64
2.1	Operações matriciais fundamentais	65
2.1.1	Soma e subtração de matrizes	65
2.1.2	Produto matriz-vetor	68
2.1.3	Produto entre matrizes	71
2.1.4	Propriedades do produto matricial	76
2.2	Transposição, simetria e traço	77
2.2.1	Transposição	77
2.2.2	Matrizes simétricas	79
2.2.3	Traço	81
2.3	Identidade, inversa, determinante, posto e sistemas lineares	84
2.3.1	Matriz identidade	84
2.3.2	Matriz inversa	86
2.3.3	Determinante	88
2.3.4	Posto	91
2.3.5	Sistemas lineares	94
2.4	Matrizes ortogonais e diagonais	98
2.4.1	Matrizes ortogonais	98
2.4.2	Matrizes diagonais	101
2.5	Formas quadráticas e positividade	103
2.5.1	Formas quadráticas	103
2.5.2	Positividade	109
2.5.3	Superfícies de nível	115
2.6	Matrizes particionadas e complemento de Schur	116
2.6.1	Matrizes particionadas	116
2.6.2	Soma e multiplicação por escalar	117
2.6.3	Transposição por blocos	118
2.6.4	Multiplicação por blocos	119
2.6.5	Complemento de Schur	120
2.6.6	Positividade e complemento de Schur	122
2.7	Aprofundamento teórico	125
2.7.1	Antissimetria e decomposição simétrica-antissimétrica	125
2.7.2	Cálculo por cofatores	128

2.7.3	Interpretação geométrica do determinante	129
2.7.4	Pseudoinversa de Moore–Penrose	131
2.7.5	Matrizes e sistemas triangulares	132
2.7.6	Eliminação por blocos	136
2.7.7	Determinante de uma matriz particionada	137
2.7.8	Inversão em blocos	139
2.8	Síntese do capítulo	140
3	Espaços vetoriais, bases e projeções	143
3.1	Espaços, subespaços e geração	144
3.1.1	Subespaços vetoriais	146
3.1.2	Subespaço gerado	148
3.2	Independência linear, bases e dimensão	151
3.2.1	Independência linear	151
3.2.2	Independência linear e posto	153
3.2.3	Bases	155
3.2.4	Coordenadas em uma base	156
3.2.5	Base canônica	158
3.2.6	Bases ortogonais e ortonormais	159
3.2.7	Dimensão	162
3.3	Espaços fundamentais de uma matriz	163
3.3.1	Espaço nulo	164
3.3.2	Espaço coluna	167
3.3.3	Espaço linha	169
3.3.4	Espaço nulo à esquerda	171
3.3.5	Teorema Posto–Nulidade	173
3.3.6	Os quatro espaços fundamentais	177
3.3.7	Complemento ortogonal	177
3.3.8	Relações de ortogonalidade	178
3.4	Produtos internos e matrizes de Gram	181
3.4.1	Produtos internos e geometrias induzidas	181
3.4.2	Matrizes de Gram	186
3.4.3	Propriedades da matriz de Gram	188
3.4.4	Matrizes de Gram e bases ortonormais	191
3.4.5	Produtos cruzados em uma matriz de dados	192
3.5	Complemento e decomposição ortogonais	193
3.5.1	Propriedades do complemento ortogonal	193
3.5.2	Dimensão do complemento ortogonal	195
3.5.3	Decomposição ortogonal	198
3.5.4	Decomposição dos espaços fundamentais	202
3.6	Projeções ortogonais	203
3.6.1	Projeção sobre uma direção	204
3.6.2	Projeção sobre um subespaço com base ortonormal	207

3.6.3	Projeção sobre o espaço coluna de uma matriz	212
3.6.4	Propriedades da matriz de projeção	216
3.6.5	Projeção residual	220
3.6.6	Projeção como melhor aproximação	225
3.6.7	Projeções e mínimos quadrados	228
3.7	Aprofundamento teórico	233
3.7.1	Extensão de uma base	233
3.7.2	Matrizes semidefinidas positivas	234
3.7.3	Projeções e mínimos quadrados ponderados	234
3.8	Síntese do capítulo	234
4	Transformações lineares	238
4.1	Transformações lineares e representação matricial	238
4.1.1	Transformação determinada por uma base	241
4.1.2	Representação matricial nas bases canônicas	243
4.1.3	Núcleo e imagem de uma transformação linear	245
4.1.4	Imagem de um subespaço	246
4.2	Transformação de vetores e matrizes de dados	247
4.2.1	Novas variáveis como combinações lineares	249
4.2.2	Dimensão da configuração transformada	251
4.2.3	Efeito sobre diferenças e produtos internos	253
4.2.4	Transformação das matrizes de produtos internos	256
4.3	Composição, invertibilidade e perda de informação	257
4.3.1	Composição de transformações lineares	258
4.3.2	A ordem das transformações	259
4.3.3	Transformação inversa	262
4.3.4	Injetividade, sobrejetividade e bijetividade	263
4.3.5	Perda de informação	267
4.3.6	Redução de dimensionalidade	268
4.3.7	Transformações singulares	269
4.4	Transformações geométricas	271
4.4.1	Rotação	271
4.4.2	Reflexão	272
4.4.3	Escalonamento	274
4.4.4	Cisalhamento	275
4.4.5	Projeção	277
4.4.6	Comparação geométrica	278
4.5	Transformações ortogonais	279
4.5.1	Transformação de uma matriz de dados	281
4.5.2	Matrizes ortogonais e bases ortonormais	282
4.5.3	Comparação com transformações não ortogonais	283
4.6	Mudanças de coordenadas e representação em bases	284
4.6.1	Representação de um operador em uma nova base	287

4.6.2	Mudança de coordenadas de uma matriz de dados	289
4.7	Transformações afins e pré-processamento	289
4.7.1	Translação	291
4.7.2	Transformação afim de uma matriz de dados	291
4.7.3	Centralização	292
4.7.4	Escalonamento das variáveis	296
4.7.5	Padronização	297
4.7.6	Ordem entre centralização e escalonamento	298
4.7.7	Composição e inversão de transformações afins	299
4.7.8	Comparação das operações de pré-processamento	301
4.8	Aprofundamento teórico	301
4.8.1	Determinante, volume e orientação	301
4.8.2	Determinante e orientação em transformações ortogonais	303
4.8.3	Conversão entre duas bases	304
4.8.4	Representação de uma transformação em bases gerais	306
4.8.5	Transformação ativa e mudança passiva	309
4.9	Síntese do capítulo	311
5	Autovalores, autovetores e decomposição espectral	317
5.1	Direções invariantes, autovalores e autoespaços	318
5.2	Equação característica e diagonalização	324
5.2.1	Determinação dos autovalores e autoespaços	326
5.2.2	Diagonalização	328
5.3	Matrizes simétricas e decomposição espectral	330
5.3.1	Decomposição espectral do exemplo condutor	335
5.3.2	Forma aditiva da decomposição espectral	337
5.3.3	Projetores sobre autoespaços	338
5.3.4	Não unicidade da matriz de autovetores	340
5.4	Consequências da decomposição espectral	341
5.4.1	Traço, determinante, posto e invertibilidade	342
5.4.2	Formas quadráticas em coordenadas espectrais	344
5.4.3	Superfícies de nível em coordenadas espectrais	349
5.5	Quociente de Rayleigh	352
5.5.1	Representação espectral	353
5.5.2	Formulação com restrição de norma	359
5.5.3	Multiplicadores de Lagrange	360
5.5.4	Direções sucessivas	364
5.6	Funções espectrais de matrizes	369
5.6.1	Ação sobre os autoespaços	370
5.6.2	Inversa espectral	371
5.6.3	Raiz quadrada principal	372
5.6.4	Raiz quadrada inversa	373

5.7	Autovalores generalizados	375
5.7.1	Quociente de Rayleigh generalizado	377
5.7.2	Redução a um problema espectral ordinário	380
5.7.3	Ortogonalidade na métrica de $\mathbf{M}$	383
5.8	Aprofundamento teórico	389
5.8.1	Multiplicidades algébrica e geométrica	389
5.8.2	Núcleo e imagem na decomposição espectral	394
5.8.3	Pseudoinversa espectral	396
5.8.4	Diagonalização simultânea por congruência	398
5.8.5	Subespaços invariantes	400
5.8.6	Autovalores complexos de matrizes reais	403
5.8.7	Independência entre autovetores	404
5.8.8	CrITÉrios gerais de diagonalização	405
5.8.9	Potências de uma matriz diagonalizável	407
5.8.10	Potências inteiras de matrizes simétricas	408
5.8.11	Exponencial e logaritmo matriciais	409
5.9	Síntese do capítulo	410
6	Decomposição em Valores Singulares	417
6.1	Definição e formas da Decomposição em Valores Singulares	418
6.1.1	Vetores singulares	422
6.1.2	Interpretação como composição de transformações	424
6.1.3	SVD completa	425
6.1.4	SVD compacta	426
6.1.5	SVD compacta e SVD truncada	427
6.1.6	Sinal dos pares singulares	433
6.2	Construção da SVD e relação com a decomposição espectral	433
6.2.1	Propriedades das matrizes de Gram associadas	434
6.2.2	Construção dos pares singulares	439
6.2.3	Construção da SVD compacta	444
6.2.4	Decomposições espectrais associadas	448
6.2.5	Exemplo de construção da SVD	450
6.2.6	Relação com a decomposição espectral de matrizes simétricas	453
6.3	Interpretação geométrica da SVD	454
6.3.1	Imagem da bola unitária	455
6.3.2	Alteração dos comprimentos	459
6.3.3	Exemplo geométrico no plano	463
6.3.4	Transformações com núcleo não trivial	464
6.4	Espaços fundamentais, posto e normas	466
6.4.1	Espaço coluna e espaço linha	467
6.4.2	Projetores ortogonais	472
6.4.3	Posto e nulidades	475
6.4.4	Produto interno de Frobenius	477

6.4.5	Normas e valores singulares	478
6.5	Condicionamento e número de condição	481
6.6	SVD de uma matriz de dados	486
6.6.1	Dualidade entre observações e variáveis	487
6.6.2	Coordenadas das observações nas direções singulares à direita	488
6.6.3	Coordenadas das variáveis nas direções singulares à esquerda	489
6.6.4	Matrizes de Gram da matriz de dados	490
6.6.5	Representação exata das observações	492
6.6.6	Centralização da matriz de dados	494
6.6.7	Relação com a matriz de covariâncias amostral	496
6.6.8	Representação exata e aproximação	499
6.7	Forma expandida e aproximações de posto reduzido	500
6.7.1	Ortogonalidade dos componentes singulares	503
6.7.2	SVD truncada na forma expandida	504
6.7.3	Erros produzidos pelo truncamento	505
6.7.4	Teorema de Eckart–Young–Mirsky	510
6.7.5	Exemplo de aproximação de posto 1	514
6.8	Pseudoinversa e soluções de mínimos quadrados	516
6.8.1	Pseudoinversa e projetores	518
6.8.2	Mínimos quadrados	520
6.8.3	Exemplo com o sistema condutor	526
6.9	Aprofundamento teórico	528
6.9.1	Não unicidade dos vetores singulares	528
6.9.2	Construção teórica e cálculo numérico	530
6.9.3	Invariância ortogonal	530
6.9.4	Determinante e invertibilidade	531
6.9.5	Magnitude quadrática da matriz centralizada	532
6.9.6	Unicidade da aproximação	534
6.9.7	Aproximação de uma matriz de dados	535
6.9.8	Relação com a pseudoinversa espectral	539
6.9.9	Caracterização de Moore–Penrose	540
6.9.10	Sistemas lineares compatíveis	543
6.9.11	Caso de posto linha completo	546
6.9.12	Expressão da solução nas direções singulares	547
6.10	Síntese do capítulo	548
7	Cálculo Diferencial, Integral e Matricial Aplicado à Estatística Multivariada	556
7.1	Funções, variações e diferenciais	556
7.1.1	Tipos de funções	556
7.1.2	Convenções de derivação	559
7.1.3	Variação de uma função	560
7.1.4	Diferencial	562
7.1.5	Aproximação ao longo de uma direção	564

7.1.6	Diferenciabilidade de funções vetoriais	564
7.2	Gradiente, derivada direcional, Jacobiana e Hessiana	567
7.2.1	Gradiente e derivada direcional	567
7.2.2	Gradiente e conjuntos de nível	569
7.2.3	Jacobiana	571
7.2.4	Regra da cadeia	574
7.2.5	Hessiana	576
7.3	Aproximações de Taylor e classificação local	579
7.3.1	Aproximação de Taylor de primeira ordem	579
7.3.2	Aproximação de Taylor de segunda ordem	580
7.3.3	Pontos estacionários	582
7.3.4	Classificação pela Hessiana	583
7.4	Convexidade e concavidade	588
7.4.1	Conjuntos convexos	588
7.4.2	Funções convexas	589
7.4.3	Caracterização de primeira ordem	590
7.4.4	Caracterização pela Hessiana	590
7.4.5	Consequências para otimização	594
7.4.6	Funções quadráticas	595
7.5	Otimização sem restrições	597
7.6	Otimização com restrições de igualdade	597
7.6.1	Multiplicadores de Lagrange	599
7.6.2	Relação com problemas de autovalores	604
7.7	Derivadas de formas lineares, quadráticas e funções de resíduos	605
7.7.1	Formas lineares e bilineares	605
7.7.2	Derivadas de formas quadráticas	606
7.7.3	Derivadas da norma euclidiana	609
7.7.4	Funções de resíduos lineares	610
7.7.5	Equações normais	611
7.8	Diferenciais matriciais e cálculo por traços	614
7.8.1	Regras básicas do diferencial matricial	616
7.8.2	Identidades de traço	617
7.8.3	Função linear de uma matriz	618
7.8.4	Derivadas da norma de Frobenius	619
7.8.5	Funções quadráticas de uma matriz	620
7.8.6	Funções matriciais de resíduos	621
7.9	Derivadas de inversas, determinantes e log-determinantes	626
7.9.1	Diferencial da matriz inversa	626
7.9.2	Diferencial do determinante	628
7.9.3	Diferencial do log-determinante	630
7.9.4	Traço envolvendo uma matriz inversa	631
7.9.5	Forma quadrática com matriz inversa	633
7.9.6	Critério com log-determinante e traço	634

7.10	Vetorização e produto de Kronecker	638
7.10.1	Operador de vetorização	639
7.10.2	Produto de Kronecker	640
7.11	Integração múltipla e mudança de variáveis	641
7.11.1	Integrais múltiplas	642
7.11.2	Teorema de Tonelli	643
7.11.3	Densidades multivariadas	643
7.11.4	Distribuições marginais	644
7.11.5	Esperanças de funções escalares, vetoriais e matriciais	646
7.11.6	Mudança de variáveis	648
7.11.7	Transformação de densidades	649
7.11.8	Transformações afins	651
7.11.9	Interpretação geométrica do determinante Jacobiano	652
7.11.10	Transformações elipsoidais	653
7.12	Aprofundamento teórico	655
7.12.1	Identidade de vetorização	655
7.12.2	Log-verossimilhança e vetor escore	657
7.12.3	Informação observada e informação de Fisher	658
7.13	Síntese do capítulo	660
7.14	Apêndice de cálculo para Estatística Multivariada	661
7.14.1	Caso inconclusivo na classificação pela Hessiana	661
7.14.2	Método de Newton	662
7.14.3	Restrições lineares	666
7.14.4	Mínimos quadrados ponderados	668
7.14.5	Funções compostas de resíduos	670
7.14.6	Mínimos quadrados não lineares	671
7.14.7	Ponderação de observações e respostas	673
7.14.8	Segunda variação do log-determinante	675
7.14.9	Parâmetros matriciais simétricos	676
7.14.10	Derivadas vetorizadas e parâmetros matriciais	677
7.14.11	Teorema de Fubini	689
7.14.12	Coordenadas polares	690
7.14.13	Diferenciação sob o sinal de integração	691
7.14.14	Newton–Raphson	698
7.14.15	Método do escore de Fisher	700
7.14.16	Expansão local de uma raiz do escore	701
7.14.17	Método delta	702
Exercícios de fixação do Módulo I		709
Parte I — Exercícios sem uso de computador		709
Parte II — Exercícios com uso do R		725

II	Módulo II — Fundamentos Probabilísticos e Inferenciais da Análise Multivariada	735
8	Matrizes de covariâncias e correlações	736
8.1	Momentos, centralização e covariância	737
8.1.1	Vetor de médias e centralização	737
8.1.2	Momentos de segunda ordem	738
8.1.3	Covariância entre duas variáveis	740
8.2	Matriz de covariâncias populacional	745
8.2.1	Definição e interpretação dos elementos	745
8.2.2	Variâncias e covariâncias de combinações lineares	746
8.2.3	Propriedades estruturais e singularidade	749
8.3	Covariâncias entre vetores e transformações	755
8.3.1	Covariâncias cruzadas e vetores particionados	755
8.3.2	Transformações afins da média e da covariância	762
8.4	Padronização e matriz de correlações	766
8.4.1	Matriz de correlações populacional	766
8.4.2	Propriedades, escala e independência	771
8.5	Geometria e medidas globais da dispersão	777
8.5.1	Eixos espectrais e elipsoide de covariância	777
8.5.2	Variância total e variância generalizada	785
8.6	Distância de Mahalanobis	788
8.6.1	Interpretação geométrica e espectral	789
8.6.2	Branqueamento e esferização	792
8.7	Representação descritiva a partir dos dados	797
8.7.1	Centralização, SQPC e matriz de covariâncias observada	797
8.7.2	Matriz de correlações e covariâncias cruzadas observadas	801
8.8	Decomposição da dispersão por grupos	807
8.8.1	Dispersão total, intragrupos e entre grupos	809
8.8.2	Somas de quadrados e traço das matrizes de dispersão	815
8.8.3	Propriedades e limites de posto	818
8.9	Aprofundamentos teóricos	822
8.9.1	Variância média e interpretação volumétrica da variância generalizada	822
8.9.2	Esperança das matrizes de dispersão por grupos	825
8.10	Síntese do capítulo	830
9	Distribuição Normal Multivariada	836
9.1	Definição e construção	837
9.1.1	Definição por combinações lineares	837
9.1.2	Construção afim a partir do vetor normal padrão	839
9.1.3	Determinação pelos parâmetros	842
9.2	Densidade da normal multivariada	845
9.2.1	Função densidade e log-densidade	845

9.2.2	Superfícies de igual densidade	848
9.3	Transformações e distribuições marginais	850
9.3.1	Fechamento sob transformações afins	850
9.3.2	Combinações lineares	852
9.3.3	Distribuições marginais	854
9.3.4	Padronização marginal e branqueamento	856
9.4	Independência e distribuições condicionais	858
9.4.1	Independência entre blocos conjuntamente normais	858
9.4.2	Distribuição condicional	862
9.4.3	Média e covariância condicionais	866
9.4.4	Caso bivariado	868
9.5	Distância de Mahalanobis e regiões de probabilidade	871
9.5.1	Distribuição qui-quadrado	872
9.5.2	Regiões elipsoidais de probabilidade	874
9.6	Comparação entre distribuições normais	875
9.6.1	Médias distintas e covariância comum	876
9.6.2	Covariâncias distintas	877
9.7	Alcance da hipótese de normalidade	879
9.7.1	Resultados que não exigem normalidade	879
9.7.2	Resultados específicos da família normal	880
9.7.3	Passagem do modelo populacional para a inferência	881
9.8	Aprofundamento metodológico e aplicado	882
9.8.1	Avaliação de uma observação fixa	882
9.9	Aprofundamento teórico: Normal Singular	884
9.10	Síntese do capítulo	893
10	Estatísticas Amostrais e Estimação	896
10.1	Da população à amostra	897
10.1.1	Amostra aleatória multivariada	898
10.1.2	Matriz aleatória da amostra e matriz observada	900
10.1.3	Parâmetros, estatísticas, estimadores e estimativas	901
10.2	Propriedades dos estimadores multivariados	904
10.2.1	Viés e variabilidade	905
10.2.2	Consistência	906
10.3	Métodos de estimação	907
10.3.1	Método dos momentos	908
10.3.2	Verossimilhança e máxima verossimilhança	909
10.4	Estimação do vetor de médias	916
10.4.1	Vetor de médias amostrais	917
10.4.2	Não viesamento e variabilidade	919
10.4.3	Combinações lineares	921
10.4.4	Consistência e transformação afim	923
10.4.5	Variabilidade entre amostras	925

10.5	SQPC e estimação da matriz de covariâncias	926
10.5.1	SQPC como estatística aleatória	927
10.5.2	Decomposição em torno de um centro arbitrário	928
10.5.3	Esperança da SQPC	929
10.5.4	Estimador não viesado da matriz de covariâncias	931
10.5.5	Estimador com divisor n : momentos e máxima verossimilhança	933
10.5.6	Consistência dos estimadores de covariância	935
10.5.7	Transformações, posto e singularidade	937
10.6	Estimação de covariâncias cruzadas e correlações	940
10.6.1	Covariâncias cruzadas entre blocos	940
10.6.2	Matriz de correlações amostral	943
10.7	Aprofundamento teórico	944
10.7.1	Erro quadrático médio e funções de perda	945
10.7.2	Erro quadrático médio do vetor de médias amostrais	946
10.7.3	Variabilidade e erro quadrático da matriz de covariâncias amostral	947
10.7.4	Eficiência	947
10.7.5	Suficiência	949
10.7.6	Equivariância	953
10.7.7	Propriedades gerais dos métodos de estimação	956
10.7.8	Invariância da máxima verossimilhança	959
10.7.9	Extensões para covariâncias cruzadas e correlações	962
10.8	Aprofundamento metodológico e aplicado: dimensão, estabilidade e extensões da estimação	971
10.8.1	Relação entre p e n	971
10.8.2	Condicionamento e inversão	973
10.8.3	Regularização	975
10.8.4	Pseudoinversa e regularização	980
10.8.5	Sensibilidade e robustez	981
10.9	Exemplo integrado	982
10.10	Síntese do capítulo	990
11	Modelo Linear Multivariado e Hipóteses Lineares	994
11.1	Formulação do modelo linear multivariado	995
11.1.1	Resposta vetorial e matriz de respostas	995
11.1.2	Estrutura matricial do modelo	998
11.1.3	Estrutura de médias e covariâncias residuais	999
11.1.4	Formulação normal do modelo	1000
11.2	Estimação da matriz de parâmetros	1001
11.2.1	Mínimos quadrados	1001
11.2.2	Estimador sob posto completo	1003
11.3	Valores ajustados, resíduos e projeções	1004
11.3.1	Valores ajustados e resíduos	1006
11.3.2	Ortogonalidade	1007

11.3.3	Conexão com o modelo contendo somente intercepto	1008
11.4	SQPC residual e estimação da covariância	1008
11.4.1	Construção da SQPC residual	1009
11.4.2	Esperança e graus de liberdade	1010
11.4.3	Estimação da covariância residual	1013
11.4.4	Posto e singularidade	1014
11.5	Decomposição da variação multivariada	1016
11.5.1	SQPC total	1016
11.5.2	SQPC associada ao modelo	1017
11.5.3	Decomposição entre modelo e resíduo	1019
11.5.4	Modelo de grupos como caso particular	1020
11.6	Posto, parametrização e estimabilidade	1023
11.6.1	Delineamento com posto deficiente	1024
11.6.2	Pseudoinversa e unicidade do ajuste	1024
11.6.3	Funções estimáveis	1025
11.6.4	Estimador de uma função estimável	1027
11.7	Hipóteses lineares multivariadas	1028
11.7.1	Combinações das linhas da matriz de parâmetros	1028
11.7.2	Combinações das respostas	1030
11.7.3	Hipótese linear geral	1031
11.7.4	Estimabilidade da hipótese	1032
11.7.5	SQPC da hipótese	1034
11.7.6	Casos particulares	1036
11.8	Aprofundamento teórico	1038
11.8.1	Forma vetorizada	1038
11.8.2	Distribuição normal matricial em forma geral	1039
11.8.3	Formulação matricial conjunta do modelo normal	1040
11.8.4	Transformações lineares das respostas	1041
11.8.5	Formulação por colunas da matriz de respostas	1042
11.8.6	Momentos do estimador da matriz de parâmetros	1042
11.8.7	Covariâncias entre estimadores de respostas	1044
11.8.8	Mínimos quadrados e máxima verossimilhança	1045
11.8.9	Modelo contendo somente intercepto	1046
11.8.10	Esperança dos valores ajustados e dos resíduos	1049
11.8.11	Covariâncias dos valores ajustados e dos resíduos	1050
11.8.12	Modelos sem intercepto	1051
11.8.13	Parametrizações equivalentes	1052
11.8.14	Caso escalar da hipótese bilateral	1053
11.8.15	Modelos encaixados	1054
11.8.16	Modelos encaixados para combinações de respostas	1056
11.8.17	SQPC residual de combinações das respostas	1056
11.8.18	Estimador de máxima verossimilhança da covariância residual	1057
11.8.19	Viés do estimador de máxima verossimilhança da covariância residual	1058

11.8.20	Formas equivalentes da decomposição da variação	1058
11.8.21	Decomposição para combinações lineares das respostas	1060
11.8.22	Postos das matrizes na decomposição da variação	1061
11.9	Aprofundamento metodológico e aplicado	1061
11.9.1	Representação dos ajustes e resíduos	1061
11.9.2	Interpretação da covariância residual estimada	1061
11.9.3	Representação geométrica da decomposição no modelo de grupos	1062
11.9.4	Casos adicionais de hipóteses lineares	1063
11.9.5	Exemplo integrado	1065
11.10	Síntese do capítulo	1074
12	Inferência Multivariada	1079
12.1	Distribuições amostrais exatas e assintóticas	1080
12.1.1	Distribuição da média amostral sob normalidade	1080
12.1.2	Teorema Central do Limite multivariado	1083
12.2	Distribuição de Wishart	1085
12.2.1	Construção e parametrização	1086
12.2.2	Suporte, posto e definição positiva	1088
12.2.3	Aditividade	1089
12.2.4	Transformações lineares	1090
12.2.5	Distribuição da SQPC e da covariância amostral	1091
12.2.6	Independência entre média e covariância	1096
12.3	Distribuições no modelo linear multivariado	1099
12.3.1	Distribuição da SQPC residual	1099
12.4	Princípios da inferência multivariada	1102
12.4.1	Testes globais e hipóteses simultâneas	1103
12.4.2	Razão de verossimilhanças	1104
12.5	Inferência sobre um vetor de médias	1106
12.5.1	Estatística T^2 de Hotelling	1107
12.5.2	Relações com os casos assintótico e univariado	1110
12.6	Comparação entre dois vetores de médias	1111
12.6.1	Duas amostras independentes	1111
12.7	Condições e limites da inferência clássica	1117
12.7.1	Independência, normalidade e covariância comum	1118
12.7.2	Posto, dimensão e tamanho amostral	1121
12.8	Aprofundamentos teóricos	1123
12.8.1	Distribuição do estimador da matriz de parâmetros	1124
12.8.2	Distribuição de funções estimáveis	1126
12.8.3	Independência entre estimação e SQPC residual	1127
12.8.4	Momentos	1129
12.8.5	Formas quadráticas	1131
12.8.6	Consequências adicionais para a matriz de covariâncias amostral	1132
12.8.7	Extensões das transformações da Wishart	1133

12.8.8	Densidade da distribuição de Wishart	1133
12.8.9	Distribuição da SQPC da hipótese sob H_0	1135
12.8.10	Resultado assintótico de Wilks	1139
12.8.11	Razão de verossimilhanças em modelos normais encaixados	1142
12.8.12	Inferência sobre o vetor de médias com covariância conhecida	1145
12.8.13	Invariância afim do T^2 de Hotelling	1147
12.8.14	Hipóteses lineares sobre o vetor de médias	1147
12.8.15	Relação com o modelo linear multivariado	1152
12.9	Aprofundamentos metodológicos e aplicados	1153
12.9.1	Região de confiança elipsoidal	1153
12.9.2	Geometria da região	1154
12.9.3	Intervalos simultâneos	1155
12.9.4	Região de confiança e intervalos simultâneos para duas amostras inde- pendentes	1157
12.9.5	Covariâncias populacionais distintas	1159
12.9.6	Observações pareadas	1160
12.9.7	Alta dimensão e robustez	1164
12.10	Quadro-síntese das condições inferenciais	1166
12.11	Síntese do Módulo 2	1167
12.11.1	Passagem para o Módulo 3	1169
Exercícios de fixação do Módulo II		1171
Parte I — Conceitos, fundamentos, operações matriciais e inferência sem uso de computador		1172
Parte II — Exercícios com uso do R		1182
 III Módulo III — Formulação Matemática e Estatística das Técnicas Multi- variadas		 1187
13 Problemas e estruturas das técnicas multivariadas		1188
13.1	O caráter multivariado dos dados	1189
13.2	Do problema estatístico à técnica multivariada	1189
13.3	Classes de problemas multivariados	1191
13.3.1	Redução de dimensionalidade	1191
13.3.2	Representação de estruturas latentes	1191
13.3.3	Formação de grupos	1192
13.3.4	Representação de associações em tabelas de contingência	1192
13.3.5	Teste conjunto de hipóteses sobre várias respostas	1192
13.3.6	Discriminação e classificação	1193
13.4	Diferentes formas de classificar as técnicas	1193
13.4.1	Interdependência e dependência	1193
13.4.2	Exploratórias, descritivas, preditivas e inferenciais	1194

13.4.3	Supervisionadas e não supervisionadas	1194
13.5	Estruturas matemáticas recorrentes	1195
13.5.1	Combinações lineares e projeções	1195
13.5.2	Formas quadráticas e problemas espectrais	1196
13.5.3	Otimização sob restrições e critérios de ajuste	1196
13.5.4	SVD e representações de baixa dimensão	1197
13.5.5	Distâncias e métricas	1198
13.5.6	Modelos lineares e probabilísticos	1198
13.6	Mesmas operações, diferentes funções	1200
13.7	Relações entre as técnicas	1202
13.8	Aprofundamento metodológico e aplicado	1203
13.8.1	Etapas da análise multivariada	1203
13.8.2	Natureza das variáveis e escalas de medida	1204
13.8.3	Tamanho amostral, dimensão e poder	1206
13.8.4	Exame preliminar dos dados	1207
13.8.5	Pressupostos da formulação adotada	1208
13.8.6	Transformações e reespecificações	1209
13.8.7	Interpretação e significância prática	1209
13.8.8	Diagnóstico da análise	1210
13.8.9	Parcimônia	1211
13.8.10	Estabilidade e validação	1211
13.9	Síntese	1212
14	Formulação da Análise de Componentes Principais	1214
14.1	O problema de redução de dimensionalidade	1214
14.2	Componentes principais como combinações lineares	1217
14.3	Primeira componente principal	1218
14.4	Componentes principais sucessivas	1219
14.5	Formulação espectral	1221
14.6	Variância total e proporção de variância	1223
14.7	Subespaço principal, projeção e reconstrução	1226
14.8	Formulação amostral	1228
14.9	Formulação da ACP pela SVD	1231
14.10	ACP baseada na matriz de correlações	1233
14.11	Formulação descritiva, populacional e inferencial	1236
14.12	Limites da representação por componentes principais	1237
14.13	Aprofundamentos teóricos	1238
14.13.1	Formulação do subespaço principal e variabilidade máxima	1238
14.13.2	Reconstrução e erro quadrático	1245
14.13.3	Aproximação de posto reduzido	1249
14.13.4	Propriedades da solução	1251
14.13.5	Estimação e inferência das componentes sob normalidade	1254

14.14	Aprofundamentos metodológicos e aplicados	1256
14.14.1	Preparação dos dados para a ACP	1257
14.14.2	Escolha do número de componentes	1258
14.14.3	Coeficientes e relação das variáveis com as componentes	1261
14.14.4	Interpretação das componentes	1265
14.14.5	Representação das observações e das variáveis	1266
14.14.6	Elementos ativos e suplementares na interpretação da ACP	1273
14.14.7	Estabilidade da solução amostral	1275
14.14.8	Correspondência com a implementação utilizada	1276
14.15	Síntese	1279
15	Formulação da Análise Fatorial	1282
15.1	O problema da estrutura latente	1282
15.2	Formulação do modelo de fatores comuns	1283
15.3	Hipóteses do modelo ortogonal	1287
15.4	Estrutura da matriz de covariâncias	1288
15.4.1	Covariâncias entre variáveis	1290
15.4.2	Variâncias das variáveis	1291
15.5	Comunalidades e especificidades	1291
15.6	Cargas fatoriais e associação com os fatores	1294
15.7	Geometria das cargas fatoriais	1296
15.8	Estrutura comum de covariâncias	1298
15.9	Identificação do modelo fatorial	1300
15.9.1	Escala dos fatores	1301
15.9.2	Indeterminação do sinal	1301
15.9.3	Indeterminação rotacional	1302
15.10	Rotação dos eixos fatoriais	1302
15.10.1	Rotações ortogonais	1303
15.10.2	Rotações oblíquas	1303
15.11	Formulação populacional e amostral	1306
15.11.1	O problema de estimação	1306
15.11.2	Escores fatoriais	1307
15.12	Pressupostos e limites do modelo	1309
15.12.1	Número de fatores	1310
15.12.2	Dependência do conjunto de variáveis	1311
15.12.3	Dependência da escala das variáveis	1311
15.12.4	Papel da normalidade	1311
15.12.5	Limites da interpretação	1312
15.13	Análise Fatorial e Análise de Componentes Principais	1312
15.14	Aprofundamentos teóricos	1315
15.14.1	Contagem de parâmetros e identificação	1315
15.14.2	Invariâncias da rotação ortogonal	1320
15.14.3	Formulação probabilística normal	1321

15.14.4	Distribuições associadas à avaliação da matriz de correlações	1327
15.14.5	Distribuição condicional dos fatores e escore por regressão	1329
15.15	Aprofundamentos metodológicos e aplicados	1331
15.15.1	Avaliação da matriz de correlações antes da Análise Fatorial	1331
15.15.2	Tamanho amostral e estabilidade das estimativas	1337
15.15.3	Fatores principais e mínimos resíduos	1337
15.15.4	Escolha do número de fatores	1342
15.15.5	Matriz reproduzida e resíduos	1343
15.15.6	CrITÉRIOS de rotação como problemas de otimização	1346
15.15.7	Interpretação e reespecificação da solução	1349
15.15.8	CrITÉRIOS e propriedades dos métodos de escores fatoriais	1349
15.15.9	Diferentes métodos de escores fatoriais	1353
15.15.10	Estabilidade e validação da solução	1354
15.15.11	Correspondência com a implementação utilizada	1355
15.16	Síntese	1357
16	Formulação da Análise de Agrupamentos	1360
16.1	O problema de formação de grupos	1361
16.2	Representação dos objetos e proximidade	1361
16.3	Dissimilaridades entre objetos	1363
16.3.1	Efeito da escala	1364
16.4	Partições	1365
16.5	Homogeneidade interna e separação	1367
16.6	Centroides e dispersão quadrática	1367
16.6.1	Dispersão intragrupos e entre grupos	1368
16.6.2	Formulação das K -médias	1369
16.6.3	Partição para centros fixados	1371
16.7	Estrutura dos métodos hierárquicos	1373
16.7.1	Ligações simples, completa e média	1374
16.7.2	Método de Ward e dispersão intragrupos	1376
16.7.3	Dendrograma e níveis de fusão	1377
16.7.4	Uma partição e uma hierarquia representam objetos diferentes	1380
16.8	Dependência da solução e limites da formulação	1381
16.9	Limites da interpretação dos grupos	1382
16.10	Relações com outras técnicas multivariadas	1382
16.10.1	Agrupamentos e ACP	1383
16.10.2	Agrupamentos e Análise Discriminante	1383
16.10.3	Agrupamentos e MANOVA	1384
16.11	Aprofundamentos teóricos	1384
16.11.1	O centroide como minimizador	1384
16.11.2	Derivação do incremento de Ward	1385
16.11.3	Empates e não unicidade da hierarquia	1385

16.12	Aprofundamentos metodológicos e aplicados	1385
16.12.1	Preparação da representação para o agrupamento	1386
16.12.2	Dados mistos e dissimilaridade de Gower	1388
16.12.3	Escolha da medida de proximidade e do procedimento	1388
16.12.4	Escolha do número de grupos	1390
16.12.5	Algoritmo das K -médias	1392
16.12.6	Estabilidade, validação e perfil dos grupos	1393
16.12.7	Correspondência com a implementação utilizada	1396
16.13	Síntese	1400
17	Formulação da Análise de Correspondência	1403
17.1	O problema de associação em uma tabela de contingência	1404
17.2	Massas e perfis	1405
17.2.1	Distribuições condicionais observadas	1407
17.2.2	Independência como referência	1409
17.3	Geometria dos perfis	1410
17.4	Inércia e afastamento da independência	1412
17.5	Padronização dos desvios da independência	1414
17.5.1	Inércia como norma matricial	1415
17.6	Relação algébrica com a estatística de Pearson	1416
17.7	Formulação pela decomposição em valores singulares	1417
17.7.1	Decomposição da inércia	1418
17.7.2	Representação em dimensão reduzida	1420
17.8	Coordenadas da Análise de Correspondência	1422
17.8.1	Sistema de coordenadas padrão	1422
17.8.2	Sistema de coordenadas principais	1423
17.8.3	Distâncias entre perfis e coordenadas principais	1425
17.9	Representação conjunta de linhas e colunas	1426
17.9.1	O significado das proximidades	1426
17.10	Formulação descritiva e relação com a inferência	1427
17.11	Relação com a Análise de Componentes Principais	1433
17.12	Condições e limites da representação	1434
17.12.1	Massas positivas e frequências nulas	1434
17.12.2	Composição da tabela e generalização	1435
17.12.3	Dimensão da representação	1435
17.12.4	Sinais e orientação	1435
17.12.5	Limites da interpretação	1436
17.13	Aprofundamentos teóricos	1436
17.13.1	Limite do posto da matriz de desvios padronizados	1436
17.13.2	Não unicidade dos eixos e dos subespaços representados	1438
17.13.3	Centralização ponderada das coordenadas padrão e principais	1439
17.13.4	Reconstrução dos desvios da independência	1439
17.13.5	Decomposição da estatística de Pearson pelas dimensões	1441

17.13.6	Formulação probabilística e teste de independência	1441
17.14	Aprofundamentos metodológicos e aplicados	1443
17.14.1	Definição da tabela e exame das categorias	1444
17.14.2	Relação com o teste global de independência	1444
17.14.3	Escolha do número de dimensões	1444
17.14.4	Leitura da representação reduzida	1445
17.14.5	Sensibilidade e validação da interpretação	1447
17.14.6	Análise de Correspondência Múltipla	1447
17.14.7	Correspondência com a implementação utilizada	1447
17.15	Síntese	1448
18	Formulação da MANOVA	1451
18.1	O problema de comparação multivariada	1452
18.2	A hipótese no modelo linear multivariado	1453
18.2.1	SQPC da hipótese e SQPC residual	1454
18.3	Hipótese e erro em uma combinação linear das respostas	1456
18.4	Problema espectral da MANOVA	1457
18.4.1	Padronização pela SQPC residual e interpretação geométrica	1459
18.5	Critérios multivariados	1463
18.6	Quatro critérios como funções das raízes características	1467
18.6.1	Uso inferencial dos critérios	1468
18.7	Pressupostos e limites	1469
18.7.1	Estrutura da média e estimabilidade	1469
18.7.2	Independência entre unidades	1470
18.7.3	Covariância residual comum	1470
18.7.4	Não singularidade populacional e amostral	1470
18.7.5	Normalidade multivariada	1472
18.7.6	Associação residual, condicionamento e singularidade	1473
18.8	Relações com outras técnicas	1473
18.8.1	ANOVA	1473
18.8.2	T^2 de Hotelling	1474
18.8.3	Regressão multivariada	1475
18.8.4	Análise Discriminante	1475
18.9	Aprofundamentos teóricos	1476
18.9.1	Distribuições Wishart de hipótese e erro sob H_0	1476
18.9.2	Calibração inferencial dos critérios	1479
18.9.3	Invariância a transformações lineares não singulares das respostas	1480
18.9.4	Posto, sinais e multiplicidades das direções	1483
18.10	Aprofundamentos metodológicos e aplicados	1484
18.10.1	Tamanho das células e balanceamento	1484
18.10.2	Avaliação da homogeneidade das matrizes de covariâncias	1485
18.10.3	Observações atípicas e influência	1485
18.10.4	Escolha e interpretação do critério multivariado	1486

18.10.5 Avaliação das respostas após o teste global	1486
18.10.6 Contrastes e comparações posteriores	1487
18.10.7 MANOVA fatorial e MANCOVA	1488
18.10.8 Validação dos resultados	1490
18.10.9 Correspondência com a implementação utilizada	1491
18.11 Síntese	1494
19 Formulação da Análise Discriminante	1496
19.1 O problema de discriminação e classificação	1497
19.2 Classificação como problema de decisão	1498
19.2.1 Probabilidades <i>a priori</i> e <i>a posteriori</i>	1498
19.2.2 Regra de Bayes sob perda zero-um	1499
19.3 Discriminação linear sob normalidade (LDA)	1502
19.3.1 Fronteiras e distância de Mahalanobis	1503
19.4 Discriminação quadrática (QDA)	1505
19.4.1 Fronteiras e comparação com a LDA	1506
19.5 Da regra populacional à regra estimada	1507
19.5.1 Covariância comum na LDA	1509
19.5.2 Probabilidades <i>a priori</i>	1510
19.5.3 Regra estimada da LDA	1510
19.5.4 Regra estimada da QDA	1512
19.6 Formulação geométrica de Fisher	1513
19.6.1 Dispersões populacionais dentro e entre grupos	1513
19.6.2 Dispersões projetadas	1515
19.7 Formulação amostral de Fisher	1516
19.8 Direções discriminantes e autovalores generalizados	1519
19.8.1 Geometria pela dispersão intragrupos	1520
19.8.2 Número de direções discriminantes	1523
19.9 Representação no subespaço discriminante	1524
19.10 Relação espectral com a MANOVA	1526
19.11 Dois grupos e relação entre Fisher e LDA	1527
19.11.1 Formulação populacional para dois grupos	1529
19.11.2 Mais de dois grupos	1530
19.12 Pressupostos e limites	1531
19.12.1 Grupos previamente definidos	1532
19.12.2 Normalidade e estrutura das covariâncias	1532
19.12.3 Não singularidade e dimensão	1533
19.12.4 Independência das unidades de treinamento	1535
19.12.5 Probabilidades <i>a priori</i> e perdas	1536
19.12.6 Sobreposição entre as classes	1536
19.13 Relações com outras técnicas	1537
19.13.1 Análise de Componentes Principais	1537
19.13.2 Análise de Agrupamentos	1538

19.14	Aprofundamentos teóricos	1538
19.14.1	Perdas e risco de classificação	1539
19.14.2	Erro de classificação e separação de Mahalanobis	1541
19.14.3	Forma explícita da fronteira quadrática	1544
19.14.4	Decomposição da covariância por grupos	1545
19.14.5	Relação com a discriminação linear normal	1545
19.14.6	Relação amostral entre Fisher e LDA	1547
19.14.7	Identificação das direções discriminantes	1548
19.15	Aprofundamentos metodológicos e aplicados	1549
19.15.1	Definição das probabilidades <i>a priori</i> e consequências dos erros	1549
19.15.2	Avaliação das condições da análise	1550
19.15.3	Tamanho amostral e estabilidade das estimativas	1550
19.15.4	Escolha entre LDA e QDA	1551
19.15.5	Importância e avaliação das funções discriminantes de Fisher	1552
19.15.6	Coefficientes das funções discriminantes de Fisher	1553
19.15.7	Centroides e interpretação dos grupos	1555
19.15.8	Erro aparente e erro em novas observações	1556
19.15.9	Matriz de classificação e desempenho por classe	1557
19.15.10	Casos classificados incorretamente	1558
19.15.11	Correspondência com a implementação utilizada	1559
19.16	Síntese	1562
Exercícios de fixação do Módulo III		1565
Parte I — Núcleo		1566
Parte II — Aprofundamentos teóricos		1574
Parte III — Aprofundamentos metodológicos e aplicados		1582
Referências		1591

Informações Legais e Declaração de Uso de Inteligência Artificial

Direitos Autorais e Uso da Obra

© 2026 — Os autores.

Todos os direitos reservados. Esta obra é protegida pela legislação brasileira de direitos autorais (Lei nº 9.610/1998). É vedada a reprodução, distribuição, armazenamento ou transmissão total ou parcial deste livro, por qualquer meio ou processo, eletrônico ou mecânico, sem autorização expressa e por escrito dos autores, salvo nos casos permitidos pela legislação vigente para fins exclusivamente acadêmicos e não comerciais, com a devida citação da fonte.

A utilização do material em ambientes de ensino é permitida desde que preservada a integridade do conteúdo, mencionada a autoria e respeitados os princípios de uso responsável da informação científica. A reprodução para fins comerciais, bem como a modificação substancial do conteúdo sem autorização, constitui violação de direitos autorais.

Declaração sobre o Uso de Ferramentas de Inteligência Artificial

Durante a elaboração deste livro foram utilizadas ferramentas de Inteligência Artificial, em especial sistemas de apoio à escrita e organização textual, como recurso complementar no processo de produção acadêmica.

O uso de IA teve caráter **estritamente assistivo**, não substituindo o desenvolvimento conceitual, a formulação matemática, a interpretação estatística nem as decisões pedagógicas da obra. Todo conteúdo foi cuidadosamente revisado, validado e adaptado pelos autores, que assumem integral responsabilidade científica e intelectual pelo texto final.

Não foram delegadas à IA decisões metodológicas, inferenciais ou conclusões analíticas. A elaboração teórica, a seleção de exemplos, a validação matemática e a coerência didática resultam da experiência acadêmica e da atuação dos autores na área de Modelos de Regressão.

Reafirmamos que o uso responsável de tecnologias emergentes deve sempre preservar o rigor científico, a integridade acadêmica e o protagonismo intelectual humano.

Prefácio

Este livro foi elaborado como material de apoio ao estudo da Análise Multivariada no curso de Bacharelado em Estatística da Universidade Federal do Ceará.

A Análise Multivariada costuma ser apresentada por meio de um conjunto de métodos com finalidades distintas, como reduzir a dimensionalidade, identificar estruturas latentes, formar grupos, representar associações, comparar vetores de médias ou classificar observações. Quando essas técnicas são estudadas isoladamente, pode ser difícil perceber que muitas delas compartilham os mesmos objetos e operações: vetores e matrizes, combinações lineares, projeções, formas quadráticas, matrizes de covariâncias, decomposições espectrais, valores singulares, distâncias e modelos probabilísticos. Técnicas diferentes podem ainda ser aplicadas a um mesmo conjunto de dados e produzir representações distintas ou complementares, pois cada uma privilegia um aspecto específico da estrutura multivariada.

O livro foi organizado para tornar essas relações explícitas. O **Módulo I** apresenta os fundamentos matemáticos e geométricos necessários à representação e à transformação dos dados multivariados. O **Módulo II** desenvolve os fundamentos probabilísticos e inferenciais, incluindo matrizes de covariâncias e correlações, distribuição normal multivariada, estatísticas amostrais, estimação, modelo linear e inferência. O **Módulo III** mostra como esses resultados são combinados na formulação matemática e estatística das principais técnicas multivariadas.

A exposição busca equilibrar rigor e interpretação. As definições e propriedades são acompanhadas, sempre que possível, por representações geométricas, exemplos numéricos e conexões com os problemas estatísticos que motivam cada resultado. As demonstrações são incluídas quando contribuem diretamente para a compreensão da estrutura dos métodos; resultados mais especializados são apresentados de forma compatível com os objetivos de uma disciplina de graduação.

As técnicas são inicialmente estudadas a partir do problema que procuram resolver, dos dados que utilizam e dos objetos matemáticos que definem sua solução. A formulação conceitual e matemática orienta a interpretação dos resultados e o uso dos procedimentos computacionais. Essa organização permite compreender por que cada técnica assume determinada forma, que tipo de informação preserva ou modela e quais fundamentos sustentam sua utilização e interpretação.

O **jamovi** é utilizado nas aplicações das técnicas multivariadas, enquanto o ambiente **R** e o sistema **Quarto** apoiam a produção de exemplos, figuras e do próprio livro. A implementação computacional é relacionada explicitamente à formulação estatística apresentada, permitindo

interpretar as opções e as saídas do software sem substituir o desenvolvimento matemático e conceitual dos métodos.

Identificação da Disciplina

Curso: Bacharelado em Estatística

Disciplina: Análise Multivariada

Carga Horária: 96 horas

Período Letivo: 2026.2

Professores: Dr. Rafael Bráz Azevedo Farias e Dra. Alessandra Cristina da Silva Farias

EMENTA

Fundamentos matemáticos, geométricos, probabilísticos e inferenciais da Análise Multivariada. Representação vetorial e matricial dos dados, espaços vetoriais, projeções, transformações lineares, decomposição espectral e decomposição em valores singulares. Matrizes de covariâncias e correlações, distribuição normal multivariada, estatísticas amostrais, estimação, modelo linear e inferência multivariada. Formulação matemática e estatística das principais técnicas multivariadas.

OBJETIVO GERAL

Compreender os fundamentos matemáticos, geométricos, probabilísticos e estatísticos que sustentam a Análise Multivariada e reconhecer como esses fundamentos são utilizados na formulação, na aplicação e na interpretação das principais técnicas multivariadas.

OBJETIVOS ESPECÍFICOS

Ao final da disciplina, o estudante deverá ser capaz de:

- representar dados multivariados por meio de vetores e matrizes;
- interpretar geometricamente observações, variáveis, distâncias, projeções e transformações;

- compreender o papel de autovalores, autovetores, decomposição espectral e decomposição em valores singulares;
- analisar a estrutura de matrizes de covariâncias e correlações;
- compreender os fundamentos da distribuição normal multivariada, da estimação e da inferência;
- identificar o problema estatístico e selecionar a técnica multivariada de acordo com o objetivo da análise e a natureza dos dados;
- relacionar cada técnica aos seus objetos matemáticos, critérios de otimização ou modelos probabilísticos;
- distinguir técnicas de redução de dimensionalidade, representação de estruturas latentes, agrupamento, associação, comparação e classificação;
- conduzir análises multivariadas com apoio computacional;
- interpretar criticamente os resultados e comunicar conclusões compatíveis com os dados e com os pressupostos adotados.

CONTEÚDO PROGRAMÁTICO

Módulo I – Fundamentos Matemáticos e Geométricos da Análise Multivariada

Vetores e representação dos dados multivariados

Álgebra matricial aplicada

Espaços vetoriais, bases e projeções

Transformações lineares

Autovalores, autovetores e decomposição espectral

Decomposição em valores singulares

Cálculo diferencial, integral e matricial aplicado à Estatística Multivariada

Módulo II – Fundamentos Probabilísticos e Inferenciais da Análise Multivariada

Matrizes de covariâncias e correlações

Distribuição normal multivariada

Estatísticas amostrais e estimação

Modelo linear multivariado e hipóteses lineares

Inferência multivariada

Módulo III – Formulação Matemática e Estatística das Técnicas Multivariadas

Problemas e estruturas das técnicas multivariadas

Análise de Componentes Principais

Análise Fatorial

Análise de Agrupamentos
Análise de Correspondência
Análise Multivariada de Variância
Análise Discriminante

METODOLOGIA

A disciplina será desenvolvida por meio de aulas expositivo-dialogadas, atividades práticas em laboratório e exercícios de interpretação. Os fundamentos matemáticos, probabilísticos e inferenciais serão articulados à formulação e à aplicação das técnicas multivariadas.

Serão utilizados exemplos numéricos, representações geométricas, demonstrações selecionadas e conjuntos de dados reais ou simulados. A parte computacional será conduzida de modo a apoiar a compreensão dos métodos, a avaliação dos pressupostos e a interpretação dos resultados, mantendo explícita a relação entre a formulação estatística e a implementação utilizada.

AValiação

As avaliações contemplarão os fundamentos teóricos, a condução das análises e a interpretação dos resultados. Poderão ser utilizadas provas escritas, avaliações práticas em laboratório, exercícios e outras atividades definidas no plano de ensino da disciplina.

A aprovação seguirá as normas vigentes da Universidade Federal do Ceará.

CRITÉRIOS DE AVALIAÇÃO

Serão considerados:

- correção matemática e estatística;
- domínio conceitual;
- adequação das decisões metodológicas;
- interpretação dos resultados no contexto do problema;
- clareza e organização da exposição escrita;
- qualidade e reprodutibilidade das análises computacionais.

BIBLIOGRAFIA BÁSICA

ANDERSON, T. W.

An Introduction to Multivariate Statistical Analysis. 3rd ed. Wiley, 2003. (Anderson, 2003)

ARTES, R.; BARROSO, L. P.; PAULA, G. A.

Métodos Multivariados de Análise Estatística. (Artes; Barroso, 2023)

HAIR, J. F. et al.

Multivariate Data Analysis. (Hair et al., 2019)

BIBLIOGRAFIA COMPLEMENTAR

ARTES, R.; BARROSO, L. P.; PAULA, G. A.

Métodos Multivariados de Análise Estatística. (Artes; Barroso, 2023)

JOHNSON, R. A.; WICHERN, D. W.

Applied Multivariate Statistical Analysis. 6th ed. Pearson, 2007. (Johnson; Wichern, 2007)

MANLY, B. F. J.; ALBERTO, J. A. N.

Métodos Estatísticos Multivariados: Uma Introdução. (Manly; Navarro Alberto, 2019)

MARDIA, K. V.; KENT, J. T.; TAYLOR, C. C.

Multivariate Analysis. (Mardia; Kent; Taylor, 2024)

MINGOTI, S. A.

Análise de Dados Através de Métodos de Estatística Multivariada: Uma Abordagem Aplicada. Belo Horizonte: Editora UFMG, 2005. (Mingoti, 2005)

RENCER, A. C.; CHRISTENSEN, W. F.

Methods of Multivariate Analysis. (Rencher; Christensen, 2012)

Parte I

Módulo I — Fundamentos Matemáticos e Geométricos da Análise Multivariada

1 Vetores e representação dos dados multivariados

Em estudos multivariados, cada unidade observacional é descrita por várias características registradas simultaneamente. Quando são observadas p variáveis quantitativas, esses valores podem ser organizados em um vetor de $\mathbb{R}^p$.

Para n unidades, os vetores formam uma matriz de dados de dimensão $n \times p$, na qual as linhas representam as observações e as colunas representam as variáveis.

Essa representação permite interpretar as observações como pontos em um espaço multidimensional e estudar suas relações por meio de operações vetoriais e conceitos geométricos.

Convenções gerais de notação

Adotam-se as seguintes convenções de notação:

- letras minúsculas sem negrito, como a , x e α , representam escalares;
- letras minúsculas em negrito, como $\mathbf{x}$ e $\mathbf{y}$, representam vetores observados;
- letras maiúsculas em negrito, como $\mathbf{A}$ e $\mathbf{X}$, representam matrizes;
- letras maiúsculas sem negrito, como X , representam variáveis aleatórias escalares;
- o vetor aleatório multivariado será representado por $\mathbf{X}$;
- a realização observada de $\mathbf{X}$ será representada por $\mathbf{x}$;
- o elemento situado na posição i de um vetor será indicado por x_i ;
- o elemento situado na linha i e na coluna j de uma matriz será indicado por a_{ij} ;
- a i -ésima linha de uma matriz $\mathbf{A}$ será representada por $\mathbf{a}_i^\top$;
- a j -ésima coluna de uma matriz $\mathbf{A}$ será representada por $\mathbf{a}_{.j}$;
- quando não houver ambiguidade, $\mathbf{a}_i^\top$ poderá ser utilizada como forma abreviada de $\mathbf{a}_{i.}^\top$;
- o vetor-coluna associado à i -ésima linha será representado por $\mathbf{a}_i \in \mathbb{R}^p$;
- o ponto na notação matricial indica o índice que varia;
- $\mathbb{R}^p$ representa o espaço dos vetores reais com p componentes;
- $\mathbb{R}^{n \times p}$ representa o conjunto das matrizes reais com n linhas e p colunas;
- o símbolo $\top$ indica transposição;
- $\mathbf{0}$ representa um vetor ou uma matriz nula, com dimensão determinada pelo contexto.

Para a matriz de dados $\mathbf{X}$, será adotada a mesma convenção para as linhas: $\mathbf{x}_i \in \mathbb{R}^p$

representa a observação i , $\mathbf{x}_i^\top$ representa essa observação como a i -ésima linha de $\mathbf{X}$ e $\mathbf{x}_{:,j} \in \mathbb{R}^n$ representa a coluna correspondente à variável j . Quando houver risco de ambiguidade, a dimensão será indicada explicitamente.

1.1 Escalares, vetores e matrizes

Em uma análise univariada, cada observação é representada pelo valor de uma única variável. Quando várias variáveis são medidas na mesma unidade observacional, seus valores podem ser organizados em um vetor. Os vetores de todas as unidades formam uma matriz de dados.

Definição 1.1 (Escalar). Um **escalar** é um número real:

$$a \in \mathbb{R}.$$

Em uma aplicação estatística, um escalar pode representar uma medida observada ou o coeficiente de uma expressão matemática.

Em Estatística, uma variável aleatória escalar será representada por uma letra maiúscula, como X . Uma realização dessa variável será representada pela letra minúscula correspondente:

$$x \in \mathbb{R}.$$

Por exemplo, X pode representar a massa de uma unidade selecionada aleatoriamente, enquanto $x = 65$ representa um valor observado.

Definição 1.2 (Vetor aleatório e vetor observado). Um **vetor aleatório** de dimensão p é uma coleção ordenada de p variáveis aleatórias:

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix} = (X_1, X_2, \dots, X_p)^\top.$$

Uma realização de $\mathbf{X}$ é representada pelo vetor observado

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix} = (x_1, x_2, \dots, x_p)^\top \in \mathbb{R}^p.$$

Cada componente x_j corresponde ao valor observado da variável j , para $j = 1, \dots, p$. (Anderson, 2003)

Exemplo 1.1 (Representação de uma observação). Considere uma unidade descrita por três variáveis:

- X_1 : idade, em anos;
- X_2 : massa corporal, em quilogramas;
- X_3 : altura, em centímetros.

O vetor aleatório é

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix}.$$

Para uma unidade com 52 anos, 74 quilogramas e 168 centímetros de altura, o vetor observado é

$$\mathbf{x} = \begin{bmatrix} 52 \\ 74 \\ 168 \end{bmatrix}.$$

A ordem das componentes identifica a correspondência entre valores e variáveis. Assim,

$$\begin{bmatrix} 52 \\ 74 \\ 168 \end{bmatrix} \neq \begin{bmatrix} 74 \\ 52 \\ 168 \end{bmatrix}$$

O primeiro vetor representa uma unidade com 52 anos, 74 quilogramas e 168 centímetros de altura. O segundo representa uma unidade com 74 anos, 52 quilogramas e 168 centímetros de altura.

Nesse exemplo, o vetor organiza as medidas observadas. A comparação geométrica de variáveis com unidades diferentes exige atenção às escalas.

Dois vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ são iguais quando suas componentes correspondentes são iguais:

$$\mathbf{x} = \mathbf{y} \iff x_j = y_j, \quad j = 1, \dots, p.$$

Definição 1.3 (Matriz). Uma **matriz** com n linhas e p colunas é um arranjo retangular de números:

$$\mathbf{A} = (a_{ij})_{n \times p} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1p} \\ a_{21} & a_{22} & \cdots & a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

O elemento a_{ij} ocupa a linha i e a coluna j .

A dimensão de $\mathbf{A}$ é $n \times p$. O primeiro número indica a quantidade de linhas, e o segundo indica a quantidade de colunas.

Para a matriz $\mathbf{A}$ definida anteriormente, a i -ésima linha é o vetor-linha

$$\mathbf{a}_{i.}^\top = [a_{i1} \quad a_{i2} \quad \cdots \quad a_{ip}] \in \mathbb{R}^{1 \times p},$$

enquanto a j -ésima coluna é o vetor-coluna

$$\mathbf{a}_{.j} = \begin{bmatrix} a_{1j} \\ a_{2j} \\ \vdots \\ a_{nj} \end{bmatrix} \in \mathbb{R}^{n \times 1}.$$

O ponto na notação indica o índice que varia. Assim:

- em $\mathbf{a}_{i.}^\top$, a linha i permanece fixa e o índice das colunas varia;
- em $\mathbf{a}_{.j}$, a coluna j permanece fixa e o índice das linhas varia.

Notação abreviada para linhas

Quando não houver risco de ambiguidade, a notação das linhas da matriz $\mathbf{A}$ poderá ser simplificada. Em particular, o vetor associado à i -ésima linha será representado por

$$\mathbf{a}_i \in \mathbb{R}^p,$$

de modo que a i -ésima linha da matriz poderá ser escrita como

$$\mathbf{a}_i^\top = \mathbf{a}_{i.}^\top.$$

A notação com ponto será utilizada quando for necessário distinguir explicitamente linhas e colunas da mesma matriz.

Essa convenção será especialmente útil para a matriz de dados $\mathbf{X}$, em que $\mathbf{x}_i \in \mathbb{R}^p$ representa a i -ésima observação e $\mathbf{x}_{i.}^\top$ representa essa observação como a i -ésima linha de

X. As colunas permanecerão representadas explicitamente por $\mathbf{x}_{.j}$.

Com essas convenções, a matriz pode ser representada por suas linhas,

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_{1.}^\top \\ \mathbf{a}_{2.}^\top \\ \vdots \\ \mathbf{a}_{n.}^\top \end{bmatrix} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_n^\top \end{bmatrix},$$

ou por suas colunas,

$$\mathbf{A} = [\mathbf{a}_{.1} \ \mathbf{a}_{.2} \ \cdots \ \mathbf{a}_{.p}].$$

1.1.1 Vetor-coluna, vetor-linha e transposição

Definição 1.4 (Vetor-coluna, vetor-linha e transposição). Um vetor-coluna com p componentes pode ser tratado como uma matriz de dimensão $p \times 1$:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix} \in \mathbb{R}^{p \times 1}.$$

A **transposição** é a operação que troca as linhas de uma matriz por suas colunas e é indicada pelo símbolo $\top$.

A transposta do vetor-coluna $\mathbf{x}$ é o vetor-linha

$$\mathbf{x}^\top = [x_1 \ x_2 \ \cdots \ x_p] \in \mathbb{R}^{1 \times p}.$$

Portanto,

$$\mathbf{x} \in \mathbb{R}^{p \times 1} \quad \implies \quad \mathbf{x}^\top \in \mathbb{R}^{1 \times p}.$$

A Tabela 1.1 resume a notação utilizada no capítulo.

Tabela 1.1: Notação utilizada para escalares, vetores e matrizes.

Objeto	Notação	Descrição
Escalar	a	Número real
Variável aleatória escalar	X	Variável que assume valores em $\mathbb{R}$
Realização escalar	x	Valor observado de X
Vetor aleatório	$\mathbf{X}$	Coleção ordenada de variáveis aleatórias
Vetor observado	$\mathbf{x}$	Realização de um vetor aleatório
Matriz genérica	$\mathbf{A}$	Arranjo retangular de números
Linha i de uma matriz	$\mathbf{a}_i^\top$ ou $\mathbf{a}_i^\top$	Vetor-linha formado pelos elementos da linha i de $\mathbf{A}$
Coluna j de uma matriz	$\mathbf{a}_{\cdot j}$	Vetor-coluna formado pelos elementos da coluna j de $\mathbf{A}$
Matriz de dados	$\mathbf{X}$	Matriz observada com linhas e colunas associadas às unidades e às variáveis

Um escalar representa uma medida, um vetor reúne as medidas de uma unidade e uma matriz organiza os valores de várias unidades. Antes de utilizar essas representações geometricamente, é necessário distinguir a natureza das variáveis que fornecem suas componentes.

1.2 Natureza das variáveis e representação

A representação de uma observação como ponto em $\mathbb{R}^p$ pressupõe que suas coordenadas sejam valores numéricos para os quais as operações utilizadas na geometria tenham significado compatível com as variáveis analisadas.

Uma **variável quantitativa** assume valores numéricos que representam quantidades. Ela pode ser discreta, quando seus valores pertencem a um conjunto enumerável, ou contínua, quando pode assumir valores em um intervalo da reta real. Em ambos os casos, seus valores observados podem ser representados por números reais e utilizados como coordenadas quando essa representação for adequada ao problema.

Uma **variável categórica** registra a categoria à qual pertence uma unidade. Em uma variável **nominal**, as categorias não possuem uma ordenação intrínseca. Em uma variável **ordinal**, as categorias possuem uma ordenação, mas as diferenças entre posições sucessivas não representam necessariamente distâncias de mesma magnitude. Uma variável binária constitui um caso particular de variável categórica com duas categorias.

A atribuição de códigos numéricos a categorias não modifica a natureza da variável. Se três categorias nominais forem codificadas por 1, 2 e 3, por exemplo, as diferenças entre esses números não passam a representar automaticamente distâncias entre as categorias. Para uma

variável ordinal, uma codificação numérica pode preservar a ordenação, mas não implica que a diferença entre categorias consecutivas possua significado quantitativo.

Essa distinção também deve ser preservada na organização computacional dos dados. Uma coluna armazenada por números inteiros pode representar uma medida quantitativa, uma variável ordinal ou apenas códigos de categorias nominais. O significado estatístico da coluna é determinado pela variável e por sua escala de mensuração, e não pelo formato numérico utilizado para armazená-la.

A representação direta de uma observação como vetor de $\mathbb{R}^p$ será utilizada para variáveis quantitativas, salvo indicação explícita em contrário. Variáveis categóricas e conjuntos de dados mistos requerem representações compatíveis com a natureza das variáveis e com a técnica utilizada.

1.3 O espaço $\mathbb{R}^p$

Considerando p variáveis quantitativas, os valores observados em uma unidade podem ser organizados em um vetor com p componentes reais. O conjunto de todos os vetores desse tipo é denotado por $\mathbb{R}^p$.

Definição 1.5 (Espaço $\mathbb{R}^p$). O espaço $\mathbb{R}^p$ é o conjunto

$$\mathbb{R}^p = \{(x_1, x_2, \dots, x_p)^\top : x_j \in \mathbb{R}, j = 1, \dots, p\}.$$

Cada elemento de $\mathbb{R}^p$ é um vetor formado por p componentes reais.

Uma observação descrita por p variáveis pode ser representada por

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{bmatrix} \in \mathbb{R}^p,$$

em que x_{ij} é o valor da variável j observado na unidade i .

As unidades observacionais são representadas como pontos de $\mathbb{R}^p$, com uma coordenada para cada uma das p variáveis (Anderson, 2003). A notação $\mathbb{R}^p$ identifica explicitamente o espaço ambiente dessa representação.

A dimensão do espaço é determinada pelo número de variáveis:

- para $p = 1$, cada observação possui uma componente;
- para $p = 2$, cada observação possui duas componentes;

- para $p = 3$, cada observação possui três componentes;
- para $p > 3$, a representação permanece definida em $\mathbb{R}^p$, embora não possa ser visualizada diretamente em sua totalidade.

A Figura 1.1 apresenta os três casos que podem ser representados graficamente.




Figura 1.1: Representação de observações em espaços de uma, duas e três dimensões.

Exemplo 1.2 (Observação em duas dimensões). Considere duas variáveis quantitativas, X_1 e X_2 . A observação i é representada por

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \end{bmatrix} \in \mathbb{R}^2.$$

Se $x_{i1} = 3$ e $x_{i2} = 5$, então

$$\mathbf{x}_i = \begin{bmatrix} 3 \\ 5 \end{bmatrix}.$$

Esse vetor pode ser representado por uma seta que parte da origem e termina no ponto de coordenadas $(3, 5)$, como mostra a Figura 1.2.

A extremidade da seta determina o ponto $(3, 5)$. Assim, o vetor $\mathbf{x}_i$ pode ser interpretado geometricamente como uma seta com origem em $(0, 0)$ e extremidade em $(3, 5)$.

O número de observações e o número de variáveis possuem funções distintas. Para um conjunto com n observações e p variáveis:




Figura 1.2: Representação do vetor $\mathbf{x}_i = (3, 5)^\top$ no plano.

- n determina a quantidade de pontos;
- p determina a dimensão do espaço ambiente.

As n observações formam uma nuvem de pontos em $\mathbb{R}^p$.

1.4 Representação matricial de um conjunto de dados

Considere n unidades observacionais descritas pelas mesmas p variáveis quantitativas. A observação i é representada pelo vetor

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{bmatrix} \in \mathbb{R}^p, \quad i = 1, \dots, n.$$

Cada componente x_{ij} corresponde ao valor da variável j observado na unidade i . Os n vetores observados podem ser organizados nas linhas de uma matriz.

Definição 1.6 (Matriz de dados). A **matriz de dados** de n observações e p variáveis é definida por

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

O elemento x_{ij} representa o valor da variável j observado na unidade i .

As linhas da matriz correspondem às observações, e as colunas correspondem às variáveis. Essa organização coincide com a estrutura usual de uma planilha ou de um banco de dados. (Gentle, 2017)

Com a notação estabelecida anteriormente, a matriz de dados pode ser representada por suas linhas como

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix},$$

ou por suas colunas como

$$\mathbf{X} = [\mathbf{x}_{.1} \ \mathbf{x}_{.2} \ \cdots \ \mathbf{x}_{.p}] .$$

Exemplo 1.3 (Matriz de dados com duas variáveis). Considere quatro unidades observacionais descritas pelas variáveis X_1 e X_2 . Os vetores observados são

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 5 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} 3 \\ 1 \end{bmatrix},$$

$$\mathbf{x}_3 = \begin{bmatrix} 5 \\ 7 \end{bmatrix}, \quad \mathbf{x}_4 = \begin{bmatrix} 8 \\ 3 \end{bmatrix}.$$

A matriz de dados é

$$\mathbf{X} = \begin{bmatrix} 1 & 5 \\ 3 & 1 \\ 5 & 7 \\ 8 & 3 \end{bmatrix} \in \mathbb{R}^{4 \times 2}.$$

A terceira observação é

$$\mathbf{x}_3 = \begin{bmatrix} 5 \\ 7 \end{bmatrix},$$

e aparece na matriz como a terceira linha,

$$\mathbf{x}_3^\top = [5 \quad 7] .$$

O elemento

$$x_{32} = 7$$

é o valor da segunda variável observado na terceira unidade.

1.4.1 Representações por linhas e por colunas

A organização da matriz de dados permite considerar dois conjuntos de vetores.

Pelas linhas,

$$\mathbf{x}_i \in \mathbb{R}^p, \quad i = 1, \dots, n,$$

cada vetor representa uma observação descrita pelas p variáveis.

Pelas colunas,

$$\mathbf{x}_{\cdot j} \in \mathbb{R}^n, \quad j = 1, \dots, p,$$

cada vetor representa uma variável observada nas n unidades.

Na representação por linhas, cada unidade observacional é representada por um ponto em $\mathbb{R}^p$, cujas coordenadas correspondem às p variáveis.

Na representação por colunas, cada variável é representada por um vetor em $\mathbb{R}^n$, cujas componentes correspondem às n unidades observacionais.

A Tabela 1.2 resume essas duas representações.

Tabela 1.2: Representações da matriz de dados por linhas e colunas.

Representação	Vetor	Objeto representado	Espaço	Quantidade
Linhas de $\mathbf{X}$	$\mathbf{x}_i$	Observação i	$\mathbb{R}^p$	n vetores
Colunas de $\mathbf{X}$	$\mathbf{x}_{\cdot j}$	Variável j	$\mathbb{R}^n$	p vetores

A interpretação utilizada depende do objeto de interesse. Relações entre unidades observacionais são estudadas a partir das linhas da matriz, enquanto relações entre variáveis são estudadas a partir de suas colunas.

1.5 Operações elementares com vetores

Considere os vetores

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_p \end{bmatrix} \in \mathbb{R}^p$$

e um escalar $\alpha \in \mathbb{R}$.

Dois vetores são iguais quando suas componentes correspondentes são iguais:

$$\mathbf{x} = \mathbf{y} \iff x_j = y_j, \quad j = 1, \dots, p.$$

1.5.1 Soma e subtração

A soma de dois vetores é realizada componente a componente:

$$\mathbf{x} + \mathbf{y} = \begin{bmatrix} x_1 + y_1 \\ x_2 + y_2 \\ \vdots \\ x_p + y_p \end{bmatrix} \in \mathbb{R}^p.$$

A diferença também é calculada componente a componente:

$$\mathbf{x} - \mathbf{y} = \begin{bmatrix} x_1 - y_1 \\ x_2 - y_2 \\ \vdots \\ x_p - y_p \end{bmatrix} \in \mathbb{R}^p.$$

O vetor $\mathbf{x} - \mathbf{y}$ representa o deslocamento de $\mathbf{y}$ até $\mathbf{x}$.

Exemplo 1.4 (Soma e subtração de vetores). Considere

$$\mathbf{x} = \begin{bmatrix} 2,0 \\ 1,5 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 1,0 \\ 3,0 \end{bmatrix}.$$

A soma é

$$\mathbf{x} + \mathbf{y} = \begin{bmatrix} 2,0 + 1,0 \\ 1,5 + 3,0 \end{bmatrix} = \begin{bmatrix} 3,0 \\ 4,5 \end{bmatrix}.$$

A diferença é

$$\mathbf{x} - \mathbf{y} = \begin{bmatrix} 2,0 - 1,0 \\ 1,5 - 3,0 \end{bmatrix} = \begin{bmatrix} 1,0 \\ -1,5 \end{bmatrix}.$$

Definição 1.7 (Vetor nulo). O **vetor nulo** de $\mathbb{R}^p$ é definido por

$$\mathbf{0} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$

Ele é o elemento neutro da adição:

$$\mathbf{x} + \mathbf{0} = \mathbf{x}.$$

A Figura 1.3 apresenta a interpretação geométrica da soma em $\mathbb{R}^2$.

Na figura, os vetores $\mathbf{x}$ e $\mathbf{y}$ formam dois lados de um paralelogramo. A diagonal que parte da origem representa $\mathbf{x} + \mathbf{y}$.

1.5.2 Multiplicação por escalar

A multiplicação do vetor $\mathbf{x}$ pelo escalar α é definida por

$$\alpha \mathbf{x} = \begin{bmatrix} \alpha x_1 \\ \alpha x_2 \\ \vdots \\ \alpha x_p \end{bmatrix} \in \mathbb{R}^p.$$

Quando $\mathbf{x} = \mathbf{0}$, tem-se

$$\alpha \mathbf{x} = \mathbf{0}$$

para qualquer $\alpha \in \mathbb{R}$.




Figura 1.3: Soma de vetores pela regra do paralelogramo.

Exemplo 1.5 (Multiplicação por escalar). Para

$$\mathbf{x} = \begin{bmatrix} 2,0 \\ -1,5 \end{bmatrix}$$

e $\alpha = -2$, tem-se

$$-2\mathbf{x} = \begin{bmatrix} -2(2,0) \\ -2(-1,5) \end{bmatrix} = \begin{bmatrix} -4,0 \\ 3,0 \end{bmatrix}.$$

1.5.3 Combinações lineares

Uma combinação linear é construída por meio das duas operações apresentadas anteriormente: a multiplicação de vetores por escalares e a adição de vetores.

Definição 1.8 (Combinação linear de vetores). Sejam

$$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k \in \mathbb{R}^p$$

e

$$\alpha_1, \alpha_2, \dots, \alpha_k \in \mathbb{R}.$$

Uma **combinação linear** dos vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$ é qualquer vetor da forma

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_k \mathbf{v}_k.$$

O resultado também pertence a $\mathbb{R}^p$, pois é obtido por multiplicações por escalares e somas de vetores de $\mathbb{R}^p$:

$$\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k \in \mathbb{R}^p.$$

Exemplo 1.6 (Combinação linear de vetores). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 3 \\ -1 \end{bmatrix}.$$

A combinação linear $2\mathbf{v}_1 - \mathbf{v}_2$ é

$$2\mathbf{v}_1 - \mathbf{v}_2 = 2 \begin{bmatrix} 1 \\ 2 \end{bmatrix} - \begin{bmatrix} 3 \\ -1 \end{bmatrix} = \begin{bmatrix} -1 \\ 5 \end{bmatrix}.$$

As combinações lineares permitem construir novos vetores a partir de vetores já conhecidos. Seus coeficientes determinam quanto cada vetor contribui para o resultado.

Exemplo 1.7 (Combinação linear das variáveis). Considere as variáveis X_1 , X_2 e X_3 e os coeficientes

$$a_1 = 2,0, \quad a_2 = -0,5, \quad a_3 = 3,0.$$

A combinação linear definida por esses coeficientes é

$$Y = 2,0X_1 - 0,5X_2 + 3,0X_3.$$

Para uma observação com valores

$$x_1 = 4,0, \quad x_2 = 2,0, \quad x_3 = 1,5,$$

o valor observado da combinação linear é

$$y = 2,0(4,0) - 0,5(2,0) + 3,0(1,5) = 11,5.$$

Em uma combinação linear, cada coeficiente determina a contribuição do vetor ou da variável correspondente para o resultado.

1.6 Produto interno, norma, ângulo e distância euclidiana

O produto interno associa dois vetores de $\mathbb{R}^p$ a um número real. A partir dessa operação, definem-se norma, ângulo, ortogonalidade e distância euclidiana. (Eaton, 2007)

1.6.1 Produto interno euclidiano

Definição 1.9 (Produto interno euclidiano). Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, o **produto interno euclidiano** entre $\mathbf{x}$ e $\mathbf{y}$ é definido por

$$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_{j=1}^p x_j y_j.$$

Em termos das componentes,

$$\langle \mathbf{x}, \mathbf{y} \rangle = x_1 y_1 + x_2 y_2 + \cdots + x_p y_p.$$

O resultado do produto interno é um escalar.

Exemplo 1.8 (Cálculo do produto interno). Considere

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \\ 3 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 4 \\ 2 \\ -1 \end{bmatrix}.$$

Então,

$$\langle \mathbf{x}, \mathbf{y} \rangle = 2(4) + 1(2) + 3(-1) = 7.$$

Proposição 1.1 (Propriedades do produto interno euclidiano). *Para quaisquer vetores $\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$ e quaisquer escalares $\alpha, \beta \in \mathbb{R}$, o produto interno euclidiano satisfaz as seguintes propriedades:*

1. Simetria

$$\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{y}, \mathbf{x} \rangle.$$

2. Linearidade no primeiro argumento

$$\langle \alpha \mathbf{x} + \beta \mathbf{z}, \mathbf{y} \rangle = \alpha \langle \mathbf{x}, \mathbf{y} \rangle + \beta \langle \mathbf{z}, \mathbf{y} \rangle.$$

3. Linearidade no segundo argumento

$$\langle \mathbf{x}, \alpha \mathbf{y} + \beta \mathbf{z} \rangle = \alpha \langle \mathbf{x}, \mathbf{y} \rangle + \beta \langle \mathbf{x}, \mathbf{z} \rangle.$$

4. Não negatividade

$$\langle \mathbf{x}, \mathbf{x} \rangle \geq 0.$$

5. Positividade definida

$$\langle \mathbf{x}, \mathbf{x} \rangle = 0 \iff \mathbf{x} = \mathbf{0}.$$

1.6.2 Norma euclidiana

Definição 1.10 (Norma euclidiana). A **norma euclidiana** de $\mathbf{x} \in \mathbb{R}^p$ é definida por

$$\|\mathbf{x}\| = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle} = \sqrt{x_1^2 + x_2^2 + \cdots + x_p^2}.$$

A norma representa o comprimento do vetor em relação à origem.

Para qualquer $\mathbf{x} \in \mathbb{R}^p$ e $\alpha \in \mathbb{R}$,

$$\|\mathbf{x}\| \geq 0,$$

$$\|\mathbf{x}\| = 0 \iff \mathbf{x} = \mathbf{0},$$

e

$$\|\alpha \mathbf{x}\| = |\alpha| \|\mathbf{x}\|.$$

Portanto, para $\mathbf{x} \neq \mathbf{0}$:

- se $|\alpha| > 1$, o comprimento do vetor aumenta;
- se $0 < |\alpha| < 1$, o comprimento do vetor diminui;
- se $|\alpha| = 1$, o comprimento do vetor é preservado;
- se $\alpha = 0$, o resultado é o vetor nulo;
- se $\alpha < 0$, o sentido do vetor é invertido.

As alterações de comprimento dependem de $|\alpha|$, enquanto a inversão do sentido depende do sinal de α . Assim, um escalar negativo pode aumentar, diminuir ou preservar o comprimento do vetor.

Exemplo 1.9 (Norma de um vetor). Para

$$\mathbf{x} = \begin{bmatrix} 3 \\ 4 \end{bmatrix},$$

tem-se

$$\|\mathbf{x}\| = \sqrt{3^2 + 4^2} = 5.$$

A Figura 1.4 mostra a representação geométrica desse vetor no plano. O comprimento da seta corresponde à norma euclidiana do vetor.




Figura 1.4: A norma euclidiana corresponde ao comprimento do vetor.


Nesse caso, a norma coincide com a hipotenusa de um triângulo retângulo cujos catetos têm comprimentos 3 e 4.

1.6.3 Desigualdade de Cauchy–Schwarz

Teorema 1.1 (Desigualdade de Cauchy–Schwarz). *Para quaisquer vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,*

$$|\langle \mathbf{x}, \mathbf{y} \rangle| \leq \|\mathbf{x}\| \|\mathbf{y}\|.$$

A igualdade ocorre se, e somente se, um dos vetores é múltiplo escalar do outro. (Eaton, 2007)



i Demonstração

Se $\mathbf{y} = \mathbf{0}$, então

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0$$

e

$$\|\mathbf{x}\| \|\mathbf{y}\| = 0.$$

Portanto, a desigualdade é satisfeita com igualdade. Além disso,

$$\mathbf{y} = 0\mathbf{x},$$

de modo que um dos vetores é múltiplo escalar do outro.

Considere agora $\mathbf{y} \neq \mathbf{0}$. Para qualquer escalar $\alpha \in \mathbb{R}$, a não negatividade do produto interno implica

$$\langle \mathbf{x} - \alpha\mathbf{y}, \mathbf{x} - \alpha\mathbf{y} \rangle \geq 0.$$

Escolha

$$\alpha = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{y}\|^2}.$$

Expandindo o produto interno,

$$\begin{aligned} 0 &\leq \langle \mathbf{x} - \alpha\mathbf{y}, \mathbf{x} - \alpha\mathbf{y} \rangle \\ &= \langle \mathbf{x}, \mathbf{x} \rangle - \alpha\langle \mathbf{x}, \mathbf{y} \rangle - \alpha\langle \mathbf{y}, \mathbf{x} \rangle + \alpha^2\langle \mathbf{y}, \mathbf{y} \rangle \\ &= \|\mathbf{x}\|^2 - 2\alpha\langle \mathbf{x}, \mathbf{y} \rangle + \alpha^2\|\mathbf{y}\|^2. \end{aligned}$$

Na última igualdade, foi utilizada a simetria do produto interno:

Para vetores não nulos, a desigualdade de Cauchy–Schwarz também implica

$$-1 \leq \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|} \leq 1.$$

Assim, a desigualdade fornece uma justificativa algébrica de que a razão utilizada no cálculo do ângulo pertence ao intervalo $[-1, 1]$, que é o domínio da função arccos.

1.6.4 Ângulo entre vetores

Definição 1.11 (Ângulo entre vetores). Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ não nulos, o **ângulo** entre os vetores é o único valor $\theta \in [0, \pi]$ que satisfaz

$$\cos(\theta) = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

A existência desse ângulo é garantida pela desigualdade de Cauchy–Schwarz, pois

$$-1 \leq \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|} \leq 1.$$

Equivalentemente,

$$\theta = \arccos \left(\frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|} \right).$$

A relação que define o ângulo também pode ser escrita como

$$\langle \mathbf{x}, \mathbf{y} \rangle = \|\mathbf{x}\| \|\mathbf{y}\| \cos(\theta).$$

Interpretação geométrica

A divisão pelo produto das normas retira o efeito dos comprimentos dos vetores. Desse modo, o valor de $\cos(\theta)$ descreve apenas o alinhamento entre suas direções.

Como $\|\mathbf{x}\|$ e $\|\mathbf{y}\|$ são positivos, o sinal do produto interno depende apenas do sinal de $\cos(\theta)$:

- se $0 \leq \theta < \frac{\pi}{2}$, o ângulo é agudo e

$$\langle \mathbf{x}, \mathbf{y} \rangle > 0;$$

- se $\theta = \frac{\pi}{2}$, o ângulo é reto e

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0;$$

- se $\frac{\pi}{2} < \theta \leq \pi$, o ângulo é obtuso e


$$\langle \mathbf{x}, \mathbf{y} \rangle < 0.$$

Geometricamente, o produto interno é positivo quando os vetores apontam para direções relativamente próximas, é nulo quando são ortogonais e é negativo quando apontam para direções relativamente opostas.


O ângulo não é definido quando um dos vetores é nulo, pois o vetor nulo não possui direção determinada e o denominador da expressão seria igual a zero.

A Figura 1.5 apresenta essas três situações.

Ângulo agudo



Ângulo reto



Ângulo obtuso




Figura 1.5: Sinal do produto interno segundo o ângulo formado entre dois vetores.

Definição 1.12 (Vetores ortogonais). Dois vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ são **ortogonais** quando

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0.$$

Se ambos forem não nulos, o ângulo entre eles é igual a 90° .

O vetor nulo é ortogonal a todos os vetores, pois

$$\langle \mathbf{0}, \mathbf{x} \rangle = 0.$$

O ângulo entre o vetor nulo e outro vetor não é definido porque $\|\mathbf{0}\| = 0$.

1.6.5 Distância euclidiana

Definição 1.13 (Distância euclidiana). A **distância euclidiana** entre $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ é definida por

$$d_E(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|.$$

Em termos das componentes,

$$d_E(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{j=1}^p (x_j - y_j)^2}.$$

A distância euclidiana corresponde ao comprimento do segmento que liga os pontos representados por $\mathbf{x}$ e $\mathbf{y}$.

Exemplo 1.10 (Distância entre duas observações). Considere

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 5 \\ 5 \end{bmatrix}.$$

A diferença entre os vetores é

$$\mathbf{x} - \mathbf{y} = \begin{bmatrix} -3 \\ -4 \end{bmatrix}.$$

Logo,

$$d_E(\mathbf{x}, \mathbf{y}) = \sqrt{(-3)^2 + (-4)^2} = 5.$$

Escalas das variáveis

A distância euclidiana depende das unidades e das escalas das variáveis. Uma variável com valores numericamente maiores pode contribuir mais para a distância entre as ob-




Figura 1.6: Os vetores $\mathbf{x}$ e $\mathbf{y}$ são representados por setas. A distância euclidiana é o comprimento do segmento que une suas extremidades.

servações. Por isso, comparações baseadas em distância podem requerer padronização ou outra geometria compatível com as escalas das variáveis.

1.6.6 Desigualdade triangular

Teorema 1.2 (Desigualdade triangular). *Para quaisquer vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,*

$$\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|.$$

Consequentemente, para quaisquer pontos $\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$,

$$d_E(\mathbf{x}, \mathbf{z}) \leq d_E(\mathbf{x}, \mathbf{y}) + d_E(\mathbf{y}, \mathbf{z}).$$

(Gentle, 2017)

i Demonstração

Pela definição da norma euclidiana,

$$\|\mathbf{x} + \mathbf{y}\|^2 = \langle \mathbf{x} + \mathbf{y}, \mathbf{x} + \mathbf{y} \rangle.$$

Usando a linearidade e a simetria do produto interno,

$$\begin{aligned}\|\mathbf{x} + \mathbf{y}\|^2 &= \langle \mathbf{x}, \mathbf{x} \rangle + \langle \mathbf{x}, \mathbf{y} \rangle + \langle \mathbf{y}, \mathbf{x} \rangle + \langle \mathbf{y}, \mathbf{y} \rangle \\ &= \|\mathbf{x}\|^2 + 2\langle \mathbf{x}, \mathbf{y} \rangle + \|\mathbf{y}\|^2.\end{aligned}$$

Pela desigualdade de Cauchy–Schwarz,

$$\langle \mathbf{x}, \mathbf{y} \rangle \leq |\langle \mathbf{x}, \mathbf{y} \rangle| \leq \|\mathbf{x}\| \|\mathbf{y}\|.$$

Portanto,

$$\begin{aligned}\|\mathbf{x} + \mathbf{y}\|^2 &\leq \|\mathbf{x}\|^2 + 2\|\mathbf{x}\| \|\mathbf{y}\| + \|\mathbf{y}\|^2 \\ &= (\|\mathbf{x}\| + \|\mathbf{y}\|)^2.\end{aligned}$$

Como ambos os lados são não negativos, podemos tomar a raiz quadrada e obter

$$\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|.$$

Para demonstrar a desigualdade triangular da distância euclidiana, observe que

$$\mathbf{x} - \mathbf{z} = (\mathbf{x} - \mathbf{y}) + (\mathbf{y} - \mathbf{z}).$$

Aplicando a desigualdade triangular da norma,

$$\|\mathbf{x} - \mathbf{z}\| \leq \|\mathbf{x} - \mathbf{y}\| + \|\mathbf{y} - \mathbf{z}\|.$$

Como

$$d_E(\mathbf{u}, \mathbf{v}) = \|\mathbf{u} - \mathbf{v}\|,$$

segue que

$$d_E(\mathbf{x}, \mathbf{z}) \leq d_E(\mathbf{x}, \mathbf{y}) + d_E(\mathbf{y}, \mathbf{z}).$$

O produto interno, em conjunto com as normas, determina o ângulo entre vetores. A norma mede o comprimento de um vetor, e a distância euclidiana mede a separação entre dois pontos. Esses conceitos completam a representação geométrica inicial dos dados multivariados.

1.6.7 Produto externo

O produto interno associa dois vetores de mesma dimensão a um escalar. Dois vetores também podem ser utilizados para construir uma matriz por meio do **produto externo**.

Definição 1.14 (Produto externo). Para $\mathbf{x} \in \mathbb{R}^p$ e $\mathbf{y} \in \mathbb{R}^q$, o **produto externo** de $\mathbf{x}$ e $\mathbf{y}$, denotado por

$$\text{ext}(\mathbf{x}, \mathbf{y}),$$

é definido como a matriz em $\mathbb{R}^{p \times q}$

$$\text{ext}(\mathbf{x}, \mathbf{y}) = \begin{bmatrix} x_1 y_1 & x_1 y_2 & \cdots & x_1 y_q \\ x_2 y_1 & x_2 y_2 & \cdots & x_2 y_q \\ \vdots & \vdots & \ddots & \vdots \\ x_p y_1 & x_p y_2 & \cdots & x_p y_q \end{bmatrix}.$$

O elemento localizado na linha i e na coluna j é

$$[\text{ext}(\mathbf{x}, \mathbf{y})]_{ij} = x_i y_j.$$

O resultado do produto externo é uma matriz. (Gentle, 2017)

A estrutura do produto externo pode ser observada por suas colunas. Como

$$\text{ext}(\mathbf{x}, \mathbf{y}) = [y_1 \mathbf{x} \quad y_2 \mathbf{x} \quad \cdots \quad y_q \mathbf{x}],$$

cada coluna é um múltiplo escalar de $\mathbf{x}$.

Equivalentemente, considerando as linhas,

$$\text{ext}(\mathbf{x}, \mathbf{y}) = \begin{bmatrix} x_1 \mathbf{y}^\top \\ x_2 \mathbf{y}^\top \\ \vdots \\ x_p \mathbf{y}^\top \end{bmatrix},$$

de modo que cada linha é um múltiplo escalar de $\mathbf{y}^\top$.

Exemplo 1.11 (Produto externo de dois vetores). Considere

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \in \mathbb{R}^2$$

e

$$\mathbf{y} = \begin{bmatrix} 3 \\ -1 \\ 4 \end{bmatrix} \in \mathbb{R}^3.$$

O produto externo é

$$\begin{aligned} \text{ext}(\mathbf{x}, \mathbf{y}) &= \begin{bmatrix} 1(3) & 1(-1) & 1(4) \\ 2(3) & 2(-1) & 2(4) \end{bmatrix} \\ &= \begin{bmatrix} 3 & -1 & 4 \\ 6 & -2 & 8 \end{bmatrix}. \end{aligned}$$

O resultado possui dimensão 2×3 , correspondente às dimensões de $\mathbf{x}$ e $\mathbf{y}$, respectivamente.

O produto interno e o produto externo produzem objetos de naturezas diferentes. Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,

$$\langle \mathbf{x}, \mathbf{y} \rangle \in \mathbb{R},$$

enquanto

$$\text{ext}(\mathbf{x}, \mathbf{y}) \in \mathbb{R}^{p \times p}.$$

Assim, o produto interno produz um escalar, enquanto o produto externo produz uma matriz.

1.7 Síntese do capítulo

Uma observação descrita por p variáveis quantitativas pode ser representada por um vetor

$$\mathbf{x}_i \in \mathbb{R}^p.$$

Um conjunto formado por n observações e p variáveis é organizado na matriz de dados

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

As linhas de $\mathbf{X}$ representam as observações como pontos de $\mathbb{R}^p$, enquanto as colunas representam as variáveis como vetores de $\mathbb{R}^n$.

A soma, a subtração e a multiplicação por escalar permitem construir novos vetores. As combinações lineares permitem reunir diferentes vetores ou variáveis mediante coeficientes previamente definidos.

Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, o produto interno euclidiano é definido por

$$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_{j=1}^p x_j y_j.$$

A norma euclidiana de $\mathbf{x}$ é

$$\|\mathbf{x}\| = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle},$$

e representa o comprimento do vetor.

Para vetores não nulos, o ângulo $\theta \in [0, \pi]$ é determinado por

$$\cos(\theta) = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

Dois vetores são ortogonais quando

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0.$$

A distância euclidiana entre dois pontos é definida por

$$d_E(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|.$$

Além das operações que produzem vetores ou escalares, dois vetores podem gerar uma matriz por meio do produto externo. Para

$$\mathbf{x} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{y} \in \mathbb{R}^q,$$

tem-se

$$\text{ext}(\mathbf{x}, \mathbf{y}) \in \mathbb{R}^{p \times q}.$$

Esses conceitos permitem interpretar os dados multivariados simultaneamente como vetores, matrizes e uma nuvem de pontos.

2 Álgebra matricial aplicada

No capítulo anterior, vetores foram apresentados nas formas coluna e linha, e a matriz de dados foi construída a partir da organização conjunta das observações e das variáveis. O produto externo mostrou ainda como dois vetores podem gerar uma matriz. Essas representações estabelecem a passagem natural da linguagem vetorial para a linguagem matricial.

Este capítulo desenvolve as operações e propriedades necessárias para manipular matrizes. O produto matriz-vetor e o produto entre matrizes permitem combinar linhas e colunas de dimensões compatíveis, enquanto a transposição, a simetria e o traço descrevem propriedades estruturais importantes dessas operações. Nesse contexto, o produto externo é um caso particular do produto matricial.

Também serão estudadas a identidade, a inversa, o determinante, o posto e sua relação com sistemas lineares, além de classes particulares de matrizes e de formas quadráticas. Matrizes particionadas e o complemento de Schur fornecem a base algébrica para covariâncias por blocos e distribuições condicionais.

Convenções matriciais

As convenções gerais apresentadas no capítulo anterior permanecem válidas. Neste capítulo, serão utilizadas também as seguintes convenções:

- $\mathbf{A}$, $\mathbf{B}$ e $\mathbf{C}$ representam matrizes gerais;
- $\mathbf{X}$ representa preferencialmente uma matriz de dados;
- $\mathbf{x}$, $\mathbf{y}$ e $\mathbf{b}$ representam vetores-coluna;
- a_{ij} representa o elemento localizado na linha i e na coluna j de $\mathbf{A}$;
- $\mathbf{A}_{n \times p}$ ou $\mathbf{A} \in \mathbb{R}^{n \times p}$ indica que $\mathbf{A}$ possui n linhas e p colunas;
- $\mathbf{A}^\top$ representa a transposta de $\mathbf{A}$;
- $\mathbf{A}^{-1}$ representa a inversa de $\mathbf{A}$, quando ela existe;
- $\mathbf{A}^+$ representa a pseudoinversa de Moore–Penrose;
- $\mathbf{I}_k$ representa a matriz identidade de ordem k ;
- $\mathbf{0}_{n \times p}$ representa a matriz nula de dimensão $n \times p$;
- $\det(\mathbf{A})$ representa o determinante de uma matriz quadrada;
- $\text{tr}(\mathbf{A})$ representa o traço de uma matriz quadrada;
- $\text{posto}(\mathbf{A})$ representa o posto de $\mathbf{A}$.

Quando as linhas ou colunas de uma matriz forem consideradas individualmente, serão mantidas as convenções estabelecidas no capítulo anterior. Em particular, $\mathbf{a}_i^\top$ representa,

de forma abreviada, a i -ésima linha de $\mathbf{A}$, enquanto $\mathbf{a}_{.j}$ representa sua j -ésima coluna. As condições de existência e as propriedades de cada operação serão apresentadas nas seções correspondentes.

2.1 Operações matriciais fundamentais

As dimensões das matrizes determinam quais operações podem ser realizadas. A igualdade, a soma, a subtração e a multiplicação por escalar atuam sobre elementos correspondentes. O produto matricial combina linhas da primeira matriz com colunas da segunda.

Definição 2.1 (Igualdade entre matrizes). Sejam $\mathbf{A} = (a_{ij})_{n \times p}$ e $\mathbf{B} = (b_{ij})_{r \times s}$. As matrizes $\mathbf{A}$ e $\mathbf{B}$ são iguais quando possuem as mesmas dimensões e elementos correspondentes iguais:

$$\mathbf{A} = \mathbf{B} \iff n = r, \quad p = s \quad \text{e} \quad a_{ij} = b_{ij}$$

para $i = 1, \dots, n$ e $j = 1, \dots, p$.

Assim,

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix},$$

mas

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \neq \begin{bmatrix} 1 & 2 \\ 4 & 3 \end{bmatrix}.$$

A posição de cada elemento faz parte da estrutura da matriz.

2.1.1 Soma e subtração de matrizes

Definição 2.2 (Soma e subtração de matrizes). Sejam $\mathbf{A} = (a_{ij})_{n \times p}$ e $\mathbf{B} = (b_{ij})_{n \times p}$. A soma e a subtração são definidas por

$$\mathbf{A} + \mathbf{B} = (a_{ij} + b_{ij})_{n \times p}$$

e

$$\mathbf{A} - \mathbf{B} = (a_{ij} - b_{ij})_{n \times p}.$$

As duas operações exigem que as matrizes possuam as mesmas dimensões.

Exemplo 2.1 (Soma e subtração de matrizes). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ -1 & 3 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 4 & -2 \\ 2 & 1 \end{bmatrix}.$$

A soma é

$$\mathbf{A} + \mathbf{B} = \begin{bmatrix} 1+4 & 2+(-2) \\ -1+2 & 3+1 \end{bmatrix} = \begin{bmatrix} 5 & 0 \\ 1 & 4 \end{bmatrix}.$$

A subtração é

$$\mathbf{A} - \mathbf{B} = \begin{bmatrix} 1-4 & 2-(-2) \\ -1-2 & 3-1 \end{bmatrix} = \begin{bmatrix} -3 & 4 \\ -3 & 2 \end{bmatrix}.$$

Proposição 2.1 (Propriedades da adição matricial). *Sejam*

$$\mathbf{A}, \mathbf{B}, \mathbf{C} \in \mathbb{R}^{n \times p}.$$

A adição de matrizes satisfaz as seguintes propriedades:

1. *Comutatividade*

$$\mathbf{A} + \mathbf{B} = \mathbf{B} + \mathbf{A}.$$

2. *Associatividade*

$$(\mathbf{A} + \mathbf{B}) + \mathbf{C} = \mathbf{A} + (\mathbf{B} + \mathbf{C}).$$

3. *Existência do elemento neutro*

$$\mathbf{A} + \mathbf{0}_{n \times p} = \mathbf{A},$$

em que $\mathbf{0}_{n \times p}$ é o elemento neutro de dimensão $n \times p$:

$$\mathbf{0}_{n \times p} = \begin{bmatrix} 0 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 0 \end{bmatrix}.$$

4. Existência do elemento oposto

$$\mathbf{A} + (-\mathbf{A}) = \mathbf{0}_{n \times p}.$$

Definição 2.3 (Multiplicação de matriz por escalar). Seja $\mathbf{A} = (a_{ij})_{n \times p}$ e seja $\alpha \in \mathbb{R}$. A multiplicação de $\mathbf{A}$ por α é definida por

$$\alpha \mathbf{A} = (\alpha a_{ij})_{n \times p}.$$

Cada elemento da matriz é multiplicado pelo mesmo escalar.

Exemplo 2.2 (Multiplicação de matriz por escalar). Para

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ -1 & 3 \end{bmatrix}$$

e $\alpha = -2$, tem-se

$$-2\mathbf{A} = -2 \begin{bmatrix} 1 & 2 \\ -1 & 3 \end{bmatrix} = \begin{bmatrix} -2 & -4 \\ 2 & -6 \end{bmatrix}.$$

Proposição 2.2 (Propriedades da multiplicação por escalar). *Sejam $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times p}$ e $\alpha, \beta \in \mathbb{R}$. A multiplicação de uma matriz por um escalar satisfaz as seguintes propriedades:*

1. Distributividade em relação à adição de matrizes

$$\alpha(\mathbf{A} + \mathbf{B}) = \alpha\mathbf{A} + \alpha\mathbf{B}.$$

2. Distributividade em relação à adição de escalares

$$(\alpha + \beta)\mathbf{A} = \alpha\mathbf{A} + \beta\mathbf{A}.$$

3. Associatividade da multiplicação por escalares

$$\alpha(\beta\mathbf{A}) = (\alpha\beta)\mathbf{A}.$$

4. *Elemento neutro da multiplicação escalar*

$$1\mathbf{A} = \mathbf{A}.$$

A adição de matrizes e a multiplicação por escalar preservam as dimensões das matrizes envolvidas. O produto matricial utiliza uma regra diferente e pode produzir uma matriz com dimensões distintas das matrizes multiplicadas.

2.1.2 Produto matriz-vetor

O produto de uma matriz por um vetor é definido quando o número de colunas da matriz coincide com o número de componentes do vetor.

Para

$$\mathbf{A} \in \mathbb{R}^{n \times p} \quad \text{e} \quad \mathbf{x} \in \mathbb{R}^p,$$

cada linha de $\mathbf{A}$ pode ser associada a um produto interno com $\mathbf{x}$. O produto matriz-vetor reúne esses produtos internos em um vetor de $\mathbb{R}^n$.

Definição 2.4 (Produto matriz-vetor). Sejam

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}$$

e

$$\mathbf{x} \in \mathbb{R}^p.$$

O produto de $\mathbf{A}$ por $\mathbf{x}$ é o vetor

$$\mathbf{Ax} = \begin{bmatrix} \langle \mathbf{a}_1, \mathbf{x} \rangle \\ \langle \mathbf{a}_2, \mathbf{x} \rangle \\ \vdots \\ \langle \mathbf{a}_n, \mathbf{x} \rangle \end{bmatrix} \in \mathbb{R}^n.$$

Escrevendo

$$\mathbf{A} = (a_{ij})_{n \times p}$$

e

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix},$$

cada produto interno pode ser escrito como

$$\langle \mathbf{a}_i, \mathbf{x} \rangle = \sum_{j=1}^p a_{ij} x_j.$$

Portanto,

$$\mathbf{Ax} = \begin{bmatrix} \sum_{j=1}^p a_{1j} x_j \\ \sum_{j=1}^p a_{2j} x_j \\ \vdots \\ \sum_{j=1}^p a_{nj} x_j \end{bmatrix}.$$

A componente i do vetor resultante é, portanto,

$$(\mathbf{Ax})_i = \mathbf{a}_i^\top \mathbf{x} = \langle \mathbf{a}_i, \mathbf{x} \rangle = \sum_{j=1}^p a_{ij} x_j.$$

O mesmo produto admite outra interpretação. Escrevendo $\mathbf{A}$ por suas colunas,

$$\mathbf{A} = [\mathbf{a}_1 \ \mathbf{a}_2 \ \cdots \ \mathbf{a}_p],$$

tem-se

$$\mathbf{Ax} = x_1 \mathbf{a}_1 + x_2 \mathbf{a}_2 + \cdots + x_p \mathbf{a}_p.$$

Assim, o produto matriz-vetor possui duas interpretações complementares:

- **pelas linhas**, cada componente de $\mathbf{Ax}$ é um produto interno entre o vetor associado a uma linha de $\mathbf{A}$ e $\mathbf{x}$;
- **pelas colunas**, $\mathbf{Ax}$ é uma combinação linear das colunas de $\mathbf{A}$, com coeficientes dados pelas componentes de $\mathbf{x}$.

Exemplo 2.3 (Produto de uma matriz por um vetor). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ -1 & 3 \\ 2 & 0 \end{bmatrix} \in \mathbb{R}^{3 \times 2}$$

e

$$\mathbf{x} = \begin{bmatrix} 2 \\ -1 \end{bmatrix} \in \mathbb{R}^2.$$

Pelas linhas de $\mathbf{A}$,

$$\mathbf{Ax} = \begin{bmatrix} (1)(2) + (2)(-1) \\ (-1)(2) + (3)(-1) \\ (2)(2) + (0)(-1) \end{bmatrix} = \begin{bmatrix} 0 \\ -5 \\ 4 \end{bmatrix}.$$

Cada componente é um produto interno entre $\mathbf{x}$ e uma linha de $\mathbf{A}$.

Pelas colunas,

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix}, \quad \mathbf{a}_2 = \begin{bmatrix} 2 \\ 3 \\ 0 \end{bmatrix}.$$

Logo,

$$\begin{aligned} \mathbf{Ax} &= 2\mathbf{a}_1 - \mathbf{a}_2 \\ &= 2 \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix} - \begin{bmatrix} 2 \\ 3 \\ 0 \end{bmatrix} \\ &= \begin{bmatrix} 0 \\ -5 \\ 4 \end{bmatrix}. \end{aligned}$$

As duas formas de cálculo produzem o mesmo vetor: pelas linhas, o resultado é obtido por produtos internos; pelas colunas, por uma combinação linear.

2.1.3 Produto entre matrizes

O produto entre matrizes estende o produto matriz-vetor. Se as colunas de uma matriz $\mathbf{B}$ são

$$\mathbf{b}_{.1}, \mathbf{b}_{.2}, \dots, \mathbf{b}_{.r},$$

então multiplicar $\mathbf{A}$ por $\mathbf{B}$ equivale a multiplicar $\mathbf{A}$ por cada uma dessas colunas:

$$\mathbf{AB} = \mathbf{A} [\mathbf{b}_{.1} \ \mathbf{b}_{.2} \ \dots \ \mathbf{b}_{.r}] = [\mathbf{Ab}_{.1} \ \mathbf{Ab}_{.2} \ \dots \ \mathbf{Ab}_{.r}].$$

Como cada componente de $\mathbf{Ab}_{.j}$ é um produto interno entre uma linha de $\mathbf{A}$ e a coluna $\mathbf{b}_{.j}$, cada elemento do produto matricial também pode ser interpretado como um produto interno.

Definição 2.5 (Produto entre matrizes). Sejam

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}$$

e

$$\mathbf{B} = [\mathbf{b}_{.1} \ \mathbf{b}_{.2} \ \dots \ \mathbf{b}_{.r}] \in \mathbb{R}^{p \times r}.$$

O produto de $\mathbf{A}$ por $\mathbf{B}$ é a seguinte matriz em $\mathbb{R}^{n \times r}$

$$\mathbf{AB} = \begin{bmatrix} \mathbf{a}_1^\top \mathbf{b}_{.1} & \mathbf{a}_1^\top \mathbf{b}_{.2} & \dots & \mathbf{a}_1^\top \mathbf{b}_{.r} \\ \mathbf{a}_2^\top \mathbf{b}_{.1} & \mathbf{a}_2^\top \mathbf{b}_{.2} & \dots & \mathbf{a}_2^\top \mathbf{b}_{.r} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{a}_n^\top \mathbf{b}_{.1} & \mathbf{a}_n^\top \mathbf{b}_{.2} & \dots & \mathbf{a}_n^\top \mathbf{b}_{.r} \end{bmatrix}.$$

Portanto, o elemento localizado na linha i e na coluna j do produto é

$$(\mathbf{AB})_{ij} = \mathbf{a}_i^\top \mathbf{b}_{.j} = \langle \mathbf{a}_i, \mathbf{b}_{.j} \rangle.$$

Escrevendo

$$\mathbf{A} = (a_{ik})_{n \times p}$$

e

$$\mathbf{B} = (b_{kj})_{p \times r},$$

o mesmo elemento pode ser expresso como

$$(\mathbf{AB})_{ij} = \sum_{k=1}^p a_{ik} b_{kj},$$

para

$$i = 1, \dots, n \quad \text{e} \quad j = 1, \dots, r.$$

Assim, o produto matricial admite duas leituras complementares:

- **pelos elementos**, cada entrada de $\mathbf{AB}$ é o produto interno entre uma linha de $\mathbf{A}$ e uma coluna de $\mathbf{B}$;
- **pelas colunas**, cada coluna de $\mathbf{AB}$ é obtida multiplicando $\mathbf{A}$ pela coluna correspondente de $\mathbf{B}$.

Compatibilidade dimensional

O produto $\mathbf{AB}$ é definido somente quando o número de colunas de $\mathbf{A}$ coincide com o número de linhas de $\mathbf{B}$:

$$\underset{n \times p}{\mathbf{A}} \underset{p \times r}{\mathbf{B}} = \underset{n \times r}{\mathbf{AB}}.$$

As dimensões internas devem coincidir. As dimensões externas determinam a dimensão do resultado.

Exemplo 2.4 (Produto entre duas matrizes). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 3 & 1 \end{bmatrix} \in \mathbb{R}^{2 \times 3}$$

e

$$\mathbf{B} = \begin{bmatrix} 2 & 1 \\ 0 & -1 \\ 4 & 2 \end{bmatrix} \in \mathbb{R}^{3 \times 2}.$$

Como o número de colunas de $\mathbf{A}$ coincide com o número de linhas de $\mathbf{B}$, o produto está definido e possui dimensão 2×2 .

Cada elemento é obtido pelo produto interno entre uma linha de $\mathbf{A}$ e uma coluna de $\mathbf{B}$. Por exemplo,

$$(\mathbf{AB})_{11} = \begin{bmatrix} 1 & 2 & 0 \end{bmatrix} \begin{bmatrix} 2 \\ 0 \\ 4 \end{bmatrix} = (1)(2) + (2)(0) + (0)(4) = 2,$$

enquanto

$$(\mathbf{AB})_{12} = \begin{bmatrix} 1 & 2 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix} = (1)(1) + (2)(-1) + (0)(2) = -1.$$

Procedendo da mesma forma para os demais elementos,

$$\mathbf{AB} = \begin{bmatrix} 2 & -1 \\ 2 & -2 \end{bmatrix}.$$

i Produto interno e produto externo como produtos matriciais

As operações entre vetores apresentadas anteriormente também podem ser expressas por meio do produto matricial.

Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, o **produto interno** pode ser escrito como

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^\top \mathbf{y}.$$

Como

$$\mathbf{x}^\top \in \mathbb{R}^{1 \times p} \quad \text{e} \quad \mathbf{y} \in \mathbb{R}^{p \times 1},$$

o produto possui dimensão 1×1 e corresponde a um escalar:

$$\mathbf{x}^\top \mathbf{y} = x_1 y_1 + x_2 y_2 + \cdots + x_p y_p.$$

De forma semelhante, para

$$\mathbf{x} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{y} \in \mathbb{R}^q,$$

o **produto externo**, anteriormente denotado por

$$\text{ext}(\mathbf{x}, \mathbf{y}),$$

pode ser escrito como

$$\text{ext}(\mathbf{x}, \mathbf{y}) = \mathbf{xy}^\top.$$

Nesse caso,

$$\mathbf{x} \in \mathbb{R}^{p \times 1} \quad \text{e} \quad \mathbf{y}^\top \in \mathbb{R}^{1 \times q},$$

de modo que

$$\mathbf{xy}^\top \in \mathbb{R}^{p \times q}.$$

Portanto, a ordem e a orientação dos vetores determinam objetos diferentes:

$$\mathbf{x}^\top \mathbf{y} \text{ é um escalar}$$

enquanto

$$\mathbf{xy}^\top \text{ é uma matriz.}$$

Exemplo 2.5 (Produtos envolvendo uma matriz de dados). Considere a matriz de dados

$$\mathbf{X} = \begin{bmatrix} 2 & 1 & 4 \\ 3 & 5 & 2 \\ 6 & 2 & 1 \\ 4 & 3 & 5 \end{bmatrix} \in \mathbb{R}^{4 \times 3}.$$

As quatro linhas correspondem às observações, e as três colunas correspondem às variáveis.

A matriz

$$\mathbf{X}^\top = \begin{bmatrix} 2 & 3 & 6 & 4 \\ 1 & 5 & 2 & 3 \\ 4 & 2 & 1 & 5 \end{bmatrix} \in \mathbb{R}^{3 \times 4}$$

é obtida escrevendo as colunas de $\mathbf{X}$ como linhas. A operação de transposição e suas propriedades serão formalizadas adiante.

Considere ainda

$$\mathbf{a} = \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix}.$$

O produto

$$\mathbf{X}\mathbf{a} = \begin{bmatrix} 0 \\ 11 \\ 9 \\ 5 \end{bmatrix}$$

pode ser escrito, em termos das colunas de $\mathbf{X}$, como

$$\mathbf{X}\mathbf{a} = \mathbf{x}_{\cdot 1} + 2\mathbf{x}_{\cdot 2} - \mathbf{x}_{\cdot 3}.$$

Portanto, o vetor resultante contém os valores da nova variável formada pela combinação linear

$$X_1 + 2X_2 - X_3.$$

Considere agora o produto

$$\mathbf{X}^\top \mathbf{X} = \begin{bmatrix} 65 & 41 & 40 \\ 41 & 39 & 31 \\ 40 & 31 & 46 \end{bmatrix}.$$

Esse produto possui dimensão 3×3 . Cada elemento é o produto interno entre duas colunas de $\mathbf{X}$ e, portanto, relaciona duas variáveis. Em geral,

$$(\mathbf{X}^\top \mathbf{X})_{jk} = \langle \mathbf{x}_{\cdot j}, \mathbf{x}_{\cdot k} \rangle.$$

Por exemplo,

$$(\mathbf{X}^\top \mathbf{X})_{12} = \langle \mathbf{x}_{\cdot 1}, \mathbf{x}_{\cdot 2} \rangle = 41.$$

Por outro lado,

$$\mathbf{X}\mathbf{X}^\top = \begin{bmatrix} 21 & 19 & 18 & 31 \\ 19 & 38 & 30 & 37 \\ 18 & 30 & 41 & 35 \\ 31 & 37 & 35 & 50 \end{bmatrix}$$

possui dimensão 4×4 . Cada elemento é o produto interno entre duas linhas de $\mathbf{X}$ e, portanto, relaciona duas observações. Em geral,

$$(\mathbf{X}\mathbf{X}^\top)_{ih} = \langle \mathbf{x}_i, \mathbf{x}_h \rangle.$$

Por exemplo,

$$(\mathbf{X}\mathbf{X}^\top)_{12} = \langle \mathbf{x}_1, \mathbf{x}_2 \rangle = 19.$$

Assim, a mesma matriz de dados gera dois produtos com interpretações distintas:

- $\mathbf{X}^\top \mathbf{X}$ relaciona as variáveis;
- $\mathbf{X}\mathbf{X}^\top$ relaciona as observações.

Esses produtos aparecem em matrizes de Gram, produtos cruzados, covariâncias e na decomposição em valores singulares.

2.1.4 Propriedades do produto matricial

Proposição 2.3 (Propriedades do produto matricial). *Para matrizes com dimensões compatíveis, o produto matricial satisfaz as seguintes propriedades:*

1. *Associatividade*

$$(\mathbf{A}\mathbf{B})\mathbf{C} = \mathbf{A}(\mathbf{B}\mathbf{C}).$$

2. *Distributividade à esquerda*

$$\mathbf{A}(\mathbf{B} + \mathbf{C}) = \mathbf{A}\mathbf{B} + \mathbf{A}\mathbf{C}.$$

3. *Distributividade à direita*

$$(\mathbf{A} + \mathbf{B})\mathbf{C} = \mathbf{A}\mathbf{C} + \mathbf{B}\mathbf{C}.$$

4. *Compatibilidade com a multiplicação por escalar*

Para $\alpha \in \mathbb{R}$,

$$(\alpha \mathbf{A})\mathbf{B} = \alpha(\mathbf{A}\mathbf{B}) = \mathbf{A}(\alpha \mathbf{B}).$$

O produto matricial, em geral, **não é comutativo**. Mesmo quando $\mathbf{A}\mathbf{B}$ e $\mathbf{B}\mathbf{A}$ estão ambos definidos e possuem a mesma dimensão, pode ocorrer

$$\mathbf{A}\mathbf{B} \neq \mathbf{B}\mathbf{A}.$$

Exemplo 2.6 (Não comutatividade do produto matricial). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}.$$

Tem-se

$$\mathbf{AB} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix},$$

enquanto

$$\mathbf{BA} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix}.$$

Portanto,

$$\mathbf{AB} \neq \mathbf{BA}.$$

2.2 Transposição, simetria e traço

A transposição troca as linhas de uma matriz por suas colunas. Essa operação permite reorganizar produtos matriciais e definir matrizes simétricas.

2.2.1 Transposição

Definição 2.6 (Matriz transposta). Seja $\mathbf{A} = (a_{ij})_{n \times p} \in \mathbb{R}^{n \times p}$. A **transposta** de $\mathbf{A}$ é a matriz

$$\mathbf{A}^\top = (a_{ji})_{p \times n} \in \mathbb{R}^{p \times n}.$$

O elemento que ocupa a linha i e a coluna j de $\mathbf{A}$ passa a ocupar a linha j e a coluna i de $\mathbf{A}^\top$.

Exemplo 2.7 (Transposição de uma matriz). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} \in \mathbb{R}^{2 \times 3}.$$

Sua transposta é

$$\mathbf{A}^\top = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix} \in \mathbb{R}^{3 \times 2}.$$

Para uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a transposta possui dimensão

$$\mathbf{X}^\top \in \mathbb{R}^{p \times n}.$$

As linhas de $\mathbf{X}$ tornam-se as colunas de $\mathbf{X}^\top$, e as colunas de $\mathbf{X}$ tornam-se suas linhas.

Proposição 2.4 (Propriedades da transposição). *Sejam $\mathbf{A}$ e $\mathbf{B}$ matrizes com dimensões compatíveis e seja $\alpha \in \mathbb{R}$. Então,*

1. $(\mathbf{A}^\top)^\top = \mathbf{A}$,
2. $(\mathbf{A} + \mathbf{B})^\top = \mathbf{A}^\top + \mathbf{B}^\top$,
3. $(\alpha \mathbf{A})^\top = \alpha \mathbf{A}^\top$ e
4. $(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top$.
5. Em particular, para vetores $\mathbf{x} \in \mathbb{R}^p$ e $\mathbf{y} \in \mathbb{R}^q$, $(\mathbf{xy}^\top)^\top = \mathbf{yx}^\top$.

A última propriedade mostra que a transposição de um produto inverte a ordem dos fatores. Em particular, ela será útil para reconhecer estruturas simétricas construídas a partir de produtos externos.

Exemplo 2.8 (Transposta de um produto). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 3 & 1 \\ 2 & 4 \end{bmatrix}.$$

O produto é

$$\mathbf{AB} = \begin{bmatrix} 7 & 9 \\ 2 & 4 \end{bmatrix},$$

de modo que

$$(\mathbf{AB})^\top = \begin{bmatrix} 7 & 2 \\ 9 & 4 \end{bmatrix}.$$

Por outro lado,

$$\mathbf{B}^\top \mathbf{A}^\top = \begin{bmatrix} 3 & 2 \\ 1 & 4 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix} = \begin{bmatrix} 7 & 2 \\ 9 & 4 \end{bmatrix}.$$

Portanto,

$$(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top.$$

2.2.2 Matrizes simétricas

A simetria compara uma matriz quadrada com sua transposta.

Definição 2.7 (Matriz simétrica). Uma matriz $\mathbf{A} \in \mathbb{R}^{n \times n}$ é **simétrica** quando

$$\mathbf{A}^\top = \mathbf{A}.$$

Em termos dos elementos,

$$a_{ij} = a_{ji}, \quad i, j = 1, \dots, n.$$

Em uma matriz simétrica, os elementos situados em posições opostas em relação à diagonal principal são iguais.

Exemplo 2.9 (Matriz simétrica). A matriz

$$\mathbf{A} = \begin{bmatrix} 2 & 1 & -3 \\ 1 & 4 & 2 \\ -3 & 2 & 5 \end{bmatrix}$$

é simétrica, pois

$$\mathbf{A}^\top = \begin{bmatrix} 2 & 1 & -3 \\ 1 & 4 & 2 \\ -3 & 2 & 5 \end{bmatrix} = \mathbf{A}.$$

A soma de matrizes simétricas de mesma dimensão é simétrica. Se $\mathbf{A}$ é simétrica e $\alpha \in \mathbb{R}$, então $\alpha\mathbf{A}$ também é simétrica.

Um caso particularmente importante é obtido pelo produto externo de um vetor consigo mesmo. Para $\mathbf{x} \in \mathbb{R}^p$, tem-se

$$(\mathbf{x}\mathbf{x}^\top)^\top = \mathbf{x}\mathbf{x}^\top.$$

Portanto,

$$\mathbf{x}\mathbf{x}^\top$$

é uma matriz simétrica.

O produto de duas matrizes simétricas não é necessariamente simétrico. Para matrizes simétricas $\mathbf{A}$ e $\mathbf{B}$,

$$(\mathbf{AB})^\top = \mathbf{BA}.$$

Portanto, $\mathbf{AB}$ é simétrica quando

$$\mathbf{AB} = \mathbf{BA}.$$

As matrizes de covariâncias também pertencem à classe das matrizes simétricas.

2.2.3 Traço

O traço reúne os elementos da diagonal principal de uma matriz quadrada. Apesar de sua definição simples, essa operação permite representar de forma compacta somas de quadrados, produtos internos, formas quadráticas e diversas expressões matriciais utilizadas em Estatística Multivariada.

Definição 2.8 (Traço de uma matriz). Seja $\mathbf{A} = (a_{ij})_{n \times n} \in \mathbb{R}^{n \times n}$. O **traço** de $\mathbf{A}$ é definido por

$$\text{tr}(\mathbf{A}) = \sum_{i=1}^n a_{ii}.$$

Exemplo 2.10 (Cálculo do traço). Para $\mathbf{A} = \begin{bmatrix} 2 & 1 & 0 \\ -1 & 4 & 3 \\ 2 & 5 & -3 \end{bmatrix}$, tem-se

$$\text{tr}(\mathbf{A}) = 2 + 4 - 3 = 3.$$

Proposição 2.5 (Propriedades básicas do traço). *Sejam $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times n}$ e $\alpha, \beta \in \mathbb{R}$. Então,*

1. Linearidade:

$$\text{tr}(\alpha \mathbf{A} + \beta \mathbf{B}) = \alpha \text{tr}(\mathbf{A}) + \beta \text{tr}(\mathbf{B}).$$

2. Invariância à transposição:

$$\text{tr}(\mathbf{A}^\top) = \text{tr}(\mathbf{A}).$$

3. Traço da matriz identidade:

$$\text{tr}(\mathbf{I}_n) = n.$$

Consequentemente,

$$\text{tr}(\alpha \mathbf{I}_n) = \alpha n.$$

4. Propriedade cíclica: se $\mathbf{C} \in \mathbb{R}^{n \times p}$ e $\mathbf{D} \in \mathbb{R}^{p \times n}$, então

$$\text{tr}(\mathbf{CD}) = \text{tr}(\mathbf{DC}).$$

(Gentle, 2017)

A primeira propriedade mostra que o traço é uma operação linear. A segunda decorre do fato de que a transposição não modifica os elementos da diagonal principal. A quarta permite reorganizar produtos matriciais dentro do traço, desde que seja preservada a ordem cíclica dos fatores.

A propriedade cíclica pode ser demonstrada diretamente a partir da definição do produto matricial.

i Demonstração

Como $\mathbf{C} \in \mathbb{R}^{n \times p}$ e $\mathbf{D} \in \mathbb{R}^{p \times n}$,

$$\text{tr}(\mathbf{CD}) = \sum_{i=1}^n (\mathbf{CD})_{ii} = \sum_{i=1}^n \sum_{j=1}^p c_{ij} d_{ji}.$$

Trocando a ordem das somas,

$$\sum_{i=1}^n \sum_{j=1}^p c_{ij} d_{ji} = \sum_{j=1}^p \sum_{i=1}^n d_{ji} c_{ij} = \text{tr}(\mathbf{DC}).$$

Proposição 2.6 (Ciclicidade para vários fatores). *Para matrizes com dimensões compatíveis, os fatores de um produto podem ser deslocados ciclicamente dentro do traço. Por exemplo,*

$$\text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{BCA}) = \text{tr}(\mathbf{CAB}).$$

A propriedade é **cíclica**. Portanto, a ordem relativa dos fatores é preservada. Em geral,

$$\text{tr}(\mathbf{ABC}) \neq \text{tr}(\mathbf{ACB}).$$

Proposição 2.7 (Traço, produto interno e produto externo). *Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,*

$$\text{tr}(\mathbf{xy}^\top) = \mathbf{y}^\top \mathbf{x} = \langle \mathbf{x}, \mathbf{y} \rangle.$$

Como $\mathbf{xy}^\top = \text{ext}(\mathbf{x}, \mathbf{y})$, também podemos escrever

$$\text{tr}[\text{ext}(\mathbf{x}, \mathbf{y})] = \langle \mathbf{x}, \mathbf{y} \rangle.$$

Em particular,

$$\text{tr}(\mathbf{xx}^\top) = \mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|^2.$$

Essa propriedade estabelece uma ligação direta entre o traço e as operações vetoriais introduzidas anteriormente.

Proposição 2.8 (Traço de produtos matriciais). *Para $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times p}$,*

$$\text{tr}(\mathbf{A}^\top \mathbf{B}) = \sum_{i=1}^n \sum_{j=1}^p a_{ij} b_{ij}.$$

Consequentemente,

$$\text{tr}(\mathbf{A}^\top \mathbf{A}) = \sum_{i=1}^n \sum_{j=1}^p a_{ij}^2.$$

Pela propriedade cíclica,

$$\text{tr}(\mathbf{A}^\top \mathbf{A}) = \text{tr}(\mathbf{A} \mathbf{A}^\top).$$

Portanto, o traço permite representar a soma dos quadrados de todos os elementos de uma matriz. Essa expressão também aparece no estudo da norma de Frobenius, de matrizes de produtos cruzados e de decomposições matriciais.

Exemplo 2.11 (Traço de produtos matriciais). Considere $\mathbf{A} = \begin{bmatrix} 2 & 1 \\ -1 & 4 \end{bmatrix}$ e $\mathbf{B} = \begin{bmatrix} 1 & 3 \\ -2 & 3 \end{bmatrix}$.

Os produtos são

$$\mathbf{AB} = \begin{bmatrix} 0 & 9 \\ -9 & 9 \end{bmatrix}$$

e

$$\mathbf{BA} = \begin{bmatrix} -1 & 13 \\ -7 & 10 \end{bmatrix}.$$

Embora

$$\mathbf{AB} \neq \mathbf{BA},$$

seus traços são iguais:

$$\text{tr}(\mathbf{AB}) = 0 + 9 = 9$$

e

$$\text{tr}(\mathbf{BA}) = -1 + 10 = 9.$$

O traço aparece na representação de somas de quadrados, produtos cruzados, variâncias totais, formas quadráticas e expressões de verossimilhança. Sua relação com os autovalores é estabelecida no capítulo sobre decomposição espectral.

2.3 Identidade, inversa, determinante, posto e sistemas lineares

As matrizes identidade e inversa permitem representar operações que preservam ou recuperam vetores. A existência da inversa está relacionada ao determinante, ao posto e às soluções de sistemas lineares.

2.3.1 Matriz identidade

Definição 2.9 (Matriz identidade). A **matriz identidade** de ordem n é a matriz quadrada

$$\mathbf{I}_n = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix} \in \mathbb{R}^{n \times n}.$$

Seus elementos podem ser representados pelo **delta de Kronecker**,

$$\delta_{ij} = \begin{cases} 1, & i = j, \\ 0, & i \neq j, \end{cases}$$

de modo que

$$(\mathbf{I}_n)_{ij} = \delta_{ij}.$$

O delta de Kronecker permite representar de forma compacta relações de ortogonalidade e ortonormalidade.

A matriz identidade é o elemento neutro do produto matricial. Para

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

tem-se

$$\mathbf{I}_n \mathbf{A} = \mathbf{A}$$

e

$$\mathbf{A} \mathbf{I}_p = \mathbf{A}.$$

Para um vetor $\mathbf{x} \in \mathbb{R}^p$,

$$\mathbf{I}_p \mathbf{x} = \mathbf{x}.$$

Exemplo 2.12 (Produto pela matriz identidade). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

Então,

$$\mathbf{I}_2 \mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$$

e

$$\mathbf{A} \mathbf{I}_2 = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

2.3.2 Matriz inversa

Definição 2.10 (Matriz inversa). Uma matriz quadrada $\mathbf{A} \in \mathbb{R}^{n \times n}$ é **invertível** quando existe uma matriz

$$\mathbf{A}^{-1} \in \mathbb{R}^{n \times n}$$

tal que

$$\mathbf{A}\mathbf{A}^{-1} = \mathbf{A}^{-1}\mathbf{A} = \mathbf{I}_n.$$

A matriz $\mathbf{A}^{-1}$ é denominada **inversa** de $\mathbf{A}$.

Uma matriz que não possui inversa é denominada **singular**.

Teorema 2.1 (Unicidade da matriz inversa). *Se uma matriz possui inversa, essa inversa é única.*

i Demonstração

Suponha que $\mathbf{B}$ e $\mathbf{C}$ sejam inversas de $\mathbf{A}$. Então,

$$\mathbf{AB} = \mathbf{BA} = \mathbf{I}_n$$

e

$$\mathbf{AC} = \mathbf{CA} = \mathbf{I}_n.$$

Assim,

$$\mathbf{B} = \mathbf{BI}_n = \mathbf{B}(\mathbf{AC}) = (\mathbf{BA})\mathbf{C} = \mathbf{I}_n\mathbf{C} = \mathbf{C}.$$

Logo, a inversa é única.

Exemplo 2.13 (Verificação de uma matriz inversa). Considere

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix}.$$

Calculando os produtos,

$$\mathbf{AB} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \mathbf{I}_2$$

e

$$\mathbf{BA} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \mathbf{I}_2.$$

Portanto,

$$\mathbf{A}^{-1} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix}.$$

Além disso,

$$(\mathbf{A}^\top)^{-1} = (\mathbf{A}^{-1})^\top$$

e, para $\alpha \neq 0$,

$$(\alpha \mathbf{A})^{-1} = \frac{1}{\alpha} \mathbf{A}^{-1}.$$

Teorema 2.2 (Inversa de um produto). *Se $\mathbf{A}$ e $\mathbf{B}$ são matrizes invertíveis de ordem n , então $\mathbf{AB}$ é invertível e*

$$(\mathbf{AB})^{-1} = \mathbf{B}^{-1} \mathbf{A}^{-1}.$$

i Demonstração

Tem-se

$$(\mathbf{AB})(\mathbf{B}^{-1} \mathbf{A}^{-1}) = \mathbf{A}(\mathbf{BB}^{-1})\mathbf{A}^{-1} = \mathbf{AI}_n \mathbf{A}^{-1} = \mathbf{I}_n.$$

Também,

$$(\mathbf{B}^{-1} \mathbf{A}^{-1})(\mathbf{AB}) = \mathbf{B}^{-1}(\mathbf{A}^{-1} \mathbf{A})\mathbf{B} = \mathbf{B}^{-1} \mathbf{I}_n \mathbf{B} = \mathbf{I}_n.$$

Logo,

$$(\mathbf{AB})^{-1} = \mathbf{B}^{-1} \mathbf{A}^{-1}.$$

A existência da inversa ainda não foi caracterizada. Essa condição será expressa por meio do determinante e do posto.

2.3.3 Determinante

O determinante associa uma matriz quadrada a um número real. Seu valor permite caracterizar a invertibilidade, e suas propriedades relacionam determinantes de produtos, transpostas e inversas.

Definição 2.11 (Determinante). Seja

$$\mathbf{A} = (a_{ij})_{n \times n} \in \mathbb{R}^{n \times n}.$$

O **determinante** de $\mathbf{A}$ é o escalar

$$\det(\mathbf{A}) = \sum_{\sigma \in S_n} \text{sgn}(\sigma) \prod_{i=1}^n a_{i, \sigma(i)},$$

em que S_n é o conjunto das permutações de $\{1, \dots, n\}$. Uma **inversão** de uma permutação σ é um par de índices $i < j$ tal que $\sigma(i) > \sigma(j)$. Define-se $\text{sgn}(\sigma) = 1$ quando o número de inversões é par e $\text{sgn}(\sigma) = -1$ quando é ímpar. (Gentle, 2017)

Para $n = 1$,

$$\det([a_{11}]) = a_{11}.$$

Para uma matriz de ordem dois,

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix},$$

tem-se

$$\det(\mathbf{A}) = ad - bc.$$

Exemplo 2.14 (Determinante de uma matriz de ordem dois). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 2 & 4 \end{bmatrix}.$$

O determinante é

$$\det(\mathbf{A}) = 3(4) - 1(2) = 10.$$

Proposição 2.9 (Propriedades do determinante). *Para matrizes quadradas de ordem n :*

1.

$$\det(\mathbf{I}_n) = 1.$$

2.

$$\det(\mathbf{A}^\top) = \det(\mathbf{A}).$$

3.

$$\det(\mathbf{AB}) = \det(\mathbf{A}) \det(\mathbf{B}).$$

4. Para $\alpha \in \mathbb{R}$,

$$\det(\alpha \mathbf{A}) = \alpha^n \det(\mathbf{A}).$$

As operações elementares sobre as linhas modificam o determinante de maneira específica:

- a troca de duas linhas multiplica o determinante por -1 ;
- a multiplicação de uma linha por α multiplica o determinante por α ;
- a adição de um múltiplo de uma linha a outra linha não altera o determinante.

Se as linhas de $\mathbf{A}$ são linearmente dependentes, então

$$\det(\mathbf{A}) = 0.$$

A mesma conclusão vale quando as colunas são linearmente dependentes. A ocorrência de duas linhas ou duas colunas iguais é um caso particular dessa propriedade.

Teorema 2.3 (Determinante e invertibilidade). *Para*

$$\mathbf{A} \in \mathbb{R}^{n \times n},$$

as afirmações seguintes são equivalentes:

$$\mathbf{A} \text{ é invertível} \iff \det(\mathbf{A}) \neq 0.$$

Quando $\mathbf{A}$ é invertível,

$$\det(\mathbf{A}^{-1}) = \frac{1}{\det(\mathbf{A})}.$$

De fato,

$$\det(\mathbf{A}\mathbf{A}^{-1}) = \det(\mathbf{I}_n) = 1,$$

e, pela propriedade multiplicativa,

$$\det(\mathbf{A}) \det(\mathbf{A}^{-1}) = 1.$$

Exemplo 2.15 (Verificação da invertibilidade). Para

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix},$$

tem-se

$$\det(\mathbf{A}) = 2(1) - 1(1) = 1.$$

Como

$$\det(\mathbf{A}) \neq 0,$$

a matriz é invertível.

Considere agora

$$\mathbf{B} = \begin{bmatrix} 2 & 4 \\ 1 & 2 \end{bmatrix}.$$

Nesse caso,

$$\det(\mathbf{B}) = 2(2) - 4(1) = 0.$$

A matriz $\mathbf{B}$ é singular.

2.3.4 Posto

O posto mede a dimensão da informação linearmente independente representada por uma matriz. Ele identifica o número máximo de direções que não podem ser obtidas como combinações lineares umas das outras.

Definição 2.12 (Posto de uma matriz). Seja

$$\mathbf{A} \in \mathbb{R}^{n \times p}.$$

O **posto** de $\mathbf{A}$, denotado por

$$\text{posto}(\mathbf{A}),$$

é a maior ordem de uma submatriz quadrada de $\mathbf{A}$ com determinante diferente de zero.

Equivalentemente, o posto é:

- o número máximo de colunas linearmente independentes de $\mathbf{A}$;
- o número máximo de linhas linearmente independentes de $\mathbf{A}$.

Esses dois números são sempre iguais. A interpretação do posto por meio dos espaços gerados pelas linhas e pelas colunas será desenvolvida no próximo capítulo.

O posto satisfaz

$$0 \leq \text{posto}(\mathbf{A}) \leq \min(n, p).$$

Uma matriz possui **posto completo** quando

$$\text{posto}(\mathbf{A}) = \min(n, p).$$

Um caso importante é o produto externo. Se

$$\mathbf{x} \neq \mathbf{0} \quad \text{e} \quad \mathbf{y} \neq \mathbf{0},$$

então

$$\text{posto}(\mathbf{xy}^\top) = 1.$$

De fato, todas as colunas de $\mathbf{xy}^\top$ são múltiplos escalares de $\mathbf{x}$ e, como $\mathbf{y} \neq \mathbf{0}$, pelo menos uma dessas colunas é não nula.

Essa estrutura aparece nas decomposições matriciais, em que uma matriz pode ser representada como soma de parcelas de posto 1.

Para uma matriz quadrada de ordem n ,

$$\text{posto}(\mathbf{A}) = n$$

equivale à existência de sua inversa.

Teorema 2.4 (Condições equivalentes de invertibilidade). *Para*

$$\mathbf{A} \in \mathbb{R}^{n \times n},$$

as afirmações seguintes são equivalentes:

$\mathbf{A}$ *é invertível,*

$$\det(\mathbf{A}) \neq 0$$

e

$$\text{posto}(\mathbf{A}) = n.$$

(Gentle, 2017)

Exemplo 2.16 (Posto de matrizes). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

Como

$$\det(\mathbf{A}) = 1(4) - 2(3) = -2,$$

tem-se

$$\text{posto}(\mathbf{A}) = 2.$$

Considere agora

$$\mathbf{B} = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}.$$

Como

$$\det(\mathbf{B}) = 0$$

e $\mathbf{B} \neq \mathbf{0}$,

$$\text{posto}(\mathbf{B}) = 1.$$

A segunda linha de $\mathbf{B}$ é o dobro da primeira, de modo que uma delas não acrescenta informação linear.

Para uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

tem-se

$$\text{posto}(\mathbf{X}) \leq \min(n, p).$$

Quando

$$\text{posto}(\mathbf{X}) < p,$$

existe redundância linear entre as variáveis. A interpretação do posto em termos de espaços gerados, independência linear e dimensão será desenvolvida no próximo capítulo.

2.3.5 Sistemas lineares

Um sistema de n equações lineares com p incógnitas pode ser escrito na forma matricial.

Definição 2.13 (Sistema linear). Sejam

$$\mathbf{A} \in \mathbb{R}^{n \times p}, \quad \mathbf{x} \in \mathbb{R}^p$$

e

$$\mathbf{b} \in \mathbb{R}^n.$$

O sistema linear associado é

$$\mathbf{Ax} = \mathbf{b}.$$

A matriz $\mathbf{A}$ contém os coeficientes, $\mathbf{x}$ contém as incógnitas e $\mathbf{b}$ contém os termos independentes.

Em componentes, o sistema é

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1p}x_p &= b_1, \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2p}x_p &= b_2, \\ \vdots & \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{np}x_p &= b_n. \end{aligned}$$

A matriz aumentada do sistema é

$$[\mathbf{A} \mid \mathbf{b}] = \begin{bmatrix} a_{11} & \cdots & a_{1p} & b_1 \\ \vdots & \ddots & \vdots & \vdots \\ a_{n1} & \cdots & a_{np} & b_n \end{bmatrix}.$$

Teorema 2.5 (Existência e quantidade de soluções). *Sejam*

$$\mathbf{A} \in \mathbb{R}^{n \times p}, \quad \mathbf{x} \in \mathbb{R}^p$$

e

$$\mathbf{b} \in \mathbb{R}^n.$$

O sistema

$$\mathbf{Ax} = \mathbf{b}$$

possui solução se, e somente se,

$$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]).$$

Quando o sistema é consistente:

- a solução é única se

$$\text{posto}(\mathbf{A}) = p;$$

- existem infinitas soluções se

$$\text{posto}(\mathbf{A}) < p.$$

Definição 2.14 (Sistema linear homogêneo). Um **sistema linear homogêneo** é um sistema da forma

$$\mathbf{Ax} = \mathbf{0},$$

em que

$$\mathbf{A} \in \mathbb{R}^{n \times p}, \quad \mathbf{x} \in \mathbb{R}^p$$

e

$$\mathbf{0} \in \mathbb{R}^n.$$

Portanto, um sistema homogêneo é um caso particular de sistema linear no qual todos os termos independentes são iguais a zero.

Todo sistema homogêneo possui pelo menos a **solução trivial**

$$\mathbf{x} = \mathbf{0}.$$

Dependendo da matriz $\mathbf{A}$, também podem existir **soluções não triviais**, isto é, soluções para as quais

$$\mathbf{x} \neq \mathbf{0}.$$

A Tabela 2.1 resume a classificação das soluções de um sistema linear.

Tabela 2.1: Classificação das soluções de um sistema linear.

Condição	Resultado
$\text{posto}(\mathbf{A}) \neq \text{posto}([\mathbf{A} \mid \mathbf{b}])$	Não existe solução
$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]) = p$	Existe uma única solução
$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]) < p$	Existem infinitas soluções

Exemplo 2.17 (Sistema com solução única). Considere

$$\begin{aligned} 2x_1 + x_2 &= 5, \\ x_1 + x_2 &= 3. \end{aligned}$$

A forma matricial é

$$\begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 5 \\ 3 \end{bmatrix}.$$

Como

$$\det \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} = 1,$$

a matriz de coeficientes é invertível. A solução é

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

Exemplo 2.18 (Sistemas com infinitas soluções e sem solução). Considere inicialmente o sistema

$$\begin{aligned}x_1 + x_2 &= 2, \\ 2x_1 + 2x_2 &= 4.\end{aligned}$$

A segunda equação é o dobro da primeira. Portanto,

$$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]) = 1 < 2.$$

O sistema possui infinitas soluções, que podem ser escritas como

$$x_1 = 2 - t, \quad x_2 = t, \quad t \in \mathbb{R}.$$

Considere agora

$$\begin{aligned}x_1 + x_2 &= 2, \\ 2x_1 + 2x_2 &= 5.\end{aligned}$$

As linhas da matriz de coeficientes continuam proporcionais, mas os termos independentes não preservam a mesma proporção. Nesse caso,

$$\text{posto}(\mathbf{A}) = 1$$

e

$$\text{posto}([\mathbf{A} \mid \mathbf{b}]) = 2.$$

Como os postos são diferentes, o sistema não possui solução.

Para uma matriz quadrada invertível,

$$\mathbf{Ax} = \mathbf{b}$$

possui a solução única

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b}.$$

Cálculo da solução

A expressão

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b}$$

caracteriza a solução quando $\mathbf{A}$ é invertível. Em cálculos computacionais, sistemas lineares são resolvidos diretamente, sem calcular explicitamente a matriz inversa.

O número de equações e o número de incógnitas não determinam, isoladamente, a existência ou a quantidade de soluções:

- se $n > p$, o sistema é sobredeterminado;
- se $n < p$, o sistema é subdeterminado;
- se $n = p$, o sistema é quadrado.

A classificação completa depende dos postos de $\mathbf{A}$ e de $[\mathbf{A} \mid \mathbf{b}]$.

2.4 Matrizes ortogonais e diagonais

Algumas matrizes quadradas possuem estruturas que simplificam produtos e inversões. Entre elas estão as matrizes ortogonais e diagonais.

2.4.1 Matrizes ortogonais

Definição 2.15 (Matriz ortogonal). Uma matriz

$$\mathbf{Q} \in \mathbb{R}^{n \times n}$$

é **ortogonal** quando

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_n.$$

A condição anterior implica que $\mathbf{Q}$ é invertível e

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

Consequentemente,

$$\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}_n.$$

Escrevendo as colunas de $\mathbf{Q}$ como

$$\mathbf{Q} = [\mathbf{q}_{\cdot 1} \ \mathbf{q}_{\cdot 2} \ \cdots \ \mathbf{q}_{\cdot n}],$$

tem-se

$$\mathbf{Q}^\top \mathbf{Q} = \begin{bmatrix} \mathbf{q}_{\cdot 1}^\top \mathbf{q}_{\cdot 1} & \cdots & \mathbf{q}_{\cdot 1}^\top \mathbf{q}_{\cdot n} \\ \vdots & \ddots & \vdots \\ \mathbf{q}_{\cdot n}^\top \mathbf{q}_{\cdot 1} & \cdots & \mathbf{q}_{\cdot n}^\top \mathbf{q}_{\cdot n} \end{bmatrix}.$$

Portanto, $\mathbf{Q}$ é ortogonal quando suas colunas satisfazem

$$\mathbf{q}_{\cdot i}^\top \mathbf{q}_{\cdot j} = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

As colunas possuem norma unitária e são ortogonais duas a duas. A mesma propriedade é satisfeita pelas linhas de $\mathbf{Q}$.

Exemplo 2.19 (Verificação da ortogonalidade). Considere

$$\mathbf{Q} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}.$$

Sua transposta é

$$\mathbf{Q}^\top = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}.$$

Calculando o produto,

$$\mathbf{Q}^\top \mathbf{Q} = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix} \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix} = \mathbf{I}_2.$$

Logo, $\mathbf{Q}$ é ortogonal e

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

Teorema 2.6 (Preservação do produto interno). *Se $\mathbf{Q} \in \mathbb{R}^{n \times n}$ é ortogonal, então, para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$,*

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{y}.$$

i Demonstração

Pela associatividade do produto matricial,

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{Q}^\top \mathbf{Q} \mathbf{y}.$$

Como

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_n,$$

obtém-se

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{I}_n \mathbf{y} = \mathbf{x}^\top \mathbf{y}.$$

Tomando $\mathbf{y} = \mathbf{x}$, obtém-se

$$\|\mathbf{Q}\mathbf{x}\| = \|\mathbf{x}\|.$$

Aplicando a mesma propriedade ao vetor $\mathbf{x} - \mathbf{y}$,

$$\|\mathbf{Q}\mathbf{x} - \mathbf{Q}\mathbf{y}\| = \|\mathbf{x} - \mathbf{y}\|.$$

Portanto, matrizes ortogonais preservam produtos internos, normas e distâncias euclidianas.

Além disso,

$$\det(\mathbf{Q})^2 = \det(\mathbf{Q}^\top \mathbf{Q}) = \det(\mathbf{I}_n) = 1,$$

de modo que

$$\det(\mathbf{Q}) \in \{-1, 1\}.$$

O produto de matrizes ortogonais de mesma ordem também é ortogonal.

As interpretações das matrizes ortogonais como rotações, reflexões e mudanças de orientação serão desenvolvidas no capítulo sobre transformações lineares.

2.4.2 Matrizes diagonais

Definição 2.16 (Matriz diagonal). Uma matriz

$$\mathbf{D} = (d_{ij})_{n \times n} \in \mathbb{R}^{n \times n}$$

é **diagonal** quando

$$d_{ij} = 0 \quad \text{para} \quad i \neq j.$$

Uma matriz diagonal possui a forma

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & d_n \end{bmatrix} = \text{diag} \left(\begin{bmatrix} d_1 \\ d_2 \\ \vdots \\ d_n \end{bmatrix} \right).$$

A matriz identidade é uma matriz diagonal:

$$\mathbf{I}_n = \text{diag}(1, 1, \dots, 1).$$

Toda matriz diagonal é simétrica, pois

$$\mathbf{D}^\top = \mathbf{D}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix},$$

o produto por uma matriz diagonal é

$$\mathbf{D}\mathbf{x} = \begin{bmatrix} d_1 x_1 \\ d_2 x_2 \\ \vdots \\ d_n x_n \end{bmatrix}.$$

Cada componente de $\mathbf{x}$ é multiplicada pelo elemento correspondente da diagonal.

Exemplo 2.20 (Produto por uma matriz diagonal). Considere

$$\mathbf{D} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & 3 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} 1 \\ 4 \\ -2 \end{bmatrix}.$$

Então,

$$\mathbf{D}\mathbf{x} = \begin{bmatrix} 2(1) \\ -1(4) \\ 3(-2) \end{bmatrix} = \begin{bmatrix} 2 \\ -4 \\ -6 \end{bmatrix}.$$

A soma e o produto de matrizes diagonais de mesma ordem também são diagonais. Se

$$\mathbf{D}_1 = \text{diag}(d_1, \dots, d_n)$$

e

$$\mathbf{D}_2 = \text{diag}(e_1, \dots, e_n),$$

então

$$\mathbf{D}_1 + \mathbf{D}_2 = \text{diag}(d_1 + e_1, \dots, d_n + e_n)$$

e

$$\mathbf{D}_1 \mathbf{D}_2 = \text{diag}(d_1 e_1, \dots, d_n e_n).$$

Duas matrizes diagonais de mesma ordem comutam:

$$\mathbf{D}_1 \mathbf{D}_2 = \mathbf{D}_2 \mathbf{D}_1.$$

O determinante de uma matriz diagonal é o produto dos elementos de sua diagonal:

$$\det(\mathbf{D}) = \prod_{i=1}^n d_i.$$

Logo, $\mathbf{D}$ é invertível se, e somente se,

$$d_i \neq 0, \quad i = 1, \dots, n.$$

Nesse caso,

$$\mathbf{D}^{-1} = \text{diag} \left(\frac{1}{d_1}, \frac{1}{d_2}, \dots, \frac{1}{d_n} \right).$$

Para um inteiro positivo k ,

$$\mathbf{D}^k = \text{diag}(d_1^k, d_2^k, \dots, d_n^k).$$

As matrizes diagonais aparecem naturalmente em decomposições matriciais.

2.5 Formas quadráticas e positividade

As formas quadráticas associam um vetor a um escalar por meio de uma expressão do tipo $\mathbf{x}^\top \mathbf{A} \mathbf{x}$. Elas aparecem em somas de quadrados, variâncias, distâncias e densidades multivariadas e permitem relacionar propriedades de matrizes simétricas a propriedades escalares.

2.5.1 Formas quadráticas

Definição 2.17 (Forma quadrática). Seja

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

A função

$$Q : \mathbb{R}^p \longrightarrow \mathbb{R}$$

definida por

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

é denominada **forma quadrática** associada à matriz $\mathbf{A}$. (Searle; Khuri, 2017)

A forma quadrática depende de um único vetor e, em geral, não é uma função linear desse vetor. Para qualquer $\alpha \in \mathbb{R}$,

$$\begin{aligned} Q(\alpha \mathbf{x}) &= (\alpha \mathbf{x})^\top \mathbf{A}(\alpha \mathbf{x}) \\ &= \alpha^2 \mathbf{x}^\top \mathbf{A} \mathbf{x} \\ &= \alpha^2 Q(\mathbf{x}). \end{aligned}$$

O produto interno usual corresponde ao caso $\mathbf{A} = \mathbf{I}_p$.

Exemplo 2.21 (Produto interno e norma ao quadrado). Considere $\mathbf{A} = \mathbf{I}_p$. Então,

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{I}_p \mathbf{x} = \mathbf{x}^\top \mathbf{x} = \langle \mathbf{x}, \mathbf{x} \rangle = \|\mathbf{x}\|^2.$$

Portanto, a norma euclidiana ao quadrado é uma forma quadrática cuja matriz representante é $\mathbf{I}_p$.

Em geral, se

$$\mathbf{A} = (a_{ij})_{p \times p},$$

então

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{i=1}^p \sum_{j=1}^p a_{ij} x_i x_j. \quad (2.1)$$

Para

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

tem-se

$$\begin{aligned}
Q(\mathbf{x}) &= \mathbf{x}^\top \mathbf{A} \mathbf{x} \\
&= \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} a & b \\ c & d \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \\
&= ax_1^2 + (b+c)x_1x_2 + dx_2^2.
\end{aligned}$$

Os termos fora da diagonal aparecem combinados. No caso bidimensional, b e c contribuem somente por meio da soma

$$b + c.$$

Consequentemente, a matriz que aparece em uma representação

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

não é necessariamente única quando matrizes não simétricas são admitidas. Duas matrizes com a mesma parte simétrica produzem a mesma forma quadrática.

Entretanto, toda forma quadrática possui uma única matriz simétrica que a representa. Essa propriedade é apresentada na proposição seguinte.

Proposição 2.10 (Parte simétrica de uma forma quadrática). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e defina

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2}.$$


Então $\mathbf{S}$ é simétrica e, para todo

$$\mathbf{x} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{S} \mathbf{x}.$$

Além disso, $\mathbf{S}$ é a única matriz simétrica que representa essa forma quadrática.



Assim, embora uma forma quadrática possa possuir diferentes representações por matrizes não simétricas, sua representação por uma matriz simétrica é única.

Por essa razão, no estudo de formas quadráticas, pode-se trabalhar sem perda de generalidade com matrizes simétricas.

A parcela

$$\mathbf{K} = \frac{\mathbf{A} - \mathbf{A}^\top}{2},$$

por satisfazer $\mathbf{K}^\top = -\mathbf{K}$, não altera o valor de $\mathbf{x}^\top \mathbf{A} \mathbf{x}$. Portanto, toda forma quadrática pode ser estudada por sua única matriz simétrica representante.

Exemplo 2.22 (Expansão de uma forma quadrática). Considere

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

A forma quadrática associada a $\mathbf{A}$ é

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

Então,

$$Q(\mathbf{x}) = \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

Efetuando os produtos,

$$Q(\mathbf{x}) = 2x_1^2 + 2x_1x_2 + 3x_2^2.$$

Para

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix},$$

obtém-se

$$\begin{aligned}Q(\mathbf{x}) &= 2(1)^2 + 2(1)(2) + 3(2)^2 \\&= 2 + 4 + 12 \\&= 18.\end{aligned}$$

2.5.2 Positividade

Como toda forma quadrática pode ser representada por uma única matriz simétrica, propriedades importantes da forma quadrática podem ser estudadas a partir dos valores assumidos por

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x},$$

com $\mathbf{A}$ simétrica.

A classificação em positiva definida, semidefinida positiva, negativa definida, semidefinida negativa ou indefinida depende do sinal assumido por essa expressão.

Definição 2.18 (Classificação de matrizes simétricas pela forma quadrática). Seja

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

uma matriz simétrica e considere a forma quadrática

$$q_{\mathbf{A}}(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

A matriz $\mathbf{A}$ é:

- **positiva definida** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$. Nesse caso, escreve-se

$$\mathbf{A} \succ \mathbf{0};$$

- **semidefinida positiva** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} \geq 0$$

para todo $\mathbf{x} \in \mathbb{R}^p$. Nesse caso, escreve-se

$$\mathbf{A} \succeq \mathbf{0};$$

- **negativa definida** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} < 0$$

para todo $\mathbf{x} \neq \mathbf{0}$. Nesse caso, escreve-se

$$\mathbf{A} \prec \mathbf{0};$$

- **semidefinida negativa** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} \leq 0$$

para todo $\mathbf{x} \in \mathbb{R}^p$. Nesse caso, escreve-se

$$\mathbf{A} \preceq \mathbf{0};$$

- **indefinida** quando existem vetores não nulos $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ tais que

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0$$

e

$$\mathbf{y}^\top \mathbf{A} \mathbf{y} < 0.$$

Para matrizes indefinidas, não se utiliza uma relação de ordem do tipo $\mathbf{A} \succeq \mathbf{0}$ ou $\mathbf{A} \preceq \mathbf{0}$.

Com essas definições, toda matriz positiva definida é também semidefinida positiva, e toda matriz negativa definida é também semidefinida negativa. Quando for necessário excluir os casos definidos, essa restrição será indicada explicitamente.

As notações $\succ$, $\succeq$, $\prec$ e $\preceq$ expressam a ordem de Löwner para matrizes simétricas. Em particular,

$$\begin{aligned}\mathbf{A} \succ \mathbf{0} &\iff \mathbf{A} \text{ é positiva definida,} \\ \mathbf{A} \succeq \mathbf{0} &\iff \mathbf{A} \text{ é semidefinida positiva,} \\ \mathbf{A} \prec \mathbf{0} &\iff \mathbf{A} \text{ é negativa definida,} \\ \mathbf{A} \preceq \mathbf{0} &\iff \mathbf{A} \text{ é semidefinida negativa.}\end{aligned}$$

O produto interno usual fornece um exemplo imediato de forma quadrática associada a uma matriz positiva definida.

Como

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{I}_p \mathbf{x} = \|\mathbf{x}\|^2,$$

tem-se

$$Q(\mathbf{x}) > 0$$

para todo

$$\mathbf{x} \neq \mathbf{0}.$$

Portanto, a matriz identidade

$$\mathbf{I}_p$$

é positiva definida.

Outro exemplo importante de matriz semidefinida positiva é obtido pelo produto externo de um vetor consigo mesmo.

Para

$$\mathbf{x}, \mathbf{z} \in \mathbb{R}^p,$$

considere

$$\mathbf{x}\mathbf{x}^\top.$$

Então,

$$\begin{aligned}\mathbf{z}^\top (\mathbf{x}\mathbf{x}^\top) \mathbf{z} &= (\mathbf{z}^\top \mathbf{x}) (\mathbf{x}^\top \mathbf{z}) \\ &= (\mathbf{x}^\top \mathbf{z})^2 \\ &\geq 0.\end{aligned}$$

Portanto,

$$\mathbf{x}\mathbf{x}^\top$$

é semidefinida positiva.

Se $\mathbf{x} \neq \mathbf{0}$, então

$$\text{rank}(\mathbf{x}\mathbf{x}^\top) = 1.$$

Assim, quando $p > 1$, existem vetores não nulos $\mathbf{z}$ ortogonais a $\mathbf{x}$. Para esses vetores,

$$\mathbf{x}^\top \mathbf{z} = 0$$

e, portanto,

$$\mathbf{z}^\top (\mathbf{x}\mathbf{x}^\top) \mathbf{z} = 0.$$

Logo, para $p > 1$ e $\mathbf{x} \neq \mathbf{0}$, a matriz

$$\mathbf{x}\mathbf{x}^\top$$

é semidefinida positiva, mas não positiva definida.

Esse tipo de matriz terá importância particular na construção das matrizes de covariâncias, que envolvem somas de produtos externos de vetores de desvios.

Exemplo 2.23 (Classificação de formas quadráticas). Considere inicialmente

$$\mathbf{A} = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

tem-se

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x} = 2x_1^2 + 3x_2^2.$$

Como

$$2x_1^2 + 3x_2^2 > 0$$

para todo

$$\mathbf{x} \neq \mathbf{0},$$

a matriz $\mathbf{A}$ é positiva definida.

Considere agora

$$\mathbf{B} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}.$$

Nesse caso,

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{B} \mathbf{x} = x_1^2 \geq 0.$$

Portanto, $\mathbf{B}$ é semidefinida positiva.

Entretanto, para vetores não nulos da forma

$$\mathbf{x} = \begin{bmatrix} 0 \\ x_2 \end{bmatrix}, \quad x_2 \neq 0,$$

tem-se

$$Q(\mathbf{x}) = 0.$$

Assim, $\mathbf{B}$ não é positiva definida.

Finalmente, considere

$$\mathbf{C} = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}.$$

A forma quadrática associada é

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{C} \mathbf{x} = x_1^2 - x_2^2.$$

Para

$$\mathbf{x} = \begin{bmatrix} 1 \\ 0 \end{bmatrix},$$

obtém-se

$$Q(\mathbf{x}) = 1 > 0.$$

Por outro lado, para

$$\mathbf{y} = \begin{bmatrix} 0 \\ 1 \end{bmatrix},$$

obtém-se

$$Q(\mathbf{y}) = -1 < 0.$$

Portanto, a forma quadrática assume valores positivos e negativos, e a matriz $\mathbf{C}$ é indefinida.

2.5.3 Superfícies de nível

Uma superfície de nível de uma forma quadrática é definida por

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = c,$$

em que c é uma constante.

Quando $\mathbf{A}$ é positiva definida e $c > 0$, as superfícies de nível são elipsoides. Em duas dimensões, correspondem a elipses. Para $c = 0$, a superfície contém somente o vetor nulo, enquanto, para $c < 0$, não existem pontos que satisfaçam a equação.

Quando $\mathbf{A}$ é indefinida, a forma quadrática assume valores positivos e negativos. Em duas dimensões, no caso indefinido não singular, os níveis não nulos formam hipérboles. O nível zero pode formar um par de retas que se cruzam na origem. Por exemplo,

$$x_1^2 - x_2^2 = 0$$

equivale a

$$x_2 = x_1 \quad \text{ou} \quad x_2 = -x_1.$$

A Figura 2.1 apresenta três formas quadráticas em $\mathbb{R}^2$.




Figura 2.1: Curvas de nível de formas quadráticas em duas dimensões. Na forma indefinida, níveis positivos, negativos e nulos são diferenciados também pelo tipo de linha.

A primeira forma produz circunferências. A segunda produz elipses com eixos de comprimentos diferentes. A terceira produz hipérboles.

Formas quadráticas aparecem em expressões de distância, variância e densidade. Os critérios baseados em autovalores serão apresentados no capítulo sobre decomposição espectral.

2.6 Matrizes particionadas e complemento de Schur

Uma matriz pode ser dividida em submatrizes denominadas blocos. O particionamento organiza os elementos sem alterar a matriz e permite realizar operações matriciais utilizando os blocos.

2.6.1 Matrizes particionadas

Definição 2.19 (Matriz particionada). Considere

$$\mathbf{A} \in \mathbb{R}^{(m_1+m_2) \times (n_1+n_2)}.$$

Um particionamento de $\mathbf{A}$ em quatro blocos pode ser escrito como

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

em que

$$\mathbf{A}_{11} \in \mathbb{R}^{m_1 \times n_1}, \quad \mathbf{A}_{12} \in \mathbb{R}^{m_1 \times n_2},$$

$$\mathbf{A}_{21} \in \mathbb{R}^{m_2 \times n_1}, \quad \mathbf{A}_{22} \in \mathbb{R}^{m_2 \times n_2}.$$

Os blocos de uma mesma linha do particionamento possuem o mesmo número de linhas. Os blocos de uma mesma coluna possuem o mesmo número de colunas.

Exemplo 2.24 (Particionamento de uma matriz). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}.$$

Separando as duas primeiras linhas e colunas das restantes,

$$\mathbf{A} = \left[\begin{array}{cc|c} 1 & 2 & 3 \\ 4 & 5 & 6 \\ \hline 7 & 8 & 9 \end{array} \right] = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

com

$$\mathbf{A}_{11} = \begin{bmatrix} 1 & 2 \\ 4 & 5 \end{bmatrix}, \quad \mathbf{A}_{12} = \begin{bmatrix} 3 \\ 6 \end{bmatrix},$$

$$\mathbf{A}_{21} = \begin{bmatrix} 7 & 8 \end{bmatrix}, \quad \mathbf{A}_{22} = \begin{bmatrix} 9 \end{bmatrix}.$$

O particionamento pode ser definido de acordo com a organização do problema. Em uma matriz de dados, por exemplo, as colunas podem ser separadas em dois grupos de variáveis:

$$\mathbf{X} = [\mathbf{X}_1 \ \mathbf{X}_2],$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{n \times p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{n \times p_2}$$

e

$$p_1 + p_2 = p.$$

2.6.2 Soma e multiplicação por escalar

Considere matrizes com o mesmo particionamento:

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{bmatrix}.$$

A soma pode ser realizada por blocos:

$$\mathbf{A} + \mathbf{B} = \begin{bmatrix} \mathbf{A}_{11} + \mathbf{B}_{11} & \mathbf{A}_{12} + \mathbf{B}_{12} \\ \mathbf{A}_{21} + \mathbf{B}_{21} & \mathbf{A}_{22} + \mathbf{B}_{22} \end{bmatrix}.$$

Para $\alpha \in \mathbb{R}$,

$$\alpha \mathbf{A} = \begin{bmatrix} \alpha \mathbf{A}_{11} & \alpha \mathbf{A}_{12} \\ \alpha \mathbf{A}_{21} & \alpha \mathbf{A}_{22} \end{bmatrix}.$$

As operações exigem que os blocos correspondentes possuam as mesmas dimensões.

2.6.3 Transposição por blocos

A transposta de uma matriz particionada é

$$\mathbf{A}^\top = \begin{bmatrix} \mathbf{A}_{11}^\top & \mathbf{A}_{21}^\top \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22}^\top \end{bmatrix}.$$

Os blocos situados fora da diagonal trocam de posição e são transpostos.

Se $\mathbf{A}$ é simétrica, então

$$\mathbf{A}_{11}^\top = \mathbf{A}_{11}, \quad \mathbf{A}_{22}^\top = \mathbf{A}_{22}$$

e

$$\mathbf{A}_{21} = \mathbf{A}_{12}^\top.$$

Nesse caso, a matriz pode ser escrita como

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22} \end{bmatrix}.$$

2.6.4 Multiplicação por blocos

Considere

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix} \in \mathbb{R}^{(m_1+m_2) \times (n_1+n_2)}$$

e

$$\mathbf{B} = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{bmatrix} \in \mathbb{R}^{(n_1+n_2) \times (r_1+r_2)},$$

com

$$\mathbf{B}_{11} \in \mathbb{R}^{n_1 \times r_1}, \quad \mathbf{B}_{12} \in \mathbb{R}^{n_1 \times r_2},$$

$$\mathbf{B}_{21} \in \mathbb{R}^{n_2 \times r_1}, \quad \mathbf{B}_{22} \in \mathbb{R}^{n_2 \times r_2}.$$

O produto é

$$\mathbf{AB} = \begin{bmatrix} \mathbf{A}_{11}\mathbf{B}_{11} + \mathbf{A}_{12}\mathbf{B}_{21} & \mathbf{A}_{11}\mathbf{B}_{12} + \mathbf{A}_{12}\mathbf{B}_{22} \\ \mathbf{A}_{21}\mathbf{B}_{11} + \mathbf{A}_{22}\mathbf{B}_{21} & \mathbf{A}_{21}\mathbf{B}_{12} + \mathbf{A}_{22}\mathbf{B}_{22} \end{bmatrix}.$$

A regra é a mesma utilizada no produto matricial, com os elementos substituídos por blocos de dimensões compatíveis.

Exemplo 2.25 (Multiplicação de matrizes particionadas). Considere

$$\mathbf{A} = \left[\begin{array}{cc|c} 1 & 2 & 1 \\ 0 & 1 & 3 \\ \hline 2 & 0 & 4 \end{array} \right] = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}$$

e

$$\mathbf{B} = \left[\begin{array}{cc|c} 1 & 0 & 1 \\ 2 & 1 & 0 \\ \hline -1 & 2 & 3 \end{array} \right] = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{bmatrix}.$$

Os blocos da primeira linha do produto são

$$\mathbf{A}_{11}\mathbf{B}_{11} + \mathbf{A}_{12}\mathbf{B}_{21} = \begin{bmatrix} 4 & 4 \\ -1 & 7 \end{bmatrix}$$

e

$$\mathbf{A}_{11}\mathbf{B}_{12} + \mathbf{A}_{12}\mathbf{B}_{22} = \begin{bmatrix} 4 \\ 9 \end{bmatrix}.$$

Os blocos da segunda linha são

$$\mathbf{A}_{21}\mathbf{B}_{11} + \mathbf{A}_{22}\mathbf{B}_{21} = \begin{bmatrix} -2 & 8 \end{bmatrix}$$

e

$$\mathbf{A}_{21}\mathbf{B}_{12} + \mathbf{A}_{22}\mathbf{B}_{22} = \begin{bmatrix} 14 \end{bmatrix}.$$

Portanto,

$$\mathbf{AB} = \left[\begin{array}{cc|c} 4 & 4 & 4 \\ -1 & 7 & 9 \\ \hline -2 & 8 & 14 \end{array} \right].$$

As operações por blocos permitem manipular grupos de linhas e colunas como unidades matriciais. (Anderson, 2003)

O complemento de Schur utiliza essa estrutura para representar a parcela de um bloco ajustada pelo outro.

2.6.5 Complemento de Schur

Matrizes particionadas permitem tratar uma matriz de grande dimensão a partir de blocos menores. Em vários problemas, é útil eliminar um desses blocos e estudar a estrutura que permanece no outro. O **complemento de Schur** é a matriz que surge naturalmente nesse processo de eliminação.

Definição 2.20 (Complemento de Schur). Considere a matriz quadrada particionada

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

em que

$$\mathbf{A}_{11} \in \mathbb{R}^{p \times p}, \quad \mathbf{A}_{12} \in \mathbb{R}^{p \times q},$$

$$\mathbf{A}_{21} \in \mathbb{R}^{q \times p}, \quad \mathbf{A}_{22} \in \mathbb{R}^{q \times q}.$$

Os blocos diagonais $\mathbf{A}_{11}$ e $\mathbf{A}_{22}$ são quadrados. Quando um deles é invertível, podemos utilizá-lo para eliminar os efeitos dos blocos fora da diagonal.

Se $\mathbf{A}_{22}$ é invertível, o **complemento de Schur de $\mathbf{A}_{22}$** em $\mathbf{A}$ é

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21}.$$

Se $\mathbf{A}_{11}$ é invertível, o **complemento de Schur de $\mathbf{A}_{11}$** em $\mathbf{A}$ é

$$\mathbf{A}_{22.1} = \mathbf{A}_{22} - \mathbf{A}_{21} \mathbf{A}_{11}^{-1} \mathbf{A}_{12}.$$

(Searle; Khuri, 2017)

O complemento $\mathbf{A}_{11.2}$ possui dimensão $p \times p$, enquanto $\mathbf{A}_{22.1}$ possui dimensão $q \times q$.

A expressão pode ser compreendida como uma correção do bloco diagonal original. Por exemplo,

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21}$$

parte de $\mathbf{A}_{11}$ e retira a parcela associada às relações que passam pelo segundo bloco. A fatoração matricial que produz essa correção é apresentada na Seção 2.7.6.

Exemplo 2.26 (Cálculo de um complemento de Schur). Considere a matriz particionada

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

em que

$$\mathbf{A}_{11} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}, \quad \mathbf{A}_{12} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix},$$

$$\mathbf{A}_{21} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{A}_{22} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

Como $\mathbf{A}_{22} = \mathbf{I}_2$, tem-se $\mathbf{A}_{22}^{-1} = \mathbf{I}_2$. Logo,

$$\begin{aligned} \mathbf{A}_{11 \cdot 2} &= \mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21} \\ &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} - \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}. \end{aligned}$$

2.6.6 Positividade e complemento de Schur

Para matrizes simétricas, o complemento de Schur permite verificar a definição positiva de uma matriz particionada por meio de matrizes de menor dimensão.

Considere

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22} \end{bmatrix}.$$

Para estudar se $\mathbf{A}$ é positiva definida, consideramos sua forma quadrática. Para $\mathbf{x} \in \mathbb{R}^p$ e $\mathbf{y} \in \mathbb{R}^q$,

$$\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix}^\top \mathbf{A} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} = \mathbf{x}^\top \mathbf{A}_{11} \mathbf{x} + 2\mathbf{x}^\top \mathbf{A}_{12} \mathbf{y} + \mathbf{y}^\top \mathbf{A}_{22} \mathbf{y}.$$

Quando $\mathbf{A}_{22}$ é invertível, os termos envolvendo $\mathbf{y}$ podem ser reorganizados completando a forma quadrática:

$$\begin{aligned}
& \mathbf{x}^\top \mathbf{A}_{11} \mathbf{x} + 2\mathbf{x}^\top \mathbf{A}_{12} \mathbf{y} + \mathbf{y}^\top \mathbf{A}_{22} \mathbf{y} \\
&= \mathbf{x}^\top (\mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top) \mathbf{x} \\
&\quad + (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x})^\top \mathbf{A}_{22} (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x}).
\end{aligned}$$

O primeiro termo contém exatamente o complemento de Schur de $\mathbf{A}_{22}$.

Teorema 2.7 (Positividade e complemento de Schur). *Considere a matriz simétrica*

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22} \end{bmatrix}.$$

Se $\mathbf{A}_{22}$ é positiva definida, então $\mathbf{A}$ é positiva definida se, e somente se,

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top$$

é positiva definida. (Gentle, 2017)

i Demonstração

Pela decomposição da forma quadrática,

$$\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix}^\top \mathbf{A} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} = \mathbf{x}^\top \mathbf{A}_{11 \cdot 2} \mathbf{x} + (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x})^\top \mathbf{A}_{22} (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x}).$$

Suponha inicialmente que $\mathbf{A}_{11 \cdot 2}$ e $\mathbf{A}_{22}$ sejam positivas definidas.

Se $\mathbf{x} \neq \mathbf{0}$, então

$$\mathbf{x}^\top \mathbf{A}_{11 \cdot 2} \mathbf{x} > 0,$$

enquanto a segunda parcela é não negativa.

Se $\mathbf{x} = \mathbf{0}$, então $\mathbf{y} \neq \mathbf{0}$ e a forma quadrática reduz-se a

$$\mathbf{y}^\top \mathbf{A}_{22} \mathbf{y} > 0.$$

Logo, $\mathbf{A}$ é positiva definida.

Reciprocamente, suponha que $\mathbf{A}$ seja positiva definida. Para qualquer $\mathbf{x} \neq \mathbf{0}$, escolha

$$\mathbf{y} = -\mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x}.$$

Com essa escolha, a segunda parcela da decomposição é igual a zero. Portanto,

$$\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix}^\top \mathbf{A} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} = \mathbf{x}^\top \mathbf{A}_{11 \cdot 2} \mathbf{x} > 0.$$

Assim, $\mathbf{A}_{11 \cdot 2}$ é positiva definida.

Uma condição equivalente pode ser formulada utilizando $\mathbf{A}_{11}$ e o complemento $\mathbf{A}_{22 \cdot 1}$.

Algebricamente, o termo

$$\mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21}$$

representa a correção associada ao segundo bloco, enquanto

$$\mathbf{A}_{11 \cdot 2} = \mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21}$$

representa o primeiro bloco depois dessa correção.

Essa interpretação é puramente matricial e vale para matrizes particionadas gerais.

Quando $\mathbf{A}$ é uma matriz de covariâncias particionada,

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22} \end{bmatrix},$$

o complemento

$$\mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{12}^\top$$

representa a covariância residual do primeiro bloco após o ajuste linear pelo segundo bloco, como desenvolvido na Capítulo 8. Sob normalidade conjunta, a mesma matriz é a covariância condicional do primeiro bloco dado o segundo, como apresentado na Capítulo 9. (Anderson, 2003)

2.7 Aprofundamento teórico

2.7.1 Antissimetria e decomposição simétrica-antissimétrica

Definição 2.21 (Matriz antissimétrica). Uma matriz $\mathbf{A} \in \mathbb{R}^{n \times n}$ é **antissimétrica** quando

$$\mathbf{A}^\top = -\mathbf{A}.$$

Os elementos da diagonal principal de uma matriz antissimétrica são iguais a zero. De fato,

$$a_{ii} = -a_{ii}$$

implica

$$a_{ii} = 0.$$

Uma matriz antissimétrica possui a forma

$$\mathbf{A} = \begin{bmatrix} 0 & a_{12} & \cdots & a_{1n} \\ -a_{12} & 0 & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ -a_{1n} & -a_{2n} & \cdots & 0 \end{bmatrix}.$$

Teorema 2.8 (Decomposição em partes simétrica e antissimétrica). *Toda matriz quadrada $\mathbf{A} \in \mathbb{R}^{n \times n}$ pode ser escrita de maneira única como*

$$\mathbf{A} = \mathbf{S} + \mathbf{K},$$

em que

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2}$$

é simétrica e

$$\mathbf{K} = \frac{\mathbf{A} - \mathbf{A}^\top}{2}$$

é antissimétrica. (Searle; Khuri, 2017)

i Demonstração

A transposta de $\mathbf{S}$ é

$$\mathbf{S}^\top = \left(\frac{\mathbf{A} + \mathbf{A}^\top}{2} \right)^\top = \frac{\mathbf{A}^\top + \mathbf{A}}{2} = \mathbf{S}.$$

Logo, $\mathbf{S}$ é simétrica.

Para $\mathbf{K}$,

$$\mathbf{K}^\top = \left(\frac{\mathbf{A} - \mathbf{A}^\top}{2} \right)^\top = \frac{\mathbf{A}^\top - \mathbf{A}}{2} = -\mathbf{K}.$$

Logo, $\mathbf{K}$ é antissimétrica. Além disso,

$$\mathbf{S} + \mathbf{K} = \frac{\mathbf{A} + \mathbf{A}^\top}{2} + \frac{\mathbf{A} - \mathbf{A}^\top}{2} = \mathbf{A}.$$

Para verificar a unicidade, suponha que

$$\mathbf{A} = \mathbf{S}_1 + \mathbf{K}_1,$$

em que $\mathbf{S}_1$ é simétrica e $\mathbf{K}_1$ é antissimétrica. Transpondo essa igualdade,

$$\mathbf{A}^\top = \mathbf{S}_1 - \mathbf{K}_1.$$

Somando e subtraindo as duas expressões, obtém-se

$$\mathbf{S}_1 = \frac{\mathbf{A} + \mathbf{A}^\top}{2}$$

e

$$\mathbf{K}_1 = \frac{\mathbf{A} - \mathbf{A}^\top}{2}.$$

Portanto, as partes simétrica e antissimétrica são únicas.

Exemplo 2.27 (Partes simétrica e antissimétrica). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 4 \\ -2 & 3 \end{bmatrix}.$$

A parte simétrica é

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2} = \frac{1}{2} \left(\begin{bmatrix} 1 & 4 \\ -2 & 3 \end{bmatrix} + \begin{bmatrix} 1 & -2 \\ 4 & 3 \end{bmatrix} \right) = \begin{bmatrix} 1 & 1 \\ 1 & 3 \end{bmatrix}.$$

A parte antissimétrica é

$$\mathbf{K} = \frac{\mathbf{A} - \mathbf{A}^\top}{2} = \frac{1}{2} \left(\begin{bmatrix} 1 & 4 \\ -2 & 3 \end{bmatrix} - \begin{bmatrix} 1 & -2 \\ 4 & 3 \end{bmatrix} \right) = \begin{bmatrix} 0 & 3 \\ -3 & 0 \end{bmatrix}.$$

Portanto,

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & 3 \end{bmatrix} + \begin{bmatrix} 0 & 3 \\ -3 & 0 \end{bmatrix}.$$

2.7.2 Cálculo por cofatores

Definição 2.22 (Menor e cofator). Seja

$$\mathbf{A} = (a_{ij})_{n \times n}.$$

O **menor** M_{ij} é o determinante da matriz obtida pela retirada da linha i e da coluna j de $\mathbf{A}$.

O **cofator** do elemento a_{ij} é

$$C_{ij} = (-1)^{i+j} M_{ij}.$$

Para uma matriz $\mathbf{A} = (a_{ij})_{n \times n}$, a expansão em cofatores de uma linha fixa i é

$$\det(\mathbf{A}) = \sum_{j=1}^n a_{ij} C_{ij},$$

e a expansão em cofatores de uma coluna fixa j é

$$\det(\mathbf{A}) = \sum_{i=1}^n a_{ij} C_{ij}.$$

Cada cofator envolve o determinante de uma matriz de ordem $n - 1$, de modo que a expansão pode ser aplicada recursivamente. (Gentle, 2017)

Para uma matriz de ordem três, a expansão pela primeira linha é

$$\det(\mathbf{A}) = a_{11} C_{11} + a_{12} C_{12} + a_{13} C_{13}.$$

Exemplo 2.28 (Determinante de uma matriz de ordem três). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 0 \\ 3 & 1 & 2 \\ 0 & 4 & 1 \end{bmatrix}.$$

Expandindo pela primeira linha,

$$\det(\mathbf{A}) = 1 \begin{vmatrix} 1 & 2 \\ 4 & 1 \end{vmatrix} - 2 \begin{vmatrix} 3 & 2 \\ 0 & 1 \end{vmatrix} + 0 \begin{vmatrix} 3 & 1 \\ 0 & 4 \end{vmatrix}.$$

Portanto,

$$\det(\mathbf{A}) = 1(1 - 8) - 2(3 - 0) = -13.$$

Cálculo de determinantes

A expansão por cofatores é útil para compreender a definição do determinante e realizar cálculos de pequena ordem. Para matrizes maiores, a expansão direta se torna pouco eficiente. Nesses casos, o determinante costuma ser obtido por eliminação ou por decomposições matriciais.

2.7.3 Interpretação geométrica do determinante

Considere uma matriz quadrada

$$\mathbf{A} = [\mathbf{a}_1 \quad \mathbf{a}_2 \quad \cdots \quad \mathbf{a}_n] \in \mathbb{R}^{n \times n}.$$

As colunas de $\mathbf{A}$ podem ser interpretadas como vetores em $\mathbb{R}^n$. Esses vetores determinam uma região geométrica cuja medida depende de suas direções e comprimentos.

O valor absoluto do determinante,

$$|\det(\mathbf{A})|,$$

corresponde à medida do paralelepípedo determinado pelas colunas de $\mathbf{A}$:

- em uma dimensão, corresponde a um comprimento;
- em duas dimensões, corresponde à área do paralelogramo determinado pelas duas colunas;

- em três dimensões, corresponde ao volume do paralelepípedo determinado pelas três colunas;
- em $\mathbb{R}^n$, corresponde ao volume n -dimensional determinado pelas n colunas.

Como a matriz identidade $\mathbf{I}_n$ possui determinante igual a 1, suas colunas determinam uma região de volume unitário. Assim, $|\det(\mathbf{A})|$ também pode ser interpretado como o fator pelo qual esse volume unitário é ampliado ou reduzido quando os vetores canônicos são substituídos pelas colunas de $\mathbf{A}$.

O sinal do determinante acrescenta informação sobre a orientação dos vetores:

- se $\det(\mathbf{A}) > 0$, a orientação é preservada;
- se $\det(\mathbf{A}) < 0$, a orientação é invertida;
- se $\det(\mathbf{A}) = 0$, o volume n -dimensional é nulo.

No último caso, as colunas não determinam todas as direções necessárias para formar um volume n -dimensional. Em $\mathbb{R}^2$, por exemplo, duas colunas alinhadas formam uma região de área zero; em $\mathbb{R}^3$, três colunas contidas em um mesmo plano formam uma região de volume zero.

A Figura 2.2 apresenta essas situações em $\mathbb{R}^2$.




Figura 2.2: Interpretação geométrica do determinante em duas dimensões.

Na primeira situação, $\det(\mathbf{A}) = 2$: a área é multiplicada por 2 e a orientação é preservada. Na segunda, $\det(\mathbf{A}) = 0$: a região bidimensional é comprimida em uma reta. Na terceira, $\det(\mathbf{A}) = -2$: a área também é multiplicada por 2, mas a orientação é invertida.

O determinante informa se uma matriz quadrada é invertível. O posto amplia essa análise para matrizes quadradas ou retangulares.

2.7.4 Pseudoinversa de Moore–Penrose

A pseudoinversa estende a resolução de sistemas lineares a matrizes retangulares ou singulares. As condições de Moore–Penrose a caracterizam; a decomposição em valores singulares fornece sua construção no Capítulo 6.

Definição 2.23 (Pseudoinversa de Moore–Penrose). Seja

$$\mathbf{A} \in \mathbb{R}^{n \times p}.$$

A **pseudoinversa de Moore–Penrose** de $\mathbf{A}$ é a única matriz

$$\mathbf{A}^+ \in \mathbb{R}^{p \times n}$$

que satisfaz simultaneamente:

$$\mathbf{A}\mathbf{A}^+\mathbf{A} = \mathbf{A},$$

$$\mathbf{A}^+\mathbf{A}\mathbf{A}^+ = \mathbf{A}^+,$$

$$(\mathbf{A}\mathbf{A}^+)^{\top} = \mathbf{A}\mathbf{A}^+$$

e

$$(\mathbf{A}^+\mathbf{A})^{\top} = \mathbf{A}^+\mathbf{A}.$$

(Gentle, 2017)

Quando $\mathbf{A}$ é quadrada e invertível,

$$\mathbf{A}^+ = \mathbf{A}^{-1}.$$

Considere o problema

$$\mathbf{A}\mathbf{x} = \mathbf{b}.$$

O vetor

$$\mathbf{x}^+ = \mathbf{A}^+ \mathbf{b}$$

possui interpretações diferentes conforme a existência e a quantidade de soluções exatas.

Tabela 2.2: Interpretação da solução obtida pela pseudoinversa.

Situação do sistema	Interpretação de $\mathbf{x}^+ = \mathbf{A}^+ \mathbf{b}$
O sistema é consistente e possui solução única	$\mathbf{x}^+$ é a solução exata do sistema
O sistema é consistente e possui várias soluções	$\mathbf{x}^+$ é a solução exata de menor norma euclidiana
O sistema é inconsistente	$\mathbf{x}^+$ minimiza $\ \mathbf{Ax} - \mathbf{b}\ $ e possui a menor norma entre todos os minimizadores

(Gentle, 2017)

No caso inconsistente, $\mathbf{x}^+$ resolve o problema de mínimos quadrados

$$\min_{\mathbf{x} \in \mathbb{R}^p} \|\mathbf{Ax} - \mathbf{b}\|.$$

Pseudoinversa e inversa

Em geral,

$$\mathbf{A}^+ \mathbf{A} \neq \mathbf{I}_p$$

e

$$\mathbf{AA}^+ \neq \mathbf{I}_n.$$

Portanto, a pseudoinversa não satisfaz todas as propriedades da inversa usual.

2.7.5 Matrizes e sistemas triangulares

Definição 2.24 (Matrizes triangulares). Uma matriz

$$\mathbf{U} = (u_{ij})_{n \times n}$$

é **triangular superior** quando

$$u_{ij} = 0 \quad \text{para} \quad i > j.$$

Sua forma geral é

$$\mathbf{U} = \begin{bmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ 0 & u_{22} & \cdots & u_{2n} \\ \vdots & \ddots & \ddots & \vdots \\ 0 & \cdots & 0 & u_{nn} \end{bmatrix}.$$

Uma matriz

$$\mathbf{L} = (\ell_{ij})_{n \times n}$$

é **triangular inferior** quando

$$\ell_{ij} = 0 \quad \text{para} \quad i < j.$$

Sua forma geral é

$$\mathbf{L} = \begin{bmatrix} \ell_{11} & 0 & \cdots & 0 \\ \ell_{21} & \ell_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ \ell_{n1} & \ell_{n2} & \cdots & \ell_{nn} \end{bmatrix}.$$

A transposta de uma matriz triangular superior é triangular inferior:

$$\mathbf{U}^\top \text{ é triangular inferior.}$$

Da mesma forma,

$$\mathbf{L}^\top \text{ é triangular superior.}$$

A soma e o produto de matrizes triangulares superiores de mesma ordem permanecem triangulares superiores. A mesma propriedade vale para matrizes triangulares inferiores.

O determinante de uma matriz triangular é o produto dos elementos de sua diagonal:

$$\det(\mathbf{U}) = \prod_{i=1}^n u_{ii}$$

e

$$\det(\mathbf{L}) = \prod_{i=1}^n \ell_{ii}.$$

Uma matriz triangular é invertível se, e somente se, todos os elementos de sua diagonal são diferentes de zero.

Exemplo 2.29 (Determinante de uma matriz triangular). Considere

$$\mathbf{U} = \begin{bmatrix} 2 & 1 & -1 \\ 0 & 3 & 4 \\ 0 & 0 & 5 \end{bmatrix}.$$

Como $\mathbf{U}$ é triangular superior,

$$\det(\mathbf{U}) = 2(3)(5) = 30.$$

Como todos os elementos da diagonal são diferentes de zero, $\mathbf{U}$ é invertível.

2.7.5.1 Resolução de sistemas triangulares

Um sistema cuja matriz de coeficientes é triangular pode ser resolvido sequencialmente.

Para uma matriz triangular superior,

$$\mathbf{U}\mathbf{x} = \mathbf{b},$$

a última equação contém somente a incógnita x_n . Após determinar x_n , substitui-se seu valor na equação anterior. Esse procedimento continua até a determinação de x_1 e é denominado **substituição regressiva**.

Exemplo 2.30 (Sistema triangular superior). Considere o sistema

$$\begin{aligned} x_1 + 2x_2 - x_3 &= 4, \\ 2x_2 + 3x_3 &= 7, \\ x_3 &= 1. \end{aligned}$$

Sua forma matricial é

$$\begin{bmatrix} 1 & 2 & -1 \\ 0 & 2 & 3 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 4 \\ 7 \\ 1 \end{bmatrix}.$$

A última equação fornece

$$x_3 = 1.$$

Substituindo na segunda equação,

$$2x_2 + 3(1) = 7,$$

de modo que

$$x_2 = 2.$$

Substituindo os valores obtidos na primeira equação,

$$x_1 + 2(2) - 1 = 4,$$

resulta

$$x_1 = 1.$$

Portanto,

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}.$$

Para um sistema

$$\mathbf{Lx} = \mathbf{b},$$

com $\mathbf{L}$ triangular inferior, a resolução começa pela primeira equação e segue até a última. Esse procedimento é denominado **substituição progressiva**.

As matrizes triangulares aparecem na resolução de sistemas e em decomposições matriciais.

2.7.6 Eliminação por blocos

Considere a matriz particionada de Definição 2.20 e suponha que $\mathbf{A}_{22}$ seja invertível. A eliminação do bloco $\mathbf{A}_{12}$ produz uma matriz equivalente cuja posição superior direita é ocupada por uma matriz nula.

Para isso, considere

$$\mathbf{E} = \begin{bmatrix} \mathbf{I}_p & -\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix}.$$

Multiplicando $\mathbf{E}$ por $\mathbf{A}$,

$$\mathbf{EA} = \begin{bmatrix} \mathbf{I}_p & -\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix} \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Efetuando o produto por blocos,

$$\mathbf{EA} = \begin{bmatrix} \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21} & \mathbf{A}_{12} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{22} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Como $\mathbf{A}_{22}^{-1}\mathbf{A}_{22} = \mathbf{I}_q$,

$$\mathbf{EA} = \begin{bmatrix} \mathbf{A}_{11.2} & \mathbf{0} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Portanto, o complemento de Schur aparece exatamente como o bloco que permanece depois da eliminação de $\mathbf{A}_{12}$ utilizando $\mathbf{A}_{22}$.

Como

$$\mathbf{E}^{-1} = \begin{bmatrix} \mathbf{I}_p & \mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix},$$

também podemos escrever

$$\mathbf{A} = \begin{bmatrix} \mathbf{I}_p & \mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix} \begin{bmatrix} \mathbf{A}_{11.2} & \mathbf{0} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Essa fatoração é consequência direta da eliminação por blocos.

Um caso simples ajuda a reconhecer a estrutura. Para uma matriz 2×2 ,

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix},$$

com $d \neq 0$, o complemento de Schur de d é

$$a - bd^{-1}c.$$

Nesse caso,

$$\det(\mathbf{A}) = d(a - bd^{-1}c) = ad - bc,$$

recuperando a expressão usual do determinante de uma matriz 2×2 .

2.7.7 Determinante de uma matriz particionada

A eliminação por blocos mostra uma das principais utilidades do complemento de Schur: calcular o determinante de uma matriz particionada utilizando determinantes de matrizes menores.

Teorema 2.9 (Determinante e complemento de Schur). *Para*

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

se $\mathbf{A}_{22}$ é invertível, então

$$\det(\mathbf{A}) = \det(\mathbf{A}_{22}) \det(\mathbf{A}_{11 \cdot 2}).$$

Se $\mathbf{A}_{11}$ é invertível, então

$$\det(\mathbf{A}) = \det(\mathbf{A}_{11}) \det(\mathbf{A}_{22 \cdot 1}).$$

(Boyd; Vandenberghe, 2004)

i Demonstração

Suponha que $\mathbf{A}_{22}$ seja invertível. Pela eliminação por blocos apresentada anteriormente,

$$\mathbf{EA} = \begin{bmatrix} \mathbf{A}_{11.2} & \mathbf{0} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

com

$$\mathbf{E} = \begin{bmatrix} \mathbf{I}_p & -\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix}.$$

Como $\mathbf{E}$ é triangular por blocos e possui matrizes identidade na diagonal,

$$\det(\mathbf{E}) = 1.$$

Portanto,

$$\det(\mathbf{EA}) = \det(\mathbf{A}).$$

A matriz $\mathbf{EA}$ também é triangular por blocos. Assim,

$$\det(\mathbf{EA}) = \det(\mathbf{A}_{11.2}) \det(\mathbf{A}_{22}).$$

Logo,

$$\det(\mathbf{A}) = \det(\mathbf{A}_{22}) \det(\mathbf{A}_{11.2}).$$

A segunda identidade é obtida de forma análoga, eliminando o bloco $\mathbf{A}_{21}$ a partir de $\mathbf{A}_{11}$.

No Exemplo 2.26,

$$\det(\mathbf{A}_{22}) = 1$$

e

$$\det(\mathbf{A}_{11.2}) = 3.$$

Consequentemente,

$$\det(\mathbf{A}) = 3.$$

2.7.8 Inversão em blocos

O complemento de Schur também permite obter a inversa de uma matriz particionada. A origem da expressão pode ser entendida a partir da mesma fatoração obtida pela eliminação por blocos.

Se $\mathbf{A}_{22}$ é invertível,

$$\mathbf{A} = \begin{bmatrix} \mathbf{I}_p & \mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix} \begin{bmatrix} \mathbf{A}_{11.2} & \mathbf{0} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Se $\mathbf{A}_{11.2}$ também é invertível, os dois fatores são invertíveis. Como a inversa de um produto inverte a ordem dos fatores, a inversa de $\mathbf{A}$ pode ser construída a partir das inversas dessas duas matrizes mais simples.

Proposição 2.11 (Inversa em blocos). *Considere a matriz particionada*

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}$$

e o complemento de Schur de $\mathbf{A}_{22}$ em $\mathbf{A}$,

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21}.$$

Se $\mathbf{A}_{22}$ e $\mathbf{A}_{11.2}$ são invertíveis, então

$$\mathbf{A}^{-1} = \begin{bmatrix} \mathbf{A}_{11.2}^{-1} & -\mathbf{A}_{11.2}^{-1}\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ -\mathbf{A}_{22}^{-1}\mathbf{A}_{21}\mathbf{A}_{11.2}^{-1} & \mathbf{B}_{22} \end{bmatrix},$$

com o bloco (2,2) dado por

$$\mathbf{B}_{22} = \mathbf{A}_{22}^{-1} + \mathbf{A}_{22}^{-1}\mathbf{A}_{21}\mathbf{A}_{11.2}^{-1}\mathbf{A}_{12}\mathbf{A}_{22}^{-1}.$$

(Gentle, 2017)

A expressão pode parecer extensa, mas sua estrutura é determinada pela eliminação anterior. O bloco $\mathbf{A}_{11.2}^{-1}$ representa a parte de $\mathbf{A}_{11}$ que permanece depois da eliminação do segundo bloco.

Uma expressão equivalente pode ser obtida utilizando $\mathbf{A}_{22.1}$ quando $\mathbf{A}_{11}$ e $\mathbf{A}_{22.1}$ são invertíveis.

2.8 Síntese do capítulo

Uma matriz organiza valores em linhas e colunas e permite representar simultaneamente observações, variáveis, transformações e sistemas lineares. As dimensões determinam quais operações são possíveis e qual será a dimensão do resultado.

A tabela a seguir reúne os principais objetos desenvolvidos no capítulo.

Tabela 2.3: Principais objetos e operações matriciais desenvolvidos no capítulo.

Objeto ou operação	Expressão ou condição	Interpretação e utilização
Produto matriz-vetor	$\mathbf{Ax}$	Produz produtos internos pelas linhas e combinações lineares pelas colunas
Produto matricial	$\mathbf{A}_{n \times p} \mathbf{B}_{p \times r}$	Combina linhas e colunas de matrizes com dimensões compatíveis
Transposta	$(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top$	Troca linhas por colunas e reorganiza produtos
Matriz simétrica	$\mathbf{A}^\top = \mathbf{A}$	Estrutura presente em formas quadráticas e matrizes de covariâncias
Traço	$\text{tr}(\mathbf{A}) = \sum_i a_{ii}$	Resume a diagonal e reorganiza expressões matriciais
Matriz inversa	$\mathbf{A}^{-1} \mathbf{A} = \mathbf{I}_n$	Reverte a ação de uma matriz invertível
Determinante	$\det(\mathbf{A})$	Registra invertibilidade, alteração de volume e orientação
Posto	$\text{posto}(\mathbf{A})$	Mede a dimensão da informação linearmente independente
Matriz ortogonal	$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_n$	Preserva produtos internos, normas e distâncias
Forma quadrática	$\mathbf{x}^\top \mathbf{Ax}$	Representa variâncias, distâncias e superfícies de nível
Complemento de Schur	$\mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21}$	Elimina um bloco e produz um bloco reduzido

Para uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{n \times n},$$

as condições

$\mathbf{A}$ é invertível,

$$\det(\mathbf{A}) \neq 0$$

e

$$\text{posto}(\mathbf{A}) = n$$

são equivalentes.

O posto também permite classificar as soluções do sistema

$$\mathbf{Ax} = \mathbf{b}.$$

Quando a matriz não é invertível ou não é quadrada, a pseudoinversa permite formular soluções exatas de menor norma ou soluções de mínimos quadrados.

Para uma matriz simétrica, os valores da forma quadrática

$$\mathbf{x}^\top \mathbf{Ax}$$

permitem classificá-la como positiva definida, semidefinida positiva, negativa definida, semi-definida negativa ou indefinida.

Ao final deste capítulo, o estudante deverá ser capaz de:

- verificar a compatibilidade dimensional das operações matriciais;
- calcular e interpretar produtos matriz-vetor e matriz-matriz;
- utilizar transposição, simetria e traço;
- relacionar inversa, determinante e posto;
- classificar as soluções de sistemas lineares;
- reconhecer matrizes ortogonais, diagonais e triangulares;
- calcular e interpretar formas quadráticas;
- classificar matrizes simétricas por meio de suas formas quadráticas;
- operar com matrizes particionadas em situações introdutórias.

O próximo capítulo desenvolverá espaços vetoriais, bases, dimensão e projeções, fornecendo uma interpretação geométrica mais ampla para o posto, os sistemas lineares e as transformações matriciais.

3 Espaços vetoriais, bases e projeções

Os capítulos anteriores apresentaram a representação vetorial dos dados e as operações matriciais utilizadas para manipulá-los. Neste capítulo, os vetores são estudados como elementos de conjuntos que preservam as operações de adição e multiplicação por escalar.

A estrutura de espaço vetorial permite identificar subespaços, verificar relações de dependência linear e representar um espaço por meio de uma base. Para uma matriz, o posto se relaciona às dimensões de seus espaços fundamentais.

A parte final do capítulo desenvolve a projeção ortogonal. Essa operação decompõe um vetor em uma componente pertencente a um subespaço e uma componente ortogonal, fornecendo a interpretação geométrica dos problemas de melhor aproximação e mínimos quadrados.

Convenções para espaços vetoriais e subespaços

As convenções vetoriais e matriciais apresentadas nos capítulos anteriores permanecem válidas. Neste capítulo, serão utilizadas também as seguintes convenções:

- V e W representam espaços vetoriais ou subespaços vetoriais;
- S representa, em geral, um subespaço de $\mathbb{R}^p$;
- $\mathcal{B}$ representa uma base;
- $\mathcal{B}_W$ representa uma base associada ao subespaço W ;
- $\dim(V)$ representa a dimensão do espaço vetorial V ;
- $\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$ representa o subespaço gerado pelos vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$;
- $[\mathbf{x}]_{\mathcal{B}}$ representa o vetor de coordenadas de $\mathbf{x}$ em relação à base $\mathcal{B}$;
- $S^\perp$ representa o complemento ortogonal de S ;
- $\mathcal{C}(\mathbf{A})$ representa o espaço coluna de $\mathbf{A}$;
- $\mathcal{L}(\mathbf{A})$ representa o espaço linha de $\mathbf{A}$;
- $\mathcal{N}(\mathbf{A})$ representa o espaço nulo de $\mathbf{A}$;
- $\mathcal{N}(\mathbf{A}^\top)$ representa o espaço nulo de $\mathbf{A}^\top$;
- $\oplus$ representa soma direta de subespaços;
- $\text{proj}_S(\mathbf{x})$ representa a projeção ortogonal de $\mathbf{x}$ sobre S ;
- $\mathbf{P}_S$ representa uma matriz de projeção ortogonal sobre S ;
- $\mathbf{G}$ representa, quando indicado, uma matriz de Gram.

Quando uma base for escrita como

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\},$$

a ordem dos vetores será considerada fixada sempre que forem utilizadas coordenadas em relação a essa base.

Os vetores continuarão sendo representados por letras minúsculas em negrito, como $\mathbf{x}$, $\mathbf{y}$ e $\mathbf{v}$, enquanto matrizes serão representadas por letras maiúsculas em negrito, como $\mathbf{A}$, $\mathbf{B}$ e $\mathbf{Q}$.

As definições e propriedades específicas de cada espaço, base, decomposição ou operador serão apresentadas nas seções correspondentes.

3.1 Espaços, subespaços e geração

Um espaço vetorial é um conjunto no qual a soma de vetores e a multiplicação por escalares permanecem definidas e satisfazem propriedades algébricas específicas.

Definição 3.1 (Espaço vetorial). Um conjunto não vazio V é um **espaço vetorial real** quando estão definidas:

- a soma $\mathbf{x} + \mathbf{y} \in V$, para $\mathbf{x}, \mathbf{y} \in V$;
- a multiplicação $\alpha \mathbf{x} \in V$, para $\alpha \in \mathbb{R}$ e $\mathbf{x} \in V$;

e são satisfeitas as seguintes propriedades:

1. Para quaisquer $\mathbf{x}, \mathbf{y} \in V$,

$$\mathbf{x} + \mathbf{y} = \mathbf{y} + \mathbf{x}.$$

2. Para quaisquer $\mathbf{x}, \mathbf{y}, \mathbf{z} \in V$,

$$(\mathbf{x} + \mathbf{y}) + \mathbf{z} = \mathbf{x} + (\mathbf{y} + \mathbf{z}).$$

3. Existe um vetor $\mathbf{0} \in V$ tal que, para todo $\mathbf{x} \in V$,

$$\mathbf{x} + \mathbf{0} = \mathbf{x}.$$

4. Para todo $\mathbf{x} \in V$, existe um vetor $-\mathbf{x} \in V$ tal que

$$\mathbf{x} + (-\mathbf{x}) = \mathbf{0}.$$

5. Para quaisquer $\mathbf{x}, \mathbf{y} \in V$ e $\alpha \in \mathbb{R}$,

$$\alpha(\mathbf{x} + \mathbf{y}) = \alpha\mathbf{x} + \alpha\mathbf{y}.$$

6. Para quaisquer $\mathbf{x} \in V$ e $\alpha, \beta \in \mathbb{R}$,

$$(\alpha + \beta)\mathbf{x} = \alpha\mathbf{x} + \beta\mathbf{x}.$$

7. Para quaisquer $\mathbf{x} \in V$ e $\alpha, \beta \in \mathbb{R}$,

$$\alpha(\beta\mathbf{x}) = (\alpha\beta)\mathbf{x}.$$

8. Para todo $\mathbf{x} \in V$,

$$1\mathbf{x} = \mathbf{x}.$$

O espaço $\mathbb{R}^p$, com as operações usuais de adição e multiplicação por escalar, é um espaço vetorial. Seus elementos são vetores com p componentes reais. O vetor nulo é

$$\mathbf{0} = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix},$$

e, para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix},$$

seu inverso aditivo é

$$-\mathbf{x} = \begin{bmatrix} -x_1 \\ \vdots \\ -x_p \end{bmatrix}.$$

Os elementos de um espaço vetorial não precisam ser necessariamente vetores numéricos. Por exemplo, o conjunto de todas as matrizes reais de dimensão $n \times p$,

$$\mathbb{R}^{n \times p},$$

também é um espaço vetorial com as operações usuais de adição de matrizes e multiplicação por escalar. Nesse caso, os elementos do espaço vetorial são matrizes.

3.1.1 Subespaços vetoriais

Um subconjunto de um espaço vetorial pode preservar a estrutura das operações.

Definição 3.2 (Subespaço vetorial). Seja V um espaço vetorial. Um subconjunto não vazio $W \subseteq V$ é um **subespaço vetorial** de V quando, para quaisquer $\mathbf{x}, \mathbf{y} \in W$ e $\alpha \in \mathbb{R}$,

$$\mathbf{x} + \mathbf{y} \in W$$

e

$$\alpha \mathbf{x} \in W.$$

As duas condições garantem que toda combinação linear de vetores de W também pertence a W .

Proposição 3.1 (Critério de subespaço). *Um subconjunto não vazio $W \subseteq V$ é um subespaço vetorial se, e somente se,*

$$\alpha \mathbf{x} + \beta \mathbf{y} \in W$$

para quaisquer $\mathbf{x}, \mathbf{y} \in W$ e $\alpha, \beta \in \mathbb{R}$. (Eaton, 2007)

O vetor nulo pertence a todo subespaço. De fato, para qualquer $\mathbf{x} \in W$,

$$0\mathbf{x} = \mathbf{0} \in W.$$

Exemplo 3.1 (Reta que é um subespaço). Considere

$$W = \left\{ \begin{bmatrix} t \\ t \end{bmatrix} : t \in \mathbb{R} \right\} \subseteq \mathbb{R}^2.$$

Se

$$\mathbf{x} = \begin{bmatrix} t_1 \\ t_1 \end{bmatrix} \quad \text{e} \quad \mathbf{y} = \begin{bmatrix} t_2 \\ t_2 \end{bmatrix}$$

pertencem a W , então

$$\alpha \mathbf{x} + \beta \mathbf{y} = \begin{bmatrix} \alpha t_1 + \beta t_2 \\ \alpha t_1 + \beta t_2 \end{bmatrix} \in W.$$

Portanto, W é um subespaço de $\mathbb{R}^2$.

Uma reta que não passa pela origem não é um subespaço.

Exemplo 3.2 (Reta que não é um subespaço). Considere

$$S = \left\{ \begin{bmatrix} t \\ t+1 \end{bmatrix} : t \in \mathbb{R} \right\}.$$

O vetor nulo não pertence a S . Portanto, S não é um subespaço de $\mathbb{R}^2$.

Geometricamente, S é uma reta paralela a W , mas deslocada e sem passar pela origem.

A Figura 3.1 compara uma reta que é subespaço de $\mathbb{R}^2$ com uma reta paralela que não é subespaço.




Figura 3.1: Comparação entre uma reta que é subespaço de $\mathbb{R}^2$ e uma reta que não é subespaço.

A reta do primeiro painel contém a origem e é fechada em relação às combinações lineares. A reta do segundo painel não contém a origem e, por isso, não é um subespaço de $\mathbb{R}^2$.

3.1.2 Subespaço gerado

As combinações lineares de um conjunto de vetores formam um subespaço.

Definição 3.3 (Subespaço gerado). Sejam

$$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k \in V.$$

O **subespaço gerado** por esses vetores é o conjunto de todas as suas combinações lineares,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\} = \{\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k : \alpha_1, \dots, \alpha_k \in \mathbb{R}\}.$$

A notação

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\}$$

indica o subespaço gerado pelos vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$.

Esse conjunto também é denominado **envoltória linear** dos vetores.

O subespaço gerado é o menor subespaço que contém todos os vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$.

Exemplo 3.3 (Subespaço gerado por um vetor). Considere

$$\mathbf{v} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

O conjunto

$$\text{span}\{\mathbf{v}\} = \left\{ \alpha \begin{bmatrix} 1 \\ 2 \end{bmatrix} : \alpha \in \mathbb{R} \right\}$$

é uma reta que passa pela origem.

Exemplo 3.4 (Subespaço gerado por dois vetores). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Uma combinação linear desses vetores é

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 = \begin{bmatrix} \alpha_1 + \alpha_2 \\ \alpha_2 \end{bmatrix}.$$

Para qualquer vetor

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \in \mathbb{R}^2,$$

basta escolher

$$\alpha_2 = x_2$$

e

$$\alpha_1 = x_1 - x_2.$$

Portanto,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2\} = \mathbb{R}^2.$$

Exemplo 3.5 (Espaço e subespaço gerado). Considere o espaço vetorial

$$V = \mathbb{R}^3.$$

Primeiro, considere os vetores

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

Uma combinação linear desses vetores é

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \alpha_3 \mathbf{v}_3 = \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{bmatrix}.$$

Como qualquer vetor de $\mathbb{R}^3$ pode ser obtido escolhendo adequadamente α_1 , α_2 e α_3 ,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3\} = \mathbb{R}^3.$$

Nesse caso, o subespaço gerado coincide com o próprio espaço V .

Considere agora apenas os vetores

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}.$$

As combinações lineares desses vetores são da forma

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 = \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ 0 \end{bmatrix}.$$

Portanto,

$$W = \text{span}\{\mathbf{v}_1, \mathbf{v}_2\} = \left\{ \begin{bmatrix} x_1 \\ x_2 \\ 0 \end{bmatrix} : x_1, x_2 \in \mathbb{R} \right\}.$$

O conjunto W é o plano $x_3 = 0$ contido em $\mathbb{R}^3$. Assim,

$$W \subsetneq V,$$

Os dois casos mostram que um subespaço gerado pode coincidir com todo o espaço ou possuir dimensão menor. Em um espaço vetorial de dimensão finita, um subespaço não pode ter dimensão maior que a do espaço que o contém.

Um mesmo subespaço pode ser gerado por diferentes conjuntos de vetores. Alguns conjuntos podem conter vetores redundantes. A independência linear permite identificar quando um vetor acrescenta uma nova direção ao subespaço gerado.

3.2 Independência linear, bases e dimensão

Um conjunto de vetores pode gerar um subespaço mesmo quando contém vetores redundantes. A independência linear permite verificar se cada vetor acrescenta uma nova direção ao conjunto gerado.

3.2.1 Independência linear

Definição 3.4 (Independência linear). Os vetores

$$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k \in V$$

são **linearmente independentes** quando a igualdade

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_k \mathbf{v}_k = \mathbf{0}$$

implica

$$\alpha_1 = \alpha_2 = \dots = \alpha_k = 0.$$

Quando existe uma solução em que pelo menos um coeficiente é diferente de zero, os vetores são **linearmente dependentes**.

A solução

$$\alpha_1 = \alpha_2 = \dots = \alpha_k = 0$$

é denominada **solução trivial**. Um conjunto é linearmente independente quando a solução trivial é a única combinação linear que produz o vetor nulo.

Exemplo 3.6 (Vetores linearmente dependentes). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 2 \\ 4 \end{bmatrix}.$$

Como

$$\mathbf{v}_2 = 2\mathbf{v}_1,$$

tem-se

$$2\mathbf{v}_1 - \mathbf{v}_2 = \mathbf{0}.$$

Os coeficientes 2 e -1 não são ambos nulos. Portanto, $\mathbf{v}_1$ e $\mathbf{v}_2$ são linearmente dependentes. Além disso,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2\} = \text{span}\{\mathbf{v}_1\}.$$

O vetor $\mathbf{v}_2$ não acrescenta uma nova direção ao subespaço gerado.

Exemplo 3.7 (Vetores linearmente independentes). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Suponha que

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 = \mathbf{0}.$$

Então,

$$\alpha_1 \begin{bmatrix} 1 \\ 0 \end{bmatrix} + \alpha_2 \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} \alpha_1 + \alpha_2 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

A segunda equação fornece

$$\alpha_2 = 0,$$

e a primeira fornece

$$\alpha_1 = 0.$$

Portanto, os vetores são linearmente independentes.

A Figura 3.2 compara dois vetores dependentes com dois vetores independentes em $\mathbb{R}^2$.

No primeiro painel, os vetores pertencem à mesma reta e geram um subespaço unidimensional. No segundo, os vetores determinam duas direções distintas e geram $\mathbb{R}^2$.




Figura 3.2: Comparação entre vetores linearmente dependentes e independentes em $\mathbb{R}^2$.

3.2.2 Independência linear e posto

Considere a matriz cujas colunas são os vetores analisados:

$$\mathbf{A} = [\mathbf{v}_1 \quad \mathbf{v}_2 \quad \cdots \quad \mathbf{v}_k], \quad \mathbf{A} \in \mathbb{R}^{p \times k}.$$

As colunas de $\mathbf{A}$ são linearmente independentes se, e somente se,

$$\text{posto}(\mathbf{A}) = k.$$

Assim, o número de vetores linearmente independentes entre as colunas de $\mathbf{A}$ é determinado pelo posto da matriz.

Como

$$\text{posto}(\mathbf{A}) \leq \min(p, k),$$

não pode haver mais de p vetores linearmente independentes em $\mathbb{R}^p$.

Proposição 3.2 (Propriedades da independência linear). *Sejam $\mathbf{v}_1, \dots, \mathbf{v}_k \in V$.*

1. *Um conjunto que contém o vetor nulo é linearmente dependente.*

2. Um conjunto formado por um único vetor é linearmente independente se, e somente se, esse vetor é diferente de zero.
3. Todo subconjunto de um conjunto linearmente independente também é linearmente independente.
4. Todo conjunto que contém um subconjunto linearmente dependente é linearmente dependente.
5. Se um vetor do conjunto pode ser escrito como combinação linear dos demais, o conjunto é linearmente dependente.

A última propriedade fornece uma interpretação direta da redundância.

Proposição 3.3 (Dependência linear e redundância). *O conjunto*

$$\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$$

é linearmente dependente se, e somente se, pelo menos um de seus vetores pode ser escrito como combinação linear dos demais.

i Demonstração

Suponha que o conjunto seja linearmente dependente. Então existem coeficientes, não todos nulos, tais que

$$\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k = \mathbf{0}.$$

Escolha um índice j para o qual $\alpha_j \neq 0$. Isolando $\mathbf{v}_j$,

$$\mathbf{v}_j = - \sum_{i \neq j} \frac{\alpha_i}{\alpha_j} \mathbf{v}_i.$$

Portanto, $\mathbf{v}_j$ é combinação linear dos demais.

Reciprocamente, se um vetor é combinação linear dos demais, essa igualdade pode ser reorganizada como uma combinação linear não trivial que produz o vetor nulo. Logo, o conjunto é linearmente dependente.

A independência linear permite retirar vetores redundantes sem alterar o subespaço gerado. Um conjunto gerador sem redundâncias fornece uma base do subespaço.

3.2.3 Bases

Um conjunto gerador pode conter vetores redundantes. Quando os vetores geram o espaço e são linearmente independentes, obtém-se uma base.

Definição 3.5 (Base). Seja V um espaço vetorial. Um conjunto

$$\mathcal{B} = \{\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_k\}$$

é uma **base** de V quando:

1. os vetores $\mathbf{b}_1, \dots, \mathbf{b}_k$ são linearmente independentes;
2. os vetores geram V , isto é,

$$\text{span}\{\mathbf{b}_1, \dots, \mathbf{b}_k\} = V.$$

Uma base fornece um conjunto de vetores suficiente para gerar o espaço sem incluir redundâncias.

Exemplo 3.8 (Uma base de $\mathbb{R}^2$). Considere

$$\mathbf{b}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{b}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Os vetores são linearmente independentes e geram $\mathbb{R}^2$. Portanto,

$$\mathcal{B} = \{\mathbf{b}_1, \mathbf{b}_2\}$$

é uma base de $\mathbb{R}^2$.

Um mesmo espaço possui diferentes bases.

Exemplo 3.9 (Bases diferentes do mesmo espaço). Os conjuntos

$$\mathcal{B}_1 = \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix} \right\}$$

e

$$\mathcal{B}_2 = \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}$$

são bases de $\mathbb{R}^2$.

Os vetores de cada conjunto são linearmente independentes e geram todo o espaço.

3.2.4 Coordenadas em uma base

Uma base permite representar cada vetor por meio dos coeficientes de sua combinação linear.

Teorema 3.1 (Representação única em uma base). *Se*

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é uma base de V , então todo vetor $\mathbf{x} \in V$ pode ser escrito de maneira única como

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k.$$

i Demonstração

Como $\mathcal{B}$ gera V , existem escalares $c_1, \dots, c_k$ tais que

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k.$$

Suponha que também exista outra representação:

$$\mathbf{x} = d_1 \mathbf{b}_1 + \dots + d_k \mathbf{b}_k.$$

Subtraindo as duas expressões,

$$(c_1 - d_1) \mathbf{b}_1 + \dots + (c_k - d_k) \mathbf{b}_k = \mathbf{0}.$$

Como os vetores da base são linearmente independentes,

$$c_i - d_i = 0, \quad i = 1, \dots, k.$$

Portanto,

$$c_i = d_i, \quad i = 1, \dots, k,$$

e a representação é única.

Definição 3.6 (Coordenadas em uma base). *Se*

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k,$$

o vetor

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} c_1 \\ \vdots \\ c_k \end{bmatrix}$$

é o **vetor de coordenadas de $\mathbf{x}$** na base $\mathcal{B}$.

Considere a matriz formada pelos vetores da base:

$$\mathbf{B} = [\mathbf{b}_1 \quad \cdots \quad \mathbf{b}_k].$$

A representação de $\mathbf{x}$ pode ser escrita como

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Exemplo 3.10 (Coordenadas de um vetor). Considere a base

$$\mathcal{B} = \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}$$

e o vetor

$$\mathbf{x} = \begin{bmatrix} 4 \\ 2 \end{bmatrix}.$$

Deseja-se determinar c_1 e c_2 tais que

$$\begin{bmatrix} 4 \\ 2 \end{bmatrix} = c_1 \begin{bmatrix} 1 \\ 1 \end{bmatrix} + c_2 \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Isso produz o sistema

$$\begin{aligned} c_1 + c_2 &= 4, \\ c_1 - c_2 &= 2. \end{aligned}$$

Somando as equações,

$$2c_1 = 6,$$

de modo que

$$c_1 = 3.$$

Consequentemente,

$$c_2 = 1.$$

Logo,

$$[\mathbf{x}]_B = \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

As coordenadas dependem da base escolhida. O vetor permanece o mesmo, mas os coeficientes que o representam podem mudar.

As coordenadas de um vetor em uma base são os coeficientes que indicam quanto de cada vetor da base é necessário para reconstruir esse vetor por combinação linear. Assim, o vetor de coordenadas não é o próprio vetor, mas a representação desse vetor em relação à base escolhida.

3.2.5 Base canônica

Definição 3.7 (Base canônica). A **base canônica** de $\mathbb{R}^p$ é

$$\mathcal{E} = \{\mathbf{e}_1, \dots, \mathbf{e}_p\},$$

em que $\mathbf{e}_j$ possui valor 1 na posição j e valor 0 nas demais posições.

Em $\mathbb{R}^3$,

$$\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{e}_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix},$$

tem-se

$$\mathbf{x} = x_1 \mathbf{e}_1 + x_2 \mathbf{e}_2 + x_3 \mathbf{e}_3.$$

Assim, as coordenadas de $\mathbf{x}$ na base canônica coincidem com suas componentes usuais.

3.2.6 Bases ortogonais e ortonormais

A partir deste ponto, considere um subespaço $S \subseteq \mathbb{R}^p$ com o produto interno euclidiano.

Definição 3.8 (Base ortogonal). Uma base

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

de S é **ortogonal** quando

$$\mathbf{b}_i^\top \mathbf{b}_j = 0 \quad \text{para} \quad i \neq j.$$

Definição 3.9 (Base ortonormal). Uma base $\mathcal{B}$ de S é **ortonormal** quando seus vetores são ortogonais e possuem norma igual a 1:

$$\mathbf{b}_i^\top \mathbf{b}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Utilizando o delta de Kronecker, a condição de ortonormalidade pode ser escrita como

$$\mathbf{b}_i^\top \mathbf{b}_j = \delta_{ij}.$$

Se

$$\mathbf{Q} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_k]$$

possui como colunas os vetores de uma base ortonormal, então

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k.$$

Quando $\mathbf{Q}$ é quadrada,

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

No caso quadrado, $\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_p$ caracteriza $\mathbf{Q}$ como uma matriz ortogonal, conforme Definição 2.15.

Teorema 3.2 (Existência de bases ortonormais). *Todo subespaço de dimensão finita de $\mathbb{R}^p$ possui uma base ortonormal.*

A partir de qualquer base do subespaço, uma base ortonormal pode ser construída pelo processo de ortogonalização de Gram–Schmidt. (Eaton, 2007)

A existência de uma base ortonormal permite descrever a geometria de um subespaço de dimensão finita por direções mutuamente ortogonais e de norma unitária.

Em uma base ortogonal, os coeficientes da representação de um vetor podem ser determinados separadamente.

Proposição 3.4 (Coordenadas em uma base ortogonal). *Se*

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é uma base ortogonal de um subespaço $S \subseteq \mathbb{R}^p$, então todo vetor $\mathbf{x} \in S$ pode ser escrito de maneira única como

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k.$$

Cada coordenada de $\mathbf{x}$ na base $\mathcal{B}$ pode ser obtida separadamente por

$$c_j = \frac{\mathbf{b}_j^\top \mathbf{x}}{\mathbf{b}_j^\top \mathbf{b}_j}, \quad j = 1, \dots, k.$$

Portanto,

$$\mathbf{x} = \sum_{j=1}^k \frac{\mathbf{b}_j^\top \mathbf{x}}{\mathbf{b}_j^\top \mathbf{b}_j} \mathbf{b}_j.$$

Se a base é ortonormal, então $\mathbf{b}_j^\top \mathbf{b}_j = 1$ para todo j , de modo que

$$c_j = \mathbf{b}_j^\top \mathbf{x},$$

e

$$\mathbf{x} = \sum_{j=1}^k (\mathbf{b}_j^\top \mathbf{x}) \mathbf{b}_j.$$

Assim, em uma base ortogonal, cada coordenada pode ser determinada por meio de um produto interno, sem a necessidade de resolver simultaneamente um sistema linear. (Eaton, 2007)

i Demonstração

Como $\mathcal{B}$ é uma base de S , todo vetor $\mathbf{x} \in S$ pode ser escrito de maneira única como

$$\mathbf{x} = c_1 \mathbf{b}_1 + \cdots + c_k \mathbf{b}_k.$$

Multiplicando ambos os lados à esquerda por $\mathbf{b}_j^\top$,

$$\mathbf{b}_j^\top \mathbf{x} = \sum_{i=1}^k c_i \mathbf{b}_j^\top \mathbf{b}_i.$$

Como a base é ortogonal,

$$\mathbf{b}_j^\top \mathbf{b}_i = 0 \quad \text{para} \quad i \neq j.$$

Assim, todos os termos da soma com $i \neq j$ são nulos, restando

$$\mathbf{b}_j^\top \mathbf{x} = c_j \mathbf{b}_j^\top \mathbf{b}_j.$$

Como $\mathbf{b}_j \neq \mathbf{0}$,

$$\mathbf{b}_j^\top \mathbf{b}_j = \|\mathbf{b}_j\|^2 > 0,$$

e, portanto,

$$c_j = \frac{\mathbf{b}_j^\top \mathbf{x}}{\mathbf{b}_j^\top \mathbf{b}_j}.$$

Se a base é ortonormal, então $\|\mathbf{b}_j\| = 1$ e, conseqüentemente,

$$\mathbf{b}_j^\top \mathbf{b}_j = 1.$$

Logo,

$$c_j = \mathbf{b}_j^\top \mathbf{x},$$

o que fornece diretamente as coordenadas de $\mathbf{x}$ na base ortonormal.

A Figura 3.3 compara três bases de $\mathbb{R}^2$ e destaca a diferença entre independência linear e ortogonalidade.




Figura 3.3: Comparação entre uma base canônica, uma base oblíqua e uma base ortonormal rotacionada de $\mathbb{R}^2$. O símbolo de ângulo reto identifica os pares de vetores ortogonais.

Na primeira e na terceira bases, os vetores são ortogonais e possuem norma igual a 1, como indicado pelos marcadores de ângulo reto. Portanto, ambas são bases ortonormais. Na base oblíqua, os vetores continuam sendo linearmente independentes e, por isso, formam uma base de $\mathbb{R}^2$, mas não são ortogonais.

3.2.7 Dimensão

Um espaço vetorial é denominado **finito-dimensional** quando possui uma base formada por um número finito de vetores.

Para que a dimensão possa ser definida pelo número de vetores de uma base, é necessário estabelecer primeiro que esse número não depende da base escolhida.

Teorema 3.3 (Número de vetores de uma base). *Se um espaço vetorial V possui uma base finita, então todas as bases de V são finitas e possuem a mesma quantidade de vetores. (Eaton, 2007)*

Definição 3.10 (Dimensão). Se as bases de um espaço vetorial finito-dimensional V possuem k vetores, a **dimensão** de V é definida por

$$\dim(V) = k.$$

Como a base canônica de $\mathbb{R}^p$ possui p vetores,

$$\dim(\mathbb{R}^p) = p.$$

Exemplo 3.11 (Dimensão de subespaços). A reta

$$W_1 = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \right\} \subseteq \mathbb{R}^3$$

possui dimensão 1.

O plano

$$W_2 = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \right\} \subseteq \mathbb{R}^3$$

possui dimensão 2.

O espaço $\mathbb{R}^3$ possui dimensão 3.

Proposição 3.5 (Independência, geração e dimensão). *Se $\dim(V) = k$, então:*

1. *qualquer conjunto com mais de k vetores é linearmente dependente;*
2. *qualquer conjunto com menos de k vetores não gera V ;*
3. *qualquer conjunto de k vetores linearmente independentes é uma base de V ;*
4. *qualquer conjunto de k vetores que gera V é uma base de V .*

Para uma matriz, independência, geração e dimensão são descritas pelos espaços coluna, linha e nulo e por suas dimensões.

3.3 Espaços fundamentais de uma matriz

Uma matriz está associada a subespaços determinados por suas linhas, por suas colunas e pelas soluções de sistemas lineares homogêneos. Esses subespaços permitem relacionar o posto, a dependência linear e as soluções de sistemas lineares.

Considere

$$\mathbf{A} \in \mathbb{R}^{n \times p}.$$

Serão estudados quatro subespaços associados a $\mathbf{A}$:

- o espaço coluna;
- o espaço linha;
- o espaço nulo;
- o espaço nulo à esquerda.

Os dois primeiros são construídos a partir das colunas e das linhas da matriz. Os dois últimos são determinados pelas soluções dos sistemas homogêneos associados, respectivamente, a $\mathbf{A}$ e a $\mathbf{A}^\top$.

3.3.1 Espaço nulo

Definição 3.11 (Espaço nulo). O **espaço nulo** de uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

é o conjunto

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{A}\mathbf{x} = \mathbf{0}\}.$$

Quando $\mathbf{A}$ é interpretada como a matriz associada a uma transformação linear, $\mathcal{N}(\mathbf{A})$ corresponde ao **núcleo** da transformação, definido em Definição 4.2.

O espaço nulo reúne todos os vetores $\mathbf{x} \in \mathbb{R}^p$ que são anulados pela multiplicação por $\mathbf{A}$, isto é, aqueles para os quais $\mathbf{A}\mathbf{x} = \mathbf{0}$.

Proposição 3.6 (O espaço nulo é um subespaço). *Para qualquer matriz*

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

o conjunto

$$\mathcal{N}(\mathbf{A})$$

é um subespaço de $\mathbb{R}^p$.

i Demonstração

O vetor nulo pertence a $\mathcal{N}(\mathbf{A})$, pois

$$\mathbf{A}\mathbf{0} = \mathbf{0}.$$

Se

$$\mathbf{x}, \mathbf{y} \in \mathcal{N}(\mathbf{A}),$$

então

$$\mathbf{A}\mathbf{x} = \mathbf{0} \quad \text{e} \quad \mathbf{A}\mathbf{y} = \mathbf{0}.$$

Para quaisquer $\alpha, \beta \in \mathbb{R}$,

$$\begin{aligned}\mathbf{A}(\alpha\mathbf{x} + \beta\mathbf{y}) &= \alpha\mathbf{A}\mathbf{x} + \beta\mathbf{A}\mathbf{y} \\ &= \alpha\mathbf{0} + \beta\mathbf{0} \\ &= \mathbf{0}.\end{aligned}$$

Logo,

$$\alpha\mathbf{x} + \beta\mathbf{y} \in \mathcal{N}(\mathbf{A}),$$

e $\mathcal{N}(\mathbf{A})$ é um subespaço.

A dimensão do espaço nulo é denominada **nulidade** da matriz:

$$\text{nul}(\mathbf{A}) = \dim \mathcal{N}(\mathbf{A}).$$

Exemplo 3.12 (Determinação do espaço nulo). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

Para determinar $\mathcal{N}(\mathbf{A})$, resolve-se

$$\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Assim,

$$\begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

As duas equações são equivalentes, e o sistema reduz-se a

$$x_1 + 2x_2 - x_3 = 0.$$

Tomando

$$x_2 = s \quad \text{e} \quad x_3 = t,$$

obtém-se

$$x_1 = -2s + t.$$

Portanto,

$$\mathbf{x} = \begin{bmatrix} -2s + t \\ s \\ t \end{bmatrix} = s \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix} + t \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}.$$

Logo,

$$\mathcal{N}(\mathbf{A}) = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} \right\}.$$

Os dois vetores são linearmente independentes. Assim,

$$\text{nul}(\mathbf{A}) = 2.$$

Se

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

as colunas de $\mathbf{A}$ são linearmente independentes. Nesse caso, o sistema homogêneo possui apenas a solução trivial.

3.3.2 Espaço coluna

Definição 3.12 (Espaço coluna). O **espaço coluna** de uma matriz

$$\mathbf{A} = [\mathbf{a}_{.1} \quad \mathbf{a}_{.2} \quad \cdots \quad \mathbf{a}_{.p}] \in \mathbb{R}^{n \times p}$$

é o subespaço

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{a}_{.1}, \dots, \mathbf{a}_{.p} \} \subseteq \mathbb{R}^n.$$

O produto matriz-vetor pode ser escrito como

$$\mathbf{A}\mathbf{x} = x_1 \mathbf{a}_{.1} + \cdots + x_p \mathbf{a}_{.p}, \quad \mathbf{x} \in \mathbb{R}^p.$$

Portanto, todo vetor produzido por $\mathbf{A}$ é uma combinação linear de suas colunas.

Como

$$\mathbf{A}\mathbf{x} = x_1 \mathbf{a}_{.1} + \cdots + x_p \mathbf{a}_{.p},$$

o conjunto de todos os vetores que podem ser escritos na forma $\mathbf{A}\mathbf{x}$ coincide com o espaço gerado pelas colunas de $\mathbf{A}$:

$$\mathcal{C}(\mathbf{A}) = \{ \mathbf{A}\mathbf{x} : \mathbf{x} \in \mathbb{R}^p \}.$$

Essa caracterização permite relacionar diretamente o espaço coluna à existência de soluções de sistemas lineares.

Proposição 3.7 (Consistência de um sistema linear). *O sistema*

$$\mathbf{A}\mathbf{x} = \mathbf{b}$$

possui pelo menos uma solução se, e somente se,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

i Demonstração

Se o sistema possui uma solução $\mathbf{x}$, então

$$\mathbf{b} = \mathbf{A}\mathbf{x},$$

de modo que $\mathbf{b}$ é uma combinação linear das colunas de $\mathbf{A}$. Portanto,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Reciprocamente, se

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}),$$

existem escalares $x_1, \dots, x_p$ tais que

$$\mathbf{b} = x_1 \mathbf{a}_{.1} + \dots + x_p \mathbf{a}_{.p}.$$

Definindo

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix} \in \mathbb{R}^p,$$

obtém-se

$$\mathbf{A}\mathbf{x} = \mathbf{b}.$$

Exemplo 3.13 (Determinação do espaço coluna). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

As colunas são

$$\mathbf{a}_{.1} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \mathbf{a}_{.2} = \begin{bmatrix} 2 \\ 4 \end{bmatrix}, \mathbf{a}_{.3} = \begin{bmatrix} -1 \\ -2 \end{bmatrix}.$$

Como

$$\mathbf{a}_{.2} = 2\mathbf{a}_{.1}$$

e

$$\mathbf{a}_3 = -\mathbf{a}_1,$$

tem-se

$$\mathcal{C}(\mathbf{A}) = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \end{bmatrix} \right\}.$$

Logo,

$$\dim \mathcal{C}(\mathbf{A}) = 1.$$

A dimensão do espaço coluna é igual ao posto da matriz:

$$\dim \mathcal{C}(\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Uma base de $\mathcal{C}(\mathbf{A})$ pode ser formada por quaisquer vetores linearmente independentes que gerem esse espaço. Quando se deseja obter uma base selecionando colunas da própria matriz $\mathbf{A}$, as posições das colunas pivô podem ser identificadas por escalonamento. Nesse procedimento, os vetores da base são as colunas correspondentes da matriz original, e não as colunas da matriz escalonada.

3.3.3 Espaço linha

Definição 3.13 (Espaço linha). O **espaço linha** de uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

é o subespaço de $\mathbb{R}^p$ gerado por suas linhas.

Escrevendo as linhas de $\mathbf{A}$ como

$$\mathbf{a}_1^\top, \mathbf{a}_2^\top, \dots, \mathbf{a}_n^\top,$$

o espaço linha pode ser representado por

$$\mathcal{L}(\mathbf{A}) = \text{span} \{ \mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n \} \subseteq \mathbb{R}^p.$$

Equivalentemente, como as linhas de $\mathbf{A}$ são as colunas de $\mathbf{A}^\top$,

$$\mathcal{L}(\mathbf{A}) = \mathcal{C}(\mathbf{A}^\top).$$

O espaço linha e o espaço coluna possuem a mesma dimensão:

$$\dim \mathcal{L}(\mathbf{A}) = \dim \mathcal{C}(\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Essa igualdade permite interpretar o posto tanto como o número máximo de colunas linearmente independentes quanto como o número máximo de linhas linearmente independentes.

Exemplo 3.14 (Determinação do espaço linha). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

As linhas de $\mathbf{A}$ são

$$\mathbf{a}_1^\top = [1 \quad 2 \quad -1]$$

e

$$\mathbf{a}_2^\top = [2 \quad 4 \quad -2].$$

Os vetores-coluna associados a essas linhas são

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix} \quad \text{e} \quad \mathbf{a}_2 = \begin{bmatrix} 2 \\ 4 \\ -2 \end{bmatrix}.$$

Como

$$\mathbf{a}_2 = 2\mathbf{a}_1,$$

tem-se

$$\mathcal{L}(\mathbf{A}) = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix} \right\}.$$

Logo,

$$\dim \mathcal{L}(\mathbf{A}) = 1.$$

As linhas não nulas de uma forma escalonada de $\mathbf{A}$ formam uma base de $\mathcal{L}(\mathbf{A})$. Diferentemente do espaço coluna, pode-se utilizar diretamente as linhas da matriz escalonada, pois as operações elementares por linhas preservam o espaço linha.

3.3.4 Espaço nulo à esquerda

Definição 3.14 (Espaço nulo à esquerda). O **espaço nulo à esquerda** de

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

é definido por

$$\mathcal{N}(\mathbf{A}^\top) = \{\mathbf{y} \in \mathbb{R}^n : \mathbf{A}^\top \mathbf{y} = \mathbf{0}\}.$$

Um vetor $\mathbf{y}$ pertence a $\mathcal{N}(\mathbf{A}^\top)$ quando é ortogonal a todas as colunas de $\mathbf{A}$. De fato,

$$\mathbf{A}^\top \mathbf{y} = \begin{bmatrix} \mathbf{a}_1^\top \mathbf{y} \\ \mathbf{a}_2^\top \mathbf{y} \\ \vdots \\ \mathbf{a}_p^\top \mathbf{y} \end{bmatrix}.$$

Assim,

$$\mathbf{A}^\top \mathbf{y} = \mathbf{0}$$

se, e somente se,

$$\mathbf{a}_j^\top \mathbf{y} = 0, \quad j = 1, \dots, p.$$

Portanto, todo vetor de $\mathcal{N}(\mathbf{A}^\top)$ é ortogonal a cada coluna de $\mathbf{A}$ e, consequentemente, a toda combinação linear dessas colunas. A igualdade $\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp$ é estabelecida em Teorema 3.5.

Exemplo 3.15 (Determinação do espaço nulo à esquerda). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

Para determinar $\mathcal{N}(\mathbf{A}^\top)$, resolve-se

$$\mathbf{A}^\top \mathbf{y} = \mathbf{0}.$$

Assim,

$$\begin{bmatrix} 1 & 2 \\ 2 & 4 \\ -1 & -2 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}.$$

O sistema reduz-se a

$$y_1 + 2y_2 = 0.$$

Tomando

$$y_2 = t,$$

obtém-se

$$y_1 = -2t.$$

Portanto,

$$\mathbf{y} = t \begin{bmatrix} -2 \\ 1 \end{bmatrix},$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \end{bmatrix} \right\}.$$

Logo,

$$\dim \mathcal{N}(\mathbf{A}^\top) = 1.$$

3.3.5 Teorema Posto–Nulidade

As dimensões do espaço nulo e do espaço coluna estão relacionadas ao número de colunas da matriz.


Teorema 3.4 (Teorema Posto–Nulidade). *Se*

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

então

$$\text{posto}(\mathbf{A}) + \text{nul}(\mathbf{A}) = p.$$

(Eaton, 2007; Gentle, 2017)



i Demonstração

Considere uma base do espaço nulo,

$$\mathcal{B}_{\mathcal{N}} = \{\mathbf{v}_1, \dots, \mathbf{v}_s\},$$

em que

$$s = \dim \mathcal{N}(\mathbf{A}).$$

Como toda base de um subespaço de dimensão finita pode ser completada para formar uma base do espaço ambiente (Teorema 3.8), existem vetores $\mathbf{w}_1, \dots, \mathbf{w}_r \in \mathbb{R}^p$ tais que

$$\{\mathbf{v}_1, \dots, \mathbf{v}_s, \mathbf{w}_1, \dots, \mathbf{w}_r\}$$

é uma base de $\mathbb{R}^p$.

Como essa base possui p vetores,

$$s + r = p.$$

Todo vetor $\mathbf{x} \in \mathbb{R}^p$ possui uma representação da forma

$$\mathbf{x} = \sum_{i=1}^s \alpha_i \mathbf{v}_i + \sum_{j=1}^r \beta_j \mathbf{w}_j.$$

Como

$$\mathbf{A}\mathbf{v}_i = \mathbf{0}, \quad i = 1, \dots, s,$$

tem-se

Aplicando o teorema a $\mathbf{A}^\top$,

$$\text{posto}(\mathbf{A}^\top) + \dim \mathcal{N}(\mathbf{A}^\top) = n.$$

Como

$$\text{posto}(\mathbf{A}^\top) = \text{posto}(\mathbf{A}),$$

obtém-se

$$\text{posto}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}^\top) = n.$$

Exemplo 3.16 (Aplicação do Teorema Posto–Nulidade). Para a matriz utilizada nesta seção,

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix},$$

tem-se

$$\text{posto}(\mathbf{A}) = 1,$$

$$\dim \mathcal{N}(\mathbf{A}) = 2$$

e

$$\dim \mathcal{N}(\mathbf{A}^\top) = 1.$$

Assim, para $\mathbf{A} \in \mathbb{R}^{2 \times 3}$,

$$1 + 2 = 3,$$

confirmando que

$$\text{posto}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}) = 3.$$

Aplicando o resultado a $\mathbf{A}^\top$,

$$1 + 1 = 2,$$

de modo que

$$\text{posto}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}^\top) = 2.$$

Os resultados correspondem, respectivamente, às dimensões dos espaços ambientes $\mathbb{R}^3$ e $\mathbb{R}^2$.

3.3.6 Os quatro espaços fundamentais

Os quatro subespaços associados a

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

são:

Tabela 3.1: Espaços fundamentais de uma matriz $\mathbf{A} \in \mathbb{R}^{n \times p}$ com posto r .

Espaço	Definição	Subespaço de	Dimensão
Espaço coluna	$\mathcal{C}(\mathbf{A})$	$\mathbb{R}^n$	r
Espaço linha	$\mathcal{L}(\mathbf{A}) = \mathcal{C}(\mathbf{A}^\top)$	$\mathbb{R}^p$	r
Espaço nulo	$\mathcal{N}(\mathbf{A})$	$\mathbb{R}^p$	$p - r$
Espaço nulo à esquerda	$\mathcal{N}(\mathbf{A}^\top)$	$\mathbb{R}^n$	$n - r$

A Tabela 3.1 mostra que os quatro espaços se organizam em dois espaços ambientes. O espaço coluna e o espaço nulo à esquerda são subespaços de $\mathbb{R}^n$, enquanto o espaço linha e o espaço nulo são subespaços de $\mathbb{R}^p$.

3.3.7 Complemento ortogonal

Definição 3.15 (Complemento ortogonal). Seja S um subespaço de $\mathbb{R}^p$. O **complemento ortogonal** de S é

$$S^\perp = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{x}^\top \mathbf{s} = 0 \text{ para todo } \mathbf{s} \in S\}.$$

O complemento ortogonal reúne todos os vetores de $\mathbb{R}^p$ que são ortogonais a cada vetor de S e permite expressar as relações de ortogonalidade entre os quatro espaços fundamentais de uma matriz.

3.3.8 Relações de ortogonalidade

Teorema 3.5 (Ortogonalidade entre os espaços fundamentais). *Para*

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

tem-se

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$



i Demonstração

Considere inicialmente

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}).$$

Então

$$\mathbf{Ax} = \mathbf{0}.$$

Cada componente de $\mathbf{Ax}$ é o produto interno entre uma linha de $\mathbf{A}$ e $\mathbf{x}$. Portanto, $\mathbf{x}$ é ortogonal a todas as linhas de $\mathbf{A}$ e, conseqüentemente, a todo vetor de $\mathcal{L}(\mathbf{A})$. Logo,

$$\mathbf{x} \in \mathcal{L}(\mathbf{A})^\perp.$$

Assim,

$$\mathcal{N}(\mathbf{A}) \subseteq \mathcal{L}(\mathbf{A})^\perp.$$

Reciprocamente, suponha que

$$\mathbf{x} \in \mathcal{L}(\mathbf{A})^\perp.$$

Então $\mathbf{x}$ é ortogonal a todas as linhas de $\mathbf{A}$. Cada componente de $\mathbf{Ax}$ é, portanto, igual a zero, de modo que

$$\mathbf{Ax} = \mathbf{0}.$$

Logo,

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}),$$

e

$$\mathcal{L}(\mathbf{A})^\perp \subseteq \mathcal{N}(\mathbf{A}).$$

Portanto,

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp.$$

De forma análoga, para

$$\mathbf{y} \in \mathbb{R}^n,$$

a condição

$$\mathbf{A}^\top \mathbf{y} = \mathbf{0}$$

equivale a $\mathbf{y}$ ser ortogonal a todas as colunas de $\mathbf{A}$. Portanto,

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Essas relações mostram que os espaços fundamentais se organizam em dois pares ortogonais:

$$\mathcal{L}(\mathbf{A}) \perp \mathcal{N}(\mathbf{A})$$

em $\mathbb{R}^p$, e

$$\mathcal{C}(\mathbf{A}) \perp \mathcal{N}(\mathbf{A}^\top)$$

em $\mathbb{R}^n$.

As decomposições dos espaços ambientes em somas diretas desses pares são estabelecidas em Proposição 3.12.

3.4 Produtos internos e matrizes de Gram

O produto interno euclidiano

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^\top \mathbf{y}$$

define comprimentos, ângulos e ortogonalidade em $\mathbb{R}^p$. Além da geometria euclidiana, é possível definir outras geometrias atribuindo pesos e relações diferentes às coordenadas.

3.4.1 Produtos internos e geometrias induzidas

Uma matriz simétrica positiva definida permite definir um produto interno que modifica comprimentos, distâncias e relações de ortogonalidade em relação à geometria euclidiana. O produto interno induzido fornece a base matemática para distâncias ponderadas e geometrias determinadas por matrizes de dispersão. (Gentle, 2017)

Considere uma matriz simétrica positiva definida

$$\mathbf{M} \in \mathbb{R}^{p \times p}.$$

Definição 3.16 (Produto interno induzido por uma matriz). O **produto interno induzido por $\mathbf{M}$** é definido por

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{y}, \quad \mathbf{x}, \mathbf{y} \in \mathbb{R}^p.$$

A simetria de $\mathbf{M}$ garante que

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \langle \mathbf{y}, \mathbf{x} \rangle_{\mathbf{M}},$$

pois

$$\mathbf{x}^\top \mathbf{M} \mathbf{y} = (\mathbf{x}^\top \mathbf{M} \mathbf{y})^\top = \mathbf{y}^\top \mathbf{M}^\top \mathbf{x} = \mathbf{y}^\top \mathbf{M} \mathbf{x}.$$

A definição positiva garante que

$$\langle \mathbf{x}, \mathbf{x} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$.

Proposição 3.8 (Propriedades do produto interno induzido). *Para quaisquer $\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$ e $\alpha, \beta \in \mathbb{R}$,*

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \langle \mathbf{y}, \mathbf{x} \rangle_{\mathbf{M}},$$

$$\langle \alpha \mathbf{x} + \beta \mathbf{y}, \mathbf{z} \rangle_{\mathbf{M}} = \alpha \langle \mathbf{x}, \mathbf{z} \rangle_{\mathbf{M}} + \beta \langle \mathbf{y}, \mathbf{z} \rangle_{\mathbf{M}},$$

e

$$\langle \mathbf{x}, \mathbf{x} \rangle_{\mathbf{M}} > 0 \quad \text{para} \quad \mathbf{x} \neq \mathbf{0}.$$

(Eaton, 2007; Gentle, 2017)

Quando

$$\mathbf{M} = \mathbf{I}_p,$$

recupera-se o produto interno euclidiano:

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{I}_p} = \mathbf{x}^\top \mathbf{y}.$$

Exemplo 3.17 (Cálculo de um produto interno induzido). Considere

$$\mathbf{M} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

e

$$\mathbf{y} = \begin{bmatrix} 2 \\ -1 \end{bmatrix}.$$

Então,

$$\mathbf{M}\mathbf{y} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 2 \\ -1 \end{bmatrix} = \begin{bmatrix} 3 \\ 0 \end{bmatrix}.$$

Logo,

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^{\top} \mathbf{M} \mathbf{y} = \begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} 3 \\ 0 \end{bmatrix} = 3.$$

O produto interno euclidiano entre os mesmos vetores é

$$\mathbf{x}^{\top} \mathbf{y} = 1(2) + 2(-1) = 0.$$

Portanto, os vetores são ortogonais segundo o produto interno euclidiano, mas não segundo o produto interno induzido por $\mathbf{M}$.

3.4.1.1 Norma e distância induzidas

Definição 3.17 (Norma induzida). A norma associada ao produto interno induzido por $\mathbf{M}$ é

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle_{\mathbf{M}}} = \sqrt{\mathbf{x}^{\top} \mathbf{M} \mathbf{x}}.$$

A distância associada é

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_{\mathbf{M}},$$

ou, equivalentemente,

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \sqrt{(\mathbf{x} - \mathbf{y})^{\top} \mathbf{M} (\mathbf{x} - \mathbf{y})}.$$

Quando $\mathbf{M} = \mathbf{I}_p$, obtêm-se a norma e a distância euclidianas.

Exemplo 3.18 (Norma e distância induzidas). Considere

$$\mathbf{M} = \begin{bmatrix} 1 & 0 \\ 0 & 4 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

A norma euclidiana de $\mathbf{x}$ é

$$\|\mathbf{x}\| = \sqrt{2^2 + 1^2} = \sqrt{5}.$$

A norma induzida por $\mathbf{M}$ é

$$\begin{aligned} \|\mathbf{x}\|_{\mathbf{M}} &= \sqrt{\begin{bmatrix} 2 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix}} \\ &= \sqrt{8}. \end{aligned}$$

A segunda coordenada recebe peso maior na geometria definida por $\mathbf{M}$.

3.4.1.2 Ortogonalidade induzida

Dois vetores $\mathbf{x}$ e $\mathbf{y}$ são ortogonais segundo $\mathbf{M}$ quando

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^{\top} \mathbf{M} \mathbf{y} = 0.$$

Uma base

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é $\mathbf{M}$ -ortonormal quando

$$\mathbf{b}_i^{\top} \mathbf{M} \mathbf{b}_j = \delta_{ij},$$

em que δ_{ij} é o delta de Kronecker definido em Definição 2.9.

Se

$$\mathbf{B} = [\mathbf{b}_1 \quad \cdots \quad \mathbf{b}_k],$$

essa condição pode ser escrita como

$$\mathbf{B}^\top \mathbf{M} \mathbf{B} = \mathbf{I}_k.$$

3.4.1.3 Relação com a geometria euclidiana

Como $\mathbf{M}$ é simétrica positiva definida, existe uma matriz invertível $\mathbf{C}$ tal que

$$\mathbf{M} = \mathbf{C}^\top \mathbf{C}.$$

Assim,

$$\begin{aligned} \langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} &= \mathbf{x}^\top \mathbf{C}^\top \mathbf{C} \mathbf{y} \\ &= (\mathbf{C} \mathbf{x})^\top (\mathbf{C} \mathbf{y}). \end{aligned}$$

Assim, o produto interno induzido por $\mathbf{M}$ pode ser interpretado como o produto interno euclidiano entre os vetores $\mathbf{C} \mathbf{x}$ e $\mathbf{C} \mathbf{y}$. Da mesma forma,

$$\|\mathbf{x}\|_{\mathbf{M}} = \|\mathbf{C} \mathbf{x}\|.$$

As curvas de nível

$$\|\mathbf{x}\|_{\mathbf{M}} = 1$$

satisfazem

$$\mathbf{x}^\top \mathbf{M} \mathbf{x} = 1.$$

Na geometria euclidiana, essas curvas são circunferências quando $\mathbf{M} = \mathbf{I}_2$ e elipses para outras matrizes positivas definidas.

A Figura 3.4 compara três geometrias em $\mathbb{R}^2$.

A matriz identidade produz a circunferência euclidiana. Uma matriz diagonal com pesos distintos produz uma elipse alinhada aos eixos coordenados. Elementos fora da diagonal podem alterar a orientação da elipse.




Figura 3.4: Curvas de norma unitária para diferentes produtos internos em $\mathbb{R}^2$.

Os produtos internos entre vários vetores podem ser organizados em uma matriz de Gram.

3.4.2 Matrizes de Gram

Os produtos internos entre um conjunto de vetores podem ser organizados em uma matriz.

Definição 3.18 (Matriz de Gram). Sejam $\mathbf{v}_1, \dots, \mathbf{v}_k \in \mathbb{R}^p$ e

$$\mathbf{V} = [\mathbf{v}_1 \quad \mathbf{v}_2 \quad \dots \quad \mathbf{v}_k] \in \mathbb{R}^{p \times k}.$$

A **matriz de Gram** dos vetores é

$$\mathbf{G} = \mathbf{V}^\top \mathbf{V}.$$

Seu elemento na posição (i, j) é

$$g_{ij} = \mathbf{v}_i^\top \mathbf{v}_j.$$

A diagonal de $\mathbf{G}$ contém os quadrados das normas:

$$g_{ii} = \mathbf{v}_i^\top \mathbf{v}_i = \|\mathbf{v}_i\|^2.$$

Os elementos fora da diagonal contêm os produtos internos entre vetores distintos.

Quando $\mathbf{v}_i$ e $\mathbf{v}_j$ são não nulos,

$$g_{ij} = \|\mathbf{v}_i\| \|\mathbf{v}_j\| \cos(\theta_{ij}).$$

Portanto, o produto interno depende tanto das normas quanto do ângulo entre os vetores.

Exemplo 3.19 (Construção de uma matriz de Gram). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$$

e

$$\mathbf{V} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

A matriz de Gram é

$$\begin{aligned} \mathbf{G} &= \mathbf{V}^\top \mathbf{V} \\ &= \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}. \end{aligned}$$

Os elementos diagonais são

$$\|\mathbf{v}_1\|^2 = \|\mathbf{v}_2\|^2 = 2,$$

e o elemento fora da diagonal é

$$\mathbf{v}_1^\top \mathbf{v}_2 = 1.$$

3.4.3 Propriedades da matriz de Gram


Proposição 3.9 (Propriedades da matriz de Gram). *Para*

$$\mathbf{G} = \mathbf{V}^\top \mathbf{V},$$

tem-se:

1. $\mathbf{G}$ é simétrica;
2. $\mathbf{G}$ é semidefinida positiva;
3. $\mathbf{G}$ é positiva definida se, e somente se, as colunas de $\mathbf{V}$ são linearmente independentes;
4. $\text{posto}(\mathbf{G}) = \text{posto}(\mathbf{V})$.

(Gentle, 2017)



i Demonstração

A simetria decorre de

$$\mathbf{G}^\top = (\mathbf{V}^\top \mathbf{V})^\top = \mathbf{V}^\top \mathbf{V} = \mathbf{G}.$$

Para qualquer $\mathbf{c} \in \mathbb{R}^k$,

$$\begin{aligned}\mathbf{c}^\top \mathbf{G} \mathbf{c} &= \mathbf{c}^\top \mathbf{V}^\top \mathbf{V} \mathbf{c} \\ &= (\mathbf{V} \mathbf{c})^\top (\mathbf{V} \mathbf{c}) \\ &= \|\mathbf{V} \mathbf{c}\|^2 \\ &\geq 0.\end{aligned}$$

Logo, $\mathbf{G}$ é semidefinida positiva.

Além disso,

$$\mathbf{c}^\top \mathbf{G} \mathbf{c} = 0$$

se, e somente se,

$$\mathbf{V} \mathbf{c} = \mathbf{0}.$$

Portanto, $\mathbf{G}$ é positiva definida se, e somente se, o sistema homogêneo

$$\mathbf{V} \mathbf{c} = \mathbf{0}$$

possui apenas a solução trivial, o que equivale à independência linear das colunas de $\mathbf{V}$.

Para demonstrar a igualdade dos núcleos, suponha inicialmente que

$$\mathbf{V}^\top \mathbf{V} \mathbf{c} = \mathbf{0}.$$

Multiplicando à esquerda por $\mathbf{c}^\top$,

$$\mathbf{c}^\top \mathbf{V}^\top \mathbf{V} \mathbf{c} = \|\mathbf{V} \mathbf{c}\|^2 = 0.$$

Logo,

$$\mathbf{V} \mathbf{c} = \mathbf{0},$$

e, portanto,

Uma consequência é:

$$\det(\mathbf{V}^\top \mathbf{V}) > 0$$

se, e somente se, as colunas de $\mathbf{V}$ são linearmente independentes.

Quando as colunas são linearmente dependentes,

$$\det(\mathbf{V}^\top \mathbf{V}) = 0.$$

3.4.4 Matrizes de Gram e bases ortonormais

Se as colunas de $\mathbf{Q}$ formam um conjunto ortonormal, então

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}.$$

Portanto, a matriz de Gram de um conjunto ortonormal é a matriz identidade.

Para uma base ortogonal não normalizada,

$$\mathbf{V}^\top \mathbf{V} = \text{diag}(\|\mathbf{v}_1\|^2, \dots, \|\mathbf{v}_k\|^2).$$

Exemplo 3.20 (Matriz de Gram de uma base ortogonal). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Como

$$\mathbf{v}_1^\top \mathbf{v}_2 = 0,$$

os vetores são ortogonais.

A matriz de Gram é

$$\mathbf{G} = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}.$$

Normalizando os vetores,

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

obtem-se

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_2.$$

3.4.5 Produtos cruzados em uma matriz de dados

Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p}.$$

O produto

$$\mathbf{X}^\top \mathbf{X} \in \mathbb{R}^{p \times p}$$

é a matriz de Gram das colunas de $\mathbf{X}$. Seus elementos são

$$(\mathbf{X}^\top \mathbf{X})_{jk} = \sum_{i=1}^n x_{ij} x_{ik}.$$

Assim:

- os elementos diagonais são somas de quadrados das variáveis;
- os elementos fora da diagonal são produtos cruzados entre pares de variáveis.

O produto

$$\mathbf{X} \mathbf{X}^\top \in \mathbb{R}^{n \times n}$$

é a matriz de Gram das linhas de $\mathbf{X}$. Seus elementos são

$$(\mathbf{X} \mathbf{X}^\top)_{ij} = \mathbf{x}_i^\top \mathbf{x}_j,$$

em que $\mathbf{x}_i^\top$ e $\mathbf{x}_j^\top$ representam duas observações.

A Tabela 3.2 resume as duas construções.

Tabela 3.2: Produtos de Gram associados a uma matriz de dados.

Produto	Dimensão	Vetores comparados	Elemento genérico
$\mathbf{X}^\top \mathbf{X}$	$p \times p$	Colunas ou variáveis	$\sum_{i=1}^n x_{ij} x_{ik}$
$\mathbf{X} \mathbf{X}^\top$	$n \times n$	Linhas ou observações	$\mathbf{x}_i^\top \mathbf{x}_j$

Quando as colunas da matriz de dados estão centradas, $\mathbf{X}^\top \mathbf{X}$ reúne as somas de quadrados e produtos cruzados. Para a matriz centralizada $\mathbf{X}_c$, a matriz total SQPC é $\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c$, conforme Definição 8.9.

As matrizes de Gram também aparecem na construção da projeção de um vetor sobre o espaço gerado pelas colunas de uma matriz.

3.5 Complemento e decomposição ortogonais

3.5.1 Propriedades do complemento ortogonal

Para um subespaço arbitrário $S \subseteq \mathbb{R}^p$, o complemento ortogonal reúne os vetores ortogonais a todos os elementos de S .

Se

$$S = \text{span}\{\mathbf{s}_1, \dots, \mathbf{s}_k\},$$

então basta verificar a ortogonalidade em relação aos vetores geradores:

$$S^\perp = \left\{ \mathbf{x} \in \mathbb{R}^p : \mathbf{s}_j^\top \mathbf{x} = 0, \quad j = 1, \dots, k \right\}.$$

Isso ocorre porque todo vetor de S é uma combinação linear dos vetores $\mathbf{s}_1, \dots, \mathbf{s}_k$. Portanto, um vetor ortogonal a todos os geradores é ortogonal a todo o subespaço.

Proposição 3.10 (O complemento ortogonal é um subespaço). *Se S é um subespaço de $\mathbb{R}^p$, então $S^\perp$ também é um subespaço de $\mathbb{R}^p$.*

i Demonstração

O vetor nulo pertence a $S^\perp$, pois

$$\mathbf{0}^\top \mathbf{s} = 0$$

para todo $\mathbf{s} \in S$.

Se

$$\mathbf{x}, \mathbf{y} \in S^\perp,$$

então, para quaisquer $\alpha, \beta \in \mathbb{R}$ e $\mathbf{s} \in S$,

$$(\alpha \mathbf{x} + \beta \mathbf{y})^\top \mathbf{s} = \alpha \mathbf{x}^\top \mathbf{s} + \beta \mathbf{y}^\top \mathbf{s} = 0.$$

Portanto,

$$\alpha \mathbf{x} + \beta \mathbf{y} \in S^\perp,$$

e $S^\perp$ é um subespaço de $\mathbb{R}^p$.

Exemplo 3.21 (Complemento ortogonal de uma reta). Considere

$$S = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \end{bmatrix} \right\} \subseteq \mathbb{R}^2.$$

Um vetor

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

pertence a $S^\perp$ quando

$$\begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0.$$

Assim,

$$x_1 + 2x_2 = 0.$$

Tomando $x_2 = t$, obtém-se

$$x_1 = -2t.$$


Logo,

$$S^\perp = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \end{bmatrix} \right\}.$$

3.5.2 Dimensão do complemento ortogonal

Proposição 3.11 (Dimensão do complemento ortogonal). *Se S é um subespaço de $\mathbb{R}^p$, então*

$$\dim(S) + \dim(S^\perp) = p.$$



i Demonstração

Seja

$$\dim(S) = k.$$

Pelo Teorema 3.2, existe uma base ortonormal

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$$

de S .

Como toda base de um subespaço de dimensão finita pode ser completada para formar uma base do espaço ambiente (Teorema 3.8), podem-se acrescentar vetores à base de S . Aplicando o processo de Gram–Schmidt aos vetores acrescentados, preservando os primeiros k vetores, obtém-se uma base ortonormal de $\mathbb{R}^p$:

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k, \mathbf{q}_{k+1}, \dots, \mathbf{q}_p\}.$$

Como a base é ortonormal,

$$\mathbf{q}_i^\top \mathbf{q}_j = 0, \quad i = 1, \dots, k, \quad j = k + 1, \dots, p.$$

Portanto,

$$\mathbf{q}_{k+1}, \dots, \mathbf{q}_p \in S^\perp.$$

Além disso, esses vetores geram $S^\perp$. De fato, para qualquer

$$\mathbf{x} \in S^\perp,$$

como a coleção completa é uma base de $\mathbb{R}^p$, pode-se escrever

$$\mathbf{x} = \sum_{j=1}^p \alpha_j \mathbf{q}_j.$$

Para $i = 1, \dots, k$,

$$\mathbf{q}_i^\top \mathbf{x} = \alpha_i.$$

Como $\mathbf{x} \in S^\perp$,

$$\mathbf{q}_i^\top \mathbf{x} = 0,$$

Consequentemente, se

$$\dim(S) = k,$$

então

$$\dim(S^\perp) = p - k.$$

Além disso,

$$S \cap S^\perp = \{\mathbf{0}\}.$$

De fato, se

$$\mathbf{x} \in S \cap S^\perp,$$

então $\mathbf{x}$ é ortogonal a todos os vetores de S , inclusive a si próprio. Portanto,

$$\mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|^2 = 0,$$

o que implica

$$\mathbf{x} = \mathbf{0}.$$

3.5.3 Decomposição ortogonal

Teorema 3.6 (Decomposição ortogonal). *Se S é um subespaço de $\mathbb{R}^p$, então todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito de maneira única como*

$$\mathbf{x} = \mathbf{x}_S + \mathbf{x}_{S^\perp},$$

em que

$$\mathbf{x}_S \in S$$

e

$$\mathbf{x}_{S^\perp} \in S^\perp.$$

Equivalentemente,

$$\mathbb{R}^p = S \oplus S^\perp.$$

*O símbolo $\oplus$ representa uma **soma direta**: cada vetor de $\mathbb{R}^p$ possui uma única decomposição como soma de um vetor pertencente a S e um vetor pertencente a $S^\perp$.*



i Demonstração

Pelo Teorema 3.2, existe uma base ortonormal

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$$

de S .

Defina

$$\mathbf{x}_S = \sum_{j=1}^k (\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_j$$

e

$$\mathbf{x}_{S^\perp} = \mathbf{x} - \mathbf{x}_S.$$

Por construção,

$$\mathbf{x}_S \in S.$$

Para cada $i = 1, \dots, k$,

$$\begin{aligned} \mathbf{q}_i^\top \mathbf{x}_{S^\perp} &= \mathbf{q}_i^\top \mathbf{x} - \sum_{j=1}^k (\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_i^\top \mathbf{q}_j \\ &= \mathbf{q}_i^\top \mathbf{x} - \mathbf{q}_i^\top \mathbf{x} \\ &= 0. \end{aligned}$$

Logo,

$$\mathbf{x}_{S^\perp} \in S^\perp,$$

o que demonstra a existência da decomposição.

Para demonstrar a unicidade, suponha que

$$\mathbf{x} = \mathbf{s}_1 + \mathbf{r}_1 = \mathbf{s}_2 + \mathbf{r}_2,$$

com

$$\mathbf{s}_1, \mathbf{s}_2 \in S$$

A decomposição separa $\mathbf{x}$ em duas componentes únicas: $\mathbf{x}_S \in S$ e $\mathbf{x}_{S^\perp} \in S^\perp$. A componente $\mathbf{x}_S$ é a projeção ortogonal de $\mathbf{x}$ sobre S , enquanto

$$\mathbf{x}_{S^\perp} = \mathbf{x} - \mathbf{x}_S$$

é a componente ortogonal a S .

3.5.4 Decomposição dos espaços fundamentais

A decomposição ortogonal pode ser aplicada diretamente aos quatro espaços fundamentais de uma matriz.

Proposição 3.12 (Decomposição dos espaços fundamentais). *Para uma matriz $\mathbf{A} \in \mathbb{R}^{n \times p}$,*

$$\mathbb{R}^p = \mathcal{L}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A})$$

e

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top).$$

De fato, pelo Teorema 3.5,

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp.$$

Aplicando o Teorema 3.6,

$$\mathbb{R}^p = \mathcal{L}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}).$$

Portanto, todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito de maneira única como

$$\mathbf{x} = \mathbf{x}_{\mathcal{L}} + \mathbf{x}_{\mathcal{N}},$$

com $\mathbf{x}_{\mathcal{L}} \in \mathcal{L}(\mathbf{A})$ e $\mathbf{x}_{\mathcal{N}} \in \mathcal{N}(\mathbf{A})$.

Analogamente,

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp,$$

e, portanto,

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top).$$

Assim, todo vetor $\mathbf{y} \in \mathbb{R}^n$ pode ser escrito de maneira única como

$$\mathbf{y} = \mathbf{y}_{\mathcal{C}} + \mathbf{y}_{\mathcal{N}^\top},$$

com $\mathbf{y}_{\mathcal{C}} \in \mathcal{C}(\mathbf{A})$ e $\mathbf{y}_{\mathcal{N}^\top} \in \mathcal{N}(\mathbf{A}^\top)$.

Os quatro espaços fundamentais formam, portanto, dois pares de subespaços ortogonais complementares: um em $\mathbb{R}^p$ e outro em $\mathbb{R}^n$.

3.6 Projeções ortogonais

O Teorema 3.6 estabelece que, para qualquer subespaço $S \subseteq \mathbb{R}^p$, todo vetor $\mathbf{x} \in \mathbb{R}^p$ admite uma decomposição única em uma componente pertencente a S e outra pertencente a $S^\perp$. Essa decomposição permite definir a projeção ortogonal sobre um subespaço.

Definição 3.19 (Projeção ortogonal). Seja S um subespaço de $\mathbb{R}^p$. Pela decomposição ortogonal, todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito de maneira única como

$$\mathbf{x} = \mathbf{x}_S + \mathbf{x}_{S^\perp},$$

com $\mathbf{x}_S \in S$ e $\mathbf{x}_{S^\perp} \in S^\perp$.

A **projeção ortogonal de $\mathbf{x}$ sobre S** é definida por

$$\text{proj}_S(\mathbf{x}) = \mathbf{x}_S.$$

Consequentemente,

$$\mathbf{x} - \text{proj}_S(\mathbf{x}) \in S^\perp.$$

A forma da projeção depende de como o subespaço S é representado. Começaremos pelo caso mais simples, em que S possui dimensão 1.

3.6.1 Projeção sobre uma direção

Considere o subespaço unidimensional

$$S = \text{span}\{\mathbf{u}\},$$

em que

$$\mathbf{u} \neq \mathbf{0}.$$

A projeção de $\mathbf{x} \in \mathbb{R}^p$ sobre S deve pertencer ao próprio subespaço. Portanto, possui a forma

$$\text{proj}_S(\mathbf{x}) = \alpha \mathbf{u},$$

para algum $\alpha \in \mathbb{R}$.

O resíduo

$$\mathbf{r} = \mathbf{x} - \alpha \mathbf{u}$$

deve ser ortogonal a $\mathbf{u}$. Assim,

$$\mathbf{u}^\top (\mathbf{x} - \alpha \mathbf{u}) = 0.$$

Logo,

$$\mathbf{u}^\top \mathbf{x} - \alpha \mathbf{u}^\top \mathbf{u} = 0,$$

e, como $\mathbf{u} \neq \mathbf{0}$,

$$\alpha = \frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}}.$$

Proposição 3.13 (Projeção sobre uma direção). *Se*

$$S = \text{span}\{\mathbf{u}\}, \quad \mathbf{u} \neq \mathbf{0},$$

então a projeção ortogonal de $\mathbf{x} \in \mathbb{R}^p$ sobre S é

$$\text{proj}_S(\mathbf{x}) = \frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}} \mathbf{u}.$$

Como $\mathbf{u}^\top \mathbf{x}$ é um escalar, pode-se escrever

$$\frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}} \mathbf{u} = \frac{1}{\mathbf{u}^\top \mathbf{u}} \mathbf{u} (\mathbf{u}^\top \mathbf{x}).$$

Pela associatividade da multiplicação matricial,

$$\mathbf{u} (\mathbf{u}^\top \mathbf{x}) = (\mathbf{u} \mathbf{u}^\top) \mathbf{x}.$$

Portanto,

$$\begin{aligned} \text{proj}_S(\mathbf{x}) &= \frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}} \mathbf{u} = \frac{1}{\mathbf{u}^\top \mathbf{u}} \mathbf{u} (\mathbf{u}^\top \mathbf{x}) \\ &= \frac{1}{\mathbf{u}^\top \mathbf{u}} (\mathbf{u} \mathbf{u}^\top) \mathbf{x} = \frac{\mathbf{u} \mathbf{u}^\top}{\mathbf{u}^\top \mathbf{u}} \mathbf{x}. \end{aligned}$$

Portanto, definindo

$$\mathbf{P}_S = \frac{\mathbf{u} \mathbf{u}^\top}{\mathbf{u}^\top \mathbf{u}},$$

a projeção pode ser escrita na forma matricial

$$\text{proj}_S(\mathbf{x}) = \mathbf{P}_S \mathbf{x}.$$

A matriz

$$\mathbf{u} \mathbf{u}^\top$$

é o produto externo de $\mathbf{u}$ por ele próprio. Como visto nos capítulos anteriores, essa matriz é simétrica e, para $\mathbf{u} \neq \mathbf{0}$, possui posto 1. A normalização por $\mathbf{u}^\top \mathbf{u}$ produz a matriz que projeta ortogonalmente os vetores sobre a direção gerada por $\mathbf{u}$.

Se $\mathbf{u}$ possui norma igual a 1, então

$$\mathbf{u}^\top \mathbf{u} = 1,$$

e as expressões reduzem-se a

$$\text{proj}_S(\mathbf{x}) = (\mathbf{u}^\top \mathbf{x}) \mathbf{u}$$

e

$$\mathbf{P}_S = \mathbf{u}\mathbf{u}^\top.$$

Exemplo 3.22 (Projeção sobre uma reta). Considere

$$\mathbf{x} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}$$

e

$$S = \text{span} \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}.$$

Tomando

$$\mathbf{u} = \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

tem-se

$$\mathbf{u}^\top \mathbf{x} = 4$$

e

$$\mathbf{u}^\top \mathbf{u} = 2.$$

Portanto,

$$\text{proj}_S(\mathbf{x}) = \frac{4}{2} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \end{bmatrix}.$$

Equivalentemente, a matriz de projeção é

$$\begin{aligned} \mathbf{P}_S &= \frac{\mathbf{u}\mathbf{u}^\top}{\mathbf{u}^\top \mathbf{u}} \\ &= \frac{1}{2} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \end{bmatrix} \\ &= \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}. \end{aligned}$$

Assim,

$$\mathbf{P}_S \mathbf{x} = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 3 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \end{bmatrix}.$$

O resíduo é

$$\mathbf{r} = \mathbf{x} - \text{proj}_S(\mathbf{x}) = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A ortogonalidade é verificada por

$$\begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = 0.$$

Assim,

$$\mathbf{x} = \begin{bmatrix} 2 \\ 2 \end{bmatrix} + \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

com a primeira componente em S e a segunda em $S^\perp$.

A Figura 3.5 representa essa decomposição e destaca a ortogonalidade entre a projeção e o resíduo.

A projeção pertence ao subespaço S , enquanto o resíduo pertence a $S^\perp$. Para uma base ortonormal de S , a projeção é obtida pela soma das projeções sobre as direções da base.

3.6.2 Projeção sobre um subespaço com base ortonormal

Considere um subespaço

$$S = \text{span}\{\mathbf{q}_1, \dots, \mathbf{q}_k\} \subseteq \mathbb{R}^p,$$

em que

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$$

é uma base ortonormal de S .

A projeção de $\mathbf{x} \in \mathbb{R}^p$ sobre S é obtida somando as projeções de $\mathbf{x}$ sobre cada vetor da base:




Figura 3.5: Decomposição de um vetor em sua projeção sobre um subespaço e em um resíduo ortogonal.

$$\text{proj}_S(\mathbf{x}) = \sum_{j=1}^k (\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_j.$$

Como

$$(\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_j = \mathbf{q}_j \mathbf{q}_j^\top \mathbf{x},$$

tem-se

$$\text{proj}_S(\mathbf{x}) = \left(\sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top \right) \mathbf{x}.$$

Cada matriz

$$\mathbf{q}_j \mathbf{q}_j^\top$$

é o produto externo do vetor $\mathbf{q}_j$ por ele próprio. Como $\mathbf{q}_j \neq \mathbf{0}$, cada uma dessas matrizes possui posto 1 e projeta sobre a direção gerada por $\mathbf{q}_j$.

Reunindo os vetores da base na matriz

$$\mathbf{Q} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_k] \in \mathbb{R}^{p \times k},$$

tem-se

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k.$$

Além disso,

$$\mathbf{Q} \mathbf{Q}^\top = \sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top.$$

Portanto,

$$\text{proj}_S(\mathbf{x}) = \mathbf{Q} \mathbf{Q}^\top \mathbf{x}.$$

Proposição 3.14 (Projeção sobre uma base ortonormal). *Se as colunas de*

$$\mathbf{Q} \in \mathbb{R}^{p \times k}$$

formam uma base ortonormal de S , então

$$\text{proj}_S(\mathbf{x}) = \mathbf{Q}\mathbf{Q}^\top \mathbf{x}.$$

A matriz de projeção sobre S é

$$\mathbf{P}_S = \mathbf{Q}\mathbf{Q}^\top = \sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top.$$

(Eaton, 2007)

O vetor

$$\mathbf{Q}^\top \mathbf{x} = \begin{bmatrix} \mathbf{q}_1^\top \mathbf{x} \\ \vdots \\ \mathbf{q}_k^\top \mathbf{x} \end{bmatrix}$$

contém as coordenadas da projeção de $\mathbf{x}$ na base ortonormal de S . A multiplicação por $\mathbf{Q}$ utiliza essas coordenadas para reconstruir o vetor projetado no espaço original:

$$\mathbf{x} \xrightarrow{\mathbf{Q}^\top} \mathbf{Q}^\top \mathbf{x} \xrightarrow{\mathbf{Q}} \mathbf{Q}\mathbf{Q}^\top \mathbf{x}.$$

Assim, $\mathbf{Q}^\top$ obtém as coordenadas no subespaço, enquanto $\mathbf{Q}$ reconstrói o vetor correspondente em $\mathbb{R}^p$.

Exemplo 3.23 (Projeção sobre um plano). Considere o subespaço

$$S = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \right\} \subseteq \mathbb{R}^3.$$

Uma base ortonormal de S é formada por

$$\mathbf{q}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} \quad \text{e} \quad \mathbf{q}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}.$$

Assim,

$$\mathbf{Q} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}.$$

A matriz de projeção é

$$\begin{aligned} \mathbf{P}_S &= \mathbf{Q}\mathbf{Q}^\top \\ &= \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}. \end{aligned}$$

Equivalentemente,

$$\mathbf{P}_S = \mathbf{q}_1\mathbf{q}_1^\top + \mathbf{q}_2\mathbf{q}_2^\top.$$

Para

$$\mathbf{x} = \begin{bmatrix} 2 \\ -1 \\ 3 \end{bmatrix},$$

tem-se

$$\text{proj}_S(\mathbf{x}) = \mathbf{P}_S\mathbf{x} = \begin{bmatrix} 2 \\ -1 \\ 0 \end{bmatrix}.$$

O resíduo é

$$\mathbf{r} = \mathbf{x} - \text{proj}_S(\mathbf{x}) = \begin{bmatrix} 0 \\ 0 \\ 3 \end{bmatrix},$$

que pertence a $S^\perp$.

3.6.3 Projeção sobre o espaço coluna de uma matriz

Considere vetores linearmente independentes

$$\mathbf{a}_1, \dots, \mathbf{a}_k \in \mathbb{R}^p$$

e a matriz formada por esses vetores:

$$\mathbf{A} = [\mathbf{a}_1 \quad \dots \quad \mathbf{a}_k] \in \mathbb{R}^{p \times k}.$$

Como os vetores foram previamente nomeados e depois reunidos em $\mathbf{A}$, a notação $\mathbf{a}_1, \dots, \mathbf{a}_k$ será mantida nesta subseção.

O subespaço gerado pelas colunas de $\mathbf{A}$ é

$$S = \mathcal{C}(\mathbf{A}) = \text{span}\{\mathbf{a}_1, \dots, \mathbf{a}_k\}.$$

A projeção de $\mathbf{x} \in \mathbb{R}^p$ sobre S deve pertencer ao espaço coluna de $\mathbf{A}$. Portanto, possui a forma

$$\hat{\mathbf{x}} = \mathbf{A}\mathbf{c},$$

para algum vetor de coeficientes

$$\mathbf{c} \in \mathbb{R}^k.$$

O resíduo

$$\mathbf{r} = \mathbf{x} - \mathbf{A}\mathbf{c}$$

deve pertencer ao complemento ortogonal de $\mathcal{C}(\mathbf{A})$. Assim, ele deve ser ortogonal a todas as colunas de $\mathbf{A}$:

$$\mathbf{A}^\top (\mathbf{x} - \mathbf{A}\mathbf{c}) = \mathbf{0}.$$

Desenvolvendo,

$$\mathbf{A}^\top \mathbf{x} - \mathbf{A}^\top \mathbf{A}\mathbf{c} = \mathbf{0},$$

de modo que

$$\mathbf{A}^\top \mathbf{A} \mathbf{c} = \mathbf{A}^\top \mathbf{x}.$$

A matriz

$$\mathbf{A}^\top \mathbf{A}$$

é a matriz de Gram das colunas de $\mathbf{A}$. Como essas colunas são linearmente independentes, $\mathbf{A}^\top \mathbf{A}$ é positiva definida e, portanto, invertível.

Assim,

$$\mathbf{c} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x}.$$

Substituindo em

$$\hat{\mathbf{x}} = \mathbf{A} \mathbf{c},$$

obtém-se

$$\hat{\mathbf{x}} = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x}.$$

Proposição 3.15 (Projeção sobre o espaço coluna). *Se*

$$\mathbf{A} \in \mathbb{R}^{p \times k}$$

possui colunas linearmente independentes, a projeção ortogonal de $\mathbf{x} \in \mathbb{R}^p$ sobre $\mathcal{C}(\mathbf{A})$ é

$$\text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}) = \mathbf{P}_\mathbf{A} \mathbf{x},$$

em que

$$\mathbf{P}_\mathbf{A} = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

A matriz $\mathbf{P}_\mathbf{A}$ depende apenas do subespaço gerado pelas colunas de $\mathbf{A}$, e não da base particular escolhida para representá-lo.

De fato, suponha que outra base do mesmo subespaço seja organizada em uma matriz

$$\mathbf{B} = \mathbf{A}\mathbf{R},$$

em que $\mathbf{R} \in \mathbb{R}^{k \times k}$ é invertível. Então

$$\begin{aligned}\mathbf{P}_\mathbf{B} &= \mathbf{B}(\mathbf{B}^\top \mathbf{B})^{-1} \mathbf{B}^\top \\ &= \mathbf{A}\mathbf{R}(\mathbf{R}^\top \mathbf{A}^\top \mathbf{A}\mathbf{R})^{-1} \mathbf{R}^\top \mathbf{A}^\top \\ &= \mathbf{A}\mathbf{R}\mathbf{R}^{-1}(\mathbf{A}^\top \mathbf{A})^{-1}(\mathbf{R}^\top)^{-1} \mathbf{R}^\top \mathbf{A}^\top \\ &= \mathbf{A}(\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \\ &= \mathbf{P}_\mathbf{A}.\end{aligned}$$

Portanto, bases diferentes do mesmo subespaço produzem a mesma matriz de projeção ortogonal.

Quando as colunas de $\mathbf{A}$ são ortonormais,

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_k,$$

e a expressão reduz-se a

$$\mathbf{P}_\mathbf{A} = \mathbf{A}\mathbf{A}^\top.$$

Esse é exatamente o resultado obtido anteriormente para uma matriz $\mathbf{Q}$ cujas colunas formam uma base ortonormal:

$$\mathbf{P}_\mathbf{S} = \mathbf{Q}\mathbf{Q}^\top.$$

Portanto,

$$\mathbf{Q}\mathbf{Q}^\top$$

é o caso ortonormal da expressão geral

$$\mathbf{A}(\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

Exemplo 3.24 (Projeção utilizando uma base não ortogonal). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}.$$

As colunas de $\mathbf{A}$ são linearmente independentes. A matriz de Gram é

$$\mathbf{A}^\top \mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix},$$

cujas inversa é

$$(\mathbf{A}^\top \mathbf{A})^{-1} = \frac{1}{3} \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}.$$

Além disso,

$$\mathbf{A}^\top \mathbf{x} = \begin{bmatrix} 3 \\ 5 \end{bmatrix}.$$

Os coeficientes da projeção são

$$\begin{aligned} \mathbf{c} &= (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x} \\ &= \frac{1}{3} \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} \begin{bmatrix} 3 \\ 5 \end{bmatrix} \\ &= \frac{1}{3} \begin{bmatrix} 1 \\ 7 \end{bmatrix}. \end{aligned}$$

Portanto,

$$\begin{aligned}
\text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}) &= \mathbf{A}\mathbf{c} \\
&= \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1/3 \\ 7/3 \end{bmatrix} \\
&= \begin{bmatrix} 1/3 \\ 8/3 \\ 7/3 \end{bmatrix}.
\end{aligned}$$

O resíduo é

$$\mathbf{r} = \mathbf{x} - \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}) = \begin{bmatrix} 2/3 \\ -2/3 \\ 2/3 \end{bmatrix}.$$

A ortogonalidade pode ser verificada por

$$\mathbf{A}^\top \mathbf{r} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

Logo,

$$\mathbf{r} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

3.6.4 Propriedades da matriz de projeção

Proposição 3.16 (Propriedades da matriz de projeção). *Se*

$$\mathbf{A} \in \mathbb{R}^{p \times k}$$

possui colunas linearmente independentes e


$$\mathbf{P}_\mathbf{A} = \mathbf{A}(\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top,$$

então:

1. $\mathbf{P}_\mathbf{A}$ é simétrica;
2. $\mathbf{P}_\mathbf{A}$ é idempotente;
3. $\mathcal{C}(\mathbf{P}_\mathbf{A}) = \mathcal{C}(\mathbf{A})$;

$$4. \mathcal{N}(\mathbf{P}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top);$$

$$5. \text{posto}(\mathbf{P}_{\mathbf{A}}) = \text{posto}(\mathbf{A}) = k.$$



A idempotência possui uma interpretação direta: depois que um vetor foi projetado sobre $\mathcal{C}(\mathbf{A})$, uma nova aplicação da mesma projeção não o modifica:

$$\mathbf{P}_{\mathbf{A}} (\mathbf{P}_{\mathbf{A}} \mathbf{x}) = \mathbf{P}_{\mathbf{A}} \mathbf{x}.$$

Além disso, a igualdade

$$\mathcal{N}(\mathbf{P}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})^\perp$$

mostra que a projeção anula exatamente a componente de $\mathbf{x}$ ortogonal ao subespaço projetado.

3.6.5 Projeção residual

A projeção residual separa a componente ortogonal ao espaço projetado e fornece a representação matricial dos resíduos utilizada em mínimos quadrados e em modelos lineares. (Gentle, 2017)

Considere

$$\mathbf{A} \in \mathbb{R}^{p \times k}$$

e seja

$$\mathbf{P}_{\mathbf{A}}$$

a matriz de projeção ortogonal sobre $\mathcal{C}(\mathbf{A})$.

A componente de $\mathbf{x} \in \mathbb{R}^p$ que permanece fora desse subespaço é o resíduo

$$\mathbf{r} = \mathbf{x} - \mathbf{P}_{\mathbf{A}} \mathbf{x}.$$

Definindo

$$\mathbf{M}_{\mathbf{A}} = \mathbf{I}_p - \mathbf{P}_{\mathbf{A}},$$

tem-se

$$\mathbf{r} = \mathbf{M}_{\mathbf{A}} \mathbf{x}.$$

Definição 3.20 (Matriz de projeção residual). A matriz

$$\mathbf{M}_{\mathbf{A}} = \mathbf{I}_p - \mathbf{P}_{\mathbf{A}}$$

é denominada **matriz de projeção residual**. Ela realiza a projeção ortogonal sobre

$$\mathcal{C}(\mathbf{A})^\perp.$$

Como

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top),$$

a matriz $\mathbf{M}_{\mathbf{A}}$ também pode ser interpretada como a matriz de projeção ortogonal sobre o espaço nulo à esquerda de $\mathbf{A}$.

A decomposição ortogonal de $\mathbf{x}$ pode ser escrita como

$$\mathbf{x} = \mathbf{P}_{\mathbf{A}}\mathbf{x} + \mathbf{M}_{\mathbf{A}}\mathbf{x},$$

em que

$$\mathbf{P}_{\mathbf{A}}\mathbf{x} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{M}_{\mathbf{A}}\mathbf{x} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Como essas duas componentes são ortogonais,

$$(\mathbf{P}_{\mathbf{A}}\mathbf{x})^\top (\mathbf{M}_{\mathbf{A}}\mathbf{x}) = 0.$$

Consequentemente, pelo Teorema de Pitágoras,

$$\|\mathbf{x}\|^2 = \|\mathbf{P}_{\mathbf{A}}\mathbf{x}\|^2 + \|\mathbf{M}_{\mathbf{A}}\mathbf{x}\|^2.$$

Proposição 3.17 (Propriedades da matriz de projeção residual). *Se*

$$\mathbf{M}_{\mathbf{A}} = \mathbf{I}_p - \mathbf{P}_{\mathbf{A}},$$

então:

1. $\mathbf{M}_{\mathbf{A}}$ é simétrica;
2. $\mathbf{M}_{\mathbf{A}}$ é idempotente;
3. $\mathbf{P}_{\mathbf{A}}\mathbf{M}_{\mathbf{A}} = \mathbf{0}$ e $\mathbf{M}_{\mathbf{A}}\mathbf{P}_{\mathbf{A}} = \mathbf{0}$;
4. $\mathcal{C}(\mathbf{M}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top)$;
5. $\mathcal{N}(\mathbf{M}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})$;
6. $\text{posto}(\mathbf{M}_{\mathbf{A}}) = p - \text{posto}(\mathbf{A})$.



3.6.6 Projeção como melhor aproximação

A projeção ortogonal pode ser caracterizada por uma propriedade de otimização: entre todos os vetores de um subespaço, ela é o único vetor que possui a menor distância até o vetor original.

Teorema 3.7 (Teorema da melhor aproximação). *Seja S um subespaço de $\mathbb{R}^p$ e seja*

$$\hat{\mathbf{x}} = \text{proj}_S(\mathbf{x}).$$


Então, para qualquer $\mathbf{y} \in S$,

$$\|\mathbf{x} - \hat{\mathbf{x}}\| \leq \|\mathbf{x} - \mathbf{y}\|.$$

A igualdade ocorre se, e somente se,

$$\mathbf{y} = \hat{\mathbf{x}}.$$

(Eaton, 2007)



i Demonstração

Como

$$\hat{\mathbf{x}} \in S$$

e

$$\mathbf{y} \in S,$$

tem-se

$$\hat{\mathbf{x}} - \mathbf{y} \in S.$$

Por outro lado, como $\hat{\mathbf{x}}$ é a projeção ortogonal de $\mathbf{x}$ sobre S , o resíduo

$$\mathbf{x} - \hat{\mathbf{x}}$$

pertence a $S^\perp$.

Portanto,

$$\mathbf{x} - \hat{\mathbf{x}}$$

e

$$\hat{\mathbf{x}} - \mathbf{y}$$

são ortogonais.

Escrevendo

$$\mathbf{x} - \mathbf{y} = (\mathbf{x} - \hat{\mathbf{x}}) + (\hat{\mathbf{x}} - \mathbf{y}),$$

o Teorema de Pitágoras fornece

$$\|\mathbf{x} - \mathbf{y}\|^2 = \|\mathbf{x} - \hat{\mathbf{x}}\|^2 + \|\hat{\mathbf{x}} - \mathbf{y}\|^2.$$

Como

$$\|\hat{\mathbf{x}} - \mathbf{y}\|^2 \geq 0,$$

segue que

$$\|\mathbf{x} - \mathbf{y}\|^2 \geq \|\mathbf{x} - \hat{\mathbf{x}}\|^2.$$

A igualdade ocorre se, e somente se,

$$\|\hat{\mathbf{x}} - \mathbf{y}\|^2 = 0,$$

isto é,

$$\mathbf{y} = \hat{\mathbf{x}}.$$

$$\mathbf{y} = \hat{\mathbf{x}}.$$

Portanto, a projeção ortogonal pode ser caracterizada equivalentemente como

$$\text{proj}_S(\mathbf{x}) = \underset{\mathbf{y} \in S}{\text{argmin}} \|\mathbf{x} - \mathbf{y}\|^2.$$

Assim, projetar ortogonalmente $\mathbf{x}$ sobre S equivale a encontrar, entre todos os vetores pertencentes a S , aquele que está mais próximo de $\mathbf{x}$ segundo a distância euclidiana.

Quando $S = \mathcal{C}(\mathbf{A})$, com $\mathbf{A} \in \mathbb{R}^{p \times k}$, todo vetor de S pode ser escrito como

$$\mathbf{y} = \mathbf{A}\mathbf{c}, \quad \mathbf{c} \in \mathbb{R}^k.$$

Consequentemente, o problema de melhor aproximação pode ser escrito como

$$\hat{\mathbf{c}} \in \underset{\mathbf{c} \in \mathbb{R}^k}{\text{argmin}} \|\mathbf{x} - \mathbf{A}\mathbf{c}\|^2,$$

e o vetor mais próximo de $\mathbf{x}$ em $\mathcal{C}(\mathbf{A})$ é

$$\hat{\mathbf{x}} = \mathbf{A}\hat{\mathbf{c}} = \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}).$$

Essa formulação estabelece a ligação entre projeção ortogonal e mínimos quadrados. As equações normais resultam da ortogonalidade entre o vetor residual e o espaço coluna da matriz.

3.6.7 Projeções e mínimos quadrados

Considere

$$\mathbf{A} \in \mathbb{R}^{n \times k}$$

e

$$\mathbf{b} \in \mathbb{R}^n.$$

O sistema

$$\mathbf{A}\beta = \mathbf{b}, \quad \beta \in \mathbb{R}^k,$$

possui solução exata se, e somente se,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Quando

$$\mathbf{b} \notin \mathcal{C}(\mathbf{A}),$$

não existe vetor β capaz de reproduzir exatamente $\mathbf{b}$. Nesse caso, procura-se a combinação linear das colunas de $\mathbf{A}$ que mais se aproxima de $\mathbf{b}$ no sentido da distância euclidiana.

O problema de mínimos quadrados é

$$\hat{\beta} \in \underset{\beta \in \mathbb{R}^k}{\operatorname{argmin}} \|\mathbf{b} - \mathbf{A}\beta\|^2.$$

Pelo Teorema 3.7, o vetor ajustado

$$\hat{\mathbf{b}} = \mathbf{A}\hat{\beta}$$

é a projeção ortogonal de $\mathbf{b}$ sobre o espaço coluna de $\mathbf{A}$:

$$\hat{\mathbf{b}} = \operatorname{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{b}).$$

O vetor de resíduos é

$$\hat{\mathbf{e}} = \mathbf{b} - \hat{\mathbf{b}} = \mathbf{b} - \mathbf{A}\hat{\beta}.$$

Como a projeção é ortogonal,

$$\hat{\mathbf{e}} \in \mathcal{C}(\mathbf{A})^\perp.$$

Pela relação entre os espaços fundamentais,

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top),$$

portanto

$$\hat{\mathbf{e}} \in \mathcal{N}(\mathbf{A}^\top).$$

Consequentemente,

$$\mathbf{A}^\top \hat{\mathbf{e}} = \mathbf{0}.$$

Substituindo

$$\hat{\mathbf{e}} = \mathbf{b} - \mathbf{A}\hat{\beta},$$

obtém-se

$$\mathbf{A}^\top (\mathbf{b} - \mathbf{A}\hat{\beta}) = \mathbf{0},$$

e, portanto,

$$\mathbf{A}^\top \mathbf{A}\hat{\beta} = \mathbf{A}^\top \mathbf{b}.$$

Definição 3.21 (Equações normais). As equações

$$\mathbf{A}^\top \mathbf{A}\hat{\beta} = \mathbf{A}^\top \mathbf{b}$$

são denominadas **equações normais** do problema de mínimos quadrados. Elas possuem pelo menos uma solução para quaisquer $\mathbf{A} \in \mathbb{R}^{n \times k}$ e $\mathbf{b} \in \mathbb{R}^n$. (Eaton, 2007; Gentle, 2017)

Se as colunas de $\mathbf{A}$ são linearmente independentes, então

$$\text{posto}(\mathbf{A}) = k$$

e a matriz de Gram

$$\mathbf{A}^\top \mathbf{A}$$

é positiva definida e invertível. Nesse caso, as equações normais possuem solução única:

$$\hat{\beta} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

O vetor ajustado pode então ser escrito como

$$\begin{aligned} \hat{\mathbf{b}} &= \mathbf{A}\hat{\beta} \\ &= \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b} \\ &= \mathbf{P}_\mathbf{A} \mathbf{b}, \end{aligned}$$

enquanto o vetor de resíduos é

$$\begin{aligned}\hat{\mathbf{e}} &= \mathbf{b} - \hat{\mathbf{b}} \\ &= (\mathbf{I}_n - \mathbf{P}_\mathbf{A}) \mathbf{b} \\ &= \mathbf{M}_\mathbf{A} \mathbf{b}.\end{aligned}$$

Aqui,

$$\mathbf{P}_\mathbf{A} = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \in \mathbb{R}^{n \times n}$$

projeta sobre $\mathcal{C}(\mathbf{A})$, enquanto

$$\mathbf{M}_\mathbf{A} = \mathbf{I}_n - \mathbf{P}_\mathbf{A} \in \mathbb{R}^{n \times n}$$

projeta sobre

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Proposição 3.18 (Decomposição de mínimos quadrados). *No problema de mínimos quadrados,*

$$\mathbf{b} = \hat{\mathbf{b}} + \hat{\mathbf{e}},$$

em que

$$\hat{\mathbf{b}} \in \mathcal{C}(\mathbf{A})$$

e

$$\hat{\mathbf{e}} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Consequentemente,

$$\hat{\mathbf{b}}^\top \hat{\mathbf{e}} = 0$$

e

$$\|\mathbf{b}\|^2 = \|\hat{\mathbf{b}}\|^2 + \|\hat{\mathbf{e}}\|^2.$$

(Gentle, 2017)

Essa decomposição é a aplicação direta da decomposição ortogonal

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top)$$

ao vetor $\mathbf{b}$.

Se as colunas de $\mathbf{A}$ são linearmente dependentes, o problema de mínimos quadrados pode possuir diferentes vetores de coeficientes que produzem o mesmo ajuste. Portanto, $\hat{\beta}$ pode não ser único.

Entretanto, o vetor ajustado

$$\hat{\mathbf{b}} = \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{b})$$

permanece único, pois a projeção depende apenas do subespaço $\mathcal{C}(\mathbf{A})$. (Gentle, 2017; Searle; Khuri, 2017)

Utilizando a pseudoinversa de Moore–Penrose (ver Definição 2.23),

$$\hat{\beta} = \mathbf{A}^+ \mathbf{b}$$

fornece, entre as soluções de mínimos quadrados, a solução de menor norma. O vetor ajustado pode ser escrito como

$$\hat{\mathbf{b}} = \mathbf{A} \mathbf{A}^+ \mathbf{b},$$

de modo que

$$\mathbf{P}_{\mathbf{A}} = \mathbf{A} \mathbf{A}^+.$$

A definição algébrica da pseudoinversa de Moore–Penrose está em Definição 2.23, e sua representação pela Decomposição em Valores Singulares em Definição 6.10.

3.7 Aprofundamento teórico

3.7.1 Extensão de uma base

Uma base de um subespaço pode ser completada acrescentando vetores até formar uma base de todo o espaço.

Teorema 3.8 (Extensão de uma base). *Seja W um subespaço de um espaço vetorial V de dimensão finita. Se*

$$\mathcal{B}_W = \{\mathbf{u}_1, \dots, \mathbf{u}_s\}$$

é uma base de W , então existem vetores $\mathbf{z}_1, \dots, \mathbf{z}_r \in V$ tais que

$$\{\mathbf{u}_1, \dots, \mathbf{u}_s, \mathbf{z}_1, \dots, \mathbf{z}_r\}$$

é uma base de V . (Eaton, 2007)

i Demonstração

Se $\mathcal{B}_W$ já gera V , então $\mathcal{B}_W$ é uma base de V e nada precisa ser acrescentado. Caso contrário, existe um vetor $\mathbf{z}_1 \in V$ que não pertence ao subespaço gerado por $\mathcal{B}_W$. Assim,

$$\{\mathbf{u}_1, \dots, \mathbf{u}_s, \mathbf{z}_1\}$$

é linearmente independente.

Se esse conjunto ainda não gera V , escolhe-se um vetor $\mathbf{z}_2 \in V$ que não pertence ao subespaço gerado pelos vetores já selecionados. O novo conjunto continua linearmente independente.

Repetindo esse procedimento, acrescentam-se vetores enquanto o conjunto obtido não gerar V . Como V possui dimensão finita, não é possível acrescentar indefinidamente vetores linearmente independentes. Portanto, após um número finito de etapas, obtém-se um conjunto

$$\{\mathbf{u}_1, \dots, \mathbf{u}_s, \mathbf{z}_1, \dots, \mathbf{z}_r\}$$

que é linearmente independente e gera V . Logo, esse conjunto é uma base de V .

3.7.2 Matrizes semidefinidas positivas

Se $\mathbf{M}$ é apenas semidefinida positiva, a expressão

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\mathbf{x}^{\top} \mathbf{M} \mathbf{x}}$$

pode ser igual a zero para algum vetor $\mathbf{x} \neq \mathbf{0}$.

Nesse caso, a expressão define uma **seminorma**, e não uma norma. Analogamente,

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_{\mathbf{M}}$$

pode ser igual a zero mesmo quando $\mathbf{x} \neq \mathbf{y}$. Portanto, essa expressão define, em geral, uma **pseudodistância**.

3.7.3 Projeções e mínimos quadrados ponderados

As projeções ponderadas são definidas em relação a um produto interno induzido por uma matriz positiva definida. Nessa geometria, ortogonalidade e distância são determinadas pela matriz que define o produto interno, conduzindo à formulação ponderada dos mínimos quadrados. (Eaton, 2007; Gentle, 2017)

3.8 Síntese do capítulo

Os espaços vetoriais permitem organizar conjuntos de vetores que preservam as operações de adição e multiplicação por escalar. Dentro desses espaços, os subespaços representam estruturas lineares de menor dimensão, enquanto bases fornecem conjuntos de vetores linearmente independentes capazes de gerar todo o espaço considerado. Fixada uma base, cada vetor pode ser representado de maneira única por suas coordenadas nessa base.

A dimensão quantifica o número de direções independentes necessárias para representar um espaço. Para uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

essa ideia conduz aos quatro espaços fundamentais:

$$\mathcal{C}(\mathbf{A}), \mathcal{L}(\mathbf{A}), \mathcal{N}(\mathbf{A}) \text{ e } \mathcal{N}(\mathbf{A}^{\top}).$$

Se $r = \text{posto}(\mathbf{A})$, suas dimensões são

$$\dim \mathcal{C}(\mathbf{A}) = \dim \mathcal{L}(\mathbf{A}) = r,$$

$$\dim \mathcal{N}(\mathbf{A}) = p - r$$

e

$$\dim \mathcal{N}(\mathbf{A}^\top) = n - r.$$

Esses espaços se organizam em pares ortogonais:

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Consequentemente,

$$\mathbb{R}^p = \mathcal{L}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A})$$

e

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top).$$

Se $\mathbf{M}$ é simétrica positiva definida, o produto

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{y}$$

define uma geometria em que normas, distâncias e ortogonalidade dependem de $\mathbf{M}$. A norma associada é

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\mathbf{x}^\top \mathbf{M} \mathbf{x}},$$

A geometria induzida por $\mathbf{M}$ fornece a base para geometrias ponderadas utilizadas em métodos multivariados.

As matrizes de Gram organizam produtos internos entre conjuntos de vetores. Para uma matriz $\mathbf{V}$,

$$\mathbf{G} = \mathbf{V}^\top \mathbf{V}$$

é simétrica e semidefinida positiva, e sua estrutura permite relacionar produtos internos, independência linear e posto.

A decomposição ortogonal estabelece que, para qualquer subespaço $S \subseteq \mathbb{R}^p$, todo vetor pode ser escrito de maneira única como

$$\mathbf{x} = \text{proj}_S(\mathbf{x}) + \mathbf{x}_{S^\perp},$$

com $\text{proj}_S(\mathbf{x}) \in S$ e $\mathbf{x}_{S^\perp} \in S^\perp$.

Se as colunas de $\mathbf{Q}$ formam uma base ortonormal de S , a matriz de projeção é

$$\mathbf{P}_S = \mathbf{Q}\mathbf{Q}^\top = \sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top.$$

Se $S = \mathcal{C}(\mathbf{A})$ e as colunas de $\mathbf{A}$ são linearmente independentes, a mesma projeção pode ser escrita como

$$\mathbf{P}_A = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

A projeção ortogonal possui ainda uma interpretação por otimização:

$$\text{proj}_S(\mathbf{x}) = \underset{\mathbf{y} \in S}{\text{argmin}} \|\mathbf{x} - \mathbf{y}\|^2.$$

Para $\mathbf{A} \in \mathbb{R}^{n \times k}$, a matriz de projeção residual

$$\mathbf{M}_A = \mathbf{I}_n - \mathbf{P}_A$$

projeta sobre $\mathcal{C}(\mathbf{A})^\perp$. No problema de mínimos quadrados, a ortogonalidade do resíduo em relação a $\mathcal{C}(\mathbf{A})$ conduz às equações normais

$$\mathbf{A}^\top \mathbf{A} \hat{\boldsymbol{\beta}} = \mathbf{A}^\top \mathbf{b}.$$

Quando as colunas de $\mathbf{A}$ são linearmente dependentes, os coeficientes de mínimos quadrados podem não ser únicos, mas o vetor ajustado permanece único. Com a pseudoinversa de Moore–Penrose,

$$\mathbf{P}_A = \mathbf{A}\mathbf{A}^+.$$

Ao final deste capítulo, o estudante deverá ser capaz de:

- verificar se um conjunto é um subespaço vetorial;
- interpretar geração, dependência e independência linear;
- identificar bases e determinar dimensões;
- representar vetores por coordenadas em uma base;
- distinguir bases gerais, ortogonais e ortonormais;
- determinar e interpretar os quatro espaços fundamentais de uma matriz;
- relacionar posto, nulidade e dimensão;
- interpretar as relações de ortogonalidade entre os espaços fundamentais;
- construir e interpretar matrizes de Gram;
- interpretar produtos internos, normas e distâncias induzidos por matrizes positivas definidas;
- determinar complementos ortogonais e decomposições ortogonais;
- calcular projeções sobre direções e subespaços;
- interpretar matrizes de projeção e de projeção residual;
- interpretar a projeção ortogonal como problema de melhor aproximação;
- obter as equações normais de um problema de mínimos quadrados;
- distinguir a unicidade do vetor ajustado da possível não unicidade dos coeficientes em problemas de posto deficiente.

Em Capítulo 4, matrizes representam transformações lineares entre espaços vetoriais. Bases, dimensão, posto, espaços fundamentais e projeções permitem interpretar a ação dessas transformações sobre vetores e subespaços. Nesse contexto, o espaço nulo e o espaço coluna correspondem, respectivamente, ao núcleo e à imagem da transformação linear associada à matriz.

4 Transformações lineares

Vetores, matrizes, espaços vetoriais, bases e projeções fornecem a linguagem algébrica e geométrica para representar observações multivariadas e relações lineares entre suas coordenadas.

Uma matriz $\mathbf{A}$ também define uma aplicação $\mathbf{x} \mapsto \mathbf{Ax}$. Dependendo de $\mathbf{A}$, a aplicação pode alterar orientação, escala ou dimensão. Quando preserva combinações lineares, constitui uma **transformação linear**.

Para $T_{\mathbf{A}}(\mathbf{x}) = \mathbf{Ax}$, o espaço nulo de $\mathbf{A}$ é o núcleo da transformação e o espaço coluna de $\mathbf{A}$ é sua imagem. Transformações lineares e afins também descrevem operações sobre matrizes de dados, composição, invertibilidade, perda de dimensão, mudanças de coordenadas, centralização, escalonamento e padronização.

Convenções para transformações lineares

Além das convenções vetoriais e matriciais já adotadas, usam-se:

- $T : V \rightarrow W$ representa uma transformação entre os espaços vetoriais V e W ;
- V representa o domínio e W o contradomínio da transformação;
- $\mathbf{x} \in V$ representa um vetor do domínio e $T(\mathbf{x}) \in W$ sua imagem pela transformação;
- $T_{\mathbf{A}}$ representa a transformação linear associada à matriz $\mathbf{A}$;
- $\mathbf{A} \in \mathbb{R}^{q \times p}$ representa uma transformação de $\mathbb{R}^p$ em $\mathbb{R}^q$ quando utilizada na forma $T_{\mathbf{A}}(\mathbf{x}) = \mathbf{Ax}$;
- $\ker(T)$ representa o núcleo de uma transformação linear;
- $\text{Im}(T)$ representa a imagem de uma transformação linear;
- $\mathcal{E}_p$ representa a base canônica de $\mathbb{R}^p$;
- $[T]_{\mathcal{C} \leftarrow \mathcal{B}}$ representa a matriz de uma transformação em relação a uma base $\mathcal{B}$ do domínio e a uma base $\mathcal{C}$ do contradomínio.

4.1 Transformações lineares e representação matricial

Uma aplicação entre espaços vetoriais associa a cada vetor do domínio um vetor do contradomínio. A linearidade exige que essa aplicação preserve as operações de adição e multiplicação por escalar.

Definição 4.1 (Transformação linear). Sejam V e W espaços vetoriais reais. Uma aplicação

$$T : V \longrightarrow W$$

é uma **transformação linear** quando, para quaisquer vetores $\mathbf{u}, \mathbf{v} \in V$ e escalares $\alpha, \beta \in \mathbb{R}$,

$$T(\alpha\mathbf{u} + \beta\mathbf{v}) = \alpha T(\mathbf{u}) + \beta T(\mathbf{v}).$$

(Eaton, 2007)

Tomando $\alpha = \beta = 1$, obtém-se a preservação da soma:

$$T(\mathbf{u} + \mathbf{v}) = T(\mathbf{u}) + T(\mathbf{v}).$$

Tomando $\beta = 0$, obtém-se a preservação da multiplicação por escalar:

$$T(\alpha\mathbf{u}) = \alpha T(\mathbf{u}).$$

Assim, a imagem de uma combinação linear é a combinação linear das imagens:

$$T\left(\sum_{j=1}^k \alpha_j \mathbf{v}_j\right) = \sum_{j=1}^k \alpha_j T(\mathbf{v}_j).$$

A Figura 4.1 representa a preservação da soma. O paralelogramo formado pelos vetores originais é transformado em outro paralelogramo cujos lados são as imagens desses vetores.

No primeiro painel, $\mathbf{u} + \mathbf{v}$ é a diagonal do paralelogramo formado pelos vetores originais. No segundo painel, a relação

$$T(\mathbf{u} + \mathbf{v}) = T(\mathbf{u}) + T(\mathbf{v})$$

é preservada.

Proposição 4.1 (Propriedades elementares das transformações lineares). *Se*

$$T : V \longrightarrow W$$

é uma transformação linear, então:

1. $T(\mathbf{0}) = \mathbf{0}$;




Figura 4.1: Preservação da soma de vetores por uma transformação linear.

2. $T(-\mathbf{x}) = -T(\mathbf{x})$;
3. $T(\mathbf{u} - \mathbf{v}) = T(\mathbf{u}) - T(\mathbf{v})$.

(Meyer, 2023)

Demonstração

Pela homogeneidade,

$$T(\mathbf{0}) = T(0\mathbf{x}) = 0T(\mathbf{x}) = \mathbf{0}.$$

Também pela homogeneidade,

$$T(-\mathbf{x}) = T((-1)\mathbf{x}) = -T(\mathbf{x}).$$

Consequentemente,

$$\begin{aligned} T(\mathbf{u} - \mathbf{v}) &= T(\mathbf{u} + (-\mathbf{v})) \\ &= T(\mathbf{u}) + T(-\mathbf{v}) \\ &= T(\mathbf{u}) - T(\mathbf{v}). \end{aligned}$$

A igualdade $T(\mathbf{0}) = \mathbf{0}$ é uma condição necessária para a linearidade. Se uma aplicação não envia o vetor nulo ao vetor nulo, ela não é uma transformação linear.

4.1.1 Transformação determinada por uma base

Uma transformação linear é determinada por sua ação sobre os vetores de uma base do domínio.

Proposição 4.2 (Determinação de uma transformação por uma base). *Seja V um espaço vetorial de dimensão finita e seja*

$$\mathcal{B} = \{\mathbf{v}_1, \dots, \mathbf{v}_k\}$$

uma base de V . Uma transformação linear

$$T : V \longrightarrow W$$

fica completamente determinada pelos vetores

$$T(\mathbf{v}_1), \dots, T(\mathbf{v}_k).$$

(Meyer, 2023)

Demonstração

Todo vetor $\mathbf{x} \in V$ possui uma representação única na base $\mathcal{B}$:

$$\mathbf{x} = c_1 \mathbf{v}_1 + \dots + c_k \mathbf{v}_k.$$

Pela linearidade,

$$T(\mathbf{x}) = c_1 T(\mathbf{v}_1) + \dots + c_k T(\mathbf{v}_k).$$

Portanto, conhecidas as imagens dos vetores da base, a imagem de qualquer vetor do domínio fica determinada de maneira única.

Exemplo 4.1 (Transformação determinada pelas imagens de uma base). Considere uma transformação

$$T : \mathbb{R}^2 \longrightarrow \mathbb{R}^2$$

definida sobre os vetores da base canônica por

$$T(\mathbf{e}_1) = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

e

$$T(\mathbf{e}_2) = \begin{bmatrix} -1 \\ 3 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = x_1 \mathbf{e}_1 + x_2 \mathbf{e}_2,$$

tem-se

$$\begin{aligned} T(\mathbf{x}) &= x_1 T(\mathbf{e}_1) + x_2 T(\mathbf{e}_2) \\ &= x_1 \begin{bmatrix} 2 \\ 1 \end{bmatrix} + x_2 \begin{bmatrix} -1 \\ 3 \end{bmatrix} \\ &= \begin{bmatrix} 2x_1 - x_2 \\ x_1 + 3x_2 \end{bmatrix}. \end{aligned}$$

Essa expressão pode ser escrita como

$$T(\mathbf{x}) = \begin{bmatrix} 2 & -1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

Portanto, a matriz que representa T na base canônica é

$$\mathbf{A} = \begin{bmatrix} 2 & -1 \\ 1 & 3 \end{bmatrix},$$

cujas colunas são precisamente

$$T(\mathbf{e}_1) \quad \text{e} \quad T(\mathbf{e}_2).$$

4.1.2 Representação matricial nas bases canônicas

Considere uma transformação linear

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Se

$$\mathcal{E}_p = \{\mathbf{e}_1, \dots, \mathbf{e}_p\}$$

é a base canônica de $\mathbb{R}^p$, defina

$$\mathbf{a}_j = T(\mathbf{e}_j), \quad j = 1, \dots, p.$$

Organizando esses vetores nas colunas de uma matriz, obtém-se

$$\mathbf{A} = [\mathbf{a}_1 \quad \dots \quad \mathbf{a}_p] \in \mathbb{R}^{q \times p}.$$

Para

$$\mathbf{x} = x_1 \mathbf{e}_1 + \dots + x_p \mathbf{e}_p,$$

a linearidade fornece

$$\begin{aligned} T(\mathbf{x}) &= x_1 T(\mathbf{e}_1) + \dots + x_p T(\mathbf{e}_p) \\ &= x_1 \mathbf{a}_1 + \dots + x_p \mathbf{a}_p \\ &= \mathbf{A}\mathbf{x}. \end{aligned}$$

Logo, existe uma matriz que representa T nas bases canônicas.

Para verificar a unicidade, suponha que outra matriz

$$\mathbf{C} \in \mathbb{R}^{q \times p}$$

também satisfaça

$$T(\mathbf{x}) = \mathbf{C}\mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^p$. Aplicando essa igualdade aos vetores da base canônica,

$$\mathbf{C}\mathbf{e}_j = T(\mathbf{e}_j) = \mathbf{A}\mathbf{e}_j, \quad j = 1, \dots, p.$$

Como $\mathbf{A}\mathbf{e}_j$ e $\mathbf{C}\mathbf{e}_j$ correspondem, respectivamente, às j -ésimas colunas de $\mathbf{A}$ e $\mathbf{C}$, todas as colunas das duas matrizes são iguais. Portanto,

$$\mathbf{C} = \mathbf{A}.$$

A matriz representante de T nas bases canônicas é, assim, única.

Proposição 4.3 (Representação matricial de uma transformação linear). *Toda transformação linear*

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

pode ser representada de maneira única por uma matriz

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

tal que

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^p$.

A j -ésima coluna de $\mathbf{A}$ é a imagem do j -ésimo vetor da base canônica:

$$\mathbf{a}_j = T(\mathbf{e}_j).$$

(Meyer, 2023)

Reciprocamente, toda matriz

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

define uma transformação linear

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

por

$$T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

De fato,

$$\begin{aligned} T_{\mathbf{A}}(\alpha\mathbf{u} + \beta\mathbf{v}) &= \mathbf{A}(\alpha\mathbf{u} + \beta\mathbf{v}) \\ &= \alpha\mathbf{A}\mathbf{u} + \beta\mathbf{A}\mathbf{v} \\ &= \alpha T_{\mathbf{A}}(\mathbf{u}) + \beta T_{\mathbf{A}}(\mathbf{v}). \end{aligned}$$

A matriz $\mathbf{A}$ nessa representação é relativa às bases canônicas do domínio e do contradomínio.

4.1.3 Núcleo e imagem de uma transformação linear

Dois subespaços descrevem aspectos fundamentais da ação de uma transformação linear: os vetores do domínio que são enviados ao vetor nulo e os vetores do contradomínio que podem ser obtidos pela transformação.

Definição 4.2 (Núcleo e imagem de uma transformação linear). Seja

$$T : V \longrightarrow W$$

uma transformação linear.

O **núcleo** de T é o conjunto

$$\ker(T) = \{\mathbf{x} \in V : T(\mathbf{x}) = \mathbf{0}\}.$$

A **imagem** de T é o conjunto

$$\text{Im}(T) = \{T(\mathbf{x}) : \mathbf{x} \in V\}.$$

O núcleo é um subespaço do domínio V , enquanto a imagem é um subespaço do contradomínio W .

(Searle; Khuri, 2017)

Para a transformação matricial

$$T_{\mathbf{A}}(\mathbf{x}) = \mathbf{Ax},$$

o núcleo é

$$\begin{aligned}\ker(T_{\mathbf{A}}) &= \{\mathbf{x} \in \mathbb{R}^p : \mathbf{Ax} = \mathbf{0}\} \\ &= \mathcal{N}(\mathbf{A}),\end{aligned}$$

e a imagem é

$$\begin{aligned}\text{Im}(T_{\mathbf{A}}) &= \{\mathbf{Ax} : \mathbf{x} \in \mathbb{R}^p\} \\ &= \mathcal{C}(\mathbf{A}).\end{aligned}$$

Relação com os subespaços associados a uma matriz

Para $T_{\mathbf{A}}(\mathbf{x}) = \mathbf{Ax}$, o **espaço nulo** e o **espaço coluna** de $\mathbf{A}$ correspondem, respectivamente, ao **núcleo** e à **imagem** da transformação:

$$\mathcal{N}(\mathbf{A}) = \ker(T_{\mathbf{A}}), \quad \mathcal{C}(\mathbf{A}) = \text{Im}(T_{\mathbf{A}}).$$

Se

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

o **contradomínio** é $\mathbb{R}^q$, enquanto a imagem é o subespaço efetivamente alcançado pela transformação,

$$\text{Im}(T_{\mathbf{A}}) \subseteq \mathbb{R}^q.$$

4.1.4 Imagem de um subespaço

Considere um subespaço

$$S = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\} \subseteq V.$$

Todo vetor $\mathbf{x} \in S$ possui a forma

$$\mathbf{x} = \alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k.$$

Aplicando T ,

$$T(\mathbf{x}) = \alpha_1 T(\mathbf{v}_1) + \cdots + \alpha_k T(\mathbf{v}_k).$$

Portanto,

$$T(S) = \text{span}\{T(\mathbf{v}_1), \dots, T(\mathbf{v}_k)\}.$$

A imagem de um subespaço por uma transformação linear também é um subespaço do contradomínio.

A transformação preserva as combinações lineares, mas pode reduzir a dimensão do espaço gerado. Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}.$$

Os vetores canônicos $\mathbf{e}_1$ e $\mathbf{e}_2$ são linearmente independentes, mas

$$\mathbf{A}\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{A}\mathbf{e}_2 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

A segunda direção é eliminada, a imagem da transformação possui dimensão 1 e $\mathbf{e}_2$ pertence ao núcleo de $T_{\mathbf{A}}$.

4.2 Transformação de vetores e matrizes de dados

A representação

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x}$$

considera cada observação como um vetor-coluna. Em uma matriz de dados, as observações são organizadas nas linhas. A aplicação simultânea da transformação exige, portanto, a transposição da matriz que atua sobre cada vetor.

Considere

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p},$$

em que

$$\mathbf{x}_i \in \mathbb{R}^p, \quad i = 1, \dots, n,$$

representa a i -ésima observação.

Se

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é representada por

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

a imagem de cada observação é

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i \in \mathbb{R}^q.$$

Transpondo essa igualdade,

$$\mathbf{y}_i^\top = \mathbf{x}_i^\top \mathbf{A}^\top.$$

Proposição 4.4 (Transformação de uma matriz de dados). *Se as observações estão organizadas nas linhas de*

$$\mathbf{X} \in \mathbb{R}^{n \times p}$$

e cada observação é transformada por

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i, \quad \mathbf{A} \in \mathbb{R}^{q \times p},$$

então a matriz transformada é

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top \in \mathbb{R}^{n \times q}.$$

Demonstração

A i -ésima linha de $\mathbf{Y}$ é

$$\mathbf{x}_i^\top \mathbf{A}^\top.$$

Como

$$\mathbf{x}_i^\top \mathbf{A}^\top = (\mathbf{A} \mathbf{x}_i)^\top = \mathbf{y}_i^\top,$$

tem-se

$$\mathbf{Y} = \begin{bmatrix} \mathbf{y}_1^\top \\ \mathbf{y}_2^\top \\ \vdots \\ \mathbf{y}_n^\top \end{bmatrix} = \mathbf{X} \mathbf{A}^\top.$$

As dimensões da multiplicação são

$$\underbrace{\mathbf{X}}_{n \times p} \underbrace{\mathbf{A}^\top}_{p \times q} = \underbrace{\mathbf{Y}}_{n \times q}.$$

A transposição não altera a transformação definida sobre vetores-coluna. Ela adapta a multiplicação à organização das observações nas linhas da matriz de dados.

4.2.1 Novas variáveis como combinações lineares

Seja

$$\mathbf{w}_j \in \mathbb{R}^p$$

o vetor de coeficientes associado à j -ésima coordenada transformada. As linhas de $\mathbf{A}$ podem ser representadas por

$$\mathbf{A} = \begin{bmatrix} \mathbf{w}_1^\top \\ \mathbf{w}_2^\top \\ \vdots \\ \mathbf{w}_q^\top \end{bmatrix},$$

de modo que

$$\mathbf{A}^\top = [\mathbf{w}_1 \quad \mathbf{w}_2 \quad \cdots \quad \mathbf{w}_q].$$

Consequentemente,

$$\mathbf{Y} = [\mathbf{X}\mathbf{w}_1 \quad \mathbf{X}\mathbf{w}_2 \quad \cdots \quad \mathbf{X}\mathbf{w}_q].$$

A j -ésima coluna da matriz transformada é

$$\mathbf{y}_{\cdot j} = \mathbf{X}\mathbf{w}_j.$$

Cada nova variável é, portanto, uma combinação linear das variáveis originais. Para a i -ésima observação,

$$y_{ij} = a_{j1}x_{i1} + a_{j2}x_{i2} + \cdots + a_{jp}x_{ip}.$$

A identidade $\mathbf{Y} = \mathbf{X}\mathbf{A}^\top$ admite duas leituras:

- cada linha de $\mathbf{Y}$ é a imagem de uma observação;
- cada coluna de $\mathbf{Y}$ é uma nova variável construída por combinação linear.

Exemplo 4.2 (Transformação de um conjunto de observações). Considere

$$\mathbf{X} = \begin{bmatrix} 1 & 2 \\ 3 & 1 \\ 2 & 4 \end{bmatrix}$$

e

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 2 & -1 \end{bmatrix}.$$

Para uma observação genérica,

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \end{bmatrix},$$

tem-se

$$\begin{aligned} \mathbf{y}_i &= \mathbf{A}\mathbf{x}_i \\ &= \begin{bmatrix} 1 & 1 \\ 2 & -1 \end{bmatrix} \begin{bmatrix} x_{i1} \\ x_{i2} \end{bmatrix} \\ &= \begin{bmatrix} x_{i1} + x_{i2} \\ 2x_{i1} - x_{i2} \end{bmatrix}. \end{aligned}$$

Como as observações estão nas linhas de $\mathbf{X}$,

$$\begin{aligned}\mathbf{Y} &= \mathbf{XA}^\top \\ &= \begin{bmatrix} 1 & 2 \\ 3 & 1 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 1 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 3 & 0 \\ 4 & 5 \\ 6 & 0 \end{bmatrix}.\end{aligned}$$

A primeira variável transformada é a soma das duas variáveis originais:

$$\mathbf{y}_{.1} = \mathbf{x}_{.1} + \mathbf{x}_{.2}.$$

A segunda é

$$\mathbf{y}_{.2} = 2\mathbf{x}_{.1} - \mathbf{x}_{.2}.$$

4.2.2 Dimensão da configuração transformada

Quando

$$q = p,$$

a transformação atua entre espaços de mesma dimensão:

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^p.$$

O domínio e o contradomínio possuem a mesma dimensão. A dimensão efetiva da imagem, entretanto, pode ser menor que p quando $\mathbf{A}$ não possui posto completo.

Quando

$$q < p,$$

a transformação produz vetores com menos coordenadas:

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Quando

$$q > p,$$

os vetores passam a ser representados em um espaço com mais coordenadas. Esse aumento do contradomínio não implica aumento da dimensão efetiva da imagem.

Se

$$\text{posto}(\mathbf{A}) = r,$$

então

$$\mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q$$

possui dimensão r . Como

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i,$$

todas as observações transformadas pertencem a esse espaço:

$$\mathbf{y}_i \in \mathcal{C}(\mathbf{A}).$$

Portanto, todas as observações transformadas pertencem a um subespaço de dimensão

$$r = \text{posto}(\mathbf{A}).$$

Assim, a dimensão da configuração transformada não pode exceder $\text{posto}(\mathbf{A})$, embora possa ser menor, dependendo da configuração original dos dados.

Se

$$r = q,$$

a imagem coincide com todo o contradomínio.

Se

$$r < q,$$

a imagem ocupa apenas um subespaço próprio de $\mathbb{R}^q$.

Quando $r < p$, a transformação possui núcleo não trivial e elimina pelo menos uma direção do domínio. Existe, nesse caso, um vetor não nulo

$$\mathbf{v} \in \ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A})$$

tal que

$$\mathbf{A}\mathbf{v} = \mathbf{0}.$$

Para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\begin{aligned}\mathbf{A}(\mathbf{x} + \mathbf{v}) &= \mathbf{A}\mathbf{x} + \mathbf{A}\mathbf{v} \\ &= \mathbf{A}\mathbf{x}.\end{aligned}$$

Vetores distintos podem, portanto, produzir a mesma imagem quando diferem por um elemento do espaço nulo.

A Figura 4.2 compara os efeitos de diferentes matrizes sobre uma mesma configuração de pontos.

A rotação gira a configuração em relação aos eixos coordenados sem alterar sua forma. A reflexão também preserva a forma, mas inverte sua orientação. O escalonamento modifica os comprimentos em cada direção, enquanto o cisalhamento altera uma coordenada de acordo com a outra. A projeção elimina a segunda coordenada e reduz a configuração a uma reta.

As cinco operações preservam combinações lineares. Entretanto, não preservam necessariamente comprimentos, ângulos, áreas ou dimensão.

4.2.3 Efeito sobre diferenças e produtos internos

Se duas observações são representadas por $\mathbf{x}_i$ e $\mathbf{x}_j$, então

$$\begin{aligned}\mathbf{y}_i - \mathbf{y}_j &= \mathbf{A}\mathbf{x}_i - \mathbf{A}\mathbf{x}_j \\ &= \mathbf{A}(\mathbf{x}_i - \mathbf{x}_j).\end{aligned}$$

A transformação das diferenças determina o efeito sobre as distâncias. O quadrado da distância entre as imagens é




Figura 4.2: Efeito de diferentes transformações lineares sobre uma mesma configuração de pontos.

$$\begin{aligned}\|\mathbf{y}_i - \mathbf{y}_j\|^2 &= [\mathbf{A}(\mathbf{x}_i - \mathbf{x}_j)]^\top [\mathbf{A}(\mathbf{x}_i - \mathbf{x}_j)] \\ &= (\mathbf{x}_i - \mathbf{x}_j)^\top \mathbf{A}^\top \mathbf{A} (\mathbf{x}_i - \mathbf{x}_j).\end{aligned}$$

A matriz

$$\mathbf{A}^\top \mathbf{A}$$

descreve, no domínio, como a transformação modifica produtos internos, comprimentos e distâncias. Quando $\mathbf{A}$ possui posto completo nas colunas, $\mathbf{A}^\top \mathbf{A}$ é positiva definida e determina um produto interno no domínio. Quando $\mathbf{A}$ não possui posto completo nas colunas, essa matriz é apenas semidefinida positiva e algumas direções são eliminadas pela transformação.

Para quaisquer vetores $\mathbf{x}, \mathbf{z} \in \mathbb{R}^p$,

$$\begin{aligned}T(\mathbf{x})^\top T(\mathbf{z}) &= (\mathbf{A}\mathbf{x})^\top (\mathbf{A}\mathbf{z}) \\ &= \mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{z}.\end{aligned}$$

Em particular,

$$\|\mathbf{A}\mathbf{x}\|^2 = \mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x}.$$

Como

$$\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} = \|\mathbf{A}\mathbf{x}\|^2 \geq 0,$$

a matriz $\mathbf{A}^\top \mathbf{A}$ é simétrica e semidefinida positiva.

Se $\mathbf{A}$ possui posto completo nas colunas, então

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$$

e

$$\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$. Nesse caso,

$$\mathbf{A}^\top \mathbf{A} \succ 0,$$

e a expressão

$$\|\mathbf{x}\|_{\mathbf{A}^\top \mathbf{A}} = \sqrt{\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x}} = \|\mathbf{A} \mathbf{x}\|$$

define uma norma em $\mathbb{R}^p$.

Quando $\mathbf{A}$ não possui posto completo nas colunas, existem vetores não nulos em

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A})$$

para os quais

$$\|\mathbf{x}\|_{\mathbf{A}^\top \mathbf{A}} = 0.$$

Nesse caso, $\|\cdot\|_{\mathbf{A}^\top \mathbf{A}}$ define uma seminorma.

4.2.4 Transformação das matrizes de produtos internos

A matriz de Gram entre as observações originais é

$$\mathbf{G}_{\mathbf{X}} = \mathbf{X} \mathbf{X}^\top.$$

Para

$$\mathbf{Y} = \mathbf{X} \mathbf{A}^\top,$$

tem-se

$$\begin{aligned} \mathbf{G}_{\mathbf{Y}} &= \mathbf{Y} \mathbf{Y}^\top \\ &= \mathbf{X} \mathbf{A}^\top \mathbf{A} \mathbf{X}^\top. \end{aligned}$$

Portanto,

$$\mathbf{G}_{\mathbf{Y}} = \mathbf{X} \mathbf{A}^\top \mathbf{A} \mathbf{X}^\top.$$

Se

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_p,$$

então

$$\mathbf{G}_Y = \mathbf{X}\mathbf{X}^\top = \mathbf{G}_X.$$

Nesse caso, todos os produtos internos entre as observações são preservados.

A matriz de produtos cruzados entre as variáveis transformadas é

$$\begin{aligned}\mathbf{Y}^\top \mathbf{Y} &= (\mathbf{X}\mathbf{A}^\top)^\top (\mathbf{X}\mathbf{A}^\top) \\ &= \mathbf{A}\mathbf{X}^\top \mathbf{X}\mathbf{A}^\top.\end{aligned}$$

Logo,

$$\mathbf{Y}^\top \mathbf{Y} = \mathbf{A}\mathbf{X}^\top \mathbf{X}\mathbf{A}^\top.$$

Essa expressão descreve como os produtos cruzados entre as novas variáveis são obtidos a partir dos produtos cruzados entre as variáveis originais.

Quando $\mathbf{X}$ está centralizada, $\mathbf{X}^\top \mathbf{X}$ reúne os produtos cruzados utilizados na matriz de covariâncias amostrais. A transformação $\mathbf{Y} = \mathbf{X}\mathbf{A}^\top$ modifica esses produtos segundo

$$\mathbf{Y}^\top \mathbf{Y} = \mathbf{A}\mathbf{X}^\top \mathbf{X}\mathbf{A}^\top,$$

enquanto os produtos internos entre as observações transformadas são descritos por

$$\mathbf{Y}\mathbf{Y}^\top = \mathbf{X}\mathbf{A}^\top \mathbf{A}\mathbf{X}^\top.$$

4.3 Composição, invertibilidade e perda de informação

Transformações lineares podem ser aplicadas sucessivamente. A matriz da transformação resultante é obtida pelo produto das matrizes que representam cada etapa.

4.3.1 Composição de transformações lineares

Considere

$$T_1 : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

e

$$T_2 : \mathbb{R}^q \longrightarrow \mathbb{R}^r,$$

representadas, respectivamente, por

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{B} \in \mathbb{R}^{r \times q}.$$

Para $\mathbf{x} \in \mathbb{R}^p$,

$$T_1(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

Aplicando T_2 à imagem produzida por T_1 ,

$$\begin{aligned} T_2(T_1(\mathbf{x})) &= \mathbf{B}(\mathbf{A}\mathbf{x}) \\ &= (\mathbf{B}\mathbf{A})\mathbf{x}. \end{aligned}$$

Proposição 4.5 (Matriz de uma composição). *Se T_1 é representada por $\mathbf{A}$ e T_2 é representada por $\mathbf{B}$, então a composição*

$$T_2 \circ T_1$$

é representada por

$$\mathbf{B}\mathbf{A}.$$

Em particular,

$$[T_2 \circ T_1] = [T_2][T_1].$$

A ordem do produto é interpretada da direita para a esquerda:

1. $\mathbf{A}$ atua primeiro;
2. $\mathbf{B}$ atua depois.

As dimensões refletem essa sequência:

$$\underbrace{\mathbf{B}}_{r \times q} \underbrace{\mathbf{A}}_{q \times p} \underbrace{\mathbf{x}}_{p \times 1} \in \mathbb{R}^r.$$

Se as observações estão nas linhas de

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a primeira transformação produz

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top.$$

A segunda produz

$$\begin{aligned} \mathbf{Z} &= \mathbf{Y}\mathbf{B}^\top \\ &= \mathbf{X}\mathbf{A}^\top\mathbf{B}^\top \\ &= \mathbf{X}(\mathbf{BA})^\top. \end{aligned}$$

Portanto, a composição aplicada à matriz de dados é

$$\mathbf{Z} = \mathbf{X}(\mathbf{BA})^\top.$$

4.3.2 A ordem das transformações

Como a multiplicação matricial não é comutativa, a composição depende da ordem em que as transformações são aplicadas. Para duas transformações que atuam sobre o mesmo espaço,

$$T_1 : \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

e

$$T_2 : \mathbb{R}^p \longrightarrow \mathbb{R}^p,$$

representadas, respectivamente, por

$$\mathbf{A}, \mathbf{B} \in \mathbb{R}^{p \times p},$$

as duas composições

$$T_2 \circ T_1$$

e

$$T_1 \circ T_2$$

estão definidas. Suas matrizes representantes são, respectivamente,

$$\mathbf{BA}$$

e

$$\mathbf{AB}.$$

Como a multiplicação de matrizes não é, em geral, comutativa,

$$\mathbf{BA} \neq \mathbf{AB}.$$

Consequentemente, em geral,

$$T_2 \circ T_1 \neq T_1 \circ T_2.$$

A igualdade pode ocorrer para transformações particulares, mas não constitui uma propriedade geral da composição.

Exemplo 4.3 (Composição de rotação e escalonamento). Considere uma rotação de 45° ,

$$\mathbf{Q}\left(\frac{\pi}{4}\right) = \begin{bmatrix} \cos(\pi/4) & -\sin(\pi/4) \\ \sin(\pi/4) & \cos(\pi/4) \end{bmatrix},$$

e um escalonamento não uniforme,

$$\mathbf{L} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}.$$

Aplicar primeiro a rotação e depois o escalonamento corresponde a

$$\mathbf{L}\mathbf{Q}\left(\frac{\pi}{4}\right).$$

Aplicar primeiro o escalonamento e depois a rotação corresponde a

$$\mathbf{Q}\left(\frac{\pi}{4}\right)\mathbf{L}.$$

Como

$$\mathbf{L}\mathbf{Q}\left(\frac{\pi}{4}\right) \neq \mathbf{Q}\left(\frac{\pi}{4}\right)\mathbf{L},$$

as duas sequências produzem transformações diferentes.

A Figura 4.3 compara as duas ordens de aplicação.




Figura 4.3: Efeito da ordem na composição de uma rotação e de um escalonamento não uniforme.

As duas composições utilizam as mesmas transformações, mas produzem configurações diferentes. Na primeira, a nuvem é rotacionada antes de ser escalonada em relação aos eixos coordenados. Na segunda, o escalonamento ocorre antes da mudança de orientação.

4.3.3 Transformação inversa

Uma transformação linear invertível permite recuperar de maneira única o vetor original a partir de sua imagem.

Definição 4.3 (Transformação inversa). Uma transformação linear

$$T : V \longrightarrow W$$

é invertível quando existe uma transformação

$$T^{-1} : W \longrightarrow V$$

tal que

$$T^{-1}(T(\mathbf{x})) = \mathbf{x}$$

para todo $\mathbf{x} \in V$ e

$$T(T^{-1}(\mathbf{y})) = \mathbf{y}$$

para todo $\mathbf{y} \in W$.

Considere uma transformação

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

representada por uma matriz quadrada e invertível

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Se

$$\mathbf{y} = \mathbf{Ax},$$

então

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{y}.$$

A transformação inversa é representada por $\mathbf{A}^{-1}$.

Proposição 4.6 (Inversa de uma composição). *Se $\mathbf{A}$ e $\mathbf{B}$ são matrizes quadradas e invertíveis de dimensões compatíveis, então*

$$(\mathbf{BA})^{-1} = \mathbf{A}^{-1}\mathbf{B}^{-1}.$$

Demonstração

Tem-se

$$\begin{aligned} (\mathbf{BA})(\mathbf{A}^{-1}\mathbf{B}^{-1}) &= \mathbf{B}(\mathbf{AA}^{-1})\mathbf{B}^{-1} \\ &= \mathbf{BB}^{-1} \\ &= \mathbf{I}. \end{aligned}$$

De forma análoga,

$$\begin{aligned} (\mathbf{A}^{-1}\mathbf{B}^{-1})(\mathbf{BA}) &= \mathbf{A}^{-1}(\mathbf{B}^{-1}\mathbf{B})\mathbf{A} \\ &= \mathbf{A}^{-1}\mathbf{A} \\ &= \mathbf{I}. \end{aligned}$$

Logo,

$$(\mathbf{BA})^{-1} = \mathbf{A}^{-1}\mathbf{B}^{-1}.$$

A ordem é invertida porque a última transformação aplicada deve ser a primeira a ser desfeita.

4.3.4 Injetividade, sobrejetividade e bijetividade

As propriedades de injetividade e sobrejetividade descrevem, respectivamente, a possibilidade de distinguir vetores do domínio por suas imagens e a possibilidade de atingir todos os vetores do contradomínio.

Definição 4.4 (Injetividade, sobrejetividade e bijetividade). Uma transformação

$$T : V \longrightarrow W$$

é:

1. **injetiva** quando

$$T(\mathbf{x}_1) = T(\mathbf{x}_2) \implies \mathbf{x}_1 = \mathbf{x}_2;$$

2. **sobrejetiva** quando, para todo $\mathbf{y} \in W$, existe pelo menos um $\mathbf{x} \in V$ tal que

$$T(\mathbf{x}) = \mathbf{y};$$

3. **bijetiva** quando é simultaneamente injetiva e sobrejetiva.

Para uma transformação matricial

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

essas propriedades podem ser caracterizadas pelo núcleo, pelo espaço coluna e pelo posto.

Proposição 4.7 (Caracterizações por núcleo, imagem e posto). *Seja*

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

com $\mathbf{A} \in \mathbb{R}^{q \times p}$. Então:

1. $T_{\mathbf{A}}$ é injetiva se, e somente se,

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\};$$

2. $T_{\mathbf{A}}$ é injetiva se, e somente se,

$$\text{posto}(\mathbf{A}) = p;$$

3. $T_{\mathbf{A}}$ é sobrejetiva se, e somente se,

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \mathbb{R}^q;$$

4. $T_{\mathbf{A}}$ é sobrejetiva se, e somente se,

$$\text{posto}(\mathbf{A}) = q.$$

(Meyer, 2023)

Demonstração

Suponha inicialmente que $T_{\mathbf{A}}$ seja injetiva. Se

$$\mathbf{x} \in \ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}),$$

então

$$\mathbf{A}\mathbf{x} = \mathbf{0} = \mathbf{A}\mathbf{0}.$$

Pela injetividade,

$$\mathbf{x} = \mathbf{0}.$$

Logo,

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}.$$

Reciprocamente, suponha que

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$$

e que

$$\mathbf{A}\mathbf{x}_1 = \mathbf{A}\mathbf{x}_2.$$

Então,

$$\mathbf{A}(\mathbf{x}_1 - \mathbf{x}_2) = \mathbf{0}.$$

Portanto,

$$\mathbf{x}_1 - \mathbf{x}_2 \in \ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}),$$

o que implica

$$\mathbf{x}_1 = \mathbf{x}_2.$$

Assim, $T_{\mathbf{A}}$ é injetiva.

Pelo Teorema 3.4,

$$\dim \mathcal{N}(\mathbf{A}) + \text{posto}(\mathbf{A}) = p.$$

Como $\mathcal{N}(\mathbf{A}) = \ker(T_{\mathbf{A}})$, tem-se

$$\ker(T_{\mathbf{A}}) = \{\mathbf{0}\}$$

se, e somente se,

$$\text{posto}(\mathbf{A}) = p.$$

Por outro lado, $T_{\mathbf{A}}$ é sobrejetiva quando todo vetor de $\mathbb{R}^q$ pertence à sua imagem. Como

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}),$$

a sobrejetividade equivale a

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \mathbb{R}^q.$$

Essa igualdade ocorre se, e somente se,

$$\dim \mathcal{C}(\mathbf{A}) = q,$$

isto é,

$$\text{posto}(\mathbf{A}) = q.$$

Uma transformação de $\mathbb{R}^p$ em $\mathbb{R}^q$ pode ser injetiva somente quando

$$q \geq p.$$

De forma análoga, pode ser sobrejetiva somente quando

$$p \geq q.$$

Se a transformação é bijetiva, então

$$p = q$$

e

$$\text{posto}(\mathbf{A}) = p.$$

Combinando a Proposição 4.7 com o Teorema 2.4, obtêm-se equivalências entre invertibilidade, núcleo, imagem, posto e determinante.

Proposição 4.8 (Equivalências para uma transformação linear associada a uma matriz quadrada). *Considere*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e a transformação linear

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^p, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

São equivalentes:

1. $T_{\mathbf{A}}$ é injetiva;
2. $T_{\mathbf{A}}$ é sobrejetiva;
3. $T_{\mathbf{A}}$ é bijetiva;
4. $T_{\mathbf{A}}$ é invertível;
5. $\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$;
6. $\mathcal{C}(\mathbf{A}) = \mathbb{R}^p$;
7. $\text{posto}(\mathbf{A}) = p$;
8. $\det(\mathbf{A}) \neq 0$;
9. $\mathbf{A}^{-1}$ existe.

(Meyer, 2023)

A Tabela 4.1 resume as relações principais.

Tabela 4.1: Relações entre injetividade, sobrejetividade, bijetividade e posto.

Propriedade	Condição geométrica	Condição matricial
Injetividade	Vetores distintos possuem imagens distintas	$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$ e $\text{posto}(\mathbf{A}) = p$
Sobrejetividade	Todo vetor do contradomínio é atingido	$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \mathbb{R}^q$ e $\text{posto}(\mathbf{A}) = q$
Bijetividade	Há correspondência única entre domínio e contradomínio	$p = q = \text{posto}(\mathbf{A})$
Invertibilidade	A transformação pode ser desfeita	$\mathbf{A}$ é quadrada e $\det(\mathbf{A}) \neq 0$

4.3.5 Perda de informação

Quando a transformação não é injetiva, existem vetores distintos com a mesma imagem.

Se

$$\mathbf{v} \in \ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}),$$

então, para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\begin{aligned} \mathbf{A}(\mathbf{x} + \mathbf{v}) &= \mathbf{A}\mathbf{x} + \mathbf{A}\mathbf{v} \\ &= \mathbf{A}\mathbf{x}. \end{aligned}$$

Portanto, todos os vetores do conjunto

$$\mathbf{x} + \ker(T_{\mathbf{A}}) = \{\mathbf{x} + \mathbf{v} : \mathbf{v} \in \ker(T_{\mathbf{A}})\}$$

produzem a mesma imagem.

Reciprocamente, se

$$\mathbf{A}\mathbf{x}_1 = \mathbf{A}\mathbf{x}_2,$$

então

$$\mathbf{x}_1 - \mathbf{x}_2 \in \mathcal{N}(\mathbf{A}).$$

A ambiguidade na recuperação do vetor original é, assim, determinada pelo núcleo da transformação, que coincide com o espaço nulo da matriz associada.

Se

$$\text{posto}(\mathbf{A}) = r,$$

o Teorema Posto–Nulidade fornece

$$\dim(\mathcal{N}(\mathbf{A})) = p - r.$$

O espaço nulo possui dimensão $p - r$. Portanto, existem $p - r$ direções linearmente independentes no domínio que são anuladas pela transformação, enquanto a imagem possui dimensão r .

4.3.6 Redução de dimensionalidade

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com

$$q < p.$$

Mesmo que

$$\text{posto}(\mathbf{A}) = q,$$

tem-se

$$\dim(\mathcal{N}(\mathbf{A})) = p - q > 0.$$

A perda de informação é inevitável quando a transformação é considerada sobre todo o espaço $\mathbb{R}^p$. Entretanto, sua restrição a um conjunto particular ou a um subespaço de dimensão menor ou igual a q pode ser injetiva. Assim, reduzir o número de coordenadas não implica necessariamente identificar observações distintas no conjunto de dados efetivamente analisado.

Em técnicas de redução dimensional, a matriz é escolhida para preservar determinadas direções e eliminar outras.

4.3.7 Transformações singulares

Uma matriz quadrada é singular quando

$$\det(\mathbf{A}) = 0.$$

Nesse caso,

$$\text{posto}(\mathbf{A}) < p,$$

e a transformação leva $\mathbb{R}^p$ a um subespaço de menor dimensão.

Por exemplo,

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

transforma

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

em

$$\begin{bmatrix} x_1 \\ 0 \end{bmatrix}.$$

Todos os pontos com a mesma primeira coordenada produzem a mesma imagem.

A Figura 4.4 compara uma transformação invertível, a recuperação pela inversa e uma transformação singular.




Figura 4.4: Transformação invertível, recuperação pela inversa e colapso provocado por uma transformação singular.

A transformação representada por $\mathbf{A}$ modifica a configuração, mas mantém uma correspondência única entre os pontos originais e transformados. A aplicação de $\mathbf{A}^{-1}$ recupera a configuração inicial. A transformação singular elimina a segunda coordenada e reduz toda a nuvem a uma reta.

Para

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

as possibilidades podem ser resumidas da seguinte forma:

- se $q < p$, a transformação não pode ser injetiva;
- se $q > p$, a transformação não pode ser sobrejetiva;
- se $q = p$, ela é bijetiva quando $\text{posto}(\mathbf{A}) = p$;
- se $\text{posto}(\mathbf{A}) < \min(p, q)$, ela não é injetiva nem sobrejetiva.

Essas relações permitem interpretar

$$\text{posto}(\mathbf{A})$$

como a dimensão da imagem da transformação, isto é, como o número máximo de direções linearmente independentes que podem compor o espaço transformado.

4.4 Transformações geométricas

Matrizes distintas produzem efeitos geométricos diferentes sobre vetores e conjuntos de pontos. Algumas modificam a posição da configuração em relação aos eixos coordenados sem deformar sua geometria, enquanto outras alteram comprimentos, ângulos, áreas ou dimensão.

As cinco transformações consideradas no plano são:

- rotação;
- reflexão;
- escalonamento;
- cisalhamento;
- projeção.

Todas preservam combinações lineares e, portanto, são transformações lineares. As propriedades geométricas preservadas dependem da matriz utilizada.

4.4.1 Rotação

Uma rotação de ângulo θ em torno da origem é representada por

$$\mathbf{Q}_\theta = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

a imagem é

$$\mathbf{y} = \mathbf{Q}_\theta \mathbf{x},$$

isto é,

$$\begin{aligned} y_1 &= x_1 \cos \theta - x_2 \sin \theta, \\ y_2 &= x_1 \sin \theta + x_2 \cos \theta. \end{aligned}$$

A matriz de rotação satisfaz

$$\mathbf{Q}_\theta^\top \mathbf{Q}_\theta = \mathbf{I}_2.$$

Consequentemente,

$$\mathbf{Q}_\theta^{-1} = \mathbf{Q}_\theta^\top = \mathbf{Q}(-\theta).$$

A transformação inversa corresponde a uma rotação pelo mesmo ângulo no sentido oposto.

Além disso,

$$\det(\mathbf{Q}_\theta) = 1.$$

A rotação preserva comprimentos, distâncias, ângulos, áreas e orientação.

4.4.2 Reflexão

Uma reflexão no plano produz a imagem especular dos vetores em relação a uma reta que passa pela origem.

A reflexão em relação ao eixo horizontal é representada por

$$\mathbf{F}_1 = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix},$$

de modo que

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \mapsto \begin{bmatrix} x_1 \\ -x_2 \end{bmatrix}.$$

A reflexão em relação ao eixo vertical é representada por

$$\mathbf{F}_2 = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix},$$

e produz

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \mapsto \begin{bmatrix} -x_1 \\ x_2 \end{bmatrix}.$$

As duas matrizes satisfazem

$$\mathbf{F}^\top \mathbf{F} = \mathbf{I}_2$$

e

$$\mathbf{F}^{-1} = \mathbf{F}.$$

Assim,

$$\mathbf{F}^2 = \mathbf{I}_2.$$

Aplicar duas vezes a mesma reflexão recupera o vetor original.

Considere agora uma reta gerada por um vetor unitário

$$\mathbf{u} \in \mathbb{R}^2, \quad \|\mathbf{u}\| = 1.$$

A projeção de $\mathbf{x}$ sobre essa reta é

$$\mathbf{u}\mathbf{u}^\top \mathbf{x},$$

enquanto sua componente ortogonal é

$$(\mathbf{I}_2 - \mathbf{u}\mathbf{u}^\top) \mathbf{x}.$$

Na reflexão, a componente paralela é preservada e a componente ortogonal tem seu sinal invertido:

$$\begin{aligned} \mathbf{x}_{\text{ref}} &= \mathbf{u}\mathbf{u}^\top \mathbf{x} - (\mathbf{I}_2 - \mathbf{u}\mathbf{u}^\top) \mathbf{x} \\ &= (2\mathbf{u}\mathbf{u}^\top - \mathbf{I}_2) \mathbf{x}. \end{aligned}$$

Portanto, a reflexão em relação à reta gerada por $\mathbf{u}$ é representada por

$$\mathbf{F}_{\mathbf{u}} = 2\mathbf{u}\mathbf{u}^\top - \mathbf{I}_2.$$

Essa matriz satisfaz

$$\mathbf{F}_{\mathbf{u}}^\top \mathbf{F}_{\mathbf{u}} = \mathbf{I}_2$$

e

$$\det(\mathbf{F}_{\mathbf{u}}) = -1.$$

A reflexão preserva comprimentos, distâncias, ângulos e áreas, mas inverte a orientação.

Em dimensão p , a matriz

$$\mathbf{H}_{\mathbf{u}} = \mathbf{I}_p - 2\mathbf{u}\mathbf{u}^\top, \quad \|\mathbf{u}\| = 1,$$

representa a reflexão em relação ao hiperplano ortogonal a $\mathbf{u}$. Essa transformação é denominada **reflexão de Householder**. (Gentle, 2017)

Observe que as duas construções preservam componentes diferentes. A matriz $2\mathbf{u}\mathbf{u}^\top - \mathbf{I}$ preserva a componente na direção de $\mathbf{u}$ e inverte as componentes ortogonais a ela, enquanto $\mathbf{I} - 2\mathbf{u}\mathbf{u}^\top$ preserva as componentes ortogonais a $\mathbf{u}$ e inverte a componente na direção de $\mathbf{u}$.

4.4.3 Escalonamento

Um escalonamento modifica o comprimento dos vetores ao longo de direções determinadas.

No plano, o escalonamento em relação aos eixos coordenados é representado por

$$\mathbf{L} = \begin{bmatrix} s_1 & 0 \\ 0 & s_2 \end{bmatrix}.$$

A transformação correspondente é

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \mapsto \begin{bmatrix} s_1 x_1 \\ s_2 x_2 \end{bmatrix}.$$

Quando

$$s_1 = s_2 = s,$$

o escalonamento é uniforme:

$$\mathbf{L} = s\mathbf{I}_2.$$

Nesse caso, todos os comprimentos e todas as distâncias são multiplicados por $|s|$. Para $s \neq 0$, os ângulos são preservados.

Quando

$$s_1 \neq s_2,$$

o escalonamento é não uniforme. Cada direção coordenada é reescalada por um fator próprio, de modo que comprimentos, ângulos e proporções podem ser alterados. Se algum fator s_j for negativo, além da alteração de escala ocorre a inversão do sentido da coordenada correspondente.

O determinante da matriz é

$$\det(\mathbf{L}) = s_1 s_2.$$

A área de uma figura é, portanto, multiplicada por

$$|s_1 s_2|.$$

A transformação é invertível quando

$$s_1 \neq 0 \quad \text{e} \quad s_2 \neq 0.$$

Nesse caso,

$$\mathbf{L}^{-1} = \begin{bmatrix} 1/s_1 & 0 \\ 0 & 1/s_2 \end{bmatrix}.$$

Se algum fator de escala for igual a zero, uma direção é eliminada. Por exemplo,

$$\mathbf{L} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

leva todo o plano ao eixo horizontal.

4.4.4 Cisalhamento

Um cisalhamento modifica uma coordenada adicionando a ela uma parcela proporcional a outra coordenada.

O cisalhamento horizontal é representado por

$$\mathbf{C}_{12}(k) = \begin{bmatrix} 1 & k \\ 0 & 1 \end{bmatrix}.$$

Nesse caso,

$$\begin{aligned}y_1 &= x_1 + kx_2, \\y_2 &= x_2.\end{aligned}$$

A segunda coordenada permanece inalterada, enquanto a primeira é modificada de acordo com o valor de x_2 .

O cisalhamento vertical é representado por

$$\mathbf{C}_{21}(k) = \begin{bmatrix} 1 & 0 \\ k & 1 \end{bmatrix},$$

e produz

$$\begin{aligned}y_1 &= x_1, \\y_2 &= kx_1 + x_2.\end{aligned}$$

Em dimensão p , um cisalhamento elementar pode ser escrito como

$$\mathbf{C}_{ij}(k) = \mathbf{I}_p + k\mathbf{e}_i\mathbf{e}_j^\top, \quad i \neq j.$$

Essa transformação adiciona à coordenada i uma parcela proporcional à coordenada j .

Como

$$\left(\mathbf{e}_i\mathbf{e}_j^\top\right)^2 = \mathbf{0}$$

para $i \neq j$, tem-se

$$\begin{aligned}\mathbf{C}_{ij}(k)\mathbf{C}_{ij}(-k) &= \left(\mathbf{I}_p + k\mathbf{e}_i\mathbf{e}_j^\top\right)\left(\mathbf{I}_p - k\mathbf{e}_i\mathbf{e}_j^\top\right) \\ &= \mathbf{I}_p.\end{aligned}$$

Portanto,

$$\mathbf{C}_{ij}(k)^{-1} = \mathbf{C}_{ij}(-k).$$

O determinante de um cisalhamento elementar é

$$\det(\mathbf{C}_{ij}(k)) = 1.$$

Assim, o cisalhamento preserva áreas e volumes, mas altera comprimentos e ângulos. Retas e paralelismo são preservados. (Gentle, 2017)

4.4.5 Projeção

A projeção ortogonal definida em Definição 3.19 também pode ser interpretada como uma transformação linear.

Considere uma direção unitária

$$\mathbf{u} \in \mathbb{R}^p, \quad \|\mathbf{u}\| = 1,$$

e o subespaço

$$S = \text{span}\{\mathbf{u}\}.$$

A matriz da projeção ortogonal sobre S é

$$\mathbf{P}_S = \mathbf{u}\mathbf{u}^\top,$$

de modo que

$$T_{\mathbf{P}_S}(\mathbf{x}) = \mathbf{P}_S \mathbf{x}.$$

Pelas propriedades das matrizes de projeção em Proposição 3.16,

$$\mathbf{P}_S^2 = \mathbf{P}_S$$

e

$$\mathbf{P}_S^\top = \mathbf{P}_S.$$

Do ponto de vista das transformações lineares,

$$\text{Im}(T_{\mathbf{P}_S}) = S$$

e

$$\ker(T_{\mathbf{P}_S}) = S^\perp.$$

Assim, a projeção preserva a componente pertencente a S e elimina toda a componente pertencente a $S^\perp$.

Para uma projeção sobre uma única direção,

$$\text{posto}(\mathbf{P}_S) = 1.$$

Consequentemente, quando $p > 1$,

$$\det(\mathbf{P}_S) = 0,$$

e a transformação não é invertível. Vetores que diferem apenas por uma componente pertencente a $S^\perp$ possuem a mesma imagem.

4.4.6 Comparação geométrica

A Figura 4.5 mostra o efeito das transformações anteriores sobre o quadrado unitário. Como todos os painéis utilizam a mesma escala, alterações de forma, área e dimensão podem ser comparadas diretamente.




Figura 4.5: Efeito de diferentes transformações lineares sobre o quadrado unitário.

A rotação altera a posição do quadrado em relação aos eixos coordenados sem modificar sua forma, sua área ou sua orientação. A reflexão preserva a forma e a área, mas inverte a orientação. O escalonamento não uniforme modifica os comprimentos nas direções coordenadas e transforma o quadrado em um retângulo. O cisalhamento transforma o quadrado em um paralelogramo com a mesma área, mostrando que preservar área não implica preservar ângulos ou comprimentos. A projeção elimina uma direção e reduz a figura a um segmento de reta.

A Tabela 4.2 resume as propriedades das transformações estudadas.

Tabela 4.2: Propriedades das principais transformações geométricas no plano.

Transformação	Matriz no plano	Determinante	Efeito geométrico
Rotação	$\mathbf{Q}_\theta$	1	Gira a configuração
Reflexão	$\mathbf{F}$	-1	Produz uma imagem especular
Escala	$\text{diag}(s_1, s_2)$	$s_1 s_2$	Reescala direções coordenadas
Cisalhamento	$\begin{bmatrix} 1 & k \\ 0 & 1 \end{bmatrix}$	1	Inclina a configuração
Projeção sobre uma reta	$\mathbf{u}\mathbf{u}^\top$	0	Elimina uma direção

A preservação de área ou volume não implica preservação de distâncias e ângulos. O cisalhamento possui determinante igual a 1, mas deforma a configuração. Transformações ortogonais são caracterizadas pela preservação da geometria euclidiana.

4.5 Transformações ortogonais

A linearidade não garante a preservação de comprimentos, distâncias ou ângulos. Essas propriedades são preservadas pelas transformações representadas por matrizes ortogonais.

Retomando a Definição 2.15, uma matriz

$$\mathbf{Q} \in \mathbb{R}^{p \times p}$$

é ortogonal quando

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_p.$$

Essa condição implica

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top$$

e

$$\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}_p.$$

A transformação

$$T_{\mathbf{Q}} : \mathbb{R}^p \longrightarrow \mathbb{R}^p, \quad T_{\mathbf{Q}}(\mathbf{x}) = \mathbf{Q}\mathbf{x},$$

é denominada **transformação ortogonal**.

Proposição 4.9 (Preservação da geometria euclidiana). *Se $\mathbf{Q} \in \mathbb{R}^{p \times p}$ é ortogonal, então, para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, a transformação*

$$T_{\mathbf{Q}}(\mathbf{x}) = \mathbf{Q}\mathbf{x}$$

preserva:

1. o produto interno;
2. as normas;
3. as distâncias euclidianas;
4. os ângulos entre vetores não nulos;
5. a ortogonalidade.

(Gentle, 2017)

Demonstração

Pelo Teorema 2.6,

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{y}.$$

Portanto, o produto interno entre quaisquer dois vetores é preservado.

Tomando $\mathbf{y} = \mathbf{x}$,

$$\begin{aligned} \|\mathbf{Q}\mathbf{x}\|^2 &= (\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{x}) \\ &= \mathbf{x}^\top \mathbf{x} \\ &= \|\mathbf{x}\|^2. \end{aligned}$$

Como as normas são não negativas,

$$\|\mathbf{Q}\mathbf{x}\| = \|\mathbf{x}\|.$$

Para dois vetores $\mathbf{x}$ e $\mathbf{y}$,

$$\begin{aligned}\|\mathbf{Q}\mathbf{x} - \mathbf{Q}\mathbf{y}\| &= \|\mathbf{Q}(\mathbf{x} - \mathbf{y})\| \\ &= \|\mathbf{x} - \mathbf{y}\|.\end{aligned}$$

Logo, todas as distâncias euclidianas entre pares de vetores são preservadas.

Para vetores não nulos, o ângulo θ entre $\mathbf{x}$ e $\mathbf{y}$ é determinado por

$$\cos(\theta) = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

Como o produto interno e as normas são preservados,

$$\frac{(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y})}{\|\mathbf{Q}\mathbf{x}\| \|\mathbf{Q}\mathbf{y}\|} = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

Portanto, os ângulos também são preservados.

Em particular, se

$$\mathbf{x}^\top \mathbf{y} = 0,$$

então

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = 0,$$

e a ortogonalidade é preservada.

Assim, transformações ortogonais preservam integralmente as relações métricas determinadas pelo produto interno euclidiano. Elas podem alterar a orientação da configuração, mas não deformam sua geometria interna.

4.5.1 Transformação de uma matriz de dados

Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p}$$

e uma transformação ortogonal representada por

$$\mathbf{Q} \in \mathbb{R}^{p \times p}.$$

Como as observações estão organizadas nas linhas, a matriz transformada é

$$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top.$$

Proposição 4.10 (Preservação da matriz de Gram). *Se*

$$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top$$

e $\mathbf{Q}$ é ortogonal, então

$$\mathbf{Y}\mathbf{Y}^\top = \mathbf{X}\mathbf{X}^\top.$$

Demonstração

Tem-se

$$\begin{aligned}\mathbf{Y}\mathbf{Y}^\top &= (\mathbf{X}\mathbf{Q}^\top)(\mathbf{X}\mathbf{Q}^\top)^\top \\ &= \mathbf{X}\mathbf{Q}^\top\mathbf{Q}\mathbf{X}^\top \\ &= \mathbf{X}\mathbf{I}_p\mathbf{X}^\top \\ &= \mathbf{X}\mathbf{X}^\top.\end{aligned}$$

A matriz de Gram reúne os produtos internos entre as observações. Sua preservação implica que permanecem inalterados:

- os quadrados das normas das observações;
- os produtos internos entre pares de observações;
- as distâncias entre as observações;
- os ângulos entre os vetores observados não nulos.

A nuvem de pontos pode ser rotacionada ou refletida, mas sua forma e suas relações internas permanecem as mesmas.

4.5.2 Matrizes ortogonais e bases ortonormais

As colunas de uma matriz ortogonal formam uma base ortonormal de $\mathbb{R}^p$.

Se

$$\mathbf{Q} = [\mathbf{q}_1 \quad \mathbf{q}_2 \quad \cdots \quad \mathbf{q}_p],$$

então suas colunas satisfazem

$$\mathbf{q}_i^\top \mathbf{q}_j = \delta_{ij},$$

em que δ_{ij} é o delta de Kronecker definido no Capítulo 2. Portanto, as colunas de $\mathbf{Q}$ possuem norma unitária e são ortogonais duas a duas.

Como

$$\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}_p,$$

as linhas de $\mathbf{Q}$ também formam um conjunto ortonormal.

Uma matriz ortogonal admite, portanto, duas interpretações que devem ser distinguidas:

- como matriz de uma transformação linear que preserva a geometria euclidiana;
- como matriz cujas colunas constituem uma base ortonormal de $\mathbb{R}^p$.

Na primeira interpretação, a matriz atua sobre o vetor e modifica sua posição no espaço. Na segunda, seus vetores-coluna definem um sistema de coordenadas. Para uma base ortonormal formada pelas colunas de $\mathbf{Q}$, as coordenadas de $\mathbf{x}$ são $\mathbf{Q}^\top \mathbf{x}$.

4.5.3 Comparação com transformações não ortogonais

A Figura 4.6 compara o efeito de diferentes matrizes sobre a circunferência unitária e sobre duas direções inicialmente ortogonais. O marcador de ângulo reto identifica os casos em que a ortogonalidade é preservada.

A rotação e a reflexão mantêm a circunferência unitária e preservam o ângulo reto entre as duas direções. O escalonamento não uniforme transforma a circunferência em uma elipse; embora as duas direções coordenadas permaneçam ortogonais neste exemplo particular, seus comprimentos são alterados e a transformação não é ortogonal. O cisalhamento deforma a circunferência e também altera o ângulo entre as direções.

A Tabela 4.3 compara as propriedades dessas transformações.

Tabela 4.3: Comparação entre transformações ortogonais e não ortogonais.

Transformação	Ortogonal	Preserva normas	Preserva distâncias	Preserva ângulos	$ \det(\mathbf{A}) $
Rotação	Sim	Sim	Sim	Sim	1
Reflexão	Sim	Sim	Sim	Sim	1
Escalonamento uniforme	Somente se $ s = 1$	Somente se $ s = 1$	Somente se $ s = 1$	Sim, se $s \neq 0$	$ s ^p$

Transformação	Ortogonal	Preserva normas	Preserva distâncias	Preserva ângulos	$ \det(\mathbf{A}) $
Escalonamento não uniforme	Não	Não	Não	Não, em geral	$\prod_j s_j $
Cisalhamento	Não	Não	Não	Não, em geral	1
Projeção própria	Não	Não	Não	Não, em geral	0

A condição

$$|\det(\mathbf{A})| = 1$$

não é suficiente para que uma matriz seja ortogonal. O cisalhamento possui determinante igual a 1 e preserva áreas, mas não preserva normas nem ângulos.

A condição que caracteriza a preservação da geometria euclidiana é

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_p.$$

4.6 Mudanças de coordenadas e representação em bases

Pela Definição 3.6, um mesmo vetor pode ter coordenadas distintas em bases distintas, embora o vetor geométrico permaneça o mesmo. Seja

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_p\}$$

uma base de $\mathbb{R}^p$, com a ordem dos vetores fixada. A matriz formada pelos vetores da base é

$$\mathbf{B} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_p].$$

Como os vetores de $\mathcal{B}$ são linearmente independentes, $\mathbf{B}$ é invertível.

Se

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} c_1 \\ \vdots \\ c_p \end{bmatrix}$$




Figura 4.6: Efeito de transformações ortogonais e não ortogonais sobre a circunferência unitária e duas direções inicialmente ortogonais.

é o vetor de coordenadas de $\mathbf{x}$ na base $\mathcal{B}$, então

$$\mathbf{x} = c_1 \mathbf{b}_1 + \cdots + c_p \mathbf{b}_p.$$

Em forma matricial,

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Consequentemente,

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{B}^{-1}\mathbf{x}.$$

Assim, $\mathbf{B}$ converte as coordenadas de $\mathbf{x}$ na base $\mathcal{B}$ em suas coordenadas na base canônica, enquanto $\mathbf{B}^{-1}$ realiza a conversão no sentido contrário.

Quando $\mathcal{B}$ é uma base ortonormal, pela Definição 3.9,

$$\mathbf{B}^{\top}\mathbf{B} = \mathbf{I}_p.$$

Logo,

$$\mathbf{B}^{-1} = \mathbf{B}^{\top}$$

e

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{B}^{\top}\mathbf{x}.$$

Nesse caso,

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} \mathbf{b}_1^{\top}\mathbf{x} \\ \vdots \\ \mathbf{b}_p^{\top}\mathbf{x} \end{bmatrix},$$

de modo que cada coordenada é obtida pelo produto interno entre $\mathbf{x}$ e o vetor correspondente da base.

4.6.1 Representação de um operador em uma nova base

Considere um operador linear

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

representado na base canônica por $\mathbf{A}$, e seja $\mathcal{B}$ uma base de $\mathbb{R}^p$ com matriz $\mathbf{B}$. Como

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}},$$

tem-se

$$\begin{aligned} [T(\mathbf{x})]_{\mathcal{B}} &= \mathbf{B}^{-1}T(\mathbf{x}) \\ &= \mathbf{B}^{-1}\mathbf{A}\mathbf{x} \\ &= \mathbf{B}^{-1}\mathbf{A}\mathbf{B}[\mathbf{x}]_{\mathcal{B}}. \end{aligned}$$

Portanto,

$$[T]_{\mathcal{B} \leftarrow \mathcal{B}} = \mathbf{B}^{-1}\mathbf{A}\mathbf{B}.$$

Adota-se a notação abreviada

$$\mathbf{A}_{\mathcal{B}} = \mathbf{B}^{-1}\mathbf{A}\mathbf{B}.$$

Definição 4.5 (Matrizes semelhantes). Duas matrizes quadradas $\mathbf{A}$ e $\mathbf{D}$ são **semelhantes** quando existe uma matriz invertível $\mathbf{P}$ tal que

$$\mathbf{D} = \mathbf{P}^{-1}\mathbf{A}\mathbf{P}.$$

(Gentle, 2017)

Matrizes semelhantes representam o mesmo operador linear em bases diferentes. Por essa razão, preservam propriedades que não dependem do sistema de coordenadas.

Proposição 4.11 (Invariantes por semelhança). *Sejam*

$$\mathbf{A}, \mathbf{D}, \mathbf{P} \in \mathbb{R}^{p \times p},$$

com $\mathbf{P}$ invertível. Se

$$\mathbf{D} = \mathbf{P}^{-1} \mathbf{A} \mathbf{P},$$

então

$$\det(\mathbf{D}) = \det(\mathbf{A}),$$

$$\text{tr}(\mathbf{D}) = \text{tr}(\mathbf{A})$$

e

$$\text{posto}(\mathbf{D}) = \text{posto}(\mathbf{A}).$$

(Horn; Johnson, 2013)

Demonstração

Para o determinante,

$$\begin{aligned} \det(\mathbf{D}) &= \det(\mathbf{P}^{-1} \mathbf{A} \mathbf{P}) \\ &= \det(\mathbf{P}^{-1}) \det(\mathbf{A}) \det(\mathbf{P}) \\ &= \det(\mathbf{A}). \end{aligned}$$

Para o traço, pela propriedade cíclica,

$$\begin{aligned} \text{tr}(\mathbf{D}) &= \text{tr}(\mathbf{P}^{-1} \mathbf{A} \mathbf{P}) \\ &= \text{tr}(\mathbf{A} \mathbf{P} \mathbf{P}^{-1}) \\ &= \text{tr}(\mathbf{A}). \end{aligned}$$

Como a multiplicação à esquerda ou à direita por uma matriz invertível não altera o posto,

$$\text{posto}(\mathbf{P}^{-1} \mathbf{A} \mathbf{P}) = \text{posto}(\mathbf{A}).$$

Matrizes semelhantes representam o mesmo operador em bases diferentes e possuem os mesmos autovalores, propriedade utilizada na diagonalização.

4.6.2 Mudança de coordenadas de uma matriz de dados

Considere

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

com as observações organizadas nas linhas, e uma base ortonormal cujos vetores estão nas colunas de $\mathbf{Q}$.

As coordenadas da i -ésima observação na nova base são

$$\mathbf{z}_i = \mathbf{Q}^\top \mathbf{x}_i.$$

Transpondo,

$$\mathbf{z}_i^\top = \mathbf{x}_i^\top \mathbf{Q}.$$

Portanto, a matriz de novas coordenadas é

$$\mathbf{Z} = \mathbf{X}\mathbf{Q}.$$

Para a mesma matriz ortogonal $\mathbf{Q}$, a mudança de coordenadas usa $\mathbf{Z} = \mathbf{X}\mathbf{Q}$, enquanto a transformação ativa usa $\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top$; a distinção é detalhada em [Seção 4.8.5](#).

4.7 Transformações afins e pré-processamento

Toda transformação linear mantém o vetor nulo fixo:

$$T(\mathbf{0}) = \mathbf{0}.$$

Se uma aplicação possui a forma $T(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b}$ com $\mathbf{b} \neq \mathbf{0}$, então $T(\mathbf{0}) = \mathbf{b} \neq \mathbf{0}$. Essas aplicações são transformações afins.

Definição 4.6 (Transformação afim). Uma aplicação

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é uma **transformação afim** quando pode ser escrita como

$$T(\mathbf{x}) = \mathbf{Ax} + \mathbf{b},$$

em que

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{b} \in \mathbb{R}^q.$$

A matriz $\mathbf{A}$ determina a parte linear da transformação, enquanto $\mathbf{b}$ determina o deslocamento.

Quando

$$\mathbf{b} = \mathbf{0},$$

a transformação afim reduz-se a uma transformação linear.

Quando

$$\mathbf{b} \neq \mathbf{0},$$

tem-se

$$T(\mathbf{0}) = \mathbf{b} \neq \mathbf{0},$$

e a transformação não é linear.

4.7.1 Translação

A translação é o caso particular

$$T(\mathbf{x}) = \mathbf{x} + \mathbf{b}.$$

Todos os pontos são deslocados pelo mesmo vetor $\mathbf{b}$.

Para dois vetores $\mathbf{x}_i$ e $\mathbf{x}_j$,

$$\begin{aligned} T(\mathbf{x}_i) - T(\mathbf{x}_j) &= (\mathbf{x}_i + \mathbf{b}) - (\mathbf{x}_j + \mathbf{b}) \\ &= \mathbf{x}_i - \mathbf{x}_j. \end{aligned}$$

Consequentemente,

$$\|T(\mathbf{x}_i) - T(\mathbf{x}_j)\| = \|\mathbf{x}_i - \mathbf{x}_j\|.$$

A translação preserva:

- diferenças entre os pontos;
- distâncias;
- ângulos entre segmentos;
- forma;
- áreas e volumes.

Ela modifica apenas a posição da configuração em relação à origem.

4.7.2 Transformação afim de uma matriz de dados

Considere uma transformação afim aplicada a cada observação:

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i + \mathbf{b}.$$

Se as observações estão organizadas nas linhas de

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a matriz transformada é

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top + \mathbf{1}_n \mathbf{b}^\top,$$

em que

$$\mathbf{1}_n = \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} \in \mathbb{R}^n.$$

A matriz

$$\mathbf{1}_n \mathbf{b}^\top$$

possui dimensão $n \times q$ e contém n linhas iguais a $\mathbf{b}^\top$. Assim, o mesmo deslocamento é acrescentado a todas as observações.

As dimensões da transformação são

$$\underbrace{\mathbf{X}}_{n \times p} \underbrace{\mathbf{A}^\top}_{p \times q} + \underbrace{\mathbf{1}_n}_{n \times 1} \underbrace{\mathbf{b}^\top}_{1 \times q} = \underbrace{\mathbf{Y}}_{n \times q}.$$

No caso de uma translação pura,

$$\mathbf{A} = \mathbf{I}_p,$$

e

$$\mathbf{Y} = \mathbf{X} + \mathbf{1}_n \mathbf{b}^\top.$$

4.7.3 Centralização

A centralização desloca uma configuração para que um vetor de localização coincida com a origem.

Para um vetor fixo

$$\mathbf{m} \in \mathbb{R}^p,$$

define-se

$$\mathbf{x}_c = \mathbf{x} - \mathbf{m}.$$

Essa operação é afim:

$$T(\mathbf{x}) = \mathbf{I}_p \mathbf{x} - \mathbf{m}.$$

Quando

$$\mathbf{m} \neq \mathbf{0},$$

ela não é linear, pois

$$T(\mathbf{0}) = -\mathbf{m}.$$

Para uma matriz de dados,

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix},$$

a centralização por $\mathbf{m}$ é

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \mathbf{m}^\top.$$

Quando o vetor de localização é a média amostral,

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i,$$

tem-se

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top.$$

Retomando a matriz de centralização,

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top,$$

a matriz centralizada pode ser escrita como

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}.$$

De fato,

$$\begin{aligned}
\mathbf{H}_n \mathbf{X} &= \left(\mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top \right) \mathbf{X} \\
&= \mathbf{X} - \mathbf{1}_n \left(\frac{1}{n} \mathbf{1}_n^\top \mathbf{X} \right) \\
&= \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top.
\end{aligned}$$

A centralização de cada observação em torno de um vetor fixo é uma transformação afim. Em contraste, a aplicação

$$\mathbf{X} \mapsto \mathbf{H}_n \mathbf{X}$$

sobre o espaço das matrizes de dados é linear, pois $\mathbf{H}_n$ é uma matriz fixa.

Além disso,

$$\mathbf{H}_n = \mathbf{H}_n^\top$$

e

$$\mathbf{H}_n^2 = \mathbf{H}_n.$$

Portanto, $\mathbf{H}_n$ é uma matriz de projeção ortogonal. Como

$$\mathbf{H}_n \mathbf{1}_n = \mathbf{0},$$

seu núcleo é

$$\mathcal{N}(\mathbf{H}_n) = \text{span}\{\mathbf{1}_n\},$$

e sua imagem é o subespaço

$$\mathcal{C}(\mathbf{H}_n) = \{\mathbf{z} \in \mathbb{R}^n : \mathbf{1}_n^\top \mathbf{z} = 0\} = \text{span}\{\mathbf{1}_n\}^\perp.$$

Assim, multiplicar uma variável observada por $\mathbf{H}_n$ equivale a projetá-la ortogonalmente sobre o subespaço dos vetores cujas componentes somam zero.

Como $\mathbf{H}_n$ é simétrica e

$$\mathbf{H}_n \mathbf{1}_n = \mathbf{0},$$

tem-se também

$$\mathbf{1}_n^\top \mathbf{H}_n = \mathbf{0}^\top.$$

Consequentemente,

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{1}_n^\top \mathbf{H}_n \mathbf{X} = \mathbf{0}^\top.$$

Portanto, cada coluna de $\mathbf{X}_c$ possui média igual a zero.

Proposição 4.12 (Preservação das distâncias pela centralização). *Se*

$$\mathbf{x}_{ci} = \mathbf{x}_i - \mathbf{m}$$

e

$$\mathbf{x}_{cj} = \mathbf{x}_j - \mathbf{m},$$

então

$$\|\mathbf{x}_{ci} - \mathbf{x}_{cj}\| = \|\mathbf{x}_i - \mathbf{x}_j\|.$$

Demonstração

Tem-se

$$\begin{aligned} \mathbf{x}_{ci} - \mathbf{x}_{cj} &= (\mathbf{x}_i - \mathbf{m}) - (\mathbf{x}_j - \mathbf{m}) \\ &= \mathbf{x}_i - \mathbf{x}_j. \end{aligned}$$

Logo, as duas diferenças possuem a mesma norma.

A centralização modifica a posição da nuvem em relação à origem, mas preserva sua configuração interna.

4.7.4 Escalonamento das variáveis

Considere uma matriz diagonal

$$\mathbf{L} = \text{diag}(\ell_1, \dots, \ell_p),$$

com

$$\ell_j > 0, \quad j = 1, \dots, p.$$

A transformação

$$\mathbf{y} = \mathbf{L}^{-1}\mathbf{x}$$

divide cada coordenada por sua escala correspondente:

$$y_j = \frac{x_j}{\ell_j}.$$

Essa operação é linear e, para uma matriz de dados, assume a forma

$$\mathbf{Y} = \mathbf{X}\mathbf{L}^{-1}.$$

A multiplicação ocorre à direita porque as variáveis ocupam as colunas de $\mathbf{X}$.

Quando as escalas são diferentes, o escalonamento modifica, em geral, distâncias e ângulos. Alguns pares particulares de vetores podem manter sua relação angular, mas a geometria euclidiana não é preservada para todos os vetores. Para duas observações,

$$\|\mathbf{L}^{-1}\mathbf{x}_i - \mathbf{L}^{-1}\mathbf{x}_j\|^2 = (\mathbf{x}_i - \mathbf{x}_j)^\top \mathbf{L}^{-2} (\mathbf{x}_i - \mathbf{x}_j).$$

O escalonamento induz, no espaço original, a geometria determinada pela matriz positiva definida

$$\mathbf{L}^{-2}.$$

Variáveis associadas a escalas menores recebem maior peso nas distâncias transformadas. Quando todas as escalas são iguais, isto é,

$$\mathbf{L} = \ell \mathbf{I}_p,$$

o escalonamento é uniforme: todas as distâncias são multiplicadas pelo mesmo fator $1/\ell$ e os ângulos são preservados.

4.7.5 Padronização

A padronização combina centralização e escalonamento. (Gentle, 2017)

Para um vetor de localização $\mathbf{m}$ e uma matriz diagonal de escalas positivas $\mathbf{L}$, define-se

$$\mathbf{z} = \mathbf{L}^{-1} (\mathbf{x} - \mathbf{m}).$$

Essa expressão pode ser reorganizada como

$$\mathbf{z} = \mathbf{L}^{-1}\mathbf{x} - \mathbf{L}^{-1}\mathbf{m}.$$

Portanto, a padronização é uma transformação afim com

$$\mathbf{A} = \mathbf{L}^{-1}$$

e

$$\mathbf{b} = -\mathbf{L}^{-1}\mathbf{m}.$$

Para uma matriz de dados,

$$\mathbf{Z} = (\mathbf{X} - \mathbf{1}_n \mathbf{m}^\top) \mathbf{L}^{-1}.$$

Quando $\mathbf{m} = \bar{\mathbf{x}}$ e os elementos diagonais de $\mathbf{L}$ são os desvios-padrão amostrais, cada coluna de $\mathbf{Z}$ possui média zero e desvio-padrão igual a 1, desde que todas as variáveis apresentem desvio-padrão amostral positivo.

A interpretação da padronização como transformação afim considera $\mathbf{m}$ e $\mathbf{L}$ fixados. Quando o vetor de médias e os desvios-padrão são calculados a partir da própria matriz de dados $\mathbf{X}$, esses elementos passam a depender dos dados. Nesse caso, para os valores calculados de $\mathbf{m}$ e $\mathbf{L}$, cada observação é submetida à transformação afim

$$\mathbf{x} \mapsto \mathbf{L}^{-1} (\mathbf{x} - \mathbf{m}),$$

mas a operação completa que associa a matriz original $\mathbf{X}$ à matriz padronizada $\mathbf{Z}$ é dependente dos dados e não constitui, globalmente, uma transformação afim de $\mathbf{X}$.

Para duas observações padronizadas,

$$\begin{aligned}\mathbf{z}_i - \mathbf{z}_j &= \mathbf{L}^{-1} (\mathbf{x}_i - \mathbf{m}) - \mathbf{L}^{-1} (\mathbf{x}_j - \mathbf{m}) \\ &= \mathbf{L}^{-1} (\mathbf{x}_i - \mathbf{x}_j) .\end{aligned}$$

Logo,

$$\|\mathbf{z}_i - \mathbf{z}_j\|^2 = (\mathbf{x}_i - \mathbf{x}_j)^\top \mathbf{L}^{-2} (\mathbf{x}_i - \mathbf{x}_j) .$$

A translação associada à centralização não altera as diferenças entre observações. A alteração da geometria decorre do escalonamento.

4.7.6 Ordem entre centralização e escalonamento

A padronização usual é

$$\mathbf{z} = \mathbf{L}^{-1} (\mathbf{x} - \mathbf{m}) .$$

Se o escalonamento for aplicado primeiro,

$$\mathbf{y} = \mathbf{L}^{-1} \mathbf{x} ,$$

o vetor de localização também deve ser expresso na nova escala:

$$\mathbf{L}^{-1} \mathbf{m} .$$

Assim,

$$\mathbf{z} = \mathbf{y} - \mathbf{L}^{-1} \mathbf{m} .$$

As duas sequências produzem o mesmo resultado quando o vetor de centralização é transformado juntamente com os dados.

4.7.7 Composição e inversão de transformações afins

Considere

$$T_1(\mathbf{x}) = \mathbf{Ax} + \mathbf{b}$$

e

$$T_2(\mathbf{y}) = \mathbf{Cy} + \mathbf{d}.$$

A composição é

$$\begin{aligned} T_2(T_1(\mathbf{x})) &= \mathbf{C}(\mathbf{Ax} + \mathbf{b}) + \mathbf{d} \\ &= \mathbf{CAx} + \mathbf{Cb} + \mathbf{d}. \end{aligned}$$

Portanto,

$$(T_2 \circ T_1)(\mathbf{x}) = \mathbf{CAx} + (\mathbf{Cb} + \mathbf{d}).$$

A composição de transformações afins também é afim.

Considere agora

$$\mathbf{y} = \mathbf{Ax} + \mathbf{b},$$

com $\mathbf{A}$ quadrada e invertível. Subtraindo $\mathbf{b}$ e multiplicando por $\mathbf{A}^{-1}$,

$$\mathbf{x} = \mathbf{A}^{-1}(\mathbf{y} - \mathbf{b}).$$

A transformação inversa é

$$T^{-1}(\mathbf{y}) = \mathbf{A}^{-1}\mathbf{y} - \mathbf{A}^{-1}\mathbf{b}.$$

Uma transformação afim de $\mathbb{R}^p$ em $\mathbb{R}^p$ é invertível se, e somente se, sua parte linear $\mathbf{A}$ é invertível.




Figura 4.7: Efeito da centralização, do escalonamento e da padronização sobre uma mesma configuração de dados.

4.7.8 Comparação das operações de pré-processamento

A Figura 4.7 compara centralização, escalonamento e padronização de uma mesma nuvem de pontos. O mesmo vetor de escalas é utilizado no escalonamento e na padronização, permitindo separar visualmente o efeito da alteração de escala do efeito da centralização.

A centralização desloca a nuvem para que sua média coincida com a origem, sem modificar as diferenças nem as distâncias entre as observações. O escalonamento altera as unidades das coordenadas e, em geral, modifica comprimentos, distâncias e ângulos. A padronização combina esses dois efeitos: centraliza a nuvem e reescala suas coordenadas.

A Tabela 4.4 compara transformações lineares, transformações afins, centralização, escalonamento e padronização quanto à linearidade e à preservação da origem.

Tabela 4.4: Comparação entre transformações lineares, transformações afins e operações de pré-processamento.

Operação	Expressão para um vetor	Linear como função de $\mathbf{x}$?	Mantém a origem fixa?
Transformação linear	$\mathbf{Ax}$	Sim	Sim
Translação	$\mathbf{x} + \mathbf{b}$	Não, se $\mathbf{b} \neq \mathbf{0}$	Não
Transformação afim	$\mathbf{Ax} + \mathbf{b}$	Não, em geral	Não, em geral
Centralização	$\mathbf{x} - \mathbf{m}$	Não, se $\mathbf{m} \neq \mathbf{0}$	Não
Escalação	$\mathbf{L}^{-1}\mathbf{x}$	Sim	Sim
Padronização	$\mathbf{L}^{-1}(\mathbf{x} - \mathbf{m})$	Não, em geral	Não, em geral

Transformações lineares podem modificar direção, escala ou dimensão, mas mantêm necessariamente a origem fixa. Transformações afins acrescentam a possibilidade de deslocar a configuração. A centralização e a padronização pertencem a essa segunda classe quando consideradas como operações sobre uma observação individual e para parâmetros de localização e escala fixados. Quando a centralização de uma matriz de dados é escrita como $\mathbf{X} \mapsto \mathbf{H}_n \mathbf{X}$, a operação é linear no espaço das matrizes.

4.8 Aprofundamento teórico

4.8.1 Determinante, volume e orientação

Para uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{p \times p},$$

o valor absoluto do determinante representa o fator pelo qual volumes são multiplicados.

Proposição 4.13 (Alteração de volume por uma transformação linear). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e seja

$$E \subseteq \mathbb{R}^p$$

um conjunto mensurável com volume p -dimensional finito. Denote por

$$\mathbf{A}E = \{\mathbf{A}\mathbf{x} : \mathbf{x} \in E\}$$

sua imagem pela transformação linear representada por $\mathbf{A}$.

Então,

$$\text{Vol}_p(\mathbf{A}E) = |\det(\mathbf{A})| \text{Vol}_p(E),$$

em que Vol_p representa o volume p -dimensional.

Se

$$\det(\mathbf{A}) = 0,$$

então

$$\text{posto}(\mathbf{A}) < p,$$

de modo que a imagem $\mathbf{A}E$ está contida em um subespaço próprio de $\mathbb{R}^p$. Consequentemente,

$$\text{Vol}_p(\mathbf{A}E) = 0.$$

No plano, o Proposição 4.13 descreve a alteração de área; em $\mathbb{R}^3$, a alteração de volume; em dimensão p , a alteração do volume p -dimensional.

Quando $\det(\mathbf{A}) \neq 0$, o sinal do determinante determina a orientação:

- se $\det(\mathbf{A}) > 0$, a orientação é preservada;
- se $\det(\mathbf{A}) < 0$, a orientação é invertida.

Se $\det(\mathbf{A}) = 0$, a transformação não é invertível, sua imagem possui dimensão inferior a p e o volume p -dimensional é reduzido a zero.

4.8.2 Determinante e orientação em transformações ortogonais

Proposição 4.14 (Determinante de uma matriz ortogonal). *Se $\mathbf{Q} \in \mathbb{R}^{p \times p}$ é ortogonal, então*

$$\det(\mathbf{Q}) \in \{-1, 1\}.$$

Consequentemente,

$$|\det(\mathbf{Q})| = 1,$$

e a transformação preserva volumes p -dimensionais.

(Gentle, 2017)

Demonstração

Como

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_p,$$

tem-se

$$\begin{aligned} 1 &= \det(\mathbf{Q}^\top \mathbf{Q}) \\ &= \det(\mathbf{Q}^\top) \det(\mathbf{Q}) \\ &= \det(\mathbf{Q})^2. \end{aligned}$$

Portanto,

$$\det(\mathbf{Q}) = 1 \quad \text{ou} \quad \det(\mathbf{Q}) = -1.$$

Logo,

$$|\det(\mathbf{Q})| = 1.$$

No plano, a preservação do volume p -dimensional corresponde à preservação de áreas; em $\mathbb{R}^3$, corresponde à preservação de volumes.

Quando

$$\det(\mathbf{Q}) = 1,$$

a transformação é denominada **ortogonal própria**. Ela preserva a orientação.

No plano, toda transformação ortogonal própria é uma rotação e pode ser representada por

$$\mathbf{Q} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}.$$

Quando

$$\det(\mathbf{Q}) = -1,$$

a transformação é denominada **ortogonal imprópria**. Ela inverte a orientação.

No plano, toda transformação ortogonal imprópria corresponde a uma reflexão em relação a uma reta que passa pela origem. Em dimensões superiores, pode combinar uma reflexão com rotações em subespaços ortogonais.

4.8.3 Conversão entre duas bases

Considere duas bases de $\mathbb{R}^p$,

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_p\}$$

e

$$\mathcal{C} = \{\mathbf{c}_1, \dots, \mathbf{c}_p\},$$

e as respectivas matrizes

$$\mathbf{B} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_p]$$

e

$$\mathbf{C} = [\mathbf{c}_1 \quad \dots \quad \mathbf{c}_p].$$

O mesmo vetor pode ser representado por

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}$$

e por

$$\mathbf{x} = \mathbf{C}[\mathbf{x}]_{\mathcal{C}}.$$

Igualando as duas expressões,

$$\mathbf{C}[\mathbf{x}]_{\mathcal{C}} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Multiplicando à esquerda por $\mathbf{C}^{-1}$,

$$[\mathbf{x}]_{\mathcal{C}} = \mathbf{C}^{-1}\mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Definição 4.7 (Matriz de mudança de base). A **matriz de mudança de base de $\mathcal{B}$ para $\mathcal{C}$** é

$$\mathbf{C}^{-1}\mathbf{B}.$$

Ela transforma as coordenadas de um vetor na base $\mathcal{B}$ em suas coordenadas na base $\mathcal{C}$:

$$[\mathbf{x}]_{\mathcal{C}} = (\mathbf{C}^{-1}\mathbf{B}) [\mathbf{x}]_{\mathcal{B}}.$$

O sentido da conversão deve ser observado na ordem das matrizes:

$$\mathcal{B} \longrightarrow \mathcal{C} \quad \Longleftrightarrow \quad \mathbf{C}^{-1}\mathbf{B}.$$

No sentido contrário, a matriz de mudança de base é

$$\mathbf{B}^{-1}\mathbf{C}.$$

As duas matrizes são inversas entre si:

$$\mathbf{B}^{-1}\mathbf{C} = (\mathbf{C}^{-1}\mathbf{B})^{-1}.$$

4.8.4 Representação de uma transformação em bases gerais

Considere uma transformação linear

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

representada nas bases canônicas por

$$\mathbf{y} = \mathbf{A}\mathbf{x},$$

com

$$\mathbf{A} \in \mathbb{R}^{q \times p}.$$

Seja $\mathcal{B}$ uma base do domínio, com matriz

$$\mathbf{B} = [\mathbf{b}_1 \quad \cdots \quad \mathbf{b}_p],$$

e seja $\mathcal{C}$ uma base do contradomínio, com matriz

$$\mathbf{C} = [\mathbf{c}_1 \quad \cdots \quad \mathbf{c}_q].$$

Como

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}},$$

tem-se

$$\begin{aligned} [T(\mathbf{x})]_{\mathcal{C}} &= \mathbf{C}^{-1}T(\mathbf{x}) \\ &= \mathbf{C}^{-1}\mathbf{A}\mathbf{x} \\ &= \mathbf{C}^{-1}\mathbf{A}\mathbf{B}[\mathbf{x}]_{\mathcal{B}}. \end{aligned}$$

Proposição 4.15 (Matriz de uma transformação em bases gerais). *Se uma transformação linear*

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é representada nas bases canônicas por $\mathbf{A}$, sua matriz em relação à base $\mathcal{B}$ do domínio e à base $\mathcal{C}$ do contradomínio é

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \mathbf{C}^{-1} \mathbf{A} \mathbf{B}.$$

Para todo $\mathbf{x} \in \mathbb{R}^p$,

$$[T(\mathbf{x})]_{\mathcal{C}} = [T]_{\mathcal{C} \leftarrow \mathcal{B}} [\mathbf{x}]_{\mathcal{B}}.$$

(Meyer, 2023)

A sequência das operações, da direita para a esquerda, é:

$$[\mathbf{x}]_{\mathcal{B}} \xrightarrow{\mathbf{B}} \mathbf{x} \xrightarrow{\mathbf{A}} T(\mathbf{x}) \xrightarrow{\mathbf{C}^{-1}} [T(\mathbf{x})]_{\mathcal{C}}.$$

As colunas de

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}}$$

são as coordenadas, na base $\mathcal{C}$, das imagens dos vetores da base $\mathcal{B}$:

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \begin{bmatrix} [T(\mathbf{b}_1)]_{\mathcal{C}} & \cdots & [T(\mathbf{b}_p)]_{\mathcal{C}} \end{bmatrix}.$$

A fórmula $[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \mathbf{C}^{-1} \mathbf{A} \mathbf{B}$ generaliza a representação matricial nas bases canônicas.

Exemplo 4.4 (Representação de uma transformação em bases distintas). Considere

$$T : \mathbb{R}^2 \longrightarrow \mathbb{R}^2$$

representada na base canônica por

$$\mathbf{A} = \begin{bmatrix} 2 & 0 \\ 1 & 1 \end{bmatrix}.$$

Considere a base do domínio

$$\mathcal{B} = \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \end{bmatrix} \right\}$$

e a base do contradomínio

$$\mathcal{C} = \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}.$$

As matrizes das bases são

$$\mathbf{B} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix}$$

e

$$\mathbf{C} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}.$$

Como

$$\mathbf{C}^{-1} = \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix},$$

tem-se

$$\begin{aligned} [T]_{\mathcal{C} \leftarrow \mathcal{B}} &= \mathbf{C}^{-1} \mathbf{A} \mathbf{B} \\ &= \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix} \\ &= \begin{bmatrix} 0 & 1 \\ 2 & 1 \end{bmatrix}. \end{aligned}$$

A primeira coluna é

$$[T(\mathbf{b}_1)]_{\mathcal{C}} = \begin{bmatrix} 0 \\ 2 \end{bmatrix},$$

e a segunda é

$$[T(\mathbf{b}_2)]_{\mathcal{C}} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

4.8.5 Transformação ativa e mudança passiva

Uma matriz pode representar a transformação de um vetor ou a alteração do sistema de coordenadas utilizado para descrevê-lo. Essas operações são relacionadas, mas não são idênticas.

Em uma **transformação ativa**, os eixos coordenados permanecem fixos e o vetor é modificado:

$$\mathbf{y} = \mathbf{Q}\mathbf{x}.$$

No caso de uma rotação, o vetor muda de posição em relação aos mesmos eixos.

Em uma **mudança passiva de coordenadas**, o vetor geométrico permanece fixo e a base é alterada.

Se as colunas de uma matriz ortogonal $\mathbf{Q}$ formam a nova base

$$\mathcal{B} = \{\mathbf{q}_1, \dots, \mathbf{q}_p\},$$

então

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{Q}^{\top} \mathbf{x} = \mathbf{Q}^{-1} \mathbf{x}.$$

Para a matriz de rotação $\mathbf{Q}_{\theta}$,

$$\mathbf{Q}_{\theta}^{-1} = \mathbf{Q}_{\theta}^{\top} = \mathbf{Q}_{(-\theta)}.$$

Girar os eixos pelo ângulo θ transforma as coordenadas do vetor por uma rotação de ângulo $-\theta$.

A transformação ativa e a mudança passiva utilizam matrizes inversas:

$$\text{transformação ativa:} \quad \mathbf{y} = \mathbf{Q}\mathbf{x},$$

$$\text{mudança passiva:} \quad [\mathbf{x}]_{\mathcal{B}} = \mathbf{Q}^{-1} \mathbf{x}.$$

Quando $\mathbf{Q}$ é ortogonal,

$$\mathbf{Q}^{-1} = \mathbf{Q}^{\top}.$$

Portanto, embora uma mesma matriz ortogonal possa aparecer nas duas interpretações, o sentido da operação é distinto: na transformação ativa, $\mathbf{Q}$ atua sobre o vetor; na mudança passiva para a base formada pelas colunas de $\mathbf{Q}$, a conversão das coordenadas é realizada por $\mathbf{Q}^{-1} = \mathbf{Q}^\top$.

A Figura 4.8 compara as duas interpretações.




Figura 4.8: Comparação entre uma transformação ativa e uma mudança passiva de coordenadas.

No primeiro painel, os eixos permanecem fixos e $\mathbf{x}$ é transformado em $\mathbf{Q}\mathbf{x}$. No segundo, o vetor permanece fixo e os novos eixos são definidos por $\mathbf{q}_1$ e $\mathbf{q}_2$.

A mudança passiva $\mathbf{Z} = \mathbf{X}\mathbf{Q}$ deve ser distinguida da transformação ativa por $\mathbf{Q}$, que produz

$$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top.$$

A Tabela 4.5 resume as duas operações.

Tabela 4.5: Transformação ativa e mudança passiva para uma base ortonormal.

Operação	Vetor-coluna	Matriz de dados
Transformação ativa por $\mathbf{Q}$	$\mathbf{y} = \mathbf{Q}\mathbf{x}$	$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top$
Mudança passiva para a base formada pelas colunas de $\mathbf{Q}$	$\mathbf{z} = \mathbf{Q}^\top \mathbf{x}$	$\mathbf{Z} = \mathbf{X}\mathbf{Q}$

Na transformação ativa, a configuração é modificada em relação a um sistema de coordenadas fixo. Na mudança passiva, a configuração permanece a mesma e cada observação passa a ser descrita pelas coordenadas em uma nova base.

4.9 Síntese do capítulo

Uma transformação linear preserva combinações lineares. Para uma transformação

$$T : V \longrightarrow W,$$

tem-se

$$T(\alpha \mathbf{u} + \beta \mathbf{v}) = \alpha T(\mathbf{u}) + \beta T(\mathbf{v}).$$

A linearidade implica, entre outras consequências,

$$T(\mathbf{0}) = \mathbf{0},$$

e determina a transformação linear a partir de sua ação sobre uma base do domínio.

Fixadas as bases do domínio e do contradomínio, uma transformação linear possui uma representação matricial única. Em particular, nas bases canônicas, uma transformação

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é representada por

$$T_{\mathbf{A}}(\mathbf{x}) = \mathbf{Ax}, \quad \mathbf{A} \in \mathbb{R}^{q \times p}.$$

Quando as observações ocupam as linhas de uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a transformação simultânea das observações é

$$\mathbf{Y} = \mathbf{XA}^{\top}.$$

Cada linha de $\mathbf{Y}$ representa uma observação transformada, enquanto cada coluna corresponde a uma combinação linear das variáveis originais.

Para $T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}$, o núcleo e a imagem coincidem com os espaços fundamentais associados a $\mathbf{A}$:

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A})$$

e

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}).$$

Assim, o núcleo reúne os vetores eliminados pela transformação, enquanto a imagem contém todos os vetores que podem ser produzidos por ela. Pelo teorema posto-nulidade,

$$\dim \ker(T_{\mathbf{A}}) + \dim \text{Im}(T_{\mathbf{A}}) = p,$$

ou, equivalentemente,

$$\dim \mathcal{N}(\mathbf{A}) + \text{posto}(\mathbf{A}) = p.$$

O posto é, portanto, a dimensão da imagem da transformação. Quando o núcleo contém vetores não nulos, diferentes vetores do domínio podem possuir a mesma imagem e ocorre perda de informação.

Para uma transformação quadrada, as condições

$$\ker(T_{\mathbf{A}}) = \{\mathbf{0}\},$$

$$\text{Im}(T_{\mathbf{A}}) = \mathbb{R}^p,$$

$$\text{posto}(\mathbf{A}) = p,$$

$$\det(\mathbf{A}) \neq 0$$

e a existência de $\mathbf{A}^{-1}$ são equivalentes.

A composição de transformações corresponde ao produto de suas matrizes. Se T_1 é representada por $\mathbf{A}_1$ e T_2 por $\mathbf{A}_2$, então

$$[T_2 \circ T_1] = \mathbf{A}_2 \mathbf{A}_1.$$

A matriz situada à direita atua primeiro. Como o produto matricial não é comutativo, inverter a ordem pode produzir uma transformação composta diferente.

Rotações e reflexões são transformações ortogonais e preservam a geometria euclidiana. Escalonamentos alteram as escalas das direções coordenadas; cisalhamentos modificam, em geral, ângulos e comprimentos; projeções eliminam componentes pertencentes ao complemento do subespaço sobre o qual se projeta.

As transformações ortogonais são caracterizadas por

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_p.$$

Elas preservam produtos internos e, conseqüentemente, normas, distâncias, ângulos e ortogonalidade. Além disso,

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

As colunas de uma matriz ortogonal formam uma base ortonormal e satisfazem

$$\mathbf{q}_i^\top \mathbf{q}_j = \delta_{ij}.$$

Uma matriz ortogonal pode, portanto, ser usada como matriz de uma base ortonormal.

Se

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_p\}$$

é uma base de $\mathbb{R}^p$ e

$$\mathbf{B} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_p],$$

então

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}$$

e

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{B}^{-1}\mathbf{x}.$$

Se um operador é representado na base canônica por $\mathbf{A}$ e $\mathbf{B}$ é a matriz de uma base de $\mathbb{R}^p$, sua representação nessa base é

$$\mathbf{A}_{\mathcal{B}} = \mathbf{B}^{-1} \mathbf{A} \mathbf{B}.$$

As matrizes $\mathbf{A}$ e $\mathbf{A}_{\mathcal{B}}$ são semelhantes e representam o mesmo operador em sistemas de coordenadas distintos.

Quando as colunas de uma matriz ortogonal $\mathbf{Q}$ formam uma base ortonormal e as observações estão nas linhas de $\mathbf{X}$, a matriz de coordenadas nessa base é

$$\mathbf{Z} = \mathbf{X} \mathbf{Q}.$$

As transformações afins generalizam as transformações lineares por meio da inclusão de uma translação:

$$T(\mathbf{x}) = \mathbf{A} \mathbf{x} + \mathbf{b}.$$

A centralização de uma observação em torno de um vetor fixo é uma transformação afim, enquanto o escalonamento é uma transformação linear diagonal. A padronização combina essas duas operações.

Para uma matriz de dados, a centralização pela média amostral pode ser escrita como

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X},$$

em que

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

Como

$$\mathbf{H}_n^\top = \mathbf{H}_n$$

e

$$\mathbf{H}_n^2 = \mathbf{H}_n,$$

a matriz $\mathbf{H}_n$ é uma matriz de projeção ortogonal. Sua imagem é

$$\mathcal{C}(\mathbf{H}_n) = \text{span}\{\mathbf{1}_n\}^\perp,$$

o subespaço dos vetores cujas componentes somam zero.

A Tabela 4.6 reúne as expressões centrais para transformações lineares, ortogonais e afins e para mudanças de coordenadas.

Tabela 4.6: Expressões centrais para transformações e mudanças de coordenadas.

Objeto ou operação	Expressão	Interpretação
Transformação linear	$T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}$	Preserva combinações lineares
Transformação dos dados	$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top$	Transforma simultaneamente as observações
Núcleo	$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A})$	Reúne os vetores enviados ao vetor nulo
Imagem	$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})$	Reúne os vetores alcançados pela transformação
Composição	$(T_2 \circ T_1)(\mathbf{x}) = \mathbf{A}_2\mathbf{A}_1\mathbf{x}$	Aplica T_1 antes de T_2
Transformação inversa	$\mathbf{x} = \mathbf{A}^{-1}\mathbf{y}$	Recupera o vetor original quando $\mathbf{A}$ é invertível
Rotação	$\mathbf{Q}_\theta\mathbf{x}$	Preserva a geometria e a orientação
Reflexão	$\mathbf{F}\mathbf{x}$	Preserva a geometria e produz uma imagem especular
Escalonamento	$\mathbf{L}\mathbf{x}$	Reescala direções coordenadas
Cisalhamento	$\mathbf{C}_{ij}(k)\mathbf{x}$	Inclina a configuração preservando volume no caso elementar
Projeção ortogonal	$\mathbf{P}_S\mathbf{x}$	Mantém a componente em S e elimina a componente em $S^\perp$
Coordenadas em uma base	$[\mathbf{x}]_{\mathcal{B}} = \mathbf{B}^{-1}\mathbf{x}$	Representa o mesmo vetor na base $\mathcal{B}$
Operador em uma nova base	$\mathbf{A}_{\mathcal{B}} = \mathbf{B}^{-1}\mathbf{A}\mathbf{B}$	Representa o mesmo operador em outro sistema de coordenadas
Coordenadas dos dados em base ortonormal	$\mathbf{Z} = \mathbf{X}\mathbf{Q}$	Expressa as observações nas coordenadas da base formada pelas colunas de $\mathbf{Q}$
Transformação afim	$\mathbf{A}\mathbf{x} + \mathbf{b}$	Combina transformação linear e translação

Objeto ou operação	Expressão	Interpretação
Centralização dos dados	$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}$	Projeta cada variável no subespaço de média zero
Padronização	$\mathbf{L}^{-1}(\mathbf{x} - \mathbf{m})$	Ajusta localização e escala

Ao final deste capítulo, o estudante deverá ser capaz de:

- reconhecer e verificar a linearidade de uma transformação;
- construir a matriz de uma transformação a partir da imagem de uma base;
- relacionar núcleo e imagem de uma transformação ao espaço nulo e ao espaço coluna da matriz associada;
- interpretar posto, injetividade, sobrejetividade, bijetividade e perda de informação;
- representar a composição e a inversão de transformações por operações matriciais;
- interpretar geometricamente rotações, reflexões, escalonamentos, cisalhamentos e projeções;
- reconhecer transformações ortogonais e interpretar as propriedades geométricas que elas preservam;
- representar vetores por coordenadas em uma base;
- representar o mesmo operador linear em uma nova base e reconhecer matrizes semelhantes;
- obter as coordenadas de uma matriz de dados em uma base ortonormal;
- interpretar transformações afins, centralização, escalonamento e padronização;
- reconhecer a matriz de centralização como uma matriz de projeção ortogonal.

Uma direção não nula $\mathbf{v}$ que satisfaz

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

é preservada pela transformação, exceto pelo fator de escala λ . Essa condição introduz os conceitos de autovetores, autovalores, autoespaços e decomposição espectral.

5 Autovalores, autovetores e decomposição espectral

Uma transformação linear com domínio e contradomínio iguais é um operador linear. Em $\mathbb{R}^p$, considere o operador

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^p, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

representado por uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Pela Proposição 4.15, a representação matricial de um operador depende da base escolhida. Uma base formada por direções invariantes pode transformar essa representação em uma matriz diagonal.

Uma direção gerada por um vetor não nulo $\mathbf{v}$ é invariante quando $\mathbf{A}\mathbf{v}$ permanece na reta gerada por $\mathbf{v}$. Essa condição define autovalores, autovetores e autoespaços.

Quando existe uma base de autovetores, a matriz do operador é diagonal nessa base. Para matrizes simétricas reais, o Teorema Espectral garante uma base ortonormal de autovetores e uma diagonalização ortogonal. A decomposição espectral sustenta a análise de formas quadráticas, positividade, elipsoides, funções de matrizes e problemas de otimização presentes em covariâncias, ACP, MANOVA e análise discriminante.

Convenções de notação

Adota-se a seguinte notação:

- λ representa um autovalor;
- $\mathbf{v}$ representa um autovetor;
- $\mathcal{E}_{\lambda}$ representa o autoespaço associado a λ ;
- $m_a(\lambda)$ e $m_g(\lambda)$ representam, respectivamente, as multiplicidades algébrica e geométrica;
- $\mathcal{B}_{\mathbf{A}}$ representa uma base de autovetores de $\mathbf{A}$, quando tal base existe;
- $\mathbf{B}_{\mathbf{A}}$ representa a matriz formada pelos vetores da base $\mathcal{B}_{\mathbf{A}}$;
- $\Lambda_{\mathbf{A}}$ representa a matriz diagonal dos autovalores correspondente à ordenação esco-

- $\mathbf{Q}_{\mathbf{A}}$ representa uma matriz ortogonal de autovetores quando $\mathbf{A}$ é simétrica;
- Π_{λ} representa o projetor espectral associado ao autoespaço de λ ;
- $\mathcal{R}_{\mathbf{A}}(\mathbf{x})$ representa o quociente de Rayleigh.

Salvo indicação contrária, as interpretações geométricas referem-se a espaços vetoriais reais. Autovalores e autovetores complexos aparecem apenas quando explicitamente indicados.

5.1 Direções invariantes, autovalores e autoespaços

Uma direção determinada por um vetor não nulo $\mathbf{v}$ é preservada por $\mathbf{A}$ quando a imagem $\mathbf{A}\mathbf{v}$ permanece na reta gerada por $\mathbf{v}$. Nesse caso, existe um escalar λ tal que

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

A condição $\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$ define autovalores e autovetores.

Definição 5.1 (Autovalor e autovetor). Seja

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Um escalar $\lambda \in \mathbb{R}$ é um **autovalor** de $\mathbf{A}$ quando existe um vetor

$$\mathbf{v} \in \mathbb{R}^p, \quad \mathbf{v} \neq \mathbf{0},$$

tal que

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

O vetor $\mathbf{v}$ é denominado **autovetor** de $\mathbf{A}$ associado ao autovalor λ . O par $(\lambda, \mathbf{v})$ é denominado **autopar** de $\mathbf{A}$.

A equação

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

mostra que a transformação não combina a direção de $\mathbf{v}$ com outras direções do espaço. Sua ação sobre esse vetor consiste em alterar seu comprimento e, possivelmente, seu sentido.

O módulo de λ determina a alteração do comprimento:

- se $|\lambda| > 1$, ocorre expansão;
- se $0 < |\lambda| < 1$, ocorre contração;
- se $|\lambda| = 1$, o comprimento é preservado;
- se $\lambda = 0$, o vetor é transformado no vetor nulo.

O sinal determina o sentido:

- se $\lambda > 0$, o sentido é preservado;
- se $\lambda < 0$, o sentido é invertido.

Portanto, quando $\lambda = -1$, o vetor tem seu sentido invertido sem alteração do comprimento. Quando $\lambda = 0$, a reta gerada pelo autovetor continua sendo um subespaço invariante, pois toda a reta é enviada ao vetor nulo, mas sua direção deixa de aparecer na imagem da transformação.

Exemplo 5.1 (Direções invariantes de uma matriz simétrica). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Para o vetor

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

tem-se

$$\begin{aligned} \mathbf{A}\mathbf{v}_1 &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ &= \begin{bmatrix} 4 \\ 4 \end{bmatrix} \\ &= 4 \begin{bmatrix} 1 \\ 1 \end{bmatrix}. \end{aligned}$$

Assim,

$$\mathbf{A}\mathbf{v}_1 = 4\mathbf{v}_1,$$

e $\mathbf{v}_1$ é um autovetor associado ao autovalor

$$\lambda_1 = 4.$$

Para

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

obtém-se

$$\begin{aligned} \mathbf{A}\mathbf{v}_2 &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\ &= \begin{bmatrix} 2 \\ -2 \end{bmatrix} \\ &= 2 \begin{bmatrix} 1 \\ -1 \end{bmatrix}. \end{aligned}$$

Portanto,

$$\mathbf{A}\mathbf{v}_2 = 2\mathbf{v}_2,$$

e $\mathbf{v}_2$ é um autovetor associado ao autovalor

$$\lambda_2 = 2.$$

Considere agora

$$\mathbf{x} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Sua imagem é

$$\mathbf{A}\mathbf{x} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

Não existe um escalar λ que satisfaça

$$\begin{bmatrix} 3 \\ 1 \end{bmatrix} = \lambda \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Logo, $\mathbf{x}$ não é um autovetor de $\mathbf{A}$. A transformação modifica seu comprimento e sua direção.

A Figura 5.1 compara as imagens dos autovetores $\mathbf{v}_1$ e $\mathbf{v}_2$ com a imagem do vetor genérico $\mathbf{x}$. As retas tracejadas em cinza representam as duas direções invariantes.




Figura 5.1: Autovetores permanecem nas mesmas direções após a transformação, enquanto um vetor genérico pode ter sua direção modificada.

As retas tracejadas representam as direções geradas por $\mathbf{v}_1$ e $\mathbf{v}_2$. A transformação amplia os vetores por fatores diferentes, mas mantém cada um na reta correspondente. O vetor $\mathbf{x}$ não pertence a uma direção invariante e sua imagem ocupa outra direção.

Um autovetor não é único. Se $\mathbf{v}$ é um autovetor associado ao autovalor λ , então qualquer múltiplo não nulo de $\mathbf{v}$ também é um autovetor associado ao mesmo autovalor.

Proposição 5.1 (Múltiplos de um autovetor). *Se $\mathbf{v}$ é um autovetor de $\mathbf{A}$ associado ao autovalor λ , então todo múltiplo*

$$c\mathbf{v}, \quad c \neq 0,$$

também é um autovetor associado a λ .

i Demonstração

Como

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v},$$

pela linearidade,

$$\begin{aligned}\mathbf{A}(c\mathbf{v}) &= c\mathbf{A}\mathbf{v} \\ &= c\lambda\mathbf{v} \\ &= \lambda(c\mathbf{v}).\end{aligned}$$

Como $c \neq 0$ e $\mathbf{v} \neq \mathbf{0}$, tem-se $c\mathbf{v} \neq \mathbf{0}$. Portanto, $c\mathbf{v}$ é um autovetor associado a λ .

Para reunir todos os autovetores associados ao mesmo autovalor, reorganiza-se a equação

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

como

$$(\mathbf{A} - \lambda\mathbf{I}_p)\mathbf{v} = \mathbf{0}.$$

O conjunto de soluções é o núcleo de

$$\mathbf{A} - \lambda\mathbf{I}_p.$$

Definição 5.2 (Autoespaço). Se λ é um autovalor de

$$\mathbf{A} \in \mathbb{R}^{p \times p},$$

o **autoespaço** associado a λ é

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p).$$

Os autovetores associados a λ são os elementos não nulos de $\mathcal{E}_\lambda$:

$$\mathcal{E}_\lambda \setminus \{\mathbf{0}\}.$$

O vetor nulo pertence a todo autoespaço, mas não é considerado um autovetor. A igualdade

$$\mathbf{A}\mathbf{0} = \lambda\mathbf{0}$$

é satisfeita para qualquer λ e não identifica uma direção.

Proposição 5.2 (Estrutura e invariância do autoespaço). *Se λ é um autovalor de $\mathbf{A}$, então $\mathcal{E}_\lambda$ é um subespaço não trivial de $\mathbb{R}^p$ e é invariante sob $\mathbf{A}$.*

i Demonstração

Como

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p),$$

o autoespaço é o núcleo de uma transformação linear e, portanto, é um subespaço de $\mathbb{R}^p$.

Como λ é um autovalor, existe pelo menos um vetor não nulo $\mathbf{v}$ tal que

$$(\mathbf{A} - \lambda\mathbf{I}_p)\mathbf{v} = \mathbf{0}.$$

Logo,

$$\mathcal{E}_\lambda \neq \{\mathbf{0}\}.$$

Para qualquer $\mathbf{w} \in \mathcal{E}_\lambda$,

$$\mathbf{A}\mathbf{w} = \lambda\mathbf{w}.$$

Como $\mathcal{E}_\lambda$ é fechado pela multiplicação por escalares,

$$\lambda\mathbf{w} \in \mathcal{E}_\lambda.$$

Portanto,

$$\mathbf{A}\mathbf{w} \in \mathcal{E}_\lambda,$$

e o autoespaço é invariante sob $\mathbf{A}$.

Quando

$$\dim(\mathcal{E}_\lambda) = 1,$$

o autoespaço determina uma única direção invariante. Todos os autovetores associados a λ são múltiplos não nulos de um mesmo vetor.

Quando

$$\dim(\mathcal{E}_\lambda) > 1,$$

o autovalor está associado a várias direções linearmente independentes. Nesse caso, o objeto geométrico determinado pela matriz é todo o autoespaço. Uma base específica desse subespaço não é necessariamente única.

A definição do autoespaço transforma a busca por autovetores em um problema de núcleo. Para um valor fixado de λ , existem autovetores associados precisamente quando

$$\mathcal{N}(\mathbf{A} - \lambda \mathbf{I}_p) \neq \{\mathbf{0}\}.$$

Resta, portanto, determinar quais valores de λ tornam esse núcleo não trivial. Essa condição equivale à singularidade de $\mathbf{A} - \lambda \mathbf{I}_p$ e conduz à equação característica.

5.2 Equação característica e diagonalização

A definição de autovalor permite verificar se um vetor conhecido determina uma direção invariante. Para encontrar essas direções a partir de uma matriz, é necessário determinar os valores de λ para os quais

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}$$

possui soluções não triviais.

Esse é um sistema linear homogêneo.

Se

$$\mathbf{A} - \lambda \mathbf{I}_p$$

fosse invertível, sua única solução seria $\mathbf{v} = \mathbf{0}$. Portanto, um autovalor deve tornar essa matriz singular.

Teorema 5.1 (Caracterização dos autovalores pelo determinante). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Um escalar $\lambda \in \mathbb{R}$ é autovalor de $\mathbf{A}$ se, e somente se,

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0.$$

i Demonstração

Se λ é autovalor de $\mathbf{A}$, existe um vetor não nulo $\mathbf{v}$ tal que

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}.$$

Como o sistema possui uma solução não trivial, a matriz

$$\mathbf{A} - \lambda \mathbf{I}_p$$

não é invertível. Logo,

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0.$$

Reciprocamente, se

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0,$$

a matriz é singular. Portanto, seu núcleo contém pelo menos um vetor não nulo $\mathbf{v}$, para o qual

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}.$$

Consequentemente,

$$\mathbf{A} \mathbf{v} = \lambda \mathbf{v},$$

e λ é autovalor de $\mathbf{A}$.

Definição 5.3 (Polinômio e equação característicos). O **polinômio característico** de uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é definido por

$$p_{\mathbf{A}}(\lambda) = \det (\mathbf{A} - \lambda \mathbf{I}_p) .$$

A equação

$$p_{\mathbf{A}}(\lambda) = 0$$

é denominada **equação característica** de $\mathbf{A}$. (Searle; Khuri, 2017)

Também é possível definir o polinômio característico por

$$\det (\lambda \mathbf{I}_p - \mathbf{A}) .$$

As duas convenções diferem pelo fator $(-1)^p$ e possuem as mesmas raízes. Portanto, produzem os mesmos autovalores.

O polinômio característico de uma matriz de ordem p possui grau p . Contando as raízes repetidas, ele possui p raízes no conjunto dos números complexos. Uma matriz real pode ter autovalores reais, autovalores complexos ou ambos.

5.2.1 Determinação dos autovalores e autoespaços

Considere novamente

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} .$$

Tem-se

$$\mathbf{A} - \lambda \mathbf{I}_2 = \begin{bmatrix} 3 - \lambda & 1 \\ 1 & 3 - \lambda \end{bmatrix} .$$

O polinômio característico é

$$\begin{aligned} p_{\mathbf{A}}(\lambda) &= \det \begin{bmatrix} 3 - \lambda & 1 \\ 1 & 3 - \lambda \end{bmatrix} \\ &= (3 - \lambda)^2 - 1 \\ &= \lambda^2 - 6\lambda + 8 \\ &= (\lambda - 4)(\lambda - 2) . \end{aligned}$$

Assim, os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Para determinar o autoespaço associado a $\lambda_1 = 4$, resolve-se

$$(\mathbf{A} - 4\mathbf{I}_2) \mathbf{v} = \mathbf{0}.$$

Como

$$\mathbf{A} - 4\mathbf{I}_2 = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix},$$

o sistema conduz a

$$-v_1 + v_2 = 0,$$

ou seja,

$$v_2 = v_1.$$

Portanto,

$$\mathcal{E}_4 = \text{span} \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}.$$

Para $\lambda_2 = 2$,

$$\mathbf{A} - 2\mathbf{I}_2 = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix},$$

e o sistema correspondente fornece

$$v_1 + v_2 = 0.$$

Logo,

$$\mathcal{E}_2 = \text{span} \left\{ \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}.$$

O procedimento possui duas etapas:

1. resolver

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0$$

para obter os autovalores;

2. para cada autovalor λ , determinar

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda \mathbf{I}_p).$$

5.2.2 Diagonalização

Pela Proposição 4.15, a representação matricial de um operador depende das bases escolhidas. A diagonalização corresponde à escolha de uma base formada por autovetores.

Considere uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e suponha que exista uma base de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$,

$$\mathcal{B}_\mathbf{A} = \{\mathbf{v}_1, \dots, \mathbf{v}_p\}.$$

A matriz dessa base é

$$\mathbf{B}_\mathbf{A} = [\mathbf{v}_1 \quad \dots \quad \mathbf{v}_p].$$

Como os vetores da base são linearmente independentes, $\mathbf{B}_\mathbf{A}$ é invertível.

Se

$$\mathbf{A}\mathbf{v}_j = \lambda_j \mathbf{v}_j, \quad j = 1, \dots, p,$$

e

$$\Lambda_\mathbf{A} = \text{diag}(\lambda_1, \dots, \lambda_p),$$

então

$$\mathbf{A}\mathbf{B}_\mathbf{A} = \mathbf{B}_\mathbf{A}\Lambda_\mathbf{A}.$$

Multiplicando à esquerda por $\mathbf{B}_{\mathbf{A}}^{-1}$,

$$\mathbf{B}_{\mathbf{A}}^{-1}\mathbf{A}\mathbf{B}_{\mathbf{A}} = \Lambda_{\mathbf{A}}.$$

Definição 5.4 (Matriz diagonalizável). Uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é **diagonalizável sobre** $\mathbb{R}$ quando existe uma base $\mathcal{B}_{\mathbf{A}}$ de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$.

Equivalentemente, existem uma matriz invertível $\mathbf{B}_{\mathbf{A}}$ e uma matriz diagonal $\Lambda_{\mathbf{A}}$ tais que

$$\mathbf{A} = \mathbf{B}_{\mathbf{A}}\Lambda_{\mathbf{A}}\mathbf{B}_{\mathbf{A}}^{-1}.$$

A ordem das colunas de $\mathbf{B}_{\mathbf{A}}$ deve coincidir com a ordem dos autovalores em $\Lambda_{\mathbf{A}}$.

Pela Proposição 4.15,

$$[T_{\mathbf{A}}]_{\mathcal{B}_{\mathbf{A}} \leftarrow \mathcal{B}_{\mathbf{A}}} = \mathbf{B}_{\mathbf{A}}^{-1}\mathbf{A}\mathbf{B}_{\mathbf{A}} = \Lambda_{\mathbf{A}}.$$

Assim, $\Lambda_{\mathbf{A}}$ é a matriz do mesmo operador quando tanto o domínio quanto o contradomínio são representados na base de autovetores.

Para qualquer vetor $\mathbf{x} \in \mathbb{R}^p$, suas coordenadas nessa base são

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}} = \mathbf{B}_{\mathbf{A}}^{-1}\mathbf{x},$$

de modo que

$$\mathbf{x} = \mathbf{B}_{\mathbf{A}}\mathbf{z}.$$

Nas coordenadas da base de autovetores,

$$[T_{\mathbf{A}}(\mathbf{x})]_{\mathcal{B}_{\mathbf{A}}} = \Lambda_{\mathbf{A}}[\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}}.$$

Como

$$\Lambda_{\mathbf{A}}\mathbf{z} = \begin{bmatrix} \lambda_1 z_1 \\ \vdots \\ \lambda_p z_p \end{bmatrix},$$

a transformação atua separadamente sobre cada coordenada: a componente correspondente ao autovetor $\mathbf{v}_j$ é multiplicada por λ_j .

A diagonalização é, portanto, uma mudança para um sistema de coordenadas no qual as direções da base são invariantes e a ação do operador deixa de misturar coordenadas.

5.3 Matrizes simétricas e decomposição espectral

A diagonalização pode falhar para matrizes quadradas arbitrárias: uma matriz pode não possuir autovalores reais ou autovetores linearmente independentes em número suficiente para formar uma base.

Pela Definição 2.7, uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é simétrica quando

$$\mathbf{A}^\top = \mathbf{A}.$$

Para essa classe de matrizes, todos os autovalores são reais e os autoespaços associados a autovalores distintos são ortogonais. Como consequência, existe uma base ortonormal de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$.

Teorema 5.2 (Teorema Espectral para matrizes simétricas reais). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

uma matriz simétrica. Então:

- 1. todos os autovalores de $\mathbf{A}$ são reais;*
- 2. autoespaços associados a autovalores distintos são ortogonais;*
- 3. existe uma base ortonormal de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$;*
- 4. existe uma matriz ortogonal*

$$\mathbf{Q}_\mathbf{A} \in \mathbb{R}^{p \times p}$$

e uma matriz diagonal

$$\Lambda_{\mathbf{A}} \in \mathbb{R}^{p \times p}$$

tais que

$$\mathbf{A} = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^{\top}.$$

(Eaton, 2007)



A representação

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top$$

é denominada **decomposição espectral** de $\mathbf{A}$. Ela é uma diagonalização ortogonal.

Considere a base ortonormal de autovetores

$$\mathcal{B}_\mathbf{A} = \{\mathbf{q}_1, \dots, \mathbf{q}_p\}.$$

A matriz dessa base é

$$\mathbf{Q}_\mathbf{A} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p].$$

Pelo Teorema 5.2, no caso simétrico a matriz da base de autovetores pode ser escolhida ortogonal:

$$\mathbf{B}_\mathbf{A} = \mathbf{Q}_\mathbf{A},$$

com

$$\mathbf{Q}_\mathbf{A}^{-1} = \mathbf{Q}_\mathbf{A}^\top.$$

Como $\mathbf{Q}_\mathbf{A}^{-1} = \mathbf{Q}_\mathbf{A}^\top$, as coordenadas definidas na Definição 3.6 são

$$[\mathbf{x}]_{\mathcal{B}_\mathbf{A}} = \mathbf{Q}_\mathbf{A}^\top \mathbf{x}.$$

Denotando

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_\mathbf{A}},$$

tem-se

$$\mathbf{x} = \mathbf{Q}_\mathbf{A} \mathbf{z}.$$

A matriz do operador nessa base é

$$[T_\mathbf{A}]_{\mathcal{B}_\mathbf{A} \leftarrow \mathcal{B}_\mathbf{A}} = \mathbf{Q}_\mathbf{A}^\top \mathbf{A} \mathbf{Q}_\mathbf{A} = \Lambda_\mathbf{A}.$$

Consequentemente,

$$[T_{\mathbf{A}}(\mathbf{x})]_{\mathcal{B}_{\mathbf{A}}} = \Lambda_{\mathbf{A}}[\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}}.$$

Em coordenadas canônicas,

$$\begin{aligned}\mathbf{Ax} &= \mathbf{Q}_{\mathbf{A}}\Lambda_{\mathbf{A}}\mathbf{Q}_{\mathbf{A}}^{\top}\mathbf{x} \\ &= \mathbf{Q}_{\mathbf{A}}\Lambda_{\mathbf{A}}\mathbf{z}.\end{aligned}$$

A ação da matriz pode ser interpretada em três etapas:

1. $\mathbf{Q}_{\mathbf{A}}^{\top}$ converte o vetor para as coordenadas da base ortonormal de autovetores;
2. $\Lambda_{\mathbf{A}}$ multiplica separadamente cada coordenada pelo autovalor correspondente;
3. $\mathbf{Q}_{\mathbf{A}}$ reconstrói o vetor nas coordenadas canônicas.

Assim, uma matriz simétrica atua por fatores escalares independentes em direções ortogonais. Quando algum autovalor é negativo, o escalonamento na direção correspondente inclui também a inversão do sentido.

5.3.1 Decomposição espectral do exemplo condutor

Exemplo 5.2 (Decomposição espectral de uma matriz simétrica). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Os autovetores

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

são ortogonais, pois

$$\mathbf{v}_1^\top \mathbf{v}_2 = 0.$$

Normalizando-os, obtêm-se

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Portanto,

$$\mathcal{B}_{\mathbf{A}} = \{\mathbf{q}_1, \mathbf{q}_2\}$$

é uma base ortonormal de autovetores de $\mathbb{R}^2$.

A matriz dessa base é a matriz ortogonal

$$\mathbf{Q}_{\mathbf{A}} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix},$$

e a matriz diagonal de autovalores é

$$\Lambda_{\mathbf{A}} = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}.$$

Consequentemente,

$$\mathbf{A} = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^\top.$$

De fato,

$$\begin{aligned} \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^\top &= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}. \end{aligned}$$

Na direção de $\mathbf{q}_1$, a transformação multiplica o comprimento por 4. Na direção ortogonal $\mathbf{q}_2$, multiplica o comprimento por 2.

A Figura 5.2 mostra a circunferência unitária em $\mathbb{R}^2$ e sua imagem pela matriz $\mathbf{A}$. Como os dois autovalores são positivos, a imagem é uma elipse cujos semieixos possuem comprimentos 4 e 2 e estão alinhados aos autovetores.




Figura 5.2: A decomposição espectral identifica as direções ortogonais nas quais uma matriz simétrica atua por fatores escalares independentes.

Na base canônica, a ação da matriz combina as duas coordenadas. Na base formada por $\mathbf{q}_1$ e $\mathbf{q}_2$, a transformação apenas multiplica as coordenadas por 4 e 2.

Para uma matriz simétrica arbitrária, os comprimentos dos semieixos da imagem da esfera unitária em $\mathbb{R}^p$ são determinados por

$$|\lambda_1|, \dots, |\lambda_p|.$$

Autovalores negativos também invertem o sentido ao longo das direções correspondentes. Autovalores nulos colapsam os respectivos eixos, reduzindo a dimensão da imagem.

5.3.2 Forma aditiva da decomposição espectral

Como

$$\mathbf{Q}_A = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p]$$

e

$$\Lambda_{\mathbf{A}} = \text{diag}(\lambda_1, \dots, \lambda_p),$$

a decomposição espectral também pode ser escrita como

$$\mathbf{A} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^\top.$$

Cada matriz

$$\mathbf{q}_j \mathbf{q}_j^\top$$

é o projetor ortogonal sobre a reta gerada por $\mathbf{q}_j$. Assim,

$$\mathbf{A}\mathbf{x} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^\top \mathbf{x}.$$

A transformação pode ser interpretada como:

1. projetar $\mathbf{x}$ sobre cada direção espectral;
2. multiplicar cada projeção pelo autovalor correspondente;
3. somar as parcelas resultantes.

No exemplo,

$$\mathbf{A} = 4\mathbf{q}_1 \mathbf{q}_1^\top + 2\mathbf{q}_2 \mathbf{q}_2^\top.$$

5.3.3 Projetores sobre autoespaços

Quando um autovalor é repetido e seu autoespaço possui dimensão maior que 1, os autovetores individuais associados a ele não são únicos. O autoespaço, entretanto, é determinado pela matriz.

Considere os autovalores distintos

$$\lambda^{(1)}, \dots, \lambda^{(s)}$$

de $\mathbf{A}$. Para cada autovalor $\lambda^{(h)}$, seja

$$\mathbf{Q}_h$$

uma matriz cujas colunas formam uma base ortonormal do autoespaço correspondente.

Define-se o projetor espectral

$$\Pi_{\lambda^{(h)}} = \mathbf{Q}_h \mathbf{Q}_h^\top.$$

Esse projetor não depende da base ortonormal escolhida dentro do autoespaço.

Proposição 5.3 (Decomposição por projetores espectrais). *Se $\mathbf{A}$ é simétrica e possui autovalores distintos*

$$\lambda^{(1)}, \dots, \lambda^{(s)},$$

então

$$\mathbf{A} = \sum_{h=1}^s \lambda^{(h)} \Pi_{\lambda^{(h)}}.$$

Além disso,

$$\Pi_{\lambda^{(h)}}^\top = \Pi_{\lambda^{(h)}},$$

$$\Pi_{\lambda^{(h)}}^2 = \Pi_{\lambda^{(h)}},$$

$$\Pi_{\lambda^{(h)}} \Pi_{\lambda^{(\ell)}} = \mathbf{0}, \quad h \neq \ell,$$

e

$$\sum_{h=1}^s \Pi_{\lambda^{(h)}} = \mathbf{I}_p.$$

(Gentle, 2017)

i Demonstração

As colunas de $\mathbf{Q}_h$ são ortonormais. Portanto,

$$\Pi_{\lambda^{(h)}} = \mathbf{Q}_h \mathbf{Q}_h^\top$$

é o projetor ortogonal sobre o autoespaço associado a $\lambda^{(h)}$. Pela Proposição 3.16, ele é simétrico e idempotente.

Autoespaços associados a autovalores distintos são ortogonais. Logo,

$$\mathbf{Q}_h^\top \mathbf{Q}_\ell = \mathbf{0}$$

para $h \neq \ell$, e

$$\begin{aligned} \Pi_{\lambda^{(h)}} \Pi_{\lambda^{(\ell)}} &= \mathbf{Q}_h \mathbf{Q}_h^\top \mathbf{Q}_\ell \mathbf{Q}_\ell^\top \\ &= \mathbf{0}. \end{aligned}$$

A soma direta ortogonal de todos os autoespaços é $\mathbb{R}^p$. Por isso,

$$\sum_{h=1}^s \Pi_{\lambda^{(h)}} = \mathbf{I}_p.$$

Agrupando na decomposição espectral todos os autovetores associados ao mesmo autovalor,

$$\mathbf{A} = \sum_{h=1}^s \lambda^{(h)} \Pi_{\lambda^{(h)}}.$$

A decomposição por projetores separa o que depende de uma escolha de base do que é determinado pelo operador. Quando um autovalor é simples, o projetor correspondente possui posto 1:

$$\Pi_\lambda = \mathbf{q} \mathbf{q}^\top.$$

Quando o autoespaço possui dimensão maior que 1, o projetor representa todo o autoespaço e possui posto igual à sua dimensão.

5.3.4 Não unicidade da matriz de autovetores

A matriz

$$\mathbf{Q}_A$$

não é necessariamente única.

Mesmo quando todos os autovalores são distintos, cada autovetor pode ser substituído por seu oposto:

$$\mathbf{q}_j \mapsto -\mathbf{q}_j.$$

A ordem dos autovetores também pode ser alterada, desde que a mesma alteração seja aplicada aos autovalores em

$$\Lambda_{\mathbf{A}}.$$

Quando há autovalores repetidos, qualquer base ortonormal do autoespaço correspondente pode ser utilizada.

Essas alterações não modificam a matriz original nem os projetores espectrais. O sinal, a ordem e a base escolhida dentro de um autoespaço são elementos da representação; os autovalores, os autoespaços e seus projetores são propriedades do operador.

A decomposição espectral fornece uma base ortonormal na qual formas quadráticas, determinantes, traços, postos, inversas e superfícies de nível podem ser analisados diretamente a partir dos autovalores.

5.4 Consequências da decomposição espectral

Considere uma matriz simétrica

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

com decomposição espectral

$$\mathbf{A} = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^{\top},$$

em que

$$\mathbf{Q}_{\mathbf{A}} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p]$$

é ortogonal e

$$\Lambda_{\mathbf{A}} = \text{diag}(\lambda_1, \dots, \lambda_p).$$

A representação diagonal permite obter propriedades da matriz diretamente de seus autovalores e autoespaços.

5.4.1 Traço, determinante, posto e invertibilidade

Proposição 5.4 (Consequências espectrais básicas). *Se $\mathbf{A} \in \mathbb{R}^{p \times p}$ é simétrica e possui autovalores*

$$\lambda_1, \dots, \lambda_p,$$

listados com repetição quando necessário, então:

$$\text{tr}(\mathbf{A}) = \sum_{j=1}^p \lambda_j,$$

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j,$$

$$\text{posto}(\mathbf{A}) = \# \{j : \lambda_j \neq 0\},$$

e

$$\dim \mathcal{N}(\mathbf{A}) = \# \{j : \lambda_j = 0\}.$$

Além disso,

$$\mathbf{A} \text{ é invertível} \iff \lambda_j \neq 0 \text{ para todo } j.$$

i Demonstração

Pela propriedade cíclica do traço,

$$\begin{aligned}\operatorname{tr}(\mathbf{A}) &= \operatorname{tr}(\mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top) \\ &= \operatorname{tr}(\Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top \mathbf{Q}_\mathbf{A}) \\ &= \operatorname{tr}(\Lambda_\mathbf{A}) \\ &= \sum_{j=1}^p \lambda_j.\end{aligned}$$

Para o determinante,

$$\begin{aligned}\det(\mathbf{A}) &= \det(\mathbf{Q}_\mathbf{A}) \det(\Lambda_\mathbf{A}) \det(\mathbf{Q}_\mathbf{A}^\top) \\ &= \det(\Lambda_\mathbf{A}),\end{aligned}$$

pois

$$\det(\mathbf{Q}_\mathbf{A}) \det(\mathbf{Q}_\mathbf{A}^\top) = \det(\mathbf{I}_p) = 1.$$

Como $\Lambda_\mathbf{A}$ é diagonal,

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j.$$

As matrizes $\mathbf{A}$ e $\Lambda_\mathbf{A}$ são semelhantes, pois

$$\Lambda_\mathbf{A} = \mathbf{Q}_\mathbf{A}^\top \mathbf{A} \mathbf{Q}_\mathbf{A}.$$

Como a multiplicação à esquerda e à direita por matrizes invertíveis preserva o posto, $\mathbf{A}$ e $\Lambda_\mathbf{A}$ possuem o mesmo posto. O posto de uma matriz diagonal é igual ao número de elementos diagonais não nulos. Portanto,

$$\operatorname{posto}(\mathbf{A}) = \#\{j : \lambda_j \neq 0\}.$$

Pelo Teorema Posto–Nulidade,

$$\begin{aligned}\dim \mathcal{N}(\mathbf{A}) &= p - \operatorname{posto}(\mathbf{A}) \\ &= \#\{j : \lambda_j = 0\}.\end{aligned}$$

Por fim, $\mathbf{A}$ é invertível se, e somente se, seu determinante é diferente de zero. Como

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j,$$

isso ocorre exatamente quando todos os autovalores são não nulos.

5.4.2 Formas quadráticas em coordenadas espectrais

Considere a forma quadrática definida na Definição 2.17,

$$q_{\mathbf{A}}(\mathbf{x}) = \mathbf{x}^{\top} \mathbf{A} \mathbf{x}.$$

As coordenadas de $\mathbf{x}$ na base espectral são

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}} = \mathbf{Q}_{\mathbf{A}}^{\top} \mathbf{x}.$$

Como

$$\mathbf{x} = \mathbf{Q}_{\mathbf{A}} \mathbf{z},$$

tem-se

$$\begin{aligned} q_{\mathbf{A}}(\mathbf{x}) &= \mathbf{x}^{\top} \mathbf{A} \mathbf{x} \\ &= \mathbf{z}^{\top} \mathbf{Q}_{\mathbf{A}}^{\top} \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^{\top} \mathbf{Q}_{\mathbf{A}} \mathbf{z} \\ &= \mathbf{z}^{\top} \Lambda_{\mathbf{A}} \mathbf{z} \\ &= \sum_{j=1}^p \lambda_j z_j^2. \end{aligned}$$

A mudança ortogonal de coordenadas elimina os produtos cruzados. A contribuição da direção $\mathbf{q}_j$ para a forma quadrática é

$$\lambda_j z_j^2.$$

As possibilidades de sinal da forma quadrática são determinadas pelos sinais dos autovalores, enquanto o valor assumido para um vetor específico depende também de suas coordenadas espectrais $z_1, \dots, z_p$.

Exemplo 5.3 (Forma quadrática em coordenadas espectrais). Considere a matriz simétrica

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.$$

Seus autovalores são

$$\lambda_1 = 3 \quad \text{e} \quad \lambda_2 = 1,$$

com autovetores ortonormais associados

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Portanto,

$$\mathbf{Q}_A = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

e

$$\Lambda_A = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}.$$

A decomposição espectral de $\mathbf{A}$ é

$$\mathbf{A} = \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top.$$

Considere agora o vetor

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

Nas coordenadas originais, a forma quadrática é

$$\begin{aligned} q_A(\mathbf{x}) &= \mathbf{x}^\top \mathbf{A} \mathbf{x} \\ &= \begin{bmatrix} 2 & 1 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 1 \end{bmatrix} \begin{bmatrix} 5 \\ 4 \end{bmatrix} \\ &= 14. \end{aligned}$$

Equivalentemente, escrevendo a forma quadrática em função das coordenadas originais,

$$q_A(\mathbf{x}) = 2x_1^2 + 2x_1x_2 + 2x_2^2.$$

Observe a presença do produto cruzado $2x_1x_2$.

As coordenadas de $\mathbf{x}$ na base espectral são

$$\mathbf{z} = \mathbf{Q}_A^\top \mathbf{x}.$$

Como

$$\mathbf{Q}_A^\top = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix},$$

tem-se

$$\begin{aligned} \mathbf{z} &= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} \\ &= \frac{1}{\sqrt{2}} \begin{bmatrix} 3 \\ 1 \end{bmatrix}. \end{aligned}$$

Portanto,

$$z_1 = \frac{3}{\sqrt{2}} \quad \text{e} \quad z_2 = \frac{1}{\sqrt{2}}.$$

Nas coordenadas espectrais, a mesma forma quadrática é

$$\begin{aligned} q_A(\mathbf{x}) &= \mathbf{z}^\top \Lambda_A \mathbf{z} \\ &= \lambda_1 z_1^2 + \lambda_2 z_2^2 \\ &= 3 \left(\frac{3}{\sqrt{2}} \right)^2 + 1 \left(\frac{1}{\sqrt{2}} \right)^2 \\ &= 3 \left(\frac{9}{2} \right) + \frac{1}{2} \\ &= 14. \end{aligned}$$

Assim, nas coordenadas espectrais,

$$q_A(\mathbf{x}) = 3z_1^2 + z_2^2,$$

sem produtos cruzados. A mudança de coordenadas não altera o valor da forma quadrática; ela apenas a expressa em uma base na qual a matriz é diagonal.

Proposição 5.5 (Positividade e sinais dos autovalores). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica. Então:*

1. $\mathbf{A}$ é positiva definida se, e somente se,

$$\lambda_j > 0$$

para todo j ;

2. $\mathbf{A}$ é semidefinida positiva se, e somente se,

$$\lambda_j \geq 0$$

para todo j ;

3. $\mathbf{A}$ é negativa definida se, e somente se,

$$\lambda_j < 0$$

para todo j ;

4. $\mathbf{A}$ é semidefinida negativa se, e somente se,

$$\lambda_j \leq 0$$

para todo j ;

5. $\mathbf{A}$ é indefinida se, e somente se, possui pelo menos um autovalor positivo e pelo menos um autovalor negativo.

(Eaton, 2007)

i Demonstração

Para qualquer $\mathbf{x} \in \mathbb{R}^p$, escreva

$$\mathbf{x} = \sum_{j=1}^p z_j \mathbf{q}_j.$$

Então,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2.$$

Se todos os autovalores são positivos e $\mathbf{x} \neq \mathbf{0}$, pelo menos uma coordenada z_j é não nula. Portanto,

$$\sum_{j=1}^p \lambda_j z_j^2 > 0,$$

e $\mathbf{A}$ é positiva definida.

Reciprocamente, se $\mathbf{A}$ é positiva definida, para cada autovetor unitário $\mathbf{q}_j$,

$$\mathbf{q}_j^\top \mathbf{A} \mathbf{q}_j = \lambda_j > 0.$$

Logo, todos os autovalores são positivos.

As caracterizações semidefinidas e negativas seguem pelo mesmo argumento.

Se existem autovalores $\lambda_i > 0$ e $\lambda_j < 0$, então

$$\mathbf{q}_i^\top \mathbf{A} \mathbf{q}_i = \lambda_i > 0$$

e

$$\mathbf{q}_j^\top \mathbf{A} \mathbf{q}_j = \lambda_j < 0.$$

Assim, a forma quadrática assume valores positivos e negativos, e a matriz é indefinida.

Reciprocamente, se a matriz é indefinida, a expressão

$$\sum_{j=1}^p \lambda_j z_j^2$$

deve assumir ambos os sinais. Isso exige a existência de autovalores positivos e negativos.

Uma matriz simétrica positiva definida é necessariamente invertível, pois todos os seus autovalores são positivos. Uma matriz semidefinida positiva pode ser singular quando possui pelo menos um autovalor igual a zero.

5.4.3 Superfícies de nível em coordenadas espectrais

Considere uma matriz positiva definida e a superfície de nível

$$\mathcal{S}_c(\mathbf{A}) = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{x}^\top \mathbf{A} \mathbf{x} = c\}, \quad c > 0.$$

Nas coordenadas espectrais,

$$\sum_{j=1}^p \lambda_j z_j^2 = c.$$

Como todos os autovalores são positivos,

$$\sum_{j=1}^p \frac{z_j^2}{(c/\lambda_j)} = 1.$$

Essa é a equação de um elipsoide. Suas direções principais são os autovetores

$$\mathbf{q}_1, \dots, \mathbf{q}_p,$$

e o comprimento do semieixo associado a $\mathbf{q}_j$ é

$$r_j = \sqrt{\frac{c}{\lambda_j}}.$$

Autovalores maiores correspondem a semieixos menores. Autovalores menores correspondem a maior extensão da superfície na direção associada.

Para uma superfície centralizada em um vetor fixo $\mathbf{x}_0$,

$$(\mathbf{x} - \mathbf{x}_0)^\top \mathbf{A} (\mathbf{x} - \mathbf{x}_0) = c,$$

os autovetores e os comprimentos dos semieixos permanecem os mesmos. O vetor $\mathbf{x}_0$ determina o centro do elipsoide.

Quando $\mathbf{A}$ é semidefinida positiva e singular, existem direções do núcleo nas quais a forma quadrática não se altera. Para $c > 0$, a superfície de nível é ilimitada nessas direções.

Quando $\mathbf{A}$ é indefinida, a forma quadrática possui parcelas positivas e negativas. Suas superfícies de nível deixam de ser elipsoides e podem apresentar formas hiperbólicas.

Exemplo 5.4 (Forma quadrática na base espectral). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Na base canônica,

$$\begin{aligned} q_{\mathbf{A}}(\mathbf{x}) &= \mathbf{x}^{\top} \mathbf{A} \mathbf{x} \\ &= 3x_1^2 + 2x_1x_2 + 3x_2^2. \end{aligned}$$

Os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2,$$

com autovetores unitários

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

As coordenadas espectrais são

$$z_1 = \mathbf{q}_1^{\top} \mathbf{x} = \frac{x_1 + x_2}{\sqrt{2}}$$

e

$$z_2 = \mathbf{q}_2^{\top} \mathbf{x} = \frac{x_1 - x_2}{\sqrt{2}}.$$

Nessas coordenadas,

$$q_{\mathbf{A}}(\mathbf{x}) = 4z_1^2 + 2z_2^2.$$

A superfície de nível

$$\mathbf{x}^{\top} \mathbf{A} \mathbf{x} = 8$$

pode ser escrita como

$$4z_1^2 + 2z_2^2 = 8,$$

ou

$$\frac{z_1^2}{2} + \frac{z_2^2}{4} = 1.$$

O elipsoide possui semieixo de comprimento

$$\sqrt{2}$$

na direção de $\mathbf{q}_1$ e semieixo de comprimento

$$2$$

na direção de $\mathbf{q}_2$. A direção associada ao menor autovalor apresenta a maior extensão.

O termo cruzado $2x_1x_2$ presente nas coordenadas canônicas desaparece nas coordenadas espectrais porque os eixos coordenados passam a coincidir com as direções principais da forma quadrática.

A representação

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2$$

também permite comparar os valores assumidos pela forma quadrática entre vetores de mesmo comprimento.

Se

$$\|\mathbf{x}\| = 1,$$

então, como a mudança de coordenadas é ortogonal,

$$\|\mathbf{z}\| = 1$$

e

$$\sum_{j=1}^p z_j^2 = 1.$$

Nesse caso,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2$$

é uma média ponderada dos autovalores, com pesos não negativos que somam 1. Essa observação conduz ao quociente de Rayleigh e à caracterização variacional dos autovalores extremos.

5.5 Quociente de Rayleigh

Definição 5.5 (Quociente de Rayleigh). Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica e seja $\mathbf{a} \in \mathbb{R}^p$, com $\mathbf{a} \neq \mathbf{0}$. O **quociente de Rayleigh** de $\mathbf{A}$ avaliado em $\mathbf{a}$ é

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{a}} = \frac{q_{\mathbf{A}}(\mathbf{a})}{\|\mathbf{a}\|^2}.$$

O numerador é a forma quadrática associada a $\mathbf{A}$, enquanto o denominador é o quadrado da norma euclidiana de $\mathbf{a}$.

Quando $\mathbf{A}$ é definida positiva, a forma quadrática também pode ser escrita como

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \langle \mathbf{a}, \mathbf{a} \rangle_{\mathbf{A}},$$

em que $\langle \cdot, \cdot \rangle_{\mathbf{A}}$ é o produto interno induzido por $\mathbf{A}$, definido na Definição 3.16.

A divisão por $\|\mathbf{a}\|^2$ remove o efeito da magnitude do vetor. Consequentemente, o quociente de Rayleigh depende da direção determinada por $\mathbf{a}$, e não de seu comprimento.

Para qualquer escalar $c \neq 0$,

$$\begin{aligned} \mathcal{R}_{\mathbf{A}}(c\mathbf{a}) &= \frac{(c\mathbf{a})^\top \mathbf{A} (c\mathbf{a})}{(c\mathbf{a})^\top (c\mathbf{a})} \\ &= \frac{c^2 \mathbf{a}^\top \mathbf{A} \mathbf{a}}{c^2 \mathbf{a}^\top \mathbf{a}} \\ &= \mathcal{R}_{\mathbf{A}}(\mathbf{a}). \end{aligned}$$

Assim, todos os vetores não nulos de uma mesma reta produzem o mesmo valor.

Quando

$$\|\mathbf{a}\| = 1,$$

tem-se

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \mathbf{a}^\top \mathbf{A} \mathbf{a}.$$

Desse modo, estudar o quociente entre todos os vetores não nulos equivale a estudar a forma quadrática sobre a esfera unitária.

5.5.1 Representação espectral

Considere a decomposição espectral

$$\mathbf{A} = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^\top,$$

com autovalores ordenados de modo que

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p.$$

As coordenadas de $\mathbf{a}$ na base espectral são

$$\mathbf{z} = [\mathbf{a}]_{\mathcal{B}_{\mathbf{A}}} = \mathbf{Q}_{\mathbf{A}}^\top \mathbf{a},$$

de modo que

$$\mathbf{a} = \mathbf{Q}_{\mathbf{A}} \mathbf{z}.$$

Como $\mathbf{Q}_{\mathbf{A}}$ é ortogonal,

$$\mathbf{a}^\top \mathbf{a} = \mathbf{z}^\top \mathbf{z} = \sum_{j=1}^p z_j^2.$$

Além disso,

$$\begin{aligned}\mathbf{a}^\top \mathbf{A} \mathbf{a} &= \mathbf{z}^\top \Lambda_{\mathbf{A}} \mathbf{z} \\ &= \sum_{j=1}^p \lambda_j z_j^2.\end{aligned}$$

Portanto,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\sum_{j=1}^p \lambda_j z_j^2}{\sum_{j=1}^p z_j^2}.$$

Definindo

$$\omega_j = \frac{z_j^2}{\sum_{\ell=1}^p z_\ell^2},$$

tem-se

$$\omega_j \geq 0$$

e

$$\sum_{j=1}^p \omega_j = 1.$$

Logo,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \sum_{j=1}^p \omega_j \lambda_j.$$

O quociente de Rayleigh é, portanto, uma média ponderada dos autovalores. Para uma base espectral fixada, ω_j mede a proporção do comprimento ao quadrado de $\mathbf{a}$ associada à direção $\mathbf{q}_j$.

Quando o autoespaço associado a um autovalor λ possui dimensão maior que 1, a quantidade intrínseca ao autoespaço é a soma dos pesos associados aos vetores de uma base ortonormal desse subespaço. Essa soma é igual à proporção do comprimento ao quadrado da projeção de $\mathbf{a}$ sobre $\mathcal{E}_\lambda$.

Teorema 5.3 (Extremos do quociente de Rayleigh). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica, com autovalores ordenados como*

$$\lambda_1 \geq \dots \geq \lambda_p.$$

Então, para todo $\mathbf{a} \neq \mathbf{0}$,

$$\lambda_p \leq \mathcal{R}_{\mathbf{A}}(\mathbf{a}) \leq \lambda_1.$$

Além disso,

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \lambda_1$$

e

$$\min_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \lambda_p.$$

O máximo é atingido por todo vetor não nulo do autoespaço associado a λ_1 , e o mínimo é atingido por todo vetor não nulo do autoespaço associado a λ_p . (Gentle, 2017)

i Demonstração

Como

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \sum_{j=1}^p \omega_j \lambda_j,$$

com pesos não negativos que somam 1, o quociente não pode ser menor que o menor autovalor nem maior que o maior:

$$\lambda_p \leq \sum_{j=1}^p \omega_j \lambda_j \leq \lambda_1.$$

Se $\mathbf{a}$ pertence ao autoespaço associado a λ_1 , então

$$\mathbf{A}\mathbf{a} = \lambda_1 \mathbf{a},$$

e

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\mathbf{a}^\top \lambda_1 \mathbf{a}}{\mathbf{a}^\top \mathbf{a}} = \lambda_1.$$

Portanto, o limite superior é atingido.

Analogamente, se $\mathbf{a}$ pertence ao autoespaço associado a λ_p ,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \lambda_p,$$

e o limite inferior também é atingido.

Se o maior autovalor é simples, a reta que maximiza o quociente é

$$\text{span}\{\mathbf{q}_1\}.$$

Se o autoespaço associado ao autovalor extremo possui dimensão maior que 1, todo vetor não nulo desse autoespaço produz o mesmo valor máximo. Nesse caso, a solução é um subespaço, e não uma direção individual única.

Exemplo 5.5 (Quociente de Rayleigh em diferentes direções). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Um vetor unitário do plano pode ser escrito como

$$\mathbf{a}(\theta) = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix}.$$

Como

$$\mathbf{a}(\theta)^\top \mathbf{a}(\theta) = 1,$$

o quociente de Rayleigh é

$$\begin{aligned} \mathcal{R}_{\mathbf{A}}(\mathbf{a}(\theta)) &= \mathbf{a}(\theta)^\top \mathbf{A} \mathbf{a}(\theta) \\ &= 3 \cos^2 \theta + 2 \cos \theta \sin \theta + 3 \sin^2 \theta \\ &= 3 + \sin(2\theta). \end{aligned}$$

O valor máximo é

$$4,$$

atingido quando

$$\sin(2\theta) = 1.$$

Uma das direções correspondentes é

$$\theta = \frac{\pi}{4},$$

associada ao autovetor

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

O valor mínimo é

$$2,$$

atingido quando

$$\sin(2\theta) = -1.$$

Uma direção correspondente é

$$\theta = -\frac{\pi}{4},$$

associada ao autovetor

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

O quociente de Rayleigh assume máximo igual a 4 na direção de $\mathbf{q}_1$ e mínimo igual a 2 na direção de $\mathbf{q}_2$, coincidindo com os autovalores extremos de $\mathbf{A}$.

A Figura 5.3 mostra a variação de

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}(\theta))$$

ao longo das direções da circunferência unitária.




Figura 5.3: O quociente de Rayleigh assume seus valores extremos nas direções dos autovetores associados aos autovalores máximo e mínimo.

As direções opostas representam a mesma reta e, por isso, produzem o mesmo valor do quociente. Os máximos aparecem em duas posições angulares separadas por π , assim como os mínimos.

5.5.2 Formulação com restrição de norma

A invariância à escala permite substituir o problema sobre vetores não nulos por um problema sobre a esfera unitária:

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}}(\mathbf{a})$$

é equivalente a

$$\max_{\mathbf{a}} \mathbf{a}^{\top} \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^{\top} \mathbf{a} = 1.$$

A restrição de norma separa a escolha da **direção** da escolha da magnitude do vetor. De fato,

$$(\mathbf{c}\mathbf{a})^{\top} \mathbf{A} (\mathbf{c}\mathbf{a}) = c^2 \mathbf{a}^{\top} \mathbf{A} \mathbf{a}.$$

Portanto, sem uma normalização, o valor da forma quadrática pode ser alterado simplesmente pelo escalonamento do vetor, mesmo quando sua direção permanece a mesma.

Se existe uma direção para a qual

$$\mathbf{a}^{\top} \mathbf{A} \mathbf{a} > 0,$$

o problema de maximização sem restrição é ilimitado superiormente. Analogamente, se existe uma direção para a qual

$$\mathbf{a}^{\top} \mathbf{A} \mathbf{a} < 0,$$

o problema de minimização sem restrição é ilimitado inferiormente.

A condição

$$\mathbf{a}^\top \mathbf{a} = 1$$

elimina esse efeito de escala e restringe a otimização às direções representadas por vetores unitários.

5.5.3 Multiplicadores de Lagrange

Em diferentes problemas da Estatística Multivariada, procura-se uma **direção** no espaço das variáveis que maximize ou minimize um critério escalar. Esse critério pode representar variabilidade, separação entre grupos ou associação entre conjuntos de variáveis.

Uma direção pode ser representada por um vetor $\mathbf{a}$. Entretanto, os vetores $\mathbf{a}$ e $c\mathbf{a}$, para $c \neq 0$, representam a mesma direção, embora tenham comprimentos diferentes. Por isso, quando o interesse está apenas na direção, é conveniente impor a normalização

$$\mathbf{a}^\top \mathbf{a} = 1.$$

Essa restrição faz com que a busca seja realizada sobre o conjunto dos vetores unitários. Geometricamente, em $\mathbb{R}^p$, esses vetores formam a esfera unitária.

Considere agora a forma quadrática

$$f(\mathbf{a}) = \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

em que $\mathbf{A} \in \mathbb{R}^{p \times p}$ é simétrica. O problema consiste em investigar como o valor de $f(\mathbf{a})$ varia quando a direção $\mathbf{a}$ percorre a esfera unitária.

5.5.3.1 Ponto estacionário sob uma restrição

Em um problema sem restrições, um ponto estacionário de uma função diferenciável é um ponto no qual seu gradiente é nulo. Em um problema com restrição, essa condição precisa ser modificada, pois nem todas as direções de deslocamento são permitidas.

Neste caso, $\mathbf{a}$ deve permanecer sobre a esfera

$$\mathbf{a}^\top \mathbf{a} = 1.$$

Um ponto é estacionário para o problema restrito quando pequenas alterações de $\mathbf{a}$ que respeitem essa restrição não produzem, em primeira ordem, aumento ou redução da função objetivo.

Geometricamente, isso ocorre quando o gradiente da função objetivo não possui componente na direção tangente à superfície da restrição. De forma equivalente, o gradiente da função objetivo deve ser proporcional ao gradiente da função que define a restrição.

Essa condição é obtida pelo método dos multiplicadores de Lagrange.

Considere a função lagrangiana

$$\mathcal{L}(\mathbf{a}, \eta) = \mathbf{a}^\top \mathbf{A} \mathbf{a} - \eta (\mathbf{a}^\top \mathbf{a} - 1),$$

em que η é o multiplicador de Lagrange.

Como $\mathbf{A}$ é simétrica,

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{A} \mathbf{a}) = 2\mathbf{A} \mathbf{a},$$

e

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{a}) = 2\mathbf{a}.$$

A condição de primeira ordem para um ponto estacionário é

$$\nabla_{\mathbf{a}} \mathcal{L} = \mathbf{0},$$

isto é,

$$2\mathbf{A} \mathbf{a} - 2\eta \mathbf{a} = \mathbf{0}.$$

Portanto,

$$\mathbf{A} \mathbf{a} = \eta \mathbf{a}.$$

Como a restrição

$$\mathbf{a}^\top \mathbf{a} = 1$$

garante que $\mathbf{a} \neq \mathbf{0}$, essa equação mostra que as direções estacionárias do problema são precisamente direções de autovetores de $\mathbf{A}$. O multiplicador de Lagrange η é o autovalor associado à direção encontrada.

Multiplicando a equação

$$\mathbf{A}\mathbf{a} = \eta\mathbf{a}$$

à esquerda por $\mathbf{a}^\top$, obtém-se

$$\begin{aligned}\mathbf{a}^\top \mathbf{A}\mathbf{a} &= \eta \mathbf{a}^\top \mathbf{a} \\ &= \eta,\end{aligned}$$

pois $\mathbf{a}^\top \mathbf{a} = 1$.

Assim, quando $\mathbf{a}$ é um autovetor unitário associado ao autovalor λ ,

$$\mathbf{A}\mathbf{a} = \lambda\mathbf{a}$$

e

$$\mathbf{a}^\top \mathbf{A}\mathbf{a} = \lambda.$$

Portanto, as direções estacionárias são precisamente as direções dos autovetores, e o valor da forma quadrática em cada direção estacionária é o autovalor correspondente.

Como $\mathbf{A}$ é simétrica, seus autovalores são reais. Além disso, pelo Teorema 5.3, para todo vetor unitário $\mathbf{a}$,

$$\lambda_{\min} \leq \mathbf{a}^\top \mathbf{A}\mathbf{a} \leq \lambda_{\max}.$$

Os extremos são atingidos nos autoespaços associados ao menor e ao maior autovalor. Consequentemente,

$$\max_{\mathbf{a}^\top \mathbf{a}=1} \mathbf{a}^\top \mathbf{A}\mathbf{a} = \lambda_{\max},$$

e

$$\min_{\mathbf{a}^\top \mathbf{a}=1} \mathbf{a}^\top \mathbf{A}\mathbf{a} = \lambda_{\min}.$$

Assim:

- o maior autovalor fornece o máximo global da forma quadrática sobre a esfera unitária;
- o menor autovalor fornece o mínimo global;
- os demais autovalores correspondem a valores estacionários intermediários;
- os autovetores associados fornecem as respectivas direções.

Teorema 5.4 (Autovalores como valores estacionários). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica e considere*

$$f(\mathbf{a}) = \mathbf{a}^\top \mathbf{A} \mathbf{a}$$

restrita aos vetores que satisfazem

$$\mathbf{a}^\top \mathbf{a} = 1.$$

Um vetor unitário $\mathbf{a}$ é um ponto estacionário de f sobre a esfera unitária se, e somente se, $\mathbf{a}$ é um autovetor de $\mathbf{A}$.

Se

$$\mathbf{A} \mathbf{a} = \lambda \mathbf{a},$$

então

$$f(\mathbf{a}) = \mathbf{a}^\top \mathbf{A} \mathbf{a} = \lambda.$$

Em particular, o maior autovalor corresponde ao máximo global da função sobre a esfera unitária, e o menor autovalor corresponde ao mínimo global.

O Teorema 5.4 aplica-se diretamente a problemas em que o critério a otimizar é uma forma quadrática.

Na Análise de Componentes Principais, por exemplo, para um vetor aleatório $\mathbf{X}$ com matriz de covariâncias Σ , a variância da combinação linear

$$Y = \mathbf{a}^\top \mathbf{X}$$

é

$$\text{Var}(Y) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

A primeira componente principal procura a direção unitária que maximiza essa variância:

$$\max_{\mathbf{a}^\top \mathbf{a} = 1} \mathbf{a}^\top \Sigma \mathbf{a}.$$

Pelo Teorema 5.4, a solução é um autovetor associado ao maior autovalor de Σ . O maior autovalor é a maior variância possível entre combinações lineares unitárias, e o autovetor correspondente determina a direção de maior variabilidade.

A imposição sucessiva de restrições de ortogonalidade conduz aos autovetores associados aos autovalores seguintes.

Razões entre formas quadráticas aparecem, com critérios específicos, em outros problemas multivariados. Na análise discriminante, procura-se uma direção que produza grande separação entre grupos em relação à variabilidade dentro dos grupos. Na MANOVA, determinadas direções maximizam a variação associada à hipótese em relação à variação residual. Na correlação canônica, procuram-se combinações lineares de dois conjuntos de variáveis que apresentem associação máxima.

Nesses casos, a função a ser otimizada envolve frequentemente uma razão entre duas formas quadráticas,

$$\frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{B} \mathbf{a}},$$

e a condição de estacionariedade conduz ao problema de autovalores generalizados

$$\mathbf{A} \mathbf{a} = \lambda \mathbf{B} \mathbf{a}.$$

Assim, autovalores e autovetores aparecem nessas técnicas porque representam soluções de problemas de otimização sobre direções: os autovetores fornecem as direções de interesse e os autovalores quantificam o valor atingido pelo critério nessas direções.

5.5.4 Direções sucessivas

O problema de otimização anterior identifica uma direção associada ao maior autovalor de $\mathbf{A}$. As direções seguintes são obtidas maximizando a mesma forma quadrática sob restrições sucessivas de ortogonalidade em relação às direções já determinadas.

Considere

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$$

e uma base ortonormal de autovetores

$$\mathbf{q}_1, \dots, \mathbf{q}_p.$$

O segundo problema é

$$\max_{\mathbf{a}} \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^\top \mathbf{a} = 1$$

e

$$\mathbf{a}^\top \mathbf{q}_1 = 0.$$

A restrição

$$\mathbf{a}^\top \mathbf{q}_1 = 0$$

impede que $\mathbf{a}$ possua componente na direção de $\mathbf{q}_1$. Assim, se $\mathbf{a}$ for escrito na base espectral,

$$\mathbf{a} = z_1 \mathbf{q}_1 + z_2 \mathbf{q}_2 + \cdots + z_p \mathbf{q}_p,$$

a condição de ortogonalidade implica

$$z_1 = 0.$$

Portanto, a otimização passa a ocorrer apenas no subespaço gerado por

$$\mathbf{q}_2, \dots, \mathbf{q}_p.$$

Nesse subespaço, o maior autovalor disponível é λ_2 . Assim, o maior valor da forma quadrática é λ_2 , atingido na direção de $\mathbf{q}_2$ quando λ_2 é simples.

De forma geral, a k -ésima direção pode ser obtida por

$$\max_{\mathbf{a}} \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^\top \mathbf{a} = 1$$

e

$$\mathbf{a}^\top \mathbf{q}_j = 0, \quad j = 1, \dots, k-1.$$

Teorema 5.5 (Caracterização variacional de direções sucessivas). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica, com autovalores ordenados como*

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p,$$

e seja

$$\mathbf{q}_1, \dots, \mathbf{q}_p$$

uma base ortonormal de autovetores correspondente a essa ordenação. Então, para $k = 1, \dots, p$,

$$\lambda_k = \max_{\substack{\|\mathbf{a}\|=1 \\ \mathbf{a}^\top \mathbf{q}_j = 0, \, j=1, \dots, k-1}} \mathbf{a}^\top \mathbf{A} \mathbf{a}.$$

O máximo é atingido por $\mathbf{q}_k$ e, quando o autoespaço associado a λ_k possui dimensão maior que 1, por qualquer autovetor unitário desse autoespaço que satisfaça as restrições de ortogonalidade. (Horn; Johnson, 2013)



i Demonstração

Como

$$\mathbf{q}_1, \dots, \mathbf{q}_p$$

formam uma base ortonormal de $\mathbb{R}^p$, qualquer vetor $\mathbf{a}$ pode ser escrito como

$$\mathbf{a} = \sum_{j=1}^p z_j \mathbf{q}_j,$$

em que

$$z_j = \mathbf{q}_j^\top \mathbf{a}.$$

As restrições

$$\mathbf{a}^\top \mathbf{q}_j = 0, \quad j = 1, \dots, k-1,$$

implicam

$$z_1 = \dots = z_{k-1} = 0.$$

Portanto,

$$\mathbf{a} = \sum_{j=k}^p z_j \mathbf{q}_j.$$

Como os autovetores são ortonormais e $\|\mathbf{a}\| = 1$,

$$\sum_{j=k}^p z_j^2 = 1.$$

Nas coordenadas espectrais,

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \sum_{j=k}^p \lambda_j z_j^2.$$

Como os autovalores estão ordenados de forma decrescente,

Quando há autovalores repetidos, as direções individuais dentro do autoespaço correspondente não são unicamente determinadas. Diferentes bases ortonormais desse autoespaço produzem o mesmo valor da função objetivo e representam o mesmo subespaço espectral. Assim, o subespaço associado ao autovalor repetido é bem determinado, embora a escolha particular dos autovetores que formam uma base desse subespaço não seja única.

A caracterização variacional identifica os autovalores como valores extremos ou estacionários da forma quadrática sobre a esfera unitária e os autovetores como as direções em que esses valores são atingidos. Restrições sucessivas de ortogonalidade recuperam os autovalores ordenados e seus autoespaços.

5.6 Funções espectrais de matrizes

A decomposição espectral define funções de matrizes simétricas pela aplicação de uma função escalar aos autovalores. A inversa, a raiz quadrada principal e a raiz quadrada inversa são casos dessa construção.

Considere uma matriz simétrica

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

com decomposição espectral

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A} = \text{diag}(\lambda_1, \dots, \lambda_p).$$

Se f é uma função escalar real definida em todos os autovalores de $\mathbf{A}$, pode-se aplicá-la aos elementos diagonais:

$$f(\Lambda_\mathbf{A}) = \text{diag}(f(\lambda_1), \dots, f(\lambda_p)).$$

Definição 5.6 (Função espectral de uma matriz simétrica). Seja

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top$$

uma matriz simétrica e seja f uma função real definida no espectro de $\mathbf{A}$.

A **função espectral** $f(\mathbf{A})$ é definida por

$$f(\mathbf{A}) = \mathbf{Q}_{\mathbf{A}} f(\Lambda_{\mathbf{A}}) \mathbf{Q}_{\mathbf{A}}^{\top}.$$

A definição não depende da base ortonormal escolhida dentro de um autoespaço associado a um autovalor repetido.

De fato, considerando os autovalores distintos

$$\lambda^{(1)}, \dots, \lambda^{(s)}$$

e os respectivos projetores espectrais, a função também pode ser escrita como

$$f(\mathbf{A}) = \sum_{h=1}^s f(\lambda^{(h)}) \Pi_{\lambda^{(h)}}.$$

Os projetores são determinados pelos autoespaços, independentemente da base ortonormal utilizada para representá-los.

5.6.1 Ação sobre os autoespaços

Proposição 5.6 (Ação de uma função espectral). *Se $\mathbf{v}$ pertence ao autoespaço de $\mathbf{A}$ associado ao autovalor λ , então*

$$f(\mathbf{A})\mathbf{v} = f(\lambda)\mathbf{v}.$$

(Gentle, 2017)

i Demonstração

Como

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v},$$

o vetor $\mathbf{v}$ pertence à imagem do projetor

$$\Pi_\lambda$$

e é anulado pelos projetores associados aos demais autovalores. Assim,

$$\begin{aligned} f(\mathbf{A})\mathbf{v} &= \sum_{h=1}^s f(\lambda^{(h)}) \Pi_{\lambda^{(h)}} \mathbf{v} \\ &= f(\lambda)\mathbf{v}. \end{aligned}$$

Portanto, todo autovetor de $\mathbf{A}$ associado a λ também é autovetor de $f(\mathbf{A})$, agora associado ao autovalor $f(\lambda)$. Mais geralmente, todo o autoespaço $\mathcal{E}_\lambda$ de $\mathbf{A}$ permanece invariante sob $f(\mathbf{A})$.

A função pode fazer autovalores originalmente distintos assumirem o mesmo valor. Se

$$f(\lambda_i) = f(\lambda_j),$$

os autoespaços correspondentes passam a pertencer ao mesmo autoespaço de $f(\mathbf{A})$. Por isso, $f(\mathbf{A})$ pode possuir autoespaços de dimensão maior que os autoespaços individuais de $\mathbf{A}$.

5.6.2 Inversa espectral

Se todos os autovalores são diferentes de zero, define-se

$$f(\lambda) = \frac{1}{\lambda}.$$

Nesse caso,

$$\mathbf{A}^{-1} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^{-1} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A}^{-1} = \text{diag} \left(\frac{1}{\lambda_1}, \dots, \frac{1}{\lambda_p} \right).$$

A inversa desfaz o escalonamento em cada direção espectral:

$$\mathbf{A}^{-1}\mathbf{q}_j = \frac{1}{\lambda_j}\mathbf{q}_j.$$

Para o exemplo anterior,

$$\mathbf{A}^{-1} = \mathbf{Q}_\mathbf{A} \begin{bmatrix} 1/4 & 0 \\ 0 & 1/2 \end{bmatrix} \mathbf{Q}_\mathbf{A}^\top,$$

o que resulta em

$$\mathbf{A}^{-1} = \frac{1}{8} \begin{bmatrix} 3 & -1 \\ -1 & 3 \end{bmatrix}.$$

Se pelo menos um autovalor é igual a zero, a inversa usual não existe.

5.6.3 Raiz quadrada principal

Para uma matriz semidefinida positiva, todos os autovalores são não negativos. Assim, pode-se definir

$$f(\lambda) = \sqrt{\lambda}.$$

Definição 5.7 (Raiz quadrada principal). Se

$$\mathbf{A} \succeq 0,$$

a raiz quadrada principal de $\mathbf{A}$ é

$$\mathbf{A}^{1/2} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^{1/2} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A}^{1/2} = \text{diag} \left(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_p} \right).$$

A matriz $\mathbf{A}^{1/2}$ é simétrica, semidefinida positiva e satisfaz

$$\mathbf{A}^{1/2} \mathbf{A}^{1/2} = \mathbf{A}.$$

A raiz quadrada principal $\mathbf{A}^{1/2}$ é a única matriz simétrica semidefinida positiva cujo quadrado é $\mathbf{A}$.

Para

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix},$$

tem-se

$$\mathbf{A}^{1/2} = \mathbf{Q}_\mathbf{A} \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix} \mathbf{Q}_\mathbf{A}^\top.$$

Logo,

$$\mathbf{A}^{1/2} = \frac{1}{2} \begin{bmatrix} 2 + \sqrt{2} & 2 - \sqrt{2} \\ 2 - \sqrt{2} & 2 + \sqrt{2} \end{bmatrix}.$$

A raiz quadrada principal multiplica as componentes espectrais por

$$\sqrt{\lambda_j}.$$

Aplicada duas vezes, ela produz o escalonamento original por λ_j .

5.6.4 Raiz quadrada inversa

Se

$$\mathbf{A} \succ 0,$$

todos os autovalores são estritamente positivos. Define-se então

$$\mathbf{A}^{-1/2} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^{-1/2} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_{\mathbf{A}}^{-1/2} = \text{diag} \left(\frac{1}{\sqrt{\lambda_1}}, \dots, \frac{1}{\sqrt{\lambda_p}} \right).$$

Como $\mathbf{A} \succ 0$, a raiz quadrada principal é invertível e

$$\mathbf{A}^{-1/2} = \left(\mathbf{A}^{1/2} \right)^{-1}.$$

Além disso,

$$\mathbf{A}^{-1} = \mathbf{A}^{-1/2} \mathbf{A}^{-1/2}$$

e

$$\mathbf{A}^{-1/2} \mathbf{A} \mathbf{A}^{-1/2} = \mathbf{I}_p.$$

De fato,

$$\begin{aligned} \mathbf{A}^{-1/2} \mathbf{A} \mathbf{A}^{-1/2} &= \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}}^{-1/2} \Lambda_{\mathbf{A}} \Lambda_{\mathbf{A}}^{-1/2} \mathbf{Q}_{\mathbf{A}}^{\top} \\ &= \mathbf{Q}_{\mathbf{A}} \mathbf{I}_p \mathbf{Q}_{\mathbf{A}}^{\top} \\ &= \mathbf{I}_p. \end{aligned}$$

A transformação

$$\mathbf{z} = \mathbf{A}^{-1/2} \mathbf{x}$$

reescala as componentes espectrais de $\mathbf{x}$ segundo os fatores $1/\sqrt{\lambda_j}$. Além disso, converte a forma quadrática associada à inversa em uma norma euclidiana:

$$\begin{aligned} \mathbf{x}^{\top} \mathbf{A}^{-1} \mathbf{x} &= \mathbf{x}^{\top} \mathbf{A}^{-1/2} \mathbf{A}^{-1/2} \mathbf{x} \\ &= \mathbf{z}^{\top} \mathbf{z} \\ &= \|\mathbf{z}\|^2. \end{aligned}$$

Quando $\mathbf{A} = \Sigma \succ 0$ é uma matriz de covariâncias, a transformação espectral aplicada ao vetor centralizado é

$$\mathbf{z} = \Sigma^{-1/2} (\mathbf{x} - \mu).$$

No Capítulo 8, essa transformação define o branqueamento simétrico; nas coordenadas branqueadas, a distância de Mahalanobis coincide com a distância euclidiana.

A mudança de métrica por uma raiz quadrada inversa também reduz problemas definidos por uma matriz positiva definida a problemas euclidianos equivalentes, princípio utilizado no problema de autovalores generalizados.

5.7 Autovalores generalizados

Quando o critério de interesse compara duas formas quadráticas, em vez de uma única forma quadrática relativamente à norma euclidiana, obtém-se o problema de autovalores generalizados,

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{M}\mathbf{v},$$

em que $\mathbf{A}$ é simétrica e $\mathbf{M}$ é simétrica positiva definida.

A equação generalizada reduz-se ao problema ordinário de autovalores quando

$$\mathbf{M} = \mathbf{I}_p.$$

Problemas desse tipo aparecem quando o critério é uma razão entre duas formas quadráticas; para $\mathbf{A}$ simétrica e $\mathbf{M} \succ 0$, o problema generalizado pode ser reduzido a um problema espectral simétrico ordinário (Gentle, 2017).

O quociente de Rayleigh compara uma forma quadrática com a norma euclidiana do vetor. Em outros problemas, a normalização também é definida por uma forma quadrática:

$$\mathbf{a}^\top \mathbf{M} \mathbf{a},$$

em que

$$\mathbf{M} = \mathbf{M}^\top \succ 0.$$

Conforme a Definição 3.16, a matriz $\mathbf{M}$ determina o produto interno

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{y}$$

e a norma

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\mathbf{x}^{\top} \mathbf{M} \mathbf{x}}.$$

Nesse contexto, procura-se uma direção que compare as formas quadráticas associadas a duas matrizes.

Definição 5.8 (Autovalor e autovetor generalizados). Sejam

$$\mathbf{A}, \mathbf{M} \in \mathbb{R}^{p \times p},$$

com

$$\mathbf{A} = \mathbf{A}^{\top}$$

e

$$\mathbf{M} = \mathbf{M}^{\top} \succ 0.$$

Um escalar real

$$\lambda \in \mathbb{R}$$

é um **autovalor generalizado** do par $(\mathbf{A}, \mathbf{M})$ quando existe um vetor não nulo

$$\mathbf{v} \in \mathbb{R}^p$$

tal que

$$\mathbf{A} \mathbf{v} = \lambda \mathbf{M} \mathbf{v}.$$

O vetor $\mathbf{v}$ é denominado **autovetor generalizado** associado a λ .

Quando

$$\mathbf{M} = \mathbf{I}_p,$$

recupera-se o problema ordinário:

$$\mathbf{A} \mathbf{v} = \lambda \mathbf{v}.$$

A equação generalizada pode ser reorganizada como

$$(\mathbf{A} - \lambda \mathbf{M}) \mathbf{v} = \mathbf{0}.$$

Existem soluções não triviais se, e somente se,

$$\det(\mathbf{A} - \lambda \mathbf{M}) = 0.$$

Essa equação é a equação característica generalizada do par $(\mathbf{A}, \mathbf{M})$ e determina seus autovvalores generalizados.

5.7.1 Quociente de Rayleigh generalizado

Definição 5.9 (Quociente de Rayleigh generalizado). Sejam $\mathbf{A} \in \mathbb{R}^{p \times p}$ simétrica e $\mathbf{M} \in \mathbb{R}^{p \times p}$ simétrica positiva definida. Para $\mathbf{a} \in \mathbb{R}^p$, com $\mathbf{a} \neq \mathbf{0}$, o **quociente de Rayleigh generalizado** associado ao par $(\mathbf{A}, \mathbf{M})$ é

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{M} \mathbf{a}} = \frac{q_{\mathbf{A}}(\mathbf{a})}{\|\mathbf{a}\|_{\mathbf{M}}^2}.$$

O numerador é a forma quadrática associada a $\mathbf{A}$, enquanto o denominador é o quadrado da norma induzida por $\mathbf{M}$,

$$\|\mathbf{a}\|_{\mathbf{M}}^2 = \langle \mathbf{a}, \mathbf{a} \rangle_{\mathbf{M}} = \mathbf{a}^\top \mathbf{M} \mathbf{a}.$$

Como $\mathbf{M} \succ \mathbf{0}$,

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} > 0$$

para todo $\mathbf{a} \neq \mathbf{0}$. Portanto, o denominador é sempre positivo e o quociente está definido para todo vetor não nulo.

No quociente de Rayleigh ordinário, a normalização é realizada pela norma euclidiana,

$$\|\mathbf{a}\|^2 = \mathbf{a}^\top \mathbf{a}.$$

No caso generalizado, essa normalização é substituída pela norma induzida por $\mathbf{M}$. Assim, o comprimento do vetor passa a ser medido segundo a geometria determinada por essa matriz.

Assim como no caso ordinário, o quociente é invariante à escala. Para qualquer escalar $c \neq 0$,

$$\begin{aligned}
\mathcal{R}_{\mathbf{A},\mathbf{M}}(c\mathbf{a}) &= \frac{(c\mathbf{a})^\top \mathbf{A}(c\mathbf{a})}{(c\mathbf{a})^\top \mathbf{M}(c\mathbf{a})} \\
&= \frac{c^2 \mathbf{a}^\top \mathbf{A} \mathbf{a}}{c^2 \mathbf{a}^\top \mathbf{M} \mathbf{a}} \\
&= \mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}).
\end{aligned}$$

Portanto, o valor do quociente depende da direção determinada por $\mathbf{a}$, e não de sua magnitude segundo a norma induzida por $\mathbf{M}$.

Essa invariância permite escolher, em cada direção, um representante com norma unitária na geometria determinada por $\mathbf{M}$. Consequentemente, o problema

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a})$$

é equivalente a

$$\max_{\mathbf{a}} \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = 1.$$

A restrição equivale a

$$\|\mathbf{a}\|_{\mathbf{M}} = 1$$

e, portanto, fixa o comprimento de $\mathbf{a}$ segundo a geometria induzida por $\mathbf{M}$.

Para determinar os pontos estacionários desse problema restrito, considere a função lagrangiana

$$\mathcal{L}(\mathbf{a}, \eta) = \mathbf{a}^\top \mathbf{A} \mathbf{a} - \eta (\mathbf{a}^\top \mathbf{M} \mathbf{a} - 1),$$

em que η é o multiplicador de Lagrange.

Como $\mathbf{A}$ e $\mathbf{M}$ são simétricas,

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{A} \mathbf{a}) = 2\mathbf{A} \mathbf{a}$$

e

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{M} \mathbf{a}) = 2\mathbf{M} \mathbf{a}.$$

Assim,

$$\nabla_{\mathbf{a}} \mathcal{L} = 2\mathbf{A} \mathbf{a} - 2\eta \mathbf{M} \mathbf{a}.$$

A condição de primeira ordem

$$\nabla_{\mathbf{a}} \mathcal{L} = \mathbf{0}$$

produz

$$\mathbf{A} \mathbf{a} = \eta \mathbf{M} \mathbf{a}.$$

Como a restrição

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = 1$$

garante que $\mathbf{a} \neq \mathbf{0}$, essa equação mostra que todo ponto estacionário $\mathbf{a}$ é um autovetor generalizado do par $(\mathbf{A}, \mathbf{M})$ e que o multiplicador η é o autovalor generalizado correspondente.

Multiplicando a equação

$$\mathbf{A} \mathbf{a} = \eta \mathbf{M} \mathbf{a}$$

à esquerda por $\mathbf{a}^\top$, obtém-se

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \eta \mathbf{a}^\top \mathbf{M} \mathbf{a}.$$

Sob a normalização

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = 1,$$

segue que

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \eta.$$

Além disso,

$$\mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{M} \mathbf{a}} = \eta.$$

Portanto, em um autovetor generalizado normalizado, o valor do quociente de Rayleigh generalizado coincide com o autovalor generalizado correspondente.

5.7.2 Redução a um problema espectral ordinário

Como $\mathbf{M} \succ 0$, a matriz $\mathbf{M}$ é invertível, e a equação generalizada também poderia ser escrita como

$$\mathbf{M}^{-1} \mathbf{A} \mathbf{v} = \lambda \mathbf{v}.$$

Entretanto, mesmo que $\mathbf{A}$ e $\mathbf{M}$ sejam simétricas, a matriz $\mathbf{M}^{-1} \mathbf{A}$ não precisa ser simétrica. Para preservar a estrutura simétrica e poder aplicar diretamente o Teorema Espectral, é preferível transformar o problema utilizando a raiz quadrada de $\mathbf{M}$.

Como $\mathbf{M} \succ 0$, existem as matrizes simétricas

$$\mathbf{M}^{1/2}$$

e

$$\mathbf{M}^{-1/2}.$$

Defina

$$\mathbf{u} = \mathbf{M}^{1/2} \mathbf{v}.$$

Consequentemente,

$$\mathbf{v} = \mathbf{M}^{-1/2} \mathbf{u}.$$

Substituindo na equação generalizada,

$$\mathbf{A} \mathbf{M}^{-1/2} \mathbf{u} = \lambda \mathbf{M} \mathbf{M}^{-1/2} \mathbf{u}.$$

Como

$$\mathbf{M}\mathbf{M}^{-1/2} = \mathbf{M}^{1/2},$$

obtém-se

$$\mathbf{A}\mathbf{M}^{-1/2}\mathbf{u} = \lambda\mathbf{M}^{1/2}\mathbf{u}.$$

Multiplicando à esquerda por $\mathbf{M}^{-1/2}$,

$$(\mathbf{M}^{-1/2}\mathbf{A}\mathbf{M}^{-1/2})\mathbf{u} = \lambda\mathbf{u}.$$

Defina

$$\widetilde{\mathbf{A}} = \mathbf{M}^{-1/2}\mathbf{A}\mathbf{M}^{-1/2}.$$

Como $\mathbf{A}$ e $\mathbf{M}^{-1/2}$ são simétricas,

$$\widetilde{\mathbf{A}}^\top = \widetilde{\mathbf{A}}.$$

Assim, o problema generalizado é convertido no problema espectral ordinário

$$\widetilde{\mathbf{A}}\mathbf{u} = \lambda\mathbf{u},$$

para uma matriz simétrica. Consequentemente, todos os autovalores generalizados do par $(\mathbf{A}, \mathbf{M})$ são reais e o Teorema 5.2 aplica-se à matriz $\widetilde{\mathbf{A}}$.

Essa transformação também converte o quociente generalizado em um quociente ordinário. Como

$$\mathbf{a} = \mathbf{M}^{-1/2}\mathbf{u},$$

tem-se

$$\begin{aligned}\mathbf{a}^\top \mathbf{M} \mathbf{a} &= \mathbf{u}^\top \mathbf{M}^{-1/2} \mathbf{M} \mathbf{M}^{-1/2} \mathbf{u} \\ &= \mathbf{u}^\top \mathbf{u}\end{aligned}$$

e

$$\begin{aligned}\mathbf{a}^\top \mathbf{A} \mathbf{a} &= \mathbf{u}^\top \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2} \mathbf{u} \\ &= \mathbf{u}^\top \widetilde{\mathbf{A}} \mathbf{u}.\end{aligned}$$

Portanto,

$$\mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}) = \mathcal{R}_{\tilde{\mathbf{A}}}(\mathbf{u}).$$

A mudança de variáveis

$$\mathbf{u} = \mathbf{M}^{1/2}\mathbf{a}$$

transforma a geometria induzida por $\mathbf{M}$ em geometria euclidiana, pois

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = \mathbf{u}^\top \mathbf{u}.$$

Equivalentemente,

$$\mathbf{a} = \mathbf{M}^{-1/2}\mathbf{u}.$$

Geometricamente, $\mathbf{M}^{-1/2}$ transforma a esfera unitária euclidiana no elipsoide

$$\{\mathbf{a} \in \mathbb{R}^p : \mathbf{a}^\top \mathbf{M} \mathbf{a} = 1\}.$$

O problema generalizado pode, portanto, ser estudado como um problema de Rayleigh ordinário no sistema de coordenadas em que a métrica definida por $\mathbf{M}$ se torna euclidiana.

Quando $\mathbf{M}$ é uma matriz de covariâncias positiva definida, a transformação $\mathbf{M}^{-1/2}$ coincide com a forma espectral do branqueamento apresentada no Capítulo 8. No problema generalizado, $\mathbf{M}$ representa genericamente a matriz que define a geometria.

Teorema 5.6 (Extremos do quociente de Rayleigh generalizado). *Sejam $\mathbf{A}$ simétrica e $\mathbf{M}$ positiva definida. Denote por*

$$\lambda_1 \geq \dots \geq \lambda_p$$

os autovalores generalizados do par $(\mathbf{A}, \mathbf{M})$.

Então, para todo $\mathbf{a} \neq \mathbf{0}$,

$$\lambda_p \leq \mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}) \leq \lambda_1.$$

Além disso,

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \lambda_1$$

e

$$\min_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \lambda_p.$$

O máximo é atingido por todo vetor não nulo do autoespaço generalizado associado a λ_1 , e o mínimo é atingido por todo vetor não nulo do autoespaço generalizado associado a λ_p .

i Demonstração

A transformação

$$\mathbf{u} = \mathbf{M}^{1/2} \mathbf{a}$$

é invertível e estabelece

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \mathcal{R}_{\tilde{\mathbf{A}}}(\mathbf{u}),$$

em que

$$\tilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}$$

é simétrica.

Os autovalores ordinários de $\tilde{\mathbf{A}}$ são os autovalores generalizados do par $(\mathbf{A}, \mathbf{M})$. Aplicando o Teorema 5.3 a $\tilde{\mathbf{A}}$, obtêm-se os limites e os extremos apresentados.

5.7.3 Ortogonalidade na métrica de $\mathbf{M}$

Os autovetores generalizados não precisam ser ortogonais segundo o produto interno euclidiano. Eles podem, entretanto, ser escolhidos ortonormais na geometria determinada por $\mathbf{M}$.

Proposição 5.7 (Ortogonalidade e base de autovetores generalizados). *Sejam $\mathbf{A}$ simétrica e $\mathbf{M} \succ 0$.*

Se $\mathbf{v}_i$ e $\mathbf{v}_j$ são autovetores generalizados associados a autovalores distintos λ_i e λ_j , então

$$\mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = 0.$$

Além disso, existe uma base de $\mathbb{R}^p$ formada por autovetores generalizados

$$\mathcal{B}_g = \{\mathbf{v}_1, \dots, \mathbf{v}_p\}$$

que pode ser escolhida de modo que

$$\mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = \delta_{ij}.$$

(Gentle, 2017)

i Demonstração

Para autovalores distintos,

$$\mathbf{A}\mathbf{v}_i = \lambda_i \mathbf{M}\mathbf{v}_i$$

e

$$\mathbf{A}\mathbf{v}_j = \lambda_j \mathbf{M}\mathbf{v}_j.$$

Como $\mathbf{A}$ é simétrica,

$$\begin{aligned}\lambda_i \mathbf{v}_i^\top \mathbf{M}\mathbf{v}_j &= (\mathbf{A}\mathbf{v}_i)^\top \mathbf{v}_j \\ &= \mathbf{v}_i^\top \mathbf{A}^\top \mathbf{v}_j \\ &= \mathbf{v}_i^\top \mathbf{A}\mathbf{v}_j \\ &= \lambda_j \mathbf{v}_i^\top \mathbf{M}\mathbf{v}_j.\end{aligned}$$

Portanto,

$$(\lambda_i - \lambda_j) \mathbf{v}_i^\top \mathbf{M}\mathbf{v}_j = 0.$$

Como $\lambda_i \neq \lambda_j$,

$$\mathbf{v}_i^\top \mathbf{M}\mathbf{v}_j = 0.$$

Para mostrar a existência de uma base completa, considere

$$\tilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}.$$

Como $\tilde{\mathbf{A}}$ é simétrica, o Teorema Espectral garante uma base ortonormal de autovetores

$$\{\mathbf{u}_1, \dots, \mathbf{u}_p\}.$$

Defina

$$\mathbf{v}_j = \mathbf{M}^{-1/2} \mathbf{u}_j.$$

Esses vetores são autovetores generalizados e

$$\begin{aligned}\mathbf{v}_i^\top \mathbf{M}\mathbf{v}_j &= \mathbf{u}_i^\top \mathbf{M}^{-1/2} \mathbf{M} \mathbf{M}^{-1/2} \mathbf{u}_j \\ &= \mathbf{u}_i^\top \mathbf{u}_j \\ &= \delta_{ij}.\end{aligned}$$

Assim, mesmo quando há autovalores generalizados repetidos, pode-se escolher uma base ortonormal segundo o produto interno induzido por $\mathbf{M}$.

Exemplo 5.6 (Autovalores generalizados de duas formas quadráticas). Considere

$$\mathbf{A} = \begin{bmatrix} 5 & 1 \\ 1 & 2 \end{bmatrix}$$

e

$$\mathbf{M} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}.$$

As duas matrizes são simétricas e $\mathbf{M}$ é positiva definida.

Os autovalores generalizados são obtidos por

$$\det(\mathbf{A} - \lambda\mathbf{M}) = 0.$$

Como

$$\mathbf{A} - \lambda\mathbf{M} = \begin{bmatrix} 5 - 2\lambda & 1 \\ 1 & 2 - \lambda \end{bmatrix},$$

tem-se

$$\begin{aligned} \det(\mathbf{A} - \lambda\mathbf{M}) &= (5 - 2\lambda)(2 - \lambda) - 1 \\ &= 2\lambda^2 - 9\lambda + 9 \\ &= (2\lambda - 3)(\lambda - 3). \end{aligned}$$

Portanto,

$$\lambda_1 = 3$$

e

$$\lambda_2 = \frac{3}{2}.$$

Para $\lambda_1 = 3$,

$$\mathbf{A} - 3\mathbf{M} = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix}.$$

O sistema fornece

$$v_2 = v_1,$$

de modo que um autovetor generalizado é

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

De fato,

$$\mathbf{A}\mathbf{v}_1 = \begin{bmatrix} 6 \\ 3 \end{bmatrix}$$

e

$$3\mathbf{M}\mathbf{v}_1 = 3 \begin{bmatrix} 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 6 \\ 3 \end{bmatrix}.$$

Para

$$\lambda_2 = \frac{3}{2},$$

tem-se

$$\mathbf{A} - \frac{3}{2}\mathbf{M} = \begin{bmatrix} 2 & 1 \\ 1 & 1/2 \end{bmatrix}.$$

O sistema conduz a

$$v_2 = -2v_1.$$

Assim, pode-se escolher

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -2 \end{bmatrix}.$$

Esses vetores não são ortogonais no produto interno euclidiano:

$$\mathbf{v}_1^\top \mathbf{v}_2 = -1.$$

Entretanto,

$$\begin{aligned}\mathbf{v}_1^\top \mathbf{M} \mathbf{v}_2 &= \begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -2 \end{bmatrix} \\ &= 0.\end{aligned}$$

Logo, eles são ortogonais na geometria determinada por $\mathbf{M}$.

Suas normas nessa métrica são

$$\|\mathbf{v}_1\|_{\mathbf{M}} = \sqrt{3}$$

e

$$\|\mathbf{v}_2\|_{\mathbf{M}} = \sqrt{6}.$$

Os autovetores generalizados normalizados são

$$\mathbf{b}_{g,1} = \frac{1}{\sqrt{3}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{b}_{g,2} = \frac{1}{\sqrt{6}} \begin{bmatrix} 1 \\ -2 \end{bmatrix}.$$

O maior valor da razão

$$\frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{M} \mathbf{a}}$$

é 3 e ocorre no autoespaço generalizado gerado por $\mathbf{v}_1$. O menor valor é 3/2 e ocorre no autoespaço generalizado gerado por $\mathbf{v}_2$.

5.8 Aprofundamento teórico

5.8.1 Multiplicidades algébrica e geométrica

Definição 5.10 (Multiplicidades de um autovalor). Seja λ um autovalor de $\mathbf{A}$.

A **multiplicidade algébrica** de λ , denotada por

$$m_a(\lambda),$$

é o número de vezes que λ aparece como raiz do polinômio característico.

A **multiplicidade geométrica** de λ , denotada por

$$m_g(\lambda),$$

é a dimensão do autoespaço correspondente:

$$m_g(\lambda) = \dim(\mathcal{E}_\lambda) = \dim \mathcal{N}(\mathbf{A} - \lambda \mathbf{I}_p).$$

(Searle; Khuri, 2017)

Para todo autovalor,

$$1 \leq m_g(\lambda) \leq m_a(\lambda).$$

A multiplicidade geométrica é pelo menos 1 porque o autoespaço contém vetores não nulos. Ela representa o número máximo de autovetores linearmente independentes que podem ser escolhidos para aquele autovalor.

Exemplo 5.7 (Mesma multiplicidade algébrica e diferentes multiplicidades geométricas). Considere as matrizes

$$\mathbf{A}_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

e

$$\mathbf{A}_2 = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix}.$$

Polinômio característico e multiplicidade algébrica

Para $\mathbf{A}_1$,

$$\begin{aligned} p_{\mathbf{A}_1}(\lambda) &= \det(\mathbf{A}_1 - \lambda \mathbf{I}_2) \\ &= \det \begin{bmatrix} 2 - \lambda & 0 \\ 0 & 2 - \lambda \end{bmatrix} \\ &= (2 - \lambda)^2. \end{aligned}$$

Para $\mathbf{A}_2$,

$$\begin{aligned} p_{\mathbf{A}_2}(\lambda) &= \det(\mathbf{A}_2 - \lambda \mathbf{I}_2) \\ &= \det \begin{bmatrix} 2 - \lambda & 1 \\ 0 & 2 - \lambda \end{bmatrix} \\ &= (2 - \lambda)^2. \end{aligned}$$

Portanto, as duas matrizes possuem o mesmo polinômio característico,

$$p(\lambda) = (2 - \lambda)^2,$$

e, conseqüentemente, o mesmo autovalor,

$$\lambda = 2.$$

Como o fator $(2 - \lambda)$ aparece duas vezes no polinômio característico, o autovalor $\lambda = 2$ possui multiplicidade algébrica

$$m_a(2) = 2$$

para ambas as matrizes.

Autoespaço de $\mathbf{A}_1$

Para determinar o autoespaço associado a $\lambda = 2$, procuramos todos os vetores

$$\mathbf{v} = \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}$$

que satisfazem

$$\mathbf{A}_1 \mathbf{v} = 2\mathbf{v}.$$

Essa equação pode ser escrita como

$$(\mathbf{A}_1 - 2\mathbf{I}_2) \mathbf{v} = \mathbf{0}.$$

Calculando a matriz,

$$\begin{aligned}\mathbf{A}_1 - 2\mathbf{I}_2 &= \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} - \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \\ &= \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}.\end{aligned}$$

Assim, o sistema a ser resolvido é

$$\begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix},$$

ou seja,

$$\begin{cases} 0 = 0, \\ 0 = 0. \end{cases}$$

O sistema não impõe nenhuma restrição sobre v_1 e v_2 . Portanto, ambos são livres e qualquer vetor de $\mathbb{R}^2$ pertence ao espaço nulo de $\mathbf{A}_1 - 2\mathbf{I}_2$.

Logo,

$$\mathcal{E}_2 = \mathcal{N}(\mathbf{A}_1 - 2\mathbf{I}_2) = \mathbb{R}^2.$$

Como

$$\dim(\mathbb{R}^2) = 2,$$

temos

$$m_g(2) = \dim(\mathcal{E}_2) = 2.$$

Assim, todo vetor não nulo de $\mathbb{R}^2$ é um autovetor de $\mathbf{A}_1$ associado ao autovalor $\lambda = 2$.

Autoespaço de $\mathbf{A}_2$

Para $\mathbf{A}_2$, procuramos novamente os vetores

$$\mathbf{v} = \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}$$

que satisfazem

$$(\mathbf{A}_2 - 2\mathbf{I}_2) \mathbf{v} = \mathbf{0}.$$

Calculando,

$$\begin{aligned} \mathbf{A}_2 - 2\mathbf{I}_2 &= \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix} - \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \\ &= \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}. \end{aligned}$$

Portanto,

$$\begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

Efetuando a multiplicação,

$$\begin{bmatrix} v_2 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix},$$

o que corresponde ao sistema

$$\begin{cases} v_2 = 0, \\ 0 = 0. \end{cases}$$

Nesse caso, v_2 deve ser igual a zero, enquanto v_1 permanece livre. Assim, todo vetor do autoespaço possui a forma

$$\mathbf{v} = \begin{bmatrix} v_1 \\ 0 \end{bmatrix} = v_1 \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Logo,

$$\mathcal{E}_2 = \mathcal{N}(\mathbf{A}_2 - 2\mathbf{I}_2) = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix} \right\}.$$

Esse autoespaço possui uma única direção linearmente independente. Portanto,

$$m_g(2) = \dim(\mathcal{E}_2) = 1.$$

As duas matrizes possuem, portanto, o mesmo autovalor $\lambda = 2$ e a mesma multiplicidade algébrica,

$$m_a(2) = 2,$$

mas apresentam multiplicidades geométricas diferentes:

$$m_g(2) = \begin{cases} 2, & \text{para } \mathbf{A}_1, \\ 1, & \text{para } \mathbf{A}_2. \end{cases}$$

A diferença decorre da dimensão dos respectivos autoespaços. Para $\mathbf{A}_1$, o autoespaço é todo o plano $\mathbb{R}^2$; para $\mathbf{A}_2$, o autoespaço é apenas a reta gerada por $(1,0)^\top$.

A Figura 5.4 compara o autoespaço bidimensional de $\mathbf{A}_1$ com o autoespaço unidimensional de $\mathbf{A}_2$.




Figura 5.4: Matrizes com o mesmo autovalor repetido podem possuir autoespaços de dimensões diferentes.

As duas matrizes possuem o mesmo autovalor com a mesma multiplicidade algébrica. A diferença entre as multiplicidades geométricas determina se existem autovetores suficientes para formar uma base.

5.8.2 Núcleo e imagem na decomposição espectral

Para matrizes simétricas, o autoespaço associado ao autovalor zero descreve o núcleo, enquanto os autoespaços associados aos autovalores não nulos geram a imagem.

Proposição 5.8 (Núcleo e imagem em termos dos autovetores). *Se*

$$\mathbf{A} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^\top$$

é a decomposição espectral de uma matriz simétrica, então

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j = 0 \}$$

e

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Consequentemente,

$$\text{Im}(T_{\mathbf{A}}) = \ker(T_{\mathbf{A}})^\perp,$$

ou, equivalentemente,

$$\mathcal{C}(\mathbf{A}) = \mathcal{N}(\mathbf{A})^\perp.$$

i Demonstração

Todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito na base ortonormal de autovetores como

$$\mathbf{x} = \sum_{j=1}^p z_j \mathbf{q}_j,$$

em que

$$z_j = \mathbf{q}_j^\top \mathbf{x}.$$

Aplicando $\mathbf{A}$,

$$\mathbf{A}\mathbf{x} = \sum_{j=1}^p \lambda_j z_j \mathbf{q}_j.$$

A igualdade

$$\mathbf{A}\mathbf{x} = \mathbf{0}$$

ocorre se, e somente se,

$$\lambda_j z_j = 0$$

para todo j . Portanto, as coordenadas de $\mathbf{x}$ podem ser não nulas apenas nas direções associadas a autovalores iguais a zero. Logo,

$$\mathcal{N}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j = 0 \}.$$

Toda imagem $\mathbf{A}\mathbf{x}$ é uma combinação linear dos autovetores associados a autovalores não nulos. Assim,

$$\mathcal{C}(\mathbf{A}) \subseteq \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Reciprocamente, se $\lambda_j \neq 0$, então

$$\mathbf{q}_j = \mathbf{A} \left(\frac{1}{\lambda_j} \mathbf{q}_j \right),$$

de modo que $\mathbf{q}_j \in \mathcal{C}(\mathbf{A})$. Portanto,

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Como os autovetores associados a autovalores nulos são ortogonais aos autovetores associados a autovalores não nulos, e juntos formam uma base ortonormal de $\mathbb{R}^p$, os dois subespaços são complementos ortogonais.

O autoespaço associado ao autovalor zero reúne exatamente as direções eliminadas pela trans-

formação. Os autoespaços associados a autovalores não nulos constituem, em conjunto, a imagem da transformação.

5.8.3 Pseudoinversa espectral

A pseudoinversa espectral estende a inversão às matrizes simétricas singulares sem inverter as direções pertencentes ao núcleo.

Definição 5.11 (Pseudoinversa de uma matriz simétrica). Seja

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top$$

uma matriz simétrica.

Define-se

$$\lambda_j^+ = \begin{cases} 1/\lambda_j, & \lambda_j \neq 0, \\ 0, & \lambda_j = 0. \end{cases}$$

A **pseudoinversa de Moore–Penrose** de $\mathbf{A}$ é

$$\mathbf{A}^+ = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^+ \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A}^+ = \text{diag}(\lambda_1^+, \dots, \lambda_p^+).$$

A pseudoinversa atua separadamente sobre os autoespaços: nas direções associadas a autovalores não nulos, aplica o fator $1/\lambda$; no autoespaço associado ao autovalor zero, sua ação é nula. Assim, ela inverte a transformação sobre sua imagem e mantém eliminadas as componentes pertencentes ao núcleo.

Exemplo 5.8 (Pseudoinversa de uma matriz singular). Considere

$$\mathbf{A}_0 = \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix}.$$

Seus autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 0,$$

com autovetores unitários

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A matriz $\mathbf{A}_0$ não é invertível porque possui um autovalor nulo. Para a pseudoinversa,

$$(\Lambda_{\mathbf{A}_0})^+ = \begin{bmatrix} 1/4 & 0 \\ 0 & 0 \end{bmatrix}.$$

Portanto,

$$\begin{aligned} \mathbf{A}_0^+ &= \mathbf{Q}_{\mathbf{A}_0} \begin{bmatrix} 1/4 & 0 \\ 0 & 0 \end{bmatrix} \mathbf{Q}_{\mathbf{A}_0}^\top \\ &= \frac{1}{8} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}. \end{aligned}$$

A componente na direção de $\mathbf{q}_1$ é dividida por 4. A componente na direção de $\mathbf{q}_2$, pertencente ao núcleo de $\mathbf{A}_0$, é anulada.

Quando $\mathbf{A}$ é invertível,

$$\mathbf{A}^+ = \mathbf{A}^{-1}.$$

A pseudoinversa de Moore–Penrose para matrizes retangulares é construída por meio da decomposição em valores singulares no Capítulo 6.

5.8.4 Diagonalização simultânea por congruência

A redução simultânea de duas formas quadráticas conecta o problema espectral generalizado às raízes características de uma matriz relativamente a outra (Anderson, 2003).

Considere a decomposição espectral

$$\widetilde{\mathbf{A}} = \mathbf{Q}_g \mathbf{\Lambda}_g \mathbf{Q}_g^\top,$$

em que

$$\widetilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}.$$

Defina

$$\mathbf{B}_g = \mathbf{M}^{-1/2} \mathbf{Q}_g.$$

Como $\mathbf{M}^{-1/2}$ é invertível e $\mathbf{Q}_g$ é ortogonal, $\mathbf{B}_g$ é invertível. Suas colunas formam uma base $\mathbf{M}$ -ortonormal de autovetores generalizados.

De fato,

$$\begin{aligned} \mathbf{A} \mathbf{B}_g &= \mathbf{A} \mathbf{M}^{-1/2} \mathbf{Q}_g \\ &= \mathbf{M}^{1/2} \widetilde{\mathbf{A}} \mathbf{Q}_g \\ &= \mathbf{M}^{1/2} \mathbf{Q}_g \mathbf{\Lambda}_g \\ &= \mathbf{M} \mathbf{B}_g \mathbf{\Lambda}_g. \end{aligned}$$

Além disso,

$$\begin{aligned} \mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g &= \mathbf{Q}_g^\top \mathbf{M}^{-1/2} \mathbf{M} \mathbf{M}^{-1/2} \mathbf{Q}_g \\ &= \mathbf{Q}_g^\top \mathbf{Q}_g \\ &= \mathbf{I}_p, \end{aligned}$$

e

$$\begin{aligned} \mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g &= \mathbf{Q}_g^\top \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2} \mathbf{Q}_g \\ &= \mathbf{Q}_g^\top \widetilde{\mathbf{A}} \mathbf{Q}_g \\ &= \mathbf{\Lambda}_g. \end{aligned}$$

Portanto,

$$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_p$$

e

$$\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g = \Lambda_g.$$

O par $(\mathbf{A}, \mathbf{M})$ é, assim, reduzido simultaneamente por uma transformação de congruência:

$$(\mathbf{A}, \mathbf{M}) \longrightarrow (\Lambda_g, \mathbf{I}_p).$$

Essa operação deve ser distinguida da semelhança

$$\mathbf{B}^{-1} \mathbf{A} \mathbf{B},$$

utilizada para representar um único operador em outra base. Na congruência, as matrizes aparecem multiplicadas pela transposta da matriz de base à esquerda e pela própria matriz à direita.

Como

$$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_p,$$

segue que

$$\mathbf{B}_g^{-1} = \mathbf{B}_g^\top \mathbf{M}.$$

Assim, se

$$\mathbf{a} = \mathbf{B}_g \mathbf{z},$$

então as coordenadas de $\mathbf{a}$ nessa base são

$$\mathbf{z} = \mathbf{B}_g^{-1} \mathbf{a} = \mathbf{B}_g^\top \mathbf{M} \mathbf{a}.$$

Nessas coordenadas,

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = \mathbf{z}^\top \mathbf{z}$$

e

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \mathbf{z}^\top \Lambda_g \mathbf{z}.$$

Consequentemente,

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \frac{\sum_{j=1}^p \lambda_j z_j^2}{\sum_{j=1}^p z_j^2}.$$

O quociente generalizado assume, portanto, a mesma forma do quociente de Rayleigh ordinário quando expresso na base $\mathbf{M}$ -ortonormal de autovetores generalizados.

5.8.4.1 Continuação do exemplo: forma diagonal simultânea

Os autovetores generalizados normalizados do Exemplo 5.6 formam as colunas da matriz da base

$$\mathbf{B}_g = [\mathbf{b}_{g,1} \quad \mathbf{b}_{g,2}],$$

obtêm-se

$$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_2$$

e

$$\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g = \begin{bmatrix} 3 & 0 \\ 0 & 3/2 \end{bmatrix}.$$

5.8.5 Subespaços invariantes

Subespaços invariantes aparecem na demonstração do Teorema Espectral para operadores autoadjuntos (Eaton, 2007).

Definição 5.12 (Subespaço invariante). Considere

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e um subespaço

$$\mathcal{W} \subseteq \mathbb{R}^p.$$

O subespaço $\mathcal{W}$ é **invariante sob $\mathbf{A}$** quando

$$\mathbf{A}\mathbf{w} \in \mathcal{W}$$

para todo

$$\mathbf{w} \in \mathcal{W}.$$

Isso significa que a multiplicação por $\mathbf{A}$ transforma vetores de $\mathcal{W}$ em vetores que permanecem no próprio subespaço $\mathcal{W}$.

O caso unidimensional estabelece a ligação entre subespaços invariantes e autovetores.

Seja

$$\mathbf{v} \in \mathbb{R}^p, \quad \mathbf{v} \neq \mathbf{0}.$$

O subespaço gerado por $\mathbf{v}$ é

$$\mathcal{W} = \text{span}\{\mathbf{v}\} = \{c\mathbf{v} : c \in \mathbb{R}\}.$$

Como $\mathbf{v} \neq \mathbf{0}$, o conjunto $\{\mathbf{v}\}$ é uma base de $\mathcal{W}$ e, portanto,

$$\dim(\mathcal{W}) = 1.$$

Geometricamente, $\mathcal{W}$ corresponde a uma reta que passa pela origem e está contida em $\mathbb{R}^p$.

Se $\mathcal{W}$ é invariante sob $\mathbf{A}$, então

$$\mathbf{A}\mathbf{v} \in \mathcal{W}.$$

Como todos os vetores de $\mathcal{W}$ são múltiplos escalares de $\mathbf{v}$, existe um escalar λ tal que

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

Assim, a ação de $\mathbf{A}$ sobre $\mathbf{v}$ mantém sua imagem na mesma reta gerada por $\mathbf{v}$. A magnitude pode ser alterada e, dependendo do sinal de λ , também pode ocorrer mudança de sentido.

Exemplo 5.9 (Uma reta invariante em $\mathbb{R}^2$). Considere

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$$

e o vetor

$$\mathbf{v} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

O subespaço gerado por $\mathbf{v}$ é

$$\mathcal{W} = \text{span} \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\},$$

que corresponde à reta

$$x_2 = x_1$$

em $\mathbb{R}^2$.

Aplicando $\mathbf{A}$ ao vetor $\mathbf{v}$,

$$\begin{aligned} \mathbf{A}\mathbf{v} &= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ &= \begin{bmatrix} 3 \\ 3 \end{bmatrix} = 3 \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ &= 3\mathbf{v}. \end{aligned}$$

Portanto,

$$\mathbf{A}\mathbf{v} \in \mathcal{W},$$

e a reta $\mathcal{W}$ é invariante sob $\mathbf{A}$. Nesse caso, a transformação multiplica os vetores dessa direção por um fator igual a 3, sem retirar suas imagens da reta.

A condição

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

mostra que todo subespaço invariante unidimensional é gerado por um autovetor.

5.8.6 Autovalores complexos de matrizes reais

Matrizes reais gerais podem possuir autovalores complexos; o caso simétrico real distingue-se por possuir espectro real (Gentle, 2017).

As definições de autovalor, autovetor, autoespaço e equação característica foram apresentadas inicialmente no espaço real. Elas se estendem ao espaço complexo substituindo

$$\mathbb{R}^p$$

por

$$\mathbb{C}^p$$

e permitindo

$$\lambda \in \mathbb{C}.$$

Nesse caso, um autovetor complexo é um vetor não nulo $\mathbf{v} \in \mathbb{C}^p$ que satisfaz

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

A caracterização

$$\det(\mathbf{A} - \lambda\mathbf{I}_p) = 0$$

permanece válida no espaço complexo.

Nem toda matriz real possui autovalores reais. Considere a rotação de 90° ($\theta = \frac{\pi}{2}$),

$$\mathbf{Q}_{\frac{\pi}{2}} = \begin{bmatrix} \cos\left(\frac{\pi}{2}\right) & -\sin\left(\frac{\pi}{2}\right) \\ \sin\left(\frac{\pi}{2}\right) & \cos\left(\frac{\pi}{2}\right) \end{bmatrix} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}.$$

Seu polinômio característico é

$$\begin{aligned} p_{\mathbf{Q}}(\lambda) &= \det \begin{bmatrix} -\lambda & -1 \\ 1 & -\lambda \end{bmatrix} \\ &= \lambda^2 + 1. \end{aligned}$$

A equação

$$\lambda^2 + 1 = 0$$

não possui raízes reais. Suas raízes complexas são

$$\lambda_1 = i \quad \text{e} \quad \lambda_2 = -i.$$

Portanto, a matriz não possui autovalores reais e, consequentemente, não possui autovetores reais. Geometricamente, nenhuma reta real que passa pela origem permanece invariante sob uma rotação de 90° .

Considerada como operador em $\mathbb{C}^2$, a mesma matriz possui autovalores e autovetores complexos. O espectro complexo explica a ausência de retas invariantes reais na rotação de 90° . Para matrizes simétricas reais, o Teorema 5.2 garante autovalores reais e uma base ortonormal de autovetores reais.

5.8.7 Independência entre autovetores

Autovetores associados a autovalores distintos são linearmente independentes, propriedade que permite construir bases de autovetores quando existem autovalores suficientes (Searle; Khuri, 2017).

Teorema 5.7 (Independência de autovetores associados a autovalores distintos). *Se*

$$\lambda_1, \dots, \lambda_r$$

são autovalores distintos de uma matriz $\mathbf{A}$ e

$$\mathbf{v}_1, \dots, \mathbf{v}_r$$

são autovetores associados, respectivamente, a esses autovalores, então

$$\mathbf{v}_1, \dots, \mathbf{v}_r$$

são linearmente independentes.

i Demonstração

A demonstração procede por indução sobre r .

Para $r = 1$, o resultado é imediato porque um autovetor é não nulo.

Suponha que o resultado seja válido para $r - 1$ autovetores e considere

$$c_1 \mathbf{v}_1 + \cdots + c_r \mathbf{v}_r = \mathbf{0}.$$

Multiplicando por $\mathbf{A}$,

$$c_1 \lambda_1 \mathbf{v}_1 + \cdots + c_r \lambda_r \mathbf{v}_r = \mathbf{0}.$$

Multiplicando a primeira igualdade por λ_r e subtraindo-a da segunda,

$$c_1 (\lambda_1 - \lambda_r) \mathbf{v}_1 + \cdots + c_{r-1} (\lambda_{r-1} - \lambda_r) \mathbf{v}_{r-1} = \mathbf{0}.$$

Pela hipótese de indução,

$$c_j (\lambda_j - \lambda_r) = 0, \quad j = 1, \dots, r-1.$$

Como os autovalores são distintos,

$$\lambda_j - \lambda_r \neq 0,$$

e, portanto,

$$c_1 = \cdots = c_{r-1} = 0.$$

A igualdade original reduz-se a

$$c_r \mathbf{v}_r = \mathbf{0}.$$

Como $\mathbf{v}_r \neq \mathbf{0}$, segue que $c_r = 0$. Logo, os autovetores são linearmente independentes.

Uma consequência imediata é que uma matriz de ordem p com p autovalores distintos possui uma base formada por autovetores. Essa condição é suficiente para a diagonalização, mas não é necessária: uma matriz também pode ser diagonalizável quando possui autovalores repetidos.

5.8.8 Critérios gerais de diagonalização

Para uma matriz geral, a existência de uma base completa de autovetores é equivalente à coincidência entre as multiplicidades algébrica e geométrica de cada autovalor, desde que o polinômio característico se decomponha no corpo considerado (Searle; Khuri, 2017).

Teorema 5.8 (Critérios de diagonalização). *Seja*

$$\mathbf{A} \in \mathbb{F}^{p \times p},$$

em que $\mathbb{F}$ representa $\mathbb{R}$ ou $\mathbb{C}$, e suponha que seu polinômio característico se decompõe em fatores lineares sobre $\mathbb{F}$.

São equivalentes:

1. *$\mathbf{A}$ é diagonalizável sobre $\mathbb{F}$;*
2. *$\mathbf{A}$ possui p autovetores linearmente independentes em $\mathbb{F}^p$;*
3. *existe uma base de $\mathbb{F}^p$ formada por autovetores de $\mathbf{A}$;*
4. *a soma das dimensões dos autoespaços é igual a p ;*
5. *para cada autovalor λ ,*

$$m_g(\lambda) = m_a(\lambda).$$

(Searle; Khuri, 2017)

O requisito de decomposição do polinômio característico é necessário porque uma matriz real pode não possuir todos os seus autovalores em $\mathbb{R}$. A matriz de rotação $\mathbf{Q}(\pi/2)$ não é diagonalizável sobre $\mathbb{R}$, mas é diagonalizável sobre $\mathbb{C}$, pois possui dois autovalores complexos distintos.

Uma condição suficiente para a diagonalização é a existência de p autovalores distintos. Nesse caso, o Teorema 5.7 garante p autovetores linearmente independentes.

Autovalores repetidos não impedem a diagonalização. Para

$$\mathbf{A}_1 = 2\mathbf{I}_2,$$

tem-se

$$m_g(2) = m_a(2) = 2,$$

e a matriz é diagonalizável.

Para

$$\mathbf{A}_2 = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix},$$

tem-se

$$m_g(2) = 1 < m_a(2) = 2.$$

A matriz não possui autovetores linearmente independentes em número suficiente para formar uma base e, portanto, não é diagonalizável.

5.8.9 Potências de uma matriz diagonalizável

A diagonalização permite calcular potências aplicando a potência correspondente aos autovalores (Gentle, 2017).

A representação diagonal também simplifica o cálculo de potências. Se

$$\mathbf{A} = \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1},$$

então

$$\begin{aligned} \mathbf{A}^2 &= \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1} \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1} \\ &= \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A}^2 \mathbf{B}_\mathbf{A}^{-1}. \end{aligned}$$

De forma geral, para todo inteiro $k \geq 0$,

$$\mathbf{A}^k = \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A}^k \mathbf{B}_\mathbf{A}^{-1}.$$

Como $\Lambda_\mathbf{A}$ é diagonal,

$$\Lambda_\mathbf{A}^k = \text{diag}(\lambda_1^k, \dots, \lambda_p^k).$$

Assim, a aplicação repetida do operador pode ser analisada coordenada a coordenada na base de autovetores: após k aplicações, a coordenada associada a $\mathbf{v}_j$ é multiplicada por λ_j^k .

Para matrizes quadradas arbitrárias, a diagonalização pode falhar. Pelo Teorema 5.2, toda matriz simétrica real admite uma base ortonormal de autovetores; sua diagonalização é, portanto, ortogonal e preserva a geometria euclidiana.

5.8.10 Potências inteiras de matrizes simétricas

No caso simétrico, a diagonalização ortogonal fornece a mesma construção com uma base ortonormal (Gentle, 2017).

Para um inteiro $k \geq 0$, escolha

$$f(\lambda) = \lambda^k.$$

Então,

$$\mathbf{A}^k = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^k \mathbf{Q}_\mathbf{A}^\top,$$

com

$$\Lambda_\mathbf{A}^k = \text{diag}(\lambda_1^k, \dots, \lambda_p^k).$$

Essa expressão coincide com a fórmula obtida pela diagonalização, mas a ortogonalidade de $\mathbf{Q}_\mathbf{A}$ fornece

$$\mathbf{Q}_\mathbf{A}^{-1} = \mathbf{Q}_\mathbf{A}^\top.$$

Exemplo 5.10 (Potência de uma matriz simétrica). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix},$$

com decomposição espectral

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix} \mathbf{Q}_\mathbf{A}^\top.$$

Então,

$$\mathbf{A}^2 = \mathbf{Q}_\mathbf{A} \begin{bmatrix} 16 & 0 \\ 0 & 4 \end{bmatrix} \mathbf{Q}_\mathbf{A}^\top.$$

Efetuando a multiplicação,

$$\mathbf{A}^2 = \begin{bmatrix} 10 & 6 \\ 6 & 10 \end{bmatrix}.$$

A aplicação de $\mathbf{A}$ duas vezes multiplica a componente na direção de $\mathbf{q}_1$ por

$$4^2 = 16$$

e a componente na direção de $\mathbf{q}_2$ por

$$2^2 = 4.$$

A potência $\mathbf{A}^2$ preserva os autoespaços de $\mathbf{A}$ e eleva ao quadrado os fatores de escala associados aos autovalores.

5.8.11 Exponencial e logaritmo matriciais

A definição geral de funções de matrizes diagonalizáveis permite aplicar uma função escalar ao espectro; em particular, a exponencial possui também representação por série de potências (Gentle, 2017).

A função exponencial é definida para qualquer matriz simétrica por

$$\exp(\mathbf{A}) = \mathbf{Q}_{\mathbf{A}} \operatorname{diag}(e^{\lambda_1}, \dots, e^{\lambda_p}) \mathbf{Q}_{\mathbf{A}}^{\top}.$$

Como

$$e^{\lambda_j} > 0,$$

a matriz $\exp(\mathbf{A})$ é positiva definida.

A exponencial matricial também pode ser representada pela série

$$\exp(\mathbf{A}) = \sum_{k=0}^{\infty} \frac{\mathbf{A}^k}{k!}.$$

Para uma matriz simétrica positiva definida, define-se o **logaritmo principal** por

$$\log(\mathbf{A}) = \mathbf{Q}_{\mathbf{A}} \operatorname{diag}(\log \lambda_1, \dots, \log \lambda_p) \mathbf{Q}_{\mathbf{A}}^{\top}.$$

As identidades escalares são preservadas espectralmente:

$$\exp(\log(\mathbf{A})) = \mathbf{A}$$

para $\mathbf{A} \succ 0$, e

$$\log(\exp(\mathbf{A})) = \mathbf{A}$$

para toda matriz simétrica real.

A Tabela 5.1 resume a ação de cada função espectral sobre os autovalores e as condições adicionais de definição.

Tabela 5.1: Principais funções espectrais de matrizes simétricas.

Função	Ação sobre λ_j	Condição adicional
$\mathbf{A}^k$	λ_j^k	$k \in \{0, 1, 2, \dots\}$
$\mathbf{A}^{-1}$	$1/\lambda_j$	$\lambda_j \neq 0$ para todo j
$\mathbf{A}^{1/2}$	$\sqrt{\lambda_j}$	$\mathbf{A} \succeq 0$
$\mathbf{A}^{-1/2}$	$1/\sqrt{\lambda_j}$	$\mathbf{A} \succ 0$
$\mathbf{A}^+$	$1/\lambda_j$ se $\lambda_j \neq 0$; 0 se $\lambda_j = 0$	nenhuma além da simetria assumida na seção
$\exp(\mathbf{A})$	e^{λ_j}	nenhuma além da simetria assumida na seção
$\log(\mathbf{A})$	$\log \lambda_j$	$\mathbf{A} \succ 0$

As funções espectrais preservam os autoespaços e substituem cada autovalor λ pelo escalar $f(\lambda)$. Potências, inversas, raízes e pseudoinversas correspondem a escolhas específicas de f .

5.9 Síntese do capítulo

Autovalores e autovetores identificam direções nas quais a ação de uma matriz quadrada reduz-se à multiplicação por um escalar. Os autoespaços reúnem todas as direções associadas ao mesmo autovalor.

Para

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v},$$

com $\mathbf{v} \neq \mathbf{0}$, o escalar λ é um autovalor e $\mathbf{v}$ é um autovetor correspondente. O conjunto formado pelo vetor nulo e por todos os autovetores associados a λ constitui o autoespaço

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p).$$

Os autovalores são determinados pela condição

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0.$$

A multiplicidade algébrica $m_a(\lambda)$ registra a multiplicidade de λ como raiz do polinômio característico, enquanto a multiplicidade geométrica

$$m_g(\lambda) = \dim(\mathcal{E}_\lambda)$$

mede a dimensão do autoespaço correspondente.

Quando $\mathbf{A}$ possui p autovetores linearmente independentes, eles formam uma base

$$\mathcal{B}_{\mathbf{A}} = \{\mathbf{v}_1, \dots, \mathbf{v}_p\},$$

cujas matrizes são

$$\mathbf{B}_{\mathbf{A}} = [\mathbf{v}_1 \quad \dots \quad \mathbf{v}_p].$$

Nessa base,

$$[T_{\mathbf{A}}]_{\mathcal{B}_{\mathbf{A}} \leftarrow \mathcal{B}_{\mathbf{A}}} = \mathbf{B}_{\mathbf{A}}^{-1} \mathbf{A} \mathbf{B}_{\mathbf{A}} = \Lambda_{\mathbf{A}},$$

e, portanto,

$$\mathbf{A} = \mathbf{B}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{B}_{\mathbf{A}}^{-1}.$$

A diagonalização é, assim, uma mudança para coordenadas nas quais o operador atua separadamente sobre cada direção da base de autovetores.

Para matrizes simétricas reais, o Teorema Espectral garante uma base ortonormal de autovetores. Nesse caso, a matriz da base pode ser escolhida ortogonal,

$$\mathbf{Q}_{\mathbf{A}} = [\mathbf{q}_1 \quad \dots \quad \mathbf{q}_p],$$

com

$$\mathbf{Q}_{\mathbf{A}}^{-1} = \mathbf{Q}_{\mathbf{A}}^{\top},$$

e obtém-se a decomposição espectral

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Equivalentemente,

$$\mathbf{A} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^\top.$$

Agrupando autovalores repetidos, a decomposição espectral pode ser escrita em termos dos projetores espectrais:

$$\mathbf{A} = \sum_h \lambda^{(h)} \Pi_{\lambda^{(h)}}.$$

A decomposição por projetores mostra que uma matriz simétrica atua projetando o vetor sobre autoespaços ortogonais e aplicando a cada componente o autovalor correspondente.

Os autovalores determinam diretamente o traço, o determinante e o posto da matriz:

$$\text{tr}(\mathbf{A}) = \sum_{j=1}^p \lambda_j,$$

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j,$$

e

$$\text{posto}(\mathbf{A}) = \#\{j : \lambda_j \neq 0\},$$

contando as multiplicidades.

Além disso,

$$\ker(T_\mathbf{A}) = \mathcal{N}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j = 0 \},$$

enquanto

$$\text{Im}(T_\mathbf{A}) = \mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Para matrizes simétricas,

$$\text{Im}(T_{\mathbf{A}}) = \ker(T_{\mathbf{A}})^\perp.$$

A mesma decomposição simplifica as formas quadráticas. Se

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}} = \mathbf{Q}_{\mathbf{A}}^\top \mathbf{x},$$

então

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2.$$

As possibilidades de sinal da forma quadrática são, portanto, determinadas pelos sinais dos autovalores. Quando $\mathbf{A} \succ 0$, suas superfícies de nível são elipsoides cujos eixos estão alinhados aos autovetores.

O quociente de Rayleigh,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{a}},$$

é uma média ponderada dos autovalores. Para

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p,$$

tem-se

$$\lambda_p \leq \mathcal{R}_{\mathbf{A}}(\mathbf{a}) \leq \lambda_1.$$

O máximo e o mínimo são atingidos nos autoespaços associados aos autovalores extremos. A otimização de uma forma quadrática sob a restrição

$$\mathbf{a}^\top \mathbf{a} = 1$$

conduz à condição

$$\mathbf{A} \mathbf{a} = \lambda \mathbf{a}.$$

Autovalores e autovetores podem, portanto, ser interpretados também como valores e direções estacionárias de problemas de otimização quadrática.

A decomposição espectral permite ainda definir funções de matrizes simétricas. Se f está definida no espectro de $\mathbf{A}$,

$$f(\mathbf{A}) = \mathbf{Q}_{\mathbf{A}} f(\Lambda_{\mathbf{A}}) \mathbf{Q}_{\mathbf{A}}^{\top}.$$

Equivalentemente,

$$f(\mathbf{A}) = \sum_h f(\lambda^{(h)}) \Pi_{\lambda^{(h)}}.$$

A definição espectral preserva os autoespaços e transforma cada autovalor λ no escalar $f(\lambda)$. Potências, inversas, raízes quadradas, raízes quadradas inversas, pseudoinversas, exponenciais e logaritmos correspondem a escolhas específicas de f , sob as condições de definição de cada função.

Quando a geometria do problema é determinada por uma matriz simétrica positiva definida $\mathbf{M}$, surge o problema de autovalores generalizados

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{M}\mathbf{v},$$

com $\mathbf{A} = \mathbf{A}^{\top}$ e $\mathbf{M} \succ 0$.

O quociente correspondente é

$$\mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}) = \frac{\mathbf{a}^{\top} \mathbf{A} \mathbf{a}}{\mathbf{a}^{\top} \mathbf{M} \mathbf{a}}.$$

A transformação

$$\mathbf{u} = \mathbf{M}^{1/2} \mathbf{a}$$

converte esse problema em um problema de Rayleigh ordinário para a matriz simétrica

$$\widetilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}.$$

Consequentemente, os autovalores generalizados são reais e pode-se escolher uma base de autovetores generalizados cuja matriz $\mathbf{B}_g$ satisfaz

$$\mathbf{B}_g^{\top} \mathbf{M} \mathbf{B}_g = \mathbf{I}_p$$

e

$$\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g = \Lambda_g.$$

A Tabela 5.2 organiza os principais objetos espectrais, suas expressões e interpretações.

Tabela 5.2: Síntese dos principais objetos espectrais desenvolvidos no capítulo.

Objeto	Expressão	Interpretação
Equação de autovalor	$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$	Identifica direções invariantes
Autoespaço	$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p)$	Reúne os vetores associados a λ
Diagonalização	$\mathbf{A} = \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1}$	Representa o operador em uma base de autovetores
Decomposição espectral	$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top$	Diagonaliza ortogonalmente uma matriz simétrica
Projeto espectral	$\Pi_\lambda = \mathbf{Q}_\lambda \mathbf{Q}_\lambda^\top$	Projeta sobre o autoespaço associado a λ
Forma quadrática	$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_j \lambda_j z_j^2$	Separa as contribuições das direções espectrais
Quociente de Rayleigh	$\mathcal{R}_\mathbf{A}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{a}}$	Caracteriza valores e direções espectrais por otimização
Função espectral	$f(\mathbf{A}) = \mathbf{Q}_\mathbf{A} f(\Lambda_\mathbf{A}) \mathbf{Q}_\mathbf{A}^\top$	Aplica uma função aos autovalores
Problema generalizado	$\mathbf{A}\mathbf{v} = \lambda \mathbf{M} \mathbf{v}$	Compara duas formas quadráticas
Base generalizada	$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_p$	Define ortonormalidade na geometria induzida por $\mathbf{M}$
Diagonalização por congruência	$\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g = \Lambda_g$	Reduz simultaneamente as duas formas quadráticas

Ao final deste capítulo, o estudante deverá ser capaz de:

- identificar autovalores, autovetores e autoespaços e interpretar seu significado geométrico;
- distinguir multiplicidades algébrica e geométrica;
- determinar quando uma matriz é diagonalizável;
- interpretar a diagonalização como mudança para uma base de autovetores;
- aplicar o Teorema Espectral a matrizes simétricas reais;
- interpretar projetores e subespaços espectrais;
- relacionar autovalores a traço, determinante, posto, núcleo, imagem e positividade;
- representar formas quadráticas em coordenadas espectrais;
- formular problemas de otimização por meio do quociente de Rayleigh;

- construir e interpretar funções espectrais de matrizes;
- compreender inversas, raízes e pseudoinversas pela ação sobre os autovalores;
- formular e transformar problemas de autovalores generalizados;
- distinguir ortogonalidade euclidiana de ortogonalidade segundo uma matriz positiva definida.

A decomposição espectral aplica-se diretamente a matrizes simétricas quadradas. Para matrizes retangulares ou não simétricas, a **Decomposição em Valores Singulares**, desenvolvida no Capítulo 6, relaciona a matriz aos espectros de $\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A}\mathbf{A}^\top$ e conecta valores singulares, espaços fundamentais, posto e aproximações de baixa dimensão.

6 Decomposição em Valores Singulares

Pelo Teorema 5.2, uma matriz simétrica real admite a decomposição espectral ortogonal na forma

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Essa representação identifica uma base ortonormal de autovetores na qual a transformação atua separadamente sobre cada coordenada. A decomposição espectral ortogonal, entretanto, depende da simetria da matriz e é formulada para operadores cujo domínio e contradomínio possuem a mesma dimensão.

Em Análise Multivariada, um dos objetos mais frequentes é a matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

cujas linhas representam observações e colunas representam variáveis. Em geral,

$$n \neq p,$$

de modo que $\mathbf{X}$ é retangular. Mesmo quando uma matriz é quadrada, ela pode não ser simétrica nem possuir uma base ortonormal de autovetores.

A **Decomposição em Valores Singulares**, ou SVD, fornece uma representação aplicável a qualquer matriz real. Para uma transformação

$$T_\mathbf{A} : \mathbb{R}^p \longrightarrow \mathbb{R}^q, \quad T_\mathbf{A}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

a SVD relaciona duas bases ortonormais:

- uma base do espaço de origem $\mathbb{R}^p$;
- uma base do espaço de chegada $\mathbb{R}^q$.

A transformação associa determinadas direções dessas duas bases e multiplica os comprimentos por fatores não negativos denominados **valores singulares**.

Essa representação permite descrever:

- o posto da matriz;
- os espaços das linhas e das colunas;
- o núcleo e o núcleo da transposta;
- os fatores máximos e mínimos de alteração dos comprimentos;
- aproximações de posto reduzido;
- a pseudoinversa;
- soluções de mínimos quadrados.

Para uma matriz de dados, os mesmos valores singulares conectam direções da representação por linhas em $\mathbb{R}^p$ e da representação por colunas em $\mathbb{R}^n$.

Convenções de notação

Adotam-se as seguintes convenções:

- $\mathbf{A} \in \mathbb{R}^{q \times p}$ representa uma matriz real e $T_{\mathbf{A}} : \mathbb{R}^p \rightarrow \mathbb{R}^q$ a transformação linear associada;
- $r = \text{posto}(\mathbf{A})$ representa o posto de $\mathbf{A}$;
- $d_1 \geq \dots \geq d_r > 0$ representam os valores singulares positivos de $\mathbf{A}$;
- $\mathbf{v}_j \in \mathbb{R}^p$ representa um vetor singular à direita;
- $\mathbf{u}_j \in \mathbb{R}^q$ representa um vetor singular à esquerda;
- $\mathbf{U}$, $\mathbf{D}$ e $\mathbf{V}$ representam os fatores da SVD completa;
- $\mathbf{U}_r$, $\mathbf{D}_r$ e $\mathbf{V}_r$ representam os fatores da SVD compacta;
- $\mathbf{U}_k$, $\mathbf{D}_k$ e $\mathbf{V}_k$ representam os fatores de uma SVD truncada;
- $\mathbf{A}^+$ representa a pseudoinversa de Moore–Penrose;
- $\|\mathbf{A}\|_2$ e $\|\mathbf{A}\|_F$ representam, respectivamente, as normas espectral e de Frobenius.

6.1 Definição e formas da Decomposição em Valores Singulares

Considere uma matriz real

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

que representa uma transformação de $\mathbb{R}^p$ em $\mathbb{R}^q$.

A matriz pode ser retangular, quadrada, simétrica ou não simétrica. Nenhuma hipótese de invertibilidade ou de posto completo é necessária para a existência da SVD.

Teorema 6.1 (Existência da Decomposição em Valores Singulares). *Para toda matriz*

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

existem matrizes ortogonais

$$\mathbf{U} \in \mathbb{R}^{q \times q}$$

e

$$\mathbf{V} \in \mathbb{R}^{p \times p},$$

e uma matriz diagonal retangular

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

tais que

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

As matrizes ortogonais satisfazem

$$\mathbf{U}^\top \mathbf{U} = \mathbf{U}\mathbf{U}^\top = \mathbf{I}_q$$

e

$$\mathbf{V}^\top \mathbf{V} = \mathbf{V}\mathbf{V}^\top = \mathbf{I}_p.$$

Os elementos diagonais não negativos de $\mathbf{D}$ podem ser ordenados como

$$d_1 \geq d_2 \geq \dots \geq d_{\min(q,p)} \geq 0.$$

*Esses elementos são os **valores singulares** de $\mathbf{A}$. (Eaton, 2007; Searle; Khuri, 2017)*

A construção da SVD a partir das decomposições espectrais de $\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A}\mathbf{A}^\top$ fornece a demonstração do teorema.

Definição 6.1 (Matriz diagonal retangular). Seja

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

e defina

$$s = \min(q, p).$$

A matriz $\mathbf{D}$ é denominada **diagonal retangular** quando existem escalares

$$d_1, \dots, d_s$$

tais que

$$D_{ij} = \begin{cases} d_i, & i = j \leq s, \\ 0, & \text{caso contrário.} \end{cases}$$

Assim, apenas os elementos da diagonal principal podem ser diferentes de zero.

No bloco diagonal de ordem s , essa condição pode ser escrita de forma compacta utilizando a delta de Kronecker:

$$D_{ij} = d_i \delta_{ij}, \quad i, j = 1, \dots, s.$$

Se

$$q > p,$$

então $s = p$ e $\mathbf{D}$ possui $q - p$ linhas nulas abaixo de sua parte diagonal.

Se

$$p > q,$$

então $s = q$ e $\mathbf{D}$ possui $p - q$ colunas nulas à direita de sua parte diagonal.

Por exemplo, quando $q > p$,

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & d_p \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & 0 \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

Nesse caso, a parte diagonal possui $p = \min(q, p)$ elementos e as $q - p$ linhas restantes são nulas.

Quando $p > q$,

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & \cdots & 0 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & d_q & 0 & \cdots & 0 \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

Agora, a parte diagonal possui $q = \min(q, p)$ elementos e as $p - q$ colunas restantes são nulas.

Como

$$s = \min(q, p),$$

a matriz $\mathbf{D}$ possui s posições diagonais. Se

$$r = \text{posto}(\mathbf{A}),$$

então exatamente r valores singulares são positivos. Ordenando-os de forma decrescente,

$$d_1 \geq d_2 \geq \cdots \geq d_r > 0,$$

enquanto, quando $r < s$,

$$d_{r+1} = \cdots = d_s = 0.$$

Assim, o número de valores singulares positivos é exatamente o posto de $\mathbf{A}$ e, consequentemente, a dimensão da imagem da transformação linear associada:

$$r = \text{posto}(\mathbf{A}) = \dim(\text{Im}(T_{\mathbf{A}})).$$

6.1.1 Vetores singulares

Escreva as matrizes ortogonais como

$$\mathbf{U} = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_q]$$

e

$$\mathbf{V} = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_p].$$

Definição 6.2 (Valores e vetores singulares). Na decomposição

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

os elementos diagonais não negativos

$$d_1, \dots, d_{\min(q,p)}$$

de $\mathbf{D}$ são os **valores singulares** de $\mathbf{A}$.

As colunas

$$\mathbf{v}_1, \dots, \mathbf{v}_p$$

de $\mathbf{V}$ são os **vetores singulares à direita**. Elas formam uma base ortonormal de $\mathbb{R}^p$.

As colunas

$$\mathbf{u}_1, \dots, \mathbf{u}_q$$

de $\mathbf{U}$ são os **vetores singulares à esquerda**. Elas formam uma base ortonormal de $\mathbb{R}^q$.

Para cada valor singular positivo,

$$d_j > 0, \quad j = 1, \dots, r,$$

os vetores singulares correspondentes satisfazem

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$$

e

$$\mathbf{A}^\top \mathbf{u}_j = d_j \mathbf{v}_j.$$

A primeira igualdade mostra como a transformação associa uma direção no espaço de origem a uma direção no espaço de chegada:

$$\mathbf{v}_j \xrightarrow{\mathbf{A}} d_j \mathbf{u}_j.$$

Como

$$\|\mathbf{v}_j\| = \|\mathbf{u}_j\| = 1,$$

tem-se

$$\|\mathbf{A} \mathbf{v}_j\| = d_j.$$

Portanto, d_j mede o fator de alteração do comprimento na direção $\mathbf{v}_j$:

- se $d_j > 1$, ocorre ampliação;
- se $0 < d_j < 1$, ocorre contração;
- se $d_j = 1$, o comprimento é preservado;
- se $d_j = 0$, a direção correspondente é eliminada.

Os valores singulares são sempre não negativos. Diferentemente dos autovalores, eles não representam inversões de sentido. Possíveis mudanças de orientação ficam incorporadas às matrizes ortogonais $\mathbf{U}$ e $\mathbf{V}$.

As colunas de $\mathbf{V}$ correspondentes às colunas nulas de $\mathbf{D}$ são transformadas no vetor nulo. Elas pertencem ao núcleo de $\mathbf{A}$. De maneira análoga, colunas de $\mathbf{U}$ que correspondem às linhas nulas de $\mathbf{D}$ pertencem ao núcleo de $\mathbf{A}^\top$. As identificações completas dos quatro espaços fundamentais são dadas em Proposição 6.7.

6.1.2 Interpretação como composição de transformações

Para qualquer

$$\mathbf{x} \in \mathbb{R}^p,$$

a ação de $\mathbf{A}$ pode ser escrita como

$$\mathbf{Ax} = \mathbf{UDV}^\top \mathbf{x}.$$

Essa transformação pode ser decomposta em três etapas:

$$\mathbf{x} \mapsto \mathbf{V}^\top \mathbf{x} \mapsto \mathbf{DV}^\top \mathbf{x} \mapsto \mathbf{UDV}^\top \mathbf{x}.$$

Na primeira etapa,

$$\mathbf{z} = \mathbf{V}^\top \mathbf{x}$$

fornece as coordenadas de $\mathbf{x}$ na base ortonormal dos vetores singulares à direita,

$$\mathcal{B}_V = \{\mathbf{v}_1, \dots, \mathbf{v}_p\}.$$

Assim,

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_V}.$$

Na segunda etapa,

$$\mathbf{Dz}$$

multiplica separadamente as coordenadas pelas entradas diagonais de $\mathbf{D}$. Como $\mathbf{D} \in \mathbb{R}^{q \times p}$ pode ser retangular, essa etapa também realiza a passagem entre as dimensões do domínio e do contradomínio.

Na terceira etapa, $\mathbf{U}$ reconstrói o resultado nas coordenadas canônicas de $\mathbb{R}^q$ a partir da base ortonormal

$$\mathcal{B}_U = \{\mathbf{u}_1, \dots, \mathbf{u}_q\}.$$

Como $\mathbf{U}$ e $\mathbf{V}$ são ortogonais, essas duas matrizes preservam normas, distâncias, ângulos e produtos internos. As alterações de comprimento e a possível redução de dimensão são determinadas por $\mathbf{D}$.

6.1.3 SVD completa

Definição 6.3 (SVD completa). A representação

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

com

$$\mathbf{U} \in \mathbb{R}^{q \times q}, \quad \mathbf{D} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{V} \in \mathbb{R}^{p \times p},$$

é denominada **SVD completa** de $\mathbf{A}$.

As dimensões e os papéis dos fatores são apresentados na Tabela 6.1.

Tabela 6.1: Dimensões das matrizes na SVD completa.

Matriz	Dimensão	Papel
$\mathbf{U}$	$q \times q$	Base ortonormal do espaço de chegada
$\mathbf{D}$	$q \times p$	Matriz diagonal retangular dos valores singulares
$\mathbf{V}$	$p \times p$	Base ortonormal do espaço de origem

A SVD completa descreve bases ortonormais de todo o espaço de origem e de todo o espaço de chegada. Por isso, ela contém também as direções associadas ao núcleo de $\mathbf{A}$ e ao núcleo de $\mathbf{A}^\top$.

6.1.4 SVD compacta

Quando

$$r = \text{posto}(\mathbf{A}),$$

defina

$$\mathbf{U}_r = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r] \in \mathbb{R}^{q \times r},$$

$$\mathbf{V}_r = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_r] \in \mathbb{R}^{p \times r}$$

e

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r) \in \mathbb{R}^{r \times r}.$$

Definição 6.4 (SVD compacta). A representação

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

formada somente pelos valores singulares positivos e por seus vetores singulares correspondentes, é denominada **SVD compacta** de $\mathbf{A}$.

A SVD compacta reconstrói exatamente a matriz original. Ela não é uma aproximação.

As colunas de $\mathbf{U}_r$ e de $\mathbf{V}_r$ são ortonormais:

$$\mathbf{U}_r^\top \mathbf{U}_r = \mathbf{I}_r$$

e

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r.$$

Quando $r < q$, tem-se

$$\mathbf{U}_r \mathbf{U}_r^\top \neq \mathbf{I}_q.$$

Quando $r < p$,

$$\mathbf{V}_r \mathbf{V}_r^\top \neq \mathbf{I}_p.$$

Esses produtos são os projetores ortogonais formalizados em Proposição 6.8.

As dimensões da SVD compacta são apresentadas na Tabela 6.2.

Tabela 6.2: Dimensões das matrizes na SVD compacta.

Matriz	Dimensão	Conteúdo
$\mathbf{U}_r$	$q \times r$	Vetores singulares à esquerda associados aos valores positivos
$\mathbf{D}_r$	$r \times r$	Valores singulares positivos
$\mathbf{V}_r$	$p \times r$	Vetores singulares à direita associados aos valores positivos

A forma completa acrescenta bases ortonormais para os complementos ortogonais dos subespaços gerados pelas colunas de $\mathbf{U}_r$ e $\mathbf{V}_r$.

6.1.5 SVD compacta e SVD truncada

A **SVD compacta** e a **SVD truncada** representam objetos diferentes.

A SVD compacta conserva todos os r valores singulares positivos e fornece a representação exata

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

A SVD truncada conserva apenas parte desses componentes singulares.

Para

$$1 \leq k < r,$$

defina

$$\mathbf{U}_k = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_k] \in \mathbb{R}^{q \times k},$$

$$\mathbf{D}_k = \text{diag}(d_1, \dots, d_k) \in \mathbb{R}^{k \times k}$$

e

$$\mathbf{V}_k = [\mathbf{v}_1 \quad \dots \quad \mathbf{v}_k] \in \mathbb{R}^{p \times k}.$$

Definição 6.5 (SVD truncada). Seja

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

a SVD compacta de uma matriz de posto r .

Para

$$1 \leq k < r,$$

a matriz

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top$$

é denominada **SVD truncada de posto k** de $\mathbf{A}$.

Como $k < r$, a SVD truncada descarta componentes associados a valores singulares positivos. Portanto, em geral,

$$\mathbf{A}_k \neq \mathbf{A}.$$

A matriz $\mathbf{A}_k$ possui posto k e constitui uma aproximação de $\mathbf{A}$. Os erros do truncamento são caracterizados em Proposição 6.16, e sua propriedade de otimalidade em Teorema 6.2.

A literatura apresenta formas equivalentes da SVD com fatores de dimensões diferentes. Neste capítulo, adotam-se as três convenções a seguir para distinguir a decomposição exata completa, sua forma exata reduzida aos valores singulares positivos e o truncamento aproximado (Gentle, 2017; Searle; Khuri, 2017):

- **SVD completa**, para a representação que utiliza bases ortonormais completas dos espaços de origem e de chegada;
- **SVD compacta**, para a representação exata que conserva somente os $r = \text{posto}(\mathbf{A})$ valores singulares positivos e os vetores singulares correspondentes;

- **SVD truncada**, para a aproximação que conserva apenas os $k < r$ maiores valores singulares.

Exemplo 6.1 (SVD completa, compacta e truncada de uma matriz retangular). Considere a matriz

$$\mathbf{A} = \begin{bmatrix} 2 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 2 \\ 2 & 0 & 1 \\ 1 & 1 & 1 \end{bmatrix} \in \mathbb{R}^{5 \times 3}.$$

A matriz possui posto

$$r = 3$$

e seus valores singulares, em ordem decrescente, são aproximadamente

$$d_1 = 4.1780, \quad d_2 = 2.1600, \quad d_3 = 1.3706.$$

Os valores numéricos estão arredondados a quatro casas decimais; por isso, as igualdades que utilizam esses valores estão sujeitas ao erro de arredondamento.

SVD completa

Uma SVD completa de $\mathbf{A}$ é

$$\mathbf{A} \approx \mathbf{U} \mathbf{D} \mathbf{V}^\top,$$

em que

$$\mathbf{U} \approx \begin{bmatrix} 0.4449 & 0.5397 & 0.3147 & -0.6014 & -0.2239 \\ 0.5461 & -0.2239 & 0.5466 & 0.5614 & -0.1943 \\ 0.3803 & -0.6954 & -0.3419 & -0.4142 & -0.2887 \\ 0.4348 & 0.4111 & -0.6965 & 0.3743 & -0.1295 \\ 0.4126 & -0.0779 & -0.0136 & -0.1073 & 0.9011 \end{bmatrix} \in \mathbb{R}^{5 \times 5},$$

$$\mathbf{D} \approx \begin{bmatrix} 4.1780 & 0 & 0 \\ 0 & 2.1600 & 0 \\ 0 & 0 & 1.3706 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \in \mathbb{R}^{5 \times 3},$$

e

$$\mathbf{V} \approx \begin{bmatrix} 0.6506 & 0.7406 & -0.1682 \\ 0.5576 & -0.3155 & 0.7678 \\ 0.5156 & -0.5933 & -0.6182 \end{bmatrix} \in \mathbb{R}^{3 \times 3}.$$

As colunas de $\mathbf{U}$ são os vetores singulares à esquerda,

$$\mathbf{u}_1, \dots, \mathbf{u}_5,$$

e as colunas de $\mathbf{V}$ são os vetores singulares à direita,

$$\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3.$$

Os três primeiros pares de vetores singulares estão associados aos três valores singulares positivos:

$$(\mathbf{u}_1, \mathbf{v}_1) \leftrightarrow d_1 = 4.1780,$$

$$(\mathbf{u}_2, \mathbf{v}_2) \leftrightarrow d_2 = 2.1600,$$

e

$$(\mathbf{u}_3, \mathbf{v}_3) \leftrightarrow d_3 = 1.3706.$$

As duas últimas colunas de $\mathbf{U}$ completam uma base ortonormal de $\mathbb{R}^5$. Elas correspondem às duas linhas nulas de $\mathbf{D}$.

SVD compacta

Como

$$r = \text{posto}(\mathbf{A}) = 3,$$

a SVD compacta conserva somente os três valores singulares positivos e os vetores singulares correspondentes:

$$\mathbf{A} \approx \mathbf{U}_3 \mathbf{D}_3 \mathbf{V}_3^\top,$$

com

$$\mathbf{U}_3 \approx \begin{bmatrix} 0.4449 & 0.5397 & 0.3147 \\ 0.5461 & -0.2239 & 0.5466 \\ 0.3803 & -0.6954 & -0.3419 \\ 0.4348 & 0.4111 & -0.6965 \\ 0.4126 & -0.0779 & -0.0136 \end{bmatrix} \in \mathbb{R}^{5 \times 3},$$

$$\mathbf{D}_3 \approx \begin{bmatrix} 4.1780 & 0 & 0 \\ 0 & 2.1600 & 0 \\ 0 & 0 & 1.3706 \end{bmatrix} \in \mathbb{R}^{3 \times 3},$$

e

$$\mathbf{V}_3 = \mathbf{V} \approx \begin{bmatrix} 0.6506 & 0.7406 & -0.1682 \\ 0.5576 & -0.3155 & 0.7678 \\ 0.5156 & -0.5933 & -0.6182 \end{bmatrix} \in \mathbb{R}^{3 \times 3}.$$

A representação continua sendo exata antes do arredondamento numérico. A SVD compacta elimina apenas as duas colunas adicionais de $\mathbf{U}$ e as duas linhas nulas correspondentes de $\mathbf{D}$.

Como

$$r = p = 3,$$

todos os vetores singulares à direita participam da SVD compacta. Por isso,

$$\mathbf{V}_3 = \mathbf{V}.$$

SVD truncada de posto 2

Considere agora a conservação apenas dos dois maiores valores singulares,

$$d_1 = 4.1780 \quad \text{e} \quad d_2 = 2.1600.$$

A SVD truncada de posto 2 utiliza

$$\mathbf{U}_2 \approx \begin{bmatrix} 0.4449 & 0.5397 \\ 0.5461 & -0.2239 \\ 0.3803 & -0.6954 \\ 0.4348 & 0.4111 \\ 0.4126 & -0.0779 \end{bmatrix} \in \mathbb{R}^{5 \times 2},$$

$$\mathbf{D}_2 \approx \begin{bmatrix} 4.1780 & 0 \\ 0 & 2.1600 \end{bmatrix} \in \mathbb{R}^{2 \times 2},$$

e

$$\mathbf{V}_2 \approx \begin{bmatrix} 0.6506 & 0.7406 \\ 0.5576 & -0.3155 \\ 0.5156 & -0.5933 \end{bmatrix} \in \mathbb{R}^{3 \times 2}.$$

Assim,

$$\mathbf{A}_2 = \mathbf{U}_2 \mathbf{D}_2 \mathbf{V}_2^\top$$

é uma aproximação de posto 2 da matriz original. Numericamente,

$$\mathbf{A}_2 \approx \begin{bmatrix} 2.0726 & 0.6688 & 0.2667 \\ 1.1260 & 1.4248 & 1.4631 \\ -0.0788 & 1.3598 & 1.7103 \\ 1.8394 & 0.7330 & 0.4098 \\ 0.9969 & 1.0143 & 0.9885 \end{bmatrix}.$$

Como o terceiro valor singular positivo foi descartado,

$$\mathbf{A}_2 \neq \mathbf{A}.$$

As três formas podem ser comparadas pelas dimensões de seus fatores:

Forma	Matriz à esquerda	Matriz diagonal	Matriz à direita	Valores singulares mantidos	Resultado
SVD completa	$\mathbf{U} : 5 \times 5$	$\mathbf{D} : 5 \times 3$	$\mathbf{V} : 3 \times 3$	d_1, d_2, d_3	Exato
SVD compacta	$\mathbf{U}_3 : 5 \times 3$	$\mathbf{D}_3 : 3 \times 3$	$\mathbf{V}_3 : 3 \times 3$	d_1, d_2, d_3	Exato
SVD truncada	$\mathbf{U}_2 : 5 \times 2$	$\mathbf{D}_2 : 2 \times 2$	$\mathbf{V}_2 : 3 \times 2$	d_1, d_2	Aproximado

A SVD completa apresenta bases ortonormais completas dos espaços de origem e de chegada. A SVD compacta mantém somente as direções associadas aos valores singulares positivos e reconstrói exatamente $\mathbf{A}$. A SVD truncada conserva apenas parte dessas direções e, por isso, produz uma aproximação de posto menor.

6.1.6 Sinal dos pares singulares

Os valores singulares de uma matriz são determinados de maneira única quando apresentados em ordem decrescente e consideradas suas multiplicidades. Os vetores singulares, entretanto, podem não ser únicos.

Para cada par associado a um valor singular positivo, a substituição simultânea

$$\mathbf{u}_j \mapsto -\mathbf{u}_j$$

e

$$\mathbf{v}_j \mapsto -\mathbf{v}_j$$

não altera a parcela

$$d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

pois

$$d_j (-\mathbf{u}_j) (-\mathbf{v}_j)^\top = d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Assim, cada par singular associado a um valor positivo é determinado apenas a menos de uma mudança simultânea de sinal.

6.2 Construção da SVD e relação com a decomposição espectral

A existência da SVD decorre das propriedades das duas matrizes de Gram associadas a $\mathbf{A}$:

$$\mathbf{A}^\top \mathbf{A} \quad \text{e} \quad \mathbf{A} \mathbf{A}^\top.$$

Os espectros de $\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A} \mathbf{A}^\top$ estão diretamente relacionados: seus autovalores positivos coincidem, e os autovetores correspondentes determinam as direções singulares da transformação

$$T_{\mathbf{A}} : \mathbb{R}^p \rightarrow \mathbb{R}^q.$$

Para

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

tem-se

$$\mathbf{A}^\top \mathbf{A} \in \mathbb{R}^{p \times p}$$

e

$$\mathbf{A}\mathbf{A}^\top \in \mathbb{R}^{q \times q}.$$

Mesmo que $\mathbf{A}$ seja retangular ou não simétrica, essas duas matrizes são quadradas, simétricas e semidefinidas positivas.

6.2.1 Propriedades das matrizes de Gram associadas

As matrizes

$$\mathbf{A}^\top \mathbf{A}$$

e

$$\mathbf{A}\mathbf{A}^\top$$

são matrizes de Gram associadas, respectivamente, às colunas e às linhas de $\mathbf{A}$.

Pela Proposição 3.9, ambas são simétricas e semidefinidas positivas. Portanto,

$$\mathbf{A}^\top \mathbf{A} \succeq \mathbf{0}$$

e

$$\mathbf{A}\mathbf{A}^\top \succeq \mathbf{0}.$$

Além disso,

$$\text{posto}(\mathbf{A}^\top \mathbf{A}) = \text{posto}(\mathbf{A})$$

e

$$\text{posto}(\mathbf{A}\mathbf{A}^\top) = \text{posto}(\mathbf{A}).$$

Assim, se

$$r = \text{posto}(\mathbf{A}),$$

cada uma dessas matrizes possui exatamente r autovalores positivos, considerando suas multiplicidades.

Como ambas são simétricas, o Teorema 5.2 garante a existência de bases ortonormais de autovetores. Como também são semidefinidas positivas, todos os seus autovalores são não negativos.

Proposição 6.1 (Espectros das matrizes de Gram associadas). *Seja*

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com posto

$$r = \text{posto}(\mathbf{A}).$$

Então:

1. *as matrizes*

$$\mathbf{A}^\top \mathbf{A}$$

e

$$\mathbf{A} \mathbf{A}^\top$$

possuem os mesmos r autovalores positivos, incluindo suas multiplicidades;

2. *se esses autovalores são ordenados como*

$$\lambda_1 \geq \dots \geq \lambda_r > 0,$$

podem-se definir

$$d_j = \sqrt{\lambda_j}, \quad j = 1, \dots, r;$$

3. os núcleos satisfazem

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) = \mathcal{N}(\mathbf{A})$$

e

$$\mathcal{N}(\mathbf{A}\mathbf{A}^\top) = \mathcal{N}(\mathbf{A}^\top).$$

(Eaton, 2007)



As duas matrizes podem possuir quantidades diferentes de autovalores nulos. A matriz

$$\mathbf{A}^\top \mathbf{A}$$

tem ordem p , enquanto

$$\mathbf{A}\mathbf{A}^\top$$

tem ordem q . Entretanto, seus espectros positivos coincidem.

6.2.2 Construção dos pares singulares

Suponha que

$$\mathbf{A} \neq \mathbf{0}.$$

Então,

$$r = \text{posto}(\mathbf{A}) \geq 1.$$

A construção começa pela matriz

$$\mathbf{A}^\top \mathbf{A},$$

que atua em

$$\mathbb{R}^p,$$

o domínio da transformação

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Seus autovetores associados aos autovalores positivos determinarão os **vetores singulares à direita**. A aplicação de $\mathbf{A}$ a essas direções, seguida de normalização, produzirá os **vetores singulares à esquerda** em $\mathbb{R}^q$.

Considere a decomposição espectral

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V} \Lambda_V \mathbf{V}^\top,$$

em que

$$\mathbf{V} = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_p]$$

é ortogonal.

Ordene os autovalores de modo que

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_r > 0$$

e

$$\lambda_{r+1} = \cdots = \lambda_p = 0.$$

Defina

$$d_j = \sqrt{\lambda_j}, \quad j = 1, \dots, r.$$

Particione a matriz de autovetores como

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0],$$

em que

$$\mathbf{V}_r = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_r]$$

contém os autovetores associados aos autovalores positivos e

$$\mathbf{V}_0 = [\mathbf{v}_{r+1} \quad \cdots \quad \mathbf{v}_p]$$

contém os autovetores associados ao autovalor zero.

Pela Proposição [6.1](#),

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) = \mathcal{N}(\mathbf{A}).$$

Portanto, as colunas de $\mathbf{V}_0$ formam uma base ortonormal de

$$\mathcal{N}(\mathbf{A}),$$

enquanto as colunas de $\mathbf{V}_r$ formam uma base ortonormal de

$$\mathcal{N}(\mathbf{A})^\perp = \mathcal{C}(\mathbf{A}^\top).$$

Proposição 6.2 (Construção dos pares singulares positivos). *Para cada*

$$j = 1, \dots, r,$$

defina

$$\mathbf{u}_j = \frac{\mathbf{A}\mathbf{v}_j}{d_j}.$$

Então:

1. *os vetores*

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

são ortonormais;

2. *para cada $j = 1, \dots, r$,*

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$$

e


$$\mathbf{A}^\top\mathbf{u}_j = d_j\mathbf{v}_j;$$

3. *os vetores*

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

formam uma base ortonormal de

$$\mathcal{C}(\mathbf{A}).$$



i Demonstração

Para $i, j \leq r$,

$$\begin{aligned}\mathbf{u}_i^\top \mathbf{u}_j &= \frac{\mathbf{v}_i^\top \mathbf{A}^\top \mathbf{A} \mathbf{v}_j}{d_i d_j} \\ &= \frac{d_j^2 \mathbf{v}_i^\top \mathbf{v}_j}{d_i d_j} \\ &= \frac{d_j}{d_i} \mathbf{v}_i^\top \mathbf{v}_j.\end{aligned}$$

Como os vetores

$$\mathbf{v}_1, \dots, \mathbf{v}_r$$

são ortonormais,

$$\mathbf{v}_i^\top \mathbf{v}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Logo,

$$\mathbf{u}_i^\top \mathbf{u}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Portanto,

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

são ortonormais.

Pela definição de $\mathbf{u}_j$,

$$\mathbf{A} \mathbf{v}_j = d_j \mathbf{u}_j.$$

Além disso,

$$\begin{aligned}\mathbf{A}^\top \mathbf{u}_j &= \frac{\mathbf{A}^\top \mathbf{A} \mathbf{v}_j}{d_j} \\ &= \frac{d_j^2 \mathbf{v}_j}{d_j} \\ &= d_j \mathbf{v}_j.\end{aligned}$$

Cada $\mathbf{u}_j$ pertence a

A construção estabelece uma correspondência entre duas direções ortonormais:

$$\mathbf{v}_j \in \mathcal{C}(\mathbf{A}^\top) \subseteq \mathbb{R}^p \xrightarrow{\mathbf{A}} d_j \mathbf{u}_j \in \mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q,$$

e

$$\mathbf{u}_j \in \mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q \xrightarrow{\mathbf{A}^\top} d_j \mathbf{v}_j \in \mathcal{C}(\mathbf{A}^\top) \subseteq \mathbb{R}^p.$$

Assim, $\mathbf{v}_j$ é uma direção singular à direita, $\mathbf{u}_j$ é a direção singular à esquerda correspondente e d_j é o fator de escalonamento que relaciona as duas.

6.2.3 Construção da SVD compacta

Reúna os vetores singulares à esquerda em

$$\mathbf{U}_r = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r]$$

e defina

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r).$$

As relações

$$\mathbf{A} \mathbf{v}_j = d_j \mathbf{u}_j, \quad j = 1, \dots, r,$$

podem ser escritas simultaneamente como

$$\mathbf{A} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r.$$

Proposição 6.3 (SVD compacta obtida dos pares singulares). *Com as matrizes $\mathbf{U}_r$, $\mathbf{D}_r$ e $\mathbf{V}_r$ definidas anteriormente,*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

Portanto,

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de $\mathbf{A}$, e

$$d_1, \dots, d_r$$

são seus valores singulares positivos.

i Demonstração

Como

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0]$$

é ortogonal,

$$\mathbf{I}_p = \mathbf{V}_r \mathbf{V}_r^\top + \mathbf{V}_0 \mathbf{V}_0^\top.$$

As colunas de $\mathbf{V}_0$ pertencem a

$$\mathcal{N}(\mathbf{A}),$$

de modo que

$$\mathbf{A} \mathbf{V}_0 = \mathbf{0}.$$


Assim,

$$\begin{aligned} \mathbf{A} &= \mathbf{A} \mathbf{I}_p \\ &= \mathbf{A} (\mathbf{V}_r \mathbf{V}_r^\top + \mathbf{V}_0 \mathbf{V}_0^\top) \\ &= \mathbf{A} \mathbf{V}_r \mathbf{V}_r^\top \\ &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top. \end{aligned}$$

A SVD compacta utiliza exatamente as direções que participam da transformação:

- as colunas de $\mathbf{V}_r$ formam uma base ortonormal de $\mathcal{C}(\mathbf{A}^\top)$;
- $\mathbf{D}_r$ contém os fatores de escalonamento positivos;
- as colunas de $\mathbf{U}_r$ formam uma base ortonormal de $\mathcal{C}(\mathbf{A})$.

A Proposição 6.3 fornece a parte não nula da decomposição; a SVD completa é obtida completando as bases ortonormais dos espaços envolvidos.



i Demonstração

Se

$$\mathbf{A} = \mathbf{0},$$

tome

$$\mathbf{U} = \mathbf{I}_q, \quad \mathbf{V} = \mathbf{I}_p$$

e

$$\mathbf{D} = \mathbf{0}_{q \times p}.$$

Então,

$$\mathbf{A} = \mathbf{U} \mathbf{D} \mathbf{V}^\top.$$

Suponha agora que

$$447$$

$$\mathbf{A} \neq \mathbf{0}.$$

Pela Proposição 6.3,

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

As colunas de $\mathbf{U}_r$ formam uma base ortonormal de

6.2.4 Decomposições espectrais associadas

Proposição 6.4 (Decomposições espectrais induzidas pela SVD). *Se*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

então

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top$$

e

$$\mathbf{A} \mathbf{A}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

i Demonstração

Utilizando a SVD compacta,

$$\begin{aligned} \mathbf{A}^\top \mathbf{A} &= (\mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top)^\top (\mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top) \\ &= \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top. \end{aligned}$$

Como as colunas de $\mathbf{U}_r$ são ortonormais,

$$\mathbf{U}_r^\top \mathbf{U}_r = \mathbf{I}_r.$$

Portanto,

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top.$$

Analogamente,

$$\begin{aligned} \mathbf{A} \mathbf{A}^\top &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \\ &= \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top, \end{aligned}$$

pois

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r.$$

Na forma completa, as decomposições são

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V} \operatorname{diag} \left(d_1^2, \dots, d_r^2, \underbrace{0, \dots, 0}_{p-r} \right) \mathbf{V}^\top$$

e

$$\mathbf{A} \mathbf{A}^\top = \mathbf{U} \operatorname{diag} \left(d_1^2, \dots, d_r^2, \underbrace{0, \dots, 0}_{q-r} \right) \mathbf{U}^\top.$$

Essas expressões deixam explícito que:

- $\mathbf{A}^\top \mathbf{A}$ possui $p - r$ autovalores nulos;
- $\mathbf{A} \mathbf{A}^\top$ possui $q - r$ autovalores nulos;
- as duas matrizes possuem os mesmos r autovalores positivos.

Para cada $j = 1, \dots, r$,

$$\mathbf{A}^\top \mathbf{A} \mathbf{v}_j = d_j^2 \mathbf{v}_j$$

e

$$\mathbf{A} \mathbf{A}^\top \mathbf{u}_j = d_j^2 \mathbf{u}_j.$$

Assim, os valores singulares podem ser obtidos por

$$d_j = \sqrt{\lambda_j},$$

em que λ_j é um autovalor positivo de qualquer uma das duas matrizes de Gram.

As duas decomposições também identificam os espaços aos quais pertencem os vetores singulares:

$$\mathbf{v}_j \in \mathcal{C}(\mathbf{A}^\top) \subseteq \mathbb{R}^p$$

e

$$\mathbf{u}_j \in \mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q.$$

Portanto, $\mathbf{A}^\top \mathbf{A}$ descreve a estrutura espectral relevante no domínio, enquanto $\mathbf{A} \mathbf{A}^\top$ descreve a estrutura correspondente no contradomínio. Os valores singulares positivos realizam a ligação entre esses dois espaços.

6.2.5 Exemplo de construção da SVD

Exemplo 6.2 (Construção da SVD de uma matriz retangular). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

A matriz possui dimensão 3×2 . Inicialmente,

$$\begin{aligned} \mathbf{A}^\top \mathbf{A} &= \begin{bmatrix} 1 & 1 & 1 \\ 1 & -1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}. \end{aligned}$$

A matriz $\mathbf{A}^\top \mathbf{A}$ coincide com a matriz analisada em Exemplo 5.1. Seus autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Os valores singulares são as raízes quadradas não negativas:

$$d_1 = 2 \quad \text{e} \quad d_2 = \sqrt{2}.$$

Autovetores unitários associados são

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Portanto,

$$\mathbf{V}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

O primeiro vetor singular à esquerda é

$$\begin{aligned}
\mathbf{u}_1 &= \frac{\mathbf{A}\mathbf{v}_1}{d_1} \\
&= \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\
&= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}.
\end{aligned}$$

O segundo é

$$\begin{aligned}
\mathbf{u}_2 &= \frac{\mathbf{A}\mathbf{v}_2}{d_2} \\
&= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\
&= \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}.
\end{aligned}$$

Logo,

$$\mathbf{U}_2 = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 0 & 1 \\ 1/\sqrt{2} & 0 \end{bmatrix}$$

e

$$\mathbf{D}_2 = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix}.$$

A SVD compacta é

$$\mathbf{A} = \mathbf{U}_2 \mathbf{D}_2 \mathbf{V}_2^\top.$$

Como os dois valores singulares são positivos,

$$\text{posto}(\mathbf{A}) = 2.$$

Para construir a SVD completa, é necessário completar as colunas de $\mathbf{U}_2$ com um vetor unitário ortogonal a $\mathbf{u}_1$ e $\mathbf{u}_2$. Pode-se escolher

$$\mathbf{u}_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}.$$

Assim,

$$\mathbf{U} = \begin{bmatrix} 1/\sqrt{2} & 0 & 1/\sqrt{2} \\ 0 & 1 & 0 \\ 1/\sqrt{2} & 0 & -1/\sqrt{2} \end{bmatrix}$$

e

$$\mathbf{D} = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix}.$$

Como $\mathbf{V}_2$ já é uma matriz 2×2 ortogonal,

$$\mathbf{V} = \mathbf{V}_2.$$

A SVD completa é

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

Por outro lado,

$$\mathbf{A}\mathbf{A}^\top = \begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & 0 \\ 2 & 0 & 2 \end{bmatrix}.$$

Seus autovalores são

$$4, \quad 2, \quad 0,$$

com autovetores unitários

$$\mathbf{u}_1, \quad \mathbf{u}_2, \quad \mathbf{u}_3,$$

respectivamente.

O exemplo mostra que:

- $\mathbf{A}^\top \mathbf{A}$ determina as direções singulares no espaço de origem $\mathbb{R}^2$;
- $\mathbf{A}\mathbf{A}^\top$ determina as direções singulares no espaço de chegada $\mathbb{R}^3$;
- os dois espaços são relacionados pelos mesmos valores singulares positivos.

6.2.6 Relação com a decomposição espectral de matrizes simétricas

Se $\mathbf{A}$ é quadrada e simétrica, sua decomposição espectral é

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Quando

$$\mathbf{A} \succeq 0,$$

todos os autovalores são não negativos. Nesse caso, pode-se escolher uma SVD na qual, após ordenar os autovalores,

$$\mathbf{U} = \mathbf{V} = \mathbf{Q}_\mathbf{A}$$

e

$$\mathbf{D} = \Lambda_\mathbf{A}.$$

Portanto, a SVD coincide com a decomposição espectral:

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

6.3 Interpretação geométrica da SVD

A SVD descreve uma transformação linear por meio de duas bases ortonormais e de um escalonamento entre elas. Para

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

a matriz $\mathbf{V}^\top$ expressa os vetores nas coordenadas dos vetores singulares à direita, $\mathbf{D}$ altera separadamente essas coordenadas e $\mathbf{U}$ expressa o resultado nas direções singulares à esquerda.

Considere um vetor

$$\mathbf{x} \in \mathbb{R}^p.$$

Como as colunas de $\mathbf{V}$ formam uma base ortonormal, ele pode ser escrito como

$$\mathbf{x} = \sum_{j=1}^p \alpha_j \mathbf{v}_j,$$

em que

$$\alpha_j = \mathbf{v}_j^\top \mathbf{x}.$$

Aplicando $\mathbf{A}$,

$$\begin{aligned} \mathbf{A}\mathbf{x} &= \sum_{j=1}^p \alpha_j \mathbf{A}\mathbf{v}_j \\ &= \sum_{j=1}^r d_j \alpha_j \mathbf{u}_j. \end{aligned}$$

As parcelas associadas aos vetores

$$\mathbf{v}_{r+1}, \dots, \mathbf{v}_p$$

desaparecem porque pertencem ao núcleo de $\mathbf{A}$.

A transformação pode, portanto, ser interpretada por meio das correspondências

$$\mathbf{v}_j \mapsto d_j \mathbf{u}_j, \quad j = 1, \dots, r.$$

Cada vetor singular à direita determina uma direção no domínio. O valor singular correspondente determina o fator de escala, enquanto o vetor singular à esquerda determina a direção resultante no contradomínio.

6.3.1 Imagem da bola unitária

Considere a bola unitária de $\mathbb{R}^p$:

$$\mathcal{B}_p = \{\mathbf{x} \in \mathbb{R}^p : \|\mathbf{x}\| \leq 1\}.$$

A SVD permite descrever geometricamente sua imagem pela transformação $\mathbf{A}$.

Proposição 6.5 (Imagem da bola unitária pela SVD). *Seja*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

a SVD compacta de uma matriz de posto $r \geq 1$. A imagem da bola unitária por $\mathbf{A}$ é o elipsoide sólido de dimensão r , contido em $\mathcal{C}(\mathbf{A})$,

$$\mathbf{A}(\mathcal{B}_p) = \left\{ \sum_{j=1}^r \beta_j \mathbf{u}_j : \sum_{j=1}^r \frac{\beta_j^2}{d_j^2} \leq 1 \right\}.$$

As direções principais desse elipsoide são

$$\mathbf{u}_1, \dots, \mathbf{u}_r,$$

e os comprimentos de seus semieixos são

$$d_1, \dots, d_r.$$


Em particular,

$$\mathbf{A}(\mathcal{B}_p) \subseteq \mathcal{C}(\mathbf{A}),$$

e a dimensão desse elipsoide é

$$\dim(\mathcal{C}(\mathbf{A})) = r.$$

No caso extremo $\mathbf{A} = \mathbf{0}$, a imagem da bola unitária reduz-se ao conjunto $\{\mathbf{0}\}$.



i Demonstração

Escreva

$$\mathbf{x} = \sum_{j=1}^r \alpha_j \mathbf{v}_j + \mathbf{x}_0,$$

em que

$$\mathbf{x}_0 \in \mathcal{N}(\mathbf{A}).$$

Como os vetores singulares à direita e o núcleo formam subespaços ortogonais,

$$\|\mathbf{x}\|^2 = \sum_{j=1}^r \alpha_j^2 + \|\mathbf{x}_0\|^2.$$

Se $\mathbf{x} \in \mathcal{B}_p$, então

$$\sum_{j=1}^r \alpha_j^2 \leq 1.$$

Aplicando a transformação,

$$\mathbf{Ax} = \sum_{j=1}^r d_j \alpha_j \mathbf{u}_j.$$

Definindo

$$\beta_j = d_j \alpha_j,$$

obtem-se

$$\sum_{j=1}^r \frac{\beta_j^2}{d_j^2} = \sum_{j=1}^r \alpha_j^2 \leq 1.$$

Portanto, toda imagem de um vetor da bola unitária pertence ao elipsoide apresentado.

Reciprocamente, considere um vetor 457

$$\mathbf{y} = \sum_{j=1}^r \beta_j \mathbf{u}_j$$

que satisfaz

$$\sum_{j=1}^r \frac{\beta_j^2}{d_j^2} \leq 1$$

O comportamento da esfera unitária depende da existência de um núcleo não trivial.

Se $\mathbf{A}$ possui posto coluna completo,

$$r = p,$$

então

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}.$$

Nesse caso, a imagem da esfera unitária

$$\mathcal{S}_{p-1} = \{\mathbf{x} \in \mathbb{R}^p : \|\mathbf{x}\| = 1\}$$

é a fronteira relativa do elipsoide

$$\mathbf{A}(\mathcal{B}_p)$$

no subespaço $\mathcal{C}(\mathbf{A})$.

Por outro lado, se

$$r < p,$$

então

$$\dim(\mathcal{N}(\mathbf{A})) = p - r > 0.$$

Nesse caso, a imagem da esfera unitária coincide com a imagem da bola unitária:

$$\mathbf{A}(\mathcal{S}_{p-1}) = \mathbf{A}(\mathcal{B}_p).$$

De fato, para qualquer ponto do elipsoide cuja componente nas direções $\mathbf{v}_1, \dots, \mathbf{v}_r$ tenha norma menor que 1, pode-se acrescentar uma componente pertencente ao núcleo até obter um vetor de norma 1, sem alterar sua imagem por $\mathbf{A}$.

Finalmente, se

$$r < q,$$

o elipsoide não ocupa todo o espaço de chegada. Ele está contido no subespaço de dimensão r

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{u}_1, \dots, \mathbf{u}_r \} \subset \mathbb{R}^q.$$

Assim, a geometria da imagem da bola revela simultaneamente os fatores de escala da transformação e a dimensão de sua imagem.

6.3.2 Alteração dos comprimentos

Os valores singulares permitem determinar os fatores extremos de alteração dos comprimentos produzidos pela transformação.

Proposição 6.6 (Extremos da alteração dos comprimentos). *Seja*

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

uma matriz de posto $r \geq 1$, com valores singulares positivos ordenados como

$$d_1 \geq d_2 \geq \dots \geq d_r > 0.$$

Então, para todo

$$\mathbf{x} \in \mathbb{R}^p,$$

tem-se

$$\|\mathbf{Ax}\| \leq d_1 \|\mathbf{x}\|.$$

Consequentemente,

$$\max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_1.$$

Se $\mathbf{A}$ possui posto coluna completo, isto é,

$$r = p,$$

então

$$d_p \|\mathbf{x}\| \leq \|\mathbf{Ax}\| \leq d_1 \|\mathbf{x}\|$$

para todo $\mathbf{x} \in \mathbb{R}^p$, e


$$\min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_p.$$

Se

$$r < p,$$

então

$$\min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = 0.$$



O maior valor singular d_1 representa, portanto, o maior fator de ampliação produzido pela transformação. Quando $\mathbf{A}$ possui posto coluna completo, o menor valor singular d_p representa o menor fator de alteração de comprimento entre vetores unitários. Quando o posto coluna não é completo, existem direções unitárias eliminadas pela transformação, e o menor comprimento possível da imagem é zero.

O maior valor singular determina a norma espectral em Definição 6.8, e os valores singulares extremos determinam o número de condição em Definição 6.9.

6.3.3 Exemplo geométrico no plano

Exemplo 6.3 (Transformação da circunferência unitária em uma elipse). Considere a matriz não simétrica

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix}.$$

Sua SVD pode ser escrita como

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

com valores singulares aproximadamente iguais a

$$d_1 \approx 2,288$$

e

$$d_2 \approx 0,874.$$

A circunferência unitária pode ser parametrizada por

$$\mathbf{x}(\theta) = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix}, \quad 0 \leq \theta \leq 2\pi.$$

Sua imagem é

$$\mathbf{y}(\theta) = \mathbf{A}\mathbf{x}(\theta).$$

A SVD mostra que essa imagem é uma elipse com:

- semieixo maior de comprimento d_1 na direção $\mathbf{u}_1$;

- semieixo menor de comprimento d_2 na direção $\mathbf{u}_2$.

No domínio, as direções correspondentes são $\mathbf{v}_1$ e $\mathbf{v}_2$.

A Figura 6.1 mostra as direções singulares no domínio e no contradomínio. No primeiro painel, $\mathbf{v}_1$ e $\mathbf{v}_2$ formam uma base ortonormal de $\mathbb{R}^2$ e identificam duas direções sobre a circunferência unitária. No segundo, essas direções são transformadas em $d_1\mathbf{u}_1$ e $d_2\mathbf{u}_2$, que determinam os semieixos da elipse.




Figura 6.1: A SVD transforma as direções singulares à direita nos semieixos da elipse orientados pelos vetores singulares à esquerda.

Neste exemplo, as bases singulares do domínio e do contradomínio são distintas. A matriz $\mathbf{V}^T$ expressa os pontos da circunferência nas coordenadas da base formada por $\mathbf{v}_1$ e $\mathbf{v}_2$. Como essa transformação é ortogonal, a circunferência permanece uma circunferência. Em seguida, $\mathbf{D}$ realiza a deformação, multiplicando os comprimentos nas duas direções por d_1 e d_2 . Finalmente, $\mathbf{U}$ orienta os semieixos da elipse nas direções $\mathbf{u}_1$ e $\mathbf{u}_2$ no espaço de chegada.

6.3.4 Transformações com núcleo não trivial

Quando

$$r < p,$$

a transformação possui núcleo não trivial e elimina $p - r$ direções linearmente independentes do domínio. Geometricamente, a imagem da bola unitária passa a ter dimensão inferior à dimensão do domínio.

Exemplo 6.4 (Colapso de uma direção pela transformação). Considere

$$\mathbf{A}_0 = \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}.$$

Os valores singulares são

$$d_1 = 2 \quad \text{e} \quad d_2 = 0.$$

A ação da transformação sobre um vetor

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

é

$$\mathbf{A}_0 \mathbf{x} = \begin{bmatrix} 2x_1 \\ 0 \end{bmatrix}.$$

Portanto, toda a direção

$$\mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

é eliminada, pois

$$\mathbf{A}_0 \mathbf{e}_2 = \mathbf{0}.$$

De fato,

$$\mathcal{N}(\mathbf{A}_0) = \text{span} \{ \mathbf{e}_2 \}.$$

A bola unitária de $\mathbb{R}^2$ é transformada no segmento

$$\left\{ \begin{bmatrix} y_1 \\ 0 \end{bmatrix} : -2 \leq y_1 \leq 2 \right\}.$$

Assim, a imagem possui dimensão 1, que coincide com

$$\text{posto}(\mathbf{A}_0) = 1.$$

O valor singular positivo $d_1 = 2$ determina o comprimento do único semieixo não nulo, enquanto o valor singular $d_2 = 0$ identifica a direção eliminada pela transformação.

De modo geral:

- cada valor singular positivo produz um semieixo não nulo da imagem;
- existem exatamente r semieixos não nulos;
- o núcleo possui dimensão $p - r$ e contém todas as direções que são transformadas no vetor nulo;
- a dimensão do elipsoide resultante é r ;
- o elipsoide está contido em $\mathcal{C}(\mathbf{A})$.

A SVD identifica bases ortonormais dos quatro espaços fundamentais associados à matriz. Essas bases determinam o posto, os núcleos e os projetores ortogonais, enquanto os valores singulares determinam as normas espectral e de Frobenius.

6.4 Espaços fundamentais, posto e normas

A SVD fornece bases ortonormais para os quatro espaços fundamentais associados a uma matriz. Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com posto

$$r = \text{posto}(\mathbf{A})$$

e SVD compacta

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

As colunas de

$$\mathbf{U}_r \in \mathbb{R}^{q \times r}$$

são os vetores singulares à esquerda associados aos valores singulares positivos. As colunas de

$$\mathbf{V}_r \in \mathbb{R}^{p \times r}$$

são os vetores singulares à direita correspondentes.

Complete essas matrizes com bases ortonormais dos respectivos complementos:

$$\mathbf{U} = [\mathbf{U}_r \quad \mathbf{U}_0]$$

e

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0],$$

em que

$$\mathbf{U}_0 \in \mathbb{R}^{q \times (q-r)}$$

e

$$\mathbf{V}_0 \in \mathbb{R}^{p \times (p-r)}.$$

Quando $r = q$, a matriz $\mathbf{U}_0$ não possui colunas. Quando $r = p$, o mesmo ocorre com $\mathbf{V}_0$.

6.4.1 Espaço coluna e espaço linha

Proposição 6.7 (Espaços fundamentais determinados pela SVD). *Se*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de posto r , então

$$\mathcal{C}(\mathbf{A}) = \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_r\} = \mathcal{C}(\mathbf{U}_r),$$


$$\mathcal{C}(\mathbf{A}^\top) = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_r\} = \mathcal{C}(\mathbf{V}_r),$$

$$\mathcal{N}(\mathbf{A}) = \text{span} \{ \mathbf{v}_{r+1}, \dots, \mathbf{v}_p \} = \mathcal{C}(\mathbf{V}_0),$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \text{span} \{ \mathbf{u}_{r+1}, \dots, \mathbf{u}_q \} = \mathcal{C}(\mathbf{U}_0).$$

(Eaton, 2007)



i Demonstração

Pela SVD compacta,

$$\mathbf{Ax} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^p$. Logo, toda imagem de $\mathbf{A}$ é uma combinação linear das colunas de $\mathbf{U}_r$:

$$\mathcal{C}(\mathbf{A}) \subseteq \mathcal{C}(\mathbf{U}_r).$$

Reciprocamente, para cada $j = 1, \dots, r$,

$$\mathbf{Av}_j = d_j \mathbf{u}_j.$$

Como $d_j > 0$,

$$\mathbf{u}_j = \mathbf{A} \left(\frac{1}{d_j} \mathbf{v}_j \right).$$

Portanto,

As quatro bases fornecidas pela SVD podem ser organizadas como na Tabela 6.3.

Tabela 6.3: Espaços fundamentais e bases ortonormais fornecidas pela SVD.

Espaço	Subespaço de	Base ortonormal fornecida pela SVD	Dimensão
Espaço coluna $\mathcal{C}(\mathbf{A})$	$\mathbb{R}^q$	Colunas de $\mathbf{U}_r$	r
Núcleo à esquerda $\mathcal{N}(\mathbf{A}^\top)$	$\mathbb{R}^q$	Colunas de $\mathbf{U}_0$	$q - r$
Espaço linha $\mathcal{C}(\mathbf{A}^\top)$	$\mathbb{R}^p$	Colunas de $\mathbf{V}_r$	r
Núcleo $\mathcal{N}(\mathbf{A})$	$\mathbb{R}^p$	Colunas de $\mathbf{V}_0$	$p - r$

A SVD torna explícitas as decomposições ortogonais

$$\mathbb{R}^q = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top)$$

e

$$\mathbb{R}^p = \mathcal{C}(\mathbf{A}^\top) \oplus \mathcal{N}(\mathbf{A}).$$

O símbolo $\oplus$ indica uma soma direta ortogonal.

Todo vetor

$$\mathbf{y} \in \mathbb{R}^q$$

pode ser escrito de maneira única como

$$\mathbf{y} = \mathbf{y}_{\mathcal{C}} + \mathbf{y}_{\mathcal{N}},$$

com

$$\mathbf{y}_{\mathcal{C}} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{y}_{\mathcal{N}} \in \mathcal{N}(\mathbf{A}^\top).$$

De modo análogo, todo vetor

$$\mathbf{x} \in \mathbb{R}^p$$

se decompõe em uma parcela no espaço linha e outra no núcleo de $\mathbf{A}$.

6.4.2 Projetores ortogonais

A identificação das bases dos quatro espaços fundamentais permite construir diretamente seus projetores ortogonais.

Proposição 6.8 (Projetores dos espaços fundamentais pela SVD). *Considere a SVD completa escrita como*

$$\mathbf{U} = [\mathbf{U}_r \quad \mathbf{U}_0]$$

e

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0].$$

Então, os projetores ortogonais sobre os quatro espaços fundamentais são

$$\mathbf{P}_{\mathcal{C}(\mathbf{A})} = \mathbf{U}_r \mathbf{U}_r^\top$$

e

$$\mathbf{P}_{\mathcal{N}(\mathbf{A}^\top)} = \mathbf{U}_0 \mathbf{U}_0^\top = \mathbf{I}_q - \mathbf{U}_r \mathbf{U}_r^\top.$$

No espaço de origem,

$$\mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)} = \mathbf{V}_r \mathbf{V}_r^\top$$

e

$$\mathbf{P}_{\mathcal{N}(\mathbf{A})} = \mathbf{V}_0 \mathbf{V}_0^\top = \mathbf{I}_p - \mathbf{V}_r \mathbf{V}_r^\top.$$

i Demonstração

Pela Proposição 6.7,

$$\mathcal{C}(\mathbf{A}) = \mathcal{C}(\mathbf{U}_r)$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{U}_0).$$

Como as colunas de $\mathbf{U}_r$ e de $\mathbf{U}_0$ são ortonormais, a Proposição 3.14 fornece

$$\mathbf{P}_{\mathcal{C}(\mathbf{A})} = \mathbf{U}_r \mathbf{U}_r^\top$$

e

$$\mathbf{P}_{\mathcal{N}(\mathbf{A}^\top)} = \mathbf{U}_0 \mathbf{U}_0^\top.$$

Além disso, como

$$\mathbf{U} = [\mathbf{U}_r \quad \mathbf{U}_0]$$

é ortogonal,

$$\mathbf{U} \mathbf{U}^\top = \mathbf{I}_q.$$

Portanto,

$$\mathbf{U}_r \mathbf{U}_r^\top + \mathbf{U}_0 \mathbf{U}_0^\top = \mathbf{I}_q,$$

de onde

$$\mathbf{U}_0 \mathbf{U}_0^\top = \mathbf{I}_q - \mathbf{U}_r \mathbf{U}_r^\top.$$

Aplicando o mesmo argumento a

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0],$$

obtêm-se

$$\mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)} = \mathbf{V}_r \mathbf{V}_r^\top$$

e

$$\mathbf{P}_{\mathcal{N}(\mathbf{A})} = \mathbf{V}_0 \mathbf{V}_0^\top = \mathbf{I}_p - \mathbf{V}_r \mathbf{V}_r^\top.$$

Como são projetores ortogonais, essas matrizes são simétricas e idempotentes pela Proposi-

ção 3.16.

Exemplo 6.5 (Espaços fundamentais do exemplo condutor). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

Sua SVD completa foi construída com

$$\mathbf{u}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \quad \mathbf{u}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{u}_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}.$$

Os vetores singulares à direita são

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Como os dois valores singulares são positivos,

$$r = 2.$$

Assim,

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{u}_1, \mathbf{u}_2 \},$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \text{span} \{ \mathbf{u}_3 \}.$$

A matriz possui posto coluna completo, pois

$$r = p = 2.$$

Consequentemente,

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$$

e

$$\mathcal{C}(\mathbf{A}^\top) = \mathbb{R}^2.$$

O projetor sobre o espaço coluna é

$$\begin{aligned}\mathbf{U}_2 \mathbf{U}_2^\top &= \mathbf{u}_1 \mathbf{u}_1^\top + \mathbf{u}_2 \mathbf{u}_2^\top \\ &= \begin{bmatrix} 1/2 & 0 & 1/2 \\ 0 & 1 & 0 \\ 1/2 & 0 & 1/2 \end{bmatrix}.\end{aligned}$$

O projetor sobre o núcleo à esquerda é

$$\mathbf{u}_3 \mathbf{u}_3^\top = \begin{bmatrix} 1/2 & 0 & -1/2 \\ 0 & 0 & 0 \\ -1/2 & 0 & 1/2 \end{bmatrix}.$$

A soma dos dois projetores é

$$\mathbf{U}_2 \mathbf{U}_2^\top + \mathbf{u}_3 \mathbf{u}_3^\top = \mathbf{I}_3.$$

6.4.3 Posto e nulidades

Pela SVD, o posto de $\mathbf{A}$ é exatamente o número de valores singulares positivos:

$$\text{posto}(\mathbf{A}) = r = \#\{j : d_j > 0\}.$$

Como consequência do Teorema Posto–Nulidade,

$$\dim \mathcal{N}(\mathbf{A}) = p - r$$

e

$$\dim \mathcal{N}(\mathbf{A}^\top) = q - r.$$

Essas dimensões também são visualizadas diretamente na SVD completa:

- as r colunas de $\mathbf{V}_r$ formam uma base do espaço linha;
- as $p - r$ colunas de $\mathbf{V}_0$ formam uma base do núcleo de $\mathbf{A}$;
- as r colunas de $\mathbf{U}_r$ formam uma base do espaço coluna;
- as $q - r$ colunas de $\mathbf{U}_0$ formam uma base do núcleo de $\mathbf{A}^\top$.

As dimensões $p - r$ e $q - r$ dos núcleos não coincidem, em geral, com o número de posições diagonais nulas de $\mathbf{D}$. Como

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

possui apenas

$$s = \min(q, p)$$

posições diagonais, existem

$$s - r$$

valores singulares nulos entre essas posições, enquanto as dimensões dos dois núcleos são, respectivamente,

$$p - r \quad \text{e} \quad q - r.$$

Assim, em matrizes retangulares, a estrutura completa dos núcleos não deve ser inferida apenas pela quantidade de elementos diagonais nulos de $\mathbf{D}$.

A Tabela 6.4 reúne as principais relações entre os valores e vetores singulares e a estrutura da transformação.

Tabela 6.4: Relação entre a SVD e a estrutura da matriz.

Estrutura ou propriedade	Caracterização pela SVD
Posto	Número de valores singulares positivos
Imagem $\mathcal{C}(\mathbf{A})$	Vetores singulares à esquerda associados a $d_j > 0$

Estrutura ou propriedade	Caracterização pela SVD
Espaço linha $\mathcal{C}(\mathbf{A}^\top)$	Vetores singulares à direita associados a $d_j > 0$
Núcleo $\mathcal{N}(\mathbf{A})$	Vetores singulares à direita associados à parte nula
Núcleo à esquerda $\mathcal{N}(\mathbf{A}^\top)$	Vetores singulares à esquerda associados à parte nula
Ampliação máxima	d_1
Menor fator positivo de escala	d_r

Se $r < p$, a menor norma de $\mathbf{A}\mathbf{x}$ entre todos os vetores unitários do domínio é zero, pois existem vetores unitários no núcleo. O valor d_r descreve o menor fator **positivo** de escala, isto é, a menor ação da transformação quando restrita ao espaço linha $\mathcal{C}(\mathbf{A}^\top)$.

6.4.4 Produto interno de Frobenius

O estudo das aproximações matriciais exige uma geometria para o espaço das matrizes.

Definição 6.6 (Produto interno de Frobenius). Para matrizes

$$\mathbf{A}, \widetilde{\mathbf{A}} \in \mathbb{R}^{q \times p},$$

o produto interno de Frobenius é

$$\langle \mathbf{A}, \widetilde{\mathbf{A}} \rangle_F = \text{tr}(\mathbf{A}^\top \widetilde{\mathbf{A}}).$$

Equivalentemente,

$$\langle \mathbf{A}, \widetilde{\mathbf{A}} \rangle_F = \sum_{i=1}^q \sum_{j=1}^p a_{ij} \widetilde{a}_{ij}.$$

O produto interno de Frobenius trata uma matriz como um vetor formado por todos os seus elementos. Duas matrizes são ortogonais segundo esse produto quando

$$\langle \mathbf{A}, \widetilde{\mathbf{A}} \rangle_F = 0.$$

A norma induzida por esse produto interno é a norma de Frobenius.

Definição 6.7 (Norma de Frobenius). A **norma de Frobenius** de

$$\mathbf{A} = (a_{ij}) \in \mathbb{R}^{q \times p}$$

é

$$\|\mathbf{A}\|_F = \sqrt{\langle \mathbf{A}, \mathbf{A} \rangle_F}.$$

Equivalentemente,

$$\|\mathbf{A}\|_F = \sqrt{\text{tr}(\mathbf{A}^\top \mathbf{A})}$$

ou

$$\|\mathbf{A}\|_F = \sqrt{\sum_{i=1}^q \sum_{j=1}^p a_{ij}^2}.$$

A norma de Frobenius mede a magnitude quadrática total dos elementos da matriz.

6.4.5 Normas e valores singulares

Definição 6.8 (Norma espectral). A **norma espectral**, ou norma matricial induzida pela norma euclidiana, é

$$\|\mathbf{A}\|_2 = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|}.$$

Equivalentemente,

$$\|\mathbf{A}\|_2 = \max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\|.$$

Pela Proposição 6.6, a norma espectral é o maior fator de ampliação produzido pela transformação.

Proposição 6.9 (Normas matriciais e valores singulares). *Se*

$$d_1 \geq \cdots \geq d_r > 0$$

são os valores singulares positivos de $\mathbf{A}$, então

$$\|\mathbf{A}\|_2 = d_1$$

e

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

(Gentle, 2017)

i Demonstração

Pela Proposição 6.6,

$$\max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_1.$$

Como, pela Definição 6.8,

$$\|\mathbf{A}\|_2 = \max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\|,$$

segue imediatamente que

$$\|\mathbf{A}\|_2 = d_1.$$

Para a norma de Frobenius, utilizando a Proposição 6.4,

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top.$$

Portanto,

$$\begin{aligned} \|\mathbf{A}\|_F^2 &= \text{tr}(\mathbf{A}^\top \mathbf{A}) \\ &= \text{tr}(\mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top) \\ &= \text{tr}(\mathbf{D}_r^2 \mathbf{V}_r^\top \mathbf{V}_r) \\ &= \text{tr}(\mathbf{D}_r^2) \\ &= \sum_{j=1}^r d_j^2. \end{aligned}$$

Logo,

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

Se $\mathbf{A} = \mathbf{0}$, então não há valores singulares positivos e, diretamente pelas definições,

$$\|\mathbf{A}\|_2 = \|\mathbf{A}\|_F = 0.$$

As duas normas medem aspectos diferentes:

- $\|\mathbf{A}\|_2$ depende somente do maior valor singular e representa o maior fator de ampliação;
- $\|\mathbf{A}\|_F$ reúne as contribuições quadráticas de todos os valores singulares.

Para qualquer matriz,

$$\|\mathbf{A}\|_2 \leq \|\mathbf{A}\|_F \leq \sqrt{r}\|\mathbf{A}\|_2.$$

A primeira desigualdade decorre de

$$d_1^2 \leq \sum_{j=1}^r d_j^2.$$

A segunda decorre de

$$\sum_{j=1}^r d_j^2 \leq r d_1^2.$$

6.5 Condicionamento e número de condição

Em uma matriz de posto máximo, os valores singulares extremos descrevem a maior e a menor escala ativa da transformação. Uma grande disparidade entre essas escalas indica que a inversão das direções mais contraídas pode amplificar pequenas perturbações.

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e defina

$$s = \min(q, p).$$

Quando

$$\text{posto}(\mathbf{A}) = s,$$

a matriz possui o maior posto possível para suas dimensões e todos os seus s valores singulares são positivos:

$$d_1 \geq \dots \geq d_s > 0.$$

Definição 6.9 (Número de condição na norma espectral). Para uma matriz de posto máximo,

$$\text{posto}(\mathbf{A}) = s,$$

define-se o **número de condição na norma espectral** por

$$\kappa_2(\mathbf{A}) = \frac{d_1}{d_s}.$$

(Gentle, 2017)

Neste material, quando

$$\text{posto}(\mathbf{A}) < s,$$

adota-se

$$\kappa_2(\mathbf{A}) = \infty.$$

Para matrizes de posto máximo, o número de condição compara o maior e o menor fatores positivos de escala associados à transformação.

Quando

$$\kappa_2(\mathbf{A}) \approx 1,$$

os valores singulares extremos possuem magnitudes semelhantes. Quando

$$\kappa_2(\mathbf{A})$$

é elevado, algumas direções ativas são transformadas por fatores muito maiores que outras.

Núcleo não trivial, deficiência de posto e mau condicionamento são propriedades distintas.

A deficiência de posto ocorre quando

$$\text{posto}(\mathbf{A}) < \min(q, p).$$

Entretanto, uma matriz retangular pode possuir núcleo não trivial mesmo apresentando posto máximo.

Por exemplo, se

$$q < p$$

e

$$\text{posto}(\mathbf{A}) = q,$$

então $\mathbf{A}$ possui posto linha completo e, portanto, posto máximo. Mesmo assim,

$$\dim \mathcal{N}(\mathbf{A}) = p - q > 0.$$

Assim, existem direções do domínio que são transformadas no vetor nulo.

Nesse caso, a transformação não é injetiva em todo o domínio $\mathbb{R}^p$. Sua restrição ao espaço linha,

$$\mathcal{C}(\mathbf{A}^\top) = \mathcal{N}(\mathbf{A})^\perp,$$

é, entretanto, injetiva.

Nesse subespaço,

$$d_q = \min_{\substack{\|\mathbf{x}\|=1 \\ \mathbf{x} \in \mathcal{C}(\mathbf{A}^\top)}} \|\mathbf{A}\mathbf{x}\|.$$

Portanto, para matrizes largas de posto linha completo, o número de condição finito descreve a variação dos fatores de escala sobre o espaço linha, isto é, sobre a parte do domínio na qual a transformação atua de forma injetiva.

Se

$$q \geq p$$

e

$$\text{posto}(\mathbf{A}) = p,$$

então $\mathbf{A}$ possui posto coluna completo e

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}.$$

Nesse caso,

$$d_p = \min_{\|\mathbf{x}\|=1} \|\mathbf{A}\mathbf{x}\|$$

e

$$\kappa_2(\mathbf{A}) = \frac{d_1}{d_p}.$$

Para uma matriz quadrada invertível,

$$q = p = r,$$

tem-se também

$$\kappa_2(\mathbf{A}) = \|\mathbf{A}\|_2 \|\mathbf{A}^{-1}\|_2.$$

De fato,

$$\|\mathbf{A}\|_2 = d_1,$$

e os valores singulares de $\mathbf{A}^{-1}$ são

$$\frac{1}{d_p}, \dots, \frac{1}{d_1}.$$

Portanto,

$$\|\mathbf{A}^{-1}\|_2 = \frac{1}{d_p},$$

de modo que

$$\kappa_2(\mathbf{A}) = \frac{d_1}{d_p}.$$

Uma matriz de posto máximo com número de condição elevado é denominada **mal condicionada**. Valores singulares positivos muito pequenos indicam direções nas quais a transformação produz forte contração. Ao inverter a ação da matriz nessas direções, pequenas perturbações podem ser amplificadas.

Essa amplificação explica por que posto completo e invertibilidade não garantem, por si sós, estabilidade numérica.

Exemplo 6.6 (Comparação entre duas transformações). Considere

$$\mathbf{A}_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

e

$$\mathbf{A}_2 = \begin{bmatrix} 2 & 0 \\ 0 & 0,02 \end{bmatrix}.$$

Os valores singulares de $\mathbf{A}_1$ são

$$2 \quad \text{e} \quad 2.$$

Portanto,

$$\kappa_2(\mathbf{A}_1) = 1.$$

Nesse caso, as duas direções singulares são transformadas pelo mesmo fator.

Para $\mathbf{A}_2$, os valores singulares são

$$2 \quad \text{e} \quad 0,02.$$

Logo,

$$\kappa_2(\mathbf{A}_2) = \frac{2}{0,02} = 100.$$

A primeira direção é ampliada por um fator igual a 2, enquanto a segunda é contraída por um fator igual a 0,02.

A inversão da segunda componente exige um fator

$$\frac{1}{0,02} = 50.$$

Consequentemente, pequenas perturbações nessa direção podem ser fortemente ampliadas quando se procura inverter a transformação.

6.6 SVD de uma matriz de dados

Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

em que as linhas representam n observações e as colunas representam p variáveis.

Se

$$r = \text{posto}(\mathbf{X}),$$

a SVD compacta é

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

com

$$\mathbf{U}_r \in \mathbb{R}^{n \times r}, \quad \mathbf{D}_r \in \mathbb{R}^{r \times r}$$

e

$$\mathbf{V}_r \in \mathbb{R}^{p \times r}.$$

A SVD relaciona as representações por linhas e por colunas da matriz de dados:

- as colunas de $\mathbf{V}_r$ pertencem a $\mathbb{R}^p$ e determinam direções na representação das observações por linhas;
- as colunas de $\mathbf{U}_r$ pertencem a $\mathbb{R}^n$ e determinam direções na representação das variáveis por colunas.

Os mesmos valores singulares conectam essas duas representações.

6.6.1 Dualidade entre observações e variáveis

A SVD relaciona diretamente as duas representações da matriz de dados: as observações como vetores em $\mathbb{R}^p$ e as variáveis como vetores em $\mathbb{R}^n$.

Proposição 6.10 (Dualidade entre observações e variáveis). *Se*

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

então

$$\mathbf{X} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r$$

e

$$\mathbf{X}^\top \mathbf{U}_r = \mathbf{V}_r \mathbf{D}_r.$$

Consequentemente, para

$$j = 1, \dots, r,$$

tem-se

$$\mathbf{X} \mathbf{v}_j = d_j \mathbf{u}_j$$

e

$$\mathbf{X}^\top \mathbf{u}_j = d_j \mathbf{v}_j.$$

Assim, o mesmo valor singular d_j relaciona uma direção $\mathbf{v}_j$ em $\mathbb{R}^p$, associada à representação das observações por linhas, a uma direção $\mathbf{u}_j$ em $\mathbb{R}^n$, associada à representação das variáveis por colunas.

i Demonstração

Multiplicando a SVD compacta à direita por $\mathbf{V}_r$,

$$\begin{aligned}\mathbf{X}\mathbf{V}_r &= \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top\mathbf{V}_r \\ &= \mathbf{U}_r\mathbf{D}_r,\end{aligned}$$

pois

$$\mathbf{V}_r^\top\mathbf{V}_r = \mathbf{I}_r.$$

Transpondo a SVD compacta,

$$\mathbf{X}^\top = \mathbf{V}_r\mathbf{D}_r\mathbf{U}_r^\top.$$

Multiplicando à direita por $\mathbf{U}_r$,

$$\begin{aligned}\mathbf{X}^\top\mathbf{U}_r &= \mathbf{V}_r\mathbf{D}_r\mathbf{U}_r^\top\mathbf{U}_r \\ &= \mathbf{V}_r\mathbf{D}_r,\end{aligned}$$

pois

$$\mathbf{U}_r^\top\mathbf{U}_r = \mathbf{I}_r.$$

As relações correspondentes a cada coluna seguem diretamente dessas duas identidades matriciais.

6.6.2 Coordenadas das observações nas direções singulares à direita

Defina

$$\mathbf{Z} = \mathbf{X}\mathbf{V}_r.$$

Pela Proposição 6.10,

$$\mathbf{Z} = \mathbf{U}_r\mathbf{D}_r.$$

A matriz

$$\mathbf{Z} \in \mathbb{R}^{n \times r}$$

contém as coordenadas das observações na base ortonormal

$$\{\mathbf{v}_1, \dots, \mathbf{v}_r\}$$

do espaço linha

$$\mathcal{C}(\mathbf{X}^\top) \subseteq \mathbb{R}^p.$$

Como cada observação pertence a esse subespaço, as r coordenadas são suficientes para representá-la exatamente.

Se a linha i de $\mathbf{X}$ corresponde ao vetor

$$\mathbf{x}_i \in \mathbb{R}^p,$$

então

$$z_{ij} = \mathbf{x}_i^\top \mathbf{v}_j.$$

Portanto, z_{ij} é a coordenada da observação i na direção singular $\mathbf{v}_j$.

A j -ésima coluna de $\mathbf{Z}$ é

$$\mathbf{z}_j = \mathbf{X}\mathbf{v}_j = d_j \mathbf{u}_j.$$

Assim, $\mathbf{v}_j$ determina a direção utilizada para representar as observações, enquanto $\mathbf{u}_j$ descreve como as coordenadas correspondentes se distribuem entre as n unidades observacionais.

6.6.3 Coordenadas das variáveis nas direções singulares à esquerda

A relação dual é

$$\mathbf{U}_r^\top \mathbf{X} = \mathbf{D}_r \mathbf{V}_r^\top.$$

Defina

$$\mathbf{W} = \mathbf{U}_r^\top \mathbf{X} \in \mathbb{R}^{r \times p}.$$

Cada coluna de $\mathbf{X}$ representa uma variável como vetor em $\mathbb{R}^n$. Se

$$\mathbf{x}^{(j)} \in \mathbb{R}^n$$

denota a j -ésima variável, então a j -ésima coluna de $\mathbf{W}$ contém suas coordenadas na base ortonormal

$$\{\mathbf{u}_1, \dots, \mathbf{u}_r\}$$

do espaço coluna

$$\mathcal{C}(\mathbf{X}) \subseteq \mathbb{R}^n.$$

Para a direção singular ℓ ,

$$\mathbf{u}_\ell^\top \mathbf{x}^{(j)} = d_\ell v_{j\ell}.$$

Portanto, os elementos de $\mathbf{V}_r$, escalonados pelos valores singulares, também descrevem as coordenadas das variáveis na base singular à esquerda.

As relações

$$\mathbf{X}\mathbf{V}_r = \mathbf{U}_r\mathbf{D}_r$$

e

$$\mathbf{X}^\top \mathbf{U}_r = \mathbf{V}_r\mathbf{D}_r$$

expressam, assim, a dualidade entre a representação por linhas e a representação por colunas da matriz de dados.

6.6.4 Matrizes de Gram da matriz de dados

As duas matrizes de Gram associadas a $\mathbf{X}$ descrevem relações entre objetos diferentes.

A matriz

$$\mathbf{X}^\top \mathbf{X} \in \mathbb{R}^{p \times p}$$

reúne os produtos internos entre as colunas de $\mathbf{X}$, isto é, entre as variáveis representadas como vetores em $\mathbb{R}^n$.

A matriz

$$\mathbf{X}\mathbf{X}^\top \in \mathbb{R}^{n \times n}$$

reúne os produtos internos entre as linhas de $\mathbf{X}$, isto é, entre as observações representadas como vetores em $\mathbb{R}^p$.

Pela Proposição 6.4,

$$\mathbf{X}^\top \mathbf{X} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top$$

e

$$\mathbf{X}\mathbf{X}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

Portanto, as duas matrizes possuem os mesmos autovalores positivos,

$$d_1^2, \dots, d_r^2,$$

mas seus autovetores pertencem a espaços diferentes:

- $\mathbf{v}_j \in \mathbb{R}^p$ determina uma direção associada à representação das observações por linhas;
- $\mathbf{u}_j \in \mathbb{R}^n$ determina uma direção associada à representação das variáveis por colunas.

As matrizes $\mathbf{X}^\top \mathbf{X}$ e $\mathbf{X}\mathbf{X}^\top$ possuem ordens p e n , respectivamente. Se

$$n \gg p,$$

a matriz

$$\mathbf{X}^\top \mathbf{X}$$

possui ordem menor. Se

$$p \gg n,$$

a matriz

$$\mathbf{X}\mathbf{X}^\top$$

possui ordem menor.

Em ambos os casos, os autovalores positivos são os mesmos e correspondem aos quadrados dos valores singulares de $\mathbf{X}$.

6.6.5 Representação exata das observações

Proposição 6.11 (Preservação da geometria pelas coordenadas singulares). *Seja*

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

a SVD compacta de uma matriz de dados e defina

$$\mathbf{Z} = \mathbf{X} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r.$$

Então,

$$\mathbf{X} = \mathbf{Z} \mathbf{V}_r^\top$$

e

$$\mathbf{Z} \mathbf{Z}^\top = \mathbf{X} \mathbf{X}^\top.$$

Consequentemente, para quaisquer observações $\mathbf{x}_i$ e $\mathbf{x}_\ell$, com coordenadas correspondentes $\mathbf{z}_i$ e $\mathbf{z}_\ell$,

$$\mathbf{x}_i^\top \mathbf{x}_\ell = \mathbf{z}_i^\top \mathbf{z}_\ell,$$

$$\|\mathbf{x}_i\| = \|\mathbf{z}_i\|$$

e

$$\|\mathbf{x}_i - \mathbf{x}_\ell\| = \|\mathbf{z}_i - \mathbf{z}_\ell\|.$$

i Demonstração

Como

$$\mathbf{Z} = \mathbf{U}_r \mathbf{D}_r,$$

segue da SVD compacta que

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top = \mathbf{Z} \mathbf{V}_r^\top.$$

Além disso,

$$\begin{aligned} \mathbf{Z} \mathbf{Z}^\top &= \mathbf{U}_r \mathbf{D}_r \mathbf{D}_r \mathbf{U}_r^\top \\ &= \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top. \end{aligned}$$

Pela Proposição 6.4,

$$\mathbf{X} \mathbf{X}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

Portanto,

$$\mathbf{Z} \mathbf{Z}^\top = \mathbf{X} \mathbf{X}^\top.$$

Os elementos dessas duas matrizes são os produtos internos entre pares de observações. Logo,

$$\mathbf{x}_i^\top \mathbf{x}_\ell = \mathbf{z}_i^\top \mathbf{z}_\ell.$$

Tomando $i = \ell$, obtém-se

$$\|\mathbf{x}_i\|^2 = \|\mathbf{z}_i\|^2.$$

Finalmente,

$$\begin{aligned} \|\mathbf{x}_i - \mathbf{x}_\ell\|^2 &= \|\mathbf{x}_i\|^2 + \|\mathbf{x}_\ell\|^2 - 2\mathbf{x}_i^\top \mathbf{x}_\ell \\ &= \|\mathbf{z}_i\|^2 + \|\mathbf{z}_\ell\|^2 - 2\mathbf{z}_i^\top \mathbf{z}_\ell \\ &= \|\mathbf{z}_i - \mathbf{z}_\ell\|^2. \end{aligned}$$

A reconstrução de cada observação pode ser escrita como

$$\mathbf{x}_i = \sum_{j=1}^r z_{ij} \mathbf{v}_j.$$

Portanto,

$$\mathbf{x}_i \in \mathcal{C}(\mathbf{V}_r) \subseteq \mathbb{R}^p.$$

Se

$$r < p,$$

as observações podem ser representadas exatamente por apenas r coordenadas, sem alteração de seus produtos internos, normas ou distâncias euclidianas.

Essa situação pode ocorrer mesmo quando $\mathbf{X}$ possui o maior posto possível para suas dimensões. Por exemplo, se

$$n < p$$

e

$$r = n,$$

a matriz possui posto linha completo, mas ainda assim

$$r < p.$$

Nesse caso, as observações ocupam um subespaço de dimensão r dentro de $\mathbb{R}^p$ e sua representação por $\mathbf{Z}$ é exata.

6.6.6 Centralização da matriz de dados

A posição da nuvem depende de seu centro. Para estudar os afastamentos em relação ao vetor de médias, utiliza-se a matriz centralizada

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X},$$

em que

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

Proposição 6.12 (Vetores singulares à esquerda de uma matriz centralizada). *Se*

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de dados centralizada, então

$$\mathbf{1}_n^\top \mathbf{U}_r = \mathbf{0}^\top.$$

Consequentemente,

$$\mathbf{1}_n^\top \mathbf{u}_j = 0, \quad j = 1, \dots, r,$$

e as colunas da matriz de coordenadas

$$\mathbf{Z} = \mathbf{X}_c \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r$$

também possuem média igual a zero.

i Demonstração

Como as colunas de $\mathbf{X}_c$ estão centralizadas,

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{0}^\top.$$

Substituindo a SVD compacta,

$$\mathbf{1}_n^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top = \mathbf{0}^\top.$$

Como $\mathbf{D}_r$ é invertível e $\mathbf{V}_r$ possui colunas ortonormais, segue que

$$\mathbf{1}_n^\top \mathbf{U}_r = \mathbf{0}^\top.$$

Portanto,

$$\mathbf{1}_n^\top \mathbf{u}_j = 0, \quad j = 1, \dots, r.$$

Como

$$\mathbf{z}_j = d_j \mathbf{u}_j,$$

tem-se também

$$\mathbf{1}_n^\top \mathbf{z}_j = 0.$$

6.6.7 Relação com a matriz de covariâncias amostral

Para uma matriz de dados centralizada $\mathbf{X}_c$, com $n \geq 2$, considere

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c.$$

A SVD compacta de $\mathbf{X}_c$ determina diretamente a decomposição espectral de $\mathbf{S}$.

Proposição 6.13 (Relação entre a SVD e a covariância amostral). *Se*

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta da matriz de dados centralizada, então

$$\mathbf{S} = \mathbf{V}_r \left(\frac{\mathbf{D}_r^2}{n-1} \right) \mathbf{V}_r^\top.$$

Consequentemente:

- *os vetores singulares à direita de $\mathbf{X}_c$ são autovetores de $\mathbf{S}$ associados aos autovalores positivos;*
- *os autovalores positivos de $\mathbf{S}$ são*

$$\lambda_j = \frac{d_j^2}{n-1}, \quad j = 1, \dots, r;$$

- *tem-se*

$$\text{posto}(\mathbf{S}) = \text{posto}(\mathbf{X}_c) = r.$$

(Gentle, 2017)

i Demonstração

Substituindo a SVD compacta,

$$\begin{aligned}\mathbf{S} &= \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c \\ &= \frac{1}{n-1} \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \mathbf{V}_r \left(\frac{\mathbf{D}_r^2}{n-1} \right) \mathbf{V}_r^\top,\end{aligned}$$

pois

$$\mathbf{U}_r^\top \mathbf{U}_r = \mathbf{I}_r.$$

A expressão obtida é uma decomposição espectral de $\mathbf{S}$ em seu subespaço associado aos autovalores positivos. Portanto, os autovetores correspondentes são as colunas de $\mathbf{V}_r$ e os autovalores positivos são

$$\frac{d_j^2}{n-1}.$$

Como $\mathbf{D}_r$ possui exatamente r elementos diagonais positivos,

$$\text{posto}(\mathbf{S}) = r.$$

A centralização impõe ainda uma restrição ao posto. Como

$$\text{posto}(\mathbf{H}_n) = n - 1,$$

tem-se

$$\text{posto}(\mathbf{X}_c) \leq \min(n-1, p).$$

Consequentemente,

$$\text{posto}(\mathbf{S}) \leq \min(n-1, p).$$

Em particular, se

$$p \geq n,$$

então

$$\text{posto}(\mathbf{S}) \leq n - 1 < p,$$

e a matriz de covariâncias amostral é necessariamente singular.

Portanto, a SVD da matriz centralizada determina diretamente a estrutura espectral da matriz de covariâncias amostral.

Exemplo 6.7 (Coordenadas singulares de uma matriz de dados). Considere a matriz

$$\mathbf{X} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix},$$

cuja SVD compacta é

$$\mathbf{X} = \mathbf{U}_2 \mathbf{D}_2 \mathbf{V}_2^\top,$$

com

$$\mathbf{U}_2 = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 0 & 1 \\ 1/\sqrt{2} & 0 \end{bmatrix},$$

$$\mathbf{D}_2 = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix}$$

e

$$\mathbf{V}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

As coordenadas das observações nas direções singulares à direita são

$$\begin{aligned} \mathbf{Z} &= \mathbf{X} \mathbf{V}_2 \\ &= \mathbf{U}_2 \mathbf{D}_2 \\ &= \begin{bmatrix} \sqrt{2} & 0 \\ 0 & \sqrt{2} \\ \sqrt{2} & 0 \end{bmatrix}. \end{aligned}$$

A primeira e a terceira observações possuem as mesmas coordenadas, pois suas linhas originais são iguais.

Além disso,

$$\mathbf{Z}\mathbf{Z}^\top = \begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & 0 \\ 2 & 0 & 2 \end{bmatrix} = \mathbf{X}\mathbf{X}^\top.$$

Portanto, os produtos internos e as distâncias entre as observações são preservados pela representação nas duas direções singulares positivas.

Nesse exemplo,

$$r = p = 2.$$

Por isso, a transformação por $\mathbf{V}_2$ representa apenas uma mudança ortogonal de coordenadas na representação das observações por linhas. Não ocorre redução exata da dimensão.

Se o posto fosse menor que p , a representação por $\mathbf{Z}$ utilizaria menos colunas que a matriz original e ainda preservaria exatamente a geometria da nuvem.

6.6.8 Representação exata e aproximação

A SVD compacta fornece a representação exata

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

Como todos os r componentes associados a valores singulares positivos são mantidos:

- a matriz é reconstruída exatamente;
- os produtos internos entre as observações são preservados;
- as normas das observações são preservadas;
- as distâncias euclidianas entre as observações são preservadas;
- nenhuma parcela da norma de Frobenius é descartada.

Uma representação de dimensão menor pode ser construída conservando apenas os primeiros k pares singulares, com

$$k < r.$$

Nesse caso, componentes associados a valores singulares positivos são deliberadamente descartados e a reconstrução deixa de ser exata.

A distinção é:

- a **SVD compacta** omite dos fatores completos apenas direções associadas à parte nula da transformação e preserva exatamente a matriz;
- a **SVD truncada** descarta também componentes associados a valores singulares positivos e produz uma aproximação.

Na forma expandida da SVD, a contribuição de cada componente singular e o erro produzido pelo truncamento podem ser identificados separadamente.

6.7 Forma expandida e aproximações de posto reduzido

A SVD compacta também pode ser expressa como uma soma de componentes matriciais associados aos pares singulares.

Proposição 6.14 (Forma expandida da SVD). *Se*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de posto r , então

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Cada parcela

$$d_j \mathbf{u}_j \mathbf{v}_j^\top$$

possui posto 1 e satisfaz

$$\|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_2 = \|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_F = d_j.$$



i Demonstração

Escrevendo

$$\mathbf{U}_r = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r],$$

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r)$$

e

$$\mathbf{V}_r = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_r],$$

tem-se

$$\begin{aligned} \mathbf{A} &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top. \end{aligned}$$

Como $\mathbf{u}_j$ e $\mathbf{v}_j$ são não nulos,

$$\text{posto}(\mathbf{u}_j \mathbf{v}_j^\top) = 1.$$

Multiplicar por $d_j > 0$ não altera o posto, de modo que

$$\text{posto}(d_j \mathbf{u}_j \mathbf{v}_j^\top) = 1.$$

Para a norma espectral, se $\|\mathbf{x}\| = 1$,

$$\begin{aligned} \|d_j \mathbf{u}_j \mathbf{v}_j^\top \mathbf{x}\| &= d_j |\mathbf{v}_j^\top \mathbf{x}| \|\mathbf{u}_j\| \\ &\leq d_j. \end{aligned}$$

A igualdade é atingida para

$$\mathbf{x} = \mathbf{v}_j.$$

Portanto,

$$\|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_2 = d_j.$$

Para a norma de Frobenius,

$$\begin{aligned} \|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_F^2 &= d_j^2 \text{tr}(\mathbf{v}_j \mathbf{u}_j^\top \mathbf{u}_j \mathbf{v}_j^\top) \\ &= d_j^2 (\mathbf{u}_j^\top \mathbf{u}_j) (\mathbf{v}_j^\top \mathbf{v}_j) \\ &= d_j^2. \end{aligned}$$

Logo,

502

$$\|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_F = d_j.$$

A expressão

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top$$

é denominada **forma expandida da SVD**.

Cada componente singular representa uma transformação de posto 1: a componente do vetor de entrada na direção $\mathbf{v}_j$ é multiplicada por d_j e enviada para a direção $\mathbf{u}_j$.

Como

$$d_1 \geq d_2 \geq \dots \geq d_r > 0,$$

os componentes singulares estão ordenados de acordo com suas magnitudes nas normas espectral e de Frobenius.

6.7.1 Ortogonalidade dos componentes singulares

Proposição 6.15 (Ortogonalidade dos componentes singulares). *Para*

$$i \neq j,$$

os componentes singulares

$$d_i \mathbf{u}_i \mathbf{v}_i^\top$$

e

$$d_j \mathbf{u}_j \mathbf{v}_j^\top$$

são ortogonais segundo o produto interno de Frobenius:

$$\langle d_i \mathbf{u}_i \mathbf{v}_i^\top, d_j \mathbf{u}_j \mathbf{v}_j^\top \rangle_F = 0.$$

i Demonstração

Pelo produto interno de Frobenius,

$$\begin{aligned}\langle d_i \mathbf{u}_i \mathbf{v}_i^\top, d_j \mathbf{u}_j \mathbf{v}_j^\top \rangle_F \\&= d_i d_j \operatorname{tr} \left[(\mathbf{u}_i \mathbf{v}_i^\top)^\top (\mathbf{u}_j \mathbf{v}_j^\top) \right] \\&= d_i d_j (\mathbf{u}_i^\top \mathbf{u}_j) (\mathbf{v}_j^\top \mathbf{v}_i).\end{aligned}$$

Como os vetores singulares são ortonormais, para $i \neq j$,

$$\mathbf{u}_i^\top \mathbf{u}_j = 0$$

e

$$\mathbf{v}_i^\top \mathbf{v}_j = 0.$$

Logo,

$$\langle d_i \mathbf{u}_i \mathbf{v}_i^\top, d_j \mathbf{u}_j \mathbf{v}_j^\top \rangle_F = 0.$$

Como a forma expandida é uma soma de componentes ortogonais segundo o produto interno de Frobenius,

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

Essa igualdade fornece uma decomposição pitagórica da magnitude quadrática total da matriz entre seus componentes singulares.

6.7.2 SVD truncada na forma expandida

Pela Definição 6.5, a aproximação de posto k pode ser expressa diretamente a partir da forma expandida da SVD.

Se

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

então

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top, \quad 1 \leq k < r.$$

Equivalentemente,

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Assim, truncar a SVD corresponde a conservar as primeiras k parcelas singulares e descartar

$$\sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

O erro do truncamento é determinado pelas parcelas singulares descartadas.

Como as colunas de $\mathbf{U}_k$ e $\mathbf{V}_k$ são linearmente independentes e os elementos diagonais de $\mathbf{D}_k$ são positivos,

$$\text{posto}(\mathbf{A}_k) = k.$$

A diferença entre a matriz original e sua aproximação é

$$\mathbf{A} - \mathbf{A}_k = \sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

A matriz $\mathbf{A}_k$ conserva as direções associadas aos k maiores valores singulares. A diferença reúne as direções descartadas.

6.7.3 Erros produzidos pelo truncamento

Proposição 6.16 (Decomposição e erros da SVD truncada). *Se*

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top, \quad 1 \leq k < r,$$

então

$$\mathbf{A} - \mathbf{A}_k = \sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Além disso,

$$\langle \mathbf{A}_k, \mathbf{A} - \mathbf{A}_k \rangle_F = 0,$$

$$\|\mathbf{A}_k\|_F^2 = \sum_{j=1}^k d_j^2,$$

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2$$

e

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1}.$$

Consequentemente,

$$\|\mathbf{A}\|_F^2 = \|\mathbf{A}_k\|_F^2 + \|\mathbf{A} - \mathbf{A}_k\|_F^2.$$



i Demonstração

Pela forma expandida,

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Subtraindo

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

obtém-se

$$\mathbf{A} - \mathbf{A}_k = \sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Pela Proposição 6.15, os componentes associados a índices diferentes são ortogonais segundo o produto interno de Frobenius. Como $\mathbf{A}_k$ utiliza os índices

$$1, \dots, k$$

e a diferença utiliza

$$k+1, \dots, r,$$

segue que

$$\langle \mathbf{A}_k, \mathbf{A} - \mathbf{A}_k \rangle_F = 0.$$

Aplicando a decomposição pitagórica,

$$\|\mathbf{A}_k\|_F^2 = \sum_{j=1}^k d_j^2$$

e

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

Portanto,

$$\|\mathbf{A}\|_F^2 = \|\mathbf{A}_k\|_F^2 + \|\mathbf{A} - \mathbf{A}_k\|_F^2.$$

Por outro lado, a matriz residual

$$\mathbf{A} - \mathbf{A}_k$$

possui valores singulares positivos

$$d_{k+1}, d_{k+2}, \dots, d_r.$$

Pela Proposição 6.9, sua norma espectral é igual ao maior desses valores:

A proporção da magnitude quadrática de Frobenius preservada pela aproximação pode ser escrita como

$$\eta_k = \frac{\|\mathbf{A}_k\|_F^2}{\|\mathbf{A}\|_F^2} = \frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2}.$$

A proporção descartada é

$$1 - \eta_k = \frac{\|\mathbf{A} - \mathbf{A}_k\|_F^2}{\|\mathbf{A}\|_F^2} = \frac{\sum_{j=k+1}^r d_j^2}{\sum_{j=1}^r d_j^2}.$$

Para uma matriz genérica, η_k mede exclusivamente a proporção de sua magnitude quadrática, segundo a norma de Frobenius, representada pelos primeiros k componentes singulares. A razão η_k não deve ser interpretada, em geral, como proporção de variância explicada.

Quando $\mathbf{A}$ é uma matriz de dados centralizada, entretanto,

$$\|\mathbf{A}\|_F^2$$

corresponde à soma quadrática total dos afastamentos das observações em relação ao centro da nuvem. Nesse contexto específico, η_k representa a proporção dessa dispersão quadrática preservada pelos primeiros k componentes singulares.

A norma espectral descreve outro aspecto do erro. Como

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1},$$

o primeiro valor singular descartado determina o maior erro produzido pelo truncamento sobre qualquer vetor unitário:

$$d_{k+1} = \max_{\|\mathbf{x}\|=1} \|(\mathbf{A} - \mathbf{A}_k) \mathbf{x}\|.$$

Esse máximo é atingido, por exemplo, na direção

$$\mathbf{v}_{k+1},$$

pois

$$(\mathbf{A} - \mathbf{A}_k) \mathbf{v}_{k+1} = d_{k+1} \mathbf{u}_{k+1}.$$

Assim, a norma espectral mede um erro de pior caso, enquanto a norma de Frobenius agrega quadraticamente os erros associados a todos os componentes singulares descartados.

6.7.4 Teorema de Eckart–Young–Mirsky

A SVD truncada fornece uma aproximação ótima entre as matrizes de posto limitado.

Teorema 6.2 (Teorema de Eckart–Young–Mirsky). *Seja*

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

uma matriz de posto r , com valores singulares

$$d_1 \geq \dots \geq d_r > 0.$$

Para

$$1 \leq k < r,$$

defina

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Então $\mathbf{A}_k$ é uma solução dos problemas

$$\min_{\text{posto}(\tilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \tilde{\mathbf{A}}\|_2$$

e

$$\min_{\text{posto}(\tilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \tilde{\mathbf{A}}\|_F.$$


Os erros mínimos são

$$\min_{\text{posto}(\tilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \tilde{\mathbf{A}}\|_2 = d_{k+1}$$

e

$$\min_{\text{posto}(\tilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \tilde{\mathbf{A}}\|_F = \sqrt{\sum_{j=k+1}^r d_j^2}.$$

A formulação da melhor aproximação de posto k na norma de Frobenius é apresentada em Gentle (2017).



O teorema mostra que nenhuma matriz de posto no máximo k pode apresentar erro menor que $\mathbf{A}_k$ nas duas normas consideradas.

Na norma espectral, o erro ótimo é determinado exclusivamente pelo primeiro valor singular descartado,

$$d_{k+1}.$$

Na norma de Frobenius, o erro ótimo depende de toda a parcela espectral descartada,

$$\sqrt{\sum_{j=k+1}^r d_j^2}.$$

6.7.5 Exemplo de aproximação de posto 1

Exemplo 6.8 (Aproximação de posto 1 do exemplo condutor). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

Sua forma expandida é

$$\mathbf{A} = 2\mathbf{u}_1\mathbf{v}_1^\top + \sqrt{2}\mathbf{u}_2\mathbf{v}_2^\top,$$

em que

$$\mathbf{u}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \quad \mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

e

$$\mathbf{u}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A aproximação de posto 1 é

$$\begin{aligned}
\mathbf{A}_1 &= 2\mathbf{u}_1\mathbf{v}_1^\top \\
&= 2\left(\frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}\right)\left(\frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \end{bmatrix}\right) \\
&= \begin{bmatrix} 1 & 1 \\ 0 & 0 \\ 1 & 1 \end{bmatrix}.
\end{aligned}$$

A diferença entre a matriz original e a aproximação é

$$\mathbf{A} - \mathbf{A}_1 = \begin{bmatrix} 0 & 0 \\ 1 & -1 \\ 0 & 0 \end{bmatrix}.$$

Como

$$d_1 = 2$$

e

$$d_2 = \sqrt{2},$$

o erro espectral é

$$\|\mathbf{A} - \mathbf{A}_1\|_2 = \sqrt{2}.$$

O erro de Frobenius também é

$$\|\mathbf{A} - \mathbf{A}_1\|_F = \sqrt{2},$$

pois somente um valor singular foi descartado.

A magnitude quadrática total é

$$\|\mathbf{A}\|_F^2 = 2^2 + (\sqrt{2})^2 = 6.$$

A aproximação preserva

$$\|\mathbf{A}_1\|_F^2 = 2^2 = 4.$$

Portanto, a proporção preservada é

$$\frac{\|\mathbf{A}_1\|_F^2}{\|\mathbf{A}\|_F^2} = \frac{4}{6} = \frac{2}{3}.$$

A primeira parcela reproduz exatamente a primeira e a terceira linhas da matriz. A segunda linha está inteiramente associada à direção singular descartada.

Neste exemplo, as normas espectral e de Frobenius do erro coincidem porque a matriz residual possui apenas um valor singular positivo. Quando mais de um componente singular é descartado, os dois erros são, em geral, diferentes.

6.8 Pseudoinversa e soluções de mínimos quadrados

A inversa usual é definida somente para matrizes quadradas e invertíveis. A SVD permite construir uma transformação inversa generalizada para qualquer matriz real, inclusive matrizes:

- retangulares;
- singulares;
- deficientes em posto.

Essa transformação é a **pseudoinversa de Moore–Penrose**.

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com posto

$$r = \text{posto}(\mathbf{A})$$

e SVD compacta

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

Se $r \geq 1$, todos os elementos diagonais de

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r)$$

são positivos. Portanto,

$$\mathbf{D}_r^{-1} = \text{diag} \left(\frac{1}{d_1}, \dots, \frac{1}{d_r} \right)$$

está bem definida.

Se $r = 0$, então $\mathbf{A} = \mathbf{0}$ e define-se sua pseudoinversa como a matriz nula de dimensão $p \times q$.

Definição 6.10 (Pseudoinversa de Moore–Penrose). A **pseudoinversa de Moore–Penrose** de

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a matriz

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top.$$

Sua dimensão é

$$\mathbf{A}^+ \in \mathbb{R}^{p \times q}.$$

No caso $\mathbf{A} = \mathbf{0}$, define-se

$$\mathbf{A}^+ = \mathbf{0}_{p \times q}.$$

A pseudoinversa inverte os escalonamentos associados aos valores singulares positivos:

$$\mathbf{A}^+ \mathbf{u}_j = \frac{1}{d_j} \mathbf{v}_j, \quad j = 1, \dots, r.$$

As componentes pertencentes ao núcleo de $\mathbf{A}^\top$ são anuladas. Se

$$\mathbf{u} \in \mathcal{N}(\mathbf{A}^\top),$$

então

$$\mathbf{A}^+ \mathbf{u} = \mathbf{0}.$$

Portanto, a pseudoinversa desfaz os escalonamentos de $\mathbf{A}$ nas direções associadas aos valores singulares positivos e anula as componentes pertencentes a

$$\mathcal{N}(\mathbf{A}^\top).$$

Assim, ela atua como uma inversão entre os subespaços

$$\mathcal{C}(\mathbf{A}^\top) \subseteq \mathbb{R}^p$$

e

$$\mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q,$$

nos quais a ação de $\mathbf{A}$ é não nula.

6.8.1 Pseudoinversa e projetores

Os produtos envolvendo $\mathbf{A}$ e sua pseudoinversa recuperam os projetores ortogonais dos quatro espaços fundamentais.

Proposição 6.17 (Projetores determinados pela pseudoinversa). *Se*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

e

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top,$$

então

$$\mathbf{A}\mathbf{A}^+ = \mathbf{U}_r \mathbf{U}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A})}$$

e

$$\mathbf{A}^+ \mathbf{A} = \mathbf{V}_r \mathbf{V}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)}.$$

Consequentemente,

$$\mathbf{I}_q - \mathbf{A}\mathbf{A}^+ = \mathbf{P}_{\mathcal{N}(\mathbf{A}^\top)}$$

e

$$\mathbf{I}_p - \mathbf{A}^+ \mathbf{A} = \mathbf{P}_{\mathcal{N}(\mathbf{A})}.$$

i Demonstração

Pela definição da pseudoinversa,

$$\begin{aligned} \mathbf{A}\mathbf{A}^+ &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \\ &= \mathbf{U}_r \mathbf{U}_r^\top, \end{aligned}$$

pois

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r.$$

Pela Proposição 6.8,

$$\mathbf{U}_r \mathbf{U}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A})}.$$

Analogamente,

$$\begin{aligned} \mathbf{A}^+ \mathbf{A} &= \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \mathbf{V}_r \mathbf{V}_r^\top \\ &= \mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)}. \end{aligned}$$

Como

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top)$$

e

$$\mathcal{C}(\mathbf{A}^\top)^\perp = \mathcal{N}(\mathbf{A}),$$

os projetores sobre os complementos ortogonais são

$$\mathbf{I}_q - \mathbf{A}\mathbf{A}^+ = \mathbf{P}_{\mathcal{N}(\mathbf{A}^\top)}$$

e

$$\mathbf{I}_p - \mathbf{A}^+ \mathbf{A} = \mathbf{P}_{\mathcal{N}(\mathbf{A})}.$$

A Tabela 6.5 resume essas relações.

Tabela 6.5: Projetores ortogonais determinados pela pseudoinversa.

Matriz	Espaço projetado
$\mathbf{A}\mathbf{A}^+$	$\mathcal{C}(\mathbf{A})$
$\mathbf{I}_q - \mathbf{A}\mathbf{A}^+$	$\mathcal{N}(\mathbf{A}^\top)$
$\mathbf{A}^+\mathbf{A}$	$\mathcal{C}(\mathbf{A}^\top)$
$\mathbf{I}_p - \mathbf{A}^+\mathbf{A}$	$\mathcal{N}(\mathbf{A})$

Os dois produtos atuam em espaços diferentes. A matriz

$$\mathbf{A}\mathbf{A}^+ \in \mathbb{R}^{q \times q}$$

atua no contradomínio e seleciona a componente pertencente à imagem da transformação.

Por outro lado,

$$\mathbf{A}^+\mathbf{A} \in \mathbb{R}^{p \times p}$$

atua no domínio e seleciona a componente pertencente ao espaço linha, isto é, ao complemento ortogonal do núcleo de $\mathbf{A}$.

6.8.2 Mínimos quadrados

Para qualquer

$$\mathbf{b} \in \mathbb{R}^q,$$

o problema de mínimos quadrados consiste em determinar $\mathbf{x}$ que minimize a distância entre $\mathbf{b}$ e $\mathbf{A}\mathbf{x}$:

$$\min_{\mathbf{x} \in \mathbb{R}^p} \|\mathbf{b} - \mathbf{A}\mathbf{x}\|^2.$$

Quando

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}),$$

o erro mínimo é zero e o problema coincide com a resolução de um sistema compatível.

Quando

$$\mathbf{b} \notin \mathcal{C}(\mathbf{A}),$$

não existe solução exata, e o problema consiste em minimizar a distância de $\mathbf{b}$ ao espaço coluna de $\mathbf{A}$.

Definição 6.11 (Solução de mínimos quadrados). Um vetor

$$\hat{\mathbf{x}} \in \mathbb{R}^p$$

é uma **solução de mínimos quadrados** de

$$\mathbf{Ax} = \mathbf{b}$$

quando

$$\|\mathbf{b} - \mathbf{A}\hat{\mathbf{x}}\| = \min_{\mathbf{x} \in \mathbb{R}^p} \|\mathbf{b} - \mathbf{Ax}\|.$$

A pseudoinversa fornece a solução de mínimos quadrados de menor norma e, juntamente com o núcleo de $\mathbf{A}$, permite caracterizar todos os minimizadores.

Proposição 6.18 (Mínimos quadrados pela pseudoinversa). *Para qualquer*

$$\mathbf{b} \in \mathbb{R}^q,$$

o vetor ajustado de mínimos quadrados é

$$\hat{\mathbf{b}} = \mathbf{AA}^+\mathbf{b} = \mathbf{P}_{\mathcal{C}(\mathbf{A})}\mathbf{b}.$$

O resíduo é

$$\mathbf{r} = \mathbf{b} - \hat{\mathbf{b}} = (\mathbf{I}_q - \mathbf{AA}^+)\mathbf{b}$$

e satisfaz

$$\mathbf{r} \in \mathcal{N}(\mathbf{A}^\top),$$

ou, equivalentemente,

$$\mathbf{A}^\top \mathbf{r} = \mathbf{0}.$$

Consequentemente, uma solução de mínimos quadrados satisfaz as equações normais

$$\mathbf{A}^\top \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{b}.$$

O conjunto de todas as soluções de mínimos quadrados é

$$\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b} + \mathbf{V}_0 \gamma,$$

em que

$$\gamma \in \mathbb{R}^{p-r}.$$

Entre todos os minimizadores,

$$\hat{\mathbf{x}}^\star = \mathbf{A}^+ \mathbf{b}$$

é o único de menor norma euclidiana.

(Gentle, 2017)



A decomposição geométrica correspondente é

$$\mathbf{b} = \hat{\mathbf{b}} + \mathbf{r},$$

com

$$\hat{\mathbf{b}} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{r} \in \mathcal{N}(\mathbf{A}^\top).$$

Como essas parcelas são ortogonais,

$$\|\mathbf{b}\|^2 = \|\hat{\mathbf{b}}\|^2 + \|\mathbf{r}\|^2.$$

6.8.2.1 Caso de posto coluna completo

Se

$$r = p,$$

então

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

e a solução de mínimos quadrados é única:

$$\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b}.$$

Nesse caso,

$$\mathbf{A}^\top \mathbf{A}$$

é positiva definida e invertível, e

$$\mathbf{A}^+ = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

Portanto,

$$\hat{\mathbf{x}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

6.8.3 Exemplo com o sistema condutor

Exemplo 6.9 (Pseudoinversa e mínimos quadrados no exemplo condutor). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}$$

e

$$\mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix}.$$

A SVD compacta de $\mathbf{A}$ possui

$$\mathbf{U}_2 = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 0 & 1 \\ 1/\sqrt{2} & 0 \end{bmatrix},$$

$$\mathbf{D}_2 = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix}$$

e

$$\mathbf{V}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

A pseudoinversa é

$$\mathbf{A}^+ = \mathbf{V}_2 \mathbf{D}_2^{-1} \mathbf{U}_2^\top.$$

Efetuada os produtos,

$$\mathbf{A}^+ = \begin{bmatrix} 1/4 & 1/2 & 1/4 \\ 1/4 & -1/2 & 1/4 \end{bmatrix}.$$

A solução de mínimos quadrados é

$$\begin{aligned}\hat{\mathbf{x}} &= \mathbf{A}^+ \mathbf{b} \\ &= \begin{bmatrix} 1/4 & 1/2 & 1/4 \\ 1/4 & -1/2 & 1/4 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix} \\ &= \begin{bmatrix} 5/4 \\ -3/4 \end{bmatrix}.\end{aligned}$$

O vetor ajustado é

$$\begin{aligned}\hat{\mathbf{b}} &= \mathbf{A} \hat{\mathbf{x}} \\ &= \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 5/4 \\ -3/4 \end{bmatrix} \\ &= \begin{bmatrix} 1/2 \\ 2 \\ 1/2 \end{bmatrix}.\end{aligned}$$

O resíduo é

$$\begin{aligned}\mathbf{r} &= \mathbf{b} - \hat{\mathbf{b}} \\ &= \begin{bmatrix} 1/2 \\ 0 \\ -1/2 \end{bmatrix}.\end{aligned}$$

O vetor

$$\mathbf{u}_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}$$

forma uma base do núcleo de $\mathbf{A}^\top$. De fato,

$$\mathbf{r} = \frac{1}{\sqrt{2}} \mathbf{u}_3.$$

Consequentemente,

$$\mathbf{A}^\top \mathbf{r} = \mathbf{0}.$$

O sistema original é incompatível porque a primeira e a terceira equações exigiriam simultaneamente

$$x_1 + x_2 = 1$$

e

$$x_1 + x_2 = 0.$$

A solução de mínimos quadrados substitui esses dois valores pela projeção comum

$$x_1 + x_2 = \frac{1}{2}.$$

Como $\mathbf{A}$ possui posto coluna completo, a solução de mínimos quadrados é única.

A pseudoinversa reúne, em uma única construção:

- inversão dos fatores de escala associados aos valores singulares positivos;
- anulação das componentes pertencentes a $\mathcal{N}(\mathbf{A}^\top)$;
- construção dos projetores sobre $\mathcal{C}(\mathbf{A})$ e $\mathcal{C}(\mathbf{A}^\top)$;
- solução de sistemas lineares compatíveis;
- seleção da solução exata de menor norma quando há não unicidade;
- solução de problemas de mínimos quadrados;
- seleção da solução de mínimos quadrados de menor norma quando há vários minimizadores.

6.9 Aprofundamento teórico

6.9.1 Não unicidade dos vetores singulares

Considere um valor singular positivo d com multiplicidade m . Se

$$\mathbf{U}_d \in \mathbb{R}^{q \times m}$$

e

$$\mathbf{V}_d \in \mathbb{R}^{p \times m}$$

contêm bases ortonormais dos subespaços singulares correspondentes, a contribuição desse valor é

$$d\mathbf{U}_d\mathbf{V}_d^\top.$$

Para qualquer matriz ortogonal

$$\mathbf{R} \in \mathbb{R}^{m \times m},$$

tem-se

$$\begin{aligned} d(\mathbf{U}_d\mathbf{R})(\mathbf{V}_d\mathbf{R})^\top &= d\mathbf{U}_d\mathbf{R}\mathbf{R}^\top\mathbf{V}_d^\top \\ &= d\mathbf{U}_d\mathbf{V}_d^\top. \end{aligned}$$

Portanto, valores singulares positivos repetidos permitem rotações ortogonais simultâneas das bases à esquerda e à direita.

A situação é diferente nos subespaços associados ao valor singular zero. As colunas de $\mathbf{V}_0$ formam uma base de

$$\mathcal{N}(\mathbf{A}),$$

enquanto as colunas de $\mathbf{U}_0$ formam uma base de

$$\mathcal{N}(\mathbf{A}^\top).$$

Essas bases completam espaços diferentes e podem ser escolhidas independentemente, pois suas parcelas são multiplicadas por zero na SVD completa.

Portanto:

- os valores singulares são propriedades da matriz;
- os subespaços singulares associados aos valores positivos são propriedades da matriz;
- os núcleos de $\mathbf{A}$ e de $\mathbf{A}^\top$ são propriedades da matriz;
- sinais e bases ortonormais específicas dentro desses subespaços dependem da representação escolhida.

A existência da SVD e as relações entre os dois conjuntos de vetores singulares decorrem das decomposições espectrais das matrizes simétricas

$$\mathbf{A}^\top\mathbf{A} \quad \text{e} \quad \mathbf{A}\mathbf{A}^\top.$$

6.9.2 Construção teórica e cálculo numérico

A decomposição espectral de

$$\mathbf{A}^\top \mathbf{A}$$

fornece uma demonstração da existência da SVD e permite realizar cálculos manuais em exemplos pequenos.

Em aplicações numéricas, a SVD não costuma ser calculada formando explicitamente

$$\mathbf{A}^\top \mathbf{A}.$$

Esse produto pode ampliar diferenças entre as magnitudes dos valores singulares e aumentar os efeitos de erros de arredondamento. Programas numéricos utilizam procedimentos específicos para calcular a SVD diretamente, com maior estabilidade.

6.9.3 Invariância ortogonal

As normas espectral e de Frobenius são preservadas por multiplicações ortogonais.

Proposição 6.19 (Invariância ortogonal das normas). *Se $\mathbf{Q}_1$ e $\mathbf{Q}_2$ são matrizes ortogonais de dimensões compatíveis, então*

$$\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_2 = \|\mathbf{A}\|_2$$

e

$$\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_F = \|\mathbf{A}\|_F.$$

(Gentle, 2017)

i Demonstração

Para a norma espectral, como $\mathbf{Q}_1$ preserva normas,

$$\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2 \mathbf{x}\| = \|\mathbf{A} \mathbf{Q}_2 \mathbf{x}\|.$$

Como $\mathbf{Q}_2$ é ortogonal, a transformação

$$\mathbf{z} = \mathbf{Q}_2 \mathbf{x}$$

preserva a norma e percorre todos os vetores unitários quando $\mathbf{x}$ percorre a esfera unitária. Portanto,

$$\begin{aligned}\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_2 &= \max_{\|\mathbf{x}\|=1} \|\mathbf{A} \mathbf{Q}_2 \mathbf{x}\| \\ &= \max_{\|\mathbf{z}\|=1} \|\mathbf{A} \mathbf{z}\| \\ &= \|\mathbf{A}\|_2.\end{aligned}$$

Para a norma de Frobenius,

$$\begin{aligned}\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_F^2 &= \text{tr} \left[(\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2)^\top (\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2) \right] \\ &= \text{tr} (\mathbf{Q}_2^\top \mathbf{A}^\top \mathbf{A} \mathbf{Q}_2) \\ &= \text{tr} (\mathbf{A}^\top \mathbf{A} \mathbf{Q}_2 \mathbf{Q}_2^\top) \\ &= \text{tr} (\mathbf{A}^\top \mathbf{A}) \\ &= \|\mathbf{A}\|_F^2.\end{aligned}$$

Logo, ambas as normas são invariantes sob multiplicações ortogonais.

Pela invariância ortogonal, as normas espectral e de Frobenius de $\mathbf{A}$ coincidem com as de $\mathbf{D}$:

$$\|\mathbf{A}\|_2 = \|\mathbf{D}\|_2$$

e

$$\|\mathbf{A}\|_F = \|\mathbf{D}\|_F.$$

6.9.4 Determinante e invertibilidade

Quando

$$q = p,$$

a matriz $\mathbf{A}$ é quadrada. Pela SVD,

$$\det(\mathbf{A}) = \det(\mathbf{U}) \det(\mathbf{D}) \det(\mathbf{V}^\top).$$

Como $\mathbf{U}$ e $\mathbf{V}$ são ortogonais,

$$|\det(\mathbf{U})| = |\det(\mathbf{V})| = 1.$$

Portanto,

$$|\det(\mathbf{A})| = \prod_{j=1}^p d_j.$$

O módulo do determinante é o produto dos valores singulares.

Além disso,

$$\mathbf{A} \text{ é invertível} \iff d_j > 0 \text{ para todo } j.$$

Nesse caso,

$$r = p = q,$$

de modo que não existem direções singulares associadas ao valor zero. Assim, as formas compacta e completa possuem as mesmas dimensões e podem ser escritas com os mesmos fatores:

$$\mathbf{U}_r = \mathbf{U}, \quad \mathbf{D}_r = \mathbf{D}, \quad \mathbf{V}_r = \mathbf{V}.$$

6.9.5 Magnitude quadrática da matriz centralizada

Proposição 6.20 (Magnitude quadrática da nuvem centralizada). *Se*

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta da matriz de dados centralizada, então

$$\|\mathbf{X}_c\|_F^2 = \sum_{j=1}^r d_j^2.$$

Além disso, se

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c,$$

então

$$\|\mathbf{X}_c\|_F^2 = (n-1) \operatorname{tr}(\mathbf{S}).$$

Consequentemente,

$$\sum_{j=1}^r d_j^2 = (n-1) \operatorname{tr}(\mathbf{S}).$$

i Demonstração

Pela Proposição 6.9,

$$\|\mathbf{X}_c\|_F^2 = \sum_{j=1}^r d_j^2.$$

Por outro lado,

$$\mathbf{X}_c^\top \mathbf{X}_c = (n-1) \mathbf{S}.$$

Logo,

$$\begin{aligned} \|\mathbf{X}_c\|_F^2 &= \operatorname{tr}(\mathbf{X}_c^\top \mathbf{X}_c) \\ &= (n-1) \operatorname{tr}(\mathbf{S}). \end{aligned}$$

Se

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

é o vetor de médias das observações, então

$$\|\mathbf{X}_c\|_F^2 = \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2.$$

Portanto,

$$\sum_{j=1}^r d_j^2 = \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2.$$

A soma dos quadrados dos valores singulares da matriz centralizada representa, assim, a soma quadrática total dos afastamentos das observações em relação ao centro da nuvem.

Como $\text{tr}(\mathbf{S})$ é a soma dos elementos diagonais de $\mathbf{S}$, ela corresponde à soma das variâncias amostrais das p variáveis.

A centralização é essencial para essa interpretação. Para uma matriz não centralizada,

$$\|\mathbf{X}\|_F^2 = \sum_{i=1}^n \|\mathbf{x}_i\|^2$$

mede a soma dos quadrados das posições em relação à origem, e não a dispersão das observações em torno de seu vetor de médias.

6.9.6 Unicidade da aproximação

A otimalidade estabelecida pelo Teorema 6.2 não implica, em geral, que a matriz aproximante seja única. A situação depende também da norma considerada.

Na norma de Frobenius, a melhor aproximação de posto no máximo k é única quando há separação estrita entre os valores singulares que ficam em lados opostos do truncamento:

$$d_k > d_{k+1}.$$

Se

$$d_k = d_{k+1},$$

o ponto de truncamento atravessa um subespaço singular associado a um valor repetido. Nesse caso, diferentes escolhas de subespaços dentro desse bloco singular podem produzir aproximações ótimas distintas.

Na norma espectral, a matriz

$$\mathbf{A}_k$$

é sempre uma aproximação ótima, mas a aproximação ótima pode não ser única mesmo quando

$$d_k > d_{k+1}.$$

Isso ocorre porque outras matrizes de posto no máximo k podem produzir o mesmo erro máximo

$$d_{k+1}.$$

Portanto, a condição

$$d_k > d_{k+1}$$

garante unicidade da melhor aproximação na norma de Frobenius, mas não deve ser utilizada como critério geral de unicidade na norma espectral.

Quando todos os r componentes singulares positivos são mantidos, não há truncamento e a reconstrução é exata:

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

com erro igual a zero.

6.9.7 Aproximação de uma matriz de dados

A SVD truncada possui uma interpretação direta como projeção das observações em um subespaço de menor dimensão.

Proposição 6.21 (SVD truncada como projeção das observações). *Se*

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de dados e

$$1 \leq k < r,$$

então sua aproximação truncada satisfaz

$$\mathbf{X}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top = \mathbf{X} \mathbf{V}_k \mathbf{V}_k^\top.$$

Como

$$\mathbf{P}_k = \mathbf{V}_k \mathbf{V}_k^\top$$

é o projetor ortogonal sobre

$$\mathcal{S}_k = \text{span} \{ \mathbf{v}_1, \dots, \mathbf{v}_k \},$$

cada linha de $\mathbf{X}_k$ é a projeção ortogonal da observação correspondente sobre $\mathcal{S}_k$.

Se

$$\mathbf{Z}_k = \mathbf{X} \mathbf{V}_k,$$

então

$$\mathbf{Z}_k = \mathbf{U}_k \mathbf{D}_k$$

e

$$\mathbf{X}_k = \mathbf{Z}_k \mathbf{V}_k^\top.$$

i Demonstração

Pela relação

$$\mathbf{X}\mathbf{V}_k = \mathbf{U}_k\mathbf{D}_k,$$

tem-se

$$\begin{aligned}\mathbf{X}\mathbf{V}_k\mathbf{V}_k^\top &= \mathbf{U}_k\mathbf{D}_k\mathbf{V}_k^\top \\ &= \mathbf{X}_k.\end{aligned}$$

Como as colunas de $\mathbf{V}_k$ são ortonormais,

$$\mathbf{P}_k = \mathbf{V}_k\mathbf{V}_k^\top$$

é o projetor ortogonal sobre $\mathcal{S}_k$.

Portanto, para cada observação $\mathbf{x}_i$,

$$\hat{\mathbf{x}}_{i,k} = \mathbf{P}_k\mathbf{x}_i$$

e, equivalentemente,

$$\hat{\mathbf{x}}_{i,k} = \sum_{j=1}^k z_{ij}\mathbf{v}_j.$$

O resíduo correspondente é

$$\mathbf{x}_i - \hat{\mathbf{x}}_{i,k} = \sum_{j=k+1}^r z_{ij}\mathbf{v}_j.$$

A matriz

$$\mathbf{Z}_k \in \mathbb{R}^{n \times k}$$

fornece uma representação das observações em k coordenadas. A multiplicação por

$$\mathbf{V}_k^\top$$

reconstrói suas aproximações no espaço original $\mathbb{R}^p$.

Além disso,

$$\|\mathbf{X} - \mathbf{X}_k\|_F^2 = \sum_{i=1}^n \|\mathbf{x}_i - \hat{\mathbf{x}}_{i,k}\|^2 = \sum_{j=k+1}^r d_j^2.$$

Pelo Teorema 6.2, nenhuma matriz de posto no máximo k possui erro de reconstrução menor na norma de Frobenius. Em particular, entre as representações obtidas pela projeção das observações em subespaços lineares de dimensão no máximo k , o subespaço

$$\mathcal{S}_k = \text{span} \{ \mathbf{v}_1, \dots, \mathbf{v}_k \}$$

minimiza a soma dos erros quadráticos de reconstrução.

Quando $\mathbf{X}$ está centralizada,

$$\frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2}$$

representa a proporção da dispersão quadrática total da nuvem preservada pelas primeiras k direções singulares.

A SVD truncada e a pseudoinversa utilizam os mesmos componentes singulares com finalidades distintas.

Na aproximação de posto reduzido, componentes associados a valores singulares positivos são deliberadamente descartados:

$$\mathbf{A} \longrightarrow \mathbf{A}_k.$$

Na pseudoinversa, todos os componentes associados a valores singulares positivos são mantidos, mas os fatores de escala são invertidos:

$$d_j \longrightarrow \frac{1}{d_j}, \quad j = 1, \dots, r.$$

As direções associadas à parte nula da transformação não são invertidas.

6.9.8 Relação com a pseudoinversa espectral

A pseudoinversa espectral definida em Definição 5.11 é obtida a partir da decomposição espectral de uma matriz simétrica.

Se

$$\mathbf{A} = \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top,$$

então

$$\mathbf{A}^+ = \mathbf{Q}_A \Lambda_A^+ \mathbf{Q}_A^\top,$$

em que cada autovalor não nulo é substituído por seu inverso e os autovalores nulos permanecem iguais a zero.

A definição baseada na SVD,

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top,$$

estende essa construção para qualquer matriz real, inclusive matrizes retangulares e não simétricas.

Quando $\mathbf{A}$ é quadrada e invertível,

$$r = p = q,$$

todos os valores singulares são positivos e

$$\mathbf{A}^+ = \mathbf{A}^{-1}.$$

Portanto, a inversa usual constitui um caso particular da pseudoinversa.

6.9.9 Caracterização de Moore–Penrose

A pseudoinversa é caracterizada por quatro identidades.

Teorema 6.3 (Condições de Moore–Penrose). *Para toda matriz real $\mathbf{A}$, existe uma única matriz $\mathbf{A}^+$ que satisfaz*

$$\mathbf{A}\mathbf{A}^+\mathbf{A} = \mathbf{A},$$


$$\mathbf{A}^+\mathbf{A}\mathbf{A}^+ = \mathbf{A}^+,$$

$$(\mathbf{A}\mathbf{A}^+)^{\top} = \mathbf{A}\mathbf{A}^+,$$

e

$$(\mathbf{A}^+\mathbf{A})^{\top} = \mathbf{A}^+\mathbf{A}.$$

(Gentle, 2017; Searle; Khuri, 2017)



6.9.10 Sistemas lineares compatíveis

Considere o sistema

$$\mathbf{Ax} = \mathbf{b}, \quad \mathbf{b} \in \mathbb{R}^q.$$

A pseudoinversa permite caracterizar a compatibilidade do sistema, descrever todas as suas soluções e identificar aquela de menor norma.

Proposição 6.22 (Sistemas compatíveis pela pseudoinversa). *O sistema*

$$\mathbf{Ax} = \mathbf{b}$$

é compatível se, e somente se,

$$\mathbf{AA}^+\mathbf{b} = \mathbf{b}.$$

Quando o sistema é compatível, o conjunto de todas as soluções é

$$\mathbf{x} = \mathbf{A}^+\mathbf{b} + \mathbf{V}_0\boldsymbol{\gamma},$$

em que

$$\boldsymbol{\gamma} \in \mathbb{R}^{p-r}.$$

Entre todas essas soluções,


$$\mathbf{x}^* = \mathbf{A}^+\mathbf{b}$$

é a única de menor norma euclidiana.

Se

$$r = p,$$

o núcleo de $\mathbf{A}$ é trivial e a solução é única.



i Demonstração

O sistema é compatível exatamente quando

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Pela Proposição 6.17,

$$\mathbf{A}\mathbf{A}^+ = \mathbf{P}_{\mathcal{C}(\mathbf{A})}.$$

Portanto,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}) \iff \mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{b}.$$

Suponha que o sistema seja compatível. Então

$$\mathbf{x}_0 = \mathbf{A}^+\mathbf{b}$$

é uma solução, pois

$$\mathbf{A}\mathbf{x}_0 = \mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{b}.$$

Se $\mathbf{x}$ é qualquer outra solução,

$$\mathbf{A}\mathbf{x} = \mathbf{A}\mathbf{x}_0.$$

Logo,

$$\mathbf{A}(\mathbf{x} - \mathbf{x}_0) = \mathbf{0},$$

e, portanto,

$$\mathbf{x} - \mathbf{x}_0 \in \mathcal{N}(\mathbf{A}).$$

Como as colunas de $\mathbf{V}_0$ formam uma base ortonormal desse núcleo,

$$\mathbf{x} = \mathbf{A}^+\mathbf{b} + \mathbf{V}_0\boldsymbol{\gamma}.$$

6.9.11 Caso de posto linha completo

Se

$$r = q \leq p,$$

então

$$\mathcal{C}(\mathbf{A}) = \mathbb{R}^q.$$

Logo, para todo

$$\mathbf{b} \in \mathbb{R}^q,$$

o sistema

$$\mathbf{Ax} = \mathbf{b}$$

é compatível.

Nesse caso,

$$\mathbf{AA}^\top$$

é invertível e

$$\mathbf{A}^+ = \mathbf{A}^\top (\mathbf{AA}^\top)^{-1}.$$

A solução

$$\mathbf{x}^* = \mathbf{A}^+ \mathbf{b}$$

é a solução exata de menor norma.

6.9.12 Expressão da solução nas direções singulares

A forma expandida da pseudoinversa permite expressar diretamente a solução de mínimos quadrados de menor norma nas direções singulares.

Como

$$\mathbf{A}^+ = \sum_{j=1}^r \frac{1}{d_j} \mathbf{v}_j \mathbf{u}_j^\top,$$

tem-se

$$\hat{\mathbf{x}}^* = \mathbf{A}^+ \mathbf{b} = \sum_{j=1}^r \frac{\mathbf{u}_j^\top \mathbf{b}}{d_j} \mathbf{v}_j.$$

A solução é construída em três etapas:

1. calcula-se a componente de $\mathbf{b}$ na direção $\mathbf{u}_j$:

$$\mathbf{u}_j^\top \mathbf{b};$$

2. divide-se essa componente pelo valor singular:

$$\frac{\mathbf{u}_j^\top \mathbf{b}}{d_j};$$

3. expressa-se o resultado na direção $\mathbf{v}_j$.

A componente de $\mathbf{b}$ no núcleo de $\mathbf{A}^\top$ não aparece na solução, pois não pode ser reproduzida por nenhum vetor da forma $\mathbf{Ax}$.

O vetor ajustado é

$$\hat{\mathbf{b}} = \sum_{j=1}^r (\mathbf{u}_j^\top \mathbf{b}) \mathbf{u}_j,$$

enquanto o resíduo é

$$\mathbf{r} = \sum_{j=r+1}^q (\mathbf{u}_j^\top \mathbf{b}) \mathbf{u}_j.$$

6.10 Síntese do capítulo

A Decomposição em Valores Singulares estende a ideia de decomposição espectral a qualquer matriz real. Para

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

existe uma decomposição

$$\mathbf{A} = \mathbf{U} \mathbf{D} \mathbf{V}^\top,$$

em que $\mathbf{U}$ e $\mathbf{V}$ são matrizes ortogonais e $\mathbf{D}$ contém os valores singulares não negativos.

Para cada valor singular positivo d_j ,

$$\mathbf{A} \mathbf{v}_j = d_j \mathbf{u}_j$$

e

$$\mathbf{A}^\top \mathbf{u}_j = d_j \mathbf{v}_j.$$

Assim, $\mathbf{v}_j$ determina uma direção no domínio, d_j determina o fator de escala e $\mathbf{u}_j$ determina a direção correspondente no contradomínio.

Se

$$r = \text{posto}(\mathbf{A}),$$

a SVD compacta é

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

com

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r), \quad d_1 \geq \dots \geq d_r > 0.$$

A SVD compacta é uma representação exata. A SVD truncada,

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top, \quad k < r,$$

descarta parcelas associadas a valores singulares positivos e produz uma aproximação de posto reduzido.

A construção da SVD decorre das decomposições espectrais das duas matrizes de Gram:

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top$$

e

$$\mathbf{A} \mathbf{A}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

Seus autovalores positivos são

$$d_1^2, \dots, d_r^2.$$

Assim, $\mathbf{A}^\top \mathbf{A}$ descreve a estrutura espectral relevante no domínio, enquanto $\mathbf{A} \mathbf{A}^\top$ descreve a estrutura correspondente no contradomínio.

Geometricamente, a imagem da bola unitária é um elipsoide de dimensão r contido em

$$\mathcal{C}(\mathbf{A}),$$

com semieixos

$$d_1 \mathbf{u}_1, \dots, d_r \mathbf{u}_r.$$

Os valores singulares medem, portanto, os fatores de escala nas direções singulares. Em particular,

$$\|\mathbf{A}\|_2 = d_1,$$

de modo que o maior valor singular é o maior fator de ampliação produzido pela transformação.

A SVD também fornece bases ortonormais para os quatro espaços fundamentais:

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{u}_1, \dots, \mathbf{u}_r \},$$

$$\mathcal{N}(\mathbf{A}^\top) = \text{span} \{ \mathbf{u}_{r+1}, \dots, \mathbf{u}_q \},$$

$$\mathcal{C}(\mathbf{A}^\top) = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_r\},$$

e

$$\mathcal{N}(\mathbf{A}) = \text{span}\{\mathbf{v}_{r+1}, \dots, \mathbf{v}_p\}.$$

Consequentemente,

$$\dim(\mathcal{N}(\mathbf{A})) = p - r$$

e

$$\dim(\mathcal{N}(\mathbf{A}^\top)) = q - r.$$

As normas espectral e de Frobenius possuem representações simples em termos dos valores singulares:

$$\|\mathbf{A}\|_2 = d_1$$

e

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

Para uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a SVD compacta fornece

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

As coordenadas das observações nas direções singulares à direita são

$$\mathbf{Z} = \mathbf{X} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r.$$

Como

$$\mathbf{X} = \mathbf{Z}\mathbf{V}_r^\top,$$

essa representação é exata quando são mantidos todos os r componentes singulares positivos.

Além disso,

$$\mathbf{Z}\mathbf{Z}^\top = \mathbf{X}\mathbf{X}^\top,$$

de modo que a representação compacta preserva os produtos internos, as normas e as distâncias euclidianas entre as observações.

Analogamente,

$$\mathbf{U}_r^\top \mathbf{X} = \mathbf{D}_r \mathbf{V}_r^\top$$

fornece as coordenadas das variáveis nas direções singulares à esquerda.

Quando a matriz de dados está centralizada,

$$\mathbf{X}_c^\top \mathbf{X}_c = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top.$$

Adotando a matriz de covariâncias amostral

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c,$$

obtém-se

$$\mathbf{S} = \mathbf{V}_r \left(\frac{\mathbf{D}_r^2}{n-1} \right) \mathbf{V}_r^\top.$$

Assim, os vetores singulares à direita de $\mathbf{X}_c$ determinam as direções espectrais associadas aos autovalores positivos de $\mathbf{S}$, enquanto

$$\frac{d_j^2}{n-1}$$

são os autovalores positivos correspondentes.

A forma expandida,

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

representa a matriz como uma soma de componentes singulares de posto 1, ortogonais entre si segundo o produto interno de Frobenius.

Na norma de Frobenius,

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2$$

é uma decomposição pitagórica da magnitude quadrática total da matriz.

O Teorema de Eckart–Young–Mirsky estabelece que

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top$$

é uma solução do problema de melhor aproximação de $\mathbf{A}$ entre todas as matrizes de posto no máximo k , tanto na norma espectral quanto na norma de Frobenius. Os erros mínimos são

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1}$$

e

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

A norma espectral mede o maior erro remanescente em uma direção unitária, enquanto a norma de Frobenius agrega quadraticamente todas as parcelas descartadas.

A pseudoinversa de Moore–Penrose é

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top,$$

com $\mathbf{A}^+ = \mathbf{0}$ quando $\mathbf{A} = \mathbf{0}$.

Ela determina os projetores

$$\mathbf{A}\mathbf{A}^+ = \mathbf{U}_r \mathbf{U}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A})}$$

e

$$\mathbf{A}^+ \mathbf{A} = \mathbf{V}_r \mathbf{V}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)}.$$

Para qualquer

$$\mathbf{b} \in \mathbb{R}^q,$$

o vetor

$$\hat{\mathbf{x}}^\star = \mathbf{A}^+ \mathbf{b}$$

é a solução de mínimos quadrados de menor norma.

Quando

$$r < p,$$

o núcleo de $\mathbf{A}$ é não trivial e existem outros minimizadores, obtidos pela adição de componentes pertencentes a

$$\mathcal{N}(\mathbf{A}).$$

A pseudoinversa seleciona, entre todos eles, o único vetor de menor norma euclidiana.

O vetor ajustado é

$$\hat{\mathbf{b}} = \mathbf{A} \mathbf{A}^+ \mathbf{b},$$

isto é, a projeção ortogonal de $\mathbf{b}$ sobre $\mathcal{C}(\mathbf{A})$, enquanto o resíduo

$$\mathbf{r} = (\mathbf{I}_q - \mathbf{A} \mathbf{A}^+) \mathbf{b}$$

pertence a

$$\mathcal{N}(\mathbf{A}^\top).$$

A Tabela 6.6 reúne as relações principais.

Tabela 6.6: Síntese das principais relações da Decomposição em Valores Singulares.

Objeto	Expressão	Interpretação
SVD completa	$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top$	Utiliza bases ortonormais completas no domínio e no contradomínio
SVD compacta	$\mathbf{A} = \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top$	Representação exata usando somente os componentes associados aos valores singulares positivos
Pares singulares	$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$	Relaciona uma direção do domínio a uma direção do contradomínio
Matrizes de Gram	$\mathbf{A}^\top\mathbf{A}$ e $\mathbf{A}\mathbf{A}^\top$	Determinam os quadrados dos valores singulares e os vetores singulares correspondentes
Posto	$r = \#\{j : d_j > 0\}$	Dimensão da imagem da transformação
Norma espectral	$\ \mathbf{A}\ _2 = d_1$	Maior fator de ampliação da transformação
Norma de Frobenius	$\ \mathbf{A}\ _F^2 = \sum_{j=1}^r d_j^2$	Magnitude quadrática total da matriz
Número de condição	$\kappa_2(\mathbf{A}) = d_1/d_s$ para posto máximo	Compara os fatores extremos de escala e caracteriza sensibilidade a perturbações
Coordenadas das observações	$\mathbf{Z} = \mathbf{X}\mathbf{V}_r = \mathbf{U}_r\mathbf{D}_r$	Representação das observações nas direções singulares à direita
SVD truncada	$\mathbf{A}_k = \mathbf{U}_k\mathbf{D}_k\mathbf{V}_k^\top$	Aproximação ótima de posto no máximo k
Erro espectral	$\ \mathbf{A} - \mathbf{A}_k\ _2 = d_{k+1}$	Maior erro do truncamento sobre vetores unitários
Erro de Frobenius	$\ \mathbf{A} - \mathbf{A}_k\ _F^2 = \sum_{j=k+1}^r d_j^2$	Magnitude quadrática total dos componentes descartados
Pseudoinversa	$\mathbf{A}^+ = \mathbf{V}_r\mathbf{D}_r^{-1}\mathbf{U}_r^\top$	Inverte os fatores de escala associados aos valores singulares positivos
Projetor no espaço coluna	$\mathbf{A}\mathbf{A}^+$	Projeta sobre $\mathcal{C}(\mathbf{A})$
Projetor no espaço linha	$\mathbf{A}^+\mathbf{A}$	Projeta sobre $\mathcal{C}(\mathbf{A}^\top)$

Objeto	Expressão	Interpretação
Mínimos quadrados	$\hat{\mathbf{x}}^* = \mathbf{A}^+ \mathbf{b}$	Seleciona a solução de mínimos quadrados de menor norma

Ao final deste capítulo, o estudante deverá ser capaz de:

- distinguir as formas completa, compacta e truncada da SVD;
- diferenciar uma representação compacta exata de uma aproximação truncada de posto reduzido;
- relacionar a SVD às decomposições espectrais de $\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A} \mathbf{A}^\top$;
- interpretar geometricamente os valores e vetores singulares;
- identificar o posto e os quatro espaços fundamentais por meio da SVD;
- construir os projetores ortogonais associados aos espaços fundamentais;
- calcular e interpretar as normas espectral e de Frobenius a partir dos valores singulares;
- distinguir deficiência de posto, invertibilidade e mau condicionamento por meio do número de condição espectral;
- interpretar a dualidade entre observações e variáveis em uma matriz de dados;
- representar exatamente as observações em coordenadas singulares e compreender a preservação de produtos internos e distâncias;
- relacionar a SVD de uma matriz centralizada à estrutura espectral de sua matriz de covariâncias amostral;
- representar uma matriz como soma de componentes singulares ortogonais de posto 1;
- construir aproximações de posto reduzido e determinar seus erros nas normas espectral e de Frobenius;
- aplicar o Teorema de Eckart–Young–Mirsky;
- construir e interpretar a pseudoinversa de Moore–Penrose;
- distinguir solução exata, solução de mínimos quadrados e solução de mínimos quadrados de menor norma;
- interpretar mínimos quadrados como um problema de projeção ortogonal.

Ideia central do capítulo

A Decomposição em Valores Singulares descreve uma matriz por meio de pares de direções ortonormais no domínio e no contradomínio e dos fatores de escala que relacionam essas direções. Essa estrutura revela o posto e os espaços fundamentais, fornece representações exatas ou aproximadas de menor dimensão e permite construir projetores, pseudoinversas e soluções de mínimos quadrados.

Em problemas de otimização, estimação e transformação de variáveis, as estruturas matriciais desenvolvidas neste módulo são combinadas com gradientes, Hessianas, multiplicadores de Lagrange, diferenciais matriciais e integrais, tratados no Capítulo 7.

7 Cálculo Diferencial, Integral e Matricial Aplicado à Estatística Multivariada

Os capítulos anteriores desenvolveram a representação vetorial dos dados, a álgebra matricial, os espaços vetoriais, as transformações lineares e as principais decomposições matriciais. Este capítulo estuda funções cujos argumentos e resultados podem ser escalares, vetores ou matrizes.

O cálculo diferencial descreve como essas funções variam localmente. Gradientes, Jacobianas e Hessianas permitem construir aproximações, identificar direções de variação e formular condições de otimização. O cálculo matricial permite diferenciar expressões que envolvem traços, produtos, inversas e determinantes.

O cálculo integral será utilizado para representar probabilidades, esperanças, distribuições marginais e transformações de vetores aleatórios. Nessas transformações, o determinante Jacobiano descreve a alteração local de volume.

O objetivo é reunir as ferramentas de cálculo utilizadas nos capítulos probabilísticos e inferenciais, sem desenvolver antecipadamente os modelos e procedimentos específicos desses capítulos.

7.1 Funções, variações e diferenciais

7.1.1 Tipos de funções

Uma função real de uma variável real possui a forma

$$f : \mathbb{R} \longrightarrow \mathbb{R}.$$

Em problemas multivariados, o domínio ou o contradomínio pode ter dimensão maior que um. A natureza desses espaços determina a forma da derivada.

Uma função escalar de um vetor é representada por

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix},$$

escreve-se

$$f(\mathbf{x}) = f(x_1, \dots, x_p).$$

São exemplos:

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{x},$$

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

e

$$f(\mathbf{x}) = \|\mathbf{b} - \mathbf{A} \mathbf{x}\|^2.$$

Essas funções associam um escalar a cada vetor do domínio.

Neste capítulo, salvo indicação em contrário, $\|\cdot\|$ aplicada a vetores denota a norma euclidiana definida em Definição [1.10](#).

Uma função vetorial de um vetor possui a forma

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Ela pode ser escrita como

$$\mathbf{g}(\mathbf{x}) = \begin{bmatrix} g_1(\mathbf{x}) \\ \vdots \\ g_q(\mathbf{x}) \end{bmatrix},$$

em que cada componente

$$g_i : \mathbb{R}^p \longrightarrow \mathbb{R}$$

é uma função escalar.

Uma transformação linear é um caso particular:

$$\mathbf{g}(\mathbf{x}) = \mathbf{Ax}, \quad \mathbf{A} \in \mathbb{R}^{q \times p}.$$

Também são utilizadas funções escalares de matrizes:

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}.$$

São exemplos:

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X})$$

e

$$\phi(\mathbf{X}) = \|\mathbf{X}\|_F^2,$$

em que $\|\cdot\|_F$ denota a norma de Frobenius definida em Definição 6.7.

Uma função matricial de uma matriz possui a forma

$$\mathcal{G} : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}^{r \times s}.$$

São exemplos:

$$\mathcal{G}(\mathbf{X}) = \mathbf{X}^\top \mathbf{X},$$

$$\mathcal{G}(\mathbf{X}) = \mathbf{AXB}$$

e, para matrizes quadradas invertíveis,

$$\mathcal{G}(\mathbf{X}) = \mathbf{X}^{-1}.$$

A Tabela 7.1 resume os tipos de funções utilizados no capítulo.

Tabela 7.1: Tipos de funções e objetos diferenciais correspondentes.

Função	Domínio	Contradomínio	Representação de primeira ordem
$f(x)$	$\mathbb{R}$	$\mathbb{R}$	Derivada escalar
$f(\mathbf{x})$	$\mathbb{R}^p$	$\mathbb{R}$	Gradiente
$\mathbf{g}(\mathbf{x})$	$\mathbb{R}^p$	$\mathbb{R}^q$	Jacobiana
$\phi(\mathbf{X})$	$\mathbb{R}^{m \times n}$	$\mathbb{R}$	Gradiente matricial
$\mathcal{G}(\mathbf{X})$	$\mathbb{R}^{m \times n}$	$\mathbb{R}^{r \times s}$	Operador diferencial

As dimensões do domínio e do contradomínio devem ser identificadas antes da diferenciação. Elas determinam a forma da transformação linear que representa localmente a variação da função e, conseqüentemente, a dimensão do gradiente, da Jacobiana ou do operador diferencial utilizado para representá-la.

7.1.2 Convenções de derivação

Neste capítulo, o gradiente de uma função escalar de um vetor será um vetor-coluna:

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_p} \end{bmatrix} \in \mathbb{R}^p.$$

Para uma função vetorial

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

a Jacobiana será definida por

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \begin{bmatrix} \frac{\partial g_1}{\partial x_1} & \dots & \frac{\partial g_1}{\partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial g_q}{\partial x_1} & \dots & \frac{\partial g_q}{\partial x_p} \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

A Hessiana de uma função escalar será representada por

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \in \mathbb{R}^{p \times p}.$$

Para uma função escalar de uma matriz,

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R},$$

o gradiente matricial terá a mesma dimensão do argumento:

$$\nabla_{\mathbf{X}} \phi(\mathbf{X}) \in \mathbb{R}^{m \times n}.$$

Ele será identificado pela relação

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X} \right].$$

Essa convenção utiliza o produto interno de Frobenius entre o gradiente e a perturbação da matriz.

7.1.3 Variação de uma função

Considere uma função

$$f : \mathcal{U} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R},$$

um ponto interior

$$\mathbf{x} \in \mathcal{U}$$

e uma perturbação

$$\mathbf{h} \in \mathbb{R}^p$$

tal que $\mathbf{x} + \mathbf{h} \in \mathcal{U}$.

A variação exata da função é

$$\Delta f = f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}).$$

Essa diferença mede a alteração total no valor da função. Para perturbações pequenas, procura-se representar sua parcela dominante por uma função linear de $\mathbf{h}$.

Definição 7.1 (Diferenciabilidade de uma função escalar). A função

$$f : \mathcal{U} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}$$

é diferenciável em um ponto interior

$$\mathbf{x} \in \mathcal{U}$$

quando existe uma transformação linear

$$L_{\mathbf{x}} : \mathbb{R}^p \longrightarrow \mathbb{R}$$

tal que

$$f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) = L_{\mathbf{x}}(\mathbf{h}) + r_{\mathbf{x}}(\mathbf{h}),$$

com

$$\frac{r_{\mathbf{x}}(\mathbf{h})}{\|\mathbf{h}\|} \longrightarrow 0 \quad \text{quando} \quad \|\mathbf{h}\| \longrightarrow 0.$$

A função linear $L_{\mathbf{x}}$ fornece a aproximação de primeira ordem da variação. No espaço euclidiano, existe um único vetor

$$\nabla_{\mathbf{x}} f(\mathbf{x}) \in \mathbb{R}^p$$

tal que

$$L_{\mathbf{x}}(\mathbf{h}) = \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h}.$$

Portanto,

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h} + r_{\mathbf{x}}(\mathbf{h}),$$

em que o termo residual é pequeno em relação a $\|\mathbf{h}\|$.

Utilizando a notação de ordem,

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h} + o(\|\mathbf{h}\|).$$

A aproximação linear é

$$f(\mathbf{x} + \mathbf{h}) \approx f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^\top \mathbf{h}.$$

7.1.4 Diferencial

O diferencial de f em $\mathbf{x}$ é a parte linear de sua variação:

$$df = \nabla_{\mathbf{x}} f(\mathbf{x})^\top d\mathbf{x}.$$

Em coordenadas,

$$df = \sum_{j=1}^p \frac{\partial f}{\partial x_j} dx_j.$$

O vetor

$$d\mathbf{x} = \begin{bmatrix} dx_1 \\ \vdots \\ dx_p \end{bmatrix}$$

representa o incremento utilizado como argumento da transformação linear que define o diferencial. Assim,

$$df = \nabla_{\mathbf{x}} f(\mathbf{x})^\top d\mathbf{x}$$

é linear em $d\mathbf{x}$.

A notação diferencial é frequentemente interpretada de maneira informal como uma variação infinitesimal. Formalmente, porém, o diferencial é a aplicação linear que fornece a parte de primeira ordem da variação da função.

Exemplo 7.1 (Diferencial de uma função linear). Considere

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

em que $\mathbf{a} \in \mathbb{R}^p$ é constante.

A variação é

$$\begin{aligned} f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) &= \mathbf{a}^\top (\mathbf{x} + \mathbf{h}) - \mathbf{a}^\top \mathbf{x} \\ &= \mathbf{a}^\top \mathbf{h}. \end{aligned}$$

Logo,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{a}$$

e

$$df = \mathbf{a}^\top d\mathbf{x}.$$

Como a função é linear, a aproximação de primeira ordem coincide com a variação exata.

Exemplo 7.2 (Diferencial do quadrado da norma). Considere

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|^2.$$

A variação exata é

$$\begin{aligned} f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) &= (\mathbf{x} + \mathbf{h})^\top (\mathbf{x} + \mathbf{h}) - \mathbf{x}^\top \mathbf{x} \\ &= 2\mathbf{x}^\top \mathbf{h} + \mathbf{h}^\top \mathbf{h}. \end{aligned}$$

O termo

$$2\mathbf{x}^\top \mathbf{h}$$

é linear em $\mathbf{h}$, enquanto

$$\mathbf{h}^\top \mathbf{h} = \|\mathbf{h}\|^2$$

é de segunda ordem.

Portanto,

$$df = 2\mathbf{x}^\top d\mathbf{x}$$

e

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{x}.$$

7.1.5 Aproximação ao longo de uma direção

Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2,$$

o ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1/2 \end{bmatrix}$$

e o vetor unitário

$$\mathbf{h} = \begin{bmatrix} -4/5 \\ 3/5 \end{bmatrix}.$$

A restrição da função à reta que passa por $\mathbf{x}_0$ na direção $\mathbf{h}$ é

$$\varphi(t) = f(\mathbf{x}_0 + t\mathbf{h}).$$

Em torno de $t = 0$,

$$\varphi(t) \approx \varphi(0) + \varphi'(0)t.$$

A Figura 7.1 compara a função exata ao longo dessa reta com sua aproximação linear.

No ponto $t = 0$, a função e sua aproximação linear possuem o mesmo valor e a mesma inclinação. À medida que $|t|$ aumenta, os termos de segunda ordem passam a contribuir mais para a variação.

7.1.6 Diferenciabilidade de funções vetoriais

Para uma função

$$\mathbf{g} : \mathcal{U} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

a aproximação de primeira ordem é uma transformação linear de $\mathbb{R}^p$ em $\mathbb{R}^q$.




Figura 7.1: Função exata ao longo de uma direção e aproximação linear no ponto $t = 0$.

Definição 7.2 (Diferenciabilidade de uma função vetorial). A função $\mathbf{g}$ é diferenciável em um ponto interior

$$\mathbf{x} \in \mathcal{U}$$

quando existe uma matriz

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) \in \mathbb{R}^{q \times p}$$

tal que

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) - \mathbf{g}(\mathbf{x}) = \mathbf{J}_{\mathbf{g}}(\mathbf{x})\mathbf{h} + \mathbf{r}_{\mathbf{x}}(\mathbf{h}),$$

com

$$\frac{\|\mathbf{r}_{\mathbf{x}}(\mathbf{h})\|}{\|\mathbf{h}\|} \longrightarrow 0 \quad \text{quando} \quad \|\mathbf{h}\| \longrightarrow 0.$$

Assim,

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) \approx \mathbf{g}(\mathbf{x}) + \mathbf{J}_{\mathbf{g}}(\mathbf{x})\mathbf{h},$$

e o diferencial é

$$d\mathbf{g} = \mathbf{J}_{\mathbf{g}}(\mathbf{x})d\mathbf{x}.$$

Para a transformação linear

$$\mathbf{g}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

tem-se

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}$$

em todos os pontos. Portanto,

$$d\mathbf{g} = \mathbf{A} d\mathbf{x},$$

e a aproximação linear é exata.

Gradiente e Jacobiana estão associados à mesma ideia de aproximação linear local, mas correspondem a contradomínios diferentes. Para uma função escalar, o gradiente fornece a representação vetorial da aplicação linear que define o diferencial. Para uma função vetorial, a Jacobiana fornece a representação matricial dessa aplicação linear.

7.2 Gradiente, derivada direcional, Jacobiana e Hessiana

7.2.1 Gradiente e derivada direcional

Para uma função diferenciável

$$f : \mathbb{R}^p \longrightarrow \mathbb{R},$$

o gradiente reúne as derivadas parciais:

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_p} \end{bmatrix}.$$

A derivada parcial em relação a x_j mede a variação da função na direção do vetor canônico $\mathbf{e}_j$. A variação em uma direção arbitrária é descrita pela derivada direcional.

Definição 7.3 (Derivada direcional). Seja

$$\mathbf{u} \in \mathbb{R}^p.$$

A derivada direcional de f no ponto $\mathbf{x}$ na direção de $\mathbf{u}$ é

$$D_{\mathbf{u}} f(\mathbf{x}) = \lim_{t \rightarrow 0} \frac{f(\mathbf{x} + t\mathbf{u}) - f(\mathbf{x})}{t},$$

quando esse limite existe.

Considere a função de uma variável

$$\varphi(t) = f(\mathbf{x} + t\mathbf{u}).$$

Pela regra da cadeia,

$$\begin{aligned}\varphi'(0) &= \nabla_{\mathbf{x}}f(\mathbf{x})^\top \frac{d}{dt}(\mathbf{x} + t\mathbf{u}) \Big|_{t=0} \\ &= \nabla_{\mathbf{x}}f(\mathbf{x})^\top \mathbf{u}.\end{aligned}$$

Portanto, se f é diferenciável,

$$D_{\mathbf{u}}f(\mathbf{x}) = \nabla_{\mathbf{x}}f(\mathbf{x})^\top \mathbf{u}.$$

Quando $\mathbf{u}$ é unitário, a derivada direcional mede a taxa de variação por unidade de deslocamento.

Se θ é o ângulo entre $\nabla_{\mathbf{x}}f(\mathbf{x})$ e $\mathbf{u}$, então

$$D_{\mathbf{u}}f(\mathbf{x}) = \|\nabla_{\mathbf{x}}f(\mathbf{x})\| \|\mathbf{u}\| \cos \theta.$$

Para $\|\mathbf{u}\| = 1$,

$$D_{\mathbf{u}}f(\mathbf{x}) = \|\nabla_{\mathbf{x}}f(\mathbf{x})\| \cos \theta.$$

Proposição 7.1 (Direções de maior crescimento e redução). *Se f é diferenciável em $\mathbf{x}$ e*

$$\nabla_{\mathbf{x}}f(\mathbf{x}) \neq \mathbf{0},$$

então, entre todas as direções unitárias,

$$\max_{\|\mathbf{u}\|=1} D_{\mathbf{u}}f(\mathbf{x}) = \|\nabla_{\mathbf{x}}f(\mathbf{x})\|,$$

e o máximo é atingido na direção

$$\mathbf{u}_{\max} = \frac{\nabla_{\mathbf{x}}f(\mathbf{x})}{\|\nabla_{\mathbf{x}}f(\mathbf{x})\|}.$$

A maior taxa de redução de primeira ordem ocorre na direção oposta:

$$\mathbf{u}_{\min} = -\frac{\nabla_{\mathbf{x}}f(\mathbf{x})}{\|\nabla_{\mathbf{x}}f(\mathbf{x})\|},$$

com

$$\min_{\|\mathbf{u}\|=1} D_{\mathbf{u}}f(\mathbf{x}) = -\|\nabla_{\mathbf{x}}f(\mathbf{x})\|.$$

(Apostol, 1969)

i Demonstração

Pelo Teorema 1.1,

$$\begin{aligned} D_{\mathbf{u}}f(\mathbf{x}) &= \nabla_{\mathbf{x}}f(\mathbf{x})^{\top} \mathbf{u} \\ &\leq \|\nabla_{\mathbf{x}}f(\mathbf{x})\| \|\mathbf{u}\|. \end{aligned}$$

Para $\|\mathbf{u}\| = 1$,

$$D_{\mathbf{u}}f(\mathbf{x}) \leq \|\nabla_{\mathbf{x}}f(\mathbf{x})\|.$$

A igualdade ocorre quando $\mathbf{u}$ possui a mesma direção e o mesmo sentido do gradiente. Aplicando o mesmo argumento à direção oposta, obtém-se o resultado para a maior taxa de redução de primeira ordem.

Se

$$\nabla_{\mathbf{x}}f(\mathbf{x}) = \mathbf{0},$$

todas as derivadas direcionais de primeira ordem são nulas. Nesse caso, a aproximação de primeira ordem não distingue direções de crescimento ou redução, e o comportamento local passa a depender de termos de ordem superior.

7.2.2 Gradiente e conjuntos de nível

Um conjunto de nível de f é definido por

$$\mathcal{S}_c = \{\mathbf{x} \in \mathbb{R}^p : f(\mathbf{x}) = c\},$$

em que c é constante.

Considere uma curva diferenciável

$$\gamma(t)$$

contida em $\mathcal{S}_c$. Então,

$$f(\gamma(t)) = c.$$

Derivando,

$$\nabla_{\mathbf{x}} f(\gamma(t))^{\top} \gamma'(t) = 0.$$

O vetor $\gamma'(t)$ é tangente ao conjunto de nível. Portanto, o gradiente é ortogonal a todas as direções tangentes.

Quando

$$\nabla_{\mathbf{x}} f(\mathbf{x}) \neq \mathbf{0},$$

o gradiente é um vetor normal ao conjunto de nível no ponto $\mathbf{x}$.

Exemplo 7.3 (Gradiente de uma função quadrática). Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2.$$

O gradiente é

$$\nabla_{\mathbf{x}} f(x_1, x_2) = \begin{bmatrix} 2x_1 \\ 4x_2 \end{bmatrix}.$$

No ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1/2 \end{bmatrix},$$

tem-se

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0) = \begin{bmatrix} 2 \\ 2 \end{bmatrix}$$

e

$$\|\nabla_{\mathbf{x}} f(\mathbf{x}_0)\| = 2\sqrt{2}.$$

A direção de maior crescimento é

$$\mathbf{u}_{\max} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Uma direção tangente à curva de nível é

$$\mathbf{u}_{\tan} = \frac{1}{\sqrt{2}} \begin{bmatrix} -1 \\ 1 \end{bmatrix}.$$

Como

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top \mathbf{u}_{\tan} = 0,$$

a derivada direcional nessa direção é nula.

A Figura 7.2 representa as curvas de nível da função, o gradiente e uma direção tangente no ponto $\mathbf{x}_0$.

A direção do gradiente depende do ponto. Para a função considerada, as curvas de nível são elipses e o gradiente aponta para fora, perpendicularmente à curva correspondente.

7.2.3 Jacobiana

A derivada de uma função vetorial é representada por sua matriz Jacobiana.

Definição 7.4 (Matriz Jacobiana). Seja

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

com

$$\mathbf{g}(\mathbf{x}) = \begin{bmatrix} g_1(\mathbf{x}) \\ \vdots \\ g_q(\mathbf{x}) \end{bmatrix}.$$

Suponha que as derivadas parciais das componentes de $\mathbf{g}$ existam no ponto $\mathbf{x}$. A matriz Jacobiana de $\mathbf{g}$ nesse ponto é




Figura 7.2: O gradiente é perpendicular à curva de nível e aponta na direção de maior crescimento local.

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \begin{bmatrix} \frac{\partial g_1}{\partial x_1} & \dots & \frac{\partial g_1}{\partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial g_q}{\partial x_1} & \dots & \frac{\partial g_q}{\partial x_p} \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

Cada linha da Jacobiana é o gradiente transposto de uma componente:

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \begin{bmatrix} \nabla_{\mathbf{x}} g_1(\mathbf{x})^\top \\ \vdots \\ \nabla_{\mathbf{x}} g_q(\mathbf{x})^\top \end{bmatrix}.$$

A aproximação de primeira ordem é

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) = \mathbf{g}(\mathbf{x}) + \mathbf{J}_{\mathbf{g}}(\mathbf{x})\mathbf{h} + o(\|\mathbf{h}\|).$$

A Jacobiana transforma uma pequena variação no domínio em uma aproximação da variação correspondente no contradomínio.

Exemplo 7.4 (Jacobiana de uma função de $\mathbb{R}^2$ em $\mathbb{R}^2$). Considere

$$\mathbf{g}(x_1, x_2) = \begin{bmatrix} g_1 \\ g_2 \end{bmatrix} = \begin{bmatrix} x_1^2 + x_2 \\ x_1 x_2 \end{bmatrix}.$$

Os gradientes das componentes são

$$\nabla_{\mathbf{x}} g_1 = \begin{bmatrix} 2x_1 \\ 1 \end{bmatrix}$$

e

$$\nabla_{\mathbf{x}} g_2 = \begin{bmatrix} x_2 \\ x_1 \end{bmatrix}.$$

Logo,

$$\mathbf{J}_{\mathbf{g}}(x_1, x_2) = \begin{bmatrix} 2x_1 & 1 \\ x_2 & x_1 \end{bmatrix}.$$

No ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 2 \end{bmatrix},$$

tem-se

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}_0) = \begin{bmatrix} 2 & 1 \\ 2 & 1 \end{bmatrix}.$$

Para uma pequena perturbação

$$\mathbf{h} = \begin{bmatrix} h_1 \\ h_2 \end{bmatrix},$$

a alteração é aproximada por

$$\mathbf{g}(\mathbf{x}_0 + \mathbf{h}) - \mathbf{g}(\mathbf{x}_0) \approx \begin{bmatrix} 2 & 1 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} h_1 \\ h_2 \end{bmatrix}.$$

Para uma transformação afim

$$\mathbf{g}(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b},$$

a Jacobiana é constante:

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}.$$

Assim, a parte linear local de uma transformação afim é exatamente a matriz $\mathbf{A}$, enquanto o termo de translação desaparece na diferenciação.

7.2.4 Regra da cadeia

A composição de funções exige a composição de suas aproximações lineares.

Teorema 7.1 (Regra da cadeia para funções vetoriais). *Considere funções diferenciáveis*

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

e

$$\mathbf{h} : \mathbb{R}^q \longrightarrow \mathbb{R}^r.$$

Para

$$\mathbf{f} = \mathbf{h} \circ \mathbf{g},$$

a Jacobiana é

$$\mathbf{J}_{\mathbf{f}}(\mathbf{x}) = \mathbf{J}_{\mathbf{h}}(\mathbf{g}(\mathbf{x})) \mathbf{J}_{\mathbf{g}}(\mathbf{x}).$$

(Apostol, 1969)

As dimensões do produto são

$$(r \times q)(q \times p) = r \times p.$$

A ordem do produto reflete a composição das aplicações lineares: sobre uma perturbação $\mathbf{h}_{\mathbf{x}} \in \mathbb{R}^p$, atua primeiro $\mathbf{J}_{\mathbf{g}}(\mathbf{x})$ e, sobre o resultado, atua $\mathbf{J}_{\mathbf{h}}(\mathbf{g}(\mathbf{x}))$. Por isso, na representação matricial, a Jacobiana de $\mathbf{h}$ aparece à esquerda.

No caso de uma composição escalar

$$f(\mathbf{x}) = h(\mathbf{g}(\mathbf{x})),$$

em que

$$h : \mathbb{R}^q \longrightarrow \mathbb{R},$$

a regra da cadeia assume a forma

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{J}_{\mathbf{g}}(\mathbf{x})^{\top} \nabla_{\mathbf{y}} h(\mathbf{y}) \Big|_{\mathbf{y}=\mathbf{g}(\mathbf{x})}.$$

Exemplo 7.5 (Gradiente de uma função composta). Considere

$$\mathbf{g}(\mathbf{x}) = \mathbf{Ax} - \mathbf{b}$$

e

$$h(\mathbf{y}) = \mathbf{y}^\top \mathbf{y}.$$

A função composta é

$$f(\mathbf{x}) = \|\mathbf{Ax} - \mathbf{b}\|^2.$$

Como

$$\mathbf{J}_g(\mathbf{x}) = \mathbf{A}$$

e

$$\nabla_{\mathbf{y}} h(\mathbf{y}) = 2\mathbf{y},$$

segue que

$$\begin{aligned}\nabla_{\mathbf{x}} f(\mathbf{x}) &= \mathbf{A}^\top [2(\mathbf{Ax} - \mathbf{b})] \\ &= 2\mathbf{A}^\top (\mathbf{Ax} - \mathbf{b}).\end{aligned}$$

A expressão $2\mathbf{A}^\top (\mathbf{Ax} - \mathbf{b})$ é o gradiente do critério de mínimos quadrados desenvolvido em Proposição 7.5.

7.2.5 Hessiana

A Hessiana descreve a variação local do gradiente.

Definição 7.5 (Matriz Hessiana). Seja

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}$$

uma função com derivadas parciais de segunda ordem no ponto considerado. Sua matriz Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_p \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_p^2} \end{bmatrix} \in \mathbb{R}^{p \times p}.$$

A Hessiana é a Jacobiana do gradiente:

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{J}_{\nabla f}(\mathbf{x}).$$

Se as derivadas parciais de segunda ordem são contínuas em uma vizinhança do ponto, então

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i},$$

e a Hessiana é simétrica:

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \nabla_{\mathbf{x}}^2 f(\mathbf{x})^\top.$$

O segundo diferencial é

$$d^2 f = d\mathbf{x}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}) d\mathbf{x}.$$

O segundo diferencial é uma forma quadrática no incremento $d\mathbf{x}$ e descreve a contribuição local de segunda ordem da função.

Para uma direção $\mathbf{u}$, considere novamente

$$\varphi(t) = f(\mathbf{x} + t\mathbf{u}).$$

A primeira derivada é

$$\varphi'(0) = \nabla_{\mathbf{x}} f(\mathbf{x})^\top \mathbf{u}.$$

A segunda derivada é

$$\varphi''(0) = \mathbf{u}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}) \mathbf{u}.$$

Essa forma quadrática representa a segunda taxa de variação de f ao longo da reta que passa por $\mathbf{x}$ na direção $\mathbf{u}$ e fornece a medida de curvatura direcional utilizada neste capítulo.

Exemplo 7.6 (Hessiana de uma função quadrática). Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2.$$

O gradiente é

$$\nabla_{\mathbf{x}} f(x_1, x_2) = \begin{bmatrix} 2x_1 \\ 4x_2 \end{bmatrix}.$$

A Hessiana é

$$\nabla_{\mathbf{x}}^2 f(x_1, x_2) = \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix}.$$

Para

$$\mathbf{u} = \begin{bmatrix} u_1 \\ u_2 \end{bmatrix},$$

a curvatura direcional é

$$\begin{aligned} \mathbf{u}^\top \nabla_{\mathbf{x}}^2 f \mathbf{u} &= \begin{bmatrix} u_1 & u_2 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} \\ &= 2u_1^2 + 4u_2^2. \end{aligned}$$

Ela é positiva para todo vetor não nulo. Para vetores unitários, a segunda taxa de variação é maior nas direções com maior componente em módulo no segundo eixo.

Para a função quadrática

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + c,$$

com $\mathbf{A}$ simétrica,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{A} \mathbf{x} - \mathbf{b}$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A}.$$

A curvatura da função é determinada pela matriz $\mathbf{A}$. A relação entre a Hessiana, a aproximação de segunda ordem, a convexidade e a classificação de pontos estacionários será desenvolvida na próxima seção.

7.3 Aproximações de Taylor e classificação local

7.3.1 Aproximação de Taylor de primeira ordem

A diferenciabilidade fornece uma aproximação linear da função em uma vizinhança de um ponto.

Para

$$f : \mathbb{R}^p \longrightarrow \mathbb{R},$$

diferenciável em $\mathbf{x}_0$,

$$f(\mathbf{x}_0 + \mathbf{h}) = f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^{\top} \mathbf{h} + o(\|\mathbf{h}\|).$$

Tomando

$$\mathbf{h} = \mathbf{x} - \mathbf{x}_0,$$

obtém-se

$$f(\mathbf{x}) \approx f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^{\top} (\mathbf{x} - \mathbf{x}_0).$$

Essa é a aproximação de Taylor de primeira ordem.

Para funções de uma variável, ela corresponde à reta tangente. Para funções de duas variáveis, corresponde ao plano tangente. Em dimensão geral, corresponde a uma função afim que aproxima localmente f .

Exemplo 7.7 (Aproximação linear de uma função quadrática). Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2$$

e o ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1/2 \end{bmatrix}.$$

Tem-se

$$f(\mathbf{x}_0) = 1^2 + 2 \left(\frac{1}{2} \right)^2 = \frac{3}{2}$$

e

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0) = \begin{bmatrix} 2 \\ 2 \end{bmatrix}.$$

A aproximação de primeira ordem é

$$\begin{aligned} f(\mathbf{x}) &\approx \frac{3}{2} + [2 \quad 2] \left[\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} - \begin{bmatrix} 1 \\ 1/2 \end{bmatrix} \right] \\ &= \frac{3}{2} + 2(x_1 - 1) + 2 \left(x_2 - \frac{1}{2} \right). \end{aligned}$$

A aproximação linear descreve a variação determinada pelo gradiente. Ela não representa a curvatura da função.

7.3.2 Aproximação de Taylor de segunda ordem

Quando f é duas vezes diferenciável, a Hessiana permite incorporar a curvatura local.

Teorema 7.2 (Expansão de Taylor de segunda ordem). *Se*

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}$$

possui derivadas de segunda ordem contínuas em uma vizinhança de $\mathbf{x}_0$, então

$$\begin{aligned} f(\mathbf{x}_0 + \mathbf{h}) &= f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top \mathbf{h} \\ &\quad + \frac{1}{2} \mathbf{h}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}_0) \mathbf{h} + o(\|\mathbf{h}\|^2). \end{aligned}$$

(Apostol, 1969)

Em termos de $\mathbf{x} - \mathbf{x}_0$,

$$\begin{aligned} f(\mathbf{x}) &\approx f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top (\mathbf{x} - \mathbf{x}_0) \\ &\quad + \frac{1}{2} (\mathbf{x} - \mathbf{x}_0)^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}_0) (\mathbf{x} - \mathbf{x}_0). \end{aligned}$$

Os três termos possuem funções distintas:

- $f(\mathbf{x}_0)$ determina o nível da aproximação;
- o gradiente determina a variação local de primeira ordem;
- a Hessiana determina a variação local de segunda ordem.

Quando

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0) = \mathbf{0},$$

o termo linear desaparece. Se a forma quadrática associada à Hessiana é não degenerada, ela fornece o termo dominante da variação local. Quando essa forma se anula em alguma direção, termos de ordem superior podem ser necessários para determinar o comportamento da função.

Exemplo 7.8 (Expansão de uma função quadrática). Considere

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + c,$$

com $\mathbf{A}$ simétrica.

O gradiente é

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{A} \mathbf{x} - \mathbf{b},$$

e a Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A}.$$

Como a função é quadrática, a expansão de Taylor de segunda ordem é exata:

$$\begin{aligned} f(\mathbf{x}_0 + \mathbf{h}) &= f(\mathbf{x}_0) + (\mathbf{A} \mathbf{x}_0 - \mathbf{b})^\top \mathbf{h} \\ &\quad + \frac{1}{2} \mathbf{h}^\top \mathbf{A} \mathbf{h}. \end{aligned}$$

Não existe termo residual de ordem superior.

7.3.3 Pontos estacionários

Definição 7.6 (Ponto estacionário). Um ponto

$$\mathbf{x}^*$$

é estacionário para uma função diferenciável f quando

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}.$$

Em um ponto estacionário, todas as derivadas direcionais de primeira ordem são nulas:

$$D_{\mathbf{u}} f(\mathbf{x}^*) = 0$$

para toda direção $\mathbf{u}$.

Proposição 7.2 (Condição necessária de primeira ordem). *Se f é diferenciável em um ponto interior $\mathbf{x}^*$ de seu domínio e possui nesse ponto um máximo ou mínimo local, então*

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}.$$

i Demonstração

Se

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) \neq \mathbf{0},$$

considere a direção unitária

$$\mathbf{u} = \frac{\nabla_{\mathbf{x}} f(\mathbf{x}^*)}{\|\nabla_{\mathbf{x}} f(\mathbf{x}^*)\|}.$$

Então,

$$D_{\mathbf{u}} f(\mathbf{x}^*) = \|\nabla_{\mathbf{x}} f(\mathbf{x}^*)\| > 0,$$

enquanto

$$D_{-\mathbf{u}} f(\mathbf{x}^*) = -\|\nabla_{\mathbf{x}} f(\mathbf{x}^*)\| < 0.$$

Assim, existem direções locais de aumento e de redução, o que contradiz a existência de um extremo local interior. Portanto,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}.$$

Como

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0},$$

tem-se

$$D_{\mathbf{u}} f(\mathbf{x}^*) = 0$$

para toda direção $\mathbf{u}$.

A recíproca da proposição anterior não é verdadeira em geral: um ponto estacionário pode ser mínimo local, máximo local ou ponto de sela.

7.3.4 Classificação pela Hessiana

Teorema 7.3 (Teste da Hessiana em um ponto estacionário). *Considere uma função duas vezes continuamente diferenciável em uma vizinhança de um ponto estacionário $\mathbf{x}^*$.*

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \succ \mathbf{0},$$

então $\mathbf{x}^*$ é um mínimo local estrito.

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \prec \mathbf{0},$$

então $\mathbf{x}^*$ é um máximo local estrito.

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^*)$$

é indefinida, então $\mathbf{x}^*$ é um ponto de sela.

Se a Hessiana é apenas semidefinida positiva ou semidefinida negativa, o teste pode ser inconclusivo. (Apostol, 1969)



i Demonstração

Como

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0},$$

a expansão de Taylor fornece

$$f(\mathbf{x}^* + \mathbf{h}) - f(\mathbf{x}^*) = \frac{1}{2} \mathbf{h}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \mathbf{h} + o(\|\mathbf{h}\|^2).$$

Considere inicialmente

$$\mathbf{H} = \nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \succ \mathbf{0}.$$

Como $\mathbf{H}$ é simétrica e positiva definida, seu menor autovalor satisfaz

$$\lambda_{\min}(\mathbf{H}) > 0.$$

Portanto,

$$\mathbf{h}^\top \mathbf{H} \mathbf{h} \geq \lambda_{\min}(\mathbf{H}) \|\mathbf{h}\|^2.$$

Além disso,

$$o(\|\mathbf{h}\|^2) = \varepsilon(\mathbf{h}) \|\mathbf{h}\|^2,$$

com

$$\varepsilon(\mathbf{h}) \xrightarrow{586} 0$$

quando $\mathbf{h} \rightarrow \mathbf{0}$.

Logo, para $\mathbf{h}$ suficientemente pequeno,

$$|\varepsilon(\mathbf{h})| < \frac{1}{4} \lambda_{\min}(\mathbf{H}).$$

Assim,

Exemplo 7.9 (Mínimo, máximo e ponto de sela). Considere as funções

$$f_1(x_1, x_2) = x_1^2 + x_2^2,$$

$$f_2(x_1, x_2) = -x_1^2 - x_2^2$$

e

$$f_3(x_1, x_2) = x_1^2 - x_2^2.$$

As três possuem ponto estacionário na origem.

Para f_1 ,

$$\nabla_{\mathbf{x}}^2 f_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \succ \mathbf{0}.$$

Logo, a origem é um mínimo estrito.

Para f_2 ,

$$\nabla_{\mathbf{x}}^2 f_2 = \begin{bmatrix} -2 & 0 \\ 0 & -2 \end{bmatrix} \prec \mathbf{0}.$$

Logo, a origem é um máximo estrito.

Para f_3 ,

$$\nabla_{\mathbf{x}}^2 f_3 = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix}.$$

A Hessiana possui um autovalor positivo e outro negativo. Portanto, a origem é um ponto de sela.

A Figura 7.3 compara as curvas de nível dos três casos.




Figura 7.3: Curvas de nível associadas a um mínimo, um máximo e um ponto de sela.

7.4 Convexidade e concavidade

7.4.1 Conjuntos convexos

Definição 7.7 (Conjunto convexo). Um conjunto

$$\mathcal{C} \subseteq \mathbb{R}^p$$

é convexo quando, para quaisquer

$$\mathbf{x}, \mathbf{y} \in \mathcal{C}$$

e

$$t \in [0, 1],$$

tem-se

$$t\mathbf{x} + (1 - t)\mathbf{y} \in \mathcal{C}.$$

O vetor

$$t\mathbf{x} + (1-t)\mathbf{y}$$

percorre o segmento de reta entre $\mathbf{x}$ e $\mathbf{y}$. Assim, um conjunto é convexo quando contém todos os segmentos que ligam seus pontos.

Subespaços, conjuntos afins como hiperplanos, bolas e regiões elipsoidais da forma

$$\left\{ \mathbf{x} : (\mathbf{x} - \mu)^\top \mathbf{A} (\mathbf{x} - \mu) \leq c \right\},$$

com $\mathbf{A} \succ \mathbf{0}$ e $c > 0$, e o cone das matrizes positivas definidas são exemplos de conjuntos convexos.

7.4.2 Funções convexas

Definição 7.8 (Função convexa). Uma função

$$f : \mathcal{C} \longrightarrow \mathbb{R},$$

definida em um conjunto convexo $\mathcal{C}$, é convexa quando

$$f(t\mathbf{x} + (1-t)\mathbf{y}) \leq tf(\mathbf{x}) + (1-t)f(\mathbf{y})$$

para quaisquer $\mathbf{x}, \mathbf{y} \in \mathcal{C}$ e $t \in [0, 1]$.

A função é estritamente convexa quando a desigualdade é estrita para $\mathbf{x} \neq \mathbf{y}$ e $t \in (0, 1)$.

Uma função é côncava quando $-f$ é convexa.

Geometricamente, o gráfico de uma função convexa permanece abaixo das cordas que ligam dois pontos de seu gráfico.

7.4.3 Caracterização de primeira ordem

Teorema 7.4 (Critério de primeira ordem para convexidade). *Se f é diferenciável em um conjunto convexo aberto $\mathcal{C}$, então f é convexa se, e somente se,*

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^\top (\mathbf{y} - \mathbf{x})$$

para quaisquer $\mathbf{x}, \mathbf{y} \in \mathcal{C}$. (Boyd; Vandenberghe, 2004)

A expressão

$$f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^\top (\mathbf{y} - \mathbf{x})$$

é a aproximação afim determinada pelo plano tangente em $\mathbf{x}$. Para uma função convexa, essa aproximação é um limite inferior global.

7.4.4 Caracterização pela Hessiana

Teorema 7.5 (Critério da Hessiana para convexidade). *Considere uma função*

$$f : \mathcal{C} \longrightarrow \mathbb{R}$$

duas vezes continuamente diferenciável em um conjunto convexo aberto

$$\mathcal{C} \subseteq \mathbb{R}^p.$$

Então, f é convexa em $\mathcal{C}$ se, e somente se,

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \succeq \mathbf{0}$$

para todo

$$\mathbf{x} \in \mathcal{C}.$$

Analogamente, f é côncava em $\mathcal{C}$ se, e somente se,

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \preceq \mathbf{0}$$

para todo

$$\mathbf{x} \in \mathcal{C}.$$

Além disso, se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \succ \mathbf{0}$$

para todo $\mathbf{x} \in \mathcal{C}$, então f é estritamente convexa. Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \prec \mathbf{0}$$

para todo $\mathbf{x} \in \mathcal{C}$, então f é estritamente côncava.

(Boyd; Vandenberghe, 2004)



i Demonstração

Considere dois pontos distintos

$$\mathbf{x}, \mathbf{y} \in \mathcal{C}$$

e defina

$$g(t) = f(\mathbf{x} + t(\mathbf{y} - \mathbf{x})), \quad 0 \leq t \leq 1.$$

Como $\mathcal{C}$ é convexo, todo o segmento entre $\mathbf{x}$ e $\mathbf{y}$ pertence a $\mathcal{C}$.
Pela regra da cadeia,

$$g''(t) = (\mathbf{y} - \mathbf{x})^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x} + t(\mathbf{y} - \mathbf{x})) (\mathbf{y} - \mathbf{x}).$$

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{z}) \succeq \mathbf{0}$$

para todo $\mathbf{z} \in \mathcal{C}$, então

$$g''(t) \geq 0,$$

e, portanto, g é convexa em $[0, 1]$. Como isso vale para qualquer segmento contido em $\mathcal{C}$, f é convexa.

Reciprocamente, se f é convexa, então a restrição de f a qualquer reta é convexa.
Para qualquer

$$\mathbf{x} \in \mathcal{C}$$

e qualquer direção

$$\mathbf{u} \in \mathbb{R}^p,$$

considere

$$h(t) = f(\mathbf{x} + t\mathbf{u})$$

para t suficientemente próximo de zero. A convexidade de h implica

$$h''(0) \geq 0.$$

Como

$$h''(0) = \mathbf{u}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}) \mathbf{u},$$

tem-se

A positividade da Hessiana deve ser verificada para todos os pontos do domínio considerado, e não somente em um ponto estacionário.

A condição

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \succ \mathbf{0}$$

em todo o domínio é suficiente para convexidade estrita, mas não é necessária. Uma função estritamente convexa pode possuir Hessiana singular em pontos isolados. Por exemplo,

$$f(x) = x^4$$

é estritamente convexa em $\mathbb{R}$, embora

$$f''(0) = 0.$$

7.4.5 Consequências para otimização

Proposição 7.3 (Pontos estacionários de funções convexas). *Se f é diferenciável e convexa em um conjunto convexo, qualquer ponto*

$$\mathbf{x}^*$$

que satisfaça

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}$$

é um mínimo global.

Se f é estritamente convexa e existe um ponto estacionário $\mathbf{x}^$, então esse ponto é o único minimizador global. (Boyd; Vandenberghe, 2004)*

i Demonstração

Pela caracterização de primeira ordem,

$$f(\mathbf{x}) \geq f(\mathbf{x}^*) + \nabla_{\mathbf{x}} f(\mathbf{x}^*)^\top (\mathbf{x} - \mathbf{x}^*).$$

Como o gradiente é nulo,

$$f(\mathbf{x}) \geq f(\mathbf{x}^*)$$

para todo $\mathbf{x}$ do domínio.

Se a função é estritamente convexa, a igualdade só pode ocorrer em $\mathbf{x} = \mathbf{x}^*$.

Essa propriedade diferencia a otimização convexa da otimização geral. Para uma função convexa, não existem mínimos locais que deixem de ser globais.

7.4.6 Funções quadráticas

Considere

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + c,$$

com $\mathbf{A}$ simétrica.

Como

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A},$$

tem-se:

- f é convexa se $\mathbf{A} \succeq \mathbf{0}$;
- f é estritamente convexa se $\mathbf{A} \succ \mathbf{0}$;
- f é côncava se $\mathbf{A} \preceq \mathbf{0}$;
- f é estritamente côncava se $\mathbf{A} \prec \mathbf{0}$.

Se

$$\mathbf{A} \succ \mathbf{0},$$

o ponto estacionário satisfaz

$$\mathbf{A} \mathbf{x}^* = \mathbf{b},$$

e

$$\mathbf{x}^* = \mathbf{A}^{-1}\mathbf{b}.$$

Esse ponto é o único mínimo global.

Se

$$\mathbf{A} \succeq \mathbf{0}$$

é singular, a existência de minimizadores depende de $\mathbf{b}$.

Quando

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}),$$

o sistema

$$\mathbf{Ax} = \mathbf{b}$$

possui solução. Nesse caso, os minimizadores formam o conjunto afim

$$\mathbf{x}_0 + \mathcal{N}(\mathbf{A}),$$

em que $\mathbf{x}_0$ é uma solução particular.

Quando

$$\mathbf{b} \notin \mathcal{C}(\mathbf{A}),$$

a função é ilimitada inferiormente e não possui minimizador.

De fato, como $\mathbf{A}$ é simétrica,

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}).$$

Assim, existe

$$\mathbf{z} \in \mathcal{N}(\mathbf{A})$$

tal que

$$\mathbf{b}^\top \mathbf{z} \neq 0.$$

Ao longo da reta

$$\mathbf{x} = t\mathbf{z},$$

o termo quadrático é nulo e

$$f(t\mathbf{z}) = -t\mathbf{b}^\top \mathbf{z} + c,$$

que pode tender a $-\infty$ escolhendo o sinal apropriado de t .

7.5 Otimização sem restrições

Um problema de minimização sem restrições possui a forma

$$\min_{\mathbf{x} \in \mathbb{R}^p} f(\mathbf{x}).$$

A Proposição 7.2 estabelece a condição necessária de primeira ordem para extremos locais interiores, enquanto o Teorema 7.3 utiliza a Hessiana para classificar pontos estacionários quando o teste de segunda ordem é conclusivo.

No caso convexo, a Proposição 7.3 mostra que um ponto estacionário é minimizador global. Esses resultados fornecem as condições de otimalidade; a questão seguinte é construir um procedimento iterativo para localizar esses pontos.

7.6 Otimização com restrições de igualdade

Considere o problema

$$\min_{\mathbf{x} \in \mathbb{R}^p} f(\mathbf{x})$$

sujeito a

$$\mathbf{c}(\mathbf{x}) = \mathbf{0},$$

em que

$$\mathbf{c} : \mathbb{R}^p \longrightarrow \mathbb{R}^m$$

é uma função vetorial de restrições:

$$\mathbf{c}(\mathbf{x}) = \begin{bmatrix} c_1(\mathbf{x}) \\ \vdots \\ c_m(\mathbf{x}) \end{bmatrix}.$$

O conjunto viável é

$$\mathcal{F} = \{\mathbf{x} : \mathbf{c}(\mathbf{x}) = \mathbf{0}\}.$$

Em um ponto regular, as linhas da Jacobiana das restrições são linearmente independentes. O espaço tangente ao conjunto viável é então

$$\mathcal{T}_{\mathbf{x}} = \mathcal{N}(\mathbf{J}_{\mathbf{c}}(\mathbf{x})).$$

Portanto, uma direção tangente $\mathbf{d}$ satisfaz

$$\mathbf{J}_{\mathbf{c}}(\mathbf{x})\mathbf{d} = \mathbf{0}.$$

O espaço normal correspondente é

$$\mathcal{T}_{\mathbf{x}}^{\perp} = \mathcal{C}(\mathbf{J}_{\mathbf{c}}(\mathbf{x})^{\top}),$$

isto é, o espaço gerado pelos gradientes das restrições.

Em um ótimo local regular $\mathbf{x}^*$, a derivada direcional de f deve ser nula em todas as direções tangentes:

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*)^{\top} \mathbf{d} = 0$$

para todo

$$\mathbf{d} \in \mathcal{T}_{\mathbf{x}^*}.$$

Consequentemente,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) \in \mathcal{T}_{\mathbf{x}^*}^{\perp} = \mathcal{C}[\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)^{\top}].$$

7.6.1 Multiplicadores de Lagrange

Teorema 7.6 (Condição de Lagrange). *Considere funções continuamente diferenciáveis*

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}$$

e

$$\mathbf{c} : \mathbb{R}^p \longrightarrow \mathbb{R}^m.$$

Seja $\mathbf{x}^*$ um ótimo local do problema

$$\min_{\mathbf{x}} f(\mathbf{x})$$

sujeito a

$$\mathbf{c}(\mathbf{x}) = \mathbf{0}.$$

Suponha que as linhas da Jacobiana

$$\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)$$

sejam linearmente independentes.

Essa condição equivale a

$$\text{posto} [\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)] = m.$$

Então existe um vetor

$$\lambda^* \in \mathbb{R}^m$$

tal que

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) + \mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)^\top \lambda^* = \mathbf{0}.$$

(Apostol, 1969)

i Demonstração

Como $\mathbf{x}^*$ é um ótimo local regular, a derivada direcional da função objetivo é nula em todas as direções tangentes ao conjunto viável. Portanto,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*)^\top \mathbf{d} = 0$$

para todo

$$\mathbf{d} \in \mathcal{N}[\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)].$$

Logo,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) \in \mathcal{N}[\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)]^\perp.$$

Pelo Teorema 3.5,

$$\mathcal{N}[\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)]^\perp = \mathcal{C}[\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)^\top].$$

Assim, existe um vetor

$$\mu^* \in \mathbb{R}^m$$

tal que

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)^\top \mu^*.$$

Definindo

$$\lambda^* = -\mu^*,$$

obtém-se

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) + \mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)^\top \lambda^* = \mathbf{0}.$$

A função lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = f(\mathbf{x}) + \lambda^\top \mathbf{c}(\mathbf{x}).$$

Sob a condição de regularidade do teorema, as condições necessárias de primeira ordem podem ser escritas como

$$\nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \lambda) = \mathbf{0}$$

e

$$\nabla_{\lambda} \mathcal{L}(\mathbf{x}, \lambda) = \mathbf{c}(\mathbf{x}) = \mathbf{0}.$$

Essas condições identificam candidatos a ótimo restrito. No caso geral, elas não são suficientes para garantir mínimo ou máximo. A classificação exige condições adicionais sobre a função objetivo, as restrições e a variação de segunda ordem nas direções tangentes.

Os multiplicadores ajustam a condição de gradiente nulo para levar em conta as direções que não estão disponíveis devido às restrições.

Exemplo 7.10 (Otimização com restrição de norma). Considere o problema

$$\max_{\mathbf{x}} \mathbf{a}^{\top} \mathbf{x},$$

em que

$$\mathbf{a} \neq \mathbf{0},$$

sujeito à restrição

$$\mathbf{x}^{\top} \mathbf{x} = 1.$$

A restrição exige que $\mathbf{x}$ tenha norma euclidiana unitária:

$$\|\mathbf{x}\| = 1.$$

Escrevendo-a na forma

$$c(\mathbf{x}) = \mathbf{x}^{\top} \mathbf{x} - 1 = 0,$$

o problema pode ser tratado pelos multiplicadores de Lagrange.

Para manter a formulação como um problema de minimização, considere a função objetivo

$$f(\mathbf{x}) = -\mathbf{a}^{\top} \mathbf{x}.$$

A lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = -\mathbf{a}^{\top} \mathbf{x} + \lambda (\mathbf{x}^{\top} \mathbf{x} - 1).$$

As condições de primeira ordem são obtidas diferenciando a lagrangiana em relação a $\mathbf{x}$ e ao multiplicador λ .

Em relação a $\mathbf{x}$,

$$\nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \lambda) = -\mathbf{a} + 2\lambda\mathbf{x}.$$

Portanto, em um ponto candidato à solução,

$$-\mathbf{a} + 2\lambda\mathbf{x} = \mathbf{0},$$

de modo que

$$\mathbf{x} = \frac{1}{2\lambda}\mathbf{a}.$$

Em relação a λ ,

$$\frac{\partial \mathcal{L}(\mathbf{x}, \lambda)}{\partial \lambda} = \mathbf{x}^\top \mathbf{x} - 1.$$

Assim, a segunda condição de primeira ordem simplesmente recupera a restrição:

$$\mathbf{x}^\top \mathbf{x} = 1.$$

Substituindo

$$\mathbf{x} = \frac{1}{2\lambda}\mathbf{a}$$

na restrição,

$$\left(\frac{1}{2\lambda}\mathbf{a}\right)^\top \left(\frac{1}{2\lambda}\mathbf{a}\right) = 1,$$

e, portanto,

$$\frac{\mathbf{a}^\top \mathbf{a}}{4\lambda^2} = 1.$$

Como

$$\mathbf{a}^\top \mathbf{a} = \|\mathbf{a}\|^2,$$

segue que

$$4\lambda^2 = \|\mathbf{a}\|^2,$$

ou

$$\lambda = \pm \frac{\|\mathbf{a}\|}{2}.$$

Consequentemente, existem dois pontos candidatos:

$$\mathbf{x}_1 = \frac{\mathbf{a}}{\|\mathbf{a}\|}$$

e

$$\mathbf{x}_2 = -\frac{\mathbf{a}}{\|\mathbf{a}\|}.$$

Para identificar qual deles maximiza a função objetivo original, avalie

$$\mathbf{a}^\top \mathbf{x}.$$

No primeiro ponto,

$$\mathbf{a}^\top \mathbf{x}_1 = \mathbf{a}^\top \frac{\mathbf{a}}{\|\mathbf{a}\|} = \frac{\|\mathbf{a}\|^2}{\|\mathbf{a}\|} = \|\mathbf{a}\|.$$

No segundo,

$$\mathbf{a}^\top \mathbf{x}_2 = -\|\mathbf{a}\|.$$

Logo, o máximo é atingido em

$$\mathbf{x}^* = \frac{\mathbf{a}}{\|\mathbf{a}\|},$$

e o valor máximo é

$$\mathbf{a}^\top \mathbf{x}^* = \|\mathbf{a}\|.$$

Geometricamente, a solução mostra que, entre todos os vetores unitários, o produto interno com $\mathbf{a}$ é máximo quando $\mathbf{x}$ possui a mesma direção e o mesmo sentido de $\mathbf{a}$.

O resultado também coincide com o caso de igualdade no Teorema 1.1, pois

$$\mathbf{a}^\top \mathbf{x} \leq \|\mathbf{a}\| \|\mathbf{x}\| = \|\mathbf{a}\|,$$

e a igualdade ocorre quando $\mathbf{x}$ é proporcional a $\mathbf{a}$.

Se $\mathbf{a} = \mathbf{0}$, a função objetivo é constante e todo vetor unitário satisfaz

$$\mathbf{a}^\top \mathbf{x} = 0.$$

Nesse caso, todo vetor que satisfaz a restrição é uma solução ótima.

7.6.2 Relação com problemas de autovalores

Considere o problema

$$\max_{\mathbf{x}} \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

sujeito a

$$\mathbf{x}^\top \mathbf{x} = 1,$$

com $\mathbf{A}$ simétrica.

A lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = \mathbf{x}^\top \mathbf{A} \mathbf{x} - \lambda (\mathbf{x}^\top \mathbf{x} - 1).$$

A condição de primeira ordem é

$$2\mathbf{A}\mathbf{x} - 2\lambda\mathbf{x} = \mathbf{0},$$

ou

$$\mathbf{A}\mathbf{x} = \lambda\mathbf{x}.$$

Portanto, todo ponto regular estacionário do problema restrito é um autovetor de $\mathbf{A}$, e o valor da função objetivo nesse ponto é o autovalor correspondente.

Pelo Teorema 5.3, desenvolvido no capítulo de decomposição espectral,

$$\max_{\|\mathbf{x}\|=1} \mathbf{x}^\top \mathbf{A} \mathbf{x} = \lambda_{\max}(\mathbf{A}),$$

e

$$\min_{\|\mathbf{x}\|=1} \mathbf{x}^\top \mathbf{A} \mathbf{x} = \lambda_{\min}(\mathbf{A}).$$

Assim, os multiplicadores de Lagrange produzem a equação de autovalores como condição de estacionariedade, enquanto o resultado espectral identifica quais desses pontos realizam os extremos globais.

7.7 Derivadas de formas lineares, quadráticas e funções de resíduos

7.7.1 Formas lineares e bilineares

Considere

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

em que $\mathbf{a} \in \mathbb{R}^p$ é constante. Como

$$df = \mathbf{a}^\top d\mathbf{x},$$

tem-se

$$\nabla_{\mathbf{x}} f = \mathbf{a}$$

e

$$\nabla_{\mathbf{x}}^2 f = \mathbf{0}.$$

Para a forma bilinear

$$f(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y},$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times q},$$

o diferencial é

$$df = d\mathbf{x}^\top \mathbf{A} \mathbf{y} + \mathbf{x}^\top \mathbf{A} d\mathbf{y}.$$

Reescrevendo o primeiro termo,

$$d\mathbf{x}^\top \mathbf{A} \mathbf{y} = (\mathbf{A} \mathbf{y})^\top d\mathbf{x},$$

e o segundo,

$$\mathbf{x}^\top \mathbf{A} d\mathbf{y} = (\mathbf{A}^\top \mathbf{x})^\top d\mathbf{y}.$$

Logo,

$$\nabla_{\mathbf{x}} f = \mathbf{A} \mathbf{y}$$

e

$$\nabla_{\mathbf{y}} f = \mathbf{A}^\top \mathbf{x}.$$

7.7.2 Derivadas de formas quadráticas

As formas quadráticas foram definidas em Definição 2.17, e a Proposição 2.10 mostrou que seu valor depende apenas da parte simétrica da matriz. Suas derivadas dependem dessa mesma parte simétrica.

Considere

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x},$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

O diferencial é

$$\begin{aligned} df &= d\mathbf{x}^\top \mathbf{A} \mathbf{x} + \mathbf{x}^\top \mathbf{A} d\mathbf{x} \\ &= \mathbf{x}^\top \mathbf{A}^\top d\mathbf{x} + \mathbf{x}^\top \mathbf{A} d\mathbf{x} \\ &= [(\mathbf{A} + \mathbf{A}^\top) \mathbf{x}]^\top d\mathbf{x}. \end{aligned}$$

Portanto,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A} + \mathbf{A}^\top.$$

A forma quadrática depende somente da parte simétrica da matriz:

$$\mathbf{A}_s = \frac{\mathbf{A} + \mathbf{A}^\top}{2}.$$

Assim,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{A}_s \mathbf{x},$$

e

$$\nabla_{\mathbf{x}} (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{A}_s \mathbf{x}.$$

Quando $\mathbf{A}$ é simétrica,

$$\nabla_{\mathbf{x}} (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{A} \mathbf{x}$$

e

$$\nabla_{\mathbf{x}}^2 (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{A}.$$

Proposição 7.4 (Derivadas de uma forma quadrática deslocada). *Se $\mathbf{A}$ é simétrica e*

$$f(\mathbf{x}) = (\mathbf{x} - \mu)^\top \mathbf{A} (\mathbf{x} - \mu),$$

então

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{A} (\mathbf{x} - \mu)$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}.$$

(Searle; Khuri, 2017)

i Demonstração

Defina

$$\mathbf{z} = \mathbf{x} - \mu.$$

Como

$$d\mathbf{z} = d\mathbf{x},$$

tem-se

$$\begin{aligned} df &= d\mathbf{z}^\top \mathbf{A} \mathbf{z} + \mathbf{z}^\top \mathbf{A} d\mathbf{z} \\ &= 2\mathbf{z}^\top \mathbf{A} d\mathbf{x}, \end{aligned}$$

pois $\mathbf{A}$ é simétrica. Portanto,

$$\nabla_{\mathbf{x}} f = 2\mathbf{A} \mathbf{z} = 2\mathbf{A} (\mathbf{x} - \mu).$$

A diferenciação do gradiente fornece a Hessiana.

Utilizando a classificação de positividade apresentada em Definição 2.18, se

$$\mathbf{A} \succeq \mathbf{0},$$

a forma quadrática deslocada é convexa. Se

$$\mathbf{A} \succ \mathbf{0},$$

ela é estritamente convexa e possui mínimo único em

$$\mathbf{x} = \boldsymbol{\mu}.$$

Se

$$\mathbf{A} \succeq \mathbf{0}$$

é singular, todos os vetores da forma

$$\mathbf{x} = \boldsymbol{\mu} + \mathbf{z}, \quad \mathbf{z} \in \mathcal{N}(\mathbf{A}),$$

também minimizam a função. Portanto, a unicidade ocorre quando

$$\mathbf{A} \succ \mathbf{0}.$$

7.7.3 Derivadas da norma euclidiana

Retomando a norma euclidiana definida em Definição 1.10,

$$\|\mathbf{x}\|^2 = \mathbf{x}^\top \mathbf{x}.$$

Portanto,

segue que

$$\nabla_{\mathbf{x}} \|\mathbf{x}\|^2 = 2\mathbf{x}$$

e

$$\nabla_{\mathbf{x}}^2 \|\mathbf{x}\|^2 = 2\mathbf{I}_p.$$

Para $\mathbf{x} \neq \mathbf{0}$,

$$\|\mathbf{x}\| = (\mathbf{x}^\top \mathbf{x})^{1/2}.$$

Pela regra da cadeia,

$$\nabla_{\mathbf{x}} \|\mathbf{x}\| = \frac{\mathbf{x}}{\|\mathbf{x}\|}.$$

A norma euclidiana não é diferenciável em $\mathbf{x} = \mathbf{0}$.

7.7.4 Funções de resíduos lineares

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}, \quad \mathbf{b} \in \mathbb{R}^q,$$

e defina o vetor de resíduos

$$\mathbf{r}(\mathbf{x}) = \mathbf{b} - \mathbf{A}\mathbf{x}.$$

Sua Jacobiana é

$$\mathbf{J}_{\mathbf{r}}(\mathbf{x}) = -\mathbf{A}.$$

A soma de quadrados dos resíduos é

$$f(\mathbf{x}) = \|\mathbf{r}(\mathbf{x})\|^2 = (\mathbf{b} - \mathbf{A}\mathbf{x})^\top (\mathbf{b} - \mathbf{A}\mathbf{x}).$$

Pela regra da cadeia,

$$\begin{aligned} \nabla_{\mathbf{x}} f(\mathbf{x}) &= 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^\top \mathbf{r}(\mathbf{x}) \\ &= -2\mathbf{A}^\top (\mathbf{b} - \mathbf{A}\mathbf{x}). \end{aligned}$$

Equivalentemente,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{A}^\top (\mathbf{A}\mathbf{x} - \mathbf{b}).$$

A Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}^\top \mathbf{A}.$$

A Hessiana é constante e não depende de $\mathbf{x}$. Além disso,

$$\mathbf{z}^\top \mathbf{A}^\top \mathbf{A} \mathbf{z} = \|\mathbf{A} \mathbf{z}\|^2 \geq 0,$$

para todo

$$\mathbf{z} \in \mathbb{R}^p.$$

Portanto,

$$\mathbf{A}^\top \mathbf{A} \succeq \mathbf{0}.$$

Como

$$\mathbf{A}^\top \mathbf{A} \succeq \mathbf{0},$$

a função é convexa.

Se $\mathbf{A}$ possui posto coluna completo,

$$\mathbf{A}^\top \mathbf{A} \succ \mathbf{0},$$

e a função é estritamente convexa.

As equações normais já foram introduzidas geometricamente em Definição 3.21, a partir da projeção sobre o espaço coluna. No Capítulo 6, Proposição 6.18 apresentou a solução por meio da SVD e da pseudoinversa. Nesta seção, o mesmo resultado será obtido a partir da condição de primeira ordem do cálculo diferencial.

7.7.5 Equações normais

Proposição 7.5 (Caracterização dos mínimos quadrados pelas equações normais). *Considere*

$$f(\mathbf{x}) = \|\mathbf{b} - \mathbf{A} \mathbf{x}\|^2,$$

com

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{b} \in \mathbb{R}^q.$$

Um vetor

$$\hat{\mathbf{x}} \in \mathbb{R}^p$$

é minimizador global de f se, e somente se, satisfaz as equações normais

$$\mathbf{A}^\top \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{b}.$$

Equivalentemente,

$$\mathbf{A}^\top (\mathbf{b} - \mathbf{A} \hat{\mathbf{x}}) = \mathbf{0}.$$

Se $\mathbf{A}$ possui posto coluna completo, o minimizador é único e dado por

$$\hat{\mathbf{x}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

(Eaton, 2007; Gentle, 2017)

i Demonstração

A derivação anterior fornece

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{A}^\top (\mathbf{Ax} - \mathbf{b})$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}^\top \mathbf{A} \succeq \mathbf{0}.$$

Logo, f é convexa. Pelo Proposição 7.3, um ponto é minimizador global se, e somente se, seu gradiente é nulo. Portanto,

$$\nabla_{\mathbf{x}} f(\hat{\mathbf{x}}) = \mathbf{0}$$

se, e somente se,

$$\mathbf{A}^\top \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{b}.$$

Se $\mathbf{A}$ possui posto coluna completo,

$$\mathbf{A}^\top \mathbf{A} \succ \mathbf{0},$$

de modo que f é estritamente convexa e possui, no máximo, um minimizador. Como

$$\mathbf{A}^\top \mathbf{A}$$

é invertível, esse minimizador é

$$\hat{\mathbf{x}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

A condição

$$\mathbf{A}^\top (\mathbf{b} - \mathbf{A}\hat{\mathbf{x}}) = \mathbf{0}$$

mostra que o resíduo de mínimos quadrados é ortogonal ao espaço coluna de $\mathbf{A}$.

O caso de posto deficiente, o conjunto de todos os minimizadores e a solução de menor norma foram estabelecidos em Proposição 6.18. Aqui, o objetivo é destacar que as equações normais surgem diretamente da condição de primeira ordem do problema de otimização.

Exemplo 7.11 (Média como solução de mínimos quadrados). Considere valores

$$z_1, \dots, z_n$$

e a função

$$f(m) = \sum_{i=1}^n (z_i - m)^2.$$

A derivada é

$$\begin{aligned} f'(m) &= -2 \sum_{i=1}^n (z_i - m) \\ &= 2nm - 2 \sum_{i=1}^n z_i. \end{aligned}$$

A condição

$$f'(m) = 0$$

fornece

$$m = \frac{1}{n} \sum_{i=1}^n z_i.$$

Como

$$f''(m) = 2n > 0,$$

a média aritmética é o único minimizador da soma dos quadrados dos desvios.

7.8 Diferenciais matriciais e cálculo por traços

Uma função escalar pode depender de todos os elementos de uma matriz. A diferenciação elemento a elemento é possível, mas se torna extensa quando a dimensão aumenta. Os diferenciais matriciais e as identidades de traço permitem organizar essas derivadas preservando a estrutura dos produtos. (Gentle, 2017; Searle; Khuri, 2017)

Considere uma função

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R},$$

cujo argumento é

$$\mathbf{X} = (x_{ij}).$$

O diferencial total pode ser escrito como

$$d\phi = \sum_{i=1}^m \sum_{j=1}^n \frac{\partial \phi}{\partial x_{ij}} dx_{ij}.$$

Retomando a convenção estabelecida no início do capítulo, o gradiente matricial é

$$\nabla_{\mathbf{X}} \phi = \left(\frac{\partial \phi}{\partial x_{ij}} \right) \in \mathbb{R}^{m \times n}.$$

Utilizando o produto interno de Frobenius definido em Definição 6.6,

$$\langle \mathbf{A}, \mathbf{B} \rangle_F = \text{tr}(\mathbf{A}^\top \mathbf{B}),$$

o diferencial assume a forma

$$d\phi = \langle \nabla_{\mathbf{X}} \phi, d\mathbf{X} \rangle_F.$$

Portanto,

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X} \right].$$

Essa identidade será utilizada para reconhecer o gradiente após reorganizar o diferencial.

Assim como o gradiente de uma função escalar de vetor representa o diferencial segundo o produto interno euclidiano, o gradiente matricial representa o diferencial segundo o produto interno de Frobenius.

7.8.1 Regras básicas do diferencial matricial

Se $\mathbf{A}$ e $\mathbf{B}$ são matrizes constantes e $\mathbf{X}$ é variável, então

$$d\mathbf{A} = \mathbf{0}$$

e

$$d\mathbf{B} = \mathbf{0}.$$

O diferencial é linear:

$$d(\mathbf{X} + \mathbf{Y}) = d\mathbf{X} + d\mathbf{Y},$$

e, para escalares constantes α e β ,

$$d(\alpha\mathbf{X} + \beta\mathbf{Y}) = \alpha d\mathbf{X} + \beta d\mathbf{Y}.$$

Para um produto de matrizes variáveis,

$$d(\mathbf{XY}) = d\mathbf{X} \mathbf{Y} + \mathbf{X} d\mathbf{Y}.$$

Para três fatores,

$$\begin{aligned} d(\mathbf{XYZ}) &= d\mathbf{X} \mathbf{Y} \mathbf{Z} \\ &\quad + \mathbf{X} d\mathbf{Y} \mathbf{Z} \\ &\quad + \mathbf{X} \mathbf{Y} d\mathbf{Z}. \end{aligned}$$

A transposição comuta com o diferencial:

$$d(\mathbf{X}^\top) = (d\mathbf{X})^\top.$$

Quando $\mathbf{A}$ e $\mathbf{B}$ são constantes,

$$d(\mathbf{AXB}) = \mathbf{A} d\mathbf{X} \mathbf{B}.$$

Para o produto cruzado,

$$d(\mathbf{X}^\top \mathbf{X}) = d\mathbf{X}^\top \mathbf{X} + \mathbf{X}^\top d\mathbf{X}.$$

Essas regras mantêm a ordem dos fatores. Em geral, os produtos matriciais não podem ser reorganizados por comutatividade.

7.8.2 Identidades de traço

O traço foi definido em Definição 2.8, e suas propriedades algébricas foram estabelecidas em Proposição 2.5 e Proposição 2.8. Para o cálculo matricial, serão utilizadas especialmente as permutações cíclicas dos fatores:

$$\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA}),$$

quando os produtos são definidos.

Para três fatores,

$$\text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{BCA}) = \text{tr}(\mathbf{CAB}).$$

A ordem cíclica pode ser alterada, mas não uma ordem arbitrária. Em geral,

$$\text{tr}(\mathbf{ABC}) \neq \text{tr}(\mathbf{ACB}).$$

Também são válidas as identidades

$$\text{tr}(\mathbf{A}^\top) = \text{tr}(\mathbf{A})$$

e

$$\text{tr}(\mathbf{A}^\top \mathbf{B}) = \text{tr}(\mathbf{B}^\top \mathbf{A}).$$

Para reorganizar diferenciais, será utilizada a relação

$$\text{tr}(\mathbf{A} d\mathbf{X}^\top) = \text{tr}(\mathbf{A}^\top d\mathbf{X}).$$

De modo semelhante,

$$\text{tr}(d\mathbf{X}^\top \mathbf{A}) = \text{tr}(\mathbf{A}^\top d\mathbf{X}).$$

O objetivo dessas transformações é escrever o diferencial na forma

$$d\phi = \text{tr}(\mathbf{G}^\top d\mathbf{X}).$$

Nesse caso,

$$\nabla_{\mathbf{X}}\phi = \mathbf{G}.$$

7.8.3 Função linear de uma matriz

Proposição 7.6 (Gradiente de uma função matricial linear). *Se*

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X}),$$

em que $\mathbf{A}$ é constante e possui a mesma dimensão de $\mathbf{X}$, então

$$\nabla_{\mathbf{X}}\phi = \mathbf{A}.$$

(Magnus; Neudecker, 2019)

i Demonstração

O diferencial é

$$\begin{aligned} d\phi &= d \text{tr}(\mathbf{A}^\top \mathbf{X}) \\ &= \text{tr}(\mathbf{A}^\top d\mathbf{X}). \end{aligned}$$

Comparando com

$$d\phi = \text{tr}[(\nabla_{\mathbf{X}}\phi)^\top d\mathbf{X}],$$

obtem-se

$$\nabla_{\mathbf{X}}\phi = \mathbf{A}.$$

Como

$$\text{tr}(\mathbf{A}^\top \mathbf{X}) = \sum_{i=1}^m \sum_{j=1}^n a_{ij} x_{ij},$$

essa função é o equivalente matricial da forma linear $\mathbf{a}^\top \mathbf{x}$.

7.8.4 Derivadas da norma de Frobenius

Pela Definição 6.7,

$$\|\mathbf{X}\|_F^2 = \text{tr}(\mathbf{X}^\top \mathbf{X}).$$

Seu diferencial é

$$\begin{aligned} d\|\mathbf{X}\|_F^2 &= d\text{tr}(\mathbf{X}^\top \mathbf{X}) \\ &= \text{tr}(d\mathbf{X}^\top \mathbf{X}) + \text{tr}(\mathbf{X}^\top d\mathbf{X}). \end{aligned}$$

Como

$$\text{tr}(d\mathbf{X}^\top \mathbf{X}) = \text{tr}(\mathbf{X}^\top d\mathbf{X}),$$

segue que

$$d\|\mathbf{X}\|_F^2 = 2\text{tr}(\mathbf{X}^\top d\mathbf{X}).$$

Portanto,

$$\nabla_{\mathbf{X}} \|\mathbf{X}\|_F^2 = 2\mathbf{X}.$$

Para uma matriz constante $\mathbf{M}$,

$$\phi(\mathbf{X}) = \|\mathbf{X} - \mathbf{M}\|_F^2$$

possui gradiente

$$\nabla_{\mathbf{X}} \phi = 2(\mathbf{X} - \mathbf{M}).$$

O único minimizador é

$$\mathbf{X} = \mathbf{M}.$$

De fato, essa função é estritamente convexa em $\mathbf{X}$, pois sua segunda variação em uma perturbação não nula $d\mathbf{X}$ é

$$d^2\phi = 2\|d\mathbf{X}\|_F^2 > 0.$$

7.8.5 Funções quadráticas de uma matriz

Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma),$$

com

$$\mathbf{X} \in \mathbb{R}^{m \times n}, \quad \mathbf{A} \in \mathbb{R}^{m \times m}$$

e

$$\Gamma \in \mathbb{R}^{n \times n}.$$

O diferencial é

$$\begin{aligned} d\phi &= \text{tr}(d\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma) \\ &\quad + \text{tr}(\mathbf{X}^\top \mathbf{A} d\mathbf{X} \Gamma). \end{aligned}$$

O primeiro termo pode ser escrito como

$$\text{tr}(d\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma) = \text{tr}[(\mathbf{A} \mathbf{X} \Gamma)^\top d\mathbf{X}].$$

No segundo termo, pela propriedade cíclica,

$$\begin{aligned} \text{tr}(\mathbf{X}^\top \mathbf{A} d\mathbf{X} \Gamma) &= \text{tr}(\Gamma \mathbf{X}^\top \mathbf{A} d\mathbf{X}) \\ &= \text{tr}[(\mathbf{A}^\top \mathbf{X} \Gamma^\top)^\top d\mathbf{X}]. \end{aligned}$$

Logo,

$$\nabla_{\mathbf{X}} \phi = \mathbf{A} \mathbf{X} \Gamma + \mathbf{A}^\top \mathbf{X} \Gamma^\top.$$

Se $\mathbf{A}$ e Γ são simétricas,

$$\nabla_{\mathbf{X}} \phi = 2\mathbf{A} \mathbf{X} \Gamma.$$

A dimensão do gradiente coincide com a dimensão do argumento:

$$\nabla_{\mathbf{X}} \phi \in \mathbb{R}^{m \times n}.$$

Exemplo 7.12 (Soma ponderada de produtos quadráticos). Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X}),$$

com $\mathbf{A}$ simétrica.

Esse é o caso particular

$$\Gamma = \mathbf{I}_n.$$

Portanto,

$$\nabla_{\mathbf{X}} \phi = 2\mathbf{A}\mathbf{X}.$$

Se as colunas de $\mathbf{X}$ são

$$\mathbf{x}_{.1}, \dots, \mathbf{x}_{.n},$$

então

$$\phi(\mathbf{X}) = \sum_{j=1}^n \mathbf{x}_{.j}^\top \mathbf{A} \mathbf{x}_{.j}.$$

O gradiente reúne, em suas colunas, os gradientes das formas quadráticas individuais:

$$2\mathbf{A}\mathbf{x}_{.1}, \dots, 2\mathbf{A}\mathbf{x}_{.n}.$$

7.8.6 Funções matriciais de resíduos

Considere o modelo matricial

$$\mathbf{Y} = \mathbf{X}\mathbf{B} + \mathcal{E},$$

em que

$$\mathbf{Y} \in \mathbb{R}^{n \times p}, \quad \mathbf{X} \in \mathbb{R}^{n \times k}$$

e

$$\mathbf{B} \in \mathbb{R}^{k \times p}.$$

Para um valor genérico de $\mathbf{B}$, defina a matriz de resíduos

$$\mathcal{E}(\mathbf{B}) = \mathbf{Y} - \mathbf{XB}.$$

A função de soma de quadrados é

$$Q(\mathbf{B}) = \|\mathcal{E}(\mathbf{B})\|_F^2.$$

Equivalentemente,

$$Q(\mathbf{B}) = \text{tr} [\mathcal{E}(\mathbf{B})^\top \mathcal{E}(\mathbf{B})].$$

Como

$$d\mathcal{E} = -\mathbf{X} d\mathbf{B},$$

tem-se

$$\begin{aligned} dQ &= 2 \text{tr} (\mathcal{E}^\top d\mathcal{E}) \\ &= -2 \text{tr} (\mathcal{E}^\top \mathbf{X} d\mathbf{B}) \\ &= -2 \text{tr} [(\mathbf{X}^\top \mathcal{E})^\top d\mathbf{B}]. \end{aligned}$$

Logo,

$$\nabla_{\mathbf{B}} Q(\mathbf{B}) = -2\mathbf{X}^\top \mathcal{E}(\mathbf{B}).$$

Substituindo a matriz de resíduos,

$$\nabla_{\mathbf{B}} Q(\mathbf{B}) = 2\mathbf{X}^\top (\mathbf{XB} - \mathbf{Y}).$$

A condição de primeira ordem é

$$\mathbf{X}^\top (\mathbf{Y} - \mathbf{XB}) = \mathbf{0},$$

ou

$$\mathbf{X}^\top \mathbf{X} \mathbf{B} = \mathbf{X}^\top \mathbf{Y}.$$

Essas são as equações normais matriciais.

Se $\mathbf{X}$ possui posto coluna completo,

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

Se $\mathbf{X}$ não possui posto coluna completo, os minimizadores não são únicos. A solução de mínimos quadrados de menor norma de Frobenius é

$$\widehat{\mathbf{B}}^\star = \mathbf{X}^+ \mathbf{Y}.$$

Mais geralmente, todos os minimizadores podem ser escritos como

$$\widehat{\mathbf{B}} = \mathbf{X}^+ \mathbf{Y} + (\mathbf{I}_k - \mathbf{X}^+ \mathbf{X}) \mathbf{C},$$

em que

$$\mathbf{C} \in \mathbb{R}^{k \times p}$$

é arbitrária.

A parcela adicional pertence ao núcleo da transformação

$$\mathbf{B} \mapsto \mathbf{X} \mathbf{B}$$

e, portanto, não altera os valores ajustados.


Assim, quando o critério utilizado é simplesmente a norma de Frobenius dos resíduos, o problema matricial pode ser interpretado como p problemas de mínimos quadrados que compartilham a mesma matriz de delineamento.

Proposição 7.7 (Convexidade dos mínimos quadrados matriciais). *A função*

$$Q(\mathbf{B}) = \|\mathbf{Y} - \mathbf{X} \mathbf{B}\|_F^2$$

é convexa em $\mathbf{B}$.

Ela é estritamente convexa se, e somente se, $\mathbf{X}$ possui posto coluna completo.



i Demonstração

Considere uma perturbação

$$d\mathbf{B}.$$

A segunda variação de Q é

$$d^2Q = 2 \operatorname{tr} (d\mathbf{B}^\top \mathbf{X}^\top \mathbf{X} d\mathbf{B}).$$

Equivalentemente,

$$d^2Q = 2 \|\mathbf{X} d\mathbf{B}\|_F^2 \geq 0.$$

Portanto, a função é convexa.

Se $\mathbf{X}$ possui posto coluna completo, então

$$\mathbf{X} d\mathbf{B} = \mathbf{0}$$

implica

$$d\mathbf{B} = \mathbf{0}.$$

Assim, a segunda variação é positiva para toda perturbação não nula, e a função é estritamente convexa.

Reciprocamente, se $\mathbf{X}$ não possui posto coluna completo, existe

$$\mathbf{z} \neq \mathbf{0}$$

tal que

$$\mathbf{X}\mathbf{z} = \mathbf{0}.$$

Escolha qualquer vetor não nulo

$$\mathbf{c} \in \mathbb{R}^p$$

e defina

$$d\mathbf{B} = \mathbf{z}\mathbf{c}^\top.$$

Então

$$d\mathbf{B} \neq \mathbf{0},$$

mas

$$d^2Q = 0$$

$$\mathbf{X} d\mathbf{B} = \mathbf{0}.$$

Portanto,

$$d^2Q = 0$$

em uma direção não nula, e a função não é estritamente convexa.

7.9 Derivadas de inversas, determinantes e log-determinantes

A matriz inversa e o determinante foram definidos em Definição 2.10 e Definição 2.11, enquanto a relação entre determinante e invertibilidade foi estabelecida em Teorema 2.3. A classificação das matrizes simétricas por positividade foi apresentada em Definição 2.18.

Nesta seção, esses objetos são retomados como funções de uma matriz variável. Suas derivadas exigem condições de invertibilidade e, em aplicações com matrizes de covariâncias, definição positiva.

7.9.1 Diferencial da matriz inversa

Considere uma matriz invertível

$$\mathbf{X} \in \mathbb{R}^{p \times p}.$$

A identidade

$$\mathbf{X}\mathbf{X}^{-1} = \mathbf{I}_p$$

permite obter o diferencial da inversa.

Proposição 7.8 (Diferencial da matriz inversa). *Se $\mathbf{X}$ é invertível, então*

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}(d\mathbf{X})\mathbf{X}^{-1}.$$

(Magnus; Neudecker, 2019; Searle; Khuri, 2017)

i Demonstração

Diferenciando

$$\mathbf{X}\mathbf{X}^{-1} = \mathbf{I}_p,$$

obtém-se

$$d\mathbf{X}\mathbf{X}^{-1} + \mathbf{X}d(\mathbf{X}^{-1}) = \mathbf{0}.$$

Multiplicando à esquerda por $\mathbf{X}^{-1}$,

$$\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1} + d(\mathbf{X}^{-1}) = \mathbf{0}.$$

Logo,

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}(d\mathbf{X})\mathbf{X}^{-1}.$$

Quando $\mathbf{X} \succ \mathbf{0}$ e a perturbação

$$d\mathbf{X} \succeq \mathbf{0},$$

tem-se

$$\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1} \succeq \mathbf{0},$$

e, portanto,

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1} \preceq \mathbf{0}.$$

Assim, a inversão reverte a ordem de Loewner: aumentos semidefinidos positivos da matriz produzem variações semidefinidas negativas de sua inversa.

Para uma perturbação $d\mathbf{X}$,

$$(\mathbf{X} + d\mathbf{X})^{-1} \approx \mathbf{X}^{-1} - \mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1}.$$

Essa aproximação é válida para perturbações suficientemente pequenas que preservem a invertibilidade.

Exemplo 7.13 (Caso escalar). Para

$$x \neq 0,$$

a função inversa é

$$f(x) = \frac{1}{x}.$$

A fórmula matricial reduz-se a

$$d(x^{-1}) = -x^{-1}(dx)x^{-1} = -\frac{1}{x^2}dx.$$

Portanto,

$$f'(x) = -\frac{1}{x^2}.$$

7.9.2 Diferencial do determinante

O determinante é uma função escalar definida sobre matrizes quadradas:

$$\det : \mathbb{R}^{p \times p} \longrightarrow \mathbb{R}.$$

Sua derivada é descrita pela fórmula de Jacobi.

Proposição 7.9 (Fórmula de Jacobi). *Se $\mathbf{X}$ é invertível, então*

$$d \det(\mathbf{X}) = \det(\mathbf{X}) \operatorname{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

(Magnus; Neudecker, 2019; Searle; Khuri, 2017)

i Demonstração

Considere uma perturbação $\mathbf{H}$ e a função

$$g(t) = \det(\mathbf{X} + t\mathbf{H}).$$

Como $\mathbf{X}$ é invertível,

$$g(t) = \det(\mathbf{X}) \det(\mathbf{I}_p + t\mathbf{X}^{-1}\mathbf{H}).$$

Pela multilinearidade do determinante,

$$\det(\mathbf{I}_p + t\mathbf{M}) = 1 + t \operatorname{tr}(\mathbf{M}) + o(t).$$

Aplicando essa expansão com

$$\mathbf{M} = \mathbf{X}^{-1}\mathbf{H},$$

obtem-se

$$g(t) = \det(\mathbf{X}) [1 + t \operatorname{tr}(\mathbf{X}^{-1}\mathbf{H}) + o(t)].$$

Logo,

$$g'(0) = \det(\mathbf{X}) \operatorname{tr}(\mathbf{X}^{-1}\mathbf{H}).$$

Como $\mathbf{H}$ representa uma perturbação arbitrária,

$$d \det(\mathbf{X}) = \det(\mathbf{X}) \operatorname{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

Como

$$d \det(\mathbf{X}) = \operatorname{tr} [(\nabla_{\mathbf{X}} \det(\mathbf{X}))^{\top} d\mathbf{X}],$$

segue que

$$\nabla_{\mathbf{X}} \det(\mathbf{X}) = \det(\mathbf{X}) \mathbf{X}^{-\top}.$$

Se $\mathbf{X}$ é simétrica,

$$\mathbf{X}^{-\top} = \mathbf{X}^{-1},$$

e

$$\nabla_{\mathbf{X}} \det(\mathbf{X}) = \det(\mathbf{X}) \mathbf{X}^{-1}.$$

A fórmula pode ser estendida a matrizes singulares por meio da matriz adjunta, mas a forma envolvendo $\mathbf{X}^{-1}$ exige invertibilidade.

7.9.3 Diferencial do log-determinante

Para matrizes positivas definidas,

$$\mathbf{X} \succ \mathbf{0},$$

o determinante é positivo e a função

$$\phi(\mathbf{X}) = \log \det(\mathbf{X})$$

está bem definida.

A restrição

$$\mathbf{X} \succ \mathbf{0}$$

garante simultaneamente que $\mathbf{X}$ é invertível e que

$$\det(\mathbf{X}) > 0,$$

de modo que o logaritmo real do determinante está bem definido.

Proposição 7.10 (Diferencial do log-determinante). *Se $\mathbf{X} \succ \mathbf{0}$, então*

$$d \log \det(\mathbf{X}) = \text{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

Consequentemente,

$$\nabla_{\mathbf{X}} \log \det(\mathbf{X}) = \mathbf{X}^{-1}.$$

(Searle; Khuri, 2017)

i Demonstração

Pela regra da cadeia,

$$d \log \det(\mathbf{X}) = \frac{1}{\det(\mathbf{X})} d \det(\mathbf{X}).$$

Aplicando a fórmula de Jacobi,

$$\begin{aligned} d \log \det(\mathbf{X}) &= \frac{1}{\det(\mathbf{X})} \det(\mathbf{X}) \operatorname{tr}(\mathbf{X}^{-1} d\mathbf{X}) \\ &= \operatorname{tr}(\mathbf{X}^{-1} d\mathbf{X}). \end{aligned}$$

Como $\mathbf{X}$ é simétrica,

$$\mathbf{X}^{-\top} = \mathbf{X}^{-1},$$

o que fornece o gradiente.

Para uma matriz real invertível, não necessariamente simétrica, pode-se considerar

$$\phi(\mathbf{X}) = \log |\det(\mathbf{X})|.$$

Como o determinante não se anula no conjunto das matrizes invertíveis, seu sinal permanece constante em uma vizinhança suficientemente pequena de cada matriz invertível. Nesse domínio,

$$d \log |\det(\mathbf{X})| = \operatorname{tr}(\mathbf{X}^{-1} d\mathbf{X}),$$

e, portanto,

$$\nabla_{\mathbf{X}} \log |\det(\mathbf{X})| = \mathbf{X}^{-\top}.$$

7.9.4 Traço envolvendo uma matriz inversa

Considere

$$\phi(\mathbf{X}) = \operatorname{tr}(\mathbf{A}\mathbf{X}^{-1}),$$

em que $\mathbf{A}$ é constante e $\mathbf{X}$ é invertível.

O diferencial é

$$\begin{aligned} d\phi &= \text{tr} [\mathbf{A} d(\mathbf{X}^{-1})] \\ &= -\text{tr} (\mathbf{A} \mathbf{X}^{-1} d\mathbf{X} \mathbf{X}^{-1}). \end{aligned}$$

Pela propriedade cíclica,

$$d\phi = -\text{tr} (\mathbf{X}^{-1} \mathbf{A} \mathbf{X}^{-1} d\mathbf{X}).$$

Portanto,

$$\nabla_{\mathbf{X}} \phi = -\mathbf{X}^{-\top} \mathbf{A}^{\top} \mathbf{X}^{-\top}.$$

Observe que o gradiente possui a mesma dimensão de $\mathbf{X}$,

$$\nabla_{\mathbf{X}} \phi \in \mathbb{R}^{p \times p}.$$

Se $\mathbf{A}$ e $\mathbf{X}$ são simétricas,

$$\nabla_{\mathbf{X}} \phi = -\mathbf{X}^{-1} \mathbf{A} \mathbf{X}^{-1}.$$

Exemplo 7.14 (Traço da inversa). Para

$$\phi(\mathbf{X}) = \text{tr} (\mathbf{X}^{-1}),$$

tem-se $\mathbf{A} = \mathbf{I}_p$. Logo,

$$\nabla_{\mathbf{X}} \phi = -\mathbf{X}^{-\top} \mathbf{X}^{-\top}.$$

Se $\mathbf{X}$ é simétrica positiva definida,

$$\nabla_{\mathbf{X}} \phi = -\mathbf{X}^{-2}.$$

7.9.5 Forma quadrática com matriz inversa

Considere

$$\phi(\mathbf{X}) = \mathbf{a}^\top \mathbf{X}^{-1} \mathbf{a},$$

em que $\mathbf{a} \in \mathbb{R}^p$ é constante e $\mathbf{X} \succ \mathbf{0}$.

A função pode ser escrita como

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^{-1} \mathbf{a} \mathbf{a}^\top).$$

Aplicando o resultado anterior,

$$\nabla_{\mathbf{X}} \phi = -\mathbf{X}^{-1} \mathbf{a} \mathbf{a}^\top \mathbf{X}^{-1}.$$

Equivalentemente,

$$\nabla_{\mathbf{X}} \phi = -(\mathbf{X}^{-1} \mathbf{a})(\mathbf{X}^{-1} \mathbf{a})^\top.$$

Essa matriz é semidefinida negativa.

Consequentemente, para uma perturbação

$$\mathbf{H} \succeq \mathbf{0},$$

tem-se

$$d\phi[\mathbf{H}] = \text{tr}[(\nabla_{\mathbf{X}} \phi)^\top \mathbf{H}] \leq 0.$$

Assim, aumentar $\mathbf{X}$ segundo a ordem de Loewner não aumenta a forma quadrática inversa.

Se o vetor também varia, considere

$$\phi(\mathbf{x}, \mathbf{X}) = \mathbf{x}^\top \mathbf{X}^{-1} \mathbf{x}.$$

Em relação ao vetor,

$$\nabla_{\mathbf{x}} \phi = 2\mathbf{X}^{-1} \mathbf{x},$$

enquanto, em relação à matriz,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-1}\mathbf{xx}^{\top}\mathbf{X}^{-1}.$$

7.9.6 Critério com log-determinante e traço

Considere $n > 0$ e o critério

$$Q(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \text{tr}(\Sigma^{-1}\mathbf{G}),$$

em que

$$\Sigma \succ \mathbf{0}$$

é variável e

$$\mathbf{G} \succeq \mathbf{0}$$

é constante e simétrica.

O diferencial é

$$\begin{aligned} dQ &= \frac{n}{2} \text{tr}(\Sigma^{-1}d\Sigma) \\ &\quad - \frac{1}{2} \text{tr}(\Sigma^{-1}\mathbf{G}\Sigma^{-1}d\Sigma). \end{aligned}$$

Logo,

$$\nabla_{\Sigma}Q = \frac{n}{2}\Sigma^{-1} - \frac{1}{2}\Sigma^{-1}\mathbf{G}\Sigma^{-1}.$$

A condição de primeira ordem é

$$n\Sigma^{-1} = \Sigma^{-1}\mathbf{G}\Sigma^{-1}.$$

Multiplicando à esquerda e à direita por Σ ,

$$n\Sigma = \mathbf{G}.$$

Portanto, o ponto estacionário é

$$\widehat{\Sigma} = \frac{1}{n} \mathbf{G}.$$

Para que esse ponto pertença ao domínio

$$\Sigma \succ \mathbf{0},$$

é necessário que

$$\mathbf{G} \succ \mathbf{0}.$$

Proposição 7.11 (Minimização do critério de covariância). *Considere*

$$n > 0$$

e uma matriz

$$\mathbf{G} \succ \mathbf{0}.$$


Então, a função

$$Q(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \operatorname{tr}(\Sigma^{-1} \mathbf{G})$$

possui minimizador único no conjunto das matrizes positivas definidas:

$$\widehat{\Sigma} = \frac{1}{n} \mathbf{G}.$$

(Anderson, 2003)



i Demonstração

Defina

$$\mathbf{Z} = \mathbf{G}^{1/2} \Sigma^{-1} \mathbf{G}^{1/2}.$$

Como $\mathbf{G}$ e Σ são positivas definidas,

$$\mathbf{Z} \succ \mathbf{0}.$$

Além disso,

$$\text{tr}(\Sigma^{-1} \mathbf{G}) = \text{tr}(\mathbf{Z})$$

e

$$\log \det(\Sigma) = \log \det(\mathbf{G}) - \log \det(\mathbf{Z}).$$

Assim, a menos de uma constante,

$$Q(\Sigma) = \frac{1}{2} [\text{tr}(\mathbf{Z}) - n \log \det(\mathbf{Z})].$$

Se

$$z_1, \dots, z_p$$

são os autovalores positivos de $\mathbf{Z}$, então

$$Q(\Sigma) = \text{constante} + \frac{1}{2} \sum_{j=1}^p (z_j - n \log z_j).$$

Para cada $z_j > 0$, a função

$$h(z) = z - n \log z$$

possui derivada

$$h'(z) = 1 - \frac{n}{z}$$

e segunda derivada

$$h''(z) = \frac{n}{z^2} > 0.$$

Seu único mínimo ocorre em

Se $\mathbf{G}$ é singular, o candidato

$$\frac{1}{n}\mathbf{G}$$

não pertence ao domínio positivo definido.

Além disso, o critério é ilimitado inferiormente. De fato, escolhendo uma direção unitária

$$\mathbf{u} \in \mathcal{N}(\mathbf{G}),$$

pode-se fazer o autovalor de Σ associado a essa direção tender a zero. Nessa direção, o termo

$$\text{tr}(\Sigma^{-1}\mathbf{G})$$

não recebe contribuição, enquanto

$$\log \det(\Sigma) \longrightarrow -\infty.$$

Portanto,

$$Q(\Sigma) \longrightarrow -\infty,$$

e o problema não possui minimizador no cone positivo definido.

7.10 Vetorização e produto de Kronecker

A vetorização transforma uma matriz em um vetor. O produto de Kronecker permite representar estruturas matriciais por meio de operações entre vetores e matrizes.

7.10.1 Operador de vetorização

Definição 7.9 (Operador de vetorização). Para

$$\mathbf{X} = \begin{bmatrix} x_{11} & \cdots & x_{1n} \\ \vdots & \ddots & \vdots \\ x_{m1} & \cdots & x_{mn} \end{bmatrix} \in \mathbb{R}^{m \times n},$$

o vetor

$$\text{vec}(\mathbf{X}) \in \mathbb{R}^{mn}$$

é obtido pelo empilhamento das colunas de $\mathbf{X}$:

$$\text{vec}(\mathbf{X}) = \begin{bmatrix} x_{11} \\ \vdots \\ x_{m1} \\ x_{12} \\ \vdots \\ x_{m2} \\ \vdots \\ x_{1n} \\ \vdots \\ x_{mn} \end{bmatrix}.$$

(Fujikoshi; Ulyanov; Shimizu, 2010; Searle; Khuri, 2017)

Exemplo 7.15 (Vetorização de uma matriz). Considere

$$\mathbf{X} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}.$$

Então,

$$\text{vec}(\mathbf{X}) = \begin{bmatrix} 1 \\ 4 \\ 2 \\ 5 \\ 3 \\ 6 \end{bmatrix}.$$

A vetorização é linear:

$$\text{vec}(\alpha \mathbf{X} + \beta \mathbf{Y}) = \alpha \text{vec}(\mathbf{X}) + \beta \text{vec}(\mathbf{Y}).$$

Além disso,

$$\|\mathbf{X}\|_F = \|\text{vec}(\mathbf{X})\|.$$

Isso ocorre porque os dois lados reúnem os mesmos elementos ao quadrado:

$$\|\mathbf{X}\|_F^2 = \sum_{i=1}^m \sum_{j=1}^n x_{ij}^2.$$

7.10.2 Produto de Kronecker

Definição 7.10 (Produto de Kronecker). Considere

$$\mathbf{A} = (a_{ij}) \in \mathbb{R}^{m \times n}$$

e

$$\mathbf{C} \in \mathbb{R}^{r \times s}.$$

O produto de Kronecker é a matriz

$$\mathbf{A} \otimes \mathbf{C} = \begin{bmatrix} a_{11}\mathbf{C} & \cdots & a_{1n}\mathbf{C} \\ \vdots & \ddots & \vdots \\ a_{m1}\mathbf{C} & \cdots & a_{mn}\mathbf{C} \end{bmatrix} \in \mathbb{R}^{mr \times ns}.$$

(Eaton, 2007; Fujikoshi; Ulyanov; Shimizu, 2010)

Exemplo 7.16 (Produto de Kronecker). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$$

e

$$\mathbf{C} = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}.$$

Então,

$$\begin{aligned} \mathbf{A} \otimes \mathbf{C} &= \begin{bmatrix} 1\mathbf{C} & 2\mathbf{C} \\ 3\mathbf{C} & 4\mathbf{C} \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 & 2 & 0 \\ 0 & -1 & 0 & -2 \\ 3 & 0 & 4 & 0 \\ 0 & -3 & 0 & -4 \end{bmatrix}. \end{aligned}$$

(Magnus; Neudecker, 2019)

O produto de Kronecker satisfaz:

$$(\mathbf{A} \otimes \mathbf{C})^\top = \mathbf{A}^\top \otimes \mathbf{C}^\top,$$

e, para produtos de dimensões compatíveis,

$$(\mathbf{A}_1 \otimes \mathbf{C}_1) (\mathbf{A}_2 \otimes \mathbf{C}_2) = (\mathbf{A}_1 \mathbf{A}_2) \otimes (\mathbf{C}_1 \mathbf{C}_2).$$

Se $\mathbf{A}$ e $\mathbf{C}$ são invertíveis,

$$(\mathbf{A} \otimes \mathbf{C})^{-1} = \mathbf{A}^{-1} \otimes \mathbf{C}^{-1}.$$

Se $\mathbf{A}$ e $\mathbf{C}$ são simétricas positivas definidas, então

$$\mathbf{A} \otimes \mathbf{C} \succ \mathbf{0}.$$

7.11 Integração múltipla e mudança de variáveis

O cálculo integral permite obter probabilidades, esperanças, momentos e distribuições marginais de vetores aleatórios contínuos. A mudança de variáveis permite, adicionalmente, transformar regiões de integração e determinar densidades após transformações do vetor aleatório. (Apostol, 1969; Eaton, 2007)

Para vetores aleatórios contínuos, as integrais são realizadas sobre subconjuntos de $\mathbb{R}^p$. Integrais múltiplas, marginalização, esperanças e mudança de variáveis descrevem probabilidades e transformações de distribuições contínuas.

7.11.1 Integrais múltiplas

Considere uma função

$$f : \mathcal{D} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}.$$

Sua integral sobre $\mathcal{D}$ é representada por

$$\int_{\mathcal{D}} f(\mathbf{x}) d\mathbf{x},$$

em que

$$d\mathbf{x} = dx_1 \cdots dx_p.$$

Em duas dimensões,

$$\int_{\mathcal{D}} f(x_1, x_2) dx_1 dx_2$$

representa a acumulação dos valores da função sobre uma região do plano.

Quando

$$\mathcal{D} = \mathcal{D}_1 \times \cdots \times \mathcal{D}_p$$

é um produto cartesiano, a integral pode ser escrita como integral iterada:

$$\int_{\mathcal{D}} f(\mathbf{x}) d\mathbf{x} = \int_{\mathcal{D}_p} \cdots \int_{\mathcal{D}_1} f(x_1, \dots, x_p) dx_1 \cdots dx_p,$$

desde que sejam satisfeitas as condições que permitem a integração sucessiva.

O produto cartesiano corresponde ao caso mais simples. Para regiões mais gerais, os limites de uma integral podem depender das demais variáveis. Em duas dimensões, por exemplo, uma região da forma

$$\mathcal{D} = \{(x_1, x_2) : a < x_1 < b, c(x_1) < x_2 < d(x_1)\}$$

conduz a

$$\int_{\mathcal{D}} f(x_1, x_2) dx_1 dx_2 = \int_a^b \int_{c(x_1)}^{d(x_1)} f(x_1, x_2) dx_2 dx_1,$$

quando as condições de integração correspondentes são satisfeitas.

7.11.2 Teorema de Tonelli

Teorema 7.7 (Teorema de Tonelli). *Se*

$$f : \mathcal{D}_1 \times \mathcal{D}_2 \longrightarrow [0, \infty]$$

é mensurável e não negativa, então

$$\begin{aligned} \int_{\mathcal{D}_1 \times \mathcal{D}_2} f(x_1, x_2) dx_1 dx_2 &= \int_{\mathcal{D}_1} \left[\int_{\mathcal{D}_2} f(x_1, x_2) dx_2 \right] dx_1 \\ &= \int_{\mathcal{D}_2} \left[\int_{\mathcal{D}_1} f(x_1, x_2) dx_1 \right] dx_2, \end{aligned}$$

permitindo valores infinitos. (Axler, 2020)

Para funções não negativas, a ordem de integração pode ser alterada mesmo quando a integral total não é finita.

7.11.3 Densidades multivariadas

Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ \vdots \\ X_p \end{bmatrix} \in \mathbb{R}^p.$$

Definição 7.11 (Densidade conjunta). O vetor aleatório $\mathbf{X}$ é absolutamente contínuo em relação à medida de Lebesgue em $\mathbb{R}^p$ quando existe uma função mensurável

$$f_{\mathbf{X}} : \mathbb{R}^p \longrightarrow [0, \infty]$$

tal que, para todo conjunto mensurável

$$\mathcal{A} \subseteq \mathbb{R}^p,$$

tem-se

$$P(\mathbf{X} \in \mathcal{A}) = \int_{\mathcal{A}} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

A função $f_{\mathbf{X}}$ é denominada **densidade conjunta** de $\mathbf{X}$.

Tomando

$$\mathcal{A} = \mathbb{R}^p,$$

segue necessariamente que

$$\int_{\mathbb{R}^p} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x} = 1.$$

Em duas dimensões,

$$P[(X_1, X_2) \in \mathcal{A}] = \iint_{\mathcal{A}} f_{X_1, X_2}(x_1, x_2) dx_1 dx_2.$$

7.11.4 Distribuições marginais

Considere a partição

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix},$$

com

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}$$

e

$$p_1 + p_2 = p.$$

Proposição 7.12 (Densidades marginais). *Considere o vetor aleatório absolutamente contínuo particionado como*

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix},$$

com densidade conjunta

$$f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2).$$

Então, uma densidade marginal de $\mathbf{X}_1$ é

$$f_{\mathbf{X}_1}(\mathbf{x}_1) = \int_{\mathbb{R}^{p_2}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_2,$$

e uma densidade marginal de $\mathbf{X}_2$ é

$$f_{\mathbf{X}_2}(\mathbf{x}_2) = \int_{\mathbb{R}^{p_1}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_1.$$

i Demonstração

Como a densidade conjunta é não negativa, o Teorema 7.7 permite integrar sucessivamente suas componentes.

Para qualquer conjunto mensurável

$$\mathcal{A} \subseteq \mathbb{R}^{p_1},$$

tem-se

$$\begin{aligned} P(\mathbf{X}_1 \in \mathcal{A}) &= \int_{\mathcal{A} \times \mathbb{R}^{p_2}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_1 d\mathbf{x}_2 \\ &= \int_{\mathcal{A}} \left[\int_{\mathbb{R}^{p_2}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_2 \right] d\mathbf{x}_1. \end{aligned}$$

Portanto,

$$f_{\mathbf{X}_1}(\mathbf{x}_1) = \int_{\mathbb{R}^{p_2}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_2$$

é uma densidade marginal de $\mathbf{X}_1$. O argumento para $\mathbf{X}_2$ é análogo.

A marginalização elimina as componentes que não aparecem no resultado, acumulando a densidade conjunta sobre todos os seus valores possíveis.

Exemplo 7.17 (Densidade marginal em uma região triangular). Considere a densidade conjunta

$$f_{\mathbf{X}_1, \mathbf{X}_2}(x_1, x_2) = 2,$$

para

$$0 < x_2 < x_1 < 1,$$

e zero fora dessa região.

A densidade marginal de $\mathbf{X}_1$ é

$$\begin{aligned} f_{\mathbf{X}_1}(x_1) &= \int_0^{x_1} 2 \, dx_2 \\ &= 2x_1, \quad 0 < x_1 < 1. \end{aligned}$$

A densidade marginal de $\mathbf{X}_2$ é

$$\begin{aligned} f_{\mathbf{X}_2}(x_2) &= \int_{x_2}^1 2 \, dx_1 \\ &= 2(1 - x_2), \quad 0 < x_2 < 1. \end{aligned}$$

As duas densidades integram 1 em seus respectivos domínios.

7.11.5 Esperanças de funções escalares, vetoriais e matriciais

Se

$$h : \mathbb{R}^p \longrightarrow \mathbb{R}$$

é uma função integrável, sua esperança é

$$E[h(\mathbf{X})] = \int_{\mathbb{R}^p} h(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) \, d\mathbf{x}.$$

Para uma função vetorial

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

com

$$\mathbf{g}(\mathbf{x}) = \begin{bmatrix} g_1(\mathbf{x}) \\ \vdots \\ g_q(\mathbf{x}) \end{bmatrix},$$

a esperança é definida componente a componente:

$$E[\mathbf{g}(\mathbf{X})] = \begin{bmatrix} E[g_1(\mathbf{X})] \\ \vdots \\ E[g_q(\mathbf{X})] \end{bmatrix}.$$

Equivalentemente,

$$E[\mathbf{g}(\mathbf{X})] = \int_{\mathbb{R}^p} \mathbf{g}(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

Para uma função matricial

$$\mathcal{G} : \mathbb{R}^p \longrightarrow \mathbb{R}^{m \times n},$$

a esperança também é calculada elemento a elemento:

$$E[\mathcal{G}(\mathbf{X})] = \int_{\mathbb{R}^p} \mathcal{G}(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

Em particular,

$$E[\mathbf{X}\mathbf{X}^\top] = \int_{\mathbb{R}^p} \mathbf{x}\mathbf{x}^\top f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

A existência da esperança vetorial ou matricial exige integrabilidade dos elementos correspondentes.

7.11.6 Mudança de variáveis

Uma transformação diferenciável altera a posição dos pontos e o volume dos elementos infinitesimais. O determinante da Jacobiana mede essa alteração local de volume.

Considere uma transformação

$$\mathbf{g} : \mathcal{D} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

e defina

$$\mathbf{y} = \mathbf{g}(\mathbf{x}).$$

A aproximação local é

$$d\mathbf{y} = \mathbf{J}_{\mathbf{g}}(\mathbf{x})d\mathbf{x}.$$

O fator local de alteração de volume é

$$|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|.$$

O valor absoluto é necessário porque o determinante pode ser negativo quando a transformação altera a orientação do espaço.

Teorema 7.8 (Teorema da Mudança de Variáveis). *Considere conjuntos abertos*

$$\mathcal{D}, \mathcal{G} \subseteq \mathbb{R}^p$$

e uma transformação bijetiva

$$\mathbf{g} : \mathcal{D} \longrightarrow \mathcal{G}$$

continuamente diferenciável, com inversa continuamente diferenciável e

$$\det \mathbf{J}_{\mathbf{g}}(\mathbf{x}) \neq 0$$

para todo $\mathbf{x} \in \mathcal{D}$.

Então, para uma função integrável h ,

$$\int_{\mathcal{G}} h(\mathbf{y}) d\mathbf{y} = \int_{\mathcal{D}} h(\mathbf{g}(\mathbf{x})) |\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})| d\mathbf{x}.$$

(Apostol, 1969; Eaton, 2007)

Utilizando a transformação inversa

$$\mathbf{x} = \mathbf{g}^{-1}(\mathbf{y}),$$

o elemento de volume transforma-se segundo

$$d\mathbf{x} = |\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y})| d\mathbf{y}.$$

Como

$$\mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y}) = [\mathbf{J}_{\mathbf{g}}(\mathbf{x})]^{-1},$$

segue que

$$|\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y})| = \frac{1}{|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|}.$$

7.11.7 Transformação de densidades

Proposição 7.13 (Densidade de uma transformação invertível). *Considere um vetor aleatório absolutamente contínuo $\mathbf{X}$ com densidade $f_{\mathbf{X}}$, tal que*

$$P(\mathbf{X} \in \mathcal{D}) = 1,$$

e uma transformação

$$\mathbf{g} : \mathcal{D} \longrightarrow \mathcal{G}$$

satisfazendo as condições do Teorema 7.8.

Defina

$$\mathbf{Y} = \mathbf{g}(\mathbf{X}).$$

Então, para

$$\mathbf{y} \in \mathcal{G},$$

a densidade de $\mathbf{Y}$ é

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}(\mathbf{g}^{-1}(\mathbf{y})) |\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y})|.$$

Para

$$\mathbf{y} \notin \mathcal{G},$$

tem-se

$$f_{\mathbf{Y}}(\mathbf{y}) = 0.$$

Equivalentemente, com

$$\mathbf{y} = \mathbf{g}(\mathbf{x}),$$

tem-se

$$f_{\mathbf{Y}}(\mathbf{g}(\mathbf{x})) = \frac{f_{\mathbf{X}}(\mathbf{x})}{|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|}.$$

A densidade é reduzida em regiões expandidas pela transformação e aumentada em regiões contraídas, de modo que a probabilidade total permaneça igual a 1.

Quando a transformação não é globalmente injetiva, a fórmula anterior não pode ser aplicada diretamente com uma única inversa. Sob condições de regularidade, pode-se particionar o domínio em regiões nas quais a transformação seja injetiva e somar as contribuições correspondentes às diferentes pré-imagens.

Esse caso não será desenvolvido em detalhe neste capítulo.

7.11.8 Transformações afins

Considere

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b},$$

em que

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é invertível e

$$\mathbf{b} \in \mathbb{R}^p.$$

A transformação inversa é

$$\mathbf{X} = \mathbf{A}^{-1} (\mathbf{Y} - \mathbf{b}).$$

A Jacobiana da transformação é constante:

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}.$$

A Jacobiana da inversa é

$$\mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y}) = \mathbf{A}^{-1}.$$

Logo,

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}[\mathbf{A}^{-1}(\mathbf{y} - \mathbf{b})] \frac{1}{|\det(\mathbf{A})|}.$$

A translação $\mathbf{b}$ altera a posição da distribuição, mas não altera o fator de volume. Esse fator depende apenas da parte linear.

Exemplo 7.18 (Transformação afim em uma dimensão). Considere

$$Y = aX + b,$$

com $a \neq 0$.

A transformação inversa é

$$X = \frac{Y - b}{a},$$

e

$$\left| \frac{dx}{dy} \right| = \frac{1}{|a|}.$$

Portanto,

$$f_Y(y) = f_X\left(\frac{y - b}{a}\right) \frac{1}{|a|}.$$

7.11.9 Interpretação geométrica do determinante Jacobiano

Considere a transformação não linear

$$\mathbf{g}(x_1, x_2) = \begin{bmatrix} x_1 + 0,35x_1x_2 \\ x_2 + 0,20x_1^2 \end{bmatrix}.$$

Sua Jacobiana é

$$\mathbf{J}_{\mathbf{g}}(x_1, x_2) = \begin{bmatrix} 1 + 0,35x_2 & 0,35x_1 \\ 0,40x_1 & 1 \end{bmatrix}.$$

O determinante é

$$\det \mathbf{J}_{\mathbf{g}}(x_1, x_2) = 1 + 0,35x_2 - 0,14x_1^2.$$

O fator de alteração de área varia de acordo com o ponto. A Figura 7.4 mostra uma grade no domínio e sua imagem pela transformação.

Uma pequena região em torno de $\mathbf{x}$ tem sua área multiplicada aproximadamente por




Figura 7.4: Transformação de uma grade e alteração local de área determinada pelo Jacobiano.

$$|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|.$$

A imagem da grade apresenta expansão e contração diferentes ao longo do domínio porque o determinante Jacobiano não é constante.

7.11.10 Transformações elipsoidais

Considere uma matriz positiva definida

$$\Sigma \in \mathbb{R}^{p \times p}$$

e sua raiz quadrada principal simétrica positiva definida

$$\Sigma^{1/2}.$$

Considere a transformação

$$\mathbf{x} = \mu + \Sigma^{1/2} \mathbf{z}.$$

A Jacobiana é

$$\mathbf{J}_{\mathbf{g}}(\mathbf{z}) = \Sigma^{1/2}.$$

Logo,

$$|\det \mathbf{J}_{\mathbf{g}}(\mathbf{z})| = \det(\Sigma^{1/2}) = \det(\Sigma)^{1/2}.$$

A transformação inversa é

$$\mathbf{z} = \Sigma^{-1/2} (\mathbf{x} - \mu),$$

com fator

$$|\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{x})| = \det(\Sigma)^{-1/2}.$$

Além disso,

$$\begin{aligned} \mathbf{z}^{\top} \mathbf{z} &= (\mathbf{x} - \mu)^{\top} \Sigma^{-1/2} \Sigma^{-1/2} (\mathbf{x} - \mu) \\ &= (\mathbf{x} - \mu)^{\top} \Sigma^{-1} (\mathbf{x} - \mu). \end{aligned}$$

A transformação converte esferas no espaço de $\mathbf{z}$ em elipsóides no espaço de $\mathbf{x}$. Essa relação será utilizada na construção de densidades multivariadas.

Integrais múltiplas calculam probabilidades e esperanças, a marginalização produz densidades marginais e a mudança de variáveis determina como integrais e densidades se transformam.

As relações centrais são:

- probabilidades são obtidas por integração da densidade conjunta;
- densidades marginais são obtidas integrando as componentes que se deseja eliminar;
- esperanças de vetores e matrizes são calculadas componente a componente;
- mudanças de variáveis exigem o determinante absoluto da Jacobiana;
- transformações afins produzem fatores de volume constantes;
- transformações elipsoidais convertem geometria esférica e elipsoidal.

7.12 Aprofundamento teórico

Leitura de aprofundamento

A identidade geral de vetorização, o vetor escore, a informação observada e a informação de Fisher aparecem em desenvolvimentos inferenciais baseados em representações vetorizadas e funções de verossimilhança.

A interpretação inferencial desses objetos requer condições de regularidade e resultados probabilísticos sobre estimadores.

7.12.1 Identidade de vetorização

A relação entre vetorização e produto de Kronecker permite representar um produto matricial como uma transformação linear do vetor de elementos da matriz.

Proposição 7.14 (Identidade fundamental da vetorização). *Considere*

$$\mathbf{A} \in \mathbb{R}^{r \times m}, \quad \mathbf{X} \in \mathbb{R}^{m \times n}$$

e

$$\Gamma \in \mathbb{R}^{n \times s}.$$

Então,

$$\text{vec}(\mathbf{A}\mathbf{X}\Gamma) = (\Gamma^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

(Magnus; Neudecker, 2019)

(Gentle, 2017)

O lado esquerdo possui dimensão rs . No lado direito,

$$\Gamma^\top \otimes \mathbf{A} \in \mathbb{R}^{rs \times mn},$$

e

$$\text{vec}(\mathbf{X}) \in \mathbb{R}^{mn}.$$

Casos particulares importantes são

$$\text{vec}(\mathbf{A}\mathbf{X}) = (\mathbf{I}_n \otimes \mathbf{A}) \text{vec}(\mathbf{X})$$

e

$$\text{vec}(\mathbf{X}\Gamma) = (\Gamma^\top \otimes \mathbf{I}_m) \text{vec}(\mathbf{X}).$$

A identidade mostra que uma transformação que atua simultaneamente à esquerda e à direita de uma matriz pode ser representada como uma transformação linear usual sobre o vetor formado por seus elementos.

Assim,

$$\mathbf{X} \mapsto \mathbf{A}\mathbf{X}\Gamma$$

corresponde, após vetorização, a

$$\text{vec}(\mathbf{X}) \mapsto (\Gamma^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

Exemplo 7.19 (Vetorização de um produto matricial). Considere

$$\mathbf{Y} = \mathbf{A}\mathbf{X}\Gamma.$$

Uma pequena perturbação de $\mathbf{X}$ produz

$$d\mathbf{Y} = \mathbf{A} d\mathbf{X} \Gamma.$$

Vetorizando,

$$d \text{vec}(\mathbf{Y}) = (\Gamma^\top \otimes \mathbf{A}) d \text{vec}(\mathbf{X}).$$

Portanto, a Jacobiana da transformação vetorizada é

$$\frac{\partial \text{vec}(\mathbf{Y})}{\partial \text{vec}(\mathbf{X})^\top} = \Gamma^\top \otimes \mathbf{A}.$$

7.12.2 Log-verossimilhança e vetor escore

Considere observações independentes

$$\mathbf{x}_1, \dots, \mathbf{x}_n$$

provenientes de um mesmo modelo paramétrico com função de densidade ou de probabilidade

$$f(\mathbf{x}; \theta),$$

em que

$$\theta \in \Theta \subseteq \mathbb{R}^k$$

é o vetor de parâmetros e Θ é o espaço paramétrico.

Nessas condições, a função de verossimilhança é

$$L_n(\theta) = \prod_{i=1}^n f(\mathbf{x}_i; \theta).$$

A log-verossimilhança é

$$\ell_n(\theta) = \log L_n(\theta) = \sum_{i=1}^n \log f(\mathbf{x}_i; \theta).$$

Como o logaritmo é estritamente crescente, maximizar L_n equivale a maximizar ℓ_n .

Definição 7.12 (Vetor escore). O vetor escore é o gradiente da log-verossimilhança:

$$\mathbf{s}_n(\theta) = \nabla_{\theta} \ell_n(\theta) \in \mathbb{R}^k.$$

Em coordenadas,

$$\mathbf{s}_n(\theta) = \begin{bmatrix} \frac{\partial \ell_n}{\partial \theta_1} \\ \vdots \\ \frac{\partial \ell_n}{\partial \theta_k} \end{bmatrix}.$$

Se um estimador de máxima verossimilhança é um ponto interior do espaço paramétrico e a log-verossimilhança é diferenciável nesse ponto, então deve satisfazer

$$\mathbf{s}_n(\hat{\theta}) = \mathbf{0}.$$

Essa condição é necessária, mas pode não ser suficiente para identificar um máximo. Também devem ser examinados:

- a curvatura da log-verossimilhança;
- a existência e a unicidade da solução;
- os limites do espaço paramétrico;
- possíveis máximos na fronteira.

7.12.3 Informação observada e informação de Fisher

Definição 7.13 (Informação observada). A matriz de informação observada é

$$\mathcal{J}_n(\theta) = -\nabla_{\theta}^2 \ell_n(\theta).$$

(Casella; Berger, 2002)

Se

$$\mathbf{s}_n(\hat{\theta}) = \mathbf{0}$$

e

$$\mathcal{J}_n(\hat{\theta}) \succ \mathbf{0},$$

então

$$\nabla_{\theta}^2 \ell_n(\hat{\theta}) \prec \mathbf{0},$$

e o teste da Hessiana fornece uma condição suficiente para que $\hat{\theta}$ seja um máximo local estrito da log-verossimilhança.

Em um ponto arbitrário do espaço paramétrico, a matriz

$$\mathcal{J}_n(\theta) = -\nabla_{\theta}^2 \ell_n(\theta)$$

não precisa ser positiva semidefinida e pode, inclusive, ser indefinida.

Em um ponto estacionário interior que seja máximo local,

$$\nabla_{\theta}^2 \ell_n(\hat{\theta}) \preceq \mathbf{0},$$

de modo que

$$\mathcal{J}_n(\hat{\theta}) \succeq \mathbf{0}.$$

A informação observada pode ser singular quando, por exemplo:

- há parâmetros localmente não identificados;
- existem redundâncias na parametrização;
- a log-verossimilhança apresenta direções localmente planas.

Máximos na fronteira exigem tratamento separado, pois as condições usuais de ponto estacionário e o teste irrestrito da Hessiana não os caracterizam adequadamente.

Definição 7.14 (Informação de Fisher). Suponha que o vetor escore possua segundo momento finito. A informação de Fisher da amostra é definida por

$$\mathcal{J}_n(\theta) = E_{\theta} [\mathbf{s}_n(\theta) \mathbf{s}_n(\theta)^{\top}].$$

(Anderson, 2003; Casella; Berger, 2002)

Sob condições de regularidade que permitem diferenciar a densidade sob o sinal de integração,

$$E_{\theta} [\mathbf{s}_n(\theta)] = \mathbf{0}.$$

Sob condições adicionais que justificam a relação entre a primeira e a segunda derivadas da log-verossimilhança,

$$\begin{aligned} \mathcal{J}_n(\theta) &= -E_{\theta} [\nabla_{\theta}^2 \ell_n(\theta)] \\ &= E_{\theta} [\mathcal{J}_n(\theta)]. \end{aligned}$$

Assim, em modelos regulares, a informação de Fisher coincide com a esperança da informação observada. Como o escore possui esperança nula nessas condições,

$$\mathcal{J}_n(\theta) = \text{Cov}_{\theta} [\mathbf{s}_n(\theta)].$$

Essas identidades não devem ser utilizadas automaticamente. Sua validade depende das condições de regularidade, incluindo a possibilidade de intercambiar derivação e integração e o comportamento do suporte em relação ao parâmetro.

7.13 Síntese do capítulo

O capítulo reuniu as ferramentas de cálculo necessárias para estudar funções de vetores e matrizes e para formular problemas posteriores da Estatística Multivariada.

No cálculo diferencial, o gradiente representa a variação de primeira ordem de uma função escalar, a Jacobiana representa a transformação linear local de uma função vetorial e a Hessiana descreve sua curvatura. Essas estruturas sustentam aproximações de Taylor e condições de otimalidade.

A otimização utiliza essas derivadas de formas diferentes. Em problemas sem restrições, pontos estacionários e a definitude da Hessiana permitem caracterizar soluções locais, enquanto a convexidade fornece resultados globais. Em problemas com restrições de igualdade, os multiplicadores de Lagrange incorporam a geometria do conjunto viável. As funções de resíduos mostram como essas ferramentas conduzem às equações normais e aos problemas de mínimos quadrados.

No cálculo matricial, os diferenciais e as identidades de traço permitem trabalhar diretamente com parâmetros matriciais. Derivadas de inversas, determinantes e log-determinantes serão utilizadas em critérios que envolvem matrizes de covariâncias. A vetorização e o produto de Kronecker fornecem uma representação vetorial para transformações entre matrizes.

O cálculo integral completa essa estrutura ao permitir a obtenção de probabilidades, expectativas e densidades marginais. O Teorema da Mudança de Variáveis mostra como o determinante Jacobiano modifica elementos de volume e densidades sob transformações. Transformações afins e elipsoidais conectam essa ideia às formas quadráticas e às matrizes positivas definidas.

As principais relações estabelecidas no capítulo podem ser resumidas da seguinte forma:

Tabela 7.2: Relações entre as ferramentas do cálculo e seus usos posteriores.

Estrutura matemática	Papel nos capítulos seguintes
Derivadas	Aproximação local e otimização
Diferenciais matriciais	Manipulação e estimação de parâmetros matriciais
Integração e Jacobianos	Construção e transformação de distribuições multivariadas

A Tabela 7.3 reúne algumas das identidades de uso recorrente.

Tabela 7.3: Identidades selecionadas de cálculo vetorial e matricial.

Função ou transformação	Derivada ou diferencial
$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x}$	$\nabla_{\mathbf{x}} f = \mathbf{a}$
$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$	$\nabla_{\mathbf{x}} f = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}$
$f(\mathbf{x}) = \ \mathbf{b} - \mathbf{A} \mathbf{x}\ ^2$	$\nabla_{\mathbf{x}} f = -2\mathbf{A}^\top (\mathbf{b} - \mathbf{A} \mathbf{x})$
$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X})$	$\nabla_{\mathbf{X}} \phi = \mathbf{A}$
$\phi(\mathbf{X}) = \ \mathbf{X}\ _F^2$	$\nabla_{\mathbf{X}} \phi = 2\mathbf{X}$
$\mathbf{X} \mapsto \mathbf{X}^{-1}$	$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}(d\mathbf{X})\mathbf{X}^{-1}$
$\phi(\mathbf{X}) = \log \det(\mathbf{X}), \mathbf{X} \succ \mathbf{0}$	$d\phi = \text{tr}(\mathbf{X}^{-1} d\mathbf{X})$

A identidade geral de vetorização, o vetor escore, a informação observada e a informação de Fisher formam o aprofundamento teórico. O apêndice reúne extensões de otimização, cálculo matricial, integração e aproximação inferencial.

Ao final deste capítulo, o estudante deverá ser capaz de:

- distinguir gradiente, Jacobiana, Hessiana e gradiente matricial;
- interpretar derivadas como aproximações locais;
- utilizar Taylor e a Hessiana em problemas de otimização;
- formular condições de primeira ordem com e sem restrições;
- derivar critérios quadráticos e equações normais;
- utilizar diferenciais e identidades de traço em funções matriciais;
- diferenciar expressões envolvendo inversas, determinantes e log-determinantes;
- utilizar vec e o produto de Kronecker;
- calcular probabilidades, expectativas e densidades marginais por integração;
- aplicar mudanças de variáveis e interpretar o determinante Jacobiano.

7.14 Apêndice de cálculo para Estatística Multivariada

O apêndice reúne extensões de otimização, mínimos quadrados, cálculo matricial, integração e aproximação inferencial que não integram o núcleo do capítulo.

7.14.1 Caso inconclusivo na classificação pela Hessiana

Considere

$$f(x_1, x_2) = x_1^4 + x_2^4.$$

A origem é um ponto estacionário e

$$\nabla_{\mathbf{x}}^2 f(0,0) = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}.$$

A Hessiana é semidefinida positiva, mas não positiva definida. Ainda assim,

$$f(x_1, x_2) \geq 0$$

para todos os pontos, com igualdade somente na origem. Portanto, a origem é um mínimo estrito.

Considere agora

$$g(x_1, x_2) = x_1^4 - x_2^4.$$

A Hessiana na origem também é nula. Entretanto, a função assume valores positivos e negativos em qualquer vizinhança da origem. O ponto é de sela.

Esses exemplos mostram que, quando o termo quadrático se anula em determinadas direções, é necessário examinar termos de ordem superior ou utilizar outro argumento.

7.14.2 Método de Newton

O método de Newton utiliza a aproximação quadrática local de f . (Gentle, 2017)

Em torno de um ponto $\mathbf{x}^{(t)}$,

$$\begin{aligned} f(\mathbf{x}) &\approx f(\mathbf{x}^{(t)}) + \nabla_{\mathbf{x}} f(\mathbf{x}^{(t)})^\top (\mathbf{x} - \mathbf{x}^{(t)}) \\ &\quad + \frac{1}{2} (\mathbf{x} - \mathbf{x}^{(t)})^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)}) (\mathbf{x} - \mathbf{x}^{(t)}). \end{aligned}$$

Defina

$$\mathbf{g}^{(t)} = \nabla_{\mathbf{x}} f(\mathbf{x}^{(t)})$$

e

$$\mathbf{H}^{(t)} = \nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)}).$$

Escrevendo

$$\mathbf{d} = \mathbf{x} - \mathbf{x}^{(t)},$$

o modelo quadrático local pode ser representado por

$$m_t(\mathbf{d}) = f(\mathbf{x}^{(t)}) + (\mathbf{g}^{(t)})^\top \mathbf{d} + \frac{1}{2} \mathbf{d}^\top \mathbf{H}^{(t)} \mathbf{d}.$$

Seu gradiente em relação a $\mathbf{d}$ é

$$\nabla_{\mathbf{d}} m_t(\mathbf{d}) = \mathbf{g}^{(t)} + \mathbf{H}^{(t)} \mathbf{d}.$$

Se

$$\mathbf{H}^{(t)} \succ \mathbf{0},$$

o modelo quadrático é estritamente convexo e possui um único minimizador. Esse minimizador, denominado **direção de Newton**, satisfaz

$$\mathbf{H}^{(t)} \mathbf{d}^{(t)} = -\mathbf{g}^{(t)}.$$

Quando $\mathbf{H}^{(t)}$ é invertível,

$$\mathbf{d}^{(t)} = -(\mathbf{H}^{(t)})^{-1} \mathbf{g}^{(t)}.$$

A atualização de Newton com passo completo é

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} + \mathbf{d}^{(t)},$$

ou, equivalentemente,

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} - [\nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)})]^{-1} \nabla_{\mathbf{x}} f(\mathbf{x}^{(t)}).$$

Na implementação computacional, é preferível resolver o sistema linear

$$\mathbf{H}^{(t)} \mathbf{d}^{(t)} = -\mathbf{g}^{(t)}$$

sem calcular explicitamente a inversa da Hessiana.

Se a Hessiana é apenas invertível, mas não positiva definida, a solução desse sistema é um ponto estacionário do modelo quadrático, mas pode não ser seu minimizador. Nesse caso, a direção de Newton também pode deixar de ser uma direção de descida para a função original.

Proposição 7.15 (Direção de Newton como direção de descida). *Suponha que*

$$\nabla_{\mathbf{x}} f(\mathbf{x}^{(t)}) \neq \mathbf{0}$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)}) \succ \mathbf{0}.$$

Então a direção de Newton $\mathbf{d}^{(t)}$ é uma direção de descida para f em $\mathbf{x}^{(t)}$, isto é,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^{(t)})^\top \mathbf{d}^{(t)} < 0.$$

i Demonstração

Como

$$\mathbf{d}^{(t)} = -(\mathbf{H}^{(t)})^{-1} \mathbf{g}^{(t)},$$

tem-se

$$(\mathbf{g}^{(t)})^\top \mathbf{d}^{(t)} = -(\mathbf{g}^{(t)})^\top (\mathbf{H}^{(t)})^{-1} \mathbf{g}^{(t)}.$$

Como $\mathbf{H}^{(t)} \succ \mathbf{0}$, também

$$(\mathbf{H}^{(t)})^{-1} \succ \mathbf{0}.$$

Logo, para $\mathbf{g}^{(t)} \neq \mathbf{0}$,

$$(\mathbf{g}^{(t)})^\top (\mathbf{H}^{(t)})^{-1} \mathbf{g}^{(t)} > 0,$$

e, portanto,

$$(\mathbf{g}^{(t)})^\top \mathbf{d}^{(t)} < 0.$$

O passo completo corresponde a

$$\alpha_t = 1.$$

Uma forma mais geral da atualização é

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} + \alpha_t \mathbf{d}^{(t)}, \quad 0 < \alpha_t \leq 1.$$

A escolha de $\alpha_t < 1$ produz um passo de Newton amortecido. Esse recurso pode ser utilizado quando o modelo quadrático local ainda não representa adequadamente a função ao longo de um passo completo.

Assim, a construção da direção e a escolha do comprimento da etapa são operações distintas. Métodos numéricos de otimização costumam combinar a direção de Newton com procedimentos de controle da etapa (Boyd; Vandenberghe, 2004).

Exemplo 7.20 (Newton para uma função quadrática). Considere

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x},$$

com $\mathbf{A} \succ \mathbf{0}$.

O gradiente é

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{A} \mathbf{x} - \mathbf{b},$$

e a Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A}.$$

A atualização de Newton é

$$\begin{aligned} \mathbf{x}^{(t+1)} &= \mathbf{x}^{(t)} - \mathbf{A}^{-1} (\mathbf{A} \mathbf{x}^{(t)} - \mathbf{b}) \\ &= \mathbf{A}^{-1} \mathbf{b}. \end{aligned}$$

Assim, para uma função quadrática com Hessiana constante e positiva definida, uma etapa completa de Newton conduz exatamente ao único minimizador,

$$\mathbf{x}^* = \mathbf{A}^{-1} \mathbf{b},$$

independentemente do ponto inicial.

7.14.3 Restrições lineares

Considere o problema quadrático

$$\min_{\mathbf{x}} \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x}$$

sujeito a

$$\mathbf{C} \mathbf{x} = \mathbf{d},$$

em que

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é simétrica,

$$\mathbf{C} \in \mathbb{R}^{m \times p}$$

e

$$\mathbf{d} \in \mathbb{R}^m.$$

A lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + \lambda^\top (\mathbf{C} \mathbf{x} - \mathbf{d}).$$

As condições de primeira ordem são

$$\mathbf{A} \mathbf{x} - \mathbf{b} + \mathbf{C}^\top \lambda = \mathbf{0}$$

e

$$\mathbf{C} \mathbf{x} = \mathbf{d}.$$

Essas condições podem ser organizadas no sistema em blocos

$$\begin{bmatrix} \mathbf{A} & \mathbf{C}^\top \\ \mathbf{C} & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{x} \\ \lambda \end{bmatrix} = \begin{bmatrix} \mathbf{b} \\ \mathbf{d} \end{bmatrix}.$$

Esse sistema em blocos reúne as condições de primeira ordem do problema restrito.

Se

$$\mathbf{A} \succ \mathbf{0}$$

e $\mathbf{C}$ possui posto linha completo, a função objetivo é estritamente convexa e o conjunto definido por

$$\mathbf{C}\mathbf{x} = \mathbf{d}$$

é afim. Quando esse conjunto é não vazio, as condições de primeira ordem identificam o único minimizador global.

Mais geralmente, para uma matriz $\mathbf{A}$ semidefinida positiva, a unicidade depende de a forma quadrática ser positiva nas direções viáveis não nulas, isto é,

$$\mathbf{z}^\top \mathbf{A} \mathbf{z} > 0$$

para todo

$$\mathbf{z} \neq \mathbf{0}$$

tal que

$$\mathbf{C}\mathbf{z} = \mathbf{0}.$$

Sem condições desse tipo, a resolução do sistema fornece apenas candidatos que satisfazem as condições de primeira ordem.

As ferramentas desta seção serão aplicadas a funções de resíduos, critérios quadráticos e funções de parâmetros matriciais.

7.14.4 Mínimos quadrados ponderados

Considere pesos não negativos

$$\omega_1, \dots, \omega_q \geq 0$$

e a matriz diagonal

$$\Omega = \text{diag}(\omega_1, \dots, \omega_q).$$

A função de mínimos quadrados ponderados é

$$f_\omega(\mathbf{x}) = (\mathbf{b} - \mathbf{Ax})^\top \Omega (\mathbf{b} - \mathbf{Ax}).$$

Como Ω é diagonal e, portanto, simétrica,

$$\nabla_{\mathbf{x}} f_\omega(\mathbf{x}) = -2\mathbf{A}^\top \Omega (\mathbf{b} - \mathbf{Ax})$$

e

$$\nabla_{\mathbf{x}}^2 f_\omega(\mathbf{x}) = 2\mathbf{A}^\top \Omega \mathbf{A}.$$

Se

$$\Omega \succeq \mathbf{0},$$

a função é convexa.

As equações normais ponderadas são

$$\mathbf{A}^\top \Omega \mathbf{Ax} = \mathbf{A}^\top \Omega \mathbf{b}.$$

Equivalentemente,

$$\mathbf{A}^\top \Omega \mathbf{r}(\mathbf{x}) = \mathbf{0}.$$

Portanto, em qualquer minimizador, o resíduo satisfaz a condição de ortogonalidade ponderada

$$\mathbf{A}^\top \Omega \mathbf{r}(\mathbf{x}) = \mathbf{0}.$$

Quando

$$\Omega \succ \mathbf{0},$$

retoma-se o produto interno induzido definido em Definição 3.16:

$$\langle \mathbf{u}, \mathbf{v} \rangle_{\Omega} = \mathbf{u}^{\top} \Omega \mathbf{v}.$$

A condição anterior corresponde, portanto, à ortogonalidade do resíduo ao espaço coluna de $\mathbf{A}$ nessa geometria ponderada.

Se Ω é singular, a mesma condição algébrica permanece válida, mas a forma ponderada é apenas semidefinida positiva e não define um produto interno em todo o espaço.

Se

$$\Omega \succ \mathbf{0}$$

e $\mathbf{A}$ possui posto coluna completo, então

$$\mathbf{A}^{\top} \Omega \mathbf{A} \succ \mathbf{0},$$

e o minimizador é único:

$$\hat{\mathbf{x}} = (\mathbf{A}^{\top} \Omega \mathbf{A})^{-1} \mathbf{A}^{\top} \Omega \mathbf{b}.$$

A matriz Ω modifica a importância relativa dos resíduos. Para uma matriz diagonal, cada observação recebe um peso próprio.

Quando

$$\Omega \succ \mathbf{0},$$

o critério pode ser escrito utilizando a norma induzida de Definição 3.17:

$$f_{\omega}(\mathbf{x}) = \|\mathbf{b} - \mathbf{A}\mathbf{x}\|_{\Omega}^2,$$

com

$$\|\mathbf{z}\|_{\Omega}^2 = \mathbf{z}^{\top} \Omega \mathbf{z}.$$

Assim, os mínimos quadrados ponderados correspondem a uma projeção segundo a geometria induzida por Ω .

7.14.5 Funções compostas de resíduos

Considere uma função diferenciável

$$\rho : \mathbb{R} \longrightarrow \mathbb{R}$$

e resíduos escalares

$$r_i(\mathbf{x}), \quad i = 1, \dots, q.$$

Uma classe ampla de funções de ajuste pode ser escrita como

$$f(\mathbf{x}) = \sum_{i=1}^q \rho(r_i(\mathbf{x})).$$

Pela regra da cadeia,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \sum_{i=1}^q \rho'(r_i(\mathbf{x})) \nabla_{\mathbf{x}} r_i(\mathbf{x}).$$

Se

$$\rho(t) = t^2,$$

então

$$\rho'(t) = 2t,$$

e recupera-se a soma de quadrados.

Essa formulação mostra que diferentes funções de perda modificam a contribuição de cada resíduo no gradiente.

7.14.6 Mínimos quadrados não lineares

Considere uma função residual duas vezes diferenciável

$$\mathbf{r} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

e o critério

$$f(\mathbf{x}) = \|\mathbf{r}(\mathbf{x})\|^2.$$

A Jacobiana dos resíduos é

$$\mathbf{J}_{\mathbf{r}}(\mathbf{x}) \in \mathbb{R}^{q \times p}.$$

Proposição 7.16 (Derivadas de uma soma de quadrados não linear). *Para*

$$f(\mathbf{x}) = \sum_{i=1}^q r_i(\mathbf{x})^2,$$

tem-se

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^{\top} \mathbf{r}(\mathbf{x})$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^{\top} \mathbf{J}_{\mathbf{r}}(\mathbf{x}) + 2 \sum_{i=1}^q r_i(\mathbf{x}) \nabla_{\mathbf{x}}^2 r_i(\mathbf{x}).$$

i Demonstração

Pela regra da cadeia,

$$\begin{aligned}\nabla_{\mathbf{x}} f(\mathbf{x}) &= \sum_{i=1}^q 2r_i(\mathbf{x}) \nabla_{\mathbf{x}} r_i(\mathbf{x}) \\ &= 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^{\top} \mathbf{r}(\mathbf{x}).\end{aligned}$$

Diferenciando novamente cada parcela,

$$\nabla_{\mathbf{x}} [r_i(\mathbf{x}) \nabla_{\mathbf{x}} r_i(\mathbf{x})] = \nabla_{\mathbf{x}} r_i(\mathbf{x}) \nabla_{\mathbf{x}} r_i(\mathbf{x})^{\top} + r_i(\mathbf{x}) \nabla_{\mathbf{x}}^2 r_i(\mathbf{x}).$$

Somando sobre i , obtém-se a expressão da Hessiana.

A Hessiana possui, portanto, duas parcelas com papéis distintos:

$$\underbrace{2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^{\top} \mathbf{J}_{\mathbf{r}}(\mathbf{x})}_{\text{parcela de primeira ordem dos resíduos}} + 2 \underbrace{\sum_{i=1}^q r_i(\mathbf{x}) \nabla_{\mathbf{x}}^2 r_i(\mathbf{x})}_{\text{correção de não linearidade}}.$$

O primeiro termo da Hessiana,

$$2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^{\top} \mathbf{J}_{\mathbf{r}}(\mathbf{x}),$$

é semidefinido positivo. Isso não implica, porém, que a função de mínimos quadrados não linear seja convexa, pois a segunda parcela da Hessiana pode ser indefinida.

O segundo termo depende:

- dos valores dos resíduos;
- das Hessianas das funções residuais;
- da não linearidade do modelo.

Quando os resíduos são pequenos ou quando as Hessianas das funções residuais têm contribuição reduzida na região considerada, a segunda parcela pode ser desprezada aproximadamente. Nesse caso,

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \approx 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^{\top} \mathbf{J}_{\mathbf{r}}(\mathbf{x}).$$

No caso linear,

$$\mathbf{r}(\mathbf{x}) = \mathbf{b} - \mathbf{A}\mathbf{x},$$

tem-se

$$\nabla_{\mathbf{x}}^2 r_i(\mathbf{x}) = \mathbf{0}$$

para todo i . Portanto, a segunda parcela desaparece exatamente e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}^\top \mathbf{A}.$$

Essa aproximação conduz ao método de Gauss–Newton. (Gentle, 2017)

As mesmas ideias serão estendidas a funções cujos argumentos são matrizes. Nesse caso, os diferenciais e as identidades de traço permitem organizar as derivadas sem decompor a matriz em todos os seus elementos.

7.14.7 Ponderação de observações e respostas

Considere uma matriz diagonal de pesos das observações

$$\Omega = \text{diag}(\omega_1, \dots, \omega_n) \succeq \mathbf{0}$$

e uma matriz simétrica positiva definida

$$\Sigma \in \mathbb{R}^{p \times p}.$$

O critério ponderado é

$$Q_{\Omega, \Sigma}(\mathbf{B}) = \text{tr} [\Sigma^{-1} \mathcal{E}(\mathbf{B})^\top \Omega \mathcal{E}(\mathbf{B})].$$

Como

$$\Omega \succeq \mathbf{0}$$

e

$$\Sigma \succ \mathbf{0},$$

o critério também pode ser escrito como

$$Q_{\Omega, \Sigma}(\mathbf{B}) = \left\| \Omega^{1/2} \mathcal{E}(\mathbf{B}) \Sigma^{-1/2} \right\|_F^2.$$

Essa forma mostra que a ponderação atua simultaneamente nas duas dimensões da matriz residual.

A matriz Ω atua no espaço das observações e pondera as linhas da matriz de resíduos. A matriz Σ^{-1} atua no espaço das respostas e define a geometria utilizada para combinar as colunas da matriz de resíduos.

Como Ω e Σ^{-1} são simétricas,

$$\begin{aligned} dQ_{\Omega, \Sigma} &= 2 \operatorname{tr} \left[\Sigma^{-1} \mathcal{E}^\top \Omega d\mathcal{E} \right] \\ &= -2 \operatorname{tr} \left[\Sigma^{-1} \mathcal{E}^\top \Omega \mathbf{X} d\mathbf{B} \right]. \end{aligned}$$

Pela propriedade cíclica,

$$dQ_{\Omega, \Sigma} = -2 \operatorname{tr} \left[(\mathbf{X}^\top \Omega \mathcal{E} \Sigma^{-1})^\top d\mathbf{B} \right].$$

Portanto,

$$\nabla_{\mathbf{B}} Q_{\Omega, \Sigma}(\mathbf{B}) = -2 \mathbf{X}^\top \Omega \mathcal{E}(\mathbf{B}) \Sigma^{-1}.$$

A condição de primeira ordem é

$$\mathbf{X}^\top \Omega (\mathbf{Y} - \mathbf{X}\mathbf{B}) \Sigma^{-1} = \mathbf{0}.$$

Como Σ^{-1} é invertível,

$$\mathbf{X}^\top \Omega (\mathbf{Y} - \mathbf{X}\mathbf{B}) = \mathbf{0}.$$

Logo,

$$\mathbf{X}^\top \Omega \mathbf{X} \mathbf{B} = \mathbf{X}^\top \Omega \mathbf{Y}.$$

Se

$$\mathbf{X}^\top \Omega \mathbf{X}$$

é invertível, ou equivalentemente, se as colunas de

$$\Omega^{1/2} \mathbf{X}$$

são linearmente independentes, então o minimizador é

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \Omega \mathbf{X})^{-1} \mathbf{X}^\top \Omega \mathbf{Y}.$$

Para Σ fixa e positiva definida, a ponderação invertível no espaço das respostas altera o valor do critério e sua geometria, mas não altera o conjunto de minimizadores em relação a $\mathbf{B}$.

Isso ocorre porque

$$\Sigma^{-1}$$

é invertível e pode ser eliminada da condição de primeira ordem.

A ponderação das observações por Ω , por outro lado, permanece nas equações normais e pode modificar o estimador. (Anderson, 2003)

Os diferenciais matriciais e as identidades de traço permitem agora tratar funções em que a própria matriz variável aparece no interior de uma inversa ou de um determinante. Essas estruturas são particularmente importantes quando o parâmetro pertence ao conjunto das matrizes positivas definidas.

7.14.8 Segunda variação do log-determinante

Considere uma matriz positiva definida $\mathbf{X}$ e uma perturbação simétrica $d\mathbf{X}$.

A primeira variação é

$$d\phi = \text{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

Utilizando o diferencial da inversa,

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1} d\mathbf{X} \mathbf{X}^{-1},$$

a segunda variação na mesma direção é

$$d^2\phi = -\text{tr}(\mathbf{X}^{-1} d\mathbf{X} \mathbf{X}^{-1} d\mathbf{X}).$$

Logo,

$$d^2\phi \leq 0.$$

Proposição 7.17 (Concavidade do log-determinante). *A função*

$$\phi(\mathbf{X}) = \log \det(\mathbf{X})$$

é estritamente côncava no conjunto das matrizes simétricas positivas definidas.

(Boyd; Vandenberghe, 2004)

i Demonstração

O conjunto das matrizes simétricas positivas definidas é convexo. Para toda matriz

$$\mathbf{X} \succ \mathbf{0}$$

e toda direção simétrica não nula $\mathbf{H}$,

$$d^2\phi[\mathbf{H}, \mathbf{H}] = -\|\mathbf{X}^{-1/2}\mathbf{H}\mathbf{X}^{-1/2}\|_F^2 < 0.$$

Logo, a restrição de ϕ a qualquer segmento não degenerado do cone positivo definido possui segunda derivada negativa. Portanto,

$$\phi(\mathbf{X}) = \log \det(\mathbf{X})$$

é estritamente côncava nesse domínio.

Consequentemente,

$$-\log \det(\mathbf{X})$$

é estritamente convexa nesse domínio.

7.14.9 Parâmetros matriciais simétricos

As fórmulas anteriores foram escritas utilizando matrizes completas. Entretanto, uma matriz simétrica

$$\Sigma = \Sigma^\top$$

possui apenas

$$\frac{p(p+1)}{2}$$

elementos distintos.

Quando o argumento é restrito ao espaço das matrizes simétricas, as perturbações admissíveis também devem ser simétricas:

$$d\Sigma = d\Sigma^\top.$$

Para uma função escalar $\phi(\Sigma)$, somente a parte simétrica do gradiente contribui para o diferencial:

$$\text{tr} \left[(\nabla_\Sigma \phi)^\top d\Sigma \right] = \text{tr} \left[\left(\frac{\nabla_\Sigma \phi + \nabla_\Sigma \phi^\top}{2} \right)^\top d\Sigma \right].$$

Nos resultados anteriores, os gradientes obtidos para argumentos positivos definidos já são simétricos quando as matrizes constantes envolvidas também são simétricas.

Uma parametrização explícita dos elementos distintos será desenvolvida com os operadores de vetorização e meia vetorização.

7.14.10 Derivadas vetorizadas e parâmetros matriciais

Leitura complementar

As subseções seguintes desenvolvem ferramentas úteis quando parâmetros matriciais precisam ser tratados explicitamente como vetores. Elas permitem representar Hessianas, transposições, parâmetros simétricos e Jacobianas matriciais por meio de vec , produto de Kronecker e matrizes especiais.

Esses resultados são importantes em desenvolvimentos avançados de inferência multivariada e cálculo matricial, mas podem ser omitidos em uma primeira leitura sem comprometer a continuidade dos capítulos seguintes.

7.14.10.1 Gradiente matricial e gradiente vetorizado

Considere

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}.$$

Pela definição do gradiente matricial,

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X} \right].$$

Como

$$\text{tr}(\mathbf{A}^\top \Gamma) = \text{vec}(\mathbf{A})^\top \text{vec}(\Gamma),$$

tem-se

$$d\phi = \text{vec}(\nabla_{\mathbf{X}}\phi)^\top d\text{vec}(\mathbf{X}).$$

Logo,

$$\nabla_{\text{vec}(\mathbf{X})}\phi = \text{vec}(\nabla_{\mathbf{X}}\phi).$$

A forma matricial e a forma vetorizada representam a mesma derivada, organizadas em estruturas diferentes.

7.14.10.2 Hessiana de uma função matricial

Para uma função escalar de matriz, a Hessiana vetorizada é definida por

$$\nabla_{\text{vec}(\mathbf{X})}^2\phi = \frac{\partial \text{vec}(\nabla_{\mathbf{X}}\phi)}{\partial \text{vec}(\mathbf{X})^\top}.$$

Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma),$$

com $\mathbf{A}$ e Γ simétricas.

Foi obtido que

$$\nabla_{\mathbf{X}}\phi = 2\mathbf{A}\mathbf{X}\Gamma.$$

Vetorizando,

$$\begin{aligned} \text{vec}(\nabla_{\mathbf{X}}\phi) &= 2\text{vec}(\mathbf{A}\mathbf{X}\Gamma) \\ &= 2(\Gamma \otimes \mathbf{A})\text{vec}(\mathbf{X}). \end{aligned}$$

Portanto,

$$\nabla_{\text{vec}(\mathbf{X})}^2\phi = 2(\Gamma \otimes \mathbf{A}).$$

Proposição 7.18 (Convexidade da forma quadrática matricial). *Considere*

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma),$$

em que

$$\mathbf{A} = \mathbf{A}^\top \in \mathbb{R}^{m \times m}$$

e

$$\Gamma = \Gamma^\top \in \mathbb{R}^{n \times n}.$$

Se

$$\mathbf{A} \succeq \mathbf{0}$$

e

$$\Gamma \succeq \mathbf{0},$$

então ϕ é convexa em $\mathbf{X}$.

Se

$$\mathbf{A} \succ \mathbf{0}$$

e

$$\Gamma \succ \mathbf{0},$$

então ϕ é estritamente convexa.

i Demonstração

A Hessiana vetorizada é

$$\nabla_{\text{vec}(\mathbf{X})}^2 \phi = 2 (\Gamma \otimes \mathbf{A}).$$

Se

$$\mathbf{A} \succeq \mathbf{0}$$

e

$$\Gamma \succeq \mathbf{0},$$

então

$$\Gamma \otimes \mathbf{A} \succeq \mathbf{0}.$$

Logo, a Hessiana é semidefinida positiva e ϕ é convexa.

Se ambas as matrizes são positivas definidas, então

$$\Gamma \otimes \mathbf{A} \succ \mathbf{0}.$$

Nesse caso, a Hessiana é positiva definida e ϕ é estritamente convexa.

7.14.10.3 Matriz de comutação

A vetorização de uma matriz e de sua transposta possui ordenações diferentes.

Definição 7.15 (Matriz de comutação). A matriz de comutação

$$\mathbf{K}_{m,n} \in \mathbb{R}^{mn \times mn}$$

é a matriz de permutação que satisfaz

$$\mathbf{K}_{m,n} \text{vec}(\mathbf{X}) = \text{vec}(\mathbf{X}^\top)$$

para toda

$$\mathbf{X} \in \mathbb{R}^{m \times n}.$$

(Gentle, 2017)

A transposição pode ser desfeita:

$$\mathbf{K}_{n,m} \mathbf{K}_{m,n} = \mathbf{I}_{mn}.$$

Logo,

$$\mathbf{K}_{m,n}^{-1} = \mathbf{K}_{n,m} = \mathbf{K}_{m,n}^{\top}.$$

Para matrizes quadradas,

$$\mathbf{K}_{p,p} = \mathbf{K}_{p,p}^{\top}$$

e

$$\mathbf{K}_{p,p}^2 = \mathbf{I}_{p^2}.$$

Considere

$$\mathbf{A} \in \mathbb{R}^{m \times n}$$

e

$$\Gamma \in \mathbb{R}^{r \times s}.$$

A matriz de comutação satisfaz

$$\mathbf{K}_{m,r} (\mathbf{A} \otimes \Gamma) = (\Gamma \otimes \mathbf{A}) \mathbf{K}_{n,s}.$$

Equivalentemente,

$$\mathbf{K}_{m,r} (\mathbf{A} \otimes \Gamma) \mathbf{K}_{s,n} = \Gamma \otimes \mathbf{A}.$$

7.14.10.4 Meia vetorização de matrizes simétricas

Uma matriz simétrica possui elementos repetidos acima e abaixo da diagonal. O operador vech conserva somente os elementos da parte triangular inferior.

Definição 7.16 (Operador de meia vetorização). Para uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{p \times p},$$

o vetor

$$\text{vech}(\mathbf{A}) \in \mathbb{R}^{p(p+1)/2}$$

é obtido pelo empilhamento, por colunas, dos elementos da parte triangular inferior de $\mathbf{A}$, incluindo a diagonal.

(Searle; Khuri, 2017)

Quando

$$\mathbf{A} = \mathbf{S} = \mathbf{S}^\top,$$

o operador vech contém exatamente os elementos distintos de $\mathbf{S}$. Por isso, ele fornece uma parametrização sem redundância do espaço das matrizes simétricas.

Exemplo 7.21 (Meia vetorização de uma matriz simétrica). Considere

$$\mathbf{S} = \begin{bmatrix} s_{11} & s_{12} & s_{13} \\ s_{12} & s_{22} & s_{23} \\ s_{13} & s_{23} & s_{33} \end{bmatrix}.$$

Então,

$$\text{vech}(\mathbf{S}) = \begin{bmatrix} s_{11} \\ s_{12} \\ s_{13} \\ s_{22} \\ s_{23} \\ s_{33} \end{bmatrix}.$$

A ordem acompanha as colunas da parte triangular inferior:

- primeira coluna: s_{11}, s_{12}, s_{13} ;
- segunda coluna: s_{22}, s_{23} ;
- terceira coluna: s_{33} .

O operador vech elimina a duplicação dos elementos simétricos. Enquanto

$$\text{vec}(\mathbf{S})$$

possui p^2 elementos,

$$\text{vech}(\mathbf{S})$$

possui

$$\frac{p(p+1)}{2}$$

elementos. A redução ocorre porque uma matriz simétrica possui apenas

$$\frac{p(p+1)}{2}$$

elementos distintos. Assim, vech fornece uma parametrização sem redundância do espaço das matrizes simétricas.

7.14.10.5 Matriz de duplicação

Definição 7.17 (Matriz de duplicação). A matriz de duplicação

$$\mathbf{D}_p^{\text{dup}} \in \mathbb{R}^{p^2 \times p(p+1)/2}$$

é definida pela identidade

$$\text{vec}(\mathbf{S}) = \mathbf{D}_p^{\text{dup}} \text{vech}(\mathbf{S})$$

para toda matriz simétrica

$$\mathbf{S} \in \mathbb{R}^{p \times p}.$$

A matriz de duplicação repete os elementos fora da diagonal nas posições correspondentes de $\text{vec}(\mathbf{S})$.

Para $p = 2$,

$$\mathbf{S} = \begin{bmatrix} s_{11} & s_{12} \\ s_{12} & s_{22} \end{bmatrix},$$

e

$$\text{vech}(\mathbf{S}) = \begin{bmatrix} s_{11} \\ s_{12} \\ s_{22} \end{bmatrix}.$$

Como

$$\text{vec}(\mathbf{S}) = \begin{bmatrix} s_{11} \\ s_{12} \\ s_{12} \\ s_{22} \end{bmatrix},$$

tem-se

$$\mathbf{D}_2^{\text{dup}} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

7.14.10.6 Matriz de eliminação

Definição 7.18 (Matriz de eliminação). A matriz de eliminação

$$\mathbf{L}_p^{\text{elim}} \in \mathbb{R}^{p(p+1)/2 \times p^2}$$

é a matriz de seleção que satisfaz

$$\text{vech}(\mathbf{A}) = \mathbf{L}_p^{\text{elim}} \text{vec}(\mathbf{A})$$

para toda matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

A matriz de eliminação seleciona da vetorização completa os elementos pertencentes à parte triangular inferior.

As duas matrizes satisfazem

$$\mathbf{L}_p^{\text{elim}} \mathbf{D}_p^{\text{dup}} = \mathbf{I}_{p(p+1)/2}.$$

Em geral,

$$\mathbf{D}_p^{\text{dup}} \mathbf{L}_p^{\text{elim}} \neq \mathbf{I}_{p^2}.$$

A matriz $\mathbf{L}_p^{\text{elim}}$ conserva apenas os elementos correspondentes à parte triangular inferior, enquanto $\mathbf{D}_p^{\text{dup}}$ reconstrói uma matriz impondo simetria. Portanto, esse produto não recupera arbitrariamente uma matriz não simétrica.

Para uma matriz simétrica $\mathbf{S}$, entretanto,

$$\mathbf{D}_p^{\text{dup}} \mathbf{L}_p^{\text{elim}} \text{vec}(\mathbf{S}) = \text{vec}(\mathbf{S}).$$

7.14.10.7 Diferenciais de parâmetros simétricos

Proposição 7.19 (Gradiente em relação aos elementos distintos de uma matriz simétrica).
Considere um parâmetro matricial

$$\Sigma = \Sigma^\top \in \mathbb{R}^{p \times p}$$

e uma função escalar

$$\phi(\Sigma).$$

Suponha que seu diferencial possa ser escrito como

$$d\phi = \text{tr} [\mathbf{G}^\top d\Sigma],$$

em que

$$d\Sigma = d\Sigma^\top.$$

Então,

$$\nabla_{\text{vech}(\Sigma)}\phi = (\mathbf{D}_p^{\text{dup}})^\top \text{vec}(\mathbf{G}).$$

Em particular, quando

$$\mathbf{G} = \nabla_\Sigma \phi,$$

tem-se

$$\nabla_{\text{vech}(\Sigma)}\phi = (\mathbf{D}_p^{\text{dup}})^\top \text{vec}(\nabla_\Sigma \phi).$$

i Demonstração

Como

$$\text{vec}(\Sigma) = \mathbf{D}_p^{\text{dup}} \text{vech}(\Sigma),$$

tem-se

$$d \text{vec}(\Sigma) = \mathbf{D}_p^{\text{dup}} d \text{vech}(\Sigma).$$

Além disso,

$$d\phi = \text{vec}(\mathbf{G})^\top d \text{vec}(\Sigma).$$

Substituindo,

$$d\phi = \text{vec}(\mathbf{G})^\top \mathbf{D}_p^{\text{dup}} d \text{vech}(\Sigma).$$

Logo,

$$d\phi = \left[(\mathbf{D}_p^{\text{dup}})^\top \text{vec}(\mathbf{G}) \right]^\top d \text{vech}(\Sigma),$$

de onde segue

$$\nabla_{\text{vech}(\Sigma)}\phi = (\mathbf{D}_p^{\text{dup}})^\top \text{vec}(\mathbf{G}).$$

A parametrização por

$$\text{vech}(\Sigma)$$

remove a redundância existente em

$$\text{vec}(\Sigma),$$

pois uma matriz simétrica possui apenas

$$\frac{p(p+1)}{2}$$

elementos livres.

7.14.10.8 Jacobiana de transformações matriciais

Considere uma transformação

$$\mathcal{G} : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}^{r \times s}.$$

Sua representação vetorizada é

$$\mathbf{g}(\text{vec}(\mathbf{X})) = \text{vec}(\mathcal{G}(\mathbf{X})).$$

A Jacobiana vetorizada é

$$\mathbf{J}_{\mathcal{G}}(\mathbf{X}) = \frac{\partial \text{vec}(\mathcal{G}(\mathbf{X}))}{\partial \text{vec}(\mathbf{X})^{\top}}.$$

(Fujikoshi; Ulyanov; Shimizu, 2010)

Ela satisfaz

$$d \text{vec}(\mathcal{G}(\mathbf{X})) = \mathbf{J}_{\mathcal{G}}(\mathbf{X}) d \text{vec}(\mathbf{X}).$$

Exemplo 7.22 (Jacobiana de $\mathbf{X}^{\top} \mathbf{X}$). Considere

$$\mathcal{G}(\mathbf{X}) = \mathbf{X}^{\top} \mathbf{X},$$

com

$$\mathbf{X} \in \mathbb{R}^{m \times n}.$$

O diferencial é

$$d\mathcal{G} = d\mathbf{X}^\top \mathbf{X} + \mathbf{X}^\top d\mathbf{X}.$$

Vetorizando o primeiro termo,

$$\begin{aligned} \text{vec}(d\mathbf{X}^\top \mathbf{X}) &= (\mathbf{X}^\top \otimes \mathbf{I}_n) \text{vec}(d\mathbf{X}^\top) \\ &= (\mathbf{X}^\top \otimes \mathbf{I}_n) \mathbf{K}_{m,n} \text{vec}(d\mathbf{X}). \end{aligned}$$

Para o segundo termo,

$$\text{vec}(\mathbf{X}^\top d\mathbf{X}) = (\mathbf{I}_n \otimes \mathbf{X}^\top) \text{vec}(d\mathbf{X}).$$

Logo,

$$\begin{aligned} d \text{vec}(\mathbf{X}^\top \mathbf{X}) &= [(\mathbf{X}^\top \otimes \mathbf{I}_n) \mathbf{K}_{m,n} + \mathbf{I}_n \otimes \mathbf{X}^\top] \\ &\quad \times d \text{vec}(\mathbf{X}). \end{aligned}$$

Portanto, a Jacobiana vetorizada é

$$\mathbf{J}_{\mathcal{G}}(\mathbf{X}) = (\mathbf{X}^\top \otimes \mathbf{I}_n) \mathbf{K}_{m,n} + \mathbf{I}_n \otimes \mathbf{X}^\top.$$

Como

$$\mathbf{X}^\top \mathbf{X}$$

é simétrica, a representação por

$$\text{vec}(\mathbf{X}^\top \mathbf{X})$$

contém elementos repetidos. Uma representação sem redundância é obtida por

$$\text{vech}(\mathbf{X}^\top \mathbf{X}).$$

Aplicando a matriz de eliminação,

$$\begin{aligned} d \text{vech}(\mathbf{X}^\top \mathbf{X}) &= \mathbf{L}_n^{\text{elim}} d \text{vec}(\mathbf{X}^\top \mathbf{X}) \\ &= \mathbf{L}_n^{\text{elim}} \mathbf{J}_{\mathcal{G}}(\mathbf{X}) d \text{vec}(\mathbf{X}). \end{aligned}$$

Assim, a Jacobiana relativa somente aos elementos distintos de $\mathbf{X}^\top \mathbf{X}$ é

$$\mathbf{J}_{\text{vech} \circ \mathcal{G}}(\mathbf{X}) = \mathbf{L}_n^{\text{elim}} \mathbf{J}_{\mathcal{G}}(\mathbf{X}).$$

A vetorização e o produto de Kronecker permitem representar derivadas matriciais por matrizes usuais. Essa representação será útil para covariâncias de vetores matriciais, Hessianas e aproximações de funções de parâmetros matriciais.

O bloco de aprofundamento mostrou como vec e o produto de Kronecker podem ser estendidos para representar derivadas de ordem superior e parâmetros matriciais com restrições estruturais.

As relações centrais são

$$\text{vec}(\mathbf{A}\mathbf{X}\mathbf{\Gamma}) = (\mathbf{\Gamma}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X})$$

e o fato de que matrizes simétricas possuem apenas

$$\frac{p(p+1)}{2}$$

elementos distintos.

7.14.11 Teorema de Fubini

Teorema 7.9 (Teorema de Fubini). *Se*

$$f : \mathcal{D}_1 \times \mathcal{D}_2 \longrightarrow \mathbb{R}$$

é mensurável e absolutamente integrável, isto é,

$$\int_{\mathcal{D}_1 \times \mathcal{D}_2} |f(x_1, x_2)| \, dx_1 \, dx_2 < \infty,$$

então, para quase todo $x_1 \in \mathcal{D}_1$,

$$x_2 \longmapsto f(x_1, x_2)$$

é integrável em $\mathcal{D}_2$, e, para quase todo $x_2 \in \mathcal{D}_2$,

$$x_1 \longmapsto f(x_1, x_2)$$

é integrável em $\mathcal{D}_1$.

Além disso,

$$\begin{aligned}\int_{\mathcal{D}_1 \times \mathcal{D}_2} f(x_1, x_2) dx_1 dx_2 &= \int_{\mathcal{D}_1} \left[\int_{\mathcal{D}_2} f(x_1, x_2) dx_2 \right] dx_1 \\ &= \int_{\mathcal{D}_2} \left[\int_{\mathcal{D}_1} f(x_1, x_2) dx_1 \right] dx_2.\end{aligned}$$

(Axler, 2020)

A integrabilidade absoluta é uma condição suficiente para trocar a ordem de integração.

7.14.12 Coordenadas polares

Em duas dimensões, defina

$$x_1 = r \cos \theta$$

e

$$x_2 = r \sin \theta,$$

com

$$r > 0$$

e

$$0 \leq \theta < 2\pi.$$

A transformação é

$$\mathbf{g}(r, \theta) = \begin{bmatrix} r \cos \theta \\ r \sin \theta \end{bmatrix}.$$

Sua Jacobiana é

$$\mathbf{J}_{\mathbf{g}}(r, \theta) = \begin{bmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{bmatrix}.$$

O determinante é

$$\det \mathbf{J}_{\mathbf{g}}(r, \theta) = r.$$

Portanto,

$$dx_1 dx_2 = r dr d\theta.$$

Assim,

$$\iint_{\mathbb{R}^2} h(x_1, x_2) dx_1 dx_2 = \int_0^{2\pi} \int_0^\infty h(r \cos \theta, r \sin \theta) r dr d\theta,$$

quando a função é integrável.

A parametrização polar não é uma transformação globalmente bijetiva em todas as escolhas possíveis de domínio: a origem possui representação angular não única e o ângulo é periódico. Para a aplicação da fórmula de mudança de variáveis, trabalha-se em regiões adequadas de injetividade; as fronteiras envolvidas possuem medida nula e não alteram o valor das integrais usuais. (Apostol, 1969)

7.14.13 Diferenciação sob o sinal de integração

Leitura complementar

A diferenciação sob o sinal de integração é utilizada para justificar formalmente identidades envolvendo funções de verossimilhança, vetor escore e informação de Fisher.

Esse conteúdo é importante para desenvolvimentos inferenciais mais formais, mas pode ser omitido em uma primeira leitura. Para a continuidade imediata dos capítulos probabilísticos, basta reter que a troca entre derivação e integração exige condições de regularidade e não pode ser realizada automaticamente.

Considere um conjunto mensurável

$$\mathcal{D} \subseteq \mathbb{R}^p,$$

uma região aberta

$$\mathcal{V} \subseteq \mathbb{R}^k$$

e uma função

$$h : \mathcal{D} \times \mathcal{V} \longrightarrow \mathbb{R}.$$

A função depende da variável de integração $\mathbf{x}$ e do parâmetro

$$\theta \in \mathcal{V}.$$

Defina

$$F(\theta) = \int_{\mathcal{D}} h(\mathbf{x}, \theta) d\mathbf{x}.$$

A troca entre diferenciação e integração pode ser justificada pelo Teorema da Convergência Dominada.

Teorema 7.10 (Teorema da Convergência Dominada). *Considere uma sequência de funções mensuráveis*

$$g_1, g_2, \dots$$

definidas em $\mathcal{D}$ e suponha que

$$g_m(\mathbf{x}) \longrightarrow g(\mathbf{x})$$

para quase todo $\mathbf{x} \in \mathcal{D}$.

Se existe uma função integrável

$$M : \mathcal{D} \longrightarrow [0, \infty)$$

tal que

$$|g_m(\mathbf{x})| \leq M(\mathbf{x})$$

para todo m e quase todo $\mathbf{x} \in \mathcal{D}$, então g é integrável e

$$\lim_{m \rightarrow \infty} \int_{\mathcal{D}} g_m(\mathbf{x}) d\mathbf{x} = \int_{\mathcal{D}} g(\mathbf{x}) d\mathbf{x}.$$

(Axler, 2020)

O teorema permite trocar um limite e uma integral quando todas as funções da sequência são dominadas por uma mesma função integrável. A diferenciação sob o sinal de integração decorre da aplicação desse resultado aos quocientes de diferenças.

Teorema 7.11 (Diferenciação sob o sinal de integração). *Considere um ponto*

$$\theta_0 \in \mathcal{V}$$

e uma componente

$$j \in \{1, \dots, k\}.$$

Suponha que:

1. *para todo $\theta \in \mathcal{V}$, a função*

$$\mathbf{x} \mapsto h(\mathbf{x}, \theta)$$

seja mensurável e integrável em $\mathcal{D}$;

2. *exista $\delta > 0$ tal que*

$$\theta_0 + t\mathbf{e}_j \in \mathcal{V}$$

para todo t com $|t| < \delta$, em que $\mathbf{e}_j$ é o j -ésimo vetor da base canônica de $\mathbb{R}^k$;

3. *para quase todo $\mathbf{x} \in \mathcal{D}$, a função*

$$t \mapsto h(\mathbf{x}, \theta_0 + t\mathbf{e}_j)$$

seja diferenciável em $(-\delta, \delta)$;

4. exista uma função integrável

$$M_j : \mathcal{D} \longrightarrow [0, \infty)$$

tal que, para quase todo

$$\mathbf{x} \in \mathcal{D},$$

a desigualdade

$$\left| \frac{\partial h(\mathbf{x}, \theta_0 + t\mathbf{e}_j)}{\partial \theta_j} \right| \leq M_j(\mathbf{x})$$

seja válida para todo t com $|t| < \delta$;

5. a função

$$\mathbf{x} \longmapsto \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j}$$

seja mensurável.

Então, F é parcialmente diferenciável em relação a θ_j no ponto θ_0 e

$$\frac{\partial F(\theta_0)}{\partial \theta_j} = \int_{\mathcal{D}} \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j} d\mathbf{x}.$$

(Casella; Berger, 2002)



i Demonstração

Considere uma sequência arbitrária de números não nulos

$$t_1, t_2, \dots$$

tal que

$$t_m \longrightarrow 0$$

e

$$|t_m| < \delta.$$

Defina o quociente de diferenças

$$q_m(\mathbf{x}) = \frac{h(\mathbf{x}, \theta_0 + t_m \mathbf{e}_j) - h(\mathbf{x}, \theta_0)}{t_m}.$$

Para quase todo $\mathbf{x} \in \mathcal{D}$, a diferenciabilidade em relação a θ_j implica

$$q_m(\mathbf{x}) \longrightarrow \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j}.$$

Pelo Teorema do Valor Médio aplicado à função

$$t \mapsto h(\mathbf{x}, \theta_0 + t \mathbf{e}_j),$$

existe um número $\xi_m(\mathbf{x})$ situado entre 0 e t_m tal que

$$q_m(\mathbf{x}) = \frac{\partial h(\mathbf{x}, \theta_0 + \xi_m(\mathbf{x}) \mathbf{e}_j)}{\partial \theta_j}.$$

Como

$$|\xi_m(\mathbf{x})| < \delta,$$

a hipótese de dominação fornece

$$|q_m(\mathbf{x})| \leq M_j(\mathbf{x})$$

para quase todo $\mathbf{x} \in \mathcal{D}$.

O Teorema da Convergência Dominada implica

Quando as condições do Teorema 7.11 são satisfeitas para todas as componentes do parâmetro,

$$\nabla_{\theta} F(\theta_0) = \int_{\mathcal{D}} \nabla_{\theta} h(\mathbf{x}, \theta_0) d\mathbf{x}.$$

A função dominante pode ser diferente para cada componente do gradiente, desde que cada uma seja integrável.

O resultado pressupõe que o domínio $\mathcal{D}$ não depende de θ . Quando o domínio ou a fronteira da região de integração varia com o parâmetro, a derivação pode produzir termos adicionais. Esse caso não será desenvolvido neste capítulo.

Exemplo 7.23 (Derivação de uma identidade de normalização). Considere uma família de densidades

$$f(\mathbf{x}; \theta),$$

definida sobre um suporte comum

$$\mathcal{D}$$

que não depende de θ .

Para todo θ ,

$$\int_{\mathcal{D}} f(\mathbf{x}; \theta) d\mathbf{x} = 1.$$

Suponha que as condições do Teorema 7.11 sejam satisfeitas para todas as componentes de θ . Então,

$$\begin{aligned} \mathbf{0} &= \nabla_{\theta} 1 \\ &= \nabla_{\theta} \int_{\mathcal{D}} f(\mathbf{x}; \theta) d\mathbf{x} \\ &= \int_{\mathcal{D}} \nabla_{\theta} f(\mathbf{x}; \theta) d\mathbf{x}. \end{aligned}$$

Se

$$f(\mathbf{x}; \theta) > 0$$

para quase todo $\mathbf{x} \in \mathcal{D}$, então

$$\nabla_{\theta} f(\mathbf{x}; \theta) = f(\mathbf{x}; \theta) \nabla_{\theta} \log f(\mathbf{x}; \theta).$$

Portanto,

$$\int_{\mathcal{D}} f(\mathbf{x}; \theta) \nabla_{\theta} \log f(\mathbf{x}; \theta) d\mathbf{x} = \mathbf{0}.$$

Se

$$\mathbf{X}$$

possui densidade $f(\mathbf{x}; \theta)$, segue que

$$E_{\theta} [\nabla_{\theta} \log f(\mathbf{X}; \theta)] = \mathbf{0}.$$

Essa é a identidade de média nula do escore para uma observação. Sua validade depende do suporte comum e das condições de dominação que justificam a troca entre diferenciação e integração.

7.14.14 Newton–Raphson

A estimação por máxima verossimilhança pode exigir a solução numérica de

$$\mathbf{s}_n(\theta) = \mathbf{0}.$$

A expansão de primeira ordem do escore em torno de um valor atual $\theta^{(t)}$ é

$$\mathbf{s}_n(\theta) \approx \mathbf{s}_n(\theta^{(t)}) + \nabla_{\theta}^2 \ell_n(\theta^{(t)}) (\theta - \theta^{(t)}).$$

Igualando a aproximação a zero,

$$\begin{aligned} \theta^{(t+1)} &= \theta^{(t)} - [\nabla_{\theta}^2 \ell_n(\theta^{(t)})]^{-1} \mathbf{s}_n(\theta^{(t)}) \\ &= \theta^{(t)} + \mathcal{J}_n(\theta^{(t)})^{-1} \mathbf{s}_n(\theta^{(t)}). \end{aligned}$$

Na implementação, a atualização deve ser obtida pela solução do sistema

$$\mathcal{J}_n \left(\theta^{(t)} \right) \mathbf{d}^{(t)} = \mathbf{s}_n \left(\theta^{(t)} \right),$$

seguida de

$$\theta^{(t+1)} = \theta^{(t)} + \mathbf{d}^{(t)}.$$

Isso evita calcular explicitamente a inversa da informação observada.

Essa é a aplicação do método de Newton à equação

$$\mathbf{s}_n(\theta) = \mathbf{0}.$$

(Anderson, 2003)

Quando

$$\mathcal{J}_n \left(\theta^{(t)} \right) \succ \mathbf{0},$$

a direção

$$\mathbf{d}^{(t)} = \mathcal{J}_n \left(\theta^{(t)} \right)^{-1} \mathbf{s}_n \left(\theta^{(t)} \right)$$

é uma direção local de aumento da log-verossimilhança, pois

$$\mathbf{s}_n \left(\theta^{(t)} \right)^\top \mathbf{d}^{(t)} > 0$$

quando o escore é não nulo.

Ainda assim, um passo completo pode não aumentar a log-verossimilhança quando o ponto atual está distante da solução. Em aplicações numéricas, podem ser utilizados controles do comprimento da etapa.

7.14.15 Método do escore de Fisher

O método do escore de Fisher substitui a informação observada

$$\mathcal{J}_n(\theta)$$

pela informação de Fisher

$$\mathcal{J}_n(\theta).$$

Sob as condições de regularidade para as quais

$$\mathcal{J}_n(\theta) = E_{\theta} [\mathcal{J}_n(\theta)],$$

essa substituição pode ser interpretada como a troca da curvatura observada pela curvatura esperada da log-verossimilhança.

Quando

$$\mathcal{J}_n(\theta^{(t)})$$

é invertível, a direção $\mathbf{d}^{(t)}$ é obtida pela solução de

$$\mathcal{J}_n(\theta^{(t)}) \mathbf{d}^{(t)} = \mathbf{s}_n(\theta^{(t)}),$$

seguida da atualização

$$\theta^{(t+1)} = \theta^{(t)} + \mathbf{d}^{(t)}.$$

Assim, Newton–Raphson utiliza

$$\mathcal{J}_n(\theta),$$

enquanto o método do escore de Fisher utiliza

$$\mathcal{J}_n(\theta).$$

Quando a identidade de informação é válida, a primeira representa a curvatura observada e a segunda sua correspondente curvatura esperada. (Anderson, 2003)

As atualizações coincidem quando as duas matrizes são iguais no ponto considerado ou, mais geralmente, quando produzem a mesma solução para a equação que determina a direção da etapa.

7.14.16 Expansão local de uma raiz do escore

Suponha que um estimador

$$\hat{\theta}$$

satisfaça a equação

$$\mathbf{s}_n(\hat{\theta}) = \mathbf{0}.$$

Expandindo o escore em torno do parâmetro verdadeiro θ_0 ,

$$\begin{aligned} \mathbf{0} &= \mathbf{s}_n(\hat{\theta}) \\ &\approx \mathbf{s}_n(\theta_0) + \nabla_{\theta}^2 \ell_n(\theta_0) (\hat{\theta} - \theta_0). \end{aligned}$$

Como

$$\nabla_{\theta}^2 \ell_n(\theta_0) = -\mathcal{J}_n(\theta_0),$$

obtém-se a aproximação

$$\hat{\theta} - \theta_0 \approx \mathcal{J}_n(\theta_0)^{-1} \mathbf{s}_n(\theta_0).$$

Essa expressão é uma aproximação local de primeira ordem. A obtenção de uma representação assintótica rigorosa exige controlar o termo restante da expansão e substituir a informação observada por um limite apropriado.

Essa relação mostra que o erro do estimador pode ser aproximado pelo produto entre:

- a inversa da curvatura da log-verossimilhança;
- o escore calculado no parâmetro verdadeiro.

A obtenção de uma distribuição assintótica exige resultados probabilísticos adicionais sobre consistência, convergência da informação e distribuição limite do escore.

7.14.17 Método delta

O método delta utiliza a aproximação de Taylor para obter a distribuição aproximada de uma transformação de um estimador.

Teorema 7.12 (Método delta multivariado). *Suponha que*

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N_k(\mathbf{0}, \Xi),$$

em que

$$\Xi \in \mathbb{R}^{k \times k}.$$

Considere uma função

$$\mathbf{g} : \mathbb{R}^k \longrightarrow \mathbb{R}^q$$

diferenciável no ponto

$$\theta.$$

Então,

$$\sqrt{n}[\mathbf{g}(\hat{\theta}) - \mathbf{g}(\theta)] \xrightarrow{d} N_q(\mathbf{0}, \mathbf{J}_{\mathbf{g}}(\theta)\Xi\mathbf{J}_{\mathbf{g}}(\theta)^\top).$$

(Vaart, 1998)

A demonstração formal utiliza a aproximação de Taylor de primeira ordem juntamente com resultados probabilísticos sobre convergência em distribuição. (Fujikoshi; Ulyanov; Shimizu, 2010) Esses resultados serão desenvolvidos no módulo inferencial; neste capítulo interessa principalmente a origem diferencial da matriz

$$\mathbf{J}_{\mathbf{g}}(\theta)\Xi\mathbf{J}_{\mathbf{g}}(\theta)^\top.$$

A aproximação de primeira ordem é

$$\mathbf{g}(\hat{\theta}) - \mathbf{g}(\theta) \approx \mathbf{J}_{\mathbf{g}}(\theta)(\hat{\theta} - \theta).$$

A matriz

$$\mathbf{V}_{\mathbf{g}} = \mathbf{J}_{\mathbf{g}}(\theta) \Xi \mathbf{J}_{\mathbf{g}}(\theta)^{\top}$$

é a matriz de covariâncias da distribuição limite de

$$\sqrt{n} \left[\mathbf{g}(\hat{\theta}) - \mathbf{g}(\theta) \right].$$

Por isso, denomina-se

$$\frac{1}{n} \mathbf{V}_{\mathbf{g}}$$

matriz de covariâncias assintótica de

$$\mathbf{g}(\hat{\theta}).$$

Em aplicações, é comum utilizá-la como aproximação da matriz de covariâncias do estimador para amostras grandes. A convergência em distribuição, isoladamente, não garante convergência dos segundos momentos; essa interpretação requer condições adicionais de regularidade.

Para uma função escalar

$$g : \mathbb{R}^k \longrightarrow \mathbb{R},$$

a variância assintótica é

$$\frac{1}{n} \nabla_{\theta} g(\theta)^{\top} \Xi \nabla_{\theta} g(\theta).$$

Exemplo 7.24 (Método delta para uma razão). Considere

$$\theta = \begin{bmatrix} \theta_1 \\ \theta_2 \end{bmatrix}, \quad \theta_2 \neq 0,$$

e

$$g(\theta) = \frac{\theta_1}{\theta_2}.$$

O gradiente é

$$\nabla_{\theta} g = \begin{bmatrix} \frac{1}{\theta_2} \\ \frac{\theta_2}{\theta_1} \\ -\frac{1}{\theta_2^2} \end{bmatrix}.$$

Se

$$\sqrt{n} \left(\hat{\theta} - \theta \right) \xrightarrow{d} N_2 \left(\mathbf{0}, \Xi \right),$$

então

$$\sqrt{n} \left(\frac{\hat{\theta}_1}{\hat{\theta}_2} - \frac{\theta_1}{\theta_2} \right)$$

converge em distribuição para uma normal com variância assintótica

$$\nabla_{\theta} g(\theta)^{\top} \Xi \nabla_{\theta} g(\theta).$$

Exemplo 7.25 (Estimação de um vetor de médias). Considere observações

$$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^p$$

e uma matriz positiva definida conhecida

$$\Sigma.$$

Considere o critério

$$Q(\mu) = \sum_{i=1}^n (\mathbf{x}_i - \mu)^{\top} \Sigma^{-1} (\mathbf{x}_i - \mu).$$

O gradiente é

$$\nabla_{\mu} Q = -2\Sigma^{-1} \sum_{i=1}^n (\mathbf{x}_i - \mu).$$

A condição de primeira ordem é

$$\sum_{i=1}^n (\mathbf{x}_i - \mu) = \mathbf{0}.$$

Logo,

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i.$$

A Hessiana é

$$\nabla_{\mu}^2 Q = 2n\Sigma^{-1} \succ \mathbf{0}.$$

Portanto, o vetor de médias amostrais é o único minimizador do critério. (Anderson, 2003)

Exemplo 7.26 (Critério do modelo linear multivariado). Considere

$$\mathbf{Y} = \mathbf{XB} + \mathcal{E},$$

com

$$\mathbf{Y} \in \mathbb{R}^{n \times p}, \quad \mathbf{X} \in \mathbb{R}^{n \times k}, \quad \mathbf{B} \in \mathbb{R}^{k \times p}.$$

Para

$$\Sigma \succ \mathbf{0},$$

considere o critério

$$\begin{aligned} Q(\mathbf{B}, \Sigma) &= \frac{n}{2} \log \det(\Sigma) \\ &\quad + \frac{1}{2} \operatorname{tr} \left[\Sigma^{-1} (\mathbf{Y} - \mathbf{XB})^{\top} (\mathbf{Y} - \mathbf{XB}) \right]. \end{aligned}$$

Para Σ fixada,

$$\nabla_{\mathbf{B}} Q = -\mathbf{X}^{\top} (\mathbf{Y} - \mathbf{XB}) \Sigma^{-1}.$$

A condição de primeira ordem é

$$\mathbf{X}^\top (\mathbf{Y} - \mathbf{XB}) = \mathbf{0}.$$

Se $\mathbf{X}$ possui posto coluna completo,

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

Observe que, para Σ fixa e positiva definida, o minimizador em relação a $\mathbf{B}$ não depende de Σ . Isso decorre do fato de que Σ^{-1} é invertível e desaparece da condição de primeira ordem.

Defina a matriz de Gram dos resíduos

$$\mathbf{G}_\mathcal{E} = (\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}})^\top (\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}}).$$

Para $\mathbf{B} = \widehat{\mathbf{B}}$, o critério em relação a Σ é

$$Q(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{G}_\mathcal{E}).$$

Se

$$\mathbf{G}_\mathcal{E} \succ \mathbf{0},$$

o minimizador interior é

$$\widehat{\Sigma} = \frac{1}{n} \mathbf{G}_\mathcal{E}.$$

A condição

$$\mathbf{G}_\mathcal{E} \succ \mathbf{0}$$

exige que a matriz residual possua posto coluna completo.

Se $\mathbf{X}$ possui posto coluna completo k , a matriz residual pode ser escrita como

$$\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}} = (\mathbf{I}_n - \mathbf{P}_\mathbf{X}) \mathbf{Y},$$

em que

$$\text{posto}(\mathbf{I}_n - \mathbf{P}_\mathbf{X}) = n - k.$$

Consequentemente,

$$\text{posto}(\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}}) \leq \min(p, n - k).$$

Assim, uma condição necessária para

$$\mathbf{G}_{\mathcal{E}} \succ \mathbf{0}$$

é

$$n - k \geq p.$$

Quando $\mathbf{G}_{\mathcal{E}}$ é singular, o critério é ilimitado inferiormente no cone das matrizes positivas definidas. Em particular, pode-se fazer um autovalor de Σ tender a zero em uma direção pertencente ao núcleo de $\mathbf{G}_{\mathcal{E}}$ sem produzir aumento compensatório no termo de traço.

Aqui o modelo foi utilizado apenas como uma aplicação conjunta de gradientes matriciais, log-determinante e diferenciação de funções envolvendo matrizes inversas.

A interpretação probabilística do critério, as propriedades dos estimadores, suas distribuições e a formulação de hipóteses serão desenvolvidas posteriormente nos capítulos de estimação, modelo linear multivariado e inferência.

O bloco de aprofundamento mostrou como as ferramentas de cálculo deste capítulo aparecem em problemas de estimação e inferência:

Tabela 7.4: Relações entre as ferramentas de cálculo e suas aplicações estatísticas.

Ferramenta matemática	Aplicação estatística
Gradiente	Vetor escore
Hessiana	Informação observada
Esperança da curvatura	Informação de Fisher
Expansão de Taylor	Aproximações locais e método delta
Cálculo matricial	Estimação de parâmetros vetoriais e matriciais

Essas relações devem ser entendidas neste capítulo como aplicações das ferramentas matemáticas. Sua interpretação estatística completa será retomada no Módulo II.

O Capítulo 7 encerra o **Módulo I — Fundamentos Matemáticos e Geométricos da Análise Multivariada**.

Antes do início do Módulo II, os **Exercícios de fixação do Módulo I** retomam de forma integrada os principais conceitos desenvolvidos ao longo dos sete capítulos. Os exercícios articulam representação matricial dos dados, projeções, transformações lineares, formas quadráticas, autovalores e autovetores, SVD, pseudoinversa e cálculo vetorial e matricial em problemas que serão utilizados posteriormente na Estatística Multivariada.

O capítulo seguinte inicia o **Módulo II — Fundamentos Probabilísticos e Inferenciais da Análise Multivariada** com o estudo das matrizes de covariâncias e correlações. Gradientes, formas quadráticas, transformações lineares, integrais, projeções e produtos matriciais fornecerão as ferramentas matemáticas para descrever a variabilidade conjunta de vetores aleatórios e sustentar os desenvolvimentos probabilísticos e inferenciais posteriores.

Exercícios de fixação do Módulo I

Os exercícios deste módulo retomam os fundamentos matemáticos desenvolvidos nos capítulos anteriores e os utilizam em problemas que reaparecerão ao longo da Estatística Multivariada.

A lista está dividida em duas partes. Na primeira, os problemas devem ser resolvidos sem auxílio computacional e enfatizam conceitos, propriedades e operações com vetores e matrizes, bem como suas interpretações algébricas e geométricas. As matrizes foram escolhidas para permitir resultados exatos e favorecer a compreensão das relações entre Álgebra Linear, Geometria e Cálculo.

Na segunda parte, o R ou Python será utilizado para estender essas mesmas ideias a matrizes de maior dimensão e a conjuntos de dados. O objetivo não é substituir os cálculos matriciais por funções prontas, mas utilizar a computação para aplicar e verificar propriedades estudadas no Módulo I.

Diretrizes gerais. A consulta aos capítulos faz parte da atividade. Os resultados já estabelecidos no Módulo I (definições, teoremas, proposições, propriedades, identidades e decomposições) podem e devem ser utilizados diretamente, sem necessidade de nova demonstração, salvo quando isso for solicitado explicitamente.

Ao utilizar um resultado, identifique o resultado empregado e verifique se suas condições são satisfeitas no problema considerado. Não basta reproduzir uma fórmula. Quando uma conclusão depender de propriedades como simetria, ortogonalidade, independência linear, posto, invertibilidade, definição positiva ou outras condições específicas, essas condições devem ser verificadas ou justificadas.

As questões foram elaboradas para exigir a escolha e a articulação dos resultados adequados. Por isso, algumas fórmulas não são fornecidas no enunciado e devem ser localizadas nos capítulos.

Parte I — Exercícios sem uso de computador

Exercício 7.1 (Transformação de variáveis em uma matriz de dados). Considere a matriz de dados

$$\mathbf{X} = \begin{bmatrix} 2 & 1 & 0 \\ 1 & 3 & 1 \\ 0 & 2 & 2 \\ 3 & 0 & 1 \end{bmatrix},$$

em que as linhas representam quatro observações e as colunas representam três variáveis.

Considere também a transformação

$$\mathbf{A} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & -1 \end{bmatrix}.$$

1. Escreva, para uma observação genérica

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix},$$

as duas componentes de

$$\mathbf{y} = \mathbf{Ax}.$$

2. Interprete cada nova componente como uma combinação linear das variáveis originais.
3. Determine a matriz de dados transformada utilizando

$$\mathbf{Y} = \mathbf{XA}^\top.$$

4. Indique as dimensões de $\mathbf{X}$, $\mathbf{A}$ e $\mathbf{Y}$ e explique por que a transformação reduziu o número de variáveis de três para duas.
5. Determine o posto de $\mathbf{A}$.
6. Determine a dimensão de $\mathcal{N}(\mathbf{A})$ e explique o significado desse resultado em termos de perda de informação.
7. Sabendo apenas $\mathbf{y} = \mathbf{Ax}$, discuta se é possível recuperar unicamente o vetor original $\mathbf{x}$.

Exercício 7.2 (Centralização como projeção). Considere $n = 4$ e defina

$$\mathbf{H}_4 = \mathbf{I}_4 - \frac{1}{4}\mathbf{1}_4\mathbf{1}_4^\top.$$

1. Escreva explicitamente a matriz $\mathbf{H}_4$.

2. Verifique que

$$\mathbf{H}_4^\top = \mathbf{H}_4$$

e

$$\mathbf{H}_4^2 = \mathbf{H}_4.$$

3. Mostre que

$$\mathbf{H}_4 \mathbf{1}_4 = \mathbf{0}.$$

4. Aplique $\mathbf{H}_4$ à matriz $\mathbf{X}$ do Exercício 7.1:

$$\mathbf{X}_c = \mathbf{H}_4 \mathbf{X}.$$

5. Verifique diretamente que

$$\mathbf{1}_4^\top \mathbf{X}_c = \mathbf{0}^\top.$$

6. Interprete a igualdade anterior em termos das médias das variáveis.

Exercício 7.3 (Centralização e reescalonamento das variáveis). Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times 3}$$

e a matriz diagonal

$$\mathbf{D} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 4 \end{bmatrix}.$$

1. Determine $\mathbf{D}^{-1}$.

2. Considere inicialmente uma matriz já centralizada $\mathbf{X}_c$ e defina

$$\mathbf{Z} = \mathbf{X}_c \mathbf{D}^{-1}.$$

Explique o efeito dessa transformação sobre cada uma das três variáveis.

3. Explique por que $\mathbf{D}^{-1}$ atua à direita da matriz de dados.
4. Compare essa operação com a centralização

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X},$$

explicando por que $\mathbf{H}_n$ atua à esquerda enquanto $\mathbf{D}^{-1}$ atua à direita.

5. Escreva, em uma única expressão, a transformação que primeiro centraliza $\mathbf{X}$ e depois reescala suas variáveis.
6. A centralização e o reescalonamento atuam no mesmo espaço? Justifique utilizando as dimensões de $\mathbf{H}_n$ e $\mathbf{D}^{-1}$.

Exercício 7.4 (Duas matrizes de Gram para os mesmos dados). Considere a matriz centralizada

$$\mathbf{X}_c = \begin{bmatrix} 1 & 0 \\ -1 & 0 \\ 0 & 2 \\ 0 & -2 \end{bmatrix}.$$

1. Calcule

$$\mathbf{G}_V = \mathbf{X}_c^\top \mathbf{X}_c$$

e

$$\mathbf{G}_O = \mathbf{X}_c \mathbf{X}_c^\top.$$

2. Indique as dimensões das duas matrizes.
3. Qual das duas matrizes contém os produtos internos entre as colunas de $\mathbf{X}_c$?
4. Qual contém os produtos internos entre as linhas de $\mathbf{X}_c$?
5. Determine o posto das duas matrizes.
6. Determine os autovalores positivos de cada matriz.
7. Verifique que os autovalores positivos coincidem.
8. Relacione esse resultado à construção da SVD de uma matriz retangular.

Exercício 7.5 (Projeção, ajuste e resíduos). Considere

$$\mathbf{X} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}.$$

1. Verifique que as colunas de $\mathbf{X}$ são linearmente independentes.
2. Determine

$$\mathbf{P}_X = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top.$$

3. Verifique que

$$\mathbf{P}_X^\top = \mathbf{P}_X$$

e

$$\mathbf{P}_X^2 = \mathbf{P}_X.$$

4. Calcule

$$\hat{\mathbf{y}} = \mathbf{P}_X \mathbf{y}.$$

5. Determine o vetor de resíduos

$$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}.$$

6. Verifique que

$$\mathbf{X}^\top \mathbf{e} = \mathbf{0}.$$

7. Identifique o subespaço ao qual pertence $\hat{\mathbf{y}}$.
8. Identifique o subespaço ao qual pertence $\mathbf{e}$.
9. Interprete geometricamente a decomposição

$$\mathbf{y} = \hat{\mathbf{y}} + \mathbf{e}.$$

Exercício 7.6 (Um problema de mínimos quadrados por três perspectivas). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 0 \\ 0 & 2 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix}.$$

O objetivo é determinar o vetor que minimiza

$$\|\mathbf{b} - \mathbf{A}\mathbf{x}\|^2.$$

Resolva o problema das três formas seguintes.

1. Determine a projeção de $\mathbf{b}$ sobre $\mathcal{C}(\mathbf{A})$ e obtenha, a partir dela, o vetor ajustado.
2. Resolva as equações normais

$$\mathbf{A}^\top \mathbf{A} \mathbf{x} = \mathbf{A}^\top \mathbf{b}.$$

3. Calcule

$$\mathbf{A}^\top \mathbf{A}$$

e determine os valores singulares de $\mathbf{A}$.

4. Construa uma SVD compacta de $\mathbf{A}$.
5. Construa a pseudoinversa

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top$$

e obtenha

$$\mathbf{x}^* = \mathbf{A}^+ \mathbf{b}.$$

6. Compare as soluções obtidas pelas três abordagens.
7. Compare também os vetores ajustados e os resíduos.
8. Explique por que projeções, equações normais e pseudoinversa conduzem ao mesmo problema de aproximação.

Exercício 7.7 (Forma quadrática e direções privilegiadas). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$$

e

$$q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

1. Calcule $q(\mathbf{x})$ para

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{x}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}.$$

2. Determine os autovalores de $\mathbf{A}$.
3. Determine uma base ortonormal de autovetores.
4. Calcule a forma quadrática em cada autovetor unitário.
5. Determine

$$\max_{\|\mathbf{x}\|=1} q(\mathbf{x})$$

e

$$\min_{\|\mathbf{x}\|=1} q(\mathbf{x}).$$

6. Relacione os valores encontrados aos autovalores de $\mathbf{A}$.

Exercício 7.8 (Norma euclidiana e norma induzida). Considere

$$\mathbf{M} = \begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 0 \\ 2 \end{bmatrix}, \quad \mathbf{z} = \begin{bmatrix} 1 \\ 0 \end{bmatrix},$$

responda:

1. Calcule as normas euclidianas de $\mathbf{x}$, $\mathbf{y}$ e $\mathbf{z}$.
2. Calcule as normas induzidas por $\mathbf{M}$,

$$\|\mathbf{v}\|_{\mathbf{M}} = \sqrt{\mathbf{v}^{\top} \mathbf{M} \mathbf{v}}.$$

3. Calcule a distância euclidiana entre $\mathbf{x}$ e $\mathbf{y}$.
4. Calcule a distância induzida por $\mathbf{M}$ entre os mesmos vetores.
5. Qual coordenada recebe maior peso na geometria induzida por $\mathbf{M}$?
6. Explique por que duas geometrias diferentes podem produzir avaliações diferentes da proximidade entre observações.

Exercício 7.9 (Matrizes particionadas e complemento de Schur). Considere a matriz simétrica

$$\mathbf{M} = \begin{bmatrix} 4 & 2 & 1 \\ 2 & 3 & 1 \\ 1 & 1 & 2 \end{bmatrix}$$

particionada como

$$\mathbf{M} = \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{B}^{\top} & \mathbf{D} \end{bmatrix},$$

em que

$$\mathbf{A} = \begin{bmatrix} 4 & 2 \\ 2 & 3 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{D} = [2].$$

1. Verifique que $\mathbf{A}$ é invertível.
2. Determine $\mathbf{A}^{-1}$.
3. Calcule o complemento de Schur de $\mathbf{A}$ em $\mathbf{M}$,

$$\mathbf{S} = \mathbf{D} - \mathbf{B}^{\top} \mathbf{A}^{-1} \mathbf{B}.$$

4. Verifique que $\mathbf{S} > 0$.
5. Utilize a identidade por blocos

$$\det(\mathbf{M}) = \det(\mathbf{A}) \det(\mathbf{S})$$

para calcular $\det(\mathbf{M})$.

6. Confirme o resultado calculando diretamente o determinante de $\mathbf{M}$.

Exercício 7.10 (Direção que maximiza uma medida de dispersão). Considere

$$\mathbf{S} = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}.$$

Para um vetor unitário $\mathbf{a}$, defina

$$D(\mathbf{a}) = \mathbf{a}^\top \mathbf{S} \mathbf{a}.$$

1. Determine os autovalores de $\mathbf{S}$.
2. Determine uma base ortonormal de autovetores.
3. Resolva

$$\max_{\|\mathbf{a}\|=1} \mathbf{a}^\top \mathbf{S} \mathbf{a}.$$

4. Determine a direção que minimiza $D(\mathbf{a})$ sob a mesma restrição.
5. Calcule o valor da forma quadrática nas duas direções.
6. Se $\mathbf{S}$ representasse uma matriz de dispersão de duas variáveis, interprete a direção associada ao maior autovalor.
7. Interprete também a direção associada ao menor autovalor.

Exercício 7.11 (Maximização de uma razão entre duas formas quadráticas). Considere

$$\mathbf{A} = \begin{bmatrix} 12 & 2 \\ 2 & 3 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix}.$$

Resolva

$$\max_{\mathbf{x} \neq \mathbf{0}} \frac{\mathbf{x}^\top \mathbf{A} \mathbf{x}}{\mathbf{x}^\top \mathbf{B} \mathbf{x}}.$$

1. Mostre, por multiplicadores de Lagrange ou pelo quociente de Rayleigh generalizado, que as direções candidatas satisfazem

$$\mathbf{A} \mathbf{x} = \lambda \mathbf{B} \mathbf{x}.$$

2. Determine os autovalores generalizados.
3. Determine um autovetor associado a cada autovalor generalizado.
4. Normalize os autovetores segundo a geometria de $\mathbf{B}$, impondo

$$\mathbf{x}^\top \mathbf{B} \mathbf{x} = 1.$$

5. Determine o valor máximo do quociente.
6. Determine também o valor mínimo.
7. Verifique que os dois autovetores podem ser escolhidos de modo que

$$\mathbf{x}_1^\top \mathbf{B} \mathbf{x}_2 = 0.$$

8. Compare essa ortogonalidade com a ortogonalidade euclidiana usual.

Exercício 7.12 (Transformação de um problema generalizado). Utilize as matrizes $\mathbf{A}$ e $\mathbf{B}$ do Exercício 7.11.

1. Determine a raiz quadrada principal

$$\mathbf{B}^{1/2}$$

e sua inversa

$$\mathbf{B}^{-1/2}.$$

2. Construa

$$\mathbf{C} = \mathbf{B}^{-1/2} \mathbf{A} \mathbf{B}^{-1/2}.$$

3. Determine os autovalores de $\mathbf{C}$.

4. Compare-os com os autovalores generalizados obtidos no exercício anterior.

5. Considere a transformação

$$\mathbf{z} = \mathbf{B}^{1/2} \mathbf{x}.$$

Mostre que

$$\mathbf{x}^\top \mathbf{B} \mathbf{x} = \mathbf{z}^\top \mathbf{z}.$$

6. Mostre que

$$\frac{\mathbf{x}^\top \mathbf{A} \mathbf{x}}{\mathbf{x}^\top \mathbf{B} \mathbf{x}} = \frac{\mathbf{z}^\top \mathbf{C} \mathbf{z}}{\mathbf{z}^\top \mathbf{z}}.$$

7. Explique por que a transformação converte um problema em geometria induzida por $\mathbf{B}$ em um problema espectral euclidiano.

Exercício 7.13 (Construção da SVD de uma matriz retangular). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 2 \\ 1 & 0 \end{bmatrix}.$$

1. Calcule

$$\mathbf{A}^\top \mathbf{A}.$$

2. Determine os autovalores de $\mathbf{A}^\top \mathbf{A}$.

3. Determine os valores singulares positivos de $\mathbf{A}$ em ordem decrescente.

4. Determine os vetores singulares à direita correspondentes.

5. Utilize

$$\mathbf{u}_j = \frac{\mathbf{A}\mathbf{v}_j}{d_j}$$

para construir os vetores singulares à esquerda.

6. Verifique que os vetores obtidos são ortonormais.

7. Construa

$$\mathbf{U}_r, \quad \mathbf{D}_r, \quad \mathbf{V}_r.$$

8. Verifique diretamente que

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

9. Identifique uma base ortonormal para $\mathcal{C}(\mathbf{A})$.

10. Identifique uma base ortonormal para $\mathcal{C}(\mathbf{A}^\top)$.

Exercício 7.14 (Aproximação de posto reduzido). Utilize a matriz e a SVD do Exercício [7.13](#).

1. Escreva

$$\mathbf{A} = d_1 \mathbf{u}_1 \mathbf{v}_1^\top + d_2 \mathbf{u}_2 \mathbf{v}_2^\top.$$

2. Construa a aproximação de posto 1

$$\mathbf{A}_1 = d_1 \mathbf{u}_1 \mathbf{v}_1^\top.$$

3. Determine explicitamente

$$\mathbf{A} - \mathbf{A}_1.$$

4. Calcule

$$\|\mathbf{A} - \mathbf{A}_1\|_F.$$

5. Verifique que, neste caso,

$$\|\mathbf{A} - \mathbf{A}_1\|_F = d_2.$$

6. Calcule

$$\|\mathbf{A}\|_F^2.$$

7. Verifique que

$$\|\mathbf{A}\|_F^2 = d_1^2 + d_2^2.$$

8. Calcule

$$\frac{d_1^2}{d_1^2 + d_2^2}.$$

9. Interprete essa razão como a parcela da magnitude quadrática da matriz preservada pela aproximação de posto 1.

Exercício 7.15 (Gradiente e Hessiana de um critério de mínimos quadrados). Considere

$$Q(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|^2.$$

1. Desenvolva $Q(\beta)$ como uma expressão quadrática em β .

2. Obtenha

$$\nabla_{\beta} Q(\beta).$$

3. Obtenha

$$\nabla_{\beta}^2 Q(\beta).$$

4. Mostre que, se $\mathbf{X}$ possui posto completo de colunas,

$$\mathbf{X}^{\top} \mathbf{X} \succ \mathbf{0}.$$

5. Conclua que a Hessiana é positiva definida.

6. Mostre que o ponto estacionário é o único minimizador global.
7. Aplique o resultado a

$$\mathbf{X} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix},$$

determinando $\hat{\beta}$ exatamente.

8. Compare a solução com aquela obtida geometricamente no Exercício 7.5.

Exercício 7.16 (Multiplicadores de Lagrange e autovalores). Considere uma matriz real simétrica $\mathbf{A}$ e o problema

$$\max_{\mathbf{x}} \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

sujeito a

$$\mathbf{x}^\top \mathbf{x} = 1.$$

1. Construa a função lagrangiana.
2. Diferencie-a em relação a $\mathbf{x}$.
3. Diferencie-a em relação ao multiplicador de Lagrange.
4. Mostre que as condições de primeira ordem conduzem a uma equação da forma

$$\mathbf{A} \mathbf{x} = \lambda \mathbf{x}.$$

5. Explique por que o problema de otimização se transforma em um problema de autovalores.
6. Resolva completamente o problema para

$$\mathbf{A} = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}.$$

7. Determine também o mínimo sob a mesma restrição.
8. Compare os resultados com os obtidos no Exercício 7.10.

Exercício 7.17 (Vetorização e produto de Kronecker). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{X} = \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}.$$

Adote a convenção de que $\text{vec}(\mathbf{X})$ empilha as colunas de $\mathbf{X}$.

1. Calcule diretamente

$$\mathbf{Y} = \mathbf{AXB}.$$

2. Determine

$$\text{vec}(\mathbf{X})$$

e

$$\text{vec}(\mathbf{Y}).$$

3. Construa

$$\mathbf{B}^\top \otimes \mathbf{A}.$$

4. Calcule

$$(\mathbf{B}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

5. Verifique a identidade

$$\text{vec}(\mathbf{AXB}) = (\mathbf{B}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

6. Compare as dimensões da transformação matricial com as dimensões de sua representação vetorizada.

Exercício 7.18 (Diferenciação de um critério matricial). Considere, para

$$\Sigma \succ \mathbf{0},$$

a função

$$Q(\Sigma) = 2 \log \det(\Sigma) + \text{tr}(\mathbf{G}\Sigma^{-1}),$$

em que

$$\mathbf{G} = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}.$$

1. Utilize diferenciais para obter

$$dQ.$$

2. Mostre que um ponto estacionário deve satisfazer

$$2\Sigma^{-1} - \Sigma^{-1}\mathbf{G}\Sigma^{-1} = \mathbf{0}.$$

3. Resolva essa equação para Σ .
4. Verifique que a matriz obtida é positiva definida.

Exercício 7.19 (Transformação afim, Jacobiana e alteração de área). Considere

$$\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b},$$

com

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

1. Calcule $\det(\mathbf{A})$ e mostre que a transformação é invertível.
2. Determine $\mathbf{A}^{-1}$.
3. Escreva a transformação inversa

$$\mathbf{x} = \mathbf{A}^{-1}(\mathbf{y} - \mathbf{b}).$$

4. Determine a matriz Jacobiana da transformação de $\mathbf{x}$ para $\mathbf{y}$.
5. Determine o determinante Jacobiano.
6. Considere a região

$$0 \leq x_1 \leq 1, \quad 0 \leq x_2 \leq 1.$$

Determine as imagens de seus quatro vértices.

7. Descreva geometricamente a região transformada.
8. Determine sua área.
9. Compare a razão entre a área transformada e a área original com

$$|\det(\mathbf{A})|.$$

Parte II — Exercícios com uso do R

Nesta parte, utilize preferencialmente operações matriciais do R. Quando uma função pronta reproduzir diretamente um resultado estudado no Módulo I, utilize-a apenas depois da construção matricial, como forma de conferência.

Em comparações envolvendo posto, autovalores teoricamente nulos ou valores singulares numericamente nulos, considere a possibilidade de pequenos erros de arredondamento computacional e utilize uma tolerância numérica adequada.

Exercício 7.20 (Centralização matricial dos dados `USArrests`). Considere as quatro variáveis quantitativas do conjunto de dados `USArrests`.

1. Armazene a matriz de dados em um objeto $\mathbf{X}$.
2. Determine n e p a partir da própria matriz.
3. Construa explicitamente

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

4. Obtenha

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}.$$

- Verifique numericamente que as médias das colunas de $\mathbf{X}_c$ são zero, admitindo apenas diferenças de arredondamento.
- Verifique numericamente que

$$\mathbf{H}_n^\top = \mathbf{H}_n$$

e

$$\mathbf{H}_n^2 = \mathbf{H}_n.$$

- Determine o posto numérico de $\mathbf{H}_n$.
- Verifique que

$$\mathbf{H}_n \mathbf{1}_n \approx \mathbf{0}.$$

- Somente ao final, compare $\mathbf{X}_c$ com o resultado produzido por

```
scale(X, center = TRUE, scale = FALSE)
```

- Explique geometricamente o papel de $\mathbf{H}_n$.

Exercício 7.21 (Matrizes de Gram e seus espectros). Utilize a matriz centralizada $\mathbf{X}_c$ obtida no Exercício 7.20.

- Calcule

$$\mathbf{G}_V = \mathbf{X}_c^\top \mathbf{X}_c$$

e

$$\mathbf{G}_O = \mathbf{X}_c \mathbf{X}_c^\top.$$

- Compare as dimensões das duas matrizes.
- Determine seus postos numéricos.
- Calcule os autovalores de ambas.
- Para identificar os autovalores numericamente positivos, utilize uma tolerância relativa, por exemplo,

$$\lambda_j > 10^{-10} \lambda_{\max}.$$

6. Compare os autovalores positivos de $\mathbf{G}_V$ e $\mathbf{G}_O$.
7. Explique por que uma matriz 4×4 e uma matriz 50×50 contêm o mesmo espectro não nulo.
8. Relacione os resultados aos valores singulares de $\mathbf{X}_c$.

Exercício 7.22 (Construção de novas variáveis por transformação linear). Considere apenas as quatro variáveis quantitativas de `iris`, formando

$$\mathbf{X} \in \mathbb{R}^{150 \times 4}.$$

Defina

$$\mathbf{A} = \begin{bmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 1 & -1 & 0 & 0 \end{bmatrix}.$$

1. Obtenha

$$\mathbf{Y} = \mathbf{XA}^\top.$$

2. Escreva explicitamente cada uma das três novas variáveis como combinação das quatro variáveis originais.
3. Verifique as dimensões de $\mathbf{Y}$.
4. Determine o posto de $\mathbf{A}$.
5. Determine a dimensão de $\mathcal{N}(\mathbf{A})$.
6. Discuta se a transformação preserva toda a informação necessária para reconstruir as quatro variáveis originais.
7. Centralize $\mathbf{X}$.
8. Aplique a mesma transformação à matriz centralizada.
9. Verifique as médias das três variáveis transformadas após a centralização.
10. Explique por que uma transformação linear de dados centralizados continua produzindo variáveis com média amostral zero.

Exercício 7.23 (Busca da direção de maior dispersão). Utilize as variáveis quantitativas de `USArrests`.

1. Centralize a matriz de dados e denote o resultado por $\mathbf{X}_c$.

2. Construa

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c.$$

3. Obtenha os autovalores e autovetores de $\mathbf{S}$ utilizando `eigen()`.
4. Identifique a direção unitária $\mathbf{a}_1$ associada ao maior autovalor.
5. Calcule

$$\mathbf{a}_1^\top \mathbf{S} \mathbf{a}_1.$$

6. Compare o resultado com o maior autovalor de $\mathbf{S}$.
7. Gere um grande número de vetores aleatórios em $\mathbb{R}^4$ e normalize cada um para norma unitária.
8. Para cada vetor $\mathbf{a}$, calcule

$$\mathbf{a}^\top \mathbf{S} \mathbf{a}.$$

9. Compare o maior valor encontrado entre as direções aleatórias com o maior autovalor de $\mathbf{S}$.
10. Explique o que esse experimento numérico mostra sobre o quociente de Rayleigh.
11. Repita a análise após padronizar as quatro variáveis para variância unitária.
12. Compare a nova direção de máxima dispersão com aquela obtida utilizando as variáveis apenas centralizadas e discuta o efeito da mudança de escala.

Não utilize `prcomp()` neste exercício.

Exercício 7.24 (Projeção e reconstrução a partir de uma direção). Utilize $\mathbf{X}_c$ e a direção $\mathbf{a}_1$ obtidas no Exercício 7.23.

1. Calcule as coordenadas das observações na direção $\mathbf{a}_1$:

$$\mathbf{z}_1 = \mathbf{X}_c \mathbf{a}_1.$$

2. Verifique as dimensões de $\mathbf{z}_1$.
3. Reconstrua a parcela da matriz de dados associada a essa direção:

$$\widehat{\mathbf{X}}_1 = \mathbf{z}_1 \mathbf{a}_1^\top.$$

4. Verifique que $\widehat{\mathbf{X}}_1$ possui posto 1.
5. Calcule

$$\mathbf{E}_1 = \mathbf{X}_c - \widehat{\mathbf{X}}_1.$$

6. Calcule

$$\|\mathbf{X}_c\|_F^2, \quad \|\widehat{\mathbf{X}}_1\|_F^2, \quad \|\mathbf{E}_1\|_F^2.$$

7. Verifique numericamente que

$$\|\mathbf{X}_c\|_F^2 \approx \|\widehat{\mathbf{X}}_1\|_F^2 + \|\mathbf{E}_1\|_F^2.$$

8. Verifique também que

$$\langle \widehat{\mathbf{X}}_1, \mathbf{E}_1 \rangle_F \approx 0.$$

9. Interprete o que foi preservado e o que foi descartado pela projeção.

Exercício 7.25 (SVD e decomposição espectral da matriz de dados). Utilize a matriz centralizada de `USArrests`.

1. Calcule sua SVD utilizando `svd()`.
2. Extraia $\mathbf{U}$, os valores singulares e $\mathbf{V}$.
3. Construa explicitamente a matriz diagonal $\mathbf{D}$.
4. Verifique numericamente que

$$\mathbf{X}_c \approx \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

5. Verifique que

$$\mathbf{X}_c^\top \mathbf{X}_c \approx \mathbf{V}\mathbf{D}^2\mathbf{V}^\top.$$

6. Calcule

```
eigen(t(Xc) %*% Xc)
```

e compare os autovetores obtidos com os vetores singulares à direita.

7. Compare os autovalores de $\mathbf{X}_c^\top \mathbf{X}_c$ com os quadrados dos valores singulares.
8. Explique por que vetores produzidos por `eigen()` e `svd()` podem diferir apenas pelo sinal.
9. Relacione as colunas de $\mathbf{V}$ a direções no espaço das variáveis.

Exercício 7.26 (Aproximações de posto reduzido em uma matriz de dados). Utilize a SVD obtida no Exercício 7.25.

Para

$$k = 1, 2, 3,$$

construa

$$\mathbf{X}_{c,k} = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Para cada valor de k :

1. determine o posto numérico de $\mathbf{X}_{c,k}$;
2. calcule

$$\|\mathbf{X}_c - \mathbf{X}_{c,k}\|_F;$$

3. verifique numericamente que

$$\|\mathbf{X}_c - \mathbf{X}_{c,k}\|_F^2 \approx \sum_{j=k+1}^r d_j^2;$$

4. calcule

$$\frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2};$$

5. interprete essa quantidade em termos da magnitude quadrática preservada pela aproximação;
6. compare os erros para $k = 1$, $k = 2$ e $k = 3$;
7. explique por que o erro não pode aumentar quando k cresce.

Não utilize `prcomp()` para construir as aproximações.

Exercício 7.27 (Mínimos quadrados com duas variáveis respostas). Utilize o conjunto de dados `mtcars`.

Considere como respostas:

- `mpg`;
- `qsec`;

e como variáveis explicativas:

- intercepto;
- `wt`;
- `hp`.

Construa

$$\mathbf{Y} \in \mathbb{R}^{n \times 2}$$

e

$$\mathbf{X} \in \mathbb{R}^{n \times 3}.$$

1. Verifique as dimensões das duas matrizes.
2. Verifique que $\mathbf{X}$ possui posto completo de colunas.
3. Calcule

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

4. Determine as dimensões de $\widehat{\mathbf{B}}$.
5. Interprete suas duas colunas.
6. Calcule

$$\widehat{\mathbf{Y}} = \mathbf{X} \widehat{\mathbf{B}}$$

e

$$\mathbf{E} = \mathbf{Y} - \widehat{\mathbf{Y}}.$$

7. Verifique numericamente que

$$\mathbf{X}^\top \mathbf{E} \approx \mathbf{0}.$$

8. Ajuste separadamente, utilizando `lm()`, um modelo para `mpg` e outro para `qsec`.
 9. Compare os coeficientes das duas regressões com as colunas de $\widehat{\mathbf{B}}$.

Exercício 7.28 (Posto deficiente e pseudoinversa). Utilize `mtcars` e considere `mpg` como vetor-resposta.

Construa uma matriz de delineamento cujas colunas sejam

$$\mathbf{1}, \quad \text{wt}, \quad 2 \text{ wt}.$$

1. Determine o posto da matriz de delineamento.
2. Compare o posto com o número de colunas.
3. Calcule seus valores singulares.
4. Identifique quais valores singulares devem ser considerados numericamente positivos utilizando uma tolerância adequada.
5. Tente utilizar diretamente

$$(\mathbf{X}^\top \mathbf{X})^{-1}$$

e explique o problema encontrado.

6. Construa manualmente a pseudoinversa de $\mathbf{X}$ a partir de sua SVD, invertendo apenas os valores singulares considerados positivos.
7. Obtenha

$$\hat{\beta}^+ = \mathbf{X}^+ \mathbf{y}.$$

8. Calcule

$$\hat{\mathbf{y}} = \mathbf{X} \hat{\beta}^+.$$

9. Determine um vetor não nulo

$$\mathbf{h} \in \mathcal{N}(\mathbf{X}).$$

10. Para diferentes valores de γ , construa

$$\hat{\beta}(\gamma) = \hat{\beta}^+ + \gamma \mathbf{h}.$$

11. Verifique que todos esses vetores produzem o mesmo vetor ajustado.

12. Compare numericamente

$$\|\hat{\beta}(\gamma)\|$$

para vários valores positivos e negativos de γ .

13. Verifique que a solução fornecida pela pseudoinversa possui a menor norma euclidiana.

14. Relacione a não unicidade dos coeficientes ao núcleo de $\mathbf{X}$.

Exercício 7.29 (Vetorização de um modelo com várias respostas). Retome as matrizes $\mathbf{X}$, $\mathbf{Y}$ e $\widehat{\mathbf{B}}$ do Exercício 7.27.

A relação matricial é

$$\widehat{\mathbf{Y}} = \mathbf{X}\widehat{\mathbf{B}}.$$

1. Construa em R

$$\text{vec}(\widehat{\mathbf{Y}})$$

empilhando as colunas.

2. Construa

$$\text{vec}(\widehat{\mathbf{B}}).$$

3. Construa

$$\mathbf{I}_2 \otimes \mathbf{X}.$$

4. Verifique suas dimensões.

5. Verifique numericamente que

$$\text{vec}(\widehat{\mathbf{Y}}) = (\mathbf{I}_2 \otimes \mathbf{X}) \text{vec}(\widehat{\mathbf{B}}).$$

6. Compare as dimensões dos dois lados da igualdade.

Parte II

Módulo II — Fundamentos Probabilísticos e Inferenciais da Análise Multivariada

8 Matrizes de covariâncias e correlações

A variância descreve a dispersão de uma variável em torno de sua média. Quando várias variáveis são observadas conjuntamente, também é necessário representar como suas variações se relacionam. A análise separada das variâncias não registra se duas componentes tendem a variar no mesmo sentido, em sentidos opostos ou se apresentam relações lineares de redundância.

A matriz de covariâncias reúne as variâncias individuais e as covariâncias entre todos os pares de componentes de um vetor aleatório. Sua estrutura permite calcular a variância de combinações lineares, caracterizar relações lineares entre as componentes e representar geometricamente a dispersão conjunta (Johnson; Wichern, 2002).

A matriz de correlações resulta da padronização das covariâncias pelos desvios-padrão das variáveis. Seus elementos são adimensionais e permitem comparar a intensidade e o sentido das associações lineares entre variáveis medidas em diferentes unidades.

O tratamento das matrizes de covariâncias e correlações distingue o nível populacional do nível descritivo dos dados observados. As propriedades inferenciais das estatísticas amostrais são tratadas no Capítulo 10. No Capítulo 9, a distribuição normal multivariada utiliza o vetor de médias e a matriz de covariâncias para especificar a distribuição conjunta.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{X} \in \mathbb{R}^p$ representa um vetor aleatório e $\mathbf{x} \in \mathbb{R}^p$ uma de suas realizações;
- $\boldsymbol{\mu} \in \mathbb{R}^p$ representa o vetor de médias populacional;
- $\boldsymbol{\Sigma} \in \mathbb{R}^{p \times p}$ representa a matriz de covariâncias populacional;
- $\mathcal{R} \in \mathbb{R}^{p \times p}$ representa a matriz de correlações populacional;
- $\boldsymbol{\Sigma}_{XY} \in \mathbb{R}^{p \times q}$ representa a matriz de covariâncias cruzadas entre os vetores aleatórios $\mathbf{X} \in \mathbb{R}^p$ e $\mathbf{Y} \in \mathbb{R}^q$;
- $\mathbf{D}_{\boldsymbol{\Sigma}} = \text{diag}(\sigma_{11}, \dots, \sigma_{pp})$ representa a matriz diagonal das variâncias populacionais;
- $\mathbf{X} \in \mathbb{R}^{n \times p}$ representa uma matriz de dados observada, com observações nas linhas e variáveis nas colunas;
- $\bar{\mathbf{x}} \in \mathbb{R}^p$ representa o vetor de médias calculado a partir dos dados observados;
- $\mathbf{H}_n = \mathbf{I}_n - n^{-1} \mathbf{1}_n \mathbf{1}_n^\top$ representa a matriz de centralização;
- $\mathbf{X}_c = \mathbf{H}_n \mathbf{X}$ representa a matriz de dados centralizada;
- $\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c$ representa a matriz total de somas de quadrados e produtos cruzados;

- $\mathbf{S} \in \mathbb{R}^{p \times p}$ e $\mathbf{R} \in \mathbb{R}^{p \times p}$ representam, respectivamente, as matrizes de covariâncias e de correlações calculadas a partir dos dados observados;
- $\mathbf{D}_S = \text{diag}(s_{11}, \dots, s_{pp})$ representa a matriz diagonal das variâncias observadas;
- $\mathbf{S}_{XY} \in \mathbb{R}^{p \times q}$ representa a matriz de covariâncias cruzadas calculada entre dois blocos de variáveis observadas;
- $\bar{\mathbf{X}}$, $\mathbf{T}$, $\mathbf{S}$ e $\mathbf{R}$ representam, respectivamente, a média amostral, a matriz de somas de quadrados e produtos cruzados centralizados, a matriz de covariâncias amostral e a matriz de correlações amostral consideradas como objetos aleatórios; suas propriedades serão desenvolvidas no Capítulo 10;
- $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$ representam as parcelas intragrupos e entre grupos da matriz total de somas de quadrados e produtos cruzados;
- SQ_{total} , SQ_{intra} e SQ_{entre} representam, respectivamente, as somas de quadrados total, intragrupos e entre grupos obtidas pelos traços de $\mathbf{T}$, $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$;
- SQ_{total} , SQ_{intra} e SQ_{entre} representam essas somas de quadrados consideradas como objetos aleatórios;
- $QM_{\text{intra}} = SQ_{\text{intra}}/(n - K)$ e $QM_{\text{entre}} = SQ_{\text{entre}}/(K - 1)$ representam os quadrados médios intragrupos e entre grupos no caso escalar;
- Σ^+ representa a pseudoinversa de Moore–Penrose de Σ quando a matriz de covariâncias é singular.

As convenções estabelecidas nos capítulos anteriores para posto, núcleo, espaço coluna, formas quadráticas, matrizes positivas semidefinidas, decomposição espectral, raízes matriciais e pseudoinversa permanecem válidas.

8.1 Momentos, centralização e covariância

8.1.1 Vetor de médias e centralização

Retomando Definição 1.2, considere o vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_p)^\top \in \mathbb{R}^p,$$

com realização $\mathbf{x} \in \mathbb{R}^p$. Quando n realizações são observadas, sua organização em uma matriz $\mathbf{X} \in \mathbb{R}^{n \times p}$ segue a representação estabelecida na Definição 1.6.

Suponha inicialmente que $E(|X_j|) < \infty$ para $j = 1, \dots, p$. O **vetor de médias populacional** é

$$\mu = E(\mathbf{X}) = \begin{bmatrix} E(X_1) \\ E(X_2) \\ \vdots \\ E(X_p) \end{bmatrix} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix} \in \mathbb{R}^p. \quad (8.1)$$

O vetor μ determina a localização média da distribuição no espaço das observações. Subtraindo esse vetor de $\mathbf{X}$, obtém-se o vetor aleatório centralizado,

$$\mathbf{X}_c = \mathbf{X} - \mu. \quad (8.2)$$

Pela linearidade da esperança,

$$E(\mathbf{X}_c) = E(\mathbf{X}) - \mu = \mathbf{0}.$$

A centralização corresponde a uma translação da distribuição, levando seu vetor de médias à origem. Como estabelecido na Proposição 4.12, a subtração do mesmo vetor de todos os pontos preserva as distâncias entre pares de realizações. Portanto, a centralização altera a localização, mas não a geometria relativa da nuvem de pontos.

A centralização da matriz de dados observada será retomada posteriormente neste capítulo, quando forem construídas a matriz de produtos cruzados e a matriz de covariâncias observada.

8.1.2 Momentos de segunda ordem

O estudo das variâncias e covariâncias exige a existência de momentos de segunda ordem. Neste capítulo, assume-se que

$$E(X_j^2) < \infty, \quad j = 1, \dots, p.$$

Essa condição garante também a existência dos primeiros momentos. Além disso, para quaisquer componentes X_j e X_k , a desigualdade de Cauchy–Schwarz aplicada a variáveis aleatórias de segundo momento finito fornece

$$E(|X_j X_k|) \leq \sqrt{E(X_j^2)E(X_k^2)} < \infty.$$

Portanto, os produtos cruzados necessários à construção das covariâncias possuem esperança finita.

A matriz de segundos momentos em relação à origem é

$$\mathbf{M}_2 = E(\mathbf{X}\mathbf{X}^\top) \in \mathbb{R}^{p \times p}.$$

O produto $\mathbf{X}\mathbf{X}^\top$ é o produto externo definido na Definição 1.14. Seus elementos são

$$[\mathbf{X}\mathbf{X}^\top]_{jk} = X_j X_k,$$

de modo que

$$\mathbf{M}_2 = \begin{bmatrix} E(X_1^2) & E(X_1 X_2) & \cdots & E(X_1 X_p) \\ E(X_2 X_1) & E(X_2^2) & \cdots & E(X_2 X_p) \\ \vdots & \vdots & \ddots & \vdots \\ E(X_p X_1) & E(X_p X_2) & \cdots & E(X_p^2) \end{bmatrix}.$$

A matriz $\mathbf{M}_2$ utiliza a origem como referência. Seus elementos dependem, portanto, da localização da distribuição e de sua variabilidade conjunta.

Para descrever a dispersão em torno do vetor de médias, utiliza-se o segundo momento central:

$$\Sigma = E[(\mathbf{X} - \mu)(\mathbf{X} - \mu)^\top].$$

Expandindo o produto e utilizando $E(\mathbf{X}) = \mu$,

$$\begin{aligned} \Sigma &= E(\mathbf{X}\mathbf{X}^\top) - E(\mathbf{X})\mu^\top - \mu E(\mathbf{X})^\top + \mu\mu^\top \\ &= \mathbf{M}_2 - \mu\mu^\top. \end{aligned} \tag{8.3}$$

A identidade Equação 8.3 é a versão matricial da relação univariada

$$\text{Var}(X) = E(X^2) - [E(X)]^2.$$

A diferença entre $\mathbf{M}_2$ e Σ está, portanto, no ponto de referência: $\mathbf{M}_2$ descreve segundos momentos em relação à origem, enquanto Σ descreve a variabilidade em torno da média.

8.1.3 Covariância entre duas variáveis

Considere duas variáveis aleatórias X e Y , definidas no mesmo espaço de probabilidade, com segundos momentos finitos e médias

$$\mu_X = E(X) \quad \text{e} \quad \mu_Y = E(Y).$$

Definição 8.1 (Covariância populacional). Se X e Y são variáveis aleatórias com segundos momentos finitos e médias $\mu_X = E(X)$ e $\mu_Y = E(Y)$, a **covariância populacional** entre X e Y é

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)].$$

A covariância é a esperança do produto dos desvios das duas variáveis em relação às respectivas médias. Seu sinal descreve o sentido predominante da associação linear:

- uma covariância positiva indica predominância de desvios de mesmo sinal;
- uma covariância negativa indica predominância de desvios de sinais opostos;
- uma covariância nula indica ausência de associação linear registrada pela covariância.

A Figura 8.1 apresenta configurações com covariâncias positiva, aproximadamente nula e negativa.




Figura 8.1: Padrões de dispersão associados ao sinal da covariância.

Na primeira configuração, a nuvem de pontos tende a se alongar em uma direção crescente; na terceira, em uma direção decrescente. A configuração central não apresenta orientação linear predominante. O valor da covariância depende também das escalas das variáveis e, por isso,

seu módulo não fornece isoladamente uma medida comparável de intensidade entre diferentes pares de variáveis.

Expandindo o produto dos desvios,

$$\begin{aligned}\text{Cov}(X, Y) &= E[(X - \mu_X)(Y - \mu_Y)] \\ &= E(XY) - \mu_X E(Y) - \mu_Y E(X) + \mu_X \mu_Y.\end{aligned}$$

Como $E(X) = \mu_X$ e $E(Y) = \mu_Y$,

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y). \quad (8.4)$$

A expressão Equação 8.4 relaciona a covariância ao momento conjunto $E(XY)$ e aos primeiros momentos das duas variáveis.

Quando as duas variáveis coincidem,

$$\text{Cov}(X, X) = E[(X - \mu_X)^2] = \text{Var}(X).$$

A covariância também é simétrica:

$$\text{Cov}(X, Y) = \text{Cov}(Y, X).$$

Para constantes a , b , c e d ,

$$\text{Cov}(aX + b, cY + d) = ac \text{Cov}(X, Y). \quad (8.5)$$

A identidade Equação 8.5 mostra que translações não alteram a covariância. Mudanças de escala multiplicam a covariância pelo produto dos fatores aplicados às duas variáveis. Quando somente um desses fatores é negativo, o sinal da covariância é invertido.

Essa dependência das unidades impede a comparação direta entre covariâncias associadas a pares de variáveis em escalas distintas. Se uma variável medida em metros for convertida para centímetros, por exemplo, sua covariância com outra variável será multiplicada por 100.

Pela desigualdade de Cauchy–Schwarz,

$$|\text{Cov}(X, Y)| \leq \sqrt{\text{Var}(X) \text{Var}(Y)}. \quad (8.6)$$

O limite Equação 8.6 será utilizado posteriormente para mostrar que a correlação pertence ao intervalo $[-1, 1]$.

Covariância nula e independência

Covariância nula não implica independência em uma distribuição geral. A covariância registra associação linear de segunda ordem, e relações não lineares podem produzir covariância igual a zero.

Exemplo 8.1 (Dependência não linear com covariância nula). Considere

$$X \sim \text{Uniforme}(-2, 2)$$

e

$$Y = X^2 + \varepsilon,$$

em que ε é independente de X , possui média zero e segundo momento finito.

A simetria da distribuição de X em torno de zero implica

$$E(X) = 0 \quad \text{e} \quad E(X^3) = 0.$$

Como ε é independente de X ,

$$E(X\varepsilon) = E(X)E(\varepsilon) = 0.$$

Para calcular a covariância entre X e Y , utiliza-se

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y).$$

Como $Y = X^2 + \varepsilon$,

$$\begin{aligned} E(XY) &= E[X(X^2 + \varepsilon)] \\ &= E(X^3) + E(X\varepsilon) \\ &= 0. \end{aligned}$$

Além disso,

$$E(X)E(Y) = 0,$$

pois $E(X) = 0$. Portanto,

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y) = 0.$$

Apesar da covariância nula, X e Y não são independentes. Para verificar isso, considere a esperança condicional de Y dado $X = x$. Como

$$\begin{aligned} E(Y \mid X = x) &= E(X^2 + \varepsilon \mid X = x) \\ &= x^2 + E(\varepsilon \mid X = x). \end{aligned}$$

Como ε é independente de X ,

$$E(\varepsilon \mid X = x) = E(\varepsilon) = 0.$$

Portanto,

$$E(Y \mid X = x) = x^2.$$

Assim, a média condicional de Y depende do valor de X . Se X e Y fossem independentes, a distribuição condicional de Y dado $X = x$ seria a mesma distribuição marginal de Y e, consequentemente,

$$E(Y \mid X = x) = E(Y),$$

não dependendo de x . Logo, X e Y são dependentes, apesar de apresentarem covariância nula.

A Figura 8.2 ilustra essa relação.

A configuração parabólica evidencia uma dependência que não produz orientação linear global. O exemplo delimita a informação fornecida pela covariância e mostra por que o valor zero não deve ser interpretado, sem hipóteses adicionais, como independência.

As variâncias das componentes e as covariâncias entre todos os pares de componentes podem ser reunidas em uma única matriz.




Figura 8.2: Dependência não linear com covariância aproximadamente nula na amostra simulada.

8.2 Matriz de covariâncias populacional

8.2.1 Definição e interpretação dos elementos

Definição 8.2 (Matriz de covariâncias populacional). Seja $\mathbf{X} \in \mathbb{R}^p$ um vetor aleatório com vetor de médias μ e segundos momentos finitos. A **matriz de covariâncias populacional** de $\mathbf{X}$ é

$$\Sigma = \text{Cov}(\mathbf{X}) = E[(\mathbf{X} - \mu)(\mathbf{X} - \mu)^\top] \in \mathbb{R}^{p \times p}. \quad (8.7)$$

O elemento situado na linha j e na coluna k de Σ é

$$\sigma_{jk} = \text{Cov}(X_j, X_k), \quad j, k = 1, \dots, p.$$

Assim,

$$\Sigma = \begin{bmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & \cdots & \text{Cov}(X_1, X_p) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) & \cdots & \text{Cov}(X_2, X_p) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_p, X_1) & \text{Cov}(X_p, X_2) & \cdots & \text{Var}(X_p) \end{bmatrix}. \quad (8.8)$$

Os elementos da diagonal principal são as variâncias,

$$\sigma_{jj} = \text{Var}(X_j),$$

e os elementos fora da diagonal são as covariâncias entre componentes distintos.

Como

$$\text{Cov}(X_j, X_k) = \text{Cov}(X_k, X_j),$$

tem-se

$$\sigma_{jk} = \sigma_{kj},$$

e Σ é simétrica. Para p componentes, existem p variâncias e

$$\frac{p(p-1)}{2}$$

covariâncias distintas, totalizando

$$\frac{p(p+1)}{2}$$

elementos distintos.

As unidades dos elementos dependem das variáveis envolvidas. Se X_j é medida em uma unidade u_j , então

$$\sigma_{jj}$$

é expressa em u_j^2 . Para $j \neq k$,

$$\sigma_{jk}$$

é expressa em $u_j u_k$. Essa dependência das unidades motiva a construção posterior da matriz de correlações.

8.2.2 Variâncias e covariâncias de combinações lineares

Uma combinação linear das componentes de $\mathbf{X}$ possui a forma

$$Y = \mathbf{a}^\top \mathbf{X}, \quad \mathbf{a} \in \mathbb{R}^p.$$

O vetor $\mathbf{a}$ contém os coeficientes da combinação e define uma direção no espaço das variáveis. A combinação linear, já utilizada no Módulo 1, adquire aqui uma interpretação probabilística: sua média e sua variância são determinadas por μ e Σ .

Proposição 8.1 (Momentos de combinações lineares). *Seja $\mathbf{X} \in \mathbb{R}^p$ um vetor aleatório com média μ e matriz de covariâncias Σ . Para quaisquer vetores fixos $\mathbf{a}, \mathbf{b} \in \mathbb{R}^p$,*

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \mu, \tag{8.9}$$

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}, \tag{8.10}$$

e

$$\text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{b}. \tag{8.11}$$

i Demonstração

Pela linearidade da esperança,

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top E(\mathbf{X}) = \mathbf{a}^\top \boldsymbol{\mu}.$$

Além disso,

$$\mathbf{a}^\top \mathbf{X} - \mathbf{a}^\top \boldsymbol{\mu} = \mathbf{a}^\top (\mathbf{X} - \boldsymbol{\mu}).$$

Consequentemente,

$$\begin{aligned}\text{Var}(\mathbf{a}^\top \mathbf{X}) &= E[\mathbf{a}^\top (\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top \mathbf{a}] \\ &= \mathbf{a}^\top \Sigma \mathbf{a}.\end{aligned}$$

De modo análogo,

$$\begin{aligned}\text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{X}) &= E[\mathbf{a}^\top (\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top \mathbf{b}] \\ &= \mathbf{a}^\top \Sigma \mathbf{b}.\end{aligned}$$

A expressão Equação 8.10 mostra que a matriz de covariâncias determina a variabilidade de todas as combinações lineares das componentes. A quantidade

$$\mathbf{a}^\top \Sigma \mathbf{a}$$

é uma forma quadrática no sentido de Definição 2.17. Quando $\|\mathbf{a}\| = 1$, ela representa a variância da projeção de $\mathbf{X}$ sobre a direção unitária $\mathbf{a}$.

Essa relação constitui a ligação entre a matriz de covariâncias e a geometria desenvolvida no Módulo 1: diferentes direções podem apresentar diferentes níveis de dispersão.

Exemplo 8.2 (Matriz de covariâncias com três variáveis). Considere

$$\Sigma = \begin{bmatrix} 4 & 1,5 & -0,8 \\ 1,5 & 9 & 0 \\ -0,8 & 0 & 1 \end{bmatrix}.$$

As variâncias das três componentes são

$$\text{Var}(X_1) = 4, \quad \text{Var}(X_2) = 9, \quad \text{Var}(X_3) = 1,$$

e as covariâncias distintas são

$$\text{Cov}(X_1, X_2) = 1,5,$$

$$\text{Cov}(X_1, X_3) = -0,8,$$

e

$$\text{Cov}(X_2, X_3) = 0.$$

Considere a combinação linear

$$Y = X_1 + 0,5X_2 - X_3,$$

com vetor de coeficientes

$$\mathbf{a} = \begin{bmatrix} 1 \\ 0,5 \\ -1 \end{bmatrix}.$$

Pela expressão Equação 8.10,

$$\begin{aligned} \text{Var}(Y) &= \mathbf{a}^\top \Sigma \mathbf{a} \\ &= \begin{bmatrix} 1 & 0,5 & -1 \end{bmatrix} \begin{bmatrix} 4 & 1,5 & -0,8 \\ 1,5 & 9 & 0 \\ -0,8 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 0,5 \\ -1 \end{bmatrix} \\ &= 10,35. \end{aligned}$$

A variância da combinação depende das variâncias individuais, das covariâncias e dos coeficientes utilizados. A covariância negativa entre X_1 e X_3 , por exemplo, contribui positivamente para $\text{Var}(Y)$ porque os coeficientes dessas duas componentes possuem sinais opostos.

8.2.3 Propriedades estruturais e singularidade

A matriz de covariâncias pertence à classe das matrizes simétricas positivas semidefinidas. A classificação de positividade de matrizes foi estabelecida na Definição 2.18; aqui ela adquire uma interpretação probabilística direta, pois a forma quadrática associada a Σ representa uma variância (Eaton, 2007).


Proposição 8.2 (Caracterização estrutural das matrizes de covariâncias). *Uma matriz $\mathbf{C} \in \mathbb{R}^{p \times p}$ é matriz de covariâncias de algum vetor aleatório com segundos momentos finitos se, e somente se,*

$$\mathbf{C} = \mathbf{C}^\top$$

e

$$\mathbf{C} \succeq \mathbf{0}.$$

Consequentemente, toda matriz de covariâncias possui elementos diagonais não negativos, autovalores não negativos e submatrizes principais positivas semidefinidas.



i Demonstração

Se

$$\mathbf{C} = \text{Cov}(\mathbf{X}),$$

a simetria decorre de

$$\text{Cov}(X_j, X_k) = \text{Cov}(X_k, X_j).$$

Além disso, para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}^\top \mathbf{C} \mathbf{a} = \text{Var}(\mathbf{a}^\top \mathbf{X}) \geq 0.$$

Logo, $\mathbf{C}$ é positiva semidefinida.

Reciprocamente, suponha que $\mathbf{C}$ seja real, simétrica e positiva semidefinida. Pelo Teorema 5.2 e pela raiz quadrada principal definida na Definição 5.7, existe uma matriz simétrica positiva semidefinida $\mathbf{C}^{1/2}$ tal que

$$\mathbf{C} = \mathbf{C}^{1/2} \mathbf{C}^{1/2}.$$

Considere um vetor aleatório

$$\mathbf{U} = (U_1, \dots, U_p)^\top,$$

cujas componentes são independentes e satisfazem

$$P(U_j = 1) = P(U_j = -1) = \frac{1}{2}, \quad j = 1, \dots, p.$$

Então,

$$E(\mathbf{U}) = \mathbf{0}$$

e

$$\text{Cov}(\mathbf{U}) = \mathbf{I}_p.$$

Defina

$$\mathbf{X} = \mathbf{C}^{1/2} \mathbf{U}.$$

Como

Essa construção estabelece apenas a existência de um vetor aleatório com matriz de covariâncias $\mathbf{C}$ e não exige uma família de distribuições específica.

A semidefinição positiva impõe restrições aos elementos da matriz. Para duas componentes X_j e X_k , a submatriz principal

$$\begin{bmatrix} \sigma_{jj} & \sigma_{jk} \\ \sigma_{jk} & \sigma_{kk} \end{bmatrix}$$

também deve ser positiva semidefinida. Logo,

$$\sigma_{jj}\sigma_{kk} - \sigma_{jk}^2 \geq 0,$$

o que equivale a

$$|\sigma_{jk}| \leq \sqrt{\sigma_{jj}\sigma_{kk}}.$$

A desigualdade $|\sigma_{jk}| \leq \sqrt{\sigma_{jj}\sigma_{kk}}$ recupera, no nível matricial, o limite apresentado na Equação 8.6.

A simetria, isoladamente, não é suficiente para caracterizar uma matriz de covariâncias.

Exemplo 8.3 (Matriz simétrica que não pode ser uma matriz de covariâncias). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}.$$

A matriz é simétrica. Entretanto, para

$$\mathbf{a} = \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

tem-se

$$\begin{aligned} \mathbf{a}^\top \mathbf{A} \mathbf{a} &= \begin{bmatrix} 1 & -1 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\ &= -2. \end{aligned}$$

Se $\mathbf{A}$ fosse uma matriz de covariâncias, esse valor representaria a variância de uma combinação linear, o que é impossível. A matriz é, portanto, simétrica, mas não positiva semidefinida.

Quando

$$\mathbf{a}^\top \Sigma \mathbf{a} > 0$$

para todo $\mathbf{a} \neq \mathbf{0}$, a matriz Σ é positiva definida. Pela Equação 8.10, isso significa que toda combinação linear não trivial das componentes possui variância positiva.

A situação muda quando Σ é singular. Nesse caso, aparecerá a expressão **quase certamente**. Seja U uma variável aleatória definida em um espaço de probabilidade $(\Omega, \mathcal{F}, P)$ e seja $c \in \mathbb{R}$. Escrever

$$U = c \quad \text{quase certamente}$$

significa que

$$P(\{\omega \in \Omega : U(\omega) = c\}) = P(U = c) = 1.$$

Equivalentemente, a igualdade pode falhar apenas em um conjunto de resultados de probabilidade zero.

Proposição 8.3 (Caracterização da singularidade da matriz de covariâncias). *Seja $\mathbf{X} \in \mathbb{R}^p$ um vetor aleatório com média μ e matriz de covariâncias Σ . As seguintes afirmações são equivalentes:*

1. Σ é singular;
2. existe $\mathbf{a} \neq \mathbf{0}$ tal que

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0;$$

3. existe $\mathbf{a} \neq \mathbf{0}$ tal que

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = 0;$$

4. existe $\mathbf{a} \neq \mathbf{0}$ tal que

$$\mathbf{a}^\top (\mathbf{X} - \mu) = 0 \quad \text{quase certamente.}$$

i Demonstração

Como Σ é simétrica e positiva semidefinida, o Teorema 5.2 garante uma decomposição com autovalores não negativos. A matriz é singular se, e somente se, pelo menos um desses autovalores é zero. Nesse caso, existe $\mathbf{a} \neq \mathbf{0}$ no núcleo de Σ e, portanto,

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0.$$

Reciprocamente, para uma matriz positiva semidefinida,

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0$$

implica que $\mathbf{a}$ pertence ao núcleo de Σ .

Pela Equação 8.10,

$$\mathbf{a}^\top \Sigma \mathbf{a} = \text{Var}(\mathbf{a}^\top \mathbf{X}),$$

o que estabelece a equivalência entre as duas condições seguintes.

Uma variável aleatória possui variância zero se, e somente se, é constante quase certamente. Como

$$E[\mathbf{a}^\top (\mathbf{X} - \mu)] = 0,$$

essa constante deve ser zero. Portanto,

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = 0$$

se, e somente se,

$$\mathbf{a}^\top (\mathbf{X} - \mu) = 0 \quad \text{quase certamente.}$$

A última condição da Proposição 8.3 também pode ser escrita como

$$\mathbf{a}^\top \mathbf{X} = \mathbf{a}^\top \mu \quad \text{quase certamente.}$$

Portanto, a singularidade de Σ corresponde à existência de uma relação afim exata e não trivial entre as componentes do vetor aleatório.

Em termos geométricos, os vetores pertencentes a

$$\mathcal{N}(\Sigma)$$

determinam direções de variância nula. Como Σ é simétrica, a relação entre núcleo e espaço coluna desenvolvida no Módulo 1 permite escrever

$$\mathcal{N}(\Sigma)^\perp = \mathcal{C}(\Sigma).$$

Consequentemente,

$$\mathbf{X} - \mu \in \mathcal{C}(\Sigma) \quad \text{quase certamente.}$$

Se

$$\text{posto}(\Sigma) = r < p,$$

a variabilidade do vetor centralizado está restrita a um subespaço de dimensão r . O vetor original está, portanto, restrito quase certamente ao subespaço afim

$$\mu + \mathcal{C}(\Sigma).$$

A matriz de covariâncias também pode ser utilizada para descrever conjuntamente dois vetores aleatórios distintos. Essa extensão produz matrizes retangulares de covariâncias cruzadas e permite representar as relações lineares entre dois blocos de variáveis.

8.3 Covariâncias entre vetores e transformações

8.3.1 Covariâncias cruzadas e vetores particionados

A covariância pode relacionar componentes pertencentes a dois vetores aleatórios distintos. Considere

$$\mathbf{X} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{Y} \in \mathbb{R}^q,$$

com vetores de médias

$$\mu_X = E(\mathbf{X}) \in \mathbb{R}^p$$

e

$$\mu_Y = E(\mathbf{Y}) \in \mathbb{R}^q.$$

Admite-se que todas as componentes possuam segundos momentos finitos.

Definição 8.3 (Matriz de covariâncias cruzadas). A **matriz de covariâncias cruzadas** entre $\mathbf{X}$ e $\mathbf{Y}$ é

$$\Sigma_{XY} = \text{Cov}(\mathbf{X}, \mathbf{Y}) = E \left[(\mathbf{X} - \mu_X) (\mathbf{Y} - \mu_Y)^\top \right] \in \mathbb{R}^{p \times q}, \quad (8.12)$$

em que $\mathbf{X} \in \mathbb{R}^p$ e $\mathbf{Y} \in \mathbb{R}^q$ possuem segundos momentos finitos e médias μ_X e μ_Y , respectivamente.

O elemento situado na linha j e na coluna k é

$$(\Sigma_{XY})_{jk} = \text{Cov}(X_j, Y_k),$$

para $j = 1, \dots, p$ e $k = 1, \dots, q$. Portanto,

$$\Sigma_{XY} = \begin{bmatrix} \text{Cov}(X_1, Y_1) & \cdots & \text{Cov}(X_1, Y_q) \\ \vdots & \ddots & \vdots \\ \text{Cov}(X_p, Y_1) & \cdots & \text{Cov}(X_p, Y_q) \end{bmatrix}.$$

A orientação da matriz depende da ordem dos vetores. Invertendo essa ordem,

$$\Sigma_{YX} = \Sigma_{XY}^\top. \quad (8.13)$$

Assim,

$$\Sigma_{XY} \in \mathbb{R}^{p \times q}, \quad \Sigma_{YX} \in \mathbb{R}^{q \times p}.$$

Mesmo quando $p = q$, não se tem em geral

$$\Sigma_{XY} = \Sigma_{YX},$$

pois uma matriz de covariâncias cruzadas não precisa ser simétrica.

Proposição 8.4 (Covariância entre combinações de dois vetores). *Sejam $\mathbf{X} \in \mathbb{R}^p$ e $\mathbf{Y} \in \mathbb{R}^q$ vetores aleatórios com matriz de covariâncias cruzadas Σ_{XY} . Para quaisquer vetores fixos*

$$\mathbf{a} \in \mathbb{R}^p \quad e \quad \mathbf{b} \in \mathbb{R}^q,$$

tem-se

$$\text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{Y}) = \mathbf{a}^\top \Sigma_{XY} \mathbf{b}. \quad (8.14)$$

i Demonstração

As versões centralizadas das duas combinações são

$$\mathbf{a}^\top (\mathbf{X} - \mu_X)$$

e

$$\mathbf{b}^\top (\mathbf{Y} - \mu_Y).$$

Logo,

$$\begin{aligned} \text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{Y}) \\ &= E \left[\mathbf{a}^\top (\mathbf{X} - \mu_X) (\mathbf{Y} - \mu_Y)^\top \mathbf{b} \right] \\ &= \mathbf{a}^\top \Sigma_{XY} \mathbf{b}. \end{aligned}$$

Em particular,

$$\Sigma_{XY} = \mathbf{0}$$

se, e somente se,

$$\text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{Y}) = 0$$

para todos os vetores $\mathbf{a} \in \mathbb{R}^p$ e $\mathbf{b} \in \mathbb{R}^q$. Nesse caso, nenhuma combinação linear do primeiro bloco possui covariância não nula com uma combinação linear do segundo.

A condição

$$\Sigma_{XY} = \mathbf{0}$$

não implica, em uma distribuição geral, independência entre os vetores. Essa relação será retomada no Capítulo 9 sob a distribuição normal multivariada.

Os dois vetores podem ser reunidos em um único vetor particionado:

$$\mathbf{v} = \begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix} \in \mathbb{R}^{p+q}.$$

Seu vetor de médias é

$$\mu_V = \begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix},$$

e sua matriz de covariâncias pode ser representada por blocos, conforme a estrutura de matrizes particionadas definida na Definição 2.19:

$$\Sigma_V = \begin{bmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{bmatrix}, \quad (8.15)$$

em que

$$\Sigma_{XX} = \text{Cov}(\mathbf{X})$$

e

$$\Sigma_{YY} = \text{Cov}(\mathbf{Y}).$$

Os blocos diagonais descrevem a dispersão interna de cada vetor, enquanto os blocos fora da diagonal descrevem as covariâncias entre suas componentes.

Como Σ_V é uma matriz de covariâncias, ela é simétrica e positiva semidefinida. Essa condição restringe conjuntamente seus blocos. Em particular, Σ_{XY} não pode ser especificada arbitrariamente depois de fixadas Σ_{XX} e Σ_{YY} .

8.3.1.1 Complemento de Schur e dispersão residual

O complemento de Schur já foi definido na Definição 2.20. Aplicado à matriz de covariâncias particionada, ele recebe uma interpretação estatística de segunda ordem.

Suponha que

$$\Sigma_{YY} \succ \mathbf{0}.$$

O complemento de Schur de Σ_{YY} em Σ_V é

$$\Sigma_{XX \cdot Y} = \Sigma_{XX} - \Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{YX}. \quad (8.16)$$

Pelo resultado de positividade do complemento de Schur no Teorema 2.7,

$$\Sigma_{XX \cdot Y} \succeq \mathbf{0}.$$

A expressão também pode ser interpretada diretamente como uma covariância residual.

Proposição 8.5 (Complemento de Schur e covariância residual). *Sejam*

$$\mathbf{X} \in \mathbb{R}^p \quad e \quad \mathbf{Y} \in \mathbb{R}^q$$

vetores aleatórios com segundos momentos finitos, vetores de médias

$$\mu_X = E(\mathbf{X}) \quad e \quad \mu_Y = E(\mathbf{Y}),$$

e matriz de covariâncias conjunta

$$\text{Cov} \left(\begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix} \right) = \begin{bmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{bmatrix}.$$

Se

$$\Sigma_{YY} \succ \mathbf{0},$$

o complemento de Schur

$$\Sigma_{XX.Y} = \Sigma_{XX} - \Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{YX}$$

é a menor matriz de covariâncias residuais, segundo a ordem de Loewner, entre as matrizes obtidas ao aproximar linearmente $\mathbf{X}_c$ por $\mathbf{L}\mathbf{Y}_c$, com

$$\mathbf{L} \in \mathbb{R}^{p \times q}.$$

Para

$$\mathbf{L}^* = \Sigma_{XY} \Sigma_{YY}^{-1},$$

tem-se

$$\text{Cov}(\mathbf{R}_{\mathbf{L}^*}) = \Sigma_{XX.Y},$$

e, para qualquer

$$\mathbf{L} \in \mathbb{R}^{p \times q},$$

tem-se

$$\text{Cov}(\mathbf{R}_L) - \Sigma_{XX \cdot Y} \succeq \mathbf{0},$$

em que

$$\mathbf{R}_L = \mathbf{X}_c - \mathbf{L}\mathbf{Y}_c,$$

$$\mathbf{X}_c = \mathbf{X} - \mu_X \quad e \quad \mathbf{Y}_c = \mathbf{Y} - \mu_Y.$$

i Demonstração

Para uma matriz arbitrária $\mathbf{L}$,

$$\text{Cov}(\mathbf{R}_L) = \Sigma_{XX} - \mathbf{L}\Sigma_{YX} - \Sigma_{XY}\mathbf{L}^\top + \mathbf{L}\Sigma_{YY}\mathbf{L}^\top.$$

Substituindo

$$\mathbf{L}^* = \Sigma_{XY}\Sigma_{YY}^{-1},$$

a expressão pode ser reorganizada como

$$\begin{aligned} \text{Cov}(\mathbf{R}_L) &= \Sigma_{XX \cdot Y} \\ &\quad + (\mathbf{L} - \mathbf{L}^*)\Sigma_{YY}(\mathbf{L} - \mathbf{L}^*)^\top. \end{aligned}$$

Como Σ_{YY} é positiva definida,

$$(\mathbf{L} - \mathbf{L}^*)\Sigma_{YY}(\mathbf{L} - \mathbf{L}^*)^\top \succeq \mathbf{0}.$$

A diferença entre a covariância residual correspondente a qualquer $\mathbf{L}$ e aquela obtida com $\mathbf{L}^*$ é, portanto, positiva semidefinida.

Essa interpretação depende apenas dos segundos momentos e não exige normalidade. Sob normalidade conjunta, o mesmo complemento de Schur aparecerá no Capítulo 9 como matriz de covariâncias da distribuição condicional de um bloco dado o outro.

Exemplo 8.4 (Covariâncias entre dois blocos). Considere

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

e

$$\mathbf{Y} = \begin{bmatrix} Y_1 \\ Y_2 \\ Y_3 \end{bmatrix},$$

com

$$\Sigma_{XY} = \begin{bmatrix} 2 & -1 & 0,5 \\ 1 & 3 & -2 \end{bmatrix}.$$

Para as combinações

$$U = X_1 - 2X_2$$

e

$$V = Y_1 + Y_2,$$

os vetores de coeficientes são

$$\mathbf{a} = \begin{bmatrix} 1 \\ -2 \end{bmatrix}$$

e

$$\mathbf{b} = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}.$$

Pela expressão Equação 8.14,

$$\begin{aligned} \text{Cov}(U, V) &= \mathbf{a}^\top \Sigma_{XY} \mathbf{b} \\ &= \begin{bmatrix} 1 & -2 \end{bmatrix} \begin{bmatrix} 2 & -1 & 0,5 \\ 1 & 3 & -2 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} \\ &= -7. \end{aligned}$$

A covariância entre U e V resulta conjuntamente das covariâncias entre todas as componentes que participam das duas combinações lineares.

8.3.2 Transformações afins da média e da covariância

As transformações afins foram definidas na Definição 4.6. No contexto probabilístico, interessa determinar como elas modificam a média e a matriz de covariâncias.

Considere

$$\mathbf{U} = \mathbf{A}\mathbf{X} + \mathbf{c},$$

em que

$$\mathbf{X} \in \mathbb{R}^p, \quad \mathbf{A} \in \mathbb{R}^{r \times p}, \quad \mathbf{c} \in \mathbb{R}^r.$$

Proposição 8.6 (Média e covariância sob transformação afim). *Seja $\mathbf{X} \in \mathbb{R}^p$ um vetor aleatório com média μ_X e matriz de covariâncias Σ_{XX} . Para*

$$\mathbf{U} = \mathbf{A}\mathbf{X} + \mathbf{c}, \quad \mathbf{A} \in \mathbb{R}^{r \times p}, \quad \mathbf{c} \in \mathbb{R}^r,$$

tem-se

$$E(\mathbf{U}) = \mathbf{A}\mu_X + \mathbf{c} \tag{8.17}$$

e

$$\text{Cov}(\mathbf{U}) = \mathbf{A}\Sigma_{XX}\mathbf{A}^\top. \tag{8.18}$$

i Demonstração

Pela linearidade da esperança,

$$E(\mathbf{A}\mathbf{X} + \mathbf{c}) = \mathbf{A}\mu_X + \mathbf{c}.$$

O vetor transformado centralizado é

$$\begin{aligned}\mathbf{U} - E(\mathbf{U}) &= \mathbf{A}\mathbf{X} + \mathbf{c} - \mathbf{A}\mu_X - \mathbf{c} \\ &= \mathbf{A}(\mathbf{X} - \mu_X).\end{aligned}$$

Portanto,

$$\begin{aligned}\text{Cov}(\mathbf{U}) &= E\left[\mathbf{A}(\mathbf{X} - \mu_X)(\mathbf{X} - \mu_X)^\top \mathbf{A}^\top\right] \\ &= \mathbf{A}\Sigma_{XX}\mathbf{A}^\top.\end{aligned}$$

A ausência do vetor $\mathbf{c}$ na Equação 8.18 confirma que translações alteram a localização, mas não a matriz de covariâncias.

Quando

$$r = 1 \quad \text{e} \quad \mathbf{A} = \mathbf{a}^\top,$$

a expressão reduz-se a

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma_{XX} \mathbf{a},$$

recuperando Equação 8.10.

Se $\mathbf{A}$ é diagonal,

$$\mathbf{A} = \text{diag}(a_1, \dots, a_p),$$

então

$$\text{Cov}(a_j X_j, a_k X_k) = a_j a_k \sigma_{jk}.$$

Em particular,

$$\text{Var}(a_j X_j) = a_j^2 \sigma_{jj}.$$

Se $\mathbf{Q} \in \mathbb{R}^{p \times p}$ é ortogonal no sentido de Definição 2.15,

$$\text{Cov}(\mathbf{Q}\mathbf{X}) = \mathbf{Q}\Sigma_{XX}\mathbf{Q}^\top.$$

Como $\mathbf{Q}^\top = \mathbf{Q}^{-1}$, essa transformação produz uma matriz semelhante a Σ_{XX} e preserva seus autovalores. A interpretação estatística dessa propriedade será retomada na geometria da covariância.

Exemplo 8.5 (Transformação de duas variáveis). Considere

$$\Sigma_{XX} = \begin{bmatrix} 4 & 2 \\ 2 & 9 \end{bmatrix}$$

e

$$\mathbf{U} = \mathbf{A}\mathbf{X},$$

com

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

As componentes transformadas são

$$U_1 = X_1 + X_2$$

e

$$U_2 = X_1 - X_2.$$

Pela expressão Equação 8.18,

$$\begin{aligned} \text{Cov}(\mathbf{U}) &= \mathbf{A}\Sigma_{XX}\mathbf{A}^\top \\ &= \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 4 & 2 \\ 2 & 9 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 17 & -5 \\ -5 & 9 \end{bmatrix}. \end{aligned}$$

Logo,

$$\text{Var}(U_1) = 17, \quad \text{Var}(U_2) = 9$$

e

$$\text{Cov}(U_1, U_2) = -5.$$

A transformação modifica simultaneamente as variâncias das componentes e a covariância entre elas.

As covariâncias cruzadas também se transformam de maneira compatível.

Proposição 8.7 (Covariância cruzada sob transformações afins). *Sejam $\mathbf{X} \in \mathbb{R}^p$ e $\mathbf{Y} \in \mathbb{R}^q$ vetores aleatórios com matriz de covariâncias cruzadas Σ_{XY} . Considere*

$$\mathbf{U} = \mathbf{A}_X \mathbf{X} + \mathbf{c}$$

e

$$\mathbf{V} = \mathbf{A}_Y \mathbf{Y} + \mathbf{d},$$

com

$$\mathbf{A}_X \in \mathbb{R}^{r \times p}, \quad \mathbf{A}_Y \in \mathbb{R}^{s \times q}, \quad \mathbf{c} \in \mathbb{R}^r, \quad \mathbf{d} \in \mathbb{R}^s.$$

Então,

$$\text{Cov}(\mathbf{U}, \mathbf{V}) = \mathbf{A}_X \Sigma_{XY} \mathbf{A}_Y^\top. \quad (8.19)$$

i Demonstração

Após a centralização,

$$\mathbf{U} - E(\mathbf{U}) = \mathbf{A}_X (\mathbf{X} - \mu_X)$$

e

$$\mathbf{V} - E(\mathbf{V}) = \mathbf{A}_Y (\mathbf{Y} - \mu_Y).$$

Logo,

$$\begin{aligned} \text{Cov}(\mathbf{U}, \mathbf{V}) &= E \left[\mathbf{A}_X (\mathbf{X} - \mu_X) (\mathbf{Y} - \mu_Y)^\top \mathbf{A}_Y^\top \right] \\ &= \mathbf{A}_X \Sigma_{XY} \mathbf{A}_Y^\top. \end{aligned}$$

As expressões Equação 8.18 e Equação 8.19 mostram que a matriz de covariâncias responde de maneira sistemática às transformações lineares. A padronização das componentes constitui um caso particular dessa estrutura.

8.4 Padronização e matriz de correlações

8.4.1 Matriz de correlações populacional

As covariâncias dependem das unidades de medida das variáveis. Para retirar as escalas marginais, suponha que

$$\sigma_{jj} = \text{Var}(X_j) > 0, \quad j = 1, \dots, p.$$

Defina a matriz diagonal das variâncias populacionais por

$$\mathbf{D}_\Sigma = \text{diag}(\sigma_{11}, \dots, \sigma_{pp}). \quad (8.20)$$

Como todas as variâncias são positivas,

$$\mathbf{D}_\Sigma \succ \mathbf{0}$$

e existem as matrizes diagonais

$$\mathbf{D}_\Sigma^{1/2} = \text{diag}(\sqrt{\sigma_{11}}, \dots, \sqrt{\sigma_{pp}})$$

e

$$\mathbf{D}_{\Sigma}^{-1/2} = \text{diag} \left(\frac{1}{\sqrt{\sigma_{11}}}, \dots, \frac{1}{\sqrt{\sigma_{pp}}} \right).$$

Definição 8.4 (Vetor aleatório padronizado). Se $\mathbf{X} \in \mathbb{R}^p$ possui média μ e variâncias marginais positivas, o vetor aleatório marginalmente padronizado correspondente é

$$\mathbf{Z} = \mathbf{D}_{\Sigma}^{-1/2} (\mathbf{X} - \mu), \quad (8.21)$$

em que $\mathbf{D}_{\Sigma} \succ \mathbf{0}$ é a matriz diagonal das variâncias populacionais e

$$\mathbf{D}_{\Sigma}^{-1/2} = \text{diag} \left(\frac{1}{\sqrt{\sigma_{11}}}, \dots, \frac{1}{\sqrt{\sigma_{pp}}} \right).$$

Sua componente j é

$$Z_j = \frac{X_j - \mu_j}{\sqrt{\sigma_{jj}}}.$$

Assim,

$$E(Z_j) = 0$$

e

$$\text{Var}(Z_j) = 1.$$

Em forma vetorial,

$$E(\mathbf{Z}) = \mathbf{0}.$$

Aplicando Equação [8.18](#),

$$\text{Cov}(\mathbf{Z}) = \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}.$$

Definição 8.5 (Matriz de correlações populacional). A **matriz de correlações populacional** de $\mathbf{X} \in \mathbb{R}^p$ é

$$\mathcal{R} = \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}, \quad (8.22)$$

em que Σ é a matriz de covariâncias de $\mathbf{X}$ e

$$\mathbf{D}_{\Sigma} = \text{diag}(\sigma_{11}, \dots, \sigma_{pp}),$$

com

$$\sigma_{jj} > 0, \quad j = 1, \dots, p.$$

O símbolo $\mathcal{R}$ é reservado à matriz populacional. Posteriormente, $\mathbf{R}$ representará a matriz de correlações amostral, enquanto $\mathbf{R}$ representará seu valor calculado a partir de uma amostra observada.

A matriz $\mathcal{R}$ possui a forma

$$\mathcal{R} = \begin{bmatrix} 1 & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{21} & 1 & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \cdots & 1 \end{bmatrix},$$

em que

$$\rho_{jk} = \text{Corr}(X_j, X_k) = \frac{\sigma_{jk}}{\sqrt{\sigma_{jj}\sigma_{kk}}}. \quad (8.23)$$

Equivalentemente,

$$\rho_{jk} = \text{Cov}(Z_j, Z_k).$$

A correlação é adimensional porque o numerador e o denominador de Equação 8.23 possuem as mesmas unidades.

A relação entre covariâncias e correlações pode ser invertida:

$$\Sigma = \mathbf{D}_{\Sigma}^{1/2} \mathcal{R} \mathbf{D}_{\Sigma}^{1/2}. \quad (8.24)$$

Portanto, Σ pode ser decomposta em dois elementos:

- $\mathbf{D}_\Sigma$ registra as variâncias e, consequentemente, as escalas marginais;
- $\mathcal{R}$ registra a estrutura de associação linear após a remoção dessas escalas.

A matriz de correlações isoladamente não permite recuperar as variâncias originais.

Exemplo 8.6 (Matriz de correlações obtida por uma transformação de padronização). Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

com vetor de médias μ e matriz de covariâncias

$$\Sigma = \begin{bmatrix} 16 & 12 \\ 12 & 25 \end{bmatrix}.$$

Os desvios-padrão populacionais são

$$\sqrt{\sigma_{11}} = 4 \quad \text{e} \quad \sqrt{\sigma_{22}} = 5.$$

Portanto,

$$\mathbf{D}_\Sigma = \begin{bmatrix} 16 & 0 \\ 0 & 25 \end{bmatrix}$$

e

$$\mathbf{D}_\Sigma^{-1/2} = \begin{bmatrix} 1/4 & 0 \\ 0 & 1/5 \end{bmatrix}.$$

Considere a transformação de padronização

$$\mathbf{Z} = \mathbf{D}_\Sigma^{-1/2} (\mathbf{X} - \mu).$$

Ela pode ser escrita como a transformação afim

$$\mathbf{Z} = \mathbf{A}\mathbf{X} + \mathbf{c},$$

com

$$\mathbf{A} = \mathbf{D}_\Sigma^{-1/2}$$

e

$$\mathbf{c} = -\mathbf{D}_{\Sigma}^{-1/2} \mu.$$

Utilizando Proposição 8.6,

$$\text{Cov}(\mathbf{Z}) = \mathbf{A}\Sigma\mathbf{A}^{\top}.$$

Como $\mathbf{A}$ é diagonal e simétrica,

$$\begin{aligned} \text{Cov}(\mathbf{Z}) &= \begin{bmatrix} 1/4 & 0 \\ 0 & 1/5 \end{bmatrix} \begin{bmatrix} 16 & 12 \\ 12 & 25 \end{bmatrix} \begin{bmatrix} 1/4 & 0 \\ 0 & 1/5 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 3/5 \\ 3/5 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0,6 \\ 0,6 & 1 \end{bmatrix}. \end{aligned}$$

Essa é precisamente a matriz de correlações populacional,

$$\mathcal{R} = \begin{bmatrix} 1 & 0,6 \\ 0,6 & 1 \end{bmatrix}.$$

De fato,

$$\rho_{12} = \frac{\sigma_{12}}{\sqrt{\sigma_{11}\sigma_{22}}} = \frac{12}{\sqrt{16 \cdot 25}} = \frac{12}{20} = 0,6.$$

O exemplo mostra duas formas equivalentes de chegar ao mesmo resultado. Pela transformação do vetor,

$$\text{padronizar } \mathbf{X} \implies \text{Cov}(\mathbf{Z}).$$

Equivalentemente, pode-se transformar diretamente a matriz de covariâncias:

$$\Sigma \implies \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}.$$

Em ambas as perspectivas, as variâncias tornam-se unitárias e a covariância entre as componentes padronizadas passa a coincidir com sua correlação.

8.4.2 Propriedades, escala e independência

Proposição 8.8 (Caracterização das matrizes de correlações). *Uma matriz*

$$\mathbf{C} \in \mathbb{R}^{p \times p}$$

é matriz de correlações de algum vetor aleatório com variâncias marginais positivas se, e somente se,

$$\mathbf{C} = \mathbf{C}^\top,$$

$$\mathbf{C} \succeq \mathbf{0}$$

e

$$c_{jj} = 1, \quad j = 1, \dots, p.$$

Consequentemente, toda matriz de correlações possui:

- 1. elementos no intervalo $[-1, 1]$;*
- 2. autovalores reais e não negativos;*
- 3. traço igual a p .*



i Demonstração

Se $\mathbf{C} = \mathcal{R}$ é uma matriz de correlações, então

$$\mathcal{R} = \mathbf{D}_\Sigma^{-1/2} \Sigma \mathbf{D}_\Sigma^{-1/2}.$$

Como Σ é simétrica,

$$\mathcal{R}^\top = \mathcal{R}.$$

Além disso, para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\begin{aligned} \mathbf{a}^\top \mathcal{R} \mathbf{a} &= (\mathbf{D}_\Sigma^{-1/2} \mathbf{a})^\top \Sigma (\mathbf{D}_\Sigma^{-1/2} \mathbf{a}) \\ &\geq 0, \end{aligned}$$

de modo que

$$\mathcal{R} \succeq \mathbf{0}.$$

A diagonal é unitária porque

$$\rho_{jj} = \frac{\sigma_{jj}}{\sqrt{\sigma_{jj}\sigma_{jj}}} = 1.$$

Reciprocamente, suponha que $\mathbf{C}$ seja simétrica, positiva semidefinida e possua diagonal unitária. Pela raiz quadrada principal definida na Definição 5.7, existe $\mathbf{C}^{1/2}$ tal que

$$\mathbf{C} = \mathbf{C}^{1/2} \mathbf{C}^{1/2}.$$

Considere um vetor aleatório

$$\mathbf{U} = (U_1, \dots, U_p)^\top,$$

cujas componentes são independentes e satisfazem

$$P(U_j = 1) = P(U_j = -1) = \frac{1}{2}.$$

Então,

Se Σ possui variâncias marginais positivas, então $\mathbf{D}_\Sigma^{-1/2}$ é invertível e a padronização preserva a definição positiva. Assim,

$$\mathcal{R} \succ \mathbf{0} \iff \Sigma \succ \mathbf{0}.$$

Os valores extremos da correlação correspondem a relações lineares exatas entre as variáveis padronizadas. Para $j \neq k$,

$$\rho_{jk} = 1 \iff Z_k = Z_j \quad \text{quase certamente,}$$

enquanto

$$\rho_{jk} = -1 \iff Z_k = -Z_j \quad \text{quase certamente.}$$

Portanto, uma correlação de módulo igual a 1 implica uma relação linear exata entre as duas variáveis e, conseqüentemente, a singularidade da matriz de covariâncias do par correspondente.

Além disso, não basta que cada correlação, considerada isoladamente, pertença ao intervalo $[-1, 1]$ para que uma matriz seja uma matriz de correlações válida; a matriz completa também deve ser positiva semidefinida.

Exemplo 8.7 (Matriz com diagonal unitária que não é uma matriz de correlações). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0,9 & 0,9 \\ 0,9 & 1 & -0,9 \\ 0,9 & -0,9 & 1 \end{bmatrix}.$$

Todos os elementos pertencem ao intervalo $[-1, 1]$, a matriz é simétrica e sua diagonal é unitária. Entretanto,

$$\det(\mathbf{A}) = -2,888 < 0.$$

Uma matriz positiva semidefinida não pode possuir determinante negativo. Logo, $\mathbf{A}$ não é uma matriz de correlações.

O exemplo mostra que as correlações entre pares devem ser compatíveis com uma única estrutura conjunta positiva semidefinida.

Duas componentes X_j e X_k são não correlacionadas quando

$$\rho_{jk} = 0.$$

Como suas variâncias são positivas,

$$\rho_{jk} = 0 \iff \sigma_{jk} = 0.$$

Essa condição não implica independência em uma distribuição geral, conforme ilustrado no Exemplo 8.1.

Se X_j e X_k são independentes e possuem segundos momentos finitos, então

$$E(X_j X_k) = E(X_j)E(X_k),$$

e, portanto,

$$\text{Cov}(X_j, X_k) = 0.$$

Assim,

$$\text{independência} \implies \text{correlação nula},$$

mas a recíproca depende de hipóteses adicionais.

Uma matriz de correlações diagonal necessariamente é

$$\mathcal{R} = \mathbf{I}_p.$$

Nesse caso, todas as componentes são duas a duas não correlacionadas. Essa propriedade não garante, por si só, independência conjunta. A relação especial entre ausência de correlação e independência sob normalidade conjunta será estabelecida no Capítulo 9.

Considere agora uma mudança de localização e escala aplicada separadamente às componentes:

$$Y_j = c_j X_j + d_j, \quad c_j \neq 0.$$

Tem-se

$$\text{Cov}(Y_j, Y_k) = c_j c_k \sigma_{jk},$$

enquanto

$$\text{Var}(Y_j) = c_j^2 \sigma_{jj}.$$

Consequentemente,

$$\text{Corr}(Y_j, Y_k) = \text{sgn}(c_j) \text{sgn}(c_k) \rho_{jk}. \quad (8.25)$$

Se $c_j > 0$ e $c_k > 0$,

$$\text{Corr}(Y_j, Y_k) = \rho_{jk}.$$

Portanto, translações e mudanças positivas de unidade não alteram a correlação. A multiplicação de uma variável por uma constante negativa inverte o sinal de suas correlações, sem alterar seus módulos.

Exemplo 8.8 (Conversão de covariâncias em correlações). Retome a matriz de covariâncias do Exemplo 8.2:

$$\Sigma = \begin{bmatrix} 4 & 1,5 & -0,8 \\ 1,5 & 9 & 0 \\ -0,8 & 0 & 1 \end{bmatrix}.$$

A matriz das variâncias marginais é

$$\mathbf{D}_{\Sigma} = \begin{bmatrix} 4 & 0 & 0 \\ 0 & 9 & 0 \\ 0 & 0 & 1 \end{bmatrix},$$

de modo que

$$\mathbf{D}_{\Sigma}^{-1/2} = \begin{bmatrix} 1/2 & 0 & 0 \\ 0 & 1/3 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

Pela expressão Equação 8.22,

$$\begin{aligned} \mathcal{R} &= \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2} \\ &= \begin{bmatrix} 1 & 0,25 & -0,4 \\ 0,25 & 1 & 0 \\ -0,4 & 0 & 1 \end{bmatrix}. \end{aligned}$$

Por exemplo,

$$\rho_{12} = \frac{1,5}{\sqrt{4 \cdot 9}} = 0,25,$$

enquanto

$$\rho_{13} = \frac{-0,8}{\sqrt{4 \cdot 1}} = -0,4.$$

Embora

$$|\sigma_{12}| > |\sigma_{13}|,$$

tem-se

$$|\rho_{13}| > |\rho_{12}|.$$

A covariância entre X_1 e X_2 possui maior módulo nas unidades originais, mas a associação linear padronizada entre X_1 e X_3 é mais intensa. A comparação evidencia a diferença entre a informação fornecida por covariâncias e por correlações.

A matriz de covariâncias preserva as variâncias e as unidades originais das componentes. A matriz de correlações descreve a mesma estrutura de segunda ordem após a padronização marginal, atribuindo variância unitária a todas as componentes. Essa mudança de escala pode alterar a geometria da dispersão e será considerada na interpretação espectral das duas matrizes.

8.5 Geometria e medidas globais da dispersão

8.5.1 Eixos espectrais e elipsoide de covariância

A expressão Equação 8.10 mostra que a matriz de covariâncias associa a cada direção $\mathbf{a} \in \mathbb{R}^p$ a variância

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

Quando $\|\mathbf{a}\| = 1$, essa quantidade representa a dispersão ao longo da direção unitária $\mathbf{a}$. A interpretação espectral das formas quadráticas foi desenvolvida no Capítulo 5. Aplicando o Teorema 5.2 à matriz simétrica positiva semidefinida Σ ,

$$\Sigma = \mathbf{Q}\Lambda\mathbf{Q}^\top, \quad (8.26)$$

em que

$$\mathbf{Q} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p]$$

é ortogonal e

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p), \quad \lambda_j \geq 0.$$

A transformação

$$\mathbf{Y} = \mathbf{Q}^\top (\mathbf{X} - \mu) \quad (8.27)$$

expressa o vetor centralizado nas coordenadas da base de autovetores. Pela regra de transformação da covariância,

$$\text{Cov}(\mathbf{Y}) = \mathbf{Q}^\top \Sigma \mathbf{Q} = \Lambda. \quad (8.28)$$

Portanto,

$$\text{Var}(Y_j) = \lambda_j$$

e

$$\text{Cov}(Y_j, Y_k) = 0, \quad j \neq k.$$

Os autovetores $\mathbf{q}_1, \dots, \mathbf{q}_p$ serão denominados **eixos espectrais da covariância**. O autovalor λ_j quantifica a variância ao longo do eixo $\mathbf{q}_j$.

Se

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p \geq 0,$$

o resultado sobre os extremos do quociente de Rayleigh no Teorema 5.3 fornece

$$\lambda_p \leq \mathbf{a}^\top \Sigma \mathbf{a} \leq \lambda_1, \quad \|\mathbf{a}\| = 1. \quad (8.29)$$

Os valores extremos são alcançados nos autovetores correspondentes. Assim, a decomposição espectral identifica direções ortogonais nas quais as covariâncias desaparecem e as variâncias são dadas diretamente pelos autovalores.

Neste capítulo, essa decomposição é utilizada somente para descrever a geometria da dispersão. A seleção de eixos espectrais para construir uma representação de dimensão reduzida pertence à formulação da Análise de Componentes Principais.

Exemplo 8.9 (Obtenção dos eixos de maior e menor variabilidade). Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

com matriz de covariâncias

$$\Sigma = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}.$$

Queremos determinar a direção unitária

$$\mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \end{bmatrix}, \quad \mathbf{a}^\top \mathbf{a} = 1,$$

na qual a combinação linear

$$Y = \mathbf{a}^\top \mathbf{X}$$

apresenta a maior variância possível.

Pela expressão Equação 8.10,

$$\text{Var}(Y) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

Portanto, o problema é

$$\max_{\mathbf{a}} \quad \mathbf{a}^\top \Sigma \mathbf{a}$$

sujeito a

$$\mathbf{a}^\top \mathbf{a} = 1.$$

Esse é precisamente o tipo de problema de otimização com restrição estudado no Módulo 1. Como maximizar uma função equivale a minimizar seu negativo, a condição necessária de Lagrange estabelecida no Teorema 7.6 aplica-se também a este problema. Considere

$$\mathcal{L}(\mathbf{a}, \eta) = \mathbf{a}^\top \Sigma \mathbf{a} - \eta (\mathbf{a}^\top \mathbf{a} - 1).$$

Como Σ é simétrica,

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \Sigma \mathbf{a}) = 2\Sigma \mathbf{a}$$

e

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{a}) = 2\mathbf{a}.$$

A condição de primeira ordem é, portanto,

$$2\Sigma \mathbf{a} - 2\eta \mathbf{a} = \mathbf{0},$$

ou

$$\Sigma \mathbf{a} = \eta \mathbf{a}. \tag{8.30}$$

Assim, as direções estacionárias do problema são autovetores de Σ , e os multiplicadores de Lagrange correspondentes são seus autovalores.

Para determiná-los,

$$\det(\Sigma - \eta \mathbf{I}_2) = 0.$$

Logo,

$$\begin{aligned} \det \begin{bmatrix} 4-\eta & 2 \\ 2 & 4-\eta \end{bmatrix} &= (4-\eta)^2 - 4 \\ &= \eta^2 - 8\eta + 12 \\ &= (\eta - 6)(\eta - 2). \end{aligned}$$

Os autovalores são, portanto,

$$\lambda_1 = 6 \quad \text{e} \quad \lambda_2 = 2.$$

Para $\lambda_1 = 6$,

$$(\Sigma - 6\mathbf{I}_2) \mathbf{a} = \mathbf{0}$$

produz

$$a_1 = a_2.$$

Impondo a restrição de norma unitária,

$$a_1^2 + a_2^2 = 1,$$

podemos escolher

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Para $\lambda_2 = 2$,

$$(\Sigma - 2\mathbf{I}_2) \mathbf{a} = \mathbf{0}$$

produz

$$a_1 = -a_2,$$

e podemos escolher

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Pelo resultado dos extremos do quociente de Rayleigh no Teorema [5.3](#),

$$\max_{\|\mathbf{a}\|=1} \mathbf{a}^\top \Sigma \mathbf{a} = \lambda_1 = 6,$$

alcançado na direção $\mathbf{q}_1$, enquanto

$$\min_{\|\mathbf{a}\|=1} \mathbf{a}^\top \Sigma \mathbf{a} = \lambda_2 = 2,$$

alcançado na direção $\mathbf{q}_2$.

Consequentemente,

$$\text{Var}(\mathbf{q}_1^\top \mathbf{X}) = 6$$

e

$$\text{Var}(\mathbf{q}_2^\top \mathbf{X}) = 2.$$

Reunindo os autovetores em

$$\mathbf{Q} = [\mathbf{q}_1 \quad \mathbf{q}_2] = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix},$$

a transformação

$$\mathbf{Y} = \mathbf{Q}^\top (\mathbf{X} - \mu)$$

produz

$$\text{Cov}(\mathbf{Y}) = \mathbf{Q}^\top \Sigma \mathbf{Q} = \begin{bmatrix} 6 & 0 \\ 0 & 2 \end{bmatrix}.$$

O cálculo mostra concretamente a conexão entre **variância de uma combinação linear, otimização restrita e decomposição espectral**: os autovetores da matriz de covariâncias surgem como as direções estacionárias da variância sob a restrição de norma unitária, e os autovalores fornecem as variâncias nessas direções.

As direções espectrais obtidas acima caracterizam a geometria da matriz de covariâncias. Na Análise de Componentes Principais, essas direções também determinam uma representação de dimensão reduzida.

Quando Σ é diagonal, os eixos espectrais coincidem com os eixos coordenados. No caso particular

$$\Sigma = \sigma^2 \mathbf{I}_p, \tag{8.31}$$

tem-se, para qualquer vetor unitário $\mathbf{a}$,

$$\mathbf{a}^\top \Sigma \mathbf{a} = \sigma^2.$$

A condição Equação 8.31 descreve uma estrutura de segunda ordem isotrópica: a variância é a mesma em todas as direções. Essa condição, isoladamente, não implica que a distribuição de $\mathbf{X}$ seja esfericamente simétrica.

Suponha agora que

$$\Sigma \succ \mathbf{0}.$$

Para $c > 0$, considere

$$\mathcal{E}_c = \left\{ \mathbf{x} \in \mathbb{R}^p : (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \leq c^2 \right\}. \quad (8.32)$$

A interpretação das superfícies de nível de formas quadráticas positivas definidas foi estabelecida no Capítulo 5. Neste caso, utilizando Equação 8.26 e definindo

$$\mathbf{y} = \mathbf{Q}^\top (\mathbf{x} - \mu),$$

a condição que define $\mathcal{E}_c$ torna-se

$$\sum_{j=1}^p \frac{y_j^2}{c^2 \lambda_j} \leq 1. \quad (8.33)$$

Portanto:

- o centro é μ ;
- os eixos possuem as direções $\mathbf{q}_1, \dots, \mathbf{q}_p$;
- o semieixo associado a $\mathbf{q}_j$ possui comprimento $c\sqrt{\lambda_j}$.

Assim, autovalores maiores correspondem a maior extensão da dispersão na direção associada.

A Figura 8.3 mostra essa geometria no caso bidimensional.

A orientação da elipse é determinada pelos autovetores, enquanto suas extensões dependem das raízes quadradas dos autovalores. A matriz de covariâncias determina, assim, uma geometria de segunda ordem para a dispersão conjunta.

Interpretação probabilística do elipsoide

O conjunto $\mathcal{E}_c$ é definido somente por μ e Σ . Sem uma hipótese adicional sobre a distribuição de $\mathbf{X}$, não se pode atribuir a esse elipsoide uma probabilidade específica nem interpretá-lo como região de confiança. A interpretação probabilística dessas superfícies será desenvolvida no Capítulo 9 para a distribuição normal multivariada.




Figura 8.3: Elipse associada a uma matriz de covariâncias e seus eixos espectrais.

Quando Σ é singular, a variabilidade está restrita ao subespaço

$$\mathcal{C}(\Sigma).$$

A raiz quadrada principal definida na Definição 5.7 permite representar o elipsoide degenerado por

$$\mathcal{E}_c^{(r)} = \left\{ \mu + \Sigma^{1/2} \mathbf{u} : \|\mathbf{u}\| \leq c \right\}, \quad (8.34)$$

em que

$$r = \text{posto}(\Sigma) < p.$$

Esse conjunto está contido no subespaço afim

$$\mu + \mathcal{C}(\Sigma)$$

e possui r semieixos não nulos, com comprimentos $c\sqrt{\lambda_j}$ para os autovalores positivos. No Capítulo 9, a pseudoinversa de Moore–Penrose será utilizada para estender ao suporte efetivo a forma quadrática associada à distância de Mahalanobis quando Σ for singular.

8.5.2 Variância total e variância generalizada

Uma matriz de covariâncias contém toda a estrutura de segunda ordem do vetor aleatório. Algumas funções escalares de Σ resumem aspectos específicos dessa dispersão, mas nenhuma delas substitui a matriz completa.

Definição 8.6 (Variância total). Se $\mathbf{X} \in \mathbb{R}^p$ possui matriz de covariâncias Σ , sua **variância total** é

$$V_T(\mathbf{X}) = \text{tr}(\Sigma). \quad (8.35)$$

Pela definição de traço na Definição 2.8,

$$\text{tr}(\Sigma) = \sum_{j=1}^p \text{Var}(X_j). \quad (8.36)$$

Pela decomposição espectral,

$$\text{tr}(\Sigma) = \sum_{j=1}^p \lambda_j. \quad (8.37)$$

A variância total também possui uma interpretação em termos de esperança matemática. Mais geralmente, seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica e seja $\mathbf{a} \in \mathbb{R}^p$ um vetor fixo. Então,

$$E \left[(\mathbf{X} - \mathbf{a})^\top \mathbf{A} (\mathbf{X} - \mathbf{a}) \right] = \text{tr}(\mathbf{A}\Sigma) + (\mu - \mathbf{a})^\top \mathbf{A} (\mu - \mathbf{a}). \quad (8.38)$$

De fato,

$$\mathbf{X} - \mathbf{a} = (\mathbf{X} - \mu) + (\mu - \mathbf{a}),$$

e, ao expandir a forma quadrática, os termos cruzados possuem esperança nula porque

$$E(\mathbf{X} - \mu) = \mathbf{0}.$$

Além disso,

$$E \left[(\mathbf{X} - \mu)^\top \mathbf{A} (\mathbf{X} - \mu) \right] = \text{tr}(\mathbf{A}\Sigma).$$

Tomando

$$\mathbf{A} = \mathbf{I}_p \quad \text{e} \quad \mathbf{a} = \mu,$$

obtém-se

$$E \left[\|\mathbf{X} - \mu\|^2 \right] = \text{tr}(\Sigma). \quad (8.39)$$

Portanto, a variância total é o afastamento euclidiano quadrático médio do vetor aleatório em relação ao seu vetor de médias.

Mais geralmente, tomando $\mathbf{A} = \mathbf{I}_p$,

$$E \left[\|\mathbf{X} - \mathbf{a}\|^2 \right] = \text{tr}(\Sigma) + \|\mu - \mathbf{a}\|^2. \quad (8.40)$$

Essa expressão mostra que μ minimiza o afastamento quadrático médio:

$$E \left[\|\mathbf{X} - \mathbf{a}\|^2 \right] \geq E \left[\|\mathbf{X} - \mu\|^2 \right].$$

Como

$$\text{tr}(\Sigma) = \sum_{j=1}^p \lambda_j,$$

segue também que

$$E[\|\mathbf{X} - \mu\|^2] = \sum_{j=1}^p \lambda_j.$$

Assim, a mesma quantidade pode ser interpretada como soma das variâncias marginais, soma das variâncias nos eixos espectrais ou afastamento euclidiano quadrático médio em relação ao centro.

Outra medida utiliza o determinante da matriz de covariâncias.

Definição 8.7 (Variância generalizada). Se $\mathbf{X} \in \mathbb{R}^p$ possui matriz de covariâncias Σ , sua **variância generalizada** é

$$V_G(\mathbf{X}) = \det(\Sigma). \quad (8.41)$$

Pelas propriedades do determinante e pela decomposição espectral,

$$\det(\Sigma) = \prod_{j=1}^p \lambda_j. \quad (8.42)$$

A variância generalizada reúne multiplicativamente as dispersões nos eixos espectrais. Se pelo menos um autovalor é zero,

$$\det(\Sigma) = 0,$$

mesmo que exista variabilidade nas demais direções. Nesse caso, o valor zero indica que a dispersão ocupa um subespaço de dimensão inferior a p ; não indica ausência de variabilidade.

Exemplo 8.10 (Variância total e variância generalizada). Considere

$$\Sigma_1 = \begin{bmatrix} 4 & 0 \\ 0 & 4 \end{bmatrix}$$

e

$$\Sigma_2 = \begin{bmatrix} 7 & 0 \\ 0 & 1 \end{bmatrix}.$$

As duas matrizes possuem a mesma variância total:

$$\text{tr}(\Sigma_1) = \text{tr}(\Sigma_2) = 8.$$

Entretanto,

$$\det(\Sigma_1) = 16$$

e

$$\det(\Sigma_2) = 7.$$

A primeira configuração distribui a variabilidade igualmente entre os dois eixos. A segunda concentra maior variabilidade em uma direção e menor variabilidade na outra. A igualdade das variâncias totais não implica, portanto, igualdade da geometria da dispersão.

A forma quadrática que define o elipsoide fornece também uma medida de afastamento adaptada à estrutura de covariâncias. Essa medida é a distância de Mahalanobis.

8.6 Distância de Mahalanobis

A distância euclidiana utiliza a mesma geometria em todas as direções. Em dados multivariados, entretanto, um deslocamento pode representar um afastamento pequeno em uma direção de grande variabilidade e um afastamento expressivo em outra direção de pequena variabilidade.

A distância de Mahalanobis incorpora essa estrutura por meio da matriz de covariâncias. No caso univariado, ela reduz o afastamento $|x - \mu|$ à sua escala natural,

$$\frac{|x - \mu|}{\sigma}.$$

Definição 8.8 (Distância de Mahalanobis). Se $\Sigma \in \mathbb{R}^{p \times p}$ é positiva definida, a **distância de Mahalanobis** entre $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, em relação a Σ , é

$$d_M(\mathbf{x}, \mathbf{y}; \Sigma) = \sqrt{(\mathbf{x} - \mathbf{y})^\top \Sigma^{-1} (\mathbf{x} - \mathbf{y})}. \quad (8.43)$$

Em particular, a distância de $\mathbf{x}$ ao vetor de médias é

$$d_M(\mathbf{x}, \mu) = \sqrt{(\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu)}. \quad (8.44)$$

8.6.1 Interpretação geométrica e espectral

O quadrado da distância de Mahalanobis de $\mathbf{x}$ ao vetor de médias é

$$d_M^2(\mathbf{x}, \mu) = (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu). \quad (8.45)$$

Como $\Sigma^{-1} \succ \mathbf{0}$, ela define o produto interno induzido apresentado na Definição 3.16 e a norma correspondente de Definição 3.17. Assim, Equação 8.43 é uma distância métrica, sem necessidade de repetir aqui a demonstração das propriedades métricas desenvolvidas no Módulo 1.

Quando

$$\Sigma = \mathbf{I}_p,$$

a distância de Mahalanobis coincide com a distância euclidiana. Quando $p = 1$,

$$d_M(x, \mu) = \frac{|x - \mu|}{\sigma}.$$

A medida é adimensional, pois a inversa da matriz de covariâncias compensa as unidades presentes no vetor de diferenças.

A interpretação espectral decorre diretamente de Equação 8.26. Se

$$\mathbf{u} = \mathbf{Q}^\top (\mathbf{x} - \mu),$$

então

$$d_M^2(\mathbf{x}, \mu) = \sum_{j=1}^p \frac{u_j^2}{\lambda_j}. \quad (8.46)$$

Essa expressão mostra como a distância de Mahalanobis incorpora a geometria da dispersão. Cada componente u_j representa o deslocamento de $\mathbf{x} - \mu$ na direção do autovetor correspondente, enquanto λ_j é a variância nessa direção.

Cada deslocamento é, portanto, ponderado pelo inverso da variância na direção correspondente. Um mesmo deslocamento geométrico recebe menor peso em uma direção de grande variabilidade e maior peso em uma direção de pequena variabilidade.

Exemplo 8.11 (Afastamentos em direções com variâncias distintas). Considere dois eixos espectrais com

$$\lambda_1 = 9 \quad \text{e} \quad \lambda_2 = 1.$$

Um afastamento de magnitude 2 ao longo do primeiro eixo produz

$$d_M^2 = \frac{2^2}{9} = \frac{4}{9}.$$

O mesmo afastamento ao longo do segundo produz

$$d_M^2 = \frac{2^2}{1} = 4.$$

Os dois pontos possuem a mesma distância euclidiana ao centro, mas o segundo apresenta maior distância de Mahalanobis porque se encontra em uma direção com menor dispersão populacional.

As superfícies de igual distância,

$$d_M(\mathbf{x}, \mu) = c,$$

são exatamente as fronteiras dos elipsoides definidos na Equação 8.32. Isso reforça a interpretação geométrica da distância de Mahalanobis: pontos pertencentes à mesma superfície elipsoidal apresentam o mesmo afastamento em relação ao centro quando a estrutura de covariâncias é considerada.

A Figura 8.4 compara dois deslocamentos com a mesma distância euclidiana ao centro, mas orientados segundo eixos de dispersão distintos.

O ponto situado no eixo de menor variância pertence a uma curva de maior distância de Mahalanobis. A medida compara o deslocamento com a quantidade de variabilidade disponível na direção em que ele ocorre.




Figura 8.4: Pontos com a mesma distância euclidiana podem apresentar distâncias de Mahalanobis distintas.

8.6.2 Branqueamento e esferização

Uma forma alternativa de compreender a geometria associada à matriz de covariâncias consiste em transformar as coordenadas de modo que a variabilidade resultante seja a mesma em todas as direções.

Seja $\mathbf{X}$ um vetor aleatório com vetor de médias μ e matriz de covariâncias $\Sigma \succ \mathbf{0}$. Uma transformação linear da forma

$$\mathbf{Z} = \mathbf{W}(\mathbf{X} - \mu)$$

é denominada **branqueamento** (*whitening*) quando a matriz $\mathbf{W}$ é escolhida de modo que

$$\text{Cov}(\mathbf{Z}) = \mathbf{W}\Sigma\mathbf{W}^\top = \mathbf{I}_p.$$

Assim, as componentes do vetor branqueado possuem variância unitária e covariâncias nulas entre si. O termo **esferização** enfatiza a interpretação geométrica da mesma transformação: os elipsoides associados à estrutura de covariâncias são transformados em esferas.

Essa interpretação refere-se à estrutura de segunda ordem do vetor aleatório, representada pela matriz de covariâncias. Em geral, o branqueamento não implica que toda a distribuição do vetor transformado seja esfericamente simétrica.

A raiz quadrada inversa de uma matriz positiva definida foi construída no Capítulo 5 a partir da raiz quadrada principal dada na Definição 5.7. Uma escolha para a matriz de branqueamento é

$$\mathbf{W} = \Sigma^{-1/2},$$

pois

$$\Sigma^{-1/2}\Sigma\Sigma^{-1/2} = \mathbf{I}_p.$$

Essa escolha é denominada **branqueamento simétrico**. Ela remove simultaneamente as diferenças de variância e as covariâncias entre as componentes. Para um ponto $\mathbf{x}$, a transformação correspondente é

$$\mathbf{z} = \Sigma^{-1/2}(\mathbf{x} - \mu). \quad (8.47)$$

Para o vetor aleatório,

$$\mathbf{Z} = \Sigma^{-1/2}(\mathbf{X} - \mu),$$

tem-se

$$E(\mathbf{Z}) = \mathbf{0} \quad \text{e} \quad \text{Cov}(\mathbf{Z}) = \mathbf{I}_p. \quad (8.48)$$

A transformação de branqueamento também permite interpretar diretamente a distância de Mahalanobis. De Equação 8.47,

$$\begin{aligned} \|\mathbf{z}\|^2 &= (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \\ &= d_M^2(\mathbf{x}, \mu). \end{aligned}$$

Logo,

$$d_M(\mathbf{x}, \mu) = \left\| \Sigma^{-1/2} (\mathbf{x} - \mu) \right\|. \quad (8.49)$$

A distância de Mahalanobis é, portanto, a distância euclidiana após a centralização e o branqueamento.

A esperança da distância quadrática de Mahalanobis também depende apenas da matriz de covariâncias. Como

$$d_M^2(\mathbf{X}, \mu) = (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu),$$

a expressão Equação 8.38, com

$$\mathbf{A} = \Sigma^{-1},$$

fornece

$$\begin{aligned} E[d_M^2(\mathbf{X}, \mu)] &= \text{tr}(\Sigma^{-1} \Sigma) \\ &= \text{tr}(\mathbf{I}_p) \\ &= p. \end{aligned} \quad (8.50)$$

A identidade Equação 8.50 exige apenas a existência de μ e $\Sigma \succ \mathbf{0}$; a normalidade não é necessária. No Capítulo 9, a hipótese de normalidade multivariada permite caracterizar a distribuição completa da distância quadrática de Mahalanobis, da qual $E[d_M^2(\mathbf{X}, \mu)] = p$ é uma consequência.

Exemplo 8.12 (Branqueamento a partir da decomposição espectral). Retome a matriz de covariâncias do Exemplo 8.9,

$$\Sigma = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}.$$

Sua decomposição espectral é

$$\Sigma = \mathbf{Q}\Lambda\mathbf{Q}^\top,$$

com

$$\mathbf{Q} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

e

$$\Lambda = \begin{bmatrix} 6 & 0 \\ 0 & 2 \end{bmatrix}.$$

Utilizando a raiz quadrada inversa desenvolvida no Módulo 1,

$$\Sigma^{-1/2} = \mathbf{Q}\Lambda^{-1/2}\mathbf{Q}^\top,$$

em que

$$\Lambda^{-1/2} = \begin{bmatrix} 1/\sqrt{6} & 0 \\ 0 & 1/\sqrt{2} \end{bmatrix}.$$

Defina

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu).$$

Então,

$$\begin{aligned} \text{Cov}(\mathbf{Z}) &= \Sigma^{-1/2} \Sigma \Sigma^{-1/2} \\ &= \mathbf{Q}\Lambda^{-1/2}\mathbf{Q}^\top \mathbf{Q}\Lambda\mathbf{Q}^\top \mathbf{Q}\Lambda^{-1/2}\mathbf{Q}^\top \\ &= \mathbf{Q}\Lambda^{-1/2}\Lambda\Lambda^{-1/2}\mathbf{Q}^\top \\ &= \mathbf{Q}\mathbf{I}_2\mathbf{Q}^\top \\ &= \mathbf{I}_2. \end{aligned}$$

A transformação pode ser compreendida em três etapas:

$$\begin{aligned} \mathbf{X} - \mu &\xrightarrow{\mathbf{Q}^\top} \text{coordenadas nos eixos espectrais} \\ &\xrightarrow{\Lambda^{-1/2}} \text{reescalonamento para variância unitária} \\ &\xrightarrow{\mathbf{Q}} \mathbf{Z}. \end{aligned}$$

O primeiro passo expressa o vetor na base de autovetores de Σ , na qual a matriz de covariâncias é diagonal. O segundo divide cada coordenada por $\sqrt{\lambda_j}$, tornando todas as variâncias iguais a 1. O terceiro retorna ao sistema original de coordenadas por meio da transformação ortogonal $\mathbf{Q}$.

Considere agora um ponto cuja diferença em relação ao centro é

$$\mathbf{x} - \mu = \begin{bmatrix} 2 \\ 0 \end{bmatrix}.$$

Suas coordenadas espectrais são

$$\mathbf{Q}^\top (\mathbf{x} - \mu) = \begin{bmatrix} \sqrt{2} \\ \sqrt{2} \end{bmatrix}.$$

Pela expressão Equação 8.46,

$$\begin{aligned} d_M^2(\mathbf{x}, \mu) &= \frac{(\sqrt{2})^2}{6} + \frac{(\sqrt{2})^2}{2} \\ &= \frac{2}{6} + \frac{2}{2} \\ &= \frac{4}{3}. \end{aligned}$$

Por outro lado,

$$\left\| \Sigma^{-1/2} (\mathbf{x} - \mu) \right\|^2 = \frac{4}{3}.$$

Assim, o exemplo verifica concretamente a identidade

$$d_M(\mathbf{x}, \mu) = \left\| \Sigma^{-1/2} (\mathbf{x} - \mu) \right\|.$$

A decomposição espectral, a raiz matricial, o branqueamento e a distância de Mahalanobis aparecem, portanto, como partes de uma mesma construção geométrica.

O branqueamento não é único. De fato, se $\mathbf{Q}_0$ é uma matriz ortogonal, então

$$\mathbf{W} = \mathbf{Q}_0 \Sigma^{-1/2}$$

também satisfaz

$$\mathbf{W} \Sigma \mathbf{W}^\top = \mathbf{I}_p.$$

Portanto, diferentes transformações podem produzir vetores com matriz de covariâncias igual à identidade. Essas versões diferem por uma transformação ortogonal e, conseqüentemente, preservam as distâncias euclidianas no espaço branqueado.

A padronização marginal e o branqueamento devem ser distinguidos. Pela expressão Equação 8.22, a padronização marginal produz

$$\text{Cov} \left(\mathbf{D}_\Sigma^{-1/2} (\mathbf{X} - \mu) \right) = \mathcal{R}.$$

Assim, a padronização marginal torna as variâncias iguais a 1, mas a matriz resultante pode apresentar correlações não nulas fora da diagonal. O branqueamento, por sua vez, utiliza a estrutura completa da matriz de covariâncias e produz

$$\text{Cov} (\mathbf{Z}) = \mathbf{I}_p.$$

Se

$$\mathbf{z}_D = \mathbf{D}_\Sigma^{-1/2} (\mathbf{x} - \mu),$$

a relação

$$\Sigma = \mathbf{D}_\Sigma^{1/2} \mathcal{R} \mathbf{D}_\Sigma^{1/2}$$

implica

$$d_M^2(\mathbf{x}, \mu) = \mathbf{z}_D^\top \mathcal{R}^{-1} \mathbf{z}_D. \quad (8.51)$$

Assim, a padronização marginal remove as escalas individuais, enquanto $\mathcal{R}^{-1}$ incorpora a associação linear remanescente. Somente quando

$$\mathcal{R} = \mathbf{I}_p$$

a distância de Mahalanobis coincide com a distância euclidiana entre as coordenadas marginalmente padronizadas.

8.7 Representação descritiva a partir dos dados

As matrizes Σ e $\mathcal{R}$ são objetos populacionais. Quando se dispõe de um conjunto de dados observado, a localização e a dispersão conjunta podem ser representadas por quantidades calculadas diretamente a partir das observações.

Nesta seção,

$$\bar{\mathbf{x}}, \quad \mathbf{S} \quad \text{e} \quad \mathbf{R}$$

representam valores obtidos de uma matriz de dados específica. Quando as linhas dessa matriz forem consideradas realizações de uma amostra aleatória, esses valores corresponderão a realizações das estatísticas

$$\bar{\mathbf{X}}, \quad \mathbf{S} \quad \text{e} \quad \mathbf{R}.$$

As propriedades dessas estatísticas como estimadores serão desenvolvidas no Capítulo 10.

8.7.1 Centralização, SQPC e matriz de covariâncias observada

Considere $n \geq 2$ observações de p variáveis organizadas, conforme Definição 1.6, em

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p},$$

em que

$$\mathbf{x}_i \in \mathbb{R}^p$$

representa a i -ésima observação.

O vetor de médias das colunas é

$$\bar{\mathbf{x}} = \frac{1}{n} \mathbf{X}^\top \mathbf{1}_n \in \mathbb{R}^p, \quad (8.52)$$

em que

$$\mathbf{1}_n = (1, \dots, 1)^\top \in \mathbb{R}^n.$$

A matriz de dados centralizada é

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top. \quad (8.53)$$

Cada linha de $\mathbf{X}_c$ é

$$(\mathbf{x}_i - \bar{\mathbf{x}})^\top,$$

e suas colunas satisfazem

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{0}^\top. \quad (8.54)$$

Retomando a matriz de centralização utilizada no Capítulo 4,

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top,$$

tem-se

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}. \quad (8.55)$$

A operação remove a localização das colunas sem alterar as diferenças entre as observações, conforme a propriedade estabelecida na Proposição 4.12.

Definição 8.9 (Matriz total de somas de quadrados e produtos cruzados). A **matriz total de somas de quadrados e produtos cruzados**, ou matriz total SQPC, é

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

Equivalentemente,

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c = \mathbf{X}^\top \mathbf{H}_n \mathbf{X}. \quad (8.56)$$

A sigla **SQPC** significa **Somas de Quadrados e Produtos Cruzados** e será utilizada como equivalente, em português, à sigla inglesa **SSCP**, de *sum of squares and cross-products*. O elemento (j, k) de $\mathbf{T}$ é

$$t_{jk} = \sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k).$$

Quando $j = k$, t_{jj} é a soma dos quadrados dos desvios da variável j . Quando $j \neq k$, t_{jk} é a soma dos produtos cruzados entre as variáveis j e k .

Como

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c,$$

ela é uma matriz de Gram das colunas centralizadas no sentido de Definição 3.18. Assim, pelas propriedades estabelecidas na Proposição 3.9,

$$\mathbf{T} = \mathbf{T}^\top,$$

$$\mathbf{T} \succeq \mathbf{0}$$

e

$$\text{posto}(\mathbf{T}) = \text{posto}(\mathbf{X}_c).$$

A centralização impõe

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{0}^\top,$$

de modo que as colunas de $\mathbf{X}_c$ pertencem ao subespaço ortogonal a $\mathbf{1}_n$, cuja dimensão é $n - 1$. Consequentemente,

$$\text{posto}(\mathbf{T}) = \text{posto}(\mathbf{X}_c) \leq \min(p, n - 1). \quad (8.57)$$

A matriz $\mathbf{T}$ registra a dispersão sem uma normalização pelo número de observações.

Definição 8.10 (Matriz de covariâncias observada). A **matriz de covariâncias observada** é

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}.$$

Equivalentemente,

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c = \frac{1}{n-1} \mathbf{X}^\top \mathbf{H}_n \mathbf{X}. \quad (8.58)$$

Seu elemento (j, k) é

$$s_{jk} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k). \quad (8.59)$$

Os elementos diagonais são as variâncias calculadas para as colunas,

$$s_{jj} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2,$$

e os elementos fora da diagonal são as covariâncias calculadas entre pares de colunas.

Como $\mathbf{S}$ é um múltiplo positivo de $\mathbf{T}$,

$$\mathbf{S} = \mathbf{S}^\top, \quad \mathbf{S} \succeq \mathbf{0}$$

e

$$\text{posto}(\mathbf{S}) = \text{posto}(\mathbf{T}) = \text{posto}(\mathbf{X}_c).$$

Portanto,

$$\text{posto}(\mathbf{S}) \leq \min(p, n-1). \quad (8.60)$$

Em particular, se

$$p \geq n,$$

então

$$\text{posto}(\mathbf{S}) \leq n - 1 < p,$$

e $\mathbf{S}$ é necessariamente singular.

Essa singularidade decorre da dimensão dos dados centralizados. Suas consequências para estimação e regularização serão tratadas no Capítulo 10.

Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

tem-se

$$\begin{aligned} \mathbf{a}^\top \mathbf{S} \mathbf{a} &= \frac{1}{n-1} \mathbf{a}^\top \mathbf{X}_c^\top \mathbf{X}_c \mathbf{a} \\ &= \frac{1}{n-1} \|\mathbf{X}_c \mathbf{a}\|^2. \end{aligned} \tag{8.61}$$

O vetor $\mathbf{X}_c \mathbf{a}$ contém os valores centralizados da combinação linear das colunas determinada por $\mathbf{a}$. Portanto, Equação 8.61 é a contraparte descritiva de Equação 8.10.

O divisor $n - 1$ é utilizado aqui como convenção para a matriz de covariâncias observada. Sua relação com graus de liberdade, ausência de viés e máxima verossimilhança será estabelecida no Capítulo 10.

8.7.2 Matriz de correlações e covariâncias cruzadas observadas

Suponha que

$$s_{jj} > 0, \quad j = 1, \dots, p.$$

Defina a matriz diagonal das variâncias observadas por

$$\mathbf{D}_S = \text{diag}(s_{11}, \dots, s_{pp}). \tag{8.62}$$

Definição 8.11 (Matriz de correlações observada). A **matriz de correlações observada** é

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}. \tag{8.63}$$

Seu elemento (j, k) é

$$r_{jk} = \frac{s_{jk}}{\sqrt{s_{jj}s_{kk}}}. \quad (8.64)$$

A matriz $\mathbf{R}$ é simétrica, positiva semidefinida e possui diagonal unitária. Como $\mathbf{D}_S^{-1/2}$ é invertível,

$$\text{posto}(\mathbf{R}) = \text{posto}(\mathbf{S}).$$

Em particular,

$$\mathbf{R} \succ \mathbf{0} \iff \mathbf{S} \succ \mathbf{0}.$$

A relação inversa é

$$\mathbf{S} = \mathbf{D}_S^{1/2} \mathbf{R} \mathbf{D}_S^{1/2}. \quad (8.65)$$

Defina agora a matriz das colunas centralizadas e padronizadas,

$$\mathbf{X}_{\text{pad}} = \mathbf{X}_c \mathbf{D}_S^{-1/2} \in \mathbb{R}^{n \times p}. \quad (8.66)$$

Então,

$$\begin{aligned} \frac{1}{n-1} \mathbf{X}_{\text{pad}}^\top \mathbf{X}_{\text{pad}} &= \frac{1}{n-1} \mathbf{D}_S^{-1/2} \mathbf{X}_c^\top \mathbf{X}_c \mathbf{D}_S^{-1/2} \\ &= \mathbf{R}. \end{aligned}$$

Portanto,

$$\mathbf{R} = \frac{1}{n-1} \mathbf{X}_{\text{pad}}^\top \mathbf{X}_{\text{pad}}. \quad (8.67)$$

A expressão Equação 8.67 mostra que $\mathbf{R}$ é, a menos do fator $1/(n-1)$, uma matriz de Gram das colunas padronizadas.

Exemplo 8.13 (Da matriz de dados às matrizes de covariâncias e correlações). Considere quatro observações de duas variáveis organizadas na matriz

$$\mathbf{X} = \begin{bmatrix} 1 & 2 \\ 2 & 1 \\ 3 & 4 \\ 4 & 3 \end{bmatrix}.$$

Aqui,

$$n = 4 \quad \text{e} \quad p = 2.$$

O vetor de médias das colunas é

$$\bar{\mathbf{x}} = \frac{1}{4} \mathbf{X}^\top \mathbf{1}_4 = \begin{bmatrix} 2,5 \\ 2,5 \end{bmatrix}.$$

Portanto, a matriz centralizada é

$$\begin{aligned} \mathbf{X}_c &= \mathbf{X} - \mathbf{1}_4 \bar{\mathbf{x}}^\top \\ &= \begin{bmatrix} -1,5 & -0,5 \\ -0,5 & -1,5 \\ 0,5 & 1,5 \\ 1,5 & 0,5 \end{bmatrix}. \end{aligned}$$

A matriz total de somas de quadrados e produtos cruzados é

$$\begin{aligned} \mathbf{T} &= \mathbf{X}_c^\top \mathbf{X}_c \\ &= \begin{bmatrix} 5 & 3 \\ 3 & 5 \end{bmatrix}. \end{aligned}$$

Os elementos diagonais são as somas dos quadrados dos desvios de cada variável. O elemento fora da diagonal é a soma dos produtos cruzados.

Como

$$n - 1 = 3,$$

a matriz de covariâncias observada é

$$\begin{aligned}\mathbf{S} &= \frac{1}{3}\mathbf{T} \\ &= \begin{bmatrix} 5/3 & 1 \\ 1 & 5/3 \end{bmatrix}.\end{aligned}$$

Assim,

$$s_{11} = s_{22} = \frac{5}{3}$$

e

$$s_{12} = 1.$$

A matriz diagonal das variâncias observadas é

$$\mathbf{D}_S = \begin{bmatrix} 5/3 & 0 \\ 0 & 5/3 \end{bmatrix}.$$

Como as duas variâncias são iguais,

$$\mathbf{D}_S^{-1/2} = \sqrt{\frac{3}{5}}\mathbf{I}_2.$$

Logo,

$$\begin{aligned}\mathbf{R} &= \mathbf{D}_S^{-1/2}\mathbf{S}\mathbf{D}_S^{-1/2} \\ &= \begin{bmatrix} 1 & 3/5 \\ 3/5 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0,6 \\ 0,6 & 1 \end{bmatrix}.\end{aligned}$$

Também podemos obter diretamente a correlação entre as duas colunas:

$$r_{12} = \frac{s_{12}}{\sqrt{s_{11}s_{22}}} = \frac{1}{\sqrt{(5/3)(5/3)}} = \frac{3}{5} = 0,6.$$

O exemplo reúne as etapas da construção descritiva desenvolvida nesta seção. A partir da matriz de dados $\mathbf{X}$, calcula-se o vetor de médias $\bar{\mathbf{x}}$ e obtém-se a matriz centralizada $\mathbf{X}_c$. A matriz SQPC $\mathbf{T}$ registra a dispersão sem normalização, $\mathbf{S}$ introduz a normalização por $n - 1$ e $\mathbf{R}$ remove as escalas marginais por meio da padronização.

Nesse ponto, $\bar{\mathbf{x}}$, $\mathbf{S}$ e $\mathbf{R}$ são valores calculados a partir da matriz de dados observada. Sua interpretação como realizações de estatísticas amostrais e suas propriedades inferenciais serão desenvolvidas no Capítulo 10.

Se $\mathbf{x}_{\text{pad},j}$ representa a coluna j de $\mathbf{X}_{\text{pad}}$, então

$$\|\mathbf{x}_{\text{pad},j}\|^2 = n - 1.$$

Consequentemente,

$$r_{jk} = \frac{\mathbf{x}_{\text{pad},j}^\top \mathbf{x}_{\text{pad},k}}{\|\mathbf{x}_{\text{pad},j}\| \|\mathbf{x}_{\text{pad},k}\|}. \quad (8.68)$$

Assim, a correlação observada entre duas variáveis é o cosseno do ângulo entre suas colunas centralizadas e padronizadas no espaço das observações. Essa interpretação utiliza diretamente a geometria de produtos internos desenvolvida no Módulo 1.

A representação descritiva também se estende a dois blocos de variáveis. Considere

$$\mathbf{X} \in \mathbb{R}^{n \times p} \quad \text{e} \quad \mathbf{Y} \in \mathbb{R}^{n \times q},$$

cujas linhas correspondem às mesmas n unidades observacionais. Se

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}$$

e

$$\mathbf{Y}_c = \mathbf{H}_n \mathbf{Y},$$

define-se:

Definição 8.12 (Matriz de covariâncias cruzadas observada). A **matriz de covariâncias cruzadas observada** entre os blocos $\mathbf{X}$ e $\mathbf{Y}$ é

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{Y}_c.$$

Equivalentemente,

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{X}^\top \mathbf{H}_n \mathbf{Y} \in \mathbb{R}^{p \times q}. \quad (8.69)$$

Sua orientação satisfaz

$$\mathbf{S}_{YX} = \mathbf{S}_{XY}^\top. \quad (8.70)$$

Para

$$\mathbf{a} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{b} \in \mathbb{R}^q,$$

a covariância observada entre as combinações

$$\mathbf{u} = \mathbf{X}\mathbf{a}$$

e

$$\mathbf{v} = \mathbf{Y}\mathbf{b}$$

é

$$s_{uv} = \mathbf{a}^\top \mathbf{S}_{XY} \mathbf{b}. \quad (8.71)$$

A expressão Equação 8.71 é a contraparte descritiva de Equação 8.14.

Se as duas matrizes forem concatenadas,

$$[\mathbf{X} \quad \mathbf{Y}],$$

a matriz de covariâncias observada correspondente possui a estrutura

$$\begin{bmatrix} \mathbf{S}_{XX} & \mathbf{S}_{XY} \\ \mathbf{S}_{YX} & \mathbf{S}_{YY} \end{bmatrix}. \quad (8.72)$$

Os blocos diagonais descrevem a dispersão interna de cada conjunto de variáveis, enquanto os blocos fora da diagonal registram as covariâncias entre os dois conjuntos.

A matriz $\mathbf{T}$ descreve a dispersão conjunta de todas as observações em torno de $\bar{\mathbf{x}}$. Quando as observações pertencem a grupos previamente identificados, essa dispersão admite uma decomposição adicional.

8.8 Decomposição da dispersão por grupos

Considere as n observações distribuídas em K grupos não vazios. O grupo k contém n_k observações, com

$$n_1 + \cdots + n_K = n.$$

Represente a observação i do grupo k por

$$\mathbf{x}_{ik} \in \mathbb{R}^p, \quad i = 1, \dots, n_k, \quad k = 1, \dots, K.$$

O vetor de médias do grupo k é

$$\bar{\mathbf{x}}_k = \frac{1}{n_k} \sum_{i=1}^{n_k} \mathbf{x}_{ik}. \quad (8.73)$$

A média total satisfaz

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{k=1}^K \sum_{i=1}^{n_k} \mathbf{x}_{ik} = \frac{1}{n} \sum_{k=1}^K n_k \bar{\mathbf{x}}_k. \quad (8.74)$$

A dispersão total das observações em torno da média geral pode ser separada em duas fontes:

- **dispersão intragrupos:** afastamentos das observações em relação à média do grupo ao qual pertencem;
- **dispersão entre grupos:** afastamentos das médias dos grupos em relação à média total.

Essa decomposição distingue, portanto, a variabilidade existente **dentro dos grupos** daquela associada às **diferenças entre seus centros**. Em várias técnicas multivariadas, essa distinção será fundamental para avaliar se os grupos apresentam centros suficientemente separados em relação à variabilidade existente internamente.

Geometricamente, para cada observação, o deslocamento em relação à média total pode ser percorrido em duas etapas: primeiro, da observação até a média de seu grupo e, depois, da média do grupo até a média total. Assim,

$$\mathbf{x}_{ik} - \bar{\mathbf{x}} = (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) + (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}). \quad (8.75)$$

A Figura 8.5 ilustra essas duas componentes. Os afastamentos das observações em relação aos respectivos centros representam a dispersão intragrupos, enquanto os afastamentos dos centros dos grupos em relação à média total representam a dispersão entre grupos.




Figura 8.5: Decomposição geométrica da dispersão em componentes intragrupos e entre grupos.

8.8.1 Dispersão total, intragrupos e entre grupos

A matriz total é

$$\mathbf{T} = \sum_{k=1}^K \sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}) (\mathbf{x}_{ik} - \bar{\mathbf{x}})^\top. \quad (8.76)$$

Definição 8.13 (Matriz de dispersão intragrupos). A **matriz de dispersão intragrupos** é

$$\mathbf{T}_{\text{intra}} = \sum_{k=1}^K \sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k)^\top \in \mathbb{R}^{p \times p}. \quad (8.77)$$

Cada termo mede o afastamento de uma observação em relação ao centro de seu próprio grupo.

Definição 8.14 (Matriz de dispersão entre grupos). A **matriz de dispersão entre grupos** é

$$\mathbf{T}_{\text{entre}} = \sum_{k=1}^K n_k (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}) (\bar{\mathbf{x}}_k - \bar{\mathbf{x}})^\top \in \mathbb{R}^{p \times p}. \quad (8.78)$$

A ponderação por n_k registra o número de observações representadas por cada média de grupo. Assim, um mesmo afastamento $\bar{\mathbf{x}}_k - \bar{\mathbf{x}}$ contribui mais para a dispersão entre grupos quando corresponde a um grupo com maior número de observações.

Proposição 8.9 (Decomposição da dispersão total). *Para qualquer partição das n observações em K grupos não vazios,*

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}. \quad (8.79)$$

i Demonstração

Pela decomposição vetorial apresentada na Equação 8.75,

$$\mathbf{x}_{ik} - \bar{\mathbf{x}} = (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) + (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}).$$

Ao formar o produto externo e somar sobre as observações, surgem duas parcelas quadráticas e dois termos cruzados. Para cada grupo,

$$\sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) = \mathbf{0}.$$

Consequentemente, os termos cruzados desaparecem. A soma das primeiras parcelas produz $\mathbf{T}_{\text{intra}}$, enquanto

$$\sum_{i=1}^{n_k} (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}) (\bar{\mathbf{x}}_k - \bar{\mathbf{x}})^\top = n_k (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}) (\bar{\mathbf{x}}_k - \bar{\mathbf{x}})^\top.$$

Somando sobre os grupos, obtém-se

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}.$$

Exemplo 8.14 (Decomposição da dispersão em dois grupos). Considere quatro observações de duas variáveis, distribuídas em dois grupos:

Grupo	X_1	X_2
1	1	1
1	3	1
2	3	5
2	5	5

Assim,

$$n_1 = n_2 = 2, \quad n = 4, \quad K = 2.$$

As médias dos grupos são

$$\bar{\mathbf{x}}_1 = \frac{1}{2} \left[\begin{bmatrix} 1 \\ 1 \end{bmatrix} + \begin{bmatrix} 3 \\ 1 \end{bmatrix} \right] = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

e

$$\bar{\mathbf{x}}_2 = \frac{1}{2} \left[\begin{bmatrix} 3 \\ 5 \end{bmatrix} + \begin{bmatrix} 5 \\ 5 \end{bmatrix} \right] = \begin{bmatrix} 4 \\ 5 \end{bmatrix}.$$

A média total é

$$\begin{aligned} \bar{\mathbf{x}} &= \frac{1}{4} \left[\begin{bmatrix} 1 \\ 1 \end{bmatrix} + \begin{bmatrix} 3 \\ 1 \end{bmatrix} + \begin{bmatrix} 3 \\ 5 \end{bmatrix} + \begin{bmatrix} 5 \\ 5 \end{bmatrix} \right] \\ &= \begin{bmatrix} 3 \\ 3 \end{bmatrix}. \end{aligned}$$

Podemos agora calcular separadamente as três matrizes da decomposição.

Dispersão intragrupos.

No primeiro grupo,

$$\mathbf{x}_{11} - \bar{\mathbf{x}}_1 = \begin{bmatrix} -1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{x}_{21} - \bar{\mathbf{x}}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Sua contribuição para a dispersão intragrupos é

$$\begin{aligned} \mathbf{T}_{\text{intra},1} &= \begin{bmatrix} -1 \\ 0 \end{bmatrix} \begin{bmatrix} -1 & 0 \end{bmatrix} + \begin{bmatrix} 1 \\ 0 \end{bmatrix} \begin{bmatrix} 1 & 0 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}. \end{aligned}$$

No segundo grupo,

$$\mathbf{x}_{12} - \bar{\mathbf{x}}_2 = \begin{bmatrix} -1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{x}_{22} - \bar{\mathbf{x}}_2 = \begin{bmatrix} 1 \\ 0 \end{bmatrix},$$

de modo que

$$\mathbf{T}_{\text{intra},2} = \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}.$$

Portanto,

$$\begin{aligned} \mathbf{T}_{\text{intra}} &= \mathbf{T}_{\text{intra},1} + \mathbf{T}_{\text{intra},2} \\ &= \begin{bmatrix} 4 & 0 \\ 0 & 0 \end{bmatrix}. \end{aligned} \tag{8.80}$$

Toda a dispersão dentro dos grupos ocorre, neste exemplo, na primeira variável. A segunda variável é constante dentro de cada grupo.

Dispersão entre grupos.

Os afastamentos das médias dos grupos em relação à média total são

$$\bar{\mathbf{x}}_1 - \bar{\mathbf{x}} = \begin{bmatrix} -1 \\ -2 \end{bmatrix}$$

e

$$\bar{\mathbf{x}}_2 - \bar{\mathbf{x}} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

Como ambos os grupos possuem duas observações,

$$\begin{aligned} \mathbf{T}_{\text{entre}} &= 2 \begin{bmatrix} -1 \\ -2 \end{bmatrix} \begin{bmatrix} -1 & -2 \end{bmatrix} + 2 \begin{bmatrix} 1 \\ 2 \end{bmatrix} \begin{bmatrix} 1 & 2 \end{bmatrix} \\ &= 2 \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} + 2 \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} \\ &= \begin{bmatrix} 4 & 8 \\ 8 & 16 \end{bmatrix}. \end{aligned} \tag{8.81}$$

Nesse caso, a diferença entre os centros dos grupos envolve simultaneamente as duas variáveis.

Dispersão total.

Calculando diretamente os desvios das quatro observações em relação a

$$\bar{\mathbf{x}} = \begin{bmatrix} 3 \\ 3 \end{bmatrix},$$

obtém-se

$$\begin{aligned}
\mathbf{T} &= \begin{bmatrix} -2 \\ -2 \end{bmatrix} \begin{bmatrix} -2 & -2 \end{bmatrix} + \begin{bmatrix} 0 \\ -2 \end{bmatrix} \begin{bmatrix} 0 & -2 \end{bmatrix} \\
&\quad + \begin{bmatrix} 0 \\ 2 \end{bmatrix} \begin{bmatrix} 0 & 2 \end{bmatrix} + \begin{bmatrix} 2 \\ 2 \end{bmatrix} \begin{bmatrix} 2 & 2 \end{bmatrix} \\
&= \begin{bmatrix} 8 & 8 \\ 8 & 16 \end{bmatrix}.
\end{aligned} \tag{8.82}$$

A identidade Equação 8.79 pode então ser verificada diretamente:

$$\begin{aligned}
\mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}} &= \begin{bmatrix} 4 & 0 \\ 0 & 0 \end{bmatrix} + \begin{bmatrix} 4 & 8 \\ 8 & 16 \end{bmatrix} \\
&= \begin{bmatrix} 8 & 8 \\ 8 & 16 \end{bmatrix} \\
&= \mathbf{T}.
\end{aligned}$$

A decomposição também pode ser examinada em direções específicas. Para

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix},$$

que selecciona a primeira variável,

$$\mathbf{a}_1^\top \mathbf{T} \mathbf{a}_1 = 8,$$

com

$$\mathbf{a}_1^\top \mathbf{T}_{\text{intra}} \mathbf{a}_1 = 4$$

e

$$\mathbf{a}_1^\top \mathbf{T}_{\text{entre}} \mathbf{a}_1 = 4.$$

Assim,

$$8 = 4 + 4.$$

Metade da dispersão de X_1 decorre de diferenças dentro dos grupos e metade das diferenças entre seus centros.

Para

$$\mathbf{a}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix},$$

que seleciona a segunda variável,

$$\mathbf{a}_2^\top \mathbf{T} \mathbf{a}_2 = 16,$$

enquanto

$$\mathbf{a}_2^\top \mathbf{T}_{\text{intra}} \mathbf{a}_2 = 0$$

e

$$\mathbf{a}_2^\top \mathbf{T}_{\text{entre}} \mathbf{a}_2 = 16.$$

Portanto,

$$16 = 0 + 16.$$

A variável X_2 não apresenta dispersão dentro dos grupos neste conjunto de dados; toda a sua dispersão total está associada à diferença entre as médias dos dois grupos.

O exemplo mostra que a identidade

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

expressa simultaneamente a decomposição da dispersão em todas as direções. Para qualquer combinação linear das variáveis, a dispersão total dessa combinação também se decompõe nas parcelas intragrupos e entre grupos, conforme Equação 8.83.

A identidade Equação 8.79 é algébrica e depende somente da partição das observações e das definições das médias total e de grupo (Johnson; Wichern, 2002). Normalidade, independência e outros pressupostos probabilísticos não são necessários para estabelecê-la.

Para qualquer direção

$$\mathbf{a} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{a}^\top \mathbf{T} \mathbf{a} = \mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a} + \mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}. \quad (8.83)$$

Se

$$y_{ik} = \mathbf{a}^\top \mathbf{x}_{ik},$$

então Equação 8.83 corresponde exatamente à decomposição univariada

$$\sum_{k=1}^K \sum_{i=1}^{n_k} (y_{ik} - \bar{y})^2 = \sum_{k=1}^K \sum_{i=1}^{n_k} (y_{ik} - \bar{y}_k)^2 + \sum_{k=1}^K n_k (\bar{y}_k - \bar{y})^2. \quad (8.84)$$

A decomposição matricial reúne simultaneamente essa identidade para todas as combinações lineares das variáveis.

8.8.2 Somas de quadrados e traço das matrizes de dispersão

As matrizes $\mathbf{T}$, $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$ são matrizes de somas de quadrados e produtos cruzados e descrevem simultaneamente a dispersão das diferentes variáveis e suas associações.

O traço dessas matrizes reúne apenas os termos quadráticos da diagonal e fornece uma medida escalar de dispersão. Defina

$$SQ_{\text{total}} = \text{tr}(\mathbf{T}),$$

$$SQ_{\text{intra}} = \text{tr}(\mathbf{T}_{\text{intra}})$$

e

$$SQ_{\text{entre}} = \text{tr}(\mathbf{T}_{\text{entre}}).$$

Essas quantidades constituem as somas de quadrados total, intragrupos e entre grupos, respectivamente. No caso univariado, elas coincidem com as somas de quadrados usuais da análise de variância. No caso multivariado, correspondem à soma das somas de quadrados das p variáveis.

Como o traço soma as contribuições das diferentes variáveis, essas quantidades dependem das escalas em que as variáveis são expressas. Sua interpretação conjunta é mais direta quando as variáveis possuem unidades comparáveis ou quando uma padronização apropriada foi realizada.

Para a matriz de dispersão total,

$$\mathbf{T} = \sum_{k=1}^K \sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}) (\mathbf{x}_{ik} - \bar{\mathbf{x}})^\top,$$

tem-se

$$\begin{aligned} \text{tr}(\mathbf{T}) &= \sum_{k=1}^K \sum_{i=1}^{n_k} \text{tr} \left[(\mathbf{x}_{ik} - \bar{\mathbf{x}}) (\mathbf{x}_{ik} - \bar{\mathbf{x}})^\top \right] \\ &= \sum_{k=1}^K \sum_{i=1}^{n_k} \|\mathbf{x}_{ik} - \bar{\mathbf{x}}\|^2. \end{aligned} \quad (8.85)$$

Portanto,

$$SQ_{\text{total}} = \text{tr}(\mathbf{T}) = \sum_{k=1}^K \sum_{i=1}^{n_k} \|\mathbf{x}_{ik} - \bar{\mathbf{x}}\|^2. \quad (8.86)$$

Assim, SQ_{total} é a soma dos quadrados das distâncias euclidianas das observações à média total.

Analogamente,

$$SQ_{\text{intra}} = \text{tr}(\mathbf{T}_{\text{intra}}) = \sum_{k=1}^K \sum_{i=1}^{n_k} \|\mathbf{x}_{ik} - \bar{\mathbf{x}}_k\|^2 \quad (8.87)$$

mede a soma dos quadrados dos afastamentos das observações em relação aos centros de seus respectivos grupos.

Por sua vez,

$$SQ_{\text{entre}} = \text{tr}(\mathbf{T}_{\text{entre}}) = \sum_{k=1}^K n_k \|\bar{\mathbf{x}}_k - \bar{\mathbf{x}}\|^2 \quad (8.88)$$

mede a soma ponderada dos quadrados das distâncias entre os centros dos grupos e a média total.

Como

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

a linearidade do traço fornece

$$SQ_{\text{total}} = SQ_{\text{intra}} + SQ_{\text{entre}}. \quad (8.89)$$

Equivalentemente,

$$\text{tr}(\mathbf{T}) = \text{tr}(\mathbf{T}_{\text{intra}}) + \text{tr}(\mathbf{T}_{\text{entre}}). \quad (8.90)$$

Ao tomar o traço da decomposição matricial, recupera-se uma identidade escalar análoga à decomposição de somas de quadrados familiar da análise de variância:

$$SQ_{\text{total}} = SQ_{\text{intra}} + SQ_{\text{entre}}.$$

A decomposição matricial

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

é mais informativa, pois preserva também os produtos cruzados entre as variáveis. O traço resume essa estrutura matricial em uma única soma de quadrados.

Assim, a decomposição matricial da dispersão também produz uma decomposição da quantidade total de dispersão medida pelas distâncias euclidianas quadráticas.

Dividindo essas somas por n , obtêm-se medidas médias da dispersão quadrática. Por exemplo,

$$\frac{SQ_{\text{total}}}{n} = \frac{1}{n} \text{tr}(\mathbf{T}) = \frac{1}{n} \sum_{k=1}^K \sum_{i=1}^{n_k} \|\mathbf{x}_{ik} - \bar{\mathbf{x}}\|^2.$$

Essa quantidade representa o afastamento quadrático médio das observações em relação à média total. De modo correspondente,

$$\frac{SQ_{\text{intra}}}{n}$$

e

$$\frac{SQ_{\text{entre}}}{n}$$

representam, respectivamente, as contribuições médias da dispersão intragrupos e entre grupos.

8.8.3 Propriedades e limites de posto

As propriedades estruturais a seguir decorrem diretamente das definições das matrizes de dispersão e não dependem de hipóteses probabilísticas sobre as observações.

Proposição 8.10 (Estrutura das matrizes de dispersão por grupos). *As matrizes*

$$\mathbf{T}, \quad \mathbf{T}_{\text{intra}} \quad e \quad \mathbf{T}_{\text{entre}}$$

são simétricas e positivas semidefinidas. Além disso,

$$\mathbf{0} \preceq \mathbf{T}_{\text{intra}} \preceq \mathbf{T}$$

e

$$\mathbf{0} \preceq \mathbf{T}_{\text{entre}} \preceq \mathbf{T}.$$


Seus postos satisfazem

$$\text{posto}(\mathbf{T}) \leq \min(p, n - 1),$$

$$\text{posto}(\mathbf{T}_{\text{intra}}) \leq \min(p, n - K), \tag{8.91}$$

e

$$\text{posto}(\mathbf{T}_{\text{entre}}) \leq \min(p, K - 1). \tag{8.92}$$



i Demonstração

Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a} = \sum_{k=1}^K \sum_{i=1}^{n_k} [\mathbf{a}^\top (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k)]^2 \geq 0$$

e

$$\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a} = \sum_{k=1}^K n_k [\mathbf{a}^\top (\bar{\mathbf{x}}_k - \bar{\mathbf{x}})]^2 \geq 0.$$

Logo, as duas parcelas são positivas semidefinidas. Pela identidade Equação 8.79,

$$\mathbf{T} - \mathbf{T}_{\text{intra}} = \mathbf{T}_{\text{entre}} \succeq \mathbf{0}$$

e

$$\mathbf{T} - \mathbf{T}_{\text{entre}} = \mathbf{T}_{\text{intra}} \succeq \mathbf{0},$$

o que estabelece as relações na ordem de Loewner.

O limite para $\mathbf{T}$ foi obtido na Equação 8.57.

Dentro do grupo k , os n_k vetores centralizados satisfazem

$$\sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) = \mathbf{0}.$$

Assim, os vetores centralizados desse grupo geram um subespaço de dimensão no máximo $n_k - 1$. Considerando todos os grupos,

$$\sum_{k=1}^K (n_k - 1) = n - K,$$

e, portanto,

$$\text{posto}(\mathbf{T}_{\text{intra}}) \leq \min(p, n - K).$$

Para a parcela entre grupos,

$$\sum_{k=1}^K n_k (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}) = \mathbf{0}.$$

Os K vetores

$$\sqrt{n_k} (\bar{\mathbf{x}}_k - \bar{\mathbf{x}})$$

geram, portanto, um subespaço de dimensão no máximo $K - 1$. Consequentemente,

$$\text{posto}(\mathbf{T}_{\text{entre}}) \leq \min(p, K - 1).$$

Os limites podem ser estritos quando existem relações lineares adicionais entre as variáveis ou entre os vetores de médias dos grupos.

As relações na ordem de Loewner implicam, para qualquer direção $\mathbf{a}$,

$$0 \leq \mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a} \leq \mathbf{a}^\top \mathbf{T} \mathbf{a}$$

e

$$0 \leq \mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a} \leq \mathbf{a}^\top \mathbf{T} \mathbf{a}.$$

Assim, a dispersão intragrupos ou entre grupos em uma direção não pode exceder a dispersão total na mesma direção.

Dois casos extremos auxiliam a interpretação. Se

$$\bar{\mathbf{x}}_1 = \cdots = \bar{\mathbf{x}}_K = \bar{\mathbf{x}},$$

então

$$\mathbf{T}_{\text{entre}} = \mathbf{0}.$$

Se, por outro lado, todas as observações de cada grupo coincidem com a respectiva média,

$$\mathbf{x}_{ik} = \bar{\mathbf{x}}_k,$$

então

$$\mathbf{T}_{\text{intra}} = \mathbf{0}.$$

A identidade

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

separa algebricamente a dispersão total observada nas parcelas intragrupos e entre grupos. Essa decomposição, juntamente com as propriedades de positividade e os limites de posto das três matrizes, não depende de hipóteses probabilísticas sobre as observações.

Sob independência entre as observações e matriz de covariâncias comum aos grupos, as mesmas matrizes também admitem uma interpretação probabilística por meio de suas esperanças. A formulação por matrizes de projeção, os estimadores de covariâncias residuais e as hipóteses lineares são tratados no Capítulo 12.

8.9 Aprofundamentos teóricos

8.9.1 Variância média e interpretação volumétrica da variância generalizada

A variância total e a variância generalizada resumem aspectos distintos da dispersão por meio do traço e do determinante de Σ . A variância média reescala a variância total pelo número de componentes, enquanto a raiz quadrada da variância generalizada determina a escala de volume do elipsoide de covariância quando $\Sigma \succ \mathbf{0}$.

Definição 8.15 (Variância média). Se $\mathbf{X} \in \mathbb{R}^p$ possui matriz de covariâncias Σ , com autovalores $\lambda_1, \dots, \lambda_p$, sua **variância média** é

$$\text{VM}(\mathbf{X}) = \frac{1}{p} \text{tr}(\Sigma) = \frac{1}{p} \sum_{j=1}^p \lambda_j.$$

A variância total e a variância média dependem das escalas das componentes. Quando as variáveis possuem unidades distintas, sua interpretação requer cautela.

A variância generalizada definida em Definição 8.7 não deve ser confundida com o volume do elipsoide de covariância de Equação 8.32. Para $\Sigma \succ \mathbf{0}$, a relação entre essas quantidades envolve a raiz quadrada do determinante (Johnson; Wichern, 2002).

Proposição 8.11 (Volume do elipsoide de covariância). Se

$$p \geq 1, \quad \mu \in \mathbb{R}^p, \quad \Sigma \in \mathbb{R}^{p \times p}, \quad \Sigma \succ \mathbf{0}$$

e

$$c > 0,$$

considere o elipsoide

$$\mathcal{E}_c = \left\{ \mathbf{x} \in \mathbb{R}^p : (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \leq c^2 \right\}.$$

Seu volume p -dimensional é

$$\text{Vol}_p(\mathcal{E}_c) = \kappa_p c^p \det(\Sigma)^{1/2}, \quad (8.93)$$

em que

$$\kappa_p = \frac{\pi^{p/2}}{\Gamma(p/2 + 1)}$$

é o volume da esfera unitária de $\mathbb{R}^p$.

i Demonstração

O elipsoide é a imagem da bola

$$\mathcal{B}_c = \{\mathbf{u} \in \mathbb{R}^p : \|\mathbf{u}\| \leq c\}$$

pela transformação

$$\mathbf{x} = \mu + \Sigma^{1/2} \mathbf{u}.$$

A translação não altera o volume. Pelo Proposição 4.13, a transformação linear multiplica volumes por

$$|\det(\Sigma^{1/2})| = \det(\Sigma)^{1/2}.$$

Como

$$\text{Vol}_p(\mathcal{B}_c) = \kappa_p c^p,$$

obtem-se Equação 8.93.

Portanto,

$$\det(\Sigma)^{1/2}$$

é o fator associado à escala de volume da dispersão, enquanto

$$\det(\Sigma)$$

é a variância generalizada.

As unidades também diferem entre essas medidas. Se as componentes possuem unidades

$$u_1, \dots, u_p,$$

a variância generalizada possui unidade

$$u_1^2 \cdots u_p^2,$$

enquanto

$$\det(\Sigma)^{1/2}$$

possui unidade

$$u_1 \cdots u_p,$$

compatível com uma medida de volume no espaço das variáveis.

Considere agora uma transformação linear quadrada

$$\mathbf{Y} = \mathbf{A}\mathbf{X}, \quad \mathbf{A} \in \mathbb{R}^{p \times p}.$$

Pela expressão Equação 8.18,

$$\Sigma_{YY} = \mathbf{A}\Sigma_{XX}\mathbf{A}^\top.$$

Consequentemente,

$$\det(\Sigma_{YY}) = \det(\mathbf{A})^2 \det(\Sigma_{XX}). \quad (8.94)$$

Para a escala de volume,

$$\det(\Sigma_{YY})^{1/2} = |\det(\mathbf{A})| \det(\Sigma_{XX})^{1/2}. \quad (8.95)$$

Essa expressão é compatível com o fator de alteração de volume desenvolvido na Proposição 4.13.

Quando $\mathbf{A}$ é ortogonal, $|\det(\mathbf{A})| = 1$ e a transformação preserva os autovalores de Σ . Consequentemente, preserva a variância total, a variância generalizada e os comprimentos dos semieixos do elipsoide, alterando somente sua orientação no sistema de coordenadas.

8.9.2 Esperança das matrizes de dispersão por grupos

A decomposição

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

é uma identidade algébrica para os dados observados. Sob uma estrutura probabilística para as observações, as matrizes de dispersão tornam-se objetos aleatórios e suas esperanças permitem separar a variabilidade comum aos grupos da dispersão associada às diferenças entre seus vetores de médias populacionais.

Suponha que todos os vetores aleatórios

$$\mathbf{X}_{ik}, \quad i = 1, \dots, n_k, \quad k = 1, \dots, K,$$

sejam mutuamente independentes, com

$$E(\mathbf{X}_{ik}) = \mu_k$$

e matriz de covariâncias comum

$$\text{Cov}(\mathbf{X}_{ik}) = \Sigma.$$

Não é necessário assumir normalidade.

Defina a média populacional ponderada dos grupos por

$$\mu = \frac{1}{n} \sum_{k=1}^K n_k \mu_k. \quad (8.96)$$

Considere ainda a matriz

$$\mathbf{B}_\mu = \sum_{k=1}^K n_k (\mu_k - \mu) (\mu_k - \mu)^\top, \quad (8.97)$$

que representa a dispersão entre os vetores de médias populacionais dos grupos.

Quando as matrizes de dispersão são consideradas objetos aleatórios, as somas de quadrados correspondentes também são objetos aleatórios. Defina

$$\text{SQ}_{\text{total}} = \text{tr}(\mathbf{T}),$$

$$SQ_{\text{intra}} = \text{tr}(\mathbf{T}_{\text{intra}})$$

e

$$SQ_{\text{entre}} = \text{tr}(\mathbf{T}_{\text{entre}}).$$

Suas realizações observadas são, respectivamente,

$$SQ_{\text{total}}, \quad SQ_{\text{intra}} \quad \text{e} \quad SQ_{\text{entre}}.$$

Para a matriz de dispersão intragrupo,

$$\mathbf{T}_{\text{intra}} = \sum_{k=1}^K \sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k)^\top,$$

tem-se

$$E(\mathbf{T}_{\text{intra}}) = (n - K)\Sigma. \quad (8.98)$$

Tomando o traço dos dois lados e utilizando a linearidade do traço e da esperança,

$$E(SQ_{\text{intra}}) = (n - K) \text{tr}(\Sigma).$$

Consequentemente,

$$E\left(\frac{SQ_{\text{intra}}}{n - K}\right) = \text{tr}(\Sigma).$$

Dentro de cada grupo, os vetores centralizados satisfazem

$$\sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) = \mathbf{0}.$$

Assim, a centralização pela média do grupo reduz em uma unidade a dimensão disponível, fazendo com que o grupo k contribua com $n_k - 1$ graus de liberdade. Portanto,

$$\sum_{k=1}^K (n_k - 1) = n - K.$$

A quantidade $n-K$ corresponde, assim, aos graus de liberdade intragrupos familiares da análise de variância. A divisão por $n-K$ antecipa a construção dos quadrados médios utilizada em ANOVA e planejamento de experimentos.

Para a dispersão entre grupos,

$$\mathbf{T}_{\text{entre}} = \sum_{k=1}^K n_k (\bar{\mathbf{X}}_k - \bar{\mathbf{X}}) (\bar{\mathbf{X}}_k - \bar{\mathbf{X}})^\top,$$

a esperança é

$$E(\mathbf{T}_{\text{entre}}) = (K-1)\Sigma + \mathbf{B}_\mu. \quad (8.99)$$

Essa expressão contém duas parcelas com interpretações distintas. O termo

$$(K-1)\Sigma$$

representa a variabilidade decorrente do fato de que as médias amostrais dos grupos variam de amostra para amostra, enquanto

$$\mathbf{B}_\mu$$

representa a separação efetiva entre os vetores de médias populacionais.

Em particular, se

$$\mu_1 = \cdots = \mu_K,$$

então

$$\mathbf{B}_\mu = \mathbf{0},$$

mas, ainda assim,

$$E(\mathbf{T}_{\text{entre}}) = (K-1)\Sigma.$$

Tomando o traço na Equação 8.99,

$$E(\text{SQ}_{\text{entre}}) = (K-1) \text{tr}(\Sigma) + \text{tr}(\mathbf{B}_\mu).$$

Consequentemente,

$$E \left(\frac{SQ_{\text{entre}}}{K-1} \right) = \text{tr}(\Sigma) + \frac{\text{tr}(\mathbf{B}_\mu)}{K-1}.$$

Quando os grupos possuem o mesmo vetor de médias populacional,

$$\mu_1 = \cdots = \mu_K,$$

tem-se

$$\mathbf{B}_\mu = \mathbf{0}.$$

Nesse caso,

$$E \left(\frac{SQ_{\text{entre}}}{K-1} \right) = E \left(\frac{SQ_{\text{intra}}}{n-K} \right) = \text{tr}(\Sigma).$$

Portanto, quando não existe separação entre os vetores de médias populacionais, as somas de quadrados intragrupos e entre grupos, após a divisão pelas respectivas quantidades $n-K$ e $K-1$, possuem a mesma esperança.

Isso ocorre porque as médias amostrais dos grupos não coincidem exatamente, mesmo quando seus vetores de médias populacionais são iguais.

Por fim, como

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

a linearidade da esperança fornece

$$\begin{aligned} E(\mathbf{T}) &= E(\mathbf{T}_{\text{intra}}) + E(\mathbf{T}_{\text{entre}}) \\ &= (n-1)\Sigma + \mathbf{B}_\mu. \end{aligned} \tag{8.100}$$

Tomando o traço,

$$E(SQ_{\text{total}}) = (n-1)\text{tr}(\Sigma) + \text{tr}(\mathbf{B}_\mu). \tag{8.101}$$

Além disso,

$$SQ_{\text{total}} = SQ_{\text{intra}} + SQ_{\text{entre}},$$

que é a versão aleatória da decomposição observada

$$SQ_{\text{total}} = SQ_{\text{intra}} + SQ_{\text{entre}}.$$

Quando todos os grupos possuem o mesmo vetor de médias populacional,

$$E(\mathbf{T}) = (n-1)\Sigma.$$

Esses resultados dependem apenas de momentos de primeira e segunda ordem e da independência entre as observações; a normalidade não é necessária. Distribuições amostrais e resultados inferenciais associados a essas matrizes serão tratados posteriormente.

No caso univariado, as matrizes reduzem-se a escalares e a decomposição assume a forma familiar

$$SQ_{\text{total}} = SQ_{\text{intra}} + SQ_{\text{entre}}.$$

As divisões

$$QM_{\text{intra}} = \frac{SQ_{\text{intra}}}{n-K}$$

e

$$QM_{\text{entre}} = \frac{SQ_{\text{entre}}}{K-1}$$

correspondem aos quadrados médios familiares da análise de variância e do planejamento de experimentos.

No contexto multivariado, contudo, as matrizes completas de somas de quadrados e produtos cruzados preservam informações adicionais sobre as associações entre as variáveis. Por essa razão, métodos multivariados posteriores utilizarão $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$, e não apenas seus traços.

8.10 Síntese do capítulo

A matriz de covariâncias

$$\Sigma = \text{Cov}(\mathbf{X})$$

representa a estrutura de segunda ordem de um vetor aleatório. Sua diagonal contém as variâncias das componentes, e seus elementos fora da diagonal registram covariâncias. Para qualquer combinação linear,

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a},$$

de modo que a matriz de covariâncias determina a dispersão em todas as direções.

A padronização marginal conduz à matriz de correlações

$$\mathcal{R} = \mathbf{D}_\Sigma^{-1/2} \Sigma \mathbf{D}_\Sigma^{-1/2},$$

que preserva a estrutura de associação linear após a retirada das escalas marginais.

A decomposição espectral de Σ fornece eixos ortogonais de dispersão, enquanto o traço e o determinante produzem resumos escalares distintos. A variância total é

$$\text{tr}(\Sigma) = \sum_{j=1}^p \sigma_{jj} = \sum_{j=1}^p \lambda_j,$$

e também pode ser interpretada como o afastamento euclidiano quadrático médio do vetor aleatório em relação ao seu centro:

$$E[\|\mathbf{X} - \mu\|^2] = \text{tr}(\Sigma).$$

Mais geralmente, para uma matriz simétrica $\mathbf{A}$ e um vetor fixo $\mathbf{a}$,

$$E[(\mathbf{X} - \mathbf{a})^\top \mathbf{A} (\mathbf{X} - \mathbf{a})] = \text{tr}(\mathbf{A}\Sigma) + (\mu - \mathbf{a})^\top \mathbf{A} (\mu - \mathbf{a}).$$

A variância generalizada é

$$\det(\Sigma),$$

e, quando $\Sigma \succ \mathbf{0}$, a distância de Mahalanobis

$$d_M^2(\mathbf{x}, \mu) = (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu)$$

mede afastamentos levando em conta simultaneamente escalas e covariâncias. Sua esperança populacional satisfaz

$$E[d_M^2(\mathbf{X}, \mu)] = p.$$

A transformação de **branqueamento** (*whitening*), também denominada **esferização**, transforma a estrutura de covariâncias em identidade. No branqueamento simétrico,

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu),$$

e

$$\text{Cov}(\mathbf{Z}) = \mathbf{I}_p.$$

Nesse espaço transformado, a distância de Mahalanobis coincide com a distância euclidiana. A padronização marginal e o branqueamento diferem porque a primeira produz matriz de covariâncias igual a $\mathcal{R}$, enquanto o branqueamento produz $\mathbf{I}_p$.

No nível descritivo, as mesmas estruturas são representadas por

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c, \quad \mathbf{S} = \frac{1}{n-1} \mathbf{T}$$

e

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}.$$

A sigla **SQPC** significa **somas de quadrados e produtos cruzados** e será utilizada como equivalente, em português, à sigla inglesa **SSCP**, de *sum of squares and cross-products*.

Quando as observações estão organizadas em grupos,

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

separa a dispersão observada dentro dos grupos da dispersão associada às diferenças entre seus centros. As matrizes completas preservam tanto as somas de quadrados de cada variável quanto os produtos cruzados entre variáveis.

Tomando o traço, obtém-se a decomposição escalar

$$SQ_{\text{total}} = SQ_{\text{intra}} + SQ_{\text{entre}},$$

em que

$$SQ_{\text{total}} = \text{tr}(\mathbf{T}), \quad SQ_{\text{intra}} = \text{tr}(\mathbf{T}_{\text{intra}})$$

e

$$SQ_{\text{entre}} = \text{tr}(\mathbf{T}_{\text{entre}}).$$

No caso univariado, essa identidade coincide com a decomposição de somas de quadrados familiar da análise de variância. Os correspondentes quadrados médios são

$$QM_{\text{intra}} = \frac{SQ_{\text{intra}}}{n - K}$$

e

$$QM_{\text{entre}} = \frac{SQ_{\text{entre}}}{K - 1}.$$

No contexto multivariado, entretanto, as matrizes $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$ contêm informação adicional sobre os produtos cruzados e, por isso, são mais informativas do que seus traços.

Sob independência entre as observações e matriz de covariâncias comum Σ nos grupos, as matrizes de dispersão também admitem interpretações probabilísticas. Se

$$\mu = \frac{1}{n} \sum_{k=1}^K n_k \mu_k$$

e

$$\mathbf{B}_{\mu} = \sum_{k=1}^K n_k (\mu_k - \mu) (\mu_k - \mu)^{\top},$$

então

$$E(\mathbf{T}_{\text{intra}}) = (n - K)\Sigma,$$

$$E(\mathbf{T}_{\text{entre}}) = (K - 1)\Sigma + \mathbf{B}_{\mu},$$

e

$$E(\mathbf{T}) = (n-1)\Sigma + \mathbf{B}_\mu.$$

Tomando os traços,

$$E(\text{SQ}_{\text{intra}}) = (n-K) \text{tr}(\Sigma)$$

e

$$E(\text{SQ}_{\text{entre}}) = (K-1) \text{tr}(\Sigma) + \text{tr}(\mathbf{B}_\mu).$$

Definindo os quadrados médios como objetos aleatórios por

$$\text{QM}_{\text{intra}} = \frac{\text{SQ}_{\text{intra}}}{n-K}$$

e

$$\text{QM}_{\text{entre}} = \frac{\text{SQ}_{\text{entre}}}{K-1},$$

quando

$$\mu_1 = \cdots = \mu_K,$$

tem-se

$$E(\text{QM}_{\text{intra}}) = E(\text{QM}_{\text{entre}}) = \text{tr}(\Sigma).$$

Essa igualdade antecipa a lógica dos quadrados médios da análise de variância, enquanto a formulação multivariada posterior utilizará as matrizes completas de somas de quadrados e produtos cruzados.

A Tabela 8.1 reúne os principais objetos do capítulo.

Tabela 8.1: Principais objetos desenvolvidos no capítulo.

Nível	Objeto	Símbolo	Função
Populacional	vetor de médias	μ	localização

Nível	Objeto	Símbolo	Função
Populacional	matriz de covariâncias	Σ	dispersão conjunta
Populacional	matriz de correlações	$\mathcal{R}$	associação linear padronizada
Populacional	covariância cruzada	Σ_{XY}	associação linear entre blocos
Geométrico	variância total	$\text{tr}(\Sigma)$	dispersão quadrática média
Geométrico	variância generalizada	$\det(\Sigma)$	dispersão multidimensional global
Geométrico	distância de Mahalanobis	d_M	afastamento ajustado à dispersão
Geométrico	branqueamento	$\Sigma^{-1/2}$	transformação para covariância identidade
Dados observados	média	$\bar{\mathbf{x}}$	centro das observações
Dados observados	SQPC	$\mathbf{T}$	dispersão não normalizada
Dados observados	covariância	$\mathbf{S}$	dispersão calculada dos dados
Dados observados	correlação	$\mathbf{R}$	associação linear padronizada nos dados
Dados agrupados	dispersão intragrupos	$\mathbf{T}_{\text{intra}}$	dispersão dentro dos grupos
Dados agrupados	dispersão entre grupos	$\mathbf{T}_{\text{entre}}$	dispersão entre os centros dos grupos
Dados agrupados	decomposição matricial	$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$	separação da dispersão por grupos
Dados agrupados	somas de quadrados	$SQ_{\text{total}}, SQ_{\text{intra}}, SQ_{\text{entre}}$	resumos escalares obtidos pelos traços das matrizes de dispersão

Dados agrupados	quadrados médios	$QM_{\text{intra}}, QM_{\text{entre}}$	somas de quadrados ajustadas pelos respectivos graus de liberdade
-----------------	------------------	--	---

Ao final deste capítulo, o estudante deverá ser capaz de:

- representar a variabilidade conjunta por matrizes de covariâncias e correlações;
- calcular e interpretar variâncias e covariâncias de combinações lineares;
- reconhecer as condições estruturais, a singularidade e o posto de matrizes de covariâncias e correlações;
- interpretar a decomposição espectral, a variância total, a variância generalizada e a geometria dos elipsoides de dispersão;
- relacionar formas quadráticas e esperanças matemáticas à estrutura de covariâncias;
- interpretar a distância de Mahalanobis e sua relação com o branqueamento e a esferização;
- distinguir padronização marginal e branqueamento;
- distinguir parâmetros populacionais, estatísticas amostrais e valores calculados de dados observados;
- decompor a dispersão observada em parcelas total, intragrupos e entre grupos;
- relacionar os traços das matrizes de dispersão às somas de quadrados total, intragrupos e entre grupos;
- reconhecer a relação entre somas de quadrados, graus de liberdade e quadrados médios, estabelecendo a conexão com a análise de variância;
- interpretar, sob hipóteses probabilísticas apropriadas, as esperanças das matrizes de dispersão e das correspondentes somas de quadrados e quadrados médios.

A matriz de covariâncias descreve a estrutura de segunda ordem de um vetor aleatório, mas, em geral, não determina sua distribuição conjunta. O próximo capítulo introduz a **Distribuição Normal Multivariada**, na qual o vetor de médias e a matriz de covariâncias determinam completamente a distribuição. Serão desenvolvidas suas distribuições marginais e condicionais e, no caso não singular, sua função densidade. Nesse contexto, a distância quadrática de Mahalanobis deixará de ser apenas uma construção geométrica baseada em momentos de segunda ordem e passará a possuir uma distribuição probabilística específica.

9 Distribuição Normal Multivariada

O Capítulo 8 definiu o vetor de médias na Equação 8.1, a matriz de covariâncias na Definição 8.2 e os elipsoides de covariância na Equação 8.32. Fora da família normal, o vetor de médias e a matriz de covariâncias não determinam a distribuição conjunta: distribuições distintas podem compartilhar os mesmos momentos de primeira e segunda ordem.

Na família normal multivariada, μ e Σ determinam a distribuição conjunta. Transformações afins e subvectores permanecem normais e, sob normalidade conjunta, covariância nula entre blocos equivale à independência.

O capítulo desenvolve a densidade, as distribuições marginais e condicionais, a independência entre blocos, a padronização, o branqueamento e a distribuição da distância quadrática de Mahalanobis. O percurso principal assume $\Sigma \succ \mathbf{0}$ quando são necessárias invertibilidade e densidade em $\mathbb{R}^p$; o caso singular é tratado na Seção 9.9.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{X} \in \mathbb{R}^p$ representa um vetor aleatório e $\mathbf{x} \in \mathbb{R}^p$ uma de suas realizações;
- $\mu \in \mathbb{R}^p$ representa o vetor de médias populacional;
- $\Sigma \in \mathbb{R}^{p \times p}$ representa a matriz de covariâncias populacional;
- $\mathbf{X} \sim N_p(\mu, \Sigma)$ indica uma distribuição normal multivariada de dimensão p , parametrizada pelo vetor de médias e pela matriz de covariâncias;
- $\mathbf{Z}$ representa um vetor normal multivariado padrão, cuja dimensão será indicada pelo contexto; por exemplo, $\mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r)$ em dimensão r ;
- $\mathbf{D}_\Sigma = \text{diag}(\sigma_{11}, \dots, \sigma_{pp})$ representa a matriz diagonal das variâncias marginais;
- $\sigma_j = \sqrt{\sigma_{jj}}$ representa o desvio-padrão marginal da componente X_j ;
- $\mathcal{R}$ representa a matriz de correlações populacional;
- $\mathbf{X}_1$ e $\mathbf{X}_2$ representam blocos de um vetor normal particionado, com matrizes de covariâncias Σ_{11} e Σ_{22} e covariâncias cruzadas Σ_{12} e Σ_{21} ;
- $\Sigma_{11.2}$ representa o complemento de Schur de Σ_{22} em Σ ;
- $d_M^2(\mathbf{x}, \mu)$ representa a distância quadrática de Mahalanobis de um ponto fixo $\mathbf{x}$ ao centro populacional;
- D_M^2 representa a distância quadrática de Mahalanobis considerada como variável aleatória;
- χ_p^2 representa a distribuição qui-quadrado com p graus de liberdade, e $\chi_{p;1-\alpha}^2$ representa seu quantil de ordem $1 - \alpha$.

9.1 Definição e construção

9.1.1 Definição por combinações lineares

Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix} \in \mathbb{R}^p,$$

com

$$E(\mathbf{X}) = \mu$$

e

$$\text{Cov}(\mathbf{X}) = \Sigma.$$

Definição 9.1 (Distribuição normal multivariada). O vetor aleatório $\mathbf{X} \in \mathbb{R}^p$ possui **distribuição normal multivariada** se, para todo vetor constante $\mathbf{a} \in \mathbb{R}^p$, a combinação linear

$$\mathbf{a}^\top \mathbf{X}$$

possui distribuição normal univariada, admitindo-se também variância igual a zero.

Quando

$$E(\mathbf{X}) = \mu$$

e

$$\text{Cov}(\mathbf{X}) = \Sigma,$$

escreve-se

$$\mathbf{X} \sim N_p(\mu, \Sigma). \quad (9.1)$$

Pela Proposição 8.1 do Capítulo 8, para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \boldsymbol{\mu}$$

e

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \boldsymbol{\Sigma} \mathbf{a}.$$

Portanto,

$$\mathbf{a}^\top \mathbf{X} \sim N(\mathbf{a}^\top \boldsymbol{\mu}, \mathbf{a}^\top \boldsymbol{\Sigma} \mathbf{a}). \quad (9.2)$$

Se

$$\mathbf{a}^\top \boldsymbol{\Sigma} \mathbf{a} = 0,$$

então

$$\mathbf{a}^\top \mathbf{X} = \mathbf{a}^\top \boldsymbol{\mu}$$

quase certamente.

Escolhendo $\mathbf{a} = \mathbf{e}_j$, em que $\mathbf{e}_j$ é o j -ésimo vetor da base canônica, obtém-se

$$X_j \sim N(\mu_j, \sigma_{jj}).$$

Assim, cada componente de um vetor normal multivariado possui distribuição normal univariada.

Normalidade marginal e normalidade conjunta

A normalidade de cada componente considerada separadamente não garante normalidade multivariada. A definição exige que **todas as combinações lineares** das componentes possuam distribuição normal.

Portanto,

$$X_j \text{ normal para todo } j$$

não implica, isoladamente,

$$\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}).$$

Quando $\|\mathbf{a}\| = 1$, a variável $\mathbf{a}^\top \mathbf{X}$ representa a coordenada da projeção de $\mathbf{X}$ na direção de $\mathbf{a}$. A definição estabelece que toda projeção unidimensional de um vetor normal multivariado possui distribuição normal.

9.1.2 Construção afim a partir do vetor normal padrão

A definição anterior também permite construir vetores normais multivariados a partir de variáveis normais padrão independentes.

Considere

$$\mathbf{Z} = \begin{bmatrix} Z_1 \\ \vdots \\ Z_r \end{bmatrix},$$

com

$$Z_j \sim N(0, 1), \quad j = 1, \dots, r,$$

e componentes mutuamente independentes.

Para qualquer $\mathbf{c} \in \mathbb{R}^r$,

$$\mathbf{c}^\top \mathbf{Z} = \sum_{j=1}^r c_j Z_j$$

é uma variável normal. Além disso,

$$E(\mathbf{Z}) = \mathbf{0}$$

e

$$\text{Cov}(\mathbf{Z}) = \mathbf{I}_r.$$

Logo,

$$\mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r).$$

A transformação afim definida na Definição 4.6 permite transportar essa distribuição para outros vetores de médias e outras estruturas de covariância.

Proposição 9.1 (Construção afim de um vetor normal). *O vetor*

$$\mathbf{X} = \mu + \mathbf{A}\mathbf{Z} \quad (9.3)$$

satisfaz

$$\mathbf{X} \sim N_p(\mu, \mathbf{A}\mathbf{A}^\top), \quad (9.4)$$

em que

$$\mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r),$$

$\mathbf{A} \in \mathbb{R}^{p \times r}$ e $\mu \in \mathbb{R}^p$.

i Demonstração

Pelo resultado de transformação da covariância na Proposição 8.6,

$$E(\mathbf{X}) = \mu$$

e

$$\text{Cov}(\mathbf{X}) = \mathbf{A} \text{Cov}(\mathbf{Z}) \mathbf{A}^\top = \mathbf{A}\mathbf{A}^\top. \quad (9.5)$$

Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\begin{aligned} \mathbf{a}^\top \mathbf{X} &= \mathbf{a}^\top \mu + \mathbf{a}^\top \mathbf{A}\mathbf{Z} \\ &= \mathbf{a}^\top \mu + (\mathbf{A}^\top \mathbf{a})^\top \mathbf{Z}. \end{aligned}$$

A última parcela é uma combinação linear das componentes de $\mathbf{Z}$ e, portanto, possui distribuição normal. Assim, $\mathbf{a}^\top \mathbf{X}$ é normal para todo $\mathbf{a}$, o que caracteriza $\mathbf{X}$ como normal multivariado.

A matriz $\mathbf{A}$ determina como as componentes independentes de $\mathbf{Z}$ são combinadas. A transformação pode introduzir covariâncias entre as componentes de $\mathbf{X}$, mesmo que as componentes do vetor inicial sejam independentes.

Pela Proposição 8.2, uma matriz de covariâncias é simétrica e positiva semidefinida. Reciprocamente, toda matriz real simétrica e positiva semidefinida admite uma fatoração

$$\Sigma = \mathbf{A}\mathbf{A}^\top. \quad (9.6)$$

De fato, pelo Teorema 5.2,

$$\Sigma = \mathbf{Q}\Lambda\mathbf{Q}^\top,$$

com autovalores não negativos. Definindo

$$\mathbf{A} = \mathbf{Q}\Lambda^{1/2},$$

obtém-se

$$\mathbf{A}\mathbf{A}^\top = \Sigma.$$

Consequentemente, qualquer vetor $\mu \in \mathbb{R}^p$ e qualquer matriz simétrica positiva semidefinida Σ podem parametrizar uma distribuição normal multivariada.

Se Σ é positiva semidefinida, mas não positiva definida, obtém-se o caso singular, tratado na Seção 9.9. No percurso regular, considere

$$\Sigma \succ \mathbf{0}.$$

A raiz quadrada principal definida na Definição 5.7 é invertível e pode ser utilizada como matriz da construção afim, pois

$$\Sigma^{1/2}\Sigma^{1/2} = \Sigma.$$

Assim, se

$$\mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I}_p),$$

o vetor

$$\mathbf{Y} = \mu + \Sigma^{1/2}\mathbf{Z}$$

possui distribuição

$$\mathbf{Y} \sim N_p(\mu, \Sigma).$$

9.1.3 Determinação pelos parâmetros

O vetor de médias μ e a matriz de covariâncias Σ descrevem características de primeira e segunda ordem, mas, por si sós, não determinam uma distribuição conjunta. Na família normal multivariada, esses parâmetros determinam a distribuição, pois todas as projeções lineares são normais e seus parâmetros são determinados por μ e Σ .

Para vetores aleatórios $\mathbf{X}$ e $\mathbf{Y}$ em $\mathbb{R}^p$, a notação de **igualdade em distribuição**

$$\mathbf{X} \stackrel{d}{=} \mathbf{Y}$$

significa que os dois vetores possuem a mesma distribuição conjunta. Equivalentemente, para todo

$$\mathbf{x} = (x_1, \dots, x_p)^\top \in \mathbb{R}^p,$$

tem-se

$$P(X_1 \leq x_1, \dots, X_p \leq x_p) = P(Y_1 \leq x_1, \dots, Y_p \leq x_p).$$

A igualdade em distribuição não significa que

$$\mathbf{X} = \mathbf{Y}$$

quase certamente. Os vetores podem, inclusive, estar definidos em espaços de probabilidade distintos.

O resultado geral que permite passar das distribuições das projeções à distribuição conjunta é o Teorema de Cramér–Wold (Eaton, 2007).

Teorema 9.1 (Teorema de Cramér–Wold). *Sejam*

$$\mathbf{X} \in \mathbb{R}^p \quad e \quad \mathbf{Y} \in \mathbb{R}^p$$

vetores aleatórios. Então,

$$\mathbf{X} \stackrel{d}{=} \mathbf{Y}$$

se, e somente se,

$$\mathbf{a}^\top \mathbf{X} \stackrel{d}{=} \mathbf{a}^\top \mathbf{Y}$$

para todo

$$\mathbf{a} \in \mathbb{R}^p.$$

(Eaton, 2007)

A implicação direta decorre da aplicação da mesma transformação linear a vetores com a mesma distribuição. A implicação inversa estabelece que a coleção das distribuições de todas as projeções lineares determina a distribuição conjunta.

Leitura de aprofundamento

O Teorema de Cramér–Wold é um resultado geral e não depende da hipótese de normalidade. Sua demonstração usual utiliza funções características, que não serão desenvolvidas neste capítulo.

No caso normal multivariado, o Teorema 9.1 garante que o vetor de médias e a matriz de covariâncias determinam a distribuição conjunta.

Proposição 9.2 (Determinação da distribuição normal pelos parâmetros). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma)$$

e

$$\mathbf{Y} \sim N_p(\mu, \Sigma),$$

então

$$\mathbf{X} \stackrel{d}{=} \mathbf{Y}.$$

i Demonstração

Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}^\top \mathbf{X} \sim N(\mathbf{a}^\top \mu, \mathbf{a}^\top \Sigma \mathbf{a})$$

e

$$\mathbf{a}^\top \mathbf{Y} \sim N(\mathbf{a}^\top \mu, \mathbf{a}^\top \Sigma \mathbf{a}).$$

Logo,

$$\mathbf{a}^\top \mathbf{X} \stackrel{d}{=} \mathbf{a}^\top \mathbf{Y}$$

para todo $\mathbf{a}$. Pelo Teorema 9.1,

$$\mathbf{X} \stackrel{d}{=} \mathbf{Y}.$$

Pela Proposição 9.2, a notação

$$N_p(\mu, \Sigma)$$

é suficiente para identificar uma distribuição normal multivariada.

Como consequência, quando

$$\Sigma \succ \mathbf{0}$$

e

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

a construção anterior permite escrever

$$\mathbf{X} \stackrel{d}{=} \mu + \Sigma^{1/2} \mathbf{Z}, \quad \mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I}_p). \quad (9.7)$$

9.2 Densidade da normal multivariada

A partir deste ponto, considere

$$\Sigma \succ \mathbf{0}.$$

Então,

$$\Sigma^{-1}$$

existe e

$$\det(\Sigma) > 0,$$

permitindo representar a distribuição normal multivariada por uma densidade em relação à medida de Lebesgue em $\mathbb{R}^p$ (Johnson; Wichern, 2002).

9.2.1 Função densidade e log-densidade

Proposição 9.3 (Densidade da normal multivariada). *A densidade de*

$$\mathbf{X} \sim N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

é

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \right\}, \quad (9.8)$$

para todo $\mathbf{x} \in \mathbb{R}^p$.

i Demonstração

Pela Equação 9.7,

$$\mathbf{X} \stackrel{d}{=} \mu + \Sigma^{1/2} \mathbf{Z},$$

com

$$\mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I}_p).$$

Como as componentes de $\mathbf{Z}$ são normais padrão independentes, sua densidade conjunta é

$$f_{\mathbf{Z}}(\mathbf{z}) = \frac{1}{(2\pi)^{p/2}} \exp\left(-\frac{1}{2} \mathbf{z}^\top \mathbf{z}\right).$$

Considere a transformação afim

$$\mathbf{x} = \mu + \Sigma^{1/2} \mathbf{z}.$$

Como $\Sigma^{1/2}$ é invertível,

$$\mathbf{z} = \Sigma^{-1/2} (\mathbf{x} - \mu).$$

A Jacobiana da transformação inversa é a matriz constante $\Sigma^{-1/2}$, de modo que

$$|\det(\Sigma^{-1/2})| = \det(\Sigma)^{-1/2}.$$

Aplicando a transformação de densidades estabelecida na Proposição 7.13,

$$\begin{aligned} f_{\mathbf{X}}(\mathbf{x}) &= f_{\mathbf{Z}}[\Sigma^{-1/2}(\mathbf{x} - \mu)] \det(\Sigma)^{-1/2} \\ &= \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}} \exp\left\{-\frac{1}{2} (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu)\right\}. \end{aligned}$$

A derivação mostra a função desempenhada pelos dois termos matriciais da densidade. O determinante surge da alteração de volume provocada pela transformação afim, enquanto a matriz inversa aparece ao expressar o afastamento de $\mathbf{x}$ nas coordenadas da normal padrão obtidas pelo branqueamento.

Como a distribuição é contínua,

$$P(\mathbf{X} = \mathbf{x}) = 0$$

para qualquer ponto fixo $\mathbf{x} \in \mathbb{R}^p$. Probabilidades são atribuídas a regiões:

$$P(\mathbf{X} \in \mathcal{A}) = \int_{\mathcal{A}} f_{\mathbf{X}}(\mathbf{x}) \, d\mathbf{x}, \quad (9.9)$$

para conjuntos mensuráveis $\mathcal{A} \subseteq \mathbb{R}^p$.

A forma quadrática no expoente é a distância quadrática de Mahalanobis definida na Definição 8.8:

$$d_M^2(\mathbf{x}, \mu) = (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu).$$

Assim,

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}} \exp \left[-\frac{1}{2} d_M^2(\mathbf{x}, \mu) \right]. \quad (9.10)$$

Para μ e Σ fixos, a posição de $\mathbf{x}$ afeta a densidade somente por meio de sua distância de Mahalanobis ao vetor de médias. Como

$$c \mapsto \exp \left(-\frac{c}{2} \right)$$

é estritamente decrescente para $c \geq 0$, pontos mais afastados do centro segundo essa métrica possuem menor densidade.

A log-densidade é

$$\begin{aligned} \log f_{\mathbf{X}}(\mathbf{x}) &= -\frac{p}{2} \log(2\pi) - \frac{1}{2} \log \det(\Sigma) \\ &\quad - \frac{1}{2} (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu). \end{aligned} \quad (9.11)$$

Na Equação 9.11, o termo $-\frac{p}{2} \log(2\pi)$ depende apenas da dimensão, $-\frac{1}{2} \log \det(\Sigma)$ depende da matriz de covariâncias e o termo quadrático mede o afastamento de $\mathbf{x}$ em relação a μ . Para uma amostra normal multivariada, essas contribuições aparecem na Equação 10.26 do Capítulo 10.

Quando $p = 1$,

$$\Sigma = [\sigma^2],$$

e a Equação 9.8 reduz-se a

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left[-\frac{(x-\mu)^2}{2\sigma^2} \right].$$

O vetor μ determina a localização da distribuição. Como

$$d_M^2(\mathbf{x}, \mu) \geq 0$$

e a igualdade ocorre em $\mathbf{x} = \mu$, a densidade atinge seu máximo no centro:

$$f_{\mathbf{x}}(\mu) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}}. \quad (9.12)$$

A matriz Σ determina a escala, a orientação e a forma das superfícies de igual densidade. Pela Equação 9.10, a densidade depende de $\mathbf{x}$ por meio de $d_M^2(\mathbf{x}, \mu)$; portanto, as superfícies de nível da densidade normal coincidem com elipsóides de distância de Mahalanobis constante, cuja geometria foi estabelecida na Equação 8.32.

9.2.2 Superfícies de igual densidade

Para $c > 0$, considere

$$\mathcal{S}_c = \{\mathbf{x} \in \mathbb{R}^p : d_M^2(\mathbf{x}, \mu) = c\}. \quad (9.13)$$

Para todo $\mathbf{x} \in \mathcal{S}_c$,

$$f_{\mathbf{x}}(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}} \exp \left(-\frac{c}{2} \right).$$

Portanto, $\mathcal{S}_c$ é uma superfície de igual densidade.

Pela representação espectral na Equação 8.33, essas superfícies são elipsoidais. Seus eixos e extensões são determinados pelos autovalores e autovetores de Σ . No modelo normal, dois pontos possuem a mesma densidade se, e somente se, apresentam a mesma distância de Mahalanobis ao vetor de médias.

A Figura 9.1 mostra essa correspondência para uma distribuição normal bivariada.

As curvas de nível são elipses centradas em μ . Todos os pontos sobre uma mesma curva apresentam a mesma distância de Mahalanobis ao centro e, consequentemente, a mesma densidade.

A região interna correspondente é




Figura 9.1: Mapa de densidade e curvas de nível de uma distribuição normal bivariada.

$$\mathcal{E}_c = \{\mathbf{x} \in \mathbb{R}^p : d_M^2(\mathbf{x}, \mu) \leq c\}. \quad (9.14)$$

Neste ponto, c é apenas uma constante positiva. Mais adiante, a distribuição de D_M^2 permitirá escolher valores de c associados a probabilidades populacionais específicas.

9.3 Transformações e distribuições marginais

A Proposição 9.1 parte de um vetor normal padrão. O fechamento sob transformações afins generaliza essa construção: combinações lineares, projeções, subvectores e padronizações de um vetor normal permanecem na família normal sem exigir nova integração da densidade.

9.3.1 Fechamento sob transformações afins

Considere

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

$\mathbf{A} \in \mathbb{R}^{m \times p}$ e $\mathbf{b} \in \mathbb{R}^m$.

Proposição 9.4 (Fechamento da família normal sob transformações afins). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

a transformação afim

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b} \quad (9.15)$$

satisfaz

$$\mathbf{Y} \sim N_m(\mathbf{A}\mu + \mathbf{b}, \mathbf{A}\Sigma\mathbf{A}^\top), \quad (9.16)$$

em que

$$\mathbf{A} \in \mathbb{R}^{m \times p} \quad e \quad \mathbf{b} \in \mathbb{R}^m.$$

i Demonstração

Pela Proposição 8.6,

$$E(\mathbf{Y}) = \mathbf{A}\mu + \mathbf{b}$$

e

$$\text{Cov}(\mathbf{Y}) = \mathbf{A}\Sigma\mathbf{A}^\top.$$

Para qualquer $\mathbf{c} \in \mathbb{R}^m$,

$$\begin{aligned}\mathbf{c}^\top \mathbf{Y} &= \mathbf{c}^\top (\mathbf{A}\mathbf{X} + \mathbf{b}) \\ &= (\mathbf{A}^\top \mathbf{c})^\top \mathbf{X} + \mathbf{c}^\top \mathbf{b}.\end{aligned}$$

Como $\mathbf{X}$ é normal multivariado,

$$(\mathbf{A}^\top \mathbf{c})^\top \mathbf{X}$$

é normal. A adição de uma constante preserva a normalidade. Portanto, toda combinação linear das componentes de $\mathbf{Y}$ é normal, o que demonstra o resultado.

As fórmulas para média e covariância são válidas para vetores aleatórios gerais com segundos momentos finitos. O resultado específico da família normal é o **fechamento distribucional**: se $\mathbf{X}$ possui distribuição normal multivariada, então $\mathbf{A}\mathbf{X} + \mathbf{b}$ também possui distribuição normal multivariada.

A matriz $\mathbf{A}$ não precisa possuir posto completo. Consequentemente, a matriz de covariâncias transformada

$$\mathbf{A}\Sigma\mathbf{A}^\top$$

pode não ser positiva definida. Esse caso é tratado na Seção 9.9.

Exemplo 9.1 (Transformação de um vetor normal bivariado). Considere

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} 2 \\ 1 \end{bmatrix}, \begin{bmatrix} 4 & 1 \\ 1 & 2 \end{bmatrix} \right).$$

Defina

$$\mathbf{Y} = \begin{bmatrix} Y_1 \\ Y_2 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \mathbf{X} + \begin{bmatrix} 0 \\ 3 \end{bmatrix}.$$

Logo,

$$Y_1 = X_1 + X_2$$

e

$$Y_2 = X_1 - X_2 + 3.$$

O vetor de médias é

$$\begin{aligned} E(\mathbf{Y}) &= \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} + \begin{bmatrix} 0 \\ 3 \end{bmatrix} \\ &= \begin{bmatrix} 3 \\ 4 \end{bmatrix}, \end{aligned}$$

e a matriz de covariâncias é

$$\begin{aligned} \text{Cov}(\mathbf{Y}) &= \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 4 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 8 & 2 \\ 2 & 4 \end{bmatrix}. \end{aligned}$$

Portanto,

$$\mathbf{Y} \sim N_2 \left(\begin{bmatrix} 3 \\ 4 \end{bmatrix}, \begin{bmatrix} 8 & 2 \\ 2 & 4 \end{bmatrix} \right).$$

O exemplo mostra que uma transformação afim modifica simultaneamente localização e covariância, mas preserva a família normal.

9.3.2 Combinações lineares

A Proposição 9.4, com $m = 1$, fornece a distribuição de uma combinação linear.

Para $\mathbf{a} \in \mathbb{R}^p$ e $b \in \mathbb{R}$,

$$Y = \mathbf{a}^\top \mathbf{X} + b$$

satisfaz

$$Y \sim N(\mathbf{a}^\top \mu + b, \mathbf{a}^\top \Sigma \mathbf{a}). \quad (9.17)$$

A expressão fornece diretamente a distribuição de somas, diferenças, contrastes, médias ponderadas e projeções lineares.

Exemplo 9.2 (Soma e diferença de componentes conjuntamente normais). Considere

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix} \right).$$

Para

$$Y_1 = X_1 + X_2,$$

tem-se

$$Y_1 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2 + 2\sigma_{12}).$$

Para

$$Y_2 = X_1 - X_2,$$

tem-se

$$Y_2 \sim N(\mu_1 - \mu_2, \sigma_1^2 + \sigma_2^2 - 2\sigma_{12}).$$

Quando $\sigma_{12} > 0$, a covariância aumenta a variância da soma e reduz a variância da diferença. Para $\sigma_{12} < 0$, ocorre o efeito inverso.

Se

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0,$$

então

$$\mathbf{a}^\top \mathbf{X} + b = \mathbf{a}^\top \mu + b$$

quase certamente.

9.3.3 Distribuições marginais

As distribuições marginais de subvetores também podem ser obtidas como transformações lineares.

Considere

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right), \quad (9.18)$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}, \quad p_1 + p_2 = p.$$

Proposição 9.5 (Distribuições marginais da normal multivariada). *Os blocos marginais de um vetor normal multivariado particionado satisfazem*

$$\mathbf{X}_1 \sim N_{p_1}(\mu_1, \Sigma_{11}) \quad (9.19)$$

e

$$\mathbf{X}_2 \sim N_{p_2}(\mu_2, \Sigma_{22}). \quad (9.20)$$

As distribuições marginais acima são obtidas da distribuição conjunta

$$\begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right),$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}, \quad p_1 + p_2 = p.$$

i Demonstração

O primeiro bloco pode ser escrito como

$$\mathbf{X}_1 = \mathbf{A}_1 \mathbf{X},$$

com

$$\mathbf{A}_1 = [\mathbf{I}_{p_1} \quad \mathbf{0}].$$

Pela Proposição 9.4,

$$\mathbf{X}_1 \sim N_{p_1}(\mathbf{A}_1 \mu, \mathbf{A}_1 \Sigma \mathbf{A}_1^\top).$$

Pelas definições de $\mathbf{A}_1$, μ e Σ ,

$$\mathbf{A}_1 \mu = \mu_1$$

e

$$\mathbf{A}_1 \Sigma \mathbf{A}_1^\top = \Sigma_{11}.$$

O segundo bloco é obtido de forma análoga.

A distribuição marginal de um bloco depende de seu vetor de médias e de sua própria matriz de covariâncias. A matriz Σ_{12} não aparece nos parâmetros marginais e corresponde à covariância cruzada entre $\mathbf{X}_1$ e $\mathbf{X}_2$.

Exemplo 9.3 (Marginal de um vetor normal trivariado). Considere

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix} \sim N_3 \left(\begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix}, \begin{bmatrix} 4 & 1 & -1 \\ 1 & 3 & 0,5 \\ -1 & 0,5 & 2 \end{bmatrix} \right).$$

Selecioneando X_1 e X_3 ,

$$\begin{bmatrix} X_1 \\ X_3 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 4 & -1 \\ -1 & 2 \end{bmatrix} \right).$$

A média marginal é formada pelas componentes correspondentes de μ , e a matriz de covariâncias marginal é a submatriz principal associada às variáveis selecionadas.

9.3.4 Padronização marginal e branqueamento

O Capítulo 8 definiu na Equação 8.20 a matriz

$$\mathbf{D}_\Sigma = \text{diag}(\sigma_{11}, \dots, \sigma_{pp}).$$

Suponha

$$\sigma_{jj} > 0, \quad j = 1, \dots, p.$$

A padronização marginal é

$$\mathbf{Z}_{\text{pad}} = \mathbf{D}_\Sigma^{-1/2}(\mathbf{X} - \boldsymbol{\mu}). \quad (9.21)$$

Pela Proposição 9.4 e pela definição de $\mathcal{R}$ na Definição 8.5,

$$\mathbf{Z}_{\text{pad}} \sim N_p(\mathbf{0}, \mathcal{R}), \quad (9.22)$$

com

$$\mathcal{R} = \mathbf{D}_\Sigma^{-1/2} \Sigma \mathbf{D}_\Sigma^{-1/2}.$$

Cada componente padronizada satisfaz

$$Z_{\text{pad},j} \sim N(0, 1),$$

mas as componentes não são necessariamente independentes.

Padronização não implica independência

A padronização marginal produz componentes com média zero e variância unitária, mas preserva as correlações existentes entre elas.

Assim,

$$\mathbf{Z}_{\text{pad}} \sim N_p(\mathbf{0}, \mathcal{R}).$$

Pela Proposição 9.6, as componentes serão independentes precisamente quando

$$\mathcal{R} = \mathbf{I}_p.$$

Quando

$$\Sigma \succ \mathbf{0},$$

o Capítulo 8 mostrou na Equação 8.48 que o branqueamento simétrico transforma a matriz de covariâncias em $\mathbf{I}_p$. Para um vetor normal multivariado, a Proposição 9.4 determina também a distribuição do vetor branqueado.

O branqueamento simétrico é dado por

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu). \quad (9.23)$$

Pelo fechamento da família normal,

$$\begin{aligned} \mathbf{Z} &\sim N_p(\mathbf{0}, \Sigma^{-1/2} \Sigma \Sigma^{-1/2}) \\ &= N_p(\mathbf{0}, \mathbf{I}_p). \end{aligned} \quad (9.24)$$

A diferença entre as duas transformações é, portanto,

$$\mathbf{D}_\Sigma^{-1/2} (\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \mathcal{R})$$

e

$$\Sigma^{-1/2} (\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \mathbf{I}_p).$$

A padronização marginal transforma as variâncias em um e preserva as correlações. O branqueamento transforma toda a matriz de covariâncias em identidade.

Pela Proposição 9.6, uma matriz de covariâncias diagonal implica independência entre as componentes de um vetor conjuntamente normal. Como o vetor branqueado possui distribuição $N_p(\mathbf{0}, \mathbf{I}_p)$, suas componentes são independentes.

O branqueamento não é único. Para um vetor normal multivariado, uma transformação ortogonal do vetor branqueado também possui distribuição normal padrão. Se $\mathbf{Q}_0$ é ortogonal, então

$$\mathbf{Q}_0 \Sigma^{-1/2} (\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \mathbf{I}_p),$$

pois

$$\mathbf{Q}_0 \mathbf{I}_p \mathbf{Q}_0^\top = \mathbf{I}_p.$$

O branqueamento simétrico constitui uma escolha específica entre transformações que produzem covariância identidade.

A independência das componentes branqueadas é um caso particular da equivalência entre covariância cruzada nula e independência para blocos conjuntamente normais.

9.4 Independência e distribuições condicionais

Quando os segundos momentos existem, a independência entre dois blocos implica covariância cruzada nula. A implicação inversa, entretanto, não é válida sem hipóteses adicionais. Na família normal multivariada, a normalidade conjunta estabelece a equivalência entre independência e covariância cruzada nula.

Para um vetor normal particionado com $\Sigma \succ \mathbf{0}$, a distribuição condicional é determinada pelos blocos do vetor de médias e da matriz de covariâncias. O complemento de Schur definido na Definição 2.20 e aplicado à matriz de covariâncias no Capítulo 8 corresponde à matriz de covariâncias condicional.

9.4.1 Independência entre blocos conjuntamente normais

Considere o vetor particionado

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right), \quad (9.25)$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}, \quad p_1 + p_2 = p.$$

Se os dois blocos são independentes, então

$$\text{Cov}(\mathbf{X}_1, \mathbf{X}_2) = \Sigma_{12} = \mathbf{0}.$$

Essa implicação vale para quaisquer vetores aleatórios independentes com segundos momentos finitos. A normalidade conjunta permite estabelecer também a implicação inversa.

Nesta seção, quando o símbolo $\perp$ aparece entre vetores aleatórios, a notação

$$\mathbf{X}_1 \perp \mathbf{X}_2$$

significa que $\mathbf{X}_1$ e $\mathbf{X}_2$ são **independentes**. Esse uso deve ser distinguido da ortogonalidade geométrica, também representada pelo símbolo $\perp$ nos capítulos de Álgebra Linear.

Proposição 9.6 (Independência de blocos conjuntamente normais). *Para dois blocos conjuntamente normais,*

$$\mathbf{X}_1 \perp \mathbf{X}_2$$

se, e somente se,

$$\Sigma_{12} = \mathbf{0}, \quad (9.26)$$

sob a distribuição conjunta


$$\begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right),$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}, \quad p_1 + p_2 = p,$$

e

$$\Sigma_{12} = \text{Cov}(\mathbf{X}_1, \mathbf{X}_2).$$



i Demonstração

Se

$$\mathbf{X}_1 \perp \mathbf{X}_2,$$

então a independência implica

$$\Sigma_{12} = \text{Cov}(\mathbf{X}_1, \mathbf{X}_2) = \mathbf{0}.$$

Para a implicação inversa, suponha

$$\Sigma_{12} = \mathbf{0}.$$

Como

$$\Sigma_{21} = \Sigma_{12}^\top,$$

a matriz de covariâncias conjunta assume a forma

$$\Sigma = \begin{bmatrix} \Sigma_{11} & \mathbf{0} \\ \mathbf{0} & \Sigma_{22} \end{bmatrix}.$$

Existem matrizes $\mathbf{A}_1$ e $\mathbf{A}_2$ tais que

$$\Sigma_{11} = \mathbf{A}_1 \mathbf{A}_1^\top$$

e

$$\Sigma_{22} = \mathbf{A}_2 \mathbf{A}_2^\top.$$

Considere vetores normais padrão independentes $\mathbf{Z}_1$ e $\mathbf{Z}_2$ e defina

$$\mathbf{Y}_1 = \mu_1 + \mathbf{A}_1 \mathbf{Z}_1$$

e

$$\mathbf{Y}_2 = \mu_2 + \mathbf{A}_2 \mathbf{Z}_2.$$

Por construção,

$$\mathbf{Y}_1 \perp \mathbf{Y}_2.$$

Além disso,

$$\begin{bmatrix} \mathbf{Y}_1 \\ \mathbf{Y}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \mathbf{0} \\ \mathbf{0} & \Sigma_{22} \end{bmatrix} \right).$$

Pela Proposição 9.2,

$$\begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \stackrel{d}{=} \begin{bmatrix} \mathbf{Y}_1 \\ \mathbf{Y}_2 \end{bmatrix}.$$

Portanto,

Como caso particular, se

$$\mathbf{X} \sim N_p(\mu, \Sigma)$$

e Σ é diagonal, então

$$X_1, \dots, X_p$$

são mutuamente independentes.

Esse resultado é uma consequência específica da normalidade conjunta. Sem essa hipótese, uma matriz de covariâncias diagonal garante covariância nula entre componentes, mas não implica independência.

A normalidade deve ser conjunta

A equivalência

$$\text{Cov}(X_i, X_j) = 0 \iff X_i \perp X_j$$

exige que X_i e X_j pertençam ao mesmo vetor normal multivariado.

A normalidade de cada variável considerada separadamente não é suficiente para essa conclusão.

9.4.2 Distribuição condicional

Considere novamente

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right),$$

e suponha

$$\Sigma \succ \mathbf{0}.$$

Como Σ_{22} é uma submatriz principal de uma matriz positiva definida,

$$\Sigma_{22} \succ \mathbf{0},$$

de modo que Σ_{22}^{-1} existe.

Na notação condicional, a barra vertical $|$ deve ser lida como **dado**. Assim,

$$\mathbf{X}_1 \mid \mathbf{X}_2 = \mathbf{x}_2$$

representa o vetor $\mathbf{X}_1$ condicionado ao valor $\mathbf{X}_2 = \mathbf{x}_2$, e o subscrito $1 \mid 2$ identifica quantidades condicionais relativas ao primeiro bloco dado o segundo.

Proposição 9.7 (Distribuição condicional da normal multivariada). *A distribuição condicional de um bloco de um vetor normal multivariado particionado é normal multivariada (Anderson, 2003):*

$$\mathbf{X}_1 \mid \mathbf{X}_2 = \mathbf{x}_2 \sim N_{p_1} \left(\mu_{1|2}(\mathbf{x}_2), \Sigma_{11 \cdot 2} \right). \quad (9.27)$$

As distribuições marginais acima são obtidas da distribuição conjunta

$$\begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right),$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}, \quad \mathbf{x}_2 \in \mathbb{R}^{p_2}, \quad p_1 + p_2 = p,$$

e

$$\Sigma_{22} \succ \mathbf{0}.$$


A média condicional é

$$\mu_{1|2}(\mathbf{x}_2) = \mu_1 + \Sigma_{12} \Sigma_{22}^{-1} (\mathbf{x}_2 - \mu_2) \quad (9.28)$$

e a matriz de covariâncias condicional é

$$\Sigma_{11 \cdot 2} = \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}. \quad (9.29)$$

A matriz $\Sigma_{11 \cdot 2}$ é o complemento de Schur de Σ_{22} em Σ , definido na Equação 8.16.



i Demonstração

Considere

$$\mathbf{L}^* = \Sigma_{12} \Sigma_{22}^{-1}$$

e defina o vetor residual

$$\mathbf{E}_{1|2} = \mathbf{X}_1 - \mu_1 - \mathbf{L}^* (\mathbf{X}_2 - \mu_2). \quad (9.30)$$

Os vetores $\mathbf{E}_{1|2}$ e $\mathbf{X}_2$ são obtidos conjuntamente por uma transformação afim de $\mathbf{X}$. Pela Proposição 9.4,

$$\begin{bmatrix} \mathbf{E}_{1|2} \\ \mathbf{X}_2 \end{bmatrix}$$

possui distribuição normal multivariada.

A covariância cruzada entre o resíduo e o bloco condicionante é

$$\begin{aligned} \text{Cov}(\mathbf{E}_{1|2}, \mathbf{X}_2) &= \Sigma_{12} - \mathbf{L}^* \Sigma_{22} \\ &= \Sigma_{12} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{22} \\ &= \mathbf{0}. \end{aligned}$$

Pela Proposição 9.6,

$$\mathbf{E}_{1|2} \perp \mathbf{X}_2. \quad (9.31)$$

Além disso,

$$E(\mathbf{E}_{1|2}) = \mathbf{0}.$$

Pela Proposição 8.5,

$$\begin{aligned} \text{Cov}(\mathbf{E}_{1|2}) &= \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} \\ &= \Sigma_{11 \cdot 2}. \end{aligned}$$

Portanto,

$$\mathbf{E}_{1|2} \sim \mathcal{N}_{p_1}(\mathbf{0}, \Sigma_{11 \cdot 2}).$$

Reorganizando a Equação 9.30,

$$\mathbf{X}_1 = \mu_1 + \Sigma_{12} \Sigma_{22}^{-1} (\mathbf{X}_2 - \mu_2) + \mathbf{E}_{1|2}.$$

Condicionando em

$$\mathbf{X}_2 = \mathbf{x}_2$$

A decomposição de $\mathbf{X}_1$ em esperança condicional e resíduo é

$$\mathbf{X}_1 = \mu_{1|2}(\mathbf{X}_2) + \mathbf{E}_{1|2}, \quad (9.32)$$

com

$$\mathbf{E}_{1|2} \perp \mathbf{X}_2.$$

Consequentemente,

$$E(\mathbf{X}_1 | \mathbf{X}_2) = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{X}_2 - \mu_2). \quad (9.33)$$

Na Proposição 8.5, a expressão

$$\mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{X}_2 - \mu_2)$$

é o melhor ajuste linear de $\mathbf{X}_1$ em função de $\mathbf{X}_2$, determinado pelo vetor de médias e pela matriz de covariâncias.

Sob normalidade conjunta, o melhor ajuste linear coincide com a esperança condicional:

$$E(\mathbf{X}_1 | \mathbf{X}_2) = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{X}_2 - \mu_2).$$

A matriz de covariâncias do resíduo linear também coincide com a matriz de covariâncias condicional.

9.4.3 Média e covariância condicionais

A média condicional

$$\mu_{1|2}(\mathbf{x}_2) = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2)$$

depende do valor condicionado.

O vetor

$$\mathbf{x}_2 - \mu_2$$

representa o afastamento do bloco conhecido em relação à sua média. A matriz

$$\Sigma_{12}\Sigma_{22}^{-1}$$

transforma esse afastamento em um ajuste para a média de $\mathbf{X}_1$.

Quando

$$\mathbf{x}_2 = \mu_2,$$

tem-se

$$\mu_{1|2}(\mu_2) = \mu_1.$$

Quando

$$\Sigma_{12} = \mathbf{0},$$

a média condicional não depende de $\mathbf{x}_2$:

$$\mu_{1|2}(\mathbf{x}_2) = \mu_1.$$

A matriz de covariâncias condicional é

$$\Sigma_{11\cdot 2} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}.$$

Ela não depende do valor específico de $\mathbf{x}_2$. Assim, diferentes valores do bloco condicionante deslocam o centro da distribuição condicional, mas não alteram sua matriz de covariâncias.

Como $\Sigma \succ \mathbf{0}$, a propriedade de positividade do complemento de Schur fornece

$$\Sigma_{11\cdot 2} \succ \mathbf{0}. \quad (9.34)$$

A diferença entre as covariâncias marginal e condicional é

$$\Sigma_{11} - \Sigma_{11\cdot 2} = \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}. \quad (9.35)$$

Como

$$\Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} \succeq \mathbf{0},$$

segue que

$$\Sigma_{11.2} \preceq \Sigma_{11}. \quad (9.36)$$

Portanto, para qualquer $\mathbf{a} \in \mathbb{R}^{p_1}$,

$$\begin{aligned} \text{Var} [\mathbf{a}^\top \mathbf{X}_1 \mid \mathbf{X}_2 = \mathbf{x}_2] &= \mathbf{a}^\top \Sigma_{11.2} \mathbf{a} \\ &\leq \mathbf{a}^\top \Sigma_{11} \mathbf{a}. \end{aligned}$$

Condicionar no segundo bloco não aumenta a variância de nenhuma combinação linear do primeiro bloco.

Quando

$$\Sigma_{12} = \mathbf{0},$$

tem-se simultaneamente

$$\mu_{1|2}(\mathbf{x}_2) = \mu_1$$

e

$$\Sigma_{11.2} = \Sigma_{11}.$$

Nesse caso, a distribuição condicional coincide com a distribuição marginal, como consequência da independência entre os blocos estabelecida na Proposição 9.6.

9.4.4 Caso bivariado

Considere

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix} \right), \quad (9.37)$$

com

$$\sigma_1 > 0, \quad \sigma_2 > 0, \quad -1 < \rho < 1.$$

A média condicional de X_1 dado $X_2 = x_2$ é

$$\begin{aligned}
E(X_1 | X_2 = x_2) &= \mu_1 + \frac{\rho\sigma_1\sigma_2}{\sigma_2^2}(x_2 - \mu_2) \\
&= \mu_1 + \rho\frac{\sigma_1}{\sigma_2}(x_2 - \mu_2).
\end{aligned} \tag{9.38}$$

A variância condicional é

$$\begin{aligned}
\text{Var}(X_1 | X_2 = x_2) &= \sigma_1^2 - \frac{\rho^2\sigma_1^2\sigma_2^2}{\sigma_2^2} \\
&= \sigma_1^2(1 - \rho^2).
\end{aligned} \tag{9.39}$$

Portanto,

$$X_1 | X_2 = x_2 \sim N \left[\mu_1 + \rho\frac{\sigma_1}{\sigma_2}(x_2 - \mu_2), \sigma_1^2(1 - \rho^2) \right]. \tag{9.40}$$

O sinal de ρ determina a direção do deslocamento da média condicional. Se $\rho > 0$, valores de X_2 acima de μ_2 deslocam a média de X_1 para valores maiores; se $\rho < 0$, o deslocamento ocorre em sentido oposto.

A variância condicional depende de ρ^2 e não do valor observado x_2 . Quanto maior $|\rho|$, menor é a variabilidade remanescente de X_1 depois de conhecido X_2 .

Quando

$$\rho = 0,$$

obtém-se

$$E(X_1 | X_2 = x_2) = \mu_1$$

e

$$\text{Var}(X_1 | X_2 = x_2) = \sigma_1^2.$$

A distribuição condicional coincide, então, com a marginal. Isso é consistente com a Proposição 9.6, pois, sob normalidade conjunta, $\rho = 0$ implica independência entre X_1 e X_2 .

Exemplo 9.4 (Condicional em uma normal bivariada padronizada). Considere

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 & 0,8 \\ 0,8 & 1 \end{bmatrix} \right).$$

Para

$$X_2 = 1,$$

a média condicional é

$$E(X_1 | X_2 = 1) = 0,8,$$

e a variância condicional é

$$\begin{aligned} \text{Var}(X_1 | X_2 = 1) &= 1 - 0,8^2 \\ &= 0,36. \end{aligned}$$

Logo,

$$X_1 | X_2 = 1 \sim N(0,8, 0,36).$$

O desvio-padrão condicional é

$$\sqrt{0,36} = 0,6.$$

A Figura 9.2 apresenta as curvas de nível da distribuição conjunta e a densidade condicional de X_1 quando $X_2 = 1$.

No primeiro painel, a linha horizontal identifica o valor condicionado $X_2 = 1$. O ponto sobre essa linha indica a média da distribuição condicional de X_1 .

O segundo painel mostra

$$X_1 | X_2 = 1 \sim N(0,8, 0,36).$$

Em relação à distribuição marginal $N(0,1)$, a média passa de 0 para 0,8 e a variância passa de 1 para 0,36. O exemplo ilustra duas propriedades gerais: a média condicional depende do valor condicionado, enquanto a matriz de covariâncias condicional não depende desse valor.

Sob normalidade multivariada e $\Sigma \succ \mathbf{0}$, o branqueamento relaciona a distância quadrática de Mahalanobis à norma euclidiana de um vetor $N_p(\mathbf{0}, \mathbf{I}_p)$.




Figura 9.2: Distribuição normal bivariada e densidade condicional de X_1 para $X_2 = 1$.

9.5 Distância de Mahalanobis e regiões de probabilidade

A Definição 8.8 definiu a distância de Mahalanobis como uma medida geométrica determinada pela matriz de covariâncias. Quando

$$\mathbf{X} \sim N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

a distância quadrática ao vetor de médias possui uma distribuição probabilística conhecida.

Considere

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0}.$$

A variável aleatória

$$D_M^2 = (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \quad (9.41)$$

representa a distância quadrática de Mahalanobis entre uma realização aleatória e o centro populacional.

9.5.1 Distribuição qui-quadrado

Proposição 9.8 (Distribuição da distância quadrática de Mahalanobis). *A distância quadrática de Mahalanobis*

$$D_M^2 = (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \sim \chi_p^2, \quad (9.42)$$

para

$$\mathbf{X} \sim N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0}.$$

i Demonstração

Pelo branqueamento na Equação 9.23,

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \mathbf{I}_p).$$

As componentes

$$Z_1, \dots, Z_p$$

são, portanto, normais padrão independentes.

Além disso,

$$\begin{aligned} D_M^2 &= (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \\ &= [\Sigma^{-1/2} (\mathbf{X} - \mu)]^\top [\Sigma^{-1/2} (\mathbf{X} - \mu)] \\ &= \mathbf{Z}^\top \mathbf{Z} \\ &= \sum_{j=1}^p Z_j^2. \end{aligned}$$

A soma dos quadrados de p variáveis normais padrão independentes possui distribuição qui-quadrado com p graus de liberdade. Logo,

$$D_M^2 \sim \chi_p^2.$$

Como $\Sigma \succ \mathbf{0}$, a dimensão da distribuição é p , que determina os graus de liberdade da distribuição qui-quadrado.

Consequentemente,

$$E(D_M^2) = p$$

e

$$\text{Var}(D_M^2) = 2p. \quad (9.43)$$

A escala de D_M^2 depende, portanto, da dimensão. Sob o modelo normal, seu valor esperado é p , e não zero.

A igualdade

$$E(D_M^2) = p$$

não depende da normalidade multivariada. A Equação 8.50 do Capítulo 8 registra essa identidade para qualquer vetor aleatório com vetor de médias μ e matriz de covariâncias positiva definida Σ , sem exigir normalidade.

Sob normalidade multivariada, a Proposição 9.8 estabelece

$$D_M^2 \sim \chi_p^2.$$

A distribuição χ_p^2 determina, além da média, a variância e os quantis de D_M^2 .

No espaço branqueado,

$$D_M^2 = \|\mathbf{Z}\|^2.$$

Assim, a distância quadrática de Mahalanobis no espaço original corresponde ao quadrado da distância euclidiana à origem no espaço branqueado.

Parâmetros populacionais e quantidades estimadas

O resultado

$$D_M^2 \sim \chi_p^2$$

utiliza os parâmetros populacionais μ e Σ .

Se esses parâmetros forem substituídos por estimadores obtidos a partir de uma amostra, a distribuição da forma quadrática resultante não será, em geral, χ_p^2 e dependerá das distribuições amostrais dos estimadores envolvidos.

9.5.2 Regiões elipsoidais de probabilidade

Definição 9.2 (Região elipsoidal de probabilidade). Para

$$\mathbf{X} \sim N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

a região elipsoidal de probabilidade $1 - \alpha$ é

$$\mathcal{E}_{1-\alpha} = \left\{ \mathbf{x} \in \mathbb{R}^p : (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \leq \chi_{p;1-\alpha}^2 \right\}, \quad (9.44)$$

em que $0 < \alpha < 1$ e $\chi_{p;1-\alpha}^2$ é o quantil de ordem $1 - \alpha$ da distribuição χ_p^2 .

Consequentemente,

$$P(\mathbf{X} \in \mathcal{E}_{1-\alpha}) = 1 - \alpha.$$

Pela Proposição 9.8,

$$\begin{aligned} P(\mathbf{X} \in \mathcal{E}_{1-\alpha}) &= P[D_M^2 \leq \chi_{p;1-\alpha}^2] \\ &= P[\chi_p^2 \leq \chi_{p;1-\alpha}^2] \\ &= 1 - \alpha. \end{aligned} \quad (9.45)$$

Portanto, $\mathcal{E}_{1-\alpha}$ é uma região populacional que contém uma realização de $\mathbf{X}$ com probabilidade $1 - \alpha$.

Sua fronteira é

$$(\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) = \chi_{p;1-\alpha}^2.$$

A Equação 8.32 define a mesma família de elipsoides de Mahalanobis. Sob normalidade multivariada, a Proposição 9.8 determina a constante por meio de um quantil da distribuição χ_p^2 . No Capítulo 8, o elipsoide foi definido por

$$d_M^2(\mathbf{x}, \mu) \leq c^2,$$

a região de probabilidade $1 - \alpha$ é obtida fazendo

$$c^2 = \chi_{p;1-\alpha}^2,$$

ou, equivalentemente,

$$c = \sqrt{\chi_{p;1-\alpha}^2}.$$

No espaço branqueado, a região corresponde à esfera

$$\{\mathbf{z} \in \mathbb{R}^p : \mathbf{z}^\top \mathbf{z} \leq \chi_{p;1-\alpha}^2\},$$

de raio

$$\sqrt{\chi_{p;1-\alpha}^2}.$$

As superfícies de igual densidade e as fronteiras das regiões elipsoidais de probabilidade possuem a mesma forma geométrica porque ambas são determinadas por valores constantes de d_M^2 . A diferença está na escolha da constante: nas regiões de probabilidade, ela é determinada por um quantil da distribuição χ_p^2 .

Região de probabilidade e região de confiança

A região

$$\mathcal{E}_{1-\alpha}$$

refere-se à posição de uma **realização de $\mathbf{X}$** quando os parâmetros populacionais μ e Σ são conhecidos.

Ela não é uma região de confiança para μ .

Regiões de confiança para parâmetros populacionais são desenvolvidas no Capítulo 12 a partir de distribuições amostrais.

A forma da log-razão entre duas densidades normais depende de as populações compartilharem ou não a mesma matriz de covariâncias. Essa distinção fornece a base probabilística das formas linear e quadrática da Análise Discriminante.

9.6 Comparação entre distribuições normais

Considere duas populações descritas por distribuições normais multivariadas:

$$\mathbf{X}_1 \sim N_p(\mu_1, \Sigma_1)$$

e

$$\mathbf{X}_2 \sim N_p(\mu_2, \Sigma_2),$$

com

$$\Sigma_1 \succ \mathbf{0} \quad \text{e} \quad \Sigma_2 \succ \mathbf{0}.$$

Os vetores de médias determinam a localização das distribuições, enquanto as matrizes de covariâncias determinam sua dispersão, orientação e forma. A comparação entre duas distribuições normais permite observar como esses dois componentes da parametrização atuam conjuntamente.

9.6.1 Médias distintas e covariância comum

Suponha

$$\Sigma_1 = \Sigma_2 = \Sigma,$$

mas

$$\mu_1 \neq \mu_2.$$

As duas distribuições possuem superfícies de igual densidade com a mesma forma, orientação e extensão, mas centradas em pontos diferentes.

Pela log-densidade na Equação 9.11, ambas contêm o termo quadrático

$$-\frac{1}{2} \mathbf{x}^\top \Sigma^{-1} \mathbf{x}.$$

Ao comparar as duas log-densidades, esse termo é comum e se cancela. De fato,

$$\begin{aligned} \log \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} &= \mathbf{x}^\top \Sigma^{-1} (\mu_1 - \mu_2) \\ &\quad - \frac{1}{2} (\mu_1^\top \Sigma^{-1} \mu_1 - \mu_2^\top \Sigma^{-1} \mu_2). \end{aligned} \tag{9.46}$$

A log-razão entre as densidades é, portanto, uma função afim de $\mathbf{x}$.

Consequentemente, o conjunto

$$\{\mathbf{x} \in \mathbb{R}^p : f_1(\mathbf{x}) = f_2(\mathbf{x})\}$$

é um hiperplano.

A matriz de covariâncias comum influencia a orientação desse hiperplano por meio do vetor

$$\Sigma^{-1}(\mu_1 - \mu_2),$$

que determina sua direção normal. Assim, a separação entre os centros é avaliada segundo a geometria induzida pela matriz de covariâncias comum.

9.6.2 Covariâncias distintas

Considere agora

$$\Sigma_1 \neq \Sigma_2.$$

As distribuições podem diferir não somente quanto à localização, mas também quanto à forma, orientação e extensão de suas superfícies de igual densidade.

Nesse caso, as log-densidades envolvem as formas quadráticas

$$-\frac{1}{2}(\mathbf{x} - \mu_1)^\top \Sigma_1^{-1}(\mathbf{x} - \mu_1)$$

e

$$-\frac{1}{2}(\mathbf{x} - \mu_2)^\top \Sigma_2^{-1}(\mathbf{x} - \mu_2).$$

Como as matrizes inversas são diferentes, os termos quadráticos em $\mathbf{x}$ não se cancelam em geral. Expandindo a diferença entre as log-densidades,

$$\begin{aligned} \log \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} &= -\frac{1}{2}\mathbf{x}^\top (\Sigma_1^{-1} - \Sigma_2^{-1})\mathbf{x} \\ &\quad + \mathbf{x}^\top (\Sigma_1^{-1}\mu_1 - \Sigma_2^{-1}\mu_2) \\ &\quad - \frac{1}{2}(\mu_1^\top \Sigma_1^{-1}\mu_1 - \mu_2^\top \Sigma_2^{-1}\mu_2) \\ &\quad - \frac{1}{2} \log \left(\frac{|\Sigma_1|}{|\Sigma_2|} \right). \end{aligned} \tag{9.47}$$

A presença do termo

$$\mathbf{x}^\top (\Sigma_1^{-1} - \Sigma_2^{-1})\mathbf{x}$$

faz com que a log-razão seja, em geral, uma função quadrática de $\mathbf{x}$.

Assim, o conjunto de pontos nos quais

$$f_1(\mathbf{x}) = f_2(\mathbf{x})$$

é determinado, em geral, por uma equação quadrática em $\mathbf{x}$. Sua geometria pode, portanto, diferir substancialmente do hiperplano obtido no caso de covariância comum.

A Figura 9.3 ilustra as duas situações.




Figura 9.3: Comparação entre distribuições normais bivariadas com covariância comum e com covariâncias distintas.

No primeiro painel, as duas distribuições apresentam superfícies de nível com a mesma forma e orientação, deslocadas para centros diferentes. No segundo, as diferenças entre as matrizes de covariâncias modificam também a extensão e a orientação dessas superfícies.

Com uma matriz de covariâncias comum, a Equação 9.46 é uma função afim de $\mathbf{x}$ porque os termos quadráticos comuns se cancelam. Com matrizes de covariâncias distintas, a Equação 9.47 contém, em geral, termos quadráticos.

A primeira forma sustenta a discriminação linear normal desenvolvida na Seção 19.3, enquanto a segunda sustenta a discriminação quadrática da Seção 19.4. Probabilidades *a priori*, funções de perda e estimação dos parâmetros completam as regras de classificação no capítulo de Análise Discriminante.

9.7 Alcance da hipótese de normalidade

Resultados sobre médias, covariâncias, transformações afins, complemento de Schur e geometria de Mahalanobis podem ser obtidos sem normalidade, sob as condições de existência dos momentos e de invertibilidade exigidas em cada caso. A normalidade conjunta acrescenta propriedades sobre a distribuição completa do vetor e de suas transformações.

9.7.1 Resultados que não exigem normalidade

As relações de média e covariância dependem somente da existência dos momentos correspondentes.

Para um vetor aleatório com média μ e matriz de covariâncias Σ ,

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \mu$$

e

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}$$

não exigem normalidade.

Da mesma forma, para

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b},$$

as relações

$$E(\mathbf{Y}) = \mathbf{A}\mu + \mathbf{b}$$

e

$$\text{Cov}(\mathbf{Y}) = \mathbf{A}\Sigma\mathbf{A}^\top$$

são propriedades gerais dos primeiros e segundos momentos.

A Proposição 8.2 estabelece que a matriz de covariâncias é simétrica e positiva semidefinida. Quando $\Sigma \succ \mathbf{0}$, a Definição 8.8 define a geometria de Mahalanobis. A Proposição 8.5 identifica o complemento de Schur com a matriz de covariâncias do resíduo do melhor ajuste linear entre blocos. Nenhuma dessas propriedades exige normalidade multivariada.

Também não depende da normalidade a esperança de uma forma quadrática centrada. Para uma matriz simétrica $\mathbf{A}$,

$$E \left[(\mathbf{X} - \mathbf{a})^\top \mathbf{A} (\mathbf{X} - \mathbf{a}) \right] = \text{tr}(\mathbf{A}\Sigma) + (\mu - \mathbf{a})^\top \mathbf{A} (\mu - \mathbf{a}),$$

desde que existam os momentos de segunda ordem necessários.

Em particular, quando $\Sigma \succ \mathbf{0}$,

$$E \left[(\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \right] = p.$$

Portanto, o valor esperado da distância quadrática de Mahalanobis é uma propriedade de segunda ordem e não uma consequência específica da normalidade.

O vetor de médias, a matriz de covariâncias e as identidades derivadas de seus momentos de primeira e segunda ordem não determinam, em geral, a distribuição conjunta.

9.7.2 Resultados específicos da família normal

Sob normalidade conjunta, valem adicionalmente:

- o vetor de médias e a matriz de covariâncias determinam completamente a distribuição;
- transformações afins preservam a família normal;
- distribuições marginais de subvectores permanecem normais;
- covariância cruzada nula entre blocos conjuntamente normais equivale à independência;
- distribuições condicionais permanecem normais;
- a esperança condicional entre blocos é uma função afim do bloco condicionante;
- a matriz de covariâncias condicional é o complemento de Schur correspondente;
- quando $\Sigma \succ \mathbf{0}$, o branqueamento produz componentes normais padrão independentes;
- quando $\Sigma \succ \mathbf{0}$, a distância quadrática de Mahalanobis populacional possui distribuição χ_p^2 .

A equivalência

$$\Sigma_{12} = \mathbf{0} \quad \Longleftrightarrow \quad \mathbf{X}_1 \perp \mathbf{X}_2$$

é um exemplo da diferença entre uma propriedade geral de covariância e uma propriedade específica da família normal.

A implicação

$$\mathbf{X}_1 \perp \mathbf{X}_2 \quad \Longrightarrow \quad \Sigma_{12} = \mathbf{0}$$

vale, quando os segundos momentos existem, sem normalidade. A implicação inversa requer que os dois blocos sejam conjuntamente normais, conforme a Proposição 9.6.

De maneira semelhante, a igualdade

$$E(D_M^2) = p$$

decorre do vetor de médias e da matriz de covariâncias, sem exigir normalidade, mas a afirmação

$$D_M^2 = (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \sim \chi_p^2$$

é específica do modelo normal multivariado sob $\Sigma \succ \mathbf{0}$.

Conhecer apenas μ e Σ permite determinar a esperança dessa forma quadrática, mas não sua distribuição. A distribuição qui-quadrado estabelecida na Proposição 9.8 requer normalidade multivariada.

A diferença entre $E(D_M^2) = p$ e $D_M^2 \sim \chi_p^2$ distingue uma propriedade de segunda ordem de uma propriedade distributiva específica da família normal.

9.7.3 Passagem do modelo populacional para a inferência

Neste capítulo, μ e Σ são parâmetros populacionais da distribuição

$$N_p(\mu, \Sigma),$$

e os resultados anteriores consideram esses parâmetros conhecidos.

Em uma aplicação estatística, esses parâmetros são geralmente desconhecidos. A observação de uma amostra introduz uma nova distinção entre:

- parâmetros populacionais;
- estatísticas aleatórias;
- estimadores;
- valores calculados a partir dos dados observados.

A substituição de parâmetros populacionais por estimadores altera a distribuição de algumas formas quadráticas. Por exemplo,

$$(\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \sim \chi_p^2$$

não autoriza substituir diretamente μ e Σ por estimativas e manter a mesma distribuição.

Da mesma forma, conhecer a forma da densidade normal não é suficiente para realizar inferência sobre parâmetros desconhecidos. É necessário especificar uma amostra aleatória, construir estatísticas e estudar suas propriedades e distribuições amostrais.

No Capítulo 10, a Definição 10.1 introduz a amostra aleatória multivariada, a Equação 10.8 define o vetor de médias amostral e a Definição 10.10 define a matriz de covariâncias amostral. Esses objetos permitem estimar μ e Σ e estudar suas distribuições amostrais.

9.8 Aprofundamento metodológico e aplicado

Para μ e $\Sigma \succ \mathbf{0}$ conhecidos, a região elipsoidal $\mathcal{E}_{1-\alpha}$ da Definição 9.2 também pode ser utilizada para avaliar a posição de um ponto fixo por meio de sua distância quadrática de Mahalanobis.

9.8.1 Avaliação de uma observação fixa

Considere um ponto fixo

$$\mathbf{x}_0 \in \mathbb{R}^p.$$

Sua distância quadrática de Mahalanobis em relação ao modelo é

$$d_M^2(\mathbf{x}_0, \mu) = (\mathbf{x}_0 - \mu)^\top \Sigma^{-1} (\mathbf{x}_0 - \mu). \quad (9.48)$$

O ponto está dentro de $\mathcal{E}_{1-\alpha}$ quando

$$d_M^2(\mathbf{x}_0, \mu) \leq \chi_{p;1-\alpha}^2. \quad (9.49)$$

Se

$$d_M^2(\mathbf{x}_0, \mu) > \chi_{p;1-\alpha}^2,$$

a observação está fora da região que contém probabilidade populacional $1 - \alpha$.

O critério da Equação 9.49 determina a posição de um valor já observado em relação à região populacional. Depois que $\mathbf{x}_0$ foi fixado, não se atribui a ele probabilidade de pertencer à região: ele está dentro ou fora dela.

Também pode ser calculada a probabilidade de cauda

$$p_M = P[\chi_p^2 \geq d_M^2(\mathbf{x}_0, \mu)]. \quad (9.50)$$

A quantidade p_M mede, sob o modelo populacional completamente especificado, a probabilidade de obter uma distância quadrática de Mahalanobis pelo menos tão grande quanto a observada.

Um valor pequeno de p_M indica que, sob a distribuição especificada, é pequena a probabilidade de obter uma distância quadrática de Mahalanobis pelo menos tão grande quanto a observada. Essa interpretação pressupõe μ e Σ conhecidos e não constitui um procedimento inferencial para detecção de observações atípicas quando esses parâmetros são estimados.

Exemplo 9.5 (Avaliação de uma observação em uma normal bivariada). Considere

$$\mathbf{x} \sim N_2 \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 4 & 1 \\ 1 & 1 \end{bmatrix} \right)$$

e

$$\mathbf{x}_0 = \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

A inversa da matriz de covariâncias é

$$\Sigma^{-1} = \frac{1}{3} \begin{bmatrix} 1 & -1 \\ -1 & 4 \end{bmatrix}.$$

Logo,

$$\begin{aligned} d_M^2(\mathbf{x}_0, \mu) &= \begin{bmatrix} 3 & 1 \end{bmatrix} \frac{1}{3} \begin{bmatrix} 1 & -1 \\ -1 & 4 \end{bmatrix} \begin{bmatrix} 3 \\ 1 \end{bmatrix} \\ &= \frac{7}{3} \\ &\approx 2,33. \end{aligned}$$

Para a região que contém probabilidade 0,95,

$$\chi_{2;0,95}^2 \approx 5,99.$$

Como

$$2,33 < 5,99,$$

a observação está dentro da região elipsoidal que contém 95% da probabilidade populacional.

A probabilidade de cauda associada à distância observada é

$$p_M = P(\chi_2^2 \geq 2,33) \\ \approx 0,31.$$

Assim, aproximadamente 31% dos vetores gerados pelo modelo apresentam distância quadrática de Mahalanobis ao centro pelo menos tão grande quanto a observada. O ponto, portanto, não apresenta um afastamento particularmente extremo em relação à distribuição especificada.

Se μ e Σ forem substituídos por estimadores obtidos a partir de uma amostra, a distribuição da forma quadrática resultante não será, em geral, χ_p^2 e deverá ser determinada a partir das distribuições amostrais dos estimadores envolvidos.

9.9 Aprofundamento teórico: Normal Singular

Leitura de aprofundamento

Se

$$\Sigma \succ \mathbf{0},$$

a matriz de covariâncias é invertível e a distribuição normal multivariada possui densidade em todo $\mathbb{R}^p$.

Se Σ é positiva semidefinida e singular, existem direções com variância zero e a distribuição fica concentrada em um subespaço afim de dimensão inferior a p . A dimensão efetiva, o suporte, a densidade no suporte, o branqueamento reduzido e a forma generalizada de Mahalanobis dependem do posto de Σ .

Definição 9.3 (Distribuição normal multivariada singular). Uma distribuição

$$N_p(\mu, \Sigma)$$

é denominada **singular** ou **degenerada** quando

$$\text{posto}(\Sigma) = r < p.$$

Como toda matriz de covariâncias é positiva semidefinida, esse caso equivale a

$$\Sigma \succeq \mathbf{0} \quad \text{e} \quad \Sigma \neq \mathbf{0}.$$

A distribuição é **não singular** quando

$$\text{posto}(\Sigma) = p,$$

equivalentemente,

$$\Sigma \succ \mathbf{0}.$$

A normal singular surge quando existem relações lineares exatas entre as componentes do vetor. Se, por exemplo,

$$X_3 = X_1 + X_2$$

quase certamente, uma das componentes não acrescenta uma nova direção de variabilidade e a matriz de covariâncias não possui posto completo.

O caso singular também pode resultar de uma transformação linear que reduz a dimensão. Se

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b} \in \mathbb{R}^m$$

e

$$\text{posto}(\mathbf{A}) < m,$$

então

$$\text{posto}(\mathbf{A}\Sigma\mathbf{A}^\top) \leq \text{posto}(\mathbf{A}) < m.$$

Portanto,

$$\text{Cov}(\mathbf{Y}) = \mathbf{A}\Sigma\mathbf{A}^\top$$

é singular.

Vetores normais sujeitos a restrições lineares exatas podem, portanto, possuir dimensão probabilística efetiva menor que a dimensão do espaço ambiente em que são representados.

A singularidade de uma matriz de covariâncias calculada a partir de uma amostra, entretanto, não implica singularidade da matriz de covariâncias populacional. Pela Equação 8.60, para uma matriz de dados com n observações e p variáveis,

$$\text{posto}(\mathbf{S}) \leq \min(p, n-1).$$

Assim, quando $p \geq n$, a matriz de covariâncias observada é necessariamente singular, mesmo que a matriz de covariâncias populacional seja positiva definida. No Capítulo 10, $\mathbf{S}$ será formalizada como realização da matriz de covariâncias amostral aleatória.

Considere inicialmente

$$1 \leq r = \text{posto}(\Sigma) < p.$$

O caso $r = 0$ é tratado separadamente ao final da seção.

Como Σ é simétrica e positiva semidefinida, o Teorema 5.2 e a Proposição 5.5 garantem que sua decomposição espectral reduzida pode ser escrita como

$$\Sigma = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top. \quad (9.51)$$

em que

$$\mathbf{Q}_r \in \mathbb{R}^{p \times r}$$

possui colunas ortonormais associadas aos r autovalores positivos e

$$\Lambda_r = \text{diag}(\lambda_1, \dots, \lambda_r), \quad \lambda_j > 0.$$

Pela Proposição 5.8,

$$\mathcal{C}(\Sigma) = \mathcal{C}(\mathbf{Q}_r).$$

Definindo

$$\mathbf{A}_r = \mathbf{Q}_r \Lambda_r^{1/2},$$

tem-se

$$\Sigma = \mathbf{A}_r \mathbf{A}_r^\top.$$

Logo, uma representação da distribuição singular é

$$\mathbf{X} \stackrel{d}{=} \mu + \mathbf{A}_r \mathbf{Z}, \quad \mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r). \quad (9.52)$$

Pela Proposição 8.3, qualquer vetor aleatório com matriz de covariâncias singular Σ satisfaz

$$\mathbf{X} - \mu \in \mathcal{C}(\Sigma)$$

quase certamente. Para a normal multivariada, a Equação 9.52 estabelece adicionalmente que o suporte é todo o subespaço afim

$$\mu + \mathcal{C}(\Sigma).$$

Proposição 9.9 (Suporte efetivo da normal singular). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma)$$

e

$$\text{posto}(\Sigma) = r < p,$$

o suporte da distribuição é o subespaço afim

$$\mu + \mathcal{C}(\Sigma),$$

de dimensão r .

Consequentemente,

$$P[\mathbf{X} \in \mu + \mathcal{C}(\Sigma)] = 1. \quad (9.53)$$

i Demonstração

Pela representação Equação 9.52,

$$\mathbf{X} \stackrel{d}{=} \mu + \mathbf{A}_r \mathbf{Z}.$$

Como $\Lambda_r^{1/2}$ é invertível,

$$\mathcal{C}(\mathbf{A}_r) = \mathcal{C}(\mathbf{Q}_r) = \mathcal{C}(\Sigma).$$

Portanto,

$$\mathbf{A}_r \mathbf{Z} \in \mathcal{C}(\Sigma)$$

quase certamente, o que fornece a Equação 9.53.

Além disso, $\mathbf{A}_r$ possui posto coluna r . A aplicação

$$\mathbf{z} \mapsto \mu + \mathbf{A}_r \mathbf{z}$$

é uma transformação afim bijetiva entre $\mathbb{R}^r$ e

$$\mu + \mathcal{C}(\Sigma).$$

Como a normal padrão em $\mathbb{R}^r$ possui densidade positiva em todo $\mathbb{R}^r$, todo conjunto relativamente aberto e não vazio desse subespaço afim possui probabilidade positiva. Assim, esse subespaço é o suporte da distribuição.

As direções sem variabilidade também podem ser caracterizadas pelo núcleo da matriz de covariâncias. Se

$$\mathbf{a} \in \mathcal{N}(\Sigma),$$

então

$$\text{Var}[\mathbf{a}^\top (\mathbf{X} - \mu)] = \mathbf{a}^\top \Sigma \mathbf{a} = 0,$$

e, conseqüentemente,

$$\mathbf{a}^\top (\mathbf{X} - \mu) = 0$$

quase certamente.

As direções do núcleo são, portanto, direções sem variabilidade probabilística.

A normal singular não possui densidade em relação à medida de Lebesgue de dimensão p em $\mathbb{R}^p$, pois toda a probabilidade está concentrada no suporte

$$\mu + \mathcal{C}(\Sigma),$$

de dimensão $r < p$. Nesse subespaço afim, a distribuição possui densidade em relação à medida de volume r -dimensional.

Exemplo 9.6 (Normal bivariada concentrada em uma reta). Considere

$$Z \sim N(0, 1)$$

e defina

$$\mathbf{x} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} = \begin{bmatrix} Z \\ 2Z \end{bmatrix}.$$

Equivalentemente,

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} Z.$$

Logo,

$$\mathbf{x} \sim N_2 \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} \right).$$

A matriz de covariâncias possui posto 1 e

$$X_2 = 2X_1$$

quase certamente. Portanto, toda a distribuição está concentrada na reta

$$x_2 = 2x_1.$$

Embora o vetor tenha duas componentes, sua dimensão probabilística efetiva é 1.

Densidade no suporte da normal singular

Pela Proposição 9.9, a distribuição está concentrada no subespaço afim

$$\mu + \mathcal{C}(\Sigma),$$

de dimensão

$$r = \text{posto}(\Sigma).$$

Pela decomposição espectral da Equação 9.51,

$$\Sigma = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top, \quad \Lambda_r = \text{diag}(\lambda_1, \dots, \lambda_r),$$

a Definição 5.11 fornece

$$\Sigma^+ = \mathbf{Q}_r \Lambda_r^{-1} \mathbf{Q}_r^\top.$$

Como

$$\det(\Lambda_r) = \prod_{j=1}^r \lambda_j > 0,$$

a densidade relativamente à medida de volume r -dimensional no suporte afim pode ser escrita como

$$f_{\text{sup}}(\mathbf{x}) = \frac{1}{(2\pi)^{r/2} \det(\Lambda_r)^{1/2}} \exp \left[-\frac{1}{2} (\mathbf{x} - \mu)^\top \Sigma^+ (\mathbf{x} - \mu) \right], \quad (9.54)$$

para

$$\mathbf{x} \in \mu + \mathcal{C}(\Sigma).$$

A Equação 9.54 possui a mesma forma exponencial quadrática da Equação 9.8, mas envolve somente os r autovalores positivos de Σ (Anderson, 2003).

A Equação 9.52 permite expressar a normal singular por meio de uma normal não singular de dimensão r . Defina

$$\mathbf{Y} = \Lambda_r^{1/2} \mathbf{Z}, \quad \mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r).$$

Pela Proposição 9.1,

$$\mathbf{Y} \sim N_r(\mathbf{0}, \Lambda_r).$$

Assim, a Equação 9.52 pode ser escrita como

$$\mathbf{X} \stackrel{d}{=} \mu + \mathbf{Q}_r \mathbf{Y}. \quad (9.55)$$

Portanto, a normal singular em $\mathbb{R}^p$ corresponde à representação de uma normal não singular de dimensão r no subespaço afim

$$\mu + \mathcal{C}(\Sigma).$$

Branqueamento no caso singular

Se

$$\text{posto}(\Sigma) = r < p,$$

a matriz $\Sigma^{1/2}$ é singular e não possui inversa ordinária. Utilizando

$$\Sigma = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top,$$

pode-se definir

$$\mathbf{Z}_r = \Lambda_r^{-1/2} \mathbf{Q}_r^\top (\mathbf{X} - \mu). \quad (9.56)$$

Então,

$$\mathbf{Z}_r \sim N_r(\mathbf{0}, \mathbf{I}_r). \quad (9.57)$$

A Equação 9.56 projeta $\mathbf{X} - \mu$ nas r direções de variância positiva e padroniza essas coordenadas. O vetor resultante possui distribuição $N_r(\mathbf{0}, \mathbf{I}_r)$, embora $\mathbf{X}$ seja representado em $\mathbb{R}^p$.

Proposição 9.10 (Forma generalizada de Mahalanobis no caso normal singular). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma), \quad 1 \leq r = \text{posto}(\Sigma) < p,$$

a forma quadrática generalizada de Mahalanobis

$$D_{M,+}^2 = (\mathbf{X} - \mu)^\top \Sigma^+ (\mathbf{X} - \mu) \quad (9.58)$$

satisfaz

$$D_{M,+}^2 \sim \chi_r^2, \quad (9.59)$$

em que Σ^+ é a pseudoinversa de Moore–Penrose de Σ .

i Demonstração

Considere a decomposição espectral reduzida

$$\Sigma = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top,$$

em que

$$\Lambda_r = \text{diag}(\lambda_1, \dots, \lambda_r), \quad \lambda_j > 0.$$

Pelo branqueamento reduzido na Equação 9.56,

$$\mathbf{Z}_r = \Lambda_r^{-1/2} \mathbf{Q}_r^\top (\mathbf{X} - \mu) \sim N_r(\mathbf{0}, \mathbf{I}_r).$$

A pseudoinversa de Σ é

$$\Sigma^+ = \mathbf{Q}_r \Lambda_r^{-1} \mathbf{Q}_r^\top.$$

Como

$$\mathbf{X} - \mu \in \mathcal{C}(\Sigma)$$

quase certamente,

$$\begin{aligned} & (\mathbf{X} - \mu)^\top \Sigma^+ (\mathbf{X} - \mu) \\ &= \mathbf{Z}_r^\top \mathbf{Z}_r \\ &= \sum_{j=1}^r Z_{rj}^2. \end{aligned}$$

As componentes de $\mathbf{Z}_r$ são normais padrão independentes. Portanto,

$$\mathbf{Z}_r^\top \mathbf{Z}_r \sim \chi_r^2.$$

Consequentemente,

$$E(D_{M,+}^2) = r$$

e

$$\text{Var}(D_{M,+}^2) = 2r.$$

A distribuição de $D_{M,+}^2$, sua média, sua variância e seus quantis dependem da dimensão efetiva r , e não da dimensão ambiente p .

Uma região de probabilidade $1 - \alpha$ no suporte efetivo pode ser definida por

$$\mathcal{E}_{1-\alpha}^{(r)} = \left\{ \mathbf{x} \in \mathbb{R}^p : \mathbf{x} - \mu \in \mathcal{C}(\Sigma), \right. \\ \left. (\mathbf{x} - \mu)^\top \Sigma^+ (\mathbf{x} - \mu) \leq \chi_{r;1-\alpha}^2 \right\}. \quad (9.60)$$

Pela Proposição 9.10,

$$P \left[\mathbf{X} \in \mathcal{E}_{1-\alpha}^{(r)} \right] = 1 - \alpha.$$

A calibração utiliza a dimensão efetiva r , e não a dimensão ambiente p .

Se

$$r = 0,$$

então

$$\Sigma = \mathbf{0}$$

e

$$\mathbf{X} = \mu$$

quase certamente. Nesse caso extremo, a distribuição está concentrada em um único ponto.

A restrição

$$\mathbf{x} - \mu \in \mathcal{C}(\Sigma)$$

é necessária porque a distribuição singular atribui probabilidade 1 ao seu suporte afim.

9.10 Síntese do capítulo

Se $\mathbf{X} \sim N_p(\mu, \Sigma)$, sua distribuição conjunta é completamente determinada por μ e Σ .

A Tabela 9.1 reúne os principais resultados.

Tabela 9.1: Principais estruturas e resultados da distribuição normal multivariada.

Estrutura	Resultado
Definição	$\mathbf{a}^\top \mathbf{X}$ é normal para todo $\mathbf{a} \in \mathbb{R}^p$
Parametrização	$\mathbf{X} \sim N_p(\mu, \Sigma)$ é determinada por μ e Σ
Construção	$\mathbf{X} \stackrel{d}{=} \mu + \mathbf{A}\mathbf{Z}$, com $\Sigma = \mathbf{A}\mathbf{A}^\top$
Caso singular	se $\text{posto}(\Sigma) = r < p$, o suporte é $\mu + \mathcal{C}(\Sigma)$ e a densidade é definida relativamente ao volume r -dimensional nesse subespaço
Caso não singular	se $\Sigma \succ \mathbf{0}$, o suporte é $\mathbb{R}^p$ e existe densidade em relação à medida de Lebesgue em $\mathbb{R}^p$
Transformação afim	$\mathbf{A}\mathbf{X} + \mathbf{b}$ permanece normal
Marginalização	subvectores de um vetor normal multivariado permanecem normais
Independência	$\Sigma_{12} = \mathbf{0}$ equivale à independência entre blocos conjuntamente normais
Condicionamento	a distribuição condicional é normal, com média afim e covariância dada por complemento de Schur
Branqueamento	se $\Sigma \succ \mathbf{0}$, produz $N_p(\mathbf{0}, \mathbf{I}_p)$; no caso singular, o branqueamento reduzido produz $N_r(\mathbf{0}, \mathbf{I}_r)$
Mahalanobis	$D_M^2 \sim \chi_p^2$ no caso não singular
Regiões de probabilidade	$D_M^2 \leq \chi_{p;1-\alpha}^2$ define uma região populacional de probabilidade $1 - \alpha$
Caso singular de Mahalanobis	$D_{M,+}^2 \sim \chi_r^2$, com $r = \text{posto}(\Sigma)$
Comparação de distribuições	covariância comum produz log-razão afim; covariâncias distintas produzem, em geral, log-razão quadrática

A definição por combinações lineares caracteriza a normalidade por todas as projeções $\mathbf{a}^\top \mathbf{X}$. A representação afim expressa um vetor normal como transformação de um vetor normal padrão e relaciona diretamente μ e Σ à sua distribuição conjunta.

Quando $\Sigma \succ \mathbf{0}$, a distribuição possui densidade em $\mathbb{R}^p$, o branqueamento produz uma normal padrão multivariada e a distância quadrática de Mahalanobis possui distribuição χ_p^2 . Por isso, os elipsoides de Mahalanobis podem ser calibrados por quantis da distribuição χ_p^2 para formar regiões populacionais com probabilidade especificada.

Quando Σ é singular, a distribuição permanece normal, mas sua variabilidade fica restrita ao subespaço afim $\mu + \mathcal{C}(\Sigma)$. A dimensão probabilística efetiva passa a ser $r = \text{posto}(\Sigma)$. A decomposição espectral reduzida fornece as coordenadas efetivas, a densidade e o branqueamento

no suporte, enquanto a pseudoinversa de Moore–Penrose permite definir a forma quadrática generalizada de Mahalanobis.

Transformações afins e marginalizações preservam a família normal. Sob normalidade conjunta, covariância cruzada nula equivale à independência entre blocos, e o complemento de Schur fornece a matriz de covariâncias da distribuição condicional.

Ao término deste capítulo, deve-se ser capaz de:

- caracterizar uma distribuição normal multivariada por combinações lineares;
- construir vetores normais por transformações afins de vetores normais padrão;
- distinguir distribuições normais singulares e não singulares;
- identificar o suporte e a dimensão probabilística efetiva de uma normal singular;
- interpretar a densidade normal multivariada e suas superfícies de nível;
- obter distribuições de transformações afins, combinações lineares e subvetores;
- diferenciar padronização marginal e branqueamento;
- relacionar covariância cruzada nula e independência sob normalidade conjunta;
- determinar média e matriz de covariâncias de uma distribuição condicional;
- interpretar o complemento de Schur como covariância condicional;
- utilizar a distribuição qui-quadrado da distância de Mahalanobis populacional e interpretar regiões elipsoidais de probabilidade;
- comparar distribuições normais com covariância comum e com covariâncias distintas por meio de suas log-densidades;
- distinguir resultados gerais de segunda ordem daqueles que dependem da normalidade.

Neste capítulo, μ e Σ são parâmetros populacionais. No Capítulo 10, a Definição 10.1 introduz a amostra aleatória multivariada, a Equação 10.8 define o vetor de médias amostral e a Definição 10.10 define a matriz de covariâncias amostral. Esses objetos serão utilizados para estimar μ e Σ e estudar as propriedades de seus estimadores.

10 Estatísticas Amostrais e Estimação

O Capítulo 8 definiu o vetor de médias populacional na Equação 8.1 e a matriz de covariâncias populacional na Definição 8.2. O Capítulo 9 formulou a distribuição normal multivariada na Definição 9.1. Em aplicações estatísticas, μ e Σ são parâmetros populacionais geralmente desconhecidos e precisam ser estimados a partir de uma amostra.

A passagem da população para a amostra introduz estatísticas aleatórias utilizadas como estimadores. Entre elas estão o vetor de médias amostrais, a matriz de somas de quadrados e produtos cruzados (SQPC), os estimadores da matriz de covariâncias, a matriz de correlações amostral e as covariâncias cruzadas entre blocos de variáveis.

Os métodos dos momentos e da máxima verossimilhança fornecem princípios de construção para esses estimadores. As derivações utilizam, quando necessário, propriedades matriciais e resultados de cálculo estabelecidos no Módulo 1. A Capítulo 12 trata das distribuições amostrais exatas, da distribuição de Wishart, da independência entre o vetor de médias e a matriz de covariâncias amostrais sob normalidade e dos procedimentos de inferência.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{X} \in \mathbb{R}^p$ representa um vetor aleatório populacional;
- $\mathbf{X}_1, \dots, \mathbf{X}_n$ representam os vetores aleatórios que compõem a amostra;
- $\mathbf{x}_1, \dots, \mathbf{x}_n$ representam suas realizações;
- $\mathcal{X} \in \mathbb{R}^{n \times p}$ representa a matriz aleatória da amostra;
- $\mathbf{X} \in \mathbb{R}^{n \times p}$ representa a matriz de dados observada;
- μ, Σ e $\mathcal{R}$ representam, respectivamente, o vetor de médias, a matriz de covariâncias e a matriz de correlações populacionais;
- $\bar{\mathbf{X}}$ representa o vetor de médias amostrais como estatística aleatória, enquanto $\bar{\mathbf{x}}$ representa seu valor observado;
- $\mathbf{T}$ representa a matriz total de somas de quadrados e produtos cruzados (SQPC) como estatística aleatória, e $\mathbf{T}$ sua realização observada;
- $\mathbf{S}$ representa a matriz de covariâncias amostral como estatística aleatória, e $\mathbf{S}$ seu valor observado;
- $\mathbf{R}$ representa a matriz de correlações amostral como estatística aleatória, e $\mathbf{R}$ seu valor observado;
- T_{jk}, S_{jk} e R_{jk} representam elementos das respectivas matrizes aleatórias, enquanto

- t_{jk} , s_{jk} e r_{jk} representam seus valores observados;
- $\mathbf{G} = G(\mathcal{X})$ denota genericamente uma estatística; o símbolo $\mathbf{T}$ permanece reservado à matriz SQPC;
- $\hat{\theta}$ representa um estimador de um parâmetro θ , e $\hat{\theta}_{\text{obs}}$ o valor assumido pelo estimador após a observação da amostra.

10.1 Da população à amostra

Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ \vdots \\ X_p \end{bmatrix} \in \mathbb{R}^p$$

com distribuição pertencente a uma família

$$\{F_\theta : \theta \in \Theta\},$$

em que θ representa o conjunto de parâmetros desconhecidos e Θ é o espaço paramétrico.

Quando existem momentos de primeira e segunda ordem, o vetor de médias e a matriz de covariâncias definidos na Equação 8.1 e Definição 8.2 satisfazem

$$E(\mathbf{X}) = \mu \in \mathbb{R}^p$$

e

$$\text{Cov}(\mathbf{X}) = \Sigma \in \mathbb{R}^{p \times p}.$$

Os parâmetros são características fixas da distribuição populacional. A aleatoriedade introduzida pelo processo de amostragem está nos vetores que compõem a amostra e, consequentemente, nas estatísticas definidas a partir deles.

10.1.1 Amostra aleatória multivariada

A unidade amostral de um estudo multivariado é um vetor. Cada unidade fornece simultaneamente os valores das p variáveis que compõem $\mathbf{X}$.

Definição 10.1 (Amostra aleatória multivariada). Uma amostra aleatória multivariada de tamanho n proveniente de F_θ é uma coleção de vetores aleatórios

$$\mathbf{X}_1, \dots, \mathbf{X}_n \in \mathbb{R}^p$$

independentes e identicamente distribuídos:

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} F_\theta. \quad (10.1)$$

A notação

$$\stackrel{\text{iid}}{\sim}$$

indica que os vetores aleatórios são independentes e identicamente distribuídos segundo a mesma distribuição.

A condição de distribuição idêntica estabelece que todas as unidades são regidas pela mesma distribuição populacional. A independência estabelece que a realização de uma unidade não altera a distribuição das demais unidades (Johnson; Wichern, 2002).

Quando a distribuição populacional possui densidade em relação a uma medida comum, a independência implica

$$f_\theta^{(n)}(\mathbf{x}_1, \dots, \mathbf{x}_n) = \prod_{i=1}^n f_\theta(\mathbf{x}_i). \quad (10.2)$$

A independência também implica a fatoração da função de distribuição conjunta da amostra:

$$F_\theta^{(n)}(\mathbf{x}_1, \dots, \mathbf{x}_n) = \prod_{i=1}^n F_\theta(\mathbf{x}_i). \quad (10.3)$$

Essas fatorações dizem respeito à independência **entre unidades amostrais**. A dependência entre as componentes de um mesmo vetor continua representada pela distribuição multivariada F_θ .

Cada vetor da amostra possui a forma

$$\mathbf{X}_i = \begin{bmatrix} X_{i1} \\ X_{i2} \\ \vdots \\ X_{ip} \end{bmatrix}, \quad i = 1, \dots, n,$$

em que X_{ij} representa a variável j na unidade i .

A independência entre

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

não implica independência entre

$$X_{i1}, \dots, X_{ip}.$$

As componentes de uma mesma unidade podem apresentar covariâncias e outras formas de dependência.

Quando os segundos momentos existem,

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma$$

para todo i . Para unidades distintas,

$$\text{Cov}(\mathbf{X}_i, \mathbf{X}_\ell) = \mathbf{0}, \quad i \neq \ell,$$

como consequência da independência.

No modelo normal multivariado definido na Definição 9.1,

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma). \quad (10.4)$$

A definição do vetor de médias amostrais, da matriz SQPC, da matriz de covariâncias amostral e da matriz de correlações amostral não exige normalidade. As expressões de máxima verossimilhança para μ e Σ desenvolvidas neste capítulo são obtidas sob o modelo normal multivariado. A Capítulo 12 estabelece as distribuições amostrais exatas sob normalidade e os resultados inferenciais correspondentes.

10.1.2 Matriz aleatória da amostra e matriz observada

Os vetores da amostra podem ser organizados nas linhas de uma matriz aleatória.

Definição 10.2 (Matriz aleatória da amostra). A matriz aleatória associada à amostra é

$$\mathcal{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} = \begin{bmatrix} X_{11} & X_{12} & \cdots & X_{1p} \\ X_{21} & X_{22} & \cdots & X_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ X_{n1} & X_{n2} & \cdots & X_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (10.5)$$

Antes da coleta dos dados, os elementos de $\mathcal{X}$ são variáveis aleatórias. Cada possível resultado do processo amostral corresponde a uma matriz numérica.

Após a observação da amostra, uma realização de $\mathcal{X}$ coincide com a matriz de dados definida na Definição 1.6 e é denotada por

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (10.6)$$

A diferença tipográfica registra a natureza dos objetos:

- $\mathcal{X}$ é a matriz aleatória da amostra;
- $\mathbf{X}$ é a matriz de dados observada;
- $\mathbf{X}_i$ é o vetor aleatório correspondente à unidade i ;
- $\mathbf{x}_i$ é sua realização;
- X_{ij} é uma variável aleatória;
- x_{ij} é o valor observado correspondente.

Se o suporte de $\mathbf{X}$ é

$$\mathcal{S}_{\mathbf{X}} \subseteq \mathbb{R}^p,$$

o espaço das possíveis amostras é

$$\mathcal{S}_{\mathbf{X}}^n.$$

No caso em que

$$\mathcal{S}_{\mathbf{X}} = \mathbb{R}^p,$$

esse espaço pode ser identificado com

$$(\mathbb{R}^p)^n$$

ou, equivalentemente, com o conjunto das matrizes reais $n \times p$.

Uma estatística associa a cada possível realização da amostra uma quantidade escalar, vetorial ou matricial. Antes da observação da amostra, ela constitui um objeto aleatório; após a observação, obtém-se seu valor calculado a partir de $\mathbf{X}$.

10.1.3 Parâmetros, estatísticas, estimadores e estimativas

Um parâmetro é uma característica fixa da distribuição populacional. Ele pode ser escalar, vetorial ou matricial.

As principais quantidades populacionais consideradas na estimação são o vetor de médias μ , definido na Equação 8.1, a matriz de covariâncias Σ , definida na Definição 8.2, e a matriz de correlações $\mathcal{R}$, definida na Definição 8.5.

A matriz $\mathcal{R}$ é determinada por Σ e, portanto, não constitui um parâmetro adicional quando a matriz de covariâncias já integra a parametrização do modelo.

No modelo normal multivariado não singular definido na Definição 9.1, o parâmetro completo pode ser representado por

$$\theta = (\mu, \Sigma),$$

com espaço paramétrico

$$\Theta = \{(\mu, \Sigma) : \mu \in \mathbb{R}^p, \Sigma \succ \mathbf{0}\}.$$

Definição 10.3 (Estatística amostral). Considere a matriz aleatória da amostra

$$\mathcal{X} \in \mathbb{R}^{n \times p}.$$

Uma estatística é uma função

$$G : \mathbb{R}^{n \times p} \longrightarrow \mathcal{T},$$

cujas regras de cálculo não contêm parâmetros populacionais desconhecidos, em que $\mathcal{T}$ é o espaço em que o resultado assume valores.

A estatística correspondente é

$$\mathbf{G} = G(\mathcal{X}). \quad (10.7)$$

O espaço $\mathcal{T}$ pode ser escalar, vetorial ou matricial, de acordo com a estatística considerada.

Embora a expressão da estatística não contenha parâmetros desconhecidos, sua distribuição amostral pode depender dos parâmetros da distribuição populacional.

O vetor de médias amostrais é um exemplo de estatística vetorial:

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i. \quad (10.8)$$

Após a observação da amostra,

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i. \quad (10.9)$$

A distribuição de uma estatística é denominada **distribuição amostral**. Ela descreve como a estatística varia entre as possíveis realizações da amostra aleatória de tamanho n .

Distribuição populacional e distribuição amostral

A distribuição

$$\mathbf{X} \sim F_\theta$$

descreve a variabilidade de uma unidade populacional.

A distribuição de

$$\mathbf{G} = G(\mathcal{X})$$

descreve a variabilidade da estatística entre as possíveis realizações da amostra.

A distribuição populacional e a distribuição amostral correspondem a objetos probabilísticos distintos. A Capítulo 12 estabelece distribuições amostrais específicas das estatísticas utilizadas nos procedimentos inferenciais.

Uma estatística torna-se um estimador quando é utilizada para aproximar um parâmetro desconhecido.

Definição 10.4 (Estimador e estimativa). Considere um parâmetro

$$\theta \in \Theta \subseteq \mathcal{A},$$

em que $\mathcal{A}$ é o espaço em que o parâmetro é representado.

Um estimador de θ é uma estatística definida por uma função

$$G : \mathbb{R}^{n \times p} \longrightarrow \mathcal{A},$$

de modo que

$$\hat{\theta} = G(\mathcal{X}). \quad (10.10)$$

A estimativa é o valor assumido pelo estimador após a observação da amostra:

$$\hat{\theta}_{\text{obs}} = G(\mathbf{X}). \quad (10.11)$$

Todo estimador é uma estatística, mas nem toda estatística precisa ser utilizada para estimar um parâmetro. A função atribuída à estatística depende do objetivo da análise.

Assim,

$$\bar{\mathbf{X}}$$

é um estimador de μ , enquanto

$$\bar{\mathbf{x}}$$

é a estimativa obtida para uma amostra específica.

A matriz de covariâncias amostral definida na Definição 10.10,

$$\mathbf{S},$$

é um estimador de Σ , enquanto

$$\mathbf{s}$$

é sua realização observada.

O erro de estimação é

$$\hat{\theta} - \theta. \quad (10.12)$$

Como o estimador é uma função da amostra aleatória, o erro de estimação também é aleatório. A distribuição do erro de estimação determina as probabilidades associadas aos possíveis valores de $\hat{\theta} - \theta$ e sustenta a avaliação de viés e variabilidade.

Um mesmo parâmetro pode possuir diferentes estimadores. Para Σ , dois estimadores construídos a partir da matriz SQPC são o estimador não viesado

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}$$

e, sob o modelo normal multivariado, o estimador de máxima verossimilhança

$$\hat{\Sigma}_{\text{MV}} = \frac{1}{n} \mathbf{T},$$

ambos construídos a partir da matriz SQPC $\mathbf{T}$ definida na Definição 8.9.

A estimação pontual utiliza uma estimativa única para representar o parâmetro. A estimação por regiões utiliza conjuntos de valores para quantificar a incerteza associada ao processo amostral. A construção de regiões de confiança depende das distribuições amostrais desenvolvidas na Capítulo 12.

A comparação entre estimadores exige critérios que descrevam seu comportamento ao longo das possíveis amostras. Viés e variabilidade caracterizam o comportamento para tamanho amostral fixo, enquanto a consistência descreve o comportamento quando n aumenta. Funções de perda, erro quadrático médio, eficiência, suficiência e equivariância complementam essa análise no Seção 10.7. Dimensão, condicionamento, regularização e robustez são examinados no Seção 10.8.

10.2 Propriedades dos estimadores multivariados

A existência de um estimador não determina sua adequação. Diferentes estatísticas podem estimar o mesmo parâmetro e apresentar comportamentos distintos ao longo das possíveis amostras.

Considere

$$\theta \in \Theta \subseteq \mathbb{R}^r$$

e um estimador

$$\hat{\theta} = G(\mathcal{X}) \in \mathbb{R}^r.$$

Viés e variabilidade são definidos a partir da distribuição amostral de $\hat{\theta}$, enquanto a consistência considera uma sequência de estimadores $\hat{\theta}_n$ quando n aumenta (**casella1990inference?**).

10.2.1 Viés e variabilidade

Definição 10.5 (Viés de um estimador). Se $E(\hat{\theta})$ existe, o viés (*Bias* em inglês) de $\hat{\theta}$ na estimação de θ é

$$\text{Bias}(\hat{\theta}) = E(\hat{\theta}) - \theta. \quad (10.13)$$

O estimador é não viesado quando

$$E(\hat{\theta}) = \theta.$$

O viés é um vetor em $\mathbb{R}^r$. Sua componente j é

$$E(\hat{\theta}_j) - \theta_j.$$

A ausência de viés descreve o comportamento médio do procedimento sobre as possíveis amostras. Ela não garante que uma estimativa particular esteja próxima do parâmetro.

Para um parâmetro matricial

$$\Theta \in \mathbb{R}^{a \times b}$$

e um estimador

$$\hat{\Theta} \in \mathbb{R}^{a \times b},$$

define-se, elemento a elemento,

$$\text{Bias}(\hat{\Theta}) = E(\hat{\Theta}) - \Theta. \quad (10.14)$$

A variabilidade de um estimador vetorial é descrita por

$$\text{Cov}(\hat{\theta}) = E \left[\left\{ \hat{\theta} - E(\hat{\theta}) \right\} \left\{ \hat{\theta} - E(\hat{\theta}) \right\}^{\top} \right]. \quad (10.15)$$

Os elementos diagonais são as variâncias de seus componentes e os elementos fora da diagonal são as covariâncias entre eles.

Para qualquer $\mathbf{a} \in \mathbb{R}^r$,

$$\text{Var}(\mathbf{a}^{\top} \hat{\theta}) = \mathbf{a}^{\top} \text{Cov}(\hat{\theta}) \mathbf{a}.$$

Uma medida escalar da variabilidade total é

$$\text{tr}[\text{Cov}(\hat{\theta})] = \sum_{j=1}^r \text{Var}(\hat{\theta}_j).$$

A variabilidade total medida por $\text{tr}[\text{Cov}(\hat{\theta})]$ depende da escala e da parametrização e não representa as covariâncias entre os componentes do estimador.

Para um estimador matricial, uma representação da variabilidade é

$$\text{Cov}[\text{vec}(\hat{\Theta})].$$

O operador vec , definido na Definição 7.9, transforma a matriz estimada em um vetor, de modo que $\text{Cov}[\text{vec}(\hat{\Theta})]$ reúne as variâncias e covariâncias de seus elementos.

Viés e variabilidade descrevem aspectos diferentes do desempenho de um estimador. Um procedimento pode apresentar pequeno viés e grande variabilidade, ou maior viés e menor variabilidade. A comparação conjunta dessas duas fontes de erro por funções de perda e erro quadrático médio é desenvolvida no Seção 10.7.

10.2.2 Consistência

A consistência descreve o comportamento de uma sequência de estimadores quando o tamanho da amostra aumenta (Vaart, 1998).

Definição 10.6 (Consistência). Considere

$$\theta \in \Theta \subseteq \mathbb{R}^r$$

e uma sequência de estimadores

$$\hat{\theta}_n \in \mathbb{R}^r,$$

com r fixo quando $n \rightarrow \infty$.

A sequência $\hat{\theta}_n$ é consistente para θ quando

$$\hat{\theta}_n \xrightarrow{P} \theta \quad (10.16)$$

quando

$$n \rightarrow \infty.$$

A notação

$$\xrightarrow{P}$$

indica **convergência em probabilidade**. Pela definição, para todo $\varepsilon > 0$,

$$P \left(\left\| \hat{\theta}_n - \theta \right\| > \varepsilon \right) \rightarrow 0. \quad (10.17)$$

Na formulação clássica, a dimensão do parâmetro permanece fixa enquanto n aumenta. Quando a dimensão também varia com n , o regime dimensional e a métrica utilizada para avaliar o erro precisam ser especificados. O Seção 10.8 trata dessa situação para a estimação da matriz de covariâncias.

Não viesamento e consistência descrevem propriedades diferentes. O não viesamento compara a esperança do estimador com o parâmetro para um tamanho amostral dado, enquanto a consistência descreve o que acontece com o erro de estimação quando n aumenta. Uma propriedade não deve ser interpretada como sinônimo da outra.

10.3 Métodos de estimação

Um estimador pode ser construído a partir de diferentes princípios. O método dos momentos relaciona momentos populacionais a seus correspondentes amostrais. A máxima verossimilhança escolhe os valores dos parâmetros que tornam os dados observados mais compatíveis com o modelo especificado (**casella1990inference?**).

Os dois métodos podem produzir o mesmo estimador em determinados modelos, mas essa coincidência não ocorre em geral. O princípio utilizado para construir um estimador deve ser distinguido de suas propriedades. Em particular, não viesamento e consistência precisam ser verificados para o estimador e para o modelo considerados.

10.3.1 Método dos momentos

O método dos momentos constrói estimadores substituindo momentos populacionais por seus correspondentes amostrais. Para estimar μ e Σ , são utilizados momentos de primeira e segunda ordem. O Seção 10.7 apresenta a formulação geral do método.

Para o vetor de médias populacional,

$$E(\mathbf{X}) = \mu.$$

O primeiro momento amostral é

$$\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i = \bar{\mathbf{X}},$$

de modo que

$$\hat{\mu}_{\text{MM}} = \bar{\mathbf{X}}. \quad (10.18)$$

Para a matriz de covariâncias, considere o segundo momento não central

$$\mathbf{M}_2 = E(\mathbf{X}\mathbf{X}^\top).$$

Pela identidade Equação 8.3,

$$\Sigma = \mathbf{M}_2 - \mu\mu^\top.$$

Substituindo os momentos populacionais por seus correspondentes amostrais,

$$\begin{aligned} \hat{\Sigma}_{\text{MM}} &= \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^\top - \bar{\mathbf{X}} \bar{\mathbf{X}}^\top \\ &= \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{X}}) (\mathbf{x}_i - \bar{\mathbf{X}})^\top. \end{aligned} \quad (10.19)$$

A matriz no numerador é a versão aleatória da matriz total de somas de quadrados e produtos cruzados (SQPC) definida, para dados observados, na Definição 8.9. Denote-a por

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{X}}) (\mathbf{x}_i - \bar{\mathbf{X}})^\top. \quad (10.20)$$

Portanto,

$$\widehat{\Sigma}_{\text{MM}} = \frac{1}{n} \mathbf{T}. \quad (10.21)$$

O estimador $\mathbf{T}/n$ utiliza apenas momentos de primeira e segunda ordem e não exige normalidade multivariada. Sob o modelo normal, a mesma expressão também é obtida por máxima verossimilhança quando o máximo existe, conforme a Equação 10.32.

A Definição 10.9 formaliza $\mathbf{T}$ como estatística aleatória. Para cada realização da amostra, $\mathbf{T}$ produz a matriz $\mathbf{T}$ definida na Definição 8.9.

10.3.2 Verossimilhança e máxima verossimilhança

Definição 10.7 (Função de verossimilhança). Considere um espaço paramétrico Θ e uma família de distribuições indexada por

$$\theta \in \Theta,$$

na qual cada observação possui densidade ou função de probabilidade

$$f(\mathbf{x}; \theta)$$

em um espaço amostral $\mathcal{X}$.

Para uma amostra i.i.d.

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

e uma realização observada

$$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathcal{X},$$

a função de verossimilhança, para os dados observados fixados, é a função

$$L(\cdot; \mathbf{x}_1, \dots, \mathbf{x}_n) : \Theta \longrightarrow [0, \infty)$$

definida por

$$L(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n) = \prod_{i=1}^n f(\mathbf{x}_i; \theta). \quad (10.22)$$

Na verossimilhança, os dados observados são mantidos fixos e θ varia em Θ . Portanto, L não é, em geral, uma distribuição de probabilidade sobre θ .

A log-verossimilhança é

$$\ell(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n) = \log L(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n),$$

e, sob independência,

$$\ell(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n) = \sum_{i=1}^n \log f(\mathbf{x}_i; \theta). \quad (10.23)$$

Como o logaritmo é estritamente crescente, a verossimilhança e a log-verossimilhança possuem os mesmos pontos de máximo.

Definição 10.8 (Estimador de máxima verossimilhança). Considere a função de verossimilhança definida na Definição 10.7 e suponha que

$$\arg \max_{\theta \in \Theta} L(\theta; \mathcal{X}) \neq \emptyset.$$

Um **estimador de máxima verossimilhança** de θ é uma estatística

$$\hat{\theta}_{\text{MV}}$$

que seleciona um elemento desse conjunto:

$$\hat{\theta}_{\text{MV}} \in \arg \max_{\theta \in \Theta} L(\theta; \mathcal{X}). \quad (10.24)$$

Se o conjunto de máximos contiver mais de um elemento, qualquer elemento selecionado segundo a regra de estimação adotada é um estimador de máxima verossimilhança.

Como o logaritmo é estritamente crescente, a mesma regra pode ser obtida maximizando a log-verossimilhança:

$$\hat{\theta}_{\text{MV}} \in \arg \max_{\theta \in \Theta} \ell(\theta; \mathcal{X}).$$

Após a observação da amostra, a estimativa correspondente satisfaz

$$\hat{\theta}_{\text{MV,obs}} \in \arg \max_{\theta \in \Theta} L(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n).$$

A notação $\arg \max$ representa o conjunto dos valores do parâmetro em que o máximo é atingido. Assim, a definição admite a possibilidade de mais de um máximo. A existência e a unicidade do estimador precisam ser verificadas no modelo e no espaço paramétrico considerados.

10.3.2.1 Máxima verossimilhança no modelo normal multivariado

Considere uma amostra do modelo normal multivariado definido na Definição 9.1:

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\mu \in \mathbb{R}^p \quad \text{e} \quad \Sigma \succ \mathbf{0}.$$

Pela densidade normal multivariada na Equação 9.8 e pela independência das unidades amostrais, para uma amostra observada a verossimilhança é

$$\begin{aligned} L(\mu, \Sigma) &= (2\pi)^{-np/2} \det(\Sigma)^{-n/2} \\ &\times \exp \left\{ -\frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu) \right\}. \end{aligned} \quad (10.25)$$

A log-verossimilhança é

$$\begin{aligned} \ell(\mu, \Sigma) &= -\frac{np}{2} \log(2\pi) - \frac{n}{2} \log \det(\Sigma) \\ &\quad - \frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu). \end{aligned} \quad (10.26)$$

Considere a matriz SQPC observada $\mathbf{T}$, definida na Definição 8.9:

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \quad (10.27)$$

Separando o afastamento em relação a μ no desvio em relação à média amostral e no deslocamento da própria média, obtém-se

$$\begin{aligned} & \sum_{i=1}^n (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^\top \\ &= \mathbf{T} + n (\bar{\mathbf{x}} - \mu) (\bar{\mathbf{x}} - \mu)^\top. \end{aligned} \quad (10.28)$$

A forma quadrática presente na log-verossimilhança pode ser reescrita utilizando o traço. Pela relação entre traço e produto externo em Proposição 2.7 e pela propriedade cíclica em Exemplo 2.11, para um vetor $\mathbf{z}$ e uma matriz compatível $\mathbf{A}$,

$$\mathbf{z}^\top \mathbf{A} \mathbf{z} = \text{tr}(\mathbf{A} \mathbf{z} \mathbf{z}^\top).$$

Consequentemente,

$$\begin{aligned} & \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu) \\ &= \text{tr} \left[\Sigma^{-1} \sum_{i=1}^n (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^\top \right] \\ &= \text{tr}(\Sigma^{-1} \mathbf{T}) + n (\bar{\mathbf{x}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{x}} - \mu), \end{aligned}$$

em que a última igualdade utiliza Equação 10.28. Assim, a log-verossimilhança pode ser escrita como

$$\begin{aligned} \ell(\mu, \Sigma) &= -\frac{np}{2} \log(2\pi) - \frac{n}{2} \log \det(\Sigma) \\ &\quad - \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{T}) \\ &\quad - \frac{n}{2} (\bar{\mathbf{x}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{x}} - \mu). \end{aligned} \quad (10.29)$$

Para Σ fixa, o último termo é não positivo na log-verossimilhança e atinge seu maior valor quando

$$\mu = \bar{\mathbf{x}}.$$

Substituindo esse valor, obtém-se a log-verossimilhança perfilada

$$\ell_p(\Sigma) = C - \frac{n}{2} \left\{ \log \det(\Sigma) + \text{tr} \left[\Sigma^{-1} \left(\frac{\mathbf{T}}{n} \right) \right] \right\}, \quad (10.30)$$

em que C não depende de Σ .

Desconsiderando a constante C , maximizar Equação 10.30 equivale a minimizar

$$\frac{n}{2} \log \det (\Sigma) + \frac{1}{2} \operatorname{tr} \left(\Sigma^{-1} \mathbf{T} \right).$$

Essa expressão possui exatamente a forma do critério estudado na Proposição 7.11, com

$$\mathbf{G} = \mathbf{T}.$$

Assim, quando $\mathbf{T} \succ \mathbf{0}$, aquele resultado pode ser aplicado diretamente para obter o minimizador.

Proposição 10.1 (Estimadores de máxima verossimilhança no modelo normal). *No evento amostral em que o máximo da verossimilhança existe, os estimadores no modelo normal multivariado são (Anderson, 2003)*

$$\hat{\mu}_{\text{MV}} = \bar{\mathbf{X}} \tag{10.31}$$

e

$$\hat{\Sigma}_{\text{MV}} = \frac{\mathbf{T}}{n}. \tag{10.32}$$

O resultado considera

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0}.$$

Para uma amostra observada, o máximo existe e é único quando

$$\text{posto}(\mathbf{T}) = p,$$

e, nesse caso,

$$\hat{\mu}_{\text{MV,obs}} = \bar{\mathbf{x}}$$

e

$$\hat{\Sigma}_{\text{MV,obs}} = \frac{\mathbf{T}}{n}.$$

i Demonstração

A maximização em relação a μ decorre de Equação 10.29. Como

$$\Sigma^{-1} \succ \mathbf{0},$$

tem-se

$$(\bar{\mathbf{x}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{x}} - \mu) \geq 0,$$

com igualdade somente em

$$\mu = \bar{\mathbf{x}}.$$

Para a maximização em relação a Σ , a log-verossimilhança perfilada na Equação 10.30 mostra que é equivalente minimizar

$$Q(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{T}).$$

Sob a hipótese

$$\text{posto}(\mathbf{T}) = p,$$

tem-se

$$\mathbf{T} \succ \mathbf{0}.$$

Aplicando Proposição 7.11 com $\mathbf{G} = \mathbf{T}$, o minimizador único é

$$\Sigma = \frac{\mathbf{T}}{n}.$$

Logo,

$$\hat{\Sigma}_{\text{MV,obs}} = \frac{\mathbf{T}}{n}.$$

Pelo limite de posto da matriz SQPC estabelecido na Equação 8.57,

$$\text{posto}(\mathbf{T}) \leq \min(p, n - 1).$$

Consequentemente, uma condição necessária para posto completo é

$$n \geq p + 1.$$

Essa condição não é suficiente para uma amostra arbitrária, pois as colunas da matriz centralizada ainda podem ser linearmente dependentes. Sob uma distribuição normal multivariada não singular e

$$n \geq p + 1,$$

a condição

$$\text{posto}(\mathbf{T}) = p$$

ocorre quase certamente.

Se $\mathbf{T}$ é singular, a verossimilhança não possui máximo no espaço

$$\{\Sigma : \Sigma \succ \mathbf{0}\}.$$

De fato, pelo Teorema 5.2, escreva

$$\mathbf{T} = \mathbf{Q} \text{diag}(t_1, \dots, t_r, 0, \dots, 0) \mathbf{Q}^\top,$$

com

$$t_j > 0, \quad j = 1, \dots, r, \quad r < p.$$

Para $\varepsilon > 0$, considere

$$\Sigma_\varepsilon = \mathbf{Q} \text{diag}\left(\frac{t_1}{n}, \dots, \frac{t_r}{n}, \varepsilon, \dots, \varepsilon\right) \mathbf{Q}^\top.$$

Então,

$$\text{tr}(\Sigma_\varepsilon^{-1} \mathbf{T}) = nr,$$

enquanto

$$\log \det(\Sigma_\varepsilon) \longrightarrow -\infty$$

quando

$$\varepsilon \longrightarrow 0.$$

Consequentemente, a log-verossimilhança cresce sem limite ao longo dessa sequência, e o máximo não é atingido no espaço das matrizes positivas definidas.

A matriz

$$\frac{\mathbf{T}}{n}$$

continua sendo bem definida e positiva semidefinida e coincide com o estimador obtido pelo método dos momentos. Quando essa matriz é singular, ela não constitui o estimador de máxima verossimilhança no modelo cujo espaço paramétrico exige

$$\Sigma \succ \mathbf{0}.$$

Quando o máximo existe, o estimador de máxima verossimilhança de Σ utiliza o divisor n . A Equação 10.57 relaciona esse estimador à matriz de covariâncias amostral com divisor $n - 1$, cujo não viesamento é estabelecido na Proposição 10.8.

No modelo normal, método dos momentos e máxima verossimilhança produzem o mesmo estimador para μ e a mesma matriz com divisor n para Σ .

10.4 Estimação do vetor de médias

O vetor de médias populacional μ , definido na Equação 8.1, descreve a localização da população em $\mathbb{R}^p$. O método dos momentos e, sob o modelo normal multivariado, a máxima verossimilhança conduzem ao vetor de médias amostrais como estimador de μ . Para esse estimador, são estabelecidos não viesamento, matriz de covariâncias, comportamento de combinações lineares, consistência e transformação afim.

Considere a amostra aleatória multivariada definida na Equação 10.1 e suponha que

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n.$$

Os resultados para a esperança, a matriz de covariâncias e a consistência de $\bar{\mathbf{X}}$ requerem independência entre as unidades amostrais e existência dos segundos momentos. No desenvolvimento de máxima verossimilhança apresentado neste capítulo, a identificação de $\bar{\mathbf{X}}$ como estimador de máxima verossimilhança de μ é obtida sob o modelo normal multivariado.

10.4.1 Vetor de médias amostrais

Retomando a Equação 10.8, o vetor de médias amostrais é

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i.$$

Componente a componente,

$$\bar{\mathbf{X}} = \begin{bmatrix} \bar{X}_1 \\ \bar{X}_2 \\ \vdots \\ \bar{X}_p \end{bmatrix},$$

com

$$\bar{X}_j = \frac{1}{n} \sum_{i=1}^n X_{ij}, \quad j = 1, \dots, p. \quad (10.33)$$

Utilizando a matriz aleatória da amostra,

$$\mathcal{X} \in \mathbb{R}^{n \times p},$$

tem-se

$$\bar{\mathbf{X}} = \frac{1}{n} \mathcal{X}^\top \mathbf{1}_n. \quad (10.34)$$

Após a observação dos dados,

$$\bar{\mathbf{x}} = \frac{1}{n} \mathbf{X}^\top \mathbf{1}_n. \quad (10.35)$$

Essa é a mesma quantidade descritiva definida na Equação 8.52. Aqui, $\bar{\mathbf{x}}$ é interpretado como a realização observada da estatística aleatória $\bar{\mathbf{X}}$.

Pelo método dos momentos, a Equação 10.18 fornece

$$\hat{\mu}_{\text{MM}} = \bar{\mathbf{X}}.$$

Sob o modelo normal multivariado, quando o estimador de máxima verossimilhança existe, a Equação 10.31 fornece

$$\hat{\mu}_{\text{MV}} = \bar{\mathbf{X}}.$$

Portanto,

$$\hat{\mu}_{\text{MM}} = \hat{\mu}_{\text{MV}} = \bar{\mathbf{X}}. \quad (10.36)$$

A igualdade em Equação 10.36 mostra que método dos momentos e máxima verossimilhança conduzem ao mesmo estimador de μ sob o modelo normal e nas condições de existência do máximo. Não viesamento, variabilidade e consistência de $\bar{\mathbf{X}}$ dependem das propriedades de sua distribuição amostral, e não do princípio utilizado para construir o estimador.

Além de sua interpretação como estimativa de μ , o valor observado $\bar{\mathbf{x}}$ possui uma caracterização geométrica: ele é o centroide da nuvem de pontos e minimiza a soma dos quadrados das distâncias euclidianas das observações a um centro comum.

Proposição 10.2 (Caracterização da média amostral como centroide). *Para observações*

$$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^p,$$

o vetor $\bar{\mathbf{x}}$ é o único minimizador de

$$Q(\mathbf{m}) = \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2, \quad \mathbf{m} \in \mathbb{R}^p.$$

Portanto,

$$\bar{\mathbf{x}} = \arg \min_{\mathbf{m} \in \mathbb{R}^p} \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2. \quad (10.37)$$

i Demonstração

Para qualquer $\mathbf{m} \in \mathbb{R}^p$,

$$\mathbf{x}_i - \mathbf{m} = (\mathbf{x}_i - \bar{\mathbf{x}}) + (\bar{\mathbf{x}} - \mathbf{m}).$$

Somando os quadrados das normas,

$$\begin{aligned} \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2 &= \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2 \\ &\quad + 2(\bar{\mathbf{x}} - \mathbf{m})^\top \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) \\ &\quad + n \|\bar{\mathbf{x}} - \mathbf{m}\|^2. \end{aligned}$$

Pela propriedade de centralização estabelecida na Equação 8.54,

$$\sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) = \mathbf{0}.$$

Logo,

$$\sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2 = \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2 + n \|\bar{\mathbf{x}} - \mathbf{m}\|^2. \quad (10.38)$$

A primeira parcela não depende de $\mathbf{m}$, e a segunda é não negativa e se anula somente em

$$\mathbf{m} = \bar{\mathbf{x}}.$$

Logo, $\bar{\mathbf{x}}$ é o único minimizador.

A Equação 10.38 fundamenta a decomposição matricial da SQPC em Equação 10.50.

10.4.2 Não viesamento e variabilidade

Proposição 10.3 (Esperança e covariância do vetor de médias amostrais). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

são independentes e satisfazem

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n,$$

então

$$E(\bar{\mathbf{X}}) = \mu \quad (10.39)$$

e

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}. \quad (10.40)$$

i Demonstração

Pela linearidade da esperança,

$$\begin{aligned} E(\bar{\mathbf{X}}) &= \frac{1}{n} \sum_{i=1}^n E(\mathbf{X}_i) \\ &= \mu. \end{aligned}$$

Para a matriz de covariâncias,

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{1}{n^2} \text{Cov}\left(\sum_{i=1}^n \mathbf{X}_i\right).$$

Como as unidades amostrais são independentes,

$$\text{Cov}\left(\sum_{i=1}^n \mathbf{X}_i\right) = \sum_{i=1}^n \text{Cov}(\mathbf{X}_i) = n\Sigma.$$

Portanto,

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}.$$

Consequentemente,

$$\text{Bias}(\bar{\mathbf{X}}) = \mathbf{0}.$$

O vetor de médias amostrais é, portanto, não viesado para μ .

Elemento a elemento,

$$\text{Var}(\bar{X}_j) = \frac{\sigma_{jj}}{n}$$

e

$$\text{Cov}(\bar{X}_j, \bar{X}_k) = \frac{\sigma_{jk}}{n}.$$

A matriz de covariâncias do erro de estimação é obtida multiplicando Σ pelo fator $1/n$. Assim, o aumento do tamanho amostral reduz a magnitude das variâncias e covariâncias, preservando a estrutura relativa determinada por Σ .

10.4.3 Combinações lineares

Considere o parâmetro escalar

$$\mathbf{a}^\top \mu, \quad \mathbf{a} \in \mathbb{R}^p.$$

O correspondente estimador é

$$\mathbf{a}^\top \bar{\mathbf{X}}.$$

Aplicando Proposição 8.1 ao vetor aleatório $\bar{\mathbf{X}}$, cuja média e matriz de covariâncias são dadas na Proposição 10.3,

$$E(\mathbf{a}^\top \bar{\mathbf{X}}) = \mathbf{a}^\top \mu,$$

e

$$\begin{aligned} \text{Var}(\mathbf{a}^\top \bar{\mathbf{X}}) &= \mathbf{a}^\top \text{Cov}(\bar{\mathbf{X}}) \mathbf{a} \\ &= \frac{1}{n} \mathbf{a}^\top \Sigma \mathbf{a}. \end{aligned} \tag{10.41}$$

Cada vetor $\mathbf{a}$ define uma combinação linear dos componentes de $\bar{\mathbf{X}}$ e, geometricamente, especifica uma direção juntamente com uma escala. Sua variabilidade é determinada por

$$\frac{1}{n} \mathbf{a}^\top \Sigma \mathbf{a}.$$

Para comparar apenas direções, considere vetores $\mathbf{a}$ de norma unitária. A quantidade $\mathbf{a}^\top \Sigma \mathbf{a}$ é a variância populacional na direção $\mathbf{a}$; direções com maior variância populacional produzem maior variabilidade entre as estimativas das respectivas combinações lineares.

Quando

$$\mathbf{a} = \mathbf{e}_j,$$

recupera-se

$$\text{Var}(\bar{X}_j) = \frac{\sigma_{jj}}{n}.$$

Mais geralmente, para

$$\mathbf{C} \in \mathbb{R}^{q \times p},$$

o estimador de

$$\mathbf{C}\mu$$

é

$$\mathbf{C}\bar{\mathbf{X}},$$

com

$$E(\mathbf{C}\bar{\mathbf{X}}) = \mathbf{C}\mu$$

e

$$\text{Cov}(\mathbf{C}\bar{\mathbf{X}}) = \frac{1}{n} \mathbf{C} \Sigma \mathbf{C}^\top. \quad (10.42)$$

10.4.4 Consistência e transformação afim

Proposição 10.4 (Consistência do vetor de médias amostrais). *Considere*

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

independentes, com

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n,$$

com segundos momentos finitos. Para dimensão p fixa,

$$\bar{\mathbf{X}} \xrightarrow{P} \mu \tag{10.43}$$

quando $n \rightarrow \infty$.

i Demonstração

Pela Proposição 10.3,

$$E(\bar{\mathbf{X}}) = \mu$$

e

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{1}{n}\Sigma.$$

Portanto,

$$\begin{aligned} E\left[\|\bar{\mathbf{X}} - \mu\|^2\right] &= \text{tr}[\text{Cov}(\bar{\mathbf{X}})] \\ &= \frac{\text{tr}(\Sigma)}{n}. \end{aligned}$$

Para $\varepsilon > 0$, a desigualdade de Markov aplicada à variável não negativa

$$\|\bar{\mathbf{X}} - \mu\|^2$$

fornece

$$\begin{aligned} P(\|\bar{\mathbf{X}} - \mu\| > \varepsilon) &\leq \frac{E\left[\|\bar{\mathbf{X}} - \mu\|^2\right]}{\varepsilon^2} \\ &= \frac{\text{tr}(\Sigma)}{n\varepsilon^2} \rightarrow 0. \end{aligned}$$

Logo,

$$\bar{\mathbf{X}} \xrightarrow{P} \mu.$$

A prova utiliza segundos momentos finitos. Para dimensão fixa, a consistência também pode ser obtida por leis dos grandes números sob condições de integrabilidade mais gerais.

Sob uma transformação afim dos dados, o vetor de médias amostrais transforma-se da mesma forma que o vetor de médias populacional.

Proposição 10.5 (Transformação afim do vetor de médias amostrais). *Considere*

$$\mathbf{Y}_i = \mathbf{C}\mathbf{X}_i + \mathbf{d}, \quad i = 1, \dots, n,$$

com

$$\mathbf{C} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{d} \in \mathbb{R}^q.$$

Então,

$$\bar{\mathbf{Y}} = \mathbf{C}\bar{\mathbf{X}} + \mathbf{d}. \quad (10.44)$$

Como, por Equação 8.17,

$$\mu_Y = \mathbf{C}\mu + \mathbf{d},$$

a transformação aplicada ao estimador acompanha exatamente a transformação correspondente do parâmetro populacional.

O vetor de médias amostrais é não viesado, possui matriz de covariâncias Σ/n , é consistente sob as condições especificadas e satisfaz a transformação afim registrada na Proposição 10.5. Cada propriedade decorre do comportamento específico de $\bar{\mathbf{X}}$ sob o modelo amostral, e não apenas do método utilizado para construir o estimador.

10.4.5 Variabilidade entre amostras

O vetor $\bar{\mathbf{X}}$ é uma estatística aleatória, enquanto $\bar{\mathbf{x}}$ é sua realização para uma amostra observada. Se o processo de amostragem fosse repetido, diferentes amostras produziriam diferentes valores de $\bar{\mathbf{x}}$. A distribuição desses valores corresponde à distribuição amostral do estimador.

A Figura 10.1 apresenta 250 realizações de $\bar{\mathbf{X}}$ para amostras de tamanhos 5 e 50 geradas de uma mesma distribuição normal bivariada. A normalidade é utilizada apenas para gerar a ilustração; o resultado na Equação 10.40 depende apenas da independência das unidades amostrais e da existência dos segundos momentos.

Nos dois painéis, os vetores de médias amostrais se distribuem ao redor de μ . Para $n = 50$, a nuvem é mais concentrada do que para $n = 5$, em concordância com a redução da matriz de covariâncias por $1/n$.

A Figura 10.1 ilustra a variabilidade entre realizações de $\bar{\mathbf{X}}$, sem caracterizar sua distribuição amostral exata. A distribuição de $\bar{\mathbf{X}}$ sob normalidade é estabelecida na Capítulo 12.

O vetor de médias amostrais estima a localização da população. A dispersão multivariada é representada pelos produtos dos desvios das observações em relação à média amostral, reunidos na matriz SQPC.




Figura 10.1: Vetores de médias amostrais obtidos em 250 amostras de uma distribuição normal bivariada, para tamanhos amostrais 5 e 50.

10.5 SQPC e estimação da matriz de covariâncias

O Capítulo 8 definiu a matriz total de somas de quadrados e produtos cruzados na Definição 8.9 e a matriz de covariâncias observada na Definição 8.10. Como estatísticas aleatórias, a SQPC e as matrizes derivadas dela fornecem estimadores de Σ associados a critérios distintos, incluindo não viesamento, método dos momentos e, sob normalidade e existência do máximo, máxima verossimilhança.

Considere a amostra aleatória multivariada definida na Equação 10.1, com unidades independentes e

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n,$$

e suponha que os segundos momentos sejam finitos.

10.5.1 SQPC como estatística aleatória

A matriz aleatória da amostra é

$$\mathcal{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

Retomando a matriz de centralização utilizada na Equação 8.55,

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top,$$

define-se a matriz aleatória centralizada por

$$\mathcal{X}_c = \mathbf{H}_n \mathcal{X}. \quad (10.45)$$

Suas linhas são

$$(\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

Definição 10.9 (Matriz SQPC amostral). A **matriz de somas de quadrados e produtos cruzados (SQPC) amostral** é a estatística

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \quad (10.46)$$

Equivalentemente,

$$\mathbf{T} = \mathcal{X}_c^\top \mathcal{X}_c = \mathcal{X}^\top \mathbf{H}_n \mathcal{X}. \quad (10.47)$$

Após a observação da amostra,

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}$$

e

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \quad (10.48)$$

A matriz $\mathbf{T}$ é exatamente a matriz SQPC observada definida na Definição 8.9 e escrita matricialmente na Equação 8.56. A diferença de notação é probabilística: $\mathbf{T}$ representa a estatística aleatória, enquanto $\mathbf{T}$ representa sua realização observada.

O elemento (j, k) de $\mathbf{T}$ é

$$\mathsf{T}_{jk} = \sum_{i=1}^n (X_{ij} - \bar{X}_j) (X_{ik} - \bar{X}_k). \quad (10.49)$$

Na diagonal,

$$\mathsf{T}_{jj} = \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2$$

é a soma de quadrados centralizada da variável j . Fora da diagonal, T_{jk} é o produto cruzado centralizado entre as variáveis j e k .

Após a observação da amostra, os elementos correspondentes de $\mathbf{T}$ são denotados por t_{jk} .

10.5.2 Decomposição em torno de um centro arbitrário

A Equação 10.38 decompõe a soma das distâncias quadráticas a um centro arbitrário em uma parcela em torno da média amostral e outra associada ao deslocamento do centro. A decomposição matricial correspondente é expressa em termos de produtos externos.

Proposição 10.6 (Decomposição da SQPC em torno de um centro arbitrário). *Para qualquer vetor fixo*

$$\mathbf{c} \in \mathbb{R}^p,$$

tem-se

$$\begin{aligned} & \sum_{i=1}^n (\mathbf{X}_i - \mathbf{c}) (\mathbf{X}_i - \mathbf{c})^\top \\ &= \mathbf{T} + n (\bar{\mathbf{X}} - \mathbf{c}) (\bar{\mathbf{X}} - \mathbf{c})^\top. \end{aligned} \quad (10.50)$$

i Demonstração

Escreva

$$\mathbf{X}_i - \mathbf{c} = (\mathbf{X}_i - \bar{\mathbf{X}}) + (\bar{\mathbf{X}} - \mathbf{c}).$$

Substituindo na soma dos produtos externos, surgem quatro parcelas. Os dois termos cruzados contêm

$$\sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}}) = \mathbf{0},$$

e, portanto, se anulam. Restam

$$\mathbf{T}$$

e

$$n (\bar{\mathbf{X}} - \mathbf{c}) (\bar{\mathbf{X}} - \mathbf{c})^\top,$$

o que fornece Equação 10.50.

Para

$$\mathbf{c} = \mu,$$

obtém-se

$$\begin{aligned} \sum_{i=1}^n (\mathbf{X}_i - \mu) (\mathbf{X}_i - \mu)^\top \\ = \mathbf{T} + n (\bar{\mathbf{X}} - \mu) (\bar{\mathbf{X}} - \mu)^\top. \end{aligned} \tag{10.51}$$

A Equação 10.51 separa a dispersão em torno de μ na SQPC em torno da média amostral e na parcela associada a $\bar{\mathbf{X}} - \mu$.

10.5.3 Esperança da SQPC

A Equação 10.51 fornece a esperança de $\mathbf{T}$ sem exigir normalidade (Johnson; Wichern, 2002).

Proposição 10.7 (Esperança da SQPC). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

são independentes e satisfazem

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n,$$

então

$$E(\mathbf{T}) = (n-1)\Sigma. \quad (10.52)$$

i Demonstração

Tomando esperança no lado esquerdo de Equação 10.51,

$$\begin{aligned} E \left[\sum_{i=1}^n (\mathbf{X}_i - \mu) (\mathbf{X}_i - \mu)^\top \right] &= \sum_{i=1}^n \Sigma \\ &= n\Sigma. \end{aligned}$$

Para a segunda parcela do lado direito,

$$E \left[n (\bar{\mathbf{X}} - \mu) (\bar{\mathbf{X}} - \mu)^\top \right] = n \text{Cov}(\bar{\mathbf{X}}).$$

Por Equação 10.40,

$$n \text{Cov}(\bar{\mathbf{X}}) = \Sigma.$$

Portanto,

$$n\Sigma = E(\mathbf{T}) + \Sigma,$$

e segue que

$$E(\mathbf{T}) = (n-1)\Sigma.$$

O fator $n-1$ surge porque a SQPC utiliza desvios em relação à média estimada a partir da própria amostra. A centralização impõe

$$\sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}}) = \mathbf{0},$$

de modo que os n vetores de desvios satisfazem uma restrição linear. Assim, a centralização reduz em uma unidade a dimensão associada às variações em torno da média amostral.

A relação

$$E(\mathbf{T}) = (n-1)\Sigma$$

depende apenas da independência entre as unidades amostrais e da existência dos segundos momentos necessários; a normalidade multivariada não é exigida. Sob normalidade, a distribuição de $\mathbf{T}$ é obtida na Capítulo 12 a partir da distribuição de Wishart.

10.5.4 Estimador não viesado da matriz de covariâncias

Definição 10.10 (Matriz de covariâncias amostral). Para $n \geq 2$, define-se

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}, \quad (10.53)$$

em que $\mathbf{T}$ é definida na Definição 10.9.

Proposição 10.8 (Não viesamento da matriz de covariâncias amostral). Se

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

são independentes, possuem segundos momentos finitos e satisfazem

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n,$$

então

$$E(\mathbf{S}) = \Sigma. \quad (10.54)$$

Portanto, $\mathbf{S}$ é um estimador não viesado de Σ .

i Demonstração

Por Equação 10.53 e Equação 10.52,

$$\begin{aligned} E(\mathbf{S}) &= \frac{1}{n-1} E(\mathbf{T}) \\ &= \frac{1}{n-1} (n-1) \Sigma \\ &= \Sigma. \end{aligned}$$

Após a observação, obtém-se a matriz de covariâncias observada definida na Definição 8.10:

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}. \quad (10.55)$$

Componente a componente,

$$S_{jk} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j) (X_{ik} - \bar{X}_k). \quad (10.56)$$

Para $j = k$,

$$S_{jj} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2$$

é a variância amostral da variável j .

Assim,

$$\mathbf{S} = \begin{bmatrix} S_{11} & S_{12} & \cdots & S_{1p} \\ S_{21} & S_{22} & \cdots & S_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ S_{p1} & S_{p2} & \cdots & S_{pp} \end{bmatrix}.$$

Após a observação da amostra, os elementos correspondentes de $\mathbf{S}$ são denotados por s_{jk} .

A divisão por $n-1$ corrige o viés associado à centralização pela média amostral. Ela não é escolhida para garantir semidefinição positiva. Como a matriz SQPC observada satisfaz

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c,$$

ela é uma matriz de Gram, conforme Definição 3.18, e suas propriedades de simetria e semidefinição positiva decorrem da Proposição 3.9. A multiplicação por $1/(n-1) > 0$ preserva essas propriedades em $\mathbf{S}$.

O não viesamento de $\mathbf{S}$ foi obtido utilizando apenas segundos momentos. Propriedades adicionais de variabilidade são tratadas no Seção 10.7.

10.5.5 Estimador com divisor n : momentos e máxima verossimilhança

Pelo método dos momentos, a Equação 10.21 fornece

$$\hat{\Sigma}_{\text{MM}} = \frac{1}{n} \mathbf{T}.$$

Sob o modelo normal multivariado não singular e quando o máximo existe, a Equação 10.32 fornece a mesma estatística (Johnson; Wichern, 2002):

$$\hat{\Sigma}_{\text{MV}} = \frac{1}{n} \mathbf{T}.$$

Portanto, no modelo normal e nas condições de existência do estimador de máxima verossimilhança,

$$\hat{\Sigma}_{\text{MM}} = \hat{\Sigma}_{\text{MV}} = \frac{1}{n} \mathbf{T}.$$

Como

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T},$$

tem-se, sob o modelo normal,

$$\hat{\Sigma}_{\text{MV}} = \frac{n-1}{n} \mathbf{S}. \tag{10.57}$$

Por Equação 10.52,

$$E\left(\frac{\mathbf{T}}{n}\right) = \frac{n-1}{n} \Sigma.$$

Portanto, como estimador de Σ ,

$$\text{Bias}\left(\frac{\mathbf{T}}{n}\right) = -\frac{1}{n}\Sigma.$$

O viés de $\mathbf{T}/n$ como estimador de Σ independe da normalidade. Sob o modelo normal e nas condições de existência do máximo, $\mathbf{T}/n$ também é o estimador de máxima verossimilhança e, portanto,

$$E\left(\widehat{\Sigma}_{\text{MV}}\right) = \frac{n-1}{n}\Sigma \quad (10.58)$$

e

$$\text{Bias}\left(\widehat{\Sigma}_{\text{MV}}\right) = -\frac{1}{n}\Sigma. \quad (10.59)$$

Assim, o viés é uma propriedade da estatística $\mathbf{T}/n$ como estimador de Σ , e não uma consequência do método utilizado para obtê-la.

Os estimadores

$$\frac{\mathbf{T}}{n} \quad \text{e} \quad \frac{\mathbf{T}}{n-1}$$

correspondem a critérios distintos. O primeiro resulta do método dos momentos e, sob normalidade e existência do máximo, da máxima verossimilhança. O segundo utiliza o fator necessário para satisfazer $E(\mathbf{S}) = \Sigma$.

Quando n aumenta,

$$\frac{n-1}{n} \rightarrow 1,$$

de modo que a diferença relativa entre os dois estimadores desaparece.

Dois divisores, dois critérios

A matriz

$$\frac{\mathbf{T}}{n}$$

surge como estimador de momentos e, sob o modelo normal e as condições de existência do máximo, como estimador de máxima verossimilhança.

A matriz

$$\frac{\mathbf{T}}{n-1}$$

é construída para satisfazer

$$E(\mathbf{S}) = \Sigma.$$

Nenhum dos dois divisores é universalmente “correto” sem especificar o critério de estimação.

10.5.6 Consistência dos estimadores de covariância

O não viesamento é uma propriedade para tamanho amostral fixo. A consistência descreve o comportamento quando n aumenta.

Proposição 10.9 (Consistência da matriz de covariâncias amostral). *Considere uma amostra aleatória i.i.d.*

$$\mathbf{X}_1, \dots, \mathbf{X}_n,$$

em que

$$\mathbf{X}_i \in \mathbb{R}^p,$$

com

$$E(\mathbf{X}_i) = \mu,$$

$$\text{Cov}(\mathbf{X}_i) = \Sigma,$$

e

$$E(\|\mathbf{X}_i\|^2) < \infty.$$

Se o número p de variáveis permanece fixo quando $n \rightarrow \infty$, então

$$\mathbf{S} \xrightarrow{P} \Sigma. \tag{10.60}$$

i Demonstração

Pela identidade

$$\frac{1}{n} \mathbf{T} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^\top - \bar{\mathbf{x}} \bar{\mathbf{x}}^\top, \quad (10.61)$$

a matriz com divisor n pode ser escrita como diferença entre o segundo momento amostral não central e o produto externo da média amostral.

Para cada par (j, k) , a condição de segundos momentos finitos implica

$$E(|X_j X_k|) < \infty.$$

Pela Lei dos Grandes Números,

$$\frac{1}{n} \sum_{i=1}^n X_{ij} X_{ik} \xrightarrow{P} E(X_j X_k),$$

e

$$\bar{X}_j \xrightarrow{P} \mu_j.$$

Logo, elemento a elemento,

$$\frac{1}{n} \mathbf{T} \xrightarrow{P} E(\mathbf{x} \mathbf{x}^\top) - \mu \mu^\top = \Sigma.$$

Como p é fixo,

$$\mathbf{S} = \frac{n}{n-1} \left(\frac{\mathbf{T}}{n} \right) \xrightarrow{P} \Sigma.$$

Pela mesma argumentação,

$$\hat{\Sigma}_{\text{MV}} = \frac{\mathbf{T}}{n} \xrightarrow{P} \Sigma \quad (10.62)$$

sempre que $\mathbf{T}/n$ é considerada como estatística. No modelo normal positivo definido, sua interpretação como estimador de máxima verossimilhança requer adicionalmente as condições de existência do máximo da Proposição 10.1.

A Proposição 10.9 considera o regime clássico de **dimensão fixa**. Quando p aumenta com n , a noção de convergência depende do regime dimensional e da norma utilizada para medir o erro.

10.5.7 Transformações, posto e singularidade

A representação de Gram na Equação 8.56 determina a simetria, a semidefinição positiva e o posto da matriz SQPC observada. Como essas propriedades valem para cada realização, caracterizam também $\mathbf{T}$ e $\mathbf{S}$ amostra a amostra.

Transformações afins. Sob uma transformação afim dos dados, a matriz de covariâncias amostral transforma-se da mesma forma que a matriz de covariâncias populacional. Se

$$\mathbf{Y}_i = \mathbf{C}\mathbf{X}_i + \mathbf{d}, \quad i = 1, \dots, n,$$

então

$$\mathbf{T}_Y = \mathbf{C}\mathbf{T}_X\mathbf{C}^\top \quad (10.63)$$

e

$$\mathbf{S}_Y = \mathbf{C}\mathbf{S}_X\mathbf{C}^\top. \quad (10.64)$$

A translação $\mathbf{d}$ desaparece pela centralização. Como a matriz populacional satisfaz, pela Proposição 8.6,

$$\Sigma_Y = \mathbf{C}\Sigma_X\mathbf{C}^\top,$$

a matriz de covariâncias amostral e a matriz de covariâncias populacional obedecem à mesma regra de transformação por congruência.

Simetria e semidefinição positiva. Pela representação de Gram na Equação 8.56 e pelas propriedades de matrizes de Gram na Proposição 3.9, para qualquer realização da amostra,

$$\mathbf{T} = \mathbf{T}^\top \quad \text{e} \quad \mathbf{T} \succeq \mathbf{0}.$$

Como

$$\mathbf{S} = \frac{1}{n-1}\mathbf{T},$$

a matriz $\mathbf{S}$ também é simétrica e positiva semidefinida. Assim, em aritmética exata, o estimador não produz autovalores negativos.

Variância de combinações lineares. Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{a}^\top \mathbf{S} \mathbf{a} = \frac{1}{n-1} \sum_{i=1}^n [\mathbf{a}^\top (\mathbf{X}_i - \bar{\mathbf{X}})]^2. \quad (10.65)$$

A forma quadrática é a variância amostral da variável projetada

$$\mathbf{a}^\top \mathbf{X}.$$

Portanto,

$$\mathbf{a}^\top \mathbf{S} \mathbf{a} = 0$$

se, e somente se, os valores observados da combinação linear $\mathbf{a}^\top \mathbf{X}_i$ são constantes na amostra.

Posto. Pelo resultado estabelecido na Equação 8.57, para qualquer realização da amostra,

$$\text{posto}(\mathbf{T}) = \text{posto}(\mathbf{X}_c) \leq \min(p, n-1). \quad (10.66)$$

Como $\mathbf{S}$ é obtida por multiplicação de $\mathbf{T}$ por uma constante positiva,

$$\text{posto}(\mathbf{S}) = \text{posto}(\mathbf{T}). \quad (10.67)$$

Uma condição necessária para

$$\mathbf{S} \succ \mathbf{0}$$

é, portanto,

$$n \geq p+1.$$

Mesmo quando $n \geq p+1$, a definitude positiva de $\mathbf{S}$ exige que as colunas de $\mathbf{X}_c$ tenham posto completo.

Se

$$p \geq n,$$

então

$$\text{posto}(\mathbf{S}) \leq n - 1 < p,$$

e $\mathbf{S}$ é necessariamente singular.

A singularidade significa que existe algum vetor não nulo

$$\mathbf{a} \in \mathbb{R}^p$$

tal que

$$\mathbf{S}\mathbf{a} = \mathbf{0}.$$

Equivalentemente,

$$\mathbf{a}^\top \mathbf{S}\mathbf{a} = 0,$$

de modo que a combinação linear correspondente apresenta variância amostral nula.

Inversão. Quando

$$\mathbf{S} \succ \mathbf{0},$$

sua inversa existe e pode ser utilizada em formas quadráticas e métricas baseadas na covariância estimada.

Se $\mathbf{S}$ é singular, $\mathbf{S}^{-1}$ não existe. Pseudoinversa e regularização tratam essa situação por mecanismos distintos, descritos no Seção 10.8.

Forma quadrática com covariância estimada

A distância de Mahalanobis foi definida na Definição 8.8 utilizando os parâmetros populacionais. Sob normalidade, Proposição 9.8 estabelece a distribuição qui-quadrado da forma correspondente quando μ e Σ são conhecidos.

Substituir esses parâmetros por quantidades estimadas, como $\bar{\mathbf{x}}$ e $\mathbf{S}$, produz outra estatística. Portanto, a distribuição

$$D_M^2 \sim \chi_p^2$$

não pode ser transferida diretamente para uma forma quadrática construída com estimadores.

A Capítulo 12 estabelece as distribuições amostrais utilizadas quando μ e Σ são substituídos por estimadores.

A matriz $\mathbf{S} = \mathbf{T}/(n-1)$ é não viesada e consistente no regime de dimensão fixa. A matriz $\mathbf{T}/n$ é viesada em amostras finitas, também é consistente e corresponde ao estimador de momentos e, sob normalidade e existência do máximo, ao estimador de máxima verossimilhança. A matriz $\mathbf{S}$ satisfaz a transformação afim da Equação 10.64, é positiva semidefinida em cada realização e possui posto limitado por $\min(p, n-1)$.

A comparação entre estimadores concorrentes e a caracterização completa da variabilidade de $\mathbf{S}$ exigem hipóteses adicionais além dos segundos momentos.

Além da dispersão dentro de um único vetor, a análise multivariada utiliza covariâncias entre blocos de variáveis e correlações obtidas pela padronização das covariâncias amostrais.

10.6 Estimação de covariâncias cruzadas e correlações

Em diversos problemas multivariados, as variáveis são organizadas em blocos observados sobre as mesmas unidades amostrais. As covariâncias cruzadas descrevem associações lineares entre variáveis pertencentes a blocos distintos, enquanto as correlações removem as escalas marginais dessas associações.

O Capítulo 8 definiu a matriz de covariâncias cruzadas populacional na Definição 8.3, a matriz de covariâncias cruzadas observada na Definição 8.12 e a matriz de correlações observada na Definição 8.11. As versões aleatórias desses objetos definem os estimadores correspondentes no contexto amostral.

10.6.1 Covariâncias cruzadas entre blocos

Considere os vetores aleatórios

$$\mathbf{X} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{Y} \in \mathbb{R}^q.$$

A matriz de covariâncias cruzadas populacional

$$\Sigma_{XY}$$

foi definida na Definição 8.3. Sua orientação satisfaz, conforme Equação 8.13,

$$\Sigma_{YX} = \Sigma_{XY}^\top.$$

Para o vetor conjunto

$$\begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix},$$

a matriz de covariâncias possui a estrutura em blocos da Equação 8.15. Denote-a por

$$\Sigma_{\text{conj}} = \begin{bmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{bmatrix}. \quad (10.68)$$

Para estimar Σ_{XY} , é necessária uma amostra **pareada**:

$$(\mathbf{X}_1, \mathbf{Y}_1), \dots, (\mathbf{X}_n, \mathbf{Y}_n),$$

independente e identicamente distribuída segundo a distribuição conjunta de

$$(\mathbf{X}, \mathbf{Y}).$$

O pareamento significa que $\mathbf{X}_i$ e $\mathbf{Y}_i$ correspondem à mesma unidade amostral. Alterar a correspondência entre as linhas dos dois blocos modifica as covariâncias cruzadas.

Organize as observações nas matrizes aleatórias

$$\mathcal{X} \in \mathbb{R}^{n \times p}$$

e

$$\mathcal{Y} \in \mathbb{R}^{n \times q}.$$

Após a centralização,

$$\mathcal{X}_c = \mathbf{H}_n \mathcal{X}$$

e

$$\mathcal{Y}_c = \mathbf{H}_n \mathcal{Y}.$$

Definição 10.11 (Matriz de somas de produtos cruzados entre blocos). A **matriz de somas de produtos cruzados entre os dois blocos** é

$$\mathbf{T}_{XY} = \mathbf{x}_c^\top \mathbf{y}_c. \quad (10.69)$$

Equivalentemente,

$$\mathbf{T}_{XY} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{y}_i - \bar{\mathbf{y}})^\top. \quad (10.70)$$

Após a observação,

$$\mathbf{T}_{XY} = \mathbf{X}_c^\top \mathbf{Y}_c. \quad (10.71)$$

A inversão da ordem dos blocos produz

$$\mathbf{T}_{YX} = \mathbf{T}_{XY}^\top$$

e

$$\mathbf{T}_{YX} = \mathbf{T}_{XY}^\top.$$

Definição 10.12 (Matriz de covariâncias cruzadas amostral). Para $n \geq 2$, a matriz de covariâncias cruzadas amostral é

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{T}_{XY}, \quad (10.72)$$

em que $\mathbf{T}_{XY}$ é a matriz de somas de produtos cruzados entre os blocos definida na Definição 10.11.

Após a observação da amostra, obtém-se a matriz de covariâncias cruzadas observada definida na Definição 8.12:

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{T}_{XY} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{Y}_c. \quad (10.73)$$

Seu elemento (j, k) é

$$S_{X_j Y_k} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j) (Y_{ik} - \bar{Y}_k). \quad (10.74)$$

Após a observação da amostra, o elemento correspondente de $\mathbf{S}_{XY}$ é denotado por $s_{X_j Y_k}$.

A Equação 12.125 utiliza $\mathbf{S}_{XY}$ na matriz de covariâncias das diferenças pareadas. Não viesamento, consistência, máxima verossimilhança, transformação e posto de $\mathbf{S}_{XY}$ são tratados no Seção 10.7.

10.6.2 Matriz de correlações amostral

A matriz de correlações amostral é obtida pela padronização das covariâncias pelas variâncias marginais correspondentes.

Considere

$$\mathbf{S} = (S_{jk})$$

e defina a matriz diagonal das variâncias amostrais por

$$\mathbf{D}_S = \text{diag}(S_{11}, \dots, S_{pp}).$$

Definição 10.13 (Matriz de correlações amostral). Quando todas as variâncias amostrais são positivas, a matriz de correlações amostral é

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}, \quad (10.75)$$

em que

$$\mathbf{D}_S = \text{diag}(S_{11}, \dots, S_{pp}).$$

Após a observação da amostra, obtém-se a matriz $\mathbf{R}$ definida na Definição 8.11:

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}, \quad (10.76)$$

em que

$$\mathbf{D}_S = \text{diag}(s_{11}, \dots, s_{pp}).$$

O elemento (j, k) da estatística aleatória $\mathbf{R}$ é

$$R_{jk} = \frac{S_{jk}}{\sqrt{S_{jj}S_{kk}}}. \quad (10.77)$$

Após a observação da amostra, o elemento correspondente de $\mathbf{R}$ é

$$r_{jk} = \frac{s_{jk}}{\sqrt{s_{jj}s_{kk}}}.$$

Consequentemente,

$$R_{jj} = 1$$

e, para a realização observada,

$$r_{jj} = 1.$$

A Equação 8.68 identifica r_{jk} com o cosseno do ângulo entre as colunas centralizadas e padronizadas. Como estatística aleatória, $\mathbf{R}$ estima a matriz de correlações populacional $\mathcal{R}$.

Existência da correlação amostral

A correlação envolvendo uma variável não está definida quando sua variância amostral é zero.

Se

$$S_{jj} = 0$$

a correspondente padronização não existe.

O vetor de médias amostrais e a matriz de covariâncias amostral estimam localização e dispersão. A matriz $\mathbf{S}_{XY}$ estima covariâncias entre dois blocos, enquanto $\mathbf{R}$ estima a matriz de correlações populacional. Esses objetos completam a formulação amostral de localização, dispersão e associação utilizada nos capítulos posteriores.

10.7 Aprofundamento teórico

Viés, variabilidade e consistência não esgotam a comparação entre estimadores. Funções de perda e erro quadrático médio incorporam conjuntamente erro sistemático e variabilidade; eficiência compara procedimentos concorrentes; suficiência caracteriza a informação preservada por uma estatística; e equivariância relaciona transformações dos dados e dos estimadores.

10.7.1 Erro quadrático médio e funções de perda

A comparação entre estimadores requer especificar como diferentes erros são avaliados. Essa escolha é formalizada por uma **função de perda**. Para uma perda L , o **risco** do estimador é seu valor esperado sob o parâmetro θ :

$$R(\theta, \hat{\theta}) = E_{\theta} [L(\hat{\theta}, \theta)].$$

Assim, diferentes funções de perda podem conduzir a diferentes critérios de comparação entre estimadores (**casella1990inference?**).

Para um estimador vetorial, considere a perda quadrática euclidiana

$$L(\hat{\theta}, \theta) = \|\hat{\theta} - \theta\|^2. \quad (10.78)$$

A perda quadrática euclidiana atribui o mesmo peso aos erros nas diferentes coordenadas da parametrização utilizada. Outras funções de perda podem atribuir pesos distintos às coordenadas ou avaliar os erros segundo critérios diferentes.

Definição 10.14 (Erro quadrático médio vetorial). Sob a perda quadrática euclidiana,

$$\text{EQM}(\hat{\theta}) = E [\|\hat{\theta} - \theta\|^2]. \quad (10.79)$$

Proposição 10.10 (Decomposição do erro quadrático médio). *Se $\hat{\theta}$ possui segundos momentos finitos, então*

$$\text{EQM}(\hat{\theta}) = \text{tr} [\text{Cov}(\hat{\theta})] + \|\text{Bias}(\hat{\theta})\|^2. \quad (10.80)$$

i Demonstração

Escreva

$$\hat{\theta} - \theta = [\hat{\theta} - E(\hat{\theta})] + \text{Bias}(\hat{\theta}).$$

O primeiro termo possui média zero. Ao expandir o quadrado da norma e tomar esperança, o termo cruzado desaparece. Além disso,

$$E [\|\hat{\theta} - E(\hat{\theta})\|^2] = \text{tr} [\text{Cov}(\hat{\theta})].$$

A substituição dessas esperanças fornece a decomposição do erro quadrático médio em Equação 10.80.

Quando o estimador é não viesado,

$$\text{EQM}(\hat{\theta}) = \text{tr} [\text{Cov}(\hat{\theta})].$$

A decomposição na Equação 10.80 também pode ser vista como uma aplicação de Equação 8.38, tomando a matriz identidade e considerando $\hat{\theta}$ como vetor aleatório com média $E(\hat{\theta})$.

A ausência de viés não implica EQM mínimo. Um estimador viesado pode apresentar menor risco quadrático quando a redução da variabilidade compensa o aumento do viés.

Para um parâmetro matricial Θ , a norma de Frobenius definida na Definição 6.7 conduz à perda quadrática

$$L_F(\hat{\Theta}, \Theta) = \|\hat{\Theta} - \Theta\|_F^2.$$

O erro quadrático médio matricial é

$$\text{EQM}_F(\hat{\Theta}) = E \left[\|\hat{\Theta} - \Theta\|_F^2 \right]. \quad (10.81)$$

Equivalentemente,

$$\begin{aligned} \text{EQM}_F(\hat{\Theta}) &= \text{tr} \left\{ \text{Cov} [\text{vec}(\hat{\Theta})] \right\} \\ &\quad + \|\text{Bias}(\hat{\Theta})\|_F^2. \end{aligned} \quad (10.82)$$

A norma de Frobenius corresponde a uma escolha específica de perda. Em problemas de estimação de matrizes de covariâncias, outros critérios podem atribuir pesos diferentes a autovalores, direções ou erros de inversão.

10.7.2 Erro quadrático médio do vetor de médias amostrais

Como $\bar{\mathbf{X}}$ é não viesado, a decomposição do erro quadrático médio na Equação 10.80 reduz-se ao termo de variabilidade. Sob a perda quadrática euclidiana,

$$\begin{aligned} \text{EQM}(\bar{\mathbf{X}}) &= \text{tr} [\text{Cov}(\bar{\mathbf{X}})] \\ &= \frac{1}{n} \text{tr}(\Sigma). \end{aligned} \quad (10.83)$$

Como a variância total populacional foi definida na Equação 8.35 por

$$\text{tr}(\Sigma),$$

Equação 10.83 mostra que o erro quadrático médio sob perda euclidiana corresponde à variância total dividida pelo tamanho amostral.

Para $\bar{\mathbf{X}}$, o não viesamento e a matriz de covariâncias Σ/n determinam o erro quadrático médio na Equação 10.83. A eficiência exige adicionalmente a comparação de $\bar{\mathbf{X}}$ com estimadores concorrentes segundo um critério especificado.

10.7.3 Variabilidade e erro quadrático da matriz de covariâncias amostral

O não viesamento de $\mathbf{S}$ exige apenas segundos momentos. A caracterização conjunta da variabilidade de seus elementos envolve

$$\text{Cov}[\text{vec}(\mathbf{S})],$$

utilizando o operador definido na Definição 7.9. Sob a perda baseada na norma de Frobenius definida na Definição 6.7, o erro quadrático médio de $\mathbf{S}$ é determinado por

$$E[\|\mathbf{S} - \Sigma\|_F^2].$$

A matriz $\text{Cov}[\text{vec}(\mathbf{S})]$ e o EQM matricial de $\mathbf{S}$ dependem, em geral, de momentos de quarta ordem. Portanto, a existência de segundos momentos não determina completamente essas duas quantidades. Sob normalidade, a Capítulo 12 obtém propriedades adicionais de $\mathbf{S}$ a partir de sua distribuição amostral.

10.7.4 Eficiência

A eficiência compara estimadores concorrentes segundo sua variabilidade ou segundo um risco especificado. Para estimadores vetoriais não viesados, a ordem de Löwner permite comparar suas matrizes de covariâncias. Considere dois estimadores

$$\hat{\theta}_1 \quad \text{e} \quad \hat{\theta}_2,$$

ambos não viesados para θ .

Diz-se que $\hat{\theta}_1$ é uniformemente pelo menos tão eficiente quanto $\hat{\theta}_2$, segundo a ordem de Löwner, quando

$$\text{Cov}_\theta(\hat{\theta}_1) \preceq \text{Cov}_\theta(\hat{\theta}_2) \quad \text{para todo } \theta \in \Theta. \quad (10.84)$$

Equivalentemente,

$$\text{Cov}_\theta(\hat{\theta}_2) - \text{Cov}_\theta(\hat{\theta}_1) \succeq \mathbf{0}.$$

Consequentemente, para todo $\mathbf{a} \in \mathbb{R}^r$,

$$\text{Var}_\theta(\mathbf{a}^\top \hat{\theta}_1) \leq \text{Var}_\theta(\mathbf{a}^\top \hat{\theta}_2).$$

No caso vetorial, não existe necessariamente um estimador que seja mais preciso em todos os aspectos. Cada vetor $\mathbf{a} \in \mathbb{R}^r$ define uma combinação linear $\mathbf{a}^\top \hat{\theta}$ e, portanto, uma direção na qual a variabilidade dos estimadores pode ser comparada. Um estimador pode apresentar menor variabilidade em determinadas direções e maior variabilidade em outras.

A ordem de Löwner declara $\hat{\theta}_1$ pelo menos tão eficiente quanto $\hat{\theta}_2$ somente quando

$$\text{Var}_\theta(\mathbf{a}^\top \hat{\theta}_1) \leq \text{Var}_\theta(\mathbf{a}^\top \hat{\theta}_2)$$

para toda direção $\mathbf{a} \in \mathbb{R}^r$. A ordem é parcial porque duas matrizes de covariâncias podem não ser comparáveis por semidefinição positiva.

Quando duas matrizes de covariâncias não são comparáveis pela ordem de Löwner, um critério escalar pode resumir a variabilidade total dos componentes do estimador. Um exemplo é

$$\text{tr} [\text{Cov}(\hat{\theta})],$$

que soma as variâncias dos componentes do estimador. O traço da matriz de covariâncias define um critério específico de comparação; outra função de perda pode produzir uma ordenação diferente dos estimadores.

Para estimadores viesados, a comparação baseada somente nas matrizes de covariâncias é insuficiente. É necessário considerar um risco que incorpore viés e variabilidade.

A eficiência assintótica compara as matrizes de covariâncias que aparecem nas distribuições-limite de sequências de estimadores. Sob condições de regularidade, estimadores de máxima verossimilhança podem atingir limites associados à informação de Fisher definida na Definição 7.14.

10.7.5 Suficiência

Uma estatística é suficiente para θ quando, condicionada ao valor dessa estatística, a distribuição da amostra deixa de depender de θ (**casella1990inference?**).

Definição 10.15 (Estatística suficiente). Considere uma amostra aleatória

$$\mathcal{X} \in \mathbb{R}^{n \times p},$$

cujas distribuições pertencem a uma família indexada por

$$\theta \in \Theta,$$

e uma estatística definida por

$$G : \mathbb{R}^{n \times p} \longrightarrow \mathcal{G},$$

de modo que

$$\mathbf{G} = G(\mathcal{X}).$$

A estatística $\mathbf{G}$ é **suficiente para** θ quando a distribuição condicional de $\mathcal{X}$ dado $\mathbf{G}$ é a mesma para todos os valores de $\theta \in \Theta$ para os quais essa distribuição condicional está definida.

A função G reduz a amostra à estatística $\mathbf{G}$. Se $\mathbf{G}$ é suficiente, a distribuição condicional de $\mathcal{X}$ dado $\mathbf{G}$ não depende de θ .

A suficiência corresponde a uma redução dos dados que preserva, no modelo considerado, toda a dependência da distribuição amostral em relação a θ . A suficiência de $\mathbf{G}$ não implica que a amostra original possa ser reconstruída a partir de $\mathbf{G}$.

A definição de suficiência é formulada em termos de uma distribuição condicional, que nem sempre é a forma mais conveniente para verificar a propriedade diretamente. Para famílias dominadas por uma medida comum, o Teorema da Fatoração de Neyman–Fisher fornece um critério equivalente baseado na forma da densidade ou da função de probabilidade conjunta.

Teorema 10.1 (Teorema da Fatoração de Neyman–Fisher). *Considere uma família de distribuições indexada por*

$$\theta \in \Theta$$

e dominada por uma medida comum ν , com densidade conjunta

$$f_{\theta} : \mathcal{X} \longrightarrow [0, \infty)$$

em relação a ν .

Considere também uma estatística definida por

$$G : \mathcal{X} \longrightarrow \mathcal{G}.$$

A estatística $G(\mathcal{X})$ é suficiente para θ se, e somente se, existem funções não negativas

$$q_{\theta} : \mathcal{G} \longrightarrow [0, \infty), \quad \theta \in \Theta,$$

e

$$r : \mathcal{X} \longrightarrow [0, \infty),$$

com r independente de θ , tais que

$$f_{\theta}(\mathbf{x}) = q_{\theta}[G(\mathbf{x})] r(\mathbf{x}) \tag{10.85}$$

para ν -quase todo $\mathbf{x} \in \mathcal{X}$ e para todo $\theta \in \Theta$.

(casella1990inference?)

Na Equação [10.85](#),

$$q_{\theta}[G(\mathbf{x})]$$

contém toda a dependência da densidade em relação a θ e depende dos dados somente por meio de $G(\mathbf{x})$. O fator

$$r(\mathbf{x})$$

pode depender da amostra completa, mas é independente de θ . Portanto, a dependência da verossimilhança em relação ao parâmetro ocorre por meio de $G(\mathbf{x})$.

No modelo normal multivariado definido na Definição 9.1, o vetor de médias amostrais e a matriz SQPC formam conjuntamente uma estatística suficiente para μ e Σ (Anderson, 2003).

Proposição 10.11 (Suficiência no modelo normal multivariado). *No modelo normal multivariado, a estatística*

$$(\bar{\mathbf{X}}, \mathbf{T})$$

é suficiente para o parâmetro

$$(\mu, \Sigma),$$

quando

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0}.$$

Na Proposição 10.11,

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

é o vetor de médias amostrais e

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{X}}) (\mathbf{x}_i - \bar{\mathbf{X}})^\top \quad (10.86)$$

é a matriz SQPC.

i Demonstração

Para uma realização $\mathbf{x}_1, \dots, \mathbf{x}_n$, a densidade conjunta é

$$f_{\mu, \Sigma}(\mathbf{x}_1, \dots, \mathbf{x}_n) = (2\pi)^{-np/2} \det(\Sigma)^{-n/2} \times \exp \left\{ -\frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu) \right\}.$$

A identidade de decomposição em torno da média fornece

$$\begin{aligned} \sum_{i=1}^n (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^\top \\ = \mathbf{T} + n (\bar{\mathbf{x}} - \mu) (\bar{\mathbf{x}} - \mu)^\top, \end{aligned}$$

em que $\mathbf{T}$ é a matriz SQPC observada definida na Definição 8.9:

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

Logo, toda a dependência da densidade conjunta em relação a μ e Σ ocorre por meio de

$$(\bar{\mathbf{x}}, \mathbf{T}).$$

O resultado segue de Teorema 10.1.

Suficiência, não viesamento, consistência e eficiência são propriedades distintas. A suficiência caracteriza a dependência da distribuição amostral em relação ao parâmetro e não estabelece a qualidade de um estimador segundo viés, variabilidade ou risco.

Sob o modelo normal multivariado, a Proposição 10.11 garante que

$$(\bar{\mathbf{X}}, \mathbf{T})$$

é suficiente para

$$(\mu, \Sigma).$$

Como, para n fixado,

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}$$

é uma transformação bijetiva de $\mathbf{T}$, o par

$$(\bar{\mathbf{X}}, \mathbf{S})$$

também é suficiente para (μ, Σ) . A suficiência pertence ao par $(\bar{\mathbf{X}}, \mathbf{S})$; $\mathbf{S}$ isoladamente não é suficiente para (μ, Σ) .

10.7.6 Equivariância

Quando uma transformação dos dados induz uma transformação correspondente do parâmetro, um estimador é equivariante se estimar após transformar os dados produz a transformação correspondente da estimativa obtida nos dados originais.

Definição 10.16 (Equivariância de um estimador). Considere um espaço amostral $\mathcal{X}$, um espaço amostral transformado $\mathcal{Y}$ e espaços paramétricos Θ e Ψ .

Sejam

$$h : \mathcal{X} \longrightarrow \mathcal{Y}$$

uma transformação dos dados e

$$g : \Theta \longrightarrow \Psi$$

a transformação correspondente do parâmetro.

Considere uma regra de estimação

$$G_{\Theta} : \mathcal{X} \longrightarrow \Theta$$

para $\theta \in \Theta$ e a regra correspondente

$$G_{\Psi} : \mathcal{Y} \longrightarrow \Psi$$

para

$$\psi = g(\theta).$$

As regras de estimação são **equivariantes** em relação a h e g quando

$$G_{\Psi}[h(\mathcal{X})] = g[G_{\Theta}(\mathcal{X})]. \quad (10.87)$$

A função h atua sobre os dados, enquanto g atua sobre o parâmetro. Por isso, as duas funções não precisam possuir a mesma forma.

Considere, por exemplo, a transformação afim dos dados

$$h : \mathbf{X}_i \mapsto \mathbf{Y}_i = \mathbf{C}\mathbf{X}_i + \mathbf{d}, \quad i = 1, \dots, n,$$

com

$$\mathbf{C} \in \mathbb{R}^{q \times p} \quad \text{e} \quad \mathbf{d} \in \mathbb{R}^q.$$

A função h transforma cada vetor da amostra por $\mathbf{X}_i \mapsto \mathbf{C}\mathbf{X}_i + \mathbf{d}$.

Para o vetor de médias, o parâmetro populacional é

$$\theta = \mu,$$

e a transformação correspondente no espaço paramétrico é

$$g_1(\mu) = \mathbf{C}\mu + \mathbf{d}.$$

Portanto,

$$\mu_Y = g_1(\mu) = \mathbf{C}\mu + \mathbf{d}.$$

Para a matriz de covariâncias, o parâmetro populacional é

$$\theta = \Sigma,$$

e, por Proposição 8.6, a transformação correspondente é

$$g_2(\Sigma) = \mathbf{C}\Sigma\mathbf{C}^\top.$$

Portanto,

$$\Sigma_Y = g_2(\Sigma) = \mathbf{C}\Sigma\mathbf{C}^\top.$$

A transformação afim h induz transformações distintas conforme o parâmetro considerado. Para a média,

$$g_1(\mu) = \mathbf{C}\mu + \mathbf{d},$$

enquanto, para a covariância,

$$g_2(\Sigma) = \mathbf{C}\Sigma\mathbf{C}^\top.$$

Portanto, a transformação paramétrica depende do objeto estimado, mesmo quando a transformação dos dados é a mesma.

Para estimar μ , a regra de estimação é

$$G_1(\mathcal{X}) = \bar{\mathbf{X}}.$$

Aplicando a mesma regra aos dados transformados,

$$G_1[h(\mathcal{X})] = \bar{\mathbf{Y}} = \mathbf{C}\bar{\mathbf{X}} + \mathbf{d} = g_1[G_1(\mathcal{X})].$$

Portanto, o vetor de médias amostrais é equivariante em relação a essa transformação afim.

Para estimar Σ , a regra de estimação é

$$G_2(\mathcal{X}) = \mathbf{S}_X.$$

Para os dados transformados,

$$G_2[h(\mathcal{X})] = \mathbf{S}_Y = \mathbf{C}\mathbf{S}_X\mathbf{C}^\top = g_2[G_2(\mathcal{X})].$$

Assim, a matriz de covariâncias amostral também é equivariante em relação à transformação considerada.

A equivariância descreve como um estimador responde a uma transformação dos **dados**: transformar os dados e depois estimar deve produzir o mesmo resultado que estimar primeiro e aplicar a transformação correspondente ao parâmetro.

Equivariância e invariância da máxima verossimilhança são propriedades distintas. A equivariância relaciona transformações dos dados e dos parâmetros. A invariância da máxima verossimilhança transforma um estimador de máxima verossimilhança de θ em um estimador de máxima verossimilhança de uma função de θ .

Viés, variabilidade, erro quadrático médio, consistência, eficiência, suficiência e equivariância respondem a perguntas diferentes sobre um procedimento de estimação:

- **viés** compara o valor médio do estimador com o parâmetro;
- **variabilidade** descreve quanto o estimador muda entre amostras;
- **erro quadrático médio** combina viés e variabilidade segundo uma função de perda;
- **consistência** descreve o comportamento do estimador quando o tamanho amostral aumenta;
- **eficiência** compara a variabilidade de procedimentos concorrentes;
- **suficiência** examina quanta informação sobre o parâmetro é preservada por uma estatística;
- **equivariância** examina a coerência do estimador diante de transformações dos dados.

Nenhuma dessas propriedades estabelece, isoladamente, uma ordenação universal entre estimadores. Um estimador pode apresentar menor viés segundo um critério e maior variabilidade segundo outro. A escolha entre procedimentos de estimação depende do parâmetro de interesse, da função de perda, do modelo probabilístico, do tamanho amostral, da dimensão e do objetivo da análise.

10.7.7 Propriedades gerais dos métodos de estimação

As expressões em Equação 10.18, Equação 10.21, Equação 10.31 e Equação 10.32 são aplicações específicas do método dos momentos e da máxima verossimilhança. A formulação geral distingue o princípio de construção do estimador das propriedades estatísticas que exigem condições adicionais.

10.7.7.1 Formulação geral do método dos momentos

Definição 10.17 (Estimador pelo método dos momentos). Considere

$$\theta \in \Theta \subseteq \mathbb{R}^r$$

e uma função

$$\mathbf{q} : \mathbb{R}^p \longrightarrow \mathbb{R}^r$$

tal que

$$E_{\theta} [\|\mathbf{q}(\mathbf{X})\|] < \infty$$

para os valores de θ considerados.

Defina

$$\mathbf{m} : \Theta \longrightarrow \mathbb{R}^r$$

por

$$\mathbf{m}(\theta) = E_{\theta}[\mathbf{q}(\mathbf{X})]. \quad (10.88)$$

Para uma amostra i.i.d.

$$\mathbf{X}_1, \dots, \mathbf{X}_n,$$

defina

$$\widehat{\mathbf{m}} = \frac{1}{n} \sum_{i=1}^n \mathbf{q}(\mathbf{X}_i). \quad (10.89)$$

Um **estimador pelo método dos momentos** de θ é qualquer solução

$$\hat{\theta}_{\text{MM}} \in \Theta$$

do sistema

$$\mathbf{m}(\hat{\theta}_{\text{MM}}) = \widehat{\mathbf{m}}. \quad (10.90)$$

A existência e a unicidade do estimador dependem dos momentos escolhidos e da forma da função $\mathbf{m}$. O método dos momentos substitui $\mathbf{m}(\theta)$ por $\widehat{\mathbf{m}}$ e resolve o sistema resultante em relação a θ .

O sistema pode não possuir solução, possuir mais de uma solução ou produzir valores que não pertençam a Θ .

Propriedades dos estimadores de momentos

A Equação 10.90 define o estimador pela igualdade entre momentos populacionais e amostrais. Essa igualdade não implica não viesamento, eficiência, suficiência, equivariância ou robustez.

A consistência de um estimador de momentos exige condições adicionais, entre elas existência dos momentos utilizados, convergência dos momentos amostrais, identificação do parâmetro pelos momentos populacionais e continuidade da solução das equações de momentos.

Portanto, cada propriedade deve ser verificada para o estimador e o modelo considerados.

Restrições do espaço paramétrico

A solução das equações de momentos deve pertencer ao espaço paramétrico Θ . Condições de positividade, ordem, posto ou outras restrições estruturais podem excluir soluções algébricas das equações de momentos.

10.7.7.2 Propriedades gerais da máxima verossimilhança

Propriedades dos estimadores de máxima verossimilhança

Em amostras finitas, a construção por máxima verossimilhança não implica não viesamento, EQM mínimo, suficiência, equivariância em relação a transformações dos dados ou robustez.

Sob condições de regularidade e identificabilidade, estimadores de máxima verossimilhança podem ser consistentes, assintoticamente normais e assintoticamente eficientes. Consistência, normalidade assintótica e eficiência assintótica dependem das condições específicas do modelo.

A máxima verossimilhança é invariante em relação a funções do parâmetro: quando o estimador de máxima verossimilhança existe, uma função apropriada desse estimador fornece um estimador de máxima verossimilhança da função correspondente do parâmetro. A Proposição 10.12 apresenta a formulação geral.

10.7.7.3 Comparação entre método dos momentos e máxima verossimilhança

No modelo normal multivariado, método dos momentos e máxima verossimilhança conduzem às mesmas expressões para μ e Σ quando o estimador de máxima verossimilhança existe. A igualdade entre os estimadores depende do modelo e não constitui uma propriedade geral dos dois métodos. A Tabela 10.1 resume outras diferenças entre os procedimentos.

Tabela 10.1: Relação entre os métodos de estimação e propriedades dos estimadores.

Propriedade	Método dos momentos	Máxima verossimilhança
Não viesamento em amostras finitas	Não é garantido pelo método	Não é garantido pelo método
Consistência	Pode ser obtida sob condições de convergência, identificação e continuidade	Pode ser obtida sob condições de regularidade e identificação
Eficiência em amostras finitas	Não é garantida	Não é garantida
Eficiência assintótica	Não é uma propriedade geral do método	Pode ocorrer sob condições de regularidade

Propriedade	Método dos momentos	Máxima verossimilhança
Suficiência	Não é garantida pelo método	Não é garantida apenas pela maximização
Equivariância sob transformações dos dados	Depende do estimador e da transformação	Depende do estimador e da transformação
Invariância sob funções do parâmetro	Não é uma propriedade geral do método	É uma propriedade estrutural da máxima verossimilhança, quando o estimador existe
Robustez	Não é garantida	Não é garantida

Não viesamento, consistência, eficiência, suficiência, equivariância e robustez exigem condições que não decorrem automaticamente da escolha entre método dos momentos e máxima verossimilhança.

10.7.8 Invariância da máxima verossimilhança

Para uma função do parâmetro, a invariância da máxima verossimilhança relaciona o estimador do parâmetro original ao estimador de sua transformação, sem exigir uma nova maximização (Eaton, 2007).

Considere uma função

$$g : \Theta \longrightarrow \Psi, \quad \Psi = g(\Theta),$$

e defina

$$\psi = g(\theta).$$

Para cada

$$\psi \in \Psi,$$

defina a verossimilhança perfilada por

$$L_g(\psi) = \sup_{\theta \in \Theta: g(\theta) = \psi} L(\theta). \quad (10.91)$$

A invariância da máxima verossimilhança não exige que g seja injetiva, contínua ou monótona.

Proposição 10.12 (Invariância da máxima verossimilhança). *Considere*

$$g : \Theta \longrightarrow \Psi, \quad \Psi = g(\Theta),$$

e suponha que

$$\hat{\theta}_{\text{MV}} \in \arg \max_{\theta \in \Theta} L(\theta).$$

Então

$$g(\hat{\theta}_{\text{MV}}) \in \arg \max_{\psi \in \Psi} L_g(\psi).$$

Portanto,

$$\hat{\psi}_{\text{MV}} = g(\hat{\theta}_{\text{MV}})$$

é um estimador de máxima verossimilhança de

$$\psi = g(\theta).$$

i Demonstração

Defina

$$\hat{\psi} = g(\hat{\theta}_{\text{MV}}).$$

Como a fibra

$$\{\theta \in \Theta : g(\theta) = \hat{\psi}\}$$

contém $\hat{\theta}_{\text{MV}}$, tem-se

$$L_g(\hat{\psi}) = L(\hat{\theta}_{\text{MV}}).$$

Nenhum outro valor de ψ pode apresentar verossimilhança perfilada superior, pois isso implicaria a existência de algum θ cuja verossimilhança superasse o máximo global. Portanto,

$$\hat{\psi} = g(\hat{\theta}_{\text{MV}})$$

é um estimador de máxima verossimilhança de ψ .

A Proposição 10.12 refere-se a funções do parâmetro e difere da equivariância, que relaciona transformações dos dados às transformações correspondentes do estimador.

Considere a matriz de correlações populacional definida na Definição 8.5:

$$\mathcal{R} = \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}.$$

Quando o estimador de máxima verossimilhança de Σ existe e possui diagonal positiva, a invariância fornece

$$\widehat{\mathcal{R}}_{\text{MV}} = \widehat{\mathbf{D}}_{\Sigma, \text{MV}}^{-1/2} \widehat{\Sigma}_{\text{MV}} \widehat{\mathbf{D}}_{\Sigma, \text{MV}}^{-1/2}. \quad (10.92)$$

Como a correlação é invariante a mudanças positivas de escala, conforme Equação 8.25, o fator comum que distingue as matrizes de covariâncias com divisores n e $n - 1$ cancela-se na padronização. Portanto, a Equação 10.92 produz a mesma matriz de correlações obtida a partir de $\mathbf{S}$.

10.7.8.1 Consequência para a matriz de correlações amostral

Sob o modelo normal multivariado, quando o estimador de máxima verossimilhança de Σ existe,

$$\widehat{\Sigma}_{\text{MV}} = \frac{n-1}{n} \mathbf{S}.$$

O fator $(n-1)/n$ cancela-se na padronização de $\widehat{\Sigma}_{\text{MV}}$. Pela Proposição 10.12,

$$\widehat{\mathcal{R}}_{\text{MV}} = \mathbf{R}. \quad (10.93)$$

Sob o modelo normal e nas condições de existência do máximo, $\mathbf{R}$ é, portanto, um estimador de máxima verossimilhança de $\mathcal{R}$.

A Proposição 10.12 também se aplica a funções como

$$\det(\Sigma), \quad \text{tr}(\Sigma)$$

e, quando o estimador é positivo definido,

$$\Sigma^{-1}.$$

A invariância da máxima verossimilhança não implica não viesamento, consistência ou estabilidade numérica. Em particular, aplicar a função inversa a uma matriz estimada mal condicionada pode amplificar pequenas perturbações na estimativa.

10.7.9 Extensões para covariâncias cruzadas e correlações

A matriz $\mathbf{S}_{XY}$ definida na Definição 10.12 estima Σ_{XY} , enquanto $\mathbf{R}$ definida na Definição 10.13 estima $\mathcal{R}$. Não viesamento, consistência, posto e comportamento sob transformações exigem resultados adicionais às respectivas definições.

10.7.9.1 Propriedades da covariância cruzada amostral

Proposição 10.13 (Não viesamento da covariância cruzada amostral). *Considere uma amostra pareada i.i.d. do vetor conjunto*

$$\begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix},$$

com segundos momentos finitos. Então,

$$E(\mathbf{S}_{XY}) = \Sigma_{XY}. \quad (10.94)$$

i Demonstração

A matriz de covariâncias amostral do vetor conjunto é

$$\mathbf{S}_{\text{conj}} = \begin{bmatrix} \mathbf{S}_{XX} & \mathbf{S}_{XY} \\ \mathbf{S}_{YX} & \mathbf{S}_{YY} \end{bmatrix}.$$

Pelo não viesamento da matriz de covariâncias amostral estabelecido na Equação 10.54,

$$E(\mathbf{S}_{\text{conj}}) = \Sigma_{\text{conj}}.$$

A igualdade entre os blocos superiores direitos fornece

$$E(\mathbf{S}_{XY}) = \Sigma_{XY}.$$

O método dos momentos aplicado à matriz de covariâncias do vetor conjunto conduz ao estimador

$$\widehat{\Sigma}_{\text{conj,MM}} = \frac{1}{n} \mathbf{T}_{\text{conj}}.$$

O bloco fora da diagonal correspondente a Σ_{XY} é

$$\widehat{\Sigma}_{XY,\text{MM}} = \frac{1}{n} \mathbf{T}_{XY}.$$

Sob normalidade conjunta não singular,

$$\begin{bmatrix} \mathbf{X}_i \\ \mathbf{Y}_i \end{bmatrix} \stackrel{\text{iid}}{\sim} N_{p+q} \left(\begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, \Sigma_{\text{conj}} \right),$$

o estimador de máxima verossimilhança da matriz conjunta de covariâncias, quando existe, utiliza também o divisor n . Portanto,

$$\widehat{\Sigma}_{XY,\text{MM}} = \widehat{\Sigma}_{XY,\text{MV}} = \frac{1}{n} \mathbf{T}_{XY} = \frac{n-1}{n} \mathbf{S}_{XY}. \quad (10.95)$$

Se

$$n \geq p + q + 1$$

e a distribuição normal conjunta é não singular, a matriz SQPC do vetor conjunto possui posto $p + q$ quase certamente. Sob normalidade conjunta não singular e $n \geq p + q + 1$, o estimador de máxima verossimilhança positivo definido de Σ_{conj} existe quase certamente.

Por Equação 10.94,

$$E \left(\frac{1}{n} \mathbf{T}_{XY} \right) = \frac{n-1}{n} \Sigma_{XY}.$$

Assim,

$$\text{Bias} \left(\frac{1}{n} \mathbf{T}_{XY} \right) = -\frac{1}{n} \Sigma_{XY}.$$

O viés de $\mathbf{T}_{XY}/n$ como estimador de Σ_{XY} independe da normalidade. A hipótese normal é necessária apenas para identificar $\mathbf{T}_{XY}/n$ como o bloco cruzado do estimador de máxima verossimilhança de Σ_{conj} .

A consistência de $\mathbf{S}_{XY}$ decorre da consistência da matriz de covariâncias amostral do vetor conjunto. Sob as condições da Proposição 10.9, aplicadas ao vetor de dimensão $p + q$,

$$\mathbf{S}_{\text{conj}} \xrightarrow{P} \Sigma_{\text{conj}}.$$

Consequentemente, cada um de seus blocos converge para o bloco populacional correspondente e, em particular,

$$\mathbf{S}_{XY} \xrightarrow{P} \Sigma_{XY}. \quad (10.96)$$

Como

$$\frac{1}{n} \mathbf{T}_{XY} = \frac{n-1}{n} \mathbf{S}_{XY},$$

também se obtém

$$\frac{1}{n} \mathbf{T}_{XY} \xrightarrow{P} \Sigma_{XY}.$$

A covariância cruzada amostral obedece à mesma regra de transformação bilinear da covariância cruzada populacional estabelecida na Equação 8.19. Se

$$\mathbf{U} = \mathbf{CX} + \mathbf{c}$$

e

$$\mathbf{V} = \mathbf{DY} + \mathbf{d},$$

então

$$\mathbf{S}_{UV} = \mathbf{CS}_{XY}\mathbf{D}^\top. \quad (10.97)$$

Portanto, $\mathbf{S}_{XY}$ é equivariante sob as transformações afins $\mathbf{X} \mapsto \mathbf{CX} + \mathbf{c}$ e $\mathbf{Y} \mapsto \mathbf{DY} + \mathbf{d}$. Os termos de localização $\mathbf{c}$ e $\mathbf{d}$ desaparecem após a centralização.

Para

$$U = \mathbf{a}^\top \mathbf{X}$$

e

$$V = \mathbf{b}^\top \mathbf{Y},$$

segue que

$$\mathbf{S}_{UV} = \mathbf{a}^\top \mathbf{S}_{XY} \mathbf{b}. \quad (10.98)$$

Diferentemente de uma matriz de covariâncias de um único vetor, $\mathbf{S}_{XY}$ é, em geral, retangular quando $p \neq q$. Mesmo quando $p = q$, ela não precisa ser simétrica. Os dois blocos satisfazem

$$\mathbf{S}_{YX} = \mathbf{S}_{XY}^\top.$$

Simetria e semidefinitude positiva são propriedades da matriz de covariâncias do vetor conjunto, não do bloco $\mathbf{S}_{XY}$ considerado isoladamente.

O posto satisfaz

$$\text{posto}(\mathbf{S}_{XY}) \leq \min(p, q, n - 1). \quad (10.99)$$

O limite de posto decorre simultaneamente das dimensões dos dois blocos e do posto máximo $n - 1$ imposto pela centralização amostral.

10.7.9.2 Propriedades estruturais da matriz de correlações amostral

Proposição 10.14 (Propriedades da matriz de correlações amostral). *Quando todas as variâncias amostrais são positivas, $\mathbf{R}$ é:*

1. *simétrica;*
2. *positiva semidefinida;*
3. *unitária na diagonal.*

Além disso,

$$\text{posto}(\mathbf{R}) = \text{posto}(\mathbf{S}). \quad (10.100)$$

Consequentemente,

$$\mathbf{R} \succ \mathbf{0} \iff \mathbf{S} \succ \mathbf{0}. \quad (10.101)$$

i Demonstração

A simetria decorre da simetria de $\mathbf{S}$.

Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\begin{aligned}\mathbf{a}^\top \mathbf{R} \mathbf{a} &= (\mathbf{D}_S^{-1/2} \mathbf{a})^\top \mathbf{S} (\mathbf{D}_S^{-1/2} \mathbf{a}) \\ &\geq 0.\end{aligned}$$

Logo, $\mathbf{R}$ é positiva semidefinida.

A diagonal unitária decorre de

$$R_{jj} = \frac{S_{jj}}{S_{jj}} = 1.$$

Como $\mathbf{D}_S^{-1/2}$ é invertível, a transformação por congruência preserva o posto e a definitude positiva.

Uma matriz simétrica com diagonal unitária e elementos em $[-1, 1]$ não é necessariamente uma matriz de correlações válida. A positividade semidefinida também é necessária.

Como

$$\text{posto}(\mathbf{R}) = \text{posto}(\mathbf{S}),$$

uma condição necessária para definitude positiva é

$$n \geq p + 1.$$

A condição $n \geq p+1$ não é suficiente para uma amostra arbitrária, pois as colunas centralizadas ainda podem ser linearmente dependentes.

Quando

$$p \geq n,$$

a matriz de correlações, se definida, é necessariamente singular.

Para uma realização observada,

$$\det(\mathbf{R}) = \frac{\det(\mathbf{S})}{\prod_{j=1}^p s_{jj}}. \quad (10.102)$$

A padronização remove as escalas marginais, mas não altera o posto.

10.7.9.3 Estimação, viés e consistência da matriz de correlações amostral

A matriz de correlações populacional é uma função da matriz de covariâncias,

$$\mathcal{R} = \mathbf{D}_\Sigma^{-1/2} \Sigma \mathbf{D}_\Sigma^{-1/2}.$$

Substituindo Σ pelo estimador de momentos

$$\widehat{\Sigma}_{\text{MM}} = \frac{1}{n} \mathbf{T},$$

obtem-se um estimador por substituição de $\mathcal{R}$. Como o fator comum $1/n$ aparece tanto nas covariâncias quanto nas variâncias marginais, ele se cancela na padronização. A matriz resultante é

$$\mathbf{R}.$$

A padronização de $\widehat{\Sigma}_{\text{MM}} = \mathbf{T}/n$ produz, portanto, $\mathbf{R}$.

A construção de $\mathbf{R}$ por padronização da matriz de covariâncias estimada não implica não viesamento. Em geral,

$$E(\mathbf{R}_{jk}) \neq \rho_{jk}.$$

O não viesamento das variâncias e covariâncias amostrais não é preservado automaticamente pela transformação não linear que as converte em correlações.

Para estabelecer a consistência da matriz de correlações amostral, considere a transformação

$$g(\mathbf{A}) = \mathbf{D}_A^{-1/2} \mathbf{A} \mathbf{D}_A^{-1/2},$$

em que

$$\mathbf{D}_A = \text{diag}(a_{11}, \dots, a_{pp}).$$

A função $g(\mathbf{A}) = \mathbf{D}_A^{-1/2} \mathbf{A} \mathbf{D}_A^{-1/2}$ converte uma matriz de covariâncias em sua matriz de correlações e é contínua em matrizes com diagonal estritamente positiva.

O **teorema do mapeamento contínuo** estabelece que, se uma sequência de estatísticas converge em probabilidade e uma função é contínua no limite, então a sequência obtida pela aplicação dessa função também converge em probabilidade (Vaart, 1998).

Como

$$\mathbf{S} \xrightarrow{P} \Sigma$$

no regime de dimensão fixa e

$$\sigma_{jj} > 0, \quad j = 1, \dots, p,$$

a transformação g é contínua em Σ . Portanto,

$$g(\mathbf{S}) \xrightarrow{P} g(\Sigma).$$

Como

$$g(\mathbf{S}) = \mathbf{R}$$

e

$$g(\Sigma) = \mathcal{R},$$

segue que

$$\mathbf{R} \xrightarrow{P} \mathcal{R}. \quad (10.103)$$

Logo, $\mathbf{R} \xrightarrow{P} \mathcal{R}$ no regime de dimensão fixa, mesmo que $E(\mathbf{R}_{jk}) \neq \rho_{jk}$ em amostras finitas.

10.7.9.4 Transformações de localização e escala

A Equação 8.25 descreve o efeito populacional de transformações de localização e escala. Para uma realização observada, considere

$$y_{ij} = a_j + b_j x_{ij}, \quad b_j \neq 0.$$

A localização a_j desaparece após a centralização. Para duas variáveis transformadas,

$$r_{Y_j Y_k} = \text{sgn}(b_j) \text{sgn}(b_k) r_{X_j X_k}. \quad (10.104)$$

Fatores de escala positivos preservam a correlação. Quando apenas um dos fatores b_j e b_k é negativo, o sinal da correlação é invertido. Mudanças de localização não alteram a correlação.

Em forma matricial, para

$$\mathbf{Y} = \mathbf{X}\mathbf{D}_b + \mathbf{1}_n \mathbf{a}^\top,$$

com

$$\mathbf{D}_b = \text{diag}(b_1, \dots, b_p),$$

defina

$$\mathbf{D}_{\text{sgn}} = \text{diag}[\text{sgn}(b_1), \dots, \text{sgn}(b_p)].$$

Então,

$$\mathbf{R}_Y = \mathbf{D}_{\text{sgn}} \mathbf{R}_X \mathbf{D}_{\text{sgn}}. \quad (10.105)$$

Se todos os fatores de escala são positivos,

$$\mathbf{R}_Y = \mathbf{R}_X.$$

10.7.9.5 Correlações cruzadas entre blocos

Para os blocos $\mathbf{X} \in \mathbb{R}^p$ e $\mathbf{Y} \in \mathbb{R}^q$, defina as matrizes diagonais aleatórias

$$\mathbf{D}_X = \text{diag}(\mathbf{S}_{X_1 X_1}, \dots, \mathbf{S}_{X_p X_p})$$

e

$$\mathbf{D}_Y = \text{diag}(\mathbf{S}_{Y_1 Y_1}, \dots, \mathbf{S}_{Y_q Y_q}).$$

Quando todas as variâncias amostrais envolvidas são positivas, define-se a matriz de correlações cruzadas amostral por

$$\mathbf{R}_{XY} = \mathbf{D}_X^{-1/2} \mathbf{S}_{XY} \mathbf{D}_Y^{-1/2}. \quad (10.106)$$

Seu elemento (j, k) é

$$R_{X_j Y_k} = \frac{S_{X_j Y_k}}{\sqrt{S_{X_j X_j} S_{Y_k Y_k}}}.$$

Após a observação da amostra,

$$\mathbf{R}_{XY} = \mathbf{D}_X^{-1/2} \mathbf{S}_{XY} \mathbf{D}_Y^{-1/2},$$

em que

$$\mathbf{D}_X = \text{diag}(s_{X_1 X_1}, \dots, s_{X_p X_p})$$

e

$$\mathbf{D}_Y = \text{diag}(s_{Y_1 Y_1}, \dots, s_{Y_q Y_q}).$$

Seu elemento observado é

$$r_{X_j Y_k} = \frac{s_{X_j Y_k}}{\sqrt{s_{X_j X_j} s_{Y_k Y_k}}}.$$

Além disso,

$$\mathbf{R}_{YX} = \mathbf{R}_{XY}^\top$$

e, após a observação,

$$\mathbf{R}_{YX} = \mathbf{R}_{XY}^\top.$$

A matriz de correlações do vetor conjunto assume a forma

$$\mathbf{R}_{\text{conj}} = \begin{bmatrix} \mathbf{R}_{XX} & \mathbf{R}_{XY} \\ \mathbf{R}_{YX} & \mathbf{R}_{YY} \end{bmatrix}. \quad (10.107)$$

10.8 Aprofundamento metodológico e aplicado: dimensão, estabilidade e extensões da estimação

A relação entre dimensão e tamanho amostral afeta o posto, a variabilidade e o condicionamento das matrizes estimadas. Em aplicações multivariadas, a estabilidade das estimativas depende conjuntamente de n , de p e da técnica utilizada (Hair et al., 2009). Regularização e estimação robusta modificam os estimadores clássicos para tratar, respectivamente, instabilidade matricial e sensibilidade a observações ou distribuições discrepantes do modelo de referência.

Uma matriz de covariâncias não estruturada de um vetor com p componentes possui

$$\frac{p(p+1)}{2}$$

parâmetros distintos. O número de parâmetros distintos de dispersão cresce, portanto, quadraticamente com p , enquanto a amostra contém n unidades.

Regularização e robustez respondem a problemas diferentes. A regularização procura reduzir a instabilidade associada à dimensão, à redundância, ao tamanho amostral ou ao mau condicionamento. A estimação robusta procura reduzir a sensibilidade do procedimento a determinadas formas de contaminação ou desvios do modelo. As duas abordagens podem ser combinadas, mas tratam de problemas distintos.

10.8.1 Relação entre p e n

O limite de posto estabelecido na Equação 10.66,

$$\text{posto}(\mathbf{S}) \leq \min(p, n-1),$$

permite distinguir diferentes regimes dimensionais.

Dimensão fixa. No regime clássico,

$$p$$

permanece fixo enquanto

$$n \rightarrow \infty.$$

Sob as condições da Proposição 10.9,

$$\mathbf{S} \xrightarrow{P} \Sigma.$$

Como p é fixo, a convergência dos elementos implica convergência em qualquer norma matricial sobre $\mathbb{R}^{p \times p}$, pois todas essas normas são equivalentes em dimensão finita.

Dimensão crescente. Quando

$$p = p_n$$

também aumenta com n , os resultados obtidos para dimensão fixa não podem ser transferidos automaticamente. Um regime de referência amplamente utilizado na teoria multivariada de alta dimensão é

$$\frac{p_n}{n} \longrightarrow c, \quad 0 < c < 1.$$

(Fujikoshi; Ulyanov; Shimizu, 2010)

Nesse regime, a matriz de covariâncias amostral pode possuir posto completo e, ainda assim, apresentar elevada variabilidade em seu espectro.

O controle dos erros elemento a elemento não implica controle do erro em norma espectral. Portanto, erros pequenos nas covariâncias individuais não garantem erros pequenos nos autovalores, autovetores, determinante, inversa ou formas quadráticas que dependem da matriz inversa.

Além disso, o número de covariâncias fora da diagonal é

$$\frac{p(p-1)}{2},$$

e todas são estimadas a partir das mesmas n unidades.

Não existe um valor universal de p/n que separe matrizes estáveis e instáveis. O comportamento depende também da estrutura de Σ , da separação entre seus autovalores, da distribuição populacional e do funcional de interesse, como determinante, inversa, autovetores ou formas quadráticas.

Dimensão maior ou igual ao tamanho amostral. Se

$$p \geq n,$$

Equação 10.66 implica

$$\text{posto}(\mathbf{S}) \leq n - 1 < p.$$

Logo, a matriz de covariâncias amostral é necessariamente singular.

A singularidade de $\mathbf{S}$ quando $p \geq n$ não implica singularidade de Σ ; ela decorre do limite de posto imposto às observações centralizadas.

Posto amostral e posto populacional

Quando

$$p \geq n,$$

$\mathbf{S}$ é singular por construção, mesmo que a matriz populacional satisfaça

$$\Sigma \succ \mathbf{0}.$$

A singularidade da matriz amostral, portanto, não constitui evidência suficiente de singularidade da matriz de covariâncias populacional.

10.8.2 Condicionamento e inversão

Considere uma realização positiva definida,

$$\mathbf{S} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^\top,$$

com

$$\mathbf{\Lambda} = \text{diag}(\ell_1, \dots, \ell_p),$$

e

$$\ell_1 \geq \dots \geq \ell_p > 0.$$

A inversa é

$$\mathbf{S}^{-1} = \mathbf{Q}\mathbf{\Lambda}^{-1}\mathbf{Q}^\top.$$

Autovalores pequenos de $\mathbf{S}$ tornam-se pesos elevados em $\mathbf{S}^{-1}$.

O número de condição espectral foi definido na Definição 6.9. Para uma matriz simétrica positiva definida,

$$\kappa_2(\mathbf{S}) = \frac{\ell_{\max}(\mathbf{S})}{\ell_{\min}(\mathbf{S})}. \quad (10.108)$$

Valores elevados de $\kappa_2(\mathbf{S})$ indicam grande razão entre o maior e o menor autovalor de $\mathbf{S}$.

Para uma sequência de matrizes positivas definidas $\{\mathbf{S}_m\}$, se

$$\ell_{\min}(\mathbf{S}_m) \longrightarrow 0$$

e existe $c > 0$ tal que

$$\ell_{\max}(\mathbf{S}_m) \geq c$$

para todo m , então

$$\kappa_2(\mathbf{S}_m) \longrightarrow \infty.$$

Se $\mathbf{S}$ é singular, o número de condição associado à inversão é infinito. Portanto, invertibilidade e bom condicionamento são propriedades distintas.

Quando $\ell_{\min}(\mathbf{S})$ é pequeno, a inversão atribui peso elevado às direções correspondentes. Pequenas perturbações em $\mathbf{S}$ podem, por isso, produzir alterações maiores em

$$\mathbf{S}^{-1}.$$

O determinante também depende de todo o espectro:

$$\det(\mathbf{S}) = \prod_{j=1}^p \ell_j.$$

A estabilidade dos autovetores depende da separação entre os autovalores. Autovalores próximos podem produzir autovetores individuais sensíveis a pequenas perturbações da matriz.

Considere, por exemplo, a contraparte amostral da forma quadrática utilizada na distância de Mahalanobis definida na Definição 8.8:

$$d_{\mathbf{S}}^2(\mathbf{x}, \bar{\mathbf{x}}) = (\mathbf{x} - \bar{\mathbf{x}})^\top \mathbf{S}^{-1} (\mathbf{x} - \bar{\mathbf{x}}).$$

Nas coordenadas dos autovetores de $\mathbf{S}$,

$$d_{\mathbf{S}}^2(\mathbf{x}, \bar{\mathbf{x}}) = \sum_{j=1}^p \frac{z_j^2}{\ell_j}.$$

Assim, erros na estimação de autovalores pequenos podem ser amplificados pela inversão, pois essas direções recebem pesos proporcionais a $1/\ell_j$.

Inversão computacional

O produto

$$\mathbf{S}^{-1}\mathbf{b}$$

pode ser obtido sem formar explicitamente $\mathbf{S}^{-1}$, resolvendo o sistema

$$\mathbf{S}\mathbf{x} = \mathbf{b}.$$

A resolução do sistema não elimina o mau condicionamento, mas evita a formação explícita da matriz inversa.

10.8.3 Regularização

A regularização substitui $\mathbf{S}$ por um estimador que incorpora restrições ou uma matriz de referência. A regularização pode reduzir o risco segundo uma função de perda especificada, alterar o espectro e produzir uma matriz invertível quando $\mathbf{S}$ é singular.

Uma classe simples combina $\mathbf{S}$ com uma matriz-alvo (Ledoit; Wolf, 2004).

Definição 10.18 (Estimador de covariância por contração). Considere uma matriz-alvo fixada

$$\Gamma \in \mathbb{R}^{p \times p}, \quad \Gamma \succeq \mathbf{0},$$

e um peso

$$0 \leq \lambda \leq 1.$$

Define-se o estimador por contração

$$\widehat{\Sigma}_{\lambda} = (1 - \lambda)\mathbf{S} + \lambda\Gamma. \tag{10.109}$$

Para

$$\lambda = 0,$$

recupera-se $\mathbf{S}$. Para

$$\lambda = 1,$$

o estimador coincide com o alvo.

A contração geralmente introduz viés. Sua avaliação deve considerar conjuntamente viés e variabilidade por meio de uma função de perda e do risco correspondente.

A consistência também depende da forma como a regularização varia com o tamanho amostral. Se $\lambda \in (0, 1]$ e Γ são fixos e

$$\mathbf{S} \xrightarrow{P} \Sigma,$$

então

$$\widehat{\Sigma}_\lambda \xrightarrow{P} (1 - \lambda)\Sigma + \lambda\Gamma.$$

Portanto, com $\lambda > 0$ fixo, o estimador não é, em geral, consistente para Σ . Se a matriz-alvo Γ é fixa e o peso passa a depender de n , com

$$\lambda_n \longrightarrow 0,$$

então

$$\widehat{\Sigma}_{\lambda_n} = (1 - \lambda_n)\mathbf{S} + \lambda_n\Gamma \xrightarrow{P} \Sigma,$$

sempre que

$$\mathbf{S} \xrightarrow{P} \Sigma.$$

Assim, nesse caso, a intensidade da regularização desaparece assintoticamente e a consistência da matriz de covariâncias amostral é preservada.

Em aplicações, o alvo e o peso podem ser estimados a partir dos próprios dados. Nesse caso,

$$\widehat{\Sigma}_{\widehat{\lambda}} = (1 - \widehat{\lambda})\mathbf{S} + \widehat{\lambda}\widehat{\Gamma}. \quad (10.110)$$

A aleatoriedade de $\hat{\lambda}$ e de $\hat{\Gamma}$ passa, então, a fazer parte das propriedades do estimador.

A matriz-alvo precisa ser compatível com as unidades e escalas das variáveis. Um alvo diagonal preserva as escalas marginais e reduz as covariâncias. Um alvo esférico $\tau \mathbf{I}_p$ pressupõe que uma escala comum possua interpretação. Para matrizes de correlações, a identidade $\mathbf{I}_p$ corresponde ao alvo com variâncias unitárias e correlações nulas. O alvo também pode representar relações previamente especificadas entre as variáveis, como covariâncias nulas ou uma estrutura de correlação definida antes da estimação.

A identidade $\mathbf{I}_p$ não é um alvo neutro para uma matriz de covariâncias quando as variáveis são medidas em unidades ou escalas distintas.

Um alvo esférico adaptado à escala observada pode utilizar

$$\hat{\tau} = \frac{1}{p} \text{tr}(\mathbf{S}), \quad (10.111)$$

levando a

$$\hat{\Sigma}_\lambda = (1 - \lambda)\mathbf{S} + \lambda\hat{\tau}\mathbf{I}_p. \quad (10.112)$$

O alvo $\hat{\tau}\mathbf{I}_p$ pressupõe que uma variância média comum tenha significado para as variáveis consideradas. A definitude positiva introduzida pelo componente esférico exige $\hat{\tau} > 0$; como $\mathbf{S} \succeq \mathbf{0}$, essa condição equivale à existência de variabilidade amostral positiva em pelo menos uma direção.

Outro alvo é

$$\hat{\Gamma}_{\text{diag}} = \text{diag}(S_{11}, \dots, S_{pp})$$

com

$$\hat{\Sigma}_{\lambda, \text{diag}} = (1 - \lambda)\mathbf{S} + \lambda\hat{\Gamma}_{\text{diag}}. \quad (10.113)$$

Com o alvo diagonal $\hat{\Gamma}_{\text{diag}}$, as variâncias amostrais permanecem inalteradas e as covariâncias são multiplicadas por $1 - \lambda$.

Proposição 10.15 (Definitude positiva do estimador por contração). *Se*

$$\mathbf{S} \succeq \mathbf{0},$$

$$\Gamma \succ \mathbf{0}$$

e

$$0 < \lambda \leq 1,$$

então

$$\widehat{\Sigma}_\lambda \succ \mathbf{0}. \quad (10.114)$$

i Demonstração

Para qualquer $\mathbf{a} \neq \mathbf{0}$,

$$\mathbf{a}^\top \widehat{\Sigma}_\lambda \mathbf{a} = (1 - \lambda) \mathbf{a}^\top \mathbf{S} \mathbf{a} + \lambda \mathbf{a}^\top \Gamma \mathbf{a}.$$

A primeira parcela é não negativa e a segunda é estritamente positiva. Logo,

$$\mathbf{a}^\top \widehat{\Sigma}_\lambda \mathbf{a} > 0.$$

Com um alvo esférico,

$$\Gamma = \tau \mathbf{I}_p, \quad \tau > 0,$$

e uma decomposição

$$\mathbf{S} = \mathbf{Q} \operatorname{diag} (\mathbf{L}_1, \dots, \mathbf{L}_p) \mathbf{Q}^\top,$$

obtem-se

$$\widehat{\Sigma}_\lambda = \mathbf{Q} \operatorname{diag} [(1 - \lambda) \mathbf{L}_1 + \lambda \tau, \dots, (1 - \lambda) \mathbf{L}_p + \lambda \tau] \mathbf{Q}^\top. \quad (10.115)$$

Portanto,

$$\mathbf{L}_{j,\lambda} = (1 - \lambda) \mathbf{L}_j + \lambda \tau. \quad (10.116)$$

Se

$$\mathbf{L}_j = \mathbf{0}$$

e

$$\lambda > 0,$$

então

$$L_{j,\lambda} = \lambda\tau > 0.$$

A contração esférica desloca os autovalores em direção a τ e afasta de zero os autovalores nulos quando $\lambda > 0$ e $\tau > 0$. A modificação do espectro não implica, por si só, menor erro de estimação; alvo e peso de contração devem ser avaliados segundo a função de perda e o risco considerados.

A Figura 10.2 compara o espectro da covariância amostral com uma versão regularizada.




Figura 10.2: Espectros da matriz de covariâncias amostral e de sua versão regularizada em dois regimes dimensionais.

No regime $p < n$, a regularização desloca os autovalores na direção do alvo. No regime $p \geq n$, os autovalores nulos decorrentes do limite de posto são substituídos por valores positivos.

A Figura 10.2 ilustra apenas a transformação espectral produzida pela contração. A seleção de λ e da matriz-alvo exige um critério estatístico específico e não decorre da transformação algébrica dos autovalores.

10.8.4 Pseudoinversa e regularização

A pseudoinversa de Moore–Penrose foi definida na Definição 6.10. Para uma matriz de covariâncias amostral com decomposição espectral reduzida

$$\mathbf{S} = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top,$$

em que Λ_r contém os r autovalores positivos, tem-se

$$\mathbf{S}^+ = \mathbf{Q}_r \Lambda_r^{-1} \mathbf{Q}_r^\top. \quad (10.117)$$

A pseudoinversa e a regularização modificam o tratamento das direções espectrais por mecanismos diferentes. Considere

$$\mathbf{S} = \mathbf{Q} \operatorname{diag}(\ell_1, \dots, \ell_p) \mathbf{Q}^\top,$$

com

$$\ell_j \geq 0.$$

A pseudoinversa atribui os pesos

$$\begin{cases} 1/\ell_j, & \ell_j > 0, \\ 0, & \ell_j = 0. \end{cases}$$

Considere agora

$$\mathbf{S}_\lambda = (1 - \lambda)\mathbf{S} + \lambda\tau\mathbf{I}_p,$$

com

$$0 < \lambda \leq 1 \quad \text{e} \quad \tau > 0.$$

Sua inversa é

$$\mathbf{S}_\lambda^{-1} = \mathbf{Q} \operatorname{diag} \left[\frac{1}{(1-\lambda)\ell_j + \lambda\tau} \right] \mathbf{Q}^\top. \quad (10.118)$$

Se

$$\ell_j = 0,$$

a pseudoinversa atribui peso zero, enquanto a inversa regularizada atribui

$$\frac{1}{\lambda\tau}.$$

A pseudoinversa não modifica $\mathbf{S}$; ela substitui a inversão usual por sua extensão de Moore–Penrose. Os autovalores positivos continuam recebendo pesos $1/\ell_j$, mesmo quando são muito pequenos, enquanto as direções associadas a autovalores nulos recebem peso zero.

A regularização modifica a matriz utilizada para estimar Σ . Na contração esférica, os autovalores são deslocados em direção a τ , e a inversão utiliza os recíprocos dos autovalores regularizados. A pseudoinversa mantém a matriz original e altera a operação de inversão; a regularização altera o estimador antes da inversão.

Invertibilidade não implica validade inferencial

Substituir $\mathbf{S}^{-1}$ por $\mathbf{S}^+$ ou por uma inversa regularizada modifica a estatística utilizada. Distribuições amostrais e calibrações inferenciais derivadas para a inversa clássica não podem ser transferidas automaticamente para essas substituições.

10.8.5 Sensibilidade e robustez

O vetor de médias e a matriz de covariâncias amostrais têm sensibilidade não limitada à substituição de uma observação quando o valor contaminante pode assumir magnitude arbitrariamente grande (Maronna et al., 2019).

Considere a substituição de uma observação $\mathbf{x}_k$ por $\mathbf{x}_k^*$. A nova média é

$$\bar{\mathbf{x}}^* = \bar{\mathbf{x}} + \frac{1}{n} (\mathbf{x}_k^* - \mathbf{x}_k). \quad (10.119)$$

Portanto,

$$\bar{\mathbf{x}}^* - \bar{\mathbf{x}} = \frac{1}{n} (\mathbf{x}_k^* - \mathbf{x}_k).$$

A diferença $\bar{\mathbf{x}}^* - \bar{\mathbf{x}}$ não possui limite uniforme quando $\|\mathbf{x}_k^*\|$ pode crescer sem limite. Portanto, a substituição de uma única observação pode produzir uma alteração arbitrariamente grande na média amostral.

Na matriz de covariâncias, os produtos externos

$$(\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top$$

crescem quadraticamente com a magnitude dos desvios em relação à média e, por isso, observações extremas podem alterar simultaneamente variâncias, covariâncias e a estrutura espectral da matriz estimada.

Uma observação extrema pode corresponder a uma unidade válida da população de referência, a uma unidade proveniente de outra população ou a um erro de registro ou medição. Valores extremos também podem indicar caudas pesadas, assimetria ou heterogeneidade não representadas pelo modelo adotado.

A decisão de manter, corrigir ou excluir uma observação deve considerar o processo de coleta, a possibilidade de erro de registro ou medição e a compatibilidade da unidade com a população definida para a análise.

Estimadores robustos de localização e dispersão limitam a sensibilidade a formas especificadas de contaminação ou afastamento do modelo de referência. A comparação entre procedimentos pode considerar sensibilidade à contaminação, eficiência sob o modelo de referência, equivalência, condições de existência em função de n e p , custo computacional e o parâmetro que cada procedimento estima. Esses critérios podem favorecer estimadores diferentes.

Observações extremas, alta dimensão e má especificação correspondem a problemas distintos. Observações extremas podem alterar estimadores sensíveis; a alta dimensão afeta o número de parâmetros, o posto e a estabilidade das matrizes estimadas; e a má especificação ocorre quando a distribuição ou a estrutura assumida pelo modelo não representa adequadamente o processo gerador dos dados. A ocorrência simultânea desses problemas não implica que possam ser tratados pelo mesmo procedimento.

A avaliação de uma matriz de covariâncias estimada depende do funcional ou procedimento que utilizará essa matriz. Tamanho amostral e dimensão determinam restrições de posto; o espectro caracteriza direções de variabilidade e condicionamento; as escalas das variáveis afetam a interpretação e a escolha de alvos de regularização; e a sensibilidade deve ser examinada quando observações extremas ou desvios do modelo podem modificar as estimativas.

10.9 Exemplo integrado

A amostra do exemplo permite calcular estimativas de localização, dispersão e associação entre dois blocos de variáveis, além do diagnóstico de condicionamento da matriz de covariâncias.

Os valores numéricos correspondem às realizações observadas das estatísticas definidas no capítulo.

Exemplo 10.1 (Estimação em dois blocos de variáveis). Considere seis unidades amostrais nas quais foram observados dois blocos de variáveis. O primeiro bloco contém três variáveis:

$$\mathbf{X} = \begin{bmatrix} 2 & 4 & 2 \\ 3 & 5 & 3 \\ 3 & 6 & 3 \\ 5 & 7 & 4 \\ 5 & 6 & 6 \\ 6 & 8 & 6 \end{bmatrix} \in \mathbb{R}^{6 \times 3}.$$

O segundo bloco contém duas variáveis observadas nas mesmas unidades:

$$\mathbf{Y} = \begin{bmatrix} 1 & 3 \\ 3 & 2 \\ 4 & 5 \\ 5 & 7 \\ 3 & 4 \\ 8 & 9 \end{bmatrix} \in \mathbb{R}^{6 \times 2}.$$

A linha i de $\mathbf{X}$ e a linha i de $\mathbf{Y}$ correspondem à mesma unidade amostral; esse pareamento determina os produtos cruzados utilizados em $\mathbf{T}_{XY}$.

Os vetores de médias observados são

$$\bar{\mathbf{x}} = \frac{1}{6} \mathbf{X}^\top \mathbf{1}_6 = \begin{bmatrix} 4 \\ 6 \\ 4 \end{bmatrix}$$

e

$$\bar{\mathbf{y}} = \frac{1}{6} \mathbf{Y}^\top \mathbf{1}_6 = \begin{bmatrix} 4 \\ 5 \end{bmatrix}.$$

As matrizes centralizadas são, portanto,

$$\mathbf{X}_c = \begin{bmatrix} -2 & -2 & -2 \\ -1 & -1 & -1 \\ -1 & 0 & -1 \\ 1 & 1 & 0 \\ 1 & 0 & 2 \\ 2 & 2 & 2 \end{bmatrix}$$

e

$$\mathbf{Y}_c = \begin{bmatrix} -3 & -2 \\ -1 & -3 \\ 0 & 0 \\ 1 & 2 \\ -1 & -1 \\ 4 & 4 \end{bmatrix}.$$

Em ambas as matrizes centralizadas,

$$\mathbf{1}_6^\top \mathbf{X}_c = \mathbf{0}^\top \quad \text{e} \quad \mathbf{1}_6^\top \mathbf{Y}_c = \mathbf{0}^\top.$$

Para o primeiro bloco, a matriz SQPC observada é

$$\mathbf{T}_X = \mathbf{X}_c^\top \mathbf{X}_c.$$

Os elementos da diagonal são somas de quadrados. Por exemplo,

$$t_{11} = (-2)^2 + (-1)^2 + (-1)^2 + 1^2 + 1^2 + 2^2 = 12.$$

Os elementos fora da diagonal são somas de produtos cruzados. Por exemplo,

$$\begin{aligned} t_{12} &= (-2)(-2) + (-1)(-1) + (-1)(0) + (1)(1) + (1)(0) + (2)(2) \\ &= 10. \end{aligned}$$

Calculando os demais elementos da mesma forma,

$$\mathbf{T}_X = \begin{bmatrix} 12 & 10 & 12 \\ 10 & 10 & 9 \\ 12 & 9 & 14 \end{bmatrix}. \tag{10.120}$$

A simetria decorre de $t_{jk} = t_{kj}$, de modo que somente a diagonal e uma das partes triangulares precisam ser calculadas diretamente.

A matriz de covariâncias amostral utiliza o divisor

$$n - 1 = 5.$$

Logo,

$$\begin{aligned} \mathbf{S}_X &= \frac{1}{5} \mathbf{T}_X \\ &= \begin{bmatrix} 2,4 & 2,0 & 2,4 \\ 2,0 & 2,0 & 1,8 \\ 2,4 & 1,8 & 2,8 \end{bmatrix}. \end{aligned} \quad (10.121)$$

A matriz $\mathbf{S}_X$ é a realização observada do estimador não viesado $\mathbf{S}_X$ de Σ_{XX} , cujo não viesamento foi estabelecido na Equação 10.54.

Para os dados observados,

$$\text{posto}(\mathbf{T}_X) = 3.$$

Sob o modelo normal multivariado da Definição 9.1, a condição de posto completo da Proposição 10.1 é satisfeita. A estimativa de máxima verossimilhança da matriz de covariâncias é

$$\begin{aligned} \widehat{\Sigma}_{XX, \text{MV, obs}} &= \frac{1}{6} \mathbf{T}_X \\ &= \begin{bmatrix} 2 & 5/3 & 2 \\ 5/3 & 5/3 & 3/2 \\ 2 & 3/2 & 7/3 \end{bmatrix}. \end{aligned} \quad (10.122)$$

As duas matrizes estão relacionadas por

$$\widehat{\Sigma}_{XX, \text{MV, obs}} = \frac{5}{6} \mathbf{S}_X.$$

Como diferem apenas pelo fator escalar positivo $5/6$, possuem os mesmos autovetores e o mesmo posto. Seus autovalores diferem pelo fator $5/6$, enquanto o número de condição espectral permanece inalterado.

Os cálculos subsequentes utilizam os valores exatos sempre que disponíveis, com arredondamento apenas na apresentação final. Como o fator comum da matriz de covariâncias se cancela na padronização, as correlações podem ser calculadas diretamente por

$$r_{jk} = \frac{t_{jk}}{\sqrt{t_{jj}t_{kk}}},$$

pois o divisor comum de $\mathbf{S}_X$ se cancela. Autovalores e números de condição apresentados em forma decimal devem ser calculados com os valores não arredondados e arredondados apenas ao final.

A matriz de correlações observada é

$$\mathbf{R}_X \approx \begin{bmatrix} 1,000 & 0,913 & 0,926 \\ 0,913 & 1,000 & 0,761 \\ 0,926 & 0,761 & 1,000 \end{bmatrix}. \quad (10.123)$$

As três correlações são positivas. A maior ocorre entre X_1 e X_3 ,

$$r_{13} \approx 0,926,$$

e a menor entre X_2 e X_3 ,

$$r_{23} \approx 0,761.$$

Os autovalores de $\mathbf{S}_X$, em ordem decrescente, são aproximadamente

$$\ell_1 \approx 6,579, \quad \ell_2 \approx 0,560 \quad \text{e} \quad \ell_3 \approx 0,061.$$

Como todos são positivos,

$$\text{posto}(\mathbf{S}_X) = 3,$$

e

$$\mathbf{S}_X \succ \mathbf{0}.$$

Seu número de condição espectral é aproximadamente

$$\kappa_2(\mathbf{S}_X) = \frac{\ell_1}{\ell_3} \approx 108,3.$$

O cálculo com os autovalores não arredondados fornece $\kappa_2(\mathbf{S}_X) \approx 108,3$. Portanto, $\mathbf{S}_X$ é invertível, mas apresenta grande razão entre seus autovalores extremos. Invertibilidade e condicionamento são propriedades distintas.

Para estimar as relações entre os dois blocos, utiliza-se

$$\mathbf{T}_{XY} = \mathbf{X}_c^\top \mathbf{Y}_c.$$

Por exemplo, o elemento correspondente a X_1 e Y_1 é

$$\begin{aligned} t_{X_1Y_1} &= (-2)(-3) + (-1)(-1) + (-1)(0) + (1)(1) + (1)(-1) + (2)(4) \\ &= 15. \end{aligned}$$

Os demais produtos cruzados fornecem

$$\mathbf{T}_{XY} = \begin{bmatrix} 15 & 16 \\ 16 & 17 \\ 13 & 13 \end{bmatrix}. \quad (10.124)$$

Logo, pela definição de covariância cruzada observada na Definição 8.12,

$$\mathbf{S}_{XY} = \frac{1}{5} \mathbf{T}_{XY} = \begin{bmatrix} 3,0 & 3,2 \\ 3,2 & 3,4 \\ 2,6 & 2,6 \end{bmatrix}. \quad (10.125)$$

Por exemplo,

$$s_{X_3Y_1} = 2,6$$

é a covariância amostral entre X_3 e Y_1 .

A inversão da ordem dos blocos segue Equação 8.70:

$$\mathbf{S}_{YX} = \mathbf{S}_{XY}^\top = \begin{bmatrix} 3,0 & 3,2 & 2,6 \\ 3,2 & 3,4 & 2,6 \end{bmatrix}.$$

Para o segundo bloco,

$$\mathbf{T}_Y = \mathbf{Y}_c^\top \mathbf{Y}_c = \begin{bmatrix} 28 & 28 \\ 28 & 34 \end{bmatrix},$$

de modo que

$$\mathbf{S}_Y = \frac{1}{5} \mathbf{T}_Y = \begin{bmatrix} 5,6 & 5,6 \\ 5,6 & 6,8 \end{bmatrix}.$$

Reunindo as cinco variáveis,

$$\mathbf{X}_{\text{conj}} = [\mathbf{X} \quad \mathbf{Y}] \in \mathbb{R}^{6 \times 5},$$

a matriz SQPC conjunta possui a forma em blocos

$$\mathbf{T}_{\text{conj}} = \begin{bmatrix} \mathbf{T}_X & \mathbf{T}_{XY} \\ \mathbf{T}_{YX} & \mathbf{T}_Y \end{bmatrix}.$$

Numericamente,

$$\mathbf{T}_{\text{conj}} = \begin{bmatrix} 12 & 10 & 12 & 15 & 16 \\ 10 & 10 & 9 & 16 & 17 \\ 12 & 9 & 14 & 13 & 13 \\ 15 & 16 & 13 & 28 & 28 \\ 16 & 17 & 13 & 28 & 34 \end{bmatrix}.$$

Como $n - 1 = 5$,

$$\mathbf{S}_{\text{conj}} = \frac{1}{5} \mathbf{T}_{\text{conj}} = \begin{bmatrix} 2,4 & 2,0 & 2,4 & 3,0 & 3,2 \\ 2,0 & 2,0 & 1,8 & 3,2 & 3,4 \\ 2,4 & 1,8 & 2,8 & 2,6 & 2,6 \\ 3,0 & 3,2 & 2,6 & 5,6 & 5,6 \\ 3,2 & 3,4 & 2,6 & 5,6 & 6,8 \end{bmatrix}. \quad (10.126)$$

Os blocos diagonais de $\mathbf{S}_{\text{conj}}$ são $\mathbf{S}_X$ e $\mathbf{S}_Y$, enquanto os blocos fora da diagonal são $\mathbf{S}_{XY}$ e $\mathbf{S}_{YX}$.

Como existem seis observações e cinco variáveis,

$$\text{posto}(\mathbf{S}_{\text{conj}}) \leq 5.$$

A matriz conjunta centralizada é

$$\mathbf{X}_{\text{conj},c} = \begin{bmatrix} -2 & -2 & -2 & -3 & -2 \\ -1 & -1 & -1 & -1 & -3 \\ -1 & 0 & -1 & 0 & 0 \\ 1 & 1 & 0 & 1 & 2 \\ 1 & 0 & 2 & -1 & -1 \\ 2 & 2 & 2 & 4 & 4 \end{bmatrix}.$$

Seu escalonamento fornece cinco pivôs, de modo que

$$\text{posto}(\mathbf{X}_{\text{conj},c}) = 5.$$

Como

$$\mathbf{T}_{\text{conj}} = \mathbf{X}_{\text{conj},c}^{\top} \mathbf{X}_{\text{conj},c},$$

segue de Equação 8.57 que

$$\text{posto}(\mathbf{S}_{\text{conj}}) = 5.$$

Portanto,

$$\mathbf{S}_{\text{conj}} \succ \mathbf{0}.$$

Como $n = 6$ e $p = 5$, verifica-se $n = p + 1$, condição necessária para que $\mathbf{S}_{\text{conj}}$ possa ter posto completo. O posto completo depende adicionalmente da independência linear das colunas centralizadas.

Os vetores $\bar{\mathbf{x}}$ e $\bar{\mathbf{y}}$ são estimativas das médias populacionais, e $\mathbf{T}_X$ é a realização observada da estatística SQPC. A matriz $\mathbf{S}_X = \mathbf{T}_X/(n - 1)$ é a estimativa associada ao estimador não viesado de Σ_{XX} , enquanto $\mathbf{T}_X/n$ é a estimativa pelo método dos momentos e, sob normalidade e existência do máximo, também pela máxima verossimilhança.

A matriz $\mathbf{R}_X$ resulta da padronização de $\mathbf{S}_X$ pelas variâncias marginais. O posto completo garante a invertibilidade de $\mathbf{S}_X$, enquanto $\kappa_2(\mathbf{S}_X) \approx 108,3$ indica que a existência da inversa não implica bom condicionamento.

O pareamento das linhas de $\mathbf{X}$ e $\mathbf{Y}$ determina os produtos cruzados em $\mathbf{T}_{XY}$ e, consequentemente, as covariâncias em $\mathbf{S}_{XY}$. A matriz conjunta reúne em um único objeto as covariâncias internas dos dois blocos e as covariâncias entre eles.

As matrizes e os vetores numéricos calculados no exemplo são realizações observadas. Não viesamento, consistência e eficiência referem-se aos estimadores como funções da amostra aleatória e, portanto, ao seu comportamento sob amostras repetidas do modelo.

10.10 Síntese do capítulo

A estimação amostral distingue parâmetro populacional, estatística, estimador e estimativa observada. O parâmetro θ é uma característica fixa da distribuição populacional. Uma amostra aleatória $\mathcal{X}$ produz estatísticas por meio de funções dos dados,

$$\mathbf{G} = G(\mathcal{X}).$$

Quando uma estatística é utilizada para estimar θ , ela constitui um estimador,

$$\hat{\theta} = G(\mathcal{X}).$$

Após a observação da amostra, a realização

$$\hat{\theta}_{\text{obs}} = G(\mathbf{X})$$

é a estimativa do parâmetro. Portanto, todo estimador é uma estatística, mas nem toda estatística é utilizada como estimador.

Para uma amostra multivariada i.i.d., o vetor de médias amostrais estima μ , enquanto a matriz de covariâncias amostral estima Σ :

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i$$

e

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T},$$

em que $\mathbf{T}$ é a matriz SQPC amostral definida na Definição 10.9.

Método dos momentos e máxima verossimilhança são princípios de construção de estimadores e não determinam, isoladamente, não viesamento ou consistência. Para os parâmetros de primeira e segunda ordem considerados aqui, o método dos momentos fornece

$$\hat{\mu}_{\text{MM}} = \bar{\mathbf{X}}$$

e

$$\hat{\Sigma}_{\text{MM}} = \frac{1}{n} \mathbf{T}.$$

Sob o modelo normal multivariado e quando o máximo existe, a máxima verossimilhança conduz às mesmas estatísticas.

O estimador $\mathbf{T}/n$ é viesado em amostras finitas, enquanto

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}$$

é não viesado. Ambos são consistentes para Σ no regime de dimensão fixa sob as condições especificadas.

Os resultados na Proposição 10.3 e Equação 10.54 fornecem

$$E(\bar{\mathbf{X}}) = \mu, \quad \text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}, \quad E(\mathbf{S}) = \Sigma.$$

No regime de dimensão fixa, Proposição 10.4 e Proposição 10.9 estabelecem

$$\bar{\mathbf{X}} \xrightarrow{P} \mu \quad \text{e} \quad \mathbf{S} \xrightarrow{P} \Sigma.$$

Para variáveis organizadas em dois blocos pareados,

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{T}_{XY}$$

estima a matriz de covariâncias cruzadas. Quando as variâncias amostrais são positivas, a matriz de correlações amostral é

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}.$$

A Tabela 10.2 resume as relações entre parâmetros, estimadores e realizações observadas.

Tabela 10.2: Relação entre parâmetros, estatísticas, estimadores e valores observados utilizados no capítulo.

Parâmetro ou objeto	Estatística/estima- dor	Propriedade destacada	Valor observado
μ	$\bar{\mathbf{X}}$	Não viesado e consistente; MM; MV sob normalidade e existência do máximo	$\bar{\mathbf{x}}$

Parâmetro ou objeto	Estatística/estimador	Propriedade destacada	Valor observado
Σ	$\mathbf{S} = \mathbf{T}/(n-1)$	Não viesado e consistente	$\mathbf{S}$
Σ	$\mathbf{T}/n$	MM; MV sob normalidade e existência do máximo; viesado em amostras finitas e consistente	$\mathbf{T}/n$
SQPC amostral	$\mathbf{T}$	Estatística que reúne somas de quadrados e produtos cruzados	$\mathbf{T}$
Σ_{XY}	$\mathbf{S}_{XY}$	Covariância cruzada amostral	$\mathbf{S}_{XY}$
$\mathcal{R}$	$\mathbf{R}$	Padronização da matriz de covariâncias amostral, quando as variâncias amostrais são positivas	$\mathbf{R}$

Viés e variabilidade caracterizam o comportamento do estimador para tamanho amostral fixo, enquanto a consistência descreve seu comportamento quando n aumenta.

A estrutura de posto

$$\text{posto}(\mathbf{S}) \leq \min(p, n-1)$$

implica que a dimensão e o tamanho amostral restringem o posto da matriz estimada. Em particular, quando $p \geq n$, a matriz de covariâncias amostral é necessariamente singular.

Os resultados centrais do capítulo sustentam as seguintes competências:

- distinguir população, amostra aleatória e amostra observada, bem como parâmetro, estatística, estimador, estimativa e distribuição amostral;
- avaliar viés, variabilidade e consistência na extensão necessária aos estimadores estudados;
- distinguir os princípios do método dos momentos e da máxima verossimilhança;
- construir o vetor de médias amostrais, a matriz SQPC e os estimadores da matriz de covariâncias;
- explicar a origem e a função dos divisores n e $n-1$;

- construir a matriz de covariâncias cruzadas amostral e a matriz de correlações amostral;
- identificar as restrições básicas de posto e singularidade das matrizes amostrais.

O aprofundamento teórico amplia a comparação entre estimadores por meio de funções de perda, erro quadrático médio, eficiência, suficiência, equivariância, propriedades gerais dos métodos de estimação e invariância da máxima verossimilhança.

O aprofundamento metodológico e aplicado trata da relação entre dimensão e tamanho amostral, condicionamento, resolução de sistemas, pseudoinversa, regularização, contração, estabilidade e robustez.

No Capítulo 11, várias variáveis-resposta são relacionadas simultaneamente a uma matriz de delineamento. A formulação utiliza a matriz de covariâncias populacional de Definição 8.2, o modelo normal multivariado de Definição 9.1 e os estimadores definidos neste capítulo para obter a matriz de parâmetros, os valores ajustados, os resíduos e as matrizes SQPC associadas às fontes de variação.

A Capítulo 12 estabelece as distribuições da média amostral e da matriz de covariâncias sob normalidade e utiliza esses resultados na construção dos procedimentos de inferência multivariada.

11 Modelo Linear Multivariado e Hipóteses Lineares

O Capítulo 10 desenvolveu a estimação do vetor de médias e da matriz de covariâncias a partir de uma amostra aleatória multivariada. O vetor de médias amostrais e suas propriedades foram estabelecidos em Proposição 10.3, enquanto a matriz de covariâncias amostral foi definida em Definição 10.10 e seu não viesamento foi estabelecido em Proposição 10.8. Nesse contexto, todas as unidades compartilhavam o mesmo vetor de médias populacional.

O modelo linear multivariado substitui essa média comum por uma estrutura de médias que pode variar entre as unidades segundo características conhecidas. Essa formulação permite representar, em um mesmo modelo, regressões com várias respostas, comparações entre grupos e estruturas de médias determinadas por fatores e covariáveis.

A formulação do modelo conduz à estimação de $\mathbf{B}$, aos valores ajustados e resíduos, à SQPC residual, à estimação da matriz de covariâncias dos erros, à decomposição da dispersão observada e às hipóteses lineares sobre funções dos parâmetros e combinações das respostas (Johnson; Wichern, 2002).

No modelo de grupos, a decomposição da dispersão em uma parcela residual e uma parcela associada ao modelo recupera as matrizes de dispersão intragrupos e entre grupos definidas em Definição 8.13 e Definição 8.14.

Testes e regiões de confiança exigem, adicionalmente, as distribuições amostrais dos estimadores e das matrizes SQPC.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{Y}_i \in \mathbb{R}^p$ representa o vetor aleatório de respostas da unidade i ;
- $\mathbf{y}_i \in \mathbb{R}^p$ representa uma realização desse vetor;
- $\mathbf{Y} \in \mathbb{R}^{n \times p}$ representa a matriz aleatória de respostas;
- $\mathbf{Y} \in \mathbb{R}^{n \times p}$ representa a matriz observada de respostas;
- $\mathbf{Z} \in \mathbb{R}^{n \times q}$ representa a matriz de delineamento;
- $\mathbf{z}_i^\top$ representa a linha i de $\mathbf{Z}$;
- $\mathbf{B} \in \mathbb{R}^{q \times p}$ representa a matriz de parâmetros;
- $\varepsilon_i \in \mathbb{R}^p$ representa o vetor aleatório de erros da unidade i ;
- $\mathcal{E} \in \mathbb{R}^{n \times p}$ representa a matriz aleatória de erros;

- $\Sigma \in \mathbb{R}^{p \times p}$ representa a matriz de covariâncias dos erros entre as respostas de uma mesma unidade, isto é, a matriz de covariâncias residual populacional;
- $\widehat{\mathbf{B}}$ representa o estimador de mínimos quadrados de $\mathbf{B}$ quando $\mathbf{Z}$ possui posto coluna completo e, no caso de posto deficiente, a solução de mínimos quadrados especificada;
- $\widehat{\mathbf{U}}$ representará a matriz aleatória de resíduos e $\widehat{\mathbf{U}}$ sua realização observada;
- $\mathbf{E}_{\text{res}}$ representará a SQPC residual como estatística aleatória e $\mathbf{E}$ sua realização observada;
- $\mathbf{T}$ continuará representando a SQPC total observada;
- $\mathbf{T}_{\text{mod}}$, quando $\mathbf{1}_n \in \mathcal{C}(\mathbf{Z})$, representará a dispersão dos valores ajustados pelo modelo em torno da média geral;
- $\mathbf{H}$ ficará reservada à SQPC associada a uma hipótese linear estimável.

A letra $\mathbf{Z}$ é utilizada para o delineamento para preservar $\mathbf{X}$ como símbolo da matriz de dados nos capítulos anteriores.

11.1 Formulação do modelo linear multivariado

11.1.1 Resposta vetorial e matriz de respostas

No modelo linear univariado, cada unidade fornece uma única resposta. No caso multivariado, a unidade i fornece simultaneamente

$$\mathbf{Y}_i = \begin{bmatrix} Y_{i1} \\ Y_{i2} \\ \vdots \\ Y_{ip} \end{bmatrix} \in \mathbb{R}^p. \quad (11.1)$$

As componentes podem apresentar dependência. O modelo deve, portanto, representar simultaneamente:

1. a estrutura das médias das p respostas;
2. a variabilidade de cada resposta;
3. as covariâncias entre respostas observadas na mesma unidade.

Considere

$$\mathbf{z}_i = \begin{bmatrix} z_{i1} \\ \vdots \\ z_{iq} \end{bmatrix} \in \mathbb{R}^q,$$

contendo os valores das q colunas do delineamento para a unidade i .

Cada coluna pode representar, por exemplo, o intercepto, um indicador de grupo ou tratamento, uma covariável quantitativa ou outra função conhecida utilizada na especificação da estrutura de médias. A matriz de delineamento reúne essas informações para todas as unidades.

A matriz de parâmetros é

$$\mathbf{B} = \begin{bmatrix} \beta_{11} & \beta_{12} & \cdots & \beta_{1p} \\ \beta_{21} & \beta_{22} & \cdots & \beta_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \beta_{q1} & \beta_{q2} & \cdots & \beta_{qp} \end{bmatrix} \in \mathbb{R}^{q \times p}. \quad (11.2)$$

A coluna j de $\mathbf{B}$ contém os coeficientes do modelo para a resposta j . A linha h reúne, para as p respostas, os coeficientes associados à coluna h da matriz de delineamento.

Assim, uma mesma coluna do delineamento pode possuir coeficientes diferentes nas diferentes respostas, embora todas utilizem a mesma matriz $\mathbf{Z}$.

A média condicional do vetor de respostas da unidade i é

$$E(\mathbf{Y}_i \mid \mathbf{Z}) = \mathbf{B}^\top \mathbf{z}_i. \quad (11.3)$$

Equivalentemente, em forma de vetor linha,

$$E(\mathbf{Y}_i^\top \mid \mathbf{Z}) = \mathbf{z}_i^\top \mathbf{B}.$$

Definição 11.1 (Modelo linear multivariado para uma unidade). O vetor de respostas da unidade i é representado por

$$\mathbf{Y}_i = \mathbf{B}^\top \mathbf{z}_i + \varepsilon_i, \quad (11.4)$$

em que

$$\mathbf{Y}_i, \varepsilon_i \in \mathbb{R}^p, \quad \mathbf{z}_i \in \mathbb{R}^q, \quad \mathbf{B} \in \mathbb{R}^{q \times p}.$$

Componente a componente,

$$Y_{ij} = \mathbf{z}_i^\top \beta_j + \varepsilon_{ij}, \quad j = 1, \dots, p, \quad (11.5)$$

em que β_j é a coluna j de $\mathbf{B}$.

As equações das diferentes respostas compartilham a mesma matriz de delineamento. O caráter multivariado do modelo decorre da análise conjunta dessas respostas e da estrutura de covariâncias dos respectivos erros.

Para reunir as n unidades, defina a matriz aleatória

Definição 11.2 (Matriz aleatória de respostas).

$$\mathbf{y} = \begin{bmatrix} \mathbf{Y}_1^\top \\ \mathbf{Y}_2^\top \\ \vdots \\ \mathbf{Y}_n^\top \end{bmatrix} = \begin{bmatrix} Y_{11} & \dots & Y_{1p} \\ Y_{21} & \dots & Y_{2p} \\ \vdots & \ddots & \vdots \\ Y_{n1} & \dots & Y_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (11.6)$$

Após a observação,

$$\mathbf{Y} = \begin{bmatrix} \mathbf{y}_1^\top \\ \vdots \\ \mathbf{y}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (11.7)$$

A matriz de delineamento é

$$\mathbf{Z} = \begin{bmatrix} \mathbf{z}_1^\top \\ \mathbf{z}_2^\top \\ \vdots \\ \mathbf{z}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times q}. \quad (11.8)$$

Neste capítulo, o modelo e os resultados de estimação são formulados condicionalmente a $\mathbf{Z}$. Assim, a matriz de delineamento é tratada como conhecida. Essa convenção abrange tanto delineamentos fixados previamente quanto análises condicionais aos valores observados das variáveis explicativas.

11.1.2 Estrutura matricial do modelo

Organize os vetores de erros nas linhas de

$$\mathcal{E} = \begin{bmatrix} \varepsilon_1^\top \\ \vdots \\ \varepsilon_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (11.9)$$

Definição 11.3 (Modelo linear multivariado). O modelo linear multivariado é

$$\mathcal{Y} = \mathbf{Z}\mathbf{B} + \mathcal{E}. \quad (11.10)$$

em que:

- $\mathcal{Y} \in \mathbb{R}^{n \times p}$ é a matriz aleatória de respostas;
- $\mathbf{Z} \in \mathbb{R}^{n \times q}$ é a matriz de delineamento;
- $\mathbf{B} \in \mathbb{R}^{q \times p}$ é a matriz de parâmetros;
- $\mathcal{E} \in \mathbb{R}^{n \times p}$ é a matriz aleatória de erros.

A matriz de médias condicionais é

$$E(\mathcal{Y} \mid \mathbf{Z}) = \mathbf{Z}\mathbf{B}. \quad (11.11)$$

Cada coluna da matriz de médias condicionais

$$\mathbf{Z}\mathbf{B}$$

pertence ao espaço coluna de $\mathbf{Z}$ e é, portanto, uma combinação linear das colunas do delineamento.

Se

$$r = \text{posto}(\mathbf{Z}), \quad (11.12)$$

então

$$r \leq \min(n, q).$$

O valor r é a dimensão do espaço coluna $\mathcal{C}(\mathbf{Z})$, equivalentemente, o número máximo de colunas linearmente independentes de $\mathbf{Z}$. Para cada resposta, o vetor de médias pertence a esse subespaço de dimensão r .

Quando

$$r = q,$$

a matriz de delineamento possui posto coluna completo. Se $r < q$, a matriz $\mathbf{Z}$ possui posto coluna deficiente e a parametrização por $\mathbf{B}$ pode deixar de ser identificável.

11.1.3 Estrutura de médias e covariâncias residuais

No modelo aditivo de Equação 11.4, a estrutura de médias especificada em Equação 11.3 equivale à centralização condicional dos erros.

Definição 11.4 (Média nula dos erros).

$$E(\varepsilon_i \mid \mathbf{Z}) = \mathbf{0}, \quad i = 1, \dots, n. \quad (11.13)$$

De fato,

$$E(\mathbf{Y}_i \mid \mathbf{Z}) = \mathbf{B}^\top \mathbf{z}_i.$$

A dependência entre as respostas de uma mesma unidade e entre unidades distintas é especificada pela estrutura de covariâncias dos erros.

Definição 11.5 (Estrutura de covariâncias dos erros). Para cada unidade,

$$\varepsilon_i \in \mathbb{R}^p, \quad i = 1, \dots, n,$$

e assume-se que os segundos momentos condicionais existem.

A matriz de covariâncias condicional é comum às unidades:

$$\text{Cov}(\varepsilon_i \mid \mathbf{Z}) = \Sigma, \quad i = 1, \dots, n, \quad (11.14)$$

em que

$$\Sigma \in \mathbb{R}^{p \times p}, \quad \Sigma = \Sigma^\top, \quad \Sigma \succeq \mathbf{0}.$$

Além disso,

$$\text{Cov}(\varepsilon_i, \varepsilon_\ell \mid \mathbf{Z}) = \mathbf{0}_{p \times p}, \quad i \neq \ell. \quad (11.15)$$

A matriz

$$\Sigma = \begin{bmatrix} \sigma_{11} & \cdots & \sigma_{1p} \\ \vdots & \ddots & \vdots \\ \sigma_{p1} & \cdots & \sigma_{pp} \end{bmatrix}$$

é a matriz de covariâncias residuais entre as p respostas.

Assim,

$$\text{Var}(Y_{ij} | \mathbf{Z}) = \sigma_{jj},$$

e, para duas respostas da mesma unidade,

$$\text{Cov}(Y_{ij}, Y_{ik} | \mathbf{Z}) = \sigma_{jk}.$$

A expressão “covariância residual” indica a variabilidade que permanece após a estrutura de médias $\mathbf{ZB}$ ter sido especificada. Ela não deve ser confundida com a covariância marginal das respostas quando suas médias variam entre unidades.

As condições anteriores implicam que a dependência entre respostas é permitida **dentro de uma unidade**, enquanto erros de unidades distintas são não correlacionados. Sob normalidade conjunta, a covariância cruzada nula entre unidades implica independência por Proposição 9.6.

11.1.4 Formulação normal do modelo

A normalidade não é necessária para definir o modelo linear multivariado nem para obter o estimador de mínimos quadrados. Quando a inferência é baseada no modelo normal, a hipótese probabilística pode ser formulada diretamente para os vetores de erros das unidades (Anderson, 2003).

Definição 11.6 (Modelo linear normal multivariado). Além das condições de média e covariância de Definição 11.4 e Definição 11.5, assume-se que, condicionalmente a $\mathbf{Z}$,

$$\varepsilon_i \sim N_p(\mathbf{0}, \Sigma), \quad i = 1, \dots, n,$$

e que os vetores de erros de unidades distintas são independentes.

Equivalentemente, condicionalmente a $\mathbf{Z}$,

$$\mathbf{Y}_i \sim N_p(\mathbf{B}^\top \mathbf{z}_i, \Sigma), \quad i = 1, \dots, n, \quad (11.16)$$

e os vetores $\mathbf{Y}_1, \dots, \mathbf{Y}_n$ são independentes.

A hipótese normal acrescenta uma distribuição probabilística à estrutura de médias e covariâncias do modelo; a estimação por mínimos quadrados da estrutura de médias não depende dessa hipótese.

A estimação de $\mathbf{B}$ parte da matriz observada de respostas e da estrutura de médias $\mathbf{ZB}$.

11.2 Estimação da matriz de parâmetros

A estimação de $\mathbf{B}$ consiste em determinar a estrutura de médias

$$\mathbf{ZB}$$

que melhor aproxima a matriz observada de respostas $\mathbf{Y}$ segundo o critério adotado.

Como todas as respostas utilizam a mesma matriz de delineamento, cada coluna de $\mathbf{B}$ pode ser estimada pelo modelo linear correspondente àquela resposta. A formulação matricial reúne os p ajustes e mantém explícita a estrutura necessária para estudar conjuntamente os coeficientes e a covariância residual entre as respostas (Fujikoshi; Ulyanov; Shimizu, 2010; Johnson; Wichern, 2002).

11.2.1 Mínimos quadrados

Considere uma matriz candidata

$$\mathbf{B}^* \in \mathbb{R}^{q \times p}.$$

A matriz de resíduos correspondente é

$$\mathbf{Y} - \mathbf{ZB}^*.$$

Definição 11.7 (Critério de mínimos quadrados multivariado). O critério de mínimos quadrados é

$$Q(\mathbf{B}^*) = \|\mathbf{Y} - \mathbf{Z}\mathbf{B}^*\|_F^2. \quad (11.17)$$

Equivalentemente,

$$Q(\mathbf{B}^*) = \text{tr} \left[(\mathbf{Y} - \mathbf{Z}\mathbf{B}^*)^\top (\mathbf{Y} - \mathbf{Z}\mathbf{B}^*) \right]. \quad (11.18)$$

A norma de Frobenius foi definida em Definição 6.7. Neste problema,

$$Q(\mathbf{B}^*) = \sum_{j=1}^p \|\mathbf{y}_{\cdot j} - \mathbf{Z}\mathbf{b}_j^*\|^2, \quad (11.19)$$

em que $\mathbf{y}_{\cdot j}$ é a coluna j de $\mathbf{Y}$ e $\mathbf{b}_j^*$ é a coluna correspondente de $\mathbf{B}^*$.

Portanto, minimizar $Q(\mathbf{B}^*)$ equivale a minimizar separadamente a soma de quadrados residual de cada uma das p respostas.

Por essa razão, as covariâncias fora da diagonal de Σ não alteram o estimador de mínimos quadrados de $\mathbf{B}$ quando todas as respostas utilizam a mesma matriz $\mathbf{Z}$. Elas permanecem, porém, na estrutura de covariâncias dos erros e nos produtos cruzados residuais entre respostas.

As equações normais e sua derivação por cálculo matricial foram estabelecidas em Definição 3.21 e Proposição 7.5. Aplicadas ao modelo atual, elas assumem a forma

$$\mathbf{Z}^\top \mathbf{Z} \widehat{\mathbf{B}}_{\text{obs}} = \mathbf{Z}^\top \mathbf{Y}. \quad (11.20)$$

Equivalentemente,

$$\mathbf{Z}^\top (\mathbf{Y} - \mathbf{Z} \widehat{\mathbf{B}}_{\text{obs}}) = \mathbf{0}_{q \times p}. \quad (11.21)$$

Se

$$\widehat{\mathbf{U}} = \mathbf{Y} - \mathbf{Z} \widehat{\mathbf{B}}_{\text{obs}},$$

então

$$\mathbf{Z}^\top \widehat{\mathbf{U}} = \mathbf{0}. \quad (11.22)$$

Cada coluna da matriz de resíduos é, portanto, ortogonal ao espaço coluna de $\mathbf{Z}$. Essa propriedade é a versão multivariada da decomposição de mínimos quadrados estabelecida em Proposição 3.18.

11.2.2 Estimador sob posto completo

Suponha

$$\text{posto}(\mathbf{Z}) = q. \quad (11.23)$$

Nesse caso,

$$q \leq n$$

e

$$\mathbf{Z}^\top \mathbf{Z} \succ \mathbf{0}.$$

Proposição 11.1 (Estimador de mínimos quadrados sob posto completo). *Se*

$$\text{posto}(\mathbf{Z}) = q,$$

o estimador de mínimos quadrados de $\mathbf{B}$ é

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}. \quad (11.24)$$

Após a observação das respostas,

$$\widehat{\mathbf{B}}_{\text{obs}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}. \quad (11.25)$$

A unicidade do minimizador decorre da definição positiva de

$$\mathbf{Z}^\top \mathbf{Z}.$$

A convexidade do critério e a caracterização do minimizador global por meio das equações normais foram desenvolvidas em Proposição 7.7 e não precisam ser novamente demonstradas aqui.

Para a resposta j , a coluna correspondente é

$$\hat{\beta}_j = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}_{\cdot j}, \quad (11.26)$$

em que

$$\mathbf{Y}_{\cdot j} = \begin{bmatrix} Y_{1j} \\ \vdots \\ Y_{nj} \end{bmatrix}.$$

Assim, cada coluna de $\widehat{\mathbf{B}}$ coincide com o estimador de mínimos quadrados obtido para a resposta correspondente. A formulação matricial reúne esses estimadores em um único objeto.

11.3 Valores ajustados, resíduos e projeções

A estimação de $\mathbf{B}$ determina uma matriz de médias ajustadas pertencente ao espaço coluna da matriz de delineamento. A projeção ortogonal sobre um espaço coluna foi estabelecida em Proposição 3.15.

Seja

$$r = \text{posto}(\mathbf{Z}).$$

O projetor ortogonal sobre

$$\mathcal{C}(\mathbf{Z})$$

pode ser escrito como

$$\mathbf{P}_Z = \mathbf{Z}\mathbf{Z}^+, \quad (11.27)$$

em que $\mathbf{Z}^+$ é a pseudoinversa de Moore–Penrose definida em Definição 6.10.

Essa expressão depende apenas de $\mathcal{C}(\mathbf{Z})$ e permanece válida quando $\mathbf{Z}$ possui posto coluna deficiente. Portanto, $\mathbf{P}_Z$ e os valores ajustados permanecem unicamente determinados pelo espaço do modelo mesmo quando a parametrização por $\mathbf{B}$ não é identificável.

Quando

$$\text{posto}(\mathbf{Z}) = q,$$

essa expressão reduz-se a

$$\mathbf{P}_Z = \mathbf{Z}(\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top. \quad (11.28)$$

O projetor sobre o complemento ortogonal é

$$\mathbf{M}_Z = \mathbf{I}_n - \mathbf{P}_Z. \quad (11.29)$$

As propriedades gerais dos projetores ortogonais foram desenvolvidas em Proposição 3.15 e Definição 3.20. Em particular,

$$\mathbf{P}_Z^\top = \mathbf{P}_Z, \quad \mathbf{P}_Z^2 = \mathbf{P}_Z,$$

$$\mathbf{M}_Z^\top = \mathbf{M}_Z, \quad \mathbf{M}_Z^2 = \mathbf{M}_Z,$$

e

$$\mathbf{P}_Z \mathbf{M}_Z = \mathbf{M}_Z \mathbf{P}_Z = \mathbf{0}. \quad (11.30)$$

Além disso,

$$\text{posto}(\mathbf{P}_Z) = r$$

e

$$\text{posto}(\mathbf{M}_Z) = n - r. \quad (11.31)$$

Essas dimensões terão interpretação direta nos graus de liberdade associados ao ajuste e ao resíduo.

11.3.1 Valores ajustados e resíduos

Definição 11.8 (Valores ajustados). A matriz aleatória de valores ajustados é

$$\hat{y} = \mathbf{P}_Z y. \quad (11.32)$$

Após a observação,

$$\hat{\mathbf{Y}} = \mathbf{P}_Z \mathbf{Y}. \quad (11.33)$$

Como

$$\mathbf{P}_Z \mathbf{Z} = \mathbf{Z},$$

tem-se

$$\begin{aligned} \hat{y} &= \mathbf{P}_Z (\mathbf{Z}\mathbf{B} + \mathcal{E}) \\ &= \mathbf{Z}\mathbf{B} + \mathbf{P}_Z \mathcal{E}. \end{aligned} \quad (11.34)$$

Portanto, os valores ajustados preservam a estrutura sistemática do modelo e incorporam a projeção dos erros sobre o espaço do delineamento.

Definição 11.9 (Resíduos). A matriz aleatória de resíduos é

$$\hat{u} = y - \hat{y} = \mathbf{M}_Z y. \quad (11.35)$$

Após a observação,

$$\hat{\mathbf{U}} = \mathbf{Y} - \hat{\mathbf{Y}} = \mathbf{M}_Z \mathbf{Y}. \quad (11.36)$$

Como

$$\mathbf{M}_Z \mathbf{Z} = \mathbf{0},$$

segue que

$$\hat{u} = \mathbf{M}_Z \mathcal{E}. \quad (11.37)$$

Os resíduos são, portanto, a parcela dos erros pertencente ao complemento ortogonal de

$$\mathcal{C}(\mathbf{Z}).$$

Para cada realização,

$$\mathbf{Y} = \widehat{\mathbf{Y}} + \widehat{\mathbf{U}}. \quad (11.38)$$

A decomposição ocorre coluna a coluna: cada vetor de respostas observadas é separado em sua projeção sobre o espaço do modelo e em um resíduo ortogonal a esse espaço.

11.3.2 Ortogonalidade

As equações normais já forneceram

$$\mathbf{Z}^\top \widehat{\mathbf{U}} = \mathbf{0}.$$

Além disso,

$$\begin{aligned} \widehat{\mathbf{Y}}^\top \widehat{\mathbf{U}} &= \mathbf{Y}^\top \mathbf{P}_Z \mathbf{M}_Z \mathbf{Y} \\ &= \mathbf{0}. \end{aligned} \quad (11.39)$$

Assim, para quaisquer respostas j e k ,

$$\widehat{\mathbf{y}}_{\cdot j}^\top \widehat{\mathbf{u}}_{\cdot k} = 0.$$

A ortogonalidade não ocorre somente entre o ajuste e o resíduo da mesma resposta. Como o mesmo par de projetores atua sobre todas as colunas de $\mathbf{Y}$, qualquer coluna ajustada é ortogonal a qualquer coluna residual.

Consequentemente,

$$\|\mathbf{Y}\|_F^2 = \|\widehat{\mathbf{Y}}\|_F^2 + \|\widehat{\mathbf{U}}\|_F^2. \quad (11.40)$$

Essa identidade corresponde à decomposição em relação à origem. Quando $\mathbf{1}_n \in \mathcal{C}(\mathbf{Z})$, a centralização pela média geral conduz à decomposição corrigida estabelecida em Proposição 11.5.

11.3.3 Conexão com o modelo contendo somente intercepto

Quando

$$\mathbf{Z} = \mathbf{1}_n,$$

tem-se

$$\mathbf{P}_Z = \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top$$

e

$$\mathbf{M}_Z = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top = \mathbf{H}_n. \quad (11.41)$$

Assim,

$$\widehat{\mathbf{Y}} = \mathbf{1}_n \bar{\mathbf{y}}^\top,$$

enquanto

$$\widehat{\mathbf{U}} = \mathbf{H}_n \mathbf{Y}.$$

A matriz residual coincide, nesse caso, com a matriz de respostas centralizada. Portanto, a centralização utilizada nos Capítulos 8 e 10 aparece como um caso particular da projeção residual no modelo linear multivariado.

Consequentemente, no modelo somente com intercepto, os produtos cruzados dos resíduos reproduzem a SQPC amostral centralizada dos Capítulos 8 e 10.

11.4 SQPC residual e estimação da covariância

A matriz de resíduos

$$\widehat{\mathbf{u}} = \mathbf{M}_Z \mathbf{y}$$

contém os desvios das respostas em relação aos valores ajustados pelo modelo. Os produtos cruzados entre esses resíduos formam uma matriz que descreve a dispersão conjunta que permanece após o ajuste e permite estimar

$$\Sigma,$$

a matriz de covariâncias dos erros.

No modelo contendo somente intercepto, essa construção recupera a SQPC amostral dos Capítulos 8 e 10. No modelo linear geral, o ajuste remove um espaço de médias de dimensão

$$r = \text{posto}(\mathbf{Z}),$$

restando um espaço residual de dimensão $n - r$.

11.4.1 Construção da SQPC residual

Definição 11.10 (SQPC residual). A SQPC residual aleatória é

$$\mathbf{E}_{\text{res}} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}}. \quad (11.42)$$

Como

$$\widehat{\mathbf{U}} = \mathbf{M}_Z \mathbf{y},$$

e $\mathbf{M}_Z$ é simétrica e idempotente,

$$\mathbf{E}_{\text{res}} = \mathbf{y}^\top \mathbf{M}_Z \mathbf{y}. \quad (11.43)$$

Após a observação,

$$\mathbf{E} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}} = \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y}. \quad (11.44)$$

O elemento (j, k) de $\mathbf{E}$ é

$$e_{jk} = \sum_{i=1}^n \hat{u}_{ij} \hat{u}_{ik}. \quad (11.45)$$

Para $j = k$,

$$e_{jj} = \sum_{i=1}^n \hat{u}_{ij}^2$$

é a soma de quadrados residual da resposta j . Para $j \neq k$, e_{jk} é o produto cruzado residual entre as respostas j e k .

Como

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E}$$

e

$$\mathbf{M}_Z \mathbf{Z} = \mathbf{0},$$

tem-se

$$\widehat{\mathbf{u}} = \mathbf{M}_Z \mathcal{E}, \quad (11.46)$$

e, consequentemente,

$$\mathbf{E}_{\text{res}} = \mathcal{E}^\top \mathbf{M}_Z \mathcal{E}. \quad (11.47)$$

A SQPC residual depende do espaço de médias removido pelo ajuste por meio de $\mathbf{M}_Z$, mas não depende do valor específico de $\mathbf{B}$.

Como toda matriz de Gram, $\mathbf{E}$ é simétrica e positiva semidefinida. Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

$$\begin{aligned} \mathbf{a}^\top \mathbf{E} \mathbf{a} &= \|\widehat{\mathbf{U}} \mathbf{a}\|^2 \\ &\geq 0. \end{aligned} \quad (11.48)$$

11.4.2 Esperança e graus de liberdade

A dimensão do espaço residual é determinada pelo posto da matriz de delineamento.

Como

$$\mathbf{M}_Z = \mathbf{I}_n - \mathbf{P}_Z,$$

tem-se

$$\text{posto}(\mathbf{M}_Z) = \text{tr}(\mathbf{M}_Z) = n - r.$$

Definição 11.11 (Graus de liberdade residuais). Se

$$r = \text{posto}(\mathbf{Z}),$$

os graus de liberdade residuais são

$$\nu_E = n - r. \quad (11.49)$$

Quando $\mathbf{Z}$ possui posto coluna completo,

$$r = q,$$

e, portanto,

$$\nu_E = n - q.$$

A expressão utiliza r , e não simplesmente o número de colunas de $\mathbf{Z}$, porque somente as r direções linearmente independentes do espaço do modelo consomem graus de liberdade. Colunas redundantes não aumentam a dimensão do espaço de médias ajustado.

Proposição 11.2 (Esperança da SQPC residual). *Sob a estrutura do modelo linear multivariado,*

$$E(\mathcal{E} \mid \mathbf{Z}) = \mathbf{0},$$

$$\text{Cov}(\varepsilon_i \mid \mathbf{Z}) = \Sigma,$$

e

$$\text{Cov}(\varepsilon_i, \varepsilon_\ell \mid \mathbf{Z}) = \mathbf{0}, \quad i \neq \ell,$$

com

$$r = \text{posto}(\mathbf{Z}),$$

tem-se

$$E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) = (n - r)\Sigma. \quad (11.50)$$

i Demonstração

Pela Equação 11.47,

$$\mathbf{E}_{\text{res}} = \mathcal{E}^\top \mathbf{M}_Z \mathcal{E}.$$

Considere o elemento (j, k) :

$$[\mathbf{E}_{\text{res}}]_{jk} = \varepsilon_{\cdot j}^\top \mathbf{M}_Z \varepsilon_{\cdot k}.$$

Escrevendo

$$\mathbf{M}_Z = (m_{i\ell}),$$

obtem-se

$$[\mathbf{E}_{\text{res}}]_{jk} = \sum_{i=1}^n \sum_{\ell=1}^n m_{i\ell} \varepsilon_{ij} \varepsilon_{\ell k}.$$

Para $i \neq \ell$,

$$E(\varepsilon_{ij} \varepsilon_{\ell k} \mid \mathbf{Z}) = 0,$$

enquanto, para $i = \ell$,

$$E(\varepsilon_{ij} \varepsilon_{ik} \mid \mathbf{Z}) = \sigma_{jk}.$$

Logo,

$$\begin{aligned} E\left([\mathbf{E}_{\text{res}}]_{jk} \mid \mathbf{Z}\right) &= \sum_{i=1}^n m_{ii} \sigma_{jk} \\ &= \text{tr}(\mathbf{M}_Z) \sigma_{jk} \\ &= (n - r) \sigma_{jk}. \end{aligned}$$

Como a igualdade vale para todos os elementos,

$$E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) = (n - r) \Sigma.$$

A expressão generaliza Proposição 10.7, que estabelece

$$E(\mathbf{T}) = (n - 1) \Sigma.$$

No modelo contendo somente intercepto,

$$r = 1,$$

de modo que

$$n - r = n - 1.$$

No modelo linear geral, cada direção independente utilizada para representar a estrutura de médias reduz em uma unidade a dimensão do espaço residual.

11.4.3 Estimação da covariância residual

Definição 11.12 (Estimador residual da matriz de covariâncias). Se

$$r = \text{posto}(\mathbf{Z})$$

e

$$n - r > 0,$$

define-se

$$\widehat{\Sigma} = \frac{\mathbf{E}_{\text{res}}}{n - r}. \quad (11.51)$$

Após a observação,

$$\widehat{\Sigma}_{\text{obs}} = \frac{\mathbf{E}}{n - r}. \quad (11.52)$$

Proposição 11.3 (Não viesamento do estimador residual). Se

$$r = \text{posto}(\mathbf{Z}), \quad n - r > 0,$$

e

$$E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) = (n - r)\Sigma,$$

então

$$E(\widehat{\Sigma} \mid \mathbf{Z}) = \Sigma. \quad (11.53)$$

Portanto, $\widehat{\Sigma}$ é um estimador não viesado da matriz de covariâncias dos erros.

i Demonstração

Por Equação 11.51 e Equação 11.50,

$$\begin{aligned} E(\widehat{\Sigma} \mid \mathbf{Z}) &= \frac{1}{n-r} E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) \\ &= \frac{1}{n-r} (n-r) \Sigma \\ &= \Sigma. \end{aligned}$$

Covariância total e covariância residual

A matriz de covariâncias calculada diretamente das respostas descreve a variabilidade conjunta observada antes do ajuste.

A matriz

$$\widehat{\Sigma}_{\text{obs}}$$

descreve a variabilidade que permanece depois de removida a estrutura de médias pertencente a

$$\mathcal{C}(\mathbf{Z}).$$

Por isso, em geral, as duas matrizes não coincidem.

11.4.4 Posto e singularidade

A SQPC residual possui a forma de Gram

$$\mathbf{E} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}}.$$

Portanto,

$$\text{posto}(\mathbf{E}) = \text{posto}(\widehat{\mathbf{U}}).$$

Como

$$\widehat{\mathbf{U}} = \mathbf{M}_Z \mathbf{Y}$$

e

$$\text{posto}(\mathbf{M}_Z) = n - r,$$

obtém-se:

Proposição 11.4 (Posto da SQPC residual). *Se*

$$r = \text{posto}(\mathbf{Z}),$$

a SQPC residual observada

$$\mathbf{E} = \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y}$$

satisfaz

$$\text{posto}(\mathbf{E}) \leq \min(p, n - r). \quad (11.54)$$

Consequentemente, se

$$p > n - r,$$

então $\mathbf{E}$ é necessariamente singular.

Uma condição necessária para

$$\mathbf{E} \succ \mathbf{0}$$

é

$$n - r \geq p. \quad (11.55)$$

Para uma amostra arbitrária, essa desigualdade não é suficiente: também é necessário

$$\text{posto}(\widehat{\mathbf{U}}) = p.$$

Portanto, uma condição necessária para que a SQPC residual seja positiva definida é haver pelo menos p dimensões residuais,

$$n - r \geq p.$$

A desigualdade, isoladamente, não garante posto completo em uma amostra arbitrária; também é necessário que os resíduos observados gerem p direções linearmente independentes.

O limite de posto é a extensão de Equação 10.66, que no caso de uma única média fornece

$$\text{posto}(\mathbf{S}) \leq \min(p, n - 1).$$

O condicionamento, a pseudoinversa e a regularização de matrizes de covariâncias foram tratados, respectivamente, em Equação 10.108, Equação 10.117 e Definição 10.18.

11.5 Decomposição da variação multivariada

Quando o espaço coluna de $\mathbf{Z}$ contém o vetor $\mathbf{1}_n$, a dispersão das respostas em torno do vetor de médias amostrais pode ser decomposta em uma parcela associada ao modelo e uma parcela residual. Essa condição é satisfeita, por exemplo, quando o modelo possui um intercepto explícito e também em parametrizações nas quais a média geral pertence ao espaço do modelo sem corresponder a uma coluna específica de $\mathbf{Z}$.

No caso univariado, essa separação produz as somas de quadrados utilizadas na análise de variância. No modelo multivariado, cada parcela é representada por uma matriz SQPC, preservando também os produtos cruzados entre as respostas (Johnson; Wichern, 2002).

A principal decomposição é

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E},$$

em que $\mathbf{T}$ representa a dispersão total em torno da média geral, $\mathbf{T}_{\text{mod}}$ representa a dispersão dos valores ajustados em torno da média geral e $\mathbf{E}$ representa a dispersão residual em torno dos valores ajustados.

11.5.1 SQPC total

A SQPC total observada foi definida em Definição 8.9. Aplicada à matriz de respostas,

$$\mathbf{T} = \mathbf{Y}^\top \mathbf{H}_n \mathbf{Y}, \tag{11.56}$$

em que $\mathbf{H}_n$ é a matriz de centralização utilizada em Equação 8.55:

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

11.5.2 SQPC associada ao modelo

Suponha que a direção constante pertença ao espaço do modelo, isto é,

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}). \quad (11.57)$$

Essa condição é satisfeita quando o modelo possui um intercepto explícito e também em parametrizações nas quais a média geral pertence ao espaço do modelo sem corresponder a uma coluna específica de $\mathbf{Z}$.

Defina o projetor sobre o espaço das constantes por

$$\mathbf{P}_1 = \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top. \quad (11.58)$$

Como

$$\mathcal{C}(\mathbf{1}_n) \subseteq \mathcal{C}(\mathbf{Z}),$$

tem-se

$$\mathbf{P}_Z \mathbf{P}_1 = \mathbf{P}_1 \mathbf{P}_Z = \mathbf{P}_1. \quad (11.59)$$

Consequentemente,

$$\mathbf{P}_Z - \mathbf{P}_1$$

é o projetor ortogonal sobre a parte de $\mathcal{C}(\mathbf{Z})$ ortogonal à direção constante. Essa parte representa as variações ajustadas pelo modelo em torno da média geral.

Seu posto é

$$\text{posto}(\mathbf{P}_Z - \mathbf{P}_1) = r - 1, \quad (11.60)$$

em que

$$r = \text{posto}(\mathbf{Z}).$$

Definição 11.13 (SQPC associada ao modelo, corrigida pela média geral). Quando

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}),$$

define-se

$$\mathbf{T}_{\text{mod}} = \mathbf{Y}^\top (\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y}. \quad (11.61)$$

em que $\mathbf{P}_Z$ é o projetor sobre $\mathcal{C}(\mathbf{Z})$ e

$$\mathbf{P}_1 = \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top$$

é o projetor sobre a direção constante.

Se

$$\mathcal{C}(\mathbf{Z}) = \mathcal{C}(\mathbf{1}_n),$$

então

$$\mathbf{P}_Z = \mathbf{P}_1$$

e, conseqüentemente,

$$\mathbf{T}_{\text{mod}} = \mathbf{0}.$$

Assim, $\mathbf{T}_{\text{mod}}$ quantifica somente a variação ajustada que excede a representação da média geral.

A matriz

$$\mathbf{T}_{\text{mod}}$$

mede a dispersão dos valores ajustados pelo modelo em torno da média geral. No modelo de grupos, essa matriz coincide com a dispersão entre grupos. Em modelos com covariáveis, ela representa conjuntamente a variação dos valores ajustados em torno da média geral.

11.5.3 Decomposição entre modelo e resíduo

Sob a condição

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}),$$

considere

$$\mathbf{H}_n = \mathbf{I}_n - \mathbf{P}_1$$

e

$$\mathbf{I}_n = \mathbf{P}_Z + \mathbf{M}_Z.$$

segue que

$$\mathbf{H}_n = (\mathbf{P}_Z - \mathbf{P}_1) + \mathbf{M}_Z. \quad (11.62)$$

Além disso,

$$(\mathbf{P}_Z - \mathbf{P}_1) \mathbf{M}_Z = \mathbf{0}.$$

Assim, as duas parcelas correspondem a subespaços ortogonais.

Proposição 11.5 (Decomposição da SQPC total). *Se*

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}),$$

então

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E}, \quad (11.63)$$

em que

$$\mathbf{T} = \mathbf{Y}^\top \mathbf{H}_n \mathbf{Y},$$

$$\mathbf{T}_{\text{mod}} = \mathbf{Y}^\top (\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y}$$

e

$$\mathbf{E} = \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y}.$$

i Demonstração

Substituindo Equação 11.62 na definição de $\mathbf{T}$,

$$\begin{aligned} \mathbf{T} &= \mathbf{Y}^\top \mathbf{H}_n \mathbf{Y} \\ &= \mathbf{Y}^\top [(\mathbf{P}_Z - \mathbf{P}_1) + \mathbf{M}_Z] \mathbf{Y} \\ &= \mathbf{T}_{\text{mod}} + \mathbf{E}. \end{aligned}$$

As dimensões dos subespaços correspondentes fornecem

$$n - 1 = (r - 1) + (n - r). \quad (11.64)$$

A Tabela 11.1 resume as dimensões dos três subespaços envolvidos.

Tabela 11.1: Decomposição das dimensões associadas à SQPC total quando a direção constante pertence ao espaço do modelo.

Fonte	Projetor	Graus de liberdade
Total corrigido pela média geral	$\mathbf{H}_n$	$n - 1$
Modelo corrigido pela média geral	$\mathbf{P}_Z - \mathbf{P}_1$	$r - 1$
Residual	$\mathbf{M}_Z$	$n - r$

Os graus de liberdade correspondem aos postos dos projetores no espaço das unidades. Eles não devem ser confundidos com os postos das matrizes de SQPC, que também dependem de p .

11.5.4 Modelo de grupos como caso particular

Considere K grupos não vazios. Uma parametrização particularmente simples utiliza uma coluna indicadora para cada grupo (Johnson; Wichern, 2002). Para três grupos, por exemplo, a matriz de delineamento possui a forma

$$\mathbf{Z} = \begin{bmatrix} 1 & 0 & 0 \\ \vdots & \vdots & \vdots \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ \vdots & \vdots & \vdots \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ \vdots & \vdots & \vdots \\ 0 & 0 & 1 \end{bmatrix},$$

em que cada linha identifica o grupo da respectiva unidade. Para K grupos não vazios,

$$\mathbf{Z} \in \mathbb{R}^{n \times K}, \quad \text{posto}(\mathbf{Z}) = K,$$

e

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}).$$

Portanto, neste caso,

$$r = K.$$

Na parametrização por médias de grupos,

$$\mathbf{B} = \begin{bmatrix} \mu_1^\top \\ \vdots \\ \mu_K^\top \end{bmatrix},$$

em que $\mu_k \in \mathbb{R}^p$ é o vetor de médias do grupo k .

Denote por $\mathcal{J}_k$ o conjunto dos índices das unidades pertencentes ao grupo k e por

$$n_k = |\mathcal{J}_k|$$

o número de unidades desse grupo. Para $i \in \mathcal{J}_k$,

$$E(\mathbf{Y}_i) = \mu_k.$$

O estimador de mínimos quadrados é

$$\widehat{\mathbf{B}}_{\text{obs}} = \begin{bmatrix} \bar{\mathbf{y}}_1^\top \\ \vdots \\ \bar{\mathbf{y}}_K^\top \end{bmatrix}. \quad (11.65)$$

Portanto, o vetor ajustado para cada unidade é a média amostral do grupo ao qual ela pertence.

A SQPC residual é

$$\mathbf{E} = \sum_{k=1}^K \sum_{i \in \mathcal{J}_k} (\mathbf{y}_i - \bar{\mathbf{y}}_k) (\mathbf{y}_i - \bar{\mathbf{y}}_k)^\top. \quad (11.66)$$

Pela definição de dispersão intragrupos em Definição 8.13,

$$\mathbf{E} = \mathbf{T}_{\text{intra}}. \quad (11.67)$$

Assim, a SQPC residual do modelo de grupos mede exatamente a dispersão das observações em torno das médias de seus respectivos grupos.

Como $r = K$, quando $n > K$ o estimador residual de covariância satisfaz

$$\widehat{\Sigma}_{\text{obs}} = \frac{\mathbf{E}}{n - K} = \frac{\mathbf{T}_{\text{intra}}}{n - K}.$$

A parcela associada ao modelo é

$$\mathbf{T}_{\text{mod}} = \sum_{k=1}^K n_k (\bar{\mathbf{y}}_k - \bar{\mathbf{y}}) (\bar{\mathbf{y}}_k - \bar{\mathbf{y}})^\top. \quad (11.68)$$

Por Definição 8.14,

$$\mathbf{T}_{\text{mod}} = \mathbf{T}_{\text{entre}}. \quad (11.69)$$

Portanto,

$$\mathbf{T} = \mathbf{T}_{\text{entre}} + \mathbf{T}_{\text{intra}}, \quad (11.70)$$

recuperando Proposição 8.9 como um caso particular do modelo linear multivariado.

Os graus de liberdade também se decompõem como

$$n - 1 = (K - 1) + (n - K). \quad (11.71)$$

A decomposição depende do espaço de médias $\mathcal{C}(\mathbf{Z})$, e não de uma parametrização específica desse espaço. Assim, parametrizações distintas que representam o mesmo espaço de médias produzem os mesmos valores ajustados, resíduos e componentes da decomposição, embora seus coeficientes possam não ser únicos.

11.6 Posto, parametrização e estimabilidade

A expressão

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}$$

exige

$$\text{posto}(\mathbf{Z}) = q.$$

Nesse caso, as colunas de $\mathbf{Z}$ são linearmente independentes e a aplicação

$$\mathbf{B} \mapsto \mathbf{ZB}$$

é injetiva. Portanto, para uma matriz de delineamento $\mathbf{Z}$ fixada, a estrutura de médias $\mathbf{ZB}$ identifica unicamente a matriz de parâmetros $\mathbf{B}$.

Alguns modelos, especialmente aqueles que representam grupos ou fatores, podem ser escritos com colunas redundantes em $\mathbf{Z}$. Diferentes valores dos coeficientes podem então representar exatamente a mesma estrutura de médias (Johnson; Wichern, 2002)

$$\mathbf{ZB}.$$

Por isso, é necessário distinguir a unicidade dos coeficientes da unicidade dos valores ajustados e das combinações de parâmetros que se deseja interpretar.

11.6.1 Delineamento com posto deficiente

Considere

$$\mathbf{Z} \in \mathbb{R}^{n \times q}$$

com

$$r = \text{posto}(\mathbf{Z}) < q. \quad (11.72)$$

Nesse caso, as colunas de $\mathbf{Z}$ são linearmente dependentes. Portanto, existe pelo menos um vetor não nulo

$$\mathbf{d} \in \mathbb{R}^q$$

tal que

$$\mathbf{Z}\mathbf{d} = \mathbf{0}.$$

Consequentemente, alterações dos coeficientes em direções pertencentes ao núcleo de $\mathbf{Z}$ não modificam a estrutura de médias.

Assim, quando $r < q$, a parametrização por $\mathbf{B}$ não é identificável: matrizes de coeficientes distintas podem produzir a mesma matriz de médias $\mathbf{Z}\mathbf{B}$.

11.6.2 Pseudoinversa e unicidade do ajuste

A pseudoinversa de Moore–Penrose e sua relação com mínimos quadrados foram desenvolvidas em Definição 6.10 e Proposição 6.18.

Quando

$$r < q,$$

a matriz

$$\mathbf{Z}^\top \mathbf{Z}$$

é singular, mas o problema de mínimos quadrados continua tendo solução. Uma delas é

$$\widehat{\mathbf{B}}_0 = \mathbf{Z}^+ \mathbf{y}. \quad (11.73)$$

Proposição 11.6 (Unicidade dos valores ajustados sob posto deficiente). *Mesmo quando os coeficientes de mínimos quadrados não são únicos, todas as soluções produzem a mesma matriz de valores ajustados,*

$$\hat{\mathbf{y}} = \mathbf{P}_Z \mathbf{y}. \quad (11.74)$$

Consequentemente, também são únicos

$$\hat{\mathbf{u}} = \mathbf{M}_Z \mathbf{y}$$

e

$$\mathbf{E}_{\text{res}} = \mathbf{y}^\top \mathbf{M}_Z \mathbf{y}.$$

Portanto, a deficiência de posto pode impedir a interpretação única de determinados coeficientes sem impedir o cálculo dos valores ajustados, dos resíduos e da SQPC residual.

Os graus de liberdade residuais continuam sendo determinados pelo posto efetivo,

$$\nu_E = n - r,$$

e o estimador não viesado da covariância residual permanece

$$\hat{\Sigma} = \frac{\mathbf{E}_{\text{res}}}{n - r}.$$

11.6.3 Funções estimáveis

Quando os coeficientes de $\mathbf{B}$ não são individualmente identificados, ainda podem existir combinações deles que sejam determinadas unicamente pela estrutura de médias. Essas combinações são particularmente importantes em modelos com fatores, nos quais comparações entre grupos podem ser estimáveis mesmo quando uma parametrização utiliza coeficientes redundantes.

Considere

$$\mathbf{C} \in \mathbb{R}^{g \times q}.$$

A função

$$\mathbf{CB} \in \mathbb{R}^{g \times p}$$

forma combinações lineares das linhas de $\mathbf{B}$, isto é, dos coeficientes associados às colunas da matriz de delineamento.

Definição 11.14 (Função linear estimável). Para

$$\mathbf{C} \in \mathbb{R}^{g \times q},$$

a função

$$\mathbf{CB}$$

é estimável quando existe uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times g}$$

tal que

$$E(\mathbf{A}^\top \mathbf{y} \mid \mathbf{Z}) = \mathbf{CB}$$

para toda matriz de parâmetros $\mathbf{B}$.

Como

$$E(\mathbf{y} \mid \mathbf{Z}) = \mathbf{ZB},$$

a condição anterior equivale a

$$\mathbf{A}^\top \mathbf{Z} = \mathbf{C}. \tag{11.75}$$

Portanto, a estimabilidade depende do espaço linha de $\mathbf{Z}$.

Proposição 11.7 (Caracterização das funções estimáveis). Para

$$\mathbf{C} \in \mathbb{R}^{g \times q},$$

são equivalentes:

1. $\mathbf{CB}$ é estimável;

2. as linhas de $\mathbf{C}$ pertencem ao espaço linha de $\mathbf{Z}$,

$$\mathcal{C}(\mathbf{C}^\top) \subseteq \mathcal{C}(\mathbf{Z}^\top);$$

3. vale

$$\mathbf{C} = \mathbf{C}\mathbf{Z}^+\mathbf{Z}.$$

Em particular,

$$\mathbf{CB} \text{ é estimável} \iff \mathbf{C} = \mathbf{C}\mathbf{Z}^+\mathbf{Z}. \quad (11.76)$$

i Demonstração

Pela definição de estimabilidade, deve existir uma matriz $\mathbf{A}$ tal que

$$\mathbf{C} = \mathbf{A}^\top \mathbf{Z}.$$

Isso ocorre exatamente quando cada linha de $\mathbf{C}$ pertence ao espaço linha de $\mathbf{Z}$.

Como

$$\mathbf{Z}^+\mathbf{Z}$$

é o projetor ortogonal sobre esse espaço, a mesma condição pode ser escrita como

$$\mathbf{C} = \mathbf{C}\mathbf{Z}^+\mathbf{Z}.$$

11.6.4 Estimador de uma função estimável

Quando $\mathbf{CB}$ é estimável, pode-se utilizar

$$\widehat{\Theta}_C = \mathbf{C}\mathbf{Z}^+\mathbf{y}. \quad (11.77)$$

Como

$$\mathbf{C} = \mathbf{C}\mathbf{Z}^+\mathbf{Z},$$

tem-se

$$E(\widehat{\Theta}_C | \mathbf{Z}) = \mathbf{CB}. \quad (11.78)$$

Portanto, uma função estimável possui o mesmo valor para todas as matrizes de parâmetros que produzem a mesma estrutura de médias. Essa propriedade permite formular hipóteses sobre funções dos parâmetros sem depender da parametrização escolhida.

A distinção entre coeficientes individuais e funções estimáveis permite formular comparações que não dependem da parametrização adotada. Essas comparações podem envolver funções dos coeficientes associados às colunas do delineamento e combinações das respostas.

11.7 Hipóteses lineares multivariadas

O modelo linear multivariado permite formular hipóteses sobre funções lineares dos coeficientes, diferenças entre grupos e combinações das respostas. A multiplicação à esquerda de $\mathbf{B}$ forma combinações de suas linhas, enquanto a multiplicação à direita seleciona ou combina respostas (Anderson, 2003; Johnson; Wichern, 2002).

11.7.1 Combinações das linhas da matriz de parâmetros

Considere

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q}.$$

A matriz

$$\mathbf{C}_1 \mathbf{B} \in \mathbb{R}^{g \times p}$$

forma combinações lineares das linhas de $\mathbf{B}$.

Se

$$\mathbf{c}_1^\top \in \mathbb{R}^{1 \times q}$$

é uma linha de $\mathbf{C}_1$, então

$$\mathbf{c}_1^\top \mathbf{B} \in \mathbb{R}^{1 \times p}$$

contém, para as p respostas, a mesma combinação dos coeficientes associados às colunas do delineamento.

Por exemplo, se

$$\mathbf{c}_1^\top = \mathbf{e}_h^\top,$$

então $\mathbf{c}_1^\top \mathbf{B}$ seleciona, para as p respostas, os coeficientes associados à coluna h de $\mathbf{Z}$.

No modelo parametrizado diretamente pelas médias de K grupos,

$$\mathbf{B} = \begin{bmatrix} \mu_1^\top \\ \vdots \\ \mu_K^\top \end{bmatrix},$$

uma combinação

$$\mathbf{c}_1^\top \mathbf{B} = \sum_{k=1}^K c_{1k} \mu_k^\top$$

é um contraste entre os vetores de médias quando

$$\sum_{k=1}^K c_{1k} = 0.$$

Por exemplo,

$$\mathbf{c}_1^\top = [1 \quad -1 \quad 0 \quad \cdots \quad 0]$$

produz

$$\mathbf{c}_1^\top \mathbf{B} = (\mu_1 - \mu_2)^\top.$$

Assim, uma única linha de $\mathbf{C}_1$ pode representar uma comparação entre grupos, enquanto várias linhas permitem representar simultaneamente diferentes contrastes.

11.7.2 Combinações das respostas

A multiplicação à direita de $\mathbf{B}$ atua sobre as respostas. Considere

$$\mathbf{C}_2 \in \mathbb{R}^{p \times s}.$$

Então,

$$\mathbf{BC}_2 \in \mathbb{R}^{q \times s}$$

contém os coeficientes do modelo para as s combinações de respostas definidas por $\mathbf{C}_2$.

Para uma única combinação, considere

$$\mathbf{c}_2 \in \mathbb{R}^p$$

e defina

$$W_i = \mathbf{c}_2^\top \mathbf{Y}_i.$$

Sua média condicional é

$$E(W_i | \mathbf{Z}) = \mathbf{z}_i^\top \mathbf{BC}_2, \quad (11.79)$$

e sua variância residual é

$$\text{Var}(W_i | \mathbf{Z}) = \mathbf{c}_2^\top \Sigma \mathbf{c}_2. \quad (11.80)$$

Para várias combinações simultâneas,

$$\mathbf{y}_{C_2} = \mathbf{y} \mathbf{C}_2,$$

e

$$\mathbf{y}_{C_2} = \mathbf{Z}(\mathbf{BC}_2) + \mathcal{E} \mathbf{C}_2. \quad (11.81)$$

A matriz de covariâncias residuais correspondente é

$$\Sigma_{C_2} = \mathbf{C}_2^\top \Sigma \mathbf{C}_2. \quad (11.82)$$

Portanto, $\mathbf{C}_1$ forma combinações das linhas de $\mathbf{B}$, enquanto $\mathbf{C}_2$ seleciona ou combina suas colunas, correspondentes às respostas.

11.7.3 Hipótese linear geral

Combinando as duas operações anteriores, define-se

$$\Theta = \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 \in \mathbb{R}^{g \times s}, \quad (11.83)$$

com

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q} \quad \text{e} \quad \mathbf{C}_2 \in \mathbb{R}^{p \times s}.$$

As linhas de Θ correspondem às combinações das linhas de $\mathbf{B}$ definidas por $\mathbf{C}_1$, enquanto suas colunas correspondem às combinações das respostas definidas por $\mathbf{C}_2$.

Definição 11.15 (Hipótese linear geral multivariada). Para

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q} \quad \text{e} \quad \mathbf{C}_2 \in \mathbb{R}^{p \times s},$$

a hipótese linear geral é

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0, \quad (11.84)$$

em que

$$\Theta_0 \in \mathbb{R}^{g \times s}$$

contém os valores especificados pela hipótese. Supõe-se que a hipótese seja não vazia, isto é, que exista ao menos uma matriz de parâmetros $\mathbf{B}$ compatível com

$$\mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0.$$

Quando

$$\Theta_0 = \mathbf{0},$$

obtém-se

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \mathbf{0}. \quad (11.85)$$

Se

$$\mathbf{C}_2 = \mathbf{I}_p,$$

a hipótese envolve, em todas as respostas, as funções dos coeficientes especificadas por $\mathbf{C}_1$:

$$H_0 : \mathbf{C}_1 \mathbf{B} = \Theta_0.$$

11.7.4 Estimabilidade da hipótese

A hipótese deve envolver uma função dos parâmetros determinada pela estrutura de médias. Por Proposição [11.7](#),

$$\mathbf{C}_1 \mathbf{B}$$

é estimável quando

$$\mathbf{C}_1 = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Z}. \quad (11.86)$$

Nessa situação,

$$\widehat{\Theta} = \mathbf{C}_1 \mathbf{Z}^+ \mathcal{Y} \mathbf{C}_2 \quad (11.87)$$

é um estimador de

$$\Theta = \mathbf{C}_1 \mathbf{B} \mathbf{C}_2,$$

e, após a observação,

$$\widehat{\Theta}_{\text{obs}} = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Y} \mathbf{C}_2. \quad (11.88)$$

Sua esperança condicional satisfaz

$$E\left(\widehat{\Theta} \mid \mathbf{Z}\right) = \mathbf{C}_1 \mathbf{B} \mathbf{C}_2. \quad (11.89)$$

Para construir a SQPC associada à hipótese, defina

$$\mathbf{V}_{C_1} = \mathbf{C}_1 \mathbf{Z}^+ (\mathbf{Z}^+)^{\top} \mathbf{C}_1^{\top}. \quad (11.90)$$

Para qualquer combinação das respostas definida por

$$\mathbf{c}_2 \in \mathbb{R}^p,$$

a estrutura de covariâncias dos erros implica

$$\text{Cov}(\mathbf{C}_1 \mathbf{Z}^+ \mathcal{Y} \mathbf{c}_2 \mid \mathbf{Z}) = (\mathbf{c}_2^{\top} \Sigma \mathbf{c}_2) \mathbf{V}_{C_1}.$$

Assim, $\mathbf{V}_{C_1}$ representa a contribuição do delineamento para a covariância das funções especificadas por $\mathbf{C}_1$.

Quando $\mathbf{Z}$ possui posto coluna completo,

$$\mathbf{V}_{C_1} = \mathbf{C}_1 (\mathbf{Z}^{\top} \mathbf{Z})^{-1} \mathbf{C}_1^{\top}. \quad (11.91)$$

Considere $\mathbf{C}_1$ sem linhas redundantes, de modo que

$$\text{posto}(\mathbf{C}_1) = g,$$

e os graus de liberdade associados à hipótese são

$$\nu_H = g. \quad (11.92)$$

11.7.5 SQPC da hipótese

A SQPC da hipótese representa o afastamento observado em relação à hipótese, ponderado pela variabilidade decorrente do delineamento.

Definição 11.16 (SQPC da hipótese linear). Considere

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q}, \quad \text{posto}(\mathbf{C}_1) = g,$$

$$\mathbf{C}_2 \in \mathbb{R}^{p \times s}$$

e

$$\Theta_0 \in \mathbb{R}^{g \times s}.$$

Suponha que as funções lineares especificadas por $\mathbf{C}_1$ sejam estimáveis, isto é,

$$\mathbf{C}_1 = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Z}.$$

Para a hipótese

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0,$$

o afastamento observado é

$$\widehat{\Delta} = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Y} \mathbf{C}_2 - \Theta_0 \in \mathbb{R}^{g \times s}. \quad (11.93)$$

Defina

$$\mathbf{V}_{C_1} = \mathbf{C}_1 \mathbf{Z}^+ (\mathbf{Z}^+)^{\top} \mathbf{C}_1^{\top} \in \mathbb{R}^{g \times g}.$$

Quando

$$\mathbf{V}_{C_1} \succ \mathbf{0},$$

a **SQPC da hipótese linear** é

$$\mathbf{H} = \widehat{\Delta}^{\top} \mathbf{V}_{C_1}^{-1} \widehat{\Delta} \in \mathbb{R}^{s \times s}. \quad (11.94)$$

A matriz

$$\mathbf{H} \in \mathbb{R}^{s \times s}$$

é simétrica e positiva semidefinida,

$$\mathbf{H} \succeq \mathbf{0},$$

e satisfaz

$$\text{posto}(\mathbf{H}) \leq \min(g, s). \quad (11.95)$$

Se

$$\widehat{\Delta} = \mathbf{0},$$

então

$$\mathbf{H} = \mathbf{0}.$$

Para as mesmas combinações de respostas, a matriz de resíduos é

$$\widehat{\mathbf{U}}_{C_2} = \mathbf{M}_Z \mathbf{Y} \mathbf{C}_2 = \widehat{\mathbf{U}} \mathbf{C}_2.$$

Consequentemente, a SQPC residual correspondente é

$$\begin{aligned} \mathbf{E}_{C_2} &= \widehat{\mathbf{U}}_{C_2}^\top \widehat{\mathbf{U}}_{C_2} \\ &= \mathbf{C}_2^\top \mathbf{E} \mathbf{C}_2. \end{aligned} \quad (11.96)$$

Portanto, a hipótese produz o par

$$(\mathbf{H}, \mathbf{E}_{C_2}).$$

A matriz $\mathbf{H}$ representa a variação associada ao afastamento da hipótese, enquanto $\mathbf{E}_{C_2}$ representa a variação residual das mesmas combinações de respostas.

Quando

$$\mathbf{C}_2 = \mathbf{I}_p,$$

obtém-se o par

$$(\mathbf{H}, \mathbf{E}),$$

formado pela SQPC da hipótese e pela SQPC residual nas respostas originais. Esse é o par de matrizes de hipótese e erro utilizado na formulação da MANOVA.

11.7.6 Casos particulares

A forma geral inclui diferentes perguntas sem necessidade de construir uma notação específica para cada uma.

11.7.6.1 Comparação entre vetores de médias de grupos

Na parametrização por médias de grupos, considere

$$\mathbf{c}_1^\top = [1 \quad -1 \quad 0 \quad \cdots \quad 0]$$

e

$$\mathbf{C}_2 = \mathbf{I}_p.$$

A hipótese

$$H_0 : \mathbf{c}_1^\top \mathbf{B} = \mathbf{0}^\top$$

equivale a

$$H_0 : \mu_1 = \mu_2. \tag{11.97}$$

Várias linhas em $\mathbf{C}_1$ permitem representar simultaneamente diferentes contrastes entre grupos.

11.7.6.2 Igualdade global dos vetores de médias dos grupos

No modelo de K grupos, considere

$$\mathbf{C}_G \in \mathbb{R}^{(K-1) \times K},$$

com

$$\text{posto}(\mathbf{C}_G) = K - 1$$

e

$$\mathbf{C}_G \mathbf{1}_K = \mathbf{0}.$$

A hipótese

$$H_0 : \mathbf{C}_G \mathbf{B} = \mathbf{0}$$

é equivalente a

$$H_0 : \mu_1 = \cdots = \mu_K.$$

Nesse caso,

$$\nu_H = K - 1$$

e, para $\mathbf{C}_2 = \mathbf{I}_p$,

$$\mathbf{H} = \mathbf{T}_{\text{mod}} = \mathbf{T}_{\text{entre}}. \quad (11.98)$$

Juntamente com Equação [11.67](#),

$$\mathbf{E} = \mathbf{T}_{\text{intra}}.$$

11.7.6.3 Coeficientes associados a uma coluna do delineamento em todas as respostas

Para examinar os coeficientes associados à coluna h de $\mathbf{Z}$, tome

$$\mathbf{C}_1 = \mathbf{e}_h^\top$$

e

$$\mathbf{C}_2 = \mathbf{I}_p.$$

A hipótese

$$H_0 : \mathbf{e}_h^\top \mathbf{B} = \mathbf{0}^\top \quad (11.99)$$

afirma que os coeficientes associados à coluna h do delineamento são nulos para todas as respostas.

As matrizes $\mathbf{H}$ e $\mathbf{E}_{C_2}$ referem-se às mesmas s combinações de respostas definidas por $\mathbf{C}_2$. Quando $\mathbf{C}_2 = \mathbf{I}_p$, ambas são expressas nas p respostas originais.

11.8 Aprofundamento teórico

11.8.1 Forma vetorizada

A forma matricial

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E}$$

pode ser reexpressa em um único vetor por meio do operador vec e do produto de Kronecker definidos em Definição 7.9 e Definição 7.10.

Pela identidade de Proposição 7.14,

$$\text{vec}(\mathbf{ZB}) = (\mathbf{I}_p \otimes \mathbf{Z}) \text{vec}(\mathbf{B}), \quad (11.100)$$

de modo que

$$\text{vec}(\mathbf{y}) = (\mathbf{I}_p \otimes \mathbf{Z}) \text{vec}(\mathbf{B}) + \text{vec}(\mathcal{E}). \quad (11.101)$$

Proposição 11.8 (Covariância do erro vetorizado). *Se*

$$\text{Cov}(\varepsilon_i \mid \mathbf{Z}) = \Sigma, \quad i = 1, \dots, n,$$

e

$$\text{Cov}(\varepsilon_i, \varepsilon_\ell \mid \mathbf{Z}) = \mathbf{0}, \quad i \neq \ell,$$

então

$$\text{Cov}[\text{vec}(\mathcal{E}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n. \quad (11.102)$$

Consequentemente,

$$\text{Cov}[\text{vec}(\mathcal{Y}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n. \quad (11.103)$$

A forma vetorizada explicita a estrutura conjunta de covariâncias das respostas e fornece uma representação conveniente para resultados que envolvem vec e produtos de Kronecker.

11.8.2 Distribuição normal matricial em forma geral

A distribuição normal matricial expressa uma distribuição normal no espaço vetorial das matrizes por meio da vetorização. A notação

$$N_{n \times p}(\Xi, \mathbf{U}, \mathbf{V})$$

representa a estrutura separável em que a covariância de $\text{vec}(\mathcal{A})$ é $\mathbf{V} \otimes \mathbf{U}$ (Eaton, 2007).

Definição 11.17 (Distribuição normal matricial). *Se*

$$\mathcal{A} \in \mathbb{R}^{n \times p},$$

diz-se que

$$\mathcal{A} \sim N_{n \times p}(\Xi, \mathbf{U}, \mathbf{V})$$

quando

$$\text{vec}(\mathcal{A}) \sim N_{np}[\text{vec}(\Xi), \mathbf{V} \otimes \mathbf{U}]. \quad (11.104)$$

Aqui,

$$\Xi \in \mathbb{R}^{n \times p}, \quad \mathbf{U} \in \mathbb{R}^{n \times n}, \quad \mathbf{V} \in \mathbb{R}^{p \times p},$$

com

$$\mathbf{U} \succeq \mathbf{0} \quad \text{e} \quad \mathbf{V} \succeq \mathbf{0}.$$

A distribuição normal multivariada utilizada no lado direito de Equação 11.104 é a distribuição definida em Definição 9.1.

No modelo linear normal multivariado, a estrutura conjunta das unidades corresponde ao caso

$$\mathbf{U} = \mathbf{I}_n$$

e

$$\mathbf{V} = \Sigma.$$

A matriz $\mathbf{I}_n$ representa a ausência de covariâncias cruzadas entre unidades, enquanto Σ representa a covariância residual entre as respostas de uma mesma unidade.

11.8.3 Formulação matricial conjunta do modelo normal

A formulação por unidade de Definição 11.6 pode ser representada conjuntamente por meio de Definição 11.17:

$$\mathcal{E} \mid \mathbf{Z} \sim N_{n \times p}(\mathbf{0}_{n \times p}, \mathbf{I}_n, \Sigma). \quad (11.105)$$

Equivalentemente,

$$\mathcal{Y} \mid \mathbf{Z} \sim N_{n \times p}(\mathbf{Z}\mathbf{B}, \mathbf{I}_n, \Sigma). \quad (11.106)$$

Pela definição da normal matricial e pela identidade de vetorização em Proposição 7.14,

$$\text{vec}(\mathcal{Y}) \mid \mathbf{Z} \sim N_{np} \left[(\mathbf{I}_p \otimes \mathbf{Z}) \text{vec}(\mathbf{B}), \Sigma \otimes \mathbf{I}_n \right]. \quad (11.107)$$

Essa representação é equivalente à formulação por unidade de Equação 11.16 e explicita conjuntamente as covariâncias entre respostas e unidades.

11.8.4 Transformações lineares das respostas

Considere uma transformação linear das respostas dada por

$$\mathbf{W}_i = \mathbf{A}^\top \mathbf{Y}_i,$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times s}.$$

Em forma matricial,

$$\mathcal{W} = \mathcal{Y} \mathbf{A}.$$

Como

$$\mathcal{Y} = \mathbf{Z} \mathbf{B} + \mathcal{E},$$

segue que

$$\mathcal{W} = \mathbf{Z} (\mathbf{B} \mathbf{A}) + \mathcal{E} \mathbf{A}. \quad (11.108)$$

A matriz de parâmetros da resposta transformada é

$$\mathbf{B}_W = \mathbf{B} \mathbf{A},$$

e sua matriz de covariâncias residuais é

$$\Sigma_W = \mathbf{A}^\top \Sigma \mathbf{A},$$

em concordância com Proposição 8.6.

Sob o modelo linear normal multivariado,

$$\mathcal{W} \mid \mathbf{Z} \sim N_{n \times s}(\mathbf{ZBA}, \mathbf{I}_n, \mathbf{A}^\top \Sigma \mathbf{A}). \quad (11.109)$$

Portanto, combinações lineares das respostas permanecem na classe dos modelos lineares multivariados, com parâmetros e covariância residual transformados por $\mathbf{A}$.

11.8.5 Formulação por colunas da matriz de respostas

Para uma resposta específica j , a coluna correspondente satisfaz

$$\mathbf{Y}_{\cdot j} \mid \mathbf{Z} \sim N_n(\mathbf{Z}\beta_j, \sigma_{jj}\mathbf{I}_n). \quad (11.110)$$

Para duas respostas j e k ,

$$\text{Cov}(\mathbf{Y}_{\cdot j}, \mathbf{Y}_{\cdot k} \mid \mathbf{Z}) = \sigma_{jk}\mathbf{I}_n. \quad (11.111)$$

Assim, ajustar separadamente as p equações produz os mesmos estimadores de mínimos quadrados quando todas utilizam a mesma matriz $\mathbf{Z}$. A formulação conjunta preserva explicitamente as covariâncias σ_{jk} entre respostas distintas.

11.8.6 Momentos do estimador da matriz de parâmetros

Substituindo

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E}$$

em Equação 11.24,

$$\begin{aligned} \widehat{\mathbf{B}} &= (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top (\mathbf{ZB} + \mathcal{E}) \\ &= \mathbf{B} + (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathcal{E}. \end{aligned} \quad (11.112)$$

A segunda parcela representa o erro de estimação.

Proposição 11.9 (Esperança e covariância do estimador da matriz de parâmetros). *Considere*

$$E(\mathcal{E} \mid \mathbf{Z}) = \mathbf{0}$$

e

$$\text{Cov}[\text{vec}(\mathcal{E}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n.$$

Se

$$\text{posto}(\mathbf{Z}) = q,$$

então

$$E(\widehat{\mathbf{B}} \mid \mathbf{Z}) = \mathbf{B} \tag{11.113}$$

e

$$\text{Cov}[\text{vec}(\widehat{\mathbf{B}}) \mid \mathbf{Z}] = \Sigma \otimes (\mathbf{Z}^\top \mathbf{Z})^{-1}. \tag{11.114}$$

i Demonstração

De Equação 11.112 e da condição

$$E(\mathcal{E} \mid \mathbf{Z}) = \mathbf{0},$$

segue imediatamente que

$$E(\widehat{\mathbf{B}} \mid \mathbf{Z}) = \mathbf{B}.$$

Para a covariância, defina

$$\mathbf{A}_Z = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top.$$

Então,

$$\widehat{\mathbf{B}} - \mathbf{B} = \mathbf{A}_Z \mathcal{E}.$$

Pela identidade de vetorização em Proposição 7.14,

$$\text{vec}(\widehat{\mathbf{B}} - \mathbf{B}) = (\mathbf{I}_p \otimes \mathbf{A}_Z) \text{vec}(\mathcal{E}).$$

Aplicando a estrutura de covariâncias dos erros,

$$\text{Cov}[\text{vec}(\widehat{\mathbf{B}}) \mid \mathbf{Z}] = \Sigma \otimes (\mathbf{A}_Z \mathbf{A}_Z^\top).$$

Como

$$\mathbf{A}_Z \mathbf{A}_Z^\top = (\mathbf{Z}^\top \mathbf{Z})^{-1},$$

obtém-se Equação 11.114.

O resultado mostra duas fontes distintas de variabilidade:

$$\Sigma$$

descreve a variabilidade residual e a associação entre as respostas, enquanto

$$(\mathbf{Z}^\top \mathbf{Z})^{-1}$$

descreve a contribuição do delineamento para a precisão dos coeficientes.

11.8.7 Covariâncias entre estimadores de respostas

Para duas respostas j e k ,

$$\text{Cov}(\hat{\beta}_j, \hat{\beta}_k | \mathbf{Z}) = \sigma_{jk} (\mathbf{Z}^\top \mathbf{Z})^{-1}. \quad (11.115)$$

Para $j = k$,

$$\text{Cov}(\hat{\beta}_j | \mathbf{Z}) = \sigma_{jj} (\mathbf{Z}^\top \mathbf{Z})^{-1}. \quad (11.116)$$

Assim, estimadores associados a respostas diferentes são correlacionados sempre que os erros dessas respostas apresentam covariância residual diferente de zero.

11.8.8 Mínimos quadrados e máxima verossimilhança

Sob o modelo linear normal multivariado, a log-verossimilhança para uma matriz observada de respostas $\mathbf{Y}$ pode ser escrita, com const independente de $\mathbf{B}$ e Σ , como

$$\begin{aligned} \ell(\mathbf{B}, \Sigma; \mathbf{Y}) = \text{const} - \frac{n}{2} \log \det(\Sigma) \\ - \frac{1}{2} \text{tr} \left[\Sigma^{-1} (\mathbf{Y} - \mathbf{ZB})^\top (\mathbf{Y} - \mathbf{ZB}) \right]. \end{aligned} \quad (11.117)$$

Para $\Sigma \succ \mathbf{0}$ fixada, o primeiro termo não depende de $\mathbf{B}$. Portanto, maximizar a log-verossimilhança em relação a $\mathbf{B}$ equivale a minimizar o termo quadrático residual.

Aplicando ao termo quadrático residual o procedimento de diferenciação matricial utilizado em Proposição 7.5, obtém-se

$$\mathbf{Z}^\top (\mathbf{Y} - \mathbf{ZB}) \Sigma^{-1} = \mathbf{0}.$$

Como Σ é invertível,

$$\mathbf{Z}^\top (\mathbf{Y} - \mathbf{ZB}) = \mathbf{0},$$

que coincide com a equação normal de mínimos quadrados em Equação 11.21.

Proposição 11.10 (Mínimos quadrados e máxima verossimilhança). *Considere o modelo linear normal multivariado com*

$$\text{posto}(\mathbf{Z}) = q.$$

Para qualquer $\Sigma \succ \mathbf{0}$ fixada, o maximizador da verossimilhança em relação a $\mathbf{B}$ é

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}.$$

Consequentemente, sempre que o estimador de máxima verossimilhança conjunto de

$$(\mathbf{B}, \Sigma)$$

existir no espaço paramétrico considerado,

$$\widehat{\mathbf{B}}_{\text{MV}} = \widehat{\mathbf{B}}. \quad (11.118)$$

A coincidência ocorre porque todas as respostas utilizam a mesma matriz de delineamento $\mathbf{Z}$ e porque Σ atua sobre a dependência entre as respostas, não sobre a estrutura entre as unidades.

Assim, Σ determina a covariância conjunta dos coeficientes estimados, mas não modifica a expressão de $\widehat{\mathbf{B}}$.

Esse resultado depende da estrutura do modelo e não se transfere automaticamente para situações em que as respostas utilizam delineamentos diferentes ou em que existe dependência residual entre unidades.

A estimação de máxima verossimilhança de Σ a partir da SQPC residual é apresentada em Equação 11.144.

11.8.9 Modelo contendo somente intercepto

11.8.9.1 Estimação da média

O modelo mais simples ocorre quando todas as unidades possuem o mesmo vetor de médias:

$$\mathbf{Y}_i = \mu + \varepsilon_i, \quad i = 1, \dots, n. \quad (11.119)$$

Nesse caso,

$$\mathbf{Z} = \mathbf{1}_n$$

e

$$\mathbf{B} = \mu^\top.$$

Como

$$\mathbf{Z}^\top \mathbf{Z} = n,$$

tem-se

$$\widehat{\mathbf{B}} = \frac{1}{n} \mathbf{1}_n^\top \mathbf{y} = \bar{\mathbf{Y}}^\top. \quad (11.120)$$

Após a observação,

$$\widehat{\mathbf{B}}_{\text{obs}} = \bar{\mathbf{y}}^\top.$$

Portanto, Equação 11.120 recupera o estimador do vetor de médias estudado em Proposição 10.3.

Além disso,

$$\text{Cov}(\bar{\mathbf{Y}}) = \frac{\Sigma}{n},$$

recuperando diretamente Equação 10.40.

O modelo contendo somente intercepto é, assim, um caso particular do problema de estimação desenvolvido no Capítulo 10. No modelo linear multivariado geral, a única média comum é substituída por vetores de médias que podem variar entre as unidades de acordo com os respectivos vetores de delineamento $\mathbf{z}_i$.

11.8.9.2 SQPC residual e covariância

Considere

$$\mathbf{Z} = \mathbf{1}_n.$$

Nesse caso,

$$r = 1,$$

$$\mathbf{P}_Z = \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top$$

e

$$\mathbf{M}_Z = \mathbf{H}_n.$$

Logo,

$$\widehat{\mathbf{U}} = \mathbf{H}_n \mathbf{Y},$$

e a SQPC residual observada é

$$\begin{aligned} \mathbf{E} &= \mathbf{Y}^\top \mathbf{H}_n \mathbf{Y} \\ &= \sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}}) (\mathbf{y}_i - \bar{\mathbf{y}})^\top. \end{aligned} \quad (11.121)$$

Essa matriz é exatamente a SQPC total observada

$$\mathbf{T}$$

definida em Definição 8.9 e correspondente à realização da estatística aleatória definida em Definição 10.9.

Como

$$n - r = n - 1,$$

obtem-se

$$\widehat{\Sigma}_{\text{obs}} = \frac{\mathbf{E}}{n - 1} = \mathbf{S}, \quad (11.122)$$

recuperando Definição 10.10.

Sob normalidade e quando a SQPC possui posto completo,

$$\widehat{\Sigma}_{\text{MV,obs}} = \frac{\mathbf{E}}{n},$$

em concordância com Equação 10.32.

Portanto, no modelo contendo somente intercepto,

$$\mathbf{E} = \mathbf{T}$$

e

$$\frac{\mathbf{E}}{n-1} = \mathbf{S}.$$

Assim, a SQPC residual e o estimador não viesado da covariância residual recuperam exatamente os objetos estudados nos Capítulos 8 e 10. O modelo linear multivariado substitui a remoção de uma única média pela remoção de toda a estrutura de médias representada por

$$\mathcal{C}(\mathbf{Z}).$$

Quando $\mathbf{1}_n \in \mathcal{C}(\mathbf{Z})$, a SQPC residual integra a decomposição estabelecida em Proposição 11.5.

11.8.10 Esperança dos valores ajustados e dos resíduos

Proposição 11.11 (Esperança dos valores ajustados e dos resíduos). *Sob*

$$E(\mathcal{E} \mid \mathbf{Z}) = \mathbf{0},$$

tem-se

$$E(\hat{\mathcal{Y}} \mid \mathbf{Z}) = \mathbf{ZB} \tag{11.123}$$

e

$$E(\hat{\mathcal{U}} \mid \mathbf{Z}) = \mathbf{0}. \tag{11.124}$$

De fato,

$$\begin{aligned} E(\hat{\mathcal{Y}} \mid \mathbf{Z}) &= \mathbf{P}_Z E(\mathcal{Y} \mid \mathbf{Z}) \\ &= \mathbf{P}_Z \mathbf{ZB} \\ &= \mathbf{ZB}, \end{aligned}$$

enquanto

$$\begin{aligned} E(\hat{\mathcal{U}} \mid \mathbf{Z}) &= \mathbf{M}_Z \mathbf{ZB} \\ &= \mathbf{0}. \end{aligned}$$

Os valores ajustados são, portanto, não viesados para a matriz de médias representável pelo modelo, enquanto os resíduos possuem média condicional nula.

11.8.11 Covariâncias dos valores ajustados e dos resíduos

A forma vetorizada permite obter diretamente suas matrizes de covariâncias.

Como

$$\text{vec}(\mathbf{P}_Z \mathcal{E}) = (\mathbf{I}_p \otimes \mathbf{P}_Z) \text{vec}(\mathcal{E}),$$

tem-se

Proposição 11.12 (Covariâncias dos valores ajustados e dos resíduos). *Sob*

$$\text{Cov}[\text{vec}(\mathcal{E}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n,$$

vale

$$\text{Cov}[\text{vec}(\hat{\mathcal{Y}}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{P}_Z \quad (11.125)$$

e

$$\text{Cov}[\text{vec}(\hat{\mathcal{U}}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{M}_Z. \quad (11.126)$$

Além disso,

$$\text{Cov}[\text{vec}(\hat{\mathcal{Y}}), \text{vec}(\hat{\mathcal{U}}) \mid \mathbf{Z}] = \mathbf{0}. \quad (11.127)$$

A última igualdade decorre de

$$\mathbf{P}_Z \mathbf{M}_Z = \mathbf{0}.$$

Os valores ajustados e os resíduos são, portanto, não correlacionados. Sob o modelo normal matricial, eles são conjuntamente normais e, conseqüentemente, independentes. Essa independência decorre da normalidade conjunta e da ortogonalidade dos projetores $\mathbf{P}_Z$ e $\mathbf{M}_Z$.

As matrizes

$$\Sigma \otimes \mathbf{P}_Z$$

e

$$\Sigma \otimes \mathbf{M}_Z$$

também mostram que o ajuste pode induzir dependência entre valores ajustados ou resíduos associados a unidades distintas. Embora os erros originais sejam não correlacionados entre unidades, os valores ajustados e os resíduos resultam de projeções que utilizam conjuntamente todas as observações.

A análise de medidas de influência e alavancagem pertence ao diagnóstico de modelos e não será desenvolvida neste capítulo.

11.8.12 Modelos sem intercepto

Se

$$\mathbf{1}_n \notin \mathcal{C}(\mathbf{Z}),$$

a SQPC do modelo definida em Definição 11.13 não possui a interpretação projetiva utilizada em Proposição 11.5, porque $\mathbf{P}_Z - \mathbf{P}_1$ não é, em geral, um projetor.

Permanece válida a decomposição em relação à origem,

$$\mathbf{Y}^\top \mathbf{Y} = \mathbf{Y}^\top \mathbf{P}_Z \mathbf{Y} + \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y}. \quad (11.128)$$

Essa identidade não deve ser interpretada como uma decomposição da dispersão em torno da média amostral. A decomposição corrigida

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E}$$

requer $\mathbf{1}_n \in \mathcal{C}(\mathbf{Z})$.

11.8.13 Parametrizações equivalentes

Definição 11.18 (Matrizes de parâmetros equivalentes). Duas matrizes

$$\mathbf{B}_1, \mathbf{B}_2 \in \mathbb{R}^{q \times p}$$

são equivalentes em relação a $\mathbf{Z}$ quando

$$\mathbf{Z}\mathbf{B}_1 = \mathbf{Z}\mathbf{B}_2. \quad (11.129)$$

A caracterização da estimabilidade em Proposição 11.7 também pode ser expressa em termos de matrizes de parâmetros equivalentes.

Se

$$\mathbf{Z}\mathbf{B}_1 = \mathbf{Z}\mathbf{B}_2,$$

então

$$\mathbf{C}\mathbf{B}$$

é estimável se

$$\mathbf{C}\mathbf{B}_1 = \mathbf{C}\mathbf{B}_2$$

para todas as matrizes de parâmetros equivalentes.

Isso ocorre precisamente porque $\mathbf{C}$ elimina as componentes pertencentes ao núcleo de $\mathbf{Z}$.

Diferentes matrizes de delineamento podem representar o mesmo conjunto de estruturas de médias.

Se

$$\mathcal{C}(\mathbf{Z}_1) = \mathcal{C}(\mathbf{Z}_2), \quad (11.130)$$

então

$$\mathbf{P}_{\mathbf{Z}_1} = \mathbf{P}_{\mathbf{Z}_2},$$

e, para a mesma matriz de respostas, os dois modelos produzem os mesmos valores ajustados, resíduos e SQPC residual.

Essa situação ocorre, por exemplo, quando um fator é representado por diferentes sistemas de codificação. Os coeficientes individuais podem mudar de interpretação, mas as médias ajustadas e os contrastes estimáveis permanecem os mesmos.

O objeto que caracteriza a estrutura de médias é, portanto,

$$\mathcal{C}(\mathbf{Z}),$$

e não uma lista específica de coeficientes.

Deficiência de posto e mau condicionamento são problemas distintos. A deficiência de posto corresponde a dependências lineares exatas entre as colunas de $\mathbf{Z}$; o mau condicionamento pode ocorrer mesmo com posto completo e tornar os coeficientes sensíveis a pequenas perturbações. O número de condição definido em Definição 6.9 e a SVD definida em Definição 6.3 podem ser utilizados no diagnóstico desse problema.

11.8.14 Caso escalar da hipótese bilateral

Se

$$g = s = 1,$$

obtém-se a hipótese escalar

$$H_0 : \mathbf{c}_1^\top \mathbf{B} \mathbf{c}_2 = \theta_0. \quad (11.131)$$

No caso escalar, com uma combinação das linhas de $\mathbf{B}$ definida por $\mathbf{c}_1$ e uma combinação das respostas definida por $\mathbf{c}_2$,

$$\text{Var}(\mathbf{c}_1^\top \widehat{\mathbf{B}} \mathbf{c}_2 \mid \mathbf{Z}) = \left[\mathbf{c}_1^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{c}_1 \right] (\mathbf{c}_2^\top \Sigma \mathbf{c}_2), \quad (11.132)$$

quando $\mathbf{Z}$ possui posto coluna completo.

A primeira parcela depende do delineamento e da combinação dos coeficientes especificada por $\mathbf{c}_1$; a segunda depende da variabilidade residual da combinação de respostas especificada por $\mathbf{c}_2$.

11.8.15 Modelos encaixados

Uma hipótese sobre uma parte da estrutura de médias também pode ser representada pela comparação entre um modelo completo e um modelo reduzido (Johnson; Wichern, 2002).

Considere matrizes de delineamento $\mathbf{Z}_F$ e $\mathbf{Z}_R$ tais que

$$\mathcal{C}(\mathbf{Z}_R) \subseteq \mathcal{C}(\mathbf{Z}_F). \quad (11.133)$$

O modelo reduzido representa um subconjunto das estruturas de médias disponíveis no modelo completo.

Defina

$$r_F = \text{posto}(\mathbf{Z}_F) \quad \text{e} \quad r_R = \text{posto}(\mathbf{Z}_R).$$

Seus projetores são

$$\mathbf{P}_F = \mathbf{Z}_F \mathbf{Z}_F^+$$

e

$$\mathbf{P}_R = \mathbf{Z}_R \mathbf{Z}_R^+.$$

Como os espaços são encaixados,

$$\mathbf{P}_F - \mathbf{P}_R$$

é o projetor sobre as direções acrescentadas pelo modelo completo e possui posto

$$\text{posto}(\mathbf{P}_F - \mathbf{P}_R) = r_F - r_R. \quad (11.134)$$

As SQPCs residuais são

$$\mathbf{E}_F = \mathbf{Y}^\top (\mathbf{I}_n - \mathbf{P}_F) \mathbf{Y}$$

e

$$\mathbf{E}_R = \mathbf{Y}^\top (\mathbf{I}_n - \mathbf{P}_R) \mathbf{Y}.$$

Proposição 11.13 (Decomposição das SQPCs de modelos encaixados). *Se*

$$\mathcal{C}(\mathbf{Z}_R) \subseteq \mathcal{C}(\mathbf{Z}_F),$$

e $\mathbf{P}_R$ e $\mathbf{P}_F$ são os projetores sobre os espaços dos modelos reduzido e completo, respectivamente, então

$$\mathbf{E}_R = \mathbf{H} + \mathbf{E}_F, \quad (11.135)$$

em que

$$\mathbf{H} = \mathbf{Y}^\top (\mathbf{P}_F - \mathbf{P}_R) \mathbf{Y}. \quad (11.136)$$

Equivalentemente,

$$\mathbf{H} = \mathbf{E}_R - \mathbf{E}_F. \quad (11.137)$$

Portanto, $\mathbf{H}$ mede a redução da SQPC residual obtida quando as direções presentes no modelo completo são acrescentadas ao modelo reduzido.

Os graus de liberdade correspondentes são

$$\nu_H = r_F - r_R \quad (11.138)$$

e

$$\nu_E = n - r_F. \quad (11.139)$$

A formulação por $\mathbf{C}_1 \mathbf{B} \mathbf{C}_2$ identifica a função paramétrica examinada; a formulação por modelos encaixados mostra quanto a ampliação do espaço do modelo reduz a SQPC residual.

11.8.16 Modelos encaixados para combinações de respostas

Para combinações de respostas definidas por $\mathbf{C}_2$, defina

$$\mathbf{E}_{R,C_2} = \mathbf{C}_2^\top \mathbf{E}_R \mathbf{C}_2,$$

$$\mathbf{H}_{C_2} = \mathbf{C}_2^\top \mathbf{H} \mathbf{C}_2$$

e

$$\mathbf{E}_{F,C_2} = \mathbf{C}_2^\top \mathbf{E}_F \mathbf{C}_2. \quad (11.140)$$

Aplicando a transformação por $\mathbf{C}_2$ a Equação 11.135, obtém-se

$$\mathbf{E}_{R,C_2} = \mathbf{H}_{C_2} + \mathbf{E}_{F,C_2}.$$

Assim, a decomposição entre a SQPC adicional e a SQPC residual do modelo completo é preservada para as mesmas combinações de respostas.

11.8.17 SQPC residual de combinações das respostas

Para

$$\mathbf{a} \in \mathbb{R}^p,$$

considere a combinação linear das respostas

$$\mathbf{Y}\mathbf{a}.$$

Seu vetor de resíduos é

$$\hat{\mathbf{u}}_{\mathbf{a}} = \mathbf{M}_Z \mathbf{Y}\mathbf{a} = \widehat{\mathbf{U}}\mathbf{a},$$

e

$$\hat{\mathbf{u}}_{\mathbf{a}}^\top \hat{\mathbf{u}}_{\mathbf{a}} = \mathbf{a}^\top \mathbf{E}\mathbf{a}. \quad (11.141)$$

Se as respostas forem transformadas por

$$\mathbf{Y}^* = \mathbf{Y}\mathbf{A}, \quad \mathbf{A} \in \mathbb{R}^{p \times s},$$

então

$$\widehat{\mathbf{U}}^* = \widehat{\mathbf{U}}\mathbf{A}$$

e

$$\mathbf{E}^* = \mathbf{A}^\top \mathbf{E} \mathbf{A}. \quad (11.142)$$

Essa transformação é a contraparte amostral da regra populacional

$$\Sigma^* = \mathbf{A}^\top \Sigma \mathbf{A},$$

preservando na SQPC residual as mesmas combinações lineares aplicadas às respostas.

11.8.18 Estimador de máxima verossimilhança da covariância residual

Sob o modelo linear normal multivariado, depois da maximização em relação à estrutura de médias, a parte da log-verossimilhança que depende de Σ é, a menos de constantes,

$$\ell_c(\Sigma) = -\frac{n}{2} \log \det(\Sigma) - \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{E}). \quad (11.143)$$

Quando

$$\mathbf{E} \succ \mathbf{0},$$

o máximo no espaço

$$\Sigma \succ \mathbf{0}$$

é alcançado em

$$\widehat{\Sigma}_{\text{MV,obs}} = \frac{\mathbf{E}}{n}. \quad (11.144)$$

Assim, o divisor $n - r$ produz o estimador não viesado, enquanto o divisor n é utilizado pela máxima verossimilhança sob normalidade e existência do máximo. Essa relação generaliza Equação 10.57, na qual os divisores correspondentes são $n - 1$ e n .

Existência do estimador de máxima verossimilhança

A expressão

$$\frac{\mathbf{E}}{n}$$

é a estimativa de máxima verossimilhança de Σ no modelo normal não singular somente quando

$$\mathbf{E} \succ \mathbf{0}.$$

Se $\mathbf{E}$ é singular, a verossimilhança não possui máximo no interior do espaço

$$\Sigma \succ \mathbf{0}.$$

A matriz $\mathbf{E}/n$ continua sendo calculável, mas perde essa interpretação de máxima verossimilhança no modelo positivo definido.

11.8.19 Viés do estimador de máxima verossimilhança da covariância residual

Como

$$E(\mathbf{E}_{\text{res}} | \mathbf{Z}) = (n - r)\Sigma,$$

a estatística com divisor n satisfaz

$$E\left(\frac{\mathbf{E}_{\text{res}}}{n} | \mathbf{Z}\right) = \frac{n - r}{n}\Sigma.$$

Portanto, seu viés é

$$-\frac{r}{n}\Sigma.$$

11.8.20 Formas equivalentes da decomposição da variação

A decomposição de Equação 11.63 admite representações equivalentes em termos das observações e dos valores ajustados. A SQPC total pode ser escrita como

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}})(\mathbf{y}_i - \bar{\mathbf{y}})^{\top}, \quad (11.145)$$

com

$$\bar{\mathbf{y}} = \frac{1}{n} \mathbf{Y}^\top \mathbf{1}_n.$$

A matriz $\mathbf{T}$ descreve a dispersão conjunta das respostas antes da remoção da estrutura explicada pelo delineamento.

Se

$$\widehat{\mathbf{Y}} = \mathbf{P}_Z \mathbf{Y},$$

então os valores ajustados centralizados são

$$\widehat{\mathbf{Y}}_c = \widehat{\mathbf{Y}} - \mathbf{1}_n \bar{\mathbf{y}}^\top = (\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y}.$$

Logo,

$$\mathbf{T}_{\text{mod}} = \widehat{\mathbf{Y}}_c^\top \widehat{\mathbf{Y}}_c. \quad (11.146)$$

Para qualquer combinação linear das respostas,

$$\mathbf{a}^\top \mathbf{T}_{\text{mod}} \mathbf{a} = \|(\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y} \mathbf{a}\|^2. \quad (11.147)$$

Portanto, $\mathbf{T}_{\text{mod}}$ reúne, para todas as combinações lineares das respostas, as somas de quadrados dos valores ajustados em torno da respectiva média geral.

A decomposição pode ser escrita também como

$$\begin{aligned} & \sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}}) (\mathbf{y}_i - \bar{\mathbf{y}})^\top \\ &= \sum_{i=1}^n (\hat{\mathbf{y}}_i - \bar{\mathbf{y}}) (\hat{\mathbf{y}}_i - \bar{\mathbf{y}})^\top \\ & \quad + \sum_{i=1}^n (\mathbf{y}_i - \hat{\mathbf{y}}_i) (\mathbf{y}_i - \hat{\mathbf{y}}_i)^\top. \end{aligned} \quad (11.148)$$

A primeira parcela à direita é $\mathbf{T}_{\text{mod}}$ e a segunda é $\mathbf{E}$.

11.8.21 Decomposição para combinações lineares das respostas

A decomposição matricial contém, simultaneamente, as decomposições correspondentes a todas as combinações lineares das respostas.

Para

$$\mathbf{a} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{a}^\top \mathbf{T} \mathbf{a} = \mathbf{a}^\top \mathbf{T}_{\text{mod}} \mathbf{a} + \mathbf{a}^\top \mathbf{E} \mathbf{a}. \quad (11.149)$$

Cada termo possui interpretação univariada:

$$\mathbf{a}^\top \mathbf{T} \mathbf{a}$$

é a soma de quadrados total de $\mathbf{Y}\mathbf{a}$,

$$\mathbf{a}^\top \mathbf{T}_{\text{mod}} \mathbf{a}$$

é a soma de quadrados associada ao modelo, e

$$\mathbf{a}^\top \mathbf{E} \mathbf{a}$$

é a soma de quadrados residual.

A identidade mostra que a decomposição matricial contém simultaneamente as decomposições univariadas de todas as combinações lineares $\mathbf{Y}\mathbf{a}$. As formas quadráticas correspondentes fornecem as parcelas associada ao modelo e residual para cada combinação.

11.8.22 Postos das matrizes na decomposição da variação

Os postos das matrizes da decomposição em Equação 11.63 são limitados pelos postos dos projetores correspondentes:

$$\text{posto}(\mathbf{T}) \leq \min(p, n - 1),$$

$$\text{posto}(\mathbf{T}_{\text{mod}}) \leq \min(p, r - 1),$$

e

$$\text{posto}(\mathbf{E}) \leq \min(p, n - r). \quad (11.150)$$

11.9 Aprofundamento metodológico e aplicado

11.9.1 Representação dos ajustes e resíduos

A Figura 11.1 apresenta um modelo com uma variável explicativa e duas respostas. As duas colunas da matriz de respostas utilizam o mesmo espaço de ajuste, mas possuem coeficientes e resíduos próprios.

Os segmentos verticais representam os resíduos de cada resposta. O mesmo projetor $\mathbf{P}_Z$ determina as posições ajustadas nas duas colunas, enquanto a associação residual entre as respostas não é representada diretamente nos painéis.

A associação residual entre as respostas aparece nos elementos fora da diagonal de $\mathbf{E}$ e, após a divisão por $n - r$, de $\hat{\Sigma}_{\text{obs}}$.

11.9.2 Interpretação da covariância residual estimada

Componente a componente,

$$\hat{\sigma}_{jk, \text{obs}} = \frac{e_{jk}}{n - r}. \quad (11.151)$$

Assim,

$$\hat{\sigma}_{jj, \text{obs}} = \frac{1}{n - r} \sum_{i=1}^n \hat{u}_{ij}^2$$




Figura 11.1: Valores observados, retas ajustadas e resíduos para duas respostas modeladas pela mesma variável explicativa.

estima a variância residual da resposta j , enquanto, para $j \neq k$,

$$\hat{\sigma}_{jk,\text{obs}} = \frac{1}{n-r} \sum_{i=1}^n \hat{u}_{ij} \hat{u}_{ik}$$

estima a covariância residual entre as respostas j e k .

Se as variâncias residuais estimadas são positivas, defina

$$\mathbf{D} = \text{diag}(\hat{\sigma}_{11,\text{obs}}, \dots, \hat{\sigma}_{pp,\text{obs}}).$$

A matriz de correlações residuais estimada é

$$\widehat{\mathbf{R}}_{\text{res}} = \mathbf{D}^{-1/2} \widehat{\Sigma}_{\text{obs}} \mathbf{D}^{-1/2}.$$

11.9.3 Representação geométrica da decomposição no modelo de grupos

A Figura 11.2 representa geometricamente a decomposição

$$\mathbf{T} = \mathbf{T}_{\text{entre}} + \mathbf{T}_{\text{intra}}$$

de Equação 11.70. Os segmentos que ligam cada observação à média de seu grupo representam os desvios intragrupos, enquanto os segmentos tracejados que ligam as médias dos grupos à média geral representam os deslocamentos associados à dispersão entre grupos.




Figura 11.2: Dispersão intragrupos e deslocamento das médias dos grupos em relação à média geral.

As cruzes representam as médias dos grupos e o asterisco representa a média geral. Os segmentos internos aos grupos visualizam os termos associados a $\mathbf{T}_{\text{intra}}$, enquanto os deslocamentos das médias dos grupos em relação à média geral visualizam a estrutura associada a $\mathbf{T}_{\text{entre}}$.

11.9.4 Casos adicionais de hipóteses lineares

11.9.4.1 Hipótese sobre uma combinação das respostas

Para

$$\mathbf{c}_1 \in \mathbb{R}^q$$

e

$$\mathbf{c}_2 \in \mathbb{R}^p,$$

suponha que

$$\mathbf{c}_1^\top = \mathbf{c}_1^\top \mathbf{Z}^+ \mathbf{Z},$$

de modo que $\mathbf{c}_1^\top \mathbf{B}$ seja estimável. A hipótese

$$H_0 : \mathbf{c}_1^\top \mathbf{B} \mathbf{c}_2 = 0 \quad (11.152)$$

examina a função paramétrica $\mathbf{c}_1^\top \mathbf{B} \mathbf{c}_2$ associada à combinação de respostas definida por $\mathbf{c}_2$.

Por exemplo,

$$\mathbf{c}_2 = \mathbf{e}_j - \mathbf{e}_k$$

representa a diferença entre as respostas j e k .

11.9.4.2 Igualdade de coeficientes em duas respostas

Tomando

$$\mathbf{C}_1 = \mathbf{e}_h^\top$$

e

$$\mathbf{C}_2 = \mathbf{e}_j - \mathbf{e}_k,$$

obtém-se

$$H_0 : \mathbf{e}_h^\top \mathbf{B} (\mathbf{e}_j - \mathbf{e}_k) = 0, \quad (11.153)$$

equivalente a

$$H_0 : \beta_{hj} = \beta_{hk}.$$

A matriz $\mathbf{C}_1$ forma combinações lineares das linhas de $\mathbf{B}$, enquanto $\mathbf{C}_2$ seleciona ou combina respostas.

11.9.5 Exemplo integrado

Exemplo 11.1 (Regressão multivariada com uma covariável e duas respostas). Considere seis unidades. Para cada unidade, registra-se uma variável explicativa quantitativa x e duas respostas Y_1 e Y_2 .

Unidade	x	Y_1	Y_2
1	1	3	8
2	2	5	7
3	3	4	7
4	4	8	5
5	5	9	4
6	6	11	3

A matriz observada de respostas é

$$\mathbf{Y} = \begin{bmatrix} 3 & 8 \\ 5 & 7 \\ 4 & 7 \\ 8 & 5 \\ 9 & 4 \\ 11 & 3 \end{bmatrix},$$

e a matriz de delineamento, contendo intercepto e a covariável, é

$$\mathbf{Z} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \\ 1 & 6 \end{bmatrix}. \quad (11.154)$$

Nesse modelo,

$$\mathbf{B} = \begin{bmatrix} \beta_{01} & \beta_{02} \\ \beta_{11} & \beta_{12} \end{bmatrix},$$

em que a primeira linha contém os interceptos e a segunda contém os coeficientes associados a x nas duas respostas.

Como

$$q = 2$$

e

$$\text{posto}(\mathbf{Z}) = 2,$$

a matriz de delineamento possui posto coluna completo. Portanto, $\mathbf{Z}^\top \mathbf{Z}$ é invertível e a estimativa de mínimos quadrados de $\mathbf{B}$ é única.

Tem-se

$$\mathbf{Z}^\top \mathbf{Z} = \begin{bmatrix} 6 & 21 \\ 21 & 91 \end{bmatrix}$$

e

$$(\mathbf{Z}^\top \mathbf{Z})^{-1} = \frac{1}{105} \begin{bmatrix} 91 & -21 \\ -21 & 6 \end{bmatrix}.$$

Estimação da matriz de parâmetros

A estimativa de mínimos quadrados é

$$\widehat{\mathbf{B}}_{\text{obs}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}.$$

Numericamente,

$$\widehat{\mathbf{B}}_{\text{obs}} = \begin{bmatrix} 16/15 & 139/15 \\ 8/5 & -36/35 \end{bmatrix} \approx \begin{bmatrix} 1,067 & 9,267 \\ 1,600 & -1,029 \end{bmatrix}. \quad (11.155)$$

Portanto, as equações ajustadas são

$$\widehat{Y}_1 = 1,067 + 1,600x$$

e

$$\widehat{Y}_2 = 9,267 - 1,029x.$$

Para um aumento de uma unidade em x , a média ajustada de Y_1 aumenta em aproximadamente 1,600, enquanto a média ajustada de Y_2 diminui em aproximadamente 1,029.

A Figura 11.3 mostra simultaneamente as duas respostas, seus ajustes e os respectivos resíduos.




Figura 11.3: Respostas observadas, ajustes lineares e resíduos do exemplo integrado.

A figura evidencia as inclinações em sentidos opostos das duas respostas. Os segmentos tracejados ligam cada observação ao valor ajustado correspondente e representam os resíduos que compõem a matriz $\widehat{U}$.

A matriz de valores ajustados é

$$\widehat{\mathbf{Y}} = \mathbf{Z}\widehat{\mathbf{B}}_{\text{obs}} \approx \begin{bmatrix} 2,667 & 8,238 \\ 4,267 & 7,210 \\ 5,867 & 6,181 \\ 7,467 & 5,152 \\ 9,067 & 4,124 \\ 10,667 & 3,095 \end{bmatrix}. \quad (11.156)$$

Consequentemente,

$$\widehat{\mathbf{U}} = \mathbf{Y} - \widehat{\mathbf{Y}} \approx \begin{bmatrix} 0,333 & -0,238 \\ 0,733 & -0,210 \\ -1,867 & 0,819 \\ 0,533 & -0,152 \\ -0,067 & -0,124 \\ 0,333 & -0,095 \end{bmatrix}. \quad (11.157)$$

As equações normais garantem

$$\mathbf{Z}^\top \widehat{\mathbf{U}} = \mathbf{0}.$$

Em particular, como o modelo contém intercepto, os resíduos somam zero em cada resposta.

SQPC residual e covariância residual

A SQPC residual é

$$\begin{aligned} \mathbf{E} &= \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}} \\ &= \begin{bmatrix} 68/15 & -28/15 \\ -28/15 & 86/105 \end{bmatrix} \\ &\approx \begin{bmatrix} 4,533 & -1,867 \\ -1,867 & 0,819 \end{bmatrix}. \end{aligned} \quad (11.158)$$

Como

$$n = 6$$

e

$$r = 2,$$

os graus de liberdade residuais são

$$\nu_E = n - r = 4.$$

A estimativa não viesada da matriz de covariâncias residual é

$$\begin{aligned}\widehat{\Sigma}_{\text{obs}} &= \frac{\mathbf{E}}{4} \\ &= \begin{bmatrix} 17/15 & -7/15 \\ -7/15 & 43/210 \end{bmatrix} \\ &\approx \begin{bmatrix} 1,133 & -0,467 \\ -0,467 & 0,205 \end{bmatrix}.\end{aligned}\tag{11.159}$$

A covariância residual estimada é negativa. Isso indica que, depois de removida a relação linear com x , desvios positivos de uma resposta tendem a ocorrer juntamente com desvios negativos da outra neste conjunto de dados.

Sob o modelo normal matricial, como $\mathbf{E} \succ \mathbf{0}$, a estimativa de máxima verossimilhança é

$$\begin{aligned}\widehat{\Sigma}_{\text{MV,obs}} &= \frac{\mathbf{E}}{6} \\ &\approx \begin{bmatrix} 0,756 & -0,311 \\ -0,311 & 0,137 \end{bmatrix}.\end{aligned}\tag{11.160}$$

A diferença entre as duas estimativas decorre dos divisores:

$$n - r = 4$$

para o estimador não viesado e

$$n = 6$$

para a máxima verossimilhança sob normalidade.

Decomposição da SQPC total

Como o modelo contém intercepto,

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E}.$$

A SQPC total é

$$\mathbf{T} = \begin{bmatrix} 148/3 & -92/3 \\ -92/3 & 58/3 \end{bmatrix} \approx \begin{bmatrix} 49,333 & -30,667 \\ -30,667 & 19,333 \end{bmatrix}. \quad (11.161)$$

A parcela associada à covariável, além do intercepto, é

$$\mathbf{T}_{\text{mod}} = \begin{bmatrix} 224/5 & -144/5 \\ -144/5 & 648/35 \end{bmatrix} \approx \begin{bmatrix} 44,800 & -28,800 \\ -28,800 & 18,514 \end{bmatrix}. \quad (11.162)$$

Utilizando os valores exatos das matrizes,

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E}.$$

Assim, a dispersão total em torno da média é decomposta na parcela associada à covariável e na parcela residual.

Os graus de liberdade apresentam a decomposição correspondente:

$$5 = 1 + 4,$$

isto é,

$$n - 1 = (r - 1) + (n - r).$$

Hipótese sobre os coeficientes da covariável

Considere a hipótese de que os coeficientes associados a x sejam nulos nas duas respostas.

Para seleccionar a segunda linha de $\mathbf{B}$, defina

$$\mathbf{C}_1 = \begin{bmatrix} 0 & 1 \end{bmatrix}.$$

Como as duas respostas são mantidas,

$$\mathbf{C}_2 = \mathbf{I}_2.$$

A hipótese é

$$H_0 : \mathbf{C}_1 \mathbf{B} = \mathbf{0}^\top,$$

ou, equivalentemente,

$$H_0 : \beta_{11} = \beta_{12} = 0. \quad (11.163)$$

O afastamento observado em relação à hipótese nula é

$$\widehat{\Delta} = \mathbf{C}_1 \widehat{\mathbf{B}}_{\text{obs}} = \begin{bmatrix} 8/5 & -36/35 \end{bmatrix} \approx \begin{bmatrix} 1,600 & -1,029 \end{bmatrix}. \quad (11.164)$$

Nesse caso, $\widehat{\Delta}$ é exatamente o vetor formado pelas duas inclinações estimadas, pois a hipótese específica que ambas devem ser iguais a zero.

A matriz associada à variabilidade desse contraste é escalar:

$$\begin{aligned} \mathbf{V}_{C_1} &= \mathbf{C}_1 (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{C}_1^\top \\ &= \frac{2}{35} \\ &\approx 0,057. \end{aligned} \quad (11.165)$$

A SQPC da hipótese é

$$\begin{aligned} \mathbf{H} &= \widehat{\Delta}^\top \mathbf{V}_{C_1}^{-1} \widehat{\Delta} \\ &= \begin{bmatrix} 224/5 & -144/5 \\ -144/5 & 648/35 \end{bmatrix} \\ &\approx \begin{bmatrix} 44,800 & -28,800 \\ -28,800 & 18,514 \end{bmatrix}. \end{aligned} \quad (11.166)$$

Nesse caso,

$$\mathbf{H} = \mathbf{T}_{\text{mod}}.$$

O modelo completo contém intercepto e covariável, enquanto o modelo sob H_0 contém apenas o intercepto. Portanto, $\mathbf{H}$ representa exatamente a redução da SQPC residual obtida pela inclusão da covariável.

Como o modelo reduzido contém somente a média geral,

$$\mathbf{E}_R = \mathbf{T},$$

e

$$\mathbf{E}_R = \mathbf{H} + \mathbf{E}.$$

Assim, a hipótese sobre a covariável produz o par

$$(\mathbf{H}, \mathbf{E}),$$

formado pela SQPC associada à hipótese e pela SQPC residual.

A decisão inferencial depende da comparação entre a SQPC da hipótese e a SQPC residual.

Hipótese sobre uma combinação das respostas

A mesma formulação permite examinar o coeficiente associado à covariável em uma combinação específica das respostas.

Considere

$$\mathbf{c}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A resposta transformada é

$$Y_1 - Y_2.$$

A hipótese

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{c}_2 = 0 \quad (11.167)$$

afirma que o coeficiente associado à covariável na resposta transformada $Y_1 - Y_2$ é igual a zero.

A estimativa é

$$\begin{aligned} \hat{\theta} &= \mathbf{C}_1 \widehat{\mathbf{B}}_{\text{obs}} \mathbf{c}_2 \\ &= \frac{92}{35} \\ &\approx 2,629. \end{aligned}$$

Como

$$V_{C_1} = \frac{2}{35},$$

a SQPC da hipótese para essa combinação de respostas é o escalar

$$\begin{aligned}
H_{c_2} &= \frac{\hat{\theta}^2}{V_{C_1}} \\
&= \frac{4232}{35} \\
&\approx 120,914.
\end{aligned}$$

A SQPC residual dessa resposta transformada é

$$\begin{aligned}
E_{c_2} &= \mathbf{c}_2^\top \mathbf{E} \mathbf{c}_2 \\
&= \frac{318}{35} \\
&\approx 9,086.
\end{aligned} \tag{11.168}$$

A hipótese sobre a diferença $Y_1 - Y_2$ produz, portanto, o par escalar

$$(H_{c_2}, E_{c_2}) = \left(\frac{4232}{35}, \frac{318}{35} \right).$$

O mesmo ajuste permite formular hipóteses tanto para as respostas originais quanto para suas combinações lineares. Com $\mathbf{C}_2 = \mathbf{I}_2$, examinam-se conjuntamente os coeficientes associados à covariável nas duas respostas. Com

$$\mathbf{c}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

examina-se o coeficiente associado à covariável na resposta transformada $Y_1 - Y_2$. Em ambos os casos, a hipótese e a variação residual são representadas pelo par de SQPCs correspondente.

Neste exemplo, uma única matriz de delineamento produziu sucessivamente

$$\widehat{\mathbf{B}}_{\text{obs}}, \quad \widehat{\mathbf{Y}}, \quad \widehat{\mathbf{U}}, \quad \mathbf{E}, \quad \widehat{\Sigma}_{\text{obs}}$$

e as matrizes associadas às hipóteses examinadas. No modelo de grupos, Equação 11.67 estabelece

$$\mathbf{E} = \mathbf{T}_{\text{intra}},$$

enquanto, para a hipótese global de igualdade dos vetores de médias, Equação 11.98 fornece

$$\mathbf{H} = \mathbf{T}_{\text{entre}}.$$

Assim, na MANOVA de um fator com hipótese global de igualdade dos vetores de médias, as matrizes de hipótese e erro coincidem com as dispersões entre e dentro dos grupos, respectivamente. A Análise Discriminante de Fisher utiliza essas mesmas componentes de dispersão com o objetivo de construir direções de separação entre os grupos.

11.10 Síntese do capítulo

O modelo linear multivariado representa conjuntamente p respostas observadas nas mesmas n unidades:

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E}.$$

A matriz $\mathbf{Z}$ contém as q colunas do delineamento, e $\mathbf{B}$ reúne, para cada resposta, os coeficientes associados a essas colunas. A estrutura de médias condicionais é

$$E(\mathbf{y} \mid \mathbf{Z}) = \mathbf{Z}\mathbf{B}.$$

A matriz

$$\Sigma$$

é a matriz de covariâncias dos erros entre as respostas de uma mesma unidade. Sob o modelo linear normal multivariado,

$$\mathbf{Y}_i \mid \mathbf{Z} \sim N_p(\mathbf{B}^\top \mathbf{z}_i, \Sigma), \quad i = 1, \dots, n,$$

com independência entre unidades.

Quando $\mathbf{Z}$ possui posto coluna completo, a matriz de parâmetros é estimada por

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}.$$

O ajuste depende do espaço coluna de $\mathbf{Z}$. Os valores ajustados e os resíduos são

$$\hat{\mathbf{y}} = \mathbf{P}_Z \mathbf{y}$$

e

$$\hat{\mathbf{u}} = \mathbf{M}_Z \mathbf{y},$$

com

$$\mathbf{P}_Z + \mathbf{M}_Z = \mathbf{I}_n.$$

Assim, cada coluna da matriz de respostas é decomposta em sua projeção sobre $\mathcal{C}(\mathbf{Z})$ e em uma parcela pertencente ao complemento ortogonal desse espaço.

A SQPC residual

$$\mathbf{E}_{\text{res}} = \widehat{\mathcal{U}}^\top \widehat{\mathcal{U}}$$

satisfaz

$$E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) = (n - r)\Sigma,$$

em que

$$r = \text{posto}(\mathbf{Z}).$$

Assim,

$$\widehat{\Sigma} = \frac{\mathbf{E}_{\text{res}}}{n - r}$$

é um estimador não viesado da matriz de covariâncias dos erros. Após a observação,

$$\widehat{\Sigma}_{\text{obs}} = \frac{\mathbf{E}}{n - r}.$$

Quando

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}),$$

a dispersão em torno da média geral satisfaz

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E},$$

com graus de liberdade

$$n - 1 = (r - 1) + (n - r).$$

No modelo de grupos,

$$\mathbf{E} = \mathbf{T}_{\text{intra}}$$

e

$$\mathbf{T}_{\text{mod}} = \mathbf{T}_{\text{entre}},$$

de modo que

$$\mathbf{T} = \mathbf{T}_{\text{entre}} + \mathbf{T}_{\text{intra}}.$$

Assim, Proposição 8.9 passa a ser representada como um caso particular da decomposição de um modelo de médias. Na MANOVA de um fator, para a hipótese global de igualdade dos vetores de médias, $\mathbf{T}_{\text{mod}} = \mathbf{T}_{\text{entre}}$ corresponde à SQPC da hipótese e $\mathbf{E} = \mathbf{T}_{\text{intra}}$ à SQPC residual. Na Análise Discriminante, as dispersões entre e dentro dos grupos sustentam o critério de separação.

Quando

$$\text{posto}(\mathbf{Z}) < q,$$

a matriz de coeficientes pode não ser identificável, embora os valores ajustados e os resíduos permaneçam determinados pelo espaço coluna de $\mathbf{Z}$. Uma função linear

$$\mathbf{CB}$$

é estimável, e portanto possui valor determinado pela estrutura de médias, quando

$$\mathbf{C} = \mathbf{CZ}^+\mathbf{Z}.$$

A hipótese linear multivariada geral é

$$H_0 : \mathbf{C}_1\mathbf{B}\mathbf{C}_2 = \Theta_0.$$

A matriz $\mathbf{C}_1$ forma combinações lineares dos coeficientes associados às colunas do delineamento, enquanto $\mathbf{C}_2$ seleciona ou combina respostas. No caso de posto deficiente, as linhas de $\mathbf{C}_1$ devem satisfazer a condição de estimabilidade

$$\mathbf{C}_1 = \mathbf{C}_1\mathbf{Z}^+\mathbf{Z}.$$

A hipótese produz duas matrizes construídas sobre as mesmas combinações de respostas:

$$\mathbf{H} = \widehat{\Delta}^\top \mathbf{V}_{C_1}^{-1} \widehat{\Delta}$$

e

$$\mathbf{E}_{C_2} = \mathbf{C}_2^\top \mathbf{E} \mathbf{C}_2.$$

A matriz $\mathbf{H}$ é a SQPC associada ao afastamento observado em relação à hipótese, enquanto $\mathbf{E}_{C_2}$ é a SQPC residual das mesmas combinações de respostas. Quando $\mathbf{C}_2 = \mathbf{I}_p$, obtém-se o par

$$(\mathbf{H}, \mathbf{E}),$$

que constitui o par de matrizes de hipótese e erro da MANOVA.

A Tabela 11.2 reúne os principais objetos utilizados no capítulo.

Tabela 11.2: Principais objetos do modelo linear multivariado.

Objeto	Expressão	Papel
estrutura de médias	$\mathbf{ZB}$	determina os vetores de médias representáveis pelo delineamento
estimador/solução de mínimos quadrados	$\widehat{\mathbf{B}}$	estima $\mathbf{B}$ sob posto coluna completo e especifica uma solução de mínimos quadrados sob posto deficiente
projedor do modelo	$\mathbf{P}_Z$	produz os valores ajustados
projedor residual	$\mathbf{M}_Z$	produz os resíduos
SQPC residual	$\mathbf{E}$	reúne os quadrados e produtos cruzados dos resíduos
covariância residual populacional	Σ	descreve as covariâncias dos erros entre as respostas de uma mesma unidade
estimador residual de covariância	$\widehat{\Sigma} = \mathbf{E}_{\text{res}}/(n - r)$	estima Σ sem viés

Objeto	Expressão	Papel
SQPC associada ao modelo	$\mathbf{T}_{\text{mod}}$	quando $\mathbf{1}_n \in \mathcal{C}(\mathbf{Z})$, representa a dispersão dos valores ajustados em torno da média geral
modelo de grupos	$\mathbf{E} = \mathbf{T}_{\text{intra}}, \mathbf{T}_{\text{mod}} = \mathbf{T}_{\text{entre}}$	identifica as parcelas residual e associada ao modelo com as dispersões intra e entre grupos
função estimável	$\mathbf{CB}$	representa uma função linear dos parâmetros determinada pela estrutura de médias
hipótese linear geral	$\mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0$	combina funções dos coeficientes com seleções ou combinações das respostas
SQPC da hipótese	$\mathbf{H}$	representa a SQPC associada ao afastamento observado em relação à hipótese
SQPC residual transformada	$\mathbf{E}_{C_2} = \mathbf{C}_2^\top \mathbf{E} \mathbf{C}_2$	representa a SQPC residual das mesmas combinações de respostas da hipótese

Ao concluir este capítulo, o estudante deve ser capaz de:

- formular um modelo linear para várias respostas e interpretar $\mathbf{Z}$, $\mathbf{B}$ e Σ ;
- obter valores ajustados e resíduos por meio das projeções associadas a $\mathbf{Z}$;
- construir a SQPC residual e estimar a matriz de covariâncias dos erros;
- decompor a dispersão total em parcelas associada ao modelo e residual;
- relacionar, na MANOVA de um fator sob a hipótese global de igualdade dos vetores de médias, as matrizes $\mathbf{H}$ e $\mathbf{E}$ às dispersões entre e dentro dos grupos;
- distinguir unicidade dos coeficientes de estimabilidade de combinações dos parâmetros;
- interpretar a função de $\mathbf{C}_1$ e de $\mathbf{C}_2$ em uma hipótese linear;
- formular hipóteses na forma $\mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0$ e construir as SQPCs correspondentes.

O modelo linear multivariado integra a estimação da estrutura de médias, a decomposição da dispersão e a formulação de hipóteses lineares. Na MANOVA, essa estrutura aparece no par $(\mathbf{H}, \mathbf{E})$; no modelo de grupos, as identidades $\mathbf{E} = \mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{mod}} = \mathbf{T}_{\text{entre}}$ estabelecem a ligação com a Análise Discriminante.

12 Inferência Multivariada

Os capítulos anteriores construíram os objetos sobre os quais será formulada a inferência multivariada. A matriz de covariâncias populacional foi definida em Definição 8.2, a distribuição normal multivariada em Definição 9.1, o vetor de médias amostral e suas propriedades em Proposição 10.3, e a matriz de covariâncias amostral em Definição 10.10. O modelo linear multivariado foi definido em Definição 11.3 e sua hipótese linear geral em Definição 11.15.

O objetivo deste capítulo é obter distribuições amostrais para esses objetos e utilizá-las na construção de testes de hipóteses e regiões de confiança. A distribuição de Wishart descreverá as matrizes SQPC sob normalidade, enquanto a estatística T^2 de Hotelling permitirá realizar inferência sobre vetores de médias quando a matriz de covariâncias populacional é desconhecida.

Os resultados exatos serão desenvolvidos principalmente sob normalidade multivariada. Resultados assintóticos serão utilizados quando a distribuição exata não estiver disponível ou quando o objetivo for descrever o comportamento limite das estatísticas. As duas situações serão distinguidas porque dependem de condições diferentes.

O capítulo também obterá as distribuições dos estimadores e das matrizes SQPC construídas no modelo linear multivariado. Esses resultados encerram a base probabilística e inferencial do Módulo 2 e serão utilizados na formulação das técnicas do Módulo 3.

Convenções de notação

Neste capítulo:

- $\bar{\mathbf{X}}$ representa o vetor de médias amostral como estatística aleatória e $\bar{\mathbf{x}}$ sua realização observada;
- $\mathbf{S}$ representa a matriz de covariâncias amostral como estatística aleatória e $\mathbf{S}$ sua realização observada;
- $\mathbf{T}$ representa a SQPC amostral aleatória e $\mathbf{T}$ sua realização observada;
- $\mathbf{W}$ representa uma matriz aleatória com distribuição de Wishart;
- $\mathbf{E}_{\text{res}}$ e $\mathbf{E}$ representam, respectivamente, a SQPC residual aleatória e sua realização observada;
- $\mathbf{H}$ e $\mathbf{H}$ representam, respectivamente, a SQPC da hipótese aleatória e sua realização observada;
- $\mathbf{Z}$ continua representando a matriz de delineamento do modelo linear multivariado;
- $\mathbf{C}_1$ combina termos do modelo e $\mathbf{C}_2$ combina respostas nas hipóteses lineares defi-

nidas no Capítulo 11;

- $\mathbf{M}_Z$ permanece reservada ao projetor residual;
- $\mathbf{A}$ será utilizada posteriormente para formular hipóteses lineares diretamente sobre o vetor de médias.

As convenções preservam a distinção entre objetos populacionais, estatísticas aleatórias e realizações observadas estabelecida nos capítulos anteriores.

12.1 Distribuições amostrais exatas e assintóticas

A inferência estatística utiliza a distribuição amostral de uma estatística para quantificar sua variabilidade e calibrar procedimentos como testes e regiões de confiança. Essa distribuição pode ser conhecida exatamente sob um modelo probabilístico especificado ou aproximada por seu comportamento limite quando o tamanho amostral cresce.

Definição 12.1 (Resultados exatos e assintóticos). Um **resultado exato** é válido para o tamanho amostral considerado sem recorrer a um argumento limite. Quando o resultado é distribucional, ele fornece a distribuição da estatística sob as hipóteses probabilísticas especificadas.

Um **resultado assintótico** descreve o comportamento limite de uma estatística quando o tamanho amostral tende ao infinito. Sua utilização em amostras finitas constitui uma aproximação cuja qualidade depende das condições do problema.

Neste capítulo, os resultados exatos dependerão principalmente da normalidade multivariada. Os resultados assintóticos considerarão, salvo indicação em contrário, o regime

$$p \text{ fixo} \quad \text{e} \quad n \rightarrow \infty. \quad (12.1)$$

Essa distinção deve ser mantida também na interpretação: uma distribuição exata decorre do modelo probabilístico especificado, enquanto uma distribuição limite decorre de um argumento de convergência.

12.1.1 Distribuição da média amostral sob normalidade

Considere uma amostra aleatória

$$\mathbf{X}_1, \dots, \mathbf{X}_n \in \mathbb{R}^p,$$

independente e identicamente distribuída, com

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma.$$

O vetor de médias amostral é

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i.$$

Por Proposição 10.3,

$$E(\bar{\mathbf{X}}) = \mu$$

e

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}.$$

Esses resultados dependem dos momentos correspondentes, mas não da normalidade multivariada.

A normalidade acrescenta a distribuição exata da estatística.

Proposição 12.1 (Distribuição da média amostral sob normalidade). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

então

$$\bar{\mathbf{X}} \sim N_p\left(\mu, \frac{\Sigma}{n}\right). \quad (12.2)$$

O resultado é exato para qualquer $n \geq 1$.

i Demonstração

A média amostral é uma combinação linear dos vetores normais independentes. Por Proposição 9.4, sua distribuição é normal multivariada. Como Proposição 10.3 fornece

$$E(\bar{\mathbf{X}}) = \mu$$

e

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n},$$

obtém-se Equação 12.2.

A proposição mostra a diferença entre propriedades de um estimador e sua distribuição amostral. A igualdade

$$E(\bar{\mathbf{X}}) = \mu$$

expressa ausência de viés. Já

$$\bar{\mathbf{X}} \sim N_p\left(\mu, \frac{\Sigma}{n}\right)$$

descreve toda a distribuição da estatística sob o modelo normal.

Se

$$\Sigma \succ \mathbf{0},$$

a média amostral pode ser branqueada:

$$\sqrt{n} \Sigma^{-1/2} (\bar{\mathbf{X}} - \mu) \sim N_p(\mathbf{0}, \mathbf{I}_p). \quad (12.3)$$

Aplicando o resultado qui-quadrado da distância de Mahalanobis estabelecido em Proposição 9.8,

$$n (\bar{\mathbf{X}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{X}} - \mu) \sim \chi_p^2. \quad (12.4)$$

O fator n aparece porque

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n},$$

de modo que

$$\left(\frac{\Sigma}{n}\right)^{-1} = n\Sigma^{-1}.$$

A expressão em Equação 12.4 fornece a base do procedimento inferencial para o vetor de médias quando Σ é conhecida. O caso em que Σ precisa ser estimada exigirá a distribuição da matriz de covariâncias amostral.

12.1.2 Teorema Central do Limite multivariado

Fora da família normal, a distribuição de

$$\bar{\mathbf{X}}$$

depende da distribuição conjunta da população. Em dimensão fixa, o Teorema Central do Limite multivariado fornece uma aproximação normal sob condições mais gerais (Johnson; Wichern, 2002).

Teorema 12.1 (Teorema Central do Limite multivariado). *Considere, para dimensão fixa p , vetores aleatórios independentes e identicamente distribuídos*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \in \mathbb{R}^p,$$

com

$$E(\mathbf{X}_i) = \mu$$

e matriz de covariâncias finita

$$\text{Cov}(\mathbf{X}_i) = \Sigma.$$

Então,

$$\sqrt{n}(\bar{\mathbf{X}} - \mu) \xrightarrow{d} N_p(\mathbf{0}, \Sigma). \quad (12.5)$$

i Demonstração

Para qualquer vetor fixo

$$\mathbf{a} \in \mathbb{R}^p,$$

considere

$$\sqrt{n} \mathbf{a}^\top (\bar{\mathbf{X}} - \mu) = \frac{1}{\sqrt{n}} \sum_{i=1}^n \mathbf{a}^\top (\mathbf{X}_i - \mu).$$

As variáveis

$$\mathbf{a}^\top \mathbf{X}_1, \dots, \mathbf{a}^\top \mathbf{X}_n$$

são independentes e identicamente distribuídas, com média

$$\mathbf{a}^\top \mu$$

e variância finita

$$\mathbf{a}^\top \Sigma \mathbf{a}.$$

Pelo Teorema Central do Limite univariado,

$$\sqrt{n} \mathbf{a}^\top (\bar{\mathbf{X}} - \mu) \xrightarrow{d} N(0, \mathbf{a}^\top \Sigma \mathbf{a}).$$

Como a convergência vale para todo vetor fixo $\mathbf{a}$, o Teorema de Cramér–Wold em Teorema 9.1 implica Equação 12.5.

O resultado permite escrever, em sentido assintótico,

$$\bar{\mathbf{X}} \stackrel{a}{\sim} N_p \left(\mu, \frac{\Sigma}{n} \right). \quad (12.6)$$

A mesma expressão possui, portanto, dois significados distintos:

$$\bar{\mathbf{X}} \sim N_p \left(\mu, \frac{\Sigma}{n} \right)$$

é uma distribuição **exata** quando a população é normal multivariada, enquanto

$$\bar{\mathbf{X}} \stackrel{a}{\sim} N_p \left(\mu, \frac{\Sigma}{n} \right)$$

é uma aproximação **assintótica** sob as condições do Teorema 12.1.

Se

$$\Sigma \succ \mathbf{0},$$

então

$$\sqrt{n} \Sigma^{-1/2} (\bar{\mathbf{X}} - \mu) \xrightarrow{d} N_p(\mathbf{0}, \mathbf{I}_p), \quad (12.7)$$

e, pelo teorema da aplicação contínua,

$$n (\bar{\mathbf{X}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{X}} - \mu) \xrightarrow{d} \chi_p^2. \quad (12.8)$$

Assim, a mesma forma quadrática possui distribuição qui-quadrado exata sob normalidade e distribuição limite qui-quadrado sob as condições do TCL multivariado.

Alcance da aproximação assintótica

O Teorema 12.1 considera dimensão p fixa e exige a existência dos momentos de segunda ordem.

O resultado não justifica automaticamente a inferência clássica quando há dependência entre unidades, inexistência de segundos momentos ou crescimento de p juntamente com n . Além disso, a substituição de Σ por uma matriz de covariâncias estimada introduz outra fonte de aleatoriedade que precisa ser considerada separadamente.

A distribuição da média amostral descreve a incerteza associada à localização. Quando Σ é desconhecida, a inferência depende também da distribuição da matriz que estima a dispersão. Sob normalidade multivariada, essa distribuição é obtida a partir da distribuição de Wishart.

12.2 Distribuição de Wishart

A inferência sobre uma matriz de covariâncias exige conhecer a distribuição das matrizes de produtos cruzados que a originam. No caso univariado, somas de quadrados de variáveis normais padronizadas conduzem à distribuição qui-quadrado. A distribuição de Wishart estende essa construção para somas de produtos externos de vetores normais e ocupa, na inferência normal multivariada, papel análogo ao da distribuição qui-quadrado na inferência univariada (Eaton, 2007).

12.2.1 Construção e parametrização

Considere vetores aleatórios independentes

$$\mathbf{U}_1, \dots, \mathbf{U}_\nu \in \mathbb{R}^p$$

tais que

$$\mathbf{U}_j \sim N_p(\mathbf{0}, \Sigma), \quad j = 1, \dots, \nu,$$

com

$$\nu \in \{1, 2, \dots\}$$

e

$$\Sigma \succ \mathbf{0}.$$

Cada produto externo

$$\mathbf{U}_j \mathbf{U}_j^\top$$

é uma matriz simétrica e positiva semidefinida.

Definição 12.2 (Distribuição de Wishart). Se

$$\mathbf{U}_1, \dots, \mathbf{U}_\nu \stackrel{\text{iid}}{\sim} N_p(\mathbf{0}, \Sigma),$$

com

$$\nu \in \{1, 2, \dots\}$$

e

$$\Sigma \succ \mathbf{0},$$

então a matriz aleatória

$$\mathbf{W} = \sum_{j=1}^{\nu} \mathbf{U}_j \mathbf{U}_j^{\top} \quad (12.9)$$

segue uma distribuição de Wishart com ν graus de liberdade e matriz de escala Σ .

Escreve-se

$$\mathbf{W} \sim W_p(\nu, \Sigma). \quad (12.10)$$

Nesta parametrização,

$$\Sigma$$

é denominada **matriz de escala** e ν é o número de graus de liberdade. A Proposição 12.12 estabelece

$$E(\mathbf{W}) = \nu \Sigma.$$

Diferentes convenções para a matriz de escala aparecem na literatura; a igualdade $E(\mathbf{W}) = \nu \Sigma$ identifica a convenção adotada.

Quando

$$p = 1,$$

a matriz Wishart possui um único elemento. Se

$$\Sigma = [\sigma^2],$$

então

$$W = \sum_{j=1}^{\nu} U_j^2$$

e

$$\frac{W}{\sigma^2} \sim \chi_{\nu}^2. \quad (12.11)$$

Assim, a distribuição qui-quadrado é o caso univariado da distribuição de Wishart.

12.2.2 Suporte, posto e definição positiva

Organize os vetores geradores nas linhas da matriz

$$\mathcal{U} = \begin{bmatrix} \mathbf{U}_1^\top \\ \vdots \\ \mathbf{U}_\nu^\top \end{bmatrix} \in \mathbb{R}^{\nu \times p}.$$

Então,

$$\mathbf{W} = \mathcal{U}^\top \mathcal{U}. \quad (12.12)$$

Portanto, $\mathbf{W}$ é uma matriz de Gram no sentido de Definição 3.18. Por Proposição 3.9,

$$\mathbf{W} \succeq \mathbf{0}$$

e

$$\text{posto}(\mathbf{W}) = \text{posto}(\mathcal{U}) \leq \min(\nu, p).$$

Proposição 12.2 (Posto de uma matriz Wishart). *Se*

$$\mathbf{W} \sim W_p(\nu, \Sigma),$$

pela construção em Definição 12.2, com

$$\Sigma \succ \mathbf{0},$$

então, com probabilidade 1,

$$\text{posto}(\mathbf{W}) = \min(\nu, p). \quad (12.13)$$

Consequentemente:

- se $\nu \geq p$, então $\mathbf{W} \succ \mathbf{0}$ com probabilidade 1;
- se $\nu < p$, então $\text{posto}(\mathbf{W}) = \nu$ com probabilidade 1 e a matriz é singular.

Como $\Sigma \succ \mathbf{0}$, cada vetor gerador possui distribuição normal não singular. A distribuição conjunta das entradas de $\mathcal{U}$ é contínua, e o conjunto das matrizes cujo posto é menor que $\min(\nu, p)$ possui probabilidade zero. Assim, a matriz de Gram atinge quase certamente o maior posto permitido por suas dimensões (Muirhead, 1982).

A condição

$$\nu \geq p$$

é, portanto, necessária e suficiente para a definição positiva quase certa na construção com graus de liberdade inteiros e

$$\Sigma \succ \mathbf{0}.$$

12.2.3 Aditividade

Proposição 12.3 (Aditividade da distribuição de Wishart). *Se*

$$\mathbf{W}_1 \sim W_p(\nu_1, \Sigma)$$

e

$$\mathbf{W}_2 \sim W_p(\nu_2, \Sigma)$$

são independentes e possuem a mesma matriz de escala, então

$$\mathbf{W}_1 + \mathbf{W}_2 \sim W_p(\nu_1 + \nu_2, \Sigma). \quad (12.14)$$

i Demonstração

Pela construção da distribuição, as duas matrizes podem ser representadas por somas de, respectivamente, ν_1 e ν_2 produtos externos de vetores normais independentes com a mesma matriz de covariâncias Σ .

A soma das duas matrizes reúne

$$\nu_1 + \nu_2$$

produtos externos independentes e, portanto, possui a distribuição indicada.

A condição de escala comum é necessária para esse resultado. Matrizes Wishart independentes com matrizes de escala distintas não podem, em geral, ser somadas mantendo a mesma forma Wishart.

12.2.4 Transformações lineares

A transformação de uma matriz Wishart acompanha a transformação da matriz de covariâncias dos vetores normais que a geram.

Proposição 12.4 (Transformação linear de uma matriz Wishart). *Considere*

$$\mathbf{W} \sim W_p(\nu, \Sigma)$$

pela construção em Definição 12.2.

Se

$$\mathbf{L} \in \mathbb{R}^{r \times p}$$

possui posto linha completo,

$$\text{posto}(\mathbf{L}) = r,$$

então

$$\mathbf{LWL}^\top \sim W_r(\nu, \mathbf{L}\Sigma\mathbf{L}^\top). \quad (12.15)$$

i Demonstração

Pela construção,

$$\mathbf{LWL}^\top = \sum_{j=1}^{\nu} (\mathbf{LU}_j) (\mathbf{LU}_j)^\top.$$

Por Proposição 9.4,

$$\mathbf{LU}_j \sim N_r(\mathbf{0}, \mathbf{L}\Sigma\mathbf{L}^\top).$$

Como as transformações são aplicadas separadamente aos vetores independentes, os vetores transformados permanecem independentes.

Como $\mathbf{L}$ possui posto linha completo e

$$\Sigma \succ \mathbf{0},$$

tem-se

$$\mathbf{L}\Sigma\mathbf{L}^\top \succ \mathbf{0}.$$

Logo, a soma possui a distribuição apresentada.

12.2.5 Distribuição da SQPC e da covariância amostral

Retomando Definição 10.9,

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

Por Definição 10.10,

$$\mathbf{S} = \frac{\mathbf{T}}{n-1}.$$

Por Proposição 10.7,

$$E(\mathbf{T}) = (n-1)\Sigma.$$

Sob normalidade multivariada, a distribuição completa dessa estatística pode ser estabelecida.

Teorema 12.2 (Distribuição da SQPC e da covariância amostral). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$n \geq 2$$

e

$$\Sigma \succ \mathbf{0},$$

então

$$\mathbf{T} = (n-1)\mathbf{S} \sim W_p(n-1, \Sigma). \quad (12.16)$$



i Demonstração

Organize a amostra na matriz aleatória

$$\mathcal{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix}.$$

Considere uma matriz ortogonal

$$\mathbf{Q} \in \mathbb{R}^{n \times n}$$

cujas primeira linha seja

$$\frac{1}{\sqrt{n}} \mathbf{1}_n^\top,$$

e defina a matriz transformada

$$\mathcal{X}^* = \mathbf{Q}\mathcal{X}.$$

Sua primeira linha satisfaz

$$(\mathbf{x}_1^*)^\top = \sqrt{n} \bar{\mathbf{x}}^\top. \quad (12.17)$$

As demais linhas são combinações lineares cujos coeficientes somam zero. Portanto,

$$E(\mathbf{x}_j^*) = \mathbf{0}, \quad j = 2, \dots, n.$$

A covariância cruzada entre duas linhas transformadas é

$$\text{Cov}(\mathbf{x}_j^*, \mathbf{x}_k^*) = [\mathbf{Q}\mathbf{Q}^\top]_{jk} \Sigma = \delta_{jk} \Sigma.$$

As linhas transformadas são conjuntamente normais. Por Proposição 9.6, as covariâncias cruzadas nulas implicam independência. Assim,

$$\mathbf{x}_2^*, \dots, \mathbf{x}_n^* \stackrel{\text{iid}}{\sim} N_p(\mathbf{0}, \Sigma).$$

A matriz de centralização pode ser escrita como

$$\mathbf{H}_n = \mathbf{Q}^\top \begin{bmatrix} 0 & \mathbf{0}^\top \\ \mathbf{0} & \mathbf{I}_{n-1} \end{bmatrix} \mathbf{Q}.$$

Utilizando a forma matricial da SQPC estabelecida em Equação 10.47,

$$\begin{aligned} \mathbf{T} &= \mathcal{X}^\top \mathbf{H}_n \mathcal{X} \\ &= \sum_{j=2}^n \mathbf{x}_j^* (\mathbf{x}_j^*)^\top. \end{aligned}$$

Essa é a soma de $n - 1$ produtos externos de vetores independentes com distribuição

$$N_p(\mathbf{0}, \Sigma).$$

A informação nova é a distribuição amostral completa:

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma).$$

A matriz de covariâncias amostral possui, com probabilidade 1,

$$\text{posto}(\mathbf{S}) = \min(p, n-1). \quad (12.18)$$

Portanto, sob

$$\Sigma \succ \mathbf{0},$$

a condição

$$n > p \quad (12.19)$$

é necessária e suficiente para que

$$\mathbf{S} \succ \mathbf{0}$$

com probabilidade 1.

Quando

$$p \geq n,$$

a matriz $\mathbf{S}$ é necessariamente singular. Essa restrição dimensional terá consequência direta para a forma clássica da estatística T^2 de Hotelling.

Sob o modelo normal, Equação 10.32 fornece

$$\widehat{\Sigma}_{\text{MV}} = \frac{\mathbf{T}}{n}.$$

Sempre que sua interpretação como estimador de máxima verossimilhança no espaço

$$\Sigma \succ \mathbf{0}$$

for válida,

$$n\widehat{\Sigma}_{\text{MV}} = \mathbf{T} \sim W_p(n-1, \Sigma). \quad (12.20)$$

A distribuição continua envolvendo $n-1$ graus de liberdade, pois a média populacional também foi estimada a partir da amostra.

12.2.6 Independência entre média e covariância

A transformação ortogonal utilizada na prova do Teorema 12.2 separa a informação amostral associada à localização da informação associada à dispersão.

A primeira linha transformada depende exclusivamente de

$$\bar{\mathbf{X}},$$

enquanto

$$\mathbf{T}$$

e, consequentemente,

$$\mathbf{S},$$

dependem apenas das demais linhas.

Teorema 12.3 (Independência entre média e covariância amostral). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$n \geq 2$$

e

$$\Sigma \succ \mathbf{0},$$

então

$$\bar{\mathbf{X}} \perp \mathbf{T}.$$

Como

$$\mathbf{S} = \frac{\mathbf{T}}{n-1},$$

também vale

$$\bar{\mathbf{X}} \perp \mathbf{S}. \quad (12.21)$$

i Demonstração

Na prova de Teorema 12.2, a primeira linha de $\mathcal{X}^*$ depende apenas de

$$\bar{\mathbf{X}},$$

enquanto $\mathbf{T}$ depende apenas das demais linhas transformadas.

Esses dois blocos são independentes por Proposição 9.6. Portanto,

$$\bar{\mathbf{X}} \perp \mathbf{T}.$$

Como

$$\mathbf{S} = \frac{\mathbf{T}}{n-1},$$

segue também

$$\bar{\mathbf{X}} \perp \mathbf{S}.$$

A independência é um resultado **exato da amostragem normal**. Ela não decorre somente da independência entre as observações.

O que depende da normalidade

As propriedades

$$E(\bar{\mathbf{X}}) = \mu$$

e

$$E(\mathbf{S}) = \Sigma$$

não exigem normalidade multivariada.

Em contraste,

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma)$$

e

$$\bar{\mathbf{X}} \perp \mathbf{S}$$

são resultados exatos da amostragem normal.

Para uma população geral, a distribuição de $\mathbf{S}$ depende de características adicionais da distribuição, incluindo momentos de ordem superior, e a média e a covariância amostrais não são, em geral, independentes.

Temos, portanto, sob amostragem normal, o par

$$\bar{\mathbf{X}} \sim N_p\left(\mu, \frac{\Sigma}{n}\right)$$

e

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma),$$

com

$$\bar{\mathbf{X}} \perp \mathbf{S}. \tag{12.22}$$

O par

$$(\bar{\mathbf{X}}, \mathbf{S})$$

combina uma distribuição normal para a localização, uma distribuição Wishart para a dispersão e independência entre os dois objetos. Essa estrutura normal–Wishart será utilizada posteriormente na construção da estatística T^2 de Hotelling.

No modelo linear multivariado, a mesma organização reaparece. O vetor de médias amostral é substituído pelo estimador de $\mathbf{B}$, enquanto a SQPC amostral é substituída pela SQPC residual. Os $n-1$ graus de liberdade do problema de uma única média passam a ser os $n-r$ graus de liberdade residuais do modelo.

12.3 Distribuições no modelo linear multivariado

O modelo linear normal multivariado foi definido em Definição 11.6. Nesta seção, a normalidade será utilizada para obter a distribuição da SQPC residual construída no Capítulo 11.

Condicionalmente a $\mathbf{Z}$,

$$\mathbf{Y}_i \sim N_p(\mathbf{B}^\top \mathbf{z}_i, \Sigma), \quad i = 1, \dots, n,$$

com $\Sigma \succ \mathbf{0}$, e os vetores de respostas correspondentes a unidades distintas são independentes.

A matriz de delineamento é considerada fixa, ou a análise é condicionada em seus valores observados. Defina

$$r = \text{posto}(\mathbf{Z})$$

e

$$\nu_E = n - r,$$

em concordância com Equação 11.49.

Nesta seção, o resultado central é a distribuição da SQPC residual sob o modelo linear normal multivariado. As distribuições do estimador dos parâmetros, das funções estimáveis e da SQPC associada a uma hipótese linear são desenvolvidas posteriormente no aprofundamento teórico.

12.3.1 Distribuição da SQPC residual

Por Definição 11.10,

$$\mathbf{E}_{\text{res}} = \hat{\mathbf{u}}^\top \hat{\mathbf{u}} = \mathbf{y}^\top \mathbf{M}_Z \mathbf{y}.$$

Como

$$\mathbf{M}_Z \mathbf{Z} = \mathbf{0},$$

pode-se escrever

$$\mathbf{E}_{\text{res}} = \mathcal{E}^\top \mathbf{M}_Z \mathcal{E}.$$

A matriz

$$\mathbf{M}_Z$$

é um projetor ortogonal de posto

$$\nu_E = n - r.$$

Proposição 12.5 (Distribuição da SQPC residual). *Sob o modelo linear normal multivariado, se*

$$r = \text{posto}(\mathbf{Z})$$

e

$$\nu_E = n - r \geq 1,$$

então

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(n - r, \Sigma). \quad (12.23)$$

i Demonstração

Seja

$$\mathbf{Q}_E \in \mathbb{R}^{n \times (n-r)}$$

uma matriz cujas colunas formam uma base ortonormal de

$$\mathcal{C}(\mathbf{M}_Z).$$

Como $\mathbf{M}_Z$ é o projetor ortogonal sobre esse espaço,

$$\mathbf{M}_Z = \mathbf{Q}_E \mathbf{Q}_E^\top.$$

Defina

$$\mathcal{E}^* = \mathbf{Q}_E^\top \mathcal{E}.$$

Pela transformação da normal matricial,

$$\mathcal{E}^* \mid \mathbf{Z} \sim N_{(n-r) \times p}(\mathbf{0}, \mathbf{I}_{n-r}, \Sigma).$$

Portanto, suas $n - r$ linhas são vetores independentes com distribuição

$$N_p(\mathbf{0}, \Sigma).$$

Além disso,

$$\begin{aligned} \mathbf{E}_{\text{res}} &= \mathcal{E}^\top \mathbf{Q}_E \mathbf{Q}_E^\top \mathcal{E} \\ &= (\mathcal{E}^*)^\top \mathcal{E}^*. \end{aligned}$$

Pela construção da distribuição de Wishart,

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(n - r, \Sigma).$$

Como o estimador residual foi definido em Equação 11.51 por

$$\widehat{\Sigma} = \frac{\mathbf{E}_{\text{res}}}{n - r},$$

segue que

$$(n - r)\widehat{\Sigma} \mid \mathbf{Z} \sim W_p(n - r, \Sigma). \quad (12.24)$$

O posto da SQPC residual é, com probabilidade 1,

$$\text{posto}(\mathbf{E}_{\text{res}}) = \min(p, n - r). \quad (12.25)$$

Assim,

$$\mathbf{E}_{\text{res}} \succ \mathbf{0}$$

com probabilidade 1 se, e somente se,

$$n - r \geq p. \quad (12.26)$$

A condição é a contraparte probabilística do limite de posto discutido no Capítulo 11 e decorre diretamente de Proposição 12.2.

12.4 Princípios da inferência multivariada

Uma hipótese multivariada pode impor simultaneamente várias restrições sobre um vetor, uma matriz ou uma função dos parâmetros. Um teste global avalia essas restrições como uma única afirmação estatística, considerando a dependência entre seus componentes.

No modelo linear multivariado, por exemplo,

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0$$

é a hipótese geral definida em Definição 11.15. De forma semelhante,

$$H_0 : \mu = \mu_0$$

é uma única hipótese sobre o vetor de médias, ainda que envolva p componentes.

O nível α controla a probabilidade de rejeitar H_0 quando ela é verdadeira. Para uma alternativa especificada, o poder é a probabilidade de rejeitar H_0 quando essa alternativa é verdadeira. Na inferência multivariada, essas probabilidades dependem da forma como as várias componentes são reunidas na estatística de teste.

12.4.1 Testes globais e hipóteses simultâneas

Considere uma hipótese vetorial

$$H_0 : \mu = \mu_0.$$

Ela implica as igualdades coordenadas

$$\mu_j = \mu_{0j}, \quad j = 1, \dots, p,$$

mas a realização de p testes marginais separados não é equivalente a um teste global do vetor (Johnson; Wichern, 2002).

Se cada teste marginal possui nível α e os testes são independentes, a probabilidade de pelo menos uma rejeição incorreta sob a hipótese global é

$$1 - (1 - \alpha)^p. \quad (12.27)$$

Por exemplo, para

$$p = 5$$

e

$$\alpha = 0,05,$$

essa probabilidade é

$$1 - 0,95^5 \approx 0,226.$$

Quando as estatísticas são dependentes, a expressão anterior não se aplica diretamente, mas a conclusão permanece: realizar vários testes marginais no mesmo nível não garante controle do nível global.

Teste global e análise posterior

Um teste global avalia uma hipótese conjunta e utiliza a estrutura de dependência entre seus componentes.

A rejeição da hipótese global não identifica, por si só, quais componentes ou combinações lineares são responsáveis pelo afastamento. Essa investigação exige procedimentos posteriores, como contrastes ou intervalos simultâneos, com controle adequado da multi-

plicidade (Hair et al., 2009).

A distribuição da estatística sob H_0 determina a calibração do teste. Quando sua distribuição amostral exata é conhecida, os valores críticos e o valor- p podem ser obtidos diretamente dessa distribuição. Quando apenas uma distribuição limite é conhecida, a calibração é assintótica.

Sob alternativas, algumas estatísticas passam a depender de parâmetros de não centralidade que incorporam o afastamento de H_0 em relação à variabilidade do problema. Esses parâmetros são utilizados no estudo do poder, mas suas distribuições detalhadas não serão desenvolvidas neste capítulo.

12.4.2 Razão de verossimilhanças

A razão de verossimilhanças fornece um princípio geral para comparar o melhor ajuste permitido por uma hipótese nula com o melhor ajuste disponível no modelo irrestrito (Johnson; Wichern, 2002).

A hipótese nula restringe o espaço paramétrico do modelo irrestrito a um subconjunto de valores admissíveis.

Definição 12.3 (Estatística da razão de verossimilhanças). Considere um parâmetro

$$\vartheta \in \mathcal{P}$$

e a hipótese

$$H_0 : \vartheta \in \mathcal{P}_0, \quad \emptyset \neq \mathcal{P}_0 \subseteq \mathcal{P}.$$

Suponha que, para as realizações consideradas,

$$0 < \sup_{\vartheta \in \mathcal{P}} L(\vartheta; \mathcal{Y}) < \infty.$$

A estatística da razão de verossimilhanças é

$$\Lambda_{\text{RV}}(\mathcal{Y}) = \frac{\sup_{\vartheta \in \mathcal{P}_0} L(\vartheta; \mathcal{Y})}{\sup_{\vartheta \in \mathcal{P}} L(\vartheta; \mathcal{Y})}. \quad (12.28)$$

Para uma realização observada $\mathbf{y}$, o valor observado da estatística é

$$\Lambda_{\text{RV,obs}} = \frac{\sup_{\vartheta \in \mathcal{P}_0} L(\vartheta; \mathbf{y})}{\sup_{\vartheta \in \mathcal{P}} L(\vartheta; \mathbf{y})}.$$

Como

$$\mathcal{P}_0 \subseteq \mathcal{P},$$

tem-se

$$0 \leq \Lambda_{\text{RV}} \leq 1.$$

Valores próximos de 1 indicam que a restrição imposta por H_0 produz pequena redução na verossimilhança máxima. Valores reduzidos indicam maior incompatibilidade entre a hipótese nula e os dados observados.

É conveniente utilizar a transformação

$$-2 \log \Lambda_{\text{RV}}.$$

Quando os máximos são atingidos e

$$\hat{\vartheta}$$

e

$$\tilde{\vartheta}$$

denotam, respectivamente, os estimadores de máxima verossimilhança irrestrito e restrito,

$$-2 \log \Lambda_{\text{RV}} = 2 \left[\ell(\hat{\vartheta}) - \ell(\tilde{\vartheta}) \right], \quad (12.29)$$

em que

$$\ell(\vartheta) = \log L(\vartheta; \mathbf{y}).$$

A estatística é não negativa e cresce à medida que as restrições impostas por H_0 reduzem o máximo da verossimilhança.

A distribuição de

$$-2 \log \Lambda_{\text{RV}}$$

depende do modelo. Em alguns problemas, existe uma distribuição exata ou uma transformação exata para uma distribuição conhecida. Em modelos paramétricos regulares, Teorema 12.4 estabelece

$$-2 \log \Lambda_{\text{RV}} \xrightarrow{d} \chi_d^2,$$

com d igual ao número de restrições independentes.

A razão de verossimilhanças fornece um princípio geral para comparar modelos restritos e irrestritos. Para a inferência sobre um único vetor de médias, entretanto, existem distribuições exatas mais específicas.

Quando Σ é conhecida, a forma quadrática da média amostral conduz diretamente a uma distribuição qui-quadrado. Quando Σ é desconhecida e precisa ser estimada por $\mathbf{S}$, a distribuição muda e conduz à estatística T^2 de Hotelling.

12.5 Inferência sobre um vetor de médias

Considere uma amostra aleatória

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0}.$$

O objetivo inicial é testar

$$H_0 : \mu = \mu_0$$

contra

$$H_1 : \mu \neq \mu_0,$$

em que

$$\mu_0 \in \mathbb{R}^p$$

é conhecido.

A distribuição da média amostral foi estabelecida em Proposição 12.1. Quando Σ é conhecida, Seção 12.8.12 utiliza uma forma quadrática com distribuição de referência χ_p^2 . Quando Σ é desconhecida, sua estimação por $\mathbf{S}$ conduz à estatística T^2 de Hotelling.

12.5.1 Estatística T^2 de Hotelling

Na maior parte das aplicações,

$$\Sigma$$

é desconhecida e precisa ser estimada. A substituição de Σ por $\mathbf{S}$ torna aleatória a matriz utilizada na forma quadrática. A distribuição da estatística deve, portanto, incorporar também a variabilidade associada à estimação da matriz de covariâncias.

Os resultados obtidos anteriormente fornecem

$$\bar{\mathbf{X}} \sim N_p \left(\mu, \frac{\Sigma}{n} \right)$$

por Proposição 12.1,

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma)$$

por Teorema 12.2, e

$$\bar{\mathbf{X}} \perp \mathbf{S}$$

por Teorema 12.3.

A estatística T^2 combina esses três resultados.

Definição 12.4 (Estatística T^2 de Hotelling para uma amostra). A estatística para testar

$$H_0 : \mu = \mu_0$$

quando Σ é desconhecida e $\mathbf{S} \succ \mathbf{0}$ é

$$T^2 = n (\bar{\mathbf{X}} - \mu_0)^\top \mathbf{S}^{-1} (\bar{\mathbf{X}} - \mu_0). \quad (12.30)$$

A forma clássica de T^2 exige

$$\mathbf{S} \succ \mathbf{0},$$

pois utiliza $\mathbf{S}^{-1}$.

Como

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma),$$

Proposição 12.2 mostra que, sob $\Sigma \succ \mathbf{0}$,

$$\mathbf{S} \succ \mathbf{0}$$

com probabilidade 1 quando

$$n > p. \tag{12.31}$$

O fator n aparece porque a matriz de covariâncias da média é

$$\frac{\Sigma}{n}.$$

A expressão de T^2 tem a mesma forma quadrática utilizada na distância de Mahalanobis, mas emprega a matriz aleatória $\mathbf{S}$ no lugar de Σ . Portanto, trata-se de uma forma de Mahalanobis **estimada**, cuja distribuição precisa incorporar a variabilidade da estimação da covariância.

Proposição 12.6 (Distribuição exata de T^2). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0}$$

e

$$n > p,$$

então, sob

$$H_0 : \mu = \mu_0,$$

vale

$$\frac{n-p}{p(n-1)} \mathbf{T}^2 \sim F_{p, n-p}. \quad (12.32)$$

Esse resultado utiliza conjuntamente a distribuição normal da média, a distribuição Wishart da covariância amostral e a independência entre esses dois objetos (Johnson; Wichern, 2002).

Quando Σ é conhecida, somente a média amostral é aleatória na forma quadrática e obtém-se uma distribuição χ_p^2 . Quando Σ é substituída por $\mathbf{S}$, a incerteza da covariância estimada também participa da estatística. A transformação em Equação 12.32 incorpora essa fonte adicional de variabilidade e produz a distribuição F exata.

Após a observação,

$$\mathbf{T}_{\text{obs}}^2 = n \left(\bar{\mathbf{x}} - \mu_0 \right)^\top \mathbf{S}^{-1} \left(\bar{\mathbf{x}} - \mu_0 \right). \quad (12.33)$$

Defina

$$\mathbf{F}_{\text{obs}} = \frac{n-p}{p(n-1)} \mathbf{T}_{\text{obs}}^2. \quad (12.34)$$

Um teste de nível α rejeita H_0 quando

$$\mathbf{T}_{\text{obs}}^2 > \frac{p(n-1)}{n-p} F_{p, n-p; 1-\alpha}, \quad (12.35)$$

ou, equivalentemente, quando

$$\mathbf{F}_{\text{obs}} > F_{p, n-p; 1-\alpha}.$$

O valor- p é

$$P \left(F_{p, n-p} \geq \mathbf{F}_{\text{obs}} \right). \quad (12.36)$$

A rejeição informa que o vetor populacional não coincide com μ_0 . Ela não identifica, isoladamente, quais componentes ou combinações lineares são responsáveis pelo afastamento.

12.5.2 Relações com os casos assintótico e univariado

Quando p permanece fixo e

$$n \longrightarrow \infty,$$

a distribuição da média amostral sob H_0 , juntamente com a consistência de $\mathbf{S}$ estabelecida em Proposição 10.9 e o teorema de Slutsky, implica

$$\mathbf{T}^2 \xrightarrow{d} \chi_p^2. \quad (12.37)$$

Portanto, a distribuição qui-quadrado fornece uma aproximação assintótica. Sob normalidade e em amostras finitas, a distribuição F em Equação 12.32 é o resultado exato.

Quando

$$p = 1,$$

a matriz de covariâncias amostral reduz-se à variância amostral S . Assim,

$$\mathbf{T}^2 = \frac{n(\bar{X} - \mu_0)^2}{S} = \mathbf{t}^2, \quad (12.38)$$

em que

$$\mathbf{t} = \frac{\sqrt{n}(\bar{X} - \mu_0)}{\sqrt{S}} \sim t_{n-1}$$

sob H_0 .

Assim, o teste T^2 de uma amostra é a extensão multivariada do teste t de Student.

12.6 Comparação entre dois vetores de médias

A comparação entre dois vetores de médias depende da relação entre as unidades que produziram as observações. Duas estruturas serão consideradas:

- **amostras independentes**, formadas por unidades distintas;
- **observações pareadas**, nas quais cada unidade ou par fornece duas medições relacionadas.

Para amostras independentes, a diferença entre vetores de médias é padronizada por uma matriz de covariâncias agrupada sob a hipótese de covariância populacional comum. No delineamento pareado, a inferência é aplicada aos vetores de diferenças definidos em Seção 12.9.6.

Nos dois casos, o parâmetro de interesse é uma diferença entre vetores de médias. O delineamento determina, porém, a matriz de covariâncias dessa diferença e, consequentemente, a estatística utilizada na inferência.

12.6.1 Duas amostras independentes

Considere duas amostras mutuamente independentes:

$$\mathbf{X}_{11}, \dots, \mathbf{X}_{1n_1} \stackrel{\text{iid}}{\sim} N_p(\mu_1, \Sigma)$$

e

$$\mathbf{X}_{21}, \dots, \mathbf{X}_{2n_2} \stackrel{\text{iid}}{\sim} N_p(\mu_2, \Sigma),$$

com

$$\Sigma \succ \mathbf{0}.$$

A especificação de uma mesma matriz

$$\Sigma$$

para as duas populações é parte do modelo utilizado pelo procedimento clássico com covariância agrupada (Johnson; Wichern, 2002).

O parâmetro de interesse é

$$\delta = \mu_1 - \mu_2 \in \mathbb{R}^p. \quad (12.39)$$

Considere a hipótese

$$H_0 : \mu_1 - \mu_2 = \delta_0 \quad (12.40)$$

contra

$$H_1 : \mu_1 - \mu_2 \neq \delta_0.$$

A igualdade dos vetores de médias corresponde ao caso

$$\delta_0 = \mathbf{0}.$$

12.6.1.1 Distribuição da diferença entre as médias

Aplicando Proposição 12.1 separadamente às duas amostras,

$$\bar{\mathbf{X}}_1 \sim N_p \left(\mu_1, \frac{\Sigma}{n_1} \right)$$

e

$$\bar{\mathbf{X}}_2 \sim N_p \left(\mu_2, \frac{\Sigma}{n_2} \right).$$

Como as amostras são independentes,

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 \sim N_p \left[\mu_1 - \mu_2, \left(\frac{1}{n_1} + \frac{1}{n_2} \right) \Sigma \right]. \quad (12.41)$$

Para simplificar as expressões seguintes, defina o fator

$$n_{\text{ef}} = \left(\frac{1}{n_1} + \frac{1}{n_2} \right)^{-1} = \frac{n_1 n_2}{n_1 + n_2}. \quad (12.42)$$

Então,

$$\text{Cov}(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2) = \frac{\Sigma}{n_{\text{ef}}}.$$

A notação n_{ef} será utilizada apenas como fator de escala da covariância da diferença entre as médias. Ela não representa o número total de observações nem os graus de liberdade do procedimento.

12.6.1.2 Covariância agrupada

Como Σ é desconhecida, as duas amostras fornecem estimativas da mesma matriz de covariâncias populacional. Essas estimativas são combinadas ponderando cada SQPC pelos respectivos graus de liberdade:

$$\mathbf{S}_p = \frac{(n_1 - 1)\mathbf{S}_1 + (n_2 - 1)\mathbf{S}_2}{n_1 + n_2 - 2}. \quad (12.43)$$

A matriz $\mathbf{S}_p$ é denominada **matriz de covariâncias agrupada**.

Após a observação,

$$\mathbf{S}_p = \frac{(n_1 - 1)\mathbf{S}_1 + (n_2 - 1)\mathbf{S}_2}{n_1 + n_2 - 2}. \quad (12.44)$$

Por Teorema 12.2, sob o modelo de covariância comum,

$$(n_h - 1)\mathbf{S}_h \sim W_p(n_h - 1, \Sigma), \quad h = 1, 2.$$

Como as duas amostras são independentes, essas matrizes Wishart também são independentes. Portanto, Proposição 12.3 pode ser aplicada às duas SQPCs.

Proposição 12.7 (Distribuição da covariância agrupada). *Se as duas amostras são independentes, cada amostra é formada por observações i.i.d. normais multivariadas em $\mathbb{R}^p$ e ambas possuem matriz de covariâncias comum*

$$\Sigma \succ \mathbf{0},$$

com

$$n_1 \geq 2 \quad e \quad n_2 \geq 2,$$

então

$$(n_1 + n_2 - 2)\mathbf{S}_p \sim W_p(n_1 + n_2 - 2, \Sigma). \quad (12.45)$$

Além disso,

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 \perp \mathbf{S}_p. \quad (12.46)$$

i Demonstração

Pela aditividade da distribuição de Wishart,

$$(n_1 - 1)\mathbf{S}_1 + (n_2 - 1)\mathbf{S}_2 \\ \sim W_p(n_1 + n_2 - 2, \Sigma).$$

A matriz no lado esquerdo é

$$(n_1 + n_2 - 2)\mathbf{S}_p.$$

Sob normalidade, em cada amostra a média é independente da respectiva matriz de covariâncias. A independência entre as duas amostras implica então a independência entre

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2$$

e

$$\mathbf{S}_p.$$

A distribuição em Equação 12.45 fornece

$$E(\mathbf{S}_p) = \Sigma.$$

Além disso, por Proposição 12.2,

$$\text{posto}(\mathbf{S}_p) = \min(p, n_1 + n_2 - 2)$$

com probabilidade 1. Portanto,

$$\mathbf{S}_p \succ \mathbf{0}$$

com probabilidade 1 quando

$$n_1 + n_2 - 2 \geq p. \tag{12.47}$$

12.6.1.3 Estatística T^2 para duas amostras

Definição 12.5 (Estatística T^2 para duas amostras independentes). Para testar

$$H_0 : \mu_1 - \mu_2 = \delta_0,$$

quando

$$\mathbf{S}_p \succ \mathbf{0},$$

define-se

$$T_{\text{ind}}^2 = n_{\text{ef}} \left(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \delta_0 \right)^\top \mathbf{S}_p^{-1} \left(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \delta_0 \right), \quad (12.48)$$

em que

$$n_{\text{ef}} = \frac{n_1 n_2}{n_1 + n_2}$$

e

$$\mathbf{S}_p = \frac{(n_1 - 1)\mathbf{S}_1 + (n_2 - 1)\mathbf{S}_2}{n_1 + n_2 - 2}.$$

A estatística possui a mesma forma quadrática do T^2 de uma amostra. O vetor de afastamento é agora

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \delta_0,$$

e sua variabilidade é estimada pela matriz de covariâncias agrupada.

Proposição 12.8 (Distribuição exata de T^2 para duas amostras). *Se as duas amostras são independentes e*

$$\mathbf{X}_{1i} \stackrel{\text{iid}}{\sim} N_p(\mu_1, \Sigma), \quad i = 1, \dots, n_1,$$

e

$$\mathbf{X}_{2i} \overset{\text{iid}}{\sim} N_p\left(\mu_2, \Sigma\right), \quad i=1, \ldots, n_2,$$

com

$$\Sigma \succ \mathbf{0}, \quad n_1 \geq 2, \quad n_2 \geq 2,$$

e

$$n_1+n_2-2 \geq p,$$

então, sob

$$H_0: \mu_1-\mu_2=\delta_0,$$

tem-se

$$\frac{n_1+n_2-p-1}{p(n_1+n_2-2)}\mathsf{T}^2_{\text{ind}} \sim F_{p,\,n_1+n_2-p-1}. \tag{12.49}$$

i Demonstração

Sob H_0 , o vetor

$$\mathbf{V} = \sqrt{n_{\text{ef}}} (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \delta_0)$$

satisfaz

$$\mathbf{V} \sim N_p(\mathbf{0}, \Sigma).$$

Além disso,

$$\mathbf{W} = (n_1 + n_2 - 2)\mathbf{S}_p$$

satisfaz, por Proposição 12.7,

$$\mathbf{W} \sim W_p(n_1 + n_2 - 2, \Sigma)$$

e

$$\mathbf{V} \perp \mathbf{W}.$$

A mesma estrutura normal–Wishart utilizada em Proposição 12.6 fornece

$$\frac{n_1 + n_2 - p - 1}{p(n_1 + n_2 - 2)} T_{\text{ind}}^2 \sim F_{p, n_1 + n_2 - p - 1}.$$

Para os dados observados,

$$T_{\text{ind,obs}}^2 = n_{\text{ef}} \left(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - \delta_0 \right)^\top \mathbf{S}_p^{-1} \left(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - \delta_0 \right). \quad (12.50)$$

Um teste de nível α rejeita H_0 quando

$$T_{\text{ind,obs}}^2 > \frac{p(n_1 + n_2 - 2)}{n_1 + n_2 - p - 1} F_{p, n_1 + n_2 - p - 1; 1 - \alpha}. \quad (12.51)$$

12.7 Condições e limites da inferência clássica

Os resultados desenvolvidos neste capítulo dependem da estrutura probabilística da amostra, das hipóteses específicas de cada procedimento e do posto das matrizes envolvidas. Essas condições não são intercambiáveis: uma hipótese necessária para um procedimento pode ser irrelevante para outro.

Quatro aspectos organizam a validade da inferência clássica:

1. independência entre as unidades amostrais na estrutura especificada pelo delineamento;
2. normalidade multivariada quando se utilizam distribuições exatas normal–Wishart;
3. covariância comum nos procedimentos que a pressupõem;
4. posto suficiente das matrizes utilizadas nas formas quadráticas, inversas e determinantes.

12.7.1 Independência, normalidade e covariância comum

12.7.1.1 Independência

Nos resultados para uma amostra,

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

são consideradas independentes.

Para duas amostras independentes, exige-se também independência entre as duas amostras. No delineamento pareado, admite-se dependência entre as duas medições de um mesmo par, mas os pares devem ser independentes entre si.

No modelo linear multivariado clássico,

$$\text{Cov} [\text{vec} (\mathcal{E}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n$$

expressa a ausência de covariância residual entre unidades distintas.

A independência é determinada principalmente pelo processo de amostragem e pelo delineamento do estudo. Se existe dependência entre unidades e ela não é incorporada ao modelo, expressões como

$$\text{Cov} (\bar{\mathbf{X}}) = \frac{\Sigma}{n}$$

podem deixar de representar a variabilidade efetiva da média amostral.

Consequentemente, estatísticas construídas com essa estrutura podem apresentar níveis de significância e coberturas diferentes dos valores nominais.

Independência e delineamento

A independência deve ser avaliada a partir da forma como as unidades foram selecionadas, agrupadas e mensuradas. Testes aplicados aos valores observados não garantem, por si só, essa condição (Hair et al., 2009).

Dependência espacial, temporal, hierárquica ou decorrente de medidas repetidas exige uma estrutura probabilística compatível com o delineamento.

12.7.1.2 Normalidade multivariada

A normalidade multivariada sustenta os principais resultados exatos deste capítulo. Sob esse modelo foram estabelecidas:

- a distribuição normal da média em Proposição 12.1;
- a distribuição Wishart da SQPC amostral em Teorema 12.2;
- a independência entre média e covariância amostrais em Teorema 12.3;
- a distribuição F exata do T^2 de uma amostra em Proposição 12.6;
- a distribuição F exata do T^2 de duas amostras em Proposição 12.8, sob a hipótese adicional de covariância comum;
- as distribuições Wishart e as independências associadas ao modelo linear multivariado em Proposição 12.15.

Esses resultados devem ser distinguidos das propriedades que dependem apenas de momentos. Por exemplo, Proposição 10.3 e Proposição 10.8 não exigem normalidade.

Fora do modelo normal, a distribuição Wishart e as independências utilizadas para construir as distribuições exatas deixam, em geral, de estar disponíveis. No regime de dimensão fixa de Equação 12.1, resultados assintóticos podem ainda ser obtidos.

Se as observações são i.i.d., possuem matriz de covariâncias finita e positiva definida, e as condições de Teorema 12.1 e Proposição 10.9 são satisfeitas, então, sob

$$H_0 : \mu = \mu_0,$$

o Teorema Central do Limite multivariado e o teorema de Slutsky fornecem

$$T^2 \xrightarrow{d} \chi_p^2. \quad (12.52)$$

Essa convergência não implica que

$$\frac{n-p}{p(n-1)} T^2 \sim F_{p, n-p}$$

seja uma distribuição exata em amostras finitas fora do modelo normal.

Exato e assintótico

A normalidade não é necessária para definir médias, covariâncias, matrizes SQPC ou formas quadráticas.

Neste capítulo, ela é utilizada para obter determinadas distribuições amostrais **exatas**. Fora desse modelo, uma aproximação assintótica depende das condições do resultado limite utilizado e do regime em que n e p variam.

12.7.1.3 Covariância comum

A hipótese

$$\Sigma_1 = \Sigma_2$$

não pertence a todos os procedimentos multivariados.

Ela foi utilizada especificamente no teste de duas amostras independentes com covariância agrupada, pois permite obter

$$(n_1 + n_2 - 2)\mathbf{S}_p \sim W_p(n_1 + n_2 - 2, \Sigma).$$

Quando

$$\Sigma_1 \neq \Sigma_2,$$

a covariância da diferença entre as médias é

$$\frac{\Sigma_1}{n_1} + \frac{\Sigma_2}{n_2},$$

e a matriz agrupada não conduz à distribuição F exata da Proposição 12.8.

No procedimento pareado, essa hipótese não é necessária. A matriz relevante é

$$\Sigma_D = \text{Cov}(\mathbf{X}_i - \mathbf{Y}_i).$$

No modelo linear multivariado clássico, a estrutura

$$\text{Cov}(\varepsilon_i | \mathbf{Z}) = \Sigma$$

supõe uma matriz residual comum às unidades representadas pelo modelo.

Assim, a homogeneidade deve ser entendida como uma hipótese do **procedimento que utiliza uma matriz de covariâncias comum**, e não como uma condição universal da inferência multivariada.

12.7.2 Posto, dimensão e tamanho amostral

As formas clássicas das estatísticas utilizam matrizes inversas. A condição necessária depende da dimensão efetivamente utilizada em cada problema.

12.7.2.1 Uma amostra

Sob normalidade não singular,

$$\text{posto}(\mathbf{S}) = \min(p, n - 1)$$

com probabilidade 1.

Portanto,

$$\mathbf{S}^{-1}$$

existe com probabilidade 1 se, e somente se,

$$n > p.$$

Essa é também a condição que torna positivo o segundo grau de liberdade

$$n - p$$

da distribuição

$$F_{p, n-p}.$$

12.7.2.2 Duas amostras independentes

Sob normalidade e covariância comum,

$$\text{posto}(\mathbf{S}_p) = \min(p, n_1 + n_2 - 2)$$

com probabilidade 1.

A inversão clássica requer

$$n_1 + n_2 - 2 \geq p.$$

Sob essa condição,

$$n_1 + n_2 - p - 1 > 0,$$

como necessário para a distribuição F da Proposição [12.8](#).

12.7.2.3 Modelo linear multivariado

Se

$$r = \text{posto}(\mathbf{Z}),$$

então

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(n - r, \Sigma),$$

e

$$\text{posto}(\mathbf{E}_{\text{res}}) = \min(p, n - r)$$

com probabilidade 1.

Logo,

$$\mathbf{E}_{\text{res}} \succ \mathbf{0}$$

com probabilidade 1 quando

$$n - r \geq p.$$

Para combinações de respostas definidas por

$$\mathbf{C}_2 \in \mathbb{R}^{p \times s},$$

com posto coluna completo,

$$\mathbf{E}_{C_2} = \mathbf{C}_2^\top \mathbf{E}_{\text{res}} \mathbf{C}_2$$

é positiva definida com probabilidade 1 quando

$$n - r \geq s,$$

conforme Equação 12.79.

Portanto, a condição de posto depende da dimensão do objeto que efetivamente participa da inferência. Uma matriz de covariâncias completa pode ser singular e, ainda assim, determinadas combinações previamente especificadas admitirem inferência clássica em um espaço de menor dimensão.

As condições desta seção delimitam quais resultados do capítulo são exatos, quais dependem de aproximações assintóticas e quando as formas clássicas deixam de estar definidas. Com essas fronteiras estabelecidas, o Módulo 2 reúne os objetos probabilísticos, amostrais, de estimação, modelagem e inferência que serão utilizados pelas técnicas multivariadas do Módulo 3.

12.8 Aprofundamentos teóricos

Os resultados a seguir completam a estrutura probabilística do modelo linear normal multivariado e aprofundam propriedades das distribuições utilizadas no núcleo. Para estudar as distribuições dos estimadores e das funções estimáveis, será utilizada a formulação matricial conjunta do modelo normal desenvolvida no aprofundamento teórico do Capítulo 11.

12.8.1 Distribuição do estimador da matriz de parâmetros

Suponha inicialmente que

$$r = q.$$

Nesse caso, o estimador de mínimos quadrados definido em Equação 11.24 é

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}.$$

Por Equação 11.112,

$$\widehat{\mathbf{B}} = \mathbf{B} + (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathcal{E}.$$

Assim, $\widehat{\mathbf{B}}$ é uma transformação afim da matriz normal de erros.

Proposição 12.9 (Distribuição do estimador da matriz de parâmetros). *Sob o modelo linear normal multivariado e*

$$\text{posto}(\mathbf{Z}) = q,$$

tem-se

$$\widehat{\mathbf{B}} \mid \mathbf{Z} \sim N_{q \times p} \left[\mathbf{B}, (\mathbf{Z}^\top \mathbf{Z})^{-1}, \Sigma \right]. \quad (12.53)$$

Equivalentemente,

$$\text{vec}(\widehat{\mathbf{B}}) \mid \mathbf{Z} \sim N_{pq} \left[\text{vec}(\mathbf{B}), \Sigma \otimes (\mathbf{Z}^\top \mathbf{Z})^{-1} \right]. \quad (12.54)$$

i Demonstração

Defina

$$\mathbf{A}_Z = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top.$$

Então

$$\widehat{\mathbf{B}} = \mathbf{B} + \mathbf{A}_Z \mathcal{E}.$$

Pela transformação da distribuição normal matricial,

$$\mathbf{A}_Z \mathcal{E} \mid \mathbf{Z} \sim N_{q \times p}(\mathbf{0}, \mathbf{A}_Z \mathbf{A}_Z^\top, \Sigma).$$

Como

$$\begin{aligned} \mathbf{A}_Z \mathbf{A}_Z^\top &= (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Z} (\mathbf{Z}^\top \mathbf{Z})^{-1} \\ &= (\mathbf{Z}^\top \mathbf{Z})^{-1}, \end{aligned}$$

segue o resultado.

A distribuição em Equação 12.53 contém como momentos os resultados de Proposição 11.9. A matriz

$$(\mathbf{Z}^\top \mathbf{Z})^{-1}$$

descreve a contribuição do delineamento para a variabilidade dos coeficientes, enquanto

$$\Sigma$$

descreve a dependência residual entre as respostas.

Quando

$$r < q,$$

os coeficientes de $\mathbf{B}$ podem não ser únicos. Nesse caso, a inferência deve ser formulada sobre as funções estimáveis caracterizadas em Proposição 11.7.

12.8.2 Distribuição de funções estimáveis

O Capítulo 11 caracterizou as funções estimáveis do modelo linear multivariado. Sob normalidade, a distribuição exata de seu estimador decorre de uma transformação linear da matriz de erros.

Proposição 12.10 (Distribuição de uma função estimável). *Sob o modelo linear normal multivariado,*

$$\widehat{\Theta} \mid \mathbf{Z} \sim N_{g \times s} \left(\mathbf{C}_1 \mathbf{B} \mathbf{C}_2, \mathbf{V}_{C_1}, \Sigma_{C_2} \right). \quad (12.55)$$

Nesse resultado,

$$\Theta = \mathbf{C}_1 \mathbf{B} \mathbf{C}_2$$

e

$$\widehat{\Theta} = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{y} \mathbf{C}_2.$$

A matriz

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q}, \quad \text{posto}(\mathbf{C}_1) = g,$$

satisfaz a condição de estimabilidade

$$\mathbf{C}_1 = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Z},$$

enquanto

$$\mathbf{C}_2 \in \mathbb{R}^{p \times s}, \quad \text{posto}(\mathbf{C}_2) = s.$$

As matrizes de covariâncias são

$$\mathbf{V}_{C_1} = \mathbf{C}_1 \mathbf{Z}^+ (\mathbf{Z}^+)^{\top} \mathbf{C}_1^{\top} \quad (12.56)$$

e

$$\Sigma_{C_2} = \mathbf{C}_2^{\top} \Sigma \mathbf{C}_2. \quad (12.57)$$

Sob essas condições,

$$\mathbf{V}_{C_1} \succ \mathbf{0} \quad e \quad \Sigma_{C_2} \succ \mathbf{0}.$$

Equivalentemente,

$$\text{vec}(\widehat{\Theta}) \mid \mathbf{Z} \sim N_{gs} \left[\text{vec}(\mathbf{C}_1 \mathbf{B} \mathbf{C}_2), \Sigma_{C_2} \otimes \mathbf{V}_{C_1} \right]. \quad (12.58)$$

i Demonstração

Pela estimabilidade,

$$\mathbf{C}_1 \mathbf{Z}^+ \mathbf{Z} = \mathbf{C}_1.$$

Portanto,

$$\widehat{\Theta} = \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 + \mathbf{C}_1 \mathbf{Z}^+ \mathcal{E} \mathbf{C}_2.$$

A segunda parcela é uma transformação bilateral da matriz normal de erros, com matriz de covariâncias entre linhas $\mathbf{V}_{C_1}$ e matriz de covariâncias entre colunas Σ_{C_2} . Isso fornece Equação 12.55.

A matriz $\mathbf{V}_{C_1}$ representa a variabilidade associada às combinações dos termos do modelo, enquanto Σ_{C_2} representa a covariância residual das combinações de respostas. A normalidade acrescenta a distribuição amostral exata à estrutura construída no Capítulo 11.

12.8.3 Independência entre estimação e SQPC residual

Para uma função estimável,

$$\widehat{\Theta} - \Theta = \mathbf{C}_1 \mathbf{Z}^+ \mathcal{E} \mathbf{C}_2,$$

enquanto os resíduos satisfazem

$$\widehat{\mathcal{U}} = \mathbf{M}_Z \mathcal{E}.$$

Como

$$\mathbf{Z}^+ \mathbf{M}_Z = \mathbf{0},$$

as duas parcelas correspondem a projeções ortogonais dos erros.

Proposição 12.11 (Independência entre estimação paramétrica e resíduos). *Sob o modelo linear normal multivariado,*

$$\widehat{\Theta} \perp \widehat{\mathcal{U}} \mid \mathbf{Z}.$$

Consequentemente,

$$\widehat{\Theta} \perp \mathbf{E}_{\text{res}} \mid \mathbf{Z}. \quad (12.59)$$

i Demonstração

As duas matrizes são transformações lineares da mesma matriz normal de erros e, portanto, são conjuntamente normais.

Como

$$\mathbf{C}_1 \mathbf{Z}^+ \mathbf{M}_Z = \mathbf{0},$$

a covariância cruzada entre as duas transformações é nula. Por Proposição 9.6, segue a independência.

Como $\mathbf{E}_{\text{res}}$ é função dos resíduos, a segunda independência também é obtida.

Quando $\mathbf{Z}$ possui posto coluna completo, tomando

$$\mathbf{C}_1 = \mathbf{I}_q \quad \text{e} \quad \mathbf{C}_2 = \mathbf{I}_p,$$

obtem-se

$$\widehat{\mathbf{B}} \perp \mathbf{E}_{\text{res}} \mid \mathbf{Z}. \quad (12.60)$$

Esse resultado generaliza a independência entre média e covariância amostrais. No modelo contendo somente intercepto,

$$\widehat{\mathbf{B}} = \bar{\mathbf{X}}^\top$$

e

$$\mathbf{E}_{\text{res}} = (n - 1)\mathbf{S}.$$

Papel da normalidade

A ortogonalidade entre as projeções garante covariância cruzada nula entre as parcelas estimada e residual.

A conclusão de **independência** utiliza adicionalmente a normalidade conjunta. Fora do modelo normal, ortogonalidade das projeções não implica, por si só, independência entre as estatísticas correspondentes.

12.8.4 Momentos

A esperança da matriz Wishart é obtida diretamente da construção por produtos externos.

Proposição 12.12 (Momentos de uma matriz Wishart). *Se*

$$\mathbf{W} \sim W_p(\nu, \Sigma),$$

pela construção em Definição 12.2, então

$$E(\mathbf{W}) = \nu \Sigma. \quad (12.61)$$

Para os elementos da matriz,

$$\text{Cov}(W_{jk}, W_{\ell m}) = \nu (\sigma_{j\ell} \sigma_{km} + \sigma_{jm} \sigma_{k\ell}). \quad (12.62)$$

i Demonstração

Pela construção em Equação 12.9,

$$W_{jk} = \sum_{h=1}^{\nu} U_{hj} U_{hk}.$$

Como

$$E(U_{hj} U_{hk}) = \sigma_{jk},$$

segue que

$$E(W_{jk}) = \nu \sigma_{jk}.$$

Portanto,

$$E(\mathbf{W}) = \nu \Sigma.$$

A expressão para

$$\text{Cov}(W_{jk}, W_{\ell m})$$

decorre dos momentos de quarta ordem do vetor normal de média zero e da independência entre os ν vetores geradores (Muirhead, 1982).

Em particular,

$$\text{Var}(W_{jj}) = 2\nu \sigma_{jj}^2, \quad (12.63)$$

e, para $j \neq k$,

$$\text{Var}(W_{jk}) = \nu (\sigma_{jj} \sigma_{kk} + \sigma_{jk}^2). \quad (12.64)$$

Dividindo pelos graus de liberdade,

$$E\left(\frac{\mathbf{W}}{\nu}\right) = \Sigma.$$

Além disso, Equação 12.62 implica

$$\text{Cov}\left(\frac{W_{jk}}{\nu}, \frac{W_{\ell m}}{\nu}\right) = \frac{\sigma_{j\ell} \sigma_{km} + \sigma_{jm} \sigma_{k\ell}}{\nu}.$$

Portanto, para Σ fixa, a variabilidade dos elementos de $\mathbf{W}/\nu$ diminui à medida que ν aumenta.

A esperança obtida pela distribuição de Wishart é consistente com Proposição 10.7 e Proposição 10.8.

A esperança fornecida pela distribuição de Wishart coincide com Proposição 11.2.

12.8.5 Formas quadráticas

A analogia com a distribuição qui-quadrado também aparece em qualquer direção fixa do espaço das variáveis.

Proposição 12.13 (Forma quadrática de uma matriz Wishart). *Se*

$$\mathbf{W} \sim W_p(\nu, \Sigma)$$

pela construção em Definição 12.2, então, para qualquer

$$\mathbf{a} \in \mathbb{R}^p, \quad \mathbf{a} \neq \mathbf{0},$$

vale

$$\frac{\mathbf{a}^\top \mathbf{W} \mathbf{a}}{\mathbf{a}^\top \Sigma \mathbf{a}} \sim \chi_\nu^2. \quad (12.65)$$

i Demonstração

De Equação 12.9,

$$\mathbf{a}^\top \mathbf{W} \mathbf{a} = \sum_{j=1}^{\nu} (\mathbf{a}^\top \mathbf{U}_j)^2.$$

Por Proposição 9.4,

$$\mathbf{a}^\top \mathbf{U}_j \sim N(0, \mathbf{a}^\top \Sigma \mathbf{a}).$$

Assim, as variáveis

$$\frac{\mathbf{a}^\top \mathbf{U}_j}{\sqrt{\mathbf{a}^\top \Sigma \mathbf{a}}}$$

são normais padrão independentes. A soma de seus quadrados possui distribuição χ_ν^2 .

Assim, cada projeção univariada de uma matriz Wishart recupera a estrutura qui-quadrado correspondente à variância naquela direção.

12.8.6 Consequências adicionais para a matriz de covariâncias amostral

Pela Proposição 12.13, para qualquer

$$\mathbf{a} \neq \mathbf{0},$$

tem-se

$$\frac{(n-1)\mathbf{a}^\top \mathbf{S} \mathbf{a}}{\mathbf{a}^\top \Sigma \mathbf{a}} \sim \chi_{n-1}^2. \quad (12.66)$$

Assim, a variância amostral de qualquer combinação linear fixa possui a mesma estrutura qui-quadrado conhecida do caso univariado.

Para os elementos de $\mathbf{S}$,

$$\text{Cov}(S_{jk}, S_{\ell m}) = \frac{\sigma_{j\ell}\sigma_{km} + \sigma_{jm}\sigma_{k\ell}}{n-1}. \quad (12.67)$$

Em particular,

$$\text{Var}(S_{jj}) = \frac{2\sigma_{jj}^2}{n-1}$$

e, para $j \neq k$,

$$\text{Var}(S_{jk}) = \frac{\sigma_{jj}\sigma_{kk} + \sigma_{jk}^2}{n-1}.$$

Esses resultados são exatos sob normalidade multivariada.

12.8.7 Extensões das transformações da Wishart

A Proposição 12.4 estabelece a transformação de uma matriz Wishart quando $\mathbf{L}$ possui posto linha completo. Se $\mathbf{L}$ não possui posto linha completo,

$$\mathbf{L}\Sigma\mathbf{L}^\top$$

é singular e a distribuição fica restrita ao subespaço imagem de $\mathbf{L}$. Essa extensão singular não será necessária na sequência principal.

Tomando

$$\mathbf{L} = \Sigma^{-1/2},$$

com a raiz quadrada principal definida em Definição 5.7, obtém-se

$$\Sigma^{-1/2}\mathbf{W}\Sigma^{-1/2} \sim W_p(\nu, \mathbf{I}_p). \quad (12.68)$$

A transformação remove a matriz de escala da distribuição, de modo análogo ao branqueamento normal em Equação 9.23.

12.8.8 Densidade da distribuição de Wishart

Representação por produtos externos e densidade

A construção por produtos externos em Definição 12.2 determina a parametrização $W_p(\nu, \Sigma)$ utilizada nos resultados exatos baseados na estrutura normal–Wishart.

A densidade estende a família Wishart não singular para graus de liberdade reais $\nu > p-1$ e explicita sua forma no cone das matrizes simétricas positivas definidas.

A construção em Definição 12.2 utiliza um número inteiro de vetores normais. A família Wishart não singular admite uma extensão para graus de liberdade reais

$$\nu > p - 1$$

por meio de sua densidade no cone das matrizes simétricas positivas definidas (Muirhead, 1982).

Proposição 12.14 (Densidade da distribuição de Wishart). *Se*

$$\mathbf{W} \sim W_p(\nu, \Sigma),$$

com

$$\nu > p - 1$$

e

$$\Sigma \succ \mathbf{0},$$

então sua densidade é

$$f_{\mathbf{W}}(\mathbf{W}) = \frac{|\mathbf{W}|^{(\nu-p-1)/2} \exp \left[-\frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{W}) \right]}{2^{\nu p/2} |\Sigma|^{\nu/2} \Gamma_p(\nu/2)}, \quad (12.69)$$

para

$$\mathbf{W} \succ \mathbf{0}.$$

A função gama multivariada é

$$\Gamma_p(a) = \pi^{p(p-1)/4} \prod_{j=1}^p \Gamma\left(a - \frac{j-1}{2}\right), \quad (12.70)$$

definida para

$$a > \frac{p-1}{2}.$$

Quando a Wishart é construída pela soma de ν produtos externos e

$$\nu < p,$$

a matriz é singular com probabilidade 1. Nesse caso, sua distribuição está concentrada em matrizes positivas semidefinidas de posto ν e não possui a densidade anterior no cone positivo definido.

Nos resultados inferenciais desenvolvidos no núcleo deste capítulo, os graus de liberdade provêm do tamanho amostral ou do posto de matrizes de projeção e são inteiros.

12.8.9 Distribuição da SQPC da hipótese sob H_0

Sob o modelo linear normal multivariado, a SQPC associada à hipótese e a SQPC residual correspondente possuem distribuições Wishart independentes (Anderson, 2003). Esse resultado fornece a estrutura probabilística que será utilizada posteriormente na inferência multivariada do modelo linear.

Proposição 12.15 (Distribuições da SQPC da hipótese e da SQPC residual). *Sob o modelo linear normal multivariado, com*

$$\Sigma \succ \mathbf{0},$$

considere a hipótese

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0. \quad (12.71)$$

A matriz

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q}, \quad \mathbf{C}_1 = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Z}, \quad \text{posto}(\mathbf{C}_1) = g,$$

representa g funções estimáveis linearmente independentes.

Além disso,

$$\mathbf{C}_2 \in \mathbb{R}^{p \times s}, \quad \text{posto}(\mathbf{C}_2) = s.$$

Defina

$$r = \text{posto}(\mathbf{Z}), \quad n - r \geq 1,$$

e

$$\Sigma_{C_2} = \mathbf{C}_2^\top \Sigma \mathbf{C}_2.$$

O afastamento aleatório da hipótese é

$$\mathcal{D} = \mathbf{C}_1 \mathbf{Z}^+ \mathcal{Y} \mathbf{C}_2 - \Theta_0. \quad (12.72)$$

Além disso,

$$\mathbf{V}_{C_1} = \mathbf{C}_1 \mathbf{Z}^+ (\mathbf{Z}^+)^{\top} \mathbf{C}_1^{\top}.$$

Sob H_0 ,

$$\mathcal{D} \mid \mathbf{Z} \sim N_{g \times s} \left(\mathbf{0}, \mathbf{V}_{C_1}, \Sigma_{C_2} \right). \quad (12.73)$$

Defina

$$\mathbf{H} = \mathcal{D}^{\top} \mathbf{V}_{C_1}^{-1} \mathcal{D} \quad (12.74)$$

e

$$\mathbf{E}_{C_2} = \mathbf{C}_2^{\top} \mathbf{E}_{\text{res}} \mathbf{C}_2. \quad (12.75)$$

Então,

$$\mathbf{H} \mid \mathbf{Z} \sim W_s \left(g, \Sigma_{C_2} \right) \quad (12.76)$$

e

$$\mathbf{E}_{C_2} \mid \mathbf{Z} \sim W_s \left(n - r, \Sigma_{C_2} \right). \quad (12.77)$$

Além disso,

$$\mathbf{H} \perp \mathbf{E}_{C_2} \mid \mathbf{Z}. \quad (12.78)$$

i Demonstração

Sob H_0 ,

$$\mathbf{V}_{C_1}^{-1/2} \mathcal{D} \mid \mathbf{Z} \sim N_{g \times s}(\mathbf{0}, \mathbf{I}_g, \Sigma_{C_2}).$$

Portanto, suas g linhas são vetores independentes com distribuição

$$N_s(\mathbf{0}, \Sigma_{C_2}).$$

Como

$$\mathbf{H} = (\mathbf{V}_{C_1}^{-1/2} \mathcal{D})^\top (\mathbf{V}_{C_1}^{-1/2} \mathcal{D}),$$

Definição 12.2 fornece

$$\mathbf{H} \mid \mathbf{Z} \sim W_s(g, \Sigma_{C_2}).$$

Por Proposição 12.4,

$$\mathbf{E}_{C_2} = \mathbf{C}_2^\top \mathbf{E}_{\text{res}} \mathbf{C}_2 \mid \mathbf{Z} \sim W_s(n - r, \Sigma_{C_2}).$$

A independência decorre de Proposição 12.11.

As duas matrizes possuem a mesma matriz de escala,

$$\Sigma_{C_2},$$

mas graus de liberdade diferentes:

- g corresponde ao número de combinações linearmente independentes dos termos do modelo definidas por $\mathbf{C}_1$;
- $n - r$ corresponde à dimensão do espaço residual.

Como

$$\text{posto}(\mathbf{C}_1) = g \quad \text{e} \quad \text{posto}(\mathbf{C}_2) = s,$$

a hipótese contém gs restrições escalares independentes.

O grau de liberdade da distribuição Wishart de $\mathbf{H}$ é, entretanto, g , porque a SQPC da hipótese é construída a partir de g vetores aleatórios no espaço das s combinações de respostas.

Por Proposição 12.2,

$$\text{posto}(\mathbf{H}) = \min(g, s)$$

e

$$\text{posto}(\mathbf{E}_{C_2}) = \min(n - r, s)$$

com probabilidade 1.

Em particular,

$$\mathbf{E}_{C_2} \succ \mathbf{0}$$

com probabilidade 1 se, e somente se,

$$n - r \geq s. \quad (12.79)$$

As distribuições obtidas nesta seção fornecem a estrutura probabilística geral para hipóteses lineares multivariadas.

Quando

$$\mathbf{C}_2 = \mathbf{I}_p,$$

obtém-se, sob H_0 ,

$$\mathbf{H} \mid \mathbf{Z} \sim W_p(g, \Sigma)$$

e

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(n - r, \Sigma),$$

com independência entre as duas matrizes. Sob H_0 , a distribuição conjunta de $\mathbf{H}$ e $\mathbf{E}_{\text{res}}$ sustenta testes globais que comparam a variação associada à hipótese com a variação residual.

Distribuição da SQPC da hipótese sob H_1

Em Proposição 12.15, a hipótese nula corresponde a

$$\mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0.$$

Sob H_1 , o afastamento populacional é

$$\Delta_0 = \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 - \Theta_0. \quad (12.80)$$

Quando

$$\Delta_0 \neq \mathbf{0},$$

a SQPC $\mathbf{H}$ possui distribuição Wishart não central. A matriz

$$\mathbf{E}_{C_2}$$

mantém sua distribuição Wishart central e permanece independente de $\mathbf{H}$ (Anderson, 2003).

A não centralidade incorpora o afastamento entre $\mathbf{C}_1 \mathbf{B} \mathbf{C}_2$ e Θ_0 e será relevante para o estudo do poder. Sua parametrização detalhada não será necessária neste capítulo.

12.8.10 Resultado assintótico de Wilks

Para a razão de verossimilhanças definida em Definição 12.3, o teorema de Wilks fornece uma calibração qui-quadrado assintótica sob condições de regularidade. Essas condições utilizam a Jacobiana de Definição 7.4, a Hessiana de Definição 7.5, o vetor escore de Definição 7.12, a informação observada de Definição 7.13 e a informação de Fisher de Definição 7.14.

Teorema 12.4 (Resultado assintótico de Wilks). *Considere um espaço paramétrico*

$$\mathcal{P} \subseteq \mathbb{R}^k,$$

com k fixo quando $n \rightarrow \infty$, e um parâmetro verdadeiro

$$\vartheta_0 \in \text{int}(\mathcal{P}).$$

Considere a hipótese

$$H_0 : \vartheta \in \mathcal{P}_0,$$

em que, em uma vizinhança de ϑ_0 ,

$$\mathcal{P}_0 = \{\vartheta \in \mathcal{P} : \mathbf{h}(\vartheta) = \mathbf{0}\},$$

com

$$\mathbf{h} : \mathcal{P} \longrightarrow \mathbb{R}^d$$

continuamente diferenciável e

$$\text{posto} [\mathbf{J}_{\mathbf{h}}(\vartheta_0)] = d,$$

com d fixo.

Seja

$$\ell_n(\vartheta) = \log L_n(\vartheta).$$

Suponha que:

- 1. o modelo seja identificável;*
- 2. $\ell_n(\vartheta)$ seja duas vezes continuamente diferenciável em uma vizinhança de ϑ_0 ;*
- 3. exista uma matriz*

$$\mathbf{I}(\vartheta_0) \succ \mathbf{0}$$

tal que

$$\frac{1}{\sqrt{n}} \nabla \ell_n(\vartheta_0) \xrightarrow{d} N_k[\mathbf{0}, \mathbf{I}(\vartheta_0)];$$

- 4. para toda sequência*

$$\vartheta_n \xrightarrow{P} \vartheta_0,$$

tem-se

$$-\frac{1}{n} \nabla^2 \ell_n(\vartheta_n) \xrightarrow{P} \mathbf{I}(\vartheta_0);$$

5. os estimadores de máxima verossimilhança irrestrito e restrito existem e satisfazem

$$\hat{\vartheta}_n \xrightarrow{P} \vartheta_0$$

e

$$\tilde{\vartheta}_n \xrightarrow{P} \vartheta_0$$

sob H_0 .

Então, sob H_0 ,

$$-2 \log \Lambda_{\text{RV}} \xrightarrow{d} \chi_d^2. \quad (12.81)$$

O número d corresponde ao número de restrições localmente independentes impostas por H_0 e satisfaz

$$d = \dim(\mathcal{P}) - \dim(\mathcal{P}_0)$$

na vizinhança de ϑ_0 .

(Vaart, 1998)

O resultado é assintótico (Vaart, 1998). Para uma amostra grande, uma região crítica aproximada de nível α é

$$-2 \log \Lambda_{\text{RV}} > \chi_{d;1-\alpha}^2. \quad (12.82)$$

O correspondente valor- p aproximado é

$$P \left[\chi_d^2 \geq -2 \log \Lambda_{\text{RV,obs}} \right]. \quad (12.83)$$

O número

$$d$$

não deve ser obtido simplesmente pela contagem de todas as expressões escritas na hipótese. Ele corresponde ao número de restrições **localmente independentes** ou, equivalentemente em situações regulares, à diferença entre as dimensões dos espaços paramétricos irrestrito e restrito.

Situações não regulares

A aproximação qui-quadrado do Teorema 12.4 não se aplica automaticamente quando:

- o parâmetro verdadeiro está na fronteira do espaço paramétrico;
- o modelo não é identificável;
- há restrições redundantes;
- a informação de Fisher é singular;
- a dimensão do parâmetro cresce com o tamanho amostral.

Nessas situações, a distribuição limite pode ser diferente de uma qui-quadrado convencional.

O **teorema de Wilks** em Teorema 12.4 é um resultado assintótico geral sobre razões de verossimilhanças. Ele deve ser distinguido da **lambda de Wilks**, que é uma estatística matricial específica utilizada posteriormente na MANOVA.

12.8.11 Razão de verossimilhanças em modelos normais encaixados

O princípio da razão de verossimilhanças pode ser aplicado aos modelos lineares multivariados encaixados de Proposição 11.13.

Considere a comparação entre um modelo completo e um modelo reduzido encaixado. A matriz $\mathbf{H}$ representa a redução da SQPC residual obtida pela inclusão, no modelo completo, dos termos ausentes no modelo reduzido.

Sob o modelo normal matricial com matriz de covariâncias residual comum, a verossimilhança maximizada é proporcional a $|\mathbf{E}|^{-n/2}$. A razão de verossimilhanças pode, portanto, ser expressa por meio dos determinantes das SQPCs residuais dos dois modelos.

Proposição 12.16 (Razão de verossimilhanças em modelos normais encaixados). *Considere modelos lineares normais multivariados completo e reduzido, definidos sobre as mesmas n unidades, com matriz de covariâncias residual comum*

$$\Sigma \succ \mathbf{0},$$

e tais que

$$\mathcal{C}(\mathbf{Z}_R) \subseteq \mathcal{C}(\mathbf{Z}_F).$$

Se suas SQPCs residuais $\mathbf{E}_F$ e $\mathbf{E}_R$ são positivas definidas e

$$\mathbf{E}_R = \mathbf{E}_F + \mathbf{H} \quad (12.84)$$

e

$$\mathbf{H} \succeq \mathbf{0},$$

então

$$\Lambda_{\text{RV}} = \left(\frac{|\mathbf{E}_F|}{|\mathbf{E}_R|} \right)^{n/2}. \quad (12.85)$$

Equivalentemente,

$$\Lambda_{\text{RV}} = \left[\frac{|\mathbf{E}_F|}{|\mathbf{E}_F + \mathbf{H}|} \right]^{n/2}. \quad (12.86)$$

A razão de determinantes

$$\Lambda_{\text{W}} = \frac{|\mathbf{E}_F|}{|\mathbf{E}_F + \mathbf{H}|} \quad (12.87)$$

é denominada **lambda de Wilks**. Assim,

$$\Lambda_{\text{RV}} = \Lambda_{\text{W}}^{n/2}. \quad (12.88)$$

Portanto, Λ_{RV} e Λ_{W} são funções monotônicas uma da outra e conduzem à mesma ordenação das evidências contra H_0 .

Neste capítulo, a lambda de Wilks aparece como consequência da razão de verossimilhanças em modelos normais encaixados. Sua distribuição e sua utilização como critério específico da MANOVA serão desenvolvidas no Módulo 3.

Como

$$\mathbf{H} \succeq \mathbf{0},$$

a imposição das restrições do modelo reduzido não diminui a SQPC residual na ordem de Löwner:

$$\mathbf{E}_R \succeq \mathbf{E}_F.$$

Quando ambas são positivas definidas,

$$|\mathbf{E}_R| \geq |\mathbf{E}_F|,$$

e, portanto,

$$0 < \Lambda_{RV} \leq 1.$$

Valores de Λ_W próximos de 1 indicam pequena diferença entre os ajustes completo e reduzido. Valores menores indicam maior redução da dispersão residual quando os termos adicionais do modelo completo são incluídos.

A decomposição desse critério por raízes características e sua relação com os demais critérios multivariados pertencem à MANOVA.

Existência da forma por determinantes

A expressão em Equação 12.85 exige que as matrizes residuais relevantes sejam positivas definidas.

Sob o modelo normal, uma condição suficiente para

$$\mathbf{E}_F \succ \mathbf{0}$$

com probabilidade 1 é

$$n - r_F \geq p,$$

em que

$$r_F = \text{posto}(\mathbf{Z}_F).$$

Como

$$\mathbf{E}_R = \mathbf{E}_F + \mathbf{H}$$

e

$$\mathbf{H} \succeq \mathbf{0},$$

a definição positiva de $\mathbf{E}_F$ implica a definição positiva de $\mathbf{E}_R$.

Quando a SQPC residual é singular, a razão de determinantes clássica deixa de estar disponível na forma anterior. Pseudoinversas, pseudodeterminantes ou regularização definem procedimentos diferentes e não preservam automaticamente a distribuição nula utilizada pela inferência clássica.

12.8.12 Inferência sobre o vetor de médias com covariância conhecida

Pela Proposição 12.1,

$$\bar{\mathbf{X}} \sim N_p \left(\mu, \frac{\Sigma}{n} \right).$$

Sob H_0 ,

$$\sqrt{n} \Sigma^{-1/2} (\bar{\mathbf{X}} - \mu_0) \sim N_p (\mathbf{0}, \mathbf{I}_p).$$

Definição 12.6 (Estatística para a média com covariância conhecida). Quando $\Sigma \succ \mathbf{0}$ é conhecida, define-se

$$Q_\mu = n (\bar{\mathbf{X}} - \mu_0)^\top \Sigma^{-1} (\bar{\mathbf{X}} - \mu_0). \quad (12.89)$$

A forma quadrática utiliza a distância de Mahalanobis definida em Definição 8.8. Como

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n},$$

o fator n ajusta a distância à variabilidade da média amostral, e não à variabilidade de uma observação individual.

Proposição 12.17 (Distribuição com covariância conhecida). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com $\Sigma \succ \mathbf{0}$ conhecida, então, sob

$$H_0 : \mu = \mu_0,$$

tem-se

$$Q_\mu \sim \chi_p^2. \quad (12.90)$$

O resultado decorre de Proposição 9.8 aplicado à distribuição da média amostral em Proposição 12.1. A matriz de covariâncias da média é Σ/n , o que produz a forma em Equação 12.89.

Assim, um teste de nível α rejeita H_0 quando

$$Q_{\mu,\text{obs}} > \chi_{p;1-\alpha}^2, \quad (12.91)$$

em que

$$Q_{\mu,\text{obs}} = n \left(\bar{\mathbf{x}} - \mu_0 \right)^\top \Sigma^{-1} \left(\bar{\mathbf{x}} - \mu_0 \right). \quad (12.92)$$

O valor- p é

$$P \left(\chi_p^2 \geq Q_{\mu,\text{obs}} \right). \quad (12.93)$$

Sob uma alternativa fixa, a distribuição torna-se qui-quadrado não central, com parâmetro

$$\lambda_\mu = n \left(\mu - \mu_0 \right)^\top \Sigma^{-1} \left(\mu - \mu_0 \right). \quad (12.94)$$

Assim, a não centralidade cresce com o tamanho amostral e com o afastamento entre μ e μ_0 medido na geometria de Σ . Esse parâmetro será utilizado apenas como referência para a interpretação do poder.

Quando

$$p = 1,$$

obtém-se

$$Q_\mu = \frac{n \left(\bar{X} - \mu_0 \right)^2}{\sigma^2},$$

que corresponde ao quadrado da estatística normal padronizada utilizada no teste de uma média com variância conhecida.

Sob uma alternativa fixa, a transformação de T^2 possui distribuição F não central, com o mesmo parâmetro λ_μ definido em Equação 12.94. Essa distribuição é utilizada em estudos de poder e não será desenvolvida adicionalmente neste capítulo.

12.8.13 Invariância afim do T^2 de Hotelling

A estatística T^2 de Hotelling definida em Definição 12.4 é invariante a transformações afins com parte linear não singular. Se

$$\mathbf{Y}_i = \mathbf{A}\mathbf{X}_i + \mathbf{b}, \quad \det(\mathbf{A}) \neq 0,$$

então Proposição 8.6 fornece

$$\mathbf{S}_Y = \mathbf{A}\mathbf{S}\mathbf{A}^\top.$$

Como

$$(\mathbf{A}\mathbf{S}\mathbf{A}^\top)^{-1} = \mathbf{A}^{-\top}\mathbf{S}^{-1}\mathbf{A}^{-1},$$

os fatores $\mathbf{A}$ se cancelam na forma quadrática e o valor de T^2 permanece inalterado.

12.8.14 Hipóteses lineares sobre o vetor de médias

A hipótese

$$H_0 : \mu = \mu_0$$

especifica todo o vetor de médias. Em outros problemas, o interesse está restrito a determinadas combinações lineares (Anderson, 2003).

Considere

$$\mathbf{A} \in \mathbb{R}^{h \times p},$$

com

$$\text{posto}(\mathbf{A}) = h \leq p,$$

e

$$\mathbf{d} \in \mathbb{R}^h.$$

A hipótese é

$$H_0 : \mathbf{A}\mu = \mathbf{d}. \quad (12.95)$$

Cada linha de $\mathbf{A}$ define uma restrição linear. A condição de posto linha completo elimina restrições redundantes.

Defina

$$\mathbf{U}_i = \mathbf{A}\mathbf{X}_i.$$

A distribuição decorre diretamente de Proposição 9.4.

Como $\mathbf{A}$ possui posto linha completo e

$$\Sigma \succ \mathbf{0},$$

tem-se

$$\mathbf{A}\Sigma\mathbf{A}^\top \succ \mathbf{0}.$$

A média e a covariância amostrais transformadas são

$$\bar{\mathbf{U}} = \mathbf{A}\bar{\mathbf{X}}$$

e

$$\mathbf{S}_U = \mathbf{A}\mathbf{S}\mathbf{A}^\top.$$

Assim, o problema reduz-se exatamente à inferência sobre um vetor de médias de dimensão h .

12.8.14.1 Covariância conhecida

Quando Σ é conhecida, defina

$$Q_A = n (\mathbf{A}\bar{\mathbf{X}} - \mathbf{d})^\top (\mathbf{A}\Sigma\mathbf{A}^\top)^{-1} (\mathbf{A}\bar{\mathbf{X}} - \mathbf{d}). \quad (12.96)$$

Sob H_0 ,

$$Q_A \sim \chi_h^2. \quad (12.97)$$

Esse é Proposição 12.17 aplicado ao vetor transformado $\mathbf{U}_i$. Portanto, os graus de liberdade são determinados pelas h combinações linearmente independentes presentes na hipótese, e não pela dimensão original p .

12.8.14.2 Covariância desconhecida

Sob normalidade,

$$\mathbf{A}\mathbf{S}\mathbf{A}^\top \succ \mathbf{0}$$

com probabilidade 1 quando

$$n > h. \quad (12.98)$$

Proposição 12.18 (Distribuição para hipóteses lineares sobre a média). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

e

$$\mathbf{A} \in \mathbb{R}^{h \times p}, \quad 1 \leq h \leq p, \quad \text{posto}(\mathbf{A}) = h, \quad \mathbf{d} \in \mathbb{R}^h, \quad n > h,$$

então, sob

$$H_0 : \mathbf{A}\mu = \mathbf{d},$$

a estatística

$$\mathbf{T}_A^2 = n (\mathbf{A}\bar{\mathbf{X}} - \mathbf{d})^\top (\mathbf{A}\mathbf{S}\mathbf{A}^\top)^{-1} (\mathbf{A}\bar{\mathbf{X}} - \mathbf{d}) \quad (12.99)$$

satisfaz

$$\frac{n-h}{h(n-1)} \mathbf{T}_A^2 \sim F_{h,n-h}. \quad (12.100)$$

O resultado é Proposição 12.6 aplicado aos vetores transformados

$$\mathbf{U}_i = \mathbf{A}\mathbf{X}_i \in \mathbb{R}^h.$$

Por isso, a condição dimensional passa de $n > p$ para $n > h$.

Assim, um teste de nível α rejeita H_0 quando

$$\mathbf{T}_{A,\text{obs}}^2 > \frac{h(n-1)}{n-h} F_{h,n-h;1-\alpha}, \quad (12.101)$$

em que

$$\mathbf{T}_{A,\text{obs}}^2 = n (\mathbf{A}\bar{\mathbf{x}} - \mathbf{d})^\top (\mathbf{A}\mathbf{S}\mathbf{A}^\top)^{-1} (\mathbf{A}\bar{\mathbf{x}} - \mathbf{d}). \quad (12.102)$$

Uma consequência importante é que a condição dimensional depende de

$$h,$$

e não necessariamente de p .

Assim, mesmo quando

$$p \geq n$$

e a matriz completa

$$\mathbf{S}$$

é singular, uma hipótese de dimensão reduzida ainda pode admitir a inferência clássica se

$$n > h$$

e

$$\mathbf{A}\mathbf{S}\mathbf{A}^\top$$

for não singular.

Quando

$$h = 1,$$

com

$$\mathbf{A} = \mathbf{a}^\top,$$

a hipótese

$$H_0 : \mathbf{a}^\top \mu = d$$

reduz-se ao teste t univariado aplicado à combinação linear

$$\mathbf{a}^\top \mathbf{X}.$$

Quando

$$h = p, \quad \mathbf{A} = \mathbf{I}_p, \quad \mathbf{d} = \mu_0,$$

recupera-se o teste T^2 para o vetor completo de médias.

12.8.14.3 Hipóteses de dimensão reduzida

Para

$$H_0 : \mathbf{A}\mu = \mathbf{d},$$

com

$$\text{posto}(\mathbf{A}) = h,$$

a matriz relevante é

$$\mathbf{A}\mathbf{S}\mathbf{A}^\top.$$

A condição clássica passa a ser

$$n > h.$$

Portanto, a singularidade da matriz completa $\mathbf{S}$ não impede necessariamente a inferência sobre combinações previamente especificadas de dimensão menor.

12.8.15 Relação com o modelo linear multivariado

O modelo de uma única população pode ser escrito como

$$y = \mathbf{1}_n \mu^\top + \mathcal{E}.$$

Nesse caso,

$$\mathbf{Z} = \mathbf{1}_n$$

e

$$\mathbf{B} = \mu^\top.$$

Na hipótese geral de Definição 11.15,

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0,$$

tome

$$\mathbf{C}_1 = [1], \quad \mathbf{C}_2 = \mathbf{A}^\top$$

e

$$\Theta_0 = \mathbf{d}^\top.$$

Então,

$$\mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \mu^\top \mathbf{A}^\top = (\mathbf{A} \mu)^\top.$$

Portanto,

$$H_0 : \mathbf{A} \mu = \mathbf{d}$$

é um caso particular da hipótese linear geral do Capítulo 11.

Essa correspondência mostra que o teste T^2 para uma média, as hipóteses sobre combinações lineares e a inferência no modelo linear multivariado utilizam a mesma estrutura. A comparação entre dois vetores de médias foi desenvolvida no núcleo do capítulo, com o caso de duas amostras independentes formalizado em Definição 12.5.

12.9 Aprofundamentos metodológicos e aplicados

12.9.1 Região de confiança elipsoidal

A região de confiança para μ é obtida reunindo todos os vetores que não seriam rejeitados pelo teste T^2 ao nível α . Essa inversão do teste produz uma região simultânea para todo o vetor de médias.

Proposição 12.19 (Região de confiança para o vetor de médias). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

com

$$n > p \quad \text{e} \quad 0 < \alpha < 1,$$

defina

$$c_{\alpha,p,n} = \frac{p(n-1)}{n-p} F_{p,n-p;1-\alpha}. \quad (12.103)$$

Então,

$$\mathcal{C}_{1-\alpha} = \left\{ \theta \in \mathbb{R}^p : n (\bar{\mathbf{X}} - \theta)^\top \mathbf{S}^{-1} (\bar{\mathbf{X}} - \theta) \leq c_{\alpha,p,n} \right\} \quad (12.104)$$

possui cobertura

$$P(\mu \in \mathcal{C}_{1-\alpha}) = 1 - \alpha. \quad (12.105)$$

Após a observação,

$$\mathcal{C}_{1-\alpha} = \left\{ \theta \in \mathbb{R}^p : (\theta - \bar{\mathbf{x}})^\top \mathbf{S}^{-1} (\theta - \bar{\mathbf{x}}) \leq \frac{c_{\alpha,p,n}}{n} \right\}. \quad (12.106)$$

A dualidade entre teste e região de confiança fornece

$$\mu_0 \in \mathcal{C}_{1-\alpha} \iff T_{\text{obs}}^2(\mu_0) \leq c_{\alpha,p,n}. \quad (12.107)$$

12.9.2 Geometria da região

A região observada é um elipsoide centrado em

$$\bar{\mathbf{x}}.$$

Considere a decomposição espectral

$$\mathbf{S} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^\top,$$

com

$$\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_p).$$

Em coordenadas espectrais, sua fronteira é

$$\sum_{j=1}^p \frac{z_j^2}{c_{\alpha,p,n} \lambda_j / n} = 1. \quad (12.108)$$

Consequentemente, os eixos do elipsoide são os autovetores de $\mathbf{S}$ e o comprimento do j -ésimo semieixo é

$$a_j = \sqrt{\frac{c_{\alpha,p,n} \lambda_j}{n}}. \quad (12.109)$$

A forma da região é a mesma estrutura elipsoidal de Equação 8.32, agora centrada em $\bar{\mathbf{x}}$ e escalada pela constante inferencial $c_{\alpha,p,n}/n$. A orientação e os comprimentos dos eixos decorrem da decomposição espectral utilizada em Equação 8.26.

A Figura 12.1 mostra, no caso bidimensional, como a covariância altera a orientação da região de confiança.




Figura 12.1: Efeito da matriz de covariâncias sobre a forma e a orientação da região de confiança para o vetor de médias.

Na primeira configuração da Figura 12.1, os eixos permanecem alinhados às coordenadas originais. Na segunda, a covariância positiva produz rotação do elipsoide. A região reflete, portanto, tanto as variâncias marginais quanto a dependência entre as componentes.

Interpretação da cobertura

Antes da observação dos dados,

$$\mathcal{C}_{1-\alpha}$$

é uma região aleatória que contém o verdadeiro vetor μ com probabilidade $1 - \alpha$.

Depois da observação, a região está fixada. Na interpretação frequentista, o parâmetro não passa a ser aleatório; a cobertura refere-se ao comportamento do procedimento em repetições amostrais.

12.9.3 Intervalos simultâneos

Cada vetor

$$\mathbf{a} \in \mathbb{R}^p$$

define uma combinação linear $\mathbf{a}^\top \mu$. Como todos esses funcionais são obtidos da mesma região elipsoidal, é possível construir intervalos com cobertura simultânea para todas as direções.

Proposição 12.20 (Intervalos simultâneos de Hotelling). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

com

$$n > p \quad e \quad 0 < \alpha < 1,$$

e

$$c_{\alpha,p,n} = \frac{p(n-1)}{n-p} F_{p,n-p;1-\alpha},$$

os intervalos

$$\mathbf{a}^\top \bar{\mathbf{X}} \pm \sqrt{\frac{c_{\alpha,p,n}}{n} \mathbf{a}^\top \mathbf{S} \mathbf{a}}, \quad \mathbf{a} \in \mathbb{R}^p, \quad (12.110)$$

possuem cobertura simultânea $1 - \alpha$ para todas as combinações lineares.

i Demonstração

Se

$$\mu \in \mathcal{C}_{1-\alpha},$$

então

$$(\mu - \bar{\mathbf{X}})^\top \mathbf{S}^{-1} (\mu - \bar{\mathbf{X}}) \leq \frac{c_{\alpha,p,n}}{n}.$$

Pela desigualdade de Cauchy–Schwarz na geometria induzida por $\mathbf{S}$,

$$|\mathbf{a}^\top (\mu - \bar{\mathbf{X}})| \leq \sqrt{\mathbf{a}^\top \mathbf{S} \mathbf{a}} \sqrt{(\mu - \bar{\mathbf{X}})^\top \mathbf{S}^{-1} (\mu - \bar{\mathbf{X}})}.$$

Substituindo o limite da região, obtém-se Equação 12.110 simultaneamente para todas as direções $\mathbf{a}$.

Após a observação dos dados,

$$\mathbf{a}^\top \mu \in \mathbf{a}^\top \bar{\mathbf{x}} \pm \sqrt{\frac{c_{\alpha,p,n}}{n} \mathbf{a}^\top \mathbf{S} \mathbf{a}}. \quad (12.111)$$

Para

$$\mathbf{a} = \mathbf{e}_j,$$

obtém-se o intervalo simultâneo para uma componente:

$$\mu_j \in \bar{x}_j \pm \sqrt{\frac{c_{\alpha,p,n} S_{jj}}{n}}. \quad (12.112)$$

Para

$$\mathbf{a} = \mathbf{e}_j - \mathbf{e}_k,$$

obtém-se

$$\mu_j - \mu_k \in \bar{x}_j - \bar{x}_k \pm \sqrt{\frac{c_{\alpha,p,n}}{n} (S_{jj} + S_{kk} - 2S_{jk})}. \quad (12.113)$$

Os intervalos de Hotelling fornecem cobertura simultânea para todas as combinações lineares $\mathbf{a}^\top \mu$. Quando o interesse está restrito a um conjunto finito e previamente especificado de combinações, procedimentos como Bonferroni utilizam uma família de inferências menor e podem produzir intervalos mais estreitos, dependendo da estrutura de covariâncias e do número de comparações.

12.9.4 Região de confiança e intervalos simultâneos para duas amostras independentes

A inversão do teste calibrado por Proposição 12.8 produz uma região de confiança para $\delta = \mu_1 - \mu_2$. Defina

$$c_{\alpha,p,n_1,n_2} = \frac{p(n_1 + n_2 - 2)}{n_1 + n_2 - p - 1} F_{p, n_1 + n_2 - p - 1; 1 - \alpha}. \quad (12.114)$$

A inversão do teste fornece uma região de confiança de nível $1 - \alpha$ para

$$\delta = \mu_1 - \mu_2 :$$

$$\mathcal{C}_{\delta, 1-\alpha} = \left\{ \theta \in \mathbb{R}^p : n_{\text{ef}} \left(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \theta \right)^\top \mathbf{S}_p^{-1} \left(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \theta \right) \leq c_{\alpha, p, n_1, n_2} \right\}. \quad (12.115)$$

A região é um elipsoide centrado em

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2,$$

com orientação determinada pela matriz de covariâncias agrupada.

Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

os intervalos derivados dessa região são

$$\mathbf{a}^\top (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2) \pm \sqrt{\frac{c_{\alpha, p, n_1, n_2}}{n_{\text{ef}}} \mathbf{a}^\top \mathbf{S}_p \mathbf{a}}. \quad (12.116)$$

Esses intervalos fornecem cobertura simultânea para todas as combinações lineares de δ .

Quando

$$p = 1,$$

o procedimento reduz-se ao quadrado do teste t para duas amostras independentes com variâncias populacionais iguais:

$$\mathsf{T}_{\text{ind}}^2 = \mathsf{t}_{\text{pooled}}^2. \quad (12.117)$$

12.9.5 Covariâncias populacionais distintas

O T^2 para duas amostras independentes de Definição 12.5 utiliza a hipótese

$$\Sigma_1 = \Sigma_2.$$

Se

$$\Sigma_1 \neq \Sigma_2,$$

a diferença entre as médias continua tendo, sob normalidade,

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 \sim N_p \left(\mu_1 - \mu_2, \frac{\Sigma_1}{n_1} + \frac{\Sigma_2}{n_2} \right). \quad (12.118)$$

Entretanto, a matriz agrupada satisfaz

$$E(\mathbf{S}_p) = \frac{(n_1 - 1)\Sigma_1 + (n_2 - 1)\Sigma_2}{n_1 + n_2 - 2},$$

e não estima diretamente

$$\frac{\Sigma_1}{n_1} + \frac{\Sigma_2}{n_2}.$$

Consequentemente, a estrutura normal–Wishart utilizada em Proposição 12.8 deixa de ser válida com a matriz agrupada, e a transformação para a distribuição F não é mais exata.

Papel da homogeneidade das covariâncias

A igualdade

$$\Sigma_1 = \Sigma_2$$

não é necessária para o T^2 de uma amostra nem para o procedimento pareado.

Ela é uma hipótese específica do procedimento de duas amostras independentes que utiliza a covariância agrupada.

Quando as covariâncias populacionais são distintas, o problema inferencial é diferente e requer outro procedimento ou outra aproximação. A simples substituição de $\mathbf{S}_p$ por uma matriz alternativa não preserva automaticamente a distribuição F clássica.

12.9.6 Observações pareadas

No delineamento pareado, considere

$$(\mathbf{X}_i, \mathbf{Y}_i), \quad i = 1, \dots, n,$$

em que os pares são independentes entre si, mas as duas medições dentro de cada par podem ser dependentes.

O número

$$n$$

representa o número de pares completos.

Defina

$$\mathbf{D}_i = \mathbf{X}_i - \mathbf{Y}_i. \quad (12.119)$$

O vetor médio das diferenças é

$$\delta = E(\mathbf{D}_i) = \mu_X - \mu_Y. \quad (12.120)$$

Sua matriz de covariâncias é

$$\Sigma_D = \Sigma_X + \Sigma_Y - \Sigma_{XY} - \Sigma_{YX}. \quad (12.121)$$

A expressão mostra por que a associação dentro dos pares deve ser preservada: ela participa diretamente da variabilidade das diferenças.

A hipótese é

$$H_0 : \delta = \delta_0. \quad (12.122)$$

Para comparar diretamente as duas condições,

$$\delta_0 = \mathbf{0}.$$

Depois de formar as diferenças, cada par produz um único vetor

$$\mathbf{D}_i.$$

A comparação entre as duas condições passa, portanto, a ser uma inferência sobre o vetor médio de uma única população de diferenças:

$$\mathbf{D}_1, \dots, \mathbf{D}_n.$$

Suponha

$$\mathbf{D}_1, \dots, \mathbf{D}_n \stackrel{\text{iid}}{\sim} N_p(\delta, \Sigma_D),$$

com

$$\Sigma_D \succ \mathbf{0}.$$

A média amostral das diferenças é

$$\bar{\mathbf{D}} = \frac{1}{n} \sum_{i=1}^n \mathbf{D}_i = \bar{\mathbf{X}} - \bar{\mathbf{Y}}. \quad (12.123)$$

A matriz de covariâncias amostral é

$$\mathbf{S}_D = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{D}_i - \bar{\mathbf{D}}) (\mathbf{D}_i - \bar{\mathbf{D}})^\top. \quad (12.124)$$

Quando as matrizes são calculadas sobre os mesmos pares completos,

$$\mathbf{S}_D = \mathbf{S}_X + \mathbf{S}_Y - \mathbf{S}_{XY} - \mathbf{S}_{YX}. \quad (12.125)$$

A decomposição populacional em Equação 12.121 utiliza a covariância cruzada definida em Definição 8.3. Sua contraparte amostral em Equação 12.125 utiliza a matriz definida em Definição 10.12.

Definição 12.7 (Estatística T^2 para observações pareadas). Para os vetores de diferenças pareadas

$$\mathbf{D}_i = \mathbf{X}_i - \mathbf{Y}_i, \quad i = 1, \dots, n,$$

com vetor de médias amostrais $\bar{\mathbf{D}}$ e matriz de covariâncias amostral $\mathbf{S}_D \succ \mathbf{0}$, define-se

$$\mathsf{T}_{\text{par}}^2 = n (\bar{\mathbf{D}} - \delta_0)^\top \mathbf{S}_D^{-1} (\bar{\mathbf{D}} - \delta_0). \quad (12.126)$$

Proposição 12.21 (Distribuição exata de T^2 para observações pareadas). *Se*

$$\mathbf{D}_1, \dots, \mathbf{D}_n \stackrel{\text{iid}}{\sim} N_p(\delta, \Sigma_D),$$

com

$$\Sigma_D \succ \mathbf{0}$$

e

$$n > p,$$

então, sob

$$H_0 : \delta = \delta_0,$$

tem-se

$$\frac{n-p}{p(n-1)} T_{\text{par}}^2 \sim F_{p, n-p}. \quad (12.127)$$

A proposição é Proposição 12.6 aplicada à amostra

$$\mathbf{D}_1, \dots, \mathbf{D}_n.$$

Por isso, o número de observações utilizado no teste é o número de pares completos.

Para os dados observados,

$$T_{\text{par,obs}}^2 = n (\bar{\mathbf{d}} - \delta_0)^\top \mathbf{S}_D^{-1} (\bar{\mathbf{d}} - \delta_0). \quad (12.128)$$

Um teste de nível α rejeita H_0 quando

$$T_{\text{par,obs}}^2 > \frac{p(n-1)}{n-p} F_{p, n-p; 1-\alpha}. \quad (12.129)$$

Quando

$$p = 1,$$

recupera-se o quadrado do teste t pareado:

$$T_{\text{par}}^2 = t_{\text{par}}^2. \quad (12.130)$$

Aplicando Proposição 12.19 à população de diferenças, obtém-se a região de confiança de nível $1 - \alpha$

$$\mathcal{C}_{D,1-\alpha} = \left\{ \theta \in \mathbb{R}^p : n (\bar{\mathbf{D}} - \theta)^\top \mathbf{S}_D^{-1} (\bar{\mathbf{D}} - \theta) \leq c_{\alpha,p,n} \right\}, \quad (12.131)$$

em que $c_{\alpha,p,n}$ foi definida em Equação 12.103.

Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

Proposição 12.20 fornece

$$\mathbf{a}^\top \bar{\mathbf{D}} \pm \sqrt{\frac{c_{\alpha,p,n}}{n} \mathbf{a}^\top \mathbf{S}_D \mathbf{a}}. \quad (12.132)$$

Assim, teste, região de confiança e intervalos simultâneos do caso pareado são os resultados de uma amostra aplicados aos vetores de diferenças.

Preservação do pareamento

O procedimento deve ser aplicado às diferenças construídas com a correspondência correta entre as unidades.

Tratar as duas condições como amostras independentes elimina da análise a covariância intrapar e utiliza uma estrutura de variabilidade diferente daquela determinada pelo delineamento.

A normalidade necessária ao resultado exato refere-se à distribuição dos vetores

$$\mathbf{D}_i,$$

e não exige, separadamente, que cada uma das duas condições possua distribuição marginal normal multivariada.

A Tabela 12.1 resume a diferença entre os dois delineamentos.

Tabela 12.1: Comparação entre o T^2 para amostras independentes e para observações pareadas.

Característica	Amostras independentes	Observações pareadas
unidade básica	observações distintas	par de medições relacionadas
parâmetro	$\mu_1 - \mu_2$	$E(\mathbf{D})$
matriz usada na forma quadrática	covariância comum estimada por $\mathbf{S}_p$	covariância das diferenças estimada por $\mathbf{S}_D$
dependência entre as duas medições	não há correspondência entre unidades das duas amostras	incorporada em Σ_{XY} e Σ_{YX} e, portanto, em Σ_D
graus de liberdade da matriz de covariâncias	$n_1 + n_2 - 2$	$n - 1$
condição clássica de inversão	$n_1 + n_2 - 2 \geq p$	$n > p$
redução univariada	teste t com variâncias iguais	teste t pareado

Os dois procedimentos utilizam a mesma lógica inferencial, mas estimam estruturas de variabilidade distintas. A distinção entre as duas estruturas de dependência é retomada em Seção 12.7 ao organizar as condições necessárias à inferência multivariada clássica.

12.9.7 Alta dimensão e robustez

A teoria desenvolvida neste capítulo é predominantemente uma teoria de **dimensão fixa**, na qual a informação amostral cresce enquanto a dimensão permanece constante. Em regimes de alta dimensão, nos quais a dimensão também cresce com o tamanho amostral, as aproximações clássicas de dimensão fixa não podem ser transferidas automaticamente, e singularidade e instabilidade tornam-se parte central do problema (Fujikoshi; Ulyanov; Shimizu, 2010; Ledoit; Wolf, 2004).

Existência e estabilidade

A existência de uma inversa é uma condição algébrica; sua estabilidade depende também da separação entre os autovalores da matriz.

O efeito do condicionamento sobre a inversão de matrizes de covariâncias foi discutido em Equação 10.108. Assim, uma matriz pode possuir posto completo e ainda produzir formas quadráticas sensíveis a pequenas perturbações dos dados.

12.9.7.1 Alta dimensão

Os limites de posto estabelecidos neste capítulo mostram que a inferência clássica baseada em inversas deixa de estar disponível quando a dimensão ultrapassa os graus de liberdade correspondentes. Para uma amostra, por exemplo, Equação 10.66 implica que

$$p \geq n$$

torna $\mathbf{S}$ necessariamente singular. Situações análogas ocorrem para a covariância agrupada quando

$$p > n_1 + n_2 - 2$$

e para a SQPC residual do modelo linear quando

$$p > n - r.$$

O Capítulo 10 distinguiu duas respostas algébricas a problemas dessa natureza: a pseudo-inversa em Equação 10.117 e a regularização da matriz de covariâncias em Definição 10.18. Nenhuma dessas substituições preserva automaticamente as distribuições inferenciais derivadas neste capítulo para a inversa clássica.

Por exemplo, substituir $\mathbf{S}^{-1}$ por $\mathbf{S}^+$ modifica a estatística T^2 e não permite utilizar automaticamente

$$\frac{n-p}{p(n-1)} T^2 \sim F_{p, n-p}.$$

O mesmo ocorre quando $\mathbf{S}$ é substituída por um estimador regularizado (Ledoit; Wolf, 2004).

Uma alternativa diferente consiste em formular previamente a hipótese em um espaço de menor dimensão. Isso ocorre em

$$H_0 : \mathbf{A}\mu = \mathbf{d}$$

e, no modelo linear, em

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0.$$

Nesse caso, a condição de posto depende da dimensão das combinações efetivamente examinadas. Se essas combinações forem escolhidas a partir dos próprios dados, entretanto, o processo de seleção também integra o procedimento inferencial.

Testes específicos para alta dimensão, regularização inferencial, reamostragem e procedimentos baseados em projeções possuem distribuições e critérios próprios e não serão desenvolvidos neste capítulo (Fujikoshi; Ulyanov; Shimizu, 2010).

12.9.7.2 Sensibilidade e robustez

O Capítulo 10 mostrou que a média e a matriz de covariâncias amostrais podem ser fortemente afetadas por observações suficientemente afastadas dos demais dados. Para a média, esse efeito foi explicitado em Equação 10.119; para a matriz de covariâncias, a sensibilidade decorre dos produtos externos utilizados em sua construção.

Essa propriedade afeta diretamente a inferência deste capítulo porque estatísticas como T^2 utilizam simultaneamente

$$\bar{\mathbf{X}}$$

e

$$\mathbf{S}^{-1}.$$

Uma observação influente pode, portanto, modificar tanto o vetor de afastamento quanto a matriz utilizada para ponderá-lo. Isso não significa que toda observação extrema seja um erro nem permite classificar universalmente um procedimento como robusto ou não robusto. O efeito depende da distribuição, da dimensão, do tamanho amostral e da configuração dos dados (Johnson; Wichern, 2002; Maronna et al., 2019).

Sob independência entre as unidades, existência dos momentos requeridos e em dimensão fixa, determinados resultados assintóticos podem continuar válidos fora da normalidade (Anderson, 2003). Essa validade assintótica não transforma em exatas as distribuições finitas derivadas da estrutura normal–Wishart.

Substituir $\bar{\mathbf{X}}$ ou $\mathbf{S}$ por estimadores robustos define outro procedimento estatístico e exige uma distribuição nula ou um método de calibração apropriado (Maronna et al., 2019).

Alcance desta seção

O objetivo é delimitar os procedimentos clássicos desenvolvidos neste capítulo. Diagnósticos detalhados, estimação robusta, regularização, testes de alta dimensão e métodos de reamostragem possuem desenvolvimentos próprios e não serão tratados neste módulo.

12.10 Quadro-síntese das condições inferenciais

A Tabela Tabela 12.2 resume as condições centrais dos procedimentos desenvolvidos neste capítulo.

Tabela 12.2: Condições centrais para os resultados exatos da inferência multivariada clássica.

Procedimento	Estrutura probabilística para o resultado exato	Condição principal de posto
média com Σ conhecida	normalidade da média amostral	$\Sigma \succ \mathbf{0}$
T^2 de uma amostra	amostra normal multivariada	$n > p$
T^2 para $\mathbf{A}\mu = \mathbf{d}$	amostra normal multivariada	$n > h$
duas amostras independentes	normalidade, independência e covariância comum	$n_1 + n_2 - 2 \geq p$
observações pareadas	normalidade dos vetores de diferenças	$n > p$
modelo linear multivariado	normalidade matricial dos erros	$n - r \geq p$ para $\mathbf{E}_{\text{res}} \succ \mathbf{0}$
combinações de s respostas	normalidade matricial dos erros	$n - r \geq s$ para $\mathbf{E}_{C_2} \succ \mathbf{0}$

12.11 Síntese do Módulo 2

O Módulo 2 desenvolveu a base probabilística e inferencial necessária para estudar conjuntamente várias variáveis. O percurso começou com a representação da variabilidade conjunta por meio das covariâncias, introduziu a distribuição normal multivariada como modelo probabilístico, passou à construção e avaliação de estimadores, ampliou a estrutura da média por meio do modelo linear multivariado e concluiu com distribuições amostrais e procedimentos de inferência.

O percurso do módulo começou com a matriz de covariâncias populacional definida em Definição 8.2 e com a representação da variabilidade conjunta construída no Capítulo 8. A distribuição normal multivariada de Definição 9.1 acrescentou um modelo probabilístico para esses objetos.

No Capítulo 10, o vetor de médias amostral em Equação 10.8 e a matriz de covariâncias amostral definida em Definição 10.10 estabeleceram a passagem dos parâmetros populacionais para estatísticas e estimadores.

O Capítulo 11 generalizou a estrutura da média por meio do modelo linear multivariado de Definição 11.3,

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E},$$

e organizou hipóteses estimáveis na forma

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0,$$

definida em Definição 11.15.

Neste capítulo, a distribuição de Wishart transformou as matrizes SQPC em objetos inferenciais. Em particular, Teorema 12.2 estabelece a distribuição da covariância amostral sob normalidade, enquanto Teorema 12.3 fornece a independência entre média e covariância amostrais.

No modelo linear multivariado, a mesma estrutura aparece nas matrizes de hipótese e erro. Sob H_0 , Proposição 12.15 fornece distribuições Wishart para $\mathbf{H}$ e para a SQPC residual correspondente, com independência entre elas. Esse resultado constitui a base probabilística que será reutilizada na MANOVA.

A inferência sobre vetores de médias foi organizada pela estatística T^2 de Hotelling. Quando Σ é conhecida, a forma quadrática possui distribuição qui-quadrado; quando a covariância é estimada por $\mathbf{S}$, Proposição 12.6 fornece uma transformação exata para a distribuição F . A mesma estrutura foi estendida a hipóteses $H_0 : \mathbf{A}\mu = \mathbf{d}$, à comparação de duas amostras independentes e às diferenças pareadas.

A razão de verossimilhanças forneceu uma formulação geral para comparar modelos sob restrições. No modelo linear normal, essa comparação levou à lambda de Wilks,

$$\Lambda_W = \frac{|\mathbf{E}_F|}{|\mathbf{E}_F + \mathbf{H}|},$$

relacionando diretamente a redução da dispersão residual às matrizes $\mathbf{H}$ e $\mathbf{E}$.

Os resultados exatos deste módulo dependem das hipóteses probabilísticas e das condições de posto declaradas em cada procedimento. Fora dessas condições, resultados assintóticos, pseudoinversas ou regularização definem problemas inferenciais diferentes e não preservam automaticamente as distribuições clássicas.

A Tabela 12.3 reúne os objetos centrais dos cinco capítulos.

Tabela 12.3: Objetos centrais dos capítulos do Módulo 2.

Capítulo	Objeto central	Papel no Módulo 2
8. Matrizes de covariâncias e correlações	Σ e matrizes de dispersão	representa variabilidade, dependência e geometria
9. Distribuição Normal Multivariada	$N_p(\mu, \Sigma)$	estabelece o principal modelo probabilístico do módulo

Capítulo	Objeto central	Papel no Módulo 2
10. Estatísticas Amostrais e Estimação	$\bar{\mathbf{X}}, \mathbf{T}$ e $\mathbf{S}$	relaciona parâmetros populacionais, estatísticas e estimadores
11. Modelo Linear Multivariado e Hipóteses Lineares	$\mathbf{y} = \mathbf{ZB} + \mathcal{E}$ e $\mathbf{C}_1\mathbf{B}\mathbf{C}_2$	organiza médias, resíduos, SQPCs e hipóteses estimáveis
12. Inferência Multivariada	Wishart, T^2 , $(\mathbf{H}, \mathbf{E})$ e Λ_{RV}	fornece distribuições amostrais, testes e regiões de confiança

Ao concluir o Módulo 2, o estudante deve ser capaz de:

- distinguir parâmetros populacionais, estatísticas amostrais, estimadores, estimativas e distribuições amostrais;
- interpretar a matriz de covariâncias e a distribuição normal multivariada como bases da modelagem probabilística conjunta;
- reconhecer a distribuição de Wishart e sua relação com matrizes SQPC e estimadores de covariância;
- formular e interpretar o modelo linear multivariado e hipóteses da forma $\mathbf{C}_1\mathbf{B}\mathbf{C}_2 = \Theta_0$;
- utilizar o T^2 de Hotelling para formular inferência sobre vetores de médias e combinações lineares;
- interpretar as matrizes $\mathbf{H}$ e $\mathbf{E}$ como variação associada à hipótese e ao resíduo;
- distinguir resultados exatos de aproximações assintóticas e identificar as condições de normalidade, independência, posto e delineamento que sustentam cada procedimento.

12.11.1 Passagem para o Módulo 3

Os dois primeiros módulos construíram a linguagem que será utilizada na formulação das técnicas multivariadas.

O Módulo 1 forneceu a base matemática formada por vetores, matrizes, subespaços, transformações, decomposições e ferramentas de cálculo.

O Módulo 2 acrescentou a estrutura probabilística e inferencial, abrangendo covariâncias, distribuições multivariadas, estimação, modelos lineares e procedimentos de inferência.

O Módulo 3 combinará essas duas estruturas para formular problemas multivariados específicos.

Matrizes de covariâncias serão decompostas ou modeladas. Projeções serão utilizadas para construir representações de menor dimensão. Distâncias e produtos internos serão utilizados para representar proximidades e formar grupos. Tabelas de contingência serão transformadas

em estruturas geométricas. Matrizes de hipótese e erro serão retomadas na comparação multivariada de grupos. Modelos probabilísticos serão utilizados na discriminação e classificação. Combinações lineares e problemas espectrais reaparecerão, com interpretações específicas, na Análise de Componentes Principais, na MANOVA e na Análise Discriminante.

A passagem para o Módulo 3 corresponde, portanto, à mudança de uma teoria geral dos objetos multivariados para a formulação de técnicas destinadas a problemas estatísticos específicos.

Exercícios de fixação do Módulo II

Os exercícios deste módulo retomam os fundamentos probabilísticos e inferenciais desenvolvidos nos Capítulos 8 a 12 e os articulam com os resultados matemáticos estudados no Módulo I.

A lista está dividida em duas partes. Na primeira, os problemas devem ser resolvidos sem auxílio computacional e enfatizam conceitos, propriedades, operações com vetores e matrizes e procedimentos de inferência. Na segunda, o R será utilizado para aplicar essas estruturas a conjuntos de dados.

Diretrizes gerais. A consulta aos capítulos faz parte da atividade. Os resultados já estabelecidos nos Módulos I e II (definições, teoremas, proposições, propriedades, identidades e decomposições) podem e devem ser utilizados diretamente, sem necessidade de nova demonstração, salvo quando isso for solicitado explicitamente.

Ao utilizar um resultado, identifique o resultado empregado e verifique se suas condições são satisfeitas no problema considerado. Não basta reproduzir uma fórmula. Quando uma conclusão depender de normalidade, independência, existência de momentos, definição positiva, invertibilidade, posto, tamanho amostral, graus de liberdade ou outra hipótese específica, essa condição deve ser indicada.

Em particular, ao longo desta lista deve-se distinguir três situações:

1. resultados que permanecem válidos sem a hipótese de normalidade multivariada, desde que sejam satisfeitas as condições específicas necessárias, como existência de momentos e independência das unidades;
2. resultados exatos para amostras finitas cuja validade depende da normalidade multivariada;
3. resultados assintóticos que podem ser obtidos, sob condições próprias, quando o tamanho amostral cresce e a dimensão permanece fixa.

O fato de uma estatística poder ser calculada não significa que uma distribuição de referência utilizada para realizar inferência seja válida. Da mesma forma, o aumento do tamanho amostral pode justificar determinados resultados assintóticos, mas não transforma uma distribuição de amostra finita em um resultado exato fora das condições em que ela foi derivada.

A robustez de um procedimento diante de desvios da normalidade também não deve ser tratada como uma propriedade universal. Sua avaliação depende, entre outros aspectos, da intensidade

e do tipo de desvio da distribuição, da presença de observações extremas, da dimensão e do tamanho amostral.

As questões foram elaboradas para exigir a escolha e a articulação dos resultados adequados. Por isso, algumas fórmulas não são fornecidas no enunciado e devem ser localizadas nos capítulos.

Parte I — Conceitos, fundamentos, operações matriciais e inferência sem uso de computador

Exercício 12.1 (Covariância, correlação e transformação de escala). Considere as matrizes

$$\Sigma_A = \begin{bmatrix} 4 & 2 \\ 2 & 3 \end{bmatrix}$$

e

$$\Sigma_B = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}.$$

Um estudante afirma que ambas podem representar matrizes de covariâncias porque são simétricas e possuem elementos diagonais positivos.

1. Verifique, separadamente para Σ_A e Σ_B , se estão satisfeitas as condições necessárias para que uma matriz real seja uma matriz de covariâncias. Em particular, verifique utilizando um dos critérios estudados no Módulo I. Apresente os cálculos utilizados e conclua, para cada matriz, se ela pode ou não representar uma matriz de covariâncias.
2. Para a matriz identificada no item anterior como uma matriz de covariâncias válida, determine numericamente a matriz de correlações correspondente. Verifique, no resultado obtido, os valores da diagonal e do elemento fora da diagonal.
3. Considere um vetor aleatório

$$\mathbf{x} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

cujas matrizes de covariâncias sejam as matrizes válidas identificadas no item 1. Para a combinação linear

$$Y = X_1 - X_2,$$

escreva o vetor de coeficientes da combinação linear, determine numericamente $\text{Var}(Y)$ utilizando uma forma quadrática e explique como o termo de covariância entre X_1 e X_2 participa do valor obtido.

4. Para o mesmo vetor $\mathbf{X}$, considere a transformação

$$Z_1 = X_1 \quad \text{e} \quad Z_2 = 10X_2.$$

Utilize a propriedade de transformação da matriz de covariâncias, sem retornar às definições escalares de variância e covariância. Calcule numericamente:

- $\text{Var}(Z_2)$;
- $\text{Cov}(Z_1, Z_2)$;
- $\text{Corr}(Z_1, Z_2)$.

Compare cada resultado com a quantidade correspondente para X_1 e X_2 .

5. Classifique como verdadeira ou falsa a afirmação a seguir e justifique sua resposta utilizando os resultados obtidos nos itens anteriores e a diferença entre covariância e correlação:

Quanto maior a covariância entre duas variáveis, mais forte é necessariamente a associação linear entre elas.

6. Considere agora que nenhuma distribuição probabilística específica, em particular a normal multivariada, tenha sido assumida para $\mathbf{X}$. Indique quais resultados utilizados nos itens 1 a 5 continuam válidos desde que existam os momentos de primeira e segunda ordem necessários. Explique por que a definição e as propriedades algébricas da matriz de covariâncias não dependem da hipótese de normalidade multivariada.

Exercício 12.2 (Normalidade conjunta, independência e condicionamento). Considere

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix} \sim N_3 \left(\begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}, \begin{bmatrix} 2 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 2 \end{bmatrix} \right).$$

1. Determine a distribuição marginal do vetor

$$\begin{bmatrix} X_1 \\ X_3 \end{bmatrix}.$$

Apresente explicitamente o vetor de médias e a matriz de covariâncias dessa distribuição marginal. Em seguida, determine se X_1 e X_3 são independentes e indique o resultado da distribuição normal multivariada que permite estabelecer essa conclusão.

2. Considere agora os blocos

$$\mathbf{X}_A = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

e X_3 . Extraia da matriz de covariâncias de $\mathbf{X}$ o bloco de covariâncias cruzadas entre $\mathbf{X}_A$ e X_3 . A partir desse bloco e das propriedades da distribuição normal multivariada, determine se $\mathbf{X}_A$ e X_3 são independentes. Justifique a conclusão.

3. Determine a distribuição condicional

$$\mathbf{X}_A \mid X_3 = 0.$$

Para isso, particione o vetor de médias e a matriz de covariâncias de acordo com os dois blocos considerados. Apresente numericamente o vetor de médias condicionais e a matriz de covariâncias condicionais e escreva a distribuição normal resultante.

4. Suponha agora que fossem conhecidos apenas o vetor de médias e a matriz de covariâncias apresentados no enunciado, sem assumir que $\mathbf{X}$ possui distribuição normal multivariada. Reavalie separadamente:

- a conclusão de independência entre X_1 e X_3 ;
- a conclusão sobre a independência entre $\mathbf{X}_A$ e X_3 ;
- a forma da distribuição condicional de $\mathbf{X}_A$ dado $X_3 = 0$.

Para cada caso, indique o que ainda pode ser concluído somente a partir das médias e covariâncias conhecidas e o que dependia especificamente da normalidade conjunta. Em particular, explique por que covariância nula não implica, em geral, independência e por que a distribuição condicional não é determinada, em uma população arbitrária, apenas pelos dois primeiros momentos.

Exercício 12.3 (Estatística, estimador e estimativa da matriz de covariâncias). Uma amostra aleatória de tamanho $n = 6$ de um vetor com $p = 3$ componentes produziu a matriz SQPC observada

$$\mathbf{T} = \begin{bmatrix} 10 & 2 & 0 \\ 2 & 5 & 1 \\ 0 & 1 & 4 \end{bmatrix}.$$

1. Explique a função de cada um dos objetos a seguir no problema de estimação da matriz de covariâncias:
- a estatística aleatória $\mathbf{T}$;
 - sua realização observada $\mathbf{T}$;

- o parâmetro populacional Σ ;
- um estimador de Σ ;
- a estimativa obtida após a observação da amostra.

Em sua resposta, deixe explícita a diferença entre um objeto aleatório, seu valor observado e o parâmetro populacional que se pretende estimar.

2. A partir de $\mathbf{T}$, calcule numericamente:

- a estimativa não viesada de Σ ;
- a estimativa de máxima verossimilhança de Σ sob o modelo normal multivariado, quando o máximo da verossimilhança existe.

Identifique o divisor utilizado em cada caso. Em seguida, explique por que os dois divisores são diferentes e qual propriedade de cada estimador está sendo considerada em sua construção.

3. Verifique se $\mathbf{T}$ é positiva definida utilizando um critério estudado no Módulo I e apresente a verificação realizada. A partir desse resultado, determine o posto de $\mathbf{T}$ e conclua se, para esta amostra, a estimativa de máxima verossimilhança calculada no item 2 pertence ao espaço das matrizes de covariâncias positivas definidas exigido pelo modelo normal não singular.
4. Os dois estimadores utilizados no item 2 são diferentes para uma amostra finita. Explique por que essa diferença não impede que ambos sejam consistentes para Σ quando p permanece fixo e $n \rightarrow \infty$. Em sua justificativa, relacione os dois estimadores por meio de seus divisores e indique o que ocorre com essa diferença relativa quando n aumenta.
5. Suponha agora que as observações sejam i.i.d. de uma população multivariada que **não** possui distribuição normal, mas possui vetor de médias e matriz de covariâncias finitos. Para cada afirmação a seguir, indique se ela permanece válida, deixa de ser válida em geral ou necessita de hipóteses adicionais:

- $E(\bar{\mathbf{X}}) = \mu$;
- $\text{Cov}(\bar{\mathbf{X}}) = \Sigma/n$;
- $E(\mathbf{S}) = \Sigma$;
- $\mathbf{S} \xrightarrow{P} \Sigma$ quando $n \rightarrow \infty$ e p permanece fixo;
- $(n-1)\mathbf{S}$ possui exatamente distribuição de Wishart;
- $\bar{\mathbf{X}}$ e $\mathbf{S}$ são independentes.

Explique também por que a matriz $\mathbf{T}/n$ continua podendo ser calculada para uma amostra não normal, mas não deve ser chamada automaticamente de estimativa de máxima verossimilhança de Σ sem que seja especificado um modelo probabilístico cuja verossimilhança conduza a esse estimador.

Exercício 12.4 (Estrutura e hipótese em um modelo linear multivariado). Considere um modelo linear multivariado com $n = 4$ unidades e duas variáveis-resposta:

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E}.$$

A matriz de delineamento possui duas colunas: a primeira corresponde ao intercepto e a segunda a uma covariável. Suponha que

$$\text{posto}(\mathbf{Z}) = 2,$$

$$\mathbf{Z}^\top \mathbf{Z} = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}$$

e

$$\mathbf{Z}^\top \mathbf{Y} = \begin{bmatrix} 8 & 12 \\ 2 & -2 \end{bmatrix}.$$

Após o ajuste, a SQPC residual observada é

$$\mathbf{E} = \begin{bmatrix} 2 & 1 \\ 1 & 4 \end{bmatrix}.$$

1. Utilize o resultado de mínimos quadrados para o caso em que $\mathbf{Z}$ possui posto completo e calcule numericamente $\widehat{\mathbf{B}}_{\text{obs}}$. Apresente a matriz estimada completa e suas dimensões.
2. Utilizando a organização das linhas e colunas de $\widehat{\mathbf{B}}_{\text{obs}}$, identifique explicitamente:
 - quais elementos correspondem aos interceptos das duas variáveis-resposta;
 - quais elementos correspondem aos coeficientes da covariável nas duas variáveis-resposta;
 - qual coluna reúne os coeficientes do modelo para a primeira resposta;
 - qual coluna reúne os coeficientes do modelo para a segunda resposta.

A interpretação solicitada neste item refere-se à posição e à função dos coeficientes no modelo, pois não foi atribuído um significado específico à covariável.

3. Determine numericamente:
 - o posto r da matriz de delineamento;
 - os graus de liberdade residuais $n - r$;
 - a estimativa não viesada da matriz de covariâncias dos erros.

Apresente a matriz de covariâncias residual estimada.

4. Formule a hipótese de que a covariável não possui efeito linear sobre nenhuma das duas variáveis-resposta na forma

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0.$$

Especifique numericamente $\mathbf{C}_1$, $\mathbf{C}_2$ e Θ_0 , informe as dimensões dessas matrizes e mostre que a hipótese resultante equivale a impor simultaneamente que os dois coeficientes associados à covariável sejam iguais a zero. Justifique também por que essa função de $\mathbf{B}$ é estimável no modelo considerado.

5. O estimador de mínimos quadrados de cada coluna de $\mathbf{B}$ coincide com o estimador obtido ao ajustar separadamente um modelo linear para cada variável-resposta utilizando a mesma matriz $\mathbf{Z}$. Explique por que essa equivalência na estimação dos coeficientes não torna desnecessária a matriz de covariâncias residual. Em sua resposta, indique qual informação sobre a relação entre as respostas é registrada pelos elementos fora da diagonal dessa matriz.

Exercício 12.5 (Resultados exatos, ausência de normalidade e resultados assintóticos). Considere as afirmações a seguir.

I. Se

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

então o vetor de médias amostrais possui exatamente uma distribuição normal multivariada, a SQPC amostral possui distribuição de Wishart e o vetor de médias amostrais é independente da matriz de covariâncias amostral.

II. Para qualquer população com vetor de médias e matriz de covariâncias finitos,

$$(n-1)\mathbf{S}$$

possui exatamente uma distribuição de Wishart.

III. Se

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

são i.i.d., possuem vetor de médias μ e matriz de covariâncias finita Σ e a dimensão p permanece fixa, então

$$\sqrt{n}(\bar{\mathbf{X}} - \mu)$$

converge em distribuição para uma distribuição normal multivariada quando $n \rightarrow \infty$, mesmo que a população de origem não possua distribuição normal multivariada.

IV. Se o modelo é identificável, o parâmetro verdadeiro pertence ao interior do espaço paramétrico, log-verossimilhança duas vezes continuamente diferenciável em uma vizinhança do parâmetro verdadeiro, possibilidade de trocar diferenciação e integração ou esperança, a matriz de informação de Fisher é positiva definida, as restrições impostas por H_0 são regulares e a dimensão paramétrica permanece fixa quando $n \rightarrow \infty$, então, sob H_0 ,

$$-2 \log \Lambda_{\text{RV}} \xrightarrow{d} \chi^2_{\nu},$$

em que ν corresponde ao número de restrições independentes impostas por H_0 . Portanto, a distribuição qui-quadrado obtida pelo Teorema de Wilks é assintótica e, em geral, não corresponde à distribuição exata da estatística em amostras finitas.

V. Se a população não possui distribuição normal multivariada, então, mesmo sob amostragem i.i.d. e existência de segundos momentos finitos, o vetor de médias amostrais deixa de ser não viesado para μ e a matriz de covariâncias amostral deixa de ser não viesada e consistente para Σ .

VI. Considere uma amostra aleatória

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0} \quad \text{e} \quad n > p.$$

Para testar

$$H_0 : \mu = \mu_0,$$

considere a estatística

$$T^2 = n(\bar{\mathbf{X}} - \mu_0)^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \mu_0).$$

Sob H_0 , a normalidade multivariada das observações, a independência entre as unidades amostrais, a definição positiva de Σ e a condição $n > p$ permitem obter o resultado exato

$$\frac{n-p}{p(n-1)} \mathbf{T}^2 \sim F_{p, n-p}.$$

Se a população não possui distribuição normal multivariada, mas as observações são i.i.d., possuem vetor de médias μ , matriz de covariâncias finita e positiva definida Σ , a matriz de covariâncias amostral satisfaz

$$\mathbf{S} \xrightarrow{P} \Sigma,$$

e p permanece fixo quando

$$n \rightarrow \infty,$$

então, sob H_0 ,

$$\mathbf{T}^2 \xrightarrow{d} \chi_p^2.$$

Portanto, fora da normalidade multivariada, a distribuição qui-quadrado é um resultado assintótico. Esse resultado não implica que a transformação de $\mathbf{T}^2$ para a distribuição F permaneça exata em amostras finitas.

Para cada afirmação:

1. Classifique a afirmação como **correta** ou **incorreta** e apresente uma justificativa baseada em um resultado estudado nos capítulos.
2. Para cada afirmação classificada como incorreta, escreva uma versão corrigida, modificando apenas as hipóteses ou a conclusão necessárias para que ela se torne válida.
3. Para cada resultado utilizado, liste explicitamente as hipóteses necessárias à sua validade e indique quais delas já aparecem na respectiva afirmação. Considere, quando pertinente, amostragem i.i.d., independência das unidades, normalidade multivariada, existência de momentos, definição positiva de Σ , dimensão p fixa e condições de regularidade do modelo.

Ao final, explique por que as duas afirmações a seguir são inadequadas:

Se os dados não são normais, os métodos clássicos deixam de funcionar.

e

Se a amostra é grande, os pressupostos deixam de ser importantes.

Em sua resposta, distinga a perda de uma **distribuição exata em amostra finita** da possibilidade de utilizar um **resultado assintótico**, e explique por que independência, existência de momentos e o regime dimensional continuam sendo relevantes quando n cresce.

Exercício 12.6 (T^2 de Hotelling, normalidade e o papel do delineamento). Um estudo mede duas variáveis nos mesmos 10 indivíduos antes e depois de uma intervenção. Para cada indivíduo, define-se o vetor de diferenças

$$\mathbf{D}_i = \mathbf{X}_{i,\text{depois}} - \mathbf{X}_{i,\text{antes}}, \quad i = 1, \dots, 10.$$

Os vetores de diferenças produziram

$$\bar{\mathbf{d}} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

e

$$\mathbf{S}_D = \begin{bmatrix} 4 & 1 \\ 1 & 1 \end{bmatrix}.$$

Deseja-se avaliar se houve alteração média conjunta nas duas variáveis após a intervenção.

Admita inicialmente que as condições necessárias para a distribuição exata de T^2 sejam satisfeitas e utilize

$$F_{2,8;0,95} = 4,46.$$

1. Defina o vetor populacional de médias das diferenças μ_D e formule as hipóteses nula e alternativa para avaliar a ausência de alteração média conjunta. Em seguida, explique por que, após a construção dos vetores $\mathbf{D}_i$, o problema pode ser tratado como um problema de uma amostra aplicado aos vetores de diferenças.
2. Identifique explicitamente as condições necessárias para utilizar a distribuição exata de T^2 neste problema. Sua resposta deve considerar:
 - a distribuição conjunta dos vetores $\mathbf{D}_i$;
 - a independência entre indivíduos;
 - a definição positiva da matriz de covariâncias populacional das diferenças;
 - a relação entre o tamanho amostral n e a dimensão p .

Verifique numericamente a condição que envolve n e p .

3. Calcule a estatística T^2 para o teste da hipótese formulada no item 1. Em seguida, utilize a transformação estudada no capítulo para obter a estatística com distribuição F , informe seus graus de liberdade, compare o valor calculado com o valor crítico fornecido e apresente:
 - a decisão estatística ao nível de significância de 5%;
 - a conclusão no contexto da alteração média conjunta das duas variáveis.
4. Escreva a matriz de covariâncias do vetor de diferenças $\mathbf{D}_i$ em função das matrizes de covariâncias das medidas “antes” e “depois” e das covariâncias cruzadas entre essas duas medidas. Utilize essa expressão para explicar precisamente qual informação sobre a dependência dentro de cada indivíduo seria ignorada se as observações “antes” e “depois” fossem tratadas como duas amostras independentes.
5. Suponha, em outro estudo, que as duas condições sejam aplicadas a dois grupos constituídos por indivíduos distintos. Sob independência entre os grupos, normalidade multivariada e uma matriz de covariâncias populacional comum, indique:
 - qual estimador da matriz de covariâncias comum deve ser utilizado;
 - qual versão da estatística T^2 deve ser utilizada para comparar os vetores de médias dos dois grupos;
 - qual característica do delineamento distingue esse problema do problema pareado apresentado no início da questão.
6. Retorne ao estudo pareado original e suponha agora que a normalidade multivariada dos vetores de diferenças $\mathbf{D}_i$ não seja uma hipótese razoável.
 - a. Explique quais quantidades calculadas nos itens anteriores continuam podendo ser obtidas normalmente a partir da amostra, como $\bar{\mathbf{d}}$, $\mathbf{S}_D$ e o valor numérico de T^2 .
 - b. Explique por que, com $n = 10$, a transformação de T^2 para a distribuição F deixa de possuir, em geral, a justificativa de uma distribuição exata.
 - c. Suponha que, em vez de 10 indivíduos, uma sequência de estudos forneça amostras i.i.d. cada vez maiores de vetores de diferenças, com $p = 2$ fixo, segundos momentos finitos e matriz $\Sigma_D \succ \mathbf{0}$. Indique qual distribuição assintótica de T^2 pode ser utilizada sob H_0 quando $n \rightarrow \infty$.
 - d. Explique por que o resultado do item anterior não permite afirmar que a calibração finita pela distribuição F se tornou exata fora da normalidade.

Parte II — Exercícios com uso do R

Nesta parte, os cálculos solicitados devem ser construídos preferencialmente por meio de operações matriciais no R. Quando existir uma função pronta que reproduza diretamente um resultado estudado nos Módulos I ou II, utilize-a somente depois de realizar a construção matricial correspondente e apenas como forma de conferência.

Os códigos devem ser reprodutíveis e os resultados numéricos devem ser acompanhados das interpretações solicitadas. Nos procedimentos inferenciais, identifique as condições que sustentam a distribuição utilizada. A obtenção de uma estatística de teste ou de um valor- p pelo software não constitui, por si só, evidência de que as hipóteses probabilísticas do procedimento sejam satisfeitas.

Exercício 12.7 (Modelo linear multivariado com os dados `swiss`). Utilize o conjunto de dados `swiss`.

Considere como variáveis-resposta:

- `Fertility`;
- `Infant.Mortality`.

Construa

$$\mathbf{Y} = [\text{Fertility} \quad \text{Infant.Mortality}]$$

e uma matriz de delineamento $\mathbf{Z}$ cujas colunas, nesta ordem, correspondam a:

1. intercepto;
2. `Agriculture`;
3. `Education`.
4. Determine n , p , q e o posto r de $\mathbf{Z}$. Calcule os graus de liberdade residuais $n - r$. Em seguida, obtenha $\widehat{\mathbf{B}}_{\text{obs}}$ diretamente por operações matriciais e apresente a matriz com as linhas identificadas por `Intercepto`, `Agriculture` e `Education` e as colunas por `Fertility` e `Infant.Mortality`.

Somente depois desse cálculo, ajuste separadamente com `lm()` os dois modelos univariados correspondentes e verifique se seus coeficientes coincidem, salvo diferenças de arredondamento, com as respectivas colunas de $\widehat{\mathbf{B}}_{\text{obs}}$.

5. Calcule a matriz de valores ajustados e a matriz de resíduos $\widehat{\mathbf{U}}$. Verifique numericamente a condição

$$\mathbf{Z}^\top \widehat{\mathbf{U}} = \mathbf{0}$$

calculando $\mathbf{Z}^\top \widehat{\mathbf{U}}$ e examinando se seus elementos são numericamente próximos de zero.

Explique por que essa propriedade decorre do ajuste por mínimos quadrados e não constitui uma verificação de normalidade dos erros.

6. Construa a SQPC residual

$$\mathbf{E} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}}$$

e calcule o estimador não viesado da matriz de covariâncias residual. Interprete:

- os elementos da diagonal como variâncias residuais das duas respostas;
- o elemento fora da diagonal como covariância residual entre `Fertility` e `Infant.Mortality` após considerados os efeitos lineares de `Agriculture` e `Education`.

Como a direção constante pertence ao espaço coluna de $\mathbf{Z}$, construa também $\mathbf{T}$ e $\mathbf{T}_{\text{mod}}$ e verifique numericamente

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E}.$$

7. Formule, na forma

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0,$$

a hipótese de que o coeficiente de `Education` é igual a zero simultaneamente nas duas variáveis-resposta. Especifique numericamente $\mathbf{C}_1$, $\mathbf{C}_2$ e Θ_0 , informe suas dimensões e verifique a condição de estimabilidade.

Não realize um teste multivariado dessa hipótese. O objetivo é construir corretamente a restrição matricial correspondente aos coeficientes de `Education`.

8. Considere os resultados obtidos nos itens anteriores e classifique-os em três grupos:
- resultados que decorrem da álgebra de mínimos quadrados e podem ser calculados sem assumir normalidade multivariada dos erros;

- b. propriedades de esperança e covariância dos estimadores que exigem condições sobre a média, a independência entre unidades e a estrutura de covariâncias dos erros, mas não necessariamente normalidade;
- c. resultados inferenciais exatos, como distribuições normais matriciais, distribuições de Wishart e independência entre estimadores e SQPC residual, cuja derivação depende da normalidade multivariada dos erros.

Para cada grupo, identifique pelo menos um resultado utilizado nesta questão e indique as condições necessárias.

Exercício 12.8 (Comparação multivariada entre regiões dos Estados Unidos). Utilize o conjunto `USArrests` e associe cada estado à sua região por meio dos objetos `state.name` e `state.region`.

Uma possibilidade para construir o vetor de regiões é

```
regiao <- state.region[
  match(
    rownames(USArrests),
    state.name
  )
]
```

Considere apenas os estados classificados nas regiões **South** e **Northeast**. Em cada região, utilize conjuntamente as quatro variáveis quantitativas de `USArrests`.

1. Determine:

- os tamanhos amostrais n_1 e n_2 ;
- a dimensão p ;
- os vetores de médias amostrais;
- as matrizes de covariâncias amostrais.

Calcule também

$$\nu = n_1 + n_2 - 2$$

e verifique se a relação entre ν e p satisfaz a condição dimensional necessária à construção da estatística clássica T^2 para duas amostras.

2. Construa matricialmente a matriz de covariâncias agrupada $\mathbf{S}_p$ e verifique se ela é invertível. Em seguida, calcule a estatística T^2 de Hotelling para testar

$$H_0 : \mu_{\text{South}} = \mu_{\text{Northeast}}.$$

Transforme T^2 para a estatística com distribuição F correspondente e informe:

- o valor de T^2 ;
- o valor da estatística F ;
- os graus de liberdade;
- o valor- p ;
- a decisão ao nível de significância de 5%;
- a conclusão sobre a igualdade dos vetores de médias populacionais.

A conclusão deve se referir ao vetor de quatro médias analisado conjuntamente, e não a cada variável separadamente.

3. A distribuição F utilizada no item anterior é exata sob condições específicas. Identifique explicitamente:

- a independência entre as duas amostras;
- a independência das unidades dentro de cada amostra;
- a normalidade multivariada em cada população;
- a igualdade das matrizes de covariâncias populacionais;
- a definição positiva da matriz de covariâncias comum;
- a condição dimensional necessária à inversão da matriz utilizada em T^2 .

Indique quais dessas condições são características do delineamento e quais são hipóteses sobre as distribuições populacionais.

4. Examine graficamente as quatro variáveis em cada região utilizando gráficos adequados para identificar assimetria acentuada e observações extremas. Utilize também gráficos quantil-quantil normais para cada variável.

A partir desses gráficos, descreva os principais desvios observados em relação à normalidade marginal. Não conclua que a distribuição é normal multivariada apenas porque uma ou mais variáveis apresentam comportamento aproximadamente normal em análises marginais.

Explique por que essas análises podem fornecer informações sobre a plausibilidade da normalidade, mas não demonstram que a hipótese de normalidade multivariada seja satisfeita.

5. Suponha que a normalidade multivariada não seja considerada razoável para esses dados.
- a.** Indique quais das seguintes quantidades continuam perfeitamente definidas como estatísticas calculadas a partir da amostra:
- os vetores de médias amostrais;
 - as matrizes de covariâncias amostrais;
 - a matriz de covariâncias agrupada;
 - o valor numérico de T^2 .
- b.** Explique por que a ausência de normalidade não impede o cálculo dessas quantidades, mas elimina, em geral, a justificativa para afirmar que a transformação de T^2 possui exatamente a distribuição F utilizada no item 2.
- c.** Considere uma sequência de estudos em que $p = 4$ permanece fixo, $n_1 \rightarrow \infty$, $n_2 \rightarrow \infty$, $n_1/(n_1 + n_2) \rightarrow \lambda \in (0, 1)$, as unidades são independentes, as duas populações possuem segundos momentos finitos e compartilham uma matriz de covariâncias positiva definida Σ . Explique por que resultados assintóticos podem ser utilizados para a inferência sobre a diferença entre os vetores de médias mesmo sem normalidade multivariada.
- d.** Explique por que o crescimento dos tamanhos amostrais não transforma a distribuição F de amostra finita, derivada sob normalidade multivariada e matriz de covariâncias comum, em uma distribuição exata fora dessas condições.

Parte III

Módulo III — Formulação Matemática e Estatística das Técnicas Multivariadas

13 Problemas e estruturas das técnicas multivariadas

Os Módulos 1 e 2 estabeleceram a base matemática, geométrica, probabilística e inferencial utilizada na Análise Multivariada. Vetores e matrizes fornecem a representação dos dados; distâncias, produtos internos e projeções descrevem sua geometria; autovetores e vetores singulares fornecem direções determinadas pelas decomposições correspondentes, enquanto autovalores e valores singulares quantificam suas magnitudes; matrizes de covariâncias e correlações descrevem a variabilidade conjunta e a associação linear; e os modelos probabilísticos e inferenciais permitem formular conclusões sobre populações multivariadas.

Neste módulo, os fundamentos anteriores são utilizados para formular técnicas multivariadas específicas. Cada técnica parte de um problema estatístico e utiliza os objetos matemáticos, probabilísticos ou inferenciais necessários à sua solução. Redução de dimensionalidade, representação de estruturas latentes, formação de grupos, análise de associações em tabelas de contingência, análise conjunta de várias respostas e discriminação de grupos exigem formulações distintas (Johnson; Wichern, 2002).

Uma mesma estrutura matemática pode aparecer em técnicas diferentes. A decomposição espectral pode identificar direções de maior variabilidade, fornecer uma solução não rotacionada de cargas fatoriais no método de fatores principais ou participar da determinação de direções de separação entre grupos. A função desempenhada pela decomposição depende da matriz analisada e do critério definido pela técnica.

A Tabela 13.1 reúne os elementos que estruturam a formulação das técnicas deste módulo.

Tabela 13.1: Elementos utilizados na formulação das técnicas multivariadas.

Elemento	Função na formulação
Problema estatístico	Define o objetivo da análise
Estrutura dos dados	Define como observações, variáveis, categorias ou grupos são representados
Objeto matemático	Organiza a informação utilizada pelo critério ou modelo
Critério ou modelo	Determina a propriedade otimizada, decomposta ou modelada

Elemento	Função na formulação
Solução	Produz direções, coordenadas, grupos, parâmetros ou funções
Interpretação	Relaciona a solução ao problema estatístico e à representação geométrica utilizada

Problema estatístico, estrutura dos dados, objeto matemático e critério ou modelo fornecem os eixos para relacionar os fundamentos dos Módulos 1 e 2 às técnicas do Módulo 3.

13.1 O caráter multivariado dos dados

Uma análise não se torna multivariada apenas pela presença de várias variáveis em um conjunto de dados. O caráter multivariado decorre de considerar conjuntamente as características observadas e as relações existentes entre elas.

Para uma unidade i observada em p variáveis,

$$\mathbf{x}_i = \begin{pmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{pmatrix}$$

reúne os valores observados dessa unidade. O vetor $\mathbf{x}_i$ representa seu perfil multivariado.

Duas unidades podem apresentar o mesmo valor em uma variável e diferir nas demais. Da mesma forma, duas variáveis examinadas separadamente não descrevem as covariâncias, correlações ou outras relações existentes entre elas. A análise conjunta permite considerar essas relações e formular problemas que não podem ser reduzidos ao exame isolado de cada variável.

13.2 Do problema estatístico à técnica multivariada

A presença de várias variáveis em um conjunto de dados caracteriza o contexto multivariado, mas não determina a técnica. A escolha depende do problema estatístico, do objeto analisado e do critério ou modelo adotado.

Considere a matriz de dados $\mathbf{X}$ definida na Definição 1.6. Quando suas colunas correspondem a variáveis quantitativas, cada observação pode ser representada geometricamente pelas respectivas coordenadas em $\mathbb{R}^p$, conforme discutido na Seção 1.2. Variáveis categóricas não devem ser incorporadas automaticamente a essa geometria apenas pela atribuição de códigos

numéricos; técnicas que utilizam categorias ou dados mistos exigem representações compatíveis com a natureza das variáveis.

A mesma matriz de dados quantitativos pode ser utilizada para construir combinações lineares que concentrem variabilidade, identificar grupos de observações semelhantes ou, quando os grupos são conhecidos, determinar direções que os separem. O conjunto de dados permanece o mesmo, enquanto o objeto de interesse e o critério de solução se modificam.

A Tabela 13.2 reúne as correspondências entre problemas estatísticos, objetos centrais, critérios e técnicas do Módulo 3.

Tabela 13.2: Correspondência entre problemas, estruturas e técnicas multivariadas.

Problema estatístico	Estrutura ou objeto central	Critério ou modelo	Técnica
Representar a variabilidade em menor dimensão	Σ , $\mathbf{S}$, $\mathcal{R}$, $\mathbf{R}$ ou matriz de dados centralizada	Maximização da variância e aproximação de posto reduzido	Análise de Componentes Principais
Representar as covariâncias por fatores comuns	Matriz de covariâncias ou correlações	Modelo de fatores comuns	Análise Fatorial
Formar grupos de objetos semelhantes	Matriz de dados ou de dissimilaridades	Critérios de proximidade, dispersão ou ligação	Análise de Agrupamentos
Representar associações entre categorias	Tabela de contingência, massas e perfis	Geometria qui-quadrado, SVD e decomposição da inércia	Análise de Correspondência
Testar conjuntamente hipóteses sobre várias respostas	Modelo linear multivariado, SQPC da hipótese $\mathbf{H}$ e SQPC residual $\mathbf{E}$	Raízes características e critérios multivariados de teste	MANOVA
Separar grupos conhecidos e classificar observações	Médias, covariâncias, probabilidades <i>a priori</i> e dispersões intragrupos e entre grupos	Regra de Bayes e suas especializações normais LDA/QDA; critério de Fisher para separação	Análise Discriminante

Parte dos objetos utilizados nessa tabela foi definida nos módulos anteriores. A matriz de dados da Definição 1.6 representa observações e variáveis. A matriz de covariâncias populacional Σ , definida na Definição 8.2, e sua correspondente observada $\mathbf{S}$, definida na Definição 8.10,

descrevem a variabilidade conjunta. A matriz de correlações observada $\mathbf{R}$, definida na Definição 8.11, descreve a estrutura linear depois da padronização marginal das variáveis.

A escolha entre covariâncias e correlações não altera o objetivo estatístico da técnica, mas modifica a representação da variabilidade e pode modificar a solução. A matriz de covariâncias preserva as escalas originais, enquanto a matriz de correlações atribui variância unitária às variáveis. Na ACP, a opção por $\mathbf{S}$ ou $\mathbf{R}$ pode modificar as componentes obtidas, conforme o Capítulo 14. Na Análise de Agrupamentos, a padronização pode modificar as distâncias e, conseqüentemente, a partição ou hierarquia obtida, conforme o Capítulo 16.

A estrutura de entrada delimita a informação disponível para a técnica. Uma matriz de covariâncias resume relações de segunda ordem entre variáveis. Uma matriz de dissimilaridades representa relações entre pares de objetos. Uma tabela de contingência registra frequências conjuntas entre categorias. A formulação deve preservar essa diferença.

13.3 Classes de problemas multivariados

As técnicas deste módulo podem ser organizadas de acordo com o problema estatístico que resolvem. Essa classificação estabelece a função de cada método antes de sua formulação matemática.

13.3.1 Redução de dimensionalidade

A redução de dimensionalidade representa os dados em um espaço de menor dimensão segundo um critério definido pela técnica.

No Capítulo 14, as novas dimensões são combinações lineares escolhidas para concentrar sucessivamente a variância. A formulação utiliza as projeções de Definição 3.19, a decomposição espectral sintetizada na Tabela 5.2 e a decomposição em valores singulares sintetizada na Tabela 6.6.

No Capítulo 17, a SVD decompõe os desvios padronizados da independência e fornece uma representação de menor dimensão dos perfis de linhas e colunas segundo a geometria qui-quadrado.

13.3.2 Representação de estruturas latentes

O Capítulo 15 procura representar a estrutura de covariâncias entre as variáveis observadas por meio de um número menor $m < p$ de fatores comuns latentes.

No modelo fatorial, a matriz de covariâncias é representada por uma parcela comum, associada aos fatores, e por variâncias específicas das variáveis.

A decomposição em parcelas comum e específica distingue o Capítulo 15 do Capítulo 14. A ACP organiza a variabilidade total representada pela matriz analisada em direções principais, enquanto a Análise Fatorial especifica um modelo para representar a estrutura de covariâncias por fatores comuns e variâncias específicas.

13.3.3 Formação de grupos

A Análise de Agrupamentos organiza objetos em grupos sem utilizar classes conhecidas previamente. A solução depende da representação dos objetos, da medida de proximidade e do critério que define a organização procurada.

A distância euclidiana definida na Definição 1.13 fornece uma medida de proximidade já estabelecida no Módulo 1. No Capítulo 16, uma dissimilaridade é formalizada na Definição 16.1. As K -médias produzem uma partição, objeto definido na Definição 16.2, enquanto os métodos hierárquicos produzem uma sequência de partições aninhadas, formalizada na Definição 16.4.

Uma partição e uma hierarquia representam objetos diferentes e resultam de critérios distintos. Além disso, os procedimentos desenvolvidos no Capítulo 16 podem ser formulados geometricamente, sem a especificação de um modelo probabilístico gerador. Os grupos obtidos representam, portanto, uma organização dos objetos segundo a representação, a proximidade e o critério adotados e não correspondem automaticamente a populações distintas.

13.3.4 Representação de associações em tabelas de contingência

A Análise de Correspondência parte de uma tabela de contingência e representa geometricamente o afastamento da estrutura de independência entre as duas variáveis categóricas.

No Capítulo 17, as frequências relativas marginais definem as massas da Definição 17.1, e a normalização das linhas e colunas pelas respectivas massas define os perfis da Definição 17.2. A comparação entre perfis utiliza a distância qui-quadrado da Definição 17.3, enquanto os desvios padronizados da independência são reunidos na matriz da Definição 17.5.

A Seção 17.7 decompõe a inércia total em inércias principais associadas às dimensões não nulas da solução. As coordenadas padrão e principais são formalizadas, respectivamente, na Definição 17.7 e na Definição 17.8.

13.3.5 Teste conjunto de hipóteses sobre várias respostas

Na MANOVA, a comparação de vetores de médias constitui um caso particular de um problema mais geral: testar hipóteses sobre funções estimáveis dos parâmetros de um modelo linear multivariado com várias respostas.

A MANOVA utiliza o modelo definido na Definição 11.3 para representar conjuntamente as respostas e o delineamento, enquanto a hipótese linear geral da Definição 11.15 especifica as funções estimáveis dos parâmetros submetidas ao teste. No Capítulo 18, a SQPC da hipótese $\mathbf{H}$ e a SQPC residual $\mathbf{E}$ conduzem ao problema de autovalores generalizados da Equação 18.14. As raízes características da Definição 18.1 são utilizadas na construção dos quatro critérios reunidos na Seção 18.5.

13.3.6 Discriminação e classificação

A Análise Discriminante utiliza grupos conhecidos durante a construção da solução. A classificação associa novas observações às classes, enquanto a formulação de Fisher constrói direções que representam a separação entre os grupos conhecidos.

Sob perda zero-um, as distribuições condicionais e as probabilidades *a priori* determinam a regra de Bayes da Equação 19.3. Sob normalidade multivariada, a hipótese de covariância comum conduz à LDA da Seção 19.3, enquanto covariâncias específicas por classe conduzem à QDA da Seção 19.4. A distância de Mahalanobis da Definição 8.8 define uma métrica comum entre as classes na LDA e métricas específicas por classe na QDA.

A formulação geométrica da Seção 19.6 compara a dispersão entre grupos à dispersão intragrupos. O critério amostral da Definição 19.8 conduz ao problema de autovalores generalizados da Equação 19.30.

Quando a MANOVA de um fator compara os mesmos grupos utilizados pela formulação de Fisher, a SQPC da hipótese corresponde à dispersão entre grupos e a SQPC residual corresponde à dispersão intragrupos, produzindo o mesmo problema de autovalores generalizados. A Equação 19.40 formaliza essa correspondência. A MANOVA utiliza as raízes na construção de testes multivariados, enquanto Fisher utiliza as direções associadas para representar a separação entre os grupos.

13.4 Diferentes formas de classificar as técnicas

A classificação pelo problema estatístico distingue as técnicas segundo a finalidade que orienta sua formulação. As classificações por dependência ou interdependência, finalidade analítica e supervisão descrevem aspectos complementares.

13.4.1 Interdependência e dependência

Nas técnicas de interdependência, as variáveis ou os objetos são analisados sem uma divisão prévia entre respostas e variáveis explicativas. ACP, Análise Fatorial, Análise de Agrupamentos e Análise de Correspondência são exemplos.

Nas técnicas de dependência, o problema estabelece previamente qual variável ou conjunto de variáveis ocupa a posição de resposta e qual informação explica, compara ou prediz essa resposta. Na MANOVA, o vetor de respostas e os efeitos avaliados são definidos pelo delineamento. Na Análise Discriminante, a classe conhecida ocupa a posição de resposta categórica e as características observadas são utilizadas para discriminar ou classificar.

Nas técnicas de interdependência, o objeto cuja relação é examinada também ajuda a distinguir os métodos. ACP e Análise Fatorial estudam principalmente relações entre variáveis; a Análise de Agrupamentos organiza casos ou objetos segundo suas proximidades; a Análise de Correspondência representa relações entre categorias de uma tabela de contingência.

13.4.2 Exploratórias, descritivas, preditivas e inferenciais

Uma técnica exploratória identifica padrões ou estruturas nos dados. Uma técnica descritiva resume uma configuração observada. Uma técnica preditiva produz uma regra aplicável a novas observações. Uma técnica inferencial utiliza a variabilidade amostral para formular conclusões sobre parâmetros ou populações.

Essas finalidades podem coexistir. A ACP é predominantemente exploratória e descritiva em muitas aplicações, embora exista teoria inferencial para componentes populacionais. Na Análise Discriminante, a formulação de Fisher representa a separação entre grupos conhecidos, enquanto a formulação probabilística produz regras para classificar novas observações. A MANOVA possui finalidade principalmente inferencial.

13.4.3 Supervisionadas e não supervisionadas

A classificação por supervisão depende da existência de rótulos, respostas ou delineamentos especificados antes da análise.

Na Análise Discriminante, os rótulos conhecidos dos grupos participam da construção das direções de Fisher e das regras de classificação. Na MANOVA, o delineamento especifica o vetor de respostas e os efeitos submetidos ao teste, embora a terminologia supervisionada seja menos usual nesse contexto.

ACP e Análise de Agrupamentos não utilizam classes ou respostas previamente especificadas e são usualmente classificadas como não supervisionadas.

Na Análise Fatorial e na Análise de Correspondência, a formulação não depende de uma variável-resposta externa previamente especificada; a oposição entre supervisão e não supervisão não define o problema estatístico dessas técnicas.

A Tabela 13.3 compara as técnicas segundo o problema predominante, a relação entre variáveis, a finalidade frequente e a estrutura de supervisão.

Tabela 13.3: Classificações complementares das técnicas estudadas no Módulo 3.

Técnica	Problema predominante	Relação entre variáveis	Finalidade frequente	Estrutura de supervisão
ACP	Redução de dimensionalidade	Interdependência	Exploratória e descritiva	Não supervisionada
Análise Fatorial	Estrutura latente	Interdependência	Exploratória; inferencial sob formulações probabilísticas específicas	Sem resposta externa na formulação exploratória
Análise de Agrupamentos	Formação de grupos	Interdependência	Exploratória e descritiva	Não supervisionada
Análise de Correspondência	Associação em tabelas de contingência	Interdependência	Exploratória e descritiva	Sem resposta externa na formulação
MANOVA	Hipóteses sobre várias respostas	Dependência	Inferencial	Respostas e efeitos definidos pelo delineamento
Análise Discriminante	Discriminação e classificação	Dependência	Descritiva e preditiva	Grupos conhecidos

Problema estatístico, objeto matemático e critério ou modelo permitem distinguir técnicas que reutilizam estruturas matemáticas semelhantes para finalidades diferentes.

13.5 Estruturas matemáticas recorrentes

As técnicas deste módulo reutilizam estruturas desenvolvidas nos Módulos 1 e 2. Combinações lineares, formas quadráticas, problemas espectrais, decomposições matriciais, métricas e modelos probabilísticos assumem funções diferentes conforme o problema estatístico.

13.5.1 Combinações lineares e projeções

As combinações lineares definidas na Definição 1.8 constroem novas variáveis e novas direções a partir das variáveis originais. Para um vetor aleatório $\mathbf{X}$, sua forma é

$$Y = \mathbf{a}^\top \mathbf{X}.$$

O vetor $\mathbf{a}$ desempenha funções distintas nessas técnicas. No Capítulo 14, seus coeficientes definem direções de variabilidade. No Capítulo 18, $\mathbf{a}$ define uma combinação linear das respostas na qual se compara a SQPC da hipótese à SQPC residual. Na Seção 19.6, seus coeficientes definem direções de separação entre grupos.

A projeção ortogonal definida na Definição 3.19 associa cada observação ao seu representante em um subespaço. No Capítulo 14, essa operação produz a representação no subespaço principal. Na formulação de Fisher, a representação da Seção 19.9 é construída pelas combinações lineares definidas pelas direções discriminantes, que são ortonormais na métrica induzida por $\mathbf{T}_{\text{intra}}$; essas coordenadas não devem ser identificadas, em geral, com uma projeção ortogonal euclidiana no espaço original.

13.5.2 Formas quadráticas e problemas espectrais

As formas quadráticas definidas na Definição 2.17 aparecem na variância de combinações lineares, em distâncias ponderadas e em diferentes medidas de dispersão. Quando o critério depende da direção escolhida, surgem problemas de otimização espectral.

O quociente de Rayleigh definido na Definição 5.5 relaciona a otimização de uma forma quadrática aos autovalores de uma matriz simétrica. O resultado do Teorema 5.3 é aplicado no Capítulo 14 à matriz de covariâncias ou de correlações para formular as componentes principais.

Quando duas formas quadráticas são comparadas, o quociente de Rayleigh generalizado da Definição 5.9 conduz ao problema de autovalores generalizados descrito no Teorema 5.6. Na Equação 18.14, o quociente compara a SQPC da hipótese $\mathbf{H}$ à SQPC residual $\mathbf{E}$; na Equação 19.30, compara a dispersão entre grupos à dispersão intragrupos.

Quando a matriz do denominador é positiva definida, a transformação de branqueamento da Equação 8.47 converte o produto interno por ela induzido em um produto interno euclidiano. Na MANOVA, o branqueamento pela SQPC residual $\mathbf{E}$ conduz ao problema simétrico da Equação 18.18; na formulação de Fisher, o branqueamento pela dispersão intragrupos conduz à matriz da Equação 19.31.

A decomposição espectral, sintetizada na Tabela 5.2, fornece as direções e magnitudes associadas a uma matriz simétrica. A interpretação dessas direções depende da matriz que foi construída e do problema estatístico que a originou.

13.5.3 Otimização sob restrições e critérios de ajuste

Diversas técnicas multivariadas definem suas soluções por meio da maximização ou minimização de um critério. Em termos gerais, a solução pode ser caracterizada por um problema da forma

$$\max_{\theta} f(\theta)$$

ou

$$\min_{\theta} Q(\theta),$$

eventualmente sujeito a restrições que delimitam o conjunto de soluções admissíveis.

Quando a função objetivo envolve uma forma quadrática e a restrição fixa a norma do vetor, os multiplicadores de Lagrange estabelecem a relação entre o problema de otimização e a equação de autovalores. A condição geral foi apresentada no Teorema 7.6 e a otimização sob restrição de norma foi ilustrada no Exemplo 7.10.

Os critérios de solução variam entre as técnicas. Na ACP, maximiza-se a variância de uma combinação linear sob uma restrição de normalização. Na formulação de Fisher, maximiza-se a razão entre dispersão entre grupos e dispersão intragrupos. Nas K -médias, minimiza-se a dispersão intragrupos em relação à partição e aos centroides. Na Análise Fatorial, o método de fatores principais utiliza uma construção espectral baseada em uma matriz reduzida; o método de mínimos resíduos (MINRES) minimiza a discrepância entre associações observadas e reproduzidas; e, sob normalidade multivariada, a máxima verossimilhança maximiza a verossimilhança do modelo.

O objeto obtido depende do critério e das restrições: as direções principais resolvem um problema variacional, os centroides minimizam a soma de quadrados intragrupos para uma partição fixa e as cargas fatoriais dependem do método de estimação adotado.

13.5.4 SVD e representações de baixa dimensão

A decomposição em valores singulares relaciona os espaços de linhas e colunas de uma matriz e permite construir aproximações de posto reduzido. Suas propriedades foram sintetizadas na Tabela 6.6.

No Capítulo 14, a SVD é aplicada à matriz de dados centralizada. No Capítulo 17, a SVD é aplicada à matriz de desvios padronizados da independência definida na Definição 17.5 e decompõe a inércia conforme a Seção 17.7.

A operação matricial é a mesma, mas a matriz decomposta e a interpretação dos valores e vetores singulares são diferentes.

13.5.5 Distâncias e métricas

Distância e dissimilaridade não são sinônimos. A Definição 16.1 admite medidas que não satisfazem todas as propriedades de uma distância. A distância euclidiana da Definição 1.13 é central nas K -médias e constitui uma das medidas disponíveis nos métodos hierárquicos do Capítulo 16.

No Capítulo 17, a Definição 17.3 estabelece a geometria dos perfis, ponderando suas diferenças pelas massas da margem oposta. A distância de Mahalanobis da Definição 8.8 pondera os deslocamentos pela matriz de covariâncias. Na Equação 8.46, direções de maior variabilidade recebem menor peso no afastamento padronizado. Na Seção 19.3, uma matriz de covariâncias comum define a mesma métrica de Mahalanobis para todas as classes; na Seção 19.4, cada classe utiliza sua própria matriz de covariâncias.

13.5.6 Modelos lineares e probabilísticos

O modelo linear multivariado da Definição 11.3 representa conjuntamente várias respostas, o delineamento e a matriz de parâmetros. A hipótese linear geral da Definição 11.15 seleciona as funções dos parâmetros que serão testadas. No Capítulo 18, a hipótese determina a SQPC $\mathbf{H}$, enquanto o ajuste residual do modelo determina a SQPC $\mathbf{E}$; as raízes características do par $(\mathbf{H}, \mathbf{E})$ são utilizadas nos critérios da Seção 18.5.

Outras técnicas acrescentam estruturas probabilísticas específicas à sua formulação. No Capítulo 15, o modelo da Definição 15.1 especifica uma estrutura para a matriz de covariâncias, e a estimação por máxima verossimilhança acrescenta uma formulação probabilística baseada na normalidade multivariada. No Capítulo 19, distribuições condicionais, probabilidades *a priori* e perdas definem o problema de decisão; sob perda zero-um, a regra de Bayes escolhe a classe de maior probabilidade *a posteriori*.

Nas formulações por máxima verossimilhança, a função da Definição 10.7 e a razão da Definição 12.3 são utilizadas sem nova definição. A interpretação inferencial preserva a distinção entre resultados exatos e assintóticos estabelecida na Definição 12.1.

A Tabela 13.4 relaciona estruturas dos Módulos 1 e 2 às técnicas do Módulo 3 que as utilizam diretamente.

Tabela 13.4: Estruturas dos Módulos 1 e 2 reutilizadas na formulação das técnicas.

Estrutura desenvolvida anteriormente	Utilização no Módulo 3	Técnicas diretamente relacionadas
Centralização e padronização	Centralização da representação na ACP e definição das escalas relativas na ACP e na Análise de Agrupamentos	ACP, Agrupamentos
Combinações lineares	Construção de novas direções ou variáveis	ACP, MANOVA, Discriminante
Projeções ortogonais	Representação em subespaços ortogonais	ACP
Formas quadráticas	Medida de variabilidade, distância ponderada, inércia ou separação	ACP, Correspondência, MANOVA, Discriminante
Otimização sob restrições e critérios de ajuste	Definição de soluções por maximização ou minimização de um critério	ACP, Fatorial, Agrupamentos, MANOVA, Discriminante
Autovalores e autovetores	Decomposição espectral e determinação de direções; em métodos fatoriais específicos, obtenção de soluções de cargas	ACP; Fatorial pelo método de fatores principais
Autovalores e autovetores generalizados	Comparação entre formas quadráticas e determinação de direções extremas	MANOVA; Discriminante na formulação de Fisher
SVD	Decomposição e representação de baixa dimensão	ACP, Correspondência
Produtos internos e métricas induzidas	Construção de geometrias ponderadas ou adaptadas à estrutura de dispersão	Correspondência, MANOVA, Discriminante
Distâncias e métricas	Comparação de objetos ou perfis e construção de regras de classificação	Agrupamentos, Correspondência, Discriminante
Covariâncias e correlações	Representação da variabilidade conjunta e da associação linear	ACP, Fatorial, MANOVA, Discriminante

Estrutura desenvolvida anteriormente	Utilização no Módulo 3	Técnicas diretamente relacionadas
Dispersão dentro e entre grupos	Quantificação da homogeneidade intragrupos e da separação entre grupos	Agrupamentos; MANOVA em delineamentos com grupos; Discriminante na formulação de Fisher
Modelo linear multivariado	Representação conjunta de respostas e efeitos	MANOVA
Normal multivariada	Formulações probabilísticas e resultados inferenciais sob hipóteses específicas	ACP em resultados específicos de estimação e inferência; Fatorial na formulação probabilística normal; Discriminante nas regras LDA/QDA; MANOVA
Função e razão de verossimilhanças	Estimação e comparação sob formulações probabilísticas específicas	Fatorial por máxima verossimilhança; MANOVA na relação entre a razão de verossimilhanças e a lambda de Wilks sob o modelo normal

13.6 Mesmas operações, diferentes funções

Uma mesma operação matemática pode desempenhar funções diferentes conforme a matriz, a métrica ou o critério ao qual é aplicada.

No Capítulo 14, a decomposição espectral da matriz de covariâncias ou correlações determina as direções principais e suas variâncias. No Capítulo 15, o método de fatores principais aplica a decomposição espectral a uma matriz reduzida, cuja diagonal contém comunalidades estimadas, para obter uma solução não rotacionada de cargas. No Capítulo 18, os autovalores generalizados comparam a SQPC da hipótese $\mathbf{H}$ à SQPC residual $\mathbf{E}$; na Seção 19.6, comparam a dispersão entre grupos à dispersão intragrupos.

A SVD apresenta a mesma característica. Aplicada à matriz de dados centralizada, participa da formulação da ACP. Aplicada à matriz de desvios padronizados da independência, decompõe a inércia e determina as dimensões da Análise de Correspondência.

A Tabela 13.5 associa cada operação ao objeto analisado e ao papel que desempenha na técnica.

Tabela 13.5: Exemplos de operações matemáticas aplicadas a objetos distintos.

Operação matemática	Objeto analisado	Papel na técnica
Decomposição espectral	Matriz de covariâncias ou correlações	Direções e variâncias principais
Decomposição espectral	Matriz reduzida da Análise Fatorial	Solução não rotacionada de cargas pelo método de fatores principais
Autovalores generalizados	Dispersão entre e dentro dos grupos na formulação de Fisher	Direções discriminantes de Fisher
Autovalores generalizados	SQPC da hipótese $\mathbf{H}$ e SQPC residual $\mathbf{E}$	Direções que extremizam a razão $\mathbf{a}^\top \mathbf{H} \mathbf{a} / \mathbf{a}^\top \mathbf{E} \mathbf{a}$ e raízes características associadas
SVD	Matriz de dados centralizada	Direções, escores e representação de baixa dimensão
SVD	Matriz de desvios padronizados da independência	Dimensões que decompõem a inércia da tabela

A interpretação de um autovalor, autovetor, valor singular, vetor singular ou coordenada exige identificar a matriz de origem e o critério que definiu sua construção. Uma mesma operação pode resolver problemas estatísticos diferentes quando é aplicada a objetos distintos ou associada a critérios diferentes.

As fontes de não unicidade também devem ser distinguidas. Na ACP, a indeterminação de sinal e os efeitos da multiplicidade são desenvolvidos na Seção 14.13.4.3. Na Análise Fatorial, a Proposição 15.2 formaliza a indeterminação associada à rotação dos fatores. Na Análise de Agrupamentos, diferentes inicializações das K -médias podem conduzir a partições finais distintas, conforme a Seção 16.12.5.1, enquanto empates durante a construção de uma hierarquia podem produzir diferentes sequências de fusões, como discutido na Seção 16.11.3. Na MANOVA, sinais e multiplicidades das direções são discutidos na Seção 18.9.4. Na formulação de Fisher, o problema de autovalores generalizados também produz indeterminação de sinal para raízes simples e identifica um subespaço, em vez de uma base única de direções, quando há raízes múltiplas, conforme a Seção 19.14.7. Essas indeterminações possuem origens matemáticas distintas.

As propriedades diante de transformações dependem da técnica e da transformação considerada. A ACP baseada em covariâncias é invariante a translações, mas pode mudar sob reescalamentos individuais, conforme a Seção 14.13.4. Na Análise Fatorial, rotações ortogonais preservam a parte comum da matriz de covariâncias e modificam as cargas, conforme a

Seção 15.14.2. Na Análise de Agrupamentos, translações não alteram as distâncias euclidianas, uma mudança comum de escala multiplica todas essas distâncias pelo mesmo fator e reescalamentos distintos das variáveis podem modificar suas proximidades relativas, conforme a Seção 16.3.1. Na MANOVA, transformações lineares não singulares das respostas preservam as raízes características e os critérios quando a hipótese é transformada de modo correspondente, conforme a Seção 18.9.3.

13.7 Relações entre as técnicas

Algumas técnicas compartilham estruturas matemáticas, embora resolvam problemas estatísticos diferentes. A Tabela 13.6 explicita a estrutura compartilhada e a diferença entre as finalidades de cada par de técnicas.

Tabela 13.6: Relações conceituais entre técnicas do Módulo 3.

Técnicas relacionadas	Estrutura compartilhada	Diferença principal
ACP e Análise Fatorial	Matrizes de covariâncias ou correlações e representações de menor dimensão	ACP representa a variabilidade total; Fatorial modela as covariâncias por fatores comuns e variâncias específicas
Agrupamentos e Discriminante	Grupos, médias e medidas de dispersão ou proximidade	A Análise de Agrupamentos constrói grupos sem rótulos previamente fornecidos; na Análise Discriminante, os rótulos conhecidos participam da construção das direções de Fisher ou das regras de classificação
MANOVA e Discriminante	Na MANOVA de um fator e na formulação de Fisher para os mesmos grupos, matrizes de dispersão entre e dentro dos grupos e o mesmo problema de autovalores generalizados	MANOVA testa hipóteses sobre os vetores de médias; Fisher utiliza as direções características para representar a separação entre grupos, e a classificação requer uma formulação adicional

Técnicas relacionadas	Estrutura compartilhada	Diferença principal
ACP e Correspondência	Decomposições matriciais e representações de baixa dimensão	ACP organiza a variabilidade de dados quantitativos a partir de matrizes de covariâncias ou correlações; Correspondência organiza os desvios padronizados da independência e representa perfis segundo a geometria qui-quadrado

A Tabela 15.4 sintetiza a relação entre ACP e Análise Fatorial. A Tabela 16.6 organiza as relações da Análise de Agrupamentos com outras técnicas. A Equação 19.40 estabelece a conexão espectral entre MANOVA e a formulação de Fisher.

A técnica é identificada pelo problema estatístico, pelo objeto analisado e pelo critério de solução; a operação matricial, isoladamente, não determina o método.

13.8 Aprofundamento metodológico e aplicado

A escolha de uma técnica multivariada começa pela definição do problema estatístico. O número de variáveis disponíveis não determina o método. A finalidade da análise, a natureza das variáveis, a estrutura dos dados e o objeto que se pretende estimar, representar, comparar ou classificar determinam quais procedimentos são compatíveis com a investigação.

A Tabela 13.2 relaciona as classes de problemas estudadas às respectivas estruturas matemáticas e estatísticas. A Tabela 13.3 complementa essa organização ao distinguir dependência e interdependência, finalidade analítica e presença de supervisão. Essas classificações orientam a escolha do método, mas não substituem a definição do problema de pesquisa (Hair et al., 2009; Johnson; Wichern, 2002).

13.8.1 Etapas da análise multivariada

Hair et al. organizam a aplicação de métodos multivariados em seis estágios: definição do problema, planejamento da análise, avaliação das condições da técnica, obtenção da solução, interpretação e validação (Hair et al., 2009). Essa organização pode ser utilizada para as técnicas consideradas aqui desde que cada etapa seja adaptada ao objeto estatístico correspondente.

Tabela 13.7: Etapas gerais de uma análise multivariada.

Etapa	Conteúdo
1. Definição do problema	Especificar a finalidade da análise, as unidades observacionais, os objetos de interesse e o papel das variáveis, grupos ou categorias.
2. Planejamento	Definir as variáveis utilizadas, suas escalas de medida, a estrutura de entrada, o tamanho amostral total e por grupo e as decisões estabelecidas antes do exame dos dados.
3. Exame dos dados e das condições	Examinar distribuições marginais, relações entre variáveis, dados ausentes, observações atípicas e condições exigidas pela formulação adotada.
4. Obtenção e avaliação da solução	Aplicar o critério, modelo, algoritmo ou decomposição correspondente e avaliar o ajuste, a adequação ou as discrepâncias pertinentes à técnica.
5. Interpretação	Relacionar componentes, fatores, grupos, dimensões, efeitos ou funções ao problema que motivou a análise.
6. Estabilidade e validação	Avaliar a dependência da solução em relação à amostra, às variáveis utilizadas e às decisões metodológicas adotadas.

As etapas podem exigir revisão de decisões anteriores. A identificação de dados ausentes pode alterar o tamanho amostral efetivo; observações atípicas podem motivar a verificação dos registros ou uma análise de sensibilidade; uma transformação pode modificar a escala das variáveis; uma solução instável pode exigir revisão das variáveis utilizadas ou do critério de análise. Alterações motivadas pelo exame dos próprios dados devem ser registradas como parte da análise.

13.8.2 Natureza das variáveis e escalas de medida

A natureza da variável descreve o tipo de valor registrado. Variáveis qualitativas representam categorias, enquanto variáveis quantitativas representam quantidades numéricas.

A escala de medida especifica como os valores podem ser comparados e quais operações possuem interpretação. Escalas nominais distinguem categorias; escalas ordinais acrescentam or-

denação; escalas intervalares admitem interpretação das diferenças; escalas de razão também possuem uma origem compatível com a interpretação de razões.

A representação de uma categoria por um número não altera sua natureza. Códigos como 1, 2 e 3 podem identificar categorias nominais ou ordinais sem representar distâncias quantitativas entre seus níveis.

Variáveis nominais representam categorias sem ordenação quantitativa. Variáveis ordinais acrescentam uma ordenação, mas não estabelecem, por si só, a magnitude das diferenças entre categorias consecutivas. Variáveis quantitativas permitem operações relacionadas à magnitude dos valores, respeitadas as propriedades da escala utilizada.

Essa distinção aparece diretamente nas técnicas consideradas. Nas formulações desenvolvidas neste módulo, a ACP e a Análise Fatorial utilizam matrizes de covariâncias ou correlações entre variáveis tratadas como quantitativas. A Análise de Correspondência utiliza frequências de categorias. A MANOVA distingue as respostas quantitativas dos fatores que definem os grupos ou efeitos do delineamento. A Análise Discriminante utiliza grupos previamente conhecidos e variáveis observadas para construir funções de separação ou regras de classificação. Na Análise de Agrupamentos, a natureza das variáveis determina quais medidas de proximidade possuem interpretação coerente.

As unidades de medida também interferem nas técnicas baseadas em variâncias, covariâncias ou distâncias. Na ACP baseada na matriz de covariâncias, uma variável com maior escala numérica pode contribuir mais para a variabilidade total. Na Análise de Agrupamentos baseada em distância euclidiana, reescalamentos distintos das variáveis modificam as distâncias e podem alterar os grupos obtidos.

Centralização e padronização devem ser distinguidas. A centralização de todas as observações de uma variável pela mesma constante modifica a origem da representação, mas não altera as distâncias euclidianas entre pares de observações. A padronização modifica as escalas relativas das variáveis e, portanto, pode alterar essas distâncias.

13.8.2.1 Erro de medida, validade e confiabilidade

Os valores registrados podem diferir dos valores que se pretende representar. Erros de mensuração podem decorrer de instrumentos imprecisos, procedimentos de coleta, codificação, classificação ou respostas fornecidas pelas próprias unidades observadas. Esses erros podem alterar médias, variâncias, covariâncias, correlações, distâncias e outras quantidades utilizadas pelas técnicas multivariadas.

A **validade** refere-se à correspondência entre a medida utilizada e a característica ou o conceito que se pretende representar. Uma variável pode ser medida com precisão e ainda assim representar inadequadamente o conceito de interesse.

A **confiabilidade** refere-se à consistência da mensuração. Medidas pouco confiáveis apresentam maior variação atribuível ao processo de mensuração e podem dificultar a identificação das relações de interesse.

Quando um conceito não é observado diretamente, vários indicadores podem ser utilizados para representar diferentes aspectos desse conceito. O uso de múltiplos indicadores, entretanto, não garante validade ou confiabilidade; a qualidade das medidas e sua relação com o conceito continuam precisando de avaliação.

13.8.3 Tamanho amostral, dimensão e poder

O tamanho da amostra afeta a precisão das estimativas, a estabilidade das estruturas calculadas a partir dos dados e, nos procedimentos inferenciais, o poder dos testes.

A dimensão também deve ser considerada conjuntamente com o número de observações. Para uma matriz de dados com n observações e p variáveis, a Equação 8.60 estabelece

$$\text{posto}(\mathbf{S}) \leq \min(p, n - 1).$$

Consequentemente, quando $p \geq n$, a matriz de covariâncias observada é necessariamente singular. Mesmo antes da singularidade, um número elevado de variáveis em relação ao tamanho da amostra pode produzir estimativas instáveis de covariâncias, correlações e direções obtidas a partir dessas matrizes.

Nas análises com grupos, o tamanho amostral total não descreve toda a informação disponível. As quantidades de observações em cada grupo afetam a estimação das médias e das matrizes de dispersão e podem produzir precisões diferentes entre grupos.

Nos procedimentos inferenciais, o poder depende do tamanho amostral, do nível de significância e da magnitude do efeito. Amostras pequenas podem produzir baixa probabilidade de detectar efeitos existentes. Amostras muito grandes podem tornar estatisticamente detectáveis diferenças de pequena magnitude. A interpretação de um teste deve, portanto, considerar o tamanho do efeito estimado e sua importância para o problema investigado, além do valor- p (Hair et al., 2009).

Não há uma razão única entre número de observações e número de variáveis que seja aplicável a todas as técnicas. Condições de posto, número de parâmetros, método de estimação e finalidade da análise produzem exigências distintas.

13.8.4 Exame preliminar dos dados

O exame preliminar deve considerar características marginais e conjuntas. Médias, dispersões, frequências e distribuições marginais descrevem cada variável separadamente, mas não determinam as relações entre variáveis. Diagramas de dispersão, matrizes de correlações, matrizes de covariâncias, tabelas de contingência e gráficos condicionados a grupos acrescentam informação sobre a configuração conjunta (Hair et al., 2009; Johnson; Wichern, 2002).

Para variáveis quantitativas, devem ser examinados localização, dispersão, assimetria, amplitude e possíveis observações atípicas. Para variáveis categóricas, devem ser verificadas as frequências das categorias, a presença de categorias pouco representadas e a coerência das codificações.

Quando existem grupos conhecidos, a descrição também deve ser feita dentro de cada grupo. Médias e dispersões agregadas podem ocultar diferenças importantes entre grupos, enquanto padrões aparentemente presentes no conjunto completo podem decorrer apenas da mistura de grupos com comportamentos distintos.

O exame conjunto também pode revelar relações não lineares, redundâncias entre variáveis e combinações incomuns de valores que não aparecem nas análises marginais. Uma observação pode ser comum em cada variável isoladamente e atípica quando considerada sua posição conjunta.

13.8.4.1 Dados ausentes

Dados ausentes devem ser examinados por variável e por observação. A quantidade total de valores ausentes não informa, sozinha, seu impacto. A concentração das ausências em determinadas variáveis, grupos ou tipos de observação pode alterar a composição da amostra utilizada na análise.

A eliminação completa de observações com algum valor ausente pode reduzir o tamanho amostral efetivo, sobretudo quando as ausências se distribuem por várias variáveis. A exclusão de uma variável também pode alterar o problema estatístico, especialmente quando ela representa um aspecto necessário da investigação.

O tratamento escolhido para os dados ausentes pode modificar médias, covariâncias, correlações e distâncias. A extensão das ausências, seu padrão e sua relação com o processo de coleta devem ser examinados antes da escolha entre exclusão, imputação ou outro procedimento (Hair et al., 2009).

13.8.4.2 Observações atípicas

Observações atípicas podem ocorrer em uma variável isolada, em uma relação entre duas variáveis ou apenas na configuração multivariada. A identificação exclusivamente marginal não é suficiente para localizar todos os casos que podem exercer influência sobre uma análise multivariada.

Uma observação atípica não deve ser removida apenas porque se diferencia das demais. Primeiro deve ser verificado se há erro de registro, erro de mensuração ou condição especial de coleta. Quando o valor é legítimo, sua influência sobre a análise deve ser examinada.

A exclusão de uma observação legítima altera a amostra analisada e pode modificar as estimativas e a solução obtida. Por esse motivo, análises com e sem observações influentes podem ser utilizadas para avaliar a sensibilidade dos resultados quando houver justificativa para essa comparação.

13.8.5 Pressupostos da formulação adotada

Normalidade, linearidade, independência e homogeneidade de variâncias ou covariâncias não constituem um conjunto de requisitos comum a todas as técnicas multivariadas. Cada condição deve ser associada à formulação na qual é utilizada.

A ACP descritiva pode ser construída a partir de uma matriz de covariâncias ou correlações sem hipótese de normalidade multivariada. A Análise de Agrupamentos baseada em distâncias também não exige normalidade para formar os grupos. A Análise de Correspondência utiliza frequências, massas, perfis e geometria qui-quadrado sem assumir normalidade multivariada. A formulação de Fisher para Análise Discriminante define direções de separação a partir das dispersões entre grupos e intragrupos sem exigir normalidade.

A normalidade passa a desempenhar papel específico quando a formulação utiliza um modelo probabilístico normal ou resultados inferenciais derivados desse modelo. Isso ocorre, por exemplo, na estimação por máxima verossimilhança da Análise Fatorial, na inferência clássica da MANOVA e nas regras LDA e QDA derivadas de distribuições normais por classe.

A igualdade de matrizes de covariâncias também possui funções específicas. Na MANOVA clássica com grupos, ela integra as condições do modelo utilizado para obter a calibração inferencial correspondente. Na classificação normal, a hipótese de matriz de covariâncias comum conduz à LDA, enquanto matrizes específicas por classe conduzem à QDA.

A independência entre unidades amostrais decorre do delineamento e do mecanismo de amostragem e não pode ser diagnosticada apenas a partir de histogramas ou matrizes de correlações. Quando existe dependência temporal, espacial, familiar ou decorrente do próprio desenho amostral, a formulação estatística deve representar essa dependência ou empregar um procedimento compatível com o mecanismo de amostragem.

O exame marginal também não substitui o exame conjunto. Normalidade univariada de todas as variáveis, por exemplo, não implica normalidade multivariada. A propriedade exigida pela técnica deve ser verificada no nível em que aparece na formulação estatística (Hair et al., 2009).

13.8.6 Transformações e reespecificações

Transformações podem ser definidas pela natureza da variável ou motivadas pelo exame dos dados. Hair et al. distinguem essas duas situações porque a justificativa da transformação interfere em sua interpretação (Hair et al., 2009).

Transformações logarítmicas, de raiz ou de potência modificam a escala da variável e podem alterar assimetria, dispersão, covariâncias, correlações e distâncias. A transformação escolhida deve ser compatível com o domínio da variável e com o significado dos valores transformados.

Padronização não é equivalente a uma transformação destinada a corrigir assimetria ou heterogeneidade de variâncias. A padronização altera a origem e a unidade da variável para produzir uma escala comum; uma transformação não linear altera também as relações entre diferenças originalmente observadas.

Mudanças realizadas após a inspeção dos dados devem ser documentadas. Quando não estavam previstas no plano de análise, a retirada de variáveis, a mudança da medida de proximidade ou a modificação da especificação de um modelo constituem reespecificações. A escolha do número de componentes ou fatores por um critério definido previamente faz parte do procedimento de análise; mudanças posteriores no critério de retenção constituem reespecificações. Essas decisões devem ser consideradas na interpretação e na avaliação de estabilidade.

13.8.7 Interpretação e significância prática

A interpretação deve utilizar o objeto definido pela técnica. Na ACP, os autovalores são as variâncias das componentes principais. Na MANOVA e na formulação de Fisher, as raízes características são os autovalores dos problemas generalizados definidos pelas respectivas matrizes de dispersão. Cargas fatoriais representam relações entre variáveis observadas e fatores na formulação adotada. Escores localizam observações nas dimensões construídas. Distâncias quantificam proximidades segundo a métrica escolhida. Funções discriminantes representam direções de separação entre grupos conhecidos.

A significância estatística responde a uma questão inferencial sobre compatibilidade entre os dados e uma hipótese. Ela não determina a importância científica ou aplicada da diferença observada. A interpretação deve considerar também o tamanho do efeito, a precisão de sua estimação e as consequências associadas ao problema investigado (Hair et al., 2009).

Previsão, explicação estatística e inferência causal também devem ser distinguidas. Uma regra pode apresentar bom desempenho preditivo sem que suas variáveis tenham interpretação causal. Da mesma forma, associação estatística ou rejeição de uma hipótese nula não estabelece, por si só, que uma variável ou intervenção produza o efeito observado.

A interpretação causal exige que o delineamento e as hipóteses de identificação permitam separar o efeito de interesse de explicações alternativas. Em estudos experimentais, a aleatorização pode fornecer essa base. Em estudos observacionais, conclusões causais exigem condições adicionais que não decorrem da aplicação de uma técnica multivariada.

Nas técnicas exploratórias e descritivas, a avaliação utiliza critérios associados ao respectivo problema. Na ACP, a proporção de variância representada quantifica a variabilidade preservada pelas componentes mantidas. Na Análise Fatorial, as comunalidades e as discrepâncias entre associações observadas e reproduzidas informam sobre a representação da estrutura de covariâncias ou correlações. Na Análise de Agrupamentos, a dispersão intragrupos e a estabilidade da partição fornecem informações sobre a solução obtida. Na Análise de Correspondência, as inércias principais quantificam a parcela da inércia associada às dimensões da representação.

13.8.8 Diagnóstico da análise

Medidas globais não identificam todos os pontos nos quais uma análise representa mal os dados. O diagnóstico deve examinar os casos, variáveis ou grupos responsáveis pelas principais discrepâncias.

Em modelos que produzem resíduos, padrões residuais podem indicar relações não representadas, heterogeneidade ou observações influentes. Na Análise Discriminante, os erros de classificação mostram quais observações ou grupos são mais difíceis de distinguir. Na Análise de Agrupamentos, grupos formados por uma única observação ou objetos cuja associação ao grupo muda diante de pequenas alterações podem indicar instabilidade. Em métodos de redução de dimensionalidade, observações ou variáveis com baixa qualidade de representação exigem cautela na interpretação das dimensões mantidas.

Hair et al. tratam erros, resíduos, classificações incorretas e observações atípicas como fontes de diagnóstico, e não como elementos que devam ser removidos automaticamente (Hair et al., 2009).

Uma discrepância pode decorrer de erro de registro, insuficiência do modelo, escolha inadequada das variáveis, presença de subgrupos não considerados ou comportamento legítimo de uma parte da população. A causa deve ser investigada antes de qualquer alteração da análise.

13.8.9 Parcimônia

A seleção das variáveis deve ser orientada pelo problema de pesquisa. A inclusão indiscriminada de variáveis pode aumentar a complexidade, introduzir redundância e tornar a interpretação menos estável.

A definição das variáveis utilizadas na análise deve ser distinguida da seleção de variáveis orientada pelos próprios dados. A especificação parte do problema de pesquisa e determina quais características são necessárias para representar o fenômeno, formar a geometria da análise ou definir o modelo. A seleção utiliza os dados observados para escolher um subconjunto entre variáveis candidatas.

Essa distinção é importante porque, em várias técnicas, retirar ou acrescentar uma variável modifica o próprio objeto analisado. Em uma Análise de Agrupamentos, por exemplo, a alteração do conjunto de variáveis modifica as proximidades entre os objetos. Na ACP, modifica a matriz cuja variabilidade será decomposta. Em procedimentos de classificação, uma seleção realizada com os mesmos dados utilizados para avaliar a regra pode produzir uma estimativa excessivamente favorável de desempenho.

Procedimentos automáticos não substituem a justificativa para a presença das variáveis na análise. Quando a seleção depende dos dados, essa etapa também deve ser considerada na avaliação de estabilidade ou validação.

Em métodos baseados em covariâncias ou correlações, variáveis fortemente redundantes podem produzir matrizes mal condicionadas ou quase singulares. Em métodos baseados em distâncias, variáveis sem relação com o objetivo da análise podem alterar as proximidades entre objetos. Em procedimentos preditivos, variáveis adicionais podem melhorar o ajuste na própria amostra sem melhorar o desempenho em novas observações (Hair et al., 2009).

Parcimônia não corresponde à minimização automática do número de variáveis ou dimensões. A redução deve preservar a informação necessária ao objetivo da análise. Uma solução mais simples é preferível quando representa de forma comparável o aspecto do problema que motivou a técnica.

13.8.10 Estabilidade e validação

Resultados multivariados podem depender da amostra observada e de escolhas realizadas durante a análise. A avaliação de estabilidade examina quanto a solução se modifica quando a informação disponível ou decisões metodológicas plausíveis são alteradas.

Em problemas preditivos, o desempenho deve ser avaliado com observações que não tenham sido utilizadas para estimar a regra sempre que o tamanho amostral permitir. Separação entre treinamento e teste, validação cruzada e reamostragem são alternativas para estimar desempenho fora da amostra.

Em métodos exploratórios, a estabilidade pode ser avaliada por reamostragem ou por análises de sensibilidade. Na ACP e na Análise Fatorial, interessa verificar a estabilidade das direções, cargas ou dimensionalidade selecionada. Na Análise de Agrupamentos, devem ser examinados efeitos da inicialização, das variáveis incluídas, da padronização e da medida de proximidade. Na Análise de Correspondência, categorias com grande influência podem alterar a representação de baixa dimensão.

Em MANOVA, a interpretação dos testes depende das condições do modelo e da sensibilidade das conclusões a observações influentes e a especificações plausíveis. Na Análise Discriminante, a taxa de classificação obtida nos mesmos dados utilizados para construir a regra tende a ser otimista e deve ser distinguida do desempenho obtido em novas observações.

Validação e estabilidade não transformam uma técnica exploratória em procedimento confirmatório. Elas indicam em que medida a solução depende de particularidades da amostra ou das escolhas feitas durante a análise. Se pequenas alterações nos dados ou nas decisões metodológicas modificarem a interpretação ou a conclusão da análise, a solução deve ser descrita como instável.

13.9 Síntese

As técnicas multivariadas deste módulo utilizam os fundamentos construídos nos Módulos 1 e 2 para resolver problemas estatísticos distintos. A formulação de cada técnica combina uma estrutura de dados, um objeto matemático e um critério ou modelo. O compartilhamento de uma decomposição, uma forma quadrática, uma métrica ou um problema espectral não torna duas técnicas estatisticamente equivalentes; o significado da solução depende do problema e do objeto ao qual a estrutura matemática é aplicada.

A centralização e a padronização definem a origem e a escala da representação utilizada por determinadas técnicas. Combinações lineares e projeções produzem novas direções e representações. Formas quadráticas e problemas espectrais permitem estudar variabilidade e comparar fontes de dispersão. Na MANOVA, o branqueamento pela SQPC residual $\mathbf{E}$ conduz a um problema espectral simétrico; na formulação de Fisher, o branqueamento pela dispersão intragrupos produz a construção análoga.

Autovalores e autovetores definem diretamente a solução da ACP e aparecem na Análise Fatorial no método de fatores principais; o modelo fatorial, porém, é definido pela decomposição da covariância em uma parte comum e uma parte específica. A SVD fornece representações de baixa dimensão na ACP e, na Seção 17.7, decompõe a inércia da Análise de Correspondência. No Capítulo 16, as K -médias e os métodos hierárquicos mostram que a organização dos objetos em grupos depende da representação, da proximidade e do critério adotados. A Seção 18.5 constrói quatro critérios a partir das mesmas raízes características. No Capítulo 19, a classificação probabilística por Bayes e suas especializações LDA/QDA permanecem distintas da separação geométrica definida pelo critério de Fisher.

As fontes de não unicidade são específicas da técnica. Na ACP, na MANOVA e na formulação de Fisher, sinais e bases de subespaços podem ser indeterminados em problemas espectrais; na Análise Fatorial, a rotação produz indeterminação das cargas; na Análise de Agrupamentos, diferentes inicializações das K -médias ou empates hierárquicos podem produzir soluções distintas.

A normalidade multivariada é uma hipótese adicional nas formulações probabilísticas e inferenciais que a assumem; não é requisito das construções algébricas e geométricas. A máxima verossimilhança aparece nos métodos cujo critério de estimação ou teste é formulado por verossimilhança.

A interpretação de cada técnica exige considerar conjuntamente o problema estatístico, o objeto analisado, o critério de solução e as hipóteses probabilísticas associadas à formulação adotada.

14 Formulação da Análise de Componentes Principais

A Análise de Componentes Principais (ACP) representa a variabilidade de um conjunto de variáveis por meio de combinações lineares ordenadas segundo a variância que concentram (Johnson; Wichern, 2002). Seu objetivo é construir uma representação de menor dimensão que preserve, segundo esse critério, a maior parcela possível da variabilidade original.

A formulação utiliza o quociente de Rayleigh da Definição 5.5, o Teorema 5.2, a projeção ortogonal da Definição 3.19 e a SVD compacta da Definição 6.4. A construção é desenvolvida nas formulações populacional, amostral e por SVD e distingue a ACP baseada na matriz de covariâncias daquela baseada na matriz de correlações.

14.1 O problema de redução de dimensionalidade

Considere o vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_p)^\top \in \mathbb{R}^p,$$

com vetor de médias μ e matriz de covariâncias populacional Σ , definida na Definição 8.2.

Cada realização $\mathbf{x} \in \mathbb{R}^p$ representa uma unidade por meio de p coordenadas. Quando várias dessas coordenadas apresentam associação linear, a variabilidade conjunta pode estar concentrada em um número menor de direções.

A Figura 14.1 ilustra essa interpretação geométrica. Uma nuvem de pontos em $\mathbb{R}^2$ pode apresentar grande extensão em uma direção e pequena extensão na direção ortogonal. Duas coordenadas são necessárias para representar exatamente cada ponto, mas uma única direção pode concentrar a maior parte da dispersão da nuvem. Em dimensão p , o mesmo princípio conduz à procura de um subespaço de dimensão $k < p$ que preserve a maior variabilidade possível segundo o critério da ACP.

A ACP não seleciona diretamente k variáveis dentre as p variáveis originais. Ela constrói novas variáveis como combinações lineares das componentes de $\mathbf{X}$. Cada combinação é determinada por um vetor de coeficientes em $\mathbb{R}^p$, que define uma direção no espaço das observações.

O vetor aleatório centralizado,

$$\mathbf{X}_c = \mathbf{X} - \mu,$$

tem média nula e preserva a matriz de covariâncias de $\mathbf{X}$. A centralização separa a localização da distribuição de sua estrutura de dispersão. Por isso, a formulação populacional da ACP pode ser construída diretamente a partir de $\mathbf{X}_c$ e de Σ .

Uma direção unitária

$$\alpha \in \mathbb{R}^p, \quad \alpha^\top \alpha = 1,$$

produz a combinação linear

$$Y = \alpha^\top \mathbf{X}_c.$$

Como α possui norma unitária, Y representa a coordenada de $\mathbf{X}_c$ na direção definida por α .

Pelo resultado sobre momentos de combinações lineares apresentado na Proposição 8.1,

$$E(Y) = 0$$

e

$$\text{Var}(Y) = \alpha^\top \Sigma \alpha.$$

A variância da combinação linear depende, portanto, da direção α . Algumas direções podem apresentar grande dispersão, enquanto outras apresentam pequena dispersão.

A ACP ordena as direções pela variância das combinações lineares associadas. A primeira direção principal é a direção unitária que maximiza essa variância. Cada direção seguinte maximiza a variância entre as direções unitárias ortogonais às já selecionadas.

A Figura 14.1 representa uma nuvem bidimensional com variabilidade distinta segundo diferentes direções. A primeira direção principal acompanha a maior extensão da nuvem, enquanto a segunda é ortogonal à primeira e representa a variabilidade remanescente.

A maior dispersão ocorre na direção da primeira componente. A segunda componente representa a maior variabilidade possível entre as direções ortogonais à primeira. As duas direções mostram geometricamente a ordenação das componentes segundo a variância.

A redução de dimensionalidade ocorre quando apenas as primeiras $k < p$ direções são mantidas. A parcela de variabilidade preservada depende da concentração da variância total nessas direções. Quando as primeiras componentes concentram grande parte da variância total, poucas componentes retêm uma parcela elevada da variabilidade. Quando a variância se distribui




Figura 14.1: As direções principais acompanham os eixos de maior e menor variabilidade da nuvem de observações.

de modo mais uniforme entre as componentes, reduzir a dimensão descarta uma parcela maior da variabilidade total.

14.2 Componentes principais como combinações lineares

A j -ésima componente principal populacional tem a forma

$$Y_j = \alpha_j^\top \mathbf{X}_c = \alpha_j^\top (\mathbf{X} - \mu),$$

em que

$$\alpha_j \in \mathbb{R}^p$$

é o vetor de coeficientes da componente.

A formulação distingue os seguintes objetos:

- α_j define uma direção no espaço das variáveis;
- Y_j é uma variável aleatória obtida pela projeção de $\mathbf{X}_c$ nessa direção;
- a variância de Y_j quantifica a dispersão populacional representada pela direção;
- na formulação amostral, a versão estimada de α_j determina os escores das observações definidos na Definição [14.1](#).

Para duas combinações lineares,

$$Y_j = \alpha_j^\top \mathbf{X}_c$$

e

$$Y_\ell = \alpha_\ell^\top \mathbf{X}_c,$$

tem-se

$$\text{Cov}(Y_j, Y_\ell) = \alpha_j^\top \Sigma \alpha_\ell.$$

Assim, a matriz Σ determina simultaneamente a variância de cada combinação linear e a covariância entre diferentes combinações lineares.

A restrição de norma unitária é necessária porque a variância depende da escala do vetor de coeficientes. Para qualquer constante c ,

$$\text{Var}(c\alpha^\top \mathbf{X}_c) = c^2 \alpha^\top \Sigma \alpha.$$

Sem controlar a norma de α , a variância poderia ser aumentada apenas multiplicando os coeficientes por uma constante. A condição

$$\alpha^\top \alpha = 1$$

remove esse efeito de escala e transforma o problema em uma escolha de direção.

14.3 Primeira componente principal

A primeira componente principal é a combinação linear cujo vetor de coeficientes unitário maximiza a variância.

O problema é

$$\max_{\alpha_1 \in \mathbb{R}^p} \alpha_1^\top \Sigma \alpha_1,$$

sujeito a

$$\alpha_1^\top \alpha_1 = 1.$$

O Teorema 5.3 caracteriza os extremos do quociente definido na Definição 5.5. Aplicando esse resultado à matriz simétrica e semidefinida positiva Σ , o máximo é igual ao maior autovalor da matriz de covariâncias.

A variação do quociente de Rayleigh segundo a direção foi ilustrada na Figura 5.3. Na ACP, a matriz utilizada naquele problema passa a ser Σ , e o máximo do quociente corresponde à maior variância possível de uma combinação linear com coeficientes de norma unitária.

Se os autovalores de Σ forem ordenados como

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0,$$

e α_1 for um autovetor unitário associado a λ_1 , então

$$\Sigma \alpha_1 = \lambda_1 \alpha_1.$$

A primeira componente principal é

$$Y_1 = \alpha_1^\top \mathbf{X}_c,$$

e sua variância é

$$\begin{aligned}\text{Var}(Y_1) &= \alpha_1^\top \Sigma \alpha_1 \\ &= \alpha_1^\top \lambda_1 \alpha_1 \\ &= \lambda_1 \alpha_1^\top \alpha_1.\end{aligned}$$

Portanto, como $\alpha_1^\top \alpha_1 = 1$, temos

$$\text{Var}(Y_1) = \lambda_1.$$

O maior autovalor possui uma interpretação estatística direta: ele é a maior variância que pode ser obtida por uma combinação linear das variáveis com vetor de coeficientes de norma unitária.

O autovetor correspondente define a direção em que essa variância é alcançada. A projeção de $\mathbf{X}_c$ nessa direção define a primeira componente principal.

A Seção 13.5.3 relaciona critérios de otimização e soluções espectrais. O Teorema 5.4 estabelece a relação entre a otimização de uma forma quadrática sob restrição de norma e os autovetores, a partir da condição geral do Teorema 7.6.

14.4 Componentes principais sucessivas

A primeira componente utiliza a direção unitária que maximiza a variância. As componentes seguintes são construídas sucessivamente, impondo ortogonalidade entre seus vetores de coeficientes.

A segunda componente principal é a combinação linear cujo vetor de coeficientes unitário é ortogonal a α_1 e maximiza a variância sob essa restrição:

$$\max_{\alpha_2 \in \mathbb{R}^p} \alpha_2^\top \Sigma \alpha_2,$$

sujeito a

$$\alpha_2^\top \alpha_2 = 1$$

e

$$\alpha_2^\top \alpha_1 = 0.$$

O mesmo princípio é aplicado sucessivamente. Para $j = 1, \dots, p$, a j -ésima direção principal resolve

$$\max_{\alpha_j \in \mathbb{R}^p} \alpha_j^\top \Sigma \alpha_j,$$

sujeito a

$$\alpha_j^\top \alpha_j = 1$$

e

$$\alpha_j^\top \alpha_\ell = 0, \quad \ell = 1, \dots, j-1.$$

A caracterização variacional de direções sucessivas já foi estabelecida no Teorema 5.5. Aplicando esse resultado a Σ , obtém-se

$$\Sigma \alpha_j = \lambda_j \alpha_j, \quad j = 1, \dots, p.$$

Assim, pode-se escolher uma base ortonormal de autovetores da matriz de covariâncias, ordenada de acordo com os autovalores decrescentes, para definir as direções principais. Quando um autovalor possui multiplicidade maior que um, os autovetores individuais dentro do autoespaço correspondente não são únicos; essa não unicidade é desenvolvida na Seção 14.13.4.3.

A j -ésima componente principal é

$$Y_j = \alpha_j^\top \mathbf{X}_c$$

e possui variância

$$\text{Var}(Y_j) = \lambda_j.$$

Para $j \neq \ell$,

$$\begin{aligned} \text{Cov}(Y_j, Y_\ell) &= \alpha_j^\top \Sigma \alpha_\ell \\ &= \lambda_\ell \alpha_j^\top \alpha_\ell \\ &= 0. \end{aligned}$$

Logo, as componentes principais são não correlacionadas:

$$\text{Cov}(Y_j, Y_\ell) = 0, \quad j \neq \ell.$$

Duas propriedades diferentes aparecem nessa construção. Os vetores de coeficientes são ortogonais,

$$\alpha_j^\top \alpha_\ell = 0,$$

enquanto as componentes principais são não correlacionadas,

$$\text{Cov}(Y_j, Y_\ell) = 0.$$

A primeira propriedade pertence à geometria dos vetores de coeficientes. A segunda pertence à estrutura probabilística das variáveis construídas. Na ACP, a equação de autovetores

$$\Sigma \alpha_\ell = \lambda_\ell \alpha_\ell$$

faz a ligação entre essas duas propriedades.

A ausência de correlação não implica independência em uma distribuição geral. Se $\mathbf{X}$ possui distribuição normal multivariada, qualquer transformação linear também é normal, conforme a Proposição 9.4. Nesse caso, o vetor das componentes principais é normal multivariado e possui matriz de covariâncias diagonal. Pela Proposição 9.6, as componentes principais são independentes.

A normalidade, portanto, acrescenta uma propriedade probabilística às componentes, mas não participa da definição da ACP.

14.5 Formulação espectral

Reunindo os vetores de coeficientes em

$$\mathbf{A} = (\alpha_1 \quad \alpha_2 \quad \cdots \quad \alpha_p),$$

tem-se

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_p.$$

A matriz $\mathbf{A}$ é ortogonal. Pelo Teorema 5.2,

$$\Sigma = \mathbf{A}\Lambda\mathbf{A}^\top,$$

em que

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p).$$

As componentes podem ser reunidas no vetor aleatório

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_p \end{pmatrix} = \mathbf{A}^\top \mathbf{X}_c.$$

Como

$$E(\mathbf{X}_c) = \mathbf{0},$$

tem-se

$$E(\mathbf{Y}) = \mathbf{0}.$$

Pela regra de transformação da matriz de covariâncias estabelecida na Equação 8.18,

$$\text{Cov}(\mathbf{A}^\top \mathbf{X}_c) = \mathbf{A}^\top \Sigma \mathbf{A}.$$

Substituindo a decomposição espectral,

$$\begin{aligned} \text{Cov}(\mathbf{Y}) &= \mathbf{A}^\top \mathbf{A} \Lambda \mathbf{A}^\top \mathbf{A} \\ &= \Lambda. \end{aligned}$$

Portanto,

$$\text{Cov}(\mathbf{Y}) = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_p \end{pmatrix}.$$

A transformação para componentes principais diagonaliza a estrutura de covariâncias. As variáveis originais podem apresentar covariâncias diferentes de zero; no novo sistema de coordenadas, as componentes são não correlacionadas e suas variâncias aparecem na diagonal de Λ .

A transformação completa

$$\mathbf{X}_c \mapsto \mathbf{Y} = \mathbf{A}^\top \mathbf{X}_c$$

não reduz a dimensão. Ela representa o mesmo vetor em uma base ortonormal diferente. Pela propriedade de preservação geométrica das transformações ortogonais estabelecida na Proposição 4.9, produtos internos, normas e distâncias são preservados quando todas as p componentes são mantidas.

A redução ocorre somente quando a transformação é seguida pela retenção das primeiras $k < p$ coordenadas.

14.6 Variância total e proporção de variância

A variância total foi definida na Definição 8.6 por

$$V_T = \text{tr}(\Sigma).$$

Pela relação entre traço e autovalores estabelecida na Proposição 5.4,

$$\text{tr}(\Sigma) = \sum_{j=1}^p \lambda_j.$$

Além disso,

$$\text{Cov}(\mathbf{Y}) = \Lambda,$$

de modo que

$$\text{tr}[\text{Cov}(\mathbf{Y})] = \sum_{j=1}^p \lambda_j.$$

Assim,

$$\sum_{j=1}^p \text{Var}(Y_j) = \text{tr}(\Sigma).$$

A transformação completa para componentes principais preserva a variância total das variáveis originais. Como as componentes são ordenadas por autovalores decrescentes, as maiores parcelas dessa variância correspondem às primeiras componentes.

Se

$$\text{tr}(\Sigma) > 0,$$

a proporção da variância total associada à componente j é

$$\pi_j = \frac{\lambda_j}{\sum_{\ell=1}^p \lambda_\ell}.$$

Para as primeiras k componentes, a proporção acumulada é

$$\Pi_k = \frac{\sum_{j=1}^k \lambda_j}{\sum_{\ell=1}^p \lambda_\ell}.$$

A variabilidade representada pelas primeiras k direções é

$$\sum_{j=1}^k \lambda_j,$$

enquanto a variabilidade associada às direções descartadas é

$$\sum_{j=k+1}^p \lambda_j.$$

A decomposição pode ser resumida pela Tabela 14.1.

Tabela 14.1: Relação entre componentes principais, direções, autovalores e variância representada, quando a variância total é positiva.

Componente	Direção	Variância	Proporção da variância total
Y_1	α_1	λ_1	$\lambda_1 / \sum_{\ell=1}^p \lambda_\ell$
Y_2	α_2	λ_2	$\lambda_2 / \sum_{\ell=1}^p \lambda_\ell$
$\vdots$	$\vdots$	$\vdots$	$\vdots$
Y_p	α_p	λ_p	$\lambda_p / \sum_{\ell=1}^p \lambda_\ell$

Exemplo 14.1 (Componentes principais de duas variáveis). Considere um vetor aleatório

$$\mathbf{X} = \begin{pmatrix} X_1 \\ X_2 \end{pmatrix}$$

com matriz de covariâncias

$$\Sigma = \begin{pmatrix} 4 & 2 \\ 2 & 4 \end{pmatrix}.$$

A decomposição espectral fornece os autovalores

$$\lambda_1 = 6 \quad \text{e} \quad \lambda_2 = 2,$$

com autovetores unitários

$$\alpha_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

e

$$\alpha_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}.$$

A primeira componente principal é

$$Y_1 = \frac{(X_1 - \mu_1) + (X_2 - \mu_2)}{\sqrt{2}},$$

com

$$\text{Var}(Y_1) = 6.$$

A segunda componente é

$$Y_2 = \frac{(X_1 - \mu_1) - (X_2 - \mu_2)}{\sqrt{2}},$$

com

$$\text{Var}(Y_2) = 2$$

e

$$\text{Cov}(Y_1, Y_2) = 0.$$

A variância total é

$$\text{tr}(\Sigma) = 4 + 4 = 8,$$

que coincide com

$$\lambda_1 + \lambda_2 = 6 + 2 = 8.$$

A primeira componente representa $\frac{6}{8} = 75\%$ da variabilidade total, enquanto a segunda representa $\frac{2}{8} = 25\%$.

Se a representação for reduzida de duas para uma dimensão, a direção α_1 preserva 75% da variabilidade e descarta 25%. Nesse exemplo, a redução de dimensão possui interpretação direta: a maior parte da dispersão ocorre na direção em que as duas variáveis se deslocam conjuntamente.

A Figura 14.2 mostra, em um exemplo didático, duas leituras complementares dos autovalores. O primeiro painel apresenta a variância associada individualmente a cada componente. O segundo apresenta a proporção acumulada da variância representada pelas primeiras componentes.

A concentração da variância nos primeiros autovalores determina quanto da variabilidade total pode ser preservado com poucas componentes. Quando Π_k está próximo de 1 para um valor pequeno de k , as primeiras k componentes preservam grande parcela da variância total. A proporção acumulada, entretanto, não determina sozinha quantas componentes devem ser mantidas. Outros critérios utilizados nessa decisão são apresentados na Seção 14.14.2, incluindo uma regra heurística específica para a ACP baseada na matriz de correlações.

14.7 Subespaço principal, projeção e reconstrução

Até aqui, cada componente principal foi associada a uma direção que maximiza a variância sob as restrições correspondentes. Quando apenas $k < p$ componentes são mantidas, as direções associadas podem ser consideradas conjuntamente. Os vetores $\alpha_1, \dots, \alpha_k$ geram um **subespaço principal de dimensão k** , no qual as realizações podem ser representadas por suas primeiras k coordenadas principais.




Figura 14.2: Os autovalores quantificam a variância de cada componente, e sua soma acumulada determina a proporção da variabilidade representada pelas primeiras dimensões.

A redução dimensional pode ser interpretada geometricamente como a projeção de $\mathbf{X}_c$ sobre o subespaço principal. Para uma realização do vetor aleatório, essa projeção fornece uma representação utilizando apenas as primeiras k componentes principais.

Entre todos os subespaços lineares de dimensão k , o subespaço principal maximiza a variância total da projeção de $\mathbf{X}_c$. Essa variância corresponde à soma dos k maiores autovalores de Σ , enquanto a parcela não representada corresponde à soma dos autovalores associados às direções descartadas.

As primeiras k componentes também permitem construir, no espaço original, uma aproximação de cada realização de $\mathbf{X}_c$. Quando $k < p$, a aproximação difere da realização original por um resíduo ortogonal ao subespaço principal.

A variabilidade preservada e o erro de reconstrução descrevem a mesma escolha de subespaço sob perspectivas diferentes. O subespaço de dimensão k que preserva a maior variabilidade total é também aquele que minimiza o erro quadrático médio de reconstrução.

Quando existe separação entre o k -ésimo e o $(k+1)$ -ésimo autovalores, o subespaço principal de dimensão k é determinado de maneira única. Se houver empate nessa fronteira, diferentes subespaços podem preservar a mesma variabilidade máxima. A definição formal dessa estrutura e as condições de unicidade são apresentadas na Definição 14.2.

A formulação matricial da propriedade de máxima variabilidade é desenvolvida na Seção 14.13.1, enquanto a relação entre variabilidade preservada e erro quadrático de reconstrução é formalizada na Seção 14.13.2.

14.8 Formulação amostral

A formulação populacional define as componentes em termos de Σ , que geralmente é desconhecida. A aplicação da técnica utiliza uma amostra para estimar suas direções e variâncias.

Considere uma realização amostral com $n \geq 2$ observações, organizada na matriz

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

com média observada $\bar{\mathbf{x}}$ e matriz centralizada

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top.$$

A matriz de covariâncias observada foi definida na Definição 8.10 como

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c.$$

A versão amostral da ACP substitui a matriz populacional Σ por $\mathbf{S}$.

Considere a decomposição espectral

$$\mathbf{S} = \widehat{\mathbf{A}} \widehat{\Lambda} \widehat{\mathbf{A}}^\top,$$

em que

$$\widehat{\Lambda} = \text{diag}(\hat{\lambda}_1, \dots, \hat{\lambda}_p),$$

com

$$\hat{\lambda}_1 \geq \dots \geq \hat{\lambda}_p \geq 0,$$

e

$$\widehat{\mathbf{A}} = (\hat{\alpha}_1 \quad \dots \quad \hat{\alpha}_p).$$

A Tabela 14.2 sintetiza a distinção entre os principais objetos populacionais e amostrais da ACP.

Tabela 14.2: Correspondência entre objetos populacionais e amostrais na ACP.

Objeto	População	Amostra observada
Matriz de covariâncias	Σ	$\mathbf{S}$
Direção principal j	α_j	$\hat{\alpha}_j$
Variância da componente j	λ_j	$\hat{\lambda}_j$
Componente principal	$Y_j = \alpha_j^\top (\mathbf{X} - \mu)$	construída a partir da direção estimada $\hat{\alpha}_j$
Coordenada da observação i na componente j	$y_{ij} = \alpha_j^\top (\mathbf{x}_i - \mu)$	escore $\hat{y}_{ij} = \hat{\alpha}_j^\top (\mathbf{x}_i - \bar{\mathbf{x}})$

A direção $\hat{\alpha}_j$ é obtida a partir da amostra. Quando o autovalor populacional correspondente é simples, o autoespaço associado é unidimensional e a direção principal é determinada até mudança de sinal; nesse sentido, a direção amostral pode ser utilizada para estimar a direção populacional. Quando há multiplicidade, os autovetores individuais não são determinados de forma única, e o objeto de interesse passa a ser o autoespaço correspondente (Anderson, 2003). A distinção entre as formulações amostral e populacional é discutida na Seção 14.11.

Os escores amostrais das observações são definidos a partir das direções principais estimadas.

Definição 14.1 (Escore de uma componente principal). Considere a observação

$$\mathbf{x}_i \in \mathbb{R}^p,$$

sua versão centralizada

$$\mathbf{x}_i - \bar{\mathbf{x}},$$

e uma direção principal amostral unitária

$$\hat{\alpha}_j \in \mathbb{R}^p.$$

O **escore amostral da observação i na componente principal j** é sua coordenada na direção principal estimada:

$$\hat{y}_{ij} = \hat{\alpha}_j^\top (\mathbf{x}_i - \bar{\mathbf{x}}).$$

Para as primeiras k componentes, considere

$$\widehat{\mathbf{A}}_k = (\hat{\alpha}_1 \quad \dots \quad \hat{\alpha}_k).$$

Os escores das n observações nas k primeiras componentes podem ser organizados na matriz

$$\widehat{\mathbf{Y}}_k = \mathbf{X}_c \widehat{\mathbf{A}}_k \in \mathbb{R}^{n \times k}.$$

O elemento $\hat{y}_{ij}$ de $\widehat{\mathbf{Y}}_k$ é o escore da observação i na componente j . Assim, $\widehat{\mathbf{Y}}_k$ reúne as coordenadas das observações nas primeiras k direções principais.

Para uma observação específica i , suas coordenadas nas primeiras k componentes podem ser reunidas no vetor

$$\hat{\mathbf{y}}_{i,k} = \widehat{\mathbf{A}}_k^\top (\mathbf{x}_i - \bar{\mathbf{x}}) = \begin{pmatrix} \hat{y}_{i1} \\ \vdots \\ \hat{y}_{ik} \end{pmatrix}.$$

Os elementos de $\hat{\alpha}_j$ são os **coeficientes da componente principal**, enquanto $\hat{y}_{ij}$ é o **escore amostral** da observação i nessa componente. Os coeficientes definem as direções principais e os escores fornecem as coordenadas das observações nessas direções.

A matriz centralizada reconstruída a partir das primeiras k componentes pode ser escrita como

$$\widetilde{\mathbf{X}}_{c,k} = \widehat{\mathbf{Y}}_k \widehat{\mathbf{A}}_k^\top.$$

Como

$$\widehat{\mathbf{Y}}_k = \mathbf{X}_c \widehat{\mathbf{A}}_k,$$

segue que

$$\widetilde{\mathbf{X}}_{c,k} = \mathbf{X}_c \widehat{\mathbf{A}}_k \widehat{\mathbf{A}}_k^\top.$$

Assim, a reconstrução amostral também é uma projeção ortogonal sobre o subespaço principal estimado.

Para retornar às unidades e à localização originais, adiciona-se novamente o vetor de médias:

$$\widetilde{\mathbf{X}}_k = \widetilde{\mathbf{X}}_{c,k} + \mathbf{1}_n \bar{\mathbf{x}}^\top.$$

A centralização remove a localização antes da determinação das direções principais; a reconstrução final restitui essa localização.

14.9 Formulação da ACP pela SVD

A formulação amostral pode ser obtida diretamente da matriz centralizada sem formar previamente $\mathbf{S}$.

Se

$$r = \text{posto}(\mathbf{X}_c) > 0,$$

considere a SVD compacta definida na Definição 6.4:

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

em que

$$\mathbf{U}_r \in \mathbb{R}^{n \times r}, \quad \mathbf{D}_r \in \mathbb{R}^{r \times r}, \quad \mathbf{V}_r \in \mathbb{R}^{p \times r}.$$

Os valores singulares são ordenados como

$$d_1 \geq d_2 \geq \dots \geq d_r > 0.$$

Como

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c,$$

a Proposição 6.13 relaciona a SVD da matriz centralizada à decomposição espectral da matriz de covariâncias:

$$\mathbf{S} = \mathbf{V}_r \frac{\mathbf{D}_r^2}{n-1} \mathbf{V}_r^\top.$$

Portanto, denotando por $\mathbf{v}_j$ a j -ésima coluna de $\mathbf{V}_r$, para $j = 1, \dots, r$, cada $\mathbf{v}_j$ é um autovetor de $\mathbf{S}$ associado a $\hat{\lambda}_j$ e pode ser escolhido como a direção principal amostral correspondente:

$$\hat{\alpha}_j = \mathbf{v}_j.$$

Como $\mathbf{v}_j$ e $-\mathbf{v}_j$ determinam a mesma direção, a mudança de sinal não altera o eixo principal; ela apenas inverte o sinal dos escores da componente correspondente.

Assim,

$$\hat{\lambda}_j = \frac{d_j^2}{n-1}, \quad j = 1, \dots, r.$$

Os vetores singulares à direita da matriz centralizada são as direções principais amostrais associadas à variabilidade positiva. O quadrado de cada valor singular, dividido por $n-1$, é a variância observada da componente correspondente.

Se

$$r < p,$$

as $p-r$ componentes restantes possuem autovalor zero e, portanto, variância amostral nula. A SVD compacta não inclui uma base para esse complemento nulo, pois retém apenas os vetores singulares associados a valores singulares positivos.

A interpretação geométrica da SVD foi apresentada na Figura 6.1. Na ACP amostral, a matriz decomposta é $\mathbf{X}_c$. Os vetores singulares à direita, em $\mathbb{R}^p$, fornecem as direções principais no espaço em que as observações são representadas, enquanto $\mathbf{U}_r \mathbf{D}_r$ reúne os escores das observações nessas direções.

Essa relação mostra que a decomposição espectral de $\mathbf{S}$ e a SVD de $\mathbf{X}_c$ não constituem duas técnicas diferentes. Para as componentes de variância positiva, elas fornecem duas formas de obter a mesma solução amostral da ACP.

Os escores também são obtidos diretamente pela SVD:

$$\widehat{\mathbf{Y}}_r = \mathbf{X}_c \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r.$$

Assim, a SVD reúne os elementos da solução amostral:

- $\mathbf{V}_r$ contém as r direções principais em $\mathbb{R}^p$ associadas a variância amostral positiva;
- $\widehat{\mathbf{Y}}_r = \mathbf{U}_r \mathbf{D}_r$ contém os escores amostrais das observações;
- $\mathbf{D}_r$ contém os valores singulares d_j , relacionados às variâncias das componentes por $\hat{\lambda}_j = d_j^2/(n-1)$.

A centralização também limita o número de componentes com variância positiva. Pela Equação 8.60,

$$\text{posto}(\mathbf{S}) = \text{posto}(\mathbf{X}_c) \leq \min(p, n - 1).$$

Portanto, existem no máximo

$$\min(p, n - 1)$$

componentes principais com variância amostral positiva.

Em particular, quando $p \geq n$, a matriz $\mathbf{S}$ é necessariamente singular. Essa singularidade amostral não implica que a matriz populacional Σ seja singular, pois a centralização impõe $\text{posto}(\mathbf{X}_c) \leq n - 1 < p$.

14.10 ACP baseada na matriz de correlações

A formulação anterior utiliza a matriz de covariâncias. Quando as variáveis possuem escalas ou unidades de medida diferentes, pode ser definido outro problema: realizar a ACP após padronizar cada variável para variância unitária (Johnson; Wichern, 2002).

A matriz de correlações populacional $\mathcal{R}$ foi definida na Definição 8.5, sob a condição de que todas as variâncias marginais populacionais sejam positivas, e sua correspondente observada $\mathbf{R}$ foi definida na Definição 8.11, sob a condição de que

$$s_{jj} > 0, \quad j = 1, \dots, p.$$

No nível observado, defina

$$\mathbf{D}_S = \text{diag}(s_{11}, \dots, s_{pp}).$$

Como

$$s_{jj} > 0, \quad j = 1, \dots, p,$$

a matriz $\mathbf{D}_S$ é positiva definida e $\mathbf{D}_S^{-1/2}$ existe. Assim,

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}.$$

A Equação 8.67 relaciona a matriz de correlações às colunas centralizadas e padronizadas. Para manter essa notação distinta da matriz de delineamento $\mathbf{Z}$ utilizada na Definição 11.3, neste capítulo denotaremos a matriz padronizada por

$$\mathbf{X}_{\text{pad}} = \mathbf{X}_c \mathbf{D}_S^{-1/2}.$$

Assim,

$$\mathbf{R} = \frac{1}{n-1} \mathbf{X}_{\text{pad}}^\top \mathbf{X}_{\text{pad}}.$$

Realizar a ACP de $\mathbf{R}$ equivale, portanto, a realizar a ACP sobre as colunas centralizadas e padronizadas de $\mathbf{X}$.

Se

$$\mathbf{R} = \widehat{\mathbf{A}}_R \widehat{\Lambda}_R \widehat{\mathbf{A}}_R^\top,$$

as direções principais observadas são os autovetores de $\mathbf{R}$, definidos nas coordenadas padronizadas. Os autovalores

$$\hat{\lambda}_{R1}, \dots, \hat{\lambda}_{Rp}$$

representam as variâncias observadas das componentes construídas a partir dessas variáveis.

Como a diagonal de $\mathbf{R}$ é formada por valores iguais a 1,

$$\text{tr}(\mathbf{R}) = p.$$

Logo,

$$\sum_{j=1}^p \hat{\lambda}_{Rj} = p.$$

A proporção da variância padronizada representada pela componente j é

$$\frac{\hat{\lambda}_{Rj}}{p},$$

e a proporção acumulada nas primeiras k componentes é

$$\frac{\sum_{j=1}^k \hat{\lambda}_{Rj}}{p}.$$

A utilização de **S** ou **R** corresponde a **duas formulações diferentes da ACP**.

Na ACP baseada em **S**, o critério de máxima variância é avaliado nas escalas originais. As variâncias marginais s_{jj} entram no problema espectral com suas magnitudes observadas.

Na ACP baseada em **R**, cada variável é previamente padronizada para variância unitária. O problema espectral passa, portanto, a representar a variabilidade das variáveis padronizadas.

A Tabela 14.3 resume essa distinção.

Tabela 14.3: Diferenças entre a ACP baseada em covariâncias e em correlações.

Aspecto	ACP por covariâncias	ACP por correlações
Matriz de entrada	S	R
Dados equivalentes	Centralizados	Centralizados e padronizados
Variâncias marginais	Mantidas nas unidades originais	Iguais a 1
Variância total	$\text{tr}(\mathbf{S})$	p
Influência da escala	Preservada	Removida pela padronização
Problema resolvido	Representar a variabilidade nas escalas originais	Representar a variabilidade após igualar as escalas marginais

A Figura 14.3 ilustra o efeito da padronização. Os dois painéis representam as mesmas observações, antes e depois da padronização marginal. A mudança das escalas altera a geometria e, conseqüentemente, as direções principais.

A seta vermelha representa a primeira direção principal em cada geometria. A padronização remove as diferenças de escala marginal entre as variáveis e, nesse exemplo, modifica a direção que maximiza a variância.

A escolha entre **S** e **R** determina se o critério de máxima variância é aplicado às variáveis em suas escalas originais ou após a padronização e, portanto, qual estrutura de variabilidade será representada pela ACP.

A padronização modifica a geometria da nuvem de dados por meio de um escalonamento diferente em cada eixo. Conseqüentemente, os autovetores, os autovalores, os escores e o subespaço principal podem mudar.

No Capítulo 15, a Análise Fatorial também pode ser formulada sobre uma matriz de covariâncias ou de correlações, mas seu objetivo é diferente: em vez de decompor a variabilidade




Figura 14.3: A ACP baseada em covariâncias preserva as escalas originais, enquanto a ACP baseada em correlações utiliza a geometria das variáveis padronizadas.

total em direções principais, especifica um modelo para a estrutura de covariação entre as variáveis.

14.11 Formulação descritiva, populacional e inferencial

A ACP pode ser formulada sem hipótese de normalidade. Na formulação populacional baseada em covariâncias, basta que $\mathbf{X}$ possua momentos de segunda ordem finitos para que a matriz de covariâncias Σ e suas componentes principais estejam definidas. Na formulação baseada em correlações, exige-se adicionalmente que as variâncias marginais sejam positivas, conforme a Definição 8.5.

Na formulação **descritiva**, a matriz de dados observada é o objeto de interesse, e autovalores, direções e escores descrevem sua estrutura de variabilidade.

Na formulação **populacional**, os autovalores

$$\lambda_j$$

e os autovetores unitários

$$\alpha_j$$

são características da matriz populacional Σ . Na formulação amostral, os autovalores e autovetores de $\mathbf{S}$ são denotados por

$$\hat{\lambda}_j \quad \text{e} \quad \hat{\alpha}_j.$$

Na ACP baseada em correlações, a distinção é análoga: os objetos populacionais são determinados pela matriz $\mathcal{R}$, enquanto os correspondentes observados são obtidos de $\mathbf{R}$.

Sob as condições de consistência da matriz de covariâncias amostral estabelecidas na Proposição 10.9, os autovalores, direções e subespaços amostrais podem estimar seus correspondentes populacionais, respeitadas as condições de identificação. Quando um autovalor populacional é simples, a direção principal correspondente é determinada até mudança de sinal; quando há multiplicidade, os autovetores individuais deixam de ser únicos e o objeto identificado é o autoespaço correspondente, como discutido na Seção 14.13.4.3.

A normalidade multivariada não é necessária para a formulação da ACP. Quando

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

a transformação ortogonal para as componentes produz

$$\mathbf{Y} = \mathbf{A}^\top (\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \Lambda).$$

Nesse caso, as componentes são independentes. Sem normalidade conjunta, a ACP garante que componentes distintas sejam não correlacionadas, mas não necessariamente independentes.

A inferência sobre autovalores, autovetores e subespaços requer hipóteses adicionais e teoria distribucional ou assintótica específica. Esses resultados não são necessários para a formulação da ACP e são retomados na Seção 14.13.5.

14.12 Limites da representação por componentes principais

A ACP resolve um problema definido de forma precisa: encontrar combinações lineares e subespaços que preservem variabilidade segundo uma matriz de covariâncias ou correlações. Os limites da técnica decorrem diretamente dessa formulação e são sintetizados na Tabela 14.4.

Tabela 14.4: Limites decorrentes da formulação clássica da Análise de Componentes Principais.

Aspecto	Consequência para a ACP
Critério de importância	As componentes são ordenadas pela variância. Uma componente de pequena variância pode ser relevante para outro objetivo estatístico.
Estrutura representada	A redução é realizada por projeção em subespaços lineares determinados pela matriz de covariâncias ou de correlações. Quando a variabilidade não se concentra próxima de um subespaço linear de baixa dimensão, muitas componentes podem ser necessárias para representá-la.
Conjunto de variáveis	Inclusão, exclusão, transformação ou mudança de escala altera a matriz analisada e pode modificar toda a solução.
Sensibilidade da matriz de entrada	Valores extremos podem alterar variâncias, covariâncias, correlações e, consequentemente, autovalores e autovetores.
Redução de dimensão	Quando são descartadas direções com autovalores positivos, parte da variabilidade original deixa de ser representada.

Quando são retidas menos dimensões do que o posto da matriz analisada, pelo menos uma direção associada a um autovalor positivo é descartada. Pela Proposição 14.2, a variabilidade não representada corresponde à soma dos autovalores associados às direções excluídas. Toda a variabilidade é preservada apenas quando os autovalores das direções descartadas são nulos.

14.13 Aprofundamentos teóricos

Leitura de aprofundamento

Esta parte reúne desenvolvimentos sobre o subespaço principal, a reconstrução por projeção, a aproximação de posto reduzido, as propriedades da solução e a estimação e inferência das componentes sob normalidade.

14.13.1 Formulação do subespaço principal e variabilidade máxima

Considere uma base ortonormal de autovetores de Σ ,

$$\alpha_1, \dots, \alpha_p,$$

ordenada de modo que

$$\lambda_1 \geq \dots \geq \lambda_p.$$

Defina

$$\mathbf{A}_k = (\alpha_1 \quad \dots \quad \alpha_k) \in \mathbb{R}^{p \times k}.$$

Como esses vetores são ortonormais,

$$\mathbf{A}_k^\top \mathbf{A}_k = \mathbf{I}_k.$$

Suas colunas geram o subespaço associado às primeiras k direções dessa base.

Definição 14.2 (Subespaço principal). Seja

$$\Sigma \in \mathbb{R}^{p \times p}$$

uma matriz de covariâncias, com autovalores ordenados como

$$\lambda_1 \geq \dots \geq \lambda_p \geq 0,$$

e seja

$$\alpha_1, \dots, \alpha_p$$

uma base ortonormal de autovetores correspondente a essa ordenação.

Para $1 \leq k \leq p$, um **subespaço principal de dimensão k** é

$$\mathcal{S}_k = \text{span} \{ \alpha_1, \dots, \alpha_k \}.$$

Se $k < p$ e

$$\lambda_k > \lambda_{k+1},$$

o subespaço principal de dimensão k é único.

Se $\lambda_k = \lambda_{k+1}$, existem diferentes subespaços principais de dimensão k que atingem a mesma variância total máxima da projeção.

A matriz de projeção ortogonal sobre um subespaço principal $\mathcal{S}_k$ é

$$\mathbf{P}_k = \mathbf{A}_k \mathbf{A}_k^\top.$$

Essa expressão é uma aplicação direta da projeção sobre um subespaço com base ortonormal desenvolvida na Proposição 3.14.

As coordenadas de $\mathbf{X}_c$ nesse subespaço são

$$\mathbf{Y}_k = \mathbf{A}_k^\top \mathbf{X}_c = \begin{pmatrix} Y_1 \\ \vdots \\ Y_k \end{pmatrix}.$$

Sua matriz de covariâncias é

$$\begin{aligned} \text{Cov}(\mathbf{Y}_k) &= \mathbf{A}_k^\top \Sigma \mathbf{A}_k \\ &= \text{diag}(\lambda_1, \dots, \lambda_k). \end{aligned}$$

Portanto, a variância total das coordenadas mantidas é

$$\text{tr}[\text{Cov}(\mathbf{Y}_k)] = \sum_{j=1}^k \lambda_j.$$

A soma $\sum_{j=1}^k \lambda_j$ é a variância total das primeiras k componentes. As direções $\alpha_1, \dots, \alpha_k$ geram o subespaço principal associado a essas componentes.

Considere qualquer matriz

$$\mathbf{Q} = (\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_k) \in \mathbb{R}^{p \times k},$$

com colunas ortonormais,

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k.$$

A projeção de $\mathbf{X}_c$ sobre o subespaço gerado por $\mathbf{Q}$ possui coordenadas

$$\mathbf{Q}^\top \mathbf{x}_c$$

e variância total

$$\text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}) = \sum_{j=1}^k \mathbf{q}_j^\top \Sigma \mathbf{q}_j.$$

A expressão $\text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q})$ permite comparar a variância total das projeções em diferentes subespaços de dimensão k .

Proposição 14.1 (Variabilidade máxima do subespaço principal). *Seja*

$$\Sigma \in \mathbb{R}^{p \times p}$$

uma matriz de covariâncias com autovalores

$$\lambda_1 \geq \dots \geq \lambda_p \geq 0.$$

Para $1 \leq k \leq p$ e qualquer matriz

$$\mathbf{Q} \in \mathbb{R}^{p \times k}$$

com colunas ortonormais,

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k,$$

tem-se

$$\text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}) \leq \sum_{j=1}^k \lambda_j.$$


Portanto, a maior variância total que pode ser preservada por uma projeção ortogonal em um subespaço de dimensão k é

$$\sum_{j=1}^k \lambda_j.$$

Esse máximo é atingido por qualquer subespaço principal $\mathcal{S}_k$ definido na Definição [14.2](#).

Se $k < p$ e $\lambda_k > \lambda_{k+1}$, o subespaço que maximiza a variância é único.

Se $\lambda_k = \lambda_{k+1}$, o subespaço maximizador pode não ser único.



i Demonstração

Pelo Teorema 5.2,

$$\Sigma = \mathbf{A}\mathbf{A}\mathbf{A}^\top.$$

Defina

$$\mathbf{B} = \mathbf{A}^\top \mathbf{Q}.$$

Como $\mathbf{A}$ é ortogonal e

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k,$$

tem-se

$$\mathbf{B}^\top \mathbf{B} = \mathbf{I}_k.$$

Se $b_{i\ell}$ denota o elemento da linha i e da coluna ℓ de $\mathbf{B}$, defina

$$w_i = \sum_{\ell=1}^k b_{i\ell}^2.$$

Então,

$$\begin{aligned} \text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}) &= \text{tr}(\mathbf{B}^\top \Lambda \mathbf{B}) \\ &= \sum_{i=1}^p \lambda_i w_i. \end{aligned}$$

Como

$$\mathbf{B}\mathbf{B}^\top$$

é um projetor ortogonal, seus elementos diagonais satisfazem

$$0 \leq w_i \leq 1.$$

Além disso,

14.13.2 Reconstrução e erro quadrático

As primeiras k componentes fornecem as coordenadas de $\mathbf{X}_c$ no subespaço principal. A projeção no espaço original é obtida por

$$\tilde{\mathbf{X}}_{c,k} = \mathbf{A}_k \mathbf{Y}_k.$$

Como

$$\mathbf{Y}_k = \mathbf{A}_k^\top \mathbf{X}_c,$$

segue que

$$\tilde{\mathbf{X}}_{c,k} = \mathbf{A}_k \mathbf{A}_k^\top \mathbf{X}_c = \mathbf{P}_k \mathbf{X}_c.$$

O vetor $\tilde{\mathbf{X}}_{c,k}$ é a representação de $\mathbf{X}_c$ obtida utilizando apenas as primeiras k direções principais.

A parcela não representada é

$$\mathbf{E}_k = \mathbf{X}_c - \tilde{\mathbf{X}}_{c,k} = (\mathbf{I}_p - \mathbf{P}_k) \mathbf{X}_c.$$

A matriz de projeção residual foi definida na Definição 3.20, e a ortogonalidade entre a projeção e o resíduo decorre da Proposição 3.17. Portanto,

$$\|\mathbf{X}_c\|^2 = \|\tilde{\mathbf{X}}_{c,k}\|^2 + \|\mathbf{E}_k\|^2.$$

Tomando esperanças, a variabilidade total também se decompõe em parcela representada e parcela não representada:

$$E(\|\mathbf{X}_c\|^2) = E(\|\tilde{\mathbf{X}}_{c,k}\|^2) + E(\|\mathbf{E}_k\|^2).$$

A primeira parcela é

$$E(\|\tilde{\mathbf{X}}_{c,k}\|^2) = \sum_{j=1}^k \lambda_j,$$

enquanto, pela definição de variância total na Definição 8.6,

$$E \left(\|\mathbf{X}_c\|^2 \right) = \text{tr} (\Sigma) = \sum_{j=1}^p \lambda_j.$$

Consequentemente,

$$E \left(\|\mathbf{E}_k\|^2 \right) = \sum_{j=k+1}^p \lambda_j.$$

A variabilidade descartada pela redução de dimensão corresponde exatamente à soma dos autovalores associados às direções excluídas.

Proposição 14.2 (Variância preservada e erro de reconstrução). *Seja*

$$\mathbf{X} \in \mathbb{R}^p$$

um vetor aleatório com segundos momentos finitos, vetor de médias μ e matriz de covariâncias Σ . Defina

$$\mathbf{X}_c = \mathbf{X} - \mu.$$

Para $1 \leq k \leq p$, considere uma matriz

$$\mathbf{Q} \in \mathbb{R}^{p \times k}$$

com colunas ortonormais,

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k,$$

e a projeção ortogonal

$$\tilde{\mathbf{X}}_{c,\mathbf{Q}} = \mathbf{Q}\mathbf{Q}^\top \mathbf{X}_c.$$

O erro quadrático médio de reconstrução é

$$E \left[\left\| \mathbf{X}_c - \tilde{\mathbf{X}}_{c,\mathbf{Q}} \right\|^2 \right] = \text{tr}(\Sigma) - \text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}).$$

Consequentemente, maximizar a variância preservada,

$$\text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}),$$

equivale a minimizar o erro quadrático médio de reconstrução.

Para um subespaço principal de dimensão k ,

$$\text{variância preservada} = \sum_{j=1}^k \lambda_j$$

e o erro mínimo é

$$\min_{\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k} E \left[\|\mathbf{x}_c - \mathbf{Q} \mathbf{Q}^\top \mathbf{x}_c\|^2 \right] = \sum_{j=k+1}^p \lambda_j.$$

i Demonstração

Como $\mathbf{Q} \mathbf{Q}^\top$ é um projetor ortogonal,

$$\begin{aligned} E \left[\|\mathbf{x}_c - \mathbf{Q} \mathbf{Q}^\top \mathbf{x}_c\|^2 \right] &= \text{tr} \left[(\mathbf{I}_p - \mathbf{Q} \mathbf{Q}^\top) \Sigma \right] \\ &= \text{tr}(\Sigma) - \text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}). \end{aligned}$$

O primeiro termo é constante em relação a $\mathbf{Q}$. Portanto, minimizar o erro equivale a maximizar a variância preservada. Pela Proposição 14.1, o máximo é $\sum_{j=1}^k \lambda_j$ e, como $\text{tr}(\Sigma) = \sum_{j=1}^p \lambda_j$, o erro mínimo é

$$\sum_{j=k+1}^p \lambda_j.$$

A decomposição de um vetor em projeção e resíduo ortogonal foi apresentada na Figura 3.5. Na ACP, cada realização centralizada pode ser decomposta em sua projeção sobre um subespaço principal e em um resíduo ortogonal. Para $k = 1$, esse subespaço é a reta gerada pela primeira direção principal.

A Figura 14.4 representa a redução de duas para uma dimensão. Cada observação é projetada sobre a primeira direção principal. Os segmentos vermelhos representam os resíduos de reconstrução.

Os pontos azuis são as observações centralizadas, os pontos verdes são suas projeções sobre a primeira direção principal e os segmentos vermelhos representam os resíduos de reconstrução. Entre todas as retas que passam pela origem no espaço dos dados centralizados, a reta gerada pela primeira direção principal minimiza a soma dos quadrados das normas dos resíduos ortogonais. Essa mesma reta maximiza a variância dos pontos projetados.




Figura 14.4: A redução para uma componente substitui cada observação por sua projeção sobre a primeira direção principal; os segmentos ortogonais representam o erro de reconstrução.

14.13.3 Aproximação de posto reduzido

A SVD relaciona diretamente a redução de dimensionalidade ao problema de aproximação matricial.

Para

$$1 \leq k < r,$$

mantendo apenas os k primeiros termos da SVD,

$$\widetilde{\mathbf{X}}_{c,k} = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Pelo Teorema 6.2, $\widetilde{\mathbf{X}}_{c,k}$ é uma melhor aproximação de $\mathbf{X}_c$ entre todas as matrizes de posto não superior a k , segundo a norma de Frobenius.

Se

$$d_k > d_{k+1},$$

essa melhor aproximação é única. Quando

$$d_k = d_{k+1},$$

existem diferentes aproximações de posto não superior a k que atingem o mesmo erro mínimo.

Além disso, pela relação entre projeção e SVD estabelecida na Proposição 6.21,

$$\widetilde{\mathbf{X}}_{c,k} = \mathbf{X}_c \mathbf{V}_k \mathbf{V}_k^\top.$$

Como os escores associados às primeiras k direções são

$$\widehat{\mathbf{Y}}_k = \mathbf{X}_c \mathbf{V}_k,$$

também se obtém

$$\widetilde{\mathbf{X}}_{c,k} = \widehat{\mathbf{Y}}_k \mathbf{V}_k^\top.$$

Essas três expressões representam o mesmo objeto:

$$\mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top = \mathbf{X}_c \mathbf{V}_k \mathbf{V}_k^\top = \widehat{\mathbf{Y}}_k \mathbf{V}_k^\top.$$

A primeira expressão mostra a aproximação de posto reduzido; a segunda mostra a projeção sobre o subespaço principal; a terceira mostra a reconstrução a partir dos escores amostrais e das direções principais.

O erro quadrático total da aproximação é

$$\|\mathbf{X}_c - \widetilde{\mathbf{X}}_{c,k}\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

Como

$$d_j^2 = (n-1)\hat{\lambda}_j,$$

segue que

$$\|\mathbf{X}_c - \widetilde{\mathbf{X}}_{c,k}\|_F^2 = (n-1) \sum_{j=k+1}^r \hat{\lambda}_j.$$

A parcela da soma de quadrados preservada pela aproximação é

$$\frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2} = \frac{\sum_{j=1}^k \hat{\lambda}_j}{\sum_{j=1}^r \hat{\lambda}_j}.$$

Essa expressão coincide com a proporção de variância observada representada pelas primeiras k componentes.

A equivalência entre as formulações pode ser resumida pela Tabela 14.5.

Tabela 14.5: Formulações relacionadas da Análise de Componentes Principais.

Formulação	Objeto otimizado ou decomposto	Solução
Variância	$\alpha^\top \Sigma \alpha$ ou $\alpha^\top \mathbf{S} \alpha$	Autovetores associados aos maiores autovalores
Subespaço	Variância total da projeção em dimensão k	Subespaço gerado pelas primeiras k direções
Reconstrução	Erro quadrático da representação	Projeção sobre um subespaço principal

Formulação	Objeto otimizado ou decomposto	Solução
SVD	Matriz de dados centralizada $\mathbf{X}_c$	Vetores singulares à direita associados aos valores singulares positivos
Aproximação matricial	$\ \mathbf{X}_c - \mathbf{B}\ _F$ com $\text{posto}(\mathbf{B}) \leq k$	$\mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top$

As formulações da Tabela 14.5 descrevem a mesma solução sob três perspectivas relacionadas. Estatisticamente, a ACP maximiza a variância das combinações lineares sujeitas às restrições de normalização e ortogonalidade. Geometricamente, o subespaço principal maximiza a variância total da projeção e minimiza o erro quadrático de reconstrução (Johnson; Wichern, 2002). Matricialmente, a SVD truncada fornece a melhor aproximação de posto reduzido da matriz de dados centralizada, conforme o resultado geral desenvolvido a partir da SVD no Módulo 1 (Eaton, 2007). Na formulação amostral da ACP, essas perspectivas conduzem ao mesmo subespaço principal estimado.

14.13.4 Propriedades da solução

14.13.4.1 Invariância a translações

Para qualquer vetor constante $\mathbf{c} \in \mathbb{R}^p$,

$$\mathbf{X}^* = \mathbf{X} + \mathbf{c}$$

possui a mesma matriz de covariâncias de $\mathbf{X}$:

$$\text{Cov}(\mathbf{X}^*) = \Sigma.$$

Consequentemente, os autovalores e as direções principais não se alteram. A ACP baseada em covariâncias é, portanto, invariante a translações. A centralização modifica a origem da representação, mas não sua estrutura de dispersão.

14.13.4.2 Dependência da escala

A ACP baseada em covariâncias não é, em geral, invariante a mudanças individuais de escala. Como desenvolvido na Seção 14.10, uma transformação

$$\mathbf{X}^* = \mathbf{D}\mathbf{X},$$

com $\mathbf{D}$ diagonal e positiva, produz

$$\Sigma^* = \mathbf{D}\Sigma\mathbf{D},$$

cujos autovalores e autovetores podem diferir dos obtidos a partir de Σ . Essa dependência da escala é a razão para distinguir a ACP baseada em covariâncias da ACP baseada em correlações.

14.13.4.3 Unicidade, multiplicidade e dimensão efetiva

Quando todos os autovalores são simples, cada direção principal é determinada até mudança de sinal. Se α_j é um autovetor associado a λ_j , então $-\alpha_j$ representa a mesma direção principal. A inversão do sinal modifica também o sinal dos escores correspondentes, mas preserva o mesmo eixo, sua variância e o subespaço gerado.

Consequentemente, sinais opostos apresentados por diferentes programas ou decomposições numéricas não caracterizam soluções distintas.

A mudança de sinal corresponde à não unicidade da orientação de uma direção individual. Autovalores repetidos e matrizes singulares introduzem questões adicionais: no primeiro caso, é necessário distinguir a direção individual do autoespaço associado; no segundo, a variabilidade pode estar restrita a um subespaço de dimensão inferior a p .

14.13.4.3.1 Multiplicidade de autovalores

Os conceitos de multiplicidade algébrica e geométrica foram definidos na Definição 5.10. Como Σ é simétrica, o Teorema 5.2 garante uma base ortonormal em cada autoespaço.

Considere

$$\lambda_j = \lambda_{j+1}.$$

Qualquer base ortonormal do autoespaço associado pode ser utilizada. Assim, os vetores

$$\alpha_j \quad \text{e} \quad \alpha_{j+1}$$

não são individualmente determinados de forma única. O objeto determinado é o autoespaço associado ao autovalor repetido.

Quando um autovalor é simples, sua direção principal é determinada até mudança de sinal. Quando há multiplicidade, diferentes bases ortonormais do autoespaço produzem conjuntos

diferentes de autovetores igualmente válidos. A ACP identifica, nesse caso, o autoespaço associado ao autovalor repetido, e não uma base ortonormal única dentro dele.

A não unicidade das bases de um autoespaço com multiplicidade foi ilustrada na Figura 5.4. Na ACP, a mesma propriedade explica a condição de unicidade apresentada na Definição 14.2 e na Proposição 14.1.

Se

$$\lambda_k > \lambda_{k+1},$$

o subespaço principal de dimensão k é único. Se

$$\lambda_k = \lambda_{k+1},$$

o corte ocorre dentro de um autoespaço associado a um autovalor repetido. Nesse caso, existem diferentes subespaços de dimensão k que atingem a mesma variância total máxima da projeção.

Mesmo sem igualdade exata, uma pequena separação entre autovalores adjacentes pode tornar os autovetores individuais sensíveis a pequenas variações da matriz analisada. Essa relação é formalizada na Seção 14.13.5: sob as condições ali apresentadas, a variância assintótica da direção estimada envolve termos da forma

$$\frac{1}{(\lambda_j - \lambda_\ell)^2}.$$

Assim, direções associadas a autovalores muito próximos podem apresentar maior incerteza amostral (Anderson, 2003; Johnson; Wichern, 2002).

14.13.4.3.2 Singularidade e dimensão efetiva

A Proposição 8.3 relaciona a singularidade da matriz de covariâncias à existência de combinações lineares com variância zero.

Se

$$\text{posto}(\Sigma) = r < p,$$

então exatamente r autovalores são positivos:

$$\lambda_1 \geq \dots \geq \lambda_r > 0,$$

enquanto

$$\lambda_{r+1} = \dots = \lambda_p = 0.$$

O vetor centralizado $\mathbf{X}_c$ pertence, com probabilidade 1, ao subespaço gerado pelos autovetores associados aos r autovalores positivos. Para $j > r$, a componente Y_j possui média zero e variância zero e, portanto, $Y_j = 0$ quase certamente. Assim, a representação pelas r componentes de variância positiva preserva toda a variância populacional.

No nível amostral, a centralização implica

$$\text{posto}(\mathbf{X}_c) \leq n - 1$$

e, conseqüentemente,

$$\text{posto}(\mathbf{S}) \leq \min(p, n - 1).$$

Quando

$$p \geq n,$$

a matriz de covariâncias amostral é necessariamente singular, ainda que a matriz populacional não seja. Na SVD compacta de $\mathbf{X}_c$, os vetores singulares à direita associados aos valores singulares positivos formam uma base ortonormal do subespaço das direções com variância amostral positiva. A formulação da ACP por SVD permanece, portanto, bem definida mesmo quando $\mathbf{S}$ é singular.

14.13.5 Estimação e inferência das componentes sob normalidade

A formulação da ACP não exige normalidade multivariada. Os resultados desta seção referem-se à ACP populacional baseada na matriz de covariâncias. A hipótese normal passa a ter função específica quando os autovalores e as direções principais são tratados como parâmetros de uma população e se deseja estudar sua estimação ou sua distribuição amostral.

Considere uma amostra aleatória da distribuição normal multivariada definida na Definição 9.1,

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0}.$$

Para uma amostra observada, a Proposição 10.1 fornece a estimativa de máxima verossimilhança de Σ quando o máximo da verossimilhança existe. Esse máximo existe e é único quando

$\text{posto}(\mathbf{S}) = p$; sob o modelo normal não singular, essa condição ocorre quase certamente para $n \geq p + 1$. Com a convenção amostral utilizada neste capítulo, a Equação 10.57 fornece

$$\widehat{\Sigma}_{\text{MV,obs}} = \frac{n-1}{n} \mathbf{S}.$$

Considere a decomposição espectral da matriz de covariâncias amostral,

$$\mathbf{S} = \widehat{\mathbf{A}} \widehat{\Lambda} \widehat{\mathbf{A}}^\top,$$

em que

$$\widehat{\Lambda} = \text{diag}(\hat{\lambda}_1, \dots, \hat{\lambda}_p).$$

Como $\widehat{\Sigma}_{\text{MV,obs}}$ é um múltiplo positivo de $\mathbf{S}$,

$$\widehat{\Sigma}_{\text{MV,obs}} = \widehat{\mathbf{A}} \left(\frac{n-1}{n} \widehat{\Lambda} \right) \widehat{\mathbf{A}}^\top.$$

As duas matrizes possuem, portanto, os mesmos autovetores. Seus autovalores diferem pelo fator

$$\frac{n-1}{n}.$$

Com a notação adotada neste capítulo, a estimativa de máxima verossimilhança do j -ésimo autovalor é

$$\hat{\lambda}_{j,\text{MV,obs}} = \frac{n-1}{n} \hat{\lambda}_j.$$

Nessas condições de existência e quando os autovalores populacionais são distintos, a direção $\hat{\alpha}_j$, com uma convenção de sinal, e $\hat{\lambda}_{j,\text{MV,obs}}$ são as estimativas de máxima verossimilhança da direção principal populacional e de sua variância, respectivamente (Anderson, 2003).

A diferença entre os divisores n e $n-1$ não altera os eixos da ACP. Ela também não altera a proporção de variância associada a cada componente, pois

$$\frac{\hat{\lambda}_{j,\text{MV,obs}}}{\sum_{\ell=1}^p \hat{\lambda}_{\ell,\text{MV,obs}}} = \frac{\hat{\lambda}_j}{\sum_{\ell=1}^p \hat{\lambda}_\ell}.$$

A escolha do divisor modifica a escala dos autovalores, mas preserva as direções, os escores definidos a partir dessas direções e as proporções de variância.

Para estudar as distribuições amostrais, $\hat{\lambda}_j$ e $\hat{\alpha}_j$ passam a ser considerados como estatísticas da amostra aleatória, isto é, como estimadores dos objetos espectrais populacionais. Sob normalidade multivariada, autovalores populacionais distintos e dimensão p fixa,

$$\sqrt{n} (\hat{\lambda}_j - \lambda_j) \xrightarrow{d} N(0, 2\lambda_j^2).$$

Para estudar uma direção individual, fixe o sinal de $\hat{\alpha}_j$ de modo que

$$\hat{\alpha}_j^\top \alpha_j > 0.$$

Então,

$$\sqrt{n} (\hat{\alpha}_j - \alpha_j) \xrightarrow{d} N_p(\mathbf{0}, \Gamma_j),$$

com

$$\Gamma_j = \sum_{\ell \neq j} \frac{\lambda_j \lambda_\ell}{(\lambda_j - \lambda_\ell)^2} \alpha_\ell \alpha_\ell^\top$$

(Anderson, 2003; Johnson; Wichern, 2002).

A expressão de Γ_j mostra o efeito da separação entre autovalores. Quando λ_j se aproxima de outro autovalor λ_ℓ , o termo $(\lambda_j - \lambda_\ell)^{-2}$ aumenta e amplia a variância assintótica do estimador da direção principal. Esse resultado formaliza a sensibilidade das direções individuais discutida na Seção 14.13.4.3.

Os resultados assintóticos acima pressupõem autovalores populacionais distintos. Quando um autovalor possui multiplicidade maior que 1, os autovetores individuais não são parâmetros identificados de forma única; o objeto inferencial passa a ser o autoespaço associado ao autovalor repetido, e as fórmulas anteriores para direções individuais deixam de se aplicar.

14.14 Aprofundamentos metodológicos e aplicados

Leitura de aprofundamento

Esta parte reúne critérios e objetos utilizados na condução e na interpretação da ACP, incluindo a escolha do número de componentes, a relação das variáveis com as componentes, a representação das observações e das variáveis, a utilização de elementos suplementares

e a avaliação da estabilidade da solução amostral.

14.14.1 Preparação dos dados para a ACP

A solução da ACP é determinada pela matriz de covariâncias ou de correlações calculada a partir das variáveis ativas. A definição dessas variáveis, o tratamento das escalas, os dados ausentes e as observações atípicas podem modificar essa matriz e, conseqüentemente, os autovalores e as direções principais.

14.14.1.1 Variáveis ativas

As variáveis ativas devem ser escolhidas de acordo com o problema de redução de dimensionalidade. Incluir uma variável significa permitir que sua variabilidade e suas relações com as demais participem da determinação dos eixos principais. Retirar uma variável modifica a matriz analisada e pode modificar todas as componentes.

Variáveis destinadas apenas à caracterização posterior da solução podem permanecer fora da construção dos eixos e ser incorporadas como elementos suplementares, conforme a Seção 14.14.6.

A presença de variáveis fortemente redundantes também deve ser examinada. Autovalores muito próximos de zero podem revelar dependências lineares ou quase lineares, conforme discutido na Seção 14.14.2. A redundância não constitui, por si só, razão para retirar uma variável: a decisão depende de seu papel no problema e da informação que se pretende preservar.

14.14.1.2 Escala das variáveis

A escolha entre a matriz de covariâncias e a matriz de correlações deve ser definida antes da interpretação das componentes. Quando as unidades ou dispersões das variáveis diferem e essas diferenças não devem determinar sua influência relativa, a padronização evita que a ACP seja dominada apenas pelas escalas numéricas. Quando as diferenças de escala possuem interpretação pertinente ao problema, a padronização modifica essa informação.

Essa decisão corresponde às duas formulações desenvolvidas na Seção 14.10 e não deve ser tomada apenas por conveniência computacional.

14.14.1.3 Dados ausentes

O tratamento de dados ausentes deve preceder a construção da matriz utilizada na ACP. A exclusão de observações altera a amostra analisada; procedimentos de imputação alteram os valores a partir dos quais são calculadas covariâncias e correlações.

Também é necessário cuidado com matrizes de correlações calculadas utilizando conjuntos diferentes de observações para cada par de variáveis. Nesse procedimento, cada correlação pode utilizar um subconjunto distinto da amostra, e a coleção resultante de correlações pode não apresentar a mesma coerência matricial de uma matriz calculada a partir de uma única matriz de dados completa (Hair et al., 2019).

A estratégia adotada para os dados ausentes deve ser registrada antes da interpretação dos autovalores, das componentes e das representações gráficas.

14.14.1.4 Observações atípicas e influência

Observações atípicas podem modificar médias, variâncias, covariâncias e correlações e, por essa via, alterar os autovalores e as direções principais. Esse efeito é especialmente relevante quando poucas observações respondem por parcela importante da variabilidade em determinada direção (Hair et al., 2019).

A identificação de uma observação atípica não implica sua retirada. Devem ser examinadas sua origem, a possibilidade de erro de registro ou mensuração e sua influência sobre a solução. Quando a observação é legítima, a comparação entre a ACP obtida com e sem o caso pode ser utilizada como análise de sensibilidade, sem substituir a solução correspondente à amostra efetivamente definida para o estudo.

14.14.2 Escolha do número de componentes

Tanto na ACP baseada em covariâncias quanto na baseada em correlações, a decomposição espectral produz p componentes, embora aquelas associadas a autovalores nulos tenham variância zero. A redução de dimensionalidade exige decidir quantas das primeiras componentes serão mantidas. Essa decisão não é determinada pela solução matemática da ACP e deve considerar o objetivo da representação, a parcela de variabilidade preservada, os tamanhos relativos dos autovalores e a interpretação das componentes (Johnson; Wichern, 2002).

Na aplicação amostral, denote por

$$\hat{\lambda}_1 \geq \dots \geq \hat{\lambda}_p \geq 0$$

os autovalores da matriz observada utilizada na ACP. A proporção acumulada observada é

$$\hat{\Pi}_k = \frac{\sum_{j=1}^k \hat{\lambda}_j}{\sum_{\ell=1}^p \hat{\lambda}_\ell}.$$

Essa quantidade descreve a parcela da variabilidade observada representada pelas primeiras k componentes. Quanto mais próximo de 1 estiver $\hat{\Pi}_k$ para um valor pequeno de k , maior será a parcela da variabilidade representada por poucas componentes. Não existe, entretanto, uma proporção mínima universal que determine, por si só, quantas componentes devem ser retidas.

Outra informação é fornecida pelo gráfico dos autovalores, usualmente denominado **gráfico de declive** (*scree plot*). Os autovalores são apresentados em ordem decrescente e procura-se identificar uma mudança de inclinação que separe o trecho de quedas mais acentuadas daquele em que os autovalores se tornam relativamente pequenos e semelhantes. As componentes anteriores ao trecho de estabilização constituem candidatas à retenção (Johnson; Wichern, 2002).

A Figura 14.5 ilustra esse comportamento. A linha horizontal também permite comparar, no mesmo exemplo, o gráfico de declive com a referência $\lambda = 1$ utilizada na ACP baseada em correlações.

No exemplo, os cinco autovalores somam 5, como ocorre para uma matriz de correlações de ordem 5. Após a segunda componente, os autovalores são menores e as quedas entre valores sucessivos tornam-se menos acentuadas. A linha tracejada representa outro critério: apenas os dois primeiros autovalores excedem 1. O gráfico de declive e a comparação com 1 utilizam, portanto, critérios distintos, embora neste exemplo ambos destaquem as primeiras componentes.

Na ACP baseada na matriz de correlações, há ainda uma referência específica decorrente da padronização. Como

$$\text{tr}(\mathbf{R}) = p,$$

a média dos p autovalores é igual a 1. O **critério da raiz latente** utiliza essa referência e propõe reter componentes com

$$\hat{\lambda}_{Rj} > 1.$$

Nesse contexto, cada variável padronizada possui variância unitária, de modo que uma componente com autovalor maior que 1 apresenta variância superior à de uma variável original padronizada (Hair et al., 2009).




Figura 14.5: Gráfico de declive dos autovalores. A linha tracejada indica a referência autovalor igual a 1 para uma ACP baseada em correlações.

Esse critério constitui uma regra heurística de retenção e não uma condição matemática necessária da ACP. Sua justificativa também não se transfere diretamente para a ACP baseada em uma matriz de covariâncias, cujas variâncias dependem das escalas das variáveis.

Na ACP baseada na matriz de correlações, a **análise paralela** fornece uma referência amostral adicional para a escolha do número de componentes. O procedimento compara os autovalores observados com autovalores obtidos de dados simulados sem associação entre as variáveis, mantendo o mesmo número de observações e de variáveis. Para cada posição, a retenção é considerada enquanto o autovalor observado excede a referência simulada correspondente. Essa referência pode ser definida pela média ou por um quantil dos autovalores simulados, e o critério empregado deve ser informado. A análise paralela é um critério de retenção e não substitui a interpretação das componentes nem a avaliação da variância representada.

A escolha de k deve considerar conjuntamente a proporção acumulada de variância, o padrão dos autovalores no gráfico de declive e a interpretação das componentes em termos das variáveis originais e do problema em estudo. Esses elementos podem ser examinados tanto na ACP baseada em covariâncias quanto na baseada em correlações. O critério da raiz latente e a forma de análise paralela descrita acima referem-se à ACP baseada na matriz de correlações. Diferentes critérios podem sugerir dimensões distintas, e a decisão não é determinada por um único critério (Johnson; Wichern, 2002).

Os autovalores pequenos também possuem informação diagnóstica. Valores muito próximos de zero, especialmente entre as últimas componentes, podem indicar dependências lineares ou quase lineares entre as variáveis. Assim, mesmo quando essas componentes não são mantidas na representação reduzida, os autovalores correspondentes devem ser examinados quanto à possível presença dessas dependências (Johnson; Wichern, 2002).

14.14.3 Coeficientes e relação das variáveis com as componentes

Os elementos do vetor

$$\alpha_j = \begin{pmatrix} \alpha_{1j} \\ \vdots \\ \alpha_{pj} \end{pmatrix}$$

são os **coeficientes da j -ésima componente principal**. Eles definem a combinação linear

$$Y_j = \sum_{i=1}^p \alpha_{ij} (X_i - \mu_i).$$

Esses coeficientes são as coordenadas do vetor unitário α_j que define a direção principal em $\mathbb{R}^p$ associada à componente. Eles não devem ser confundidos com as correlações entre cada variável e a componente.

A relação entre esses dois objetos pode ser obtida diretamente a partir da matriz de covariâncias.

Para a variável X_i ,

$$\begin{aligned}\text{Cov}(X_i, Y_j) &= \text{Cov}\left[X_i, \alpha_j^\top (\mathbf{X} - \mu)\right] \\ &= \sum_{\ell=1}^p \alpha_{\ell j} \text{Cov}(X_i, X_\ell) \\ &= (\Sigma \alpha_j)_i.\end{aligned}$$

Como

$$\Sigma \alpha_j = \lambda_j \alpha_j,$$

segue que

$$\text{Cov}(X_i, Y_j) = \lambda_j \alpha_{ij}.$$

Além disso,

$$\text{Var}(Y_j) = \lambda_j$$

e

$$\text{Var}(X_i) = \sigma_{ii}.$$

Se

$$\sigma_{ii} > 0$$

e

$$\lambda_j > 0,$$

então a correlação está definida e

$$\text{Corr}(X_i, Y_j) = \frac{\sqrt{\lambda_j} \alpha_{ij}}{\sqrt{\sigma_{ii}}}.$$

Na ACP baseada na matriz de correlações $\mathcal{R}$, suponha que as variâncias marginais sejam positivas, como exigido na Definição 8.5. Para a variável padronizada $X_{i,\text{pad}}$ e a componente Y_{Rj} associada a um autovalor $\lambda_{Rj} > 0$,

$$\text{Corr}(X_{i,\text{pad}}, Y_{Rj}) = \sqrt{\lambda_{Rj}} \alpha_{R,ij}.$$

Isso ocorre porque

$$\text{Var}(X_{i,\text{pad}}) = 1.$$

A condição $\lambda_j > 0$ é necessária porque a correlação exige variância positiva para a componente. Se

$$\lambda_j = 0,$$

então

$$\text{Var}(Y_j) = 0,$$

e a correlação entre Y_j e qualquer variável não está definida.

A expressão mostra que o coeficiente α_{ij} e a correlação entre X_i e Y_j representam objetos diferentes. O coeficiente é uma coordenada da direção principal e participa diretamente da definição da combinação linear; a correlação é uma medida padronizada da associação linear entre uma variável original e a componente já construída (Johnson; Wichern, 2002).

A diferença entre os coeficientes da componente e as correlações com as variáveis pode ser visualizada na Figura 14.6. O exemplo utiliza uma matriz de covariâncias com variâncias marginais diferentes.

Os coeficientes são as coordenadas do vetor unitário que define a direção principal e, conjuntamente, determinam a combinação linear da componente. As correlações descrevem separadamente a associação linear de cada variável com a componente já construída. Na ACP baseada em covariâncias, elas dependem do coeficiente correspondente, da variância da componente e da variância marginal da variável. Portanto, coeficientes e correlações não são medidas intercambiáveis (Johnson; Wichern, 2002).

A distinção também afeta a interpretação. A correlação examina a relação bivariada entre uma variável e uma componente, enquanto os coeficientes pertencem à definição multivariada da componente. Por essa razão, a interpretação pode considerar os dois objetos, sem atribuir à correlação o papel de coeficiente da combinação linear (Johnson; Wichern, 2002).




Figura 14.6: Os coeficientes definem a direção principal associada à componente, enquanto as correlações medem a associação linear de cada variável com essa componente.

No Capítulo 15, as cargas fatoriais pertencem à parametrização do modelo de fatores comuns. Na ACP, em contraste, os coeficientes α_{ij} pertencem aos autovetores que definem as combinações lineares das variáveis observadas. Portanto, cargas fatoriais e coeficientes de componentes principais não devem ser identificados como o mesmo objeto.

Na formulação amostral baseada em $\mathbf{S}$, se

$$s_{ii} > 0$$

e

$$\hat{\lambda}_j > 0,$$

então

$$\widehat{\text{Corr}}(X_i, Y_j) = \frac{\sqrt{\hat{\lambda}_j} \hat{\alpha}_{ij}}{\sqrt{s_{ii}}}.$$

Quando a ACP é realizada sobre $\mathbf{R}$, cada variável padronizada possui variância observada igual a 1. Para uma componente com

$$\hat{\lambda}_{Rj} > 0,$$

denotando por $X_{i,\text{pad}}$ a variável padronizada e por Y_{Rj} a componente correspondente,

$$\widehat{\text{Corr}}(X_{i,\text{pad}}, Y_{Rj}) = \sqrt{\hat{\lambda}_{Rj}} \hat{\alpha}_{R,ij}.$$

14.14.4 Interpretação das componentes

A interpretação substantiva de uma componente pode ser apoiada nas correlações entre cada variável original e a componente, desenvolvidas na Seção 14.14.3. Correlações de maior módulo indicam as variáveis mais fortemente associadas linearmente à componente, enquanto o sinal indica o sentido dessa associação.

Os sinais devem ser interpretados de forma relativa dentro de cada componente. Se α_j for substituído por $-\alpha_j$, os coeficientes, os escores e as correlações associados à componente mudam simultaneamente de sinal, sem alterar a direção principal representada. Assim, o contraste entre variáveis com sinais opostos pode ser interpretado, mas a escolha global de qual polo recebe sinal positivo é arbitrária.

Uma componente principal é uma variável calculada como combinação linear das variáveis observadas. Um rótulo descritivo pode resumir o padrão das correlações entre a componente e essas variáveis, mas não transforma a componente em um fator latente nem introduz um modelo causal.

14.14.5 Representação das observações e das variáveis

A representação das observações utiliza os escores das componentes. Para as variáveis, é necessário distinguir dois objetos: as coordenadas utilizadas no mapa das variáveis e as correlações entre as variáveis e as componentes, desenvolvidas na Seção 14.14.3.

14.14.5.1 Observações: coordenadas, qualidade de representação e contribuição

Para a observação i , a coordenada na componente j é o próprio escore

$$\hat{y}_{ij} = \hat{\alpha}_j^\top (\mathbf{x}_i - \bar{\mathbf{x}}).$$

Assim, em uma representação pelas duas primeiras componentes, a observação i é localizada pelo ponto

$$(\hat{y}_{i1}, \hat{y}_{i2}).$$

O escore é a coordenada da observação na direção principal. Fixada a orientação de $\hat{\alpha}_j$, seu sinal indica de que lado da origem está a projeção, e seu módulo fornece a distância dessa projeção à origem ao longo do eixo.

Para uma observação com

$$\|\mathbf{x}_i - \bar{\mathbf{x}}\| > 0,$$

a qualidade de representação pode ser descrita pelo quadrado do cosseno do ângulo entre o vetor da observação centralizada e uma direção principal. Como $\hat{\alpha}_j$ possui norma unitária e

$$\hat{y}_{ij} = \hat{\alpha}_j^\top (\mathbf{x}_i - \bar{\mathbf{x}}),$$

tem-se

$$\cos_{ij}^{2(\text{obs})} = \frac{\hat{y}_{ij}^2}{\|\mathbf{x}_i - \bar{\mathbf{x}}\|^2} = \frac{\hat{y}_{ij}^2}{\sum_{\ell=1}^p \hat{y}_{i\ell}^2}. \quad (14.1)$$

Para as primeiras k componentes,

$$\cos_{i,(1:k)}^2(\text{obs}) = \sum_{j=1}^k \cos_{ij}^2(\text{obs}) = \frac{\sum_{j=1}^k \hat{y}_{ij}^2}{\sum_{\ell=1}^p \hat{y}_{i\ell}^2}.$$

Essa razão compara a norma quadrática da projeção da observação no subespaço retido com sua distância quadrática total ao centro. Valores próximos de 1 indicam que grande parcela dessa distância é preservada na representação de menor dimensão.

Se $\mathbf{x}_i = \bar{\mathbf{x}}$, a observação coincide com o centro da nuvem, todos os seus escores são nulos e o $\cos^2$ não é definido, pois sua distância quadrática ao centro é zero.

Como medida descritiva de participação relativa, adota-se neste capítulo, para uma componente com $\hat{\lambda}_j > 0$, a **contribuição** da observação i para a componente j definida por

$$\text{ctr}_{ij}^{(\text{obs})} = \frac{\hat{y}_{ij}^2}{\sum_{h=1}^n \hat{y}_{hj}^2}. \quad (14.2)$$

Por essa normalização,

$$\sum_{i=1}^n \text{ctr}_{ij}^{(\text{obs})} = 1.$$

Como, na convenção amostral utilizada neste capítulo,

$$\sum_{h=1}^n \hat{y}_{hj}^2 = (n-1)\hat{\lambda}_j,$$

a contribuição também pode ser escrita como

$$\text{ctr}_{ij}^{(\text{obs})} = \frac{\hat{y}_{ij}^2}{(n-1)\hat{\lambda}_j}.$$

Assim, $\text{ctr}_{ij}^{(\text{obs})}$ expressa a parcela da soma de quadrados dos escores da componente j associada à observação i . Quanto maior seu valor, maior a participação relativa dessa observação na componente segundo essa convenção.

O $\cos^2$ e a contribuição utilizam o mesmo escore quadrático, mas respondem a perguntas diferentes e empregam normalizações distintas. O $\cos^2$ compara o escore quadrático com a distância quadrática total da própria observação ao centro e descreve sua qualidade de representação. A contribuição compara esse mesmo escore quadrático com a soma de quadrados dos escores de todas as observações na componente e descreve, na convenção adotada, sua participação relativa nessa componente.

14.14.5.2 Variáveis: coordenadas, qualidade de representação e contribuição

A Seção 14.14.3 mostrou que os coeficientes que definem uma direção principal e as correlações das variáveis com as componentes são objetos distintos. A representação das variáveis também exige distinguir essas correlações das coordenadas associadas aos eixos principais.

Considere primeiro a ACP baseada em $\mathbf{S}$. Para a variável i e a componente j , a coordenada adotada neste capítulo é

$$c_{ij} = \sqrt{\hat{\lambda}_j} \hat{\alpha}_{ij}.$$

Essa coordenada deve ser distinguida tanto do coeficiente $\hat{\alpha}_{ij}$ quanto da covariância entre a variável e a componente. Como

$$\widehat{\text{Cov}}(X_i, Y_j) = \hat{\lambda}_j \hat{\alpha}_{ij},$$

tem-se

$$\widehat{\text{Cov}}(X_i, Y_j) = \sqrt{\hat{\lambda}_j} c_{ij}.$$

Portanto, coeficiente, coordenada e covariância são, em geral, quantidades distintas.

Pela relação desenvolvida na Seção 14.14.3,

$$r_{ij} = \widehat{\text{Corr}}(X_i, Y_j) = \frac{c_{ij}}{\sqrt{s_{ii}}},$$

quando $s_{ii} > 0$.

A coordenada c_{ij} e a correlação r_{ij} coincidem apenas quando a variável considerada possui variância unitária. Esse é o caso da ACP aplicada às variáveis padronizadas.

Na ACP baseada em $\mathbf{R}$,

$$c_{R,ij} = \sqrt{\hat{\lambda}_{Rj}} \hat{\alpha}_{R,ij}$$

e, como cada variável padronizada possui variância igual a 1,

$$c_{R,ij} = r_{R,ij}.$$

Para as variáveis, a qualidade de representação pode ser descrita a partir das correlações entre cada variável e as componentes. Como a correlação entre dois vetores centralizados corresponde ao cosseno do ângulo entre eles, define-se, para $s_{ii} > 0$ e uma componente com $\hat{\lambda}_j > 0$,

$$\cos_{ij}^{2(\text{var})} = r_{ij}^2 = \frac{\hat{\lambda}_j \hat{\alpha}_{ij}^2}{s_{ii}}. \quad (14.3)$$

Para as primeiras k componentes,

$$\cos_{i,(1:k)}^{2(\text{var})} = \sum_{j=1}^k r_{ij}^2.$$

Essa quantidade corresponde à parcela da variância da variável representada pelo subespaço gerado pelas componentes consideradas. Valores próximos de 1 indicam boa representação da variável nesse subespaço.

Na mesma convenção de participação relativa, para uma componente com $\hat{\lambda}_j > 0$, define-se a contribuição da variável i para a componente j por

$$\text{ctr}_{ij}^{(\text{var})} = \frac{c_{ij}^2}{\hat{\lambda}_j}. \quad (14.4)$$

Como

$$c_{ij} = \sqrt{\hat{\lambda}_j} \hat{\alpha}_{ij},$$

essa quantidade reduz-se a

$$\text{ctr}_{ij}^{(\text{var})} = \hat{\alpha}_{ij}^2.$$

Como os coeficientes da direção principal satisfazem

$$\sum_{i=1}^p \hat{\alpha}_{ij}^2 = 1,$$

tem-se

$$\sum_{i=1}^p \text{ctr}_{ij}^{(\text{var})} = 1.$$

Assim, essa contribuição reparte entre as variáveis a norma quadrática unitária do autovetor associado à componente j .

Na ACP baseada em correlações, para uma componente com $\hat{\lambda}_{Rj} > 0$,

$$c_{R,ij} = r_{R,ij},$$

de modo que, na convenção adotada, a contribuição também pode ser escrita como

$$\text{ctr}_{ij}^{(\text{var})} = \frac{r_{R,ij}^2}{\hat{\lambda}_{Rj}}.$$

A coordenada localiza a variável na geometria associada às componentes. O $\cos^2$ descreve sua qualidade de representação. Na convenção adotada, a contribuição descreve sua participação relativa na componente.

14.14.5.3 Mapas das observações e das variáveis

A interpretação gráfica da ACP distingue o **mapa das observações** do **mapa das variáveis**. Embora os dois utilizem os mesmos eixos principais, eles representam objetos diferentes e suas coordenadas possuem significados distintos.

No **mapa das observações**, os pontos são posicionados pelos escores nas componentes retidas. Para as primeiras k componentes, a distância quadrática entre as representações das observações i e h é

$$d_{ih,(k)}^2 = \sum_{j=1}^k (\hat{y}_{ij} - \hat{y}_{hj})^2.$$

Se

$$\widehat{\mathbf{A}}_k = [\hat{\alpha}_1 \quad \cdots \quad \hat{\alpha}_k],$$

então

$$d_{ih,(k)}^2 = \left\| \widehat{\mathbf{A}}_k \widehat{\mathbf{A}}_k^\top (\mathbf{x}_i - \mathbf{x}_h) \right\|^2 \leq \|\mathbf{x}_i - \mathbf{x}_h\|^2$$

na ACP baseada em covariâncias. Na ACP baseada em correlações, a mesma relação é aplicada aos vetores das observações depois da padronização.

Assim, a distância entre dois pontos no mapa corresponde à distância entre suas **projeções no subespaço retido**. Quando todas as componentes são consideradas, a transformação ortogonal preserva exatamente as distâncias euclidianas no espaço em que a ACP foi construída: nas escalas originais para a ACP baseada em covariâncias e nas escalas padronizadas para

a ACP baseada em correlações. Quando apenas $k < p$ componentes são mantidas, parte da separação entre duas observações pode estar nas dimensões omitidas.

Consequentemente, duas observações próximas no mapa possuem projeções próximas nas componentes representadas, mas não precisam ser próximas no espaço completo. A interpretação dessa proximidade deve considerar também a qualidade de representação das observações no subespaço, descrita pelos respectivos $\cos^2$.

Da mesma forma, uma observação localizada próxima da origem possui escores pequenos nas componentes representadas. Isso não implica necessariamente pequena distância ao centro no espaço completo, pois a observação pode possuir escores importantes em componentes não representadas.

No **mapa das variáveis**, é necessário distinguir as coordenadas

$$c_{ij} = \sqrt{\hat{\lambda}_j} \hat{\alpha}_{ij}$$

das correlações

$$r_{ij} = \widehat{\text{Corr}}(X_i, Y_j).$$

As coordenadas c_{ij} descrevem a posição das variáveis na geometria associada às componentes. As correlações r_{ij} descrevem, em uma escala comum entre -1 e 1 , a intensidade e o sentido da associação linear entre cada variável e cada componente.

Quando a representação utiliza as correlações, a variável i é localizada, nas duas primeiras componentes, pelo ponto

$$(r_{i1}, r_{i2}).$$

Como

$$r_{i1}^2 + r_{i2}^2 \leq 1,$$

esses pontos estão contidos no círculo unitário. Além disso,

$$r_{i1}^2 + r_{i2}^2 = \cos_{i,(1:2)}^2(\text{var}),$$

de modo que a distância radial da variável à origem está diretamente relacionada à sua qualidade de representação no plano. Variáveis próximas da circunferência estão bem representadas pelas duas componentes consideradas. Uma variável próxima da origem apresenta correlações pequenas com essas componentes, mas pode estar associada a componentes posteriores;

portanto, proximidade da origem não significa, por si só, pouca importância da variável no conjunto completo.

Na ACP baseada em correlações,

$$c_{R,ij} = r_{R,ij},$$

e, portanto, o mapa definido pelas coordenadas das variáveis coincide com o círculo de correlações. Na ACP baseada em covariâncias, esses dois objetos não coincidem em geral, pois

$$r_{ij} = \frac{c_{ij}}{\sqrt{s_{ii}}}.$$

O círculo de correlações também permite examinar relações entre variáveis. Considerando todas as componentes com variância positiva,

$$\widehat{\text{Corr}}(X_i, X_h) = \sum_j r_{ij} r_{hj}.$$

Assim, no plano formado pelas duas primeiras componentes,

$$r_{i1}r_{h1} + r_{i2}r_{h2}$$

é a parcela dessa relação reconstruída pelas dimensões representadas. Se θ_{ih} é o ângulo entre os vetores das duas variáveis nesse plano, então

$$r_{i1}r_{h1} + r_{i2}r_{h2} = \sqrt{r_{i1}^2 + r_{i2}^2} \sqrt{r_{h1}^2 + r_{h2}^2} \cos(\theta_{ih}).$$

Quando ambas as variáveis estão bem representadas no plano, seus comprimentos estão próximos de 1 e o cosseno do ângulo fornece uma aproximação mais direta de sua correlação: ângulos pequenos estão associados a relações positivas, ângulos próximos de π a relações negativas e ângulos próximos de $\pi/2$ a relações próximas de zero nas dimensões representadas. Quando uma ou ambas as variáveis apresentam baixa qualidade de representação, o ângulo isoladamente deve ser interpretado com cautela.

Coordenada, $\cos^2$ e contribuição respondem, portanto, a perguntas diferentes:

- a **coordenada** determina a posição do elemento na representação;
- o $\cos^2$ descreve quanto da observação ou da variância da variável é representado pela dimensão ou pelo subespaço considerado;
- a **contribuição**, segundo a convenção adotada, descreve a participação relativa do elemento em uma componente.

Os mapas das observações e das variáveis são complementares, mas não devem ser tratados como se utilizassem necessariamente a mesma métrica. Em particular, a distância entre um ponto que representa uma observação e um ponto que representa uma variável não possui interpretação direta nos dois mapas separados. A representação conjunta desses dois tipos de elementos exige a definição de uma escala específica de *biplot* (Johnson; Wichern, 2002).

Os autovalores descrevem a variância das componentes; os mapas descrevem como observações e variáveis se relacionam com as dimensões retidas. A interpretação gráfica deve, portanto, combinar a posição dos elementos com sua qualidade de representação e com a parcela de variabilidade preservada pelo subespaço escolhido.

14.14.6 Elementos ativos e suplementares na interpretação da ACP

Para organizar a interpretação dos resultados e a correspondência com a implementação utilizada, distinguiremos **elementos ativos** e **elementos suplementares**. Essa distinção é operacional e não modifica a definição matemática da ACP.

As observações e as variáveis ativas são aquelas utilizadas na construção da solução. As observações ativas participam do cálculo das médias, dos desvios-padrão quando há padronização e da matriz de covariâncias ou de correlações. As variáveis ativas formam as coordenadas do vetor analisado e, portanto, determinam a matriz sobre a qual são calculados os autovalores e as direções principais.

Os elementos suplementares não participam dessa construção. Depois que a solução é determinada, uma nova observação pode ser projetada nas direções principais já estimadas; uma variável quantitativa adicional pode ser relacionada às componentes por correlações; e uma variável categórica pode ser descrita a partir da posição das observações pertencentes a cada categoria no espaço das componentes.

Em todos esses casos, o elemento suplementar é relacionado a uma solução previamente construída e não modifica seus autovalores nem suas direções principais.

14.14.6.1 Observações suplementares

Depois que as direções principais são estimadas, uma nova observação pode ser representada no mesmo sistema de coordenadas sem que a ACP seja recalculada (Johnson; Wichern, 2002).

Considere

$$\mathbf{x}_* \in \mathbb{R}^p$$

uma observação que não participou da construção da solução. Mantendo a média e as direções principais estimadas a partir das observações ativas, seu escore na componente j é

$$\hat{y}_{*j} = \hat{\alpha}_j^\top (\mathbf{x}_* - \bar{\mathbf{x}}). \quad (14.5)$$

A nova observação é, portanto, projetada sobre direções já determinadas. Ela recebe coordenadas no espaço das componentes, mas não modifica

$$\hat{\lambda}_j \quad \text{nem} \quad \hat{\alpha}_j.$$

Quando a ACP é realizada sobre variáveis padronizadas, a nova observação deve ser centralizada e padronizada utilizando as mesmas médias e os mesmos desvios-padrão empregados na construção da solução. Esses valores não são recalculados com a inclusão da nova observação.

Essa construção utiliza a projeção sobre um subespaço com base ortonormal desenvolvida na Proposição 3.14. Uma vez definida a base do espaço principal, outros vetores podem ser representados nessa base sem que ela precise ser novamente estimada.

14.14.6.2 Variáveis quantitativas suplementares

Uma variável quantitativa que não participou da determinação dos eixos pode ser relacionada posteriormente às componentes já obtidas. Depois que os escores das observações ativas são calculados, essa relação pode ser descrita pela correlação

$$r_{*j} = \widehat{\text{Corr}}(X_*, Y_j),$$

desde que a variável apresente variância observada positiva.

Essa operação utiliza a mesma relação entre variáveis e componentes empregada na interpretação das variáveis ativas (Johnson; Wichern, 2002). A diferença é que X_* não participou da matriz utilizada para determinar as direções principais.

O valor r_{*j} descreve a intensidade e o sentido da associação linear entre a variável e a componente j . Seu quadrado,

$$r_{*j}^2,$$

pode ser utilizado como medida descritiva da parcela da variância da variável associada linearmente a essa componente.

Como essa relação é calculada depois da obtenção da solução, a variável suplementar não participa da determinação de $\hat{\lambda}_j$ nem de $\hat{\alpha}_j$.

14.14.6.3 Variáveis categóricas suplementares

Uma variável categórica não integra diretamente a matriz de covariâncias ou de correlações utilizada na ACP desenvolvida neste capítulo. Depois que os eixos são obtidos, entretanto, suas categorias podem ser descritas a partir das posições das observações no espaço das componentes.

Uma possibilidade descritiva é representar cada categoria pelo centro dos escores das observações que a compõem. Considere uma categoria g formada pelo conjunto I_g de n_g observações. Com pesos iguais, sua coordenada na componente j é

$$\bar{y}_{gj} = \frac{1}{n_g} \sum_{i \in I_g} \hat{y}_{ij}.$$

Essa quantidade é o baricentro dos escores das observações pertencentes à categoria. Em uma representação pelas duas primeiras componentes, a categoria pode ser localizada pelo ponto

$$(\bar{y}_{g1}, \bar{y}_{g2}).$$

O baricentro resume a posição média das observações da categoria nas dimensões representadas. Diferenças entre baricentros descrevem diferenças entre esses escores médios, mas não constituem, por si mesmas, um teste estatístico de diferenças entre categorias.

Essa representação é calculada depois da construção dos eixos. Portanto, a variável categórica e seus baricentros não alteram os autovalores, os autovetores ou os escores das observações utilizadas na construção da ACP.

Em todos esses procedimentos, a solução da ACP é mantida fixa. A projeção de uma nova observação decorre diretamente da geometria das componentes principais; as relações com variáveis quantitativas e os baricentros de categorias constituem descrições calculadas posteriormente sobre os escores já obtidos.

14.14.7 Estabilidade da solução amostral

A ACP obtida de uma matriz amostral de covariâncias ou de correlações depende da amostra observada. Como $\mathbf{S}$ e $\mathbf{R}$ variam entre amostras, seus autovalores e autovetores também estão sujeitos à variação amostral (Johnson; Wichern, 2002). Quando a interpretação das componentes pretende ser estendida além da amostra utilizada na estimação, interessa examinar a estabilidade desses objetos.

A estabilidade pode ser examinada recalculando a ACP em uma nova amostra, em subamostras ou em amostras obtidas por reamostragem. A comparação deve utilizar a mesma definição das variáveis, a mesma decisão sobre padronização e os mesmos critérios de retenção. Hair

et al. utilizam a replicação em novas amostras ou subamostras como estratégia para avaliar a estabilidade de soluções exploratórias (Hair et al., 2019).

A comparação entre as soluções pode examinar:

- os autovalores e as proporções de variância representada pelas primeiras componentes;
- o número de componentes sugerido pelos mesmos critérios de retenção;
- as direções principais, depois de considerada a indeterminação de sinal;
- as correlações entre as variáveis originais e as componentes;
- a interpretação atribuída às componentes a partir dessas relações.

Vetores de coeficientes com sinais globalmente opostos representam a mesma direção principal e não caracterizam soluções diferentes, conforme discutido na Seção 14.13.4.3.

A separação entre autovalores também afeta essa comparação. Quando autovalores adjacentes são muito próximos, as direções individuais apresentam maior incerteza amostral, como formalizado na Seção 14.13.5. Nessa situação, diferenças entre autovetores obtidos em duas amostras não constituem, isoladamente, evidência de estruturas distintas; deve-se considerar também o subespaço gerado pelas componentes associadas.

O particionamento reduz o número de observações utilizado em cada ACP e, consequentemente, pode aumentar a variabilidade amostral dos autovalores e dos autovetores. Assim, diferenças maiores entre soluções obtidas após a divisão da amostra podem resultar tanto de instabilidade quanto da menor informação disponível em cada subconjunto.

A concordância dos autovalores, das proporções de variância, das direções principais e das relações entre variáveis e componentes fornece evidência empírica de estabilidade. Essa estabilidade se refere à repetibilidade da representação descritiva obtida pela ACP; ela não transforma a técnica em um modelo confirmatório nem estabelece relações causais ou construtos latentes.

14.14.8 Correspondência com a implementação utilizada

Nas atividades computacionais, a ACP será realizada pelo módulo [MEDA](#) (Leblay et al., 2026) do [jamovi](#) (The jamovi project, 2026). O MEDA utiliza o pacote [FactoMineR](#) (Lê; Josse; Husson, 2026). As opções e os resultados apresentados pela implementação correspondem a objetos estatísticos distintos desenvolvidos no capítulo.

Tabela 14.6: Correspondência entre elementos da implementação e os objetos estatísticos desenvolvidos no capítulo.

Elemento da implementação	Correspondência estatística	Desenvolvimento no capítulo
Scale to unit variance	padronização ou não das variáveis quantitativas ativas antes da construção da ACP	Seção 14.10
Number of factors	número de dimensões incluídas nas descrições e tabelas da implementação; não constitui, por si só, um critério para escolher a dimensionalidade	Seção 14.14.2
Variáveis quantitativas ativas	variáveis utilizadas na determinação dos eixos principais	Seção 14.14.6
Variáveis quantitativas suplementares	variáveis relacionadas posteriormente às componentes por coordenadas, correlações e $\cos^2$	Seção 14.14.6
Variáveis categóricas suplementares	categorias descritas posteriormente por suas posições baricêntricas no espaço das componentes	Seção 14.14.6
Coordenadas das observações	escores nas componentes principais; sua escala numérica depende da convenção de padronização descrita abaixo	Seção 14.14.5
Coordenadas das variáveis ativas	coordenadas c_{ij} associadas aos eixos principais	Seção 14.14.5
$\cos^2$	medida descritiva da qualidade de representação nas dimensões consideradas	Seção 14.14.5
Contribuições	medidas normalizadas da participação relativa das observações e das variáveis ativas em cada componente	Seção 14.14.5

A opção **Scale to unit variance** controla a padronização das variáveis quantitativas ativas antes da construção da ACP. Quando ela está ativada, as variáveis são centralizadas e divididas

por seus desvios-padrão, de modo que a solução corresponde à ACP baseada em correlações desenvolvida na Seção 14.10. Quando está desativada, as variáveis permanecem em suas escalas observadas após a centralização e a solução corresponde à ACP baseada em covariâncias, ressaltada a convenção de normalização descrita a seguir.

Na ACP sem padronização, a mudança do divisor $n - 1$ para n multiplica todos os autovalores por $(n - 1)/n$, mas preserva os autovetores, os escores das observações e as proporções de variância representada. As coordenadas das variáveis, que dependem de $\sqrt{\hat{\lambda}_j}$, são multiplicadas por $\sqrt{(n - 1)/n}$, enquanto correlações, $\cos^2$ e contribuições permanecem invariantes.

Quando **Scale to unit variance** está ativada, há uma diferença adicional na escala utilizada para padronizar as observações. Neste capítulo,

$$s_{jj} = \frac{1}{n - 1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2.$$

Com pesos iguais, o **FactoMineR** utiliza

$$s_{j,\text{FM}}^2 = \frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2 = \frac{n - 1}{n} s_{jj}.$$

Consequentemente,

$$\mathbf{X}_{\text{FM,pad}} = \sqrt{\frac{n}{n - 1}} \mathbf{X}_{\text{pad}}.$$

Entretanto,

$$\frac{1}{n} \mathbf{X}_{\text{FM,pad}}^\top \mathbf{X}_{\text{FM,pad}} = \mathbf{R}.$$

Assim, a ACP padronizada do **FactoMineR** produz a mesma matriz de correlações, os mesmos autovalores e as mesmas direções principais definidas neste capítulo. As coordenadas das observações diferem apenas pelo fator

$$\hat{y}_{ij,\text{FM}} = \sqrt{\frac{n}{n - 1}} \hat{y}_{R,ij}.$$

Essa mudança de escala não altera os $\cos^2$, as contribuições nem as relações geométricas baseadas em razões de normas.

Neste capítulo, as contribuições são expressas como proporções que somam 1 em cada componente. O **FactoMineR** apresenta essas mesmas medidas em porcentagem, multiplicando-as por 100.

14.14.8.1 Correspondência direta com `stats::prcomp()`

Para uma matriz de dados completa, a decomposição também pode ser examinada diretamente com `stats::prcomp()`. Com `scale. = FALSE`, a ACP é realizada nas escalas originais após a centralização; com `scale. = TRUE`, as variáveis são padronizadas antes da decomposição.

O vetor `ajuste$sdev^2` contém as variâncias das componentes, `ajuste$rotation` contém as direções principais e `ajuste$x` contém os escores das observações. A função utiliza o divisor $n - 1$ no cálculo das variâncias, de modo que sua convenção coincide com a formulação amostral adotada neste capítulo. Diferenças globais de sinal entre as direções retornadas por implementações distintas não representam diferenças entre as componentes correspondentes.

14.15 Síntese

A Análise de Componentes Principais constrói novas variáveis como combinações lineares das variáveis observadas centralizadas. Para

$$\mathbf{X}_c = \mathbf{X} - \mu,$$

a j -ésima componente principal é

$$Y_j = \alpha_j^\top \mathbf{X}_c,$$

em que α_j é uma direção unitária escolhida de modo que as componentes sejam ordenadas segundo suas variâncias.

A primeira componente maximiza

$$\text{Var}(\alpha^\top \mathbf{X}_c)$$

sob a restrição

$$\alpha^\top \alpha = 1.$$

As componentes seguintes maximizam o mesmo critério sujeitas adicionalmente à ortogonalidade em relação às direções anteriormente obtidas. Pela decomposição espectral,

$$\Sigma \alpha_j = \lambda_j \alpha_j,$$

com

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0,$$

de modo que

$$\text{Var}(Y_j) = \lambda_j.$$

Como os autovetores de uma matriz de covariâncias simétrica podem ser escolhidos ortonormais, componentes principais distintas são não correlacionadas. Para um autovalor simples, a direção principal é determinada até mudança de sinal; quando há multiplicidade, o autoespaço associado é determinado, mas uma base individual dentro dele não é única. Além disso,

$$\sum_{j=1}^p \lambda_j = \text{tr}(\Sigma),$$

de modo que os autovalores decompõem a variabilidade total da matriz analisada entre as componentes principais.

A redução de dimensionalidade utiliza as primeiras $k < p$ componentes para representar as observações em um subespaço de menor dimensão. O subespaço gerado pelas primeiras direções principais preserva a maior quantidade possível de variância entre todos os subespaços lineares de dimensão k e, de forma equivalente, produz o menor erro quadrático de reconstrução. Quando componentes associadas a autovalores positivos são descartadas, parte da variabilidade original deixa de ser representada.

No nível amostral, a ACP é obtida a partir da matriz de covariâncias $\mathbf{S}$ ou da matriz de correlações $\mathbf{R}$. Os autovetores estimados determinam as direções principais e os escores fornecem as coordenadas das observações nessas direções. Se $\mathbf{X}_c$ é a matriz de dados centralizada e

$$\mathbf{X}_c = \mathbf{U}\mathbf{D}\mathbf{V}^\top$$

é sua decomposição em valores singulares, os vetores singulares à direita correspondentes aos valores singulares positivos determinam as mesmas direções principais obtidas pela decomposição espectral de $\mathbf{S}$. Os escores correspondentes podem ser escritos em termos de $\mathbf{U}\mathbf{D}$.

A escolha entre a ACP baseada em covariâncias e a ACP baseada em correlações define a geometria da análise. A primeira preserva as escalas e variâncias originais das variáveis. A segunda utiliza variáveis padronizadas e atribui variância unitária a cada uma delas. Por isso, mudanças de unidade podem modificar a solução baseada em covariâncias, enquanto a ACP baseada em correlações elimina esse efeito de escala marginal.

A ACP pode ser utilizada de forma descritiva diretamente sobre uma matriz de dados observada, sem exigir normalidade multivariada. Em uma formulação populacional baseada em

covariâncias, são necessários momentos de segunda ordem finitos; quando a análise é baseada em correlações, também são necessárias variâncias marginais positivas. A normalidade multivariada constitui uma hipótese adicional para os resultados específicos de máxima verossimilhança e de inferência apresentados no aprofundamento teórico; ela não é necessária para calcular autovalores, autovetores ou escores amostrais.

A ACP representa a variabilidade segundo um critério específico: componentes são ordenadas pela variância. Sua solução depende do conjunto de variáveis, de suas escalas e da matriz utilizada. Além disso, a representação é linear e pode exigir várias componentes quando a variabilidade dos dados não se concentra próxima de um subespaço linear de baixa dimensão. Valores extremos também podem modificar a matriz de entrada e, consequentemente, os autovalores e as direções principais.

A ACP não introduz fatores latentes nem separa a variabilidade observada em parcelas comum e específica. No Capítulo 15, o problema passa a ser outro: a Análise Fatorial especifica um modelo no qual a estrutura comum de covariâncias é representada por fatores latentes, enquanto a variabilidade específica de cada variável é modelada separadamente.

15 Formulação da Análise Fatorial

A Análise Fatorial representa a estrutura de covariâncias entre variáveis observadas por meio de um número menor de variáveis latentes, denominadas **fatores comuns**. No modelo ortogonal, as covariâncias entre variáveis distintas são atribuídas aos fatores comuns, enquanto a variância de cada variável é decomposta em uma parcela comum e uma parcela específica (Johnson; Wichern, 2002).

Diferentemente da ACP formulada no Capítulo 14, que constrói componentes como combinações lineares das variáveis observadas, ordenadas segundo suas variâncias, a Análise Fatorial especifica um modelo para a estrutura de covariâncias. No modelo ortogonal,

$$\Sigma = \Phi\Phi^\top + \Psi,$$

em que $\Phi\Phi^\top$ é a matriz de covariâncias da parcela comum e Ψ é a matriz diagonal das variâncias específicas.

A formulação utiliza a matriz de covariâncias populacional definida na Definição 8.2 e a noção de posto da Definição 2.12. A normalidade multivariada não é necessária para definir a estrutura de segunda ordem do modelo; ela é requerida apenas nas formulações probabilísticas e inferenciais que dependem dessa hipótese.

Neste capítulo, a matriz de cargas fatoriais será denotada por $\Phi = (\phi_{ij})$, seguindo a notação adotada por Artes e Barroso (Artes; Barroso, 2023).

15.1 O problema da estrutura latente

Considere o vetor aleatório

$$\mathbf{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_p \end{pmatrix} \in \mathbb{R}^p,$$

com segundos momentos finitos, vetor de médias

$$\mu = E(\mathbf{X})$$

e matriz de covariâncias populacional Σ , definida na Definição 8.2.

Os elementos fora da diagonal de Σ registram as covariâncias entre pares de variáveis e, portanto, sua associação linear. No modelo fatorial ortogonal, essas covariâncias são atribuídas à influência conjunta de um número menor de fatores não diretamente observados.

Considere

$$\mathbf{F} = \begin{pmatrix} F_1 \\ \vdots \\ F_m \end{pmatrix} \in \mathbb{R}^m,$$

com

$$1 \leq m < p$$

na representação de dimensão reduzida considerada.

As componentes de $\mathbf{F}$ são variáveis aleatórias latentes. Elas não correspondem a colunas observadas da matriz de dados. Sua existência é postulada pelo modelo para representar a estrutura de covariâncias entre as variáveis observadas.

A Análise Fatorial introduz uma estrutura latente de dimensão $m < p$ para modelar as covariâncias entre as variáveis observadas. Cada variável é representada por uma parcela associada aos fatores comuns e por uma parcela específica.

Os fatores comuns representam a parcela da estrutura de covariâncias atribuída às relações comuns entre as variáveis. Os fatores específicos representam a variabilidade de cada variável que não é atribuída aos fatores comuns. As condições que definem essa decomposição são estabelecidas no modelo ortogonal.

15.2 Formulação do modelo de fatores comuns

O modelo básico representa o vetor observado como a soma de três parcelas:

1. localização média;
2. contribuição dos fatores comuns;
3. contribuição específica.

Definição 15.1 (Modelo de fatores comuns). Considere um vetor aleatório

$$\mathbf{X} \in \mathbb{R}^p$$

com segundos momentos finitos e vetor de médias

$$\mu = E(\mathbf{X}).$$

Sejam

$$\mathbf{F} \in \mathbb{R}^m$$

um vetor aleatório de fatores comuns e

$$\varepsilon \in \mathbb{R}^p$$

um vetor aleatório de fatores específicos, ambos com segundos momentos finitos e satisfazendo

$$E(\mathbf{F}) = \mathbf{0}$$

e

$$E(\varepsilon) = \mathbf{0}.$$

O modelo de fatores comuns é

$$\mathbf{X} = \mu + \Phi \mathbf{F} + \varepsilon, \quad (15.1)$$

em que

$$\Phi \in \mathbb{R}^{p \times m}$$

é a matriz de cargas fatoriais.

Os elementos do modelo são organizados na Tabela [15.1](#).

Tabela 15.1: Elementos do modelo de fatores comuns.

Objeto	Dimensão	Função no modelo
$\mathbf{X}$	$p \times 1$	Vetor de variáveis observadas
μ	$p \times 1$	Vetor de médias

Objeto	Dimensão	Função no modelo
$\mathbf{F}$	$m \times 1$	Vetor de fatores comuns latentes
Φ	$p \times m$	Matriz de cargas fatoriais
ε	$p \times 1$	Vetor de fatores específicos
Ψ	$p \times p$	Matriz de covariâncias dos fatores específicos no modelo ortogonal

A i -ésima variável pode ser escrita como

$$X_i = \mu_i + \phi_{i1}F_1 + \phi_{i2}F_2 + \cdots + \phi_{im}F_m + \varepsilon_i. \quad (15.2)$$

A linha i da matriz de cargas será denotada por

$$\phi_i^\top = (\phi_{i1} \quad \cdots \quad \phi_{im}).$$

A coluna j será denotada por

$$\phi_{\cdot j} = \begin{pmatrix} \phi_{1j} \\ \vdots \\ \phi_{pj} \end{pmatrix} \in \mathbb{R}^p.$$

Assim,

$$X_i - \mu_i = \phi_i^\top \mathbf{F} + \varepsilon_i.$$

A carga ϕ_{ij} representa o coeficiente associado ao fator F_j na expressão linear da variável X_i . Sua interpretação depende da escala dos fatores, da escala das variáveis e da parametrização utilizada.

A Figura 15.1 representa a estrutura de um modelo com dois fatores e três variáveis observadas. As setas azuis representam as contribuições dos fatores comuns e as setas vermelhas representam os fatores específicos.

A figura mostra a estrutura linear postulada pelo modelo. Sob as hipóteses do modelo ortogonal estabelecidas a seguir, as covariâncias entre variáveis distintas são atribuídas à parcela comum, enquanto os fatores específicos não acrescentam covariâncias entre variáveis distintas.




Figura 15.1: Estrutura do modelo de fatores comuns: as variáveis observadas recebem contribuições dos fatores comuns e dos fatores específicos.

15.3 Hipóteses do modelo ortogonal

A expressão na Equação 15.1 ainda não determina a estrutura de covariâncias. Na parametrização ortogonal adotada neste capítulo, são impostas condições de centralização e padronização dos fatores comuns, diagonalidade da matriz de covariâncias dos fatores específicos e ausência de covariância entre as parcelas comum e específica. Essas condições são reunidas na definição a seguir.

Definição 15.2 (Modelo fatorial ortogonal). Considere o modelo de fatores comuns da Definição 15.1, com

$$E(\mathbf{F}) = \mathbf{0}$$

e

$$E(\varepsilon) = \mathbf{0}.$$

O modelo é denominado **fatorial ortogonal** quando

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m,$$

$$\text{Cov}(\varepsilon) = \Psi = \text{diag}(\psi_1, \dots, \psi_p), \quad \psi_i \geq 0,$$

e

$$\text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0}.$$

A condição

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m$$

fixa a escala dos fatores, atribui variância unitária a cada fator e estabelece covariâncias nulas entre fatores distintos. A ortogonalidade, nesse contexto, refere-se à estrutura de covariâncias dos fatores.

Essa padronização se refere aos **fatores latentes** e não implica que as variáveis observadas tenham variância unitária. A padronização das variáveis observadas ocorre quando o modelo é formulado a partir da matriz de correlações.

A diagonalidade de Ψ estabelece

$$\text{Cov}(\varepsilon_i, \varepsilon_j) = 0, \quad \forall i \neq j.$$

Consequentemente, a parcela específica do modelo não acrescenta covariância entre variáveis distintas.

A diagonalidade de Ψ estabelece **não correlação** entre fatores específicos distintos, mas não implica sua independência sem hipóteses probabilísticas adicionais. Se ε possui distribuição normal multivariada, a diagonalidade de Ψ implica independência entre seus componentes pela Proposição 9.6.

A condição

$$\text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0}$$

separa, em termos de covariância, a parcela comum da parcela específica.

Essas hipóteses são suficientes para obter a estrutura de segunda ordem do modelo fatorial ortogonal. A normalidade multivariada não é necessária para essa formulação. Seu papel é retomado na seção sobre pressupostos e desenvolvido na Seção 15.14.3.

15.4 Estrutura da matriz de covariâncias

Da Equação 15.1,

$$\mathbf{X} - \mu = \Phi \mathbf{F} + \varepsilon.$$

Pelas condições de média do modelo,

$$E(\mathbf{X}) = \mu.$$

Para a matriz de covariâncias,

$$\begin{aligned} \text{Cov}(\mathbf{X}) &= \text{Cov}(\Phi \mathbf{F} + \varepsilon) \\ &= \Phi \text{Cov}(\mathbf{F}) \Phi^\top + \text{Cov}(\varepsilon) \\ &\quad + \Phi \text{Cov}(\mathbf{F}, \varepsilon) + \text{Cov}(\varepsilon, \mathbf{F}) \Phi^\top. \end{aligned}$$

A regra de transformação da covariância utilizada nessa expressão foi estabelecida na Proposição 8.6.

Pelas hipóteses do modelo fatorial ortogonal,

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m,$$

$$\text{Cov}(\varepsilon) = \Psi$$

e

$$\text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0}.$$

Portanto,

$$\Sigma = \Phi\Phi^\top + \Psi. \quad (15.3)$$

Proposição 15.1 (Estrutura de covariâncias do modelo fatorial ortogonal). *Sob as hipóteses da Definição 15.2, a matriz de covariâncias de $\mathbf{X}$ é*

$$\Sigma = \Phi\Phi^\top + \Psi,$$

em que

$$\Phi\Phi^\top \succeq \mathbf{0}$$

e

$$\Psi = \text{diag}(\psi_1, \dots, \psi_p) \succeq \mathbf{0}.$$

A matriz

$$\Phi\Phi^\top$$

é a matriz de covariâncias da parcela comum do modelo. Como

$$\Phi \in \mathbb{R}^{p \times m},$$

tem-se

$$\text{posto}(\Phi\Phi^\top) \leq m.$$

Assim, a estrutura comum é representada por uma matriz semidefinida positiva cujo posto é limitado pelo número de fatores.

A matriz

$$\Psi = \text{diag}(\psi_1, \dots, \psi_p)$$

contém as variâncias específicas.

A decomposição

$$\Sigma = \underbrace{\Phi\Phi^\top}_{\text{parcela comum}} + \underbrace{\Psi}_{\text{parcela específica}}$$

explicita a diferença em relação à ACP. A Análise Fatorial não procura uma decomposição espectral completa de Σ . Ela procura representar a matriz de covariâncias por uma estrutura comum de posto reduzido acrescida de uma matriz diagonal de variâncias específicas.

15.4.1 Covariâncias entre variáveis

Considere duas variáveis distintas X_i e X_j . Pelo modelo,

$$X_i - \mu_i = \phi_i^\top \mathbf{F} + \varepsilon_i$$

e

$$X_j - \mu_j = \phi_j^\top \mathbf{F} + \varepsilon_j.$$

Sob as hipóteses do modelo fatorial ortogonal,

$$\text{Cov}(X_i, X_j) = \phi_i^\top \phi_j, \quad i \neq j.$$

Equivalentemente,

$$\sigma_{ij} = \sum_{h=1}^m \phi_{ih} \phi_{jh}, \quad i \neq j. \quad (15.4)$$

A covariância entre duas variáveis observadas é, portanto, igual ao produto interno entre seus vetores de cargas.

Esse resultado admite uma interpretação geométrica. As linhas de Φ podem ser vistas como vetores em $\mathbb{R}^m$. O sinal do produto interno entre dois vetores de cargas determina o sinal da covariância correspondente no modelo: produto interno positivo corresponde a covariância positiva, produto interno negativo corresponde a covariância negativa e ortogonalidade corresponde a covariância nula.

Essa geometria é desenvolvida na Seção 15.7.

15.4.2 Variâncias das variáveis

Para uma variável X_i ,

$$\begin{aligned}\text{Var}(X_i) &= \text{Var}(\phi_i^\top \mathbf{F} + \varepsilon_i) \\ &= \phi_i^\top \phi_i + \psi_i.\end{aligned}$$

Portanto,

$$\sigma_{ii} = \sum_{h=1}^m \phi_{ih}^2 + \psi_i. \quad (15.5)$$

A variância de cada variável é decomposta em uma parcela comum e uma parcela específica.

15.5 Comunalidades e especificidades

A decomposição da Equação 15.5 permite definir duas quantidades próprias da Análise Fatorial.

Definição 15.3 (Comunalidade). No modelo fatorial ortogonal definido na Definição 15.2, a **comunalidade** da variável X_i é

$$h_i^2 = \phi_i^\top \phi_i = \sum_{h=1}^m \phi_{ih}^2. \quad (15.6)$$

A comunalidade é a parcela da variância de X_i atribuída aos fatores comuns.

Definição 15.4 (Especificidade). No modelo fatorial ortogonal definido na Definição 15.2, a **especificidade** da variável X_i é

$$\psi_i = \text{Var}(\varepsilon_i), \quad \psi_i \geq 0.$$

Assim,

$$\text{Var}(X_i) = h_i^2 + \psi_i. \quad (15.7)$$

A comunalidade e a especificidade pertencem à decomposição da variância de **cada variável**. Na parametrização adotada neste capítulo, ψ_i é a variância do termo específico ε_i e reúne a parcela da variância de X_i que não é representada pelos fatores comuns. Na terminologia aplicada de Hair et al., essa parcela não comum pode ser discutida conceitualmente em termos de variância específica ou única e variância de erro. O modelo fatorial básico adotado aqui não identifica separadamente essas duas fontes a partir de ψ_i (Hair et al., 2009).

Essa decomposição não corresponde à decomposição da variância total em componentes sucessivamente ordenadas, como ocorre na ACP.

Quando as variáveis estão padronizadas,

$$\text{Var}(X_i) = 1,$$

e, portanto,

$$1 = h_i^2 + \psi_i. \quad (15.8)$$

Nesse caso,

$$0 \leq h_i^2 \leq 1$$

e

$$0 \leq \psi_i \leq 1.$$

Como a variância total da variável padronizada é igual a 1, a comunalidade h_i^2 também pode ser interpretada como a proporção de sua variância atribuída aos fatores comuns, enquanto ψ_i é a proporção não representada pela parcela comum do modelo.

A soma das comunalidades pode ser escrita como

$$\sum_{i=1}^p h_i^2 = \text{tr}(\Phi\Phi^\top).$$

Como

$$\text{tr}(\Sigma) = \text{tr}(\Phi\Phi^\top) + \text{tr}(\Psi),$$

a variância total também admite a decomposição

$$\text{tr}(\Sigma) = \sum_{i=1}^p h_i^2 + \sum_{i=1}^p \psi_i. \quad (15.9)$$

A interpretação dessa identidade difere daquela utilizada na ACP. Na ACP, os autovalores distribuem a variância total entre componentes principais. Na Análise Fatorial, a identidade separa a variabilidade atribuída à estrutura comum da variabilidade específica das variáveis.

Exemplo 15.1 (Modelo com um fator comum). Considere três variáveis padronizadas e centralizadas representadas por um único fator comum,

$$\mathbf{X} = \Phi F + \varepsilon,$$

com

$$\Phi = \begin{pmatrix} 0,80 \\ 0,70 \\ 0,60 \end{pmatrix}$$

e

$$\Psi = \begin{pmatrix} 0,36 & 0 & 0 \\ 0 & 0,51 & 0 \\ 0 & 0 & 0,64 \end{pmatrix}.$$

As communalidades são

$$h_1^2 = 0,80^2 = 0,64,$$

$$h_2^2 = 0,70^2 = 0,49$$

e

$$h_3^2 = 0,60^2 = 0,36.$$

Como as variáveis são padronizadas,

$$h_i^2 + \psi_i = 1$$

para cada variável.

A matriz de covariâncias da parcela comum é

$$\Phi\Phi^\top = \begin{pmatrix} 0,64 & 0,56 & 0,48 \\ 0,56 & 0,49 & 0,42 \\ 0,48 & 0,42 & 0,36 \end{pmatrix}.$$

Somando as variâncias específicas,

$$\mathcal{R} = \Phi\Phi^\top + \Psi = \begin{pmatrix} 1 & 0,56 & 0,48 \\ 0,56 & 1 & 0,42 \\ 0,48 & 0,42 & 1 \end{pmatrix}.$$

No modelo com um fator, as correlações entre variáveis distintas são iguais ao produto das cargas correspondentes. Por exemplo,

$$\text{Corr}(X_1, X_2) = 0,80 \times 0,70 = 0,56.$$

A primeira variável apresenta comunalidade 0,64, de modo que 64% de sua variância padronizada é atribuída ao fator comum e 36% é atribuída ao fator específico. Para a terceira variável, essas parcelas são 36% e 64%, respectivamente.

O exemplo mostra que a Análise Fatorial procura representar simultaneamente as covariâncias entre as variáveis e a decomposição de suas variâncias em parcelas comum e específica.

15.6 Cargas fatoriais e associação com os fatores

A matriz Φ reúne as cargas fatoriais do modelo. Seus elementos são os coeficientes de $\mathbf{F}$ na representação de $\mathbf{X} - \mu$ e determinam a matriz de covariâncias da parcela comum $\Phi\Phi^\top$.

No modelo ortogonal,

$$\text{Cov}(\mathbf{X}, \mathbf{F}) = \text{Cov}(\Phi\mathbf{F} + \varepsilon, \mathbf{F}).$$

Como

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m$$

e

$$\text{Cov}(\varepsilon, \mathbf{F}) = \mathbf{0},$$

segue que

$$\text{Cov}(\mathbf{X}, \mathbf{F}) = \Phi. \quad (15.10)$$

Portanto,

$$\text{Cov}(X_i, F_j) = \phi_{ij}.$$

Essa igualdade decorre conjuntamente de $\text{Cov}(\mathbf{F}) = \mathbf{I}_m$ e $\text{Cov}(\varepsilon, \mathbf{F}) = \mathbf{0}$.

A carga fatorial coincide com a correlação entre X_i e F_j somente quando a variável observada também possui variância unitária. Se $\sigma_{ii} > 0$,

$$\text{Corr}(X_i, F_j) = \frac{\phi_{ij}}{\sqrt{\sigma_{ii}}}. \quad (15.11)$$

Para variáveis padronizadas,

$$\sigma_{ii} = 1,$$

e então

$$\text{Corr}(X_i, F_j) = \phi_{ij}.$$

Essa distinção é semelhante àquela estabelecida na Seção 14.14.3 entre os coeficientes das componentes principais e as correlações das variáveis com as componentes. Na Análise Fatorial, as cargas são parâmetros do próprio modelo de covariâncias.

A formulação construída até este ponto mostra que o problema da estrutura latente pode ser expresso por

$$\Sigma = \Phi\Phi^\top + \Psi.$$

A fatoração $\Phi\Phi^\top$ não é única: diferentes matrizes de cargas podem gerar a mesma matriz de covariâncias da parcela comum. Assim, as cargas individuais dependem da parametrização adotada, enquanto a estrutura comum pode permanecer inalterada.

15.7 Geometria das cargas fatoriais

No modelo ortogonal, cada linha da matriz de cargas

$$\phi_i^\top = (\phi_{i1} \quad \cdots \quad \phi_{im})$$

pode ser representada como um vetor em $\mathbb{R}^m$.

A interpretação geométrica reúne a expressão da comunalidade na Equação 15.6 e a expressão da covariância entre variáveis distintas na Equação 15.4:

$$h_i^2 = \phi_i^\top \phi_i = \|\phi_i\|^2$$

e, para $i \neq j$,

$$\sigma_{ij} = \phi_i^\top \phi_j.$$

Portanto, o quadrado da norma do vetor de cargas da variável X_i é sua comunalidade, enquanto o produto interno entre os vetores de cargas de duas variáveis é a covariância entre elas no modelo fatorial ortogonal.

Pela relação entre produto interno, normas e ângulo, para $\phi_i \neq \mathbf{0}$ e $\phi_j \neq \mathbf{0}$,

$$\sigma_{ij} = \phi_i^\top \phi_j = \|\phi_i\| \|\phi_j\| \cos(\theta_{ij}),$$

em que $\theta_{ij} \in [0, \pi]$ é o ângulo entre os vetores de cargas ϕ_i e ϕ_j . Assim, a covariância comum depende simultaneamente dos comprimentos dos vetores e de sua orientação relativa.

Para vetores de cargas não nulos, se $0 \leq \theta_{ij} < \pi/2$, então $\sigma_{ij} > 0$; se $\theta_{ij} = \pi/2$, então $\sigma_{ij} = 0$; e, se $\pi/2 < \theta_{ij} \leq \pi$, então $\sigma_{ij} < 0$.

A Figura 15.2 representa quatro variáveis padronizadas em um modelo com dois fatores. O quadrado do comprimento de cada vetor é a comunalidade da variável, enquanto suas coordenadas são as cargas nos dois fatores.

Os vetores de X_1 e X_2 formam um ângulo agudo e, portanto, possuem produto interno positivo. A variável X_3 apresenta carga de maior magnitude em F_2 do que em F_1 . Para X_4 , as cargas possuem sinais opostos nos dois fatores.

O círculo unitário fornece uma referência geométrica para variáveis padronizadas. Nesse caso,

$$h_i^2 \leq 1,$$




Figura 15.2: Geometria das cargas de variáveis padronizadas em um modelo com dois fatores. O quadrado do comprimento de cada vetor é a communalidade, e o produto interno entre dois vetores é a covariância correspondente.

de modo que os vetores de cargas permanecem no interior ou sobre a circunferência.

A figura representa geometricamente os vetores de cargas das variáveis. Esses vetores contêm os coeficientes que relacionam cada variável observada aos fatores latentes.

15.8 Estrutura comum de covariâncias

A estrutura fatorial comum pode ser isolada pela diferença entre a matriz total de covariâncias e a matriz de variâncias específicas.

Defina

$$\Sigma_{\text{com}} = \Sigma - \Psi.$$

Pela Equação 15.3,

$$\Sigma_{\text{com}} = \Phi\Phi^{\top}. \quad (15.12)$$

Essa matriz é a matriz de covariâncias da parcela comum do modelo. De fato, definindo

$$\mathbf{X}_{\text{com}} = \Phi\mathbf{F},$$

e utilizando

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m,$$

obtém-se

$$\text{Cov}(\mathbf{X}_{\text{com}}) = \Phi \text{Cov}(\mathbf{F})\Phi^{\top} = \Phi\Phi^{\top} = \Sigma_{\text{com}}.$$

Definição 15.5 (Matriz de covariâncias da parcela comum). No modelo fatorial ortogonal definido na Definição 15.2, a **matriz de covariâncias da parcela comum** é

$$\Sigma_{\text{com}} = \Phi\Phi^{\top}.$$

Seus elementos diagonais são as comunalidades e, fora da diagonal, seus elementos são as covariâncias entre as variáveis observadas especificadas pelo modelo.

A diagonal de Σ_{com} é

$$\text{diag}(\Sigma_{\text{com}}) = \begin{pmatrix} h_1^2 \\ \vdots \\ h_p^2 \end{pmatrix},$$

enquanto, para $i \neq j$,

$$(\Sigma_{\text{com}})_{ij} = \sigma_{ij}.$$

Na formulação populacional exata do modelo básico, toda covariância entre variáveis distintas é atribuída aos fatores comuns. As variâncias possuem uma parcela adicional representada por Ψ .

Quando as variáveis são padronizadas,

$$\Sigma = \mathcal{R},$$

e a matriz comum possui diagonal formada pelas comunalidades:

$$\Sigma_{\text{com}} = \mathcal{R} - \Psi.$$

Como Ψ é diagonal, Σ_{com} e $\mathcal{R}$ possuem os mesmos elementos fora da diagonal. A diferença ocorre na diagonal: os valores unitários de $\mathcal{R}$ são substituídos pelas comunalidades h_i^2 na matriz comum.

O posto da estrutura comum é limitado pelo número de fatores. Como

$$\text{posto}(\Phi\Phi^\top) \leq m,$$

a Análise Fatorial representa uma matriz de covariâncias de ordem $p \times p$ por uma parcela comum cujo posto é, no máximo, $m < p$.

Essa restrição de posto aplica-se apenas à parcela comum. A matriz total

$$\Sigma = \Sigma_{\text{com}} + \Psi$$

pode apresentar posto completo, pois a adição da matriz diagonal Ψ não preserva, em geral, o posto reduzido de Σ_{com} .

Esse ponto distingue novamente a Análise Fatorial da aproximação de posto reduzido utilizada na ACP. Uma aproximação espectral truncada de Σ produz diretamente uma matriz de posto

reduzido. No modelo fatorial, a parcela comum possui posto reduzido, enquanto Ψ mantém separadamente a variância específica de cada variável.

A Figura 15.3 representa a decomposição de uma matriz de covariâncias em sua parcela comum e sua parcela específica.




Figura 15.3: Decomposição de uma matriz de covariâncias em parcela comum, produzida pelas cargas fatoriais, e parcela específica diagonal.

A matriz comum contém as covariâncias entre variáveis distintas e, em sua diagonal, as communalidades. A matriz específica é diagonal e contém as variâncias específicas ψ_i . A soma dessas duas parcelas é a matriz de covariâncias Σ especificada pelo modelo.

15.9 Identificação do modelo fatorial

A equação

$$\Sigma = \Phi\Phi^\top + \Psi$$

não implica uma parametrização única em termos de Φ e Ψ .

Na formulação de segunda ordem, a identificação diz respeito aos parâmetros ou estruturas associados a Φ e Ψ que são determinados de forma única por Σ . Se o vetor observado for modelado por uma distribuição normal multivariada, sua distribuição será determinada por μ e Σ , de modo que a identificação dos parâmetros de covariância continuará dependente da decomposição de Σ . Essa formulação probabilística é desenvolvida na Seção 15.14.3.

Antes da imposição de restrições de parametrização, escala, sinal e orientação dos eixos fatoriais não são determinados pela representação latente. No modelo ortogonal adotado neste capítulo, a condição $\text{Cov}(\mathbf{F}) = \mathbf{I}_m$ fixa a escala dos fatores, enquanto permanecem as indeterminações de sinal e de orientação.

15.9.1 Escala dos fatores

Considere, inicialmente, um único fator:

$$\mathbf{X} = \mu + \Phi F + \varepsilon.$$

Para qualquer constante não nula c ,

$$\Phi F = (c\Phi) \left(\frac{F}{c} \right).$$

Logo, sem uma restrição adicional, a escala do vetor de cargas e a escala do fator podem ser modificadas inversamente sem alterar a parcela comum do modelo.

No modelo ortogonal padronizado, a condição

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m$$

fixa a variância de cada fator e remove essa indeterminação de escala.

15.9.2 Indeterminação do sinal

Se uma coluna de Φ e o fator correspondente tiverem seus sinais invertidos simultaneamente, o produto permanece inalterado.

Para o fator F_j ,

$$\phi_{.j} F_j = (-\phi_{.j}) (-F_j).$$

Portanto, o sinal de um fator não é determinado pelo modelo.

Essa propriedade é análoga à indeterminação de sinal dos autovetores na ACP. No modelo fatorial, a inversão simultânea do sinal de uma coluna de Φ e do fator correspondente preserva o produto $\Phi\mathbf{F}$ e, portanto, a distribuição observável especificada pelo modelo.

A ordem dos fatores também não é determinada pelo modelo. Permutar simultaneamente as colunas de Φ e os componentes correspondentes de $\mathbf{F}$ apenas modifica os rótulos atribuídos aos fatores, sem alterar a parcela comum nem a matriz de covariâncias especificada.

15.9.3 Indeterminação rotacional

Quando

$$m \geq 2,$$

existem transformações ortogonais que modificam conjuntamente a orientação dos eixos fatoriais sem alterar a estrutura comum de covariâncias.

Assim, a matriz de covariâncias não determina uma orientação única para os eixos fatoriais.

A invariância da estrutura comum sob essas transformações é demonstrada na Seção 15.14.1.

15.10 Rotação dos eixos fatoriais

A rotação modifica as coordenadas das cargas em relação aos eixos fatoriais. Uma rotação ortogonal preserva a matriz de covariâncias da parcela comum e, mantendo Ψ , preserva também a matriz de covariâncias especificada pelo modelo.

A Figura 15.4 compara uma matriz de cargas com uma solução obtida por uma rotação ortogonal. Para fins ilustrativos, aplica-se uma transformação ortogonal correspondente a uma rotação de 35° . Esse valor não corresponde a um critério específico de rotação: em uma aplicação, a orientação é determinada pelo critério adotado. Os vetores mudam de coordenadas em relação aos eixos, mas seus comprimentos e produtos internos são preservados.

A rotação ortogonal altera as cargas individuais, mas preserva as comunalidades e a matriz de covariâncias da parcela comum. Em consequência, preserva também a soma das comunalidades, enquanto as somas de quadrados das cargas associadas a cada fator podem mudar.

As demonstrações dessas propriedades são apresentadas na Seção 15.14.2.

Assim, os fatores rotacionados não possuem uma ordenação intrínseca por variância comparável à ordenação das componentes principais.

A estimação e a rotação cumprem funções distintas. A estimação obtém uma solução fatorial segundo determinado critério; a rotação transforma as cargas dessa solução sem constituir um novo método de estimação. Seu objetivo é favorecer uma **estrutura simples**, na qual cada variável apresente cargas concentradas em poucos fatores e cargas pequenas nos demais.




Figura 15.4: Uma rotação ortogonal modifica as coordenadas das cargas, mas preserva comprimentos, produtos internos, communalidades e a matriz de covariâncias da parcela comum.

15.10.1 Rotações ortogonais

Nas rotações ortogonais, os fatores permanecem não correlacionados. Em uma solução com dois fatores, a transformação pode ser visualizada como uma rotação dos eixos por determinado ângulo θ . Esse ângulo não é fixado previamente: a orientação resulta do critério de rotação adotado. Os eixos permanecem perpendiculares entre si, formando 90° . Com mais de dois fatores, uma transformação ortogonal não é descrita, em geral, por um único ângulo.

Diferentes critérios podem selecionar orientações ortogonais distintas que favoreçam uma estrutura simples. Em todas elas, os fatores permanecem não correlacionados e a matriz de covariâncias da parcela comum permanece inalterada. Alguns critérios específicos são apresentados na Seção 15.15.6.

15.10.2 Rotações oblíquas

A hipótese de fatores não correlacionados pode ser excessivamente restritiva. Quando não há razão para impor covariâncias nulas entre os fatores, podem ser utilizadas **rotações oblíquas**.

Um **modelo com fatores correlacionados** e uma **rotação oblíqua** são conceitos relacionados, mas distintos. O primeiro admite uma matriz de covariâncias fatoriais diferente da identidade. A rotação oblíqua é uma transformação não ortogonal aplicada a uma solução fatorial; na representação resultante, os fatores podem ser correlacionados e sua matriz de covariâncias passa a integrar explicitamente a estrutura comum.

Denote por

$$\Omega = \text{Cov}(\mathbf{F})$$

a matriz de covariâncias dos fatores. Quando os fatores possuem variâncias unitárias,

$$\text{diag}(\Omega) = \mathbf{1},$$

e Ω é a matriz de correlações fatoriais.

No modelo ortogonal,

$$\Omega = \mathbf{I}_m,$$

enquanto, em uma solução oblíqua,

$$\Omega \neq \mathbf{I}_m$$

em geral.

Na extensão oblíqua do modelo de fatores comuns, mantêm-se

$$\text{Cov}(\varepsilon) = \Psi$$

e

$$\text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0}.$$

Sob essas condições, a matriz de covariâncias das variáveis é

$$\Sigma = \Phi\Omega\Phi^\top + \Psi. \quad (15.13)$$

A parcela comum é, portanto,

$$\Sigma_{\text{com}} = \Phi\Omega\Phi^\top.$$

Consequentemente, na solução oblíqua a comunalidade da variável i corresponde ao i -ésimo elemento diagonal dessa matriz:

$$h_i^2 = (\Phi\Omega\Phi^\top)_{ii}.$$

Quando $\Omega = \mathbf{I}_m$, recupera-se o resultado do modelo ortogonal,

$$h_i^2 = \sum_{j=1}^m \phi_{ij}^2.$$

A matriz Φ contém os coeficientes que relacionam diretamente os fatores às variáveis no modelo e, em uma solução oblíqua, é denominada **matriz de padrão fatorial** (Hair et al., 2009).

A covariância entre as variáveis observadas e os fatores é

$$\text{Cov}(\mathbf{X}, \mathbf{F}) = \Phi\Omega.$$

Denotando

$$\Phi_\Omega = \Phi\Omega, \tag{15.14}$$

obtém-se a **matriz de estrutura fatorial**. Quando variáveis e fatores possuem variâncias unitárias, seus elementos correspondem às correlações entre as variáveis observadas e os fatores (Hair et al., 2009).

Assim, em uma solução oblíqua devem ser distinguidos três objetos:

- a **matriz de padrão fatorial** Φ , formada pelos coeficientes do modelo;
- a **matriz de correlações fatoriais** Ω ;
- a **matriz de estrutura fatorial** $\Phi_\Omega = \Phi\Omega$, cujos elementos, sob padronização, são as correlações entre variáveis e fatores.

No caso ortogonal,

$$\Omega = \mathbf{I}_m,$$

de modo que

$$\Phi_\Omega = \Phi.$$

Por isso, a distinção entre matriz de padrão fatorial e matriz de estrutura fatorial desaparece quando os fatores são ortogonais.

Diferentes critérios também podem ser utilizados para selecionar uma orientação oblíqua. Alguns deles são apresentados na Seção 15.15.6.

A escolha entre rotação ortogonal e oblíqua define a estrutura permitida para as correlações entre os fatores. Na solução ortogonal, essas correlações são fixadas em zero. Na solução oblíqua, elas podem ser diferentes de zero.

A escolha entre rotação ortogonal e oblíqua deve considerar se é substantivamente justificável impor correlações nulas entre os fatores. O padrão observado das cargas, isoladamente, não determina essa escolha.

A avaliação da matriz de correlações antes da estimação fatorial é tratada na Seção 15.15.1.

15.11 Formulação populacional e amostral

No nível populacional, o modelo fatorial especifica uma estrutura para a matriz de covariâncias. No modelo ortogonal,

$$\Sigma = \Phi\Phi^{\top} + \Psi.$$

Os elementos de Φ e as variâncias específicas de Ψ compõem a parametrização populacional da estrutura de covariâncias.

15.11.1 O problema de estimação

No nível amostral, a matriz de covariâncias ou de correlações observada fornece a informação utilizada para estimar a estrutura fatorial. Diferentes métodos utilizam critérios distintos para obter estimativas dessa estrutura (Johnson; Wichern, 2002).

O método de fatores principais utiliza uma construção espectral baseada em uma matriz reduzida, cuja diagonal contém comunalidades estimadas. Outros métodos definem a estimação por meio de uma função de discrepância entre a matriz observada e a matriz reproduzida pelo modelo.

Para uma análise baseada em covariâncias, essa segunda classe pode ser representada genericamente por

$$\min_{\theta} d[\mathbf{S}, \Sigma(\theta)], \quad (15.15)$$

em que θ reúne os parâmetros livres do modelo e

$$\Sigma(\theta) = \Phi\Phi^{\top} + \Psi$$

é a matriz de covariâncias implicada pelo modelo para um determinado valor de θ .

A função

$$d[\mathbf{S}, \Sigma(\theta)]$$

associa à matriz amostral $\mathbf{S}$ e à matriz implicada pelo modelo $\Sigma(\theta)$ um valor numérico de discrepância. Para a amostra observada, a estimação é realizada sobre os valores admissíveis de θ . Um valor minimizante $\hat{\theta}$ constitui uma estimativa dos parâmetros livres na parametrização adotada, e $\Sigma(\hat{\theta})$ é a matriz de covariâncias implicada pela solução ajustada. A distinção entre estimador e estimativa segue a Definição 10.4.

Quando a análise é baseada em correlações, o critério compara a matriz amostral $\mathbf{R}$ com a matriz de correlações implicada pelo modelo para as variáveis padronizadas.

O critério de estimação compara a estrutura de segunda ordem observada com aquela implicada pelo modelo. No caso ortogonal, transformações das cargas que preservam $\Phi\Phi^\top$ produzem o mesmo ajuste da estrutura de covariâncias e, portanto, o critério não distingue essas orientações. A rotação tratada na Seção 15.10 seleciona uma representação das cargas para interpretação.

Neste capítulo são considerados três métodos para obter uma solução fatorial. O método de **fatores principais** utiliza a decomposição espectral de uma matriz reduzida cuja diagonal contém comunalidades estimadas. O método de **mínimos resíduos** (MINRES) estima a estrutura fatorial pela minimização de um critério de discrepância entre associações observadas e implicadas pelo modelo. Sob normalidade multivariada, a **máxima verossimilhança** estima os parâmetros a partir da função de verossimilhança do modelo probabilístico.

Os métodos de fatores principais e mínimos resíduos são desenvolvidos na Seção 15.15.3. A máxima verossimilhança é desenvolvida na Seção 15.14.3.

15.11.2 Escores fatoriais

Os fatores comuns aparecem no modelo como variáveis latentes,

F.

Eles não são observados diretamente. Essa situação difere da ACP, em que o escore definido na Definição 14.1 é obtido pela projeção da observação sobre uma direção principal determinada pela solução.

Na Análise Fatorial, é necessário acrescentar um critério para relacionar uma observação aos fatores latentes. Esse é o **problema dos escores fatoriais** (Johnson; Wichern, 2002).

Considere uma observação

$$\mathbf{x} \in \mathbb{R}^p.$$

Depois que uma solução fatorial é especificada ou ajustada, pode-se calcular, a partir de $\mathbf{x}$, um valor associado a cada fator. Dependendo do tratamento dos fatores e do critério adotado, esse valor é interpretado como estimativa ou predição da realização latente dos fatores e é denominado **escore fatorial**.

Definição 15.6 (Escore fatorial). Um **escore fatorial** é um vetor calculado a partir das variáveis observadas e de uma solução fatorial para estimar ou prever a realização dos fatores associada a uma unidade. Quando os fatores são tratados como aleatórios, o escore possui interpretação probabilística como predição de sua realização.

A Tabela 15.2 sintetiza as funções distintas desempenhadas pelos fatores, pelas cargas e pelos escores fatoriais.

Tabela 15.2: Distinção entre fatores, cargas e escores fatoriais.

Objeto	Natureza
$\mathbf{F}$	Vetor aleatório latente especificado pelo modelo
Φ	Matriz de parâmetros que relaciona fatores e variáveis
$\mathbf{f}_i$	Realização latente dos fatores associada à unidade i , não diretamente observada
$\hat{\mathbf{f}}_i$	Escore utilizado para estimar ou prever $\mathbf{f}_i$

As cargas fatoriais são parâmetros da estrutura do modelo, enquanto os escores são quantidades associadas às unidades observacionais.

Mesmo com uma solução fatorial fixada, em geral a observação não determina univocamente a realização latente dos fatores, pois o modelo inclui também a parcela específica. A obtenção de $\hat{\mathbf{f}}_i$ exige, portanto, um critério adicional de estimação ou predição, e critérios distintos podem produzir escores diferentes para a mesma unidade (Johnson; Wichern, 2002).

Os escores dependem da orientação adotada para os fatores. Quando a solução fatorial é transformada, os escores correspondentes devem ser expressos na mesma parametrização. Em uma rotação ortogonal $\Phi^* = \Phi\mathbf{Q}$, por exemplo, as coordenadas fatoriais transformam-se por $\mathbf{f}_i^* = \mathbf{Q}^\top \mathbf{f}_i$. Assim, os valores dos escores são interpretados em relação à orientação da solução correspondente.

A interpretação probabilística do escore por regressão é desenvolvida na Seção 15.14.5. Outros métodos são apresentados na Seção 15.15.9.

15.12 Pressupostos e limites do modelo

Os aspectos que condicionam a Análise Fatorial possuem funções diferentes. Alguns definem o modelo de fatores comuns. Outros correspondem a restrições dos parâmetros, condições de identificação, escolhas de especificação ou hipóteses necessárias para procedimentos probabilísticos específicos.

A Tabela 15.3 organiza essas diferenças.

Tabela 15.3: Pressupostos, condições e limites da formulação fatorial.

Aspecto	Natureza	Papel na formulação
Forma linear do modelo	Hipótese definidora	A parcela comum e a parcela específica entram linearmente na representação $\mathbf{X} - \mu = \Phi \mathbf{F} + \varepsilon$
Estrutura comum de dimensão m	Especificação estrutural	A parcela comum da matriz de covariâncias é representada por $m < p$ fatores
Diagonalidade de Ψ	Hipótese definidora	Fatores específicos associados a variáveis distintas possuem covariância nula
Não correlação entre fatores comuns e específicos	Hipótese definidora	Separa, em termos de covariância, as parcelas comum e específica
Identificação	Condição do modelo	Determina quais aspectos de Φ e Ψ são definidos univocamente por Σ sob a parametrização e as restrições adotadas
Admissibilidade	Restrição paramétrica	As variâncias específicas devem satisfazer $\psi_i \geq 0$; soluções que violem essa restrição não são admissíveis no modelo fatorial básico
Normalidade	Hipótese probabilística adicional	Não é necessária para a estrutura de segunda ordem; integra o modelo fatorial normal e sustenta a máxima verossimilhança normal e os resultados inferenciais que dependem dessa formulação

Aspecto	Natureza	Papel na formulação
Amostragem para inferência	Condição inferencial	Os resultados amostrais clássicos requerem condições sobre o mecanismo de amostragem; na formulação normal utilizada para máxima verossimilhança, considera-se uma amostra aleatória da população especificada
Número de fatores	Escolha de especificação	Determina a dimensão da estrutura comum e a classe de matrizes de covariâncias representáveis
Conjunto de variáveis	Dependência conceitual	A estrutura fatorial e sua interpretação são definidas em relação às variáveis incluídas na análise
Escala das variáveis	Dependência da análise	Alterações de escala modificam a matriz de covariâncias; trabalhar com a matriz de correlações corresponde a modelar as variáveis padronizadas

A tabela distingue propriedades do próprio modelo de condições necessárias apenas a procedimentos específicos. Em particular, tamanho amostral, composição da amostra e adequação da matriz de correlações influenciam a qualidade e a estabilidade da análise, mas não constituem hipóteses definidoras da decomposição fatorial. Hair et al. (Hair et al., 2009) destacam que, na Análise Fatorial, as premissas conceituais relacionadas ao conjunto de variáveis e à amostra assumem papel central.

15.12.1 Número de fatores

O número m determina a dimensão máxima da estrutura comum e a classe de matrizes de covariâncias que o modelo pode representar. Diminuir m restringe o posto de $\Phi\Phi^\top$ e a classe de estruturas comuns representáveis; aumentar m amplia essa classe.

Um número insuficiente de fatores pode deixar padrões sistemáticos de covariância sem representação pela parcela comum. Um número excessivo reduz a parcimônia e pode dificultar a interpretação da solução (Hair et al., 2009).

15.12.2 Dependência do conjunto de variáveis

A estrutura fatorial é definida em relação ao conjunto de variáveis incluído na análise. Adicionar ou retirar variáveis modifica a matriz de covariâncias ou correlações e pode alterar as cargas, as communalidades, o número de fatores retidos e sua interpretação. Por isso, a seleção das variáveis deve ser justificada pelo problema substantivo e pelas relações que se pretende representar (Hair et al., 2009).

As restrições matemáticas utilizadas para identificar uma solução não atribuem significado substantivo aos fatores. A interpretação é construída a partir do padrão de cargas (Anderson, 2003) e do significado das variáveis incluídas na análise.

15.12.3 Dependência da escala das variáveis

Uma análise baseada na matriz de covariâncias depende das unidades de medida. Se

$$\mathbf{X}^* = \mathbf{D}\mathbf{X},$$

para uma matriz diagonal $\mathbf{D}$ com elementos positivos, então a matriz de covariâncias e os parâmetros fatoriais são modificados de forma correspondente (Anderson, 2003).

A utilização da matriz de correlações remove essas diferenças marginais de escala antes do ajuste, mas passa a definir a estrutura fatorial das variáveis padronizadas. Portanto, fatorar $\mathbf{S}$ e fatorar $\mathbf{R}$ correspondem a problemas relacionados, mas não idênticos. A mesma distinção entre covariâncias e correlações foi desenvolvida para a ACP na Seção 14.10.

15.12.4 Papel da normalidade

A decomposição

$$\Sigma = \Phi\Phi^\top + \Psi$$

é uma estrutura de segunda ordem e não exige normalidade multivariada.

A normalidade é uma hipótese probabilística adicional ao modelo de segunda ordem. Quando fatores comuns e específicos são especificados como normais, o vetor observado possui distribuição normal multivariada, o que permite desenvolver a máxima verossimilhança normal, a distribuição condicional dos fatores e os resultados inferenciais correspondentes (Anderson, 2003).

Na análise amostral clássica por máxima verossimilhança, considera-se ainda uma amostra aleatória dessa população. Essas condições pertencem à formulação probabilística e aos procedimentos inferenciais; elas não são necessárias para definir a decomposição de segunda ordem $\Sigma = \Phi\Phi^\top + \Psi$. A formulação normal é desenvolvida na Seção 15.14.3.

15.12.5 Limites da interpretação

A obtenção de uma solução fatorial não determina, por si só, o significado substantivo dos fatores. Diferentes orientações equivalentes podem representar a mesma estrutura comum, e as restrições utilizadas para identificar a solução não conferem significado intrínseco aos eixos fatoriais (Anderson, 2003). A interpretação deve ser construída a partir do padrão de cargas e do significado das variáveis incluídas na análise (Hair et al., 2009).

Uma solução obtida em uma amostra também não estabelece, por si só, que a mesma estrutura será reproduzida em outras amostras ou populações. A estabilidade da solução deve ser examinada por procedimentos de validação, como a comparação entre subamostras ou com novas amostras quando disponíveis (Hair et al., 2009).

15.13 Análise Fatorial e Análise de Componentes Principais

A Análise de Componentes Principais, formulada no Capítulo 14, e a Análise Fatorial resolvem problemas estatísticos distintos. A ACP constrói componentes como combinações lineares das variáveis observadas e as ordena segundo a variância representada em cada direção. A Análise Fatorial especifica um modelo com variáveis latentes para representar a estrutura de covariâncias entre as variáveis observadas (Anderson, 2003).

Em termos de variabilidade, a ACP trabalha com a variância total contida na matriz analisada, enquanto, no modelo de fatores comuns, os fatores representam a parcela comum da variabilidade e a parcela específica é representada separadamente por Ψ (Hair et al., 2009).

As duas técnicas podem utilizar matrizes de covariâncias ou de correlações, e decomposições espectrais aparecem em algumas de suas formulações. Essas semelhanças algébricas não tornam equivalentes os objetos estatísticos representados.

Na ACP,

$$\Sigma = \mathbf{A}\mathbf{\Lambda}\mathbf{A}^\top,$$

em que as colunas de $\mathbf{A}$ são os autovetores unitários $\alpha_1, \dots, \alpha_p$ e os elementos diagonais de $\mathbf{\Lambda}$ são os autovalores.

No modelo fatorial ortogonal,

$$\Sigma = \Phi\Phi^\top + \Psi.$$

A Tabela 15.4 reúne as diferenças principais.

Tabela 15.4: Diferenças matemáticas e estatísticas entre ACP e Análise Fatorial.

Aspecto	ACP	Análise Fatorial
Problema	Reduzir a dimensão preservando a maior variância possível nas componentes retidas	Modelar as covariâncias por fatores latentes e variâncias específicas
Objeto populacional	Σ ou $\mathcal{R}$	Σ ou $\mathcal{R}$
Estrutura definidora	Decomposição espectral da matriz analisada	Modelo de fatores comuns
Formulação ortogonal	$\Sigma = \mathbf{A}\mathbf{A}\mathbf{A}^\top$	$\Sigma = \Phi\Phi^\top + \Psi$
Papel da variabilidade	As componentes decompõem e ordenam a variância total da matriz analisada	Os fatores representam a variância comum, enquanto a variância específica é representada separadamente por Ψ
Objetos de menor dimensão	Componentes construídas como combinações lineares das variáveis observadas	Fatores latentes especificados pelo modelo
Coeficientes	Os autovetores α_j definem os coeficientes das combinações lineares	As cargas ϕ_{ij} são parâmetros que relacionam as variáveis observadas aos fatores comuns
Escores	Uma vez fixadas as direções, são as coordenadas obtidas pela projeção das observações	São estimativas ou predições das realizações fatoriais não observadas e dependem do método de obtenção dos escores
Rotação	Uma rotação geral das componentes retidas preserva o subespaço, mas em geral elimina a ordenação e a propriedade de variância máxima que definem as componentes principais	A indeterminação rotacional permite selecionar representações equivalentes da estrutura comum para facilitar a interpretação

Aspecto	ACP	Análise Fatorial
Não unicidade	Sinal; com autovalores repetidos, bases dos autoespaços e, quando o corte atravessa um autovalor múltiplo, o subespaço truncado	Após fixada a escala, sinal, permutação e orientação rotacional; a identificação pode exigir restrições adicionais
Normalidade	Não necessária para definir a técnica	Não necessária para o modelo de segunda ordem; adicionada na formulação probabilística normal e nos procedimentos que dependem dessa hipótese

A expressão **variância comum** possui um significado específico no modelo fatorial. Para a variável X_i ,

$$\sigma_{ii} = h_i^2 + \psi_i,$$

em que

$$h_i^2 = \sum_{j=1}^m \phi_{ij}^2$$

é a comunalidade no modelo ortogonal e ψ_i é a variância específica. Quando as variáveis são padronizadas,

$$1 = h_i^2 + \psi_i.$$

Assim, no modelo ortogonal padronizado, h_i^2 é a parcela da variância de X_i atribuída aos fatores comuns, enquanto ψ_i é sua variância específica.

A presença de autovalores e autovetores em alguns métodos de estimação fatorial não torna esses procedimentos equivalentes à ACP. Na ACP, os autovetores da matriz analisada definem as próprias direções principais e os autovalores são as variâncias das componentes correspondentes. Na Análise Fatorial, decomposições espectrais podem ser utilizadas como instrumentos de estimação da estrutura comum, que permanece inserida no modelo

$$\Sigma = \Phi\Phi^\top + \Psi.$$

No método de fatores principais, por exemplo, a decomposição espectral é aplicada a uma matriz reduzida cuja diagonal contém estimativas das comunalidades, e não necessariamente à matriz de correlações original. Portanto, as raízes utilizadas nesse procedimento não possuem automaticamente a mesma interpretação dos autovalores da ACP (Johnson; Wichern, 2002).

A parcela

$$\Phi\Phi^\top$$

é a matriz de covariâncias da parcela comum, enquanto a matriz diagonal Ψ contém as variâncias específicas das variáveis.

Neste capítulo, o modelo de fatores comuns é estudado no contexto da **Análise Fatorial Exploratória**, em que a estrutura das cargas não é completamente especificada antes do ajuste. A Análise Fatorial Confirmatória, em que restrições sobre a estrutura fatorial são especificadas previamente a partir de um modelo de mensuração, não integra o escopo deste capítulo (Hair et al., 2009).

A função da rotação também difere entre as técnicas. Na Análise Fatorial, a não unicidade da orientação dos fatores permite selecionar uma representação equivalente da estrutura comum para facilitar a interpretação. Na ACP clássica, as direções principais são definidas pela otimização sucessiva da variância e pelos autovetores da matriz analisada. Uma rotação arbitrária das componentes retidas pode preservar o subespaço representado, mas, em geral, as novas direções deixam de ser as componentes principais ordenadas pelas respectivas variâncias.

15.14 Aprofundamentos teóricos

Leitura de aprofundamento

Esta parte reúne desenvolvimentos sobre identificação e indeterminação do modelo, invariâncias da rotação ortogonal, formulação probabilística normal, máxima verossimilhança, distribuições associadas à avaliação da matriz de correlações e distribuição condicional dos fatores.

15.14.1 Contagem de parâmetros e identificação

No modelo ortogonal adotado neste capítulo, a condição

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m$$

fixa a escala dos fatores, mas não determina uma orientação única dos eixos fatoriais. Diferentes matrizes de cargas relacionadas por transformações ortogonais podem representar a mesma estrutura de covariâncias (Anderson, 2003). Inversões de sinal e permutações dos fatores são casos particulares dessas transformações.

A contagem de parâmetros apresentada nesta seção fornece uma condição necessária de compatibilidade dimensional entre a parametrização e os elementos distintos de Σ em pontos regulares. Ela não constitui, isoladamente, uma condição suficiente de identificação.

15.14.1.1 Desenvolvimento matricial da indeterminação rotacional

A não unicidade da orientação dos fatores pode ser estabelecida formalmente por transformações da matriz de cargas e do vetor de fatores (Anderson, 2003).

Quando

$$m \geq 2,$$

a indeterminação da orientação inclui uma família contínua de transformações ortogonais.

Considere uma matriz ortogonal

$$\mathbf{Q} \in \mathbb{R}^{m \times m},$$

definida na Definição 2.15, de modo que

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{Q} \mathbf{Q}^\top = \mathbf{I}_m.$$

Defina

$$\Phi^* = \Phi \mathbf{Q}$$

e

$$\mathbf{F}^* = \mathbf{Q}^\top \mathbf{F}.$$

Então,

$$\begin{aligned} \Phi^* \mathbf{F}^* &= \Phi \mathbf{Q} \mathbf{Q}^\top \mathbf{F} \\ &= \Phi \mathbf{F}. \end{aligned}$$

Além disso,

$$\begin{aligned}\text{Cov}(\mathbf{F}^*) &= \mathbf{Q}^\top \text{Cov}(\mathbf{F}) \mathbf{Q} \\ &= \mathbf{Q}^\top \mathbf{Q} \\ &= \mathbf{I}_m.\end{aligned}$$

Os fatores transformados permanecem padronizados e mutuamente não correlacionados.

Para a matriz de covariâncias da parcela comum,

$$\begin{aligned}\Phi^* \Phi^{*\top} &= \Phi \mathbf{Q} \mathbf{Q}^\top \Phi^\top \\ &= \Phi \Phi^\top.\end{aligned}$$

Portanto,

$$\Phi^* \Phi^{*\top} = \Phi \Phi^\top. \quad (15.16)$$

Proposição 15.2 (Indeterminação rotacional do modelo fatorial ortogonal). *Considere um modelo fatorial ortogonal com*

$$\Phi \in \mathbb{R}^{p \times m}$$

e seja

$$\mathbf{Q} \in \mathbb{R}^{m \times m}$$

qualquer matriz ortogonal. Então a matriz de cargas

$$\Phi^* = \Phi \mathbf{Q}$$

produz a mesma matriz de covariâncias da parcela comum:

$$\Phi^* \Phi^{*\top} = \Phi \Phi^\top.$$

Além disso, com

$$\mathbf{F}^* = \mathbf{Q}^\top \mathbf{F},$$

a parcela comum do modelo é preservada e

$$\text{Cov}(\mathbf{F}^*) = \mathbf{I}_m.$$

Assim, a estrutura de covariâncias do modelo não determina uma orientação ortogonal única para os fatores.

A invariância na Equação 15.16 utiliza diretamente a preservação do produto interno estabelecida no Teorema 2.6.

A Proposição 15.2 demonstra a não unicidade da orientação dos fatores: transformações ortogonais de Φ preservam $\Phi\Phi^\top$. Essa invariância não implica, entretanto, que $\Phi\Phi^\top$ e Ψ sejam identificáveis de forma única a partir de Σ ; essa questão depende de condições adicionais de identificação.

15.14.1.2 Contagem de parâmetros

A matriz simétrica Σ possui

$$\frac{p(p+1)}{2}$$

elementos distintos.

No modelo ortogonal com m fatores, a matriz de cargas possui

$$pm$$

elementos e a matriz diagonal Ψ possui

$$p$$

variâncias específicas.

Uma contagem direta produz

$$pm + p$$

parâmetros. Essa parametrização contém diferentes matrizes de cargas relacionadas por transformações ortogonais que representam a mesma matriz de covariâncias.

Em um ponto regular com

$$\text{posto}(\Phi) = m,$$

as transformações ortogonais possuem

$$\frac{m(m-1)}{2}$$

graus de liberdade contínuos. Inversões de sinal e permutações das colunas de Φ também produzem representações equivalentes. Essas transformações constituem indeterminações discretas e, portanto, não alteram a dimensão local da parametrização.

Descontando os graus de liberdade contínuos associados à indeterminação rotacional, obtém-se a contagem dimensional

$$pm + p - \frac{m(m-1)}{2}. \quad (15.17)$$

Uma condição necessária de contagem é, portanto,

$$pm + p - \frac{m(m-1)}{2} \leq \frac{p(p+1)}{2}. \quad (15.18)$$

Essa desigualdade compara o número de elementos distintos de Σ com a contagem dimensional da parametrização após descontar a indeterminação rotacional. Ela é uma condição necessária de contagem em pontos regulares.

Sob regularidade e identificação local, a diferença entre o número de elementos distintos de Σ e essa contagem dimensional corresponde ao número de restrições independentes utilizado nos graus de liberdade do teste de ajuste por máxima verossimilhança, definidos na Equação 15.24.

A contagem de parâmetros não garante identificação

Satisfazer a condição de contagem da Equação 15.18 não garante identificação do modelo. A identificação depende também da estrutura das cargas, das restrições impostas e da posição do parâmetro no espaço paramétrico.

Uma parametrização identificada exige restrições que eliminem as representações equivalentes relevantes para o problema considerado. Essas restrições podem atuar sobre as cargas ou sobre a orientação dos fatores (Anderson, 2003).

Na estimação por máxima verossimilhança do modelo ortogonal, quando

$$\Psi \succ \mathbf{0},$$

uma condição computacional clássica consiste em selecionar uma orientação para a qual

$$\Phi^T \Psi^{-1} \Phi$$

seja diagonal (Johnson; Wichern, 2002). Essa restrição seleciona uma orientação para fins de estimação. Ela não atribui significado substantivo aos eixos fatoriais; após a estimação, uma transformação equivalente pode ser escolhida para facilitar a interpretação (Anderson, 2003).

Na Análise Fatorial Exploratória, esse tipo de restrição permite obter uma parametrização inicial antes da rotação. Na Análise Fatorial Confirmatória, restrições sobre a estrutura das cargas são especificadas previamente e participam diretamente da identificação do modelo.

As condições algébricas de identificação dependem da estrutura imposta ao modelo e das restrições adotadas na parametrização.

Duas formas distintas de não unicidade

A **indeterminação rotacional** tratada nesta seção refere-se à existência de parametrizações equivalentes da estrutura fatorial: diferentes orientações de Φ e dos fatores podem produzir a mesma matriz de covariâncias observável.

Esse problema é distinto da **indeterminação dos escores fatoriais**. Mesmo depois de escolhida uma orientação e fixados os parâmetros do modelo, os fatores de uma unidade não são, em geral, determinados exatamente pelo vetor observado. Sob o modelo fatorial normal, essa incerteza é representada pela distribuição condicional de $\mathbf{F} \mid \mathbf{X}$, desenvolvida na Seção 15.14.5.

15.14.2 Invariâncias da rotação ortogonal

Considere a matriz de cargas rotacionada

$$\Phi^* = \Phi \mathbf{Q},$$

com $\mathbf{Q}$ ortogonal.

Para a variável i , a linha correspondente da matriz rotacionada é

$$\phi_i^{*\top} = \phi_i^\top \mathbf{Q}.$$

A comunalidade permanece inalterada porque

$$\begin{aligned}\|\phi_i^*\|^2 &= \phi_i^\top \mathbf{Q} \mathbf{Q}^\top \phi_i \\ &= \|\phi_i\|^2.\end{aligned}$$

Para duas variáveis i e j ,

$$\begin{aligned}\phi_i^{*\top} \phi_j^* &= \phi_i^\top \mathbf{Q} \mathbf{Q}^\top \phi_j \\ &= \phi_i^\top \phi_j.\end{aligned}$$

As covariâncias comuns permanecem, portanto, inalteradas. Esse resultado é a versão elemento a elemento da invariância matricial estabelecida na Equação 15.16.

A variância comum total também é preservada:

$$\begin{aligned}\text{tr}(\Phi^* \Phi^{*\top}) &= \text{tr}(\Phi \Phi^\top) \\ &= \sum_{j=1}^m \|\phi_{\cdot j}\|^2.\end{aligned}$$

A soma dos quadrados das cargas associadas a um fator pode mudar após a rotação. Em geral,

$$\sum_{i=1}^p \phi_{ij}^{*2} \neq \sum_{i=1}^p \phi_{ij}^2.$$

Assim, a rotação preserva $\Phi \Phi^\top$ e a soma das communalidades, mas pode alterar as somas de quadrados das cargas atribuídas a cada fator.

15.14.3 Formulação probabilística normal

A estrutura de segunda ordem não exige normalidade. No modelo fatorial normal, fatores comuns e específicos são especificados como normais, o que induz uma distribuição normal para o vetor observado e permite desenvolver estimação por máxima verossimilhança e inferência associada (Anderson, 2003).

Definição 15.7 (Modelo fatorial normal). Considere o modelo fatorial ortogonal definido na Definição 15.2.

O modelo é denominado **fatorial normal ortogonal** quando

$$\mathbf{F} \sim N_m(\mathbf{0}, \mathbf{I}_m),$$

$$\varepsilon \sim N_p(\mathbf{0}, \Psi),$$

e

$$\mathbf{F} \perp \varepsilon.$$

O vetor aleatório observado é

$$\mathbf{X} = \mu + \Phi \mathbf{F} + \varepsilon.$$

A Definição 9.1 admite matrizes de covariâncias singulares. Assim, a distribuição de ε permanece bem definida quando alguma especificidade ψ_i é nula.

Como $\mathbf{F}$ e ε são vetores normais independentes, sua distribuição conjunta é normal. Pela estabilidade da normal multivariada sob transformações afins, estabelecida na Proposição 9.4,

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

com

$$\Sigma = \Phi \Phi^\top + \Psi. \quad (15.19)$$

Além disso, como ε é conjuntamente normal e Ψ é diagonal, os fatores específicos são independentes. Essa conclusão utiliza a propriedade de independência entre blocos normais estabelecida na Proposição 9.6.

A hipótese

$$\mathbf{F} \perp \varepsilon$$

também é mais forte do que a condição de covariância cruzada nula utilizada no modelo de segunda ordem.

Sob essa especificação probabilística, a função de verossimilhança da amostra depende de μ e da matriz de covariâncias

$$\Sigma = \Phi \Phi^\top + \Psi.$$

A estimação por máxima verossimilhança segue a Definição 10.8.

Sob o modelo fatorial normal, a máxima verossimilhança estima os parâmetros de uma parametrização identificada de modo que a matriz

$$\Sigma = \Phi\Phi^\top + \Psi$$

maximize a verossimilhança da amostra observada dentro da classe admitida pelo modelo. Diferentemente do método de fatores principais, o critério de estimação deriva da distribuição probabilística especificada e também conduz à comparação, por razão de verossimilhanças, entre o modelo fatorial e o modelo normal de covariâncias sem restrições estruturais.

15.14.3.1 Estimação por máxima verossimilhança e ajuste global

Seja Θ_{fat} o espaço paramétrico admissível de uma parametrização identificada do modelo fatorial normal, com

$$\Sigma(\theta) = \Phi\Phi^\top + \Psi.$$

A forma de densidade normal utilizada nesta construção da verossimilhança envolve o determinante e a inversa da matriz de covariâncias e, portanto, requer uma matriz modelada positiva definida. Define-se

$$\Theta_{\text{fat}}^+ = \{\theta \in \Theta_{\text{fat}} : \Sigma(\theta) \succ \mathbf{0}\}. \quad (15.20)$$

Considere uma amostra

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p[\mu, \Sigma(\theta)].$$

A Proposição 10.1 fornece

$$\hat{\mu} = \bar{\mathbf{x}}.$$

Quando $\text{posto}(\mathbf{S}) = p$, a Proposição 10.1 garante que o máximo da verossimilhança do modelo normal irrestrito existe e que a estimativa da matriz de covariâncias é $\mathbf{S}_{\text{MV}}$. Pela Equação 10.57,

$$\mathbf{S}_{\text{MV}} = \frac{n-1}{n} \mathbf{S}. \quad (15.21)$$

A log-verossimilhança concentrada, desconsiderando termos constantes em relação a θ , é

$$\ell(\theta) = C - \frac{n}{2} \left\{ \log |\Sigma(\theta)| + \text{tr} [\mathbf{S}_{\text{MV}} \Sigma(\theta)^{-1}] \right\}. \quad (15.22)$$

Assim, a estimação por máxima verossimilhança equivale a minimizar

$$\log |\Sigma(\theta)| + \text{tr} [\mathbf{S}_{\text{MV}} \Sigma(\theta)^{-1}]$$

sobre Θ_{fat}^+ .

Quando

$$\mathbf{S}_{\text{MV}} \succ \mathbf{0},$$

pode-se utilizar a função de discrepância normalizada

$$F_{\text{ML}}(\theta) = \log |\Sigma(\theta)| + \text{tr} [\mathbf{S}_{\text{MV}} \Sigma(\theta)^{-1}] - \log |\mathbf{S}_{\text{MV}}| - p. \quad (15.23)$$

Essa função satisfaz

$$F_{\text{ML}} = 0$$

quando

$$\Sigma(\theta) = \mathbf{S}_{\text{MV}}.$$

Se $\mathbf{S}_{\text{MV}}$ é singular, a matriz $\mathbf{S}_{\text{MV}} = (n-1)\mathbf{S}/n$ continua definida e a log-verossimilhança na Equação 15.22 pode ser avaliada para matrizes modeladas positivas definidas. Nesse caso, porém, o modelo normal irrestrito com matriz de covariâncias positiva definida não possui estimativa de máxima verossimilhança, e a forma normalizada em Equação 15.23 e a comparação por razão de verossimilhanças com o modelo irrestrito não estão disponíveis na forma apresentada.

A maximização da verossimilhança fatorial não possui, em geral, solução explícita e requer procedimentos numéricos de otimização (Anderson, 2003).

15.14.3.2 Ajuste global e graus de liberdade

A formulação por máxima verossimilhança permite comparar o modelo fatorial com o modelo normal de covariâncias sem restrições estruturais.

Em um ponto regular de uma parametrização identificada do modelo fatorial ortogonal com m fatores, o número de restrições independentes é a diferença entre os

$$\frac{p(p+1)}{2}$$

parâmetros livres da matriz de covariâncias irrestrita e a contagem dimensional da parametrização após descontar a indeterminação rotacional, dada na Equação 15.17. Assim,

$$\begin{aligned}\nu_{\text{fat}} &= \frac{p(p+1)}{2} - pm - p + \frac{m(m-1)}{2} \\ &= \frac{1}{2} [(p-m)^2 - p - m].\end{aligned}\tag{15.24}$$

Para que o teste possua graus de liberdade positivos, é necessário que

$$\nu_{\text{fat}} > 0.$$

Essa condição é mais forte do que simplesmente admitir uma contagem de parâmetros não superior ao número de elementos distintos da matriz de covariâncias quando se deseja realizar o teste de ajuste (Johnson; Wichern, 2002).

Quando $\mathbf{S}_{\text{MV}} \succ \mathbf{0}$, a estatística da razão de verossimilhanças pode ser escrita como

$$-2 \log \Lambda_{\text{RV}} = n F_{\text{ML}}(\hat{\theta}_{\text{MV}}).\tag{15.25}$$

Sob identificação, solução populacional interior e as demais condições regulares do resultado assintótico de Wilks em Teorema 12.4, mantendo p e m fixos e fazendo

$$n \rightarrow \infty,$$

tem-se, se o modelo está corretamente especificado,

$$-2 \log \Lambda_{\text{RV}} \xrightarrow{d} \chi^2_{\nu_{\text{fat}}}.\tag{15.26}$$

Na solução interior de máxima verossimilhança do modelo fatorial, as equações de estimação implicam

$$\text{tr} \left[\mathbf{S}_{\text{MV}} \widehat{\Sigma}_{\text{fat}}^{-1} \right] = p.$$

Consequentemente,

$$F_{\text{ML}} \left(\hat{\theta}_{\text{MV}} \right) = \log \left| \widehat{\Sigma}_{\text{fat}} \right| - \log \left| \mathbf{S}_{\text{MV}} \right|.$$

Esse resultado permite escrever a estatística corrigida diretamente em termos de F_{ML} (Johnson; Wichern, 2002).

Uma correção de Bartlett pode ser utilizada para melhorar a aproximação qui-quadrado em amostras finitas. Na parametrização adotada aqui, a estatística corrigida pode ser escrita como

$$T_{\text{B,fat}} = \left[n - 1 - \frac{2p + 4m + 5}{6} \right] F_{\text{ML}} \left(\hat{\theta}_{\text{MV}} \right), \quad (15.27)$$

e é comparada, aproximadamente, com

$$\chi_{\nu_{\text{fat}}}^2,$$

sob as condições do modelo fatorial normal. Johnson e Wichern (Johnson; Wichern, 2002) apresentam essa aproximação para n e $n - p$ grandes.

Essa correção pertence ao **teste de ajuste do modelo fatorial por máxima verossimilhança**. Ela não deve ser confundida com o **teste de esfericidade de Bartlett**, apresentado na Seção 15.15.1, cuja hipótese nula é $\mathcal{R} = \mathbf{I}_p$.

A convergência na Equação 15.26 é assintótica, e a correção em Equação 15.27 procura melhorar essa aproximação sem torná-la exata em amostras finitas. O aumento de m amplia a classe de estruturas fatoriais representáveis e reduz os graus de liberdade enquanto $\nu_{\text{fat}} > 0$.

A escolha de m é discutida na Seção 15.15.4. Quando a máxima verossimilhança é utilizada, o teste de ajuste global fornece informação adicional sobre a adequação de uma estrutura com m fatores. A rejeição indica incompatibilidade entre essa estrutura fatorial e a matriz de covariâncias populacional sob as condições do modelo; a não rejeição não identifica, por si só, um número verdadeiro e único de fatores.

15.14.4 Distribuições associadas à avaliação da matriz de correlações

Os procedimentos utilizados na avaliação da matriz de correlações não possuem o mesmo status inferencial. Sob normalidade, correlações simples e parciais possuem resultados distribucionais próprios, enquanto MSA e KMO são índices descritivos construídos a partir de correlações simples e parciais. O teste de esfericidade de Bartlett, por sua vez, utiliza uma aproximação qui-quadrado para uma hipótese global sobre a matriz de correlações.

15.14.4.1 Correlação amostral

Considere uma amostra aleatória de tamanho $n > 2$ de uma distribuição normal bivariada com correlação populacional ρ_{ij} . Sob

$$H_0 : \rho_{ij} = 0,$$

vale o resultado exato

$$T_{ij} = \frac{r_{ij}\sqrt{n-2}}{\sqrt{1-r_{ij}^2}} \sim t_{n-2}. \quad (15.28)$$

Para ρ_{ij} não necessariamente nula, a transformação de Fisher fornece, em grandes amostras,

$$Z_{ij} = \operatorname{arctanh}(r_{ij}) \stackrel{\text{aprox}}{\sim} N\left[\operatorname{arctanh}(\rho_{ij}), \frac{1}{n-3}\right]. \quad (15.29)$$

Esses resultados referem-se a uma correlação isolada e não constituem testes de adequação global da matriz de correlações à Análise Fatorial (Anderson, 2003).

15.14.4.2 Correlação parcial

Considere

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

e a correlação parcial entre X_i e X_j depois do controle linear das outras $p-2$ variáveis. Denote a correlação parcial populacional por $\rho_{ij \cdot -ij}$.

Sob

$$H_0 : \rho_{ij \cdot -ij} = 0,$$

e $n > p$, vale

$$T_{ij \cdot -ij} = \frac{p_{ij} \sqrt{n-p}}{\sqrt{1-p_{ij}^2}} \sim t_{n-p}. \quad (15.30)$$

Para $n > p + 1$, a transformação de Fisher fornece a aproximação

$$\operatorname{arctanh}(p_{ij}) \stackrel{\text{aprox}}{\sim} N \left[\operatorname{arctanh}(\rho_{ij \cdot -ij}), \frac{1}{n-p-1} \right]. \quad (15.31)$$

Esses resultados descrevem correlações parciais individuais (Anderson, 2003). As correlações parciais utilizadas na matriz anti-imagem são estatísticas amostrais, mas as distribuições individuais acima não fornecem, por si só, uma distribuição de referência para MSA ou KMO.

MSA e KMO são índices descritivos e não possuem p -valor associado.

15.14.4.3 Aproximação de Bartlett

O teste de esfericidade considera conjuntamente a matriz de correlações e testa

$$H_0 : \mathcal{R} = \mathbf{I}_p.$$

Sob normalidade multivariada, a estatística definida na Equação 15.44 utiliza uma correção de uma quantidade baseada em

$$-\log |\mathbf{R}|,$$

e sua distribuição de referência é aproximadamente

$$\chi_B^2 \stackrel{\text{aprox}}{\sim} \chi_{p(p-1)/2}^2.$$

A distribuição qui-quadrado é uma aproximação, e não uma distribuição exata em amostras finitas (Bartlett, 1950).

A aplicação desses resultados à avaliação da matriz de correlações é discutida na Seção 15.15.1.

15.14.5 Distribuição condicional dos fatores e escore por regressão

Sob o modelo fatorial normal com fatores aleatórios, o escore por regressão é obtido a partir da distribuição condicional do vetor fatorial latente dado o vetor observado. No modelo ortogonal, sua forma populacional corresponde à média condicional dos fatores (Johnson; Wichern, 2002).

Considere o modelo fatorial normal ortogonal da Definição 15.7 e suponha

$$\Sigma \succ \mathbf{0}.$$

Como

$$\text{Cov}(\mathbf{F}, \mathbf{X}) = \Phi^\top,$$

a distribuição condicional normal da Proposição 9.7 fornece diretamente

$$\mathbf{F} \mid (\mathbf{X} = \mathbf{x}) \sim N_m \left[\Phi^\top \Sigma^{-1} (\mathbf{x} - \mu), \mathbf{I}_m - \Phi^\top \Sigma^{-1} \Phi \right]. \quad (15.32)$$

Consequentemente,

$$E(\mathbf{F} \mid \mathbf{X} = \mathbf{x}) = \Phi^\top \Sigma^{-1} (\mathbf{x} - \mu), \quad (15.33)$$

e

$$\text{Cov}(\mathbf{F} \mid \mathbf{X} = \mathbf{x}) = \mathbf{I}_m - \Phi^\top \Sigma^{-1} \Phi. \quad (15.34)$$

A média condicional fornece o **escore fatorial por regressão** (Johnson; Wichern, 2002):

$$\hat{\mathbf{f}}_{\text{reg}} = \Phi^\top \Sigma^{-1} (\mathbf{x} - \mu). \quad (15.35)$$

A mesma construção se estende à formulação normal com fatores correlacionados. Considere

$$\mathbf{F} \sim N_m(\mathbf{0}, \Omega),$$

$$\varepsilon \sim N_p(\mathbf{0}, \Psi),$$

com

$$\mathbf{F} \perp \varepsilon,$$

e

$$\Sigma = \Phi\Omega\Phi^\top + \Psi \succ \mathbf{0}.$$

Nesse caso,

$$\text{Cov}(\mathbf{F}, \mathbf{X}) = \Omega\Phi^\top.$$

Consequentemente,

$$E(\mathbf{F} \mid \mathbf{X} = \mathbf{x}) = \Omega\Phi^\top \Sigma^{-1}(\mathbf{x} - \mu), \quad (15.36)$$

e

$$\text{Cov}(\mathbf{F} \mid \mathbf{X} = \mathbf{x}) = \Omega - \Omega\Phi^\top \Sigma^{-1}\Phi\Omega. \quad (15.37)$$

Quando $\Omega = \mathbf{I}_m$, recuperam-se os resultados da formulação ortogonal.

Quando os parâmetros são desconhecidos, uma versão por substituição utiliza as estimativas da solução fatorial ajustada:

$$\hat{\mathbf{f}}_{\text{reg}} = \hat{\Phi}^\top \hat{\Sigma}^{-1}(\mathbf{x} - \hat{\mu})$$

no caso ortogonal.

Na construção empírica dos escores por regressão, a matriz de covariâncias ou de correlações amostral também pode ser utilizada no cálculo dos coeficientes (Johnson; Wichern, 2002). Para variáveis padronizadas, uma solução ortogonal e uma matriz de correlações amostral positiva definida,

$$\mathbf{R} \succ \mathbf{0},$$

essa forma pode ser escrita como

$$\hat{\mathbf{f}}_{\text{Th}} = \hat{\Phi}^\top \mathbf{R}^{-1} \mathbf{z}. \quad (15.38)$$

em que $\mathbf{z}$ é o vetor de valores padronizados da unidade analisada.

Para uma solução oblíqua, a matriz de padrão fatorial deve ser combinada com a matriz de correlações fatoriais. Utilizando a matriz de estrutura fatorial

$$\widehat{\Phi}_{\Omega} = \widehat{\Phi}\widehat{\Omega},$$

a forma correspondente é

$$\widehat{\mathbf{f}}_{\text{Th}} = \widehat{\Omega}\widehat{\Phi}^{\top}\mathbf{R}^{-1}\mathbf{z}. \quad (15.39)$$

Em geral,

$$\mathbf{I}_m - \Phi^{\top}\Sigma^{-1}\Phi \neq \mathbf{0},$$

de modo que a distribuição condicional dos fatores não é degenerada e a observação $\mathbf{x}$ não determina univocamente sua realização latente. Diferentes critérios de obtenção dos escores podem, portanto, atribuir valores distintos à mesma observação sob uma solução fatorial fixada.

A matriz de covariâncias condicional quantifica a incerteza que permanece sobre os fatores mesmo depois de observada $\mathbf{x}$.

15.15 Aprofundamentos metodológicos e aplicados

Leitura de aprofundamento

Esta parte reúne critérios e procedimentos utilizados na condução da Análise Fatorial Exploratória, incluindo avaliação da matriz de correlações, métodos de estimação, escolha do número de fatores, avaliação dos resíduos, critérios de rotação, obtenção de escores e avaliação da estabilidade da solução.

15.15.1 Avaliação da matriz de correlações antes da Análise Fatorial

Na Análise Fatorial Exploratória, a matriz de correlações pode ser examinada antes da estimação comparando-se as correlações simples com as correlações parciais entre pares de variáveis, controlando-se linearmente as demais.

Como diagnóstico exploratório, correlações simples acompanhadas por correlações parciais menores em módulo são compatíveis com uma estrutura em que parte das associações entre as variáveis é compartilhada. Correlações parciais elevadas indicam que parte da associação

entre determinados pares permanece após o controle linear das demais variáveis, o que é menos compatível com uma estrutura comum de baixa dimensão (Hair et al., 2009).

A matriz anti-imagem, a MSA e o KMO utilizam $\mathbf{R}^{-1}$ e, portanto, exigem uma matriz de correlações não singular. Pela Definição 8.11, quando as variâncias amostrais são positivas,

$$\text{posto}(\mathbf{R}) = \text{posto}(\mathbf{S}).$$

Combinando essa relação com a Equação 8.60,

$$\text{posto}(\mathbf{R}) \leq \min(p, n - 1).$$

Assim, $n > p$ é necessário para que $\mathbf{R}$ possa ter posto completo, mas não garante sua invertibilidade. Dependências lineares exatas entre as variáveis padronizadas também tornam $\mathbf{R}$ singular.

Apesar da expressão *sampling adequacy*, MSA e KMO não medem diretamente o tamanho da amostra. Seus valores são construídos a partir da comparação entre correlações simples e parciais.

Esses procedimentos examinam aspectos distintos da estrutura de correlações antes da estimação fatorial. A matriz anti-imagem evidencia as associações residuais entre pares de variáveis depois do controle linear das demais; MSA e KMO comparam a magnitude das correlações simples com a das correlações parciais; e o teste de Bartlett avalia a hipótese de que a matriz de correlações populacional seja a identidade (Dziuban; Shirkey, 1974; Hair et al., 2009). Nenhum desses procedimentos avalia o ajuste de um modelo fatorial com número de fatores previamente especificado.

As distribuições associadas às correlações simples e parciais e o caráter aproximado da distribuição utilizada no teste de Bartlett são desenvolvidos na Seção 15.14.4. MSA e KMO são medidas descritivas e não possuem p -valor associado.

15.15.1.1 Matriz anti-imagem

A matriz anti-imagem é construída a partir das correlações parciais entre pares de variáveis, controlando-se linearmente as demais.

Considere a matriz de correlações observada

$$\mathbf{R} = (r_{ij}),$$

positiva definida, e sua inversa

$$\mathbf{C} = \mathbf{R}^{-1} = (c_{ij}).$$

Para $i \neq j$, a correlação parcial entre X_i e X_j , controlando-se as demais variáveis, é

$$p_{ij} = -\frac{c_{ij}}{\sqrt{c_{ii}c_{jj}}}.$$

Defina

$$\mathbf{D} = \text{diag} \left(\frac{1}{c_{11}}, \dots, \frac{1}{c_{pp}} \right).$$

A matriz de covariâncias anti-imagem é

$$\mathbf{S}_{\text{AI}} = \mathbf{D}\mathbf{C}\mathbf{D}. \quad (15.40)$$

Seus elementos diagonais são

$$s_{ii}^{(\text{AI})} = \frac{1}{c_{ii}},$$

enquanto, para $i \neq j$,

$$s_{ij}^{(\text{AI})} = \frac{c_{ij}}{c_{ii}c_{jj}}.$$

A padronização dessa matriz produz a matriz de correlações anti-imagem. Definindo

$$\mathbf{D}_C = \text{diag} (c_{11}, \dots, c_{pp}),$$

tem-se

$$\mathbf{R}_{\text{AI}} = \mathbf{D}_C^{-1/2} \mathbf{C} \mathbf{D}_C^{-1/2}. \quad (15.41)$$

Sua diagonal é unitária e, para $i \neq j$,

$$r_{ij}^{(\text{AI})} = \frac{c_{ij}}{\sqrt{c_{ii}c_{jj}}} = -p_{ij}.$$

Portanto, os elementos fora da diagonal da matriz de correlações anti-imagem correspondem aos negativos das correlações parciais entre pares de variáveis, controlando-se as demais. Valores pequenos em módulo indicam pouca associação residual entre os pares depois desse controle.

A matriz de correlações anti-imagem definida na Equação 15.41 possui diagonal unitária. Em algumas saídas computacionais, essa diagonal é substituída pelas medidas individuais de adequação apresentadas a seguir. Essa convenção de apresentação não altera a definição matemática da matriz anti-imagem.

15.15.1.2 Medida de adequação amostral (MSA)

A **Measure of Sampling Adequacy (MSA)** avalia cada variável separadamente pela relação entre suas correlações simples e suas correlações parciais com as demais variáveis. A forma utilizada aqui corresponde à medida modificada apresentada por Kaiser e Rice (Kaiser; Rice, 1974) e empregada na avaliação de matrizes de correlações para Análise Fatorial por Dziuban e Shirkey (Dziuban; Shirkey, 1974).

Para a variável X_i , quando o denominador é positivo,

$$MSA_i = \frac{\sum_{j \neq i} r_{ij}^2}{\sum_{j \neq i} r_{ij}^2 + \sum_{j \neq i} p_{ij}^2}. \quad (15.42)$$

Nesse caso,

$$0 \leq MSA_i \leq 1.$$

A MSA se aproxima de 1 quando as correlações parciais são pequenas em relação às correlações simples. Valores baixos indicam que parte importante das associações da variável com as demais permanece mesmo depois do controle linear das outras variáveis. Esse padrão é menos compatível com uma representação em que essas associações sejam predominantemente atribuídas a fatores comuns.

Hair et al. utilizam 0,50 como referência operacional mínima para examinar a adequação de uma variável (Hair et al., 2009). Esse valor é uma **regra prática**. Ele não constitui condição matemática de existência ou identificação do modelo fatorial.

15.15.1.3 Kaiser-Meyer-Olkin (KMO)

O índice de **Kaiser-Meyer-Olkin (KMO)** aplica ao conjunto de variáveis o mesmo princípio utilizado pela MSA individual, comparando globalmente as correlações simples e as correlações parciais (Kaiser; Rice, 1974):

$$\text{KMO} = \frac{\sum_{i < j} r_{ij}^2}{\sum_{i < j} r_{ij}^2 + \sum_{i < j} p_{ij}^2}. \quad (15.43)$$

Quando o denominador é positivo,

$$0 \leq \text{KMO} \leq 1.$$

Valores próximos de 1 correspondem a correlações parciais pequenas em relação às correlações simples. Esse padrão indica que, depois do controle linear das demais variáveis, resta relativamente pouca associação entre os pares e é compatível com o uso de um modelo de fatores comuns.

Valores baixos indicam que parte importante das associações entre pares permanece depois do controle das demais variáveis. Hair et al. utilizam 0,50 como referência operacional mínima para a medida global (Hair et al., 2009).

MSA e KMO diferem pela abrangência. A MSA_i avalia uma variável em relação às demais. O KMO resume o mesmo tipo de comparação para o conjunto de variáveis. Nenhuma das duas medidas testa a hipótese de que um modelo fatorial específico seja verdadeiro.

15.15.1.4 Teste de esfericidade de Bartlett

O teste de esfericidade de Bartlett avalia a hipótese de que a matriz de correlações populacional $\mathcal{R}$, definida na Definição 8.5, seja a matriz identidade (Bartlett, 1950).

Considere uma amostra aleatória da distribuição normal multivariada definida na Definição 9.1,

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com variâncias marginais positivas. Seja $\mathbf{R}$ a matriz de correlações observada calculada a partir das n observações completas. A hipótese nula é

$$H_0 : \mathcal{R} = \mathbf{I}_p,$$

contra

$$H_1 : \mathcal{R} \neq \mathbf{I}_p.$$

Sob H_0 , todas as correlações populacionais fora da diagonal são nulas.

Supondo $\mathbf{R}$ positiva definida, utiliza-se a estatística

$$\chi_B^2 = - \left[n - 1 - \frac{2p + 5}{6} \right] \log |\mathbf{R}|. \quad (15.44)$$

Para amostras suficientemente grandes,

$$\chi_B^2 \stackrel{\text{aprox}}{\sim} \chi_{p(p-1)/2}^2$$

sob H_0 (Bartlett, 1950).

A rejeição de H_0 fornece evidência de que a matriz de correlações populacional não é a identidade. Existe, portanto, associação linear entre pelo menos algumas das variáveis.

Esse resultado não estabelece a existência de uma estrutura fatorial de baixa dimensão nem o bom ajuste de um modelo com determinado número de fatores. Ele apenas afasta o caso em que todas as correlações populacionais entre variáveis distintas são nulas.

A não rejeição de H_0 indica que os dados não fornecem evidência suficiente para distinguir a matriz de correlações populacional da identidade, situação pouco favorável à busca de fatores comuns.

O teste de Bartlett deve ser interpretado em conjunto com a estrutura das correlações simples e parciais e com as medidas de adequação (Hair et al., 2009). Em amostras grandes, mesmo afastamentos pequenos da matriz identidade podem produzir rejeição de H_0 . A significância do teste não deve ser utilizada isoladamente como evidência de uma estrutura fatorial de baixa dimensão.

Tabela 15.5: Síntese dos diagnósticos da estrutura de correlações utilizados antes da estimação fatorial.

Procedimento	Referência para interpretação	Conclusão permitida
Elementos fora da diagonal da anti-imagem	valores próximos de 0	correlações parciais pequenas em módulo

Procedimento	Referência para interpretação	Conclusão permitida
MSA_i	0,50 como referência operacional mínima	valores menores indicam maior importância relativa das correlações parciais da variável
KMO	0,50 como referência operacional mínima	valores maiores indicam menor importância relativa das correlações parciais
Bartlett	rejeitar H_0 quando o p -valor é menor que o nível α definido	a matriz de correlações populacional difere da identidade

15.15.2 Tamanho amostral e estabilidade das estimativas

O tamanho amostral afeta a precisão da matriz de correlações utilizada na AFE e, por consequência, a estabilidade das cargas, das comunalidades e do número de fatores retidos. Não existe uma razão fixa entre número de observações e número de variáveis que funcione como condição universal de adequação.

As orientações práticas de Hair et al. devem ser tratadas como heurísticas. A exigência amostral tende a aumentar quando as comunalidades são menores, quando cada fator é definido por poucas variáveis com cargas elevadas ou quando pequenas alterações nos dados produzem mudanças relevantes nas cargas e no número de fatores retidos (Hair et al., 2009). Fatores definidos por várias variáveis e comunalidades maiores tendem a ser estimados com maior estabilidade para um mesmo tamanho amostral.

A avaliação deve considerar conjuntamente o número de observações efetivamente utilizado, o número de variáveis, as comunalidades estimadas, a quantidade de variáveis que definem cada fator e a estabilidade observada em análises de sensibilidade ou reestimações. KMO e MSA não substituem essa avaliação, pois são construídos a partir das correlações simples e parciais, e não constituem medidas diretas do tamanho amostral.

A condição $n > p$ discutida na Seção 15.15.1 refere-se à possibilidade de a matriz de correlações possuir posto completo, necessária aos procedimentos que utilizam $\mathbf{R}^{-1}$. Ela não constitui uma regra geral de tamanho amostral para a existência do modelo fatorial.

15.15.3 Fatores principais e mínimos resíduos

Fatores principais e mínimos resíduos utilizam critérios distintos para obter uma solução fatorial. O método de fatores principais constrói sucessivamente uma matriz reduzida com comunalidades estimadas na diagonal e aplica a ela uma decomposição espectral. O MINRES

determina as cargas pela minimização dos resíduos entre associações observadas e reproduzidas.

Os dois métodos procuram estimar a estrutura comum, mas utilizam critérios distintos.

15.15.3.1 Fatores principais

O método de **fatores principais**, também denominado **método dos eixos principais** (*principal axis factoring*, PAF), utiliza uma decomposição espectral de uma matriz construída para representar a parcela comum da estrutura de covariâncias ou correlações (Johnson; Wichern, 2002).

Fatores ou eixos principais não são componentes principais. As duas técnicas utilizam autovalores e autovetores, mas os aplicam a objetos estatísticos diferentes.

Na ACP, os autovetores da matriz de covariâncias ou de correlações definem as direções principais, e os autovalores são as variâncias das componentes correspondentes. No método dos fatores principais, a decomposição espectral é aplicada a uma matriz reduzida, cuja diagonal contém communalidades estimadas.

No nível populacional, para o modelo ortogonal,

$$\Sigma_{\text{com}} = \Sigma - \Psi = \Phi\Phi^{\top}.$$

Como

$$\text{posto}(\Sigma_{\text{com}}) \leq m,$$

um modelo com m fatores representa a estrutura comum por uma matriz de posto não superior a m .

Na aplicação amostral baseada em correlações, as communalidades são desconhecidas. O procedimento parte de estimativas iniciais

$$\hat{h}_1^2, \dots, \hat{h}_p^2$$

e substitui a diagonal unitária de $\mathbf{R}$ por esses valores, formando a denominada **matriz de correlações reduzida**

$$\mathbf{R}_{\text{red}} = \begin{pmatrix} \hat{h}_1^2 & r_{12} & \cdots & r_{1p} \\ r_{21} & \hat{h}_2^2 & \cdots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \cdots & \hat{h}_p^2 \end{pmatrix}. \quad (15.45)$$

A denominação é tradicional: depois da substituição dos elementos diagonais, $\mathbf{R}_{\text{red}}$ não é, em geral, uma matriz de correlações no sentido estrito. Sua diagonal passa a representar a parcela estimada da variância de cada variável atribuída aos fatores comuns.

A matriz reduzida é um objeto intermediário do método e constitui a matriz à qual se aplica a decomposição espectral. Ela não deve ser confundida com a matriz de correlações implicada pela solução fatorial ajustada.

A decomposição espectral é, portanto, aplicada a $\mathbf{R}_{\text{red}}$, e não à matriz $\mathbf{R}$ utilizada na ACP baseada em correlações.

Como $\mathbf{R}_{\text{red}}$ é simétrica, considere seus autovalores

$$\hat{\lambda}_{\text{red},1} \geq \hat{\lambda}_{\text{red},2} \geq \dots \geq \hat{\lambda}_{\text{red},p}$$

e autovetores unitários associados

$$\hat{\alpha}_{\text{red},1}, \dots, \hat{\alpha}_{\text{red},p},$$

satisfazendo

$$\mathbf{R}_{\text{red}} \hat{\alpha}_{\text{red},j} = \hat{\lambda}_{\text{red},j} \hat{\alpha}_{\text{red},j}, \quad \hat{\alpha}_{\text{red},j}^\top \hat{\alpha}_{\text{red},j} = 1.$$

Reunindo os autovetores em

$$\widehat{\mathbf{A}}_{\text{red}} = (\hat{\alpha}_{\text{red},1} \quad \dots \quad \hat{\alpha}_{\text{red},p})$$

e definindo

$$\widehat{\Lambda}_{\text{red}} = \text{diag}(\hat{\lambda}_{\text{red},1}, \dots, \hat{\lambda}_{\text{red},p}),$$

tem-se

$$\mathbf{R}_{\text{red}} = \widehat{\mathbf{A}}_{\text{red}} \widehat{\Lambda}_{\text{red}} \widehat{\mathbf{A}}_{\text{red}}^\top. \quad (15.46)$$

Os autovalores positivos selecionados nessa decomposição determinam, juntamente com os autovetores correspondentes, as cargas fatoriais não rotacionadas.

Suponha que a solução utilize m autovalores positivos da matriz reduzida,

$$\hat{\lambda}_{\text{red},1} \geq \dots \geq \hat{\lambda}_{\text{red},m} > 0.$$

Defina

$$\widehat{\mathbf{A}}_{\text{red},m} = (\hat{\alpha}_{\text{red},1} \quad \cdots \quad \hat{\alpha}_{\text{red},m}) \in \mathbb{R}^{p \times m}$$

e

$$\widehat{\Lambda}_{\text{red},m} = \text{diag}(\hat{\lambda}_{\text{red},1}, \dots, \hat{\lambda}_{\text{red},m}).$$

A matriz de cargas não rotacionadas correspondente é

$$\widehat{\Phi}_0 = \widehat{\mathbf{A}}_{\text{red},m} \widehat{\Lambda}_{\text{red},m}^{1/2}. \quad (15.47)$$

Se $\hat{a}_{\text{red},ij}$ é o i -ésimo elemento de $\hat{\alpha}_{\text{red},j}$, então

$$\hat{\phi}_{ij}^{(0)} = \sqrt{\hat{\lambda}_{\text{red},j}} \hat{a}_{\text{red},ij}. \quad (15.48)$$

A estrutura comum estimada pela solução de m fatores é

$$\widehat{\Phi}_0 \widehat{\Phi}_0^\top = \widehat{\mathbf{A}}_{\text{red},m} \widehat{\Lambda}_{\text{red},m} \widehat{\mathbf{A}}_{\text{red},m}^\top.$$

As comunalidades associadas às cargas obtidas são os elementos diagonais dessa matriz. Para a variável X_i ,

$$\hat{h}_i^2 = \sum_{j=1}^m \left(\hat{\phi}_{ij}^{(0)} \right)^2.$$

No procedimento iterativo de fatores principais, essas comunalidades são utilizadas para atualizar a diagonal da matriz reduzida. A nova matriz produz outra decomposição espectral e, conseqüentemente, novas cargas e comunalidades. As atualizações prosseguem segundo o critério de convergência adotado.

As comunalidades iniciais, a tolerância de convergência e os demais critérios numéricos são escolhas algorítmicas e podem variar entre implementações.

A solução obtida por fatores principais é inicialmente não rotacionada. Uma transformação posterior pode selecionar outra orientação para as cargas, conforme desenvolvido na Seção 15.10. No caso ortogonal, a invariância da estrutura comum foi estabelecida na Equação 15.16.

Como $\mathbf{R}_{\text{red}}$ depende de comunalidades estimadas, ela não é necessariamente semidefinida positiva durante todo o procedimento. Autovalores negativos podem ocorrer nessa matriz intermediária.

Esses autovalores negativos pertencem à matriz reduzida intermediária e não correspondem a variâncias fatoriais. Na construção da Equação 15.48, apenas autovalores positivos podem ser retidos, pois as cargas envolvem suas raízes quadradas.

15.15.3.2 Mínimos resíduos

O método de **mínimos resíduos** (*minimum residual*, MINRES) estima uma solução fatorial buscando reduzir as diferenças entre as associações observadas e aquelas reproduzidas pela estrutura comum. Na análise baseada em correlações, o ajuste é determinado pelos resíduos dos elementos fora da diagonal da matriz de correlações.

O MINRES constitui uma alternativa aos fatores principais e à máxima verossimilhança para a obtenção das cargas fatoriais. Na implementação utilizada, ele corresponde a uma das opções de estimação. A avaliação dos resíduos da solução ajustada é apresentada na Seção 15.15.5.

15.15.3.3 Admissibilidade e casos de Heywood

Independentemente do método de estimação, uma solução fatorial deve respeitar as restrições de admissibilidade do modelo. Em particular,

$$\hat{\psi}_i \geq 0, \quad i = 1, \dots, p.$$

Uma estimativa com

$$\hat{\psi}_i < 0$$

caracteriza uma solução imprópria denominada **caso de Heywood** (Johnson; Wichern, 2002).

Para variáveis padronizadas, como

$$1 = \hat{h}_i^2 + \hat{\psi}_i,$$

uma variância específica negativa corresponde a uma comunalidade estimada superior a 1.

O caso $\hat{\psi}_i = 0$ situa-se na fronteira do espaço paramétrico admissível definido por $\psi_i \geq 0$.

15.15.4 Escolha do número de fatores

A dimensão m da estrutura fatorial é parte da especificação do modelo. Um número muito pequeno de fatores pode ser insuficiente para representar a estrutura comum das variáveis, enquanto um número excessivo reduz a parcimônia e pode dificultar a interpretação da solução (Hair et al., 2009).

A formulação do modelo estabelece que $m < p$, mas não determina, por si só, o valor de m . A escolha do número de fatores constitui uma decisão de modelagem e pode ser auxiliada por diferentes critérios.

Os critérios de retenção fornecem informações auxiliares para a escolha do número de fatores e devem ser considerados em conjunto com a interpretação da solução obtida.

A escolha de m não deve ser confundida com a avaliação preliminar da matriz de correlações. A matriz anti-imagem, MSA, KMO e o teste de esfericidade de Bartlett avaliam aspectos da estrutura de correlações antes da estimação fatorial, mas não determinam quantos fatores devem ser retidos.

Alguns critérios utilizam uma sequência de raízes associadas à estrutura analisada. Antes de interpretá-las, é necessário identificar **qual matriz ou qual procedimento de estimação as produziu**. Na ACP, os autovalores pertencem diretamente à matriz de covariâncias ou de correlações. Na Análise Fatorial, métodos distintos podem utilizar estruturas diferentes para representar a parcela comum.

O **gráfico de declive** (*scree plot*) representa em ordem decrescente a sequência de autovalores ou raízes definida pelo procedimento utilizado. Procura-se um **cotovelo**, a partir do qual a queda se torna menos acentuada e os valores restantes são relativamente pequenos. A interpretação depende da matriz e do procedimento que produziram essa sequência (Hair et al., 2009).

O **critério da raiz latente** utiliza como referência a retenção de fatores associados a raízes maiores que 1 e é empregado como regra auxiliar na escolha do número de fatores (Hair et al., 2009). A interpretação desse limiar depende, entretanto, da sequência de raízes considerada.

Quando se utilizam os autovalores da matriz de correlações $\mathbf{R}$, o valor 1 corresponde à variância de uma variável padronizada e também à média dos p autovalores de $\mathbf{R}$. Essa é a justificativa desenvolvida para a ACP na Seção 14.14.2. Johnson e Wichern (Johnson; Wichern, 2002) também utilizam autovalores de $\mathbf{R}$ maiores que 1 em um exemplo de estimação fatorial pelo método de componentes.

Quando as raízes são obtidas de outra matriz ou de outro procedimento de estimação, o limiar 1 não conserva automaticamente essa mesma interpretação. Por isso, critérios baseados na magnitude das raízes devem ser tratados como auxiliares e interpretados em relação à matriz e ao procedimento que as produziram.

A implementação utilizada também oferece a **análise paralela** como procedimento auxiliar para a escolha do número de fatores. O procedimento compara as raízes obtidas dos dados observados com valores de referência produzidos sob uma estrutura sem associação sistemática entre as variáveis. A forma dessa comparação depende do método de estimação e do procedimento computacional utilizado; por isso, as raízes observadas e as de referência devem ser interpretadas de acordo com a forma como foram obtidas.

A escolha de m pode considerar conjuntamente:

- a possibilidade de interpretar cada fator a partir das variáveis associadas a ele;
- o comportamento das raízes e do gráfico de declive;
- os resíduos da solução ajustada;
- o ajuste global, quando o método utilizado fornece esse procedimento;
- a interpretação da solução após a rotação;
- a análise paralela, quando essa opção da implementação for utilizada.

Essas informações podem indicar soluções diferentes. Nesse caso, modelos com dimensões próximas devem ser comparados quanto às mudanças nas cargas, nas comunalidades, nos resíduos e na interpretação dos fatores (Hair et al., 2009).

Entre soluções com ajuste e interpretação satisfatórios, a escolha do menor número de fatores preserva a parcimônia do modelo (Johnson; Wichern, 2002).

15.15.5 Matriz reproduzida e resíduos

Depois da estimação, o ajuste pode ser examinado comparando a matriz observada com a matriz implicada pela solução fatorial estimada. Essa última é denominada **matriz reproduzida** (Johnson; Wichern, 2002).

No modelo ortogonal, sejam

$$\widehat{\Phi}$$

e

$$\widehat{\Psi}$$

as estimativas correspondentes a uma solução com m fatores.

A matriz de cargas depende da parametrização e da orientação escolhida. Para avaliar o ajuste, interessa a matriz de covariâncias implicada pela solução ajustada, e não uma orientação específica das cargas.

No modelo ortogonal, a matriz de covariâncias reproduzida é

$$\widehat{\Sigma}_{\text{fat}} = \widehat{\Phi}\widehat{\Phi}^\top + \widehat{\Psi}. \quad (15.49)$$

Quando a análise é baseada em correlações, a expressão correspondente é

$$\widehat{\mathcal{R}}_{\text{fat}} = \widehat{\Phi}\widehat{\Phi}^\top + \widehat{\Psi},$$

com a parametrização definida para as variáveis padronizadas.

Em uma solução com fatores correlacionados, a parcela comum é

$$\widehat{\Phi}\widehat{\Omega}\widehat{\Phi}^\top,$$

e a matriz reproduzida é obtida acrescentando $\widehat{\Psi}$, conforme a formulação oblíqua desenvolvida na Seção 15.10.

A matriz de resíduos é definida como a diferença entre a matriz utilizada no ajuste e a matriz reproduzida pela solução fatorial.

Para uma análise baseada em covariâncias, a matriz de resíduos é

$$\mathbf{E}_S = \mathbf{S} - \widehat{\Sigma}_{\text{fat}}. \quad (15.50)$$

Para uma análise baseada em correlações,

$$\mathbf{E}_R = \mathbf{R} - \widehat{\mathcal{R}}_{\text{fat}}. \quad (15.51)$$

No modelo ortogonal, para $i \neq j$, o resíduo de uma covariância é

$$e_{S,ij} = s_{ij} - \sum_{h=1}^m \hat{\phi}_{ih} \hat{\phi}_{jh}.$$

Na análise baseada em correlações,

$$e_{R,ij} = r_{ij} - \sum_{h=1}^m \hat{\phi}_{ih} \hat{\phi}_{jh}.$$

Para $i \neq j$, cada resíduo é a diferença entre a covariância ou correlação observada e o valor correspondente reproduzido pela solução fatorial. Quanto menor sua magnitude, menor é essa diferença.

Os resíduos diagonais correspondem às diferenças entre as variâncias observadas e aquelas implicadas pela solução ajustada. Seu comportamento depende do método de estimação e da forma como as variâncias específicas são determinadas. Em procedimentos que definem

$$\hat{\psi}_i = s_{ii} - \hat{h}_i^2$$

ou, no caso padronizado,

$$\hat{\psi}_i = 1 - \hat{h}_i^2,$$

os resíduos diagonais são nulos por construção e, portanto, não fornecem um diagnóstico independente de ajuste.

A matriz de resíduos também permite separar o papel da estimação do papel da rotação. Em uma rotação ortogonal,

$$\hat{\Phi}^* = \hat{\Phi}\mathbf{Q}$$

e, pela Equação 15.16,

$$\hat{\Phi}^* \hat{\Phi}^{*\top} = \hat{\Phi} \hat{\Phi}^\top.$$

A matriz reproduzida e a matriz de resíduos permanecem inalteradas. A rotação modifica a orientação das cargas, não o ajuste da estrutura reproduzida.

Na formulação oblíqua, a mesma conclusão vale para transformações conjuntas das cargas e das correlações fatoriais que preservem

$$\hat{\Phi} \hat{\Omega} \hat{\Phi}^\top.$$

Se o modelo populacional ortogonal com m fatores representa exatamente a estrutura de covariâncias,

$$\Sigma = \Phi\Phi^\top + \Psi,$$

a matriz residual populacional correspondente é nula.

Na amostra, resíduos diferentes de zero podem ocorrer mesmo quando a matriz populacional satisfaz exatamente o modelo fatorial, pois $\mathbf{S}$ ou $\mathbf{R}$ diferem de suas correspondentes populacionais em razão da variabilidade amostral e os parâmetros da solução são estimados a partir da própria amostra.

Resíduos amostrais também podem refletir inadequação da estrutura fatorial especificada. Um número insuficiente de fatores ou associações entre variáveis que não são representadas pela estrutura comum especificada podem produzir padrões sistemáticos nos resíduos.

A matriz residual deve ser examinada quanto à magnitude e ao padrão das discrepâncias entre a matriz observada e a matriz reproduzida (Johnson; Wichern, 2002). Padrões sistemáticos podem indicar inadequação local da estrutura especificada, mas um resíduo isolado não identifica, por si só, a causa da discrepância.

15.15.6 Critérios de rotação como problemas de otimização

A indeterminação rotacional permite escolher, entre representações equivalentes da estrutura comum, uma orientação que favoreça determinado padrão das cargas. Um critério de rotação formaliza essa escolha por meio de uma função objetivo. Nas rotações ortogonais, a matriz de cargas rotacionada é

$$\Phi^* = \Phi \mathbf{Q},$$

com $\mathbf{Q}$ ortogonal. A estrutura comum permanece inalterada, conforme estabelecido na Seção 15.14.2, mas os elementos de Φ^* dependem da orientação escolhida.

15.15.6.1 Varimax

O critério **Varimax** procura favorecer uma estrutura simples nas colunas da matriz de cargas, aumentando a dispersão dos quadrados das cargas dentro de cada fator (Kaiser, 1958). Assim, para um mesmo fator, o critério favorece a coexistência de cargas de maior magnitude e cargas próximas de zero.

Na forma normalizada de Kaiser, as cargas de cada variável são previamente escaladas pela raiz de sua comunalidade (Kaiser, 1958). Para uma variável com comunalidade $h_i^2 > 0$, defina

$$\tilde{\phi}_{ij}^* = \frac{\phi_{ij}^*}{\sqrt{h_i^2}}.$$

O critério pode ser escrito como

$$v_{\text{Varimax}} = \sum_{j=1}^m \left[\frac{1}{p} \sum_{i=1}^p (\tilde{\phi}_{ij}^*)^4 - \left(\frac{1}{p} \sum_{i=1}^p (\tilde{\phi}_{ij}^*)^2 \right)^2 \right]. \quad (15.52)$$

A orientação é escolhida para maximizar v_{Varimax} . Para cada fator, a expressão entre colchetes mede a dispersão dos quadrados das cargas normalizadas. A maximização favorece colunas nas quais algumas cargas apresentam magnitude elevada e outras se aproximam de zero.

Como a rotação ortogonal preserva h_i^2 , a normalização produz

$$\sum_{j=1}^m (\tilde{\phi}_{ij}^*)^2 = 1.$$

Assim, cada vetor de cargas normalizadas possui norma unitária, e o critério depende da distribuição relativa das cargas da variável entre os fatores, e não da magnitude de sua comunalidade.

15.15.6.2 Quartimax

O critério **Quartimax** procura favorecer uma estrutura simples nas linhas da matriz de cargas, concentrando a comunalidade de cada variável em um número reduzido de fatores (Neuhauser; Wrigley, 1954). Sob rotação ortogonal, uma forma equivalente do critério consiste em maximizar

$$v_{\text{Quartimax}} = \sum_{i=1}^p \sum_{j=1}^m (\phi_{ij}^*)^4. \quad (15.53)$$

Como a rotação ortogonal preserva

$$h_i^2 = \sum_{j=1}^m (\phi_{ij}^*)^2,$$

a maximização das quartas potências favorece a concentração dessa magnitude em poucas cargas de cada linha.

Aplicados à mesma solução inicial, Varimax e Quartimax preservam a mesma estrutura comum, mas selecionam orientações diferentes segundo suas respectivas funções objetivo. O Varimax enfatiza a simplicidade das colunas da matriz de cargas, procurando distinguir mais claramente quais variáveis caracterizam cada fator, enquanto o Quartimax enfatiza a simplicidade das linhas, procurando concentrar a comunalidade de cada variável em poucos fatores (Hair et al., 2009).

Como consequência dessa orientação, soluções Quartimax podem favorecer o aparecimento de um fator geral no qual muitas variáveis apresentam cargas elevadas (Hair et al., 2009). Essa característica não constitui um erro do método; ela decorre do tipo de estrutura simples privilegiado pelo critério.

15.15.6.3 Oblimin

O **Oblimin** pertence à classe das rotações oblíquas. Nessas rotações, a orientação dos fatores é modificada sem impor que eles permaneçam não correlacionados. O objetivo continua sendo favorecer uma estrutura que facilite a interpretação das cargas, mas permitindo correlações entre os fatores (Hair et al., 2009).

Em uma solução oblíqua, a interpretação envolve a matriz de padrão fatorial, a matriz de estrutura fatorial e a matriz de correlações fatoriais Ω , conforme desenvolvido na Seção 15.10.

15.15.6.4 Promax

O **Promax** também pertence à classe das rotações oblíquas e, portanto, permite fatores correlacionados (Hair et al., 2009). Ele constitui uma alternativa ao Oblimin para a obtenção de uma orientação oblíqua da solução fatorial.

Oblimin e Promax são procedimentos distintos, embora compartilhem a característica de não impor ortogonalidade entre os fatores. A escolha entre métodos de rotação deve ser examinada em função dos objetivos da análise e da interpretabilidade da solução (Hair et al., 2009).

15.15.6.5 Escolha da rotação

Não existe um critério de rotação que seja superior em todas as aplicações (Hair et al., 2009). A escolha entre rotação ortogonal e oblíqua depende da relação admitida entre os fatores. A rotação ortogonal impõe

$$\Omega = \mathbf{I}_m,$$

enquanto a rotação oblíqua estima também as correlações entre os fatores, representadas pelos elementos fora da diagonal de Ω , conforme a Seção 15.10.

Quando o problema analisado admite fatores correlacionados, a rotação oblíqua preserva essa possibilidade no modelo rotacionado. A matriz estimada $\hat{\Omega}$ mostra as correlações obtidas entre os fatores. Correlações fatoriais de pequena magnitude indicam que a dependência estimada entre os fatores é limitada nessa solução, mas não estabelecem, por si sós, equivalência com uma solução ortogonal. Correlações de maior magnitude mostram que a imposição de ortogonalidade excluiria uma associação entre fatores presente na solução oblíqua.

O critério de rotação também pode afetar o padrão das cargas fatoriais. A comparação entre soluções obtidas por critérios admissíveis deve considerar quais variáveis apresentam as maiores cargas em cada fator, a ocorrência de cargas cruzadas e a correspondência entre os conjuntos de variáveis associados aos fatores. Quando essas características permanecem semelhantes entre

soluções, a interpretação depende menos do critério de rotação escolhido (Johnson; Wichern, 2002).

A rotação de uma solução fatorial não modifica o ajuste global correspondente à matriz de covariâncias reproduzida; ela modifica a representação dos fatores e das cargas. Por isso, a escolha da rotação deve ser separada da avaliação do ajuste do modelo. Os resíduos avaliam a reprodução das associações observadas, enquanto as cargas rotacionadas e, no caso oblíquo, as correlações entre fatores orientam a interpretação da solução.

15.15.7 Interpretação e reespecificação da solução

A interpretação deve utilizar a solução rotacionada correspondente ao modelo adotado. Em rotações ortogonais, as cargas relacionam diretamente as variáveis aos fatores não correlacionados. Em rotações oblíquas, a matriz de padrão e a matriz de estrutura desempenham papéis distintos: a primeira contém os coeficientes que relacionam as variáveis aos fatores na parametrização rotacionada, enquanto a segunda contém as correlações entre variáveis e fatores, conforme a Seção 15.10.

Para cada variável, devem ser examinadas conjuntamente a comunalidade, as cargas e a presença de cargas relevantes em mais de um fator. Uma comunalidade baixa indica que pequena parcela da variância da variável é representada pelos fatores retidos. Uma carga cruzada indica que a variável apresenta relações relevantes com mais de um fator e pode impedir sua atribuição simples a uma única dimensão.

A exclusão de uma variável não deve decorrer automaticamente de um único limiar de carga ou comunalidade. A decisão deve considerar a função substantiva da variável, seu padrão de cargas, sua comunalidade e o efeito de sua retirada sobre as demais cargas, sobre o número de fatores retidos e sobre a interpretação dos fatores. Se forem alterados o conjunto de variáveis, o número de fatores, o método de estimação ou o critério de rotação, a análise deve ser reestimada e a nova solução comparada com a anterior (Hair et al., 2009).

A denominação de um fator resume o conteúdo comum das variáveis que apresentam as relações mais informativas com ele. O rótulo deve ser sustentado pelo conteúdo dessas variáveis e pelo problema substantivo; ele não é determinado pelo algoritmo de extração ou de rotação. A presença de um fator latente no modelo não estabelece, por si só, a validade de um construto nem a confiabilidade de uma escala.

15.15.8 Critérios e propriedades dos métodos de escores fatoriais

Para comparar diferentes critérios de obtenção dos escores fatoriais, considere inicialmente uma solução fatorial com parâmetros fixados e

$$\mathbf{z} = \mathbf{x} - \mu = \Phi \mathbf{f} + \varepsilon.$$

15.15.8.1 Escore de Bartlett

O método de Bartlett trata $\mathbf{f}$ como o vetor de valores fatoriais a ser estimado e utiliza as variâncias específicas para ponderar os resíduos (Anderson, 2003).

Supondo

$$\Psi \succ \mathbf{0},$$

considera-se

$$d_B(\mathbf{f}) = (\mathbf{z} - \Phi\mathbf{f})^\top \Psi^{-1} (\mathbf{z} - \Phi\mathbf{f}). \quad (15.54)$$

Quando

$$\Phi^\top \Psi^{-1} \Phi$$

é invertível, a minimização produz

$$\hat{\mathbf{f}}_B = (\Phi^\top \Psi^{-1} \Phi)^{-1} \Phi^\top \Psi^{-1} \mathbf{z}. \quad (15.55)$$

Condicionalmente a

$$\mathbf{F} = \mathbf{f},$$

tem-se

$$E(\hat{\mathbf{f}}_B \mid \mathbf{F} = \mathbf{f}) = \mathbf{f},$$

e

$$\text{Cov}(\hat{\mathbf{f}}_B - \mathbf{f} \mid \mathbf{F} = \mathbf{f}) = (\Phi^\top \Psi^{-1} \Phi)^{-1}.$$

O método atribui maior peso relativo às variáveis com menor variância específica. Tratando os valores fatoriais como quantidades não estocásticas a serem estimadas, o estimador de Bartlett é linear e não viesado e possui variância mínima entre os estimadores lineares não viesados. Sob normalidade, nessa formulação condicional, ele também coincide com o estimador de máxima verossimilhança dos valores fatoriais (Anderson, 2003).

15.15.8.2 Relação entre os escores de Bartlett e por regressão

Os métodos de Bartlett e por regressão partem de perspectivas distintas sobre os fatores. No método de Bartlett, para uma observação dada, o vetor fatorial é tratado como uma quantidade desconhecida a ser estimada a partir de

$$\mathbf{z} = \Phi \mathbf{f} + \varepsilon.$$

No método por regressão, os fatores são tratados como variáveis aleatórias e o escore corresponde à média condicional de $\mathbf{F}$ dado $\mathbf{X}$ sob o modelo fatorial normal (Johnson; Wichern, 2002).

No modelo ortogonal, suponha

$$\Psi \succ \mathbf{0}$$

e

$$\text{posto}(\Phi) = m.$$

Defina

$$\mathbf{G} = \Phi^\top \Psi^{-1} \Phi.$$

Nessas condições,

$$\mathbf{G} \succ \mathbf{0},$$

e, portanto, $\mathbf{G}$ é invertível. O escore de Bartlett é

$$\hat{\mathbf{f}}_{\text{B}} = \mathbf{G}^{-1} \Phi^\top \Psi^{-1} \mathbf{z}.$$

O escore por regressão pode ser escrito como

$$\hat{\mathbf{f}}_{\text{reg}} = (\mathbf{I}_m + \mathbf{G})^{-1} \Phi^\top \Psi^{-1} \mathbf{z},$$

e, consequentemente,

$$\hat{\mathbf{f}}_{\text{reg}} = (\mathbf{I}_m + \mathbf{G})^{-1} \mathbf{G} \hat{\mathbf{f}}_{\text{B}}. \quad (15.56)$$

A relação mostra que o escore por regressão não é, em geral, igual ao escore de Bartlett. Nas direções associadas a autovalores positivos de $\mathbf{G}$, o fator multiplicativo correspondente é

$$\frac{\gamma}{1 + \gamma}, \quad 0 < \frac{\gamma}{1 + \gamma} < 1,$$

de modo que o escore por regressão apresenta retração em direção à média dos fatores. Anderson (Anderson, 2003) apresenta essa relação explicitamente quando $\mathbf{G}$ é diagonal.

A diferença entre os dois critérios também aparece no erro de predição. No modelo ortogonal normal, a matriz de erro quadrático médio do escore por regressão é

$$E \left[(\hat{\mathbf{F}}_{\text{reg}} - \mathbf{F}) (\hat{\mathbf{F}}_{\text{reg}} - \mathbf{F})^\top \right] = \mathbf{I}_m - \Phi^\top \Sigma^{-1} \Phi,$$

que coincide com a matriz de covariâncias condicionais apresentada na Equação 15.34.

Pela identidade matricial correspondente,

$$\mathbf{I}_m - \Phi^\top \Sigma^{-1} \Phi = (\mathbf{I}_m + \mathbf{G})^{-1}.$$

Como $\mathbf{G} \succ \mathbf{0}$,

$$\mathbf{0} \prec (\mathbf{I}_m + \mathbf{G})^{-1} \prec \mathbf{G}^{-1}.$$

Portanto, no sentido da ordem de Loewner, a matriz de erro quadrático médio do escore por regressão é menor que a matriz de erro do estimador não viesado de Bartlett (Anderson, 2003).

Assim, a escolha entre Bartlett e regressão não corresponde à escolha entre um método correto e outro incorreto. Os dois métodos empregam critérios distintos para atribuir valores às realizações fatoriais não observadas.

15.15.8.3 Outros métodos disponíveis na implementação

Além dos escores por regressão e de Bartlett, a implementação utilizada oferece os métodos **Anderson–Rubin**, **ten Berge** e **Harman**.

O método **Anderson–Rubin** produz escores padronizados e mutuamente não correlacionados, propriedade compatível com uma representação fatorial ortogonal.

O método **ten Berge** procura preservar, nos escores, a estrutura de correlações entre os fatores.

O método **Harman** utiliza uma construção não ponderada, em contraste com o critério de Bartlett, que pondera os resíduos pelas variâncias específicas.

Esses métodos podem produzir valores diferentes para uma mesma unidade observacional mesmo quando as cargas fatoriais, as comunalidades e as variâncias específicas permanecem fixadas. A escolha do método de escores não modifica a solução fatorial estimada; ela modifica a forma como valores são atribuídos às unidades no espaço fatorial.

15.15.9 Diferentes métodos de escores fatoriais

Os fatores são variáveis latentes e seus valores não são observados diretamente. Por isso, diferentes critérios podem atribuir escores distintos às mesmas unidades mesmo quando a solução fatorial permanece fixada (Johnson; Wichern, 2002).

O método por **regressão**, apresentado na Seção 15.14.5, corresponde à média condicional dos fatores dadas as variáveis observadas sob o modelo fatorial normal (Johnson; Wichern, 2002). O método de **Bartlett**, apresentado na Seção 15.15.8, utiliza mínimos quadrados ponderados pelas variâncias específicas (Anderson, 2003).

A tabela resume a propriedade utilizada para distinguir as opções de escores disponíveis na implementação.

Tabela 15.6: Métodos de escores fatoriais considerados na implementação utilizada.

Método	Característica utilizada na escolha
Thurstone ou regressão	prediz os fatores a partir das variáveis observadas; no modelo normal corresponde à média condicional
Bartlett	pondera os resíduos pelas variâncias específicas
Anderson–Rubin	produz escores padronizados e mutuamente não correlacionados
ten Berge	procura preservar nos escores a estrutura de correlações entre os fatores
Harman	utiliza uma construção não ponderada para obtenção dos escores

Os valores dos escores dependem do método empregado. Essa escolha não modifica as cargas fatoriais, as comunalidades, as variâncias específicas nem a matriz de covariâncias reproduzida, pois os escores são obtidos após a estimação da solução fatorial.

Quando escores fatoriais forem utilizados em análises posteriores, o método empregado em seu cálculo deve ser informado.

15.15.10 Estabilidade e validação da solução

Uma solução fatorial obtida em uma única amostra pode refletir características específicas das observações analisadas. A plausibilidade da interpretação não garante que a mesma estrutura seja reproduzida em outra amostra; por isso, a estabilidade amostral deve ser examinada quando os dados disponíveis permitirem (Hair et al., 2009).

Uma forma direta de avaliação consiste em **reestimar a análise em subamostras** e comparar as soluções obtidas. Quando uma amostra independente estiver disponível, a repetição da análise nessa nova amostra fornece uma avaliação mais direta da capacidade de reprodução da estrutura em dados distintos (Hair et al., 2009).

A comparação deve considerar os principais objetos utilizados na interpretação da solução, entre eles:

- o número de fatores retidos;
- o padrão das cargas fatoriais;
- as variáveis associadas predominantemente a cada fator;
- as comunalidades;
- a ocorrência de cargas cruzadas;
- as correlações entre fatores, quando a rotação é oblíqua.

A comparação literal das colunas das matrizes de cargas exige cuidado. Como sinais, permutações e, antes da escolha de uma orientação, rotações podem produzir representações equivalentes, diferenças nesses aspectos não constituem necessariamente diferenças na estrutura fatorial. As soluções devem ser comparadas depois de estabelecer correspondência entre os fatores e considerar as indeterminações discutidas na Seção 15.14.1.

A estabilidade também pode ser examinada por **análises de sensibilidade**. Johnson e Wichern (Johnson; Wichern, 2002) recomendam comparar soluções obtidas com diferentes métodos de estimação e com números próximos de fatores. Resultados semelhantes quanto à organização das cargas e à interpretação dos fatores indicam menor dependência de uma decisão analítica específica.

Essas comparações avaliam aspectos diferentes. A concordância entre métodos ou critérios na mesma amostra examina a **sensibilidade da solução às decisões analíticas**; a reprodução em subamostras ou em novas amostras examina sua **estabilidade amostral**. Nenhuma dessas avaliações garante a unicidade da representação fatorial nem sua reprodução em populações distintas.

Quando a amostra é dividida, cada subamostra precisa conter observações suficientes para permitir a estimação do mesmo modelo. Caso contrário, diferenças entre as soluções podem resultar do aumento da variabilidade amostral provocado pela redução do número de observações.

15.15.11 Correspondência com a implementação utilizada

Nas atividades computacionais, a Análise Fatorial Exploratória será realizada pela análise EFA do núcleo do [jamovi](#) (The jamovi project, 2026). A mesma análise pode ser executada diretamente em R por `jmv::efa()`, com opções correspondentes para o método de estimação, a escolha do número de fatores, a rotação e os diagnósticos apresentados pela interface. As opções da implementação correspondem a etapas estatísticas distintas da análise.

Tabela 15.7: Correspondência entre opções da implementação e os objetos estatísticos desenvolvidos no capítulo.

Elemento da implementação	Correspondência estatística	Desenvolvimento no capítulo
Minimum residuals	estimação pelo método MINRES	Seção 15.15.3
Principal axis	estimação pelo método de fatores ou eixos principais	Seção 15.15.3
Maximum likelihood	estimação sob o modelo fatorial normal por máxima verossimilhança	Seção 15.14.3
Based on parallel analysis, Based on eigenvalue e Fixed number	procedimentos para determinar ou fixar o número de fatores	Seção 15.15.4
KMO measure of sampling adequacy	KMO global e medidas individuais MSA_i	Seção 15.15.1
Bartlett's test of sphericity	teste de $H_0 : \mathcal{R} = \mathbf{I}_p$	Seção 15.15.1
Varimax, Quartimax, Oblimin e Promax	critérios de rotação considerados no capítulo	Seção 15.15.6
Simplimax	rotação oblíqua disponível na implementação, não desenvolvida neste capítulo	Seção 15.10
Factor correlations	estimativa da matriz de correlações fatoriais $\hat{\Omega}$ em soluções oblíquas	Seção 15.10
Model fit measures	medidas de ajuste calculadas para a solução fatorial estimada	Seção 15.14.3 , Seção 15.15.5 e esta seção
Thurstone, Bartlett, ten Berge, Anderson–Rubin e Harman	diferentes critérios para obtenção dos escores fatoriais	Seção 15.14.5 e Seção 15.15.9

Na EFA da implementação utilizada, as raízes empregadas por **Based on eigenvalue** e **Based on parallel analysis** dependem do método de estimação selecionado. A implementação obtém essas raízes a partir do procedimento fatorial correspondente tanto para os dados observados quanto, na análise paralela, para as matrizes de referência simuladas. Portanto, elas não devem ser identificadas automaticamente com os autovalores da matriz de correlações **R** utilizados na ACP. Essa distinção é discutida na Seção 15.15.4.

A opção *Principal axis* não corresponde à Análise de Componentes Principais. Na ACP, os autovetores da matriz de covariâncias ou de correlações definem as direções principais e os autovalores são as variâncias das componentes correspondentes. No método de fatores principais, decomposições espectrais sucessivas são aplicadas a uma matriz reduzida cuja diagonal contém communalidades estimadas.

A opção *Factor correlations* apresenta a estimativa de Ω nas soluções oblíquas. Nas rotações ortogonais, as correlações entre fatores são fixadas em zero pela própria parametrização.

A opção **Model fit measures** apresenta estatística qui-quadrado, graus de liberdade, *p*-valor, RMSEA com intervalo de confiança, TLI e BIC. A implementação obtém essas medidas a partir da solução fatorial ajustada e as disponibiliza para os diferentes métodos de estimação.

No procedimento utilizado pelo jamovi, a matriz de correlações reproduzida é construída a partir das cargas e, nas soluções oblíquas, da matriz de correlações fatoriais. A partir dessa matriz, são calculadas uma função de discrepância e medidas de ajuste associadas.

Quando a solução é estimada por **Maximum likelihood**, o teste qui-quadrado está diretamente relacionado ao quadro de ajuste por máxima verossimilhança desenvolvido na Seção 15.14.3. Quando a solução é obtida por **Minimum residuals** ou **Principal axis**, entretanto, as medidas de ajuste são calculadas depois da estimação a partir da matriz reproduzida; elas não constituem o critério utilizado na estimação dos fatores e não transformam esses métodos em procedimentos de máxima verossimilhança.

O **BIC** apresentado pela implementação também deve ser interpretado nesse contexto. No procedimento computacional utilizado, ele é calculado a partir da estatística qui-quadrado e dos graus de liberdade da solução. Para métodos de estimação que não utilizam máxima verossimilhança, esse valor não deve ser identificado automaticamente com o critério de Schwarz derivado diretamente de uma log-verossimilhança maximizada.

RMSEA e TLI são medidas auxiliares de avaliação global do ajuste. Valores de referência desenvolvidos em outros contextos, especialmente CFA e SEM, não devem ser transferidos mecanicamente para a AFE como limites universais de aceitação.

Na implementação utilizada, **Thurstone** corresponde ao método de escores por regressão desenvolvido na Seção 15.14.5. O cálculo utiliza a matriz de correlações amostral e, nas soluções oblíquas, incorpora a matriz de estrutura fatorial associada às cargas e às correlações entre fatores.

15.15.11.1 Inspeção dos objetos fatoriais com `psych::fa()`

Os objetos estatísticos utilizados na interpretação também podem ser examinados diretamente em R. Para manter o mesmo conjunto de observações utilizado na análise com casos completos, considere:

Na solução oblíqua, `loadings` contém a matriz de padrão, `Structure` contém a matriz de estrutura e `Phi` contém as correlações entre os fatores. `communality` e `uniquenesses` apresentam, respectivamente, as parcelas comum e não comum estimadas para cada variável.

15.15.11.2 Correspondência direta com `psych::fa()`

A função utilizada na estimação permite examinar diretamente objetos desenvolvidos no capítulo. Por exemplo, para uma solução MINRES com rotação Oblimin:

Em uma solução oblíqua, `loadings` contém a matriz de padrão, `Structure` contém a matriz de estrutura e `Phi` contém as correlações entre os fatores. `communality` e `uniquenesses` correspondem às parcelas comum e não comum estimadas para cada variável.

Dados ausentes na implementação utilizada

Antes da execução da EFA, a implementação utilizada remove as unidades que apresentem valores ausentes em alguma das variáveis selecionadas para a análise. Consequentemente, a matriz de correlações, o tamanho amostral utilizado nos testes e as demais estimativas são calculados a partir do conjunto de casos completos nessas variáveis. Esse tratamento constitui uma decisão operacional da implementação e não uma propriedade do modelo fatorial. Quando houver dados ausentes, a redução da amostra e o mecanismo responsável pelas ausências devem ser considerados na interpretação dos resultados.

15.16 Síntese

A Análise Fatorial representa a estrutura de covariâncias entre p variáveis observadas por meio de um número menor $m < p$ de fatores comuns latentes e de fatores específicos. No modelo ortogonal,

$$\mathbf{X} = \mu + \Phi \mathbf{F} + \varepsilon,$$

com

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m, \quad \text{Cov}(\varepsilon) = \Psi, \quad \text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0}.$$

Consequentemente,

$$\Sigma = \Phi\Phi^\top + \Psi.$$

A matriz

$$\Phi\Phi^\top$$

é a matriz de covariâncias da parcela comum, enquanto a matriz diagonal Ψ reúne as variâncias específicas. Para uma variável padronizada,

$$1 = h_i^2 + \psi_i, \quad h_i^2 = \sum_{j=1}^m \phi_{ij}^2,$$

em que h_i^2 é a comunalidade e ψ_i é a variância específica de X_i .

As cargas fatoriais relacionam as variáveis observadas aos fatores comuns. No modelo ortogonal com variáveis padronizadas,

$$\text{Corr}(X_i, F_j) = \phi_{ij}.$$

A orientação dos fatores não é determinada univocamente pelo modelo. Inversões de sinal, permutações e transformações ortogonais podem produzir representações equivalentes da mesma matriz de covariâncias da parcela comum. A rotação seleciona uma orientação da solução para interpretação e não constitui um novo método de estimação.

Quando são admitidos fatores correlacionados, escreve-se

$$\text{Cov}(\mathbf{F}) = \Omega,$$

mantidas as demais condições do modelo de fatores comuns. Nesse caso,

$$\Sigma = \Phi\Omega\Phi^\top + \Psi.$$

Como representações diferentes podem produzir a mesma estrutura observável, a estimação requer uma parametrização identificada. As restrições de identificação selecionam uma representação entre parametrizações equivalentes; posteriormente, a rotação pode alterar a orientação dos fatores sem modificar a estrutura que deve ser preservada pela transformação considerada.

No nível amostral, a matriz de covariâncias $\mathbf{S}$ ou a matriz de correlações $\mathbf{R}$ fornece a estrutura de segunda ordem a partir da qual os parâmetros do modelo são estimados. A solução amostral constitui, portanto, uma estimativa da estrutura fatorial especificada em nível populacional.

O número de fatores, o conjunto de variáveis e a escala utilizada na análise influenciam a solução obtida. A normalidade multivariada não é necessária para definir a decomposição de segunda ordem

$$\Sigma = \Phi\Phi^\top + \Psi.$$

Ela constitui uma hipótese probabilística adicional quando se adota o modelo fatorial normal e procedimentos inferenciais que dependem dessa formulação.

Os fatores comuns são variáveis latentes e não são observados diretamente. Os escores fatoriais são utilizados para estimar ou prever suas realizações associadas às unidades observacionais. Como sua obtenção requer um critério adicional, métodos distintos podem produzir escores diferentes para a mesma unidade sem modificar a solução fatorial estimada.

A Análise Fatorial e a Análise de Componentes Principais resolvem problemas distintos. A ACP constrói componentes como combinações lineares das variáveis observadas e decompõe a variância total representada pela matriz analisada. A Análise Fatorial especifica um modelo latente no qual os fatores representam a parcela comum da variabilidade e Ψ representa separadamente as variâncias específicas.

O significado atribuído aos fatores deve ser construído a partir do padrão de cargas e do significado das variáveis incluídas na análise. Além disso, uma estrutura obtida em uma amostra não garante sua reprodução em outra amostra ou população.

No Capítulo 16, o objeto de interesse passa das relações entre variáveis para a formação de grupos de observações. A Análise de Agrupamentos será formulada a partir de medidas de proximidade e de critérios utilizados para reunir observações em grupos.

16 Formulação da Análise de Agrupamentos

A Análise de Agrupamentos organiza objetos em grupos a partir de uma representação dos dados, de uma medida de proximidade e de um critério que define a organização procurada (Hair et al., 2009; Johnson; Wichern, 2002).

Sua formulação reutiliza a matriz de dados da Definição 1.6, a distância euclidiana da Definição 1.13, as geometrias induzidas da Definição 3.17 e a decomposição da dispersão intragrupos e entre grupos estabelecida na Proposição 8.9.

A formulação distingue partições e hierarquias. As K -médias definem uma partição pela minimização da dispersão intragrupos, enquanto os métodos hierárquicos constroem uma sequência de fusões segundo uma medida de proximidade e uma regra de ligação. O capítulo também examina as decisões sobre representação dos objetos, número de grupos, inicialização, estabilidade e interpretação da solução.

Os elementos que definem o problema são organizados na Tabela 16.1.

Tabela 16.1: Elementos que definem um problema de Análise de Agrupamentos.

Elemento	Objeto	Papel na análise
Representação dos objetos	matriz de dados $\mathbf{X}$ ou matriz de dissimilaridades Δ	determina a informação disponível para comparar os objetos
Proximidade	distância, dissimilaridade ou similaridade	define como diferenças ou semelhanças entre objetos são quantificadas
Organização	partição $\mathcal{P}$ ou estrutura hierárquica	representa os grupos construídos
Critério	função de perda, medida de dispersão ou regra de ligação	define como organizações candidatas são avaliadas ou construídas
Solução	organização resultante	partição ou hierarquia obtida segundo o critério adotado

A mesma coleção de observações pode produzir agrupamentos diferentes quando um desses elementos é alterado. Por isso, a Análise de Agrupamentos não possui uma definição universal de grupo independente da representação, da proximidade e do critério utilizado.

16.1 O problema de formação de grupos

Considere n objetos representados pelas linhas da matriz de dados

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p},$$

conforme a Definição 1.6.

Os grupos não são conhecidos previamente. O objetivo é construir uma organização dos índices das observações segundo a representação dos objetos, a medida de proximidade e o critério adotado.

O significado de pertencer ao mesmo grupo depende desse critério. Nas K -médias, os grupos são definidos pela concentração das observações em torno de centroides; nos métodos hierárquicos, pela regra utilizada para comparar e reunir conjuntos de objetos.

Essa formulação distingue a Análise de Agrupamentos da Análise Discriminante (apresentada no Capítulo 19). Na Análise de Agrupamentos, a própria organização dos objetos faz parte da solução; na Análise Discriminante, os grupos são conhecidos previamente e integram a informação utilizada pela técnica.

A Figura 16.1 mostra uma mesma configuração bidimensional organizada de duas formas. A figura ilustra que os pontos observados, isoladamente, não determinam qual partição deve ser escolhida.

As duas organizações mantêm os mesmos pontos e alteram somente a regra utilizada para reuni-los. A figura representa uma característica da técnica: a estrutura de grupos deve ser interpretada em relação ao critério que a produziu.

16.2 Representação dos objetos e proximidade

A matriz de dados não é a única forma de entrada da Análise de Agrupamentos. Quando as coordenadas dos objetos estão disponíveis, a proximidade pode ser calculada a partir das linhas de $\mathbf{X}$. Cada linha $\mathbf{x}_i$ representa um objeto, e sua coordenada x_{ij} corresponde ao valor da variável j para esse objeto. Quando as relações entre os objetos já são fornecidas diretamente, a análise pode partir de uma matriz de dissimilaridades (Johnson; Wichern, 2002).

A distância euclidiana definida na Definição 1.13, para duas observações $\mathbf{x}_i$ e $\mathbf{x}_j$, é

$$d_{ij} = \|\mathbf{x}_i - \mathbf{x}_j\|.$$




Figura 16.1: Diferentes partições de uma mesma configuração de observações.

Sua forma quadrática é

$$d_{ij}^2 = \|\mathbf{x}_i - \mathbf{x}_j\|^2.$$

A distância euclidiana quadrática aparece nos critérios baseados em somas de quadrados. Nas K -médiãs, o critério utiliza as distâncias euclidianas quadráticas das observações aos centroides; no método de Ward, as fusões são avaliadas pelo aumento da dispersão quadrática intragrupos (Hair et al., 2009; Johnson; Wichern, 2002).

Pela Definição 3.17, uma matriz positiva definida determina uma geometria ponderada para comprimentos e distâncias. Diferentes escolhas dessa geometria podem atribuir proximidades diferentes ao mesmo conjunto de observações. A distância de Mahalanobis, definida na Definição 8.8, é uma aplicação estatística dessa construção (Johnson; Wichern, 2002).

A Análise de Agrupamentos também pode receber como entrada uma matriz

$$\Delta = (\delta_{ij}) \in \mathbb{R}^{n \times n},$$

na qual δ_{ij} representa a dissimilaridade entre os objetos i e j .

16.3 Dissimilaridades entre objetos

Definição 16.1 (Dissimilaridade). Seja

$$\mathcal{I} = \{1, \dots, n\}$$

um conjunto de objetos. Uma **dissimilaridade** é uma função

$$\delta : \mathcal{I} \times \mathcal{I} \longrightarrow [0, \infty),$$

na qual valores maiores representam menor proximidade entre os objetos.

Neste capítulo, serão consideradas dissimilaridades que satisfazem

$$\delta(i, i) = 0, \quad i \in \mathcal{I},$$

e

$$\delta(i, j) = \delta(j, i), \quad i, j \in \mathcal{I}.$$

Não será exigido que

$$\delta(i, j) > 0 \quad \text{para} \quad i \neq j,$$

nem que seja satisfeita a desigualdade triangular.

A matriz associada a δ é

$$\Delta = (\delta_{ij}), \quad \delta_{ij} = \delta(i, j).$$

Assim, uma distância métrica pode ser utilizada como dissimilaridade, mas uma dissimilaridade não precisa satisfazer todas as propriedades exigidas de uma distância métrica (Johnson; Wichern, 2002).

De forma correspondente, uma similaridade atribui valores maiores a objetos considerados mais semelhantes, enquanto distâncias e dissimilaridades atribuem valores maiores a objetos considerados mais afastados ou menos semelhantes (Hair et al., 2009; Johnson; Wichern, 2002).

A distinção entre matriz de atributos e matriz de dissimilaridades é sintetizada na Tabela 16.2.

Tabela 16.2: Formas de representação utilizadas na Análise de Agrupamentos.

Representação	Informação disponível	Consequência para a formulação
$\mathbf{X} \in \mathbb{R}^{n \times p}$	valores das p variáveis para cada objeto	a proximidade é construída a partir das coordenadas
$\Delta \in \mathbb{R}^{n \times n}$	dissimilaridades entre pares de objetos	o agrupamento pode ser formulado diretamente sobre as relações entre objetos

A escolha entre essas representações também delimita os métodos disponíveis. O critério das K -médias utiliza explicitamente centroides no espaço das variáveis e requer as coordenadas das observações. Ligações simples, completa e média podem ser formuladas diretamente a partir das dissimilaridades entre objetos; procedimentos que dependem de centroides ou de somas de quadrados exigem estrutura adicional sobre a representação.

A presença de uma medida de dissimilaridade não significa que ela possa substituir livremente a distância euclidiana na formulação das K -médias. No procedimento das K -médias, as observações são comparadas aos centroides dos grupos pela distância euclidiana (Johnson; Wichern, 2002). O centroide é o representante ótimo de um grupo porque a média minimiza a soma das distâncias euclidianas quadráticas às observações, conforme a Proposição 10.2. Ao modificar essa função de perda, podem mudar o representante ótimo do grupo, o critério e a própria definição do método. Por isso, procedimentos construídos a partir de outras dissimilaridades devem ser identificados pela formulação que efetivamente utilizam.

16.3.1 Efeito da escala

Considere uma transformação aplicada separadamente às variáveis,

$$x_{ij}^* = a_j + b_j x_{ij}.$$

Para dois objetos i e h , a distância euclidiana quadrática após a transformação é

$$(d_{ih}^*)^2 = \sum_{j=1}^p b_j^2 (x_{ij} - x_{hj})^2.$$

As translações a_j desaparecem das diferenças entre os objetos e, portanto, não alteram suas distâncias euclidianas. Se todas as variáveis recebem o mesmo fator de escala, $b_1 = \dots = b_p = b$, todas as distâncias são multiplicadas pelo mesmo fator $|b|$. Quando os fatores b_j diferem entre as variáveis, suas contribuições relativas para as distâncias são modificadas.

A padronização observada da Equação 8.66 é um caso particular dessa transformação. Como cada variável é dividida por seu próprio desvio-padrão, a padronização pode modificar as proximidades relativas e, conseqüentemente, os grupos obtidos (Hair et al., 2009).

A Figura 16.2 ilustra, em uma configuração bidimensional, como uma mudança relativa de escala entre as variáveis modifica a geometria utilizada para comparar os mesmos objetos.




Figura 16.2: Mudanças de escala alteram a geometria utilizada para comparar as observações.

A ampliação da segunda coordenada aumenta sua contribuição para as distâncias. Um método baseado nessas distâncias passa a comparar os mesmos objetos segundo outra geometria.

A padronização não constitui uma exigência geral da Análise de Agrupamentos. Ela altera a contribuição relativa das variáveis para as proximidades e pode modificar a solução obtida. A decisão de padronizar deve considerar os objetivos da análise e se as diferenças de escala entre as variáveis devem participar da definição de proximidade (Hair et al., 2009).

16.4 Partições

Uma das formas mais comuns de representar um agrupamento é por meio de uma partição rígida do conjunto de objetos. Nesse tipo de partição, cada objeto é atribuído a um único grupo.

Seja

$$\mathcal{I} = \{1, \dots, n\}$$

o conjunto dos índices das observações.

Definição 16.2 (Partição em grupos). Para

$$1 \leq K \leq n,$$

uma **partição em K grupos** é uma coleção

$$\mathcal{P} = \{C_1, \dots, C_K\}$$

de subconjuntos não vazios de $\mathcal{I}$ que satisfaz

$$C_k \cap C_\ell = \emptyset, \quad k \neq \ell,$$

e

$$\bigcup_{k=1}^K C_k = \mathcal{I}.$$

As duas condições estabelecem que:

- um objeto não pertence simultaneamente a dois grupos distintos;
- todos os objetos são atribuídos a algum grupo.

O número de elementos do grupo C_k será denotado por

$$n_k = |C_k|,$$

com

$$\sum_{k=1}^K n_k = n.$$

Os índices $1, \dots, K$ identificam os grupos, mas seus rótulos são arbitrários: permutar os rótulos de $C_1, \dots, C_K$ não modifica a partição.

A partição é um objeto combinatório: ela descreve como as observações estão distribuídas entre os grupos. Essa representação informa a composição dos grupos, mas não especifica a medida de proximidade, o critério de agrupamento ou o procedimento utilizado para produzir essa divisão.

A atribuição de uma observação a um grupo pode ser representada por meio de indicadores de pertinência,

$$u_{ik} = \begin{cases} 1, & i \in C_k, \\ 0, & i \notin C_k. \end{cases}$$

Assim, $u_{ik} = 1$ indica que a observação i pertence ao grupo C_k , enquanto $u_{ik} = 0$ indica que ela não pertence a esse grupo.

Para uma partição rígida,

$$\sum_{k=1}^K u_{ik} = 1, \quad i = 1, \dots, n. \quad (16.1)$$

Como $u_{ik} \in \{0, 1\}$, essa restrição estabelece que, para cada observação i , exatamente um dos K indicadores de pertinência é igual a 1. Portanto, cada observação pertence a um único grupo.

16.5 Homogeneidade interna e separação

Uma partição só pode ser comparada com outras partições depois que se estabelece um critério de agrupamento.

Considere

$$\mathcal{P} = \{C_1, \dots, C_K\}.$$

Alguns critérios avaliam diretamente a dispersão intragrupos; outros utilizam relações de proximidade entre observações ou entre conjuntos de observações. A separação entre grupos pode resultar dessas construções sem constituir uma parcela explícita do critério utilizado.

A Proposição 10.2 estabelece que a média minimiza a soma das distâncias euclidianas quadráticas. Aplicada a cada grupo da partição, essa propriedade identifica seu centroide como o ponto que minimiza a dispersão quadrática intragrupo.

16.6 Centroides e dispersão quadrática

Cada grupo de uma partição pode ser resumido geometricamente por seu centroide. Para

$$\mathcal{P} = \{C_1, \dots, C_K\},$$

com

$$n_k = |C_k|,$$

o **centroide** do grupo C_k será denotado por

$$\bar{\mathbf{x}}_k = \frac{1}{n_k} \sum_{i \in C_k} \mathbf{x}_i. \quad (16.2)$$

Como os grupos da partição são não vazios, $n_k > 0$, e $\bar{\mathbf{x}}_k \in \mathbb{R}^p$. O centroide é a média vetorial das observações pertencentes ao grupo e constitui uma característica da partição observada (Hair et al., 2009; Johnson; Wichern, 2002).

Nas K -médias, cada observação é comparada aos centroides dos grupos por meio da distância euclidiana. Essa representação conduz a um critério baseado na dispersão quadrática das observações em torno de seus centroides (Johnson; Wichern, 2002).

16.6.1 Dispersão intragrupos e entre grupos

A Definição 8.13 e a Definição 8.14 definem as matrizes de dispersão intragrupos e entre grupos, e a Proposição 8.9 estabelece

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}.$$

Nesses resultados, os grupos são dados. Na Análise de Agrupamentos, a mesma decomposição assume outra função: a partição é desconhecida e passa a integrar o problema de agrupamento.

Para uma partição

$$\mathcal{P} = \{C_1, \dots, C_K\},$$

a matriz intragrupos pode ser escrita, utilizando os centroides definidos na Equação 16.2, como

$$\mathbf{T}_{\text{intra}}(\mathcal{P}) = \sum_{k=1}^K \sum_{i \in C_k} (\mathbf{x}_i - \bar{\mathbf{x}}_k) (\mathbf{x}_i - \bar{\mathbf{x}}_k)^\top. \quad (16.3)$$

Tomando o traço,

$$\begin{aligned} \text{tr}[\mathbf{T}_{\text{intra}}(\mathcal{P})] &= \sum_{k=1}^K \sum_{i \in C_k} \text{tr}[(\mathbf{x}_i - \bar{\mathbf{x}}_k) (\mathbf{x}_i - \bar{\mathbf{x}}_k)^\top] \\ &= \sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \bar{\mathbf{x}}_k\|^2. \end{aligned} \quad (16.4)$$

A Equação 16.4 expressa o traço da matriz intragrupos definida na Definição 8.13 como um critério escalar para comparar partições.

Quanto menores forem as distâncias quadráticas das observações aos centroides de seus grupos, menor será

$$\text{tr}(\mathbf{T}_{\text{intra}}).$$

Como a matriz total $\mathbf{T}$ não depende da partição e

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

segue também que

$$\text{tr}(\mathbf{T}) = \text{tr}(\mathbf{T}_{\text{intra}}) + \text{tr}(\mathbf{T}_{\text{entre}}). \quad (16.5)$$

Para o conjunto de observações fixado, $\text{tr}(\mathbf{T})$ não depende da partição. Portanto, entre as partições admissíveis em K grupos não vazios, minimizar $\text{tr}(\mathbf{T}_{\text{intra}})$ equivale a maximizar $\text{tr}(\mathbf{T}_{\text{entre}})$.

Essa equivalência decorre da decomposição quadrática da dispersão e não deve ser estendida a critérios de agrupamento definidos por outras formas de proximidade entre grupos. A formulação das K -médias utiliza a dispersão quadrática intragrupos.

16.6.2 Formulação das K -médias

O método das K -médias forma K grupos representados por seus centroides. As observações são comparadas aos centroides pela distância euclidiana, e o procedimento de realocação utiliza o centroide mais próximo (Johnson; Wichern, 2002). A dispersão quadrática das observações em torno dos centroides fornece o critério utilizado neste capítulo para representar a homogeneidade intragrupos.

Definição 16.3 (Critério das K -médias). Para uma partição

$$\mathcal{P} = \{C_1, \dots, C_K\},$$

a dispersão quadrática intragrupos pode ser escrita como

$$J_K(\mathcal{P}) = \sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \bar{\mathbf{x}}_k\|^2, \quad (16.6)$$

em que

$$\bar{\mathbf{x}}_k = \frac{1}{n_k} \sum_{i \in C_k} \mathbf{x}_i.$$

A propriedade de que esses centroides minimizam o critério para uma partição fixada decorre diretamente da Proposição 10.2.

Pela relação na Equação 16.4,

$$J_K(\mathcal{P}) = \text{tr}[\mathbf{T}_{\text{intra}}(\mathcal{P})]. \quad (16.7)$$

Nas K -médias, a estrutura da Definição 8.13 e da Proposição 8.9 é aplicada a uma partição desconhecida, e o critério passa a ser utilizado para comparar partições em K grupos.

A partir da Equação 16.5,

$$J_K(\mathcal{P}) = \text{tr}(\mathbf{T}) - \text{tr}[\mathbf{T}_{\text{entre}}(\mathcal{P})].$$

Como

$$\text{tr}(\mathbf{T})$$

é constante para a mesma matriz de dados, minimizar o critério das K -médias equivale a maximizar

$$\text{tr}[\mathbf{T}_{\text{entre}}(\mathcal{P})]. \quad (16.8)$$

Como a dispersão entre grupos pode ser escrita em função dos centroides e de seus tamanhos,

$$\mathbf{T}_{\text{entre}} = \sum_{k=1}^K n_k (\bar{\mathbf{x}}_k - \bar{\mathbf{x}})(\bar{\mathbf{x}}_k - \bar{\mathbf{x}})^\top,$$

tem-se

$$\text{tr}(\mathbf{T}_{\text{entre}}) = \sum_{k=1}^K n_k \|\bar{\mathbf{x}}_k - \bar{\mathbf{x}}\|^2. \quad (16.9)$$

Para a mesma matriz de dados e um valor fixado de K ,

$$\text{tr}(\mathbf{T})$$

é constante entre as partições admissíveis. Assim, uma partição minimiza

$$\text{tr}(\mathbf{T}_{\text{intra}})$$

se, e somente se, maximiza

$$\text{tr}(\mathbf{T}_{\text{entre}}).$$

As duas formulações expressam, portanto, o mesmo critério das K -médias para partições com K grupos.

16.6.3 Partição para centros fixados

Considere os centros

$$\mathbf{c}_1, \dots, \mathbf{c}_K$$

como fixados. A regra utilizada pelas K -médias associa cada observação a um grupo cujo centroide apresenta distância euclidiana mínima (Johnson; Wichern, 2002). Em notação compacta,

$$k_i \in \arg \min_{1 \leq k \leq K} \|\mathbf{x}_i - \mathbf{c}_k\|^2. \quad (16.10)$$

A utilização de $\in$ permite que a expressão não pressuponha unicidade quando mais de um centro atinge a mesma distância mínima.

Exemplo 16.1 (Comparação de duas partições). Considere quatro observações unidimensionais,

$$x_1 = 1, \quad x_2 = 2, \quad x_3 = 8, \quad x_4 = 9,$$

e duas partições candidatas com

$$K = 2.$$

Na primeira,

$$\mathcal{P}_1 = \{\{1, 2\}, \{3, 4\}\}.$$

Os centroides são

$$c_1 = 1,5$$

e

$$c_2 = 8,5.$$

Logo,

$$\begin{aligned} J_2(\mathcal{P}_1) &= (1 - 1,5)^2 + (2 - 1,5)^2 \\ &\quad + (8 - 8,5)^2 + (9 - 8,5)^2 \\ &= 1. \end{aligned}$$

Considere agora

$$\mathcal{P}_2 = \{\{1, 3\}, \{2, 4\}\}.$$

Os centroides são

$$c_1 = 4,5$$

e

$$c_2 = 5,5.$$

Nesse caso,

$$\begin{aligned} J_2(\mathcal{P}_2) &= (1 - 4,5)^2 + (8 - 4,5)^2 \\ &\quad + (2 - 5,5)^2 + (9 - 5,5)^2 \\ &= 49. \end{aligned}$$

Como

$$J_2(\mathcal{P}_1) = 1 < 49 = J_2(\mathcal{P}_2),$$

o critério atribui menor dispersão intragrupos a $\mathcal{P}_1$. A comparação utiliza a soma das distâncias quadráticas de cada observação ao centroide de seu grupo; distâncias entre pares de observações não entram isoladamente no critério das K -médias.

A comparação entre as partições é determinada pela soma das dispersões quadráticas dentro dos grupos. Distâncias elevadas entre alguns pares de observações, isoladamente, não definem a solução.

A formulação por centroides caracteriza grupos pela concentração quadrática em torno de centros. Os métodos hierárquicos utilizam outra estrutura: constroem uma sequência de agrupamentos aninhados a partir de regras de proximidade entre conjuntos.

16.7 Estrutura dos métodos hierárquicos

As K -médias procuram diretamente uma partição para um número K previamente fixado de grupos. Os métodos hierárquicos produzem outro objeto: uma sequência de partições aninhadas, na qual a organização dos grupos é construída progressivamente (Hair et al., 2009; Johnson; Wichern, 2002).

Os métodos hierárquicos podem ser aglomerativos ou divisivos. Nos procedimentos **aglomerativos**, cada objeto começa como um grupo unitário e grupos são sucessivamente reunidos; nos **divisivos**, parte-se de um único grupo, que é progressivamente subdividido. As formulações de ligação e do método de Ward desenvolvidas neste capítulo referem-se aos procedimentos aglomerativos (Hair et al., 2009; Johnson; Wichern, 2002).

A construção aglomerativa exige um critério para comparar os grupos disponíveis em cada etapa. Nas ligações simples, completa e média, esse critério é obtido a partir das dissimilaridades entre os objetos. No método de Ward, o critério é o aumento da dispersão quadrática intragrupos produzido por cada fusão. O dendrograma registra a hierarquia resultante.

Em um procedimento aglomerativo, parte-se da partição formada por n grupos unitários,

$$\mathcal{P}_n = \{\{1\}, \dots, \{n\}\},$$

e, a cada etapa, dois grupos são fundidos. Após uma fusão, obtém-se uma nova partição com um grupo a menos, até chegar a

$$\mathcal{P}_1 = \{\{1, \dots, n\}\}.$$

O percurso de $\mathcal{P}_n$ até $\mathcal{P}_1$ envolve, portanto, $n-1$ fusões. Depois de cada fusão, as proximidades entre o novo grupo e os grupos restantes são calculadas segundo o critério adotado (Johnson; Wichern, 2002).

As partições sucessivas são aninhadas: um grupo formado em determinada etapa permanece contido em algum grupo das etapas posteriores.

Definição 16.4 (Hierarquia de agrupamentos). Uma **hierarquia aglomerativa** é uma sequência de partições

$$\mathcal{P}_n, \mathcal{P}_{n-1}, \dots, \mathcal{P}_1,$$

na qual $\mathcal{P}_{r-1}$ é obtida de $\mathcal{P}_r$ pela fusão de exatamente dois grupos.

Considere dois grupos não vazios

$$A \subseteq \{1, \dots, n\}$$

e

$$B \subseteq \{1, \dots, n\}.$$

A matriz

$$\Delta = (\delta_{ij})$$

contém dissimilaridades entre objetos. Depois que objetos são reunidos em grupos, é necessário definir como dois grupos serão comparados.

Uma **regra de ligação** define uma dissimilaridade

$$D(A, B)$$

entre os grupos A e B a partir das dissimilaridades entre seus elementos. Diferentes regras utilizam informações distintas da mesma matriz Δ e, por isso, podem produzir hierarquias diferentes (Johnson; Wichern, 2002).

16.7.1 Ligações simples, completa e média

Três regras podem ser construídas diretamente a partir das dissimilaridades entre pares de objetos.

Na **ligação simples**,

$$D_{\text{simples}}(A, B) = \min_{\substack{i \in A \\ j \in B}} \delta_{ij}. \quad (16.11)$$

A proximidade entre os grupos é determinada pelo par mais próximo. A fusão pode, portanto, ocorrer quando existe uma conexão curta entre dois conjuntos, mesmo que outros elementos estejam relativamente afastados.

Na **ligação completa**,

$$D_{\text{completa}}(A, B) = \max_{\substack{i \in A \\ j \in B}} \delta_{ij}. \quad (16.12)$$

A comparação é determinada pelo par mais distante. Assim, a fusão é avaliada pela maior dissimilaridade entre os elementos dos dois grupos (Hair et al., 2009; Johnson; Wichern, 2002).

Na **ligação média**,

$$D_{\text{media}}(A, B) = \frac{1}{n_A n_B} \sum_{i \in A} \sum_{j \in B} \delta_{ij}. \quad (16.13)$$

A dissimilaridade entre os grupos corresponde à média das dissimilaridades entre todos os pares formados por um elemento de A e um elemento de B .

As três regras utilizam a mesma matriz de dissimilaridades, mas representam noções distintas de proximidade entre conjuntos.

A Tabela 16.3 compara as três definições de proximidade entre grupos.

Tabela 16.3: Regras de ligação construídas a partir das dissimilaridades entre objetos.

Regra de ligação	Dissimilaridade entre A e B	Estrutura privilegiada
simples	menor dissimilaridade entre pares	conexão entre elementos próximos
completa	maior dissimilaridade entre pares	controle da maior dissimilaridade entre os grupos candidatos à fusão
média	média das dissimilaridades entre pares	proximidade média entre os conjuntos

A diferença entre os critérios pode ser observada mesmo com poucos objetos. Considere dois grupos

$$A = \{1, 2\}$$

e

$$B = \{3, 4\},$$

com dissimilaridades entre seus elementos dadas por

$$\delta_{13} = 2, \quad \delta_{14} = 8, \quad \delta_{23} = 3, \quad \delta_{24} = 7.$$

Então,

$$D_{\text{simples}}(A, B) = 2,$$

$$D_{\text{completa}}(A, B) = 8$$

e

$$D_{\text{media}}(A, B) = \frac{2 + 8 + 3 + 7}{2 \times 2} = 5.$$

Os três valores diferem porque cada regra define a dissimilaridade entre grupos por uma característica distinta dos pares formados entre A e B .

16.7.2 Método de Ward e dispersão intragrupos

O método de Ward utiliza um critério de fusão baseado na dispersão quadrática intragrupos. Para objetos representados por coordenadas em um espaço euclidiano, cada etapa compara os aumentos de dispersão produzidos pelas fusões admissíveis (Hair et al., 2009; Johnson; Wichern, 2002).

Essa interpretação utiliza a matriz $\mathbf{T}_{\text{intra}}$ definida na Definição 8.13 e a decomposição estabelecida na Proposição 8.9.

Proposição 16.1 (Incremento de dispersão no método de Ward). *Para dois grupos não vazios A e B , com tamanhos n_A e n_B e centroides $\bar{\mathbf{x}}_A$ e $\bar{\mathbf{x}}_B$, a fusão aumenta a soma de quadrados intragrupos em*

$$D_{\text{Ward}}(A, B) = \frac{n_A n_B}{n_A + n_B} \|\bar{\mathbf{x}}_A - \bar{\mathbf{x}}_B\|^2. \quad (16.14)$$

O método de Ward seleciona, em cada etapa, entre todas as fusões possíveis, aquela que produz o menor valor de D_{Ward} . Pela Equação 16.14, esse incremento depende dos tamanhos dos dois grupos e da distância euclidiana quadrática entre seus centroides.

Ward e K -médias utilizam a dispersão quadrática intragrupos, mas constroem agrupamentos por procedimentos diferentes.

Nas K -médias, o número K é fixado e o procedimento produz diretamente uma partição em K grupos. No método de Ward, constrói-se uma hierarquia por fusões sucessivas. Em cada etapa, são reunidos os dois grupos cuja fusão produz o menor aumento da soma de quadrados intragrupos (Johnson; Wichern, 2002).

Uma fusão realizada em uma etapa do procedimento hierárquico permanece nas etapas posteriores. Assim, uma partição obtida pelo corte da hierarquia de Ward e uma partição produzida pelas K -médias não devem ser tratadas como resultados do mesmo procedimento.

A Figura 16.3 representa a diferença conceitual entre ligação simples, ligação completa e Ward para dois grupos.

Na ligação simples, apenas o par mais próximo determina a comparação. Na ligação completa, utiliza-se o par mais afastado. Em Ward, a distância entre centroides participa de uma expressão ponderada pelos tamanhos dos grupos e determina o aumento produzido na dispersão intragrupos.

A ligação média não aparece na figura porque utiliza simultaneamente todos os pares entre os dois grupos e não pode ser representada por um único segmento.

16.7.3 Dendrograma e níveis de fusão

A sequência produzida por um método hierárquico pode ser representada por um dendrograma.

Definição 16.5 (Dendrograma). Um **dendrograma** é uma representação gráfica de uma hierarquia de agrupamentos na qual as folhas representam os objetos e as alturas das junções registram os níveis associados às fusões entre grupos (Hair et al., 2009; Johnson; Wichern, 2002).

O dendrograma representa a sequência de partições aninhadas produzida pelo método. Quando os níveis de fusão permitem essa separação, um corte horizontal seleciona uma das partições contidas na hierarquia. Esse corte identifica uma partição da sequência, mas não estabelece que ela seja preferível às demais.

A escolha do número de grupos e os critérios auxiliares utilizados nessa decisão são tratados na Seção 16.12.4.

A Figura 16.4 apresenta uma hierarquia simples construída a partir de seis objetos.

O significado do eixo vertical do dendrograma depende do procedimento utilizado. Nas ligações baseadas em dissimilaridades, as junções registram os níveis de dissimilaridade em que ocorrem as fusões. No método de Ward apresentado por Johnson e Wichern, cada fusão é escolhida pelo menor aumento de ESS, enquanto o eixo vertical do dendrograma registra os valores de ESS nos quais as fusões ocorrem (Johnson; Wichern, 2002).




Figura 16.3: Diferentes critérios utilizam diferentes características para medir a proximidade entre dois grupos.




Figura 16.4: Representação hierárquica das fusões entre seis objetos. A altura registra o nível da fusão.

Assim, o critério utilizado para escolher uma fusão e a quantidade representada como altura no dendrograma não devem ser confundidos. Dendrogramas produzidos por procedimentos diferentes também não precisam apresentar alturas com o mesmo significado.

16.7.4 Uma partição e uma hierarquia representam objetos diferentes

As K -médias produzem diretamente uma partição

$$\mathcal{P} = \{C_1, \dots, C_K\}.$$

Um método hierárquico produz uma coleção ordenada de partições aninhadas.

Essa diferença modifica o tipo de informação fornecida pela técnica e é sintetizada na Tabela 16.4.

Tabela 16.4: Estruturas produzidas por diferentes formulações de agrupamento.

Estrutura	Resultado principal	Critério
K -médias	uma partição para K fixado	minimização da dispersão quadrática intragrupos
ligação simples	uma hierarquia	menor dissimilaridade entre grupos
ligação completa	uma hierarquia	maior dissimilaridade entre grupos
ligação média	uma hierarquia	média das dissimilaridades entre grupos
Ward	uma hierarquia	menor aumento da dispersão intragrupos

Nas K -médias, um grupo é representado por proximidade a um centroide. Na ligação simples, a formação de grupos depende da conectividade produzida por pares próximos. Na ligação completa, controla-se a maior dissimilaridade entre elementos de grupos candidatos à fusão. Na ligação média, considera-se conjuntamente o conjunto de dissimilaridades entre os dois grupos. Em Ward, a fusão é avaliada por seu efeito sobre a dispersão quadrática intragrupos.

Além disso, uma partição selecionada de uma hierarquia e uma partição produzida pelas K -médias para o mesmo número de grupos resultam de procedimentos diferentes e não precisam coincidir. A hierarquia conserva as fusões realizadas anteriormente e, portanto, restringe as partições que podem aparecer nas etapas posteriores.

16.8 Dependência da solução e limites da formulação

As K -médias e os métodos hierárquicos desenvolvidos neste capítulo podem ser formulados geometricamente, sem hipótese de normalidade multivariada ou de um modelo probabilístico gerador (Hair et al., 2009).

A solução depende das escolhas que definem o problema. A Tabela 16.5 resume essas dependências.

Tabela 16.5: Elementos dos quais depende uma solução de agrupamento.

Elemento modificado	Estrutura alterada	Consequência possível
conjunto de variáveis	representação dos objetos	proximidades e grupos podem mudar
escala das variáveis	geometria do espaço	variáveis recebem pesos relativos diferentes
métrica ou dissimilaridade	relação de proximidade	pares considerados próximos podem mudar
número de grupos ou corte da hierarquia	partição considerada	pode produzir organizações diferentes dos mesmos objetos
critério de agrupamento	avaliação ou construção da solução	partições ou hierarquias podem mudar
regra de ligação	critério de comparação entre grupos	pode alterar a sequência de fusões e a hierarquia

Adicionar, retirar ou transformar variáveis modifica a representação dos objetos e pode alterar as relações de proximidade. Mudanças de escala e de métrica modificam a geometria utilizada para compará-los.

Observações muito afastadas das demais também podem alterar a solução (Hair et al., 2009; Johnson; Wichern, 2002). Nas K -médias, elas podem deslocar centroides e aumentar a dispersão quadrática. Nos métodos hierárquicos, podem modificar as proximidades e a sequência de fusões. Como as fusões realizadas por um procedimento aglomerativo não são desfeitas, seus efeitos podem permanecer nas etapas posteriores da hierarquia (Hair et al., 2009; Johnson; Wichern, 2002).

A forma de grupo procurada também depende do critério. As K -médias representam grupos por centroides e minimizam dispersão quadrática intragrupos. As ligações simples, completa e média utilizam diferentes definições de proximidade entre conjuntos. O método de Ward seleciona fusões segundo o aumento da dispersão intragrupos.

A solução também pode depender do procedimento utilizado. Nas K -médias, diferentes inicializações podem conduzir a partições finais distintas (Hair et al., 2009; Johnson; Wichern, 2002);

nos métodos hierárquicos, empates podem produzir diferentes sequências de fusões (Johnson; Wichern, 2002). Além disso, os rótulos atribuídos aos grupos são arbitrários.

Os pressupostos e os limites devem, portanto, ser interpretados relativamente à formulação utilizada. A representação dos objetos, a proximidade e o critério de agrupamento fazem parte da própria definição do problema.

16.9 Limites da interpretação dos grupos

A Análise de Agrupamentos é uma técnica não supervisionada: os rótulos dos grupos não são conhecidos previamente.

Os procedimentos de agrupamento produzem uma organização dos objetos de acordo com a representação, a proximidade e o critério adotados. A obtenção de uma partição ou de uma hierarquia não demonstra, por si só, que exista uma estrutura de grupos na população (Hair et al., 2009).

Uma solução obtida por K -médias ou por um método hierárquico descreve uma organização dos objetos segundo a formulação adotada. A existência dessa solução não demonstra que os dados tenham sido gerados por populações distintas.

Solução de agrupamento e categorias externas

Uma solução de agrupamento organiza os objetos segundo as variáveis, a medida de proximidade e o critério utilizados. Essa solução não estabelece, por si só, correspondência com categorias definidas por informações externas ao procedimento de agrupamento.

Essa correspondência deve ser examinada utilizando variáveis que não participaram da formação dos grupos ou outras informações externas ao procedimento (Hair et al., 2009).

16.10 Relações com outras técnicas multivariadas

A Análise de Agrupamentos compartilha alguns objetos matemáticos com outras técnicas do módulo, mas esses objetos desempenham funções diferentes em cada problema. A Tabela 16.6 resume essas relações.

Tabela 16.6: Relações entre a Análise de Agrupamentos e outras técnicas multivariadas.

Técnica relacionada	Estrutura compartilhada	Diferença principal
ACP	representação das observações por coordenadas	ACP constrói novas coordenadas; Agrupamentos constrói grupos

Técnica relacionada	Estrutura compartilhada	Diferença principal
Análise Discriminante	grupos de observações	Agrupamentos constrói os grupos; Discriminante parte de grupos conhecidos
MANOVA	dispersão intragrupos e entre grupos	K -médias e Ward utilizam dispersão intragrupos na construção da solução; MANOVA parte de grupos ou tratamentos definidos para realizar inferência

16.10.1 Agrupamentos e ACP

Os escores das componentes principais fornecem novas coordenadas para as observações (Johnson; Wichern, 2002). Se essas coordenadas forem utilizadas como representação de entrada, a Análise de Agrupamentos passa a ser realizada no espaço dos escores.

Quando todas as componentes de uma transformação ortogonal são mantidas, as distâncias euclidianas são preservadas pela Proposição 4.9. Quando apenas $k < p$ componentes são mantidas, as observações são projetadas sobre o subespaço principal da Definição 14.2, e as distâncias passam a ser calculadas na representação reduzida.

A ACP pode ser utilizada para construir a representação das observações empregada na Análise de Agrupamentos, mas não constitui uma etapa obrigatória. Quando há redução efetiva de dimensão ou outra mudança prévia da representação dos dados, o agrupamento passa a ser realizado nessa nova representação.

16.10.2 Agrupamentos e Análise Discriminante

Na Análise de Agrupamentos, os grupos fazem parte da solução. Na Análise Discriminante formulada no Capítulo 19, os grupos são conhecidos previamente e integram a informação utilizada para construir funções discriminantes ou regras de classificação (Johnson; Wichern, 2002).

A diferença central está, portanto, no papel dos grupos: em Agrupamentos, eles são construídos a partir dos dados; em Análise Discriminante, eles são fornecidos antes da construção da regra discriminante.

16.10.3 Agrupamentos e MANOVA

A conexão com a MANOVA formulada no Capítulo 18 aparece na decomposição

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

estabelecida na Proposição 8.9.

Nas K -médias,

$$J_K(\mathcal{P}) = \text{tr}(\mathbf{T}_{\text{intra}}),$$

e a partição faz parte da solução do problema de agrupamento. O método de Ward também utiliza o aumento da dispersão quadrática intragrupos para selecionar cada fusão.

Na MANOVA, os grupos ou tratamentos são definidos antes da análise, e a decomposição da variabilidade participa da formulação inferencial sobre diferenças entre vetores de médias (Johnson; Wichern, 2002).

A decomposição da dispersão tem funções distintas nas duas técnicas: em Agrupamentos, a organização dos objetos é construída pelo procedimento; em MANOVA, os grupos ou tratamentos são definidos antes da análise.

16.11 Aprofundamentos teóricos

Leitura de aprofundamento

Esta parte aprofunda três propriedades matemáticas da Análise de Agrupamentos: o centroide como minimizador da soma de quadrados, a derivação do incremento de dispersão no método de Ward e a possível não unicidade da hierarquia na presença de empates.

16.11.1 O centroide como minimizador

Aplicando a Equação 10.38 e a Proposição 10.2 às observações de um grupo não vazio C_k , seu centroide

$$\bar{\mathbf{x}}_k = \frac{1}{n_k} \sum_{i \in C_k} \mathbf{x}_i$$

é o único ponto que minimiza

$$\sum_{i \in C_k} \|\mathbf{x}_i - \mathbf{c}\|^2$$

em relação a $\mathbf{c} \in \mathbb{R}^p$.

Essa propriedade explica o uso da média do grupo como centroide nos critérios quadráticos empregados pelas K -médias e pelo método de Ward (Johnson; Wichern, 2002).

16.11.2 Derivação do incremento de Ward

No método de Ward, cada etapa seleciona a fusão que produz o menor aumento da soma de quadrados intragrupos (ESS) (Johnson; Wichern, 2002).

Considere dois grupos disjuntos A e B , com tamanhos n_A e n_B , centroides $\bar{\mathbf{x}}_A$ e $\bar{\mathbf{x}}_B$ e centroide do grupo resultante

$$\bar{\mathbf{x}}_{A \cup B} = \frac{n_A \bar{\mathbf{x}}_A + n_B \bar{\mathbf{x}}_B}{n_A + n_B}.$$

Aplicando a Equação 10.38 aos grupos A e B , com $\bar{\mathbf{x}}_{A \cup B}$ como ponto de referência, o aumento da soma de quadrados intragrupos é

$$\begin{aligned} D_{\text{Ward}}(A, B) &= n_A \|\bar{\mathbf{x}}_A - \bar{\mathbf{x}}_{A \cup B}\|^2 + n_B \|\bar{\mathbf{x}}_B - \bar{\mathbf{x}}_{A \cup B}\|^2 \\ &= \frac{n_A n_B}{n_A + n_B} \|\bar{\mathbf{x}}_A - \bar{\mathbf{x}}_B\|^2. \end{aligned}$$

Obtém-se, assim, a expressão apresentada na Equação 16.14.

16.11.3 Empates e não unicidade da hierarquia

Em uma etapa do procedimento aglomerativo, mais de um par de grupos pode apresentar o mesmo menor valor do critério de fusão. Nesse caso, diferentes tratamentos dos empates podem produzir sequências de fusões e dendrogramas distintos (Johnson; Wichern, 2002).

16.12 Aprofundamentos metodológicos e aplicados

Leitura de aprofundamento

Esta parte trata das decisões de condução, interpretação e avaliação da Análise de Agrupamentos: preparação da representação dos objetos, escolha da proximidade e do pro-

cedimento, tratamento computacional de dados mistos, escolha do número de grupos, algoritmo e inicialização das K -médias, estabilidade, validação e correspondência com a implementação utilizada.

16.12.1 Preparação da representação para o agrupamento

As **variáveis de agrupamento** são as variáveis utilizadas para representar os objetos na formação dos grupos. Sua escolha, escala e redundância participam da definição de proximidade e podem modificar a solução (Hair et al., 2009).

16.12.1.1 Variáveis utilizadas na formação dos grupos

O conjunto de variáveis deve ser definido de acordo com o objetivo da análise. Incluir uma variável significa permitir que suas diferenças participem da construção dos grupos.

Variáveis destinadas à caracterização posterior dos grupos ou à avaliação da validade de critério podem ser mantidas fora da formação da partição e examinadas posteriormente. Essa separação evita utilizar a mesma informação simultaneamente para construir e para avaliar os grupos.

16.12.1.2 Escala e ponderação

O efeito da escala foi desenvolvido na Seção 16.3.1. Na condução da análise, deve-se decidir se diferenças nas unidades e amplitudes das variáveis devem produzir contribuições diferentes para as proximidades entre os objetos.

Quando essa ponderação não é desejada, a padronização pode colocar as variáveis em escalas comparáveis. Quando as diferenças de escala devem participar da definição de proximidade, a padronização modifica essa relação e não deve ser adotada automaticamente.

16.12.1.3 Redundância entre variáveis

Variáveis fortemente relacionadas podem produzir uma forma de ponderação implícita. Se várias variáveis representam praticamente a mesma característica, essa característica participa repetidamente do cálculo das proximidades.

Assim, mesmo quando todas as variáveis recebem o mesmo peso explícito, um conjunto numeroso de variáveis redundantes pode dominar a geometria da análise.

Esse problema difere da multicolinearidade em modelos de regressão. Na Análise de Agrupamentos, variáveis redundantes atribuem maior peso implícito às características que representam repetidamente no cálculo das proximidades (Hair et al., 2009).

16.12.1.4 Observações atípicas e representatividade

A Análise de Agrupamentos é sensível a observações muito diferentes das demais. A identificação de uma observação atípica não determina automaticamente sua exclusão (Hair et al., 2009).

Uma observação atípica pode corresponder a uma unidade aberrante não representativa da população, a um representante de um grupo pequeno ou a uma observação de um grupo real que esteja sub-representado na amostra (Hair et al., 2009).

A decisão sobre sua permanência deve considerar o objetivo da análise e a população de interesse. A retirada de observações pertencentes a grupos pequenos pode eliminar uma estrutura que deveria permanecer representada.

A generalização dos grupos depende da representatividade da amostra. A própria Análise de Agrupamentos não determina se o planejamento amostral representa adequadamente a população de interesse (Hair et al., 2009).

16.12.1.5 Tamanho da amostra e grupos pequenos

Na Análise de Agrupamentos, a consideração sobre tamanho da amostra não é formulada em termos de poder estatístico. A amostra deve ser suficientemente grande para representar a heterogeneidade da população e, quando pertinente ao objetivo da análise, permitir a identificação de grupos de baixa frequência (Hair et al., 2009).

Amostras pequenas podem representar grupos de baixa frequência por poucas observações, tornando mais difícil distinguir uma observação atípica de um representante de um grupo pequeno (Hair et al., 2009).

Grupos com poucas observações não devem ser excluídos automaticamente. Eles podem corresponder a observações atípicas ou a segmentos de baixa frequência que façam parte da população de interesse; sua interpretação deve considerar o objetivo da análise e a representatividade da amostra (Hair et al., 2009).

Tabela 16.7: Aspectos da preparação da representação que afetam a Análise de Agrupamentos.

Aspecto	Efeito sobre a solução	Questão metodológica
seleção das variáveis	define quais características participam da proximidade	as variáveis representam o conceito segundo o qual os objetos devem ser agrupados?
escala	altera a contribuição relativa das variáveis	diferenças de escala devem funcionar como ponderação?
redundância	repete implicitamente algumas dimensões	várias variáveis estão representando a mesma característica?
observações atípicas	podem alterar a solução ou formar grupos muito pequenos	são unidades aberrantes ou representantes de grupos pequenos?
tamanho da amostra	pode impedir que grupos de baixa frequência estejam representados nos dados	há observações suficientes para representar e caracterizar os grupos de interesse?

16.12.2 Dados mistos e dissimilaridade de Gower

Variáveis de naturezas diferentes exigem que a medida de proximidade seja escolhida de forma compatível com a informação que deve definir a semelhança entre os objetos.

Na implementação utilizada, a opção **Gower distance** aciona um procedimento específico para dados mistos. Esse procedimento não corresponde à simples substituição da distância euclidiana no critério clássico das K -médias.

A correspondência entre essa opção da interface e o procedimento computacional efetivamente utilizado é apresentada na Seção 16.12.7.

16.12.3 Escolha da medida de proximidade e do procedimento

A medida de proximidade e o procedimento de agrupamento devem ser escolhidos de forma compatível. A mesma matriz de dados pode produzir soluções diferentes quando muda a geometria utilizada para comparar os objetos ou o critério que define a formação dos grupos.

A primeira decisão é determinar qual informação deve representar a proximidade entre os objetos. Para variáveis quantitativas, a distância euclidiana utiliza diretamente as diferenças entre

suas coordenadas e é compatível com métodos baseados em centroides e dispersão quadrática. A distância de Mahalanobis incorpora a estrutura de covariâncias e modifica a geometria segundo a variabilidade e a associação entre as variáveis, conforme a Definição 8.8.

A medida de proximidade também depende do aspecto dos objetos que deve definir a semelhança. Medidas de distância comparam suas posições no espaço das variáveis. Medidas baseadas em correlação podem, quando pertinente ao objetivo da análise, comparar o padrão relativo das características (Hair et al., 2009). Nesse caso, objetos com níveis distintos podem apresentar padrões semelhantes. O procedimento de agrupamento deve ser compatível com a medida adotada.

Para dados de tipos diferentes, a implementação utilizada no capítulo disponibiliza uma rota baseada em **Gower distance**, apresentada na Seção 16.12.2. Essa rota deve ser distinguida da formulação euclidiana das K -médias desenvolvida no núcleo.

A segunda decisão é definir qual noção de grupo é compatível com o objetivo da análise. Os principais procedimentos desenvolvidos neste capítulo privilegiam estruturas diferentes.

Tabela 16.8: Relação entre procedimentos de agrupamento e a estrutura privilegiada por seus critérios.

Procedimento	Informação utilizada na formação dos grupos	Estrutura favorecida	Aspecto a examinar
K-médias	distâncias euclidianas quadráticas aos centroides	grupos concentrados em torno de médias	depende de K e da inicialização
ligação simples	menor dissimilaridade entre dois grupos	conexão determinada pelo par mais próximo	pode produzir encadeamento
ligação completa	maior dissimilaridade entre dois grupos	controle da maior dissimilaridade entre os grupos	depende do par mais afastado
ligação média	média das dissimilaridades entre todos os pares dos dois grupos	comparação baseada em todos os pares entre os grupos	não depende exclusivamente de um par extremo
Ward	aumento da dispersão quadrática intragrupos	grupos compactos segundo a dispersão quadrática intragrupos	requer compatibilidade com a geometria euclidiana adotada

A ligação simples pode produzir cadeias sucessivas de observações conectadas por pequenas dissimilaridades. Como resultado, observações situadas em extremos opostos de uma cadeia

podem pertencer ao mesmo grupo mesmo apresentando maior dissimilaridade entre si (Hair et al., 2009).

A ligação completa utiliza a maior dissimilaridade entre os grupos candidatos à fusão. Ela evita o mecanismo de encadeamento da ligação simples e tende a produzir grupos mais compactos, embora a comparação dependa dos elementos mais afastados de cada par de grupos.

A ligação média utiliza todas as dissimilaridades entre os dois grupos e não depende exclusivamente do par mais próximo ou mais afastado. Por isso, representa uma alternativa intermediária entre as ligações simples e completa (Hair et al., 2009).

O método de Ward procura limitar o aumento da dispersão intragrupos a cada fusão. Sua interpretação está diretamente vinculada à formulação quadrática desenvolvida na Seção 16.7.2. Observações atípicas podem alterar fortemente essa dispersão e, conseqüentemente, a sequência de fusões.

As K -médias utilizam uma partição com número de grupos previamente especificado e permitem a realocação das observações durante a busca computacional. Métodos hierárquicos produzem simultaneamente uma sequência de partições aninhadas e não desfazem fusões realizadas em etapas anteriores (Johnson; Wichern, 2002).

Quando o objetivo e os dados permitem mais de um procedimento, a comparação entre soluções permite examinar a sensibilidade da estrutura às escolhas metodológicas. Se procedimentos e medidas de proximidade plausíveis conduzem a organizações semelhantes, a interpretação apresenta menor dependência de uma escolha específica (Johnson; Wichern, 2002).

Uma estratégia possível consiste em utilizar inicialmente um método hierárquico para examinar diferentes números de grupos e obter centroides candidatos, seguidos por K -médias com esses centroides como valores iniciais (Hair et al., 2009). Essa combinação é uma estratégia computacional e não estabelece equivalência entre os dois critérios.

16.12.4 Escolha do número de grupos

A escolha do número de grupos é uma decisão metodológica. A Análise de Agrupamentos não dispõe de um procedimento padrão e objetivo que determine o número de grupos, de modo que diferentes soluções candidatas devem ser examinadas em conjunto com o objetivo da análise (Hair et al., 2009).

Nos procedimentos hierárquicos, Hair et al. propõem examinar mudanças na heterogeneidade produzidas pelas fusões, juntamente com o dendrograma e com considerações conceituais sobre as soluções candidatas (Hair et al., 2009). Um aumento acentuado da heterogeneidade pode indicar que a fusão seguinte reúne grupos mais distintos segundo o critério adotado, fornecendo uma referência para examinar a solução anterior.

16.12.4.1 Critérios auxiliares para comparar valores de K

Para uma solução de K -médias, a dispersão quadrática intragrupos

$$J_K(\mathcal{P}_K)$$

não aumenta quando se permite um número maior de grupos. Assim, a simples redução de J_K não determina quantos grupos devem ser mantidos. Os critérios auxiliares procuram avaliar como essa redução ocorre ou combinar informações sobre concentração intragrupos e separação entre grupos.

No **método do cotovelo**, examina-se a sequência da dispersão intragrupos para diferentes valores de K . Procura-se uma região em que a redução obtida pela inclusão de grupos adicionais passa a ser relativamente menor. O ponto de mudança pode não ser nítido, de modo que o gráfico não fornece, por si só, uma regra objetiva para determinar K .

O **índice de silhueta** pode ser definido a partir das dissimilaridades entre os objetos. Para uma observação i , seja $a(i)$ sua dissimilaridade média em relação às demais observações do próprio grupo e seja $b(i)$ a menor dissimilaridade média de i em relação às observações de qualquer outro grupo. A largura de silhueta é

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}.$$

Valores positivos maiores indicam que a observação está, segundo a dissimilaridade adotada, mais próxima do próprio grupo do que do grupo alternativo mais próximo. Valores próximos de zero indicam menor separação, e valores negativos indicam que a dissimilaridade média da observação em relação a outro grupo é menor do que em relação ao grupo ao qual foi atribuída. A média das larguras de silhueta pode ser utilizada para comparar partições candidatas. Como o índice é calculado a partir da própria partição e das dissimilaridades utilizadas na análise, ele constitui um critério interno e não uma validação externa dos grupos.

A **estatística Gap** compara uma medida de dispersão intragrupos observada com a dispersão obtida em conjuntos de referência gerados sem a mesma organização dos dados. Para cada valor de K , a comparação é realizada na escala logarítmica e incorpora a variabilidade das simulações de referência (Tibshirani; Walther; Hastie, 2001). Sua interpretação depende da definição da dispersão, da distribuição de referência e da regra utilizada para selecionar uma solução entre os valores de K examinados.

Esses critérios podem indicar soluções distintas. A escolha de K deve considerar conjuntamente os critérios compatíveis com o procedimento utilizado, os tamanhos e os perfis dos grupos, o objetivo da análise e as avaliações de estabilidade e validação (Hair et al., 2019).

A escolha final deve considerar as soluções candidatas em relação ao objetivo da análise, ao tamanho e aos perfis dos grupos e às avaliações de estabilidade e validação apresentadas na Seção 16.12.6.

16.12.4.2 Escolha de uma partição na hierarquia

Um método hierárquico fornece uma sequência aninhada de partições, representada pelo dendrograma. Escolher K significa selecionar, nessa sequência, uma partição com K grupos. Quando os níveis de fusão permitem essa representação, a mesma partição pode ser identificada por um corte horizontal no dendrograma.

Um aumento acentuado entre valores sucessivos de fusão indica que a etapa seguinte exige reunir grupos mais dissimilares segundo o critério adotado. Esse comportamento pode ser examinado no dendrograma ou diretamente na sequência dos valores de fusão.

O tamanho desse aumento não constitui um teste estatístico da existência de grupos e depende da medida de proximidade e do critério de ligação utilizados.

Uma partição candidata obtida por corte do dendrograma deve ser examinada quanto a:

- tamanho dos grupos;
- perfis das variáveis;
- observações que se unem somente em níveis elevados;
- estabilidade segundo os procedimentos examinados na Seção 16.12.6;
- interpretação dos grupos em relação ao objetivo da análise.

Quando diferentes cortes do dendrograma são plausíveis, a decisão deve considerar as diferenças entre os perfis produzidos por essas partições e não apenas a aparência gráfica da árvore.

Uma partição obtida pelo corte da hierarquia de Ward e uma partição produzida pelas K -médias resultam de procedimentos diferentes, conforme discutido na Seção 16.7.2. Suas soluções podem ser comparadas, mas não devem ser tratadas como resultados do mesmo procedimento.

16.12.5 Algoritmo das K -médias

O critério $J_K(\mathcal{P})$ e o algoritmo utilizado para obter uma partição devem ser distinguidos. O critério descreve a dispersão quadrática intragrupos, enquanto o algoritmo especifica o procedimento computacional utilizado para construir uma partição.

Uma versão sequencial das K -médias pode iniciar com uma partição em K grupos ou com K centroides iniciais. Os objetos são examinados e associados ao grupo cujo centroide é mais próximo. Quando ocorre uma realocação, os centroides dos grupos afetados são atualizados. O procedimento é repetido até que não ocorram novas realocações (Johnson; Wichern, 2002).

Procedimentos não hierárquicos de otimização permitem, portanto, que observações sejam redesignadas durante a formação dos grupos (Hair et al., 2009). As regras de atribuição e atualização pertencem ao algoritmo computacional utilizado. O critério $J_K(\mathcal{P})$ é um objeto distinto do algoritmo empregado para procurar a partição.

16.12.5.1 Inicialização e comparação entre execuções

O procedimento pode começar por uma partição inicial das observações ou por K centroides iniciais. A configuração inicial pode influenciar a atribuição final dos objetos aos grupos (Johnson; Wichern, 2002).

Por isso, para um mesmo valor de K e a mesma representação dos dados, o procedimento pode ser repetido a partir de diferentes inicializações. Johnson e Wichern recomendam essa repetição como uma forma de examinar a estabilidade da solução obtida (Johnson; Wichern, 2002).

Entre partições produzidas sob o mesmo critério, valores menores de

$$J_K(\mathcal{P})$$

correspondem a menor dispersão quadrática intragrupos. A comparação entre execuções também pode considerar os tamanhos dos grupos, seus centroides e as alocações das observações.

Diferentes inicializações podem conduzir a partições finais distintas. A partição obtida em uma execução deve, portanto, ser interpretada como o resultado produzido pelo algoritmo e pela configuração inicial utilizados; uma solução não hierárquica obtida dessa forma não é garantidamente ótima (Hair et al., 2009).

Centroides obtidos por um procedimento hierárquico também podem ser utilizados como pontos-semente de um procedimento não hierárquico, estratégia empregada por Hair et al. em sua condução aplicada da análise (Hair et al., 2009).

A estabilidade em relação à inicialização informa a sensibilidade da solução ao procedimento de busca. Ela não demonstra, por si só, a existência de grupos distintos na população.

16.12.6 Estabilidade, validação e perfil dos grupos

Uma solução de agrupamento deve ser examinada além do critério utilizado para produzi-la. As subseções seguintes distinguem a sensibilidade à inicialização, a validação cruzada por subamostras, a comparação entre procedimentos, a caracterização pelas variáveis de agrupamento, a validade de critério e o perfil com variáveis adicionais.

16.12.6.1 Sensibilidade à inicialização

A sensibilidade das K -médias à configuração inicial e a comparação entre diferentes execuções foram desenvolvidas na Seção 16.12.5.1. No contexto da avaliação da solução, essa análise informa sua dependência em relação ao procedimento de busca; ela não constitui evidência de generalização da partição para a população.

16.12.6.2 Validação cruzada por subamostras

Hair et al. propõem dividir aleatoriamente a amostra em duas subamostras, repetir a análise e comparar as soluções quanto ao número de grupos e aos seus perfis (Hair et al., 2009).

A reprodução de uma organização semelhante nas duas subamostras fornece informação sobre a consistência da solução dentro da amostra disponível. Diferenças entre as soluções devem ser examinadas considerando o número e o tamanho dos grupos e seus perfis.

Para soluções hierárquicas, Johnson e Wichern também indicam que a sensibilidade pode ser examinada comparando os agrupamentos antes e depois de pequenas perturbações nos dados (Johnson; Wichern, 2002).

16.12.6.3 Comparação entre procedimentos

Johnson e Wichern recomendam examinar mais de um procedimento de agrupamento e diferentes medidas de proximidade quando essas alternativas forem compatíveis com o problema (Johnson; Wichern, 2002).

Resultados semelhantes entre alternativas plausíveis indicam menor dependência da interpretação em relação a uma escolha metodológica específica. Essa concordância, entretanto, não constitui prova da existência de grupos na população.

16.12.6.4 Caracterização pelas variáveis de agrupamento

Depois de escolhida uma solução, os grupos devem ser caracterizados pelas variáveis que participaram de sua formação.

Para métodos baseados em centroides, os vetores

$$\bar{\mathbf{x}}_1, \dots, \bar{\mathbf{x}}_K$$

fornecem os perfis médios dos grupos. A comparação desses perfis permite identificar quais variáveis diferenciam os grupos e quais apresentam valores semelhantes entre eles (Hair et al., 2009).

O tamanho dos grupos e outras características da solução também auxiliam sua interpretação. Como essas informações derivam das próprias variáveis utilizadas para construir os grupos, elas caracterizam a solução e não constituem evidência de validade de critério.

16.12.6.5 Validade de critério com variáveis externas

Variáveis que não participaram da formação dos grupos podem ser reservadas para examinar a relação da solução com critérios externos.

Quando existe, com base no problema de pesquisa, uma relação esperada entre uma variável externa e os grupos, diferenças compatíveis com essa relação fornecem informação sobre a validade de critério da solução (Hair et al., 2009).

A variável utilizada como critério não deve participar da formação dos grupos, e a relação esperada deve ser definida a partir do problema de pesquisa.

16.12.6.6 Perfil dos grupos com variáveis adicionais

Variáveis que não participaram da formação dos grupos também podem ser utilizadas apenas para descrever os grupos depois que a solução foi escolhida (Hair et al., 2009).

Quando não existe uma relação externa previamente especificada, essas variáveis contribuem para a caracterização dos grupos, mas não devem ser tratadas como evidência de validade de critério.

Tabela 16.9: Procedimentos utilizados para avaliar e interpretar uma solução de agrupamento.

Dimensão examinada	Procedimento	Informação obtida
sensibilidade à inicialização	repetir K -médias com diferentes inicializações	dependência da solução em relação à inicialização
validação cruzada por subamostras	dividir a amostra e comparar as soluções	consistência do número e dos perfis dos grupos
comparação entre procedimentos	comparar métodos ou medidas de proximidade compatíveis com o problema	dependência da solução em relação às escolhas metodológicas
caracterização pelas variáveis de agrupamento	examinar os perfis das variáveis utilizadas na formação dos grupos	interpretação da própria solução
validade de critério	examinar variáveis externas para as quais exista uma relação esperada	relação da solução com critérios externos

Dimensão examinada	Procedimento	Informação obtida
perfil com variáveis adicionais	descrever os grupos por variáveis não utilizadas na formação	caracterização adicional dos grupos

A consistência entre inicializações, subamostras ou procedimentos não substitui a validade de critério. Além disso, nenhuma dessas verificações demonstra, isoladamente, a existência de grupos na população.

16.12.7 Correspondência com a implementação utilizada

Nas atividades computacionais, a Análise de Agrupamentos será realizada pelo módulo **snowCluster** (Seol, 2026) do **jamovi** (The jamovi project, 2026). As opções e saídas da interface correspondem a procedimentos computacionais distintos e devem ser relacionadas aos objetos estatísticos desenvolvidos no capítulo.

Tabela 16.10: Correspondência entre elementos da implementação e os objetos estatísticos desenvolvidos no capítulo.

Elemento da implementação	Correspondência estatística ou computacional	Desenvolvimento no capítulo
K-means Clustering	agrupamento de variáveis quantitativas pela rota baseada em <code>stats::kmeans()</code>	Seção 16.6.2
Number of clusters	número K de grupos especificado para o procedimento	Seção 16.12.4
Maximum clusters	maior valor de K examinado pelo Elbow plot ; na versão auditada, essa opção não é repassada ao cálculo do Gap statistic plot	Seção 16.12.4.1
Standardize variables	padronização da representação antes da formação dos grupos	Seção 16.3.1 e Seção 16.12.1
Algorithm	variante algorítmica utilizada na busca computacional da partição	Seção 16.12.5

Elemento da implementação	Correspondência estatística ou computacional	Desenvolvimento no capítulo
Number of random starting values	número de inicializações utilizadas na execução das K -médias	Seção 16.12.5.1
Centroids	médias vetoriais dos grupos obtidos	Seção 16.6.2
Within-cluster, between-cluster e total sum of squares	dispersões intragrupos, entre grupos e total na representação utilizada	Seção 16.6.1
Elbow plot	rota das K -médias que compara <code>tot.withinss</code> entre diferentes valores de K	Seção 16.12.4.1
Gap statistic plot	rota das K -médias baseada em <code>factoextra::fviz_nbclust(..., method = "gap_stat")</code> e <code>cluster::clusGap()</code>	Seção 16.12.4.1
Silhouette index	comparação de partições na rota Gower Distance por <code>clustMixType::validation_kproto(..., type = "gower")</code>	Seção 16.12.2 e Seção 16.12.4.1
Silhouette plot	médias das larguras de silhueta por grupo para uma partição obtida na rota de Gower	Seção 16.12.2 e Seção 16.12.4.1
Gower distance	rota específica para dados mistos que utiliza <code>clustMixType::kproto(..., type = "gower")</code> , e não as K -médias euclidianas clássicas	Seção 16.12.2
Cluster scatter plot	representação bidimensional das observações construída por ACP para fins gráficos	relação com ACP em Seção 16.10.1
Distance measure	medida utilizada para construir as dissimilaridades no agrupamento hierárquico	Seção 16.12.3
Clustering method	critério utilizado para selecionar as fusões na construção hierárquica	Seção 16.7 e Seção 16.12.3

Elemento da implementação	Correspondência estatística ou computacional	Desenvolvimento no capítulo
Ward.D e Ward.D2	convênções computacionais distintas disponibilizadas para o agrupamento hierárquico	Seção 16.7.2
Dendrogram	representação gráfica da hierarquia de fusões	Definição 16.5
Variable clustering (PCA)	agrupamento de variáveis em uma representação construída por ACP	não corresponde ao agrupamento das observações desenvolvido no núcleo
With p-values	agrupamento hierárquico de variáveis pela rota baseada em <code>pvclust</code>	não corresponde à validação da partição das observações

Na análise de K -médias para variáveis quantitativas, `stats::kmeans()`. A opção **Algorithm** altera o algoritmo computacional empregado na busca, enquanto **Number of random starting values** controla o número de inicializações. Essas escolhas não modificam a definição do critério $J_K(\mathcal{P})$ apresentado no núcleo.

A opção **Standardize variables** modifica a representação fornecida ao procedimento. Consequentemente, os centroides, as distâncias e as somas de quadrados apresentados na saída referem-se à escala efetivamente utilizada na análise. A escolha de padronizar deve ser interpretada de acordo com a discussão da Seção 16.12.1.

Nas rotas de K -médias, Gower e agrupamento hierárquico, a versão auditada utiliza casos completos no conjunto de variáveis selecionado para cada procedimento. Na rota de Gower, essa verificação considera conjuntamente as variáveis quantitativas e categóricas selecionadas. As observações excluídas recebem **NA** na variável de pertencimento salva pelo módulo.

Consequentemente, a inclusão ou retirada de uma variável com valores ausentes pode alterar também o conjunto de observações efetivamente utilizado no agrupamento. O número de casos analisados e eventuais diferenças em relação à amostra original devem ser considerados na interpretação da representatividade e dos tamanhos dos grupos.

O **Gap statistic plot** segue uma rota diferente, baseada em `factoextra::fviz_nbclust(..., method = "gap_stat")`, que utiliza `cluster::clusGap()`. Na versão auditada, essa chamada não repassa as opções **Algorithm** e **Number of random starting values** da análise principal. O gráfico deve, portanto, ser interpretado como um cálculo auxiliar, e não como uma avaliação obtida necessariamente sob a mesma configuração computacional da partição final. A implementação de `clusGap()` também possui convênções próprias para a medida de dispersão e para a seleção de K .

O **Silhouette index** pertence à rota **Gower Distance**. A versão auditada utiliza `clustMixType::validation_kproto(..., type = "gower")` para comparar números de grupos segundo a silhueta média. O **Silhouette plot** parte de uma partição de Gower com K fixado, calcula larguras de silhueta por `cluster::silhouette()` e apresenta a média dessas larguras separadamente para cada grupo. Assim, o gráfico não representa a curva utilizada pelo **Silhouette index** para comparar diferentes valores de K .

A opção **Gower distance** deve, portanto, ser distinguida da formulação euclidiana das K -médias desenvolvida no núcleo.

O **Cluster scatter plot** é uma representação gráfica bidimensional da partição. Na versão auditada, o **snowCluster** utiliza `factoextra::fviz_cluster()`, cuja configuração padrão padroniza os dados empregados na representação gráfica. Quando há mais de duas variáveis, esses dados padronizados são então projetados nas duas primeiras componentes principais.

Essa etapa gráfica deve ser distinguida da formação dos grupos. Se **Standardize variables** estiver desmarcada na análise de K -médias, a partição é obtida nas escalas originais, mas o **Cluster scatter plot** continua utilizando a padronização realizada internamente para a visualização. O gráfico auxilia a representar a partição em duas dimensões, mas não reproduz necessariamente a mesma geometria utilizada para formar os grupos.

No agrupamento hierárquico, **Distance measure** e **Clustering method** representam decisões distintas: a primeira define as dissimilaridades entre objetos e a segunda define o critério utilizado nas fusões. Para o método de Ward desenvolvido neste capítulo, a correspondência com **Ward.D2** pressupõe distâncias euclidianas. **Ward.D** utiliza uma convenção computacional diferente e não deve ser interpretado como uma denominação equivalente para o mesmo cálculo.

As opções **Variable clustering (PCA)** e **With p-values** tratam de agrupamento de variáveis, e não das observações utilizadas na formulação principal do capítulo. Na modalidade **Variable clustering (PCA)**, a versão auditada padroniza as variáveis quantitativas independentemente da opção **Standardize variables**, realiza uma ACP por `FactoMineR::PCA()` e aplica `stats::kmeans()` às coordenadas das variáveis nessa representação. Essa saída deve, portanto, ser interpretada como um agrupamento de variáveis no espaço construído pela ACP, e não como a partição das observações desenvolvida no núcleo.

Na modalidade **With p-values**, a versão auditada utiliza `pvclust` e associa à hierarquia de variáveis valores AU (*approximately unbiased*) e BP (*bootstrap probability*) obtidos por reamostragem (Suzuki; Shimodaira, 2006). Esses valores pertencem à hierarquia de variáveis produzida por esse procedimento e não constituem validação da partição de observações discutida na Seção 16.12.6.

16.12.7.1 Correspondência direta com R

Para variáveis quantitativas, os principais objetos desenvolvidos no capítulo podem ser examinados diretamente pelas funções básicas do R. Considere inicialmente a matriz de casos completos nas variáveis selecionadas:

Para uma partição por K -médias:

centers contém os centroides dos grupos. **withinss** contém as contribuições de cada grupo para a dispersão quadrática intragrupos, **tot.withinss** contém sua soma e **betweenss** contém a dispersão entre grupos na representação utilizada.

Para o agrupamento hierárquico, a matriz de dissimilaridades e a hierarquia podem ser construídas separadamente:

dist() define as dissimilaridades entre os objetos, **hclust()** aplica o critério de ligação e **cutree()** seleciona uma partição da hierarquia. A utilização de **ward.D2** neste exemplo corresponde à formulação de Ward baseada na geometria euclidiana discutida na Seção 16.7.2.

16.13 Síntese

A Análise de Agrupamentos procura organizar objetos em grupos sem utilizar classes previamente conhecidas. A solução depende da representação dos objetos, das variáveis utilizadas, da medida de proximidade e do procedimento adotado.

Quando cada objeto i é representado por uma observação

$$\mathbf{x}_i \in \mathbb{R}^p,$$

as proximidades podem ser construídas a partir das coordenadas. Alguns procedimentos também podem partir diretamente de uma matriz de dissimilaridades

$$\Delta = (\delta_{ij}) \in \mathbb{R}^{n \times n}.$$

Uma distância pode ser utilizada como dissimilaridade, mas uma dissimilaridade não precisa satisfazer todas as propriedades de uma distância métrica. A escala das variáveis também participa da definição das proximidades: mudanças relativas de escala podem alterar a contribuição das variáveis e, consequentemente, a solução obtida.

Uma partição em K grupos é uma coleção

$$\mathcal{P} = \{C_1, \dots, C_K\}$$

de grupos não vazios, disjuntos e cuja união contém todos os objetos. Em termos gerais, uma solução de agrupamento procura reunir objetos mais semelhantes dentro dos grupos e distinguir grupos segundo o critério adotado.

Cada grupo C_k pode ser representado por seu centroide

$$\bar{\mathbf{x}}_k = \frac{1}{n_k} \sum_{i \in C_k} \mathbf{x}_i.$$

A dispersão total admite a decomposição

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}.$$

Nas K -médias, a dispersão quadrática intragrupos é expressa pelo critério

$$J_K(\mathcal{P}) = \sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \bar{\mathbf{x}}_k\|^2 = \text{tr}(\mathbf{T}_{\text{intra}}).$$

As K -médias produzem diretamente uma partição em K grupos. Os métodos hierárquicos, por sua vez, produzem uma sequência de partições aninhadas. Nos procedimentos aglomerativos, grupos são sucessivamente fundidos segundo um critério de fusão.

As ligações simples, completa e média definem a dissimilaridade entre dois grupos, respectivamente, pela menor, pela maior e pela média das dissimilaridades entre seus elementos. O método de Ward utiliza o aumento da dispersão quadrática intragrupos. Para dois grupos A e B ,

$$D_{\text{Ward}}(A, B) = \frac{n_A n_B}{n_A + n_B} \|\bar{\mathbf{x}}_A - \bar{\mathbf{x}}_B\|^2.$$

Em cada etapa, Ward seleciona a fusão que produz o menor aumento da dispersão intragrupos.

O dendrograma representa graficamente a hierarquia de fusões e seus níveis. Um corte da hierarquia seleciona uma das partições nela contidas, sem estabelecer, por si só, que essa partição seja preferível às demais.

A solução de uma Análise de Agrupamentos depende das variáveis, de suas escalas, da medida de proximidade, do procedimento utilizado e do número de grupos ou do corte da hierarquia. A obtenção de uma partição ou de uma hierarquia não demonstra, por si só, a existência de grupos distintos na população nem sua correspondência com categorias externas ao procedimento.

A Análise de Agrupamentos também se relaciona a outras técnicas do módulo. A ACP pode construir uma nova representação das observações antes do agrupamento. Na Análise Discriminante, diferentemente do agrupamento, os grupos são conhecidos previamente. A decomposição da dispersão em componentes intragrupos e entre grupos também aparece na MANOVA, mas nessa técnica os grupos ou tratamentos são definidos antes da análise.

17 Formulação da Análise de Correspondência

A Análise de Correspondência simples representa geometricamente a estrutura de associação entre as categorias de duas variáveis categóricas a partir de uma tabela de contingência. A técnica compara os perfis observados com a estrutura correspondente à independência segundo a geometria qui-quadrado (Johnson; Wichern, 2002).

Os desvios da independência são padronizados pelas massas e reunidos em uma matriz submetida à SVD. A decomposição determina as dimensões não nulas, as inércias principais e as coordenadas das categorias de linhas e colunas. A formulação é geométrica e descritiva. A relação com a estatística de Pearson exige distinguir a identidade algébrica válida para a tabela observada da inferência sobre independência em uma população.

Os elementos da formulação são organizados na Tabela 17.1.

Tabela 17.1: Elementos da formulação da Análise de Correspondência.

Elemento	Objeto	Papel na análise
dados observados	tabela de contingência $\mathbf{N}$	registra as frequências conjuntas
distribuição observada referência	matriz $\mathbf{P}$ independência	expressa frequências relativas fornece a estrutura sem associação
representação interna	perfis de linhas e de colunas	descreve distribuições condicionais observadas
ponderação	massas de linha e de coluna	determinam os pesos utilizados na geometria dos perfis
geometria	distância qui-quadrado	compara perfis com ponderação pelos inversos das massas da margem oposta
estrutura matricial	matriz de desvios padronizados da independência $\mathbf{Q}_{CA}$	reúne os desvios da independência após a padronização pelas massas

17.1 O problema de associação em uma tabela de contingência

A Análise de Correspondência simples considera duas variáveis categóricas. Para n observações, os dados categóricos podem ser organizados como

$$\mathbf{X}_{\text{cat}} = \begin{pmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \\ \vdots & \vdots \\ x_{n1} & x_{n2} \end{pmatrix},$$

em que cada linha representa uma observação e cada coluna representa uma das duas variáveis categóricas.

A primeira variável possui I categorias e a segunda possui J categorias. Os índices $1, \dots, I$ e $1, \dots, J$ identificam essas categorias, de modo que

$$x_{h1} \in \{1, \dots, I\}, \quad x_{h2} \in \{1, \dots, J\}, \quad h = 1, \dots, n.$$

A matriz $\mathbf{X}_{\text{cat}}$ contém duas variáveis. As quantidades I e J indicam os números de categorias da primeira e da segunda variável, respectivamente. Os índices atribuídos às categorias funcionam apenas como identificadores e não definem coordenadas quantitativas em $\mathbb{R}^2$.

A Análise de Correspondência utiliza as frequências conjuntas das categorias. Para $i = 1, \dots, I$ e $j = 1, \dots, J$, defina

$$n_{ij} = |\{h \in \{1, \dots, n\} : x_{h1} = i, x_{h2} = j\}|.$$

A quantidade n_{ij} corresponde ao número de observações que pertencem simultaneamente à categoria i da primeira variável e à categoria j da segunda. Essas frequências formam a tabela de contingência

$$\mathbf{N} = (n_{ij}) \in \mathbb{N}_0^{I \times J}.$$

A matriz $\mathbf{N}$ possui I linhas, correspondentes às categorias da primeira variável, e J colunas, correspondentes às categorias da segunda. Suas dimensões $I \times J$ referem-se às categorias das duas variáveis categóricas.

O total observado é

$$n = \sum_{i=1}^I \sum_{j=1}^J n_{ij}, \quad n > 0. \quad (17.1)$$

Como $n > 0$, a matriz de frequências relativas observadas é definida por

$$\mathbf{P} = \frac{1}{n} \mathbf{N} = (p_{ij}) \in \mathbb{R}^{I \times J}. \quad (17.2)$$

Assim,

$$p_{ij} = \frac{n_{ij}}{n} \geq 0$$

e

$$\sum_{i=1}^I \sum_{j=1}^J p_{ij} = 1.$$

A matriz $\mathbf{P}$ reúne as **frequências relativas observadas** da tabela e é construída diretamente a partir das frequências observadas. Ela deve ser distinguida da distribuição conjunta populacional considerada na Seção 17.13.6.

A análise procura determinar como $\mathbf{P}$ se afasta da estrutura correspondente à independência e representar esse afastamento em poucas dimensões.

A tabela possui duas leituras complementares. Comparando as linhas, investigam-se diferenças entre as distribuições das categorias das colunas condicionadas a cada linha. Comparando as colunas, investigam-se diferenças entre as distribuições das categorias das linhas condicionadas a cada coluna.

17.2 Massas e perfis

As frequências relativas marginais são denominadas **massas** e determinam a ponderação utilizada na geometria da Análise de Correspondência.

Definição 17.1 (Massas de linha e de coluna). Considere uma matriz de frequências relativas

$$\mathbf{P} = (p_{ij}) \in \mathbb{R}^{I \times J},$$

com

$$p_{ij} \geq 0$$

e

$$\sum_{i=1}^I \sum_{j=1}^J p_{ij} = 1.$$

As **massas das linhas** são

$$r_i = \sum_{j=1}^J p_{ij}, \quad i = 1, \dots, I,$$

e as **massas das colunas** são

$$c_j = \sum_{i=1}^I p_{ij}, \quad j = 1, \dots, J.$$

Em forma vetorial,

$$\mathbf{r} = \mathbf{P} \mathbf{1}_J \in \mathbb{R}^I$$

e

$$\mathbf{c} = \mathbf{P}^\top \mathbf{1}_I \in \mathbb{R}^J.$$

Como a soma dos elementos de $\mathbf{P}$ é igual a 1,

$$\mathbf{1}_I^\top \mathbf{r} = \mathbf{1}_J^\top \mathbf{c} = 1.$$

As matrizes diagonais das massas são

$$\mathbf{D}_r = \text{diag}(r_1, \dots, r_I) \in \mathbb{R}^{I \times I}$$

e

$$\mathbf{D}_c = \text{diag}(c_1, \dots, c_J) \in \mathbb{R}^{J \times J}.$$

A definição admite massas nulas. Como a geometria da Análise de Correspondência utiliza inversas e raízes inversas das matrizes de massas, o desenvolvimento considera apenas categorias com

$$r_i > 0, \quad i = 1, \dots, I,$$

e

$$c_j > 0, \quad j = 1, \dots, J. \quad (17.3)$$

Categorias de massa nula não possuem perfis definidos e ficam fora da geometria construída sob a condição da Equação 17.3.

17.2.1 Distribuições condicionais observadas

A Análise de Correspondência compara distribuições condicionais observadas, denominadas perfis.

Definição 17.2 (Perfis de linhas e de colunas). Considere

$$\mathbf{P} = (p_{ij}) \in \mathbb{R}^{I \times J}$$

uma matriz de frequências relativas com massas de linhas e colunas definidas na Definição 17.1.

Para uma linha i com

$$r_i > 0,$$

o perfil da linha i é

$$\mathbf{p}_{i\cdot} = \begin{pmatrix} \frac{p_{i1}}{r_i} \\ \vdots \\ \frac{p_{iJ}}{r_i} \end{pmatrix} \in \mathbb{R}^J. \quad (17.4)$$

Para uma coluna j com

$$c_j > 0,$$

o **perfil da coluna** j é

$$\mathbf{p}_{\cdot|j} = \begin{pmatrix} \frac{p_{1j}}{c_j} \\ \vdots \\ \frac{p_{Ij}}{c_j} \end{pmatrix} \in \mathbb{R}^I. \quad (17.5)$$

Cada perfil possui soma unitária:

$$\mathbf{1}_J^\top \mathbf{p}_{i|\cdot} = 1$$

e

$$\mathbf{1}_I^\top \mathbf{p}_{\cdot|j} = 1.$$

Sob a condição da Equação 17.3, os perfis de linhas podem ser reunidos na matriz

$$\mathbf{P}^{(r)} = \mathbf{D}_r^{-1} \mathbf{P} \in \mathbb{R}^{I \times J}, \quad (17.6)$$

enquanto os perfis de colunas são organizados em

$$\mathbf{P}^{(c)} = \mathbf{D}_c^{-1} \mathbf{P}^\top \in \mathbb{R}^{J \times I}. \quad (17.7)$$

O perfil médio das linhas, ponderado pelas massas r_i , é

$$\sum_{i=1}^I r_i \mathbf{p}_{i|\cdot} = \mathbf{c}, \quad (17.8)$$

pois, para cada componente j ,

$$\sum_{i=1}^I r_i \frac{p_{ij}}{r_i} = \sum_{i=1}^I p_{ij} = c_j.$$

De forma dual,

$$\sum_{j=1}^J c_j \mathbf{p}_{\cdot|j} = \mathbf{r}. \quad (17.9)$$

Assim, $\mathbf{c}$ é o centro ponderado da nuvem dos perfis de linhas e $\mathbf{r}$ é o centro ponderado da nuvem dos perfis de colunas.

17.2.2 Independência como referência

Para a matriz $\mathbf{P}$, a estrutura de independência associada às massas $\mathbf{r}$ e $\mathbf{c}$ é

$$p_{ij} = r_i c_j, \quad (17.10)$$

ou, em forma matricial,

$$\mathbf{P} = \mathbf{r} \mathbf{c}^\top. \quad (17.11)$$

Sob a condição da Equação 17.3,

$$\frac{p_{ij}}{r_i} = c_j,$$

de modo que

$$\mathbf{p}_{i| \cdot} = \mathbf{c}$$

para todas as linhas.

Analogamente,

$$\frac{p_{ij}}{c_j} = r_i,$$

e todos os perfis de colunas coincidem com

$$\mathbf{r}.$$

A independência corresponde, portanto, ao colapso de cada nuvem de perfis em seu respectivo centro.

Quando

$$\mathbf{P} \neq \mathbf{r}\mathbf{c}^\top,$$

as diferenças

$$p_{ij} - r_i c_j$$

representam os desvios observados em relação à estrutura de independência.

Esses desvios ainda não incorporam a ponderação marginal da geometria qui-quadrado. Na Análise de Correspondência, eles são padronizados pelos produtos das massas marginais.

17.3 Geometria dos perfis

A Análise de Correspondência compara os perfis por meio de produtos internos ponderados pelos inversos das massas da margem oposta.

Pela Definição 3.16 e pela Definição 3.17, sob a condição da Equação 17.3,

$$\mathbf{D}_c^{-1}$$

e

$$\mathbf{D}_r^{-1}$$

são matrizes diagonais positivas definidas e, portanto, definem produtos internos nos espaços de perfis de linhas e de colunas.

Esses produtos internos determinam a geometria dos perfis. As distâncias associadas são as distâncias qui-quadrado.

Definição 17.3 (Distância qui-quadrado entre perfis). Considere uma matriz

$$\mathbf{P} \in \mathbb{R}^{I \times J}$$

de frequências relativas cujas massas satisfazem

$$r_i > 0, \quad i = 1, \dots, I,$$

e

$$c_j > 0, \quad j = 1, \dots, J.$$

Se

$$\mathbf{p}_{i|\cdot}, \mathbf{p}_{i'|\cdot} \in \mathbb{R}^J$$

são dois perfis de linhas, o **quadrado de sua distância qui-quadrado** é definido por

$$d_{\chi^2}^2(i, i') = (\mathbf{p}_{i|\cdot} - \mathbf{p}_{i'|\cdot})^\top \mathbf{D}_c^{-1} (\mathbf{p}_{i|\cdot} - \mathbf{p}_{i'|\cdot}). \quad (17.12)$$

Equivalentemente,

$$d_{\chi^2}^2(i, i') = \sum_{j=1}^J \frac{1}{c_j} \left(\frac{p_{ij}}{r_i} - \frac{p_{i'j}}{r_{i'}} \right)^2.$$

Se

$$\mathbf{p}_{\cdot|j}, \mathbf{p}_{\cdot|j'} \in \mathbb{R}^I$$

são dois perfis de colunas, o quadrado de sua distância qui-quadrado é

$$d_{\chi^2}^2(j, j') = (\mathbf{p}_{\cdot|j} - \mathbf{p}_{\cdot|j'})^\top \mathbf{D}_r^{-1} (\mathbf{p}_{\cdot|j} - \mathbf{p}_{\cdot|j'}). \quad (17.13)$$

Equivalentemente,

$$d_{\chi^2}^2(j, j') = \sum_{i=1}^I \frac{1}{r_i} \left(\frac{p_{ij}}{c_j} - \frac{p_{ij'}}{c_{j'}} \right)^2.$$

A distância qui-quadrado é, portanto, uma distância euclidiana em coordenadas reescaladas pelas massas. Para as linhas,

$$d_{\chi^2}(i, i') = \left\| \mathbf{D}_c^{-1/2} (\mathbf{p}_{i|\cdot} - \mathbf{p}_{i'|\cdot}) \right\|,$$

e, para as colunas,

$$d_{\chi^2}(j, j') = \left\| \mathbf{D}_r^{-1/2} (\mathbf{p}_{\cdot|j} - \mathbf{p}_{\cdot|j'}) \right\|.$$

Na comparação entre perfis de linhas, a diferença na categoria de coluna j é ponderada por

$$\frac{1}{c_j}.$$

Na comparação entre perfis de colunas, a diferença na categoria de linha i é ponderada por

$$\frac{1}{r_i}.$$

Assim, para diferenças absolutas de mesma magnitude, a componente associada a uma categoria de menor massa tem maior peso na distância qui-quadrado.

A distância de uma linha ao centro da nuvem é

$$d_{\chi^2}^2(i, \mathbf{c}) = (\mathbf{p}_{i\cdot} - \mathbf{c})^\top \mathbf{D}_c^{-1} (\mathbf{p}_{i\cdot} - \mathbf{c}), \quad (17.14)$$

ou, utilizando

$$\frac{p_{ij}}{r_i} - c_j = \frac{p_{ij} - r_i c_j}{r_i},$$

tem-se

$$d_{\chi^2}^2(i, \mathbf{c}) = \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i^2 c_j}. \quad (17.15)$$

De forma dual,

$$d_{\chi^2}^2(j, \mathbf{r}) = \sum_{i=1}^I \frac{(p_{ij} - r_i c_j)^2}{c_j^2 r_i}. \quad (17.16)$$

17.4 Inércia e afastamento da independência

Definição 17.4 (Inércia total). A **inércia total** mede o afastamento global dos perfis em relação à estrutura de independência por meio das distâncias qui-quadrado entre os perfis e o centro da nuvem.

Para a nuvem de perfis de linhas, com massas $r_1, \dots, r_I$ e centro $\mathbf{c}$, a inércia total é

$$\mathcal{J} = \sum_{i=1}^I r_i d_{\chi^2}^2(i, \mathbf{c}). \quad (17.17)$$

Como

$$\sum_{i=1}^I r_i = 1,$$

$\mathcal{J}$ é a média ponderada das distâncias qui-quadrado ao quadrado entre os perfis de linhas e o centro da nuvem. O termo

$$r_i d_{\chi^2}^2(i, \mathbf{c})$$

é a parcela da inércia total associada à categoria de linha i .

Substituindo a distância qui-quadrado da Equação 17.15 na Equação 17.17,

$$\mathcal{J} = \sum_{i=1}^I \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i c_j}. \quad (17.18)$$

De forma dual,

$$\mathcal{J} = \sum_{j=1}^J c_j d_{\chi^2}^2(j, \mathbf{r}), \quad (17.19)$$

de modo que a mesma inércia total pode ser obtida pela dispersão da nuvem de linhas em torno de $\mathbf{c}$ ou pela dispersão da nuvem de colunas em torno de $\mathbf{r}$.

Como todos os termos na Equação 17.18 são não negativos,

$$\mathcal{J} = 0$$

se, e somente se,

$$p_{ij} = r_i c_j$$

para todas as células, ou equivalentemente,

$$\mathbf{P} = \mathbf{r}\mathbf{c}^\top.$$

A inércia total é nula quando a distribuição observada coincide com a estrutura de independência. Valores positivos indicam afastamento dessa estrutura, e valores maiores correspondem a maior dispersão global dos perfis em relação aos respectivos centros.

17.5 Padronização dos desvios da independência

Na Equação 17.18, os desvios

$$p_{ij} - r_i c_j$$

aparecem padronizados pelas massas correspondentes. Esses termos podem ser reunidos em uma única matriz.

Definição 17.5 (Matriz de desvios padronizados da independência). Considere

$$\mathbf{P} = (p_{ij}) \in \mathbb{R}^{I \times J}$$

uma matriz de frequências relativas cujas massas

$$r_i > 0, \quad i = 1, \dots, I,$$

e

$$c_j > 0, \quad j = 1, \dots, J,$$

são estritamente positivas.

A matriz de desvios padronizados da independência é

$$\mathbf{Q}_{\text{CA}} = \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r} \mathbf{c}^\top) \mathbf{D}_c^{-1/2} \in \mathbb{R}^{I \times J}. \quad (17.20)$$

Seu elemento (i, j) é

$$q_{ij} = \frac{p_{ij} - r_i c_j}{\sqrt{r_i c_j}}. \quad (17.21)$$

A matriz $\mathbf{Q}_{\text{CA}}$ reúne os desvios da independência padronizados pelos produtos das massas marginais.

As restrições impostas pelas marginais implicam que o posto de $\mathbf{Q}_{\text{CA}}$, definido na Definição 2.12, satisfaz

$$\text{posto}(\mathbf{Q}_{\text{CA}}) \leq \min(I - 1, J - 1). \quad (17.22)$$

As dependências lineares impostas pelas marginais, cuja derivação é apresentada na Seção 17.13.1, implicam que a Análise de Correspondência possui, no máximo,

$$\min(I - 1, J - 1)$$

dimensões não nulas.

17.5.1 Inércia como norma matricial

Pela Definição 17.5 e pela Definição 6.7,

$$\begin{aligned}\|\mathbf{Q}_{\text{CA}}\|_F^2 &= \sum_{i=1}^I \sum_{j=1}^J q_{ij}^2 \\ &= \sum_{i=1}^I \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i c_j}.\end{aligned}$$

Comparando essa expressão com a Equação 17.18,

$$\mathcal{J} = \|\mathbf{Q}_{\text{CA}}\|_F^2. \quad (17.23)$$

Proposição 17.1 (Formas equivalentes da inércia). *Sob massas de linhas e colunas estritamente positivas,*

$$\mathcal{J} = \sum_{i=1}^I r_i d_{\chi^2}^2(i, \mathbf{c}) = \sum_{j=1}^J c_j d_{\chi^2}^2(j, \mathbf{r})$$

e

$$\mathcal{J} = \sum_{i=1}^I \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i c_j} = \|\mathbf{Q}_{\text{CA}}\|_F^2.$$

A inércia possui três interpretações compatíveis: dispersão da nuvem de linhas, dispersão da nuvem de colunas e magnitude matricial dos desvios padronizados da independência.

17.6 Relação algébrica com a estatística de Pearson

Sob a estrutura de independência ajustada às marginais observadas, a frequência esperada da célula (i, j) é

$$\hat{e}_{ij} = nr_i c_j.$$

A estatística de Pearson calculada a partir da tabela observada é

$$\chi^2 = \sum_{i=1}^I \sum_{j=1}^J \frac{(n_{ij} - \hat{e}_{ij})^2}{\hat{e}_{ij}} = \sum_{i=1}^I \sum_{j=1}^J \frac{(n_{ij} - nr_i c_j)^2}{nr_i c_j}. \quad (17.24)$$

Como

$$n_{ij} = np_{ij},$$

tem-se

$$\begin{aligned} \chi^2 &= \sum_{i=1}^I \sum_{j=1}^J \frac{n^2(p_{ij} - r_i c_j)^2}{nr_i c_j} \\ &= n \sum_{i=1}^I \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i c_j}. \end{aligned}$$

Comparando a expressão anterior com a Equação 17.18,

$$\chi^2 = n\mathcal{J}. \quad (17.25)$$

A identidade

$$\chi^2 = n\mathcal{J}$$

é **algébrica e exata para a tabela observada**. Ela não exige um modelo probabilístico para a geração da tabela nem uma aproximação assintótica.

Sua interpretação como estatística de teste exige um modelo probabilístico para a geração da tabela, desenvolvido na Seção 17.13.6. A inércia e a identidade acima pertencem à estrutura descritiva e geométrica da Análise de Correspondência, enquanto a distribuição de referência de χ^2 pertence à inferência.

A estatística de Pearson resume o afastamento global da independência em uma única quantidade. A Análise de Correspondência decompõe a inércia correspondente entre dimensões e representa geometricamente os perfis de linhas e colunas (Johnson; Wichern, 2002).

17.7 Formulação pela decomposição em valores singulares

A matriz de desvios padronizados

$$\mathbf{Q}_{CA} \in \mathbb{R}^{I \times J}$$

é, em geral, retangular. A decomposição de $\mathbf{Q}_{CA}$ utiliza a SVD compacta definida na Definição 6.4.

Defina

$$L = \text{posto}(\mathbf{Q}_{CA}).$$

Pela Equação 17.22,

$$0 \leq L \leq \min(I - 1, J - 1).$$

Se

$$L = 0,$$

então

$$\mathbf{Q}_{CA} = \mathbf{0}$$

e, pela Proposição 17.1,

$$J = 0.$$

Nesse caso,

$$\mathbf{P} = \mathbf{r}\mathbf{c}^\top,$$

e não existem dimensões não nulas a decompor.

Quando $L \geq 1$, pela SVD compacta definida na Definição 6.4,

$$\mathbf{Q}_{\text{CA}} = \mathbf{U}\mathbf{D}\mathbf{V}^\top, \quad (17.26)$$

com

$$\mathbf{U} \in \mathbb{R}^{I \times L}, \quad \mathbf{D} \in \mathbb{R}^{L \times L}, \quad \mathbf{V} \in \mathbb{R}^{J \times L},$$

satisfazendo

$$\mathbf{U}^\top \mathbf{U} = \mathbf{I}_L,$$

$$\mathbf{V}^\top \mathbf{V} = \mathbf{I}_L$$

e

$$\mathbf{D} = \text{diag}(d_1, \dots, d_L),$$

em que

$$d_1 \geq d_2 \geq \dots \geq d_L > 0.$$

Os vetores singulares à esquerda e à direita formam as bases ortonormais associadas à SVD. O reescalonamento por $\mathbf{D}_r^{-1/2}$ e $\mathbf{D}_c^{-1/2}$ produz as coordenadas padrão das linhas e das colunas em suas respectivas geometrias ponderadas.

A SVD acopla as duas representações por meio dos mesmos valores singulares.

17.7.1 Decomposição da inércia

Definição 17.6 (Inércia principal). A SVD de $\mathbf{Q}_{\text{CA}}$ decompõe a inércia total entre as dimensões não nulas da solução.

Para

$$\mathbf{Q}_{\text{CA}} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

com

$$\mathbf{D} = \text{diag}(d_1, \dots, d_L),$$

a **inércia principal da dimensão ℓ** é

$$\lambda_\ell = d_\ell^2, \quad \ell = 1, \dots, L. \quad (17.27)$$

A quantidade λ_ℓ representa a parcela da inércia total associada à dimensão ℓ .

Pela relação entre a norma de Frobenius e os valores singulares estabelecida na Proposição 6.9,

$$\|\mathbf{Q}_{\text{CA}}\|_F^2 = \sum_{\ell=1}^L d_\ell^2.$$

Pela Equação 17.23,

$$\mathcal{J} = \|\mathbf{Q}_{\text{CA}}\|_F^2,$$

e, portanto,

$$\mathcal{J} = \sum_{\ell=1}^L \lambda_\ell. \quad (17.28)$$

A SVD decompõe a inércia total em parcelas não negativas associadas às diferentes dimensões da solução.

Pela identidade exata da Equação 17.25,

$$\chi^2 = n\mathcal{J},$$

$$\chi^2 = n \sum_{\ell=1}^L \lambda_\ell. \quad (17.29)$$

A igualdade $\chi^2 = n \sum_{\ell=1}^L \lambda_\ell$ é uma decomposição algébrica da estatística observada e não depende de uma distribuição amostral. Sua interpretação inferencial depende da formulação probabilística especificada na Seção 17.13.6.

Quando $\mathcal{J} > 0$, a **proporção da inércia total associada à dimensão ℓ** é

$$\frac{\lambda_\ell}{\mathcal{J}} = \frac{\lambda_\ell}{\sum_{h=1}^L \lambda_h}, \quad \ell = 1, \dots, L. \quad (17.30)$$

Essa proporção representa a parcela da inércia total associada à dimensão ℓ .

Para $1 \leq k \leq L$, a **proporção acumulada da inércia nas primeiras k dimensões** é

$$\Pi_k^{(\text{CA})} = \frac{\sum_{\ell=1}^k \lambda_\ell}{\mathcal{J}} = \frac{\sum_{\ell=1}^k \lambda_\ell}{\sum_{\ell=1}^L \lambda_\ell}. \quad (17.31)$$

A quantidade $\Pi_k^{(\text{CA})}$ representa a parcela da inércia total associada conjuntamente às primeiras k dimensões.

Essas proporções descrevem a decomposição da inércia total entre as dimensões da Análise de Correspondência. Embora sejam formalmente semelhantes às proporções de variância da ACP, o objeto decomposto é diferente: na Análise de Correspondência, a inércia quantifica os desvios padronizados em relação à independência.

17.7.2 Representação em dimensão reduzida

Para

$$1 \leq k < L,$$

defina

$$\mathbf{U}_k = (\mathbf{u}_1 \quad \dots \quad \mathbf{u}_k) \in \mathbb{R}^{I \times k},$$

$$\mathbf{V}_k = (\mathbf{v}_1 \quad \dots \quad \mathbf{v}_k) \in \mathbb{R}^{J \times k}$$

e

$$\mathbf{D}_k = \text{diag}(d_1, \dots, d_k) \in \mathbb{R}^{k \times k}.$$

A SVD truncada é

$$\mathbf{Q}_{\text{CA},k} = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top. \quad (17.32)$$

Pelo Teorema 6.2,

$$\mathbf{Q}_{\text{CA},k}$$

é uma melhor aproximação de posto no máximo k de

$$\mathbf{Q}_{\text{CA}}$$

em norma de Frobenius.

O erro quadrático de aproximação é

$$\begin{aligned} \|\mathbf{Q}_{\text{CA}} - \mathbf{Q}_{\text{CA},k}\|_F^2 &= \sum_{\ell=k+1}^L d_\ell^2 \\ &= \sum_{\ell=k+1}^L \lambda_\ell. \end{aligned} \quad (17.33)$$

A quantidade

$$\mathcal{J}_k = \sum_{\ell=1}^k \lambda_\ell \quad (17.34)$$

é a parcela da inércia total representada pelas primeiras k dimensões.

Consequentemente,

$$\mathcal{J} = \mathcal{J}_k + \sum_{\ell=k+1}^L \lambda_\ell.$$

Na Análise de Correspondência, a SVD truncada fornece uma aproximação ótima, em norma de Frobenius, da **matriz de desvios padronizados da independência**, e não da tabela de contingência $\mathbf{N}$ segundo uma distância euclidiana ordinária.

17.8 Coordenadas da Análise de Correspondência

A SVD é realizada sobre uma matriz em que os desvios da independência já foram ponderados pelas massas das categorias. As coordenadas da Análise de Correspondência transformam os vetores singulares novamente para os espaços dos perfis de linhas e de colunas.

A Análise de Correspondência utiliza duas escalas: coordenadas padrão e coordenadas principais.

17.8.1 Sistema de coordenadas padrão

Definição 17.7 (Coordenadas padrão). Considere uma matriz de frequências relativas

$$\mathbf{P} \in \mathbb{R}^{I \times J}$$

com massas de linhas e colunas estritamente positivas e a SVD compacta

$$\mathbf{Q}_{\text{CA}} = \mathbf{U} \mathbf{D} \mathbf{V}^\top,$$

com

$$L = \text{posto}(\mathbf{Q}_{\text{CA}}) \geq 1.$$

As **coordenadas padrão das linhas** são as linhas de

$$\mathbf{A}_r = \mathbf{D}_r^{-1/2} \mathbf{U} = (a_{i\ell}^{(r)}) \in \mathbb{R}^{I \times L}. \quad (17.35)$$

em que $a_{i\ell}^{(r)}$ é a coordenada padrão da linha i na dimensão ℓ . O vetor de coordenadas padrão da linha i é

$$\mathbf{a}_i^{(r)} = \begin{pmatrix} a_{i1}^{(r)} \\ \vdots \\ a_{iL}^{(r)} \end{pmatrix} \in \mathbb{R}^L.$$

As **coordenadas padrão das colunas** são as linhas de

$$\mathbf{A}_c = \mathbf{D}_c^{-1/2} \mathbf{V} = (a_{j\ell}^{(c)}) \in \mathbb{R}^{J \times L}. \quad (17.36)$$

em que $a_{j\ell}^{(c)}$ é a coordenada padrão da coluna j na dimensão ℓ . O vetor de coordenadas padrão da coluna j é

$$\mathbf{a}_j^{(c)} = \begin{pmatrix} a_{j1}^{(c)} \\ \vdots \\ a_{jL}^{(c)} \end{pmatrix} \in \mathbb{R}^L.$$

Como as colunas de $\mathbf{U}$ e $\mathbf{V}$ são ortonormais,

$$\mathbf{A}_r^\top \mathbf{D}_r \mathbf{A}_r = \mathbf{I}_L$$

e

$$\mathbf{A}_c^\top \mathbf{D}_c \mathbf{A}_c = \mathbf{I}_L.$$

As coordenadas padrão são, portanto, ortonormais nas geometrias ponderadas pelas respectivas massas.

17.8.2 Sistema de coordenadas principais

Definição 17.8 (Coordenadas principais). Mantidas as condições da Definição 17.7, as **coordenadas principais das linhas** são as linhas da matriz

$$\mathbf{F}_r = \mathbf{A}_r \mathbf{D} = \mathbf{D}_r^{-1/2} \mathbf{U} \mathbf{D} = (f_{i\ell}^{(r)}) \in \mathbb{R}^{I \times L}, \quad (17.37)$$

em que $f_{i\ell}^{(r)}$ é a coordenada principal da linha i na dimensão ℓ . O vetor de coordenadas principais da linha i é

$$\mathbf{f}_i^{(r)} = \begin{pmatrix} f_{i1}^{(r)} \\ \vdots \\ f_{iL}^{(r)} \end{pmatrix} \in \mathbb{R}^L.$$

As **coordenadas principais das colunas** são as linhas da matriz

$$\mathbf{F}_c = \mathbf{A}_c \mathbf{D} = \mathbf{D}_c^{-1/2} \mathbf{V} \mathbf{D} = (f_{j\ell}^{(c)}) \in \mathbb{R}^{J \times L}, \quad (17.38)$$

em que $f_{j\ell}^{(c)}$ é a coordenada principal da coluna j na dimensão ℓ . O vetor de coordenadas principais da coluna j é

$$\mathbf{f}_j^{(c)} = \begin{pmatrix} f_{j1}^{(c)} \\ \vdots \\ f_{jL}^{(c)} \end{pmatrix} \in \mathbb{R}^L.$$

As coordenadas principais incorporam os valores singulares, de modo que sua dispersão ponderada em cada dimensão corresponde à respectiva inércia principal. Como

$$\mathbf{A}_r^\top \mathbf{D}_r \mathbf{A}_r = \mathbf{I}_L$$

e

$$\mathbf{A}_c^\top \mathbf{D}_c \mathbf{A}_c = \mathbf{I}_L,$$

segue que

$$\mathbf{F}_r^\top \mathbf{D}_r \mathbf{F}_r = \mathbf{D}^2$$

e

$$\mathbf{F}_c^\top \mathbf{D}_c \mathbf{F}_c = \mathbf{D}^2.$$

Consequentemente, para cada dimensão ℓ ,

$$\lambda_\ell = \sum_{i=1}^I r_i \left(f_{i\ell}^{(r)} \right)^2 = \sum_{j=1}^J c_j \left(f_{j\ell}^{(c)} \right)^2, \quad \ell = 1, \dots, L. \quad (17.39)$$

A identidade mostra que a inércia principal λ_ℓ também corresponde à dispersão ponderada das coordenadas principais das linhas na dimensão ℓ e, de forma dual, à dispersão ponderada das coordenadas principais das colunas nessa mesma dimensão.

Em cada nuvem, a origem corresponde ao centro ponderado dos perfis. Para as linhas, esse centro é o perfil marginal $\mathbf{c}$ das colunas; para as colunas, é o perfil marginal $\mathbf{r}$ das linhas. Assim, uma categoria localizada próxima da origem possui perfil próximo do perfil marginal na representação considerada. A origem não representa uma categoria nem uma frequência pequena.

A igualdade das inércias principais nas duas nuvens não implica que os perfis de linhas e de colunas pertençam ao mesmo espaço. As linhas são perfis em $\mathbb{R}^J$ e as colunas são perfis em $\mathbb{R}^I$. Para cada dimensão ℓ , a SVD associa um eixo da nuvem de linhas a um eixo da nuvem de colunas pelo mesmo valor singular d_ℓ . Esses eixos determinam o termo

$$d_\ell \mathbf{u}_\ell \mathbf{v}_\ell^\top$$

da decomposição de $\mathbf{Q}_{\text{CA}}$.

17.8.3 Distâncias entre perfis e coordenadas principais

As coordenadas principais completas preservam as distâncias qui-quadrado entre os perfis.

Para as linhas,

$$\mathbf{P}^{(r)} = \mathbf{D}_r^{-1} \mathbf{P}.$$

Pela Equação 17.20,

$$(\mathbf{P}^{(r)} - \mathbf{1}_I \mathbf{c}^\top) \mathbf{D}_c^{-1/2} = \mathbf{D}_r^{-1/2} \mathbf{Q}_{\text{CA}}.$$

Substituindo a decomposição da Equação 17.26 e utilizando a Equação 17.37,

$$(\mathbf{P}^{(r)} - \mathbf{1}_I \mathbf{c}^\top) \mathbf{D}_c^{-1/2} = \mathbf{F}_r \mathbf{V}^\top. \quad (17.40)$$

Como

$$\mathbf{V}^\top \mathbf{V} = \mathbf{I}_L,$$

a multiplicação por $\mathbf{V}^\top$ preserva a norma das diferenças entre as linhas de $\mathbf{F}_r$.

Proposição 17.2 (Preservação das distâncias qui-quadrado). *Mantidas todas as L dimensões associadas aos valores singulares positivos, para quaisquer linhas i e i' ,*

$$d_{\chi^2}^2(i, i') = \|\mathbf{f}_i^{(r)} - \mathbf{f}_{i'}^{(r)}\|^2,$$

e, de forma dual, para quaisquer colunas j e j' ,

$$d_{\chi^2}^2(j, j') = \|\mathbf{f}_j^{(c)} - \mathbf{f}_{j'}^{(c)}\|^2.$$

Se apenas as primeiras

$$k < L$$

dimensões forem mantidas, a distância representada entre dois perfis não pode exceder a distância completa, pois as parcelas quadráticas associadas às dimensões descartadas são não negativas. A representação reduzida preserva apenas as componentes das distâncias qui-quadrado associadas às dimensões retidas.

17.9 Representação conjunta de linhas e colunas

A Análise de Correspondência produz duas nuvens de pontos: uma para as categorias de linha e outra para as categorias de coluna. A representação pode ser construída a partir dos perfis de linhas ou, de forma dual, dos perfis de colunas (Johnson; Wichern, 2002).

Quando as linhas são representadas por suas coordenadas principais, as distâncias euclidianas entre os pontos de linhas reproduzem suas distâncias qui-quadrado se todas as dimensões não nulas forem mantidas. A propriedade dual vale para as colunas representadas por suas coordenadas principais.

Linhas e colunas também podem ser exibidas conjuntamente em um mesmo plano. Nesse mapa, a distância euclidiana entre uma categoria de linha e uma categoria de coluna não é uma distância qui-quadrado. A interpretação métrica permanece definida separadamente dentro de cada nuvem.

17.9.1 O significado das proximidades

Dentro da nuvem das linhas, pontos próximos correspondem a categorias com perfis de linha semelhantes segundo a distância qui-quadrado; a interpretação dual vale para as categorias de coluna.

A posição relativa entre uma categoria de linha e uma categoria de coluna pode auxiliar na interpretação da associação entre as duas margens (Hair et al., 2009; Johnson; Wichern, 2002). Essa posição relativa não define uma distância qui-quadrado entre os dois tipos de pontos; a interpretação métrica permanece restrita aos perfis pertencentes à mesma margem.

17.10 Formulação descritiva e relação com a inferência

A Análise de Correspondência descreve geometricamente o afastamento da independência na tabela observada. O teste de Pearson utiliza a mesma tabela para avaliar, sob um modelo probabilístico, a hipótese populacional de independência.

Para a tabela observada,

$$\chi^2 = n\mathcal{J},$$

conforme a Equação 17.25. Essa identidade é algébrica e exata: a estatística de Pearson χ^2 é igual ao tamanho total n multiplicado pela inércia total da tabela (Johnson; Wichern, 2002).

A interpretação inferencial exige um modelo probabilístico adicional para a geração da tabela. A formulação multinomial, as condições do resultado assintótico de Pearson e a origem dos graus de liberdade são desenvolvidas na Seção 17.13.6.

A distância qui-quadrado entre perfis, a estatística de Pearson χ^2 e a distribuição qui-quadrado utilizada como referência inferencial são objetos distintos. A distância qui-quadrado compara perfis; a estatística de Pearson quantifica o afastamento observado da independência; a distribuição de referência pertence à formulação inferencial.

Na formulação descritiva,

$$p_{ij}, \quad r_i \quad \text{e} \quad c_j$$

são quantidades calculadas a partir da tabela observada. A inércia

$$\mathcal{J}$$

mede o afastamento de

$$\mathbf{P} = \mathbf{rc}^\top.$$

A SVD decompõe esse afastamento observado entre as dimensões,

$$\mathcal{J} = \sum_{\ell=1}^L \lambda_\ell.$$

Uma dimensão da Análise de Correspondência não corresponde a uma hipótese inferencial populacional separada. O teste de Pearson avalia globalmente a independência entre as duas variáveis, enquanto as dimensões decompõem descritivamente o afastamento observado.

A construção geométrica da Análise de Correspondência não depende da realização do teste formal de independência. A identidade

$$\chi^2 = n\mathcal{J}$$

relaciona algebricamente a estatística de Pearson à inércia da tabela observada, enquanto a interpretação inferencial de χ^2 requer a formulação probabilística apresentada em Seção 17.13.6.

Exemplo 17.1 (Análise de Correspondência de uma tabela 3×4). Considere a classificação de 120 atendimentos de uma lanchonete segundo o turno e o tipo de item escolhido. Os turnos são **manhã**, **tarde** e **noite**, e os itens são **café**, **suco**, **salgado** e **doce**. As frequências conjuntas observadas são

$$\mathbf{N} = \begin{pmatrix} 16 & 8 & 12 & 4 \\ 8 & 16 & 4 & 12 \\ 6 & 6 & 14 & 14 \end{pmatrix},$$

em que as linhas correspondem aos turnos manhã, tarde e noite, e as colunas correspondem a quatro categorias de itens.

O total observado é

$$n = 120.$$

A matriz de frequências relativas é

$$\mathbf{P} = \frac{1}{120}\mathbf{N} \approx \begin{pmatrix} 0,1333 & 0,0667 & 0,1000 & 0,0333 \\ 0,0667 & 0,1333 & 0,0333 & 0,1000 \\ 0,0500 & 0,0500 & 0,1167 & 0,1167 \end{pmatrix}.$$

As massas das linhas são

$$\mathbf{r} = \begin{pmatrix} 1/3 \\ 1/3 \\ 1/3 \end{pmatrix},$$

e as massas das colunas são

$$\mathbf{c} = \begin{pmatrix} 1/4 \\ 1/4 \\ 1/4 \\ 1/4 \end{pmatrix}.$$

Os perfis das linhas são

$$\mathbf{p}_{1| \cdot} = \begin{pmatrix} 0,40 \\ 0,20 \\ 0,30 \\ 0,10 \end{pmatrix}, \quad \mathbf{p}_{2| \cdot} = \begin{pmatrix} 0,20 \\ 0,40 \\ 0,10 \\ 0,30 \end{pmatrix},$$

e

$$\mathbf{p}_{3| \cdot} = \begin{pmatrix} 0,15 \\ 0,15 \\ 0,35 \\ 0,35 \end{pmatrix}.$$

O centro da nuvem dos perfis de linhas é

$$\mathbf{c} = \begin{pmatrix} 0,25 \\ 0,25 \\ 0,25 \\ 0,25 \end{pmatrix}.$$

A distância qui-quadrado entre os dois primeiros perfis é

$$\begin{aligned} d_{\chi^2}^2(1, 2) &= \sum_{j=1}^4 \frac{1}{c_j} \left(\frac{p_{1j}}{r_1} - \frac{p_{2j}}{r_2} \right)^2 \\ &= \frac{(0,40 - 0,20)^2}{0,25} + \frac{(0,20 - 0,40)^2}{0,25} \\ &\quad + \frac{(0,30 - 0,10)^2}{0,25} + \frac{(0,10 - 0,30)^2}{0,25} \\ &= 0,64. \end{aligned}$$

Logo,

$$d_{\chi^2}(1, 2) = 0,80.$$

A matriz correspondente à independência é

$$\mathbf{rc}^\top = \begin{pmatrix} 1/12 & 1/12 & 1/12 & 1/12 \\ 1/12 & 1/12 & 1/12 & 1/12 \\ 1/12 & 1/12 & 1/12 & 1/12 \end{pmatrix}.$$

A matriz de desvios padronizados é

$$\mathbf{Q}_{\text{CA}} = \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{rc}^\top) \mathbf{D}_c^{-1/2},$$

o que fornece

$$\mathbf{Q}_{\text{CA}} \approx \begin{pmatrix} 0,1732 & -0,0577 & 0,0577 & -0,1732 \\ -0,0577 & 0,1732 & -0,1732 & 0,0577 \\ -0,1155 & -0,1155 & 0,1155 & 0,1155 \end{pmatrix}.$$

Como

$$L = \text{posto}(\mathbf{Q}_{\text{CA}}) \leq \min(I - 1, J - 1) = \min(2, 3) = 2,$$

há no máximo duas dimensões não nulas. A SVD de $\mathbf{Q}_{\text{CA}}$ fornece dois valores singulares positivos,

$$d_1 \approx 0,3266, \quad d_2 \approx 0,2828.$$

Portanto,

$$L = 2.$$

As inércias principais são

$$\lambda_1 = d_1^2 \approx 0,1067$$

e

$$\lambda_2 = d_2^2 \approx 0,0800.$$

A inércia total é

$$\mathcal{J} = \lambda_1 + \lambda_2 \approx 0,1867.$$

As proporções da inércia total associadas às duas dimensões são

$$\frac{\lambda_1}{\mathcal{J}} \approx 0,5714$$

e

$$\frac{\lambda_2}{\mathcal{J}} \approx 0,4286.$$

Assim, a primeira dimensão representa aproximadamente 57,14% da inércia total e a segunda representa aproximadamente 42,86%.

Uma orientação possível para as coordenadas principais das linhas é

$$\mathbf{F}_r = \begin{pmatrix} 0,40 & -0,20 \\ -0,40 & -0,20 \\ 0 & 0,40 \end{pmatrix}.$$

As coordenadas principais das colunas podem ser escritas como

$$\mathbf{F}_c \approx \begin{pmatrix} 0,3266 & -0,2828 \\ -0,3266 & -0,2828 \\ 0,3266 & 0,2828 \\ -0,3266 & 0,2828 \end{pmatrix}.$$

A Figura 17.1 representa simultaneamente as coordenadas principais das três categorias de linha e das quatro categorias de coluna. As distâncias dentro de cada margem possuem a interpretação estabelecida pelas coordenadas principais; a distância entre um ponto de linha e um ponto de coluna não constitui uma distância qui-quadrado.

Na nuvem das linhas, manhã e tarde apresentam a maior separação na primeira dimensão, enquanto noite se distingue das duas primeiras principalmente pela segunda dimensão. Na nuvem das colunas, café e suco diferem na primeira dimensão, assim como salgado e doce, enquanto a segunda dimensão separa café e suco de salgado e doce.

As duas nuvens são apresentadas no mesmo sistema de eixos porque as dimensões de linhas e colunas são acopladas pela mesma decomposição singular. As distâncias entre categorias pertencentes à mesma margem podem ser interpretadas em termos das distâncias qui-quadrado entre seus perfis. A distância entre uma categoria de linha e uma categoria de coluna, entretanto, não corresponde diretamente a uma distância qui-quadrado.




Figura 17.1: Representação conjunta das categorias de linha e de coluna em coordenadas principais nas duas dimensões da Análise de Correspondência.

A distância euclidiana entre as duas primeiras linhas na representação completa é

$$\begin{aligned}\|\mathbf{f}_1^{(r)} - \mathbf{f}_2^{(r)}\| &= \sqrt{(0,40 + 0,40)^2 + (-0,20 + 0,20)^2} \\ &= 0,80,\end{aligned}$$

igual à distância qui-quadrado entre seus perfis.

A tabela possui duas dimensões não nulas. A primeira concentra aproximadamente 57,14% da inércia total e separa principalmente os perfis associados às duas primeiras categorias de linha. A segunda concentra aproximadamente 42,86% da inércia e distingue a terceira categoria de linha das demais. Como as duas dimensões são mantidas, a representação das linhas preserva exatamente suas distâncias qui-quadrado, e o mesmo ocorre para as colunas.

A estatística de Pearson é

$$\chi^2 = nJ = 120(0,1867) \approx 22,4.$$

Sob a hipótese populacional de independência e nas condições assintóticas apresentadas na Proposição 17.3, a distribuição de referência é

$$\chi^2_{(I-1)(J-1)} = \chi^2_6.$$

O exemplo distingue três quantidades relacionadas: as distâncias qui-quadrado comparam perfis dentro de cada margem, a inércia total quantifica o afastamento global da independência e a estatística de Pearson relaciona esse afastamento ao total de observações.

17.11 Relação com a Análise de Componentes Principais

A Análise de Componentes Principais e a Análise de Correspondência produzem representações de baixa dimensão a partir de decomposições matriciais, mas são formuladas para estruturas estatísticas diferentes (Johnson; Wichern, 2002).

Na ACP, as direções principais descrevem a variabilidade de dados quantitativos a partir de uma matriz de covariâncias ou correlações, conforme desenvolvido no Capítulo 14. Na Análise de Correspondência, a decomposição é aplicada à matriz de desvios da independência padronizados pelas massas,

$$\mathbf{Q}_{CA} = \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r}\mathbf{c}^\top) \mathbf{D}_c^{-1/2},$$

e a representação descreve a associação entre categorias por meio dos perfis e da geometria qui-quadrado.

A semelhança entre as duas técnicas está na redução dimensional por decomposição matricial. A ACP organiza a variabilidade de dados quantitativos, enquanto a Análise de Correspondência organiza os desvios da independência em uma tabela de frequências. A Análise de Correspondência não corresponde à aplicação direta da ACP a variáveis categóricas.

17.12 Condições e limites da representação

A formulação da Análise de Correspondência desenvolvida neste capítulo é geométrica e descritiva. Hair et al. (Hair et al., 2009) destacam que a técnica apresenta relativa liberdade de pressupostos estatísticos, sem dispensar a avaliação da comparabilidade das categorias e da composição do conjunto analisado. As condições necessárias à construção da geometria são distintas das hipóteses adicionais utilizadas na inferência sobre independência.

17.12.1 Massas positivas e frequências nulas

A tabela de contingência observada satisfaz

$$\mathbf{N} \in \mathbb{N}_0^{I \times J}$$

e

$$n > 0.$$

A definição dos perfis e da matriz $\mathbf{Q}_{CA}$ requer

$$r_i > 0, \quad i = 1, \dots, I,$$

e

$$c_j > 0, \quad j = 1, \dots, J,$$

para que os perfis e as inversas de $\mathbf{D}_r$ e $\mathbf{D}_c$ utilizados na técnica estejam definidos.

Linhas ou colunas com massa nula não possuem perfis definidos e não integram a geometria construída pelas matrizes $\mathbf{D}_r^{-1/2}$ e $\mathbf{D}_c^{-1/2}$.

Massas positivas muito pequenas não impedem matematicamente a análise. Na distância entre perfis de linhas, diferenças nas categorias de coluna são ponderadas pelos inversos das massas c_j ; na distância entre perfis de colunas, diferenças nas categorias de linha são ponderadas pelos inversos das massas r_i . Assim, uma categoria de pequena massa aumenta o peso de desvios

que a envolvem na geometria da margem oposta. Sua própria distância ao centro depende de seu perfil, e não apenas de sua massa.

Uma frequência celular nula,

$$n_{ij} = 0,$$

não impede a construção dos perfis e da geometria quando a massa da linha i e a massa da coluna j permanecem positivas.

17.12.2 Composição da tabela e generalização

A solução depende das categorias que compõem a tabela. Linhas ou colunas atípicas podem alterar a configuração obtida, e a omissão de categorias pertencentes ao conjunto de interesse limita a generalização da representação (Hair et al., 2009).

17.12.3 Dimensão da representação

Pela Equação 17.22,

$$L = \text{posto}(\mathbf{Q}_{CA}) \leq \min(I - 1, J - 1).$$

Quando apenas

$$1 \leq k < L$$

dimensões são mantidas, $\Pi_k^{(CA)}$ é a proporção da inércia total representada pelas primeiras k dimensões.

O mapa é, nesse caso, uma representação de posto reduzido. Uma representação bidimensional não implica que a associação observada seja intrinsecamente bidimensional.

17.12.4 Sinais e orientação

A troca simultânea do sinal de $\mathbf{u}_\ell$ e $\mathbf{v}_\ell$ reflete as coordenadas de linhas e colunas na dimensão ℓ , mas não altera a reconstrução nem a inércia. A designação dos lados positivo e negativo de um eixo é arbitrária, enquanto as posições relativas das categorias permanecem inalteradas.

A não unicidade associada a valores singulares repetidos é desenvolvida em Seção 17.13.2.

17.12.5 Limites da interpretação

A Análise de Correspondência descreve associações entre categorias e é utilizada principalmente de forma exploratória (Hair et al., 2009). Uma inércia positiva,

$$\mathcal{J} > 0,$$

indica que a tabela observada se afasta da estrutura

$$\mathbf{P} = \mathbf{rc}^\top.$$

Sob a formulação multinomial da Seção 17.13.6, a rejeição do teste global fornece evidência contra a hipótese populacional de independência e, portanto, de associação entre as variáveis na população considerada. Esse resultado não estabelece precedência temporal nem exclui explicações alternativas e, portanto, não sustenta interpretação causal.

17.13 Aprofundamentos teóricos

Leitura de aprofundamento

Esta parte trata do limite do posto decorrente das restrições marginais, da não unicidade dos eixos em blocos singulares, da centralização ponderada das coordenadas, da reconstrução dos desvios da independência, da decomposição da estatística de Pearson pelas dimensões e da formulação probabilística do teste global de independência.

17.13.1 Limite do posto da matriz de desvios padronizados

O limite da Equação 17.22 decorre de restrições lineares produzidas pelas próprias marginais da tabela. Como

$$\mathbf{P}\mathbf{1}_J = \mathbf{r}$$

e

$$\mathbf{c}^\top \mathbf{1}_J = 1,$$

segue que

$$\begin{aligned}
\mathbf{Q}_{\text{CA}} \mathbf{D}_c^{1/2} \mathbf{1}_J &= \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r} \mathbf{c}^\top) \mathbf{1}_J \\
&= \mathbf{D}_r^{-1/2} (\mathbf{r} - \mathbf{r}) \\
&= \mathbf{0}.
\end{aligned} \tag{17.41}$$

Analogamente,

$$\mathbf{Q}_{\text{CA}}^\top \mathbf{D}_r^{1/2} \mathbf{1}_I = \mathbf{0}. \tag{17.42}$$

Como

$$\mathbf{D}_c^{1/2} \mathbf{1}_J \neq \mathbf{0}$$

e

$$\mathbf{D}_r^{1/2} \mathbf{1}_I \neq \mathbf{0}$$

sob massas positivas, $\mathbf{Q}_{\text{CA}}$ possui um vetor não nulo em seu núcleo à direita e um vetor não nulo no núcleo de sua transposta. Portanto,

$$\text{posto}(\mathbf{Q}_{\text{CA}}) \leq J - 1$$

e

$$\text{posto}(\mathbf{Q}_{\text{CA}}^\top) \leq I - 1.$$

Consequentemente,

$$\text{posto}(\mathbf{Q}_{\text{CA}}) \leq \min(I - 1, J - 1),$$

o que demonstra o limite enunciado em Equação [17.22](#).

17.13.2 Não unicidade dos eixos e dos subespaços representados

A não unicidade geral dos vetores singulares descrita na Seção 6.9.1 determina, na Análise de Correspondência, quais aspectos de um mapa permanecem invariantes quando a base singular não é única.

Para um valor singular simples, a troca simultânea

$$\mathbf{u}_\ell \mapsto -\mathbf{u}_\ell, \quad \mathbf{v}_\ell \mapsto -\mathbf{v}_\ell$$

não altera

$$d_\ell \mathbf{u}_\ell \mathbf{v}_\ell^\top.$$

Consequentemente, as coordenadas de linhas e colunas podem ser refletidas simultaneamente em uma dimensão sem modificar a reconstrução.

Quando um valor singular d possui multiplicidade $m > 1$, considere as matrizes $\mathbf{U}_B$ e $\mathbf{V}_B$ formadas pelos vetores singulares do bloco correspondente. Para qualquer matriz ortogonal

$$\mathbf{R} \in \mathbb{R}^{m \times m},$$

tem-se

$$\mathbf{U}_B \mapsto \mathbf{U}_B \mathbf{R}, \quad \mathbf{V}_B \mapsto \mathbf{V}_B \mathbf{R},$$

e

$$\mathbf{U}_B \mathbf{R} (d \mathbf{I}_m) (\mathbf{V}_B \mathbf{R})^\top = \mathbf{U}_B (d \mathbf{I}_m) \mathbf{V}_B^\top.$$

Assim, os eixos individuais do bloco não são determinados de maneira única, mas o subespaço por eles gerado permanece o mesmo.

Se todas as dimensões associadas ao valor singular repetido forem mantidas, o subespaço, a parcela de inércia e as distâncias euclidianas entre os pontos de cada nuvem permanecem invariantes. Se o truncamento ocorrer dentro desse bloco, diferentes subespaços de mesma dimensão podem produzir aproximações igualmente ótimas. Nesse caso, a orientação dos eixos retidos não deve ser tratada como uma característica única da solução.

17.13.3 Centralização ponderada das coordenadas padrão e principais

As restrições marginais demonstradas na Seção 17.13.1 determinam também a centralização ponderada das coordenadas padrão e principais.

A partir da Equação 17.41, da Equação 17.42 e da decomposição da Equação 17.26, obtêm-se

$$\mathbf{V}^\top \mathbf{D}_c^{1/2} \mathbf{1}_J = \mathbf{0}$$

e

$$\mathbf{U}^\top \mathbf{D}_r^{1/2} \mathbf{1}_I = \mathbf{0}.$$

De fato, a matriz $\mathbf{D}$ da SVD compacta reúne apenas os valores singulares positivos e, portanto, é invertível. Substituindo as definições das coordenadas padrão dadas na Equação 17.35 e na Equação 17.36, segue que

$$\begin{aligned} \mathbf{r}^\top \mathbf{A}_r &= \left(\mathbf{D}_r^{1/2} \mathbf{1}_I \right)^\top \mathbf{U} = \mathbf{0}^\top, \\ \mathbf{c}^\top \mathbf{A}_c &= \left(\mathbf{D}_c^{1/2} \mathbf{1}_J \right)^\top \mathbf{V} = \mathbf{0}^\top. \end{aligned}$$

As coordenadas principais herdam a mesma centralização:

$$\mathbf{r}^\top \mathbf{F}_r = \mathbf{0}^\top, \quad \mathbf{c}^\top \mathbf{F}_c = \mathbf{0}^\top.$$

Portanto, os centros ponderados das categorias de linha e de coluna coincidem com a origem, tanto em coordenadas padrão quanto em coordenadas principais. Os pesos são as massas das categorias, e não, em geral, pesos iguais. A centralização permanece válida coordenada a coordenada quando apenas parte das dimensões é mantida.

17.13.4 Reconstrução dos desvios da independência

A SVD decompõe os desvios da independência e produz representações de posto reduzido dos perfis (Johnson; Wichern, 2002).

Pela Equação 17.20,

$$\mathbf{P} - \mathbf{r}\mathbf{c}^\top = \mathbf{D}_r^{1/2} \mathbf{Q}_{CA} \mathbf{D}_c^{1/2}.$$

Substituindo a decomposição da Equação 17.26 e usando as definições das coordenadas padrão da Equação 17.35 e da Equação 17.36, obtêm-se

$$\mathbf{P} - \mathbf{r}\mathbf{c}^\top = \mathbf{D}_r \mathbf{A}_r \mathbf{D}_c \mathbf{A}_c^\top \mathbf{D}_c. \quad (17.43)$$

Consequentemente, para a célula (i, j) ,

$$p_{ij} - r_i c_j = r_i c_j \sum_{\ell=1}^L d_\ell a_{i\ell}^{(r)} a_{j\ell}^{(c)}, \quad (17.44)$$

e

$$p_{ij} = r_i c_j \left[1 + \sum_{\ell=1}^L d_\ell a_{i\ell}^{(r)} a_{j\ell}^{(c)} \right]. \quad (17.45)$$

Quando apenas as primeiras $k < L$ dimensões são mantidas, a reconstrução correspondente é

$$\tilde{p}_{ij}^{(k)} = r_i c_j \left[1 + \sum_{\ell=1}^k d_\ell a_{i\ell}^{(r)} a_{j\ell}^{(c)} \right]. \quad (17.46)$$

Essa reconstrução é induzida pela aproximação

$$\mathbf{Q}_{\text{CA},k} = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top,$$

que retém os primeiros k termos da SVD e produz uma aproximação de posto reduzido dos perfis (Johnson; Wichern, 2002).

O erro da aproximação na matriz de desvios padronizados é

$$\|\mathbf{Q}_{\text{CA}} - \mathbf{Q}_{\text{CA},k}\|_F^2 = \sum_{\ell=k+1}^L d_\ell^2 = \sum_{\ell=k+1}^L \lambda_\ell.$$

A soma das inércias principais descartadas corresponde, portanto, à inércia não representada pela solução de dimensão k .

17.13.5 Decomposição da estatística de Pearson pelas dimensões

Pela Equação 17.29,

$$\chi^2 = \sum_{\ell=1}^L n\lambda_{\ell}. \quad (17.47)$$

Cada termo $n\lambda_{\ell}$ é o componente da decomposição algébrica da estatística de Pearson associado à dimensão ℓ da tabela observada.

A Equação 17.47 é uma identidade algébrica. Ela não implica que os termos $n\lambda_{\ell}$ sejam estatísticas qui-quadrado independentes nem define testes separados por dimensão. Conforme a Seção 12.4.1, o teste de Pearson avalia a hipótese global de independência. Sob a formulação multinomial da Seção 17.13.6, a distribuição de referência é associada à estatística global χ^2 .

17.13.6 Formulação probabilística e teste de independência

Na formulação multinomial, sejam A e B duas variáveis categóricas com probabilidades conjuntas populacionais

$$\pi_{ij} = P(A = i, B = j),$$

com

$$\pi_{ij} \geq 0, \quad \sum_{i=1}^I \sum_{j=1}^J \pi_{ij} = 1.$$

As probabilidades marginais são

$$\pi_{i\cdot} = \sum_{j=1}^J \pi_{ij}$$

e

$$\pi_{\cdot j} = \sum_{i=1}^I \pi_{ij}.$$

A hipótese populacional de independência é

$$H_0 : \pi_{ij} = \pi_{i\cdot} \pi_{\cdot j}, \quad i = 1, \dots, I, \quad j = 1, \dots, J. \quad (17.48)$$

As quantidades p_{ij} , r_i e c_j são calculadas a partir da tabela observada, enquanto π_{ij} , $\pi_{i\cdot}$ e $\pi_{\cdot j}$ são parâmetros da distribuição populacional.

Em uma amostra aleatória de tamanho n formada por observações independentes dessa distribuição conjunta, o vetor das frequências celulares é aleatório e possui distribuição multinomial de tamanho n e probabilidades celulares π_{ij} . As frequências n_{ij} utilizadas na tabela são a realização observada desse vetor.

Proposição 17.3 (Distribuição assintótica da estatística de Pearson sob independência). *Considere uma tabela de contingência $I \times J$, com*

$$I \geq 2, \quad J \geq 2,$$

obtida de uma amostra multinomial de tamanho n , mantendo I e J fixos.

Sob

$$H_0 : \pi_{ij} = \pi_{i\cdot} \pi_{\cdot j},$$

suponha

$$\pi_{i\cdot} > 0, \quad i = 1, \dots, I,$$

e

$$\pi_{\cdot j} > 0, \quad j = 1, \dots, J.$$

Então, quando

$$n \longrightarrow \infty,$$

a estatística de Pearson satisfaz

$$\chi^2 \xrightarrow{d} \chi^2_{(I-1)(J-1)}. \quad (17.49)$$

Os $(I-1)(J-1)$ graus de liberdade resultam da diferença entre a dimensão do modelo conjunto irrestrito e a dimensão do modelo de independência. Uma distribuição conjunta sobre uma tabela $I \times J$ possui

$$IJ - 1$$

probabilidades livres, pois sua soma é igual a 1. Sob independência, a distribuição é determinada pelas probabilidades marginais das linhas e das colunas, que possuem, respectivamente,

$$I - 1 \quad \text{e} \quad J - 1$$

parâmetros livres. A diferença entre essas dimensões é

$$(IJ - 1) - [(I - 1) + (J - 1)] = (I - 1)(J - 1),$$

que corresponde aos graus de liberdade da estatística de Pearson sob a hipótese de independência.

A convergência em distribuição da Equação 17.49 é um resultado assintótico no sentido da Definição 12.1 e deve ser distinguida da identidade algébrica exata

$$\chi^2 = n\mathcal{J}.$$

Sob H_0 , a distribuição $\chi^2_{(I-1)(J-1)}$ é a referência inferencial assintótica; a identidade $\chi^2 = n\mathcal{J}$ é válida para a tabela observada.

17.14 Aprofundamentos metodológicos e aplicados

Leitura de aprofundamento

Esta parte trata da definição da tabela e do exame das categorias, da escolha do número de dimensões, da leitura da representação reduzida e da avaliação da sensibilidade e da validação da solução.

17.14.1 Definição da tabela e exame das categorias

A solução depende das categorias incluídas na tabela de contingência. Alterar esse conjunto modifica as massas, os perfis, a matriz de desvios padronizados da independência e, portanto, as dimensões obtidas.

A interpretação do mapa deve considerar as frequências marginais e os perfis. Pela geometria qui-quadrado, diferenças associadas a categorias de pequena massa recebem maior peso na comparação dos perfis da margem oposta. Hair et al. (Hair et al., 2009) destacam ainda a sensibilidade da solução a linhas ou colunas atípicas e ao conjunto de categorias incluídas na análise.

A exclusão, a agregação ou a recodificação de categorias modifica a tabela e pode modificar a solução. Essas decisões devem decorrer da definição das categorias, da origem dos dados e do objetivo da análise.

17.14.2 Relação com o teste global de independência

A Análise de Correspondência é utilizada principalmente como técnica exploratória (Hair et al., 2009) e como técnica gráfica de representação de associações em baixa dimensão (Johnson; Wichern, 2002). Sua construção geométrica não depende da realização de um teste de independência.

Quando a estatística de Pearson é considerada no modelo probabilístico desenvolvido em Seção 17.13.6, sua referência inferencial corresponde à hipótese global de independência. Esse resultado não define testes separados para dimensões, categorias ou células da representação.

17.14.3 Escolha do número de dimensões

A solução completa possui as L dimensões não nulas da decomposição da Equação 17.26, com o limite dimensional dado pela Equação 17.22. Para $L > 1$, uma representação reduzida exige escolher $k < L$ dimensões.

A escolha de k não modifica a solução completa; ela determina quantas dimensões serão utilizadas na representação. A proporção acumulada

$$\Pi_k^{(CA)} = \frac{\sum_{\ell=1}^k \lambda_{\ell}}{\mathcal{J}}$$

quantifica a parcela da inércia total representada pelas primeiras k dimensões. A parcela não representada é

$$1 - \Pi_k^{(CA)} = \frac{\sum_{\ell=k+1}^L \lambda_\ell}{J}. \quad (17.50)$$

A proporção de inércia representada é utilizada para avaliar soluções de baixa dimensão (Johnson; Wichern, 2002). Valores elevados indicam que o subespaço retido preserva grande parte da inércia total.

A Análise de Correspondência não possui um procedimento conclusivo para determinar o número apropriado de dimensões. Hair et al. (Hair et al., 2009) recomendam equilibrar parcimônia e interpretabilidade e apresentam, como orientação prática, a consideração de dimensões cujo **autovalor (valor singular)** seja superior a 0,2, além da manutenção de dimensões suficientes para atender aos objetivos da análise, geralmente duas ou três.

Na notação adotada neste capítulo, essa quantidade corresponde ao valor singular d_ℓ , enquanto a inércia principal é definida por

$$\lambda_\ell = d_\ell^2.$$

Assim, o critério $d_\ell > 0,2$ corresponderia a $\lambda_\ell > 0,04$. Esse limite é uma heurística apresentada por Hair et al. e não constitui um critério matemático para determinar k .

A escolha da representação reduzida deve considerar a proporção acumulada de inércia $\Pi_k^{(CA)}$, a parcela de inércia descartada, a interpretabilidade das dimensões e o objetivo da análise. Uma representação bidimensional pode facilitar a visualização sem representar toda a inércia da tabela.

17.14.4 Leitura da representação reduzida

A leitura de uma representação reduzida deve considerar a proporção de inércia preservada e a geometria definida pela técnica.

Entre categorias de linhas, distâncias pequenas correspondem a perfis de linhas semelhantes segundo a distância qui-quadrado. A interpretação dual vale entre categorias de colunas. Quando apenas $k < L$ dimensões são representadas, as distâncias exibidas correspondem às parcelas das distâncias completas associadas às dimensões retidas.

A posição de uma categoria também deve ser examinada em relação à origem. Em cada nuvem, a origem representa o perfil marginal correspondente; categorias mais afastadas apresentam perfis mais distintos desse centro na representação considerada.

Na comparação entre perfis de linhas, diferenças associadas a colunas de pequena massa recebem maior peso; na comparação entre perfis de colunas, a propriedade dual vale para as

massas das linhas. Massas e perfis devem, portanto, acompanhar a leitura das posições no mapa.

A distância qui-quadrado compara perfis pertencentes à mesma margem (Hair et al., 2009). Distâncias entre duas linhas ou entre duas colunas possuem essa interpretação métrica. A distância euclidiana entre uma categoria de linha e uma categoria de coluna não possui a mesma interpretação. A posição relativa entre as duas margens integra a representação da associação, mas não define uma distância entre perfis.

Na Figura 17.2, as distâncias dentro de cada nuvem são representadas nas duas dimensões exibidas e podem diferir das distâncias qui-quadrado completas quando existem dimensões omitidas.




Figura 17.2: Representação conjunta das categorias de linhas e colunas nas duas primeiras dimensões. As distâncias dentro de cada nuvem são representadas no subespaço exibido; a distância entre uma linha e uma coluna não corresponde, em geral, a uma distância qui-quadrado.

17.14.5 Sensibilidade e validação da interpretação

A reprodução da solução pode ser examinada em relação à amostra e ao conjunto de categorias (Hair et al., 2009).

Em subamostras ou múltiplas amostras, a comparação deve considerar a estrutura dimensional e as posições relativas das categorias.

A sensibilidade ao conjunto de categorias pode ser examinada comparando soluções obtidas após a inclusão ou a exclusão de categorias (Hair et al., 2009). Mudanças nas dimensões retidas ou nas posições relativas das categorias indicam dependência da configuração em relação à composição da tabela.

Uma representação com $k < L$ dimensões omite parte da inércia total. A interpretação do mapa deve, portanto, considerar a proporção de inércia preservada.

A inversão simultânea do sinal de um eixo não caracteriza mudança da solução. Quando valores singulares iguais ou próximos tornam a orientação dos eixos individualmente instável, a comparação deve privilegiar as configurações e os subespaços representados, conforme a Seção 17.13.2.

17.14.6 Análise de Correspondência Múltipla

Quando três ou mais variáveis categóricas são analisadas conjuntamente, a extensão é denominada **Análise de Correspondência Múltipla (ACM)** (Hair et al., 2009).

A ACM representa as categorias das variáveis em um espaço multidimensional comum. O objetivo é obter uma configuração de baixa dimensão que sintetize as associações entre categorias das diferentes variáveis (Hair et al., 2009).

A formulação matricial baseada em uma tabela bidimensional corresponde à Análise de Correspondência simples. A ACM requer uma extensão dessa formulação para acomodar simultaneamente mais de duas variáveis categóricas.

17.14.7 Correspondência com a implementação utilizada

Nas atividades computacionais, a Análise de Correspondência será realizada pelo módulo **MEDA** (Leblay et al., 2026) do **jamovi** (The jamovi project, 2026). Na versão auditada, o **MEDA** utiliza procedimentos do pacote **FactoMineR** (Lê; Josse; Husson, 2008).

A Tabela 17.2 relaciona as principais saídas utilizadas nas atividades aos objetos estatísticos desenvolvidos no capítulo.

Tabela 17.2: Correspondência entre elementos da implementação e os objetos estatísticos desenvolvidos no capítulo.

Elemento da implementação	Correspondência estatística	Desenvolvimento no capítulo
Coluna de identificação das linhas	rótulos das categorias de linha	Seção 17.1
Colunas quantitativas ativas	frequências das categorias de coluna utilizadas na análise	Seção 17.1 e Seção 17.14.1
Percentage	proporção $\lambda_\ell/\mathcal{J}$ da inércia total associada à dimensão ℓ	Equação 17.30 e Seção 17.14.3
Row coordinates	coordenadas principais das linhas $\mathbf{F}_r$	Equação 17.37
Column coordinates	coordenadas principais das colunas $\mathbf{F}_c$	Equação 17.38
Chi-square test	estatística e teste global de independência de Pearson	Seção 17.13.6 e Seção 17.14.2

As coordenadas principais de linhas e colunas determinam a representação das duas margens. Distâncias entre categorias pertencentes à mesma margem devem ser interpretadas segundo a geometria discutida em Seção 17.14.4; a distância entre uma categoria de linha e uma categoria de coluna não constitui uma distância qui-quadrado.

A porcentagem associada a cada dimensão corresponde a

$$100 \frac{\lambda_\ell}{\mathcal{J}}.$$

A soma das porcentagens das primeiras k dimensões corresponde a

$$100 \Pi_k^{(\text{CA})}.$$

O teste qui-quadrado corresponde ao teste global de independência discutido em Seção 17.13.6 e Seção 17.14.2. Sua presença entre as saídas computacionais não altera o caráter exploratório da representação de Correspondência.

17.15 Síntese

A Análise de Correspondência simples representa associações entre as categorias de duas variáveis categóricas a partir de uma tabela de contingência

$$\mathbf{N} = (n_{ij}) \in \mathbb{N}_0^{I \times J}.$$

A matriz de frequências relativas

$$\mathbf{P} = \frac{1}{n} \mathbf{N}$$

determina as massas

$$\mathbf{r} = \mathbf{P} \mathbf{1}_J \quad \text{e} \quad \mathbf{c} = \mathbf{P}^\top \mathbf{1}_I$$

e os perfis condicionais das linhas e das colunas.

Sob independência, a estrutura de referência é

$$\mathbf{P} = \mathbf{r} \mathbf{c}^\top.$$

A Correspondência analisa o afastamento dessa estrutura por meio dos perfis ponderados e das distâncias qui-quadrado. Os desvios padronizados da independência são reunidos na matriz

$$\mathbf{Q}_{\text{CA}} = \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r} \mathbf{c}^\top) \mathbf{D}_c^{-1/2}.$$

A norma de Frobenius de $\mathbf{Q}_{\text{CA}}$ determina a inércia total,

$$\mathcal{J} = \|\mathbf{Q}_{\text{CA}}\|_F^2.$$

A decomposição em valores singulares

$$\mathbf{Q}_{\text{CA}} = \mathbf{U} \mathbf{D} \mathbf{V}^\top$$

decompõe essa inércia em

$$\mathcal{J} = \sum_{\ell=1}^L \lambda_\ell, \quad \lambda_\ell = d_\ell^2.$$

As inércias principais λ_ℓ quantificam a inércia associada a cada dimensão. As razões $\lambda_\ell/\mathcal{J}$ indicam as proporções da inércia total associadas às dimensões individuais, enquanto $\Pi_k^{(\text{CA})}$ indica a proporção acumulada nas primeiras k dimensões. Uma representação com $k < L$ dimensões preserva a proporção $\Pi_k^{(\text{CA})}$ da inércia total e descarta a proporção $1 - \Pi_k^{(\text{CA})}$.

As coordenadas principais fornecem representações euclidianas das distâncias qui-quadrado dentro de cada margem. Quando todas as dimensões não nulas são mantidas, as distâncias euclidianas entre pontos de linhas reproduzem as distâncias qui-quadrado entre seus perfis, e a relação dual vale para as colunas. A dualidade da construção conecta as duas nuvens, mas não estabelece uma distância qui-quadrado direta entre uma categoria de linha e uma categoria de coluna.

Para a tabela observada,

$$\chi^2 = nJ.$$

Essa identidade relaciona a geometria da Correspondência à estatística de Pearson. A inércia descreve o afastamento observado da independência, enquanto a interpretação inferencial de χ^2 em relação à hipótese populacional de independência requer um modelo probabilístico e as condições do resultado assintótico.

A ACP e a Análise de Correspondência produzem representações de baixa dimensão por decomposição matricial, mas partem de objetos diferentes. A ACP organiza a variabilidade de dados quantitativos, enquanto a Análise de Correspondência organiza os desvios da independência em uma tabela de contingência segundo a geometria qui-quadrado.

No Capítulo 18, o problema estatístico passa da representação de associações entre categorias para a comparação conjunta de várias respostas quantitativas entre grupos ou condições previamente definidos. A formulação utiliza o modelo linear multivariado, as matrizes de hipótese e erro e critérios baseados em sua estrutura espectral.

18 Formulação da MANOVA

A Análise Multivariada de Variância (MANOVA) testa hipóteses sobre vetores de médias ou, de forma mais geral, sobre funções estimáveis dos parâmetros de um modelo linear com várias respostas. A formulação considera p respostas quantitativas observadas nas mesmas unidades amostrais. Grupos, tratamentos, fatores e covariáveis são representados na matriz de delineamento.

O modelo linear multivariado definido na Definição 11.3 é

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E}.$$

A MANOVA compara a matriz de somas de quadrados e produtos cruzados (SQPC) da hipótese, $\mathbf{H}$, com a SQPC residual, $\mathbf{E}$. O problema de autovalores generalizados associado a essas matrizes produz as raízes utilizadas pelo lambda de Wilks, pelo traço de Pillai, pelo traço de Hotelling e pela maior raiz característica de Roy (Anderson, 2003).

A hipótese linear geral da Definição 11.15, a SQPC da hipótese da Definição 11.16 e a SQPC residual da Definição 11.10 são utilizadas diretamente na formulação da MANOVA.

Os elementos da formulação são resumidos na Tabela 18.1.

Tabela 18.1: Elementos da formulação da MANOVA.

Elemento	Objeto	Papel na MANOVA
respostas	$\mathbf{y}$	reúne as p respostas observadas nas mesmas unidades amostrais
delineamento	$\mathbf{Z}$	representa grupos, tratamentos, covariáveis e demais termos
parâmetros	$\mathbf{B}$	reúne os coeficientes que determinam a matriz de médias $\mathbf{ZB}$
hipótese	$\mathbf{C}_1\mathbf{B} = \Theta_0$	especifica uma função estimável sobre todas as respostas

Elemento	Objeto	Papel na MANOVA
SQPC da hipótese	$\mathbf{H}$	reúne somas de quadrados e produtos cruzados associados ao afastamento observado de H_0
SQPC residual	$\mathbf{E}$	reúne somas de quadrados e produtos cruzados residuais
comparação direcional	$\mathbf{a}^\top \mathbf{H} \mathbf{a} / \mathbf{a}^\top \mathbf{E} \mathbf{a}$	compara hipótese e erro para uma combinação das respostas
solução espectral	raízes e direções características	identifica as direções extremas da razão entre hipótese e erro e seus valores associados
critérios de teste	lambda de Wilks, traço de Pillai, traço de Hotelling e maior raiz característica de Roy	combinam as mesmas raízes características por funções diferentes

18.1 O problema de comparação multivariada

Considere inicialmente $K \geq 2$ grupos e um vetor de p respostas para cada unidade,

$$\mathbf{Y}_i = \begin{pmatrix} Y_{i1} \\ \vdots \\ Y_{ip} \end{pmatrix} \in \mathbb{R}^p.$$

Se o vetor de médias do grupo k é

$$\mu_k = \begin{pmatrix} \mu_{k1} \\ \vdots \\ \mu_{kp} \end{pmatrix} \in \mathbb{R}^p, \quad k = 1, \dots, K,$$

a hipótese de igualdade dos vetores de médias é

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_K. \quad (18.1)$$

A hipótese alternativa afirma que pelo menos dois desses vetores de médias diferem.

Quando

$$p = 1,$$

a hipótese da Equação 18.1 é univariada e a comparação pode ser expressa pela razão entre a soma de quadrados da hipótese e a soma de quadrados residual.

Quando

$$p > 1,$$

as diferenças entre os vetores de médias pertencem a $\mathbb{R}^p$ e podem ser examinadas por combinações lineares das respostas. Uma combinação linear pode evidenciar diferenças entre grupos que são pequenas em cada resposta considerada isoladamente. Diferenças marginais observadas em várias respostas também devem ser interpretadas considerando as covariâncias residuais entre elas.

A MANOVA avalia as diferenças entre os vetores de médias em relação à variabilidade residual de cada resposta e às covariâncias residuais entre as respostas.

A comparação multivariada não é equivalente a realizar separadamente p análises de variância, pois essas análises marginais não incorporam as covariâncias residuais entre as respostas. Na MANOVA, somas de quadrados e produtos cruzados da hipótese e do erro são organizados em matrizes que preservam essa informação conjunta.

18.2 A hipótese no modelo linear multivariado

O problema de comparação entre grupos é uma aplicação do modelo linear multivariado. Indicadores de grupos, tratamentos, fatores e covariáveis são incorporados à matriz de delineamento $\mathbf{Z}$.

Pela Definição 11.15, a hipótese linear geral é

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0. \quad (18.2)$$

Na MANOVA formulada para as p respostas originais,

$$\mathbf{C}_2 = \mathbf{I}_p,$$

e a hipótese torna-se

$$H_0 : \mathbf{C}_1 \mathbf{B} = \Theta_0, \quad (18.3)$$

com

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q}$$

e

$$\Theta_0 \in \mathbb{R}^{g \times p}.$$

A matriz $\mathbf{C}_1$ reúne as combinações lineares dos parâmetros que definem o efeito testado. A formulação utiliza $\mathbf{C}_1$ com linhas linearmente independentes,

$$\text{posto}(\mathbf{C}_1) = g, \quad (18.4)$$

e exige que $\mathbf{C}_1 \mathbf{B}$ seja estimável. Pela condição da Equação 11.76,

$$\mathbf{C}_1 = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Z}. \quad (18.5)$$

Como $\mathbf{C}_1$ possui g linhas linearmente independentes, os graus de liberdade da hipótese são

$$\nu_H = g. \quad (18.6)$$

Para a hipótese de igualdade dos vetores de médias de K grupos,

$$g = K - 1. \quad (18.7)$$

A hipótese de igualdade dos vetores de médias da Equação 18.1 é um caso particular da hipótese linear geral da Definição 11.15.

18.2.1 SQPC da hipótese e SQPC residual

Para a hipótese da Equação 18.3, a SQPC da hipótese definida na Definição 11.16 é denotada por

$$\mathbf{H} \in \mathbb{R}^{p \times p},$$

com

$$\mathbf{H} = \mathbf{H}^\top \succeq \mathbf{0}.$$

A matriz $\mathbf{H}$ reúne as somas de quadrados e os produtos cruzados associados ao afastamento observado de H_0 . Seus elementos diagonais são as somas de quadrados da hipótese para cada resposta, enquanto os elementos fora da diagonal são os produtos cruzados entre os afastamentos correspondentes.

Pela Definição 11.10, a SQPC residual é

$$\mathbf{E} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}} \in \mathbb{R}^{p \times p},$$

com

$$\mathbf{E} = \mathbf{E}^\top \succeq \mathbf{0}.$$

Os elementos diagonais de $\mathbf{E}$ são as somas de quadrados residuais de cada resposta, enquanto os elementos fora da diagonal são os produtos cruzados residuais entre as respostas.

A Tabela 18.2 compara a origem e a interpretação das SQPCs $\mathbf{H}$ e $\mathbf{E}$.

Tabela 18.2: Funções das matrizes de hipótese e erro na MANOVA.

Matriz	Origem	Interpretação
$\mathbf{H}$	hipótese testada	somas de quadrados e produtos cruzados associados ao afastamento observado de H_0
$\mathbf{E}$	resíduos do modelo	somas de quadrados e produtos cruzados residuais

Se

$$\mathbf{H} = \mathbf{0},$$

não há afastamento observado da hipótese nas funções paramétricas consideradas. Quando $\mathbf{H} \neq \mathbf{0}$, o afastamento deve ser avaliado em relação à variação residual representada por $\mathbf{E}$.

A comparação entre $\mathbf{H}$ e $\mathbf{E}$ é feita para as mesmas combinações lineares das respostas.

18.3 Hipótese e erro em uma combinação linear das respostas

Para a unidade i , considere a combinação linear das p respostas

$$W_i = \mathbf{a}^\top \mathbf{Y}_i, \quad \mathbf{a} \in \mathbb{R}^p. \quad (18.8)$$

Para a combinação linear da Equação 18.8, as somas de quadrados associadas à hipótese e ao erro são

$$h(\mathbf{a}) = \mathbf{a}^\top \mathbf{H} \mathbf{a} \quad (18.9)$$

e

$$e(\mathbf{a}) = \mathbf{a}^\top \mathbf{E} \mathbf{a}. \quad (18.10)$$

Pela Definição 2.17, $h(\mathbf{a})$ e $e(\mathbf{a})$ são formas quadráticas em $\mathbf{a}$. A primeira é a soma de quadrados associada à hipótese para a resposta combinada W_i , enquanto a segunda é sua soma de quadrados residual.

A formulação espectral adotada pressupõe

$$\mathbf{E} \succ \mathbf{0}. \quad (18.11)$$

Então,

$$\mathbf{a}^\top \mathbf{E} \mathbf{a} > 0$$

para todo

$$\mathbf{a} \neq \mathbf{0},$$

e a razão entre hipótese e erro é definida por

$$\mathcal{R}_{\mathbf{H}, \mathbf{E}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{H} \mathbf{a}}{\mathbf{a}^\top \mathbf{E} \mathbf{a}}. \quad (18.12)$$

A razão da Equação 18.12 é o quociente de Rayleigh generalizado definido na Definição 5.9, aplicado ao par

$$(\mathbf{H}, \mathbf{E}).$$

A razão é invariante à escala de $\mathbf{a}$. Para qualquer

$$c \neq 0,$$

$$\mathcal{R}_{\mathbf{H}, \mathbf{E}}(c\mathbf{a}) = \mathcal{R}_{\mathbf{H}, \mathbf{E}}(\mathbf{a}).$$

A razão depende apenas da direção definida por $\mathbf{a}$ e não de sua norma.

Uma direção apresenta grande razão hipótese/erro quando a soma de quadrados associada à hipótese é grande em relação à soma de quadrados residual da mesma combinação de respostas.

18.4 Problema espectral da MANOVA

Pelo Teorema 5.6, aplicado ao par $(\mathbf{H}, \mathbf{E})$ com

$$\mathbf{H} \succeq \mathbf{0} \quad \text{e} \quad \mathbf{E} \succ \mathbf{0},$$

o maior valor da razão hipótese/erro é

$$\max_{\mathbf{a} \neq \mathbf{0}} \frac{\mathbf{a}^\top \mathbf{H} \mathbf{a}}{\mathbf{a}^\top \mathbf{E} \mathbf{a}} = \lambda_1. \quad (18.13)$$

As direções características são obtidas do problema de autovalor generalizado

$$\mathbf{H} \mathbf{a} = \lambda \mathbf{E} \mathbf{a}. \quad (18.14)$$

Esse é o problema de autovalor generalizado definido na Definição 5.8.

Definição 18.1 (Raízes características da MANOVA). Sejam

$$\mathbf{H}, \mathbf{E} \in \mathbb{R}^{p \times p}$$

simétricas, com

$$\mathbf{H} \succeq \mathbf{0}$$

e

$$\mathbf{E} \succ \mathbf{0}.$$

As **raízes características da MANOVA** são os autovalores generalizados

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p \geq 0$$

do par $(\mathbf{H}, \mathbf{E})$. Como $\mathbf{E} \succ \mathbf{0}$, os autovetores generalizados associados podem ser escolhidos com a normalização

$$\alpha_j^\top \mathbf{E} \alpha_j = 1.$$

Os pares

$$(\lambda_j, \alpha_j)$$

satisfazem

$$\mathbf{H} \alpha_j = \lambda_j \mathbf{E} \alpha_j.$$

Cada λ_j é uma raiz característica, isto é, um autovalor generalizado do par $(\mathbf{H}, \mathbf{E})$. O vetor α_j é um autovetor generalizado normalizado, e a reta

$$\text{span}(\alpha_j)$$

define a direção característica correspondente.

Se

$$r_H = \text{posto}(\mathbf{H}),$$

então exatamente r_H raízes são positivas. Quando $r_H > 0$,

$$\lambda_1 \geq \cdots \geq \lambda_{r_H} > 0.$$

Se $r_H < p$,

$$\lambda_{r_H+1} = \cdots = \lambda_p = 0.$$

Como $\mathbf{C}_1$ possui posto g , a SQPC da hipótese satisfaz

$$\text{posto}(\mathbf{H}) \leq \min(p, g),$$

tem-se

$$r_H \leq \min(p, g). \quad (18.15)$$

Na hipótese de igualdade dos vetores de médias de K grupos,

$$g = K - 1,$$

logo

$$r_H \leq \min(p, K - 1). \quad (18.16)$$

Portanto, o número de raízes características positivas é limitado simultaneamente pelo número de respostas e pelo número de restrições lineares independentes da hipótese.

Como $\mathbf{E} \succ \mathbf{0}$, o produto interno induzido definido na Definição 3.16 pode ser aplicado com matriz $\mathbf{E}$. Os autovetores generalizados podem ser escolhidos ortonormais nesse produto interno:

$$\alpha_j^\top \mathbf{E} \alpha_\ell = \delta_{j\ell}. \quad (18.17)$$

As direções características não precisam, portanto, ser ortogonais na geometria euclidiana original das respostas.

18.4.1 Padronização pela SQPC residual e interpretação geométrica

Como

$$\mathbf{E} \succ \mathbf{0},$$

a raiz quadrada principal $\mathbf{E}^{1/2}$ é definida pela Definição 5.7 e também é positiva definida. Portanto, $\mathbf{E}^{1/2}$ é invertível.

Defina

$$\mathbf{z} = \mathbf{E}^{1/2} \mathbf{a}.$$

Então,

$$\mathbf{a} = \mathbf{E}^{-1/2} \mathbf{z},$$

e o problema generalizado transforma-se em

$$\mathbf{M}_{\text{HE}} \mathbf{z} = \lambda \mathbf{z}, \quad (18.18)$$

em que

$$\mathbf{M}_{\text{HE}} = \mathbf{E}^{-1/2} \mathbf{H} \mathbf{E}^{-1/2} \in \mathbb{R}^{p \times p}. \quad (18.19)$$

Como $\mathbf{H} \succeq \mathbf{0}$,

$$\mathbf{M}_{\text{HE}} = \mathbf{M}_{\text{HE}}^\top \succeq \mathbf{0}.$$

Além disso,

$$\text{posto}(\mathbf{M}_{\text{HE}}) = \text{posto}(\mathbf{H}) = r_H,$$

Portanto, $\mathbf{M}_{\text{HE}}$ possui exatamente r_H autovalores positivos, que coincidem com as raízes positivas da MANOVA.

Substituindo

$$\mathbf{a} = \mathbf{E}^{-1/2} \mathbf{z},$$

obtêm-se

$$\mathbf{a}^\top \mathbf{E} \mathbf{a} = \mathbf{z}^\top \mathbf{z}$$

e

$$\mathbf{a}^\top \mathbf{H} \mathbf{a} = \mathbf{z}^\top \mathbf{M}_{\text{HE}} \mathbf{z}.$$

Portanto,

$$\mathcal{R}_{\mathbf{H}, \mathbf{E}}(\mathbf{a}) = \frac{\mathbf{z}^\top \mathbf{M}_{\text{HE}} \mathbf{z}}{\mathbf{z}^\top \mathbf{z}}. \quad (18.20)$$

A transformação $\mathbf{z} = \mathbf{E}^{1/2}\mathbf{a}$ converte a forma quadrática residual em uma norma euclidiana. Nesse sistema, $\mathbf{z}^\top \mathbf{M}_{\text{HE}} \mathbf{z}$ é a forma quadrática da hipótese correspondente à direção $\mathbf{z}$.

A Figura 18.1 representa a mudança de coordenadas $\mathbf{z} = \mathbf{E}^{1/2}\mathbf{a}$ no espaço dos coeficientes das combinações lineares. Antes da padronização, o conjunto de vetores de coeficientes que satisfaz

$$\mathbf{a}^\top \mathbf{E} \mathbf{a} = 1$$

forma uma elipse determinada pela forma quadrática residual. Sob a transformação

$$\mathbf{z} = \mathbf{E}^{1/2}\mathbf{a},$$

a condição

$$\mathbf{a}^\top \mathbf{E} \mathbf{a} = 1$$

torna-se

$$\mathbf{z}^\top \mathbf{z} = 1,$$

que define o círculo unitário. Nesse sistema padronizado, as direções características são os autovetores de $\mathbf{M}_{\text{HE}}$.

A Figura 18.1 não representa observações, médias de grupos ou regiões de probabilidade. O contorno corresponde ao conjunto de combinações lineares normalizadas pela forma quadrática residual. A transformação

$$\mathbf{z} = \mathbf{E}^{1/2}\mathbf{a}$$

converte

$$\mathbf{a}^\top \mathbf{E} \mathbf{a}$$

em

$$\mathbf{z}^\top \mathbf{z}.$$

Se uma direção característica for normalizada por




Figura 18.1: Branqueamento da geometria residual. À esquerda, o contorno representa as combinações lineares normalizadas por $\mathbf{a}^\top \mathbf{E} \mathbf{a} = 1$. Após a transformação $\mathbf{z} = \mathbf{E}^{1/2} \mathbf{a}$, a métrica residual torna-se euclidiana e o contorno transforma-se no círculo unitário. As linhas indicam as duas direções características do problema.

$$\alpha_j^\top \mathbf{E} \alpha_j = 1,$$

então

$$\alpha_j^\top \mathbf{H} \alpha_j = \lambda_j. \quad (18.21)$$

Cada raiz λ_j é a razão hipótese/erro na respectiva direção característica normalizada. A ordenação $\lambda_1 \geq \dots \geq \lambda_p$ ordena essas direções pela razão entre a soma de quadrados da hipótese e a soma de quadrados residual.

A solução do problema espectral produz as raízes características ordenadas

$$\lambda_1 \geq \dots \geq \lambda_p \geq 0.$$

Os quatro critérios clássicos da MANOVA são funções dessas raízes.

18.5 Critérios multivariados

Considere as raízes características

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$$

definidas na Definição 18.1 para o par $(\mathbf{H}, \mathbf{E})$, sob

$$\mathbf{H} \succeq \mathbf{0} \quad \text{e} \quad \mathbf{E} \succ \mathbf{0}.$$

Os quatro critérios clássicos da MANOVA são funções das raízes

$$\lambda_1, \dots, \lambda_p.$$

As formas espectrais dos critérios decorrem da matriz padronizada

$$\mathbf{M}_{\mathbf{H}\mathbf{E}} = \mathbf{E}^{-1/2} \mathbf{H} \mathbf{E}^{-1/2},$$

definida na Equação 18.19. Essa matriz é simétrica positiva semidefinida e possui autovalores

$$\lambda_1, \dots, \lambda_p.$$

Pela Proposição 5.4, o traço de uma matriz simétrica é a soma de seus autovalores e seu determinante é o produto desses autovalores. A Proposição 2.5 e a Proposição 2.9 permitem relacionar essas propriedades às expressões originais em $\mathbf{H}$ e $\mathbf{E}$. Além disso, pela Definição 5.6 e pela Proposição 5.6, uma função espectral de $\mathbf{M}_{\text{HE}}$ transforma cada autovalor λ_j no valor correspondente da função escalar.

Definição 18.2 (Lambda de Wilks). A **lambda de Wilks** é

$$\Lambda_W = \frac{|\mathbf{E}|}{|\mathbf{E} + \mathbf{H}|} = \prod_{j=1}^p \frac{1}{1 + \lambda_j}. \quad (18.22)$$

De fato, pela definição de $\mathbf{M}_{\text{HE}}$,

$$\mathbf{E} + \mathbf{H} = \mathbf{E}^{1/2} (\mathbf{I}_p + \mathbf{M}_{\text{HE}}) \mathbf{E}^{1/2}.$$

Pela propriedade multiplicativa do determinante em Proposição 2.9,

$$\begin{aligned} |\mathbf{E} + \mathbf{H}| &= |\mathbf{E}^{1/2}|^2 |\mathbf{I}_p + \mathbf{M}_{\text{HE}}| \\ &= |\mathbf{E}| |\mathbf{I}_p + \mathbf{M}_{\text{HE}}|. \end{aligned}$$

Os autovalores de $\mathbf{I}_p + \mathbf{M}_{\text{HE}}$ são

$$1 + \lambda_1, \dots, 1 + \lambda_p.$$

Pela Proposição 5.4,

$$|\mathbf{I}_p + \mathbf{M}_{\text{HE}}| = \prod_{j=1}^p (1 + \lambda_j).$$

Portanto,

$$|\mathbf{E} + \mathbf{H}| = |\mathbf{E}| \prod_{j=1}^p (1 + \lambda_j),$$

o que fornece

$$\Lambda_W = \prod_{j=1}^p \frac{1}{1 + \lambda_j}.$$

A lambda de Wilks satisfaz

$$0 < \Lambda_W \leq 1,$$

com

$$\Lambda_W = 1$$

se, e somente se,

$$\mathbf{H} = \mathbf{0}.$$

Como cada fator $(1 + \lambda_j)^{-1}$ decresce com λ_j , valores menores de Λ_W correspondem a raízes características maiores. Na Seção 18.9.1.1, esse critério é relacionado à razão de verossimilhanças sob o modelo normal (Wilks, 1932).

Definição 18.3 (Traço de Pillai). O **traço de Pillai** é (Pillai, 1955)

$$V = \text{tr} [\mathbf{H} (\mathbf{H} + \mathbf{E})^{-1}] = \sum_{j=1}^p \frac{\lambda_j}{1 + \lambda_j}. \quad (18.23)$$

Cada raiz contribui pelo termo

$$\frac{\lambda_j}{1 + \lambda_j},$$

que pertence a $[0, 1)$ e cresce monotonicamente com λ_j .

Como

$$\mathbf{H} = \mathbf{E}^{1/2} \mathbf{M}_{\text{HE}} \mathbf{E}^{1/2}$$

e

$$\mathbf{H} + \mathbf{E} = \mathbf{E}^{1/2} (\mathbf{I}_p + \mathbf{M}_{\text{HE}}) \mathbf{E}^{1/2},$$

tem-se

$$\mathbf{H} (\mathbf{H} + \mathbf{E})^{-1} = \mathbf{E}^{1/2} \mathbf{M}_{\text{HE}} (\mathbf{I}_p + \mathbf{M}_{\text{HE}})^{-1} \mathbf{E}^{-1/2}.$$

Pela propriedade cíclica do traço em Proposição 2.5,

$$V = \text{tr} \left[\mathbf{M}_{\text{HE}} (\mathbf{I}_p + \mathbf{M}_{\text{HE}})^{-1} \right].$$

A matriz

$$\mathbf{M}_{\text{HE}} (\mathbf{I}_p + \mathbf{M}_{\text{HE}})^{-1}$$

é a função espectral de $\mathbf{M}_{\text{HE}}$ correspondente a

$$f(\lambda) = \frac{\lambda}{1 + \lambda}.$$

Pela Proposição 5.6, seus autovalores são

$$\frac{\lambda_1}{1 + \lambda_1}, \dots, \frac{\lambda_p}{1 + \lambda_p}.$$

Aplicando a Proposição 5.4 ao traço,

$$V = \sum_{j=1}^p \frac{\lambda_j}{1 + \lambda_j}.$$

Definição 18.4 (Traço de Hotelling). O **traço de Hotelling** é

$$U = \text{tr} (\mathbf{E}^{-1} \mathbf{H}) = \sum_{j=1}^p \lambda_j. \quad (18.24)$$

Pela propriedade cíclica do traço em Proposição 2.5,

$$\begin{aligned} \text{tr} (\mathbf{E}^{-1} \mathbf{H}) &= \text{tr} (\mathbf{E}^{-1/2} \mathbf{H} \mathbf{E}^{-1/2}) \\ &= \text{tr} (\mathbf{M}_{\text{HE}}). \end{aligned}$$

Como os autovalores de $\mathbf{M}_{\text{HE}}$ são $\lambda_1, \dots, \lambda_p$, a Proposição 5.4 fornece

$$U = \sum_{j=1}^p \lambda_j.$$

O critério utiliza diretamente a soma das razões hipótese/erro. Como

$$\lambda_j \geq 0,$$

tem-se

$$U \geq 0,$$

com igualdade se, e somente se, $\mathbf{H} = \mathbf{0}$.

Definição 18.5 (Maior raiz característica de Roy). A **maior raiz característica de Roy** é

$$\lambda_1. \quad (18.25)$$

Pela Equação 18.13,

$$\lambda_1 = \max_{\mathbf{a} \neq \mathbf{0}} \frac{\mathbf{a}^\top \mathbf{H} \mathbf{a}}{\mathbf{a}^\top \mathbf{E} \mathbf{a}}. \quad (18.26)$$

A maior raiz característica de Roy utiliza somente λ_1 . Pela Equação 18.26, essa raiz corresponde ao máximo da razão entre a SQPC da hipótese e a SQPC residual entre todas as direções não nulas.

18.6 Quatro critérios como funções das raízes características

Os quatro critérios dependem das raízes características

$$\lambda_1, \dots, \lambda_p$$

do problema

$$\mathbf{H} \mathbf{a} = \lambda \mathbf{E} \mathbf{a}.$$

Uma raiz nula contribui com o fator 1 para a lambda de Wilks e com o termo 0 para o traço de Pillai e para o traço de Hotelling. Portanto, as raízes

$$\lambda_{r_H+1}, \dots, \lambda_p$$

não alteram os valores desses critérios. A maior raiz característica de Roy depende apenas de λ_1 .

A Tabela 18.3 compara as operações aplicadas às raízes.

Tabela 18.3: Critérios clássicos da MANOVA como funções das mesmas raízes características.

Critério	Expressão em função das raízes	Operação sobre as raízes	Evidência crescente contra H_0
Lambda de Wilks	$\prod_{j=1}^p (1 + \lambda_j)^{-1}$	produto	valores menores
Traço de Pillai	$\sum_{j=1}^p \frac{\lambda_j}{1 + \lambda_j}$	soma dos termos transformados	valores maiores
Traço de Hotelling	$\sum_{j=1}^p \lambda_j$	soma das raízes	valores maiores
Maior raiz característica de Roy	λ_1	maior raiz	valores maiores

A maior raiz característica de Roy utiliza apenas λ_1 . O traço de Hotelling soma as raízes, o traço de Pillai soma os termos $\lambda_j/(1+\lambda_j)$ e a lambda de Wilks multiplica os fatores $(1+\lambda_j)^{-1}$.

Quando existe apenas uma raiz positiva, os quatro critérios são funções monotônicas dessa raiz. Com duas ou mais raízes positivas, as funções que definem os quatro critérios não são, em geral, transformações monotônicas entre si.

18.6.1 Uso inferencial dos critérios

Os valores observados da lambda de Wilks, do traço de Pillai, do traço de Hotelling e da maior raiz característica de Roy são funções de $\mathbf{H}$ e $\mathbf{E}$. Sua utilização como estatísticas de teste requer a distribuição de referência sob

$$H_0 : \mathbf{C}_1 \mathbf{B} = \Theta_0.$$

Sob o modelo normal multivariado clássico, essa distribuição depende do número de respostas p , dos graus de liberdade da hipótese

$$\nu_H = g,$$

e dos graus de liberdade residuais ν_E .

Em configurações particulares, transformações dos critérios possuem distribuição F exata. Quando existem várias raízes positivas, são utilizadas distribuições, transformações ou aproximações específicas para cada critério, determinadas por p , g e ν_E (Anderson, 2003; Johnson; Wichern, 2002).

Fixado um nível de significância α , rejeita-se H_0 quando o valor p obtido pela distribuição de referência é menor ou igual a α . Valores menores de Λ_W e valores maiores de V , U e λ_1 correspondem a maior evidência contra H_0 .

Sob normalidade, a calibração decorre da distribuição conjunta de $\mathbf{H}$ e $\mathbf{E}_{\text{res}}$ estabelecida na Seção 18.9.1. Os casos exatos e as aproximações utilizadas para os critérios são especificados na Seção 18.9.2.

18.7 Pressupostos e limites

A formulação da MANOVA especifica a média das respostas, a comparação entre hipótese e erro e, para a inferência clássica, a distribuição dos erros. A estimabilidade determina quais hipóteses podem ser formuladas, enquanto independência entre unidades, covariância residual comum, não singularidade e normalidade multivariada sustentam a calibração inferencial clássica.

18.7.1 Estrutura da média e estimabilidade

O modelo pressupõe

$$E(\mathbf{y} \mid \mathbf{Z}) = \mathbf{Z}\mathbf{B}.$$

Grupos, tratamentos, covariáveis e demais efeitos incluídos no modelo são representados por colunas de $\mathbf{Z}$. Essa especificação determina o espaço de médias e os resíduos do modelo; a hipótese é definida por funções estimáveis de $\mathbf{B}$.

Para

$$H_0 : \mathbf{C}_1\mathbf{B} = \Theta_0,$$

a função $\mathbf{C}_1\mathbf{B}$ deve ser estimável. Pela Equação 18.5,

$$\mathbf{C}_1 = \mathbf{C}_1\mathbf{Z}^+\mathbf{Z}.$$

Essa condição garante que $\mathbf{C}_1\mathbf{B}$ seja determinada pela média $\mathbf{Z}\mathbf{B}$, mesmo quando diferentes parametrizações de $\mathbf{B}$ produzem a mesma média. A estimabilidade não depende da normalidade multivariada.

18.7.2 Independência entre unidades

Na formulação probabilística clássica, os vetores de erros associados a unidades observacionais distintas são independentes:

$$\mathbf{e}_1, \dots, \mathbf{e}_n.$$

A dependência entre as respostas de uma mesma unidade é descrita por Σ . Quando várias medidas da mesma unidade compõem um único vetor resposta, suas covariâncias integram essa matriz. Se unidades distintas também apresentam dependência temporal, espacial ou decorrente de agrupamentos, a hipótese de independência entre os vetores de erros deixa de valer. Nesse caso, o modelo deve especificar também as covariâncias entre erros de unidades distintas.

18.7.3 Covariância residual comum

O modelo clássico utiliza

$$\text{Cov}(\mathbf{e}_i | \mathbf{Z}) = \Sigma, \quad i = 1, \dots, n.$$

Na comparação entre grupos, a mesma matriz Σ descreve a covariância residual populacional em todos os grupos. A matriz $\mathbf{E}$ é a SQPC residual observada do modelo.

Se as matrizes de covariâncias residuais diferem entre grupos, os quatro critérios ainda podem ser calculados quando as operações matriciais necessárias estão definidas, mas suas distribuições de referência clássicas não decorrem do modelo normal com covariância comum.

18.7.4 Não singularidade populacional e amostral

A formulação clássica considera

$$\Sigma \succ \mathbf{0}.$$

Pela Proposição 8.3, $\Sigma \succ \mathbf{0}$ implica que nenhuma combinação linear não nula das respostas residuais possui variância igual a zero.

A forma simétrica

$$\mathbf{M}_{\text{HE}} = \mathbf{E}^{-1/2} \mathbf{H} \mathbf{E}^{-1/2}$$

exige

$$\mathbf{E} \succ \mathbf{0}.$$

Com ν_E denotando os graus de liberdade residuais definidos na Definição 11.11,

$$\text{posto}(\mathbf{E}) \leq \min(p, \nu_E).$$

a condição

$$\mathbf{E} \succ \mathbf{0}$$

exige

$$\nu_E \geq p.$$

Essa condição é necessária, mas não suficiente para dados arbitrários: relações lineares exatas entre as respostas residuais podem reduzir o posto de $\mathbf{E}$ mesmo quando $\nu_E \geq p$.

Sob o modelo normal clássico, com $\Sigma \succ \mathbf{0}$, pela Equação 12.26,

$$\mathbf{E}_{\text{res}} \succ \mathbf{0}$$

com probabilidade 1 se, e somente se, $\nu_E \geq p$. A matriz observada $\mathbf{E}$ é uma realização de $\mathbf{E}_{\text{res}}$.

Quando $\mathbf{E}$ é singular, sua raiz quadrada $\mathbf{E}^{1/2}$ existe, mas também é singular. Portanto,

$$\mathbf{E}^{-1} \quad \text{e} \quad \mathbf{E}^{-1/2}$$

não existem como inversas ordinárias. A formulação espectral baseada em $\mathbf{E}^{-1/2}$ não está definida nesse caso.

18.7.5 Normalidade multivariada

A normalidade não é necessária para construir as SQPCs $\mathbf{H}$ e $\mathbf{E}$. Sob

$$\mathbf{E} \succ \mathbf{0},$$

as raízes características e os quatro critérios são definidos algebricamente sem exigir uma distribuição normal para os erros.

Sob o modelo linear normal multivariado definido na Definição 11.6, os erros são normais multivariados, independentes entre unidades e possuem matriz de covariâncias comum. Sob H_0 , essas condições implicam distribuições Wishart centrais para $\mathbf{H}$ e $\mathbf{E}_{\text{res}}$ e independência entre essas matrizes.

A hipótese de normalidade refere-se aos vetores de erros do modelo, condicionada à matriz de delineamento $\mathbf{Z}$. Ela não exige que a distribuição marginal obtida ao reunir respostas de unidades com diferentes médias condicionais seja uma única normal multivariada.

Na comparação entre grupos, uma formulação condicional com médias específicas por grupo é

$$\mathbf{Y}_i \mid G_i = k \sim N_p(\mu_k, \Sigma),$$

com vetores de médias distintos entre os grupos. A distribuição marginal resultante da mistura desses grupos não precisa pertencer à família normal multivariada, mesmo quando o modelo normal condicional está corretamente especificado.

Um diagnóstico aplicado às respostas agrupadas sem ajustar suas médias condicionais pode refletir diferenças entre grupos ou outros efeitos incluídos no modelo, e não falta de normalidade dos erros. O pressuposto de normalidade deve ser examinado nos resíduos obtidos após o ajuste da média

$$E(\mathcal{Y} \mid \mathbf{Z}) = \mathbf{ZB}.$$

Para $p = 1$, os quatro critérios são funções monotônicas da única raiz

$$\lambda = \frac{H}{E}.$$

Como

$$F = \frac{\nu_E}{\nu_H} \lambda,$$

os quatro critérios produzem a mesma ordenação das amostras em relação à evidência contra H_0 e, quando calibrados em suas respectivas escalas, conduzem ao mesmo teste. Para $p > 1$, H e E são substituídos pelas SQPCs $\mathbf{H}$ e $\mathbf{E}$.

18.7.6 Associação residual, condicionamento e singularidade

Associação residual entre as respostas não invalida, por si só, a MANOVA. A dependência entre as componentes de um mesmo vetor de erros é representada por Σ e, nos dados observados, pelos produtos cruzados reunidos em $\mathbf{E}$. A MANOVA incorpora essa associação na comparação conjunta das respostas.

Relações lineares entre as respostas residuais muito próximas de uma dependência exata podem produzir uma matriz $\mathbf{E}$ mal condicionada, conforme a noção de condicionamento da Definição 6.9. Nesse caso, $\mathbf{E}$ permanece invertível, mas pequenas perturbações nos dados podem produzir alterações relativamente grandes em sua inversa, nas raízes e nas direções características. Invertibilidade, portanto, não garante estabilidade numérica.

Uma relação linear residual exata reduz o posto de $\mathbf{E}$ e pode torná-la singular, conforme a Seção 18.7.4. Se $\mathbf{E}$ é singular, $\mathbf{E}^{-1/2}$ não existe como inversa ordinária e a matriz $\mathbf{M}_{\mathbf{H}\mathbf{E}}$ não está definida pela Equação 18.19.

18.8 Relações com outras técnicas

A ANOVA e o T^2 de Hotelling surgem como casos particulares da formulação da MANOVA. A regressão multivariada utiliza o mesmo modelo linear multivariado e, na comparação entre grupos, o problema espectral relaciona-se à formulação de Fisher da Análise Discriminante.

18.8.1 ANOVA

Quando existe uma única resposta,

$$p = 1,$$

as matrizes de hipótese e erro reduzem-se a escalares,

$$\mathbf{H} = (H), \quad \mathbf{E} = (E),$$

e existe no máximo uma raiz característica,

$$\lambda = \frac{H}{E}.$$

Se ν_H e ν_E são os graus de liberdade da hipótese e do erro, respectivamente, então

$$F = \frac{H/\nu_H}{E/\nu_E} = \frac{\nu_E}{\nu_H} \lambda. \quad (18.27)$$

Para $p = 1$, os quatro critérios são transformações monotônicas da única raiz $\lambda = H/E$. Como

$$F = \frac{\nu_E}{\nu_H} \lambda,$$

esses critérios não acrescentam informação além da razão entre as somas de quadrados da hipótese e do erro. Para $p > 1$, os escalares H e E são substituídos pelas SQPCs $\mathbf{H}$ e $\mathbf{E}$.

18.8.2 T^2 de Hotelling

Na comparação clássica de duas populações,

$$K = 2,$$

há apenas um contraste independente e, portanto,

$$g = 1.$$

Existe no máximo uma raiz característica positiva.

Para duas amostras independentes de tamanhos n_1 e n_2 , com matriz de covariâncias comum e hipótese de igualdade dos vetores de médias, a relação com a estatística definida na Definição 12.5 é

$$\lambda_1 = \frac{T^2}{n_1 + n_2 - 2}. \quad (18.28)$$

Pela Equação 18.28,

$$T^2 = (n_1 + n_2 - 2) \lambda_1.$$

Com dois grupos,

$$g = 1$$

e

$$\text{posto}(\mathbf{H}) \leq 1.$$

Existe, portanto, no máximo uma raiz característica positiva. Quando $\lambda_1 > 0$, os quatro critérios dependem exclusivamente dessa raiz.

18.8.3 Regressão multivariada

MANOVA e regressão multivariada utilizam o mesmo modelo

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E}.$$

Na MANOVA de grupos ou fatores, colunas de $\mathbf{Z}$ representam indicadores, contrastes e outros termos do delineamento. Na regressão multivariada, $\mathbf{Z}$ pode incluir preditores quantitativos contínuos. Em ambas as formulações, hipóteses estimáveis sobre

$$\mathbf{C}_1\mathbf{B}$$

são avaliadas pelas mesmas SQPCs de hipótese e erro.

18.8.4 Análise Discriminante

Na MANOVA de um fator que compara os vetores de médias dos mesmos K grupos utilizados na formulação de Fisher,

$$\mathbf{H} = \mathbf{T}_{\text{entre}} \quad \text{e} \quad \mathbf{E} = \mathbf{T}_{\text{intra}}.$$

Consequentemente, o problema

$$\mathbf{H}\mathbf{a} = \lambda\mathbf{E}\mathbf{a}$$

coincide com

$$\mathbf{T}_{\text{entre}}\alpha = \lambda\mathbf{T}_{\text{intra}}\alpha,$$

definido na Seção 19.6.

Na MANOVA, as raízes características são utilizadas pelo lambda de Wilks, pelo traço de Pillai, pelo traço de Hotelling e pela maior raiz característica de Roy. Na formulação de Fisher, os autovetores associados às raízes positivas definem direções que maximizam a razão entre dispersão entre grupos e dispersão intragrupos.

A coincidência do problema de autovalores generalizados não torna as técnicas equivalentes. Na MANOVA, os grupos são termos do modelo e o objetivo é testar hipóteses sobre os vetores de médias ou sobre funções estimáveis dos parâmetros. Na formulação de Fisher, os rótulos dos grupos são conhecidos e utilizados para construir as matrizes de dispersão entre e dentro dos grupos. A construção de uma regra de classificação requer uma formulação adicional.

18.9 Aprofundamentos teóricos

Leitura de aprofundamento

Sob normalidade e H_0 , as SQPCs de hipótese e erro possuem distribuições Wishart independentes. Essa formulação probabilística fundamenta as distribuições de referência dos critérios. A razão de verossimilhanças conduz à lambda de Wilks, enquanto a invariância e a forma canônica caracterizam o papel das raízes e das direções características.

18.9.1 Distribuições Wishart de hipótese e erro sob H_0

Sob o modelo linear normal multivariado definido na Definição 11.6,

$$\Sigma \succ \mathbf{0},$$

os vetores de erros de unidades distintas são independentes e possuem a mesma matriz de covariâncias Σ .

Para uma hipótese estimável

$$H_0 : \mathbf{C}_1 \mathbf{B} = \Theta_0,$$

com

$$\text{posto}(\mathbf{C}_1) = g,$$

os graus de liberdade residuais, definidos na Definição 11.11, são

$$\nu_E = n - \text{posto}(\mathbf{Z}) .$$

Denote por

$$\mathbf{H}$$

a SQPC aleatória da hipótese e por

$$\mathbf{E}_{\text{res}}$$

a SQPC residual aleatória. Pela Proposição 12.15, aplicada às respostas originais, sob H_0 ,

$$\mathbf{H} \mid \mathbf{Z} \sim W_p(g, \Sigma) , \quad (18.29)$$

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(\nu_E, \Sigma) , \quad (18.30)$$

e

$$\mathbf{H} \perp \mathbf{E}_{\text{res}} \mid \mathbf{Z} . \quad (18.31)$$

A distribuição residual da Equação 18.30 corresponde à Proposição 12.5; a Equação 18.29 especializa a distribuição da SQPC da hipótese para as respostas originais.

Sob H_0 , $\mathbf{H}$ e $\mathbf{E}_{\text{res}}$ são matrizes Wishart independentes com a mesma matriz de escala Σ e graus de liberdade g e ν_E , respectivamente. As distribuições sob H_0 dos critérios clássicos decorrem dessa distribuição conjunta.

Se as matrizes de covariâncias populacionais diferem entre os grupos, $\mathbf{H}$ e $\mathbf{E}_{\text{res}}$ não possuem, em geral, a representação da Equação 18.29, da Equação 18.30 e da Equação 18.31 com uma matriz de escala comum Σ . A calibração clássica dos critérios baseada nessa representação deixa, portanto, de decorrer do modelo normal com covariância comum.

18.9.1.1 Lambda de Wilks e razão de verossimilhanças

Para a hipótese estimável

$$H_0 : \mathbf{C}_1 \mathbf{B} = \Theta_0,$$

denote por $\mathbf{E}_R$ a SQPC residual do ajuste sujeito a H_0 e por $\mathbf{E}$ a SQPC residual do ajuste irrestrito. A SQPC da hipótese corresponde ao aumento da SQPC residual imposto pela restrição, de modo que

$$\mathbf{E}_R = \mathbf{E} + \mathbf{H}.$$

Quando H_0 é obtida pela comparação entre modelos lineares encaixados, essa decomposição coincide com a Proposição 11.13.

No modelo normal multivariado, a maximização da verossimilhança sob o modelo irrestrito e sob H_0 produz

$$\Lambda_{RV} = \left[\frac{|\mathbf{E}|}{|\mathbf{E} + \mathbf{H}|} \right]^{n/2} = \Lambda_W^{n/2}. \quad (18.32)$$

Assim, rejeitar H_0 para valores pequenos da razão de verossimilhanças equivale a rejeitá-la para valores pequenos da lambda de Wilks (Anderson, 2003; Johnson; Wichern, 2002).

A Equação 18.22 reúne as duas formas da mesma estatística. A razão $|\mathbf{E}|/|\mathbf{E} + \mathbf{H}|$ compara as SQPCs residuais dos modelos completo e reduzido, enquanto o produto $\prod_{j=1}^p (1 + \lambda_j)^{-1}$ expressa a lambda de Wilks em função das raízes características (Wilks, 1932).

Sob o modelo normal, o traço de Pillai, o traço de Hotelling e a maior raiz característica de Roy também são funções do par aleatório $(\mathbf{H}, \mathbf{E}_{\text{res}})$. Esses três critérios não correspondem, em geral, ao critério da razão de verossimilhanças para a hipótese linear.

As matrizes observadas $\mathbf{H}$ e $\mathbf{E}$, suas raízes características e os quatro critérios são definidos algebricamente. Sob o modelo normal, a distribuição conjunta de $\mathbf{H}$ e $\mathbf{E}_{\text{res}}$ determina as distribuições de referência dos critérios sob H_0 .

18.9.2 Calibração inferencial dos critérios

Pela Equação 18.29, pela Equação 18.30 e pela Equação 18.31, as distribuições de referência dos critérios sob H_0 são determinadas por

$$p, \quad g \quad \text{e} \quad \nu_E,$$

em que p é o número de respostas, $g = \text{posto}(\mathbf{C}_1)$ e ν_E é o número de graus de liberdade residuais.

Algumas configurações admitem distribuições F exatas. Se existe uma única resposta,

$$p = 1,$$

então há no máximo uma raiz positiva e, sob H_0 ,

$$\frac{\nu_E}{g} \lambda_1 \sim F_{g, \nu_E}. \quad (18.33)$$

Se a hipótese possui um grau de liberdade,

$$g = 1,$$

e $\nu_E \geq p$, então

$$\frac{\nu_E - p + 1}{p} \lambda_1 \sim F_{p, \nu_E - p + 1}. \quad (18.34)$$

Nessas duas situações, os quatro critérios são funções monotônicas da única raiz e conduzem ao mesmo teste global.

Para $p > 1$ e $g > 1$, a distribuição da lambda de Wilks não se reduz, em geral, às distribuições F exatas anteriores. Mantendo p e g fixos, uma aproximação assintótica de Bartlett, quando ν_E cresce, é

$$-\left(\nu_E - \frac{p - g + 1}{2}\right) \log \Lambda_W \sim \chi_{pg}^2. \quad (18.35)$$

A aproximação é utilizada sob H_0 (Anderson, 2003; Johnson; Wichern, 2002). O traço de Pillai, o traço de Hotelling e a maior raiz característica de Roy possuem calibrações próprias, determinadas pelas respectivas distribuições de referência.

Quando uma amostra apresenta $r_H \leq 1$, os valores observados dos quatro critérios dependem de, no máximo, uma raiz positiva. Se $\lambda_1 > 0$,

$$\Lambda_W = \frac{1}{1 + \lambda_1}, \quad V = \frac{\lambda_1}{1 + \lambda_1}, \quad U = \lambda_1,$$

e a maior raiz característica de Roy é λ_1 .

Se $p = 1$ ou $g = 1$, a Equação 18.15 garante $r_H \leq 1$ para qualquer amostra. Nessas duas configurações, os quatro critérios são funções estritamente monotônicas da mesma raiz e conduzem a regiões de rejeição equivalentes quando cada critério é calibrado em sua escala correspondente.

Uma redução adicional de posto que produza $r_H \leq 1$ apenas na amostra observada estabelece as identidades algébricas acima para essa amostra, mas não implica, por si só, equivalência entre as distribuições de referência dos quatro critérios.

Quando existem duas ou mais raízes positivas, as distribuições de referência dos quatro critérios não são obtidas pela mesma transformação. As estatísticas transformadas e seus graus de liberdade dependem do critério, de p , de g e de ν_E (Anderson, 2003).

As distribuições de referência anteriores pressupõem normalidade multivariada dos erros, independência entre unidades, matriz de covariâncias residual comum e $\mathbf{E} \succ \mathbf{0}$. A violação dessas condições retira a justificativa, pelo modelo clássico, dos valores críticos e valores p obtidos com essas distribuições ou aproximações. Se $\mathbf{E}$ é singular, também deixam de estar definidas as formulações dos critérios que exigem sua inversa ou seu determinante não nulo.

18.9.3 Invariância a transformações lineares não singulares das respostas

Considere uma transformação linear não singular das respostas,

$$\mathbf{y}^* = \mathbf{y}\mathbf{A}, \tag{18.36}$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times p}, \quad \det(\mathbf{A}) \neq 0.$$

No sistema transformado,

$$\mathbf{B}^* = \mathbf{B}\mathbf{A}, \quad \mathcal{E}^* = \mathcal{E}\mathbf{A}.$$

Para representar a mesma hipótese, utiliza-se

$$\Theta_0^* = \Theta_0 \mathbf{A}.$$

As matrizes de hipótese e erro transformam-se por congruência:

$$\mathbf{H}^* = \mathbf{A}^\top \mathbf{H} \mathbf{A} \quad (18.37)$$

e

$$\mathbf{E}^* = \mathbf{A}^\top \mathbf{E} \mathbf{A}. \quad (18.38)$$

Proposição 18.1 (Invariância das raízes características). *Se $\mathbf{A}$ é não singular, os pares*

$$(\mathbf{H}, \mathbf{E})$$

e

$$(\mathbf{H}^*, \mathbf{E}^*)$$

possuem as mesmas raízes características, incluindo suas multiplicidades.

Demonstração

Tem-se

$$\begin{aligned} \det(\mathbf{H}^* - \lambda \mathbf{E}^*) &= \det[\mathbf{A}^\top (\mathbf{H} - \lambda \mathbf{E}) \mathbf{A}] \\ &= \det(\mathbf{A})^2 \det(\mathbf{H} - \lambda \mathbf{E}). \end{aligned}$$

Como

$$\det(\mathbf{A}) \neq 0,$$

as duas equações características possuem os mesmos zeros, com as mesmas multiplicidades.

Para o par observado $(\mathbf{H}, \mathbf{E})$, a decomposição espectral da matriz padronizada $\mathbf{E}^{-1/2} \mathbf{H} \mathbf{E}^{-1/2}$ determina uma forma canônica. Se

$$\mathbf{E}^{-1/2} \mathbf{H} \mathbf{E}^{-1/2} = \mathbf{Q} \operatorname{diag}(\lambda_1, \dots, \lambda_p) \mathbf{Q}^\top,$$

com $\mathbf{Q}$ ortogonal, então a transformação das respostas definida por

$$\mathbf{A} = \mathbf{E}^{-1/2} \mathbf{Q}$$

produz

$$\mathbf{E}^* = \mathbf{I}_p$$

e

$$\mathbf{H}^* = \text{diag}(\lambda_1, \dots, \lambda_p).$$

Assim, para o par observado $(\mathbf{H}, \mathbf{E})$, a transformação definida por $\mathbf{A} = \mathbf{E}^{-1/2} \mathbf{Q}$ reduz a SQPC residual à identidade e a SQPC da hipótese à matriz diagonal das raízes características (Anderson, 2003).

Consequentemente, a lambda de Wilks, o traço de Pillai, o traço de Hotelling e a maior raiz característica de Roy são invariantes a transformações lineares não singulares das respostas.

Se α_j é uma direção característica normalizada no sistema original, a direção correspondente no sistema transformado é

$$\alpha_j^* = \mathbf{A}^{-1} \alpha_j.$$

Essa transformação preserva a normalização,

$$(\alpha_j^*)^\top \mathbf{E}^* \alpha_j^* = \alpha_j^\top \mathbf{E} \alpha_j,$$

e a combinação linear das respostas,

$$\mathbf{y}^* \alpha_j^* = \mathbf{y} \alpha_j.$$

As raízes e os quatro critérios não dependem da escolha de um sistema invertível de coordenadas para as respostas. Os coeficientes das direções características, entretanto, são expressos nas coordenadas do sistema utilizado.

18.9.4 Posto, sinais e multiplicidades das direções

O número de raízes positivas é

$$r_H = \text{posto}(\mathbf{H}) \leq \min(p, g),$$

pela Equação 18.15.

O número de raízes positivas não é determinado apenas pelo número p de respostas. Como $r_H \leq g$, uma hipótese com poucas restrições lineares independentes pode produzir poucas raízes positivas mesmo quando p é elevado.

Como $\mathbf{H}$ é simétrica e $\mathbf{E} \succ \mathbf{0}$, aplica-se ao par $(\mathbf{H}, \mathbf{E})$ a ortogonalidade dos autovetores generalizados estabelecida na Proposição 5.7. As direções características podem ser escolhidas ortonormais no produto interno induzido por $\mathbf{E}$.

Para uma raiz simples, qualquer múltiplo escalar não nulo de um autovetor generalizado representa a mesma direção característica. Com a normalização

$$\alpha_j^\top \mathbf{E} \alpha_j = 1,$$

restam duas representações normalizadas da mesma direção:

$$\alpha_j \quad \text{e} \quad -\alpha_j.$$

Quando uma raiz λ possui multiplicidade $m > 1$, seja

$$\mathbf{A}_\lambda = [\alpha_1 \quad \cdots \quad \alpha_m]$$

uma matriz cujas colunas formam uma base $\mathbf{E}$ -ortonormal do subespaço característico correspondente, de modo que

$$\mathbf{A}_\lambda^\top \mathbf{E} \mathbf{A}_\lambda = \mathbf{I}_m.$$

Para qualquer matriz ortogonal

$$\mathbf{R} \in \mathbb{R}^{m \times m},$$

a matriz

$$\mathbf{A}_\lambda^* = \mathbf{A}_\lambda \mathbf{R}$$

fornece outra base **E**-ortonormal do mesmo subespaço. Portanto, uma raiz de multiplicidade $m > 1$ determina o subespaço característico, mas não uma base **E**-ortonormal única dentro dele.

A escolha de outra base **E**-ortonormal para esse subespaço não altera a λ de Wilks, o traço de Pillai, o traço de Hotelling ou a maior raiz característica de Roy, pois os quatro critérios dependem apenas das raízes características.

18.10 Aprofundamentos metodológicos e aplicados

Leitura de aprofundamento

Esta parte trata das decisões de condução, interpretação e avaliação da MANOVA: tamanho das células, homogeneidade das matrizes de covariâncias, escolha do critério multivariado, análise posterior ao teste global, MANOVA fatorial, MANCOVA e validação dos resultados.

18.10.1 Tamanho das células e balanceamento

Na MANOVA com fatores categóricos, o tamanho amostral deve ser examinado em cada célula do delineamento. Células menores produzem estimativas menos precisas das médias e das covariâncias e reduzem o poder para detectar diferenças entre os vetores de médias (Hair et al., 2009).

Uma matriz de covariâncias amostral calculada separadamente na célula k pode ter posto completo somente se

$$n_k - 1 \geq p,$$

além da ausência de dependências lineares exatas entre as respostas. Essa condição é necessária para procedimentos que utilizam as matrizes de covariâncias de cada grupo separadamente, como o teste M de Box. A MANOVA baseada na SQPC residual conjunta exige $\mathbf{E} \succ \mathbf{0}$, conforme a Seção 18.7.4, mas não exige posto completo de cada matriz de covariâncias amostral de grupo.

Tamanhos desiguais entre células são admitidos pelo modelo linear. Quando as matrizes de covariâncias populacionais diferem entre os grupos, células com tamanhos muito distintos aumentam a sensibilidade dos testes multivariados à violação da hipótese de covariância comum (Hair et al., 2009).

Células com tamanhos semelhantes reduzem a sensibilidade dos testes à heterogeneidade das matrizes de covariâncias.

18.10.2 Avaliação da homogeneidade das matrizes de covariâncias

Na comparação entre K grupos, a MANOVA clássica assume

$$\Sigma_1 = \Sigma_2 = \dots = \Sigma_K.$$

O teste M de Box avalia

$$H_0 : \Sigma_1 = \dots = \Sigma_K.$$

Sua estatística utiliza os determinantes das matrizes de covariâncias amostrais dos grupos e da matriz de covariâncias combinada. O cálculo exige matrizes amostrais não singulares. A rejeição de H_0 fornece evidência contra a hipótese de covariância comum; a não rejeição não demonstra igualdade das matrizes populacionais.

O teste M de Box é sensível a desvios da normalidade multivariada. Hair recomenda, por essa razão, níveis de significância como 0,01 ou menores (Hair et al., 2009). A rejeição do teste deve ser interpretada juntamente com a avaliação da normalidade, pois desvios da normalidade podem aumentar a frequência de rejeição da hipótese de covariância comum.

Em modelos com covariáveis, a hipótese de homogeneidade refere-se às matrizes de covariâncias dos erros condicionais ao modelo ajustado. O teste calculado com as respostas brutas agrupadas pelos fatores compara matrizes não ajustadas e não testa diretamente a igualdade das covariâncias residuais da MANCOVA.

18.10.3 Observações atípicas e influência

Uma observação atípica apresenta valores incomuns em uma ou mais respostas ou em uma combinação dessas respostas. Como as médias podem variar entre os níveis do delineamento, a avaliação deve considerar os resíduos do modelo,

$$\hat{e}_i = y_i - \hat{\mu}_i,$$

em que $\hat{\mu}_i$ é o vetor de médias ajustadas para a unidade i . Valores residuais extremos em uma resposta ou combinações residuais incomuns entre várias respostas identificam unidades que devem ser examinadas (Hair et al., 2009; Johnson; Wichern, 2002).

Uma observação é influente quando sua presença altera de forma apreciável os vetores de médias ajustadas, $\mathbf{H}$, $\mathbf{E}$, as raízes características ou os critérios multivariados. A comparação da análise com e sem a observação quantifica essa influência, mas não justifica sua exclusão.

A exclusão requer evidência independente de erro de registro, erro de mensuração ou inadequação da unidade à população definida para o estudo. Uma observação extrema e válida deve ser mantida quando pertence à população analisada (Hair et al., 2009).

18.10.4 Escolha e interpretação do critério multivariado

Os quatro critérios são funções das mesmas raízes características. A escolha do critério deve considerar os tamanhos das células, a plausibilidade dos pressupostos e o número de raízes que caracterizam o efeito, e não o menor valor p observado.

Quando os tamanhos das células são semelhantes e os pressupostos de normalidade e covariância comum são plausíveis, Hair recomenda o traço de Pillai ou a lambda de Wilks (Hair et al., 2009). Quando há células com tamanhos distintos ou evidência contra a hipótese de covariância comum, Hair recomenda o traço de Pillai por sua maior robustez nessas condições (Hair et al., 2009). Johnson e Wichern também relatam maior robustez de Pillai diante de desvios da normalidade (Johnson; Wichern, 2002).

A maior raiz característica de Roy utiliza apenas λ_1 e é indicada por Hair quando uma única dimensão domina o efeito e os pressupostos do modelo são plausíveis (Hair et al., 2009). O traço de Hotelling, o traço de Pillai e a lambda de Wilks incorporam todas as raízes positivas.

Resultados diferentes entre os quatro critérios decorrem das funções distintas aplicadas às mesmas raízes e não constituem evidências independentes. O relatório deve identificar o critério utilizado, seu valor observado, a estatística F quando houver transformação correspondente, os graus de liberdade e o valor p .

18.10.5 Avaliação das respostas após o teste global

A rejeição da hipótese multivariada fornece evidência de que a hipótese testada não se sustenta para o vetor de respostas. Essa rejeição não identifica quais respostas apresentam efeitos marginais. Os testes univariados podem ser utilizados para examinar separadamente cada componente do vetor resposta (Hair et al., 2009).

Para a resposta j , os elementos diagonais

$$H_{jj} \quad \text{e} \quad E_{jj}$$

são as somas de quadrados da hipótese e do erro correspondentes a essa resposta. A estatística univariada é

$$F_j = \frac{H_{jj}/\nu_H}{E_{jj}/\nu_E}. \quad (18.39)$$

Sob o modelo normal clássico e sob a hipótese nula marginal,

$$F_j \sim F_{\nu_H, \nu_E}.$$

O teste baseado em F_j utiliza somente H_{jj} e E_{jj} . Os critérios multivariados utilizam as matrizes completas $\mathbf{H}$ e $\mathbf{E}$ e, portanto, incorporam também os produtos cruzados entre as respostas. Um teste univariado não constitui uma decomposição do teste MANOVA.

Quando as p respostas são examinadas separadamente, as hipóteses marginais formam uma família de testes. A rejeição prévia da hipótese multivariada não controla a probabilidade de pelo menos uma rejeição incorreta nessa família. O ajuste de Bonferroni controla o erro familiar em nível α utilizando

$$\frac{\alpha}{p}$$

como nível de significância para cada uma das p hipóteses marginais. Outros procedimentos de multiplicidade podem ser utilizados de acordo com a família de hipóteses que será interpretada.

A rejeição da hipótese multivariada não exige que todas as hipóteses marginais sejam rejeitadas. A diferença entre grupos pode estar concentrada em algumas respostas ou em uma combinação linear das respostas (Hair et al., 2009; Johnson; Wichern, 2002).

Intervalos de confiança simultâneos podem ser construídos para componentes ou contrastes previamente especificados dos vetores de médias. Esses intervalos quantificam as diferenças estimadas e controlam conjuntamente o nível de confiança da família de afirmações considerada (Johnson; Wichern, 2002).

18.10.6 Contrastes e comparações posteriores

A rejeição da hipótese multivariada não identifica quais níveis do fator diferem. Quando o fator possui três ou mais níveis, contrastes e comparações posteriores podem localizar essas diferenças.

Um contraste planejado entre K médias de grupos pode ser escrito como

$$L = c_1\mu_1 + \cdots + c_K\mu_K,$$

com

$$\sum_{k=1}^K c_k = 0.$$

Os coeficientes $c_1, \dots, c_K$ definem a comparação entre os grupos. No modelo linear multivariado, contrastes estimáveis são incorporados à matriz $\mathbf{C}_1$ da hipótese linear definida na Definição 11.15.

Contrastes planejados devem ser especificados a partir da pergunta de pesquisa antes da inspeção das diferenças amostrais. Como o número de comparações planejadas costuma ser menor, eles podem apresentar maior poder para as comparações previamente definidas (Hair et al., 2009).

Quando as comparações são escolhidas depois do exame das médias, elas pertencem a uma análise *post hoc*. O procedimento de multiplicidade deve considerar o conjunto de comparações efetivamente realizado. A realização de várias comparações sem ajuste aumenta a probabilidade de pelo menos uma rejeição incorreta (Hair et al., 2009).

Testes por resposta e contrastes entre níveis avaliam hipóteses diferentes. O teste baseado em F_j examina o efeito sobre uma resposta específica, enquanto um contraste compara níveis ou combinações de níveis do fator.

Em uma análise *stepdown*, cada resposta é testada condicionalmente às respostas que a precedem. A ordem das respostas altera as hipóteses condicionais avaliadas e deve ser definida antes da análise com base no problema de pesquisa (Hair et al., 2009).

Na MANOVA de um fator, as direções associadas às raízes características definem combinações lineares das respostas ordenadas pela razão entre a dispersão entre grupos e a dispersão intragrupos. A relação entre essas direções e as funções discriminantes de Fisher é estabelecida na Seção 18.8.4.

18.10.7 MANOVA fatorial e MANCOVA

No modelo linear multivariado, fatores, interações e covariáveis determinam os termos da matriz de delineamento $\mathbf{Z}$. Cada hipótese linear estimável determina sua SQPC $\mathbf{H}$, enquanto a SQPC residual $\mathbf{E}$ é obtida do modelo ajustado.

18.10.7.1 MANOVA fatorial

Em um delineamento com dois ou mais fatores, efeitos principais e interações são avaliados por hipóteses lineares sobre os coeficientes do modelo. Para cada hipótese estimável constrói-se uma SQPC $\mathbf{H}$, enquanto a SQPC residual $\mathbf{E}$ é obtida do modelo ajustado.

Em delineamentos ortogonais, como ocorre nos delineamentos fatoriais balanceados usuais, as decomposições associadas aos diferentes efeitos apresentam uma separação direta. Em delineamentos não ortogonais, como pode ocorrer com tamanhos de células desiguais ou com a inclusão de covariáveis, a expressão **efeito de um fator** deve ser acompanhada da hipótese

estimável utilizada. Diferentes formas de atribuir a variação aos termos do modelo podem produzir SQPCs de hipótese distintas. A formulação geral

$$H_0 : \mathbf{C}_1 \mathbf{B} = \Theta_0$$

permite explicitar qual comparação está sendo realizada.

A interação deve ser examinada antes da interpretação dos efeitos principais. Quando existe interação, a diferença associada a um fator depende do nível do outro fator. O efeito principal resume diferenças marginais e pode ocultar o padrão observado nas combinações específicas de níveis (Hair et al., 2009; Johnson; Wichern, 2002).

Na inspeção de uma resposta específica, Hair distingue interações ordinais e desordinais. Em uma interação ordinal, a ordenação das médias entre os níveis de um fator permanece a mesma nos níveis do outro fator, embora as diferenças possam mudar de magnitude. Em uma interação desordinal, essa ordenação se inverte em pelo menos parte dos níveis examinados (Hair et al., 2009). Essa classificação descreve o perfil da resposta considerada e não substitui o teste multivariado da interação.

A rejeição da hipótese de ausência de interação não identifica quais combinações de níveis diferem. As médias das células, os efeitos simples e os contrastes entre combinações de níveis podem ser utilizados para localizar essas diferenças.

18.10.7.2 MANCOVA

Na MANCOVA, covariáveis quantitativas são incluídas na matriz de delineamento $\mathbf{Z}$. As hipóteses sobre os fatores comparam vetores de médias das respostas condicionais aos valores das covariáveis.

Para uma covariável escalar c e um fator com K níveis, o modelo aditivo pode ser escrito como

$$E(\mathbf{Y} \mid \mathbf{G} = k, c) = \mu_k + \gamma c, \quad k = 1, \dots, K,$$

em que $\gamma \in \mathbb{R}^p$ contém os coeficientes associados à covariável. A mesma inclinação γ em todos os grupos expressa a **homogeneidade dos coeficientes de regressão** exigida pelo modelo aditivo de MANCOVA (Hair et al., 2009).

Se os coeficientes associados à covariável diferem entre os grupos, o modelo pode ser escrito com coeficientes específicos,

$$E(\mathbf{Y} \mid \mathbf{G} = k, c) = \mu_k + \gamma_k c.$$

A diferença entre os grupos k e ℓ nesse caso é

$$(\mu_k - \mu_\ell) + (\gamma_k - \gamma_\ell) c.$$

Portanto, quando

$$\gamma_k \neq \gamma_\ell,$$

a diferença entre os vetores de médias depende do valor da covariável. No modelo linear, essa situação corresponde a uma interação fator–covariável.

Uma covariável associada às respostas pode reduzir a SQPC residual depois do ajuste e aumentar a precisão das comparações entre os níveis dos fatores. Hair recomenda selecionar covariáveis relacionadas às respostas e evitar covariáveis fortemente associadas aos fatores quando o objetivo é aumentar a precisão dos testes dos efeitos de grupo (Hair et al., 2009).

A associação entre a covariável e o fator não viola, por si só, o modelo linear. A MANOVA sem covariáveis compara os vetores de médias definidos pelo modelo sem ajuste para a covariável, enquanto a MANCOVA compara vetores de médias condicionais aos valores da covariável. Diferenças entre esses dois resultados decorrem das hipóteses distintas formuladas pelos dois modelos.

18.10.8 Validação dos resultados

A repetição do estudo sob o mesmo delineamento constitui a principal forma de avaliar a reprodução dos resultados de uma MANOVA (Hair et al., 2009). Em uma nova amostra da mesma população-alvo, devem ser comparadas as estimativas das diferenças entre os vetores de médias e as decisões obtidas para as mesmas hipóteses multivariadas.

Diferenças entre as duas análises devem ser examinadas considerando os tamanhos amostrais, os tamanhos das células, as matrizes de covariâncias e as estimativas dos efeitos.

Em estudos observacionais, a reprodução de uma associação em diferentes amostras não substitui a designação aleatória dos tratamentos. Quando os grupos são definidos por características observadas, a MANOVA compara os vetores de médias condicionais a esses grupos. Sem um delineamento ou uma estratégia de identificação causal que sustente essa interpretação, diferenças entre os vetores de médias não devem ser interpretadas como efeitos causais (Hair et al., 2009).

A repetição da análise em outra amostra da mesma população-alvo avalia a reprodução dos resultados nessa população. A generalização para outras populações exige suporte do delineamento amostral e das condições sob as quais as amostras foram obtidas.

18.10.9 Correspondência com a implementação utilizada

A implementação utilizada é a análise MANCOVA do núcleo do [jamovi](#) (The jamovi project, 2026). A Tabela 18.4 relaciona as opções e saídas da interface aos objetos estatísticos da MANOVA.

Tabela 18.4: Correspondência entre elementos da implementação e os objetos estatísticos desenvolvidos no capítulo.

Elemento da implementação	Correspondência estatística	Desenvolvimento no capítulo
Dependent Variables	colunas da matriz de respostas $\mathcal{Y}$	Definição 11.3
Factors	fatores categóricos que determinam termos da matriz de delineamento $\mathbf{Z}$	Definição 11.3 e Seção 18.10.7
Covariates	covariáveis quantitativas incluídas como termos de $\mathbf{Z}$	Seção 18.10.7
Pillai's Trace	traço de Pillai	Seção 18.5
Wilks' Lambda	lambda de Wilks	Seção 18.5
Hotelling's Trace	traço de Hotelling	Seção 18.5
Roy's Largest Root	maior raiz característica de Roy	Seção 18.5
Univariate Tests	testes univariados sequenciais de cada resposta para os mesmos termos do modelo; a multiplicidade entre respostas deve ser tratada separadamente	Equação 18.39 e Seção 18.10.5
Box's M	teste de igualdade das matrizes de covariâncias dos grupos formados pelos fatores	Seção 18.10.2
Multivariate Shapiro–Wilk	teste de normalidade multivariada calculado pela implementação com os vetores de respostas observados; não utiliza os resíduos do modelo	Seção 18.7.5

Elemento da implementação	Correspondência estatística	Desenvolvimento no capítulo
Q-Q plot	comparação das distâncias de Mahalanobis calculadas com os vetores de respostas observados com quantis qui-quadrado; não utiliza os resíduos do modelo	Seção 18.7.5
Missing values	exclusão das unidades com valor ausente em alguma variável utilizada no modelo	convenção da implementação; tratamento estatístico de dados ausentes não desenvolvido no capítulo

Quando há dois ou mais fatores, a implementação inclui seus efeitos principais e as interações entre fatores. As covariáveis entram como termos aditivos e não geram automaticamente interações fator-covariável. O modelo ajustado pela interface impõe, portanto, coeficientes comuns para cada covariável nos diferentes níveis dos fatores, conforme a condição descrita na Seção [18.10.7](#).

Na versão auditada, o MANCOVA do `jmv` ajusta o modelo por `stats::manova()` e utiliza as SQPCs associadas sequencialmente aos termos do modelo. Assim, os testes multivariados e univariados apresentados para cada termo correspondem a testes sequenciais, também denominados testes com SQPC tipo I. Cada termo é avaliado pela variação adicional atribuída a ele depois dos termos que o precedem.

Em delineamentos ortogonais, essa dependência da ordem não afeta as comparações correspondentes. Em delineamentos não ortogonais, especialmente com células desiguais ou covariáveis, a SQPC atribuída a um termo pode depender dos termos que o precedem. Portanto, nesses casos, a linha apresentada pela interface deve ser interpretada como a hipótese sequencial efetivamente calculada, e não como uma definição independente da ordem para o efeito correspondente.

A denominação **Hotelling's Trace** corresponde ao traço de Hotelling-Lawley, denominado traço de Hotelling neste capítulo. Para cada termo do modelo, os quatro critérios utilizam a mesma SQPC da hipótese e a mesma SQPC residual. As diferenças entre os critérios decorrem das funções aplicadas às raízes características.

A implementação apresenta também a estatística F , os graus de liberdade e o valor p fornecidos por `summary.manova()`. Essas estatísticas F resultam das transformações ou aproximações associadas a cada critério. Quando a hipótese possui um grau de liberdade, os quatro valores F coincidem. Para a maior raiz característica de Roy, quando a hipótese possui mais de um grau de liberdade, a estatística F apresentada pela implementação constitui um limite superior na formulação utilizada por `summary.manova()`.

Os testes univariados correspondem aos testes da Seção 18.10.5. Para cada termo do modelo, cada resposta é examinada separadamente por uma estatística baseada em H_{jj} e E_{jj} . Esses testes não utilizam os produtos cruzados entre respostas e não reproduzem o teste multivariado.

Quando várias respostas são examinadas, os valores p univariados devem ser interpretados como uma família de testes. A rejeição prévia da hipótese multivariada não controla automaticamente o erro Tipo I dessa família; o procedimento de multiplicidade deve ser definido de acordo com as hipóteses marginais que serão interpretadas.

O teste M de Box utiliza as combinações dos níveis dos fatores para formar os grupos e compara as matrizes de covariâncias das respostas observadas. Em uma MANCOVA, as covariáveis não entram nesse cálculo; portanto, o teste não avalia diretamente a igualdade das matrizes de covariâncias residuais após o ajuste das covariáveis exigida pelo modelo.

A hipótese de normalidade da MANOVA refere-se aos vetores de erros condicionais à matriz de delineamento,

$$\varepsilon_i = y_i - E(\mathbf{Y}_i | \mathbf{Z}).$$

O teste multivariado de Shapiro–Wilk e o gráfico Q–Q da implementação auditada são calculados com os vetores de respostas observados y_i , e não com os resíduos do modelo ajustado.

Quando os vetores de médias diferem entre os níveis dos fatores, as respostas reunidas não precisam seguir uma única distribuição normal multivariada, mesmo que os erros condicionais sejam normais. Na MANCOVA, a média condicional também varia com os valores das covariáveis. Portanto, a distribuição das respostas não ajustadas não coincide, em geral, com a distribuição dos erros do modelo.

O teste multivariado de Shapiro–Wilk e o gráfico Q–Q da interface não testam diretamente a hipótese de normalidade formulada na Seção 18.7.5. A avaliação dessa hipótese deve utilizar os resíduos do modelo ajustado.

Na MANOVA de um fator, os resíduos são os desvios das observações em relação ao vetor de médias do respectivo grupo. Em modelos fatoriais ou com covariáveis, os resíduos são obtidos após o ajuste de todos os termos incluídos no modelo.

A exclusão das unidades com valores ausentes reduz a amostra analisada e pode alterar os tamanhos das células e os graus de liberdade residuais. A análise das observações completas não modela o mecanismo de ausência. Johnson e Wichern (Johnson; Wichern, 2002) destacam que, quando a ocorrência de valores ausentes está relacionada aos níveis das respostas, procedimentos que ignoram essa estrutura podem introduzir viés. O tratamento estatístico de dados ausentes não é desenvolvido neste capítulo.

A interface não fornece os contrastes planejados e as comparações posteriores discutidos na Seção 18.10.6. Quando essas análises são necessárias, elas devem ser realizadas por procedimentos adicionais após o teste multivariado global.

18.11 Síntese

A MANOVA formula hipóteses sobre um vetor de respostas no modelo linear multivariado

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E}.$$

Para uma hipótese estimável

$$H_0 : \mathbf{C}_1 \mathbf{B} = \Theta_0,$$

a SQPC da hipótese $\mathbf{H}$ quantifica a variação associada à hipótese testada, enquanto a SQPC residual $\mathbf{E}$ quantifica a variação não explicada pelo modelo.

Quando

$$\mathbf{E} \succ \mathbf{0},$$

a comparação entre hipótese e erro conduz ao problema

$$\mathbf{H}\mathbf{a} = \lambda\mathbf{E}\mathbf{a}.$$

As raízes características

$$\lambda_1 \geq \cdots \geq \lambda_p \geq 0$$

são os autovalores generalizados do par $(\mathbf{H}, \mathbf{E})$. O número de raízes positivas é

$$r_H = \text{posto}(\mathbf{H}) \leq \min(p, g),$$

em que $g = \text{posto}(\mathbf{C}_1)$.

Os quatro critérios clássicos são funções dessas raízes:

$$\Lambda_W = \prod_{j=1}^p \frac{1}{1 + \lambda_j}, \quad V = \sum_{j=1}^p \frac{\lambda_j}{1 + \lambda_j},$$

$$U = \sum_{j=1}^p \lambda_j, \quad \text{maior raiz característica de Roy} = \lambda_1.$$

A lambda de Wilks diminui à medida que aumenta a evidência contra H_0 ; o traço de Pillai, o traço de Hotelling e a maior raiz característica de Roy aumentam. A calibração inferencial clássica pressupõe independência entre unidades, normalidade multivariada dos erros, matriz de covariâncias residual comum e as condições de posto necessárias às operações matriciais utilizadas.

Para $p = 1$, o problema reduz-se à ANOVA. Com dois grupos, há no máximo uma raiz positiva e

$$\lambda_1 = \frac{T^2}{n_1 + n_2 - 2}.$$

A regressão multivariada utiliza o mesmo modelo linear multivariado, com hipóteses distintas sobre $\mathbf{B}$. Na MANOVA de um fator, $\mathbf{H}$ e $\mathbf{E}$ coincidem, respectivamente, com as matrizes de dispersão entre e dentro dos grupos utilizadas na formulação de Fisher.

A Análise Discriminante parte de grupos conhecidos e muda o objetivo da análise: em vez de testar hipóteses sobre vetores de médias, utiliza a separação entre e dentro dos grupos para construir direções discriminantes e, sob modelos probabilísticos específicos, regras de classificação.

19 Formulação da Análise Discriminante

A Análise Discriminante utiliza grupos previamente conhecidos para resolver dois problemas relacionados: representar a separação entre os grupos e construir regras para classificar novas observações (Johnson; Wichern, 2002).

O capítulo desenvolve duas formulações. Na formulação probabilística, as classes são descritas por distribuições condicionais e a classificação é tratada como um problema de decisão envolvendo probabilidades *a priori*, perdas e probabilidades *a posteriori*. Na formulação geométrica de Fisher, procuram-se combinações lineares que maximizem a separação entre grupos relativamente à dispersão intragrupos.

As duas formulações possuem objetivos distintos. A primeira produz regras de classificação; a segunda constrói direções que representam a separação entre grupos conhecidos. Sob condições específicas, suas soluções podem estar relacionadas.

Parâmetros populacionais, estatísticas amostrais e regras estimadas são objetos distintos. As formulações consideradas são as versões clássicas, sem regularização ou seleção automática de variáveis.

A Tabela 19.1 resume as formulações utilizadas.

Tabela 19.1: Formulações complementares da Análise Discriminante.

Formulação	Objeto de partida	Problema	Resultado
decisão estatística	densidades condicionais, probabilidades <i>a priori</i> e perdas	escolher uma ação para uma nova observação	regra de Bayes
normal com covariância comum	μ_k, Σ e π_k	minimizar risco sob perda zero-um	regra de classificação linear (LDA)
normal com covariâncias específicas por classe	μ_k, Σ_k e π_k	minimizar risco sob perda zero-um	regra de classificação quadrática (QDA)
geométrica de Fisher	dispersões intragrupos e entre grupos	maximizar separação relativa	direções e coordenadas discriminantes

19.1 O problema de discriminação e classificação

Considere uma variável aleatória de classe

$$C \in \{1, \dots, K\}, \quad K \geq 2.$$

A variável C é categórica. Os valores $1, \dots, K$ funcionam como rótulos das classes e não como medidas quantitativas. Sua ordem ou suas diferenças numéricas não participam da definição da Análise Discriminante.

Considere também um vetor aleatório de características quantitativas

$$\mathbf{x} = \begin{pmatrix} x_1 \\ \vdots \\ x_p \end{pmatrix} \in \mathbb{R}^p.$$

Para cada classe

$$k \in \{1, \dots, K\},$$

existe uma distribuição condicional de

$$\mathbf{x} \mid C = k.$$

Uma realização

$$\mathbf{x} \in \mathbb{R}^p$$

representa os valores observados das características de uma unidade.

Durante a construção da técnica, os rótulos das unidades utilizadas para caracterizar os grupos são conhecidos. A Análise Discriminante é, portanto, uma técnica supervisionada.

Na **discriminação**, procura-se construir funções ou direções que representem a separação entre os grupos. Na **classificação**, procura-se uma regra

$$\psi : \mathbb{R}^p \longrightarrow \{1, \dots, K\}$$

que associe uma nova observação $\mathbf{x}$ a uma das classes.

Taxas de erro, matrizes de classificação e validação cruzada avaliam a qualidade preditiva de uma regra estimada. Esses procedimentos pertencem à avaliação da regra, e não à sua definição, conforme detalhado na Seção [19.15](#).

19.2 Classificação como problema de decisão

A classificação pode ser formulada como um problema de decisão. Para uma observação

$$\mathbf{x} \in \mathbb{R}^p,$$

deve-se escolher uma ação

$$a \in \mathcal{A}, \quad \mathcal{A} = \{1, \dots, K\}.$$

A ação a significa atribuir a observação à classe a . A decisão depende das probabilidades *a priori*, das distribuições condicionais das características e das perdas associadas às possíveis classificações.

19.2.1 Probabilidades *a priori* e *a posteriori*

Definição 19.1 (Probabilidades *a priori* das classes). Seja

$$C \in \{1, \dots, K\}$$

uma variável aleatória de classe.

As probabilidades *a priori* são

$$\pi_k = P(C = k), \quad k = 1, \dots, K,$$

com

$$\pi_k > 0$$

e

$$\sum_{k=1}^K \pi_k = 1.$$

As probabilidades *a priori* descrevem a distribuição das classes antes da observação das características da nova unidade. Elas são parâmetros do problema de decisão e não devem ser identificadas automaticamente com as proporções das classes em uma amostra de treinamento.

Suponha que, para cada classe k ,

$$\mathbf{X} \mid C = k$$

possua densidade condicional

$$f_k(\mathbf{x}) = f(\mathbf{x} \mid C = k).$$

Para uma observação $\mathbf{x}$ tal que

$$\sum_{\ell=1}^K \pi_{\ell} f_{\ell}(\mathbf{x}) > 0,$$

o teorema de Bayes fornece

$$P(C = k \mid \mathbf{X} = \mathbf{x}) = \frac{\pi_k f_k(\mathbf{x})}{\sum_{\ell=1}^K \pi_{\ell} f_{\ell}(\mathbf{x})}. \quad (19.1)$$

A probabilidade *a posteriori* é determinada pelo produto entre a probabilidade *a priori* π_k e o valor $f_k(\mathbf{x})$ da densidade condicional na observação $\mathbf{x}$, normalizado pela soma desses produtos entre as classes.

19.2.2 Regra de Bayes sob perda zero-um

No caso mais simples, atribui-se perda zero a uma classificação correta e a mesma perda unitária a qualquer classificação incorreta:

$$L(a, k) = \begin{cases} 0, & a = k, \\ 1, & a \neq k. \end{cases} \quad (19.2)$$

Se a observação $\mathbf{x}$ for atribuída à classe a , a perda depende da verdadeira classe, que permanece desconhecida. Depois de observar $\mathbf{x}$, cada classe k possui probabilidade *a posteriori*

$$P(C = k \mid \mathbf{X} = \mathbf{x}).$$

A perda esperada associada à decisão a é obtida ponderando a perda correspondente a cada possível classe verdadeira por sua probabilidade *a posteriori*:

$$\sum_{k=1}^K L(a, k) P(C = k | \mathbf{X} = \mathbf{x}).$$

Sob a perda zero-um da Equação 19.2, o termo correspondente a $k = a$ é nulo e todos os termos com $k \neq a$ recebem perda unitária. Assim,

$$\begin{aligned} \sum_{k=1}^K L(a, k) P(C = k | \mathbf{X} = \mathbf{x}) &= \sum_{k \neq a} P(C = k | \mathbf{X} = \mathbf{x}) \\ &= 1 - P(C = a | \mathbf{X} = \mathbf{x}). \end{aligned}$$

Portanto, a perda esperada de atribuir $\mathbf{x}$ à classe a é a probabilidade *a posteriori* de que sua verdadeira classe seja diferente de a . Como

$$1 - u$$

decrece quando u aumenta, a menor perda esperada corresponde à maior probabilidade *a posteriori*. A regra de Bayes sob perda zero-um é, então,

$$\psi_B(\mathbf{x}) \in \arg \max_{k \in \{1, \dots, K\}} P(C = k | \mathbf{X} = \mathbf{x}).$$

Pela Equação 19.1,

$$P(C = k | \mathbf{X} = \mathbf{x}) = \frac{\pi_k f_k(\mathbf{x})}{\sum_{h=1}^K \pi_h f_h(\mathbf{x})}.$$

Para uma observação fixa $\mathbf{x}$, o denominador

$$\sum_{h=1}^K \pi_h f_h(\mathbf{x})$$

é o mesmo na probabilidade *a posteriori* de todas as classes. A comparação entre as classes depende, portanto, apenas dos valores

$$\pi_1 f_1(\mathbf{x}), \dots, \pi_K f_K(\mathbf{x}).$$

A regra de classificação pode ser escrita como

$$\psi_B(\mathbf{x}) \in \arg \max_{k \in \{1, \dots, K\}} \pi_k f_k(\mathbf{x}). \quad (19.3)$$

Se

$$\pi_k > 0 \quad \text{e} \quad f_k(\mathbf{x}) > 0$$

para todas as classes, a aplicação do logaritmo preserva a ordenação desses valores, pois o logaritmo é uma função estritamente crescente. Além disso,

$$\log [\pi_k f_k(\mathbf{x})] = \log \pi_k + \log f_k(\mathbf{x}).$$

Assim, para uma mesma observação $\mathbf{x}$, comparar

$$\pi_1 f_1(\mathbf{x}), \dots, \pi_K f_K(\mathbf{x})$$

é equivalente a comparar

$$\log \pi_1 + \log f_1(\mathbf{x}), \dots, \log \pi_K + \log f_K(\mathbf{x}).$$

A classe atribuída a $\mathbf{x}$ é aquela que apresenta o maior valor de

$$\log \pi_k + \log f_k(\mathbf{x}). \quad (19.4)$$

Sob normalidade multivariada, a forma de $f_k(\mathbf{x})$ determina duas especializações dessa regra. Quando todas as classes compartilham a mesma matriz de covariâncias, obtém-se a **Análise Discriminante Linear** (*Linear Discriminant Analysis*, LDA). Quando cada classe possui sua própria matriz de covariâncias, obtém-se a **Análise Discriminante Quadrática** (*Quadratic Discriminant Analysis*, QDA) (Johnson; Wichern, 2002).

Quando as perdas dos diferentes erros de classificação não são iguais, a decisão ótima depende conjuntamente das probabilidades *a posteriori* e dos valores $L(a, k)$. Nesse caso, a classe de maior probabilidade *a posteriori* não precisa ser a decisão de menor perda esperada.

19.3 Discriminação linear sob normalidade (LDA)

Utilizando a distribuição Normal Multivariada definida na Definição 9.1, considere a especialização probabilística

$$\mathbf{x} \mid C = k \sim N_p(\mu_k, \Sigma), \quad k = 1, \dots, K, \quad (19.5)$$

em que

$$\mu_k \in \mathbb{R}^p$$

e todas as classes compartilham a matriz de covariâncias

$$\Sigma \in \mathbb{R}^{p \times p}, \quad \Sigma \succ \mathbf{0}.$$

Considere também probabilidades *a priori*

$$\pi_k > 0, \quad \sum_{k=1}^K \pi_k = 1.$$

A normalidade não é necessária para definir a regra de Bayes. Na LDA normal, ela especifica as distribuições condicionais das características.

Sob perda zero-um, a Equação 19.3 mostra que a classificação pode ser obtida comparando

$$\log \pi_k + \log f_k(\mathbf{x}).$$

A comparação entre log-densidades normais com matriz de covariâncias comum foi estabelecida na Equação 9.46. Os termos quadráticos em $\mathbf{x}$ e os termos que não dependem da classe cancelam-se, restando uma função afim das características.

Definição 19.2 (Função discriminante linear de classe). Sob o modelo normal especificado na Equação 19.5 e perda zero-um, a **função discriminante linear da classe k** é

$$\delta_k(\mathbf{x}) = \mathbf{x}^\top \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^\top \Sigma^{-1} \mu_k + \log \pi_k. \quad (19.6)$$

A regra discriminante linear é

$$\psi_{\text{LDA}}(\mathbf{x}) \in \arg \max_{k \in \{1, \dots, K\}} \delta_k(\mathbf{x}). \quad (19.7)$$

A função $\delta_k(\mathbf{x})$ é afim em $\mathbf{x}$. A denominação *Linear Discriminant Analysis* refere-se à forma das fronteiras de decisão entre as classes.

19.3.1 Fronteiras e distância de Mahalanobis

Considere duas classes distintas,

$$k \neq h.$$

A fronteira entre elas é determinada por

$$\delta_k(\mathbf{x}) = \delta_h(\mathbf{x}),$$

ou, equivalentemente,

$$\begin{aligned} 0 &= \mathbf{x}^\top \Sigma^{-1} (\mu_k - \mu_h) \\ &\quad - \frac{1}{2} (\mu_k^\top \Sigma^{-1} \mu_k - \mu_h^\top \Sigma^{-1} \mu_h) + \log \frac{\pi_k}{\pi_h}. \end{aligned} \quad (19.8)$$

Quando

$$\mu_k \neq \mu_h,$$

essa equação define um hiperplano cujo vetor normal é

$$\Sigma^{-1} (\mu_k - \mu_h). \quad (19.9)$$

A orientação da fronteira é determinada por $\Sigma^{-1}(\mu_k - \mu_h)$. Mantidos μ_k , μ_h e Σ , alterar as probabilidades *a priori* modifica o termo constante e desloca a fronteira, mas não altera seu vetor normal.

Se

$$\mu_k = \mu_h,$$

as duas classes possuem a mesma densidade condicional sob o modelo de covariância comum. A comparação entre elas depende apenas das probabilidades *a priori*. Se também

$$\pi_k = \pi_h,$$

os valores das funções discriminantes das duas classes coincidem para todo $\mathbf{x}$, e a regra não permite distingui-las.

A distância de Mahalanobis definida na Definição 8.8 permite escrever a mesma regra em forma geométrica. Para a classe k ,

$$d_M^2(\mathbf{x}, \mu_k; \Sigma) = (\mathbf{x} - \mu_k)^\top \Sigma^{-1} (\mathbf{x} - \mu_k).$$

Sob perda zero-um,

$$\psi_{\text{LDA}}(\mathbf{x}) \in \arg \min_{k \in \{1, \dots, K\}} \left\{ d_M^2(\mathbf{x}, \mu_k; \Sigma) - 2 \log \pi_k \right\}. \quad (19.10)$$

Se as probabilidades *a priori* são iguais,

$$\pi_1 = \dots = \pi_K = \frac{1}{K},$$

o termo associado às probabilidades é comum a todas as classes e

$$\psi_{\text{LDA}}(\mathbf{x}) \in \arg \min_{k \in \{1, \dots, K\}} d_M^2(\mathbf{x}, \mu_k; \Sigma). \quad (19.11)$$

Assim, sob normalidade, covariância comum, probabilidades *a priori* iguais e perda zero-um, a regra de Bayes classifica pela menor distância de Mahalanobis ao vetor de médias populacional μ_k de cada classe.

Na LDA, a matriz Σ desempenha dois papéis: é a matriz de covariâncias comum das distribuições condicionais e define a métrica de Mahalanobis utilizada para comparar uma nova observação com os vetores de médias das classes.

A LDA desenvolvida nesta seção é populacional, pois utiliza

$$\mu_1, \dots, \mu_K, \quad \Sigma, \quad \pi_1, \dots, \pi_K.$$

Na regra definida na Seção 19.5, esses parâmetros populacionais são substituídos pelas quantidades correspondentes obtidas ou adotadas a partir da amostra de treinamento.

19.4 Discriminação quadrática (QDA)

A linearidade da LDA decorre da utilização de uma matriz de covariâncias comum. Considere agora

$$\mathbf{x} \mid C = k \sim N_p(\mu_k, \Sigma_k), \quad k = 1, \dots, K, \quad (19.12)$$

em que

$$\mu_k \in \mathbb{R}^p$$

e

$$\Sigma_k \in \mathbb{R}^{p \times p}, \quad \Sigma_k \succ \mathbf{0}.$$

Considere também

$$\pi_k > 0, \quad \sum_{k=1}^K \pi_k = 1.$$

Sob perda zero-um, a regra de Bayes continua comparando

$$\log \pi_k + \log f_k(\mathbf{x}).$$

A diferença está nas matrizes de covariâncias das distribuições condicionais. Como mostra a Equação 9.47, para duas classes com matrizes de covariâncias distintas, os termos quadráticos em $\mathbf{x}$ não se cancelam na comparação.

Definição 19.3 (Função discriminante quadrática de classe). Sob o modelo normal especificado na Equação 19.12 e perda zero-um, a **função discriminante quadrática da classe k** é

$$\delta_k^Q(\mathbf{x}) = -\frac{1}{2} \log |\Sigma_k| - \frac{1}{2}(\mathbf{x} - \mu_k)^\top \Sigma_k^{-1}(\mathbf{x} - \mu_k) + \log \pi_k. \quad (19.13)$$

A regra discriminante quadrática é

$$\psi_{\text{QDA}}(\mathbf{x}) \in \arg \max_{k \in \{1, \dots, K\}} \delta_k^Q(\mathbf{x}). \quad (19.14)$$

A função possui dois componentes dependentes da dispersão da classe. A forma quadrática, no sentido da Definição 2.17,

$$(\mathbf{x} - \mu_k)^\top \Sigma_k^{-1} (\mathbf{x} - \mu_k)$$

é a distância quadrática de Mahalanobis à média da classe segundo sua própria matriz de covariâncias. O termo

$$\log |\Sigma_k|$$

é o logaritmo da variância generalizada da distribuição condicional da classe k , conforme a Definição 8.7, e participa do termo de normalização da densidade normal.

Na QDA, cada classe é comparada com sua média segundo a matriz de covariâncias Σ_k . Quando essas matrizes diferem entre as classes, não existe uma única métrica de Mahalanobis compartilhada por todas elas.

19.4.1 Fronteiras e comparação com a LDA

Considere duas classes distintas,

$$k \neq h.$$

A fronteira é determinada por

$$\delta_k^Q(\mathbf{x}) = \delta_h^Q(\mathbf{x}).$$

Após reunir os termos quadráticos, lineares e constantes, obtém-se

$$\mathbf{x}^\top \mathbf{A}_{kh} \mathbf{x} + \mathbf{b}_{kh}^\top \mathbf{x} + c_{kh} = 0, \quad (19.15)$$

em que $\mathbf{A}_{kh}$, $\mathbf{b}_{kh}$ e c_{kh} dependem das médias, das matrizes de covariâncias e das probabilidades *a priori* das duas classes.

Quando

$$\Sigma_k \neq \Sigma_h,$$

tem-se

$$\mathbf{A}_{kh} \neq \mathbf{0},$$

e permanecem termos quadráticos em $\mathbf{x}$. A fronteira entre as classes não precisa, portanto, ser um hiperplano.

Quando todas as classes compartilham

$$\Sigma_1 = \dots = \Sigma_K = \Sigma,$$

o termo quadrático em $\mathbf{x}$ e o log-determinante tornam-se comuns a todas as classes. Esses termos podem ser retirados da comparação entre as funções discriminantes de classe, e a parte dependente da classe coincide com a Equação 19.6. A regra de classificação da QDA torna-se, portanto, equivalente à LDA.

A diferença entre LDA e QDA decorre das matrizes de covariâncias assumidas para as distribuições condicionais. Na LDA, uma única matriz Σ define a métrica de Mahalanobis comum às classes e conduz a fronteiras lineares; na QDA, cada classe pode possuir sua própria matriz Σ_k , de modo que a comparação utiliza métricas de Mahalanobis específicas por classe e pode produzir fronteiras quadráticas.

A Figura 19.1 ilustra essa diferença para duas populações normais.

Na LDA, a matriz de covariâncias comum faz com que os termos quadráticos em $\mathbf{x}$ se cancelem na comparação entre as classes, produzindo a fronteira linear representada no primeiro painel. Na QDA, quando as matrizes de covariâncias das classes diferem, esse cancelamento não ocorre e a fronteira pode ser quadrática, como no segundo painel.

19.5 Da regra populacional à regra estimada

As regras populacionais da LDA e da QDA dependem de parâmetros populacionais.

Na LDA, são necessários

$$\mu_1, \dots, \mu_K, \quad \Sigma, \quad \pi_1, \dots, \pi_K.$$

Na QDA, são necessários




Figura 19.1: Fronteiras de decisão para duas populações normais. As elipses delimitam regiões de concentração de 75%. Com covariância comum, a LDA produz uma fronteira linear; com covariâncias distintas, a QDA pode produzir uma fronteira quadrática.

$$\mu_1, \dots, \mu_K, \quad \Sigma_1, \dots, \Sigma_K, \quad \pi_1, \dots, \pi_K.$$

Em uma aplicação, as médias e as matrizes de covariâncias populacionais são geralmente desconhecidas e são estimadas a partir de uma amostra de treinamento com classes conhecidas. As probabilidades *a priori* podem ser conhecidas, especificadas ou estimadas, conforme a informação disponível e o mecanismo de amostragem. Conforme a Definição 10.4, os estimadores são estatísticas aleatórias; após a observação da amostra, seus valores constituem estimativas.

Considere

$$n = \sum_{k=1}^K n_k,$$

em que n_k é o número de unidades observadas da classe k .

Para cada classe, a média amostral aleatória é obtida aplicando a Equação 10.8 às observações do grupo, e sua realização observada será denotada por

$$\bar{\mathbf{x}}_k \in \mathbb{R}^p.$$

Quando

$$n_k \geq 2,$$

a matriz de covariâncias amostral definida em Definição 10.10 fornece o estimador da covariância da classe, cuja realização será denotada por

$$\mathbf{S}_k \in \mathbb{R}^{p \times p}.$$

Essas estatísticas não exigem normalidade para serem definidas. Nas formulações LDA e QDA, elas são utilizadas como estimadores dos parâmetros dos respectivos modelos normais.

19.5.1 Covariância comum na LDA

Sob a hipótese populacional

$$\Sigma_1 = \dots = \Sigma_K = \Sigma,$$

a dispersão das classes é reunida em uma única estimativa.

Utilizando a matriz de dispersão intragrupos $\mathbf{T}_{\text{intra}}$ definida na Definição 8.13 e sua correspondência com a SQPC residual da MANOVA expressa pela Equação 11.67, para

$$n > K,$$

a matriz de covariâncias agrupada observada é

$$\mathbf{S}_p = \frac{1}{n - K} \mathbf{T}_{\text{intra}}. \quad (19.16)$$

Equivalentemente, quando todas as matrizes $\mathbf{S}_k$ estão definidas,

$$\mathbf{S}_p = \frac{\sum_{k=1}^K (n_k - 1) \mathbf{S}_k}{n - K}.$$

A matriz $\mathbf{T}_{\text{intra}}$ utilizada na estimativa da covariância comum da LDA pela Equação 19.16 também compõe o critério amostral de Fisher desenvolvido na Seção 19.6.

19.5.2 Probabilidades *a priori*

Na regra estimada, as probabilidades *a priori* utilizadas na classificação podem ser conhecidas a partir de informação populacional, especificadas externamente ou estimadas a partir da amostra de treinamento.

Quando a amostra de treinamento representa a mistura populacional das classes, pode-se utilizar a estimativa

$$\hat{\pi}_k = \frac{n_k}{n}. \quad (19.17)$$

Essa escolha não é automática. Se os tamanhos das classes foram fixados pelo delineamento ou se o mecanismo amostral altera suas proporções, n_k/n não representa necessariamente

$$P(C = k).$$

Nessas situações, as probabilidades *a priori* devem ser especificadas a partir do problema ou de informação populacional externa.

Para distinguir a estimativa amostral do valor efetivamente utilizado na regra, denote por

$$\tilde{\pi}_k$$

a probabilidade *a priori* adotada para a classificação. Quando ela é estimada pelas proporções da amostra,

$$\tilde{\pi}_k = \hat{\pi}_k;$$

quando é especificada externamente, $\tilde{\pi}_k$ representa diretamente o valor adotado.

19.5.3 Regra estimada da LDA

Substituindo as médias e a matriz de covariâncias populacionais por estimativas e utilizando os valores das probabilidades *a priori* adotados para a classificação, obtém-se uma regra *plug-in*.

Definição 19.4 (Função discriminante linear de classe estimada). Considere médias observadas

$$\bar{\mathbf{x}}_1, \dots, \bar{\mathbf{x}}_K,$$

a matriz de covariâncias agrupada

$$\mathbf{S}_p \succ \mathbf{0}$$

definida na Equação 19.16 e probabilidades *a priori* utilizadas na regra

$$\tilde{\pi}_k > 0, \quad \sum_{k=1}^K \tilde{\pi}_k = 1.$$

A função discriminante linear estimada da classe k é

$$\hat{\delta}_k(\mathbf{x}) = \mathbf{x}^\top \mathbf{S}_p^{-1} \bar{\mathbf{x}}_k - \frac{1}{2} \bar{\mathbf{x}}_k^\top \mathbf{S}_p^{-1} \bar{\mathbf{x}}_k + \log \tilde{\pi}_k. \quad (19.18)$$

A regra estimada é

$$\hat{\psi}_{\text{LDA}}(\mathbf{x}) \in \arg \max_{k \in \{1, \dots, K\}} \hat{\delta}_k(\mathbf{x}). \quad (19.19)$$

A forma algébrica coincide com a regra populacional, mas os objetos possuem naturezas estatísticas diferentes:

$$\mu_k \longrightarrow \bar{\mathbf{x}}_k, \quad \Sigma \longrightarrow \mathbf{S}_p, \quad \pi_k \longrightarrow \tilde{\pi}_k.$$

A regra estimada depende da amostra de treinamento e, portanto, varia entre amostras.

19.5.4 Regra estimada da QDA

Na QDA estimada, a matriz de covariâncias de cada classe é estimada separadamente.

Definição 19.5 (Função discriminante quadrática de classe estimada). Considere

$$\mathbf{S}_k \succ \mathbf{0}, \quad k = 1, \dots, K.$$

A função discriminante quadrática estimada da classe k é

$$\hat{\delta}_k^Q(\mathbf{x}) = -\frac{1}{2} \log |\mathbf{S}_k| - \frac{1}{2} (\mathbf{x} - \bar{\mathbf{x}}_k)^\top \mathbf{S}_k^{-1} (\mathbf{x} - \bar{\mathbf{x}}_k) + \log \tilde{\pi}_k. \quad (19.20)$$

A regra correspondente é

$$\hat{\psi}_{\text{QDA}}(\mathbf{x}) \in \arg \max_{k \in \{1, \dots, K\}} \hat{\delta}_k^Q(\mathbf{x}). \quad (19.21)$$

A LDA utiliza uma única estimativa de covariância, $\mathbf{S}_p$, enquanto a QDA utiliza

$$\mathbf{S}_1, \dots, \mathbf{S}_K.$$

A QDA exige, portanto, amostras de classe que permitam estimar matrizes de covariâncias não singulares. As condições de posto correspondentes são reunidas na Seção 19.12.

A Tabela 19.2 sintetiza a diferença entre as duas formulações.

Tabela 19.2: Comparação entre LDA e QDA.

Aspecto	LDA	QDA
modelo condicional	$N_p(\mu_k, \Sigma)$	$N_p(\mu_k, \Sigma_k)$
covariância populacional	comum	específica por classe
estimativa de covariância	$\mathbf{S}_p$	$\mathbf{S}_k$
função discriminante de classe	afim em $\mathbf{x}$	quadrática em $\mathbf{x}$
fronteira entre duas classes	hiperplano	superfície quadrática em geral
geometria	uma métrica de Mahalanobis comum	uma métrica de Mahalanobis por classe
probabilidades <i>a priori</i>	entram por $\log \pi_k$ na regra populacional e por $\log \tilde{\pi}_k$ na regra estimada	entram por $\log \pi_k$ na regra populacional e por $\log \tilde{\pi}_k$ na regra estimada

A substituição das médias e covariâncias populacionais por estimativas transforma a regra populacional em uma regra construída a partir da amostra de treinamento. Quando as probabilidades *a priori* também são estimadas a partir da amostra, sua variabilidade amostral integra a regra; quando são especificadas externamente, seus valores permanecem fixos.

19.6 Formulação geométrica de Fisher

A classificação probabilística produz regras para classificar novas observações. A formulação de Fisher utiliza os grupos conhecidos para construir combinações lineares das características que representem sua separação relativamente à dispersão existente dentro dos grupos.

O problema admite uma formulação populacional e uma formulação amostral. A formulação populacional constrói as dispersões dentro e entre classes a partir dos momentos condicionais de $\mathbf{X} \mid C = k$; a formulação amostral utiliza as matrizes de dispersão calculadas a partir das observações com rótulos conhecidos.

A razão geométrica adotada neste capítulo pode ser definida a partir das dispersões entre e dentro dos grupos sem introduzir uma hipótese de normalidade e pode ser escrita mesmo quando as matrizes de covariâncias condicionais diferem entre as classes. Essa extensão deve ser distinguida da formulação clássica de Fisher apresentada por Johnson e Wichern, que não exige normalidade, mas pressupõe implicitamente uma matriz de covariâncias populacional comum (Johnson; Wichern, 2002). Sob covariância comum, estabelece-se também a correspondência direta com a orientação da LDA normal.

19.6.1 Dispersões populacionais dentro e entre grupos

Considere

$$C \in \{1, \dots, K\},$$

com

$$P(C = k) = \pi_k, \quad \pi_k > 0, \quad \sum_{k=1}^K \pi_k = 1,$$

e um vetor aleatório

$$\mathbf{X} \in \mathbb{R}^p$$

com segundos momentos finitos.

Para cada classe, sejam

$$\mu_k = E(\mathbf{X} \mid C = k)$$

e

$$\Sigma_k = \text{Cov}(\mathbf{X} \mid C = k).$$

A média marginal é

$$\mu = E(\mathbf{X}) = \sum_{k=1}^K \pi_k \mu_k. \quad (19.22)$$

Definição 19.6 (Dispersões populacionais de Fisher). A **dispersão populacional intra-grupos** é

$$\Sigma_W = \sum_{k=1}^K \pi_k \Sigma_k \in \mathbb{R}^{p \times p}, \quad (19.23)$$

e a **dispersão populacional entre grupos** é

$$\Sigma_B = \sum_{k=1}^K \pi_k (\mu_k - \mu) (\mu_k - \mu)^\top \in \mathbb{R}^{p \times p}. \quad (19.24)$$

As duas matrizes são simétricas e semidefinidas positivas. A matriz Σ_W é a média, ponderada pelas probabilidades π_k , das matrizes de covariâncias condicionais, enquanto Σ_B é a dispersão dos vetores de médias condicionais em torno da média marginal, também ponderada pelas probabilidades π_k .

Proposição 19.1 (Decomposição populacional da covariância por grupos). *Sob as condições da Definição 19.6,*

$$\text{Cov}(\mathbf{X}) = \Sigma_W + \Sigma_B. \quad (19.25)$$

A Equação 19.25 decorre da lei da covariância total condicionada à variável de classe C ; sua derivação está na Seção 19.14.4.

A Equação 19.25 é a contraparte populacional da decomposição amostral

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

estabelecida na Proposição 8.9. Os objetos possuem naturezas distintas: Σ_W e Σ_B são parâmetros populacionais, enquanto $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$ são matrizes calculadas a partir das observações.

19.6.2 Dispersões projetadas

Considere uma direção

$$\mathbf{a} \in \mathbb{R}^p, \quad \mathbf{a} \neq \mathbf{0},$$

e a combinação linear

$$Z = \mathbf{a}^\top \mathbf{X}.$$

A dispersão média de Z dentro das classes é

$$\sum_{k=1}^K \pi_k \text{Var}(Z \mid C = k) = \mathbf{a}^\top \Sigma_W \mathbf{a}, \quad (19.26)$$

enquanto a dispersão das médias condicionais projetadas é

$$\sum_{k=1}^K \pi_k \left[\mathbf{a}^\top (\mu_k - \mu) \right]^2 = \mathbf{a}^\top \Sigma_B \mathbf{a}. \quad (19.27)$$

Definição 19.7 (Critério populacional de Fisher). Se

$$\Sigma_B \succeq \mathbf{0}$$

e

$$\Sigma_W \succ \mathbf{0},$$

o critério populacional de Fisher é

$$J_F^{(P)}(\mathbf{a}) = \frac{\mathbf{a}^\top \Sigma_B \mathbf{a}}{\mathbf{a}^\top \Sigma_W \mathbf{a}}, \quad \mathbf{a} \neq \mathbf{0}. \quad (19.28)$$

O numerador é a dispersão, ponderada pelas probabilidades π_k , das médias condicionais projetadas em torno da média marginal projetada. O denominador é a média, também ponderada por π_k , das variâncias condicionais da projeção dentro das classes. O critério procura, portanto, direções em que a dispersão entre classes seja elevada relativamente à dispersão intragrupos.

O critério populacional de Fisher exige segundos momentos finitos. A solução baseada em Σ_W^{-1} exige adicionalmente

$$\Sigma_W \succ \mathbf{0}.$$

A normalidade multivariada e a igualdade

$$\Sigma_1 = \dots = \Sigma_K$$

não são necessárias para definir a extensão populacional do critério adotada neste capítulo.

Quando as covariâncias condicionais são comuns,

$$\Sigma_k = \Sigma, \quad k = 1, \dots, K,$$

tem-se

$$\Sigma_W = \Sigma.$$

Para duas classes com covariância comum, a direção de Fisher é paralela ao vetor normal da fronteira da LDA, conforme demonstrado na Seção [19.14.5](#).

19.7 Formulação amostral de Fisher

Considere uma amostra com grupos conhecidos, com n_k observações no grupo k e

$$n = \sum_{k=1}^K n_k$$

observações no total.

As matrizes de dispersão intragrupos $\mathbf{T}_{\text{intra}}$ e entre grupos $\mathbf{T}_{\text{entre}}$ são as definidas, respectivamente, na Definição 8.13 e na Definição 8.14.

Pela Proposição 8.9,

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}.$$

Na formulação amostral de Fisher, essas matrizes desempenham funções distintas: $\mathbf{T}_{\text{intra}}$ representa a dispersão das observações em torno dos centroides de seus grupos, enquanto $\mathbf{T}_{\text{entre}}$ representa a dispersão dos centroides em torno da média global, ponderada pelos tamanhos dos grupos.

As matrizes

$$\frac{1}{n} \mathbf{T}_{\text{intra}} \quad \text{e} \quad \frac{1}{n} \mathbf{T}_{\text{entre}}$$

correspondem às versões empíricas das dispersões populacionais quando as classes recebem pesos n_k/n . Como a multiplicação do numerador e do denominador por um mesmo escalar positivo não altera o quociente de Fisher, o critério pode ser formulado diretamente com as SQPCs.

Os pesos n_k presentes em $\mathbf{T}_{\text{entre}}$ pertencem à decomposição da amostra observada. Eles não devem ser identificados automaticamente com as probabilidades *a priori* π_k utilizadas na classificação probabilística.

Considere agora uma direção

$$\mathbf{a} \in \mathbb{R}^p, \quad \mathbf{a} \neq \mathbf{0}.$$

Para uma observação

$$\mathbf{x} \in \mathbb{R}^p,$$

sua coordenada projetada é

$$z = \mathbf{a}^\top \mathbf{x}.$$

Depois da projeção, a dispersão intragrupos é

$$\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a},$$

enquanto a dispersão entre os centroides, ponderada pelos tamanhos dos grupos, é

$$\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}.$$

Definição 19.8 (Critério amostral de Fisher). Sejam

$$\mathbf{T}_{\text{entre}}, \mathbf{T}_{\text{intra}} \in \mathbb{R}^{p \times p}$$

matrizes simétricas tais que

$$\mathbf{T}_{\text{entre}} \succeq \mathbf{0}$$

e

$$\mathbf{T}_{\text{intra}} \succ \mathbf{0}.$$

Para

$$\mathbf{a} \in \mathbb{R}^p, \quad \mathbf{a} \neq \mathbf{0},$$

o critério amostral de Fisher é

$$J_F(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}}{\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a}}. \quad (19.29)$$

O numerador mede a dispersão dos centroides projetados em torno da média global projetada, ponderada pelos tamanhos dos grupos, enquanto o denominador mede a dispersão das observações em torno dos centroides de seus grupos na mesma direção.

Como

$$J_F(c\mathbf{a}) = J_F(\mathbf{a}), \quad c \neq 0,$$

o critério identifica direções, e não vetores com comprimento determinado.

Maximizar $J_F(\mathbf{a})$ corresponde a procurar uma combinação das características na qual a separação entre grupos seja elevada relativamente à dispersão intragrupos. A construção é supervisionada porque os rótulos dos grupos determinam diretamente $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$.

A Figura 19.2 compara duas projeções das mesmas observações. A primeira utiliza a direção que une os centroides; a segunda utiliza a direção determinada pelo critério de Fisher. Os




Figura 19.2: Projeção das mesmas duas classes na direção que une os centroides e na direção de Fisher. A direção discriminante aumenta a separação entre os grupos relativamente à dispersão intragrupos.

escores são padronizados pelo desvio padrão intragrupos para tornar comparáveis as duas projeções.

A figura ilustra o critério da Equação 19.29 em uma escala padronizada pela dispersão intragrupos. A direção de Fisher é escolhida para maximizar a dispersão entre grupos relativamente à dispersão intragrupos, enquanto a direção que une os centroides considera apenas sua separação no espaço original.

19.8 Direções discriminantes e autovalores generalizados

O critério definido na Equação 19.29 é o quociente de Rayleigh generalizado definido na Definição 5.9, aplicado ao par

$$(\mathbf{T}_{\text{entre}}, \mathbf{T}_{\text{intra}}).$$

Pelo Teorema 5.6, os extremos de

$$J_F(\mathbf{a})$$

são determinados pelo problema

$$\mathbf{T}_{\text{entre}} \mathbf{a} = \lambda \mathbf{T}_{\text{intra}} \mathbf{a}. \quad (19.30)$$

A Equação 19.30 é um problema de autovalores generalizados no sentido da Definição 5.8. Nessa expressão, $\mathbf{a}$ representa uma direção genérica. As soluções normalizadas serão denotadas por α_j .

19.8.1 Geometria pela dispersão intragrupos

Como

$$\mathbf{T}_{\text{intra}} \succ \mathbf{0},$$

sua raiz quadrada principal, definida na Definição 5.7, também é positiva definida e, portanto, invertível.

A mudança de métrica está relacionada ao branqueamento dos pontos pela Equação 8.47. Como os pontos são transformados por $\mathbf{T}_{\text{intra}}^{-1/2}$, a direção correspondente no espaço transformado é definida por

$$\mathbf{u} = \mathbf{T}_{\text{intra}}^{1/2} \mathbf{a}.$$

Então,

$$\mathbf{a} = \mathbf{T}_{\text{intra}}^{-1/2} \mathbf{u},$$

e a Equação 19.30 torna-se

$$\mathbf{M}_F \mathbf{u} = \lambda \mathbf{u},$$

em que

$$\mathbf{M}_F = \mathbf{T}_{\text{intra}}^{-1/2} \mathbf{T}_{\text{entre}} \mathbf{T}_{\text{intra}}^{-1/2} \in \mathbb{R}^{p \times p}. \quad (19.31)$$

A matriz $\mathbf{M}_F$ é simétrica e semidefinida positiva. Como $\mathbf{T}_{\text{intra}}^{-1/2}$ é invertível,

$$\text{posto}(\mathbf{M}_F) = \text{posto}(\mathbf{T}_{\text{entre}}).$$

Defina

$$r_F = \text{posto}(\mathbf{T}_{\text{entre}}).$$

A matriz $\mathbf{M}_F$ possui exatamente r_F autovalores positivos. Esses autovalores coincidem com os autovalores generalizados do par

$$(\mathbf{T}_{\text{entre}}, \mathbf{T}_{\text{intra}})$$

e, na Análise Discriminante, são denominados **raízes discriminantes de Fisher**.

Definição 19.9 (Direções discriminantes de Fisher). Sejam

$$\mathbf{T}_{\text{entre}}, \mathbf{T}_{\text{intra}} \in \mathbb{R}^{p \times p},$$

com

$$\mathbf{T}_{\text{entre}} \succeq \mathbf{0} \quad \text{e} \quad \mathbf{T}_{\text{intra}} \succ \mathbf{0}.$$

Defina

$$r_F = \text{posto}(\mathbf{T}_{\text{entre}}).$$

Se $r_F \geq 1$, as **direções discriminantes de Fisher** são autovetores generalizados

$$\alpha_1, \dots, \alpha_{r_F} \in \mathbb{R}^p$$

associados às raízes positivas

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_{r_F} > 0$$

e escolhidos com a normalização

$$\alpha_j^\top \mathbf{T}_{\text{intra}} \alpha_\ell = \begin{cases} 1, & j = \ell, \\ 0, & j \neq \ell. \end{cases} \quad (19.32)$$

Sob essa condição,

$$\mathbf{T}_{\text{entre}} \alpha_j = \lambda_j \mathbf{T}_{\text{intra}} \alpha_j.$$

Se

$$r_F = 0,$$

então

$$\mathbf{T}_{\text{entre}} = \mathbf{0},$$

e não existe direção com separação amostral positiva entre os centroides.

Para a primeira direção,

$$J_F(\alpha_1) = \lambda_1 = \max_{\mathbf{a} \neq \mathbf{0}} J_F(\mathbf{a}).$$

A condição de normalização da Equação 19.32 implica, para cada j ,

$$\alpha_j^\top \mathbf{T}_{\text{intra}} \alpha_j = 1. \quad (19.33)$$

Consequentemente,

$$\alpha_j^\top \mathbf{T}_{\text{entre}} \alpha_j = \lambda_j. \quad (19.34)$$

Cada raiz λ_j é, portanto, a dispersão entre grupos na direção α_j quando a dispersão intragrupos nessa direção é normalizada para 1.

Quando $r_F \geq 1$, a participação relativa de cada raiz na soma das raízes discriminantes positivas é

$$\frac{\lambda_j}{\sum_{\ell=1}^{r_F} \lambda_\ell}, \quad j = 1, \dots, r_F. \quad (19.35)$$

Essas participações somam 1:

$$\sum_{j=1}^{r_F} \frac{\lambda_j}{\sum_{\ell=1}^{r_F} \lambda_\ell} = 1.$$

A razão

$$\frac{\lambda_j}{\sum_{\ell=1}^{r_F} \lambda_\ell}$$

descreve a participação relativa da direção j na soma das raízes discriminantes positivas. Ela não representa uma proporção da variância total das características, como ocorre na ACP. As raízes de Fisher quantificam separação entre grupos relativamente à dispersão intragrupos, de modo que sua interpretação permanece vinculada ao critério discriminante.

Como $\mathbf{T}_{\text{intra}} \succ \mathbf{0}$, ela induz o produto interno definido na Definição 3.16. A ortogonalidade expressa pela Equação 19.32 é, portanto, a ortogonalidade nessa geometria. Pela Proposição 5.7, direções associadas a raízes distintas podem ser escolhidas ortogonais nessa métrica. Em geral,

$$\alpha_j^\top \alpha_\ell$$

não precisa ser zero para

$$j \neq \ell.$$

19.8.2 Número de direções discriminantes

Pelo limite de posto estabelecido na Equação 8.92,

$$\text{posto}(\mathbf{T}_{\text{entre}}) \leq \min(p, K - 1).$$

Como

$$r_F = \text{posto}(\mathbf{T}_{\text{entre}}),$$

segue que

$$r_F \leq \min(p, K - 1). \quad (19.36)$$

O limite decorre de duas restrições. A separação ocorre em um espaço de dimensão p , e os K centroides centralizados em torno da média global podem gerar no máximo $K - 1$ direções linearmente independentes.

Assim, dois grupos produzem no máximo uma direção discriminante, e K grupos produzem no máximo $K - 1$, sem ultrapassar a dimensão original p .

O subespaço gerado por

$$\alpha_1, \dots, \alpha_{r_F}$$

é o subespaço discriminante de Fisher. As coordenadas das observações e dos centroides nesse subespaço são definidas na Seção 19.9.

19.9 Representação no subespaço discriminante

As direções

$$\alpha_1, \dots, \alpha_{r_F}$$

definidas na Definição 19.9 determinam um subespaço supervisionado de dimensão

$$r_F \leq \min(p, K - 1).$$

As combinações lineares associadas a essas direções produzem coordenadas construídas especificamente para representar a separação entre os grupos relativamente à dispersão intragrupos.

Definição 19.10 (Coordenadas discriminantes). Considere as direções discriminantes normalizadas

$$\alpha_1, \dots, \alpha_{r_F} \in \mathbb{R}^p$$

e a média global amostral

$$\bar{\mathbf{x}} \in \mathbb{R}^p.$$

A **função discriminante de Fisher** j é a aplicação

$$z_j(\mathbf{x}) = \alpha_j^\top (\mathbf{x} - \bar{\mathbf{x}}), \quad j = 1, \dots, r_F. \quad (19.37)$$

Para uma observação

$$\mathbf{x} \in \mathbb{R}^p,$$

o valor $z_j(\mathbf{x})$ é sua **coordenada discriminante** j , também denominada **escore discriminante** j .

O vetor de coordenadas discriminantes é

$$\mathbf{z}(\mathbf{x}) = \begin{pmatrix} z_1(\mathbf{x}) \\ \vdots \\ z_{r_F}(\mathbf{x}) \end{pmatrix} \in \mathbb{R}^{r_F}. \quad (19.38)$$

A denominação **coordenada discriminante** destaca a posição da observação no subespaço de Fisher; **escore discriminante** designa o mesmo valor numérico quando calculado para uma observação.

A centralização coloca a média global na origem da representação. Utilizar

$$\alpha_j^\top \mathbf{x}$$

sem centralização preservaria as diferenças entre observações e centroides, modificando apenas a origem das coordenadas.

O centroide do grupo k na dimensão discriminante j é

$$\bar{z}_{kj} = \alpha_j^\top (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}). \quad (19.39)$$

A representação é supervisionada porque

$$\alpha_1, \dots, \alpha_{r_F}$$

dependem de $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$, que são construídas a partir dos grupos conhecidos. Alterações nos rótulos ou na composição dos grupos podem modificar o subespaço discriminante.

No segundo painel, as direções são determinadas pelo problema espectral de Fisher. A transformação por

$$\mathbf{T}_{\text{intra}}^{-1/2}$$

transforma a matriz de dispersão intragrupos em uma matriz identidade, e os autovetores de

$$\mathbf{M}_F$$

identificam as direções de maior dispersão entre grupos nesse espaço transformado.




Figura 19.3: Representação de três grupos em duas características originais e nas duas coordenadas discriminantes de Fisher. As coordenadas são construídas especificamente para representar a separação entre os grupos.

No segundo painel, as direções são determinadas pelo problema espectral de Fisher. A transformação por

$$\mathbf{T}_{\text{intra}}^{-1/2}$$

padroniza a dispersão intragrupos, e os autovetores de

$$\mathbf{M}_F$$

identificam as direções de maior separação entre os centroides nesse espaço transformado.

A construção difere da ACP. No Capítulo 14, as direções são escolhidas pela variabilidade total; em Fisher, são escolhidas pela separação entre grupos relativamente à dispersão intragrupos.

19.10 Relação espectral com a MANOVA

Considere a MANOVA de um fator em que os K níveis do fator correspondem aos mesmos K grupos utilizados na formulação de Fisher e a hipótese nula é a igualdade dos vetores de médias

desses grupos. Nessa configuração, a matriz de erro da MANOVA coincide com a dispersão intragrupos,

$$\mathbf{E} = \mathbf{T}_{\text{intra}},$$

e a matriz de hipótese coincide com a dispersão entre grupos,

$$\mathbf{H} = \mathbf{T}_{\text{entre}}. \quad (19.40)$$

Assim, para essa hipótese de comparação entre os grupos, o problema de Fisher

$$\mathbf{T}_{\text{entre}}\alpha_j = \lambda_j \mathbf{T}_{\text{intra}}\alpha_j$$

coincide com o problema de autovalores generalizados desenvolvido no Capítulo 18.

As raízes positivas e os autoespaços generalizados associados são, portanto, os mesmos quando as matrizes de hipótese e erro da MANOVA correspondem, respectivamente, às dispersões entre e dentro dos grupos.

Na MANOVA, Wilks, Pillai e Hotelling–Lawley combinam as raízes características de formas distintas, enquanto Roy utiliza a maior raiz para testar a hipótese multivariada. Na formulação de Fisher, os autovetores generalizados associados às raízes positivas definem as direções utilizadas para representar a separação entre os grupos.

A coincidência algébrica não implica coincidência de objetivos: a MANOVA utiliza as raízes para construir critérios de teste de hipóteses sobre os vetores de médias, enquanto Fisher utiliza os autovetores generalizados para construir direções discriminantes.

19.11 Dois grupos e relação entre Fisher e LDA

Quando

$$K = 2,$$

a matriz de dispersão entre grupos possui posto no máximo 1. Existe, portanto, no máximo uma direção discriminante associada a uma raiz positiva.

Defina

$$\mathbf{d} = \bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2. \quad (19.41)$$

Para dois grupos,

$$\mathbf{T}_{\text{entre}} = \frac{n_1 n_2}{n_1 + n_2} \mathbf{d} \mathbf{d}^\top. \quad (19.42)$$

Se

$$\mathbf{d} = \mathbf{0},$$

então

$$\mathbf{T}_{\text{entre}} = \mathbf{0},$$

e não existe direção com separação amostral positiva.

Suponha agora

$$\mathbf{d} \neq \mathbf{0}$$

e

$$\mathbf{T}_{\text{intra}} \succ \mathbf{0}.$$

Como $\mathbf{T}_{\text{entre}}$ na Equação 19.42 possui posto 1, a única direção discriminante associada a uma raiz positiva satisfaz

$$\alpha_1 \propto \mathbf{T}_{\text{intra}}^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2). \quad (19.43)$$

A diferença

$$\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2$$

representa a separação bruta entre os centroides. A multiplicação por

$$\mathbf{T}_{\text{intra}}^{-1}$$

repondera essa separação segundo a dispersão e as associações existentes dentro dos grupos.

A direção de Fisher não é, portanto, determinada apenas pela distância entre os centroides. Diferenças que ocorrem em direções de elevada dispersão intragrupos recebem menor peso relativo do que diferenças de mesma magnitude em direções de menor dispersão.

19.11.1 Formulação populacional para dois grupos

Para dois grupos, a formulação populacional também conduz a uma única direção discriminante determinada pela diferença entre os vetores de médias condicionais e pela dispersão populacional intragrupos.

Considere

$$P(C = 1) = \pi_1, \quad P(C = 2) = \pi_2,$$

com

$$\pi_1 + \pi_2 = 1,$$

e defina

$$\mathbf{d}_\mu = \mu_1 - \mu_2.$$

A dispersão entre grupos é

$$\Sigma_B = \pi_1 \pi_2 \mathbf{d}_\mu \mathbf{d}_\mu^\top.$$

Se

$$\Sigma_W \succ \mathbf{0}$$

e

$$\mu_1 \neq \mu_2,$$

uma direção que maximiza o critério populacional de Fisher satisfaz

$$\mathbf{a}_F \propto \Sigma_W^{-1} (\mu_1 - \mu_2). \quad (19.44)$$

Esse resultado depende dos vetores de médias condicionais e da matriz Σ_W , construída a partir das covariâncias condicionais, e não exige normalidade multivariada.

Se, adicionalmente, as duas classes seguem distribuições normais com matriz de covariâncias comum

$$\Sigma,$$

então

$$\Sigma_W = \Sigma,$$

e a direção definida pela Equação 19.44 torna-se

$$\mathbf{a}_F \propto \Sigma^{-1} (\mu_1 - \mu_2).$$

A direção de Fisher é paralela ao vetor normal da fronteira da LDA dado pela Equação 19.9. Essa correspondência envolve a orientação da fronteira, e não a regra completa de classificação: sob perda zero-um, as probabilidades *a priori* também determinam sua posição; com perdas gerais, a decisão ótima depende ainda da função de perda. A Seção 19.14.5 demonstra essa correspondência.

19.11.2 Mais de dois grupos

Quando

$$K > 2,$$

a matriz

$$\mathbf{T}_{\text{entre}}$$

pode possuir posto superior a 1, e Fisher pode produzir

$$r_F \leq \min(p, K - 1)$$

direções discriminantes.

A LDA, por sua vez, não precisa construir previamente as direções nem as coordenadas discriminantes de Fisher. Sua regra compara diretamente

$$\delta_1(\mathbf{x}), \dots, \delta_K(\mathbf{x})$$

no espaço original das características.

As direções de Fisher fornecem uma representação supervisionada da separação entre os grupos; a LDA fornece uma regra probabilística de decisão. Sob a formulação normal com covariância comum da LDA, ambas utilizam os vetores de médias das classes e a dispersão intragrupos, mas esses objetos entram em critérios com objetivos distintos.

19.12 Pressupostos e limites

Fisher, LDA e QDA exigem condições diferentes. O critério populacional de Fisher depende dos vetores de médias e das matrizes de covariâncias condicionais, enquanto sua versão amostral utiliza as dispersões calculadas a partir dos grupos observados. As formulações baseadas em inversas exigem não singularidade das matrizes correspondentes. LDA e QDA acrescentam hipóteses probabilísticas para especificar as distribuições condicionais normais, e suas regras estimadas exigem condições amostrais de posto.

A Tabela 19.3 reúne essas condições.

Tabela 19.3: Condições das formulações de Fisher, LDA e QDA.

Condição	Fisher geométrico	LDA normal	QDA normal
grupos previamente definidos	necessária	necessária	necessária
segundos momentos finitos	necessários na formulação populacional	satisfeitos sob normalidade	satisfeitos sob normalidade
normalidade multivariada	não necessária para definir o critério	assumida	assumida
covariância comum entre classes	não necessária para a extensão populacional adotada; assumida na formulação clássica de Fisher de Johnson e Wichern	assumida	não assumida
não singularidade populacional	$\Sigma_W \succ \mathbf{0}$ na forma baseada em inversas	$\Sigma \succ \mathbf{0}$	$\Sigma_k \succ \mathbf{0}$ para cada classe
não singularidade amostral	$\mathbf{T}_{\text{intra}} \succ \mathbf{0}$ na forma baseada em inversas	$\mathbf{S}_p \succ \mathbf{0}$	$\mathbf{S}_k \succ \mathbf{0}$ para cada classe
probabilidades <i>a priori</i>	funcionam como pesos na extensão populacional adotada neste capítulo	entram na regra de decisão	entram na regra de decisão

Condição	Fisher geométrico	LDA normal	QDA normal
função de perda	não entra no critério	perda zero-um na regra básica	perda zero-um na regra básica

19.12.1 Grupos previamente definidos

A Análise Discriminante utiliza rótulos conhecidos durante a construção da solução.

Na formulação de Fisher, esses rótulos determinam

$$\mathbf{T}_{\text{intra}} \quad \text{e} \quad \mathbf{T}_{\text{entre}}.$$

Na formulação probabilística, eles determinam quais observações caracterizam cada distribuição condicional

$$\mathbf{X} \mid C = k.$$

A técnica não constrói os grupos a partir dos dados. Se os rótulos utilizados não representarem as classes que se deseja discriminar ou classificar, a solução continuará descrevendo apenas os grupos fornecidos.

19.12.2 Normalidade e estrutura das covariâncias

A normalidade multivariada não é necessária para definir o critério populacional de Fisher,

$$J_F^{(P)}(\mathbf{a}),$$

nem sua versão amostral,

$$J_F(\mathbf{a}).$$

Na formulação probabilística geral, a regra de Bayes também não exige normalidade. A normalidade multivariada é introduzida na especialização da regra de Bayes que conduz à LDA e à QDA.

Na LDA,

$$\Sigma_1 = \cdots = \Sigma_K = \Sigma,$$

com

$$\Sigma \succ \mathbf{0}.$$

A matriz comum faz com que os termos quadráticos em $\mathbf{x}$ sejam iguais nas comparações entre classes e se cancelem, produzindo fronteiras lineares.

Na QDA,

$$\Sigma_k \succ \mathbf{0}, \quad k = 1, \dots, K,$$

e as matrizes podem diferir entre classes. Quando as matrizes das classes comparadas são distintas, os termos quadráticos em $\mathbf{x}$ não se cancelam em geral, e a fronteira pode ser quadrática.

A covariância comum é uma condição da formulação normal da LDA e também integra a formulação clássica de Fisher apresentada por Johnson e Wichern, que assume uma matriz de covariâncias populacional comum e de posto completo (Johnson; Wichern, 2002). O critério definido pela Equação 19.28 corresponde à extensão populacional adotada neste capítulo e utiliza, de forma mais geral, a dispersão média intragrupos Σ_W . Quando as covariâncias condicionais são comuns, $\Sigma_W = \Sigma$ e a relação direta com a orientação da LDA é recuperada.

19.12.3 Não singularidade e dimensão

A forma baseada em inversas do critério populacional de Fisher pressupõe

$$\Sigma_W \succ \mathbf{0}.$$

Essa condição garante

$$\mathbf{a}^\top \Sigma_W \mathbf{a} > 0$$

para todo

$$\mathbf{a} \neq \mathbf{0}$$

e permite utilizar

$$\Sigma_W^{-1} \quad \text{e} \quad \Sigma_W^{-1/2}.$$

A positividade definida de Σ_W é uma condição sobre a média ponderada das matrizes de covariâncias condicionais e não depende de normalidade.

Na formulação amostral,

$$\text{posto}(\mathbf{T}_{\text{intra}}) \leq \min(p, n - K). \quad (19.45)$$

Consequentemente,

$$n - K \geq p \quad (19.46)$$

é uma condição necessária para que

$$\mathbf{T}_{\text{intra}}$$

possa possuir posto completo.

Ela não é suficiente para um conjunto de dados arbitrário. Dependências lineares exatas entre as características dentro dos grupos podem tornar $\mathbf{T}_{\text{intra}}$ singular mesmo quando

$$n - K \geq p.$$

Quando

$$p > n - K,$$

a singularidade é inevitável.

Na LDA estimada,

$$\mathbf{S}_p = \frac{1}{n - K} \mathbf{T}_{\text{intra}},$$

de modo que

$$\text{posto}(\mathbf{S}_p) = \text{posto}(\mathbf{T}_{\text{intra}}).$$

A regra clássica estimada da LDA e a formulação amostral clássica de Fisher compartilham, portanto, a mesma condição de invertibilidade da dispersão intragrupos.

Na QDA, cada classe possui sua própria matriz de covariâncias amostral. Para a classe k ,

$$\text{posto}(\mathbf{S}_k) \leq \min(p, n_k - 1).$$

Assim,

$$n_k - 1 \geq p \quad (19.47)$$

é condição necessária para que $\mathbf{S}_k$ possa possuir posto completo. Essa condição deve ser satisfeita separadamente em cada classe.

A QDA estimada impõe, portanto, uma condição de posto separada em cada classe e se torna particularmente exigente em tamanho amostral quando p é elevado.

A não singularidade, entretanto, não garante estabilidade. O problema está relacionado ao número de condição definido na Definição 6.9. Quando algumas características são aproximadamente combinações lineares de outras, $\mathbf{T}_{\text{intra}}$, $\mathbf{S}_p$ ou alguma $\mathbf{S}_k$ podem permanecer invertíveis, mas apresentar autovalores muito pequenos. Nesse caso, suas inversas podem amplificar pequenas perturbações dos dados e tornar coeficientes e direções discriminantes sensíveis à amostra.

Esse problema deve ser distinguido da singularidade exata. Associação entre características é esperada em dados multivariados; quase dependência linear pode produzir mau condicionamento; dependência linear exata pode reduzir o posto das matrizes necessárias.

Quando as matrizes são singulares, as formulações clássicas baseadas em inversas e raízes quadradas inversas não estão definidas diretamente. Pseudoinversas, regularização e redução preliminar de dimensão correspondem a extensões que modificam essas formulações.

19.12.4 Independência das unidades de treinamento

As estatísticas

$$\bar{\mathbf{x}}_k, \quad \mathbf{S}_k \quad \text{e} \quad \mathbf{S}_p$$

podem ser calculadas a partir das observações sem exigir independência.

Para interpretar probabilisticamente essas estatísticas sob o esquema amostral clássico, as unidades de treinamento são tratadas como independentes e, dentro de cada classe, como observações da distribuição condicional especificada para essa classe.

Dependência temporal, espacial, longitudinal ou decorrente de agrupamentos viola a independência das unidades pressuposta pelo esquema amostral clássico e requer uma formulação probabilística que represente essa dependência. O critério algébrico de Fisher, isoladamente, não modela a dependência entre unidades.

19.12.5 Probabilidades *a priori* e perdas

As probabilidades

$$\pi_k = P(C = k)$$

desempenham funções diferentes nas duas formulações do capítulo.

Na classificação probabilística, elas representam as probabilidades *a priori* das classes e entram nas funções LDA e QDA pelo termo

$$\log \pi_k.$$

Na extensão populacional adotada neste capítulo, as probabilidades π_k aparecem como pesos na construção de

$$\Sigma_W \quad \text{e} \quad \Sigma_B.$$

Nesse critério, elas ponderam as dispersões populacionais das classes e não determinam uma ação de classificação.

Na formulação amostral de Fisher, o critério utiliza $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$, cujos pesos decorrem dos tamanhos observados n_k . A razão n_k/n coincide com a estimativa empírica de π_k definida pela Equação 19.17 somente quando a amostra de treinamento representa a mistura populacional das classes.

A função de perda pertence ao problema de decisão e não ao critério geométrico de Fisher. Sob perda zero-um, a regra de Bayes reduz-se à escolha da maior probabilidade posterior; quando diferentes erros possuem consequências distintas, a decisão ótima pode mudar mesmo que as densidades condicionais e as probabilidades *a priori* permaneçam inalteradas.

19.12.6 Sobreposição entre as classes

Mesmo quando os parâmetros populacionais são conhecidos e o modelo probabilístico está corretamente especificado, a classificação pode apresentar erro.

Se duas classes atribuem densidade positiva à mesma região do espaço das características, uma observação nessa região não determina unicamente sua classe de origem.

A regra de Bayes escolhe a ação de menor risco condicional, mas esse risco mínimo pode ser positivo. Sob perda zero-um, a probabilidade global de classificação incorreta alcançada pela regra de Bayes é denominada **erro de Bayes**.

Quando as distribuições das classes se sobrepõem, esse erro pode ser positivo mesmo que os parâmetros populacionais sejam conhecidos exatamente. Existe, portanto, uma parcela do erro de classificação associada à própria dificuldade de separar as populações no espaço das características.

O erro de Bayes deve ser distinguido do erro populacional da regra estimada, isto é, da probabilidade de classificação incorreta que a regra obtida da amostra de treinamento apresenta em novas unidades da população de aplicação. Sob perda zero-um, para uma regra estimada fixada, esse erro não pode ser inferior ao erro de Bayes; a diferença entre ambos é o excesso de erro em relação à regra de Bayes.

Validação cruzada, conjunto de teste *holdout* e amostra independente estimam o desempenho da regra em regimes que evitam, em graus diferentes, avaliar exclusivamente as observações utilizadas no ajuste. Matrizes de classificação e medidas de desempenho resumem os erros produzidos nesses regimes; ver Seção 19.15.

19.13 Relações com outras técnicas

Quando a MANOVA compara os vetores de médias correspondentes à mesma partição em grupos utilizada por Fisher, a correspondência formalizada na Equação 19.40 faz com que as duas formulações conduzam ao mesmo problema de autovalores generalizados. A diferença está no objetivo estatístico: o Capítulo 18 utiliza as raízes para construir critérios de teste, enquanto Fisher utiliza os autovetores associados para representar a separação entre grupos.

A Análise Discriminante também se distingue da Capítulo 14 e do Capítulo 16 pelo papel dos grupos na formulação. Em Fisher, os grupos são conhecidos previamente e seus rótulos participam da construção das direções discriminantes.

19.13.1 Análise de Componentes Principais

O Capítulo 14 e a formulação de Fisher constroem combinações lineares, mas utilizam critérios diferentes.

Na ACP, as direções são determinadas pela variabilidade total. Em Fisher, a direção genérica $\mathbf{a}$ é avaliada por

$$J_F(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}}{\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a}},$$

de modo que a separação entre os grupos é comparada com a dispersão existente dentro deles.

A Tabela 19.4 sintetiza essa distinção.

Tabela 19.4: Comparação entre ACP e a formulação de Fisher.

Aspecto	ACP	Fisher
informação sobre grupos	não utilizada	utilizada
objeto matricial principal	covariância ou correlação total	dispersões entre e dentro dos grupos
critério	variabilidade total	separação entre grupos relativa à dispersão intragrupos
representação	não supervisionada em relação aos grupos	supervisionada
dimensão máxima não nula	limitada pelo posto da matriz analisada	$\min(p, K - 1)$
interpretação das direções	variabilidade	separação relativa

Uma direção de elevada variabilidade total não precisa apresentar elevada capacidade de separação entre grupos. Fisher utiliza os rótulos dos grupos para construir $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$, enquanto a ACP não utiliza esses rótulos na determinação das componentes.

19.13.2 Análise de Agrupamentos

A Análise Discriminante e o Capítulo 16 utilizam objetos como centroides, distâncias e dispersões, mas partem de problemas distintos.

Na Análise Discriminante, os grupos são conhecidos e seus rótulos participam da construção das regras de classificação ou das direções de Fisher. Na Análise de Agrupamentos, os grupos não são fornecidos previamente e devem ser construídos a partir de critérios de proximidade ou dispersão.

Na Análise Discriminante, os rótulos dos grupos fazem parte dos dados de entrada. Na Análise de Agrupamentos, os grupos são construídos pela própria análise.

19.14 Aprofundamentos teóricos

Leitura de aprofundamento

Esta parte aprofunda a base decisória, probabilística, algébrica e espectral da Análise Discriminante. São examinadas a formulação por perdas e risco, a relação entre separação de Mahalanobis e erro de classificação sob normalidade, a forma explícita da fronteira quadrática, a decomposição populacional da covariância por grupos, as relações

populacional e amostral entre Fisher e LDA e as condições de identificação das direções discriminantes.

19.14.1 Perdas e risco de classificação

A regra de máxima probabilidade posterior obtida no núcleo é a regra de Bayes sob perda zero-um, na qual uma classificação correta recebe perda 0 e uma classificação incorreta recebe perda 1. Com uma função de perda geral, a decisão ótima escolhe a ação que minimiza a perda esperada posterior, denominada risco condicional.

Definição 19.11 (Perda de classificação). Considere o conjunto de ações

$$\mathcal{A} = \{1, \dots, K\}.$$

Uma **função de perda de classificação** é uma função

$$L : \mathcal{A} \times \{1, \dots, K\} \longrightarrow [0, \infty)$$

tal que

$$L(a, k)$$

quantifica a consequência de escolher a ação a quando a classe verdadeira é k .

Os valores

$$L(k, k)$$

correspondem às classificações corretas, enquanto

$$L(a, k), \quad a \neq k,$$

correspondem aos diferentes tipos de erro. A função L pode atribuir perdas distintas a diferentes classificações incorretas.

Definição 19.12 (Risco condicional de classificação). Para uma observação $\mathbf{x}$ na qual as probabilidades posteriores estão definidas, o **risco condicional** de escolher a ação

$$a \in \mathcal{A}$$

é

$$R(a | \mathbf{x}) = \sum_{k=1}^K L(a, k) P(\mathbf{C} = k | \mathbf{X} = \mathbf{x}). \quad (19.48)$$

O risco condicional é a perda esperada associada a uma ação depois de observadas as características $\mathbf{x}$. Cada perda $L(a, k)$ é ponderada pela probabilidade posterior de que k seja a classe verdadeira.

Para uma regra de classificação

$$\psi : \mathbb{R}^p \longrightarrow \mathcal{A},$$

seu risco global é

$$R(\psi) = E[L(\psi(\mathbf{X}), \mathbf{C})]. \quad (19.49)$$

Pela lei da esperança total,

$$R(\psi) = E[R(\psi(\mathbf{X}) | \mathbf{X})].$$

Assim, escolher em cada observação uma ação que minimize o risco condicional também minimiza o risco global. O menor risco alcançável é o **risco de Bayes**,

$$R_B = E\left[\min_{a \in \mathcal{A}} R(a | \mathbf{X})\right]. \quad (19.50)$$

Sob perda zero-um, R_B coincide com a probabilidade global de classificação incorreta da regra de Bayes.

Definição 19.13 (Regra de Bayes para classificação). Para cada observação $\mathbf{x}$, defina o conjunto de ações que minimizam o risco condicional por

$$\mathcal{A}_B(\mathbf{x}) = \arg \min_{a \in \mathcal{A}} R(a | \mathbf{x}). \quad (19.51)$$

Uma **regra de Bayes** é qualquer função

$$\psi_B : \mathbb{R}^p \longrightarrow \mathcal{A}$$

tal que

$$\psi_B(\mathbf{x}) \in \mathcal{A}_B(\mathbf{x})$$

sempre que os riscos condicionais estejam definidos.

Quando mais de uma ação minimiza o risco, uma regra de desempate pode ser especificada para produzir uma classificação única.

A regra de Bayes depende conjuntamente das distribuições condicionais, das probabilidades *a priori* e da função de perda. Sob perda zero-um, minimizar o risco condicional equivale a maximizar a probabilidade posterior, conforme a Equação 19.3. Com perdas assimétricas, a classe de maior probabilidade posterior não precisa ser a ação que minimiza o risco (Anderson, 2003).

19.14.2 Erro de classificação e separação de Mahalanobis

Considere duas classes sob o modelo normal da LDA,

$$\mathbf{X} | (C = k) \sim N_p(\mu_k, \Sigma), \quad k = 1, 2,$$

com

$$\Sigma \succ \mathbf{0}$$

e

$$\mu_1 \neq \mu_2.$$

A separação entre os vetores de médias na métrica definida pela matriz de covariâncias comum pode ser expressa por

$$\Delta^2 = (\mu_1 - \mu_2)^\top \Sigma^{-1} (\mu_1 - \mu_2). \quad (19.52)$$

Assim,

$$\Delta = d_M(\mu_1, \mu_2; \Sigma)$$

é a distância de Mahalanobis entre os vetores de médias das duas classes.

Sob perda zero-um, a comparação entre as duas classes pode ser realizada pela diferença entre suas funções discriminantes lineares de classe,

$$D(\mathbf{x}) = \delta_1(\mathbf{x}) - \delta_2(\mathbf{x}).$$

Pelas funções discriminantes lineares de classe definidas na Equação 19.6, essa diferença pode ser escrita como

$$D(\mathbf{x}) = (\mu_1 - \mu_2)^\top \Sigma^{-1} \left[\mathbf{x} - \frac{\mu_1 + \mu_2}{2} \right] + \log \frac{\pi_1}{\pi_2}. \quad (19.53)$$

A observação é atribuída à classe 1 quando

$$D(\mathbf{x}) > 0$$

e à classe 2 quando

$$D(\mathbf{x}) < 0.$$

Como $D(\mathbf{X})$ é uma combinação linear de um vetor normal, sua distribuição condicional também é normal. Se a observação pertence à classe 1,

$$D(\mathbf{X}) \mid (\mathbf{C} = 1) \sim N \left(\frac{\Delta^2}{2} + \log \frac{\pi_1}{\pi_2}, \Delta^2 \right),$$

enquanto, para a classe 2,

$$D(\mathbf{X}) \mid (\mathbf{C} = 2) \sim N \left(-\frac{\Delta^2}{2} + \log \frac{\pi_1}{\pi_2}, \Delta^2 \right). \quad (19.54)$$

Se Φ denota a função de distribuição acumulada da normal padrão, a probabilidade condicional de classificar incorretamente uma observação da classe 1 é

$$P[\psi_B(\mathbf{X}) = 2 \mid \mathbf{C} = 1] = \Phi\left(-\frac{\Delta}{2} - \frac{1}{\Delta} \log \frac{\pi_1}{\pi_2}\right), \quad (19.55)$$

e, para uma observação da classe 2,

$$P[\psi_B(\mathbf{X}) = 1 \mid \mathbf{C} = 2] = \Phi\left(-\frac{\Delta}{2} + \frac{1}{\Delta} \log \frac{\pi_1}{\pi_2}\right). \quad (19.56)$$

Sob perda zero-um, o erro global da regra de Bayes é, portanto,

$$\begin{aligned} R_B &= \pi_1 \Phi\left(-\frac{\Delta}{2} - \frac{1}{\Delta} \log \frac{\pi_1}{\pi_2}\right) \\ &\quad + \pi_2 \Phi\left(-\frac{\Delta}{2} + \frac{1}{\Delta} \log \frac{\pi_1}{\pi_2}\right). \end{aligned} \quad (19.57)$$

Quando as probabilidades *a priori* são iguais,

$$\pi_1 = \pi_2 = \frac{1}{2},$$

os dois tipos de erro possuem a mesma probabilidade,

$$P[\psi_B(\mathbf{X}) = 2 \mid \mathbf{C} = 1] = P[\psi_B(\mathbf{X}) = 1 \mid \mathbf{C} = 2] = \Phi\left(-\frac{\Delta}{2}\right),$$

e o erro de Bayes reduz-se a

$$R_B = \Phi\left(-\frac{\Delta}{2}\right). \quad (19.58)$$

Para probabilidades *a priori* iguais, a Equação 19.58 mostra que R_B é uma função estritamente decrescente de Δ . Em particular,

$$\Delta \rightarrow 0 \quad \Rightarrow \quad R_B \rightarrow \frac{1}{2},$$

enquanto

$$\Delta \rightarrow \infty \quad \Rightarrow \quad R_B \rightarrow 0.$$

Sob normalidade, covariância comum, perda zero-um e parâmetros populacionais conhecidos, maior distância de Mahalanobis entre os vetores de médias implica menor erro de Bayes. Com probabilidades *a priori* desiguais, as probabilidades condicionais de erro dependem também de $\log(\pi_1/\pi_2)$, que desloca a fronteira de classificação e pode produzir erros diferentes nas duas classes (Anderson, 2003).

O valor R_B é o menor erro populacional possível sob o modelo e a perda considerados. Quando μ_1 , μ_2 e Σ são substituídos por estimativas, obtém-se uma regra amostral cujo erro populacional é, em geral, maior que R_B .

19.14.3 Forma explícita da fronteira quadrática

Na QDA, a fronteira entre as classes k e h contém termos quadrático, linear e constante. Na Equação 19.15, esses termos são determinados por

$$\mathbf{A}_{kh} = \frac{1}{2} (\Sigma_h^{-1} - \Sigma_k^{-1}),$$

$$\mathbf{b}_{kh} = \Sigma_k^{-1} \mu_k - \Sigma_h^{-1} \mu_h$$

e

$$\begin{aligned} c_{kh} = & -\frac{1}{2} \mu_k^\top \Sigma_k^{-1} \mu_k + \frac{1}{2} \mu_h^\top \Sigma_h^{-1} \mu_h \\ & - \frac{1}{2} \log |\Sigma_k| + \frac{1}{2} \log |\Sigma_h| + \log \frac{\pi_k}{\pi_h}. \end{aligned}$$

Assim, a diferença entre as inversas das matrizes de covariâncias determina o termo quadrático, a diferença $\Sigma_k^{-1} \mu_k - \Sigma_h^{-1} \mu_h$ determina o termo linear, e os vetores de médias, os determinantes das matrizes de covariâncias e as probabilidades *a priori* determinam o termo constante.

Se

$$\Sigma_k = \Sigma_h,$$

então

$$\mathbf{A}_{kh} = \mathbf{0},$$

recuperando-se uma fronteira linear.

19.14.4 Decomposição da covariância por grupos

A identidade $\text{Cov}(\mathbf{X}) = \Sigma_W + \Sigma_B$ decorre da lei da covariância total aplicada ao condicionamento pela variável de classe C . A primeira parcela é a média das covariâncias condicionais, e a segunda é a covariância dos vetores de médias condicionais.

Escreva

$$\mathbf{X} - \mu = (\mathbf{X} - \mu_C) + (\mu_C - \mu),$$

em que

$$\mu_C = E(\mathbf{X} \mid C).$$

Como

$$E[\mathbf{X} - \mu_C \mid C] = \mathbf{0},$$

os termos cruzados possuem esperança nula. Assim,

$$\text{Cov}(\mathbf{X}) = E[\text{Cov}(\mathbf{X} \mid C)] + \text{Cov}[E(\mathbf{X} \mid C)],$$

o que fornece

$$\text{Cov}(\mathbf{X}) = \Sigma_W + \Sigma_B.$$

19.14.5 Relação com a discriminação linear normal

Considere a formulação normal da LDA especificada na Equação 19.5 para duas classes,

$$K = 2,$$

com matriz de covariâncias comum

$$\Sigma \succ \mathbf{0}.$$

Na LDA, o vetor normal à fronteira entre as duas classes é

$$\Sigma^{-1}(\mu_1 - \mu_2), \tag{19.59}$$

conforme a Equação 19.9.

Sob covariância condicional comum,

$$\Sigma_W = \pi_1 \Sigma + \pi_2 \Sigma = \Sigma.$$

Substituindo na Equação 19.44,

$$\mathbf{a}_F \propto \Sigma^{-1} (\mu_1 - \mu_2).$$

Assim, para duas populações com covariância comum, a direção populacional de Fisher é paralela ao vetor normal da fronteira da LDA.

Essa coincidência refere-se apenas à **orientação** da direção de Fisher e do vetor normal da fronteira da LDA; ela não torna equivalentes os dois problemas estatísticos.

Fisher procura uma direção que maximize

$$\frac{\mathbf{a}^\top \Sigma_B \mathbf{a}}{\mathbf{a}^\top \Sigma_W \mathbf{a}}.$$

A LDA utiliza as distribuições condicionais, as probabilidades *a priori* e a função de perda para construir uma regra de classificação.

Além do vetor normal que determina sua orientação, a fronteira da LDA depende dos termos constantes das funções discriminantes lineares de classe,

$$-\frac{1}{2} \mu_k^\top \Sigma^{-1} \mu_k + \log \pi_k.$$

Consequentemente, mudanças nas probabilidades *a priori* podem deslocar a fronteira sem modificar sua orientação. Com funções de perda diferentes da perda zero-um, a regra ótima também pode mudar sem alterar o critério geométrico de Fisher.

19.14.6 Relação amostral entre Fisher e LDA

Para dois grupos, a mesma coincidência de orientação aparece na versão estimada. Quando as duas formulações são construídas a partir da mesma amostra de treinamento, a matriz de covariâncias agrupada da LDA é proporcional à matriz de dispersão intragrupos utilizada por Fisher. O vetor normal estimado da fronteira da LDA e a direção amostral de Fisher são, portanto, proporcionais.

Na amostra, a Equação 19.16 fornece

$$\mathbf{S}_p = \frac{1}{n - K} \mathbf{T}_{\text{intra}}.$$

Consequentemente,

$$\mathbf{S}_p^{-1} = (n - K) \mathbf{T}_{\text{intra}}^{-1},$$

quando as duas matrizes são não singulares.

Para

$$K = 2,$$

segue que

$$\mathbf{S}_p^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2) \propto \mathbf{T}_{\text{intra}}^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2). \quad (19.60)$$

Assim, quando a mesma estimativa agrupada de covariâncias é utilizada, a orientação estimada da fronteira da LDA coincide, até escala, com a direção amostral de Fisher.

A regra estimada da LDA não se reduz a essa direção. Para duas classes, a diferença $\hat{\delta}_1(\mathbf{x}) - \hat{\delta}_2(\mathbf{x})$ contém, além do vetor normal proporcional à direção de Fisher, termos constantes formados pelas médias estimadas e pelas probabilidades *a priori* adotadas; esses termos determinam a posição da fronteira.

19.14.7 Identificação das direções discriminantes

As direções de Fisher apresentam as indeterminações de sinal e multiplicidade do problema de autovalores generalizados descritas na Seção 18.9.4. Na Análise Discriminante, essas indeterminações referem-se aos autovetores generalizados de

$$(\mathbf{T}_{\text{entre}}, \mathbf{T}_{\text{intra}})$$

e ao subespaço discriminante que eles geram.

Para uma raiz positiva simples,

$$\lambda_j,$$

a direção normalizada

$$\alpha_j$$

satisfaz

$$\mathbf{T}_{\text{entre}} \alpha_j = \lambda_j \mathbf{T}_{\text{intra}} \alpha_j$$

e

$$\alpha_j^\top \mathbf{T}_{\text{intra}} \alpha_j = 1.$$

A normalização fixa a escala, mas permanece a indeterminação de sinal:

$$\alpha_j \quad \text{e} \quad -\alpha_j$$

representam o mesmo eixo discriminante.

A mudança de sinal transforma

$$z_j(\mathbf{x})$$

em

$$-z_j(\mathbf{x}),$$

sem modificar o subespaço nem as distâncias entre observações ou entre centroides projetados ao longo do eixo.

Quando uma raiz positiva possui multiplicidade maior que 1, as direções individuais associadas não são únicas. Como na Seção 18.9.4, diferentes bases ortonormais na métrica induzida por $\mathbf{T}_{\text{intra}}$ representam o mesmo autoespaço. Na formulação de Fisher, o objeto identificado é o subespaço discriminante associado à raiz repetida, e não uma base particular de direções.

19.15 Aprofundamentos metodológicos e aplicados

Leitura de aprofundamento

Esta parte trata das decisões de condução, interpretação e avaliação da Análise Discriminante: definição das probabilidades *a priori* e das perdas, avaliação das condições da análise, escolha entre LDA e QDA, interpretação das funções discriminantes e dos centroides, avaliação da classificação e correspondência com a implementação utilizada.

19.15.1 Definição das probabilidades *a priori* e consequências dos erros

A regra estimada requer probabilidades *a priori* para as classes. Os valores utilizados para essas probabilidades devem ser definidos antes da avaliação do desempenho da classificação, pois participam da própria regra e podem modificar as fronteiras e as classes atribuídas às observações.

Quando as proporções populacionais das classes são conhecidas ou podem ser estimadas por dados externos referentes à população na qual a regra será aplicada, esses valores podem ser utilizados como probabilidades *a priori*. As proporções observadas na amostra de treinamento podem cumprir essa função quando o mecanismo de amostragem permite interpretá-las como estimativas das proporções populacionais. Se os tamanhos dos grupos foram fixados pelo delineamento, balanceados intencionalmente ou obtidos por outro mecanismo que não reproduz a frequência das classes na população, as proporções amostrais não possuem essa interpretação.

Probabilidades iguais podem ser utilizadas quando se decide não incorporar à regra diferenças conhecidas nas frequências das classes ou quando as proporções populacionais não são conhecidas nem estimadas por dados externos. Essa escolha não implica que as classes sejam igualmente frequentes na população; ela atribui o mesmo peso *a priori* às classes na regra.

Quando diferentes tipos de erro possuem consequências distintas, a avaliação da regra não deve se limitar à proporção total de classificações corretas. A função de perda definida na Definição 19.11 representa essas diferenças por $L(a, k)$, a perda associada à ação a quando k é a classe verdadeira. Na condução da análise, as perdas devem ser definidas a partir do problema de decisão, e não escolhidas depois de observados os resultados da classificação.

19.15.2 Avaliação das condições da análise

Na LDA e na QDA normais, a hipótese de normalidade refere-se às distribuições das características condicionadas à classe (Johnson; Wichern, 2002). A avaliação deve, portanto, ser realizada separadamente dentro dos grupos. Observações atípicas podem alterar $\bar{\mathbf{x}}_k$, $\mathbf{S}_k$ e, na LDA, $\mathbf{S}_p$, modificando as funções e as fronteiras estimadas; por isso, sua presença deve ser examinada (Hair et al., 2009).

Na LDA, a igualdade das matrizes de covariâncias pode ser examinada pela comparação de $\mathbf{S}_1, \dots, \mathbf{S}_K$ e pelo teste M de Box. Nesse teste,

$$H_0 : \Sigma_1 = \dots = \Sigma_K.$$

A rejeição de H_0 fornece evidência contra a matriz de covariâncias comum da LDA; a não rejeição não demonstra igualdade das matrizes. O teste M de Box é uma ferramenta para examinar essa hipótese (Hair et al., 2009). Testes de homogeneidade das matrizes de covariâncias são sensíveis a desvios da normalidade multivariada (Johnson; Wichern, 2002), de modo que sua interpretação deve ser acompanhada da avaliação das distribuições condicionais.

As condições de posto da LDA e da QDA estão estabelecidas em Equação 19.46 e Equação 19.47. Mesmo com posto completo, autovalores muito pequenos de $\mathbf{S}_p$ ou de alguma $\mathbf{S}_k$ podem produzir inversões numericamente instáveis, conforme discutido em Definição 6.9. A QDA exige essa avaliação separadamente em cada classe.

A independência das unidades decorre do delineamento e do mecanismo de amostragem. Dependência temporal, espacial, longitudinal ou por agrupamentos não é diagnosticada pela matriz de classificação e exige uma formulação que represente essa dependência.

19.15.3 Tamanho amostral e estabilidade das estimativas

As condições de posto estabelecem requisitos algébricos mínimos para que as matrizes utilizadas pela LDA, pela QDA e pelo critério de Fisher possam ser invertidas. Elas não constituem regras gerais de tamanho amostral.

A estabilidade das médias, das covariâncias, das direções discriminantes e das probabilidades de classificação depende também da quantidade de observações disponível em relação ao número de características. Essa avaliação deve ser realizada por classe, pois $\bar{\mathbf{x}}_k$ e $\mathbf{S}_k$ são estimados a partir das observações pertencentes ao grupo k . A classe menos numerosa pode, portanto, limitar a precisão da análise mesmo quando o tamanho amostral total é elevado.

A QDA é mais exigente nesse aspecto porque estima uma matriz de covariâncias distinta para cada classe, enquanto a LDA reúne a informação intragrupos na estimação de $\mathbf{S}_p$ (Johnson; Wichern, 2002). As razões entre número de observações e número de características e os tamanhos mínimos por classe apresentados como orientações práticas não devem ser tratados como

condições universais. A avaliação deve considerar conjuntamente os tamanhos das classes, p , o condicionamento de $\mathbf{S}_p$ ou das matrizes $\mathbf{S}_k$ e a estabilidade das classificações e das direções discriminantes.

Quando a amostra é dividida em conjuntos de treinamento e teste, as condições necessárias à estimação devem ser avaliadas no conjunto de treinamento, e não apenas na amostra original. O conjunto de teste também deve conter observações suficientes em cada classe para que as proporções de classificação correta por classe sejam interpretáveis.

19.15.4 Escolha entre LDA e QDA

A LDA estima uma única matriz de covariâncias, com

$$\frac{p(p+1)}{2}$$

parâmetros distintos de covariância. A QDA estima uma matriz para cada classe, totalizando

$$K \frac{p(p+1)}{2}$$

parâmetros de covariância.

Sob covariância comum, a LDA utiliza as observações de todas as classes na estimação de $\mathbf{S}_p$. A QDA permite dispersões, correlações e orientações diferentes entre as classes, mas estima $\mathbf{S}_k$ separadamente para cada grupo. Essa diferença torna a QDA mais exigente em tamanho amostral e mais sensível à instabilidade das matrizes de covariâncias (Johnson; Wichern, 2002).

Sob normalidade multivariada, diferenças populacionais entre as matrizes de covariâncias favorecem a fronteira quadrática da QDA. A rejeição do teste M de Box, entretanto, não determina automaticamente a escolha da QDA. A regra quadrática é particularmente sensível a desvios da normalidade, e diferenças entre matrizes amostrais também contêm variabilidade de estimação (Johnson; Wichern, 2002).

Quando LDA e QDA podem ser estimadas de forma estável, a comparação deve utilizar o desempenho em observações que não participaram do ajuste. As taxas de erro devem ser calculadas sob o mesmo esquema de validação, conforme Seção [19.15.8](#).

19.15.5 Importância e avaliação das funções discriminantes de Fisher

A raiz λ_j mede a separação entre os grupos na direção α_j relativamente à dispersão intragrupos, conforme a Equação 19.34. A razão definida na Equação 19.35,

$$\frac{\lambda_j}{\sum_{\ell=1}^r \lambda_\ell},$$

expressa a participação da função j na soma das raízes discriminantes positivas. Essa razão não corresponde à proporção da variância total das características.

A **correlação canônica** associada à função j pode ser relacionada diretamente às dispersões de Fisher. Pela normalização da Equação 19.33,

$$\alpha_j^\top \mathbf{T}_{\text{intra}} \alpha_j = 1,$$

e, pela Equação 19.34,

$$\alpha_j^\top \mathbf{T}_{\text{entre}} \alpha_j = \lambda_j.$$

Como

$$\mathbf{T}_{\text{total}} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

segue que

$$\alpha_j^\top \mathbf{T}_{\text{total}} \alpha_j = 1 + \lambda_j.$$

A razão entre a dispersão entre grupos e a dispersão total na direção α_j é, portanto,

$$\frac{\lambda_j}{1 + \lambda_j}.$$

Essa razão é o quadrado da correlação canônica associada à função discriminante:

$$\left[r_j^{(\text{can})} \right]^2 = \frac{\lambda_j}{1 + \lambda_j},$$

ou, equivalentemente,

$$r_j^{(\text{can})} = \sqrt{\frac{\lambda_j}{1 + \lambda_j}}. \quad (19.61)$$

Como a transformação é estritamente crescente em λ_j , a correlação canônica preserva a ordenação das raízes e expressa a mesma separação em uma escala limitada ao intervalo $(0, 1)$. Ela não deve ser confundida com as cargas discriminantes, que são correlações entre características observadas e escores discriminantes.

A separação remanescente depois das primeiras $j - 1$ funções pode ser resumida pela lambda de Wilks sequencial,

$$\Lambda_j = \prod_{\ell=j}^{r_F} \frac{1}{1 + \lambda_\ell}. \quad (19.62)$$

Para $j = 1$, Λ_1 utiliza todas as raízes positivas. Para $j > 1$, o produto utiliza somente as raízes das funções ainda não retiradas da sequência. O teste associado avalia se permanece separação populacional entre os grupos depois das primeiras $j - 1$ funções. Valores menores de Λ_j correspondem a maior separação nas funções incluídas no produto.

A fórmula de Λ_j não determina, isoladamente, seu valor p . A calibração depende do modelo, das dimensões e dos graus de liberdade. Na implementação utilizada neste capítulo, os testes sequenciais são calibrados por uma aproximação qui-quadrado de Bartlett.

Raiz discriminante, participação relativa, correlação canônica, lambda de Wilks e erro de classificação descrevem propriedades distintas: separação em uma direção, participação dessa direção na soma das raízes, reescala da raiz, evidência inferencial de separação remanescente e desempenho preditivo, respectivamente.

19.15.6 Coeficientes das funções discriminantes de Fisher

A função discriminante de Fisher

$$z_j(\mathbf{x}) = \alpha_j^\top (\mathbf{x} - \bar{\mathbf{x}})$$

é determinada pela direção α_j . Seus coeficientes podem ser expressos sob diferentes normalizações, e sua interpretação pode ser complementada pelas correlações entre as características originais e os escores discriminantes.

Os elementos de α_j são os coeficientes utilizados para construir a coordenada discriminante

$$z_j(\mathbf{x}) = \alpha_j^\top (\mathbf{x} - \bar{\mathbf{x}}).$$

Esses coeficientes dependem da escala das características, das matrizes $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$ que definem o problema de autovalores generalizados e da normalização adotada para a direção. O valor absoluto de um coeficiente, considerado isoladamente, não fornece, em geral, uma medida direta da importância da característica correspondente.

Uma mesma direção discriminante pode ser expressa em diferentes normalizações. Uma delas utiliza

$$\tilde{\alpha}_j = \frac{\alpha_j}{\|\alpha_j\|_2}. \quad (19.63)$$

Esse reescalonamento modifica a escala dos coeficientes, mas não a direção discriminante representada. Em geral, ele não preserva a condição de norma unitária na métrica intragrupos, $\tilde{\alpha}_j^\top \mathbf{T}_{\text{intra}} \tilde{\alpha}_j = 1$, correspondente à normalização da Equação 19.32.

Os **coeficientes normalizados** correspondem, portanto, a outra normalização da mesma direção discriminante. Eles não constituem uma medida de associação entre cada característica e a função discriminante e não devem ser confundidos com as cargas discriminantes.

As **cargas discriminantes**, também denominadas **correlações de estrutura**, são definidas, na formulação clássica, pelas correlações intragrupos agrupadas entre cada característica e a função discriminante.

Se $\mathbf{e}_h$ é o vetor canônico associado à característica h e $\mathbf{S}_p$ é a matriz de covariâncias intragrupos agrupada, então

$$r_{hj}^{(\text{estrutura})} = \frac{\mathbf{e}_h^\top \mathbf{S}_p \alpha_j}{\sqrt{(\mathbf{S}_p)_{hh} \alpha_j^\top \mathbf{S}_p \alpha_j}}. \quad (19.64)$$

Essa quantidade é a correlação entre a característica X_h e o escore discriminante z_j calculada a partir da covariância intragrupos agrupada. Dessa forma, ela descreve a associação da característica com a função discriminante sem incorporar a covariação decorrente apenas das diferenças entre os centroides dos grupos.

Os coeficientes da direção e as cargas discriminantes possuem interpretações distintas. Os elementos de α_j determinam a combinação linear que produz $z_j(\mathbf{x})$; as cargas discriminantes medem a associação intragrupos de cada característica com essa função. Como as características podem ser correlacionadas, um coeficiente de pequena magnitude pode coexistir com uma carga elevada.

Os coeficientes normalizados representam a mesma direção em outra escala. Eles não alteram o subespaço discriminante nem substituem as cargas discriminantes como medidas de associação intragrupos entre características e funções.

19.15.7 Centroides e interpretação dos grupos

O centroide $\bar{z}_{kj}$ definido na Equação 19.39 é a média dos escores discriminantes do grupo k na função j . Para uma função fixa, a comparação de

$$\bar{z}_{1j}, \dots, \bar{z}_{Kj}$$

mostra quais médias de grupos estão mais separadas ao longo da direção α_j (Hair et al., 2009).

Como os escores foram centralizados pela média global,

$$\sum_{k=1}^K n_k \bar{z}_{kj} = 0, \quad j = 1, \dots, r_F. \quad (19.65)$$

A origem corresponde, portanto, à média global no espaço discriminante.

As cargas discriminantes e os centroides têm funções diferentes na interpretação. As cargas descrevem a associação entre cada característica e a função discriminante; os centroides localizam os grupos nessa função. O sinal de uma carga indica a direção da associação com o escore, mas não determina, isoladamente, a ordenação das médias dos grupos na característica original. Essa ordenação deve ser verificada diretamente em $\bar{\mathbf{x}}_1, \dots, \bar{\mathbf{x}}_K$.

O sinal de α_j é arbitrário. A substituição

$$\alpha_j \mapsto -\alpha_j$$

inverte os sinais dos escores, dos centroides e das cargas sem alterar as distâncias ou a separação representada. Por isso, a interpretação utiliza as posições relativas dos grupos e as associações entre características e funções, e não o sinal isolado de um centroide.

Quando $r_F \geq 2$, os centroides podem ser representados conjuntamente nas primeiras funções discriminantes. As distâncias nesse espaço descrevem a separação entre médias projetadas dos grupos; não representam, por si mesmas, probabilidades de classificação correta.

19.15.8 Erro aparente e erro em novas observações

A formulação da LDA e da QDA determina como construir uma regra de classificação. Avaliar o desempenho dessa regra constitui um problema adicional. Em particular, o erro observado nas mesmas unidades utilizadas para estimar a regra deve ser distinguido do erro obtido em observações que não participaram da estimação.

Considere uma amostra de treinamento formada por pares

$$(\mathbf{x}_i, c_i), \quad i = 1, \dots, n,$$

utilizados para construir uma regra $\hat{\psi}$. A proporção de classificações incorretas calculada nas próprias observações utilizadas no ajuste é o **erro aparente**,

$$\widehat{R}_{\text{aparente}} = \frac{1}{n} \sum_{i=1}^n \mathbb{1} \{ \hat{\psi}(\mathbf{x}_i) \neq c_i \}, \quad (19.66)$$

em que $\mathbb{1}\{\cdot\}$ é a função indicadora.

Esse erro descreve o desempenho da regra nas unidades que também contribuíram para estimar seus parâmetros e tende a ser otimista como estimativa do erro em novas observações, porque os mesmos dados participam do ajuste e da avaliação (Johnson; Wichern, 2002).

Considere agora um conjunto de teste *holdout*, formado por m pares

$$(\mathbf{x}_i^*, c_i^*), \quad i = 1, \dots, m,$$

reservados antes do ajuste e não utilizados na estimação da regra. A proporção de classificações incorretas nesse conjunto é

$$\widehat{R}_{\text{teste}} = \frac{1}{m} \sum_{i=1}^m \mathbb{1} \{ \hat{\psi}(\mathbf{x}_i^*) \neq c_i^* \}. \quad (19.67)$$

O erro aparente descreve o comportamento da regra nas observações utilizadas em sua construção, enquanto o erro de teste *holdout* descreve seu comportamento na parcela da amostra reservada para avaliação. O conjunto *holdout* não deve participar da estimação da regra nem de decisões orientadas pelo desempenho observado nesse próprio conjunto.

Uma amostra independente, obtida separadamente dos dados utilizados para construir e selecionar a regra, constitui outro regime de avaliação. Quando representa a população na qual a regra será aplicada, seu erro de classificação fornece uma avaliação externa do desempenho preditivo.

Na validação cruzada, cada observação ou subconjunto é classificado por uma regra estimada sem utilizar, naquele ajuste, as observações que estão sendo avaliadas. As observações podem participar dos ajustes correspondentes às demais partições, mas nenhuma observação deve participar da estimação da regra utilizada para produzir sua própria classificação. Esse procedimento não equivale a uma validação externa e não corrige limitações de representatividade da amostra.

A avaliação preditiva deve preservar a distinção entre erro aparente, erro obtido por validação cruzada, erro em um conjunto de teste *holdout* e erro observado em uma amostra independente. Esses valores correspondem a regimes de avaliação diferentes e não devem ser apresentados como estimativas intercambiáveis.

19.15.9 Matriz de classificação e desempenho por classe

A matriz de classificação cruza a classe observada com a classe atribuída pela regra. Os elementos da diagonal correspondem às classificações corretas, enquanto os elementos fora da diagonal mostram quais classes estão sendo confundidas.

A proporção global de acertos resume o desempenho da regra, mas pode ocultar diferenças entre as classes. As proporções de acerto calculadas dentro de cada classe medem a frequência com que observações daquela classe são classificadas corretamente e permitem identificar classes com desempenho particularmente baixo.

A proporção global de acertos também deve ser interpretada em relação a regras de referência que não utilizam as características discriminantes. Considere um conjunto de avaliação com m observações, das quais m_k pertencem à classe k , e defina

$$q_k = \frac{m_k}{m}, \quad k = 1, \dots, K.$$

O **critério de chance máxima** corresponde à proporção de acertos obtida por uma regra que atribui todas as observações à classe mais frequente:

$$A_{\max} = \max_{1 \leq k \leq K} q_k. \quad (19.68)$$

Esse critério mostra quanto seria possível acertar sem utilizar qualquer característica, apenas escolhendo sistematicamente a classe de maior frequência.

O **critério de chance proporcional** considera uma classificação aleatória que atribui uma observação à classe k com probabilidade q_k . A probabilidade de a classe atribuída coincidir com a classe verdadeira é

$$A_{\text{prop}} = \sum_{k=1}^K q_k^2. \quad (19.69)$$

Quando as K classes possuem a mesma frequência,

$$q_1 = \cdots = q_K = \frac{1}{K},$$

os dois critérios coincidem:

$$A_{\text{max}} = A_{\text{prop}} = \frac{1}{K}.$$

Com classes desbalanceadas, os dois valores podem diferir. Em particular, uma proporção global de acertos aparentemente elevada pode representar pouco ganho classificatório se estiver próxima do desempenho obtido pela atribuição sistemática à classe majoritária (Hair et al., 2009).

Os critérios de chance máxima e chance proporcional são referências descritivas para contextualizar a proporção de acertos. Eles não substituem a avaliação em observações que não participaram da estimação e não constituem, por si mesmos, testes de desempenho preditivo. A comparação principal deve utilizar o mesmo regime de avaliação da regra: validação cruzada, conjunto de teste *holdout* ou amostra independente, conforme distinguido na Seção 19.15.8.

A matriz deve ser interpretada em conjunto com as probabilidades *a priori* e, quando pertinente, com as consequências dos diferentes erros discutidas na Seção 19.15.1. Uma regra pode apresentar elevada proporção global de acertos e desempenho baixo em uma classe pouco frequente.

Em problemas com duas classes, sensibilidade e especificidade exigem que uma das classes seja previamente definida como positiva ou de interesse. Essas medidas dependem dessa escolha e não se estendem de forma única a problemas com $K > 2$ classes.

19.15.10 Casos classificados incorretamente

Para uma observação de classe conhecida c_i , denote por

$$\hat{c}_i = \hat{\psi}(\mathbf{x}_i)$$

a classe atribuída pela regra. O erro ocorre quando

$$\hat{c}_i \neq c_i.$$

O par $(c_i, \hat{c}_i)$ identifica quais classes estão sendo confundidas. A concentração dos erros em determinados pares de classes complementa as frequências agregadas da matriz de classificação (Hair et al., 2009).

Sob perda zero-um, podem ser comparadas as probabilidades *a posteriori* da classe verdadeira e da classe atribuída:

$$P(C = c_i \mid \mathbf{X} = \mathbf{x}_i) \quad \text{e} \quad P(C = \hat{c}_i \mid \mathbf{X} = \mathbf{x}_i).$$

Uma pequena diferença entre essas probabilidades indica pouca separação entre as duas decisões segundo a regra ajustada. Quando elas são as duas maiores probabilidades *a posteriori*, valores próximos correspondem a uma observação próxima da fronteira entre essas classes. Com perdas gerais, a comparação deve utilizar os riscos condicionais da Equação 19.48.

Dentro de cada classe verdadeira, as características originais e os escores discriminantes podem ser comparados entre observações corretamente e incorretamente classificadas. Diferenças recorrentes localizam regiões do espaço das características em que os erros se concentram. Essas diferenças não identificam, por si mesmas, a causa dos erros (Hair et al., 2009).

Uma classificação incorreta não constitui motivo para excluir a observação. A exclusão requer evidência independente de erro de mensuração, registro ou rótulo. A sobreposição entre as distribuições pode produzir erros mesmo sob a regra populacional de Bayes.

Erros observados na amostra de treinamento pertencem ao erro aparente. Erros obtidos por validação cruzada, conjunto *holdout* ou amostra independente correspondem aos regimes definidos na Seção 19.15.8. A repetição do mesmo padrão de confusão fora da amostra de treinamento indica uma limitação persistente da regra, e não apenas ajuste excessivo às observações utilizadas na estimação.

19.15.11 Correspondência com a implementação utilizada

Nas atividades computacionais, a Análise Discriminante será realizada pelo módulo `snowCluster` (Seol, 2026) do `jamovi` (The jamovi project, 2026). A análise utilizada disponibiliza a **Análise Discriminante Linear (LDA)**; a QDA permanece no capítulo como parte da formulação estatística da técnica.

Tabela 19.5: Correspondência entre elementos da implementação e os objetos estatísticos desenvolvidos no capítulo.

Elemento da implementação	Correspondência estatística	Desenvolvimento no capítulo
Dependent variable / Grouping variable	classe conhecida utilizada na construção da regra de classificação e das direções discriminantes	Capítulo 19
Covariates / Variables	características quantitativas utilizadas para discriminar e classificar	Capítulo 19
Training proportion	proporção das observações utilizada para estimar a regra	Seção 19.15.8
Prior probability	probabilidades <i>a priori</i> utilizadas pela LDA	Seção 19.15.1
Coefficients of discriminants	coeficientes das direções discriminantes de Fisher	Seção 19.15.6
Normalized loadings	coeficientes das mesmas direções após normalização euclidiana	Equação 19.63
Structure coefficients	na versão auditada, correlações amostrais totais entre as características e os escores discriminantes na amostra de treinamento; não coincidem, em geral, com as correlações de estrutura intragrupos da formulação clássica	correspondência computacional
Eigenvalue	raiz discriminante de Fisher λ_j	Equação 19.30
Variance explained	participação relativa da raiz discriminante na soma das raízes positivas	Equação 19.35
Canonical correlation	correlação canônica associada à função de Fisher	Equação 19.61
Training set	matriz de classificação das observações utilizadas no ajuste	Seção 19.15.9
Test set	matriz de classificação das observações separadas para teste	Seção 19.15.8

Elemento da implementação	Correspondência estatística	Desenvolvimento no capítulo
Wilks' Lambda tests	testes sequenciais da separação nas funções de Fisher remanescentes	Equação 19.62

A rotina utilizada pela implementação é baseada em `MASS::lda()` (Ripley; Venables, 2002). Na configuração auditada, as probabilidades *a priori* correspondem às proporções das classes na amostra de treinamento. O item **Prior probability** apresenta esses valores como saída; a interface utilizada não permite substituí-los por probabilidades especificadas pelo usuário.

A opção **Training proportion** define uma única divisão estratificada da amostra segundo a variável de classe por `caret::createDataPartition()`. Na versão auditada, o módulo fixa `set.seed(1234)`, de modo que, para os mesmos dados e a mesma proporção, a divisão é reproduzida em novas execuções. Quando **Training proportion** é igual a 1, todas as observações completas são utilizadas no treinamento e não existe conjunto de teste separado.

A tabela **Training set** corresponde à avaliação aparente da regra nas observações utilizadas em sua estimação. A tabela **Test set**, quando disponível, avalia a classificação na parcela *holdout* produzida por essa única divisão. Essa avaliação não constitui validação cruzada e não informa a variabilidade do desempenho entre diferentes divisões possíveis da amostra.

Os tamanhos efetivos das classes devem ser verificados depois da divisão, especialmente quando alguma classe possui poucas observações, pois tanto a estimação quanto as proporções de classificação correta por classe dependem do número de casos disponível em cada parcela.

Os **Coefficients of discriminants** correspondem às colunas da matriz `scaling` de `MASS::lda()`. Os **Normalized loadings** são obtidos pela normalização euclidiana dessas colunas.

A saída **Structure coefficients** exige uma distinção adicional. Na formulação clássica desenvolvida na Seção 19.15.6, as correlações de estrutura são calculadas a partir da covariância intragrupos agrupada. Na versão auditada do `snowCluster`, entretanto, essa saída é calculada por `stats::cor()` entre as características observadas e os escores discriminantes considerando conjuntamente as observações da amostra de treinamento. Ela corresponde, portanto, a correlações amostrais totais e pode incluir a associação produzida pelas diferenças entre os centroides dos grupos.

Por esse motivo, **Structure coefficients** da implementação não deve ser identificado diretamente com $r_{hj}^{(\text{estrutura})}$ definido na Equação 19.64. Os coeficientes discriminantes, os coeficientes normalizados, as correlações de estrutura intragrupos e as correlações totais fornecidas por essa saída são objetos distintos.

Na configuração auditada, `MASS::lda()` utiliza o método de momentos e probabilidades *a priori* iguais às proporções das classes na amostra de treinamento. Se d_j denota o j -ésimo

valor de `MASS::lda()$svd`, n é o tamanho dessa amostra e K é o número de classes, a raiz discriminante correspondente à formulação

$$\mathbf{T}_{\text{entre}}\alpha_j = \lambda_j \mathbf{T}_{\text{intra}}\alpha_j$$

é

$$\lambda_j = d_j^2 \frac{K-1}{n-K}.$$

A saída **Eigenvalue** apresenta essas raízes discriminantes. A saída **Variance explained** apresenta, em porcentagem, a participação relativa

$$100 \frac{\lambda_j}{\sum_{\ell=1}^{r_F} \lambda_\ell} \%.$$

Essa quantidade foi definida na Equação 19.35 e não representa a proporção da variância total das características, como ocorre na ACP.

A saída **Canonical correlation** apresenta a correlação canônica $r_j^{(\text{can})}$ definida na Equação 19.61. Ela é uma transformação crescente da raiz discriminante para uma escala limitada entre 0 e 1.

Os **Wilks' Lambda tests** correspondem aos testes sequenciais descritos na Equação 19.62. Sob normalidade multivariada dentro das classes, independência entre unidades e matriz de covariâncias comum, a implementação utiliza uma aproximação qui-quadrado de Bartlett para obter os valores p desses testes.

O teste iniciado na função j avalia a hipótese de ausência de separação populacional nas funções $j, \dots, r_F$, depois de retiradas as funções anteriores da sequência. Valores menores de Λ_j indicam maior separação nas funções incluídas no produto. Esses testes avaliam separação entre os grupos e não desempenho preditivo da regra de classificação.

19.16 Síntese

A Análise Discriminante considera grupos previamente conhecidos e desenvolve duas formulações relacionadas: uma regra probabilística de classificação e uma representação geométrica da separação entre os grupos.

Na formulação probabilística, cada classe possui probabilidade *a priori* π_k e densidade condicional $f_k(\mathbf{x})$. Sob perda zero-um, a regra de Bayes atribui $\mathbf{x}$ à classe que maximiza

$$\pi_k f_k(\mathbf{x}),$$

equivalentemente, a classe de maior probabilidade *a posteriori*.

Sob normalidade multivariada e matriz de covariâncias comum às classes, a regra de Bayes conduz à LDA e a fronteiras lineares. Com matrizes de covariâncias específicas por classe, obtém-se a QDA e, em geral, fronteiras quadráticas. As regras amostrais substituem os parâmetros populacionais desconhecidos por estimativas.

Na formulação de Fisher, a separação produzida por uma direção $\mathbf{a}$ é medida relativamente à dispersão intragrupos por

$$J_F(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}}{\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a}}.$$

Quando

$$\mathbf{T}_{\text{intra}} \succ \mathbf{0},$$

as direções discriminantes satisfazem

$$\mathbf{T}_{\text{entre}} \alpha_j = \lambda_j \mathbf{T}_{\text{intra}} \alpha_j,$$

e o número de direções associadas a raízes positivas obedece a

$$r_F \leq \min(p, K - 1).$$

As coordenadas discriminantes são as projeções das observações nessas direções e representam a separação entre os grupos relativamente à dispersão intragrupos.

Para duas classes com normalidade multivariada e covariância comum, a direção populacional de Fisher é paralela ao vetor

$$\Sigma^{-1} (\mu_1 - \mu_2),$$

que também é normal à fronteira da LDA. Fisher determina uma direção de separação; a LDA determina uma regra de classificação. Na LDA, a posição da fronteira depende também das probabilidades *a priori* e, com perdas gerais, da função de perda.

A normalidade multivariada não é necessária para construir o quociente geométrico de separação. Na formulação clássica de Fisher apresentada por Johnson e Wichern, entretanto, assume-se uma matriz de covariâncias populacional comum. A extensão populacional adotada

neste capítulo utiliza a dispersão média intragrupos Σ_W e pode ser escrita mesmo quando as covariâncias condicionais diferem entre as classes. Na LDA normal, a covariância comum integra o modelo probabilístico; a QDA mantém a normalidade multivariada, mas admite matrizes de covariâncias específicas por classe. As regras que utilizam inversas de matrizes de covariâncias exigem não singularidade e podem ser numericamente instáveis diante de quase dependências lineares.

Mesmo com os parâmetros populacionais conhecidos, distribuições condicionais sobrepostas podem produzir classificações incorretas. Sob perda zero-um, o erro de Bayes é a menor probabilidade global de classificação incorreta alcançável pela regra populacional de Bayes.

A relação com a MANOVA decorre do mesmo problema de autovalores generalizados quando ambas utilizam a mesma partição em grupos. A MANOVA utiliza as raízes para testar diferenças entre vetores de médias; Fisher utiliza os autovetores para construir direções de separação. A ACP determina direções pela variabilidade total sem utilizar rótulos de classes, enquanto a Análise de Agrupamentos constrói grupos que não são conhecidos previamente.

Exercícios de fixação do Módulo III

Os exercícios deste módulo retomam a formulação matemática e estatística das técnicas multivariadas desenvolvidas no Módulo III.

A lista está dividida em três partes, de acordo com a função do conteúdo no módulo.

Na **Parte I — Núcleo**, os exercícios verificam a compreensão do problema estatístico de cada técnica, seus objetos de entrada, a formulação matemática, as principais quantidades calculadas e a interpretação dos resultados.

Na **Parte II — Aprofundamentos teóricos**, os exercícios exploram propriedades, demonstrações, condições de existência, invariâncias, identificação, relações espectrais e resultados probabilísticos que explicam por que as formulações do núcleo funcionam.

Na **Parte III — Aprofundamentos metodológicos e aplicados**, os exercícios utilizam o R para examinar decisões de análise, adequação dos dados, escolha de dimensionalidade ou número de grupos, interpretação, diagnóstico e avaliação dos resultados.

Diretrizes gerais. A consulta aos capítulos faz parte da atividade. Definições, teoremas, proposições, propriedades, identidades e decomposições já estabelecidos nos Módulos I, II e III podem e devem ser utilizados diretamente, salvo quando uma demonstração ou derivação for solicitada explicitamente.

Sempre que um resultado dos módulos anteriores for utilizado, identifique o resultado empregado e verifique suas condições de validade. Não basta reproduzir uma fórmula ou uma saída de software. Quando forem necessárias condições de existência de momentos, definição positiva, invertibilidade, posto, independência, normalidade, tamanho amostral, graus de liberdade ou identificabilidade, essas condições devem ser indicadas.

Os exercícios do Módulo III devem combinar os fundamentos anteriores com o problema específico de cada técnica. Assim, projeções, quocientes de Rayleigh, SVD, autovalores generalizados, branqueamento, matrizes de covariâncias, distribuição Normal Multivariada, estimação, modelo linear multivariado, Wishart e resultados de inferência já desenvolvidos devem ser reutilizados.

Quando houver inferência, diferencie a construção algébrica ou geométrica da estatística. Quando houver escolha metodológica, explicita como a decisão adotada pode modificar a solução.

Parte I — Núcleo

Exercício 19.1 (Problemas estatísticos e estruturas das técnicas multivariadas). Considere as situações a seguir.

Situação A. Uma equipe possui seis medidas quantitativas de qualidade ambiental obtidas em 120 locais e deseja construir duas combinações lineares que representem a maior parte possível da variabilidade observada.

Situação B. Um questionário possui doze itens quantitativos destinados a medir dimensões não observadas de satisfação. O objetivo é representar as covariâncias entre os itens por um número menor de fatores comuns.

Situação C. Cem municípios são descritos por indicadores socioeconômicos e não existe uma classificação prévia. Deseja-se formar grupos de municípios internamente semelhantes.

Situação D. Uma tabela cruza quatro categorias de ocupação com cinco níveis de escolaridade. O objetivo é representar as associações entre as categorias das duas variáveis.

Situação E. Três tratamentos foram aplicados a grupos previamente definidos e quatro respostas quantitativas foram medidas em cada unidade. O objetivo é testar se os vetores de médias diferem entre os tratamentos.

Situação F. Três espécies previamente conhecidas são descritas por medidas morfométricas. Deseja-se representar sua separação e construir uma regra para classificar novos indivíduos.

1. Para cada situação, identifique a técnica do Módulo III mais diretamente associada ao problema.
2. Para cada técnica identificada, indique:
 - o objeto de entrada;
 - qual estrutura é fornecida previamente (rótulos de grupos, tratamentos, categorias observadas ou nenhuma dessas estruturas) e qual papel ela desempenha na análise;
 - o objeto matemático;
 - o principal critério de construção da solução;
 - se o objetivo principal é redução, estrutura latente, agrupamento, associação, comparação ou classificação.
3. Compare as Situações A e B. Explique por que ambas podem produzir poucas dimensões a partir de muitas variáveis, mas não resolvem o mesmo problema estatístico.

4. Compare as Situações C e F. Explique o papel dos grupos em cada técnica e por que a existência de rótulos conhecidos modifica a formulação do problema.
5. Compare as Situações D e A. Explique por que a Análise de Correspondência utiliza uma geometria de perfis e massas, enquanto a ACP parte de uma matriz de covariâncias ou correlações entre variáveis quantitativas.
6. Compare as Situações E e F. Explique por que MANOVA e Análise Discriminante podem compartilhar estruturas de dispersão entre e dentro dos grupos, embora possuam objetivos estatísticos diferentes.

Exercício 19.2 (ACP: variância, direções principais e representação). Considere um vetor aleatório bidimensional com matriz de covariâncias

$$\Sigma = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

1. Verifique que Σ é simétrica e positiva definida.
2. Determine seus autovalores e escolha uma base ortonormal de autovetores associados, ordenando os autovalores de forma decrescente.
3. Escreva as duas componentes principais populacionais

$$Y_j = \alpha_j^\top \mathbf{X}, \quad j = 1, 2.$$

4. Determine a variância de cada componente principal e verifique que a soma dessas variâncias é igual a

$$\text{tr}(\Sigma).$$

5. Calcule a proporção da variância total explicada pela primeira componente e a proporção acumulada pelas duas componentes.
6. Explique por que a primeira componente maximiza a variância entre todas as combinações lineares com vetor de coeficientes de norma igual a um. Relacione a argumentação ao problema de variância direcional praticado em Exercício 7.10 e à caracterização variacional das direções sucessivas estabelecida em Teorema 5.5.
7. Considere a observação centralizada

$$\mathbf{x} = \begin{bmatrix} 2 \\ 0 \end{bmatrix}.$$

Calcule seus escores nas duas componentes.

8. Reconstrua $\mathbf{x}$:

- utilizando as duas componentes;
- utilizando apenas a primeira componente.

Calcule o erro quadrático da reconstrução de uma componente e interprete o que foi descartado pela redução de dimensão. Relacione a reconstrução à projeção ortogonal praticada em Exercício 7.24.

9. Explique o que mudaria na interpretação se a ACP fosse construída a partir da matriz de correlações em vez da matriz de covariâncias.

Exercício 19.3 (Análise Fatorial: estrutura comum de covariâncias). Considere um modelo fatorial ortogonal para quatro variáveis padronizadas e dois fatores comuns, com matriz de cargas

$$\Phi = \begin{bmatrix} 0,8 & 0 \\ 0,6 & 0,2 \\ 0,1 & 0,7 \\ 0 & 0,8 \end{bmatrix}$$

e matriz de especificidades

$$\Psi = \text{diag}(0,36, 0,60, 0,50, 0,36).$$

1. Calcule a comunalidade de cada variável e verifique que, para todas elas,

$$h_i^2 + \psi_i = 1.$$

2. Construa a matriz de covariâncias comuns

$$\Phi\Phi^\top.$$

3. Obtenha a matriz reproduzida

$$\Sigma = \Phi\Phi^\top + \Psi.$$

4. Interprete:

- os elementos diagonais de $\Phi\Phi^\top$;
- os elementos fora da diagonal;
- os elementos diagonais de Ψ .

5. Compare as covariâncias reproduzidas entre os pares (X_1, X_2) , (X_1, X_4) e (X_3, X_4) . Explique como as cargas compartilhadas pelos pares de variáveis determinam essas covariâncias.
6. Considere uma matriz ortogonal

$$\mathbf{Q} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix}$$

e a matriz de cargas rotacionadas

$$\Phi^* = \Phi \mathbf{Q}.$$

Mostre que

$$\Phi^* \Phi^{*\top} = \Phi \Phi^\top.$$

7. Explique por que a rotação altera as cargas individuais, mas não altera a matriz de covariâncias comuns reproduzida no modelo ortogonal.
8. Explique, com base neste exemplo, por que uma carga fatorial não deve ser interpretada da mesma maneira que um coeficiente de uma componente principal.

Exercício 19.4 (Agrupamentos: partições, centroides e métodos hierárquicos). Considere seis observações bidimensionais:

$$\mathbf{x}_1 = (0, 0), \quad \mathbf{x}_2 = (0, 2), \quad \mathbf{x}_3 = (2, 0),$$

$$\mathbf{x}_4 = (8, 8), \quad \mathbf{x}_5 = (8, 10), \quad \mathbf{x}_6 = (10, 8).$$

1. Calcule as distâncias euclidianas entre todos os pares de observações e organize os resultados em uma matriz de distâncias.
2. Considere a partição

$$\mathcal{P}_A = \{\{1, 2, 3\}, \{4, 5, 6\}\}.$$

Determine os dois centroides e calcule o critério das K -médias

$$J_2(\mathcal{P}_A).$$

3. Considere agora

$$\mathcal{P}_B = \{\{1, 2, 4\}, \{3, 5, 6\}\}.$$

Calcule os centroides e $J_2(\mathcal{P}_B)$. Compare as duas partições.

4. Explique por que a partição com menor dispersão intragrupos também possui maior dispersão entre grupos quando $K = 2$ permanece fixado.
5. Começando com seis grupos unitários, determine qual ou quais fusões podem ocorrer primeiro segundo:
 - ligação simples;
 - ligação completa;
 - ligação média;
 - método de Ward.

Em caso de empate, indique todas as fusões possíveis.

Em seguida, suponha que a primeira fusão escolhida tenha sido entre as observações 1 e 2, formando o grupo $G = \{1, 2\}$. Calcule o critério utilizado para comparar G com o grupo unitário $\{3\}$ segundo ligação simples, ligação completa, ligação média e Ward. Explique por que as quatro regras deixam de ser equivalentes depois que aparecem grupos com mais de uma observação.

6. Para dois grupos unitários contendo $\mathbf{x}_i$ e $\mathbf{x}_j$, mostre que o incremento de Ward é

$$\Delta_{ij} = \frac{1}{2} \|\mathbf{x}_i - \mathbf{x}_j\|^2.$$

7. Explique por que o corte de um dendrograma de Ward em dois grupos não precisa coincidir, em geral, com o mínimo global do critério das K -médias para $K = 2$.

Exercício 19.5 (Análise de Correspondência: perfis, inércia e dimensão). Considere a tabela de contingência

$$\mathbf{N} = \begin{bmatrix} 30 & 10 & 10 \\ 10 & 20 & 20 \end{bmatrix},$$

em que as linhas representam duas categorias de uma variável e as colunas três categorias de outra.

1. Calcule:

- o total n ;

- a matriz de frequências relativas $\mathbf{P}$;
 - as massas das linhas;
 - as massas das colunas.
2. Determine os perfis das duas linhas e os perfis das três colunas.
 3. Sob independência, obtenha a matriz esperada de frequências relativas

$$\mathbf{r}\mathbf{c}^\top.$$

4. Calcule a distância qui-quadrado entre os dois perfis de linhas.
5. Calcule a estatística qui-quadrado de Pearson da tabela e obtenha a inércia total pela identidade

$$\mathcal{J} = \frac{\chi^2}{n}.$$

6. Construa a matriz de desvios padronizados

$$\mathbf{Q}_{\text{CA}} = \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r}\mathbf{c}^\top) \mathbf{D}_c^{-1/2}.$$

Nos itens seguintes, quando utilizar a decomposição dessa matriz, recupere a interpretação da SVD praticada em Exercício 7.13.

7. Determine o posto máximo possível de $\mathbf{Q}_{\text{CA}}$ neste problema e explique por que a representação possui, no máximo, uma dimensão não trivial.
8. Verifique que a soma dos quadrados dos elementos de $\mathbf{Q}_{\text{CA}}$ é igual à inércia total.
9. Explique por que a identidade $\chi^2 = n\mathcal{J}$ é exata para a tabela observada, enquanto a utilização de uma distribuição qui-quadrado para realizar um teste de independência exige uma formulação probabilística adicional.

Exercício 19.6 (MANOVA: matrizes de hipótese e erro e critérios multivariados). Considere uma hipótese multivariada para duas respostas cuja matriz de hipótese e matriz de erro sejam

$$\mathbf{H} = \begin{bmatrix} 8 & 0 \\ 0 & 1 \end{bmatrix}$$

e

$$\mathbf{E} = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}.$$

1. Verifique que $\mathbf{E}$ é positiva definida.
2. Resolva o problema de autovalores generalizados

$$\mathbf{H}\mathbf{a} = \lambda\mathbf{E}\mathbf{a}$$

e determine as duas raízes características em ordem decrescente. Utilize, quando necessário, a estrutura praticada em Exercício 7.11.

3. Identifique as direções generalizadas correspondentes e normalize-as na métrica de $\mathbf{E}$.
4. Para uma combinação linear $\mathbf{a}^\top \mathbf{Y}$, interprete

$$\frac{\mathbf{a}^\top \mathbf{H} \mathbf{a}}{\mathbf{a}^\top \mathbf{E} \mathbf{a}}.$$

5. Calcule:

- a lambda de Wilks;
- o traço de Pillai;
- o traço de Hotelling–Lawley;
- a maior raiz de Roy.

6. Explique como cada critério agrega as mesmas raízes características de forma diferente.
7. Repita conceitualmente o problema após a transformação de branqueamento pela matriz $\mathbf{E}$. Explique o que acontece com a métrica residual e relacione a transformação a Exercício 7.12.
8. Indique quais resultados dos itens anteriores são puramente algébricos e quais etapas adicionais seriam necessárias para transformar os critérios em testes inferenciais.

Exercício 19.7 (Análise Discriminante: LDA, Fisher e classificação). Considere duas populações com vetores de médias

$$\mu_1 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad \mu_2 = \begin{bmatrix} 2 \\ 2 \end{bmatrix}$$

e matriz de covariâncias comum

$$\Sigma = \begin{bmatrix} 1 & 0,5 \\ 0,5 & 1 \end{bmatrix}.$$

Admita probabilidades *a priori* iguais e perda zero–um.

1. Verifique que Σ é positiva definida e calcule Σ^{-1} . Relacione a geometria induzida por Σ^{-1} ao que foi praticado em Exercício 7.8.
2. Escreva as duas funções discriminantes lineares populacionais da LDA, desprezando constantes comuns às classes.
3. Determine a fronteira de classificação entre as duas classes e mostre que ela pode ser escrita como

$$x_1 + x_2 = 2.$$

4. Classifique as observações

$$\mathbf{x}_A = \begin{bmatrix} 0,5 \\ 0,5 \end{bmatrix}$$

e

$$\mathbf{x}_B = \begin{bmatrix} 1,5 \\ 1,2 \end{bmatrix}.$$

5. Determine a direção populacional de Fisher para duas classes e mostre que ela é proporcional a

$$\Sigma^{-1} (\mu_2 - \mu_1).$$

Relacione essa direção ao tipo de problema espectral generalizado estudado em Exercício 7.11.

6. Explique por que, sob as condições deste exercício, a direção de Fisher e a direção que aparece na fronteira da LDA estão diretamente relacionadas.
7. Suponha agora que as probabilidades *a priori* deixem de ser iguais. Explique qual termo das funções discriminantes é alterado e por que a fronteira se desloca.
8. Explique por que a formulação geométrica de Fisher pode ser construída sem normalidade, enquanto a interpretação probabilística da LDA utilizada neste exercício depende do modelo normal com covariância comum.

Parte II — Aprofundamentos teóricos

Exercício 19.8 (ACP: propriedades espectrais, reconstrução e multiplicidade). Considere uma matriz de covariâncias populacional

$$\Sigma = \mathbf{A}\Lambda\mathbf{A}^\top,$$

em que $\mathbf{A}$ é ortogonal e

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p), \quad \lambda_1 \geq \dots \geq \lambda_p \geq 0.$$

1. Demonstre que as componentes principais

$$Y_j = \alpha_j^\top \mathbf{X}$$

são não correlacionadas.

2. Mostre que

$$\sum_{j=1}^p \text{Var}(Y_j) = \text{tr}(\Sigma).$$

3. Para uma observação centralizada $\mathbf{x}$, escreva sua reconstrução utilizando as primeiras k direções principais e mostre que o vetor reconstruído é a projeção ortogonal de $\mathbf{x}$ sobre

$$\text{span}(\alpha_1, \dots, \alpha_k).$$

4. Mostre que o erro de reconstrução pode ser escrito como a soma dos quadrados dos escores descartados.
5. Considere uma matriz de dados centralizada $\mathbf{X}_c \in \mathbb{R}^{n \times p}$ e a matriz de covariâncias amostral

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c.$$

Utilize os resultados de SVD e aproximação de posto reduzido já estudados no Módulo I, em particular Exercício 7.14 e Exercício 7.26, para relacionar a reconstrução pelas primeiras k componentes principais à melhor aproximação de posto k de $\mathbf{X}_c$.

6. Suponha agora que $\lambda_2 = \lambda_3$ seja um autovalor de multiplicidade exatamente dois, distinto dos demais autovalores.

Explique: - quais objetos continuam unicamente determinados; - por que os autovetores individuais associados a $\lambda_2 = \lambda_3$ não são únicos; - por que o autoespaço bidimensional correspondente permanece unicamente determinado.

7. Explique por que uma mudança de sinal de um autovetor altera o sinal dos escores correspondentes, mas não altera a variância explicada nem a reconstrução quando o mesmo sinal é utilizado de forma consistente.

Exercício 19.9 (Análise Fatorial: identificação, rotação e formulação normal). Considere o modelo fatorial ortogonal

$$\mathbf{X} = \mu + \Phi \mathbf{F} + \varepsilon,$$

com

$$E(\mathbf{F}) = \mathbf{0}, \quad \text{Cov}(\mathbf{F}) = \mathbf{I}_m,$$

$$E(\varepsilon) = \mathbf{0}, \quad \text{Cov}(\varepsilon) = \Psi,$$

em que $\Psi \succ \mathbf{0}$ é diagonal e

$$\text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0}.$$

1. Obtenha

$$\Sigma = \Phi \Phi^\top + \Psi.$$

2. Seja $\mathbf{Q}$ uma matriz ortogonal de ordem m . Mostre que

$$\Phi^* = \Phi \mathbf{Q}$$

gera a mesma matriz de covariâncias observável.

3. Explique por que o resultado anterior implica indeterminação rotacional e por que a rotação não corrige falta de ajuste da matriz reproduzida.
4. Inicialmente, conte os elementos livres de Φ e Ψ antes de considerar a indeterminação rotacional. Em seguida, utilize o fato de que o grupo de matrizes ortogonais de ordem m possui $m(m-1)/2$ graus de liberdade para determinar a dimensão efetiva da parametrização após descontar essa indeterminação.

Compare o resultado com os

$$\frac{p(p+1)}{2}$$

elementos distintos de Σ e obtenha a condição de contagem correspondente. Explique por que essa condição é necessária, mas não suficiente, para identificação do modelo fatorial.

5. Sob o modelo fatorial normal,

$$\mathbf{F} \sim N_m(\mathbf{0}, \mathbf{I}_m), \quad \varepsilon \sim N_p(\mathbf{0}, \Psi),$$

com independência entre os dois vetores, determine a distribuição marginal de $\mathbf{X}$.

6. Utilizando os resultados sobre a distribuição Normal Multivariada particionada estudados no Módulo II, em particular Exercício 12.2, obtenha

$$E(\mathbf{F} \mid \mathbf{X} = \mathbf{x}).$$

7. Explique por que a expressão obtida no item anterior fundamenta o escore fatorial por regressão, mas não transforma o fator latente em uma variável observada.

Exercício 19.10 (Agrupamentos: minimização, existência, invariâncias e Ward). Considere observações

$$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^p.$$

1. Para um grupo não vazio G , demonstre que o ponto

$$\bar{\mathbf{x}}_G = \frac{1}{|G|} \sum_{i \in G} \mathbf{x}_i$$

minimiza

$$\sum_{i \in G} \|\mathbf{x}_i - \mathbf{c}\|^2$$

em relação a $\mathbf{c} \in \mathbb{R}^p$.

2. Utilize o resultado anterior para justificar por que, fixada uma partição, o centroide é a escolha ótima no critério das K -médias.
3. Para $1 \leq K \leq n$, explique por que o conjunto de partições admissíveis das n observações em K grupos não vazios é finito. Conclua que o mínimo global W_K é atingido por pelo menos uma partição.
4. Mostre que, para $1 \leq K < n$,

$$W_{K+1} \leq W_K,$$

em que W_K é o mínimo global da dispersão intragrupos entre todas as partições em K grupos não vazios.

5. Explique por que a monotonicidade de W_K não fornece, sozinha, um número ótimo de grupos.
6. Mostre que translações comuns de todas as observações preservam o critério das K -médias.
7. Determine o efeito de multiplicar todas as coordenadas por uma constante $c \neq 0$ sobre:
 - as distâncias euclidianas;
 - o critério J_K ;
 - a partição que minimiza o critério.

Relacione a discussão de mudança de escala à geometria induzida já praticada em Exercício 7.8.

8. Considere dois grupos A e B , com tamanhos n_A e n_B e centroides $\bar{\mathbf{x}}_A$ e $\bar{\mathbf{x}}_B$. Obtenha o incremento de Ward

$$\Delta(A, B) = \frac{n_A n_B}{n_A + n_B} \|\bar{\mathbf{x}}_A - \bar{\mathbf{x}}_B\|^2.$$

9. Explique por que empates no critério de fusão podem produzir mais de uma hierarquia admissível.

Exercício 19.11 (Análise de Correspondência: posto, relações baricêntricas e reconstrução). Considere uma tabela ativa com I linhas, J colunas, massas estritamente positivas e matriz de desvios padronizados

$$\mathbf{Q}_{\text{CA}} = \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r}\mathbf{c}^\top) \mathbf{D}_c^{-1/2}.$$

1. Mostre que

$$\mathbf{Q}_{\text{CA}} \mathbf{D}_c^{1/2} \mathbf{1}_J = \mathbf{0}$$

e

$$\mathbf{Q}_{\text{CA}}^\top \mathbf{D}_r^{1/2} \mathbf{1}_I = \mathbf{0}.$$

2. Utilize essas relações para justificar

$$\text{posto}(\mathbf{Q}_{\text{CA}}) \leq \min(I - 1, J - 1).$$

3. A partir da SVD

$$\mathbf{Q}_{\text{CA}} = \mathbf{U} \mathbf{D} \mathbf{V}^\top,$$

obtenha a decomposição da inércia total como soma das inércias principais. Utilize diretamente a estrutura de SVD praticada em Exercício 7.13.

4. Obtenha as relações baricêntricas entre coordenadas principais de uma margem e coordenadas padrão da outra.
5. Mostre que as coordenadas padrão e principais são centralizadas em relação às respectivas massas.
6. A partir da reconstrução completa dos desvios da independência, obtenha uma expressão para p_{ij} em função de r_i , c_j , dos valores singulares e das coordenadas padrão.
7. Considere uma reconstrução truncada nas primeiras k dimensões. Mostre que as marginais $\mathbf{r}$ e $\mathbf{c}$ são preservadas. Relacione a truncagem à aproximação de posto reduzido praticada em Exercício 7.14.
8. Explique por que a reconstrução truncada pode, apesar disso, produzir alguma célula negativa.

9. Mostre como a estatística de Pearson pode ser decomposta pelas dimensões e explique por que isso não implica automaticamente que cada termo dimensional possua, isoladamente, uma distribuição qui-quadrado de referência.

Exercício 19.12 (MANOVA: base probabilística, verossimilhança e invariância). Considere o modelo linear multivariado normal com matriz de covariâncias residual $\Sigma \succ \mathbf{0}$ e uma hipótese linear estimável que produz as matrizes aleatórias de hipótese e erro

$$\mathbf{H} \text{ e } \mathbf{E}.$$

Admita que os graus de liberdade residuais sejam suficientes para que $\mathbf{E} \succ \mathbf{0}$ quase certamente. Relacione essa condição aos resultados sobre posto e distribuição Wishart estudados no Módulo II e, ao distinguir resultados exatos e assintóticos, recupere Exercício 12.5.

1. Sob H_0 , identifique as distribuições de Wishart associadas a $\mathbf{H}$ e $\mathbf{E}$ e indique os respectivos graus de liberdade.
2. Explique por que a independência entre $\mathbf{H}$ e $\mathbf{E}$ é importante para a construção das distribuições dos critérios MANOVA.
3. Mostre que as raízes características podem ser obtidas a partir do problema simétrico

$$\mathbf{E}^{-1/2} \mathbf{H} \mathbf{E}^{-1/2} \mathbf{z} = \lambda \mathbf{z}.$$

Relacione a passagem ao problema simétrico com Exercício 7.11 e Exercício 7.12.

4. Obtenha

$$\Lambda_W = \frac{|\mathbf{E}|}{|\mathbf{H} + \mathbf{E}|} = \prod_{j=1}^s \frac{1}{1 + \lambda_j}.$$

5. Relacione a lambda de Wilks à razão de verossimilhanças entre o modelo restrito e o modelo irrestrito.
6. Suponha uma transformação não singular das respostas,

$$\mathbf{Y}^* = \mathbf{Y} \mathbf{A}.$$

Mostre como $\mathbf{H}$ e $\mathbf{E}$ se transformam e prove que as raízes características permanecem inalteradas.

7. Conclua, a partir do item anterior, que Wilks, Pillai, Hotelling–Lawley e Roy são invariantes a transformações lineares não singulares das respostas quando a hipótese é transformada de forma compatível.
8. Considere o caso em que existe no máximo uma raiz não nula. Mostre que Pillai, Hotelling–Lawley e Roy são funções crescentes dessa raiz, enquanto a lambda de Wilks é decrescente, e explique por que os quatro critérios conduzem ao mesmo teste quando a calibração é realizada de forma consistente.

Exercício 19.13 (Análise Discriminante: risco, fronteiras e relações com Fisher). Considere K classes com densidades condicionais $f_k(\mathbf{x})$, probabilidades *a priori* π_k e perdas $L(j | k)$ associadas à decisão pela classe j quando a classe verdadeira é k .

1. Escreva o risco condicional de decidir pela classe j dado $\mathbf{x}$.
2. Mostre que, sob perda zero–um, a regra de Bayes escolhe a classe que maximiza

$$\pi_k f_k(\mathbf{x}).$$

3. Suponha populações normais multivariadas com matrizes de covariâncias específicas Σ_k . Obtenha a função discriminante quadrática, desprezando termos comuns às classes. Ao organizar a derivação, recupere a estrutura da distribuição Normal Multivariada praticada em Exercício 12.2.
4. Mostre que, quando

$$\Sigma_1 = \cdots = \Sigma_K = \Sigma,$$

os termos quadráticos em $\mathbf{x}$ comuns às classes se cancelam e a fronteira entre duas classes torna-se linear.

5. Para duas classes com covariância comum, obtenha a direção da fronteira da LDA e relacione-a a

$$\Sigma^{-1}(\mu_1 - \mu_2).$$

6. No caso de duas classes, mostre que a direção populacional de Fisher é proporcional à mesma quantidade quando a dispersão intragrupos é dada pela covariância comum.
7. Para K grupos, obtenha a decomposição

$$\Sigma = \Sigma_W + \Sigma_B$$

a partir da lei da covariância total.

8. Explique por que o problema espectral de Fisher compartilha a estrutura de dispersões dentro e entre grupos com a MANOVA, embora os objetivos de classificação/discriminação e teste de hipótese sejam diferentes. Relacione a construção espectral a Exercício [7.11](#) e, quando pertinente, ao branqueamento estudado em Exercício [7.12](#).
-

Parte III — Aprofundamentos metodológicos e aplicados

Nesta parte, utilize o R. Quando um objeto central da técnica puder ser construído diretamente por operações matriciais, faça primeiro essa construção e utilize funções prontas depois, como conferência ou para ampliar a análise.

As decisões metodológicas devem ser justificadas. Não escolha padronização, número de dimensões, número de fatores, número de grupos, rotação, regra de classificação ou procedimento inferencial apenas porque uma função produziu determinada saída.

Exercício 19.14 (ACP com os dados `USArrests`). Utilize o conjunto de dados `USArrests`.

1. Examine as quatro variáveis e compare suas escalas por meio de médias, desvios padrão, amplitudes e gráficos adequados. Explique por que a decisão entre utilizar a matriz de covariâncias ou a matriz de correlações pode alterar a ACP.
2. Realize duas análises:
 - ACP das variáveis centralizadas sem padronização;
 - ACP das variáveis centralizadas e padronizadas.

Utilize `prcomp()` apenas depois de identificar quais matrizes estão sendo decompostas em cada caso.

3. Para cada análise, obtenha:
 - autovalores;
 - proporções de variância;
 - proporções acumuladas;
 - coeficientes das componentes;
 - escores das observações.
4. Compare as duas soluções e identifique quais variáveis dominam as primeiras componentes quando os dados não são padronizados.
5. Para a ACP padronizada, examine o gráfico de declive e a proporção acumulada de variância. Proponha um número de componentes a manter e justifique a escolha.

6. Construa a reconstrução das observações utilizando apenas as componentes retidas. Para a ACP baseada nas variáveis padronizadas, calcule inicialmente o erro quadrático de reconstrução na própria escala padronizada utilizada para construir a solução. Identifique os estados com maior perda de representação e explique por que esses erros não devem ser interpretados diretamente nas unidades originais das quatro variáveis. Relacione a reconstrução à projeção ortogonal praticada em Exercício 7.24.
7. Interprete as duas primeiras componentes a partir dos coeficientes e das correlações variável-componente. Não trate automaticamente coeficientes elevados como equivalentes a correlações elevadas.
8. Faça um gráfico dos escores das duas primeiras componentes e descreva padrões de posição entre os estados sem transformar proximidade gráfica em evidência de agrupamentos populacionais.

Exercício 19.15 (Análise Fatorial com os dados `USJudgeRatings`). Utilize como variáveis ativas as onze avaliações de `INTG` a `RTEG` do conjunto `USJudgeRatings`. A variável `CONT`, que registra o número de contatos do advogado com o juiz, não deve participar da construção da estrutura fatorial.

1. Construa a matriz de correlações e examine:

- magnitude das correlações;
- determinante da matriz;
- autovalores.

Ao interpretar a matriz, retome a estrutura de covariâncias e correlações praticada em Exercício 12.1.

2. Calcule o teste de esfericidade de Bartlett a partir da matriz de correlações, do número de variáveis e do tamanho amostral. Informe a hipótese testada, a estatística, os graus de liberdade e o valor- p .
3. Calcule o KMO global por operações matriciais:
 - obtenha a inversa da matriz de correlações;
 - construa as correlações parciais;
 - utilize as somas dos quadrados das correlações e correlações parciais.

Interprete o resultado como medida de adequação à estrutura fatorial, sem tratá-lo como teste de existência de um modelo fatorial verdadeiro.

4. Examine o gráfico de declive dos autovalores da matriz de correlações como informação exploratória inicial. Em seguida, compare os ajustes por máxima verossimilhança com um, dois e três fatores. Não trate os autovalores da matriz de correlações original como se fossem automaticamente as raízes produzidas por todos os métodos de extração.

5. Ajuste modelos fatoriais por máxima verossimilhança com `factanal()` para os números de fatores admissíveis considerados, utilizando inicialmente `rotation = "none"`. Para cada solução:
 - examine as unicidades;
 - examine as cargas não rotacionadas;
 - examine o teste de ajuste global quando disponível;
 - construa a matriz reproduzida

$$\widehat{\mathbf{R}} = \widehat{\Phi}\widehat{\Phi}^{\top} + \widehat{\Psi}$$

e a matriz de resíduos

$$\mathbf{R} - \widehat{\mathbf{R}}.$$

Identifique os maiores resíduos em valor absoluto.

6. Escolha uma solução e aplique rotação Varimax. Compare as cargas antes e depois da rotação e verifique que a rotação ortogonal não altera as comunalidades nem a matriz de covariâncias comuns reproduzida.
7. Identifique as variáveis que mais caracterizam cada fator e proponha uma interpretação apenas quando o conjunto de cargas sustentar uma dimensão coerente.
8. Discuta se outra rotação, inclusive oblíqua, poderia ser plausível. Explique o que mudaria na interpretação se os fatores fossem autorizados a se correlacionar.

Exercício 19.16 (Agrupamentos com os dados `USArrests`). Utilize o conjunto `USArrests`.

1. Compare as escalas das quatro variáveis e execute a análise com os dados padronizados. Explique por que essa decisão é particularmente relevante em métodos baseados em distância euclidiana e relacione a discussão de métrica à geometria induzida praticada em Exercício 7.8.
2. Aplique K -médias para

$$K = 2, \dots, 6,$$

utilizando várias inicializações por meio do argumento `nstart`. Registre a dispersão intragrupos total de cada solução.

3. Construa o gráfico da dispersão intragrupos em função de K e identifique valores candidatos de K . Não faça ainda uma escolha definitiva apenas a partir desse gráfico.

4. Para pelo menos dois valores de K , repita o algoritmo com diferentes sementes e com `nstart = 1`. Investigue se diferentes inicializações produzem soluções distintas. Caso as soluções obtidas coincidam, explique por que essa coincidência não demonstra que o mínimo global foi encontrado.

5. Utilize `hclust()` com:

- ligação simples;
- ligação completa;
- ligação média;
- `ward.D2`.

Compare os dendrogramas e explique por que métodos diferentes podem produzir hierarquias diferentes sobre os mesmos dados.

6. Para os valores candidatos de K identificados no item 3, corte o dendrograma de Ward e compare as partições com as soluções das K -médias por meio de tabelas cruzadas de pertencas.
7. Utilize a silhueta, por meio do pacote `cluster`, para avaliar as soluções consideradas. Compare a silhueta média para diferentes números de grupos e, combinando esse resultado com o comportamento da dispersão intragrupos e a interpretação dos grupos, proponha um valor de K para a solução final.
8. Identifique observações cuja presença parece influenciar fortemente as soluções. Refaça, apenas como análise de sensibilidade, a solução após retirar uma dessas observações e descreva as alterações. Não utilize essa comparação como justificativa automática para excluir a observação da análise final.
9. Realize uma ACP das quatro variáveis padronizadas. Verifique que, quando todas as componentes são mantidas, as distâncias euclidianas entre as observações são preservadas pela transformação ortogonal. Em seguida, repita o agrupamento utilizando apenas as duas primeiras componentes e compare a solução com aquela obtida no espaço padronizado completo. Explique por que a redução de dimensão, ao contrário de uma transformação ortogonal completa, pode modificar o problema de agrupamento. Utilize, quando necessário, Exercício 7.24 e Exercício 7.26.

Exercício 19.17 (Análise de Correspondência com `HairEyeColor`). Utilize

```
tab <- apply(
  HairEyeColor,
  c(1, 2),
  sum
)
```

para obter uma tabela entre cor do cabelo e cor dos olhos, agregada sobre sexo.

1. Construa diretamente:
 - a matriz de frequências relativas $\mathbf{P}$;
 - as massas das linhas e colunas;
 - os perfis de linhas e colunas;
 - a matriz de desvios padronizados $\mathbf{Q}_{CA}$.
2. Calcule a estatística qui-quadrado de Pearson e a inércia total. Verifique numericamente

$$\chi^2 = n\mathcal{I}.$$

3. Aplique `svd()` a $\mathbf{Q}_{CA}$ e obtenha:

- valores singulares;
- inércias principais;
- proporções de inércia;
- proporções acumuladas.

Relacione a decomposição obtida à SVD e à aproximação truncada praticadas em Exercício 7.13 e Exercício 7.26.

4. Determine o número máximo de dimensões não triviais e proponha quantas dimensões utilizar na representação reduzida.
5. Construa as coordenadas padrão e principais das linhas e das colunas.
6. Verifique numericamente que as distâncias euclidianas entre coordenadas principais completas de uma mesma margem reproduzem as distâncias qui-quadrado entre os respectivos perfis.
7. Para as duas primeiras dimensões, calcule:
 - contribuições das categorias;
 - $\cos^2$;
 - qualidade de representação acumulada.

Identifique categorias importantes para construir cada dimensão e categorias bem representadas no plano.

8. Construa um mapa com as categorias de cabelo e olhos. Interprete:
 - posições dentro da nuvem de linhas;
 - posições dentro da nuvem de colunas;
 - associações sugeridas pela geometria conjunta.

Não interprete a distância euclidiana entre uma categoria de linha e uma categoria de coluna como uma distância qui-quadrado definida pela técnica.

Exercício 19.18 (MANOVA com os dados `iris`). Utilize `Species` como fator de grupos e as quatro medidas quantitativas de `iris` como vetor de respostas.

1. Determine:

- número de grupos;
- tamanho de cada grupo;
- dimensão do vetor resposta;
- vetores de médias amostrais;
- matrizes de covariâncias por grupo.

2. Ajuste o modelo multivariado

```
ajuste <- manova(  
  cbind(  
    Sepal.Length,  
    Sepal.Width,  
    Petal.Length,  
    Petal.Width  
  ) ~ Species,  
  data = iris  
)
```

3. Retome a construção das matrizes SQPC estudada no modelo linear multivariado do Módulo II, em particular Exercício 12.4. A partir do ajuste:

- obtenha a matriz residual e construa

$$\mathbf{E} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}};$$

- construa a SQPC total das respostas centralizadas;
- utilize a decomposição entre variação total, entre grupos e residual para obter $\mathbf{H}$;
- verifique numericamente que $\mathbf{E}$ é não singular.

Compare a função de $\mathbf{H}$ e $\mathbf{E}$ neste exercício com a SQPC de hipótese e a SQPC residual já estudadas no Módulo II.

4. Calcule as raízes características do problema

$$\mathbf{H}\mathbf{a} = \lambda\mathbf{E}\mathbf{a}$$

e, a partir delas, obtenha manualmente: - lambda de Wilks; - traço de Pillai; - traço de Hotelling–Lawley; - maior raiz de Roy.

5. Compare os valores do item anterior com as saídas de `summary()` para os quatro testes.
6. Examine separadamente:
 - quais informações seriam necessárias no delineamento ou no processo de amostragem para justificar a independência entre unidades;
 - a plausibilidade de covariância residual comum;
 - a não singularidade da matriz residual;
 - a plausibilidade da normalidade multivariada dos erros por meio dos diagnósticos disponíveis.

Explique quais dessas condições podem ser investigadas a partir dos dados observados e quais dependem do modo como os dados foram obtidos. Não trate ausência de evidência gráfica contra uma hipótese como demonstração de que ela é verdadeira.

7. Depois do teste multivariado global, examine os testes univariados para cada resposta. Explique por que esses testes não reproduzem a MANOVA e por que uma estratégia de acompanhamento deve considerar multiplicidade e finalidade da análise.
8. Compare os quatro critérios quanto à conclusão global. Explique por que valores numéricos diferentes não significam que estejam testando hipóteses multivariadas distintas.

Exercício 19.19 (Análise Discriminante com os dados `iris`). Utilize as quatro variáveis quantitativas de `iris` para classificar `Species`.

1. Fixe uma semente e divida os dados de cada espécie em uma amostra de treinamento com aproximadamente 70% das observações e uma amostra de teste com as restantes. Preserve todas as espécies nos dois conjuntos.
2. Na amostra de treinamento, calcule:
 - vetores de médias por classe;
 - matrizes de covariâncias por classe;
 - matriz de covariâncias agrupada;
 - probabilidades *a priori* empíricas.

Relacione a estimação das matrizes de covariâncias ao que foi praticado em Exercício [12.3](#).

3. Ajuste uma LDA com `MASS::lda()` utilizando primeiro probabilidades *a priori* iguais. Examine:
 - coeficientes discriminantes;
 - número de direções;
 - proporções associadas às raízes discriminantes;
 - coordenadas discriminantes das observações de treinamento.

4. Utilize a regra para classificar as observações da amostra de teste. Construa a matriz de classificação e calcule:

- erro global;
- proporção de acertos por classe;
- tipos de erro mais frequentes.

5. Considere agora uma população-alvo hipotética na qual as proporções das três espécies sejam

$$\pi = \begin{bmatrix} 0,60 \\ 0,20 \\ 0,20 \end{bmatrix}.$$

Refça a LDA utilizando essas probabilidades *a priori* e compare as funções discriminantes e as classificações com aquelas obtidas sob probabilidades iguais. Explique por que a alteração das probabilidades *a priori* modifica a regra de decisão mesmo quando as médias e a matriz de covariâncias permanecem inalteradas.

6. Ajuste também uma QDA com `MASS::qda()`. Compare sua matriz de classificação com a da LDA e relacione as diferenças à hipótese de covariância comum.

7. Calcule o erro aparente da LDA na amostra de treinamento e compare com o erro na amostra de teste. Explique por que o erro aparente pode ser otimista.

8. Na amostra de treinamento, utilize `MASS::lda(..., CV = TRUE)` para obter a classificação por validação cruzada *leave-one-out*. Calcule a taxa de erro correspondente e compare:

- erro aparente;
- erro por validação cruzada;
- erro na amostra de teste.

Explique por que essas três quantidades utilizam os dados de maneiras diferentes e não precisam coincidir.

9. Identifique observações mal classificadas e examine suas posições nas duas primeiras coordenadas discriminantes. Discuta se os erros ocorrem em regiões de sobreposição entre as classes.

10. Conclua indicando:

- qual regra apresentou melhor desempenho sob a divisão treinamento–teste e as probabilidades *a priori* adotadas;
- quais hipóteses, probabilidades *a priori*, critérios de avaliação e decisões metodológicas sustentam essa comparação;

- se as diferentes formas de estimar o erro conduzem à mesma conclusão;
- por que o desempenho observado neste exercício não deve ser tratado como propriedade populacional definitiva da regra.

Referências

ANDERSON, Theodore W. [An Introduction to Multivariate Statistical Analysis](#). 3. ed. Hoboken, NJ: John Wiley & Sons, 2003. p. 752

APOSTOL, Tom M. [Calculus, Volume II: Multi-Variable Calculus and Linear Algebra, with Applications to Differential Equations and Probability](#). 2. ed. New York: John Wiley & Sons, 1969.

ARTES, Rinaldo; BARROSO, Lúcia Pereira. [Métodos multivariados de análise estatística](#). 1. ed. São Paulo: Blucher, 2023. p. 534

AXLER, Sheldon. [Measure, Integration & Real Analysis](#). Cham: Springer, 2020. v. 282

BARTLETT, M. S. Tests of Significance in Factor Analysis. [British Journal of Psychology \(Statistical Section\)](#), v. 3, p. 77–85, 1950.

BOYD, Stephen; VANDENBERGHE, Lieven. [Convex Optimization](#). Cambridge: Cambridge University Press, 2004.

CASELLA, George; BERGER, Roger L. [Statistical Inference](#). 2. ed. Pacific Grove, CA: Duxbury, 2002.

DZIUBAN, Charles D.; SHIRKEY, Edwin C. [When Is a Correlation Matrix Appropriate for Factor Analysis? Some Decision Rules](#). [Psychological Bulletin](#), v. 81, n. 6, p. 358–361, 1974.

EATON, Morris L. [Multivariate Statistics: A Vector Space Approach](#). Beachwood, OH: Institute of Mathematical Statistics, 2007. v. 53 p. 512

FUJIKOSHI, Yasunori; ULYANOV, Vladimir V.; SHIMIZU, Ryoichi. [Multivariate Statistics: High-Dimensional and Large-Sample Approximations](#). Hoboken, NJ: John Wiley & Sons, 2010.

GENTLE, James E. [Matrix Algebra: Theory, Computations and Applications in Statistics](#). 2. ed. Cham: Springer International Publishing, 2017.

HAIR, Jr., Joseph F. *et al.* **Análise Multivariada de Dados**. Tradução: Adonai Schlup Sant'Anna. 6. ed. Porto Alegre: Bookman, 2009.

HAIR, Jr., Joseph F. *et al.* **Multivariate Data Analysis**. 8. ed. [S.l.]: Cengage Learning EMEA, 2019.

HORN, Roger A.; JOHNSON, Charles R. **Matrix Analysis**. 2. ed. Cambridge: Cambridge University Press, 2013.

JOHNSON, Richard A.; WICHERN, Dean W. **Applied Multivariate Statistical Analysis**. 5. ed. Upper Saddle River, NJ: Prentice Hall, 2002.

JOHNSON, Richard A.; WICHERN, Dean W. **Applied Multivariate Statistical Analysis**. 6. ed. Upper Saddle River, NJ: Pearson Prentice Hall, 2007.

KAISER, Henry F. **The Varimax Criterion for Analytic Rotation in Factor Analysis**. *Psychometrika*, v. 23, n. 3, p. 187–200, 1958.

KAISER, Henry F.; RICE, John. **Little Jiffy, Mark IV**. *Educational and Psychological Measurement*, v. 34, n. 1, p. 111–117, 1974.

LÊ, Sébastien; JOSSE, Julie; HUSSON, François. **FactoMineR: A Package for Multivariate Analysis**. *Journal of Statistical Software*, v. 25, n. 1, p. 1–18, 2008.

LÊ, Sébastien; JOSSE, Julie; HUSSON, François. **FactoMineR: Multivariate Exploratory Data Analysis and Data Mining**. Disponível em: <<https://cran.r-project.org/package=FactoMineR>>. Acesso em: 3 ago. 2026.

LEBLAY, Thomas *et al.* **MEDA: Multivariate Exploratory Data Analysis with jamovi and FactoMineR**. Disponível em: <<https://sebastien-le.github.io/medasite/>>. Acesso em: 1 set. 2026.

LEDOIT, Olivier; WOLF, Michael. **A Well-Conditioned Estimator for Large-Dimensional Covariance Matrices**. *Journal of Multivariate Analysis*, v. 88, n. 2, p. 365–411, 2004.

MAGNUS, Jan R.; NEUDECKER, Heinz. **Matrix Differential Calculus with Applications in Statistics and Econometrics**. 3. ed. Chichester: John Wiley & Sons, 2019. p. 504

MANLY, Bryan F. J.; NAVARRO ALBERTO, Jorge A. **Métodos Estatísticos Multivariados: Uma Introdução**. 4. ed. Porto Alegre: Bookman, 2019. p. 254

MARDIA, Kanti V.; KENT, John T.; TAYLOR, Charles C. **Multivariate Analysis**. 2. ed.

Hoboken, NJ: John Wiley & Sons, 2024. p. 592

MARONNA, Ricardo A. *et al.* **Robust Statistics: Theory and Methods (with R)**. 2. ed. Hoboken, NJ: John Wiley & Sons, 2019. p. 464

MEYER, Carl D. **Matrix Analysis and Applied Linear Algebra**. 2. ed. Philadelphia: Society for Industrial; Applied Mathematics, 2023. p. 991

MINGOTI, Sueli Aparecida. **Análise de Dados Através de Métodos de Estatística Multivariada: Uma Abordagem Aplicada**. Belo Horizonte: Editora UFMG, 2005.

MUIRHEAD, Robb J. **Aspects of Multivariate Statistical Theory**. New York: John Wiley & Sons, 1982.

NEUHAUS, Jack O.; WRIGLEY, Charles. **The Quartimax Method: An Analytic Approach to Orthogonal Simple Structure**. **British Journal of Statistical Psychology**, v. 7, n. 2, p. 81–91, 1954.

PILLAI, K. C. S. **Some New Test Criteria in Multivariate Analysis**. **The Annals of Mathematical Statistics**, v. 26, n. 1, p. 117–121, 1955.

RENCER, Alvin C.; CHRISTENSEN, William F. **Methods of Multivariate Analysis**. 3. ed. Hoboken, NJ: John Wiley & Sons, 2012.

RIPLEY, Brian D.; VENABLES, William N. **Modern Applied Statistics with S**. Fourth ed. New York: Springer, 2002.

SEARLE, Shayle R.; KHURI, André I. **Matrix Algebra Useful for Statistics**. 2. ed. Hoboken, NJ: John Wiley & Sons, 2017.

SEOL, Hyunsoo. **snowCluster: Multivariate Analysis**. Disponível em: <<https://github.com/hyunsooseol/snowCluster>>. Acesso em: 1 set. 2026.

SUZUKI, Ryota; SHIMODAIRA, Hidetoshi. **Pvclust: an R package for assessing the uncertainty in hierarchical clustering**. **Bioinformatics**, v. 22, n. 12, p. 1540–1542, 2006.

THE JAMOVİ PROJECT. **jamovi (Version 2.7) [Computer Software]**., 2026. Disponível em: <<https://www.jamovi.org>>. Acesso em: 1 set. 2026

TIBSHIRANI, Robert; WALTHER, Guenther; HASTIE, Trevor. **Estimating the Number of Clusters in a Data Set via the Gap Statistic**. **Journal of the Royal Statistical Society: Series B (Statistical Methodology)**, v. 63, n. 2, p. 411–423, 2001.

VAART, A. W. van der. [Asymptotic Statistics](#). Cambridge: Cambridge University Press, 1998. p. 462

WILKS, Samuel S. [Certain Generalizations in the Analysis of Variance](#). **Biometrika**, v. 24, n. 3–4, p. 471–494, 1932.