

Fundamentos e Formulação da Análise Multivariada

Departamento de Estatística e Matemática Aplicada/CC/UFC

Laboratório de Inovação em Estatística - StatLab

Grupo de pesquisa de Inovação em Estatística e Ciência de Dados

Versão Preliminar
- Em Elaboração -



Índice

Informações Legais e Declaração de Uso de Inteligência Artificial	24
Direitos Autorais e Uso da Obra	24
Declaração sobre o Uso de Ferramentas de Inteligência Artificial	24
Prefácio	25
Identificação da Disciplina	26
EMENTA	26
OBJETIVO GERAL	26
OBJETIVOS ESPECÍFICOS	26
CONTEÚDO PROGRAMÁTICO	27
Módulo I – Fundamentos Matemáticos e Geométricos da Análise Multivariada	27
Módulo II – Fundamentos Probabilísticos e Inferenciais da Análise Multivariada	27
Módulo III – Formulação Matemática e Estatística das Técnicas Multivariadas	27
METODOLOGIA	28
AVALIAÇÃO	28
CRITÉRIOS DE AVALIAÇÃO	28
BIBLIOGRAFIA BÁSICA	29
BIBLIOGRAFIA COMPLEMENTAR	29
 I Módulo I — Fundamentos Matemáticos e Geométricos da Análise Multivariada	 30
1 Vetores e representação dos dados multivariados	31
1.1 Escalares, vetores e matrizes	32
1.1.1 Vetor-coluna, vetor-linha e transposição	35
1.2 O espaço $\mathbb{R}^p$	36
1.3 Representação matricial de um conjunto de dados	39
1.3.1 Espaço das observações e espaço das variáveis	41
1.4 Operações elementares com vetores	42
1.4.1 Soma e subtração	42
1.4.2 Multiplicação por escalar	43
1.4.3 Combinações lineares	45
1.5 Produto interno, norma, ângulo e distância euclidiana	47
1.5.1 Produto interno euclidiano	47

1.5.2	Norma euclidiana	48
1.5.3	Desigualdade de Cauchy–Schwarz	49
1.5.4	Ângulo entre vetores	52
1.5.5	Distância euclidiana	54
1.5.6	Desigualdade triangular	56
1.5.7	Produto externo	57
1.6	Síntese do capítulo	59
2	Álgebra matricial aplicada	61
2.1	Operações matriciais fundamentais	62
2.1.1	Soma e subtração de matrizes	62
2.1.2	Produto matriz-vetor	65
2.1.3	Produto entre matrizes	68
2.1.4	Propriedades do produto matricial	73
2.2	Transposição, simetria e traço	74
2.2.1	Transposição	74
2.2.2	Matrizes simétricas	76
2.2.3	Traço	80
2.3	Identidade, inversa, determinante, posto e sistemas lineares	84
2.3.1	Matriz identidade	84
2.3.2	Matriz inversa	85
2.3.3	Determinante	88
2.3.4	Interpretação geométrica do determinante	92
2.3.5	Posto	93
2.3.6	Sistemas lineares	96
2.3.7	Aprofundamento: pseudoinversa	100
2.4	Matrizes ortogonais, diagonais e triangulares	102
2.4.1	Matrizes ortogonais	102
2.4.2	Matrizes diagonais	105
2.4.3	Matrizes triangulares	108
2.4.4	Aprofundamento: sistemas triangulares	109
2.5	Formas bilineares, formas quadráticas e positividade	111
2.5.1	Formas bilineares	111
2.5.2	Formas quadráticas	115
2.5.3	Positividade	122
2.5.4	Superfícies de nível	128
2.6	Aprofundamento: matrizes particionadas e complemento de Schur	129
2.6.1	Matrizes particionadas	129
2.6.2	Soma e multiplicação por escalar	131
2.6.3	Transposição por blocos	131
2.6.4	Multiplicação por blocos	132
2.6.5	Complemento de Schur	134
2.6.6	Eliminação por blocos	135

2.6.7	Determinante de uma matriz particionada	137
2.6.8	Inversão em blocos	138
2.6.9	Positividade e complemento de Schur	139
2.7	Síntese do capítulo	142
3	Espaços vetoriais, bases e projeções	145
3.1	Espaços, subespaços e geração	146
3.1.1	Subespaços vetoriais	148
3.1.2	Subespaço gerado	150
3.2	Independência linear, bases e dimensão	153
3.2.1	Independência linear	153
3.2.2	Independência linear e posto	155
3.2.3	Bases	157
3.2.4	Coordenadas em uma base	158
3.2.5	Base canônica	160
3.2.6	Bases ortogonais e ortonormais	161
3.2.7	Dimensão	164
3.3	Espaços fundamentais de uma matriz	166
3.3.1	Espaço nulo	166
3.3.2	Espaço coluna	169
3.3.3	Espaço linha	172
3.3.4	Espaço nulo à esquerda	173
3.3.5	Extensão de uma base	175
3.3.6	Teorema Posto–Nulidade	176
3.3.7	Os quatro espaços fundamentais	180
3.3.8	Complemento ortogonal	180
3.3.9	Relações de ortogonalidade	181
3.4	Produtos internos, bases ortonormais e matrizes de Gram	183
3.4.1	Aprofundamento: produtos internos e geometrias induzidas	183
3.4.2	Matrizes de Gram	188
3.4.3	Propriedades da matriz de Gram	190
3.4.4	Matrizes de Gram e bases ortonormais	192
3.4.5	Produtos cruzados em uma matriz de dados	193
3.4.6	Propriedades do complemento ortogonal	194
3.4.7	Dimensão do complemento ortogonal	196
3.4.8	Decomposição ortogonal	199
3.4.9	Decomposição dos espaços fundamentais	201
3.5	Projeções ortogonais	202
3.5.1	Projeção sobre uma direção	203
3.5.2	Projeção sobre um subespaço com base ortonormal	208
3.5.3	Projeção sobre o espaço coluna de uma matriz	211
3.5.4	Propriedades da matriz de projeção	215
3.5.5	Aprofundamento: projeção residual e complemento ortogonal	219

3.5.6	Projeção como melhor aproximação	224
3.5.7	Aprofundamento: projeções e mínimos quadrados	227
3.6	Síntese do capítulo	231
4	Transformações lineares	234
4.1	Transformações lineares e representação matricial	235
4.1.1	Transformação determinada por uma base	237
4.1.2	Representação matricial nas bases canônicas	239
4.1.3	Núcleo e imagem de uma transformação linear	241
4.1.4	Imagem de um subespaço	242
4.2	Transformação de vetores e matrizes de dados	243
4.2.1	Novas variáveis como combinações lineares	245
4.2.2	Dimensão da configuração transformada	247
4.2.3	Efeito sobre diferenças e produtos internos	251
4.2.4	Transformação das matrizes de produtos internos	252
4.3	Composição, invertibilidade e perda de informação	253
4.3.1	Composição de transformações lineares	254
4.3.2	A ordem das transformações	255
4.3.3	Transformação inversa	258
4.3.4	Injetividade, sobrejetividade e bijetividade	259
4.3.5	Perda de informação	264
4.3.6	Redução de dimensionalidade	265
4.3.7	Transformações singulares	266
4.4	Transformações geométricas	267
4.4.1	Rotação	268
4.4.2	Reflexão	269
4.4.3	Escalonamento	271
4.4.4	Cisalhamento	272
4.4.5	Projeção	274
4.4.6	Comparação geométrica	275
4.4.7	Determinante, volume e orientação	276
4.5	Transformações ortogonais	278
4.5.1	Transformação de uma matriz de dados	280
4.5.2	Determinante e orientação	281
4.5.3	Matrizes ortogonais e bases ortonormais	282
4.5.4	Comparação com transformações não ortogonais	283
4.6	Mudanças de coordenadas e representação em bases	285
4.6.1	Conversão entre duas bases	287
4.6.2	Representação de uma transformação em bases gerais	288
4.6.3	Representação de um operador em uma nova base	291
4.6.4	Transformação ativa e mudança passiva	293
4.6.5	Mudança de coordenadas de uma matriz de dados	294

4.7	Transformações afins e pré-processamento	295
4.7.1	Translação	297
4.7.2	Transformação afim de uma matriz de dados	297
4.7.3	Centralização	298
4.7.4	Escalonamento das variáveis	302
4.7.5	Padronização	303
4.7.6	Ordem entre centralização e escalonamento	304
4.7.7	Composição e inversão de transformações afins	305
4.7.8	Comparação das operações de pré-processamento	307
4.8	Síntese do capítulo	307
5	Autovalores, autovetores e decomposição espectral	315
5.1	Direções invariantes, autovalores e autoespaços	316
5.2	Equação característica, multiplicidades e diagonalização	325
5.2.1	Determinação dos autovalores e autoespaços	327
5.2.2	Autovalores complexos de matrizes reais	329
5.2.3	Independência entre autovetores	330
5.2.4	Multiplicidades algébrica e geométrica	332
5.2.5	Diagonalização	337
5.2.6	Potências de uma matriz diagonalizável	340
5.3	Matrizes simétricas e decomposição espectral	341
5.3.1	Decomposição espectral do exemplo condutor	347
5.3.2	Forma aditiva da decomposição espectral	349
5.3.3	Projetores sobre autoespaços	350
5.3.4	Não unicidade da matriz de autovetores	352
5.4	Consequências da decomposição espectral	353
5.4.1	Traço, determinante, posto e invertibilidade	353
5.4.2	Formas quadráticas em coordenadas espectrais	357
5.4.3	Superfícies de nível em coordenadas espectrais	362
5.5	Quociente de Rayleigh	365
5.5.1	Representação espectral	366
5.5.2	Formulação com restrição de norma	372
5.5.3	Multiplicadores de Lagrange	373
5.5.4	Direções sucessivas	378
5.6	Funções espectrais de matrizes	382
5.6.1	Ação sobre os autoespaços	383
5.6.2	Potências inteiras	384
5.6.3	Inversa espectral	385
5.6.4	Raiz quadrada principal	386
5.6.5	Raiz quadrada inversa	387
5.6.6	Pseudoinversa espectral	388
5.6.7	Exponencial e logaritmo matriciais	390

5.7	Aprofundamento: autovalores generalizados	391
5.7.1	Quociente de Rayleigh generalizado	394
5.7.2	Redução a um problema espectral ordinário	397
5.7.3	Ortogonalidade na métrica de $\mathbf{M}$	400
5.7.4	Diagonalização simultânea por congruência	402
5.8	Síntese do capítulo	408
6	Decomposição em Valores Singulares	414
6.1	Definição e formas da Decomposição em Valores Singulares	415
6.1.1	Vetores singulares	419
6.1.2	Interpretação como composição de transformações	421
6.1.3	SVD completa	422
6.1.4	SVD compacta	423
6.1.5	SVD compacta e SVD truncada	424
6.1.6	Aprofundamento: não unicidade dos vetores singulares	430
6.2	Construção da SVD e relação com a decomposição espectral	432
6.2.1	Propriedades das matrizes de Gram associadas	433
6.2.2	Construção dos pares singulares	438
6.2.3	Construção da SVD compacta	443
6.2.4	Decomposições espectrais associadas	447
6.2.5	Exemplo de construção da SVD	449
6.2.6	Relação com a decomposição espectral de matrizes simétricas	452
6.2.7	Aprofundamento: SVD de matrizes simétricas indefinidas	453
6.3	Interpretação geométrica da SVD	454
6.3.1	Imagem da bola unitária	456
6.3.2	Alteração dos comprimentos	459
6.3.3	Exemplo geométrico no plano	464
6.3.4	Transformações com núcleo não trivial	465
6.4	Espaços fundamentais, posto e normas	467
6.4.1	Espaço coluna e espaço linha	468
6.4.2	Projetores ortogonais	472
6.4.3	Posto e nulidades	476
6.4.4	Produto interno de Frobenius	477
6.4.5	Normas e valores singulares	479
6.4.6	Invariância ortogonal	481
6.4.7	Determinante e invertibilidade	482
6.4.8	Aprofundamento: condicionamento e posto numérico	483
6.5	SVD de uma matriz de dados	489
6.5.1	Dualidade entre observações e variáveis	490
6.5.2	Coordenadas das observações nas direções singulares à direita	491
6.5.3	Coordenadas das variáveis nas direções singulares à esquerda	493
6.5.4	Matrizes de Gram da matriz de dados	494
6.5.5	Representação exata das observações	495

6.5.6	Centralização da matriz de dados	498
6.5.7	Antecipação: relação com a matriz de covariâncias amostral	499
6.5.8	Magnitude quadrática da matriz centralizada	501
6.5.9	Representação exata e aproximação	504
6.6	Forma expandida e aproximações de posto reduzido	505
6.6.1	Ortogonalidade dos componentes singulares	507
6.6.2	SVD truncada na forma expandida	509
6.6.3	Erros produzidos pelo truncamento	510
6.6.4	Teorema de Eckart–Young–Mirsky	513
6.6.5	Aprofundamento: demonstração e unicidade da melhor aproximação . .	514
6.6.6	Exemplo de aproximação de posto 1	521
6.6.7	Aproximação de uma matriz de dados	523
6.7	Pseudoinversa e soluções de mínimos quadrados	526
6.7.1	Relação com a pseudoinversa espectral	528
6.7.2	Aprofundamento: caracterização de Moore–Penrose	529
6.7.3	Pseudoinversa e projetores	535
6.7.4	Sistemas lineares compatíveis	537
6.7.5	Mínimos quadrados	540
6.7.6	Expressão da solução nas direções singulares	547
6.7.7	Aprofundamento: instabilidade e pseudoinversa truncada	548
6.7.8	Exemplo com o sistema condutor	551
6.8	Síntese do capítulo	553
7	Cálculo Diferencial, Integral e Matricial Aplicado à Estatística Multivariada	562
7.1	Funções, variações e diferenciais	562
7.1.1	Tipos de funções	562
7.1.2	Convenções de derivação	565
7.1.3	Variação de uma função	566
7.1.4	Diferencial	568
7.1.5	Aproximação ao longo de uma direção	570
7.1.6	Diferenciabilidade de funções vetoriais	570
7.2	Gradiente, derivada direcional, Jacobiana e Hessiana	573
7.2.1	Gradiente e derivada direcional	573
7.2.2	Gradiente e conjuntos de nível	576
7.2.3	Jacobiana	579
7.2.4	Regra da cadeia	581
7.2.5	Hessiana	583
7.3	Aproximações de Taylor e classificação local	585
7.3.1	Aproximação de Taylor de primeira ordem	585
7.3.2	Aproximação de Taylor de segunda ordem	587
7.3.3	Pontos estacionários	588
7.3.4	Classificação pela Hessiana	590
7.3.5	Caso inconclusivo	593

7.4	Convexidade e concavidade	594
7.4.1	Conjuntos convexos	594
7.4.2	Funções convexas	595
7.4.3	Caracterização de primeira ordem	596
7.4.4	Caracterização pela Hessiana	596
7.4.5	Consequências para otimização	599
7.4.6	Funções quadráticas	600
7.5	Otimização sem restrições	602
7.5.1	Método de Newton	602
7.6	Otimização com restrições de igualdade	606
7.6.1	Multiplicadores de Lagrange	607
7.6.2	Relação com problemas de autovalores	613
7.6.3	Restrições lineares	614
7.7	Derivadas de formas lineares, quadráticas e funções de resíduos	616
7.7.1	Formas lineares e bilineares	616
7.7.2	Derivadas de formas quadráticas	617
7.7.3	Derivadas da norma euclidiana	620
7.7.4	Funções de resíduos lineares	620
7.7.5	Equações normais	622
7.7.6	Mínimos quadrados ponderados	625
7.7.7	Funções compostas de resíduos	627
7.7.8	Mínimos quadrados não lineares	628
7.8	Diferenciais matriciais e cálculo por traços	630
7.8.1	Regras básicas do diferencial matricial	631
7.8.2	Identities de traço	632
7.8.3	Função linear de uma matriz	633
7.8.4	Derivadas da norma de Frobenius	634
7.8.5	Funções quadráticas de uma matriz	635
7.8.6	Funções matriciais de resíduos	637
7.8.7	Ponderação de observações e respostas	641
7.9	Derivadas de inversas, determinantes e log-determinantes	643
7.9.1	Diferencial da matriz inversa	643
7.9.2	Diferencial do determinante	645
7.9.3	Diferencial do log-determinante	647
7.9.4	Segunda variação do log-determinante	648
7.9.5	Traço envolvendo uma matriz inversa	650
7.9.6	Forma quadrática com matriz inversa	651
7.9.7	Crítério com log-determinante e traço	652
7.9.8	Parâmetros matriciais simétricos	656
7.10	Vetorização, produto de Kronecker e parâmetros matriciais	656
7.10.1	Operador de vetorização	657
7.10.2	Produto de Kronecker	658
7.10.3	Identidade de vetorização	660

7.10.4	Aprofundamento: derivadas vetorizadas e parâmetros matriciais	661
7.11	Integração múltipla e mudança de variáveis	674
7.11.1	Integrais múltiplas	674
7.11.2	Teoremas de Tonelli e Fubini	675
7.11.3	Densidades multivariadas	677
7.11.4	Distribuições marginais	678
7.11.5	Esperanças de funções escalares, vetoriais e matriciais	680
7.11.6	Mudança de variáveis	681
7.11.7	Transformação de densidades	683
7.11.8	Transformações afins	684
7.11.9	Interpretação geométrica do determinante Jacobiano	686
7.11.10	Coordenadas polares	687
7.11.11	Transformações elipsoidais	688
7.11.12	Aprofundamento: diferenciação sob o sinal de integração	689
7.12	Aprofundamento: aplicações à estimação e à inferência	696
7.12.1	Log-verossimilhança e vetor escore	696
7.12.2	Informação observada e informação de Fisher	697
7.12.3	Newton–Raphson	699
7.12.4	Método do escore de Fisher	701
7.12.5	Expansão local de uma raiz do escore	702
7.12.6	Método delta	703
7.13	Síntese do capítulo	709
Exercícios de fixação do Módulo I		712
Parte I — Exercícios sem uso de computador		712
Parte II — Exercícios com uso do R		729
 II Módulo II — Fundamentos Probabilísticos e Inferenciais da Análise Mul-		
tivariada		738
 8 Matrizes de covariâncias e correlações		739
8.1	Momentos, centralização e covariância	740
8.1.1	Vetor de médias e centralização	740
8.1.2	Momentos de segunda ordem	741
8.1.3	Covariância entre duas variáveis	743
8.2	Matriz de covariâncias populacional	747
8.2.1	Definição e interpretação dos elementos	747
8.2.2	Variâncias e covariâncias de combinações lineares	748
8.2.3	Propriedades estruturais e singularidade	751
8.3	Covariâncias entre vetores e transformações	756
8.3.1	Covariâncias cruzadas e vetores particionados	756
8.3.2	Transformações afins da média e da covariância	763

8.4	Padronização e matriz de correlações	767
8.4.1	Matriz de correlações populacional	767
8.4.2	Propriedades, escala e independência	771
8.5	Geometria e medidas globais da dispersão	778
8.5.1	Eixos espectrais e elipsoide de covariância	778
8.5.2	Variância total, variância generalizada e volume	785
8.6	Distância de Mahalanobis	790
8.6.1	Geometria, branqueamento e invariância	790
8.6.2	Covariância singular	798
8.7	Representação descritiva a partir dos dados	799
8.7.1	Centralização, SSCP e matriz de covariâncias observada	800
8.7.2	Matriz de correlações e covariâncias cruzadas observadas	804
8.8	Decomposição da dispersão por grupos	809
8.8.1	Dispersão total, intragrupos e entre grupos	810
8.8.2	Propriedades e limites de posto	816
8.9	Síntese do capítulo	819
9	Distribuição Normal Multivariada	822
9.1	Definição e construção	823
9.1.1	Definição por combinações lineares	823
9.1.2	Construção afim a partir do vetor normal padrão	825
9.1.3	Determinação pelos parâmetros	828
9.1.4	Aprofundamento: caso singular e suporte efetivo	829
9.2	Densidade no caso não singular	833
9.2.1	Função densidade e log-densidade	834
9.2.2	Superfícies de igual densidade	837
9.3	Transformações e distribuições marginais	837
9.3.1	Fechamento sob transformações afins	839
9.3.2	Combinações lineares	841
9.3.3	Distribuições marginais	842
9.3.4	Padronização marginal e branqueamento	844
9.4	Independência e distribuições condicionais	847
9.4.1	Independência entre blocos conjuntamente normais	847
9.4.2	Distribuição condicional	850
9.4.3	Média e covariância condicionais	853
9.4.4	Caso bivariado	855
9.5	Distância de Mahalanobis e regiões de probabilidade	857
9.5.1	Distribuição qui-quadrado	858
9.5.2	Regiões elipsoidais de probabilidade	860
9.5.3	Avaliação de uma observação fixa	861
9.5.4	Aprofundamento: caso singular	863
9.6	Comparação entre distribuições normais	866
9.6.1	Médias distintas e covariância comum	866

9.6.2	Covariâncias distintas	867
9.7	Alcance da hipótese de normalidade	869
9.7.1	Resultados que não exigem normalidade	869
9.7.2	Resultados específicos da família normal	870
9.7.3	Passagem do modelo populacional para a inferência	871
9.8	Síntese do capítulo	872
10	Estatísticas Amostrais e Estimação	875
10.1	Da população à amostra	876
10.1.1	Amostra aleatória multivariada	877
10.1.2	Matriz aleatória da amostra e matriz observada	879
10.1.3	Parâmetros, estatísticas, estimadores e estimativas	880
10.2	Propriedades dos estimadores multivariados	882
10.2.1	Viés e variabilidade	883
10.2.2	Erro quadrático médio e funções de perda	884
10.2.3	Consistência	886
10.2.4	Eficiência	886
10.2.5	Suficiência	887
10.2.6	Equivariância e robustez	890
10.3	Métodos de estimação	891
10.3.1	Método dos momentos	892
10.3.2	Verossimilhança e máxima verossimilhança	894
10.3.3	Invariância da máxima verossimilhança	900
10.4	Estimação do vetor de médias	902
10.4.1	Vetor de médias amostrais	903
10.4.2	Esperança e matriz de covariâncias	906
10.4.3	Combinações lineares	907
10.4.4	Consistência e equivariância	909
10.4.5	Variabilidade entre amostras	911
10.5	SSCP e estimação da matriz de covariâncias	912
10.5.1	SSCP como estatística aleatória	912
10.5.2	Decomposição em torno de um centro arbitrário	914
10.5.3	Esperança da SSCP	915
10.5.4	Estimador não viesado da matriz de covariâncias	917
10.5.5	Estimador de máxima verossimilhança	918
10.5.6	Consistência dos estimadores de covariância	919
10.5.7	Transformações, posto e singularidade	921
10.6	Estimação de covariâncias cruzadas e correlações	924
10.6.1	Covariâncias cruzadas entre blocos	925
10.6.2	Matriz de correlações amostral	929
10.6.3	Propriedades estruturais	931
10.6.4	Transformações de localização e escala	933

10.7	Aprofundamento: dimensão, estabilidade e extensões da estimação	935
10.7.1	Relação entre p e n	935
10.7.2	Condicionamento e inversão	938
10.7.3	Regularização	939
10.7.4	Pseudoinversa e regularização	943
10.7.5	Sensibilidade e robustez	945
10.8	Exemplo integrado	947
10.9	Síntese do capítulo	952
11	Modelo Linear Multivariado e Hipóteses Lineares	955
11.1	Formulação do modelo linear multivariado	956
11.1.1	Resposta vetorial e matriz de respostas	956
11.1.2	Estrutura matricial do modelo	958
11.1.3	Estrutura de médias e covariâncias residuais	960
11.1.4	Forma vetorizada	961
11.1.5	Distribuição normal matricial	962
11.1.6	Transformações da resposta	964
11.2	Estimação da matriz de parâmetros	965
11.2.1	Mínimos quadrados	966
11.2.2	Estimador sob posto completo	967
11.2.3	Esperança e matriz de covariâncias	969
11.2.4	Relação com máxima verossimilhança	972
11.2.5	Modelo contendo somente intercepto	973
11.3	Valores ajustados, resíduos e projeções	974
11.3.1	Valores ajustados e resíduos	975
11.3.2	Ortogonalidade	977
11.3.3	Esperança dos valores ajustados e dos resíduos	977
11.3.4	Covariâncias dos valores ajustados e dos resíduos	978
11.3.5	Representação dos ajustes e resíduos	980
11.3.6	Conexão com o modelo contendo somente intercepto	981
11.4	SSCP residual e estimação da covariância	982
11.4.1	Construção da SSCP residual	982
11.4.2	Esperança e graus de liberdade	985
11.4.3	Estimador não viesado da covariância residual	987
11.4.4	Estimador de máxima verossimilhança	989
11.4.5	Posto e singularidade	990
11.4.6	Modelo contendo somente intercepto	992
11.5	Decomposição da variação multivariada	994
11.5.1	SSCP total	994
11.5.2	SSCP associada ao modelo	995
11.5.3	Decomposição entre modelo e resíduo	997
11.5.4	Combinações lineares das respostas	999
11.5.5	Modelos sem intercepto	1000

11.5.6	Modelo de grupos como caso particular	1001
11.6	Posto, parametrização e estimabilidade	1002
11.6.1	Delineamento com posto deficiente	1003
11.6.2	Pseudoinversa e soluções de mínimos quadrados	1004
11.6.3	Funções estimáveis	1006
11.6.4	Estimador de uma função estimável	1009
11.6.5	Parametrizações equivalentes	1010
11.6.6	Restrições de identificação	1011
11.6.7	Aprofundamento: posto numérico	1012
11.7	Hipóteses lineares multivariadas	1013
11.7.1	Contrastes sobre parâmetros e combinações das respostas	1013
11.7.2	Hipótese linear geral	1015
11.7.3	Estimabilidade da hipótese	1017
11.7.4	SSCP da hipótese	1020
11.7.5	Modelos encaixados	1022
11.7.6	Casos particulares	1026
11.8	Exemplo integrado	1028
11.8.1	Estimação da matriz de parâmetros	1029
11.8.2	Valores ajustados e resíduos	1030
11.8.3	SSCP residual e covariância residual	1030
11.8.4	Decomposição da SSCP total	1032
11.8.5	Hipótese sobre o efeito da covariável	1033
11.8.6	Hipótese sobre uma combinação das respostas	1034
11.9	Síntese do capítulo	1035
12	Inferência Multivariada	1039
12.1	Distribuições amostrais exatas e assintóticas	1040
12.1.1	Distribuição da média amostral sob normalidade	1040
12.1.2	Teorema Central do Limite multivariado	1043
12.2	Distribuição de Wishart	1045
12.2.1	Construção e parametrização	1046
12.2.2	Suporte, posto e definição positiva	1048
12.2.3	Momentos	1049
12.2.4	Formas quadráticas	1051
12.2.5	Aditividade	1052
12.2.6	Transformações lineares	1052
12.2.7	Aprofundamento: densidade da distribuição de Wishart	1054
12.2.8	Distribuição da SSCP e da covariância amostral	1055
12.2.9	Independência entre média e covariância	1060
12.3	Distribuições no modelo linear multivariado	1062
12.3.1	Distribuição do estimador da matriz de parâmetros	1063
12.3.2	Distribuição de funções estimáveis	1065
12.3.3	Distribuição da SSCP residual	1067

12.3.4	Independência entre estimação e SSCP residual	1070
12.3.5	Distribuição da SSCP da hipótese sob (H_0)	1071
12.4	Princípios da inferência multivariada	1075
12.4.1	Testes globais e hipóteses simultâneas	1076
12.4.2	Razão de verossimilhanças	1077
12.4.3	Resultado assintótico de Wilks	1079
12.4.4	Razão de verossimilhanças em modelos normais encaixados	1080
12.5	Inferência sobre um vetor de médias	1083
12.5.1	Covariância conhecida	1084
12.5.2	Estatística (T^2) de Hotelling	1085
12.5.3	Relações com os casos assintótico e univariado	1088
12.5.4	Região de confiança elipsoidal	1089
12.5.5	Geometria da região	1090
12.5.6	Intervalos simultâneos	1091
12.5.7	Hipóteses lineares sobre o vetor de médias	1093
12.5.8	Relação com o modelo linear multivariado	1097
12.6	Comparação entre dois vetores de médias	1098
12.6.1	Duas amostras independentes	1098
12.6.2	Covariâncias populacionais distintas	1103
12.6.3	Observações pareadas	1104
12.7	Condições e limites da inferência clássica	1108
12.7.1	Independência, normalidade e covariância comum	1108
12.7.2	Posto, dimensão e tamanho amostral	1112
12.7.3	Aprofundamento: alta dimensão e robustez	1115
12.8	Síntese do Módulo 2	1119
12.8.1	Passagem para o Módulo 3	1123

III Módulo III — Formulação Matemática e Estatística das Técnicas Multivariadas 1124

13	Problemas e estruturas das técnicas multivariadas	1125
13.1	Do problema estatístico à técnica multivariada	1126
13.2	Classes de problemas multivariados	1128
13.2.1	Redução de dimensionalidade	1128
13.2.2	Representação de estruturas latentes	1128
13.2.3	Formação de grupos	1128
13.2.4	Representação de dissimilaridades	1129
13.2.5	Representação de associações em tabelas de contingência	1129
13.2.6	Comparação de vetores de médias	1129
13.2.7	Discriminação e classificação	1130
13.2.8	Associação entre blocos de variáveis	1130
13.2.9	Decomposição de preferências	1130

13.3	Diferentes formas de classificar as técnicas	1130
13.3.1	Interdependência e dependência	1131
13.3.2	Exploratórias, descritivas, preditivas e inferenciais	1131
13.3.3	Supervisionadas e não supervisionadas	1131
13.4	Estruturas matemáticas recorrentes	1132
13.4.1	Combinações lineares e projeções	1133
13.4.2	Formas quadráticas e problemas espectrais	1133
13.4.3	SVD e representações de baixa dimensão	1133
13.4.4	Distâncias, matrizes de Gram e métricas	1134
13.4.5	Covariâncias entre blocos	1134
13.4.6	Modelos lineares e probabilísticos	1134
13.5	Mesmas estruturas, diferentes interpretações	1136
13.6	Relações entre as técnicas	1137
13.7	Síntese	1138
14	Formulação da Análise de Componentes Principais	1139
14.1	O problema de redução de dimensionalidade	1139
14.2	Componentes principais como combinações lineares	1142
14.3	Primeira componente principal	1143
14.4	Componentes principais sucessivas	1145
14.5	Formulação espectral	1147
14.6	Variância total e proporção de variância	1148
14.7	Subespaço principal e projeção	1152
14.8	Reconstrução a partir das componentes principais	1156
14.9	Formulação amostral	1159
14.10	Formulação da ACP pela SVD	1161
14.11	Aproximação de posto reduzido	1163
14.12	ACP baseada na matriz de correlações	1165
14.13	Interpretação geométrica da ACP	1168
14.13.1	Relação com o elipsoide de covariâncias	1169
14.13.2	Redução de dimensão como projeção	1170
14.14	Coefficientes e relação das variáveis com as componentes	1170
14.15	Propriedades da solução	1173
14.15.1	Invariância a translações	1173
14.15.2	Dependência da escala	1174
14.15.3	Indeterminação do sinal	1174
14.15.4	Multiplicidade de autovalores	1175
14.15.5	Autovalores próximos	1176
14.15.6	Singularidade e dimensão efetiva	1177
14.16	Papel da distribuição probabilística	1178
14.17	Formulação descritiva e formulação inferencial	1179
14.18	Limites da representação por componentes principais	1180
14.19	ACP e Análise Fatorial	1181

14.20 Síntese	1182
15 Formulação da Análise Fatorial	1184
15.1 O problema da estrutura latente	1185
15.2 Modelo de fatores comuns	1186
15.3 Hipóteses do modelo ortogonal	1187
15.4 Estrutura da matriz de covariâncias	1190
15.4.1 Covariâncias entre variáveis	1193
15.4.2 Variâncias das variáveis	1193
15.5 Comunalidades e especificidades	1194
15.6 Cargas fatoriais e associação com os fatores	1197
15.7 Geometria das cargas fatoriais	1198
15.8 Matriz de covariâncias comuns	1199
15.9 Identificação do modelo fatorial	1202
15.9.1 Escala dos fatores	1202
15.9.2 Indeterminação do sinal	1203
15.9.3 Indeterminação rotacional	1203
15.10 Rotação dos eixos fatoriais	1205
15.11 Contagem de parâmetros e identificação	1207
15.12 Fatores ortogonais e fatores oblíquos	1208
15.13 Matriz de padrões e matriz de estrutura	1211
15.14 Formulação populacional e amostral	1213
15.15 Matriz reproduzida e resíduos	1214
15.16 O problema de estimação	1215
15.16.1 Fatores principais	1216
15.16.2 Mínimos quadrados	1217
15.17 Modelo fatorial normal	1217
15.18 Estimação por máxima verossimilhança	1218
15.18.1 Ajuste e graus de liberdade	1220
15.19 Soluções admissíveis e casos de fronteira	1221
15.20 Escores fatoriais	1222
15.21 Distribuição condicional dos fatores	1223
15.22 Pressupostos e limites do modelo	1225
15.22.1 Linearidade e estrutura de segunda ordem	1225
15.22.2 Diagonalidade da estrutura específica	1226
15.22.3 Número de fatores	1226
15.22.4 Dependência do conjunto de variáveis	1227
15.23 Análise Fatorial e Análise de Componentes Principais	1227
15.24 Relação com outros modelos de variáveis latentes	1229
15.25 Síntese	1229
16 Formulação da Análise de Agrupamentos	1232
16.1 O problema de formação de grupos	1233

16.2	Representação dos objetos e proximidade	1234
16.2.1	Efeito da escala	1235
16.3	Partições	1236
16.3.1	Partições rígidas, difusas e probabilísticas	1238
16.4	Homogeneidade interna e separação	1238
16.5	Agrupamento por centroides	1239
16.5.1	Dispersão dentro e entre grupos	1240
16.5.2	Formulação das K -médias	1241
16.5.3	O centroide como minimizador	1243
16.5.4	Partição para centroides fixados	1244
16.5.5	Geometria das regiões de alocação	1245
16.5.6	Existência e não unicidade da solução	1248
16.5.7	Natureza do problema de otimização	1249
16.5.8	Formulação populacional do critério das K -médias	1249
16.5.9	Efeito de transformações sobre as K -médias	1250
16.6	Estrutura dos métodos hierárquicos	1252
16.6.1	Ligações simples, completa e média	1253
16.6.2	Método de Ward e dispersão intragrupos	1255
16.6.3	Dendrograma e níveis de fusão	1258
16.6.4	Ultramétrica induzida pela hierarquia	1260
16.6.5	Uma partição e uma hierarquia representam objetos diferentes	1261
16.7	Diferentes definições matemáticas de grupo	1261
16.7.1	Formulação probabilística de grupos	1262
16.7.2	Grupos definidos por densidade	1264
16.8	Dependência da solução	1265
16.8.1	Dependência das variáveis	1265
16.8.2	Dependência da escala e da métrica	1266
16.8.3	Dependência da forma dos grupos	1266
16.9	Ausência de classes naturais automáticas	1266
16.10	Relações com outras técnicas multivariadas	1267
16.10.1	Agrupamentos e ACP	1268
16.10.2	Agrupamentos e MDS	1268
16.10.3	Agrupamentos e Análise Discriminante	1269
16.10.4	Agrupamentos e MANOVA	1269
16.11	Síntese	1270
17	Formulação do Escalonamento Multidimensional	1272
17.1	O problema de reconstrução geométrica	1273
17.2	Configuração e indeterminações geométricas	1274
17.2.1	Translação	1275
17.2.2	Transformações ortogonais	1275
17.2.3	Centralização da configuração	1277

17.3	Da distância ao produto interno	1278
17.3.1	Matriz das distâncias quadráticas	1279
17.4	Formulação do MDS clássico	1281
17.4.1	Solução espectral	1281
17.4.2	Reprodução euclidiana exata	1283
17.4.3	Dimensão da configuração	1286
17.4.4	Representação em dimensão reduzida	1288
17.4.5	Euclideanidade e autovalores negativos	1290
17.5	MDS clássico e Análise de Componentes Principais	1293
17.6	Formulações baseadas diretamente no ajuste das distâncias	1295
17.6.1	MDS métrico	1296
17.6.2	MDS não métrico	1297
17.6.3	Função de <i>stress</i>	1299
17.6.4	Representação métrica e ordinal	1300
17.6.5	Indeterminações nas formulações baseadas em <i>stress</i>	1301
17.7	Dependência da representação	1301
17.8	Ausência de um modelo probabilístico universal	1302
17.9	Relações com outras técnicas multivariadas	1303
17.9.1	MDS e Análise de Agrupamentos	1303
17.9.2	MDS e ACP	1304
17.9.3	MDS e Análise de Correspondência	1305
17.10	Limites da interpretação geométrica	1305
17.10.1	Proximidade depende da dissimilaridade	1305
17.10.2	Os eixos não possuem interpretação substantiva automática	1306
17.10.3	Representação em baixa dimensão é uma aproximação	1306
17.10.4	Redução dimensional e não euclideanidade são problemas distintos	1307
17.10.5	Estrutura geométrica não implica estrutura de grupos	1307
17.11	Síntese	1307
18	Formulação da Análise de Correspondência	1311
18.1	O problema de associação em uma tabela de contingência	1312
18.2	Frequências marginais, massas e perfis	1313
18.2.1	Perfis de linhas e colunas	1314
18.2.2	Independência como referência	1315
18.3	Geometria dos perfis	1316
18.4	Inércia e afastamento da independência	1317
18.5	Matriz de desvios padronizados	1318
18.5.1	Inércia como norma matricial	1318
18.6	Relação com a estatística qui-quadrado	1319
18.7	Formulação pela decomposição em valores singulares	1320
18.7.1	Inércias principais	1321
18.7.2	Representação em dimensão reduzida	1322

18.8	Coordenadas da Análise de Correspondência	1322
18.8.1	Coordenadas padrão	1323
18.8.2	Coordenadas principais	1323
18.8.3	Distâncias entre perfis e coordenadas principais	1324
18.8.4	Relações baricênticas	1326
18.8.5	Reconstrução dos desvios da independência	1328
18.9	Representação conjunta de linhas e colunas	1331
18.9.1	O significado das proximidades	1331
18.9.2	Contribuição para as dimensões	1332
18.9.3	Qualidade de representação	1333
18.10	Formulação descritiva e inferencial	1335
18.11	Relações com a ACP e o MDS	1337
18.11.1	Relação com a Análise de Componentes Principais	1337
18.11.2	Relação com o Escalonamento Multidimensional	1338
18.12	Pressupostos e limites da representação	1339
18.12.1	Massas positivas	1340
18.12.2	Categorias de pequena massa	1340
18.12.3	Frequências nulas	1341
18.12.4	Dimensão da representação	1341
18.12.5	Sinais e orientação dos eixos	1342
18.12.6	Proximidade entre linhas e colunas	1342
18.12.7	Associação e causalidade	1344
18.13	Síntese	1344
19	Formulação da MANOVA	1346
19.1	O problema de comparação multivariada	1347
19.2	A hipótese no modelo linear multivariado	1348
19.2.1	Matrizes de hipótese e erro	1349
19.3	Hipótese e erro em uma combinação linear das respostas	1350
19.4	Raízes características da MANOVA	1352
19.4.1	Padronização pela dispersão residual	1354
19.5	Critérios multivariados	1355
19.5.1	Lambda de Wilks	1356
19.5.2	Traço de Pillai	1358
19.5.3	Traço de Hotelling–Lawley	1359
19.5.4	Maior raiz de Roy	1359
19.6	Uma mesma estrutura, quatro formas de agregação	1360
19.7	Base probabilística dos critérios	1361
19.7.1	Papel da covariância residual comum	1363
19.7.2	Lambda de Wilks e razão de verossimilhanças	1363
19.8	Casos particulares	1364
19.8.1	Uma única resposta	1364
19.8.2	Duas populações	1365

19.9	Geometria da MANOVA	1367
19.9.1	Geometria após padronização pelo erro	1368
19.10	Invariância a transformações lineares das respostas	1369
19.11	Existência, posto e identificação das direções	1371
19.11.1	Posto da matriz de hipótese	1372
19.11.2	Não singularidade da matriz de erro	1372
19.11.3	Estimabilidade da hipótese	1373
19.11.4	Unicidade das direções	1374
19.12	Pressupostos e limites	1375
19.12.1	Estrutura correta da média	1375
19.12.2	Independência entre unidades	1375
19.12.3	Covariância residual comum	1376
19.12.4	Não singularidade da covariância	1376
19.12.5	Normalidade multivariada	1376
19.13	Relações com outras técnicas	1377
19.13.1	ANOVA	1377
19.13.2	Regressão multivariada	1377
19.13.3	Análise Discriminante	1378
19.14	Síntese	1378
20	Formulação da Análise Discriminante	1381
20.1	O problema de discriminação e classificação	1382
20.2	Classificação como problema de decisão	1383
20.3	Discriminação linear sob normalidade	1386
20.3.1	Fronteiras entre classes	1387
20.3.2	Relação com a distância de Mahalanobis	1388
20.4	Discriminação quadrática	1389
20.4.1	Fronteiras quadráticas	1390
20.5	O que as regras probabilísticas resolvem	1391
20.6	Formulação geométrica de Fisher	1392
20.6.1	Dispersão depois de uma projeção	1393
20.7	Direções discriminantes	1395
20.7.1	Número de direções discriminantes	1396
20.8	Coordenadas discriminantes	1397
20.9	Geometria pela dispersão intragrupos	1399
20.10	O caso de dois grupos	1401
20.11	Relação entre Fisher e a discriminação linear normal	1402
20.12	Existência e singularidade	1404
20.12.1	Formulação de Fisher	1404
20.12.2	Formulações LDA e QDA	1405
20.12.3	Identificação das direções discriminantes	1406
20.13	Pressupostos e limites	1407
20.13.1	Grupos previamente definidos	1407

20.13.2	Normalidade e estrutura de covariâncias	1408
20.13.3	Probabilidades a priori e perdas	1409
20.13.4	Sobreposição entre as populações	1409
20.14	Relações com outras técnicas	1410
20.14.1	MANOVA	1410
20.14.2	Análise de Componentes Principais	1411
20.14.3	Análise de Agrupamentos	1412
20.15	Síntese	1412

21 Formulação da Correlação Canônica 1414

21.1	O problema de associação entre dois blocos	1415
21.2	Estrutura de covariâncias em blocos	1416
21.2.1	Ausência de associação linear entre os blocos	1418
21.3	Variáveis canônicas e função objetivo	1419
21.4	Da normalização ao branqueamento	1421
21.5	Solução pela decomposição em valores singulares	1423
21.6	Pares canônicos sucessivos	1427
21.6.1	Número de correlações canônicas positivas	1429
21.7	Formulação equivalente por autovalores	1430
21.8	Geometria da Correlação Canônica	1432
21.9	Interpretação das variáveis canônicas	1434
21.9.1	Cargas canônicas	1435
21.9.2	Cargas cruzadas	1436
21.9.3	Associação bivariada e associação canônica	1437
21.10	Variância extraída e redundância	1437
21.10.1	Correlação canônica e ângulo	1439
21.11	Formulação amostral	1440
21.12	Invariância, existência e identificação	1442
21.12.1	Invariância a transformações lineares não singulares	1442
21.12.2	Existência da solução clássica	1444
21.12.3	Multicolinearidade	1445
21.12.4	Identificação das direções canônicas	1446
21.13	Pressupostos e limites	1447
21.13.1	Existência de segundos momentos	1447
21.13.2	Não singularidade dentro dos blocos	1447
21.13.3	Normalidade	1448
21.13.4	Dimensão amostral	1448
21.13.5	Observações influentes	1449
21.14	Relações com outras técnicas	1449
21.14.1	Análise de Componentes Principais	1449
21.14.2	Regressão e regressão multivariada	1450
21.14.3	MANOVA	1451
21.14.4	Análise Discriminante	1452

21.15 Síntese	1452
22 Formulação da Análise Conjunta	1455
22.1 O problema da decomposição de preferências	1456
22.1.1 Atributos, níveis e perfis	1457
22.2 Preferência e utilidade	1458
22.3 Utilidades parciais	1459
22.4 Modelo aditivo de utilidade	1460
22.4.1 Aditividade	1461
22.4.2 Compensação entre atributos	1461
22.4.3 Interações entre atributos	1462
22.5 Da utilidade à representação matricial	1463
22.6 Representação matricial do modelo	1464
22.7 Codificação dos níveis	1465
22.7.1 Categoria de referência	1466
22.7.2 Codificação por efeitos	1468
22.8 Identificação do modelo	1469
22.9 Restrições de identificação	1471
22.9.1 Eliminação de uma categoria	1471
22.9.2 Restrição de soma zero	1472
22.10 Equivalência entre parametrizações	1472
22.11 Diferenças de utilidade e funções estimáveis	1473
22.12 Um exemplo de equivalência entre codificações	1474
22.13 Posto e complexidade do modelo	1476
22.14 Do modelo identificado ao delineamento dos perfis	1476
22.15 Delineamento dos perfis	1477
22.15.1 Delineamento fatorial completo	1478
22.15.2 Delineamento fracionário	1478
22.15.3 Ortogonalidade	1479
22.15.4 Balanceamento	1480
22.16 Estimação das utilidades	1480
22.16.1 Utilidade estimada de um perfil	1481
22.17 Interpretação das preferências	1483
22.17.1 Comparação entre níveis	1483
22.17.2 Amplitude das utilidades de um atributo	1483
22.18 Preferências individuais e agregadas	1485
22.18.1 Modelo individual	1485
22.18.2 Modelo agregado	1486
22.19 Diferentes formas de resposta	1486
22.19.1 Avaliação quantitativa	1487
22.19.2 Resposta ordinal	1487
22.19.3 Ordenação	1487
22.19.4 Comparação pareada	1488

22.19.5 Escolha	1488
22.20 Utilidade aleatória	1488
22.21 Natureza relativa da utilidade	1489
22.22 Pressupostos e limites	1490
22.22.1 Definição adequada dos atributos	1490
22.22.2 Aditividade	1490
22.22.3 Compensação	1491
22.22.4 Identificação	1491
22.22.5 Compatibilidade entre resposta e modelo	1491
22.22.6 Independência e estrutura dos erros	1491
22.22.7 Delineamento e estimabilidade	1491
22.22.8 Generalização	1492
22.23 Relações com outras formulações estatísticas	1492
22.23.1 Modelo linear	1492
22.23.2 Delineamento experimental	1493
22.23.3 Modelos de escolha	1493
22.24 Síntese da Análise Conjunta	1493
22.25 Síntese do Módulo 3	1495

Referências	1498
--------------------	-------------

Informações Legais e Declaração de Uso de Inteligência Artificial

Direitos Autorais e Uso da Obra

© 2026 — Os autores.

Todos os direitos reservados. Esta obra é protegida pela legislação brasileira de direitos autorais (Lei nº 9.610/1998). É vedada a reprodução, distribuição, armazenamento ou transmissão total ou parcial deste livro, por qualquer meio ou processo, eletrônico ou mecânico, sem autorização expressa e por escrito dos autores, salvo nos casos permitidos pela legislação vigente para fins exclusivamente acadêmicos e não comerciais, com a devida citação da fonte.

A utilização do material em ambientes de ensino é permitida desde que preservada a integridade do conteúdo, mencionada a autoria e respeitados os princípios de uso responsável da informação científica. A reprodução para fins comerciais, bem como a modificação substancial do conteúdo sem autorização, constitui violação de direitos autorais.

Declaração sobre o Uso de Ferramentas de Inteligência Artificial

Durante a elaboração deste livro foram utilizadas ferramentas de Inteligência Artificial, em especial sistemas de apoio à escrita e organização textual, como recurso complementar no processo de produção acadêmica.

O uso de IA teve caráter **estritamente assistivo**, não substituindo o desenvolvimento conceitual, a formulação matemática, a interpretação estatística nem as decisões pedagógicas da obra. Todo conteúdo foi cuidadosamente revisado, validado e adaptado pelos autores, que assumem integral responsabilidade científica e intelectual pelo texto final.

Não foram delegadas à IA decisões metodológicas, inferenciais ou conclusões analíticas. A elaboração teórica, a seleção de exemplos, a validação matemática e a coerência didática resultam da experiência acadêmica e da atuação dos autores na área de Modelos de Regressão.

Reafirmamos que o uso responsável de tecnologias emergentes deve sempre preservar o rigor científico, a integridade acadêmica e o protagonismo intelectual humano.

Prefácio

Este livro foi elaborado como material de apoio ao estudo da Análise Multivariada no curso de Bacharelado em Estatística da Universidade Federal do Ceará.

A Análise Multivariada costuma ser apresentada por meio de um conjunto de métodos com finalidades distintas, como reduzir a dimensionalidade, identificar estruturas latentes, formar grupos, representar associações, comparar vetores de médias ou classificar observações. Quando essas técnicas são estudadas isoladamente, pode ser difícil perceber que muitas delas compartilham os mesmos objetos e operações: vetores e matrizes, combinações lineares, projeções, formas quadráticas, matrizes de covariâncias, decomposições espectrais, valores singulares, distâncias e modelos probabilísticos.

O livro foi organizado para tornar essas relações explícitas. O **Módulo I** apresenta os fundamentos matemáticos e geométricos necessários à representação e à transformação dos dados multivariados. O **Módulo II** desenvolve os fundamentos probabilísticos e inferenciais, incluindo matrizes de covariâncias e correlações, distribuição normal multivariada, estatísticas amostrais, estimação, modelo linear e inferência. O **Módulo III** mostra como esses resultados são combinados na formulação matemática e estatística das principais técnicas multivariadas.

A exposição busca equilibrar rigor e interpretação. As definições e propriedades são acompanhadas, sempre que possível, por representações geométricas, exemplos numéricos e conexões com os problemas estatísticos que motivam cada resultado. As demonstrações são incluídas quando contribuem diretamente para a compreensão da estrutura dos métodos; resultados mais especializados são apresentados de forma compatível com os objetivos de uma disciplina de graduação.

As técnicas são inicialmente estudadas a partir do problema que procuram resolver, dos dados que utilizam e dos objetos matemáticos que definem sua solução. A formulação conceitual antecede os algoritmos, os procedimentos computacionais e a interpretação aplicada. Essa organização permite compreender por que cada técnica assume determinada forma e quais fundamentos são necessários para utilizá-la adequadamente.

Identificação da Disciplina

Curso: Bacharelado em Estatística

Disciplina: Análise Multivariada

Carga Horária: 96 horas

Período Letivo: 2026.2

Professores: Dr. Rafael Bráz Azevedo Farias e Dra. Alessandra Cristina da Silva Farias

EMENTA

Fundamentos matemáticos, geométricos, probabilísticos e inferenciais da Análise Multivariada. Representação vetorial e matricial dos dados, espaços vetoriais, projeções, transformações lineares, decomposição espectral e decomposição em valores singulares. Matrizes de covariâncias e correlações, distribuição normal multivariada, estatísticas amostrais, estimação, modelo linear e inferência multivariada. Formulação matemática e estatística das principais técnicas multivariadas.

OBJETIVO GERAL

Compreender os fundamentos matemáticos, geométricos, probabilísticos e estatísticos que sustentam a Análise Multivariada e reconhecer como esses fundamentos são utilizados na formulação, na aplicação e na interpretação das principais técnicas multivariadas.

OBJETIVOS ESPECÍFICOS

Ao final da disciplina, o estudante deverá ser capaz de:

- representar dados multivariados por meio de vetores e matrizes;
- interpretar geometricamente observações, variáveis, distâncias, projeções e transformações;

- compreender o papel de autovalores, autovetores, decomposição espectral e decomposição em valores singulares;
- analisar a estrutura de matrizes de covariâncias e correlações;
- compreender os fundamentos da distribuição normal multivariada, da estimação e da inferência;
- identificar os problemas estatísticos que dão origem às principais técnicas multivariadas;
- relacionar cada técnica aos seus objetos matemáticos, critérios de otimização ou modelos probabilísticos;
- distinguir técnicas de redução de dimensionalidade, representação de estruturas latentes, agrupamento, associação, comparação e classificação;
- conduzir análises multivariadas com apoio computacional;
- interpretar criticamente os resultados e comunicar conclusões compatíveis com os dados e com os pressupostos adotados.

CONTEÚDO PROGRAMÁTICO

Módulo I – Fundamentos Matemáticos e Geométricos da Análise Multivariada

Vetores e representação dos dados multivariados

Álgebra matricial aplicada

Espaços vetoriais, bases e projeções

Transformações lineares

Autovalores, autovetores e decomposição espectral

Decomposição em valores singulares

Cálculo diferencial, integral e matricial aplicado à Estatística Multivariada

Módulo II – Fundamentos Probabilísticos e Inferenciais da Análise Multivariada

Matrizes de covariâncias e correlações

Distribuição normal multivariada

Estatísticas amostrais e estimação

Modelo linear multivariado e hipóteses lineares

Inferência multivariada

Módulo III – Formulação Matemática e Estatística das Técnicas Multivariadas

Problemas e estruturas das técnicas multivariadas

Análise de Componentes Principais

Análise Fatorial

Análise de Agrupamentos

Escalonamento Multidimensional
Análise de Correspondência
Análise Multivariada de Variância
Análise Discriminante
Correlação Canônica
Análise Conjunta

METODOLOGIA

A disciplina será desenvolvida por meio de aulas expositivo-dialogadas, atividades práticas em laboratório e exercícios de interpretação. Os fundamentos matemáticos, probabilísticos e inferenciais serão articulados à formulação e à aplicação das técnicas multivariadas.

Serão utilizados exemplos numéricos, representações geométricas, demonstrações selecionadas e conjuntos de dados reais ou simulados. A parte computacional será conduzida de modo a apoiar a compreensão dos métodos, a verificação dos pressupostos e a interpretação dos resultados.

AVALIAÇÃO

As avaliações contemplarão os fundamentos teóricos, a condução das análises e a interpretação dos resultados. Poderão ser utilizadas provas escritas, avaliações práticas em laboratório, exercícios e outras atividades definidas no plano de ensino da disciplina.

A aprovação seguirá as normas vigentes da Universidade Federal do Ceará.

CRITÉRIOS DE AVALIAÇÃO

Serão considerados:

- correção matemática e estatística;
- domínio conceitual;
- adequação das decisões metodológicas;
- interpretação dos resultados no contexto do problema;
- clareza e organização da exposição escrita;
- qualidade e reprodutibilidade das análises computacionais.

BIBLIOGRAFIA BÁSICA

ANDERSON, T. W.

An Introduction to Multivariate Statistical Analysis. 3rd ed. Wiley, 2003. (Anderson, 2003)

ARTES, R.; BARROSO, L. P.; PAULA, G. A.

Métodos Multivariados de Análise Estatística. (Artes; Barroso, 2023)

HAIR, J. F. et al.

Multivariate Data Analysis. (Hair et al., 2018)

BIBLIOGRAFIA COMPLEMENTAR

ARTES, R.; BARROSO, L. P.; PAULA, G. A.

Métodos Multivariados de Análise Estatística. (Artes; Barroso, 2023)

JOHNSON, R. A.; WICHERN, D. W.

Applied Multivariate Statistical Analysis. 6th ed. Pearson, 2007. (Johnson; Wichern, 2007)

MANLY, B. F. J.; ALBERTO, J. A. N.

Métodos Estatísticos Multivariados: Uma Introdução. (Manly; Navarro Alberto, 2019)

MARDIA, K. V.; KENT, J. T.; TAYLOR, C. C.

Multivariate Analysis. (Mardia; Kent; Taylor, 2024)

MINGOTI, S. A.

Análise de Dados Através de Métodos de Estatística Multivariada: Uma Abordagem Aplicada. Belo Horizonte: Editora UFMG, 2005. (Mingoti, 2005)

RENCER, A. C.; CHRISTENSEN, W. F.

Methods of Multivariate Analysis. (Rencher; Christensen, 2012)

Parte I

Módulo I — Fundamentos Matemáticos e Geométricos da Análise Multivariada

1 Vetores e representação dos dados multivariados

Em estudos multivariados, cada unidade observacional é descrita por várias características registradas simultaneamente. Quando são observadas p variáveis quantitativas, esses valores podem ser organizados em um vetor de $\mathbb{R}^p$.

Para n unidades, os vetores formam uma matriz de dados de dimensão $n \times p$, na qual as linhas representam as observações e as colunas representam as variáveis.

Essa representação permite interpretar as observações como pontos em um espaço multidimensional e estudar suas relações por meio de operações vetoriais e conceitos geométricos.

O capítulo apresenta escalares, vetores, matrizes, o espaço $\mathbb{R}^p$, a matriz de dados, as operações com vetores, o produto interno, a norma, o ângulo, a distância euclidiana e o produto externo.

Convenções gerais de notação

As convenções abaixo indicam apenas como os objetos serão representados. Seus significados e propriedades serão definidos ao longo do capítulo.

- letras minúsculas sem negrito, como a , x e α , representam escalares;
- letras minúsculas em negrito, como $\mathbf{x}$ e $\mathbf{y}$, representam vetores observados;
- letras maiúsculas em negrito, como $\mathbf{A}$ e $\mathbf{X}$, representam matrizes;
- letras maiúsculas sem negrito, como X , representam variáveis aleatórias escalares;
- o vetor aleatório multivariado será representado por $\mathbf{X}$;
- a realização observada de $\mathbf{X}$ será representada por $\mathbf{x}$;
- o elemento situado na posição i de um vetor será indicado por x_i ;
- o elemento situado na linha i e na coluna j de uma matriz será indicado por a_{ij} ;
- a i -ésima linha de uma matriz $\mathbf{A}$ será representada por $\mathbf{a}_i^\top$;
- a j -ésima coluna de uma matriz $\mathbf{A}$ será representada por $\mathbf{a}_{.j}$;
- quando não houver ambiguidade, $\mathbf{a}_i^\top$ poderá ser utilizada como forma abreviada de $\mathbf{a}_i^\top$;
- o vetor-coluna associado à i -ésima linha será representado por $\mathbf{a}_i \in \mathbb{R}^p$;
- o ponto na notação matricial indica o índice que varia;
- $\mathbb{R}^p$ representa o espaço dos vetores reais com p componentes;
- $\mathbb{R}^{n \times p}$ representa o conjunto das matrizes reais com n linhas e p colunas;

- o símbolo $\top$ indica transposição;
- $\mathbf{0}$ representa um vetor ou uma matriz nula, com dimensão determinada pelo contexto.

Para a matriz de dados $\mathbf{X}$, será adotada a mesma convenção para as linhas: $\mathbf{x}_i \in \mathbb{R}^p$ representa a observação i , $\mathbf{x}_i^\top$ representa essa observação como a i -ésima linha de $\mathbf{X}$ e $\mathbf{x}_{.j} \in \mathbb{R}^n$ representa a coluna correspondente à variável j . Quando houver risco de ambiguidade, a dimensão será indicada explicitamente.

1.1 Escalares, vetores e matrizes

Em uma análise univariada, cada observação é representada pelo valor de uma única variável. Quando várias variáveis são medidas na mesma unidade observacional, seus valores podem ser organizados em um vetor. Os vetores de todas as unidades formam uma matriz de dados.

Definição 1.1 (Escalar). Um **escalar** é um número real:

$$a \in \mathbb{R}.$$

Em uma aplicação estatística, um escalar pode representar uma medida observada ou o coeficiente de uma expressão matemática.

Em Estatística, uma variável aleatória escalar será representada por uma letra maiúscula, como X . Uma realização dessa variável será representada pela letra minúscula correspondente:

$$x \in \mathbb{R}.$$

Por exemplo, X pode representar a massa de uma unidade selecionada aleatoriamente, enquanto $x = 65$ representa um valor observado.

Definição 1.2 (Vetor aleatório e vetor observado). Um **vetor aleatório** de dimensão p é uma coleção ordenada de p variáveis aleatórias:

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix} = (X_1, X_2, \dots, X_p)^\top.$$

Uma realização de $\mathbf{X}$ é representada pelo vetor observado

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix} = (x_1, x_2, \dots, x_p)^\top \in \mathbb{R}^p.$$

Cada componente x_j corresponde ao valor observado da variável j , para $j = 1, \dots, p$.

Exemplo 1.1 (Representação de uma observação). Considere uma unidade descrita por três variáveis:

- X_1 : idade, em anos;
- X_2 : massa corporal, em quilogramas;
- X_3 : altura, em centímetros.

O vetor aleatório é

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix}.$$

Para uma unidade com 52 anos, 74 quilogramas e 168 centímetros de altura, o vetor observado é

$$\mathbf{x} = \begin{bmatrix} 52 \\ 74 \\ 168 \end{bmatrix}.$$

A ordem das componentes identifica a correspondência entre valores e variáveis. Assim,

$$\begin{bmatrix} 52 \\ 74 \\ 168 \end{bmatrix} \neq \begin{bmatrix} 74 \\ 52 \\ 168 \end{bmatrix}$$

O primeiro vetor representa uma unidade com 52 anos, 74 quilogramas e 168 centímetros de altura. O segundo representa uma unidade com 74 anos, 52 quilogramas e 168 centímetros de altura.

Neste momento, o vetor é utilizado apenas para organizar as medidas. A comparação geométrica de variáveis com unidades diferentes exigirá atenção às escalas.

Dois vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ são iguais quando suas componentes correspondentes são iguais:

$$\mathbf{x} = \mathbf{y} \iff x_j = y_j, \quad j = 1, \dots, p.$$

Definição 1.3 (Matriz). Uma **matriz** com n linhas e p colunas é um arranjo retangular de números:

$$\mathbf{A} = (a_{ij})_{n \times p} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1p} \\ a_{21} & a_{22} & \cdots & a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

O elemento a_{ij} ocupa a linha i e a coluna j .

A dimensão de $\mathbf{A}$ é $n \times p$. O primeiro número indica a quantidade de linhas, e o segundo indica a quantidade de colunas.

Para a matriz $\mathbf{A}$ definida anteriormente, a i -ésima linha é o vetor-linha

$$\mathbf{a}_{i\cdot}^\top = [a_{i1} \quad a_{i2} \quad \cdots \quad a_{ip}] \in \mathbb{R}^{1 \times p},$$

enquanto a j -ésima coluna é o vetor-coluna

$$\mathbf{a}_{\cdot j} = \begin{bmatrix} a_{1j} \\ a_{2j} \\ \vdots \\ a_{nj} \end{bmatrix} \in \mathbb{R}^{n \times 1}.$$

O ponto na notação indica o índice que varia. Assim:

- em $\mathbf{a}_{i\cdot}^\top$, a linha i permanece fixa e o índice das colunas varia;
- em $\mathbf{a}_{\cdot j}$, a coluna j permanece fixa e o índice das linhas varia.

Notação abreviada para linhas

Quando não houver risco de ambiguidade, a notação das linhas da matriz $\mathbf{A}$ poderá ser simplificada. Em particular, o vetor associado à i -ésima linha será representado por

$$\mathbf{a}_i \in \mathbb{R}^p,$$

de modo que a i -ésima linha da matriz poderá ser escrita como

$$\mathbf{a}_i^\top = \mathbf{a}_{i\cdot}^\top.$$

A notação com ponto será utilizada quando for necessário distinguir explicitamente linhas e colunas da mesma matriz.

Essa convenção será especialmente útil para a matriz de dados $\mathbf{X}$, em que $\mathbf{x}_i \in \mathbb{R}^p$ representa a i -ésima observação e $\mathbf{x}_i^\top$ representa essa observação como a i -ésima linha de $\mathbf{X}$. As colunas permanecerão representadas explicitamente por $\mathbf{x}_{.j}$.

Com essas convenções, a matriz pode ser representada por suas linhas,

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_{1.}^\top \\ \mathbf{a}_{2.}^\top \\ \vdots \\ \mathbf{a}_{n.}^\top \end{bmatrix} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_n^\top \end{bmatrix},$$

ou por suas colunas,

$$\mathbf{A} = [\mathbf{a}_{.1} \ \mathbf{a}_{.2} \ \cdots \ \mathbf{a}_{.p}].$$

1.1.1 Vetor-coluna, vetor-linha e transposição

Definição 1.4 (Vetor-coluna, vetor-linha e transposição). Um vetor-coluna com p componentes pode ser tratado como uma matriz de dimensão $p \times 1$:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix} \in \mathbb{R}^{p \times 1}.$$

A **transposição** é a operação que troca as linhas de uma matriz por suas colunas e é indicada pelo símbolo $\top$.

A transposta do vetor-coluna $\mathbf{x}$ é o vetor-linha

$$\mathbf{x}^\top = [x_1 \ x_2 \ \cdots \ x_p] \in \mathbb{R}^{1 \times p}.$$

Portanto,

$$\mathbf{x} \in \mathbb{R}^{p \times 1} \quad \implies \quad \mathbf{x}^\top \in \mathbb{R}^{1 \times p}.$$

A Tabela 1.1 resume a notação utilizada no capítulo.

Tabela 1.1: Notação utilizada para escalares, vetores e matrizes.

Objeto	Notação	Descrição
Escalar	a	Número real
Variável aleatória escalar	X	Variável que assume valores em $\mathbb{R}$
Realização escalar	x	Valor observado de X
Vetor aleatório	$\mathbf{X}$	Coleção ordenada de variáveis aleatórias
Vetor observado	$\mathbf{x}$	Realização de um vetor aleatório
Matriz genérica	$\mathbf{A}$	Arranjo retangular de números
Linha i de uma matriz	$\mathbf{a}_i^\top$ ou $\mathbf{a}_i^\top$	Vetor-linha formado pelos elementos da linha i de $\mathbf{A}$
Coluna j de uma matriz	$\mathbf{a}_{\cdot j}$	Vetor-coluna formado pelos elementos da coluna j de $\mathbf{A}$
Matriz de dados	$\mathbf{X}$	Matriz observada com linhas e colunas associadas às unidades e às variáveis

Um escalar representa uma medida, um vetor reúne as medidas de uma unidade e uma matriz organiza os valores de várias unidades. A representação dos vetores em $\mathbb{R}^p$ será desenvolvida na próxima seção.

1.2 O espaço $\mathbb{R}^p$

Os valores observados de p variáveis quantitativas podem ser organizados em um vetor com p componentes. O conjunto de todos os vetores desse tipo é denotado por $\mathbb{R}^p$.

Definição 1.5 (Espaço $\mathbb{R}^p$). O espaço $\mathbb{R}^p$ é o conjunto

$$\mathbb{R}^p = \{(x_1, x_2, \dots, x_p)^\top : x_j \in \mathbb{R}, j = 1, \dots, p\}.$$

Cada elemento de $\mathbb{R}^p$ é um vetor formado por p componentes reais.

Uma observação descrita por p variáveis pode ser representada por

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{bmatrix} \in \mathbb{R}^p,$$

em que x_{ij} é o valor da variável j observado na unidade i .

Neste livro, o espaço $\mathbb{R}^p$ no qual são representadas as unidades observacionais será denominado **espaço das observações**. Cada vetor representa uma unidade, e cada componente corresponde a uma variável.

A dimensão do espaço é determinada pelo número de variáveis:

- para $p = 1$, cada observação possui uma componente;
- para $p = 2$, cada observação possui duas componentes;
- para $p = 3$, cada observação possui três componentes;
- para $p > 3$, a representação permanece definida em $\mathbb{R}^p$, embora não possa ser visualizada diretamente em sua totalidade.

A Figura 1.1 apresenta os três casos que podem ser representados graficamente.




Figura 1.1: Representação de observações em espaços de uma, duas e três dimensões.

Exemplo 1.2 (Observação em duas dimensões). Considere duas variáveis quantitativas, X_1 e X_2 . A observação i é representada por

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \end{bmatrix} \in \mathbb{R}^2.$$

Se $x_{i1} = 3$ e $x_{i2} = 5$, então

$$\mathbf{x}_i = \begin{bmatrix} 3 \\ 5 \end{bmatrix}.$$

Esse vetor pode ser representado por uma seta que parte da origem e termina no ponto de coordenadas $(3, 5)$, como mostra a Figura 1.2.




Figura 1.2: Representação do vetor $\mathbf{x}_i = (3, 5)^\top$ no plano.

A extremidade da seta determina o ponto $(3, 5)$. Assim, o vetor $\mathbf{x}_i$ pode ser interpretado geometricamente como uma seta com origem em $(0, 0)$ e extremidade em $(3, 5)$.

O número de observações e o número de variáveis possuem funções distintas. Para um conjunto com n observações e p variáveis:

- n determina a quantidade de pontos;
- p determina a dimensão do espaço ambiente.

As n observações formam uma nuvem de pontos em $\mathbb{R}^p$.

Os vetores correspondentes às n observações serão organizados em uma matriz de dados na próxima seção.

1.3 Representação matricial de um conjunto de dados

Considere n unidades observacionais descritas pelas mesmas p variáveis quantitativas. A observação i é representada pelo vetor

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{bmatrix} \in \mathbb{R}^p, \quad i = 1, \dots, n.$$

Cada componente x_{ij} corresponde ao valor da variável j observado na unidade i . Os n vetores observados podem ser organizados nas linhas de uma matriz.

Definição 1.6 (Matriz de dados). A **matriz de dados** de n observações e p variáveis é definida por

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

O elemento x_{ij} representa o valor da variável j observado na unidade i .

As linhas da matriz correspondem às observações, e as colunas correspondem às variáveis. Essa organização coincide com a estrutura usual de uma planilha ou de um banco de dados.

Com a notação estabelecida anteriormente, a matriz de dados pode ser representada por suas linhas como

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix},$$

ou por suas colunas como

$$\mathbf{X} = [\mathbf{x}_{\cdot 1} \ \mathbf{x}_{\cdot 2} \ \cdots \ \mathbf{x}_{\cdot p}].$$

Exemplo 1.3 (Matriz de dados com duas variáveis). Considere quatro unidades observacionais descritas pelas variáveis X_1 e X_2 . Os vetores observados são

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 5 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} 3 \\ 1 \end{bmatrix},$$

$$\mathbf{x}_3 = \begin{bmatrix} 5 \\ 7 \end{bmatrix}, \quad \mathbf{x}_4 = \begin{bmatrix} 8 \\ 3 \end{bmatrix}.$$

A matriz de dados é

$$\mathbf{X} = \begin{bmatrix} 1 & 5 \\ 3 & 1 \\ 5 & 7 \\ 8 & 3 \end{bmatrix} \in \mathbb{R}^{4 \times 2}.$$

A terceira observação é

$$\mathbf{x}_3 = \begin{bmatrix} 5 \\ 7 \end{bmatrix},$$

e aparece na matriz como a terceira linha,

$$\mathbf{x}_3^\top = \begin{bmatrix} 5 & 7 \end{bmatrix}.$$

O elemento

$$x_{32} = 7$$

é o valor da segunda variável observado na terceira unidade.

1.3.1 Espaço das observações e espaço das variáveis

A organização da matriz de dados permite considerar dois conjuntos de vetores.

Pelas linhas,

$$\mathbf{x}_i \in \mathbb{R}^p, \quad i = 1, \dots, n,$$

cada vetor representa uma observação descrita pelas p variáveis.

Pelas colunas,

$$\mathbf{x}_{\cdot j} \in \mathbb{R}^n, \quad j = 1, \dots, p,$$

cada vetor representa uma variável observada nas n unidades.

No **espaço das observações**, cada unidade observacional é representada por um ponto em $\mathbb{R}^p$, cujas coordenadas correspondem às variáveis.

No **espaço das variáveis**, cada variável é representada por um vetor em $\mathbb{R}^n$, cujas componentes correspondem às unidades observacionais.

A Tabela 1.2 resume essas duas representações.

Tabela 1.2: Representações da matriz de dados por linhas e colunas.

Representação	Vetor	Objeto representado	Espaço	Quantidade
Linhas de $\mathbf{X}$	$\mathbf{x}_i$	Observação i	$\mathbb{R}^p$	n vetores
Colunas de $\mathbf{X}$	$\mathbf{x}_{\cdot j}$	Variável j	$\mathbb{R}^n$	p vetores

A interpretação utilizada depende do objeto de interesse. Relações entre unidades observacionais são estudadas a partir das linhas da matriz, enquanto relações entre variáveis são estudadas a partir de suas colunas.

1.4 Operações elementares com vetores

Considere os vetores

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_p \end{bmatrix} \in \mathbb{R}^p$$

e um escalar $\alpha \in \mathbb{R}$.

Dois vetores são iguais quando suas componentes correspondentes são iguais:

$$\mathbf{x} = \mathbf{y} \iff x_j = y_j, \quad j = 1, \dots, p.$$

1.4.1 Soma e subtração

A soma de dois vetores é realizada componente a componente:

$$\mathbf{x} + \mathbf{y} = \begin{bmatrix} x_1 + y_1 \\ x_2 + y_2 \\ \vdots \\ x_p + y_p \end{bmatrix} \in \mathbb{R}^p.$$

A diferença também é calculada componente a componente:

$$\mathbf{x} - \mathbf{y} = \begin{bmatrix} x_1 - y_1 \\ x_2 - y_2 \\ \vdots \\ x_p - y_p \end{bmatrix} \in \mathbb{R}^p.$$

O vetor $\mathbf{x} - \mathbf{y}$ representa o deslocamento de $\mathbf{y}$ até $\mathbf{x}$.

Exemplo 1.4 (Soma e subtração de vetores). Considere

$$\mathbf{x} = \begin{bmatrix} 2,0 \\ 1,5 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 1,0 \\ 3,0 \end{bmatrix}.$$

A soma é

$$\mathbf{x} + \mathbf{y} = \begin{bmatrix} 2,0 + 1,0 \\ 1,5 + 3,0 \end{bmatrix} = \begin{bmatrix} 3,0 \\ 4,5 \end{bmatrix}.$$

A diferença é

$$\mathbf{x} - \mathbf{y} = \begin{bmatrix} 2,0 - 1,0 \\ 1,5 - 3,0 \end{bmatrix} = \begin{bmatrix} 1,0 \\ -1,5 \end{bmatrix}.$$

Definição 1.7 (Vetor nulo). O **vetor nulo** de $\mathbb{R}^p$ é definido por

$$\mathbf{0} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$

Ele é o elemento neutro da adição:

$$\mathbf{x} + \mathbf{0} = \mathbf{x}.$$

A Figura 1.3 apresenta a interpretação geométrica da soma em $\mathbb{R}^2$.

Na figura, os vetores $\mathbf{x}$ e $\mathbf{y}$ formam dois lados de um paralelogramo. A diagonal que parte da origem representa $\mathbf{x} + \mathbf{y}$.

1.4.2 Multiplicação por escalar

A multiplicação do vetor $\mathbf{x}$ pelo escalar α é definida por

$$\alpha \mathbf{x} = \begin{bmatrix} \alpha x_1 \\ \alpha x_2 \\ \vdots \\ \alpha x_p \end{bmatrix} \in \mathbb{R}^p.$$

A norma do vetor resultante satisfaz

$$\|\alpha \mathbf{x}\| = |\alpha| \|\mathbf{x}\|.$$

Portanto, para $\mathbf{x} \neq \mathbf{0}$:

- se $|\alpha| > 1$, o comprimento do vetor aumenta;




Figura 1.3: Soma de vetores pela regra do paralelogramo.

- se $0 < |\alpha| < 1$, o comprimento do vetor diminui;
- se $|\alpha| = 1$, o comprimento do vetor é preservado;
- se $\alpha = 0$, o resultado é o vetor nulo;
- se $\alpha < 0$, o sentido do vetor é invertido.

As alterações de comprimento dependem de $|\alpha|$, enquanto a inversão do sentido depende do sinal de α . Assim, um escalar negativo pode aumentar, diminuir ou preservar o comprimento do vetor.

Quando $\mathbf{x} = \mathbf{0}$, tem-se

$$\alpha \mathbf{x} = \mathbf{0}$$

para qualquer $\alpha \in \mathbb{R}$.

Exemplo 1.5 (Multiplicação por escalar). Para

$$\mathbf{x} = \begin{bmatrix} 2,0 \\ -1,5 \end{bmatrix}$$

e $\alpha = -2$, tem-se

$$-2\mathbf{x} = \begin{bmatrix} -2(2,0) \\ -2(-1,5) \end{bmatrix} = \begin{bmatrix} -4,0 \\ 3,0 \end{bmatrix}.$$

1.4.3 Combinações lineares

Uma combinação linear é construída por meio das duas operações apresentadas anteriormente: a multiplicação de vetores por escalares e a adição de vetores.

Definição 1.8 (Combinação linear de vetores). Sejam

$$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k \in \mathbb{R}^p$$

e

$$\alpha_1, \alpha_2, \dots, \alpha_k \in \mathbb{R}.$$

Uma **combinação linear** dos vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$ é qualquer vetor da forma

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_k \mathbf{v}_k.$$

O resultado também pertence a $\mathbb{R}^p$, pois é obtido por multiplicações por escalares e somas de vetores de $\mathbb{R}^p$:

$$\alpha_1 \mathbf{v}_1 + \cdots + \alpha_k \mathbf{v}_k \in \mathbb{R}^p.$$

Exemplo 1.6 (Combinação linear de vetores). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 3 \\ -1 \end{bmatrix}.$$

A combinação linear $2\mathbf{v}_1 - \mathbf{v}_2$ é

$$2\mathbf{v}_1 - \mathbf{v}_2 = 2 \begin{bmatrix} 1 \\ 2 \end{bmatrix} - \begin{bmatrix} 3 \\ -1 \end{bmatrix} = \begin{bmatrix} -1 \\ 5 \end{bmatrix}.$$

As combinações lineares permitem construir novos vetores a partir de vetores já conhecidos. Seus coeficientes determinam quanto cada vetor contribui para o resultado.

Exemplo 1.7 (Combinação linear das variáveis). Considere as variáveis X_1 , X_2 e X_3 e os coeficientes

$$a_1 = 2,0, \quad a_2 = -0,5, \quad a_3 = 3,0.$$

A combinação linear definida por esses coeficientes é

$$Y = 2,0X_1 - 0,5X_2 + 3,0X_3.$$

Para uma observação com valores

$$x_1 = 4,0, \quad x_2 = 2,0, \quad x_3 = 1,5,$$

o valor observado da combinação linear é

$$y = 2,0(4,0) - 0,5(2,0) + 3,0(1,5) = 11,5.$$

Em uma combinação linear, cada coeficiente determina a contribuição do vetor ou da variável correspondente para o resultado.

As operações anteriores produzem novos vetores ou novas variáveis. A próxima operação tem natureza diferente: o produto interno associa dois vetores a um número real e permite construir as noções de comprimento, ângulo, ortogonalidade e distância.

1.5 Produto interno, norma, ângulo e distância euclidiana

O produto interno associa dois vetores de $\mathbb{R}^p$ a um número real. A partir dessa operação, definem-se norma, ângulo, ortogonalidade e distância euclidiana.

1.5.1 Produto interno euclidiano

Definição 1.9 (Produto interno euclidiano). Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, o **produto interno euclidiano** entre $\mathbf{x}$ e $\mathbf{y}$ é definido por

$$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_{j=1}^p x_j y_j.$$

Em termos das componentes,

$$\langle \mathbf{x}, \mathbf{y} \rangle = x_1 y_1 + x_2 y_2 + \cdots + x_p y_p.$$

O resultado do produto interno é um escalar.

Exemplo 1.8 (Cálculo do produto interno). Considere

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \\ 3 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 4 \\ 2 \\ -1 \end{bmatrix}.$$

Então,

$$\langle \mathbf{x}, \mathbf{y} \rangle = 2(4) + 1(2) + 3(-1) = 7.$$

Proposição 1.1 (Propriedades do produto interno euclidiano). *Para quaisquer vetores $\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$ e quaisquer escalares $\alpha, \beta \in \mathbb{R}$, o produto interno euclidiano satisfaz as seguintes propriedades:*

1. Simetria

$$\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{y}, \mathbf{x} \rangle.$$

2. Linearidade no primeiro argumento

$$\langle \alpha \mathbf{x} + \beta \mathbf{z}, \mathbf{y} \rangle = \alpha \langle \mathbf{x}, \mathbf{y} \rangle + \beta \langle \mathbf{z}, \mathbf{y} \rangle.$$

3. *Linearidade no segundo argumento*

$$\langle \mathbf{x}, \alpha \mathbf{y} + \beta \mathbf{z} \rangle = \alpha \langle \mathbf{x}, \mathbf{y} \rangle + \beta \langle \mathbf{x}, \mathbf{z} \rangle.$$

4. *Não negatividade*

$$\langle \mathbf{x}, \mathbf{x} \rangle \geq 0.$$

5. *Positividade definida*

$$\langle \mathbf{x}, \mathbf{x} \rangle = 0 \quad \Longleftrightarrow \quad \mathbf{x} = \mathbf{0}.$$

1.5.2 Norma euclidiana

Definição 1.10 (Norma euclidiana). A **norma euclidiana** de $\mathbf{x} \in \mathbb{R}^p$ é definida por

$$\|\mathbf{x}\| = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle} = \sqrt{x_1^2 + x_2^2 + \cdots + x_p^2}.$$

A norma representa o comprimento do vetor em relação à origem.

Para qualquer $\mathbf{x} \in \mathbb{R}^p$ e $\alpha \in \mathbb{R}$,

$$\|\mathbf{x}\| \geq 0,$$

$$\|\mathbf{x}\| = 0 \quad \Longleftrightarrow \quad \mathbf{x} = \mathbf{0},$$

e

$$\|\alpha \mathbf{x}\| = |\alpha| \|\mathbf{x}\|.$$

Exemplo 1.9 (Norma de um vetor). Para

$$\mathbf{x} = \begin{bmatrix} 3 \\ 4 \end{bmatrix},$$

tem-se

$$\|\mathbf{x}\| = \sqrt{3^2 + 4^2} = 5.$$

A Figura 1.4 mostra a representação geométrica desse vetor no plano. O comprimento da seta corresponde à norma euclidiana do vetor.




Figura 1.4: A norma euclidiana corresponde ao comprimento do vetor.

Nesse caso, a norma coincide com a hipotenusa de um triângulo retângulo cujos catetos têm comprimentos 3 e 4.

1.5.3 Desigualdade de Cauchy–Schwarz

Teorema 1.1 (Desigualdade de Cauchy–Schwarz). *Para quaisquer vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,*

$$|\langle \mathbf{x}, \mathbf{y} \rangle| \leq \|\mathbf{x}\| \|\mathbf{y}\|.$$

A igualdade ocorre se, e somente se, um dos vetores é múltiplo escalar do outro. (Meyer, 2023)

Comprovação. Se $\mathbf{y} = \mathbf{0}$, então

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0$$

e

$$\|\mathbf{x}\| \|\mathbf{y}\| = 0.$$

Portanto, a desigualdade é satisfeita com igualdade. Além disso,

$$\mathbf{y} = 0\mathbf{x},$$

de modo que um dos vetores é múltiplo escalar do outro.

Considere agora $\mathbf{y} \neq \mathbf{0}$. Para qualquer escalar $\alpha \in \mathbb{R}$, a não negatividade do produto interno implica

$$\langle \mathbf{x} - \alpha\mathbf{y}, \mathbf{x} - \alpha\mathbf{y} \rangle \geq 0.$$

Escolha

$$\alpha = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{y}\|^2}.$$

Expandindo o produto interno,

$$\begin{aligned} 0 &\leq \langle \mathbf{x} - \alpha\mathbf{y}, \mathbf{x} - \alpha\mathbf{y} \rangle \\ &= \langle \mathbf{x}, \mathbf{x} \rangle - \alpha \langle \mathbf{x}, \mathbf{y} \rangle - \alpha \langle \mathbf{y}, \mathbf{x} \rangle + \alpha^2 \langle \mathbf{y}, \mathbf{y} \rangle \\ &= \|\mathbf{x}\|^2 - 2\alpha \langle \mathbf{x}, \mathbf{y} \rangle + \alpha^2 \|\mathbf{y}\|^2. \end{aligned}$$

Na última igualdade, foi utilizada a simetria do produto interno:

$$\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{y}, \mathbf{x} \rangle.$$

Substituindo o valor escolhido para α ,

$$\begin{aligned}
0 &\leq \|\mathbf{x}\|^2 - 2 \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{y}\|^2} \langle \mathbf{x}, \mathbf{y} \rangle \\
&\quad + \left(\frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{y}\|^2} \right)^2 \|\mathbf{y}\|^2 \\
&= \|\mathbf{x}\|^2 - \frac{\langle \mathbf{x}, \mathbf{y} \rangle^2}{\|\mathbf{y}\|^2}.
\end{aligned}$$

Logo,

$$\frac{\langle \mathbf{x}, \mathbf{y} \rangle^2}{\|\mathbf{y}\|^2} \leq \|\mathbf{x}\|^2.$$

Como $\|\mathbf{y}\|^2 > 0$, podemos multiplicar os dois lados por esse valor e obter

$$\langle \mathbf{x}, \mathbf{y} \rangle^2 \leq \|\mathbf{x}\|^2 \|\mathbf{y}\|^2.$$

Tomando a raiz quadrada dos dois lados,

$$|\langle \mathbf{x}, \mathbf{y} \rangle| \leq \|\mathbf{x}\| \|\mathbf{y}\|.$$

Resta examinar quando ocorre a igualdade. Na construção anterior, a igualdade é satisfeita se, e somente se,

$$\langle \mathbf{x} - \alpha \mathbf{y}, \mathbf{x} - \alpha \mathbf{y} \rangle = 0.$$

Pela positividade definida do produto interno, isso ocorre se, e somente se,

$$\mathbf{x} - \alpha \mathbf{y} = \mathbf{0},$$

ou seja,

$$\mathbf{x} = \alpha \mathbf{y}.$$

Portanto, quando $\mathbf{y} \neq \mathbf{0}$, a igualdade ocorre se, e somente se, $\mathbf{x}$ é múltiplo escalar de $\mathbf{y}$.

Reunindo os dois casos, concluímos que a igualdade ocorre se, e somente se, um dos vetores é múltiplo escalar do outro. $\square$

Para vetores não nulos, a desigualdade de Cauchy–Schwarz também implica

$$-1 \leq \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|} \leq 1.$$

Assim, a desigualdade fornece uma justificativa algébrica de que a razão utilizada no cálculo do ângulo pertence ao intervalo $[-1, 1]$, que é o domínio da função arccos.

1.5.4 Ângulo entre vetores

Definição 1.11 (Ângulo entre vetores). Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ não nulos, o **ângulo** entre os vetores é o único valor $\theta \in [0, \pi]$ que satisfaz

$$\cos(\theta) = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

A existência desse ângulo é garantida pela desigualdade de Cauchy–Schwarz, pois

$$-1 \leq \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|} \leq 1.$$

Equivalentemente,

$$\theta = \arccos \left(\frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|} \right).$$

A relação que define o ângulo também pode ser escrita como

$$\langle \mathbf{x}, \mathbf{y} \rangle = \|\mathbf{x}\| \|\mathbf{y}\| \cos(\theta).$$

Interpretação geométrica

A divisão pelo produto das normas retira o efeito dos comprimentos dos vetores. Desse modo, o valor de $\cos(\theta)$ descreve apenas o alinhamento entre suas direções.

Como $\|\mathbf{x}\|$ e $\|\mathbf{y}\|$ são positivos, o sinal do produto interno depende apenas do sinal de $\cos(\theta)$:

- se $0 \leq \theta < \frac{\pi}{2}$, o ângulo é agudo e

$$\langle \mathbf{x}, \mathbf{y} \rangle > 0;$$

- se $\theta = \frac{\pi}{2}$, o ângulo é reto e

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0;$$

- se $\frac{\pi}{2} < \theta \leq \pi$, o ângulo é obtuso e


$$\langle \mathbf{x}, \mathbf{y} \rangle < 0.$$

Geometricamente, o produto interno é positivo quando os vetores apontam para direções relativamente próximas, é nulo quando são ortogonais e é negativo quando apontam para direções relativamente opostas.


O ângulo não é definido quando um dos vetores é nulo, pois o vetor nulo não possui direção determinada e o denominador da expressão seria igual a zero.

A Figura 1.5 apresenta essas três situações.

Ângulo agudo



Ângulo reto



Ângulo obtuso




Figura 1.5: Sinal do produto interno segundo o ângulo formado entre dois vetores.

Definição 1.12 (Vetores ortogonais). Dois vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ são **ortogonais** quando

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0.$$

Se ambos forem não nulos, o ângulo entre eles é igual a 90° .

O vetor nulo é ortogonal a todos os vetores, pois

$$\langle \mathbf{0}, \mathbf{x} \rangle = 0.$$

O ângulo entre o vetor nulo e outro vetor não é definido porque $\|\mathbf{0}\| = 0$.

1.5.5 Distância euclidiana

Definição 1.13 (Distância euclidiana). A **distância euclidiana** entre $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ é definida por

$$d_E(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|.$$

Em termos das componentes,

$$d_E(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{j=1}^p (x_j - y_j)^2}.$$

A distância euclidiana corresponde ao comprimento do segmento que liga os pontos representados por $\mathbf{x}$ e $\mathbf{y}$.

Exemplo 1.10 (Distância entre duas observações). Considere

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 5 \\ 5 \end{bmatrix}.$$

A diferença entre os vetores é

$$\mathbf{x} - \mathbf{y} = \begin{bmatrix} -3 \\ -4 \end{bmatrix}.$$

Logo,

$$d_E(\mathbf{x}, \mathbf{y}) = \sqrt{(-3)^2 + (-4)^2} = 5.$$

Escalas das variáveis

A distância euclidiana depende das unidades e das escalas das variáveis. Uma variável com valores numericamente maiores pode contribuir mais para a distância entre as ob-




Figura 1.6: Os vetores $\mathbf{x}$ e $\mathbf{y}$ são representados por setas. A distância euclidiana é o comprimento do segmento que une suas extremidades.

servações. A padronização e outras geometrias serão estudadas nos capítulos posteriores.

1.5.6 Desigualdade triangular

Teorema 1.2 (Desigualdade triangular). *Para quaisquer vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,*

$$\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|.$$

Consequentemente, para quaisquer pontos $\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$,

$$d_E(\mathbf{x}, \mathbf{z}) \leq d_E(\mathbf{x}, \mathbf{y}) + d_E(\mathbf{y}, \mathbf{z}).$$

(Meyer, 2023)

Comprovação. Pela definição da norma euclidiana,

$$\|\mathbf{x} + \mathbf{y}\|^2 = \langle \mathbf{x} + \mathbf{y}, \mathbf{x} + \mathbf{y} \rangle.$$

Usando a linearidade e a simetria do produto interno,

$$\begin{aligned} \|\mathbf{x} + \mathbf{y}\|^2 &= \langle \mathbf{x}, \mathbf{x} \rangle + \langle \mathbf{x}, \mathbf{y} \rangle + \langle \mathbf{y}, \mathbf{x} \rangle + \langle \mathbf{y}, \mathbf{y} \rangle \\ &= \|\mathbf{x}\|^2 + 2\langle \mathbf{x}, \mathbf{y} \rangle + \|\mathbf{y}\|^2. \end{aligned}$$

Pela desigualdade de Cauchy–Schwarz,

$$\langle \mathbf{x}, \mathbf{y} \rangle \leq |\langle \mathbf{x}, \mathbf{y} \rangle| \leq \|\mathbf{x}\| \|\mathbf{y}\|.$$

Portanto,

$$\begin{aligned} \|\mathbf{x} + \mathbf{y}\|^2 &\leq \|\mathbf{x}\|^2 + 2\|\mathbf{x}\| \|\mathbf{y}\| + \|\mathbf{y}\|^2 \\ &= (\|\mathbf{x}\| + \|\mathbf{y}\|)^2. \end{aligned}$$

Como ambos os lados são não negativos, podemos tomar a raiz quadrada e obter

$$\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|.$$

Para demonstrar a desigualdade triangular da distância euclidiana, observe que

$$\mathbf{x} - \mathbf{z} = (\mathbf{x} - \mathbf{y}) + (\mathbf{y} - \mathbf{z}).$$

Aplicando a desigualdade triangular da norma,

$$\|\mathbf{x} - \mathbf{z}\| \leq \|\mathbf{x} - \mathbf{y}\| + \|\mathbf{y} - \mathbf{z}\|.$$

Como

$$d_E(\mathbf{u}, \mathbf{v}) = \|\mathbf{u} - \mathbf{v}\|,$$

segue que

$$d_E(\mathbf{x}, \mathbf{z}) \leq d_E(\mathbf{x}, \mathbf{y}) + d_E(\mathbf{y}, \mathbf{z}).$$

□

O produto interno, em conjunto com as normas, determina o ângulo entre vetores. A norma mede o comprimento de um vetor, e a distância euclidiana mede a separação entre dois pontos. Esses conceitos completam a representação geométrica inicial dos dados multivariados.

1.5.7 Produto externo

O produto interno associa dois vetores de mesma dimensão a um escalar. Dois vetores também podem ser utilizados para construir uma matriz por meio do **produto externo**.

Definição 1.14 (Produto externo). Para $\mathbf{x} \in \mathbb{R}^p$ e $\mathbf{y} \in \mathbb{R}^q$, o **produto externo** de $\mathbf{x}$ e $\mathbf{y}$, denotado por

$$\text{ext}(\mathbf{x}, \mathbf{y}),$$

é definido como a matriz em $\mathbb{R}^{p \times q}$

$$\text{ext}(\mathbf{x}, \mathbf{y}) = \begin{bmatrix} x_1 y_1 & x_1 y_2 & \cdots & x_1 y_q \\ x_2 y_1 & x_2 y_2 & \cdots & x_2 y_q \\ \vdots & \vdots & \ddots & \vdots \\ x_p y_1 & x_p y_2 & \cdots & x_p y_q \end{bmatrix}.$$

O elemento localizado na linha i e na coluna j é

$$[\text{ext}(\mathbf{x}, \mathbf{y})]_{ij} = x_i y_j.$$

O resultado do produto externo é uma matriz.

A estrutura do produto externo pode ser observada por suas colunas. Como

$$\text{ext}(\mathbf{x}, \mathbf{y}) = [y_1 \mathbf{x} \quad y_2 \mathbf{x} \quad \cdots \quad y_q \mathbf{x}],$$

cada coluna é um múltiplo escalar de $\mathbf{x}$.

Equivalentemente, considerando as linhas,

$$\text{ext}(\mathbf{x}, \mathbf{y}) = \begin{bmatrix} x_1 \mathbf{y}^\top \\ x_2 \mathbf{y}^\top \\ \vdots \\ x_p \mathbf{y}^\top \end{bmatrix},$$

de modo que cada linha é um múltiplo escalar de $\mathbf{y}^\top$.

Exemplo 1.11 (Produto externo de dois vetores). Considere

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \in \mathbb{R}^2$$

e

$$\mathbf{y} = \begin{bmatrix} 3 \\ -1 \\ 4 \end{bmatrix} \in \mathbb{R}^3.$$

O produto externo é

$$\begin{aligned} \text{ext}(\mathbf{x}, \mathbf{y}) &= \begin{bmatrix} 1(3) & 1(-1) & 1(4) \\ 2(3) & 2(-1) & 2(4) \end{bmatrix} \\ &= \begin{bmatrix} 3 & -1 & 4 \\ 6 & -2 & 8 \end{bmatrix}. \end{aligned}$$

O resultado possui dimensão 2×3 , correspondente às dimensões de $\mathbf{x}$ e $\mathbf{y}$, respectivamente.

O produto interno e o produto externo produzem objetos de naturezas diferentes. Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,

$$\langle \mathbf{x}, \mathbf{y} \rangle \in \mathbb{R},$$

enquanto

$$\text{ext}(\mathbf{x}, \mathbf{y}) \in \mathbb{R}^{p \times p}.$$

Assim, o produto interno produz um escalar, enquanto o produto externo produz uma matriz. No próximo capítulo, após a definição do produto matricial, o produto externo será relacionado às operações entre matrizes e vetores, e suas propriedades matriciais serão desenvolvidas.

1.6 Síntese do capítulo

Uma observação descrita por p variáveis quantitativas pode ser representada por um vetor

$$\mathbf{x}_i \in \mathbb{R}^p.$$

Um conjunto formado por n observações e p variáveis é organizado na matriz de dados

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

As linhas de $\mathbf{X}$ representam as observações como pontos de $\mathbb{R}^p$, enquanto as colunas representam as variáveis como vetores de $\mathbb{R}^n$.

A soma, a subtração e a multiplicação por escalar permitem construir novos vetores. As combinações lineares permitem reunir diferentes vetores ou variáveis mediante coeficientes previamente definidos.

Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, o produto interno euclidiano é definido por

$$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_{j=1}^p x_j y_j.$$

A norma euclidiana de $\mathbf{x}$ é

$$\|\mathbf{x}\| = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle},$$

e representa o comprimento do vetor.

Para vetores não nulos, o ângulo $\theta \in [0, \pi]$ é determinado por

$$\cos(\theta) = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

Dois vetores são ortogonais quando

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0.$$

A distância euclidiana entre dois pontos é definida por

$$d_E(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|.$$

Além das operações que produzem vetores ou escalares, dois vetores podem gerar uma matriz por meio do produto externo. Para

$$\mathbf{x} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{y} \in \mathbb{R}^q,$$

tem-se

$$\text{ext}(\mathbf{x}, \mathbf{y}) \in \mathbb{R}^{p \times q}.$$

Esses conceitos permitem interpretar os dados multivariados simultaneamente como vetores, matrizes e uma nuvem de pontos. O próximo capítulo desenvolverá as operações e as propriedades matriciais necessárias para manipular essas representações.

2 Álgebra matricial aplicada

No capítulo anterior, vetores foram apresentados nas formas coluna e linha, e a matriz de dados foi construída a partir da organização conjunta das observações e das variáveis. O produto externo mostrou ainda como dois vetores podem gerar uma matriz. Essas representações estabelecem a passagem natural da linguagem vetorial para a linguagem matricial.

Este capítulo desenvolve as operações e propriedades necessárias para manipular matrizes. O produto matriz-vetor e o produto entre matrizes permitem combinar linhas e colunas de dimensões compatíveis, enquanto a transposição, a simetria e o traço descrevem propriedades estruturais importantes dessas operações. Nesse contexto, o produto externo será retomado como um caso particular do produto matricial.

Também serão estudadas a identidade, a inversa, o determinante, o posto e sua relação com sistemas lineares, além de classes particulares de matrizes e de formas bilineares e quadráticas. As seções finais introduzem matrizes particionadas e complemento de Schur, preparando estruturas que serão utilizadas posteriormente na formulação de resultados multivariados.

Convenções matriciais

As convenções gerais apresentadas no capítulo anterior permanecem válidas. Neste capítulo, serão utilizadas também as seguintes convenções:

- $\mathbf{A}$, $\mathbf{B}$ e $\mathbf{C}$ representam matrizes gerais;
- $\mathbf{X}$ representa preferencialmente uma matriz de dados;
- $\mathbf{x}$, $\mathbf{y}$ e $\mathbf{b}$ representam vetores-coluna;
- a_{ij} representa o elemento localizado na linha i e na coluna j de $\mathbf{A}$;
- $\mathbf{A}_{n \times p}$ ou $\mathbf{A} \in \mathbb{R}^{n \times p}$ indica que $\mathbf{A}$ possui n linhas e p colunas;
- $\mathbf{A}^\top$ representa a transposta de $\mathbf{A}$;
- $\mathbf{A}^{-1}$ representa a inversa de $\mathbf{A}$, quando ela existe;
- $\mathbf{A}^+$ representa a pseudoinversa de Moore–Penrose;
- $\mathbf{I}_k$ representa a matriz identidade de ordem k ;
- $\mathbf{0}_{n \times p}$ representa a matriz nula de dimensão $n \times p$;
- $\det(\mathbf{A})$ representa o determinante de uma matriz quadrada;
- $\text{tr}(\mathbf{A})$ representa o traço de uma matriz quadrada;
- $\text{posto}(\mathbf{A})$ representa o posto de $\mathbf{A}$.

Quando as linhas ou colunas de uma matriz forem consideradas individualmente, serão mantidas as convenções estabelecidas no capítulo anterior. Em particular, $\mathbf{a}_i^\top$ representa,

de forma abreviada, a i -ésima linha de $\mathbf{A}$, enquanto $\mathbf{a}_{.j}$ representa sua j -ésima coluna. As condições de existência e as propriedades de cada operação serão apresentadas nas seções correspondentes.

2.1 Operações matriciais fundamentais

As dimensões das matrizes determinam quais operações podem ser realizadas. A igualdade, a soma, a subtração e a multiplicação por escalar atuam sobre elementos correspondentes. O produto matricial combina linhas da primeira matriz com colunas da segunda.

Definição 2.1 (Igualdade entre matrizes). Sejam $\mathbf{A} = (a_{ij})_{n \times p}$ e $\mathbf{B} = (b_{ij})_{r \times s}$. As matrizes $\mathbf{A}$ e $\mathbf{B}$ são iguais quando possuem as mesmas dimensões e elementos correspondentes iguais:

$$\mathbf{A} = \mathbf{B} \iff n = r, \quad p = s \quad \text{e} \quad a_{ij} = b_{ij}$$

para $i = 1, \dots, n$ e $j = 1, \dots, p$.

Assim,

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix},$$

mas

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \neq \begin{bmatrix} 1 & 2 \\ 4 & 3 \end{bmatrix}.$$

A posição de cada elemento faz parte da estrutura da matriz.

2.1.1 Soma e subtração de matrizes

Definição 2.2 (Soma e subtração de matrizes). Sejam $\mathbf{A} = (a_{ij})_{n \times p}$ e $\mathbf{B} = (b_{ij})_{n \times p}$. A soma e a subtração são definidas por

$$\mathbf{A} + \mathbf{B} = (a_{ij} + b_{ij})_{n \times p}$$

e

$$\mathbf{A} - \mathbf{B} = (a_{ij} - b_{ij})_{n \times p}.$$

As duas operações exigem que as matrizes possuam as mesmas dimensões.

Exemplo 2.1 (Soma e subtração de matrizes). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ -1 & 3 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 4 & -2 \\ 2 & 1 \end{bmatrix}.$$

A soma é

$$\mathbf{A} + \mathbf{B} = \begin{bmatrix} 1+4 & 2+(-2) \\ -1+2 & 3+1 \end{bmatrix} = \begin{bmatrix} 5 & 0 \\ 1 & 4 \end{bmatrix}.$$

A subtração é

$$\mathbf{A} - \mathbf{B} = \begin{bmatrix} 1-4 & 2-(-2) \\ -1-2 & 3-1 \end{bmatrix} = \begin{bmatrix} -3 & 4 \\ -3 & 2 \end{bmatrix}.$$

Proposição 2.1 (Propriedades da adição matricial). *Sejam*

$$\mathbf{A}, \mathbf{B}, \mathbf{C} \in \mathbb{R}^{n \times p}.$$

A adição de matrizes satisfaz as seguintes propriedades:

1. Comutatividade

$$\mathbf{A} + \mathbf{B} = \mathbf{B} + \mathbf{A}.$$

2. Associatividade

$$(\mathbf{A} + \mathbf{B}) + \mathbf{C} = \mathbf{A} + (\mathbf{B} + \mathbf{C}).$$

3. Existência do elemento neutro

$$\mathbf{A} + \mathbf{0}_{n \times p} = \mathbf{A},$$

em que $\mathbf{0}_{n \times p}$ é o elemento neutro de dimensão $n \times p$:

$$\mathbf{0}_{n \times p} = \begin{bmatrix} 0 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 0 \end{bmatrix}.$$

4. Existência do elemento oposto

$$\mathbf{A} + (-\mathbf{A}) = \mathbf{0}_{n \times p}.$$

Definição 2.3 (Multiplicação de matriz por escalar). Seja $\mathbf{A} = (a_{ij})_{n \times p}$ e seja $\alpha \in \mathbb{R}$. A multiplicação de $\mathbf{A}$ por α é definida por

$$\alpha \mathbf{A} = (\alpha a_{ij})_{n \times p}.$$

Cada elemento da matriz é multiplicado pelo mesmo escalar.

Exemplo 2.2 (Multiplicação de matriz por escalar). Para

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ -1 & 3 \end{bmatrix}$$

e $\alpha = -2$, tem-se

$$-2\mathbf{A} = -2 \begin{bmatrix} 1 & 2 \\ -1 & 3 \end{bmatrix} = \begin{bmatrix} -2 & -4 \\ 2 & -6 \end{bmatrix}.$$

Proposição 2.2 (Propriedades da multiplicação por escalar). *Sejam $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times p}$ e $\alpha, \beta \in \mathbb{R}$. A multiplicação de uma matriz por um escalar satisfaz as seguintes propriedades:*

1. Distributividade em relação à adição de matrizes

$$\alpha(\mathbf{A} + \mathbf{B}) = \alpha\mathbf{A} + \alpha\mathbf{B}.$$

2. Distributividade em relação à adição de escalares

$$(\alpha + \beta)\mathbf{A} = \alpha\mathbf{A} + \beta\mathbf{A}.$$

3. Associatividade da multiplicação por escalares

$$\alpha(\beta\mathbf{A}) = (\alpha\beta)\mathbf{A}.$$

4. *Elemento neutro da multiplicação escalar*

$$1\mathbf{A} = \mathbf{A}.$$

A adição de matrizes e a multiplicação por escalar preservam as dimensões das matrizes envolvidas. O produto matricial, apresentado a seguir, utiliza uma regra diferente e pode produzir uma matriz com dimensões distintas das matrizes multiplicadas.

2.1.2 Produto matriz-vetor

O produto de uma matriz por um vetor é definido quando o número de colunas da matriz coincide com o número de componentes do vetor.

Para

$$\mathbf{A} \in \mathbb{R}^{n \times p} \quad \text{e} \quad \mathbf{x} \in \mathbb{R}^p,$$

cada linha de $\mathbf{A}$ pode ser associada a um produto interno com $\mathbf{x}$. A definição a seguir reúne esses produtos internos em um vetor de $\mathbb{R}^n$.

Definição 2.4 (Produto matriz-vetor). Sejam

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}$$

e

$$\mathbf{x} \in \mathbb{R}^p.$$

O produto de $\mathbf{A}$ por $\mathbf{x}$ é o vetor

$$\mathbf{Ax} = \begin{bmatrix} \langle \mathbf{a}_1, \mathbf{x} \rangle \\ \langle \mathbf{a}_2, \mathbf{x} \rangle \\ \vdots \\ \langle \mathbf{a}_n, \mathbf{x} \rangle \end{bmatrix} \in \mathbb{R}^n.$$

Escrevendo

$$\mathbf{A} = (a_{ij})_{n \times p}$$

e

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix},$$

cada produto interno pode ser escrito como

$$\langle \mathbf{a}_i, \mathbf{x} \rangle = \sum_{j=1}^p a_{ij} x_j.$$

Portanto,

$$\mathbf{Ax} = \begin{bmatrix} \sum_{j=1}^p a_{1j} x_j \\ \sum_{j=1}^p a_{2j} x_j \\ \vdots \\ \sum_{j=1}^p a_{nj} x_j \end{bmatrix}.$$

A componente i do vetor resultante é, portanto,

$$(\mathbf{Ax})_i = \mathbf{a}_i^\top \mathbf{x} = \langle \mathbf{a}_i, \mathbf{x} \rangle = \sum_{j=1}^p a_{ij} x_j.$$

O mesmo produto admite outra interpretação. Escrevendo $\mathbf{A}$ por suas colunas,

$$\mathbf{A} = [\mathbf{a}_1 \ \mathbf{a}_2 \ \cdots \ \mathbf{a}_p],$$

tem-se

$$\mathbf{Ax} = x_1 \mathbf{a}_1 + x_2 \mathbf{a}_2 + \cdots + x_p \mathbf{a}_p.$$

Assim, o produto matriz-vetor possui duas interpretações complementares:

- **pelas linhas**, cada componente de $\mathbf{Ax}$ é um produto interno entre o vetor associado a uma linha de $\mathbf{A}$ e $\mathbf{x}$;
- **pelas colunas**, $\mathbf{Ax}$ é uma combinação linear das colunas de $\mathbf{A}$, com coeficientes dados pelas componentes de $\mathbf{x}$.

Exemplo 2.3 (Produto de uma matriz por um vetor). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ -1 & 3 \\ 2 & 0 \end{bmatrix} \in \mathbb{R}^{3 \times 2}$$

e

$$\mathbf{x} = \begin{bmatrix} 2 \\ -1 \end{bmatrix} \in \mathbb{R}^2.$$

Pelas linhas de $\mathbf{A}$,

$$\mathbf{Ax} = \begin{bmatrix} (1)(2) + (2)(-1) \\ (-1)(2) + (3)(-1) \\ (2)(2) + (0)(-1) \end{bmatrix} = \begin{bmatrix} 0 \\ -5 \\ 4 \end{bmatrix}.$$

Cada componente é um produto interno entre $\mathbf{x}$ e uma linha de $\mathbf{A}$.

Pelas colunas,

$$\mathbf{a}_{.1} = \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix}, \quad \mathbf{a}_{.2} = \begin{bmatrix} 2 \\ 3 \\ 0 \end{bmatrix}.$$

Logo,

$$\begin{aligned} \mathbf{Ax} &= 2\mathbf{a}_{.1} - \mathbf{a}_{.2} \\ &= 2 \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix} - \begin{bmatrix} 2 \\ 3 \\ 0 \end{bmatrix} \\ &= \begin{bmatrix} 0 \\ -5 \\ 4 \end{bmatrix}. \end{aligned}$$

As duas formas de cálculo produzem o mesmo vetor: pelas linhas, o resultado é obtido por produtos internos; pelas colunas, por uma combinação linear.

2.1.3 Produto entre matrizes

O produto entre matrizes estende o produto matriz-vetor. Se as colunas de uma matriz $\mathbf{B}$ são

$$\mathbf{b}_{.1}, \mathbf{b}_{.2}, \dots, \mathbf{b}_{.r},$$

então multiplicar $\mathbf{A}$ por $\mathbf{B}$ equivale a multiplicar $\mathbf{A}$ por cada uma dessas colunas:

$$\mathbf{AB} = \mathbf{A} [\mathbf{b}_{.1} \ \mathbf{b}_{.2} \ \dots \ \mathbf{b}_{.r}] = [\mathbf{Ab}_{.1} \ \mathbf{Ab}_{.2} \ \dots \ \mathbf{Ab}_{.r}].$$

Como cada componente de $\mathbf{Ab}_{.j}$ é um produto interno entre uma linha de $\mathbf{A}$ e a coluna $\mathbf{b}_{.j}$, cada elemento do produto matricial também pode ser interpretado como um produto interno.

Definição 2.5 (Produto entre matrizes). Sejam

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}$$

e

$$\mathbf{B} = [\mathbf{b}_{.1} \ \mathbf{b}_{.2} \ \dots \ \mathbf{b}_{.r}] \in \mathbb{R}^{p \times r}.$$

O produto de $\mathbf{A}$ por $\mathbf{B}$ é a seguinte matriz em $\mathbb{R}^{n \times r}$

$$\mathbf{AB} = \begin{bmatrix} \mathbf{a}_1^\top \mathbf{b}_{.1} & \mathbf{a}_1^\top \mathbf{b}_{.2} & \dots & \mathbf{a}_1^\top \mathbf{b}_{.r} \\ \mathbf{a}_2^\top \mathbf{b}_{.1} & \mathbf{a}_2^\top \mathbf{b}_{.2} & \dots & \mathbf{a}_2^\top \mathbf{b}_{.r} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{a}_n^\top \mathbf{b}_{.1} & \mathbf{a}_n^\top \mathbf{b}_{.2} & \dots & \mathbf{a}_n^\top \mathbf{b}_{.r} \end{bmatrix}.$$

Portanto, o elemento localizado na linha i e na coluna j do produto é

$$(\mathbf{AB})_{ij} = \mathbf{a}_i^\top \mathbf{b}_{.j} = \langle \mathbf{a}_i, \mathbf{b}_{.j} \rangle.$$

Escrevendo

$$\mathbf{A} = (a_{ik})_{n \times p}$$

e

$$\mathbf{B} = (b_{kj})_{p \times r},$$

o mesmo elemento pode ser expresso como

$$(\mathbf{AB})_{ij} = \sum_{k=1}^p a_{ik} b_{kj},$$

para

$$i = 1, \dots, n \quad \text{e} \quad j = 1, \dots, r.$$

Assim, o produto matricial admite duas leituras complementares:

- **pelos elementos**, cada entrada de $\mathbf{AB}$ é o produto interno entre uma linha de $\mathbf{A}$ e uma coluna de $\mathbf{B}$;
- **pelas colunas**, cada coluna de $\mathbf{AB}$ é obtida multiplicando $\mathbf{A}$ pela coluna correspondente de $\mathbf{B}$.

Compatibilidade dimensional

O produto $\mathbf{AB}$ é definido somente quando o número de colunas de $\mathbf{A}$ coincide com o número de linhas de $\mathbf{B}$:

$$\underset{n \times p}{\mathbf{A}} \underset{p \times r}{\mathbf{B}} = \underset{n \times r}{\mathbf{AB}}.$$

As dimensões internas devem coincidir. As dimensões externas determinam a dimensão do resultado.

Exemplo 2.4 (Produto entre duas matrizes). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 3 & 1 \end{bmatrix} \in \mathbb{R}^{2 \times 3}$$

e

$$\mathbf{B} = \begin{bmatrix} 2 & 1 \\ 0 & -1 \\ 4 & 2 \end{bmatrix} \in \mathbb{R}^{3 \times 2}.$$

Como o número de colunas de $\mathbf{A}$ coincide com o número de linhas de $\mathbf{B}$, o produto está definido e possui dimensão 2×2 .

Cada elemento é obtido pelo produto interno entre uma linha de $\mathbf{A}$ e uma coluna de $\mathbf{B}$. Por exemplo,

$$(\mathbf{AB})_{11} = \begin{bmatrix} 1 & 2 & 0 \end{bmatrix} \begin{bmatrix} 2 \\ 0 \\ 4 \end{bmatrix} = (1)(2) + (2)(0) + (0)(4) = 2,$$

enquanto

$$(\mathbf{AB})_{12} = \begin{bmatrix} 1 & 2 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix} = (1)(1) + (2)(-1) + (0)(2) = -1.$$

Procedendo da mesma forma para os demais elementos,

$$\mathbf{AB} = \begin{bmatrix} 2 & -1 \\ 2 & -2 \end{bmatrix}.$$

i Produto interno e produto externo como produtos matriciais

As operações entre vetores apresentadas anteriormente também podem ser expressas por meio do produto matricial.

Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, o **produto interno** pode ser escrito como

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^\top \mathbf{y}.$$

Como

$$\mathbf{x}^\top \in \mathbb{R}^{1 \times p} \quad \text{e} \quad \mathbf{y} \in \mathbb{R}^{p \times 1},$$

o produto possui dimensão 1×1 e corresponde a um escalar:

$$\mathbf{x}^\top \mathbf{y} = x_1 y_1 + x_2 y_2 + \cdots + x_p y_p.$$

De forma semelhante, para

$$\mathbf{x} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{y} \in \mathbb{R}^q,$$

o **produto externo**, anteriormente denotado por

$$\text{ext}(\mathbf{x}, \mathbf{y}),$$

pode ser escrito como

$$\text{ext}(\mathbf{x}, \mathbf{y}) = \mathbf{xy}^\top.$$

Nesse caso,

$$\mathbf{x} \in \mathbb{R}^{p \times 1} \quad \text{e} \quad \mathbf{y}^\top \in \mathbb{R}^{1 \times q},$$

de modo que

$$\mathbf{xy}^\top \in \mathbb{R}^{p \times q}.$$

Portanto, a ordem e a orientação dos vetores determinam objetos diferentes:

$$\mathbf{x}^\top \mathbf{y} \text{ é um escalar}$$

enquanto

$$\mathbf{xy}^\top \text{ é uma matriz.}$$

Exemplo 2.5 (Produtos envolvendo uma matriz de dados). Considere a matriz de dados

$$\mathbf{X} = \begin{bmatrix} 2 & 1 & 4 \\ 3 & 5 & 2 \\ 6 & 2 & 1 \\ 4 & 3 & 5 \end{bmatrix} \in \mathbb{R}^{4 \times 3}.$$

As quatro linhas correspondem às observações, e as três colunas correspondem às variáveis.

A matriz

$$\mathbf{X}^\top = \begin{bmatrix} 2 & 3 & 6 & 4 \\ 1 & 5 & 2 & 3 \\ 4 & 2 & 1 & 5 \end{bmatrix} \in \mathbb{R}^{3 \times 4}$$

é obtida escrevendo as colunas de $\mathbf{X}$ como linhas. A operação de transposição e suas propriedades serão formalizadas adiante.

Considere ainda

$$\mathbf{a} = \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix}.$$

O produto

$$\mathbf{X}\mathbf{a} = \begin{bmatrix} 0 \\ 11 \\ 9 \\ 5 \end{bmatrix}$$

pode ser escrito, em termos das colunas de $\mathbf{X}$, como

$$\mathbf{X}\mathbf{a} = \mathbf{x}_{\cdot 1} + 2\mathbf{x}_{\cdot 2} - \mathbf{x}_{\cdot 3}.$$

Portanto, o vetor resultante contém os valores da nova variável formada pela combinação linear

$$X_1 + 2X_2 - X_3.$$

Considere agora o produto

$$\mathbf{X}^\top \mathbf{X} = \begin{bmatrix} 65 & 41 & 40 \\ 41 & 39 & 31 \\ 40 & 31 & 46 \end{bmatrix}.$$

Esse produto possui dimensão 3×3 . Cada elemento é o produto interno entre duas colunas de $\mathbf{X}$ e, portanto, relaciona duas variáveis. Em geral,

$$(\mathbf{X}^\top \mathbf{X})_{jk} = \langle \mathbf{x}_{\cdot j}, \mathbf{x}_{\cdot k} \rangle.$$

Por exemplo,

$$(\mathbf{X}^\top \mathbf{X})_{12} = \langle \mathbf{x}_{\cdot 1}, \mathbf{x}_{\cdot 2} \rangle = 41.$$

Por outro lado,

$$\mathbf{X}\mathbf{X}^\top = \begin{bmatrix} 21 & 19 & 18 & 31 \\ 19 & 38 & 30 & 37 \\ 18 & 30 & 41 & 35 \\ 31 & 37 & 35 & 50 \end{bmatrix}$$

possui dimensão 4×4 . Cada elemento é o produto interno entre duas linhas de $\mathbf{X}$ e, portanto, relaciona duas observações. Em geral,

$$(\mathbf{X}\mathbf{X}^\top)_{ih} = \langle \mathbf{x}_i, \mathbf{x}_h \rangle.$$

Por exemplo,

$$(\mathbf{X}\mathbf{X}^\top)_{12} = \langle \mathbf{x}_1, \mathbf{x}_2 \rangle = 19.$$

Assim, a mesma matriz de dados gera dois produtos com interpretações distintas:

- $\mathbf{X}^\top \mathbf{X}$ relaciona as variáveis;
- $\mathbf{X}\mathbf{X}^\top$ relaciona as observações.

Esses produtos serão retomados no estudo de matrizes de Gram, produtos cruzados, covariâncias e decomposição em valores singulares.

2.1.4 Propriedades do produto matricial

Proposição 2.3 (Propriedades do produto matricial). *Para matrizes com dimensões compatíveis, o produto matricial satisfaz as seguintes propriedades:*

1. *Associatividade*

$$(\mathbf{A}\mathbf{B})\mathbf{C} = \mathbf{A}(\mathbf{B}\mathbf{C}).$$

2. *Distributividade à esquerda*

$$\mathbf{A}(\mathbf{B} + \mathbf{C}) = \mathbf{A}\mathbf{B} + \mathbf{A}\mathbf{C}.$$

3. *Distributividade à direita*

$$(\mathbf{A} + \mathbf{B})\mathbf{C} = \mathbf{A}\mathbf{C} + \mathbf{B}\mathbf{C}.$$

4. *Compatibilidade com a multiplicação por escalar*

Para $\alpha \in \mathbb{R}$,

$$(\alpha\mathbf{A})\mathbf{B} = \alpha(\mathbf{A}\mathbf{B}) = \mathbf{A}(\alpha\mathbf{B}).$$

O produto matricial, em geral, **não é comutativo**. Mesmo quando $\mathbf{A}\mathbf{B}$ e $\mathbf{B}\mathbf{A}$ estão ambos definidos e possuem a mesma dimensão, pode ocorrer

$$\mathbf{A}\mathbf{B} \neq \mathbf{B}\mathbf{A}.$$

Exemplo 2.6 (Não comutatividade do produto matricial). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}.$$

Tem-se

$$\mathbf{AB} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix},$$

enquanto

$$\mathbf{BA} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix}.$$

Portanto,

$$\mathbf{AB} \neq \mathbf{BA}.$$

2.2 Transposição, simetria e traço

A transposição troca as linhas de uma matriz por suas colunas. Essa operação permite reorganizar produtos matriciais e definir matrizes simétricas.

2.2.1 Transposição

Definição 2.6 (Matriz transposta). Seja $\mathbf{A} = (a_{ij})_{n \times p} \in \mathbb{R}^{n \times p}$. A **transposta** de $\mathbf{A}$ é a matriz

$$\mathbf{A}^\top = (a_{ji})_{p \times n} \in \mathbb{R}^{p \times n}.$$

O elemento que ocupa a linha i e a coluna j de $\mathbf{A}$ passa a ocupar a linha j e a coluna i de $\mathbf{A}^\top$.

Exemplo 2.7 (Transposição de uma matriz). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} \in \mathbb{R}^{2 \times 3}.$$

Sua transposta é

$$\mathbf{A}^\top = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix} \in \mathbb{R}^{3 \times 2}.$$

Para uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a transposta possui dimensão

$$\mathbf{X}^\top \in \mathbb{R}^{p \times n}.$$

As linhas de $\mathbf{X}$ tornam-se as colunas de $\mathbf{X}^\top$, e as colunas de $\mathbf{X}$ tornam-se suas linhas.

Proposição 2.4 (Propriedades da transposição). *Sejam $\mathbf{A}$ e $\mathbf{B}$ matrizes com dimensões compatíveis e seja $\alpha \in \mathbb{R}$. Então,*

1. $(\mathbf{A}^\top)^\top = \mathbf{A}$,
2. $(\mathbf{A} + \mathbf{B})^\top = \mathbf{A}^\top + \mathbf{B}^\top$,
3. $(\alpha \mathbf{A})^\top = \alpha \mathbf{A}^\top$ e
4. $(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top$.
5. Em particular, para vetores $\mathbf{x} \in \mathbb{R}^p$ e $\mathbf{y} \in \mathbb{R}^q$, $(\mathbf{xy}^\top)^\top = \mathbf{yx}^\top$.

A última propriedade mostra que a transposição de um produto inverte a ordem dos fatores. Em particular, ela será útil para reconhecer estruturas simétricas construídas a partir de produtos externos.

Exemplo 2.8 (Transposta de um produto). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 3 & 1 \\ 2 & 4 \end{bmatrix}.$$

O produto é

$$\mathbf{AB} = \begin{bmatrix} 7 & 9 \\ 2 & 4 \end{bmatrix},$$

de modo que

$$(\mathbf{AB})^\top = \begin{bmatrix} 7 & 2 \\ 9 & 4 \end{bmatrix}.$$

Por outro lado,

$$\mathbf{B}^\top \mathbf{A}^\top = \begin{bmatrix} 3 & 2 \\ 1 & 4 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix} = \begin{bmatrix} 7 & 2 \\ 9 & 4 \end{bmatrix}.$$

Portanto,

$$(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top.$$

2.2.2 Matrizes simétricas

A simetria compara uma matriz quadrada com sua transposta.

Definição 2.7 (Matriz simétrica). Uma matriz $\mathbf{A} \in \mathbb{R}^{n \times n}$ é **simétrica** quando

$$\mathbf{A}^\top = \mathbf{A}.$$

Em termos dos elementos,

$$a_{ij} = a_{ji}, \quad i, j = 1, \dots, n.$$

Em uma matriz simétrica, os elementos situados em posições opostas em relação à diagonal principal são iguais.

Exemplo 2.9 (Matriz simétrica). A matriz

$$\mathbf{A} = \begin{bmatrix} 2 & 1 & -3 \\ 1 & 4 & 2 \\ -3 & 2 & 5 \end{bmatrix}$$

é simétrica, pois

$$\mathbf{A}^\top = \begin{bmatrix} 2 & 1 & -3 \\ 1 & 4 & 2 \\ -3 & 2 & 5 \end{bmatrix} = \mathbf{A}.$$

A soma de matrizes simétricas de mesma dimensão é simétrica. Se $\mathbf{A}$ é simétrica e $\alpha \in \mathbb{R}$, então $\alpha\mathbf{A}$ também é simétrica.

Um caso particularmente importante é obtido pelo produto externo de um vetor consigo mesmo. Para $\mathbf{x} \in \mathbb{R}^p$, tem-se

$$(\mathbf{x}\mathbf{x}^\top)^\top = \mathbf{x}\mathbf{x}^\top.$$

Portanto,

$$\mathbf{x}\mathbf{x}^\top$$

é uma matriz simétrica.

O produto de duas matrizes simétricas não é necessariamente simétrico. Para matrizes simétricas $\mathbf{A}$ e $\mathbf{B}$,

$$(\mathbf{AB})^\top = \mathbf{BA}.$$

Portanto, $\mathbf{AB}$ é simétrica quando

$$\mathbf{AB} = \mathbf{BA}.$$

Definição 2.8 (Matriz antissimétrica). Uma matriz $\mathbf{A} \in \mathbb{R}^{n \times n}$ é **antissimétrica** quando

$$\mathbf{A}^\top = -\mathbf{A}.$$

Os elementos da diagonal principal de uma matriz antissimétrica são iguais a zero. De fato,

$$a_{ii} = -a_{ii}$$

implica

$$a_{ii} = 0.$$

Uma matriz antissimétrica possui a forma

$$\mathbf{A} = \begin{bmatrix} 0 & a_{12} & \cdots & a_{1n} \\ -a_{12} & 0 & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ -a_{1n} & -a_{2n} & \cdots & 0 \end{bmatrix}.$$

Aprofundamento

A decomposição seguinte mostra que toda matriz quadrada pode ser separada em uma parte simétrica e uma parte antissimétrica. A parte simétrica será particularmente importante no estudo das formas quadráticas.

Teorema 2.1 (Decomposição em partes simétrica e antissimétrica). *Toda matriz quadrada $\mathbf{A} \in \mathbb{R}^{n \times n}$ pode ser escrita de maneira única como*

$$\mathbf{A} = \mathbf{S} + \mathbf{K},$$

em que

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2}$$

é simétrica e

$$\mathbf{K} = \frac{\mathbf{A} - \mathbf{A}^\top}{2}$$

é antissimétrica. (Horn; Johnson, 2013)

Comprovação. A transposta de $\mathbf{S}$ é

$$\mathbf{S}^\top = \left(\frac{\mathbf{A} + \mathbf{A}^\top}{2} \right)^\top = \frac{\mathbf{A}^\top + \mathbf{A}}{2} = \mathbf{S}.$$

Logo, $\mathbf{S}$ é simétrica.

Para $\mathbf{K}$,

$$\mathbf{K}^\top = \left(\frac{\mathbf{A} - \mathbf{A}^\top}{2} \right)^\top = \frac{\mathbf{A}^\top - \mathbf{A}}{2} = -\mathbf{K}.$$

Logo, $\mathbf{K}$ é antissimétrica. Além disso,

$$\mathbf{S} + \mathbf{K} = \frac{\mathbf{A} + \mathbf{A}^\top}{2} + \frac{\mathbf{A} - \mathbf{A}^\top}{2} = \mathbf{A}.$$

Para verificar a unicidade, suponha que

$$\mathbf{A} = \mathbf{S}_1 + \mathbf{K}_1,$$

em que $\mathbf{S}_1$ é simétrica e $\mathbf{K}_1$ é antissimétrica. Transpondo essa igualdade,

$$\mathbf{A}^\top = \mathbf{S}_1 - \mathbf{K}_1.$$

Somando e subtraindo as duas expressões, obtém-se

$$\mathbf{S}_1 = \frac{\mathbf{A} + \mathbf{A}^\top}{2}$$

e

$$\mathbf{K}_1 = \frac{\mathbf{A} - \mathbf{A}^\top}{2}.$$

Portanto, as partes simétrica e antissimétrica são únicas. □

Exemplo 2.10 (Partes simétrica e antissimétrica). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 4 \\ -2 & 3 \end{bmatrix}.$$

A parte simétrica é

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2} = \frac{1}{2} \left(\begin{bmatrix} 1 & 4 \\ -2 & 3 \end{bmatrix} + \begin{bmatrix} 1 & -2 \\ 4 & 3 \end{bmatrix} \right) = \begin{bmatrix} 1 & 1 \\ 1 & 3 \end{bmatrix}.$$

A parte antissimétrica é

$$\mathbf{K} = \frac{\mathbf{A} - \mathbf{A}^\top}{2} = \frac{1}{2} \left(\begin{bmatrix} 1 & 4 \\ -2 & 3 \end{bmatrix} - \begin{bmatrix} 1 & -2 \\ 4 & 3 \end{bmatrix} \right) = \begin{bmatrix} 0 & 3 \\ -3 & 0 \end{bmatrix}.$$

Portanto,

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & 3 \end{bmatrix} + \begin{bmatrix} 0 & 3 \\ -3 & 0 \end{bmatrix}.$$

As matrizes de covariâncias também pertencem à classe das matrizes simétricas.

2.2.3 Traço

O traço reúne os elementos da diagonal principal de uma matriz quadrada. Apesar de sua definição simples, essa operação permite representar de forma compacta somas de quadrados, produtos internos, formas quadráticas e diversas expressões matriciais utilizadas em Estatística Multivariada.

Definição 2.9 (Traço de uma matriz). Seja $\mathbf{A} = (a_{ij})_{n \times n} \in \mathbb{R}^{n \times n}$. O **traço** de $\mathbf{A}$ é definido por

$$\text{tr}(\mathbf{A}) = \sum_{i=1}^n a_{ii}.$$

Exemplo 2.11 (Cálculo do traço). Para $\mathbf{A} = \begin{bmatrix} 2 & 1 & 0 \\ -1 & 4 & 3 \\ 2 & 5 & -3 \end{bmatrix}$, tem-se

$$\text{tr}(\mathbf{A}) = 2 + 4 - 3 = 3.$$

Proposição 2.5 (Propriedades básicas do traço). *Sejam $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times n}$ e $\alpha, \beta \in \mathbb{R}$. Então,*

1. *Linearidade:*

$$\text{tr}(\alpha \mathbf{A} + \beta \mathbf{B}) = \alpha \text{tr}(\mathbf{A}) + \beta \text{tr}(\mathbf{B}).$$

2. *Invariância à transposição:*

$$\text{tr}(\mathbf{A}^\top) = \text{tr}(\mathbf{A}).$$

3. *Traço da matriz identidade:*

$$\text{tr}(\mathbf{I}_n) = n.$$

Consequentemente,

$$\text{tr}(\alpha \mathbf{I}_n) = \alpha n.$$

4. *Propriedade cíclica:* se $\mathbf{C} \in \mathbb{R}^{n \times p}$ e $\mathbf{D} \in \mathbb{R}^{p \times n}$, então

$$\text{tr}(\mathbf{CD}) = \text{tr}(\mathbf{DC}).$$

(Harville, 1997)

A primeira propriedade mostra que o traço é uma operação linear. A segunda decorre do fato de que a transposição não modifica os elementos da diagonal principal. A quarta permite reorganizar produtos matriciais dentro do traço, desde que seja preservada a ordem cíclica dos fatores.

A propriedade cíclica pode ser demonstrada diretamente a partir da definição do produto matricial.

Comprovação. Como $\mathbf{C} \in \mathbb{R}^{n \times p}$ e $\mathbf{D} \in \mathbb{R}^{p \times n}$,

$$\text{tr}(\mathbf{CD}) = \sum_{i=1}^n (\mathbf{CD})_{ii} = \sum_{i=1}^n \sum_{j=1}^p c_{ij} d_{ji}.$$

Trocando a ordem das somas,

$$\sum_{i=1}^n \sum_{j=1}^p c_{ij} d_{ji} = \sum_{j=1}^p \sum_{i=1}^n d_{ji} c_{ij} = \text{tr}(\mathbf{DC}).$$

□

Proposição 2.6 (Ciclicidade para vários fatores). *Para matrizes com dimensões compatíveis, os fatores de um produto podem ser deslocados ciclicamente dentro do traço. Por exemplo,*

$$\text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{BCA}) = \text{tr}(\mathbf{CAB}).$$

A propriedade é **cíclica**. Portanto, a ordem relativa dos fatores é preservada. Em geral,

$$\text{tr}(\mathbf{ABC}) \neq \text{tr}(\mathbf{ACB}).$$

Proposição 2.7 (Traço, produto interno e produto externo). *Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,*

$$\text{tr}(\mathbf{xy}^\top) = \mathbf{y}^\top \mathbf{x} = \langle \mathbf{x}, \mathbf{y} \rangle.$$

Como $\mathbf{xy}^\top = \text{ext}(\mathbf{x}, \mathbf{y})$, também podemos escrever

$$\text{tr}[\text{ext}(\mathbf{x}, \mathbf{y})] = \langle \mathbf{x}, \mathbf{y} \rangle.$$

Em particular,

$$\text{tr}(\mathbf{xx}^\top) = \mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|^2.$$

Essa propriedade estabelece uma ligação direta entre o traço e as operações vetoriais introduzidas anteriormente.

Proposição 2.8 (Traço de produtos matriciais). *Para $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times p}$,*

$$\text{tr}(\mathbf{A}^\top \mathbf{B}) = \sum_{i=1}^n \sum_{j=1}^p a_{ij} b_{ij}.$$

Consequentemente,

$$\text{tr}(\mathbf{A}^\top \mathbf{A}) = \sum_{i=1}^n \sum_{j=1}^p a_{ij}^2.$$

Pela propriedade cíclica,

$$\operatorname{tr}(\mathbf{A}^\top \mathbf{A}) = \operatorname{tr}(\mathbf{A} \mathbf{A}^\top).$$

Portanto, o traço permite representar a soma dos quadrados de todos os elementos de uma matriz. Essa expressão será retomada posteriormente no estudo da norma de Frobenius, de matrizes de produtos cruzados e de decomposições matriciais.

Exemplo 2.12 (Traço de produtos matriciais). Considere $\mathbf{A} = \begin{bmatrix} 2 & 1 \\ -1 & 4 \end{bmatrix}$ e $\mathbf{B} = \begin{bmatrix} 1 & 3 \\ -2 & 3 \end{bmatrix}$.

Os produtos são

$$\mathbf{AB} = \begin{bmatrix} 0 & 9 \\ -9 & 9 \end{bmatrix}$$

e

$$\mathbf{BA} = \begin{bmatrix} -1 & 13 \\ -7 & 10 \end{bmatrix}.$$

Embora

$$\mathbf{AB} \neq \mathbf{BA},$$

seus traços são iguais:

$$\operatorname{tr}(\mathbf{AB}) = 0 + 9 = 9$$

e

$$\operatorname{tr}(\mathbf{BA}) = -1 + 10 = 9.$$

O traço será utilizado repetidamente na representação de somas de quadrados, produtos cruzados, variâncias totais, formas quadráticas e expressões de verossimilhança. Sua relação com os autovalores será estabelecida no capítulo sobre decomposição espectral.

2.3 Identidade, inversa, determinante, posto e sistemas lineares

As matrizes identidade e inversa permitem representar operações que preservam ou recuperam vetores. A existência da inversa está relacionada ao determinante, ao posto e às soluções de sistemas lineares.

2.3.1 Matriz identidade

Definição 2.10 (Matriz identidade). A **matriz identidade** de ordem n é a matriz quadrada

$$\mathbf{I}_n = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix} \in \mathbb{R}^{n \times n}.$$

Seus elementos podem ser representados pelo **delta de Kronecker**,

$$\delta_{ij} = \begin{cases} 1, & i = j, \\ 0, & i \neq j, \end{cases}$$

de modo que

$$(\mathbf{I}_n)_{ij} = \delta_{ij}.$$

O delta de Kronecker será utilizado posteriormente para representar de forma compacta relações de ortogonalidade e ortonormalidade.

A matriz identidade é o elemento neutro do produto matricial. Para

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

tem-se

$$\mathbf{I}_n \mathbf{A} = \mathbf{A}$$

e

$$\mathbf{A} \mathbf{I}_p = \mathbf{A}.$$

Para um vetor $\mathbf{x} \in \mathbb{R}^p$,

$$\mathbf{I}_p \mathbf{x} = \mathbf{x}.$$

Exemplo 2.13 (Produto pela matriz identidade). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

Então,

$$\mathbf{I}_2 \mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$$

e

$$\mathbf{A} \mathbf{I}_2 = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

2.3.2 Matriz inversa

Definição 2.11 (Matriz inversa). Uma matriz quadrada $\mathbf{A} \in \mathbb{R}^{n \times n}$ é **invertível** quando existe uma matriz

$$\mathbf{A}^{-1} \in \mathbb{R}^{n \times n}$$

tal que

$$\mathbf{A} \mathbf{A}^{-1} = \mathbf{A}^{-1} \mathbf{A} = \mathbf{I}_n.$$

A matriz $\mathbf{A}^{-1}$ é denominada **inversa** de $\mathbf{A}$.

Uma matriz que não possui inversa é denominada **singular**.

Teorema 2.2 (Unicidade da matriz inversa). *Se uma matriz possui inversa, essa inversa é única.*

Comprovação. Suponha que $\mathbf{B}$ e $\mathbf{C}$ sejam inversas de $\mathbf{A}$. Então,

$$\mathbf{AB} = \mathbf{BA} = \mathbf{I}_n$$

e

$$\mathbf{AC} = \mathbf{CA} = \mathbf{I}_n.$$

Assim,

$$\mathbf{B} = \mathbf{BI}_n = \mathbf{B}(\mathbf{AC}) = (\mathbf{BA})\mathbf{C} = \mathbf{I}_n\mathbf{C} = \mathbf{C}.$$

Logo, a inversa é única. □

Exemplo 2.14 (Verificação de uma matriz inversa). Considere

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix}.$$

Calculando os produtos,

$$\mathbf{AB} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \mathbf{I}_2$$

e

$$\mathbf{BA} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \mathbf{I}_2.$$

Portanto,

$$\mathbf{A}^{-1} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix}.$$

Além disso,

$$(\mathbf{A}^\top)^{-1} = (\mathbf{A}^{-1})^\top$$

e, para $\alpha \neq 0$,

$$(\alpha \mathbf{A})^{-1} = \frac{1}{\alpha} \mathbf{A}^{-1}.$$

Teorema 2.3 (Inversa de um produto). *Se $\mathbf{A}$ e $\mathbf{B}$ são matrizes invertíveis de ordem n , então $\mathbf{AB}$ é invertível e*

$$(\mathbf{AB})^{-1} = \mathbf{B}^{-1} \mathbf{A}^{-1}.$$

Comprovação. Tem-se

$$(\mathbf{AB})(\mathbf{B}^{-1} \mathbf{A}^{-1}) = \mathbf{A}(\mathbf{BB}^{-1})\mathbf{A}^{-1} = \mathbf{AI}_n \mathbf{A}^{-1} = \mathbf{I}_n.$$

Também,

$$(\mathbf{B}^{-1} \mathbf{A}^{-1})(\mathbf{AB}) = \mathbf{B}^{-1}(\mathbf{A}^{-1} \mathbf{A})\mathbf{B} = \mathbf{B}^{-1} \mathbf{I}_n \mathbf{B} = \mathbf{I}_n.$$

Logo,

$$(\mathbf{AB})^{-1} = \mathbf{B}^{-1} \mathbf{A}^{-1}.$$

□

A existência da inversa ainda não foi caracterizada. Essa condição será expressa por meio do determinante e do posto.

2.3.3 Determinante

O determinante associa uma matriz quadrada a um número real. Seu valor permite verificar a invertibilidade da matriz e quantificar alterações de área ou volume.

Definição 2.12 (Menor e cofator). Seja

$$\mathbf{A} = (a_{ij})_{n \times n}.$$

O **menor** M_{ij} é o determinante da matriz obtida pela retirada da linha i e da coluna j de $\mathbf{A}$.

O **cofator** do elemento a_{ij} é

$$C_{ij} = (-1)^{i+j} M_{ij}.$$

Definição 2.13 (Determinante). Para uma matriz de ordem um,

$$\mathbf{A} = [a_{11}],$$

define-se

$$\det(\mathbf{A}) = a_{11}.$$

Para $n \geq 2$, seja

$$\mathbf{A} = (a_{ij})_{n \times n} \in \mathbb{R}^{n \times n}.$$

O determinante de $\mathbf{A}$ pode ser calculado recursivamente pela expansão em cofatores de qualquer linha fixa i :

$$\det(\mathbf{A}) = \sum_{j=1}^n a_{ij} C_{ij}.$$

Também pode ser calculado pela expansão de qualquer coluna fixa j :

$$\det(\mathbf{A}) = \sum_{i=1}^n a_{ij} C_{ij}.$$

Em cada termo, o cofator C_{ij} envolve o determinante de uma matriz de ordem $n - 1$. O caso de ordem um encerra a definição recursiva.

Para uma matriz de ordem dois,

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix},$$

tem-se

$$\det(\mathbf{A}) = ad - bc.$$

Exemplo 2.15 (Determinante de uma matriz de ordem dois). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 2 & 4 \end{bmatrix}.$$

O determinante é

$$\det(\mathbf{A}) = 3(4) - 1(2) = 10.$$

Para uma matriz de ordem três, a expansão pela primeira linha é

$$\det(\mathbf{A}) = a_{11}C_{11} + a_{12}C_{12} + a_{13}C_{13}.$$

Exemplo 2.16 (Determinante de uma matriz de ordem três). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 0 \\ 3 & 1 & 2 \\ 0 & 4 & 1 \end{bmatrix}.$$

Expandindo pela primeira linha,

$$\det(\mathbf{A}) = 1 \begin{vmatrix} 1 & 2 \\ 4 & 1 \end{vmatrix} - 2 \begin{vmatrix} 3 & 2 \\ 0 & 1 \end{vmatrix} + 0 \begin{vmatrix} 3 & 1 \\ 0 & 4 \end{vmatrix}.$$

Portanto,

$$\det(\mathbf{A}) = 1(1 - 8) - 2(3 - 0) = -13.$$

Cálculo de determinantes

A expansão por cofatores é útil para compreender a definição do determinante e rea-

lizar cálculos de pequena ordem. Para matrizes maiores, a expansão direta se torna pouco eficiente. Nesses casos, o determinante costuma ser obtido por eliminação ou por decomposições matriciais, que serão estudadas posteriormente.

Proposição 2.9 (Propriedades do determinante). *Para matrizes quadradas de ordem n :*

1.

$$\det(\mathbf{I}_n) = 1.$$

2.

$$\det(\mathbf{A}^\top) = \det(\mathbf{A}).$$

3.

$$\det(\mathbf{AB}) = \det(\mathbf{A}) \det(\mathbf{B}).$$

4. Para $\alpha \in \mathbb{R}$,

$$\det(\alpha \mathbf{A}) = \alpha^n \det(\mathbf{A}).$$

5. Se $\mathbf{A}$ é triangular, então

$$\det(\mathbf{A}) = \prod_{i=1}^n a_{ii}.$$

As operações elementares sobre as linhas modificam o determinante de maneira específica:

- a troca de duas linhas multiplica o determinante por -1 ;
- a multiplicação de uma linha por α multiplica o determinante por α ;
- a adição de um múltiplo de uma linha a outra linha não altera o determinante.

Se as linhas de $\mathbf{A}$ são linearmente dependentes, então

$$\det(\mathbf{A}) = 0.$$

A mesma conclusão vale quando as colunas são linearmente dependentes. A ocorrência de duas linhas ou duas colunas iguais é um caso particular dessa propriedade.

Teorema 2.4 (Determinante e invertibilidade). *Para*

$$\mathbf{A} \in \mathbb{R}^{n \times n},$$

as afirmações seguintes são equivalentes:

$$\mathbf{A} \text{ é invertível} \iff \det(\mathbf{A}) \neq 0.$$

Quando $\mathbf{A}$ é invertível,

$$\det(\mathbf{A}^{-1}) = \frac{1}{\det(\mathbf{A})}.$$

De fato,

$$\det(\mathbf{A}\mathbf{A}^{-1}) = \det(\mathbf{I}_n) = 1,$$

e, pela propriedade multiplicativa,

$$\det(\mathbf{A}) \det(\mathbf{A}^{-1}) = 1.$$

Exemplo 2.17 (Verificação da invertibilidade). Para

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix},$$

tem-se

$$\det(\mathbf{A}) = 2(1) - 1(1) = 1.$$

Como

$$\det(\mathbf{A}) \neq 0,$$

a matriz é invertível.

Considere agora

$$\mathbf{B} = \begin{bmatrix} 2 & 4 \\ 1 & 2 \end{bmatrix}.$$

Nesse caso,

$$\det(\mathbf{B}) = 2(2) - 4(1) = 0.$$

A matriz $\mathbf{B}$ é singular.

2.3.4 Interpretação geométrica do determinante

Considere uma matriz quadrada

$$\mathbf{A} = [\mathbf{a}_1 \quad \mathbf{a}_2 \quad \cdots \quad \mathbf{a}_n] \in \mathbb{R}^{n \times n}.$$

As colunas de $\mathbf{A}$ podem ser interpretadas como vetores em $\mathbb{R}^n$. Esses vetores determinam uma região geométrica cuja medida depende de suas direções e comprimentos.

O valor absoluto do determinante,

$$|\det(\mathbf{A})|,$$

corresponde à medida do paralelepípedo determinado pelas colunas de $\mathbf{A}$:

- em uma dimensão, corresponde a um comprimento;
- em duas dimensões, corresponde à área do paralelogramo determinado pelas duas colunas;
- em três dimensões, corresponde ao volume do paralelepípedo determinado pelas três colunas;
- em $\mathbb{R}^n$, corresponde ao volume n -dimensional determinado pelas n colunas.

Como a matriz identidade $\mathbf{I}_n$ possui determinante igual a 1, suas colunas determinam uma região de volume unitário. Assim, $|\det(\mathbf{A})|$ também pode ser interpretado como o fator pelo qual esse volume unitário é ampliado ou reduzido quando os vetores canônicos são substituídos pelas colunas de $\mathbf{A}$.

O sinal do determinante acrescenta informação sobre a orientação dos vetores:

- se $\det(\mathbf{A}) > 0$, a orientação é preservada;
- se $\det(\mathbf{A}) < 0$, a orientação é invertida;
- se $\det(\mathbf{A}) = 0$, o volume n -dimensional é nulo.

No último caso, as colunas não determinam todas as direções necessárias para formar um volume n -dimensional. Em $\mathbb{R}^2$, por exemplo, duas colunas alinhadas formam uma região de área zero; em $\mathbb{R}^3$, três colunas contidas em um mesmo plano formam uma região de volume zero.

A Figura 2.1 apresenta essas situações em $\mathbb{R}^2$.




Figura 2.1: Interpretação geométrica do determinante em duas dimensões.

Na primeira situação, $\det(\mathbf{A}) = 2$: a área é multiplicada por 2 e a orientação é preservada. Na segunda, $\det(\mathbf{A}) = 0$: a região bidimensional é comprimida em uma reta. Na terceira, $\det(\mathbf{A}) = -2$: a área também é multiplicada por 2, mas a orientação é invertida.

O determinante informa se uma matriz quadrada é invertível. O posto amplia essa análise para matrizes quadradas ou retangulares.

2.3.5 Posto

O posto mede a dimensão da informação linearmente independente representada por uma matriz. Ele identifica o número máximo de direções que não podem ser obtidas como combinações lineares umas das outras.

Definição 2.14 (Posto de uma matriz). Seja

$$\mathbf{A} \in \mathbb{R}^{n \times p}.$$

O **posto** de $\mathbf{A}$, denotado por

$$\text{posto}(\mathbf{A}),$$

é a maior ordem de uma submatriz quadrada de $\mathbf{A}$ com determinante diferente de zero.

Equivalentemente, o posto é:

- o número máximo de colunas linearmente independentes de $\mathbf{A}$;
- o número máximo de linhas linearmente independentes de $\mathbf{A}$.

Esses dois números são sempre iguais. A interpretação do posto por meio dos espaços gerados pelas linhas e pelas colunas será desenvolvida no próximo capítulo.

O posto satisfaz

$$0 \leq \text{posto}(\mathbf{A}) \leq \min(n, p).$$

Uma matriz possui **posto completo** quando

$$\text{posto}(\mathbf{A}) = \min(n, p).$$

Um caso importante é o produto externo. Se

$$\mathbf{x} \neq \mathbf{0} \quad \text{e} \quad \mathbf{y} \neq \mathbf{0},$$

então

$$\text{posto}(\mathbf{xy}^\top) = 1.$$

De fato, todas as colunas de $\mathbf{xy}^\top$ são múltiplos escalares de $\mathbf{x}$ e, como $\mathbf{y} \neq \mathbf{0}$, pelo menos uma dessas colunas é não nula.

Essa estrutura será importante posteriormente nas decomposições matriciais, em que uma matriz poderá ser representada como soma de parcelas de posto 1.

Para uma matriz quadrada de ordem n ,

$$\text{posto}(\mathbf{A}) = n$$

equivale à existência de sua inversa.

Teorema 2.5 (Condições equivalentes de invertibilidade). *Para*

$$\mathbf{A} \in \mathbb{R}^{n \times n},$$

as afirmações seguintes são equivalentes:

$\mathbf{A}$ é invertível,

$$\det(\mathbf{A}) \neq 0$$

e

$$\text{posto}(\mathbf{A}) = n.$$

(Meyer, 2023)

Exemplo 2.18 (Posto de matrizes). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

Como

$$\det(\mathbf{A}) = 1(4) - 2(3) = -2,$$

tem-se

$$\text{posto}(\mathbf{A}) = 2.$$

Considere agora

$$\mathbf{B} = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}.$$

Como

$$\det(\mathbf{B}) = 0$$

e $\mathbf{B} \neq \mathbf{0}$,

$$\text{posto}(\mathbf{B}) = 1.$$

A segunda linha de $\mathbf{B}$ é o dobro da primeira, de modo que uma delas não acrescenta informação linear.

Para uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

tem-se

$$\text{posto}(\mathbf{X}) \leq \min(n, p).$$

Quando

$$\text{posto}(\mathbf{X}) < p,$$

existe redundância linear entre as variáveis. A interpretação do posto em termos de espaços gerados, independência linear e dimensão será desenvolvida no próximo capítulo.

2.3.6 Sistemas lineares

Um sistema de n equações lineares com p incógnitas pode ser escrito na forma matricial.

Definição 2.15 (Sistema linear). Sejam

$$\mathbf{A} \in \mathbb{R}^{n \times p}, \quad \mathbf{x} \in \mathbb{R}^p$$

e

$$\mathbf{b} \in \mathbb{R}^n.$$

O sistema linear associado é

$$\mathbf{Ax} = \mathbf{b}.$$

A matriz $\mathbf{A}$ contém os coeficientes, $\mathbf{x}$ contém as incógnitas e $\mathbf{b}$ contém os termos independentes.

Em componentes, o sistema é

$$\begin{aligned}a_{11}x_1 + a_{12}x_2 + \cdots + a_{1p}x_p &= b_1, \\a_{21}x_1 + a_{22}x_2 + \cdots + a_{2p}x_p &= b_2, \\&\vdots \\a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{np}x_p &= b_n.\end{aligned}$$

A matriz aumentada do sistema é

$$[\mathbf{A} \mid \mathbf{b}] = \begin{bmatrix} a_{11} & \cdots & a_{1p} & b_1 \\ \vdots & \ddots & \vdots & \vdots \\ a_{n1} & \cdots & a_{np} & b_n \end{bmatrix}.$$

Teorema 2.6 (Existência e quantidade de soluções). *Sejam*

$$\mathbf{A} \in \mathbb{R}^{n \times p}, \quad \mathbf{x} \in \mathbb{R}^p$$

e

$$\mathbf{b} \in \mathbb{R}^n.$$

O sistema

$$\mathbf{Ax} = \mathbf{b}$$

possui solução se, e somente se,

$$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]).$$

Quando o sistema é consistente:

- a solução é única se

$$\text{posto}(\mathbf{A}) = p;$$

- existem infinitas soluções se

$$\text{posto}(\mathbf{A}) < p.$$

Definição 2.16 (Sistema linear homogêneo). Um **sistema linear homogêneo** é um sistema da forma

$$\mathbf{A}\mathbf{x} = \mathbf{0},$$

em que

$$\mathbf{A} \in \mathbb{R}^{n \times p}, \quad \mathbf{x} \in \mathbb{R}^p$$

e

$$\mathbf{0} \in \mathbb{R}^n.$$

Portanto, um sistema homogêneo é um caso particular de sistema linear no qual todos os termos independentes são iguais a zero.

Todo sistema homogêneo possui pelo menos a **solução trivial**

$$\mathbf{x} = \mathbf{0}.$$

Dependendo da matriz $\mathbf{A}$, também podem existir **soluções não triviais**, isto é, soluções para as quais

$$\mathbf{x} \neq \mathbf{0}.$$

A Tabela 2.1 resume a classificação das soluções de um sistema linear.

Tabela 2.1: Classificação das soluções de um sistema linear.

Condição	Resultado
$\text{posto}(\mathbf{A}) \neq \text{posto}([\mathbf{A} \mid \mathbf{b}])$	Não existe solução
$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]) = p$	Existe uma única solução
$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]) < p$	Existem infinitas soluções

Exemplo 2.19 (Sistema com solução única). Considere

$$\begin{aligned} 2x_1 + x_2 &= 5, \\ x_1 + x_2 &= 3. \end{aligned}$$

A forma matricial é

$$\begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 5 \\ 3 \end{bmatrix}.$$

Como

$$\det \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} = 1,$$

a matriz de coeficientes é invertível. A solução é

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

Exemplo 2.20 (Sistemas com infinitas soluções e sem solução). Considere inicialmente o sistema

$$\begin{aligned} x_1 + x_2 &= 2, \\ 2x_1 + 2x_2 &= 4. \end{aligned}$$

A segunda equação é o dobro da primeira. Portanto,

$$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]) = 1 < 2.$$

O sistema possui infinitas soluções, que podem ser escritas como

$$x_1 = 2 - t, \quad x_2 = t, \quad t \in \mathbb{R}.$$

Considere agora

$$\begin{aligned} x_1 + x_2 &= 2, \\ 2x_1 + 2x_2 &= 5. \end{aligned}$$

As linhas da matriz de coeficientes continuam proporcionais, mas os termos independentes não preservam a mesma proporção. Nesse caso,

$$\text{posto}(\mathbf{A}) = 1$$

e

$$\text{posto}([\mathbf{A} \mid \mathbf{b}]) = 2.$$

Como os postos são diferentes, o sistema não possui solução.

Para uma matriz quadrada invertível,

$$\mathbf{Ax} = \mathbf{b}$$

possui a solução única

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b}.$$

Cálculo da solução

A expressão

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b}$$

caracteriza a solução quando $\mathbf{A}$ é invertível. Em cálculos computacionais, sistemas lineares são resolvidos diretamente, sem calcular explicitamente a matriz inversa.

O número de equações e o número de incógnitas não determinam, isoladamente, a existência ou a quantidade de soluções:

- se $n > p$, o sistema é sobredeterminado;
- se $n < p$, o sistema é subdeterminado;
- se $n = p$, o sistema é quadrado.

A classificação completa depende dos postos de $\mathbf{A}$ e de $[\mathbf{A} \mid \mathbf{b}]$.

2.3.7 Aprofundamento: pseudoinversa

Leitura de aprofundamento

A pseudoinversa permite estender a resolução de sistemas lineares para matrizes retangulares ou singulares. Sua construção será desenvolvida no capítulo sobre decomposição em valores singulares. Nesta seção, são apresentadas sua definição e suas principais consequências.

Definição 2.17 (Pseudoinversa de Moore–Penrose). Seja

$$\mathbf{A} \in \mathbb{R}^{n \times p}.$$

A **pseudoinversa de Moore–Penrose** de $\mathbf{A}$ é a única matriz

$$\mathbf{A}^+ \in \mathbb{R}^{p \times n}$$

que satisfaz simultaneamente:

$$\mathbf{A}\mathbf{A}^+\mathbf{A} = \mathbf{A},$$

$$\mathbf{A}^+\mathbf{A}\mathbf{A}^+ = \mathbf{A}^+,$$

$$(\mathbf{A}\mathbf{A}^+)^{\top} = \mathbf{A}\mathbf{A}^+$$

e

$$(\mathbf{A}^+\mathbf{A})^{\top} = \mathbf{A}^+\mathbf{A}.$$

(Harville, 1997)

Quando $\mathbf{A}$ é quadrada e invertível,

$$\mathbf{A}^+ = \mathbf{A}^{-1}.$$

Considere o problema

$$\mathbf{A}\mathbf{x} = \mathbf{b}.$$

O vetor

$$\mathbf{x}^+ = \mathbf{A}^+\mathbf{b}$$

possui interpretações diferentes conforme a existência e a quantidade de soluções exatas.

Tabela 2.2: Interpretação da solução obtida pela pseudoinversa.

Situação do sistema	Interpretação de $\mathbf{x}^+ = \mathbf{A}^+\mathbf{b}$
O sistema é consistente e possui solução única	$\mathbf{x}^+$ é a solução exata do sistema
O sistema é consistente e possui várias soluções	$\mathbf{x}^+$ é a solução exata de menor norma euclidiana
O sistema é inconsistente	$\mathbf{x}^+$ minimiza $\ \mathbf{Ax} - \mathbf{b}\ $ e possui a menor norma entre todos os minimizadores

No caso inconsistente, $\mathbf{x}^+$ resolve o problema de mínimos quadrados

$$\min_{\mathbf{x} \in \mathbb{R}^p} \|\mathbf{Ax} - \mathbf{b}\|.$$

Pseudoinversa e inversa

Em geral,

$$\mathbf{A}^+\mathbf{A} \neq \mathbf{I}_p$$

e

$$\mathbf{AA}^+ \neq \mathbf{I}_n.$$

Portanto, a pseudoinversa não satisfaz todas as propriedades da inversa usual.

A construção de $\mathbf{A}^+$, sua interpretação por projeções e sua relação com o posto serão desenvolvidas no capítulo sobre decomposição em valores singulares.

2.4 Matrizes ortogonais, diagonais e triangulares

Algumas matrizes quadradas possuem estruturas que simplificam produtos, inversões e sistemas lineares. Nesta seção são consideradas as matrizes ortogonais, diagonais e triangulares.

2.4.1 Matrizes ortogonais

Definição 2.18 (Matriz ortogonal). Uma matriz

$$\mathbf{Q} \in \mathbb{R}^{n \times n}$$

é **ortogonal** quando

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_n.$$

A condição anterior implica que $\mathbf{Q}$ é invertível e

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

Consequentemente,

$$\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}_n.$$

Escrevendo as colunas de $\mathbf{Q}$ como

$$\mathbf{Q} = [\mathbf{q}_1 \ \mathbf{q}_2 \ \cdots \ \mathbf{q}_n],$$

tem-se

$$\mathbf{Q}^\top \mathbf{Q} = \begin{bmatrix} \mathbf{q}_1^\top \mathbf{q}_1 & \cdots & \mathbf{q}_1^\top \mathbf{q}_n \\ \vdots & \ddots & \vdots \\ \mathbf{q}_n^\top \mathbf{q}_1 & \cdots & \mathbf{q}_n^\top \mathbf{q}_n \end{bmatrix}.$$

Portanto, $\mathbf{Q}$ é ortogonal quando suas colunas satisfazem

$$\mathbf{q}_i^\top \mathbf{q}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

As colunas possuem norma unitária e são ortogonais duas a duas. A mesma propriedade é satisfeita pelas linhas de $\mathbf{Q}$.

Exemplo 2.21 (Verificação da ortogonalidade). Considere

$$\mathbf{Q} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}.$$

Sua transposta é

$$\mathbf{Q}^\top = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}.$$

Calculando o produto,

$$\mathbf{Q}^\top \mathbf{Q} = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix} \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix} = \mathbf{I}_2.$$

Logo, $\mathbf{Q}$ é ortogonal e

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

Teorema 2.7 (Preservação do produto interno). *Se $\mathbf{Q} \in \mathbb{R}^{n \times n}$ é ortogonal, então, para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$,*

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{y}.$$

Comprovação. Pela associatividade do produto matricial,

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{Q}^\top \mathbf{Q} \mathbf{y}.$$

Como

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_n,$$

obtém-se

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{I}_n \mathbf{y} = \mathbf{x}^\top \mathbf{y}.$$

□

Tomando $\mathbf{y} = \mathbf{x}$, obtém-se

$$\|\mathbf{Q}\mathbf{x}\| = \|\mathbf{x}\|.$$

Aplicando a mesma propriedade ao vetor $\mathbf{x} - \mathbf{y}$,

$$\|\mathbf{Q}\mathbf{x} - \mathbf{Q}\mathbf{y}\| = \|\mathbf{x} - \mathbf{y}\|.$$

Portanto, matrizes ortogonais preservam produtos internos, normas e distâncias euclidianas.

Além disso,

$$\det(\mathbf{Q})^2 = \det(\mathbf{Q}^\top \mathbf{Q}) = \det(\mathbf{I}_n) = 1,$$

de modo que

$$\det(\mathbf{Q}) \in \{-1, 1\}.$$

O produto de matrizes ortogonais de mesma ordem também é ortogonal.

As interpretações das matrizes ortogonais como rotações, reflexões e mudanças de orientação serão desenvolvidas no capítulo sobre transformações lineares.

2.4.2 Matrizes diagonais

Definição 2.19 (Matriz diagonal). Uma matriz

$$\mathbf{D} = (d_{ij})_{n \times n} \in \mathbb{R}^{n \times n}$$

é **diagonal** quando

$$d_{ij} = 0 \quad \text{para} \quad i \neq j.$$

Uma matriz diagonal possui a forma

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & d_n \end{bmatrix} = \text{diag} \left(\begin{bmatrix} d_1 \\ d_2 \\ \vdots \\ d_n \end{bmatrix} \right).$$

A matriz identidade é uma matriz diagonal:

$$\mathbf{I}_n = \text{diag}(1, 1, \dots, 1).$$

Toda matriz diagonal é simétrica, pois

$$\mathbf{D}^\top = \mathbf{D}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix},$$

o produto por uma matriz diagonal é

$$\mathbf{D}\mathbf{x} = \begin{bmatrix} d_1 x_1 \\ d_2 x_2 \\ \vdots \\ d_n x_n \end{bmatrix}.$$

Cada componente de $\mathbf{x}$ é multiplicada pelo elemento correspondente da diagonal.

Exemplo 2.22 (Produto por uma matriz diagonal). Considere

$$\mathbf{D} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & 3 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} 1 \\ 4 \\ -2 \end{bmatrix}.$$

Então,

$$\mathbf{D}\mathbf{x} = \begin{bmatrix} 2(1) \\ -1(4) \\ 3(-2) \end{bmatrix} = \begin{bmatrix} 2 \\ -4 \\ -6 \end{bmatrix}.$$

A soma e o produto de matrizes diagonais de mesma ordem também são diagonais. Se

$$\mathbf{D}_1 = \text{diag}(d_1, \dots, d_n)$$

e

$$\mathbf{D}_2 = \text{diag}(e_1, \dots, e_n),$$

então

$$\mathbf{D}_1 + \mathbf{D}_2 = \text{diag}(d_1 + e_1, \dots, d_n + e_n)$$

e

$$\mathbf{D}_1 \mathbf{D}_2 = \text{diag}(d_1 e_1, \dots, d_n e_n).$$

Duas matrizes diagonais de mesma ordem comutam:

$$\mathbf{D}_1 \mathbf{D}_2 = \mathbf{D}_2 \mathbf{D}_1.$$

O determinante de uma matriz diagonal é o produto dos elementos de sua diagonal:

$$\det(\mathbf{D}) = \prod_{i=1}^n d_i.$$

Logo, $\mathbf{D}$ é invertível se, e somente se,

$$d_i \neq 0, \quad i = 1, \dots, n.$$

Nesse caso,

$$\mathbf{D}^{-1} = \text{diag}\left(\frac{1}{d_1}, \frac{1}{d_2}, \dots, \frac{1}{d_n}\right).$$

Para um inteiro positivo k ,

$$\mathbf{D}^k = \text{diag}(d_1^k, d_2^k, \dots, d_n^k).$$

As matrizes diagonais serão utilizadas nas decomposições matriciais estudadas nos capítulos posteriores.

2.4.3 Matrizes triangulares

Definição 2.20 (Matrizes triangulares). Uma matriz

$$\mathbf{U} = (u_{ij})_{n \times n}$$

é **triangular superior** quando

$$u_{ij} = 0 \quad \text{para} \quad i > j.$$

Sua forma geral é

$$\mathbf{U} = \begin{bmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ 0 & u_{22} & \cdots & u_{2n} \\ \vdots & \ddots & \ddots & \vdots \\ 0 & \cdots & 0 & u_{nn} \end{bmatrix}.$$

Uma matriz

$$\mathbf{L} = (\ell_{ij})_{n \times n}$$

é **triangular inferior** quando

$$\ell_{ij} = 0 \quad \text{para} \quad i < j.$$

Sua forma geral é

$$\mathbf{L} = \begin{bmatrix} \ell_{11} & 0 & \cdots & 0 \\ \ell_{21} & \ell_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ \ell_{n1} & \ell_{n2} & \cdots & \ell_{nn} \end{bmatrix}.$$

A transposta de uma matriz triangular superior é triangular inferior:

$$\mathbf{U}^\top \text{ é triangular inferior.}$$

Da mesma forma,

$$\mathbf{L}^\top \text{ é triangular superior.}$$

A soma e o produto de matrizes triangulares superiores de mesma ordem permanecem triangulares superiores. A mesma propriedade vale para matrizes triangulares inferiores.

O determinante de uma matriz triangular é o produto dos elementos de sua diagonal:

$$\det(\mathbf{U}) = \prod_{i=1}^n u_{ii}$$

e

$$\det(\mathbf{L}) = \prod_{i=1}^n \ell_{ii}.$$

Uma matriz triangular é invertível se, e somente se, todos os elementos de sua diagonal são diferentes de zero.

Exemplo 2.23 (Determinante de uma matriz triangular). Considere

$$\mathbf{U} = \begin{bmatrix} 2 & 1 & -1 \\ 0 & 3 & 4 \\ 0 & 0 & 5 \end{bmatrix}.$$

Como $\mathbf{U}$ é triangular superior,

$$\det(\mathbf{U}) = 2(3)(5) = 30.$$

Como todos os elementos da diagonal são diferentes de zero, $\mathbf{U}$ é invertível.

2.4.4 Aprofundamento: sistemas triangulares

Leitura de aprofundamento

Os sistemas triangulares mostram como a estrutura de uma matriz pode simplificar a resolução de equações. Esses procedimentos também aparecem nas decomposições matriciais estudadas posteriormente.

Um sistema cuja matriz de coeficientes é triangular pode ser resolvido sequencialmente.

Para uma matriz triangular superior,

$$\mathbf{U}\mathbf{x} = \mathbf{b},$$

a última equação contém somente a incógnita x_n . Após determinar x_n , substitui-se seu valor na equação anterior. Esse procedimento continua até a determinação de x_1 e é denominado **substituição regressiva**.

Exemplo 2.24 (Sistema triangular superior). Considere o sistema

$$\begin{aligned}x_1 + 2x_2 - x_3 &= 4, \\2x_2 + 3x_3 &= 7, \\x_3 &= 1.\end{aligned}$$

Sua forma matricial é

$$\begin{bmatrix} 1 & 2 & -1 \\ 0 & 2 & 3 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 4 \\ 7 \\ 1 \end{bmatrix}.$$

A última equação fornece

$$x_3 = 1.$$

Substituindo na segunda equação,

$$2x_2 + 3(1) = 7,$$

de modo que

$$x_2 = 2.$$

Substituindo os valores obtidos na primeira equação,

$$x_1 + 2(2) - 1 = 4,$$

resulta

$$x_1 = 1.$$

Portanto,

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}.$$

Para um sistema

$$\mathbf{L}\mathbf{x} = \mathbf{b},$$

com $\mathbf{L}$ triangular inferior, a resolução começa pela primeira equação e segue até a última. Esse procedimento é denominado **substituição progressiva**.

As matrizes triangulares aparecem na resolução de sistemas e em decomposições matriciais. As formas bilineares e quadráticas serão estudadas na próxima seção.

2.5 Formas bilineares, formas quadráticas e positividade

As formas bilineares associam dois vetores a um escalar e são lineares em cada argumento separadamente. Quando uma forma bilinear é avaliada utilizando o mesmo vetor em seus dois argumentos, obtém-se uma função de um único vetor, denominada forma quadrática.

Essa relação permite conectar propriedades das matrizes, como simetria e positividade, a expressões escalares que aparecem frequentemente na análise multivariada, entre elas produtos internos, normas, variâncias e distâncias.

2.5.1 Formas bilineares

Definição 2.21 (Forma bilinear). Uma função

$$g : \mathbb{R}^p \times \mathbb{R}^p \longrightarrow \mathbb{R}$$

é denominada **forma bilinear** quando é linear separadamente em cada argumento.

Isso significa que, para quaisquer

$$\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$$

e quaisquer

$$\beta \in \mathbb{R},$$

tem-se

$$g(\mathbf{x} + \beta \mathbf{z}, \mathbf{y}) = g(\mathbf{x}, \mathbf{y}) + \beta g(\mathbf{z}, \mathbf{y})$$

e

$$g(\mathbf{x}, \mathbf{z} + \beta \mathbf{y}) = g(\mathbf{x}, \mathbf{z}) + \beta g(\mathbf{x}, \mathbf{y}).$$

A bilinearidade significa, portanto, que, mantendo um dos argumentos fixo, a forma bilinear é uma função linear do outro argumento.

Fixado $\mathbf{y} \in \mathbb{R}^p$, a função

$$\mathbf{x} \mapsto g(\mathbf{x}, \mathbf{y})$$

é linear em $\mathbf{x}$. Analogamente, fixado $\mathbf{x} \in \mathbb{R}^p$, a função

$$\mathbf{y} \mapsto g(\mathbf{x}, \mathbf{y})$$

é linear em $\mathbf{y}$.

Um caso particularmente importante para a estatística são as formas bilineares simétricas.

Definição 2.22 (Forma bilinear simétrica). Uma forma bilinear

$$g : \mathbb{R}^p \times \mathbb{R}^p \longrightarrow \mathbb{R}$$

é denominada **simétrica** quando

$$g(\mathbf{x}, \mathbf{y}) = g(\mathbf{y}, \mathbf{x})$$

para quaisquer

$$\mathbf{x}, \mathbf{y} \in \mathbb{R}^p.$$

Exemplo 2.25 (Produto interno como forma bilinear simétrica). O produto interno usual em $\mathbb{R}^p$,

$$g(\mathbf{x}, \mathbf{y}) = \langle \mathbf{x}, \mathbf{y} \rangle,$$

é um exemplo de forma bilinear simétrica, pois,

$$\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{y}, \mathbf{x} \rangle,$$

ou, equivalentemente,

$$\mathbf{x}^\top \mathbf{y} = \mathbf{y}^\top \mathbf{x}.$$

Nem toda forma bilinear é simétrica.

Exemplo 2.26 (Bilinearidade e ausência de simetria). Considere a matriz

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ -1 & 3 \end{bmatrix}$$

e os vetores

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \end{bmatrix}.$$

A função

$$g(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y}$$

é dada por

$$\begin{aligned} g(\mathbf{x}, \mathbf{y}) &= \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ -1 & 3 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} \\ &= \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2y_1 + y_2 \\ -y_1 + 3y_2 \end{bmatrix} \\ &= 2x_1y_1 + x_1y_2 - x_2y_1 + 3x_2y_2. \end{aligned}$$

Para verificar a linearidade no primeiro argumento, sejam $\mathbf{x}_1, \mathbf{x}_2, \mathbf{y} \in \mathbb{R}^2$ e $\beta \in \mathbb{R}$. Então,

$$\begin{aligned}
g(\mathbf{x}_1 + \beta \mathbf{x}_2, \mathbf{y}) &= (\mathbf{x}_1 + \beta \mathbf{x}_2)^\top \mathbf{A} \mathbf{y} \\
&= \mathbf{x}_1^\top \mathbf{A} \mathbf{y} + \beta \mathbf{x}_2^\top \mathbf{A} \mathbf{y} \\
&= g(\mathbf{x}_1, \mathbf{y}) + \beta g(\mathbf{x}_2, \mathbf{y}).
\end{aligned}$$

Analogamente, para $\mathbf{x}, \mathbf{y}_1, \mathbf{y}_2 \in \mathbb{R}^2$,

$$\begin{aligned}
g(\mathbf{x}, \mathbf{y}_1 + \beta \mathbf{y}_2) &= \mathbf{x}^\top \mathbf{A} (\mathbf{y}_1 + \beta \mathbf{y}_2) \\
&= \mathbf{x}^\top \mathbf{A} \mathbf{y}_1 + \beta \mathbf{x}^\top \mathbf{A} \mathbf{y}_2 \\
&= g(\mathbf{x}, \mathbf{y}_1) + \beta g(\mathbf{x}, \mathbf{y}_2).
\end{aligned}$$

Portanto, g é linear em cada argumento separadamente e, assim, é uma forma bilinear.

Para verificar se a forma bilinear é simétrica, invertem-se os dois argumentos. Tem-se

$$g(\mathbf{y}, \mathbf{x}) = 2x_1y_1 - x_1y_2 + x_2y_1 + 3x_2y_2.$$

Por outro lado,

$$g(\mathbf{x}, \mathbf{y}) = 2x_1y_1 + x_1y_2 - x_2y_1 + 3x_2y_2.$$

As duas expressões diferem nos termos cruzados. Portanto, em geral,

$$g(\mathbf{x}, \mathbf{y}) \neq g(\mathbf{y}, \mathbf{x}),$$

e a forma bilinear não é simétrica.

De modo geral, uma forma bilinear

$$g(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y}$$

é simétrica se, e somente se, sua matriz representante é simétrica, isto é, $\mathbf{A} = \mathbf{A}^\top$.

Uma forma bilinear também pode ser avaliada utilizando o mesmo vetor em seus dois argumentos. Assim, em vez de considerar

$$g(\mathbf{x}, \mathbf{y}),$$

podemos considerar

$$g(\mathbf{x}, \mathbf{x}).$$

Essa avaliação produz uma função de um único vetor e conduz às formas quadráticas.

2.5.2 Formas quadráticas

Definição 2.23 (Forma quadrática). Seja

$$g : \mathbb{R}^p \times \mathbb{R}^p \longrightarrow \mathbb{R}$$

uma forma bilinear. A função

$$Q : \mathbb{R}^p \longrightarrow \mathbb{R}$$

definida por

$$Q(\mathbf{x}) = g(\mathbf{x}, \mathbf{x})$$

é denominada **forma quadrática** associada a g .

Se a forma bilinear possui representação matricial

$$g(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y},$$

então

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}, \quad \mathbf{x} \in \mathbb{R}^p.$$

A forma bilinear depende de dois argumentos e é linear em cada um deles separadamente. A forma quadrática, por sua vez, depende de um único argumento e, em geral, não é uma função linear desse vetor.

De fato, para qualquer $\alpha \in \mathbb{R}$,

$$\begin{aligned} Q(\alpha \mathbf{x}) &= g(\alpha \mathbf{x}, \alpha \mathbf{x}) \\ &= \alpha^2 g(\mathbf{x}, \mathbf{x}) \\ &= \alpha^2 Q(\mathbf{x}). \end{aligned}$$

Assim,

$$Q(\alpha \mathbf{x}) = \alpha^2 Q(\mathbf{x}).$$

A expressão quadrática pode ser interpretada como a avaliação da forma bilinear sobre a diagonal do produto cartesiano,

$$\{(\mathbf{x}, \mathbf{x}) : \mathbf{x} \in \mathbb{R}^p\} \subset \mathbb{R}^p \times \mathbb{R}^p.$$

O produto interno fornece um exemplo imediato dessa construção.

Exemplo 2.27 (Produto interno e norma ao quadrado). Considere a forma bilinear dada pelo produto interno usual,

$$g(\mathbf{x}, \mathbf{y}) = \langle \mathbf{x}, \mathbf{y} \rangle.$$

Ao utilizar o mesmo vetor nos dois argumentos,

$$Q(\mathbf{x}) = g(\mathbf{x}, \mathbf{x}) = \langle \mathbf{x}, \mathbf{x} \rangle.$$

Pela definição da norma euclidiana,

$$\langle \mathbf{x}, \mathbf{x} \rangle = \|\mathbf{x}\|^2.$$

Portanto,

$$Q(\mathbf{x}) = \|\mathbf{x}\|^2 = \mathbf{x}^\top \mathbf{x}.$$

A matriz representante dessa forma quadrática é

$$\mathbf{I}_p.$$

Em geral, se

$$\mathbf{A} = (a_{ij})_{p \times p},$$

então

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{i=1}^p \sum_{j=1}^p a_{ij} x_i x_j. \quad (2.1)$$

Para

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

tem-se

$$\begin{aligned} Q(\mathbf{x}) &= \mathbf{x}^\top \mathbf{A} \mathbf{x} \\ &= \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} a & b \\ c & d \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \\ &= ax_1^2 + (b+c)x_1x_2 + dx_2^2. \end{aligned}$$

Esse desenvolvimento mostra uma diferença importante entre formas bilineares e formas quadráticas.

Na forma bilinear

$$g(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y},$$

os elementos a_{ij} e a_{ji} podem produzir contribuições distintas porque os dois vetores não precisam ser iguais.

Na forma quadrática

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x},$$

os termos fora da diagonal aparecem combinados. No caso bidimensional, por exemplo, b e c aparecem somente por meio da soma

$$b + c.$$

Consequentemente, a matriz que aparece em uma representação

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

não é necessariamente única quando matrizes não simétricas são admitidas. Matrizes que diferem apenas por uma parcela antissimétrica produzem a mesma forma quadrática.

Entretanto, toda forma quadrática possui uma única matriz simétrica que a representa. Essa propriedade é apresentada na proposição seguinte.

Proposição 2.10 (Parte simétrica de uma forma quadrática). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e defina

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2}.$$

Então $\mathbf{S}$ é simétrica e, para todo

$$\mathbf{x} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{S} \mathbf{x}.$$

Além disso, $\mathbf{S}$ é a única matriz simétrica que representa essa forma quadrática.

Comprovação. A matriz $\mathbf{A}$ pode ser escrita como

$$\mathbf{A} = \mathbf{S} + \mathbf{K},$$

em que

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2}$$

é simétrica e

$$\mathbf{K} = \frac{\mathbf{A} - \mathbf{A}^\top}{2}$$

é antissimétrica.

De fato,

$$\mathbf{S}^\top = \mathbf{S}$$

e

$$\mathbf{K}^\top = -\mathbf{K}.$$

Assim,

$$\begin{aligned}\mathbf{x}^\top \mathbf{A} \mathbf{x} &= \mathbf{x}^\top (\mathbf{S} + \mathbf{K}) \mathbf{x} \\ &= \mathbf{x}^\top \mathbf{S} \mathbf{x} + \mathbf{x}^\top \mathbf{K} \mathbf{x}.\end{aligned}$$

O termo

$$\mathbf{x}^\top \mathbf{K} \mathbf{x}$$

é um escalar. Portanto,

$$\mathbf{x}^\top \mathbf{K} \mathbf{x} = (\mathbf{x}^\top \mathbf{K} \mathbf{x})^\top.$$

Utilizando a transposição do produto,

$$\begin{aligned}\mathbf{x}^\top \mathbf{K} \mathbf{x} &= \mathbf{x}^\top \mathbf{K}^\top \mathbf{x} \\ &= -\mathbf{x}^\top \mathbf{K} \mathbf{x}.\end{aligned}$$

Logo,

$$2\mathbf{x}^\top \mathbf{K} \mathbf{x} = 0$$

e, conseqüentemente,

$$\mathbf{x}^\top \mathbf{K} \mathbf{x} = 0.$$

Portanto,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{S} \mathbf{x}.$$

Resta mostrar a unicidade da representação simétrica.

Suponha que $\mathbf{S}_1$ e $\mathbf{S}_2$ sejam duas matrizes simétricas que representem a mesma forma quadrática. Então,

$$\mathbf{x}^\top \mathbf{S}_1 \mathbf{x} = \mathbf{x}^\top \mathbf{S}_2 \mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^p$.

Definindo

$$\mathbf{D} = \mathbf{S}_1 - \mathbf{S}_2,$$

a matriz $\mathbf{D}$ também é simétrica e satisfaz

$$\mathbf{x}^\top \mathbf{D} \mathbf{x} = 0$$

para todo $\mathbf{x} \in \mathbb{R}^p$.

Para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,

$$\begin{aligned} 0 &= (\mathbf{x} + \mathbf{y})^\top \mathbf{D} (\mathbf{x} + \mathbf{y}) \\ &= \mathbf{x}^\top \mathbf{D} \mathbf{x} + \mathbf{x}^\top \mathbf{D} \mathbf{y} + \mathbf{y}^\top \mathbf{D} \mathbf{x} + \mathbf{y}^\top \mathbf{D} \mathbf{y}. \end{aligned}$$

Como $\mathbf{D}$ é simétrica,

$$\mathbf{y}^\top \mathbf{D} \mathbf{x} = \mathbf{x}^\top \mathbf{D} \mathbf{y},$$

e os termos quadráticos são nulos. Assim,

$$2\mathbf{x}^\top \mathbf{D} \mathbf{y} = 0$$

para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$.

Logo,

$$\mathbf{x}^\top \mathbf{D} \mathbf{y} = 0$$

para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$.

Em particular, tomando os vetores da base canônica,

$$\mathbf{x} = \mathbf{e}_i \quad \text{e} \quad \mathbf{y} = \mathbf{e}_j,$$

obtém-se

$$\mathbf{e}_i^\top \mathbf{D} \mathbf{e}_j = d_{ij} = 0$$

para todos i e j .

Portanto,

$$\mathbf{D} = \mathbf{0},$$

o que implica

$$\mathbf{S}_1 = \mathbf{S}_2.$$

□

Assim, embora uma forma quadrática possa possuir diferentes representações por matrizes não simétricas, sua representação por uma matriz simétrica é única.

Por essa razão, no estudo de formas quadráticas, pode-se trabalhar sem perda de generalidade com matrizes simétricas.

Observe que essa propriedade é específica das formas quadráticas. Para uma forma bilinear geral,

$$g(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y},$$

a parte antissimétrica de $\mathbf{A}$ pode contribuir para o valor da expressão quando

$$\mathbf{x} \neq \mathbf{y}.$$

Quando os dois argumentos coincidem, essa contribuição desaparece.

Exemplo 2.28 (Expansão de uma forma quadrática). Considere

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

A forma quadrática associada a $\mathbf{A}$ é

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

Então,

$$Q(\mathbf{x}) = \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

Efetuando os produtos,

$$Q(\mathbf{x}) = 2x_1^2 + 2x_1x_2 + 3x_2^2.$$

Para

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix},$$

obtém-se

$$\begin{aligned} Q(\mathbf{x}) &= 2(1)^2 + 2(1)(2) + 3(2)^2 \\ &= 2 + 4 + 12 \\ &= 18. \end{aligned}$$

2.5.3 Positividade

Como toda forma quadrática pode ser representada por uma única matriz simétrica, propriedades importantes da forma quadrática podem ser estudadas a partir dos valores assumidos por

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x},$$

com $\mathbf{A}$ simétrica.

A classificação em positiva definida, semidefinida positiva, negativa definida, semidefinida negativa ou indefinida depende do sinal assumido por essa expressão.

Definição 2.24 (Classificação de matrizes simétricas pela forma quadrática). Seja

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

uma matriz simétrica e considere a forma quadrática

$$q_{\mathbf{A}}(\mathbf{x}) = \mathbf{x}^{\top} \mathbf{A} \mathbf{x}.$$

A matriz $\mathbf{A}$ é:

- **positiva definida** quando

$$\mathbf{x}^{\top} \mathbf{A} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$. Nesse caso, escreve-se

$$\mathbf{A} \succ \mathbf{0};$$

- **semidefinida positiva** quando

$$\mathbf{x}^{\top} \mathbf{A} \mathbf{x} \geq 0$$

para todo $\mathbf{x} \in \mathbb{R}^p$. Nesse caso, escreve-se

$$\mathbf{A} \succeq \mathbf{0};$$

- **negativa definida** quando

$$\mathbf{x}^{\top} \mathbf{A} \mathbf{x} < 0$$

para todo $\mathbf{x} \neq \mathbf{0}$. Nesse caso, escreve-se

$$\mathbf{A} \prec \mathbf{0};$$

- **semidefinida negativa** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} \leq 0$$

para todo $\mathbf{x} \in \mathbb{R}^p$. Nesse caso, escreve-se

$$\mathbf{A} \preceq \mathbf{0};$$

- **indefinida** quando existem vetores não nulos $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ tais que

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0$$

e

$$\mathbf{y}^\top \mathbf{A} \mathbf{y} < 0.$$

Para matrizes indefinidas, não se utiliza uma relação de ordem do tipo $\mathbf{A} \succeq \mathbf{0}$ ou $\mathbf{A} \preceq \mathbf{0}$.

As notações $\succ, \succeq, \prec$ e $\preceq$ expressam a ordem de Löwner para matrizes simétricas. Em particular,

$$\begin{aligned} \mathbf{A} \succ \mathbf{0} &\iff \mathbf{A} \text{ é positiva definida,} \\ \mathbf{A} \succeq \mathbf{0} &\iff \mathbf{A} \text{ é semidefinida positiva,} \\ \mathbf{A} \prec \mathbf{0} &\iff \mathbf{A} \text{ é negativa definida,} \\ \mathbf{A} \preceq \mathbf{0} &\iff \mathbf{A} \text{ é semidefinida negativa.} \end{aligned}$$

produto interno usual fornece um exemplo imediato de forma quadrática associada a uma matriz positiva definida.

Como

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{I}_p \mathbf{x} = \|\mathbf{x}\|^2,$$

tem-se

$$Q(\mathbf{x}) > 0$$

para todo

$$\mathbf{x} \neq \mathbf{0}.$$

Portanto, a matriz identidade

$$\mathbf{I}_p$$

é positiva definida.

Outro exemplo importante de matriz semidefinida positiva é obtido pelo produto externo de um vetor consigo mesmo.

Para

$$\mathbf{x}, \mathbf{z} \in \mathbb{R}^p,$$

considere

$$\mathbf{x}\mathbf{x}^\top.$$

Então,

$$\begin{aligned}\mathbf{z}^\top (\mathbf{x}\mathbf{x}^\top) \mathbf{z} &= (\mathbf{z}^\top \mathbf{x}) (\mathbf{x}^\top \mathbf{z}) \\ &= (\mathbf{x}^\top \mathbf{z})^2 \\ &\geq 0.\end{aligned}$$

Portanto,

$$\mathbf{x}\mathbf{x}^\top$$

é semidefinida positiva.

Se $\mathbf{x} \neq \mathbf{0}$, então

$$\text{rank}(\mathbf{x}\mathbf{x}^\top) = 1.$$

Assim, quando $p > 1$, existem vetores não nulos $\mathbf{z}$ ortogonais a $\mathbf{x}$. Para esses vetores,

$$\mathbf{x}^\top \mathbf{z} = 0$$

e, portanto,

$$\mathbf{z}^\top (\mathbf{x}\mathbf{x}^\top) \mathbf{z} = 0.$$

Logo, para $p > 1$ e $\mathbf{x} \neq \mathbf{0}$, a matriz

$$\mathbf{x}\mathbf{x}^\top$$

é semidefinida positiva, mas não positiva definida.

Esse tipo de matriz terá importância particular na construção das matrizes de covariâncias, que envolvem somas de produtos externos de vetores de desvios.

Exemplo 2.29 (Classificação de formas quadráticas). Considere inicialmente

$$\mathbf{A} = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

tem-se

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x} = 2x_1^2 + 3x_2^2.$$

Como

$$2x_1^2 + 3x_2^2 > 0$$

para todo

$$\mathbf{x} \neq \mathbf{0},$$

a matriz $\mathbf{A}$ é positiva definida.

Considere agora

$$\mathbf{B} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}.$$

Nesse caso,

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{B} \mathbf{x} = x_1^2 \geq 0.$$

Portanto, $\mathbf{B}$ é semidefinida positiva.

Entretanto, para vetores não nulos da forma

$$\mathbf{x} = \begin{bmatrix} 0 \\ x_2 \end{bmatrix}, \quad x_2 \neq 0,$$

tem-se

$$Q(\mathbf{x}) = 0.$$

Assim, $\mathbf{B}$ não é positiva definida.

Finalmente, considere

$$\mathbf{C} = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}.$$

A forma quadrática associada é

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{C} \mathbf{x} = x_1^2 - x_2^2.$$

Para

$$\mathbf{x} = \begin{bmatrix} 1 \\ 0 \end{bmatrix},$$

obtém-se

$$Q(\mathbf{x}) = 1 > 0.$$

Por outro lado, para

$$\mathbf{y} = \begin{bmatrix} 0 \\ 1 \end{bmatrix},$$

obtém-se

$$Q(\mathbf{y}) = -1 < 0.$$

Portanto, a forma quadrática assume valores positivos e negativos, e a matriz $\mathbf{C}$ é indefinida.

2.5.4 Superfícies de nível

Uma superfície de nível de uma forma quadrática é definida por

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = c,$$

em que c é uma constante.

Quando $\mathbf{A}$ é positiva definida e $c > 0$, as superfícies de nível são elipsoides. Em duas dimensões, correspondem a elipses. Para $c = 0$, a superfície contém somente o vetor nulo, enquanto, para $c < 0$, não existem pontos que satisfaçam a equação.

Quando $\mathbf{A}$ é indefinida, a forma quadrática assume valores positivos e negativos. Em duas dimensões, no caso indefinido não singular, os níveis não nulos formam hipérbolas. O nível zero pode formar um par de retas que se cruzam na origem. Por exemplo,

$$x_1^2 - x_2^2 = 0$$

equivale a

$$x_2 = x_1 \quad \text{ou} \quad x_2 = -x_1.$$

A Figura 2.2 apresenta três formas quadráticas em $\mathbb{R}^2$.

A primeira forma produz circunferências. A segunda produz elipses com eixos de comprimentos diferentes. A terceira produz hipérbolas.

Formas quadráticas aparecem em expressões de distância, variância e densidade. Os critérios baseados em autovalores serão apresentados no capítulo sobre decomposição espectral.




Figura 2.2: Curvas de nível de formas quadráticas em duas dimensões. Na forma indefinida, níveis positivos, negativos e nulos são diferenciados também pelo tipo de linha.

2.6 Aprofundamento: matrizes particionadas e complemento de Schur

Leitura de aprofundamento

Esta seção pode ser utilizada como referência nos capítulos posteriores. As operações por blocos e o complemento de Schur serão retomados no estudo de covariâncias particionadas, distribuições condicionais, regressão entre blocos e correlação canônica.

Uma matriz pode ser dividida em submatrizes denominadas blocos. O particionamento organiza os elementos sem alterar a matriz e permite realizar operações matriciais utilizando os blocos.

2.6.1 Matrizes particionadas

Definição 2.25 (Matriz particionada). Considere

$$\mathbf{A} \in \mathbb{R}^{(m_1+m_2) \times (n_1+n_2)}.$$

Um particionamento de $\mathbf{A}$ em quatro blocos pode ser escrito como

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

em que

$$\mathbf{A}_{11} \in \mathbb{R}^{m_1 \times n_1}, \quad \mathbf{A}_{12} \in \mathbb{R}^{m_1 \times n_2},$$

$$\mathbf{A}_{21} \in \mathbb{R}^{m_2 \times n_1}, \quad \mathbf{A}_{22} \in \mathbb{R}^{m_2 \times n_2}.$$

Os blocos de uma mesma linha do particionamento possuem o mesmo número de linhas. Os blocos de uma mesma coluna possuem o mesmo número de colunas.

Exemplo 2.30 (Particionamento de uma matriz). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}.$$

Separando as duas primeiras linhas e colunas das restantes,

$$\mathbf{A} = \left[\begin{array}{cc|c} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{array} \right] = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

com

$$\mathbf{A}_{11} = \begin{bmatrix} 1 & 2 \\ 4 & 5 \end{bmatrix}, \quad \mathbf{A}_{12} = \begin{bmatrix} 3 \\ 6 \end{bmatrix},$$

$$\mathbf{A}_{21} = \begin{bmatrix} 7 & 8 \end{bmatrix}, \quad \mathbf{A}_{22} = \begin{bmatrix} 9 \end{bmatrix}.$$

O particionamento pode ser definido de acordo com a organização do problema. Em uma matriz de dados, por exemplo, as colunas podem ser separadas em dois grupos de variáveis:

$$\mathbf{X} = [\mathbf{X}_1 \ \mathbf{X}_2],$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{n \times p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{n \times p_2}$$

e

$$p_1 + p_2 = p.$$

2.6.2 Soma e multiplicação por escalar

Considere matrizes com o mesmo particionamento:

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{bmatrix}.$$

A soma pode ser realizada por blocos:

$$\mathbf{A} + \mathbf{B} = \begin{bmatrix} \mathbf{A}_{11} + \mathbf{B}_{11} & \mathbf{A}_{12} + \mathbf{B}_{12} \\ \mathbf{A}_{21} + \mathbf{B}_{21} & \mathbf{A}_{22} + \mathbf{B}_{22} \end{bmatrix}.$$

Para $\alpha \in \mathbb{R}$,

$$\alpha \mathbf{A} = \begin{bmatrix} \alpha \mathbf{A}_{11} & \alpha \mathbf{A}_{12} \\ \alpha \mathbf{A}_{21} & \alpha \mathbf{A}_{22} \end{bmatrix}.$$

As operações exigem que os blocos correspondentes possuam as mesmas dimensões.

2.6.3 Transposição por blocos

A transposta de uma matriz particionada é

$$\mathbf{A}^\top = \begin{bmatrix} \mathbf{A}_{11}^\top & \mathbf{A}_{21}^\top \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22}^\top \end{bmatrix}.$$

Os blocos situados fora da diagonal trocam de posição e são transpostos.

Se $\mathbf{A}$ é simétrica, então

$$\mathbf{A}_{11}^\top = \mathbf{A}_{11}, \quad \mathbf{A}_{22}^\top = \mathbf{A}_{22}$$

e

$$\mathbf{A}_{21} = \mathbf{A}_{12}^{\top}.$$

Nesse caso, a matriz pode ser escrita como

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^{\top} & \mathbf{A}_{22} \end{bmatrix}.$$

2.6.4 Multiplicação por blocos

Considere

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix} \in \mathbb{R}^{(m_1+m_2) \times (n_1+n_2)}$$

e

$$\mathbf{B} = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{bmatrix} \in \mathbb{R}^{(n_1+n_2) \times (r_1+r_2)},$$

com

$$\mathbf{B}_{11} \in \mathbb{R}^{n_1 \times r_1}, \quad \mathbf{B}_{12} \in \mathbb{R}^{n_1 \times r_2},$$

$$\mathbf{B}_{21} \in \mathbb{R}^{n_2 \times r_1}, \quad \mathbf{B}_{22} \in \mathbb{R}^{n_2 \times r_2}.$$

O produto é

$$\mathbf{AB} = \begin{bmatrix} \mathbf{A}_{11}\mathbf{B}_{11} + \mathbf{A}_{12}\mathbf{B}_{21} & \mathbf{A}_{11}\mathbf{B}_{12} + \mathbf{A}_{12}\mathbf{B}_{22} \\ \mathbf{A}_{21}\mathbf{B}_{11} + \mathbf{A}_{22}\mathbf{B}_{21} & \mathbf{A}_{21}\mathbf{B}_{12} + \mathbf{A}_{22}\mathbf{B}_{22} \end{bmatrix}.$$

A regra é a mesma utilizada no produto matricial, com os elementos substituídos por blocos de dimensões compatíveis.

Exemplo 2.31 (Multiplicação de matrizes particionadas). Considere

$$\mathbf{A} = \left[\begin{array}{cc|c} 1 & 2 & 1 \\ 0 & 1 & 3 \\ \hline 2 & 0 & 4 \end{array} \right] = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}$$

e

$$\mathbf{B} = \left[\begin{array}{cc|c} 1 & 0 & 1 \\ 2 & 1 & 0 \\ \hline -1 & 2 & 3 \end{array} \right] = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{bmatrix}.$$

Os blocos da primeira linha do produto são

$$\mathbf{A}_{11}\mathbf{B}_{11} + \mathbf{A}_{12}\mathbf{B}_{21} = \begin{bmatrix} 4 & 4 \\ -1 & 7 \end{bmatrix}$$

e

$$\mathbf{A}_{11}\mathbf{B}_{12} + \mathbf{A}_{12}\mathbf{B}_{22} = \begin{bmatrix} 4 \\ 9 \end{bmatrix}.$$

Os blocos da segunda linha são

$$\mathbf{A}_{21}\mathbf{B}_{11} + \mathbf{A}_{22}\mathbf{B}_{21} = \begin{bmatrix} -2 & 8 \end{bmatrix}$$

e

$$\mathbf{A}_{21}\mathbf{B}_{12} + \mathbf{A}_{22}\mathbf{B}_{22} = \begin{bmatrix} 14 \end{bmatrix}.$$

Portanto,

$$\mathbf{AB} = \left[\begin{array}{cc|c} 4 & 4 & 4 \\ -1 & 7 & 9 \\ \hline -2 & 8 & 14 \end{array} \right].$$

As operações por blocos permitem manipular grupos de linhas e colunas como unidades matriciais. O complemento de Schur utiliza essa estrutura para representar a parcela de um bloco ajustada pelo outro.

2.6.5 Complemento de Schur

Matrizes particionadas permitem tratar uma matriz de grande dimensão a partir de blocos menores. Em vários problemas, é útil eliminar um desses blocos e estudar a estrutura que permanece no outro. O **complemento de Schur** é a matriz que surge naturalmente nesse processo de eliminação.

Definição 2.26 (Complemento de Schur). Considere a matriz quadrada particionada

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

em que

$$\mathbf{A}_{11} \in \mathbb{R}^{p \times p}, \quad \mathbf{A}_{12} \in \mathbb{R}^{p \times q},$$

$$\mathbf{A}_{21} \in \mathbb{R}^{q \times p}, \quad \mathbf{A}_{22} \in \mathbb{R}^{q \times q}.$$

Os blocos diagonais $\mathbf{A}_{11}$ e $\mathbf{A}_{22}$ são quadrados. Quando um deles é invertível, podemos utilizá-lo para eliminar os efeitos dos blocos fora da diagonal.

Se $\mathbf{A}_{22}$ é invertível, o **complemento de Schur de $\mathbf{A}_{22}$** em $\mathbf{A}$ é

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21}.$$

Se $\mathbf{A}_{11}$ é invertível, o **complemento de Schur de $\mathbf{A}_{11}$** em $\mathbf{A}$ é

$$\mathbf{A}_{22.1} = \mathbf{A}_{22} - \mathbf{A}_{21}\mathbf{A}_{11}^{-1}\mathbf{A}_{12}.$$

O complemento $\mathbf{A}_{11.2}$ possui dimensão $p \times p$, enquanto $\mathbf{A}_{22.1}$ possui dimensão $q \times q$.

A expressão pode ser compreendida como uma correção do bloco diagonal original. Por exemplo,

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21}$$

parte de $\mathbf{A}_{11}$ e retira a parcela associada às relações que passam pelo segundo bloco. Essa interpretação ficará mais clara ao observarmos a eliminação por blocos.

2.6.6 Eliminação por blocos

Suponha que $\mathbf{A}_{22}$ seja invertível. Queremos eliminar o bloco $\mathbf{A}_{12}$, isto é, produzir uma matriz equivalente cuja posição superior direita seja ocupada por uma matriz nula.

Para isso, considere

$$\mathbf{E} = \begin{bmatrix} \mathbf{I}_p & -\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix}.$$

Multiplicando $\mathbf{E}$ por $\mathbf{A}$,

$$\mathbf{EA} = \begin{bmatrix} \mathbf{I}_p & -\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix} \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Efetuando o produto por blocos,

$$\mathbf{EA} = \begin{bmatrix} \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21} & \mathbf{A}_{12} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{22} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Como $\mathbf{A}_{22}^{-1}\mathbf{A}_{22} = \mathbf{I}_q$,

$$\mathbf{EA} = \begin{bmatrix} \mathbf{A}_{11.2} & \mathbf{0} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Portanto, o complemento de Schur aparece exatamente como o bloco que permanece depois da eliminação de $\mathbf{A}_{12}$ utilizando $\mathbf{A}_{22}$.

Como

$$\mathbf{E}^{-1} = \begin{bmatrix} \mathbf{I}_p & \mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix},$$

também podemos escrever

$$\mathbf{A} = \begin{bmatrix} \mathbf{I}_p & \mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix} \begin{bmatrix} \mathbf{A}_{11.2} & \mathbf{0} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Essa fatoração é consequência direta da eliminação por blocos.

Um caso simples ajuda a reconhecer a estrutura. Para uma matriz 2×2 ,

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix},$$

com $d \neq 0$, o complemento de Schur de d é

$$a - bd^{-1}c.$$

Como veremos a seguir,

$$\det(\mathbf{A}) = d(a - bd^{-1}c) = ad - bc,$$

recuperando a expressão usual do determinante de uma matriz 2×2 .

Exemplo 2.32 (Cálculo de um complemento de Schur). Considere a matriz particionada

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

em que

$$\mathbf{A}_{11} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}, \quad \mathbf{A}_{12} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix},$$

$$\mathbf{A}_{21} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{A}_{22} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

Como $\mathbf{A}_{22} = \mathbf{I}_2$, tem-se $\mathbf{A}_{22}^{-1} = \mathbf{I}_2$. Logo,

$$\begin{aligned} \mathbf{A}_{11.2} &= \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21} \\ &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} - \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}. \end{aligned}$$

2.6.7 Determinante de uma matriz particionada

A eliminação por blocos mostra uma das principais utilidades do complemento de Schur: calcular o determinante de uma matriz particionada utilizando determinantes de matrizes menores.

Teorema 2.8 (Determinante e complemento de Schur). *Para*

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

se $\mathbf{A}_{22}$ é invertível, então

$$\det(\mathbf{A}) = \det(\mathbf{A}_{22}) \det(\mathbf{A}_{11.2}).$$

Se $\mathbf{A}_{11}$ é invertível, então

$$\det(\mathbf{A}) = \det(\mathbf{A}_{11}) \det(\mathbf{A}_{22.1}).$$

(Boyd; Vandenberghe, 2004)

Comprovação. Suponha que $\mathbf{A}_{22}$ seja invertível. Pela eliminação por blocos apresentada anteriormente,

$$\mathbf{EA} = \begin{bmatrix} \mathbf{A}_{11.2} & \mathbf{0} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

com

$$\mathbf{E} = \begin{bmatrix} \mathbf{I}_p & -\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix}.$$

Como $\mathbf{E}$ é triangular por blocos e possui matrizes identidade na diagonal,

$$\det(\mathbf{E}) = 1.$$

Portanto,

$$\det(\mathbf{EA}) = \det(\mathbf{A}).$$

A matriz $\mathbf{EA}$ também é triangular por blocos. Assim,

$$\det(\mathbf{EA}) = \det(\mathbf{A}_{11.2}) \det(\mathbf{A}_{22}).$$

Logo,

$$\det(\mathbf{A}) = \det(\mathbf{A}_{22}) \det(\mathbf{A}_{11.2}).$$

A segunda identidade é obtida de forma análoga, eliminando o bloco $\mathbf{A}_{21}$ a partir de $\mathbf{A}_{11}$. $\square$

No Exemplo 2.32,

$$\det(\mathbf{A}_{22}) = 1$$

e

$$\det(\mathbf{A}_{11.2}) = 3.$$

Consequentemente,

$$\det(\mathbf{A}) = 3.$$

2.6.8 Inversão em blocos

O complemento de Schur também permite obter a inversa de uma matriz particionada. A origem da expressão pode ser entendida a partir da mesma fatoração obtida pela eliminação por blocos.

Se $\mathbf{A}_{22}$ é invertível,

$$\mathbf{A} = \begin{bmatrix} \mathbf{I}_p & \mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix} \begin{bmatrix} \mathbf{A}_{11.2} & \mathbf{0} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Se $\mathbf{A}_{11.2}$ também é invertível, os dois fatores são invertíveis. Como a inversa de um produto inverte a ordem dos fatores, a inversa de $\mathbf{A}$ pode ser construída a partir das inversas dessas duas matrizes mais simples.

Proposição 2.11 (Inversa em blocos). *Considere a matriz particionada*

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}$$

e o complemento de Schur de $\mathbf{A}_{22}$ em $\mathbf{A}$,

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21}.$$

Se $\mathbf{A}_{22}$ e $\mathbf{A}_{11.2}$ são invertíveis, então

$$\mathbf{A}^{-1} = \begin{bmatrix} \mathbf{A}_{11.2}^{-1} & -\mathbf{A}_{11.2}^{-1}\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ -\mathbf{A}_{22}^{-1}\mathbf{A}_{21}\mathbf{A}_{11.2}^{-1} & \mathbf{B}_{22} \end{bmatrix},$$

com o bloco $(2,2)$ dado por

$$\mathbf{B}_{22} = \mathbf{A}_{22}^{-1} + \mathbf{A}_{22}^{-1}\mathbf{A}_{21}\mathbf{A}_{11.2}^{-1}\mathbf{A}_{12}\mathbf{A}_{22}^{-1}.$$

(Boyd; Vandenberghe, 2004)

A expressão pode parecer extensa, mas sua estrutura é determinada pela eliminação anterior. O bloco $\mathbf{A}_{11.2}^{-1}$ representa a parte de $\mathbf{A}_{11}$ que permanece depois da eliminação do segundo bloco.

Uma expressão equivalente pode ser obtida utilizando $\mathbf{A}_{22.1}$ quando $\mathbf{A}_{11}$ e $\mathbf{A}_{22.1}$ são invertíveis.

2.6.9 Positividade e complemento de Schur

Outra aplicação importante ocorre em matrizes simétricas. O complemento de Schur permite verificar a definição positiva de uma matriz particionada por meio de matrizes de menor dimensão.

Considere

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^{\top} & \mathbf{A}_{22} \end{bmatrix}.$$

Para estudar se $\mathbf{A}$ é positiva definida, consideramos sua forma quadrática. Para $\mathbf{x} \in \mathbb{R}^p$ e $\mathbf{y} \in \mathbb{R}^q$,

$$\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix}^\top \mathbf{A} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} = \mathbf{x}^\top \mathbf{A}_{11} \mathbf{x} + 2\mathbf{x}^\top \mathbf{A}_{12} \mathbf{y} + \mathbf{y}^\top \mathbf{A}_{22} \mathbf{y}.$$

Quando $\mathbf{A}_{22}$ é invertível, os termos envolvendo $\mathbf{y}$ podem ser reorganizados completando a forma quadrática:

$$\begin{aligned} & \mathbf{x}^\top \mathbf{A}_{11} \mathbf{x} + 2\mathbf{x}^\top \mathbf{A}_{12} \mathbf{y} + \mathbf{y}^\top \mathbf{A}_{22} \mathbf{y} \\ &= \mathbf{x}^\top (\mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top) \mathbf{x} \\ & \quad + (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x})^\top \mathbf{A}_{22} (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x}). \end{aligned}$$

O primeiro termo contém exatamente o complemento de Schur de $\mathbf{A}_{22}$.

Teorema 2.9 (Positividade e complemento de Schur). *Considere a matriz simétrica*

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22} \end{bmatrix}.$$

Se $\mathbf{A}_{22}$ é positiva definida, então $\mathbf{A}$ é positiva definida se, e somente se,

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top$$

é positiva definida. (Boyd; Vandenberghe, 2004)

Comprovação. Pela decomposição da forma quadrática,

$$\begin{aligned} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix}^\top \mathbf{A} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} &= \mathbf{x}^\top \mathbf{A}_{11.2} \mathbf{x} \\ & \quad + (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x})^\top \mathbf{A}_{22} (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x}). \end{aligned}$$

Suponha inicialmente que $\mathbf{A}_{11.2}$ e $\mathbf{A}_{22}$ sejam positivas definidas.

Se $\mathbf{x} \neq \mathbf{0}$, então

$$\mathbf{x}^\top \mathbf{A}_{11.2} \mathbf{x} > 0,$$

enquanto a segunda parcela é não negativa.

Se $\mathbf{x} = \mathbf{0}$, então $\mathbf{y} \neq \mathbf{0}$ e a forma quadrática reduz-se a

$$\mathbf{y}^\top \mathbf{A}_{22} \mathbf{y} > 0.$$

Logo, $\mathbf{A}$ é positiva definida.

Reciprocamente, suponha que $\mathbf{A}$ seja positiva definida. Para qualquer $\mathbf{x} \neq \mathbf{0}$, escolha

$$\mathbf{y} = -\mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x}.$$

Com essa escolha, a segunda parcela da decomposição é igual a zero. Portanto,

$$\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix}^\top \mathbf{A} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} = \mathbf{x}^\top \mathbf{A}_{11 \cdot 2} \mathbf{x} > 0.$$

Assim, $\mathbf{A}_{11 \cdot 2}$ é positiva definida. □

Uma condição equivalente pode ser formulada utilizando $\mathbf{A}_{11}$ e o complemento $\mathbf{A}_{22 \cdot 1}$.

O complemento de Schur aparece sempre que uma matriz particionada é estudada após a eliminação de um dos blocos. Por isso, ele será útil em diferentes partes da Análise Multivariada.

Algebricamente, o termo

$$\mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21}$$

representa a correção associada ao segundo bloco, enquanto

$$\mathbf{A}_{11 \cdot 2} = \mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21}$$

representa o primeiro bloco depois dessa correção.

Essa interpretação é puramente matricial e vale para matrizes particionadas gerais.

Quando $\mathbf{A}$ é uma matriz de covariâncias particionada,

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22} \end{bmatrix},$$

o complemento

$$\mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top$$

adquire uma interpretação estatística adicional. Ele representa a matriz de covariâncias da parcela do primeiro bloco que permanece após o ajuste linear pelo segundo bloco. Sob normalidade conjunta, essa mesma matriz corresponde à covariância condicional do primeiro bloco dado o segundo.

Essa estrutura será retomada no estudo de covariâncias condicionais, regressão entre blocos e distribuição normal multivariada.

2.7 Síntese do capítulo

Uma matriz organiza valores em linhas e colunas e permite representar simultaneamente observações, variáveis, transformações e sistemas lineares. As dimensões determinam quais operações são possíveis e qual será a dimensão do resultado.

A tabela a seguir reúne os principais objetos desenvolvidos no capítulo.

Tabela 2.3: Principais objetos e operações matriciais desenvolvidos no capítulo.

Objeto ou operação	Expressão ou condição	Interpretação e utilização
Produto matriz-vetor	$\mathbf{A}\mathbf{x}$	Produce produtos internos pelas linhas e combinações lineares pelas colunas
Produto matricial	$\mathbf{A}_{n \times p} \mathbf{B}_{p \times r}$	Combina linhas e colunas de matrizes com dimensões compatíveis
Transposta	$(\mathbf{A}\mathbf{B})^\top = \mathbf{B}^\top \mathbf{A}^\top$	Troca linhas por colunas e reorganiza produtos
Matriz simétrica	$\mathbf{A}^\top = \mathbf{A}$	Estrutura presente em formas quadráticas e matrizes de covariâncias
Traço	$\text{tr}(\mathbf{A}) = \sum_i a_{ii}$	Resume a diagonal e reorganiza expressões matriciais
Matriz inversa	$\mathbf{A}^{-1} \mathbf{A} = \mathbf{I}_n$	Reverte a ação de uma matriz invertível
Determinante	$\det(\mathbf{A})$	Registra invertibilidade, alteração de volume e orientação
Posto	$\text{posto}(\mathbf{A})$	Mede a dimensão da informação linearmente independente

Objeto ou operação	Expressão ou condição	Interpretação e utilização
Matriz ortogonal	$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_n$	Preserva produtos internos, normas e distâncias
Forma bilinear	$\mathbf{x}^\top \mathbf{A} \mathbf{y}$	Relaciona dois vetores por meio de uma matriz
Forma quadrática	$\mathbf{x}^\top \mathbf{A} \mathbf{x}$	Representa variâncias, distâncias e superfícies de nível
Complemento de Schur	$\mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21}$	Elimina um bloco e produz um bloco reduzido

Para uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{n \times n},$$

as condições

$\mathbf{A}$ é invertível,

$$\det(\mathbf{A}) \neq 0$$

e

$$\text{posto}(\mathbf{A}) = n$$

são equivalentes.

O posto também permite classificar as soluções do sistema

$$\mathbf{A} \mathbf{x} = \mathbf{b}.$$

Quando a matriz não é invertível ou não é quadrada, a pseudoinversa permite formular soluções exatas de menor norma ou soluções de mínimos quadrados.

Para uma matriz simétrica, os valores da forma quadrática

$$\mathbf{x}^\top \mathbf{A} \mathbf{x}$$

permitem classificá-la como positiva definida, semidefinida positiva, negativa definida, semi-definida negativa ou indefinida.

As seções sobre pseudoinversa, sistemas triangulares, matrizes particionadas e complemento de Schur funcionam como aprofundamentos. Esses resultados serão retomados quando sua utilização estatística se tornar necessária.

Ao final deste capítulo, o estudante deverá ser capaz de:

- verificar a compatibilidade dimensional das operações matriciais;
- calcular e interpretar produtos matriz-vetor e matriz-matriz;
- utilizar transposição, simetria e traço;
- relacionar inversa, determinante e posto;
- classificar as soluções de sistemas lineares;
- reconhecer matrizes ortogonais, diagonais e triangulares;
- calcular e interpretar formas bilineares e quadráticas;
- classificar matrizes simétricas por meio de suas formas quadráticas;
- operar com matrizes particionadas em situações introdutórias.

O próximo capítulo desenvolverá espaços vetoriais, bases, dimensão e projeções, fornecendo uma interpretação geométrica mais ampla para o posto, os sistemas lineares e as transformações matriciais.

3 Espaços vetoriais, bases e projeções

Os capítulos anteriores apresentaram a representação vetorial dos dados e as operações matriciais utilizadas para manipulá-los. Neste capítulo, os vetores são estudados como elementos de conjuntos que preservam as operações de adição e multiplicação por escalar.

Essa estrutura permite identificar subespaços, verificar relações de dependência linear e representar um espaço por meio de uma base. O posto de uma matriz será interpretado a partir das dimensões de seus espaços fundamentais.

A parte final do capítulo desenvolve a projeção ortogonal. Essa operação decompõe um vetor em uma componente pertencente a um subespaço e uma componente ortogonal, fornecendo a interpretação geométrica dos problemas de melhor aproximação e mínimos quadrados.

Convenções para espaços vetoriais e subespaços

As convenções vetoriais e matriciais apresentadas nos capítulos anteriores permanecem válidas. Neste capítulo, serão utilizadas também as seguintes convenções:

- V e W representam espaços vetoriais ou subespaços vetoriais;
- S representa, em geral, um subespaço de $\mathbb{R}^p$;
- $\mathcal{B}$ representa uma base;
- $\mathcal{B}_W$ representa uma base associada ao subespaço W ;
- $\dim(V)$ representa a dimensão do espaço vetorial V ;
- $\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$ representa o subespaço gerado pelos vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$;
- $[\mathbf{x}]_{\mathcal{B}}$ representa o vetor de coordenadas de $\mathbf{x}$ em relação à base $\mathcal{B}$;
- $S^\perp$ representa o complemento ortogonal de S ;
- $\mathcal{C}(\mathbf{A})$ representa o espaço coluna de $\mathbf{A}$;
- $\mathcal{L}(\mathbf{A})$ representa o espaço linha de $\mathbf{A}$;
- $\mathcal{N}(\mathbf{A})$ representa o espaço nulo de $\mathbf{A}$;
- $\mathcal{N}(\mathbf{A}^\top)$ representa o espaço nulo de $\mathbf{A}^\top$;
- $\oplus$ representa soma direta de subespaços;
- $\text{proj}_S(\mathbf{x})$ representa a projeção ortogonal de $\mathbf{x}$ sobre S ;
- $\mathbf{P}_S$ representa uma matriz de projeção ortogonal sobre S ;
- $\mathbf{G}$ representa, quando indicado, uma matriz de Gram.

Quando uma base for escrita como

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\},$$

a ordem dos vetores será considerada fixada sempre que forem utilizadas coordenadas em relação a essa base.

Os vetores continuarão sendo representados por letras minúsculas em negrito, como $\mathbf{x}$, $\mathbf{y}$ e $\mathbf{v}$, enquanto matrizes serão representadas por letras maiúsculas em negrito, como $\mathbf{A}$, $\mathbf{B}$ e $\mathbf{Q}$.

As definições e propriedades específicas de cada espaço, base, decomposição ou operador serão apresentadas nas seções correspondentes.

3.1 Espaços, subespaços e geração

Um espaço vetorial é um conjunto no qual a soma de vetores e a multiplicação por escalares permanecem definidas e satisfazem propriedades algébricas específicas.

Definição 3.1 (Espaço vetorial). Um conjunto não vazio V é um **espaço vetorial real** quando estão definidas:

- a soma $\mathbf{x} + \mathbf{y} \in V$, para $\mathbf{x}, \mathbf{y} \in V$;
- a multiplicação $\alpha \mathbf{x} \in V$, para $\alpha \in \mathbb{R}$ e $\mathbf{x} \in V$;

e são satisfeitas as seguintes propriedades:

1. Para quaisquer $\mathbf{x}, \mathbf{y} \in V$,

$$\mathbf{x} + \mathbf{y} = \mathbf{y} + \mathbf{x}.$$

2. Para quaisquer $\mathbf{x}, \mathbf{y}, \mathbf{z} \in V$,

$$(\mathbf{x} + \mathbf{y}) + \mathbf{z} = \mathbf{x} + (\mathbf{y} + \mathbf{z}).$$

3. Existe um vetor $\mathbf{0} \in V$ tal que, para todo $\mathbf{x} \in V$,

$$\mathbf{x} + \mathbf{0} = \mathbf{x}.$$

4. Para todo $\mathbf{x} \in V$, existe um vetor $-\mathbf{x} \in V$ tal que

$$\mathbf{x} + (-\mathbf{x}) = \mathbf{0}.$$

5. Para quaisquer $\mathbf{x}, \mathbf{y} \in V$ e $\alpha \in \mathbb{R}$,

$$\alpha(\mathbf{x} + \mathbf{y}) = \alpha\mathbf{x} + \alpha\mathbf{y}.$$

6. Para quaisquer $\mathbf{x} \in V$ e $\alpha, \beta \in \mathbb{R}$,

$$(\alpha + \beta)\mathbf{x} = \alpha\mathbf{x} + \beta\mathbf{x}.$$

7. Para quaisquer $\mathbf{x} \in V$ e $\alpha, \beta \in \mathbb{R}$,

$$\alpha(\beta\mathbf{x}) = (\alpha\beta)\mathbf{x}.$$

8. Para todo $\mathbf{x} \in V$,

$$1\mathbf{x} = \mathbf{x}.$$

O espaço $\mathbb{R}^p$, com as operações usuais de adição e multiplicação por escalar, é um espaço vetorial. Seus elementos são vetores com p componentes reais. O vetor nulo é

$$\mathbf{0} = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix},$$

e, para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix},$$

seu inverso aditivo é

$$-\mathbf{x} = \begin{bmatrix} -x_1 \\ \vdots \\ -x_p \end{bmatrix}.$$

Os elementos de um espaço vetorial não precisam ser necessariamente vetores numéricos. Por exemplo, o conjunto de todas as matrizes reais de dimensão $n \times p$,

$$\mathbb{R}^{n \times p},$$

também é um espaço vetorial com as operações usuais de adição de matrizes e multiplicação por escalar. Nesse caso, os elementos do espaço vetorial são matrizes.

3.1.1 Subespaços vetoriais

Um subconjunto de um espaço vetorial pode preservar a estrutura das operações.

Definição 3.2 (Subespaço vetorial). Seja V um espaço vetorial. Um subconjunto não vazio $W \subseteq V$ é um **subespaço vetorial** de V quando, para quaisquer $\mathbf{x}, \mathbf{y} \in W$ e $\alpha \in \mathbb{R}$,

$$\mathbf{x} + \mathbf{y} \in W$$

e

$$\alpha \mathbf{x} \in W.$$

As duas condições garantem que toda combinação linear de vetores de W também pertence a W .

Proposição 3.1 (Critério de subespaço). *Um subconjunto não vazio $W \subseteq V$ é um subespaço vetorial se, e somente se,*

$$\alpha \mathbf{x} + \beta \mathbf{y} \in W$$

para quaisquer $\mathbf{x}, \mathbf{y} \in W$ e $\alpha, \beta \in \mathbb{R}$. (Meyer, 2023)

O vetor nulo pertence a todo subespaço. De fato, para qualquer $\mathbf{x} \in W$,

$$0\mathbf{x} = \mathbf{0} \in W.$$

Exemplo 3.1 (Reta que é um subespaço). Considere

$$W = \left\{ \begin{bmatrix} t \\ t \end{bmatrix} : t \in \mathbb{R} \right\} \subseteq \mathbb{R}^2.$$

Se

$$\mathbf{x} = \begin{bmatrix} t_1 \\ t_1 \end{bmatrix} \quad \text{e} \quad \mathbf{y} = \begin{bmatrix} t_2 \\ t_2 \end{bmatrix}$$

pertencem a W , então

$$\alpha \mathbf{x} + \beta \mathbf{y} = \begin{bmatrix} \alpha t_1 + \beta t_2 \\ \alpha t_1 + \beta t_2 \end{bmatrix} \in W.$$

Portanto, W é um subespaço de $\mathbb{R}^2$.

Uma reta que não passa pela origem não é um subespaço.

Exemplo 3.2 (Reta que não é um subespaço). Considere

$$S = \left\{ \begin{bmatrix} t \\ t+1 \end{bmatrix} : t \in \mathbb{R} \right\}.$$

O vetor nulo não pertence a S . Portanto, S não é um subespaço de $\mathbb{R}^2$.

Geometricamente, S é uma reta paralela a W , mas deslocada e sem passar pela origem.

A Figura 3.1 compara uma reta que é subespaço de $\mathbb{R}^2$ com uma reta paralela que não é subespaço.




Figura 3.1: Comparação entre uma reta que é subespaço de $\mathbb{R}^2$ e uma reta que não é subespaço.

A reta do primeiro painel contém a origem e é fechada em relação às combinações lineares. A reta do segundo painel não contém a origem e, por isso, não é um subespaço de $\mathbb{R}^2$.

3.1.2 Subespaço gerado

As combinações lineares de um conjunto de vetores formam um subespaço.

Definição 3.3 (Subespaço gerado). Sejam

$$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k \in V.$$

O **subespaço gerado** por esses vetores é o conjunto de todas as suas combinações lineares,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\} = \{\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k : \alpha_1, \dots, \alpha_k \in \mathbb{R}\}.$$

A notação

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\}$$

indica o subespaço gerado pelos vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$.

Esse conjunto também é denominado **envoltória linear** dos vetores.

O subespaço gerado é o menor subespaço que contém todos os vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$.

Exemplo 3.3 (Subespaço gerado por um vetor). Considere

$$\mathbf{v} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

O conjunto

$$\text{span}\{\mathbf{v}\} = \left\{ \alpha \begin{bmatrix} 1 \\ 2 \end{bmatrix} : \alpha \in \mathbb{R} \right\}$$

é uma reta que passa pela origem.

Exemplo 3.4 (Subespaço gerado por dois vetores). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Uma combinação linear desses vetores é

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 = \begin{bmatrix} \alpha_1 + \alpha_2 \\ \alpha_2 \end{bmatrix}.$$

Para qualquer vetor

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \in \mathbb{R}^2,$$

basta escolher

$$\alpha_2 = x_2$$

e

$$\alpha_1 = x_1 - x_2.$$

Portanto,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2\} = \mathbb{R}^2.$$

Exemplo 3.5 (Espaço e subespaço gerado). Considere o espaço vetorial

$$V = \mathbb{R}^3.$$

Primeiro, considere os vetores

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

Uma combinação linear desses vetores é

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \alpha_3 \mathbf{v}_3 = \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{bmatrix}.$$

Como qualquer vetor de $\mathbb{R}^3$ pode ser obtido escolhendo adequadamente α_1 , α_2 e α_3 ,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3\} = \mathbb{R}^3.$$

Nesse caso, o subespaço gerado coincide com o próprio espaço V .

Considere agora apenas os vetores

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}.$$

As combinações lineares desses vetores são da forma

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 = \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ 0 \end{bmatrix}.$$

Portanto,

$$W = \text{span}\{\mathbf{v}_1, \mathbf{v}_2\} = \left\{ \begin{bmatrix} x_1 \\ x_2 \\ 0 \end{bmatrix} : x_1, x_2 \in \mathbb{R} \right\}.$$

O conjunto W é o plano $x_3 = 0$ contido em $\mathbb{R}^3$. Assim,

$$W \subsetneq V,$$

Os dois casos mostram que um subespaço gerado pode coincidir com todo o espaço ou possuir dimensão menor. Em um espaço vetorial de dimensão finita, um subespaço não pode ter dimensão maior que a do espaço que o contém.

Um mesmo subespaço pode ser gerado por diferentes conjuntos de vetores. Alguns conjuntos podem conter vetores redundantes. A independência linear permite identificar quando um vetor acrescenta uma nova direção ao subespaço gerado.

3.2 Independência linear, bases e dimensão

Um conjunto de vetores pode gerar um subespaço mesmo quando contém vetores redundantes. A independência linear permite verificar se cada vetor acrescenta uma nova direção ao conjunto gerado.

3.2.1 Independência linear

Definição 3.4 (Independência linear). Os vetores

$$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k \in V$$

são **linearmente independentes** quando a igualdade

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_k \mathbf{v}_k = \mathbf{0}$$

implica

$$\alpha_1 = \alpha_2 = \dots = \alpha_k = 0.$$

Quando existe uma solução em que pelo menos um coeficiente é diferente de zero, os vetores são **linearmente dependentes**.

A solução

$$\alpha_1 = \alpha_2 = \dots = \alpha_k = 0$$

é denominada **solução trivial**. Um conjunto é linearmente independente quando a solução trivial é a única combinação linear que produz o vetor nulo.

Exemplo 3.6 (Vetores linearmente dependentes). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 2 \\ 4 \end{bmatrix}.$$

Como

$$\mathbf{v}_2 = 2\mathbf{v}_1,$$

tem-se

$$2\mathbf{v}_1 - \mathbf{v}_2 = \mathbf{0}.$$

Os coeficientes 2 e -1 não são ambos nulos. Portanto, $\mathbf{v}_1$ e $\mathbf{v}_2$ são linearmente dependentes. Além disso,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2\} = \text{span}\{\mathbf{v}_1\}.$$

O vetor $\mathbf{v}_2$ não acrescenta uma nova direção ao subespaço gerado.

Exemplo 3.7 (Vetores linearmente independentes). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Suponha que

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 = \mathbf{0}.$$

Então,

$$\alpha_1 \begin{bmatrix} 1 \\ 0 \end{bmatrix} + \alpha_2 \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} \alpha_1 + \alpha_2 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

A segunda equação fornece

$$\alpha_2 = 0,$$

e a primeira fornece

$$\alpha_1 = 0.$$

Portanto, os vetores são linearmente independentes.

A Figura 3.2 compara dois vetores dependentes com dois vetores independentes em $\mathbb{R}^2$.

No primeiro painel, os vetores pertencem à mesma reta e geram um subespaço unidimensional. No segundo, os vetores determinam duas direções distintas e geram $\mathbb{R}^2$.




Figura 3.2: Comparação entre vetores linearmente dependentes e independentes em $\mathbb{R}^2$.

3.2.2 Independência linear e posto

Considere a matriz cujas colunas são os vetores analisados:

$$\mathbf{A} = [\mathbf{v}_1 \quad \mathbf{v}_2 \quad \cdots \quad \mathbf{v}_k], \quad \mathbf{A} \in \mathbb{R}^{p \times k}.$$

As colunas de $\mathbf{A}$ são linearmente independentes se, e somente se,

$$\text{posto}(\mathbf{A}) = k.$$

Assim, o número de vetores linearmente independentes entre as colunas de $\mathbf{A}$ é determinado pelo posto da matriz.

Como

$$\text{posto}(\mathbf{A}) \leq \min(p, k),$$

não pode haver mais de p vetores linearmente independentes em $\mathbb{R}^p$.

Proposição 3.2 (Propriedades da independência linear). *Sejam $\mathbf{v}_1, \dots, \mathbf{v}_k \in V$.*

1. *Um conjunto que contém o vetor nulo é linearmente dependente.*

2. Um conjunto formado por um único vetor é linearmente independente se, e somente se, esse vetor é diferente de zero.
3. Todo subconjunto de um conjunto linearmente independente também é linearmente independente.
4. Todo conjunto que contém um subconjunto linearmente dependente é linearmente dependente.
5. Se um vetor do conjunto pode ser escrito como combinação linear dos demais, o conjunto é linearmente dependente.

A última propriedade fornece uma interpretação direta da redundância.

Proposição 3.3 (Dependência linear e redundância). *O conjunto*

$$\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$$

é linearmente dependente se, e somente se, pelo menos um de seus vetores pode ser escrito como combinação linear dos demais.

Comprovação. Suponha que o conjunto seja linearmente dependente. Então existem coeficientes, não todos nulos, tais que

$$\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k = \mathbf{0}.$$

Escolha um índice j para o qual $\alpha_j \neq 0$. Isolando $\mathbf{v}_j$,

$$\mathbf{v}_j = - \sum_{i \neq j} \frac{\alpha_i}{\alpha_j} \mathbf{v}_i.$$

Portanto, $\mathbf{v}_j$ é combinação linear dos demais.

Reciprocamente, se um vetor é combinação linear dos demais, essa igualdade pode ser reorganizada como uma combinação linear não trivial que produz o vetor nulo. Logo, o conjunto é linearmente dependente. $\square$

A independência linear permite retirar vetores redundantes sem alterar o subespaço gerado. Um conjunto gerador sem redundâncias fornece uma base do subespaço.

3.2.3 Bases

Um conjunto gerador pode conter vetores redundantes. Quando os vetores geram o espaço e são linearmente independentes, obtém-se uma base.

Definição 3.5 (Base). Seja V um espaço vetorial. Um conjunto

$$\mathcal{B} = \{\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_k\}$$

é uma **base** de V quando:

1. os vetores $\mathbf{b}_1, \dots, \mathbf{b}_k$ são linearmente independentes;
2. os vetores geram V , isto é,

$$\text{span}\{\mathbf{b}_1, \dots, \mathbf{b}_k\} = V.$$

Uma base fornece um conjunto de vetores suficiente para gerar o espaço sem incluir redundâncias.

Exemplo 3.8 (Uma base de $\mathbb{R}^2$). Considere

$$\mathbf{b}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{b}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Os vetores são linearmente independentes e geram $\mathbb{R}^2$. Portanto,

$$\mathcal{B} = \{\mathbf{b}_1, \mathbf{b}_2\}$$

é uma base de $\mathbb{R}^2$.

Um mesmo espaço possui diferentes bases.

Exemplo 3.9 (Bases diferentes do mesmo espaço). Os conjuntos

$$\mathcal{B}_1 = \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix} \right\}$$

e

$$\mathcal{B}_2 = \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}$$

são bases de $\mathbb{R}^2$.

Os vetores de cada conjunto são linearmente independentes e geram todo o espaço.

3.2.4 Coordenadas em uma base

Uma base permite representar cada vetor por meio dos coeficientes de sua combinação linear.

Teorema 3.1 (Representação única em uma base). *Se*

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é uma base de V , então todo vetor $\mathbf{x} \in V$ pode ser escrito de maneira única como

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k.$$

Comprovação. Como $\mathcal{B}$ gera V , existem escalares $c_1, \dots, c_k$ tais que

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k.$$

Suponha que também exista outra representação:

$$\mathbf{x} = d_1 \mathbf{b}_1 + \dots + d_k \mathbf{b}_k.$$

Subtraindo as duas expressões,

$$(c_1 - d_1) \mathbf{b}_1 + \dots + (c_k - d_k) \mathbf{b}_k = \mathbf{0}.$$

Como os vetores da base são linearmente independentes,

$$c_i - d_i = 0, \quad i = 1, \dots, k.$$

Portanto,

$$c_i = d_i, \quad i = 1, \dots, k,$$

e a representação é única. □

Definição 3.6 (Coordenadas em uma base). Se

$$\mathbf{x} = c_1 \mathbf{b}_1 + \cdots + c_k \mathbf{b}_k,$$

o vetor

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} c_1 \\ \vdots \\ c_k \end{bmatrix}$$

é o **vetor de coordenadas de $\mathbf{x}$** na base $\mathcal{B}$.

Considere a matriz formada pelos vetores da base:

$$\mathbf{B} = [\mathbf{b}_1 \quad \cdots \quad \mathbf{b}_k].$$

A representação de $\mathbf{x}$ pode ser escrita como

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Exemplo 3.10 (Coordenadas de um vetor). Considere a base

$$\mathcal{B} = \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}$$

e o vetor

$$\mathbf{x} = \begin{bmatrix} 4 \\ 2 \end{bmatrix}.$$

Deseja-se determinar c_1 e c_2 tais que

$$\begin{bmatrix} 4 \\ 2 \end{bmatrix} = c_1 \begin{bmatrix} 1 \\ 1 \end{bmatrix} + c_2 \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Isso produz o sistema

$$\begin{aligned} c_1 + c_2 &= 4, \\ c_1 - c_2 &= 2. \end{aligned}$$

Somando as equações,

$$2c_1 = 6,$$

de modo que

$$c_1 = 3.$$

Consequentemente,

$$c_2 = 1.$$

Logo,

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

As coordenadas dependem da base escolhida. O vetor permanece o mesmo, mas os coeficientes que o representam podem mudar.

As coordenadas de um vetor em uma base são os coeficientes que indicam quanto de cada vetor da base é necessário para reconstruir esse vetor por combinação linear. Assim, o vetor de coordenadas não é o próprio vetor, mas a representação desse vetor em relação à base escolhida.

3.2.5 Base canônica

Definição 3.7 (Base canônica). A **base canônica** de $\mathbb{R}^p$ é

$$\mathcal{E} = \{\mathbf{e}_1, \dots, \mathbf{e}_p\},$$

em que $\mathbf{e}_j$ possui valor 1 na posição j e valor 0 nas demais posições.

Em $\mathbb{R}^3$,

$$\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{e}_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix},$$

tem-se

$$\mathbf{x} = x_1 \mathbf{e}_1 + x_2 \mathbf{e}_2 + x_3 \mathbf{e}_3.$$

Assim, as coordenadas de $\mathbf{x}$ na base canônica coincidem com suas componentes usuais.

3.2.6 Bases ortogonais e ortonormais

A partir deste ponto, considere um subespaço $S \subseteq \mathbb{R}^p$ com o produto interno euclidiano.

Definição 3.8 (Base ortogonal). Uma base

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

de S é **ortogonal** quando

$$\mathbf{b}_i^\top \mathbf{b}_j = 0 \quad \text{para} \quad i \neq j.$$

Definição 3.9 (Base ortonormal). Uma base $\mathcal{B}$ de S é **ortonormal** quando seus vetores são ortogonais e possuem norma igual a 1:

$$\mathbf{b}_i^\top \mathbf{b}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Utilizando o delta de Kronecker, a condição de ortonormalidade pode ser escrita como

$$\mathbf{b}_i^\top \mathbf{b}_j = \delta_{ij}.$$

Se

$$\mathbf{Q} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_k]$$

possui como colunas os vetores de uma base ortonormal, então

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k.$$

Quando $\mathbf{Q}$ é quadrada,

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

Essa propriedade foi apresentada no capítulo anterior para matrizes ortogonais.

Teorema 3.2 (Existência de bases ortonormais). *Todo subespaço de dimensão finita de $\mathbb{R}^p$ possui uma base ortonormal.*

A partir de qualquer base do subespaço, uma base ortonormal pode ser construída pelo processo de ortogonalização de Gram–Schmidt. (Meyer, 2023)

Esse resultado garante que a geometria de um subespaço de dimensão finita pode ser descrita por direções mutuamente ortogonais e de norma unitária.

Em uma base ortogonal, os coeficientes da representação de um vetor podem ser determinados separadamente.

Proposição 3.4 (Coordenadas em uma base ortogonal). *Se*

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é uma base ortogonal de um subespaço $S \subseteq \mathbb{R}^p$, então todo vetor $\mathbf{x} \in S$ pode ser escrito de maneira única como

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k.$$

Cada coordenada de $\mathbf{x}$ na base $\mathcal{B}$ pode ser obtida separadamente por

$$c_j = \frac{\mathbf{b}_j^\top \mathbf{x}}{\mathbf{b}_j^\top \mathbf{b}_j}, \quad j = 1, \dots, k.$$

Portanto,

$$\mathbf{x} = \sum_{j=1}^k \frac{\mathbf{b}_j^\top \mathbf{x}}{\mathbf{b}_j^\top \mathbf{b}_j} \mathbf{b}_j.$$

Se a base é ortonormal, então $\mathbf{b}_j^\top \mathbf{b}_j = 1$ para todo j , de modo que

$$c_j = \mathbf{b}_j^\top \mathbf{x},$$

e

$$\mathbf{x} = \sum_{j=1}^k (\mathbf{b}_j^\top \mathbf{x}) \mathbf{b}_j.$$

Assim, em uma base ortogonal, cada coordenada pode ser determinada por meio de um produto interno, sem a necessidade de resolver simultaneamente um sistema linear. (Meyer, 2023)

Comprovação. Como $\mathcal{B}$ é uma base de S , todo vetor $\mathbf{x} \in S$ pode ser escrito de maneira única como

$$\mathbf{x} = c_1 \mathbf{b}_1 + \cdots + c_k \mathbf{b}_k.$$

Multiplicando ambos os lados à esquerda por $\mathbf{b}_j^\top$,

$$\mathbf{b}_j^\top \mathbf{x} = \sum_{i=1}^k c_i \mathbf{b}_j^\top \mathbf{b}_i.$$

Como a base é ortogonal,

$$\mathbf{b}_j^\top \mathbf{b}_i = 0 \quad \text{para} \quad i \neq j.$$

Assim, todos os termos da soma com $i \neq j$ são nulos, restando

$$\mathbf{b}_j^\top \mathbf{x} = c_j \mathbf{b}_j^\top \mathbf{b}_j.$$

Como $\mathbf{b}_j \neq \mathbf{0}$,

$$\mathbf{b}_j^\top \mathbf{b}_j = \|\mathbf{b}_j\|^2 > 0,$$

e, portanto,

$$c_j = \frac{\mathbf{b}_j^\top \mathbf{x}}{\mathbf{b}_j^\top \mathbf{b}_j}.$$

Se a base é ortonormal, então $\|\mathbf{b}_j\| = 1$ e, consequentemente,

$$\mathbf{b}_j^\top \mathbf{b}_j = 1.$$

Logo,

$$c_j = \mathbf{b}_j^\top \mathbf{x},$$

o que fornece diretamente as coordenadas de $\mathbf{x}$ na base ortonormal. $\square$

A Figura 3.3 compara três bases de $\mathbb{R}^2$ e destaca a diferença entre independência linear e ortogonalidade.




Figura 3.3: Comparação entre uma base canônica, uma base oblíqua e uma base ortonormal rotacionada de $\mathbb{R}^2$. O símbolo de ângulo reto identifica os pares de vetores ortogonais.

Na primeira e na terceira bases, os vetores são ortogonais e possuem norma igual a 1, como indicado pelos marcadores de ângulo reto. Portanto, ambas são bases ortonormais. Na base oblíqua, os vetores continuam sendo linearmente independentes e, por isso, formam uma base de $\mathbb{R}^2$, mas não são ortogonais.

3.2.7 Dimensão

Um espaço vetorial é denominado **finito-dimensional** quando possui uma base formada por um número finito de vetores.

Para que a dimensão possa ser definida pelo número de vetores de uma base, é necessário estabelecer primeiro que esse número não depende da base escolhida.

Teorema 3.3 (Número de vetores de uma base). *Se um espaço vetorial V possui uma base finita, então todas as bases de V são finitas e possuem a mesma quantidade de vetores. (Meyer, 2023)*

Definição 3.10 (Dimensão). Se as bases de um espaço vetorial finito-dimensional V possuem k vetores, a **dimensão** de V é definida por

$$\dim(V) = k.$$

Como a base canônica de $\mathbb{R}^p$ possui p vetores,

$$\dim(\mathbb{R}^p) = p.$$

Exemplo 3.11 (Dimensão de subespaços). A reta

$$W_1 = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \right\} \subseteq \mathbb{R}^3$$

possui dimensão 1.

O plano

$$W_2 = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \right\} \subseteq \mathbb{R}^3$$

possui dimensão 2.

O espaço $\mathbb{R}^3$ possui dimensão 3.

Proposição 3.5 (Independência, geração e dimensão). *Se $\dim(V) = k$, então:*

1. *qualquer conjunto com mais de k vetores é linearmente dependente;*
2. *qualquer conjunto com menos de k vetores não gera V ;*
3. *qualquer conjunto de k vetores linearmente independentes é uma base de V ;*
4. *qualquer conjunto de k vetores que gera V é uma base de V .*

Esses resultados relacionam bases, independência e geração. Para uma matriz, essa relação será expressa pelas dimensões de seus espaços coluna, linha e nulo.

3.3 Espaços fundamentais de uma matriz

Uma matriz está associada a subespaços determinados por suas linhas, por suas colunas e pelas soluções de sistemas lineares homogêneos. Esses subespaços permitem relacionar o posto, a dependência linear e as soluções de sistemas lineares.

Considere

$$\mathbf{A} \in \mathbb{R}^{n \times p}.$$

Serão estudados quatro subespaços associados a $\mathbf{A}$:

- o espaço coluna;
- o espaço linha;
- o espaço nulo;
- o espaço nulo à esquerda.

Os dois primeiros são construídos a partir das colunas e das linhas da matriz. Os dois últimos são determinados pelas soluções dos sistemas homogêneos associados, respectivamente, a $\mathbf{A}$ e a $\mathbf{A}^\top$.

3.3.1 Espaço nulo

Definição 3.11 (Espaço nulo). O **espaço nulo** de uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

é o conjunto

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{Ax} = \mathbf{0}\}.$$

Quando $\mathbf{A}$ é interpretada como a matriz associada a uma transformação linear, esse espaço corresponde ao **núcleo** da transformação. Essa interpretação será formalizada no capítulo seguinte.

O espaço nulo reúne todos os vetores $\mathbf{x} \in \mathbb{R}^p$ que são anulados pela multiplicação por $\mathbf{A}$, isto é, aqueles para os quais $\mathbf{Ax} = \mathbf{0}$.

Proposição 3.6 (O espaço nulo é um subespaço). *Para qualquer matriz*

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

o conjunto

$$\mathcal{N}(\mathbf{A})$$

é um subespaço de $\mathbb{R}^p$.

Comprovação. O vetor nulo pertence a $\mathcal{N}(\mathbf{A})$, pois

$$\mathbf{A}\mathbf{0} = \mathbf{0}.$$

Se

$$\mathbf{x}, \mathbf{y} \in \mathcal{N}(\mathbf{A}),$$

então

$$\mathbf{A}\mathbf{x} = \mathbf{0} \quad \text{e} \quad \mathbf{A}\mathbf{y} = \mathbf{0}.$$

Para quaisquer $\alpha, \beta \in \mathbb{R}$,

$$\begin{aligned}\mathbf{A}(\alpha\mathbf{x} + \beta\mathbf{y}) &= \alpha\mathbf{A}\mathbf{x} + \beta\mathbf{A}\mathbf{y} \\ &= \alpha\mathbf{0} + \beta\mathbf{0} \\ &= \mathbf{0}.\end{aligned}$$

Logo,

$$\alpha\mathbf{x} + \beta\mathbf{y} \in \mathcal{N}(\mathbf{A}),$$

e $\mathcal{N}(\mathbf{A})$ é um subespaço. □

A dimensão do espaço nulo é denominada **nulidade** da matriz:

$$\text{nul}(\mathbf{A}) = \dim \mathcal{N}(\mathbf{A}).$$

Exemplo 3.12 (Determinação do espaço nulo). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

Para determinar $\mathcal{N}(\mathbf{A})$, resolve-se

$$\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Assim,

$$\begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

As duas equações são equivalentes, e o sistema reduz-se a

$$x_1 + 2x_2 - x_3 = 0.$$

Tomando

$$x_2 = s \quad \text{e} \quad x_3 = t,$$

obtém-se

$$x_1 = -2s + t.$$

Portanto,

$$\mathbf{x} = \begin{bmatrix} -2s + t \\ s \\ t \end{bmatrix} = s \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix} + t \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}.$$

Logo,

$$\mathcal{N}(\mathbf{A}) = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} \right\}.$$

Os dois vetores são linearmente independentes. Assim,

$$\text{nul}(\mathbf{A}) = 2.$$

Se

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

as colunas de $\mathbf{A}$ são linearmente independentes. Nesse caso, o sistema homogêneo possui apenas a solução trivial.

3.3.2 Espaço coluna

Definição 3.12 (Espaço coluna). O **espaço coluna** de uma matriz

$$\mathbf{A} = [\mathbf{a}_{.1} \quad \mathbf{a}_{.2} \quad \cdots \quad \mathbf{a}_{.p}] \in \mathbb{R}^{n \times p}$$

é o subespaço

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{a}_{.1}, \dots, \mathbf{a}_{.p} \} \subseteq \mathbb{R}^n.$$

O produto matriz-vetor pode ser escrito como

$$\mathbf{Ax} = x_1 \mathbf{a}_{.1} + \cdots + x_p \mathbf{a}_{.p}, \quad \mathbf{x} \in \mathbb{R}^p.$$

Portanto, todo vetor produzido por $\mathbf{A}$ é uma combinação linear de suas colunas.

Como

$$\mathbf{Ax} = x_1 \mathbf{a}_{.1} + \cdots + x_p \mathbf{a}_{.p},$$

o conjunto de todos os vetores que podem ser escritos na forma $\mathbf{Ax}$ coincide com o espaço gerado pelas colunas de $\mathbf{A}$:

$$\mathcal{C}(\mathbf{A}) = \{ \mathbf{Ax} : \mathbf{x} \in \mathbb{R}^p \}.$$

Essa caracterização permite relacionar diretamente o espaço coluna à existência de soluções de sistemas lineares.

Proposição 3.7 (Consistência de um sistema linear). *O sistema*

$$\mathbf{Ax} = \mathbf{b}$$

possui pelo menos uma solução se, e somente se,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Comprovação. Se o sistema possui uma solução $\mathbf{x}$, então

$$\mathbf{b} = \mathbf{Ax},$$

de modo que $\mathbf{b}$ é uma combinação linear das colunas de $\mathbf{A}$. Portanto,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Reciprocamente, se

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}),$$

existem escalares $x_1, \dots, x_p$ tais que

$$\mathbf{b} = x_1 \mathbf{a}_{.1} + \dots + x_p \mathbf{a}_{.p}.$$

Definindo

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix} \in \mathbb{R}^p,$$

obtém-se

$$\mathbf{Ax} = \mathbf{b}.$$

□

Exemplo 3.13 (Determinação do espaço coluna). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

As colunas são

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \mathbf{a}_2 = \begin{bmatrix} 2 \\ 4 \end{bmatrix}, \mathbf{a}_3 = \begin{bmatrix} -1 \\ -2 \end{bmatrix}.$$

Como

$$\mathbf{a}_2 = 2\mathbf{a}_1$$

e

$$\mathbf{a}_3 = -\mathbf{a}_1,$$

tem-se

$$\mathcal{C}(\mathbf{A}) = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \end{bmatrix} \right\}.$$

Logo,

$$\dim \mathcal{C}(\mathbf{A}) = 1.$$

A dimensão do espaço coluna é igual ao posto da matriz:

$$\dim \mathcal{C}(\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Uma base de $\mathcal{C}(\mathbf{A})$ pode ser formada por quaisquer vetores linearmente independentes que gerem esse espaço. Quando se deseja obter uma base selecionando colunas da própria matriz $\mathbf{A}$, as posições das colunas pivô podem ser identificadas por escalonamento. Nesse procedimento, os vetores da base são as colunas correspondentes da matriz original, e não as colunas da matriz escalonada.

3.3.3 Espaço linha

Definição 3.13 (Espaço linha). O **espaço linha** de uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

é o subespaço de $\mathbb{R}^p$ gerado por suas linhas.

Escrevendo as linhas de $\mathbf{A}$ como

$$\mathbf{a}_1^\top, \mathbf{a}_2^\top, \dots, \mathbf{a}_n^\top,$$

o espaço linha pode ser representado por

$$\mathcal{L}(\mathbf{A}) = \text{span} \{ \mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n \} \subseteq \mathbb{R}^p.$$

Equivalentemente, como as linhas de $\mathbf{A}$ são as colunas de $\mathbf{A}^\top$,

$$\mathcal{L}(\mathbf{A}) = \mathcal{C}(\mathbf{A}^\top).$$

O espaço linha e o espaço coluna possuem a mesma dimensão:

$$\dim \mathcal{L}(\mathbf{A}) = \dim \mathcal{C}(\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Essa igualdade permite interpretar o posto tanto como o número máximo de colunas linearmente independentes quanto como o número máximo de linhas linearmente independentes.

Exemplo 3.14 (Determinação do espaço linha). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

As linhas de $\mathbf{A}$ são

$$\mathbf{a}_1^\top = [1 \quad 2 \quad -1]$$

e

$$\mathbf{a}_2^\top = [2 \quad 4 \quad -2].$$

Os vetores-coluna associados a essas linhas são

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix} \quad \text{e} \quad \mathbf{a}_2 = \begin{bmatrix} 2 \\ 4 \\ -2 \end{bmatrix}.$$

Como

$$\mathbf{a}_2 = 2\mathbf{a}_1,$$

tem-se

$$\mathcal{L}(\mathbf{A}) = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix} \right\}.$$

Logo,

$$\dim \mathcal{L}(\mathbf{A}) = 1.$$

As linhas não nulas de uma forma escalonada de $\mathbf{A}$ formam uma base de $\mathcal{L}(\mathbf{A})$. Diferentemente do espaço coluna, pode-se utilizar diretamente as linhas da matriz escalonada, pois as operações elementares por linhas preservam o espaço linha.

3.3.4 Espaço nulo à esquerda

Definição 3.14 (Espaço nulo à esquerda). O **espaço nulo à esquerda** de

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

é definido por

$$\mathcal{N}(\mathbf{A}^\top) = \{\mathbf{y} \in \mathbb{R}^n : \mathbf{A}^\top \mathbf{y} = \mathbf{0}\}.$$

Um vetor $\mathbf{y}$ pertence a $\mathcal{N}(\mathbf{A}^\top)$ quando é ortogonal a todas as colunas de $\mathbf{A}$. De fato,

$$\mathbf{A}^\top \mathbf{y} = \begin{bmatrix} \mathbf{a}_1^\top \mathbf{y} \\ \mathbf{a}_2^\top \mathbf{y} \\ \vdots \\ \mathbf{a}_p^\top \mathbf{y} \end{bmatrix}.$$

Assim,

$$\mathbf{A}^\top \mathbf{y} = \mathbf{0}$$

se, e somente se,

$$\mathbf{a}_j^\top \mathbf{y} = 0, \quad j = 1, \dots, p.$$

Portanto, todo vetor de $\mathcal{N}(\mathbf{A}^\top)$ é ortogonal a cada coluna de $\mathbf{A}$ e, conseqüentemente, a toda combinação linear dessas colunas. A relação entre o espaço nulo à esquerda e o complemento ortogonal do espaço coluna será formalizada adiante.

Exemplo 3.15 (Determinação do espaço nulo à esquerda). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

Para determinar $\mathcal{N}(\mathbf{A}^\top)$, resolve-se

$$\mathbf{A}^\top \mathbf{y} = \mathbf{0}.$$

Assim,

$$\begin{bmatrix} 1 & 2 \\ 2 & 4 \\ -1 & -2 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}.$$

O sistema reduz-se a

$$y_1 + 2y_2 = 0.$$

Tomando

$$y_2 = t,$$

obtém-se

$$y_1 = -2t.$$

Portanto,

$$\mathbf{y} = t \begin{bmatrix} -2 \\ 1 \end{bmatrix},$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \end{bmatrix} \right\}.$$

Logo,

$$\dim \mathcal{N}(\mathbf{A}^\top) = 1.$$

3.3.5 Extensão de uma base

Uma base de um subespaço pode ser completada acrescentando vetores até formar uma base de todo o espaço. Esse resultado será utilizado na demonstração do Teorema Posto–Nulidade.

Teorema 3.4 (Extensão de uma base). *Seja W um subespaço de um espaço vetorial V de dimensão finita. Se*

$$\mathcal{B}_W = \{\mathbf{u}_1, \dots, \mathbf{u}_s\}$$

é uma base de W , então existem vetores $\mathbf{z}_1, \dots, \mathbf{z}_r \in V$ tais que

$$\{\mathbf{u}_1, \dots, \mathbf{u}_s, \mathbf{z}_1, \dots, \mathbf{z}_r\}$$

é uma base de V . (Meyer, 2023)

Comprovação. Se $\mathcal{B}_W$ já gera V , então $\mathcal{B}_W$ é uma base de V e nada precisa ser acrescentado. Caso contrário, existe um vetor $\mathbf{z}_1 \in V$ que não pertence ao subespaço gerado por $\mathcal{B}_W$. Assim,

$$\{\mathbf{u}_1, \dots, \mathbf{u}_s, \mathbf{z}_1\}$$

é linearmente independente.

Se esse conjunto ainda não gera V , escolhe-se um vetor $\mathbf{z}_2 \in V$ que não pertence ao subespaço gerado pelos vetores já selecionados. O novo conjunto continua linearmente independente.

Repetindo esse procedimento, acrescentam-se vetores enquanto o conjunto obtido não gerar V . Como V possui dimensão finita, não é possível acrescentar indefinidamente vetores linearmente independentes. Portanto, após um número finito de etapas, obtém-se um conjunto

$$\{\mathbf{u}_1, \dots, \mathbf{u}_s, \mathbf{z}_1, \dots, \mathbf{z}_r\}$$

que é linearmente independente e gera V . Logo, esse conjunto é uma base de V . $\square$

3.3.6 Teorema Posto–Nulidade

As dimensões do espaço nulo e do espaço coluna estão relacionadas ao número de colunas da matriz.

Teorema 3.5 (Teorema Posto–Nulidade). *Se*

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

então

$$\text{posto}(\mathbf{A}) + \text{nul}(\mathbf{A}) = p.$$

(Meyer, 2023)

Comprovação. Considere uma base do espaço nulo,

$$\mathcal{B}_\mathcal{N} = \{\mathbf{v}_1, \dots, \mathbf{v}_s\},$$

em que

$$s = \dim \mathcal{N}(\mathbf{A}).$$

Pelo Teorema 3.4, essa base de $\mathcal{N}(\mathbf{A})$ pode ser completada para formar uma base de $\mathbb{R}^p$. Assim, existem vetores $\mathbf{w}_1, \dots, \mathbf{w}_r \in \mathbb{R}^p$ tais que

$$\{\mathbf{v}_1, \dots, \mathbf{v}_s, \mathbf{w}_1, \dots, \mathbf{w}_r\}$$

é uma base de $\mathbb{R}^p$.

Como essa base possui p vetores,

$$s + r = p.$$

Todo vetor $\mathbf{x} \in \mathbb{R}^p$ possui uma representação da forma

$$\mathbf{x} = \sum_{i=1}^s \alpha_i \mathbf{v}_i + \sum_{j=1}^r \beta_j \mathbf{w}_j.$$

Como

$$\mathbf{A}\mathbf{v}_i = \mathbf{0}, \quad i = 1, \dots, s,$$

tem-se

$$\mathbf{A}\mathbf{x} = \sum_{j=1}^r \beta_j \mathbf{A}\mathbf{w}_j.$$

Portanto,

$$\mathbf{A}\mathbf{w}_1, \dots, \mathbf{A}\mathbf{w}_r$$

geram $\mathcal{C}(\mathbf{A})$.

Para verificar a independência linear, suponha que

$$\sum_{j=1}^r \beta_j \mathbf{A}\mathbf{w}_j = \mathbf{0}.$$

Então,

$$\mathbf{A} \left(\sum_{j=1}^r \beta_j \mathbf{w}_j \right) = \mathbf{0},$$

de modo que

$$\sum_{j=1}^r \beta_j \mathbf{w}_j \in \mathcal{N}(\mathbf{A}).$$

Esse vetor também pertence a

$$\text{span}\{\mathbf{w}_1, \dots, \mathbf{w}_r\}.$$

Como

$$\{\mathbf{v}_1, \dots, \mathbf{v}_s, \mathbf{w}_1, \dots, \mathbf{w}_r\}$$

é uma base de $\mathbb{R}^p$, a interseção entre esses dois subespaços contém somente o vetor nulo. Assim,

$$\beta_1 = \dots = \beta_r = 0.$$

Logo,

$$\mathbf{A}\mathbf{w}_1, \dots, \mathbf{A}\mathbf{w}_r$$

formam uma base de $\mathcal{C}(\mathbf{A})$. Portanto,

$$r = \dim \mathcal{C}(\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Logo,

$$\text{posto}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}) = p.$$

□

Aplicando o teorema a $\mathbf{A}^\top$,

$$\text{posto}(\mathbf{A}^\top) + \dim \mathcal{N}(\mathbf{A}^\top) = n.$$

Como

$$\text{posto}(\mathbf{A}^\top) = \text{posto}(\mathbf{A}),$$

obtém-se

$$\text{posto}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}^\top) = n.$$

Exemplo 3.16 (Aplicação do Teorema Posto–Nulidade). Para a matriz utilizada nesta seção,

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix},$$

tem-se

$$\text{posto}(\mathbf{A}) = 1,$$

$$\dim \mathcal{N}(\mathbf{A}) = 2$$

e

$$\dim \mathcal{N}(\mathbf{A}^\top) = 1.$$

Assim, para $\mathbf{A} \in \mathbb{R}^{2 \times 3}$,

$$1 + 2 = 3,$$

confirmando que

$$\text{posto}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}) = 3.$$

Aplicando o resultado a $\mathbf{A}^\top$,

$$1 + 1 = 2,$$

de modo que

$$\text{posto}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}^\top) = 2.$$

Os resultados correspondem, respectivamente, às dimensões dos espaços ambientes $\mathbb{R}^3$ e $\mathbb{R}^2$.

3.3.7 Os quatro espaços fundamentais

Os quatro subespaços associados a

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

são:

Tabela 3.1: Espaços fundamentais de uma matriz $\mathbf{A} \in \mathbb{R}^{n \times p}$ com posto r .

Espaço	Definição	Subespaço de	Dimensão
Espaço coluna	$\mathcal{C}(\mathbf{A})$	$\mathbb{R}^n$	r
Espaço linha	$\mathcal{L}(\mathbf{A}) = \mathcal{C}(\mathbf{A}^\top)$	$\mathbb{R}^p$	r
Espaço nulo	$\mathcal{N}(\mathbf{A})$	$\mathbb{R}^p$	$p - r$
Espaço nulo à esquerda	$\mathcal{N}(\mathbf{A}^\top)$	$\mathbb{R}^n$	$n - r$

A Tabela 3.1 mostra que os quatro espaços se organizam em dois espaços ambientes. O espaço coluna e o espaço nulo à esquerda são subespaços de $\mathbb{R}^n$, enquanto o espaço linha e o espaço nulo são subespaços de $\mathbb{R}^p$.

3.3.8 Complemento ortogonal

Definição 3.15 (Complemento ortogonal). Seja S um subespaço de $\mathbb{R}^p$. O **complemento ortogonal** de S é

$$S^\perp = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{x}^\top \mathbf{s} = 0 \text{ para todo } \mathbf{s} \in S\}.$$

O complemento ortogonal reúne todos os vetores de $\mathbb{R}^p$ que são ortogonais a cada vetor de S . Essa definição permite descrever relações importantes entre os quatro espaços fundamentais de uma matriz.

3.3.9 Relações de ortogonalidade

Teorema 3.6 (Ortogonalidade entre os espaços fundamentais). *Para*

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

tem-se

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Comprovação. Considere inicialmente

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}).$$

Então

$$\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Cada componente de $\mathbf{A}\mathbf{x}$ é o produto interno entre uma linha de $\mathbf{A}$ e $\mathbf{x}$. Portanto, $\mathbf{x}$ é ortogonal a todas as linhas de $\mathbf{A}$ e, conseqüentemente, a todo vetor de $\mathcal{L}(\mathbf{A})$. Logo,

$$\mathbf{x} \in \mathcal{L}(\mathbf{A})^\perp.$$

Assim,

$$\mathcal{N}(\mathbf{A}) \subseteq \mathcal{L}(\mathbf{A})^\perp.$$

Reciprocamente, suponha que

$$\mathbf{x} \in \mathcal{L}(\mathbf{A})^\perp.$$

Então $\mathbf{x}$ é ortogonal a todas as linhas de $\mathbf{A}$. Cada componente de $\mathbf{A}\mathbf{x}$ é, portanto, igual a zero, de modo que

$$\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Logo,

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}),$$

e

$$\mathcal{L}(\mathbf{A})^\perp \subseteq \mathcal{N}(\mathbf{A}).$$

Portanto,

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp.$$

De forma análoga, para

$$\mathbf{y} \in \mathbb{R}^n,$$

a condição

$$\mathbf{A}^\top \mathbf{y} = \mathbf{0}$$

equivale a $\mathbf{y}$ ser ortogonal a todas as colunas de $\mathbf{A}$. Portanto,

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

□

Essas relações mostram que os espaços fundamentais se organizam em dois pares ortogonais:

$$\mathcal{L}(\mathbf{A}) \perp \mathcal{N}(\mathbf{A})$$

em $\mathbb{R}^p$, e

$$\mathcal{C}(\mathbf{A}) \perp \mathcal{N}(\mathbf{A}^\top)$$

em $\mathbb{R}^n$.

A decomposição dos espaços ambientes em somas diretas desses pares será obtida posteriormente a partir do resultado geral sobre complementos ortogonais.

3.4 Produtos internos, bases ortonormais e matrizes de Gram

O produto interno euclidiano

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^\top \mathbf{y}$$

define comprimentos, ângulos e ortogonalidade em $\mathbb{R}^p$. Além da geometria euclidiana, é possível definir outras geometrias atribuindo pesos e relações diferentes às coordenadas.

3.4.1 Aprofundamento: produtos internos e geometrias induzidas

Leitura de aprofundamento

Esta subseção generaliza o produto interno euclidiano por meio de matrizes positivas definidas e apresenta as normas, distâncias e relações de ortogonalidade associadas a essa generalização. Esses conceitos serão retomados no estudo da distância de Mahalanobis, de geometrias determinadas por matrizes de covariâncias e de problemas de mínimos quadrados ponderados.

Considere uma matriz simétrica positiva definida

$$\mathbf{M} \in \mathbb{R}^{p \times p}.$$

Definição 3.16 (Produto interno induzido por uma matriz). O **produto interno induzido por $\mathbf{M}$** é definido por

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{y}, \quad \mathbf{x}, \mathbf{y} \in \mathbb{R}^p.$$

A simetria de $\mathbf{M}$ garante que

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \langle \mathbf{y}, \mathbf{x} \rangle_{\mathbf{M}},$$

pois

$$\mathbf{x}^\top \mathbf{M} \mathbf{y} = (\mathbf{x}^\top \mathbf{M} \mathbf{y})^\top = \mathbf{y}^\top \mathbf{M}^\top \mathbf{x} = \mathbf{y}^\top \mathbf{M} \mathbf{x}.$$

A definição positiva garante que

$$\langle \mathbf{x}, \mathbf{x} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$.

Proposição 3.8 (Propriedades do produto interno induzido). *Para quaisquer $\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$ e $\alpha, \beta \in \mathbb{R}$,*

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \langle \mathbf{y}, \mathbf{x} \rangle_{\mathbf{M}},$$

$$\langle \alpha \mathbf{x} + \beta \mathbf{y}, \mathbf{z} \rangle_{\mathbf{M}} = \alpha \langle \mathbf{x}, \mathbf{z} \rangle_{\mathbf{M}} + \beta \langle \mathbf{y}, \mathbf{z} \rangle_{\mathbf{M}},$$

e

$$\langle \mathbf{x}, \mathbf{x} \rangle_{\mathbf{M}} > 0 \quad \text{para} \quad \mathbf{x} \neq \mathbf{0}.$$

(Horn; Johnson, 2013)

Quando

$$\mathbf{M} = \mathbf{I}_p,$$

recupera-se o produto interno euclidiano:

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{I}_p} = \mathbf{x}^\top \mathbf{y}.$$

Exemplo 3.17 (Cálculo de um produto interno induzido). Considere

$$\mathbf{M} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

e

$$\mathbf{y} = \begin{bmatrix} 2 \\ -1 \end{bmatrix}.$$

Então,

$$\mathbf{M}\mathbf{y} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 2 \\ -1 \end{bmatrix} = \begin{bmatrix} 3 \\ 0 \end{bmatrix}.$$

Logo,

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^{\top} \mathbf{M} \mathbf{y} = \begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} 3 \\ 0 \end{bmatrix} = 3.$$

O produto interno euclidiano entre os mesmos vetores é

$$\mathbf{x}^{\top} \mathbf{y} = 1(2) + 2(-1) = 0.$$

Portanto, os vetores são ortogonais segundo o produto interno euclidiano, mas não segundo o produto interno induzido por $\mathbf{M}$.

3.4.1.1 Norma e distância induzidas

Definição 3.17 (Norma induzida). A norma associada ao produto interno induzido por $\mathbf{M}$ é

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle_{\mathbf{M}}} = \sqrt{\mathbf{x}^{\top} \mathbf{M} \mathbf{x}}.$$

A distância associada é

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_{\mathbf{M}},$$

ou, equivalentemente,

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \sqrt{(\mathbf{x} - \mathbf{y})^{\top} \mathbf{M} (\mathbf{x} - \mathbf{y})}.$$

Quando $\mathbf{M} = \mathbf{I}_p$, obtêm-se a norma e a distância euclidianas.

Exemplo 3.18 (Norma e distância induzidas). Considere

$$\mathbf{M} = \begin{bmatrix} 1 & 0 \\ 0 & 4 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

A norma euclidiana de $\mathbf{x}$ é

$$\|\mathbf{x}\| = \sqrt{2^2 + 1^2} = \sqrt{5}.$$

A norma induzida por $\mathbf{M}$ é

$$\begin{aligned}\|\mathbf{x}\|_{\mathbf{M}} &= \sqrt{[2 \quad 1] \begin{bmatrix} 1 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix}} \\ &= \sqrt{8}.\end{aligned}$$

A segunda coordenada recebe peso maior na geometria definida por $\mathbf{M}$.

3.4.1.2 Ortogonalidade induzida

Dois vetores $\mathbf{x}$ e $\mathbf{y}$ são ortogonais segundo $\mathbf{M}$ quando

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^{\top} \mathbf{M} \mathbf{y} = 0.$$

Uma base

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é $\mathbf{M}$ -ortonormal quando

$$\mathbf{b}_i^{\top} \mathbf{M} \mathbf{b}_j = \delta_{ij},$$

em que δ_{ij} é o delta de Kronecker definido no capítulo anterior.

Se

$$\mathbf{B} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_k],$$

essa condição pode ser escrita como

$$\mathbf{B}^{\top} \mathbf{M} \mathbf{B} = \mathbf{I}_k.$$

3.4.1.3 Relação com a geometria euclidiana

Como $\mathbf{M}$ é simétrica positiva definida, existe uma matriz invertível $\mathbf{C}$ tal que

$$\mathbf{M} = \mathbf{C}^\top \mathbf{C}.$$

Assim,

$$\begin{aligned}\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} &= \mathbf{x}^\top \mathbf{C}^\top \mathbf{C} \mathbf{y} \\ &= (\mathbf{C} \mathbf{x})^\top (\mathbf{C} \mathbf{y}).\end{aligned}$$

Assim, o produto interno induzido por $\mathbf{M}$ pode ser interpretado como o produto interno euclidiano entre os vetores $\mathbf{C} \mathbf{x}$ e $\mathbf{C} \mathbf{y}$. Da mesma forma,

$$\|\mathbf{x}\|_{\mathbf{M}} = \|\mathbf{C} \mathbf{x}\|.$$

As curvas de nível

$$\|\mathbf{x}\|_{\mathbf{M}} = 1$$

satisfazem

$$\mathbf{x}^\top \mathbf{M} \mathbf{x} = 1.$$

Na geometria euclidiana, essas curvas são circunferências quando $\mathbf{M} = \mathbf{I}_2$ e elipses para outras matrizes positivas definidas.

A Figura 3.4 compara três geometrias em $\mathbb{R}^2$.

A matriz identidade produz a circunferência euclidiana. Uma matriz diagonal com pesos distintos produz uma elipse alinhada aos eixos coordenados. Elementos fora da diagonal podem alterar a orientação da elipse.

Matrizes semidefinidas positivas

Se $\mathbf{M}$ é apenas semidefinida positiva, a expressão

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\mathbf{x}^\top \mathbf{M} \mathbf{x}}$$

pode ser igual a zero para algum vetor $\mathbf{x} \neq \mathbf{0}$.

Nesse caso, a expressão define uma **seminorma**, e não uma norma. Analogamente,

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_{\mathbf{M}}$$




Figura 3.4: Curvas de norma unitária para diferentes produtos internos em $\mathbb{R}^2$.

pode ser igual a zero mesmo quando $\mathbf{x} \neq \mathbf{y}$. Portanto, essa expressão define, em geral, uma **pseudodistância**.

Os produtos internos entre vários vetores podem ser organizados em uma matriz de Gram.

3.4.2 Matrizes de Gram

Os produtos internos entre um conjunto de vetores podem ser organizados em uma matriz.

Definição 3.18 (Matriz de Gram). Sejam $\mathbf{v}_1, \dots, \mathbf{v}_k \in \mathbb{R}^p$ e

$$\mathbf{V} = [\mathbf{v}_1 \quad \mathbf{v}_2 \quad \dots \quad \mathbf{v}_k] \in \mathbb{R}^{p \times k}.$$

A **matriz de Gram** dos vetores é

$$\mathbf{G} = \mathbf{V}^\top \mathbf{V}.$$

Seu elemento na posição (i, j) é

$$g_{ij} = \mathbf{v}_i^\top \mathbf{v}_j.$$

A diagonal de $\mathbf{G}$ contém os quadrados das normas:

$$g_{ii} = \mathbf{v}_i^\top \mathbf{v}_i = \|\mathbf{v}_i\|^2.$$

Os elementos fora da diagonal contêm os produtos internos entre vetores distintos.

Quando $\mathbf{v}_i$ e $\mathbf{v}_j$ são não nulos,

$$g_{ij} = \|\mathbf{v}_i\| \|\mathbf{v}_j\| \cos(\theta_{ij}).$$

Portanto, o produto interno depende tanto das normas quanto do ângulo entre os vetores.

Exemplo 3.19 (Construção de uma matriz de Gram). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$$

e

$$\mathbf{V} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

A matriz de Gram é

$$\begin{aligned} \mathbf{G} &= \mathbf{V}^\top \mathbf{V} \\ &= \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}. \end{aligned}$$

Os elementos diagonais são

$$\|\mathbf{v}_1\|^2 = \|\mathbf{v}_2\|^2 = 2,$$

e o elemento fora da diagonal é

$$\mathbf{v}_1^\top \mathbf{v}_2 = 1.$$

3.4.3 Propriedades da matriz de Gram

Proposição 3.9 (Propriedades da matriz de Gram). *Para*

$$\mathbf{G} = \mathbf{V}^\top \mathbf{V},$$

tem-se:

1. $\mathbf{G}$ é simétrica;
2. $\mathbf{G}$ é semidefinida positiva;
3. $\mathbf{G}$ é positiva definida se, e somente se, as colunas de $\mathbf{V}$ são linearmente independentes;
4. $\text{posto}(\mathbf{G}) = \text{posto}(\mathbf{V})$.

(Horn; Johnson, 2013)

Comprovação. A simetria decorre de

$$\mathbf{G}^\top = (\mathbf{V}^\top \mathbf{V})^\top = \mathbf{V}^\top \mathbf{V} = \mathbf{G}.$$

Para qualquer $\mathbf{c} \in \mathbb{R}^k$,

$$\begin{aligned} \mathbf{c}^\top \mathbf{G} \mathbf{c} &= \mathbf{c}^\top \mathbf{V}^\top \mathbf{V} \mathbf{c} \\ &= (\mathbf{V} \mathbf{c})^\top (\mathbf{V} \mathbf{c}) \\ &= \|\mathbf{V} \mathbf{c}\|^2 \\ &\geq 0. \end{aligned}$$

Logo, $\mathbf{G}$ é semidefinida positiva.

Além disso,

$$\mathbf{c}^\top \mathbf{G} \mathbf{c} = 0$$

se, e somente se,

$$\mathbf{V} \mathbf{c} = \mathbf{0}.$$

Portanto, $\mathbf{G}$ é positiva definida se, e somente se, o sistema homogêneo

$$\mathbf{V} \mathbf{c} = \mathbf{0}$$

possui apenas a solução trivial, o que equivale à independência linear das colunas de $\mathbf{V}$.
Para demonstrar a igualdade dos núcleos, suponha inicialmente que

$$\mathbf{V}^\top \mathbf{V} \mathbf{c} = \mathbf{0}.$$

Multiplicando à esquerda por $\mathbf{c}^\top$,

$$\mathbf{c}^\top \mathbf{V}^\top \mathbf{V} \mathbf{c} = \|\mathbf{V} \mathbf{c}\|^2 = 0.$$

Logo,

$$\mathbf{V} \mathbf{c} = \mathbf{0},$$

e, portanto,

$$\mathcal{N}(\mathbf{V}^\top \mathbf{V}) \subseteq \mathcal{N}(\mathbf{V}).$$

Reciprocamente, se

$$\mathbf{V} \mathbf{c} = \mathbf{0},$$

então

$$\mathbf{V}^\top \mathbf{V} \mathbf{c} = \mathbf{V}^\top \mathbf{0} = \mathbf{0},$$

de modo que

$$\mathcal{N}(\mathbf{V}) \subseteq \mathcal{N}(\mathbf{V}^\top \mathbf{V}).$$

Assim,

$$\mathcal{N}(\mathbf{V}^\top \mathbf{V}) = \mathcal{N}(\mathbf{V}).$$

Como $\mathbf{V}^\top \mathbf{V}$ e $\mathbf{V}$ possuem o mesmo número de colunas, a igualdade das nulidades e o Teorema Posto–Nulidade implicam

$$\text{posto}(\mathbf{V}^\top \mathbf{V}) = \text{posto}(\mathbf{V}).$$

□

Uma consequência é:

$$\det(\mathbf{V}^\top \mathbf{V}) > 0$$

se, e somente se, as colunas de $\mathbf{V}$ são linearmente independentes.

Quando as colunas são linearmente dependentes,

$$\det(\mathbf{V}^\top \mathbf{V}) = 0.$$

3.4.4 Matrizes de Gram e bases ortonormais

Se as colunas de $\mathbf{Q}$ formam um conjunto ortonormal, então

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}.$$

Portanto, a matriz de Gram de um conjunto ortonormal é a matriz identidade.

Para uma base ortogonal não normalizada,

$$\mathbf{V}^\top \mathbf{V} = \text{diag}(\|\mathbf{v}_1\|^2, \dots, \|\mathbf{v}_k\|^2).$$

Exemplo 3.20 (Matriz de Gram de uma base ortogonal). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Como

$$\mathbf{v}_1^\top \mathbf{v}_2 = 0,$$

os vetores são ortogonais.

A matriz de Gram é

$$\mathbf{G} = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}.$$

Normalizando os vetores,

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

obtem-se

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_2.$$

3.4.5 Produtos cruzados em uma matriz de dados

Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p}.$$

O produto

$$\mathbf{X}^\top \mathbf{X} \in \mathbb{R}^{p \times p}$$

é a matriz de Gram das colunas de $\mathbf{X}$. Seus elementos são

$$(\mathbf{X}^\top \mathbf{X})_{jk} = \sum_{i=1}^n x_{ij} x_{ik}.$$

Assim:

- os elementos diagonais são somas de quadrados das variáveis;
- os elementos fora da diagonal são produtos cruzados entre pares de variáveis.

O produto

$$\mathbf{X} \mathbf{X}^\top \in \mathbb{R}^{n \times n}$$

é a matriz de Gram das linhas de $\mathbf{X}$. Seus elementos são

$$(\mathbf{X} \mathbf{X}^\top)_{ij} = \mathbf{x}_i^\top \mathbf{x}_j,$$

em que $\mathbf{x}_i^\top$ e $\mathbf{x}_j^\top$ representam duas observações.

A Tabela 3.2 resume as duas construções.

Tabela 3.2: Produtos de Gram associados a uma matriz de dados.

Produto	Dimensão	Vetores comparados	Elemento genérico
$\mathbf{X}^\top \mathbf{X}$	$p \times p$	Colunas ou variáveis	$\sum_{i=1}^n x_{ij} x_{ik}$
$\mathbf{X} \mathbf{X}^\top$	$n \times n$	Linhas ou observações	$\mathbf{x}_i^\top \mathbf{x}_j$

Quando as colunas da matriz de dados estão centradas, $\mathbf{X}^\top \mathbf{X}$ reúne as somas de quadrados e produtos cruzados utilizadas na construção da matriz de covariâncias. Essa relação será retomada no capítulo sobre covariâncias e correlações.

As matrizes de Gram também aparecem na construção da projeção de um vetor sobre o espaço gerado pelas colunas de uma matriz.

3.4.6 Propriedades do complemento ortogonal

O complemento ortogonal, introduzido anteriormente na descrição dos espaços fundamentais de uma matriz, será agora estudado para um subespaço arbitrário de $\mathbb{R}^p$.

Se

$$S = \text{span}\{\mathbf{s}_1, \dots, \mathbf{s}_k\},$$

então basta verificar a ortogonalidade em relação aos vetores geradores:

$$S^\perp = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{s}_j^\top \mathbf{x} = 0, \quad j = 1, \dots, k\}.$$

Isso ocorre porque todo vetor de S é uma combinação linear dos vetores $\mathbf{s}_1, \dots, \mathbf{s}_k$. Portanto, um vetor ortogonal a todos os geradores é ortogonal a todo o subespaço.

Proposição 3.10 (O complemento ortogonal é um subespaço). *Se S é um subespaço de $\mathbb{R}^p$, então $S^\perp$ também é um subespaço de $\mathbb{R}^p$.*

Comprovação. O vetor nulo pertence a $S^\perp$, pois

$$\mathbf{0}^\top \mathbf{s} = 0$$

para todo $\mathbf{s} \in S$.

Se

$$\mathbf{x}, \mathbf{y} \in S^\perp,$$

então, para quaisquer $\alpha, \beta \in \mathbb{R}$ e $\mathbf{s} \in S$,

$$(\alpha\mathbf{x} + \beta\mathbf{y})^\top \mathbf{s} = \alpha\mathbf{x}^\top \mathbf{s} + \beta\mathbf{y}^\top \mathbf{s} = 0.$$

Portanto,

$$\alpha\mathbf{x} + \beta\mathbf{y} \in S^\perp,$$

e $S^\perp$ é um subespaço de $\mathbb{R}^p$. □

Exemplo 3.21 (Complemento ortogonal de uma reta). Considere

$$S = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \end{bmatrix} \right\} \subseteq \mathbb{R}^2.$$

Um vetor

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

pertence a $S^\perp$ quando

$$\begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0.$$

Assim,

$$x_1 + 2x_2 = 0.$$

Tomando $x_2 = t$, obtém-se

$$x_1 = -2t.$$

Logo,

$$S^\perp = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \end{bmatrix} \right\}.$$

3.4.7 Dimensão do complemento ortogonal

Proposição 3.11 (Dimensão do complemento ortogonal). *Se S é um subespaço de $\mathbb{R}^p$, então*

$$\dim(S) + \dim(S^\perp) = p.$$

Comprovação. Seja

$$\dim(S) = k.$$

Pelo Teorema 3.2, existe uma base ortonormal

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$$

de S .

Pelo Teorema 3.4, essa base de S pode ser completada para formar uma base de $\mathbb{R}^p$. Aplicando o processo de Gram–Schmidt aos vetores acrescentados, preservando os primeiros k vetores, obtém-se uma base ortonormal de $\mathbb{R}^p$:

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k, \mathbf{q}_{k+1}, \dots, \mathbf{q}_p\}.$$

Como a base é ortonormal,

$$\mathbf{q}_i^\top \mathbf{q}_j = 0, \quad i = 1, \dots, k, \quad j = k+1, \dots, p.$$

Portanto,

$$\mathbf{q}_{k+1}, \dots, \mathbf{q}_p \in S^\perp.$$

Além disso, esses vetores geram $S^\perp$. De fato, para qualquer

$$\mathbf{x} \in S^\perp,$$

como a coleção completa é uma base de $\mathbb{R}^p$, pode-se escrever

$$\mathbf{x} = \sum_{j=1}^p \alpha_j \mathbf{q}_j.$$

Para $i = 1, \dots, k$,

$$\mathbf{q}_i^\top \mathbf{x} = \alpha_i.$$

Como $\mathbf{x} \in S^\perp$,

$$\mathbf{q}_i^\top \mathbf{x} = 0,$$

e, portanto,

$$\alpha_i = 0, \quad i = 1, \dots, k.$$

Logo,

$$\mathbf{x} = \sum_{j=k+1}^p \alpha_j \mathbf{q}_j,$$

de modo que

$$\{\mathbf{q}_{k+1}, \dots, \mathbf{q}_p\}$$

é uma base de $S^\perp$.

Assim,

$$\dim(S^\perp) = p - k,$$

e, como $\dim(S) = k$,

$$\dim(S) + \dim(S^\perp) = p.$$

□

Consequentemente, se

$$\dim(S) = k,$$

então

$$\dim(S^\perp) = p - k.$$

Além disso,

$$S \cap S^\perp = \{\mathbf{0}\}.$$

De fato, se

$$\mathbf{x} \in S \cap S^\perp,$$

então $\mathbf{x}$ é ortogonal a todos os vetores de S , inclusive a si próprio. Portanto,

$$\mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|^2 = 0,$$

o que implica

$$\mathbf{x} = \mathbf{0}.$$

Outra consequência importante é

$$(S^\perp)^\perp = S.$$

De fato,

$$S \subseteq (S^\perp)^\perp,$$

pois todo vetor de S é ortogonal a todos os vetores de $S^\perp$. Além disso,

$$\begin{aligned} \dim \left((S^\perp)^\perp \right) &= p - \dim(S^\perp) \\ &= p - (p - k) \\ &= k \\ &= \dim(S). \end{aligned}$$

Como um subespaço está contido no outro e ambos possuem a mesma dimensão,

$$(S^\perp)^\perp = S.$$

3.4.8 Decomposição ortogonal

Teorema 3.7 (Decomposição ortogonal). *Se S é um subespaço de $\mathbb{R}^p$, então todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito de maneira única como*

$$\mathbf{x} = \mathbf{x}_S + \mathbf{x}_{S^\perp},$$

em que

$$\mathbf{x}_S \in S$$

e

$$\mathbf{x}_{S^\perp} \in S^\perp.$$

Equivalentemente,

$$\mathbb{R}^p = S \oplus S^\perp.$$

O símbolo $\oplus$ representa uma **soma direta**: cada vetor de $\mathbb{R}^p$ possui uma única decomposição como soma de um vetor pertencente a S e um vetor pertencente a $S^\perp$.

Comprovação. Pelo Teorema 3.2, existe uma base ortonormal

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$$

de S .

Defina

$$\mathbf{x}_S = \sum_{j=1}^k (\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_j$$

e

$$\mathbf{x}_{S^\perp} = \mathbf{x} - \mathbf{x}_S.$$

Por construção,

$$\mathbf{x}_S \in S.$$

Para cada $i = 1, \dots, k$,

$$\begin{aligned}\mathbf{q}_i^\top \mathbf{x}_{S^\perp} &= \mathbf{q}_i^\top \mathbf{x} - \sum_{j=1}^k (\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_i^\top \mathbf{q}_j \\ &= \mathbf{q}_i^\top \mathbf{x} - \mathbf{q}_i^\top \mathbf{x} \\ &= 0.\end{aligned}$$

Logo,

$$\mathbf{x}_{S^\perp} \in S^\perp,$$

o que demonstra a existência da decomposição.

Para demonstrar a unicidade, suponha que

$$\mathbf{x} = \mathbf{s}_1 + \mathbf{r}_1 = \mathbf{s}_2 + \mathbf{r}_2,$$

com

$$\mathbf{s}_1, \mathbf{s}_2 \in S$$

e

$$\mathbf{r}_1, \mathbf{r}_2 \in S^\perp.$$

Então,

$$\mathbf{s}_1 - \mathbf{s}_2 = \mathbf{r}_2 - \mathbf{r}_1.$$

O lado esquerdo pertence a S , enquanto o lado direito pertence a $S^\perp$. Portanto, esse vetor pertence a

$$S \cap S^\perp = \{\mathbf{0}\}.$$

Assim,

$$\mathbf{s}_1 - \mathbf{s}_2 = \mathbf{0}$$

e

$$\mathbf{r}_2 - \mathbf{r}_1 = \mathbf{0}.$$

Logo,

$$\mathbf{s}_1 = \mathbf{s}_2 \quad \text{e} \quad \mathbf{r}_1 = \mathbf{r}_2.$$

Portanto, a decomposição é única. □

A decomposição separa $\mathbf{x}$ em duas componentes únicas: $\mathbf{x}_S \in S$ e $\mathbf{x}_{S^\perp} \in S^\perp$. Na seção seguinte, veremos que $\mathbf{x}_S$ é precisamente a projeção ortogonal de $\mathbf{x}$ sobre S , enquanto

$$\mathbf{x}_{S^\perp} = \mathbf{x} - \mathbf{x}_S$$

é a componente ortogonal a S .

3.4.9 Decomposição dos espaços fundamentais

A decomposição ortogonal pode ser aplicada diretamente aos quatro espaços fundamentais de uma matriz.

Proposição 3.12 (Decomposição dos espaços fundamentais). *Para uma matriz $\mathbf{A} \in \mathbb{R}^{n \times p}$,*

$$\mathbb{R}^p = \mathcal{L}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A})$$

e

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top).$$

De fato, pelo Teorema 3.6,

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp.$$

Aplicando o Teorema 3.7,

$$\mathbb{R}^p = \mathcal{L}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}).$$

Portanto, todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito de maneira única como

$$\mathbf{x} = \mathbf{x}_{\mathcal{L}} + \mathbf{x}_{\mathcal{N}},$$

com $\mathbf{x}_{\mathcal{L}} \in \mathcal{L}(\mathbf{A})$ e $\mathbf{x}_{\mathcal{N}} \in \mathcal{N}(\mathbf{A})$.

Analogamente,

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp,$$

e, portanto,

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top).$$

Assim, todo vetor $\mathbf{y} \in \mathbb{R}^n$ pode ser escrito de maneira única como

$$\mathbf{y} = \mathbf{y}_{\mathcal{C}} + \mathbf{y}_{\mathcal{N}^\top},$$

com $\mathbf{y}_{\mathcal{C}} \in \mathcal{C}(\mathbf{A})$ e $\mathbf{y}_{\mathcal{N}^\top} \in \mathcal{N}(\mathbf{A}^\top)$.

Os quatro espaços fundamentais formam, portanto, dois pares de subespaços ortogonais complementares: um em $\mathbb{R}^p$ e outro em $\mathbb{R}^n$.

3.5 Projeções ortogonais

O Teorema 3.7 estabelece que, para qualquer subespaço $S \subseteq \mathbb{R}^p$, todo vetor $\mathbf{x} \in \mathbb{R}^p$ admite uma decomposição única em uma componente pertencente a S e outra pertencente a $S^\perp$. Essa decomposição permite definir a projeção ortogonal sobre um subespaço.

Definição 3.19 (Projeção ortogonal). Seja S um subespaço de $\mathbb{R}^p$. Pela decomposição ortogonal, todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito de maneira única como

$$\mathbf{x} = \mathbf{x}_S + \mathbf{x}_{S^\perp},$$

com $\mathbf{x}_S \in S$ e $\mathbf{x}_{S^\perp} \in S^\perp$.

A **projeção ortogonal de $\mathbf{x}$ sobre S** é definida por

$$\text{proj}_S(\mathbf{x}) = \mathbf{x}_S.$$

Consequentemente,

$$\mathbf{x} - \text{proj}_S(\mathbf{x}) \in S^\perp.$$

A forma da projeção depende de como o subespaço S é representado. Começaremos pelo caso mais simples, em que S possui dimensão 1.

3.5.1 Projeção sobre uma direção

Considere o subespaço unidimensional

$$S = \text{span}\{\mathbf{u}\},$$

em que

$$\mathbf{u} \neq \mathbf{0}.$$

A projeção de $\mathbf{x} \in \mathbb{R}^p$ sobre S deve pertencer ao próprio subespaço. Portanto, possui a forma

$$\text{proj}_S(\mathbf{x}) = \alpha \mathbf{u},$$

para algum $\alpha \in \mathbb{R}$.

O resíduo

$$\mathbf{r} = \mathbf{x} - \alpha \mathbf{u}$$

deve ser ortogonal a $\mathbf{u}$. Assim,

$$\mathbf{u}^\top (\mathbf{x} - \alpha \mathbf{u}) = 0.$$

Logo,

$$\mathbf{u}^\top \mathbf{x} - \alpha \mathbf{u}^\top \mathbf{u} = 0,$$

e, como $\mathbf{u} \neq \mathbf{0}$,

$$\alpha = \frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}}.$$

Proposição 3.13 (Projeção sobre uma direção). *Se*

$$S = \text{span}\{\mathbf{u}\}, \quad \mathbf{u} \neq \mathbf{0},$$

então a projeção ortogonal de $\mathbf{x} \in \mathbb{R}^p$ sobre S é

$$\text{proj}_S(\mathbf{x}) = \frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}} \mathbf{u}.$$

Como $\mathbf{u}^\top \mathbf{x}$ é um escalar, pode-se escrever

$$\frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}} \mathbf{u} = \frac{1}{\mathbf{u}^\top \mathbf{u}} \mathbf{u} (\mathbf{u}^\top \mathbf{x}).$$

Pela associatividade da multiplicação matricial,

$$\mathbf{u} (\mathbf{u}^\top \mathbf{x}) = (\mathbf{u} \mathbf{u}^\top) \mathbf{x}.$$

Portanto,

$$\begin{aligned} \text{proj}_S(\mathbf{x}) &= \frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}} \mathbf{u} = \frac{1}{\mathbf{u}^\top \mathbf{u}} \mathbf{u} (\mathbf{u}^\top \mathbf{x}) \\ &= \frac{1}{\mathbf{u}^\top \mathbf{u}} (\mathbf{u} \mathbf{u}^\top) \mathbf{x} = \frac{\mathbf{u} \mathbf{u}^\top}{\mathbf{u}^\top \mathbf{u}} \mathbf{x}. \end{aligned}$$

Portanto, definindo

$$\mathbf{P}_S = \frac{\mathbf{u} \mathbf{u}^\top}{\mathbf{u}^\top \mathbf{u}},$$

a projeção pode ser escrita na forma matricial

$$\text{proj}_S(\mathbf{x}) = \mathbf{P}_S \mathbf{x}.$$

A matriz

$$\mathbf{u} \mathbf{u}^\top$$

é o produto externo de $\mathbf{u}$ por ele próprio. Como visto nos capítulos anteriores, essa matriz é simétrica e, para $\mathbf{u} \neq \mathbf{0}$, possui posto 1. A normalização por $\mathbf{u}^\top \mathbf{u}$ produz a matriz que projeta ortogonalmente os vetores sobre a direção gerada por $\mathbf{u}$.

Se $\mathbf{u}$ possui norma igual a 1, então

$$\mathbf{u}^\top \mathbf{u} = 1,$$

e as expressões reduzem-se a

$$\text{proj}_S(\mathbf{x}) = (\mathbf{u}^\top \mathbf{x}) \mathbf{u}$$

e

$$\mathbf{P}_S = \mathbf{u}\mathbf{u}^\top.$$

Exemplo 3.22 (Projeção sobre uma reta). Considere

$$\mathbf{x} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}$$

e

$$S = \text{span} \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}.$$

Tomando

$$\mathbf{u} = \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

tem-se

$$\mathbf{u}^\top \mathbf{x} = 4$$

e

$$\mathbf{u}^\top \mathbf{u} = 2.$$

Portanto,

$$\text{proj}_S(\mathbf{x}) = \frac{4}{2} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \end{bmatrix}.$$

Equivalentemente, a matriz de projeção é

$$\begin{aligned}\mathbf{P}_S &= \frac{\mathbf{u}\mathbf{u}^\top}{\mathbf{u}^\top\mathbf{u}} \\ &= \frac{1}{2} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \end{bmatrix} \\ &= \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}.\end{aligned}$$

Assim,

$$\mathbf{P}_S\mathbf{x} = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 3 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \end{bmatrix}.$$

O resíduo é

$$\mathbf{r} = \mathbf{x} - \text{proj}_S(\mathbf{x}) = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A ortogonalidade é verificada por

$$\begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = 0.$$

Assim,

$$\mathbf{x} = \begin{bmatrix} 2 \\ 2 \end{bmatrix} + \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

com a primeira componente em S e a segunda em $S^\perp$.

A Figura 3.5 representa essa decomposição e destaca a ortogonalidade entre a projeção e o resíduo.

A projeção pertence ao subespaço S , enquanto o resíduo pertence a $S^\perp$. Essa decomposição será estendida para subespaços gerados por vários vetores.




Figura 3.5: Decomposição de um vetor em sua projeção sobre um subespaço e em um resíduo ortogonal.

3.5.2 Projeção sobre um subespaço com base ortonormal

Considere um subespaço

$$S = \text{span}\{\mathbf{q}_1, \dots, \mathbf{q}_k\} \subseteq \mathbb{R}^p,$$

em que

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$$

é uma base ortonormal de S .

A projeção de $\mathbf{x} \in \mathbb{R}^p$ sobre S é obtida somando as projeções de $\mathbf{x}$ sobre cada vetor da base:

$$\text{proj}_S(\mathbf{x}) = \sum_{j=1}^k (\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_j.$$

Como

$$(\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_j = \mathbf{q}_j \mathbf{q}_j^\top \mathbf{x},$$

tem-se

$$\text{proj}_S(\mathbf{x}) = \left(\sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top \right) \mathbf{x}.$$

Cada matriz

$$\mathbf{q}_j \mathbf{q}_j^\top$$

é o produto externo do vetor $\mathbf{q}_j$ por ele próprio. Como $\mathbf{q}_j \neq \mathbf{0}$, cada uma dessas matrizes possui posto 1 e projeta sobre a direção gerada por $\mathbf{q}_j$.

Reunindo os vetores da base na matriz

$$\mathbf{Q} = [\mathbf{q}_1 \quad \dots \quad \mathbf{q}_k] \in \mathbb{R}^{p \times k},$$

tem-se

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k.$$

Além disso,

$$\mathbf{Q}\mathbf{Q}^\top = \sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top.$$

Portanto,

$$\text{proj}_S(\mathbf{x}) = \mathbf{Q}\mathbf{Q}^\top \mathbf{x}.$$

Proposição 3.14 (Projeção sobre uma base ortonormal). *Se as colunas de*

$$\mathbf{Q} \in \mathbb{R}^{p \times k}$$

formam uma base ortonormal de S , então

$$\text{proj}_S(\mathbf{x}) = \mathbf{Q}\mathbf{Q}^\top \mathbf{x}.$$

A matriz de projeção sobre S é

$$\mathbf{P}_S = \mathbf{Q}\mathbf{Q}^\top = \sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top.$$

(Meyer, 2023)

O vetor

$$\mathbf{Q}^\top \mathbf{x} = \begin{bmatrix} \mathbf{q}_1^\top \mathbf{x} \\ \vdots \\ \mathbf{q}_k^\top \mathbf{x} \end{bmatrix}$$

contém as coordenadas da projeção de $\mathbf{x}$ na base ortonormal de S . A multiplicação por $\mathbf{Q}$ utiliza essas coordenadas para reconstruir o vetor projetado no espaço original:

$$\mathbf{x} \xrightarrow{\mathbf{Q}^\top} \mathbf{Q}^\top \mathbf{x} \xrightarrow{\mathbf{Q}} \mathbf{Q}\mathbf{Q}^\top \mathbf{x}.$$

Assim, $\mathbf{Q}^\top$ obtém as coordenadas no subespaço, enquanto $\mathbf{Q}$ reconstrói o vetor correspondente em $\mathbb{R}^p$.

Exemplo 3.23 (Projeção sobre um plano). Considere o subespaço

$$S = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \right\} \subseteq \mathbb{R}^3.$$

Uma base ortonormal de S é formada por

$$\mathbf{q}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} \quad \text{e} \quad \mathbf{q}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}.$$

Assim,

$$\mathbf{Q} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}.$$

A matriz de projeção é

$$\begin{aligned} \mathbf{P}_S &= \mathbf{Q}\mathbf{Q}^\top \\ &= \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}. \end{aligned}$$

Equivalentemente,

$$\mathbf{P}_S = \mathbf{q}_1\mathbf{q}_1^\top + \mathbf{q}_2\mathbf{q}_2^\top.$$

Para

$$\mathbf{x} = \begin{bmatrix} 2 \\ -1 \\ 3 \end{bmatrix},$$

tem-se

$$\text{proj}_S(\mathbf{x}) = \mathbf{P}_S \mathbf{x} = \begin{bmatrix} 2 \\ -1 \\ 0 \end{bmatrix}.$$

O resíduo é

$$\mathbf{r} = \mathbf{x} - \text{proj}_S(\mathbf{x}) = \begin{bmatrix} 0 \\ 0 \\ 3 \end{bmatrix},$$

que pertence a $S^\perp$.

3.5.3 Projeção sobre o espaço coluna de uma matriz

Considere vetores linearmente independentes

$$\mathbf{a}_1, \dots, \mathbf{a}_k \in \mathbb{R}^p$$

e a matriz formada por esses vetores:

$$\mathbf{A} = [\mathbf{a}_1 \quad \dots \quad \mathbf{a}_k] \in \mathbb{R}^{p \times k}.$$

Como os vetores foram previamente nomeados e depois reunidos em $\mathbf{A}$, a notação $\mathbf{a}_1, \dots, \mathbf{a}_k$ será mantida nesta subseção.

O subespaço gerado pelas colunas de $\mathbf{A}$ é

$$S = \mathcal{C}(\mathbf{A}) = \text{span}\{\mathbf{a}_1, \dots, \mathbf{a}_k\}.$$

A projeção de $\mathbf{x} \in \mathbb{R}^p$ sobre S deve pertencer ao espaço coluna de $\mathbf{A}$. Portanto, possui a forma

$$\hat{\mathbf{x}} = \mathbf{A}\mathbf{c},$$

para algum vetor de coeficientes

$$\mathbf{c} \in \mathbb{R}^k.$$

O resíduo

$$\mathbf{r} = \mathbf{x} - \mathbf{A}\mathbf{c}$$

deve pertencer ao complemento ortogonal de $\mathcal{C}(\mathbf{A})$. Assim, ele deve ser ortogonal a todas as colunas de $\mathbf{A}$:

$$\mathbf{A}^\top (\mathbf{x} - \mathbf{A}\mathbf{c}) = \mathbf{0}.$$

Desenvolvendo,

$$\mathbf{A}^\top \mathbf{x} - \mathbf{A}^\top \mathbf{A}\mathbf{c} = \mathbf{0},$$

de modo que

$$\mathbf{A}^\top \mathbf{A}\mathbf{c} = \mathbf{A}^\top \mathbf{x}.$$

A matriz

$$\mathbf{A}^\top \mathbf{A}$$

é a matriz de Gram das colunas de $\mathbf{A}$. Como essas colunas são linearmente independentes, $\mathbf{A}^\top \mathbf{A}$ é positiva definida e, portanto, invertível.

Assim,

$$\mathbf{c} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x}.$$

Substituindo em

$$\hat{\mathbf{x}} = \mathbf{A}\mathbf{c},$$

obtém-se

$$\hat{\mathbf{x}} = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x}.$$

Proposição 3.15 (Projeção sobre o espaço coluna). *Se*

$$\mathbf{A} \in \mathbb{R}^{p \times k}$$

possui colunas linearmente independentes, a projeção ortogonal de $\mathbf{x} \in \mathbb{R}^p$ sobre $\mathcal{C}(\mathbf{A})$ é

$$\text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}) = \mathbf{P}_{\mathbf{A}} \mathbf{x},$$

em que

$$\mathbf{P}_{\mathbf{A}} = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

A matriz $\mathbf{P}_{\mathbf{A}}$ depende apenas do subespaço gerado pelas colunas de $\mathbf{A}$, e não da base particular escolhida para representá-lo.

De fato, suponha que outra base do mesmo subespaço seja organizada em uma matriz

$$\mathbf{B} = \mathbf{A} \mathbf{R},$$

em que $\mathbf{R} \in \mathbb{R}^{k \times k}$ é invertível. Então

$$\begin{aligned} \mathbf{P}_{\mathbf{B}} &= \mathbf{B} (\mathbf{B}^\top \mathbf{B})^{-1} \mathbf{B}^\top \\ &= \mathbf{A} \mathbf{R} (\mathbf{R}^\top \mathbf{A}^\top \mathbf{A} \mathbf{R})^{-1} \mathbf{R}^\top \mathbf{A}^\top \\ &= \mathbf{A} \mathbf{R} \mathbf{R}^{-1} (\mathbf{A}^\top \mathbf{A})^{-1} (\mathbf{R}^\top)^{-1} \mathbf{R}^\top \mathbf{A}^\top \\ &= \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \\ &= \mathbf{P}_{\mathbf{A}}. \end{aligned}$$

Portanto, bases diferentes do mesmo subespaço produzem a mesma matriz de projeção ortogonal.

Quando as colunas de $\mathbf{A}$ são ortonormais,

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_k,$$

e a expressão reduz-se a

$$\mathbf{P}_{\mathbf{A}} = \mathbf{A} \mathbf{A}^\top.$$

Esse é exatamente o resultado obtido anteriormente para uma matriz $\mathbf{Q}$ cujas colunas formam uma base ortonormal:

$$\mathbf{P}_S = \mathbf{Q}\mathbf{Q}^\top.$$

Portanto,

$$\mathbf{Q}\mathbf{Q}^\top$$

é o caso ortonormal da expressão geral

$$\mathbf{A}(\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

Exemplo 3.24 (Projeção utilizando uma base não ortogonal). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}.$$

As colunas de $\mathbf{A}$ são linearmente independentes. A matriz de Gram é

$$\mathbf{A}^\top \mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix},$$

cuja inversa é

$$(\mathbf{A}^\top \mathbf{A})^{-1} = \frac{1}{3} \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}.$$

Além disso,

$$\mathbf{A}^\top \mathbf{x} = \begin{bmatrix} 3 \\ 5 \end{bmatrix}.$$

Os coeficientes da projeção são

$$\begin{aligned}
\mathbf{c} &= (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x} \\
&= \frac{1}{3} \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} \begin{bmatrix} 3 \\ 5 \end{bmatrix} \\
&= \frac{1}{3} \begin{bmatrix} 1 \\ 7 \end{bmatrix}.
\end{aligned}$$

Portanto,

$$\begin{aligned}
\text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}) &= \mathbf{A}\mathbf{c} \\
&= \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1/3 \\ 7/3 \end{bmatrix} \\
&= \begin{bmatrix} 1/3 \\ 8/3 \\ 7/3 \end{bmatrix}.
\end{aligned}$$

O resíduo é

$$\mathbf{r} = \mathbf{x} - \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}) = \begin{bmatrix} 2/3 \\ -2/3 \\ 2/3 \end{bmatrix}.$$

A ortogonalidade pode ser verificada por

$$\mathbf{A}^\top \mathbf{r} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

Logo,

$$\mathbf{r} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

3.5.4 Propriedades da matriz de projeção

Proposição 3.16 (Propriedades da matriz de projeção). *Se*

$$\mathbf{A} \in \mathbb{R}^{p \times k}$$

possui colunas linearmente independentes e

$$\mathbf{P}_{\mathbf{A}} = \mathbf{A} (\mathbf{A}^{\top} \mathbf{A})^{-1} \mathbf{A}^{\top},$$

então:

1. $\mathbf{P}_{\mathbf{A}}$ é simétrica;
2. $\mathbf{P}_{\mathbf{A}}$ é idempotente;
3. $\mathcal{C}(\mathbf{P}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})$;
4. $\mathcal{N}(\mathbf{P}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})^{\perp} = \mathcal{N}(\mathbf{A}^{\top})$;
5. $\text{posto}(\mathbf{P}_{\mathbf{A}}) = \text{posto}(\mathbf{A}) = k$.

Comprovação. A simetria decorre de

$$\begin{aligned} \mathbf{P}_{\mathbf{A}}^{\top} &= \left[\mathbf{A} (\mathbf{A}^{\top} \mathbf{A})^{-1} \mathbf{A}^{\top} \right]^{\top} \\ &= \mathbf{A} \left[(\mathbf{A}^{\top} \mathbf{A})^{-1} \right]^{\top} \mathbf{A}^{\top} \\ &= \mathbf{A} (\mathbf{A}^{\top} \mathbf{A})^{-1} \mathbf{A}^{\top} \\ &= \mathbf{P}_{\mathbf{A}}, \end{aligned}$$

pois $\mathbf{A}^{\top} \mathbf{A}$ e sua inversa são simétricas.

Para verificar a idempotência,

$$\begin{aligned} \mathbf{P}_{\mathbf{A}}^2 &= \mathbf{A} (\mathbf{A}^{\top} \mathbf{A})^{-1} \mathbf{A}^{\top} \mathbf{A} (\mathbf{A}^{\top} \mathbf{A})^{-1} \mathbf{A}^{\top} \\ &= \mathbf{A} (\mathbf{A}^{\top} \mathbf{A})^{-1} \mathbf{A}^{\top} \\ &= \mathbf{P}_{\mathbf{A}}. \end{aligned}$$

Para determinar o espaço coluna, observe inicialmente que, para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\mathbf{P}_{\mathbf{A}} \mathbf{x} = \mathbf{A} \left[(\mathbf{A}^{\top} \mathbf{A})^{-1} \mathbf{A}^{\top} \mathbf{x} \right].$$

Portanto,

$$\mathbf{P}_{\mathbf{A}} \mathbf{x} \in \mathcal{C}(\mathbf{A}),$$

e, consequentemente,

$$\mathcal{C}(\mathbf{P}_{\mathbf{A}}) \subseteq \mathcal{C}(\mathbf{A}).$$

Reciprocamente, se

$$\mathbf{y} \in \mathcal{C}(\mathbf{A}),$$

então existe $\mathbf{c} \in \mathbb{R}^k$ tal que

$$\mathbf{y} = \mathbf{A}\mathbf{c}.$$

Assim,

$$\begin{aligned}\mathbf{P}_\mathbf{A}\mathbf{y} &= \mathbf{A}(\mathbf{A}^\top\mathbf{A})^{-1}\mathbf{A}^\top\mathbf{A}\mathbf{c} \\ &= \mathbf{A}\mathbf{c} \\ &= \mathbf{y}.\end{aligned}$$

Logo,

$$\mathcal{C}(\mathbf{A}) \subseteq \mathcal{C}(\mathbf{P}_\mathbf{A}),$$

e, portanto,

$$\mathcal{C}(\mathbf{P}_\mathbf{A}) = \mathcal{C}(\mathbf{A}).$$

Para determinar o espaço nulo, observe que

$$\begin{aligned}\mathbf{A}^\top\mathbf{P}_\mathbf{A} &= \mathbf{A}^\top\mathbf{A}(\mathbf{A}^\top\mathbf{A})^{-1}\mathbf{A}^\top \\ &= \mathbf{A}^\top.\end{aligned}$$

Se

$$\mathbf{x} \in \mathcal{N}(\mathbf{P}_\mathbf{A}),$$

então

$$\mathbf{P}_\mathbf{A}\mathbf{x} = \mathbf{0},$$

e, portanto,

$$\mathbf{A}^\top\mathbf{x} = \mathbf{A}^\top\mathbf{P}_\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Logo,

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Reciprocamente, se

$$\mathbf{x} \in \mathcal{C}(\mathbf{A})^\perp,$$

então

$$\mathbf{A}^\top \mathbf{x} = \mathbf{0},$$

e, conseqüentemente,

$$\mathbf{P}_\mathbf{A} \mathbf{x} = \mathbf{0}.$$

Assim,

$$\mathcal{N}(\mathbf{P}_\mathbf{A}) = \mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top).$$

Finalmente, como

$$\mathcal{C}(\mathbf{P}_\mathbf{A}) = \mathcal{C}(\mathbf{A}),$$

tem-se

$$\text{posto}(\mathbf{P}_\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Como as k colunas de $\mathbf{A}$ são linearmente independentes,

$$\text{posto}(\mathbf{A}) = k.$$

Portanto,

$$\text{posto}(\mathbf{P}_\mathbf{A}) = k.$$

□

A idempotência possui uma interpretação direta: depois que um vetor foi projetado sobre $\mathcal{C}(\mathbf{A})$, uma nova aplicação da mesma projeção não o modifica:

$$\mathbf{P}_{\mathbf{A}} (\mathbf{P}_{\mathbf{A}} \mathbf{x}) = \mathbf{P}_{\mathbf{A}} \mathbf{x}.$$

Além disso, a igualdade

$$\mathcal{N}(\mathbf{P}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})^{\perp}$$

mostra que a projeção anula exatamente a componente de $\mathbf{x}$ ortogonal ao subespaço projetado.

3.5.5 Aprofundamento: projeção residual e complemento ortogonal

Leitura de aprofundamento

Esta seção desenvolve a matriz que projeta um vetor sobre o complemento ortogonal de um subespaço. Essa representação será retomada no estudo de mínimos quadrados, da Decomposição em Valores Singulares e do modelo linear multivariado.

Considere

$$\mathbf{A} \in \mathbb{R}^{p \times k}$$

com colunas linearmente independentes e seja

$$\mathbf{P}_{\mathbf{A}}$$

a matriz de projeção ortogonal sobre $\mathcal{C}(\mathbf{A})$.

A componente de $\mathbf{x} \in \mathbb{R}^p$ que permanece fora desse subespaço é o resíduo

$$\mathbf{r} = \mathbf{x} - \mathbf{P}_{\mathbf{A}} \mathbf{x}.$$

Definindo

$$\mathbf{M}_{\mathbf{A}} = \mathbf{I}_p - \mathbf{P}_{\mathbf{A}},$$

tem-se

$$\mathbf{r} = \mathbf{M}_{\mathbf{A}}\mathbf{x}.$$

Definição 3.20 (Matriz de projeção residual). A matriz

$$\mathbf{M}_{\mathbf{A}} = \mathbf{I}_p - \mathbf{P}_{\mathbf{A}}$$

é denominada **matriz de projeção residual**. Ela realiza a projeção ortogonal sobre

$$\mathcal{C}(\mathbf{A})^\perp.$$

Como

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top),$$

a matriz $\mathbf{M}_{\mathbf{A}}$ também pode ser interpretada como a matriz de projeção ortogonal sobre o espaço nulo à esquerda de $\mathbf{A}$.

A decomposição ortogonal de $\mathbf{x}$ pode ser escrita como

$$\mathbf{x} = \mathbf{P}_{\mathbf{A}}\mathbf{x} + \mathbf{M}_{\mathbf{A}}\mathbf{x},$$

em que

$$\mathbf{P}_{\mathbf{A}}\mathbf{x} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{M}_{\mathbf{A}}\mathbf{x} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Como essas duas componentes são ortogonais,

$$(\mathbf{P}_{\mathbf{A}}\mathbf{x})^\top (\mathbf{M}_{\mathbf{A}}\mathbf{x}) = 0.$$

Consequentemente, pelo Teorema de Pitágoras,

$$\|\mathbf{x}\|^2 = \|\mathbf{P}_{\mathbf{A}}\mathbf{x}\|^2 + \|\mathbf{M}_{\mathbf{A}}\mathbf{x}\|^2.$$

Proposição 3.17 (Propriedades da matriz de projeção residual). *Se*

$$\mathbf{M}_{\mathbf{A}} = \mathbf{I}_p - \mathbf{P}_{\mathbf{A}},$$

então:

1. $\mathbf{M}_{\mathbf{A}}$ é simétrica;
2. $\mathbf{M}_{\mathbf{A}}$ é idempotente;
3. $\mathbf{P}_{\mathbf{A}}\mathbf{M}_{\mathbf{A}} = \mathbf{0}$ e $\mathbf{M}_{\mathbf{A}}\mathbf{P}_{\mathbf{A}} = \mathbf{0}$;
4. $\mathcal{C}(\mathbf{M}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top)$;
5. $\mathcal{N}(\mathbf{M}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})$;
6. se $\mathbf{A}$ possui posto k , então $\text{posto}(\mathbf{M}_{\mathbf{A}}) = p - k$.

Comprovação. Como $\mathbf{P}_{\mathbf{A}}$ é simétrica,

$$\begin{aligned}\mathbf{M}_{\mathbf{A}}^\top &= (\mathbf{I}_p - \mathbf{P}_{\mathbf{A}})^\top \\ &= \mathbf{I}_p - \mathbf{P}_{\mathbf{A}}^\top \\ &= \mathbf{I}_p - \mathbf{P}_{\mathbf{A}} \\ &= \mathbf{M}_{\mathbf{A}}.\end{aligned}$$

Portanto, $\mathbf{M}_{\mathbf{A}}$ é simétrica.

Para verificar a idempotência,

$$\begin{aligned}\mathbf{M}_{\mathbf{A}}^2 &= (\mathbf{I}_p - \mathbf{P}_{\mathbf{A}})^2 \\ &= \mathbf{I}_p - 2\mathbf{P}_{\mathbf{A}} + \mathbf{P}_{\mathbf{A}}^2 \\ &= \mathbf{I}_p - \mathbf{P}_{\mathbf{A}} \\ &= \mathbf{M}_{\mathbf{A}},\end{aligned}$$

pois

$$\mathbf{P}_{\mathbf{A}}^2 = \mathbf{P}_{\mathbf{A}}.$$

Além disso,

$$\begin{aligned}\mathbf{P}_A \mathbf{M}_A &= \mathbf{P}_A (\mathbf{I}_p - \mathbf{P}_A) \\ &= \mathbf{P}_A - \mathbf{P}_A^2 \\ &= \mathbf{0},\end{aligned}$$

e, de forma análoga,

$$\mathbf{M}_A \mathbf{P}_A = \mathbf{0}.$$

Para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\mathbf{P}_A \mathbf{M}_A \mathbf{x} = \mathbf{0}.$$

Logo,

$$\mathbf{M}_A \mathbf{x} \in \mathcal{N}(\mathbf{P}_A).$$

Como

$$\mathcal{N}(\mathbf{P}_A) = \mathcal{C}(\mathbf{A})^\perp,$$

tem-se

$$\mathcal{C}(\mathbf{M}_A) \subseteq \mathcal{C}(\mathbf{A})^\perp.$$

Reciprocamente, se

$$\mathbf{y} \in \mathcal{C}(\mathbf{A})^\perp,$$

então

$$\mathbf{P}_A \mathbf{y} = \mathbf{0},$$

e, portanto,

$$\begin{aligned}\mathbf{M}_A \mathbf{y} &= (\mathbf{I}_p - \mathbf{P}_A) \mathbf{y} \\ &= \mathbf{y}.\end{aligned}$$

Assim,

$$\mathcal{C}(\mathbf{A})^\perp \subseteq \mathcal{C}(\mathbf{M}_\mathbf{A}),$$

e

$$\mathcal{C}(\mathbf{M}_\mathbf{A}) = \mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top).$$

Agora, se

$$\mathbf{x} \in \mathcal{C}(\mathbf{A}),$$

então

$$\mathbf{P}_\mathbf{A} \mathbf{x} = \mathbf{x}.$$

Consequentemente,

$$\mathbf{M}_\mathbf{A} \mathbf{x} = \mathbf{0},$$

e

$$\mathcal{C}(\mathbf{A}) \subseteq \mathcal{N}(\mathbf{M}_\mathbf{A}).$$

Reciprocamente, se

$$\mathbf{x} \in \mathcal{N}(\mathbf{M}_\mathbf{A}),$$

então

$$(\mathbf{I}_p - \mathbf{P}_\mathbf{A}) \mathbf{x} = \mathbf{0},$$

de modo que

$$\mathbf{x} = \mathbf{P}_\mathbf{A} \mathbf{x}.$$

Como

$$\mathbf{P}_\mathbf{A} \mathbf{x} \in \mathcal{C}(\mathbf{A}),$$

segue que

$$\mathbf{x} \in \mathcal{C}(\mathbf{A}).$$

Portanto,

$$\mathcal{N}(\mathbf{M}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}).$$

Finalmente,

$$\mathcal{C}(\mathbf{M}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})^\perp.$$

Como

$$\dim \mathcal{C}(\mathbf{A}) = k,$$

o teorema da dimensão do complemento ortogonal fornece

$$\dim \mathcal{C}(\mathbf{M}_{\mathbf{A}}) = p - k.$$

Logo,

$$\text{posto}(\mathbf{M}_{\mathbf{A}}) = p - k.$$

□

3.5.6 Projeção como melhor aproximação

A projeção ortogonal pode ser caracterizada por uma propriedade de otimização: entre todos os vetores de um subespaço, ela é o único vetor que possui a menor distância até o vetor original.

Teorema 3.8 (Teorema da melhor aproximação). *Seja S um subespaço de $\mathbb{R}^p$ e seja*

$$\hat{\mathbf{x}} = \text{proj}_S(\mathbf{x}).$$

Então, para qualquer $\mathbf{y} \in S$,

$$\|\mathbf{x} - \hat{\mathbf{x}}\| \leq \|\mathbf{x} - \mathbf{y}\|.$$

A igualdade ocorre se, e somente se,

$$\mathbf{y} = \hat{\mathbf{x}}.$$

(Meyer, 2023)

Comprovação. Como

$$\hat{\mathbf{x}} \in S$$

e

$$\mathbf{y} \in S,$$

tem-se

$$\hat{\mathbf{x}} - \mathbf{y} \in S.$$

Por outro lado, como $\hat{\mathbf{x}}$ é a projeção ortogonal de $\mathbf{x}$ sobre S , o resíduo

$$\mathbf{x} - \hat{\mathbf{x}}$$

pertence a $S^\perp$.

Portanto,

$$\mathbf{x} - \hat{\mathbf{x}}$$

e

$$\hat{\mathbf{x}} - \mathbf{y}$$

são ortogonais.

Escrevendo

$$\mathbf{x} - \mathbf{y} = (\mathbf{x} - \hat{\mathbf{x}}) + (\hat{\mathbf{x}} - \mathbf{y}),$$

o Teorema de Pitágoras fornece

$$\|\mathbf{x} - \mathbf{y}\|^2 = \|\mathbf{x} - \hat{\mathbf{x}}\|^2 + \|\hat{\mathbf{x}} - \mathbf{y}\|^2.$$

Como

$$\|\hat{\mathbf{x}} - \mathbf{y}\|^2 \geq 0,$$

segue que

$$\|\mathbf{x} - \mathbf{y}\|^2 \geq \|\mathbf{x} - \hat{\mathbf{x}}\|^2.$$

A igualdade ocorre se, e somente se,

$$\|\hat{\mathbf{x}} - \mathbf{y}\|^2 = 0,$$

isto é,

$$\mathbf{y} = \hat{\mathbf{x}}.$$

□

Portanto, a projeção ortogonal pode ser caracterizada equivalentemente como

$$\text{proj}_S(\mathbf{x}) = \underset{\mathbf{y} \in S}{\text{argmin}} \|\mathbf{x} - \mathbf{y}\|^2.$$

Assim, projetar ortogonalmente $\mathbf{x}$ sobre S equivale a encontrar, entre todos os vetores pertencentes a S , aquele que está mais próximo de $\mathbf{x}$ segundo a distância euclidiana.

Quando $S = \mathcal{C}(\mathbf{A})$, com $\mathbf{A} \in \mathbb{R}^{p \times k}$, todo vetor de S pode ser escrito como

$$\mathbf{y} = \mathbf{A}\mathbf{c}, \quad \mathbf{c} \in \mathbb{R}^k.$$

Consequentemente, o problema de melhor aproximação pode ser escrito como

$$\hat{\mathbf{c}} \in \underset{\mathbf{c} \in \mathbb{R}^k}{\text{argmin}} \|\mathbf{x} - \mathbf{A}\mathbf{c}\|^2,$$

e o vetor mais próximo de $\mathbf{x}$ em $\mathcal{C}(\mathbf{A})$ é

$$\hat{\mathbf{x}} = \mathbf{A}\hat{\mathbf{c}} = \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}).$$

Essa formulação estabelece a ligação entre projeção ortogonal e mínimos quadrados. O desenvolvimento algébrico dessa relação é apresentado a seguir como aprofundamento.

3.5.7 Aprofundamento: projeções e mínimos quadrados

Leitura de aprofundamento

Esta seção desenvolve algebricamente a relação entre projeção ortogonal e mínimos quadrados. As equações normais, os resíduos, as matrizes de projeção e a pseudoinversa serão retomados na Decomposição em Valores Singulares e no modelo linear multivariado.

Considere

$$\mathbf{A} \in \mathbb{R}^{n \times k}$$

e

$$\mathbf{b} \in \mathbb{R}^n.$$

O sistema

$$\mathbf{A}\beta = \mathbf{b}, \quad \beta \in \mathbb{R}^k,$$

possui solução exata se, e somente se,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Quando

$$\mathbf{b} \notin \mathcal{C}(\mathbf{A}),$$

não existe vetor β capaz de reproduzir exatamente $\mathbf{b}$. Nesse caso, procura-se a combinação linear das colunas de $\mathbf{A}$ que mais se aproxima de $\mathbf{b}$ no sentido da distância euclidiana.

O problema de mínimos quadrados é

$$\hat{\beta} \in \operatorname{argmin}_{\beta \in \mathbb{R}^k} \|\mathbf{b} - \mathbf{A}\beta\|^2.$$

Pelo Teorema 3.8, o vetor ajustado

$$\hat{\mathbf{b}} = \mathbf{A}\hat{\beta}$$

é a projeção ortogonal de $\mathbf{b}$ sobre o espaço coluna de $\mathbf{A}$:

$$\hat{\mathbf{b}} = \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{b}).$$

O vetor de resíduos é

$$\hat{\mathbf{e}} = \mathbf{b} - \hat{\mathbf{b}} = \mathbf{b} - \mathbf{A}\hat{\beta}.$$

Como a projeção é ortogonal,

$$\hat{\mathbf{e}} \in \mathcal{C}(\mathbf{A})^\perp.$$

Pela relação entre os espaços fundamentais,

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top),$$

portanto

$$\hat{\mathbf{e}} \in \mathcal{N}(\mathbf{A}^\top).$$

Consequentemente,

$$\mathbf{A}^\top \hat{\mathbf{e}} = \mathbf{0}.$$

Substituindo

$$\hat{\mathbf{e}} = \mathbf{b} - \mathbf{A}\hat{\beta},$$

obtém-se

$$\mathbf{A}^\top (\mathbf{b} - \mathbf{A}\hat{\beta}) = \mathbf{0},$$

e, portanto,

$$\mathbf{A}^\top \mathbf{A}\hat{\beta} = \mathbf{A}^\top \mathbf{b}.$$

Definição 3.21 (Equações normais). As equações

$$\mathbf{A}^\top \mathbf{A} \hat{\boldsymbol{\beta}} = \mathbf{A}^\top \mathbf{b}$$

são denominadas **equações normais** do problema de mínimos quadrados.

Se as colunas de $\mathbf{A}$ são linearmente independentes, então

$$\text{posto}(\mathbf{A}) = k$$

e a matriz de Gram

$$\mathbf{A}^\top \mathbf{A}$$

é positiva definida e invertível. Nesse caso, as equações normais possuem solução única:

$$\hat{\boldsymbol{\beta}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

O vetor ajustado pode então ser escrito como

$$\begin{aligned} \hat{\mathbf{b}} &= \mathbf{A} \hat{\boldsymbol{\beta}} \\ &= \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b} \\ &= \mathbf{P}_\mathbf{A} \mathbf{b}, \end{aligned}$$

enquanto o vetor de resíduos é

$$\begin{aligned} \hat{\mathbf{e}} &= \mathbf{b} - \hat{\mathbf{b}} \\ &= (\mathbf{I}_n - \mathbf{P}_\mathbf{A}) \mathbf{b} \\ &= \mathbf{M}_\mathbf{A} \mathbf{b}. \end{aligned}$$

Aqui,

$$\mathbf{P}_\mathbf{A} = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \in \mathbb{R}^{n \times n}$$

projeta sobre $\mathcal{C}(\mathbf{A})$, enquanto

$$\mathbf{M}_\mathbf{A} = \mathbf{I}_n - \mathbf{P}_\mathbf{A} \in \mathbb{R}^{n \times n}$$

projeta sobre

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Proposição 3.18 (Decomposição de mínimos quadrados). *No problema de mínimos quadrados,*

$$\mathbf{b} = \hat{\mathbf{b}} + \hat{\mathbf{e}},$$

em que

$$\hat{\mathbf{b}} \in \mathcal{C}(\mathbf{A})$$

e

$$\hat{\mathbf{e}} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Consequentemente,

$$\hat{\mathbf{b}}^\top \hat{\mathbf{e}} = 0$$

e

$$\|\mathbf{b}\|^2 = \|\hat{\mathbf{b}}\|^2 + \|\hat{\mathbf{e}}\|^2.$$

(Golub; Van Loan, 2013)

Essa decomposição é a aplicação direta da decomposição ortogonal

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top)$$

ao vetor $\mathbf{b}$.

Se as colunas de $\mathbf{A}$ são linearmente dependentes, o problema de mínimos quadrados pode possuir diferentes vetores de coeficientes que produzem o mesmo ajuste. Portanto, $\hat{\beta}$ pode não ser único.

Entretanto, o vetor ajustado

$$\hat{\mathbf{b}} = \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{b})$$

permanece único, pois a projeção depende apenas do subespaço $\mathcal{C}(\mathbf{A})$.

Utilizando a pseudoinversa de Moore–Penrose (ver Definição 2.17),

$$\hat{\beta} = \mathbf{A}^+ \mathbf{b}$$

fornece, entre as soluções de mínimos quadrados, a solução de menor norma. O vetor ajustado pode ser escrito como

$$\hat{\mathbf{b}} = \mathbf{A} \mathbf{A}^+ \mathbf{b},$$

de modo que

$$\mathbf{P}_{\mathbf{A}} = \mathbf{A} \mathbf{A}^+.$$

A pseudoinversa foi introduzida no capítulo anterior. Sua construção por meio da Decomposição em Valores Singulares será desenvolvida posteriormente.

As projeções ponderadas podem ser obtidas substituindo o produto interno euclidiano por um produto interno induzido por uma matriz positiva definida. Essa extensão será retomada no estudo de problemas de mínimos quadrados ponderados.

3.6 Síntese do capítulo

Os espaços vetoriais permitem organizar conjuntos de vetores que preservam as operações de adição e multiplicação por escalar. Dentro desses espaços, os subespaços representam estruturas lineares de menor dimensão, enquanto bases fornecem conjuntos de vetores linearmente independentes capazes de gerar todo o espaço considerado. Fixada uma base, cada vetor pode ser representado de maneira única por suas coordenadas nessa base.

A dimensão quantifica o número de direções independentes necessárias para representar um espaço. Para uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

essa ideia conduz aos quatro espaços fundamentais:

$$\mathcal{C}(\mathbf{A}), \mathcal{L}(\mathbf{A}), \mathcal{N}(\mathbf{A}) \text{ e } \mathcal{N}(\mathbf{A}^\top).$$

Se $r = \text{posto}(\mathbf{A})$, suas dimensões são

$$\dim \mathcal{C}(\mathbf{A}) = \dim \mathcal{L}(\mathbf{A}) = r,$$

$$\dim \mathcal{N}(\mathbf{A}) = p - r$$

e

$$\dim \mathcal{N}(\mathbf{A}^\top) = n - r.$$

Esses espaços se organizam em pares ortogonais:

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Consequentemente,

$$\mathbb{R}^p = \mathcal{L}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A})$$

e

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top).$$

As matrizes de Gram organizam produtos internos entre conjuntos de vetores. Para uma matriz $\mathbf{V}$,

$$\mathbf{G} = \mathbf{V}^\top \mathbf{V}$$

é simétrica e semidefinida positiva, e sua estrutura permite relacionar produtos internos, independência linear e posto.

A decomposição ortogonal estabelece que, para qualquer subespaço $S \subseteq \mathbb{R}^p$, todo vetor pode ser escrito de maneira única como

$$\mathbf{x} = \text{proj}_S(\mathbf{x}) + \mathbf{x}_{S^\perp},$$

com $\text{proj}_S(\mathbf{x}) \in S$ e $\mathbf{x}_{S^\perp} \in S^\perp$.

Se as colunas de $\mathbf{Q}$ formam uma base ortonormal de S , a matriz de projeção é

$$\mathbf{P}_S = \mathbf{Q}\mathbf{Q}^\top = \sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top.$$

Se $S = \mathcal{C}(\mathbf{A})$ e as colunas de $\mathbf{A}$ são linearmente independentes, a mesma projeção pode ser escrita como

$$\mathbf{P}_A = \mathbf{A}(\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

A projeção ortogonal possui ainda uma interpretação por otimização:

$$\text{proj}_S(\mathbf{x}) = \underset{\mathbf{y} \in S}{\text{argmin}} \|\mathbf{x} - \mathbf{y}\|^2.$$

Essa propriedade estabelece a ligação entre geometria, projeções e problemas de mínimos quadrados.

As partes de aprofundamento generalizam a geometria euclidiana por meio de produtos internos induzidos por matrizes positivas definidas e desenvolvem a matriz de projeção residual, as equações normais, o caso de posto deficiente e a pseudoinversa. Esses resultados serão retomados quando sua utilização se tornar necessária nos capítulos posteriores.

Ao final deste capítulo, o estudante deverá ser capaz de:

- verificar se um conjunto é um subespaço vetorial;
- interpretar geração, dependência e independência linear;
- identificar bases e determinar dimensões;
- representar vetores por coordenadas em uma base;
- distinguir bases gerais, ortogonais e ortonormais;
- determinar e interpretar os quatro espaços fundamentais de uma matriz;
- relacionar posto, nulidade e dimensão;
- interpretar as relações de ortogonalidade entre os espaços fundamentais;
- construir e interpretar matrizes de Gram;
- determinar complementos ortogonais e decomposições ortogonais;
- calcular projeções sobre direções e subespaços;
- interpretar a projeção ortogonal como problema de melhor aproximação;
- reconhecer a relação geométrica entre projeções e mínimos quadrados.

No próximo capítulo, as matrizes serão estudadas como representações de transformações lineares entre espaços vetoriais. Os conceitos de base, dimensão, posto, espaços fundamentais e projeções desenvolvidos aqui permitirão interpretar como essas transformações atuam sobre vetores e subespaços. O espaço nulo e o espaço coluna também serão relacionados, nesse novo contexto, ao núcleo e à imagem da transformação associada a uma matriz.

4 Transformações lineares

Os capítulos anteriores apresentaram vetores, matrizes, espaços vetoriais, bases e projeções. Esses objetos permitem representar observações multivariadas e descrever relações lineares entre suas coordenadas.

Uma matriz também pode representar uma aplicação que transforma vetores. Essa aplicação pode alterar a orientação, a escala ou a dimensão da configuração original. Quando preserva combinações lineares, ela é denominada **transformação linear**.

No capítulo anterior, o espaço nulo e o espaço coluna foram definidos diretamente a partir de uma matriz. Neste capítulo, essas estruturas serão também interpretadas, respectivamente, como o núcleo e a imagem da transformação linear associada à matriz.

Este capítulo desenvolve a definição e a representação matricial das transformações lineares, sua aplicação a matrizes de dados, a composição de operações, a invertibilidade e a perda de informação. Também são estudadas transformações geométricas, transformações ortogonais, mudanças de coordenadas e transformações afins utilizadas no pré-processamento de dados.

Convenções para transformações lineares

As convenções vetoriais e matriciais estabelecidas nos capítulos anteriores permanecem válidas. Neste capítulo, serão utilizadas também as seguintes convenções:

- $T : V \rightarrow W$ representa uma transformação entre os espaços vetoriais V e W ;
- V representa o domínio e W o contradomínio da transformação;
- $\mathbf{x} \in V$ representa um vetor do domínio e $T(\mathbf{x}) \in W$ sua imagem pela transformação;
- $T_{\mathbf{A}}$ representa a transformação linear associada à matriz $\mathbf{A}$;
- $\mathbf{A} \in \mathbb{R}^{q \times p}$ representa uma transformação de $\mathbb{R}^p$ em $\mathbb{R}^q$ quando utilizada na forma $T_{\mathbf{A}}(\mathbf{x}) = \mathbf{Ax}$;
- $\ker(T)$ representa o núcleo de uma transformação linear;
- $\text{Im}(T)$ representa a imagem de uma transformação linear;
- $\mathcal{E}_p$ representa a base canônica de $\mathbb{R}^p$;
- $[T]_{\mathcal{C} \leftarrow \mathcal{B}}$ representa a matriz de uma transformação em relação a uma base $\mathcal{B}$ do domínio e a uma base $\mathcal{C}$ do contradomínio.

As relações entre essas notações e os espaços fundamentais das matrizes serão estabelecidas ao longo do capítulo.

4.1 Transformações lineares e representação matricial

Uma aplicação entre espaços vetoriais associa a cada vetor do domínio um vetor do contradomínio. A linearidade exige que essa aplicação preserve as operações de adição e multiplicação por escalar.

Definição 4.1 (Transformação linear). Sejam V e W espaços vetoriais reais. Uma aplicação

$$T : V \longrightarrow W$$

é uma **transformação linear** quando, para quaisquer vetores $\mathbf{u}, \mathbf{v} \in V$ e escalares $\alpha, \beta \in \mathbb{R}$,

$$T(\alpha\mathbf{u} + \beta\mathbf{v}) = \alpha T(\mathbf{u}) + \beta T(\mathbf{v}).$$

Tomando $\alpha = \beta = 1$, obtém-se a preservação da soma:

$$T(\mathbf{u} + \mathbf{v}) = T(\mathbf{u}) + T(\mathbf{v}).$$

Tomando $\beta = 0$, obtém-se a preservação da multiplicação por escalar:

$$T(\alpha\mathbf{u}) = \alpha T(\mathbf{u}).$$

Assim, a imagem de uma combinação linear é a combinação linear das imagens:

$$T\left(\sum_{j=1}^k \alpha_j \mathbf{v}_j\right) = \sum_{j=1}^k \alpha_j T(\mathbf{v}_j).$$

A Figura 4.1 representa a preservação da soma. O paralelogramo formado pelos vetores originais é transformado em outro paralelogramo cujos lados são as imagens desses vetores.

No primeiro painel, $\mathbf{u} + \mathbf{v}$ é a diagonal do paralelogramo formado pelos vetores originais. No segundo painel, a relação

$$T(\mathbf{u} + \mathbf{v}) = T(\mathbf{u}) + T(\mathbf{v})$$

é preservada.




Figura 4.1: Preservação da soma de vetores por uma transformação linear.

Proposição 4.1 (Propriedades elementares das transformações lineares). *Se*

$$T : V \longrightarrow W$$

é uma transformação linear, então:

1. $T(\mathbf{0}) = \mathbf{0}$;
2. $T(-\mathbf{x}) = -T(\mathbf{x})$;
3. $T(\mathbf{u} - \mathbf{v}) = T(\mathbf{u}) - T(\mathbf{v})$.

(Meyer, 2023)

Comprovação. Pela homogeneidade,

$$T(\mathbf{0}) = T(0\mathbf{x}) = 0T(\mathbf{x}) = \mathbf{0}.$$

Também pela homogeneidade,

$$T(-\mathbf{x}) = T((-1)\mathbf{x}) = -T(\mathbf{x}).$$

Consequentemente,

$$\begin{aligned}
T(\mathbf{u} - \mathbf{v}) &= T(\mathbf{u} + (-\mathbf{v})) \\
&= T(\mathbf{u}) + T(-\mathbf{v}) \\
&= T(\mathbf{u}) - T(\mathbf{v}).
\end{aligned}$$

□

A igualdade $T(\mathbf{0}) = \mathbf{0}$ é uma condição necessária para a linearidade. Se uma aplicação não envia o vetor nulo ao vetor nulo, ela não é uma transformação linear.

4.1.1 Transformação determinada por uma base

Uma transformação linear é determinada por sua ação sobre os vetores de uma base do domínio.

Proposição 4.2 (Determinação de uma transformação por uma base). *Seja V um espaço vetorial de dimensão finita e seja*

$$\mathcal{B} = \{\mathbf{v}_1, \dots, \mathbf{v}_k\}$$

uma base de V . Uma transformação linear

$$T : V \longrightarrow W$$

fica completamente determinada pelos vetores

$$T(\mathbf{v}_1), \dots, T(\mathbf{v}_k).$$

(Meyer, 2023)

Comprovação. Todo vetor $\mathbf{x} \in V$ possui uma representação única na base $\mathcal{B}$:

$$\mathbf{x} = c_1 \mathbf{v}_1 + \dots + c_k \mathbf{v}_k.$$

Pela linearidade,

$$T(\mathbf{x}) = c_1 T(\mathbf{v}_1) + \dots + c_k T(\mathbf{v}_k).$$

Portanto, conhecidas as imagens dos vetores da base, a imagem de qualquer vetor do domínio fica determinada de maneira única. □

Exemplo 4.1 (Transformação determinada pelas imagens de uma base). Considere uma transformação

$$T : \mathbb{R}^2 \longrightarrow \mathbb{R}^2$$

definida sobre os vetores da base canônica por

$$T(\mathbf{e}_1) = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

e

$$T(\mathbf{e}_2) = \begin{bmatrix} -1 \\ 3 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = x_1 \mathbf{e}_1 + x_2 \mathbf{e}_2,$$

tem-se

$$\begin{aligned} T(\mathbf{x}) &= x_1 T(\mathbf{e}_1) + x_2 T(\mathbf{e}_2) \\ &= x_1 \begin{bmatrix} 2 \\ 1 \end{bmatrix} + x_2 \begin{bmatrix} -1 \\ 3 \end{bmatrix} \\ &= \begin{bmatrix} 2x_1 - x_2 \\ x_1 + 3x_2 \end{bmatrix}. \end{aligned}$$

Essa expressão pode ser escrita como

$$T(\mathbf{x}) = \begin{bmatrix} 2 & -1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

Portanto, a matriz que representa T na base canônica é

$$\mathbf{A} = \begin{bmatrix} 2 & -1 \\ 1 & 3 \end{bmatrix},$$

cujas colunas são precisamente

$$T(\mathbf{e}_1) \quad \text{e} \quad T(\mathbf{e}_2).$$

4.1.2 Representação matricial nas bases canônicas

Considere uma transformação linear

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Se

$$\mathcal{E}_p = \{\mathbf{e}_1, \dots, \mathbf{e}_p\}$$

é a base canônica de $\mathbb{R}^p$, defina

$$\mathbf{a}_j = T(\mathbf{e}_j), \quad j = 1, \dots, p.$$

Organizando esses vetores nas colunas de uma matriz, obtém-se

$$\mathbf{A} = [\mathbf{a}_1 \quad \dots \quad \mathbf{a}_p] \in \mathbb{R}^{q \times p}.$$

Para

$$\mathbf{x} = x_1 \mathbf{e}_1 + \dots + x_p \mathbf{e}_p,$$

a linearidade fornece

$$\begin{aligned} T(\mathbf{x}) &= x_1 T(\mathbf{e}_1) + \dots + x_p T(\mathbf{e}_p) \\ &= x_1 \mathbf{a}_1 + \dots + x_p \mathbf{a}_p \\ &= \mathbf{A}\mathbf{x}. \end{aligned}$$

Isso estabelece a existência de uma matriz que representa T nas bases canônicas.

Para verificar a unicidade, suponha que outra matriz

$$\mathbf{C} \in \mathbb{R}^{q \times p}$$

também satisfaça

$$T(\mathbf{x}) = \mathbf{C}\mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^p$. Aplicando essa igualdade aos vetores da base canônica,

$$\mathbf{C}\mathbf{e}_j = T(\mathbf{e}_j) = \mathbf{A}\mathbf{e}_j, \quad j = 1, \dots, p.$$

Como $\mathbf{A}\mathbf{e}_j$ e $\mathbf{C}\mathbf{e}_j$ correspondem, respectivamente, às j -ésimas colunas de $\mathbf{A}$ e $\mathbf{C}$, todas as colunas das duas matrizes são iguais. Portanto,

$$\mathbf{C} = \mathbf{A}.$$

A matriz representante de T nas bases canônicas é, assim, única.

Proposição 4.3 (Representação matricial de uma transformação linear). *Toda transformação linear*

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

pode ser representada de maneira única por uma matriz

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

tal que

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^p$.

A j -ésima coluna de $\mathbf{A}$ é a imagem do j -ésimo vetor da base canônica:

$$\mathbf{a}_j = T(\mathbf{e}_j).$$

(Meyer, 2023)

Reciprocamente, toda matriz

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

define uma transformação linear

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

por

$$T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

De fato,

$$\begin{aligned} T_{\mathbf{A}}(\alpha \mathbf{u} + \beta \mathbf{v}) &= \mathbf{A}(\alpha \mathbf{u} + \beta \mathbf{v}) \\ &= \alpha \mathbf{A}\mathbf{u} + \beta \mathbf{A}\mathbf{v} \\ &= \alpha T_{\mathbf{A}}(\mathbf{u}) + \beta T_{\mathbf{A}}(\mathbf{v}). \end{aligned}$$

A matriz apresentada nessa representação corresponde às bases canônicas do domínio e do contradomínio. A representação em bases gerais será desenvolvida posteriormente.

4.1.3 Núcleo e imagem de uma transformação linear

Dois subespaços descrevem aspectos fundamentais da ação de uma transformação linear: os vetores do domínio que são enviados ao vetor nulo e os vetores do contradomínio que podem ser obtidos pela transformação.

Definição 4.2 (Núcleo e imagem de uma transformação linear). Seja

$$T : V \longrightarrow W$$

uma transformação linear.

O **núcleo** de T é o conjunto

$$\ker(T) = \{\mathbf{x} \in V : T(\mathbf{x}) = \mathbf{0}\}.$$

A **imagem** de T é o conjunto

$$\text{Im}(T) = \{T(\mathbf{x}) : \mathbf{x} \in V\}.$$

O núcleo é um subespaço do domínio V , enquanto a imagem é um subespaço do contradomínio W .

Para a transformação matricial

$$T_{\mathbf{A}}(\mathbf{x}) = \mathbf{Ax},$$

o núcleo é

$$\begin{aligned}\ker(T_{\mathbf{A}}) &= \{\mathbf{x} \in \mathbb{R}^p : \mathbf{Ax} = \mathbf{0}\} \\ &= \mathcal{N}(\mathbf{A}),\end{aligned}$$

e a imagem é

$$\begin{aligned}\text{Im}(T_{\mathbf{A}}) &= \{\mathbf{Ax} : \mathbf{x} \in \mathbb{R}^p\} \\ &= \mathcal{C}(\mathbf{A}).\end{aligned}$$

Relação com os subespaços associados a uma matriz

O **espaço nulo** e o **espaço coluna** estudados no capítulo anterior correspondem, respectivamente, ao **núcleo** e à **imagem** da transformação linear associada à matriz $\mathbf{A}$:

$$\mathcal{N}(\mathbf{A}) = \ker(T_{\mathbf{A}}), \quad \mathcal{C}(\mathbf{A}) = \text{Im}(T_{\mathbf{A}}).$$

Se

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

o **contradomínio** é $\mathbb{R}^q$, enquanto a imagem é o subespaço efetivamente alcançado pela transformação,

$$\text{Im}(T_{\mathbf{A}}) \subseteq \mathbb{R}^q.$$

4.1.4 Imagem de um subespaço

Considere um subespaço

$$S = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\} \subseteq V.$$

Todo vetor $\mathbf{x} \in S$ possui a forma

$$\mathbf{x} = \alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k.$$

Aplicando T ,

$$T(\mathbf{x}) = \alpha_1 T(\mathbf{v}_1) + \cdots + \alpha_k T(\mathbf{v}_k).$$

Portanto,

$$T(S) = \text{span}\{T(\mathbf{v}_1), \dots, T(\mathbf{v}_k)\}.$$

A imagem de um subespaço por uma transformação linear também é um subespaço do contradomínio.

A transformação preserva as combinações lineares, mas pode reduzir a dimensão do espaço gerado. Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}.$$

Os vetores canônicos $\mathbf{e}_1$ e $\mathbf{e}_2$ são linearmente independentes, mas

$$\mathbf{A}\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{A}\mathbf{e}_2 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

A segunda direção é eliminada e a imagem da transformação possui dimensão 1. A relação entre preservação da independência linear, núcleo, posto e injetividade será desenvolvida na seção sobre invertibilidade e perda de informação.

4.2 Transformação de vetores e matrizes de dados

A representação

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x}$$

considera cada observação como um vetor-coluna. Em uma matriz de dados, as observações são organizadas nas linhas. A aplicação simultânea da transformação exige, portanto, a transposição da matriz que atua sobre cada vetor.

Considere

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p},$$

em que

$$\mathbf{x}_i \in \mathbb{R}^p, \quad i = 1, \dots, n,$$

representa a i -ésima observação.

Se

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é representada por

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

a imagem de cada observação é

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i \in \mathbb{R}^q.$$

Transpondo essa igualdade,

$$\mathbf{y}_i^\top = \mathbf{x}_i^\top \mathbf{A}^\top.$$

Proposição 4.4 (Transformação de uma matriz de dados). *Se as observações estão organizadas nas linhas de*

$$\mathbf{X} \in \mathbb{R}^{n \times p}$$

e cada observação é transformada por

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i, \quad \mathbf{A} \in \mathbb{R}^{q \times p},$$

então a matriz transformada é

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top \in \mathbb{R}^{n \times q}.$$

Comprovação. A i -ésima linha de $\mathbf{Y}$ é

$$\mathbf{x}_i^\top \mathbf{A}^\top.$$

Como

$$\mathbf{x}_i^\top \mathbf{A}^\top = (\mathbf{A} \mathbf{x}_i)^\top = \mathbf{y}_i^\top,$$

tem-se

$$\mathbf{Y} = \begin{bmatrix} \mathbf{y}_1^\top \\ \mathbf{y}_2^\top \\ \vdots \\ \mathbf{y}_n^\top \end{bmatrix} = \mathbf{X} \mathbf{A}^\top.$$

□

As dimensões da multiplicação são

$$\underbrace{\mathbf{X}}_{n \times p} \underbrace{\mathbf{A}^\top}_{p \times q} = \underbrace{\mathbf{Y}}_{n \times q}.$$

A transposição não altera a transformação definida sobre vetores-coluna. Ela adapta a multiplicação à organização das observações nas linhas da matriz de dados.

4.2.1 Novas variáveis como combinações lineares

Seja

$$\mathbf{w}_j \in \mathbb{R}^p$$

o vetor de coeficientes associado à j -ésima coordenada transformada. As linhas de $\mathbf{A}$ podem ser representadas por

$$\mathbf{A} = \begin{bmatrix} \mathbf{w}_1^\top \\ \mathbf{w}_2^\top \\ \vdots \\ \mathbf{w}_q^\top \end{bmatrix},$$

de modo que

$$\mathbf{A}^\top = [\mathbf{w}_1 \quad \mathbf{w}_2 \quad \cdots \quad \mathbf{w}_q] .$$

Consequentemente,

$$\mathbf{Y} = [\mathbf{X}\mathbf{w}_1 \quad \mathbf{X}\mathbf{w}_2 \quad \cdots \quad \mathbf{X}\mathbf{w}_q] .$$

A j -ésima coluna da matriz transformada é

$$\mathbf{y}_{\cdot j} = \mathbf{X}\mathbf{w}_j .$$

Cada nova variável é, portanto, uma combinação linear das variáveis originais. Para a i -ésima observação,

$$y_{ij} = a_{j1}x_{i1} + a_{j2}x_{i2} + \cdots + a_{jp}x_{ip} .$$

Essa relação permite interpretar a transformação de duas maneiras complementares:

- cada linha de $\mathbf{Y}$ é a imagem de uma observação;
- cada coluna de $\mathbf{Y}$ é uma nova variável construída por combinação linear.

Exemplo 4.2 (Transformação de um conjunto de observações). Considere

$$\mathbf{X} = \begin{bmatrix} 1 & 2 \\ 3 & 1 \\ 2 & 4 \end{bmatrix}$$

e

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 2 & -1 \end{bmatrix} .$$

Para uma observação genérica,

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \end{bmatrix} ,$$

tem-se

$$\begin{aligned}
\mathbf{y}_i &= \mathbf{A}\mathbf{x}_i \\
&= \begin{bmatrix} 1 & 1 \\ 2 & -1 \end{bmatrix} \begin{bmatrix} x_{i1} \\ x_{i2} \end{bmatrix} \\
&= \begin{bmatrix} x_{i1} + x_{i2} \\ 2x_{i1} - x_{i2} \end{bmatrix}.
\end{aligned}$$

Como as observações estão nas linhas de $\mathbf{X}$,

$$\begin{aligned}
\mathbf{Y} &= \mathbf{X}\mathbf{A}^\top \\
&= \begin{bmatrix} 1 & 2 \\ 3 & 1 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 1 & -1 \end{bmatrix} \\
&= \begin{bmatrix} 3 & 0 \\ 4 & 5 \\ 6 & 0 \end{bmatrix}.
\end{aligned}$$

A primeira variável transformada é a soma das duas variáveis originais:

$$\mathbf{y}_{.1} = \mathbf{x}_{.1} + \mathbf{x}_{.2}.$$

A segunda é

$$\mathbf{y}_{.2} = 2\mathbf{x}_{.1} - \mathbf{x}_{.2}.$$

4.2.2 Dimensão da configuração transformada

Quando

$$q = p,$$

a transformação atua entre espaços de mesma dimensão:

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^p.$$

e o domínio e o contradomínio possuem a mesma dimensão. A dimensão efetiva da imagem, entretanto, pode ser menor que p quando $\mathbf{A}$ não possui posto completo.

Quando

$$q < p,$$

a transformação produz vetores com menos coordenadas:

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Quando

$$q > p,$$

os vetores passam a ser representados em um espaço com mais coordenadas. Esse aumento do contradomínio não implica aumento da dimensão efetiva da imagem.

Se

$$\text{posto}(\mathbf{A}) = r,$$

então

$$\mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q$$

possui dimensão r . Como

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i,$$

todas as observações transformadas pertencem a esse espaço:

$$\mathbf{y}_i \in \mathcal{C}(\mathbf{A}).$$

Portanto, todas as observações transformadas pertencem a um subespaço de dimensão

$$r = \text{posto}(\mathbf{A}).$$

Assim, a dimensão da configuração transformada não pode exceder $\text{posto}(\mathbf{A})$, embora possa ser menor, dependendo da configuração original dos dados.

Se

$$r = q,$$

a imagem coincide com todo o contradomínio.

Se

$$r < q,$$

a imagem ocupa apenas um subespaço próprio de $\mathbb{R}^q$.

Quando $r < p$, a transformação possui núcleo não trivial e elimina pelo menos uma direção do domínio. Existe, nesse caso, um vetor não nulo

$$\mathbf{v} \in \ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A})$$

tal que

$$\mathbf{A}\mathbf{v} = \mathbf{0}.$$

Para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\begin{aligned}\mathbf{A}(\mathbf{x} + \mathbf{v}) &= \mathbf{A}\mathbf{x} + \mathbf{A}\mathbf{v} \\ &= \mathbf{A}\mathbf{x}.\end{aligned}$$

Vetores distintos podem, portanto, produzir a mesma imagem quando diferem por um elemento do espaço nulo.

A Figura 4.2 compara os efeitos de diferentes matrizes sobre uma mesma configuração de pontos.

A rotação gira a configuração em relação aos eixos coordenados sem alterar sua forma. A reflexão também preserva a forma, mas inverte sua orientação. O escalonamento modifica os comprimentos em cada direção, enquanto o cisalhamento altera uma coordenada de acordo com a outra. A projeção elimina a segunda coordenada e reduz a configuração a uma reta.

As cinco operações preservam combinações lineares. Entretanto, não preservam necessariamente comprimentos, ângulos, áreas ou dimensão.




Figura 4.2: Efeito de diferentes transformações lineares sobre uma mesma configuração de pontos.

4.2.3 Efeito sobre diferenças e produtos internos

Se duas observações são representadas por $\mathbf{x}_i$ e $\mathbf{x}_j$, então

$$\begin{aligned}\mathbf{y}_i - \mathbf{y}_j &= \mathbf{A}\mathbf{x}_i - \mathbf{A}\mathbf{x}_j \\ &= \mathbf{A}(\mathbf{x}_i - \mathbf{x}_j).\end{aligned}$$

A transformação das diferenças determina o efeito sobre as distâncias. O quadrado da distância entre as imagens é

$$\begin{aligned}\|\mathbf{y}_i - \mathbf{y}_j\|^2 &= [\mathbf{A}(\mathbf{x}_i - \mathbf{x}_j)]^\top [\mathbf{A}(\mathbf{x}_i - \mathbf{x}_j)] \\ &= (\mathbf{x}_i - \mathbf{x}_j)^\top \mathbf{A}^\top \mathbf{A} (\mathbf{x}_i - \mathbf{x}_j).\end{aligned}$$

A matriz

$$\mathbf{A}^\top \mathbf{A}$$

descreve, no domínio, como a transformação modifica produtos internos, comprimentos e distâncias. Quando $\mathbf{A}$ possui posto completo nas colunas, $\mathbf{A}^\top \mathbf{A}$ é positiva definida e determina um produto interno no domínio. Quando $\mathbf{A}$ não possui posto completo nas colunas, essa matriz é apenas semidefinida positiva e algumas direções são eliminadas pela transformação.

Para quaisquer vetores $\mathbf{x}, \mathbf{z} \in \mathbb{R}^p$,

$$\begin{aligned}T(\mathbf{x})^\top T(\mathbf{z}) &= (\mathbf{A}\mathbf{x})^\top (\mathbf{A}\mathbf{z}) \\ &= \mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{z}.\end{aligned}$$

Em particular,

$$\|\mathbf{A}\mathbf{x}\|^2 = \mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x}.$$

Como

$$\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} = \|\mathbf{A}\mathbf{x}\|^2 \geq 0,$$

a matriz $\mathbf{A}^\top \mathbf{A}$ é simétrica e semidefinida positiva.

Se $\mathbf{A}$ possui posto completo nas colunas, então

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$$

e

$$\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$. Nesse caso,

$$\mathbf{A}^\top \mathbf{A} \succ 0,$$

e a expressão

$$\|\mathbf{x}\|_{\mathbf{A}^\top \mathbf{A}} = \sqrt{\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x}} = \|\mathbf{A} \mathbf{x}\|$$

define uma norma em $\mathbb{R}^p$.

Quando $\mathbf{A}$ não possui posto completo nas colunas, existem vetores não nulos em

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A})$$

para os quais

$$\|\mathbf{x}\|_{\mathbf{A}^\top \mathbf{A}} = 0.$$

Nesse caso, $\|\cdot\|_{\mathbf{A}^\top \mathbf{A}}$ define uma seminorma.

4.2.4 Transformação das matrizes de produtos internos

A matriz de Gram entre as observações originais é

$$\mathbf{G}_{\mathbf{X}} = \mathbf{X} \mathbf{X}^\top.$$

Para

$$\mathbf{Y} = \mathbf{X} \mathbf{A}^\top,$$

tem-se

$$\begin{aligned} \mathbf{G}_{\mathbf{Y}} &= \mathbf{Y} \mathbf{Y}^\top \\ &= \mathbf{X} \mathbf{A}^\top \mathbf{A} \mathbf{X}^\top. \end{aligned}$$

Portanto,

$$\mathbf{G}_Y = \mathbf{X}\mathbf{A}^\top \mathbf{A}\mathbf{X}^\top.$$

Se

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_p,$$

então

$$\mathbf{G}_Y = \mathbf{X}\mathbf{X}^\top = \mathbf{G}_X.$$

Nesse caso, todos os produtos internos entre as observações são preservados.

A matriz de produtos cruzados entre as variáveis transformadas é

$$\begin{aligned}\mathbf{Y}^\top \mathbf{Y} &= (\mathbf{X}\mathbf{A}^\top)^\top (\mathbf{X}\mathbf{A}^\top) \\ &= \mathbf{A}\mathbf{X}^\top \mathbf{X}\mathbf{A}^\top.\end{aligned}$$

Logo,

$$\mathbf{Y}^\top \mathbf{Y} = \mathbf{A}\mathbf{X}^\top \mathbf{X}\mathbf{A}^\top.$$

Essa expressão descreve como os produtos cruzados entre as novas variáveis são obtidos a partir dos produtos cruzados entre as variáveis originais.

Quando $\mathbf{X}$ está centralizada, a mesma estrutura permite descrever posteriormente a transformação da matriz de covariâncias. Por enquanto, a relação mostra que uma transformação linear modifica simultaneamente a geometria das observações e as relações entre as variáveis.

4.3 Composição, invertibilidade e perda de informação

Transformações lineares podem ser aplicadas sucessivamente. A matriz da transformação resultante é obtida pelo produto das matrizes que representam cada etapa.

4.3.1 Composição de transformações lineares

Considere

$$T_1 : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

e

$$T_2 : \mathbb{R}^q \longrightarrow \mathbb{R}^r,$$

representadas, respectivamente, por

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{B} \in \mathbb{R}^{r \times q}.$$

Para $\mathbf{x} \in \mathbb{R}^p$,

$$T_1(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

Aplicando T_2 à imagem produzida por T_1 ,

$$\begin{aligned} T_2(T_1(\mathbf{x})) &= \mathbf{B}(\mathbf{A}\mathbf{x}) \\ &= (\mathbf{B}\mathbf{A})\mathbf{x}. \end{aligned}$$

Proposição 4.5 (Matriz de uma composição). *Se T_1 é representada por $\mathbf{A}$ e T_2 é representada por $\mathbf{B}$, então a composição*

$$T_2 \circ T_1$$

é representada por

$$\mathbf{B}\mathbf{A}.$$

Em particular,

$$[T_2 \circ T_1] = [T_2][T_1].$$

A ordem do produto é interpretada da direita para a esquerda:

1. $\mathbf{A}$ atua primeiro;
2. $\mathbf{B}$ atua depois.

As dimensões refletem essa sequência:

$$\underbrace{\mathbf{B}}_{r \times q} \underbrace{\mathbf{A}}_{q \times p} \underbrace{\mathbf{x}}_{p \times 1} \in \mathbb{R}^r.$$

Se as observações estão nas linhas de

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a primeira transformação produz

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top.$$

A segunda produz

$$\begin{aligned} \mathbf{Z} &= \mathbf{Y}\mathbf{B}^\top \\ &= \mathbf{X}\mathbf{A}^\top\mathbf{B}^\top \\ &= \mathbf{X}(\mathbf{BA})^\top. \end{aligned}$$

Portanto, a composição aplicada à matriz de dados é

$$\mathbf{Z} = \mathbf{X}(\mathbf{BA})^\top.$$

4.3.2 A ordem das transformações

A ordem de aplicação das transformações é importante. Quando duas transformações atuam sobre o mesmo espaço,

$$T_1 : \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

e

$$T_2 : \mathbb{R}^p \longrightarrow \mathbb{R}^p,$$

representadas, respectivamente, por

$$\mathbf{A}, \mathbf{B} \in \mathbb{R}^{p \times p},$$

as duas composições

$$T_2 \circ T_1$$

e

$$T_1 \circ T_2$$

estão definidas. Suas matrizes representantes são, respectivamente,

$$\mathbf{BA}$$

e

$$\mathbf{AB}.$$

Como a multiplicação de matrizes não é, em geral, comutativa,

$$\mathbf{BA} \neq \mathbf{AB}.$$

Consequentemente, em geral,

$$T_2 \circ T_1 \neq T_1 \circ T_2.$$

A igualdade pode ocorrer para transformações particulares, mas não constitui uma propriedade geral da composição.

Exemplo 4.3 (Composição de rotação e escalonamento). Considere uma rotação de 45° ,

$$\mathbf{Q}\left(\frac{\pi}{4}\right) = \begin{bmatrix} \cos(\pi/4) & -\sin(\pi/4) \\ \sin(\pi/4) & \cos(\pi/4) \end{bmatrix},$$

e um escalonamento não uniforme,

$$\mathbf{L} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}.$$

Aplicar primeiro a rotação e depois o escalonamento corresponde a

$$\mathbf{L}\mathbf{Q}\left(\frac{\pi}{4}\right).$$

Aplicar primeiro o escalonamento e depois a rotação corresponde a

$$\mathbf{Q}\left(\frac{\pi}{4}\right)\mathbf{L}.$$

Como

$$\mathbf{L}\mathbf{Q}\left(\frac{\pi}{4}\right) \neq \mathbf{Q}\left(\frac{\pi}{4}\right)\mathbf{L},$$

as duas sequências produzem transformações diferentes.

A Figura 4.3 compara as duas ordens de aplicação.




Figura 4.3: Efeito da ordem na composição de uma rotação e de um escalonamento não uniforme.

As duas composições utilizam as mesmas transformações, mas produzem configurações diferentes. Na primeira, a nuvem é rotacionada antes de ser escalonada em relação aos eixos coordenados. Na segunda, o escalonamento ocorre antes da mudança de orientação.

4.3.3 Transformação inversa

Uma transformação linear invertível permite recuperar de maneira única o vetor original a partir de sua imagem.

Definição 4.3 (Transformação inversa). Uma transformação linear

$$T : V \longrightarrow W$$

é invertível quando existe uma transformação

$$T^{-1} : W \longrightarrow V$$

tal que

$$T^{-1}(T(\mathbf{x})) = \mathbf{x}$$

para todo $\mathbf{x} \in V$ e

$$T(T^{-1}(\mathbf{y})) = \mathbf{y}$$

para todo $\mathbf{y} \in W$.

Considere uma transformação

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

representada por uma matriz quadrada e invertível

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Se

$$\mathbf{y} = \mathbf{Ax},$$

então

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{y}.$$

A transformação inversa é representada por $\mathbf{A}^{-1}$.

Proposição 4.6 (Inversa de uma composição). *Se $\mathbf{A}$ e $\mathbf{B}$ são matrizes quadradas e invertíveis de dimensões compatíveis, então*

$$(\mathbf{BA})^{-1} = \mathbf{A}^{-1}\mathbf{B}^{-1}.$$

Comprovação. Tem-se

$$\begin{aligned} (\mathbf{BA})(\mathbf{A}^{-1}\mathbf{B}^{-1}) &= \mathbf{B}(\mathbf{AA}^{-1})\mathbf{B}^{-1} \\ &= \mathbf{BB}^{-1} \\ &= \mathbf{I}. \end{aligned}$$

De forma análoga,

$$\begin{aligned} (\mathbf{A}^{-1}\mathbf{B}^{-1})(\mathbf{BA}) &= \mathbf{A}^{-1}(\mathbf{B}^{-1}\mathbf{B})\mathbf{A} \\ &= \mathbf{A}^{-1}\mathbf{A} \\ &= \mathbf{I}. \end{aligned}$$

Logo,

$$(\mathbf{BA})^{-1} = \mathbf{A}^{-1}\mathbf{B}^{-1}.$$

□

A ordem é invertida porque a última transformação aplicada deve ser a primeira a ser desfeita.

4.3.4 Injetividade, sobrejetividade e bijetividade

As propriedades de injetividade e sobrejetividade descrevem, respectivamente, a possibilidade de distinguir vetores do domínio por suas imagens e a possibilidade de atingir todos os vetores do contradomínio.

Definição 4.4 (Injetividade, sobrejetividade e bijetividade). Uma transformação

$$T : V \longrightarrow W$$

é:

1. **injetiva** quando

$$T(\mathbf{x}_1) = T(\mathbf{x}_2) \implies \mathbf{x}_1 = \mathbf{x}_2;$$

2. **sobrejetiva** quando, para todo $\mathbf{y} \in W$, existe pelo menos um $\mathbf{x} \in V$ tal que

$$T(\mathbf{x}) = \mathbf{y};$$

3. **bijetiva** quando é simultaneamente injetiva e sobrejetiva.

Para uma transformação matricial

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

essas propriedades podem ser caracterizadas pelo núcleo, pelo espaço coluna e pelo posto.

Proposição 4.7 (Caracterizações por núcleo, imagem e posto). *Seja*

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

com $\mathbf{A} \in \mathbb{R}^{q \times p}$. Então:

1. $T_{\mathbf{A}}$ é injetiva se, e somente se,

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\};$$

2. $T_{\mathbf{A}}$ é injetiva se, e somente se,

$$\text{posto}(\mathbf{A}) = p;$$

3. $T_{\mathbf{A}}$ é sobrejetiva se, e somente se,

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \mathbb{R}^q;$$

4. $T_{\mathbf{A}}$ é sobrejetiva se, e somente se,

$$\text{posto}(\mathbf{A}) = q.$$

(Meyer, 2023)

Comprovação. Suponha inicialmente que $T_{\mathbf{A}}$ seja injetiva. Se

$$\mathbf{x} \in \ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}),$$

então

$$\mathbf{Ax} = \mathbf{0} = \mathbf{A}\mathbf{0}.$$

Pela injetividade,

$$\mathbf{x} = \mathbf{0}.$$

Logo,

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}.$$

Reciprocamente, suponha que

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$$

e que

$$\mathbf{Ax}_1 = \mathbf{Ax}_2.$$

Então,

$$\mathbf{A}(\mathbf{x}_1 - \mathbf{x}_2) = \mathbf{0}.$$

Portanto,

$$\mathbf{x}_1 - \mathbf{x}_2 \in \ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}),$$

o que implica

$$\mathbf{x}_1 = \mathbf{x}_2.$$

Assim, $T_{\mathbf{A}}$ é injetiva.

Pelo Teorema [3.5](#),

$$\dim \mathcal{N}(\mathbf{A}) + \text{posto}(\mathbf{A}) = p.$$

Como $\mathcal{N}(\mathbf{A}) = \ker(T_{\mathbf{A}})$, tem-se

$$\ker(T_{\mathbf{A}}) = \{\mathbf{0}\}$$

se, e somente se,

$$\text{posto}(\mathbf{A}) = p.$$

Por outro lado, $T_{\mathbf{A}}$ é sobrejetiva quando todo vetor de $\mathbb{R}^q$ pertence à sua imagem. Como

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}),$$

a sobrejetividade equivale a

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \mathbb{R}^q.$$

Essa igualdade ocorre se, e somente se,

$$\dim \mathcal{C}(\mathbf{A}) = q,$$

isto é,

$$\text{posto}(\mathbf{A}) = q.$$

□

Uma transformação de $\mathbb{R}^p$ em $\mathbb{R}^q$ pode ser injetiva somente quando

$$q \geq p.$$

De forma análoga, pode ser sobrejetiva somente quando

$$p \geq q.$$

Se a transformação é bijetiva, então

$$p = q$$

e

$$\text{posto}(\mathbf{A}) = p.$$

Combinando o Proposição 4.7 com o Teorema 2.5, obtém-se o resultado seguinte.

Proposição 4.8 (Equivalências para uma transformação linear associada a uma matriz quadrada). *Considere*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e a transformação linear

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^p, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

São equivalentes:

1. $T_{\mathbf{A}}$ é injetiva;
2. $T_{\mathbf{A}}$ é sobrejetiva;
3. $T_{\mathbf{A}}$ é bijetiva;
4. $T_{\mathbf{A}}$ é invertível;
5. $\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$;
6. $\mathcal{C}(\mathbf{A}) = \mathbb{R}^p$;
7. $\text{posto}(\mathbf{A}) = p$;
8. $\det(\mathbf{A}) \neq 0$;
9. $\mathbf{A}^{-1}$ existe.

(Meyer, 2023)

A Tabela 4.1 resume as relações principais.

Tabela 4.1: Relações entre injetividade, sobrejetividade, bijetividade e posto.

Propriedade	Condição geométrica	Condição matricial
Injetividade	Vetores distintos possuem imagens distintas	$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$ e $\text{posto}(\mathbf{A}) = p$
Sobrejetividade	Todo vetor do contradomínio é atingido	$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \mathbb{R}^q$ e $\text{posto}(\mathbf{A}) = q$

Propriedade	Condição geométrica	Condição matricial
Bijetividade	Há correspondência única entre domínio e contradomínio	$p = q = \text{posto}(\mathbf{A})$
Invertibilidade	A transformação pode ser desfeita	$\mathbf{A}$ é quadrada e $\det(\mathbf{A}) \neq 0$

4.3.5 Perda de informação

Quando a transformação não é injetiva, existem vetores distintos com a mesma imagem.

Se

$$\mathbf{v} \in \ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}),$$

então, para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\begin{aligned}\mathbf{A}(\mathbf{x} + \mathbf{v}) &= \mathbf{A}\mathbf{x} + \mathbf{A}\mathbf{v} \\ &= \mathbf{A}\mathbf{x}.\end{aligned}$$

Portanto, todos os vetores do conjunto

$$\mathbf{x} + \ker(T_{\mathbf{A}}) = \{\mathbf{x} + \mathbf{v} : \mathbf{v} \in \ker(T_{\mathbf{A}})\}$$

produzem a mesma imagem.

Reciprocamente, se

$$\mathbf{A}\mathbf{x}_1 = \mathbf{A}\mathbf{x}_2,$$

então

$$\mathbf{x}_1 - \mathbf{x}_2 \in \mathcal{N}(\mathbf{A}).$$

A ambiguidade na recuperação do vetor original é, assim, determinada pelo núcleo da transformação, que coincide com o espaço nulo da matriz associada.

Se

$$\text{posto}(\mathbf{A}) = r,$$

o Teorema Posto–Nulidade fornece

$$\dim(\mathcal{N}(\mathbf{A})) = p - r.$$

O espaço nulo possui dimensão $p - r$. Portanto, existem $p - r$ direções linearmente independentes no domínio que são anuladas pela transformação, enquanto a imagem possui dimensão r .

4.3.6 Redução de dimensionalidade

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com

$$q < p.$$

Mesmo que

$$\text{posto}(\mathbf{A}) = q,$$

tem-se

$$\dim(\mathcal{N}(\mathbf{A})) = p - q > 0.$$

A perda de informação é inevitável quando a transformação é considerada sobre todo o espaço $\mathbb{R}^p$. Entretanto, sua restrição a um conjunto particular ou a um subespaço de dimensão menor ou igual a q pode ser injetiva. Assim, reduzir o número de coordenadas não implica necessariamente identificar observações distintas no conjunto de dados efetivamente analisado.

A redução pode ser útil quando a matriz é escolhida para preservar determinadas direções e eliminar outras. O critério utilizado para selecionar essas direções será desenvolvido posteriormente, no contexto das técnicas multivariadas.

4.3.7 Transformações singulares

Uma matriz quadrada é singular quando

$$\det(\mathbf{A}) = 0.$$

Nesse caso,

$$\text{posto}(\mathbf{A}) < p,$$

e a transformação leva $\mathbb{R}^p$ a um subespaço de menor dimensão.

Por exemplo,

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

transforma

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

em

$$\begin{bmatrix} x_1 \\ 0 \end{bmatrix}.$$

Todos os pontos com a mesma primeira coordenada produzem a mesma imagem.

A Figura 4.4 compara uma transformação invertível, a recuperação pela inversa e uma transformação singular.

A transformação representada por $\mathbf{A}$ modifica a configuração, mas mantém uma correspondência única entre os pontos originais e transformados. A aplicação de $\mathbf{A}^{-1}$ recupera a configuração inicial. A transformação singular elimina a segunda coordenada e reduz toda a nuvem a uma reta.

Para

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

as possibilidades podem ser resumidas da seguinte forma:




Figura 4.4: Transformação invertível, recuperação pela inversa e colapso provocado por uma transformação singular.

- se $q < p$, a transformação não pode ser injetiva;
- se $q > p$, a transformação não pode ser sobrejetiva;
- se $q = p$, ela é bijetiva quando $\text{posto}(\mathbf{A}) = p$;
- se $\text{posto}(\mathbf{A}) < \min(p, q)$, ela não é injetiva nem sobrejetiva.

Essas relações permitem interpretar

$$\text{posto}(\mathbf{A})$$

como a dimensão da imagem da transformação, isto é, como o número máximo de direções linearmente independentes que podem compor o espaço transformado. A seção seguinte examina os efeitos geométricos produzidos por classes particulares de matrizes.

4.4 Transformações geométricas

Matrizes distintas produzem efeitos geométricos diferentes sobre vetores e conjuntos de pontos. Algumas modificam a posição da configuração em relação aos eixos coordenados sem deformar sua geometria, enquanto outras alteram comprimentos, ângulos, áreas ou dimensão.

Nesta seção, são examinadas cinco transformações no plano:

- rotação;
- reflexão;
- escalonamento;

- cisalhamento;
- projeção.

Todas preservam combinações lineares e, portanto, são transformações lineares. As propriedades geométricas preservadas dependem da matriz utilizada.

4.4.1 Rotação

Uma rotação de ângulo θ em torno da origem é representada por

$$\mathbf{Q}_\theta = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

a imagem é

$$\mathbf{y} = \mathbf{Q}_\theta \mathbf{x},$$

isto é,

$$\begin{aligned} y_1 &= x_1 \cos \theta - x_2 \sin \theta, \\ y_2 &= x_1 \sin \theta + x_2 \cos \theta. \end{aligned}$$

A matriz de rotação satisfaz

$$\mathbf{Q}_\theta^\top \mathbf{Q}_\theta = \mathbf{I}_2.$$

Consequentemente,

$$\mathbf{Q}_\theta^{-1} = \mathbf{Q}_\theta^\top = \mathbf{Q}_{-\theta}.$$

A transformação inversa corresponde a uma rotação pelo mesmo ângulo no sentido oposto.

Além disso,

$$\det(\mathbf{Q}_\theta) = 1.$$

A rotação preserva comprimentos, distâncias, ângulos, áreas e orientação.

4.4.2 Reflexão

Uma reflexão no plano produz a imagem especular dos vetores em relação a uma reta que passa pela origem.

A reflexão em relação ao eixo horizontal é representada por

$$\mathbf{F}_1 = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix},$$

de modo que

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \mapsto \begin{bmatrix} x_1 \\ -x_2 \end{bmatrix}.$$

A reflexão em relação ao eixo vertical é representada por

$$\mathbf{F}_2 = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix},$$

e produz

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \mapsto \begin{bmatrix} -x_1 \\ x_2 \end{bmatrix}.$$

As duas matrizes satisfazem

$$\mathbf{F}^\top \mathbf{F} = \mathbf{I}_2$$

e

$$\mathbf{F}^{-1} = \mathbf{F}.$$

Assim,

$$\mathbf{F}^2 = \mathbf{I}_2.$$

Aplicar duas vezes a mesma reflexão recupera o vetor original.

Considere agora uma reta gerada por um vetor unitário

$$\mathbf{u} \in \mathbb{R}^2, \quad \|\mathbf{u}\| = 1.$$

A projeção de $\mathbf{x}$ sobre essa reta é

$$\mathbf{u}\mathbf{u}^\top \mathbf{x},$$

enquanto sua componente ortogonal é

$$(\mathbf{I}_2 - \mathbf{u}\mathbf{u}^\top) \mathbf{x}.$$

Na reflexão, a componente paralela é preservada e a componente ortogonal tem seu sinal invertido:

$$\begin{aligned} \mathbf{x}_{\text{ref}} &= \mathbf{u}\mathbf{u}^\top \mathbf{x} - (\mathbf{I}_2 - \mathbf{u}\mathbf{u}^\top) \mathbf{x} \\ &= (2\mathbf{u}\mathbf{u}^\top - \mathbf{I}_2) \mathbf{x}. \end{aligned}$$

Portanto, a reflexão em relação à reta gerada por $\mathbf{u}$ é representada por

$$\mathbf{F}_{\mathbf{u}} = 2\mathbf{u}\mathbf{u}^\top - \mathbf{I}_2.$$

Essa matriz satisfaz

$$\mathbf{F}_{\mathbf{u}}^\top \mathbf{F}_{\mathbf{u}} = \mathbf{I}_2$$

e

$$\det(\mathbf{F}_{\mathbf{u}}) = -1.$$

A reflexão preserva comprimentos, distâncias, ângulos e áreas, mas inverte a orientação.

Em dimensão p , a matriz

$$\mathbf{H}_{\mathbf{u}} = \mathbf{I}_p - 2\mathbf{u}\mathbf{u}^\top, \quad \|\mathbf{u}\| = 1,$$

representa a reflexão em relação ao hiperplano ortogonal a $\mathbf{u}$. Essa transformação é denominada **reflexão de Householder**.

Observe que as duas construções preservam componentes diferentes. A matriz $2\mathbf{u}\mathbf{u}^\top - \mathbf{I}$ preserva a componente na direção de $\mathbf{u}$ e inverte as componentes ortogonais a ela, enquanto $\mathbf{I} - 2\mathbf{u}\mathbf{u}^\top$ preserva as componentes ortogonais a $\mathbf{u}$ e inverte a componente na direção de $\mathbf{u}$.

4.4.3 Escalonamento

Um escalonamento modifica o comprimento dos vetores ao longo de direções determinadas.

No plano, o escalonamento em relação aos eixos coordenados é representado por

$$\mathbf{L} = \begin{bmatrix} s_1 & 0 \\ 0 & s_2 \end{bmatrix}.$$

A transformação correspondente é

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \mapsto \begin{bmatrix} s_1 x_1 \\ s_2 x_2 \end{bmatrix}.$$

Quando

$$s_1 = s_2 = s,$$

o escalonamento é uniforme:

$$\mathbf{L} = s\mathbf{I}_2.$$

Nesse caso, todos os comprimentos e todas as distâncias são multiplicados por $|s|$. Para $s \neq 0$, os ângulos são preservados.

Quando

$$s_1 \neq s_2,$$

o escalonamento é não uniforme. Cada direção coordenada é reescalada por um fator próprio, de modo que comprimentos, ângulos e proporções podem ser alterados. Se algum fator s_j for negativo, além da alteração de escala ocorre a inversão do sentido da coordenada correspondente.

O determinante da matriz é

$$\det(\mathbf{L}) = s_1 s_2.$$

A área de uma figura é, portanto, multiplicada por

$$|s_1 s_2|.$$

A transformação é invertível quando

$$s_1 \neq 0 \quad \text{e} \quad s_2 \neq 0.$$

Nesse caso,

$$\mathbf{L}^{-1} = \begin{bmatrix} 1/s_1 & 0 \\ 0 & 1/s_2 \end{bmatrix}.$$

Se algum fator de escala for igual a zero, uma direção é eliminada. Por exemplo,

$$\mathbf{L} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

leva todo o plano ao eixo horizontal.

O escalonamento das variáveis será retomado na seção sobre pré-processamento.

4.4.4 Cisalhamento

Um cisalhamento modifica uma coordenada adicionando a ela uma parcela proporcional a outra coordenada.

O cisalhamento horizontal é representado por

$$\mathbf{C}_{12}(k) = \begin{bmatrix} 1 & k \\ 0 & 1 \end{bmatrix}.$$

Nesse caso,

$$\begin{aligned} y_1 &= x_1 + kx_2, \\ y_2 &= x_2. \end{aligned}$$

A segunda coordenada permanece inalterada, enquanto a primeira é modificada de acordo com o valor de x_2 .

O cisalhamento vertical é representado por

$$\mathbf{C}_{21}(k) = \begin{bmatrix} 1 & 0 \\ k & 1 \end{bmatrix},$$

e produz

$$\begin{aligned}y_1 &= x_1, \\y_2 &= kx_1 + x_2.\end{aligned}$$

Em dimensão p , um cisalhamento elementar pode ser escrito como

$$\mathbf{C}_{ij}(k) = \mathbf{I}_p + k\mathbf{e}_i\mathbf{e}_j^\top, \quad i \neq j.$$

Essa transformação adiciona à coordenada i uma parcela proporcional à coordenada j .

Como

$$\left(\mathbf{e}_i\mathbf{e}_j^\top\right)^2 = \mathbf{0}$$

para $i \neq j$, tem-se

$$\begin{aligned}\mathbf{C}_{ij}(k)\mathbf{C}_{ij}(-k) &= \left(\mathbf{I}_p + k\mathbf{e}_i\mathbf{e}_j^\top\right)\left(\mathbf{I}_p - k\mathbf{e}_i\mathbf{e}_j^\top\right) \\ &= \mathbf{I}_p.\end{aligned}$$

Portanto,

$$\mathbf{C}_{ij}(k)^{-1} = \mathbf{C}_{ij}(-k).$$

O determinante de um cisalhamento elementar é

$$\det\left(\mathbf{C}_{ij}(k)\right) = 1.$$

Assim, o cisalhamento preserva áreas e volumes, mas altera comprimentos e ângulos. Retas e paralelismo são preservados.

4.4.5 Projeção

As projeções ortogonais foram desenvolvidas no capítulo anterior a partir da decomposição de um vetor em componentes pertencentes a subespaços ortogonais. Aqui, interessa interpretá-las como transformações lineares.

Considere uma direção unitária

$$\mathbf{u} \in \mathbb{R}^p, \quad \|\mathbf{u}\| = 1,$$

e o subespaço

$$S = \text{span}\{\mathbf{u}\}.$$

A matriz da projeção ortogonal sobre S é

$$\mathbf{P}_S = \mathbf{u}\mathbf{u}^\top,$$

de modo que

$$T_{\mathbf{P}_S}(\mathbf{x}) = \mathbf{P}_S \mathbf{x}.$$

Como estudado no capítulo anterior,

$$\mathbf{P}_S^2 = \mathbf{P}_S$$

e

$$\mathbf{P}_S^\top = \mathbf{P}_S.$$

Do ponto de vista das transformações lineares,

$$\text{Im}(T_{\mathbf{P}_S}) = S$$

e

$$\ker(T_{\mathbf{P}_S}) = S^\perp.$$

Assim, a projeção preserva a componente pertencente a S e elimina toda a componente pertencente a $S^\perp$.

Para uma projeção sobre uma única direção,

$$\text{posto}(\mathbf{P}_S) = 1.$$

Consequentemente, quando $p > 1$,

$$\det(\mathbf{P}_S) = 0,$$

e a transformação não é invertível. Vetores que diferem apenas por uma componente pertencente a $S^\perp$ possuem a mesma imagem.

4.4.6 Comparação geométrica

A Figura 4.5 mostra o efeito das transformações anteriores sobre o quadrado unitário. Como todos os painéis utilizam a mesma escala, alterações de forma, área e dimensão podem ser comparadas diretamente.




Figura 4.5: Efeito de diferentes transformações lineares sobre o quadrado unitário.

A rotação altera a posição do quadrado em relação aos eixos coordenados sem modificar sua forma, sua área ou sua orientação. A reflexão preserva a forma e a área, mas inverte a orientação. O escalonamento não uniforme modifica os comprimentos nas direções coordenadas e transforma o quadrado em um retângulo. O cisalhamento transforma o quadrado em um paralelogramo com a mesma área, mostrando que preservar área não implica preservar ângulos ou comprimentos. A projeção elimina uma direção e reduz a figura a um segmento de reta.

4.4.7 Determinante, volume e orientação

Para uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{p \times p},$$

o valor absoluto do determinante representa o fator pelo qual volumes são multiplicados.

Proposição 4.9 (Alteração de volume por uma transformação linear). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e seja

$$E \subseteq \mathbb{R}^p$$

um conjunto mensurável com volume p -dimensional finito. Denote por

$$\mathbf{A}E = \{\mathbf{A}\mathbf{x} : \mathbf{x} \in E\}$$

sua imagem pela transformação linear representada por $\mathbf{A}$.

Então,

$$\text{Vol}_p(\mathbf{A}E) = |\det(\mathbf{A})| \text{Vol}_p(E),$$

em que Vol_p representa o volume p -dimensional.

Se

$$\det(\mathbf{A}) = 0,$$

então

$$\text{posto}(\mathbf{A}) < p,$$

de modo que a imagem $\mathbf{A}E$ está contida em um subespaço próprio de $\mathbb{R}^p$. Consequentemente,

$$\text{Vol}_p(\mathbf{A}E) = 0.$$

A demonstração formal desse resultado, baseada no Jacobiano de uma transformação linear, será apresentada no capítulo dedicado ao cálculo multivariado.

No plano, o resultado descreve a alteração de área. Em $\mathbb{R}^3$, descreve a alteração de volume. Em dimensão geral, descreve a alteração do hipervolume.

Quando a transformação é invertível, o sinal do determinante descreve o efeito sobre a orientação:

- se $\det(\mathbf{A}) > 0$, a orientação é preservada;
- se $\det(\mathbf{A}) < 0$, a orientação é invertida.

Se $\det(\mathbf{A}) = 0$, a transformação não é invertível, sua imagem possui dimensão inferior a p e o volume p -dimensional é reduzido a zero.

A Tabela 4.2 resume as propriedades das transformações estudadas.

Tabela 4.2: Propriedades das principais transformações geométricas no plano.

Transformação	Matriz no plano	Determinante	Efeito geométrico
Rotação	$\mathbf{Q}_\theta$	1	Gira a configuração
Reflexão	$\mathbf{F}$	-1	Produz uma imagem especular
Escalonamento	$\text{diag}(s_1, s_2)$	$s_1 s_2$	Reescala direções coordenadas
Cisalhamento	$\begin{bmatrix} 1 & k \\ 0 & 1 \end{bmatrix}$	1	Inclina a configuração
Projeção sobre uma reta	$\mathbf{u}\mathbf{u}^\top$	0	Elimina uma direção

A preservação de área ou volume não implica preservação de distâncias e ângulos. O cisalhamento possui determinante igual a 1, mas deforma a configuração. A preservação integral da geometria euclidiana será estudada na seção seguinte.

4.5 Transformações ortogonais

A linearidade não garante a preservação de comprimentos, distâncias ou ângulos. Essas propriedades são preservadas pelas transformações representadas por matrizes ortogonais.

Retomando a Definição 2.18, uma matriz

$$\mathbf{Q} \in \mathbb{R}^{p \times p}$$

é ortogonal quando

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_p.$$

Essa condição implica

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top$$

e

$$\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}_p.$$

A transformação

$$T_{\mathbf{Q}} : \mathbb{R}^p \longrightarrow \mathbb{R}^p, \quad T_{\mathbf{Q}}(\mathbf{x}) = \mathbf{Q}\mathbf{x},$$

é denominada **transformação ortogonal**.

Proposição 4.10 (Preservação da geometria euclidiana). *Se $\mathbf{Q} \in \mathbb{R}^{p \times p}$ é ortogonal, então, para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, a transformação*

$$T_{\mathbf{Q}}(\mathbf{x}) = \mathbf{Q}\mathbf{x}$$

preserva:

1. o produto interno;
2. as normas;
3. as distâncias euclidianas;
4. os ângulos entre vetores não nulos;
5. a ortogonalidade.

Comprovação. Pelo Teorema 2.7,

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{y}.$$

Portanto, o produto interno entre quaisquer dois vetores é preservado.

Tomando $\mathbf{y} = \mathbf{x}$,

$$\begin{aligned}\|\mathbf{Q}\mathbf{x}\|^2 &= (\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{x}) \\ &= \mathbf{x}^\top \mathbf{x} \\ &= \|\mathbf{x}\|^2.\end{aligned}$$

Como as normas são não negativas,

$$\|\mathbf{Q}\mathbf{x}\| = \|\mathbf{x}\|.$$

Para dois vetores $\mathbf{x}$ e $\mathbf{y}$,

$$\begin{aligned}\|\mathbf{Q}\mathbf{x} - \mathbf{Q}\mathbf{y}\| &= \|\mathbf{Q}(\mathbf{x} - \mathbf{y})\| \\ &= \|\mathbf{x} - \mathbf{y}\|.\end{aligned}$$

Logo, todas as distâncias euclidianas entre pares de vetores são preservadas.

Para vetores não nulos, o ângulo θ entre $\mathbf{x}$ e $\mathbf{y}$ é determinado por

$$\cos(\theta) = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

Como o produto interno e as normas são preservados,

$$\frac{(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y})}{\|\mathbf{Q}\mathbf{x}\| \|\mathbf{Q}\mathbf{y}\|} = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

Portanto, os ângulos também são preservados.

Em particular, se

$$\mathbf{x}^\top \mathbf{y} = 0,$$

então

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = 0,$$

e a ortogonalidade é preservada. □

Assim, transformações ortogonais preservam integralmente as relações métricas determinadas pelo produto interno euclidiano. Elas podem alterar a orientação da configuração, mas não deformam sua geometria interna.

4.5.1 Transformação de uma matriz de dados

Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p}$$

e uma transformação ortogonal representada por

$$\mathbf{Q} \in \mathbb{R}^{p \times p}.$$

Como as observações estão organizadas nas linhas, a matriz transformada é

$$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top.$$

Proposição 4.11 (Preservação da matriz de Gram). *Se*

$$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top$$

e $\mathbf{Q}$ é ortogonal, então

$$\mathbf{Y}\mathbf{Y}^\top = \mathbf{X}\mathbf{X}^\top.$$

Comprovação. Tem-se

$$\begin{aligned} \mathbf{Y}\mathbf{Y}^\top &= (\mathbf{X}\mathbf{Q}^\top)(\mathbf{X}\mathbf{Q}^\top)^\top \\ &= \mathbf{X}\mathbf{Q}^\top\mathbf{Q}\mathbf{X}^\top \\ &= \mathbf{X}\mathbf{I}_p\mathbf{X}^\top \\ &= \mathbf{X}\mathbf{X}^\top. \end{aligned}$$

□

A matriz de Gram reúne os produtos internos entre as observações. Sua preservação implica que permanecem inalterados:

- os quadrados das normas das observações;
- os produtos internos entre pares de observações;
- as distâncias entre as observações;
- os ângulos entre os vetores observados não nulos.

A nuvem de pontos pode ser rotacionada ou refletida, mas sua forma e suas relações internas permanecem as mesmas.

4.5.2 Determinante e orientação

Proposição 4.12 (Determinante de uma matriz ortogonal). *Se $\mathbf{Q} \in \mathbb{R}^{p \times p}$ é ortogonal, então*

$$\det(\mathbf{Q}) \in \{-1, 1\}.$$

Consequentemente,

$$|\det(\mathbf{Q})| = 1,$$

e a transformação preserva volumes p -dimensionais.

Comprovação. Como

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_p,$$

tem-se

$$\begin{aligned} 1 &= \det(\mathbf{Q}^\top \mathbf{Q}) \\ &= \det(\mathbf{Q}^\top) \det(\mathbf{Q}) \\ &= \det(\mathbf{Q})^2. \end{aligned}$$

Portanto,

$$\det(\mathbf{Q}) = 1 \quad \text{ou} \quad \det(\mathbf{Q}) = -1.$$

Logo,

$$|\det(\mathbf{Q})| = 1.$$

□

No plano, a preservação do volume p -dimensional corresponde à preservação de áreas; em $\mathbb{R}^3$, corresponde à preservação de volumes.

Quando

$$\det(\mathbf{Q}) = 1,$$

a transformação é denominada **ortogonal própria**. Ela preserva a orientação.

No plano, toda transformação ortogonal própria é uma rotação e pode ser representada por

$$\mathbf{Q} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}.$$

Quando

$$\det(\mathbf{Q}) = -1,$$

a transformação é denominada **ortogonal imprópria**. Ela inverte a orientação.

No plano, toda transformação ortogonal imprópria corresponde a uma reflexão em relação a uma reta que passa pela origem. Em dimensões superiores, pode combinar uma reflexão com rotações em subespaços ortogonais.

4.5.3 Matrizes ortogonais e bases ortonormais

As colunas de uma matriz ortogonal formam uma base ortonormal de $\mathbb{R}^p$.

Se

$$\mathbf{Q} = [\mathbf{q}_1 \quad \mathbf{q}_2 \quad \cdots \quad \mathbf{q}_p],$$

então suas colunas satisfazem

$$\mathbf{q}_i^\top \mathbf{q}_j = \delta_{ij},$$

em que δ_{ij} é o delta de Kronecker definido no Capítulo 2. Portanto, as colunas de $\mathbf{Q}$ possuem norma unitária e são ortogonais duas a duas.

Como

$$\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}_p,$$

as linhas de $\mathbf{Q}$ também formam um conjunto ortonormal.

Uma matriz ortogonal admite, portanto, duas interpretações que devem ser distinguidas:

- como matriz de uma transformação linear que preserva a geometria euclidiana;
- como matriz cujas colunas constituem uma base ortonormal de $\mathbb{R}^p$.

Na primeira interpretação, a matriz atua sobre o vetor e modifica sua posição no espaço. Na segunda, seus vetores-coluna definem um sistema de coordenadas. A relação entre essas duas interpretações será desenvolvida na seção seguinte.

4.5.4 Comparação com transformações não ortogonais

A Figura 4.6 compara o efeito de diferentes matrizes sobre a circunferência unitária e sobre duas direções inicialmente ortogonais. O marcador de ângulo reto identifica os casos em que a ortogonalidade é preservada.

A rotação e a reflexão mantêm a circunferência unitária e preservam o ângulo reto entre as duas direções. O escalonamento não uniforme transforma a circunferência em uma elipse; embora as duas direções coordenadas permaneçam ortogonais neste exemplo particular, seus comprimentos são alterados e a transformação não é ortogonal. O cisalhamento deforma a circunferência e também altera o ângulo entre as direções.

A Tabela 4.3 compara as propriedades dessas transformações.

Tabela 4.3: Comparação entre transformações ortogonais e não ortogonais.

Transformação	Ortogonal	Preserva normas	Preserva distâncias	Preserva ângulos	$ \det(\mathbf{A}) $
Rotação	Sim	Sim	Sim	Sim	1
Reflexão	Sim	Sim	Sim	Sim	1
Escalonamento uniforme	Somente se $ s = 1$	Somente se $ s = 1$	Somente se $ s = 1$	Sim, se $s \neq 0$	$ s ^p$
Escalonamento não uniforme	Não	Não	Não	Não, em geral	$\prod_j s_j $
Cisalhamento	Não	Não	Não	Não, em geral	1
Projeção própria	Não	Não	Não	Não, em geral	0




Figura 4.6: Efeito de transformações ortogonais e não ortogonais sobre a circunferência unitária e duas direções inicialmente ortogonais.

A condição

$$|\det(\mathbf{A})| = 1$$

não é suficiente para que uma matriz seja ortogonal. O cisalhamento possui determinante igual a 1 e preserva áreas, mas não preserva normas nem ângulos.

A condição que caracteriza a preservação da geometria euclidiana é

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_p.$$

4.6 Mudanças de coordenadas e representação em bases

O Capítulo 3 mostrou que um vetor possui coordenadas diferentes quando é representado em bases distintas. O vetor geométrico permanece o mesmo; o que muda é o conjunto de coeficientes utilizado para descrevê-lo.

Retomando a Definição 3.6, seja

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_p\}$$

uma base de $\mathbb{R}^p$, com a ordem dos vetores fixada. Como definido no capítulo anterior, a matriz formada pelos vetores da base é

$$\mathbf{B} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_p].$$

Como os vetores de $\mathcal{B}$ são linearmente independentes, $\mathbf{B}$ é invertível.

Se

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} c_1 \\ \vdots \\ c_p \end{bmatrix}$$

é o vetor de coordenadas de $\mathbf{x}$ na base $\mathcal{B}$, então

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_p \mathbf{b}_p.$$

Em forma matricial,

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Consequentemente,

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{B}^{-1}\mathbf{x}.$$

Assim, $\mathbf{B}$ converte as coordenadas de $\mathbf{x}$ na base $\mathcal{B}$ em suas coordenadas na base canônica, enquanto $\mathbf{B}^{-1}$ realiza a conversão no sentido contrário.

Quando $\mathcal{B}$ é uma base ortonormal, pela Definição 3.9,

$$\mathbf{B}^{\top}\mathbf{B} = \mathbf{I}_p.$$

Logo,

$$\mathbf{B}^{-1} = \mathbf{B}^{\top}$$

e

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{B}^{\top}\mathbf{x}.$$

Nesse caso,

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} \mathbf{b}_1^{\top}\mathbf{x} \\ \vdots \\ \mathbf{b}_p^{\top}\mathbf{x} \end{bmatrix},$$

de modo que cada coordenada é obtida pelo produto interno entre $\mathbf{x}$ e o vetor correspondente da base.

4.6.1 Conversão entre duas bases

Considere duas bases de $\mathbb{R}^p$,

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_p\}$$

e

$$\mathcal{C} = \{\mathbf{c}_1, \dots, \mathbf{c}_p\},$$

e as respectivas matrizes

$$\mathbf{B} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_p]$$

e

$$\mathbf{C} = [\mathbf{c}_1 \quad \dots \quad \mathbf{c}_p].$$

O mesmo vetor pode ser representado por

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}$$

e por

$$\mathbf{x} = \mathbf{C}[\mathbf{x}]_{\mathcal{C}}.$$

Igualando as duas expressões,

$$\mathbf{C}[\mathbf{x}]_{\mathcal{C}} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Multiplicando à esquerda por $\mathbf{C}^{-1}$,

$$[\mathbf{x}]_{\mathcal{C}} = \mathbf{C}^{-1}\mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Definição 4.5 (Matriz de mudança de base). A **matriz de mudança de base de $\mathcal{B}$ para $\mathcal{C}$** é

$$\mathbf{C}^{-1}\mathbf{B}.$$

Ela transforma as coordenadas de um vetor na base $\mathcal{B}$ em suas coordenadas na base $\mathcal{C}$:

$$[\mathbf{x}]_{\mathcal{C}} = (\mathbf{C}^{-1}\mathbf{B}) [\mathbf{x}]_{\mathcal{B}}.$$

O sentido da conversão deve ser observado na ordem das matrizes:

$$\mathcal{B} \longrightarrow \mathcal{C} \quad \Longleftrightarrow \quad \mathbf{C}^{-1}\mathbf{B}.$$

No sentido contrário, a matriz de mudança de base é

$$\mathbf{B}^{-1}\mathbf{C}.$$

As duas matrizes são inversas entre si:

$$\mathbf{B}^{-1}\mathbf{C} = (\mathbf{C}^{-1}\mathbf{B})^{-1}.$$

4.6.2 Representação de uma transformação em bases gerais

Considere uma transformação linear

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

representada nas bases canônicas por

$$\mathbf{y} = \mathbf{A}\mathbf{x},$$

com

$$\mathbf{A} \in \mathbb{R}^{q \times p}.$$

Seja $\mathcal{B}$ uma base do domínio, com matriz

$$\mathbf{B} = [\mathbf{b}_1 \quad \cdots \quad \mathbf{b}_p],$$

e seja $\mathcal{C}$ uma base do contradomínio, com matriz

$$\mathbf{C} = [\mathbf{c}_1 \quad \cdots \quad \mathbf{c}_q].$$

Como

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}},$$

tem-se

$$\begin{aligned} [T(\mathbf{x})]_{\mathcal{C}} &= \mathbf{C}^{-1}T(\mathbf{x}) \\ &= \mathbf{C}^{-1}\mathbf{A}\mathbf{x} \\ &= \mathbf{C}^{-1}\mathbf{A}\mathbf{B}[\mathbf{x}]_{\mathcal{B}}. \end{aligned}$$

Proposição 4.13 (Matriz de uma transformação em bases gerais). *Se uma transformação linear*

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é representada nas bases canônicas por $\mathbf{A}$, sua matriz em relação à base $\mathcal{B}$ do domínio e à base $\mathcal{C}$ do contradomínio é

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \mathbf{C}^{-1}\mathbf{A}\mathbf{B}.$$

Para todo $\mathbf{x} \in \mathbb{R}^p$,

$$[T(\mathbf{x})]_{\mathcal{C}} = [T]_{\mathcal{C} \leftarrow \mathcal{B}}[\mathbf{x}]_{\mathcal{B}}.$$

(Meyer, 2023)

A fórmula pode ser interpretada pela sequência das operações, da direita para a esquerda:

$$[\mathbf{x}]_{\mathcal{B}} \xrightarrow{\mathbf{B}} \mathbf{x} \xrightarrow{\mathbf{A}} T(\mathbf{x}) \xrightarrow{\mathbf{C}^{-1}} [T(\mathbf{x})]_{\mathcal{C}}.$$

As colunas de

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}}$$

são as coordenadas, na base $\mathcal{C}$, das imagens dos vetores da base $\mathcal{B}$:

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \begin{bmatrix} [T(\mathbf{b}_1)]_{\mathcal{C}} & \cdots & [T(\mathbf{b}_p)]_{\mathcal{C}} \end{bmatrix}.$$

Essa construção generaliza a representação matricial nas bases canônicas.

Exemplo 4.4 (Representação de uma transformação em bases distintas). Considere

$$T : \mathbb{R}^2 \longrightarrow \mathbb{R}^2$$

representada na base canônica por

$$\mathbf{A} = \begin{bmatrix} 2 & 0 \\ 1 & 1 \end{bmatrix}.$$

Considere a base do domínio

$$\mathcal{B} = \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \end{bmatrix} \right\}$$

e a base do contradomínio

$$\mathcal{C} = \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}.$$

As matrizes das bases são

$$\mathbf{B} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix}$$

e

$$\mathbf{C} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}.$$

Como

$$\mathbf{C}^{-1} = \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix},$$

tem-se

$$\begin{aligned}
[T]_{\mathcal{C} \leftarrow \mathcal{B}} &= \mathbf{C}^{-1} \mathbf{A} \mathbf{B} \\
&= \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix} \\
&= \begin{bmatrix} 0 & 1 \\ 2 & 1 \end{bmatrix}.
\end{aligned}$$

A primeira coluna é

$$[T(\mathbf{b}_1)]_{\mathcal{C}} = \begin{bmatrix} 0 \\ 2 \end{bmatrix},$$

e a segunda é

$$[T(\mathbf{b}_2)]_{\mathcal{C}} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

4.6.3 Representação de um operador em uma nova base

Considere um operador linear

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

representado na base canônica por $\mathbf{A}$.

Quando a mesma base $\mathcal{B}$ é utilizada no domínio e no contradomínio,

$$[T]_{\mathcal{B} \leftarrow \mathcal{B}} = \mathbf{B}^{-1} \mathbf{A} \mathbf{B}.$$

Quando conveniente, essa matriz será denotada abreviadamente por

$$\mathbf{A}_{\mathcal{B}} = \mathbf{B}^{-1} \mathbf{A} \mathbf{B}.$$

Definição 4.6 (Matrizes semelhantes). Duas matrizes quadradas $\mathbf{A}$ e $\mathbf{D}$ são **semelhantes** quando existe uma matriz invertível $\mathbf{P}$ tal que

$$\mathbf{D} = \mathbf{P}^{-1} \mathbf{A} \mathbf{P}.$$

Matrizes semelhantes representam o mesmo operador linear em bases diferentes. Por essa razão, preservam propriedades que não dependem do sistema de coordenadas.

Proposição 4.14 (Invariantes por semelhança). *Sejam*

$$\mathbf{A}, \mathbf{D}, \mathbf{P} \in \mathbb{R}^{p \times p},$$

com $\mathbf{P}$ invertível. Se

$$\mathbf{D} = \mathbf{P}^{-1} \mathbf{A} \mathbf{P},$$

então

$$\det(\mathbf{D}) = \det(\mathbf{A}),$$

$$\text{tr}(\mathbf{D}) = \text{tr}(\mathbf{A})$$

e

$$\text{posto}(\mathbf{D}) = \text{posto}(\mathbf{A}).$$

(Horn; Johnson, 2013)

Comprovação. Para o determinante,

$$\begin{aligned} \det(\mathbf{D}) &= \det(\mathbf{P}^{-1} \mathbf{A} \mathbf{P}) \\ &= \det(\mathbf{P}^{-1}) \det(\mathbf{A}) \det(\mathbf{P}) \\ &= \det(\mathbf{A}). \end{aligned}$$

Para o traço, pela propriedade cíclica,

$$\begin{aligned} \text{tr}(\mathbf{D}) &= \text{tr}(\mathbf{P}^{-1} \mathbf{A} \mathbf{P}) \\ &= \text{tr}(\mathbf{A} \mathbf{P} \mathbf{P}^{-1}) \\ &= \text{tr}(\mathbf{A}). \end{aligned}$$

Como a multiplicação à esquerda ou à direita por uma matriz invertível não altera o posto,

$$\text{posto}(\mathbf{P}^{-1} \mathbf{A} \mathbf{P}) = \text{posto}(\mathbf{A}).$$

□

A relação entre matrizes semelhantes, autovalores e a representação das direções invariantes em bases diferentes será desenvolvida no capítulo seguinte.

4.6.4 Transformação ativa e mudança passiva

Uma matriz pode representar a transformação de um vetor ou a alteração do sistema de coordenadas utilizado para descrevê-lo. Essas operações são relacionadas, mas não são idênticas.

Em uma **transformação ativa**, os eixos coordenados permanecem fixos e o vetor é modificado:

$$\mathbf{y} = \mathbf{Q}\mathbf{x}.$$

No caso de uma rotação, o vetor muda de posição em relação aos mesmos eixos.

Em uma **mudança passiva de coordenadas**, o vetor geométrico permanece fixo e a base é alterada.

Se as colunas de uma matriz ortogonal $\mathbf{Q}$ formam a nova base

$$\mathcal{B} = \{\mathbf{q}_1, \dots, \mathbf{q}_p\},$$

então

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{Q}^{\top} \mathbf{x} = \mathbf{Q}^{-1} \mathbf{x}.$$

O vetor não se move. Apenas sua representação numérica é modificada.

Para a matriz de rotação $\mathbf{Q}_{\theta}$,

$$\mathbf{Q}_{\theta}^{-1} = \mathbf{Q}_{\theta}^{\top} = \mathbf{Q}_{(-\theta)}.$$

Girar os eixos pelo ângulo θ transforma as coordenadas do vetor por uma rotação de ângulo $-\theta$.

A transformação ativa e a mudança passiva utilizam matrizes inversas:

$$\text{transformação ativa:} \quad \mathbf{y} = \mathbf{Q}\mathbf{x},$$

$$\text{mudança passiva:} \quad [\mathbf{x}]_{\mathcal{B}} = \mathbf{Q}^{-1} \mathbf{x}.$$

Quando $\mathbf{Q}$ é ortogonal,

$$\mathbf{Q}^{-1} = \mathbf{Q}^{\top}.$$

Portanto, embora uma mesma matriz ortogonal possa aparecer nas duas interpretações, o sentido da operação é distinto: na transformação ativa, $\mathbf{Q}$ atua sobre o vetor; na mudança passiva para a base formada pelas colunas de $\mathbf{Q}$, a conversão das coordenadas é realizada por $\mathbf{Q}^{-1} = \mathbf{Q}^\top$.

A Figura 4.7 compara as duas interpretações.




Figura 4.7: Comparação entre uma transformação ativa e uma mudança passiva de coordenadas.

No primeiro painel, os eixos permanecem fixos e $\mathbf{x}$ é transformado em $\mathbf{Q}\mathbf{x}$. No segundo, o vetor permanece fixo e os novos eixos são definidos por $\mathbf{q}_1$ e $\mathbf{q}_2$.

4.6.5 Mudança de coordenadas de uma matriz de dados

Considere

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

com as observações organizadas nas linhas, e uma base ortonormal cujos vetores estão nas colunas de $\mathbf{Q}$.

As coordenadas da i -ésima observação na nova base são

$$\mathbf{z}_i = \mathbf{Q}^\top \mathbf{x}_i.$$

Transpondo,

$$\mathbf{z}_i^\top = \mathbf{x}_i^\top \mathbf{Q}.$$

Portanto, a matriz de novas coordenadas é

$$\mathbf{Z} = \mathbf{X}\mathbf{Q}.$$

Essa expressão deve ser distinguida da transformação ativa por $\mathbf{Q}$, que produz

$$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top.$$

A Tabela 4.4 resume as duas operações.

Tabela 4.4: Transformação ativa e mudança passiva para uma base ortonormal.

Operação	Vetor-coluna	Matriz de dados
Transformação ativa por $\mathbf{Q}$	$\mathbf{y} = \mathbf{Q}\mathbf{x}$	$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top$
Mudança passiva para a base formada pelas colunas de $\mathbf{Q}$	$\mathbf{z} = \mathbf{Q}^\top \mathbf{x}$	$\mathbf{Z} = \mathbf{X}\mathbf{Q}$

Na transformação ativa, a configuração é modificada em relação a um sistema de coordenadas fixo. Na mudança passiva, a configuração permanece a mesma e cada observação passa a ser descrita pelas coordenadas em uma nova base.

4.7 Transformações afins e pré-processamento

Toda transformação linear mantém o vetor nulo fixo:

$$T(\mathbf{0}) = \mathbf{0}.$$

Operações que incluem um deslocamento constante não satisfazem essa propriedade. Elas pertencem a uma classe mais ampla, formada pelas transformações afins.

Definição 4.7 (Transformação afim). Uma aplicação

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é uma **transformação afim** quando pode ser escrita como

$$T(\mathbf{x}) = \mathbf{Ax} + \mathbf{b},$$

em que

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{b} \in \mathbb{R}^q.$$

A matriz $\mathbf{A}$ determina a parte linear da transformação, enquanto $\mathbf{b}$ determina o deslocamento.

Quando

$$\mathbf{b} = \mathbf{0},$$

a transformação afim reduz-se a uma transformação linear.

Quando

$$\mathbf{b} \neq \mathbf{0},$$

tem-se

$$T(\mathbf{0}) = \mathbf{b} \neq \mathbf{0},$$

e a transformação não é linear.

4.7.1 Translação

A translação é o caso particular

$$T(\mathbf{x}) = \mathbf{x} + \mathbf{b}.$$

Todos os pontos são deslocados pelo mesmo vetor $\mathbf{b}$.

Para dois vetores $\mathbf{x}_i$ e $\mathbf{x}_j$,

$$\begin{aligned} T(\mathbf{x}_i) - T(\mathbf{x}_j) &= (\mathbf{x}_i + \mathbf{b}) - (\mathbf{x}_j + \mathbf{b}) \\ &= \mathbf{x}_i - \mathbf{x}_j. \end{aligned}$$

Consequentemente,

$$\|T(\mathbf{x}_i) - T(\mathbf{x}_j)\| = \|\mathbf{x}_i - \mathbf{x}_j\|.$$

A translação preserva:

- diferenças entre os pontos;
- distâncias;
- ângulos entre segmentos;
- forma;
- áreas e volumes.

Ela modifica apenas a posição da configuração em relação à origem.

4.7.2 Transformação afim de uma matriz de dados

Considere uma transformação afim aplicada a cada observação:

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i + \mathbf{b}.$$

Se as observações estão organizadas nas linhas de

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a matriz transformada é

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top + \mathbf{1}_n \mathbf{b}^\top,$$

em que

$$\mathbf{1}_n = \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} \in \mathbb{R}^n.$$

A matriz

$$\mathbf{1}_n \mathbf{b}^\top$$

possui dimensão $n \times q$ e contém n linhas iguais a $\mathbf{b}^\top$. Assim, o mesmo deslocamento é acrescentado a todas as observações.

As dimensões da transformação são

$$\underbrace{\mathbf{X}}_{n \times p} \underbrace{\mathbf{A}^\top}_{p \times q} + \underbrace{\mathbf{1}_n}_{n \times 1} \underbrace{\mathbf{b}^\top}_{1 \times q} = \underbrace{\mathbf{Y}}_{n \times q}.$$

No caso de uma translação pura,

$$\mathbf{A} = \mathbf{I}_p,$$

e

$$\mathbf{Y} = \mathbf{X} + \mathbf{1}_n \mathbf{b}^\top.$$

4.7.3 Centralização

A centralização desloca uma configuração para que um vetor de localização coincida com a origem.

Para um vetor fixo

$$\mathbf{m} \in \mathbb{R}^p,$$

define-se

$$\mathbf{x}_c = \mathbf{x} - \mathbf{m}.$$

Essa operação é afim:

$$T(\mathbf{x}) = \mathbf{I}_p \mathbf{x} - \mathbf{m}.$$

Quando

$$\mathbf{m} \neq \mathbf{0},$$

ela não é linear, pois

$$T(\mathbf{0}) = -\mathbf{m}.$$

Para uma matriz de dados,

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix},$$

a centralização por $\mathbf{m}$ é

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \mathbf{m}^\top.$$

Quando o vetor de localização é a média amostral,

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i,$$

tem-se

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top.$$

Retomando a matriz de centralização,

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top,$$

a matriz centralizada pode ser escrita como

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}.$$

De fato,

$$\begin{aligned}
\mathbf{H}_n \mathbf{X} &= \left(\mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top \right) \mathbf{X} \\
&= \mathbf{X} - \mathbf{1}_n \left(\frac{1}{n} \mathbf{1}_n^\top \mathbf{X} \right) \\
&= \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top.
\end{aligned}$$

A centralização de cada observação em torno de um vetor fixo é uma transformação afim. Em contraste, a aplicação

$$\mathbf{X} \mapsto \mathbf{H}_n \mathbf{X}$$

sobre o espaço das matrizes de dados é linear, pois $\mathbf{H}_n$ é uma matriz fixa.

Além disso,

$$\mathbf{H}_n = \mathbf{H}_n^\top$$

e

$$\mathbf{H}_n^2 = \mathbf{H}_n.$$

Portanto, $\mathbf{H}_n$ é uma matriz de projeção ortogonal. Como

$$\mathbf{H}_n \mathbf{1}_n = \mathbf{0},$$

seu núcleo é

$$\mathcal{N}(\mathbf{H}_n) = \text{span}\{\mathbf{1}_n\},$$

e sua imagem é o subespaço

$$\mathcal{C}(\mathbf{H}_n) = \{\mathbf{z} \in \mathbb{R}^n : \mathbf{1}_n^\top \mathbf{z} = 0\} = \text{span}\{\mathbf{1}_n\}^\perp.$$

Assim, multiplicar uma variável observada por $\mathbf{H}_n$ equivale a projetá-la ortogonalmente sobre o subespaço dos vetores cujas componentes somam zero.

Como $\mathbf{H}_n$ é simétrica e

$$\mathbf{H}_n \mathbf{1}_n = \mathbf{0},$$

tem-se também

$$\mathbf{1}_n^\top \mathbf{H}_n = \mathbf{0}^\top.$$

Consequentemente,

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{1}_n^\top \mathbf{H}_n \mathbf{X} = \mathbf{0}^\top.$$

Portanto, cada coluna de $\mathbf{X}_c$ possui média igual a zero.

Proposição 4.15 (Preservação das distâncias pela centralização). *Se*

$$\mathbf{x}_{ci} = \mathbf{x}_i - \mathbf{m}$$

e

$$\mathbf{x}_{cj} = \mathbf{x}_j - \mathbf{m},$$

então

$$\|\mathbf{x}_{ci} - \mathbf{x}_{cj}\| = \|\mathbf{x}_i - \mathbf{x}_j\|.$$

Comprovação. Tem-se

$$\begin{aligned}\mathbf{x}_{ci} - \mathbf{x}_{cj} &= (\mathbf{x}_i - \mathbf{m}) - (\mathbf{x}_j - \mathbf{m}) \\ &= \mathbf{x}_i - \mathbf{x}_j.\end{aligned}$$

Logo, as duas diferenças possuem a mesma norma. □

A centralização modifica a posição da nuvem em relação à origem, mas preserva sua configuração interna.

4.7.4 Escalonamento das variáveis

Considere uma matriz diagonal

$$\mathbf{L} = \text{diag}(\ell_1, \dots, \ell_p),$$

com

$$\ell_j > 0, \quad j = 1, \dots, p.$$

A transformação

$$\mathbf{y} = \mathbf{L}^{-1}\mathbf{x}$$

divide cada coordenada por sua escala correspondente:

$$y_j = \frac{x_j}{\ell_j}.$$

Essa operação é linear e, para uma matriz de dados, assume a forma

$$\mathbf{Y} = \mathbf{X}\mathbf{L}^{-1}.$$

A multiplicação ocorre à direita porque as variáveis ocupam as colunas de $\mathbf{X}$.

Quando as escalas são diferentes, o escalonamento modifica, em geral, distâncias e ângulos. Alguns pares particulares de vetores podem manter sua relação angular, mas a geometria euclidiana não é preservada para todos os vetores. Para duas observações,

$$\|\mathbf{L}^{-1}\mathbf{x}_i - \mathbf{L}^{-1}\mathbf{x}_j\|^2 = (\mathbf{x}_i - \mathbf{x}_j)^\top \mathbf{L}^{-2} (\mathbf{x}_i - \mathbf{x}_j).$$

O escalonamento induz, no espaço original, a geometria determinada pela matriz positiva definida

$$\mathbf{L}^{-2}.$$

Variáveis associadas a escalas menores recebem maior peso nas distâncias transformadas. Quando todas as escalas são iguais, isto é,

$$\mathbf{L} = \ell \mathbf{I}_p,$$

o escalonamento é uniforme: todas as distâncias são multiplicadas pelo mesmo fator $1/\ell$ e os ângulos são preservados.

4.7.5 Padronização

A padronização combina centralização e escalonamento.

Para um vetor de localização $\mathbf{m}$ e uma matriz diagonal de escalas positivas $\mathbf{L}$, define-se

$$\mathbf{z} = \mathbf{L}^{-1} (\mathbf{x} - \mathbf{m}).$$

Essa expressão pode ser reorganizada como

$$\mathbf{z} = \mathbf{L}^{-1}\mathbf{x} - \mathbf{L}^{-1}\mathbf{m}.$$

Portanto, a padronização é uma transformação afim com

$$\mathbf{A} = \mathbf{L}^{-1}$$

e

$$\mathbf{b} = -\mathbf{L}^{-1}\mathbf{m}.$$

Para uma matriz de dados,

$$\mathbf{Z} = (\mathbf{X} - \mathbf{1}_n \mathbf{m}^\top) \mathbf{L}^{-1}.$$

Quando $\mathbf{m} = \bar{\mathbf{x}}$ e os elementos diagonais de $\mathbf{L}$ são os desvios-padrão amostrais, cada coluna de $\mathbf{Z}$ possui média zero e desvio-padrão igual a 1, desde que todas as variáveis apresentem desvio-padrão amostral positivo.

A interpretação da padronização como transformação afim considera $\mathbf{m}$ e $\mathbf{L}$ fixados. Quando o vetor de médias e os desvios-padrão são calculados a partir da própria matriz de dados $\mathbf{X}$, esses elementos passam a depender dos dados. Nesse caso, para os valores calculados de $\mathbf{m}$ e $\mathbf{L}$, cada observação é submetida à transformação afim

$$\mathbf{x} \mapsto \mathbf{L}^{-1} (\mathbf{x} - \mathbf{m}),$$

mas a operação completa que associa a matriz original $\mathbf{X}$ à matriz padronizada $\mathbf{Z}$ é dependente dos dados e não constitui, globalmente, uma transformação afim de $\mathbf{X}$.

Para duas observações padronizadas,

$$\begin{aligned}\mathbf{z}_i - \mathbf{z}_j &= \mathbf{L}^{-1} (\mathbf{x}_i - \mathbf{m}) - \mathbf{L}^{-1} (\mathbf{x}_j - \mathbf{m}) \\ &= \mathbf{L}^{-1} (\mathbf{x}_i - \mathbf{x}_j) .\end{aligned}$$

Logo,

$$\|\mathbf{z}_i - \mathbf{z}_j\|^2 = (\mathbf{x}_i - \mathbf{x}_j)^\top \mathbf{L}^{-2} (\mathbf{x}_i - \mathbf{x}_j) .$$

A translação associada à centralização não altera as diferenças entre observações. A alteração da geometria decorre do escalonamento.

4.7.6 Ordem entre centralização e escalonamento

A padronização usual é

$$\mathbf{z} = \mathbf{L}^{-1} (\mathbf{x} - \mathbf{m}) .$$

Se o escalonamento for aplicado primeiro,

$$\mathbf{y} = \mathbf{L}^{-1} \mathbf{x} ,$$

o vetor de localização também deve ser expresso na nova escala:

$$\mathbf{L}^{-1} \mathbf{m} .$$

Assim,

$$\mathbf{z} = \mathbf{y} - \mathbf{L}^{-1} \mathbf{m} .$$

As duas sequências produzem o mesmo resultado quando o vetor de centralização é transformado juntamente com os dados.

4.7.7 Composição e inversão de transformações afins

Considere

$$T_1(\mathbf{x}) = \mathbf{Ax} + \mathbf{b}$$

e

$$T_2(\mathbf{y}) = \mathbf{Cy} + \mathbf{d}.$$

A composição é

$$\begin{aligned} T_2(T_1(\mathbf{x})) &= \mathbf{C}(\mathbf{Ax} + \mathbf{b}) + \mathbf{d} \\ &= \mathbf{CAx} + \mathbf{Cb} + \mathbf{d}. \end{aligned}$$

Portanto,

$$(T_2 \circ T_1)(\mathbf{x}) = \mathbf{CAx} + (\mathbf{Cb} + \mathbf{d}).$$

A composição de transformações afins também é afim.

Considere agora

$$\mathbf{y} = \mathbf{Ax} + \mathbf{b},$$

com $\mathbf{A}$ quadrada e invertível. Subtraindo $\mathbf{b}$ e multiplicando por $\mathbf{A}^{-1}$,

$$\mathbf{x} = \mathbf{A}^{-1}(\mathbf{y} - \mathbf{b}).$$

A transformação inversa é

$$T^{-1}(\mathbf{y}) = \mathbf{A}^{-1}\mathbf{y} - \mathbf{A}^{-1}\mathbf{b}.$$

Uma transformação afim de $\mathbb{R}^p$ em $\mathbb{R}^p$ é invertível se, e somente se, sua parte linear $\mathbf{A}$ é invertível.




Figura 4.8: Efeito da centralização, do escalonamento e da padronização sobre uma mesma configuração de dados.

4.7.8 Comparação das operações de pré-processamento

A Figura 4.8 compara centralização, escalonamento e padronização de uma mesma nuvem de pontos. O mesmo vetor de escalas é utilizado no escalonamento e na padronização, permitindo separar visualmente o efeito da alteração de escala do efeito da centralização.

A centralização desloca a nuvem para que sua média coincida com a origem, sem modificar as diferenças nem as distâncias entre as observações. O escalonamento altera as unidades das coordenadas e, em geral, modifica comprimentos, distâncias e ângulos. A padronização combina esses dois efeitos: centraliza a nuvem e reescala suas coordenadas.

A Tabela 4.5 resume as diferenças entre as transformações estudadas nesta seção.

Tabela 4.5: Comparação entre transformações lineares, transformações afins e operações de pré-processamento.

Operação	Expressão para um vetor	Linear como função de $\mathbf{x}$?	Mantém a origem fixa?
Transformação linear	$\mathbf{Ax}$	Sim	Sim
Translação	$\mathbf{x} + \mathbf{b}$	Não, se $\mathbf{b} \neq \mathbf{0}$	Não
Transformação afim	$\mathbf{Ax} + \mathbf{b}$	Não, em geral	Não, em geral
Centralização	$\mathbf{x} - \mathbf{m}$	Não, se $\mathbf{m} \neq \mathbf{0}$	Não
Escalação	$\mathbf{L}^{-1}\mathbf{x}$	Sim	Sim
Padronização	$\mathbf{L}^{-1}(\mathbf{x} - \mathbf{m})$	Não, em geral	Não, em geral

Transformações lineares podem modificar direção, escala ou dimensão, mas mantêm necessariamente a origem fixa. Transformações afins acrescentam a possibilidade de deslocar a configuração. A centralização e a padronização pertencem a essa segunda classe quando consideradas como operações sobre uma observação individual e para parâmetros de localização e escala fixados. Quando a centralização de uma matriz de dados é escrita como $\mathbf{X} \mapsto \mathbf{H}_n \mathbf{X}$, a operação é linear no espaço das matrizes.

4.8 Síntese do capítulo

Uma transformação linear preserva combinações lineares. Para uma transformação

$$T : V \longrightarrow W,$$

tem-se

$$T(\alpha \mathbf{u} + \beta \mathbf{v}) = \alpha T(\mathbf{u}) + \beta T(\mathbf{v}).$$

Essa propriedade implica, entre outras consequências,

$$T(\mathbf{0}) = \mathbf{0},$$

e permite determinar uma transformação linear a partir de sua ação sobre uma base do domínio.

Fixadas as bases do domínio e do contradomínio, uma transformação linear possui uma representação matricial única. Em particular, nas bases canônicas, uma transformação

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é representada por

$$T_{\mathbf{A}}(\mathbf{x}) = \mathbf{Ax}, \quad \mathbf{A} \in \mathbb{R}^{q \times p}.$$

Quando as observações ocupam as linhas de uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a transformação simultânea das observações é

$$\mathbf{Y} = \mathbf{XA}^{\top}.$$

Cada linha de $\mathbf{Y}$ representa uma observação transformada, enquanto cada coluna corresponde a uma combinação linear das variáveis originais.

A matriz associada à transformação permite relacionar os conceitos desenvolvidos neste capítulo aos espaços fundamentais estudados anteriormente:

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A})$$

e

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}).$$

Assim, o núcleo reúne os vetores eliminados pela transformação, enquanto a imagem contém todos os vetores que podem ser produzidos por ela. Pelo teorema posto-nulidade,

$$\dim \ker(T_{\mathbf{A}}) + \dim \operatorname{Im}(T_{\mathbf{A}}) = p,$$

ou, equivalentemente,

$$\dim \mathcal{N}(\mathbf{A}) + \operatorname{posto}(\mathbf{A}) = p.$$

O posto é, portanto, a dimensão da imagem da transformação. Quando o núcleo contém vetores não nulos, diferentes vetores do domínio podem possuir a mesma imagem e ocorre perda de informação.

Para uma transformação quadrada, as condições

$$\ker(T_{\mathbf{A}}) = \{\mathbf{0}\},$$

$$\operatorname{Im}(T_{\mathbf{A}}) = \mathbb{R}^p,$$

$$\operatorname{posto}(\mathbf{A}) = p,$$

$$\det(\mathbf{A}) \neq 0$$

e a existência de $\mathbf{A}^{-1}$ são equivalentes.

A composição de transformações corresponde ao produto de suas matrizes. Se T_1 é representada por $\mathbf{A}_1$ e T_2 por $\mathbf{A}_2$, então

$$[T_2 \circ T_1] = \mathbf{A}_2 \mathbf{A}_1.$$

A matriz situada à direita atua primeiro. Como o produto matricial não é comutativo, a ordem das transformações pode alterar o resultado.

As transformações geométricas estudadas ilustram diferentes efeitos possíveis sobre uma configuração. Rotações e reflexões são transformações ortogonais e preservam a geometria euclidiana. Escalonamentos alteram as escalas das direções coordenadas; cisalhamentos modificam, em geral, ângulos e comprimentos; projeções eliminam componentes pertencentes ao complemento do subespaço sobre o qual se projeta.

Para uma transformação quadrada,

$$|\det(\mathbf{A})|$$

representa o fator de alteração do volume p -dimensional. Quando $\det(\mathbf{A}) \neq 0$, seu sinal informa também o efeito sobre a orientação: valores positivos preservam a orientação e valores negativos a invertem. Se

$$\det(\mathbf{A}) = 0,$$

a transformação reduz a dimensão e o volume p -dimensional da imagem é igual a zero.

As transformações ortogonais são caracterizadas por

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_p.$$

Elas preservam produtos internos e, conseqüentemente, normas, distâncias, ângulos e ortogonalidade. Além disso,

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top$$

e

$$\det(\mathbf{Q}) \in \{-1, 1\},$$

de modo que também preservam volumes p -dimensionais.

As colunas de uma matriz ortogonal formam uma base ortonormal e satisfazem

$$\mathbf{q}_i^\top \mathbf{q}_j = \delta_{ij}.$$

Essa propriedade estabelece a ligação entre transformações ortogonais e sistemas de coordenadas ortonormais.

Se

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_p\}$$

é uma base de $\mathbb{R}^p$ e

$$\mathbf{B} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_p],$$

então

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}$$

e

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{B}^{-1}\mathbf{x}.$$

Para duas bases $\mathcal{B}$ e $\mathcal{C}$, com matrizes $\mathbf{B}$ e $\mathbf{C}$, respectivamente, a conversão das coordenadas de $\mathcal{B}$ para $\mathcal{C}$ é

$$[\mathbf{x}]_{\mathcal{C}} = \mathbf{C}^{-1}\mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Se uma transformação é representada nas bases canônicas por $\mathbf{A}$, sua matriz em relação à base $\mathcal{B}$ do domínio e à base $\mathcal{C}$ do contradomínio é

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \mathbf{C}^{-1}\mathbf{A}\mathbf{B}.$$

Quando a mesma base é utilizada no domínio e no contradomínio,

$$\mathbf{A}_{\mathcal{B}} = \mathbf{B}^{-1}\mathbf{A}\mathbf{B},$$

de modo que as duas matrizes são semelhantes e representam o mesmo operador em sistemas de coordenadas distintos.

A transformação ativa e a mudança passiva de coordenadas devem ser diferenciadas. Se $\mathbf{Q}$ é ortogonal, na transformação ativa,

$$\mathbf{y} = \mathbf{Q}\mathbf{x},$$

enquanto, na mudança passiva para a base formada pelas colunas de $\mathbf{Q}$,

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{Q}^{\top}\mathbf{x}.$$

Na primeira situação, o vetor é transformado em relação a eixos fixos. Na segunda, o vetor geométrico permanece o mesmo e apenas sua representação em coordenadas é alterada.

As transformações afins generalizam as transformações lineares por meio da inclusão de uma translação:

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b}.$$

A centralização de uma observação em torno de um vetor fixo é uma transformação afim, enquanto o escalonamento é uma transformação linear diagonal. A padronização combina essas duas operações.

Para uma matriz de dados, a centralização pela média amostral pode ser escrita como

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X},$$

em que

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

Como

$$\mathbf{H}_n^\top = \mathbf{H}_n$$

e

$$\mathbf{H}_n^2 = \mathbf{H}_n,$$

a matriz $\mathbf{H}_n$ é uma matriz de projeção ortogonal. Sua imagem é

$$\mathcal{C}(\mathbf{H}_n) = \text{span}\{\mathbf{1}_n\}^\perp,$$

o subespaço dos vetores cujas componentes somam zero.

A Tabela 4.6 reúne algumas das principais expressões desenvolvidas no capítulo.

Tabela 4.6: Síntese das transformações desenvolvidas no capítulo.

Objeto ou operação	Expressão	Interpretação
Transformação linear	$T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}$	Preserva combinações lineares
Transformação dos dados	$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top$	Transforma simultaneamente as observações
Núcleo	$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A})$	Reúne os vetores enviados ao vetor nulo
Imagem	$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})$	Reúne os vetores alcançados pela transformação
Composição	$(T_2 \circ T_1)(\mathbf{x}) = \mathbf{A}_2 \mathbf{A}_1 \mathbf{x}$	Aplica T_1 antes de T_2
Transformação inversa	$\mathbf{x} = \mathbf{A}^{-1} \mathbf{y}$	Recupera o vetor original quando $\mathbf{A}$ é invertível
Rotação	$\mathbf{Q}_\theta \mathbf{x}$	Preserva a geometria e a orientação

Objeto ou operação	Expressão	Interpretação
Reflexão	$\mathbf{F}\mathbf{x}$	Preserva a geometria; seu efeito sobre a orientação é determinado pelo determinante
Escalonamento	$\mathbf{L}\mathbf{x}$	Reescala direções coordenadas
Cisalhamento	$\mathbf{C}_{ij}(k)\mathbf{x}$	Inclina a configuração preservando volume no caso elementar
Projeção ortogonal	$\mathbf{P}_S\mathbf{x}$	Mantém a componente em S e elimina a componente em $S^\perp$
Coordenadas em uma base	$[\mathbf{x}]_{\mathcal{B}} = \mathbf{B}^{-1}\mathbf{x}$	Representa o mesmo vetor na base $\mathcal{B}$
Mudança de $\mathcal{B}$ para $\mathcal{C}$	$[\mathbf{x}]_{\mathcal{C}} = \mathbf{C}^{-1}\mathbf{B}[\mathbf{x}]_{\mathcal{B}}$	Converte coordenadas entre bases
Transformação em bases gerais	$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \mathbf{C}^{-1}\mathbf{A}\mathbf{B}$	Representa a transformação nas bases escolhidas
Transformação afim	$\mathbf{A}\mathbf{x} + \mathbf{b}$	Combina transformação linear e translação
Centralização dos dados	$\mathbf{X}_c = \mathbf{H}_n\mathbf{X}$	Projeta cada variável no subespaço de média zero
Padronização	$\mathbf{L}^{-1}(\mathbf{x} - \mathbf{m})$	Ajusta localização e escala

Ao final deste capítulo, o estudante deverá ser capaz de:

- reconhecer e verificar a linearidade de uma transformação;
- construir a matriz de uma transformação a partir da imagem de uma base;
- relacionar núcleo e imagem de uma transformação ao espaço nulo e ao espaço coluna da matriz associada;
- interpretar posto, injetividade, sobrejetividade, bijetividade e perda de informação;
- representar a composição e a inversão de transformações por operações matriciais;
- interpretar geometricamente rotações, reflexões, escalonamentos, cisalhamentos e projeções;
- relacionar o determinante à alteração de volume, à orientação e à redução de dimensão;
- reconhecer transformações ortogonais e interpretar as propriedades geométricas que elas preservam;
- converter coordenadas entre bases;
- representar uma transformação linear em bases distintas do domínio e do contradomínio;
- distinguir transformação ativa e mudança passiva de coordenadas;
- interpretar transformações afins, centralização, escalonamento e padronização;

- reconhecer a matriz de centralização como uma matriz de projeção ortogonal.

No próximo capítulo, serão estudadas direções especiais para as quais a ação de uma transformação linear produz um múltiplo escalar do próprio vetor,

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

Essas direções conduzem aos conceitos de autovetores, autovalores, autoespaços e decomposição espectral.

5 Autovalores, autovetores e decomposição espectral

No capítulo anterior, uma transformação linear foi representada por uma matriz e interpretada como uma operação capaz de modificar direções, comprimentos, ângulos e volumes. Quando o domínio e o contradomínio coincidem, a transformação é um operador linear

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^p, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

representado por uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Vimos também que a matriz de um operador depende da base utilizada para representá-lo. Uma mudança de base pode produzir uma matriz mais simples, embora o operador linear permaneça o mesmo. Neste capítulo, procuraremos bases especialmente adaptadas à ação do operador.

Algumas direções possuem um comportamento particularmente simples: quando um vetor pertence a uma dessas direções, sua imagem permanece na mesma reta que passa pela origem. A identificação dessas direções conduz aos conceitos de autovalor, autovetor e autoespaço.

Quando existem autovetores linearmente independentes em número suficiente, eles formam uma base na qual a matriz do operador é diagonal. A diagonalização pode, portanto, ser interpretada como uma mudança para um sistema de coordenadas em que a transformação atua separadamente sobre cada direção da base.

Para matrizes simétricas reais, essa simplificação possui propriedades adicionais: todos os autovalores são reais e existe uma base ortonormal de autovetores. A decomposição resultante permitirá interpretar formas quadráticas, matrizes positivas definidas, elipsoides, funções de matrizes e problemas de otimização. Essas estruturas serão retomadas nos capítulos de SVD, covariâncias e técnicas multivariadas.

Convenções de notação

Ao longo deste capítulo:

- λ representa um autovalor;

- $\mathbf{v}$ representa um autovetor;
- $\mathcal{E}_\lambda$ representa o autoespaço associado a λ ;
- $m_a(\lambda)$ e $m_g(\lambda)$ representam, respectivamente, as multiplicidades algébrica e geométrica;
- $\mathcal{B}_\mathbf{A}$ representa uma base de autovetores de $\mathbf{A}$, quando tal base existe;
- $\mathbf{B}_\mathbf{A}$ representa a matriz formada pelos vetores da base $\mathcal{B}_\mathbf{A}$;
- $\Lambda_\mathbf{A}$ representa a matriz diagonal dos autovalores correspondente à ordenação escolhida dos autovetores;
- $\mathbf{Q}_\mathbf{A}$ representa uma matriz ortogonal de autovetores quando $\mathbf{A}$ é simétrica;
- Π_λ representa o projetor espectral associado ao autoespaço de λ ;
- $\mathcal{R}_\mathbf{A}(\mathbf{x})$ representa o quociente de Rayleigh.

Salvo indicação contrária, as interpretações geométricas serão desenvolvidas em espaços vetoriais reais. Autovalores e autovetores complexos serão considerados explicitamente quando necessário.

5.1 Direções invariantes, autovalores e autoespaços

Definição 5.1 (Subespaço invariante). Considere

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e um subespaço

$$\mathcal{W} \subseteq \mathbb{R}^p.$$

O subespaço $\mathcal{W}$ é **invariante sob $\mathbf{A}$** quando

$$\mathbf{A}\mathbf{w} \in \mathcal{W}$$

para todo

$$\mathbf{w} \in \mathcal{W}.$$

Isso significa que a multiplicação por $\mathbf{A}$ transforma vetores de $\mathcal{W}$ em vetores que permanecem no próprio subespaço $\mathcal{W}$.

Um caso particularmente importante ocorre quando o subespaço invariante possui dimensão 1.

Seja

$$\mathbf{v} \in \mathbb{R}^p, \quad \mathbf{v} \neq \mathbf{0}.$$

O subespaço gerado por $\mathbf{v}$ é

$$\mathcal{W} = \text{span}\{\mathbf{v}\} = \{c\mathbf{v} : c \in \mathbb{R}\}.$$

Como $\mathbf{v} \neq \mathbf{0}$, o conjunto $\{\mathbf{v}\}$ é uma base de $\mathcal{W}$ e, portanto,

$$\dim(\mathcal{W}) = 1.$$

Geometricamente, $\mathcal{W}$ corresponde a uma reta que passa pela origem e está contida em $\mathbb{R}^p$.

Se $\mathcal{W}$ é invariante sob $\mathbf{A}$, então

$$\mathbf{A}\mathbf{v} \in \mathcal{W}.$$

Como todos os vetores de $\mathcal{W}$ são múltiplos escalares de $\mathbf{v}$, existe um escalar λ tal que

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

Assim, a ação de $\mathbf{A}$ sobre $\mathbf{v}$ mantém sua imagem na mesma reta gerada por $\mathbf{v}$. A magnitude pode ser alterada e, dependendo do sinal de λ , também pode ocorrer mudança de sentido.

Exemplo 5.1 (Uma reta invariante em $\mathbb{R}^2$). Considere

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$$

e o vetor

$$\mathbf{v} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

O subespaço gerado por $\mathbf{v}$ é

$$\mathcal{W} = \text{span} \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\},$$

que corresponde à reta

$$x_2 = x_1$$

em $\mathbb{R}^2$.

Aplicando $\mathbf{A}$ ao vetor $\mathbf{v}$,

$$\begin{aligned} \mathbf{A}\mathbf{v} &= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ &= \begin{bmatrix} 3 \\ 3 \end{bmatrix} = 3 \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ &= 3\mathbf{v}. \end{aligned}$$

Portanto,

$$\mathbf{A}\mathbf{v} \in \mathcal{W},$$

e a reta $\mathcal{W}$ é invariante sob $\mathbf{A}$. Nesse caso, a transformação multiplica os vetores dessa direção por um fator igual a 3, sem retirar suas imagens da reta.

A relação

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

observada nesse caso conduz às definições de autovalor e autovetor.

Definição 5.2 (Autovalor e autovetor). Seja

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Um escalar $\lambda \in \mathbb{R}$ é um **autovalor** de $\mathbf{A}$ quando existe um vetor

$$\mathbf{v} \in \mathbb{R}^p, \quad \mathbf{v} \neq \mathbf{0},$$

tal que

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

O vetor $\mathbf{v}$ é denominado **autovetor** de $\mathbf{A}$ associado ao autovalor λ . O par $(\lambda, \mathbf{v})$ é denominado **autopar** de $\mathbf{A}$.

A equação

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

mostra que a transformação não combina a direção de $\mathbf{v}$ com outras direções do espaço. Sua ação sobre esse vetor consiste em alterar seu comprimento e, possivelmente, seu sentido.

O módulo de λ determina a alteração do comprimento:

- se $|\lambda| > 1$, ocorre expansão;
- se $0 < |\lambda| < 1$, ocorre contração;
- se $|\lambda| = 1$, o comprimento é preservado;
- se $\lambda = 0$, o vetor é transformado no vetor nulo.

O sinal determina o sentido:

- se $\lambda > 0$, o sentido é preservado;
- se $\lambda < 0$, o sentido é invertido.

Portanto, quando $\lambda = -1$, o vetor tem seu sentido invertido sem alteração do comprimento. Quando $\lambda = 0$, a reta gerada pelo autovetor continua sendo um subespaço invariante, pois toda a reta é enviada ao vetor nulo, mas sua direção deixa de aparecer na imagem da transformação.

Exemplo 5.2 (Direções invariantes de uma matriz simétrica). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Para o vetor

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

tem-se

$$\begin{aligned}\mathbf{A}\mathbf{v}_1 &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ &= \begin{bmatrix} 4 \\ 4 \end{bmatrix} \\ &= 4 \begin{bmatrix} 1 \\ 1 \end{bmatrix}.\end{aligned}$$

Assim,

$$\mathbf{A}\mathbf{v}_1 = 4\mathbf{v}_1,$$

e $\mathbf{v}_1$ é um autovetor associado ao autovalor

$$\lambda_1 = 4.$$

Para

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

obtém-se

$$\begin{aligned}\mathbf{A}\mathbf{v}_2 &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\ &= \begin{bmatrix} 2 \\ -2 \end{bmatrix} \\ &= 2 \begin{bmatrix} 1 \\ -1 \end{bmatrix}.\end{aligned}$$

Portanto,

$$\mathbf{A}\mathbf{v}_2 = 2\mathbf{v}_2,$$

e $\mathbf{v}_2$ é um autovetor associado ao autovalor

$$\lambda_2 = 2.$$

Considere agora

$$\mathbf{x} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Sua imagem é

$$\mathbf{Ax} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

Não existe um escalar λ que satisfaça

$$\begin{bmatrix} 3 \\ 1 \end{bmatrix} = \lambda \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Logo, $\mathbf{x}$ não é um autovetor de $\mathbf{A}$. A transformação modifica seu comprimento e sua direção.

A Figura 5.1 compara as imagens dos autovetores $\mathbf{v}_1$ e $\mathbf{v}_2$ com a imagem do vetor genérico $\mathbf{x}$. As retas tracejadas em cinza representam as duas direções invariantes.

As retas tracejadas representam as direções geradas por $\mathbf{v}_1$ e $\mathbf{v}_2$. A transformação amplia os vetores por fatores diferentes, mas mantém cada um na reta correspondente. O vetor $\mathbf{x}$ não pertence a uma direção invariante e sua imagem ocupa outra direção.

Um autovetor não é único. Se $\mathbf{v}$ é um autovetor associado ao autovalor λ , então qualquer múltiplo não nulo de $\mathbf{v}$ também é um autovetor associado ao mesmo autovalor.

Proposição 5.1 (Múltiplos de um autovetor). *Se $\mathbf{v}$ é um autovetor de $\mathbf{A}$ associado ao autovalor λ , então todo múltiplo*

$$c\mathbf{v}, \quad c \neq 0,$$

também é um autovetor associado a λ .

Comprovação. Como

$$\mathbf{Av} = \lambda\mathbf{v},$$

pela linearidade,

$$\begin{aligned} \mathbf{A}(c\mathbf{v}) &= c\mathbf{Av} \\ &= c\lambda\mathbf{v} \\ &= \lambda(c\mathbf{v}). \end{aligned}$$




Figura 5.1: Autovetores permanecem nas mesmas direções após a transformação, enquanto um vetor genérico pode ter sua direção modificada.

Como $c \neq 0$ e $\mathbf{v} \neq \mathbf{0}$, tem-se $c\mathbf{v} \neq \mathbf{0}$. Portanto, $c\mathbf{v}$ é um autovetor associado a λ . □

Para reunir todos os autovetores associados ao mesmo autovalor, reorganiza-se a equação

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

como

$$(\mathbf{A} - \lambda\mathbf{I}_p)\mathbf{v} = \mathbf{0}.$$

O conjunto de soluções é o núcleo de

$$\mathbf{A} - \lambda\mathbf{I}_p.$$

Definição 5.3 (Autoespaço). Se λ é um autovalor de

$$\mathbf{A} \in \mathbb{R}^{p \times p},$$

o **autoespaço** associado a λ é

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p).$$

Os autovetores associados a λ são os elementos não nulos de $\mathcal{E}_\lambda$:

$$\mathcal{E}_\lambda \setminus \{\mathbf{0}\}.$$

O vetor nulo pertence a todo autoespaço, mas não é considerado um autovetor. A igualdade

$$\mathbf{A}\mathbf{0} = \lambda\mathbf{0}$$

é satisfeita para qualquer λ e não identifica uma direção.

Proposição 5.2 (Estrutura e invariância do autoespaço). *Se λ é um autovalor de $\mathbf{A}$, então $\mathcal{E}_\lambda$ é um subespaço não trivial de $\mathbb{R}^p$ e é invariante sob $\mathbf{A}$.*

Comprovação. Como

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda \mathbf{I}_p),$$

o autoespaço é o núcleo de uma transformação linear e, portanto, é um subespaço de $\mathbb{R}^p$.

Como λ é um autovalor, existe pelo menos um vetor não nulo $\mathbf{v}$ tal que

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}.$$

Logo,

$$\mathcal{E}_\lambda \neq \{\mathbf{0}\}.$$

Para qualquer $\mathbf{w} \in \mathcal{E}_\lambda$,

$$\mathbf{A}\mathbf{w} = \lambda\mathbf{w}.$$

Como $\mathcal{E}_\lambda$ é fechado pela multiplicação por escalares,

$$\lambda\mathbf{w} \in \mathcal{E}_\lambda.$$

Portanto,

$$\mathbf{A}\mathbf{w} \in \mathcal{E}_\lambda,$$

e o autoespaço é invariante sob $\mathbf{A}$. □

Quando

$$\dim(\mathcal{E}_\lambda) = 1,$$

o autoespaço determina uma única direção invariante. Todos os autovetores associados a λ são múltiplos não nulos de um mesmo vetor.

Quando

$$\dim(\mathcal{E}_\lambda) > 1,$$

o autovalor está associado a várias direções linearmente independentes. Nesse caso, o objeto geométrico determinado pela matriz é todo o autoespaço. Uma base específica desse subespaço não é necessariamente única.

A definição do autoespaço transforma a busca por autovetores em um problema de núcleo. Para um valor fixado de λ , existem autovetores associados precisamente quando

$$\mathcal{N}(\mathbf{A} - \lambda \mathbf{I}_p) \neq \{\mathbf{0}\}.$$

Resta, portanto, determinar quais valores de λ tornam esse núcleo não trivial. Essa condição equivale à singularidade de $\mathbf{A} - \lambda \mathbf{I}_p$ e conduz à equação característica.

5.2 Equação característica, multiplicidades e diagonalização

A definição de autovalor permite verificar se um vetor conhecido determina uma direção invariante. Para encontrar essas direções a partir de uma matriz, é necessário determinar os valores de λ para os quais

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}$$

possui soluções não triviais.

Esse é um sistema linear homogêneo.

Se

$$\mathbf{A} - \lambda \mathbf{I}_p$$

fosse invertível, sua única solução seria $\mathbf{v} = \mathbf{0}$. Portanto, um autovalor deve tornar essa matriz singular.

Teorema 5.1 (Caracterização dos autovalores pelo determinante). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Um escalar $\lambda \in \mathbb{R}$ é autovalor de $\mathbf{A}$ se, e somente se,

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0.$$

Comprovação. Se λ é autovalor de $\mathbf{A}$, existe um vetor não nulo $\mathbf{v}$ tal que

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}.$$

Como o sistema possui uma solução não trivial, a matriz

$$\mathbf{A} - \lambda \mathbf{I}_p$$

não é invertível. Logo,

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0.$$

Reciprocamente, se

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0,$$

a matriz é singular. Portanto, seu núcleo contém pelo menos um vetor não nulo $\mathbf{v}$, para o qual

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}.$$

Consequentemente,

$$\mathbf{A} \mathbf{v} = \lambda \mathbf{v},$$

e λ é autovalor de $\mathbf{A}$. □

Definição 5.4 (Polinômio e equação característicos). O **polinômio característico** de uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é definido por

$$p_{\mathbf{A}}(\lambda) = \det(\mathbf{A} - \lambda \mathbf{I}_p).$$

A equação

$$p_{\mathbf{A}}(\lambda) = 0$$

é denominada **equação característica** de $\mathbf{A}$. (Horn; Johnson, 2013)

Também é possível definir o polinômio característico por

$$\det(\lambda \mathbf{I}_p - \mathbf{A}).$$

As duas convenções diferem pelo fator $(-1)^p$ e possuem as mesmas raízes. Portanto, produzem os mesmos autovalores.

O polinômio característico de uma matriz de ordem p possui grau p . Consideradas suas multiplicidades, ele possui p raízes no conjunto dos números complexos. Uma matriz real pode ter autovalores reais, autovalores complexos ou ambos.

5.2.1 Determinação dos autovalores e autoespaços

Considere novamente

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Tem-se

$$\mathbf{A} - \lambda \mathbf{I}_2 = \begin{bmatrix} 3 - \lambda & 1 \\ 1 & 3 - \lambda \end{bmatrix}.$$

O polinômio característico é

$$\begin{aligned} p_{\mathbf{A}}(\lambda) &= \det \begin{bmatrix} 3 - \lambda & 1 \\ 1 & 3 - \lambda \end{bmatrix} \\ &= (3 - \lambda)^2 - 1 \\ &= \lambda^2 - 6\lambda + 8 \\ &= (\lambda - 4)(\lambda - 2). \end{aligned}$$

Assim, os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Para determinar o autoespaço associado a $\lambda_1 = 4$, resolve-se

$$(\mathbf{A} - 4\mathbf{I}_2) \mathbf{v} = \mathbf{0}.$$

Como

$$\mathbf{A} - 4\mathbf{I}_2 = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix},$$

o sistema conduz a

$$-v_1 + v_2 = 0,$$

ou seja,

$$v_2 = v_1.$$

Portanto,

$$\mathcal{E}_4 = \text{span} \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}.$$

Para $\lambda_2 = 2$,

$$\mathbf{A} - 2\mathbf{I}_2 = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix},$$

e o sistema correspondente fornece

$$v_1 + v_2 = 0.$$

Logo,

$$\mathcal{E}_2 = \text{span} \left\{ \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}.$$

O procedimento possui duas etapas:

1. resolver

$$\det(\mathbf{A} - \lambda\mathbf{I}_p) = 0$$

para obter os autovalores;

2. para cada autovalor λ , determinar

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p).$$

5.2.2 Autovalores complexos de matrizes reais

As definições de autovalor, autovetor, autoespaço e equação característica foram apresentadas inicialmente no espaço real. Elas se estendem ao espaço complexo substituindo

$$\mathbb{R}^p$$

por

$$\mathbb{C}^p$$

e permitindo

$$\lambda \in \mathbb{C}.$$

Nesse caso, um autovetor complexo é um vetor não nulo $\mathbf{v} \in \mathbb{C}^p$ que satisfaz

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

A caracterização

$$\det(\mathbf{A} - \lambda\mathbf{I}_p) = 0$$

permanece válida no espaço complexo.

Nem toda matriz real possui autovalores reais. Considere a rotação de 90° ($\theta = \frac{\pi}{2}$),

$$\mathbf{Q}_{\frac{\pi}{2}} = \begin{bmatrix} \cos\left(\frac{\pi}{2}\right) & -\sin\left(\frac{\pi}{2}\right) \\ \sin\left(\frac{\pi}{2}\right) & \cos\left(\frac{\pi}{2}\right) \end{bmatrix} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}.$$

Seu polinômio característico é

$$\begin{aligned} p_{\mathbf{Q}}(\lambda) &= \det \begin{bmatrix} -\lambda & -1 \\ 1 & -\lambda \end{bmatrix} \\ &= \lambda^2 + 1. \end{aligned}$$

A equação

$$\lambda^2 + 1 = 0$$

não possui raízes reais. Suas raízes complexas são

$$\lambda_1 = i \quad \text{e} \quad \lambda_2 = -i.$$

Portanto, a matriz não possui autovalores reais e, consequentemente, não possui autovetores reais. Geometricamente, nenhuma reta real que passa pela origem permanece invariante sob uma rotação de 90° .

Quando a mesma matriz é considerada como um operador em $\mathbb{C}^2$, ela possui autovalores e autovetores complexos. Neste capítulo, a interpretação geométrica será desenvolvida principalmente no contexto real. Em particular, toda matriz simétrica real possui autovalores reais e admite uma base ortonormal de autovetores reais.

5.2.3 Independência entre autovetores

Os autovetores associados a autovalores distintos possuem uma propriedade que permite construir bases de direções invariantes.

Teorema 5.2 (Independência de autovetores associados a autovalores distintos). *Se*

$$\lambda_1, \dots, \lambda_r$$

são autovalores distintos de uma matriz $\mathbf{A}$ e

$$\mathbf{v}_1, \dots, \mathbf{v}_r$$

são autovetores associados, respectivamente, a esses autovalores, então

$$\mathbf{v}_1, \dots, \mathbf{v}_r$$

são linearmente independentes.

Comprovação. A demonstração será feita por indução sobre r .

Para $r = 1$, o resultado é imediato porque um autovetor é não nulo.

Suponha que o resultado seja válido para $r - 1$ autovetores e considere

$$c_1 \mathbf{v}_1 + \dots + c_r \mathbf{v}_r = \mathbf{0}.$$

Multiplicando por $\mathbf{A}$,

$$c_1 \lambda_1 \mathbf{v}_1 + \cdots + c_r \lambda_r \mathbf{v}_r = \mathbf{0}.$$

Multiplicando a primeira igualdade por λ_r e subtraindo-a da segunda,

$$c_1 (\lambda_1 - \lambda_r) \mathbf{v}_1 + \cdots + c_{r-1} (\lambda_{r-1} - \lambda_r) \mathbf{v}_{r-1} = \mathbf{0}.$$

Pela hipótese de indução,

$$c_j (\lambda_j - \lambda_r) = 0, \quad j = 1, \dots, r-1.$$

Como os autovalores são distintos,

$$\lambda_j - \lambda_r \neq 0,$$

e, portanto,

$$c_1 = \cdots = c_{r-1} = 0.$$

A igualdade original reduz-se a

$$c_r \mathbf{v}_r = \mathbf{0}.$$

Como $\mathbf{v}_r \neq \mathbf{0}$, segue que $c_r = 0$. Logo, os autovetores são linearmente independentes. $\square$

Uma consequência imediata é que uma matriz de ordem p com p autovalores distintos possui uma base formada por autovetores. Essa condição é suficiente para a diagonalização, mas não é necessária: uma matriz também pode ser diagonalizável quando possui autovalores repetidos.

5.2.4 Multiplicidades algébrica e geométrica

Quando um autovalor aparece mais de uma vez como raiz do polinômio característico, é necessário distinguir sua repetição algébrica da dimensão do autoespaço correspondente.

Definição 5.5 (Multiplicidades de um autovalor). Seja λ um autovalor de $\mathbf{A}$.

A **multiplicidade algébrica** de λ , denotada por

$$m_a(\lambda),$$

é o número de vezes que λ aparece como raiz do polinômio característico.

A **multiplicidade geométrica** de λ , denotada por

$$m_g(\lambda),$$

é a dimensão do autoespaço correspondente:

$$m_g(\lambda) = \dim(\mathcal{E}_\lambda) = \dim \mathcal{N}(\mathbf{A} - \lambda \mathbf{I}_p).$$

Para todo autovalor,

$$1 \leq m_g(\lambda) \leq m_a(\lambda).$$

A multiplicidade geométrica é pelo menos 1 porque o autoespaço contém vetores não nulos. Ela representa o número máximo de autovetores linearmente independentes que podem ser escolhidos para aquele autovalor.

Exemplo 5.3 (Mesma multiplicidade algébrica e diferentes multiplicidades geométricas). Considere as matrizes

$$\mathbf{A}_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

e

$$\mathbf{A}_2 = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix}.$$

Polinômio característico e multiplicidade algébrica

Para $\mathbf{A}_1$,

$$\begin{aligned} p_{\mathbf{A}_1}(\lambda) &= \det(\mathbf{A}_1 - \lambda \mathbf{I}_2) \\ &= \det \begin{bmatrix} 2 - \lambda & 0 \\ 0 & 2 - \lambda \end{bmatrix} \\ &= (2 - \lambda)^2. \end{aligned}$$

Para $\mathbf{A}_2$,

$$\begin{aligned} p_{\mathbf{A}_2}(\lambda) &= \det(\mathbf{A}_2 - \lambda \mathbf{I}_2) \\ &= \det \begin{bmatrix} 2 - \lambda & 1 \\ 0 & 2 - \lambda \end{bmatrix} \\ &= (2 - \lambda)^2. \end{aligned}$$

Portanto, as duas matrizes possuem o mesmo polinômio característico,

$$p(\lambda) = (2 - \lambda)^2,$$

e, conseqüentemente, o mesmo autovalor,

$$\lambda = 2.$$

Como o fator $(2 - \lambda)$ aparece duas vezes no polinômio característico, o autovalor $\lambda = 2$ possui multiplicidade algébrica

$$m_a(2) = 2$$

para ambas as matrizes.

Autoespaço de $\mathbf{A}_1$

Para determinar o autoespaço associado a $\lambda = 2$, procuramos todos os vetores

$$\mathbf{v} = \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}$$

que satisfazem

$$\mathbf{A}_1 \mathbf{v} = 2\mathbf{v}.$$

Essa equação pode ser escrita como

$$(\mathbf{A}_1 - 2\mathbf{I}_2) \mathbf{v} = \mathbf{0}.$$

Calculando a matriz,

$$\begin{aligned}\mathbf{A}_1 - 2\mathbf{I}_2 &= \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} - \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \\ &= \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}.\end{aligned}$$

Assim, o sistema a ser resolvido é

$$\begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix},$$

ou seja,

$$\begin{cases} 0 = 0, \\ 0 = 0. \end{cases}$$

O sistema não impõe nenhuma restrição sobre v_1 e v_2 . Portanto, ambos são livres e qualquer vetor de $\mathbb{R}^2$ pertence ao espaço nulo de $\mathbf{A}_1 - 2\mathbf{I}_2$.

Logo,

$$E_2 = \mathcal{N}(\mathbf{A}_1 - 2\mathbf{I}_2) = \mathbb{R}^2.$$

Como

$$\dim(\mathbb{R}^2) = 2,$$

temos

$$m_g(2) = \dim(E_2) = 2.$$

Assim, todo vetor não nulo de $\mathbb{R}^2$ é um autovetor de $\mathbf{A}_1$ associado ao autovalor $\lambda = 2$.

Autoespaço de $\mathbf{A}_2$

Para $\mathbf{A}_2$, procuramos novamente os vetores

$$\mathbf{v} = \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}$$

que satisfazem

$$(\mathbf{A}_2 - 2\mathbf{I}_2) \mathbf{v} = \mathbf{0}.$$

Calculando,

$$\begin{aligned} \mathbf{A}_2 - 2\mathbf{I}_2 &= \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix} - \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \\ &= \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}. \end{aligned}$$

Portanto,

$$\begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

Efetuando a multiplicação,

$$\begin{bmatrix} v_2 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix},$$

o que corresponde ao sistema

$$\begin{cases} v_2 = 0, \\ 0 = 0. \end{cases}$$

Nesse caso, v_2 deve ser igual a zero, enquanto v_1 permanece livre. Assim, todo vetor do autoespaço possui a forma

$$\mathbf{v} = \begin{bmatrix} v_1 \\ 0 \end{bmatrix} = v_1 \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Logo,

$$E_2 = \mathcal{N}(\mathbf{A}_2 - 2\mathbf{I}_2) = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix} \right\}.$$

Esse autoespaço possui uma única direção linearmente independente. Portanto,

$$m_g(2) = \dim(E_2) = 1.$$

As duas matrizes possuem, portanto, o mesmo autovalor $\lambda = 2$ e a mesma multiplicidade algébrica,

$$m_a(2) = 2,$$

mas apresentam multiplicidades geométricas diferentes:

$$m_g(2) = \begin{cases} 2, & \text{para } \mathbf{A}_1, \\ 1, & \text{para } \mathbf{A}_2. \end{cases}$$

A diferença decorre da dimensão dos respectivos autoespaços. Para $\mathbf{A}_1$, o autoespaço é todo o plano $\mathbb{R}^2$; para $\mathbf{A}_2$, o autoespaço é apenas a reta gerada por $(1, 0)^\top$.

A Figura 5.2 compara as estruturas dos dois autoespaços.




Figura 5.2: Matrizes com o mesmo autovalor repetido podem possuir autoespaços de dimensões diferentes.

As duas matrizes possuem o mesmo autovalor com a mesma multiplicidade algébrica. A diferença entre as multiplicidades geométricas determina se existem autovetores suficientes para formar uma base.

5.2.5 Diagonalização

No capítulo anterior, vimos que a matriz de um operador depende da base utilizada para representá-lo. A diagonalização corresponde à escolha de uma base particularmente conveniente: uma base formada por autovetores.

Considere uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e suponha que exista uma base de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$,

$$\mathcal{B}_{\mathbf{A}} = \{\mathbf{v}_1, \dots, \mathbf{v}_p\}.$$

A matriz dessa base é

$$\mathbf{B}_{\mathbf{A}} = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_p].$$

Como os vetores da base são linearmente independentes, $\mathbf{B}_{\mathbf{A}}$ é invertível.

Se

$$\mathbf{A}\mathbf{v}_j = \lambda_j \mathbf{v}_j, \quad j = 1, \dots, p,$$

e

$$\Lambda_{\mathbf{A}} = \text{diag}(\lambda_1, \dots, \lambda_p),$$

então

$$\mathbf{A}\mathbf{B}_{\mathbf{A}} = \mathbf{B}_{\mathbf{A}}\Lambda_{\mathbf{A}}.$$

Multiplicando à esquerda por $\mathbf{B}_{\mathbf{A}}^{-1}$,

$$\mathbf{B}_{\mathbf{A}}^{-1}\mathbf{A}\mathbf{B}_{\mathbf{A}} = \Lambda_{\mathbf{A}}.$$

Definição 5.6 (Matriz diagonalizável). Uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é **diagonalizável sobre** $\mathbb{R}$ quando existe uma base $\mathcal{B}_{\mathbf{A}}$ de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$.

Equivalentemente, existem uma matriz invertível $\mathbf{B}_{\mathbf{A}}$ e uma matriz diagonal $\Lambda_{\mathbf{A}}$ tais que

$$\mathbf{A} = \mathbf{B}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{B}_{\mathbf{A}}^{-1}.$$

A ordem das colunas de $\mathbf{B}_{\mathbf{A}}$ deve coincidir com a ordem dos autovalores em $\Lambda_{\mathbf{A}}$.

Pela notação de mudança de base desenvolvida no capítulo anterior,

$$[T_{\mathbf{A}}]_{\mathcal{B}_{\mathbf{A}} \leftarrow \mathcal{B}_{\mathbf{A}}} = \mathbf{B}_{\mathbf{A}}^{-1} \mathbf{A} \mathbf{B}_{\mathbf{A}} = \Lambda_{\mathbf{A}}.$$

Assim, $\Lambda_{\mathbf{A}}$ é a matriz do mesmo operador quando tanto o domínio quanto o contradomínio são representados na base de autovetores.

Para qualquer vetor $\mathbf{x} \in \mathbb{R}^p$, suas coordenadas nessa base são

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}} = \mathbf{B}_{\mathbf{A}}^{-1} \mathbf{x},$$

de modo que

$$\mathbf{x} = \mathbf{B}_{\mathbf{A}} \mathbf{z}.$$

Nas coordenadas da base de autovetores,

$$[T_{\mathbf{A}}(\mathbf{x})]_{\mathcal{B}_{\mathbf{A}}} = \Lambda_{\mathbf{A}} [\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}}.$$

Como

$$\Lambda_{\mathbf{A}} \mathbf{z} = \begin{bmatrix} \lambda_1 z_1 \\ \vdots \\ \lambda_p z_p \end{bmatrix},$$

a transformação atua separadamente sobre cada coordenada: a componente correspondente ao autovetor $\mathbf{v}_j$ é multiplicada por λ_j .

A diagonalização é, portanto, uma mudança para um sistema de coordenadas no qual as direções da base são invariantes e a ação do operador deixa de misturar coordenadas.

Teorema 5.3 (Critérios de diagonalização). *Seja*

$$\mathbf{A} \in \mathbb{F}^{p \times p},$$

em que $\mathbb{F}$ representa $\mathbb{R}$ ou $\mathbb{C}$, e suponha que seu polinômio característico se decompõe em fatores lineares sobre $\mathbb{F}$.

São equivalentes:

- 1. $\mathbf{A}$ é diagonalizável sobre $\mathbb{F}$;*
- 2. $\mathbf{A}$ possui p autovetores linearmente independentes em $\mathbb{F}^p$;*
- 3. existe uma base de $\mathbb{F}^p$ formada por autovetores de $\mathbf{A}$;*
- 4. a soma das dimensões dos autoespaços é igual a p ;*
- 5. para cada autovalor λ ,*

$$m_g(\lambda) = m_a(\lambda).$$

(Horn; Johnson, 2013)

O requisito de decomposição do polinômio característico é necessário porque uma matriz real pode não possuir todos os seus autovalores em $\mathbb{R}$. A matriz de rotação $\mathbf{Q}(\pi/2)$ não é diagonalizável sobre $\mathbb{R}$, mas é diagonalizável sobre $\mathbb{C}$, pois possui dois autovalores complexos distintos.

Uma condição suficiente para a diagonalização é a existência de p autovalores distintos. Nesse caso, o Teorema 5.2 garante p autovetores linearmente independentes.

Autovalores repetidos não impedem a diagonalização. Para

$$\mathbf{A}_1 = 2\mathbf{I}_2,$$

tem-se

$$m_g(2) = m_a(2) = 2,$$

e a matriz é diagonalizável.

Para

$$\mathbf{A}_2 = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix},$$

tem-se

$$m_g(2) = 1 < m_a(2) = 2.$$

A matriz não possui autovetores linearmente independentes em número suficiente para formar uma base e, portanto, não é diagonalizável.

5.2.6 Potências de uma matriz diagonalizável

A representação diagonal também simplifica o cálculo de potências. Se

$$\mathbf{A} = \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1},$$

então

$$\begin{aligned} \mathbf{A}^2 &= \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1} \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1} \\ &= \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A}^2 \mathbf{B}_\mathbf{A}^{-1}. \end{aligned}$$

De forma geral, para todo inteiro $k \geq 0$,

$$\mathbf{A}^k = \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A}^k \mathbf{B}_\mathbf{A}^{-1}.$$

Como $\Lambda_\mathbf{A}$ é diagonal,

$$\Lambda_\mathbf{A}^k = \text{diag}(\lambda_1^k, \dots, \lambda_p^k).$$

Assim, a aplicação repetida do operador pode ser analisada coordenada a coordenada na base de autovetores: após k aplicações, a coordenada associada a $\mathbf{v}_j$ é multiplicada por λ_j^k .

Para matrizes quadradas arbitrárias, a diagonalização pode falhar. Para matrizes simétricas reais, existe sempre uma base ortonormal de autovetores. Essa propriedade conduz a uma diagonalização que preserva a geometria euclidiana.

5.3 Matrizes simétricas e decomposição espectral

A diagonalização estudada na seção anterior pode falhar para matrizes quadradas arbitrárias. Uma matriz pode não possuir autovalores reais ou pode não apresentar autovetores linearmente independentes em número suficiente para formar uma base.

As matrizes simétricas reais possuem uma estrutura mais regular. Retomando a Definição 2.7, uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é simétrica quando

$$\mathbf{A}^\top = \mathbf{A}.$$

Para essa classe de matrizes, todos os autovalores são reais e os autoespaços associados a autovalores distintos são ortogonais. Como consequência, existe uma base ortonormal de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$.

Teorema 5.4 (Teorema Espectral para matrizes simétricas reais). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

uma matriz simétrica. Então:

- 1. todos os autovalores de $\mathbf{A}$ são reais;*
- 2. autoespaços associados a autovalores distintos são ortogonais;*
- 3. existe uma base ortonormal de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$;*
- 4. existe uma matriz ortogonal*

$$\mathbf{Q}_\mathbf{A} \in \mathbb{R}^{p \times p}$$

e uma matriz diagonal

$$\Lambda_\mathbf{A} \in \mathbb{R}^{p \times p}$$

tais que

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

(Horn; Johnson, 2013)

Comprovação. Para demonstrar que os autovalores são reais, considere um autovalor possivelmente complexo λ e um autovetor complexo não nulo $\mathbf{z}$, de modo que

$$\mathbf{A}\mathbf{z} = \lambda\mathbf{z}.$$

Como $\mathbf{A}$ é real e simétrica, ela também é hermitiana:

$$\mathbf{A}^* = \mathbf{A},$$

em que $*$ representa a transposta conjugada.

Multiplicando a equação de autovalor à esquerda por $\mathbf{z}^*$,

$$\mathbf{z}^* \mathbf{A} \mathbf{z} = \lambda \mathbf{z}^* \mathbf{z}.$$

A quantidade

$$\mathbf{z}^* \mathbf{A} \mathbf{z}$$

é real, pois

$$(\mathbf{z}^* \mathbf{A} \mathbf{z})^* = \mathbf{z}^* \mathbf{A}^* \mathbf{z} = \mathbf{z}^* \mathbf{A} \mathbf{z}.$$

Além disso,

$$\mathbf{z}^* \mathbf{z} > 0.$$

Portanto,

$$\lambda = \frac{\mathbf{z}^* \mathbf{A} \mathbf{z}}{\mathbf{z}^* \mathbf{z}}$$

é real.

Considere agora dois autovetores reais $\mathbf{v}_i$ e $\mathbf{v}_j$, associados a autovalores distintos λ_i e λ_j . Como

$$\mathbf{A} \mathbf{v}_i = \lambda_i \mathbf{v}_i$$

e

$$\mathbf{A}\mathbf{v}_j = \lambda_j\mathbf{v}_j,$$

tem-se

$$\begin{aligned}\lambda_i\mathbf{v}_i^\top\mathbf{v}_j &= (\mathbf{A}\mathbf{v}_i)^\top\mathbf{v}_j \\ &= \mathbf{v}_i^\top\mathbf{A}^\top\mathbf{v}_j \\ &= \mathbf{v}_i^\top\mathbf{A}\mathbf{v}_j \\ &= \lambda_j\mathbf{v}_i^\top\mathbf{v}_j.\end{aligned}$$

Logo,

$$(\lambda_i - \lambda_j)\mathbf{v}_i^\top\mathbf{v}_j = 0.$$

Como $\lambda_i \neq \lambda_j$,

$$\mathbf{v}_i^\top\mathbf{v}_j = 0.$$

Portanto, os autoespaços associados a autovalores distintos são ortogonais.

A existência de uma base ortonormal de autovetores pode ser demonstrada por indução sobre a ordem p da matriz. Para $p = 1$, o resultado é imediato.

Suponha agora $p > 1$. Pelo Teorema Fundamental da Álgebra, o polinômio característico de $\mathbf{A}$ possui pelo menos uma raiz em $\mathbb{C}$. Pela primeira parte da demonstração, essa raiz é real. Denote-a por λ_1 .

Como

$$\det(\mathbf{A} - \lambda_1\mathbf{I}_p) = 0,$$

a matriz real

$$\mathbf{A} - \lambda_1\mathbf{I}_p$$

é singular e possui um vetor não nulo real em seu núcleo. Normalizando esse vetor, obtém-se um autovetor unitário $\mathbf{q}_1$.

Considere o complemento ortogonal

$$\mathcal{W} = \text{span} \{ \mathbf{q}_1 \}^\perp.$$

Para qualquer $\mathbf{x} \in \mathcal{W}$,

$$\mathbf{q}_1^\top \mathbf{x} = 0.$$

Como $\mathbf{A}$ é simétrica,

$$\begin{aligned} \mathbf{q}_1^\top \mathbf{A} \mathbf{x} &= (\mathbf{A} \mathbf{q}_1)^\top \mathbf{x} \\ &= \lambda_1 \mathbf{q}_1^\top \mathbf{x} \\ &= 0. \end{aligned}$$

Logo,

$$\mathbf{A} \mathbf{x} \in \mathcal{W},$$

e $\mathcal{W}$ é invariante sob $\mathbf{A}$.

A restrição de $\mathbf{A}$ a $\mathcal{W}$ permanece simétrica. Como

$$\dim(\mathcal{W}) = p - 1,$$

a hipótese de indução garante uma base ortonormal

$$\mathbf{q}_2, \dots, \mathbf{q}_p$$

de $\mathcal{W}$ formada por autovetores da restrição e, consequentemente, de $\mathbf{A}$.

Assim,

$$\mathbf{q}_1, \dots, \mathbf{q}_p$$

formam uma base ortonormal de $\mathbb{R}^p$ composta por autovetores de $\mathbf{A}$.

Organizando esses vetores nas colunas de

$$\mathbf{Q}_\mathbf{A} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p],$$

tem-se

$$\mathbf{Q}_{\mathbf{A}}^{\top} \mathbf{Q}_{\mathbf{A}} = \mathbf{I}_p.$$

Portanto,

$$\mathbf{Q}_{\mathbf{A}}^{-1} = \mathbf{Q}_{\mathbf{A}}^{\top}.$$

Definindo

$$\Lambda_{\mathbf{A}} = \text{diag}(\lambda_1, \dots, \lambda_p),$$

a relação

$$\mathbf{A} \mathbf{Q}_{\mathbf{A}} = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}}$$

fornece

$$\mathbf{A} = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^{\top}.$$

□

A representação

$$\mathbf{A} = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^{\top}$$

é denominada **decomposição espectral** de $\mathbf{A}$. Ela é uma diagonalização ortogonal.

Considere a base ortonormal de autovetores

$$\mathcal{B}_{\mathbf{A}} = \{\mathbf{q}_1, \dots, \mathbf{q}_p\}.$$

A matriz dessa base é

$$\mathbf{Q}_{\mathbf{A}} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p].$$

Assim, no caso simétrico, a matriz da base de autovetores introduzida na seção anterior pode ser escolhida ortogonal:

$$\mathbf{B}_{\mathbf{A}} = \mathbf{Q}_{\mathbf{A}},$$

com

$$\mathbf{Q}_A^{-1} = \mathbf{Q}_A^\top.$$

Pela notação de coordenadas desenvolvida no capítulo anterior,

$$[\mathbf{x}]_{\mathcal{B}_A} = \mathbf{Q}_A^\top \mathbf{x}.$$

Denotando

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_A},$$

tem-se

$$\mathbf{x} = \mathbf{Q}_A \mathbf{z}.$$

A matriz do operador nessa base é

$$[T_A]_{\mathcal{B}_A \leftarrow \mathcal{B}_A} = \mathbf{Q}_A^\top \mathbf{A} \mathbf{Q}_A = \Lambda_A.$$

Consequentemente,

$$[T_A(\mathbf{x})]_{\mathcal{B}_A} = \Lambda_A [\mathbf{x}]_{\mathcal{B}_A}.$$

Em coordenadas canônicas,

$$\begin{aligned} \mathbf{A} \mathbf{x} &= \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top \mathbf{x} \\ &= \mathbf{Q}_A \Lambda_A \mathbf{z}. \end{aligned}$$

A ação da matriz pode ser interpretada em três etapas:

1. $\mathbf{Q}_A^\top$ converte o vetor para as coordenadas da base ortonormal de autovetores;
2. Λ_A multiplica separadamente cada coordenada pelo autovalor correspondente;
3. $\mathbf{Q}_A$ reconstrói o vetor nas coordenadas canônicas.

Assim, uma matriz simétrica atua por fatores escalares independentes em direções ortogonais. Quando algum autovalor é negativo, o escalonamento na direção correspondente inclui também a inversão do sentido.

5.3.1 Decomposição espectral do exemplo condutor

Exemplo 5.4 (Decomposição espectral de uma matriz simétrica). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Os autovetores

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

são ortogonais, pois

$$\mathbf{v}_1^\top \mathbf{v}_2 = 0.$$

Normalizando-os, obtêm-se

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Portanto,

$$\mathcal{B}_{\mathbf{A}} = \{\mathbf{q}_1, \mathbf{q}_2\}$$

é uma base ortonormal de autovetores de $\mathbb{R}^2$.

A matriz dessa base é a matriz ortogonal

$$\mathbf{Q}_A = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix},$$

e a matriz diagonal de autovalores é

$$\Lambda_A = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}.$$

Consequentemente,

$$\mathbf{A} = \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top.$$

De fato,

$$\begin{aligned} \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top &= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}. \end{aligned}$$

Na direção de $\mathbf{q}_1$, a transformação multiplica o comprimento por 4. Na direção ortogonal $\mathbf{q}_2$, multiplica o comprimento por 2.

A Figura 5.3 mostra a circunferência unitária em $\mathbb{R}^2$ e sua imagem pela matriz $\mathbf{A}$. Como os dois autovalores são positivos, a imagem é uma elipse cujos semieixos possuem comprimentos 4 e 2 e estão alinhados aos autovetores.

Na base canônica, a ação da matriz combina as duas coordenadas. Na base formada por $\mathbf{q}_1$ e $\mathbf{q}_2$, a transformação apenas multiplica as coordenadas por 4 e 2.

Para uma matriz simétrica arbitrária, os comprimentos dos semieixos da imagem da esfera unitária em $\mathbb{R}^p$ são determinados por

$$|\lambda_1|, \dots, |\lambda_p|.$$

Autovalores negativos também invertem o sentido ao longo das direções correspondentes. Autovalores nulos colapsam os respectivos eixos, reduzindo a dimensão da imagem.




Figura 5.3: A decomposição espectral identifica as direções ortogonais nas quais uma matriz simétrica atua por fatores escalares independentes.

5.3.2 Forma aditiva da decomposição espectral

Como

$$\mathbf{Q}_A = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p]$$

e

$$\Lambda_A = \text{diag}(\lambda_1, \dots, \lambda_p),$$

a decomposição espectral também pode ser escrita como

$$\mathbf{A} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^\top.$$

Cada matriz

$$\mathbf{q}_j \mathbf{q}_j^\top$$

é o projetor ortogonal sobre a reta gerada por $\mathbf{q}_j$. Assim,

$$\mathbf{Ax} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^\top \mathbf{x}.$$

A transformação pode ser interpretada como:

1. projetar $\mathbf{x}$ sobre cada direção espectral;
2. multiplicar cada projeção pelo autovalor correspondente;
3. somar as parcelas resultantes.

No exemplo,

$$\mathbf{A} = 4\mathbf{q}_1 \mathbf{q}_1^\top + 2\mathbf{q}_2 \mathbf{q}_2^\top.$$

5.3.3 Projetores sobre autoespaços

Quando um autovalor possui multiplicidade maior que 1, os autovetores individuais associados a ele não são únicos. O autoespaço, entretanto, é determinado pela matriz.

Considere os autovalores distintos

$$\lambda^{(1)}, \dots, \lambda^{(s)}$$

de $\mathbf{A}$. Para cada autovalor $\lambda^{(h)}$, seja

$$\mathbf{Q}_h$$

uma matriz cujas colunas formam uma base ortonormal do autoespaço correspondente.

Define-se o projetor espectral

$$\Pi_{\lambda^{(h)}} = \mathbf{Q}_h \mathbf{Q}_h^\top.$$

Esse projetor não depende da base ortonormal escolhida dentro do autoespaço.

Proposição 5.3 (Decomposição por projetores espectrais). *Se $\mathbf{A}$ é simétrica e possui autovalores distintos*

$$\lambda^{(1)}, \dots, \lambda^{(s)},$$

então

$$\mathbf{A} = \sum_{h=1}^s \lambda^{(h)} \Pi_{\lambda^{(h)}}.$$

Além disso,

$$\Pi_{\lambda^{(h)}}^\top = \Pi_{\lambda^{(h)}},$$

$$\Pi_{\lambda^{(h)}}^2 = \Pi_{\lambda^{(h)}},$$

$$\Pi_{\lambda^{(h)}} \Pi_{\lambda^{(\ell)}} = \mathbf{0}, \quad h \neq \ell,$$

e

$$\sum_{h=1}^s \Pi_{\lambda^{(h)}} = \mathbf{I}_p.$$

(Horn; Johnson, 2013)

Comprovação. As colunas de $\mathbf{Q}_h$ são ortonormais. Portanto,

$$\Pi_{\lambda^{(h)}} = \mathbf{Q}_h \mathbf{Q}_h^\top$$

é o projetor ortogonal sobre o autoespaço associado a $\lambda^{(h)}$. Pela Proposição 3.16, ele é simétrico e idempotente.

Autoespaços associados a autovalores distintos são ortogonais. Logo,

$$\mathbf{Q}_h^\top \mathbf{Q}_\ell = \mathbf{0}$$

para $h \neq \ell$, e

$$\begin{aligned} \Pi_{\lambda^{(h)}} \Pi_{\lambda^{(\ell)}} &= \mathbf{Q}_h \mathbf{Q}_h^\top \mathbf{Q}_\ell \mathbf{Q}_\ell^\top \\ &= \mathbf{0}. \end{aligned}$$

A soma direta ortogonal de todos os autoespaços é $\mathbb{R}^p$. Por isso,

$$\sum_{h=1}^s \Pi_{\lambda^{(h)}} = \mathbf{I}_p.$$

Agrupando na decomposição espectral todos os autovetores associados ao mesmo autovalor,

$$\mathbf{A} = \sum_{h=1}^s \lambda^{(h)} \Pi_{\lambda^{(h)}}.$$

□

A decomposição por projetores separa o que depende de uma escolha de base do que é determinado pelo operador. Quando um autovalor é simples, o projetor correspondente possui posto 1:

$$\Pi_{\lambda} = \mathbf{q}\mathbf{q}^{\top}.$$

Quando sua multiplicidade geométrica é maior que 1, o projetor representa todo o autoespaço e possui posto igual à sua dimensão.

5.3.4 Não unicidade da matriz de autovetores

A matriz

$$\mathbf{Q}_{\mathbf{A}}$$

não é necessariamente única.

Mesmo quando todos os autovalores são distintos, cada autovetor pode ser substituído por seu oposto:

$$\mathbf{q}_j \mapsto -\mathbf{q}_j.$$

A ordem dos autovetores também pode ser alterada, desde que a mesma alteração seja aplicada aos autovalores em

$$\Lambda_{\mathbf{A}}.$$

Quando há autovalores repetidos, qualquer base ortonormal do autoespaço correspondente pode ser utilizada.

Essas alterações não modificam a matriz original nem os projetores espectrais. O sinal, a ordem e a base escolhida dentro de um autoespaço são elementos da representação; os autovalores, os autoespaços e seus projetores são propriedades do operador.

A decomposição espectral fornece uma base ortonormal na qual formas quadráticas, determinantes, traços, postos, inversas e superfícies de nível podem ser analisados diretamente a partir dos autovalores.

5.4 Consequências da decomposição espectral

Considere uma matriz simétrica

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

com decomposição espectral

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\mathbf{Q}_\mathbf{A} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p]$$

é ortogonal e

$$\Lambda_\mathbf{A} = \text{diag}(\lambda_1, \dots, \lambda_p).$$

A representação diagonal permite obter propriedades da matriz diretamente de seus autovalores e autoespaços.

5.4.1 Traço, determinante, posto e invertibilidade

Proposição 5.4 (Consequências espectrais básicas). *Se $\mathbf{A} \in \mathbb{R}^{p \times p}$ é simétrica e possui autovalores*

$$\lambda_1, \dots, \lambda_p,$$

contados com suas multiplicidades algébricas, então:

$$\text{tr}(\mathbf{A}) = \sum_{j=1}^p \lambda_j,$$

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j,$$

$$\text{posto}(\mathbf{A}) = \# \{j : \lambda_j \neq 0\},$$

e

$$\dim \mathcal{N}(\mathbf{A}) = \# \{j : \lambda_j = 0\}.$$

Além disso,

$$\mathbf{A} \text{ é invertível} \iff \lambda_j \neq 0 \text{ para todo } j.$$

Comprovação. Pela propriedade cíclica do traço,

$$\begin{aligned} \text{tr}(\mathbf{A}) &= \text{tr}(\mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^{\top}) \\ &= \text{tr}(\Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^{\top} \mathbf{Q}_{\mathbf{A}}) \\ &= \text{tr}(\Lambda_{\mathbf{A}}) \\ &= \sum_{j=1}^p \lambda_j. \end{aligned}$$

Para o determinante,

$$\begin{aligned} \det(\mathbf{A}) &= \det(\mathbf{Q}_{\mathbf{A}}) \det(\Lambda_{\mathbf{A}}) \det(\mathbf{Q}_{\mathbf{A}}^{\top}) \\ &= \det(\Lambda_{\mathbf{A}}), \end{aligned}$$

pois

$$\det(\mathbf{Q}_{\mathbf{A}}) \det(\mathbf{Q}_{\mathbf{A}}^{\top}) = \det(\mathbf{I}_p) = 1.$$

Como $\Lambda_{\mathbf{A}}$ é diagonal,

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j.$$

As matrizes $\mathbf{A}$ e $\Lambda_{\mathbf{A}}$ são semelhantes, pois

$$\Lambda_{\mathbf{A}} = \mathbf{Q}_{\mathbf{A}}^{\top} \mathbf{A} \mathbf{Q}_{\mathbf{A}}.$$

Como a multiplicação à esquerda e à direita por matrizes invertíveis preserva o posto, $\mathbf{A}$ e $\Lambda_{\mathbf{A}}$ possuem o mesmo posto. O posto de uma matriz diagonal é igual ao número de elementos diagonais não nulos. Portanto,

$$\text{posto}(\mathbf{A}) = \# \{j : \lambda_j \neq 0\}.$$

Pelo Teorema Posto–Nulidade,

$$\begin{aligned} \dim \mathcal{N}(\mathbf{A}) &= p - \text{posto}(\mathbf{A}) \\ &= \# \{j : \lambda_j = 0\}. \end{aligned}$$

Por fim, $\mathbf{A}$ é invertível se, e somente se, seu determinante é diferente de zero. Como

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j,$$

isso ocorre exatamente quando todos os autovalores são não nulos. □

Os autoespaços também fornecem descrições diretas do núcleo e da imagem.

Proposição 5.5 (Núcleo e imagem em termos dos autovetores). *Se*

$$\mathbf{A} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^{\top}$$

é a decomposição espectral de uma matriz simétrica, então

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j = 0 \}$$

e

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Consequentemente,

$$\text{Im}(T_{\mathbf{A}}) = \ker(T_{\mathbf{A}})^{\perp},$$

ou, equivalentemente,

$$\mathcal{C}(\mathbf{A}) = \mathcal{N}(\mathbf{A})^\perp.$$

Comprovação. Todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito na base ortonormal de autovetores como

$$\mathbf{x} = \sum_{j=1}^p z_j \mathbf{q}_j,$$

em que

$$z_j = \mathbf{q}_j^\top \mathbf{x}.$$

Aplicando $\mathbf{A}$,

$$\mathbf{A}\mathbf{x} = \sum_{j=1}^p \lambda_j z_j \mathbf{q}_j.$$

A igualdade

$$\mathbf{A}\mathbf{x} = \mathbf{0}$$

ocorre se, e somente se,

$$\lambda_j z_j = 0$$

para todo j . Portanto, as coordenadas de $\mathbf{x}$ podem ser não nulas apenas nas direções associadas a autovalores iguais a zero. Logo,

$$\mathcal{N}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j = 0 \}.$$

Toda imagem $\mathbf{A}\mathbf{x}$ é uma combinação linear dos autovetores associados a autovalores não nulos. Assim,

$$\mathcal{C}(\mathbf{A}) \subseteq \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Reciprocamente, se $\lambda_j \neq 0$, então

$$\mathbf{q}_j = \mathbf{A} \left(\frac{1}{\lambda_j} \mathbf{q}_j \right),$$

de modo que $\mathbf{q}_j \in \mathcal{C}(\mathbf{A})$. Portanto,

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Como os autovetores associados a autovalores nulos são ortogonais aos autovetores associados a autovalores não nulos, e juntos formam uma base ortonormal de $\mathbb{R}^p$, os dois subespaços são complementos ortogonais. $\square$

O autoespaço associado ao autovalor zero reúne exatamente as direções eliminadas pela transformação. Os autoespaços associados a autovalores não nulos constituem, em conjunto, a imagem da transformação.

5.4.2 Formas quadráticas em coordenadas espectrais

Retomando a Definição 2.23, considere

$$q_{\mathbf{A}}(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

As coordenadas de $\mathbf{x}$ na base espectral são

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}} = \mathbf{Q}_{\mathbf{A}}^\top \mathbf{x}.$$

Como

$$\mathbf{x} = \mathbf{Q}_{\mathbf{A}} \mathbf{z},$$

tem-se

$$\begin{aligned} q_{\mathbf{A}}(\mathbf{x}) &= \mathbf{x}^\top \mathbf{A} \mathbf{x} \\ &= \mathbf{z}^\top \mathbf{Q}_{\mathbf{A}}^\top \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^\top \mathbf{Q}_{\mathbf{A}} \mathbf{z} \\ &= \mathbf{z}^\top \Lambda_{\mathbf{A}} \mathbf{z} \\ &= \sum_{j=1}^p \lambda_j z_j^2. \end{aligned}$$

A mudança ortogonal de coordenadas elimina os produtos cruzados. A contribuição da direção $\mathbf{q}_j$ para a forma quadrática é

$$\lambda_j z_j^2.$$

As possibilidades de sinal da forma quadrática são determinadas pelos sinais dos autovalores, enquanto o valor assumido para um vetor específico depende também de suas coordenadas espectrais $z_1, \dots, z_p$.

Exemplo 5.5 (Forma quadrática em coordenadas espectrais). Considere a matriz simétrica

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.$$

Seus autovalores são

$$\lambda_1 = 3 \quad \text{e} \quad \lambda_2 = 1,$$

com autovetores ortonormais associados

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Portanto,

$$\mathbf{Q}_\mathbf{A} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

e

$$\Lambda_\mathbf{A} = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}.$$

A decomposição espectral de $\mathbf{A}$ é

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Considere agora o vetor

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

Nas coordenadas originais, a forma quadrática é

$$\begin{aligned} q_{\mathbf{A}}(\mathbf{x}) &= \mathbf{x}^{\top} \mathbf{A} \mathbf{x} \\ &= \begin{bmatrix} 2 & 1 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 1 \end{bmatrix} \begin{bmatrix} 5 \\ 4 \end{bmatrix} \\ &= 14. \end{aligned}$$

Equivalentemente, escrevendo a forma quadrática em função das coordenadas originais,

$$q_{\mathbf{A}}(\mathbf{x}) = 2x_1^2 + 2x_1x_2 + 2x_2^2.$$

Observe a presença do produto cruzado $2x_1x_2$.

As coordenadas de $\mathbf{x}$ na base espectral são

$$\mathbf{z} = \mathbf{Q}_{\mathbf{A}}^{\top} \mathbf{x}.$$

Como

$$\mathbf{Q}_{\mathbf{A}}^{\top} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix},$$

tem-se

$$\begin{aligned} \mathbf{z} &= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} \\ &= \frac{1}{\sqrt{2}} \begin{bmatrix} 3 \\ 1 \end{bmatrix}. \end{aligned}$$

Portanto,

$$z_1 = \frac{3}{\sqrt{2}} \quad \text{e} \quad z_2 = \frac{1}{\sqrt{2}}.$$

Nas coordenadas espectrais, a mesma forma quadrática é

$$\begin{aligned}
q_{\mathbf{A}}(\mathbf{x}) &= \mathbf{z}^\top \Lambda_{\mathbf{A}} \mathbf{z} \\
&= \lambda_1 z_1^2 + \lambda_2 z_2^2 \\
&= 3 \left(\frac{3}{\sqrt{2}} \right)^2 + 1 \left(\frac{1}{\sqrt{2}} \right)^2 \\
&= 3 \left(\frac{9}{2} \right) + \frac{1}{2} \\
&= 14.
\end{aligned}$$

Assim, nas coordenadas espectrais,

$$q_{\mathbf{A}}(\mathbf{x}) = 3z_1^2 + z_2^2,$$

sem produtos cruzados. A mudança de coordenadas não altera o valor da forma quadrática; ela apenas a expressa em uma base na qual a matriz é diagonal.

Proposição 5.6 (Positividade e sinais dos autovalores). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica. Então:*

1. $\mathbf{A}$ é positiva definida se, e somente se,

$$\lambda_j > 0$$

para todo j ;

2. $\mathbf{A}$ é semidefinida positiva se, e somente se,

$$\lambda_j \geq 0$$

para todo j ;

3. $\mathbf{A}$ é negativa definida se, e somente se,

$$\lambda_j < 0$$

para todo j ;

4. $\mathbf{A}$ é semidefinida negativa se, e somente se,

$$\lambda_j \leq 0$$

para todo j ;

5. $\mathbf{A}$ é indefinida se, e somente se, possui pelo menos um autovalor positivo e pelo menos um autovalor negativo.

(Horn; Johnson, 2013)

Comprovação. Para qualquer $\mathbf{x} \in \mathbb{R}^p$, escreva

$$\mathbf{x} = \sum_{j=1}^p z_j \mathbf{q}_j.$$

Então,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2.$$

Se todos os autovalores são positivos e $\mathbf{x} \neq \mathbf{0}$, pelo menos uma coordenada z_j é não nula. Portanto,

$$\sum_{j=1}^p \lambda_j z_j^2 > 0,$$

e $\mathbf{A}$ é positiva definida.

Reciprocamente, se $\mathbf{A}$ é positiva definida, para cada autovetor unitário $\mathbf{q}_j$,

$$\mathbf{q}_j^\top \mathbf{A} \mathbf{q}_j = \lambda_j > 0.$$

Logo, todos os autovalores são positivos.

As caracterizações semidefinidas e negativas seguem pelo mesmo argumento.

Se existem autovalores $\lambda_i > 0$ e $\lambda_j < 0$, então

$$\mathbf{q}_i^\top \mathbf{A} \mathbf{q}_i = \lambda_i > 0$$

e

$$\mathbf{q}_j^\top \mathbf{A} \mathbf{q}_j = \lambda_j < 0.$$

Assim, a forma quadrática assume valores positivos e negativos, e a matriz é indefinida.

Reciprocamente, se a matriz é indefinida, a expressão

$$\sum_{j=1}^p \lambda_j z_j^2$$

deve assumir ambos os sinais. Isso exige a existência de autovalores positivos e negativos. $\square$

Uma matriz simétrica positiva definida é necessariamente invertível, pois todos os seus autovalores são positivos. Uma matriz semidefinida positiva pode ser singular quando possui pelo menos um autovalor igual a zero.

5.4.3 Superfícies de nível em coordenadas espectrais

Considere uma matriz positiva definida e a superfície de nível

$$\mathcal{S}_c(\mathbf{A}) = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{x}^\top \mathbf{A} \mathbf{x} = c\}, \quad c > 0.$$

Nas coordenadas espectrais,

$$\sum_{j=1}^p \lambda_j z_j^2 = c.$$

Como todos os autovalores são positivos,

$$\sum_{j=1}^p \frac{z_j^2}{(c/\lambda_j)} = 1.$$

Essa é a equação de um elipsoide. Suas direções principais são os autovetores

$$\mathbf{q}_1, \dots, \mathbf{q}_p,$$

e o comprimento do semieixo associado a $\mathbf{q}_j$ é

$$r_j = \sqrt{\frac{c}{\lambda_j}}.$$

Autovalores maiores correspondem a semieixos menores. Autovalores menores correspondem a maior extensão da superfície na direção associada.

Para uma superfície centralizada em um vetor fixo $\mathbf{x}_0$,

$$(\mathbf{x} - \mathbf{x}_0)^\top \mathbf{A} (\mathbf{x} - \mathbf{x}_0) = c,$$

os autovetores e os comprimentos dos semieixos permanecem os mesmos. O vetor $\mathbf{x}_0$ determina o centro do elipsoide.

Quando $\mathbf{A}$ é semidefinida positiva e singular, existem direções do núcleo nas quais a forma quadrática não se altera. Para $c > 0$, a superfície de nível é ilimitada nessas direções.

Quando $\mathbf{A}$ é indefinida, a forma quadrática possui parcelas positivas e negativas. Suas superfícies de nível deixam de ser elipsoides e podem apresentar formas hiperbólicas.

Exemplo 5.6 (Forma quadrática na base espectral). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Na base canônica,

$$\begin{aligned} q_{\mathbf{A}}(\mathbf{x}) &= \mathbf{x}^\top \mathbf{A} \mathbf{x} \\ &= 3x_1^2 + 2x_1x_2 + 3x_2^2. \end{aligned}$$

Os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2,$$

com autovetores unitários

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

As coordenadas espectrais são

$$z_1 = \mathbf{q}_1^\top \mathbf{x} = \frac{x_1 + x_2}{\sqrt{2}}$$

e

$$z_2 = \mathbf{q}_2^\top \mathbf{x} = \frac{x_1 - x_2}{\sqrt{2}}.$$

Nessas coordenadas,

$$q_{\mathbf{A}}(\mathbf{x}) = 4z_1^2 + 2z_2^2.$$

A superfície de nível

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = 8$$

pode ser escrita como

$$4z_1^2 + 2z_2^2 = 8,$$

ou

$$\frac{z_1^2}{2} + \frac{z_2^2}{4} = 1.$$

O elipsoide possui semieixo de comprimento

$$\sqrt{2}$$

na direção de $\mathbf{q}_1$ e semieixo de comprimento

$$2$$

na direção de $\mathbf{q}_2$. A direção associada ao menor autovalor apresenta a maior extensão.

O termo cruzado $2x_1x_2$ presente nas coordenadas canônicas desaparece nas coordenadas espectrais porque os eixos coordenados passam a coincidir com as direções principais da forma quadrática.

A representação

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2$$

também permite comparar os valores assumidos pela forma quadrática entre vetores de mesmo comprimento.

Se

$$\|\mathbf{x}\| = 1,$$

então, como a mudança de coordenadas é ortogonal,

$$\|\mathbf{z}\| = 1$$

e

$$\sum_{j=1}^p z_j^2 = 1.$$

Nesse caso,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2$$

é uma média ponderada dos autovalores, com pesos não negativos que somam 1. Essa observação conduz ao quociente de Rayleigh e à caracterização variacional dos autovalores extremos.

5.5 Quociente de Rayleigh

Definição 5.7 (Quociente de Rayleigh). Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica e seja $\mathbf{a} \in \mathbb{R}^p$, com $\mathbf{a} \neq \mathbf{0}$. O **quociente de Rayleigh** de $\mathbf{A}$ avaliado em $\mathbf{a}$ é

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{a}} = \frac{q_{\mathbf{A}}(\mathbf{a})}{\|\mathbf{a}\|^2}.$$

O numerador é a forma quadrática associada a $\mathbf{A}$, enquanto o denominador é o quadrado da norma euclidiana de $\mathbf{a}$.

Quando $\mathbf{A}$ é definida positiva, a forma quadrática também pode ser escrita como

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \langle \mathbf{a}, \mathbf{a} \rangle_{\mathbf{A}},$$

em que $\langle \cdot, \cdot \rangle_{\mathbf{A}}$ é o produto interno induzido por $\mathbf{A}$, definido em Definição 3.16.

A divisão por $\|\mathbf{a}\|^2$ remove o efeito da magnitude do vetor. Consequentemente, o quociente de Rayleigh depende da direção determinada por $\mathbf{a}$, e não de seu comprimento.

Para qualquer escalar $c \neq 0$,

$$\begin{aligned} \mathcal{R}_{\mathbf{A}}(c\mathbf{a}) &= \frac{(c\mathbf{a})^\top \mathbf{A}(c\mathbf{a})}{(c\mathbf{a})^\top (c\mathbf{a})} \\ &= \frac{c^2 \mathbf{a}^\top \mathbf{A} \mathbf{a}}{c^2 \mathbf{a}^\top \mathbf{a}} \\ &= \mathcal{R}_{\mathbf{A}}(\mathbf{a}). \end{aligned}$$

Assim, todos os vetores não nulos de uma mesma reta produzem o mesmo valor.

Quando

$$\|\mathbf{a}\| = 1,$$

tem-se

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \mathbf{a}^\top \mathbf{A} \mathbf{a}.$$

Desse modo, estudar o quociente entre todos os vetores não nulos equivale a estudar a forma quadrática sobre a esfera unitária.

5.5.1 Representação espectral

Considere a decomposição espectral

$$\mathbf{A} = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^\top,$$

com autovalores ordenados de modo que

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p.$$

As coordenadas de $\mathbf{a}$ na base espectral são

$$\mathbf{z} = [\mathbf{a}]_{\mathcal{B}_\mathbf{A}} = \mathbf{Q}_\mathbf{A}^\top \mathbf{a},$$

de modo que

$$\mathbf{a} = \mathbf{Q}_\mathbf{A} \mathbf{z}.$$

Como $\mathbf{Q}_\mathbf{A}$ é ortogonal,

$$\mathbf{a}^\top \mathbf{a} = \mathbf{z}^\top \mathbf{z} = \sum_{j=1}^p z_j^2.$$

Além disso,

$$\begin{aligned} \mathbf{a}^\top \mathbf{A} \mathbf{a} &= \mathbf{z}^\top \Lambda_\mathbf{A} \mathbf{z} \\ &= \sum_{j=1}^p \lambda_j z_j^2. \end{aligned}$$

Portanto,

$$\mathcal{R}_\mathbf{A}(\mathbf{a}) = \frac{\sum_{j=1}^p \lambda_j z_j^2}{\sum_{j=1}^p z_j^2}.$$

Definindo

$$\omega_j = \frac{z_j^2}{\sum_{\ell=1}^p z_\ell^2},$$

tem-se

$$\omega_j \geq 0$$

e

$$\sum_{j=1}^p \omega_j = 1.$$

Logo,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \sum_{j=1}^p \omega_j \lambda_j.$$

O quociente de Rayleigh é, portanto, uma média ponderada dos autovalores. Para uma base espectral fixada, ω_j mede a proporção do comprimento ao quadrado de $\mathbf{a}$ associada à direção $\mathbf{q}_j$.

Quando um autovalor λ possui multiplicidade maior que 1, a quantidade intrínseca ao autoespaço correspondente é a soma dos pesos associados aos vetores de uma base ortonormal desse autoespaço. Essa soma é igual à proporção do comprimento ao quadrado da projeção de $\mathbf{a}$ sobre $\mathcal{E}_\lambda$.

Teorema 5.5 (Extremos do quociente de Rayleigh). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica, com autovalores ordenados como*

$$\lambda_1 \geq \dots \geq \lambda_p.$$

Então, para todo $\mathbf{a} \neq \mathbf{0}$,

$$\lambda_p \leq \mathcal{R}_{\mathbf{A}}(\mathbf{a}) \leq \lambda_1.$$

Além disso,

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \lambda_1$$

e

$$\min_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \lambda_p.$$

O máximo é atingido por todo vetor não nulo do autoespaço associado a λ_1 , e o mínimo é atingido por todo vetor não nulo do autoespaço associado a λ_p . (Horn; Johnson, 2013)

Comprovação. Como

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \sum_{j=1}^p \omega_j \lambda_j,$$

com pesos não negativos que somam 1, o quociente não pode ser menor que o menor autovalor nem maior que o maior:

$$\lambda_p \leq \sum_{j=1}^p \omega_j \lambda_j \leq \lambda_1.$$

Se $\mathbf{a}$ pertence ao autoespaço associado a λ_1 , então

$$\mathbf{A}\mathbf{a} = \lambda_1 \mathbf{a},$$

e

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\mathbf{a}^\top \lambda_1 \mathbf{a}}{\mathbf{a}^\top \mathbf{a}} = \lambda_1.$$

Portanto, o limite superior é atingido.

Analogamente, se $\mathbf{a}$ pertence ao autoespaço associado a λ_p ,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \lambda_p,$$

e o limite inferior também é atingido. □

Se o maior autovalor é simples, a reta que maximiza o quociente é

$$\text{span}\{\mathbf{q}_1\}.$$

Se sua multiplicidade é maior que 1, todo vetor não nulo do autoespaço correspondente produz o mesmo valor máximo. Nesse caso, a solução é um subespaço, e não uma direção individual única.

Exemplo 5.7 (Quociente de Rayleigh em diferentes direções). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Um vetor unitário do plano pode ser escrito como

$$\mathbf{a}(\theta) = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix}.$$

Como

$$\mathbf{a}(\theta)^\top \mathbf{a}(\theta) = 1,$$

o quociente de Rayleigh é

$$\begin{aligned} \mathcal{R}_{\mathbf{A}}(\mathbf{a}(\theta)) &= \mathbf{a}(\theta)^\top \mathbf{A} \mathbf{a}(\theta) \\ &= 3 \cos^2 \theta + 2 \cos \theta \sin \theta + 3 \sin^2 \theta \\ &= 3 + \sin(2\theta). \end{aligned}$$

O valor máximo é

$$4,$$

atingido quando

$$\sin(2\theta) = 1.$$

Uma das direções correspondentes é

$$\theta = \frac{\pi}{4},$$

associada ao autovetor

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

O valor mínimo é

$$2,$$

atingido quando

$$\sin(2\theta) = -1.$$

Uma direção correspondente é

$$\theta = -\frac{\pi}{4},$$

associada ao autovetor

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A Figura 5.4 mostra a variação de

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}(\theta))$$

ao longo das direções da circunferência unitária.




Figura 5.4: O quociente de Rayleigh assume seus valores extremos nas direções dos autovetores associados aos autovalores máximo e mínimo.

As direções opostas representam a mesma reta e, por isso, produzem o mesmo valor do quociente. Os máximos aparecem em duas posições angulares separadas por π , assim como os mínimos.

5.5.2 Formulação com restrição de norma

A invariância à escala permite substituir o problema sobre vetores não nulos por um problema sobre a esfera unitária:

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}}(\mathbf{a})$$

é equivalente a

$$\max_{\mathbf{a}} \mathbf{a}^{\top} \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^{\top} \mathbf{a} = 1.$$

A restrição de norma separa a escolha da **direção** da escolha da magnitude do vetor. De fato,

$$(c\mathbf{a})^{\top} \mathbf{A} (c\mathbf{a}) = c^2 \mathbf{a}^{\top} \mathbf{A} \mathbf{a}.$$

Portanto, sem uma normalização, o valor da forma quadrática pode ser alterado simplesmente pelo escalonamento do vetor, mesmo quando sua direção permanece a mesma.

Se existe uma direção para a qual

$$\mathbf{a}^{\top} \mathbf{A} \mathbf{a} > 0,$$

o problema de maximização sem restrição é ilimitado superiormente. Analogamente, se existe uma direção para a qual

$$\mathbf{a}^{\top} \mathbf{A} \mathbf{a} < 0,$$

o problema de minimização sem restrição é ilimitado inferiormente.

A condição

$$\mathbf{a}^{\top} \mathbf{a} = 1$$

elimina esse efeito de escala e restringe a otimização às direções representadas por vetores unitários.

5.5.3 Multiplicadores de Lagrange

Em diferentes problemas da Estatística Multivariada, procura-se uma **direção** no espaço das variáveis que torne máxima ou mínima alguma quantidade de interesse. Essa quantidade pode representar, por exemplo, variabilidade, separação entre grupos ou associação entre conjuntos de variáveis.

Uma direção pode ser representada por um vetor $\mathbf{a}$. Entretanto, os vetores $\mathbf{a}$ e $c\mathbf{a}$, para $c \neq 0$, representam a mesma direção, embora tenham comprimentos diferentes. Por isso, quando o interesse está apenas na direção, é conveniente impor a normalização

$$\mathbf{a}^\top \mathbf{a} = 1.$$

Essa restrição faz com que a busca seja realizada sobre o conjunto dos vetores unitários. Geometricamente, em $\mathbb{R}^p$, esses vetores formam a esfera unitária.

Considere agora a forma quadrática

$$f(\mathbf{a}) = \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

em que $\mathbf{A} \in \mathbb{R}^{p \times p}$ é simétrica. O problema consiste em investigar como o valor de $f(\mathbf{a})$ varia quando a direção $\mathbf{a}$ percorre a esfera unitária.

5.5.3.1 O que é um ponto estacionário sob uma restrição?

Em um problema sem restrições, um ponto estacionário de uma função diferenciável é um ponto no qual seu gradiente é nulo. Em um problema com restrição, essa condição precisa ser modificada, pois nem todas as direções de deslocamento são permitidas.

Neste caso, $\mathbf{a}$ deve permanecer sobre a esfera

$$\mathbf{a}^\top \mathbf{a} = 1.$$

Um ponto é estacionário para o problema restrito quando pequenas alterações de $\mathbf{a}$ que respeitam essa restrição não produzem, em primeira ordem, aumento ou redução da função objetivo.

Geometricamente, isso ocorre quando o gradiente da função objetivo não possui componente na direção tangente à superfície da restrição. De forma equivalente, o gradiente da função objetivo deve ser proporcional ao gradiente da função que define a restrição.

Essa condição é obtida pelo método dos multiplicadores de Lagrange.

Considere a função lagrangiana

$$\mathcal{L}(\mathbf{a}, \eta) = \mathbf{a}^\top \mathbf{A} \mathbf{a} - \eta (\mathbf{a}^\top \mathbf{a} - 1),$$

em que η é o multiplicador de Lagrange.

Como $\mathbf{A}$ é simétrica,

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{A} \mathbf{a}) = 2\mathbf{A} \mathbf{a},$$

e

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{a}) = 2\mathbf{a}.$$

A condição de primeira ordem para um ponto estacionário é

$$\nabla_{\mathbf{a}} \mathcal{L} = \mathbf{0},$$

isto é,

$$2\mathbf{A} \mathbf{a} - 2\eta \mathbf{a} = \mathbf{0}.$$

Portanto,

$$\mathbf{A} \mathbf{a} = \eta \mathbf{a}.$$

Como a restrição

$$\mathbf{a}^\top \mathbf{a} = 1$$

garante que $\mathbf{a} \neq \mathbf{0}$, essa equação mostra que as direções estacionárias do problema são precisamente direções de autovetores de $\mathbf{A}$. O multiplicador de Lagrange η é o autovalor associado à direção encontrada.

Multiplicando a equação

$$\mathbf{A} \mathbf{a} = \eta \mathbf{a}$$

à esquerda por $\mathbf{a}^\top$, obtém-se

$$\begin{aligned}\mathbf{a}^\top \mathbf{A} \mathbf{a} &= \eta \mathbf{a}^\top \mathbf{a} \\ &= \eta,\end{aligned}$$

pois $\mathbf{a}^\top \mathbf{a} = 1$.

Assim, quando $\mathbf{a}$ é um autovetor unitário associado ao autovalor λ ,

$$\mathbf{A} \mathbf{a} = \lambda \mathbf{a}$$

e

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \lambda.$$

Portanto, há uma correspondência direta:

direção estacionária $\leftrightarrow$ autovetor

e

valor da forma quadrática nessa direção $\leftrightarrow$ autovalor.

Como $\mathbf{A}$ é simétrica, seus autovalores são reais. Além disso, pelos resultados do quociente de Rayleigh, para todo vetor unitário $\mathbf{a}$,

$$\lambda_{\min} \leq \mathbf{a}^\top \mathbf{A} \mathbf{a} \leq \lambda_{\max}.$$

Os extremos são atingidos nos autoespaços associados ao menor e ao maior autovalor. Consequentemente,

$$\max_{\mathbf{a}^\top \mathbf{a}=1} \mathbf{a}^\top \mathbf{A} \mathbf{a} = \lambda_{\max},$$

e

$$\min_{\mathbf{a}^\top \mathbf{a}=1} \mathbf{a}^\top \mathbf{A} \mathbf{a} = \lambda_{\min}.$$

Assim:

- o maior autovalor fornece o máximo global da forma quadrática sobre a esfera unitária;
- o menor autovalor fornece o mínimo global;

- os demais autovalores correspondem a valores estacionários intermediários;
- os autovetores associados fornecem as respectivas direções.

Teorema 5.6 (Autovalores como valores estacionários). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica e considere*

$$f(\mathbf{a}) = \mathbf{a}^\top \mathbf{A} \mathbf{a}$$

restrita aos vetores que satisfazem

$$\mathbf{a}^\top \mathbf{a} = 1.$$

Um vetor unitário $\mathbf{a}$ é um ponto estacionário de f sobre a esfera unitária se, e somente se, $\mathbf{a}$ é um autovetor de $\mathbf{A}$.

Se

$$\mathbf{A} \mathbf{a} = \lambda \mathbf{a},$$

então

$$f(\mathbf{a}) = \mathbf{a}^\top \mathbf{A} \mathbf{a} = \lambda.$$

Em particular, o maior autovalor corresponde ao máximo global da função sobre a esfera unitária, e o menor autovalor corresponde ao mínimo global.

Este resultado permite compreender por que autovalores e autovetores surgem repetidamente em técnicas multivariadas. Em muitos casos, a técnica procura uma direção $\mathbf{a}$ que torne máxima uma quantidade expressa por uma forma quadrática.

Na Análise de Componentes Principais, por exemplo, para um vetor aleatório $\mathbf{X}$ com matriz de covariâncias Σ , a variância da combinação linear

$$Y = \mathbf{a}^\top \mathbf{X}$$

é

$$\text{Var}(Y) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

A primeira componente principal procura a direção unitária que maximiza essa variância:

$$\max_{\mathbf{a}^\top \mathbf{a}=1} \mathbf{a}^\top \Sigma \mathbf{a}.$$

Pelo resultado anterior, a solução é um autovetor associado ao maior autovalor de Σ . Portanto,

maior autovalor $\longrightarrow$ maior variância possível

e

autovetor correspondente $\longrightarrow$ direção de maior variabilidade.

As componentes seguintes são obtidas acrescentando restrições de ortogonalidade às direções já encontradas. Isso conduz sucessivamente aos demais autovetores e autovalores.

A mesma estrutura reaparece, com modificações, em outros problemas multivariados. Na análise discriminante, procura-se uma direção que produza grande separação entre grupos em relação à variabilidade dentro dos grupos. Na MANOVA, determinadas direções maximizam a variação associada à hipótese em relação à variação residual. Na correlação canônica, procuram-se combinações lineares de dois conjuntos de variáveis que apresentem associação máxima.

Nesses casos, a função a ser otimizada envolve frequentemente uma razão entre duas formas quadráticas,

$$\frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{B} \mathbf{a}},$$

e a condição de estacionariedade conduz ao problema de autovalores generalizados

$$\mathbf{A} \mathbf{a} = \lambda \mathbf{B} \mathbf{a}.$$

Assim, autovalores e autovetores aparecem nessas técnicas porque representam soluções de problemas de otimização sobre direções: os autovetores fornecem as direções de interesse e os autovalores quantificam o valor atingido pelo critério nessas direções.

5.5.4 Direções sucessivas

O problema de otimização anterior identifica uma direção associada ao maior autovalor de $\mathbf{A}$. Em muitas aplicações, entretanto, interessa obter não apenas uma direção ótima, mas uma sequência de direções que representem aspectos distintos da estrutura da matriz.

Depois de encontrar a primeira direção, pode-se procurar uma segunda direção que maximize a mesma forma quadrática, mas que seja ortogonal à primeira. O procedimento pode ser repetido sucessivamente, impondo que cada nova direção seja ortogonal às anteriormente obtidas.

Considere

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$$

e uma base ortonormal de autovetores

$$\mathbf{q}_1, \dots, \mathbf{q}_p.$$

O segundo problema é

$$\max_{\mathbf{a}} \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^\top \mathbf{a} = 1$$

e

$$\mathbf{a}^\top \mathbf{q}_1 = 0.$$

A restrição

$$\mathbf{a}^\top \mathbf{q}_1 = 0$$

impede que $\mathbf{a}$ possua componente na direção de $\mathbf{q}_1$. Assim, se $\mathbf{a}$ for escrito na base espectral,

$$\mathbf{a} = z_1 \mathbf{q}_1 + z_2 \mathbf{q}_2 + \dots + z_p \mathbf{q}_p,$$

a condição de ortogonalidade implica

$$z_1 = 0.$$

Portanto, a otimização passa a ocorrer apenas no subespaço gerado por

$$\mathbf{q}_2, \dots, \mathbf{q}_p.$$

Nesse subespaço, o maior autovalor disponível é λ_2 . Assim, o maior valor da forma quadrática é λ_2 , atingido na direção de $\mathbf{q}_2$ quando λ_2 é simples.

De forma geral, a k -ésima direção pode ser obtida por

$$\max_{\mathbf{a}} \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^\top \mathbf{a} = 1$$

e

$$\mathbf{a}^\top \mathbf{q}_j = 0, \quad j = 1, \dots, k-1.$$

Teorema 5.7 (Caracterização variacional de direções sucessivas). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica, com autovalores ordenados como*

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p,$$

e seja

$$\mathbf{q}_1, \dots, \mathbf{q}_p$$

uma base ortonormal de autovetores correspondente a essa ordenação. Então, para $k = 1, \dots, p$,

$$\lambda_k = \max_{\substack{\|\mathbf{a}\|=1 \\ \mathbf{a}^\top \mathbf{q}_j = 0, j=1, \dots, k-1}} \mathbf{a}^\top \mathbf{A} \mathbf{a}.$$

O máximo é atingido por $\mathbf{q}_k$ e, quando λ_k possui multiplicidade maior que 1, por qualquer autovetor unitário associado a λ_k que satisfaça as restrições de ortogonalidade. (Horn; Johnson, 2013)

Comprovação. Como

$$\mathbf{q}_1, \dots, \mathbf{q}_p$$

formam uma base ortonormal de $\mathbb{R}^p$, qualquer vetor $\mathbf{a}$ pode ser escrito como

$$\mathbf{a} = \sum_{j=1}^p z_j \mathbf{q}_j,$$

em que

$$z_j = \mathbf{q}_j^\top \mathbf{a}.$$

As restrições

$$\mathbf{a}^\top \mathbf{q}_j = 0, \quad j = 1, \dots, k-1,$$

implicam

$$z_1 = \dots = z_{k-1} = 0.$$

Portanto,

$$\mathbf{a} = \sum_{j=k}^p z_j \mathbf{q}_j.$$

Como os autovetores são ortonormais e $\|\mathbf{a}\| = 1$,

$$\sum_{j=k}^p z_j^2 = 1.$$

Nas coordenadas espectrais,

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \sum_{j=k}^p \lambda_j z_j^2.$$

Como os autovalores estão ordenados de forma decrescente,

$$\lambda_j \leq \lambda_k, \quad j \geq k.$$

Logo,

$$\begin{aligned}\mathbf{a}^\top \mathbf{A} \mathbf{a} &= \sum_{j=k}^p \lambda_j z_j^2 \\ &\leq \lambda_k \sum_{j=k}^p z_j^2 \\ &= \lambda_k.\end{aligned}$$

O limite é atingido tomando

$$\mathbf{a} = \mathbf{q}_k,$$

pois $\mathbf{q}_k$ possui norma unitária, é ortogonal a $\mathbf{q}_1, \dots, \mathbf{q}_{k-1}$ e satisfaz

$$\mathbf{A} \mathbf{q}_k = \lambda_k \mathbf{q}_k.$$

Assim,

$$\mathbf{q}_k^\top \mathbf{A} \mathbf{q}_k = \lambda_k.$$

Portanto,

$$\max_{\substack{\|\mathbf{a}\|=1 \\ \mathbf{a}^\top \mathbf{q}_j=0, j=1,\dots,k-1}} \mathbf{a}^\top \mathbf{A} \mathbf{a} = \lambda_k.$$

□

Quando há autovalores repetidos, as direções individuais dentro do autoespaço correspondente não são unicamente determinadas. Diferentes bases ortonormais desse autoespaço produzem o mesmo valor da função objetivo e representam o mesmo subespaço espectral. Assim, o subespaço associado ao autovalor repetido é bem determinado, embora a escolha particular dos autovetores que formam uma base desse subespaço não seja única.

A caracterização variacional relaciona, portanto, três objetos fundamentais:

forma quadrática $\longleftrightarrow$ problema de otimização $\longleftrightarrow$ estrutura espectral.

Além de identificar os valores extremos, essa caracterização permite obter sucessivamente as direções ortogonais associadas aos autovalores ordenados da matriz.

5.6 Funções espectrais de matrizes

A decomposição espectral permite construir novas matrizes aplicando uma função escalar aos autovalores. Esse procedimento fornece expressões para potências, inversas, raízes quadradas, exponenciais, logaritmos e pseudoinversas de matrizes simétricas.

Considere uma matriz simétrica

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

com decomposição espectral

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A} = \text{diag}(\lambda_1, \dots, \lambda_p).$$

Se f é uma função escalar real definida em todos os autovalores de $\mathbf{A}$, pode-se aplicá-la aos elementos diagonais:

$$f(\Lambda_\mathbf{A}) = \text{diag}(f(\lambda_1), \dots, f(\lambda_p)).$$

Definição 5.8 (Função espectral de uma matriz simétrica). Seja

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top$$

uma matriz simétrica e seja f uma função real definida no espectro de $\mathbf{A}$.

A **função espectral** $f(\mathbf{A})$ é definida por

$$f(\mathbf{A}) = \mathbf{Q}_\mathbf{A} f(\Lambda_\mathbf{A}) \mathbf{Q}_\mathbf{A}^\top.$$

A definição não depende da base ortonormal escolhida dentro de um autoespaço associado a um autovalor repetido.

De fato, considerando os autovalores distintos

$$\lambda^{(1)}, \dots, \lambda^{(s)}$$

e os respectivos projetores espectrais, a função também pode ser escrita como

$$f(\mathbf{A}) = \sum_{h=1}^s f(\lambda^{(h)}) \Pi_{\lambda^{(h)}}.$$

Os projetores são determinados pelos autoespaços, independentemente da base ortonormal utilizada para representá-los.

5.6.1 Ação sobre os autoespaços

Proposição 5.7 (Ação de uma função espectral). *Se $\mathbf{v}$ pertence ao autoespaço de $\mathbf{A}$ associado ao autovalor λ , então*

$$f(\mathbf{A})\mathbf{v} = f(\lambda)\mathbf{v}.$$

(Horn; Johnson, 1991)

Comprovação. Como

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v},$$

o vetor $\mathbf{v}$ pertence à imagem do projetor

$$\Pi_{\lambda}$$

e é anulado pelos projetores associados aos demais autovalores. Assim,

$$\begin{aligned} f(\mathbf{A})\mathbf{v} &= \sum_{h=1}^s f(\lambda^{(h)}) \Pi_{\lambda^{(h)}} \mathbf{v} \\ &= f(\lambda)\mathbf{v}. \end{aligned}$$

□

Portanto, todo autovetor de $\mathbf{A}$ associado a λ também é autovetor de $f(\mathbf{A})$, agora associado ao autovalor $f(\lambda)$. Mais geralmente, todo o autoespaço $\mathcal{E}_{\lambda}$ de $\mathbf{A}$ permanece invariante sob $f(\mathbf{A})$.

A função pode fazer autovalores originalmente distintos assumirem o mesmo valor. Se

$$f(\lambda_i) = f(\lambda_j),$$

os autoespaços correspondentes passam a pertencer ao mesmo autoespaço de $f(\mathbf{A})$. Por isso, $f(\mathbf{A})$ pode possuir autoespaços de dimensão maior que os autoespaços individuais de $\mathbf{A}$.

5.6.2 Potências inteiras

Para um inteiro $k \geq 0$, escolha

$$f(\lambda) = \lambda^k.$$

Então,

$$\mathbf{A}^k = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}}^k \mathbf{Q}_{\mathbf{A}}^{\top},$$

com

$$\Lambda_{\mathbf{A}}^k = \text{diag}(\lambda_1^k, \dots, \lambda_p^k).$$

Essa expressão coincide com a fórmula obtida pela diagonalização, mas a ortogonalidade de $\mathbf{Q}_{\mathbf{A}}$ fornece

$$\mathbf{Q}_{\mathbf{A}}^{-1} = \mathbf{Q}_{\mathbf{A}}^{\top}.$$

Exemplo 5.8 (Potência de uma matriz simétrica). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix},$$

com decomposição espectral

$$\mathbf{A} = \mathbf{Q}_{\mathbf{A}} \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix} \mathbf{Q}_{\mathbf{A}}^{\top}.$$

Então,

$$\mathbf{A}^2 = \mathbf{Q}_{\mathbf{A}} \begin{bmatrix} 16 & 0 \\ 0 & 4 \end{bmatrix} \mathbf{Q}_{\mathbf{A}}^{\top}.$$

Efetuando a multiplicação,

$$\mathbf{A}^2 = \begin{bmatrix} 10 & 6 \\ 6 & 10 \end{bmatrix}.$$

A aplicação de $\mathbf{A}$ duas vezes multiplica a componente na direção de $\mathbf{q}_1$ por

$$4^2 = 16$$

e a componente na direção de $\mathbf{q}_2$ por

$$2^2 = 4.$$

5.6.3 Inversa espectral

Se todos os autovalores são diferentes de zero, define-se

$$f(\lambda) = \frac{1}{\lambda}.$$

Nesse caso,

$$\mathbf{A}^{-1} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^{-1} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A}^{-1} = \text{diag} \left(\frac{1}{\lambda_1}, \dots, \frac{1}{\lambda_p} \right).$$

A inversa desfaz o escalonamento em cada direção espectral:

$$\mathbf{A}^{-1} \mathbf{q}_j = \frac{1}{\lambda_j} \mathbf{q}_j.$$

Para o exemplo anterior,

$$\mathbf{A}^{-1} = \mathbf{Q}_\mathbf{A} \begin{bmatrix} 1/4 & 0 \\ 0 & 1/2 \end{bmatrix} \mathbf{Q}_\mathbf{A}^\top,$$

o que resulta em

$$\mathbf{A}^{-1} = \frac{1}{8} \begin{bmatrix} 3 & -1 \\ -1 & 3 \end{bmatrix}.$$

Se pelo menos um autovalor é igual a zero, a inversa usual não existe.

5.6.4 Raiz quadrada principal

Para uma matriz semidefinida positiva, todos os autovalores são não negativos. Assim, pode-se definir

$$f(\lambda) = \sqrt{\lambda}.$$

Definição 5.9 (Raiz quadrada principal). Se

$$\mathbf{A} \succeq 0,$$

a raiz quadrada principal de $\mathbf{A}$ é

$$\mathbf{A}^{1/2} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^{1/2} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A}^{1/2} = \text{diag} \left(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_p} \right).$$

A matriz $\mathbf{A}^{1/2}$ é simétrica, semidefinida positiva e satisfaz

$$\mathbf{A}^{1/2} \mathbf{A}^{1/2} = \mathbf{A}.$$

Além disso, ela é a única matriz simétrica semidefinida positiva com essa propriedade.

Para

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix},$$

tem-se

$$\mathbf{A}^{1/2} = \mathbf{Q}_\mathbf{A} \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix} \mathbf{Q}_\mathbf{A}^\top.$$

Logo,

$$\mathbf{A}^{1/2} = \frac{1}{2} \begin{bmatrix} 2 + \sqrt{2} & 2 - \sqrt{2} \\ 2 - \sqrt{2} & 2 + \sqrt{2} \end{bmatrix}.$$

A raiz quadrada principal multiplica as componentes espectrais por

$$\sqrt{\lambda_j}.$$

Aplicada duas vezes, ela produz o escalonamento original por λ_j .

5.6.5 Raiz quadrada inversa

Se

$$\mathbf{A} \succ 0,$$

todos os autovalores são estritamente positivos. Define-se então

$$\mathbf{A}^{-1/2} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^{-1/2} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A}^{-1/2} = \text{diag} \left(\frac{1}{\sqrt{\lambda_1}}, \dots, \frac{1}{\sqrt{\lambda_p}} \right).$$

Como $\mathbf{A} \succ 0$, a raiz quadrada principal é invertível e

$$\mathbf{A}^{-1/2} = (\mathbf{A}^{1/2})^{-1}.$$

Além disso,

$$\mathbf{A}^{-1} = \mathbf{A}^{-1/2} \mathbf{A}^{-1/2}$$

e

$$\mathbf{A}^{-1/2} \mathbf{A} \mathbf{A}^{-1/2} = \mathbf{I}_p.$$

De fato,

$$\begin{aligned}\mathbf{A}^{-1/2}\mathbf{A}\mathbf{A}^{-1/2} &= \mathbf{Q}_\mathbf{A}\Lambda_\mathbf{A}^{-1/2}\Lambda_\mathbf{A}\Lambda_\mathbf{A}^{-1/2}\mathbf{Q}_\mathbf{A}^\top \\ &= \mathbf{Q}_\mathbf{A}\mathbf{I}_p\mathbf{Q}_\mathbf{A}^\top \\ &= \mathbf{I}_p.\end{aligned}$$

A transformação

$$\mathbf{z} = \mathbf{A}^{-1/2}\mathbf{x}$$

reescala as componentes espectrais de $\mathbf{x}$ segundo os fatores $1/\sqrt{\lambda_j}$. Além disso, converte a forma quadrática associada à inversa em uma norma euclidiana:

$$\begin{aligned}\mathbf{x}^\top \mathbf{A}^{-1}\mathbf{x} &= \mathbf{x}^\top \mathbf{A}^{-1/2}\mathbf{A}^{-1/2}\mathbf{x} \\ &= \mathbf{z}^\top \mathbf{z} \\ &= \|\mathbf{z}\|^2.\end{aligned}$$

Quando $\mathbf{A}$ for uma matriz de covariâncias $\Sigma \succ 0$, essa construção será retomada no branqueamento. Para um vetor com média μ , a transformação correspondente será aplicada ao vetor centralizado,

$$\mathbf{z} = \Sigma^{-1/2}(\mathbf{x} - \mu).$$

Nesse caso, a distância de Mahalanobis será interpretada como uma distância euclidiana nas coordenadas branqueadas.

5.6.6 Pseudoinversa espectral

Quando uma matriz possui autovalores nulos, não é possível inverter sua ação em todas as direções. Ainda assim, é possível inverter os escalonamentos nas direções associadas a autovalores não nulos.

Definição 5.10 (Pseudoinversa de uma matriz simétrica). Seja

$$\mathbf{A} = \mathbf{Q}_\mathbf{A}\Lambda_\mathbf{A}\mathbf{Q}_\mathbf{A}^\top$$

uma matriz simétrica.

Define-se

$$\lambda_j^+ = \begin{cases} 1/\lambda_j, & \lambda_j \neq 0, \\ 0, & \lambda_j = 0. \end{cases}$$

A pseudoinversa de Moore–Penrose de $\mathbf{A}$ é

$$\mathbf{A}^+ = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}}^+ \mathbf{Q}_{\mathbf{A}}^\top,$$

em que

$$\Lambda_{\mathbf{A}}^+ = \text{diag}(\lambda_1^+, \dots, \lambda_p^+).$$

A pseudoinversa atua separadamente sobre os autoespaços: nas direções associadas a autovalores não nulos, aplica o fator $1/\lambda$; no autoespaço associado ao autovalor zero, sua ação é nula. Assim, ela inverte a transformação sobre sua imagem e mantém eliminadas as componentes pertencentes ao núcleo.

Exemplo 5.9 (Pseudoinversa de uma matriz singular). Considere

$$\mathbf{A}_0 = \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix}.$$

Seus autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 0,$$

com autovetores unitários

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A matriz $\mathbf{A}_0$ não é invertível porque possui um autovalor nulo. Para a pseudoinversa,

$$(\Lambda_{\mathbf{A}_0})^+ = \begin{bmatrix} 1/4 & 0 \\ 0 & 0 \end{bmatrix}.$$

Portanto,

$$\begin{aligned}\mathbf{A}_0^+ &= \mathbf{Q}_{\mathbf{A}_0} \begin{bmatrix} 1/4 & 0 \\ 0 & 0 \end{bmatrix} \mathbf{Q}_{\mathbf{A}_0}^\top \\ &= \frac{1}{8} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}.\end{aligned}$$

A componente na direção de $\mathbf{q}_1$ é dividida por 4. A componente na direção de $\mathbf{q}_2$, pertencente ao núcleo de $\mathbf{A}_0$, é anulada.

Quando $\mathbf{A}$ é invertível,

$$\mathbf{A}^+ = \mathbf{A}^{-1}.$$

A pseudoinversa será retomada no capítulo seguinte, no qual será definida para matrizes retangulares por meio da decomposição em valores singulares.

5.6.7 Exponencial e logaritmo matriciais

A função exponencial é definida para qualquer matriz simétrica por

$$\exp(\mathbf{A}) = \mathbf{Q}_{\mathbf{A}} \operatorname{diag}(e^{\lambda_1}, \dots, e^{\lambda_p}) \mathbf{Q}_{\mathbf{A}}^\top.$$

Como

$$e^{\lambda_j} > 0,$$

a matriz $\exp(\mathbf{A})$ é positiva definida.

A exponencial matricial também pode ser representada pela série

$$\exp(\mathbf{A}) = \sum_{k=0}^{\infty} \frac{\mathbf{A}^k}{k!}.$$

Para uma matriz simétrica positiva definida, define-se o **logaritmo principal** por

$$\log(\mathbf{A}) = \mathbf{Q}_{\mathbf{A}} \operatorname{diag}(\log \lambda_1, \dots, \log \lambda_p) \mathbf{Q}_{\mathbf{A}}^\top.$$

As identidades escalares são preservadas espectralmente:

$$\exp(\log(\mathbf{A})) = \mathbf{A}$$

para $\mathbf{A} \succ 0$, e

$$\log(\exp(\mathbf{A})) = \mathbf{A}$$

para toda matriz simétrica real.

A Tabela 5.1 reúne as principais funções desenvolvidas nesta seção.

Tabela 5.1: Principais funções espectrais de matrizes simétricas.

Função	Ação sobre λ_j	Condição adicional
$\mathbf{A}^k$	λ_j^k	$k \in \{0, 1, 2, \dots\}$
$\mathbf{A}^{-1}$	$1/\lambda_j$	$\lambda_j \neq 0$ para todo j
$\mathbf{A}^{1/2}$	$\sqrt{\lambda_j}$	$\mathbf{A} \succeq 0$
$\mathbf{A}^{-1/2}$	$1/\sqrt{\lambda_j}$	$\mathbf{A} \succ 0$
$\mathbf{A}^+$	$1/\lambda_j$ se $\lambda_j \neq 0$; 0 se $\lambda_j = 0$	nenhuma além da simetria assumida na seção
$\exp(\mathbf{A})$	e^{λ_j}	nenhuma além da simetria assumida na seção
$\log(\mathbf{A})$	$\log \lambda_j$	$\mathbf{A} \succ 0$

As funções espectrais atuam separadamente sobre os autoespaços, transformando cada autovalor λ no valor escalar $f(\lambda)$. Essa construção permite obter diretamente potências, inversas, raízes e pseudoinversas e mostra como certas transformações matriciais podem ser compreendidas como reescalamentos das direções espectrais.

Em particular, a raiz quadrada e a raiz quadrada inversa permitem converter problemas definidos por uma geometria induzida por uma matriz positiva definida em problemas euclidianos equivalentes. Essa ideia será utilizada imediatamente na formulação dos autovalores generalizados.

5.7 Aprofundamento: autovalores generalizados

Leitura de aprofundamento

Esta seção apresenta uma extensão do problema ordinário de autovalores para situações em que duas formas quadráticas são consideradas simultaneamente. Embora esse desenvolvimento não seja necessário para acompanhar os resultados centrais da decomposição

espectral, ele fornece uma base matemática importante para técnicas multivariadas que envolvem a comparação entre diferentes estruturas de variabilidade, separação ou associação.

Ao longo da seção, serão apresentados os autovalores generalizados, o quociente de Rayleigh generalizado, a ortogonalidade em uma métrica definida por uma matriz positiva definida e a redução do problema generalizado a um problema espectral ordinário.

Alguns problemas de Estatística Multivariada envolvem a comparação entre duas formas quadráticas, em vez da otimização de uma única forma quadrática relativamente à norma euclidiana. Nesses casos, surge naturalmente o problema de autovalores generalizados,

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{M}\mathbf{v},$$

em que $\mathbf{A}$ é simétrica e $\mathbf{M}$ é simétrica positiva definida.

Essa estrutura generaliza o problema ordinário de autovalores, recuperado quando

$$\mathbf{M} = \mathbf{I}_p.$$

Os autovalores generalizados serão úteis posteriormente em problemas que envolvem a comparação entre diferentes medidas de variabilidade, separação ou associação. A leitura a seguir desenvolve a formulação matemática desse problema e sua relação com o quociente de Rayleigh e a decomposição espectral.

O quociente de Rayleigh compara uma forma quadrática com a norma euclidiana do vetor. Em outros problemas, a normalização também é definida por uma forma quadrática:

$$\mathbf{a}^\top \mathbf{M} \mathbf{a},$$

em que

$$\mathbf{M} = \mathbf{M}^\top \succ 0.$$

Conforme a Definição 3.16, a matriz $\mathbf{M}$ determina o produto interno

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{y}$$

e a norma

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\mathbf{x}^\top \mathbf{M} \mathbf{x}}.$$

Nesse contexto, procura-se uma direção que compare as formas quadráticas associadas a duas matrizes.

Definição 5.11 (Autovalor e autovetor generalizados). Sejam

$$\mathbf{A}, \mathbf{M} \in \mathbb{R}^{p \times p},$$

com

$$\mathbf{A} = \mathbf{A}^\top$$

e

$$\mathbf{M} = \mathbf{M}^\top \succ 0.$$

Um escalar real

$$\lambda \in \mathbb{R}$$

é um **autovalor generalizado** do par $(\mathbf{A}, \mathbf{M})$ quando existe um vetor não nulo

$$\mathbf{v} \in \mathbb{R}^p$$

tal que

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{M}\mathbf{v}.$$

O vetor $\mathbf{v}$ é denominado **autovetor generalizado** associado a λ .

Quando

$$\mathbf{M} = \mathbf{I}_p,$$

recupera-se o problema ordinário:

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

A equação generalizada pode ser reorganizada como

$$(\mathbf{A} - \lambda \mathbf{M}) \mathbf{v} = \mathbf{0}.$$

Existem soluções não triviais se, e somente se,

$$\det(\mathbf{A} - \lambda \mathbf{M}) = 0.$$

Essa equação é a equação característica generalizada do par $(\mathbf{A}, \mathbf{M})$ e determina seus autovaleiros generalizados.

5.7.1 Quociente de Rayleigh generalizado

Definição 5.12 (Quociente de Rayleigh generalizado). Sejam $\mathbf{A} \in \mathbb{R}^{p \times p}$ simétrica e $\mathbf{M} \in \mathbb{R}^{p \times p}$ simétrica positiva definida. Para $\mathbf{a} \in \mathbb{R}^p$, com $\mathbf{a} \neq \mathbf{0}$, o **quociente de Rayleigh generalizado** associado ao par $(\mathbf{A}, \mathbf{M})$ é

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{M} \mathbf{a}} = \frac{q_{\mathbf{A}}(\mathbf{a})}{\|\mathbf{a}\|_{\mathbf{M}}^2}.$$

O numerador é a forma quadrática associada a $\mathbf{A}$, enquanto o denominador é o quadrado da norma induzida por $\mathbf{M}$,

$$\|\mathbf{a}\|_{\mathbf{M}}^2 = \langle \mathbf{a}, \mathbf{a} \rangle_{\mathbf{M}} = \mathbf{a}^\top \mathbf{M} \mathbf{a}.$$

Como $\mathbf{M} \succ \mathbf{0}$,

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} > 0$$

para todo $\mathbf{a} \neq \mathbf{0}$. Portanto, o denominador é sempre positivo e o quociente está definido para todo vetor não nulo.

No quociente de Rayleigh ordinário, a normalização é realizada pela norma euclidiana,

$$\|\mathbf{a}\|^2 = \mathbf{a}^\top \mathbf{a}.$$

No caso generalizado, essa normalização é substituída pela norma induzida por $\mathbf{M}$. Assim, o comprimento do vetor passa a ser medido segundo a geometria determinada por essa matriz.

Assim como no caso ordinário, o quociente é invariante à escala. Para qualquer escalar $c \neq 0$,

$$\begin{aligned}
\mathcal{R}_{\mathbf{A},\mathbf{M}}(c\mathbf{a}) &= \frac{(c\mathbf{a})^\top \mathbf{A}(c\mathbf{a})}{(c\mathbf{a})^\top \mathbf{M}(c\mathbf{a})} \\
&= \frac{c^2 \mathbf{a}^\top \mathbf{A} \mathbf{a}}{c^2 \mathbf{a}^\top \mathbf{M} \mathbf{a}} \\
&= \mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}).
\end{aligned}$$

Portanto, o valor do quociente depende da direção determinada por $\mathbf{a}$, e não de sua magnitude segundo a norma induzida por $\mathbf{M}$.

Essa invariância permite escolher, em cada direção, um representante com norma unitária na geometria determinada por $\mathbf{M}$. Consequentemente, o problema

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a})$$

é equivalente a

$$\max_{\mathbf{a}} \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = 1.$$

A restrição equivale a

$$\|\mathbf{a}\|_{\mathbf{M}} = 1$$

e, portanto, fixa o comprimento de $\mathbf{a}$ segundo a geometria induzida por $\mathbf{M}$.

Para determinar os pontos estacionários desse problema restrito, considere a função lagrangiana

$$\mathcal{L}(\mathbf{a}, \eta) = \mathbf{a}^\top \mathbf{A} \mathbf{a} - \eta (\mathbf{a}^\top \mathbf{M} \mathbf{a} - 1),$$

em que η é o multiplicador de Lagrange.

Como $\mathbf{A}$ e $\mathbf{M}$ são simétricas,

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{A} \mathbf{a}) = 2\mathbf{A} \mathbf{a}$$

e

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{M} \mathbf{a}) = 2\mathbf{M} \mathbf{a}.$$

Assim,

$$\nabla_{\mathbf{a}} \mathcal{L} = 2\mathbf{A} \mathbf{a} - 2\eta \mathbf{M} \mathbf{a}.$$

A condição de primeira ordem

$$\nabla_{\mathbf{a}} \mathcal{L} = \mathbf{0}$$

produz

$$\mathbf{A} \mathbf{a} = \eta \mathbf{M} \mathbf{a}.$$

Como a restrição

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = 1$$

garante que $\mathbf{a} \neq \mathbf{0}$, essa equação mostra que todo ponto estacionário $\mathbf{a}$ é um autovetor generalizado do par $(\mathbf{A}, \mathbf{M})$ e que o multiplicador η é o autovalor generalizado correspondente.

Multiplicando a equação

$$\mathbf{A} \mathbf{a} = \eta \mathbf{M} \mathbf{a}$$

à esquerda por $\mathbf{a}^\top$, obtém-se

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \eta \mathbf{a}^\top \mathbf{M} \mathbf{a}.$$

Sob a normalização

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = 1,$$

segue que

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \eta.$$

Além disso,

$$\mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{M} \mathbf{a}} = \eta.$$

Portanto, em um autovetor generalizado normalizado, o valor do quociente de Rayleigh generalizado coincide com o autovalor generalizado correspondente.

5.7.2 Redução a um problema espectral ordinário

Como $\mathbf{M} \succ 0$, a matriz $\mathbf{M}$ é invertível, e a equação generalizada também poderia ser escrita como

$$\mathbf{M}^{-1} \mathbf{A} \mathbf{v} = \lambda \mathbf{v}.$$

Entretanto, mesmo que $\mathbf{A}$ e $\mathbf{M}$ sejam simétricas, a matriz $\mathbf{M}^{-1} \mathbf{A}$ não precisa ser simétrica. Para preservar a estrutura simétrica e poder aplicar diretamente o Teorema Espectral, é preferível transformar o problema utilizando a raiz quadrada de $\mathbf{M}$.

Como $\mathbf{M} \succ 0$, existem as matrizes simétricas

$$\mathbf{M}^{1/2}$$

e

$$\mathbf{M}^{-1/2}.$$

Defina

$$\mathbf{u} = \mathbf{M}^{1/2} \mathbf{v}.$$

Consequentemente,

$$\mathbf{v} = \mathbf{M}^{-1/2} \mathbf{u}.$$

Substituindo na equação generalizada,

$$\mathbf{A} \mathbf{M}^{-1/2} \mathbf{u} = \lambda \mathbf{M} \mathbf{M}^{-1/2} \mathbf{u}.$$

Como

$$\mathbf{M}\mathbf{M}^{-1/2} = \mathbf{M}^{1/2},$$

obtém-se

$$\mathbf{A}\mathbf{M}^{-1/2}\mathbf{u} = \lambda\mathbf{M}^{1/2}\mathbf{u}.$$

Multiplicando à esquerda por $\mathbf{M}^{-1/2}$,

$$(\mathbf{M}^{-1/2}\mathbf{A}\mathbf{M}^{-1/2})\mathbf{u} = \lambda\mathbf{u}.$$

Defina

$$\widetilde{\mathbf{A}} = \mathbf{M}^{-1/2}\mathbf{A}\mathbf{M}^{-1/2}.$$

Como $\mathbf{A}$ e $\mathbf{M}^{-1/2}$ são simétricas,

$$\widetilde{\mathbf{A}}^\top = \widetilde{\mathbf{A}}.$$

Assim, o problema generalizado é convertido no problema espectral ordinário

$$\widetilde{\mathbf{A}}\mathbf{u} = \lambda\mathbf{u},$$

para uma matriz simétrica. Consequentemente, todos os autovalores generalizados do par $(\mathbf{A}, \mathbf{M})$ são reais e os resultados do Teorema Espectral podem ser aplicados à matriz $\widetilde{\mathbf{A}}$.

Essa transformação também converte o quociente generalizado em um quociente ordinário. Como

$$\mathbf{a} = \mathbf{M}^{-1/2}\mathbf{u},$$

tem-se

$$\begin{aligned}\mathbf{a}^\top \mathbf{M} \mathbf{a} &= \mathbf{u}^\top \mathbf{M}^{-1/2} \mathbf{M} \mathbf{M}^{-1/2} \mathbf{u} \\ &= \mathbf{u}^\top \mathbf{u}\end{aligned}$$

e

$$\begin{aligned}\mathbf{a}^\top \mathbf{A} \mathbf{a} &= \mathbf{u}^\top \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2} \mathbf{u} \\ &= \mathbf{u}^\top \widetilde{\mathbf{A}} \mathbf{u}.\end{aligned}$$

Portanto,

$$\mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}) = \mathcal{R}_{\tilde{\mathbf{A}}}(\mathbf{u}).$$

A mudança de variáveis

$$\mathbf{u} = \mathbf{M}^{1/2}\mathbf{a}$$

transforma a geometria induzida por $\mathbf{M}$ em geometria euclidiana, pois

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = \mathbf{u}^\top \mathbf{u}.$$

Equivalentemente,

$$\mathbf{a} = \mathbf{M}^{-1/2}\mathbf{u}.$$

Geometricamente, $\mathbf{M}^{-1/2}$ transforma a esfera unitária euclidiana no elipsoide

$$\{\mathbf{a} \in \mathbb{R}^p : \mathbf{a}^\top \mathbf{M} \mathbf{a} = 1\}.$$

O problema generalizado pode, portanto, ser estudado como um problema de Rayleigh ordinário no sistema de coordenadas em que a métrica definida por $\mathbf{M}$ se torna euclidiana.

Quando $\mathbf{M}$ representar posteriormente uma matriz de covariâncias, essa mesma estrutura estará relacionada ao branqueamento. Aqui, porém, $\mathbf{M}$ representa genericamente a matriz que define a geometria do problema.

Teorema 5.8 (Extremos do quociente de Rayleigh generalizado). *Sejam $\mathbf{A}$ simétrica e $\mathbf{M}$ positiva definida. Denote por*

$$\lambda_1 \geq \dots \geq \lambda_p$$

os autovalores generalizados do par $(\mathbf{A}, \mathbf{M})$.

Então, para todo $\mathbf{a} \neq \mathbf{0}$,

$$\lambda_p \leq \mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}) \leq \lambda_1.$$

Além disso,

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \lambda_1$$

e

$$\min_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \lambda_p.$$

O máximo é atingido por todo vetor não nulo do autoespaço generalizado associado a λ_1 , e o mínimo é atingido por todo vetor não nulo do autoespaço generalizado associado a λ_p .

Comprovação. A transformação

$$\mathbf{u} = \mathbf{M}^{1/2} \mathbf{a}$$

é invertível e estabelece

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \mathcal{R}_{\tilde{\mathbf{A}}}(\mathbf{u}),$$

em que

$$\tilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}$$

é simétrica.

Os autovalores ordinários de $\tilde{\mathbf{A}}$ são os autovalores generalizados do par $(\mathbf{A}, \mathbf{M})$. Aplicando o Teorema 5.5 a $\tilde{\mathbf{A}}$, obtêm-se os limites e os extremos apresentados. $\square$

5.7.3 Ortogonalidade na métrica de $\mathbf{M}$

Os autovetores generalizados não precisam ser ortogonais segundo o produto interno euclidiano. Eles podem, entretanto, ser escolhidos ortonormais na geometria determinada por $\mathbf{M}$.

Proposição 5.8 (Ortogonalidade e base de autovetores generalizados). *Sejam $\mathbf{A}$ simétrica e $\mathbf{M} \succ 0$.*

Se $\mathbf{v}_i$ e $\mathbf{v}_j$ são autovetores generalizados associados a autovalores distintos λ_i e λ_j , então

$$\mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = 0.$$

Além disso, existe uma base de $\mathbb{R}^p$ formada por autovetores generalizados

$$\mathcal{B}_g = \{\mathbf{v}_1, \dots, \mathbf{v}_p\}$$

que pode ser escolhida de modo que

$$\mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = \delta_{ij}.$$

(Horn; Johnson, 2013)

Comprovação. Para autovalores distintos,

$$\mathbf{A} \mathbf{v}_i = \lambda_i \mathbf{M} \mathbf{v}_i$$

e

$$\mathbf{A} \mathbf{v}_j = \lambda_j \mathbf{M} \mathbf{v}_j.$$

Como $\mathbf{A}$ é simétrica,

$$\begin{aligned} \lambda_i \mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j &= (\mathbf{A} \mathbf{v}_i)^\top \mathbf{v}_j \\ &= \mathbf{v}_i^\top \mathbf{A}^\top \mathbf{v}_j \\ &= \mathbf{v}_i^\top \mathbf{A} \mathbf{v}_j \\ &= \lambda_j \mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j. \end{aligned}$$

Portanto,

$$(\lambda_i - \lambda_j) \mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = 0.$$

Como $\lambda_i \neq \lambda_j$,

$$\mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = 0.$$

Para mostrar a existência de uma base completa, considere

$$\widetilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}.$$

Como $\widetilde{\mathbf{A}}$ é simétrica, o Teorema Espectral garante uma base ortonormal de autovetores

$$\{\mathbf{u}_1, \dots, \mathbf{u}_p\}.$$

Defina

$$\mathbf{v}_j = \mathbf{M}^{-1/2} \mathbf{u}_j.$$

Esses vetores são autovetores generalizados e

$$\begin{aligned} \mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j &= \mathbf{u}_i^\top \mathbf{M}^{-1/2} \mathbf{M} \mathbf{M}^{-1/2} \mathbf{u}_j \\ &= \mathbf{u}_i^\top \mathbf{u}_j \\ &= \delta_{ij}. \end{aligned}$$

Assim, mesmo quando há autovalores generalizados repetidos, pode-se escolher uma base ortonormal segundo o produto interno induzido por $\mathbf{M}$. $\square$

5.7.4 Diagonalização simultânea por congruência

Considere a decomposição espectral

$$\widetilde{\mathbf{A}} = \mathbf{Q}_g \mathbf{\Lambda}_g \mathbf{Q}_g^\top,$$

em que

$$\widetilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}.$$

Defina

$$\mathbf{B}_g = \mathbf{M}^{-1/2} \mathbf{Q}_g.$$

Como $\mathbf{M}^{-1/2}$ é invertível e $\mathbf{Q}_g$ é ortogonal, $\mathbf{B}_g$ é invertível. Suas colunas formam uma base $\mathbf{M}$ -ortonormal de autovetores generalizados.

De fato,

$$\begin{aligned} \mathbf{A} \mathbf{B}_g &= \mathbf{A} \mathbf{M}^{-1/2} \mathbf{Q}_g \\ &= \mathbf{M}^{1/2} \widetilde{\mathbf{A}} \mathbf{Q}_g \\ &= \mathbf{M}^{1/2} \mathbf{Q}_g \mathbf{\Lambda}_g \\ &= \mathbf{M} \mathbf{B}_g \mathbf{\Lambda}_g. \end{aligned}$$

Além disso,

$$\begin{aligned}\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g &= \mathbf{Q}_g^\top \mathbf{M}^{-1/2} \mathbf{M} \mathbf{M}^{-1/2} \mathbf{Q}_g \\ &= \mathbf{Q}_g^\top \mathbf{Q}_g \\ &= \mathbf{I}_p,\end{aligned}$$

e

$$\begin{aligned}\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g &= \mathbf{Q}_g^\top \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2} \mathbf{Q}_g \\ &= \mathbf{Q}_g^\top \tilde{\mathbf{A}} \mathbf{Q}_g \\ &= \Lambda_g.\end{aligned}$$

Portanto,

$$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_p$$

e

$$\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g = \Lambda_g.$$

O par $(\mathbf{A}, \mathbf{M})$ é, assim, reduzido simultaneamente por uma transformação de congruência:

$$(\mathbf{A}, \mathbf{M}) \longrightarrow (\Lambda_g, \mathbf{I}_p).$$

Essa operação deve ser distinguida da semelhança

$$\mathbf{B}^{-1} \mathbf{A} \mathbf{B},$$

utilizada para representar um único operador em outra base. Na congruência, as matrizes aparecem multiplicadas pela transposta da matriz de base à esquerda e pela própria matriz à direita.

Como

$$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_p,$$

segue que

$$\mathbf{B}_g^{-1} = \mathbf{B}_g^\top \mathbf{M}.$$

Assim, se

$$\mathbf{a} = \mathbf{B}_g \mathbf{z},$$

então as coordenadas de $\mathbf{a}$ nessa base são

$$\mathbf{z} = \mathbf{B}_g^{-1} \mathbf{a} = \mathbf{B}_g^\top \mathbf{M} \mathbf{a}.$$

Nessas coordenadas,

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = \mathbf{z}^\top \mathbf{z}$$

e

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \mathbf{z}^\top \Lambda_g \mathbf{z}.$$

Consequentemente,

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \frac{\sum_{j=1}^p \lambda_j z_j^2}{\sum_{j=1}^p z_j^2}.$$

O quociente generalizado assume, portanto, a mesma forma do quociente de Rayleigh ordinário quando expresso na base $\mathbf{M}$ -ortonormal de autovetores generalizados.

Exemplo 5.10 (Autovalores generalizados de duas formas quadráticas). Considere

$$\mathbf{A} = \begin{bmatrix} 5 & 1 \\ 1 & 2 \end{bmatrix}$$

e

$$\mathbf{M} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}.$$

As duas matrizes são simétricas e $\mathbf{M}$ é positiva definida.

Os autovalores generalizados são obtidos por

$$\det(\mathbf{A} - \lambda \mathbf{M}) = 0.$$

Como

$$\mathbf{A} - \lambda \mathbf{M} = \begin{bmatrix} 5 - 2\lambda & 1 \\ 1 & 2 - \lambda \end{bmatrix},$$

tem-se

$$\begin{aligned} \det(\mathbf{A} - \lambda \mathbf{M}) &= (5 - 2\lambda)(2 - \lambda) - 1 \\ &= 2\lambda^2 - 9\lambda + 9 \\ &= (2\lambda - 3)(\lambda - 3). \end{aligned}$$

Portanto,

$$\lambda_1 = 3$$

e

$$\lambda_2 = \frac{3}{2}.$$

Para $\lambda_1 = 3$,

$$\mathbf{A} - 3\mathbf{M} = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix}.$$

O sistema fornece

$$v_2 = v_1,$$

de modo que um autovetor generalizado é

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

De fato,

$$\mathbf{A}\mathbf{v}_1 = \begin{bmatrix} 6 \\ 3 \end{bmatrix}$$

e

$$3\mathbf{M}\mathbf{v}_1 = 3 \begin{bmatrix} 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 6 \\ 3 \end{bmatrix}.$$

Para

$$\lambda_2 = \frac{3}{2},$$

tem-se

$$\mathbf{A} - \frac{3}{2}\mathbf{M} = \begin{bmatrix} 2 & 1 \\ 1 & 1/2 \end{bmatrix}.$$

O sistema conduz a

$$v_2 = -2v_1.$$

Assim, pode-se escolher

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -2 \end{bmatrix}.$$

Esses vetores não são ortogonais no produto interno euclidiano:

$$\mathbf{v}_1^\top \mathbf{v}_2 = -1.$$

Entretanto,

$$\begin{aligned} \mathbf{v}_1^\top \mathbf{M} \mathbf{v}_2 &= \begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -2 \end{bmatrix} \\ &= 0. \end{aligned}$$

Logo, eles são ortogonais na geometria determinada por $\mathbf{M}$.

Suas normas nessa métrica são

$$\|\mathbf{v}_1\|_{\mathbf{M}} = \sqrt{3}$$

e

$$\|\mathbf{v}_2\|_{\mathbf{M}} = \sqrt{6}.$$

Os autovetores generalizados normalizados são

$$\mathbf{b}_{g,1} = \frac{1}{\sqrt{3}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{b}_{g,2} = \frac{1}{\sqrt{6}} \begin{bmatrix} 1 \\ -2 \end{bmatrix}.$$

Reunindo-os nas colunas da matriz da base

$$\mathbf{B}_g = [\mathbf{b}_{g,1} \quad \mathbf{b}_{g,2}],$$

obtêm-se

$$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_2$$

e

$$\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g = \begin{bmatrix} 3 & 0 \\ 0 & 3/2 \end{bmatrix}.$$

O maior valor da razão

$$\frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{M} \mathbf{a}}$$

é 3 e ocorre no autoespaço generalizado gerado por $\mathbf{v}_1$. O menor valor é 3/2 e ocorre no autoespaço generalizado gerado por $\mathbf{v}_2$.

Os autovalores generalizados permitem comparar duas formas quadráticas em uma geometria definida por uma delas. Essa estrutura será utilizada posteriormente em problemas que comparam diferentes fontes de dispersão ou associação, sem antecipar aqui a formulação específica dessas técnicas.

5.8 Síntese do capítulo

Este capítulo desenvolveu a estrutura espectral das transformações lineares quadradas. O ponto de partida foi a identificação de direções invariantes, isto é, direções nas quais a ação de uma matriz reduz-se à multiplicação por um escalar.

Para

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v},$$

com $\mathbf{v} \neq \mathbf{0}$, o escalar λ é um autovalor e $\mathbf{v}$ é um autovetor correspondente. O conjunto formado pelo vetor nulo e por todos os autovetores associados a λ constitui o autoespaço

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p).$$

Os autovalores são determinados pela condição

$$\det(\mathbf{A} - \lambda\mathbf{I}_p) = 0.$$

A multiplicidade algébrica $m_a(\lambda)$ registra a multiplicidade de λ como raiz do polinômio característico, enquanto a multiplicidade geométrica

$$m_g(\lambda) = \dim(\mathcal{E}_\lambda)$$

mede a dimensão do autoespaço correspondente.

Quando $\mathbf{A}$ possui p autovetores linearmente independentes, eles formam uma base

$$\mathcal{B}_\mathbf{A} = \{\mathbf{v}_1, \dots, \mathbf{v}_p\},$$

cujas matrizes é

$$\mathbf{B}_\mathbf{A} = [\mathbf{v}_1 \quad \dots \quad \mathbf{v}_p].$$

Nessa base,

$$[T_\mathbf{A}]_{\mathcal{B}_\mathbf{A} \leftarrow \mathcal{B}_\mathbf{A}} = \mathbf{B}_\mathbf{A}^{-1} \mathbf{A} \mathbf{B}_\mathbf{A} = \Lambda_\mathbf{A},$$

e, portanto,

$$\mathbf{A} = \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1}.$$

A diagonalização é, assim, uma mudança para coordenadas nas quais o operador atua separadamente sobre cada direção da base de autovetores.

Para matrizes simétricas reais, o Teorema Espectral garante uma base ortonormal de autovetores. Nesse caso, a matriz da base pode ser escolhida ortogonal,

$$\mathbf{Q}_\mathbf{A} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p],$$

com

$$\mathbf{Q}_\mathbf{A}^{-1} = \mathbf{Q}_\mathbf{A}^\top,$$

e obtém-se a decomposição espectral

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Equivalentemente,

$$\mathbf{A} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^\top.$$

Agrupando autovalores repetidos, essa representação pode ser escrita em termos dos projetores espectrais:

$$\mathbf{A} = \sum_h \lambda^{(h)} \Pi_{\lambda^{(h)}}.$$

Essa forma mostra que uma matriz simétrica atua projetando o vetor sobre autoespaços ortogonais e aplicando a cada componente o autovalor correspondente.

A decomposição espectral também permite recuperar diretamente propriedades da matriz:

$$\text{tr}(\mathbf{A}) = \sum_{j=1}^p \lambda_j,$$

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j,$$

e

$$\text{posto}(\mathbf{A}) = \#\{j : \lambda_j \neq 0\},$$

contando as multiplicidades.

Além disso,

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \text{span} \left\{ \mathbf{q}_j : \lambda_j = 0 \right\},$$

enquanto

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \text{span} \left\{ \mathbf{q}_j : \lambda_j \neq 0 \right\}.$$

Para matrizes simétricas,

$$\text{Im}(T_{\mathbf{A}}) = \ker(T_{\mathbf{A}})^\perp.$$

A mesma decomposição simplifica as formas quadráticas. Se

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}} = \mathbf{Q}_{\mathbf{A}}^\top \mathbf{x},$$

então

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2.$$

As possibilidades de sinal da forma quadrática são, portanto, determinadas pelos sinais dos autovalores. Quando $\mathbf{A} \succ 0$, suas superfícies de nível são elipsoides cujos eixos estão alinhados aos autovetores.

O quociente de Rayleigh,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{a}},$$

é uma média ponderada dos autovalores. Para

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p,$$

tem-se

$$\lambda_p \leq \mathcal{R}_{\mathbf{A}}(\mathbf{a}) \leq \lambda_1.$$

O máximo e o mínimo são atingidos nos autoespaços associados aos autovalores extremos. A otimização de uma forma quadrática sob a restrição

$$\mathbf{a}^\top \mathbf{a} = 1$$

conduz à condição

$$\mathbf{A}\mathbf{a} = \lambda\mathbf{a}.$$

Autovalores e autovetores podem, portanto, ser interpretados também como valores e direções estacionárias de problemas de otimização quadrática.

A decomposição espectral permite ainda definir funções de matrizes simétricas. Se f está definida no espectro de $\mathbf{A}$,

$$f(\mathbf{A}) = \mathbf{Q}_{\mathbf{A}} f(\Lambda_{\mathbf{A}}) \mathbf{Q}_{\mathbf{A}}^\top.$$

Equivalentemente,

$$f(\mathbf{A}) = \sum_h f(\lambda^{(h)}) \Pi_{\lambda^{(h)}}.$$

Assim, a função espectral preserva os autoespaços e transforma cada autovalor λ no escalar $f(\lambda)$. Potências, inversas, raízes quadradas, raízes quadradas inversas, pseudoinversas, exponenciais e logaritmos são casos particulares dessa construção, sob as condições necessárias à definição de cada função.

Quando a geometria do problema é determinada por uma matriz simétrica positiva definida $\mathbf{M}$, surge o problema de autovalores generalizados

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{M}\mathbf{v},$$

com $\mathbf{A} = \mathbf{A}^\top$ e $\mathbf{M} \succ 0$.

O quociente correspondente é

$$\mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{M} \mathbf{a}}.$$

A transformação

$$\mathbf{u} = \mathbf{M}^{1/2} \mathbf{a}$$

converte esse problema em um problema de Rayleigh ordinário para a matriz simétrica

$$\tilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}.$$

Consequentemente, os autovalores generalizados são reais e pode-se escolher uma base de autovetores generalizados cuja matriz $\mathbf{B}_g$ satisfaz

$$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_p$$

e

$$\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g = \Lambda_g.$$

A Tabela 5.2 reúne as expressões principais desenvolvidas no capítulo.

Tabela 5.2: Síntese dos principais objetos espectrais desenvolvidos no capítulo.

Objeto	Expressão	Interpretação
Equação de autovalor	$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$	Identifica direções invariantes
Autoespaço	$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p)$	Reúne os vetores associados a λ
Diagonalização	$\mathbf{A} = \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1}$	Representa o operador em uma base de autovetores
Decomposição espectral	$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top$	Diagonaliza ortogonalmente uma matriz simétrica
Projeto espectral	$\Pi_\lambda = \mathbf{Q}_\lambda \mathbf{Q}_\lambda^\top$	Projeta sobre o autoespaço associado a λ
Forma quadrática	$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_j \lambda_j z_j^2$	Separa as contribuições das direções espectrais
Quociente de Rayleigh	$\mathcal{R}_\mathbf{A}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{a}}$	Caracteriza valores e direções espectrais por otimização
Função espectral	$f(\mathbf{A}) = \mathbf{Q}_\mathbf{A} f(\Lambda_\mathbf{A}) \mathbf{Q}_\mathbf{A}^\top$	Aplica uma função aos autovalores
Problema generalizado	$\mathbf{A}\mathbf{v} = \lambda \mathbf{M} \mathbf{v}$	Compara duas formas quadráticas

Objeto	Expressão	Interpretação
Base generalizada	$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_p$	Define ortonormalidade na geometria induzida por $\mathbf{M}$
Diagonalização por congruência	$\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g = \Lambda_g$	Reduz simultaneamente as duas formas quadráticas

Ao final deste capítulo, o estudante deverá ser capaz de:

- identificar autovalores, autovetores e autoespaços e interpretar seu significado geométrico;
- distinguir multiplicidades algébrica e geométrica;
- determinar quando uma matriz é diagonalizável;
- interpretar a diagonalização como mudança para uma base de autovetores;
- aplicar o Teorema Espectral a matrizes simétricas reais;
- interpretar projetores e subespaços espectrais;
- relacionar autovalores a traço, determinante, posto, núcleo, imagem e positividade;
- representar formas quadráticas em coordenadas espectrais;
- formular problemas de otimização por meio do quociente de Rayleigh;
- construir e interpretar funções espectrais de matrizes;
- compreender inversas, raízes e pseudoinversas pela ação sobre os autovalores;
- formular e transformar problemas de autovalores generalizados;
- distinguir ortogonalidade euclidiana de ortogonalidade segundo uma matriz positiva definida.

A decomposição espectral fornece uma descrição particularmente simples para matrizes simétricas quadradas. Entretanto, matrizes de dados e muitas transformações de interesse são retangulares ou não simétricas e, portanto, não admitem diretamente essa decomposição. O próximo capítulo amplia essas ideias por meio da **Decomposição em Valores Singulares**, relacionando matrizes retangulares aos espectros de $\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A} \mathbf{A}^\top$ e conectando valores singulares, espaços fundamentais, posto e aproximações de baixa dimensão.

6 Decomposição em Valores Singulares

No capítulo anterior, a decomposição espectral foi utilizada para representar uma matriz simétrica real na forma

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Essa representação identifica uma base ortonormal de autovetores na qual a transformação atua separadamente sobre cada coordenada. A decomposição espectral ortogonal, entretanto, depende da simetria da matriz e é formulada para operadores cujo domínio e contradomínio possuem a mesma dimensão.

Em Análise Multivariada, um dos objetos mais frequentes é a matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

cujas linhas representam observações e colunas representam variáveis. Em geral,

$$n \neq p,$$

de modo que $\mathbf{X}$ é retangular. Mesmo quando uma matriz é quadrada, ela pode não ser simétrica nem possuir uma base ortonormal de autovetores.

A **Decomposição em Valores Singulares**, ou SVD, fornece uma representação aplicável a qualquer matriz real. Para uma transformação

$$T_\mathbf{A} : \mathbb{R}^p \longrightarrow \mathbb{R}^q, \quad T_\mathbf{A}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

a SVD relaciona duas bases ortonormais:

- uma base do espaço de origem $\mathbb{R}^p$;
- uma base do espaço de chegada $\mathbb{R}^q$.

A transformação associa determinadas direções dessas duas bases e multiplica os comprimentos por fatores não negativos denominados **valores singulares**.

Essa representação permite descrever:

- o posto da matriz;
- os espaços das linhas e das colunas;
- o núcleo e o núcleo da transposta;
- os fatores máximos e mínimos de alteração dos comprimentos;
- aproximações de posto reduzido;
- a pseudoinversa;
- soluções de mínimos quadrados.

A SVD também estabelece uma ligação entre os espaços das observações e das variáveis de uma matriz de dados. Essa dualidade será utilizada posteriormente na formulação de métodos de redução de dimensionalidade e de representação de estruturas matriciais.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{A} \in \mathbb{R}^{q \times p}$ representa uma matriz real e $T_{\mathbf{A}} : \mathbb{R}^p \rightarrow \mathbb{R}^q$ a transformação linear associada;
- $r = \text{posto}(\mathbf{A})$ representa o posto de $\mathbf{A}$;
- $d_1 \geq \dots \geq d_r > 0$ representam os valores singulares positivos de $\mathbf{A}$;
- $\mathbf{v}_j \in \mathbb{R}^p$ representa um vetor singular à direita;
- $\mathbf{u}_j \in \mathbb{R}^q$ representa um vetor singular à esquerda;
- $\mathbf{U}$, $\mathbf{D}$ e $\mathbf{V}$ representam os fatores da SVD completa;
- $\mathbf{U}_r$, $\mathbf{D}_r$ e $\mathbf{V}_r$ representam os fatores da SVD compacta;
- $\mathbf{U}_k$, $\mathbf{D}_k$ e $\mathbf{V}_k$ representam os fatores de uma SVD truncada;
- $\mathbf{A}^+$ representa a pseudoinversa de Moore–Penrose;
- $\|\mathbf{A}\|_2$ e $\|\mathbf{A}\|_F$ representam, respectivamente, as normas espectral e de Frobenius.

As convenções estabelecidas nos capítulos anteriores para núcleo, imagem, espaço coluna, espaço linha e bases ortonormais permanecem válidas.

6.1 Definição e formas da Decomposição em Valores Singulares

Considere uma matriz real

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

que representa uma transformação de $\mathbb{R}^p$ em $\mathbb{R}^q$.

A matriz pode ser retangular, quadrada, simétrica ou não simétrica. Nenhuma hipótese de invertibilidade ou de posto completo é necessária para a existência da SVD.

Teorema 6.1 (Existência da Decomposição em Valores Singulares). *Para toda matriz*

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

existem matrizes ortogonais

$$\mathbf{U} \in \mathbb{R}^{q \times q}$$

e

$$\mathbf{V} \in \mathbb{R}^{p \times p},$$

e uma matriz diagonal retangular

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

tais que

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

As matrizes ortogonais satisfazem

$$\mathbf{U}^\top \mathbf{U} = \mathbf{U}\mathbf{U}^\top = \mathbf{I}_q$$

e

$$\mathbf{V}^\top \mathbf{V} = \mathbf{V}\mathbf{V}^\top = \mathbf{I}_p.$$

Os elementos diagonais não negativos de $\mathbf{D}$ podem ser ordenados como

$$d_1 \geq d_2 \geq \dots \geq d_{\min(q,p)} \geq 0.$$

*Esses elementos são os **valores singulares** de $\mathbf{A}$. (Golub; Van Loan, 2013)*

A demonstração será apresentada posteriormente, após a construção da SVD a partir das decomposições espectrais de $\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A}\mathbf{A}^\top$.

Definição 6.1 (Matriz diagonal retangular). Seja

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

e defina

$$s = \min(q, p).$$

A matriz $\mathbf{D}$ é denominada **diagonal retangular** quando existem escalares

$$d_1, \dots, d_s$$

tais que

$$D_{ij} = \begin{cases} d_i, & i = j \leq s, \\ 0, & \text{caso contrário.} \end{cases}$$

Assim, apenas os elementos da diagonal principal podem ser diferentes de zero.

No bloco diagonal de ordem s , essa condição pode ser escrita de forma compacta utilizando a delta de Kronecker:

$$D_{ij} = d_i \delta_{ij}, \quad i, j = 1, \dots, s.$$

Se

$$q > p,$$

então $s = p$ e $\mathbf{D}$ possui $q - p$ linhas nulas abaixo de sua parte diagonal.

Se

$$p > q,$$

então $s = q$ e $\mathbf{D}$ possui $p - q$ colunas nulas à direita de sua parte diagonal.

Por exemplo, quando $q > p$,

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & d_p \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & 0 \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

Nesse caso, a parte diagonal possui $p = \min(q, p)$ elementos e as $q - p$ linhas restantes são nulas.

Quando $p > q$,

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & \cdots & 0 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & d_q & 0 & \cdots & 0 \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

Agora, a parte diagonal possui $q = \min(q, p)$ elementos e as $p - q$ colunas restantes são nulas.

Como

$$s = \min(q, p),$$

a matriz $\mathbf{D}$ possui s posições diagonais. Se

$$r = \text{posto}(\mathbf{A}),$$

então exatamente r valores singulares são positivos. Ordenando-os de forma decrescente,

$$d_1 \geq d_2 \geq \cdots \geq d_r > 0,$$

enquanto, quando $r < s$,

$$d_{r+1} = \cdots = d_s = 0.$$

Assim, o número de valores singulares positivos é exatamente o posto de $\mathbf{A}$ e, consequentemente, a dimensão da imagem da transformação linear associada:

$$r = \text{posto}(\mathbf{A}) = \dim(\text{Im}(T_{\mathbf{A}})).$$

6.1.1 Vetores singulares

Escreva as matrizes ortogonais como

$$\mathbf{U} = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_q]$$

e

$$\mathbf{V} = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_p].$$

Definição 6.2 (Valores e vetores singulares). Na decomposição

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

os elementos diagonais não negativos

$$d_1, \dots, d_{\min(q,p)}$$

de $\mathbf{D}$ são os **valores singulares** de $\mathbf{A}$.

As colunas

$$\mathbf{v}_1, \dots, \mathbf{v}_p$$

de $\mathbf{V}$ são os **vetores singulares à direita**. Elas formam uma base ortonormal de $\mathbb{R}^p$.

As colunas

$$\mathbf{u}_1, \dots, \mathbf{u}_q$$

de $\mathbf{U}$ são os **vetores singulares à esquerda**. Elas formam uma base ortonormal de $\mathbb{R}^q$.

Para cada valor singular positivo,

$$d_j > 0, \quad j = 1, \dots, r,$$

os vetores singulares correspondentes satisfazem

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$$

e

$$\mathbf{A}^\top \mathbf{u}_j = d_j \mathbf{v}_j.$$

A primeira igualdade mostra como a transformação associa uma direção no espaço de origem a uma direção no espaço de chegada:

$$\mathbf{v}_j \xrightarrow{\mathbf{A}} d_j \mathbf{u}_j.$$

Como

$$\|\mathbf{v}_j\| = \|\mathbf{u}_j\| = 1,$$

tem-se

$$\|\mathbf{A} \mathbf{v}_j\| = d_j.$$

Portanto, d_j mede o fator de alteração do comprimento na direção $\mathbf{v}_j$:

- se $d_j > 1$, ocorre ampliação;
- se $0 < d_j < 1$, ocorre contração;
- se $d_j = 1$, o comprimento é preservado;
- se $d_j = 0$, a direção correspondente é eliminada.

Os valores singulares são sempre não negativos. Diferentemente dos autovalores, eles não representam inversões de sentido. Possíveis mudanças de orientação ficam incorporadas às matrizes ortogonais $\mathbf{U}$ e $\mathbf{V}$.

As colunas de $\mathbf{V}$ correspondentes às colunas nulas de $\mathbf{D}$ são transformadas no vetor nulo. Elas pertencem ao núcleo de $\mathbf{A}$. De maneira análoga, colunas de $\mathbf{U}$ que correspondem às linhas nulas de $\mathbf{D}$ pertencem ao núcleo de $\mathbf{A}^\top$. Essas relações serão formalizadas na seção dedicada aos espaços fundamentais.

6.1.2 Interpretação como composição de transformações

Para qualquer

$$\mathbf{x} \in \mathbb{R}^p,$$

a ação de $\mathbf{A}$ pode ser escrita como

$$\mathbf{Ax} = \mathbf{UDV}^\top \mathbf{x}.$$

Essa transformação pode ser decomposta em três etapas:

$$\mathbf{x} \mapsto \mathbf{V}^\top \mathbf{x} \mapsto \mathbf{DV}^\top \mathbf{x} \mapsto \mathbf{UDV}^\top \mathbf{x}.$$

Na primeira etapa,

$$\mathbf{z} = \mathbf{V}^\top \mathbf{x}$$

fornece as coordenadas de $\mathbf{x}$ na base ortonormal dos vetores singulares à direita,

$$\mathcal{B}_V = \{\mathbf{v}_1, \dots, \mathbf{v}_p\}.$$

Assim,

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_V}.$$

Na segunda etapa,

$$\mathbf{Dz}$$

multiplica separadamente as coordenadas pelas entradas diagonais de $\mathbf{D}$. Como $\mathbf{D} \in \mathbb{R}^{q \times p}$ pode ser retangular, essa etapa também realiza a passagem entre as dimensões do domínio e do contradomínio.

Na terceira etapa, $\mathbf{U}$ reconstrói o resultado nas coordenadas canônicas de $\mathbb{R}^q$ a partir da base ortonormal

$$\mathcal{B}_U = \{\mathbf{u}_1, \dots, \mathbf{u}_q\}.$$

Como $\mathbf{U}$ e $\mathbf{V}$ são ortogonais, essas duas matrizes preservam normas, distâncias, ângulos e produtos internos. As alterações de comprimento e a possível redução de dimensão são determinadas por $\mathbf{D}$.

6.1.3 SVD completa

Definição 6.3 (SVD completa). A representação

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

com

$$\mathbf{U} \in \mathbb{R}^{q \times q}, \quad \mathbf{D} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{V} \in \mathbb{R}^{p \times p},$$

é denominada **SVD completa** de $\mathbf{A}$.

As dimensões e os papéis dos fatores são apresentados na Tabela 6.1.

Tabela 6.1: Dimensões das matrizes na SVD completa.

Matriz	Dimensão	Papel
$\mathbf{U}$	$q \times q$	Base ortonormal do espaço de chegada
$\mathbf{D}$	$q \times p$	Matriz diagonal retangular dos valores singulares
$\mathbf{V}$	$p \times p$	Base ortonormal do espaço de origem

A SVD completa descreve bases ortonormais de todo o espaço de origem e de todo o espaço de chegada. Por isso, ela contém também as direções associadas ao núcleo de $\mathbf{A}$ e ao núcleo de $\mathbf{A}^\top$.

6.1.4 SVD compacta

Quando

$$r = \text{posto}(\mathbf{A}),$$

defina

$$\mathbf{U}_r = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r] \in \mathbb{R}^{q \times r},$$

$$\mathbf{V}_r = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_r] \in \mathbb{R}^{p \times r}$$

e

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r) \in \mathbb{R}^{r \times r}.$$

Definição 6.4 (SVD compacta). A representação

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

formada somente pelos valores singulares positivos e por seus vetores singulares correspondentes, é denominada **SVD compacta** de $\mathbf{A}$.

A SVD compacta reconstrói exatamente a matriz original. Ela não é uma aproximação.

As colunas de $\mathbf{U}_r$ e de $\mathbf{V}_r$ são ortonormais:

$$\mathbf{U}_r^\top \mathbf{U}_r = \mathbf{I}_r$$

e

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r.$$

Quando $r < q$, tem-se

$$\mathbf{U}_r \mathbf{U}_r^\top \neq \mathbf{I}_q.$$

Quando $r < p$,

$$\mathbf{V}_r \mathbf{V}_r^\top \neq \mathbf{I}_p.$$

Esses produtos são projetores ortogonais sobre os subespaços gerados pelas colunas das matrizes correspondentes. Sua interpretação será retomada na seção sobre os espaços fundamentais.

As dimensões da SVD compacta são apresentadas na Tabela 6.2.

Tabela 6.2: Dimensões das matrizes na SVD compacta.

Matriz	Dimensão	Conteúdo
$\mathbf{U}_r$	$q \times r$	Vetores singulares à esquerda associados aos valores positivos
$\mathbf{D}_r$	$r \times r$	Valores singulares positivos
$\mathbf{V}_r$	$p \times r$	Vetores singulares à direita associados aos valores positivos

A forma compacta contém toda a informação necessária para reconstruir $\mathbf{A}$ e utiliza somente as direções que participam efetivamente da transformação. A forma completa acrescenta bases ortonormais para os complementos dessas direções.

6.1.5 SVD compacta e SVD truncada

A **SVD compacta** e a **SVD truncada** representam objetos diferentes.

A SVD compacta conserva todos os r valores singulares positivos e fornece a representação exata

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

A SVD truncada conserva apenas parte desses componentes singulares.

Para

$$1 \leq k < r,$$

defina

$$\mathbf{U}_k = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_k] \in \mathbb{R}^{q \times k},$$

$$\mathbf{D}_k = \text{diag}(d_1, \dots, d_k) \in \mathbb{R}^{k \times k}$$

e

$$\mathbf{V}_k = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_k] \in \mathbb{R}^{p \times k}.$$

Definição 6.5 (SVD truncada). Seja

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

a SVD compacta de uma matriz de posto r .

Para

$$1 \leq k < r,$$

a matriz

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top$$

é denominada **SVD truncada de posto k** de $\mathbf{A}$.

Como $k < r$, a SVD truncada descarta componentes associados a valores singulares positivos. Portanto, em geral,

$$\mathbf{A}_k \neq \mathbf{A}.$$

A matriz $\mathbf{A}_k$ possui posto k e constitui uma aproximação de $\mathbf{A}$. As propriedades de otimalidade dessa aproximação e os erros decorrentes do truncamento serão estudados posteriormente.

A terminologia empregada para as diferentes formas da SVD não é uniforme na literatura. Dependendo da referência, aparecem expressões como **SVD reduzida**, **SVD fina** (*thin SVD*), **SVD econômica** (*economy-sized SVD*) e **SVD compacta**, nem sempre com exatamente o mesmo significado (Demmel, 2000; Driscoll; Braun, 2022; Sidi, 2017).

Para evitar ambiguidades, neste capítulo serão utilizadas as seguintes convenções:

- **SVD completa**, para a representação que utiliza bases ortonormais completas dos espaços de origem e de chegada;
- **SVD compacta**, para a representação exata que conserva somente os $r = \text{posto}(\mathbf{A})$ valores singulares positivos e os vetores singulares correspondentes;
- **SVD truncada**, para a aproximação que conserva apenas os $k < r$ maiores valores singulares.

Exemplo 6.1 (SVD completa, compacta e truncada de uma matriz retangular). Considere a matriz

$$\mathbf{A} = \begin{bmatrix} 2 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 2 \\ 2 & 0 & 1 \\ 1 & 1 & 1 \end{bmatrix} \in \mathbb{R}^{5 \times 3}.$$

A matriz possui posto

$$r = 3$$

e seus valores singulares, em ordem decrescente, são aproximadamente

$$d_1 = 4.1780, \quad d_2 = 2.1600, \quad d_3 = 1.3706.$$

Os valores apresentados a seguir estão arredondados a quatro casas decimais. Por esse motivo, as decomposições numéricas devem ser interpretadas a menos de arredondamento.

SVD completa

Uma SVD completa de $\mathbf{A}$ é

$$\mathbf{A} \approx \mathbf{U} \mathbf{D} \mathbf{V}^\top,$$

em que

$$\mathbf{U} \approx \begin{bmatrix} 0.4449 & 0.5397 & 0.3147 & -0.6014 & -0.2239 \\ 0.5461 & -0.2239 & 0.5466 & 0.5614 & -0.1943 \\ 0.3803 & -0.6954 & -0.3419 & -0.4142 & -0.2887 \\ 0.4348 & 0.4111 & -0.6965 & 0.3743 & -0.1295 \\ 0.4126 & -0.0779 & -0.0136 & -0.1073 & 0.9011 \end{bmatrix} \in \mathbb{R}^{5 \times 5},$$

$$\mathbf{D} \approx \begin{bmatrix} 4.1780 & 0 & 0 \\ 0 & 2.1600 & 0 \\ 0 & 0 & 1.3706 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \in \mathbb{R}^{5 \times 3},$$

e

$$\mathbf{V} \approx \begin{bmatrix} 0.6506 & 0.7406 & -0.1682 \\ 0.5576 & -0.3155 & 0.7678 \\ 0.5156 & -0.5933 & -0.6182 \end{bmatrix} \in \mathbb{R}^{3 \times 3}.$$

As colunas de $\mathbf{U}$ são os vetores singulares à esquerda,

$$\mathbf{u}_1, \dots, \mathbf{u}_5,$$

e as colunas de $\mathbf{V}$ são os vetores singulares à direita,

$$\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3.$$

Os três primeiros pares de vetores singulares estão associados aos três valores singulares positivos:

$$(\mathbf{u}_1, \mathbf{v}_1) \leftrightarrow d_1 = 4.1780,$$

$$(\mathbf{u}_2, \mathbf{v}_2) \leftrightarrow d_2 = 2.1600,$$

e

$$(\mathbf{u}_3, \mathbf{v}_3) \leftrightarrow d_3 = 1.3706.$$

As duas últimas colunas de $\mathbf{U}$ completam uma base ortonormal de $\mathbb{R}^5$. Elas correspondem às duas linhas nulas de $\mathbf{D}$.

SVD compacta

Como

$$r = \text{posto}(\mathbf{A}) = 3,$$

a SVD compacta conserva somente os três valores singulares positivos e os vetores singulares correspondentes:

$$\mathbf{A} \approx \mathbf{U}_3 \mathbf{D}_3 \mathbf{V}_3^\top,$$

com

$$\mathbf{U}_3 \approx \begin{bmatrix} 0.4449 & 0.5397 & 0.3147 \\ 0.5461 & -0.2239 & 0.5466 \\ 0.3803 & -0.6954 & -0.3419 \\ 0.4348 & 0.4111 & -0.6965 \\ 0.4126 & -0.0779 & -0.0136 \end{bmatrix} \in \mathbb{R}^{5 \times 3},$$

$$\mathbf{D}_3 \approx \begin{bmatrix} 4.1780 & 0 & 0 \\ 0 & 2.1600 & 0 \\ 0 & 0 & 1.3706 \end{bmatrix} \in \mathbb{R}^{3 \times 3},$$

e

$$\mathbf{V}_3 = \mathbf{V} \approx \begin{bmatrix} 0.6506 & 0.7406 & -0.1682 \\ 0.5576 & -0.3155 & 0.7678 \\ 0.5156 & -0.5933 & -0.6182 \end{bmatrix} \in \mathbb{R}^{3 \times 3}.$$

A representação continua sendo exata antes do arredondamento numérico. A SVD compacta elimina apenas as duas colunas adicionais de $\mathbf{U}$ e as duas linhas nulas correspondentes de $\mathbf{D}$.

Como

$$r = p = 3,$$

todos os vetores singulares à direita participam da SVD compacta. Por isso,

$$\mathbf{V}_3 = \mathbf{V}.$$

SVD truncada de posto 2

Considere agora a conservação apenas dos dois maiores valores singulares,

$$d_1 = 4.1780 \quad \text{e} \quad d_2 = 2.1600.$$

A SVD truncada de posto 2 utiliza

$$\mathbf{U}_2 \approx \begin{bmatrix} 0.4449 & 0.5397 \\ 0.5461 & -0.2239 \\ 0.3803 & -0.6954 \\ 0.4348 & 0.4111 \\ 0.4126 & -0.0779 \end{bmatrix} \in \mathbb{R}^{5 \times 2},$$

$$\mathbf{D}_2 \approx \begin{bmatrix} 4.1780 & 0 \\ 0 & 2.1600 \end{bmatrix} \in \mathbb{R}^{2 \times 2},$$

e

$$\mathbf{V}_2 \approx \begin{bmatrix} 0.6506 & 0.7406 \\ 0.5576 & -0.3155 \\ 0.5156 & -0.5933 \end{bmatrix} \in \mathbb{R}^{3 \times 2}.$$

Assim,

$$\mathbf{A}_2 = \mathbf{U}_2 \mathbf{D}_2 \mathbf{V}_2^\top$$

é uma aproximação de posto 2 da matriz original. Numericamente,

$$\mathbf{A}_2 \approx \begin{bmatrix} 2.0726 & 0.6688 & 0.2667 \\ 1.1260 & 1.4248 & 1.4631 \\ -0.0788 & 1.3598 & 1.7103 \\ 1.8394 & 0.7330 & 0.4098 \\ 0.9969 & 1.0143 & 0.9885 \end{bmatrix}.$$

Como o terceiro valor singular positivo foi descartado,

$$\mathbf{A}_2 \neq \mathbf{A}.$$

As três formas podem ser comparadas pelas dimensões de seus fatores:

Forma	Matriz à esquerda	Matriz diagonal	Matriz à direita	Valores singulares mantidos	Resultado
SVD completa	$\mathbf{U} : 5 \times 5$	$\mathbf{D} : 5 \times 3$	$\mathbf{V} : 3 \times 3$	d_1, d_2, d_3	Exato
SVD compacta	$\mathbf{U}_3 : 5 \times 3$	$\mathbf{D}_3 : 3 \times 3$	$\mathbf{V}_3 : 3 \times 3$	d_1, d_2, d_3	Exato

Forma	Matriz à esquerda	Matriz diagonal	Matriz à direita	Valores singulares mantidos	Resultado
SVD truncada	$\mathbf{U}_2 : 5 \times 2$	$\mathbf{D}_2 : 2 \times 2$	$\mathbf{V}_2 : 3 \times 2$	d_1, d_2	Aproximado

A SVD completa apresenta bases ortonormais completas dos espaços de origem e de chegada. A SVD compacta mantém somente as direções associadas aos valores singulares positivos, sem perder informação necessária à reconstrução de $\mathbf{A}$. A SVD truncada conserva apenas parte dessas direções e, por isso, produz uma aproximação de posto menor.

6.1.6 Aprofundamento: não unicidade dos vetores singulares

Leitura de aprofundamento

Esta seção examina a não unicidade dos vetores singulares. Embora os valores singulares sejam determinados pela matriz, os vetores singulares associados podem admitir diferentes representações.

Serão considerados três casos: a mudança simultânea de sinal de pares de vetores singulares, a liberdade de escolha de bases ortonormais quando um valor singular positivo possui multiplicidade maior que um e a escolha das bases associadas ao valor singular zero.

Os valores singulares de uma matriz são determinados de maneira única quando apresentados em ordem decrescente e consideradas suas multiplicidades. Os vetores singulares, entretanto, podem não ser únicos.

Para cada par associado a um valor singular positivo, a substituição simultânea

$$\mathbf{u}_j \mapsto -\mathbf{u}_j$$

e

$$\mathbf{v}_j \mapsto -\mathbf{v}_j$$

não altera a parcela

$$d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

pois

$$d_j (-\mathbf{u}_j) (-\mathbf{v}_j)^\top = d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Assim, cada par singular associado a um valor positivo é determinado apenas a menos de uma mudança simultânea de sinal.

Considere agora um valor singular positivo d com multiplicidade m . Se

$$\mathbf{U}_d \in \mathbb{R}^{q \times m}$$

e

$$\mathbf{V}_d \in \mathbb{R}^{p \times m}$$

contêm bases ortonormais dos subespaços singulares correspondentes, a contribuição desse valor é

$$d \mathbf{U}_d \mathbf{V}_d^\top.$$

Para qualquer matriz ortogonal

$$\mathbf{R} \in \mathbb{R}^{m \times m},$$

tem-se

$$\begin{aligned} d (\mathbf{U}_d \mathbf{R}) (\mathbf{V}_d \mathbf{R})^\top &= d \mathbf{U}_d \mathbf{R} \mathbf{R}^\top \mathbf{V}_d^\top \\ &= d \mathbf{U}_d \mathbf{V}_d^\top. \end{aligned}$$

Portanto, valores singulares positivos repetidos permitem rotações ortogonais simultâneas das bases à esquerda e à direita.

A situação é diferente nos subespaços associados ao valor singular zero. As colunas de $\mathbf{V}_0$ formam uma base de

$$\mathcal{N}(\mathbf{A}),$$

enquanto as colunas de $\mathbf{U}_0$ formam uma base de

$$\mathcal{N}(\mathbf{A}^\top).$$

Essas bases completam espaços diferentes e podem ser escolhidas independentemente, pois suas parcelas são multiplicadas por zero na SVD completa.

Portanto:

- os valores singulares são propriedades da matriz;
- os subespaços singulares associados aos valores positivos são propriedades da matriz;
- os núcleos de $\mathbf{A}$ e de $\mathbf{A}^\top$ são propriedades da matriz;
- sinais e bases ortonormais específicas dentro desses subespaços dependem da representação escolhida.

A existência da SVD e as relações entre os dois conjuntos de vetores singulares decorrem das decomposições espectrais das matrizes simétricas

$$\mathbf{A}^\top \mathbf{A} \quad \text{e} \quad \mathbf{A} \mathbf{A}^\top.$$

A próxima seção constrói essa relação e demonstra por que os quadrados dos valores singulares aparecem como autovalores dessas duas matrizes.

6.2 Construção da SVD e relação com a decomposição espectral

A existência da SVD decorre das propriedades das duas matrizes de Gram associadas a $\mathbf{A}$:

$$\mathbf{A}^\top \mathbf{A} \quad \text{e} \quad \mathbf{A} \mathbf{A}^\top.$$

Essas matrizes já apareceram no estudo dos espaços das variáveis e das observações. A SVD mostra agora que seus espectros estão diretamente relacionados e que essa relação permite construir bases ortonormais adaptadas à transformação

$$T_{\mathbf{A}} : \mathbb{R}^p \rightarrow \mathbb{R}^q.$$

Para

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

tem-se

$$\mathbf{A}^\top \mathbf{A} \in \mathbb{R}^{p \times p}$$

e

$$\mathbf{A}\mathbf{A}^\top \in \mathbb{R}^{q \times q}.$$

Mesmo que $\mathbf{A}$ seja retangular ou não simétrica, essas duas matrizes são quadradas, simétricas e semidefinidas positivas.

6.2.1 Propriedades das matrizes de Gram associadas

As matrizes

$$\mathbf{A}^\top \mathbf{A}$$

e

$$\mathbf{A}\mathbf{A}^\top$$

são matrizes de Gram associadas, respectivamente, às colunas e às linhas de $\mathbf{A}$.

Pela Proposição 3.9, ambas são simétricas e semidefinidas positivas. Portanto,

$$\mathbf{A}^\top \mathbf{A} \succeq \mathbf{0}$$

e

$$\mathbf{A}\mathbf{A}^\top \succeq \mathbf{0}.$$

Além disso,

$$\text{posto}(\mathbf{A}^\top \mathbf{A}) = \text{posto}(\mathbf{A})$$

e

$$\text{posto}(\mathbf{A}\mathbf{A}^\top) = \text{posto}(\mathbf{A}).$$

Assim, se

$$r = \text{posto}(\mathbf{A}),$$

cada uma dessas matrizes possui exatamente r autovalores positivos, considerando suas multiplicidades.

Como ambas são simétricas, o Teorema 5.4 garante a existência de bases ortonormais de autovetores. Como também são semidefinidas positivas, todos os seus autovalores são não negativos.

Proposição 6.1 (Espectros das matrizes de Gram associadas). *Seja*

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com posto

$$r = \text{posto}(\mathbf{A}).$$

Então:

1. *as matrizes*

$$\mathbf{A}^\top \mathbf{A}$$

e

$$\mathbf{A} \mathbf{A}^\top$$

possuem os mesmos r autovalores positivos, incluindo suas multiplicidades;

2. *se esses autovalores são ordenados como*

$$\lambda_1 \geq \dots \geq \lambda_r > 0,$$

podem-se definir

$$d_j = \sqrt{\lambda_j}, \quad j = 1, \dots, r;$$

3. os núcleos satisfazem

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) = \mathcal{N}(\mathbf{A})$$

e

$$\mathcal{N}(\mathbf{A}\mathbf{A}^\top) = \mathcal{N}(\mathbf{A}^\top).$$

(Golub; Van Loan, 2013)

Comprovação. Considere inicialmente

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}).$$

Então,

$$\mathbf{A}\mathbf{x} = \mathbf{0},$$

e, conseqüentemente,

$$\mathbf{A}^\top \mathbf{A}\mathbf{x} = \mathbf{0}.$$

Logo,

$$\mathcal{N}(\mathbf{A}) \subseteq \mathcal{N}(\mathbf{A}^\top \mathbf{A}).$$

Reciprocamente, se

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}^\top \mathbf{A}),$$

então

$$\mathbf{A}^\top \mathbf{A}\mathbf{x} = \mathbf{0}.$$

Multiplicando à esquerda por $\mathbf{x}^\top$,

$$\begin{aligned} 0 &= \mathbf{x}^\top \mathbf{A}^\top \mathbf{A}\mathbf{x} \\ &= \|\mathbf{A}\mathbf{x}\|^2. \end{aligned}$$

Portanto,

$$\mathbf{A}\mathbf{x} = \mathbf{0},$$

e

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) \subseteq \mathcal{N}(\mathbf{A}).$$

Assim,

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) = \mathcal{N}(\mathbf{A}).$$

O mesmo argumento, aplicado a $\mathbf{A}^\top$, fornece

$$\mathcal{N}(\mathbf{A}\mathbf{A}^\top) = \mathcal{N}(\mathbf{A}^\top).$$

Considere agora um autovalor positivo λ de

$$\mathbf{A}^\top \mathbf{A}$$

e um autovetor unitário $\mathbf{v}$ associado:

$$\mathbf{A}^\top \mathbf{A}\mathbf{v} = \lambda \mathbf{v}.$$

Como $\lambda > 0$, defina

$$\mathbf{u} = \frac{\mathbf{A}\mathbf{v}}{\sqrt{\lambda}}.$$

Esse vetor possui norma unitária, pois

$$\begin{aligned}\mathbf{u}^\top \mathbf{u} &= \frac{\mathbf{v}^\top \mathbf{A}^\top \mathbf{A}\mathbf{v}}{\lambda} \\ &= \frac{\lambda \mathbf{v}^\top \mathbf{v}}{\lambda} \\ &= 1.\end{aligned}$$

Além disso,

$$\begin{aligned}
\mathbf{A}\mathbf{A}^\top \mathbf{u} &= \frac{\mathbf{A}\mathbf{A}^\top \mathbf{A}\mathbf{v}}{\sqrt{\lambda}} \\
&= \frac{\mathbf{A}(\mathbf{A}^\top \mathbf{A}\mathbf{v})}{\sqrt{\lambda}} \\
&= \frac{\mathbf{A}(\lambda \mathbf{v})}{\sqrt{\lambda}} \\
&= \lambda \mathbf{u}.
\end{aligned}$$

Portanto, todo autovalor positivo de

$$\mathbf{A}^\top \mathbf{A}$$

também é autovalor de

$$\mathbf{A}\mathbf{A}^\top.$$

O argumento inverso é obtido começando por um autovetor de

$$\mathbf{A}\mathbf{A}^\top$$

e definindo

$$\mathbf{v} = \frac{\mathbf{A}^\top \mathbf{u}}{\sqrt{\lambda}}.$$

Para $\lambda > 0$, as aplicações

$$\mathbf{v} \mapsto \frac{\mathbf{A}\mathbf{v}}{\sqrt{\lambda}}$$

e

$$\mathbf{u} \mapsto \frac{\mathbf{A}^\top \mathbf{u}}{\sqrt{\lambda}}$$

estabelecem aplicações lineares inversas entre o autoespaço de $\mathbf{A}^\top \mathbf{A}$ associado a λ e o autoespaço de $\mathbf{A}\mathbf{A}^\top$ associado ao mesmo autovalor. Portanto, esses autoespaços possuem a mesma dimensão e as multiplicidades dos autovalores positivos coincidem.

Como

$$\text{posto}(\mathbf{A}^\top \mathbf{A}) = \text{posto}(\mathbf{A}) = r,$$

existem exatamente r autovalores positivos. O mesmo ocorre para

$$\mathbf{A}\mathbf{A}^\top.$$

Definindo

$$d_j = \sqrt{\lambda_j}, \quad j = 1, \dots, r,$$

obtêm-se r números positivos associados aos autovalores positivos comuns às duas matrizes de Gram. A construção a seguir mostrará que esses números são precisamente os valores singulares positivos de $\mathbf{A}$. $\square$

As duas matrizes podem possuir quantidades diferentes de autovalores nulos. A matriz

$$\mathbf{A}^\top \mathbf{A}$$

tem ordem p , enquanto

$$\mathbf{A}\mathbf{A}^\top$$

tem ordem q . Entretanto, seus espectros positivos coincidem.

6.2.2 Construção dos pares singulares

Suponha inicialmente que

$$\mathbf{A} \neq \mathbf{0}.$$

Então,

$$r = \text{posto}(\mathbf{A}) \geq 1.$$

O caso

$$\mathbf{A} = \mathbf{0}$$

será tratado diretamente na demonstração do Teorema 6.1.

A construção começa pela matriz

$$\mathbf{A}^\top \mathbf{A},$$

que atua em

$$\mathbb{R}^p,$$

o domínio da transformação

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Seus autovetores associados aos autovalores positivos determinarão os **vetores singulares à direita**. A aplicação de $\mathbf{A}$ a essas direções, seguida de normalização, produzirá os **vetores singulares à esquerda** em $\mathbb{R}^q$.

Considere a decomposição espectral

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V} \Lambda_V \mathbf{V}^\top,$$

em que

$$\mathbf{V} = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_p]$$

é ortogonal.

Ordene os autovalores de modo que

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_r > 0$$

e

$$\lambda_{r+1} = \cdots = \lambda_p = 0.$$

Defina

$$d_j = \sqrt{\lambda_j}, \quad j = 1, \dots, r.$$

Particione a matriz de autovetores como

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0],$$

em que

$$\mathbf{V}_r = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_r]$$

contém os autovetores associados aos autovalores positivos e

$$\mathbf{V}_0 = [\mathbf{v}_{r+1} \quad \cdots \quad \mathbf{v}_p]$$

contém os autovetores associados ao autovalor zero.

Pela Proposição 6.1,

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) = \mathcal{N}(\mathbf{A}).$$

Portanto, as colunas de $\mathbf{V}_0$ formam uma base ortonormal de

$$\mathcal{N}(\mathbf{A}),$$

enquanto as colunas de $\mathbf{V}_r$ formam uma base ortonormal de

$$\mathcal{N}(\mathbf{A})^\perp = \mathcal{C}(\mathbf{A}^\top).$$

Proposição 6.2 (Construção dos pares singulares positivos). *Para cada*

$$j = 1, \dots, r,$$

defina

$$\mathbf{u}_j = \frac{\mathbf{A}\mathbf{v}_j}{d_j}.$$

Então:

1. os vetores

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

são ortonormais;

2. para cada $j = 1, \dots, r$,

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$$

e

$$\mathbf{A}^\top \mathbf{u}_j = d_j \mathbf{v}_j;$$

3. os vetores

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

formam uma base ortonormal de

$$\mathcal{C}(\mathbf{A}).$$

Comprovação. Para $i, j \leq r$,

$$\begin{aligned}\mathbf{u}_i^\top \mathbf{u}_j &= \frac{\mathbf{v}_i^\top \mathbf{A}^\top \mathbf{A} \mathbf{v}_j}{d_i d_j} \\ &= \frac{d_j^2 \mathbf{v}_i^\top \mathbf{v}_j}{d_i d_j} \\ &= \frac{d_j}{d_i} \mathbf{v}_i^\top \mathbf{v}_j.\end{aligned}$$

Como os vetores

$$\mathbf{v}_1, \dots, \mathbf{v}_r$$

são ortonormais,

$$\mathbf{v}_i^\top \mathbf{v}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Logo,

$$\mathbf{u}_i^\top \mathbf{u}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Portanto,

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

são ortonormais.

Pela definição de $\mathbf{u}_j$,

$$\mathbf{A}\mathbf{v}_j = d_j \mathbf{u}_j.$$

Além disso,

$$\begin{aligned} \mathbf{A}^\top \mathbf{u}_j &= \frac{\mathbf{A}^\top \mathbf{A} \mathbf{v}_j}{d_j} \\ &= \frac{d_j^2 \mathbf{v}_j}{d_j} \\ &= d_j \mathbf{v}_j. \end{aligned}$$

Cada $\mathbf{u}_j$ pertence a

$$\mathcal{C}(\mathbf{A}),$$

pois

$$\mathbf{u}_j = \frac{1}{d_j} \mathbf{A} \mathbf{v}_j.$$

Como existem

$$r = \text{posto}(\mathbf{A}) = \dim \mathcal{C}(\mathbf{A})$$

vetores ortonormais desse tipo, eles formam uma base ortonormal de

$$\mathcal{C}(\mathbf{A}).$$

□

A construção estabelece uma correspondência entre duas direções ortonormais:

$$\mathbf{v}_j \in \mathcal{C}(\mathbf{A}^\top) \subseteq \mathbb{R}^p \xrightarrow{\mathbf{A}} d_j \mathbf{u}_j \in \mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q,$$

e

$$\mathbf{u}_j \in \mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q \xrightarrow{\mathbf{A}^\top} d_j \mathbf{v}_j \in \mathcal{C}(\mathbf{A}^\top) \subseteq \mathbb{R}^p.$$

Assim, $\mathbf{v}_j$ é uma direção singular à direita, $\mathbf{u}_j$ é a direção singular à esquerda correspondente e d_j é o fator de escalonamento que relaciona as duas.

6.2.3 Construção da SVD compacta

Reúna os vetores singulares à esquerda em

$$\mathbf{U}_r = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r]$$

e defina

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r).$$

As relações

$$\mathbf{A} \mathbf{v}_j = d_j \mathbf{u}_j, \quad j = 1, \dots, r,$$

podem ser escritas simultaneamente como

$$\mathbf{A} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r.$$

Proposição 6.3 (SVD compacta obtida dos pares singulares). *Com as matrizes $\mathbf{U}_r$, $\mathbf{D}_r$ e $\mathbf{V}_r$ definidas anteriormente,*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

Portanto,

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de $\mathbf{A}$, e

$$d_1, \dots, d_r$$

são seus valores singulares positivos.

Comprovação. Como

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0]$$

é ortogonal,

$$\mathbf{I}_p = \mathbf{V}_r \mathbf{V}_r^\top + \mathbf{V}_0 \mathbf{V}_0^\top.$$

As colunas de $\mathbf{V}_0$ pertencem a

$$\mathcal{N}(\mathbf{A}),$$

de modo que

$$\mathbf{A} \mathbf{V}_0 = \mathbf{0}.$$

Assim,

$$\begin{aligned} \mathbf{A} &= \mathbf{A} \mathbf{I}_p \\ &= \mathbf{A} (\mathbf{V}_r \mathbf{V}_r^\top + \mathbf{V}_0 \mathbf{V}_0^\top) \\ &= \mathbf{A} \mathbf{V}_r \mathbf{V}_r^\top \\ &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top. \end{aligned}$$

□

A SVD compacta utiliza exatamente as direções que participam da transformação:

- as colunas de $\mathbf{V}_r$ formam uma base ortonormal de $\mathcal{C}(\mathbf{A}^\top)$;
- $\mathbf{D}_r$ contém os fatores de escalonamento positivos;
- as colunas de $\mathbf{U}_r$ formam uma base ortonormal de $\mathcal{C}(\mathbf{A})$.

A construção anterior permite concluir a demonstração do Teorema 6.1.

Comprovação. Se

$$\mathbf{A} = \mathbf{0},$$

tome

$$\mathbf{U} = \mathbf{I}_q, \quad \mathbf{V} = \mathbf{I}_p$$

e

$$\mathbf{D} = \mathbf{0}_{q \times p}.$$

Então,

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

Suponha agora que

$$\mathbf{A} \neq \mathbf{0}.$$

Pela Proposição 6.3,

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

As colunas de $\mathbf{U}_r$ formam uma base ortonormal de

$$\mathcal{C}(\mathbf{A}) = \mathcal{N}(\mathbf{A}^\top)^\perp.$$

Complete esse conjunto com uma base ortonormal

$$\mathbf{u}_{r+1}, \dots, \mathbf{u}_q$$

de

$$\mathcal{N}(\mathbf{A}^\top).$$

Defina

$$\mathbf{U} = [\mathbf{U}_r \quad \mathbf{U}_0] \in \mathbb{R}^{q \times q},$$

em que

$$\mathbf{U}_0 = [\mathbf{u}_{r+1} \quad \cdots \quad \mathbf{u}_q].$$

A matriz $\mathbf{U}$ é ortogonal.

A matriz

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0] \in \mathbb{R}^{p \times p}$$

já foi obtida da decomposição espectral de

$$\mathbf{A}^\top \mathbf{A}$$

e também é ortogonal.

Defina

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

como a matriz diagonal retangular cujos primeiros r elementos diagonais são

$$d_1, \dots, d_r$$

e cujos demais elementos são nulos.

Como

$$\mathbf{A}\mathbf{V}_r = \mathbf{U}_r\mathbf{D}_r$$

e

$$\mathbf{A}\mathbf{V}_0 = \mathbf{0},$$

tem-se

$$\mathbf{A}\mathbf{V} = \mathbf{U}\mathbf{D}.$$

Multiplicando à direita por $\mathbf{V}^\top$,

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

Isso demonstra a existência da SVD completa. □

6.2.4 Decomposições espectrais associadas

Proposição 6.4 (Decomposições espectrais induzidas pela SVD). *Se*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

então

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top$$

e

$$\mathbf{A}\mathbf{A}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

Comprovação. Utilizando a SVD compacta,

$$\begin{aligned} \mathbf{A}^\top \mathbf{A} &= (\mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top)^\top (\mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top) \\ &= \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top. \end{aligned}$$

Como as colunas de $\mathbf{U}_r$ são ortonormais,

$$\mathbf{U}_r^\top \mathbf{U}_r = \mathbf{I}_r.$$

Portanto,

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top.$$

Analogamente,

$$\begin{aligned}\mathbf{A}\mathbf{A}^\top &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \\ &= \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top,\end{aligned}$$

pois

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r.$$

□

Na forma completa, as decomposições são

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V} \operatorname{diag} \left(d_1^2, \dots, d_r^2, \underbrace{0, \dots, 0}_{p-r} \right) \mathbf{V}^\top$$

e

$$\mathbf{A}\mathbf{A}^\top = \mathbf{U} \operatorname{diag} \left(d_1^2, \dots, d_r^2, \underbrace{0, \dots, 0}_{q-r} \right) \mathbf{U}^\top.$$

Essas expressões deixam explícito que:

- $\mathbf{A}^\top \mathbf{A}$ possui $p - r$ autovalores nulos;
- $\mathbf{A}\mathbf{A}^\top$ possui $q - r$ autovalores nulos;
- as duas matrizes possuem os mesmos r autovalores positivos.

Para cada $j = 1, \dots, r$,

$$\mathbf{A}^\top \mathbf{A} \mathbf{v}_j = d_j^2 \mathbf{v}_j$$

e

$$\mathbf{A}\mathbf{A}^\top \mathbf{u}_j = d_j^2 \mathbf{u}_j.$$

Assim, os valores singulares podem ser obtidos por

$$d_j = \sqrt{\lambda_j},$$

em que λ_j é um autovalor positivo de qualquer uma das duas matrizes de Gram.

As duas decomposições também identificam os espaços aos quais pertencem os vetores singulares:

$$\mathbf{v}_j \in \mathcal{C}(\mathbf{A}^\top) \subseteq \mathbb{R}^p$$

e

$$\mathbf{u}_j \in \mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q.$$

Portanto, $\mathbf{A}^\top \mathbf{A}$ descreve a estrutura espectral relevante no domínio, enquanto $\mathbf{A} \mathbf{A}^\top$ descreve a estrutura correspondente no contradomínio. Os valores singulares positivos realizam a ligação entre esses dois espaços.

6.2.5 Exemplo de construção da SVD

Exemplo 6.2 (Construção da SVD de uma matriz retangular). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

A matriz possui dimensão 3×2 . Inicialmente,

$$\begin{aligned} \mathbf{A}^\top \mathbf{A} &= \begin{bmatrix} 1 & 1 & 1 \\ 1 & -1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}. \end{aligned}$$

Essa é a mesma matriz utilizada como exemplo condutor no capítulo anterior. Seus autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Os valores singulares são as raízes quadradas não negativas:

$$d_1 = 2 \quad \text{e} \quad d_2 = \sqrt{2}.$$

Autovetores unitários associados são

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Portanto,

$$\mathbf{V}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

O primeiro vetor singular à esquerda é

$$\begin{aligned} \mathbf{u}_1 &= \frac{\mathbf{A}\mathbf{v}_1}{d_1} \\ &= \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ &= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}. \end{aligned}$$

O segundo é

$$\begin{aligned} \mathbf{u}_2 &= \frac{\mathbf{A}\mathbf{v}_2}{d_2} \\ &= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\ &= \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}. \end{aligned}$$

Logo,

$$\mathbf{U}_2 = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 0 & 1 \\ 1/\sqrt{2} & 0 \end{bmatrix}$$

e

$$\mathbf{D}_2 = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix}.$$

A SVD compacta é

$$\mathbf{A} = \mathbf{U}_2 \mathbf{D}_2 \mathbf{V}_2^\top.$$

Como os dois valores singulares são positivos,

$$\text{posto}(\mathbf{A}) = 2.$$

Para construir a SVD completa, é necessário completar as colunas de $\mathbf{U}_2$ com um vetor unitário ortogonal a $\mathbf{u}_1$ e $\mathbf{u}_2$. Pode-se escolher

$$\mathbf{u}_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}.$$

Assim,

$$\mathbf{U} = \begin{bmatrix} 1/\sqrt{2} & 0 & 1/\sqrt{2} \\ 0 & 1 & 0 \\ 1/\sqrt{2} & 0 & -1/\sqrt{2} \end{bmatrix}$$

e

$$\mathbf{D} = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix}.$$

Como $\mathbf{V}_2$ já é uma matriz 2×2 ortogonal,

$$\mathbf{V} = \mathbf{V}_2.$$

A SVD completa é

$$\mathbf{A} = \mathbf{U} \mathbf{D} \mathbf{V}^\top.$$

Por outro lado,

$$\mathbf{A}\mathbf{A}^\top = \begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & 0 \\ 2 & 0 & 2 \end{bmatrix}.$$

Seus autovalores são

$$4, \quad 2, \quad 0,$$

com autovetores unitários

$$\mathbf{u}_1, \quad \mathbf{u}_2, \quad \mathbf{u}_3,$$

respectivamente.

O exemplo mostra que:

- $\mathbf{A}^\top \mathbf{A}$ determina as direções singulares no espaço de origem $\mathbb{R}^2$;
- $\mathbf{A}\mathbf{A}^\top$ determina as direções singulares no espaço de chegada $\mathbb{R}^3$;
- os dois espaços são relacionados pelos mesmos valores singulares positivos.

6.2.6 Relação com a decomposição espectral de matrizes simétricas

Se $\mathbf{A}$ é quadrada e simétrica, sua decomposição espectral é

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Quando

$$\mathbf{A} \succeq 0,$$

todos os autovalores são não negativos. Nesse caso, pode-se escolher uma SVD na qual, após ordenar os autovalores,

$$\mathbf{U} = \mathbf{V} = \mathbf{Q}_\mathbf{A}$$

e

$$\mathbf{D} = \Lambda_\mathbf{A}.$$

Portanto, a SVD coincide com a decomposição espectral:

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

6.2.7 Aprofundamento: SVD de matrizes simétricas indefinidas

Leitura de aprofundamento

Esta seção examina a relação entre a decomposição espectral e a SVD quando uma matriz simétrica possui autovalores negativos. Nesse caso, os valores singulares correspondem aos módulos dos autovalores, enquanto seus sinais são incorporados a uma das matrizes ortogonais da SVD.

Esse desenvolvimento complementa o caso semidefinido positivo apresentado anteriormente, mas não é necessário para acompanhar as aplicações principais da SVD às matrizes de Gram, às matrizes de dados e às estruturas de covariância.

Se $\mathbf{A}$ é simétrica, mas indefinida, os valores singulares são os módulos dos autovalores:

$$d_j = |\lambda_j|.$$

Para tornar essa relação explícita, defina

$$\text{sgn}_0(t) = \begin{cases} 1, & t \geq 0, \\ -1, & t < 0. \end{cases}$$

Então,

$$\lambda_j = \text{sgn}_0(\lambda_j) |\lambda_j|.$$

Após ordenar os autovalores por seus módulos, uma possível SVD é obtida tomando

$$\mathbf{V} = \mathbf{Q}_\mathbf{A},$$

$$\mathbf{D} = \text{diag}(|\lambda_1|, \dots, |\lambda_p|)$$

e

$$\mathbf{U} = \mathbf{Q}_\mathbf{A} \text{diag}(\text{sgn}_0(\lambda_1), \dots, \text{sgn}_0(\lambda_p)).$$

Dessa forma,

$$\mathbf{U}\mathbf{D}\mathbf{V}^\top = \mathbf{Q}_\mathbf{A}\mathbf{\Lambda}_\mathbf{A}\mathbf{Q}_\mathbf{A}^\top = \mathbf{A}.$$

A decomposição espectral preserva o sinal dos autovalores na matriz diagonal. A SVD mantém valores singulares não negativos e transfere as mudanças de orientação para uma das matrizes ortogonais.

Para matrizes não simétricas, autovalores e valores singulares representam objetos diferentes. Os autovalores descrevem direções invariantes de um operador quadrado. Os valores singulares descrevem fatores de escalonamento entre direções ortonormais do domínio e do contradomínio e permanecem definidos para matrizes retangulares.

Construção teórica e cálculo numérico

A decomposição espectral de

$$\mathbf{A}^\top \mathbf{A}$$

fornece uma demonstração da existência da SVD e permite realizar cálculos manuais em exemplos pequenos.

Em aplicações numéricas, a SVD não costuma ser calculada formando explicitamente

$$\mathbf{A}^\top \mathbf{A}.$$

Esse produto pode ampliar diferenças entre as magnitudes dos valores singulares e aumentar os efeitos de erros de arredondamento. Programas numéricos utilizam procedimentos específicos para calcular a SVD diretamente, com maior estabilidade.

A construção algébrica identifica os pares de direções associados pelos valores singulares. A interpretação geométrica mostra como a transformação leva a bola unitária do domínio a um elipsoide contido na imagem de $\mathbf{A}$, cujos semieixos são determinados pelos valores e vetores singulares. O comportamento da esfera unitária dependerá da existência ou não de direções pertencentes ao núcleo.

6.3 Interpretação geométrica da SVD

A SVD descreve uma transformação linear por meio de duas bases ortonormais e de um escalonamento entre elas. Para

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

a matriz $\mathbf{V}^\top$ expressa os vetores nas coordenadas dos vetores singulares à direita, $\mathbf{D}$ altera separadamente essas coordenadas e $\mathbf{U}$ expressa o resultado nas direções singulares à esquerda.

Considere um vetor

$$\mathbf{x} \in \mathbb{R}^p.$$

Como as colunas de $\mathbf{V}$ formam uma base ortonormal, ele pode ser escrito como

$$\mathbf{x} = \sum_{j=1}^p \alpha_j \mathbf{v}_j,$$

em que

$$\alpha_j = \mathbf{v}_j^\top \mathbf{x}.$$

Aplicando $\mathbf{A}$,

$$\begin{aligned} \mathbf{A}\mathbf{x} &= \sum_{j=1}^p \alpha_j \mathbf{A}\mathbf{v}_j \\ &= \sum_{j=1}^r d_j \alpha_j \mathbf{u}_j. \end{aligned}$$

As parcelas associadas aos vetores

$$\mathbf{v}_{r+1}, \dots, \mathbf{v}_p$$

desaparecem porque pertencem ao núcleo de $\mathbf{A}$.

A transformação pode, portanto, ser interpretada por meio das correspondências

$$\mathbf{v}_j \mapsto d_j \mathbf{u}_j, \quad j = 1, \dots, r.$$

Cada vetor singular à direita determina uma direção no domínio. O valor singular correspondente determina o fator de escala, enquanto o vetor singular à esquerda determina a direção resultante no contradomínio.

6.3.1 Imagem da bola unitária

Considere a bola unitária de $\mathbb{R}^p$:

$$\mathcal{B}_p = \{\mathbf{x} \in \mathbb{R}^p : \|\mathbf{x}\| \leq 1\}.$$

A SVD permite descrever geometricamente sua imagem pela transformação $\mathbf{A}$.

Proposição 6.5 (Imagem da bola unitária pela SVD). *Seja*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

a SVD compacta de uma matriz de posto $r \geq 1$. A imagem da bola unitária por $\mathbf{A}$ é o elipsoide sólido de dimensão r , contido em $\mathcal{C}(\mathbf{A})$,

$$\mathbf{A}(\mathcal{B}_p) = \left\{ \sum_{j=1}^r \beta_j \mathbf{u}_j : \sum_{j=1}^r \frac{\beta_j^2}{d_j^2} \leq 1 \right\}.$$

As direções principais desse elipsoide são

$$\mathbf{u}_1, \dots, \mathbf{u}_r,$$

e os comprimentos de seus semieixos são

$$d_1, \dots, d_r.$$

Em particular,

$$\mathbf{A}(\mathcal{B}_p) \subseteq \mathcal{C}(\mathbf{A}),$$

e a dimensão desse elipsoide é

$$\dim(\mathcal{C}(\mathbf{A})) = r.$$

No caso extremo $\mathbf{A} = \mathbf{0}$, a imagem da bola unitária reduz-se ao conjunto $\{\mathbf{0}\}$.

Comprovação. Escreva

$$\mathbf{x} = \sum_{j=1}^r \alpha_j \mathbf{v}_j + \mathbf{x}_0,$$

em que

$$\mathbf{x}_0 \in \mathcal{N}(\mathbf{A}).$$

Como os vetores singulares à direita e o núcleo formam subespaços ortogonais,

$$\|\mathbf{x}\|^2 = \sum_{j=1}^r \alpha_j^2 + \|\mathbf{x}_0\|^2.$$

Se $\mathbf{x} \in \mathcal{B}_p$, então

$$\sum_{j=1}^r \alpha_j^2 \leq 1.$$

Aplicando a transformação,

$$\mathbf{A}\mathbf{x} = \sum_{j=1}^r d_j \alpha_j \mathbf{u}_j.$$

Definindo

$$\beta_j = d_j \alpha_j,$$

obtém-se

$$\sum_{j=1}^r \frac{\beta_j^2}{d_j^2} = \sum_{j=1}^r \alpha_j^2 \leq 1.$$

Portanto, toda imagem de um vetor da bola unitária pertence ao elipsoide apresentado.

Reciprocamente, considere um vetor

$$\mathbf{y} = \sum_{j=1}^r \beta_j \mathbf{u}_j$$

que satisfaz

$$\sum_{j=1}^r \frac{\beta_j^2}{d_j^2} \leq 1.$$

Defina

$$\mathbf{x} = \sum_{j=1}^r \frac{\beta_j}{d_j} \mathbf{v}_j.$$

Então,

$$\|\mathbf{x}\|^2 = \sum_{j=1}^r \frac{\beta_j^2}{d_j^2} \leq 1,$$

de modo que $\mathbf{x} \in \mathcal{B}_p$. Além disso,

$$\mathbf{A}\mathbf{x} = \sum_{j=1}^r \beta_j \mathbf{u}_j = \mathbf{y}.$$

Logo, o conjunto apresentado coincide com a imagem da bola unitária. □

O comportamento da esfera unitária depende da existência de um núcleo não trivial.

Se $\mathbf{A}$ possui posto coluna completo,

$$r = p,$$

então

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}.$$

Nesse caso, a imagem da esfera unitária

$$\mathcal{S}_{p-1} = \{\mathbf{x} \in \mathbb{R}^p : \|\mathbf{x}\| = 1\}$$

é a fronteira relativa do elipsoide

$$\mathbf{A}(\mathcal{B}_p)$$

no subespaço $\mathcal{C}(\mathbf{A})$.

Por outro lado, se

$$r < p,$$

então

$$\dim(\mathcal{N}(\mathbf{A})) = p - r > 0.$$

Nesse caso, a imagem da esfera unitária coincide com a imagem da bola unitária:

$$\mathbf{A}(\mathcal{S}_{p-1}) = \mathbf{A}(\mathcal{B}_p).$$

De fato, para qualquer ponto do elipsoide cuja componente nas direções $\mathbf{v}_1, \dots, \mathbf{v}_r$ tenha norma menor que 1, pode-se acrescentar uma componente pertencente ao núcleo até obter um vetor de norma 1, sem alterar sua imagem por $\mathbf{A}$.

Finalmente, se

$$r < q,$$

o elipsoide não ocupa todo o espaço de chegada. Ele está contido no subespaço de dimensão r

$$\mathcal{C}(\mathbf{A}) = \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_r\} \subset \mathbb{R}^q.$$

Assim, a geometria da imagem da bola revela simultaneamente os fatores de escala da transformação e a dimensão de sua imagem.

6.3.2 Alteração dos comprimentos

Os valores singulares permitem determinar os fatores extremos de alteração dos comprimentos produzidos pela transformação.

Proposição 6.6 (Extremos da alteração dos comprimentos). *Seja*

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

uma matriz de posto $r \geq 1$, com valores singulares positivos ordenados como

$$d_1 \geq d_2 \geq \cdots \geq d_r > 0.$$

Então, para todo

$$\mathbf{x} \in \mathbb{R}^p,$$

tem-se

$$\|\mathbf{Ax}\| \leq d_1 \|\mathbf{x}\|.$$

Consequentemente,

$$\max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_1.$$

Se $\mathbf{A}$ possui posto coluna completo, isto é,

$$r = p,$$

então

$$d_p \|\mathbf{x}\| \leq \|\mathbf{Ax}\| \leq d_1 \|\mathbf{x}\|$$

para todo $\mathbf{x} \in \mathbb{R}^p$, e

$$\min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_p.$$

Se

$$r < p,$$

então

$$\min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = 0.$$

Comprovação. Escreva $\mathbf{x}$ na base ortonormal dos vetores singulares à direita:

$$\mathbf{x} = \sum_{j=1}^p \alpha_j \mathbf{v}_j.$$

Como essa base é ortonormal,

$$\|\mathbf{x}\|^2 = \sum_{j=1}^p \alpha_j^2.$$

Por outro lado,

$$\mathbf{Ax} = \sum_{j=1}^r d_j \alpha_j \mathbf{u}_j.$$

Como

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

são ortonormais,

$$\|\mathbf{Ax}\|^2 = \sum_{j=1}^r d_j^2 \alpha_j^2.$$

Como

$$d_j \leq d_1, \quad j = 1, \dots, r,$$

segue que

$$\begin{aligned}
\|\mathbf{Ax}\|^2 &= \sum_{j=1}^r d_j^2 \alpha_j^2 \\
&\leq d_1^2 \sum_{j=1}^r \alpha_j^2 \\
&\leq d_1^2 \sum_{j=1}^p \alpha_j^2 \\
&= d_1^2 \|\mathbf{x}\|^2.
\end{aligned}$$

Portanto,

$$\|\mathbf{Ax}\| \leq d_1 \|\mathbf{x}\|.$$

A igualdade é atingida, por exemplo, tomando

$$\mathbf{x} = \mathbf{v}_1,$$

pois

$$\|\mathbf{Av}_1\| = \|d_1 \mathbf{u}_1\| = d_1.$$

Logo,

$$\max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_1.$$

Suponha agora que $\mathbf{A}$ possua posto coluna completo. Nesse caso,

$$r = p$$

e

$$d_p > 0.$$

Como

$$d_j \geq d_p, \quad j = 1, \dots, p,$$

tem-se

$$\begin{aligned}
\|\mathbf{Ax}\|^2 &= \sum_{j=1}^p d_j^2 \alpha_j^2 \\
&\geq d_p^2 \sum_{j=1}^p \alpha_j^2 \\
&= d_p^2 \|\mathbf{x}\|^2.
\end{aligned}$$

Portanto,

$$\|\mathbf{Ax}\| \geq d_p \|\mathbf{x}\|.$$

A igualdade é atingida, por exemplo, para

$$\mathbf{x} = \mathbf{v}_p,$$

de modo que

$$\min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_p.$$

Finalmente, se

$$r < p,$$

então

$$\dim \mathcal{N}(\mathbf{A}) = p - r > 0.$$

Logo, existe um vetor unitário

$$\mathbf{x}_0 \in \mathcal{N}(\mathbf{A}).$$

Para esse vetor,

$$\mathbf{Ax}_0 = \mathbf{0},$$

e, portanto,

$$\min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = 0.$$

□

O maior valor singular d_1 representa, portanto, o maior fator de ampliação produzido pela transformação. Quando $\mathbf{A}$ possui posto coluna completo, o menor valor singular d_p representa o menor fator de alteração de comprimento entre vetores unitários. Quando o posto coluna não é completo, existem direções unitárias eliminadas pela transformação, e o menor comprimento possível da imagem é zero.

Esses extremos serão retomados posteriormente na definição da norma espectral e do número de condição.

6.3.3 Exemplo geométrico no plano

Exemplo 6.3 (Transformação da circunferência unitária em uma elipse). Considere a matriz não simétrica

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix}.$$

Sua SVD pode ser escrita como

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

com valores singulares aproximadamente iguais a

$$d_1 \approx 2,288$$

e

$$d_2 \approx 0,874.$$

A circunferência unitária pode ser parametrizada por

$$\mathbf{x}(\theta) = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix}, \quad 0 \leq \theta \leq 2\pi.$$

Sua imagem é

$$\mathbf{y}(\theta) = \mathbf{A}\mathbf{x}(\theta).$$

A SVD mostra que essa imagem é uma elipse com:

- semieixo maior de comprimento d_1 na direção $\mathbf{u}_1$;
- semieixo menor de comprimento d_2 na direção $\mathbf{u}_2$.

No domínio, as direções correspondentes são $\mathbf{v}_1$ e $\mathbf{v}_2$.

A Figura 6.1 mostra as direções singulares no domínio e no contradomínio. No primeiro painel, $\mathbf{v}_1$ e $\mathbf{v}_2$ formam uma base ortonormal de $\mathbb{R}^2$ e identificam duas direções sobre a circunferência unitária. No segundo, essas direções são transformadas em $d_1\mathbf{u}_1$ e $d_2\mathbf{u}_2$, que determinam os semieixos da elipse.




Figura 6.1: A SVD transforma as direções singulares à direita nos semieixos da elipse orientados pelos vetores singulares à esquerda.

Neste exemplo, as bases singulares do domínio e do contradomínio são distintas. A matriz $\mathbf{V}^\top$ expressa os pontos da circunferência nas coordenadas da base formada por $\mathbf{v}_1$ e $\mathbf{v}_2$. Como essa transformação é ortogonal, a circunferência permanece uma circunferência. Em seguida, $\mathbf{D}$ realiza a deformação, multiplicando os comprimentos nas duas direções por d_1 e d_2 . Finalmente, $\mathbf{U}$ orienta os semieixos da elipse nas direções $\mathbf{u}_1$ e $\mathbf{u}_2$ no espaço de chegada.

6.3.4 Transformações com núcleo não trivial

Quando

$$r < p,$$

a transformação possui núcleo não trivial e elimina $p - r$ direções linearmente independentes do domínio. Geometricamente, a imagem da bola unitária passa a ter dimensão inferior à dimensão do domínio.

Exemplo 6.4 (Colapso de uma direção pela transformação). Considere

$$\mathbf{A}_0 = \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}.$$

Os valores singulares são

$$d_1 = 2 \quad \text{e} \quad d_2 = 0.$$

A ação da transformação sobre um vetor

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

é

$$\mathbf{A}_0 \mathbf{x} = \begin{bmatrix} 2x_1 \\ 0 \end{bmatrix}.$$

Portanto, toda a direção

$$\mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

é eliminada, pois

$$\mathbf{A}_0 \mathbf{e}_2 = \mathbf{0}.$$

De fato,

$$\mathcal{N}(\mathbf{A}_0) = \text{span} \{ \mathbf{e}_2 \}.$$

A bola unitária de $\mathbb{R}^2$ é transformada no segmento

$$\left\{ \begin{bmatrix} y_1 \\ 0 \end{bmatrix} : -2 \leq y_1 \leq 2 \right\}.$$

Assim, a imagem possui dimensão 1, que coincide com

$$\text{posto}(\mathbf{A}_0) = 1.$$

O valor singular positivo $d_1 = 2$ determina o comprimento do único semieixo não nulo, enquanto o valor singular $d_2 = 0$ identifica a direção eliminada pela transformação.

De modo geral:

- cada valor singular positivo produz um semieixo não nulo da imagem;
- existem exatamente r semieixos não nulos;
- o núcleo possui dimensão $p - r$ e contém todas as direções que são transformadas no vetor nulo;
- a dimensão do elipsoide resultante é r ;
- o elipsoide está contido em $\mathcal{C}(\mathbf{A})$.

A descrição geométrica da SVD também identifica bases ortonormais dos quatro espaços fundamentais associados à matriz. Essas relações permitem interpretar posto, núcleo, projetores e normas diretamente a partir dos vetores e valores singulares. Aspectos relacionados ao condicionamento numérico serão apresentados posteriormente como leitura de aprofundamento.

6.4 Espaços fundamentais, posto e normas

A SVD fornece bases ortonormais para os quatro espaços fundamentais associados a uma matriz. Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com posto

$$r = \text{posto}(\mathbf{A})$$

e SVD compacta

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

As colunas de

$$\mathbf{U}_r \in \mathbb{R}^{q \times r}$$

são os vetores singulares à esquerda associados aos valores singulares positivos. As colunas de

$$\mathbf{V}_r \in \mathbb{R}^{p \times r}$$

são os vetores singulares à direita correspondentes.

Complete essas matrizes com bases ortonormais dos respectivos complementos:

$$\mathbf{U} = [\mathbf{U}_r \quad \mathbf{U}_0]$$

e

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0],$$

em que

$$\mathbf{U}_0 \in \mathbb{R}^{q \times (q-r)}$$

e

$$\mathbf{V}_0 \in \mathbb{R}^{p \times (p-r)}.$$

Quando $r = q$, a matriz $\mathbf{U}_0$ não possui colunas. Quando $r = p$, o mesmo ocorre com $\mathbf{V}_0$.

6.4.1 Espaço coluna e espaço linha

Proposição 6.7 (Espaços fundamentais determinados pela SVD). *Se*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de posto r , então

$$\mathcal{C}(\mathbf{A}) = \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_r\} = \mathcal{C}(\mathbf{U}_r),$$

$$\mathcal{C}(\mathbf{A}^\top) = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_r\} = \mathcal{C}(\mathbf{V}_r),$$

$$\mathcal{N}(\mathbf{A}) = \text{span} \{ \mathbf{v}_{r+1}, \dots, \mathbf{v}_p \} = \mathcal{C}(\mathbf{V}_0),$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \text{span} \{ \mathbf{u}_{r+1}, \dots, \mathbf{u}_q \} = \mathcal{C}(\mathbf{U}_0).$$

(Golub; Van Loan, 2013)

Comprovação. Pela SVD compacta,

$$\mathbf{A}\mathbf{x} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^p$. Logo, toda imagem de $\mathbf{A}$ é uma combinação linear das colunas de $\mathbf{U}_r$:

$$\mathcal{C}(\mathbf{A}) \subseteq \mathcal{C}(\mathbf{U}_r).$$

Reciprocamente, para cada $j = 1, \dots, r$,

$$\mathbf{A}\mathbf{v}_j = d_j \mathbf{u}_j.$$

Como $d_j > 0$,

$$\mathbf{u}_j = \mathbf{A} \left(\frac{1}{d_j} \mathbf{v}_j \right).$$

Portanto,

$$\mathbf{u}_j \in \mathcal{C}(\mathbf{A}),$$

e

$$\mathcal{C}(\mathbf{U}_r) \subseteq \mathcal{C}(\mathbf{A}).$$

Assim,

$$\mathcal{C}(\mathbf{A}) = \mathcal{C}(\mathbf{U}_r).$$

Aplicando o mesmo argumento a

$$\mathbf{A}^\top = \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top,$$

obtém-se

$$\mathcal{C}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{V}_r).$$

Considere agora a base ortonormal completa

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0].$$

Todo vetor $\mathbf{x} \in \mathbb{R}^p$ possui uma decomposição única da forma

$$\mathbf{x} = \mathbf{V}_r \alpha + \mathbf{V}_0 \beta.$$

Aplicando $\mathbf{A}$,

$$\begin{aligned} \mathbf{Ax} &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top (\mathbf{V}_r \alpha + \mathbf{V}_0 \beta) \\ &= \mathbf{U}_r \mathbf{D}_r \alpha, \end{aligned}$$

pois

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r$$

e

$$\mathbf{V}_r^\top \mathbf{V}_0 = \mathbf{0}.$$

Como $\mathbf{D}_r$ é invertível,

$$\mathbf{Ax} = \mathbf{0}$$

se, e somente se,

$$\alpha = \mathbf{0}.$$

Logo,

$$\mathbf{x} \in \mathcal{N}(\mathbf{A})$$

se, e somente se,

$$\mathbf{x} = \mathbf{V}_0 \beta.$$

Portanto,

$$\mathcal{N}(\mathbf{A}) = \mathcal{C}(\mathbf{V}_0).$$

Aplicando o mesmo raciocínio a $\mathbf{A}^\top$,

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{U}_0).$$

Assim, a SVD completa fornece bases ortonormais simultaneamente para os quatro espaços fundamentais de $\mathbf{A}$. $\square$

As quatro bases fornecidas pela SVD podem ser organizadas como na Tabela 6.4.

Tabela 6.4: Espaços fundamentais e bases ortonormais fornecidas pela SVD.

Espaço	Subespaço de	Base ortonormal fornecida pela SVD	Dimensão
Espaço coluna $\mathcal{C}(\mathbf{A})$	$\mathbb{R}^q$	Colunas de $\mathbf{U}_r$	r
Núcleo à esquerda $\mathcal{N}(\mathbf{A}^\top)$	$\mathbb{R}^q$	Colunas de $\mathbf{U}_0$	$q - r$
Espaço linha $\mathcal{C}(\mathbf{A}^\top)$	$\mathbb{R}^p$	Colunas de $\mathbf{V}_r$	r
Núcleo $\mathcal{N}(\mathbf{A})$	$\mathbb{R}^p$	Colunas de $\mathbf{V}_0$	$p - r$

A SVD torna explícitas as decomposições ortogonais

$$\mathbb{R}^q = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top)$$

e

$$\mathbb{R}^p = \mathcal{C}(\mathbf{A}^\top) \oplus \mathcal{N}(\mathbf{A}).$$

O símbolo $\oplus$ indica uma soma direta ortogonal.

Todo vetor

$$\mathbf{y} \in \mathbb{R}^q$$

pode ser escrito de maneira única como

$$\mathbf{y} = \mathbf{y}_{\mathcal{C}} + \mathbf{y}_{\mathcal{N}},$$

com

$$\mathbf{y}_{\mathcal{C}} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{y}_{\mathcal{N}} \in \mathcal{N}(\mathbf{A}^{\top}).$$

De modo análogo, todo vetor

$$\mathbf{x} \in \mathbb{R}^p$$

se decompõe em uma parcela no espaço linha e outra no núcleo de $\mathbf{A}$.

6.4.2 Projetores ortogonais

A identificação das bases dos quatro espaços fundamentais permite construir diretamente seus projetores ortogonais.

Proposição 6.8 (Projetores dos espaços fundamentais pela SVD). *Considere a SVD completa escrita como*

$$\mathbf{U} = [\mathbf{U}_r \quad \mathbf{U}_0]$$

e

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0].$$

Então, os projetores ortogonais sobre os quatro espaços fundamentais são

$$\mathbf{P}_{\mathcal{C}(\mathbf{A})} = \mathbf{U}_r \mathbf{U}_r^{\top}$$

e

$$\mathbf{P}_{\mathcal{N}(\mathbf{A}^\top)} = \mathbf{U}_0 \mathbf{U}_0^\top = \mathbf{I}_q - \mathbf{U}_r \mathbf{U}_r^\top.$$

No espaço de origem,

$$\mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)} = \mathbf{V}_r \mathbf{V}_r^\top$$

e

$$\mathbf{P}_{\mathcal{N}(\mathbf{A})} = \mathbf{V}_0 \mathbf{V}_0^\top = \mathbf{I}_p - \mathbf{V}_r \mathbf{V}_r^\top.$$

Comprovação. Pela Proposição 6.7,

$$\mathcal{C}(\mathbf{A}) = \mathcal{C}(\mathbf{U}_r)$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{U}_0).$$

Como as colunas de $\mathbf{U}_r$ e de $\mathbf{U}_0$ são ortonormais, a Proposição 3.14 fornece

$$\mathbf{P}_{\mathcal{C}(\mathbf{A})} = \mathbf{U}_r \mathbf{U}_r^\top$$

e

$$\mathbf{P}_{\mathcal{N}(\mathbf{A}^\top)} = \mathbf{U}_0 \mathbf{U}_0^\top.$$

Além disso, como

$$\mathbf{U} = [\mathbf{U}_r \quad \mathbf{U}_0]$$

é ortogonal,

$$\mathbf{U} \mathbf{U}^\top = \mathbf{I}_q.$$

Portanto,

$$\mathbf{U}_r \mathbf{U}_r^\top + \mathbf{U}_0 \mathbf{U}_0^\top = \mathbf{I}_q,$$

de onde

$$\mathbf{U}_0 \mathbf{U}_0^\top = \mathbf{I}_q - \mathbf{U}_r \mathbf{U}_r^\top.$$

Aplicando o mesmo argumento a

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0],$$

obtêm-se

$$\mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)} = \mathbf{V}_r \mathbf{V}_r^\top$$

e

$$\mathbf{P}_{\mathcal{N}(\mathbf{A})} = \mathbf{V}_0 \mathbf{V}_0^\top = \mathbf{I}_p - \mathbf{V}_r \mathbf{V}_r^\top.$$

□

Como são projetores ortogonais, essas matrizes são simétricas e idempotentes, conforme as propriedades estudadas no Capítulo 3.

Exemplo 6.5 (Espaços fundamentais do exemplo condutor). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

Sua SVD completa foi construída com

$$\mathbf{u}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \quad \mathbf{u}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{u}_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}.$$

Os vetores singulares à direita são

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Como os dois valores singulares são positivos,

$$r = 2.$$

Assim,

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{u}_1, \mathbf{u}_2 \},$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \text{span} \{ \mathbf{u}_3 \}.$$

A matriz possui posto coluna completo, pois

$$r = p = 2.$$

Consequentemente,

$$\mathcal{N}(\mathbf{A}) = \{ \mathbf{0} \}$$

e

$$\mathcal{C}(\mathbf{A}^\top) = \mathbb{R}^2.$$

O projetor sobre o espaço coluna é

$$\begin{aligned} \mathbf{U}_2 \mathbf{U}_2^\top &= \mathbf{u}_1 \mathbf{u}_1^\top + \mathbf{u}_2 \mathbf{u}_2^\top \\ &= \begin{bmatrix} 1/2 & 0 & 1/2 \\ 0 & 1 & 0 \\ 1/2 & 0 & 1/2 \end{bmatrix}. \end{aligned}$$

O projetor sobre o núcleo à esquerda é

$$\mathbf{u}_3 \mathbf{u}_3^\top = \begin{bmatrix} 1/2 & 0 & -1/2 \\ 0 & 0 & 0 \\ -1/2 & 0 & 1/2 \end{bmatrix}.$$

A soma dos dois projetores é

$$\mathbf{U}_2 \mathbf{U}_2^\top + \mathbf{u}_3 \mathbf{u}_3^\top = \mathbf{I}_3.$$

6.4.3 Posto e nulidades

Pela SVD, o posto de $\mathbf{A}$ é exatamente o número de valores singulares positivos:

$$\text{posto}(\mathbf{A}) = r = \# \{j : d_j > 0\}.$$

Como consequência do Teorema Posto–Nulidade,

$$\dim \mathcal{N}(\mathbf{A}) = p - r$$

e

$$\dim \mathcal{N}(\mathbf{A}^\top) = q - r.$$

Essas dimensões também são visualizadas diretamente na SVD completa:

- as r colunas de $\mathbf{V}_r$ formam uma base do espaço linha;
- as $p - r$ colunas de $\mathbf{V}_0$ formam uma base do núcleo de $\mathbf{A}$;
- as r colunas de $\mathbf{U}_r$ formam uma base do espaço coluna;
- as $q - r$ colunas de $\mathbf{U}_0$ formam uma base do núcleo de $\mathbf{A}^\top$.

É importante distinguir essas dimensões do número de posições diagonais nulas de $\mathbf{D}$. Como

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

possui apenas

$$s = \min(q, p)$$

posições diagonais, existem

$$s - r$$

valores singulares nulos entre essas posições, enquanto as dimensões dos dois núcleos são, respectivamente,

$$p - r \quad \text{e} \quad q - r.$$

Assim, em matrizes retangulares, a estrutura completa dos núcleos não deve ser inferida apenas pela quantidade de elementos diagonais nulos de $\mathbf{D}$.

A Tabela 6.5 reúne as principais relações entre os valores e vetores singulares e a estrutura da transformação.

Tabela 6.5: Relação entre a SVD e a estrutura da matriz.

Estrutura ou propriedade	Caracterização pela SVD
Posto	Número de valores singulares positivos
Imagem $\mathcal{C}(\mathbf{A})$	Vetores singulares à esquerda associados a $d_j > 0$
Espaço linha $\mathcal{C}(\mathbf{A}^\top)$	Vetores singulares à direita associados a $d_j > 0$
Núcleo $\mathcal{N}(\mathbf{A})$	Vetores singulares à direita associados à parte nula
Núcleo à esquerda $\mathcal{N}(\mathbf{A}^\top)$	Vetores singulares à esquerda associados à parte nula
Ampliação máxima	d_1
Menor fator positivo de escala	d_r

Se $r < p$, a menor norma de $\mathbf{A}\mathbf{x}$ entre todos os vetores unitários do domínio é zero, pois existem vetores unitários no núcleo. O valor d_r descreve o menor fator **positivo** de escala, isto é, a menor ação da transformação quando restrita ao espaço linha $\mathcal{C}(\mathbf{A}^\top)$.

6.4.4 Produto interno de Frobenius

O estudo das aproximações matriciais exige uma geometria para o espaço das matrizes.

Definição 6.6 (Produto interno de Frobenius). Para matrizes

$$\mathbf{A}, \tilde{\mathbf{A}} \in \mathbb{R}^{q \times p},$$

o produto interno de Frobenius é

$$\langle \mathbf{A}, \widetilde{\mathbf{A}} \rangle_F = \text{tr} (\mathbf{A}^\top \widetilde{\mathbf{A}}).$$

Equivalentemente,

$$\langle \mathbf{A}, \widetilde{\mathbf{A}} \rangle_F = \sum_{i=1}^q \sum_{j=1}^p a_{ij} \widetilde{a}_{ij}.$$

O produto interno de Frobenius trata uma matriz como um vetor formado por todos os seus elementos. Duas matrizes são ortogonais segundo esse produto quando

$$\langle \mathbf{A}, \widetilde{\mathbf{A}} \rangle_F = 0.$$

A norma induzida por esse produto interno é a norma de Frobenius.

Definição 6.7 (Norma de Frobenius). A **norma de Frobenius** de

$$\mathbf{A} = (a_{ij}) \in \mathbb{R}^{q \times p}$$

é

$$\|\mathbf{A}\|_F = \sqrt{\langle \mathbf{A}, \mathbf{A} \rangle_F}.$$

Equivalentemente,

$$\|\mathbf{A}\|_F = \sqrt{\text{tr} (\mathbf{A}^\top \mathbf{A})}$$

ou

$$\|\mathbf{A}\|_F = \sqrt{\sum_{i=1}^q \sum_{j=1}^p a_{ij}^2}.$$

A norma de Frobenius mede a magnitude quadrática total dos elementos da matriz.

6.4.5 Normas e valores singulares

Definição 6.8 (Norma espectral). A **norma espectral**, ou norma matricial induzida pela norma euclidiana, é

$$\|\mathbf{A}\|_2 = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|}.$$

Equivalentemente,

$$\|\mathbf{A}\|_2 = \max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\|.$$

A interpretação geométrica anterior mostra que a norma espectral é o maior fator de ampliação produzido pela transformação.

Proposição 6.9 (Normas matriciais e valores singulares). *Se*

$$d_1 \geq \dots \geq d_r > 0$$

são os valores singulares positivos de $\mathbf{A}$, então

$$\|\mathbf{A}\|_2 = d_1$$

e

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

(Golub; Van Loan, 2013)

Comprovação. Pela Proposição 6.6,

$$\max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_1.$$

Como, pela Definição 6.8,

$$\|\mathbf{A}\|_2 = \max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\|,$$

segue imediatamente que

$$\|\mathbf{A}\|_2 = d_1.$$

Para a norma de Frobenius, utilizando a Proposição 6.4,

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top.$$

Portanto,

$$\begin{aligned} \|\mathbf{A}\|_F^2 &= \text{tr}(\mathbf{A}^\top \mathbf{A}) \\ &= \text{tr}(\mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top) \\ &= \text{tr}(\mathbf{D}_r^2 \mathbf{V}_r^\top \mathbf{V}_r) \\ &= \text{tr}(\mathbf{D}_r^2) \\ &= \sum_{j=1}^r d_j^2. \end{aligned}$$

Logo,

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

□

Se $\mathbf{A} = \mathbf{0}$, então não há valores singulares positivos e, diretamente pelas definições,

$$\|\mathbf{A}\|_2 = \|\mathbf{A}\|_F = 0.$$

As duas normas medem aspectos diferentes:

- $\|\mathbf{A}\|_2$ depende somente do maior valor singular e representa o maior fator de ampliação;
- $\|\mathbf{A}\|_F$ reúne as contribuições quadráticas de todos os valores singulares.

Para qualquer matriz,

$$\|\mathbf{A}\|_2 \leq \|\mathbf{A}\|_F \leq \sqrt{r} \|\mathbf{A}\|_2.$$

A primeira desigualdade decorre de

$$d_1^2 \leq \sum_{j=1}^r d_j^2.$$

A segunda decorre de

$$\sum_{j=1}^r d_j^2 \leq r d_1^2.$$

6.4.6 Invariância ortogonal

As normas espectral e de Frobenius são preservadas por multiplicações ortogonais.

Proposição 6.10 (Invariância ortogonal das normas). *Se $\mathbf{Q}_1$ e $\mathbf{Q}_2$ são matrizes ortogonais de dimensões compatíveis, então*

$$\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_2 = \|\mathbf{A}\|_2$$

e

$$\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_F = \|\mathbf{A}\|_F.$$

(Golub; Van Loan, 2013)

Comprovação. Para a norma espectral, como $\mathbf{Q}_1$ preserva normas,

$$\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2 \mathbf{x}\| = \|\mathbf{A} \mathbf{Q}_2 \mathbf{x}\|.$$

Como $\mathbf{Q}_2$ é ortogonal, a transformação

$$\mathbf{z} = \mathbf{Q}_2 \mathbf{x}$$

preserva a norma e percorre todos os vetores unitários quando $\mathbf{x}$ percorre a esfera unitária. Portanto,

$$\begin{aligned} \|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_2 &= \max_{\|\mathbf{x}\|=1} \|\mathbf{A} \mathbf{Q}_2 \mathbf{x}\| \\ &= \max_{\|\mathbf{z}\|=1} \|\mathbf{A} \mathbf{z}\| \\ &= \|\mathbf{A}\|_2. \end{aligned}$$

Para a norma de Frobenius,

$$\begin{aligned}
\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_F^2 &= \text{tr} \left[(\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2)^\top (\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2) \right] \\
&= \text{tr} (\mathbf{Q}_2^\top \mathbf{A}^\top \mathbf{A} \mathbf{Q}_2) \\
&= \text{tr} (\mathbf{A}^\top \mathbf{A} \mathbf{Q}_2 \mathbf{Q}_2^\top) \\
&= \text{tr} (\mathbf{A}^\top \mathbf{A}) \\
&= \|\mathbf{A}\|_F^2.
\end{aligned}$$

Logo, ambas as normas são invariantes sob multiplicações ortogonais. $\square$

A SVD pode, portanto, ser interpretada como uma representação que remove fatores ortogonais sem alterar essas normas:

$$\|\mathbf{A}\|_2 = \|\mathbf{D}\|_2$$

e

$$\|\mathbf{A}\|_F = \|\mathbf{D}\|_F.$$

6.4.7 Determinante e invertibilidade

Quando

$$q = p,$$

a matriz $\mathbf{A}$ é quadrada. Pela SVD,

$$\det(\mathbf{A}) = \det(\mathbf{U}) \det(\mathbf{D}) \det(\mathbf{V}^\top).$$

Como $\mathbf{U}$ e $\mathbf{V}$ são ortogonais,

$$|\det(\mathbf{U})| = |\det(\mathbf{V})| = 1.$$

Portanto,

$$|\det(\mathbf{A})| = \prod_{j=1}^p d_j.$$

O módulo do determinante é o produto dos valores singulares.

Além disso,

$$\mathbf{A} \text{ é invertível} \iff d_j > 0 \text{ para todo } j.$$

Nesse caso,

$$r = p = q,$$

de modo que não existem direções singulares associadas ao valor zero. Assim, as formas compacta e completa possuem as mesmas dimensões e podem ser escritas com os mesmos fatores:

$$\mathbf{U}_r = \mathbf{U}, \quad \mathbf{D}_r = \mathbf{D}, \quad \mathbf{V}_r = \mathbf{V}.$$

6.4.8 Aprofundamento: condicionamento e posto numérico

Leitura de aprofundamento

Esta seção apresenta duas extensões de natureza numérica da interpretação dos valores singulares. A primeira utiliza a razão entre os valores singulares extremos para avaliar o condicionamento de uma transformação. A segunda distingue o posto algébrico do posto numérico obtido após a adoção de uma tolerância computacional.

Esses conceitos são importantes para estabilidade numérica, problemas inversos e algoritmos matriciais, mas não são necessários para acompanhar os resultados centrais sobre espaços fundamentais, aproximações de posto reduzido e aplicações estatísticas da SVD.

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e defina

$$s = \min(q, p).$$

Quando

$$\text{posto}(\mathbf{A}) = s,$$

a matriz possui o maior posto possível para suas dimensões e todos os seus s valores singulares são positivos:

$$d_1 \geq \dots \geq d_s > 0.$$

Definição 6.9 (Número de condição na norma espectral). Para uma matriz de posto máximo,

$$\text{posto}(\mathbf{A}) = s,$$

define-se o **número de condição na norma espectral** por

$$\kappa_2(\mathbf{A}) = \frac{d_1}{d_s}.$$

Quando

$$\text{posto}(\mathbf{A}) < s,$$

adota-se

$$\kappa_2(\mathbf{A}) = \infty.$$

(Golub; Van Loan, 2013)

O número de condição compara o maior e o menor fatores positivos de escala associados à parte ativa da transformação.

Quando

$$\kappa_2(\mathbf{A}) \approx 1,$$

os valores singulares extremos possuem magnitudes semelhantes. Quando

$$\kappa_2(\mathbf{A})$$

é elevado, algumas direções ativas são transformadas por fatores muito maiores que outras.

É importante distinguir **núcleo não trivial**, **deficiência de posto** e **mau condicionamento**.

A deficiência de posto ocorre quando

$$\text{posto}(\mathbf{A}) < \min(q, p).$$

Entretanto, uma matriz retangular pode possuir núcleo não trivial mesmo apresentando posto máximo.

Por exemplo, se

$$q < p$$

e

$$\text{posto}(\mathbf{A}) = q,$$

então $\mathbf{A}$ possui posto linha completo e, portanto, posto máximo. Mesmo assim,

$$\dim \mathcal{N}(\mathbf{A}) = p - q > 0.$$

Assim, existem direções do domínio que são transformadas no vetor nulo.

Nesse caso, a transformação não é injetiva em todo o domínio $\mathbb{R}^p$. Sua restrição ao espaço linha,

$$\mathcal{C}(\mathbf{A}^\top) = \mathcal{N}(\mathbf{A})^\perp,$$

é, entretanto, injetiva.

Nesse subespaço,

$$d_q = \min_{\substack{\|\mathbf{x}\|=1 \\ \mathbf{x} \in \mathcal{C}(\mathbf{A}^\top)}} \|\mathbf{A}\mathbf{x}\|.$$

Portanto, para matrizes largas de posto linha completo, o número de condição finito descreve a variação dos fatores de escala sobre o espaço linha, isto é, sobre a parte do domínio na qual a transformação atua de forma injetiva.

Se

$$q \geq p$$

e

$$\text{posto}(\mathbf{A}) = p,$$

então $\mathbf{A}$ possui posto coluna completo e

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}.$$

Nesse caso,

$$d_p = \min_{\|\mathbf{x}\|=1} \|\mathbf{A}\mathbf{x}\|$$

e

$$\kappa_2(\mathbf{A}) = \frac{d_1}{d_p}.$$

Para uma matriz quadrada invertível,

$$q = p = r,$$

tem-se também

$$\kappa_2(\mathbf{A}) = \|\mathbf{A}\|_2 \|\mathbf{A}^{-1}\|_2.$$

De fato,

$$\|\mathbf{A}\|_2 = d_1,$$

e os valores singulares de $\mathbf{A}^{-1}$ são

$$\frac{1}{d_p}, \dots, \frac{1}{d_1}.$$

Portanto,

$$\|\mathbf{A}^{-1}\|_2 = \frac{1}{d_p},$$

de modo que

$$\kappa_2(\mathbf{A}) = \frac{d_1}{d_p}.$$

Uma matriz de posto máximo com número de condição elevado é denominada **mal condicionada**. Valores singulares positivos muito pequenos indicam direções nas quais a transformação produz forte contração. Ao inverter a ação da matriz nessas direções, pequenas perturbações podem ser amplificadas.

Esse fenômeno será retomado posteriormente na discussão da pseudoinversa.

Exemplo 6.6 (Comparação entre duas transformações). Considere

$$\mathbf{A}_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

e

$$\mathbf{A}_2 = \begin{bmatrix} 2 & 0 \\ 0 & 0,02 \end{bmatrix}.$$

Os valores singulares de $\mathbf{A}_1$ são

$$2 \quad \text{e} \quad 2.$$

Portanto,

$$\kappa_2(\mathbf{A}_1) = 1.$$

Nesse caso, as duas direções singulares são transformadas pelo mesmo fator.

Para $\mathbf{A}_2$, os valores singulares são

$$2 \quad \text{e} \quad 0,02.$$

Logo,

$$\kappa_2(\mathbf{A}_2) = \frac{2}{0,02} = 100.$$

A primeira direção é ampliada por um fator igual a 2, enquanto a segunda é contraída por um fator igual a 0,02.

A inversão da segunda componente exige um fator

$$\frac{1}{0,02} = 50.$$

Consequentemente, pequenas perturbações nessa direção podem ser fortemente ampliadas quando se procura inverter a transformação.

6.4.8.1 Posto exato e posto numérico

Matematicamente, o posto é determinado exatamente pelos valores singulares positivos:

$$\text{posto}(\mathbf{A}) = \# \{j : d_j > 0\}.$$

Em cálculos computacionais, entretanto, valores que seriam exatamente nulos em aritmética exata podem aparecer como números positivos muito pequenos em razão de arredondamentos, aproximações ou ruído.

Por isso, pode-se adotar uma tolerância

$$\tau \geq 0$$

e tratar como numericamente nulos os valores singulares que satisfazem

$$d_j \leq \tau.$$

Definição 6.10 (Posto numérico). Fixada uma tolerância $\tau \geq 0$, o **posto numérico** de $\mathbf{A}$ é definido por

$$r_\tau(\mathbf{A}) = \# \{j : d_j > \tau\}.$$

Diferentemente do posto algébrico, o posto numérico depende da tolerância adotada.

A escolha de τ pode depender de fatores como:

- precisão numérica;
- escala da matriz;
- dimensões da matriz;
- finalidade da análise;
- nível de perturbação ou ruído considerado relevante.

Portanto, dois valores devem ser distinguidos:

$$\text{posto}(\mathbf{A}) = \#\{j : d_j > 0\}$$

e

$$r_\tau(\mathbf{A}) = \#\{j : d_j > \tau\}.$$

Essa distinção será particularmente útil quando forem estudadas aproximações de posto reduzido. Nessas aproximações, valores singulares matematicamente positivos podem ser descartados deliberadamente quando sua contribuição é considerada pequena.

6.5 SVD de uma matriz de dados

Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

em que as linhas representam n observações e as colunas representam p variáveis.

Se

$$r = \text{posto}(\mathbf{X}),$$

a SVD compacta é

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

com

$$\mathbf{U}_r \in \mathbb{R}^{n \times r}, \quad \mathbf{D}_r \in \mathbb{R}^{r \times r}$$

e

$$\mathbf{V}_r \in \mathbb{R}^{p \times r}.$$

Nesse contexto, a SVD recupera a dupla representação da matriz de dados introduzida no Capítulo 1:

- as colunas de $\mathbf{V}_r$ pertencem a $\mathbb{R}^p$ e determinam direções no espaço em que as observações são representadas;
- as colunas de $\mathbf{U}_r$ pertencem a $\mathbb{R}^n$ e determinam direções no espaço em que as variáveis são representadas.

Os mesmos valores singulares conectam essas duas representações.

6.5.1 Dualidade entre observações e variáveis

A SVD relaciona diretamente as duas representações da matriz de dados: as observações como vetores em $\mathbb{R}^p$ e as variáveis como vetores em $\mathbb{R}^n$.

Proposição 6.11 (Dualidade entre observações e variáveis). *Se*

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

então

$$\mathbf{X} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r$$

e

$$\mathbf{X}^\top \mathbf{U}_r = \mathbf{V}_r \mathbf{D}_r.$$

Consequentemente, para

$$j = 1, \dots, r,$$

tem-se

$$\mathbf{X} \mathbf{v}_j = d_j \mathbf{u}_j$$

e

$$\mathbf{X}^\top \mathbf{u}_j = d_j \mathbf{v}_j.$$

Assim, o mesmo valor singular d_j relaciona uma direção $\mathbf{v}_j$ no espaço das observações $\mathbb{R}^p$ a uma direção $\mathbf{u}_j$ no espaço das variáveis $\mathbb{R}^n$.

Comprovação. Multiplicando a SVD compacta à direita por $\mathbf{V}_r$,

$$\begin{aligned}\mathbf{X}\mathbf{V}_r &= \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top\mathbf{V}_r \\ &= \mathbf{U}_r\mathbf{D}_r,\end{aligned}$$

pois

$$\mathbf{V}_r^\top\mathbf{V}_r = \mathbf{I}_r.$$

Transpondo a SVD compacta,

$$\mathbf{X}^\top = \mathbf{V}_r\mathbf{D}_r\mathbf{U}_r^\top.$$

Multiplicando à direita por $\mathbf{U}_r$,

$$\begin{aligned}\mathbf{X}^\top\mathbf{U}_r &= \mathbf{V}_r\mathbf{D}_r\mathbf{U}_r^\top\mathbf{U}_r \\ &= \mathbf{V}_r\mathbf{D}_r,\end{aligned}$$

pois

$$\mathbf{U}_r^\top\mathbf{U}_r = \mathbf{I}_r.$$

As relações correspondentes a cada coluna seguem diretamente dessas duas identidades matriciais. $\square$

6.5.2 Coordenadas das observações nas direções singulares à direita

Defina

$$\mathbf{Z} = \mathbf{X}\mathbf{V}_r.$$

Pela Proposição 6.11,

$$\mathbf{Z} = \mathbf{U}_r\mathbf{D}_r.$$

A matriz

$$\mathbf{Z} \in \mathbb{R}^{n \times r}$$

contém as coordenadas das observações na base ortonormal

$$\{\mathbf{v}_1, \dots, \mathbf{v}_r\}$$

do espaço linha

$$\mathcal{C}(\mathbf{X}^\top) \subseteq \mathbb{R}^p.$$

Como cada observação pertence a esse subespaço, as r coordenadas são suficientes para representá-la exatamente.

Se a linha i de $\mathbf{X}$ corresponde ao vetor

$$\mathbf{x}_i \in \mathbb{R}^p,$$

então

$$z_{ij} = \mathbf{x}_i^\top \mathbf{v}_j.$$

Portanto, z_{ij} é a coordenada da observação i na direção singular $\mathbf{v}_j$.

A j -ésima coluna de $\mathbf{Z}$ é

$$\mathbf{z}_j = \mathbf{X}\mathbf{v}_j = d_j\mathbf{u}_j.$$

Assim, $\mathbf{v}_j$ determina a direção utilizada para representar as observações, enquanto $\mathbf{u}_j$ descreve como as coordenadas correspondentes se distribuem entre as n unidades observacionais.

6.5.3 Coordenadas das variáveis nas direções singulares à esquerda

A relação dual é

$$\mathbf{U}_r^\top \mathbf{X} = \mathbf{D}_r \mathbf{V}_r^\top.$$

Defina

$$\mathbf{W} = \mathbf{U}_r^\top \mathbf{X} \in \mathbb{R}^{r \times p}.$$

Cada coluna de $\mathbf{X}$ representa uma variável como vetor em $\mathbb{R}^n$. Se

$$\mathbf{x}^{(j)} \in \mathbb{R}^n$$

denota a j -ésima variável, então a j -ésima coluna de $\mathbf{W}$ contém suas coordenadas na base ortonormal

$$\{\mathbf{u}_1, \dots, \mathbf{u}_r\}$$

do espaço coluna

$$\mathcal{C}(\mathbf{X}) \subseteq \mathbb{R}^n.$$

Para a direção singular ℓ ,

$$\mathbf{u}_\ell^\top \mathbf{x}^{(j)} = d_\ell v_{j\ell}.$$

Portanto, os elementos de $\mathbf{V}_r$, escalonados pelos valores singulares, também descrevem as coordenadas das variáveis na base singular à esquerda.

As relações

$$\mathbf{X} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r$$

e

$$\mathbf{X}^\top \mathbf{U}_r = \mathbf{V}_r \mathbf{D}_r$$

expressam, assim, a dualidade entre o espaço das observações e o espaço das variáveis.

6.5.4 Matrizes de Gram da matriz de dados

As duas matrizes de Gram associadas a $\mathbf{X}$ descrevem relações entre objetos diferentes.

A matriz

$$\mathbf{X}^\top \mathbf{X} \in \mathbb{R}^{p \times p}$$

reúne os produtos internos entre as colunas de $\mathbf{X}$, isto é, entre as variáveis representadas como vetores em $\mathbb{R}^n$.

A matriz

$$\mathbf{X}\mathbf{X}^\top \in \mathbb{R}^{n \times n}$$

reúne os produtos internos entre as linhas de $\mathbf{X}$, isto é, entre as observações representadas como vetores em $\mathbb{R}^p$.

Pela Proposição 6.4,

$$\mathbf{X}^\top \mathbf{X} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top$$

e

$$\mathbf{X}\mathbf{X}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

Portanto, as duas matrizes possuem os mesmos autovalores positivos,

$$d_1^2, \dots, d_r^2,$$

mas seus autovetores pertencem a espaços diferentes:

- $\mathbf{v}_j \in \mathbb{R}^p$ determina uma direção no espaço das observações;
- $\mathbf{u}_j \in \mathbb{R}^n$ determina uma direção no espaço das variáveis.

Essa dualidade também pode ser útil quando as dimensões da matriz são muito diferentes. Se

$$n \gg p,$$

a matriz

$$\mathbf{X}^\top \mathbf{X}$$

possui ordem menor. Se

$$p \gg n,$$

a matriz

$$\mathbf{X}\mathbf{X}^\top$$

possui ordem menor.

Em ambos os casos, os valores próprios positivos são os mesmos e correspondem aos quadrados dos valores singulares de $\mathbf{X}$.

6.5.5 Representação exata das observações

Proposição 6.12 (Preservação da geometria pelas coordenadas singulares). *Seja*

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

a SVD compacta de uma matriz de dados e defina

$$\mathbf{Z} = \mathbf{X}\mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r.$$

Então,

$$\mathbf{X} = \mathbf{Z}\mathbf{V}_r^\top$$

e

$$\mathbf{Z}\mathbf{Z}^\top = \mathbf{X}\mathbf{X}^\top.$$

Consequentemente, para quaisquer observações $\mathbf{x}_i$ e $\mathbf{x}_\ell$, com coordenadas correspondentes $\mathbf{z}_i$ e $\mathbf{z}_\ell$,

$$\mathbf{x}_i^\top \mathbf{x}_\ell = \mathbf{z}_i^\top \mathbf{z}_\ell,$$

$$\|\mathbf{x}_i\| = \|\mathbf{z}_i\|$$

e

$$\|\mathbf{x}_i - \mathbf{x}_\ell\| = \|\mathbf{z}_i - \mathbf{z}_\ell\|.$$

Comprovação. Como

$$\mathbf{Z} = \mathbf{U}_r \mathbf{D}_r,$$

segue da SVD compacta que

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top = \mathbf{Z} \mathbf{V}_r^\top.$$

Além disso,

$$\begin{aligned} \mathbf{Z} \mathbf{Z}^\top &= \mathbf{U}_r \mathbf{D}_r \mathbf{D}_r \mathbf{U}_r^\top \\ &= \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top. \end{aligned}$$

Pela Proposição 6.4,

$$\mathbf{X} \mathbf{X}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

Portanto,

$$\mathbf{Z} \mathbf{Z}^\top = \mathbf{X} \mathbf{X}^\top.$$

Os elementos dessas duas matrizes são os produtos internos entre pares de observações. Logo,

$$\mathbf{x}_i^\top \mathbf{x}_\ell = \mathbf{z}_i^\top \mathbf{z}_\ell.$$

Tomando $i = \ell$, obtém-se

$$\|\mathbf{x}_i\|^2 = \|\mathbf{z}_i\|^2.$$

Finalmente,

$$\begin{aligned}
\|\mathbf{x}_i - \mathbf{x}_\ell\|^2 &= \|\mathbf{x}_i\|^2 + \|\mathbf{x}_\ell\|^2 - 2\mathbf{x}_i^\top \mathbf{x}_\ell \\
&= \|\mathbf{z}_i\|^2 + \|\mathbf{z}_\ell\|^2 - 2\mathbf{z}_i^\top \mathbf{z}_\ell \\
&= \|\mathbf{z}_i - \mathbf{z}_\ell\|^2.
\end{aligned}$$

□

A reconstrução de cada observação pode ser escrita como

$$\mathbf{x}_i = \sum_{j=1}^r z_{ij} \mathbf{v}_j.$$

Portanto,

$$\mathbf{x}_i \in \mathcal{C}(\mathbf{V}_r) \subseteq \mathbb{R}^p.$$

Se

$$r < p,$$

as observações podem ser representadas exatamente por apenas r coordenadas, sem alteração de seus produtos internos, normas ou distâncias euclidianas.

Essa situação pode ocorrer mesmo quando $\mathbf{X}$ possui o maior posto possível para suas dimensões. Por exemplo, se

$$n < p$$

e

$$r = n,$$

a matriz possui posto linha completo, mas ainda assim

$$r < p.$$

Nesse caso, as observações ocupam um subespaço de dimensão r dentro de $\mathbb{R}^p$ e sua representação por $\mathbf{Z}$ é exata.

6.5.6 Centralização da matriz de dados

A posição da nuvem depende de seu centro. Para estudar os afastamentos em relação ao vetor de médias, utiliza-se a matriz centralizada

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X},$$

em que

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

Proposição 6.13 (Vetores singulares à esquerda de uma matriz centralizada). *Se*

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de dados centralizada, então

$$\mathbf{1}_n^\top \mathbf{U}_r = \mathbf{0}^\top.$$

Consequentemente,

$$\mathbf{1}_n^\top \mathbf{u}_j = 0, \quad j = 1, \dots, r,$$

e as colunas da matriz de coordenadas

$$\mathbf{Z} = \mathbf{X}_c \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r$$

também possuem média igual a zero.

Comprovação. Como as colunas de $\mathbf{X}_c$ estão centralizadas,

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{0}^\top.$$

Substituindo a SVD compacta,

$$\mathbf{1}_n^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top = \mathbf{0}^\top.$$

Como $\mathbf{D}_r$ é invertível e $\mathbf{V}_r$ possui colunas ortonormais, segue que

$$\mathbf{1}_n^\top \mathbf{U}_r = \mathbf{0}^\top.$$

Portanto,

$$\mathbf{1}_n^\top \mathbf{u}_j = 0, \quad j = 1, \dots, r.$$

Como

$$\mathbf{z}_j = d_j \mathbf{u}_j,$$

tem-se também

$$\mathbf{1}_n^\top \mathbf{z}_j = 0.$$

□

6.5.7 Antecipação: relação com a matriz de covariâncias amostral

A definição estatística e as propriedades da matriz de covariâncias amostral serão desenvolvidas nos capítulos posteriores dedicados à covariância e às estatísticas amostrais. Neste ponto, interessa apenas sua relação algébrica com a SVD da matriz centralizada.

Para $n \geq 2$, adotando temporariamente a notação

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c,$$

obtém-se o seguinte resultado.

Proposição 6.14 (Relação entre a SVD e a covariância amostral). *Se*

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta da matriz de dados centralizada, então

$$\mathbf{S} = \mathbf{V}_r \left(\frac{\mathbf{D}_r^2}{n-1} \right) \mathbf{V}_r^\top.$$

Consequentemente:

- os vetores singulares à direita de $\mathbf{X}_c$ são autovetores de $\mathbf{S}$ associados aos autovalores positivos;
- os autovalores positivos de $\mathbf{S}$ são

$$\lambda_j = \frac{d_j^2}{n-1}, \quad j = 1, \dots, r;$$

- tem-se

$$\text{posto}(\mathbf{S}) = \text{posto}(\mathbf{X}_c) = r.$$

Comprovação. Substituindo a SVD compacta,

$$\begin{aligned} \mathbf{S} &= \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c \\ &= \frac{1}{n-1} \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \mathbf{V}_r \left(\frac{\mathbf{D}_r^2}{n-1} \right) \mathbf{V}_r^\top, \end{aligned}$$

pois

$$\mathbf{U}_r^\top \mathbf{U}_r = \mathbf{I}_r.$$

A expressão obtida é uma decomposição espectral de $\mathbf{S}$ em seu subespaço associado aos autovalores positivos. Portanto, os autovetores correspondentes são as colunas de $\mathbf{V}_r$ e os autovalores positivos são

$$\frac{d_j^2}{n-1}.$$

Como $\mathbf{D}_r$ possui exatamente r elementos diagonais positivos,

$$\text{posto}(\mathbf{S}) = r.$$

□

A centralização impõe ainda uma restrição ao posto. Como

$$\text{posto}(\mathbf{H}_n) = n - 1,$$

tem-se

$$\text{posto}(\mathbf{X}_c) \leq \min(n - 1, p).$$

Consequentemente,

$$\text{posto}(\mathbf{S}) \leq \min(n - 1, p).$$

Em particular, se

$$p \geq n,$$

então

$$\text{posto}(\mathbf{S}) \leq n - 1 < p,$$

e a matriz de covariâncias amostral é necessariamente singular.

Essas relações serão retomadas posteriormente em sua formulação estatística. Aqui, elas mostram que a SVD da matriz centralizada determina diretamente a estrutura espectral da matriz de covariâncias amostral.

6.5.8 Magnitude quadrática da matriz centralizada

Proposição 6.15 (Magnitude quadrática da nuvem centralizada). *Se*

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta da matriz de dados centralizada, então

$$\|\mathbf{X}_c\|_F^2 = \sum_{j=1}^r d_j^2.$$

Além disso, se

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c,$$

então

$$\|\mathbf{X}_c\|_F^2 = (n-1) \operatorname{tr}(\mathbf{S}).$$

Consequentemente,

$$\sum_{j=1}^r d_j^2 = (n-1) \operatorname{tr}(\mathbf{S}).$$

Comprovação. Pela Proposição 6.9,

$$\|\mathbf{X}_c\|_F^2 = \sum_{j=1}^r d_j^2.$$

Por outro lado,

$$\mathbf{X}_c^\top \mathbf{X}_c = (n-1) \mathbf{S}.$$

Logo,

$$\begin{aligned} \|\mathbf{X}_c\|_F^2 &= \operatorname{tr}(\mathbf{X}_c^\top \mathbf{X}_c) \\ &= (n-1) \operatorname{tr}(\mathbf{S}). \end{aligned}$$

□

Se

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

é o vetor de médias das observações, então

$$\|\mathbf{X}_c\|_F^2 = \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2.$$

Portanto,

$$\sum_{j=1}^r d_j^2 = \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2.$$

A soma dos quadrados dos valores singulares da matriz centralizada representa, assim, a soma quadrática total dos afastamentos das observações em relação ao centro da nuvem.

Como $\text{tr}(\mathbf{S})$ é a soma dos elementos diagonais de $\mathbf{S}$, ela corresponde à soma das variâncias amostrais das p variáveis.

A centralização é essencial para essa interpretação. Para uma matriz não centralizada,

$$\|\mathbf{X}\|_F^2 = \sum_{i=1}^n \|\mathbf{x}_i\|^2$$

mede a soma dos quadrados das posições em relação à origem, e não a dispersão das observações em torno de seu vetor de médias.

Exemplo 6.7 (Coordenadas singulares de uma matriz de dados). Considere a matriz

$$\mathbf{X} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix},$$

cuja SVD compacta é

$$\mathbf{X} = \mathbf{U}_2 \mathbf{D}_2 \mathbf{V}_2^\top,$$

com

$$\mathbf{U}_2 = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 0 & 1 \\ 1/\sqrt{2} & 0 \end{bmatrix},$$

$$\mathbf{D}_2 = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix}$$

e

$$\mathbf{V}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

As coordenadas das observações nas direções singulares à direita são

$$\begin{aligned}\mathbf{Z} &= \mathbf{X}\mathbf{V}_2 \\ &= \mathbf{U}_2\mathbf{D}_2 \\ &= \begin{bmatrix} \sqrt{2} & 0 \\ 0 & \sqrt{2} \\ \sqrt{2} & 0 \end{bmatrix}.\end{aligned}$$

A primeira e a terceira observações possuem as mesmas coordenadas, pois suas linhas originais são iguais.

Além disso,

$$\mathbf{Z}\mathbf{Z}^\top = \begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & 0 \\ 2 & 0 & 2 \end{bmatrix} = \mathbf{X}\mathbf{X}^\top.$$

Portanto, os produtos internos e as distâncias entre as observações são preservados pela representação nas duas direções singulares positivas.

Nesse exemplo,

$$r = p = 2.$$

Por isso, a transformação por $\mathbf{V}_2$ representa apenas uma mudança ortogonal de coordenadas no espaço das observações. Não ocorre redução exata da dimensão.

Se o posto fosse menor que p , a representação por $\mathbf{Z}$ utilizaria menos colunas que a matriz original e ainda preservaria exatamente a geometria da nuvem.

6.5.9 Representação exata e aproximação

A SVD compacta fornece a representação exata

$$\mathbf{X} = \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top.$$

Como todos os r componentes associados a valores singulares positivos são mantidos:

- a matriz é reconstruída exatamente;
- os produtos internos entre as observações são preservados;
- as normas das observações são preservadas;
- as distâncias euclidianas entre as observações são preservadas;

- nenhuma parcela da norma de Frobenius é descartada.

Uma representação de dimensão menor pode ser construída conservando apenas os primeiros k pares singulares, com

$$k < r.$$

Nesse caso, componentes associados a valores singulares positivos são deliberadamente descartados e a reconstrução deixa de ser exata.

A distinção fundamental é, portanto:

- a **SVD compacta** omite dos fatores completos apenas direções associadas à parte nula da transformação e preserva exatamente a matriz;
- a **SVD truncada** descarta também componentes associados a valores singulares positivos e produz uma aproximação.

A forma expandida da SVD permitirá identificar separadamente a contribuição de cada componente singular e quantificar o erro produzido pelo truncamento.

6.6 Forma expandida e aproximações de posto reduzido

A SVD compacta também pode ser expressa como uma soma de componentes matriciais associados aos pares singulares.

Proposição 6.16 (Forma expandida da SVD). *Se*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de posto r , então

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Cada parcela

$$d_j \mathbf{u}_j \mathbf{v}_j^\top$$

possui posto 1 e satisfaz

$$\|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_2 = \|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_F = d_j.$$

Comprovação. Escrevendo

$$\mathbf{U}_r = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r],$$

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r)$$

e

$$\mathbf{V}_r = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_r],$$

tem-se

$$\begin{aligned} \mathbf{A} &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top. \end{aligned}$$

Como $\mathbf{u}_j$ e $\mathbf{v}_j$ são não nulos,

$$\text{posto}(\mathbf{u}_j \mathbf{v}_j^\top) = 1.$$

Multiplicar por $d_j > 0$ não altera o posto, de modo que

$$\text{posto}(d_j \mathbf{u}_j \mathbf{v}_j^\top) = 1.$$

Para a norma espectral, se $\|\mathbf{x}\| = 1$,

$$\begin{aligned} \|d_j \mathbf{u}_j \mathbf{v}_j^\top \mathbf{x}\| &= d_j |\mathbf{v}_j^\top \mathbf{x}| \|\mathbf{u}_j\| \\ &\leq d_j. \end{aligned}$$

A igualdade é atingida para

$$\mathbf{x} = \mathbf{v}_j.$$

Portanto,

$$\|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_2 = d_j.$$

Para a norma de Frobenius,

$$\begin{aligned}\|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_F^2 &= d_j^2 \operatorname{tr}(\mathbf{v}_j \mathbf{u}_j^\top \mathbf{u}_j \mathbf{v}_j^\top) \\ &= d_j^2 (\mathbf{u}_j^\top \mathbf{u}_j) (\mathbf{v}_j^\top \mathbf{v}_j) \\ &= d_j^2.\end{aligned}$$

Logo,

$$\|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_F = d_j.$$

□

A expressão

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top$$

é denominada **forma expandida da SVD**.

Cada componente singular representa uma transformação de posto 1: a componente do vetor de entrada na direção $\mathbf{v}_j$ é multiplicada por d_j e enviada para a direção $\mathbf{u}_j$.

Como

$$d_1 \geq d_2 \geq \dots \geq d_r > 0,$$

os componentes singulares estão ordenados de acordo com suas magnitudes nas normas espectral e de Frobenius.

6.6.1 Ortogonalidade dos componentes singulares

Proposição 6.17 (Ortogonalidade dos componentes singulares). *Para*

$$i \neq j,$$

os componentes singulares

$$d_i \mathbf{u}_i \mathbf{v}_i^\top$$

e

$$d_j \mathbf{u}_j \mathbf{v}_j^\top$$

são ortogonais segundo o produto interno de Frobenius:

$$\left\langle d_i \mathbf{u}_i \mathbf{v}_i^\top, d_j \mathbf{u}_j \mathbf{v}_j^\top \right\rangle_F = 0.$$

Comprovação. Pelo produto interno de Frobenius,

$$\begin{aligned} \left\langle d_i \mathbf{u}_i \mathbf{v}_i^\top, d_j \mathbf{u}_j \mathbf{v}_j^\top \right\rangle_F &= d_i d_j \operatorname{tr} \left[(\mathbf{u}_i \mathbf{v}_i^\top)^\top (\mathbf{u}_j \mathbf{v}_j^\top) \right] \\ &= d_i d_j (\mathbf{u}_i^\top \mathbf{u}_j) (\mathbf{v}_j^\top \mathbf{v}_i). \end{aligned}$$

Como os vetores singulares são ortonormais, para $i \neq j$,

$$\mathbf{u}_i^\top \mathbf{u}_j = 0$$

e

$$\mathbf{v}_i^\top \mathbf{v}_j = 0.$$

Logo,

$$\left\langle d_i \mathbf{u}_i \mathbf{v}_i^\top, d_j \mathbf{u}_j \mathbf{v}_j^\top \right\rangle_F = 0.$$

□

Como a forma expandida é uma soma de componentes ortogonais segundo o produto interno de Frobenius,

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

Essa igualdade fornece uma decomposição pitagórica da magnitude quadrática total da matriz entre seus componentes singulares.

6.6.2 SVD truncada na forma expandida

Retomando a Definição 6.5, a aproximação de posto k pode ser expressa diretamente a partir da forma expandida da SVD.

Se

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

então

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top, \quad 1 \leq k < r.$$

Equivalentemente,

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Assim, truncar a SVD corresponde a conservar as primeiras k parcelas singulares e descartar

$$\sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Essa representação permitirá quantificar o erro produzido pelo truncamento e estabelecer as propriedades de otimalidade de $\mathbf{A}_k$.

Como as colunas de $\mathbf{U}_k$ e $\mathbf{V}_k$ são linearmente independentes e os elementos diagonais de $\mathbf{D}_k$ são positivos,

$$\text{posto}(\mathbf{A}_k) = k.$$

A diferença entre a matriz original e sua aproximação é

$$\mathbf{A} - \mathbf{A}_k = \sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

A matriz $\mathbf{A}_k$ conserva as direções associadas aos k maiores valores singulares. A diferença reúne as direções descartadas.

6.6.3 Erros produzidos pelo truncamento

Proposição 6.18 (Decomposição e erros da SVD truncada). *Se*

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top, \quad 1 \leq k < r,$$

então

$$\mathbf{A} - \mathbf{A}_k = \sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Além disso,

$$\langle \mathbf{A}_k, \mathbf{A} - \mathbf{A}_k \rangle_F = 0,$$

$$\|\mathbf{A}_k\|_F^2 = \sum_{j=1}^k d_j^2,$$

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2$$

e

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1}.$$

Consequentemente,

$$\|\mathbf{A}\|_F^2 = \|\mathbf{A}_k\|_F^2 + \|\mathbf{A} - \mathbf{A}_k\|_F^2.$$

Comprovação. Pela forma expandida,

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Subtraindo

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

obtém-se

$$\mathbf{A} - \mathbf{A}_k = \sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Pela Proposição 6.17, os componentes associados a índices diferentes são ortogonais segundo o produto interno de Frobenius. Como $\mathbf{A}_k$ utiliza os índices

$$1, \dots, k$$

e a diferença utiliza

$$k+1, \dots, r,$$

segue que

$$\langle \mathbf{A}_k, \mathbf{A} - \mathbf{A}_k \rangle_F = 0.$$

Aplicando a decomposição pitagórica,

$$\|\mathbf{A}_k\|_F^2 = \sum_{j=1}^k d_j^2$$

e

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

Portanto,

$$\|\mathbf{A}\|_F^2 = \|\mathbf{A}_k\|_F^2 + \|\mathbf{A} - \mathbf{A}_k\|_F^2.$$

Por outro lado, a matriz residual

$$\mathbf{A} - \mathbf{A}_k$$

possui valores singulares positivos

$$d_{k+1}, d_{k+2}, \dots, d_r.$$

Pela Proposição 6.9, sua norma espectral é igual ao maior desses valores:

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1}.$$

□

A proporção da magnitude quadrática de Frobenius preservada pela aproximação pode ser escrita como

$$\eta_k = \frac{\|\mathbf{A}_k\|_F^2}{\|\mathbf{A}\|_F^2} = \frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2}.$$

A proporção descartada é

$$1 - \eta_k = \frac{\|\mathbf{A} - \mathbf{A}_k\|_F^2}{\|\mathbf{A}\|_F^2} = \frac{\sum_{j=k+1}^r d_j^2}{\sum_{j=1}^r d_j^2}.$$

Para uma matriz genérica, η_k mede exclusivamente a proporção de sua magnitude quadrática, segundo a norma de Frobenius, representada pelos primeiros k componentes singulares. Essa quantidade não deve ser interpretada automaticamente como proporção de variância ou de informação estatística.

Quando $\mathbf{A}$ é uma matriz de dados centralizada, entretanto,

$$\|\mathbf{A}\|_F^2$$

corresponde à soma quadrática total dos afastamentos das observações em relação ao centro da nuvem. Nesse contexto específico, η_k representa a proporção dessa dispersão quadrática preservada pelos primeiros k componentes singulares.

A norma espectral descreve outro aspecto do erro. Como

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1},$$

o primeiro valor singular descartado determina o maior erro produzido pelo truncamento sobre qualquer vetor unitário:

$$d_{k+1} = \max_{\|\mathbf{x}\|=1} \|(\mathbf{A} - \mathbf{A}_k) \mathbf{x}\|.$$

Esse máximo é atingido, por exemplo, na direção

$$\mathbf{v}_{k+1},$$

pois

$$(\mathbf{A} - \mathbf{A}_k) \mathbf{v}_{k+1} = d_{k+1} \mathbf{u}_{k+1}.$$

Assim, a norma espectral mede um erro de pior caso, enquanto a norma de Frobenius agrega quadraticamente os erros associados a todos os componentes singulares descartados.

6.6.4 Teorema de Eckart–Young–Mirsky

A SVD truncada não é somente uma forma conveniente de produzir uma matriz de posto menor. Ela fornece uma aproximação ótima.

Teorema 6.2 (Teorema de Eckart–Young–Mirsky). *Seja*

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

uma matriz de posto r , com valores singulares

$$d_1 \geq \dots \geq d_r > 0.$$

Para

$$1 \leq k < r,$$

defina

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Então $\mathbf{A}_k$ é uma solução dos problemas

$$\min_{\text{posto}(\tilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \tilde{\mathbf{A}}\|_2$$

e

$$\min_{\text{posto}(\tilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \tilde{\mathbf{A}}\|_F.$$

Os erros mínimos são

$$\min_{\text{posto}(\tilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \tilde{\mathbf{A}}\|_2 = d_{k+1}$$

e

$$\min_{\text{posto}(\tilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \tilde{\mathbf{A}}\|_F = \sqrt{\sum_{j=k+1}^r d_j^2}.$$

(Golub; Van Loan, 2013)

6.6.5 Aprofundamento: demonstração e unicidade da melhor aproximação

Leitura de aprofundamento

O Teorema de Eckart–Young–Mirsky estabelece a otimalidade da SVD truncada sem exigir que sua demonstração seja utilizada nas aplicações posteriores.

Nesta leitura de aprofundamento, demonstra-se a otimalidade separadamente nas normas espectral e de Frobenius e examina-se quando a melhor aproximação de posto reduzido é ou não única.

Comprovação. Considere inicialmente a norma espectral e uma matriz arbitrária

$$\tilde{\mathbf{A}}$$

com

$$\text{posto}(\tilde{\mathbf{A}}) \leq k.$$

Defina o subespaço

$$\mathcal{S}_{k+1} = \text{span} \{ \mathbf{v}_1, \dots, \mathbf{v}_{k+1} \}.$$

Como

$$\dim(\mathcal{S}_{k+1}) = k + 1$$

e a restrição de $\widetilde{\mathbf{A}}$ a esse subespaço possui imagem de dimensão no máximo k , existe um vetor unitário

$$\mathbf{x} \in \mathcal{S}_{k+1}$$

tal que

$$\widetilde{\mathbf{A}}\mathbf{x} = \mathbf{0}.$$

Escreva

$$\mathbf{x} = \sum_{j=1}^{k+1} \alpha_j \mathbf{v}_j,$$

com

$$\sum_{j=1}^{k+1} \alpha_j^2 = 1.$$

Então,

$$\begin{aligned} \left\| (\mathbf{A} - \widetilde{\mathbf{A}}) \mathbf{x} \right\|^2 &= \|\mathbf{A}\mathbf{x}\|^2 \\ &= \sum_{j=1}^{k+1} d_j^2 \alpha_j^2 \\ &\geq d_{k+1}^2 \sum_{j=1}^{k+1} \alpha_j^2 \\ &= d_{k+1}^2. \end{aligned}$$

Logo,

$$\left\| \mathbf{A} - \widetilde{\mathbf{A}} \right\|_2 \geq d_{k+1}.$$

Para a SVD truncada,

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1}.$$

Portanto, $\mathbf{A}_k$ atinge o limite inferior e é uma solução ótima na norma espectral.

Para a norma de Frobenius, considere o projetor ortogonal

$$\mathbf{P}$$

sobre o espaço coluna de $\tilde{\mathbf{A}}$. Como

$$\text{posto}(\tilde{\mathbf{A}}) \leq k,$$

tem-se

$$\text{posto}(\mathbf{P}) \leq k.$$

Além disso,

$$\mathbf{P}\tilde{\mathbf{A}} = \tilde{\mathbf{A}}.$$

A diferença pode ser decomposta como

$$\mathbf{A} - \tilde{\mathbf{A}} = (\mathbf{I}_q - \mathbf{P}) \mathbf{A} + (\mathbf{P}\mathbf{A} - \tilde{\mathbf{A}}).$$

As duas parcelas são ortogonais segundo o produto interno de Frobenius, pois a primeira possui colunas no complemento ortogonal de $\mathcal{C}(\mathbf{P})$, enquanto a segunda possui colunas em $\mathcal{C}(\mathbf{P})$.

Assim,

$$\begin{aligned} \|\mathbf{A} - \tilde{\mathbf{A}}\|_F^2 &= \|(\mathbf{I}_q - \mathbf{P}) \mathbf{A}\|_F^2 \\ &\quad + \|\mathbf{P}\mathbf{A} - \tilde{\mathbf{A}}\|_F^2 \\ &\geq \|(\mathbf{I}_q - \mathbf{P}) \mathbf{A}\|_F^2. \end{aligned}$$

A primeira parcela pode ser escrita como

$$\|(\mathbf{I}_q - \mathbf{P}) \mathbf{A}\|_F^2 = \|\mathbf{A}\|_F^2 - \|\mathbf{P}\mathbf{A}\|_F^2.$$

Considere uma base ortonormal

$$\mathbf{w}_1, \dots, \mathbf{w}_s, \quad s \leq k,$$

do espaço projetado por $\mathbf{P}$. Então,

$$\mathbf{P} = \sum_{i=1}^s \mathbf{w}_i \mathbf{w}_i^\top$$

e

$$\begin{aligned} \|\mathbf{PA}\|_F^2 &= \text{tr}(\mathbf{PAA}^\top) \\ &= \sum_{i=1}^s \mathbf{w}_i^\top \mathbf{AA}^\top \mathbf{w}_i. \end{aligned}$$

Usando a decomposição espectral

$$\mathbf{AA}^\top = \sum_{j=1}^r d_j^2 \mathbf{u}_j \mathbf{u}_j^\top,$$

tem-se

$$\begin{aligned} \|\mathbf{PA}\|_F^2 &= \text{tr}(\mathbf{PAA}^\top) \\ &= \sum_{j=1}^r d_j^2 \text{tr}(\mathbf{Pu}_j \mathbf{u}_j^\top) \\ &= \sum_{j=1}^r d_j^2 \mathbf{u}_j^\top \mathbf{Pu}_j. \end{aligned}$$

Defina

$$c_j = \mathbf{u}_j^\top \mathbf{Pu}_j = \|\mathbf{Pu}_j\|^2.$$

Como $\mathbf{P}$ é um projetor ortogonal,

$$0 \leq c_j \leq 1.$$

Além disso,

$$\begin{aligned}
\sum_{j=1}^r c_j &= \sum_{j=1}^r \mathbf{u}_j^\top \mathbf{P} \mathbf{u}_j \\
&\leq \text{tr}(\mathbf{P}) \\
&= \text{posto}(\mathbf{P}) \\
&\leq k.
\end{aligned}$$

Portanto,

$$\|\mathbf{P}\mathbf{A}\|_F^2 = \sum_{j=1}^r c_j d_j^2,$$

com

$$0 \leq c_j \leq 1$$

e

$$\sum_{j=1}^r c_j \leq k.$$

Como os valores singulares estão ordenados, sob as restrições,

$$0 \leq c_j \leq 1 \quad \text{e} \quad \sum_j c_j \leq k,$$

a soma ponderada é maximizada atribuindo peso 1 aos k maiores valores d_j^2 e peso 0 aos demais. Como

$$d_1^2 \geq \dots \geq d_r^2,$$

segue que

$$\|\mathbf{P}\mathbf{A}\|_F^2 \leq \sum_{j=1}^k d_j^2.$$

Portanto,

$$\begin{aligned}\|\mathbf{A} - \widetilde{\mathbf{A}}\|_F^2 &\geq \|\mathbf{A}\|_F^2 - \sum_{j=1}^k d_j^2 \\ &= \sum_{j=k+1}^r d_j^2.\end{aligned}$$

Para

$$\mathbf{P} = \mathbf{U}_k \mathbf{U}_k^\top,$$

tem-se

$$\mathbf{P}\mathbf{A} = \mathbf{A}_k.$$

Além disso,

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

Logo, $\mathbf{A}_k$ também atinge o limite inferior na norma de Frobenius. $\square$

O teorema mostra que nenhuma matriz de posto no máximo k pode apresentar erro menor que $\mathbf{A}_k$ nas duas normas consideradas.

Na norma espectral, o erro ótimo é determinado exclusivamente pelo primeiro valor singular descartado,

$$d_{k+1}.$$

Na norma de Frobenius, o erro ótimo depende de toda a parcela espectral descartada,

$$\sqrt{\sum_{j=k+1}^r d_j^2}.$$

6.6.5.1 Unicidade da aproximação

A otimalidade estabelecida pelo Teorema 6.2 não implica, em geral, que a matriz aproximante seja única. A situação depende também da norma considerada.

Na norma de Frobenius, a melhor aproximação de posto no máximo k é única quando há separação estrita entre os valores singulares que ficam em lados opostos do truncamento:

$$d_k > d_{k+1}.$$

Se

$$d_k = d_{k+1},$$

o ponto de truncamento atravessa um subespaço singular associado a um valor repetido. Nesse caso, diferentes escolhas de subespaços dentro desse bloco singular podem produzir aproximações ótimas distintas.

Na norma espectral, a matriz

$$\mathbf{A}_k$$

é sempre uma aproximação ótima, mas a aproximação ótima pode não ser única mesmo quando

$$d_k > d_{k+1}.$$

Isso ocorre porque outras matrizes de posto no máximo k podem produzir o mesmo erro máximo

$$d_{k+1}.$$

Portanto, a condição

$$d_k > d_{k+1}$$

garante unicidade da melhor aproximação na norma de Frobenius, mas não deve ser utilizada como critério geral de unicidade na norma espectral.

Quando

$$k \geq r,$$

não há truncamento de componentes singulares positivos e a representação exata é

$$\mathbf{A}_k = \mathbf{A},$$

com erro igual a zero.

6.6.6 Exemplo de aproximação de posto 1

Exemplo 6.8 (Aproximação de posto 1 do exemplo condutor). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

Sua forma expandida é

$$\mathbf{A} = 2\mathbf{u}_1\mathbf{v}_1^\top + \sqrt{2}\mathbf{u}_2\mathbf{v}_2^\top,$$

em que

$$\mathbf{u}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \quad \mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

e

$$\mathbf{u}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A aproximação de posto 1 é

$$\begin{aligned}
\mathbf{A}_1 &= 2\mathbf{u}_1\mathbf{v}_1^\top \\
&= 2\left(\frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}\right)\left(\frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \end{bmatrix}\right) \\
&= \begin{bmatrix} 1 & 1 \\ 0 & 0 \\ 1 & 1 \end{bmatrix}.
\end{aligned}$$

A diferença entre a matriz original e a aproximação é

$$\mathbf{A} - \mathbf{A}_1 = \begin{bmatrix} 0 & 0 \\ 1 & -1 \\ 0 & 0 \end{bmatrix}.$$

Como

$$d_1 = 2$$

e

$$d_2 = \sqrt{2},$$

o erro espectral é

$$\|\mathbf{A} - \mathbf{A}_1\|_2 = \sqrt{2}.$$

O erro de Frobenius também é

$$\|\mathbf{A} - \mathbf{A}_1\|_F = \sqrt{2},$$

pois somente um valor singular foi descartado.

A magnitude quadrática total é

$$\|\mathbf{A}\|_F^2 = 2^2 + (\sqrt{2})^2 = 6.$$

A aproximação preserva

$$\|\mathbf{A}_1\|_F^2 = 2^2 = 4.$$

Portanto, a proporção preservada é

$$\frac{\|\mathbf{A}_1\|_F^2}{\|\mathbf{A}\|_F^2} = \frac{4}{6} = \frac{2}{3}.$$

A primeira parcela reproduz exatamente a primeira e a terceira linhas da matriz. A segunda linha está inteiramente associada à direção singular descartada.

Neste exemplo, as normas espectral e de Frobenius do erro coincidem porque a matriz residual possui apenas um valor singular positivo. Quando mais de um componente singular é descartado, os dois erros são, em geral, diferentes.

6.6.7 Aproximação de uma matriz de dados

A SVD truncada possui uma interpretação direta como projeção das observações em um subespaço de menor dimensão.

Proposição 6.19 (SVD truncada como projeção das observações). *Se*

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de dados e

$$1 \leq k < r,$$

então sua aproximação truncada satisfaz

$$\mathbf{X}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top = \mathbf{X} \mathbf{V}_k \mathbf{V}_k^\top.$$

Como

$$\mathbf{P}_k = \mathbf{V}_k \mathbf{V}_k^\top$$

é o projetor ortogonal sobre

$$\mathcal{S}_k = \text{span} \{ \mathbf{v}_1, \dots, \mathbf{v}_k \},$$

cada linha de $\mathbf{X}_k$ é a projeção ortogonal da observação correspondente sobre $\mathcal{S}_k$.

Se

$$\mathbf{Z}_k = \mathbf{X}\mathbf{V}_k,$$

então

$$\mathbf{Z}_k = \mathbf{U}_k\mathbf{D}_k$$

e

$$\mathbf{X}_k = \mathbf{Z}_k\mathbf{V}_k^\top.$$

Comprovação. Pela relação

$$\mathbf{X}\mathbf{V}_k = \mathbf{U}_k\mathbf{D}_k,$$

tem-se

$$\begin{aligned}\mathbf{X}\mathbf{V}_k\mathbf{V}_k^\top &= \mathbf{U}_k\mathbf{D}_k\mathbf{V}_k^\top \\ &= \mathbf{X}_k.\end{aligned}$$

Como as colunas de $\mathbf{V}_k$ são ortonormais,

$$\mathbf{P}_k = \mathbf{V}_k\mathbf{V}_k^\top$$

é o projetor ortogonal sobre $\mathcal{S}_k$.

Portanto, para cada observação $\mathbf{x}_i$,

$$\hat{\mathbf{x}}_{i,k} = \mathbf{P}_k\mathbf{x}_i$$

e, equivalentemente,

$$\hat{\mathbf{x}}_{i,k} = \sum_{j=1}^k z_{ij}\mathbf{v}_j.$$

O resíduo correspondente é

$$\mathbf{x}_i - \hat{\mathbf{x}}_{i,k} = \sum_{j=k+1}^r z_{ij}\mathbf{v}_j.$$

□

A matriz

$$\mathbf{Z}_k \in \mathbb{R}^{n \times k}$$

fornece uma representação das observações em k coordenadas. A multiplicação por

$$\mathbf{V}_k^\top$$

reconstrói suas aproximações no espaço original $\mathbb{R}^p$.

Além disso,

$$\|\mathbf{X} - \mathbf{X}_k\|_F^2 = \sum_{i=1}^n \|\mathbf{x}_i - \hat{\mathbf{x}}_{i,k}\|^2 = \sum_{j=k+1}^r d_j^2.$$

Pelo Teorema 6.2, nenhuma matriz de posto no máximo k possui erro de reconstrução menor na norma de Frobenius. Em particular, entre as representações obtidas pela projeção das observações em subespaços lineares de dimensão no máximo k , o subespaço

$$\mathcal{S}_k = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$$

minimiza a soma dos erros quadráticos de reconstrução.

Quando $\mathbf{X}$ está centralizada,

$$\frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2}$$

representa a proporção da dispersão quadrática total da nuvem preservada pelas primeiras k direções singulares.

Essa relação será retomada posteriormente na formulação de técnicas de redução de dimensionalidade. Neste capítulo, ela deve ser interpretada como uma propriedade geral da aproximação matricial de posto reduzido.

A SVD truncada e a pseudoinversa utilizam os mesmos componentes singulares com finalidades distintas.

Na aproximação de posto reduzido, componentes associados a valores singulares positivos são deliberadamente descartados:

$$\mathbf{A} \longrightarrow \mathbf{A}_k.$$

Na pseudoinversa, todos os componentes associados a valores singulares positivos são mantidos, mas os fatores de escala são invertidos:

$$d_j \longrightarrow \frac{1}{d_j}, \quad j = 1, \dots, r.$$

As direções associadas à parte nula da transformação não são invertidas.

Essa construção conduz à pseudoinversa de Moore–Penrose e, a partir dela, às soluções de sistemas lineares e problemas de mínimos quadrados.

6.7 Pseudoinversa e soluções de mínimos quadrados

A inversa usual é definida somente para matrizes quadradas e invertíveis. A SVD permite construir uma transformação inversa generalizada para qualquer matriz real, inclusive matrizes:

- retangulares;
- singulares;
- deficientes em posto.

Essa transformação é a **pseudoinversa de Moore–Penrose**.

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com posto

$$r = \text{posto}(\mathbf{A})$$

e SVD compacta

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

Se $r \geq 1$, todos os elementos diagonais de

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r)$$

são positivos. Portanto,

$$\mathbf{D}_r^{-1} = \text{diag} \left(\frac{1}{d_1}, \dots, \frac{1}{d_r} \right)$$

está bem definida.

Se $r = 0$, então $\mathbf{A} = \mathbf{0}$ e sua pseudoinversa será definida como a matriz nula de dimensão $p \times q$.

Definição 6.11 (Pseudoinversa de Moore–Penrose). A **pseudoinversa de Moore–Penrose** de

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a matriz

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top.$$

Sua dimensão é

$$\mathbf{A}^+ \in \mathbb{R}^{p \times q}.$$

No caso $\mathbf{A} = \mathbf{0}$, define-se

$$\mathbf{A}^+ = \mathbf{0}_{p \times q}.$$

A pseudoinversa inverte os escalonamentos associados aos valores singulares positivos:

$$\mathbf{A}^+ \mathbf{u}_j = \frac{1}{d_j} \mathbf{v}_j, \quad j = 1, \dots, r.$$

As componentes pertencentes ao núcleo de $\mathbf{A}^\top$ são anuladas. Se

$$\mathbf{u} \in \mathcal{N}(\mathbf{A}^\top),$$

então

$$\mathbf{A}^+ \mathbf{u} = \mathbf{0}.$$

Portanto, a pseudoinversa desfaz os escalonamentos de $\mathbf{A}$ nas direções associadas aos valores singulares positivos e anula as componentes pertencentes a

$$\mathcal{N}(\mathbf{A}^\top).$$

Assim, ela atua como uma inversão entre os subespaços

$$\mathcal{C}(\mathbf{A}^\top) \subseteq \mathbb{R}^p$$

e

$$\mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q,$$

nos quais a ação de $\mathbf{A}$ é não nula.

6.7.1 Relação com a pseudoinversa espectral

No capítulo anterior, a pseudoinversa de uma matriz simétrica foi definida por meio de sua decomposição espectral.

Se

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top,$$

então

$$\mathbf{A}^+ = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^+ \mathbf{Q}_\mathbf{A}^\top,$$

em que cada autovalor não nulo é substituído por seu inverso e os autovalores nulos permanecem iguais a zero.

A definição baseada na SVD,

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top,$$

estende essa construção para qualquer matriz real, inclusive matrizes retangulares e não simétricas.

Quando $\mathbf{A}$ é quadrada e invertível,

$$r = p = q,$$

todos os valores singulares são positivos e

$$\mathbf{A}^+ = \mathbf{A}^{-1}.$$

Portanto, a inversa usual constitui um caso particular da pseudoinversa.

6.7.2 Aprofundamento: caracterização de Moore–Penrose

Leitura de aprofundamento

A pseudoinversa foi definida anteriormente a partir da SVD. Existe também uma caracterização independente dessa decomposição: a pseudoinversa de Moore–Penrose é a única matriz que satisfaz simultaneamente quatro identidades algébricas.

Esta seção apresenta essas condições, verifica que a matriz construída pela SVD as satisfaz e demonstra sua unicidade. A caracterização é importante na teoria de inversas generalizadas, mas não é necessária para acompanhar as aplicações posteriores da pseudoinversa a projeções e mínimos quadrados.

A pseudoinversa é caracterizada por quatro identidades.

Teorema 6.3 (Condições de Moore–Penrose). *Para toda matriz real $\mathbf{A}$, existe uma única matriz $\mathbf{A}^+$ que satisfaz*

$$\mathbf{A}\mathbf{A}^+\mathbf{A} = \mathbf{A},$$

$$\mathbf{A}^+\mathbf{A}\mathbf{A}^+ = \mathbf{A}^+,$$

$$(\mathbf{A}\mathbf{A}^+)^{\top} = \mathbf{A}\mathbf{A}^+,$$

e

$$(\mathbf{A}^+\mathbf{A})^{\top} = \mathbf{A}^+\mathbf{A}.$$

(Golub; Van Loan, 2013)

Comprovação. Considere inicialmente o caso

$$\mathbf{A} = \mathbf{0}.$$

A matriz

$$\mathbf{A}^+ = \mathbf{0}_{p \times q}$$

satisfaz imediatamente as quatro condições de Moore–Penrose.

Além disso, se uma matriz

$$\mathbf{G} \in \mathbb{R}^{p \times q}$$

satisfaz essas condições para $\mathbf{A} = \mathbf{0}$, a segunda condição fornece

$$\mathbf{GAG} = \mathbf{G}.$$

Como $\mathbf{A} = \mathbf{0}$,

$$\mathbf{GAG} = \mathbf{0},$$

e, portanto,

$$\mathbf{G} = \mathbf{0}.$$

Logo, a pseudoinversa também é única nesse caso.

Suponha agora

$$\mathbf{A} \neq \mathbf{0}.$$

Então

$$r = \text{posto}(\mathbf{A}) \geq 1,$$

e, pela SVD compacta,

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

e

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top.$$

Então,

$$\begin{aligned} \mathbf{A} \mathbf{A}^+ \mathbf{A} &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \mathbf{A}. \end{aligned}$$

De modo semelhante,

$$\begin{aligned} \mathbf{A}^+ \mathbf{A} \mathbf{A}^+ &= \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \\ &= \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \\ &= \mathbf{A}^+. \end{aligned}$$

Além disso,

$$\mathbf{A} \mathbf{A}^+ = \mathbf{U}_r \mathbf{U}_r^\top$$

e

$$\mathbf{A}^+ \mathbf{A} = \mathbf{V}_r \mathbf{V}_r^\top,$$

que são matrizes simétricas. Portanto, a matriz definida pela SVD satisfaz as quatro condições de Moore–Penrose.

Para demonstrar a unicidade, suponha que

$$\mathbf{G} \in \mathbb{R}^{p \times q}$$

também satisfaça as quatro condições.

A matriz $\mathbf{A} \mathbf{G}$ é simétrica e

$$\begin{aligned} (\mathbf{A} \mathbf{G})^2 &= \mathbf{A} \mathbf{G} \mathbf{A} \mathbf{G} \\ &= (\mathbf{A} \mathbf{G} \mathbf{A}) \mathbf{G} \\ &= \mathbf{A} \mathbf{G}. \end{aligned}$$

Logo, $\mathbf{A} \mathbf{G}$ é um projetor ortogonal.

Sua imagem está contida em $\mathcal{C}(\mathbf{A})$. Além disso, se

$$\mathbf{y} = \mathbf{A}\mathbf{x} \in \mathcal{C}(\mathbf{A}),$$

então

$$\mathbf{A}\mathbf{G}\mathbf{y} = \mathbf{A}\mathbf{G}\mathbf{A}\mathbf{x} = \mathbf{A}\mathbf{x} = \mathbf{y}.$$

Portanto,

$$\mathbf{A}\mathbf{G} = \mathbf{P}_{\mathcal{C}(\mathbf{A})} = \mathbf{U}_r \mathbf{U}_r^\top.$$

De maneira análoga, $\mathbf{G}\mathbf{A}$ é simétrica e idempotente.

Se

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}),$$

então

$$\mathbf{G}\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Reciprocamente, se

$$\mathbf{G}\mathbf{A}\mathbf{x} = \mathbf{0},$$

então

$$\mathbf{A}\mathbf{x} = \mathbf{A}\mathbf{G}\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Logo,

$$\mathcal{N}(\mathbf{G}\mathbf{A}) = \mathcal{N}(\mathbf{A}).$$

Como $\mathbf{G}\mathbf{A}$ é um projetor ortogonal,

$$\mathbf{G}\mathbf{A} = \mathbf{P}_{\mathcal{N}(\mathbf{A})^\perp} = \mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)} = \mathbf{V}_r \mathbf{V}_r^\top.$$

Da condição

$$\mathbf{GAG} = \mathbf{G},$$

segue que

$$\mathcal{C}(\mathbf{G}) \subseteq \mathcal{C}(\mathbf{GA}) = \mathcal{C}(\mathbf{A}^\top).$$

Considere agora um vetor singular à esquerda $\mathbf{u}_j$, com $j \leq r$. Como

$$\mathbf{u}_j \in \mathcal{C}(\mathbf{A}),$$

tem-se

$$\mathbf{AGu}_j = \mathbf{u}_j.$$

Como

$$\mathbf{Gu}_j \in \mathcal{C}(\mathbf{A}^\top),$$

esse vetor pode ser escrito como

$$\mathbf{Gu}_j = \sum_{\ell=1}^r c_\ell \mathbf{v}_\ell.$$

Aplicando $\mathbf{A}$,

$$\mathbf{u}_j = \sum_{\ell=1}^r c_\ell d_\ell \mathbf{u}_\ell.$$

Pela unicidade das coordenadas na base ortonormal,

$$c_\ell = \begin{cases} 1/d_j, & \ell = j, \\ 0, & \ell \neq j. \end{cases}$$

Portanto,

$$\mathbf{Gu}_j = \frac{1}{d_j} \mathbf{v}_j.$$

Considere, por fim,

$$\mathbf{u} \in \mathcal{N}(\mathbf{A}^\top).$$

Como $\mathbf{A}\mathbf{G}$ projeta sobre $\mathcal{C}(\mathbf{A})$,

$$\mathbf{A}\mathbf{G}\mathbf{u} = \mathbf{0}.$$

Além disso,

$$\mathbf{G}\mathbf{u} \in \mathcal{C}(\mathbf{A}^\top).$$

Como

$$\mathcal{C}(\mathbf{A}^\top) \cap \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

segue que

$$\mathbf{G}\mathbf{u} = \mathbf{0}.$$

Assim, $\mathbf{G}$ atua sobre a base ortonormal formada pelas colunas de $\mathbf{U}_r$ e de $\mathbf{U}_0$ exatamente como

$$\mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top.$$

Logo,

$$\mathbf{G} = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top = \mathbf{A}^+.$$

Portanto, a pseudoinversa de Moore–Penrose existe e é única. □

6.7.3 Pseudoinversa e projetores

Os produtos envolvendo $\mathbf{A}$ e sua pseudoinversa recuperam os projetores ortogonais dos quatro espaços fundamentais.

Proposição 6.20 (Projetores determinados pela pseudoinversa). *Se*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

e

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top,$$

então

$$\mathbf{A}\mathbf{A}^+ = \mathbf{U}_r \mathbf{U}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A})}$$

e

$$\mathbf{A}^+ \mathbf{A} = \mathbf{V}_r \mathbf{V}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)}.$$

Consequentemente,

$$\mathbf{I}_q - \mathbf{A}\mathbf{A}^+ = \mathbf{P}_{\mathcal{N}(\mathbf{A}^\top)}$$

e

$$\mathbf{I}_p - \mathbf{A}^+ \mathbf{A} = \mathbf{P}_{\mathcal{N}(\mathbf{A})}.$$

Comprovação. Pela definição da pseudoinversa,

$$\begin{aligned} \mathbf{A}\mathbf{A}^+ &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \\ &= \mathbf{U}_r \mathbf{U}_r^\top, \end{aligned}$$

pois

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r.$$

Pela Proposição 6.8,

$$\mathbf{U}_r \mathbf{U}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A})}.$$

Analogamente,

$$\begin{aligned}\mathbf{A}^+ \mathbf{A} &= \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \mathbf{V}_r \mathbf{V}_r^\top \\ &= \mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)}.\end{aligned}$$

Como

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top)$$

e

$$\mathcal{C}(\mathbf{A}^\top)^\perp = \mathcal{N}(\mathbf{A}),$$

os projetores sobre os complementos ortogonais são

$$\mathbf{I}_q - \mathbf{A} \mathbf{A}^+ = \mathbf{P}_{\mathcal{N}(\mathbf{A}^\top)}$$

e

$$\mathbf{I}_p - \mathbf{A}^+ \mathbf{A} = \mathbf{P}_{\mathcal{N}(\mathbf{A})}.$$

□

A Tabela 6.6 resume essas relações.

Tabela 6.6: Projetores ortogonais determinados pela pseudoinversa.

Matriz	Espaço projetado
$\mathbf{A} \mathbf{A}^+$	$\mathcal{C}(\mathbf{A})$
$\mathbf{I}_q - \mathbf{A} \mathbf{A}^+$	$\mathcal{N}(\mathbf{A}^\top)$
$\mathbf{A}^+ \mathbf{A}$	$\mathcal{C}(\mathbf{A}^\top)$
$\mathbf{I}_p - \mathbf{A}^+ \mathbf{A}$	$\mathcal{N}(\mathbf{A})$

Os dois produtos atuam em espaços diferentes. A matriz

$$\mathbf{A}\mathbf{A}^+ \in \mathbb{R}^{q \times q}$$

atua no contradomínio e seleciona a componente pertencente à imagem da transformação.

Por outro lado,

$$\mathbf{A}^+\mathbf{A} \in \mathbb{R}^{p \times p}$$

atua no domínio e seleciona a componente pertencente ao espaço linha, isto é, ao complemento ortogonal do núcleo de $\mathbf{A}$.

6.7.4 Sistemas lineares compatíveis

Considere o sistema

$$\mathbf{A}\mathbf{x} = \mathbf{b}, \quad \mathbf{b} \in \mathbb{R}^q.$$

A pseudoinversa permite caracterizar a compatibilidade do sistema, descrever todas as suas soluções e identificar aquela de menor norma.

Proposição 6.21 (Sistemas compatíveis pela pseudoinversa). *O sistema*

$$\mathbf{A}\mathbf{x} = \mathbf{b}$$

é compatível se, e somente se,

$$\mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{b}.$$

Quando o sistema é compatível, o conjunto de todas as soluções é

$$\mathbf{x} = \mathbf{A}^+\mathbf{b} + \mathbf{V}_0\boldsymbol{\gamma},$$

em que

$$\boldsymbol{\gamma} \in \mathbb{R}^{p-r}.$$

Entre todas essas soluções,

$$\mathbf{x}^\star = \mathbf{A}^+\mathbf{b}$$

é a única de menor norma euclidiana.

Se

$$r = p,$$

o núcleo de $\mathbf{A}$ é trivial e a solução é única.

Comprovação. O sistema é compatível exatamente quando

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Pela Proposição 6.20,

$$\mathbf{A}\mathbf{A}^+ = \mathbf{P}_{\mathcal{C}(\mathbf{A})}.$$

Portanto,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}) \iff \mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{b}.$$

Suponha que o sistema seja compatível. Então

$$\mathbf{x}_0 = \mathbf{A}^+\mathbf{b}$$

é uma solução, pois

$$\mathbf{A}\mathbf{x}_0 = \mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{b}.$$

Se $\mathbf{x}$ é qualquer outra solução,

$$\mathbf{A}\mathbf{x} = \mathbf{A}\mathbf{x}_0.$$

Logo,

$$\mathbf{A}(\mathbf{x} - \mathbf{x}_0) = \mathbf{0},$$

e, portanto,

$$\mathbf{x} - \mathbf{x}_0 \in \mathcal{N}(\mathbf{A}).$$

Como as colunas de $\mathbf{V}_0$ formam uma base ortonormal desse núcleo,

$$\mathbf{x} = \mathbf{A}^+\mathbf{b} + \mathbf{V}_0\gamma.$$

Além disso,

$$\mathbf{A}^+\mathbf{b} \in \mathcal{C}(\mathbf{A}^\top)$$

e

$$\mathbf{V}_0\gamma \in \mathcal{N}(\mathbf{A}).$$

Como

$$\mathcal{C}(\mathbf{A}^\top) \perp \mathcal{N}(\mathbf{A}),$$

segue que

$$\|\mathbf{x}\|^2 = \|\mathbf{A}^+\mathbf{b}\|^2 + \|\mathbf{V}_0\gamma\|^2.$$

A menor norma é obtida somente quando

$$\gamma = \mathbf{0}.$$

Portanto,

$$\mathbf{x}^\star = \mathbf{A}^+\mathbf{b}$$

é a única solução de menor norma.

Finalmente, se

$$r = p,$$

então

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

e nenhuma componente adicional pode ser acrescentada à solução. □

6.7.5 Mínimos quadrados

Para qualquer

$$\mathbf{b} \in \mathbb{R}^q,$$

pode-se procurar um vetor $\mathbf{x}$ cuja imagem $\mathbf{Ax}$ esteja o mais próxima possível de $\mathbf{b}$.

O problema é

$$\min_{\mathbf{x} \in \mathbb{R}^p} \|\mathbf{b} - \mathbf{Ax}\|^2.$$

Quando

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}),$$

o erro mínimo é zero e o problema coincide com a resolução de um sistema compatível.

Quando

$$\mathbf{b} \notin \mathcal{C}(\mathbf{A}),$$

não existe solução exata e busca-se a melhor aproximação possível dentro do espaço coluna de $\mathbf{A}$.

Definição 6.12 (Solução de mínimos quadrados). Um vetor

$$\hat{\mathbf{x}} \in \mathbb{R}^p$$

é uma **solução de mínimos quadrados** de

$$\mathbf{Ax} = \mathbf{b}$$

quando

$$\|\mathbf{b} - \mathbf{A}\hat{\mathbf{x}}\| = \min_{\mathbf{x} \in \mathbb{R}^p} \|\mathbf{b} - \mathbf{Ax}\|.$$

A pseudoinversa fornece diretamente todas as soluções desse problema.

Proposição 6.22 (Mínimos quadrados pela pseudoinversa). *Para qualquer*

$$\mathbf{b} \in \mathbb{R}^q,$$

o vetor ajustado de mínimos quadrados é

$$\hat{\mathbf{b}} = \mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{P}_{\mathcal{C}(\mathbf{A})}\mathbf{b}.$$

O resíduo é

$$\mathbf{r} = \mathbf{b} - \hat{\mathbf{b}} = (\mathbf{I}_q - \mathbf{A}\mathbf{A}^+)\mathbf{b}$$

e satisfaz

$$\mathbf{r} \in \mathcal{N}(\mathbf{A}^\top),$$

ou, equivalentemente,

$$\mathbf{A}^\top \mathbf{r} = \mathbf{0}.$$

Consequentemente, uma solução de mínimos quadrados satisfaz as equações normais

$$\mathbf{A}^\top \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{b}.$$

O conjunto de todas as soluções de mínimos quadrados é

$$\hat{\mathbf{x}} = \mathbf{A}^+\mathbf{b} + \mathbf{V}_0\gamma,$$

em que

$$\gamma \in \mathbb{R}^{p-r}.$$

Entre todos os minimizadores,

$$\hat{\mathbf{x}}^\star = \mathbf{A}^+\mathbf{b}$$

é o único de menor norma euclidiana.

Comprovação. Pela Proposição 6.20,

$$\mathbf{P}_{\mathcal{C}(\mathbf{A})} = \mathbf{A}\mathbf{A}^+.$$

Defina

$$\hat{\mathbf{b}} = \mathbf{P}_{\mathcal{C}(\mathbf{A})}\mathbf{b} = \mathbf{A}\mathbf{A}^+\mathbf{b}$$

e

$$\mathbf{r} = \mathbf{b} - \hat{\mathbf{b}}.$$

Como $\hat{\mathbf{b}}$ é a projeção ortogonal de $\mathbf{b}$ sobre $\mathcal{C}(\mathbf{A})$,

$$\hat{\mathbf{b}} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{r} \in \mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top).$$

Para qualquer

$$\mathbf{x} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{A}\mathbf{x} \in \mathcal{C}(\mathbf{A}).$$

Portanto,

$$\mathbf{b} - \mathbf{A}\mathbf{x} = \mathbf{r} + (\hat{\mathbf{b}} - \mathbf{A}\mathbf{x}),$$

em que

$$\mathbf{r} \perp (\hat{\mathbf{b}} - \mathbf{A}\mathbf{x}).$$

Pelo Teorema de Pitágoras,

$$\|\mathbf{b} - \mathbf{Ax}\|^2 = \|\mathbf{r}\|^2 + \|\hat{\mathbf{b}} - \mathbf{Ax}\|^2.$$

Assim,

$$\|\mathbf{b} - \mathbf{Ax}\|^2 \geq \|\mathbf{r}\|^2,$$

com igualdade se, e somente se,

$$\mathbf{Ax} = \hat{\mathbf{b}}.$$

Como

$$\mathbf{A}(\mathbf{A}^+\mathbf{b}) = \mathbf{AA}^+\mathbf{b} = \hat{\mathbf{b}},$$

o vetor

$$\mathbf{A}^+\mathbf{b}$$

é uma solução de mínimos quadrados.

Além disso, um vetor $\hat{\mathbf{x}}$ é uma solução de mínimos quadrados se, e somente se,

$$\mathbf{A}\hat{\mathbf{x}} = \hat{\mathbf{b}} = \mathbf{AA}^+\mathbf{b}.$$

Nesse caso, seu resíduo é

$$\mathbf{b} - \mathbf{A}\hat{\mathbf{x}} = \mathbf{r} \in \mathcal{N}(\mathbf{A}^\top).$$

Portanto,

$$\mathbf{A}^\top(\mathbf{b} - \mathbf{A}\hat{\mathbf{x}}) = \mathbf{0},$$

o que equivale às equações normais

$$\mathbf{A}^\top\mathbf{A}\hat{\mathbf{x}} = \mathbf{A}^\top\mathbf{b}.$$

Reciprocamente, se $\hat{\mathbf{x}}$ satisfaz as equações normais, então

$$\mathbf{b} - \mathbf{A}\hat{\mathbf{x}} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Como

$$\mathbf{A}\hat{\mathbf{x}} \in \mathcal{C}(\mathbf{A}),$$

a decomposição

$$\mathbf{b} = \mathbf{A}\hat{\mathbf{x}} + (\mathbf{b} - \mathbf{A}\hat{\mathbf{x}})$$

é ortogonal. Pela unicidade da projeção ortogonal,

$$\mathbf{A}\hat{\mathbf{x}} = \mathbf{P}_{\mathcal{C}(\mathbf{A})}\mathbf{b} = \hat{\mathbf{b}}.$$

Logo, $\hat{\mathbf{x}}$ é uma solução de mínimos quadrados.

Para caracterizar todos os minimizadores, observe que

$$\mathbf{A}\hat{\mathbf{x}} = \mathbf{A}\mathbf{A}^+\mathbf{b}$$

se, e somente se,

$$\mathbf{A}(\hat{\mathbf{x}} - \mathbf{A}^+\mathbf{b}) = \mathbf{0}.$$

Portanto,

$$\hat{\mathbf{x}} - \mathbf{A}^+\mathbf{b} \in \mathcal{N}(\mathbf{A}).$$

Como as colunas de $\mathbf{V}_0$ formam uma base ortonormal desse núcleo,

$$\hat{\mathbf{x}} = \mathbf{A}^+\mathbf{b} + \mathbf{V}_0\boldsymbol{\gamma},$$

com

$$\boldsymbol{\gamma} \in \mathbb{R}^{p-r}.$$

Finalmente,

$$\mathbf{A}^+\mathbf{b} \in \mathcal{C}(\mathbf{A}^\top)$$

e

$$\mathbf{V}_0\gamma \in \mathcal{N}(\mathbf{A}).$$

Como

$$\mathcal{C}(\mathbf{A}^\top) \perp \mathcal{N}(\mathbf{A}),$$

segue que

$$\|\hat{\mathbf{x}}\|^2 = \|\mathbf{A}^+\mathbf{b}\|^2 + \|\mathbf{V}_0\gamma\|^2.$$

A menor norma é obtida unicamente quando

$$\gamma = \mathbf{0}.$$

Portanto,

$$\hat{\mathbf{x}}^\star = \mathbf{A}^+\mathbf{b}$$

é a única solução de mínimos quadrados de menor norma. □

A decomposição geométrica correspondente é

$$\mathbf{b} = \hat{\mathbf{b}} + \mathbf{r},$$

com

$$\hat{\mathbf{b}} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{r} \in \mathcal{N}(\mathbf{A}^\top).$$

Como essas parcelas são ortogonais,

$$\|\mathbf{b}\|^2 = \|\hat{\mathbf{b}}\|^2 + \|\mathbf{r}\|^2.$$

6.7.5.1 Caso de posto coluna completo

Se

$$r = p,$$

então

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

e a solução de mínimos quadrados é única:

$$\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b}.$$

Nesse caso,

$$\mathbf{A}^\top \mathbf{A}$$

é positiva definida e invertível, e

$$\mathbf{A}^+ = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

Portanto,

$$\hat{\mathbf{x}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

6.7.5.2 Caso de posto linha completo

Se

$$r = q \leq p,$$

então

$$\mathcal{C}(\mathbf{A}) = \mathbb{R}^q.$$

Logo, para todo

$$\mathbf{b} \in \mathbb{R}^q,$$

o sistema

$$\mathbf{Ax} = \mathbf{b}$$

é compatível.

Nesse caso,

$$\mathbf{AA}^\top$$

é invertível e

$$\mathbf{A}^+ = \mathbf{A}^\top (\mathbf{AA}^\top)^{-1}.$$

A solução

$$\mathbf{x}^* = \mathbf{A}^+ \mathbf{b}$$

é a solução exata de menor norma.

6.7.6 Expressão da solução nas direções singulares

A forma expandida da pseudoinversa permite interpretar diretamente a solução de menor norma nas direções singulares.

Como

$$\mathbf{A}^+ = \sum_{j=1}^r \frac{1}{d_j} \mathbf{v}_j \mathbf{u}_j^\top,$$

tem-se

$$\hat{\mathbf{x}}^* = \mathbf{A}^+ \mathbf{b} = \sum_{j=1}^r \frac{\mathbf{u}_j^\top \mathbf{b}}{d_j} \mathbf{v}_j.$$

A solução é construída em três etapas:

1. calcula-se a componente de $\mathbf{b}$ na direção $\mathbf{u}_j$:

$$\mathbf{u}_j^\top \mathbf{b};$$

2. divide-se essa componente pelo valor singular:

$$\frac{\mathbf{u}_j^\top \mathbf{b}}{d_j};$$

3. expressa-se o resultado na direção $\mathbf{v}_j$.

A componente de $\mathbf{b}$ no núcleo de $\mathbf{A}^\top$ não aparece na solução, pois não pode ser reproduzida por nenhum vetor da forma $\mathbf{Ax}$.

O vetor ajustado é

$$\hat{\mathbf{b}} = \sum_{j=1}^r (\mathbf{u}_j^\top \mathbf{b}) \mathbf{u}_j,$$

enquanto o resíduo é

$$\mathbf{r} = \sum_{j=r+1}^q (\mathbf{u}_j^\top \mathbf{b}) \mathbf{u}_j.$$

6.7.7 Aprofundamento: instabilidade e pseudoinversa truncada

Leitura de aprofundamento

A pseudoinversa inverte os valores singulares positivos. Como consequência, valores singulares muito pequenos podem produzir grandes fatores de amplificação na solução. Esta seção examina a sensibilidade da pseudoinversa a perturbações e apresenta a pseudoinversa truncada como uma forma de evitar a inversão de algumas direções singulares. Essas ideias pertencem ao estudo de problemas inversos e regularização e não são necessárias para acompanhar os resultados centrais de mínimos quadrados desenvolvidos neste capítulo.

A expressão

$$\hat{\mathbf{x}}^* = \sum_{j=1}^r \frac{\mathbf{u}_j^\top \mathbf{b}}{d_j} \mathbf{v}_j$$

mostra que valores singulares pequenos podem produzir coeficientes elevados.

Considere uma perturbação

$$\mathbf{b} \mapsto \mathbf{b} + \varepsilon.$$

A alteração na solução de menor norma é

$$\begin{aligned}\Delta \hat{\mathbf{x}} &= \mathbf{A}^+ \varepsilon \\ &= \sum_{j=1}^r \frac{\mathbf{u}_j^\top \varepsilon}{d_j} \mathbf{v}_j.\end{aligned}$$

Se d_j é pequeno, uma pequena componente de ε na direção $\mathbf{u}_j$ pode ser ampliada por

$$\frac{1}{d_j}.$$

Como os valores singulares positivos de $\mathbf{A}^+$ são

$$\frac{1}{d_r} \geq \dots \geq \frac{1}{d_1},$$

tem-se, para $r \geq 1$,

$$\|\mathbf{A}^+\|_2 = \frac{1}{d_r}.$$

Consequentemente,

$$\|\Delta \hat{\mathbf{x}}\| \leq \frac{1}{d_r} \|\varepsilon\|.$$

O menor valor singular positivo controla, portanto, a maior amplificação possível de uma perturbação pela pseudoinversa.

Esse comportamento relaciona:

- valores singulares positivos pequenos;
- forte amplificação nas direções correspondentes da pseudoinversa;
- sensibilidade a perturbações;
- instabilidade de problemas inversos.

Quando $\mathbf{A}$ possui posto máximo, um menor valor singular muito pequeno em relação a d_1 corresponde também a um número de condição elevado. Se a matriz não possui posto máximo, o número de condição definido anteriormente é infinito, enquanto a pseudoinversa continua invertendo somente os valores singulares positivos.

Descartar ou modificar a inversão de valores singulares pequenos pode reduzir essa instabilidade. Esses procedimentos pertencem ao estudo da regularização e não serão desenvolvidos neste capítulo.

6.7.7.1 Pseudoinversa truncada

Considere a aproximação truncada

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Sua pseudoinversa de Moore–Penrose é

$$\mathbf{A}_k^+ = \mathbf{V}_k \mathbf{D}_k^{-1} \mathbf{U}_k^\top.$$

Ela pode ser utilizada como uma inversão truncada de $\mathbf{A}$, conservando somente os k maiores valores singulares.

A solução correspondente é

$$\hat{\mathbf{x}}_k = \mathbf{A}_k^+ \mathbf{b} = \sum_{j=1}^k \frac{\mathbf{u}_j^\top \mathbf{b}}{d_j} \mathbf{v}_j.$$

Essa expressão elimina as contribuições associadas às direções singulares descartadas.

A pseudoinversa truncada pode produzir uma solução menos sensível a componentes ligadas a valores singulares pequenos, mas também introduz erro por omitir parte da estrutura da matriz. A escolha de k depende do problema e não será tratada como um procedimento geral neste módulo.

6.7.8 Exemplo com o sistema condutor

Exemplo 6.9 (Pseudoinversa e mínimos quadrados no exemplo condutor). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}$$

e

$$\mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix}.$$

A SVD compacta de $\mathbf{A}$ possui

$$\mathbf{U}_2 = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 0 & 1 \\ 1/\sqrt{2} & 0 \end{bmatrix},$$

$$\mathbf{D}_2 = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix}$$

e

$$\mathbf{V}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

A pseudoinversa é

$$\mathbf{A}^+ = \mathbf{V}_2 \mathbf{D}_2^{-1} \mathbf{U}_2^\top.$$

Efetuando os produtos,

$$\mathbf{A}^+ = \begin{bmatrix} 1/4 & 1/2 & 1/4 \\ 1/4 & -1/2 & 1/4 \end{bmatrix}.$$

A solução de mínimos quadrados é

$$\begin{aligned}
\hat{\mathbf{x}} &= \mathbf{A}^+ \mathbf{b} \\
&= \begin{bmatrix} 1/4 & 1/2 & 1/4 \\ 1/4 & -1/2 & 1/4 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix} \\
&= \begin{bmatrix} 5/4 \\ -3/4 \end{bmatrix}.
\end{aligned}$$

O vetor ajustado é

$$\begin{aligned}
\hat{\mathbf{b}} &= \mathbf{A} \hat{\mathbf{x}} \\
&= \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 5/4 \\ -3/4 \end{bmatrix} \\
&= \begin{bmatrix} 1/2 \\ 2 \\ 1/2 \end{bmatrix}.
\end{aligned}$$

O resíduo é

$$\begin{aligned}
\mathbf{r} &= \mathbf{b} - \hat{\mathbf{b}} \\
&= \begin{bmatrix} 1/2 \\ 0 \\ -1/2 \end{bmatrix}.
\end{aligned}$$

O vetor

$$\mathbf{u}_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}$$

forma uma base do núcleo de $\mathbf{A}^\top$. De fato,

$$\mathbf{r} = \frac{1}{\sqrt{2}} \mathbf{u}_3.$$

Consequentemente,

$$\mathbf{A}^\top \mathbf{r} = \mathbf{0}.$$

O sistema original é incompatível porque a primeira e a terceira equações exigiriam simultaneamente

$$x_1 + x_2 = 1$$

e

$$x_1 + x_2 = 0.$$

A solução de mínimos quadrados substitui esses dois valores pela projeção comum

$$x_1 + x_2 = \frac{1}{2}.$$

Como $\mathbf{A}$ possui posto coluna completo, a solução de mínimos quadrados é única.

A pseudoinversa reúne, em uma única construção:

- inversão dos fatores de escala associados aos valores singulares positivos;
- anulação das componentes pertencentes a $\mathcal{N}(\mathbf{A}^\top)$;
- construção dos projetores sobre $\mathcal{C}(\mathbf{A})$ e $\mathcal{C}(\mathbf{A}^\top)$;
- solução de sistemas lineares compatíveis;
- seleção da solução exata de menor norma quando há não unicidade;
- solução de problemas de mínimos quadrados;
- seleção da solução de mínimos quadrados de menor norma quando há vários minimizadores.

Essas relações encerram a estrutura algébrica da SVD. A síntese do capítulo organiza as formas da decomposição, suas interpretações e suas principais consequências.

6.8 Síntese do capítulo

A Decomposição em Valores Singulares estende a ideia de decomposição espectral a qualquer matriz real. Para

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

existe uma decomposição

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

em que $\mathbf{U}$ e $\mathbf{V}$ são matrizes ortogonais e $\mathbf{D}$ contém os valores singulares não negativos.

Para cada valor singular positivo d_j ,

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$$

e

$$\mathbf{A}^\top \mathbf{u}_j = d_j\mathbf{v}_j.$$

Assim, $\mathbf{v}_j$ determina uma direção no domínio, d_j determina o fator de escala e $\mathbf{u}_j$ determina a direção correspondente no contradomínio.

Se

$$r = \text{posto}(\mathbf{A}),$$

a SVD compacta é

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

com

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r), \quad d_1 \geq \dots \geq d_r > 0.$$

A SVD compacta é uma representação exata. A SVD truncada,

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top, \quad k < r,$$

descarta parcelas associadas a valores singulares positivos e produz uma aproximação de posto reduzido.

A construção da SVD decorre das decomposições espectrais das duas matrizes de Gram:

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top$$

e

$$\mathbf{A} \mathbf{A}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

Seus autovalores positivos são

$$d_1^2, \dots, d_r^2.$$

Assim, $\mathbf{A}^\top \mathbf{A}$ descreve a estrutura espectral relevante no domínio, enquanto $\mathbf{A} \mathbf{A}^\top$ descreve a estrutura correspondente no contradomínio.

Geometricamente, a imagem da bola unitária é um elipsoide de dimensão r contido em

$$\mathcal{C}(\mathbf{A}),$$

com semieixos

$$d_1 \mathbf{u}_1, \dots, d_r \mathbf{u}_r.$$

Os valores singulares medem, portanto, os fatores de escala nas direções singulares. Em particular,

$$\|\mathbf{A}\|_2 = d_1,$$

de modo que o maior valor singular é o maior fator de ampliação produzido pela transformação.

A SVD também fornece bases ortonormais para os quatro espaços fundamentais:

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{u}_1, \dots, \mathbf{u}_r \},$$

$$\mathcal{N}(\mathbf{A}^\top) = \text{span} \{ \mathbf{u}_{r+1}, \dots, \mathbf{u}_q \},$$

$$\mathcal{C}(\mathbf{A}^\top) = \text{span} \{ \mathbf{v}_1, \dots, \mathbf{v}_r \},$$

e

$$\mathcal{N}(\mathbf{A}) = \text{span} \{ \mathbf{v}_{r+1}, \dots, \mathbf{v}_p \}.$$

Consequentemente,

$$\dim(\mathcal{N}(\mathbf{A})) = p - r$$

e

$$\dim(\mathcal{N}(\mathbf{A}^\top)) = q - r.$$

As normas espectral e de Frobenius possuem representações simples em termos dos valores singulares:

$$\|\mathbf{A}\|_2 = d_1$$

e

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

Para uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a SVD compacta fornece

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

As coordenadas das observações nas direções singulares à direita são

$$\mathbf{Z} = \mathbf{X} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r.$$

Como

$$\mathbf{X} = \mathbf{Z} \mathbf{V}_r^\top,$$

essa representação é exata quando são mantidos todos os r componentes singulares positivos.

Além disso,

$$\mathbf{Z} \mathbf{Z}^\top = \mathbf{X} \mathbf{X}^\top,$$

de modo que a representação compacta preserva os produtos internos, as normas e as distâncias euclidianas entre as observações.

Analogamente,

$$\mathbf{U}_r^\top \mathbf{X} = \mathbf{D}_r \mathbf{V}_r^\top$$

fornece as coordenadas das variáveis nas direções singulares à esquerda.

Quando a matriz de dados está centralizada,

$$\mathbf{X}_c^\top \mathbf{X}_c = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top.$$

Adotando a matriz de covariâncias amostral

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c,$$

obtém-se

$$\mathbf{S} = \mathbf{V}_r \left(\frac{\mathbf{D}_r^2}{n-1} \right) \mathbf{V}_r^\top.$$

Assim, os vetores singulares à direita de $\mathbf{X}_c$ determinam as direções espectrais associadas aos autovalores positivos de $\mathbf{S}$, enquanto

$$\frac{d_j^2}{n-1}$$

são os autovalores positivos correspondentes.

Essa relação antecipa uma das principais conexões entre a SVD e as técnicas de redução de dimensionalidade que serão desenvolvidas posteriormente.

A forma expandida,

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

representa a matriz como uma soma de componentes singulares de posto 1, ortogonais entre si segundo o produto interno de Frobenius.

Na norma de Frobenius,

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2$$

é uma decomposição pitagórica da magnitude quadrática total da matriz.

O Teorema de Eckart–Young–Mirsky estabelece que

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top$$

é uma solução do problema de melhor aproximação de $\mathbf{A}$ entre todas as matrizes de posto no máximo k , tanto na norma espectral quanto na norma de Frobenius. Os erros mínimos são

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1}$$

e

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

A norma espectral mede o maior erro remanescente em uma direção unitária, enquanto a norma de Frobenius agrega quadraticamente todas as parcelas descartadas.

A pseudoinversa de Moore–Penrose é

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top,$$

com $\mathbf{A}^+ = \mathbf{0}$ quando $\mathbf{A} = \mathbf{0}$.

Ela determina os projetores

$$\mathbf{A}\mathbf{A}^+ = \mathbf{U}_r \mathbf{U}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A})}$$

e

$$\mathbf{A}^+ \mathbf{A} = \mathbf{V}_r \mathbf{V}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)}.$$

Para qualquer

$$\mathbf{b} \in \mathbb{R}^q,$$

o vetor

$$\hat{\mathbf{x}}^\star = \mathbf{A}^+ \mathbf{b}$$

é a solução de mínimos quadrados de menor norma.

Quando

$$r < p,$$

podem existir outros minimizadores, obtidos pela adição de componentes pertencentes a

$$\mathcal{N}(\mathbf{A}).$$

A pseudoinversa seleciona, entre todos eles, o único vetor de menor norma euclidiana.

O vetor ajustado é

$$\hat{\mathbf{b}} = \mathbf{A}\mathbf{A}^+\mathbf{b},$$

isto é, a projeção ortogonal de $\mathbf{b}$ sobre $\mathcal{C}(\mathbf{A})$, enquanto o resíduo

$$\mathbf{r} = (\mathbf{I}_q - \mathbf{A}\mathbf{A}^+) \mathbf{b}$$

pertence a

$$\mathcal{N}(\mathbf{A}^\top).$$

A Tabela 6.7 reúne as relações principais.

Tabela 6.7: Síntese das principais relações da Decomposição em Valores Singulares.

Objeto	Expressão	Interpretação
SVD completa	$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top$	Utiliza bases ortonormais completas no domínio e no contradomínio
SVD compacta	$\mathbf{A} = \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top$	Representação exata usando somente os componentes associados aos valores singulares positivos
Pares singulares	$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$	Relaciona uma direção do domínio a uma direção do contradomínio

Objeto	Expressão	Interpretação
Matrizes de Gram	$\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A}\mathbf{A}^\top$	Determinam os quadrados dos valores singulares e os vetores singulares correspondentes
Posto	$r = \#\{j : d_j > 0\}$	Dimensão da imagem da transformação
Norma espectral	$\ \mathbf{A}\ _2 = d_1$	Maior fator de ampliação da transformação
Norma de Frobenius	$\ \mathbf{A}\ _F^2 = \sum_{j=1}^r d_j^2$	Magnitude quadrática total da matriz
Coordenadas das observações	$\mathbf{Z} = \mathbf{X}\mathbf{V}_r = \mathbf{U}_r\mathbf{D}_r$	Representação das observações nas direções singulares à direita
SVD truncada	$\mathbf{A}_k = \mathbf{U}_k\mathbf{D}_k\mathbf{V}_k^\top$	Aproximação ótima de posto no máximo k
Erro espectral	$\ \mathbf{A} - \mathbf{A}_k\ _2 = d_{k+1}$	Maior erro do truncamento sobre vetores unitários
Erro de Frobenius	$\ \mathbf{A} - \mathbf{A}_k\ _F^2 = \sum_{j=k+1}^r d_j^2$	Magnitude quadrática total dos componentes descartados
Pseudoinversa	$\mathbf{A}^+ = \mathbf{V}_r\mathbf{D}_r^{-1}\mathbf{U}_r^\top$	Inverte os fatores de escala associados aos valores singulares positivos
Projeter no espaço coluna	$\mathbf{A}\mathbf{A}^+$	Projeta sobre $\mathcal{C}(\mathbf{A})$
Projeter no espaço linha	$\mathbf{A}^+\mathbf{A}$	Projeta sobre $\mathcal{C}(\mathbf{A}^\top)$
Mínimos quadrados	$\hat{\mathbf{x}}^* = \mathbf{A}^+\mathbf{b}$	Seleciona a solução de mínimos quadrados de menor norma

Ao final deste capítulo, o estudante deverá ser capaz de:

- distinguir as formas completa, compacta e truncada da SVD;
- diferenciar uma representação compacta exata de uma aproximação truncada de posto reduzido;
- relacionar a SVD às decomposições espectrais de $\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A}\mathbf{A}^\top$;
- interpretar geometricamente os valores e vetores singulares;
- identificar o posto e os quatro espaços fundamentais por meio da SVD;
- construir os projetores ortogonais associados aos espaços fundamentais;
- calcular e interpretar as normas espectral e de Frobenius a partir dos valores singulares;
- interpretar a dualidade entre observações e variáveis em uma matriz de dados;
- representar exatamente as observações em coordenadas singulares e compreender a preservação de produtos internos e distâncias;

- relacionar a SVD de uma matriz centralizada à estrutura espectral de sua matriz de covariâncias amostral;
- representar uma matriz como soma de componentes singulares ortogonais de posto 1;
- construir aproximações de posto reduzido e determinar seus erros nas normas espectral e de Frobenius;
- aplicar o Teorema de Eckart–Young–Mirsky;
- construir e interpretar a pseudoinversa de Moore–Penrose;
- distinguir solução exata, solução de mínimos quadrados e solução de mínimos quadrados de menor norma;
- interpretar mínimos quadrados como um problema de projeção ortogonal.

Ideia central do capítulo

A Decomposição em Valores Singulares descreve uma matriz por meio de pares de direções ortonormais no domínio e no contradomínio e dos fatores de escala que relacionam essas direções. Essa estrutura revela o posto e os espaços fundamentais, fornece representações exatas ou aproximadas de menor dimensão e permite construir projetores, pseudoinversas e soluções de mínimos quadrados.

A SVD encerra o percurso dedicado às principais estruturas de Álgebra Linear utilizadas neste módulo. Matrizes, espaços vetoriais, transformações lineares, decomposição espectral e SVD fornecem, em conjunto, a base geométrica e matricial para representar estruturas multivariadas.

O próximo capítulo desenvolve **Cálculo Diferencial, Integral e Matricial Aplicado à Estatística Multivariada**. Gradientes, Hessianas, multiplicadores de Lagrange, diferenciais matriciais, traços, determinantes e integrais completarão os fundamentos matemáticos necessários para formular problemas de otimização, estimação e transformação de variáveis nos capítulos seguintes.

7 Cálculo Diferencial, Integral e Matricial Aplicado à Estatística Multivariada

Os capítulos anteriores desenvolveram a representação vetorial dos dados, a álgebra matricial, os espaços vetoriais, as transformações lineares e as principais decomposições matriciais. Este capítulo estuda funções cujos argumentos e resultados podem ser escalares, vetores ou matrizes.

O cálculo diferencial descreve como essas funções variam localmente. Gradientes, Jacobianas e Hessianas permitem construir aproximações, identificar direções de variação e formular condições de otimização. O cálculo matricial permite diferenciar expressões que envolvem traços, produtos, inversas e determinantes.

O cálculo integral será utilizado para representar probabilidades, esperanças, distribuições marginais e transformações de vetores aleatórios. Nessas transformações, o determinante Jacobiano descreve a alteração local de volume.

O objetivo é reunir as ferramentas de cálculo utilizadas nos capítulos probabilísticos e inferenciais, sem desenvolver antecipadamente os modelos e procedimentos específicos desses capítulos.

7.1 Funções, variações e diferenciais

7.1.1 Tipos de funções

Uma função real de uma variável real possui a forma

$$f : \mathbb{R} \longrightarrow \mathbb{R}.$$

Em problemas multivariados, o domínio ou o contradomínio pode ter dimensão maior que um. A natureza desses espaços determina a forma da derivada.

Uma função escalar de um vetor é representada por

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix},$$

escreve-se

$$f(\mathbf{x}) = f(x_1, \dots, x_p).$$

São exemplos:

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{x},$$

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

e

$$f(\mathbf{x}) = \|\mathbf{b} - \mathbf{A} \mathbf{x}\|^2.$$

Essas funções associam um escalar a cada vetor do domínio.

Neste capítulo, salvo indicação em contrário, $\|\cdot\|$ aplicada a vetores denota a norma euclidiana definida em Definição [1.10](#).

Uma função vetorial de um vetor possui a forma

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Ela pode ser escrita como

$$\mathbf{g}(\mathbf{x}) = \begin{bmatrix} g_1(\mathbf{x}) \\ \vdots \\ g_q(\mathbf{x}) \end{bmatrix},$$

em que cada componente

$$g_i : \mathbb{R}^p \longrightarrow \mathbb{R}$$

é uma função escalar.

Uma transformação linear é um caso particular:

$$\mathbf{g}(\mathbf{x}) = \mathbf{Ax}, \quad \mathbf{A} \in \mathbb{R}^{q \times p}.$$

Também são utilizadas funções escalares de matrizes:

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}.$$

São exemplos:

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X})$$

e

$$\phi(\mathbf{X}) = \|\mathbf{X}\|_F^2,$$

em que $\|\cdot\|_F$ denota a norma de Frobenius definida em Definição 6.7.

Uma função matricial de uma matriz possui a forma

$$\mathcal{G} : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}^{r \times s}.$$

São exemplos:

$$\mathcal{G}(\mathbf{X}) = \mathbf{X}^\top \mathbf{X},$$

$$\mathcal{G}(\mathbf{X}) = \mathbf{AXB}$$

e, para matrizes quadradas invertíveis,

$$\mathcal{G}(\mathbf{X}) = \mathbf{X}^{-1}.$$

A Tabela 7.1 resume os tipos de funções utilizados no capítulo.

Tabela 7.1: Tipos de funções e objetos diferenciais correspondentes.

Função	Domínio	Contradomínio	Representação de primeira ordem
$f(x)$	$\mathbb{R}$	$\mathbb{R}$	Derivada escalar
$f(\mathbf{x})$	$\mathbb{R}^p$	$\mathbb{R}$	Gradiente
$\mathbf{g}(\mathbf{x})$	$\mathbb{R}^p$	$\mathbb{R}^q$	Jacobiana
$\phi(\mathbf{X})$	$\mathbb{R}^{m \times n}$	$\mathbb{R}$	Gradiente matricial
$\mathcal{G}(\mathbf{X})$	$\mathbb{R}^{m \times n}$	$\mathbb{R}^{r \times s}$	Operador diferencial

As dimensões do domínio e do contradomínio devem ser identificadas antes da diferenciação. Elas determinam a forma da transformação linear que representa localmente a variação da função e, conseqüentemente, a dimensão do gradiente, da Jacobiana ou do operador diferencial utilizado para representá-la.

7.1.2 Convenções de derivação

Neste capítulo, o gradiente de uma função escalar de um vetor será um vetor-coluna:

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_p} \end{bmatrix} \in \mathbb{R}^p.$$

Para uma função vetorial

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

a Jacobiana será definida por

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \begin{bmatrix} \frac{\partial g_1}{\partial x_1} & \dots & \frac{\partial g_1}{\partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial g_q}{\partial x_1} & \dots & \frac{\partial g_q}{\partial x_p} \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

A Hessiana de uma função escalar será representada por

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \in \mathbb{R}^{p \times p}.$$

Para uma função escalar de uma matriz,

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R},$$

o gradiente matricial terá a mesma dimensão do argumento:

$$\nabla_{\mathbf{X}} \phi(\mathbf{X}) \in \mathbb{R}^{m \times n}.$$

Ele será identificado pela relação

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X} \right].$$

Essa convenção utiliza o produto interno de Frobenius entre o gradiente e a perturbação da matriz.

7.1.3 Variação de uma função

Considere uma função

$$f : \mathcal{U} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R},$$

um ponto interior

$$\mathbf{x} \in \mathcal{U}$$

e uma perturbação

$$\mathbf{h} \in \mathbb{R}^p$$

tal que $\mathbf{x} + \mathbf{h} \in \mathcal{U}$.

A variação exata da função é

$$\Delta f = f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}).$$

Essa diferença mede a alteração total no valor da função. Para perturbações pequenas, procura-se representar sua parcela dominante por uma função linear de $\mathbf{h}$.

Definição 7.1 (Diferenciabilidade de uma função escalar). A função

$$f : \mathcal{U} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}$$

é diferenciável em um ponto interior

$$\mathbf{x} \in \mathcal{U}$$

quando existe uma transformação linear

$$L_{\mathbf{x}} : \mathbb{R}^p \longrightarrow \mathbb{R}$$

tal que

$$f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) = L_{\mathbf{x}}(\mathbf{h}) + r_{\mathbf{x}}(\mathbf{h}),$$

com

$$\frac{r_{\mathbf{x}}(\mathbf{h})}{\|\mathbf{h}\|} \longrightarrow 0 \quad \text{quando} \quad \|\mathbf{h}\| \longrightarrow 0.$$

A função linear $L_{\mathbf{x}}$ fornece a aproximação de primeira ordem da variação. No espaço euclidiano, existe um único vetor

$$\nabla_{\mathbf{x}} f(\mathbf{x}) \in \mathbb{R}^p$$

tal que

$$L_{\mathbf{x}}(\mathbf{h}) = \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h}.$$

Portanto,

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h} + r_{\mathbf{x}}(\mathbf{h}),$$

em que o termo residual é pequeno em relação a $\|\mathbf{h}\|$.

Utilizando a notação de ordem,

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h} + o(\|\mathbf{h}\|).$$

A aproximação linear é

$$f(\mathbf{x} + \mathbf{h}) \approx f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^\top \mathbf{h}.$$

7.1.4 Diferencial

O diferencial de f em $\mathbf{x}$ é a parte linear de sua variação:

$$df = \nabla_{\mathbf{x}} f(\mathbf{x})^\top d\mathbf{x}.$$

Em coordenadas,

$$df = \sum_{j=1}^p \frac{\partial f}{\partial x_j} dx_j.$$

O vetor

$$d\mathbf{x} = \begin{bmatrix} dx_1 \\ \vdots \\ dx_p \end{bmatrix}$$

representa o incremento utilizado como argumento da transformação linear que define o diferencial. Assim,

$$df = \nabla_{\mathbf{x}} f(\mathbf{x})^\top d\mathbf{x}$$

é linear em $d\mathbf{x}$.

A notação diferencial é frequentemente interpretada de maneira informal como uma variação infinitesimal. Formalmente, porém, o diferencial é a aplicação linear que fornece a parte de primeira ordem da variação da função.

Exemplo 7.1 (Diferencial de uma função linear). Considere

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

em que $\mathbf{a} \in \mathbb{R}^p$ é constante.

A variação é

$$\begin{aligned} f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) &= \mathbf{a}^\top (\mathbf{x} + \mathbf{h}) - \mathbf{a}^\top \mathbf{x} \\ &= \mathbf{a}^\top \mathbf{h}. \end{aligned}$$

Logo,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{a}$$

e

$$df = \mathbf{a}^\top d\mathbf{x}.$$

Como a função é linear, a aproximação de primeira ordem coincide com a variação exata.

Exemplo 7.2 (Diferencial do quadrado da norma). Considere

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|^2.$$

A variação exata é

$$\begin{aligned} f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) &= (\mathbf{x} + \mathbf{h})^\top (\mathbf{x} + \mathbf{h}) - \mathbf{x}^\top \mathbf{x} \\ &= 2\mathbf{x}^\top \mathbf{h} + \mathbf{h}^\top \mathbf{h}. \end{aligned}$$

O termo

$$2\mathbf{x}^\top \mathbf{h}$$

é linear em $\mathbf{h}$, enquanto

$$\mathbf{h}^\top \mathbf{h} = \|\mathbf{h}\|^2$$

é de segunda ordem.

Portanto,

$$df = 2\mathbf{x}^\top d\mathbf{x}$$

e

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{x}.$$

7.1.5 Aproximação ao longo de uma direção

Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2,$$

o ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1/2 \end{bmatrix}$$

e o vetor unitário

$$\mathbf{h} = \begin{bmatrix} -4/5 \\ 3/5 \end{bmatrix}.$$

A restrição da função à reta que passa por $\mathbf{x}_0$ na direção $\mathbf{h}$ é

$$\varphi(t) = f(\mathbf{x}_0 + t\mathbf{h}).$$

Em torno de $t = 0$,

$$\varphi(t) \approx \varphi(0) + \varphi'(0)t.$$

A Figura 7.1 compara a função exata ao longo dessa reta com sua aproximação linear.

No ponto $t = 0$, a função e sua aproximação linear possuem o mesmo valor e a mesma inclinação. À medida que $|t|$ aumenta, os termos de segunda ordem passam a contribuir mais para a variação.

7.1.6 Diferenciabilidade de funções vetoriais

Para uma função

$$\mathbf{g} : \mathcal{U} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

a aproximação de primeira ordem é uma transformação linear de $\mathbb{R}^p$ em $\mathbb{R}^q$.




Figura 7.1: Função exata ao longo de uma direção e aproximação linear no ponto $t = 0$.

Definição 7.2 (Diferenciabilidade de uma função vetorial). A função $\mathbf{g}$ é diferenciável em um ponto interior

$$\mathbf{x} \in \mathcal{U}$$

quando existe uma matriz

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) \in \mathbb{R}^{q \times p}$$

tal que

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) - \mathbf{g}(\mathbf{x}) = \mathbf{J}_{\mathbf{g}}(\mathbf{x})\mathbf{h} + \mathbf{r}_{\mathbf{x}}(\mathbf{h}),$$

com

$$\frac{\|\mathbf{r}_{\mathbf{x}}(\mathbf{h})\|}{\|\mathbf{h}\|} \longrightarrow 0 \quad \text{quando} \quad \|\mathbf{h}\| \longrightarrow 0.$$

Assim,

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) \approx \mathbf{g}(\mathbf{x}) + \mathbf{J}_{\mathbf{g}}(\mathbf{x})\mathbf{h},$$

e o diferencial é

$$d\mathbf{g} = \mathbf{J}_{\mathbf{g}}(\mathbf{x})d\mathbf{x}.$$

Para a transformação linear

$$\mathbf{g}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

tem-se

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}$$

em todos os pontos. Portanto,

$$d\mathbf{g} = \mathbf{A} d\mathbf{x},$$

e a aproximação linear é exata.

Gradiente e Jacobiana estão associados à mesma ideia de aproximação linear local, mas correspondem a contradomínios diferentes. Para uma função escalar, o gradiente fornece a representação vetorial da aplicação linear que define o diferencial. Para uma função vetorial, a Jacobiana fornece a representação matricial dessa aplicação linear.

7.2 Gradiente, derivada direcional, Jacobiana e Hessiana

7.2.1 Gradiente e derivada direcional

Para uma função diferenciável

$$f : \mathbb{R}^p \longrightarrow \mathbb{R},$$

o gradiente reúne as derivadas parciais:

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_p} \end{bmatrix}.$$

A derivada parcial em relação a x_j mede a variação da função na direção do vetor canônico $\mathbf{e}_j$. A variação em uma direção arbitrária é descrita pela derivada direcional.

Definição 7.3 (Derivada direcional). Seja

$$\mathbf{u} \in \mathbb{R}^p.$$

A derivada direcional de f no ponto $\mathbf{x}$ na direção de $\mathbf{u}$ é

$$D_{\mathbf{u}} f(\mathbf{x}) = \lim_{t \rightarrow 0} \frac{f(\mathbf{x} + t\mathbf{u}) - f(\mathbf{x})}{t},$$

quando esse limite existe.

Considere a função de uma variável

$$\varphi(t) = f(\mathbf{x} + t\mathbf{u}).$$

Pela regra da cadeia,

$$\begin{aligned}\varphi'(0) &= \nabla_{\mathbf{x}}f(\mathbf{x})^\top \frac{d}{dt}(\mathbf{x} + t\mathbf{u}) \Big|_{t=0} \\ &= \nabla_{\mathbf{x}}f(\mathbf{x})^\top \mathbf{u}.\end{aligned}$$

Portanto, se f é diferenciável,

$$D_{\mathbf{u}}f(\mathbf{x}) = \nabla_{\mathbf{x}}f(\mathbf{x})^\top \mathbf{u}.$$

Quando $\mathbf{u}$ é unitário, a derivada direcional mede a taxa de variação por unidade de deslocamento.

Se θ é o ângulo entre $\nabla_{\mathbf{x}}f(\mathbf{x})$ e $\mathbf{u}$, então

$$D_{\mathbf{u}}f(\mathbf{x}) = \|\nabla_{\mathbf{x}}f(\mathbf{x})\| \|\mathbf{u}\| \cos \theta.$$

Para $\|\mathbf{u}\| = 1$,

$$D_{\mathbf{u}}f(\mathbf{x}) = \|\nabla_{\mathbf{x}}f(\mathbf{x})\| \cos \theta.$$

Proposição 7.1 (Direções de maior crescimento e redução). *Se f é diferenciável em $\mathbf{x}$ e*

$$\nabla_{\mathbf{x}}f(\mathbf{x}) \neq \mathbf{0},$$

então, entre todas as direções unitárias,

$$\max_{\|\mathbf{u}\|=1} D_{\mathbf{u}}f(\mathbf{x}) = \|\nabla_{\mathbf{x}}f(\mathbf{x})\|,$$

e o máximo é atingido na direção

$$\mathbf{u}_{\max} = \frac{\nabla_{\mathbf{x}}f(\mathbf{x})}{\|\nabla_{\mathbf{x}}f(\mathbf{x})\|}.$$

A maior taxa de redução de primeira ordem ocorre na direção oposta:

$$\mathbf{u}_{\min} = -\frac{\nabla_{\mathbf{x}}f(\mathbf{x})}{\|\nabla_{\mathbf{x}}f(\mathbf{x})\|},$$

com

$$\min_{\|\mathbf{u}\|=1} D_{\mathbf{u}}f(\mathbf{x}) = -\|\nabla_{\mathbf{x}}f(\mathbf{x})\|.$$

(Apostol, 1969)

Comprovação. Pelo Teorema 1.1,

$$\begin{aligned} D_{\mathbf{u}}f(\mathbf{x}) &= \nabla_{\mathbf{x}}f(\mathbf{x})^{\top} \mathbf{u} \\ &\leq \|\nabla_{\mathbf{x}}f(\mathbf{x})\| \|\mathbf{u}\|. \end{aligned}$$

Para $\|\mathbf{u}\| = 1$,

$$D_{\mathbf{u}}f(\mathbf{x}) \leq \|\nabla_{\mathbf{x}}f(\mathbf{x})\|.$$

A igualdade ocorre quando $\mathbf{u}$ possui a mesma direção e o mesmo sentido do gradiente. Aplicando o mesmo argumento à direção oposta, obtém-se o resultado para a maior taxa de redução de primeira ordem. $\square$

Se

$$\nabla_{\mathbf{x}}f(\mathbf{x}) = \mathbf{0},$$

todas as derivadas direcionais de primeira ordem são nulas. Nesse caso, a aproximação de primeira ordem não distingue direções de crescimento ou redução, e o comportamento local passa a depender de termos de ordem superior.

7.2.2 Gradiente e conjuntos de nível

Um conjunto de nível de f é definido por

$$\mathcal{S}_c = \{\mathbf{x} \in \mathbb{R}^p : f(\mathbf{x}) = c\},$$

em que c é constante.

Considere uma curva diferenciável

$$\gamma(t)$$

contida em $\mathcal{S}_c$. Então,

$$f(\gamma(t)) = c.$$

Derivando,

$$\nabla_{\mathbf{x}} f(\gamma(t))^\top \gamma'(t) = 0.$$

O vetor $\gamma'(t)$ é tangente ao conjunto de nível. Portanto, o gradiente é ortogonal a todas as direções tangentes.

Quando

$$\nabla_{\mathbf{x}} f(\mathbf{x}) \neq \mathbf{0},$$

o gradiente é um vetor normal ao conjunto de nível no ponto $\mathbf{x}$.

Exemplo 7.3 (Gradiente de uma função quadrática). Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2.$$

O gradiente é

$$\nabla_{\mathbf{x}} f(x_1, x_2) = \begin{bmatrix} 2x_1 \\ 4x_2 \end{bmatrix}.$$

No ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1/2 \end{bmatrix},$$

tem-se

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0) = \begin{bmatrix} 2 \\ 2 \end{bmatrix}$$

e

$$\|\nabla_{\mathbf{x}} f(\mathbf{x}_0)\| = 2\sqrt{2}.$$

A direção de maior crescimento é

$$\mathbf{u}_{\max} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Uma direção tangente à curva de nível é

$$\mathbf{u}_{\tan} = \frac{1}{\sqrt{2}} \begin{bmatrix} -1 \\ 1 \end{bmatrix}.$$

Como

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top \mathbf{u}_{\tan} = 0,$$

a derivada direcional nessa direção é nula.

A Figura 7.2 representa as curvas de nível da função, o gradiente e uma direção tangente no ponto $\mathbf{x}_0$.

A direção do gradiente depende do ponto. Para a função considerada, as curvas de nível são elipses e o gradiente aponta para fora, perpendicularmente à curva correspondente.




Figura 7.2: O gradiente é perpendicular à curva de nível e aponta na direção de maior crescimento local.

7.2.3 Jacobiana

A derivada de uma função vetorial é representada por sua matriz Jacobiana.

Definição 7.4 (Matriz Jacobiana). Seja

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

com

$$\mathbf{g}(\mathbf{x}) = \begin{bmatrix} g_1(\mathbf{x}) \\ \vdots \\ g_q(\mathbf{x}) \end{bmatrix}.$$

Suponha que as derivadas parciais das componentes de $\mathbf{g}$ existam no ponto $\mathbf{x}$. A matriz Jacobiana de $\mathbf{g}$ nesse ponto é

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \begin{bmatrix} \frac{\partial g_1}{\partial x_1} & \cdots & \frac{\partial g_1}{\partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial g_q}{\partial x_1} & \cdots & \frac{\partial g_q}{\partial x_p} \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

Cada linha da Jacobiana é o gradiente transposto de uma componente:

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \begin{bmatrix} \nabla_{\mathbf{x}} g_1(\mathbf{x})^\top \\ \vdots \\ \nabla_{\mathbf{x}} g_q(\mathbf{x})^\top \end{bmatrix}.$$

A aproximação de primeira ordem é

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) = \mathbf{g}(\mathbf{x}) + \mathbf{J}_{\mathbf{g}}(\mathbf{x})\mathbf{h} + o(\|\mathbf{h}\|).$$

A Jacobiana transforma uma pequena variação no domínio em uma aproximação da variação correspondente no contradomínio.

Exemplo 7.4 (Jacobiana de uma função de $\mathbb{R}^2$ em $\mathbb{R}^2$). Considere

$$\mathbf{g}(x_1, x_2) = \begin{bmatrix} g_1 \\ g_2 \end{bmatrix} = \begin{bmatrix} x_1^2 + x_2 \\ x_1 x_2 \end{bmatrix}.$$

Os gradientes das componentes são

$$\nabla_{\mathbf{x}} g_1 = \begin{bmatrix} 2x_1 \\ 1 \end{bmatrix}$$

e

$$\nabla_{\mathbf{x}} g_2 = \begin{bmatrix} x_2 \\ x_1 \end{bmatrix}.$$

Logo,

$$\mathbf{J}_{\mathbf{g}}(x_1, x_2) = \begin{bmatrix} 2x_1 & 1 \\ x_2 & x_1 \end{bmatrix}.$$

No ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 2 \end{bmatrix},$$

tem-se

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}_0) = \begin{bmatrix} 2 & 1 \\ 2 & 1 \end{bmatrix}.$$

Para uma pequena perturbação

$$\mathbf{h} = \begin{bmatrix} h_1 \\ h_2 \end{bmatrix},$$

a alteração é aproximada por

$$\mathbf{g}(\mathbf{x}_0 + \mathbf{h}) - \mathbf{g}(\mathbf{x}_0) \approx \begin{bmatrix} 2 & 1 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} h_1 \\ h_2 \end{bmatrix}.$$

Para uma transformação afim

$$\mathbf{g}(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b},$$

a Jacobiana é constante:

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}.$$

Assim, a parte linear local de uma transformação afim é exatamente a matriz $\mathbf{A}$, enquanto o termo de translação desaparece na diferenciação.

7.2.4 Regra da cadeia

A composição de funções exige a composição de suas aproximações lineares.

Teorema 7.1 (Regra da cadeia para funções vetoriais). *Considere funções diferenciáveis*

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

e

$$\mathbf{h} : \mathbb{R}^q \longrightarrow \mathbb{R}^r.$$

Para

$$\mathbf{f} = \mathbf{h} \circ \mathbf{g},$$

a Jacobiana é

$$\mathbf{J}_{\mathbf{f}}(\mathbf{x}) = \mathbf{J}_{\mathbf{h}}(\mathbf{g}(\mathbf{x})) \mathbf{J}_{\mathbf{g}}(\mathbf{x}).$$

(Apostol, 1969)

As dimensões do produto são

$$(r \times q)(q \times p) = r \times p.$$

A ordem do produto reflete a composição das aplicações lineares: sobre uma perturbação $\mathbf{h}_{\mathbf{x}} \in \mathbb{R}^p$, atua primeiro $\mathbf{J}_{\mathbf{g}}(\mathbf{x})$ e, sobre o resultado, atua $\mathbf{J}_{\mathbf{h}}(\mathbf{g}(\mathbf{x}))$. Por isso, na representação matricial, a Jacobiana de $\mathbf{h}$ aparece à esquerda.

No caso de uma composição escalar

$$f(\mathbf{x}) = h(\mathbf{g}(\mathbf{x})),$$

em que

$$h : \mathbb{R}^q \longrightarrow \mathbb{R},$$

a regra da cadeia assume a forma

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{J}_{\mathbf{g}}(\mathbf{x})^{\top} \nabla_{\mathbf{y}} h(\mathbf{y}) \Big|_{\mathbf{y}=\mathbf{g}(\mathbf{x})}.$$

Exemplo 7.5 (Gradiente de uma função composta). Considere

$$\mathbf{g}(\mathbf{x}) = \mathbf{Ax} - \mathbf{b}$$

e

$$h(\mathbf{y}) = \mathbf{y}^{\top} \mathbf{y}.$$

A função composta é

$$f(\mathbf{x}) = \|\mathbf{Ax} - \mathbf{b}\|^2.$$

Como

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}$$

e

$$\nabla_{\mathbf{y}} h(\mathbf{y}) = 2\mathbf{y},$$

segue que

$$\begin{aligned}\nabla_{\mathbf{x}} f(\mathbf{x}) &= \mathbf{A}^\top [2(\mathbf{Ax} - \mathbf{b})] \\ &= 2\mathbf{A}^\top (\mathbf{Ax} - \mathbf{b}).\end{aligned}$$

Essa expressão será retomada no estudo das funções de mínimos quadrados.

7.2.5 Hessiana

A Hessiana descreve a variação local do gradiente.

Definição 7.5 (Matriz Hessiana). Seja

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}$$

uma função com derivadas parciais de segunda ordem no ponto considerado. Sua matriz Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_p \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_p^2} \end{bmatrix} \in \mathbb{R}^{p \times p}.$$

A Hessiana é a Jacobiana do gradiente:

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{J}_{\nabla f}(\mathbf{x}).$$

Se as derivadas parciais de segunda ordem são contínuas em uma vizinhança do ponto, então

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i},$$

e a Hessiana é simétrica:

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \nabla_{\mathbf{x}}^2 f(\mathbf{x})^\top.$$

O segundo diferencial é

$$d^2 f = d\mathbf{x}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}) d\mathbf{x}.$$

O segundo diferencial é uma forma quadrática no incremento $d\mathbf{x}$ e descreve a contribuição local de segunda ordem da função.

Para uma direção $\mathbf{u}$, considere novamente

$$\varphi(t) = f(\mathbf{x} + t\mathbf{u}).$$

A primeira derivada é

$$\varphi'(0) = \nabla_{\mathbf{x}} f(\mathbf{x})^\top \mathbf{u}.$$

A segunda derivada é

$$\varphi''(0) = \mathbf{u}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}) \mathbf{u}.$$

Essa forma quadrática representa a segunda taxa de variação de f ao longo da reta que passa por $\mathbf{x}$ na direção $\mathbf{u}$ e fornece a medida de curvatura direcional utilizada neste capítulo.

Exemplo 7.6 (Hessiana de uma função quadrática). Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2.$$

O gradiente é

$$\nabla_{\mathbf{x}} f(x_1, x_2) = \begin{bmatrix} 2x_1 \\ 4x_2 \end{bmatrix}.$$

A Hessiana é

$$\nabla_{\mathbf{x}}^2 f(x_1, x_2) = \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix}.$$

Para

$$\mathbf{u} = \begin{bmatrix} u_1 \\ u_2 \end{bmatrix},$$

a curvatura direcional é

$$\begin{aligned}\mathbf{u}^\top \nabla_{\mathbf{x}}^2 f \mathbf{u} &= \begin{bmatrix} u_1 & u_2 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} \\ &= 2u_1^2 + 4u_2^2.\end{aligned}$$

Ela é positiva para todo vetor não nulo. Para vetores unitários, a segunda taxa de variação é maior nas direções com maior componente em módulo no segundo eixo.

Para a função quadrática

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + c,$$

com $\mathbf{A}$ simétrica,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{A} \mathbf{x} - \mathbf{b}$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A}.$$

A curvatura da função é determinada pela matriz $\mathbf{A}$. A relação entre a Hessiana, a aproximação de segunda ordem, a convexidade e a classificação de pontos estacionários será desenvolvida na próxima seção.

7.3 Aproximações de Taylor e classificação local

7.3.1 Aproximação de Taylor de primeira ordem

A diferenciabilidade fornece uma aproximação linear da função em uma vizinhança de um ponto.

Para

$$f : \mathbb{R}^p \longrightarrow \mathbb{R},$$

diferenciável em $\mathbf{x}_0$,

$$f(\mathbf{x}_0 + \mathbf{h}) = f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top \mathbf{h} + o(\|\mathbf{h}\|).$$

Tomando

$$\mathbf{h} = \mathbf{x} - \mathbf{x}_0,$$

obtém-se

$$f(\mathbf{x}) \approx f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^{\top} (\mathbf{x} - \mathbf{x}_0).$$

Essa é a aproximação de Taylor de primeira ordem.

Para funções de uma variável, ela corresponde à reta tangente. Para funções de duas variáveis, corresponde ao plano tangente. Em dimensão geral, corresponde a uma função afim que aproxima localmente f .

Exemplo 7.7 (Aproximação linear de uma função quadrática). Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2$$

e o ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1/2 \end{bmatrix}.$$

Tem-se

$$f(\mathbf{x}_0) = 1^2 + 2 \left(\frac{1}{2} \right)^2 = \frac{3}{2}$$

e

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0) = \begin{bmatrix} 2 \\ 2 \end{bmatrix}.$$

A aproximação de primeira ordem é

$$\begin{aligned} f(\mathbf{x}) &\approx \frac{3}{2} + [2 \quad 2] \left[\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} - \begin{bmatrix} 1 \\ 1/2 \end{bmatrix} \right] \\ &= \frac{3}{2} + 2(x_1 - 1) + 2 \left(x_2 - \frac{1}{2} \right). \end{aligned}$$

A aproximação linear descreve a variação determinada pelo gradiente. Ela não representa a curvatura da função.

7.3.2 Aproximação de Taylor de segunda ordem

Quando f é duas vezes diferenciável, a Hessiana permite incorporar a curvatura local.

Teorema 7.2 (Expansão de Taylor de segunda ordem). *Se*

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}$$

possui derivadas de segunda ordem contínuas em uma vizinhança de $\mathbf{x}_0$, então

$$\begin{aligned} f(\mathbf{x}_0 + \mathbf{h}) &= f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top \mathbf{h} \\ &\quad + \frac{1}{2} \mathbf{h}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}_0) \mathbf{h} + o(\|\mathbf{h}\|^2). \end{aligned}$$

(Apostol, 1969)

Em termos de $\mathbf{x} - \mathbf{x}_0$,

$$\begin{aligned} f(\mathbf{x}) &\approx f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top (\mathbf{x} - \mathbf{x}_0) \\ &\quad + \frac{1}{2} (\mathbf{x} - \mathbf{x}_0)^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}_0) (\mathbf{x} - \mathbf{x}_0). \end{aligned}$$

Os três termos possuem funções distintas:

- $f(\mathbf{x}_0)$ determina o nível da aproximação;
- o gradiente determina a variação local de primeira ordem;
- a Hessiana determina a variação local de segunda ordem.

Quando

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0) = \mathbf{0},$$

o termo linear desaparece. Se a forma quadrática associada à Hessiana é não degenerada, ela fornece o termo dominante da variação local. Quando essa forma se anula em alguma direção, termos de ordem superior podem ser necessários para determinar o comportamento da função.

Exemplo 7.8 (Expansão de uma função quadrática). Considere

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + c,$$

com $\mathbf{A}$ simétrica.

O gradiente é

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{A} \mathbf{x} - \mathbf{b},$$

e a Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A}.$$

Como a função é quadrática, a expansão de Taylor de segunda ordem é exata:

$$\begin{aligned} f(\mathbf{x}_0 + \mathbf{h}) &= f(\mathbf{x}_0) + (\mathbf{A} \mathbf{x}_0 - \mathbf{b})^\top \mathbf{h} \\ &\quad + \frac{1}{2} \mathbf{h}^\top \mathbf{A} \mathbf{h}. \end{aligned}$$

Não existe termo residual de ordem superior.

7.3.3 Pontos estacionários

Definição 7.6 (Ponto estacionário). Um ponto

$$\mathbf{x}^*$$

é estacionário para uma função diferenciável f quando

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}.$$

Em um ponto estacionário, todas as derivadas direcionais de primeira ordem são nulas:

$$D_{\mathbf{u}} f(\mathbf{x}^*) = 0$$

para toda direção $\mathbf{u}$.

Proposição 7.2 (Condição necessária de primeira ordem). *Se f é diferenciável em um ponto interior $\mathbf{x}^*$ de seu domínio e possui nesse ponto um máximo ou mínimo local, então*

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}.$$

Comprovação. Se

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) \neq \mathbf{0},$$

considere a direção unitária

$$\mathbf{u} = \frac{\nabla_{\mathbf{x}} f(\mathbf{x}^*)}{\|\nabla_{\mathbf{x}} f(\mathbf{x}^*)\|}.$$

Então,

$$D_{\mathbf{u}} f(\mathbf{x}^*) = \|\nabla_{\mathbf{x}} f(\mathbf{x}^*)\| > 0,$$

enquanto

$$D_{-\mathbf{u}} f(\mathbf{x}^*) = -\|\nabla_{\mathbf{x}} f(\mathbf{x}^*)\| < 0.$$

Assim, existem direções locais de aumento e de redução, o que contradiz a existência de um extremo local interior. Portanto,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}.$$

□

Como

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0},$$

tem-se

$$D_{\mathbf{u}} f(\mathbf{x}^*) = 0$$

para toda direção $\mathbf{u}$.

A recíproca da proposição anterior não é verdadeira em geral: um ponto estacionário pode ser mínimo local, máximo local ou ponto de sela.

7.3.4 Classificação pela Hessiana

Teorema 7.3 (Teste da Hessiana em um ponto estacionário). *Considere uma função duas vezes continuamente diferenciável em uma vizinhança de um ponto estacionário $\mathbf{x}^*$.*

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \succ \mathbf{0},$$

então $\mathbf{x}^$ é um mínimo local estrito.*

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \prec \mathbf{0},$$

então $\mathbf{x}^$ é um máximo local estrito.*

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^*)$$

é indefinida, então $\mathbf{x}^$ é um ponto de sela.*

Se a Hessiana é apenas semidefinida positiva ou semidefinida negativa, o teste pode ser inconclusivo. (Apostol, 1969)

Comprovação. Como

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0},$$

a expansão de Taylor fornece

$$f(\mathbf{x}^* + \mathbf{h}) - f(\mathbf{x}^*) = \frac{1}{2} \mathbf{h}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \mathbf{h} + o(\|\mathbf{h}\|^2).$$

Considere inicialmente

$$\mathbf{H} = \nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \succ \mathbf{0}.$$

Como $\mathbf{H}$ é simétrica e positiva definida, seu menor autovalor satisfaz

$$\lambda_{\min}(\mathbf{H}) > 0.$$

Portanto,

$$\mathbf{h}^\top \mathbf{H} \mathbf{h} \geq \lambda_{\min}(\mathbf{H}) \|\mathbf{h}\|^2.$$

Além disso,

$$o(\|\mathbf{h}\|^2) = \varepsilon(\mathbf{h}) \|\mathbf{h}\|^2,$$

com

$$\varepsilon(\mathbf{h}) \longrightarrow 0$$

quando $\mathbf{h} \rightarrow \mathbf{0}$.

Logo, para $\mathbf{h}$ suficientemente pequeno,

$$|\varepsilon(\mathbf{h})| < \frac{1}{4} \lambda_{\min}(\mathbf{H}).$$

Assim,

$$\begin{aligned} f(\mathbf{x}^* + \mathbf{h}) - f(\mathbf{x}^*) &\geq \frac{1}{2} \lambda_{\min}(\mathbf{H}) \|\mathbf{h}\|^2 - \frac{1}{4} \lambda_{\min}(\mathbf{H}) \|\mathbf{h}\|^2 \\ &= \frac{1}{4} \lambda_{\min}(\mathbf{H}) \|\mathbf{h}\|^2 \\ &> 0 \end{aligned}$$

para todo $\mathbf{h} \neq \mathbf{0}$ suficientemente pequeno. Portanto, $\mathbf{x}^*$ é um mínimo local estrito.

O caso de Hessiana negativa definida é obtido aplicando o mesmo argumento a $-f$, produzindo um máximo local estrito.

Se a Hessiana é indefinida, existem vetores unitários $\mathbf{u}_1$ e $\mathbf{u}_2$ tais que

$$\mathbf{u}_1^\top \mathbf{H} \mathbf{u}_1 > 0$$

e

$$\mathbf{u}_2^\top \mathbf{H} \mathbf{u}_2 < 0.$$

Considere perturbações da forma

$$\mathbf{h} = t\mathbf{u}_j.$$

Então,

$$f(\mathbf{x}^* + t\mathbf{u}_j) - f(\mathbf{x}^*) = \frac{1}{2}t^2\mathbf{u}_j^\top \mathbf{H}\mathbf{u}_j + o(t^2).$$

Para $|t|$ suficientemente pequeno, o sinal dessa diferença coincide com o sinal da forma quadrática. Assim, a função assume valores maiores que

$$f(\mathbf{x}^*)$$

em uma direção e menores em outra, arbitrariamente próximos de $\mathbf{x}^*$. Portanto, $\mathbf{x}^*$ é um ponto de sela. $\square$

Exemplo 7.9 (Mínimo, máximo e ponto de sela). Considere as funções

$$f_1(x_1, x_2) = x_1^2 + x_2^2,$$

$$f_2(x_1, x_2) = -x_1^2 - x_2^2$$

e

$$f_3(x_1, x_2) = x_1^2 - x_2^2.$$

As três possuem ponto estacionário na origem.

Para f_1 ,

$$\nabla_{\mathbf{x}}^2 f_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \succ \mathbf{0}.$$

Logo, a origem é um mínimo estrito.

Para f_2 ,

$$\nabla_{\mathbf{x}}^2 f_2 = \begin{bmatrix} -2 & 0 \\ 0 & -2 \end{bmatrix} \prec \mathbf{0}.$$

Logo, a origem é um máximo estrito.

Para f_3 ,

$$\nabla_{\mathbf{x}}^2 f_3 = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix}.$$

A Hessiana possui um autovalor positivo e outro negativo. Portanto, a origem é um ponto de sela.

A Figura 7.3 compara as curvas de nível dos três casos.




Figura 7.3: Curvas de nível associadas a um mínimo, um máximo e um ponto de sela.

7.3.5 Caso inconclusivo

Considere

$$f(x_1, x_2) = x_1^4 + x_2^4.$$

A origem é um ponto estacionário e

$$\nabla_{\mathbf{x}}^2 f(0, 0) = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}.$$

A Hessiana é semidefinida positiva, mas não positiva definida. Ainda assim,

$$f(x_1, x_2) \geq 0$$

para todos os pontos, com igualdade somente na origem. Portanto, a origem é um mínimo estrito.

Considere agora

$$g(x_1, x_2) = x_1^4 - x_2^4.$$

A Hessiana na origem também é nula. Entretanto, a função assume valores positivos e negativos em qualquer vizinhança da origem. O ponto é de sela.

Esses exemplos mostram que, quando o termo quadrático se anula em determinadas direções, é necessário examinar termos de ordem superior ou utilizar outro argumento.

7.4 Convexidade e concavidade

7.4.1 Conjuntos convexos

Definição 7.7 (Conjunto convexo). Um conjunto

$$\mathcal{C} \subseteq \mathbb{R}^p$$

é convexo quando, para quaisquer

$$\mathbf{x}, \mathbf{y} \in \mathcal{C}$$

e

$$t \in [0, 1],$$

tem-se

$$t\mathbf{x} + (1 - t)\mathbf{y} \in \mathcal{C}.$$

O vetor

$$t\mathbf{x} + (1 - t)\mathbf{y}$$

percorre o segmento de reta entre $\mathbf{x}$ e $\mathbf{y}$. Assim, um conjunto é convexo quando contém todos os segmentos que ligam seus pontos.

Subespaços, conjuntos afins como hiperplanos, bolas e regiões elipsoidais da forma

$$\left\{ \mathbf{x} : (\mathbf{x} - \mu)^\top \mathbf{A} (\mathbf{x} - \mu) \leq c \right\},$$

com $\mathbf{A} \succ \mathbf{0}$ e $c > 0$, e o cone das matrizes positivas definidas são exemplos de conjuntos convexos.

7.4.2 Funções convexas

Definição 7.8 (Função convexa). Uma função

$$f : \mathcal{C} \longrightarrow \mathbb{R},$$

definida em um conjunto convexo $\mathcal{C}$, é convexa quando

$$f(t\mathbf{x} + (1 - t)\mathbf{y}) \leq tf(\mathbf{x}) + (1 - t)f(\mathbf{y})$$

para quaisquer $\mathbf{x}, \mathbf{y} \in \mathcal{C}$ e $t \in [0, 1]$.

A função é estritamente convexa quando a desigualdade é estrita para $\mathbf{x} \neq \mathbf{y}$ e $t \in (0, 1)$.

Uma função é côncava quando $-f$ é convexa.

Geometricamente, o gráfico de uma função convexa permanece abaixo das cordas que ligam dois pontos de seu gráfico.

7.4.3 Caracterização de primeira ordem

Teorema 7.4 (Critério de primeira ordem para convexidade). *Se f é diferenciável em um conjunto convexo aberto $\mathcal{C}$, então f é convexa se, e somente se,*

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^\top (\mathbf{y} - \mathbf{x})$$

para quaisquer $\mathbf{x}, \mathbf{y} \in \mathcal{C}$. (Boyd; Vandenberghe, 2004)

A expressão

$$f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^\top (\mathbf{y} - \mathbf{x})$$

é a aproximação afim determinada pelo plano tangente em $\mathbf{x}$. Para uma função convexa, essa aproximação é um limite inferior global.

7.4.4 Caracterização pela Hessiana

Teorema 7.5 (Critério da Hessiana para convexidade). *Considere uma função*

$$f : \mathcal{C} \longrightarrow \mathbb{R}$$

duas vezes continuamente diferenciável em um conjunto convexo aberto

$$\mathcal{C} \subseteq \mathbb{R}^p.$$

Então, f é convexa em $\mathcal{C}$ se, e somente se,

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \succeq \mathbf{0}$$

para todo

$$\mathbf{x} \in \mathcal{C}.$$

Analogamente, f é côncava em $\mathcal{C}$ se, e somente se,

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \preceq \mathbf{0}$$

para todo

$$\mathbf{x} \in \mathcal{C}.$$

Além disso, se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \succ \mathbf{0}$$

para todo $\mathbf{x} \in \mathcal{C}$, então f é estritamente convexa. Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \prec \mathbf{0}$$

para todo $\mathbf{x} \in \mathcal{C}$, então f é estritamente côncava.

(Boyd; Vandenberghe, 2004)

Comprovação. Considere dois pontos distintos

$$\mathbf{x}, \mathbf{y} \in \mathcal{C}$$

e defina

$$g(t) = f(\mathbf{x} + t(\mathbf{y} - \mathbf{x})), \quad 0 \leq t \leq 1.$$

Como $\mathcal{C}$ é convexo, todo o segmento entre $\mathbf{x}$ e $\mathbf{y}$ pertence a $\mathcal{C}$.

Pela regra da cadeia,

$$g''(t) = (\mathbf{y} - \mathbf{x})^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x} + t(\mathbf{y} - \mathbf{x})) (\mathbf{y} - \mathbf{x}).$$

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{z}) \succeq \mathbf{0}$$

para todo $\mathbf{z} \in \mathcal{C}$, então

$$g''(t) \geq 0,$$

e, portanto, g é convexa em $[0, 1]$. Como isso vale para qualquer segmento contido em $\mathcal{C}$, f é convexa.

Reciprocamente, se f é convexa, então a restrição de f a qualquer reta é convexa. Para qualquer

$$\mathbf{x} \in \mathcal{C}$$

e qualquer direção

$$\mathbf{u} \in \mathbb{R}^p,$$

considere

$$h(t) = f(\mathbf{x} + t\mathbf{u})$$

para t suficientemente próximo de zero. A convexidade de h implica

$$h''(0) \geq 0.$$

Como

$$h''(0) = \mathbf{u}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}) \mathbf{u},$$

tem-se

$$\mathbf{u}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}) \mathbf{u} \geq 0$$

para todo $\mathbf{u}$. Logo,

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \succeq \mathbf{0}.$$

O resultado para funções côncavas segue aplicando o argumento a $-f$.

Se a Hessiana é positiva definida em todo ponto, então, para $\mathbf{x} \neq \mathbf{y}$,

$$g''(t) > 0$$

ao longo do segmento. Logo, g é estritamente convexa, e portanto f é estritamente convexa. O caso de Hessiana negativa definida é análogo. $\square$

A positividade da Hessiana deve ser verificada para todos os pontos do domínio considerado, e não somente em um ponto estacionário.

A condição

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \succ \mathbf{0}$$

em todo o domínio é suficiente para convexidade estrita, mas não é necessária. Uma função estritamente convexa pode possuir Hessiana singular em pontos isolados. Por exemplo,

$$f(x) = x^4$$

é estritamente convexa em $\mathbb{R}$, embora

$$f''(0) = 0.$$

7.4.5 Consequências para otimização

Proposição 7.3 (Pontos estacionários de funções convexas). *Se f é diferenciável e convexa em um conjunto convexo, qualquer ponto*

$$\mathbf{x}^*$$

que satisfaça

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}$$

é um mínimo global.

Se f é estritamente convexa e existe um ponto estacionário $\mathbf{x}^$, então esse ponto é o único minimizador global. (Boyd; Vandenberghe, 2004)*

Comprovação. Pela caracterização de primeira ordem,

$$f(\mathbf{x}) \geq f(\mathbf{x}^*) + \nabla_{\mathbf{x}} f(\mathbf{x}^*)^\top (\mathbf{x} - \mathbf{x}^*).$$

Como o gradiente é nulo,

$$f(\mathbf{x}) \geq f(\mathbf{x}^*)$$

para todo $\mathbf{x}$ do domínio.

Se a função é estritamente convexa, a igualdade só pode ocorrer em $\mathbf{x} = \mathbf{x}^*$. $\square$

Essa propriedade diferencia a otimização convexa da otimização geral. Para uma função convexa, não existem mínimos locais que deixem de ser globais.

7.4.6 Funções quadráticas

Considere

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + c,$$

com $\mathbf{A}$ simétrica.

Como

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A},$$

tem-se:

- f é convexa se $\mathbf{A} \succeq \mathbf{0}$;
- f é estritamente convexa se $\mathbf{A} \succ \mathbf{0}$;
- f é côncava se $\mathbf{A} \preceq \mathbf{0}$;
- f é estritamente côncava se $\mathbf{A} \prec \mathbf{0}$.

Se

$$\mathbf{A} \succ \mathbf{0},$$

o ponto estacionário satisfaz

$$\mathbf{A} \mathbf{x}^* = \mathbf{b},$$

e

$$\mathbf{x}^* = \mathbf{A}^{-1} \mathbf{b}.$$

Esse ponto é o único mínimo global.

Se

$$\mathbf{A} \succeq \mathbf{0}$$

é singular, a existência de minimizadores depende de $\mathbf{b}$.

Quando

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}),$$

o sistema

$$\mathbf{Ax} = \mathbf{b}$$

possui solução. Nesse caso, os minimizadores formam o conjunto afim

$$\mathbf{x}_0 + \mathcal{N}(\mathbf{A}),$$

em que $\mathbf{x}_0$ é uma solução particular.

Quando

$$\mathbf{b} \notin \mathcal{C}(\mathbf{A}),$$

a função é ilimitada inferiormente e não possui minimizador.

De fato, como $\mathbf{A}$ é simétrica,

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}).$$

Assim, existe

$$\mathbf{z} \in \mathcal{N}(\mathbf{A})$$

tal que

$$\mathbf{b}^\top \mathbf{z} \neq 0.$$

Ao longo da reta

$$\mathbf{x} = t\mathbf{z},$$

o termo quadrático é nulo e

$$f(t\mathbf{z}) = -t\mathbf{b}^\top \mathbf{z} + c,$$

que pode tender a $-\infty$ escolhendo o sinal apropriado de t .

7.5 Otimização sem restrições

Um problema de minimização sem restrições possui a forma

$$\min_{\mathbf{x} \in \mathbb{R}^p} f(\mathbf{x}).$$

A Proposição 7.2 estabelece a condição necessária de primeira ordem para extremos locais interiores, enquanto o Teorema 7.3 utiliza a Hessiana para classificar pontos estacionários quando o teste de segunda ordem é conclusivo.

No caso convexo, a Proposição 7.3 mostra que um ponto estacionário é minimizador global. Esses resultados fornecem as condições de otimalidade; a questão seguinte é construir um procedimento iterativo para localizar esses pontos.

7.5.1 Método de Newton

O método de Newton utiliza a aproximação quadrática local de f .

Em torno de um ponto $\mathbf{x}^{(t)}$,

$$\begin{aligned} f(\mathbf{x}) \approx & f(\mathbf{x}^{(t)}) + \nabla_{\mathbf{x}} f(\mathbf{x}^{(t)})^\top (\mathbf{x} - \mathbf{x}^{(t)}) \\ & + \frac{1}{2} (\mathbf{x} - \mathbf{x}^{(t)})^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)}) (\mathbf{x} - \mathbf{x}^{(t)}). \end{aligned}$$

Defina

$$\mathbf{g}^{(t)} = \nabla_{\mathbf{x}} f(\mathbf{x}^{(t)})$$

e

$$\mathbf{H}^{(t)} = \nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)}).$$

Escrevendo

$$\mathbf{d} = \mathbf{x} - \mathbf{x}^{(t)},$$

o modelo quadrático local pode ser representado por

$$m_t(\mathbf{d}) = f(\mathbf{x}^{(t)}) + (\mathbf{g}^{(t)})^\top \mathbf{d} + \frac{1}{2} \mathbf{d}^\top \mathbf{H}^{(t)} \mathbf{d}.$$

Seu gradiente em relação a $\mathbf{d}$ é

$$\nabla_{\mathbf{d}} m_t(\mathbf{d}) = \mathbf{g}^{(t)} + \mathbf{H}^{(t)} \mathbf{d}.$$

Se

$$\mathbf{H}^{(t)} \succ \mathbf{0},$$

o modelo quadrático é estritamente convexo e possui um único minimizador. Esse minimizador, denominado **direção de Newton**, satisfaz

$$\mathbf{H}^{(t)} \mathbf{d}^{(t)} = -\mathbf{g}^{(t)}.$$

Quando $\mathbf{H}^{(t)}$ é invertível,

$$\mathbf{d}^{(t)} = -(\mathbf{H}^{(t)})^{-1} \mathbf{g}^{(t)}.$$

A atualização de Newton com passo completo é

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} + \mathbf{d}^{(t)},$$

ou, equivalentemente,

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} - [\nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)})]^{-1} \nabla_{\mathbf{x}} f(\mathbf{x}^{(t)}).$$

Na implementação computacional, é preferível resolver o sistema linear

$$\mathbf{H}^{(t)} \mathbf{d}^{(t)} = -\mathbf{g}^{(t)}$$

sem calcular explicitamente a inversa da Hessiana.

Se a Hessiana é apenas invertível, mas não positiva definida, a solução desse sistema é um ponto estacionário do modelo quadrático, mas pode não ser seu minimizador. Nesse caso, a direção de Newton também pode deixar de ser uma direção de descida para a função original.

Proposição 7.4 (Direção de Newton como direção de descida). *Suponha que*

$$\nabla_{\mathbf{x}} f(\mathbf{x}^{(t)}) \neq \mathbf{0}$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)}) \succ \mathbf{0}.$$

Então a direção de Newton $\mathbf{d}^{(t)}$ é uma direção de descida para f em $\mathbf{x}^{(t)}$, isto é,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^{(t)})^\top \mathbf{d}^{(t)} < 0.$$

Comprovação. Como

$$\mathbf{d}^{(t)} = -(\mathbf{H}^{(t)})^{-1} \mathbf{g}^{(t)},$$

tem-se

$$(\mathbf{g}^{(t)})^\top \mathbf{d}^{(t)} = -(\mathbf{g}^{(t)})^\top (\mathbf{H}^{(t)})^{-1} \mathbf{g}^{(t)}.$$

Como $\mathbf{H}^{(t)} \succ \mathbf{0}$, também

$$(\mathbf{H}^{(t)})^{-1} \succ \mathbf{0}.$$

Logo, para $\mathbf{g}^{(t)} \neq \mathbf{0}$,

$$(\mathbf{g}^{(t)})^\top (\mathbf{H}^{(t)})^{-1} \mathbf{g}^{(t)} > 0,$$

e, portanto,

$$(\mathbf{g}^{(t)})^\top \mathbf{d}^{(t)} < 0.$$

□

O passo completo corresponde a

$$\alpha_t = 1.$$

Uma forma mais geral da atualização é

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} + \alpha_t \mathbf{d}^{(t)}, \quad 0 < \alpha_t \leq 1.$$

A escolha de $\alpha_t < 1$ produz um passo de Newton amortecido. Esse recurso pode ser utilizado quando o modelo quadrático local ainda não representa adequadamente a função ao longo de um passo completo.

Assim, a construção da direção e a escolha do comprimento da etapa são operações distintas. Métodos numéricos de otimização costumam combinar a direção de Newton com procedimentos de controle da etapa (Boyd; Vandenberghe, 2004).

Exemplo 7.10 (Newton para uma função quadrática). Considere

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x},$$

com $\mathbf{A} \succ \mathbf{0}$.

O gradiente é

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{A} \mathbf{x} - \mathbf{b},$$

e a Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A}.$$

A atualização de Newton é

$$\begin{aligned} \mathbf{x}^{(t+1)} &= \mathbf{x}^{(t)} - \mathbf{A}^{-1} (\mathbf{A} \mathbf{x}^{(t)} - \mathbf{b}) \\ &= \mathbf{A}^{-1} \mathbf{b}. \end{aligned}$$

Assim, para uma função quadrática com Hessiana constante e positiva definida, uma etapa completa de Newton conduz exatamente ao único minimizador,

$$\mathbf{x}^* = \mathbf{A}^{-1} \mathbf{b},$$

independentemente do ponto inicial.

7.6 Otimização com restrições de igualdade

Considere o problema

$$\min_{\mathbf{x} \in \mathbb{R}^p} f(\mathbf{x})$$

sujeito a

$$\mathbf{c}(\mathbf{x}) = \mathbf{0},$$

em que

$$\mathbf{c} : \mathbb{R}^p \longrightarrow \mathbb{R}^m$$

é uma função vetorial de restrições:

$$\mathbf{c}(\mathbf{x}) = \begin{bmatrix} c_1(\mathbf{x}) \\ \vdots \\ c_m(\mathbf{x}) \end{bmatrix}.$$

O conjunto viável é

$$\mathcal{F} = \{\mathbf{x} : \mathbf{c}(\mathbf{x}) = \mathbf{0}\}.$$

Em um ponto regular, as linhas da Jacobiana das restrições são linearmente independentes. O espaço tangente ao conjunto viável é então

$$\mathcal{T}_{\mathbf{x}} = \mathcal{N}(\mathbf{J}_{\mathbf{c}}(\mathbf{x})).$$

Portanto, uma direção tangente $\mathbf{d}$ satisfaz

$$\mathbf{J}_{\mathbf{c}}(\mathbf{x})\mathbf{d} = \mathbf{0}.$$

O espaço normal correspondente é

$$\mathcal{T}_{\mathbf{x}}^{\perp} = \mathcal{C}(\mathbf{J}_{\mathbf{c}}(\mathbf{x})^{\top}),$$

isto é, o espaço gerado pelos gradientes das restrições.

Em um ótimo local regular $\mathbf{x}^*$, a derivada direcional de f deve ser nula em todas as direções tangentes:

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*)^\top \mathbf{d} = 0$$

para todo

$$\mathbf{d} \in \mathcal{T}_{\mathbf{x}^*}.$$

Consequentemente,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) \in \mathcal{T}_{\mathbf{x}^*}^\perp = \mathcal{C} \left[\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)^\top \right].$$

7.6.1 Multiplicadores de Lagrange

Teorema 7.6 (Condição de Lagrange). *Considere funções continuamente diferenciáveis*

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}$$

e

$$\mathbf{c} : \mathbb{R}^p \longrightarrow \mathbb{R}^m.$$

Seja $\mathbf{x}^*$ um ótimo local do problema

$$\min_{\mathbf{x}} f(\mathbf{x})$$

sujeito a

$$\mathbf{c}(\mathbf{x}) = \mathbf{0}.$$

Suponha que as linhas da Jacobiana

$$\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)$$

sejam linearmente independentes.

Essa condição equivale a

$$\text{posto} [\mathbf{J}_c (\mathbf{x}^*)] = m.$$

Então existe um vetor

$$\lambda^* \in \mathbb{R}^m$$

tal que

$$\nabla_{\mathbf{x}} f (\mathbf{x}^*) + \mathbf{J}_c (\mathbf{x}^*)^\top \lambda^* = \mathbf{0}.$$

(Apostol, 1969)

Comprovação. Como $\mathbf{x}^*$ é um ótimo local regular, a derivada direcional da função objetivo é nula em todas as direções tangentes ao conjunto viável. Portanto,

$$\nabla_{\mathbf{x}} f (\mathbf{x}^*)^\top \mathbf{d} = 0$$

para todo

$$\mathbf{d} \in \mathcal{N} [\mathbf{J}_c (\mathbf{x}^*)].$$

Logo,

$$\nabla_{\mathbf{x}} f (\mathbf{x}^*) \in \mathcal{N} [\mathbf{J}_c (\mathbf{x}^*)]^\perp.$$

Pelo Teorema 3.6,

$$\mathcal{N} [\mathbf{J}_c (\mathbf{x}^*)]^\perp = \mathcal{C} [\mathbf{J}_c (\mathbf{x}^*)^\top].$$

Assim, existe um vetor

$$\mu^* \in \mathbb{R}^m$$

tal que

$$\nabla_{\mathbf{x}} f (\mathbf{x}^*) = \mathbf{J}_c (\mathbf{x}^*)^\top \mu^*.$$

Definindo

$$\lambda^* = -\mu^*,$$

obtém-se

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) + \mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)^\top \lambda^* = \mathbf{0}.$$

□

A função lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = f(\mathbf{x}) + \lambda^\top \mathbf{c}(\mathbf{x}).$$

Sob a condição de regularidade do teorema, as condições necessárias de primeira ordem podem ser escritas como

$$\nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \lambda) = \mathbf{0}$$

e

$$\nabla_{\lambda} \mathcal{L}(\mathbf{x}, \lambda) = \mathbf{c}(\mathbf{x}) = \mathbf{0}.$$

Essas condições identificam candidatos a ótimo restrito. No caso geral, elas não são suficientes para garantir mínimo ou máximo. A classificação exige condições adicionais sobre a função objetivo, as restrições e a variação de segunda ordem nas direções tangentes.

Os multiplicadores ajustam a condição de gradiente nulo para levar em conta as direções que não estão disponíveis devido às restrições.

Exemplo 7.11 (Otimização com restrição de norma). Considere o problema

$$\max_{\mathbf{x}} \mathbf{a}^\top \mathbf{x},$$

em que

$$\mathbf{a} \neq \mathbf{0},$$

sujeito à restrição

$$\mathbf{x}^\top \mathbf{x} = 1.$$

A restrição exige que $\mathbf{x}$ tenha norma euclidiana unitária:

$$\|\mathbf{x}\| = 1.$$

Escrevendo-a na forma

$$c(\mathbf{x}) = \mathbf{x}^\top \mathbf{x} - 1 = 0,$$

o problema pode ser tratado pelos multiplicadores de Lagrange.

Para manter a formulação como um problema de minimização, considere a função objetivo

$$f(\mathbf{x}) = -\mathbf{a}^\top \mathbf{x}.$$

A lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = -\mathbf{a}^\top \mathbf{x} + \lambda (\mathbf{x}^\top \mathbf{x} - 1).$$

As condições de primeira ordem são obtidas diferenciando a lagrangiana em relação a $\mathbf{x}$ e ao multiplicador λ .

Em relação a $\mathbf{x}$,

$$\nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \lambda) = -\mathbf{a} + 2\lambda \mathbf{x}.$$

Portanto, em um ponto candidato à solução,

$$-\mathbf{a} + 2\lambda \mathbf{x} = \mathbf{0},$$

de modo que

$$\mathbf{x} = \frac{1}{2\lambda} \mathbf{a}.$$

Em relação a λ ,

$$\frac{\partial \mathcal{L}(\mathbf{x}, \lambda)}{\partial \lambda} = \mathbf{x}^\top \mathbf{x} - 1.$$

Assim, a segunda condição de primeira ordem simplesmente recupera a restrição:

$$\mathbf{x}^\top \mathbf{x} = 1.$$

Substituindo

$$\mathbf{x} = \frac{1}{2\lambda} \mathbf{a}$$

na restrição,

$$\left(\frac{1}{2\lambda} \mathbf{a} \right)^\top \left(\frac{1}{2\lambda} \mathbf{a} \right) = 1,$$

e, portanto,

$$\frac{\mathbf{a}^\top \mathbf{a}}{4\lambda^2} = 1.$$

Como

$$\mathbf{a}^\top \mathbf{a} = \|\mathbf{a}\|^2,$$

segue que

$$4\lambda^2 = \|\mathbf{a}\|^2,$$

ou

$$\lambda = \pm \frac{\|\mathbf{a}\|}{2}.$$

Consequentemente, existem dois pontos candidatos:

$$\mathbf{x}_1 = \frac{\mathbf{a}}{\|\mathbf{a}\|}$$

e

$$\mathbf{x}_2 = -\frac{\mathbf{a}}{\|\mathbf{a}\|}.$$

Para identificar qual deles maximiza a função objetivo original, avalie

$$\mathbf{a}^\top \mathbf{x}.$$

No primeiro ponto,

$$\mathbf{a}^\top \mathbf{x}_1 = \mathbf{a}^\top \frac{\mathbf{a}}{\|\mathbf{a}\|} = \frac{\|\mathbf{a}\|^2}{\|\mathbf{a}\|} = \|\mathbf{a}\|.$$

No segundo,

$$\mathbf{a}^\top \mathbf{x}_2 = -\|\mathbf{a}\|.$$

Logo, o máximo é atingido em

$$\mathbf{x}^* = \frac{\mathbf{a}}{\|\mathbf{a}\|},$$

e o valor máximo é

$$\mathbf{a}^\top \mathbf{x}^* = \|\mathbf{a}\|.$$

Geometricamente, a solução mostra que, entre todos os vetores unitários, o produto interno com $\mathbf{a}$ é máximo quando $\mathbf{x}$ possui a mesma direção e o mesmo sentido de $\mathbf{a}$.

O resultado também coincide com o caso de igualdade no Teorema 1.1, pois

$$\mathbf{a}^\top \mathbf{x} \leq \|\mathbf{a}\| \|\mathbf{x}\| = \|\mathbf{a}\|,$$

e a igualdade ocorre quando $\mathbf{x}$ é proporcional a $\mathbf{a}$.

Se $\mathbf{a} = \mathbf{0}$, a função objetivo é constante e todo vetor unitário satisfaz

$$\mathbf{a}^\top \mathbf{x} = 0.$$

Nesse caso, todo vetor que satisfaz a restrição é uma solução ótima.

7.6.2 Relação com problemas de autovalores

Considere o problema

$$\max_{\mathbf{x}} \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

sujeito a

$$\mathbf{x}^\top \mathbf{x} = 1,$$

com $\mathbf{A}$ simétrica.

A lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = \mathbf{x}^\top \mathbf{A} \mathbf{x} - \lambda (\mathbf{x}^\top \mathbf{x} - 1).$$

A condição de primeira ordem é

$$2\mathbf{A}\mathbf{x} - 2\lambda\mathbf{x} = \mathbf{0},$$

ou

$$\mathbf{A}\mathbf{x} = \lambda\mathbf{x}.$$

Portanto, todo ponto regular estacionário do problema restrito é um autovetor de $\mathbf{A}$, e o valor da função objetivo nesse ponto é o autovalor correspondente.

Pelo Teorema 5.5, desenvolvido no capítulo de decomposição espectral,

$$\max_{\|\mathbf{x}\|=1} \mathbf{x}^\top \mathbf{A} \mathbf{x} = \lambda_{\max}(\mathbf{A}),$$

e

$$\min_{\|\mathbf{x}\|=1} \mathbf{x}^\top \mathbf{A} \mathbf{x} = \lambda_{\min}(\mathbf{A}).$$

Assim, os multiplicadores de Lagrange produzem a equação de autovalores como condição de estacionariedade, enquanto o resultado espectral identifica quais desses pontos realizam os extremos globais.

7.6.3 Restrições lineares

Considere o problema quadrático

$$\min_{\mathbf{x}} \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x}$$

sujeito a

$$\mathbf{C} \mathbf{x} = \mathbf{d},$$

em que

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é simétrica,

$$\mathbf{C} \in \mathbb{R}^{m \times p}$$

e

$$\mathbf{d} \in \mathbb{R}^m.$$

A lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + \lambda^\top (\mathbf{C} \mathbf{x} - \mathbf{d}).$$

As condições de primeira ordem são

$$\mathbf{A} \mathbf{x} - \mathbf{b} + \mathbf{C}^\top \lambda = \mathbf{0}$$

e

$$\mathbf{C} \mathbf{x} = \mathbf{d}.$$

Essas condições podem ser organizadas no sistema em blocos

$$\begin{bmatrix} \mathbf{A} & \mathbf{C}^\top \\ \mathbf{C} & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{x} \\ \lambda \end{bmatrix} = \begin{bmatrix} \mathbf{b} \\ \mathbf{d} \end{bmatrix}.$$

Esse sistema em blocos reúne as condições de primeira ordem do problema restrito.

Se

$$\mathbf{A} \succ \mathbf{0}$$

e $\mathbf{C}$ possui posto linha completo, a função objetivo é estritamente convexa e o conjunto definido por

$$\mathbf{C}\mathbf{x} = \mathbf{d}$$

é afim. Quando esse conjunto é não vazio, as condições de primeira ordem identificam o único minimizador global.

Mais geralmente, para uma matriz $\mathbf{A}$ semidefinida positiva, a unicidade depende de a forma quadrática ser positiva nas direções viáveis não nulas, isto é,

$$\mathbf{z}^\top \mathbf{A} \mathbf{z} > 0$$

para todo

$$\mathbf{z} \neq \mathbf{0}$$

tal que

$$\mathbf{C}\mathbf{z} = \mathbf{0}.$$

Sem condições desse tipo, a resolução do sistema fornece apenas candidatos que satisfazem as condições de primeira ordem.

As ferramentas desta seção serão aplicadas a funções de resíduos, critérios quadráticos e funções de parâmetros matriciais.

7.7 Derivadas de formas lineares, quadráticas e funções de resíduos

7.7.1 Formas lineares e bilineares

Considere

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

em que $\mathbf{a} \in \mathbb{R}^p$ é constante. Como

$$df = \mathbf{a}^\top d\mathbf{x},$$

tem-se

$$\nabla_{\mathbf{x}} f = \mathbf{a}$$

e

$$\nabla_{\mathbf{x}}^2 f = \mathbf{0}.$$

Para a forma bilinear

$$f(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y},$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times q},$$

o diferencial é

$$df = d\mathbf{x}^\top \mathbf{A} \mathbf{y} + \mathbf{x}^\top \mathbf{A} d\mathbf{y}.$$

Reescrevendo o primeiro termo,

$$d\mathbf{x}^\top \mathbf{A} \mathbf{y} = (\mathbf{A} \mathbf{y})^\top d\mathbf{x},$$

e o segundo,

$$\mathbf{x}^\top \mathbf{A} d\mathbf{y} = (\mathbf{A}^\top \mathbf{x})^\top d\mathbf{y}.$$

Logo,

$$\nabla_{\mathbf{x}} f = \mathbf{A} \mathbf{y}$$

e

$$\nabla_{\mathbf{y}} f = \mathbf{A}^\top \mathbf{x}.$$

7.7.2 Derivadas de formas quadráticas

As formas quadráticas foram definidas em Definição 2.23, e a Proposição 2.10 mostrou que seu valor depende apenas da parte simétrica da matriz. O objetivo agora é obter suas derivadas.

Considere

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x},$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

O diferencial é

$$\begin{aligned} df &= d\mathbf{x}^\top \mathbf{A} \mathbf{x} + \mathbf{x}^\top \mathbf{A} d\mathbf{x} \\ &= \mathbf{x}^\top \mathbf{A}^\top d\mathbf{x} + \mathbf{x}^\top \mathbf{A} d\mathbf{x} \\ &= [(\mathbf{A} + \mathbf{A}^\top) \mathbf{x}]^\top d\mathbf{x}. \end{aligned}$$

Portanto,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A} + \mathbf{A}^\top.$$

A forma quadrática depende somente da parte simétrica da matriz:

$$\mathbf{A}_s = \frac{\mathbf{A} + \mathbf{A}^\top}{2}.$$

Assim,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{A}_s \mathbf{x},$$

e

$$\nabla_{\mathbf{x}} (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{A}_s \mathbf{x}.$$

Quando $\mathbf{A}$ é simétrica,

$$\nabla_{\mathbf{x}} (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{A} \mathbf{x}$$

e

$$\nabla_{\mathbf{x}}^2 (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{A}.$$

Proposição 7.5 (Derivadas de uma forma quadrática deslocada). *Se $\mathbf{A}$ é simétrica e*

$$f(\mathbf{x}) = (\mathbf{x} - \mu)^\top \mathbf{A} (\mathbf{x} - \mu),$$

então

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{A} (\mathbf{x} - \mu)$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}.$$

Comprovação. Defina

$$\mathbf{z} = \mathbf{x} - \mu.$$

Como

$$d\mathbf{z} = d\mathbf{x},$$

tem-se

$$\begin{aligned} df &= d\mathbf{z}^\top \mathbf{A} \mathbf{z} + \mathbf{z}^\top \mathbf{A} d\mathbf{z} \\ &= 2\mathbf{z}^\top \mathbf{A} d\mathbf{x}, \end{aligned}$$

pois $\mathbf{A}$ é simétrica. Portanto,

$$\nabla_{\mathbf{x}} f = 2\mathbf{A} \mathbf{z} = 2\mathbf{A} (\mathbf{x} - \mu).$$

A diferenciação do gradiente fornece a Hessiana. □

Utilizando a classificação de positividade apresentada em Definição 2.24, se

$$\mathbf{A} \succeq \mathbf{0},$$

a forma quadrática deslocada é convexa. Se

$$\mathbf{A} \succ \mathbf{0},$$

ela é estritamente convexa e possui mínimo único em

$$\mathbf{x} = \mu.$$

Se

$$\mathbf{A} \succeq \mathbf{0}$$

é singular, todos os vetores da forma

$$\mathbf{x} = \mu + \mathbf{z}, \quad \mathbf{z} \in \mathcal{N}(\mathbf{A}),$$

também minimizam a função. Portanto, a unicidade ocorre quando

$$\mathbf{A} \succ \mathbf{0}.$$

7.7.3 Derivadas da norma euclidiana

Retomando a norma euclidiana definida em Definição 1.10,

$$\|\mathbf{x}\|^2 = \mathbf{x}^\top \mathbf{x}.$$

Portanto,

segue que

$$\nabla_{\mathbf{x}} \|\mathbf{x}\|^2 = 2\mathbf{x}$$

e

$$\nabla_{\mathbf{x}}^2 \|\mathbf{x}\|^2 = 2\mathbf{I}_p.$$

Para $\mathbf{x} \neq \mathbf{0}$,

$$\|\mathbf{x}\| = (\mathbf{x}^\top \mathbf{x})^{1/2}.$$

Pela regra da cadeia,

$$\nabla_{\mathbf{x}} \|\mathbf{x}\| = \frac{\mathbf{x}}{\|\mathbf{x}\|}.$$

A norma euclidiana não é diferenciável em $\mathbf{x} = \mathbf{0}$.

7.7.4 Funções de resíduos lineares

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}, \quad \mathbf{b} \in \mathbb{R}^q,$$

e defina o vetor de resíduos

$$\mathbf{r}(\mathbf{x}) = \mathbf{b} - \mathbf{A}\mathbf{x}.$$

Sua Jacobiana é

$$\mathbf{J}_{\mathbf{r}}(\mathbf{x}) = -\mathbf{A}.$$

A soma de quadrados dos resíduos é

$$f(\mathbf{x}) = \|\mathbf{r}(\mathbf{x})\|^2 = (\mathbf{b} - \mathbf{Ax})^\top (\mathbf{b} - \mathbf{Ax}).$$

Pela regra da cadeia,

$$\begin{aligned}\nabla_{\mathbf{x}} f(\mathbf{x}) &= 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^\top \mathbf{r}(\mathbf{x}) \\ &= -2\mathbf{A}^\top (\mathbf{b} - \mathbf{Ax}).\end{aligned}$$

Equivalentemente,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{A}^\top (\mathbf{Ax} - \mathbf{b}).$$

A Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}^\top \mathbf{A}.$$

A Hessiana é constante e não depende de $\mathbf{x}$. Além disso,

$$\mathbf{z}^\top \mathbf{A}^\top \mathbf{A} \mathbf{z} = \|\mathbf{Az}\|^2 \geq 0,$$

para todo

$$\mathbf{z} \in \mathbb{R}^p.$$

Portanto,

$$\mathbf{A}^\top \mathbf{A} \succeq \mathbf{0}.$$

Como

$$\mathbf{A}^\top \mathbf{A} \succeq \mathbf{0},$$

a função é convexa.

Se $\mathbf{A}$ possui posto coluna completo,

$$\mathbf{A}^\top \mathbf{A} \succ \mathbf{0},$$

e a função é estritamente convexa.

As equações normais já foram introduzidas geometricamente em Definição 3.21, a partir da projeção sobre o espaço coluna. No Capítulo 6, Proposição 6.22 apresentou a solução por meio da SVD e da pseudoinversa. Nesta seção, o mesmo resultado será obtido a partir da condição de primeira ordem do cálculo diferencial.

7.7.5 Equações normais

Proposição 7.6 (Caracterização dos mínimos quadrados pelas equações normais). *Considere*

$$f(\mathbf{x}) = \|\mathbf{b} - \mathbf{A}\mathbf{x}\|^2,$$

com

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{b} \in \mathbb{R}^q.$$

Um vetor

$$\hat{\mathbf{x}} \in \mathbb{R}^p$$

é minimizador global de f se, e somente se, satisfaz as equações normais

$$\mathbf{A}^\top \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{b}.$$

Equivalentemente,

$$\mathbf{A}^\top (\mathbf{b} - \mathbf{A} \hat{\mathbf{x}}) = \mathbf{0}.$$

Se $\mathbf{A}$ possui posto coluna completo, o minimizador é único e dado por

$$\hat{\mathbf{x}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

Comprovação. A derivação anterior fornece

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{A}^\top (\mathbf{Ax} - \mathbf{b})$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}^\top \mathbf{A} \succeq \mathbf{0}.$$

Logo, f é convexa. Pelo Proposição 7.3, um ponto é minimizador global se, e somente se, seu gradiente é nulo. Portanto,

$$\nabla_{\mathbf{x}} f(\hat{\mathbf{x}}) = \mathbf{0}$$

se, e somente se,

$$\mathbf{A}^\top \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{b}.$$

Se $\mathbf{A}$ possui posto coluna completo,

$$\mathbf{A}^\top \mathbf{A} \succ \mathbf{0},$$

de modo que f é estritamente convexa e possui, no máximo, um minimizador. Como

$$\mathbf{A}^\top \mathbf{A}$$

é invertível, esse minimizador é

$$\hat{\mathbf{x}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

□

A condição

$$\mathbf{A}^\top (\mathbf{b} - \mathbf{A}\hat{\mathbf{x}}) = \mathbf{0}$$

mostra que o resíduo de mínimos quadrados é ortogonal ao espaço coluna de $\mathbf{A}$.

O caso de posto deficiente, o conjunto de todos os minimizadores e a solução de menor norma foram estabelecidos em Proposição 6.22. Aqui, o objetivo é destacar que as equações normais surgem diretamente da condição de primeira ordem do problema de otimização.

Exemplo 7.12 (Média como solução de mínimos quadrados). Considere valores

$$z_1, \dots, z_n$$

e a função

$$f(m) = \sum_{i=1}^n (z_i - m)^2.$$

A derivada é

$$\begin{aligned} f'(m) &= -2 \sum_{i=1}^n (z_i - m) \\ &= 2nm - 2 \sum_{i=1}^n z_i. \end{aligned}$$

A condição

$$f'(m) = 0$$

fornece

$$m = \frac{1}{n} \sum_{i=1}^n z_i.$$

Como

$$f''(m) = 2n > 0,$$

a média aritmética é o único minimizador da soma dos quadrados dos desvios.

7.7.6 Mínimos quadrados ponderados

Considere pesos não negativos

$$\omega_1, \dots, \omega_q \geq 0$$

e a matriz diagonal

$$\Omega = \text{diag}(\omega_1, \dots, \omega_q).$$

A função de mínimos quadrados ponderados é

$$f_\omega(\mathbf{x}) = (\mathbf{b} - \mathbf{Ax})^\top \Omega (\mathbf{b} - \mathbf{Ax}).$$

Como Ω é diagonal e, portanto, simétrica,

$$\nabla_{\mathbf{x}} f_\omega(\mathbf{x}) = -2\mathbf{A}^\top \Omega (\mathbf{b} - \mathbf{Ax})$$

e

$$\nabla_{\mathbf{x}}^2 f_\omega(\mathbf{x}) = 2\mathbf{A}^\top \Omega \mathbf{A}.$$

Se

$$\Omega \succeq \mathbf{0},$$

a função é convexa.

As equações normais ponderadas são

$$\mathbf{A}^\top \Omega \mathbf{Ax} = \mathbf{A}^\top \Omega \mathbf{b}.$$

Equivalentemente,

$$\mathbf{A}^\top \Omega \mathbf{r}(\mathbf{x}) = \mathbf{0}.$$

Portanto, em qualquer minimizador, o resíduo satisfaz a condição de ortogonalidade ponderada

$$\mathbf{A}^\top \Omega \mathbf{r}(\mathbf{x}) = \mathbf{0}.$$

Quando

$$\Omega \succ \mathbf{0},$$

retoma-se o produto interno induzido definido em Definição 3.16:

$$\langle \mathbf{u}, \mathbf{v} \rangle_{\Omega} = \mathbf{u}^{\top} \Omega \mathbf{v}.$$

A condição anterior corresponde, portanto, à ortogonalidade do resíduo ao espaço coluna de $\mathbf{A}$ nessa geometria ponderada.

Se Ω é singular, a mesma condição algébrica permanece válida, mas a forma ponderada é apenas semidefinida positiva e não define um produto interno em todo o espaço.

Se

$$\Omega \succ \mathbf{0}$$

e $\mathbf{A}$ possui posto coluna completo, então

$$\mathbf{A}^{\top} \Omega \mathbf{A} \succ \mathbf{0},$$

e o minimizador é único:

$$\hat{\mathbf{x}} = (\mathbf{A}^{\top} \Omega \mathbf{A})^{-1} \mathbf{A}^{\top} \Omega \mathbf{b}.$$

A matriz Ω modifica a importância relativa dos resíduos. Para uma matriz diagonal, cada observação recebe um peso próprio.

Quando

$$\Omega \succ \mathbf{0},$$

o critério pode ser escrito utilizando a norma induzida de Definição 3.17:

$$f_{\omega}(\mathbf{x}) = \|\mathbf{b} - \mathbf{Ax}\|_{\Omega}^2,$$

com

$$\|\mathbf{z}\|_{\Omega}^2 = \mathbf{z}^{\top} \Omega \mathbf{z}.$$

Assim, os mínimos quadrados ponderados correspondem a uma projeção segundo a geometria induzida por Ω .

7.7.7 Funções compostas de resíduos

Considere uma função diferenciável

$$\rho : \mathbb{R} \longrightarrow \mathbb{R}$$

e resíduos escalares

$$r_i(\mathbf{x}), \quad i = 1, \dots, q.$$

Uma classe ampla de funções de ajuste pode ser escrita como

$$f(\mathbf{x}) = \sum_{i=1}^q \rho(r_i(\mathbf{x})).$$

Pela regra da cadeia,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \sum_{i=1}^q \rho'(r_i(\mathbf{x})) \nabla_{\mathbf{x}} r_i(\mathbf{x}).$$

Se

$$\rho(t) = t^2,$$

então

$$\rho'(t) = 2t,$$

e recupera-se a soma de quadrados.

Essa formulação mostra que diferentes funções de perda modificam a contribuição de cada resíduo no gradiente.

7.7.8 Mínimos quadrados não lineares

Considere uma função residual duas vezes diferenciável

$$\mathbf{r} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

e o critério

$$f(\mathbf{x}) = \|\mathbf{r}(\mathbf{x})\|^2.$$

A Jacobiana dos resíduos é

$$\mathbf{J}_{\mathbf{r}}(\mathbf{x}) \in \mathbb{R}^{q \times p}.$$

Proposição 7.7 (Derivadas de uma soma de quadrados não linear). *Para*

$$f(\mathbf{x}) = \sum_{i=1}^q r_i(\mathbf{x})^2,$$

tem-se

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^\top \mathbf{r}(\mathbf{x})$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^\top \mathbf{J}_{\mathbf{r}}(\mathbf{x}) + 2 \sum_{i=1}^q r_i(\mathbf{x}) \nabla_{\mathbf{x}}^2 r_i(\mathbf{x}).$$

Comprovação. Pela regra da cadeia,

$$\begin{aligned} \nabla_{\mathbf{x}} f(\mathbf{x}) &= \sum_{i=1}^q 2r_i(\mathbf{x}) \nabla_{\mathbf{x}} r_i(\mathbf{x}) \\ &= 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^\top \mathbf{r}(\mathbf{x}). \end{aligned}$$

Diferenciando novamente cada parcela,

$$\nabla_{\mathbf{x}} [r_i(\mathbf{x}) \nabla_{\mathbf{x}} r_i(\mathbf{x})] = \nabla_{\mathbf{x}} r_i(\mathbf{x}) \nabla_{\mathbf{x}} r_i(\mathbf{x})^\top + r_i(\mathbf{x}) \nabla_{\mathbf{x}}^2 r_i(\mathbf{x}).$$

Somando sobre i , obtém-se a expressão da Hessiana. □

A Hessiana possui, portanto, duas parcelas com papéis distintos:

$$\underbrace{2\mathbf{J}_r(\mathbf{x})^\top \mathbf{J}_r(\mathbf{x})}_{\text{parcela de primeira ordem dos resíduos}} + \underbrace{2 \sum_{i=1}^q r_i(\mathbf{x}) \nabla_{\mathbf{x}}^2 r_i(\mathbf{x})}_{\text{correção de não linearidade}} .$$

O primeiro termo da Hessiana,

$$2\mathbf{J}_r(\mathbf{x})^\top \mathbf{J}_r(\mathbf{x}),$$

é semidefinido positivo. Isso não implica, porém, que a função de mínimos quadrados não linear seja convexa, pois a segunda parcela da Hessiana pode ser indefinida.

O segundo termo depende:

- dos valores dos resíduos;
- das Hessianas das funções residuais;
- da não linearidade do modelo.

Quando os resíduos são pequenos ou quando as Hessianas das funções residuais têm contribuição reduzida na região considerada, a segunda parcela pode ser desprezada aproximadamente. Nesse caso,

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \approx 2\mathbf{J}_r(\mathbf{x})^\top \mathbf{J}_r(\mathbf{x}).$$

No caso linear,

$$\mathbf{r}(\mathbf{x}) = \mathbf{b} - \mathbf{A}\mathbf{x},$$

tem-se

$$\nabla_{\mathbf{x}}^2 r_i(\mathbf{x}) = \mathbf{0}$$

para todo i . Portanto, a segunda parcela desaparece exatamente e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}^\top \mathbf{A}.$$

Essa aproximação conduz ao método de Gauss–Newton. Seu desenvolvimento computacional não será necessário neste capítulo.

As mesmas ideias serão estendidas a funções cujos argumentos são matrizes. Nesse caso, os diferenciais e as identidades de traço permitem organizar as derivadas sem decompor a matriz em todos os seus elementos.

7.8 Diferenciais matriciais e cálculo por traços

Uma função escalar pode depender de todos os elementos de uma matriz. A diferenciação elemento a elemento é possível, mas se torna extensa quando a dimensão aumenta. Os diferenciais matriciais e as identidades de traço permitem organizar essas derivadas preservando a estrutura dos produtos.

Considere uma função

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R},$$

cujo argumento é

$$\mathbf{X} = (x_{ij}).$$

O diferencial total pode ser escrito como

$$d\phi = \sum_{i=1}^m \sum_{j=1}^n \frac{\partial \phi}{\partial x_{ij}} dx_{ij}.$$

Retomando a convenção estabelecida no início do capítulo, o gradiente matricial é

$$\nabla_{\mathbf{X}} \phi = \left(\frac{\partial \phi}{\partial x_{ij}} \right) \in \mathbb{R}^{m \times n}.$$

Utilizando o produto interno de Frobenius definido em Definição 6.6,

$$\langle \mathbf{A}, \mathbf{B} \rangle_F = \text{tr}(\mathbf{A}^\top \mathbf{B}),$$

o diferencial assume a forma

$$d\phi = \langle \nabla_{\mathbf{X}} \phi, d\mathbf{X} \rangle_F.$$

Portanto,

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X} \right].$$

Essa identidade será utilizada para reconhecer o gradiente após reorganizar o diferencial.

Assim como o gradiente de uma função escalar de vetor representa o diferencial segundo o produto interno euclidiano, o gradiente matricial representa o diferencial segundo o produto interno de Frobenius.

7.8.1 Regras básicas do diferencial matricial

Se $\mathbf{A}$ e $\mathbf{B}$ são matrizes constantes e $\mathbf{X}$ é variável, então

$$d\mathbf{A} = \mathbf{0}$$

e

$$d\mathbf{B} = \mathbf{0}.$$

O diferencial é linear:

$$d(\mathbf{X} + \mathbf{Y}) = d\mathbf{X} + d\mathbf{Y},$$

e, para escalares constantes α e β ,

$$d(\alpha\mathbf{X} + \beta\mathbf{Y}) = \alpha d\mathbf{X} + \beta d\mathbf{Y}.$$

Para um produto de matrizes variáveis,

$$d(\mathbf{XY}) = d\mathbf{X} \mathbf{Y} + \mathbf{X} d\mathbf{Y}.$$

Para três fatores,

$$\begin{aligned} d(\mathbf{XYZ}) &= d\mathbf{X} \mathbf{Y} \mathbf{Z} \\ &\quad + \mathbf{X} d\mathbf{Y} \mathbf{Z} \\ &\quad + \mathbf{X} \mathbf{Y} d\mathbf{Z}. \end{aligned}$$

A transposição comuta com o diferencial:

$$d(\mathbf{X}^\top) = (d\mathbf{X})^\top.$$

Quando $\mathbf{A}$ e $\mathbf{B}$ são constantes,

$$d(\mathbf{AXB}) = \mathbf{A} d\mathbf{X} \mathbf{B}.$$

Para o produto cruzado,

$$d(\mathbf{X}^\top \mathbf{X}) = d\mathbf{X}^\top \mathbf{X} + \mathbf{X}^\top d\mathbf{X}.$$

Essas regras mantêm a ordem dos fatores. Em geral, os produtos matriciais não podem ser reorganizados por comutatividade.

7.8.2 Identidades de traço

O traço foi definido em Definição 2.9, e suas propriedades algébricas foram estabelecidas em Proposição 2.5 e Proposição 2.8. Para o cálculo matricial, serão utilizadas especialmente as permutações cíclicas dos fatores:

$$\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA}),$$

quando os produtos são definidos.

Para três fatores,

$$\text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{BCA}) = \text{tr}(\mathbf{CAB}).$$

A ordem cíclica pode ser alterada, mas não uma ordem arbitrária. Em geral,

$$\text{tr}(\mathbf{ABC}) \neq \text{tr}(\mathbf{ACB}).$$

Também são válidas as identidades

$$\text{tr}(\mathbf{A}^\top) = \text{tr}(\mathbf{A})$$

e

$$\text{tr}(\mathbf{A}^\top \mathbf{B}) = \text{tr}(\mathbf{B}^\top \mathbf{A}).$$

Para reorganizar diferenciais, será utilizada a relação

$$\text{tr}(\mathbf{A} d\mathbf{X}^\top) = \text{tr}(\mathbf{A}^\top d\mathbf{X}).$$

De modo semelhante,

$$\text{tr}(d\mathbf{X}^\top \mathbf{A}) = \text{tr}(\mathbf{A}^\top d\mathbf{X}).$$

O objetivo dessas transformações é escrever o diferencial na forma

$$d\phi = \text{tr}(\mathbf{G}^\top d\mathbf{X}).$$

Nesse caso,

$$\nabla_{\mathbf{X}}\phi = \mathbf{G}.$$

7.8.3 Função linear de uma matriz

Proposição 7.8 (Gradiente de uma função matricial linear). *Se*

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X}),$$

em que $\mathbf{A}$ é constante e possui a mesma dimensão de $\mathbf{X}$, então

$$\nabla_{\mathbf{X}}\phi = \mathbf{A}.$$

(Magnus; Neudecker, 2019)

Comprovação. O diferencial é

$$\begin{aligned} d\phi &= d \text{tr}(\mathbf{A}^\top \mathbf{X}) \\ &= \text{tr}(\mathbf{A}^\top d\mathbf{X}). \end{aligned}$$

Comparando com

$$d\phi = \text{tr}[(\nabla_{\mathbf{X}}\phi)^\top d\mathbf{X}],$$

obtém-se

$$\nabla_{\mathbf{X}}\phi = \mathbf{A}.$$

□

Como

$$\text{tr}(\mathbf{A}^\top \mathbf{X}) = \sum_{i=1}^m \sum_{j=1}^n a_{ij} x_{ij},$$

essa função é o equivalente matricial da forma linear $\mathbf{a}^\top \mathbf{x}$.

7.8.4 Derivadas da norma de Frobenius

Pela Definição 6.7,

$$\|\mathbf{X}\|_F^2 = \text{tr}(\mathbf{X}^\top \mathbf{X}).$$

Seu diferencial é

$$\begin{aligned} d\|\mathbf{X}\|_F^2 &= d \text{tr}(\mathbf{X}^\top \mathbf{X}) \\ &= \text{tr}(d\mathbf{X}^\top \mathbf{X}) + \text{tr}(\mathbf{X}^\top d\mathbf{X}). \end{aligned}$$

Como

$$\text{tr}(d\mathbf{X}^\top \mathbf{X}) = \text{tr}(\mathbf{X}^\top d\mathbf{X}),$$

segue que

$$d\|\mathbf{X}\|_F^2 = 2 \text{tr}(\mathbf{X}^\top d\mathbf{X}).$$

Portanto,

$$\nabla_{\mathbf{X}} \|\mathbf{X}\|_F^2 = 2\mathbf{X}.$$

Para uma matriz constante $\mathbf{M}$,

$$\phi(\mathbf{X}) = \|\mathbf{X} - \mathbf{M}\|_F^2$$

possui gradiente

$$\nabla_{\mathbf{X}} \phi = 2(\mathbf{X} - \mathbf{M}).$$

O único minimizador é

$$\mathbf{X} = \mathbf{M}.$$

De fato, essa função é estritamente convexa em $\mathbf{X}$, pois sua segunda variação em uma perturbação não nula $d\mathbf{X}$ é

$$d^2\phi = 2\|d\mathbf{X}\|_F^2 > 0.$$

7.8.5 Funções quadráticas de uma matriz

Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma),$$

com

$$\mathbf{X} \in \mathbb{R}^{m \times n}, \quad \mathbf{A} \in \mathbb{R}^{m \times m}$$

e

$$\Gamma \in \mathbb{R}^{n \times n}.$$

O diferencial é

$$\begin{aligned} d\phi &= \text{tr}(d\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma) \\ &\quad + \text{tr}(\mathbf{X}^\top \mathbf{A} d\mathbf{X} \Gamma). \end{aligned}$$

O primeiro termo pode ser escrito como

$$\text{tr}(d\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma) = \text{tr}[(\mathbf{A} \mathbf{X} \Gamma)^\top d\mathbf{X}].$$

No segundo termo, pela propriedade cíclica,

$$\begin{aligned} \text{tr}(\mathbf{X}^\top \mathbf{A} d\mathbf{X} \Gamma) &= \text{tr}(\Gamma \mathbf{X}^\top \mathbf{A} d\mathbf{X}) \\ &= \text{tr}[(\mathbf{A}^\top \mathbf{X} \Gamma^\top)^\top d\mathbf{X}]. \end{aligned}$$

Logo,

$$\nabla_{\mathbf{X}}\phi = \mathbf{A}\mathbf{X}\Gamma + \mathbf{A}^\top\mathbf{X}\Gamma^\top.$$

Se $\mathbf{A}$ e Γ são simétricas,

$$\nabla_{\mathbf{X}}\phi = 2\mathbf{A}\mathbf{X}\Gamma.$$

A dimensão do gradiente coincide com a dimensão do argumento:

$$\nabla_{\mathbf{X}}\phi \in \mathbb{R}^{m \times n}.$$

Exemplo 7.13 (Soma ponderada de produtos quadráticos). Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X}),$$

com $\mathbf{A}$ simétrica.

Esse é o caso particular

$$\Gamma = \mathbf{I}_n.$$

Portanto,

$$\nabla_{\mathbf{X}}\phi = 2\mathbf{A}\mathbf{X}.$$

Se as colunas de $\mathbf{X}$ são

$$\mathbf{x}_{\cdot 1}, \dots, \mathbf{x}_{\cdot n},$$

então

$$\phi(\mathbf{X}) = \sum_{j=1}^n \mathbf{x}_{\cdot j}^\top \mathbf{A} \mathbf{x}_{\cdot j}.$$

O gradiente reúne, em suas colunas, os gradientes das formas quadráticas individuais:

$$2\mathbf{A}\mathbf{x}_{\cdot 1}, \dots, 2\mathbf{A}\mathbf{x}_{\cdot n}.$$

7.8.6 Funções matriciais de resíduos

Considere o modelo matricial

$$\mathbf{Y} = \mathbf{XB} + \mathcal{E},$$

em que

$$\mathbf{Y} \in \mathbb{R}^{n \times p}, \quad \mathbf{X} \in \mathbb{R}^{n \times k}$$

e

$$\mathbf{B} \in \mathbb{R}^{k \times p}.$$

Para um valor genérico de $\mathbf{B}$, defina a matriz de resíduos

$$\mathcal{E}(\mathbf{B}) = \mathbf{Y} - \mathbf{XB}.$$

A função de soma de quadrados é

$$Q(\mathbf{B}) = \|\mathcal{E}(\mathbf{B})\|_F^2.$$

Equivalentemente,

$$Q(\mathbf{B}) = \text{tr} [\mathcal{E}(\mathbf{B})^\top \mathcal{E}(\mathbf{B})].$$

Como

$$d\mathcal{E} = -\mathbf{X} d\mathbf{B},$$

tem-se

$$\begin{aligned} dQ &= 2 \text{tr} (\mathcal{E}^\top d\mathcal{E}) \\ &= -2 \text{tr} (\mathcal{E}^\top \mathbf{X} d\mathbf{B}) \\ &= -2 \text{tr} [(\mathbf{X}^\top \mathcal{E})^\top d\mathbf{B}]. \end{aligned}$$

Logo,

$$\nabla_{\mathbf{B}} Q(\mathbf{B}) = -2\mathbf{X}^\top \mathcal{E}(\mathbf{B}).$$

Substituindo a matriz de resíduos,

$$\nabla_{\mathbf{B}} Q(\mathbf{B}) = 2\mathbf{X}^\top (\mathbf{XB} - \mathbf{Y}).$$

A condição de primeira ordem é

$$\mathbf{X}^\top (\mathbf{Y} - \mathbf{XB}) = \mathbf{0},$$

ou

$$\mathbf{X}^\top \mathbf{XB} = \mathbf{X}^\top \mathbf{Y}.$$

Essas são as equações normais matriciais.

Se $\mathbf{X}$ possui posto coluna completo,

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

Se $\mathbf{X}$ não possui posto coluna completo, os minimizadores não são únicos. A solução de mínimos quadrados de menor norma de Frobenius é

$$\widehat{\mathbf{B}}^\star = \mathbf{X}^+ \mathbf{Y}.$$

Mais geralmente, todos os minimizadores podem ser escritos como

$$\widehat{\mathbf{B}} = \mathbf{X}^+ \mathbf{Y} + (\mathbf{I}_k - \mathbf{X}^+ \mathbf{X}) \mathbf{C},$$

em que

$$\mathbf{C} \in \mathbb{R}^{k \times p}$$

é arbitrária.

A parcela adicional pertence ao núcleo da transformação

$$\mathbf{B} \mapsto \mathbf{XB}$$

e, portanto, não altera os valores ajustados.

Assim, quando o critério utilizado é simplesmente a norma de Frobenius dos resíduos, o problema matricial pode ser interpretado como p problemas de mínimos quadrados que compartilham a mesma matriz de delineamento.

Proposição 7.9 (Convexidade dos mínimos quadrados matriciais). *A função*

$$Q(\mathbf{B}) = \|\mathbf{Y} - \mathbf{X}\mathbf{B}\|_F^2$$

é convexa em $\mathbf{B}$.

Ela é estritamente convexa se, e somente se, $\mathbf{X}$ possui posto coluna completo.

Comprovação. Considere uma perturbação

$$d\mathbf{B}.$$

A segunda variação de Q é

$$d^2Q = 2 \operatorname{tr} (d\mathbf{B}^\top \mathbf{X}^\top \mathbf{X} d\mathbf{B}).$$

Equivalentemente,

$$d^2Q = 2 \|\mathbf{X} d\mathbf{B}\|_F^2 \geq 0.$$

Portanto, a função é convexa.

Se $\mathbf{X}$ possui posto coluna completo, então

$$\mathbf{X} d\mathbf{B} = \mathbf{0}$$

implica

$$d\mathbf{B} = \mathbf{0}.$$

Assim, a segunda variação é positiva para toda perturbação não nula, e a função é estritamente convexa.

Reciprocamente, se $\mathbf{X}$ não possui posto coluna completo, existe

$$\mathbf{z} \neq \mathbf{0}$$

tal que

$$\mathbf{X}\mathbf{z} = \mathbf{0}.$$

Escolha qualquer vetor não nulo

$$\mathbf{c} \in \mathbb{R}^p$$

e defina

$$d\mathbf{B} = \mathbf{z}\mathbf{c}^\top.$$

Então

$$d\mathbf{B} \neq \mathbf{0},$$

mas

$$\mathbf{X} d\mathbf{B} = \mathbf{0}.$$

Portanto,

$$d^2Q = 0$$

em uma direção não nula, e a função não é estritamente convexa. □

7.8.7 Ponderação de observações e respostas

Considere uma matriz diagonal de pesos das observações

$$\Omega = \text{diag}(\omega_1, \dots, \omega_n) \succeq \mathbf{0}$$

e uma matriz simétrica positiva definida

$$\Sigma \in \mathbb{R}^{p \times p}.$$

O critério ponderado é

$$Q_{\Omega, \Sigma}(\mathbf{B}) = \text{tr} [\Sigma^{-1} \mathcal{E}(\mathbf{B})^\top \Omega \mathcal{E}(\mathbf{B})].$$

Como

$$\Omega \succeq \mathbf{0}$$

e

$$\Sigma \succ \mathbf{0},$$

o critério também pode ser escrito como

$$Q_{\Omega, \Sigma}(\mathbf{B}) = \left\| \Omega^{1/2} \mathcal{E}(\mathbf{B}) \Sigma^{-1/2} \right\|_F^2.$$

Essa forma mostra que a ponderação atua simultaneamente nas duas dimensões da matriz residual.

A matriz Ω atua no espaço das observações e pondera as linhas da matriz de resíduos. A matriz Σ^{-1} atua no espaço das respostas e define a geometria utilizada para combinar as colunas da matriz de resíduos.

Como Ω e Σ^{-1} são simétricas,

$$\begin{aligned} dQ_{\Omega, \Sigma} &= 2 \text{tr} [\Sigma^{-1} \mathcal{E}^\top \Omega d\mathcal{E}] \\ &= -2 \text{tr} [\Sigma^{-1} \mathcal{E}^\top \Omega \mathbf{X} d\mathbf{B}]. \end{aligned}$$

Pela propriedade cíclica,

$$dQ_{\Omega, \Sigma} = -2 \operatorname{tr} \left[(\mathbf{X}^\top \Omega \mathcal{E} \Sigma^{-1})^\top d\mathbf{B} \right].$$

Portanto,

$$\nabla_{\mathbf{B}} Q_{\Omega, \Sigma}(\mathbf{B}) = -2 \mathbf{X}^\top \Omega \mathcal{E}(\mathbf{B}) \Sigma^{-1}.$$

A condição de primeira ordem é

$$\mathbf{X}^\top \Omega (\mathbf{Y} - \mathbf{X}\mathbf{B}) \Sigma^{-1} = \mathbf{0}.$$

Como Σ^{-1} é invertível,

$$\mathbf{X}^\top \Omega (\mathbf{Y} - \mathbf{X}\mathbf{B}) = \mathbf{0}.$$

Logo,

$$\mathbf{X}^\top \Omega \mathbf{X} \mathbf{B} = \mathbf{X}^\top \Omega \mathbf{Y}.$$

Se

$$\mathbf{X}^\top \Omega \mathbf{X}$$

é invertível, ou equivalentemente, se as colunas de

$$\Omega^{1/2} \mathbf{X}$$

são linearmente independentes, então o minimizador é

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \Omega \mathbf{X})^{-1} \mathbf{X}^\top \Omega \mathbf{Y}.$$

Para Σ fixa e positiva definida, a ponderação invertível no espaço das respostas altera o valor do critério e sua geometria, mas não altera o conjunto de minimizadores em relação a $\mathbf{B}$.

Isso ocorre porque

$$\Sigma^{-1}$$

é invertível e pode ser eliminada da condição de primeira ordem.

A ponderação das observações por Ω , por outro lado, permanece nas equações normais e pode modificar o estimador.

Os diferenciais matriciais e as identidades de traço permitem agora tratar funções em que a própria matriz variável aparece no interior de uma inversa ou de um determinante. Essas estruturas são particularmente importantes quando o parâmetro pertence ao conjunto das matrizes positivas definidas.

7.9 Derivadas de inversas, determinantes e log-determinantes

A matriz inversa e o determinante foram definidos em Definição 2.11 e Definição 2.13, enquanto a relação entre determinante e invertibilidade foi estabelecida em Teorema 2.4. A classificação das matrizes simétricas por positividade foi apresentada em Definição 2.24.

Nesta seção, esses objetos são retomados como funções de uma matriz variável. Suas derivadas exigem condições de invertibilidade e, em aplicações com matrizes de covariâncias, definição positiva.

7.9.1 Diferencial da matriz inversa

Considere uma matriz invertível

$$\mathbf{X} \in \mathbb{R}^{p \times p}.$$

A identidade

$$\mathbf{X}\mathbf{X}^{-1} = \mathbf{I}_p$$

permite obter o diferencial da inversa.

Proposição 7.10 (Diferencial da matriz inversa). *Se $\mathbf{X}$ é invertível, então*

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}(d\mathbf{X})\mathbf{X}^{-1}.$$

(Magnus; Neudecker, 2019)

Comprovação. Diferenciando

$$\mathbf{X}\mathbf{X}^{-1} = \mathbf{I}_p,$$

obtém-se

$$d\mathbf{X}\mathbf{X}^{-1} + \mathbf{X}d(\mathbf{X}^{-1}) = \mathbf{0}.$$

Multiplicando à esquerda por $\mathbf{X}^{-1}$,

$$\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1} + d(\mathbf{X}^{-1}) = \mathbf{0}.$$

Logo,

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}(d\mathbf{X})\mathbf{X}^{-1}.$$

□

Quando $\mathbf{X} \succ \mathbf{0}$ e a perturbação

$$d\mathbf{X} \succeq \mathbf{0},$$

tem-se

$$\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1} \succeq \mathbf{0},$$

e, portanto,

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1} \preceq \mathbf{0}.$$

Assim, a inversão reverte a ordem de Loewner: aumentos semidefinidos positivos da matriz produzem variações semidefinidas negativas de sua inversa.

Para uma perturbação $d\mathbf{X}$,

$$(\mathbf{X} + d\mathbf{X})^{-1} \approx \mathbf{X}^{-1} - \mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1}.$$

Essa aproximação é válida para perturbações suficientemente pequenas que preservem a invertibilidade.

Exemplo 7.14 (Caso escalar). Para

$$x \neq 0,$$

a função inversa é

$$f(x) = \frac{1}{x}.$$

A fórmula matricial reduz-se a

$$d(x^{-1}) = -x^{-1}(dx)x^{-1} = -\frac{1}{x^2}dx.$$

Portanto,

$$f'(x) = -\frac{1}{x^2}.$$

7.9.2 Diferencial do determinante

O determinante é uma função escalar definida sobre matrizes quadradas:

$$\det : \mathbb{R}^{p \times p} \longrightarrow \mathbb{R}.$$

Sua derivada é descrita pela fórmula de Jacobi.

Proposição 7.11 (Fórmula de Jacobi). *Se $\mathbf{X}$ é invertível, então*

$$d \det(\mathbf{X}) = \det(\mathbf{X}) \operatorname{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

(Magnus; Neudecker, 2019)

Comprovação. Considere uma perturbação $\mathbf{H}$ e a função

$$g(t) = \det(\mathbf{X} + t\mathbf{H}).$$

Como $\mathbf{X}$ é invertível,

$$g(t) = \det(\mathbf{X}) \det(\mathbf{I}_p + t\mathbf{X}^{-1}\mathbf{H}).$$

Pela multilinearidade do determinante,

$$\det(\mathbf{I}_p + t\mathbf{M}) = 1 + t \operatorname{tr}(\mathbf{M}) + o(t).$$

Aplicando essa expansão com

$$\mathbf{M} = \mathbf{X}^{-1}\mathbf{H},$$

obtém-se

$$g(t) = \det(\mathbf{X}) [1 + t \operatorname{tr}(\mathbf{X}^{-1}\mathbf{H}) + o(t)].$$

Logo,

$$g'(0) = \det(\mathbf{X}) \operatorname{tr}(\mathbf{X}^{-1}\mathbf{H}).$$

Como $\mathbf{H}$ representa uma perturbação arbitrária,

$$d \det(\mathbf{X}) = \det(\mathbf{X}) \operatorname{tr}(\mathbf{X}^{-1}d\mathbf{X}).$$

□

Como

$$d \det(\mathbf{X}) = \operatorname{tr}[(\nabla_{\mathbf{X}} \det(\mathbf{X}))^{\top} d\mathbf{X}],$$

segue que

$$\nabla_{\mathbf{X}} \det(\mathbf{X}) = \det(\mathbf{X})\mathbf{X}^{-\top}.$$

Se $\mathbf{X}$ é simétrica,

$$\mathbf{X}^{-\top} = \mathbf{X}^{-1},$$

e

$$\nabla_{\mathbf{X}} \det(\mathbf{X}) = \det(\mathbf{X})\mathbf{X}^{-1}.$$

A fórmula pode ser estendida a matrizes singulares por meio da matriz adjunta, mas a forma envolvendo $\mathbf{X}^{-1}$ exige invertibilidade.

7.9.3 Diferencial do log-determinante

Para matrizes positivas definidas,

$$\mathbf{X} \succ \mathbf{0},$$

o determinante é positivo e a função

$$\phi(\mathbf{X}) = \log \det(\mathbf{X})$$

está bem definida.

A restrição

$$\mathbf{X} \succ \mathbf{0}$$

garante simultaneamente que $\mathbf{X}$ é invertível e que

$$\det(\mathbf{X}) > 0,$$

de modo que o logaritmo real do determinante está bem definido.

Proposição 7.12 (Diferencial do log-determinante). *Se $\mathbf{X} \succ \mathbf{0}$, então*

$$d \log \det(\mathbf{X}) = \text{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

Consequentemente,

$$\nabla_{\mathbf{X}} \log \det(\mathbf{X}) = \mathbf{X}^{-1}.$$

Comprovação. Pela regra da cadeia,

$$d \log \det(\mathbf{X}) = \frac{1}{\det(\mathbf{X})} d \det(\mathbf{X}).$$

Aplicando a fórmula de Jacobi,

$$\begin{aligned} d \log \det(\mathbf{X}) &= \frac{1}{\det(\mathbf{X})} \det(\mathbf{X}) \text{tr}(\mathbf{X}^{-1} d\mathbf{X}) \\ &= \text{tr}(\mathbf{X}^{-1} d\mathbf{X}). \end{aligned}$$

Como $\mathbf{X}$ é simétrica,

$$\mathbf{X}^{-\top} = \mathbf{X}^{-1},$$

o que fornece o gradiente. □

Para uma matriz real invertível, não necessariamente simétrica, pode-se considerar

$$\phi(\mathbf{X}) = \log |\det(\mathbf{X})|.$$

Como o determinante não se anula no conjunto das matrizes invertíveis, seu sinal permanece constante em uma vizinhança suficientemente pequena de cada matriz invertível. Nesse domínio,

$$d \log |\det(\mathbf{X})| = \text{tr}(\mathbf{X}^{-1} d\mathbf{X}),$$

e, portanto,

$$\nabla_{\mathbf{X}} \log |\det(\mathbf{X})| = \mathbf{X}^{-\top}.$$

7.9.4 Segunda variação do log-determinante

Considere uma matriz positiva definida $\mathbf{X}$ e uma perturbação simétrica $d\mathbf{X}$.

A primeira variação é

$$d\phi = \text{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

Utilizando o diferencial da inversa,

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1} d\mathbf{X} \mathbf{X}^{-1},$$

a segunda variação na mesma direção é

$$d^2\phi = -\text{tr}(\mathbf{X}^{-1} d\mathbf{X} \mathbf{X}^{-1} d\mathbf{X}).$$

Logo,

$$d^2\phi \leq 0.$$

Proposição 7.13 (Concavidade do log-determinante). *A função*

$$\phi(\mathbf{X}) = \log \det(\mathbf{X})$$

é estritamente côncava no conjunto das matrizes simétricas positivas definidas.

(Boyd; Vandenberghe, 2004)

Comprovação. O conjunto das matrizes simétricas positivas definidas é convexo. Para toda matriz

$$\mathbf{X} \succ \mathbf{0}$$

e toda direção simétrica não nula $\mathbf{H}$,

$$d^2\phi[\mathbf{H}, \mathbf{H}] = -\|\mathbf{X}^{-1/2}\mathbf{H}\mathbf{X}^{-1/2}\|_F^2 < 0.$$

Logo, a restrição de ϕ a qualquer segmento não degenerado do cone positivo definido possui segunda derivada negativa. Portanto,

$$\phi(\mathbf{X}) = \log \det(\mathbf{X})$$

é estritamente côncava nesse domínio. □

Consequentemente,

$$-\log \det(\mathbf{X})$$

é estritamente convexa nesse domínio.

7.9.5 Traço envolvendo uma matriz inversa

Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}\mathbf{X}^{-1}),$$

em que $\mathbf{A}$ é constante e $\mathbf{X}$ é invertível.

O diferencial é

$$\begin{aligned} d\phi &= \text{tr}[\mathbf{A} d(\mathbf{X}^{-1})] \\ &= -\text{tr}(\mathbf{A}\mathbf{X}^{-1} d\mathbf{X}\mathbf{X}^{-1}). \end{aligned}$$

Pela propriedade cíclica,

$$d\phi = -\text{tr}(\mathbf{X}^{-1}\mathbf{A}\mathbf{X}^{-1} d\mathbf{X}).$$

Portanto,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-\top}\mathbf{A}^{\top}\mathbf{X}^{-\top}.$$

Observe que o gradiente possui a mesma dimensão de $\mathbf{X}$,

$$\nabla_{\mathbf{X}}\phi \in \mathbb{R}^{p \times p}.$$

Se $\mathbf{A}$ e $\mathbf{X}$ são simétricas,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-1}\mathbf{A}\mathbf{X}^{-1}.$$

Exemplo 7.15 (Traço da inversa). Para

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^{-1}),$$

tem-se $\mathbf{A} = \mathbf{I}_p$. Logo,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-\top}\mathbf{X}^{-\top}.$$

Se $\mathbf{X}$ é simétrica positiva definida,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-2}.$$

7.9.6 Forma quadrática com matriz inversa

Considere

$$\phi(\mathbf{X}) = \mathbf{a}^\top \mathbf{X}^{-1} \mathbf{a},$$

em que $\mathbf{a} \in \mathbb{R}^p$ é constante e $\mathbf{X} \succ \mathbf{0}$.

A função pode ser escrita como

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^{-1} \mathbf{a} \mathbf{a}^\top).$$

Aplicando o resultado anterior,

$$\nabla_{\mathbf{X}} \phi = -\mathbf{X}^{-1} \mathbf{a} \mathbf{a}^\top \mathbf{X}^{-1}.$$

Equivalentemente,

$$\nabla_{\mathbf{X}} \phi = -(\mathbf{X}^{-1} \mathbf{a})(\mathbf{X}^{-1} \mathbf{a})^\top.$$

Essa matriz é semidefinida negativa.

Consequentemente, para uma perturbação

$$\mathbf{H} \succeq \mathbf{0},$$

tem-se

$$d\phi[\mathbf{H}] = \text{tr}[(\nabla_{\mathbf{X}} \phi)^\top \mathbf{H}] \leq 0.$$

Assim, aumentar $\mathbf{X}$ segundo a ordem de Loewner não aumenta a forma quadrática inversa.

Se o vetor também varia, considere

$$\phi(\mathbf{x}, \mathbf{X}) = \mathbf{x}^\top \mathbf{X}^{-1} \mathbf{x}.$$

Em relação ao vetor,

$$\nabla_{\mathbf{x}} \phi = 2\mathbf{X}^{-1} \mathbf{x},$$

enquanto, em relação à matriz,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-1}\mathbf{x}\mathbf{x}^{\top}\mathbf{X}^{-1}.$$

7.9.7 Critério com log-determinante e traço

Considere $n > 0$ e o critério

$$Q(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \text{tr}(\Sigma^{-1}\mathbf{G}),$$

em que

$$\Sigma \succ \mathbf{0}$$

é variável e

$$\mathbf{G} \succeq \mathbf{0}$$

é constante e simétrica.

O diferencial é

$$\begin{aligned} dQ &= \frac{n}{2} \text{tr}(\Sigma^{-1}d\Sigma) \\ &\quad - \frac{1}{2} \text{tr}(\Sigma^{-1}\mathbf{G}\Sigma^{-1}d\Sigma). \end{aligned}$$

Logo,

$$\nabla_{\Sigma}Q = \frac{n}{2}\Sigma^{-1} - \frac{1}{2}\Sigma^{-1}\mathbf{G}\Sigma^{-1}.$$

A condição de primeira ordem é

$$n\Sigma^{-1} = \Sigma^{-1}\mathbf{G}\Sigma^{-1}.$$

Multiplicando à esquerda e à direita por Σ ,

$$n\Sigma = \mathbf{G}.$$

Portanto, o ponto estacionário é

$$\widehat{\Sigma} = \frac{1}{n} \mathbf{G}.$$

Para que esse ponto pertença ao domínio

$$\Sigma \succ \mathbf{0},$$

é necessário que

$$\mathbf{G} \succ \mathbf{0}.$$

Proposição 7.14 (Minimização do critério de covariância). *Considere*

$$n > 0$$

e uma matriz

$$\mathbf{G} \succ \mathbf{0}.$$

Então, a função

$$Q(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \operatorname{tr}(\Sigma^{-1} \mathbf{G})$$

possui minimizador único no conjunto das matrizes positivas definidas:

$$\widehat{\Sigma} = \frac{1}{n} \mathbf{G}.$$

Comprovação. Defina

$$\mathbf{Z} = \mathbf{G}^{1/2} \Sigma^{-1} \mathbf{G}^{1/2}.$$

Como $\mathbf{G}$ e Σ são positivas definidas,

$$\mathbf{Z} \succ \mathbf{0}.$$

Além disso,

$$\mathrm{tr}(\Sigma^{-1}\mathbf{G}) = \mathrm{tr}(\mathbf{Z})$$

e

$$\log \det(\Sigma) = \log \det(\mathbf{G}) - \log \det(\mathbf{Z}).$$

Assim, a menos de uma constante,

$$Q(\Sigma) = \frac{1}{2} [\mathrm{tr}(\mathbf{Z}) - n \log \det(\mathbf{Z})].$$

Se

$$z_1, \dots, z_p$$

são os autovalores positivos de $\mathbf{Z}$, então

$$Q(\Sigma) = \text{constante} + \frac{1}{2} \sum_{j=1}^p (z_j - n \log z_j).$$

Para cada $z_j > 0$, a função

$$h(z) = z - n \log z$$

possui derivada

$$h'(z) = 1 - \frac{n}{z}$$

e segunda derivada

$$h''(z) = \frac{n}{z^2} > 0.$$

Seu único mínimo ocorre em

$$z = n.$$

Como cada parcela

$$z_j - n \log z_j$$

possui mínimo único em $z_j = n$, o mínimo global exige

$$z_1 = \cdots = z_p = n.$$

Portanto,

$$\mathbf{Z} = n\mathbf{I}_p.$$

Essa igualdade equivale a

$$\Sigma = \frac{1}{n}\mathbf{G}.$$

□

Se $\mathbf{G}$ é singular, o candidato

$$\frac{1}{n}\mathbf{G}$$

não pertence ao domínio positivo definido.

Além disso, o critério é ilimitado inferiormente. De fato, escolhendo uma direção unitária

$$\mathbf{u} \in \mathcal{N}(\mathbf{G}),$$

pode-se fazer o autovalor de Σ associado a essa direção tender a zero. Nessa direção, o termo

$$\mathrm{tr}(\Sigma^{-1}\mathbf{G})$$

não recebe contribuição, enquanto

$$\log \det(\Sigma) \longrightarrow -\infty.$$

Portanto,

$$Q(\Sigma) \longrightarrow -\infty,$$

e o problema não possui minimizador no cone positivo definido.

7.9.8 Parâmetros matriciais simétricos

As fórmulas anteriores foram escritas utilizando matrizes completas. Entretanto, uma matriz simétrica

$$\Sigma = \Sigma^\top$$

possui apenas

$$\frac{p(p+1)}{2}$$

elementos distintos.

Quando o argumento é restrito ao espaço das matrizes simétricas, as perturbações admissíveis também devem ser simétricas:

$$d\Sigma = d\Sigma^\top.$$

Para uma função escalar $\phi(\Sigma)$, somente a parte simétrica do gradiente contribui para o diferencial:

$$\text{tr} \left[(\nabla_\Sigma \phi)^\top d\Sigma \right] = \text{tr} \left[\left(\frac{\nabla_\Sigma \phi + \nabla_\Sigma \phi^\top}{2} \right)^\top d\Sigma \right].$$

Nos resultados anteriores, os gradientes obtidos para argumentos positivos definidos já são simétricos quando as matrizes constantes envolvidas também são simétricas.

Uma parametrização explícita dos elementos distintos será desenvolvida com os operadores de vetorização e meia vetorização.

7.10 Vetorização, produto de Kronecker e parâmetros matriciais

A vetorização transforma uma matriz em um vetor. Essa operação permite representar transformações matriciais por matrizes usuais e aplicar resultados de cálculo vetorial a parâmetros matriciais.

Nesta seção, o núcleo necessário para os capítulos seguintes é formado por três ideias:

- o operador vec ;
- o produto de Kronecker;
- a identidade que relaciona vec e produtos matriciais.

As subseções posteriores sobre Hessianas vetorizadas, matriz de comutação, meia vetorização, matrizes de duplicação e eliminação e Jacobianas de transformações matriciais serão apresentadas como aprofundamento. Elas são úteis em desenvolvimentos mais avançados de cálculo matricial e inferência, mas não são necessárias para uma primeira leitura do restante do livro.

7.10.1 Operador de vetorização

Definição 7.9 (Operador de vetorização). Para

$$\mathbf{X} = \begin{bmatrix} x_{11} & \cdots & x_{1n} \\ \vdots & \ddots & \vdots \\ x_{m1} & \cdots & x_{mn} \end{bmatrix} \in \mathbb{R}^{m \times n},$$

o vetor

$$\text{vec}(\mathbf{X}) \in \mathbb{R}^{mn}$$

é obtido pelo empilhamento das colunas de $\mathbf{X}$:

$$\text{vec}(\mathbf{X}) = \begin{bmatrix} x_{11} \\ \vdots \\ x_{m1} \\ x_{12} \\ \vdots \\ x_{m2} \\ \vdots \\ x_{1n} \\ \vdots \\ x_{mn} \end{bmatrix}.$$

Exemplo 7.16 (Vetorização de uma matriz). Considere

$$\mathbf{X} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}.$$

Então,

$$\text{vec}(\mathbf{X}) = \begin{bmatrix} 1 \\ 4 \\ 2 \\ 5 \\ 3 \\ 6 \end{bmatrix}.$$

A vetorização é linear:

$$\text{vec}(\alpha \mathbf{X} + \beta \mathbf{Y}) = \alpha \text{vec}(\mathbf{X}) + \beta \text{vec}(\mathbf{Y}).$$

Além disso,

$$\|\mathbf{X}\|_F = \|\text{vec}(\mathbf{X})\|.$$

Isso ocorre porque os dois lados reúnem os mesmos elementos ao quadrado:

$$\|\mathbf{X}\|_F^2 = \sum_{i=1}^m \sum_{j=1}^n x_{ij}^2.$$

7.10.2 Produto de Kronecker

Definição 7.10 (Produto de Kronecker). Considere

$$\mathbf{A} = (a_{ij}) \in \mathbb{R}^{m \times n}$$

e

$$\mathbf{C} \in \mathbb{R}^{r \times s}.$$

O produto de Kronecker é a matriz

$$\mathbf{A} \otimes \mathbf{C} = \begin{bmatrix} a_{11} \mathbf{C} & \cdots & a_{1n} \mathbf{C} \\ \vdots & \ddots & \vdots \\ a_{m1} \mathbf{C} & \cdots & a_{mn} \mathbf{C} \end{bmatrix} \in \mathbb{R}^{mr \times ns}.$$

Exemplo 7.17 (Produto de Kronecker). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$$

e

$$\mathbf{C} = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}.$$

Então,

$$\begin{aligned} \mathbf{A} \otimes \mathbf{C} &= \begin{bmatrix} 1\mathbf{C} & 2\mathbf{C} \\ 3\mathbf{C} & 4\mathbf{C} \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 & 2 & 0 \\ 0 & -1 & 0 & -2 \\ 3 & 0 & 4 & 0 \\ 0 & -3 & 0 & -4 \end{bmatrix}. \end{aligned}$$

(Magnus; Neudecker, 2019)

O produto de Kronecker satisfaz:

$$(\mathbf{A} \otimes \mathbf{C})^\top = \mathbf{A}^\top \otimes \mathbf{C}^\top,$$

e, para produtos de dimensões compatíveis,

$$(\mathbf{A}_1 \otimes \mathbf{C}_1)(\mathbf{A}_2 \otimes \mathbf{C}_2) = (\mathbf{A}_1 \mathbf{A}_2) \otimes (\mathbf{C}_1 \mathbf{C}_2).$$

Se $\mathbf{A}$ e $\mathbf{C}$ são invertíveis,

$$(\mathbf{A} \otimes \mathbf{C})^{-1} = \mathbf{A}^{-1} \otimes \mathbf{C}^{-1}.$$

Se $\mathbf{A}$ e $\mathbf{C}$ são simétricas positivas definidas, então

$$\mathbf{A} \otimes \mathbf{C} \succ \mathbf{0}.$$

7.10.3 Identidade de vetorização

A relação entre vetorização e produto de Kronecker permite representar um produto matricial como uma transformação linear do vetor de elementos da matriz.

Proposição 7.15 (Identidade fundamental da vetorização). *Considere*

$$\mathbf{A} \in \mathbb{R}^{r \times m}, \quad \mathbf{X} \in \mathbb{R}^{m \times n}$$

e

$$\Gamma \in \mathbb{R}^{n \times s}.$$

Então,

$$\text{vec}(\mathbf{A}\mathbf{X}\Gamma) = (\Gamma^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

(Magnus; Neudecker, 2019)

O lado esquerdo possui dimensão rs . No lado direito,

$$\Gamma^\top \otimes \mathbf{A} \in \mathbb{R}^{rs \times mn},$$

e

$$\text{vec}(\mathbf{X}) \in \mathbb{R}^{mn}.$$

Casos particulares importantes são

$$\text{vec}(\mathbf{A}\mathbf{X}) = (\mathbf{I}_n \otimes \mathbf{A}) \text{vec}(\mathbf{X})$$

e

$$\text{vec}(\mathbf{X}\Gamma) = (\Gamma^\top \otimes \mathbf{I}_m) \text{vec}(\mathbf{X}).$$

A identidade mostra que uma transformação que atua simultaneamente à esquerda e à direita de uma matriz pode ser representada como uma transformação linear usual sobre o vetor formado por seus elementos.

Assim,

$$\mathbf{X} \mapsto \mathbf{A}\mathbf{X}\mathbf{\Gamma}$$

corresponde, após vetorização, a

$$\text{vec}(\mathbf{X}) \mapsto (\mathbf{\Gamma}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

Exemplo 7.18 (Vetorização de um produto matricial). Considere

$$\mathbf{Y} = \mathbf{A}\mathbf{X}\mathbf{\Gamma}.$$

Uma pequena perturbação de $\mathbf{X}$ produz

$$d\mathbf{Y} = \mathbf{A} d\mathbf{X} \mathbf{\Gamma}.$$

Vetorizando,

$$d \text{vec}(\mathbf{Y}) = (\mathbf{\Gamma}^\top \otimes \mathbf{A}) d \text{vec}(\mathbf{X}).$$

Portanto, a Jacobiana da transformação vetorizada é

$$\frac{\partial \text{vec}(\mathbf{Y})}{\partial \text{vec}(\mathbf{X})^\top} = \mathbf{\Gamma}^\top \otimes \mathbf{A}.$$

7.10.4 Aprofundamento: derivadas vetorizadas e parâmetros matriciais

Leitura de aprofundamento

As subseções seguintes desenvolvem ferramentas úteis quando parâmetros matriciais precisam ser tratados explicitamente como vetores. Elas permitem representar Hessianas, transposições, parâmetros simétricos e Jacobianas matriciais por meio de vec , produto de Kronecker e matrizes especiais.

Esses resultados são importantes em desenvolvimentos avançados de inferência multivariada e cálculo matricial, mas podem ser omitidos em uma primeira leitura sem comprometer a continuidade dos capítulos seguintes.

7.10.4.1 Gradiente matricial e gradiente vetorizado

Considere

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}.$$

Pela definição do gradiente matricial,

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X} \right].$$

Como

$$\text{tr} (\mathbf{A}^\top \Gamma) = \text{vec}(\mathbf{A})^\top \text{vec}(\Gamma),$$

tem-se

$$d\phi = \text{vec} (\nabla_{\mathbf{X}} \phi)^\top d \text{vec}(\mathbf{X}).$$

Logo,

$$\nabla_{\text{vec}(\mathbf{X})} \phi = \text{vec} (\nabla_{\mathbf{X}} \phi).$$

A forma matricial e a forma vetorizada representam a mesma derivada, organizadas em estruturas diferentes.

7.10.4.2 Hessiana de uma função matricial

Para uma função escalar de matriz, a Hessiana vetorizada é definida por

$$\nabla_{\text{vec}(\mathbf{X})}^2 \phi = \frac{\partial \text{vec} (\nabla_{\mathbf{X}} \phi)}{\partial \text{vec}(\mathbf{X})^\top}.$$

Considere

$$\phi(\mathbf{X}) = \text{tr} (\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma),$$

com $\mathbf{A}$ e Γ simétricas.

Foi obtido que

$$\nabla_{\mathbf{X}}\phi = 2\mathbf{A}\mathbf{X}\Gamma.$$

Vetorizando,

$$\begin{aligned}\text{vec}(\nabla_{\mathbf{X}}\phi) &= 2\text{vec}(\mathbf{A}\mathbf{X}\Gamma) \\ &= 2(\Gamma \otimes \mathbf{A})\text{vec}(\mathbf{X}).\end{aligned}$$

Portanto,

$$\nabla_{\text{vec}(\mathbf{X})}^2\phi = 2(\Gamma \otimes \mathbf{A}).$$

Proposição 7.16 (Convexidade da forma quadrática matricial). *Considere*

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^\top \mathbf{A}\mathbf{X}\Gamma),$$

em que

$$\mathbf{A} = \mathbf{A}^\top \in \mathbb{R}^{m \times m}$$

e

$$\Gamma = \Gamma^\top \in \mathbb{R}^{n \times n}.$$

Se

$$\mathbf{A} \succeq \mathbf{0}$$

e

$$\Gamma \succeq \mathbf{0},$$

então ϕ é convexa em $\mathbf{X}$.

Se

$$\mathbf{A} \succ \mathbf{0}$$

e

$$\Gamma \succ \mathbf{0},$$

então ϕ é estritamente convexa.

Comprovação. A Hessiana vetorizada é

$$\nabla_{\text{vec}(\mathbf{X})}^2 \phi = 2 (\Gamma \otimes \mathbf{A}).$$

Se

$$\mathbf{A} \succeq \mathbf{0}$$

e

$$\Gamma \succ \mathbf{0},$$

então

$$\Gamma \otimes \mathbf{A} \succeq \mathbf{0}.$$

Logo, a Hessiana é semidefinida positiva e ϕ é convexa.

Se ambas as matrizes são positivas definidas, então

$$\Gamma \otimes \mathbf{A} \succ \mathbf{0}.$$

Nesse caso, a Hessiana é positiva definida e ϕ é estritamente convexa. □

7.10.4.3 Matriz de comutação

A vetorização de uma matriz e de sua transposta possui ordenações diferentes.

Definição 7.11 (Matriz de comutação). A matriz de comutação

$$\mathbf{K}_{m,n} \in \mathbb{R}^{mn \times mn}$$

é a matriz de permutação que satisfaz

$$\mathbf{K}_{m,n} \text{vec}(\mathbf{X}) = \text{vec}(\mathbf{X}^\top)$$

para toda

$$\mathbf{X} \in \mathbb{R}^{m \times n}.$$

A transposição pode ser desfeita:

$$\mathbf{K}_{n,m} \mathbf{K}_{m,n} = \mathbf{I}_{mn}.$$

Logo,

$$\mathbf{K}_{m,n}^{-1} = \mathbf{K}_{n,m} = \mathbf{K}_{m,n}^\top.$$

Para matrizes quadradas,

$$\mathbf{K}_{p,p} = \mathbf{K}_{p,p}^\top$$

e

$$\mathbf{K}_{p,p}^2 = \mathbf{I}_{p^2}.$$

Considere

$$\mathbf{A} \in \mathbb{R}^{m \times n}$$

e

$$\Gamma \in \mathbb{R}^{r \times s}.$$

A matriz de comutação satisfaz

$$\mathbf{K}_{m,r}(\mathbf{A} \otimes \Gamma) = (\Gamma \otimes \mathbf{A}) \mathbf{K}_{n,s}.$$

Equivalentemente,

$$\mathbf{K}_{m,r}(\mathbf{A} \otimes \Gamma) \mathbf{K}_{s,n} = \Gamma \otimes \mathbf{A}.$$

7.10.4.4 Meia vetorização de matrizes simétricas

Uma matriz simétrica possui elementos repetidos acima e abaixo da diagonal. O operador vech conserva somente os elementos da parte triangular inferior.

Definição 7.12 (Operador de meia vetorização). Para uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{p \times p},$$

o vetor

$$\text{vech}(\mathbf{A}) \in \mathbb{R}^{p(p+1)/2}$$

é obtido pelo empilhamento, por colunas, dos elementos da parte triangular inferior de $\mathbf{A}$, incluindo a diagonal.

Quando

$$\mathbf{A} = \mathbf{S} = \mathbf{S}^\top,$$

o operador vech contém exatamente os elementos distintos de $\mathbf{S}$. Por isso, ele fornece uma parametrização sem redundância do espaço das matrizes simétricas.

Exemplo 7.19 (Meia vetorização de uma matriz simétrica). Considere

$$\mathbf{S} = \begin{bmatrix} s_{11} & s_{12} & s_{13} \\ s_{12} & s_{22} & s_{23} \\ s_{13} & s_{23} & s_{33} \end{bmatrix}.$$

Então,

$$\text{vech}(\mathbf{S}) = \begin{bmatrix} s_{11} \\ s_{12} \\ s_{13} \\ s_{22} \\ s_{23} \\ s_{33} \end{bmatrix}.$$

A ordem acompanha as colunas da parte triangular inferior:

- primeira coluna: s_{11}, s_{12}, s_{13} ;
- segunda coluna: s_{22}, s_{23} ;
- terceira coluna: s_{33} .

O operador vech elimina a duplicação dos elementos simétricos. Enquanto

$$\text{vec}(\mathbf{S})$$

possui p^2 elementos,

$$\text{vech}(\mathbf{S})$$

possui

$$\frac{p(p+1)}{2}$$

elementos. A redução ocorre porque uma matriz simétrica possui apenas

$$\frac{p(p+1)}{2}$$

elementos distintos. Assim, vech fornece uma parametrização sem redundância do espaço das matrizes simétricas.

7.10.4.5 Matriz de duplicação

Definição 7.13 (Matriz de duplicação). A matriz de duplicação

$$\mathbf{D}_p^{\text{dup}} \in \mathbb{R}^{p^2 \times p(p+1)/2}$$

é definida pela identidade

$$\text{vec}(\mathbf{S}) = \mathbf{D}_p^{\text{dup}} \text{vech}(\mathbf{S})$$

para toda matriz simétrica

$$\mathbf{S} \in \mathbb{R}^{p \times p}.$$

A matriz de duplicação repete os elementos fora da diagonal nas posições correspondentes de $\text{vec}(\mathbf{S})$.

Para $p = 2$,

$$\mathbf{S} = \begin{bmatrix} s_{11} & s_{12} \\ s_{12} & s_{22} \end{bmatrix},$$

e

$$\text{vech}(\mathbf{S}) = \begin{bmatrix} s_{11} \\ s_{12} \\ s_{22} \end{bmatrix}.$$

Como

$$\text{vec}(\mathbf{S}) = \begin{bmatrix} s_{11} \\ s_{12} \\ s_{12} \\ s_{22} \end{bmatrix},$$

tem-se

$$\mathbf{D}_2^{\text{dup}} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

7.10.4.6 Matriz de eliminação

Definição 7.14 (Matriz de eliminação). A matriz de eliminação

$$\mathbf{L}_p^{\text{elim}} \in \mathbb{R}^{p(p+1)/2 \times p^2}$$

é a matriz de seleção que satisfaz

$$\text{vech}(\mathbf{A}) = \mathbf{L}_p^{\text{elim}} \text{vec}(\mathbf{A})$$

para toda matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

A matriz de eliminação seleciona da vetorização completa os elementos pertencentes à parte triangular inferior.

As duas matrizes satisfazem

$$\mathbf{L}_p^{\text{elim}} \mathbf{D}_p^{\text{dup}} = \mathbf{I}_{p(p+1)/2}.$$

Em geral,

$$\mathbf{D}_p^{\text{dup}} \mathbf{L}_p^{\text{elim}} \neq \mathbf{I}_{p^2}.$$

A matriz $\mathbf{L}_p^{\text{elim}}$ conserva apenas os elementos correspondentes à parte triangular inferior, enquanto $\mathbf{D}_p^{\text{dup}}$ reconstrói uma matriz impondo simetria. Portanto, esse produto não recupera arbitrariamente uma matriz não simétrica.

Para uma matriz simétrica $\mathbf{S}$, entretanto,

$$\mathbf{D}_p^{\text{dup}} \mathbf{L}_p^{\text{elim}} \text{vec}(\mathbf{S}) = \text{vec}(\mathbf{S}).$$

7.10.4.7 Diferenciais de parâmetros simétricos

Proposição 7.17 (Gradiente em relação aos elementos distintos de uma matriz simétrica).
Considere um parâmetro matricial

$$\Sigma = \Sigma^\top \in \mathbb{R}^{p \times p}$$

e uma função escalar

$$\phi(\Sigma).$$

Suponha que seu diferencial possa ser escrito como

$$d\phi = \text{tr} [\mathbf{G}^\top d\Sigma],$$

em que

$$d\Sigma = d\Sigma^\top.$$

Então,

$$\nabla_{\text{vech}(\Sigma)} \phi = (\mathbf{D}_p^{\text{dup}})^\top \text{vec}(\mathbf{G}).$$

Em particular, quando

$$\mathbf{G} = \nabla_\Sigma \phi,$$

tem-se

$$\nabla_{\text{vech}(\Sigma)} \phi = (\mathbf{D}_p^{\text{dup}})^\top \text{vec}(\nabla_\Sigma \phi).$$

Comprovação. Como

$$\text{vec}(\Sigma) = \mathbf{D}_p^{\text{dup}} \text{vech}(\Sigma),$$

tem-se

$$d \text{vec}(\Sigma) = \mathbf{D}_p^{\text{dup}} d \text{vech}(\Sigma).$$

Além disso,

$$d\phi = \text{vec}(\mathbf{G})^\top d \text{vec}(\Sigma).$$

Substituindo,

$$d\phi = \text{vec}(\mathbf{G})^\top \mathbf{D}_p^{\text{dup}} d \text{vech}(\Sigma).$$

Logo,

$$d\phi = \left[(\mathbf{D}_p^{\text{dup}})^\top \text{vec}(\mathbf{G}) \right]^\top d \text{vech}(\Sigma),$$

de onde segue

$$\nabla_{\text{vech}(\Sigma)} \phi = (\mathbf{D}_p^{\text{dup}})^\top \text{vec}(\mathbf{G}).$$

□

A parametrização por

$$\text{vech}(\Sigma)$$

remove a redundância existente em

$$\text{vec}(\Sigma),$$

pois uma matriz simétrica possui apenas

$$\frac{p(p+1)}{2}$$

elementos livres.

7.10.4.8 Jacobiana de transformações matriciais

Considere uma transformação

$$\mathcal{G} : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}^{r \times s}.$$

Sua representação vetorizada é

$$\mathbf{g}(\text{vec}(\mathbf{X})) = \text{vec}(\mathcal{G}(\mathbf{X})).$$

A Jacobiana vetorizada é

$$\mathbf{J}_{\mathcal{G}}(\mathbf{X}) = \frac{\partial \text{vec}(\mathcal{G}(\mathbf{X}))}{\partial \text{vec}(\mathbf{X})^{\top}}.$$

Ela satisfaz

$$d \text{vec}(\mathcal{G}(\mathbf{X})) = \mathbf{J}_{\mathcal{G}}(\mathbf{X}) d \text{vec}(\mathbf{X}).$$

Exemplo 7.20 (Jacobiana de $\mathbf{X}^{\top} \mathbf{X}$). Considere

$$\mathcal{G}(\mathbf{X}) = \mathbf{X}^{\top} \mathbf{X},$$

com

$$\mathbf{X} \in \mathbb{R}^{m \times n}.$$

O diferencial é

$$d\mathcal{G} = d\mathbf{X}^{\top} \mathbf{X} + \mathbf{X}^{\top} d\mathbf{X}.$$

Vetorizando o primeiro termo,

$$\begin{aligned} \text{vec}(d\mathbf{X}^{\top} \mathbf{X}) &= (\mathbf{X}^{\top} \otimes \mathbf{I}_n) \text{vec}(d\mathbf{X}^{\top}) \\ &= (\mathbf{X}^{\top} \otimes \mathbf{I}_n) \mathbf{K}_{m,n} \text{vec}(d\mathbf{X}). \end{aligned}$$

Para o segundo termo,

$$\text{vec}(\mathbf{X}^{\top} d\mathbf{X}) = (\mathbf{I}_n \otimes \mathbf{X}^{\top}) \text{vec}(d\mathbf{X}).$$

Logo,

$$d \operatorname{vec}(\mathbf{X}^\top \mathbf{X}) = [(\mathbf{X}^\top \otimes \mathbf{I}_n) \mathbf{K}_{m,n} + \mathbf{I}_n \otimes \mathbf{X}^\top] \\ \times d \operatorname{vec}(\mathbf{X}).$$

Portanto, a Jacobiana vetorizada é

$$\mathbf{J}_{\mathcal{G}}(\mathbf{X}) = (\mathbf{X}^\top \otimes \mathbf{I}_n) \mathbf{K}_{m,n} + \mathbf{I}_n \otimes \mathbf{X}^\top.$$

Como

$$\mathbf{X}^\top \mathbf{X}$$

é simétrica, a representação por

$$\operatorname{vec}(\mathbf{X}^\top \mathbf{X})$$

contém elementos repetidos. Uma representação sem redundância é obtida por

$$\operatorname{vech}(\mathbf{X}^\top \mathbf{X}).$$

Aplicando a matriz de eliminação,

$$d \operatorname{vech}(\mathbf{X}^\top \mathbf{X}) = \mathbf{L}_n^{\operatorname{elim}} d \operatorname{vec}(\mathbf{X}^\top \mathbf{X}) \\ = \mathbf{L}_n^{\operatorname{elim}} \mathbf{J}_{\mathcal{G}}(\mathbf{X}) d \operatorname{vec}(\mathbf{X}).$$

Assim, a Jacobiana relativa somente aos elementos distintos de $\mathbf{X}^\top \mathbf{X}$ é

$$\mathbf{J}_{\operatorname{vech} \circ \mathcal{G}}(\mathbf{X}) = \mathbf{L}_n^{\operatorname{elim}} \mathbf{J}_{\mathcal{G}}(\mathbf{X}).$$

A vetorização e o produto de Kronecker permitem representar derivadas matriciais por matrizes usuais. Essa representação será útil para covariâncias de vetores matriciais, Hessianas e aproximações de funções de parâmetros matriciais.

O bloco de aprofundamento mostrou como vec e o produto de Kronecker podem ser estendidos para representar derivadas de ordem superior e parâmetros matriciais com restrições estruturais.

Para a continuidade do livro, as ideias essenciais a reter desta seção são

$$\text{vec}(\mathbf{A}\mathbf{X}\mathbf{\Gamma}) = (\mathbf{\Gamma}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X})$$

e o fato de que matrizes simétricas possuem apenas

$$\frac{p(p+1)}{2}$$

elementos distintos.

7.11 Integração múltipla e mudança de variáveis

O cálculo integral permite obter probabilidades, esperanças, momentos e distribuições marginais de vetores aleatórios contínuos. A mudança de variáveis permite, adicionalmente, transformar regiões de integração e determinar densidades após transformações do vetor aleatório.

Para vetores aleatórios contínuos, as integrais são realizadas sobre subconjuntos de $\mathbb{R}^p$. Nesta seção, integrais múltiplas, marginalização, esperanças e mudança de variáveis constituem o núcleo necessário para os capítulos probabilísticos seguintes. A diferenciação sob o sinal de integração será apresentada posteriormente como aprofundamento.

7.11.1 Integrais múltiplas

Considere uma função

$$f : \mathcal{D} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}.$$

Sua integral sobre $\mathcal{D}$ é representada por

$$\int_{\mathcal{D}} f(\mathbf{x}) d\mathbf{x},$$

em que

$$d\mathbf{x} = dx_1 \cdots dx_p.$$

Em duas dimensões,

$$\int_{\mathcal{D}} f(x_1, x_2) dx_1 dx_2$$

representa a acumulação dos valores da função sobre uma região do plano.

Quando

$$\mathcal{D} = \mathcal{D}_1 \times \cdots \times \mathcal{D}_p$$

é um produto cartesiano, a integral pode ser escrita como integral iterada:

$$\int_{\mathcal{D}} f(\mathbf{x}) d\mathbf{x} = \int_{\mathcal{D}_p} \cdots \int_{\mathcal{D}_1} f(x_1, \dots, x_p) dx_1 \cdots dx_p,$$

desde que sejam satisfeitas as condições que permitem a integração sucessiva.

O produto cartesiano corresponde ao caso mais simples. Para regiões mais gerais, os limites de uma integral podem depender das demais variáveis. Em duas dimensões, por exemplo, uma região da forma

$$\mathcal{D} = \{(x_1, x_2) : a < x_1 < b, c(x_1) < x_2 < d(x_1)\}$$

conduz a

$$\int_{\mathcal{D}} f(x_1, x_2) dx_1 dx_2 = \int_a^b \int_{c(x_1)}^{d(x_1)} f(x_1, x_2) dx_2 dx_1,$$

quando as condições de integração correspondentes são satisfeitas.

7.11.2 Teoremas de Tonelli e Fubini

Teorema 7.7 (Teorema de Tonelli). *Se*

$$f : \mathcal{D}_1 \times \mathcal{D}_2 \longrightarrow [0, \infty]$$

é mensurável e não negativa, então

$$\begin{aligned} \int_{\mathcal{D}_1 \times \mathcal{D}_2} f(x_1, x_2) dx_1 dx_2 &= \int_{\mathcal{D}_1} \left[\int_{\mathcal{D}_2} f(x_1, x_2) dx_2 \right] dx_1 \\ &= \int_{\mathcal{D}_2} \left[\int_{\mathcal{D}_1} f(x_1, x_2) dx_1 \right] dx_2, \end{aligned}$$

permitindo valores infinitos. (Axler, 2020)

Para funções não negativas, a ordem de integração pode ser alterada mesmo quando a integral total não é finita.

Teorema 7.8 (Teorema de Fubini). *Se*

$$f : \mathcal{D}_1 \times \mathcal{D}_2 \longrightarrow \mathbb{R}$$

é mensurável e absolutamente integrável, isto é,

$$\int_{\mathcal{D}_1 \times \mathcal{D}_2} |f(x_1, x_2)| \, dx_1 \, dx_2 < \infty,$$

então, para quase todo $x_1 \in \mathcal{D}_1$,

$$x_2 \mapsto f(x_1, x_2)$$

é integrável em $\mathcal{D}_2$, e, para quase todo $x_2 \in \mathcal{D}_2$,

$$x_1 \mapsto f(x_1, x_2)$$

é integrável em $\mathcal{D}_1$.

Além disso,

$$\begin{aligned} \int_{\mathcal{D}_1 \times \mathcal{D}_2} f(x_1, x_2) \, dx_1 \, dx_2 &= \int_{\mathcal{D}_1} \left[\int_{\mathcal{D}_2} f(x_1, x_2) \, dx_2 \right] dx_1 \\ &= \int_{\mathcal{D}_2} \left[\int_{\mathcal{D}_1} f(x_1, x_2) \, dx_1 \right] dx_2. \end{aligned}$$

(Axler, 2020)

A integrabilidade absoluta é uma condição suficiente para trocar a ordem de integração.

7.11.3 Densidades multivariadas

Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ \vdots \\ X_p \end{bmatrix} \in \mathbb{R}^p.$$

Definição 7.15 (Densidade conjunta). O vetor aleatório $\mathbf{X}$ é absolutamente contínuo em relação à medida de Lebesgue em $\mathbb{R}^p$ quando existe uma função mensurável

$$f_{\mathbf{X}} : \mathbb{R}^p \longrightarrow [0, \infty]$$

tal que, para todo conjunto mensurável

$$\mathcal{A} \subseteq \mathbb{R}^p,$$

tem-se

$$P(\mathbf{X} \in \mathcal{A}) = \int_{\mathcal{A}} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

A função $f_{\mathbf{X}}$ é denominada **densidade conjunta** de $\mathbf{X}$.

Tomando

$$\mathcal{A} = \mathbb{R}^p,$$

segue necessariamente que

$$\int_{\mathbb{R}^p} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x} = 1.$$

Em duas dimensões,

$$P[(X_1, X_2) \in \mathcal{A}] = \iint_{\mathcal{A}} f_{X_1, X_2}(x_1, x_2) dx_1 dx_2.$$

7.11.4 Distribuições marginais

Considere a partição

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix},$$

com

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}$$

e

$$p_1 + p_2 = p.$$

Proposição 7.18 (Densidades marginais). *Considere o vetor aleatório absolutamente contínuo particionado como*

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix},$$

com densidade conjunta

$$f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2).$$

Então, uma densidade marginal de $\mathbf{X}_1$ é

$$f_{\mathbf{X}_1}(\mathbf{x}_1) = \int_{\mathbb{R}^{p_2}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_2,$$

e uma densidade marginal de $\mathbf{X}_2$ é

$$f_{\mathbf{X}_2}(\mathbf{x}_2) = \int_{\mathbb{R}^{p_1}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_1.$$

Comprovação. Como a densidade conjunta é não negativa, o Teorema 7.7 permite integrar sucessivamente suas componentes.

Para qualquer conjunto mensurável

$$\mathcal{A} \subseteq \mathbb{R}^{p_1},$$

tem-se

$$\begin{aligned} P(\mathbf{X}_1 \in \mathcal{A}) &= \int_{\mathcal{A} \times \mathbb{R}^{p_2}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_1 d\mathbf{x}_2 \\ &= \int_{\mathcal{A}} \left[\int_{\mathbb{R}^{p_2}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_2 \right] d\mathbf{x}_1. \end{aligned}$$

Portanto,

$$f_{\mathbf{X}_1}(\mathbf{x}_1) = \int_{\mathbb{R}^{p_2}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_2$$

é uma densidade marginal de $\mathbf{X}_1$. O argumento para $\mathbf{X}_2$ é análogo. $\square$

A marginalização elimina as componentes que não aparecem no resultado, acumulando a densidade conjunta sobre todos os seus valores possíveis.

Exemplo 7.21 (Densidade marginal em uma região triangular). Considere a densidade conjunta

$$f_{\mathbf{X}_1, \mathbf{X}_2}(x_1, x_2) = 2,$$

para

$$0 < x_2 < x_1 < 1,$$

e zero fora dessa região.

A densidade marginal de $\mathbf{X}_1$ é

$$\begin{aligned} f_{\mathbf{X}_1}(x_1) &= \int_0^{x_1} 2 dx_2 \\ &= 2x_1, \quad 0 < x_1 < 1. \end{aligned}$$

A densidade marginal de $\mathbf{X}_2$ é

$$\begin{aligned} f_{\mathbf{X}_2}(x_2) &= \int_{x_2}^1 2 dx_1 \\ &= 2(1 - x_2), \quad 0 < x_2 < 1. \end{aligned}$$

As duas densidades integram 1 em seus respectivos domínios.

7.11.5 Esperanças de funções escalares, vetoriais e matriciais

Se

$$h : \mathbb{R}^p \longrightarrow \mathbb{R}$$

é uma função integrável, sua esperança é

$$E[h(\mathbf{X})] = \int_{\mathbb{R}^p} h(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

Para uma função vetorial

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

com

$$\mathbf{g}(\mathbf{x}) = \begin{bmatrix} g_1(\mathbf{x}) \\ \vdots \\ g_q(\mathbf{x}) \end{bmatrix},$$

a esperança é definida componente a componente:

$$E[\mathbf{g}(\mathbf{X})] = \begin{bmatrix} E[g_1(\mathbf{X})] \\ \vdots \\ E[g_q(\mathbf{X})] \end{bmatrix}.$$

Equivalentemente,

$$E[\mathbf{g}(\mathbf{X})] = \int_{\mathbb{R}^p} \mathbf{g}(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

Para uma função matricial

$$\mathcal{G} : \mathbb{R}^p \longrightarrow \mathbb{R}^{m \times n},$$

a esperança também é calculada elemento a elemento:

$$E[\mathcal{G}(\mathbf{X})] = \int_{\mathbb{R}^p} \mathcal{G}(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

Em particular,

$$E[\mathbf{X}\mathbf{X}^\top] = \int_{\mathbb{R}^p} \mathbf{x}\mathbf{x}^\top f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

A existência da esperança vetorial ou matricial exige integrabilidade dos elementos correspondentes.

7.11.6 Mudança de variáveis

Uma transformação diferenciável altera a posição dos pontos e o volume dos elementos infinitesimais. O determinante da Jacobiana mede essa alteração local de volume.

Considere uma transformação

$$\mathbf{g} : \mathcal{D} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

e defina

$$\mathbf{y} = \mathbf{g}(\mathbf{x}).$$

A aproximação local é

$$d\mathbf{y} = \mathbf{J}_{\mathbf{g}}(\mathbf{x})d\mathbf{x}.$$

O fator local de alteração de volume é

$$|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|.$$

O valor absoluto é necessário porque o determinante pode ser negativo quando a transformação altera a orientação do espaço.

Teorema 7.9 (Teorema da Mudança de Variáveis). *Considere conjuntos abertos*

$$\mathcal{D}, \mathcal{G} \subseteq \mathbb{R}^p$$

e uma transformação bijetiva

$$\mathbf{g} : \mathcal{D} \longrightarrow \mathcal{G}$$

continuamente diferenciável, com inversa continuamente diferenciável e

$$\det \mathbf{J}_{\mathbf{g}}(\mathbf{x}) \neq 0$$

para todo $\mathbf{x} \in \mathcal{D}$.

Então, para uma função integrável h ,

$$\int_{\mathcal{G}} h(\mathbf{y}) \, d\mathbf{y} = \int_{\mathcal{D}} h(\mathbf{g}(\mathbf{x})) |\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})| \, d\mathbf{x}.$$

(Apostol, 1969)

Utilizando a transformação inversa

$$\mathbf{x} = \mathbf{g}^{-1}(\mathbf{y}),$$

o elemento de volume transforma-se segundo

$$d\mathbf{x} = |\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y})| \, d\mathbf{y}.$$

Como

$$\mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y}) = [\mathbf{J}_{\mathbf{g}}(\mathbf{x})]^{-1},$$

segue que

$$|\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y})| = \frac{1}{|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|}.$$

7.11.7 Transformação de densidades

Proposição 7.19 (Densidade de uma transformação invertível). *Considere um vetor aleatório absolutamente contínuo $\mathbf{X}$ com densidade $f_{\mathbf{X}}$, tal que*

$$P(\mathbf{X} \in \mathcal{D}) = 1,$$

e uma transformação

$$\mathbf{g} : \mathcal{D} \longrightarrow \mathcal{G}$$

satisfazendo as condições do Teorema 7.9.

Defina

$$\mathbf{Y} = \mathbf{g}(\mathbf{X}).$$

Então, para

$$\mathbf{y} \in \mathcal{G},$$

a densidade de $\mathbf{Y}$ é

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}(\mathbf{g}^{-1}(\mathbf{y})) |\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y})|.$$

Para

$$\mathbf{y} \notin \mathcal{G},$$

tem-se

$$f_{\mathbf{Y}}(\mathbf{y}) = 0.$$

Equivalentemente, com

$$\mathbf{y} = \mathbf{g}(\mathbf{x}),$$

tem-se

$$f_{\mathbf{Y}}(\mathbf{g}(\mathbf{x})) = \frac{f_{\mathbf{X}}(\mathbf{x})}{|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|}.$$

A densidade é reduzida em regiões expandidas pela transformação e aumentada em regiões contraídas, de modo que a probabilidade total permaneça igual a 1.

Quando a transformação não é globalmente injetiva, a fórmula anterior não pode ser aplicada diretamente com uma única inversa. Sob condições de regularidade, pode-se particionar o domínio em regiões nas quais a transformação seja injetiva e somar as contribuições correspondentes às diferentes pré-imagens.

Esse caso não será desenvolvido em detalhe neste capítulo.

7.11.8 Transformações afins

Considere

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b},$$

em que

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é invertível e

$$\mathbf{b} \in \mathbb{R}^p.$$

A transformação inversa é

$$\mathbf{X} = \mathbf{A}^{-1}(\mathbf{Y} - \mathbf{b}).$$

A Jacobiana da transformação é constante:

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}.$$

A Jacobiana da inversa é

$$\mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y}) = \mathbf{A}^{-1}.$$

Logo,

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}[\mathbf{A}^{-1}(\mathbf{y} - \mathbf{b})] \frac{1}{|\det(\mathbf{A})|}.$$

A translação $\mathbf{b}$ altera a posição da distribuição, mas não altera o fator de volume. Esse fator depende apenas da parte linear.

Exemplo 7.22 (Transformação afim em uma dimensão). Considere

$$Y = aX + b,$$

com $a \neq 0$.

A transformação inversa é

$$X = \frac{Y - b}{a},$$

e

$$\left| \frac{dx}{dy} \right| = \frac{1}{|a|}.$$

Portanto,

$$f_Y(y) = f_X\left(\frac{y - b}{a}\right) \frac{1}{|a|}.$$

7.11.9 Interpretação geométrica do determinante Jacobiano

Considere a transformação não linear

$$\mathbf{g}(x_1, x_2) = \begin{bmatrix} x_1 + 0,35x_1x_2 \\ x_2 + 0,20x_1^2 \end{bmatrix}.$$

Sua Jacobiana é

$$\mathbf{J}_{\mathbf{g}}(x_1, x_2) = \begin{bmatrix} 1 + 0,35x_2 & 0,35x_1 \\ 0,40x_1 & 1 \end{bmatrix}.$$

O determinante é

$$\det \mathbf{J}_{\mathbf{g}}(x_1, x_2) = 1 + 0,35x_2 - 0,14x_1^2.$$

O fator de alteração de área varia de acordo com o ponto. A Figura 7.4 mostra uma grade no domínio e sua imagem pela transformação.




Figura 7.4: Transformação de uma grade e alteração local de área determinada pelo Jacobiano.

Uma pequena região em torno de $\mathbf{x}$ tem sua área multiplicada aproximadamente por

$$|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|.$$

A imagem da grade apresenta expansão e contração diferentes ao longo do domínio porque o determinante Jacobiano não é constante.

7.11.10 Coordenadas polares

Em duas dimensões, defina

$$x_1 = r \cos \theta$$

e

$$x_2 = r \sin \theta,$$

com

$$r > 0$$

e

$$0 \leq \theta < 2\pi.$$

A transformação é

$$\mathbf{g}(r, \theta) = \begin{bmatrix} r \cos \theta \\ r \sin \theta \end{bmatrix}.$$

Sua Jacobiana é

$$\mathbf{J}_{\mathbf{g}}(r, \theta) = \begin{bmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{bmatrix}.$$

O determinante é

$$\det \mathbf{J}_{\mathbf{g}}(r, \theta) = r.$$

Portanto,

$$dx_1 dx_2 = r dr d\theta.$$

Assim,

$$\iint_{\mathbb{R}^2} h(x_1, x_2) dx_1 dx_2 = \int_0^{2\pi} \int_0^\infty h(r \cos \theta, r \sin \theta) r dr d\theta,$$

quando a função é integrável.

A parametrização polar não é uma transformação globalmente bijetiva em todas as escolhas possíveis de domínio: a origem possui representação angular não única e o ângulo é periódico. Para a aplicação da fórmula de mudança de variáveis, trabalha-se em regiões adequadas de injetividade; as fronteiras envolvidas possuem medida nula e não alteram o valor das integrais usuais.

7.11.11 Transformações elipsoidais

Considere uma matriz positiva definida

$$\Sigma \in \mathbb{R}^{p \times p}$$

e sua raiz quadrada principal simétrica positiva definida

$$\Sigma^{1/2}.$$

Considere a transformação

$$\mathbf{x} = \mu + \Sigma^{1/2} \mathbf{z}.$$

A Jacobiana é

$$\mathbf{J}_{\mathbf{g}}(\mathbf{z}) = \Sigma^{1/2}.$$

Logo,

$$|\det \mathbf{J}_{\mathbf{g}}(\mathbf{z})| = \det(\Sigma^{1/2}) = \det(\Sigma)^{1/2}.$$

A transformação inversa é

$$\mathbf{z} = \Sigma^{-1/2} (\mathbf{x} - \mu),$$

com fator

$$|\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{x})| = \det(\Sigma)^{-1/2}.$$

Além disso,

$$\begin{aligned}\mathbf{z}^\top \mathbf{z} &= (\mathbf{x} - \mu)^\top \Sigma^{-1/2} \Sigma^{-1/2} (\mathbf{x} - \mu) \\ &= (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu).\end{aligned}$$

A transformação converte esferas no espaço de $\mathbf{z}$ em elipsoides no espaço de $\mathbf{x}$. Essa relação será utilizada na construção de densidades multivariadas.

7.11.12 Aprofundamento: diferenciação sob o sinal de integração

Leitura de aprofundamento

A diferenciação sob o sinal de integração é utilizada para justificar formalmente identidades envolvendo funções de verossimilhança, vetor escore e informação de Fisher. Esse conteúdo é importante para desenvolvimentos inferenciais mais formais, mas pode ser omitido em uma primeira leitura. Para a continuidade imediata dos capítulos probabilísticos, basta reter que a troca entre derivação e integração exige condições de regularidade e não pode ser realizada automaticamente.

Considere um conjunto mensurável

$$\mathcal{D} \subseteq \mathbb{R}^p,$$

uma região aberta

$$\mathcal{V} \subseteq \mathbb{R}^k$$

e uma função

$$h : \mathcal{D} \times \mathcal{V} \longrightarrow \mathbb{R}.$$

A função depende da variável de integração $\mathbf{x}$ e do parâmetro

$$\theta \in \mathcal{V}.$$

Defina

$$F(\theta) = \int_{\mathcal{D}} h(\mathbf{x}, \theta) d\mathbf{x}.$$

A troca entre diferenciação e integração pode ser justificada pelo Teorema da Convergência Dominada.

Teorema 7.10 (Teorema da Convergência Dominada). *Considere uma sequência de funções mensuráveis*

$$g_1, g_2, \dots$$

definidas em $\mathcal{D}$ e suponha que

$$g_m(\mathbf{x}) \longrightarrow g(\mathbf{x})$$

para quase todo $\mathbf{x} \in \mathcal{D}$.

Se existe uma função integrável

$$M : \mathcal{D} \longrightarrow [0, \infty)$$

tal que

$$|g_m(\mathbf{x})| \leq M(\mathbf{x})$$

para todo m e quase todo $\mathbf{x} \in \mathcal{D}$, então g é integrável e

$$\lim_{m \rightarrow \infty} \int_{\mathcal{D}} g_m(\mathbf{x}) d\mathbf{x} = \int_{\mathcal{D}} g(\mathbf{x}) d\mathbf{x}.$$

(Axler, 2020)

O teorema permite trocar um limite e uma integral quando todas as funções da sequência são dominadas por uma mesma função integrável. A diferenciação sob o sinal de integração decorre da aplicação desse resultado aos quocientes de diferenças.

Teorema 7.11 (Diferenciação sob o sinal de integração). *Considere um ponto*

$$\theta_0 \in \mathcal{V}$$

e uma componente

$$j \in \{1, \dots, k\}.$$

Suponha que:

1. *para todo $\theta \in \mathcal{V}$, a função*

$$\mathbf{x} \mapsto h(\mathbf{x}, \theta)$$

seja mensurável e integrável em $\mathcal{D}$;

2. *exista $\delta > 0$ tal que*

$$\theta_0 + t\mathbf{e}_j \in \mathcal{V}$$

para todo t com $|t| < \delta$, em que $\mathbf{e}_j$ é o j -ésimo vetor da base canônica de $\mathbb{R}^k$;

3. *para quase todo $\mathbf{x} \in \mathcal{D}$, a função*

$$t \mapsto h(\mathbf{x}, \theta_0 + t\mathbf{e}_j)$$

seja diferenciável em $(-\delta, \delta)$;

4. *exista uma função integrável*

$$M_j : \mathcal{D} \rightarrow [0, \infty)$$

tal que, para quase todo

$$\mathbf{x} \in \mathcal{D},$$

a desigualdade

$$\left| \frac{\partial h(\mathbf{x}, \theta_0 + t\mathbf{e}_j)}{\partial \theta_j} \right| \leq M_j(\mathbf{x})$$

seja válida para todo t com $|t| < \delta$;

5. a função

$$\mathbf{x} \mapsto \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j}$$

seja mensurável.

Então, F é parcialmente diferenciável em relação a θ_j no ponto θ_0 e

$$\frac{\partial F(\theta_0)}{\partial \theta_j} = \int_{\mathcal{D}} \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j} d\mathbf{x}.$$

Comprovação. Considere uma sequência arbitrária de números não nulos

$$t_1, t_2, \dots$$

tal que

$$t_m \longrightarrow 0$$

e

$$|t_m| < \delta.$$

Defina o quociente de diferenças

$$q_m(\mathbf{x}) = \frac{h(\mathbf{x}, \theta_0 + t_m \mathbf{e}_j) - h(\mathbf{x}, \theta_0)}{t_m}.$$

Para quase todo $\mathbf{x} \in \mathcal{D}$, a diferenciabilidade em relação a θ_j implica

$$q_m(\mathbf{x}) \longrightarrow \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j}.$$

Pelo Teorema do Valor Médio aplicado à função

$$t \mapsto h(\mathbf{x}, \theta_0 + t \mathbf{e}_j),$$

existe um número $\xi_m(\mathbf{x})$ situado entre 0 e t_m tal que

$$q_m(\mathbf{x}) = \frac{\partial h(\mathbf{x}, \theta_0 + \xi_m(\mathbf{x})\mathbf{e}_j)}{\partial \theta_j}.$$

Como

$$|\xi_m(\mathbf{x})| < \delta,$$

a hipótese de dominação fornece

$$|q_m(\mathbf{x})| \leq M_j(\mathbf{x})$$

para quase todo $\mathbf{x} \in \mathcal{D}$.

O Teorema da Convergência Dominada implica

$$\begin{aligned} \lim_{m \rightarrow \infty} \int_{\mathcal{D}} q_m(\mathbf{x}) d\mathbf{x} &= \int_{\mathcal{D}} \lim_{m \rightarrow \infty} q_m(\mathbf{x}) d\mathbf{x} \\ &= \int_{\mathcal{D}} \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j} d\mathbf{x}. \end{aligned}$$

Por outro lado,

$$\begin{aligned} \int_{\mathcal{D}} q_m(\mathbf{x}) d\mathbf{x} &= \frac{\int_{\mathcal{D}} h(\mathbf{x}, \theta_0 + t_m \mathbf{e}_j) d\mathbf{x} - \int_{\mathcal{D}} h(\mathbf{x}, \theta_0) d\mathbf{x}}{t_m} \\ &= \frac{F(\theta_0 + t_m \mathbf{e}_j) - F(\theta_0)}{t_m}. \end{aligned}$$

Logo,

$$\lim_{m \rightarrow \infty} \frac{F(\theta_0 + t_m \mathbf{e}_j) - F(\theta_0)}{t_m} = \int_{\mathcal{D}} \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j} d\mathbf{x}.$$

Como a sequência $t_m \rightarrow 0$ foi escolhida arbitrariamente, a derivada parcial existe e satisfaz a igualdade enunciada. $\square$

Quando as condições do Teorema 7.11 são satisfeitas para todas as componentes do parâmetro,

$$\nabla_{\theta} F(\theta_0) = \int_{\mathcal{D}} \nabla_{\theta} h(\mathbf{x}, \theta_0) d\mathbf{x}.$$

A função dominante pode ser diferente para cada componente do gradiente, desde que cada uma seja integrável.

O resultado pressupõe que o domínio $\mathcal{D}$ não depende de θ . Quando o domínio ou a fronteira da região de integração varia com o parâmetro, a derivação pode produzir termos adicionais. Esse caso não será desenvolvido neste capítulo.

Exemplo 7.23 (Derivação de uma identidade de normalização). Considere uma família de densidades

$$f(\mathbf{x}; \theta),$$

definida sobre um suporte comum

$$\mathcal{D}$$

que não depende de θ .

Para todo θ ,

$$\int_{\mathcal{D}} f(\mathbf{x}; \theta) d\mathbf{x} = 1.$$

Suponha que as condições do Teorema 7.11 sejam satisfeitas para todas as componentes de θ . Então,

$$\begin{aligned} \mathbf{0} &= \nabla_{\theta} 1 \\ &= \nabla_{\theta} \int_{\mathcal{D}} f(\mathbf{x}; \theta) d\mathbf{x} \\ &= \int_{\mathcal{D}} \nabla_{\theta} f(\mathbf{x}; \theta) d\mathbf{x}. \end{aligned}$$

Se

$$f(\mathbf{x}; \theta) > 0$$

para quase todo $\mathbf{x} \in \mathcal{D}$, então

$$\nabla_{\theta} f(\mathbf{x}; \theta) = f(\mathbf{x}; \theta) \nabla_{\theta} \log f(\mathbf{x}; \theta).$$

Portanto,

$$\int_{\mathcal{D}} f(\mathbf{x}; \theta) \nabla_{\theta} \log f(\mathbf{x}; \theta) d\mathbf{x} = \mathbf{0}.$$

Se

X

possui densidade $f(\mathbf{x}; \theta)$, segue que

$$E_{\theta} [\nabla_{\theta} \log f(\mathbf{X}; \theta)] = \mathbf{0}.$$

Essa é a identidade de média nula do escore para uma observação. Sua validade depende do suporte comum e das condições de dominação que justificam a troca entre diferenciação e integração.

As integrais múltiplas, a marginalização e a mudança de variáveis fornecem a base para o estudo das distribuições multivariadas. A parte de aprofundamento mostrou, adicionalmente, como condições de dominação podem justificar a diferenciação de integrais parametrizadas e identidades utilizadas posteriormente em inferência.

Para a continuidade do livro, as ideias centrais a reter são:

- probabilidades são obtidas por integração da densidade conjunta;
- densidades marginais são obtidas integrando as componentes que se deseja eliminar;
- esperanças de vetores e matrizes são calculadas componente a componente;
- mudanças de variáveis exigem o determinante absoluto da Jacobiana;
- transformações afins produzem fatores de volume constantes;
- transformações elipsoidais convertem geometria esférica e elipsoidal.

7.12 Aprofundamento: aplicações à estimação e à inferência

Leitura de aprofundamento

As subseções seguintes mostram como as ferramentas de cálculo desenvolvidas neste capítulo aparecem em problemas de estimação e inferência.

O objetivo é apresentar apenas a estrutura matemática dessas aplicações. As propriedades probabilísticas dos estimadores, as condições de regularidade, as distribuições assintóticas e os procedimentos inferenciais serão desenvolvidos nos capítulos específicos do Módulo II.

Este bloco pode ser omitido em uma primeira leitura sem comprometer a continuidade imediata do livro.

As aplicações seguintes envolvem gradientes, Hessianas, expansões de Taylor, diferenciação sob o sinal de integração e cálculo matricial. Elas antecipam, em nível matemático, conceitos que serão retomados posteriormente.

7.12.1 Log-verossimilhança e vetor escore

Considere observações independentes

$$\mathbf{x}_1, \dots, \mathbf{x}_n$$

provenientes de um mesmo modelo paramétrico com função de densidade ou de probabilidade

$$f(\mathbf{x}; \theta),$$

em que

$$\theta \in \Theta \subseteq \mathbb{R}^k$$

é o vetor de parâmetros e Θ é o espaço paramétrico.

Nessas condições, a função de verossimilhança é

$$L_n(\theta) = \prod_{i=1}^n f(\mathbf{x}_i; \theta).$$

A log-verossimilhança é

$$\ell_n(\theta) = \log L_n(\theta) = \sum_{i=1}^n \log f(\mathbf{x}_i; \theta).$$

Como o logaritmo é estritamente crescente, maximizar L_n equivale a maximizar ℓ_n .

Definição 7.16 (Vetor escore). O vetor escore é o gradiente da log-verossimilhança:

$$\mathbf{s}_n(\theta) = \nabla_{\theta} \ell_n(\theta) \in \mathbb{R}^k.$$

Em coordenadas,

$$\mathbf{s}_n(\theta) = \begin{bmatrix} \frac{\partial \ell_n}{\partial \theta_1} \\ \vdots \\ \frac{\partial \ell_n}{\partial \theta_k} \end{bmatrix}.$$

Se um estimador de máxima verossimilhança é um ponto interior do espaço paramétrico e a log-verossimilhança é diferenciável nesse ponto, então deve satisfazer

$$\mathbf{s}_n(\hat{\theta}) = \mathbf{0}.$$

Essa condição é necessária, mas pode não ser suficiente para identificar um máximo. Também devem ser examinados:

- a curvatura da log-verossimilhança;
- a existência e a unicidade da solução;
- os limites do espaço paramétrico;
- possíveis máximos na fronteira.

7.12.2 Informação observada e informação de Fisher

Definição 7.17 (Informação observada). A matriz de informação observada é

$$\mathcal{J}_n(\theta) = -\nabla_{\theta}^2 \ell_n(\theta).$$

Se

$$\mathbf{s}_n(\hat{\theta}) = \mathbf{0}$$

e

$$\mathcal{J}_n(\hat{\theta}) \succ \mathbf{0},$$

então

$$\nabla_{\theta}^2 \ell_n(\hat{\theta}) \prec \mathbf{0},$$

e o teste da Hessiana fornece uma condição suficiente para que $\hat{\theta}$ seja um máximo local estrito da log-verossimilhança.

Em um ponto arbitrário do espaço paramétrico, a matriz

$$\mathcal{J}_n(\theta) = -\nabla_{\theta}^2 \ell_n(\theta)$$

não precisa ser positiva semidefinida e pode, inclusive, ser indefinida.

Em um ponto estacionário interior que seja máximo local,

$$\nabla_{\theta}^2 \ell_n(\hat{\theta}) \preceq \mathbf{0},$$

de modo que

$$\mathcal{J}_n(\hat{\theta}) \succeq \mathbf{0}.$$

A informação observada pode ser singular quando, por exemplo:

- há parâmetros localmente não identificados;
- existem redundâncias na parametrização;
- a log-verossimilhança apresenta direções localmente planas.

Máximos na fronteira exigem tratamento separado, pois as condições usuais de ponto estacionário e o teste irrestrito da Hessiana não os caracterizam adequadamente.

Definição 7.18 (Informação de Fisher). Suponha que o vetor escore possua segundo momento finito. A informação de Fisher da amostra é definida por

$$\mathcal{J}_n(\theta) = E_\theta [\mathbf{s}_n(\theta)\mathbf{s}_n(\theta)^\top].$$

(Casella; Berger, 2002)

Sob condições de regularidade que permitem diferenciar a densidade sob o sinal de integração,

$$E_\theta [\mathbf{s}_n(\theta)] = \mathbf{0}.$$

Sob condições adicionais que justificam a relação entre a primeira e a segunda derivadas da log-verossimilhança,

$$\begin{aligned}\mathcal{J}_n(\theta) &= -E_\theta [\nabla_\theta^2 \ell_n(\theta)] \\ &= E_\theta [\mathcal{J}_n(\theta)].\end{aligned}$$

Assim, em modelos regulares, a informação de Fisher coincide com a esperança da informação observada. Como o escore possui esperança nula nessas condições,

$$\mathcal{J}_n(\theta) = \text{Cov}_\theta [\mathbf{s}_n(\theta)].$$

Essas identidades não devem ser utilizadas automaticamente. Sua validade depende das condições de regularidade, incluindo a possibilidade de intercambiar derivação e integração e o comportamento do suporte em relação ao parâmetro.

7.12.3 Newton–Raphson

A estimação por máxima verossimilhança pode exigir a solução numérica de

$$\mathbf{s}_n(\theta) = \mathbf{0}.$$

A expansão de primeira ordem do escore em torno de um valor atual $\theta^{(t)}$ é

$$\mathbf{s}_n(\theta) \approx \mathbf{s}_n(\theta^{(t)}) + \nabla_\theta \ell_n(\theta^{(t)}) (\theta - \theta^{(t)}).$$

Igualando a aproximação a zero,

$$\begin{aligned}\theta^{(t+1)} &= \theta^{(t)} - \left[\nabla_{\theta}^2 \ell_n \left(\theta^{(t)} \right) \right]^{-1} \mathbf{s}_n \left(\theta^{(t)} \right) \\ &= \theta^{(t)} + \mathcal{J}_n \left(\theta^{(t)} \right)^{-1} \mathbf{s}_n \left(\theta^{(t)} \right).\end{aligned}$$

Na implementação, a atualização deve ser obtida pela solução do sistema

$$\mathcal{J}_n \left(\theta^{(t)} \right) \mathbf{d}^{(t)} = \mathbf{s}_n \left(\theta^{(t)} \right),$$

seguida de

$$\theta^{(t+1)} = \theta^{(t)} + \mathbf{d}^{(t)}.$$

Isso evita calcular explicitamente a inversa da informação observada.

Essa é a aplicação do método de Newton à equação

$$\mathbf{s}_n(\theta) = \mathbf{0}.$$

Quando

$$\mathcal{J}_n \left(\theta^{(t)} \right) \succ \mathbf{0},$$

a direção

$$\mathbf{d}^{(t)} = \mathcal{J}_n \left(\theta^{(t)} \right)^{-1} \mathbf{s}_n \left(\theta^{(t)} \right)$$

é uma direção local de aumento da log-verossimilhança, pois

$$\mathbf{s}_n \left(\theta^{(t)} \right)^{\top} \mathbf{d}^{(t)} > 0$$

quando o escore é não nulo.

Ainda assim, um passo completo pode não aumentar a log-verossimilhança quando o ponto atual está distante da solução. Em aplicações numéricas, podem ser utilizados controles do comprimento da etapa.

7.12.4 Método do escore de Fisher

O método do escore de Fisher substitui a informação observada

$$\mathcal{J}_n(\theta)$$

pela informação de Fisher

$$\mathcal{J}_n(\theta).$$

Sob as condições de regularidade para as quais

$$\mathcal{J}_n(\theta) = E_{\theta} [\mathcal{J}_n(\theta)],$$

essa substituição pode ser interpretada como a troca da curvatura observada pela curvatura esperada da log-verossimilhança.

Quando

$$\mathcal{J}_n(\theta^{(t)})$$

é invertível, a direção $\mathbf{d}^{(t)}$ é obtida pela solução de

$$\mathcal{J}_n(\theta^{(t)}) \mathbf{d}^{(t)} = \mathbf{s}_n(\theta^{(t)}),$$

seguida da atualização

$$\theta^{(t+1)} = \theta^{(t)} + \mathbf{d}^{(t)}.$$

Assim, Newton–Raphson utiliza

$$\mathcal{J}_n(\theta),$$

enquanto o método do escore de Fisher utiliza

$$\mathcal{J}_n(\theta).$$

Quando a identidade de informação é válida, a primeira representa a curvatura observada e a segunda sua correspondente curvatura esperada.

As atualizações coincidem quando as duas matrizes são iguais no ponto considerado ou, mais geralmente, quando produzem a mesma solução para a equação que determina a direção da etapa.

7.12.5 Expansão local de uma raiz do escore

Suponha que um estimador

$$\hat{\theta}$$

satisfaça a equação

$$\mathbf{s}_n(\hat{\theta}) = \mathbf{0}.$$

Expandindo o escore em torno do parâmetro verdadeiro θ_0 ,

$$\begin{aligned} \mathbf{0} &= \mathbf{s}_n(\hat{\theta}) \\ &\approx \mathbf{s}_n(\theta_0) + \nabla_{\theta}^2 \ell_n(\theta_0) (\hat{\theta} - \theta_0). \end{aligned}$$

Como

$$\nabla_{\theta}^2 \ell_n(\theta_0) = -\mathcal{J}_n(\theta_0),$$

obtém-se a aproximação

$$\hat{\theta} - \theta_0 \approx \mathcal{J}_n(\theta_0)^{-1} \mathbf{s}_n(\theta_0).$$

Essa expressão é uma aproximação local de primeira ordem. A obtenção de uma representação assintótica rigorosa exige controlar o termo restante da expansão e substituir a informação observada por um limite apropriado.

Essa relação mostra que o erro do estimador pode ser aproximado pelo produto entre:

- a inversa da curvatura da log-verossimilhança;
- o escore calculado no parâmetro verdadeiro.

A obtenção de uma distribuição assintótica exige resultados probabilísticos adicionais sobre consistência, convergência da informação e distribuição limite do escore.

7.12.6 Método delta

O método delta utiliza a aproximação de Taylor para obter a distribuição aproximada de uma transformação de um estimador.

Teorema 7.12 (Método delta multivariado). *Suponha que*

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N_k(\mathbf{0}, \Xi),$$

em que

$$\Xi \in \mathbb{R}^{k \times k}.$$

Considere uma função

$$\mathbf{g} : \mathbb{R}^k \longrightarrow \mathbb{R}^q$$

diferenciável no ponto

$$\theta.$$

Então,

$$\sqrt{n}[\mathbf{g}(\hat{\theta}) - \mathbf{g}(\theta)] \xrightarrow{d} N_q(\mathbf{0}, \mathbf{J}_{\mathbf{g}}(\theta)\Xi\mathbf{J}_{\mathbf{g}}(\theta)^\top).$$

(Vaart, 1998)

A demonstração formal utiliza a aproximação de Taylor de primeira ordem juntamente com resultados probabilísticos sobre convergência em distribuição. Esses resultados serão desenvolvidos no módulo inferencial; neste capítulo interessa principalmente a origem diferencial da matriz

$$\mathbf{J}_{\mathbf{g}}(\theta)\Xi\mathbf{J}_{\mathbf{g}}(\theta)^\top.$$

A aproximação de primeira ordem é

$$\mathbf{g}(\hat{\theta}) - \mathbf{g}(\theta) \approx \mathbf{J}_{\mathbf{g}}(\theta)(\hat{\theta} - \theta).$$

A matriz

$$\mathbf{V}_{\mathbf{g}} = \mathbf{J}_{\mathbf{g}}(\theta) \Xi \mathbf{J}_{\mathbf{g}}(\theta)^{\top}$$

é a matriz de covariâncias da distribuição limite de

$$\sqrt{n} \left[\mathbf{g}(\hat{\theta}) - \mathbf{g}(\theta) \right].$$

Por isso, denomina-se

$$\frac{1}{n} \mathbf{V}_{\mathbf{g}}$$

matriz de covariâncias assintótica de

$$\mathbf{g}(\hat{\theta}).$$

Em aplicações, é comum utilizá-la como aproximação da matriz de covariâncias do estimador para amostras grandes. A convergência em distribuição, isoladamente, não garante convergência dos segundos momentos; essa interpretação requer condições adicionais de regularidade.

Para uma função escalar

$$g : \mathbb{R}^k \longrightarrow \mathbb{R},$$

a variância assintótica é

$$\frac{1}{n} \nabla_{\theta} g(\theta)^{\top} \Xi \nabla_{\theta} g(\theta).$$

Exemplo 7.24 (Método delta para uma razão). Considere

$$\theta = \begin{bmatrix} \theta_1 \\ \theta_2 \end{bmatrix}, \quad \theta_2 \neq 0,$$

e

$$g(\theta) = \frac{\theta_1}{\theta_2}.$$

O gradiente é

$$\nabla_{\theta} g = \begin{bmatrix} \frac{1}{\theta_2} \\ \frac{\theta_2}{\theta_1} \\ -\frac{1}{\theta_2^2} \end{bmatrix}.$$

Se

$$\sqrt{n} \left(\hat{\theta} - \theta \right) \xrightarrow{d} N_2 \left(\mathbf{0}, \Xi \right),$$

então

$$\sqrt{n} \left(\frac{\hat{\theta}_1}{\hat{\theta}_2} - \frac{\theta_1}{\theta_2} \right)$$

converge em distribuição para uma normal com variância assintótica

$$\nabla_{\theta} g(\theta)^{\top} \Xi \nabla_{\theta} g(\theta).$$

Exemplo 7.25 (Estimação de um vetor de médias). Considere observações

$$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^p$$

e uma matriz positiva definida conhecida

$$\Sigma.$$

Considere o critério

$$Q(\mu) = \sum_{i=1}^n (\mathbf{x}_i - \mu)^{\top} \Sigma^{-1} (\mathbf{x}_i - \mu).$$

O gradiente é

$$\nabla_{\mu} Q = -2\Sigma^{-1} \sum_{i=1}^n (\mathbf{x}_i - \mu).$$

A condição de primeira ordem é

$$\sum_{i=1}^n (\mathbf{x}_i - \mu) = \mathbf{0}.$$

Logo,

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i.$$

A Hessiana é

$$\nabla_{\mu}^2 Q = 2n\Sigma^{-1} \succ \mathbf{0}.$$

Portanto, o vetor de médias amostrais é o único minimizador do critério.

Exemplo 7.26 (Critério do modelo linear multivariado). Considere

$$\mathbf{Y} = \mathbf{XB} + \mathcal{E},$$

com

$$\mathbf{Y} \in \mathbb{R}^{n \times p}, \quad \mathbf{X} \in \mathbb{R}^{n \times k}, \quad \mathbf{B} \in \mathbb{R}^{k \times p}.$$

Para

$$\Sigma \succ \mathbf{0},$$

considere o critério

$$\begin{aligned} Q(\mathbf{B}, \Sigma) &= \frac{n}{2} \log \det(\Sigma) \\ &\quad + \frac{1}{2} \operatorname{tr} \left[\Sigma^{-1} (\mathbf{Y} - \mathbf{XB})^{\top} (\mathbf{Y} - \mathbf{XB}) \right]. \end{aligned}$$

Para Σ fixada,

$$\nabla_{\mathbf{B}} Q = -\mathbf{X}^{\top} (\mathbf{Y} - \mathbf{XB}) \Sigma^{-1}.$$

A condição de primeira ordem é

$$\mathbf{X}^\top (\mathbf{Y} - \mathbf{XB}) = \mathbf{0}.$$

Se $\mathbf{X}$ possui posto coluna completo,

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

Observe que, para Σ fixa e positiva definida, o minimizador em relação a $\mathbf{B}$ não depende de Σ . Isso decorre do fato de que Σ^{-1} é invertível e desaparece da condição de primeira ordem.

Defina a matriz de Gram dos resíduos

$$\mathbf{G}_\varepsilon = (\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}})^\top (\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}}).$$

Para $\mathbf{B} = \widehat{\mathbf{B}}$, o critério em relação a Σ é

$$Q(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{G}_\varepsilon).$$

Se

$$\mathbf{G}_\varepsilon \succ \mathbf{0},$$

o minimizador interior é

$$\widehat{\Sigma} = \frac{1}{n} \mathbf{G}_\varepsilon.$$

A condição

$$\mathbf{G}_\varepsilon \succ \mathbf{0}$$

exige que a matriz residual possua posto coluna completo.

Se $\mathbf{X}$ possui posto coluna completo k , a matriz residual pode ser escrita como

$$\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}} = (\mathbf{I}_n - \mathbf{P}_\mathbf{X}) \mathbf{Y},$$

em que

$$\text{posto}(\mathbf{I}_n - \mathbf{P}_\mathbf{X}) = n - k.$$

Consequentemente,

$$\text{posto}(\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}}) \leq \min(p, n - k).$$

Assim, uma condição necessária para

$$\mathbf{G}_{\mathcal{E}} \succ \mathbf{0}$$

é

$$n - k \geq p.$$

Quando $\mathbf{G}_{\mathcal{E}}$ é singular, o critério é ilimitado inferiormente no cone das matrizes positivas definidas. Em particular, pode-se fazer um autovalor de Σ tender a zero em uma direção pertencente ao núcleo de $\mathbf{G}_{\mathcal{E}}$ sem produzir aumento compensatório no termo de traço.

Aqui o modelo foi utilizado apenas como uma aplicação conjunta de gradientes matriciais, log-determinante e diferenciação de funções envolvendo matrizes inversas.

A interpretação probabilística do critério, as propriedades dos estimadores, suas distribuições e a formulação de hipóteses serão desenvolvidas posteriormente nos capítulos de estimação, modelo linear multivariado e inferência.

O bloco de aprofundamento mostrou como as ferramentas de cálculo deste capítulo aparecem em problemas de estimação e inferência:

Tabela 7.2: Relações entre as ferramentas de cálculo e suas aplicações estatísticas.

Ferramenta matemática	Aplicação estatística
Gradiente	Vetor escore
Hessiana	Informação observada
Esperança da curvatura	Informação de Fisher
Expansão de Taylor	Aproximações locais e método delta
Cálculo matricial	Estimação de parâmetros vetoriais e matriciais

Essas relações devem ser entendidas neste capítulo como aplicações das ferramentas matemáticas. Sua interpretação estatística completa será retomada no Módulo II.

7.13 Síntese do capítulo

O capítulo reuniu as ferramentas de cálculo necessárias para estudar funções de vetores e matrizes e para formular problemas posteriores da Estatística Multivariada.

No cálculo diferencial, o gradiente representa a variação de primeira ordem de uma função escalar, a Jacobiana representa a transformação linear local de uma função vetorial e a Hessiana descreve sua curvatura. Essas estruturas sustentam aproximações de Taylor e condições de otimalidade.

A otimização utiliza essas derivadas de formas diferentes. Em problemas sem restrições, pontos estacionários e a definitude da Hessiana permitem caracterizar soluções locais, enquanto a convexidade fornece resultados globais. Em problemas com restrições de igualdade, os multiplicadores de Lagrange incorporam a geometria do conjunto viável. As funções de resíduos mostram como essas ferramentas conduzem às equações normais e aos problemas de mínimos quadrados.

No cálculo matricial, os diferenciais e as identidades de traço permitem trabalhar diretamente com parâmetros matriciais. Derivadas de inversas, determinantes e log-determinantes serão utilizadas em critérios que envolvem matrizes de covariâncias. A vetorização e o produto de Kronecker fornecem uma representação vetorial para transformações entre matrizes.

O cálculo integral completa essa estrutura ao permitir a obtenção de probabilidades, expectativas e densidades marginais. O Teorema da Mudança de Variáveis mostra como o determinante Jacobiano modifica elementos de volume e densidades sob transformações. Transformações afins e elipsoidais conectam essa ideia às formas quadráticas e às matrizes positivas definidas.

As principais relações estabelecidas no capítulo podem ser resumidas da seguinte forma:

Tabela 7.3: Relações entre as ferramentas do cálculo e seus usos posteriores.

Estrutura matemática	Papel nos capítulos seguintes
Derivadas	Aproximação local e otimização
Diferenciais matriciais	Manipulação e estimação de parâmetros matriciais
Integração e Jacobianos	Construção e transformação de distribuições multivariadas

A Tabela 7.4 reúne algumas das identidades de uso recorrente.

Tabela 7.4: Identidades selecionadas de cálculo vetorial e matricial.

Função ou transformação	Derivada ou diferencial
$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x}$	$\nabla_{\mathbf{x}} f = \mathbf{a}$
$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$	$\nabla_{\mathbf{x}} f = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}$
$f(\mathbf{x}) = \ \mathbf{b} - \mathbf{A} \mathbf{x}\ ^2$	$\nabla_{\mathbf{x}} f = -2\mathbf{A}^\top (\mathbf{b} - \mathbf{A} \mathbf{x})$
$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X})$	$\nabla_{\mathbf{X}} \phi = \mathbf{A}$
$\phi(\mathbf{X}) = \ \mathbf{X}\ _F^2$	$\nabla_{\mathbf{X}} \phi = 2\mathbf{X}$
$\mathbf{X} \mapsto \mathbf{X}^{-1}$	$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}(d\mathbf{X})\mathbf{X}^{-1}$
$\phi(\mathbf{X}) = \log \det(\mathbf{X}), \mathbf{X} \succ \mathbf{0}$	$d\phi = \text{tr}(\mathbf{X}^{-1} d\mathbf{X})$
$\mathbf{Y} = \mathbf{A} \mathbf{X} \mathbf{\Gamma}$	$\text{vec}(\mathbf{Y}) = (\mathbf{\Gamma}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X})$

Os blocos de aprofundamento desenvolveram ferramentas que não são necessárias para uma primeira leitura do capítulo, entre elas derivadas vetorizadas e parametrização de matrizes simétricas, diferenciação sob o sinal de integração e aplicações do cálculo à estimação e à inferência. Esses resultados poderão ser retomados quando forem necessários nos capítulos posteriores.

Ao final deste capítulo, o estudante deverá ser capaz de:

- distinguir gradiente, Jacobiana, Hessiana e gradiente matricial;
- interpretar derivadas como aproximações locais;
- utilizar Taylor e a Hessiana em problemas de otimização;
- formular condições de primeira ordem com e sem restrições;
- derivar critérios quadráticos e equações normais;
- utilizar diferenciais e identidades de traço em funções matriciais;
- diferenciar expressões envolvendo inversas, determinantes e log-determinantes;
- utilizar vec, produto de Kronecker e sua identidade de vetorização;
- calcular probabilidades, expectativas e densidades marginais por integração;
- aplicar mudanças de variáveis e interpretar o determinante Jacobiano.

O Capítulo 7 encerra o **Módulo I — Fundamentos Matemáticos e Geométricos da Análise Multivariada**.

Antes do início do Módulo II, os **Exercícios de fixação do Módulo I** retomam de forma integrada os principais conceitos desenvolvidos ao longo dos sete capítulos. Os exercícios articulam representação matricial dos dados, projeções, transformações lineares, formas quadráticas, autovalores e autovetores, SVD, pseudoinversa e cálculo vetorial e matricial em problemas que serão utilizados posteriormente na Estatística Multivariada.

O capítulo seguinte inicia o **Módulo II — Fundamentos Probabilísticos e Inferenciais da Análise Multivariada** com o estudo das matrizes de covariâncias e correlações. Gradientes, formas quadráticas, transformações lineares, integrais, projeções e produtos matriciais

forneirão as ferramentas matemáticas para descrever a variabilidade conjunta de vetores aleatórios e sustentar os desenvolvimentos probabilísticos e inferenciais posteriores.

Exercícios de fixação do Módulo I

Os exercícios deste módulo retomam os fundamentos matemáticos desenvolvidos nos capítulos anteriores e os utilizam em problemas que reaparecerão ao longo da Estatística Multivariada.

A lista está dividida em duas partes. Na primeira, os cálculos devem ser realizados sem auxílio computacional. As matrizes foram escolhidas para permitir resultados exatos e enfatizar as relações entre álgebra, geometria e cálculo.

Na segunda parte, o R ou Python será utilizado para estender essas mesmas ideias a conjuntos de dados de maior dimensão. O objetivo não é substituir os cálculos matriciais por funções prontas, mas utilizá-los para analisar matrizes de dados reais e verificar computacionalmente propriedades estudadas no Módulo I.

Parte I — Exercícios sem uso de computador

Exercício 7.1 (Transformação de variáveis em uma matriz de dados). Considere a matriz de dados

$$\mathbf{X} = \begin{bmatrix} 2 & 1 & 0 \\ 1 & 3 & 1 \\ 0 & 2 & 2 \\ 3 & 0 & 1 \end{bmatrix},$$

em que as linhas representam quatro observações e as colunas representam três variáveis.

Considere também a transformação

$$\mathbf{A} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & -1 \end{bmatrix}.$$

1. Escreva, para uma observação genérica

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix},$$

as duas componentes de

$$\mathbf{y} = \mathbf{A}\mathbf{x}.$$

2. Interprete cada nova componente como uma combinação linear das variáveis originais.
3. Determine a matriz de dados transformada utilizando

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top.$$

4. Indique as dimensões de $\mathbf{X}$, $\mathbf{A}$ e $\mathbf{Y}$ e explique por que a transformação reduziu o número de variáveis de três para duas.
5. Determine o posto de $\mathbf{A}$.
6. Determine a dimensão de $\mathcal{N}(\mathbf{A})$ e explique o significado desse resultado em termos de perda de informação.
7. Sabendo apenas $\mathbf{y} = \mathbf{A}\mathbf{x}$, discuta se é possível recuperar unicamente o vetor original $\mathbf{x}$.

Exercício 7.2 (Centralização como projeção). Considere $n = 4$ e defina

$$\mathbf{H}_4 = \mathbf{I}_4 - \frac{1}{4}\mathbf{1}_4\mathbf{1}_4^\top.$$

1. Escreva explicitamente a matriz $\mathbf{H}_4$.
2. Verifique que

$$\mathbf{H}_4^\top = \mathbf{H}_4$$

e

$$\mathbf{H}_4^2 = \mathbf{H}_4.$$

3. Mostre que

$$\mathbf{H}_4\mathbf{1}_4 = \mathbf{0}.$$

4. Aplique $\mathbf{H}_4$ à matriz $\mathbf{X}$ do Exercício 7.1:

$$\mathbf{X}_c = \mathbf{H}_4\mathbf{X}.$$

- Verifique diretamente que

$$\mathbf{1}_4^\top \mathbf{X}_c = \mathbf{0}^\top.$$

- Interprete a igualdade anterior em termos das médias das variáveis.

Exercício 7.3 (Centralização e reescalonamento das variáveis). Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times 3}$$

e a matriz diagonal

$$\mathbf{D} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 4 \end{bmatrix}.$$

- Determine $\mathbf{D}^{-1}$.
- Considere inicialmente uma matriz já centralizada $\mathbf{X}_c$ e defina

$$\mathbf{Z} = \mathbf{X}_c \mathbf{D}^{-1}.$$

Explique o efeito dessa transformação sobre cada uma das três variáveis.

- Explique por que $\mathbf{D}^{-1}$ atua à direita da matriz de dados.
- Compare essa operação com a centralização

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X},$$

explicando por que $\mathbf{H}_n$ atua à esquerda enquanto $\mathbf{D}^{-1}$ atua à direita.

- Escreva, em uma única expressão, a transformação que primeiro centraliza $\mathbf{X}$ e depois reescala suas variáveis.
- A centralização e o reescalonamento atuam no mesmo espaço? Justifique utilizando as dimensões de $\mathbf{H}_n$ e $\mathbf{D}^{-1}$.

Exercício 7.4 (Duas matrizes de Gram para os mesmos dados). Considere a matriz centralizada

$$\mathbf{X}_c = \begin{bmatrix} 1 & 0 \\ -1 & 0 \\ 0 & 2 \\ 0 & -2 \end{bmatrix}.$$

1. Calcule

$$\mathbf{G}_V = \mathbf{X}_c^\top \mathbf{X}_c$$

e

$$\mathbf{G}_O = \mathbf{X}_c \mathbf{X}_c^\top.$$

2. Indique as dimensões das duas matrizes.
3. Qual das duas matrizes contém os produtos internos entre as colunas de $\mathbf{X}_c$?
4. Qual contém os produtos internos entre as linhas de $\mathbf{X}_c$?
5. Determine o posto das duas matrizes.
6. Determine os autovalores positivos de cada matriz.
7. Verifique que os autovalores positivos coincidem.
8. Relacione esse resultado à construção da SVD de uma matriz retangular.

Exercício 7.5 (Projeção, ajuste e resíduos). Considere

$$\mathbf{X} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}.$$

1. Verifique que as colunas de $\mathbf{X}$ são linearmente independentes.
2. Determine

$$\mathbf{P}_X = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top.$$

3. Verifique que

$$\mathbf{P}_X^\top = \mathbf{P}_X$$

e

$$\mathbf{P}_X^2 = \mathbf{P}_X.$$

4. Calcule

$$\hat{\mathbf{y}} = \mathbf{P}_X \mathbf{y}.$$

5. Determine o vetor de resíduos

$$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}.$$

6. Verifique que

$$\mathbf{X}^\top \mathbf{e} = \mathbf{0}.$$

7. Identifique o subespaço ao qual pertence $\hat{\mathbf{y}}$.

8. Identifique o subespaço ao qual pertence $\mathbf{e}$.

9. Interprete geometricamente a decomposição

$$\mathbf{y} = \hat{\mathbf{y}} + \mathbf{e}.$$

Exercício 7.6 (Um problema de mínimos quadrados por três perspectivas). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 0 \\ 0 & 2 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix}.$$

O objetivo é determinar o vetor que minimiza

$$\|\mathbf{b} - \mathbf{A}\mathbf{x}\|^2.$$

Resolva o problema das três formas seguintes.

1. Determine a projeção de $\mathbf{b}$ sobre $\mathcal{C}(\mathbf{A})$ e obtenha, a partir dela, o vetor ajustado.
2. Resolva as equações normais

$$\mathbf{A}^\top \mathbf{A} \mathbf{x} = \mathbf{A}^\top \mathbf{b}.$$

3. Calcule

$$\mathbf{A}^\top \mathbf{A}$$

e determine os valores singulares de $\mathbf{A}$.

4. Construa uma SVD compacta de $\mathbf{A}$.
5. Construa a pseudoinversa

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top$$

e obtenha

$$\mathbf{x}^* = \mathbf{A}^+ \mathbf{b}.$$

6. Compare as soluções obtidas pelas três abordagens.
7. Compare também os vetores ajustados e os resíduos.
8. Explique por que projeções, equações normais e pseudoinversa conduzem ao mesmo problema de aproximação.

Exercício 7.7 (Forma quadrática e direções privilegiadas). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$$

e

$$q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

1. Calcule $q(\mathbf{x})$ para

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{x}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}.$$

2. Determine os autovalores de $\mathbf{A}$.
3. Determine uma base ortonormal de autovetores.
4. Calcule a forma quadrática em cada autovetor unitário.
5. Determine

$$\max_{\|\mathbf{x}\|=1} q(\mathbf{x})$$

e

$$\min_{\|\mathbf{x}\|=1} q(\mathbf{x}).$$

6. Relacione os valores encontrados aos autovalores de $\mathbf{A}$.

Exercício 7.8 (Norma euclidiana e norma induzida). Considere

$$\mathbf{M} = \begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 0 \\ 2 \end{bmatrix}, \quad \mathbf{z} = \begin{bmatrix} 1 \\ 0 \end{bmatrix},$$

responda:

1. Calcule as normas euclidianas de $\mathbf{x}$, $\mathbf{y}$ e $\mathbf{z}$.
2. Calcule as normas induzidas por $\mathbf{M}$,

$$\|\mathbf{v}\|_{\mathbf{M}} = \sqrt{\mathbf{v}^{\top} \mathbf{M} \mathbf{v}}.$$

3. Calcule a distância euclidiana entre $\mathbf{x}$ e $\mathbf{y}$.
4. Calcule a distância induzida por $\mathbf{M}$ entre os mesmos vetores.
5. Qual coordenada recebe maior peso na geometria induzida por $\mathbf{M}$?
6. Explique por que duas geometrias diferentes podem produzir avaliações diferentes da proximidade entre observações.

Exercício 7.9 (Matrizes particionadas e complemento de Schur). Considere a matriz simétrica

$$\mathbf{M} = \begin{bmatrix} 4 & 2 & 1 \\ 2 & 3 & 1 \\ 1 & 1 & 2 \end{bmatrix}$$

particionada como

$$\mathbf{M} = \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{B}^\top & \mathbf{D} \end{bmatrix},$$

em que

$$\mathbf{A} = \begin{bmatrix} 4 & 2 \\ 2 & 3 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{D} = [2].$$

1. Verifique que $\mathbf{A}$ é invertível.
2. Determine $\mathbf{A}^{-1}$.
3. Calcule o complemento de Schur de $\mathbf{A}$ em $\mathbf{M}$,

$$\mathbf{S} = \mathbf{D} - \mathbf{B}^\top \mathbf{A}^{-1} \mathbf{B}.$$

4. Verifique que $\mathbf{S} > 0$.
5. Utilize a identidade por blocos

$$\det(\mathbf{M}) = \det(\mathbf{A}) \det(\mathbf{S})$$

para calcular $\det(\mathbf{M})$.

6. Confirme o resultado calculando diretamente o determinante de $\mathbf{M}$.

Exercício 7.10 (Direção que maximiza uma medida de dispersão). Considere

$$\mathbf{S} = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}.$$

Para um vetor unitário $\mathbf{a}$, defina

$$D(\mathbf{a}) = \mathbf{a}^\top \mathbf{S} \mathbf{a}.$$

1. Determine os autovalores de $\mathbf{S}$.
2. Determine uma base ortonormal de autovetores.
3. Resolva

$$\max_{\|\mathbf{a}\|=1} \mathbf{a}^\top \mathbf{S} \mathbf{a}.$$

4. Determine a direção que minimiza $D(\mathbf{a})$ sob a mesma restrição.
5. Calcule o valor da forma quadrática nas duas direções.
6. Se $\mathbf{S}$ representasse uma matriz de dispersão de duas variáveis, interprete a direção associada ao maior autovalor.
7. Interprete também a direção associada ao menor autovalor.

Exercício 7.11 (Maximização de uma razão entre duas formas quadráticas). Considere

$$\mathbf{A} = \begin{bmatrix} 12 & 2 \\ 2 & 3 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix}.$$

Resolva

$$\max_{\mathbf{x} \neq \mathbf{0}} \frac{\mathbf{x}^\top \mathbf{A} \mathbf{x}}{\mathbf{x}^\top \mathbf{B} \mathbf{x}}.$$

1. Mostre, por multiplicadores de Lagrange ou pelo quociente de Rayleigh generalizado, que as direções candidatas satisfazem

$$\mathbf{A}\mathbf{x} = \lambda\mathbf{B}\mathbf{x}.$$

2. Determine os autovalores generalizados.
3. Determine um autovetor associado a cada autovalor generalizado.
4. Normalize os autovetores segundo a geometria de $\mathbf{B}$, impondo

$$\mathbf{x}^\top \mathbf{B}\mathbf{x} = 1.$$

5. Determine o valor máximo do quociente.
6. Determine também o valor mínimo.
7. Verifique que os dois autovetores podem ser escolhidos de modo que

$$\mathbf{x}_1^\top \mathbf{B}\mathbf{x}_2 = 0.$$

8. Compare essa ortogonalidade com a ortogonalidade euclidiana usual.

Exercício 7.12 (Transformação de um problema generalizado). Utilize as matrizes $\mathbf{A}$ e $\mathbf{B}$ do Exercício 7.11.

1. Determine a raiz quadrada principal

$$\mathbf{B}^{1/2}$$

e sua inversa

$$\mathbf{B}^{-1/2}.$$

2. Construa

$$\mathbf{C} = \mathbf{B}^{-1/2}\mathbf{A}\mathbf{B}^{-1/2}.$$

3. Verifique que

$$\mathbf{C} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

4. Determine os autovalores de $\mathbf{C}$.
5. Compare-os com os autovalores generalizados obtidos no exercício anterior.
6. Considere a transformação

$$\mathbf{z} = \mathbf{B}^{1/2} \mathbf{x}.$$

Mostre que

$$\mathbf{x}^\top \mathbf{B} \mathbf{x} = \mathbf{z}^\top \mathbf{z}.$$

7. Mostre que

$$\frac{\mathbf{x}^\top \mathbf{A} \mathbf{x}}{\mathbf{x}^\top \mathbf{B} \mathbf{x}} = \frac{\mathbf{z}^\top \mathbf{C} \mathbf{z}}{\mathbf{z}^\top \mathbf{z}}.$$

8. Explique por que a transformação converte um problema em geometria induzida por $\mathbf{B}$ em um problema espectral euclidiano.

Exercício 7.13 (Construção da SVD de uma matriz retangular). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 2 \\ 1 & 0 \end{bmatrix}.$$

1. Calcule

$$\mathbf{A}^\top \mathbf{A}.$$

2. Determine os autovalores de $\mathbf{A}^\top \mathbf{A}$.
3. Determine os valores singulares positivos de $\mathbf{A}$ em ordem decrescente.
4. Determine os vetores singulares à direita correspondentes.
5. Utilize

$$\mathbf{u}_j = \frac{\mathbf{A} \mathbf{v}_j}{d_j}$$

para construir os vetores singulares à esquerda.

6. Verifique que os vetores obtidos são ortonormais.

7. Construa

$$\mathbf{U}_r, \quad \mathbf{D}_r, \quad \mathbf{V}_r.$$

8. Verifique diretamente que

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

9. Identifique uma base ortonormal para $\mathcal{C}(\mathbf{A})$.

10. Identifique uma base ortonormal para $\mathcal{C}(\mathbf{A}^\top)$.

Exercício 7.14 (Aproximação de posto reduzido). Utilize a matriz e a SVD do Exercício [7.13](#).

1. Escreva

$$\mathbf{A} = d_1 \mathbf{u}_1 \mathbf{v}_1^\top + d_2 \mathbf{u}_2 \mathbf{v}_2^\top.$$

2. Construa a aproximação de posto 1

$$\mathbf{A}_1 = d_1 \mathbf{u}_1 \mathbf{v}_1^\top.$$

3. Determine explicitamente

$$\mathbf{A} - \mathbf{A}_1.$$

4. Calcule

$$\|\mathbf{A} - \mathbf{A}_1\|_F.$$

5. Verifique que, neste caso,

$$\|\mathbf{A} - \mathbf{A}_1\|_F = d_2.$$

6. Calcule

$$\|\mathbf{A}\|_F^2.$$

7. Verifique que

$$\|\mathbf{A}\|_F^2 = d_1^2 + d_2^2.$$

8. Calcule

$$\frac{d_1^2}{d_1^2 + d_2^2}.$$

9. Interprete essa razão como a parcela da magnitude quadrática da matriz preservada pela aproximação de posto 1.

Exercício 7.15 (Gradiente e Hessiana de um critério de mínimos quadrados). Considere

$$Q(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|^2.$$

1. Desenvolva $Q(\beta)$ como uma expressão quadrática em β .
2. Obtenha

$$\nabla_{\beta} Q(\beta).$$

3. Obtenha

$$\nabla_{\beta}^2 Q(\beta).$$

4. Mostre que, se $\mathbf{X}$ possui posto completo de colunas,

$$\mathbf{X}^{\top} \mathbf{X} \succ \mathbf{0}.$$

5. Conclua que a Hessiana é positiva definida.
6. Mostre que o ponto estacionário é o único minimizador global.
7. Aplique o resultado a

$$\mathbf{X} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix},$$

determinando $\hat{\beta}$ exatamente.

8. Compare a solução com aquela obtida geometricamente no Exercício 7.5.

Exercício 7.16 (Multiplicadores de Lagrange e autovalores). Considere uma matriz real simétrica $\mathbf{A}$ e o problema

$$\max_{\mathbf{x}} \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

sujeito a

$$\mathbf{x}^\top \mathbf{x} = 1.$$

1. Construa a função lagrangiana.
2. Diferencie-a em relação a $\mathbf{x}$.
3. Diferencie-a em relação ao multiplicador de Lagrange.
4. Mostre que as condições de primeira ordem conduzem a uma equação da forma

$$\mathbf{A} \mathbf{x} = \lambda \mathbf{x}.$$

5. Explique por que o problema de otimização se transforma em um problema de autovalores.
6. Resolva completamente o problema para

$$\mathbf{A} = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}.$$

7. Determine também o mínimo sob a mesma restrição.
8. Compare os resultados com os obtidos no Exercício 7.10.

Exercício 7.17 (Vetorização e produto de Kronecker). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{X} = \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}.$$

Adote a convenção de que $\text{vec}(\mathbf{X})$ empilha as colunas de $\mathbf{X}$.

1. Calcule diretamente

$$\mathbf{Y} = \mathbf{A} \mathbf{X} \mathbf{B}.$$

2. Determine

$$\text{vec}(\mathbf{X})$$

e

$$\text{vec}(\mathbf{Y}).$$

3. Construa

$$\mathbf{B}^\top \otimes \mathbf{A}.$$

4. Calcule

$$(\mathbf{B}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

5. Verifique a identidade

$$\text{vec}(\mathbf{AXB}) = (\mathbf{B}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

6. Compare as dimensões da transformação matricial com as dimensões de sua representação vetorizada.

Exercício 7.18 (Diferenciação de um critério matricial). Considere, para

$$\Sigma \succ \mathbf{0},$$

a função

$$Q(\Sigma) = 2 \log \det(\Sigma) + \text{tr}(\mathbf{G}\Sigma^{-1}),$$

em que

$$\mathbf{G} = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}.$$

1. Utilize diferenciais para obter

$$dQ.$$

2. Mostre que um ponto estacionário deve satisfazer

$$2\Sigma^{-1} - \Sigma^{-1}\mathbf{G}\Sigma^{-1} = \mathbf{0}.$$

3. Resolva essa equação para Σ .
4. Verifique que a matriz obtida é positiva definida.

Exercício 7.19 (Transformação afim, Jacobiana e alteração de área). Considere

$$\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b},$$

com

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

1. Calcule $\det(\mathbf{A})$ e mostre que a transformação é invertível.
2. Determine $\mathbf{A}^{-1}$.
3. Escreva a transformação inversa

$$\mathbf{x} = \mathbf{A}^{-1}(\mathbf{y} - \mathbf{b}).$$

4. Determine a matriz Jacobiana da transformação de $\mathbf{x}$ para $\mathbf{y}$.
5. Determine o determinante Jacobiano.
6. Considere a região

$$0 \leq x_1 \leq 1, \quad 0 \leq x_2 \leq 1.$$

Determine as imagens de seus quatro vértices.

7. Descreva geometricamente a região transformada.
8. Determine sua área.
9. Compare a razão entre a área transformada e a área original com

$$|\det(\mathbf{A})|.$$

Exercício 7.20 (Integração e obtenção de densidades marginais). Considere a função conjunta

$$f(x, y) = 2,$$

para

$$0 < x < y < 1,$$

e

$$f(x, y) = 0$$

fora dessa região.

1. Represente geometricamente a região em que $f(x, y) > 0$.
2. Verifique que

$$\int_0^1 \int_0^y 2 \, dx \, dy = 1.$$

3. Obtenha a função marginal de X integrando em relação a y .
4. Obtenha a função marginal de Y integrando em relação a x .
5. Verifique que cada função marginal integra 1 em seu respectivo domínio.
6. Calcule $E(X)$.
7. Calcule $E(Y)$.
8. Explique por que os limites de integração dependem da geometria da região de suporte.

Parte II — Exercícios com uso do R

Nesta parte, utilize preferencialmente operações matriciais do R. Quando uma função pronta reproduzir diretamente um resultado estudado no Módulo I, utilize-a apenas depois da construção matricial, como forma de conferência.

Em comparações envolvendo posto, autovalores teoricamente nulos ou valores singulares numericamente nulos, considere a possibilidade de pequenos erros de arredondamento computacional e utilize uma tolerância numérica adequada.

Exercício 7.21 (Centralização matricial dos dados `USArrests`). Considere as quatro variáveis quantitativas do conjunto de dados `USArrests`.

1. Armazene a matriz de dados em um objeto $\mathbf{X}$.
2. Determine n e p a partir da própria matriz.
3. Construa explicitamente

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

4. Obtenha

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}.$$

5. Verifique numericamente que as médias das colunas de $\mathbf{X}_c$ são zero, admitindo apenas diferenças de arredondamento.
6. Verifique numericamente que

$$\mathbf{H}_n^\top = \mathbf{H}_n$$

e

$$\mathbf{H}_n^2 = \mathbf{H}_n.$$

7. Determine o posto numérico de $\mathbf{H}_n$.
8. Verifique que

$$\mathbf{H}_n \mathbf{1}_n \approx \mathbf{0}.$$

9. Somente ao final, compare $\mathbf{X}_c$ com o resultado produzido por

```
scale(X, center = TRUE, scale = FALSE)
```

10. Explique geometricamente o papel de $\mathbf{H}_n$.

Exercício 7.22 (Matrizes de Gram e seus espectros). Utilize a matriz centralizada $\mathbf{X}_c$ obtida no Exercício 7.21.

1. Calcule

$$\mathbf{G}_V = \mathbf{X}_c^\top \mathbf{X}_c$$

e

$$\mathbf{G}_O = \mathbf{X}_c \mathbf{X}_c^\top.$$

2. Compare as dimensões das duas matrizes.
3. Determine seus postos numéricos.
4. Calcule os autovalores de ambas.
5. Para identificar os autovalores numericamente positivos, utilize uma tolerância relativa, por exemplo,

$$\lambda_j > 10^{-10} \lambda_{\max}.$$

6. Compare os autovalores positivos de $\mathbf{G}_V$ e $\mathbf{G}_O$.
7. Explique por que uma matriz 4×4 e uma matriz 50×50 contêm o mesmo espectro não nulo.
8. Relacione os resultados aos valores singulares de $\mathbf{X}_c$.

Exercício 7.23 (Construção de novas variáveis por transformação linear). Considere apenas as quatro variáveis quantitativas de `iris`, formando

$$\mathbf{X} \in \mathbb{R}^{150 \times 4}.$$

Defina

$$\mathbf{A} = \begin{bmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 1 & -1 & 0 & 0 \end{bmatrix}.$$

1. Obtenha

$$\mathbf{Y} = \mathbf{XA}^\top.$$

2. Escreva explicitamente cada uma das três novas variáveis como combinação das quatro variáveis originais.
3. Verifique as dimensões de $\mathbf{Y}$.
4. Determine o posto de $\mathbf{A}$.
5. Determine a dimensão de $\mathcal{N}(\mathbf{A})$.
6. Discuta se a transformação preserva toda a informação necessária para reconstruir as quatro variáveis originais.
7. Centralize $\mathbf{X}$.
8. Aplique a mesma transformação à matriz centralizada.
9. Verifique as médias das três variáveis transformadas após a centralização.
10. Explique por que uma transformação linear de dados centralizados continua produzindo variáveis com média amostral zero.

Exercício 7.24 (Busca da direção de maior dispersão). Utilize as variáveis quantitativas de `USArrests`.

1. Centralize a matriz de dados e denote o resultado por $\mathbf{X}_c$.
2. Construa

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c.$$

3. Obtenha os autovalores e autovetores de $\mathbf{S}$ utilizando `eigen()`.
4. Identifique a direção unitária $\mathbf{a}_1$ associada ao maior autovalor.
5. Calcule

$$\mathbf{a}_1^\top \mathbf{S} \mathbf{a}_1.$$

6. Compare o resultado com o maior autovalor de $\mathbf{S}$.
7. Gere um grande número de vetores aleatórios em $\mathbb{R}^4$ e normalize cada um para norma unitária.

8. Para cada vetor $\mathbf{a}$, calcule

$$\mathbf{a}^\top \mathbf{S} \mathbf{a}.$$

9. Compare o maior valor encontrado entre as direções aleatórias com o maior autovalor de $\mathbf{S}$.
10. Explique o que esse experimento numérico mostra sobre o quociente de Rayleigh.
11. Repita a análise após padronizar as quatro variáveis para variância unitária.
12. Compare a nova direção de máxima dispersão com aquela obtida utilizando as variáveis apenas centralizadas e discuta o efeito da mudança de escala.

Não utilize `prcomp()` neste exercício.

Exercício 7.25 (Projeção e reconstrução a partir de uma direção). Utilize $\mathbf{X}_c$ e a direção $\mathbf{a}_1$ obtidas no Exercício 7.24.

1. Calcule as coordenadas das observações na direção $\mathbf{a}_1$:

$$\mathbf{z}_1 = \mathbf{X}_c \mathbf{a}_1.$$

2. Verifique as dimensões de $\mathbf{z}_1$.
3. Reconstrua a parcela da matriz de dados associada a essa direção:

$$\widehat{\mathbf{X}}_1 = \mathbf{z}_1 \mathbf{a}_1^\top.$$

4. Verifique que $\widehat{\mathbf{X}}_1$ possui posto 1.
5. Calcule

$$\mathbf{E}_1 = \mathbf{X}_c - \widehat{\mathbf{X}}_1.$$

6. Calcule

$$\|\mathbf{X}_c\|_F^2, \quad \|\widehat{\mathbf{X}}_1\|_F^2, \quad \|\mathbf{E}_1\|_F^2.$$

7. Verifique numericamente que

$$\|\mathbf{X}_c\|_F^2 \approx \|\widehat{\mathbf{X}}_1\|_F^2 + \|\mathbf{E}_1\|_F^2.$$

8. Verifique também que

$$\langle \widehat{\mathbf{X}}_1, \mathbf{E}_1 \rangle_F \approx 0.$$

9. Interprete o que foi preservado e o que foi descartado pela projeção.

Exercício 7.26 (SVD e decomposição espectral da matriz de dados). Utilize a matriz centralizada de `USArrests`.

1. Calcule sua SVD utilizando `svd()`.
2. Extraia $\mathbf{U}$, os valores singulares e $\mathbf{V}$.
3. Construa explicitamente a matriz diagonal $\mathbf{D}$.
4. Verifique numericamente que

$$\mathbf{X}_c \approx \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

5. Verifique que

$$\mathbf{X}_c^\top \mathbf{X}_c \approx \mathbf{V}\mathbf{D}^2\mathbf{V}^\top.$$

6. Calcule

```
eigen(t(Xc) %*% Xc)
```

e compare os autovetores obtidos com os vetores singulares à direita.

7. Compare os autovalores de $\mathbf{X}_c^\top \mathbf{X}_c$ com os quadrados dos valores singulares.
8. Explique por que vetores produzidos por `eigen()` e `svd()` podem diferir apenas pelo sinal.
9. Relacione as colunas de $\mathbf{V}$ a direções no espaço das variáveis.

Exercício 7.27 (Aproximações de posto reduzido em uma matriz de dados). Utilize a SVD obtida no Exercício 7.26.

Para

$$k = 1, 2, 3,$$

construa

$$\mathbf{X}_{c,k} = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Para cada valor de k :

1. determine o posto numérico de $\mathbf{X}_{c,k}$;
2. calcule

$$\|\mathbf{X}_c - \mathbf{X}_{c,k}\|_F;$$

3. verifique numericamente que

$$\|\mathbf{X}_c - \mathbf{X}_{c,k}\|_F^2 \approx \sum_{j=k+1}^r d_j^2;$$

4. calcule

$$\frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2};$$

5. interprete essa quantidade em termos da magnitude quadrática preservada pela aproximação;
6. compare os erros para $k = 1$, $k = 2$ e $k = 3$;
7. explique por que o erro não pode aumentar quando k cresce.

Não utilize `prcomp()` para construir as aproximações.

Exercício 7.28 (Mínimos quadrados com duas variáveis respostas). Utilize o conjunto de dados `mtcars`.

Considere como respostas:

- `mpg`;
- `qsec`;

e como variáveis explicativas:

- `intercepto`;
- `wt`;
- `hp`.

Construa

$$\mathbf{Y} \in \mathbb{R}^{n \times 2}$$

e

$$\mathbf{X} \in \mathbb{R}^{n \times 3}.$$

1. Verifique as dimensões das duas matrizes.
2. Verifique que $\mathbf{X}$ possui posto completo de colunas.
3. Calcule

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

4. Determine as dimensões de $\widehat{\mathbf{B}}$.
5. Interprete suas duas colunas.
6. Calcule

$$\widehat{\mathbf{Y}} = \mathbf{X} \widehat{\mathbf{B}}$$

e

$$\mathbf{E} = \mathbf{Y} - \widehat{\mathbf{Y}}.$$

7. Verifique numericamente que

$$\mathbf{X}^\top \mathbf{E} \approx \mathbf{0}.$$

8. Ajuste separadamente, utilizando `lm()`, um modelo para `mpg` e outro para `qsec`.
9. Compare os coeficientes das duas regressões com as colunas de $\widehat{\mathbf{B}}$.

Exercício 7.29 (Posto deficiente e pseudoinversa). Utilize `mtcars` e considere `mpg` como vetor-resposta.

Construa uma matriz de delineamento cujas colunas sejam

$$\mathbf{1}, \quad \text{wt}, \quad 2 \text{ wt}.$$

1. Determine o posto da matriz de delineamento.
2. Compare o posto com o número de colunas.
3. Calcule seus valores singulares.
4. Identifique quais valores singulares devem ser considerados numericamente positivos utilizando uma tolerância adequada.
5. Tente utilizar diretamente

$$(\mathbf{X}^\top \mathbf{X})^{-1}$$

e explique o problema encontrado.

6. Construa manualmente a pseudoinversa de $\mathbf{X}$ a partir de sua SVD, invertendo apenas os valores singulares considerados positivos.
7. Obtenha

$$\hat{\beta}^+ = \mathbf{X}^+ \mathbf{y}.$$

8. Calcule

$$\hat{\mathbf{y}} = \mathbf{X} \hat{\beta}^+.$$

9. Determine um vetor não nulo

$$\mathbf{h} \in \mathcal{N}(\mathbf{X}).$$

10. Para diferentes valores de γ , construa

$$\hat{\beta}(\gamma) = \hat{\beta}^+ + \gamma \mathbf{h}.$$

11. Verifique que todos esses vetores produzem o mesmo vetor ajustado.
12. Compare numericamente

$$\|\hat{\beta}(\gamma)\|$$

para vários valores positivos e negativos de γ .

13. Verifique que a solução fornecida pela pseudoinversa possui a menor norma euclidiana.

14. Relacione a não unicidade dos coeficientes ao núcleo de $\mathbf{X}$.

Exercício 7.30 (Vetorização de um modelo com várias respostas). Retome as matrizes $\mathbf{X}$, $\mathbf{Y}$ e $\widehat{\mathbf{B}}$ do Exercício 7.28.

A relação matricial é

$$\widehat{\mathbf{Y}} = \mathbf{X}\widehat{\mathbf{B}}.$$

1. Construa em R

$$\text{vec}(\widehat{\mathbf{Y}})$$

empilhando as colunas.

2. Construa

$$\text{vec}(\widehat{\mathbf{B}}).$$

3. Construa

$$\mathbf{I}_2 \otimes \mathbf{X}.$$

4. Verifique suas dimensões.

5. Verifique numericamente que

$$\text{vec}(\widehat{\mathbf{Y}}) = (\mathbf{I}_2 \otimes \mathbf{X}) \text{vec}(\widehat{\mathbf{B}}).$$

6. Compare as dimensões dos dois lados da igualdade.

Parte II

Módulo II — Fundamentos Probabilísticos e Inferenciais da Análise Multivariada

8 Matrizes de covariâncias e correlações

A variância descreve a dispersão de uma variável em torno de sua média. Quando várias variáveis são observadas conjuntamente, também é necessário representar como suas variações se relacionam. A análise separada das variâncias não registra se duas componentes tendem a variar no mesmo sentido, em sentidos opostos ou se apresentam relações lineares de redundância.

A matriz de covariâncias reúne as variâncias individuais e as covariâncias entre todos os pares de componentes de um vetor aleatório. Sua estrutura permite calcular a variância de combinações lineares, caracterizar relações lineares entre as componentes e representar geometricamente a dispersão conjunta (Johnson; Wichern, 2007).

A matriz de correlações resulta da padronização das covariâncias pelos desvios-padrão das variáveis. Seus elementos são adimensionais e permitem comparar a intensidade e o sentido das associações lineares entre variáveis medidas em diferentes unidades.

O objetivo deste capítulo é desenvolver essas estruturas nos níveis populacional e descritivo dos dados observados. As propriedades inferenciais das estatísticas amostrais serão estudadas no Capítulo 10. A distribuição normal multivariada, apresentada no próximo capítulo, utilizará a matriz de covariâncias para construir um modelo probabilístico para a variabilidade conjunta.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{X} \in \mathbb{R}^p$ representa um vetor aleatório e $\mathbf{x} \in \mathbb{R}^p$ uma de suas realizações;
- $\boldsymbol{\mu} \in \mathbb{R}^p$ representa o vetor de médias populacional;
- $\boldsymbol{\Sigma} \in \mathbb{R}^{p \times p}$ representa a matriz de covariâncias populacional;
- $\mathcal{R} \in \mathbb{R}^{p \times p}$ representa a matriz de correlações populacional;
- $\boldsymbol{\Sigma}_{XY} \in \mathbb{R}^{p \times q}$ representa a matriz de covariâncias cruzadas entre os vetores aleatórios $\mathbf{X} \in \mathbb{R}^p$ e $\mathbf{Y} \in \mathbb{R}^q$;
- $\mathbf{D}_{\boldsymbol{\Sigma}} = \text{diag}(\sigma_{11}, \dots, \sigma_{pp})$ representa a matriz diagonal das variâncias populacionais;
- $\mathbf{X} \in \mathbb{R}^{n \times p}$ representa uma matriz de dados observada, com observações nas linhas e variáveis nas colunas;
- $\bar{\mathbf{x}} \in \mathbb{R}^p$ representa o vetor de médias calculado a partir dos dados observados;
- $\mathbf{H}_n = \mathbf{I}_n - n^{-1} \mathbf{1}_n \mathbf{1}_n^\top$ representa a matriz de centralização;
- $\mathbf{X}_c = \mathbf{H}_n \mathbf{X}$ representa a matriz de dados centralizada;

- $\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c$ representa a matriz total de somas de quadrados e produtos cruzados;
- $\mathbf{S} \in \mathbb{R}^{p \times p}$ e $\mathbf{R} \in \mathbb{R}^{p \times p}$ representam, respectivamente, as matrizes de covariâncias e de correlações calculadas a partir dos dados observados;
- $\mathbf{D}_S = \text{diag}(s_{11}, \dots, s_{pp})$ representa a matriz diagonal das variâncias observadas;
- $\mathbf{S}_{XY} \in \mathbb{R}^{p \times q}$ representa a matriz de covariâncias cruzadas calculada entre dois blocos de variáveis observadas;
- $\bar{\mathbf{X}}$, $\mathbf{S}$ e $\mathbf{R}$ representam, respectivamente, a média amostral, a matriz de covariâncias amostral e a matriz de correlações amostral consideradas como objetos aleatórios; suas propriedades serão desenvolvidas no Capítulo 10;
- $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$ representam as parcelas intragrupos e entre grupos da dispersão total;
- Σ^+ representa a pseudoinversa de Moore–Penrose de Σ quando a matriz de covariâncias é singular.

As convenções estabelecidas nos capítulos anteriores para posto, núcleo, espaço coluna, formas quadráticas, matrizes positivas semidefinidas, decomposição espectral, raízes matriciais e pseudoinversa permanecem válidas.

8.1 Momentos, centralização e covariância

8.1.1 Vetor de médias e centralização

Retomando Definição 1.2, considere o vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_p)^\top \in \mathbb{R}^p,$$

com realização $\mathbf{x} \in \mathbb{R}^p$. Quando n realizações são observadas, sua organização em uma matriz $\mathbf{X} \in \mathbb{R}^{n \times p}$ segue a representação estabelecida em Definição 1.6.

Suponha inicialmente que $E(|X_j|) < \infty$ para $j = 1, \dots, p$. O **vetor de médias populacional** é

$$\mu = E(\mathbf{X}) = \begin{bmatrix} E(X_1) \\ E(X_2) \\ \vdots \\ E(X_p) \end{bmatrix} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix} \in \mathbb{R}^p. \quad (8.1)$$

O vetor μ determina a localização média da distribuição no espaço das observações. Subtraindo esse vetor de $\mathbf{X}$, obtém-se o vetor aleatório centralizado,

$$\mathbf{X}_c = \mathbf{X} - \mu. \quad (8.2)$$

Pela linearidade da esperança,

$$E(\mathbf{X}_c) = E(\mathbf{X}) - \mu = \mathbf{0}.$$

A centralização corresponde a uma translação da distribuição, levando seu vetor de médias à origem. Como estabelecido em Proposição 4.15, a subtração do mesmo vetor de todos os pontos preserva as distâncias entre pares de realizações. Portanto, a centralização altera a localização, mas não a geometria relativa da nuvem de pontos.

A centralização da matriz de dados observada será retomada posteriormente neste capítulo, quando forem construídas a matriz de produtos cruzados e a matriz de covariâncias observada.

8.1.2 Momentos de segunda ordem

O estudo das variâncias e covariâncias exige a existência de momentos de segunda ordem. Neste capítulo, assume-se que

$$E(X_j^2) < \infty, \quad j = 1, \dots, p.$$

Essa condição garante também a existência dos primeiros momentos. Além disso, para quaisquer componentes X_j e X_k , a desigualdade de Cauchy–Schwarz aplicada a variáveis aleatórias de segundo momento finito fornece

$$E(|X_j X_k|) \leq \sqrt{E(X_j^2)E(X_k^2)} < \infty.$$

Portanto, os produtos cruzados necessários à construção das covariâncias possuem esperança finita.

A **matriz de segundos momentos em relação à origem** é

$$\mathbf{M}_2 = E(\mathbf{X}\mathbf{X}^\top) \in \mathbb{R}^{p \times p}.$$

O produto $\mathbf{X}\mathbf{X}^\top$ é o produto externo definido em Definição 1.14. Seus elementos são

$$[\mathbf{X}\mathbf{X}^\top]_{jk} = X_j X_k,$$

de modo que

$$\mathbf{M}_2 = \begin{bmatrix} E(X_1^2) & E(X_1X_2) & \cdots & E(X_1X_p) \\ E(X_2X_1) & E(X_2^2) & \cdots & E(X_2X_p) \\ \vdots & \vdots & \ddots & \vdots \\ E(X_pX_1) & E(X_pX_2) & \cdots & E(X_p^2) \end{bmatrix}.$$

A matriz $\mathbf{M}_2$ utiliza a origem como referência. Seus elementos dependem, portanto, da localização da distribuição e de sua variabilidade conjunta.

Para descrever a dispersão em torno do vetor de médias, utiliza-se o segundo momento central:

$$\Sigma = E \left[(\mathbf{X} - \mu) (\mathbf{X} - \mu)^\top \right].$$

Expandindo o produto e utilizando $E(\mathbf{X}) = \mu$,

$$\begin{aligned} \Sigma &= E(\mathbf{X}\mathbf{X}^\top) - E(\mathbf{X})\mu^\top - \mu E(\mathbf{X})^\top + \mu\mu^\top \\ &= \mathbf{M}_2 - \mu\mu^\top. \end{aligned} \tag{8.3}$$

A identidade Equação 8.3 é a versão matricial da relação univariada

$$\text{Var}(X) = E(X^2) - [E(X)]^2.$$

A diferença entre $\mathbf{M}_2$ e Σ está, portanto, no ponto de referência: $\mathbf{M}_2$ descreve segundos momentos em relação à origem, enquanto Σ descreve a variabilidade em torno da média.

Exemplo 8.1 (Matriz de segundos momentos e covariância). Considere

$$\mu = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

e

$$\mathbf{M}_2 = \begin{bmatrix} 6 & 3 \\ 3 & 3 \end{bmatrix}.$$

O produto externo do vetor de médias é

$$\mu\mu^\top = \begin{bmatrix} 2 \\ 1 \end{bmatrix} \begin{bmatrix} 2 & 1 \end{bmatrix} = \begin{bmatrix} 4 & 2 \\ 2 & 1 \end{bmatrix}.$$

Pela identidade Equação 8.3,

$$\begin{aligned}
\Sigma &= \mathbf{M}_2 - \mu\mu^\top \\
&= \begin{bmatrix} 6 & 3 \\ 3 & 3 \end{bmatrix} - \begin{bmatrix} 4 & 2 \\ 2 & 1 \end{bmatrix} \\
&= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.
\end{aligned}$$

Os elementos diagonais representam as variâncias das duas componentes, enquanto os elementos fora da diagonal representam sua covariância. O exemplo mostra como a retirada da parcela associada à localização transforma os segundos momentos em uma medida de dispersão em torno da média.

8.1.3 Covariância entre duas variáveis

Considere duas variáveis aleatórias X e Y , definidas no mesmo espaço de probabilidade, com segundos momentos finitos e médias

$$\mu_X = E(X) \quad \text{e} \quad \mu_Y = E(Y).$$

Definição 8.1 (Covariância populacional). Se $E(X^2) < \infty$ e $E(Y^2) < \infty$, a **covariância populacional** entre X e Y é

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)].$$

A covariância é a esperança do produto dos desvios das duas variáveis em relação às respectivas médias. Seu sinal descreve o sentido predominante da associação linear:

- uma covariância positiva indica predominância de desvios de mesmo sinal;
- uma covariância negativa indica predominância de desvios de sinais opostos;
- uma covariância nula indica ausência de associação linear registrada pela covariância.

A Figura 8.1 apresenta configurações com covariâncias positiva, aproximadamente nula e negativa.

Na primeira configuração, a nuvem tende a se alongar em uma direção crescente; na terceira, em uma direção decrescente. A configuração intermediária não apresenta orientação linear predominante. O valor da covariância depende também das escalas das variáveis e, por isso, seu módulo não fornece isoladamente uma medida comparável de intensidade entre diferentes pares de variáveis.

Expandindo o produto dos desvios,




Figura 8.1: Padrões de dispersão associados ao sinal da covariância.

$$\begin{aligned}\text{Cov}(X, Y) &= E[(X - \mu_X)(Y - \mu_Y)] \\ &= E(XY) - \mu_X E(Y) - \mu_Y E(X) + \mu_X \mu_Y.\end{aligned}$$

Como $E(X) = \mu_X$ e $E(Y) = \mu_Y$,

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y). \quad (8.4)$$

A expressão Equação 8.4 relaciona a covariância ao momento conjunto $E(XY)$ e aos primeiros momentos das duas variáveis.

Quando as duas variáveis coincidem,

$$\text{Cov}(X, X) = E[(X - \mu_X)^2] = \text{Var}(X).$$

A covariância também é simétrica:

$$\text{Cov}(X, Y) = \text{Cov}(Y, X).$$

Para constantes a , b , c e d ,

$$\text{Cov}(aX + b, cY + d) = ac \text{Cov}(X, Y). \quad (8.5)$$

A identidade Equação 8.5 mostra que translações não alteram a covariância. Mudanças de escala multiplicam a covariância pelo produto dos fatores aplicados às duas variáveis. Quando somente um desses fatores é negativo, o sinal da covariância é invertido.

Essa dependência das unidades impede a comparação direta entre covariâncias associadas a pares de variáveis em escalas distintas. Se uma variável medida em metros for convertida para centímetros, por exemplo, sua covariância com outra variável será multiplicada por 100.

Pela desigualdade de Cauchy–Schwarz,

$$|\text{Cov}(X, Y)| \leq \sqrt{\text{Var}(X) \text{Var}(Y)}. \quad (8.6)$$

O limite Equação 8.6 será utilizado posteriormente para mostrar que a correlação pertence ao intervalo $[-1, 1]$.

Covariância nula e independência

Covariância nula não implica independência em uma distribuição geral. A covariância registra associação linear de segunda ordem, e relações não lineares podem produzir covariância igual a zero.

Exemplo 8.2 (Dependência não linear com covariância nula). Considere

$$X \sim \text{Uniforme}(-2, 2)$$

e

$$Y = X^2 + \varepsilon,$$

em que ε é independente de X , possui média zero e segundo momento finito.

A simetria da distribuição de X em torno de zero implica

$$E(X) = 0 \quad \text{e} \quad E(X^3) = 0.$$

Como ε é independente de X ,

$$E(X\varepsilon) = E(X)E(\varepsilon) = 0.$$

Portanto,

$$\begin{aligned} \text{Cov}(X, Y) &= \text{Cov}(X, X^2 + \varepsilon) \\ &= E(X^3) + E(X\varepsilon) - E(X)E(Y) \\ &= 0. \end{aligned}$$

Apesar da covariância nula, X e Y não são independentes, pois

$$E(Y \mid X = x) = x^2.$$

A Figura 8.2 ilustra essa relação.




Figura 8.2: Dependência não linear com covariância aproximadamente nula na amostra simulada.

A configuração parabólica evidencia uma dependência que não produz orientação linear global. O exemplo delimita a informação fornecida pela covariância e mostra por que o valor zero não deve ser interpretado, sem hipóteses adicionais, como independência.

As variâncias das componentes e as covariâncias entre todos os pares de componentes podem ser reunidas em uma única matriz.

8.2 Matriz de covariâncias populacional

8.2.1 Definição e interpretação dos elementos

Definição 8.2 (Matriz de covariâncias populacional). Seja $\mathbf{X} \in \mathbb{R}^p$ um vetor aleatório com vetor de médias μ e segundos momentos finitos. A **matriz de covariâncias populacional** de $\mathbf{X}$ é

$$\Sigma = \text{Cov}(\mathbf{X}) = E[(\mathbf{X} - \mu)(\mathbf{X} - \mu)^\top] \in \mathbb{R}^{p \times p}. \quad (8.7)$$

O elemento situado na linha j e na coluna k de Σ é

$$\sigma_{jk} = \text{Cov}(X_j, X_k), \quad j, k = 1, \dots, p.$$

Assim,

$$\Sigma = \begin{bmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & \cdots & \text{Cov}(X_1, X_p) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) & \cdots & \text{Cov}(X_2, X_p) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_p, X_1) & \text{Cov}(X_p, X_2) & \cdots & \text{Var}(X_p) \end{bmatrix}. \quad (8.8)$$

Os elementos da diagonal principal são as variâncias,

$$\sigma_{jj} = \text{Var}(X_j),$$

e os elementos fora da diagonal são as covariâncias entre componentes distintas.

Como

$$\text{Cov}(X_j, X_k) = \text{Cov}(X_k, X_j),$$

tem-se

$$\sigma_{jk} = \sigma_{kj},$$

e Σ é simétrica. Para p componentes, existem p variâncias e

$$\frac{p(p-1)}{2}$$

covariâncias distintas, totalizando

$$\frac{p(p+1)}{2}$$

elementos distintos.

As unidades dos elementos dependem das variáveis envolvidas. Se X_j é medida em uma unidade u_j , então

$$\sigma_{jj}$$

é expressa em u_j^2 . Para $j \neq k$,

$$\sigma_{jk}$$

é expressa em $u_j u_k$. Essa dependência das unidades motiva a construção posterior da matriz de correlações.

8.2.2 Variâncias e covariâncias de combinações lineares

Uma combinação linear das componentes de $\mathbf{X}$ possui a forma

$$Y = \mathbf{a}^\top \mathbf{X}, \quad \mathbf{a} \in \mathbb{R}^p.$$

O vetor $\mathbf{a}$ contém os coeficientes da combinação e define uma direção no espaço das variáveis. A combinação linear, já utilizada no Módulo 1, adquire aqui uma interpretação probabilística: sua média e sua variância são determinadas por μ e Σ .

Proposição 8.1 (Momentos de combinações lineares). *Seja $\mathbf{X} \in \mathbb{R}^p$ um vetor aleatório com média μ e matriz de covariâncias Σ . Para quaisquer vetores fixos $\mathbf{a}, \mathbf{b} \in \mathbb{R}^p$,*

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \mu, \tag{8.9}$$

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}, \tag{8.10}$$

e

$$\text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{b}. \tag{8.11}$$

Comprovação. Pela linearidade da esperança,

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top E(\mathbf{X}) = \mathbf{a}^\top \boldsymbol{\mu}.$$

Além disso,

$$\mathbf{a}^\top \mathbf{X} - \mathbf{a}^\top \boldsymbol{\mu} = \mathbf{a}^\top (\mathbf{X} - \boldsymbol{\mu}).$$

Consequentemente,

$$\begin{aligned} \text{Var}(\mathbf{a}^\top \mathbf{X}) &= E[\mathbf{a}^\top (\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top \mathbf{a}] \\ &= \mathbf{a}^\top \Sigma \mathbf{a}. \end{aligned}$$

De modo análogo,

$$\begin{aligned} \text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{X}) &= E[\mathbf{a}^\top (\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top \mathbf{b}] \\ &= \mathbf{a}^\top \Sigma \mathbf{b}. \end{aligned}$$

□

A expressão Equação 8.10 mostra que a matriz de covariâncias determina a variabilidade de todas as combinações lineares das componentes. A quantidade

$$\mathbf{a}^\top \Sigma \mathbf{a}$$

é uma forma quadrática no sentido de Definição 2.23. Quando $\|\mathbf{a}\| = 1$, ela representa a variância da projeção de $\mathbf{X}$ sobre a direção unitária $\mathbf{a}$.

Essa relação constitui a ligação entre a matriz de covariâncias e a geometria desenvolvida no Módulo 1: diferentes direções podem apresentar diferentes níveis de dispersão.

Exemplo 8.3 (Matriz de covariâncias com três variáveis). Considere

$$\Sigma = \begin{bmatrix} 4 & 1,5 & -0,8 \\ 1,5 & 9 & 0 \\ -0,8 & 0 & 1 \end{bmatrix}.$$

As variâncias das três componentes são

$$\text{Var}(X_1) = 4, \quad \text{Var}(X_2) = 9, \quad \text{Var}(X_3) = 1,$$

e as covariâncias distintas são

$$\text{Cov}(X_1, X_2) = 1,5,$$

$$\text{Cov}(X_1, X_3) = -0,8,$$

e

$$\text{Cov}(X_2, X_3) = 0.$$

Considere a combinação linear

$$Y = X_1 + 0,5X_2 - X_3,$$

com vetor de coeficientes

$$\mathbf{a} = \begin{bmatrix} 1 \\ 0,5 \\ -1 \end{bmatrix}.$$

Pela expressão Equação 8.10,

$$\begin{aligned} \text{Var}(Y) &= \mathbf{a}^\top \Sigma \mathbf{a} \\ &= \begin{bmatrix} 1 & 0,5 & -1 \end{bmatrix} \begin{bmatrix} 4 & 1,5 & -0,8 \\ 1,5 & 9 & 0 \\ -0,8 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 0,5 \\ -1 \end{bmatrix} \\ &= 10,35. \end{aligned}$$

A variância da combinação depende das variâncias individuais, das covariâncias e dos coeficientes utilizados. A covariância negativa entre X_1 e X_3 , por exemplo, contribui positivamente para $\text{Var}(Y)$ porque os coeficientes dessas duas componentes possuem sinais opostos.

8.2.3 Propriedades estruturais e singularidade

A matriz de covariâncias pertence à classe das matrizes simétricas positivas semidefinidas. A classificação de positividade de matrizes foi estabelecida em Definição 2.24; aqui ela adquire uma interpretação probabilística direta, pois a forma quadrática associada a Σ representa uma variância (Eaton, 2007).

Proposição 8.2 (Caracterização estrutural das matrizes de covariâncias). *Uma matriz $\mathbf{C} \in \mathbb{R}^{p \times p}$ é matriz de covariâncias de algum vetor aleatório com segundos momentos finitos se, e somente se,*

$$\mathbf{C} = \mathbf{C}^\top$$

e

$$\mathbf{C} \succeq \mathbf{0}.$$

Consequentemente, toda matriz de covariâncias possui elementos diagonais não negativos, autovalores não negativos e submatrizes principais positivas semidefinidas.

Comprovação. Se

$$\mathbf{C} = \text{Cov}(\mathbf{X}),$$

a simetria decorre de

$$\text{Cov}(X_j, X_k) = \text{Cov}(X_k, X_j).$$

Além disso, para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}^\top \mathbf{C} \mathbf{a} = \text{Var}(\mathbf{a}^\top \mathbf{X}) \geq 0.$$

Logo, $\mathbf{C}$ é positiva semidefinida.

Reciprocamente, suponha que $\mathbf{C}$ seja real, simétrica e positiva semidefinida. Pelo Teorema 5.4 e pela raiz quadrada principal definida em Definição 5.9, existe uma matriz simétrica positiva semidefinida $\mathbf{C}^{1/2}$ tal que

$$\mathbf{C} = \mathbf{C}^{1/2} \mathbf{C}^{1/2}.$$

Considere um vetor aleatório

$$\mathbf{U} = (U_1, \dots, U_p)^\top,$$

cujas componentes são independentes e satisfazem

$$P(U_j = 1) = P(U_j = -1) = \frac{1}{2}, \quad j = 1, \dots, p.$$

Então,

$$E(\mathbf{U}) = \mathbf{0}$$

e

$$\text{Cov}(\mathbf{U}) = \mathbf{I}_p.$$

Defina

$$\mathbf{X} = \mathbf{C}^{1/2} \mathbf{U}.$$

Pela transformação da matriz de covariâncias,

$$\begin{aligned} \text{Cov}(\mathbf{X}) &= \mathbf{C}^{1/2} \text{Cov}(\mathbf{U}) \mathbf{C}^{1/2} \\ &= \mathbf{C}^{1/2} \mathbf{I}_p \mathbf{C}^{1/2} \\ &= \mathbf{C}. \end{aligned}$$

Portanto, toda matriz real simétrica positiva semidefinida pode ocorrer como matriz de covariâncias. $\square$

A construção estabelece apenas a existência de um vetor aleatório com matriz de covariâncias $\mathbf{C}$ e não exige uma família de distribuições específica.

A semidefinição positiva impõe restrições aos elementos da matriz. Para duas componentes X_j e X_k , a submatriz principal

$$\begin{bmatrix} \sigma_{jj} & \sigma_{jk} \\ \sigma_{jk} & \sigma_{kk} \end{bmatrix}$$

também deve ser positiva semidefinida. Logo,

$$\sigma_{jj}\sigma_{kk} - \sigma_{jk}^2 \geq 0,$$

o que equivale a

$$|\sigma_{jk}| \leq \sqrt{\sigma_{jj}\sigma_{kk}}.$$

Esse resultado recupera, no nível matricial, o limite apresentado em Equação 8.6.

A simetria, isoladamente, não é suficiente para caracterizar uma matriz de covariâncias.

Exemplo 8.4 (Matriz simétrica que não pode ser uma matriz de covariâncias). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}.$$

A matriz é simétrica. Entretanto, para

$$\mathbf{a} = \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

tem-se

$$\begin{aligned} \mathbf{a}^\top \mathbf{A} \mathbf{a} &= \begin{bmatrix} 1 & -1 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\ &= -2. \end{aligned}$$

Se $\mathbf{A}$ fosse uma matriz de covariâncias, esse valor representaria a variância de uma combinação linear, o que é impossível. A matriz é, portanto, simétrica, mas não positiva semidefinida.

Quando

$$\mathbf{a}^\top \Sigma \mathbf{a} > 0$$

para todo $\mathbf{a} \neq \mathbf{0}$, a matriz Σ é positiva definida. Pela Equação 8.10, isso significa que toda combinação linear não trivial das componentes possui variância positiva.

A situação muda quando Σ é singular.

Proposição 8.3 (Caracterização da singularidade da matriz de covariâncias). *Seja Σ a matriz de covariâncias de $\mathbf{X} \in \mathbb{R}^p$. As seguintes afirmações são equivalentes:*

1. Σ é singular;
2. existe $\mathbf{a} \neq \mathbf{0}$ tal que

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0;$$

3. existe $\mathbf{a} \neq \mathbf{0}$ tal que

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = 0;$$

4. existe $\mathbf{a} \neq \mathbf{0}$ tal que

$$\mathbf{a}^\top (\mathbf{X} - \mu) = 0 \quad \text{quase certamente.}$$

Comprovação. Como Σ é simétrica e positiva semidefinida, o Teorema 5.4 garante uma decomposição com autovalores não negativos. A matriz é singular se, e somente se, pelo menos um desses autovalores é zero. Nesse caso, existe $\mathbf{a} \neq \mathbf{0}$ no núcleo de Σ e, portanto,

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0.$$

Reciprocamente, para uma matriz positiva semidefinida,

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0$$

implica que $\mathbf{a}$ pertence ao núcleo de Σ .

Pela Equação 8.10,

$$\mathbf{a}^\top \Sigma \mathbf{a} = \text{Var}(\mathbf{a}^\top \mathbf{X}),$$

o que estabelece a equivalência entre as duas condições seguintes.

Uma variável aleatória possui variância zero se, e somente se, é constante quase certamente. Como

$$E[\mathbf{a}^\top (\mathbf{X} - \mu)] = 0,$$

essa constante deve ser zero. Portanto,

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = 0$$

se, e somente se,

$$\mathbf{a}^\top (\mathbf{X} - \mu) = 0 \quad \text{quase certamente.}$$

□

A última condição de Proposição 8.3 também pode ser escrita como

$$\mathbf{a}^\top \mathbf{X} = \mathbf{a}^\top \mu \quad \text{quase certamente.}$$

Portanto, a singularidade de Σ corresponde à existência de uma relação afim exata e não trivial entre as componentes do vetor aleatório.

Em termos geométricos, os vetores pertencentes a

$$\mathcal{N}(\Sigma)$$

determinam direções de variância nula. Como Σ é simétrica, a relação entre núcleo e espaço coluna desenvolvida no Módulo 1 permite escrever

$$\mathcal{N}(\Sigma)^\perp = \mathcal{C}(\Sigma).$$

Consequentemente,

$$\mathbf{X} - \mu \in \mathcal{C}(\Sigma) \quad \text{quase certamente.}$$

Se

$$\text{posto}(\Sigma) = r < p,$$

a variabilidade do vetor centralizado está restrita a um subespaço de dimensão r . O vetor original está, portanto, restrito quase certamente ao subespaço afim

$$\mu + \mathcal{C}(\Sigma).$$

Exemplo 8.5 (Relação linear exata e singularidade). Suponha que

$$X_3 = 2X_1 - X_2$$

quase certamente. Então,

$$-2X_1 + X_2 + X_3 = 0.$$

Definindo

$$\mathbf{a} = \begin{bmatrix} -2 \\ 1 \\ 1 \end{bmatrix},$$

obtém-se

$$\mathbf{a}^\top \mathbf{X} = 0$$

e, conseqüentemente,

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a} = 0.$$

A matriz Σ é singular porque uma combinação linear não trivial das três componentes é constante. Embora $\mathbf{X}$ possua três componentes, sua variabilidade está restrita, após a centralização, a um subespaço de dimensão no máximo dois.

A matriz de covariâncias também pode ser utilizada para descrever conjuntamente dois vetores aleatórios distintos. Essa extensão produz matrizes retangulares de covariâncias cruzadas e permite representar as relações lineares entre dois blocos de variáveis.

8.3 Covariâncias entre vetores e transformações

8.3.1 Covariâncias cruzadas e vetores particionados

A covariância pode relacionar componentes pertencentes a dois vetores aleatórios distintos. Considere

$$\mathbf{X} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{Y} \in \mathbb{R}^q,$$

com vetores de médias

$$\mu_X = E(\mathbf{X}) \in \mathbb{R}^p$$

e

$$\mu_Y = E(\mathbf{Y}) \in \mathbb{R}^q.$$

Admite-se que todas as componentes possuam segundos momentos finitos.

Definição 8.3 (Matriz de covariâncias cruzadas). A **matriz de covariâncias cruzadas** entre $\mathbf{X}$ e $\mathbf{Y}$ é

$$\Sigma_{XY} = \text{Cov}(\mathbf{X}, \mathbf{Y}) = E \left[(\mathbf{X} - \mu_X) (\mathbf{Y} - \mu_Y)^\top \right] \in \mathbb{R}^{p \times q}. \quad (8.12)$$

O elemento situado na linha j e na coluna k é

$$(\Sigma_{XY})_{jk} = \text{Cov}(X_j, Y_k),$$

para $j = 1, \dots, p$ e $k = 1, \dots, q$. Portanto,

$$\Sigma_{XY} = \begin{bmatrix} \text{Cov}(X_1, Y_1) & \cdots & \text{Cov}(X_1, Y_q) \\ \vdots & \ddots & \vdots \\ \text{Cov}(X_p, Y_1) & \cdots & \text{Cov}(X_p, Y_q) \end{bmatrix}.$$

A orientação da matriz depende da ordem dos vetores. Invertendo essa ordem,

$$\Sigma_{YX} = \Sigma_{XY}^\top. \quad (8.13)$$

Assim,

$$\Sigma_{XY} \in \mathbb{R}^{p \times q}, \quad \Sigma_{YX} \in \mathbb{R}^{q \times p}.$$

Mesmo quando $p = q$, não se tem em geral

$$\Sigma_{XY} = \Sigma_{YX},$$

pois uma matriz de covariâncias cruzadas não precisa ser simétrica.

Proposição 8.4 (Covariância entre combinações de dois vetores). *Para quaisquer vetores fixos*

$$\mathbf{a} \in \mathbb{R}^p \quad e \quad \mathbf{b} \in \mathbb{R}^q,$$

tem-se

$$\text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{Y}) = \mathbf{a}^\top \Sigma_{XY} \mathbf{b}. \quad (8.14)$$

Comprovação. As versões centralizadas das duas combinações são

$$\mathbf{a}^\top (\mathbf{X} - \mu_X)$$

e

$$\mathbf{b}^\top (\mathbf{Y} - \mu_Y).$$

Logo,

$$\begin{aligned} & \text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{Y}) \\ &= E \left[\mathbf{a}^\top (\mathbf{X} - \mu_X) (\mathbf{Y} - \mu_Y)^\top \mathbf{b} \right] \\ &= \mathbf{a}^\top \Sigma_{XY} \mathbf{b}. \end{aligned}$$

□

Em particular,

$$\Sigma_{XY} = \mathbf{0}$$

se, e somente se,

$$\text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{Y}) = 0$$

para todos os vetores $\mathbf{a} \in \mathbb{R}^p$ e $\mathbf{b} \in \mathbb{R}^q$. Nesse caso, nenhuma combinação linear do primeiro bloco possui covariância não nula com uma combinação linear do segundo.

A condição

$$\Sigma_{XY} = \mathbf{0}$$

não implica, em uma distribuição geral, independência entre os vetores. Essa relação será retomada no Capítulo 9 sob a distribuição normal multivariada.

Os dois vetores podem ser reunidos em um único vetor particionado:

$$\mathbf{V} = \begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix} \in \mathbb{R}^{p+q}.$$

Seu vetor de médias é

$$\mu_V = \begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix},$$

e sua matriz de covariâncias pode ser representada por blocos, conforme a estrutura de matrizes particionadas definida em Definição 2.25:

$$\Sigma_V = \begin{bmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{bmatrix}, \quad (8.15)$$

em que

$$\Sigma_{XX} = \text{Cov}(\mathbf{X})$$

e

$$\Sigma_{YY} = \text{Cov}(\mathbf{Y}).$$

Os blocos diagonais descrevem a dispersão interna de cada vetor, enquanto os blocos fora da diagonal descrevem as covariâncias entre suas componentes.

Como Σ_V é uma matriz de covariâncias, ela é simétrica e positiva semidefinida. Essa condição restringe conjuntamente seus blocos. Em particular, Σ_{XY} não pode ser especificada arbitrariamente depois de fixadas Σ_{XX} e Σ_{YY} .

8.3.1.1 Complemento de Schur e dispersão residual

O complemento de Schur já foi definido em Definição 2.26. Aplicado à matriz de covariâncias particionada, ele recebe uma interpretação estatística de segunda ordem.

Suponha que

$$\Sigma_{YY} \succ \mathbf{0}.$$

O complemento de Schur de Σ_{YY} em Σ_V é

$$\Sigma_{XX.Y} = \Sigma_{XX} - \Sigma_{XY}\Sigma_{YY}^{-1}\Sigma_{YX}. \quad (8.16)$$

Pelo resultado de positividade do complemento de Schur em Teorema 2.9,

$$\Sigma_{XX.Y} \succeq \mathbf{0}.$$

A expressão também pode ser interpretada diretamente como uma covariância residual.

Proposição 8.5 (Complemento de Schur e covariância residual). *Defina os vetores centralizados*

$$\mathbf{X}_c = \mathbf{X} - \mu_X$$

e

$$\mathbf{Y}_c = \mathbf{Y} - \mu_Y.$$

Para qualquer matriz

$$\mathbf{L} \in \mathbb{R}^{p \times q},$$

considere o resíduo linear

$$\mathbf{R}_L = \mathbf{X}_c - \mathbf{L}\mathbf{Y}_c.$$

Se $\Sigma_{YY} \succ \mathbf{0}$, a escolha

$$\mathbf{L}^* = \Sigma_{XY}\Sigma_{YY}^{-1}$$

satisfaz

$$\text{Cov}(\mathbf{R}_{\mathbf{L}^*}) = \Sigma_{XX.Y}.$$

Além disso, para qualquer $\mathbf{L}$,

$$\text{Cov}(\mathbf{R}_{\mathbf{L}}) - \Sigma_{XX.Y} \succeq \mathbf{0}.$$

Portanto, $\mathbf{L}^*$ minimiza a covariância residual segundo a ordem de Loewner.

Comprovação. Para uma matriz arbitrária $\mathbf{L}$,

$$\text{Cov}(\mathbf{R}_{\mathbf{L}}) = \Sigma_{XX} - \mathbf{L}\Sigma_{YX} - \Sigma_{XY}\mathbf{L}^\top + \mathbf{L}\Sigma_{YY}\mathbf{L}^\top.$$

Substituindo

$$\mathbf{L}^* = \Sigma_{XY}\Sigma_{YY}^{-1},$$

a expressão pode ser reorganizada como

$$\begin{aligned} \text{Cov}(\mathbf{R}_{\mathbf{L}}) &= \Sigma_{XX.Y} \\ &\quad + (\mathbf{L} - \mathbf{L}^*)\Sigma_{YY}(\mathbf{L} - \mathbf{L}^*)^\top. \end{aligned}$$

Como Σ_{YY} é positiva definida,

$$(\mathbf{L} - \mathbf{L}^*)\Sigma_{YY}(\mathbf{L} - \mathbf{L}^*)^\top \succeq \mathbf{0}.$$

A diferença entre a covariância residual correspondente a qualquer $\mathbf{L}$ e aquela obtida com $\mathbf{L}^*$ é, portanto, positiva semidefinida. $\square$

Essa interpretação depende apenas dos segundos momentos e não exige normalidade. Sob normalidade conjunta, o mesmo complemento de Schur aparecerá no Capítulo 9 como matriz de covariâncias da distribuição condicional de um bloco dado o outro.

Exemplo 8.6 (Covariâncias entre dois blocos). Considere

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

e

$$\mathbf{Y} = \begin{bmatrix} Y_1 \\ Y_2 \\ Y_3 \end{bmatrix},$$

com

$$\Sigma_{XY} = \begin{bmatrix} 2 & -1 & 0,5 \\ 1 & 3 & -2 \end{bmatrix}.$$

Para as combinações

$$U = X_1 - 2X_2$$

e

$$V = Y_1 + Y_2,$$

os vetores de coeficientes são

$$\mathbf{a} = \begin{bmatrix} 1 \\ -2 \end{bmatrix}$$

e

$$\mathbf{b} = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}.$$

Pela expressão Equação [8.14](#),

$$\begin{aligned}
\text{Cov}(U, V) &= \mathbf{a}^\top \Sigma_{XY} \mathbf{b} \\
&= [1 \quad -2] \begin{bmatrix} 2 & -1 & 0,5 \\ 1 & 3 & -2 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} \\
&= -7.
\end{aligned}$$

A covariância entre U e V resulta conjuntamente das covariâncias entre todas as componentes que participam das duas combinações lineares.

8.3.2 Transformações afins da média e da covariância

As transformações afins foram definidas em Definição 4.7. No contexto probabilístico, interessa determinar como elas modificam a média e a matriz de covariâncias.

Considere

$$\mathbf{U} = \mathbf{A}\mathbf{X} + \mathbf{c},$$

em que

$$\mathbf{X} \in \mathbb{R}^p, \quad \mathbf{A} \in \mathbb{R}^{r \times p}, \quad \mathbf{c} \in \mathbb{R}^r.$$

Proposição 8.6 (Média e covariância sob transformação afim). *Se $\mathbf{X}$ possui média μ_X e matriz de covariâncias Σ_{XX} , então*

$$E(\mathbf{U}) = \mathbf{A}\mu_X + \mathbf{c} \tag{8.17}$$

e

$$\text{Cov}(\mathbf{U}) = \mathbf{A}\Sigma_{XX}\mathbf{A}^\top. \tag{8.18}$$

Comprovação. Pela linearidade da esperança,

$$E(\mathbf{A}\mathbf{X} + \mathbf{c}) = \mathbf{A}\mu_X + \mathbf{c}.$$

O vetor transformado centralizado é

$$\begin{aligned}\mathbf{U} - E(\mathbf{U}) &= \mathbf{A}\mathbf{X} + \mathbf{c} - \mathbf{A}\mu_X - \mathbf{c} \\ &= \mathbf{A}(\mathbf{X} - \mu_X).\end{aligned}$$

Portanto,

$$\begin{aligned}\text{Cov}(\mathbf{U}) &= E\left[\mathbf{A}(\mathbf{X} - \mu_X)(\mathbf{X} - \mu_X)^\top \mathbf{A}^\top\right] \\ &= \mathbf{A}\Sigma_{XX}\mathbf{A}^\top.\end{aligned}$$

□

A ausência do vetor $\mathbf{c}$ em Equação 8.18 confirma que translações alteram a localização, mas não a matriz de covariâncias.

Quando

$$r = 1 \quad \text{e} \quad \mathbf{A} = \mathbf{a}^\top,$$

a expressão reduz-se a

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma_{XX} \mathbf{a},$$

recuperando Equação 8.10.

Se $\mathbf{A}$ é diagonal,

$$\mathbf{A} = \text{diag}(a_1, \dots, a_p),$$

então

$$\text{Cov}(a_j X_j, a_k X_k) = a_j a_k \sigma_{jk}.$$

Em particular,

$$\text{Var}(a_j X_j) = a_j^2 \sigma_{jj}.$$

Se $\mathbf{Q} \in \mathbb{R}^{p \times p}$ é ortogonal no sentido de Definição 2.18,

$$\text{Cov}(\mathbf{Q}\mathbf{X}) = \mathbf{Q}\Sigma_{XX}\mathbf{Q}^\top.$$

Como $\mathbf{Q}^\top = \mathbf{Q}^{-1}$, essa transformação produz uma matriz semelhante a Σ_{XX} e preserva seus autovalores. A interpretação estatística dessa propriedade será retomada na geometria da covariância.

Exemplo 8.7 (Transformação de duas variáveis). Considere

$$\Sigma_{XX} = \begin{bmatrix} 4 & 2 \\ 2 & 9 \end{bmatrix}$$

e

$$\mathbf{U} = \mathbf{A}\mathbf{X},$$

com

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

As componentes transformadas são

$$U_1 = X_1 + X_2$$

e

$$U_2 = X_1 - X_2.$$

Pela expressão Equação 8.18,

$$\begin{aligned} \text{Cov}(\mathbf{U}) &= \mathbf{A}\Sigma_{XX}\mathbf{A}^\top \\ &= \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 4 & 2 \\ 2 & 9 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 17 & -5 \\ -5 & 9 \end{bmatrix}. \end{aligned}$$

Logo,

$$\text{Var}(U_1) = 17, \quad \text{Var}(U_2) = 9$$

e

$$\text{Cov}(U_1, U_2) = -5.$$

A transformação modifica simultaneamente as variâncias das componentes e a covariância entre elas.

As covariâncias cruzadas também se transformam de maneira compatível.

Proposição 8.7 (Covariância cruzada sob transformações afins). *Considere*

$$\mathbf{U} = \mathbf{A}\mathbf{X} + \mathbf{c}$$

e

$$\mathbf{V} = \mathbf{G}\mathbf{Y} + \mathbf{d},$$

com

$$\mathbf{A} \in \mathbb{R}^{r \times p}, \quad \mathbf{G} \in \mathbb{R}^{s \times q}.$$

Então,

$$\text{Cov}(\mathbf{U}, \mathbf{V}) = \mathbf{A}\Sigma_{XY}\mathbf{G}^\top. \quad (8.19)$$

Comprovação. Após a centralização,

$$\mathbf{U} - E(\mathbf{U}) = \mathbf{A}(\mathbf{X} - \mu_X)$$

e

$$\mathbf{V} - E(\mathbf{V}) = \mathbf{G}(\mathbf{Y} - \mu_Y).$$

Logo,

$$\begin{aligned} \text{Cov}(\mathbf{U}, \mathbf{V}) &= E \left[\mathbf{A}(\mathbf{X} - \mu_X)(\mathbf{Y} - \mu_Y)^\top \mathbf{G}^\top \right] \\ &= \mathbf{A}\Sigma_{XY}\mathbf{G}^\top. \end{aligned}$$

□

As expressões Equação 8.18 e Equação 8.19 mostram que a matriz de covariâncias responde de maneira sistemática às transformações lineares. A padronização das componentes constitui um caso particular dessa estrutura.

8.4 Padronização e matriz de correlações

8.4.1 Matriz de correlações populacional

As covariâncias dependem das unidades de medida das variáveis. Para retirar as escalas marginais, suponha que

$$\sigma_{jj} = \text{Var}(X_j) > 0, \quad j = 1, \dots, p.$$

Defina a matriz diagonal das variâncias populacionais por

$$\mathbf{D}_\Sigma = \text{diag}(\sigma_{11}, \dots, \sigma_{pp}). \quad (8.20)$$

Como todas as variâncias são positivas,

$$\mathbf{D}_\Sigma \succ \mathbf{0}$$

e existem as matrizes diagonais

$$\mathbf{D}_\Sigma^{1/2} = \text{diag}(\sqrt{\sigma_{11}}, \dots, \sqrt{\sigma_{pp}})$$

e

$$\mathbf{D}_\Sigma^{-1/2} = \text{diag}\left(\frac{1}{\sqrt{\sigma_{11}}}, \dots, \frac{1}{\sqrt{\sigma_{pp}}}\right).$$

Definição 8.4 (Vetor aleatório padronizado). O vetor aleatório marginalmente padronizado correspondente a $\mathbf{X}$ é

$$\mathbf{Z} = \mathbf{D}_\Sigma^{-1/2}(\mathbf{X} - \mu). \quad (8.21)$$

Sua componente j é

$$Z_j = \frac{X_j - \mu_j}{\sqrt{\sigma_{jj}}}.$$

Assim,

$$E(Z_j) = 0$$

e

$$\text{Var}(Z_j) = 1.$$

Em forma vetorial,

$$E(\mathbf{Z}) = \mathbf{0}.$$

Aplicando Equação 8.18,

$$\text{Cov}(\mathbf{Z}) = \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}.$$

Definição 8.5 (Matriz de correlações populacional). Se todas as componentes de $\mathbf{X}$ possuem variâncias positivas, sua **matriz de correlações populacional** é

$$\mathcal{R} = \text{Cov}(\mathbf{Z}) = \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}. \quad (8.22)$$

O símbolo $\mathcal{R}$ é reservado à matriz populacional. Posteriormente, $\mathbf{R}$ representará a matriz de correlações amostral como estatística aleatória, enquanto $\mathbf{R}$ representará seu valor calculado a partir de uma amostra observada.

A matriz $\mathcal{R}$ possui a forma

$$\mathcal{R} = \begin{bmatrix} 1 & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{21} & 1 & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \cdots & 1 \end{bmatrix},$$

em que

$$\rho_{jk} = \text{Corr}(X_j, X_k) = \frac{\sigma_{jk}}{\sqrt{\sigma_{jj}\sigma_{kk}}}. \quad (8.23)$$

Equivalentemente,

$$\rho_{jk} = \text{Cov}(Z_j, Z_k).$$

A correlação é adimensional porque o numerador e o denominador de Equação 8.23 possuem as mesmas unidades.

A relação entre covariâncias e correlações pode ser invertida:

$$\Sigma = \mathbf{D}_\Sigma^{1/2} \mathcal{R} \mathbf{D}_\Sigma^{1/2}. \quad (8.24)$$

Portanto, Σ pode ser decomposta em dois elementos:

- $\mathbf{D}_\Sigma$ registra as variâncias e, consequentemente, as escalas marginais;
- $\mathcal{R}$ registra a estrutura de associação linear após a remoção dessas escalas.

A matriz de correlações isoladamente não permite recuperar as variâncias originais.

Exemplo 8.8 (Matriz de correlações obtida por uma transformação de padronização). Considere um vetor aleatório

$$\mathbf{x} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

com vetor de médias μ e matriz de covariâncias

$$\Sigma = \begin{bmatrix} 16 & 12 \\ 12 & 25 \end{bmatrix}.$$

Os desvios-padrão populacionais são

$$\sqrt{\sigma_{11}} = 4 \quad \text{e} \quad \sqrt{\sigma_{22}} = 5.$$

Portanto,

$$\mathbf{D}_\Sigma = \begin{bmatrix} 16 & 0 \\ 0 & 25 \end{bmatrix}$$

e

$$\mathbf{D}_{\Sigma}^{-1/2} = \begin{bmatrix} 1/4 & 0 \\ 0 & 1/5 \end{bmatrix}.$$

Considere a transformação de padronização

$$\mathbf{Z} = \mathbf{D}_{\Sigma}^{-1/2} (\mathbf{X} - \mu).$$

Ela pode ser escrita como a transformação afim

$$\mathbf{Z} = \mathbf{A}\mathbf{X} + \mathbf{c},$$

com

$$\mathbf{A} = \mathbf{D}_{\Sigma}^{-1/2}$$

e

$$\mathbf{c} = -\mathbf{D}_{\Sigma}^{-1/2} \mu.$$

Utilizando Proposição 8.6,

$$\text{Cov}(\mathbf{Z}) = \mathbf{A}\Sigma\mathbf{A}^{\top}.$$

Como $\mathbf{A}$ é diagonal e simétrica,

$$\begin{aligned} \text{Cov}(\mathbf{Z}) &= \begin{bmatrix} 1/4 & 0 \\ 0 & 1/5 \end{bmatrix} \begin{bmatrix} 16 & 12 \\ 12 & 25 \end{bmatrix} \begin{bmatrix} 1/4 & 0 \\ 0 & 1/5 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 3/5 \\ 3/5 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0,6 \\ 0,6 & 1 \end{bmatrix}. \end{aligned}$$

Essa é precisamente a matriz de correlações populacional,

$$\mathcal{R} = \begin{bmatrix} 1 & 0,6 \\ 0,6 & 1 \end{bmatrix}.$$

De fato,

$$\rho_{12} = \frac{\sigma_{12}}{\sqrt{\sigma_{11}\sigma_{22}}} = \frac{12}{\sqrt{16 \cdot 25}} = \frac{12}{20} = 0,6.$$

O exemplo mostra duas formas equivalentes de chegar ao mesmo resultado. Pela transformação do vetor,

$$\text{padronizar } \mathbf{X} \implies \text{Cov}(\mathbf{Z}).$$

Equivalentemente, pode-se transformar diretamente a matriz de covariâncias:

$$\Sigma \implies \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}.$$

Em ambas as perspectivas, as variâncias tornam-se unitárias e a covariância entre as componentes padronizadas passa a coincidir com sua correlação.

8.4.2 Propriedades, escala e independência

Proposição 8.8 (Caracterização das matrizes de correlações). *Uma matriz*

$$\mathbf{C} \in \mathbb{R}^{p \times p}$$

é matriz de correlações de algum vetor aleatório com variâncias marginais positivas se, e somente se,

$$\mathbf{C} = \mathbf{C}^{\top},$$

$$\mathbf{C} \succeq \mathbf{0}$$

e

$$c_{jj} = 1, \quad j = 1, \dots, p.$$

Consequentemente, toda matriz de correlações possui:

1. elementos no intervalo $[-1, 1]$;
2. autovalores reais e não negativos;
3. traço igual a p .

Comprovação. Se $\mathbf{C} = \mathcal{R}$ é uma matriz de correlações, então

$$\mathcal{R} = \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}.$$

Como Σ é simétrica,

$$\mathcal{R}^{\top} = \mathcal{R}.$$

Além disso, para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\begin{aligned} \mathbf{a}^{\top} \mathcal{R} \mathbf{a} &= \left(\mathbf{D}_{\Sigma}^{-1/2} \mathbf{a} \right)^{\top} \Sigma \left(\mathbf{D}_{\Sigma}^{-1/2} \mathbf{a} \right) \\ &\geq 0, \end{aligned}$$

de modo que

$$\mathcal{R} \succeq \mathbf{0}.$$

A diagonal é unitária porque

$$\rho_{jj} = \frac{\sigma_{jj}}{\sqrt{\sigma_{jj}\sigma_{jj}}} = 1.$$

Reciprocamente, suponha que $\mathbf{C}$ seja simétrica, positiva semidefinida e possua diagonal unitária. Pela raiz quadrada principal definida em Definição 5.9, existe $\mathbf{C}^{1/2}$ tal que

$$\mathbf{C} = \mathbf{C}^{1/2} \mathbf{C}^{1/2}.$$

Considere um vetor aleatório

$$\mathbf{U} = (U_1, \dots, U_p)^{\top},$$

cujas componentes são independentes e satisfazem

$$P(U_j = 1) = P(U_j = -1) = \frac{1}{2}.$$

Então,

$$E(\mathbf{U}) = \mathbf{0}$$

e

$$\text{Cov}(\mathbf{U}) = \mathbf{I}_p.$$

Defina

$$\mathbf{Z} = \mathbf{C}^{1/2} \mathbf{U}.$$

Tem-se

$$\text{Cov}(\mathbf{Z}) = \mathbf{C}^{1/2} \mathbf{I}_p \mathbf{C}^{1/2} = \mathbf{C}.$$

Como a diagonal de $\mathbf{C}$ é unitária, todas as componentes de $\mathbf{Z}$ possuem variância igual a um. Logo, sua matriz de covariâncias coincide com sua matriz de correlações, e $\mathbf{C}$ é uma matriz de correlações válida.

Pela desigualdade de Cauchy–Schwarz,

$$|c_{jk}| \leq \sqrt{c_{jj}c_{kk}} = 1.$$

Como $\mathbf{C}$ é simétrica e positiva semidefinida, seus autovalores são reais e não negativos. Finalmente,

$$\text{tr}(\mathbf{C}) = \sum_{j=1}^p c_{jj} = p.$$

□

Se Σ possui variâncias marginais positivas, a transformação

$$\mathcal{R} = \mathbf{D}_\Sigma^{-1/2} \Sigma \mathbf{D}_\Sigma^{-1/2}$$

é uma congruência por uma matriz invertível. Consequentemente,

$$\mathcal{R} \succ \mathbf{0} \iff \Sigma \succ \mathbf{0}.$$

Os valores extremos da correlação correspondem a relações lineares exatas. Para $j \neq k$,

$$\rho_{jk} = 1$$

se, e somente se,

$$Z_k = Z_j \quad \text{quase certamente,}$$

enquanto

$$\rho_{jk} = -1$$

se, e somente se,

$$Z_k = -Z_j \quad \text{quase certamente.}$$

Em termos das variáveis originais,

$$\rho_{jk} = 1$$

corresponde a

$$X_k - \mu_k = \sqrt{\frac{\sigma_{kk}}{\sigma_{jj}}} (X_j - \mu_j) \quad \text{quase certamente,}$$

e

$$\rho_{jk} = -1$$

corresponde a

$$X_k - \mu_k = -\sqrt{\frac{\sigma_{kk}}{\sigma_{jj}}} (X_j - \mu_j) \quad \text{quase certamente.}$$

Assim, correlação de módulo igual a um implica singularidade da matriz de covariâncias do par correspondente.

A semidefinição positiva também mostra que especificar correlações válidas par a par não é suficiente para construir uma matriz de correlações válida.

Exemplo 8.9 (Matriz com diagonal unitária que não é uma matriz de correlações). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0,9 & 0,9 \\ 0,9 & 1 & -0,9 \\ 0,9 & -0,9 & 1 \end{bmatrix}.$$

Todos os elementos pertencem ao intervalo $[-1, 1]$, a matriz é simétrica e sua diagonal é unitária. Entretanto,

$$\det(\mathbf{A}) = -2,888 < 0.$$

Uma matriz positiva semidefinida não pode possuir determinante negativo. Logo, $\mathbf{A}$ não é uma matriz de correlações.

O exemplo mostra que as correlações entre pares devem ser compatíveis com uma única estrutura conjunta positiva semidefinida.

Duas componentes X_j e X_k são não correlacionadas quando

$$\rho_{jk} = 0.$$

Como suas variâncias são positivas,

$$\rho_{jk} = 0 \iff \sigma_{jk} = 0.$$

Essa condição não implica independência em uma distribuição geral, conforme ilustrado em Exemplo 8.2.

Se X_j e X_k são independentes e possuem segundos momentos finitos, então

$$E(X_j X_k) = E(X_j)E(X_k),$$

e, portanto,

$$\text{Cov}(X_j, X_k) = 0.$$

Assim,

$$\text{independência} \implies \text{correlação nula},$$

mas a recíproca depende de hipóteses adicionais.

Uma matriz de correlações diagonal necessariamente é

$$\mathcal{R} = \mathbf{I}_p.$$

Nesse caso, todas as componentes são duas a duas não correlacionadas. Essa propriedade não garante, por si só, independência conjunta. A relação especial entre ausência de correlação e independência sob normalidade conjunta será estabelecida no Capítulo 9.

Considere agora uma mudança de localização e escala aplicada separadamente às componentes:

$$Y_j = c_j X_j + d_j, \quad c_j \neq 0.$$

Tem-se

$$\text{Cov}(Y_j, Y_k) = c_j c_k \sigma_{jk},$$

enquanto

$$\text{Var}(Y_j) = c_j^2 \sigma_{jj}.$$

Consequentemente,

$$\text{Corr}(Y_j, Y_k) = \text{sgn}(c_j) \text{sgn}(c_k) \rho_{jk}. \quad (8.25)$$

Se $c_j > 0$ e $c_k > 0$,

$$\text{Corr}(Y_j, Y_k) = \rho_{jk}.$$

Portanto, translações e mudanças positivas de unidade não alteram a correlação. A multiplicação de uma variável por uma constante negativa inverte o sinal de suas correlações, sem alterar seus módulos.

Exemplo 8.10 (Conversão de covariâncias em correlações). Retome a matriz de covariâncias do Exemplo 8.3:

$$\Sigma = \begin{bmatrix} 4 & 1,5 & -0,8 \\ 1,5 & 9 & 0 \\ -0,8 & 0 & 1 \end{bmatrix}.$$

A matriz das variâncias marginais é

$$\mathbf{D}_{\Sigma} = \begin{bmatrix} 4 & 0 & 0 \\ 0 & 9 & 0 \\ 0 & 0 & 1 \end{bmatrix},$$

de modo que

$$\mathbf{D}_{\Sigma}^{-1/2} = \begin{bmatrix} 1/2 & 0 & 0 \\ 0 & 1/3 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

Pela expressão Equação 8.22,

$$\begin{aligned} \mathcal{R} &= \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2} \\ &= \begin{bmatrix} 1 & 0,25 & -0,4 \\ 0,25 & 1 & 0 \\ -0,4 & 0 & 1 \end{bmatrix}. \end{aligned}$$

Por exemplo,

$$\rho_{12} = \frac{1,5}{\sqrt{4 \cdot 9}} = 0,25,$$

enquanto

$$\rho_{13} = \frac{-0,8}{\sqrt{4 \cdot 1}} = -0,4.$$

Embora

$$|\sigma_{12}| > |\sigma_{13}|,$$

tem-se

$$|\rho_{13}| > |\rho_{12}|.$$

A covariância entre X_1 e X_2 possui maior módulo nas unidades originais, mas a associação linear padronizada entre X_1 e X_3 é mais intensa. A comparação evidencia a diferença entre a informação fornecida por covariâncias e por correlações.

A matriz de covariâncias preserva as variâncias e as unidades originais das componentes. A matriz de correlações descreve a mesma estrutura de segunda ordem após a padronização marginal, atribuindo variância unitária a todas as componentes. Essa mudança de escala pode alterar a geometria da dispersão e será considerada na interpretação espectral das duas matrizes.

8.5 Geometria e medidas globais da dispersão

8.5.1 Eixos espectrais e elipsoide de covariância

A expressão Equação 8.10 mostra que a matriz de covariâncias associa a cada direção $\mathbf{a} \in \mathbb{R}^p$ a variância

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

Quando $\|\mathbf{a}\| = 1$, essa quantidade representa a dispersão ao longo da direção unitária $\mathbf{a}$. A interpretação espectral das formas quadráticas foi desenvolvida no Capítulo 5. Aplicando o Teorema 5.4 à matriz simétrica positiva semidefinida Σ ,

$$\Sigma = \mathbf{Q} \Lambda \mathbf{Q}^\top, \quad (8.26)$$

em que

$$\mathbf{Q} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p]$$

é ortogonal e

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p), \quad \lambda_j \geq 0.$$

A transformação

$$\mathbf{Y} = \mathbf{Q}^\top (\mathbf{X} - \mu) \quad (8.27)$$

expressa o vetor centralizado nas coordenadas da base de autovetores. Pela regra de transformação da covariância,

$$\text{Cov}(\mathbf{Y}) = \mathbf{Q}^\top \Sigma \mathbf{Q} = \Lambda. \quad (8.28)$$

Portanto,

$$\text{Var}(Y_j) = \lambda_j$$

e

$$\text{Cov}(Y_j, Y_k) = 0, \quad j \neq k.$$

Os autovetores $\mathbf{q}_1, \dots, \mathbf{q}_p$ serão denominados **eixos espectrais da covariância**. O autovalor λ_j quantifica a variância ao longo do eixo $\mathbf{q}_j$.

Se

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0,$$

o resultado sobre os extremos do quociente de Rayleigh em Teorema 5.5 fornece

$$\lambda_p \leq \mathbf{a}^\top \Sigma \mathbf{a} \leq \lambda_1, \quad \|\mathbf{a}\| = 1. \quad (8.29)$$

Os valores extremos são alcançados nos autovetores correspondentes. Assim, a decomposição espectral identifica direções ortogonais nas quais as covariâncias desaparecem e as variâncias são dadas diretamente pelos autovalores.

Neste capítulo, essa decomposição é utilizada somente para descrever a geometria da dispersão. A seleção de eixos espectrais para construir uma representação de dimensão reduzida pertence à formulação da Análise de Componentes Principais.

Exemplo 8.11 (Obtenção dos eixos de maior e menor variabilidade). Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

com matriz de covariâncias

$$\Sigma = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}.$$

Queremos determinar a direção unitária

$$\mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \end{bmatrix}, \quad \mathbf{a}^\top \mathbf{a} = 1,$$

na qual a combinação linear

$$Y = \mathbf{a}^\top \mathbf{X}$$

apresenta a maior variância possível.

Pela expressão Equação 8.10,

$$\text{Var}(Y) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

Portanto, o problema é

$$\max_{\mathbf{a}} \quad \mathbf{a}^\top \Sigma \mathbf{a}$$

sujeito a

$$\mathbf{a}^\top \mathbf{a} = 1.$$

Esse é precisamente o tipo de problema de otimização com restrição estudado no Módulo 1. Como maximizar uma função equivale a minimizar seu negativo, a condição necessária de Lagrange estabelecida em Teorema 7.6 aplica-se também a este problema. Considere

$$\mathcal{L}(\mathbf{a}, \eta) = \mathbf{a}^\top \Sigma \mathbf{a} - \eta (\mathbf{a}^\top \mathbf{a} - 1).$$

Como Σ é simétrica,

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \Sigma \mathbf{a}) = 2\Sigma \mathbf{a}$$

e

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{a}) = 2\mathbf{a}.$$

A condição de primeira ordem é, portanto,

$$2\Sigma \mathbf{a} - 2\eta \mathbf{a} = \mathbf{0},$$

ou

$$\Sigma \mathbf{a} = \eta \mathbf{a}. \quad (8.30)$$

Assim, as direções estacionárias do problema são autovetores de Σ , e os multiplicadores de Lagrange correspondentes são seus autovalores.

Para determiná-los,

$$\det(\Sigma - \eta \mathbf{I}_2) = 0.$$

Logo,

$$\begin{aligned} \det \begin{bmatrix} 4 - \eta & 2 \\ 2 & 4 - \eta \end{bmatrix} &= (4 - \eta)^2 - 4 \\ &= \eta^2 - 8\eta + 12 \\ &= (\eta - 6)(\eta - 2). \end{aligned}$$

Os autovalores são, portanto,

$$\lambda_1 = 6 \quad \text{e} \quad \lambda_2 = 2.$$

Para $\lambda_1 = 6$,

$$(\Sigma - 6\mathbf{I}_2) \mathbf{a} = \mathbf{0}$$

produz

$$a_1 = a_2.$$

Impondo a restrição de norma unitária,

$$a_1^2 + a_2^2 = 1,$$

podemos escolher

$$\mathbf{a}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Para $\lambda_2 = 2$,

$$(\Sigma - 2\mathbf{I}_2) \mathbf{a} = \mathbf{0}$$

produz

$$a_1 = -a_2,$$

e podemos escolher

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Pelo resultado dos extremos do quociente de Rayleigh em Teorema 5.5,

$$\max_{\|\mathbf{a}\|=1} \mathbf{a}^\top \Sigma \mathbf{a} = \lambda_1 = 6,$$

alcançado na direção $\mathbf{q}_1$, enquanto

$$\min_{\|\mathbf{a}\|=1} \mathbf{a}^\top \Sigma \mathbf{a} = \lambda_2 = 2,$$

alcançado na direção $\mathbf{q}_2$.

Consequentemente,

$$\text{Var}(\mathbf{q}_1^\top \mathbf{X}) = 6$$

e

$$\text{Var}(\mathbf{q}_2^\top \mathbf{X}) = 2.$$

Reunindo os autovetores em

$$\mathbf{Q} = [\mathbf{q}_1 \quad \mathbf{q}_2] = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix},$$

a transformação

$$\mathbf{Y} = \mathbf{Q}^\top (\mathbf{X} - \mu)$$

produz

$$\text{Cov}(\mathbf{Y}) = \mathbf{Q}^\top \Sigma \mathbf{Q} = \begin{bmatrix} 6 & 0 \\ 0 & 2 \end{bmatrix}.$$

O cálculo mostra concretamente a conexão entre **variância de uma combinação linear, otimização restrita e decomposição espectral**: os autovetores da matriz de covariâncias surgem como as direções estacionárias da variância sob a restrição de norma unitária, e os autovalores fornecem as variâncias nessas direções.

Neste ponto, o objetivo é somente compreender a geometria da matriz de covariâncias. A utilização dessas direções para construir uma técnica de redução de dimensionalidade será desenvolvida posteriormente na Análise de Componentes Principais.

Quando Σ é diagonal, os eixos espectrais coincidem com os eixos coordenados. No caso particular

$$\Sigma = \sigma^2 \mathbf{I}_p, \quad (8.31)$$

tem-se, para qualquer vetor unitário $\mathbf{a}$,

$$\mathbf{a}^\top \Sigma \mathbf{a} = \sigma^2.$$

A condição Equação 8.31 descreve uma estrutura de segunda ordem isotrópica: a variância é a mesma em todas as direções. Essa condição, isoladamente, não implica que a distribuição de $\mathbf{X}$ seja esfericamente simétrica.

Suponha agora que

$$\Sigma \succ \mathbf{0}.$$

Para $c > 0$, considere

$$\mathcal{E}_c = \left\{ \mathbf{x} \in \mathbb{R}^p : (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \leq c^2 \right\}. \quad (8.32)$$

A interpretação das superfícies de nível de formas quadráticas positivas definidas foi estabelecida no Capítulo 5. Neste caso, utilizando Equação 8.26 e definindo

$$\mathbf{y} = \mathbf{Q}^\top (\mathbf{x} - \mu),$$

a condição que define $\mathcal{E}_c$ torna-se

$$\sum_{j=1}^p \frac{y_j^2}{c^2 \lambda_j} \leq 1. \quad (8.33)$$

Portanto:

- o centro é μ ;
- os eixos possuem as direções $\mathbf{q}_1, \dots, \mathbf{q}_p$;
- o semieixo associado a $\mathbf{q}_j$ possui comprimento $c\sqrt{\lambda_j}$.

Assim, autovalores maiores correspondem a maior extensão da dispersão na direção associada.

A Figura 8.3 mostra essa geometria no caso bidimensional.




Figura 8.3: Elipse associada a uma matriz de covariâncias e seus eixos espectrais.

A orientação da elipse é determinada pelos autovetores, enquanto suas extensões dependem das raízes quadradas dos autovalores. A matriz de covariâncias determina, assim, uma geometria de segunda ordem para a dispersão conjunta.

Interpretação probabilística do elipsoide

O conjunto $\mathcal{E}_c$ é definido somente por μ e Σ . Sem uma hipótese adicional sobre a distribuição de $\mathbf{X}$, não se pode atribuir a esse elipsoide uma probabilidade específica nem interpretá-lo como região de confiança. A interpretação probabilística dessas superfícies será desenvolvida no Capítulo 9 para a distribuição normal multivariada.

Quando Σ é singular, a variabilidade está restrita ao subespaço

$$\mathcal{C}(\Sigma).$$

A raiz quadrada principal definida em Definição 5.9 permite representar o elipsoide degenerado por

$$\mathcal{E}_c^{(r)} = \left\{ \mu + \Sigma^{1/2} \mathbf{u} : \|\mathbf{u}\| \leq c \right\}, \quad (8.34)$$

em que

$$r = \text{posto}(\Sigma) < p.$$

Esse conjunto está contido no subespaço afim

$$\mu + \mathcal{C}(\Sigma)$$

e possui r semieixos não nulos, com comprimentos $c\sqrt{\lambda_j}$ para os autovalores positivos. A pseudoinversa será utilizada mais adiante para expressar a mesma geometria no contexto da distância de Mahalanobis.

8.5.2 Variância total, variância generalizada e volume

Uma matriz de covariâncias contém toda a estrutura de segunda ordem do vetor aleatório. Algumas funções escalares de Σ resumem aspectos específicos dessa dispersão, mas nenhuma delas substitui a matriz completa.

Definição 8.6 (Variância total). A **variância total** de $\mathbf{X} \in \mathbb{R}^p$ é

$$\text{VT}(\mathbf{X}) = \text{tr}(\Sigma). \quad (8.35)$$

Pela definição de traço em Definição 2.9,

$$\text{tr}(\Sigma) = \sum_{j=1}^p \text{Var}(X_j). \quad (8.36)$$

Pela decomposição espectral,

$$\text{tr}(\Sigma) = \sum_{j=1}^p \lambda_j. \quad (8.37)$$

A variância total também pode ser interpretada como a esperança do quadrado da distância euclidiana ao vetor de médias:

$$E[\|\mathbf{X} - \mu\|^2] = \text{tr}(\Sigma). \quad (8.38)$$

Essa medida reúne aditivamente as dispersões das componentes, ou de forma equivalente, as dispersões nos eixos espectrais.

Definição 8.7 (Variância média). A **variância média** é

$$\text{VM}(\mathbf{X}) = \frac{1}{p} \text{tr}(\Sigma) = \frac{1}{p} \sum_{j=1}^p \lambda_j.$$

A variância total e a variância média dependem das escalas das componentes. Quando as variáveis possuem unidades distintas, sua interpretação requer cautela.

Outra medida utiliza o determinante da matriz de covariâncias.

Definição 8.8 (Variância generalizada). A **variância generalizada** de $\mathbf{X}$ é

$$\text{VG}(\mathbf{X}) = \det(\Sigma). \quad (8.39)$$

Pelas propriedades do determinante e pela decomposição espectral,

$$\det(\Sigma) = \prod_{j=1}^p \lambda_j. \quad (8.40)$$

A variância generalizada reúne multiplicativamente as dispersões nos eixos espectrais. Se pelo menos um autovalor é zero,

$$\det(\Sigma) = 0,$$

mesmo que exista variabilidade nas demais direções. Nesse caso, o valor zero indica que a dispersão ocupa um subespaço de dimensão inferior a p ; não indica ausência de variabilidade.

A variância generalizada não deve ser confundida com o volume do elipsoide de covariância. A relação entre as duas quantidades envolve a raiz quadrada do determinante (Johnson; Wichern, 2007).

Proposição 8.9 (Volume do elipsoide de covariância). *Se $\Sigma \succ \mathbf{0}$, o volume p -dimensional do elipsoide $\mathcal{E}_c$ definido em Equação 8.32 é*

$$\text{Vol}_p(\mathcal{E}_c) = \kappa_p c^p \det(\Sigma)^{1/2}, \quad (8.41)$$

em que

$$\kappa_p = \frac{\pi^{p/2}}{\Gamma(p/2 + 1)}$$

é o volume da esfera unitária de $\mathbb{R}^p$.

Comprovação. O elipsoide é a imagem da bola

$$\mathcal{B}_c = \{\mathbf{u} \in \mathbb{R}^p : \|\mathbf{u}\| \leq c\}$$

pela transformação

$$\mathbf{x} = \mu + \Sigma^{1/2} \mathbf{u}.$$

A translação não altera o volume. Pelo Proposição 4.9, a transformação linear multiplica volumes por

$$|\det(\Sigma^{1/2})| = \det(\Sigma)^{1/2}.$$

Como

$$\text{Vol}_p(\mathcal{B}_c) = \kappa_p c^p,$$

obtem-se Equação 8.41. □

Portanto,

$$\det(\Sigma)^{1/2}$$

é o fator associado à escala de volume da dispersão, enquanto

$$\det(\Sigma)$$

é a variância generalizada.

Exemplo 8.12 (Variância total e variância generalizada). Considere

$$\Sigma_1 = \begin{bmatrix} 4 & 0 \\ 0 & 4 \end{bmatrix}$$

e

$$\Sigma_2 = \begin{bmatrix} 7 & 0 \\ 0 & 1 \end{bmatrix}.$$

As duas matrizes possuem a mesma variância total:

$$\text{tr}(\Sigma_1) = \text{tr}(\Sigma_2) = 8.$$

Entretanto,

$$\det(\Sigma_1) = 16$$

e

$$\det(\Sigma_2) = 7.$$

A primeira configuração distribui a variabilidade igualmente entre os dois eixos. A segunda concentra maior variabilidade em uma direção e menor variabilidade na outra. A igualdade das variâncias totais não implica, portanto, igualdade da geometria da dispersão.

As unidades também diferem entre essas medidas. Se as componentes possuem unidades

$$u_1, \dots, u_p,$$

a variância generalizada possui unidade

$$u_1^2 \cdots u_p^2,$$

enquanto

$$\det(\Sigma)^{1/2}$$

possui unidade

$$u_1 \cdots u_p,$$

compatível com uma medida de volume no espaço das variáveis.

Considere agora uma transformação linear quadrada

$$\mathbf{Y} = \mathbf{A}\mathbf{X}, \quad \mathbf{A} \in \mathbb{R}^{p \times p}.$$

Pela expressão Equação 8.18,

$$\Sigma_{YY} = \mathbf{A}\Sigma_{XX}\mathbf{A}^\top.$$

Consequentemente,

$$\det(\Sigma_{YY}) = \det(\mathbf{A})^2 \det(\Sigma_{XX}). \quad (8.42)$$

Para a escala de volume,

$$\det(\Sigma_{YY})^{1/2} = |\det(\mathbf{A})| \det(\Sigma_{XX})^{1/2}. \quad (8.43)$$

Essa expressão é compatível com o fator de alteração de volume desenvolvido em Proposição 4.9.

Quando $\mathbf{A}$ é ortogonal, $|\det(\mathbf{A})| = 1$ e a transformação preserva os autovalores de Σ . Consequentemente, preserva a variância total, a variância generalizada e os comprimentos dos semieixos do elipsoide, alterando somente sua orientação no sistema de coordenadas.

A forma quadrática que define o elipsoide fornece também uma medida de afastamento adaptada à estrutura de covariâncias. Essa medida é a distância de Mahalanobis.

8.6 Distância de Mahalanobis

A distância euclidiana utiliza a mesma geometria em todas as direções. Em dados multivariados, entretanto, um deslocamento pode representar um afastamento pequeno em uma direção de grande variabilidade e um afastamento expressivo em outra direção de pequena variabilidade.

A distância de Mahalanobis incorpora essa estrutura por meio da matriz de covariâncias. No caso univariado, ela reduz o afastamento $|x - \mu|$ à sua escala natural,

$$\frac{|x - \mu|}{\sigma}.$$

8.6.1 Geometria, branqueamento e invariância

Considere

$$\Sigma \succ \mathbf{0}.$$

Definição 8.9 (Distância de Mahalanobis). A **distância de Mahalanobis** entre $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, em relação a Σ , é

$$d_M(\mathbf{x}, \mathbf{y}; \Sigma) = \sqrt{(\mathbf{x} - \mathbf{y})^\top \Sigma^{-1} (\mathbf{x} - \mathbf{y})}. \quad (8.44)$$

Em particular, a distância de $\mathbf{x}$ ao vetor de médias é

$$d_M(\mathbf{x}, \mu) = \sqrt{(\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu)}. \quad (8.45)$$

Seu quadrado é

$$d_M^2(\mathbf{x}, \mu) = (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu). \quad (8.46)$$

Como $\Sigma^{-1} \succ \mathbf{0}$, ela define o produto interno induzido apresentado em Definição 3.16 e a norma correspondente de Definição 3.17. Assim, Equação 8.44 é uma distância métrica sem necessidade de repetir aqui a demonstração das propriedades métricas desenvolvidas no Módulo 1.

Quando

$$\Sigma = \mathbf{I}_p,$$

a distância de Mahalanobis coincide com a distância euclidiana. Quando $p = 1$,

$$d_M(x, \mu) = \frac{|x - \mu|}{\sigma}.$$

A medida é adimensional, pois a inversa da matriz de covariâncias compensa as unidades presentes no vetor de diferenças.

A interpretação espectral decorre diretamente de Equação 8.26. Se

$$\mathbf{u} = \mathbf{Q}^\top (\mathbf{x} - \mu),$$

então

$$d_M^2(\mathbf{x}, \mu) = \sum_{j=1}^p \frac{u_j^2}{\lambda_j}. \quad (8.47)$$

Cada deslocamento é, portanto, ponderado pelo inverso da variância na direção correspondente. Um mesmo deslocamento geométrico recebe menor peso em uma direção de grande variabilidade e maior peso em uma direção de pequena variabilidade.

Exemplo 8.13 (Afastamentos em direções com variâncias distintas). Considere dois eixos espectrais com

$$\lambda_1 = 9 \quad \text{e} \quad \lambda_2 = 1.$$

Um afastamento de magnitude 2 ao longo do primeiro eixo produz

$$d_M^2 = \frac{2^2}{9} = \frac{4}{9}.$$

O mesmo afastamento ao longo do segundo produz

$$d_M^2 = \frac{2^2}{1} = 4.$$

Os dois pontos possuem a mesma distância euclidiana ao centro, mas o segundo apresenta maior distância de Mahalanobis porque se encontra em uma direção com menor dispersão populacional.

A raiz quadrada inversa de uma matriz positiva definida foi construída no Capítulo 5 a partir da raiz quadrada principal de Definição 5.9. Aplicando-a à covariância, defina

$$\mathbf{z} = \Sigma^{-1/2} (\mathbf{x} - \mu). \quad (8.48)$$

Então,

$$\begin{aligned} \|\mathbf{z}\|^2 &= (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \\ &= d_M^2(\mathbf{x}, \mu). \end{aligned}$$

Logo,

$$d_M(\mathbf{x}, \mu) = \left\| \Sigma^{-1/2} (\mathbf{x} - \mu) \right\|. \quad (8.49)$$

A distância de Mahalanobis é, portanto, a distância euclidiana após centralização e branqueamento.

Para o vetor aleatório,

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu),$$

tem-se

$$\text{Cov}(\mathbf{Z}) = \mathbf{I}_p. \quad (8.50)$$

Exemplo 8.14 (Branqueamento a partir da decomposição espectral). Retome a matriz de covariâncias do Exemplo 8.11,

$$\Sigma = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}.$$

Sua decomposição espectral é

$$\Sigma = \mathbf{Q} \Lambda \mathbf{Q}^\top,$$

com

$$\mathbf{Q} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

e

$$\Lambda = \begin{bmatrix} 6 & 0 \\ 0 & 2 \end{bmatrix}.$$

Utilizando a raiz quadrada inversa desenvolvida no Módulo 1,

$$\Sigma^{-1/2} = \mathbf{Q}\Lambda^{-1/2}\mathbf{Q}^\top,$$

em que

$$\Lambda^{-1/2} = \begin{bmatrix} 1/\sqrt{6} & 0 \\ 0 & 1/\sqrt{2} \end{bmatrix}.$$

Defina

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu).$$

Então,

$$\begin{aligned} \text{Cov}(\mathbf{Z}) &= \Sigma^{-1/2} \Sigma \Sigma^{-1/2} \\ &= \mathbf{Q}\Lambda^{-1/2}\mathbf{Q}^\top \mathbf{Q}\Lambda\mathbf{Q}^\top \mathbf{Q}\Lambda^{-1/2}\mathbf{Q}^\top \\ &= \mathbf{Q}\Lambda^{-1/2}\Lambda\Lambda^{-1/2}\mathbf{Q}^\top \\ &= \mathbf{Q}\mathbf{I}_2\mathbf{Q}^\top \\ &= \mathbf{I}_2. \end{aligned}$$

A transformação atua, portanto, em três etapas conceituais:

$$\mathbf{X} - \mu \xrightarrow{\mathbf{Q}^\top} \text{coordenadas nos eixos espectrais}$$

$$\xrightarrow{\Lambda^{-1/2}} \text{reescalonamento para variância unitária}$$

$$\xrightarrow{\mathbf{Q}} \mathbf{Z}.$$

O primeiro passo elimina as covariâncias ao expressar o vetor na base de autovetores. O segundo divide cada coordenada pelo desvio-padrão correspondente, $\sqrt{\lambda_j}$. O terceiro retorna ao sistema original de coordenadas.

Considere agora um ponto cuja diferença em relação ao centro é

$$\mathbf{x} - \mu = \begin{bmatrix} 2 \\ 0 \end{bmatrix}.$$

Suas coordenadas espectrais são

$$\mathbf{Q}^\top (\mathbf{x} - \mu) = \begin{bmatrix} \sqrt{2} \\ \sqrt{2} \end{bmatrix}.$$

Pela expressão Equação 8.47,

$$\begin{aligned} d_M^2(\mathbf{x}, \mu) &= \frac{(\sqrt{2})^2}{6} + \frac{(\sqrt{2})^2}{2} \\ &= \frac{2}{6} + \frac{2}{2} \\ &= \frac{4}{3}. \end{aligned}$$

Por outro lado,

$$\left\| \Sigma^{-1/2} (\mathbf{x} - \mu) \right\|^2 = \frac{4}{3}.$$

Assim, o exemplo verifica concretamente a identidade

$$d_M(\mathbf{x}, \mu) = \left\| \Sigma^{-1/2} (\mathbf{x} - \mu) \right\|.$$

A decomposição espectral, a raiz matricial e a distância de Mahalanobis aparecem, portanto, como partes de uma mesma construção geométrica.

Essa escolha é denominada **branqueamento simétrico**. Ela remove simultaneamente as diferenças de variância e as covariâncias entre as componentes.

O branqueamento não é único. Se $\mathbf{Q}_0$ é ortogonal, então

$$\mathbf{Q}_0 \Sigma^{-1/2}$$

também transforma a matriz de covariâncias em $\mathbf{I}_p$. As diferentes versões diferem por uma transformação ortogonal e, portanto, preservam as distâncias euclidianas no espaço branqueado.

A padronização marginal e o branqueamento devem ser distinguidos. Pela expressão Equação 8.22, a padronização marginal produz

$$\text{Cov}(\mathbf{D}_\Sigma^{-1/2}(\mathbf{X} - \mu)) = \mathcal{R},$$

que pode possuir elementos fora da diagonal. O branqueamento utiliza a matriz completa $\Sigma^{-1/2}$ e produz covariância identidade.

Se

$$\mathbf{z}_D = \mathbf{D}_\Sigma^{-1/2}(\mathbf{x} - \mu),$$

a relação

$$\Sigma = \mathbf{D}_\Sigma^{1/2} \mathcal{R} \mathbf{D}_\Sigma^{1/2}$$

implica

$$d_M^2(\mathbf{x}, \mu) = \mathbf{z}_D^\top \mathcal{R}^{-1} \mathbf{z}_D. \quad (8.51)$$

Assim, a padronização marginal remove as escalas individuais, enquanto $\mathcal{R}^{-1}$ incorpora a associação linear remanescente. Somente quando

$$\mathcal{R} = \mathbf{I}_p$$

a distância de Mahalanobis coincide com a distância euclidiana entre as coordenadas marginalmente padronizadas.

As superfícies de igual distância,

$$d_M(\mathbf{x}, \mu) = c,$$

são exatamente as fronteiras dos elipsoides definidos em Equação 8.32.

A Figura 8.4 compara dois deslocamentos com a mesma distância euclidiana ao centro, mas orientados segundo eixos de dispersão distintos.

O ponto situado no eixo de menor variância pertence a uma curva de maior distância de Mahalanobis. A medida compara o deslocamento com a quantidade de variabilidade disponível na direção em que ele ocorre.

Outra propriedade decorre da transformação simultânea dos pontos e da matriz de covariâncias.




Figura 8.4: Pontos com a mesma distância euclidiana podem apresentar distâncias de Mahalanobis distintas.

Proposição 8.10 (Invariância afim da distância de Mahalanobis). *Considere*

$$\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b},$$

com $\mathbf{A} \in \mathbb{R}^{p \times p}$ invertível. Se

$$\mu_Y = \mathbf{A}\mu_X + \mathbf{b}$$

e

$$\Sigma_{YY} = \mathbf{A}\Sigma_{XX}\mathbf{A}^\top,$$

então

$$d_M(\mathbf{y}, \mu_Y; \Sigma_{YY}) = d_M(\mathbf{x}, \mu_X; \Sigma_{XX}). \quad (8.52)$$

Comprovação. Como

$$\mathbf{y} - \mu_Y = \mathbf{A}(\mathbf{x} - \mu_X)$$

e

$$\Sigma_{YY}^{-1} = \mathbf{A}^{-\top} \Sigma_{XX}^{-1} \mathbf{A}^{-1},$$

tem-se

$$\begin{aligned} d_M^2(\mathbf{y}, \mu_Y; \Sigma_{YY}) &= (\mathbf{x} - \mu_X)^\top \Sigma_{XX}^{-1} (\mathbf{x} - \mu_X). \end{aligned}$$

Como ambas as distâncias são não negativas, segue Equação 8.52. $\square$

A invariância exige que os pontos, o centro e a matriz de covariâncias sejam transformados de maneira compatível. Mudanças invertíveis de unidade, rotações e outras reparametrizações afins não alteram a distância resultante.

8.6.2 Covariância singular

A definição em Definição 8.9 utiliza Σ^{-1} e, portanto, exige

$$\Sigma \succ \mathbf{0}.$$

Quando Σ é singular, a pseudoinversa espectral definida em Definição 5.10 permite construir

$$d_{M,+}^2(\mathbf{x}, \mathbf{y}) = (\mathbf{x} - \mathbf{y})^\top \Sigma^+ (\mathbf{x} - \mathbf{y}). \quad (8.53)$$

Se

$$\Sigma = \mathbf{Q} \operatorname{diag}(\lambda_1, \dots, \lambda_r, 0, \dots, 0) \mathbf{Q}^\top,$$

com

$$\lambda_j > 0, \quad j = 1, \dots, r,$$

então

$$\Sigma^+ = \mathbf{Q} \operatorname{diag}(\lambda_1^{-1}, \dots, \lambda_r^{-1}, 0, \dots, 0) \mathbf{Q}^\top.$$

Para

$$\mathbf{u} = \mathbf{Q}^\top (\mathbf{x} - \mathbf{y}),$$

obtém-se

$$d_{M,+}^2(\mathbf{x}, \mathbf{y}) = \sum_{j=1}^r \frac{u_j^2}{\lambda_j}. \quad (8.54)$$

Somente as componentes do deslocamento pertencentes ao espaço de dispersão

$$\mathcal{C}(\Sigma)$$

contribuem para essa quantidade. As componentes pertencentes a

$$\mathcal{N}(\Sigma)$$

são anuladas pela pseudoinversa.

Interpretação no caso singular

Em todo o espaço $\mathbb{R}^p$, a expressão baseada em Σ^+ é uma **pseudodistância**. Dois pontos distintos podem apresentar valor zero quando sua diferença pertence a

$$\mathcal{N}(\Sigma).$$

Restrita ao subespaço efetivo

$$\mathcal{C}(\Sigma),$$

a forma quadrática torna-se positiva definida e a expressão define uma distância verdadeira.

Como Proposição 8.3 mostrou que

$$\mathbf{X} - \mu \in \mathcal{C}(\Sigma)$$

quase certamente quando Σ é singular, esse subespaço contém a variabilidade efetivamente presente na população.

A representação pela pseudoinversa também permite escrever o elipsoide degenerado de Equação 8.34 como

$$\mathcal{E}_c^{(r)} = \left\{ \mathbf{x} \in \mathbb{R}^p : \mathbf{x} - \mu \in \mathcal{C}(\Sigma), \quad (\mathbf{x} - \mu)^\top \Sigma^+ (\mathbf{x} - \mu) \leq c^2 \right\}. \quad (8.55)$$

A restrição ao espaço coluna é necessária, pois a pseudoinversa não penaliza deslocamentos nas direções de variância nula.

Neste capítulo, a distância de Mahalanobis é uma construção geométrica baseada na estrutura de segunda ordem de $\mathbf{X}$. No Capítulo 9, sob a distribuição normal multivariada, seu quadrado receberá uma distribuição probabilística específica.

Para dados observados, as estruturas populacionais Σ e $\mathcal{R}$ serão representadas por matrizes de produtos cruzados, covariâncias e correlações calculadas a partir das observações.

8.7 Representação descritiva a partir dos dados

As matrizes Σ e $\mathcal{R}$ são objetos populacionais. Quando se dispõe de um conjunto de dados observado, a localização e a dispersão conjunta podem ser representadas por quantidades calculadas diretamente a partir das observações.

Nesta seção,

$$\bar{\mathbf{x}}, \quad \mathbf{S} \quad \text{e} \quad \mathbf{R}$$

representam valores obtidos de uma matriz de dados específica. Quando as linhas dessa matriz forem consideradas realizações de uma amostra aleatória, esses valores corresponderão a realizações das estatísticas

$$\bar{\mathbf{X}}, \quad \mathbf{S} \quad \text{e} \quad \mathbf{R}.$$

As propriedades dessas estatísticas como estimadores serão desenvolvidas no Capítulo 10.

8.7.1 Centralização, SSCP e matriz de covariâncias observada

Considere $n \geq 2$ observações de p variáveis organizadas, conforme Definição 1.6, em

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p},$$

em que

$$\mathbf{x}_i \in \mathbb{R}^p$$

representa a i -ésima observação.

O vetor de médias das colunas é

$$\bar{\mathbf{x}} = \frac{1}{n} \mathbf{X}^\top \mathbf{1}_n \in \mathbb{R}^p, \quad (8.56)$$

em que

$$\mathbf{1}_n = (1, \dots, 1)^\top \in \mathbb{R}^n.$$

A matriz de dados centralizada é

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top. \quad (8.57)$$

Cada linha de $\mathbf{X}_c$ é

$$(\mathbf{x}_i - \bar{\mathbf{x}})^\top,$$

e suas colunas satisfazem

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{0}^\top. \quad (8.58)$$

Retomando a matriz de centralização utilizada no Capítulo 4,

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top,$$

tem-se

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}. \quad (8.59)$$

A operação remove a localização das colunas sem alterar as diferenças entre as observações, conforme a propriedade estabelecida em Proposição 4.15.

Definição 8.10 (Matriz total de somas de quadrados e produtos cruzados). A **matriz total de somas de quadrados e produtos cruzados**, ou matriz total SSCP, é

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

Equivalentemente,

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c = \mathbf{X}^\top \mathbf{H}_n \mathbf{X}. \quad (8.60)$$

A sigla SSCP deriva de *sum of squares and cross-products*. O elemento (j, k) de $\mathbf{T}$ é

$$t_{jk} = \sum_{i=1}^n (x_{ij} - \bar{x}_j) (x_{ik} - \bar{x}_k).$$

Quando $j = k$, t_{jj} é a soma dos quadrados dos desvios da variável j . Quando $j \neq k$, t_{jk} é a soma dos produtos cruzados entre as variáveis j e k .

Como

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c,$$

ela é uma matriz de Gram das colunas centralizadas no sentido de Definição 3.18. Assim, pelas propriedades estabelecidas em Proposição 3.9,

$$\mathbf{T} = \mathbf{T}^\top,$$

$$\mathbf{T} \succeq \mathbf{0}$$

e

$$\text{posto}(\mathbf{T}) = \text{posto}(\mathbf{X}_c).$$

A centralização impõe

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{0}^\top,$$

de modo que as colunas de $\mathbf{X}_c$ pertencem ao subespaço ortogonal a $\mathbf{1}_n$, cuja dimensão é $n - 1$. Consequentemente,

$$\text{posto}(\mathbf{T}) = \text{posto}(\mathbf{X}_c) \leq \min(p, n - 1). \quad (8.61)$$

A matriz $\mathbf{T}$ registra a dispersão sem uma normalização pelo número de observações.

Definição 8.11 (Matriz de covariâncias observada). A **matriz de covariâncias observada** é

$$\mathbf{S} = \frac{1}{n - 1} \mathbf{T}.$$

Equivalentemente,

$$\mathbf{S} = \frac{1}{n - 1} \mathbf{X}_c^\top \mathbf{X}_c = \frac{1}{n - 1} \mathbf{X}^\top \mathbf{H}_n \mathbf{X}. \quad (8.62)$$

Seu elemento (j, k) é

$$s_{jk} = \frac{1}{n - 1} \sum_{i=1}^n (x_{ij} - \bar{x}_j) (x_{ik} - \bar{x}_k). \quad (8.63)$$

Os elementos diagonais são as variâncias calculadas para as colunas,

$$s_{jj} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2,$$

e os elementos fora da diagonal são as covariâncias calculadas entre pares de colunas.

Como $\mathbf{S}$ é um múltiplo positivo de $\mathbf{T}$,

$$\mathbf{S} = \mathbf{S}^\top, \quad \mathbf{S} \succeq \mathbf{0}$$

e

$$\text{posto}(\mathbf{S}) = \text{posto}(\mathbf{T}) = \text{posto}(\mathbf{X}_c).$$

Portanto,

$$\text{posto}(\mathbf{S}) \leq \min(p, n-1). \quad (8.64)$$

Em particular, se

$$p \geq n,$$

então

$$\text{posto}(\mathbf{S}) \leq n-1 < p,$$

e $\mathbf{S}$ é necessariamente singular.

Essa singularidade decorre da dimensão dos dados centralizados. Suas consequências para estimação e regularização serão tratadas no Capítulo 10.

Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

tem-se

$$\begin{aligned} \mathbf{a}^\top \mathbf{S} \mathbf{a} &= \frac{1}{n-1} \mathbf{a}^\top \mathbf{X}_c^\top \mathbf{X}_c \mathbf{a} \\ &= \frac{1}{n-1} \|\mathbf{X}_c \mathbf{a}\|^2. \end{aligned} \quad (8.65)$$

O vetor $\mathbf{X}_c \mathbf{a}$ contém os valores centralizados da combinação linear das colunas determinada por $\mathbf{a}$. Portanto, Equação 8.65 é a contraparte descritiva de Equação 8.10.

O divisor $n - 1$ é utilizado aqui como convenção para a matriz de covariâncias observada. Sua relação com graus de liberdade, ausência de viés e máxima verossimilhança será estabelecida no Capítulo 10.

8.7.2 Matriz de correlações e covariâncias cruzadas observadas

Suponha que

$$s_{jj} > 0, \quad j = 1, \dots, p.$$

Defina a matriz diagonal das variâncias observadas por

$$\mathbf{D}_S = \text{diag}(s_{11}, \dots, s_{pp}). \quad (8.66)$$

Definição 8.12 (Matriz de correlações observada). A **matriz de correlações observada** é

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}. \quad (8.67)$$

Seu elemento (j, k) é

$$r_{jk} = \frac{s_{jk}}{\sqrt{s_{jj}s_{kk}}}. \quad (8.68)$$

A matriz $\mathbf{R}$ é simétrica, positiva semidefinida e possui diagonal unitária. Como $\mathbf{D}_S^{-1/2}$ é invertível,

$$\text{posto}(\mathbf{R}) = \text{posto}(\mathbf{S}).$$

Em particular,

$$\mathbf{R} \succ \mathbf{0} \iff \mathbf{S} \succ \mathbf{0}.$$

A relação inversa é

$$\mathbf{S} = \mathbf{D}_S^{1/2} \mathbf{R} \mathbf{D}_S^{1/2}. \quad (8.69)$$

Defina agora a matriz das colunas centralizadas e padronizadas,

$$\mathbf{Z} = \mathbf{X}_c \mathbf{D}_S^{-1/2} \in \mathbb{R}^{n \times p}. \quad (8.70)$$

Então,

$$\begin{aligned} \frac{1}{n-1} \mathbf{Z}^\top \mathbf{Z} &= \frac{1}{n-1} \mathbf{D}_S^{-1/2} \mathbf{X}_c^\top \mathbf{X}_c \mathbf{D}_S^{-1/2} \\ &= \mathbf{R}. \end{aligned}$$

Portanto,

$$\mathbf{R} = \frac{1}{n-1} \mathbf{Z}^\top \mathbf{Z}. \quad (8.71)$$

A expressão Equação 8.71 mostra que $\mathbf{R}$ é, a menos do fator $1/(n-1)$, uma matriz de Gram das colunas padronizadas.

Exemplo 8.15 (Da matriz de dados às matrizes de covariâncias e correlações). Considere quatro observações de duas variáveis organizadas na matriz

$$\mathbf{X} = \begin{bmatrix} 1 & 2 \\ 2 & 1 \\ 3 & 4 \\ 4 & 3 \end{bmatrix}.$$

Aqui,

$$n = 4 \quad \text{e} \quad p = 2.$$

O vetor de médias das colunas é

$$\bar{\mathbf{x}} = \frac{1}{4} \mathbf{X}^\top \mathbf{1}_4 = \begin{bmatrix} 2,5 \\ 2,5 \end{bmatrix}.$$

Portanto, a matriz centralizada é

$$\begin{aligned} \mathbf{X}_c &= \mathbf{X} - \mathbf{1}_4 \bar{\mathbf{x}}^\top \\ &= \begin{bmatrix} -1,5 & -0,5 \\ -0,5 & -1,5 \\ 0,5 & 1,5 \\ 1,5 & 0,5 \end{bmatrix}. \end{aligned}$$

A matriz total de somas de quadrados e produtos cruzados é

$$\begin{aligned}\mathbf{T} &= \mathbf{X}_c^\top \mathbf{X}_c \\ &= \begin{bmatrix} 5 & 3 \\ 3 & 5 \end{bmatrix}.\end{aligned}$$

Os elementos diagonais são as somas dos quadrados dos desvios de cada variável. O elemento fora da diagonal é a soma dos produtos cruzados.

Como

$$n - 1 = 3,$$

a matriz de covariâncias observada é

$$\begin{aligned}\mathbf{S} &= \frac{1}{3} \mathbf{T} \\ &= \begin{bmatrix} 5/3 & 1 \\ 1 & 5/3 \end{bmatrix}.\end{aligned}$$

Assim,

$$s_{11} = s_{22} = \frac{5}{3}$$

e

$$s_{12} = 1.$$

A matriz diagonal das variâncias observadas é

$$\mathbf{D}_S = \begin{bmatrix} 5/3 & 0 \\ 0 & 5/3 \end{bmatrix}.$$

Como as duas variâncias são iguais,

$$\mathbf{D}_S^{-1/2} = \sqrt{\frac{3}{5}} \mathbf{I}_2.$$

Logo,

$$\begin{aligned}
\mathbf{R} &= \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2} \\
&= \begin{bmatrix} 1 & 3/5 \\ 3/5 & 1 \end{bmatrix} \\
&= \begin{bmatrix} 1 & 0,6 \\ 0,6 & 1 \end{bmatrix}.
\end{aligned}$$

Também podemos obter diretamente a correlação entre as duas colunas:

$$r_{12} = \frac{s_{12}}{\sqrt{s_{11}s_{22}}} = \frac{1}{\sqrt{(5/3)(5/3)}} = \frac{3}{5} = 0,6.$$

O exemplo resume a cadeia de construção descritiva desenvolvida nesta seção:

$$\mathbf{X} \longrightarrow \bar{\mathbf{x}} \longrightarrow \mathbf{X}_c \longrightarrow \mathbf{T} \longrightarrow \mathbf{S} \longrightarrow \mathbf{R}.$$

Nesse ponto, $\bar{\mathbf{x}}$, $\mathbf{S}$ e $\mathbf{R}$ são valores calculados a partir da matriz de dados observada. Sua interpretação como realizações de estatísticas amostrais e suas propriedades inferenciais serão desenvolvidas no Capítulo 10.

Se $\mathbf{z}_{.j}$ representa a coluna j de $\mathbf{Z}$, então

$$\|\mathbf{z}_{.j}\|^2 = n - 1.$$

Consequentemente,

$$r_{jk} = \frac{\mathbf{z}_{.j}^\top \mathbf{z}_{.k}}{\|\mathbf{z}_{.j}\| \|\mathbf{z}_{.k}\|}. \quad (8.72)$$

Assim, a correlação observada entre duas variáveis é o cosseno do ângulo entre suas colunas centralizadas e padronizadas no espaço das observações. Essa interpretação utiliza diretamente a geometria de produtos internos desenvolvida no Módulo 1.

A representação descritiva também se estende a dois blocos de variáveis. Considere

$$\mathbf{X} \in \mathbb{R}^{n \times p} \quad \text{e} \quad \mathbf{Y} \in \mathbb{R}^{n \times q},$$

cujas linhas correspondem às mesmas n unidades observacionais. Se

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}$$

e

$$\mathbf{Y}_c = \mathbf{H}_n \mathbf{Y},$$

define-se:

Definição 8.13 (Matriz de covariâncias cruzadas observada). A **matriz de covariâncias cruzadas observada** entre os blocos $\mathbf{X}$ e $\mathbf{Y}$ é

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{Y}_c.$$

Equivalentemente,

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{X}^\top \mathbf{H}_n \mathbf{Y} \in \mathbb{R}^{p \times q}. \quad (8.73)$$

Sua orientação satisfaz

$$\mathbf{S}_{YX} = \mathbf{S}_{XY}^\top. \quad (8.74)$$

Para

$$\mathbf{a} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{b} \in \mathbb{R}^q,$$

a covariância observada entre as combinações

$$\mathbf{u} = \mathbf{X}\mathbf{a}$$

e

$$\mathbf{v} = \mathbf{Y}\mathbf{b}$$

é

$$s_{uv} = \mathbf{a}^\top \mathbf{S}_{XY} \mathbf{b}. \quad (8.75)$$

A expressão Equação 8.75 é a contraparte descritiva de Equação 8.14.

Se as duas matrizes forem concatenadas,

$$[\mathbf{X} \quad \mathbf{Y}],$$

a matriz de covariâncias observada correspondente possui a estrutura

$$\begin{bmatrix} \mathbf{S}_{XX} & \mathbf{S}_{XY} \\ \mathbf{S}_{YX} & \mathbf{S}_{YY} \end{bmatrix}. \quad (8.76)$$

Os blocos diagonais descrevem a dispersão interna de cada conjunto de variáveis, enquanto os blocos fora da diagonal registram as covariâncias entre os dois conjuntos.

A matriz $\mathbf{T}$ descreve a dispersão conjunta de todas as observações em torno de $\bar{\mathbf{x}}$. Quando as observações pertencem a grupos previamente identificados, essa dispersão admite uma decomposição adicional.

8.8 Decomposição da dispersão por grupos

Considere as n observações distribuídas em G grupos não vazios. O grupo g contém n_g observações, com

$$n_1 + \cdots + n_G = n.$$

Represente a observação i do grupo g por

$$\mathbf{x}_{ig} \in \mathbb{R}^p, \quad i = 1, \dots, n_g, \quad g = 1, \dots, G.$$

O vetor de médias do grupo g é

$$\bar{\mathbf{x}}_g = \frac{1}{n_g} \sum_{i=1}^{n_g} \mathbf{x}_{ig}. \quad (8.77)$$

A média total satisfaz

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{g=1}^G \sum_{i=1}^{n_g} \mathbf{x}_{ig} = \frac{1}{n} \sum_{g=1}^G n_g \bar{\mathbf{x}}_g. \quad (8.78)$$

A dispersão total pode ser separada em:

- dispersão das observações em torno das médias de seus grupos;
- dispersão das médias dos grupos em torno da média total.

8.8.1 Dispersão total, intragrupos e entre grupos

A matriz total é

$$\mathbf{T} = \sum_{g=1}^G \sum_{i=1}^{n_g} (\mathbf{x}_{ig} - \bar{\mathbf{x}}) (\mathbf{x}_{ig} - \bar{\mathbf{x}})^\top. \quad (8.79)$$

Definição 8.14 (Matriz de dispersão intragrupos). A **matriz de dispersão intragrupos** é

$$\mathbf{T}_{\text{intra}} = \sum_{g=1}^G \sum_{i=1}^{n_g} (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g) (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g)^\top \in \mathbb{R}^{p \times p}. \quad (8.80)$$

Cada termo mede o afastamento de uma observação em relação ao centro de seu próprio grupo.

Definição 8.15 (Matriz de dispersão entre grupos). A **matriz de dispersão entre grupos** é

$$\mathbf{T}_{\text{entre}} = \sum_{g=1}^G n_g (\bar{\mathbf{x}}_g - \bar{\mathbf{x}}) (\bar{\mathbf{x}}_g - \bar{\mathbf{x}})^\top \in \mathbb{R}^{p \times p}. \quad (8.81)$$

A ponderação por n_g registra o número de observações representadas por cada média de grupo.

Proposição 8.11 (Decomposição da dispersão total). *Para qualquer partição das n observações em G grupos não vazios,*

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}. \quad (8.82)$$

Comprovação. Para uma observação do grupo g ,

$$\mathbf{x}_{ig} - \bar{\mathbf{x}} = (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g) + (\bar{\mathbf{x}}_g - \bar{\mathbf{x}}).$$

Ao formar o produto externo e somar sobre as observações, surgem duas parcelas quadráticas e dois termos cruzados. Para cada grupo,

$$\sum_{i=1}^{n_g} (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g) = \mathbf{0}.$$

Consequentemente, os termos cruzados desaparecem. A soma das primeiras parcelas produz $\mathbf{T}_{\text{intra}}$, enquanto

$$\sum_{i=1}^{n_g} (\bar{\mathbf{x}}_g - \bar{\mathbf{x}}) (\bar{\mathbf{x}}_g - \bar{\mathbf{x}})^\top = n_g (\bar{\mathbf{x}}_g - \bar{\mathbf{x}}) (\bar{\mathbf{x}}_g - \bar{\mathbf{x}})^\top.$$

Somando sobre os grupos, obtém-se

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}.$$

□

Exemplo 8.16 (Decomposição da dispersão em dois grupos). Considere quatro observações de duas variáveis, distribuídas em dois grupos:

Grupo	X_1	X_2
1	1	1
1	3	1
2	3	5
2	5	5

Assim,

$$n_1 = n_2 = 2, \quad n = 4, \quad G = 2.$$

As médias dos grupos são

$$\bar{\mathbf{x}}_1 = \frac{1}{2} \left[\begin{bmatrix} 1 \\ 1 \end{bmatrix} + \begin{bmatrix} 3 \\ 1 \end{bmatrix} \right] = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

e

$$\bar{\mathbf{x}}_2 = \frac{1}{2} \left[\begin{bmatrix} 3 \\ 5 \end{bmatrix} + \begin{bmatrix} 5 \\ 5 \end{bmatrix} \right] = \begin{bmatrix} 4 \\ 5 \end{bmatrix}.$$

A média total é

$$\begin{aligned} \bar{\mathbf{x}} &= \frac{1}{4} \left[\begin{bmatrix} 1 \\ 1 \end{bmatrix} + \begin{bmatrix} 3 \\ 1 \end{bmatrix} + \begin{bmatrix} 3 \\ 5 \end{bmatrix} + \begin{bmatrix} 5 \\ 5 \end{bmatrix} \right] \\ &= \begin{bmatrix} 3 \\ 3 \end{bmatrix}. \end{aligned}$$

Podemos agora calcular separadamente as três matrizes da decomposição.

Dispersão intragrupos.

No primeiro grupo,

$$\mathbf{x}_{11} - \bar{\mathbf{x}}_1 = \begin{bmatrix} -1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{x}_{21} - \bar{\mathbf{x}}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Sua contribuição para a dispersão intragrupos é

$$\begin{aligned} \mathbf{T}_{\text{intra},1} &= \begin{bmatrix} -1 \\ 0 \end{bmatrix} \begin{bmatrix} -1 & 0 \end{bmatrix} + \begin{bmatrix} 1 \\ 0 \end{bmatrix} \begin{bmatrix} 1 & 0 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}. \end{aligned}$$

No segundo grupo,

$$\mathbf{x}_{12} - \bar{\mathbf{x}}_2 = \begin{bmatrix} -1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{x}_{22} - \bar{\mathbf{x}}_2 = \begin{bmatrix} 1 \\ 0 \end{bmatrix},$$

de modo que

$$\mathbf{T}_{\text{intra},2} = \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}.$$

Portanto,

$$\begin{aligned} \mathbf{T}_{\text{intra}} &= \mathbf{T}_{\text{intra},1} + \mathbf{T}_{\text{intra},2} \\ &= \begin{bmatrix} 4 & 0 \\ 0 & 0 \end{bmatrix}. \end{aligned} \tag{8.83}$$

Toda a dispersão dentro dos grupos ocorre, neste exemplo, na primeira variável. A segunda variável é constante dentro de cada grupo.

Dispersão entre grupos.

Os afastamentos das médias dos grupos em relação à média total são

$$\bar{\mathbf{x}}_1 - \bar{\mathbf{x}} = \begin{bmatrix} -1 \\ -2 \end{bmatrix}$$

e

$$\bar{\mathbf{x}}_2 - \bar{\mathbf{x}} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

Como ambos os grupos possuem duas observações,

$$\begin{aligned} \mathbf{T}_{\text{entre}} &= 2 \begin{bmatrix} -1 \\ -2 \end{bmatrix} \begin{bmatrix} -1 & -2 \end{bmatrix} + 2 \begin{bmatrix} 1 \\ 2 \end{bmatrix} \begin{bmatrix} 1 & 2 \end{bmatrix} \\ &= 2 \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} + 2 \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} \\ &= \begin{bmatrix} 4 & 8 \\ 8 & 16 \end{bmatrix}. \end{aligned} \tag{8.84}$$

Nesse caso, a diferença entre os centros dos grupos envolve simultaneamente as duas variáveis.

Dispersão total.

Calculando diretamente os desvios das quatro observações em relação a

$$\bar{\mathbf{x}} = \begin{bmatrix} 3 \\ 3 \end{bmatrix},$$

obtém-se

$$\begin{aligned} \mathbf{T} &= \begin{bmatrix} -2 \\ -2 \end{bmatrix} \begin{bmatrix} -2 & -2 \end{bmatrix} + \begin{bmatrix} 0 \\ -2 \end{bmatrix} \begin{bmatrix} 0 & -2 \end{bmatrix} \\ &\quad + \begin{bmatrix} 0 \\ 2 \end{bmatrix} \begin{bmatrix} 0 & 2 \end{bmatrix} + \begin{bmatrix} 2 \\ 2 \end{bmatrix} \begin{bmatrix} 2 & 2 \end{bmatrix} \\ &= \begin{bmatrix} 8 & 8 \\ 8 & 16 \end{bmatrix}. \end{aligned} \tag{8.85}$$

A identidade Equação 8.82 pode então ser verificada diretamente:

$$\begin{aligned}
\mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}} &= \begin{bmatrix} 4 & 0 \\ 0 & 0 \end{bmatrix} + \begin{bmatrix} 4 & 8 \\ 8 & 16 \end{bmatrix} \\
&= \begin{bmatrix} 8 & 8 \\ 8 & 16 \end{bmatrix} \\
&= \mathbf{T}.
\end{aligned}$$

A decomposição também pode ser examinada em direções específicas. Para

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix},$$

que seleciona a primeira variável,

$$\mathbf{a}_1^\top \mathbf{T} \mathbf{a}_1 = 8,$$

com

$$\mathbf{a}_1^\top \mathbf{T}_{\text{intra}} \mathbf{a}_1 = 4$$

e

$$\mathbf{a}_1^\top \mathbf{T}_{\text{entre}} \mathbf{a}_1 = 4.$$

Assim,

$$8 = 4 + 4.$$

Metade da dispersão de X_1 decorre de diferenças dentro dos grupos e metade das diferenças entre seus centros.

Para

$$\mathbf{a}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix},$$

que seleciona a segunda variável,

$$\mathbf{a}_2^\top \mathbf{T} \mathbf{a}_2 = 16,$$

enquanto

$$\mathbf{a}_2^\top \mathbf{T}_{\text{intra}} \mathbf{a}_2 = 0$$

e

$$\mathbf{a}_2^\top \mathbf{T}_{\text{entre}} \mathbf{a}_2 = 16.$$

Portanto,

$$16 = 0 + 16.$$

A variável X_2 não apresenta dispersão dentro dos grupos neste conjunto de dados; toda a sua dispersão total está associada à diferença entre as médias dos dois grupos.

O exemplo mostra que a identidade

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

expressa simultaneamente a decomposição da dispersão em todas as direções. Para qualquer combinação linear das variáveis, a dispersão total dessa combinação também se decompõe nas parcelas intragrupos e entre grupos, conforme Equação 8.86.

A identidade Equação 8.82 é algébrica e depende somente da partição das observações e das definições das médias total e de grupo (Rencher; Christensen, 2012). Normalidade, independência e outros pressupostos probabilísticos não são necessários para estabelecê-la.

Para qualquer direção

$$\mathbf{a} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{a}^\top \mathbf{T} \mathbf{a} = \mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a} + \mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}. \quad (8.86)$$

Se

$$y_{ig} = \mathbf{a}^\top \mathbf{x}_{ig},$$

então Equação 8.86 corresponde exatamente à decomposição univariada

$$\sum_{g=1}^G \sum_{i=1}^{n_g} (y_{ig} - \bar{y})^2 = \sum_{g=1}^G \sum_{i=1}^{n_g} (y_{ig} - \bar{y}_g)^2 + \sum_{g=1}^G n_g (\bar{y}_g - \bar{y})^2. \quad (8.87)$$

A decomposição matricial reúne simultaneamente essa identidade para todas as combinações lineares das variáveis.

8.8.2 Propriedades e limites de posto

Proposição 8.12 (Estrutura das matrizes de dispersão por grupos). *As matrizes*

$$\mathbf{T}, \quad \mathbf{T}_{\text{intra}} \quad e \quad \mathbf{T}_{\text{entre}}$$

são simétricas e positivas semidefinidas. Além disso,

$$\mathbf{0} \preceq \mathbf{T}_{\text{intra}} \preceq \mathbf{T}$$

e

$$\mathbf{0} \preceq \mathbf{T}_{\text{entre}} \preceq \mathbf{T}.$$

Seus postos satisfazem

$$\text{posto}(\mathbf{T}) \leq \min(p, n - 1),$$

$$\text{posto}(\mathbf{T}_{\text{intra}}) \leq \min(p, n - G), \quad (8.88)$$

e

$$\text{posto}(\mathbf{T}_{\text{entre}}) \leq \min(p, G - 1). \quad (8.89)$$

Comprovação. Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a} = \sum_{g=1}^G \sum_{i=1}^{n_g} [\mathbf{a}^\top (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g)]^2 \geq 0$$

e

$$\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a} = \sum_{g=1}^G n_g \left[\mathbf{a}^\top (\bar{\mathbf{x}}_g - \bar{\mathbf{x}}) \right]^2 \geq 0.$$

Logo, as duas parcelas são positivas semidefinidas. Pela identidade Equação 8.82,

$$\mathbf{T} - \mathbf{T}_{\text{intra}} = \mathbf{T}_{\text{entre}} \succeq \mathbf{0}$$

e

$$\mathbf{T} - \mathbf{T}_{\text{entre}} = \mathbf{T}_{\text{intra}} \succeq \mathbf{0},$$

o que estabelece as relações na ordem de Loewner.

O limite para $\mathbf{T}$ foi obtido em Equação 8.61.

Dentro do grupo g , os n_g vetores centralizados satisfazem

$$\sum_{i=1}^{n_g} (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g) = \mathbf{0}.$$

Assim, os vetores centralizados desse grupo geram um subespaço de dimensão no máximo $n_g - 1$. Considerando todos os grupos,

$$\sum_{g=1}^G (n_g - 1) = n - G,$$

e, portanto,

$$\text{posto}(\mathbf{T}_{\text{intra}}) \leq \min(p, n - G).$$

Para a parcela entre grupos,

$$\sum_{g=1}^G n_g (\bar{\mathbf{x}}_g - \bar{\mathbf{x}}) = \mathbf{0}.$$

Os G vetores

$$\sqrt{n_g} (\bar{\mathbf{x}}_g - \bar{\mathbf{x}})$$

geram, portanto, um subespaço de dimensão no máximo $G - 1$. Consequentemente,

$$\text{posto}(\mathbf{T}_{\text{entre}}) \leq \min(p, G - 1).$$

□

Os limites podem ser estritos quando existem relações lineares adicionais entre as variáveis ou entre os vetores de médias dos grupos.

As relações na ordem de Loewner implicam, para qualquer direção $\mathbf{a}$,

$$0 \leq \mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a} \leq \mathbf{a}^\top \mathbf{T} \mathbf{a}$$

e

$$0 \leq \mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a} \leq \mathbf{a}^\top \mathbf{T} \mathbf{a}.$$

Assim, a dispersão intragrupos ou entre grupos em uma direção não pode exceder a dispersão total na mesma direção.

Dois casos extremos auxiliam a interpretação. Se

$$\bar{\mathbf{x}}_1 = \cdots = \bar{\mathbf{x}}_G = \bar{\mathbf{x}},$$

então

$$\mathbf{T}_{\text{entre}} = \mathbf{0}.$$

Se, por outro lado, todas as observações de cada grupo coincidem com a respectiva média,

$$\mathbf{x}_{ig} = \bar{\mathbf{x}}_g,$$

então

$$\mathbf{T}_{\text{intra}} = \mathbf{0}.$$

Neste capítulo, a identidade

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

é utilizada exclusivamente como decomposição descritiva da dispersão observada. No Capítulo 11, uma estrutura correspondente será obtida a partir do modelo linear multivariado e de matrizes de projeção. Graus de liberdade, estimadores de covariâncias residuais e hipóteses lineares pertencem àquele contexto.

8.9 Síntese do capítulo

A matriz de covariâncias

$$\Sigma = \text{Cov}(\mathbf{X})$$

representa a estrutura de segunda ordem de um vetor aleatório. Sua diagonal contém as variâncias das componentes, e seus elementos fora da diagonal registram covariâncias. Para qualquer combinação linear,

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a},$$

de modo que a matriz de covariâncias determina a dispersão em todas as direções.

A padronização marginal conduz à matriz de correlações

$$\mathcal{R} = \mathbf{D}_\Sigma^{-1/2} \Sigma \mathbf{D}_\Sigma^{-1/2},$$

que preserva a estrutura de associação linear após a retirada das escalas marginais.

A decomposição espectral de Σ fornece eixos ortogonais de dispersão, enquanto o traço e o determinante produzem resumos escalares distintos. A variância total é

$$\text{tr}(\Sigma),$$

e a variância generalizada é

$$\det(\Sigma).$$

Quando $\Sigma \succ \mathbf{0}$, a distância de Mahalanobis

$$d_M^2(\mathbf{x}, \mu) = (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu)$$

mede afastamentos levando em conta simultaneamente escalas e covariâncias. Após o branqueamento, essa distância torna-se euclidiana.

No nível descritivo, as mesmas estruturas são representadas por

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c, \quad \mathbf{S} = \frac{1}{n-1} \mathbf{T}$$

e

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}.$$

Quando as observações estão organizadas em grupos,

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

separa a dispersão observada dentro dos grupos da dispersão associada às diferenças entre seus centros.

A Tabela 8.1 reúne os principais objetos do capítulo.

Tabela 8.1: Principais objetos desenvolvidos no capítulo.

Nível	Objeto	Símbolo	Função
Populacional	vetor de médias	μ	localização
Populacional	matriz de covariâncias	Σ	dispersão conjunta
Populacional	matriz de correlações	$\mathcal{R}$	associação linear padronizada
Populacional	covariância cruzada	Σ_{XY}	associação linear entre blocos
Geométrico	distância de Mahalanobis	d_M	afastamento ajustado à dispersão
Dados observados	média	$\bar{\mathbf{x}}$	centro das observações
Dados observados	SSCP	$\mathbf{T}$	dispersão não normalizada
Dados observados	covariância	$\mathbf{S}$	dispersão calculada dos dados
Dados observados	correlação	$\mathbf{R}$	associação linear padronizada nos dados

Nível	Objeto	Símbolo	Função
Dados agrupados	decomposição	$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$	separação da dispersão por grupos

Ao final deste capítulo, o estudante deverá ser capaz de:

- representar a variabilidade conjunta por matrizes de covariâncias e correlações;
- calcular e interpretar variâncias e covariâncias de combinações lineares;
- reconhecer as condições estruturais, a singularidade e o posto de matrizes de covariâncias e correlações;
- interpretar a geometria espectral, a variância generalizada e a distância de Mahalanobis;
- distinguir parâmetros populacionais, estatísticas amostrais e valores calculados de dados observados;
- decompor a dispersão observada em parcelas total, intragrupos e entre grupos.

A matriz de covariâncias descreve a estrutura de segunda ordem de um vetor aleatório, mas, em geral, não determina sua distribuição conjunta. O próximo capítulo introduz a **Distribuição Normal Multivariada**, na qual o vetor de médias e a matriz de covariâncias determinam a distribuição. Serão desenvolvidas suas distribuições marginais e condicionais e, no caso não singular, sua função densidade, relacionando a estrutura probabilística à geometria construída neste capítulo.

9 Distribuição Normal Multivariada

O Capítulo 8 desenvolveu o vetor de médias, a matriz de covariâncias e a geometria da dispersão de um vetor aleatório. Em uma distribuição geral, esses dois primeiros momentos não determinam completamente a distribuição conjunta. Diferentes distribuições podem possuir o mesmo vetor de médias e a mesma matriz de covariâncias.

Na família normal multivariada, o vetor de médias e a matriz de covariâncias determinam a distribuição. Além disso, transformações afins e distribuições marginais permanecem normais, e a estrutura de covariâncias assume consequências probabilísticas específicas, como a equivalência entre não correlação e independência para componentes conjuntamente normais.

O objetivo deste capítulo é construir a distribuição normal multivariada e relacionar suas propriedades probabilísticas à estrutura desenvolvida no capítulo anterior. Serão considerados os casos não singular e singular, a função densidade, as distribuições marginais e condicionais, a independência entre blocos, a padronização, o branqueamento e a distribuição da distância quadrática de Mahalanobis.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{X} \in \mathbb{R}^p$ representa um vetor aleatório e $\mathbf{x} \in \mathbb{R}^p$ uma de suas realizações;
- $\boldsymbol{\mu} \in \mathbb{R}^p$ representa o vetor de médias populacional;
- $\boldsymbol{\Sigma} \in \mathbb{R}^{p \times p}$ representa a matriz de covariâncias populacional;
- $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ indica uma distribuição normal multivariada de dimensão p , parametrizada pelo vetor de médias e pela matriz de covariâncias;
- $\mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I}_p)$ representa um vetor normal multivariado padrão;
- $\mathbf{D}_{\boldsymbol{\Sigma}} = \text{diag}(\sigma_{11}, \dots, \sigma_{pp})$ representa a matriz diagonal das variâncias marginais;
- $\sigma_j = \sqrt{\sigma_{jj}}$ representa o desvio-padrão marginal da componente X_j ;
- $\mathcal{R}$ representa a matriz de correlações populacional;
- $\mathbf{X}_1$ e $\mathbf{X}_2$ representam blocos de um vetor normal particionado, com matrizes de covariâncias $\boldsymbol{\Sigma}_{11}$ e $\boldsymbol{\Sigma}_{22}$ e covariâncias cruzadas $\boldsymbol{\Sigma}_{12}$ e $\boldsymbol{\Sigma}_{21}$;
- $\boldsymbol{\Sigma}_{11.2}$ representa o complemento de Schur de $\boldsymbol{\Sigma}_{22}$ em $\boldsymbol{\Sigma}$;
- $d_M^2(\mathbf{x}, \boldsymbol{\mu})$ representa a distância quadrática de Mahalanobis de um ponto fixo $\mathbf{x}$ ao centro populacional;
- D_M^2 representa a distância quadrática de Mahalanobis considerada como variável aleatória;
- $\boldsymbol{\Sigma}^+$ representa a pseudoinversa de Moore–Penrose no caso singular;

- $\chi^2_{p;1-\alpha}$ representa o quantil de ordem $1 - \alpha$ da distribuição qui-quadrado com p graus de liberdade.

Quando uma normal univariada possui variância zero, ela é entendida como uma distribuição degenerada concentrada em sua média.

As convenções estabelecidas nos capítulos anteriores para posto, núcleo, espaço coluna, matrizes positivas semidefinidas, decomposição espectral, raízes matriciais, transformações afins, complemento de Schur e distância de Mahalanobis permanecem válidas.

9.1 Definição e construção

9.1.1 Definição por combinações lineares

Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix} \in \mathbb{R}^p,$$

com

$$E(\mathbf{X}) = \mu$$

e

$$\text{Cov}(\mathbf{X}) = \Sigma.$$

Uma maneira de caracterizar a normalidade multivariada é examinar todas as projeções lineares do vetor. Essa caracterização inclui o caso em que alguma combinação linear possui variância zero (Eaton, 2007).

Definição 9.1 (Distribuição normal multivariada). O vetor aleatório $\mathbf{X} \in \mathbb{R}^p$ possui **distribuição normal multivariada** se, para todo vetor constante $\mathbf{a} \in \mathbb{R}^p$, a combinação linear

$$\mathbf{a}^\top \mathbf{X}$$

possui distribuição normal univariada, admitindo-se o caso degenerado de variância zero.

Quando

$$E(\mathbf{X}) = \mu$$

e

$$\text{Cov}(\mathbf{X}) = \Sigma,$$

escreve-se

$$\mathbf{X} \sim N_p(\mu, \Sigma). \quad (9.1)$$

Pelos resultados do Capítulo 8, para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \mu$$

e

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

Portanto,

$$\mathbf{a}^\top \mathbf{X} \sim N(\mathbf{a}^\top \mu, \mathbf{a}^\top \Sigma \mathbf{a}). \quad (9.2)$$

Se

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0,$$

então

$$\mathbf{a}^\top \mathbf{X} = \mathbf{a}^\top \mu$$

com probabilidade 1.

Escolhendo $\mathbf{a} = \mathbf{e}_j$, em que $\mathbf{e}_j$ é o j -ésimo vetor da base canônica, obtém-se

$$X_j \sim N(\mu_j, \sigma_{jj}).$$

Assim, cada componente de um vetor normal multivariado possui distribuição normal univariada.

Normalidade marginal e normalidade conjunta

A normalidade de cada componente considerada separadamente não garante normalidade multivariada. A definição exige que **todas as combinações lineares** das componentes possuam distribuição normal.

Portanto,

$$X_j \text{ normal para todo } j$$

não implica, isoladamente,

$$\mathbf{X} \sim N_p(\mu, \Sigma).$$

Quando $\|\mathbf{a}\| = 1$, a variável $\mathbf{a}^\top \mathbf{X}$ representa a coordenada da projeção de $\mathbf{X}$ na direção de $\mathbf{a}$. A definição estabelece que toda projeção unidimensional de um vetor normal multivariado possui distribuição normal.

9.1.2 Construção afim a partir do vetor normal padrão

A definição anterior também permite construir vetores normais multivariados a partir de variáveis normais padrão independentes.

Considere

$$\mathbf{Z} = \begin{bmatrix} Z_1 \\ \vdots \\ Z_r \end{bmatrix},$$

com

$$Z_j \sim N(0, 1), \quad j = 1, \dots, r,$$

e componentes mutuamente independentes.

Para qualquer $\mathbf{c} \in \mathbb{R}^r$,

$$\mathbf{c}^\top \mathbf{Z} = \sum_{j=1}^r c_j Z_j$$

é uma variável normal. Além disso,

$$E(\mathbf{Z}) = \mathbf{0}$$

e

$$\text{Cov}(\mathbf{Z}) = \mathbf{I}_r.$$

Logo,

$$\mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r).$$

A transformação afim definida em Definição 4.7 permite transportar essa distribuição para outros vetores de médias e outras estruturas de covariância.

Proposição 9.1 (Construção afim de um vetor normal). *Se*

$$\mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r),$$

$\mathbf{A} \in \mathbb{R}^{p \times r}$ e $\mu \in \mathbb{R}^p$, então o vetor

$$\mathbf{X} = \mu + \mathbf{AZ} \tag{9.3}$$

satisfaz

$$\mathbf{X} \sim N_p(\mu, \mathbf{AA}^\top). \tag{9.4}$$

Comprovação. Pelo resultado de transformação da covariância em Proposição 8.6,

$$E(\mathbf{X}) = \mu$$

e

$$\text{Cov}(\mathbf{X}) = \mathbf{A} \text{Cov}(\mathbf{Z}) \mathbf{A}^\top = \mathbf{AA}^\top. \tag{9.5}$$

Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\begin{aligned} \mathbf{a}^\top \mathbf{X} &= \mathbf{a}^\top \mu + \mathbf{a}^\top \mathbf{AZ} \\ &= \mathbf{a}^\top \mu + (\mathbf{A}^\top \mathbf{a})^\top \mathbf{Z}. \end{aligned}$$

A última parcela é uma combinação linear das componentes de $\mathbf{Z}$ e, portanto, possui distribuição normal. Assim, $\mathbf{a}^\top \mathbf{X}$ é normal para todo $\mathbf{a}$, o que caracteriza $\mathbf{X}$ como normal multivariado. $\square$

A matriz $\mathbf{A}$ determina como as componentes independentes de $\mathbf{Z}$ são combinadas. A transformação pode introduzir covariâncias entre as componentes de $\mathbf{X}$, mesmo que as componentes do vetor inicial sejam independentes.

Pela Proposição 8.2, uma matriz de covariâncias é simétrica e positiva semidefinida. Reciprocamente, toda matriz real simétrica e positiva semidefinida admite uma fatoração

$$\Sigma = \mathbf{A}\mathbf{A}^\top. \quad (9.6)$$

De fato, pelo Teorema 5.4,

$$\Sigma = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^\top,$$

com autovalores não negativos. Definindo

$$\mathbf{A} = \mathbf{Q}\mathbf{\Lambda}^{1/2},$$

obtém-se

$$\mathbf{A}\mathbf{A}^\top = \Sigma.$$

Consequentemente, qualquer vetor $\mu \in \mathbb{R}^p$ e qualquer matriz simétrica positiva semidefinida Σ podem parametrizar uma distribuição normal multivariada.

Quando

$$\Sigma \succ \mathbf{0},$$

a raiz quadrada principal definida em Definição 5.9 é invertível, e uma representação particularmente conveniente é

$$\mathbf{X} \stackrel{d}{=} \mu + \Sigma^{1/2}\mathbf{Z}, \quad \mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I}_p). \quad (9.7)$$

9.1.3 Determinação pelos parâmetros

Em distribuições gerais, conhecer μ e Σ não determina a distribuição conjunta. A família normal apresenta uma propriedade mais forte porque todas as suas projeções lineares são normais e os parâmetros dessas projeções são determinados por μ e Σ .

O resultado geral que permite passar das distribuições das projeções à distribuição conjunta é o Teorema de Cramér–Wold (Eaton, 2007).

Teorema 9.1 (Teorema de Cramér–Wold). *Sejam $\mathbf{X}$ e $\mathbf{Y}$ vetores aleatórios em $\mathbb{R}^p$. Então,*

$$\mathbf{X} \stackrel{d}{=} \mathbf{Y}$$

se, e somente se,

$$\mathbf{a}^\top \mathbf{X} \stackrel{d}{=} \mathbf{a}^\top \mathbf{Y}$$

para todo $\mathbf{a} \in \mathbb{R}^p$.

A implicação direta decorre da aplicação da mesma transformação linear a vetores com a mesma distribuição. A implicação inversa estabelece que a coleção das distribuições de todas as projeções lineares determina a distribuição conjunta.

Leitura de aprofundamento

O Teorema de Cramér–Wold é um resultado geral e não depende da hipótese de normalidade. Sua demonstração usual utiliza funções características, que não serão desenvolvidas neste capítulo.

Aqui, sua função é justificar que duas distribuições normais multivariadas com o mesmo vetor de médias e a mesma matriz de covariâncias são a mesma distribuição.

Proposição 9.2 (Determinação da distribuição normal pelos parâmetros). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma)$$

e

$$\mathbf{Y} \sim N_p(\mu, \Sigma),$$

então

$$\mathbf{X} \stackrel{d}{=} \mathbf{Y}.$$

Comprovação. Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}^\top \mathbf{X} \sim N(\mathbf{a}^\top \mu, \mathbf{a}^\top \Sigma \mathbf{a})$$

e

$$\mathbf{a}^\top \mathbf{Y} \sim N(\mathbf{a}^\top \mu, \mathbf{a}^\top \Sigma \mathbf{a}).$$

Logo,

$$\mathbf{a}^\top \mathbf{X} \stackrel{d}{=} \mathbf{a}^\top \mathbf{Y}$$

para todo $\mathbf{a}$. Pelo Teorema 9.1,

$$\mathbf{X} \stackrel{d}{=} \mathbf{Y}.$$

□

Essa propriedade explica por que a notação

$$N_p(\mu, \Sigma)$$

é suficiente para identificar uma distribuição normal multivariada.

9.1.4 Aprofundamento: caso singular e suporte efetivo

Leitura de aprofundamento

A normal multivariada também pode ser definida quando Σ é singular. Nesse caso, a distribuição permanece normal, mas sua variabilidade está restrita a um subespaço afim de dimensão inferior a p .

A sequência principal do capítulo utilizará predominantemente o caso não singular, $\Sigma \succ \mathbf{0}$. O caso singular esclarece a relação entre dependência linear, posto da matriz de covariâncias e suporte probabilístico.

Definição 9.2 (Distribuição normal multivariada singular). Uma distribuição

$$N_p(\mu, \Sigma)$$

é denominada **singular** ou **degenerada** quando

$$\text{posto}(\Sigma) = r < p.$$

Quando

$$\text{posto}(\Sigma) = p,$$

a distribuição é denominada **não singular**.

Se

$$\text{posto}(\Sigma) = r < p,$$

a decomposição espectral reduzida pode ser escrita como

$$\Sigma = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top,$$

em que

$$\mathbf{Q}_r \in \mathbb{R}^{p \times r}$$

possui colunas ortonormais associadas aos autovalores positivos e

$$\Lambda_r = \text{diag}(\lambda_1, \dots, \lambda_r), \quad \lambda_j > 0.$$

Definindo

$$\mathbf{A}_r = \mathbf{Q}_r \Lambda_r^{1/2},$$

tem-se

$$\Sigma = \mathbf{A}_r \mathbf{A}_r^\top.$$

Logo, uma representação da distribuição singular é

$$\mathbf{X} \stackrel{d}{=} \mu + \mathbf{A}_r \mathbf{Z}, \quad \mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r). \quad (9.8)$$

Proposição 9.3 (Suporte efetivo da normal singular). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma)$$

e

$$\text{posto}(\Sigma) = r < p,$$

então

$$P[\mathbf{X} \in \mu + \mathcal{C}(\Sigma)] = 1. \quad (9.9)$$

O suporte da distribuição é o subespaço afim

$$\mu + \mathcal{C}(\Sigma),$$

de dimensão r .

Comprovação. Pela representação Equação 9.8,

$$\mathbf{X} \stackrel{d}{=} \mu + \mathbf{A}_r \mathbf{Z}.$$

Como $\Lambda_r^{1/2}$ é invertível,

$$\mathcal{C}(\mathbf{A}_r) = \mathcal{C}(\mathbf{Q}_r) = \mathcal{C}(\Sigma).$$

Portanto,

$$\mathbf{A}_r \mathbf{Z} \in \mathcal{C}(\Sigma)$$

com probabilidade 1, o que fornece Equação 9.9.

Além disso, $\mathbf{A}_r$ possui posto coluna r . A aplicação

$$\mathbf{z} \mapsto \mu + \mathbf{A}_r \mathbf{z}$$

é uma transformação afim bijetiva entre $\mathbb{R}^r$ e

$$\mu + \mathcal{C}(\Sigma).$$

Como a normal padrão em $\mathbb{R}^r$ possui densidade positiva em todo $\mathbb{R}^r$, todo conjunto relativamente aberto e não vazio desse subespaço afim possui probabilidade positiva. Assim, esse subespaço é o suporte da distribuição. $\square$

A mesma estrutura pode ser caracterizada pelo núcleo da matriz de covariâncias. Se

$$\mathbf{a} \in \mathcal{N}(\Sigma),$$

então

$$\text{Var}[\mathbf{a}^\top (\mathbf{X} - \mu)] = \mathbf{a}^\top \Sigma \mathbf{a} = 0,$$

e, conseqüentemente,

$$\mathbf{a}^\top (\mathbf{X} - \mu) = 0$$

com probabilidade 1.

As direções do núcleo são, portanto, direções sem variabilidade probabilística.

A normal singular não possui densidade em relação à medida de Lebesgue de dimensão p em $\mathbb{R}^p$, pois concentra toda a probabilidade em um conjunto de dimensão $r < p$. Uma densidade pode ser definida relativamente à medida de dimensão r em seu suporte afim.

Exemplo 9.1 (Normal bivariada concentrada em uma reta). Considere

$$Z \sim N(0, 1)$$

e defina

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} = \begin{bmatrix} Z \\ 2Z \end{bmatrix}.$$

Equivalentemente,

$$\mathbf{X} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} Z.$$

Logo,

$$\mathbf{x} \sim N_2 \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} \right).$$

A matriz de covariâncias possui posto 1 e

$$X_2 = 2X_1$$

com probabilidade 1. Portanto, toda a distribuição está concentrada na reta

$$x_2 = 2x_1.$$

Embora o vetor tenha duas componentes, sua dimensão probabilística efetiva é 1.

Quando

$$\Sigma \succ \mathbf{0},$$

a matriz possui posto p , sua inversa existe e

$$\det(\Sigma) > 0.$$

Nesse caso, a distribuição possui densidade em relação à medida de Lebesgue em todo $\mathbb{R}^p$.

9.2 Densidade no caso não singular

A definição em Definição 9.1 inclui distribuições singulares e não singulares. A densidade usual em relação à medida de Lebesgue em $\mathbb{R}^p$ existe quando

$$\Sigma \succ \mathbf{0}.$$

Nessa situação, Σ^{-1} existe e

$$\det(\Sigma) > 0.$$

9.2.1 Função densidade e log-densidade

Proposição 9.4 (Densidade da normal multivariada não singular). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0},$$

então $\mathbf{X}$ possui densidade

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \right\}, \quad (9.10)$$

para todo $\mathbf{x} \in \mathbb{R}^p$.

Comprovação. Pela representação Equação 9.7,

$$\mathbf{X} \stackrel{d}{=} \mu + \Sigma^{1/2} \mathbf{Z},$$

com

$$\mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I}_p).$$

Como as componentes de $\mathbf{Z}$ são normais padrão independentes, sua densidade conjunta é

$$f_{\mathbf{Z}}(\mathbf{z}) = \frac{1}{(2\pi)^{p/2}} \exp \left(-\frac{1}{2} \mathbf{z}^\top \mathbf{z} \right).$$

Considere a transformação afim

$$\mathbf{x} = \mu + \Sigma^{1/2} \mathbf{z}.$$

Como $\Sigma^{1/2}$ é invertível,

$$\mathbf{z} = \Sigma^{-1/2} (\mathbf{x} - \mu).$$

A Jacobiana da transformação inversa é a matriz constante $\Sigma^{-1/2}$, de modo que

$$|\det (\Sigma^{-1/2})| = \det (\Sigma)^{-1/2}.$$

Aplicando a transformação de densidades estabelecida em Proposição 7.19,

$$\begin{aligned} f_{\mathbf{X}}(\mathbf{x}) &= f_{\mathbf{Z}}\left[\Sigma^{-1/2}(\mathbf{x} - \mu)\right] \det(\Sigma)^{-1/2} \\ &= \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \mu)^\top \Sigma^{-1}(\mathbf{x} - \mu)\right\}. \end{aligned}$$

□

A derivação mostra a função desempenhada pelos dois termos matriciais da densidade. O determinante surge da alteração de volume provocada pela transformação afim, enquanto a matriz inversa aparece ao expressar o afastamento de $\mathbf{x}$ nas coordenadas padronizadas da distribuição.

Como a distribuição é contínua,

$$P(\mathbf{X} = \mathbf{x}) = 0$$

para qualquer ponto fixo $\mathbf{x} \in \mathbb{R}^p$. Probabilidades são atribuídas a regiões:

$$P(\mathbf{X} \in \mathcal{A}) = \int_{\mathcal{A}} f_{\mathbf{X}}(\mathbf{x}) \, d\mathbf{x}, \quad (9.11)$$

para conjuntos mensuráveis $\mathcal{A} \subseteq \mathbb{R}^p$.

A forma quadrática no expoente é a distância quadrática de Mahalanobis definida em Definição 8.9:

$$d_M^2(\mathbf{x}, \mu) = (\mathbf{x} - \mu)^\top \Sigma^{-1}(\mathbf{x} - \mu).$$

Assim,

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}} \exp\left[-\frac{1}{2}d_M^2(\mathbf{x}, \mu)\right]. \quad (9.12)$$

Para μ e Σ fixos, a posição de $\mathbf{x}$ afeta a densidade somente por meio de sua distância de Mahalanobis ao vetor de médias. Como

$$c \mapsto \exp\left(-\frac{c}{2}\right)$$

é estritamente decrescente para $c \geq 0$, pontos mais afastados do centro segundo essa métrica possuem menor densidade.

A log-densidade é

$$\begin{aligned} \log f_{\mathbf{x}}(\mathbf{x}) = & -\frac{p}{2} \log(2\pi) - \frac{1}{2} \log \det(\Sigma) \\ & - \frac{1}{2} (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu). \end{aligned} \quad (9.13)$$

A expressão reúne uma constante dependente da dimensão, um termo associado ao volume da dispersão e um termo associado ao afastamento do ponto em relação ao centro. No Capítulo 10, essa mesma estrutura aparecerá na função de verossimilhança de uma amostra normal multivariada.

Quando $p = 1$,

$$\Sigma = [\sigma^2],$$

e Equação 9.10 reduz-se a

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left[-\frac{(x - \mu)^2}{2\sigma^2} \right].$$

O vetor μ determina a localização da distribuição. Como

$$d_M^2(\mathbf{x}, \mu) \geq 0$$

e a igualdade ocorre em $\mathbf{x} = \mu$, a densidade atinge seu máximo no centro:

$$f_{\mathbf{x}}(\mu) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}}. \quad (9.14)$$

A matriz Σ determina a escala, a orientação e a forma das superfícies de igual densidade. A geometria desses elipsoides foi desenvolvida no Capítulo 8; a novidade probabilística é que, na distribuição normal, essa mesma geometria organiza os valores da densidade.

9.2.2 Superfícies de igual densidade

Para $c > 0$, considere

$$\mathcal{S}_c = \{\mathbf{x} \in \mathbb{R}^p : d_M^2(\mathbf{x}, \mu) = c\}. \quad (9.15)$$

Para todo $\mathbf{x} \in \mathcal{S}_c$,

$$f_{\mathbf{x}}(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}} \exp\left(-\frac{c}{2}\right).$$

Portanto, $\mathcal{S}_c$ é uma superfície de igual densidade.

Pelos resultados geométricos do Capítulo 8, essas superfícies são elipsoidais. Seus eixos e extensões são determinados pela estrutura espectral de Σ . Não é necessário reconstruir aqui essa geometria; no modelo normal, o novo resultado é a correspondência

$$\text{distância de Mahalanobis constante} \iff \text{densidade constante}.$$

A Figura 9.1 mostra essa correspondência para uma distribuição normal bivariada.

As curvas de nível são elipses centradas em μ . Todos os pontos sobre uma mesma curva apresentam a mesma distância de Mahalanobis ao centro e, conseqüentemente, a mesma densidade.

A região interna correspondente é

$$\mathcal{E}_c = \{\mathbf{x} \in \mathbb{R}^p : d_M^2(\mathbf{x}, \mu) \leq c\}. \quad (9.16)$$

Neste ponto, c é apenas uma constante positiva. Mais adiante, a distribuição de D_M^2 permitirá escolher valores de c associados a probabilidades populacionais específicas.

9.3 Transformações e distribuições marginais

A construção em Proposição 9.1 partiu de um vetor normal padrão. Uma propriedade mais geral da família normal é o fechamento sob transformações afins. Essa propriedade permite obter distribuições de combinações lineares, projeções, subvectores e transformações de padronização sem recalculer densidades por integração.




Figura 9.1: Mapa de densidade e curvas de nível de uma distribuição normal bivariada.

9.3.1 Fechamento sob transformações afins

Considere

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

$\mathbf{A} \in \mathbb{R}^{m \times p}$ e $\mathbf{b} \in \mathbb{R}^m$.

Proposição 9.5 (Fechamento da família normal sob transformações afins). *Se*

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}, \quad (9.17)$$

então

$$\mathbf{Y} \sim N_m(\mathbf{A}\mu + \mathbf{b}, \mathbf{A}\Sigma\mathbf{A}^\top). \quad (9.18)$$

Comprovação. Pela Proposição 8.6,

$$E(\mathbf{Y}) = \mathbf{A}\mu + \mathbf{b}$$

e

$$\text{Cov}(\mathbf{Y}) = \mathbf{A}\Sigma\mathbf{A}^\top.$$

Para qualquer $\mathbf{c} \in \mathbb{R}^m$,

$$\begin{aligned} \mathbf{c}^\top \mathbf{Y} &= \mathbf{c}^\top (\mathbf{A}\mathbf{X} + \mathbf{b}) \\ &= (\mathbf{A}^\top \mathbf{c})^\top \mathbf{X} + \mathbf{c}^\top \mathbf{b}. \end{aligned}$$

Como $\mathbf{X}$ é normal multivariado,

$$(\mathbf{A}^\top \mathbf{c})^\top \mathbf{X}$$

é normal. A adição de uma constante preserva a normalidade. Portanto, toda combinação linear das componentes de $\mathbf{Y}$ é normal, o que demonstra o resultado. $\square$

As fórmulas para média e covariância são válidas para vetores aleatórios gerais com segundos momentos finitos. O resultado específico da família normal é o **fechamento distribucional**:

$$\mathbf{X} \text{ normal multivariado} \implies \mathbf{A}\mathbf{X} + \mathbf{b} \text{ normal multivariado.}$$

A matriz $\mathbf{A}$ não precisa possuir posto completo. Se

$$\text{posto}(\mathbf{A}\Sigma\mathbf{A}^\top) < m,$$

a distribuição transformada é uma normal singular em $\mathbb{R}^m$.

Exemplo 9.2 (Transformação de um vetor normal bivariado). Considere

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} 2 \\ 1 \end{bmatrix}, \begin{bmatrix} 4 & 1 \\ 1 & 2 \end{bmatrix} \right).$$

Defina

$$\mathbf{Y} = \begin{bmatrix} Y_1 \\ Y_2 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \mathbf{X} + \begin{bmatrix} 0 \\ 3 \end{bmatrix}.$$

Logo,

$$Y_1 = X_1 + X_2$$

e

$$Y_2 = X_1 - X_2 + 3.$$

O vetor de médias é

$$\begin{aligned} E(\mathbf{Y}) &= \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} + \begin{bmatrix} 0 \\ 3 \end{bmatrix} \\ &= \begin{bmatrix} 3 \\ 4 \end{bmatrix}, \end{aligned}$$

e a matriz de covariâncias é

$$\begin{aligned}\text{Cov}(\mathbf{Y}) &= \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 4 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 8 & 2 \\ 2 & 4 \end{bmatrix}.\end{aligned}$$

Portanto,

$$\mathbf{Y} \sim N_2 \left(\begin{bmatrix} 3 \\ 4 \end{bmatrix}, \begin{bmatrix} 8 & 2 \\ 2 & 4 \end{bmatrix} \right).$$

O exemplo mostra que uma transformação afim modifica simultaneamente localização e covariância, mas preserva a família normal.

9.3.2 Combinações lineares

Uma combinação linear é o caso $m = 1$ de Proposição 9.5.

Para $\mathbf{a} \in \mathbb{R}^p$ e $b \in \mathbb{R}$,

$$Y = \mathbf{a}^\top \mathbf{X} + b$$

satisfaz

$$Y \sim N(\mathbf{a}^\top \boldsymbol{\mu} + b, \mathbf{a}^\top \boldsymbol{\Sigma} \mathbf{a}). \quad (9.19)$$

A expressão fornece diretamente a distribuição de somas, diferenças, contrastes, médias ponderadas e projeções lineares.

Exemplo 9.3 (Soma e diferença de componentes conjuntamente normais). Considere

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix} \right).$$

Para

$$Y_1 = X_1 + X_2,$$

tem-se

$$Y_1 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2 + 2\sigma_{12}).$$

Para

$$Y_2 = X_1 - X_2,$$

tem-se

$$Y_2 \sim N(\mu_1 - \mu_2, \sigma_1^2 + \sigma_2^2 - 2\sigma_{12}).$$

Quando $\sigma_{12} > 0$, a covariância aumenta a variância da soma e reduz a variância da diferença. Para $\sigma_{12} < 0$, ocorre o efeito inverso.

Se

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0,$$

a distribuição é degenerada e

$$\mathbf{a}^\top \mathbf{X} + b = \mathbf{a}^\top \mu + b$$

com probabilidade 1.

9.3.3 Distribuições marginais

As distribuições marginais de subvetores também podem ser obtidas como transformações lineares.

Considere

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right), \quad (9.20)$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}, \quad p_1 + p_2 = p.$$

Proposição 9.6 (Distribuições marginais da normal multivariada). *Sob o particionamento em Equação 9.20,*

$$\mathbf{X}_1 \sim N_{p_1}(\mu_1, \Sigma_{11}) \quad (9.21)$$

e

$$\mathbf{X}_2 \sim N_{p_2}(\mu_2, \Sigma_{22}). \quad (9.22)$$

Comprovação. O primeiro bloco pode ser escrito como

$$\mathbf{X}_1 = \mathbf{A}_1 \mathbf{X},$$

com

$$\mathbf{A}_1 = [\mathbf{I}_{p_1} \quad \mathbf{0}].$$

Pela Proposição 9.5,

$$\mathbf{X}_1 \sim N_{p_1}(\mathbf{A}_1 \mu, \mathbf{A}_1 \Sigma \mathbf{A}_1^\top).$$

A estrutura particionada fornece

$$\mathbf{A}_1 \mu = \mu_1$$

e

$$\mathbf{A}_1 \Sigma \mathbf{A}_1^\top = \Sigma_{11}.$$

O segundo bloco é obtido de forma análoga. □

A distribuição marginal de um bloco depende de seu vetor de médias e de sua própria matriz de covariâncias. A matriz Σ_{12} não aparece nos parâmetros marginais, mas participa da estrutura de dependência conjunta.

Exemplo 9.4 (Marginal de um vetor normal trivariado). Considere

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix} \sim N_3 \left(\begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix}, \begin{bmatrix} 4 & 1 & -1 \\ 1 & 3 & 0,5 \\ -1 & 0,5 & 2 \end{bmatrix} \right).$$

Selecioneando X_1 e X_3 ,

$$\begin{bmatrix} X_1 \\ X_3 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 4 & -1 \\ -1 & 2 \end{bmatrix} \right).$$

A média marginal é formada pelas componentes correspondentes de μ , e a matriz de covariâncias marginal é a submatriz principal associada às variáveis selecionadas.

As distribuições marginais continuam normais quando a distribuição conjunta é singular. O subvetor selecionado pode possuir matriz de covariâncias não singular ou singular.

9.3.4 Padronização marginal e branqueamento

O Capítulo 8 definiu a matriz

$$\mathbf{D}_\Sigma = \text{diag}(\sigma_{11}, \dots, \sigma_{pp}).$$

Suponha

$$\sigma_{jj} > 0, \quad j = 1, \dots, p.$$

A padronização marginal é

$$\mathbf{Z}_{\text{pad}} = \mathbf{D}_\Sigma^{-1/2} (\mathbf{X} - \mu). \quad (9.23)$$

Pela Proposição 9.5 e pela definição de $\mathcal{R}$ em Definição 8.5,

$$\mathbf{Z}_{\text{pad}} \sim N_p(\mathbf{0}, \mathcal{R}), \quad (9.24)$$

com

$$\mathcal{R} = \mathbf{D}_\Sigma^{-1/2} \Sigma \mathbf{D}_\Sigma^{-1/2}.$$

Cada componente padronizada satisfaz

$$Z_{\text{pad},j} \sim N(0, 1),$$

mas as componentes não são necessariamente independentes.

Padronização não implica independência

A padronização marginal produz componentes com média zero e variância unitária, mas preserva as correlações existentes entre elas.

Assim,

$$\mathbf{Z}_{\text{pad}} \sim N_p(\mathbf{0}, \mathcal{R}).$$

As componentes serão independentes precisamente quando

$$\mathcal{R} = \mathbf{I}_p,$$

resultado que será formalizado na seção seguinte.

Quando

$$\Sigma \succ \mathbf{0},$$

o branqueamento simétrico é dado por

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu). \quad (9.25)$$

Pelo fechamento da família normal,

$$\begin{aligned} \mathbf{Z} &\sim N_p(\mathbf{0}, \Sigma^{-1/2} \Sigma \Sigma^{-1/2}) \\ &= N_p(\mathbf{0}, \mathbf{I}_p). \end{aligned} \quad (9.26)$$

A diferença entre as duas transformações é, portanto,

$$\mathbf{D}_{\Sigma}^{-1/2} (\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \mathcal{R})$$

e

$$\Sigma^{-1/2} (\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \mathbf{I}_p).$$

A padronização marginal transforma as variâncias em um e preserva as correlações. O branqueamento transforma toda a matriz de covariâncias em identidade.

A consequência adicional da normalidade conjunta é probabilística: as componentes do vetor branqueado são independentes.

O branqueamento não é único. Se $\mathbf{Q}_0$ é ortogonal, então

$$\mathbf{Q}_0 \Sigma^{-1/2} (\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \mathbf{I}_p),$$

pois

$$\mathbf{Q}_0 \mathbf{I}_p \mathbf{Q}_0^\top = \mathbf{I}_p.$$

O branqueamento simétrico constitui uma escolha específica entre transformações que produzem covariância identidade.

Branqueamento no caso singular

Se

$$\text{posto}(\Sigma) = r < p,$$

a matriz $\Sigma^{-1/2}$ não existe em todo $\mathbb{R}^p$. Utilizando

$$\Sigma = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top,$$

pode-se definir

$$\mathbf{Z}_r = \Lambda_r^{-1/2} \mathbf{Q}_r^\top (\mathbf{X} - \mu). \quad (9.27)$$

Então,

$$\mathbf{Z}_r \sim N_r(\mathbf{0}, \mathbf{I}_r). \quad (9.28)$$

Essa transformação expressa a distribuição em suas r direções de variância positiva e realiza o branqueamento no espaço efetivo da normal singular.

A próxima seção utiliza uma propriedade que distingue a família normal de distribuições gerais: para blocos pertencentes ao mesmo vetor normal multivariado, covariância cruzada nula é equivalente à independência.

9.4 Independência e distribuições condicionais

Para vetores aleatórios gerais, independência implica covariância cruzada nula quando os segundos momentos existem, mas a implicação inversa não é válida em geral. Na família normal multivariada, a normalidade conjunta transforma essa relação de segunda ordem em uma caracterização de independência.

Essa propriedade permite também obter a distribuição condicional de um bloco a partir da estrutura de covariâncias. O complemento de Schur, que no Capítulo 8 apareceu como matriz de covariâncias de um resíduo linear ótimo, passa a representar exatamente a matriz de covariâncias condicional.

9.4.1 Independência entre blocos conjuntamente normais

Considere o vetor particionado

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right), \quad (9.29)$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}, \quad p_1 + p_2 = p.$$

Se os dois blocos são independentes, então

$$\text{Cov}(\mathbf{X}_1, \mathbf{X}_2) = \Sigma_{12} = \mathbf{0}.$$

Essa implicação vale para quaisquer vetores aleatórios independentes com segundos momentos finitos. A normalidade conjunta permite estabelecer também a implicação inversa.

Proposição 9.7 (Independência de blocos conjuntamente normais). *Para os blocos do vetor normal multivariado em Equação 9.29,*

$$\mathbf{X}_1 \perp \mathbf{X}_2$$

se, e somente se,

$$\Sigma_{12} = \mathbf{0}. \quad (9.30)$$

Comprovação. Se

$$\mathbf{X}_1 \perp \mathbf{X}_2,$$

então a independência implica

$$\Sigma_{12} = \text{Cov}(\mathbf{X}_1, \mathbf{X}_2) = \mathbf{0}.$$

Para a implicação inversa, suponha

$$\Sigma_{12} = \mathbf{0}.$$

Como

$$\Sigma_{21} = \Sigma_{12}^\top,$$

a matriz de covariâncias conjunta assume a forma

$$\Sigma = \begin{bmatrix} \Sigma_{11} & \mathbf{0} \\ \mathbf{0} & \Sigma_{22} \end{bmatrix}.$$

Existem matrizes $\mathbf{A}_1$ e $\mathbf{A}_2$ tais que

$$\Sigma_{11} = \mathbf{A}_1 \mathbf{A}_1^\top$$

e

$$\Sigma_{22} = \mathbf{A}_2 \mathbf{A}_2^\top.$$

Considere vetores normais padrão independentes $\mathbf{Z}_1$ e $\mathbf{Z}_2$ e defina

$$\mathbf{Y}_1 = \mu_1 + \mathbf{A}_1 \mathbf{Z}_1$$

e

$$\mathbf{Y}_2 = \mu_2 + \mathbf{A}_2 \mathbf{Z}_2.$$

Por construção,

$$\mathbf{Y}_1 \perp \mathbf{Y}_2.$$

Além disso,

$$\begin{bmatrix} \mathbf{Y}_1 \\ \mathbf{Y}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \mathbf{0} \\ \mathbf{0} & \Sigma_{22} \end{bmatrix} \right).$$

Pela Proposição 9.2,

$$\begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \stackrel{d}{=} \begin{bmatrix} \mathbf{Y}_1 \\ \mathbf{Y}_2 \end{bmatrix}.$$

Portanto,

$$\mathbf{X}_1 \perp \mathbf{X}_2.$$

□

O resultado permanece válido quando a matriz de covariâncias conjunta é singular. A demonstração utiliza a caracterização da distribuição normal por seu vetor de médias e sua matriz de covariâncias e não depende da existência de densidade em todo $\mathbb{R}^p$.

Como caso particular, se

$$\mathbf{X} \sim N_p(\mu, \Sigma)$$

e Σ é diagonal, então

$$X_1, \dots, X_p$$

são mutuamente independentes.

Esse resultado distingue a família normal de distribuições gerais. Para um vetor aleatório qualquer, uma matriz de covariâncias diagonal garante ausência de correlações lineares entre componentes, mas não independência.

A normalidade deve ser conjunta

A equivalência

$$\text{Cov}(X_i, X_j) = 0 \iff X_i \perp X_j$$

exige que X_i e X_j pertençam ao mesmo vetor normal multivariado.

A normalidade de cada variável considerada separadamente não é suficiente para essa conclusão.

9.4.2 Distribuição condicional

Considere novamente

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right),$$

e suponha

$$\Sigma \succ \mathbf{0}.$$

Como Σ_{22} é uma submatriz principal de uma matriz positiva definida,

$$\Sigma_{22} \succ \mathbf{0},$$

de modo que Σ_{22}^{-1} existe.

Defina

$$\mu_{1|2}(\mathbf{x}_2) = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2) \quad (9.31)$$

e

$$\Sigma_{11 \cdot 2} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}. \quad (9.32)$$

A segunda expressão é o complemento de Schur de Σ_{22} na matriz Σ , já introduzido em Equação 8.16.

Proposição 9.8 (Distribuição condicional da normal multivariada). *Sob as condições anteriores,*

$$\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2 \sim N_{p_1} \left(\mu_{1|2}(\mathbf{x}_2), \Sigma_{11 \cdot 2} \right). \quad (9.33)$$

Comprovação. Considere

$$\mathbf{L}^* = \Sigma_{12} \Sigma_{22}^{-1}$$

e defina o vetor residual

$$\mathbf{E}_{1|2} = \mathbf{X}_1 - \mu_1 - \mathbf{L}^* (\mathbf{X}_2 - \mu_2). \quad (9.34)$$

Os vetores $\mathbf{E}_{1|2}$ e $\mathbf{X}_2$ são obtidos conjuntamente por uma transformação afim de $\mathbf{X}$. Pela Proposição 9.5,

$$\begin{bmatrix} \mathbf{E}_{1|2} \\ \mathbf{X}_2 \end{bmatrix}$$

possui distribuição normal multivariada.

A covariância cruzada entre o resíduo e o bloco condicionante é

$$\begin{aligned} \text{Cov}(\mathbf{E}_{1|2}, \mathbf{X}_2) &= \Sigma_{12} - \mathbf{L}^* \Sigma_{22} \\ &= \Sigma_{12} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{22} \\ &= \mathbf{0}. \end{aligned}$$

Pela Proposição 9.7,

$$\mathbf{E}_{1|2} \perp \mathbf{X}_2. \quad (9.35)$$

Além disso,

$$E(\mathbf{E}_{1|2}) = \mathbf{0}.$$

Pela Proposição 8.5,

$$\begin{aligned} \text{Cov}(\mathbf{E}_{1|2}) &= \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} \\ &= \Sigma_{11 \cdot 2}. \end{aligned}$$

Portanto,

$$\mathbf{E}_{1|2} \sim N_{p_1}(\mathbf{0}, \Sigma_{11 \cdot 2}).$$

Reorganizando Equação 9.34,

$$\mathbf{X}_1 = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{X}_2 - \mu_2) + \mathbf{E}_{1|2}.$$

Condicionando em

$$\mathbf{X}_2 = \mathbf{x}_2,$$

a primeira parcela aleatória do lado direito torna-se

$$\mu_{1|2}(\mathbf{x}_2).$$

Como $\mathbf{E}_{1|2}$ é independente de $\mathbf{X}_2$, sua distribuição permanece

$$N_{p_1}(\mathbf{0}, \Sigma_{11.2})$$

após o condicionamento. Portanto,

$$\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2 \sim N_{p_1}(\mu_{1|2}(\mathbf{x}_2), \Sigma_{11.2}).$$

□

A demonstração fornece a decomposição

$$\mathbf{X}_1 = \mu_{1|2}(\mathbf{X}_2) + \mathbf{E}_{1|2}, \quad (9.36)$$

com

$$\mathbf{E}_{1|2} \perp \mathbf{X}_2.$$

Consequentemente,

$$E(\mathbf{X}_1 | \mathbf{X}_2) = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{X}_2 - \mu_2). \quad (9.37)$$

No Capítulo 8, essa mesma expressão surgiu como o melhor ajuste linear de $\mathbf{X}_1$ em função de $\mathbf{X}_2$ com base apenas nos segundos momentos. Sob normalidade conjunta, o ajuste linear coincide exatamente com a esperança condicional.

9.4.3 Média e covariância condicionais

A média condicional

$$\mu_{1|2}(\mathbf{x}_2) = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2)$$

depende do valor condicionado.

O vetor

$$\mathbf{x}_2 - \mu_2$$

representa o afastamento do bloco conhecido em relação à sua média. A matriz

$$\Sigma_{12}\Sigma_{22}^{-1}$$

transforma esse afastamento em um ajuste para a média de $\mathbf{X}_1$.

Quando

$$\mathbf{x}_2 = \mu_2,$$

tem-se

$$\mu_{1|2}(\mu_2) = \mu_1.$$

Quando

$$\Sigma_{12} = \mathbf{0},$$

a média condicional não depende de $\mathbf{x}_2$:

$$\mu_{1|2}(\mathbf{x}_2) = \mu_1.$$

A matriz de covariâncias condicional é

$$\Sigma_{11.2} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}.$$

Ela não depende do valor específico de $\mathbf{x}_2$. Assim, diferentes valores do bloco condicionante deslocam o centro da distribuição condicional, mas não alteram sua matriz de covariâncias.

Como $\Sigma \succ \mathbf{0}$, a propriedade de positividade do complemento de Schur fornece

$$\Sigma_{11 \cdot 2} \succ \mathbf{0}. \quad (9.38)$$

A diferença entre as covariâncias marginal e condicional é

$$\Sigma_{11} - \Sigma_{11 \cdot 2} = \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}. \quad (9.39)$$

Como

$$\Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} \succeq \mathbf{0},$$

segue que

$$\Sigma_{11 \cdot 2} \preceq \Sigma_{11}. \quad (9.40)$$

Portanto, para qualquer $\mathbf{a} \in \mathbb{R}^{p_1}$,

$$\begin{aligned} \text{Var} [\mathbf{a}^\top \mathbf{X}_1 \mid \mathbf{X}_2 = \mathbf{x}_2] &= \mathbf{a}^\top \Sigma_{11 \cdot 2} \mathbf{a} \\ &\leq \mathbf{a}^\top \Sigma_{11} \mathbf{a}. \end{aligned}$$

Conhecer o segundo bloco não aumenta a variabilidade condicional de nenhuma combinação linear do primeiro bloco.

Quando

$$\Sigma_{12} = \mathbf{0},$$

tem-se simultaneamente

$$\mu_{1|2}(\mathbf{x}_2) = \mu_1$$

e

$$\Sigma_{11 \cdot 2} = \Sigma_{11}.$$

Nesse caso, a distribuição condicional coincide com a distribuição marginal, como consequência da independência entre os blocos.

9.4.4 Caso bivariado

Considere

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix} \right), \quad (9.41)$$

com

$$\sigma_1 > 0, \quad \sigma_2 > 0, \quad -1 < \rho < 1.$$

A média condicional de X_1 dado $X_2 = x_2$ é

$$\begin{aligned} E(X_1 | X_2 = x_2) &= \mu_1 + \frac{\rho\sigma_1\sigma_2}{\sigma_2^2} (x_2 - \mu_2) \\ &= \mu_1 + \rho \frac{\sigma_1}{\sigma_2} (x_2 - \mu_2). \end{aligned} \quad (9.42)$$

A variância condicional é

$$\begin{aligned} \text{Var}(X_1 | X_2 = x_2) &= \sigma_1^2 - \frac{\rho^2\sigma_1^2\sigma_2^2}{\sigma_2^2} \\ &= \sigma_1^2 (1 - \rho^2). \end{aligned} \quad (9.43)$$

Portanto,

$$X_1 | X_2 = x_2 \sim N \left[\mu_1 + \rho \frac{\sigma_1}{\sigma_2} (x_2 - \mu_2), \sigma_1^2 (1 - \rho^2) \right]. \quad (9.44)$$

O sinal de ρ determina a direção do deslocamento da média condicional. Se $\rho > 0$, valores de X_2 acima de μ_2 deslocam a média de X_1 para valores maiores; se $\rho < 0$, o deslocamento ocorre em sentido oposto.

A variância condicional depende de ρ^2 e não do valor observado x_2 . Quanto maior $|\rho|$, menor é a variabilidade remanescente de X_1 depois de conhecido X_2 .

Quando

$$\rho = 0,$$

obtém-se

$$E(X_1 | X_2 = x_2) = \mu_1$$

e

$$\text{Var}(X_1 | X_2 = x_2) = \sigma_1^2.$$

A distribuição condicional coincide, então, com a marginal.

Exemplo 9.5 (Condicional em uma normal bivariada padronizada). Considere

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 & 0,8 \\ 0,8 & 1 \end{bmatrix} \right).$$

Para

$$X_2 = 1,$$

a média condicional é

$$E(X_1 | X_2 = 1) = 0,8,$$

e a variância condicional é

$$\begin{aligned} \text{Var}(X_1 | X_2 = 1) &= 1 - 0,8^2 \\ &= 0,36. \end{aligned}$$

Logo,

$$X_1 | X_2 = 1 \sim N(0,8, 0,36).$$

O desvio-padrão condicional é

$$\sqrt{0,36} = 0,6.$$




Figura 9.2: Distribuição normal bivariada e densidade condicional de X_1 para $X_2 = 1$.

A Figura 9.2 apresenta as curvas de nível da distribuição conjunta e a densidade condicional de X_1 quando $X_2 = 1$.

No primeiro painel, a linha horizontal identifica o valor condicionado $X_2 = 1$. O ponto sobre essa linha indica a média da distribuição condicional de X_1 .

O segundo painel mostra

$$X_1 \mid X_2 = 1 \sim N(0,8, 0,36).$$

Em relação à distribuição marginal $N(0,1)$, a média passa de 0 para 0,8 e a variância passa de 1 para 0,36. O exemplo ilustra duas propriedades gerais: a média condicional depende do valor condicionado, enquanto a matriz de covariâncias condicional não depende desse valor.

O branqueamento desenvolvido anteriormente permite agora obter uma segunda consequência probabilística da normalidade: a distribuição exata da distância quadrática de Mahalanobis.

9.5 Distância de Mahalanobis e regiões de probabilidade

O Capítulo 8 definiu a distância de Mahalanobis como uma medida geométrica adaptada à estrutura de covariâncias. Quando o vetor segue uma distribuição normal multivariada não singular, a distância quadrática ao vetor de médias possui uma distribuição probabilística conhecida.

Considere

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0}.$$

A variável aleatória

$$D_M^2 = (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \quad (9.45)$$

representa a distância quadrática de Mahalanobis entre uma realização aleatória e o centro populacional.

9.5.1 Distribuição qui-quadrado

Proposição 9.9 (Distribuição da distância quadrática de Mahalanobis). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0},$$

então

$$(\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \sim \chi_p^2. \quad (9.46)$$

Comprovação. Pelo branqueamento em Equação 9.25,

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \mathbf{I}_p).$$

As componentes

$$Z_1, \dots, Z_p$$

são, portanto, normais padrão independentes.

Além disso,

$$\begin{aligned}
 D_M^2 &= (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \\
 &= \left[\Sigma^{-1/2} (\mathbf{X} - \mu) \right]^\top \left[\Sigma^{-1/2} (\mathbf{X} - \mu) \right] \\
 &= \mathbf{Z}^\top \mathbf{Z} \\
 &= \sum_{j=1}^p Z_j^2.
 \end{aligned}$$

A soma dos quadrados de p variáveis normais padrão independentes possui distribuição qui-quadrado com p graus de liberdade. Logo,

$$D_M^2 \sim \chi_p^2.$$

□

Os graus de liberdade correspondem à dimensão efetiva da distribuição. No caso não singular, essa dimensão é p .

Consequentemente,

$$E(D_M^2) = p$$

e

$$\text{Var}(D_M^2) = 2p. \quad (9.47)$$

A escala de D_M^2 depende, portanto, da dimensão. Sob o modelo normal, seu valor esperado é p , e não zero.

No espaço branqueado,

$$D_M^2 = \|\mathbf{Z}\|^2.$$

Assim, a distância quadrática de Mahalanobis no espaço original corresponde ao quadrado da distância euclidiana à origem no espaço branqueado.

Parâmetros populacionais e quantidades estimadas

O resultado

$$D_M^2 \sim \chi_p^2$$

utiliza os parâmetros populacionais μ e Σ .

Se esses parâmetros forem substituídos por estimativas obtidas a partir de uma amostra, a distribuição da forma quadrática resultante não será, em geral, χ_p^2 .

A distinção entre parâmetros conhecidos e estimados será desenvolvida nos Capítulos 10 e 12.

9.5.2 Regiões elipsoidais de probabilidade

Seja

$$\chi_{p;1-\alpha}^2$$

o quantil de ordem $1 - \alpha$ da distribuição qui-quadrado com p graus de liberdade, isto é,

$$P(\chi_p^2 \leq \chi_{p;1-\alpha}^2) = 1 - \alpha.$$

Definição 9.3 (Região elipsoidal de probabilidade). Para

$$0 < \alpha < 1,$$

define-se

$$\mathcal{E}_{1-\alpha} = \{\mathbf{x} \in \mathbb{R}^p : (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \leq \chi_{p;1-\alpha}^2\}. \quad (9.48)$$

Pela Proposição 9.9,

$$\begin{aligned} P(\mathbf{X} \in \mathcal{E}_{1-\alpha}) &= P[D_M^2 \leq \chi_{p;1-\alpha}^2] \\ &= P[\chi_p^2 \leq \chi_{p;1-\alpha}^2] \\ &= 1 - \alpha. \end{aligned} \quad (9.49)$$

Portanto, $\mathcal{E}_{1-\alpha}$ é uma região populacional que contém uma realização de $\mathbf{X}$ com probabilidade $1 - \alpha$.

Sua fronteira é

$$(\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) = \chi_{p;1-\alpha}^2.$$

A geometria é a mesma dos elipsoides de Mahalanobis do Capítulo 8. A novidade do modelo normal é a calibração probabilística da constante:

$$c = \chi_{p;1-\alpha}^2.$$

No espaço branqueado, a região corresponde à esfera

$$\{\mathbf{z} \in \mathbb{R}^p : \mathbf{z}^\top \mathbf{z} \leq \chi_{p;1-\alpha}^2\},$$

de raio

$$\sqrt{\chi_{p;1-\alpha}^2}.$$

As superfícies de igual densidade e as fronteiras das regiões elipsoidais de probabilidade possuem a mesma forma geométrica porque ambas são determinadas por valores constantes de d_M^2 . A diferença está na escolha da constante: nas regiões de probabilidade, ela é determinada por um quantil da distribuição χ_p^2 .

Região de probabilidade e região de confiança

A região

$$\mathcal{E}_{1-\alpha}$$

refere-se à posição de uma **realização de $\mathbf{X}$** quando os parâmetros populacionais μ e Σ são conhecidos.

Ela não é uma região de confiança para μ .

Regiões de confiança para parâmetros populacionais serão construídas no Capítulo 12 a partir de distribuições amostrais.

9.5.3 Avaliação de uma observação fixa

Considere agora um ponto fixo

$$\mathbf{x}_0 \in \mathbb{R}^p.$$

Sua distância quadrática de Mahalanobis em relação ao modelo é

$$d_M^2(\mathbf{x}_0, \mu) = (\mathbf{x}_0 - \mu)^\top \Sigma^{-1} (\mathbf{x}_0 - \mu). \quad (9.50)$$

O ponto está dentro de $\mathcal{E}_{1-\alpha}$ quando

$$d_M^2(\mathbf{x}_0, \mu) \leq \chi_{p;1-\alpha}^2. \quad (9.51)$$

Se

$$d_M^2(\mathbf{x}_0, \mu) > \chi_{p;1-\alpha}^2,$$

a observação está fora da região que contém probabilidade populacional $1 - \alpha$.

Essa comparação descreve a posição de um valor já observado em relação ao modelo. Depois que $\mathbf{x}_0$ foi fixado, não se atribui a ele probabilidade de pertencer à região: ele está dentro ou fora dela.

Também pode ser calculada a probabilidade de cauda

$$p_M = P[\chi_p^2 \geq d_M^2(\mathbf{x}_0, \mu)]. \quad (9.52)$$

A quantidade p_M mede, sob o modelo populacional completamente especificado, a probabilidade de obter uma distância quadrática de Mahalanobis pelo menos tão grande quanto a observada.

Um valor pequeno indica que $\mathbf{x}_0$ se encontra em uma região de afastamentos pouco frequentes sob a distribuição especificada. Essa interpretação depende de μ e Σ serem parâmetros populacionais conhecidos e não constitui, neste ponto, um procedimento inferencial para detecção de observações atípicas com parâmetros estimados.

Exemplo 9.6 (Avaliação de uma observação em uma normal bivariada). Considere

$$\mathbf{X} \sim N_2 \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 4 & 1 \\ 1 & 1 \end{bmatrix} \right)$$

e

$$\mathbf{x}_0 = \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

A inversa da matriz de covariâncias é

$$\Sigma^{-1} = \frac{1}{3} \begin{bmatrix} 1 & -1 \\ -1 & 4 \end{bmatrix}.$$

Logo,

$$\begin{aligned}
 d_M^2(\mathbf{x}_0, \mu) &= [3 \quad 1] \frac{1}{3} \begin{bmatrix} 1 & -1 \\ -1 & 4 \end{bmatrix} \begin{bmatrix} 3 \\ 1 \end{bmatrix} \\
 &= \frac{7}{3} \\
 &\approx 2,33.
 \end{aligned}$$

Para a região que contém probabilidade 0,95,

$$\chi_{2;0,95}^2 \approx 5,99.$$

Como

$$2,33 < 5,99,$$

a observação está dentro da região elipsoidal que contém 95% da probabilidade populacional.

O exemplo utiliza parâmetros populacionais conhecidos. Se o vetor de médias e a matriz de covariâncias fossem substituídos por estimativas amostrais, seria necessário utilizar a teoria inferencial apropriada.

9.5.4 Aprofundamento: caso singular

Leitura de aprofundamento

Quando Σ é singular, a inversa ordinária não existe e a distribuição está concentrada em um subespaço afim. A pseudoinversa permite definir a forma de Mahalanobis no espaço efetivo da distribuição.

Os graus de liberdade deixam de ser p e passam a corresponder ao posto de Σ .

Considere

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

com

$$\text{posto}(\Sigma) = r < p.$$

Define-se a forma generalizada de Mahalanobis por

$$D_{M,+}^2 = (\mathbf{X} - \mu)^\top \Sigma^+ (\mathbf{X} - \mu). \quad (9.53)$$

Proposição 9.10 (Forma generalizada de Mahalanobis no caso normal singular). *Se*

$$1 \leq r = \text{posto}(\Sigma) < p,$$

então

$$D_{M,+}^2 \sim \chi_r^2. \quad (9.54)$$

Comprovação. Considere a decomposição espectral reduzida

$$\Sigma = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top,$$

em que

$$\Lambda_r = \text{diag}(\lambda_1, \dots, \lambda_r), \quad \lambda_j > 0.$$

Pelo branqueamento reduzido em Equação 9.27,

$$\mathbf{Z}_r = \Lambda_r^{-1/2} \mathbf{Q}_r^\top (\mathbf{X} - \mu) \sim N_r(\mathbf{0}, \mathbf{I}_r).$$

A pseudoinversa de Σ é

$$\Sigma^+ = \mathbf{Q}_r \Lambda_r^{-1} \mathbf{Q}_r^\top.$$

Como

$$\mathbf{X} - \mu \in \mathcal{C}(\Sigma)$$

com probabilidade 1,

$$\begin{aligned} & (\mathbf{X} - \mu)^\top \Sigma^+ (\mathbf{X} - \mu) \\ &= \mathbf{Z}_r^\top \mathbf{Z}_r \\ &= \sum_{j=1}^r Z_{rj}^2. \end{aligned}$$

As componentes de $\mathbf{Z}_r$ são normais padrão independentes. Portanto,

$$\mathbf{Z}_r^\top \mathbf{Z}_r \sim \chi_r^2.$$

□

O número de graus de liberdade é

$$r = \text{posto}(\Sigma),$$

pois somente r direções possuem variância positiva.

Uma região de probabilidade $1 - \alpha$ no suporte efetivo pode ser definida por

$$\mathcal{E}_{1-\alpha}^{(r)} = \left\{ \mathbf{x} \in \mathbb{R}^p : \mathbf{x} - \mu \in \mathcal{C}(\Sigma), \right. \\ \left. (\mathbf{x} - \mu)^\top \Sigma^+ (\mathbf{x} - \mu) \leq \chi_{r;1-\alpha}^2 \right\}. \quad (9.55)$$

Pela Proposição 9.10,

$$P \left[\mathbf{X} \in \mathcal{E}_{1-\alpha}^{(r)} \right] = 1 - \alpha.$$

A calibração utiliza a dimensão efetiva r , e não a dimensão ambiente p .

Se

$$r = 0,$$

então

$$\Sigma = \mathbf{0}$$

e

$$\mathbf{X} = \mu$$

com probabilidade 1. Nesse caso extremo, a distribuição está concentrada em um único ponto.

A restrição

$$\mathbf{x} - \mu \in \mathcal{C}(\Sigma)$$

é necessária porque a distribuição singular atribui probabilidade 1 ao seu suporte afim.

Os resultados desta seção mostram a passagem da geometria do Capítulo 8 para uma interpretação probabilística. Na família normal, a forma quadrática de Mahalanobis possui uma distribuição conhecida, e os elipsoides podem ser calibrados por probabilidades populacionais.

A comparação entre duas distribuições normais permite observar, em seguida, como mudanças no vetor de médias e na matriz de covariâncias modificam suas posições, formas e densidades. Essa comparação será utilizada somente como motivação para técnicas de discriminação desenvolvidas posteriormente.

9.6 Comparação entre distribuições normais

Considere duas populações descritas por distribuições normais multivariadas:

$$\mathbf{X}^{(1)} \sim N_p(\mu_1, \Sigma_1)$$

e

$$\mathbf{X}^{(2)} \sim N_p(\mu_2, \Sigma_2),$$

com

$$\Sigma_1 \succ \mathbf{0} \quad \text{e} \quad \Sigma_2 \succ \mathbf{0}.$$

Os vetores de médias determinam a localização das distribuições, enquanto as matrizes de covariâncias determinam sua dispersão, orientação e forma. A comparação entre duas distribuições normais permite observar como esses dois componentes da parametrização atuam conjuntamente.

9.6.1 Médias distintas e covariância comum

Suponha

$$\Sigma_1 = \Sigma_2 = \Sigma,$$

mas

$$\mu_1 \neq \mu_2.$$

As duas distribuições possuem superfícies de igual densidade com a mesma forma, orientação e extensão, mas centradas em pontos diferentes.

Pela log-densidade em Equação 9.13, ambas contêm o termo quadrático

$$-\frac{1}{2}\mathbf{x}^\top \Sigma^{-1} \mathbf{x}.$$

Ao comparar as duas log-densidades, esse termo é comum e se cancela. De fato,

$$\begin{aligned} \log \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} &= \mathbf{x}^\top \Sigma^{-1} (\mu_1 - \mu_2) \\ &\quad - \frac{1}{2} (\mu_1^\top \Sigma^{-1} \mu_1 - \mu_2^\top \Sigma^{-1} \mu_2). \end{aligned} \tag{9.56}$$

A log-razão entre as densidades é, portanto, uma função afim de $\mathbf{x}$.

Consequentemente, o conjunto

$$\{\mathbf{x} \in \mathbb{R}^p : f_1(\mathbf{x}) = f_2(\mathbf{x})\}$$

é um hiperplano.

A matriz de covariâncias comum ainda influencia sua orientação, pois os afastamentos entre os centros são avaliados segundo a geometria induzida por Σ .

9.6.2 Covariâncias distintas

Considere agora

$$\Sigma_1 \neq \Sigma_2.$$

As distribuições podem diferir não somente quanto à localização, mas também quanto à forma, orientação e extensão de suas superfícies de igual densidade.

Nesse caso, as log-densidades envolvem as formas quadráticas

$$-\frac{1}{2} (\mathbf{x} - \mu_1)^\top \Sigma_1^{-1} (\mathbf{x} - \mu_1)$$

e

$$-\frac{1}{2} (\mathbf{x} - \mu_2)^\top \Sigma_2^{-1} (\mathbf{x} - \mu_2).$$

Como as matrizes inversas são diferentes, os termos quadráticos em $\mathbf{x}$ não se cancelam em geral. Expandindo a diferença entre as log-densidades,

$$\begin{aligned} \log \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} &= -\frac{1}{2} \mathbf{x}^\top (\Sigma_1^{-1} - \Sigma_2^{-1}) \mathbf{x} \\ &\quad + \mathbf{x}^\top (\Sigma_1^{-1} \mu_1 - \Sigma_2^{-1} \mu_2) \\ &\quad - \frac{1}{2} (\mu_1^\top \Sigma_1^{-1} \mu_1 - \mu_2^\top \Sigma_2^{-1} \mu_2) \\ &\quad - \frac{1}{2} \log \left(\frac{|\Sigma_1|}{|\Sigma_2|} \right). \end{aligned} \tag{9.57}$$

A presença do termo

$$\mathbf{x}^\top (\Sigma_1^{-1} - \Sigma_2^{-1}) \mathbf{x}$$

faz com que a log-razão seja, em geral, uma função quadrática de $\mathbf{x}$.

Assim, o conjunto de pontos nos quais

$$f_1(\mathbf{x}) = f_2(\mathbf{x})$$

pode apresentar uma superfície quadrática.

A Figura 9.3 ilustra as duas situações.

No primeiro painel, as duas distribuições apresentam superfícies de nível com a mesma forma e orientação, deslocadas para centros diferentes. No segundo, as diferenças entre as matrizes de covariâncias modificam também a extensão e a orientação dessas superfícies.

A comparação mostra duas estruturas algébricas que serão utilizadas posteriormente. Com uma matriz de covariâncias comum, a comparação das log-densidades elimina os termos quadráticos comuns e produz uma expressão afim. Com matrizes de covariâncias distintas, permanecem, em geral, termos quadráticos.

Esses resultados serão retomados na formulação da Análise Discriminante. A construção de regras de classificação, probabilidades a priori, custos de decisão e estimação dos parâmetros pertence aos módulos posteriores.




Figura 9.3: Comparação entre distribuições normais bivariadas com covariância comum e com covariâncias distintas.

9.7 Alcance da hipótese de normalidade

A distribuição normal multivariada acrescenta uma estrutura probabilística específica aos objetos desenvolvidos nos capítulos anteriores. É importante distinguir quais resultados dependem dessa hipótese e quais permanecem válidos para vetores aleatórios mais gerais.

9.7.1 Resultados que não exigem normalidade

Diversos resultados utilizados neste capítulo dependem somente da existência dos momentos necessários.

Para um vetor aleatório com média μ e matriz de covariâncias Σ ,

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \mu$$

e

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}$$

não exigem normalidade.

Da mesma forma, para

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b},$$

as relações

$$E(\mathbf{Y}) = \mathbf{A}\boldsymbol{\mu} + \mathbf{b}$$

e

$$\text{Cov}(\mathbf{Y}) = \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top$$

são propriedades gerais dos primeiros e segundos momentos.

A matriz de covariâncias continua simétrica e positiva semidefinida, a distância de Mahalanobis continua definindo uma geometria quando a matriz apropriada é positiva definida, e o complemento de Schur continua representando a covariância do resíduo do melhor ajuste linear entre blocos, sob as condições desenvolvidas no Capítulo 8.

Esses resultados descrevem estruturas de primeira e segunda ordens. Eles não determinam, por si mesmos, a distribuição conjunta.

9.7.2 Resultados específicos da família normal

A hipótese de normalidade conjunta produz propriedades adicionais.

Entre os resultados desenvolvidos neste capítulo estão:

- o vetor de médias e a matriz de covariâncias determinam completamente a distribuição;
- transformações afins preservam a família normal;
- distribuições marginais de subvectores permanecem normais;
- covariância cruzada nula entre blocos conjuntamente normais equivale à independência;
- distribuições condicionais permanecem normais;
- a esperança condicional entre blocos é uma função afim do bloco condicionante;
- a matriz de covariâncias condicional é o complemento de Schur correspondente;
- o branqueamento de uma normal não singular produz componentes normais padrão independentes;
- a distância quadrática de Mahalanobis populacional possui distribuição χ_p^2 no caso não singular;
- no caso singular, a forma construída com a pseudoinversa possui distribuição χ_r^2 , em que r é o posto da matriz de covariâncias.

A equivalência

$$\Sigma_{12} = \mathbf{0} \iff \mathbf{X}_1 \perp \mathbf{X}_2$$

é um exemplo da diferença entre uma propriedade geral de covariância e uma propriedade específica da família normal.

A implicação

$$\mathbf{X}_1 \perp \mathbf{X}_2 \implies \Sigma_{12} = \mathbf{0}$$

vale, quando os segundos momentos existem, sem normalidade. A implicação inversa requer a estrutura normal conjunta estabelecida em Proposição 9.7.

De maneira semelhante,

$$D_M^2 = (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \sim \chi_p^2$$

não decorre somente da existência de μ e Σ . A distribuição qui-quadrado em Proposição 9.9 depende da normalidade multivariada e da definição positiva de Σ .

Assim, a normalidade transforma relações entre médias, covariâncias e formas quadráticas em afirmações sobre distribuições completas.

9.7.3 Passagem do modelo populacional para a inferência

Neste capítulo, μ e Σ foram tratados como parâmetros populacionais conhecidos. Essa escolha permitiu estudar diretamente as propriedades da distribuição

$$N_p(\mu, \Sigma).$$

Em uma aplicação estatística, esses parâmetros são geralmente desconhecidos. A observação de uma amostra introduz uma nova distinção entre:

- parâmetros populacionais;
- estatísticas aleatórias;
- estimadores;
- valores calculados a partir dos dados observados.

Essa distinção modifica alguns resultados. Por exemplo,

$$(\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \sim \chi_p^2$$

não autoriza substituir diretamente μ e Σ por estimativas e manter a mesma distribuição.

Da mesma forma, conhecer a forma da densidade normal não é suficiente para realizar inferência sobre parâmetros desconhecidos. É necessário especificar uma amostra aleatória, construir estatísticas e estudar suas propriedades e distribuições amostrais.

O Capítulo 10 inicia essa passagem. O modelo probabilístico permanece o ponto de partida, mas os parâmetros deixam de ser tratados como conhecidos e passam a ser inferidos a partir dos dados.

9.8 Síntese do capítulo

A distribuição normal multivariada estabelece um modelo probabilístico para um vetor aleatório em que a estrutura conjunta é completamente determinada pelo vetor de médias e pela matriz de covariâncias.

A Tabela 9.1 reúne os principais resultados.

Tabela 9.1: Principais estruturas e resultados da distribuição normal multivariada.

Estrutura	Resultado
Definição	$\mathbf{a}^\top \mathbf{X}$ é normal para todo $\mathbf{a} \in \mathbb{R}^p$
Parametrização	$\mathbf{X} \sim N_p(\mu, \Sigma)$ é determinada por μ e Σ
Construção	$\mathbf{X} \stackrel{d}{=} \mu + \mathbf{A}\mathbf{Z}$, com $\Sigma = \mathbf{A}\mathbf{A}^\top$
Caso singular	o suporte é $\mu + \mathcal{C}(\Sigma)$
Caso não singular	existe densidade em $\mathbb{R}^p$ quando $\Sigma \succ \mathbf{0}$
Transformação afim	$\mathbf{A}\mathbf{X} + \mathbf{b}$ permanece normal
Marginalização	subvectores de um vetor normal multivariado permanecem normais
Independência	$\Sigma_{12} = \mathbf{0}$ equivale à independência entre blocos conjuntamente normais
Condicionamento	a distribuição condicional é normal, com média afim e covariância dada por complemento de Schur
Branqueamento	no caso não singular, produz $N_p(\mathbf{0}, \mathbf{I}_p)$
Mahalanobis	$D_M^2 \sim \chi_p^2$ no caso não singular
Caso singular de Mahalanobis	$D_{M,+}^2 \sim \chi_r^2$, com $r = \text{posto}(\Sigma)$

A definição por combinações lineares fornece a caracterização probabilística da família. O Teorema de Cramér–Wold permite concluir que, nessa família, as projeções unidimensionais e, conseqüentemente, μ e Σ determinam a distribuição conjunta.

A representação

$$\mathbf{X} \stackrel{d}{=} \mu + \mathbf{A}\mathbf{Z}, \quad \mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r),$$

com

$$\Sigma = \mathbf{A}\mathbf{A}^\top,$$

conecta a distribuição normal multivariada às transformações afins e à decomposição da matriz de covariâncias.

Quando

$$\text{posto}(\Sigma) < p,$$

a distribuição é singular e permanece concentrada em um subespaço afim. Quando

$$\Sigma \succ \mathbf{0},$$

a distribuição possui densidade em todo $\mathbb{R}^p$, cujas superfícies de igual densidade são determinadas pela distância de Mahalanobis.

As propriedades de transformação e marginalização preservam a família normal. A normalidade conjunta também estabelece a equivalência entre independência e covariância cruzada nula e fornece distribuições condicionais normais. Nesse contexto, o complemento de Schur deixa de representar somente uma covariância residual linear e passa a ser exatamente a matriz de covariâncias condicional.

No caso não singular, o branqueamento transforma o vetor em

$$N_p(\mathbf{0}, \mathbf{I}_p),$$

e a forma quadrática

$$D_M^2 = (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu)$$

possui distribuição χ_p^2 . Esse resultado atribui uma calibração probabilística aos elipsoides de Mahalanobis desenvolvidos geometricamente no Capítulo 8.

Ao término deste capítulo, deve-se ser capaz de:

- caracterizar uma distribuição normal multivariada por combinações lineares;
- construir vetores normais por transformações afins de vetores normais padrão;
- distinguir distribuições normais singulares e não singulares;
- identificar o suporte efetivo de uma normal singular;
- interpretar a densidade normal multivariada e suas superfícies de nível;
- obter distribuições de transformações afins, combinações lineares e subvetores;
- diferenciar padronização marginal e branqueamento;
- relacionar covariância cruzada nula e independência sob normalidade conjunta;
- determinar média e matriz de covariâncias de uma distribuição condicional;
- interpretar o complemento de Schur como covariância condicional;
- utilizar a distribuição qui-quadrado da distância de Mahalanobis populacional;
- distinguir resultados gerais de segunda ordem daqueles que dependem da normalidade.

Neste capítulo, μ e Σ foram considerados parâmetros populacionais conhecidos. O Capítulo 10 introduz a amostra aleatória multivariada e distingue parâmetros, estatísticas, estimadores e estimativas. Essa passagem permite estudar como o vetor de médias e a matriz de covariâncias podem ser estimados a partir dos dados e quais propriedades podem ser atribuídas aos respectivos estimadores.

10 Estatísticas Amostrais e Estimação

Os Capítulos 8 e 9 desenvolveram, respectivamente, a estrutura de covariâncias e o modelo normal multivariado em termos de parâmetros populacionais. Em uma aplicação estatística, esses parâmetros geralmente são desconhecidos e precisam ser inferidos a partir de uma amostra.

O objetivo deste capítulo é passar dos objetos populacionais às estatísticas calculadas sobre uma amostra multivariada e estudar sua utilização como estimadores. Serão desenvolvidos o vetor de médias amostrais, a matriz de somas de quadrados e produtos cruzados, os estimadores da matriz de covariâncias, a matriz de correlações amostral e as covariâncias cruzadas entre blocos de variáveis.

Os métodos dos momentos e da máxima verossimilhança serão utilizados como princípios de construção de estimadores. As propriedades matemáticas e os resultados de cálculo matricial estabelecidos no Módulo 1 serão retomados somente quando necessários.

As distribuições amostrais exatas, a distribuição de Wishart, a independência entre o vetor de médias e a matriz de covariâncias amostrais sob normalidade e os procedimentos de inferência serão desenvolvidos no Capítulo 12. Neste capítulo, a atenção estará concentrada na construção dos estimadores, em suas propriedades e nas limitações associadas ao tamanho amostral e à dimensão.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{X} \in \mathbb{R}^p$ representa um vetor aleatório populacional;
- $\mathbf{X}_1, \dots, \mathbf{X}_n$ representam os vetores aleatórios que compõem a amostra;
- $\mathbf{x}_1, \dots, \mathbf{x}_n$ representam suas realizações;
- $\mathcal{X} \in \mathbb{R}^{n \times p}$ representa a matriz aleatória da amostra;
- $\mathbf{X} \in \mathbb{R}^{n \times p}$ representa a matriz de dados observada;
- μ , Σ e $\mathcal{R}$ representam, respectivamente, o vetor de médias, a matriz de covariâncias e a matriz de correlações populacionais;
- $\bar{\mathbf{X}}$ representa o vetor de médias amostrais como estatística aleatória, enquanto $\bar{\mathbf{x}}$ representa seu valor observado;
- $\mathbf{T}$ representa a matriz de somas de quadrados e produtos cruzados centralizados como estatística aleatória, e $\mathbf{T}$ sua realização observada;
- $\mathbf{S}$ representa a matriz de covariâncias amostral como estatística aleatória, e $\mathbf{S}$ seu valor observado;

- $\mathbf{R}$ representa a matriz de correlações amostral como estatística aleatória, e $\mathbf{R}$ seu valor observado;
- $\mathbf{G} = G(\mathcal{X})$ será utilizada como notação genérica para uma estatística, evitando conflito com o símbolo $\mathbf{T}$ reservado à SSCP;
- $\hat{\theta}$ representa um estimador de um parâmetro θ , e $\hat{\theta}_{\text{obs}}$ o valor assumido pelo estimador após a observação da amostra.

A convenção $\mathbf{T}$ para a SSCP observada mantém a notação estabelecida no Capítulo 8.

10.1 Da população à amostra

Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ \vdots \\ X_p \end{bmatrix} \in \mathbb{R}^p$$

com distribuição pertencente a uma família

$$\{F_\theta : \theta \in \Theta\},$$

em que θ representa o conjunto de parâmetros desconhecidos e Θ é o espaço paramétrico.

Quando existem momentos de primeira e segunda ordens,

$$E(\mathbf{X}) = \mu \in \mathbb{R}^p$$

e

$$\text{Cov}(\mathbf{X}) = \Sigma \in \mathbb{R}^{p \times p}.$$

Os parâmetros são características fixas da população. A aleatoriedade introduzida pelo processo de amostragem pertence às observações e às estatísticas calculadas a partir delas.

10.1.1 Amostra aleatória multivariada

A unidade amostral de um estudo multivariado é um vetor. Cada unidade fornece simultaneamente os valores das p variáveis que compõem $\mathbf{X}$.

Definição 10.1 (Amostra aleatória multivariada). Uma amostra aleatória multivariada de tamanho n proveniente de F_θ é uma coleção de vetores aleatórios

$$\mathbf{X}_1, \dots, \mathbf{X}_n \in \mathbb{R}^p$$

independentes e identicamente distribuídos:

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} F_\theta. \quad (10.1)$$

A condição de distribuição idêntica estabelece que todas as unidades são regidas pela mesma distribuição populacional. A independência estabelece que a realização de uma unidade não altera a distribuição das demais unidades.

Quando a distribuição populacional possui densidade em relação a uma medida comum, a independência implica

$$f_\theta^{(n)}(\mathbf{x}_1, \dots, \mathbf{x}_n) = \prod_{i=1}^n f_\theta(\mathbf{x}_i). \quad (10.2)$$

Analogamente, quando a função de distribuição conjunta pode ser escrita por meio dos eventos coordenados correspondentes,

$$F_\theta^{(n)}(\mathbf{x}_1, \dots, \mathbf{x}_n) = \prod_{i=1}^n F_\theta(\mathbf{x}_i). \quad (10.3)$$

Essas fatorações dizem respeito à independência **entre unidades amostrais**. A dependência entre as componentes de um mesmo vetor continua representada pela distribuição multivariada F_θ .

Cada vetor da amostra possui a forma

$$\mathbf{X}_i = \begin{bmatrix} X_{i1} \\ X_{i2} \\ \vdots \\ X_{ip} \end{bmatrix}, \quad i = 1, \dots, n,$$

em que X_{ij} representa a variável j na unidade i .

A independência entre

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

não implica independência entre

$$X_{i1}, \dots, X_{ip}.$$

As componentes de uma mesma unidade podem apresentar covariâncias e outras formas de dependência.

Quando os segundos momentos existem,

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma$$

para todo i . Para unidades distintas,

$$\text{Cov}(\mathbf{X}_i, \mathbf{X}_\ell) = \mathbf{0}, \quad i \neq \ell,$$

como consequência da independência.

No modelo normal multivariado,

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma). \quad (10.4)$$

A normalidade não é necessária para definir o vetor de médias amostrais, a matriz de covariâncias ou a matriz de correlações. Neste capítulo, ela será utilizada especificamente na obtenção dos estimadores de máxima verossimilhança de μ e Σ . As consequências para distribuições amostrais e inferência pertencem ao Capítulo 12.

10.1.2 Matriz aleatória da amostra e matriz observada

Os vetores da amostra podem ser organizados nas linhas de uma matriz aleatória.

Definição 10.2 (Matriz aleatória da amostra). A matriz aleatória associada à amostra é

$$\mathcal{X} = \begin{bmatrix} \mathbf{X}_1^\top \\ \mathbf{X}_2^\top \\ \vdots \\ \mathbf{X}_n^\top \end{bmatrix} = \begin{bmatrix} X_{11} & X_{12} & \cdots & X_{1p} \\ X_{21} & X_{22} & \cdots & X_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ X_{n1} & X_{n2} & \cdots & X_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (10.5)$$

Antes da coleta dos dados, os elementos de $\mathcal{X}$ são variáveis aleatórias. Cada possível resultado do processo amostral corresponde a uma matriz numérica.

Após a observação da amostra, uma realização de $\mathcal{X}$ é denotada por

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (10.6)$$

A diferença tipográfica registra a natureza dos objetos:

- $\mathcal{X}$ é a matriz aleatória da amostra;
- $\mathbf{X}$ é a matriz de dados observada;
- $\mathbf{X}_i$ é o vetor aleatório correspondente à unidade i ;
- $\mathbf{x}_i$ é sua realização;
- X_{ij} é uma variável aleatória;
- x_{ij} é o valor observado correspondente.

Se o suporte da população é $\mathcal{X} \subseteq \mathbb{R}^p$, o espaço das possíveis amostras é

$$\mathcal{X}^n.$$

No caso em que $\mathcal{X} = \mathbb{R}^p$, esse espaço pode ser identificado com

$$(\mathbb{R}^p)^n$$

ou, equivalentemente, com o conjunto das matrizes reais $n \times p$.

Uma estatística associa a cada possível realização da amostra uma quantidade escalar, vetorial ou matricial. Antes da observação, seu valor é aleatório. Depois da observação, torna-se uma quantidade calculada a partir de $\mathbf{X}$.

10.1.3 Parâmetros, estatísticas, estimadores e estimativas

Um parâmetro é uma característica fixa da distribuição populacional. Ele pode ser escalar, vetorial ou matricial.

Neste capítulo, os principais parâmetros são

$$\mu, \quad \Sigma \quad \text{e} \quad \mathcal{R}.$$

No modelo normal multivariado não singular, o parâmetro completo pode ser representado por

$$\theta = (\mu, \Sigma),$$

com espaço paramétrico

$$\Theta = \{(\mu, \Sigma) : \mu \in \mathbb{R}^p, \Sigma \succ \mathbf{0}\}.$$

Definição 10.3 (Estatística amostral). Uma estatística é uma função da amostra que não contém parâmetros desconhecidos em sua expressão. De forma genérica, será representada por

$$\mathbf{G} = G(\mathcal{X}). \quad (10.7)$$

Seu contradomínio pode ser escalar, vetorial ou matricial.

A expressão da estatística não contém parâmetros desconhecidos, mas sua distribuição geralmente depende da distribuição populacional e de seus parâmetros.

O vetor de médias amostrais é um exemplo de estatística vetorial:

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i. \quad (10.8)$$

Após a observação da amostra,

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i. \quad (10.9)$$

A distribuição de uma estatística é denominada **distribuição amostral**. Ela descreve sua variabilidade entre todas as possíveis amostras de tamanho n provenientes da mesma população.

Distribuição populacional e distribuição amostral

A distribuição

$$\mathbf{X} \sim F_{\theta}$$

descreve a variabilidade de uma unidade populacional.

A distribuição de

$$\mathbf{G} = G(\mathcal{X})$$

descreve a variabilidade de uma função calculada sobre uma amostra inteira.

Esses objetos não devem ser confundidos. O Capítulo 12 estudará distribuições amostrais específicas das estatísticas introduzidas neste capítulo.

Uma estatística torna-se um estimador quando é utilizada para aproximar um parâmetro desconhecido.

Definição 10.4 (Estimador e estimativa). Um estimador de um parâmetro θ é uma estatística

$$\hat{\theta} = G(\mathcal{X}) \tag{10.10}$$

utilizada para inferir θ .

A estimativa é o valor assumido pelo estimador após a observação da amostra:

$$\hat{\theta}_{\text{obs}} = G(\mathbf{X}). \tag{10.11}$$

Assim,

$$\bar{\mathbf{X}}$$

é um estimador de μ , enquanto

$$\bar{\mathbf{x}}$$

é a estimativa obtida para uma amostra específica.

De modo semelhante,

$$\mathbf{S}$$

será utilizada como estimador de Σ , e

S

representará seu valor observado.

O erro de estimação é

$$\hat{\theta} - \theta. \quad (10.12)$$

Antes da observação da amostra, esse erro é aleatório. Sua distribuição caracteriza parte do desempenho do estimador.

Um mesmo parâmetro pode possuir diferentes estimadores. Para Σ , por exemplo, serão estudados o estimador não viesado baseado no divisor $n - 1$ e, sob o modelo normal multivariado, o estimador de máxima verossimilhança baseado no divisor n .

A estimação pontual produz um valor como aproximação do parâmetro. A estimação por regiões produz um conjunto construído para quantificar a incerteza associada ao processo amostral. Neste capítulo será desenvolvida a estimação pontual. Regiões de confiança serão tratadas no Capítulo 12.

A comparação entre estimadores exige critérios que descrevam seu comportamento ao longo das possíveis amostras. Viés, variabilidade, erro quadrático médio, consistência, eficiência, suficiência, equivariância e robustez serão examinados a seguir.

10.2 Propriedades dos estimadores multivariados

A existência de um estimador não determina sua adequação. Diferentes estatísticas podem estimar o mesmo parâmetro e apresentar comportamentos distintos ao longo das possíveis amostras.

Considere

$$\theta \in \Theta \subseteq \mathbb{R}^r$$

e um estimador

$$\hat{\theta} = G(\mathcal{X}) \in \mathbb{R}^r.$$

A avaliação de $\hat{\theta}$ depende de sua distribuição amostral e do critério utilizado para comparar procedimentos. Viés, variabilidade e erro quadrático médio descrevem aspectos de seu comportamento para tamanho amostral fixo. Consistência e eficiência assintótica tratam de sequências

de estimadores quando n aumenta. Suficiência, equivariância e robustez examinam, respectivamente, a informação preservada, a coerência sob transformações e a estabilidade diante de perturbações (Casella; Berger, 2002).

10.2.1 Viés e variabilidade

Definição 10.5 (Viés de um estimador). Se $E(\hat{\theta})$ existe, o viés de $\hat{\theta}$ na estimação de θ é

$$\text{Bias}(\hat{\theta}) = E(\hat{\theta}) - \theta. \quad (10.13)$$

O estimador é não viesado quando

$$E(\hat{\theta}) = \theta.$$

O viés é um vetor em $\mathbb{R}^r$. Sua componente j é

$$E(\hat{\theta}_j) - \theta_j.$$

A ausência de viés descreve o comportamento médio do procedimento sobre as possíveis amostras. Ela não garante que uma estimativa particular esteja próxima do parâmetro.

Para um parâmetro matricial

$$\Theta \in \mathbb{R}^{a \times b}$$

e um estimador

$$\hat{\Theta} \in \mathbb{R}^{a \times b},$$

define-se, elemento a elemento,

$$\text{Bias}(\hat{\Theta}) = E(\hat{\Theta}) - \Theta. \quad (10.14)$$

A variabilidade de um estimador vetorial é descrita por

$$\text{Cov}(\hat{\theta}) = E \left[\{ \hat{\theta} - E(\hat{\theta}) \} \{ \hat{\theta} - E(\hat{\theta}) \}^\top \right]. \quad (10.15)$$

Os elementos diagonais são as variâncias de seus componentes e os elementos fora da diagonal são as covariâncias entre eles.

Para qualquer $\mathbf{a} \in \mathbb{R}^r$,

$$\text{Var}(\mathbf{a}^\top \hat{\theta}) = \mathbf{a}^\top \text{Cov}(\hat{\theta}) \mathbf{a}.$$

Uma medida escalar da variabilidade total é

$$\text{tr}[\text{Cov}(\hat{\theta})] = \sum_{j=1}^r \text{Var}(\hat{\theta}_j).$$

Esse resumo depende da escala e da parametrização e não substitui a matriz de covariâncias quando a dependência entre os componentes do estimador é relevante.

Para um estimador matricial, uma representação da variabilidade é

$$\text{Cov}[\text{vec}(\hat{\Theta})].$$

O operador vec e suas propriedades foram desenvolvidos no Capítulo 7.

10.2.2 Erro quadrático médio e funções de perda

A comparação entre estimadores requer especificar como diferentes erros são avaliados. Essa escolha é formalizada por uma função de perda, cujo valor esperado define o risco do procedimento (Casella; Berger, 2002).

Para um estimador vetorial, considere a perda quadrática euclidiana

$$L(\hat{\theta}, \theta) = \|\hat{\theta} - \theta\|^2. \quad (10.16)$$

Essa escolha atribui o mesmo peso às coordenadas na parametrização utilizada. Outros problemas podem exigir ponderações ou perdas diferentes.

Definição 10.6 (Erro quadrático médio vetorial). Sob a perda quadrática euclidiana,

$$\text{EQM}(\hat{\theta}) = E[\|\hat{\theta} - \theta\|^2]. \quad (10.17)$$

Proposição 10.1 (Decomposição do erro quadrático médio). Se $\hat{\theta}$ possui segundos momentos finitos, então

$$\text{EQM}(\hat{\theta}) = \text{tr}[\text{Cov}(\hat{\theta})] + \|\text{Bias}(\hat{\theta})\|^2. \quad (10.18)$$

Comprovação. Escreva

$$\hat{\theta} - \theta = [\hat{\theta} - E(\hat{\theta})] + \text{Bias}(\hat{\theta}).$$

O primeiro termo possui média zero. Ao expandir o quadrado da norma e tomar esperança, o termo cruzado desaparece. Além disso,

$$E[\|\hat{\theta} - E(\hat{\theta})\|^2] = \text{tr}[\text{Cov}(\hat{\theta})].$$

Substituindo essas relações, obtém-se Equação 10.18. □

Quando o estimador é não viesado,

$$\text{EQM}(\hat{\theta}) = \text{tr}[\text{Cov}(\hat{\theta})].$$

A ausência de viés não implica EQM mínimo. Um estimador viesado pode apresentar menor risco quadrático se a redução de variabilidade compensar o viés. Essa ideia será retomada na seção de regularização.

Para parâmetros matriciais, uma escolha correspondente é a perda baseada na norma de Frobenius definida em Definição 6.7:

$$L_F(\hat{\Theta}, \Theta) = \|\hat{\Theta} - \Theta\|_F^2.$$

O erro quadrático médio matricial é

$$\text{EQM}_F(\hat{\Theta}) = E[\|\hat{\Theta} - \Theta\|_F^2]. \quad (10.19)$$

Equivalentemente,

$$\begin{aligned} \text{EQM}_F(\hat{\Theta}) &= \text{tr}\{\text{Cov}[\text{vec}(\hat{\Theta})]\} \\ &\quad + \|\text{Bias}(\hat{\Theta})\|_F^2. \end{aligned} \quad (10.20)$$

A norma de Frobenius corresponde a uma escolha específica de perda. Em problemas de estimação de matrizes de covariâncias, outros critérios podem atribuir pesos diferentes a autovalores, direções ou erros de inversão.

10.2.3 Consistência

A consistência descreve o comportamento de uma sequência de estimadores quando o tamanho da amostra aumenta (Vaart, 1998).

Definição 10.7 (Consistência). Uma sequência

$$\hat{\theta}_n$$

é consistente para θ quando

$$\hat{\theta}_n \xrightarrow{P} \theta \quad (10.21)$$

quando $n \rightarrow \infty$.

A convergência em probabilidade significa que, para todo $\varepsilon > 0$,

$$P \left(\|\hat{\theta}_n - \theta\| > \varepsilon \right) \rightarrow 0. \quad (10.22)$$

Na formulação clássica deste capítulo, a dimensão do parâmetro é mantida fixa enquanto n aumenta. Quando a dimensão também varia com n , é necessário declarar o regime dimensional e a métrica utilizada para avaliar o erro. Essa distinção será retomada na seção de aprofundamento sobre alta dimensão.

10.2.4 Eficiência

Considere dois estimadores não viesados

$$\hat{\theta}_1 \quad \text{e} \quad \hat{\theta}_2.$$

O primeiro é uniformemente pelo menos tão eficiente quanto o segundo, segundo a ordem de Loewner, quando

$$\text{Cov}_\theta(\hat{\theta}_1) \preceq \text{Cov}_\theta(\hat{\theta}_2) \quad \text{para todo } \theta \in \Theta. \quad (10.23)$$

Equivalentemente,

$$\text{Cov}_\theta(\hat{\theta}_2) - \text{Cov}_\theta(\hat{\theta}_1) \succeq \mathbf{0}.$$

Consequentemente, para todo $\mathbf{a} \in \mathbb{R}^r$,

$$\text{Var}_\theta \left(\mathbf{a}^\top \hat{\theta}_1 \right) \leq \text{Var}_\theta \left(\mathbf{a}^\top \hat{\theta}_2 \right).$$

A ordem de Loewner é parcial. Duas matrizes de covariâncias podem não ser comparáveis; nesse caso, um estimador pode apresentar menor variabilidade em determinadas direções e maior variabilidade em outras.

Uma comparação escalar pode utilizar, por exemplo,

$$\text{tr} \left[\text{Cov} \left(\hat{\theta} \right) \right],$$

mas outra função de perda pode produzir uma ordenação diferente.

Para estimadores viesados, a comparação baseada somente nas matrizes de covariâncias é insuficiente. É necessário considerar um risco que incorpore viés e variabilidade.

A eficiência assintótica compara as matrizes que aparecem nas distribuições-limite dos estimadores. Sob condições de regularidade, estimadores de máxima verossimilhança podem atingir limites associados à informação de Fisher. Os resultados assintóticos correspondentes pertencem à teoria geral desenvolvida no Capítulo 7 e à inferência do Capítulo 12.

10.2.5 Suficiência

Uma estatística suficiente preserva, segundo o modelo adotado, toda a informação da amostra sobre o parâmetro no sentido de que a distribuição condicional da amostra dado essa estatística não depende do parâmetro (Casella; Berger, 2002).

Definição 10.8 (Estatística suficiente). Uma estatística

$$\mathbf{G} = G(\mathcal{X})$$

é suficiente para θ quando a distribuição condicional da amostra dado $\mathbf{G}$ não depende de θ .

Para famílias dominadas por uma medida comum, o Teorema da Fatoração de Neyman–Fisher fornece um critério equivalente.

Teorema 10.1 (Teorema da Fatoração de Neyman–Fisher). *Considere uma família dominada por uma medida comum, com densidade ou função de probabilidade conjunta*

$$f_{\theta}(\mathbf{x}), \quad \theta \in \Theta.$$

A estatística

$$G(\mathbf{x})$$

é suficiente para θ se, e somente se, existem funções não negativas g_{θ} e h tais que

$$f_{\theta}(\mathbf{x}) = g_{\theta}[G(\mathbf{x})] h(\mathbf{x}), \quad (10.24)$$

em que h não depende de θ .

No modelo normal multivariado, o vetor de médias amostrais e a SSCP formam conjuntamente uma estatística suficiente para μ e Σ (Anderson, 2003).

Proposição 10.2 (Suficiência no modelo normal multivariado). *Considere*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0}.$$

Defina

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i$$

e

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}})(\mathbf{X}_i - \bar{\mathbf{X}})^{\top}. \quad (10.25)$$

Então,

$$(\bar{\mathbf{X}}, \mathbf{T})$$

é suficiente para

$$(\mu, \Sigma).$$

Comprovação. Para uma realização $\mathbf{x}_1, \dots, \mathbf{x}_n$, a densidade conjunta é

$$f_{\mu, \Sigma}(\mathbf{x}_1, \dots, \mathbf{x}_n) = (2\pi)^{-np/2} \det(\Sigma)^{-n/2} \\ \times \exp \left\{ -\frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu) \right\}.$$

A identidade de decomposição em torno da média fornece

$$\sum_{i=1}^n (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^\top \\ = \mathbf{T} + n (\bar{\mathbf{x}} - \mu) (\bar{\mathbf{x}} - \mu)^\top,$$

em que

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

Logo, toda a dependência da densidade conjunta em relação a μ e Σ ocorre por meio de

$$(\bar{\mathbf{x}}, \mathbf{T}).$$

O resultado segue de Teorema 10.1. □

A suficiência não implica, por si só, ausência de viés, consistência ou eficiência. Ela afirma que, sob o modelo considerado, a redução da amostra à estatística suficiente não perde informação sobre o parâmetro.

10.2.6 Equivariância e robustez

Equivariância. Uma transformação dos dados pode induzir uma transformação correspondente no parâmetro. Um procedimento equivariante respeita essa relação.

Definição 10.9 (Equivariância de um estimador). Considere uma transformação h aplicada à amostra e uma transformação g aplicada ao parâmetro. Um estimador definido pela regra G é equivariante quando

$$G[h(\mathcal{X})] = g[G(\mathcal{X})]. \quad (10.26)$$

Considere, por exemplo,

$$\mathbf{Y}_i = \mathbf{C}\mathbf{X}_i + \mathbf{d}, \quad i = 1, \dots, n,$$

com

$$\mathbf{C} \in \mathbb{R}^{q \times p} \quad \text{e} \quad \mathbf{d} \in \mathbb{R}^q.$$

Os parâmetros transformados são

$$\mu_Y = \mathbf{C}\mu + \mathbf{d}$$

e

$$\Sigma_Y = \mathbf{C}\Sigma\mathbf{C}^\top.$$

Os estimadores usuais que serão construídos adiante satisfazem

$$\bar{\mathbf{Y}} = \mathbf{C}\bar{\mathbf{X}} + \mathbf{d}$$

e

$$\mathbf{S}_Y = \mathbf{C}\mathbf{S}_X\mathbf{C}^\top.$$

A equivariância é uma propriedade do procedimento em relação às transformações consideradas. Ela deve ser distinguida da propriedade de invariância da máxima verossimilhança, que trata da estimação de funções de parâmetros a partir de um estimador de máxima verossimilhança já obtido.

Robustez. A robustez examina a estabilidade de um procedimento diante de perturbações do modelo ou dos dados. Sua avaliação exige especificar:

- a classe de perturbações considerada;
- o aspecto do estimador cuja estabilidade interessa;
- a medida utilizada para quantificar a alteração.

Não existe, portanto, uma única propriedade de robustez que ordene universalmente todos os estimadores.

A média e a covariância amostrais podem ser fortemente afetadas por observações extremas. Como diversos procedimentos multivariados utilizam esses objetos, essa sensibilidade pode se propagar para resultados posteriores.

Estimadores robustos de localização e dispersão procuram reduzir determinadas formas de sensibilidade, mas podem envolver compromissos com eficiência sob o modelo ideal, equivariância, existência, custo computacional ou interpretação do funcional populacional estimado.

Robustez também deve ser distinguida de consistência. Um estimador pode ser consistente sob o modelo especificado e, ainda assim, apresentar elevada sensibilidade a pequenas contaminações.

As propriedades desta seção não formam uma hierarquia universal. A escolha de um estimador depende do parâmetro, da função de perda, do modelo probabilístico, do tamanho amostral, da dimensão e do objetivo da análise.

Os métodos dos momentos e da máxima verossimilhança fornecem dois princípios gerais para construir os estimadores estudados a seguir.

10.3 Métodos de estimação

Um estimador pode ser construído a partir de diferentes princípios. O método dos momentos relaciona momentos populacionais a seus correspondentes amostrais. A máxima verossimilhança escolhe os valores dos parâmetros que tornam os dados observados mais compatíveis com o modelo especificado (Casella; Berger, 2002).

Os dois métodos podem produzir o mesmo estimador em determinados modelos, mas essa coincidência não ocorre em geral. O método utilizado para construir um estimador também não determina, isoladamente, seu viés, consistência, eficiência ou robustez. Essas propriedades devem ser analisadas separadamente.

10.3.1 Método dos momentos

Considere um parâmetro

$$\theta \in \Theta \subseteq \mathbb{R}^r$$

e um vetor de funções

$$\mathbf{q}(\mathbf{X}) \in \mathbb{R}^r$$

cujas esperanças existem. Defina

$$\mathbf{m}(\theta) = E_{\theta}[\mathbf{q}(\mathbf{X})]. \quad (10.27)$$

O correspondente amostral é

$$\widehat{\mathbf{m}} = \frac{1}{n} \sum_{i=1}^n \mathbf{q}(\mathbf{X}_i). \quad (10.28)$$

Definição 10.10 (Estimador pelo método dos momentos). Um estimador pelo método dos momentos de θ é uma solução de

$$\mathbf{m}(\widehat{\theta}_{\text{MM}}) = \widehat{\mathbf{m}}. \quad (10.29)$$

A construção exige que os momentos escolhidos existam e forneçam informação suficiente sobre o parâmetro. O sistema em Equação 10.29 pode não possuir solução, pode possuir mais de uma solução ou pode produzir valores fora do espaço paramétrico.

Para o vetor de médias populacional,

$$E(\mathbf{X}) = \mu.$$

O primeiro momento amostral é

$$\frac{1}{n} \sum_{i=1}^n \mathbf{X}_i = \bar{\mathbf{X}},$$

de modo que

$$\widehat{\mu}_{\text{MM}} = \bar{\mathbf{X}}. \quad (10.30)$$

Para a matriz de covariâncias, considere o segundo momento não central

$$\mathbf{M}_2 = E(\mathbf{X}\mathbf{X}^\top).$$

A relação

$$\Sigma = \mathbf{M}_2 - \mu\mu^\top \quad (10.31)$$

fornece, após a substituição dos momentos populacionais por seus correspondentes amostrais,

$$\begin{aligned} \widehat{\Sigma}_{\text{MM}} &= \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^\top - \bar{\mathbf{x}} \bar{\mathbf{x}}^\top \\ &= \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \end{aligned} \quad (10.32)$$

A matriz no numerador será denotada por

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \quad (10.33)$$

Portanto,

$$\widehat{\Sigma}_{\text{MM}} = \frac{1}{n} \mathbf{T}. \quad (10.34)$$

Essa construção utiliza somente os dois primeiros momentos e não exige normalidade multivariada.

A matriz $\mathbf{T}$ será desenvolvida em detalhes na seção dedicada à SSCP. Para cada amostra, ela é simétrica e positiva semidefinida, em concordância com as propriedades da SSCP observada estabelecidas no Capítulo 8.

Existência e admissibilidade da solução

O método dos momentos não garante que a solução pertença ao espaço paramétrico. Em modelos com restrições de positividade, ordem ou identificabilidade, os momentos amostrais podem produzir soluções inadmissíveis.

A existência, a unicidade e a admissibilidade do estimador precisam ser verificadas no modelo considerado.

10.3.2 Verossimilhança e máxima verossimilhança

Considere uma família de distribuições dominada por uma medida comum, com densidade ou função de probabilidade

$$f(\mathbf{x}; \theta), \quad \theta \in \Theta.$$

Para uma amostra aleatória independente e identicamente distribuída,

$$\mathbf{X}_1, \dots, \mathbf{X}_n,$$

a contribuição conjunta das observações é o produto das contribuições individuais.

Definição 10.11 (Função de verossimilhança). Para uma amostra observada

$$\mathbf{x}_1, \dots, \mathbf{x}_n,$$

a função de verossimilhança é

$$L(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n) = \prod_{i=1}^n f(\mathbf{x}_i; \theta). \quad (10.35)$$

Na função de verossimilhança, os dados observados permanecem fixos e θ varia em Θ . A verossimilhança não é, em geral, uma distribuição de probabilidade sobre o parâmetro.

A log-verossimilhança é

$$\ell(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n) = \log L(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n),$$

e, sob independência,

$$\ell(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n) = \sum_{i=1}^n \log f(\mathbf{x}_i; \theta). \quad (10.36)$$

Como o logaritmo é estritamente crescente, a verossimilhança e a log-verossimilhança possuem os mesmos pontos de máximo.

Definição 10.12 (Estimador de máxima verossimilhança). Um estimador de máxima verossimilhança de θ é uma estatística

$$\hat{\theta}_{\text{MV}}$$

que satisfaz

$$\hat{\theta}_{\text{MV}} \in \arg \max_{\theta \in \Theta} L(\theta; \mathcal{X}). \quad (10.37)$$

Após a observação da amostra,

$$\hat{\theta}_{\text{MV,obs}} \in \arg \max_{\theta \in \Theta} L(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n).$$

A utilização de **arg max** permite registrar situações em que há mais de um ponto de máximo. A existência e a unicidade do estimador dependem do modelo, do espaço paramétrico e da amostra observada.

10.3.2.1 Máxima verossimilhança no modelo normal multivariado

Considere

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\mu \in \mathbb{R}^p \quad \text{e} \quad \Sigma \succ \mathbf{0}.$$

Para uma amostra observada, a verossimilhança é

$$\begin{aligned} L(\mu, \Sigma) &= (2\pi)^{-np/2} \det(\Sigma)^{-n/2} \\ &\times \exp \left\{ -\frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu) \right\}. \end{aligned} \quad (10.38)$$

A log-verossimilhança é

$$\begin{aligned}\ell(\mu, \Sigma) = & -\frac{np}{2} \log(2\pi) - \frac{n}{2} \log \det(\Sigma) \\ & - \frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu).\end{aligned}\quad (10.39)$$

Defina a SSCP observada

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \quad (10.40)$$

A decomposição em torno da média amostral fornece

$$\begin{aligned}\sum_{i=1}^n (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^\top \\ = \mathbf{T} + n (\bar{\mathbf{x}} - \mu) (\bar{\mathbf{x}} - \mu)^\top.\end{aligned}\quad (10.41)$$

Utilizando a representação por traços,

$$\begin{aligned}\ell(\mu, \Sigma) = & -\frac{np}{2} \log(2\pi) - \frac{n}{2} \log \det(\Sigma) \\ & - \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{T}) \\ & - \frac{n}{2} (\bar{\mathbf{x}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{x}} - \mu).\end{aligned}\quad (10.42)$$

Para Σ fixa, o último termo é não positivo na log-verossimilhança e atinge seu maior valor quando

$$\mu = \bar{\mathbf{x}}.$$

Substituindo esse valor, obtém-se a log-verossimilhança perfilada

$$\ell_p(\Sigma) = C - \frac{n}{2} \left\{ \log \det(\Sigma) + \text{tr} \left[\Sigma^{-1} \left(\frac{\mathbf{T}}{n} \right) \right] \right\}, \quad (10.43)$$

em que C não depende de Σ .

Proposição 10.3 (Estimadores de máxima verossimilhança no modelo normal). *Considere*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0}.$$

Para uma amostra observada, se

$$\text{posto}(\mathbf{T}) = p,$$

a função de verossimilhança possui máximo único no espaço paramétrico e

$$\hat{\mu}_{\text{MV,obs}} = \bar{\mathbf{x}},$$

$$\hat{\Sigma}_{\text{MV,obs}} = \frac{\mathbf{T}}{n}.$$

No evento amostral em que a condição de posto se verifica, as regras correspondentes são

$$\hat{\mu}_{\text{MV}} = \bar{\mathbf{X}} \tag{10.44}$$

e

$$\hat{\Sigma}_{\text{MV}} = \frac{\mathbf{T}}{n}. \tag{10.45}$$

Comprovação. A maximização em relação a μ decorre de Equação 10.42. Como

$$\Sigma^{-1} \succ \mathbf{0},$$

tem-se

$$(\bar{\mathbf{x}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{x}} - \mu) \geq 0,$$

com igualdade somente em

$$\mu = \bar{\mathbf{x}}.$$

Para a maximização em relação a Σ , defina

$$\mathbf{C} = \frac{\mathbf{T}}{n}.$$

Sob a hipótese de posto completo,

$$\mathbf{C} \succ \mathbf{0}.$$

A maximização da log-verossimilhança equivale à minimização de

$$\log \det (\Sigma) + \operatorname{tr} \left(\Sigma^{-1} \mathbf{C} \right).$$

Defina

$$\mathbf{M} = \mathbf{C}^{-1/2} \Sigma \mathbf{C}^{-1/2}.$$

Então,

$$\log \det (\Sigma) = \log \det (\mathbf{C}) + \log \det (\mathbf{M}),$$

e

$$\operatorname{tr} \left(\Sigma^{-1} \mathbf{C} \right) = \operatorname{tr} \left(\mathbf{M}^{-1} \right).$$

Se $m_1, \dots, m_p$ são os autovalores positivos de $\mathbf{M}$, a parcela variável do critério é

$$\sum_{j=1}^p \left(\log m_j + \frac{1}{m_j} \right).$$

Para $m > 0$, a função

$$\log m + \frac{1}{m}$$

possui mínimo único em $m = 1$. Logo,

$$\mathbf{M} = \mathbf{I}_p,$$

e, consequentemente,

$$\Sigma = \mathbf{C} = \frac{\mathbf{T}}{n}.$$

□

Como

$$\text{posto}(\mathbf{T}) \leq \min(p, n-1),$$

uma condição necessária para posto completo é

$$n \geq p+1.$$

Essa condição não é suficiente para uma amostra arbitrária, pois as colunas da matriz centralizada ainda podem ser linearmente dependentes. Sob uma distribuição normal multivariada não singular e

$$n \geq p+1,$$

a condição

$$\text{posto}(\mathbf{T}) = p$$

ocorre com probabilidade 1.

Se $\mathbf{T}$ é singular, a verossimilhança não possui máximo no espaço

$$\{\Sigma : \Sigma \succ \mathbf{0}\}.$$

De fato, em uma direção pertencente ao núcleo de $\mathbf{T}$, um autovalor de Σ pode tender a zero sem aumentar o termo

$$\text{tr}(\Sigma^{-1}\mathbf{T}),$$

enquanto

$$-\frac{n}{2} \log \det(\Sigma)$$

tende a $+\infty$.

A matriz

$$\frac{\mathbf{T}}{n}$$

continua sendo calculável e positiva semidefinida e coincide com o estimador de momentos. Entretanto, quando é singular, ela não constitui o estimador de máxima verossimilhança no modelo cujo espaço paramétrico exige

$$\Sigma \succ \mathbf{0}.$$

Quando o máximo existe, o estimador de Σ utiliza o divisor n . Mais adiante será mostrado que esse estimador é viesado para Σ e que o divisor $n - 1$ produz o estimador não viesado usual.

10.3.3 Invariância da máxima verossimilhança

A máxima verossimilhança possui uma propriedade que permite estimar funções do parâmetro sem realizar uma nova maximização desde o início (Casella; Berger, 2002).

Considere

$$\psi = g(\theta).$$

Quando g não é injetiva, diferentes valores de θ podem produzir o mesmo valor de ψ . Defina a verossimilhança perfilada de ψ por

$$L_g(\psi) = \sup_{\theta \in \Theta: g(\theta) = \psi} L(\theta). \quad (10.46)$$

Proposição 10.4 (Invariância da máxima verossimilhança). *Se*

$$\hat{\theta}_{\text{MV}}$$

é um estimador de máxima verossimilhança de θ e

$$\psi = g(\theta),$$

então

$$g\left(\hat{\theta}_{\text{MV}}\right)$$

é um estimador de máxima verossimilhança de ψ em relação à verossimilhança perfilada em Equação 10.46.

Comprovação. Defina

$$\widehat{\psi} = g\left(\hat{\theta}_{\text{MV}}\right).$$

Como a fibra

$$\left\{\theta \in \Theta : g(\theta) = \widehat{\psi}\right\}$$

contém $\hat{\theta}_{\text{MV}}$, tem-se

$$L_g\left(\widehat{\psi}\right) = L\left(\hat{\theta}_{\text{MV}}\right).$$

Nenhum outro valor de ψ pode apresentar verossimilhança perfilada superior, pois isso implicaria a existência de algum θ cuja verossimilhança superasse o máximo global. Portanto,

$$\widehat{\psi} = g\left(\hat{\theta}_{\text{MV}}\right)$$

é um estimador de máxima verossimilhança de ψ . □

A invariância da máxima verossimilhança deve ser distinguida da equivariância.

- **Equivariância** relaciona uma transformação dos dados à transformação correspondente do estimador.
- **Invariância da máxima verossimilhança** aplica uma função do parâmetro ao estimador de máxima verossimilhança já obtido.

Considere a matriz de correlações populacional

$$\mathcal{R} = \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2},$$

em que

$$\mathbf{D}_{\Sigma} = \text{diag}\left(\sigma_{11}, \dots, \sigma_{pp}\right).$$

Quando o estimador de máxima verossimilhança de Σ existe e possui diagonal positiva, a invariância fornece

$$\widehat{\mathcal{R}}_{\text{MV}} = \widehat{\mathbf{D}}_{\Sigma, \text{MV}}^{-1/2} \widehat{\Sigma}_{\text{MV}} \widehat{\mathbf{D}}_{\Sigma, \text{MV}}^{-1/2}. \quad (10.47)$$

Como a multiplicação de uma matriz de covariâncias por uma constante escalar positiva comum não altera suas correlações, a matriz em Equação 10.47 coincide com a matriz de correlações calculada a partir da covariância amostral com divisor $n - 1$.

A propriedade pode ser aplicada também a funções como

$$\det(\Sigma), \quad \text{tr}(\Sigma)$$

e, quando o estimador é positivo definido,

$$\Sigma^{-1}.$$

A invariância é uma propriedade de otimização. Ela não implica ausência de viés, consistência automática ou estabilidade numérica. Em particular, a inversão de uma matriz estimada mal condicionada pode amplificar pequenas perturbações.

Os dois métodos apresentados produzem, no modelo normal, o mesmo estimador para μ e a mesma matriz com divisor n para Σ . A seção seguinte examina primeiro o vetor de médias amostrais e suas propriedades.

10.4 Estimação do vetor de médias

O vetor de médias populacional

$$\mu = E(\mathbf{X})$$

descreve a localização da população em $\mathbb{R}^p$. Seu estimador natural é o centro das observações que compõem a amostra.

Considere

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

independentes e identicamente distribuídos, com

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma.$$

As propriedades desenvolvidas nesta seção exigem somente os momentos indicados. A normalidade multivariada não é necessária.

10.4.1 Vetor de médias amostrais

O vetor de médias amostrais é

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i.$$

Componente a componente,

$$\bar{\mathbf{X}} = \begin{bmatrix} \bar{X}_1 \\ \bar{X}_2 \\ \vdots \\ \bar{X}_p \end{bmatrix},$$

com

$$\bar{X}_j = \frac{1}{n} \sum_{i=1}^n X_{ij}, \quad j = 1, \dots, p. \quad (10.48)$$

Utilizando a matriz aleatória da amostra,

$$\mathcal{X} \in \mathbb{R}^{n \times p},$$

tem-se

$$\bar{\mathbf{X}} = \frac{1}{n} \mathcal{X}^\top \mathbf{1}_n. \quad (10.49)$$

Após a observação dos dados,

$$\bar{\mathbf{x}} = \frac{1}{n} \mathbf{X}^\top \mathbf{1}_n. \quad (10.50)$$

Os resultados da seção anterior mostram que

$$\hat{\mu}_{\text{MM}} = \bar{\mathbf{x}},$$

e, sob o modelo normal quando o estimador de máxima verossimilhança existe,

$$\hat{\mu}_{\text{MV}} = \bar{\mathbf{x}}.$$

Assim,

$$\hat{\mu}_{\text{MM}} = \hat{\mu}_{\text{MV}} = \bar{\mathbf{x}}. \quad (10.51)$$

A coincidência resulta das estruturas específicas dos momentos e da verossimilhança normal. As propriedades de primeira e segunda ordens examinadas a seguir não dependem dessa normalidade.

O valor observado $\bar{\mathbf{x}}$ também é o centroide da nuvem de pontos.

Proposição 10.5 (Caracterização da média amostral como centroide). *Para observações*

$$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^p,$$

o vetor $\bar{\mathbf{x}}$ é o único minimizador de

$$Q(\mathbf{m}) = \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2, \quad \mathbf{m} \in \mathbb{R}^p.$$

Portanto,

$$\bar{\mathbf{x}} = \arg \min_{\mathbf{m} \in \mathbb{R}^p} \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2. \quad (10.52)$$

Comprovação. Para qualquer $\mathbf{m} \in \mathbb{R}^p$,

$$\mathbf{x}_i - \mathbf{m} = (\mathbf{x}_i - \bar{\mathbf{x}}) + (\bar{\mathbf{x}} - \mathbf{m}).$$

Somando os quadrados das normas,

$$\begin{aligned} \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2 &= \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2 \\ &\quad + 2(\bar{\mathbf{x}} - \mathbf{m})^\top \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) \\ &\quad + n \|\bar{\mathbf{x}} - \mathbf{m}\|^2. \end{aligned}$$

Como

$$\sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) = \mathbf{0},$$

segue que

$$\sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2 = \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2 + n \|\bar{\mathbf{x}} - \mathbf{m}\|^2. \quad (10.53)$$

A primeira parcela não depende de $\mathbf{m}$, e a segunda é não negativa e se anula somente em

$$\mathbf{m} = \bar{\mathbf{x}}.$$

Logo, $\bar{\mathbf{x}}$ é o único minimizador. □

A identidade Equação 10.53 será reutilizada na construção da SSCP e na decomposição da dispersão em torno de centros distintos.

10.4.2 Esperança e matriz de covariâncias

Proposição 10.6 (Esperança e covariância do vetor de médias amostrais). *Se*

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma,$$

então

$$E(\bar{\mathbf{X}}) = \mu \tag{10.54}$$

e

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}. \tag{10.55}$$

Comprovação. Pela linearidade da esperança,

$$\begin{aligned} E(\bar{\mathbf{X}}) &= \frac{1}{n} \sum_{i=1}^n E(\mathbf{X}_i) \\ &= \mu. \end{aligned}$$

Para a matriz de covariâncias,

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{1}{n^2} \text{Cov}\left(\sum_{i=1}^n \mathbf{X}_i\right).$$

Como as unidades amostrais são independentes,

$$\text{Cov}\left(\sum_{i=1}^n \mathbf{X}_i\right) = \sum_{i=1}^n \text{Cov}(\mathbf{X}_i) = n\Sigma.$$

Portanto,

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}.$$

□

Consequentemente,

$$\text{Bias}(\bar{\mathbf{X}}) = \mathbf{0}.$$

O vetor de médias amostrais é, portanto, não viesado para μ .

Elemento a elemento,

$$\text{Var}(\bar{X}_j) = \frac{\sigma_{jj}}{n}$$

e

$$\text{Cov}(\bar{X}_j, \bar{X}_k) = \frac{\sigma_{jk}}{n}.$$

O aumento do tamanho amostral reduz por $1/n$ todas as variâncias e covariâncias do erro de estimação, enquanto preserva a estrutura relativa determinada por Σ .

Sob a perda quadrática euclidiana,

$$\begin{aligned} \text{EQM}(\bar{\mathbf{X}}) &= \text{tr}[\text{Cov}(\bar{\mathbf{X}})] \\ &= \frac{1}{n} \text{tr}(\Sigma). \end{aligned} \tag{10.56}$$

Assim, a variância total populacional determina a magnitude do erro quadrático médio segundo essa perda, enquanto o aumento de n reduz esse erro na razão $1/n$.

10.4.3 Combinações lineares

Considere o parâmetro escalar

$$\mathbf{a}^\top \mu, \quad \mathbf{a} \in \mathbb{R}^p.$$

O correspondente estimador é

$$\mathbf{a}^\top \bar{\mathbf{X}}.$$

Sua esperança é

$$E(\mathbf{a}^\top \bar{\mathbf{X}}) = \mathbf{a}^\top \mu,$$

e sua variância é

$$\begin{aligned}\text{Var}(\mathbf{a}^\top \bar{\mathbf{X}}) &= \mathbf{a}^\top \text{Cov}(\bar{\mathbf{X}}) \mathbf{a} \\ &= \frac{1}{n} \mathbf{a}^\top \Sigma \mathbf{a}.\end{aligned}\tag{10.57}$$

A precisão depende da direção definida por $\mathbf{a}$. Direções com maior variabilidade populacional também produzem maior variabilidade entre as estimativas das respectivas combinações lineares.

Quando

$$\mathbf{a} = \mathbf{e}_j,$$

recupera-se

$$\text{Var}(\bar{X}_j) = \frac{\sigma_{jj}}{n}.$$

Mais geralmente, para

$$\mathbf{C} \in \mathbb{R}^{q \times p},$$

o estimador de

$$\mathbf{C}\mu$$

é

$$\mathbf{C}\bar{\mathbf{X}},$$

com

$$E(\mathbf{C}\bar{\mathbf{X}}) = \mathbf{C}\mu$$

e

$$\text{Cov}(\mathbf{C}\bar{\mathbf{X}}) = \frac{1}{n} \mathbf{C} \Sigma \mathbf{C}^\top.\tag{10.58}$$

Essas expressões serão retomadas no estudo de contrastes e hipóteses lineares.

10.4.4 Consistência e equivariância

Proposição 10.7 (Consistência do vetor de médias amostrais). *Se*

$$E \left(\|\mathbf{X}\|^2 \right) < \infty,$$

então, para dimensão p fixa,

$$\bar{\mathbf{X}} \xrightarrow{P} \mu \tag{10.59}$$

quando $n \rightarrow \infty$.

Comprovação. Como $\bar{\mathbf{X}}$ é não viesado,

$$E \left[\|\bar{\mathbf{X}} - \mu\|^2 \right] = \frac{\text{tr}(\Sigma)}{n}.$$

Para $\varepsilon > 0$, a desigualdade de Markov aplicada à variável não negativa

$$\|\bar{\mathbf{X}} - \mu\|^2$$

fornece

$$\begin{aligned} P \left(\|\bar{\mathbf{X}} - \mu\| > \varepsilon \right) &\leq \frac{E \left[\|\bar{\mathbf{X}} - \mu\|^2 \right]}{\varepsilon^2} \\ &= \frac{\text{tr}(\Sigma)}{n\varepsilon^2} \rightarrow 0. \end{aligned}$$

Logo,

$$\bar{\mathbf{X}} \xrightarrow{P} \mu.$$

□

A prova utiliza segundos momentos finitos. Para dimensão fixa, a consistência também pode ser obtida por leis dos grandes números sob condições de integrabilidade mais gerais.

O vetor de médias amostrais respeita transformações afins dos dados.

Proposição 10.8 (Equivariância afim do vetor de médias amostrais). *Considere*

$$\mathbf{Y}_i = \mathbf{C}\mathbf{X}_i + \mathbf{d}, \quad i = 1, \dots, n,$$

com

$$\mathbf{C} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{d} \in \mathbb{R}^q.$$

Então,

$$\bar{\mathbf{Y}} = \mathbf{C}\bar{\mathbf{X}} + \mathbf{d}. \quad (10.60)$$

Comprovação. Pela definição,

$$\begin{aligned} \bar{\mathbf{Y}} &= \frac{1}{n} \sum_{i=1}^n (\mathbf{C}\mathbf{X}_i + \mathbf{d}) \\ &= \mathbf{C} \left(\frac{1}{n} \sum_{i=1}^n \mathbf{X}_i \right) + \mathbf{d} \\ &= \mathbf{C}\bar{\mathbf{X}} + \mathbf{d}. \end{aligned}$$

□

Como

$$\mu_Y = \mathbf{C}\mu + \mathbf{d},$$

a transformação que relaciona os parâmetros populacionais também relaciona seus estimadores.

10.4.5 Variabilidade entre amostras

A estimativa $\bar{\mathbf{x}}$ depende da amostra observada. Diferentes amostras da mesma população produzem diferentes centroides.

A Figura 10.1 apresenta os vetores de médias obtidos em 250 amostras de tamanhos 5 e 50 geradas de uma mesma distribuição normal bivariada. A normalidade é utilizada apenas para gerar a ilustração; a relação

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}$$

depende apenas da independência das unidades e da existência dos segundos momentos.




Figura 10.1: Vetores de médias amostrais obtidos em 250 amostras de uma distribuição normal bivariada, para tamanhos amostrais 5 e 50.

Nos dois painéis, os vetores de médias amostrais se distribuem ao redor de μ . Para $n = 50$, a nuvem é mais concentrada do que para $n = 5$, em concordância com a redução da matriz de covariâncias por $1/n$.

A figura **não representa ainda um resultado sobre a forma exata da distribuição amostral de $\bar{\mathbf{X}}$** . Essa distribuição será estudada no Capítulo 12.

O vetor de médias amostrais estima a localização da população. A estimação da dispersão exige considerar os desvios das observações em relação a esse centro. Esses desvios conduzem à SSCP e aos estimadores da matriz de covariâncias.

10.5 SSCP e estimação da matriz de covariâncias

O vetor de médias amostrais descreve a localização da amostra. A estimação da matriz de covariâncias exige representar como as observações se dispersam conjuntamente em torno desse centro.

O Capítulo 8 introduziu a SSCP e a matriz de covariâncias calculadas a partir de uma matriz de dados observada. Nesta seção, os mesmos objetos passam a ser tratados como **estatísticas aleatórias** e utilizados para estimar o parâmetro populacional Σ .

Considere uma amostra aleatória multivariada

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

independente e identicamente distribuída, com

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma,$$

e suponha que os segundos momentos sejam finitos.

10.5.1 SSCP como estatística aleatória

A matriz aleatória da amostra é

$$\mathcal{X} = \begin{bmatrix} \mathbf{X}_1^\top \\ \vdots \\ \mathbf{X}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

Defina a matriz de centralização

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top$$

e a matriz aleatória centralizada

$$\mathcal{X}_c = \mathbf{H}_n \mathcal{X}. \quad (10.61)$$

Suas linhas são

$$(\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

Definição 10.13 (SSCP amostral). A matriz de somas de quadrados e produtos cruzados centralizados da amostra é a estatística

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \quad (10.62)$$

Equivalentemente,

$$\mathbf{T} = \mathcal{X}_c^\top \mathcal{X}_c = \mathcal{X}^\top \mathbf{H}_n \mathcal{X}. \quad (10.63)$$

Após a observação da amostra,

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}$$

e

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \quad (10.64)$$

Essa é a mesma SSCP observada definida em Definição 8.10. A diferença é que, neste capítulo, $\mathbf{T}$ representa o objeto **antes da realização da amostra**, enquanto $\mathbf{T}$ representa seu valor calculado para os dados observados.

O elemento (j, k) de $\mathbf{T}$ é

$$t_{jk} = \sum_{i=1}^n (X_{ij} - \bar{X}_j) (X_{ik} - \bar{X}_k). \quad (10.65)$$

Na diagonal,

$$t_{jj} = \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2$$

é a soma de quadrados centralizada da variável j . Fora da diagonal, t_{jk} é o produto cruzado centralizado entre as variáveis j e k .

10.5.2 Decomposição em torno de um centro arbitrário

A média amostral possui uma propriedade que permite separar a dispersão em torno de qualquer vetor fixo da dispersão em torno do centro amostral.

Proposição 10.9 (Decomposição da SSCP em torno de um centro arbitrário). *Para qualquer vetor fixo*

$$\mathbf{c} \in \mathbb{R}^p,$$

tem-se

$$\begin{aligned} \sum_{i=1}^n (\mathbf{X}_i - \mathbf{c})(\mathbf{X}_i - \mathbf{c})^\top \\ = \mathbf{T} + n(\bar{\mathbf{X}} - \mathbf{c})(\bar{\mathbf{X}} - \mathbf{c})^\top. \end{aligned} \tag{10.66}$$

Comprovação. Escreva

$$\mathbf{X}_i - \mathbf{c} = (\mathbf{X}_i - \bar{\mathbf{X}}) + (\bar{\mathbf{X}} - \mathbf{c}).$$

Substituindo na soma dos produtos externos, surgem quatro parcelas. Os dois termos cruzados contêm

$$\sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}}) = \mathbf{0},$$

e, portanto, se anulam. Restam

$$\mathbf{T}$$

e

$$n(\bar{\mathbf{X}} - \mathbf{c})(\bar{\mathbf{X}} - \mathbf{c})^\top,$$

o que fornece Equação [10.66](#). □

Para

$$\mathbf{c} = \mu,$$

obtém-se

$$\begin{aligned} & \sum_{i=1}^n (\mathbf{X}_i - \mu) (\mathbf{X}_i - \mu)^\top \\ &= \mathbf{T} + n (\bar{\mathbf{X}} - \mu) (\bar{\mathbf{X}} - \mu)^\top. \end{aligned} \tag{10.67}$$

Essa identidade separa a dispersão das observações em torno do centro populacional em duas parcelas: a dispersão em torno da média amostral e o afastamento entre a média amostral e a média populacional.

10.5.3 Esperança da SSCP

A identidade anterior permite obter a esperança de $\mathbf{T}$ sem assumir normalidade.

Proposição 10.10 (Esperança da SSCP). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

são independentes e identicamente distribuídos, com

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma,$$

então

$$E(\mathbf{T}) = (n-1)\Sigma. \tag{10.68}$$

Comprovação. Tomando esperança no lado esquerdo de Equação 10.67,

$$E \left[\sum_{i=1}^n (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^\top \right] = \sum_{i=1}^n \Sigma = n\Sigma.$$

Para a segunda parcela do lado direito,

$$E \left[n (\bar{\mathbf{X}} - \mu) (\bar{\mathbf{X}} - \mu)^\top \right] = n \text{Cov} (\bar{\mathbf{X}}).$$

Por Equação 10.55,

$$n \text{Cov} (\bar{\mathbf{X}}) = \Sigma.$$

Portanto,

$$n\Sigma = E(\mathbf{T}) + \Sigma,$$

e segue que

$$E(\mathbf{T}) = (n-1)\Sigma.$$

□

O fator $n-1$ surge porque a SSCP utiliza desvios em relação a uma média estimada a partir da própria amostra. A centralização impõe

$$\sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{X}}) = \mathbf{0},$$

de modo que os n vetores de desvios estão sujeitos a uma restrição linear.

A relação

$$E(\mathbf{T}) = (n-1)\Sigma$$

é um resultado de primeira esperança e **não** exige que a população seja normal. A distribuição completa de $\mathbf{T}$ sob normalidade será tratada no Capítulo 12.

10.5.4 Estimador não viesado da matriz de covariâncias

Definição 10.14 (Matriz de covariâncias amostral). Para $n \geq 2$, define-se

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}. \quad (10.69)$$

Após a observação,

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}. \quad (10.70)$$

Por Proposição 10.10,

$$E(\mathbf{S}) = \Sigma. \quad (10.71)$$

Portanto, $\mathbf{S}$ é um estimador não viesado de Σ .

Componente a componente,

$$s_{jk} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j)(X_{ik} - \bar{X}_k). \quad (10.72)$$

Para $j = k$,

$$s_{jj} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2$$

é a variância amostral da variável j .

Assim,

$$\mathbf{S} = \begin{bmatrix} S_{11} & S_{12} & \cdots & S_{1p} \\ S_{21} & S_{22} & \cdots & S_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ S_{p1} & S_{p2} & \cdots & S_{pp} \end{bmatrix}.$$

A divisão por $n-1$ corrige o viés associado à centralização pela média amostral. Ela não é escolhida para tornar a matriz positiva semidefinida: essa propriedade decorre da estrutura de Gram da SSCP e permanece válida para qualquer multiplicação por uma constante positiva.

10.5.5 Estimador de máxima verossimilhança

Sob o modelo normal multivariado não singular, a seção de máxima verossimilhança mostrou que, quando o máximo existe,

$$\widehat{\Sigma}_{\text{MV}} = \frac{1}{n} \mathbf{T}.$$

Como

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T},$$

tem-se

$$\widehat{\Sigma}_{\text{MV}} = \frac{n-1}{n} \mathbf{S}. \quad (10.73)$$

Tomando esperança,

$$\begin{aligned} E(\widehat{\Sigma}_{\text{MV}}) &= \frac{1}{n} E(\mathbf{T}) \\ &= \frac{n-1}{n} \Sigma. \end{aligned} \quad (10.74)$$

Logo,

$$\text{Bias}(\widehat{\Sigma}_{\text{MV}}) = -\frac{1}{n} \Sigma. \quad (10.75)$$

O estimador de máxima verossimilhança é, portanto, viesado para Σ em amostras finitas.

A diferença entre

$$\frac{\mathbf{T}}{n} \quad \text{e} \quad \frac{\mathbf{T}}{n-1}$$

ilustra que as propriedades **máxima verossimilhança** e **não viesamento** correspondem a critérios diferentes.

Quando n aumenta,

$$\frac{n-1}{n} \rightarrow 1,$$

de modo que a diferença relativa entre os dois estimadores desaparece.

Dois divisores, dois critérios

A matriz

$$\frac{\mathbf{T}}{n}$$

surge como estimador de momentos e, sob o modelo normal e as condições de existência do máximo, como estimador de máxima verossimilhança.

A matriz

$$\frac{\mathbf{T}}{n-1}$$

é construída para satisfazer

$$E(\mathbf{S}) = \Sigma.$$

Nenhum dos dois divisores é universalmente “correto” sem especificar o critério de estimação.

10.5.6 Consistência dos estimadores de covariância

O não viesamento é uma propriedade para tamanho amostral fixo. A consistência descreve o comportamento quando n aumenta.

Proposição 10.11 (Consistência da matriz de covariâncias amostral). *Suponha p fixo e*

$$E(\|\mathbf{X}\|^2) < \infty.$$

Então,

$$\mathbf{S} \xrightarrow{P} \Sigma \quad (10.76)$$

quando $n \rightarrow \infty$.

Comprovação. Pela identidade

$$\frac{1}{n}\mathbf{T} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^\top - \bar{\mathbf{x}} \bar{\mathbf{x}}^\top, \quad (10.77)$$

a matriz com divisor n pode ser escrita como diferença entre o segundo momento amostral não central e o produto externo da média amostral.

Para cada par (j, k) , a condição de segundos momentos finitos implica

$$E(|X_j X_k|) < \infty.$$

Pela Lei dos Grandes Números,

$$\frac{1}{n} \sum_{i=1}^n X_{ij} X_{ik} \xrightarrow{P} E(X_j X_k),$$

e

$$\bar{X}_j \xrightarrow{P} \mu_j.$$

Logo, elemento a elemento,

$$\frac{1}{n} \mathbf{T} \xrightarrow{P} E(\mathbf{X}\mathbf{X}^\top) - \mu\mu^\top = \Sigma.$$

Como p é fixo,

$$\mathbf{S} = \frac{n}{n-1} \left(\frac{\mathbf{T}}{n} \right) \xrightarrow{P} \Sigma.$$

□

Pela mesma argumentação,

$$\widehat{\Sigma}_{\text{MV}} = \frac{\mathbf{T}}{n} \xrightarrow{P} \Sigma \quad (10.78)$$

sempre que a expressão é considerada como estatística. No modelo normal positivo definido, sua interpretação como estimador de máxima verossimilhança requer adicionalmente a existência do máximo discutida anteriormente.

A consistência apresentada aqui corresponde ao regime clássico de **dimensão fixa**. Quando p aumenta com n , a convergência deve ser analisada segundo o regime dimensional e a norma de interesse.

10.5.7 Transformações, posto e singularidade

As propriedades algébricas da SSCP observada foram desenvolvidas no Capítulo 8. Como elas valem para cada realização da amostra, também caracterizam as estatísticas $\mathbf{T}$ e $\mathbf{S}$ amostra a amostra.

Transformações afins. Considere

$$\mathbf{Y}_i = \mathbf{C}\mathbf{X}_i + \mathbf{d}, \quad i = 1, \dots, n,$$

com

$$\mathbf{C} \in \mathbb{R}^{q \times p}.$$

Como

$$\bar{\mathbf{Y}} = \mathbf{C}\bar{\mathbf{X}} + \mathbf{d},$$

os vetores centralizados satisfazem

$$\mathbf{Y}_i - \bar{\mathbf{Y}} = \mathbf{C}(\mathbf{X}_i - \bar{\mathbf{X}}).$$

Consequentemente,

$$\mathbf{T}_Y = \mathbf{C}\mathbf{T}_X\mathbf{C}^\top \tag{10.79}$$

e

$$\mathbf{S}_Y = \mathbf{C}\mathbf{S}_X\mathbf{C}^\top. \tag{10.80}$$

A translação $\mathbf{d}$ desaparece após a centralização.

O resultado amostral reproduz a transformação populacional

$$\Sigma_Y = \mathbf{C}\Sigma_X\mathbf{C}^\top.$$

Isso mostra a equivariância da matriz de covariâncias amostral sob transformações afins.

Simetria e semidefinição positiva. Para qualquer realização,

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c,$$

portanto,

$$\mathbf{T}^\top = \mathbf{T}$$

e

$$\mathbf{a}^\top \mathbf{T} \mathbf{a} = \|\mathbf{X}_c \mathbf{a}\|^2 \geq 0$$

para todo $\mathbf{a} \in \mathbb{R}^p$.

Como

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T},$$

a matriz $\mathbf{S}$ também é simétrica e positiva semidefinida.

Essa é a mesma estrutura de Gram já desenvolvida no Capítulo 8; aqui sua consequência é que o estimador nunca produz uma matriz de covariâncias com autovalores negativos em aritmética exata.

Variância de combinações lineares. Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{a}^\top \mathbf{S} \mathbf{a} = \frac{1}{n-1} \sum_{i=1}^n [\mathbf{a}^\top (\mathbf{X}_i - \bar{\mathbf{X}})]^2. \quad (10.81)$$

A forma quadrática é a variância amostral da variável projetada

$$\mathbf{a}^\top \mathbf{X}.$$

Portanto,

$$\mathbf{a}^\top \mathbf{S} \mathbf{a} = 0$$

se, e somente se, os valores observados da combinação linear $\mathbf{a}^\top \mathbf{X}_i$ são constantes na amostra.

Posto. Como

$$\mathcal{X}_c = \mathbf{H}_n \mathcal{X}$$

e

$$\text{posto}(\mathbf{H}_n) = n - 1,$$

tem-se, para qualquer realização,

$$\text{posto}(\mathbf{T}) = \text{posto}(\mathbf{X}_c) \leq \min(p, n - 1). \quad (10.82)$$

Como $\mathbf{S}$ é obtida por multiplicação de $\mathbf{T}$ por uma constante positiva,

$$\text{posto}(\mathbf{S}) = \text{posto}(\mathbf{T}). \quad (10.83)$$

Uma condição necessária para

$$\mathbf{S} \succ \mathbf{0}$$

é, portanto,

$$n \geq p + 1.$$

Mesmo quando essa desigualdade é satisfeita, a definição positiva depende de as colunas de $\mathbf{X}_c$ possuírem posto completo.

Se

$$p \geq n,$$

então

$$\text{posto}(\mathbf{S}) \leq n - 1 < p,$$

e $\mathbf{S}$ é necessariamente singular.

A singularidade significa que existe algum vetor não nulo

$$\mathbf{a} \in \mathbb{R}^p$$

tal que

$$\mathbf{S}\mathbf{a} = \mathbf{0}.$$

Equivalentemente,

$$\mathbf{a}^\top \mathbf{S}\mathbf{a} = 0,$$

de modo que a combinação linear correspondente apresenta variância amostral nula.

Inversão. Quando

$$\mathbf{S} \succ \mathbf{0},$$

sua inversa existe e pode ser utilizada em formas quadráticas e métricas baseadas na covariância estimada.

Se $\mathbf{S}$ é singular, $\mathbf{S}^{-1}$ não existe. A utilização de pseudoinversas ou de estimadores regularizados corresponde a escolhas distintas e será discutida na seção de aprofundamento.

Forma quadrática com covariância estimada

A substituição de Σ por $\mathbf{S}$ em uma forma de Mahalanobis produz uma quantidade baseada em parâmetros estimados.

Por isso, o resultado populacional do Capítulo 9,

$$D_M^2 \sim \chi_p^2,$$

não pode ser transferido diretamente para uma forma quadrática construída com $\mathbf{S}$.

As distribuições apropriadas para estatísticas que envolvem parâmetros estimados pertencem ao Capítulo 12.

O posto e a estabilidade numérica da matriz de covariâncias amostral tornam-se especialmente relevantes quando p não é pequeno em relação a n . Antes de discutir esse regime, serão construídos os estimadores correspondentes para covariâncias entre blocos e para correlações.

10.6 Estimação de covariâncias cruzadas e correlações

Em diversos problemas multivariados, as variáveis são organizadas em blocos observados sobre as mesmas unidades amostrais. As covariâncias cruzadas descrevem associações lineares entre variáveis pertencentes a blocos distintos, enquanto as correlações removem as escalas marginais dessas associações.

O Capítulo 8 introduziu essas matrizes no nível descritivo. Nesta seção, elas são tratadas como estatísticas e estimadores de seus correspondentes populacionais.

10.6.1 Covariâncias cruzadas entre blocos

Considere os vetores aleatórios

$$\mathbf{X} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{Y} \in \mathbb{R}^q,$$

com

$$E(\mathbf{X}) = \mu_X$$

e

$$E(\mathbf{Y}) = \mu_Y.$$

A matriz de covariâncias cruzadas populacional é

$$\Sigma_{XY} = E \left[(\mathbf{X} - \mu_X) (\mathbf{Y} - \mu_Y)^\top \right] \in \mathbb{R}^{p \times q}. \quad (10.84)$$

Seu elemento (j, k) é

$$[\Sigma_{XY}]_{jk} = \text{Cov}(X_j, Y_k).$$

Em geral, Σ_{XY} não é quadrada nem simétrica. A inversão da ordem dos blocos fornece

$$\Sigma_{YX} = \Sigma_{XY}^\top. \quad (10.85)$$

Para o vetor conjunto

$$\begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix},$$

denote sua matriz de covariâncias por

$$\Sigma_{\text{conj}} = \begin{bmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{bmatrix}. \quad (10.86)$$

Para estimar Σ_{XY} , é necessária uma amostra **pareada**:

$$(\mathbf{X}_1, \mathbf{Y}_1), \dots, (\mathbf{X}_n, \mathbf{Y}_n),$$

independente e identicamente distribuída segundo a distribuição conjunta de

$$(\mathbf{X}, \mathbf{Y}).$$

O pareamento significa que $\mathbf{X}_i$ e $\mathbf{Y}_i$ correspondem à mesma unidade amostral. Alterar a correspondência entre as linhas dos dois blocos modifica as covariâncias cruzadas.

Organize as observações nas matrizes aleatórias

$$\mathcal{X} \in \mathbb{R}^{n \times p}$$

e

$$\mathcal{Y} \in \mathbb{R}^{n \times q}.$$

Após a centralização,

$$\mathcal{X}_c = \mathbf{H}_n \mathcal{X}$$

e

$$\mathcal{Y}_c = \mathbf{H}_n \mathcal{Y}.$$

Definição 10.15 (SSCP cruzada entre blocos). A matriz de somas de produtos cruzados centralizados entre os dois blocos é

$$\mathbf{T}_{XY} = \mathcal{X}_c^\top \mathcal{Y}_c. \quad (10.87)$$

Equivalentemente,

$$\mathbf{T}_{XY} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{y}_i - \bar{\mathbf{y}})^\top. \quad (10.88)$$

Após a observação,

$$\mathbf{T}_{XY} = \mathbf{X}_c^\top \mathbf{Y}_c. \quad (10.89)$$

A inversão da ordem dos blocos produz

$$\mathbf{T}_{YX} = \mathbf{T}_{XY}^\top$$

e

$$\mathbf{T}_{YX} = \mathbf{T}_{XY}^\top.$$

Definição 10.16 (Matriz de covariâncias cruzadas amostral). Para $n \geq 2$,

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{T}_{XY}. \quad (10.90)$$

Após a observação da amostra,

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{T}_{XY} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{Y}_c. \quad (10.91)$$

Seu elemento (j, k) é

$$S_{X_j Y_k} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j) (Y_{ik} - \bar{Y}_k). \quad (10.92)$$

Proposição 10.12 (Não viesamento da covariância cruzada amostral). *Considere uma amostra pareada i.i.d. do vetor conjunto*

$$\begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix},$$

com segundos momentos finitos. Então,

$$E(\mathbf{S}_{XY}) = \Sigma_{XY}. \quad (10.93)$$

Comprovação. A matriz de covariâncias amostral do vetor conjunto é

$$\mathbf{S}_{\text{conj}} = \begin{bmatrix} \mathbf{S}_{XX} & \mathbf{S}_{XY} \\ \mathbf{S}_{YX} & \mathbf{S}_{YY} \end{bmatrix}.$$

Pelo não viesamento da matriz de covariâncias amostral,

$$E(\mathbf{S}_{\text{conj}}) = \Sigma_{\text{conj}}.$$

A igualdade entre os blocos superiores direitos fornece

$$E(\mathbf{S}_{XY}) = \Sigma_{XY}.$$

□

Sob normalidade conjunta não singular,

$$\begin{bmatrix} \mathbf{X}_i \\ \mathbf{Y}_i \end{bmatrix} \stackrel{\text{iid}}{\sim} N_{p+q} \left(\begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, \Sigma_{\text{conj}} \right),$$

o estimador de máxima verossimilhança da matriz conjunta de covariâncias, quando existe, utiliza o divisor n . Consequentemente, seu bloco cruzado é

$$\widehat{\Sigma}_{XY, \text{MV}} = \frac{1}{n} \mathbf{T}_{XY} = \frac{n-1}{n} \mathbf{S}_{XY}. \quad (10.94)$$

Se

$$n \geq p + q + 1$$

e a distribuição normal conjunta é não singular, a SSCP do vetor conjunto possui posto $p + q$ com probabilidade 1. Nessas condições, o estimador positivo definido de máxima verossimilhança da matriz conjunta existe com probabilidade 1.

Além disso,

$$E(\widehat{\Sigma}_{XY, \text{MV}}) = \frac{n-1}{n} \Sigma_{XY}.$$

A covariância cruzada amostral também respeita transformações lineares. Se

$$\mathbf{U} = \mathbf{C}\mathbf{X} + \mathbf{c}$$

e

$$\mathbf{V} = \mathbf{D}\mathbf{Y} + \mathbf{d},$$

então

$$\mathbf{S}_{UV} = \mathbf{C}\mathbf{S}_{XY}\mathbf{D}^\top. \quad (10.95)$$

Para

$$U = \mathbf{a}^\top \mathbf{X}$$

e

$$V = \mathbf{b}^\top \mathbf{Y},$$

segue que

$$S_{UV} = \mathbf{a}^\top \mathbf{S}_{XY} \mathbf{b}. \quad (10.96)$$

O posto satisfaz

$$\text{posto}(\mathbf{S}_{XY}) \leq \min(p, q, n - 1). \quad (10.97)$$

Esse limite será relevante posteriormente em técnicas que utilizam simultaneamente dois conjuntos de variáveis.

10.6.2 Matriz de correlações amostral

A matriz de correlações amostral é obtida pela padronização das covariâncias pelas variâncias marginais correspondentes.

Considere

$$\mathbf{S} = (S_{jk})$$

e defina

$$\mathbf{D}_S = \text{diag}(S_{11}, \dots, S_{pp}).$$

A construção exige

$$S_{jj} > 0, \quad j = 1, \dots, p.$$

Definição 10.17 (Matriz de correlações amostral). Quando todas as variâncias amostrais são positivas,

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}. \quad (10.98)$$

Após a observação,

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}, \quad (10.99)$$

em que

$$\mathbf{D}_S = \text{diag}(s_{11}, \dots, s_{pp}).$$

O elemento (j, k) é

$$r_{jk} = \frac{s_{jk}}{\sqrt{s_{jj}s_{kk}}}. \quad (10.100)$$

A diagonal satisfaz

$$r_{jj} = 1.$$

O Capítulo 8 mostrou que $\mathbf{R}$ também pode ser interpretada como uma matriz de Gram das colunas centralizadas e padronizadas. Essa representação fornece

$$-1 \leq r_{jk} \leq 1$$

e relaciona r_{jk} ao cosseno do ângulo entre essas colunas. Aqui, a ênfase recai sobre $\mathbf{R}$ como estatística utilizada para estimar a matriz populacional $\mathcal{R}$.

Existência da correlação amostral

A correlação envolvendo uma variável não está definida quando sua variância amostral é zero.

Se

$$S_{jj} = 0$$

a correspondente padronização não existe.

10.6.3 Propriedades estruturais

Proposição 10.13 (Propriedades da matriz de correlações amostral). *Quando todas as variâncias amostrais são positivas, $\mathbf{R}$ é:*

1. *simétrica;*
2. *positiva semidefinida;*
3. *unitária na diagonal.*

Além disso,

$$\text{posto}(\mathbf{R}) = \text{posto}(\mathbf{S}). \quad (10.101)$$

Consequentemente,

$$\mathbf{R} \succ \mathbf{0} \iff \mathbf{S} \succ \mathbf{0}. \quad (10.102)$$

Comprovação. A simetria decorre da simetria de $\mathbf{S}$.

Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\begin{aligned} \mathbf{a}^\top \mathbf{R} \mathbf{a} &= (\mathbf{D}_S^{-1/2} \mathbf{a})^\top \mathbf{S} (\mathbf{D}_S^{-1/2} \mathbf{a}) \\ &\geq 0. \end{aligned}$$

Logo, $\mathbf{R}$ é positiva semidefinida.

A diagonal unitária decorre de

$$R_{jj} = \frac{S_{jj}}{S_{jj}} = 1$$

Como $\mathbf{D}_S^{-1/2}$ é invertível, a transformação por congruência preserva o posto e a definitude positiva. $\square$

Uma matriz simétrica com diagonal unitária e elementos em $[-1, 1]$ não é necessariamente uma matriz de correlações válida. A positividade semidefinida também é necessária.

Como

$$\text{posto}(\mathbf{R}) = \text{posto}(\mathbf{S}),$$

uma condição necessária para definitude positiva é

$$n \geq p + 1.$$

Essa condição não é suficiente para uma amostra arbitrária, pois ainda podem existir dependências lineares entre as colunas centralizadas.

Quando

$$p \geq n,$$

a matriz de correlações, se definida, é necessariamente singular.

Para uma realização observada,

$$\det(\mathbf{R}) = \frac{\det(\mathbf{S})}{\prod_{j=1}^p s_{jj}}. \quad (10.103)$$

A padronização remove as escalas marginais, mas não altera o posto.

Sob o modelo normal multivariado, quando o estimador de máxima verossimilhança de Σ existe,

$$\widehat{\Sigma}_{\text{MV}} = \frac{n-1}{n} \mathbf{S}.$$

O fator comum $(n-1)/n$ cancela-se na transformação de covariâncias em correlações. Pela Proposição 10.4,

$$\widehat{\mathcal{R}}_{\text{MV}} = \mathbf{R}. \quad (10.104)$$

Essa igualdade é específica do modelo normal considerado e da existência do estimador de máxima verossimilhança da matriz de covariâncias.

Ela também **não implica não viesamento**. Em geral,

$$E(R_{jk}) \neq \rho_{jk}.$$

A correlação amostral é uma função não linear das covariâncias e variâncias amostrais.

Se

$$\mathbf{S} \xrightarrow{P} \Sigma$$

e

$$\sigma_{jj} > 0, \quad j = 1, \dots, p,$$

então, no regime de dimensão fixa, o teorema do mapeamento contínuo fornece

$$\mathbf{R} \xrightarrow{P} \mathcal{R}. \quad (10.105)$$

10.6.4 Transformações de localização e escala

Considere

$$Y_j = a_j + b_j X_j, \quad b_j \neq 0.$$

A localização a_j desaparece após a centralização. Para duas variáveis transformadas,

$$r_{Y_j Y_k} = \operatorname{sgn}(b_j) \operatorname{sgn}(b_k) r_{X_j X_k}. \quad (10.106)$$

Portanto:

- se b_j e b_k são positivos, a correlação permanece inalterada;
- se somente um dos fatores de escala muda de sinal, a correlação muda de sinal;
- mudanças de localização não alteram a correlação.

Em forma matricial, para

$$\mathbf{Y} = \mathbf{X}\mathbf{D}_b + \mathbf{1}_n \mathbf{a}^\top,$$

com

$$\mathbf{D}_b = \operatorname{diag}(b_1, \dots, b_p),$$

defina

$$\mathbf{D}_{\text{sgn}} = \text{diag} [\text{sgn}(b_1), \dots, \text{sgn}(b_p)] .$$

Então,

$$\mathbf{R}_Y = \mathbf{D}_{\text{sgn}} \mathbf{R}_X \mathbf{D}_{\text{sgn}} . \quad (10.107)$$

Se todos os fatores de escala são positivos,

$$\mathbf{R}_Y = \mathbf{R}_X .$$

Para dois blocos, defina

$$\mathbf{D}_X = \text{diag} (s_{X_1 X_1}, \dots, s_{X_p X_p})$$

e

$$\mathbf{D}_Y = \text{diag} (s_{Y_1 Y_1}, \dots, s_{Y_q Y_q}) .$$

Quando todas as variâncias envolvidas são positivas, a matriz de correlações cruzadas é

$$\mathbf{R}_{XY} = \mathbf{D}_X^{-1/2} \mathbf{S}_{XY} \mathbf{D}_Y^{-1/2} . \quad (10.108)$$

Seu elemento (j, k) é

$$r_{X_j Y_k} = \frac{s_{X_j Y_k}}{\sqrt{s_{X_j X_j} s_{Y_k Y_k}}} .$$

Além disso,

$$\mathbf{R}_{YX} = \mathbf{R}_{XY}^\top .$$

A matriz de correlações do vetor conjunto assume a forma

$$\mathbf{R}_{\text{conj}} = \begin{bmatrix} \mathbf{R}_{XX} & \mathbf{R}_{XY} \\ \mathbf{R}_{YX} & \mathbf{R}_{YY} \end{bmatrix} . \quad (10.109)$$

As matrizes Σ_{XY} , $\mathbf{S}_{XY}$ e $\mathbf{R}_{XY}$ serão utilizadas posteriormente em métodos que relacionam dois conjuntos de variáveis. Sua formulação completa pertence aos módulos posteriores.

Antes do exemplo integrado, convém examinar situações em que a dimensão, a redundância ou a sensibilidade das estatísticas clássicas dificultam a estimação da matriz de covariâncias.

10.7 Aprofundamento: dimensão, estabilidade e extensões da estimação

Esta seção examina situações em que a dimensão, o condicionamento ou a sensibilidade das estatísticas amostrais exigem cuidados adicionais. Os resultados anteriores constituem o núcleo da estimação clássica; regularização e robustez são extensões motivadas por limitações específicas desse núcleo.

A matriz de covariâncias de um vetor com p componentes possui

$$\frac{p(p+1)}{2}$$

parâmetros distintos. O número de elementos a estimar cresce quadraticamente com p , enquanto o número de unidades disponíveis permanece igual a n .

Regularização e robustez respondem a problemas diferentes:

- **regularização** procura reduzir instabilidade associada à dimensão, redundância, pequeno tamanho amostral ou mau condicionamento;
- **estimação robusta** procura reduzir sensibilidade a determinadas formas de contaminação ou desvios do modelo.

As duas abordagens podem ser combinadas, mas não são equivalentes.

10.7.1 Relação entre p e n

O limite

$$\text{posto}(\mathbf{S}) \leq \min(p, n-1)$$

permite distinguir diferentes regimes dimensionais.

Dimensão fixa. No regime clássico,

$$p$$

permanece fixo enquanto

$$n \longrightarrow \infty.$$

Sob segundos momentos finitos,

$$\mathbf{S} \xrightarrow{P} \Sigma.$$

Em dimensão fixa, a convergência elemento a elemento implica convergência em qualquer norma matricial equivalente.

Se

$$\Sigma \succ \mathbf{0},$$

a matriz amostral tende a reproduzir essa estrutura à medida que o tamanho amostral cresce.

Dimensão crescente. Quando

$$p = p_n$$

também aumenta com n , a análise muda. Uma situação de referência é

$$\frac{p_n}{n} \longrightarrow c, \quad 0 < c < 1.$$

Nesse regime, a matriz de covariâncias amostral pode possuir posto completo e, ainda assim, apresentar elevada variabilidade em seu espectro.

O controle dos elementos individuais não garante, por si só, controle da matriz em norma espectral. Por isso, não implica automaticamente precisão na estimação de:

- autovalores;
- autovetores;
- inversa;
- determinante;
- formas quadráticas que dependem de $\mathbf{S}^{-1}$.

Além disso, o número de covariâncias fora da diagonal é

$$\frac{p(p-1)}{2},$$

e todas são estimadas a partir das mesmas n unidades.

Não existe um valor universal de p/n que separe matrizes estáveis e instáveis. O comportamento depende também da estrutura de Σ , da separação entre seus autovalores, da distribuição populacional e da função da matriz utilizada posteriormente.

Dimensão maior ou igual ao tamanho amostral. Se

$$p \geq n,$$

então

$$\text{posto}(\mathbf{S}) \leq n - 1 < p,$$

e a matriz é necessariamente singular.

Essa singularidade não implica

$$\Sigma$$

singular. Ela pode decorrer exclusivamente da quantidade limitada de direções observáveis depois da centralização.

Posto amostral e posto populacional

Quando

$$p \geq n,$$

$\mathbf{S}$ é singular por construção, mesmo que

$$\Sigma \succ \mathbf{0}.$$

Posto amostral e posto populacional são, portanto, objetos distintos.

10.7.2 Condicionamento e inversão

Considere uma realização positiva definida,

$$\mathbf{S} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^\top,$$

com

$$\mathbf{\Lambda} = \text{diag}(\ell_1, \dots, \ell_p),$$

e

$$\ell_1 \geq \dots \geq \ell_p > 0.$$

A inversa é

$$\mathbf{S}^{-1} = \mathbf{Q}\mathbf{\Lambda}^{-1}\mathbf{Q}^\top.$$

Autovalores pequenos de $\mathbf{S}$ tornam-se pesos elevados em $\mathbf{S}^{-1}$.

O número de condição espectral foi definido em Definição 6.9. Para uma matriz simétrica positiva definida,

$$\kappa_2(\mathbf{S}) = \frac{\ell_{\max}(\mathbf{S})}{\ell_{\min}(\mathbf{S})}. \quad (10.110)$$

Quando o menor autovalor se aproxima de zero,

$$\kappa_2(\mathbf{S})$$

aumenta. Se $\mathbf{S}$ é singular, o número de condição relativo à inversão é infinito.

Uma matriz pode, portanto, ser invertível e ainda estar mal condicionada.

Isso importa estatisticamente porque pequenas perturbações na matriz estimada podem produzir alterações relevantes em

$$\mathbf{S}^{-1}.$$

O determinante também depende de todo o espectro:

$$\det(\mathbf{S}) = \prod_{j=1}^p \ell_j.$$

Já a estabilidade dos autovetores depende não somente da magnitude dos autovalores, mas também de sua separação. Autovalores muito próximos podem produzir direções individuais sensíveis a pequenas perturbações.

Considere, por exemplo,

$$d_{\mathbf{S}}^2(\mathbf{x}, \bar{\mathbf{x}}) = (\mathbf{x} - \bar{\mathbf{x}})^\top \mathbf{S}^{-1} (\mathbf{x} - \bar{\mathbf{x}}).$$

Nas coordenadas dos autovetores,

$$d_{\mathbf{S}}^2(\mathbf{x}, \bar{\mathbf{x}}) = \sum_{j=1}^p \frac{z_j^2}{\ell_j}.$$

Assim, direções de pequena variância estimada recebem pesos elevados.

Inversão computacional

A existência de $\mathbf{S}^{-1}$ não significa que seja necessário formá-la explicitamente. Quando o objetivo é calcular

$$\mathbf{S}^{-1}\mathbf{b},$$

é preferível, em geral, resolver o sistema

$$\mathbf{S}\mathbf{x} = \mathbf{b}.$$

Essa escolha não elimina o mau condicionamento, mas evita uma inversão explícita desnecessária.

10.7.3 Regularização

A regularização substitui a matriz de covariâncias amostral por outro estimador que incorpora alguma estrutura adicional. O objetivo pode ser reduzir variabilidade, melhorar condicionamento ou produzir uma matriz invertível.

Uma classe simples combina $\mathbf{S}$ com uma matriz-alvo (Ledoit; Wolf, 2004).

Definição 10.18 (Estimador de covariância por contração). Considere

$$\Gamma \in \mathbb{R}^{p \times p}, \quad \Gamma \succeq \mathbf{0},$$

e

$$0 \leq \lambda \leq 1.$$

Define-se

$$\widehat{\Sigma}_\lambda = (1 - \lambda)\mathbf{S} + \lambda\Gamma. \quad (10.111)$$

Para

$$\lambda = 0,$$

recupera-se $\mathbf{S}$. Para

$$\lambda = 1,$$

o estimador coincide com o alvo.

A contração geralmente introduz viés. Sua avaliação deve, portanto, considerar uma função de perda ou risco, e não somente o não viesamento.

Em aplicações, o alvo e o peso podem ser estimados a partir dos próprios dados. Nesse caso,

$$\widehat{\Sigma}_{\widehat{\lambda}} = (1 - \widehat{\lambda})\mathbf{S} + \widehat{\lambda}\widehat{\Gamma}. \quad (10.112)$$

A aleatoriedade de $\widehat{\lambda}$ e de $\widehat{\Gamma}$ passa, então, a fazer parte das propriedades do estimador.

A matriz-alvo precisa ser compatível com as unidades e escalas das variáveis. Algumas escolhas conceituais são:

- um alvo diagonal, que preserva escalas marginais e reduz covariâncias;
- um alvo esférico $\tau\mathbf{I}_p$, quando uma escala comum possui interpretação;
- a identidade $\mathbf{I}_p$ na regularização de uma matriz de correlações;
- uma estrutura baseada em conhecimento substantivo.

A identidade não é um alvo neutro para uma matriz de covariâncias com variáveis medidas em unidades distintas.

Um alvo esférico adaptado à escala observada pode utilizar

$$\hat{\tau} = \frac{1}{p} \text{tr}(\mathbf{S}), \quad (10.113)$$

levando a

$$\hat{\Sigma}_{\lambda} = (1 - \lambda)\mathbf{S} + \lambda\hat{\tau}\mathbf{I}_p. \quad (10.114)$$

Essa escolha pressupõe que uma variância média comum tenha significado para as variáveis consideradas.

Outro alvo é

$$\hat{\Gamma}_{\text{diag}} = \text{diag}(S_{11}, \dots, S_{pp})$$

com

$$\hat{\Sigma}_{\lambda, \text{diag}} = (1 - \lambda)\mathbf{S} + \lambda\hat{\Gamma}_{\text{diag}}. \quad (10.115)$$

Nesse caso, as variâncias amostrais permanecem inalteradas e as covariâncias são multiplicadas por $1 - \lambda$.

Proposição 10.14 (Definitude positiva do estimador por contração). *Se*

$$\mathbf{S} \succeq \mathbf{0},$$

$$\Gamma \succ \mathbf{0}$$

e

$$0 < \lambda \leq 1,$$

então

$$\hat{\Sigma}_{\lambda} \succ \mathbf{0}. \quad (10.116)$$

Comprovação. Para qualquer $\mathbf{a} \neq \mathbf{0}$,

$$\mathbf{a}^\top \widehat{\Sigma}_\lambda \mathbf{a} = (1 - \lambda) \mathbf{a}^\top \mathbf{S} \mathbf{a} + \lambda \mathbf{a}^\top \Gamma \mathbf{a}.$$

A primeira parcela é não negativa e a segunda é estritamente positiva. Logo,

$$\mathbf{a}^\top \widehat{\Sigma}_\lambda \mathbf{a} > 0.$$

□

Com um alvo esférico,

$$\Gamma = \tau \mathbf{I}_p, \quad \tau > 0,$$

e uma decomposição

$$\mathbf{S} = \mathbf{Q} \operatorname{diag}(L_1, \dots, L_p) \mathbf{Q}^\top,$$

obtém-se

$$\widehat{\Sigma}_\lambda = \mathbf{Q} \operatorname{diag}[(1 - \lambda)L_1 + \lambda\tau, \dots, (1 - \lambda)L_p + \lambda\tau] \mathbf{Q}^\top. \quad (10.117)$$

Portanto,

$$L_{j,\lambda} = (1 - \lambda)L_j + \lambda\tau. \quad (10.118)$$

Se

$$L_j = 0$$

e

$$\lambda > 0,$$

então

$$L_{j,\lambda} = \lambda\tau > 0.$$

A contração esférica afasta os autovalores de zero e pode melhorar o condicionamento. Essa propriedade algébrica não determina, por si só, a adequação estatística do alvo ou do valor de λ .

A Figura 10.2 compara o espectro da covariância amostral com uma versão regularizada.




Figura 10.2: Espectros da matriz de covariâncias amostral e de sua versão regularizada em dois regimes dimensionais.

No regime $p < n$, a regularização desloca os autovalores na direção do alvo. No regime $p \geq n$, os autovalores nulos decorrentes do limite de posto são substituídos por valores positivos.

A figura mostra um efeito algébrico da regularização. A escolha de λ e do alvo é um problema estatístico distinto e não será desenvolvida algoritmicamente neste capítulo.

10.7.4 Pseudoinversa e regularização

A pseudoinversa de Moore–Penrose já foi desenvolvida no Módulo 1. Se

$$\mathbf{S} = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top$$

é a decomposição espectral reduzida com r autovalores positivos, então

$$\mathbf{S}^+ = \mathbf{Q}_r \Lambda_r^{-1} \mathbf{Q}_r^\top. \quad (10.119)$$

A pseudoinversa e a regularização resolvem problemas matemáticos diferentes.

Para visualizar essa diferença, considere

$$\mathbf{S} = \mathbf{Q} \operatorname{diag}(\ell_1, \dots, \ell_p) \mathbf{Q}^\top,$$

com

$$\ell_j \geq 0.$$

A pseudoinversa atribui os pesos

$$\begin{cases} 1/\ell_j, & \ell_j > 0, \\ 0, & \ell_j = 0. \end{cases}$$

Considere agora

$$\mathbf{S}_\lambda = (1 - \lambda)\mathbf{S} + \lambda\tau\mathbf{I}_p,$$

com

$$0 < \lambda \leq 1 \quad \text{e} \quad \tau > 0.$$

Sua inversa é

$$\mathbf{S}_\lambda^{-1} = \mathbf{Q} \operatorname{diag} \left[\frac{1}{(1 - \lambda)\ell_j + \lambda\tau} \right] \mathbf{Q}^\top. \quad (10.120)$$

Se

$$\ell_j = 0,$$

a pseudoinversa atribui peso zero, enquanto a inversa regularizada atribui

$$\frac{1}{\lambda\tau}.$$

Assim:

- a **pseudoinversa** mantém a matriz estimada e generaliza algebricamente a operação de inversão;
- a **regularização** modifica primeiro a matriz estimada e, portanto, define outro procedimento estatístico;
- a pseudoinversa não reduz os pesos $1/\ell_j$ associados a autovalores positivos muito pequenos;
- a regularização pode limitar essa amplificação ao afastar esses autovalores de zero.

Invertibilidade não implica validade inferencial

Substituir $\mathbf{S}^{-1}$ por $\mathbf{S}^+$ ou por uma inversa regularizada modifica a estatística utilizada. Distribuições amostrais e calibrações inferenciais derivadas para a inversa clássica não podem ser transferidas automaticamente para essas substituições.

10.7.5 Sensibilidade e robustez

A média e a matriz de covariâncias amostrais podem apresentar grande sensibilidade a observações extremas (Maronna et al., 2019).

Considere a substituição de uma observação $\mathbf{x}_k$ por $\mathbf{x}_k^*$. A nova média é

$$\bar{\mathbf{x}}^* = \bar{\mathbf{x}} + \frac{1}{n} (\mathbf{x}_k^* - \mathbf{x}_k). \quad (10.121)$$

Portanto,

$$\bar{\mathbf{x}}^* - \bar{\mathbf{x}} = \frac{1}{n} (\mathbf{x}_k^* - \mathbf{x}_k).$$

A alteração pode assumir magnitude arbitrariamente grande quando a observação substituída se afasta da nuvem de dados.

Na matriz de covariâncias, os produtos externos

$$(\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top$$

fazem com que observações afastadas possam modificar simultaneamente dispersões, covariâncias e direções espectrais.

Uma observação extrema não deve ser identificada automaticamente como erro. Ela pode corresponder, por exemplo, a:

- uma unidade válida de baixa frequência;
- outra população;
- erro de registro;
- caudas mais pesadas que as admitidas pelo modelo;
- assimetria ou heterogeneidade não modelada.

A decisão substantiva sobre a observação exige conhecimento do processo de coleta.

Estimadores robustos de localização e dispersão procuram limitar determinados tipos de sensibilidade. Sua comparação envolve critérios como:

- resistência à contaminação;
- eficiência sob um modelo de referência;
- equivariância;
- condições de existência em função de n e p ;
- custo computacional;
- funcional populacional estimado.

Não existe um procedimento robusto que domine universalmente todos os demais segundo esses critérios.

Também é necessário distinguir:

1. **observações extremas**, relacionadas à sensibilidade;
2. **alta dimensão**, relacionada ao número de parâmetros, posto e estabilidade;
3. **má especificação**, relacionada à inadequação da família probabilística adotada.

Esses problemas podem ocorrer simultaneamente, mas não possuem a mesma solução.

A análise de uma matriz de covariâncias estimada deve, portanto, considerar conjuntamente:

- tamanho amostral e dimensão;
- posto;
- espectro;
- condicionamento;
- estabilidade da inversão;
- escalas das variáveis;
- sensibilidade das estimativas;
- necessidade de regularização;
- finalidade estatística da matriz.

O exemplo integrado a seguir reúne os principais objetos construídos no capítulo em uma única amostra.

10.8 Exemplo integrado

O exemplo reúne a estimação da localização, da dispersão e das relações entre dois blocos de variáveis. Como os cálculos são realizados para uma amostra observada, os resultados numéricos são estimativas, representadas pelos correspondentes objetos observados.

Exemplo 10.1 (Estimação em dois blocos de variáveis). Considere seis unidades amostrais nas quais foram observados dois blocos de variáveis. O primeiro bloco contém três variáveis:

$$\mathbf{X} = \begin{bmatrix} 2 & 4 & 1 \\ 3 & 5 & 3 \\ 5 & 6 & 4 \\ 6 & 8 & 6 \\ 4 & 7 & 2 \\ 7 & 9 & 7 \end{bmatrix} \in \mathbb{R}^{6 \times 3}.$$

O segundo bloco contém duas variáveis observadas nas mesmas unidades:

$$\mathbf{Y} = \begin{bmatrix} 1 & 3 \\ 3 & 2 \\ 4 & 5 \\ 5 & 7 \\ 3 & 4 \\ 8 & 6 \end{bmatrix} \in \mathbb{R}^{6 \times 2}.$$

A correspondência entre as linhas de $\mathbf{X}$ e $\mathbf{Y}$ precisa ser preservada para a estimação das covariâncias cruzadas.

Os vetores de médias observados são

$$\bar{\mathbf{x}} = \frac{1}{6} \mathbf{X}^\top \mathbf{1}_6 = \begin{bmatrix} 4,5 \\ 6,5 \\ 3,833 \end{bmatrix}$$

e

$$\bar{\mathbf{y}} = \frac{1}{6} \mathbf{Y}^\top \mathbf{1}_6 = \begin{bmatrix} 4,0 \\ 4,5 \end{bmatrix}.$$

Para o primeiro bloco, a SSCP observada é

$$\begin{aligned}\mathbf{T}_X &= \mathbf{X}_c^\top \mathbf{X}_c \\ &= \begin{bmatrix} 17,5 & 16,5 & 20,5 \\ 16,5 & 17,5 & 18,5 \\ 20,5 & 18,5 & 26,833 \end{bmatrix}.\end{aligned}$$

A matriz de covariâncias amostral, com divisor

$$n - 1 = 5,$$

é

$$\begin{aligned}\mathbf{S}_X &= \frac{1}{5} \mathbf{T}_X \\ &= \begin{bmatrix} 3,500 & 3,300 & 4,100 \\ 3,300 & 3,500 & 3,700 \\ 4,100 & 3,700 & 5,367 \end{bmatrix}.\end{aligned}\tag{10.122}$$

A matriz $\mathbf{S}_X$ é o valor observado do estimador não viesado $\mathbf{S}_X$ de Σ_{XX} .

Se for adotado o modelo normal multivariado e considerando que, nesta amostra,

$$\text{posto}(\mathbf{T}_X) = 3,$$

o estimador de máxima verossimilhança da matriz de covariâncias existe. Sua estimativa observada é

$$\begin{aligned}\widehat{\Sigma}_{XX, \text{MV, obs}} &= \frac{1}{6} \mathbf{T}_X \\ &= \begin{bmatrix} 2,917 & 2,750 & 3,417 \\ 2,750 & 2,917 & 3,083 \\ 3,417 & 3,083 & 4,472 \end{bmatrix}.\end{aligned}\tag{10.123}$$

As duas matrizes estão relacionadas por

$$\widehat{\Sigma}_{XX, \text{MV, obs}} = \frac{5}{6} \mathbf{S}_X.$$

Consequentemente, possuem os mesmos autovetores, o mesmo posto e o mesmo número de condição. Seus autovalores diferem pelo fator 5/6.

A matriz de correlações do primeiro bloco é

$$\mathbf{R}_X = \begin{bmatrix} 1,000 & 0,943 & 0,946 \\ 0,943 & 1,000 & 0,854 \\ 0,946 & 0,854 & 1,000 \end{bmatrix}. \quad (10.124)$$

As três correlações são positivas. A maior correlação amostral ocorre entre X_1 e X_3 :

$$r_{13} \approx 0,946,$$

enquanto a menor ocorre entre X_2 e X_3 :

$$r_{23} \approx 0,854.$$

Os autovalores de $\mathbf{S}_X$, em ordem decrescente, são aproximadamente

$$\ell_1 = 11,648, \quad \ell_2 = 0,627 \quad \text{e} \quad \ell_3 = 0,092.$$

Como todos são positivos,

$$\text{posto}(\mathbf{S}_X) = 3,$$

e

$$\mathbf{S}_X \succ \mathbf{0}.$$

Seu número de condição espectral é aproximadamente

$$\begin{aligned} \kappa_2(\mathbf{S}_X) &= \frac{\ell_1}{\ell_3} \\ &\approx 126,8. \end{aligned}$$

Portanto, $\mathbf{S}_X$ é invertível, mas apresenta autovalores de magnitudes bastante distintas. A existência da inversa não elimina a possibilidade de sensibilidade a pequenas perturbações.

Para estimar as relações entre os dois blocos, a SSCP cruzada observada é

$$\begin{aligned} \mathbf{T}_{XY} &= \mathbf{X}_c^\top \mathbf{Y}_c \\ &= \begin{bmatrix} 21,0 & 15,5 \\ 20,0 & 14,5 \\ 26,0 & 17,5 \end{bmatrix}. \end{aligned} \quad (10.125)$$

Logo,

$$\begin{aligned}\mathbf{S}_{XY} &= \frac{1}{5} \mathbf{T}_{XY} \\ &= \begin{bmatrix} 4,2 & 3,1 \\ 4,0 & 2,9 \\ 5,2 & 3,5 \end{bmatrix}.\end{aligned}\tag{10.126}$$

Por exemplo,

$$s_{X_3Y_1} = 5,2$$

é a covariância amostral entre a terceira variável do primeiro bloco e a primeira variável do segundo bloco.

A mudança da ordem dos blocos produz

$$\mathbf{S}_{YX} = \mathbf{S}_{XY}^\top = \begin{bmatrix} 4,2 & 4,0 & 5,2 \\ 3,1 & 2,9 & 3,5 \end{bmatrix}.$$

A matriz de covariâncias do segundo bloco é

$$\mathbf{S}_Y = \begin{bmatrix} 5,6 & 3,2 \\ 3,2 & 3,5 \end{bmatrix}.$$

Reunindo as cinco variáveis na matriz

$$\mathbf{X}_{\text{conj}} = [\mathbf{X} \quad \mathbf{Y}] \in \mathbb{R}^{6 \times 5},$$

a matriz de covariâncias conjunta pode ser escrita em blocos como

$$\mathbf{S}_{\text{conj}} = \begin{bmatrix} \mathbf{S}_X & \mathbf{S}_{XY} \\ \mathbf{S}_{YX} & \mathbf{S}_Y \end{bmatrix}.\tag{10.127}$$

Numericamente,

$$\mathbf{S}_{\text{conj}} = \begin{bmatrix} 3,500 & 3,300 & 4,100 & 4,200 & 3,100 \\ 3,300 & 3,500 & 3,700 & 4,000 & 2,900 \\ 4,100 & 3,700 & 5,367 & 5,200 & 3,500 \\ 4,200 & 4,000 & 5,200 & 5,600 & 3,200 \\ 3,100 & 2,900 & 3,500 & 3,200 & 3,500 \end{bmatrix}.\tag{10.128}$$

Como existem seis observações e cinco variáveis,

$$\text{posto}(\mathbf{S}_{\text{conj}}) \leq \min(5, 6 - 1) = 5.$$

Nesta amostra,

$$\text{posto}(\mathbf{S}_{\text{conj}}) = 5,$$

de modo que

$$\mathbf{S}_{\text{conj}} \succ \mathbf{0}.$$

O tamanho amostral

$$n = 6$$

é exatamente o menor que permite posto completo para uma matriz de covariâncias de cinco variáveis centralizadas. A igualdade

$$n = p + 1$$

permite posto completo, mas não o garante para uma amostra arbitrária; neste conjunto de dados, a condição é efetivamente satisfeita.

O exemplo reúne as principais distinções desenvolvidas no capítulo:

1. $\bar{\mathbf{x}}$ e $\bar{\mathbf{y}}$ são estimativas dos vetores de médias populacionais;
2. $\mathbf{T}_X$ é a realização observada da SSCP $\mathbf{T}_X$;
3. $\mathbf{S}_X$ é o valor observado de um estimador não viesado de Σ_{XX} ;
4. sob o modelo normal e as condições de existência do máximo, $\mathbf{T}_X/n$ fornece a estimativa de máxima verossimilhança da covariância;
5. $\mathbf{R}_X$ remove as escalas marginais das covariâncias;
6. posto completo não implica necessariamente bom condicionamento;
7. $\mathbf{T}_{XY}$ e $\mathbf{S}_{XY}$ dependem do pareamento entre os dois blocos;
8. a matriz conjunta reúne as covariâncias internas e cruzadas em uma única estrutura.

A amostra observada produz valores específicos para esses objetos. As propriedades dos estimadores referem-se, por sua vez, ao comportamento das estatísticas correspondentes ao longo das possíveis amostras.

10.9 Síntese do capítulo

Este capítulo estabeleceu a passagem dos parâmetros populacionais às estatísticas utilizadas para estimá-los. A distinção

$$\text{parâmetro} \longrightarrow \text{estimador} \longrightarrow \text{estimativa}$$

separa uma característica fixa da população, uma função aleatória da amostra e o valor calculado após a observação dos dados.

Para uma amostra multivariada i.i.d., os principais estimadores de localização e dispersão são

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i$$

e

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T},$$

em que

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}}) (\mathbf{X}_i - \bar{\mathbf{X}})^\top.$$

Sob segundos momentos finitos,

$$E(\bar{\mathbf{X}}) = \mu, \quad \text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n},$$

e

$$E(\mathbf{S}) = \Sigma.$$

No regime de dimensão fixa,

$$\bar{\mathbf{X}} \xrightarrow{P} \mu$$

e

$$\mathbf{S} \xrightarrow{P} \Sigma.$$

Sob o modelo normal multivariado, quando o máximo existe,

$$\hat{\mu}_{\text{MV}} = \bar{\mathbf{X}}$$

e

$$\widehat{\Sigma}_{\text{MV}} = \frac{1}{n} \mathbf{T}.$$

A diferença entre os divisores n e $n - 1$ mostra que máxima verossimilhança e não viesamento correspondem a critérios distintos de estimação.

Para variáveis organizadas em dois blocos pareados,

$$\mathbf{S}_{XY} = \frac{1}{n - 1} \mathbf{T}_{XY}$$

estima a matriz de covariâncias cruzadas. Quando as variâncias amostrais são positivas,

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}$$

fornece a matriz de correlações amostral.

Os principais objetos do capítulo podem ser resumidos por:

Tabela 10.1: Relação entre parâmetros, estatísticas e demais objetos amostrais utilizados no capítulo.

Parâmetro ou objeto	Estatística/estimador	Valor observado
μ	$\bar{\mathbf{X}}$	$\bar{\mathbf{x}}$
Σ	$\mathbf{S}$	$\mathbf{S}$
SSCP amostral	$\mathbf{T}$	$\mathbf{T}$
Σ_{XY}	$\mathbf{S}_{XY}$	$\mathbf{S}_{XY}$
$\mathcal{R}$	$\mathbf{R}$	$\mathbf{R}$

A avaliação de um estimador depende do critério adotado. Viés e variabilidade descrevem seu comportamento para tamanho amostral fixo; erro quadrático médio incorpora uma função de perda; consistência descreve convergência; eficiência compara variabilidade ou risco; suficiência caracteriza a informação preservada; equivariância descreve o comportamento sob transformações; e robustez examina estabilidade diante das perturbações especificadas.

A estrutura de posto

$$\text{posto}(\mathbf{S}) \leq \min(p, n - 1)$$

mostra por que dimensão e tamanho amostral precisam ser considerados conjuntamente. Quando $p \geq n$, a covariância amostral é necessariamente singular. Mesmo quando existe uma inversa, seu uso pode ser instável quando alguns autovalores são pequenos.

Regularização e pseudoinversa tratam essa dificuldade de formas distintas. A pseudoinversa mantém a matriz estimada e generaliza a operação de inversão em seu espaço efetivo. A regularização modifica o estimador, introduzindo uma estrutura adicional que pode melhorar o condicionamento ou garantir definição positiva.

Ao término deste capítulo, deve-se ser capaz de:

- distinguir parâmetro, estatística, estimador e estimativa;
- avaliar propriedades básicas de estimadores multivariados;
- diferenciar método dos momentos e máxima verossimilhança;
- construir os estimadores do vetor de médias e da matriz de covariâncias;
- explicar a diferença entre os divisores n e $n - 1$;
- construir covariâncias cruzadas e correlações amostrais;
- analisar posto, singularidade e condicionamento de matrizes estimadas;
- distinguir pseudoinversa, regularização e robustez como respostas a problemas diferentes.

Os Capítulos 8 a 10 construíram a estrutura de covariâncias, o modelo probabilístico normal e os principais estimadores de localização e dispersão. O Capítulo 11 amplia essa estrutura para o **modelo linear multivariado**, no qual várias variáveis-resposta são relacionadas simultaneamente a uma matriz de delineamento. Nesse contexto, a estimação passa a envolver uma matriz de parâmetros, valores ajustados, resíduos e matrizes de SSCP associadas ao modelo.

11 Modelo Linear Multivariado e Hipóteses Lineares

O Capítulo 10 desenvolveu a estimação do vetor de médias e da matriz de covariâncias a partir de uma amostra aleatória multivariada. Nesse contexto, as unidades foram consideradas como provenientes de uma população com o mesmo vetor de médias.

O modelo linear multivariado amplia essa estrutura permitindo que o vetor de médias dependa de características conhecidas das unidades. Uma mesma formulação pode representar, por exemplo, uma regressão com várias respostas, efeitos associados a fatores ou covariáveis e diferentes estruturas de médias.

O modelo é escrito como

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E},$$

em que:

- $\mathbf{y} \in \mathbb{R}^{n \times p}$ é a matriz aleatória de respostas;
- $\mathbf{Z} \in \mathbb{R}^{n \times q}$ é a matriz de delineamento;
- $\mathbf{B} \in \mathbb{R}^{q \times p}$ é a matriz de parâmetros;
- $\mathcal{E} \in \mathbb{R}^{n \times p}$ é a matriz aleatória de erros.

O objetivo deste capítulo é formular esse modelo, estudar a estimação de $\mathbf{B}$, interpretar valores ajustados e resíduos por meio de projeções, construir a SSCP residual, estimar a matriz de covariâncias dos erros e representar hipóteses lineares sobre parâmetros e combinações das respostas (Rencher; Christensen, 2012).

As distribuições amostrais utilizadas para construir testes e regiões de confiança serão desenvolvidas no Capítulo 12. As técnicas multivariadas que utilizam o modelo linear, entre elas a MANOVA, serão formuladas posteriormente no Módulo 3.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{Y}_i \in \mathbb{R}^p$ representa o vetor aleatório de respostas da unidade i ;
- $\mathbf{y}_i \in \mathbb{R}^p$ representa uma realização desse vetor;
- $\mathbf{y} \in \mathbb{R}^{n \times p}$ representa a matriz aleatória de respostas;

- $\mathbf{Y} \in \mathbb{R}^{n \times p}$ representa a matriz observada de respostas;
- $\mathbf{Z} \in \mathbb{R}^{n \times q}$ representa a matriz de delineamento;
- $\mathbf{z}_i^\top$ representa a linha i de $\mathbf{Z}$;
- $\mathbf{B} \in \mathbb{R}^{q \times p}$ representa a matriz de parâmetros;
- $\varepsilon_i \in \mathbb{R}^p$ representa o vetor aleatório de erros da unidade i ;
- $\mathcal{E} \in \mathbb{R}^{n \times p}$ representa a matriz aleatória de erros;
- $\Sigma \in \mathbb{R}^{p \times p}$ representa a matriz de covariâncias entre as respostas de uma mesma unidade;
- $\widehat{\mathbf{B}}$ representa um estimador de $\mathbf{B}$;
- $\widehat{\mathbf{U}}$ representará a matriz aleatória de resíduos e $\widehat{\mathbf{U}}$ sua realização observada;
- $\mathbf{E}_{\text{res}}$ representará a SSCP residual como estatística aleatória e $\mathbf{E}$ sua realização observada;
- $\mathbf{T}$ continuará representando a SSCP total, em concordância com os Capítulos 8 e 10;
- $\mathbf{T}_{\text{mod}}$ representará a parcela da SSCP associada ao modelo além do intercepto;
- $\mathbf{H}$ ficará reservada à SSCP associada a uma hipótese linear.

A letra $\mathbf{Z}$ é utilizada para o delineamento para preservar $\mathbf{X}$ como símbolo da matriz de dados nos capítulos anteriores.

11.1 Formulação do modelo linear multivariado

11.1.1 Resposta vetorial e matriz de respostas

No modelo linear univariado, cada unidade fornece uma única resposta. No caso multivariado, a unidade i fornece simultaneamente

$$\mathbf{Y}_i = \begin{bmatrix} Y_{i1} \\ Y_{i2} \\ \vdots \\ Y_{ip} \end{bmatrix} \in \mathbb{R}^p. \quad (11.1)$$

As componentes podem apresentar dependência. O modelo deve, portanto, representar simultaneamente:

1. a estrutura das médias das p respostas;
2. a variabilidade de cada resposta;
3. as covariâncias entre respostas observadas na mesma unidade.

Considere

$$\mathbf{z}_i = \begin{bmatrix} z_{i1} \\ \vdots \\ z_{iq} \end{bmatrix} \in \mathbb{R}^q,$$

contendo os valores dos q termos do modelo para a unidade i .

A matriz de parâmetros é

$$\mathbf{B} = \begin{bmatrix} \beta_{11} & \beta_{12} & \cdots & \beta_{1p} \\ \beta_{21} & \beta_{22} & \cdots & \beta_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \beta_{q1} & \beta_{q2} & \cdots & \beta_{qp} \end{bmatrix} \in \mathbb{R}^{q \times p}. \quad (11.2)$$

A coluna j de $\mathbf{B}$ contém os coeficientes associados à resposta j . A linha h reúne os coeficientes do termo h para as p respostas.

A média condicional do vetor de respostas da unidade i é

$$E(\mathbf{Y}_i \mid \mathbf{Z}) = \mathbf{B}^\top \mathbf{z}_i. \quad (11.3)$$

Equivalentemente, em forma de vetor linha,

$$E(\mathbf{Y}_i^\top \mid \mathbf{Z}) = \mathbf{z}_i^\top \mathbf{B}.$$

Definição 11.1 (Modelo linear multivariado para uma unidade). O vetor de respostas da unidade i é representado por

$$\mathbf{Y}_i = \mathbf{B}^\top \mathbf{z}_i + \varepsilon_i, \quad (11.4)$$

em que

$$E(\varepsilon_i \mid \mathbf{Z}) = \mathbf{0}.$$

Componente a componente,

$$Y_{ij} = \mathbf{z}_i^\top \beta_j + \varepsilon_{ij}, \quad j = 1, \dots, p, \quad (11.5)$$

em que β_j é a coluna j de $\mathbf{B}$.

As equações das diferentes respostas compartilham a mesma matriz de delineamento. O caráter multivariado do modelo decorre da análise conjunta dessas respostas e da estrutura de covariâncias dos respectivos erros.

Para reunir as n unidades, defina a matriz aleatória

Definição 11.2 (Matriz aleatória de respostas).

$$\mathbf{y} = \begin{bmatrix} \mathbf{Y}_1^\top \\ \mathbf{Y}_2^\top \\ \vdots \\ \mathbf{Y}_n^\top \end{bmatrix} = \begin{bmatrix} Y_{11} & \cdots & Y_{1p} \\ Y_{21} & \cdots & Y_{2p} \\ \vdots & \ddots & \vdots \\ Y_{n1} & \cdots & Y_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (11.6)$$

Após a observação,

$$\mathbf{Y} = \begin{bmatrix} \mathbf{y}_1^\top \\ \vdots \\ \mathbf{y}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (11.7)$$

A matriz de delineamento é

$$\mathbf{Z} = \begin{bmatrix} \mathbf{z}_1^\top \\ \mathbf{z}_2^\top \\ \vdots \\ \mathbf{z}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times q}. \quad (11.8)$$

Neste capítulo, a inferência é formulada condicionalmente a $\mathbf{Z}$. Assim, a matriz de delineamento é tratada como conhecida. Essa convenção abrange tanto delineamentos fixados previamente quanto análises condicionais aos valores observados das variáveis explicativas.

11.1.2 Estrutura matricial do modelo

Organize os vetores de erros nas linhas de

$$\mathcal{E} = \begin{bmatrix} \varepsilon_1^\top \\ \vdots \\ \varepsilon_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (11.9)$$

Definição 11.3 (Modelo linear multivariado). O modelo linear multivariado é

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E}. \quad (11.10)$$

A matriz de médias condicionais é

$$E(y | \mathbf{Z}) = \mathbf{ZB}. \quad (11.11)$$

Portanto, a estrutura sistemática do modelo pertence ao espaço coluna de $\mathbf{Z}$. Cada coluna de

$$\mathbf{ZB}$$

é uma combinação linear das colunas do delineamento.

Se

$$r = \text{posto}(\mathbf{Z}), \quad (11.12)$$

então

$$r \leq \min(n, q).$$

Quando

$$r = q,$$

as colunas de $\mathbf{Z}$ são linearmente independentes e a parametrização usual de $\mathbf{B}$ é identificada. Quando

$$r < q,$$

a matriz de parâmetros não é única, embora determinadas funções de $\mathbf{B}$ e a própria matriz de médias $\mathbf{ZB}$ possam ser unicamente determinadas. Esse caso será desenvolvido na seção sobre estimabilidade.

11.1.3 Estrutura de médias e covariâncias residuais

A primeira condição do modelo é

Definição 11.4 (Média residual nula).

$$E(\varepsilon_i \mid \mathbf{Z}) = \mathbf{0}, \quad i = 1, \dots, n. \quad (11.13)$$

Consequentemente,

$$E(\mathbf{Y}_i \mid \mathbf{Z}) = \mathbf{B}^\top \mathbf{z}_i.$$

A segunda condição descreve a dependência entre as respostas de uma mesma unidade e entre unidades distintas.

Definição 11.5 (Estrutura de covariâncias dos erros). Assume-se

$$\text{Cov}(\varepsilon_i \mid \mathbf{Z}) = \Sigma, \quad i = 1, \dots, n, \quad (11.14)$$

e

$$\text{Cov}(\varepsilon_i, \varepsilon_\ell \mid \mathbf{Z}) = \mathbf{0}, \quad i \neq \ell. \quad (11.15)$$

A matriz

$$\Sigma = \begin{bmatrix} \sigma_{11} & \cdots & \sigma_{1p} \\ \vdots & \ddots & \vdots \\ \sigma_{p1} & \cdots & \sigma_{pp} \end{bmatrix}$$

é a matriz de covariâncias residuais entre as p respostas.

Assim,

$$\text{Var}(Y_{ij} \mid \mathbf{Z}) = \sigma_{jj},$$

e, para duas respostas da mesma unidade,

$$\text{Cov}(Y_{ij}, Y_{ik} \mid \mathbf{Z}) = \sigma_{jk}.$$

A expressão “covariância residual” indica a variabilidade que permanece após a estrutura de médias $\mathbf{ZB}$ ter sido especificada. Ela não deve ser confundida com a covariância marginal das respostas quando suas médias variam entre unidades.

As condições anteriores implicam que a dependência entre respostas é permitida **dentro de uma unidade**, enquanto erros de unidades distintas são não correlacionados. Sob normalidade conjunta, a covariância cruzada nula entre unidades implica independência, conforme desenvolvido no Capítulo 9.

11.1.4 Forma vetorizada

O operador vec , o produto de Kronecker e a identidade

$$\text{vec}(\mathbf{AXC}) = (\mathbf{C}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X})$$

foram definidos em Definição 7.9, Definição 7.10 e Proposição 7.15. Não é necessário reconstruir essas operações aqui.

Aplicando a identidade ao termo sistemático,

$$\text{vec}(\mathbf{ZB}) = (\mathbf{I}_p \otimes \mathbf{Z}) \text{vec}(\mathbf{B}). \quad (11.16)$$

Portanto,

$$\text{vec}(\mathbf{y}) = (\mathbf{I}_p \otimes \mathbf{Z}) \text{vec}(\mathbf{B}) + \text{vec}(\mathcal{E}). \quad (11.17)$$

Como a vetorização é feita por colunas, a estrutura de covariâncias dos erros é

Proposição 11.1 (Covariância do erro vetorizado). *Sob Definição 11.5,*

$$\text{Cov}[\text{vec}(\mathcal{E}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n. \quad (11.18)$$

A ordem dos fatores é importante. A vetorização por colunas agrupa primeiro as n observações da resposta 1, depois as n observações da resposta 2 e assim sucessivamente. Por isso, a matriz de covariâncias entre respostas ocupa o primeiro fator:

$$\Sigma \otimes \mathbf{I}_n.$$

Consequentemente,

$$\text{Cov}[\text{vec}(\mathcal{Y}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n. \quad (11.19)$$

Essa representação mostra que o modelo linear multivariado pode ser visto como um modelo linear para um vetor de dimensão np , com uma estrutura de covariâncias específica.

11.1.5 Distribuição normal matricial

A normalidade não é necessária para definir o modelo linear multivariado nem para obter diversas propriedades dos estimadores de mínimos quadrados. Ela fornece, entretanto, uma estrutura probabilística que permitirá obter resultados exatos no Capítulo 12.

A distribuição normal matricial será parametrizada pela média, por uma matriz de covariâncias entre linhas e por uma matriz de covariâncias entre colunas (Gupta; Nagar, 1999).

Definição 11.6 (Distribuição normal matricial). Se

$$\mathcal{A} \in \mathbb{R}^{n \times p},$$

diz-se que

$$\mathcal{A} \sim N_{n \times p}(\Xi, \mathbf{U}, \mathbf{V})$$

quando

$$\text{vec}(\mathcal{A}) \sim N_{np}[\text{vec}(\Xi), \mathbf{V} \otimes \mathbf{U}]. \quad (11.20)$$

Aqui,

$$\Xi \in \mathbb{R}^{n \times p}, \quad \mathbf{U} \in \mathbb{R}^{n \times n}, \quad \mathbf{V} \in \mathbb{R}^{p \times p}.$$

Nesta parametrização, $\mathbf{U}$ descreve a estrutura entre linhas e $\mathbf{V}$ a estrutura entre colunas. A representação não identifica separadamente uma escala global em $\mathbf{U}$ e $\mathbf{V}$, pois, para qualquer $c > 0$, a substituição

$$\mathbf{U}^* = c\mathbf{U}$$

e

$$\mathbf{V}^* = \frac{1}{c} \mathbf{V}$$

não altera a matriz de covariâncias vetorizada:

$$\mathbf{V}^* \otimes \mathbf{U}^* = \left(\frac{1}{c} \mathbf{V} \right) \otimes (c \mathbf{U}) = \mathbf{V} \otimes \mathbf{U}.$$

No modelo linear multivariado, a escolha

$$\mathbf{U} = \mathbf{I}_n$$

fixa essa escala e expressa a independência entre unidades.

Definição 11.7 (Modelo linear normal multivariado). O modelo linear normal multivariado é definido por

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E},$$

com

$$\mathcal{E} \mid \mathbf{Z} \sim N_{n \times p}(\mathbf{0}, \mathbf{I}_n, \Sigma). \quad (11.21)$$

Equivalentemente,

$$\mathbf{y} \mid \mathbf{Z} \sim N_{n \times p}(\mathbf{ZB}, \mathbf{I}_n, \Sigma). \quad (11.22)$$

Pela definição da normal matricial,

$$\text{vec}(\mathbf{y}) \mid \mathbf{Z} \sim N_{np}[(\mathbf{I}_p \otimes \mathbf{Z}) \text{vec}(\mathbf{B}), \Sigma \otimes \mathbf{I}_n]. \quad (11.23)$$

A mesma estrutura pode ser lida por unidade:

$$\mathbf{Y}_i \mid \mathbf{Z} \sim N_p(\mathbf{B}^\top \mathbf{z}_i, \Sigma), \quad i = 1, \dots, n, \quad (11.24)$$

com independência condicional entre as unidades.

A matriz Σ continua desempenhando o papel estabelecido nos Capítulos 8 e 9: suas diagonais são as variâncias residuais das respostas e seus elementos fora da diagonal descrevem a dependência linear residual entre elas.

Para uma resposta específica j , a coluna correspondente satisfaz

$$\mathbf{Y}_{\cdot j} \mid \mathbf{Z} \sim N_n \left(\mathbf{Z} \beta_j, \sigma_{jj} \mathbf{I}_n \right). \quad (11.25)$$

Para duas respostas j e k ,

$$\text{Cov} \left(\mathbf{Y}_{\cdot j}, \mathbf{Y}_{\cdot k} \mid \mathbf{Z} \right) = \sigma_{jk} \mathbf{I}_n. \quad (11.26)$$

Assim, ajustar separadamente as p equações produz os mesmos estimadores de mínimos quadrados para os coeficientes quando todas utilizam a mesma matriz $\mathbf{Z}$. A modelagem conjunta torna-se necessária para representar a covariância entre as respostas e para formular inferência sobre funções que envolvem simultaneamente diferentes colunas de $\mathbf{B}$.

Quando

$$\Sigma \succ \mathbf{0},$$

a log-verossimilhança, a menos de termos que não dependem dos parâmetros, pode ser escrita como

$$\begin{aligned} \ell(\mathbf{B}, \Sigma) = & -\frac{n}{2} \log \det(\Sigma) \\ & -\frac{1}{2} \text{tr} \left[\Sigma^{-1} (\mathbf{y} - \mathbf{ZB})^\top (\mathbf{y} - \mathbf{ZB}) \right]. \end{aligned} \quad (11.27)$$

A expressão combina duas estruturas já desenvolvidas: log-determinante e traço envolvendo uma matriz inversa. As regras de diferenciação correspondentes foram estabelecidas no Capítulo 7 e serão utilizadas somente quando necessárias na estimação.

11.1.6 Transformações da resposta

Uma transformação linear das respostas preserva a estrutura do modelo.

Considere

$$\mathbf{W}_i = \mathbf{A}^\top \mathbf{Y}_i,$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times s}.$$

Em forma matricial,

$$\mathcal{W} = \mathbf{y}\mathbf{A}.$$

Logo,

$$\mathcal{W} = \mathbf{Z}(\mathbf{B}\mathbf{A}) + \mathcal{E}\mathbf{A}. \quad (11.28)$$

A matriz de parâmetros transformada é

$$\mathbf{B}_W = \mathbf{B}\mathbf{A},$$

e a matriz de covariâncias residuais é

$$\Sigma_W = \mathbf{A}^\top \Sigma \mathbf{A},$$

em concordância com Proposição 8.6.

Sob normalidade,

$$\mathcal{W} \mid \mathbf{Z} \sim N_{n \times s}(\mathbf{Z}\mathbf{B}\mathbf{A}, \mathbf{I}_n, \mathbf{A}^\top \Sigma \mathbf{A}). \quad (11.29)$$

Essa propriedade será utilizada posteriormente para formular hipóteses sobre combinações lineares das respostas.

O modelo está agora especificado em termos de sua estrutura de médias e de covariâncias. A próxima etapa é estimar a matriz de parâmetros $\mathbf{B}$ a partir da matriz observada de respostas.

11.2 Estimação da matriz de parâmetros

A estimação de $\mathbf{B}$ consiste em determinar a estrutura de médias

$$\mathbf{Z}\mathbf{B}$$

que melhor aproxima a matriz observada de respostas $\mathbf{Y}$ segundo o critério adotado.

Como todas as respostas utilizam a mesma matriz de delineamento, a estimação pode ser realizada simultaneamente. Cada coluna de $\mathbf{B}$ corresponde aos coeficientes de uma resposta, mas a formulação matricial permite preservar a dependência entre as respostas e preparar a estimação conjunta de sua matriz de covariâncias residual (Rencher; Christensen, 2012).

11.2.1 Mínimos quadrados

Considere uma matriz candidata

$$\mathbf{G} \in \mathbb{R}^{q \times p}.$$

A matriz de resíduos correspondente é

$$\mathbf{Y} - \mathbf{ZG}.$$

Definição 11.8 (Critério de mínimos quadrados multivariado). O critério de mínimos quadrados é

$$Q(\mathbf{G}) = \|\mathbf{Y} - \mathbf{ZG}\|_F^2. \quad (11.30)$$

Equivalentemente,

$$Q(\mathbf{G}) = \text{tr} [(\mathbf{Y} - \mathbf{ZG})^\top (\mathbf{Y} - \mathbf{ZG})]. \quad (11.31)$$

A norma de Frobenius foi definida em Definição 6.7. Neste problema,

$$Q(\mathbf{G}) = \sum_{j=1}^p \|\mathbf{y}_{\cdot j} - \mathbf{Zg}_j\|^2, \quad (11.32)$$

em que $\mathbf{y}_{\cdot j}$ é a coluna j de $\mathbf{Y}$ e $\mathbf{g}_j$ é a coluna correspondente de $\mathbf{G}$.

Portanto, minimizar $Q(\mathbf{G})$ equivale a minimizar simultaneamente as somas de quadrados residuais das p respostas.

O critério não utiliza diretamente as covariâncias fora da diagonal de Σ . Essas covariâncias serão relevantes para:

- a covariância entre estimadores associados a respostas distintas;
- a estimação da matriz de covariâncias residual;
- hipóteses envolvendo simultaneamente diferentes respostas;
- os resultados inferenciais desenvolvidos no Capítulo 12.

As equações normais e sua derivação por cálculo matricial foram estabelecidas em Definição 3.21 e Proposição 7.6. Aplicadas ao modelo atual, elas assumem a forma

$$\mathbf{Z}^\top \mathbf{Z} \widehat{\mathbf{B}}_{\text{obs}} = \mathbf{Z}^\top \mathbf{Y}. \quad (11.33)$$

Equivalentemente,

$$\mathbf{Z}^\top (\mathbf{Y} - \mathbf{Z} \widehat{\mathbf{B}}_{\text{obs}}) = \mathbf{0}_{q \times p}. \quad (11.34)$$

Se

$$\widehat{\mathbf{U}} = \mathbf{Y} - \mathbf{Z} \widehat{\mathbf{B}}_{\text{obs}},$$

então

$$\mathbf{Z}^\top \widehat{\mathbf{U}} = \mathbf{0}. \quad (11.35)$$

Cada coluna da matriz de resíduos é, portanto, ortogonal ao espaço coluna de $\mathbf{Z}$. Essa é a aplicação, ao modelo multivariado, da geometria de mínimos quadrados desenvolvida no Módulo 1.

11.2.2 Estimador sob posto completo

Suponha

$$\text{posto}(\mathbf{Z}) = q. \quad (11.36)$$

Nesse caso,

$$q \leq n$$

e

$$\mathbf{Z}^\top \mathbf{Z} \succ \mathbf{0}.$$

Proposição 11.2 (Estimador de mínimos quadrados sob posto completo). *Se*

$$\text{posto}(\mathbf{Z}) = q,$$

o estimador de mínimos quadrados de $\mathbf{B}$ é

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}. \quad (11.37)$$

Após a observação das respostas,

$$\widehat{\mathbf{B}}_{\text{obs}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}. \quad (11.38)$$

A unicidade do minimizador decorre da definição positiva de

$$\mathbf{Z}^\top \mathbf{Z}.$$

A convexidade do critério e a caracterização do minimizador global por meio das equações normais foram desenvolvidas em Proposição 7.9 e não precisam ser novamente demonstradas aqui.

Para a resposta j , a coluna correspondente é

$$\widehat{\beta}_j = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}_{\cdot j}, \quad (11.39)$$

em que

$$\mathbf{Y}_{\cdot j} = \begin{bmatrix} Y_{1j} \\ \vdots \\ Y_{nj} \end{bmatrix}.$$

Assim, cada coluna de $\widehat{\mathbf{B}}$ coincide com o estimador de mínimos quadrados obtido para a resposta correspondente. A formulação matricial reúne esses estimadores em um único objeto.

11.2.3 Esperança e matriz de covariâncias

Substituindo

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E}$$

em Equação 11.37,

$$\begin{aligned}\widehat{\mathbf{B}} &= (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top (\mathbf{Z}\mathbf{B} + \mathcal{E}) \\ &= \mathbf{B} + (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathcal{E}.\end{aligned}\tag{11.40}$$

A segunda parcela representa o erro de estimação.

Proposição 11.3 (Esperança e covariância do estimador da matriz de parâmetros). *Considere*

$$E(\mathcal{E} \mid \mathbf{Z}) = \mathbf{0}$$

e

$$\text{Cov}[\text{vec}(\mathcal{E}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n.$$

Se

$$\text{posto}(\mathbf{Z}) = q,$$

então

$$E(\widehat{\mathbf{B}} \mid \mathbf{Z}) = \mathbf{B}\tag{11.41}$$

e

$$\text{Cov}[\text{vec}(\widehat{\mathbf{B}}) \mid \mathbf{Z}] = \Sigma \otimes (\mathbf{Z}^\top \mathbf{Z})^{-1}.\tag{11.42}$$

Comprovação. De Equação 11.40,

$$E\left(\widehat{\mathbf{B}} \mid \mathbf{Z}\right) = \mathbf{B} + (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top E(\mathcal{E} \mid \mathbf{Z}),$$

de modo que

$$E\left(\widehat{\mathbf{B}} \mid \mathbf{Z}\right) = \mathbf{B}.$$

Para a matriz de covariâncias, defina

$$\mathbf{A}_Z = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top.$$

Então,

$$\widehat{\mathbf{B}} - \mathbf{B} = \mathbf{A}_Z \mathcal{E}.$$

Utilizando Proposição 7.15,

$$\text{vec}\left(\widehat{\mathbf{B}} - \mathbf{B}\right) = (\mathbf{I}_p \otimes \mathbf{A}_Z) \text{vec}(\mathcal{E}).$$

Logo,

$$\begin{aligned} & \text{Cov}\left[\text{vec}\left(\widehat{\mathbf{B}}\right) \mid \mathbf{Z}\right] \\ &= (\mathbf{I}_p \otimes \mathbf{A}_Z) (\Sigma \otimes \mathbf{I}_n) (\mathbf{I}_p \otimes \mathbf{A}_Z^\top) \\ &= \Sigma \otimes (\mathbf{A}_Z \mathbf{A}_Z^\top). \end{aligned}$$

Como

$$\mathbf{A}_Z \mathbf{A}_Z^\top = (\mathbf{Z}^\top \mathbf{Z})^{-1},$$

obtém-se Equação 11.42. □

O resultado mostra duas fontes distintas de variabilidade:

$$\Sigma$$

descreve a variabilidade residual e a associação entre as respostas, enquanto

$$(\mathbf{Z}^\top \mathbf{Z})^{-1}$$

descreve a contribuição do delineamento para a precisão dos coeficientes.

Para duas respostas j e k ,

$$\text{Cov}(\hat{\beta}_j, \hat{\beta}_k \mid \mathbf{Z}) = \sigma_{jk} (\mathbf{Z}^\top \mathbf{Z})^{-1}. \quad (11.43)$$

Para $j = k$,

$$\text{Cov}(\hat{\beta}_j \mid \mathbf{Z}) = \sigma_{jj} (\mathbf{Z}^\top \mathbf{Z})^{-1}. \quad (11.44)$$

Assim, estimadores associados a respostas diferentes são correlacionados sempre que os erros dessas respostas apresentam covariância residual diferente de zero.

Mais geralmente, para

$$\mathbf{c} \in \mathbb{R}^q \quad \text{e} \quad \mathbf{m} \in \mathbb{R}^p,$$

a combinação escalar

$$\mathbf{c}^\top \mathbf{B} \mathbf{m}$$

é estimada por

$$\mathbf{c}^\top \widehat{\mathbf{B}} \mathbf{m}.$$

Sua variância condicional é

$$\text{Var}(\mathbf{c}^\top \widehat{\mathbf{B}} \mathbf{m} \mid \mathbf{Z}) = [\mathbf{c}^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{c}] (\mathbf{m}^\top \Sigma \mathbf{m}). \quad (11.45)$$

A expressão separa o papel do delineamento do papel da variabilidade da combinação de respostas. Essa estrutura será retomada na formulação das hipóteses lineares.

11.2.4 Relação com máxima verossimilhança

Sob o modelo linear normal multivariado, a log-verossimilhança foi escrita em Equação 11.27 como

$$\ell(\mathbf{B}, \Sigma) = -\frac{n}{2} \log \det(\Sigma) - \frac{1}{2} \text{tr} \left[\Sigma^{-1} (\mathbf{y} - \mathbf{ZB})^\top (\mathbf{y} - \mathbf{ZB}) \right],$$

a menos de termos constantes.

Para $\Sigma \succ \mathbf{0}$ fixa, maximizar essa expressão em relação a $\mathbf{B}$ produz as mesmas equações normais do critério de mínimos quadrados. As identidades de diferenciação matricial necessárias a essa conclusão foram desenvolvidas no Capítulo 7.

Proposição 11.4 (Mínimos quadrados e máxima verossimilhança). *Considere o modelo linear normal multivariado com*

$$\text{posto}(\mathbf{Z}) = q.$$

Para qualquer $\Sigma \succ \mathbf{0}$ fixada, o maximizador da verossimilhança em relação a $\mathbf{B}$ é

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}.$$

Consequentemente, sempre que o estimador de máxima verossimilhança conjunto de

$$(\mathbf{B}, \Sigma)$$

existir no espaço paramétrico considerado,

$$\widehat{\mathbf{B}}_{\text{MV}} = \widehat{\mathbf{B}}. \tag{11.46}$$

A coincidência ocorre porque todas as respostas utilizam o mesmo delineamento e a estrutura de covariâncias é

$$\Sigma \otimes \mathbf{I}_n.$$

A matriz Σ afeta a covariância conjunta dos estimadores, mas não modifica a expressão de $\widehat{\mathbf{B}}$.

O resultado depende da estrutura do modelo. Ele não se transfere automaticamente para situações em que, por exemplo, as respostas possuem delineamentos diferentes ou há dependência residual entre unidades.

A existência do estimador conjunto de máxima verossimilhança da matriz de covariâncias será examinada na seção dedicada à SSCP residual.

11.2.5 Modelo contendo somente intercepto

O modelo mais simples ocorre quando todas as unidades possuem o mesmo vetor de médias:

$$\mathbf{Y}_i = \mu + \varepsilon_i, \quad i = 1, \dots, n. \quad (11.47)$$

Nesse caso,

$$\mathbf{Z} = \mathbf{1}_n$$

e

$$\mathbf{B} = \mu^\top.$$

Como

$$\mathbf{Z}^\top \mathbf{Z} = n,$$

tem-se

$$\widehat{\mathbf{B}} = \frac{1}{n} \mathbf{1}_n^\top \mathbf{y} = \bar{\mathbf{Y}}^\top. \quad (11.48)$$

Após a observação,

$$\widehat{\mathbf{B}}_{\text{obs}} = \bar{\mathbf{y}}^\top.$$

Portanto, a média amostral estudada no Capítulo 10 aparece como o estimador de mínimos quadrados da matriz de parâmetros no modelo contendo somente intercepto.

Além disso,

$$\text{Cov}(\bar{\mathbf{Y}}) = \frac{\Sigma}{n},$$

recuperando diretamente Equação 10.55.

O modelo linear multivariado pode, assim, ser interpretado como uma generalização do problema de estimação do vetor de médias: em vez de uma única média comum a todas as unidades, a estrutura de médias passa a variar dentro do espaço gerado pelas colunas de $\mathbf{Z}$.

11.3 Valores ajustados, resíduos e projeções

A estimação de $\mathbf{B}$ determina uma matriz de médias ajustadas pertencente ao espaço coluna da matriz de delineamento. A geometria dessa operação é a mesma dos problemas de projeção e mínimos quadrados estudados no Módulo 1.

Seja

$$r = \text{posto}(\mathbf{Z}).$$

O projetor ortogonal sobre

$$\mathcal{C}(\mathbf{Z})$$

pode ser escrito como

$$\mathbf{P}_Z = \mathbf{Z}\mathbf{Z}^+, \quad (11.49)$$

em que $\mathbf{Z}^+$ é a pseudoinversa de Moore–Penrose definida no Módulo 1.

Quando

$$\text{posto}(\mathbf{Z}) = q,$$

essa expressão reduz-se a

$$\mathbf{P}_Z = \mathbf{Z}(\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top. \quad (11.50)$$

O projetor sobre o complemento ortogonal é

$$\mathbf{M}_Z = \mathbf{I}_n - \mathbf{P}_Z. \quad (11.51)$$

As propriedades gerais dos projetores ortogonais foram desenvolvidas em Proposição 3.15 e Definição 3.20. Em particular,

$$\mathbf{P}_Z^\top = \mathbf{P}_Z, \quad \mathbf{P}_Z^2 = \mathbf{P}_Z,$$

$$\mathbf{M}_Z^\top = \mathbf{M}_Z, \quad \mathbf{M}_Z^2 = \mathbf{M}_Z,$$

e

$$\mathbf{P}_Z \mathbf{M}_Z = \mathbf{M}_Z \mathbf{P}_Z = \mathbf{0}. \quad (11.52)$$

Além disso,

$$\text{posto}(\mathbf{P}_Z) = r$$

e

$$\text{posto}(\mathbf{M}_Z) = n - r. \quad (11.53)$$

Essas dimensões terão interpretação direta nos graus de liberdade associados ao ajuste e ao resíduo.

11.3.1 Valores ajustados e resíduos

Definição 11.9 (Valores ajustados). A matriz aleatória de valores ajustados é

$$\hat{\mathbf{y}} = \mathbf{P}_Z \mathbf{y}. \quad (11.54)$$

Após a observação,

$$\hat{\mathbf{Y}} = \mathbf{P}_Z \mathbf{Y}. \quad (11.55)$$

Como

$$\mathbf{P}_Z \mathbf{Z} = \mathbf{Z},$$

tem-se

$$\begin{aligned} \hat{\mathbf{y}} &= \mathbf{P}_Z (\mathbf{Z}\mathbf{B} + \mathcal{E}) \\ &= \mathbf{Z}\mathbf{B} + \mathbf{P}_Z \mathcal{E}. \end{aligned} \quad (11.56)$$

Portanto, os valores ajustados preservam a estrutura sistemática do modelo e incorporam a projeção dos erros sobre o espaço do delineamento.

Definição 11.10 (Resíduos). A matriz aleatória de resíduos é

$$\widehat{\mathcal{U}} = \mathcal{Y} - \widehat{\mathcal{Y}} = \mathbf{M}_Z \mathcal{Y}. \quad (11.57)$$

Após a observação,

$$\widehat{\mathbf{U}} = \mathbf{Y} - \widehat{\mathbf{Y}} = \mathbf{M}_Z \mathbf{Y}. \quad (11.58)$$

Como

$$\mathbf{M}_Z \mathbf{Z} = \mathbf{0},$$

segue que

$$\widehat{\mathcal{U}} = \mathbf{M}_Z \mathcal{E}. \quad (11.59)$$

Os resíduos são, portanto, a parcela dos erros pertencente ao complemento ortogonal de

$$\mathcal{C}(\mathbf{Z}).$$

Para cada realização,

$$\mathbf{Y} = \widehat{\mathbf{Y}} + \widehat{\mathbf{U}}. \quad (11.60)$$

A decomposição ocorre coluna a coluna: cada vetor de respostas observadas é separado em sua projeção sobre o espaço do modelo e em um resíduo ortogonal a esse espaço.

11.3.2 Ortogonalidade

As equações normais já forneceram

$$\mathbf{Z}^\top \widehat{\mathbf{U}} = \mathbf{0}.$$

Além disso,

$$\begin{aligned} \widehat{\mathbf{Y}}^\top \widehat{\mathbf{U}} &= \mathbf{Y}^\top \mathbf{P}_Z \mathbf{M}_Z \mathbf{Y} \\ &= \mathbf{0}. \end{aligned} \tag{11.61}$$

Assim, para quaisquer respostas j e k ,

$$\widehat{\mathbf{y}}_{\cdot j}^\top \widehat{\mathbf{u}}_{\cdot k} = 0.$$

A ortogonalidade não ocorre somente entre o ajuste e o resíduo da mesma resposta. Como o mesmo par de projetores atua sobre todas as colunas de $\mathbf{Y}$, qualquer coluna ajustada é ortogonal a qualquer coluna residual.

Consequentemente,

$$\|\mathbf{Y}\|_F^2 = \|\widehat{\mathbf{Y}}\|_F^2 + \|\widehat{\mathbf{U}}\|_F^2. \tag{11.62}$$

Essa identidade refere-se aos produtos internos em relação à origem. Quando o modelo contém intercepto, a decomposição da dispersão em torno do vetor de médias amostrais será expressa posteriormente por SSCPs.

11.3.3 Esperança dos valores ajustados e dos resíduos

Proposição 11.5 (Esperança dos valores ajustados e dos resíduos). *Sob*

$$E(\mathcal{E} \mid \mathbf{Z}) = \mathbf{0},$$

tem-se

$$E(\widehat{\mathbf{y}} \mid \mathbf{Z}) = \mathbf{Z}\mathbf{B} \tag{11.63}$$

e

$$E(\widehat{\mathbf{u}} \mid \mathbf{Z}) = \mathbf{0}. \tag{11.64}$$

De fato,

$$\begin{aligned} E(\hat{\mathcal{Y}} | \mathbf{Z}) &= \mathbf{P}_Z E(\mathcal{Y} | \mathbf{Z}) \\ &= \mathbf{P}_Z \mathbf{ZB} \\ &= \mathbf{ZB}, \end{aligned}$$

enquanto

$$\begin{aligned} E(\hat{\mathcal{U}} | \mathbf{Z}) &= \mathbf{M}_Z \mathbf{ZB} \\ &= \mathbf{0}. \end{aligned}$$

Os valores ajustados são, portanto, não viesados para a matriz de médias representável pelo modelo, enquanto os resíduos possuem média condicional nula.

11.3.4 Covariâncias dos valores ajustados e dos resíduos

A forma vetorizada permite obter diretamente suas matrizes de covariâncias.

Como

$$\text{vec}(\mathbf{P}_Z \mathcal{E}) = (\mathbf{I}_p \otimes \mathbf{P}_Z) \text{vec}(\mathcal{E}),$$

tem-se

Proposição 11.6 (Covariâncias dos valores ajustados e dos resíduos). *Sob*

$$\text{Cov}[\text{vec}(\mathcal{E}) | \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n,$$

vale

$$\text{Cov}[\text{vec}(\hat{\mathcal{Y}}) | \mathbf{Z}] = \Sigma \otimes \mathbf{P}_Z \tag{11.65}$$

e

$$\text{Cov}[\text{vec}(\hat{\mathcal{U}}) | \mathbf{Z}] = \Sigma \otimes \mathbf{M}_Z. \tag{11.66}$$

Além disso,

$$\text{Cov}[\text{vec}(\hat{\mathcal{Y}}), \text{vec}(\hat{\mathcal{U}}) | \mathbf{Z}] = \mathbf{0}. \tag{11.67}$$

A última igualdade decorre de

$$\mathbf{P}_Z \mathbf{M}_Z = \mathbf{0}.$$

Os valores ajustados e os resíduos são, portanto, não correlacionados. Sob o modelo normal matricial, eles são conjuntamente normais e, conseqüentemente, independentes. A utilização dessa independência na construção das distribuições amostrais será retomada no Capítulo 12.

Se

$$\mathbf{P}_Z = (h_{ik})$$

e

$$\mathbf{M}_Z = (m_{ik}),$$

então, para as unidades i e k ,

$$\text{Cov}(\hat{\mathbf{Y}}_i, \hat{\mathbf{Y}}_k | \mathbf{Z}) = h_{ik} \Sigma, \quad (11.68)$$

e

$$\text{Cov}(\hat{\mathbf{U}}_i, \hat{\mathbf{U}}_k | \mathbf{Z}) = m_{ik} \Sigma. \quad (11.69)$$

Em particular,

$$\text{Cov}(\hat{\mathbf{U}}_i | \mathbf{Z}) = (1 - h_{ii}) \Sigma. \quad (11.70)$$

Embora os erros de unidades distintas sejam não correlacionados, os resíduos podem apresentar covariância entre unidades porque todos dependem do mesmo ajuste.

Alavancagem

O elemento diagonal

$$h_{ii} = [\mathbf{P}_Z]_{ii} \quad (11.71)$$

é denominado **alavancagem** da unidade i .

Como $\mathbf{P}_Z$ é um projetor ortogonal,

$$0 \leq h_{ii} \leq 1$$

e

$$\sum_{i=1}^n h_{ii} = \text{tr}(\mathbf{P}_Z) = r. \quad (11.72)$$

Assim, a alavancagem média é

$$\frac{r}{n}.$$

O mesmo valor h_{ii} aplica-se às p respostas porque todas utilizam a mesma matriz de delineamento. O uso da alavancagem em diagnóstico de observações pertence ao estudo posterior de diagnóstico de modelos.

11.3.5 Representação dos ajustes e resíduos

A Figura 11.1 apresenta um modelo com uma variável explicativa e duas respostas. As duas colunas da matriz de respostas utilizam o mesmo espaço de ajuste, mas possuem coeficientes e resíduos próprios.




Figura 11.1: Valores observados, retas ajustadas e resíduos para duas respostas modeladas pela mesma variável explicativa.

Os segmentos verticais representam os resíduos de cada resposta. O mesmo projetor $\mathbf{P}_Z$ determina as posições ajustadas nas duas colunas, enquanto a associação residual entre as respostas não é representada diretamente nos painéis.

Essa associação será resumida pela SSCP residual.

11.3.6 Conexão com o modelo contendo somente intercepto

Quando

$$\mathbf{Z} = \mathbf{1}_n,$$

tem-se

$$\mathbf{P}_Z = \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top$$

e

$$\mathbf{M}_Z = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top = \mathbf{H}_n. \quad (11.73)$$

Assim,

$$\widehat{\mathbf{Y}} = \mathbf{1}_n \bar{\mathbf{y}}^\top,$$

enquanto

$$\widehat{\mathbf{U}} = \mathbf{H}_n \mathbf{Y}.$$

A matriz residual coincide, nesse caso, com a matriz de respostas centralizada. Portanto, a centralização utilizada nos Capítulos 8 e 10 aparece como um caso particular da projeção residual no modelo linear multivariado.

A próxima seção utilizará

$$\widehat{\mathbf{U}}$$

para construir a SSCP residual, determinar seus graus de liberdade e estimar a matriz de covariâncias Σ .

11.4 SSCP residual e estimação da covariância

A matriz de resíduos

$$\widehat{\mathbf{u}} = \mathbf{M}_Z \mathbf{y}$$

contém a parcela das respostas que permanece após a projeção sobre o espaço do modelo. Seus produtos cruzados fornecem a informação necessária para estimar a matriz de covariâncias residuais

$$\Sigma.$$

No modelo contendo somente intercepto, essa construção coincide com a SSCP amostral dos Capítulos 8 e 10. No modelo linear geral, o mesmo princípio é aplicado depois da remoção de um espaço de médias de dimensão

$$r = \text{posto}(\mathbf{Z}).$$

11.4.1 Construção da SSCP residual

Definição 11.11 (SSCP residual). A SSCP residual aleatória é

$$\mathbf{E}_{\text{res}} = \widehat{\mathbf{u}}^\top \widehat{\mathbf{u}}. \quad (11.74)$$

Como

$$\widehat{\mathbf{u}} = \mathbf{M}_Z \mathbf{y},$$

e $\mathbf{M}_Z$ é simétrica e idempotente,

$$\mathbf{E}_{\text{res}} = \mathbf{y}^\top \mathbf{M}_Z \mathbf{y}. \quad (11.75)$$

Após a observação,

$$\mathbf{E} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}} = \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y}. \quad (11.76)$$

O elemento (j, k) de $\mathbf{E}$ é

$$e_{jk} = \sum_{i=1}^n \hat{u}_{ij} \hat{u}_{ik}. \quad (11.77)$$

Na diagonal,

$$e_{jj} = \sum_{i=1}^n \hat{u}_{ij}^2$$

é a soma de quadrados residual da resposta j . Fora da diagonal,

$$e_{jk} = \sum_{i=1}^n \hat{u}_{ij} \hat{u}_{ik}$$

é o produto cruzado residual entre as respostas j e k .

Como

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E}$$

e

$$\mathbf{M}_Z \mathbf{Z} = \mathbf{0},$$

tem-se

$$\hat{\mathcal{U}} = \mathbf{M}_Z \mathcal{E}, \quad (11.78)$$

e, consequentemente,

$$\mathbf{E}_{\text{res}} = \mathcal{E}^\top \mathbf{M}_Z \mathcal{E}. \quad (11.79)$$

A SSCP residual depende do espaço de médias removido pelo ajuste por meio de $\mathbf{M}_Z$, mas não depende do valor específico de $\mathbf{B}$.

Como toda matriz de Gram, $\mathbf{E}$ é simétrica e positiva semidefinida. Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

$$\begin{aligned}\mathbf{a}^\top \mathbf{E} \mathbf{a} &= \|\widehat{\mathbf{U}} \mathbf{a}\|^2 \\ &\geq 0.\end{aligned}\tag{11.80}$$

A forma quadrática corresponde à soma de quadrados residual da combinação linear das respostas

$$\mathbf{Y} \mathbf{a}.$$

De fato,

$$\hat{\mathbf{u}}_{\mathbf{a}} = \mathbf{M}_Z \mathbf{Y} \mathbf{a} = \widehat{\mathbf{U}} \mathbf{a},$$

e

$$\hat{\mathbf{u}}_{\mathbf{a}}^\top \hat{\mathbf{u}}_{\mathbf{a}} = \mathbf{a}^\top \mathbf{E} \mathbf{a}.\tag{11.81}$$

Se as respostas forem transformadas por

$$\mathbf{Y}^* = \mathbf{Y} \mathbf{A}, \quad \mathbf{A} \in \mathbb{R}^{p \times s},$$

então

$$\widehat{\mathbf{U}}^* = \widehat{\mathbf{U}} \mathbf{A}$$

e

$$\mathbf{E}^* = \mathbf{A}^\top \mathbf{E} \mathbf{A}.\tag{11.82}$$

Essa transformação é coerente com a regra populacional

$$\Sigma^* = \mathbf{A}^\top \Sigma \mathbf{A}$$

e será utilizada posteriormente em hipóteses sobre combinações das respostas.

11.4.2 Esperança e graus de liberdade

A dimensão do espaço residual é determinada pelo posto da matriz de delineamento.

Como

$$\mathbf{M}_Z = \mathbf{I}_n - \mathbf{P}_Z,$$

tem-se

$$\text{posto}(\mathbf{M}_Z) = \text{tr}(\mathbf{M}_Z) = n - r.$$

Definição 11.12 (Graus de liberdade residuais). Se

$$r = \text{posto}(\mathbf{Z}),$$

os graus de liberdade residuais são

$$\nu_E = n - r. \quad (11.83)$$

Quando $\mathbf{Z}$ possui posto coluna completo,

$$r = q,$$

e, portanto,

$$\nu_E = n - q.$$

A expressão em função de r , e não simplesmente do número de colunas de $\mathbf{Z}$, continua válida quando a parametrização contém colunas redundantes.

Proposição 11.7 (Esperança da SSCP residual). *Sob a estrutura do modelo linear multivariado,*

$$E(\mathcal{E} \mid \mathbf{Z}) = \mathbf{0},$$

$$\text{Cov}(\varepsilon_i \mid \mathbf{Z}) = \Sigma,$$

e

$$\text{Cov}(\varepsilon_i, \varepsilon_\ell \mid \mathbf{Z}) = \mathbf{0}, \quad i \neq \ell,$$

tem-se

$$E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) = (n - r)\Sigma. \quad (11.84)$$

Comprovação. Pela Equação 11.79,

$$\mathbf{E}_{\text{res}} = \mathcal{E}^\top \mathbf{M}_Z \mathcal{E}.$$

Considere o elemento (j, k) :

$$[\mathbf{E}_{\text{res}}]_{jk} = \varepsilon_{\cdot j}^\top \mathbf{M}_Z \varepsilon_{\cdot k}.$$

Escrevendo

$$\mathbf{M}_Z = (m_{i\ell}),$$

obtém-se

$$[\mathbf{E}_{\text{res}}]_{jk} = \sum_{i=1}^n \sum_{\ell=1}^n m_{i\ell} \varepsilon_{ij} \varepsilon_{\ell k}.$$

Para $i \neq \ell$,

$$E(\varepsilon_{ij} \varepsilon_{\ell k} \mid \mathbf{Z}) = 0,$$

enquanto, para $i = \ell$,

$$E(\varepsilon_{ij} \varepsilon_{ik} \mid \mathbf{Z}) = \sigma_{jk}.$$

Logo,

$$\begin{aligned} E\left([\mathbf{E}_{\text{res}}]_{jk} \mid \mathbf{Z}\right) &= \sum_{i=1}^n m_{ii} \sigma_{jk} \\ &= \text{tr}(\mathbf{M}_Z) \sigma_{jk} \\ &= (n - r) \sigma_{jk}. \end{aligned}$$

Como a igualdade vale para todos os elementos,

$$E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) = (n - r)\Sigma.$$

□

A expressão generaliza diretamente o resultado do Capítulo 10,

$$E(\mathbf{T}) = (n - 1)\Sigma.$$

No modelo contendo somente intercepto,

$$r = 1,$$

de modo que

$$n - r = n - 1.$$

No modelo linear geral, cada direção independente utilizada para representar a estrutura de médias reduz em uma unidade a dimensão do espaço residual.

11.4.3 Estimador não viesado da covariância residual

Definição 11.13 (Estimador não viesado da matriz de covariâncias residual). Se

$$n - r > 0,$$

define-se

$$\widehat{\Sigma} = \frac{\mathbf{E}_{\text{res}}}{n - r}. \quad (11.85)$$

Após a observação,

$$\widehat{\Sigma}_{\text{obs}} = \frac{\mathbf{E}}{n - r}. \quad (11.86)$$

Pela Proposição 11.7,

$$E(\widehat{\Sigma} \mid \mathbf{Z}) = \Sigma. \quad (11.87)$$

Componente a componente,

$$\hat{\sigma}_{jk,\text{obs}} = \frac{e_{jk}}{n-r}. \quad (11.88)$$

Assim,

$$\hat{\sigma}_{jj,\text{obs}} = \frac{1}{n-r} \sum_{i=1}^n \hat{u}_{ij}^2$$

estima a variância residual da resposta j , enquanto, para $j \neq k$,

$$\hat{\sigma}_{jk,\text{obs}} = \frac{1}{n-r} \sum_{i=1}^n \hat{u}_{ij} \hat{u}_{ik}$$

estima a covariância residual entre as respostas j e k .

A matriz de correlações residuais pode ser obtida pela mesma padronização utilizada nos Capítulos 8 e 10, desde que as variâncias residuais estimadas sejam positivas. Não é necessário introduzir uma nova construção: aplica-se

$$\mathbf{D}^{-1/2} \widehat{\Sigma}_{\text{obs}} \mathbf{D}^{-1/2}$$

com a matriz diagonal correspondente às variâncias residuais estimadas.

Covariância total e covariância residual

A matriz de covariâncias calculada diretamente das respostas descreve a variabilidade conjunta observada antes do ajuste.

A matriz

$$\widehat{\Sigma}_{\text{obs}}$$

descreve a variabilidade que permanece depois de removida a estrutura de médias pertencente a

$$\mathcal{C}(\mathbf{Z}).$$

Por isso, em geral, as duas matrizes não coincidem.

11.4.4 Estimador de máxima verossimilhança

Sob o modelo normal matricial, a log-verossimilhança foi apresentada em Equação 11.27. Depois da maximização em relação à estrutura de médias, a parte que depende de Σ é, a menos de constantes,

$$\ell_c(\Sigma) = -\frac{n}{2} \log \det(\Sigma) - \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{E}). \quad (11.89)$$

Quando

$$\mathbf{E} \succ \mathbf{0},$$

o máximo no espaço

$$\Sigma \succ \mathbf{0}$$

é alcançado em

$$\widehat{\Sigma}_{\text{MV,obs}} = \frac{\mathbf{E}}{n}. \quad (11.90)$$

Antes da realização da amostra, defina a estatística

$$\widetilde{\Sigma}_n = \frac{\mathbf{E}_{\text{res}}}{n}. \quad (11.91)$$

Pela Equação 11.84,

$$E(\widetilde{\Sigma}_n \mid \mathbf{Z}) = \frac{n-r}{n} \Sigma. \quad (11.92)$$

Logo,

$$\text{Bias}(\widetilde{\Sigma}_n \mid \mathbf{Z}) = -\frac{r}{n} \Sigma. \quad (11.93)$$

Além disso,

$$\widetilde{\Sigma}_n = \frac{n-r}{n} \widehat{\Sigma}. \quad (11.94)$$

Portanto:

- o divisor $n - r$ produz o estimador não viesado;
- o divisor n produz uma estatística viesada em amostras finitas;
- sob o modelo normal matricial e quando o máximo existe, a estatística com divisor n coincide com o estimador de máxima verossimilhança.

Essa relação generaliza diretamente a diferença entre os divisores $n-1$ e n discutida no Capítulo 10.

Existência do estimador de máxima verossimilhança

A expressão

$$\frac{\mathbf{E}}{n}$$

é a estimativa de máxima verossimilhança de Σ no modelo normal não singular somente quando

$$\mathbf{E} \succ \mathbf{0}.$$

Se $\mathbf{E}$ é singular, a verossimilhança não possui máximo no interior do espaço

$$\Sigma \succ \mathbf{0}.$$

A matriz $\mathbf{E}/n$ continua sendo calculável, mas perde essa interpretação de máxima verossimilhança no modelo positivo definido.

11.4.5 Posto e singularidade

A SSCP residual possui a forma de Gram

$$\mathbf{E} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}}.$$

Portanto,

$$\text{posto}(\mathbf{E}) = \text{posto}(\widehat{\mathbf{U}}).$$

Como

$$\widehat{\mathbf{U}} = \mathbf{M}_Z \mathbf{Y}$$

e

$$\text{posto}(\mathbf{M}_Z) = n - r,$$

obtém-se:

Proposição 11.8 (Posto da SSCP residual). *A SSCP residual satisfaz*

$$\text{posto}(\mathbf{E}) \leq \min(p, n - r). \quad (11.95)$$

Consequentemente, se

$$p > n - r,$$

então $\mathbf{E}$ é necessariamente singular.

Uma condição necessária para

$$\mathbf{E} \succ \mathbf{0}$$

é

$$n - r \geq p. \quad (11.96)$$

Para uma amostra arbitrária, essa desigualdade não é suficiente: também é necessário

$$\text{posto}(\widehat{\mathbf{U}}) = p.$$

Sob o modelo normal matricial com

$$\Sigma \succ \mathbf{0},$$

tem-se, com probabilidade 1,

$$\text{posto}(\mathbf{E}) = \min(p, n - r). \quad (11.97)$$

Assim, sob normalidade não singular,

$$\mathbf{E} \succ \mathbf{0}$$

com probabilidade 1 quando

$$n - r \geq p.$$

O limite de posto é a extensão, para o modelo linear, da relação

$$\text{posto}(\mathbf{S}) \leq \min(p, n - 1)$$

obtida no Capítulo 10.

Questões de mau condicionamento, pseudoinversa e regularização continuam válidas para matrizes residuais, mas não serão novamente desenvolvidas aqui. Os princípios correspondentes foram tratados no aprofundamento sobre estimação de matrizes de covariâncias do Capítulo 10.

11.4.6 Modelo contendo somente intercepto

Considere

$$\mathbf{Z} = \mathbf{1}_n.$$

Nesse caso,

$$r = 1,$$

$$\mathbf{P}_Z = \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top$$

e

$$\mathbf{M}_Z = \mathbf{H}_n.$$

Logo,

$$\widehat{\mathbf{U}} = \mathbf{H}_n \mathbf{Y},$$

e a SSCP residual observada é

$$\begin{aligned}\mathbf{E} &= \mathbf{Y}^\top \mathbf{H}_n \mathbf{Y} \\ &= \sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}}) (\mathbf{y}_i - \bar{\mathbf{y}})^\top.\end{aligned}\tag{11.98}$$

Essa matriz é exatamente a SSCP total observada

$\mathbf{T}$

definida no Capítulo 8 e utilizada como estatística aleatória no Capítulo 10.

Como

$$n - r = n - 1,$$

obtém-se

$$\widehat{\Sigma}_{\text{obs}} = \frac{\mathbf{E}}{n - 1} = \mathbf{S}.\tag{11.99}$$

Sob normalidade e quando a SSCP possui posto completo,

$$\widehat{\Sigma}_{\text{MV,obs}} = \frac{\mathbf{E}}{n}.$$

Portanto, o modelo contendo somente intercepto recupera simultaneamente:

- $\bar{\mathbf{y}}$ como estimativa do vetor de médias;
- $\mathbf{H}_n \mathbf{Y}$ como matriz centralizada;
- $\mathbf{T}$ como SSCP;
- $\mathbf{S} = \mathbf{T}/(n - 1)$ como estimativa não viesada da matriz de covariâncias;
- $\mathbf{T}/n$ como estimativa de máxima verossimilhança sob o modelo normal e as condições de existência do máximo.

O modelo linear multivariado generaliza esses resultados substituindo uma única média por uma estrutura de médias pertencente a

$\mathcal{C}(\mathbf{Z})$.

A próxima seção separa a SSCP total em uma parcela associada ao modelo e uma parcela residual.

11.5 Decomposição da variação multivariada

Quando o modelo contém intercepto, a variabilidade das respostas em torno do vetor de médias amostrais pode ser separada em duas parcelas:

1. a parcela associada ao espaço do modelo além da média geral;
2. a parcela residual, ortogonal ao espaço do modelo.

Essa decomposição generaliza a separação entre variação total, ajustada e residual do modelo linear univariado. No caso multivariado, cada parcela é representada por uma matriz de somas de quadrados e produtos cruzados.

11.5.1 SSCP total

A SSCP total observada já foi definida no Capítulo 8 em Definição 8.10. Aplicada à matriz de respostas,

$$\mathbf{T} = \mathbf{Y}^\top \mathbf{H}_n \mathbf{Y}, \quad (11.100)$$

em que

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

Equivalentemente,

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}}) (\mathbf{y}_i - \bar{\mathbf{y}})^\top, \quad (11.101)$$

com

$$\bar{\mathbf{y}} = \frac{1}{n} \mathbf{Y}^\top \mathbf{1}_n.$$

A matriz $\mathbf{T}$ descreve a dispersão conjunta das respostas antes da remoção da estrutura explicada pelo delineamento.

Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

a forma quadrática

$$\mathbf{a}^\top \mathbf{T} \mathbf{a}$$

é a soma de quadrados total da resposta transformada

$$\mathbf{Y} \mathbf{a}. \quad (11.102)$$

11.5.2 SSCP associada ao modelo

Suponha que o modelo contenha intercepto, isto é,

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}). \quad (11.103)$$

Defina o projetor sobre o espaço das constantes por

$$\mathbf{P}_1 = \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top. \quad (11.104)$$

Como

$$\mathcal{C}(\mathbf{1}_n) \subseteq \mathcal{C}(\mathbf{Z}),$$

tem-se

$$\mathbf{P}_Z \mathbf{P}_1 = \mathbf{P}_1 \mathbf{P}_Z = \mathbf{P}_1. \quad (11.105)$$

Consequentemente,

$$\mathbf{P}_Z - \mathbf{P}_1$$

é o projetor ortogonal sobre a parcela do espaço do modelo que permanece após a retirada da direção constante.

Seu posto é

$$\text{posto}(\mathbf{P}_Z - \mathbf{P}_1) = r - 1, \quad (11.106)$$

em que

$$r = \text{posto}(\mathbf{Z}).$$

Definição 11.14 (SSCP associada ao modelo além do intercepto). Quando

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}),$$

define-se

$$\mathbf{T}_{\text{mod}} = \mathbf{Y}^\top (\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y}. \quad (11.107)$$

A matriz

$$\mathbf{T}_{\text{mod}}$$

mede a parcela da dispersão em torno da média geral associada aos termos do modelo além do intercepto.

Se

$$\widehat{\mathbf{Y}} = \mathbf{P}_Z \mathbf{Y},$$

então os valores ajustados centralizados são

$$\widehat{\mathbf{Y}}_c = \widehat{\mathbf{Y}} - \mathbf{1}_n \bar{\mathbf{y}}^\top = (\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y}.$$

Logo,

$$\mathbf{T}_{\text{mod}} = \widehat{\mathbf{Y}}_c^\top \widehat{\mathbf{Y}}_c. \quad (11.108)$$

Para qualquer combinação linear das respostas,

$$\mathbf{a}^\top \mathbf{T}_{\text{mod}} \mathbf{a} = \|(\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y} \mathbf{a}\|^2. \quad (11.109)$$

Portanto, $\mathbf{T}_{\text{mod}}$ reúne simultaneamente as somas de quadrados associadas ao modelo para todas as combinações lineares das respostas.

11.5.3 Decomposição entre modelo e resíduo

Como

$$\mathbf{H}_n = \mathbf{I}_n - \mathbf{P}_1$$

e

$$\mathbf{I}_n = \mathbf{P}_Z + \mathbf{M}_Z,$$

segue que

$$\mathbf{H}_n = (\mathbf{P}_Z - \mathbf{P}_1) + \mathbf{M}_Z. \quad (11.110)$$

Além disso,

$$(\mathbf{P}_Z - \mathbf{P}_1) \mathbf{M}_Z = \mathbf{0}.$$

Assim, as duas parcelas correspondem a subespaços ortogonais.

Proposição 11.9 (Decomposição da SSCP total). *Se o modelo contém intercepto,*

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E}, \quad (11.111)$$

em que

$$\mathbf{T} = \mathbf{Y}^\top \mathbf{H}_n \mathbf{Y},$$

$$\mathbf{T}_{\text{mod}} = \mathbf{Y}^\top (\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y}$$

e

$$\mathbf{E} = \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y}.$$

Comprovação. Substituindo Equação 11.110 na definição de $\mathbf{T}$,

$$\begin{aligned}\mathbf{T} &= \mathbf{Y}^\top \mathbf{H}_n \mathbf{Y} \\ &= \mathbf{Y}^\top [(\mathbf{P}_Z - \mathbf{P}_1) + \mathbf{M}_Z] \mathbf{Y} \\ &= \mathbf{T}_{\text{mod}} + \mathbf{E}.\end{aligned}$$

□

A decomposição pode ser escrita também como

$$\begin{aligned}& \sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}}) (\mathbf{y}_i - \bar{\mathbf{y}})^\top \\ &= \sum_{i=1}^n (\hat{\mathbf{y}}_i - \bar{\mathbf{y}}) (\hat{\mathbf{y}}_i - \bar{\mathbf{y}})^\top \\ & \quad + \sum_{i=1}^n (\mathbf{y}_i - \hat{\mathbf{y}}_i) (\mathbf{y}_i - \hat{\mathbf{y}}_i)^\top.\end{aligned}\tag{11.112}$$

A primeira parcela à direita é $\mathbf{T}_{\text{mod}}$ e a segunda é $\mathbf{E}$.

As dimensões dos subespaços correspondentes fornecem

$$n - 1 = (r - 1) + (n - r).\tag{11.113}$$

A Tabela 11.1 resume as dimensões dos três subespaços envolvidos.

Tabela 11.1: Decomposição das dimensões associadas à SSCP total no modelo com intercepto.

Fonte	Projetor	Graus de liberdade
Total corrigido	$\mathbf{H}_n$	$n - 1$
Modelo além do intercepto	$\mathbf{P}_Z - \mathbf{P}_1$	$r - 1$
Residual	$\mathbf{M}_Z$	$n - r$

Os graus de liberdade correspondem aos postos dos projetores no espaço das unidades. Eles não devem ser confundidos com os postos das matrizes de SSCP, que também dependem de p .

Em particular,

$$\text{posto}(\mathbf{T}) \leq \min(p, n - 1),$$

$$\text{posto}(\mathbf{T}_{\text{mod}}) \leq \min(p, r - 1),$$

e

$$\text{posto}(\mathbf{E}) \leq \min(p, n - r). \quad (11.114)$$

11.5.4 Combinações lineares das respostas

A decomposição matricial contém, simultaneamente, as decomposições correspondentes a todas as combinações lineares das respostas.

Para

$$\mathbf{a} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{a}^\top \mathbf{T} \mathbf{a} = \mathbf{a}^\top \mathbf{T}_{\text{mod}} \mathbf{a} + \mathbf{a}^\top \mathbf{E} \mathbf{a}. \quad (11.115)$$

Cada termo possui interpretação univariada:

$$\mathbf{a}^\top \mathbf{T} \mathbf{a}$$

é a soma de quadrados total de $\mathbf{Y}\mathbf{a}$,

$$\mathbf{a}^\top \mathbf{T}_{\text{mod}} \mathbf{a}$$

é a soma de quadrados associada ao modelo, e

$$\mathbf{a}^\top \mathbf{E} \mathbf{a}$$

é a soma de quadrados residual.

Essa relação é suficiente, neste capítulo, para mostrar como a decomposição matricial preserva simultaneamente as decomposições das respostas originais e de suas combinações lineares. A utilização conjunta dessas matrizes em procedimentos inferenciais será desenvolvida no Capítulo 12 e, posteriormente, na formulação das técnicas multivariadas.

11.5.5 Modelos sem intercepto

Se

$$\mathbf{1}_n \notin \mathcal{C}(\mathbf{Z}),$$

a diferença

$$\mathbf{P}_Z - \mathbf{P}_1$$

não é, em geral, um projetor. Portanto, a decomposição corrigida

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E}$$

não se aplica na forma anterior.

Continua válida a decomposição em relação à origem:

$$\mathbf{Y}^\top \mathbf{Y} = \mathbf{Y}^\top \mathbf{P}_Z \mathbf{Y} + \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y}. \quad (11.116)$$

Nesse caso, a primeira parcela descreve os valores ajustados em relação à origem, enquanto a segunda continua sendo a SSCP residual.

As dimensões satisfazem

$$n = r + (n - r).$$

Modelo sem intercepto

A retirada do intercepto altera o espaço de médias e a interpretação da decomposição da variação.

Uma decomposição em relação à origem não deve ser interpretada automaticamente como uma decomposição da dispersão em torno da média amostral.

11.5.6 Modelo de grupos como caso particular

Um delineamento formado por indicadores de g grupos não vazios fornece um caso particular do modelo linear multivariado.

Na parametrização por médias de grupos,

$$\mathbf{B} = \begin{bmatrix} \mu_1^\top \\ \vdots \\ \mu_g^\top \end{bmatrix},$$

e o estimador de mínimos quadrados é

$$\widehat{\mathbf{B}}_{\text{obs}} = \begin{bmatrix} \bar{\mathbf{y}}_1^\top \\ \vdots \\ \bar{\mathbf{y}}_g^\top \end{bmatrix}. \quad (11.117)$$

Os valores ajustados de cada unidade são, portanto, os vetores de médias do respectivo grupo.

Nesse caso, a SSCP residual é

$$\mathbf{E} = \sum_{h=1}^g \sum_{i \in G_h} (\mathbf{y}_i - \bar{\mathbf{y}}_h) (\mathbf{y}_i - \bar{\mathbf{y}}_h)^\top. \quad (11.118)$$

Comparando com Definição 8.14,

$$\mathbf{E} = \mathbf{T}_{\text{intra}}. \quad (11.119)$$

A parcela associada ao modelo é

$$\mathbf{T}_{\text{mod}} = \sum_{h=1}^g n_h (\bar{\mathbf{y}}_h - \bar{\mathbf{y}}) (\bar{\mathbf{y}}_h - \bar{\mathbf{y}})^\top. \quad (11.120)$$

Comparando com Definição 8.15,

$$\mathbf{T}_{\text{mod}} = \mathbf{T}_{\text{entre}}. \quad (11.121)$$

Assim,

$$\mathbf{T} = \mathbf{T}_{\text{entre}} + \mathbf{T}_{\text{intra}}, \quad (11.122)$$

que é exatamente Proposição 8.11, agora obtida como caso particular da decomposição por projeções do modelo linear.

Os graus de liberdade tornam-se

$$n - 1 = (g - 1) + (n - g). \quad (11.123)$$

O objetivo desta passagem é somente mostrar a correspondência entre a decomposição já estudada no Capítulo 8 e a estrutura geral do modelo linear. A formulação inferencial da comparação de vetores de médias será desenvolvida posteriormente e não é necessária neste ponto.

A decomposição depende do **espaço de médias representado pelo delineamento**, e não de uma parametrização específica desse espaço. Diferentes matrizes de delineamento podem produzir os mesmos valores ajustados e resíduos mesmo quando seus coeficientes possuem interpretações distintas. Essa questão conduz ao estudo de posto, parametrização e estimabilidade.

11.6 Posto, parametrização e estimabilidade

A expressão

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}$$

pressupõe que

$$\text{posto}(\mathbf{Z}) = q.$$

Essa condição garante a identificação dos elementos da matriz de parâmetros na parametrização adotada.

Entretanto, uma estrutura de médias pode ser representada por uma matriz de delineamento com colunas linearmente dependentes. Nesse caso, diferentes matrizes de parâmetros podem produzir exatamente a mesma matriz

ZB.

A distinção entre **identificação dos parâmetros** e **identificação da estrutura de médias** é o ponto central desta seção.

11.6.1 Delineamento com posto deficiente

Considere

$$\mathbf{Z} \in \mathbb{R}^{n \times q}$$

com

$$r = \text{posto}(\mathbf{Z}) < q. \quad (11.124)$$

Pelo teorema posto-nulidade,

$$\dim \mathcal{N}(\mathbf{Z}) = q - r.$$

Logo, existem vetores não nulos

$$\mathbf{d} \in \mathcal{N}(\mathbf{Z})$$

tais que

$$\mathbf{Z}\mathbf{d} = \mathbf{0}.$$

Mais geralmente, se

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

possui suas colunas em

$$\mathcal{N}(\mathbf{Z}),$$

então

$$\mathbf{Z}\mathbf{D} = \mathbf{0}.$$

Consequentemente,

$$\mathbf{Z}(\mathbf{B} + \mathbf{D}) = \mathbf{Z}\mathbf{B}. \quad (11.125)$$

Definição 11.15 (Matrizes de parâmetros equivalentes). Duas matrizes

$$\mathbf{B}_1, \mathbf{B}_2 \in \mathbb{R}^{q \times p}$$

são equivalentes em relação ao delineamento $\mathbf{Z}$ quando

$$\mathbf{Z}\mathbf{B}_1 = \mathbf{Z}\mathbf{B}_2. \quad (11.126)$$

Equivalentemente,

$$\mathbf{Z}(\mathbf{B}_1 - \mathbf{B}_2) = \mathbf{0}.$$

Portanto, a classe de matrizes que representam a mesma estrutura de médias é

$$\{\mathbf{B} + \mathbf{D} : \mathbf{Z}\mathbf{D} = \mathbf{0}\}. \quad (11.127)$$

Quando $r < q$, a matriz $\mathbf{B}$ não é identificada integralmente. A matriz

$$\mathbf{Z}\mathbf{B}$$

pode, entretanto, estar perfeitamente determinada.

Essa distinção explica por que um modelo pode apresentar coeficientes individualmente não identificados e, ainda assim, possuir valores ajustados, resíduos e funções paramétricas de interesse unicamente determinados.

11.6.2 Pseudoinversa e soluções de mínimos quadrados

A pseudoinversa de Moore–Penrose e sua relação com mínimos quadrados foram desenvolvidas em Definição 6.11 e Proposição 6.22.

Quando

$$r < q,$$

a matriz

$$\mathbf{Z}^\top \mathbf{Z}$$

é singular, mas o problema de mínimos quadrados continua tendo solução.

Uma solução particular é

$$\widehat{\mathbf{B}}_0 = \mathbf{Z}^+ \mathbf{y}. \quad (11.128)$$

Após a observação,

$$\widehat{\mathbf{B}}_{0,\text{obs}} = \mathbf{Z}^+ \mathbf{Y}. \quad (11.129)$$

Proposição 11.10 (Soluções de mínimos quadrados sob posto deficiente). *Se*

$$\text{posto}(\mathbf{Z}) = r < q,$$

o conjunto das soluções das equações normais pode ser escrito como

$$\widehat{\mathbf{B}}_{\mathbf{K}} = \mathbf{Z}^+ \mathbf{y} + (\mathbf{I}_q - \mathbf{Z}^+ \mathbf{Z}) \mathbf{K}, \quad (11.130)$$

em que

$$\mathbf{K} \in \mathbb{R}^{q \times p}$$

é arbitrária.

Todas as soluções produzem a mesma matriz de valores ajustados:

$$\mathbf{Z} \widehat{\mathbf{B}}_{\mathbf{K}} = \mathbf{Z} \mathbf{Z}^+ \mathbf{y} = \mathbf{P}_{\mathbf{Z}} \mathbf{y}. \quad (11.131)$$

A igualdade decorre de

$$\mathbf{Z} (\mathbf{I}_q - \mathbf{Z}^+ \mathbf{Z}) = \mathbf{0}.$$

A solução

$$\widehat{\mathbf{B}}_0 = \mathbf{Z}^+ \mathbf{y}$$

é o representante de menor norma de Frobenius entre as soluções de mínimos quadrados. Essa propriedade seleciona uma solução algébrica, mas **não torna identificáveis os elementos de $\mathbf{B}$ que não são determinados pelo modelo.**

Independentemente da solução escolhida, são únicos:

$$\hat{\mathbf{y}} = \mathbf{P}_Z \mathbf{y},$$

$$\hat{\mathbf{u}} = \mathbf{M}_Z \mathbf{y},$$

e

$$\mathbf{E}_{\text{res}} = \mathbf{y}^\top \mathbf{M}_Z \mathbf{y}.$$

Após a observação, permanecem únicos

$$\hat{\mathbf{Y}}, \quad \hat{\mathbf{U}} \quad \text{e} \quad \mathbf{E}.$$

Os graus de liberdade residuais continuam sendo determinados pelo posto efetivo:

$$\nu_E = n - r.$$

A estimação não viesada da matriz de covariâncias residual permanece, portanto,

$$\hat{\Sigma} = \frac{\mathbf{E}_{\text{res}}}{n - r}.$$

11.6.3 Funções estimáveis

Quando $\mathbf{B}$ não é identificada integralmente, afirmações sobre elementos individuais de $\mathbf{B}$ podem depender da parametrização adotada. A inferência deve ser construída sobre funções dos parâmetros que sejam invariantes em todas as representações equivalentes do mesmo modelo.

Considere

$$\mathbf{C} \in \mathbb{R}^{g \times q}.$$

A função

$$\mathbf{CB} \in \mathbb{R}^{g \times p}$$

combina as linhas da matriz de parâmetros.

Definição 11.16 (Função linear estimável). A função

$$\mathbf{CB}$$

é estimável quando existe uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times g}$$

tal que

$$E(\mathbf{A}^\top \mathbf{y} \mid \mathbf{Z}) = \mathbf{CB}$$

para toda matriz de parâmetros $\mathbf{B}$.

Como

$$E(\mathbf{y} \mid \mathbf{Z}) = \mathbf{ZB},$$

a condição anterior equivale a

$$\mathbf{A}^\top \mathbf{Z} = \mathbf{C}. \tag{11.132}$$

Portanto, a estimabilidade depende do espaço linha de $\mathbf{Z}$.

Proposição 11.11 (Caracterização das funções estimáveis). *Para*

$$\mathbf{C} \in \mathbb{R}^{g \times q},$$

são equivalentes:

1. $\mathbf{CB}$ é estimável;
2. existe $\mathbf{A} \in \mathbb{R}^{n \times g}$ tal que

$$\mathbf{C} = \mathbf{A}^\top \mathbf{Z};$$

3. as linhas de $\mathbf{C}$ pertencem ao espaço linha de $\mathbf{Z}$:

$$\mathcal{C}(\mathbf{C}^\top) \subseteq \mathcal{C}(\mathbf{Z}^\top);$$

4. vale

$$\mathbf{C} = \mathbf{C}\mathbf{Z}^+\mathbf{Z};$$

5. $\mathbf{C}$ anula as direções paramétricas não identificáveis:

$$\mathbf{C}(\mathbf{I}_q - \mathbf{Z}^+\mathbf{Z}) = \mathbf{0}.$$

Em particular,

$$\mathbf{C}\mathbf{B} \text{ é estimável} \iff \mathbf{C} = \mathbf{C}\mathbf{Z}^+\mathbf{Z}. \quad (11.133)$$

Comprovação. A existência de $\mathbf{A}$ tal que

$$\mathbf{C} = \mathbf{A}^\top \mathbf{Z}$$

é equivalente a afirmar que cada linha de $\mathbf{C}$ pertence ao espaço linha de $\mathbf{Z}$.

Por outro lado,

$$\mathbf{Z}^+\mathbf{Z}$$

é o projetor ortogonal sobre

$$\mathcal{C}(\mathbf{Z}^\top).$$

Logo, uma matriz possui todas as suas linhas nesse espaço se, e somente se,

$$\mathbf{C} = \mathbf{C}\mathbf{Z}^+\mathbf{Z}.$$

Como

$$\mathbf{I}_q - \mathbf{Z}^+\mathbf{Z}$$

projeta sobre

$$\mathcal{N}(\mathbf{Z}),$$

a última condição equivale a

$$\mathbf{C} (\mathbf{I}_q - \mathbf{Z}^+ \mathbf{Z}) = \mathbf{0}.$$

□

A caracterização também pode ser expressa diretamente em termos das parametrizações equivalentes.

Se

$$\mathbf{ZB}_1 = \mathbf{ZB}_2,$$

então

$$\mathbf{CB}$$

é estimável se

$$\mathbf{CB}_1 = \mathbf{CB}_2$$

para todas as matrizes de parâmetros equivalentes.

Isso ocorre precisamente porque $\mathbf{C}$ elimina as componentes pertencentes ao núcleo de $\mathbf{Z}$.

11.6.4 Estimador de uma função estimável

Quando $\mathbf{CB}$ é estimável, pode-se utilizar

$$\widehat{\boldsymbol{\Theta}}_C = \mathbf{CZ}^+ \mathbf{y}. \quad (11.134)$$

Sua esperança condicional é

$$\begin{aligned} E(\widehat{\boldsymbol{\Theta}}_C \mid \mathbf{Z}) &= \mathbf{CZ}^+ \mathbf{ZB} \\ &= \mathbf{CB}. \end{aligned} \quad (11.135)$$

Além disso, se

$$\widehat{\mathbf{B}}_{\mathbf{K}}$$

é qualquer solução de mínimos quadrados, então

$$\mathbf{C}\widehat{\mathbf{B}}_{\mathbf{K}} = \mathbf{C}\mathbf{Z}^+y. \quad (11.136)$$

Portanto, a estimativa de uma função estimável é invariável em relação à escolha do representante da classe de soluções de mínimos quadrados.

Esse resultado é mais importante para a inferência do que a unicidade dos coeficientes individuais: as hipóteses científicas devem ser formuladas sobre funções identificáveis da estrutura de médias.

11.6.5 Parametrizações equivalentes

Duas matrizes de delineamento podem representar o mesmo modelo de médias mesmo quando possuem números de colunas ou coeficientes com interpretações diferentes.

Se

$$\mathcal{C}(\mathbf{Z}_1) = \mathcal{C}(\mathbf{Z}_2), \quad (11.137)$$

então seus projetores ortogonais coincidem:

$$\mathbf{P}_{Z_1} = \mathbf{P}_{Z_2}.$$

Consequentemente, para qualquer matriz observada $\mathbf{Y}$,

$$\widehat{\mathbf{Y}}_1 = \widehat{\mathbf{Y}}_2,$$

$$\widehat{\mathbf{U}}_1 = \widehat{\mathbf{U}}_2,$$

e

$$\mathbf{E}_1 = \mathbf{E}_2. \quad (11.138)$$

As parametrizações podem, portanto, atribuir significados diferentes aos coeficientes individuais e ainda representar exatamente a mesma estrutura de médias.

Codificações com grupo de referência, efeitos com restrição de soma zero e outras representações de fatores são exemplos dessa situação. O desenvolvimento dessas codificações não é necessário para a formulação geral do modelo.

O objeto invariável é o espaço

$$\mathcal{C}(\mathbf{Z}),$$

e não uma determinada lista de coeficientes.

11.6.6 Restrições de identificação

Quando uma parametrização é redundante, pode-se selecionar um representante único impondo restrições adicionais aos parâmetros.

Considere

$$\mathbf{R} \in \mathbb{R}^{(q-r) \times q}$$

e

$$\mathbf{R}\mathbf{B} = \mathbf{0}. \quad (11.139)$$

Se

$$\text{posto}(\mathbf{R}) = q - r$$

e

$$\mathcal{N}(\mathbf{Z}) \cap \mathcal{N}(\mathbf{R}) = \{\mathbf{0}\}, \quad (11.140)$$

então as restrições selecionam um único representante de cada classe paramétrica equivalente.

Equivalentemente,

$$\text{posto} \begin{bmatrix} \mathbf{Z} \\ \mathbf{R} \end{bmatrix} = q. \quad (11.141)$$

A função das restrições é eliminar as direções do núcleo de $\mathbf{Z}$ que permanecem livres na parametrização.

Restrição de identificação e hipótese estatística

Uma restrição de identificação escolhe uma representação única para um modelo cuja estrutura de médias já está definida.

Ela não constitui, por si só, uma afirmação científica a ser testada.

As hipóteses estatísticas devem ser formuladas sobre funções estimáveis dos parâmetros, independentemente da restrição adotada para representar esses parâmetros.

11.6.7 Aprofundamento: posto numérico

O posto

$$r = \text{posto}(\mathbf{Z})$$

utilizado até aqui é uma propriedade algébrica: ele descreve dependências lineares exatas.

Em aplicações computacionais, colunas de $\mathbf{Z}$ podem ser quase linearmente dependentes. Nesse caso, o modelo pode possuir posto algébrico completo e, ainda assim, apresentar estimativas de coeficientes numericamente instáveis.

O número de condição e sua interpretação por meio dos valores singulares foram desenvolvidos em Definição 6.9. Para uma matriz de delineamento com posto coluna completo,

$$\kappa_2(\mathbf{Z}^\top \mathbf{Z}) = \kappa_2(\mathbf{Z})^2. \quad (11.142)$$

Por isso, a formação explícita de

$$\mathbf{Z}^\top \mathbf{Z}$$

pode acentuar problemas de condicionamento.

Posto algébrico e estabilidade numérica

Deficiência de posto e mau condicionamento são problemas distintos.

- **Deficiência de posto:** existe dependência linear exata e determinados parâmetros não são identificáveis.
- **Mau condicionamento:** o modelo pode ser identificável, mas determinadas direções paramétricas são estimadas de forma sensível a pequenas perturbações.

QR e SVD permitem trabalhar diretamente com o espaço gerado pelas colunas de $\mathbf{Z}$ e são preferíveis à inversão explícita de $\mathbf{Z}^\top \mathbf{Z}$ em cálculos numéricos.

A escolha de tolerâncias para definir um posto numérico pertence à implementação computacional e não altera a definição algébrica de estimabilidade utilizada neste capítulo.

A distinção entre parâmetros individuais e funções estimáveis permite formular hipóteses sem depender de uma parametrização particular. Na próxima seção, as combinações das linhas da

matriz de parâmetros serão combinadas também com transformações das respostas, conduzindo à forma geral

CBM.

11.7 Hipóteses lineares multivariadas

O modelo linear multivariado permite formular hipóteses sobre combinações dos parâmetros e das respostas. A estrutura geral utiliza duas transformações:

- uma multiplicação à esquerda de $\mathbf{B}$, que seleciona ou combina termos do modelo;
- uma multiplicação à direita, que seleciona ou combina respostas.

Essa organização produz hipóteses que permanecem válidas em diferentes parametrizações, desde que as funções paramétricas envolvidas sejam estimáveis (Rao, 1973; Rencher; Christensen, 2012).

11.7.1 Contrastes sobre parâmetros e combinações das respostas

Considere

$$\mathbf{C} \in \mathbb{R}^{g \times q}.$$

A função

$$\mathbf{CB} \in \mathbb{R}^{g \times p}$$

combina as linhas da matriz de parâmetros.

Se

$$\mathbf{c}^\top \in \mathbb{R}^{1 \times q},$$

então

$$\mathbf{c}^\top \mathbf{B} \in \mathbb{R}^{1 \times p}$$

contém a mesma combinação dos parâmetros para todas as respostas.

Por exemplo, se a linha h de $\mathbf{B}$ representa um determinado termo do modelo,

$$\mathbf{c}^\top = \mathbf{e}_h^\top$$

seleciona os coeficientes desse termo nas p respostas.

De modo complementar, considere

$$\mathbf{M} \in \mathbb{R}^{p \times s}.$$

A função

$$\mathbf{BM} \in \mathbb{R}^{q \times s}$$

combina as colunas de $\mathbf{B}$.

Para uma coluna

$$\mathbf{m} \in \mathbb{R}^p,$$

a resposta transformada é

$$W_i = \mathbf{m}^\top \mathbf{Y}_i.$$

Sua média condicional é

$$\begin{aligned} E(W_i \mid \mathbf{Z}) &= \mathbf{m}^\top \mathbf{B}^\top \mathbf{z}_i \\ &= \mathbf{z}_i^\top \mathbf{B} \mathbf{m}, \end{aligned} \tag{11.143}$$

e sua variância residual é

$$\text{Var}(W_i \mid \mathbf{Z}) = \mathbf{m}^\top \Sigma \mathbf{m}. \tag{11.144}$$

Para várias combinações simultâneas,

$$\mathbf{y}_M = \mathbf{y} \mathbf{M},$$

e o modelo transformado é

$$\mathbf{y}_M = \mathbf{Z}(\mathbf{B} \mathbf{M}) + \mathcal{E} \mathbf{M}. \tag{11.145}$$

A matriz de covariâncias residuais das respostas transformadas é

$$\Sigma_M = \mathbf{M}^\top \Sigma \mathbf{M}. \quad (11.146)$$

Essa transformação é a mesma discutida anteriormente para o modelo linear multivariado. Aqui ela passa a ser utilizada para definir funções paramétricas de interesse.

11.7.2 Hipótese linear geral

Definição 11.17 (Função paramétrica bilateral). Considere

$$\mathbf{C} \in \mathbb{R}^{g \times q}, \quad \mathbf{B} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{M} \in \mathbb{R}^{p \times s}.$$

Define-se

$$\Theta = \mathbf{CBM} \in \mathbb{R}^{g \times s}. \quad (11.147)$$

As dimensões são

$$(g \times q)(q \times p)(p \times s) = g \times s.$$

As linhas de Θ correspondem às combinações dos termos definidas por $\mathbf{C}$, enquanto suas colunas correspondem às combinações das respostas definidas por $\mathbf{M}$.

Definição 11.18 (Hipótese linear geral multivariada). A hipótese linear geral é

$$H_0 : \mathbf{CBM} = \Theta_0, \quad (11.148)$$

em que

$$\Theta_0 \in \mathbb{R}^{g \times s}$$

é conhecida.

A alternativa é

$$H_1 : \mathbf{CBM} \neq \Theta_0.$$

Quando

$$\Theta_0 = \mathbf{0},$$

obtém-se a hipótese homogênea

$$H_0 : \mathbf{CBM} = \mathbf{0}. \quad (11.149)$$

Dois casos particulares são:

$$H_0 : \mathbf{CB} = \Theta_0,$$

quando

$$\mathbf{M} = \mathbf{I}_p,$$

e

$$H_0 : \mathbf{BM} = \Theta_0,$$

quando

$$\mathbf{C} = \mathbf{I}_q.$$

Se

$$g = s = 1,$$

a hipótese reduz-se à forma escalar

$$H_0 : \mathbf{c}^\top \mathbf{Bm} = \theta_0. \quad (11.150)$$

A mesma estrutura permite, portanto, representar hipóteses escalares, vetoriais ou matriciais.

11.7.3 Estimabilidade da hipótese

A hipótese deve envolver uma função paramétrica identificável pelo modelo.

Como desenvolvido na seção anterior,

$$\mathbf{CB}$$

é estimável se, e somente se,

$$\mathbf{C} = \mathbf{CZ}^+\mathbf{Z}.$$

Para

$$\mathbf{M} \neq \mathbf{0},$$

essa é também a condição para que

$$\mathbf{CBM}$$

seja invariável em todas as parametrizações equivalentes de $\mathbf{B}$:

$$\mathbf{C} = \mathbf{CZ}^+\mathbf{Z}. \quad (11.151)$$

De fato, se

$$\mathbf{D}$$

satisfaz

$$\mathbf{ZD} = \mathbf{0},$$

então

$$\mathbf{B} \quad \text{e} \quad \mathbf{B} + \mathbf{D}$$

representam a mesma estrutura de médias. A função bilateral será identificada somente se

$$\mathbf{CDM} = \mathbf{0}$$

para toda perturbação dessa forma.

Quando a condição de estimabilidade é satisfeita, define-se

$$\widehat{\Theta} = \mathbf{C}\mathbf{Z}^+ \mathbf{y}\mathbf{M}. \quad (11.152)$$

Após a observação,

$$\widehat{\Theta}_{\text{obs}} = \mathbf{C}\mathbf{Z}^+ \mathbf{Y}\mathbf{M}. \quad (11.153)$$

Sua esperança condicional é

$$E\left(\widehat{\Theta} \mid \mathbf{Z}\right) = \mathbf{C}\mathbf{B}\mathbf{M}. \quad (11.154)$$

Defina

$$\mathbf{A}_C = \mathbf{C}\mathbf{Z}^+ \in \mathbb{R}^{g \times n} \quad (11.155)$$

e

$$\mathbf{G}_C = \mathbf{A}_C \mathbf{A}_C^\top.$$

Logo,

$$\mathbf{G}_C = \mathbf{C}\mathbf{Z}^+ (\mathbf{Z}^+)^{\top} \mathbf{C}^{\top}. \quad (11.156)$$

Se $\mathbf{Z}$ possui posto coluna completo,

$$\mathbf{G}_C = \mathbf{C} (\mathbf{Z}^{\top} \mathbf{Z})^{-1} \mathbf{C}^{\top}. \quad (11.157)$$

Proposição 11.12 (Covariância da função bilateral estimada). *Para uma função estimável*

$$\Theta = \mathbf{C}\mathbf{B}\mathbf{M},$$

tem-se

$$\text{Cov} \left[\text{vec} \left(\widehat{\Theta} \right) \mid \mathbf{Z} \right] = (\mathbf{M}^{\top} \Sigma \mathbf{M}) \otimes \mathbf{G}_C. \quad (11.158)$$

Comprovação. Como

$$\widehat{\Theta} - \Theta = \mathbf{A}_C \mathcal{E} \mathbf{M},$$

a identidade de vetorização fornece

$$\text{vec}(\widehat{\Theta} - \Theta) = (\mathbf{M}^\top \otimes \mathbf{A}_C) \text{vec}(\mathcal{E}).$$

Utilizando

$$\text{Cov}[\text{vec}(\mathcal{E}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n,$$

obtém-se

$$\begin{aligned} & \text{Cov}[\text{vec}(\widehat{\Theta}) \mid \mathbf{Z}] \\ &= (\mathbf{M}^\top \otimes \mathbf{A}_C) (\Sigma \otimes \mathbf{I}_n) (\mathbf{M} \otimes \mathbf{A}_C^\top) \\ &= (\mathbf{M}^\top \Sigma \mathbf{M}) \otimes (\mathbf{A}_C \mathbf{A}_C^\top). \end{aligned}$$

A segunda parcela é $\mathbf{G}_C$. □

A expressão separa novamente duas fontes de variabilidade:

$$\mathbf{G}_C$$

depende do delineamento e das combinações definidas por $\mathbf{C}$, enquanto

$$\mathbf{M}^\top \Sigma \mathbf{M}$$

depende da variabilidade residual das combinações das respostas.

Para evitar redundâncias na representação da hipótese, é conveniente trabalhar com:

$$\text{posto}(\mathbf{C}) = g$$

e

$$\text{posto}(\mathbf{M}) = s.$$

Sob estimabilidade, se $\mathbf{C}$ possui posto linha completo, então

$$\mathbf{G}_C \succ \mathbf{0}.$$

Quando $\mathbf{C}$ possui posto linha completo, a dimensão do subespaço de restrições no espaço dos termos do modelo é

$$\nu_H = g. \quad (11.159)$$

Se $\mathbf{M}$ também possui posto coluna completo, a matriz

$$\mathbf{CBM}$$

contém gs restrições escalares independentes, organizadas em g direções de hipótese sobre s combinações das respostas.

Se $\mathbf{C}$ ou $\mathbf{M}$ possui combinações redundantes, é preferível substituí-la por uma base do mesmo espaço antes da construção dos objetos inferenciais.

11.7.4 SSCP da hipótese

Considere o afastamento observado em relação à hipótese nula:

$$\widehat{\Delta} = \widehat{\Theta}_{\text{obs}} - \Theta_0 = \mathbf{C}\widehat{\mathbf{B}}_{\text{obs}}\mathbf{M} - \Theta_0. \quad (11.160)$$

Suponha que a função seja estimável e que $\mathbf{C}$ tenha sido representada sem restrições redundantes, de modo que

$$\mathbf{G}_C \succ \mathbf{0}.$$

Definição 11.19 (SSCP da hipótese linear). Define-se

$$\mathbf{H} = \widehat{\Delta}^\top \mathbf{G}_C^{-1} \widehat{\Delta}. \quad (11.161)$$

A matriz

$$\mathbf{H} \in \mathbb{R}^{s \times s}$$

é simétrica e positiva semidefinida.

Para qualquer

$$\mathbf{a} \in \mathbb{R}^s,$$

$$\begin{aligned} \mathbf{a}^\top \mathbf{H} \mathbf{a} &= \left\| \mathbf{G}_C^{-1/2} \widehat{\Delta} \mathbf{a} \right\|^2 \\ &\geq 0. \end{aligned} \tag{11.162}$$

Assim,

$$\mathbf{H} \succeq \mathbf{0}.$$

Além disso,

$$\text{posto}(\mathbf{H}) \leq \min(g, s). \tag{11.163}$$

Se

$$\widehat{\Delta} = \mathbf{0},$$

então

$$\mathbf{H} = \mathbf{0}.$$

A matriz residual correspondente às respostas transformadas é

$$\mathbf{E}_M = \mathbf{M}^\top \mathbf{E} \mathbf{M}. \tag{11.164}$$

Ela possui dimensão

$$s \times s.$$

Para qualquer

$$\mathbf{a} \in \mathbb{R}^s,$$

$$\mathbf{a}^\top \mathbf{E}_M \mathbf{a} = (\mathbf{M} \mathbf{a})^\top \mathbf{E} (\mathbf{M} \mathbf{a}) \geq 0.$$

Portanto,

$$\mathbf{E}_M \succeq \mathbf{0}.$$

Quando

$$\mathbf{E} \succ \mathbf{0}$$

e $\mathbf{M}$ possui posto coluna completo,

$$\mathbf{E}_M \succ \mathbf{0}.$$

A formulação da hipótese produz, assim, duas matrizes associadas ao mesmo conjunto de respostas transformadas:

$$(\mathbf{H}, \mathbf{E}_M).$$

A primeira representa o afastamento observado da hipótese; a segunda representa a variabilidade residual correspondente.

No Capítulo 12 serão estudadas as distribuições amostrais desses objetos e sua utilização em procedimentos inferenciais. A construção de critérios específicos das técnicas multivariadas pertence ao Módulo 3.

11.7.5 Modelos encaixados

Uma hipótese linear homogênea pode ser representada pela comparação entre dois espaços lineares de médias encaixados (Christensen, 2011). Essa formulação é particularmente útil quando a hipótese corresponde à retirada de determinados termos de um modelo completo.

Considere:

- um modelo completo, com matriz de delineamento $\mathbf{Z}_F$;
- um modelo reduzido, com matriz de delineamento $\mathbf{Z}_R$;

tais que

$$\mathcal{C}(\mathbf{Z}_R) \subseteq \mathcal{C}(\mathbf{Z}_F). \quad (11.165)$$

Defina

$$r_F = \text{posto}(\mathbf{Z}_F)$$

e

$$r_R = \text{posto}(\mathbf{Z}_R).$$

Seus projetores são

$$\mathbf{P}_F = \mathbf{Z}_F \mathbf{Z}_F^+$$

e

$$\mathbf{P}_R = \mathbf{Z}_R \mathbf{Z}_R^+.$$

Como os espaços são encaixados,

$$\mathbf{P}_F \mathbf{P}_R = \mathbf{P}_R \mathbf{P}_F = \mathbf{P}_R. \quad (11.166)$$

Proposição 11.13 (Projetor associado à diferença entre modelos). *Se*

$$\mathcal{C}(\mathbf{Z}_R) \subseteq \mathcal{C}(\mathbf{Z}_F),$$

então

$$\mathbf{P}_F - \mathbf{P}_R$$

é um projetor ortogonal.

Seu posto é

$$\text{posto}(\mathbf{P}_F - \mathbf{P}_R) = r_F - r_R. \quad (11.167)$$

Comprovação. A matriz é simétrica porque $\mathbf{P}_F$ e $\mathbf{P}_R$ são simétricas.

Além disso,

$$\begin{aligned} (\mathbf{P}_F - \mathbf{P}_R)^2 &= \mathbf{P}_F - \mathbf{P}_F \mathbf{P}_R - \mathbf{P}_R \mathbf{P}_F + \mathbf{P}_R \\ &= \mathbf{P}_F - \mathbf{P}_R. \end{aligned}$$

Logo, trata-se de um projetor ortogonal.

Seu espaço imagem corresponde às direções pertencentes ao espaço completo e ortogonais ao espaço reduzido, cuja dimensão é

$$r_F - r_R.$$

□

Considere inicialmente as respostas originais, isto é,

$$\mathbf{M} = \mathbf{I}_p.$$

A SSCP associada à diferença entre os dois espaços será denotada por $\mathbf{H} \in \mathbb{R}^{p \times p}$.

As SSCP's residuais dos dois modelos são

$$\mathbf{E}_F = \mathbf{Y}^\top (\mathbf{I}_n - \mathbf{P}_F) \mathbf{Y}$$

e

$$\mathbf{E}_R = \mathbf{Y}^\top (\mathbf{I}_n - \mathbf{P}_R) \mathbf{Y}.$$

Como

$$\mathbf{I}_n - \mathbf{P}_R = (\mathbf{P}_F - \mathbf{P}_R) + (\mathbf{I}_n - \mathbf{P}_F),$$

obtém-se:

Proposição 11.14 (Decomposição das SSCP de modelos encaixados). *Para dois modelos encaixados,*

$$\mathbf{E}_R = \mathbf{H} + \mathbf{E}_F, \tag{11.168}$$

em que

$$\mathbf{H} = \mathbf{Y}^\top (\mathbf{P}_F - \mathbf{P}_R) \mathbf{Y}. \tag{11.169}$$

Consequentemente,

$$\mathbf{H} = \mathbf{E}_R - \mathbf{E}_F. \quad (11.170)$$

Como

$$\mathbf{P}_F - \mathbf{P}_R \succeq \mathbf{0},$$

tem-se

$$\mathbf{H} \succeq \mathbf{0}. \quad (11.171)$$

Os graus de liberdade associados à diferença entre os espaços são

$$\nu_H = r_F - r_R, \quad (11.172)$$

enquanto os graus de liberdade residuais do modelo completo são

$$\nu_E = n - r_F. \quad (11.173)$$

Para respostas transformadas por $\mathbf{M}$,

$$\mathbf{H}_M = \mathbf{M}^\top \mathbf{H} \mathbf{M}$$

e

$$\mathbf{E}_{F,M} = \mathbf{M}^\top \mathbf{E}_F \mathbf{M}. \quad (11.174)$$

A formulação por

CBM

explicita a função paramétrica que está sendo restringida. A formulação por modelos encaixados explicita a diferença entre os espaços de médias. Quando ambas representam a mesma restrição linear, conduzem à mesma parcela de variação associada à hipótese.

11.7.6 Casos particulares

A forma geral comporta diversos problemas sem necessidade de desenvolver cada um como uma técnica independente.

11.7.6.1 Efeito de um termo nas respostas

Se a linha h de $\mathbf{B}$ corresponde a um termo representado por um único coeficiente, tome

$$\mathbf{C} = \mathbf{e}_h^\top$$

e

$$\mathbf{M} = \mathbf{I}_p.$$

A hipótese

$$H_0 : \mathbf{e}_h^\top \mathbf{B} = \mathbf{0}^\top \quad (11.175)$$

afirma que o termo possui coeficiente nulo para todas as respostas.

Se um efeito é representado por várias linhas de $\mathbf{B}$, a matriz $\mathbf{C}$ deve selecionar ou combinar todas as linhas correspondentes.

11.7.6.2 Efeito sobre uma combinação das respostas

Para

$$\mathbf{c} \in \mathbb{R}^q$$

e

$$\mathbf{m} \in \mathbb{R}^p,$$

a hipótese

$$H_0 : \mathbf{c}^\top \mathbf{B} \mathbf{m} = 0 \quad (11.176)$$

avalia o efeito definido por $\mathbf{c}$ sobre a combinação de respostas definida por $\mathbf{m}$.

Por exemplo,

$$\mathbf{m} = \mathbf{e}_j - \mathbf{e}_k$$

representa a diferença entre as respostas j e k .

11.7.6.3 Igualdade do efeito em duas respostas

Tomando

$$\mathbf{C} = \mathbf{e}_h^\top$$

e

$$\mathbf{M} = \mathbf{e}_j - \mathbf{e}_k,$$

obtém-se

$$H_0 : \mathbf{e}_h^\top \mathbf{B} (\mathbf{e}_j - \mathbf{e}_k) = 0, \quad (11.177)$$

que equivale a

$$H_0 : \beta_{hj} = \beta_{hk}.$$

Esses exemplos mostram que $\mathbf{C}$ e $\mathbf{M}$ possuem funções distintas: $\mathbf{C}$ atua sobre os termos do modelo e $\mathbf{M}$ atua sobre as respostas.

O capítulo não precisa enumerar todas as hipóteses possíveis. O objeto que será transportado para a inferência é a estrutura geral

$$H_0 : \mathbf{CBM} = \Theta_0,$$

acompanhada da SSCP da hipótese e da SSCP residual correspondente.

11.8 Exemplo integrado

Exemplo 11.1 (Regressão multivariada com uma covariável e duas respostas). Considere seis unidades. Para cada unidade, registra-se uma variável explicativa quantitativa x e duas respostas Y_1 e Y_2 .

Unidade	x	Y_1	Y_2
1	1	3	8
2	2	5	7
3	3	4	7
4	4	8	5
5	5	9	4
6	6	11	3

A matriz observada de respostas é

$$\mathbf{Y} = \begin{bmatrix} 3 & 8 \\ 5 & 7 \\ 4 & 7 \\ 8 & 5 \\ 9 & 4 \\ 11 & 3 \end{bmatrix},$$

e a matriz de delineamento, contendo intercepto e a covariável, é

$$\mathbf{Z} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \\ 1 & 6 \end{bmatrix}. \quad (11.178)$$

Nesse modelo,

$$\mathbf{B} = \begin{bmatrix} \beta_{01} & \beta_{02} \\ \beta_{11} & \beta_{12} \end{bmatrix},$$

em que a primeira linha contém os interceptos e a segunda contém os efeitos de x sobre as duas respostas.

Como

$$\text{posto}(\mathbf{Z}) = 2,$$

a matriz de parâmetros é identificada.

Tem-se

$$\mathbf{Z}^\top \mathbf{Z} = \begin{bmatrix} 6 & 21 \\ 21 & 91 \end{bmatrix}$$

e

$$(\mathbf{Z}^\top \mathbf{Z})^{-1} = \frac{1}{105} \begin{bmatrix} 91 & -21 \\ -21 & 6 \end{bmatrix}.$$

11.8.1 Estimação da matriz de parâmetros

A estimativa de mínimos quadrados é

$$\widehat{\mathbf{B}}_{\text{obs}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}.$$

Numericamente,

$$\widehat{\mathbf{B}}_{\text{obs}} = \begin{bmatrix} 16/15 & 139/15 \\ 8/5 & -36/35 \end{bmatrix} \approx \begin{bmatrix} 1,067 & 9,267 \\ 1,600 & -1,029 \end{bmatrix}. \quad (11.179)$$

Portanto, as equações ajustadas são

$$\widehat{Y}_1 = 1,067 + 1,600x$$

e

$$\widehat{Y}_2 = 9,267 - 1,029x.$$

A primeira resposta apresenta efeito estimado positivo de x , enquanto a segunda apresenta efeito estimado negativo.

11.8.2 Valores ajustados e resíduos

A matriz de valores ajustados é

$$\widehat{\mathbf{Y}} = \mathbf{Z}\widehat{\mathbf{B}}_{\text{obs}} \approx \begin{bmatrix} 2,667 & 8,238 \\ 4,267 & 7,210 \\ 5,867 & 6,181 \\ 7,467 & 5,152 \\ 9,067 & 4,124 \\ 10,667 & 3,095 \end{bmatrix}. \quad (11.180)$$

Consequentemente,

$$\widehat{\mathbf{U}} = \mathbf{Y} - \widehat{\mathbf{Y}} \approx \begin{bmatrix} 0,333 & -0,238 \\ 0,733 & -0,210 \\ -1,867 & 0,819 \\ 0,533 & -0,152 \\ -0,067 & -0,124 \\ 0,333 & -0,095 \end{bmatrix}. \quad (11.181)$$

As equações normais garantem

$$\mathbf{Z}^\top \widehat{\mathbf{U}} = \mathbf{0}.$$

Em particular, como o modelo contém intercepto, os resíduos somam zero em cada resposta.

11.8.3 SSCP residual e covariância residual

A SSCP residual é

$$\begin{aligned} \mathbf{E} &= \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}} \\ &= \begin{bmatrix} 68/15 & -28/15 \\ -28/15 & 86/105 \end{bmatrix} \\ &\approx \begin{bmatrix} 4,533 & -1,867 \\ -1,867 & 0,819 \end{bmatrix}. \end{aligned} \quad (11.182)$$

Como

$$n = 6$$

e

$$r = 2,$$

os graus de liberdade residuais são

$$\nu_E = n - r = 4.$$

A estimativa não viesada da matriz de covariâncias residual é

$$\begin{aligned}\widehat{\Sigma}_{\text{obs}} &= \frac{\mathbf{E}}{4} \\ &= \begin{bmatrix} 17/15 & -7/15 \\ -7/15 & 43/210 \end{bmatrix} \\ &\approx \begin{bmatrix} 1,133 & -0,467 \\ -0,467 & 0,205 \end{bmatrix}.\end{aligned}\tag{11.183}$$

A covariância residual estimada é negativa. Isso indica que, depois de removida a relação linear com x , desvios positivos de uma resposta tendem a ocorrer juntamente com desvios negativos da outra neste conjunto de dados.

Sob o modelo normal matricial, como $\mathbf{E} \succ \mathbf{0}$, a estimativa de máxima verossimilhança é

$$\begin{aligned}\widehat{\Sigma}_{\text{MV,obs}} &= \frac{\mathbf{E}}{6} \\ &\approx \begin{bmatrix} 0,756 & -0,311 \\ -0,311 & 0,137 \end{bmatrix}.\end{aligned}\tag{11.184}$$

A diferença entre as duas estimativas decorre dos divisores:

$$n - r = 4$$

para o estimador não viesado e

$$n = 6$$

para a máxima verossimilhança sob normalidade.

11.8.4 Decomposição da SSCP total

Como o modelo contém intercepto,

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E}.$$

A SSCP total é

$$\mathbf{T} = \begin{bmatrix} 148/3 & -92/3 \\ -92/3 & 58/3 \end{bmatrix} \approx \begin{bmatrix} 49,333 & -30,667 \\ -30,667 & 19,333 \end{bmatrix}. \quad (11.185)$$

A parcela associada à covariável, além do intercepto, é

$$\mathbf{T}_{\text{mod}} = \begin{bmatrix} 224/5 & -144/5 \\ -144/5 & 648/35 \end{bmatrix} \approx \begin{bmatrix} 44,800 & -28,800 \\ -28,800 & 18,514 \end{bmatrix}. \quad (11.186)$$

Verifica-se que

$$\begin{aligned} \mathbf{T}_{\text{mod}} + \mathbf{E} &= \begin{bmatrix} 44,800 & -28,800 \\ -28,800 & 18,514 \end{bmatrix} + \begin{bmatrix} 4,533 & -1,867 \\ -1,867 & 0,819 \end{bmatrix} \\ &= \begin{bmatrix} 49,333 & -30,667 \\ -30,667 & 19,333 \end{bmatrix} \\ &= \mathbf{T}, \end{aligned}$$

a menos dos arredondamentos apresentados.

Os graus de liberdade correspondentes são

$$5 = 1 + 4,$$

isto é,

$$n - 1 = (r - 1) + (n - r).$$

11.8.5 Hipótese sobre o efeito da covariável

Considere a hipótese de que x não apresenta efeito linear sobre nenhuma das duas respostas.

Para seleccionar a segunda linha de $\mathbf{B}$, defina

$$\mathbf{C} = \begin{bmatrix} 0 & 1 \end{bmatrix}.$$

Como as duas respostas são mantidas,

$$\mathbf{M} = \mathbf{I}_2.$$

A hipótese é

$$H_0 : \mathbf{CB} = \mathbf{0}^\top,$$

ou, equivalentemente,

$$H_0 : \beta_{11} = \beta_{12} = 0. \quad (11.187)$$

A estimativa da função paramétrica é

$$\widehat{\Delta} = \mathbf{CB}_{\text{obs}} = \begin{bmatrix} 8/5 & -36/35 \end{bmatrix} \approx \begin{bmatrix} 1,600 & -1,029 \end{bmatrix}. \quad (11.188)$$

A matriz associada à variabilidade desse contraste é escalar:

$$\begin{aligned} \mathbf{G}_C &= \mathbf{C}(\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{C}^\top \\ &= \frac{2}{35} \\ &\approx 0,057. \end{aligned} \quad (11.189)$$

A SSCP da hipótese é

$$\begin{aligned} \mathbf{H} &= \widehat{\Delta}^\top \mathbf{G}_C^{-1} \widehat{\Delta} \\ &= \begin{bmatrix} 224/5 & -144/5 \\ -144/5 & 648/35 \end{bmatrix} \\ &\approx \begin{bmatrix} 44,800 & -28,800 \\ -28,800 & 18,514 \end{bmatrix}. \end{aligned} \quad (11.190)$$

Nesse caso,

$$\mathbf{H} = \mathbf{T}_{\text{mod}}.$$

A igualdade ocorre porque o modelo completo contém intercepto e covariável, enquanto a hipótese elimina apenas o efeito da covariável. O modelo reduzido contém somente o intercepto.

Consequentemente,

$$\mathbf{E}_R = \mathbf{H} + \mathbf{E} = \mathbf{T}.$$

A construção termina no par

$$(\mathbf{H}, \mathbf{E}).$$

A decisão inferencial sobre a hipótese não pertence a este capítulo. Ela exige as distribuições amostrais desenvolvidas no Capítulo 12.

11.8.6 Hipótese sobre uma combinação das respostas

A mesma estrutura permite avaliar o efeito da covariável sobre uma combinação específica das respostas.

Considere

$$\mathbf{m} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A resposta transformada é

$$Y_1 - Y_2.$$

A hipótese

$$H_0 : \mathbf{CBm} = 0 \tag{11.191}$$

afirma que a covariável não apresenta efeito sobre a diferença entre as duas respostas.

A estimativa é

$$\begin{aligned}\hat{\theta} &= \mathbf{C}\widehat{\mathbf{B}}_{\text{obs}}\mathbf{m} \\ &= \frac{92}{35} \\ &\approx 2,629.\end{aligned}$$

A SSCP residual dessa resposta transformada é

$$\begin{aligned}E_m &= \mathbf{m}^\top \mathbf{E} \mathbf{m} \\ &= \frac{318}{35} \\ &\approx 9,086.\end{aligned}\tag{11.192}$$

O mesmo modelo permite, portanto, formular hipóteses sobre todas as respostas simultaneamente ou sobre combinações específicas delas sem alterar a estrutura básica da estimação.

11.9 Síntese do capítulo

O modelo linear multivariado representa a estrutura de médias de várias respostas por

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E},$$

com

$$E(\mathbf{y} \mid \mathbf{Z}) = \mathbf{Z}\mathbf{B}$$

e

$$\text{Cov}[\text{vec}(\mathcal{E}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n.$$

A matriz $\mathbf{Z}$ determina o espaço das estruturas de médias possíveis. Quando possui posto coluna completo, a matriz de parâmetros é estimada por

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}.$$

O ajuste é uma projeção sobre

$$\mathcal{C}(\mathbf{Z}),$$

de modo que

$$\hat{\mathbf{y}} = \mathbf{P}_Z \mathbf{y}$$

e

$$\hat{\mathbf{u}} = \mathbf{M}_Z \mathbf{y}.$$

A SSCP residual

$$\mathbf{E}_{\text{res}} = \hat{\mathbf{u}}^{\top} \hat{\mathbf{u}}$$

satisfaz

$$E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) = (n - r)\Sigma,$$

em que

$$r = \text{posto}(\mathbf{Z}).$$

Assim,

$$\hat{\Sigma} = \frac{\mathbf{E}_{\text{res}}}{n - r}$$

é um estimador não viesado da matriz de covariâncias residual.

Quando o modelo contém intercepto,

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E},$$

com graus de liberdade

$$n - 1 = (r - 1) + (n - r).$$

No modelo de grupos, essa decomposição recupera diretamente

$$\mathbf{T} = \mathbf{T}_{\text{entre}} + \mathbf{T}_{\text{intra}}$$

do Capítulo 8.

Quando

$$\text{posto}(\mathbf{Z}) < q,$$

os coeficientes de $\mathbf{B}$ podem não ser identificados individualmente. Os valores ajustados e as funções estimáveis permanecem definidos pelo espaço coluna de $\mathbf{Z}$. Uma função

$$\mathbf{CB}$$

é estimável quando

$$\mathbf{C} = \mathbf{CZ}^+\mathbf{Z}.$$

A hipótese linear multivariada geral é

$$H_0 : \mathbf{CBM} = \Theta_0.$$

A matriz $\mathbf{C}$ combina termos do modelo e a matriz $\mathbf{M}$ combina respostas. O afastamento observado da hipótese produz a SSCP

$$\mathbf{H} = \widehat{\Delta}^\top \mathbf{G}_C^{-1} \widehat{\Delta},$$

enquanto a variabilidade residual das respostas transformadas é representada por

$$\mathbf{E}_M = \mathbf{M}^\top \mathbf{E} \mathbf{M}.$$

A Tabela Tabela 11.3 reúne os principais objetos utilizados no capítulo.

Tabela 11.3: Principais objetos do modelo linear multivariado.

Objeto	Expressão	Papel
estrutura de médias	$\mathbf{ZB}$	representa os valores médios permitidos pelo modelo
estimador dos parâmetros	$\widehat{\mathbf{B}}$	estima a estrutura de médias
projedor do modelo	$\mathbf{P}_Z$	projeta as respostas sobre $\mathcal{C}(\mathbf{Z})$
projedor residual	$\mathbf{M}_Z$	retém a parcela ortogonal ao espaço do modelo

Objeto	Expressão	Papel
SSCP residual	$\mathbf{E}$	resume a variabilidade residual observada
SSCP do modelo	$\mathbf{T}_{\text{mod}}$	resume a dispersão associada ao modelo além do intercepto
função estimável	$\mathbf{CB}$	representa combinações paramétricas identificáveis
hipótese geral	$\mathbf{CBM} = \Theta_0$	combina termos e respostas
SSCP da hipótese	$\mathbf{H}$	mede o afastamento observado da hipótese

Ao concluir este capítulo, o estudante deve ser capaz de:

- formular um modelo linear com várias respostas;
- interpretar $\mathbf{B}$ e Σ ;
- obter e interpretar valores ajustados e resíduos;
- construir a SSCP residual e estimar Σ ;
- relacionar posto do delineamento, identificação e estimabilidade;
- formular hipóteses na forma $\mathbf{CBM} = \Theta_0$;
- distinguir a SSCP da hipótese da SSCP residual.

O capítulo estabeleceu os objetos sobre os quais a inferência será construída. O Capítulo 12 desenvolverá as distribuições amostrais necessárias para testar hipóteses e construir regiões de confiança para médias, parâmetros e funções lineares no contexto multivariado.

12 Inferência Multivariada

Os Capítulos 8 a 11 construíram os objetos necessários para a inferência multivariada. O Capítulo 8 estabeleceu a estrutura de covariâncias, o Capítulo 9 especificou a distribuição normal multivariada, o Capítulo 10 tratou das estatísticas amostrais e da estimação e o Capítulo 11 formulou o modelo linear multivariado e as hipóteses lineares.

O objetivo deste capítulo é estudar as distribuições amostrais desses objetos e utilizá-las na construção de testes de hipóteses e regiões de confiança. A distribuição de Wishart fornecerá a distribuição das matrizes de produtos cruzados sob normalidade, enquanto a estatística T^2 de Hotelling permitirá realizar inferência sobre vetores de médias quando a matriz de covariâncias populacional é desconhecida.

A teoria exata será desenvolvida principalmente sob normalidade multivariada. Resultados assintóticos serão utilizados quando a distribuição exata não estiver disponível. A distinção entre resultado exato e resultado assintótico será mantida ao longo do capítulo porque suas condições de validade são diferentes.

O capítulo também utilizará as distribuições dos estimadores e das SSCPs construídas no modelo linear multivariado. Esses resultados encerram a base probabilística e inferencial do Módulo 2. A formulação das técnicas multivariadas que utilizam essa base será desenvolvida no Módulo 3.

Convenções de notação

Neste capítulo:

- $\bar{\mathbf{X}}$ representa o vetor de médias amostral como estatística aleatória e $\bar{\mathbf{x}}$ sua realização observada;
- $\mathbf{S}$ representa a matriz de covariâncias amostral como estatística aleatória e $\mathbf{S}$ sua realização observada;
- $\mathbf{T}$ representa a SSCP amostral aleatória e $\mathbf{T}$ sua realização observada;
- $\mathbf{W}$ representa uma matriz aleatória com distribuição de Wishart;
- $\mathbf{E}_{\text{res}}$ e $\mathbf{E}$ representam, respectivamente, a SSCP residual aleatória e sua realização observada;
- $\mathbf{H}$ e $\mathbf{H}$ representam, respectivamente, a SSCP da hipótese aleatória e sua realização observada;
- $\mathbf{Z}$ continua representando a matriz de delineamento do modelo linear multivariado;
- $\mathbf{A}$ será utilizada posteriormente para formular hipóteses lineares sobre o vetor de

médias.

Os símbolos preservam as convenções estabelecidas nos Capítulos 8 a 11.

12.1 Distribuições amostrais exatas e assintóticas

A inferência estatística utiliza a distribuição amostral de uma estatística para quantificar sua variabilidade e calibrar procedimentos como testes e regiões de confiança. Essa distribuição pode ser conhecida exatamente sob um modelo probabilístico especificado ou aproximada por seu comportamento limite quando o tamanho amostral cresce.

Definição 12.1 (Resultados exatos e assintóticos). Um **resultado exato** é válido para o tamanho amostral considerado sem recorrer a um argumento limite. Quando o resultado é distribucional, ele fornece a distribuição da estatística sob as hipóteses probabilísticas especificadas.

Um **resultado assintótico** descreve o comportamento limite de uma estatística quando o tamanho amostral tende ao infinito. Sua utilização em amostras finitas constitui uma aproximação cuja qualidade depende das condições do problema.

Neste capítulo, os resultados exatos dependerão principalmente da normalidade multivariada. Os resultados assintóticos considerarão, salvo indicação em contrário, o regime

$$p \text{ fixo} \quad \text{e} \quad n \rightarrow \infty. \quad (12.1)$$

Essa distinção deve ser mantida também na interpretação: uma distribuição exata decorre do modelo probabilístico especificado, enquanto uma distribuição limite decorre de um argumento de convergência.

12.1.1 Distribuição da média amostral sob normalidade

Considere uma amostra aleatória

$$\mathbf{X}_1, \dots, \mathbf{X}_n \in \mathbb{R}^p,$$

independente e identicamente distribuída, com

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma.$$

O vetor de médias amostral é

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i.$$

O Capítulo 10 estabeleceu que

$$E(\bar{\mathbf{X}}) = \mu$$

e

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n},$$

conforme Equação 10.55. Esses resultados exigem a existência dos momentos correspondentes, mas não exigem normalidade.

A normalidade acrescenta a distribuição exata da estatística.

Proposição 12.1 (Distribuição da média amostral sob normalidade). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

então

$$\bar{\mathbf{X}} \sim N_p\left(\mu, \frac{\Sigma}{n}\right). \quad (12.2)$$

O resultado é exato para qualquer $n \geq 1$.

Comprovação. O vetor

$$\bar{\mathbf{X}}$$

é uma combinação linear de vetores normais multivariados independentes. Pelo fechamento da família normal sob transformações lineares, estabelecido em Proposição 9.5, sua distribuição é normal multivariada.

Os parâmetros dessa distribuição são os já obtidos no Capítulo 10:

$$E(\bar{\mathbf{X}}) = \mu$$

e

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}.$$

Logo, vale Equação 12.2. □

A proposição mostra a diferença entre propriedades de um estimador e sua distribuição amostral. A igualdade

$$E(\bar{\mathbf{X}}) = \mu$$

expressa ausência de viés. Já

$$\bar{\mathbf{X}} \sim N_p\left(\mu, \frac{\Sigma}{n}\right)$$

descreve toda a distribuição da estatística sob o modelo normal.

Se

$$\Sigma \succ \mathbf{0},$$

a média amostral pode ser branqueada:

$$\sqrt{n} \Sigma^{-1/2} (\bar{\mathbf{X}} - \mu) \sim N_p(\mathbf{0}, \mathbf{I}_p). \quad (12.3)$$

Aplicando o resultado qui-quadrado da distância de Mahalanobis estabelecido em Proposição 9.9,

$$n (\bar{\mathbf{X}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{X}} - \mu) \sim \chi_p^2. \quad (12.4)$$

O fator n aparece porque

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n},$$

de modo que

$$\left(\frac{\Sigma}{n}\right)^{-1} = n\Sigma^{-1}.$$

A expressão em Equação 12.4 fornece a base do procedimento inferencial para o vetor de médias quando Σ é conhecida. O caso em que Σ precisa ser estimada exigirá a distribuição da matriz de covariâncias amostral.

12.1.2 Teorema Central do Limite multivariado

Fora da família normal, a distribuição de

$$\bar{\mathbf{X}}$$

depende da distribuição conjunta da população. Sob condições mais gerais, entretanto, seu comportamento limite continua sendo normal.

Teorema 12.1 (Teorema Central do Limite multivariado). *Considere, para dimensão fixa p , vetores aleatórios independentes e identicamente distribuídos*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \in \mathbb{R}^p,$$

com

$$E(\mathbf{X}_i) = \mu$$

e matriz de covariâncias finita

$$\text{Cov}(\mathbf{X}_i) = \Sigma.$$

Então,

$$\sqrt{n}(\bar{\mathbf{X}} - \mu) \xrightarrow{d} N_p(\mathbf{0}, \Sigma). \quad (12.5)$$

Comprovação. Para qualquer vetor fixo

$$\mathbf{a} \in \mathbb{R}^p,$$

considere

$$\sqrt{n} \mathbf{a}^\top (\bar{\mathbf{X}} - \mu) = \frac{1}{\sqrt{n}} \sum_{i=1}^n \mathbf{a}^\top (\mathbf{X}_i - \mu).$$

As variáveis

$$\mathbf{a}^\top \mathbf{X}_1, \dots, \mathbf{a}^\top \mathbf{X}_n$$

são independentes e identicamente distribuídas, com média

$$\mathbf{a}^\top \mu$$

e variância finita

$$\mathbf{a}^\top \Sigma \mathbf{a}.$$

Pelo Teorema Central do Limite univariado,

$$\sqrt{n} \mathbf{a}^\top (\bar{\mathbf{X}} - \mu) \xrightarrow{d} N(0, \mathbf{a}^\top \Sigma \mathbf{a}).$$

Como a convergência vale para todo vetor fixo $\mathbf{a}$, o Teorema de Cramér–Wold em Teorema 9.1 implica Equação 12.5. $\square$

O resultado permite escrever, em sentido assintótico,

$$\bar{\mathbf{X}} \overset{a}{\sim} N_p\left(\mu, \frac{\Sigma}{n}\right). \quad (12.6)$$

A mesma expressão possui, portanto, dois significados distintos:

$$\bar{\mathbf{X}} \sim N_p\left(\mu, \frac{\Sigma}{n}\right)$$

é uma distribuição **exata** quando a população é normal multivariada, enquanto

$$\bar{\mathbf{X}} \stackrel{a}{\sim} N_p \left(\mu, \frac{\Sigma}{n} \right)$$

é uma aproximação **assintótica** sob as condições do Teorema 12.1.

Se

$$\Sigma \succ \mathbf{0},$$

então

$$\sqrt{n} \Sigma^{-1/2} (\bar{\mathbf{X}} - \mu) \stackrel{d}{\rightarrow} N_p (\mathbf{0}, \mathbf{I}_p), \quad (12.7)$$

e, pelo teorema da aplicação contínua,

$$n (\bar{\mathbf{X}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{X}} - \mu) \stackrel{d}{\rightarrow} \chi_p^2. \quad (12.8)$$

Assim, a mesma forma quadrática possui distribuição qui-quadrado exata sob normalidade e distribuição limite qui-quadrado sob as condições do TCL multivariado.

Alcance da aproximação assintótica

O Teorema 12.1 considera dimensão p fixa e exige a existência dos momentos de segunda ordem.

O resultado não justifica automaticamente a inferência clássica quando há dependência entre unidades, inexistência de segundos momentos ou crescimento de p juntamente com n . Além disso, a substituição de Σ por uma matriz de covariâncias estimada introduz outra fonte de aleatoriedade que precisa ser considerada separadamente.

A distribuição da média amostral descreve a incerteza associada à localização. Quando Σ é desconhecida, a inferência depende também da distribuição da matriz que estima a dispersão. Sob normalidade multivariada, essa distribuição é obtida a partir da distribuição de Wishart.

12.2 Distribuição de Wishart

A inferência sobre uma matriz de covariâncias exige conhecer a distribuição das matrizes de produtos cruzados que a originam. No caso univariado, somas de quadrados de variáveis normais padronizadas conduzem à distribuição qui-quadrado. A distribuição de Wishart estende essa construção para somas de produtos externos de vetores normais e ocupa, na inferência normal multivariada, papel análogo ao da distribuição qui-quadrado na inferência univariada (Muirhead, 1982).

12.2.1 Construção e parametrização

Considere vetores aleatórios independentes

$$\mathbf{Z}_1, \dots, \mathbf{Z}_\nu \in \mathbb{R}^p$$

tais que

$$\mathbf{Z}_j \sim N_p(\mathbf{0}, \Sigma), \quad j = 1, \dots, \nu,$$

com

$$n_1 \geq 2, \quad n_2 \geq 2$$

e

$$\Sigma \succ \mathbf{0}.$$

Cada produto externo

$$\mathbf{Z}_j \mathbf{Z}_j^\top$$

é uma matriz simétrica e positiva semidefinida.

Definição 12.2 (Distribuição de Wishart). Se

$$\mathbf{Z}_1, \dots, \mathbf{Z}_\nu \stackrel{\text{iid}}{\sim} N_p(\mathbf{0}, \Sigma),$$

com

$$\nu \in \{1, 2, \dots\},$$

então a matriz aleatória

$$\mathbf{W} = \sum_{j=1}^{\nu} \mathbf{Z}_j \mathbf{Z}_j^\top \tag{12.9}$$

segue uma distribuição de Wishart com ν graus de liberdade e matriz de escala Σ .

Escreve-se

$$\mathbf{W} \sim W_p(\nu, \Sigma). \quad (12.10)$$

A parametrização utilizada neste livro é caracterizada por

$$E(\mathbf{W}) = \nu \Sigma.$$

A matriz Σ é, portanto, a **matriz de escala** da distribuição. Essa convenção deve ser explicitada porque outras parametrizações da família Wishart podem ser encontradas na literatura.

Quando

$$p = 1,$$

a distribuição reduz-se à qui-quadrado. Se

$$\Sigma = [\sigma^2],$$

então

$$W = \sum_{j=1}^{\nu} Z_j^2$$

e

$$\frac{W}{\sigma^2} \sim \chi_{\nu}^2. \quad (12.11)$$

Essa redução mostra a relação direta entre as duas distribuições.

12.2.2 Suporte, posto e definição positiva

Defina

$$\mathcal{Z} = \begin{bmatrix} \mathbf{Z}_1^\top \\ \vdots \\ \mathbf{Z}_\nu^\top \end{bmatrix} \in \mathbb{R}^{\nu \times p}.$$

A matriz Wishart pode ser escrita como

$$\mathbf{W} = \mathcal{Z}^\top \mathcal{Z}. \quad (12.12)$$

Logo, $\mathbf{W}$ é uma matriz de Gram e satisfaz

$$\mathbf{W} \succeq \mathbf{0}.$$

Além disso,

$$\text{posto}(\mathbf{W}) = \text{posto}(\mathcal{Z}) \leq \min(\nu, p).$$

Proposição 12.2 (Posto de uma matriz Wishart). *Se*

$$\mathbf{W} \sim W_p(\nu, \Sigma),$$

pela construção em Definição 12.2, com

$$\Sigma \succ \mathbf{0},$$

então, com probabilidade 1,

$$\text{posto}(\mathbf{W}) = \min(\nu, p). \quad (12.13)$$

Consequentemente:

- *se $\nu \geq p$, então*

$$\mathbf{W} \succ \mathbf{0}$$

com probabilidade 1;

- se $\nu < p$, então

$$\text{posto}(\mathbf{W}) = \nu$$

com probabilidade 1 e a matriz é singular.

A condição

$$\nu \geq p$$

é, portanto, necessária e suficiente para a definição positiva quase certa na construção com graus de liberdade inteiros e

$$\Sigma \succ \mathbf{0}.$$

12.2.3 Momentos

A esperança da matriz Wishart é obtida diretamente da construção por produtos externos.

Proposição 12.3 (Momentos de uma matriz Wishart). *Se*

$$\mathbf{W} \sim W_p(\nu, \Sigma),$$

pela construção em Definição 12.2, então

$$E(\mathbf{W}) = \nu \Sigma. \quad (12.14)$$

Para os elementos da matriz,

$$\text{Cov}(W_{jk}, W_{\ell m}) = \nu (\sigma_{j\ell} \sigma_{km} + \sigma_{jm} \sigma_{k\ell}). \quad (12.15)$$

Comprovação. Pela construção,

$$W_{jk} = \sum_{h=1}^{\nu} Z_{hj} Z_{hk}.$$

Como

$$E\left(\mathbf{Z}_{hj}\mathbf{Z}_{hk}\right)=\sigma_{jk},$$

segue que

$$E\left(\mathbf{W}_{jk}\right)=\nu\sigma_{jk},$$

para todos os pares (j, k) . Portanto,

$$E\left(\mathbf{W}\right)=\nu\Sigma.$$

Para a covariância entre elementos, a independência dos vetores associados a valores distintos de h elimina as covariâncias cruzadas. Para cada vetor normal de média zero, a identidade de quarta ordem

$$\begin{aligned} E\left(\mathbf{Z}_j\mathbf{Z}_k\mathbf{Z}_\ell\mathbf{Z}_m\right) &= \sigma_{jk}\sigma_{\ell m} + \sigma_{j\ell}\sigma_{km} \\ &\quad + \sigma_{jm}\sigma_{k\ell} \end{aligned}$$

fornece, após a subtração do produto das médias e a soma das ν contribuições independentes,

$$\text{Cov}\left(\mathbf{W}_{jk},\mathbf{W}_{\ell m}\right)=\nu\left(\sigma_{j\ell}\sigma_{km}+\sigma_{jm}\sigma_{k\ell}\right).$$

□

Em particular,

$$\text{Var}\left(\mathbf{W}_{jj}\right)=2\nu\sigma_{jj}^2, \tag{12.16}$$

e, para $j \neq k$,

$$\text{Var}\left(\mathbf{W}_{jk}\right)=\nu\left(\sigma_{jj}\sigma_{kk}+\sigma_{jk}^2\right). \tag{12.17}$$

A matriz média por grau de liberdade,

$$\frac{\mathbf{W}}{\nu},$$

satisfaz

$$E\left(\frac{\mathbf{W}}{\nu}\right)=\Sigma,$$

e a variabilidade de seus elementos decresce à ordem $1/\nu$.

12.2.4 Formas quadráticas

A analogia com a distribuição qui-quadrado também aparece em qualquer direção fixa do espaço das variáveis.

Proposição 12.4 (Forma quadrática de uma matriz Wishart). *Se*

$$\mathbf{W} \sim W_p(\nu, \Sigma)$$

pela construção em Definição 12.2, então, para qualquer

$$\mathbf{a} \in \mathbb{R}^p, \quad \mathbf{a} \neq \mathbf{0},$$

vale

$$\frac{\mathbf{a}^\top \mathbf{W} \mathbf{a}}{\mathbf{a}^\top \Sigma \mathbf{a}} \sim \chi_\nu^2. \quad (12.18)$$

Comprovação. De Equação 12.9,

$$\mathbf{a}^\top \mathbf{W} \mathbf{a} = \sum_{j=1}^{\nu} (\mathbf{a}^\top \mathbf{Z}_j)^2.$$

Como

$$\mathbf{a}^\top \mathbf{Z}_j \sim N(0, \mathbf{a}^\top \Sigma \mathbf{a}),$$

as variáveis

$$\frac{\mathbf{a}^\top \mathbf{Z}_j}{\sqrt{\mathbf{a}^\top \Sigma \mathbf{a}}}$$

são normais padrão independentes. A soma de seus quadrados possui distribuição χ_ν^2 . □

Assim, cada projeção univariada de uma matriz Wishart recupera a estrutura qui-quadrado correspondente à variância naquela direção.

12.2.5 Aditividade

Proposição 12.5 (Aditividade da distribuição de Wishart). *Se*

$$\mathbf{W}_1 \sim W_p(\nu_1, \Sigma)$$

e

$$\mathbf{W}_2 \sim W_p(\nu_2, \Sigma)$$

são independentes e possuem a mesma matriz de escala, então

$$\mathbf{W}_1 + \mathbf{W}_2 \sim W_p(\nu_1 + \nu_2, \Sigma). \quad (12.19)$$

Comprovação. Pela construção da distribuição, as duas matrizes podem ser representadas por somas de, respectivamente, ν_1 e ν_2 produtos externos de vetores normais independentes com a mesma matriz de covariâncias Σ .

A soma das duas matrizes reúne

$$\nu_1 + \nu_2$$

produtos externos independentes e, portanto, possui a distribuição indicada. $\square$

A exigência de uma matriz de escala comum é necessária. A soma de matrizes Wishart independentes com escalas distintas não segue, em geral, uma distribuição Wishart.

12.2.6 Transformações lineares

A transformação de uma matriz Wishart acompanha a transformação da matriz de covariâncias dos vetores normais que a geram.

Proposição 12.6 (Transformação linear de uma matriz Wishart). *Considere*

$$\mathbf{W} \sim W_p(\nu, \Sigma)$$

pela construção em Definição 12.2.

Se

$$\mathbf{L} \in \mathbb{R}^{r \times p}$$

possui posto linha completo,

$$\text{posto}(\mathbf{L}) = r,$$

então

$$\mathbf{LWL}^\top \sim W_r(\nu, \mathbf{L}\Sigma\mathbf{L}^\top). \quad (12.20)$$

Comprovação. Pela construção,

$$\mathbf{LWL}^\top = \sum_{j=1}^{\nu} (\mathbf{LZ}_j)(\mathbf{LZ}_j)^\top.$$

Pelo fechamento da família normal sob transformações lineares,

$$\mathbf{LZ}_j \sim N_r(\mathbf{0}, \mathbf{L}\Sigma\mathbf{L}^\top),$$

e os vetores transformados permanecem independentes.

Como $\mathbf{L}$ possui posto linha completo e

$$\Sigma \succ \mathbf{0},$$

tem-se

$$\mathbf{L}\Sigma\mathbf{L}^\top \succ \mathbf{0}.$$

Logo, a soma possui a distribuição apresentada. □

Se $\mathbf{L}$ não possui posto linha completo,

$$\mathbf{L}\Sigma\mathbf{L}^\top$$

é singular e a distribuição fica restrita ao subespaço imagem de $\mathbf{L}$. Essa extensão singular não será necessária na sequência principal.

Para

$$\mathbf{L} = \Sigma^{-1/2},$$

obtém-se

$$\Sigma^{-1/2} \mathbf{W} \Sigma^{-1/2} \sim W_p(\nu, \mathbf{I}_p). \quad (12.21)$$

Essa transformação retira a escala populacional da distribuição.

12.2.7 Aprofundamento: densidade da distribuição de Wishart

Leitura de aprofundamento

A construção por produtos externos, os momentos, o posto, a aditividade e as transformações são suficientes para os resultados inferenciais utilizados neste capítulo.

A densidade explícita é apresentada para completar a descrição da família e para evidenciar sua relação posterior com verossimilhanças envolvendo matrizes de covariâncias.

A construção em Definição 12.2 utiliza um número inteiro de vetores normais. A família Wishart não singular admite uma extensão para graus de liberdade reais

$$\nu > p - 1$$

por meio de sua densidade no cone das matrizes simétricas positivas definidas (Muirhead, 1982).

Proposição 12.7 (Densidade da distribuição de Wishart). *Se*

$$\mathbf{W} \sim W_p(\nu, \Sigma),$$

com

$$\nu > p - 1$$

e

$$\Sigma \succ \mathbf{0},$$

então sua densidade é

$$f_{\mathbf{W}}(\mathbf{W}) = \frac{|\mathbf{W}|^{(\nu-p-1)/2} \exp \left[-\frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{W}) \right]}{2^{\nu p/2} |\Sigma|^{\nu/2} \Gamma_p(\nu/2)}, \quad (12.22)$$

para

$$\mathbf{W} \succ \mathbf{0}.$$

A função gama multivariada é

$$\Gamma_p(a) = \pi^{p(p-1)/4} \prod_{j=1}^p \Gamma\left(a - \frac{j-1}{2}\right), \quad (12.23)$$

definida para

$$a > \frac{p-1}{2}.$$

Quando a Wishart é construída pela soma de ν produtos externos e

$$\nu < p,$$

a matriz é singular com probabilidade 1. Nesse caso, sua distribuição está concentrada em matrizes positivas semidefinidas de posto ν e não possui a densidade anterior no cone positivo definido.

A sequência inferencial deste capítulo utilizará graus de liberdade inteiros provenientes do tamanho amostral ou do posto de matrizes de projeção.

12.2.8 Distribuição da SSCP e da covariância amostral

O Capítulo 10 definiu a SSCP amostral aleatória em Definição 10.13 por

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top$$

e a matriz de covariâncias amostral em Definição 10.14 por

$$\mathbf{S} = \frac{\mathbf{T}}{n-1}.$$

O Capítulo 10 também estabeleceu

$$E(\mathbf{T}) = (n-1)\Sigma$$

em Proposição 10.10. Sob normalidade multivariada, podemos determinar a distribuição completa dessa estatística.

Teorema 12.2 (Distribuição da SSCP e da covariância amostral). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$n \geq 2$$

e

$$\Sigma \succ \mathbf{0},$$

então

$$\mathbf{T} = (n-1)\mathbf{S} \sim W_p(n-1, \Sigma). \quad (12.24)$$

Comprovação. Organize a amostra na matriz aleatória

$$\mathcal{X} = \begin{bmatrix} \mathbf{X}_1^\top \\ \vdots \\ \mathbf{X}_n^\top \end{bmatrix}.$$

Considere uma matriz ortogonal

$$\mathbf{Q} \in \mathbb{R}^{n \times n}$$

cujas primeira linha seja

$$\frac{1}{\sqrt{n}} \mathbf{1}_n^\top$$

e defina

$$\mathcal{Z} = \mathbf{Q}\mathcal{X}.$$

A primeira linha é

$$\mathbf{Z}_1^\top = \sqrt{n} \bar{\mathbf{X}}^\top. \quad (12.25)$$

As demais linhas são combinações lineares cujos coeficientes somam zero. Portanto,

$$E(\mathbf{Z}_j) = \mathbf{0}, \quad j = 2, \dots, n.$$

A covariância cruzada entre duas linhas transformadas é

$$\text{Cov}(\mathbf{Z}_j, \mathbf{Z}_k) = [\mathbf{Q}\mathbf{Q}^\top]_{jk} \Sigma = \delta_{jk} \Sigma.$$

Como as linhas transformadas são conjuntamente normais, covariâncias cruzadas nulas implicam independência. Assim,

$$\mathbf{Z}_2, \dots, \mathbf{Z}_n \stackrel{\text{iid}}{\sim} N_p(\mathbf{0}, \Sigma).$$

A matriz de centralização pode ser escrita como

$$\mathbf{H}_n = \mathbf{Q}^\top \begin{bmatrix} 0 & \mathbf{0}^\top \\ \mathbf{0} & \mathbf{I}_{n-1} \end{bmatrix} \mathbf{Q}.$$

Utilizando a forma matricial da SSCP estabelecida em Equação 10.63,

$$\begin{aligned} \mathbf{T} &= \mathcal{X}^\top \mathbf{H}_n \mathcal{X} \\ &= \sum_{j=2}^n \mathbf{Z}_j \mathbf{Z}_j^\top. \end{aligned}$$

Essa é a soma de $n - 1$ produtos externos de vetores independentes com distribuição

$$N_p(\mathbf{0}, \Sigma).$$

Pela Definição 12.2,

$$\mathbf{T} \sim W_p(n - 1, \Sigma).$$

□

O resultado fornece novamente

$$E(\mathbf{T}) = (n-1)\Sigma$$

e, conseqüentemente,

$$E(\mathbf{S}) = \Sigma.$$

A novidade neste capítulo é a distribuição completa:

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma).$$

Pela Proposição 12.4, para qualquer

$$\mathbf{a} \neq \mathbf{0},$$

tem-se

$$\frac{(n-1)\mathbf{a}^\top \mathbf{S} \mathbf{a}}{\mathbf{a}^\top \Sigma \mathbf{a}} \sim \chi_{n-1}^2. \quad (12.26)$$

Assim, a variância amostral de qualquer combinação linear fixa possui a mesma estrutura qui-quadrado conhecida do caso univariado.

Para os elementos de $\mathbf{S}$,

$$\text{Cov}(S_{jk}, S_{\ell m}) = \frac{\sigma_{j\ell}\sigma_{km} + \sigma_{jm}\sigma_{k\ell}}{n-1}. \quad (12.27)$$

Em particular,

$$\text{Var}(S_{jj}) = \frac{2\sigma_{jj}^2}{n-1}$$

e, para $j \neq k$,

$$\text{Var}(S_{jk}) = \frac{\sigma_{jj}\sigma_{kk} + \sigma_{jk}^2}{n-1}.$$

Esses resultados são exatos sob normalidade multivariada.

A matriz de covariâncias amostral possui, com probabilidade 1,

$$\text{posto}(\mathbf{S}) = \min(p, n - 1). \quad (12.28)$$

Portanto, sob

$$\Sigma \succ \mathbf{0},$$

a condição

$$n > p \quad (12.29)$$

é necessária e suficiente para que

$$\mathbf{S} \succ \mathbf{0}$$

com probabilidade 1.

Quando

$$p \geq n,$$

a matriz $\mathbf{S}$ é necessariamente singular. Essa restrição dimensional terá consequência direta para a forma clássica da estatística T^2 de Hotelling.

Sob o modelo normal, o Capítulo 10 também definiu o estimador de máxima verossimilhança

$$\widehat{\Sigma}_{\text{MV}} = \frac{\mathbf{T}}{n}.$$

Sempre que sua interpretação como estimador de máxima verossimilhança no espaço

$$\Sigma \succ \mathbf{0}$$

for válida,

$$n\widehat{\Sigma}_{\text{MV}} = \mathbf{T} \sim W_p(n - 1, \Sigma). \quad (12.30)$$

A distribuição continua envolvendo $n - 1$ graus de liberdade, pois a média populacional também foi estimada a partir da amostra.

12.2.9 Independência entre média e covariância

A transformação ortogonal utilizada na prova do Teorema 12.2 separa a informação amostral associada à localização da informação associada à dispersão.

A primeira linha transformada depende exclusivamente de

$$\bar{\mathbf{X}},$$

enquanto

$$\mathbf{T}$$

e, conseqüentemente,

$$\mathbf{S},$$

dependem apenas das demais linhas.

Teorema 12.3 (Independência entre média e covariância amostral). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$n \geq 2$$

e

$$\Sigma \succ \mathbf{0},$$

então

$$\bar{\mathbf{X}} \perp \mathbf{T}.$$

Como

$$\mathbf{S} = \frac{\mathbf{T}}{n-1},$$

também vale

$$\bar{\mathbf{X}} \perp \mathbf{S}. \quad (12.31)$$

Comprovação. Na prova do Teorema 12.2,

$$\mathbf{Z}_1^\top = \sqrt{n} \bar{\mathbf{X}}^\top,$$

enquanto

$$\mathbf{T} = \sum_{j=2}^n \mathbf{Z}_j \mathbf{Z}_j^\top.$$

A ortogonalidade de $\mathbf{Q}$ produz covariâncias cruzadas nulas entre as linhas transformadas. Como essas linhas são conjuntamente normais,

$$\mathbf{Z}_1 \perp (\mathbf{Z}_2, \dots, \mathbf{Z}_n).$$

A média amostral é função apenas da primeira linha e a SSCP é função apenas das demais. Portanto,

$$\bar{\mathbf{X}} \perp \mathbf{T}.$$

Como $\mathbf{S}$ é uma transformação determinística de $\mathbf{T}$, segue também

$$\bar{\mathbf{X}} \perp \mathbf{S}.$$

□

A independência é um resultado **exato da amostragem normal**. Ela não decorre somente da independência entre as observações.

O que depende da normalidade

As propriedades

$$E(\bar{\mathbf{X}}) = \mu$$

e

$$E(\mathbf{S}) = \Sigma$$

não exigem normalidade multivariada.

Em contraste,

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma)$$

e

$$\bar{\mathbf{X}} \perp \mathbf{S}$$

são resultados exatos da amostragem normal.

Para uma população geral, a distribuição de $\mathbf{S}$ depende de características adicionais da distribuição, incluindo momentos de ordem superior, e a média e a covariância amostrais não são, em geral, independentes.

Temos, portanto, sob amostragem normal, o par

$$\bar{\mathbf{X}} \sim N_p\left(\mu, \frac{\Sigma}{n}\right)$$

e

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma),$$

com

$$\bar{\mathbf{X}} \perp \mathbf{S}. \quad (12.32)$$

Essa estrutura **normal–Wishart** fornece a base para a inferência exata sobre o vetor de médias quando Σ é desconhecida.

No modelo linear multivariado, a mesma lógica reaparece: a média amostral é substituída pelo estimador da matriz de parâmetros, e os $n-1$ graus de liberdade da SSCP amostral são substituídos pelos graus de liberdade residuais do modelo.

12.3 Distribuições no modelo linear multivariado

O Capítulo 11 formulou o modelo linear multivariado, obteve os estimadores de mínimos quadrados e construiu as SSCPs residual e da hipótese. Nesta seção, a hipótese de normalidade fornece as distribuições amostrais exatas desses objetos.

Considere o modelo

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E},$$

com

$$\mathcal{E} \mid \mathbf{Z} \sim N_{n \times p}(\mathbf{0}, \mathbf{I}_n, \Sigma), \quad \Sigma \succ \mathbf{0},$$

conforme Equação 11.22.

Equivalentemente,

$$\mathcal{Y} \mid \mathbf{Z} \sim N_{n \times p}(\mathbf{ZB}, \mathbf{I}_n, \Sigma). \quad (12.33)$$

A matriz de delineamento é considerada fixa, ou a análise é condicionada em seus valores observados. Defina

$$r = \text{posto}(\mathbf{Z})$$

e

$$\nu_E = n - r,$$

que coincide com o número de graus de liberdade residuais definido em Equação 11.83.

12.3.1 Distribuição do estimador da matriz de parâmetros

Suponha inicialmente que

$$r = q.$$

Nesse caso, o estimador de mínimos quadrados definido em Equação 11.37 é

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathcal{Y}.$$

Pela decomposição obtida no Capítulo 11,

$$\widehat{\mathbf{B}} = \mathbf{B} + (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathcal{E}.$$

A segunda parcela é uma transformação linear da matriz normal de erros.

Proposição 12.8 (Distribuição do estimador da matriz de parâmetros). *Sob o modelo linear normal multivariado e*

$$\text{posto}(\mathbf{Z}) = q,$$

tem-se

$$\widehat{\mathbf{B}} \mid \mathbf{Z} \sim N_{q \times p} \left[\mathbf{B}, (\mathbf{Z}^\top \mathbf{Z})^{-1}, \Sigma \right]. \quad (12.34)$$

Equivalentemente,

$$\text{vec}(\widehat{\mathbf{B}}) \mid \mathbf{Z} \sim N_{pq} \left[\text{vec}(\mathbf{B}), \Sigma \otimes (\mathbf{Z}^\top \mathbf{Z})^{-1} \right]. \quad (12.35)$$

Comprovação. Defina

$$\mathbf{A}_Z = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top.$$

Então

$$\widehat{\mathbf{B}} = \mathbf{B} + \mathbf{A}_Z \mathcal{E}.$$

Pela transformação da distribuição normal matricial,

$$\mathbf{A}_Z \mathcal{E} \mid \mathbf{Z} \sim N_{q \times p}(\mathbf{0}, \mathbf{A}_Z \mathbf{A}_Z^\top, \Sigma).$$

Como

$$\begin{aligned} \mathbf{A}_Z \mathbf{A}_Z^\top &= (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Z} (\mathbf{Z}^\top \mathbf{Z})^{-1} \\ &= (\mathbf{Z}^\top \mathbf{Z})^{-1}, \end{aligned}$$

segue o resultado. □

A distribuição confirma, em forma exata sob normalidade, os momentos obtidos em Proposição 11.3:

$$E(\widehat{\mathbf{B}} \mid \mathbf{Z}) = \mathbf{B}$$

e

$$\text{Cov}[\text{vec}(\widehat{\mathbf{B}}) \mid \mathbf{Z}] = \Sigma \otimes (\mathbf{Z}^\top \mathbf{Z})^{-1}.$$

Portanto, a variabilidade do estimador reúne duas estruturas:

- a geometria do delineamento, por meio de $(\mathbf{Z}^\top \mathbf{Z})^{-1}$;
- a dependência residual entre as respostas, por meio de Σ .

Quando

$$r < q,$$

a matriz $\mathbf{B}$ não é identificada integralmente. Como desenvolvido no Capítulo 11, a inferência deve então ser formulada sobre funções estimáveis, e não sobre uma solução particular produzida pela pseudoinversa.

12.3.2 Distribuição de funções estimáveis

Considere

$$\mathbf{C} \in \mathbb{R}^{g \times q}$$

com linhas linearmente independentes e satisfazendo a condição de estimabilidade

$$\mathbf{C} = \mathbf{C}\mathbf{Z}^+\mathbf{Z}.$$

Considere também

$$\mathbf{M} \in \mathbb{R}^{p \times s}$$

com

$$\text{posto}(\mathbf{M}) = s.$$

A função paramétrica bilateral é

$$\Theta = \mathbf{CBM} \in \mathbb{R}^{g \times s}.$$

Seu estimador, definido em Equação 11.152, é

$$\widehat{\Theta} = \mathbf{CZ}^+ y \mathbf{M}.$$

Defina

$$\mathbf{G}_C = \mathbf{CZ}^+ (\mathbf{Z}^+)^{\top} \mathbf{C}^{\top} \quad (12.36)$$

e

$$\Sigma_M = \mathbf{M}^{\top} \Sigma \mathbf{M}. \quad (12.37)$$

Sob as condições estabelecidas,

$$\mathbf{G}_C \succ \mathbf{0}$$

e

$$\Sigma_M \succ \mathbf{0}.$$

Proposição 12.9 (Distribuição de uma função estimável). *Sob o modelo linear normal multivariado,*

$$\widehat{\Theta} \mid \mathbf{Z} \sim N_{g \times s}(\mathbf{CBM}, \mathbf{G}_C, \Sigma_M). \quad (12.38)$$

Equivalentemente,

$$\text{vec}(\widehat{\Theta}) \mid \mathbf{Z} \sim N_{gs}[\text{vec}(\mathbf{CBM}), \Sigma_M \otimes \mathbf{G}_C]. \quad (12.39)$$

Comprovação. Pela condição de estimabilidade,

$$\mathbf{CZ}^+\mathbf{Z} = \mathbf{C}.$$

Logo,

$$\begin{aligned}\widehat{\Theta} &= \mathbf{CZ}^+(\mathbf{ZB} + \mathcal{E})\mathbf{M} \\ &= \mathbf{CBM} + \mathbf{CZ}^+\mathcal{E}\mathbf{M}.\end{aligned}$$

Aplicando a transformação bilateral da distribuição normal matricial,

$$\mathbf{CZ}^+\mathcal{E}\mathbf{M} \mid \mathbf{Z} \sim N_{g \times s}(\mathbf{0}, \mathbf{G}_C, \Sigma_M),$$

o que fornece o resultado. □

A matriz de covariâncias vetorizada coincide com o resultado obtido em Proposição 11.12. A normalidade acrescenta, portanto, a distribuição amostral exata à estrutura de segundos momentos já conhecida.

12.3.3 Distribuição da SSCP residual

O Capítulo 11 definiu

$$\mathbf{E}_{\text{res}} = \widehat{\mathcal{U}}^\top \widehat{\mathcal{U}} = \mathbf{y}^\top \mathbf{M}_Z \mathbf{y},$$

em Definição 11.11.

Como

$$\mathbf{M}_Z \mathbf{Z} = \mathbf{0},$$

pode-se escrever

$$\mathbf{E}_{\text{res}} = \mathcal{E}^\top \mathbf{M}_Z \mathcal{E}.$$

A matriz

$$\mathbf{M}_Z$$

é um projetor ortogonal de posto

$$\nu_E = n - r.$$

Proposição 12.10 (Distribuição da SSCP residual). *Sob o modelo linear normal multivariado, se*

$$\nu_E = n - r \geq 1,$$

então

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(n - r, \Sigma). \quad (12.40)$$

Comprovação. Seja

$$\mathbf{Q}_E \in \mathbb{R}^{n \times (n-r)}$$

uma matriz cujas colunas formam uma base ortonormal de

$$\mathcal{C}(\mathbf{M}_Z).$$

Como $\mathbf{M}_Z$ é o projetor ortogonal sobre esse espaço,

$$\mathbf{M}_Z = \mathbf{Q}_E \mathbf{Q}_E^\top.$$

Defina

$$\mathcal{Z}_E = \mathbf{Q}_E^\top \mathcal{E}.$$

Pela transformação da normal matricial,

$$\mathcal{Z}_E \mid \mathbf{Z} \sim N_{(n-r) \times p}(\mathbf{0}, \mathbf{I}_{n-r}, \Sigma).$$

Portanto, suas $n - r$ linhas são vetores independentes com distribuição

$$N_p(\mathbf{0}, \Sigma).$$

Além disso,

$$\begin{aligned}\mathbf{E}_{\text{res}} &= \mathcal{E}^\top \mathbf{Q}_E \mathbf{Q}_E^\top \mathcal{E} \\ &= \mathcal{Z}_E^\top \mathcal{Z}_E.\end{aligned}$$

Pela construção da distribuição de Wishart,

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(n - r, \Sigma).$$

□

A esperança é

$$E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) = (n - r)\Sigma,$$

recuperando Proposição 11.7.

Consequentemente,

$$\widehat{\Sigma} = \frac{\mathbf{E}_{\text{res}}}{n - r}$$

satisfaz

$$(n - r)\widehat{\Sigma} \mid \mathbf{Z} \sim W_p(n - r, \Sigma). \quad (12.41)$$

O posto da SSCP residual é, com probabilidade 1,

$$\text{posto}(\mathbf{E}_{\text{res}}) = \min(p, n - r). \quad (12.42)$$

Assim,

$$\mathbf{E}_{\text{res}} \succ \mathbf{0}$$

com probabilidade 1 se, e somente se,

$$n - r \geq p. \quad (12.43)$$

Essa condição coincide com a discussão de posto realizada no Capítulo 11, agora obtida diretamente da distribuição Wishart.

12.3.4 Independência entre estimação e SSCP residual

A separação entre a estimação da estrutura de médias e a estimação da covariância residual decorre da ortogonalidade das projeções do modelo.

Para uma função estimável,

$$\widehat{\Theta} - \Theta = \mathbf{CZ}^+ \mathcal{E} \mathbf{M}.$$

Os resíduos são

$$\widehat{\mathcal{U}} = \mathbf{M}_Z \mathcal{E}.$$

Como

$$\mathbf{Z}^+ \mathbf{M}_Z = \mathbf{0},$$

as duas transformações possuem covariância cruzada nula.

Proposição 12.11 (Independência entre estimação paramétrica e resíduos). *Sob o modelo linear normal multivariado,*

$$\widehat{\Theta} \perp \widehat{\mathcal{U}} \mid \mathbf{Z}.$$

Consequentemente,

$$\widehat{\Theta} \perp \mathbf{E}_{\text{res}} \mid \mathbf{Z}. \quad (12.44)$$

Comprovação. As duas matrizes são transformações lineares da mesma matriz normal de erros e, portanto, são conjuntamente normais.

A estrutura de covariância cruzada entre as transformações de suas linhas contém o produto

$$\mathbf{CZ}^+ \mathbf{M}_Z.$$

Como

$$\mathbf{Z}^+ \mathbf{M}_Z = \mathbf{0},$$

essa covariância cruzada é nula. Sob normalidade conjunta, segue a independência.

A SSCP residual é uma função da matriz de resíduos, preservando a independência. $\square$

Sob posto coluna completo e

$$\mathbf{C} = \mathbf{I}_q, \quad \mathbf{M} = \mathbf{I}_p,$$

o resultado fornece

$$\widehat{\mathbf{B}} \perp \mathbf{E}_{\text{res}} \mid \mathbf{Z}. \quad (12.45)$$

Esse resultado generaliza a independência entre média e covariância amostrais. No modelo contendo somente intercepto,

$$\widehat{\mathbf{B}} = \bar{\mathbf{X}}^\top$$

e

$$\mathbf{E}_{\text{res}} = (n - 1)\mathbf{S}.$$

Papel da normalidade

A ortogonalidade entre as projeções garante covariância cruzada nula entre as parcelas estimada e residual.

A conclusão de **independência** utiliza adicionalmente a normalidade conjunta. Fora do modelo normal, ortogonalidade das projeções não implica, por si só, independência entre as estatísticas correspondentes.

12.3.5 Distribuição da SSCP da hipótese sob (H_0)

Considere a hipótese linear geral definida no Capítulo 11:

$$H_0 : \mathbf{CBM} = \Theta_0. \quad (12.46)$$

Suponha que

$$\mathbf{C} = \mathbf{CZ}^+\mathbf{Z},$$

$$\text{posto}(\mathbf{C}) = g$$

e

$$\text{posto}(\mathbf{M}) = s.$$

Defina

$$\mathcal{D} = \widehat{\Theta} - \Theta_0. \quad (12.47)$$

Sob H_0 ,

$$\mathcal{D} \mid \mathbf{Z} \sim N_{g \times s}(\mathbf{0}, \mathbf{G}_C, \Sigma_M). \quad (12.48)$$

A SSCP aleatória da hipótese é

$$\mathbf{H} = \mathcal{D}^\top \mathbf{G}_C^{-1} \mathcal{D}. \quad (12.49)$$

Sua realização observada coincide com a SSCP definida em Definição 11.19.

A SSCP residual correspondente às respostas transformadas é

$$\mathbf{E}_M = \mathbf{M}^\top \mathbf{E}_{\text{res}} \mathbf{M}. \quad (12.50)$$

Proposição 12.12 (Distribuições da SSCP da hipótese e da SSCP residual). *Sob o modelo linear normal multivariado e sob*

$$H_0 : \mathbf{CBM} = \Theta_0,$$

tem-se

$$\mathbf{H} \mid \mathbf{Z} \sim W_s(g, \Sigma_M) \quad (12.51)$$

e

$$\mathbf{E}_M \mid \mathbf{Z} \sim W_s(n - r, \Sigma_M). \quad (12.52)$$

Além disso,

$$\mathbf{H} \perp \mathbf{E}_M \mid \mathbf{Z}. \quad (12.53)$$

Comprovação. Sob H_0 ,

$$\mathbf{G}_C^{-1/2} \mathcal{D} \mid \mathbf{Z} \sim N_{g \times s}(\mathbf{0}, \mathbf{I}_g, \Sigma_M).$$

Suas g linhas são independentes e possuem distribuição

$$N_s(\mathbf{0}, \Sigma_M).$$

Como

$$\begin{aligned} \mathbf{H} &= \mathcal{D}^\top \mathbf{G}_C^{-1} \mathcal{D} \\ &= (\mathbf{G}_C^{-1/2} \mathcal{D})^\top (\mathbf{G}_C^{-1/2} \mathcal{D}), \end{aligned}$$

segue da definição da distribuição de Wishart que

$$\mathbf{H} \mid \mathbf{Z} \sim W_s(g, \Sigma_M).$$

Por Proposição 12.6,

$$\begin{aligned} \mathbf{E}_M &= \mathbf{M}^\top \mathbf{E}_{\text{res}} \mathbf{M} \\ &\sim W_s(n - r, \Sigma_M). \end{aligned}$$

Finalmente, $\mathbf{H}$ é função de $\widehat{\Theta}$, enquanto $\mathbf{E}_M$ é função dos resíduos. A independência decorre de Proposição 12.11. $\square$

O resultado central pode ser resumido por

$$\mathbf{H} \mid \mathbf{Z} \sim W_s(g, \Sigma_M),$$

$$\mathbf{E}_M \mid \mathbf{Z} \sim W_s(n - r, \Sigma_M),$$

com

$$\mathbf{H} \perp \mathbf{E}_M \mid \mathbf{Z}. \tag{12.54}$$

As duas matrizes possuem a mesma matriz de escala,

$$\Sigma_M,$$

mas graus de liberdade diferentes:

- g corresponde à dimensão das combinações independentes dos termos do modelo definidas por $\mathbf{C}$;
- $n - r$ corresponde à dimensão do espaço residual.

Como $\mathbf{M}$ possui posto s , a hipótese matricial contém

$$gs$$

restrições escalares independentes. O número

$$g$$

é, entretanto, o grau de liberdade da distribuição Wishart de $\mathbf{H}$, pois a SSCP da hipótese é construída a partir de g vetores aleatórios no espaço das s respostas transformadas.

As propriedades de posto da Wishart fornecem

$$\text{posto}(\mathbf{H}) = \min(g, s)$$

e

$$\text{posto}(\mathbf{E}_M) = \min(n - r, s)$$

com probabilidade 1.

Em particular,

$$\mathbf{E}_M \succ \mathbf{0}$$

com probabilidade 1 se, e somente se,

$$n - r \geq s. \tag{12.55}$$

Sob a hipótese alternativa

Defina

$$\Delta_0 = \mathbf{CBM} - \Theta_0. \quad (12.56)$$

Quando

$$\Delta_0 \neq \mathbf{0},$$

a SSCP

$$\mathbf{H}$$

possui uma distribuição Wishart não central, enquanto

$$\mathbf{E}_M$$

mantém sua distribuição Wishart central e permanece independente de $\mathbf{H}$ (Muirhead, 1982).

Sua esperança é

$$E(\mathbf{H} | \mathbf{Z}) = g\Sigma_M + \Delta_0^\top \mathbf{G}_C^{-1} \Delta_0. \quad (12.57)$$

A segunda parcela mede o afastamento da hipótese nula na escala determinada pelo delineamento. A distribuição não central será necessária quando se estudar poder, mas sua parametrização detalhada não é necessária para os resultados centrais deste capítulo.

As distribuições obtidas nesta seção fornecem a estrutura probabilística geral para hipóteses lineares multivariadas. O passo seguinte é estabelecer como uma hipótese conjunta é transformada em uma regra inferencial, distinguindo testes globais, razão de verossimilhanças e resultados exatos ou assintóticos.

12.4 Princípios da inferência multivariada

Uma hipótese multivariada pode impor simultaneamente várias restrições sobre um vetor, uma matriz ou uma função dos parâmetros. O objetivo de um teste global é avaliar essas restrições como uma única afirmação estatística, considerando a dependência existente entre seus componentes.

No modelo linear multivariado, por exemplo,

$$H_0 : \mathbf{CBM} = \Theta_0$$

pode reunir várias restrições escalares em uma única hipótese matricial. De forma semelhante,

$$H_0 : \mu = \mu_0$$

é uma única hipótese sobre o vetor de médias, ainda que envolva p componentes.

12.4.1 Testes globais e hipóteses simultâneas

Considere uma hipótese vetorial

$$H_0 : \mu = \mu_0.$$

Ela implica as igualdades coordenadas

$$\mu_j = \mu_{0j}, \quad j = 1, \dots, p,$$

mas a realização de p testes marginais separados não é equivalente a um teste global do vetor.

Se cada teste marginal possui nível α e os testes são independentes, a probabilidade de pelo menos uma rejeição incorreta sob a hipótese global é

$$1 - (1 - \alpha)^p. \quad (12.58)$$

Por exemplo, para

$$p = 5$$

e

$$\alpha = 0,05,$$

essa probabilidade é

$$1 - 0,95^5 \approx 0,226.$$

Quando as estatísticas são dependentes, a expressão anterior não se aplica diretamente, mas a conclusão permanece: realizar vários testes marginais no mesmo nível não garante controle do nível global.

Teste global e análise posterior

Um teste global avalia uma hipótese conjunta e utiliza a estrutura de dependência entre seus componentes.

A rejeição da hipótese global não identifica, por si só, quais componentes ou combinações lineares são responsáveis pelo afastamento. Essa investigação exige procedimentos posteriores, como contrastes ou intervalos simultâneos, com controle adequado da multiplicidade.

A distribuição da estatística sob H_0 determina a calibração do teste. Quando a distribuição exata é conhecida, ela deve ser utilizada. Quando somente um resultado limite está disponível, a calibração é assintótica.

Sob alternativas, a distribuição pode envolver parâmetros de não centralidade. Esses parâmetros descrevem o afastamento de H_0 na escala determinada pela variabilidade do problema e são utilizados no estudo do poder. O desenvolvimento detalhado das distribuições não centrais não é necessário para os procedimentos centrais deste capítulo.

12.4.2 Razão de verossimilhanças

A razão de verossimilhanças fornece um princípio geral para comparar o melhor ajuste permitido por uma hipótese nula com o melhor ajuste disponível no modelo irrestrito (Casella; Berger, 2002).

Considere um modelo com parâmetro

$$\vartheta \in \mathcal{P}$$

e uma hipótese

$$H_0 : \vartheta \in \mathcal{P}_0, \quad \mathcal{P}_0 \subseteq \mathcal{P}.$$

Definição 12.3 (Estatística da razão de verossimilhanças). A estatística da razão de verossimilhanças é

$$\Lambda_{\text{RV}} = \frac{\sup_{\vartheta \in \mathcal{P}_0} L(\vartheta; \mathbf{y})}{\sup_{\vartheta \in \mathcal{P}} L(\vartheta; \mathbf{y})}. \quad (12.59)$$

Como

$$\mathcal{P}_0 \subseteq \mathcal{P},$$

tem-se

$$0 \leq \Lambda_{\text{RV}} \leq 1.$$

Valores próximos de 1 indicam que a restrição imposta por H_0 produz pequena redução na verossimilhança máxima. Valores reduzidos indicam maior incompatibilidade entre a hipótese nula e os dados observados.

É conveniente utilizar a transformação

$$-2 \log \Lambda_{\text{RV}}.$$

Quando os máximos são atingidos e

$$\hat{\vartheta}$$

e

$$\tilde{\vartheta}$$

denotam, respectivamente, os estimadores de máxima verossimilhança irrestrito e restrito,

$$-2 \log \Lambda_{\text{RV}} = 2 \left[\ell(\hat{\vartheta}) - \ell(\tilde{\vartheta}) \right], \quad (12.60)$$

em que

$$\ell(\vartheta) = \log L(\vartheta; \mathbf{y}).$$

A estatística é não negativa e cresce à medida que as restrições impostas por H_0 reduzem o máximo da verossimilhança.

A distribuição de

$$-2 \log \Lambda_{\text{RV}}$$

depende do modelo. Em alguns problemas existe uma distribuição exata ou uma transformação para uma distribuição conhecida. Em modelos regulares mais gerais, utiliza-se o resultado assintótico de Wilks.

12.4.3 Resultado assintótico de Wilks

Teorema 12.4 (Resultado assintótico de Wilks). *Considere um modelo paramétrico regular com*

$$\vartheta \in \mathcal{P} \subseteq \mathbb{R}^k.$$

Suponha que:

1. *o modelo seja identificável;*
2. *o parâmetro verdadeiro pertença ao interior do espaço paramétrico;*
3. *a log-verossimilhança possua a regularidade de diferenciação necessária em uma vizinhança do parâmetro verdadeiro;*
4. *a informação de Fisher seja finita e positiva definida;*
5. *a hipótese nula seja definida localmente por d restrições suaves e linearmente independentes;*
6. *a dimensão paramétrica permaneça fixa quando $n \rightarrow \infty$;*
7. *sejam satisfeitas as condições necessárias à consistência e à normalidade assintótica dos estimadores de máxima verossimilhança.*

Então, sob H_0 ,

$$-2 \log \Lambda_{\text{RV}} \xrightarrow{d} \chi_d^2, \quad (12.61)$$

em que

$$d = \dim(\mathcal{P}) - \dim(\mathcal{P}_0)$$

localmente no parâmetro verdadeiro.

O resultado é assintótico (Vaart, 1998). Para uma amostra grande, uma região crítica aproximada de nível α é

$$-2 \log \Lambda_{\text{RV}} > \chi_{d;1-\alpha}^2. \quad (12.62)$$

O correspondente valor- p aproximado é

$$P \left[\chi_d^2 \geq -2 \log \Lambda_{\text{RV,obs}} \right]. \quad (12.63)$$

O número

d

não deve ser obtido simplesmente pela contagem de todas as expressões escritas na hipótese. Ele corresponde ao número de restrições **localmente independentes** ou, equivalentemente em situações regulares, à diferença entre as dimensões dos espaços paramétricos irrestrito e restrito.

Situações não regulares

A aproximação qui-quadrado do Teorema 12.4 não se aplica automaticamente quando:

- o parâmetro verdadeiro está na fronteira do espaço paramétrico;
- o modelo não é identificável;
- há restrições redundantes;
- a informação de Fisher é singular;
- a dimensão do parâmetro cresce com o tamanho amostral;
- outras condições de regularidade necessárias ao resultado deixam de ser satisfeitas.

Nessas situações, a distribuição limite pode ser diferente de uma qui-quadrado convencional.

O teorema de Wilks deve ser distinguido de critérios multivariados específicos que também carregam o nome de Wilks. Aqui o termo refere-se ao resultado assintótico geral da razão de verossimilhanças.

12.4.4 Razão de verossimilhanças em modelos normais encaixados

O princípio da razão de verossimilhanças pode ser aplicado diretamente aos modelos lineares multivariados encaixados construídos no Capítulo 11.

Considere:

- um modelo completo, com matriz de delineamento $\mathbf{Z}_F$ e SSCP residual observada $\mathbf{E}_F$;
- um modelo reduzido, com matriz de delineamento $\mathbf{Z}_R$ e SSCP residual observada $\mathbf{E}_R$;

tais que

$$\mathcal{C}(\mathbf{Z}_R) \subseteq \mathcal{C}(\mathbf{Z}_F).$$

O Capítulo 11 estabeleceu

$$\mathbf{E}_R = \mathbf{H} + \mathbf{E}_F, \quad (12.64)$$

em que

$$\mathbf{H} = \mathbf{Y}^\top (\mathbf{P}_F - \mathbf{P}_R) \mathbf{Y} \succeq \mathbf{0}.$$

Suponha que os dois modelos utilizem a mesma matriz de covariâncias residual desconhecida

$$\Sigma \succ \mathbf{0}$$

e que as SSCPs necessárias sejam positivas definidas.

No modelo normal multivariado, depois da maximização em relação à matriz de parâmetros e à matriz de covariâncias, a verossimilhança maximizada é proporcional a

$$|\mathbf{E}|^{-n/2}.$$

Consequentemente,

Proposição 12.13 (Razão de verossimilhanças em modelos normais encaixados). *Sob as condições anteriores,*

$$\Lambda_{\text{RV}} = \left(\frac{|\mathbf{E}_F|}{|\mathbf{E}_R|} \right)^{n/2}. \quad (12.65)$$

Como

$$\mathbf{E}_R = \mathbf{E}_F + \mathbf{H},$$

também se pode escrever

$$\Lambda_{\text{RV}} = \left[\frac{|\mathbf{E}_F|}{|\mathbf{E}_F + \mathbf{H}|} \right]^{n/2}. \quad (12.66)$$

Como

$$\mathbf{H} \succeq \mathbf{0},$$

a imposição das restrições do modelo reduzido não diminui a SSCP residual na ordem de Loewner:

$$\mathbf{E}_R \succeq \mathbf{E}_F.$$

Quando ambas são positivas definidas,

$$|\mathbf{E}_R| \geq |\mathbf{E}_F|,$$

e, portanto,

$$0 < \Lambda_{RV} \leq 1.$$

A razão de determinantes

$$\frac{|\mathbf{E}_F|}{|\mathbf{E}_F + \mathbf{H}|}$$

resume a alteração da dispersão residual produzida pelas restrições do modelo reduzido. Sua decomposição por raízes características e sua relação com critérios multivariados específicos serão desenvolvidas no Módulo 3.

Existência da forma por determinantes

A expressão em Equação 12.65 exige que as matrizes residuais relevantes sejam positivas definidas.

Sob o modelo normal, uma condição suficiente para

$$\mathbf{E}_F \succ \mathbf{0}$$

com probabilidade 1 é

$$n - r_F \geq p,$$

em que

$$r_F = \text{posto}(\mathbf{Z}_F).$$

Como

$$\mathbf{E}_R = \mathbf{E}_F + \mathbf{H}$$

e

$$\mathbf{H} \succeq \mathbf{0},$$

a definição positiva de $\mathbf{E}_F$ implica a definição positiva de $\mathbf{E}_R$.

Quando a SSCP residual é singular, substituir inversas ou determinantes por pseudoinversas, pseudodeterminantes ou regularização produz outros procedimentos. Essas modificações não recuperam automaticamente a calibração inferencial clássica.

A razão de verossimilhanças fornece uma estrutura geral para comparar modelos sob restrições. Nos problemas seguintes, a inferência sobre o vetor de médias admitirá distribuições exatas mais específicas, conduzindo à distribuição qui-quadrado quando Σ é conhecida e à estatística T^2 de Hotelling quando ela precisa ser estimada.

12.5 Inferência sobre um vetor de médias

Considere uma amostra aleatória

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0}.$$

O objetivo inicial é testar

$$H_0 : \mu = \mu_0$$

contra

$$H_1 : \mu \neq \mu_0,$$

em que

$$\mu_0 \in \mathbb{R}^p$$

é conhecido.

A estrutura do procedimento depende de a matriz de covariâncias populacional ser conhecida ou precisar ser estimada.

12.5.1 Covariância conhecida

Pela Proposição 12.1,

$$\bar{\mathbf{X}} \sim N_p \left(\mu, \frac{\Sigma}{n} \right).$$

Sob H_0 ,

$$\sqrt{n} \Sigma^{-1/2} (\bar{\mathbf{X}} - \mu_0) \sim N_p (\mathbf{0}, \mathbf{I}_p).$$

Definição 12.4 (Estatística para a média com covariância conhecida). Quando Σ é conhecida, define-se

$$Q_\mu = n (\bar{\mathbf{X}} - \mu_0)^\top \Sigma^{-1} (\bar{\mathbf{X}} - \mu_0). \quad (12.67)$$

A estatística é a distância de Mahalanobis quadrática entre a média amostral e o vetor especificado por H_0 , ajustada pela variabilidade da média.

Proposição 12.14 (Distribuição com covariância conhecida). *Sob*

$$H_0 : \mu = \mu_0,$$

tem-se

$$Q_\mu \sim \chi_p^2. \quad (12.68)$$

O resultado é exatamente Equação 12.4 aplicado ao vetor especificado pela hipótese nula.

Assim, um teste de nível α rejeita H_0 quando

$$Q_{\mu, \text{obs}} > \chi_{p; 1-\alpha}^2, \quad (12.69)$$

em que

$$Q_{\mu, \text{obs}} = n (\bar{\mathbf{x}} - \mu_0)^\top \Sigma^{-1} (\bar{\mathbf{x}} - \mu_0). \quad (12.70)$$

O valor- p é

$$P\left(\chi_p^2 \geq Q_{\mu,\text{obs}}\right). \quad (12.71)$$

Sob uma alternativa fixa,

$$\mu \neq \mu_0,$$

a estatística possui distribuição qui-quadrado não central, com parâmetro

$$\lambda_\mu = n\left(\mu - \mu_0\right)^\top \Sigma^{-1}\left(\mu - \mu_0\right). \quad (12.72)$$

Essa expressão mostra que o afastamento relevante é medido na geometria determinada por Σ .

Quando

$$p = 1,$$

obtém-se

$$Q_\mu = \frac{n\left(\bar{X} - \mu_0\right)^2}{\sigma^2},$$

que corresponde ao quadrado da estatística normal padronizada utilizada no teste de uma média com variância conhecida.

12.5.2 Estatística (T^2) de Hotelling

Na maior parte das aplicações,

$$\Sigma$$

é desconhecida. Sua substituição por

$$S$$

altera a distribuição da forma quadrática porque a matriz utilizada na padronização passa a ser aleatória.

A estrutura normal–Wishart obtida anteriormente fornece:

$$\bar{\mathbf{X}} \sim N_p \left(\mu, \frac{\Sigma}{n} \right),$$

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma),$$

e

$$\bar{\mathbf{X}} \perp \mathbf{S}.$$

Definição 12.5 (Estatística (T^2) de Hotelling para uma amostra). A estatística para testar

$$H_0 : \mu = \mu_0$$

quando Σ é desconhecida é

$$T^2 = n \left(\bar{\mathbf{X}} - \mu_0 \right)^\top \mathbf{S}^{-1} \left(\bar{\mathbf{X}} - \mu_0 \right). \quad (12.73)$$

A estatística está definida na forma clássica quando

$$\mathbf{S} \succ \mathbf{0}.$$

Sob normalidade multivariada e

$$\Sigma \succ \mathbf{0},$$

isso ocorre com probabilidade 1 quando

$$n > p. \quad (12.74)$$

O fator n aparece porque a matriz de covariâncias da média é

$$\frac{\Sigma}{n}.$$

Assim, T^2 mede o afastamento da média amostral em relação a μ_0 na escala de sua incerteza amostral.

Proposição 12.15 (Distribuição exata de T^2). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0}$$

e

$$n > p,$$

então, sob

$$H_0 : \mu = \mu_0,$$

vale

$$\frac{n-p}{p(n-1)} T^2 \sim F_{p, n-p}. \quad (12.75)$$

Esse resultado utiliza conjuntamente a distribuição normal da média, a distribuição Wishart da covariância amostral e a independência entre esses dois objetos (Anderson, 2003; Rencher; Christensen, 2012).

Após a observação,

$$T_{\text{obs}}^2 = n (\bar{\mathbf{x}} - \mu_0)^\top \mathbf{S}^{-1} (\bar{\mathbf{x}} - \mu_0). \quad (12.76)$$

Defina

$$F_{\text{obs}} = \frac{n-p}{p(n-1)} T_{\text{obs}}^2. \quad (12.77)$$

Um teste de nível α rejeita H_0 quando

$$T_{\text{obs}}^2 > \frac{p(n-1)}{n-p} F_{p, n-p; 1-\alpha}, \quad (12.78)$$

ou, equivalentemente, quando

$$F_{\text{obs}} > F_{p,n-p;1-\alpha}.$$

O valor- p é

$$P(F_{p,n-p} \geq F_{\text{obs}}). \quad (12.79)$$

A rejeição informa que o vetor populacional não coincide com μ_0 . Ela não identifica, isoladamente, quais componentes ou combinações lineares são responsáveis pelo afastamento.

Sob uma alternativa fixa, a distribuição correspondente é uma F não central, com parâmetro

$$\lambda_\mu = n(\mu - \mu_0)^\top \Sigma^{-1}(\mu - \mu_0).$$

A não centralidade é útil para estudos de poder, mas não será desenvolvida adicionalmente neste capítulo.

12.5.3 Relações com os casos assintótico e univariado

Quando p permanece fixo e

$$n \longrightarrow \infty,$$

a consistência de $\mathbf{S}$ implica, sob H_0 ,

$$T^2 \xrightarrow{d} \chi_p^2. \quad (12.80)$$

Portanto, a distribuição qui-quadrado fornece uma aproximação assintótica. Sob normalidade e em amostras finitas, a distribuição F em Equação 12.75 é o resultado exato.

Quando

$$p = 1,$$

a matriz de covariâncias amostral reduz-se à variância amostral S . Assim,

$$T^2 = \frac{n(\bar{X} - \mu_0)^2}{S} = t^2, \quad (12.81)$$

em que

$$t = \frac{\sqrt{n}(\bar{X} - \mu_0)}{\sqrt{S}} \sim t_{n-1}$$

sob H_0 .

Assim, o teste T^2 de uma amostra é a extensão multivariada do teste t de Student.

A estatística também é invariante a transformações afins com parte linear não singular. Essa propriedade decorre da invariância da distância de Mahalanobis e garante que mudanças invertíveis de unidade ou de coordenadas não alterem o valor de T^2 .

12.5.4 Região de confiança elipsoidal

A inversão do teste T^2 produz uma região de confiança simultânea para todo o vetor

$$\mu.$$

Defina

$$c_{\alpha,p,n} = \frac{p(n-1)}{n-p} F_{p,n-p;1-\alpha}. \quad (12.82)$$

Proposição 12.16 (Região de confiança para o vetor de médias). *Sob as condições da Proposição 12.15,*

$$\mathcal{C}_{1-\alpha} = \left\{ \theta \in \mathbb{R}^p : n(\bar{\mathbf{X}} - \theta)^\top \mathbf{S}^{-1} (\bar{\mathbf{X}} - \theta) \leq c_{\alpha,p,n} \right\} \quad (12.83)$$

possui cobertura

$$P(\mu \in \mathcal{C}_{1-\alpha}) = 1 - \alpha. \quad (12.84)$$

Após a observação,

$$\mathcal{C}_{1-\alpha} = \left\{ \theta \in \mathbb{R}^p : (\theta - \bar{\mathbf{x}})^\top \mathbf{S}^{-1} (\theta - \bar{\mathbf{x}}) \leq \frac{c_{\alpha,p,n}}{n} \right\}. \quad (12.85)$$

A dualidade entre teste e região de confiança fornece

$$\mu_0 \in \mathcal{C}_{1-\alpha} \iff T_{\text{obs}}^2(\mu_0) \leq c_{\alpha,p,n}. \quad (12.86)$$

12.5.5 Geometria da região

A região observada é um elipsoide centrado em

$$\bar{\mathbf{x}}.$$

Considere a decomposição espectral

$$\mathbf{S} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^\top,$$

com

$$\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_p).$$

Em coordenadas espectrais, sua fronteira é

$$\sum_{j=1}^p \frac{z_j^2}{c_{\alpha,p,n} \lambda_j / n} = 1. \quad (12.87)$$

Consequentemente, os eixos do elipsoide são os autovetores de $\mathbf{S}$ e o comprimento do j -ésimo semieixo é

$$a_j = \sqrt{\frac{c_{\alpha,p,n} \lambda_j}{n}}. \quad (12.88)$$

Essa geometria é a mesma estrutura elipsoidal discutida nos Capítulos 8 e 9, agora aplicada à incerteza inferencial sobre o vetor de médias.

A Figura 12.1 mostra, no caso bidimensional, como a covariância altera a orientação da região de confiança.

Na primeira configuração da Figura 12.1, os eixos permanecem alinhados às coordenadas originais. Na segunda, a covariância positiva produz rotação do elipsoide. A região reflete, portanto, tanto as variâncias marginais quanto a dependência entre as componentes.

Interpretação da cobertura

Antes da observação dos dados,

$$\mathcal{C}_{1-\alpha}$$

é uma região aleatória que contém o verdadeiro vetor μ com probabilidade $1 - \alpha$.

Depois da observação, a região está fixada. Na interpretação frequentista, o parâmetro




Figura 12.1: Efeito da matriz de covariâncias sobre a forma e a orientação da região de confiança para o vetor de médias.

não passa a ser aleatório; a cobertura refere-se ao comportamento do procedimento em repetições amostrais.

12.5.6 Intervalos simultâneos

A região elipsoidal permite obter inferência simultânea para qualquer combinação linear

$$\mathbf{a}^\top \boldsymbol{\mu}.$$

Proposição 12.17 (Intervalos simultâneos de Hotelling). *Sob as condições da Proposição 12.15, os intervalos*

$$\mathbf{a}^\top \bar{\mathbf{X}} \pm \sqrt{\frac{c_{\alpha,p,n}}{n}} \mathbf{a}^\top \mathbf{S} \mathbf{a}, \quad \mathbf{a} \in \mathbb{R}^p, \quad (12.89)$$

possuem cobertura simultânea $1 - \alpha$ para todas as combinações lineares.

Comprovação. Se

$$\mu \in \mathcal{C}_{1-\alpha},$$

então

$$(\mu - \bar{\mathbf{X}})^\top \mathbf{S}^{-1} (\mu - \bar{\mathbf{X}}) \leq \frac{c_{\alpha,p,n}}{n}.$$

Pela desigualdade de Cauchy–Schwarz na geometria induzida por $\mathbf{S}$,

$$|\mathbf{a}^\top (\mu - \bar{\mathbf{X}})| \leq \sqrt{\mathbf{a}^\top \mathbf{S} \mathbf{a}} \sqrt{(\mu - \bar{\mathbf{X}})^\top \mathbf{S}^{-1} (\mu - \bar{\mathbf{X}})}.$$

Substituindo o limite da região, obtém-se Equação 12.89 simultaneamente para todas as direções $\mathbf{a}$. $\square$

Após a observação dos dados,

$$\mathbf{a}^\top \mu \in \mathbf{a}^\top \bar{\mathbf{x}} \pm \sqrt{\frac{c_{\alpha,p,n}}{n} \mathbf{a}^\top \mathbf{S} \mathbf{a}}. \quad (12.90)$$

Para

$$\mathbf{a} = \mathbf{e}_j,$$

obtém-se o intervalo simultâneo para uma componente:

$$\mu_j \in \bar{x}_j \pm \sqrt{\frac{c_{\alpha,p,n} S_{jj}}{n}}. \quad (12.91)$$

Para

$$\mathbf{a} = \mathbf{e}_j - \mathbf{e}_k,$$

obtém-se

$$\mu_j - \mu_k \in \bar{x}_j - \bar{x}_k \pm \sqrt{\frac{c_{\alpha,p,n}}{n} (S_{jj} + S_{kk} - 2S_{jk})}. \quad (12.92)$$

Os intervalos de Hotelling protegem simultaneamente todas as combinações lineares. Quando somente um conjunto finito e previamente definido de combinações é de interesse, procedimentos de multiplicidade específicos, como Bonferroni, podem fornecer alternativas menos conservadoras em determinados problemas.

12.5.7 Hipóteses lineares sobre o vetor de médias

A hipótese

$$H_0 : \mu = \mu_0$$

especifica todo o vetor de médias. Em outros problemas, o interesse está restrito a determinadas combinações lineares.

Considere

$$\mathbf{A} \in \mathbb{R}^{h \times p},$$

com

$$\text{posto}(\mathbf{A}) = h \leq p,$$

e

$$\mathbf{d} \in \mathbb{R}^h.$$

A hipótese é

$$H_0 : \mathbf{A}\mu = \mathbf{d}. \quad (12.93)$$

Cada linha de $\mathbf{A}$ define uma restrição linear. A condição de posto linha completo elimina restrições redundantes.

Defina

$$\mathbf{U}_i = \mathbf{A}\mathbf{X}_i.$$

Então

$$\mathbf{U}_i \sim N_h(\mathbf{A}\mu, \mathbf{A}\Sigma\mathbf{A}^\top). \quad (12.94)$$

Como $\mathbf{A}$ possui posto linha completo e

$$\Sigma \succ \mathbf{0},$$

tem-se

$$\mathbf{A}\Sigma\mathbf{A}^\top \succ \mathbf{0}.$$

A média e a covariância amostrais transformadas são

$$\bar{\mathbf{U}} = \mathbf{A}\bar{\mathbf{X}}$$

e

$$\mathbf{S}_U = \mathbf{A}\mathbf{S}\mathbf{A}^\top.$$

Assim, o problema reduz-se exatamente à inferência sobre um vetor de médias de dimensão h .

12.5.7.1 Covariância conhecida

Quando Σ é conhecida, defina

$$Q_A = n(\mathbf{A}\bar{\mathbf{X}} - \mathbf{d})^\top (\mathbf{A}\Sigma\mathbf{A}^\top)^{-1} (\mathbf{A}\bar{\mathbf{X}} - \mathbf{d}). \quad (12.95)$$

Sob H_0 ,

$$Q_A \sim \chi_h^2. \quad (12.96)$$

Portanto, o problema de dimensão p é reduzido às h combinações lineares efetivamente presentes na hipótese.

12.5.7.2 Covariância desconhecida

Quando Σ é desconhecida, define-se

$$T_A^2 = n(\mathbf{A}\bar{\mathbf{X}} - \mathbf{d})^\top (\mathbf{A}\mathbf{S}\mathbf{A}^\top)^{-1} (\mathbf{A}\bar{\mathbf{X}} - \mathbf{d}). \quad (12.97)$$

Sob normalidade,

$$\mathbf{A}\mathbf{S}\mathbf{A}^\top \succ \mathbf{0}$$

com probabilidade 1 quando

$$n > h. \quad (12.98)$$

Proposição 12.18 (Distribuição para hipóteses lineares sobre a média). *Sob*

$$H_0 : \mathbf{A}\mu = \mathbf{d},$$

e sob as condições anteriores,

$$\frac{n-h}{h(n-1)} \mathbf{T}_A^2 \sim F_{h,n-h}. \quad (12.99)$$

O resultado decorre diretamente da Proposição 12.15 aplicada aos vetores transformados

$$\mathbf{U}_i = \mathbf{A}\mathbf{X}_i.$$

Assim, um teste de nível α rejeita H_0 quando

$$\mathbf{T}_{A,\text{obs}}^2 > \frac{h(n-1)}{n-h} F_{h,n-h;1-\alpha}, \quad (12.100)$$

em que

$$\mathbf{T}_{A,\text{obs}}^2 = n (\mathbf{A}\bar{\mathbf{x}} - \mathbf{d})^\top (\mathbf{A}\mathbf{S}\mathbf{A}^\top)^{-1} (\mathbf{A}\bar{\mathbf{x}} - \mathbf{d}). \quad (12.101)$$

Uma consequência importante é que a condição dimensional depende de

$$h,$$

e não necessariamente de p .

Assim, mesmo quando

$$p \geq n$$

e a matriz completa

$$\mathbf{S}$$

é singular, uma hipótese de dimensão reduzida ainda pode admitir a inferência clássica se

$$n > h$$

e

$$\mathbf{A}\mathbf{S}\mathbf{A}^\top$$

for não singular.

Quando

$$h = 1,$$

com

$$\mathbf{A} = \mathbf{a}^\top,$$

a hipótese

$$H_0 : \mathbf{a}^\top \mu = d$$

reduz-se ao teste t univariado aplicado à combinação linear

$$\mathbf{a}^\top \mathbf{X}.$$

Quando

$$h = p, \quad \mathbf{A} = \mathbf{I}_p, \quad \mathbf{d} = \mu_0,$$

recupera-se o teste T^2 para o vetor completo de médias.

12.5.8 Relação com o modelo linear multivariado

O modelo de uma única população pode ser escrito como

$$y = \mathbf{1}_n \mu^\top + \mathcal{E}.$$

Nesse caso,

$$\mathbf{Z} = \mathbf{1}_n$$

e

$$\mathbf{B} = \mu^\top.$$

Na hipótese geral do Capítulo 11,

$$H_0 : \mathbf{CBM} = \Theta_0,$$

tome

$$\mathbf{C} = [1], \quad \mathbf{M} = \mathbf{A}^\top$$

e

$$\Theta_0 = \mathbf{d}^\top.$$

Então,

$$\mathbf{CBM} = \mu^\top \mathbf{A}^\top = (\mathbf{A}\mu)^\top.$$

Logo,

$$H_0 : \mathbf{A}\mu = \mathbf{d}$$

é um caso particular da hipótese linear multivariada geral desenvolvida no Capítulo 11.

Essa relação mostra que o teste T^2 , as hipóteses sobre combinações lineares e a inferência do modelo linear multivariado pertencem à mesma estrutura. A próxima seção aplica essa construção à comparação entre os vetores de médias de duas populações.

12.6 Comparação entre dois vetores de médias

A comparação entre duas populações depende da relação entre as unidades observadas. Duas estruturas são particularmente importantes:

- **amostras independentes**, formadas por unidades distintas;
- **observações pareadas**, nas quais cada par fornece duas medições relacionadas.

Nos dois casos, o parâmetro de interesse pode ser escrito como uma diferença entre vetores de médias, mas a estrutura de variabilidade é diferente. Por isso, o procedimento inferencial deve ser determinado pelo delineamento amostral.

12.6.1 Duas amostras independentes

Considere duas amostras mutuamente independentes:

$$\mathbf{X}_{11}, \dots, \mathbf{X}_{1n_1} \stackrel{\text{iid}}{\sim} N_p(\mu_1, \Sigma)$$

e

$$\mathbf{X}_{21}, \dots, \mathbf{X}_{2n_2} \stackrel{\text{iid}}{\sim} N_p(\mu_2, \Sigma),$$

com

$$\Sigma \succ \mathbf{0}.$$

A especificação de uma mesma matriz

$$\Sigma$$

para as duas populações é parte do modelo utilizado pelo procedimento clássico com covariância agrupada.

O parâmetro de interesse é

$$\delta = \mu_1 - \mu_2 \in \mathbb{R}^p. \quad (12.102)$$

Considere a hipótese

$$H_0 : \mu_1 - \mu_2 = \delta_0 \quad (12.103)$$

contra

$$H_1 : \mu_1 - \mu_2 \neq \delta_0.$$

A igualdade dos vetores de médias corresponde ao caso

$$\delta_0 = \mathbf{0}.$$

12.6.1.1 Distribuição da diferença entre as médias

As médias amostrais satisfazem

$$\bar{\mathbf{X}}_1 \sim N_p \left(\mu_1, \frac{\Sigma}{n_1} \right)$$

e

$$\bar{\mathbf{X}}_2 \sim N_p \left(\mu_2, \frac{\Sigma}{n_2} \right).$$

Como as amostras são independentes,

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 \sim N_p \left[\mu_1 - \mu_2, \left(\frac{1}{n_1} + \frac{1}{n_2} \right) \Sigma \right]. \quad (12.104)$$

Defina

$$n_{\text{ef}} = \left(\frac{1}{n_1} + \frac{1}{n_2} \right)^{-1} = \frac{n_1 n_2}{n_1 + n_2}. \quad (12.105)$$

Então,

$$\text{Cov}(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2) = \frac{\Sigma}{n_{\text{ef}}}.$$

O número n_{ef} funciona como fator de escala da variabilidade da diferença entre as médias. Ele não representa o número de observações nem os graus de liberdade do procedimento.

12.6.1.2 Covariância agrupada

Como Σ é desconhecida, combine as duas matrizes de covariâncias amostrais por

$$\mathbf{S}_p = \frac{(n_1 - 1)\mathbf{S}_1 + (n_2 - 1)\mathbf{S}_2}{n_1 + n_2 - 2}. \quad (12.106)$$

Após a observação,

$$\mathbf{S}_p = \frac{(n_1 - 1)\mathbf{S}_1 + (n_2 - 1)\mathbf{S}_2}{n_1 + n_2 - 2}. \quad (12.107)$$

A construção é apropriada porque, sob o modelo de covariância comum,

$$(n_h - 1)\mathbf{S}_h \sim W_p(n_h - 1, \Sigma), \quad h = 1, 2.$$

Como as amostras são independentes, as duas SSCPs também são independentes.

Proposição 12.19 (Distribuição da covariância agrupada). *Sob normalidade, independência entre as amostras e*

$$\Sigma_1 = \Sigma_2 = \Sigma,$$

tem-se

$$(n_1 + n_2 - 2)\mathbf{S}_p \sim W_p(n_1 + n_2 - 2, \Sigma). \quad (12.108)$$

Além disso,

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 \perp \mathbf{S}_p. \quad (12.109)$$

Comprovação. Pela aditividade da distribuição de Wishart,

$$\begin{aligned} & (n_1 - 1)\mathbf{S}_1 + (n_2 - 1)\mathbf{S}_2 \\ & \sim W_p(n_1 + n_2 - 2, \Sigma). \end{aligned}$$

A matriz no lado esquerdo é

$$(n_1 + n_2 - 2)\mathbf{S}_p.$$

Sob normalidade, em cada amostra a média é independente da respectiva matriz de covariâncias. A independência entre as duas amostras implica então a independência entre

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2$$

e

$$\mathbf{S}_p.$$

□

A esperança é

$$E(\mathbf{S}_p) = \Sigma.$$

Além disso,

$$\text{posto}(\mathbf{S}_p) = \min(p, n_1 + n_2 - 2)$$

com probabilidade 1. Portanto,

$$\mathbf{S}_p \succ \mathbf{0}$$

com probabilidade 1 quando

$$n_1 + n_2 - 2 \geq p. \quad (12.110)$$

12.6.1.3 Estatística (T^2) para duas amostras

Definição 12.6 (Estatística (T^2) para duas amostras independentes). Para testar

$$H_0 : \mu_1 - \mu_2 = \delta_0,$$

define-se

$$T_{\text{ind}}^2 = n_{\text{ef}} \left(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \delta_0 \right)^\top \mathbf{S}_p^{-1} \left(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \delta_0 \right), \quad (12.111)$$

em que

$$n_{\text{ef}} = \frac{n_1 n_2}{n_1 + n_2}.$$

A estatística possui a mesma estrutura de distância de Mahalanobis observada no T^2 de uma amostra, agora aplicada à diferença entre duas médias independentes.

Proposição 12.20 (Distribuição exata de (T^2) para duas amostras). *Sob o modelo normal com covariância comum e*

$$n_1 + n_2 - 2 \geq p,$$

tem-se, sob H_0 ,

$$\frac{n_1 + n_2 - p - 1}{p(n_1 + n_2 - 2)} T_{\text{ind}}^2 \sim F_{p, n_1 + n_2 - p - 1}. \quad (12.112)$$

Comprovação. Sob H_0 , defina

$$\mathbf{Z} = \sqrt{n_{\text{ef}}} (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \delta_0).$$

Então

$$\mathbf{Z} \sim N_p(\mathbf{0}, \Sigma).$$

Defina também

$$\mathbf{W} = (n_1 + n_2 - 2) \mathbf{S}_p.$$

Pela Proposição [12.19](#),

$$\mathbf{W} \sim W_p(n_1 + n_2 - 2, \Sigma)$$

e

$$\mathbf{Z} \perp \mathbf{W}.$$

A forma quadrática normal–Wishart correspondente fornece

$$\frac{n_1 + n_2 - p - 1}{p(n_1 + n_2 - 2)} \mathbf{T}_{\text{ind}}^2 \sim F_{p, n_1 + n_2 - p - 1}.$$

□

Para os dados observados,

$$\mathbf{T}_{\text{ind,obs}}^2 = n_{\text{ef}} \begin{pmatrix} \bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - \delta_0 \end{pmatrix}^\top \mathbf{S}_p^{-1} \begin{pmatrix} \bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - \delta_0 \end{pmatrix}. \quad (12.113)$$

Um teste de nível α rejeita H_0 quando

$$\mathbf{T}_{\text{ind,obs}}^2 > \frac{p(n_1 + n_2 - 2)}{n_1 + n_2 - p - 1} F_{p, n_1 + n_2 - p - 1; 1 - \alpha}. \quad (12.114)$$

Quando

$$p = 1,$$

o procedimento reduz-se ao quadrado do teste t para duas amostras independentes com variâncias populacionais iguais:

$$\mathbf{T}_{\text{ind}}^2 = \mathbf{t}_{\text{pooled}}^2. \quad (12.115)$$

12.6.2 Covariâncias populacionais distintas

O procedimento anterior foi construído sob

$$\Sigma_1 = \Sigma_2.$$

Se

$$\Sigma_1 \neq \Sigma_2,$$

a diferença entre as médias continua tendo, sob normalidade,

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 \sim N_p \left(\mu_1 - \mu_2, \frac{\Sigma_1}{n_1} + \frac{\Sigma_2}{n_2} \right). \quad (12.116)$$

Entretanto, a matriz agrupada satisfaz

$$E(\mathbf{S}_p) = \frac{(n_1 - 1)\Sigma_1 + (n_2 - 1)\Sigma_2}{n_1 + n_2 - 2},$$

e não estima diretamente

$$\frac{\Sigma_1}{n_1} + \frac{\Sigma_2}{n_2}.$$

Consequentemente, a distribuição F da Proposição 12.20 deixa de ser o resultado exato correspondente.

Papel da homogeneidade das covariâncias

A igualdade

$$\Sigma_1 = \Sigma_2$$

não é necessária para o T^2 de uma amostra nem para o procedimento pareado.

Ela é uma hipótese específica do procedimento de duas amostras independentes que utiliza a covariância agrupada.

Quando as covariâncias populacionais são distintas, o problema inferencial é diferente e requer outro procedimento ou outra aproximação. A simples substituição de $\mathbf{S}_p$ por uma matriz alternativa não preserva automaticamente a distribuição F clássica.

12.6.3 Observações pareadas

No delineamento pareado, considere

$$(\mathbf{X}_i, \mathbf{Y}_i), \quad i = 1, \dots, n,$$

em que os pares são independentes entre si, mas as duas medições dentro de cada par podem ser dependentes.

O número

$$n$$

representa o número de pares completos.

Defina

$$\mathbf{D}_i = \mathbf{X}_i - \mathbf{Y}_i. \quad (12.117)$$

O vetor médio das diferenças é

$$\delta = E(\mathbf{D}_i) = \mu_X - \mu_Y. \quad (12.118)$$

Sua matriz de covariâncias é

$$\Sigma_D = \Sigma_X + \Sigma_Y - \Sigma_{XY} - \Sigma_{YX}. \quad (12.119)$$

A expressão mostra por que a associação dentro dos pares deve ser preservada: ela participa diretamente da variabilidade das diferenças.

A hipótese é

$$H_0 : \delta = \delta_0. \quad (12.120)$$

Para comparar diretamente as duas condições,

$$\delta_0 = \mathbf{0}.$$

O ponto central é que o problema pareado se transforma em um problema de **uma amostra**:

$$\mathbf{D}_1, \dots, \mathbf{D}_n.$$

Suponha

$$\mathbf{D}_1, \dots, \mathbf{D}_n \stackrel{\text{iid}}{\sim} N_p(\delta, \Sigma_D),$$

com

$$\Sigma_D \succ \mathbf{0}.$$

A média amostral das diferenças é

$$\bar{\mathbf{D}} = \frac{1}{n} \sum_{i=1}^n \mathbf{D}_i = \bar{\mathbf{X}} - \bar{\mathbf{Y}}. \quad (12.121)$$

A matriz de covariâncias amostral é

$$\mathbf{S}_D = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{D}_i - \bar{\mathbf{D}}) (\mathbf{D}_i - \bar{\mathbf{D}})^\top. \quad (12.122)$$

Quando as matrizes são calculadas sobre os mesmos pares completos,

$$\mathbf{S}_D = \mathbf{S}_X + \mathbf{S}_Y - \mathbf{S}_{XY} - \mathbf{S}_{YX}. \quad (12.123)$$

Essa identidade conecta diretamente o procedimento pareado às covariâncias cruzadas desenvolvidas no Capítulo 10.

Definição 12.7 (Estatística (T^2) para observações pareadas). Define-se

$$T_{\text{par}}^2 = n (\bar{\mathbf{D}} - \delta_0)^\top \mathbf{S}_D^{-1} (\bar{\mathbf{D}} - \delta_0). \quad (12.124)$$

Proposição 12.21 (Distribuição exata de (T^2) para observações pareadas). Se

$$\mathbf{D}_1, \dots, \mathbf{D}_n \stackrel{\text{iid}}{\sim} N_p(\delta, \Sigma_D),$$

com

$$\Sigma_D \succ \mathbf{0}$$

e

$$n > p,$$

então, sob

$$H_0 : \delta = \delta_0,$$

tem-se

$$\frac{n-p}{p(n-1)} T_{\text{par}}^2 \sim F_{p, n-p}. \quad (12.125)$$

A proposição decorre diretamente da Proposição 12.15 aplicada aos vetores de diferenças. Não é necessária uma nova distribuição amostral.

Para os dados observados,

$$\mathbf{T}_{\text{par,obs}}^2 = n (\bar{\mathbf{d}} - \delta_0)^\top \mathbf{S}_D^{-1} (\bar{\mathbf{d}} - \delta_0). \quad (12.126)$$

Um teste de nível α rejeita H_0 quando

$$\mathbf{T}_{\text{par,obs}}^2 > \frac{p(n-1)}{n-p} F_{p,n-p;1-\alpha}. \quad (12.127)$$

Quando

$$p = 1,$$

recupera-se o quadrado do teste t pareado:

$$\mathbf{T}_{\text{par}}^2 = t_{\text{par}}^2. \quad (12.128)$$

Preservação do pareamento

O procedimento deve ser aplicado às diferenças construídas com a correspondência correta entre as unidades.

Tratar as duas condições como amostras independentes elimina da análise a covariância intrapar e utiliza uma estrutura de variabilidade diferente daquela determinada pelo delineamento.

A normalidade necessária ao resultado exato refere-se à distribuição dos vetores

$$\mathbf{D}_i,$$

e não exige, separadamente, que cada uma das duas condições possua distribuição marginal normal multivariada.

A Tabela 12.1 resume a diferença entre os dois delineamentos.

Tabela 12.1: Comparação entre o $(\hat{T}^2)$ para amostras independentes e para observações pareadas.

Característica	Amostras independentes	Observações pareadas
unidade básica	observações distintas	par de medições relacionadas
parâmetro	$\mu_1 - \mu_2$	$E(\mathbf{D})$

Característica	Amostras independentes	Observações pareadas
covariância utilizada	covariância comum agrupada	covariância das diferenças
informação de dependência entre condições	inexistente pelo delineamento	incorporada em Σ_D
graus de liberdade da matriz de covariâncias	$n_1 + n_2 - 2$	$n - 1$
condição clássica de inversão	$n_1 + n_2 - 2 \geq p$	$n > p$
redução univariada	teste t com variâncias iguais	teste t pareado

Os dois procedimentos utilizam a mesma lógica inferencial, mas estimam estruturas de variabilidade distintas. Essa diferença será retomada na seção seguinte ao organizar as condições necessárias à inferência multivariada clássica.

12.7 Condições e limites da inferência clássica

Os resultados desenvolvidos neste capítulo dependem da estrutura probabilística da amostra, das hipóteses específicas de cada procedimento e do posto das matrizes envolvidas. Essas condições não são intercambiáveis: uma hipótese necessária para um procedimento pode ser irrelevante para outro.

Quatro aspectos organizam a validade da inferência clássica:

1. independência entre as unidades amostrais na estrutura especificada pelo delineamento;
2. normalidade multivariada quando se utilizam distribuições exatas normal–Wishart;
3. covariância comum nos procedimentos que a pressupõem;
4. posto suficiente das matrizes utilizadas nas formas quadráticas, inversas e determinantes.

12.7.1 Independência, normalidade e covariância comum

12.7.1.1 Independência

Nos resultados para uma amostra,

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

são consideradas independentes.

Para duas amostras independentes, exige-se também independência entre as duas amostras. No delineamento pareado, admite-se dependência entre as duas medições de um mesmo par, mas os pares devem ser independentes entre si.

No modelo linear multivariado clássico,

$$\text{Cov} [\text{vec} (\mathcal{E}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n$$

expressa a ausência de covariância residual entre unidades distintas.

A independência é determinada principalmente pelo processo de amostragem e pelo delineamento do estudo. Se existe dependência entre unidades e ela não é incorporada ao modelo, expressões como

$$\text{Cov} (\bar{\mathbf{X}}) = \frac{\Sigma}{n}$$

podem deixar de representar a variabilidade efetiva da média amostral.

Consequentemente, estatísticas construídas com essa estrutura podem apresentar níveis de significância e coberturas diferentes dos valores nominais.

Independência e delineamento

A independência não é estabelecida por um teste aplicado aos valores observados. Ela deve ser avaliada a partir da forma como as unidades foram selecionadas, agrupadas e mensuradas.

Dependência espacial, temporal, hierárquica ou decorrente de medidas repetidas exige uma estrutura probabilística compatível com o delineamento.

12.7.1.2 Normalidade multivariada

A normalidade multivariada sustenta os principais resultados exatos deste capítulo. Entre eles,

$$\bar{\mathbf{X}} \sim N_p \left(\mu, \frac{\Sigma}{n} \right),$$

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma)$$

e

$$\bar{\mathbf{X}} \perp \mathbf{S}.$$

Esses resultados produzem a distribuição exata

$$\frac{n-p}{p(n-1)} \mathbf{T}^2 \sim F_{p, n-p}.$$

No modelo linear multivariado, a normalidade matricial sustenta

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(n-r, \Sigma)$$

e a independência entre funções estimáveis dos parâmetros e a SSCP residual, conforme Proposição 12.11.

Sem normalidade, propriedades como

$$E(\bar{\mathbf{X}}) = \mu$$

e

$$E(\mathbf{S}) = \Sigma$$

podem continuar válidas sob condições de momentos adequadas, mas a distribuição Wishart e as independências utilizadas nas distribuições exatas deixam de ser garantidas.

No regime clássico de dimensão fixa definido em Equação 12.1, se as observações são i.i.d., possuem vetor de médias μ , matriz de covariâncias finita

$$\Sigma \succ \mathbf{0}$$

e

$$\mathbf{S} \xrightarrow{p} \Sigma,$$

o TCL multivariado e o teorema de Slutsky fornecem, sob

$$H_0 : \mu = \mu_0,$$

a convergência

$$\mathbf{T}^2 \xrightarrow{d} \chi_p^2. \tag{12.129}$$

Esse resultado é assintótico. Ele não implica

$$\frac{n-p}{p(n-1)} T^2 \sim F_{p, n-p}$$

em amostras finitas fora do modelo normal.

Exato e assintótico

A normalidade não é necessária para definir a média, a covariância, a SSCP ou a estatística de Mahalanobis.

Ela é utilizada aqui para obter distribuições amostrais **exatas**. Fora desse modelo, a validade de uma aproximação depende das condições assintóticas correspondentes e do tamanho amostral disponível.

12.7.1.3 Covariância comum

A hipótese

$$\Sigma_1 = \Sigma_2$$

não pertence a todos os procedimentos multivariados.

Ela foi utilizada especificamente no teste de duas amostras independentes com covariância agrupada, pois permite obter

$$(n_1 + n_2 - 2) \mathbf{S}_p \sim W_p(n_1 + n_2 - 2, \Sigma).$$

Quando

$$\Sigma_1 \neq \Sigma_2,$$

a covariância da diferença entre as médias é a apresentada em Equação [12.116](#),

$$\frac{\Sigma_1}{n_1} + \frac{\Sigma_2}{n_2},$$

e a matriz agrupada não conduz à distribuição F exata da Proposição [12.20](#).

No procedimento pareado, essa hipótese não é necessária. A matriz relevante é

$$\Sigma_D = \text{Cov}(\mathbf{X}_i - \mathbf{Y}_i).$$

No modelo linear multivariado clássico, a estrutura

$$\text{Cov}(\varepsilon_i | \mathbf{Z}) = \Sigma$$

supõe uma matriz residual comum às unidades representadas pelo modelo.

Assim, a homogeneidade deve ser entendida como uma hipótese do **procedimento que utiliza uma matriz de covariâncias comum**, e não como uma condição universal da inferência multivariada.

12.7.2 Posto, dimensão e tamanho amostral

As formas clássicas das estatísticas utilizam matrizes inversas. A condição necessária depende da dimensão efetivamente utilizada em cada problema.

12.7.2.1 Uma amostra

Sob normalidade não singular,

$$\text{posto}(\mathbf{S}) = \min(p, n - 1)$$

com probabilidade 1.

Portanto,

$$\mathbf{S}^{-1}$$

existe com probabilidade 1 se, e somente se,

$$n > p.$$

Essa é também a condição que torna positivo o segundo grau de liberdade

$$n - p$$

da distribuição

$$F_{p, n-p}.$$

12.7.2.2 Hipóteses de dimensão reduzida

Para

$$H_0 : \mathbf{A}\mu = \mathbf{d},$$

com

$$\text{posto}(\mathbf{A}) = h,$$

a matriz relevante é

$$\mathbf{A}\mathbf{S}\mathbf{A}^\top.$$

A condição clássica passa a ser

$$n > h.$$

Portanto, a singularidade da matriz completa $\mathbf{S}$ não impede necessariamente a inferência sobre combinações previamente especificadas de dimensão menor.

12.7.2.3 Duas amostras independentes

Sob normalidade e covariância comum,

$$\text{posto}(\mathbf{S}_p) = \min(p, n_1 + n_2 - 2)$$

com probabilidade 1.

A inversão clássica requer

$$n_1 + n_2 - 2 \geq p.$$

Sob essa condição,

$$n_1 + n_2 - p - 1 > 0,$$

como necessário para a distribuição F da Proposição [12.20](#).

12.7.2.4 Modelo linear multivariado

Se

$$r = \text{posto}(\mathbf{Z}),$$

então

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(n - r, \Sigma),$$

e

$$\text{posto}(\mathbf{E}_{\text{res}}) = \min(p, n - r)$$

com probabilidade 1.

Logo,

$$\mathbf{E}_{\text{res}} \succ \mathbf{0}$$

com probabilidade 1 quando

$$n - r \geq p.$$

Para respostas transformadas por

$$\mathbf{M} \in \mathbb{R}^{p \times s},$$

com posto coluna completo,

$$\mathbf{E}_M = \mathbf{M}^\top \mathbf{E}_{\text{res}} \mathbf{M}$$

é positiva definida com probabilidade 1 quando

$$n - r \geq s,$$

conforme Equação [12.55](#).

A dimensão relevante é, portanto, a dimensão da matriz que efetivamente participa da inferência.

Existência e estabilidade

A existência matemática de uma inversa não garante sua estabilidade numérica. Quando os menores autovalores de uma matriz de covariâncias estão próximos de zero, pequenas perturbações podem produzir grandes alterações na inversa. O número de condição estudado em Definição 6.9 permite quantificar essa sensibilidade. Assim, uma matriz pode possuir posto completo e ainda fornecer formas quadráticas numericamente instáveis.

A Tabela 12.2 resume as condições centrais dos procedimentos desenvolvidos neste capítulo.

Tabela 12.2: Condições centrais para os resultados exatos da inferência multivariada clássica.

Procedimento	Estrutura probabilística para o resultado exato	Condição principal de posto
média com Σ conhecida	normalidade da média	$\Sigma \succ \mathbf{0}$
T^2 de uma amostra	amostra normal multivariada	$n > p$
T^2 para $\mathbf{A}\mu = \mathbf{d}$	amostra normal multivariada	$n > h$
duas amostras independentes	normalidade, independência e covariância comum	$n_1 + n_2 - 2 \geq p$
observações pareadas	normalidade dos vetores de diferenças	$n > p$
modelo linear multivariado	normalidade matricial dos erros	$n - r \geq p$ para $\mathbf{E} \succ \mathbf{0}$
respostas transformadas	normalidade matricial dos erros	$n - r \geq s$ para $\mathbf{E}_M \succ \mathbf{0}$

12.7.3 Aprofundamento: alta dimensão e robustez

A teoria desenvolvida neste capítulo é predominantemente uma teoria de **dimensão fixa**, na qual a informação amostral cresce enquanto a dimensão permanece constante. Quando a dimensão é grande em relação ao tamanho amostral, singularidade e instabilidade tornam-se parte central do problema.

12.7.3.1 Alta dimensão

Para uma amostra,

$$\text{posto}(\mathbf{S}) \leq n - 1.$$

Logo, se

$$p \geq n,$$

então

$$\mathbf{S}$$

é necessariamente singular e o T^2 clássico não pode ser calculado na forma

$$n \left(\bar{\mathbf{X}} - \mu_0 \right)^\top \mathbf{S}^{-1} \left(\bar{\mathbf{X}} - \mu_0 \right).$$

Situações análogas ocorrem quando

$$p > n_1 + n_2 - 2$$

para a covariância agrupada ou quando

$$p > n - r$$

para a SSCP residual do modelo linear.

Mesmo antes da singularidade, uma relação desfavorável entre dimensão e quantidade de informação pode tornar a estimação de

$$\Sigma^{-1}$$

instável (Mardia; Kent; Taylor, 2024).

Uma possibilidade algébrica seria substituir a inversa por uma pseudoinversa e considerar

$$n \left(\bar{\mathbf{X}} - \mu_0 \right)^\top \mathbf{S}^+ \left(\bar{\mathbf{X}} - \mu_0 \right). \quad (12.130)$$

Essa substituição, entretanto, produz **outra estatística**.

Pseudoinversa não recupera a calibração clássica

A distribuição

$$\frac{n-p}{p(n-1)} T^2 \sim F_{p, n-p}$$

foi obtida para uma matriz de covariâncias amostral não singular sob a estrutura normal-

Wishart correspondente.
Substituir

$$\mathbf{S}^{-1}$$

por

$$\mathbf{S}^{+}$$

não preserva automaticamente essa distribuição.

Outra possibilidade é utilizar uma matriz regularizada, por exemplo,

$$\mathbf{S}_{\lambda} = \mathbf{S} + \lambda \mathbf{I}_p, \quad \lambda > 0. \quad (12.131)$$

Essa matriz é positiva definida, mas a substituição altera a estatística, introduz uma escolha de regularização e exige uma calibração inferencial própria.

Uma redução para combinações previamente determinadas também pode diminuir a dimensão efetiva. Foi exatamente essa estrutura que apareceu em

$$H_0 : \mathbf{A}\mu = \mathbf{d}$$

e em

$$\mathbf{CBM} = \Theta_0.$$

Quando as combinações são escolhidas a partir dos mesmos dados com o objetivo de maximizar a evidência contra H_0 , sua seleção também passa a fazer parte do procedimento inferencial e não pode ser ignorada.

Métodos regularizados, testes específicos para alta dimensão, reamostragem e procedimentos baseados em projeções possuem teoria própria. Sua formulação não pertence ao núcleo deste capítulo.

12.7.3.2 Robustez

A média e a matriz de covariâncias amostrais podem ser sensíveis a observações extremas. Como várias estatísticas deste capítulo dependem simultaneamente de

$$\bar{\mathbf{X}}$$

e

$$\mathbf{S}^{-1},$$

alterações na posição, na escala ou na orientação estimadas podem modificar substancialmente uma forma quadrática de Mahalanobis.

Não existe uma afirmação universal de que o T^2 ou os demais procedimentos aqui estudados sejam simplesmente “robustos” ou “não robustos”. O comportamento depende, entre outros fatores, da dimensão, do tamanho amostral, da assimetria, do peso das caudas, da heterogeneidade e da presença de observações influentes. :contentReferenceoaicite:1

Sob condições adequadas e com dimensão fixa, resultados assintóticos podem continuar válidos fora da normalidade. Isso não torna exatas as distribuições finitas derivadas da estrutura normal–Wishart.

Estimadores robustos de posição ou dispersão podem ser utilizados em outros procedimentos. Entretanto, substituir

$$\bar{\mathbf{X}}$$

ou

$$\mathbf{S}$$

por estimadores robustos também modifica a estatística e requer a distribuição ou a calibração correspondente.

Alcance desta seção

O objetivo aqui é delimitar a inferência clássica desenvolvida no capítulo.

Diagnósticos detalhados de normalidade, métodos robustos, regularização, testes de alta dimensão e estratégias de reamostragem constituem procedimentos próprios e não serão desenvolvidos neste módulo.

As condições desta seção delimitam o alcance dos resultados exatos e assintóticos apresentados no Capítulo 12. Com isso, estão reunidos os fundamentos inferenciais necessários para encerrar o Módulo 2.

12.8 Síntese do Módulo 2

O Módulo 2 desenvolveu a base probabilística e inferencial necessária para estudar conjuntamente várias variáveis. Seu percurso pode ser representado por

$$\text{covariância} \longrightarrow \text{modelo probabilístico} \longrightarrow \text{estimação} \longrightarrow \text{modelo linear} \longrightarrow \text{inferência.} \quad (12.132)$$

No Capítulo 8, a matriz de covariâncias

$$\Sigma$$

organizou a variabilidade conjunta e determinou a variância das combinações lineares, a geometria de Mahalanobis e as matrizes de dispersão.

No Capítulo 9, a distribuição

$$N_p(\mu, \Sigma)$$

forneceu um modelo probabilístico no qual transformações afins, distribuições marginais e condicionais, independência e formas quadráticas possuem resultados explícitos.

No Capítulo 10, a passagem da população para a amostra distinguiu parâmetros, estatísticas, estimadores e estimativas. Foram construídos, entre outros objetos,

$$\bar{\mathbf{X}}, \quad \mathbf{T} \quad \text{e} \quad \mathbf{S},$$

com suas propriedades de viés, variabilidade, consistência e equivariância.

No Capítulo 11, a estrutura

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E}$$

integrou várias respostas em um mesmo modelo. Projeções, resíduos, SSCPs, posto, estimabilidade e hipóteses lineares passaram a ser representados em uma estrutura comum, culminando em

$$H_0 : \mathbf{CBM} = \Theta_0.$$

Neste capítulo, as distribuições amostrais desses objetos permitiram construir a inferência multivariada clássica. Sob normalidade,

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma)$$

e

$$\bar{\mathbf{X}} \perp \mathbf{S}.$$

No modelo linear multivariado,

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(n-r, \Sigma),$$

e, para uma hipótese linear estimável, sob H_0 ,

$$\mathbf{H} \mid \mathbf{Z} \sim W_s(g, \Sigma_M),$$

com independência em relação à SSCP residual correspondente.

A distribuição de Wishart e a normal multivariada formaram, assim, a estrutura distribucional que sustenta os procedimentos exatos desenvolvidos no capítulo.

A inferência sobre o vetor de médias apresentou duas situações centrais. Quando

$$\Sigma$$

é conhecida,

$$n(\bar{\mathbf{X}} - \mu_0)^\top \Sigma^{-1}(\bar{\mathbf{X}} - \mu_0) \sim \chi_p^2$$

sob a hipótese nula.

Quando

$$\Sigma$$

é desconhecida, a substituição pela matriz de covariâncias amostral conduz à estatística de Hotelling,

$$T^2 = n(\bar{\mathbf{X}} - \mu_0)^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \mu_0),$$

com distribuição exata

$$\frac{n-p}{p(n-1)} T^2 \sim F_{p, n-p}$$

sob normalidade e

$$n > p.$$

A inversão desse teste produziu uma região de confiança elipsoidal para

$$\mu,$$

e sua geometria permitiu construir intervalos simultâneos para combinações lineares. A formulação

$$H_0 : \mathbf{A}\mu = \mathbf{d}$$

mostrou que a inferência pode ser concentrada em um subespaço de dimensão menor que p .

Na comparação entre duas populações, o delineamento determinou a estrutura da variabilidade. Para amostras independentes com covariância populacional comum, utilizou-se a covariância agrupada. Para observações pareadas, o problema foi reduzido à análise dos vetores

$$\mathbf{D}_i = \mathbf{X}_i - \mathbf{Y}_i.$$

Os dois procedimentos mantêm a estrutura do T^2 , mas utilizam informações distintas sobre a variabilidade.

A distinção entre **resultado exato** e **resultado assintótico** permaneceu central. A normalidade multivariada permitiu obter distribuições normais, Wishart e F exatas em amostras finitas. Sob condições mais gerais e dimensão fixa, o Teorema Central do Limite, a consistência e o teorema de Slutsky forneceram aproximações assintóticas.

A existência das estatísticas clássicas depende também do posto das matrizes envolvidas. Em particular,

$$p \geq n$$

implica singularidade de

$$\mathbf{S},$$

enquanto, no modelo linear,

$$p > n - r$$

implica singularidade estrutural da SSCP residual. Pseudoinversas e regularização podem produzir outros procedimentos, mas não preservam automaticamente as distribuições clássicas derivadas neste módulo.

A Tabela Tabela 12.3 reúne os objetos centrais dos cinco capítulos.

Tabela 12.3: Objetos centrais dos capítulos do Módulo 2.

Capítulo	Objeto central	Papel no Módulo 2
8. Matrizes de covariâncias e correlações	Σ e matrizes de dispersão	representa variabilidade, dependência e geometria
9. Distribuição Normal Multivariada	$N_p(\mu, \Sigma)$	fornece o principal modelo probabilístico exato
10. Estatísticas Amostrais e Estimção	$\bar{\mathbf{X}}, \mathbf{T}$ e $\mathbf{S}$	conecta parâmetros populacionais à informação amostral
11. Modelo Linear Multivariado e Hipóteses Lineares	$\mathbf{y} = \mathbf{ZB} + \mathcal{E}$	organiza estimção, resíduos, SSCPs e funções estimáveis
12. Inferência Multivariada	Wishart, razão de verossimilhanças e T^2	fornece distribuições amostrais, testes e regiões de confiança

Ao concluir o Módulo 2, o estudante deve ser capaz de:

- distinguir propriedades populacionais, estatísticas amostrais e distribuições amostrais;
- identificar quais resultados dependem da normalidade multivariada;
- reconhecer a distribuição de Wishart e sua relação com SSCPs e matrizes de covariâncias;
- formular inferência sobre vetores e combinações lineares de médias;
- utilizar a estrutura do modelo linear multivariado para representar hipóteses estimáveis;
- distinguir resultados exatos de aproximações assintóticas;
- reconhecer o papel do posto, da dimensão e do delineamento na validade da inferência clássica.

12.8.1 Passagem para o Módulo 3

Os dois primeiros módulos construíram a linguagem que será utilizada na formulação das técnicas multivariadas.

O Módulo 1 forneceu os objetos matemáticos:

vetores $\rightarrow$ matrizes $\rightarrow$ subespaços $\rightarrow$ transformações $\rightarrow$ decomposições $\rightarrow$ cálculo.

O Módulo 2 acrescentou os objetos probabilísticos e inferenciais:

covariâncias $\rightarrow$ distribuições $\rightarrow$ estimação $\rightarrow$ modelos $\rightarrow$ inferência.

O Módulo 3 combinará essas duas estruturas para formular problemas multivariados específicos.

Matrizes de covariâncias serão decompostas ou modeladas. Projeções serão utilizadas para construir representações de menor dimensão. Distâncias e produtos internos serão utilizados para representar proximidades e formar grupos. Tabelas de contingência serão transformadas em estruturas geométricas. Matrizes de hipótese e erro serão retomadas na comparação multivariada de grupos. Modelos probabilísticos serão utilizados na discriminação e classificação. Dois blocos de variáveis serão relacionados por combinações lineares.

A passagem para o Módulo 3 corresponde, portanto, à mudança de uma teoria geral dos objetos multivariados para a formulação de técnicas destinadas a problemas estatísticos específicos.

Parte III

Módulo III — Formulação Matemática e Estatística das Técnicas Multivariadas

13 Problemas e estruturas das técnicas multivariadas

Os Módulos 1 e 2 estabeleceram a base matemática, geométrica, probabilística e inferencial utilizada na Análise Multivariada. Vetores e matrizes fornecem a representação dos dados; distâncias, produtos internos e projeções descrevem sua geometria; autovalores e valores singulares identificam direções e estruturas de baixa dimensão; matrizes de covariâncias e correlações representam a variabilidade conjunta; e os modelos probabilísticos e inferenciais permitem formular conclusões sobre populações multivariadas.

Neste módulo, esses conhecimentos serão combinados para formular as principais técnicas multivariadas. O ponto de partida passa a ser o **problema estatístico**. Redução de dimensionalidade, representação de estruturas latentes, formação de grupos, representação de dissimilaridades, análise de associações em tabelas de contingência, comparação de vetores de médias, discriminação de grupos, associação entre blocos de variáveis e decomposição de preferências exigem formulações distintas (Johnson; Wichern, 2007).

Uma mesma estrutura matemática pode aparecer em técnicas diferentes. A decomposição espectral pode identificar direções de maior variabilidade, fornecer coordenadas para uma representação geométrica ou participar da determinação de direções de separação entre grupos. O significado estatístico depende do objeto analisado e do critério utilizado.

A formulação das técnicas deste módulo será organizada pelos elementos apresentados na Tabela 13.1.

Tabela 13.1: Elementos utilizados na formulação das técnicas multivariadas.

Elemento	Função na formulação
Problema estatístico	Define o objetivo da análise
Estrutura dos dados	Estabelece a forma como a informação está organizada
Objeto matemático	Representa a informação relevante para a técnica
Critério ou modelo	Determina a propriedade otimizada, decomposta ou modelada
Solução	Produz direções, coordenadas, grupos, parâmetros ou funções

Elemento	Função na formulação
Interpretação	Atribui significado estatístico e geométrico à solução

O objetivo deste capítulo é organizar os principais problemas da Análise Multivariada e identificar as estruturas compartilhadas pelas técnicas que serão desenvolvidas nos capítulos seguintes.

13.1 Do problema estatístico à técnica multivariada

A presença de várias variáveis em um conjunto de dados caracteriza o contexto multivariado, mas não determina a técnica a ser utilizada. A escolha depende da estrutura que será analisada e do objetivo estabelecido.

Considere a matriz de dados $\mathbf{X}$ definida em Definição 1.6. A mesma matriz pode ser utilizada para construir combinações lineares que concentrem variabilidade, identificar grupos de observações semelhantes ou, quando os grupos são conhecidos, determinar direções que os separem. O conjunto de dados permanece o mesmo, enquanto o objeto de interesse e o critério de solução se modificam.

A Tabela 13.2 reúne as principais correspondências que serão desenvolvidas neste módulo.

Tabela 13.2: Correspondência entre problemas, estruturas e técnicas multivariadas.

Problema estatístico	Estrutura ou objeto central	Critério ou modelo	Técnica
Representar a variabilidade em menor dimensão	Σ , $\mathbf{S}$, $\mathcal{R}$, $\mathbf{R}$ ou matriz de dados centralizada	Maximização da variância e aproximação de posto reduzido	Análise de Componentes Principais
Explicar associações por dimensões não observadas	Matriz de covariâncias ou correlações	Modelo de fatores comuns	Análise Fatorial
Formar grupos de objetos semelhantes	Matriz de dados ou de dissimilaridades	Critérios de proximidade, dispersão ou ligação	Análise de Agrupamentos
Representar proximidades em poucas dimensões	Matriz de dissimilaridades	Reconstrução geométrica ou minimização de discrepâncias	Escalonamento Multidimensional

Problema estatístico	Estrutura ou objeto central	Critério ou modelo	Técnica
Representar associações entre categorias	Tabela de contingência	Geometria do qui-quadrado e decomposição da inércia	Análise de Correspondência
Comparar conjuntamente várias respostas	Matrizes de hipótese e erro	Critérios multivariados de teste	MANOVA
Separar grupos conhecidos e classificar observações	Médias, covariâncias e dispersões de grupos	Separação entre grupos ou regra probabilística	Análise Discriminante
Relacionar dois conjuntos de variáveis	Covariâncias dentro e entre blocos	Maximização da correlação entre combinações lineares	Correlação Canônica
Decompor preferências por atributos	Delineamento de perfis e respostas de preferência	Modelo de utilidade	Análise Conjunta

Os objetos utilizados nessa tabela já começaram a ser construídos nos módulos anteriores. A matriz de dados permite trabalhar diretamente com observações e variáveis. A matriz de covariâncias Σ e sua correspondente observada $\mathbf{S}$ descrevem a variabilidade conjunta. A matriz de correlações observada $\mathbf{R}$, definida em Definição 8.12, corresponde à estrutura obtida após a padronização marginal das variáveis.

A escolha entre covariâncias e correlações modifica o problema. A matriz de covariâncias preserva as escalas originais, enquanto a matriz de correlações atribui variância unitária às variáveis. Essa diferença será retomada no Capítulo 14 ao formular a ACP a partir de $\mathbf{S}$ ou $\mathbf{R}$.

Outras técnicas utilizam estruturas diferentes. Agrupamentos e Escalonamento Multidimensional podem partir de dissimilaridades entre objetos. A Análise de Correspondência parte de frequências organizadas em uma tabela de contingência. A MANOVA utiliza a estrutura do modelo linear multivariado. A Correlação Canônica trabalha com dois blocos de variáveis. A Análise Conjunta utiliza perfis construídos pela combinação de atributos e níveis.

A estrutura de entrada delimita a informação disponível para a técnica. Uma matriz de covariâncias resume relações de segunda ordem entre variáveis. Uma matriz de dissimilaridades representa relações entre pares de objetos. Uma tabela de contingência registra frequências conjuntas entre categorias. A formulação deve preservar essa diferença.

13.2 Classes de problemas multivariados

As técnicas deste módulo podem ser organizadas de acordo com o problema estatístico que resolvem. Essa classificação estabelece a função de cada método antes de sua formulação matemática.

13.2.1 Redução de dimensionalidade

A redução de dimensionalidade substitui uma representação de dimensão elevada por outra de menor dimensão, preservando uma característica definida da informação original.

Na Análise de Componentes Principais, o critério é a variabilidade. As novas dimensões são combinações lineares escolhidas para concentrar sucessivamente a variância. A formulação utilizará projeções, decomposição espectral e SVD desenvolvidas no Módulo 1.

O mesmo objetivo geral de representar dados em poucas dimensões aparece em outras técnicas, com critérios diferentes. O Escalonamento Multidimensional preserva relações de proximidade, enquanto a Análise de Correspondência representa associações entre perfis. A propriedade preservada faz parte da definição do problema.

13.2.2 Representação de estruturas latentes

A Análise Fatorial procura representar as associações entre variáveis observadas por meio de um número menor de fatores não observados.

Nesse caso, a matriz de covariâncias passa a ser objeto de um modelo. A formulação separa a parcela de variabilidade associada aos fatores comuns da parcela específica de cada variável.

Essa estrutura distingue a Análise Fatorial da ACP. A ACP procura uma representação da variabilidade observada. A Análise Fatorial especifica um modelo para explicar a covariação entre as variáveis.

13.2.3 Formação de grupos

A Análise de Agrupamentos organiza objetos em grupos sem utilizar classes conhecidas previamente. A solução depende da representação dos objetos, da medida de proximidade e do critério que define a estrutura de grupos.

As distâncias e dissimilaridades desenvolvidas no Módulo 1 passam a determinar a geometria do problema. Métodos baseados em centroides, critérios de ligação ou outras estruturas podem produzir agrupamentos diferentes para os mesmos dados.

Sem um modelo probabilístico explícito, os grupos obtidos representam a solução do critério adotado e não correspondem automaticamente a populações distintas.

13.2.4 Representação de dissimilaridades

O Escalonamento Multidimensional constrói uma configuração de pontos a partir de relações de proximidade entre objetos. O objetivo é obter coordenadas cujas distâncias representem, exatamente ou aproximadamente, as dissimilaridades disponíveis (Borg; Groenen; Mair, 2018).

No MDS clássico, a relação entre distâncias e produtos internos permite reconstruir uma matriz de Gram e obter coordenadas por decomposição espectral. Essa formulação utilizará diretamente os resultados do Módulo 1 sobre distâncias, centralização, matrizes de Gram e autovalores.

A estrutura difere da Análise de Agrupamentos. O agrupamento procura uma partição ou hierarquia; o MDS procura uma configuração geométrica.

13.2.5 Representação de associações em tabelas de contingência

A Análise de Correspondência parte de uma tabela de frequências e representa os desvios em relação à independência entre suas categorias.

A técnica utiliza perfis, massas, distância qui-quadrado e uma decomposição de baixa dimensão baseada em SVD (Greenacre, 2017). A geometria resultante difere daquela utilizada para dados quantitativos porque linhas e colunas possuem ponderações determinadas por suas frequências marginais.

O capítulo específico mostrará como a inércia total está relacionada ao afastamento da independência e como sua decomposição produz as dimensões da representação.

13.2.6 Comparação de vetores de médias

A MANOVA considera conjuntamente várias respostas e formula hipóteses sobre efeitos representados no modelo linear multivariado.

O modelo definido em Definição 11.3 e a hipótese linear geral de Definição 11.18 fornecem a estrutura necessária. A formulação da MANOVA acrescentará os critérios construídos a partir das matrizes de hipótese e erro, sem reconstruir a teoria do modelo linear desenvolvida no Módulo 2.

A análise conjunta das respostas distingue a MANOVA de uma coleção de análises univariadas separadas.

13.2.7 Discriminação e classificação

A Análise Discriminante utiliza grupos conhecidos durante a construção da solução. Seu objetivo pode ser representar as direções de maior separação entre esses grupos ou construir regras de classificação para novas observações.

A formulação geométrica utiliza a relação entre dispersão entre grupos e dispersão dentro dos grupos. A formulação probabilística utiliza distribuições condicionais e regras de classificação. A distribuição normal multivariada e a distância de Mahalanobis estudadas no Módulo 2 fornecem parte dessa base.

A Análise Discriminante e a MANOVA compartilham estruturas de dispersão entre e dentro dos grupos, mas possuem objetivos diferentes (Huberty; Olejnik, 2006).

13.2.8 Associação entre blocos de variáveis

A Correlação Canônica considera dois conjuntos de variáveis observados nas mesmas unidades. O objetivo é construir combinações lineares dos dois blocos que apresentem associação máxima.

A matriz de covariância cruzada Σ_{XY} , definida em Definição 8.3, representa a associação entre os blocos. Sua correspondente observada $\mathbf{S}_{XY}$ foi definida em Definição 8.13.

No Capítulo 21, essas matrizes serão combinadas às covariâncias internas de cada bloco para formular as variáveis e correlações canônicas.

13.2.9 Decomposição de preferências

A Análise Conjunta relaciona respostas de preferência às características que definem alternativas ou perfis.

Em uma formulação aditiva, a preferência é representada por contribuições associadas aos níveis dos atributos. Quando a resposta é métrica, essa estrutura pode ser formulada por meio de um modelo linear cuja matriz de delineamento registra a composição dos perfis.

O problema exige ainda condições de identificação decorrentes da codificação dos atributos e níveis. Esses elementos serão introduzidos no Capítulo 22.

13.3 Diferentes formas de classificar as técnicas

A classificação pelo problema estatístico será a principal organização adotada neste módulo. Outras classificações permitem comparar diferentes características das técnicas.

13.3.1 Interdependência e dependência

Nas técnicas de interdependência, a análise não estabelece previamente uma variável resposta que será explicada pelas demais. ACP, Análise Fatorial, Agrupamentos, Escalonamento Multidimensional e Análise de Correspondência são exemplos usuais.

Nas técnicas de dependência, alguma estrutura previamente definida orienta a análise. A MANOVA possui respostas e efeitos determinados pelo delineamento. A Análise Discriminante utiliza grupos conhecidos. A Análise Conjunta utiliza respostas de preferência.

A Correlação Canônica ocupa uma posição menos rígida nessa classificação. Os dois blocos são definidos previamente, mas o critério de associação é simétrico em relação a eles.

13.3.2 Exploratórias, descritivas, preditivas e inferenciais

Uma técnica exploratória identifica padrões ou estruturas nos dados. Uma técnica descritiva resume uma configuração observada. Uma técnica preditiva produz uma regra aplicável a novas observações. Uma técnica inferencial utiliza a variabilidade amostral para formular conclusões sobre parâmetros ou populações.

Essas finalidades podem coexistir. A ACP é predominantemente exploratória e descritiva em muitas aplicações, embora exista teoria inferencial para componentes populacionais. A Análise Discriminante descreve a separação entre grupos e também pode produzir regras de classificação. A MANOVA possui finalidade principalmente inferencial.

13.3.3 Supervisionadas e não supervisionadas

Métodos supervisionados utilizam uma informação externa que orienta a construção da solução. Os rótulos dos grupos desempenham esse papel na Análise Discriminante, enquanto o delineamento define os efeitos avaliados na MANOVA.

Métodos não supervisionados constroem a estrutura diretamente a partir dos dados, sem utilizar classes ou respostas previamente especificadas. ACP e Análise de Agrupamentos são exemplos.

Essa classificação não descreve com a mesma precisão todas as técnicas do módulo. Análise Fatorial, Correspondência e MDS são caracterizadas de forma mais adequada pelo problema estatístico e pela estrutura que procuram representar.

A Tabela 13.3 resume essas classificações.

Tabela 13.3: Classificações complementares das técnicas estudadas no Módulo 3.

Técnica	Problema predominante	Relação entre variáveis	Finalidade frequente	Estrutura de supervisão
ACP	Redução de dimensionalidade	Interdependência	Exploratória e descritiva	Não supervisionada
Análise Fatorial	Estrutura latente	Interdependência	Exploratória ou inferencial	Sem resposta externa na formulação exploratória
Análise de Agrupamentos	Formação de grupos	Interdependência	Exploratória e descritiva	Não supervisionada
Escalonamento Multidimensional	Representação de dissimilaridades	Interdependência	Exploratória e descritiva	Não supervisionada
Análise de Correspondência	Associação em tabelas	Interdependência	Exploratória e descritiva	Não supervisionada
MANOVA	Comparação de vetores de médias	Dependência	Inferencial	Delineamento conhecido
Análise Discriminante	Discriminação e classificação	Dependência	Descritiva e preditiva	Grupos conhecidos
Correlação Canônica	Associação entre blocos	Estrutura simétrica entre dois blocos	Descritiva e inferencial	Blocos definidos previamente
Análise Conjunta	Decomposição de preferências	Dependência	Explicativa e preditiva	Resposta de preferência observada

A classificação pelo problema estatístico permanece mais diretamente ligada à formulação das técnicas. Por essa razão, os capítulos seguintes serão organizados pelo problema, pelo objeto matemático e pelo critério ou modelo utilizado.

13.4 Estruturas matemáticas recorrentes

As técnicas deste módulo reutilizam um conjunto relativamente pequeno de estruturas desenvolvidas anteriormente. O objetivo desta seção é estabelecer as conexões necessárias, sem repetir definições e demonstrações dos Módulos 1 e 2.

13.4.1 Combinações lineares e projeções

Combinações lineares constroem novas variáveis e novas direções a partir das variáveis originais. Sua forma geral é

$$Y = \mathbf{a}^\top \mathbf{X}.$$

O significado de $\mathbf{a}$ depende do critério da técnica. Na ACP, seus coeficientes definem uma direção de variabilidade. Na Análise Discriminante, definem uma direção de separação entre grupos. Na Correlação Canônica, duas combinações são construídas simultaneamente, uma em cada bloco.

As projeções ortogonais definidas em Definição 3.19 permitem representar observações em subespaços. Essa geometria será utilizada no Capítulo 14 para interpretar a ACP como projeção sobre um subespaço principal.

13.4.2 Formas quadráticas e problemas espectrais

A variância de uma combinação linear, as distâncias ponderadas e diferentes medidas de dispersão são expressas por formas quadráticas. Quando o critério depende da direção escolhida, surgem problemas de otimização espectral.

O quociente de Rayleigh definido em Definição 5.7 relaciona a otimização de uma forma quadrática aos autovalores de uma matriz simétrica. O resultado de Teorema 5.5 será aplicado no Capítulo 14 à matriz de covariâncias para formular as componentes principais.

Quando duas formas quadráticas são comparadas, o quociente de Rayleigh generalizado de Definição 5.12 conduz ao problema de autovalores generalizados descrito em Teorema 5.8. Essa estrutura será retomada na Análise Discriminante e na MANOVA.

A decomposição espectral, sintetizada em Tabela 5.2, fornece as direções e magnitudes associadas a uma matriz simétrica. A interpretação dessas direções depende da matriz que foi construída.

13.4.3 SVD e representações de baixa dimensão

A decomposição em valores singulares relaciona os espaços de linhas e colunas de uma matriz e permite construir aproximações de posto reduzido. Suas propriedades foram sintetizadas em Tabela 6.7.

No Módulo 3, a SVD aparecerá em diferentes contextos. Na ACP, será aplicada à matriz de dados centralizada. Na Análise de Correspondência, será aplicada a uma matriz de desvios padronizados da independência. Na Correlação Canônica, poderá ser aplicada a uma matriz

que representa a associação entre dois blocos após transformações determinadas por suas covariâncias.

O mecanismo algébrico é compartilhado, mas a matriz decomposta e o significado estatístico de seus fatores são diferentes.

13.4.4 Distâncias, matrizes de Gram e métricas

Distâncias e dissimilaridades organizam relações de proximidade entre observações. A matriz de Gram definida em Definição 3.18 organiza produtos internos e estabelece a ligação entre coordenadas e distâncias.

No MDS clássico, essa relação será utilizada no sentido inverso. A partir das distâncias, será construída uma matriz de Gram cuja decomposição espectral fornecerá coordenadas para os objetos.

Na Análise de Agrupamentos, as distâncias participam da definição dos grupos. A mesma matriz de dissimilaridades pode, portanto, alimentar técnicas com resultados diferentes.

A distância de Mahalanobis acrescenta a estrutura de dispersão à geometria. A expressão em eixos espectrais apresentada em Equação 8.47 mostra que o afastamento é ponderado pela variabilidade existente em cada direção. Essa estrutura será retomada na formulação probabilística da Análise Discriminante.

13.4.5 Covariâncias entre blocos

A covariância cruzada representa a associação linear entre dois vetores aleatórios. O Módulo 2 definiu esse objeto em Definição 8.3 e apresentou sua versão observada em Definição 8.13.

Essa estrutura será utilizada diretamente na Correlação Canônica. As covariâncias internas dos blocos controlam a variabilidade de cada conjunto, enquanto a covariância cruzada representa a associação que será maximizada por combinações lineares.

A formulação transforma um problema entre dois conjuntos de variáveis em um problema de associação entre dois espaços.

13.4.6 Modelos lineares e probabilísticos

O modelo linear multivariado definido em Definição 11.3 organiza conjuntamente várias respostas, um delineamento e uma matriz de parâmetros. A hipótese linear geral de Definição 11.18 fornece a estrutura para testar combinações desses parâmetros.

A MANOVA será formulada diretamente a partir desses resultados. O novo conteúdo será a construção e interpretação dos critérios multivariados associados às matrizes de hipótese e erro.

A Análise Conjunta também poderá utilizar uma estrutura linear, mas com interpretação própria. A matriz de delineamento representa os níveis dos atributos que compõem os perfis, enquanto os coeficientes representam contribuições para a preferência.

Outras técnicas partem de modelos probabilísticos específicos. A Análise Fatorial especifica um modelo para a matriz de covariâncias utilizando fatores comuns e variâncias específicas. A Análise Discriminante pode utilizar distribuições condicionais aos grupos para construir regras de classificação. Nessas formulações, os resultados do Módulo 2 sobre normal multivariada, estimação e inferência passam a desempenhar funções específicas.

A Tabela 13.4 reúne essas conexões.

Tabela 13.4: Estruturas dos Módulos 1 e 2 reutilizadas na formulação das técnicas.

Estrutura desenvolvida anteriormente	Utilização no Módulo 3	Técnicas diretamente relacionadas
Combinações lineares	Construção de novas direções ou variáveis	ACP, Discriminante, Correlação Canônica
Projeções	Representação em subespaços	ACP
Formas quadráticas	Medida de variabilidade, distância ou separação	ACP, Discriminante, MANOVA
Autovalores	Direções extremas de matrizes simétricas	ACP, MDS clássico
Autovalores generalizados	Comparação entre duas formas quadráticas	Discriminante, MANOVA
SVD	Associação entre espaços e aproximação de baixa dimensão	ACP, Correspondência, Correlação Canônica
Distâncias e dissimilaridades	Representação da proximidade entre objetos	Agrupamentos, MDS
Matriz de Gram	Relação entre distâncias, produtos internos e coordenadas	MDS clássico
Covariâncias e correlações	Representação da variabilidade conjunta	ACP, Fatorial, Discriminante, Correlação Canônica
Covariância cruzada	Associação entre dois blocos	Correlação Canônica
Dispersão dentro e entre grupos	Comparação da estrutura de grupos	Agrupamentos, Discriminante, MANOVA

Estrutura desenvolvida anteriormente	Utilização no Módulo 3	Técnicas diretamente relacionadas
Modelo linear multivariado	Representação conjunta de respostas e efeitos	MANOVA
Normal multivariada	Modelos probabilísticos conjuntos	Fatorial por máxima verossimilhança, Discriminante, MANOVA
Variáveis latentes	Representação de estruturas não observadas	Análise Fatorial
Modelo de utilidade	Representação das contribuições de atributos	Análise Conjunta

13.5 Mesmas estruturas, diferentes interpretações

Uma operação matemática adquire significado estatístico a partir do objeto ao qual é aplicada.

A decomposição espectral de uma matriz de covariâncias fornece direções de variabilidade. A decomposição espectral de uma matriz de Gram reconstruída a partir de distâncias fornece coordenadas para uma configuração. Um problema de autovalores generalizados envolvendo duas matrizes de dispersão produz direções que comparam essas fontes de variabilidade.

A SVD apresenta a mesma característica. Aplicada à matriz de dados centralizada, participa da formulação da ACP. Aplicada aos desvios padronizados de uma tabela de contingência, produz os eixos da Análise de Correspondência. Aplicada a uma estrutura que relaciona dois blocos de variáveis, produz pares associados à Correlação Canônica.

A Tabela 13.5 resume essas diferenças.

Tabela 13.5: Exemplos de estruturas matemáticas com diferentes significados estatísticos.

Operação matemática	Objeto analisado	Significado da solução
Decomposição espectral	Matriz de covariâncias	Direções e variâncias principais
Decomposição espectral	Matriz de Gram derivada de distâncias	Coordenadas de uma configuração
Autovalores generalizados	Dispersão entre e dentro dos grupos	Direções de separação
Autovalores generalizados	Matrizes de hipótese e erro	Dimensões associadas ao efeito multivariado

Operação matemática	Objeto analisado	Significado da solução
SVD	Matriz de dados centralizada	Direções, escores e representação de baixa dimensão
SVD	Desvios padronizados da independência	Eixos de associação entre categorias
SVD	Associação transformada entre dois blocos	Pares de direções canônicas

A interpretação de um autovetor, valor singular ou coordenada exige, portanto, a identificação da matriz de origem e do critério que definiu sua construção.

13.6 Relações entre as técnicas

Algumas técnicas apresentam estruturas matemáticas próximas, mas resolvem problemas diferentes. A Tabela 13.6 reúne as distinções que serão retomadas ao longo do módulo.

Tabela 13.6: Relações conceituais entre técnicas do Módulo 3.

Técnicas relacionadas	Estrutura compartilhada	Diferença principal
ACP e Análise Fatorial	Covariâncias, correlações e baixa dimensão	ACP representa variabilidade; Fatorial modela covariação por fatores comuns
Agrupamentos e Discriminante	Estrutura de grupos e medidas de separação	Agrupamentos constrói grupos; Discriminante utiliza grupos conhecidos
Agrupamentos e MDS	Dissimilaridades entre objetos	Agrupamentos produz partições ou hierarquias; MDS produz coordenadas
ACP e MDS clássico	Representações espectrais de baixa dimensão	ACP parte de variáveis e covariâncias; MDS parte de distâncias
MANOVA e Discriminante	Dispersão entre e dentro dos grupos	MANOVA testa efeitos; Discriminante representa separação e classifica
ACP e Correlação Canônica	Combinações lineares	ACP maximiza variância em um bloco; Canônica maximiza associação entre dois blocos

Técnicas relacionadas	Estrutura compartilhada	Diferença principal
ACP e Correspondência	Decomposições de baixa dimensão	ACP utiliza geometria de covariâncias; Correspondência utiliza perfis e geometria qui-quadrado

A relação entre ACP e Análise Fatorial será retomada imediatamente após a formulação dessas técnicas. A conexão entre ACP e MDS aparecerá quando as dissimilaridades forem distâncias euclidianas derivadas de dados quantitativos. A relação entre MANOVA e Análise Discriminante será estabelecida a partir das estruturas de dispersão associadas aos grupos.

Essas conexões mostram por que a técnica deve ser identificada pelo problema estatístico e não pela operação matricial utilizada.

13.7 Síntese

As técnicas multivariadas deste módulo utilizam os fundamentos construídos nos Módulos 1 e 2 para resolver problemas estatísticos específicos. A formulação de cada técnica combina uma estrutura de dados, um objeto matemático e um critério ou modelo.

Combinações lineares e projeções produzem novas direções e representações. Formas quadráticas e problemas espectrais permitem otimizar variabilidade e separação. A SVD fornece representações de baixa dimensão e relaciona diferentes espaços. Distâncias e matrizes de Gram conectam proximidades e coordenadas. Matrizes de covariâncias representam dependência. Covariâncias cruzadas relacionam blocos. Modelos lineares organizam respostas e efeitos. Modelos probabilísticos e variáveis latentes acrescentam estruturas específicas para estimação e inferência.

Os capítulos seguintes utilizarão esses resultados sem reconstruir seus fundamentos. O Capítulo 14 inicia esse percurso com a Análise de Componentes Principais, formulada a partir da variância de combinações lineares, do quociente de Rayleigh, da decomposição espectral, das projeções e da SVD.

14 Formulação da Análise de Componentes Principais

A Análise de Componentes Principais (ACP) procura representar a variabilidade de um conjunto de variáveis por meio de um número menor de combinações lineares. A técnica substitui as coordenadas originais por novas direções ordenadas segundo a quantidade de variabilidade que representam (Jolliffe, 2002).

Os fundamentos necessários para essa construção já foram desenvolvidos nos módulos anteriores. Combinações lineares e projeções fornecem a interpretação geométrica; o quociente de Rayleigh e a decomposição espectral permitem determinar as direções de maior variabilidade; a SVD estabelece a relação entre os espaços das observações e das variáveis e fornece aproximações de posto reduzido; e as matrizes de covariâncias e correlações representam a variabilidade conjunta que será decomposta.

Neste capítulo, esses resultados serão combinados para formular a ACP em três perspectivas relacionadas:

1. maximização sucessiva da variância de combinações lineares;
2. projeção sobre um subespaço que preserve a maior variabilidade possível;
3. aproximação de posto reduzido da matriz de dados centralizada.

As três formulações conduzem ao mesmo subespaço principal quando são aplicadas à mesma estrutura de dados. A primeira estabelece diretamente o problema estatístico da técnica; a segunda explicita sua interpretação geométrica; e a terceira relaciona a ACP à SVD e à reconstrução dos dados.

A ACP é definida a partir de momentos de segunda ordem. Sua formulação não exige normalidade multivariada. A normalidade passa a ter papel específico quando se pretende obter resultados inferenciais sobre componentes populacionais, autovalores ou autovetores.

14.1 O problema de redução de dimensionalidade

Considere o vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_p)^\top \in \mathbb{R}^p,$$

com vetor de médias μ e matriz de covariâncias populacional Σ , definida em Definição 8.2.

Cada realização $\mathbf{x} \in \mathbb{R}^p$ representa uma unidade por meio de p coordenadas. Quando várias dessas coordenadas apresentam associação linear, a variabilidade conjunta pode estar concentrada em um número menor de direções.

Essa situação pode ser entendida geometricamente. Uma nuvem de pontos em $\mathbb{R}^2$ pode apresentar grande extensão em uma direção e pequena extensão na direção ortogonal. Embora duas coordenadas sejam necessárias para representar exatamente cada ponto, uma única direção pode concentrar a maior parte da dispersão da nuvem. Em dimensão p , o mesmo princípio conduz à procura de um subespaço de dimensão $k < p$ que represente adequadamente a variabilidade dos dados.

A ACP não seleciona diretamente k variáveis dentre as p variáveis originais. Ela constrói novas variáveis como combinações lineares das componentes de $\mathbf{X}$. Cada nova variável corresponde a uma direção no espaço das variáveis.

O vetor aleatório centralizado,

$$\mathbf{X}_c = \mathbf{X} - \mu,$$

tem média nula e preserva a matriz de covariâncias de $\mathbf{X}$. A centralização separa a localização da distribuição de sua estrutura de dispersão. Por isso, a formulação populacional da ACP pode ser construída diretamente a partir de $\mathbf{X}_c$ e de Σ .

Uma direção unitária

$$\mathbf{a} \in \mathbb{R}^p, \quad \mathbf{a}^\top \mathbf{a} = 1,$$

produz a combinação linear

$$Y = \mathbf{a}^\top \mathbf{X}_c.$$

Como $\mathbf{a}$ possui norma unitária, Y representa a coordenada de $\mathbf{X}_c$ na direção definida por $\mathbf{a}$.

Pelo resultado sobre momentos de combinações lineares apresentado em Proposição 8.1,

$$E(Y) = 0$$

e

$$\text{Var}(Y) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

A variância da combinação linear depende, portanto, da direção $\mathbf{a}$. Algumas direções podem apresentar grande dispersão, enquanto outras apresentam pequena dispersão.

A ACP utiliza essa diferença para ordenar as direções. O primeiro objetivo consiste em encontrar a direção unitária de maior variabilidade. Depois são procuradas novas direções, ortogonais às anteriores, que preservem sucessivamente a maior variabilidade restante.

A Figura 14.1 representa uma nuvem bidimensional com variabilidade distinta segundo diferentes direções. A primeira direção principal acompanha a maior extensão da nuvem, enquanto a segunda é ortogonal à primeira e representa a variabilidade remanescente.




Figura 14.1: As direções principais acompanham os eixos de maior e menor variabilidade da nuvem de observações.

A maior dispersão ocorre na direção da primeira componente. A segunda componente re-

apresenta a maior variabilidade possível entre as direções ortogonais à primeira. A figura transforma a ideia de maximização da variância em uma propriedade geométrica da nuvem.

A redução de dimensionalidade ocorre quando apenas as primeiras $k < p$ direções são mantidas. A qualidade dessa representação depende da concentração da variabilidade nessas direções. Quando os primeiros autovalores da matriz de covariâncias são muito maiores que os demais, poucas componentes podem representar grande parcela da variância total. Quando os autovalores possuem magnitudes semelhantes, a redução de dimensão implica perda proporcionalmente maior de variabilidade.

14.2 Componentes principais como combinações lineares

A j -ésima componente principal populacional tem a forma

$$Y_j = \mathbf{a}_j^\top \mathbf{X}_c = \mathbf{a}_j^\top (\mathbf{X} - \mu),$$

em que

$$\mathbf{a}_j \in \mathbb{R}^p$$

é o vetor de coeficientes da componente.

É importante distinguir os objetos envolvidos na formulação:

- $\mathbf{a}_j$ define uma direção no espaço das variáveis;
- Y_j é uma variável aleatória obtida pela projeção de $\mathbf{X}_c$ nessa direção;
- a variância de Y_j quantifica a dispersão populacional representada pela direção;
- posteriormente, a versão amostral de $\mathbf{a}_j$ permitirá calcular os escores das observações.

Para duas combinações lineares,

$$Y_j = \mathbf{a}_j^\top \mathbf{X}_c$$

e

$$Y_\ell = \mathbf{a}_\ell^\top \mathbf{X}_c,$$

tem-se

$$\text{Cov}(Y_j, Y_\ell) = \mathbf{a}_j^\top \Sigma \mathbf{a}_\ell.$$

Assim, a matriz Σ determina simultaneamente a variabilidade de cada direção e a covariância entre diferentes combinações lineares.

A restrição de norma unitária é necessária porque a variância depende da escala do vetor de coeficientes. Para qualquer constante c ,

$$\text{Var}(c\mathbf{a}^\top \mathbf{X}_c) = c^2 \mathbf{a}^\top \Sigma \mathbf{a}.$$

Sem controlar a norma de $\mathbf{a}$, a variância poderia ser aumentada apenas multiplicando os coeficientes por uma constante. A condição

$$\mathbf{a}^\top \mathbf{a} = 1$$

remove esse efeito de escala e transforma o problema em uma escolha de **direção**.

14.3 Primeira componente principal

A primeira componente principal é definida pela direção unitária que apresenta a maior variância.

O problema é

$$\max_{\mathbf{a}_1} \mathbf{a}_1^\top \Sigma \mathbf{a}_1,$$

sujeito a

$$\mathbf{a}_1^\top \mathbf{a}_1 = 1.$$

Esse problema já possui a forma estudada no Módulo 1. O quociente de Rayleigh foi definido em Definição 5.7 e seus extremos foram caracterizados em Teorema 5.5. Aplicando esse resultado à matriz simétrica e semidefinida positiva Σ , o máximo é igual ao maior autovalor da matriz de covariâncias.

A variação do quociente de Rayleigh segundo a direção foi ilustrada em Figura 5.4. Na ACP, a matriz utilizada naquele problema passa a ser Σ , e o máximo do quociente corresponde à maior variância possível de uma combinação linear com coeficientes de norma unitária.

Se os autovalores de Σ forem ordenados como

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0,$$

e $\mathbf{a}_1$ for um autovetor unitário associado a λ_1 , então

$$\Sigma \mathbf{a}_1 = \lambda_1 \mathbf{a}_1.$$

A primeira componente principal é

$$Y_1 = \mathbf{a}_1^\top \mathbf{X}_c,$$

e sua variância é

$$\begin{aligned} \text{Var}(Y_1) &= \mathbf{a}_1^\top \Sigma \mathbf{a}_1 \\ &= \mathbf{a}_1^\top \lambda_1 \mathbf{a}_1 \\ &= \lambda_1. \end{aligned}$$

Portanto,

$$\text{Var}(Y_1) = \lambda_1.$$

O maior autovalor possui uma interpretação estatística direta: ele é a maior variância que pode ser obtida por uma combinação linear das variáveis com vetor de coeficientes de norma unitária.

O autovetor correspondente fornece a direção em que essa variância é alcançada. A primeira componente principal transforma esse resultado geométrico em uma nova variável.

A derivação por multiplicadores de Lagrange não precisa ser reconstruída aqui. O resultado geral que relaciona a otimização de uma forma quadrática aos autovetores já foi demonstrado em Teorema 5.6. A ACP utiliza esse resultado com

$$\mathbf{A} = \Sigma.$$

Esse é o primeiro exemplo do Módulo 3 em que um problema estatístico é resolvido diretamente por uma estrutura matemática desenvolvida no Módulo 1.

14.4 Componentes principais sucessivas

A primeira direção concentra a maior variabilidade possível em uma única coordenada. As componentes seguintes devem acrescentar novas direções sem repetir a informação linear já representada.

A segunda componente principal é definida como a combinação linear de maior variância entre as direções unitárias ortogonais à primeira:

$$\max_{\mathbf{a}_2} \mathbf{a}_2^\top \Sigma \mathbf{a}_2,$$

sujeito a

$$\mathbf{a}_2^\top \mathbf{a}_2 = 1$$

e

$$\mathbf{a}_2^\top \mathbf{a}_1 = 0.$$

O mesmo princípio é aplicado sucessivamente. Para $j = 1, \dots, p$, a j -ésima direção principal resolve

$$\max_{\mathbf{a}_j} \mathbf{a}_j^\top \Sigma \mathbf{a}_j,$$

sujeito a

$$\mathbf{a}_j^\top \mathbf{a}_j = 1$$

e

$$\mathbf{a}_j^\top \mathbf{a}_\ell = 0, \quad \ell = 1, \dots, j-1.$$

A caracterização variacional de direções sucessivas já foi estabelecida em Teorema 5.7. Aplicando esse resultado a Σ , obtém-se

$$\Sigma \mathbf{a}_j = \lambda_j \mathbf{a}_j, \quad j = 1, \dots, p.$$

Assim, as direções principais são fornecidas por uma base ortonormal de autovetores da matriz de covariâncias, ordenada de acordo com os autovalores decrescentes.

A j -ésima componente principal é

$$Y_j = \mathbf{a}_j^\top \mathbf{X}_c$$

e possui variância

$$\text{Var}(Y_j) = \lambda_j.$$

Para $j \neq \ell$,

$$\begin{aligned} \text{Cov}(Y_j, Y_\ell) &= \mathbf{a}_j^\top \Sigma \mathbf{a}_\ell \\ &= \lambda_\ell \mathbf{a}_j^\top \mathbf{a}_\ell \\ &= 0. \end{aligned}$$

Logo, as componentes principais são não correlacionadas:

$$\text{Cov}(Y_j, Y_\ell) = 0, \quad j \neq \ell.$$

Duas propriedades diferentes aparecem nessa construção. Os vetores de coeficientes são **ortogonais**,

$$\mathbf{a}_j^\top \mathbf{a}_\ell = 0,$$

enquanto as componentes principais são **não correlacionadas**,

$$\text{Cov}(Y_j, Y_\ell) = 0.$$

A primeira propriedade pertence à geometria dos vetores de coeficientes. A segunda pertence à estrutura probabilística das variáveis construídas. Na ACP, a decomposição espectral de Σ conecta as duas propriedades.

A ausência de correlação não implica independência em uma distribuição geral. Se $\mathbf{X}$ possui distribuição normal multivariada, qualquer transformação linear também é normal, conforme Proposição 9.5. Nesse caso, o vetor das componentes principais é normal multivariado e possui matriz de covariâncias diagonal. Pelo resultado de independência para blocos normais de Proposição 9.7, as componentes principais são independentes. A normalidade, portanto, acrescenta uma propriedade probabilística às componentes, mas não participa da definição da ACP.

14.5 Formulação espectral

Reunindo os vetores de coeficientes em

$$\mathbf{A} = (\mathbf{a}_1 \quad \mathbf{a}_2 \quad \cdots \quad \mathbf{a}_p),$$

tem-se

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_p.$$

A matriz $\mathbf{A}$ é ortogonal. Pelo Teorema Espectral de Teorema 5.4,

$$\Sigma = \mathbf{A} \Lambda \mathbf{A}^\top,$$

em que

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p).$$

As componentes podem ser reunidas no vetor aleatório

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_p \end{pmatrix} = \mathbf{A}^\top \mathbf{X}_c.$$

Como

$$E(\mathbf{X}_c) = \mathbf{0},$$

tem-se

$$E(\mathbf{Y}) = \mathbf{0}.$$

Pela regra de transformação da matriz de covariâncias desenvolvida no Módulo 2,

$$\text{Cov}(\mathbf{A}^\top \mathbf{X}_c) = \mathbf{A}^\top \Sigma \mathbf{A}.$$

Substituindo a decomposição espectral,

$$\begin{aligned}\text{Cov}(\mathbf{Y}) &= \mathbf{A}^\top \mathbf{A} \mathbf{\Lambda} \mathbf{A}^\top \mathbf{A} \\ &= \mathbf{\Lambda}.\end{aligned}$$

Portanto,

$$\text{Cov}(\mathbf{Y}) = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_p \end{pmatrix}.$$

A transformação para componentes principais **diagonaliza a estrutura de covariâncias**. As variáveis originais podem apresentar covariâncias diferentes de zero; no novo sistema de coordenadas, toda a variabilidade aparece distribuída ao longo de eixos não correlacionados.

A transformação completa

$$\mathbf{X}_c \mapsto \mathbf{Y} = \mathbf{A}^\top \mathbf{X}_c$$

não reduz a dimensão. Ela representa o mesmo vetor em uma base ortonormal diferente. As propriedades das transformações ortogonais desenvolvidas no Módulo 1 garantem a preservação das distâncias e dos produtos internos quando todas as p componentes são mantidas.

A redução ocorre somente quando a transformação é seguida pela retenção das primeiras $k < p$ coordenadas.

14.6 Variância total e proporção de variância

A variância total foi definida em Definição 8.6 por

$$V_T = \text{tr}(\Sigma).$$

Como o traço de uma matriz é igual à soma de seus autovalores,

$$\text{tr}(\Sigma) = \sum_{j=1}^p \lambda_j.$$

Por outro lado,

$$\text{Cov}(\mathbf{Y}) = \mathbf{\Lambda},$$

de modo que

$$\text{tr} [\text{Cov}(\mathbf{Y})] = \sum_{j=1}^p \lambda_j.$$

Assim,

$$\sum_{j=1}^p \text{Var}(Y_j) = \text{tr}(\Sigma).$$

A ACP completa **redistribui**, entre novas coordenadas, a mesma variabilidade total presente nas variáveis originais. A ordenação dos autovalores concentra as maiores parcelas nas primeiras componentes.

A proporção da variância total associada à componente j é

$$\pi_j = \frac{\lambda_j}{\sum_{\ell=1}^p \lambda_{\ell}}.$$

Para as primeiras k componentes, a proporção acumulada é

$$\Pi_k = \frac{\sum_{j=1}^k \lambda_j}{\sum_{\ell=1}^p \lambda_{\ell}}.$$

A variabilidade representada pelas primeiras k direções é

$$\sum_{j=1}^k \lambda_j,$$

enquanto a variabilidade associada às direções descartadas é

$$\sum_{j=k+1}^p \lambda_j.$$

A decomposição pode ser resumida pela Tabela [14.1](#).

Tabela 14.1: Relação entre componentes principais, direções, autovalores e variância representada.

Componente	Direção	Variância	Proporção da variância total
Y_1	$\mathbf{a}_1$	λ_1	$\lambda_1 / \sum_{\ell=1}^p \lambda_\ell$
Y_2	$\mathbf{a}_2$	λ_2	$\lambda_2 / \sum_{\ell=1}^p \lambda_\ell$
$\vdots$	$\vdots$	$\vdots$	$\vdots$
Y_p	$\mathbf{a}_p$	λ_p	$\lambda_p / \sum_{\ell=1}^p \lambda_\ell$

Exemplo 14.1 (Componentes principais de duas variáveis). Considere um vetor aleatório

$$\mathbf{X} = \begin{pmatrix} X_1 \\ X_2 \end{pmatrix}$$

com matriz de covariâncias

$$\Sigma = \begin{pmatrix} 4 & 2 \\ 2 & 4 \end{pmatrix}.$$

A decomposição espectral fornece os autovalores

$$\lambda_1 = 6 \quad \text{e} \quad \lambda_2 = 2,$$

com autovetores unitários

$$\mathbf{a}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

e

$$\mathbf{a}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}.$$

A primeira componente principal é

$$Y_1 = \frac{(X_1 - \mu_1) + (X_2 - \mu_2)}{\sqrt{2}},$$

com

$$\text{Var}(Y_1) = 6.$$

A segunda componente é

$$Y_2 = \frac{(X_1 - \mu_1) - (X_2 - \mu_2)}{\sqrt{2}},$$

com

$$\text{Var}(Y_2) = 2.$$

As duas componentes são não correlacionadas porque

$$\mathbf{a}_1^\top \mathbf{a}_2 = 0.$$

A variância total é

$$\text{tr}(\Sigma) = 4 + 4 = 8,$$

que coincide com

$$\lambda_1 + \lambda_2 = 6 + 2 = 8.$$

A primeira componente representa

$$\frac{6}{8} = 75\%$$

da variabilidade total, enquanto a segunda representa

$$\frac{2}{8} = 25\%.$$

Se a representação for reduzida de duas para uma dimensão, a direção

$$\mathbf{a}_1$$

preserva 75% da variabilidade e descarta 25%. Nesse exemplo, a redução de dimensão possui interpretação direta: a maior parte da dispersão ocorre na direção em que as duas variáveis se deslocam conjuntamente.

A Figura 14.2 mostra, em um exemplo didático, duas leituras complementares dos autovalores. O primeiro painel apresenta a variância associada individualmente a cada componente. O segundo apresenta a proporção acumulada da variância representada pelas primeiras componentes.




Figura 14.2: Os autovalores quantificam a variância de cada componente, e sua soma acumulada determina a proporção da variabilidade representada pelas primeiras dimensões.

A concentração dos primeiros autovalores determina a capacidade de redução linear de dimensão. Quando Π_k é elevada para um valor pequeno de k , o subespaço principal representa grande parcela da variabilidade total. A proporção acumulada descreve a decomposição da variância, mas não estabelece um limite universal para a escolha do número de componentes.

A formulação até este ponto mostra que a ACP transforma o problema estatístico de **preservar variabilidade em poucas direções** em um problema espectral já resolvido matematicamente no Módulo 1. O passo seguinte consiste em mostrar que as primeiras k direções também definem o subespaço que maximiza a variabilidade projetada e minimiza o erro quadrático de reconstrução.

14.7 Subespaço principal e projeção

As primeiras $k < p$ componentes principais definem um subespaço de dimensão k no qual a variabilidade de $\mathbf{X}$ será representada.

Considere a matriz

$$\mathbf{A}_k = (\mathbf{a}_1 \quad \cdots \quad \mathbf{a}_k) \in \mathbb{R}^{p \times k},$$

formada pelos autovetores associados aos k maiores autovalores de Σ . Como esses vetores são ortonormais,

$$\mathbf{A}_k^\top \mathbf{A}_k = \mathbf{I}_k.$$

O subespaço gerado por suas colunas será denominado **subespaço principal de dimensão k** .

Definição 14.1 (Subespaço principal). O **subespaço principal de dimensão k** é

$$\mathcal{S}_k = \text{span} \{ \mathbf{a}_1, \dots, \mathbf{a}_k \},$$

em que $\mathbf{a}_1, \dots, \mathbf{a}_k$ são autovetores ortonormais associados aos k maiores autovalores de Σ .

A matriz de projeção ortogonal sobre $\mathcal{S}_k$ é

$$\mathbf{P}_k = \mathbf{A}_k \mathbf{A}_k^\top.$$

Essa expressão é uma aplicação direta da projeção sobre um subespaço com base ortonormal desenvolvida em Proposição 3.14.

As coordenadas de $\mathbf{X}_c$ nesse subespaço são

$$\mathbf{Y}_k = \mathbf{A}_k^\top \mathbf{X}_c = \begin{pmatrix} Y_1 \\ \vdots \\ Y_k \end{pmatrix}.$$

Sua matriz de covariâncias é

$$\begin{aligned} \text{Cov}(\mathbf{Y}_k) &= \mathbf{A}_k^\top \Sigma \mathbf{A}_k \\ &= \text{diag}(\lambda_1, \dots, \lambda_k). \end{aligned}$$

Portanto, a variância total das coordenadas mantidas é

$$\text{tr}[\text{Cov}(\mathbf{Y}_k)] = \sum_{j=1}^k \lambda_j.$$

Esse resultado fornece uma interpretação conjunta das primeiras k componentes. A ACP não procura somente a melhor primeira direção e depois as seguintes de forma isolada. O conjunto das primeiras k direções determina um subespaço que concentra a maior variabilidade possível entre os subespaços lineares de mesma dimensão.

Considere qualquer matriz

$$\mathbf{Q} = (\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_k) \in \mathbb{R}^{p \times k},$$

com colunas ortonormais,

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k.$$

A projeção de $\mathbf{X}_c$ sobre o subespaço gerado por $\mathbf{Q}$ possui coordenadas

$$\mathbf{Q}^\top \mathbf{X}_c$$

e variância total

$$\text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}) = \sum_{j=1}^k \mathbf{q}_j^\top \Sigma \mathbf{q}_j.$$

O resultado para uma única direção se estende ao conjunto das primeiras k direções.

Proposição 14.1 (Variabilidade máxima do subespaço principal). *Entre os subespaços de dimensão k , o subespaço principal $\mathcal{S}_k$ maximiza a variância total das coordenadas projetadas. Para qualquer matriz $\mathbf{Q} \in \mathbb{R}^{p \times k}$ com colunas ortonormais,*

$$\text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}) \leq \sum_{j=1}^k \lambda_j.$$

O valor máximo é

$$\sum_{j=1}^k \lambda_j,$$

e é atingido quando o espaço coluna de $\mathbf{Q}$ coincide com $\mathcal{S}_k$.

Comprovação. Pelo Teorema Espectral de Teorema 5.4,

$$\Sigma = \mathbf{A}\Lambda\mathbf{A}^\top,$$

com

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p), \quad \lambda_1 \geq \dots \geq \lambda_p.$$

Defina

$$\mathbf{B} = \mathbf{A}^\top \mathbf{Q}.$$

Como $\mathbf{A}$ é ortogonal e as colunas de $\mathbf{Q}$ são ortonormais,

$$\mathbf{B}^\top \mathbf{B} = \mathbf{I}_k.$$

Logo,

$$\begin{aligned} \text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}) &= \text{tr}(\mathbf{B}^\top \Lambda \mathbf{B}) \\ &= \sum_{i=1}^p \lambda_i w_i, \end{aligned}$$

em que

$$w_i = \sum_{j=1}^k b_{ij}^2.$$

Como $\mathbf{B}\mathbf{B}^\top$ é um projetor ortogonal,

$$0 \leq w_i \leq 1$$

e

$$\sum_{i=1}^p w_i = \text{tr}(\mathbf{B}\mathbf{B}^\top) = k.$$

Como os autovalores estão em ordem decrescente, a soma

$$\sum_{i=1}^p \lambda_i w_i$$

é maximizada atribuindo peso unitário aos k maiores autovalores. Portanto,

$$\text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}) \leq \sum_{j=1}^k \lambda_j.$$

A igualdade ocorre para

$$\mathbf{Q} = \mathbf{A}_k,$$

ou, de forma mais geral, quando $\mathbf{Q}$ gera o mesmo subespaço principal $\mathcal{S}_k$. $\square$

Para $k = 1$, o resultado recupera a direção de variância máxima. Para $k > 1$, estabelece que as primeiras componentes definem conjuntamente o subespaço que concentra a maior variabilidade possível.

14.8 Reconstrução a partir das componentes principais

As primeiras k componentes fornecem as coordenadas de $\mathbf{X}_c$ no subespaço principal. A projeção no espaço original é obtida por

$$\tilde{\mathbf{X}}_{c,k} = \mathbf{A}_k \mathbf{Y}_k.$$

Como

$$\mathbf{Y}_k = \mathbf{A}_k^\top \mathbf{X}_c,$$

segue que

$$\tilde{\mathbf{X}}_{c,k} = \mathbf{A}_k \mathbf{A}_k^\top \mathbf{X}_c = \mathbf{P}_k \mathbf{X}_c.$$

O vetor $\tilde{\mathbf{X}}_{c,k}$ é a representação de $\mathbf{X}_c$ obtida utilizando apenas as primeiras k direções principais.

A parcela não representada é

$$\mathbf{E}_k = \mathbf{X}_c - \widetilde{\mathbf{X}}_{c,k} = (\mathbf{I}_p - \mathbf{P}_k) \mathbf{X}_c.$$

A projeção e o resíduo pertencem a subespaços ortogonais. Assim,

$$\|\mathbf{X}_c\|^2 = \|\widetilde{\mathbf{X}}_{c,k}\|^2 + \|\mathbf{E}_k\|^2.$$

Tomando esperanças, a variabilidade total também se decompõe em parcela representada e parcela não representada:

$$E(\|\mathbf{X}_c\|^2) = E(\|\widetilde{\mathbf{X}}_{c,k}\|^2) + E(\|\mathbf{E}_k\|^2).$$

A primeira parcela é

$$E(\|\widetilde{\mathbf{X}}_{c,k}\|^2) = \sum_{j=1}^k \lambda_j,$$

enquanto, pela definição de variância total em Definição 8.6,

$$E(\|\mathbf{X}_c\|^2) = \text{tr}(\Sigma) = \sum_{j=1}^p \lambda_j.$$

Consequentemente,

$$E(\|\mathbf{E}_k\|^2) = \sum_{j=k+1}^p \lambda_j.$$

A variabilidade descartada pela redução de dimensão corresponde exatamente à soma dos autovalores associados às direções excluídas.

Proposição 14.2 (Variância preservada e erro de reconstrução). *Para uma dimensão k fixada, maximizar a variância preservada pela projeção equivale a minimizar o erro quadrático médio de reconstrução. Na solução da ACP,*

$$\text{variância preservada} = \sum_{j=1}^k \lambda_j$$

e

$$\text{variância descartada} = \sum_{j=k+1}^p \lambda_j.$$

A decomposição de um vetor em projeção e resíduo ortogonal foi apresentada em Figura 3.5. Na ACP, o mesmo princípio é aplicado simultaneamente à nuvem de observações, utilizando como subespaço a direção ou o subespaço principal.

A Figura 14.3 representa a redução de duas para uma dimensão. Cada observação é projetada sobre a primeira direção principal. Os segmentos vermelhos representam os resíduos de reconstrução.




Figura 14.3: A redução para uma componente substitui cada observação por sua projeção sobre a primeira direção principal; os segmentos ortogonais representam o erro de reconstrução.

Os pontos azuis são as observações centralizadas, os pontos verdes são suas representações utilizando somente a primeira componente e os segmentos vermelhos correspondem à parcela

descartada. A ACP escolhe a direção que minimiza conjuntamente esses resíduos quadráticos entre todas as retas que passam pelo centro da nuvem.

Essa equivalência conecta duas interpretações da técnica. A ACP pode ser formulada como busca das direções que preservam maior variabilidade ou como busca do subespaço que produz menor perda quadrática na reconstrução.

14.9 Formulação amostral

A formulação populacional define as componentes em termos de Σ , que geralmente é desconhecida. A aplicação da técnica utiliza uma amostra para estimar suas direções e variâncias.

Considere uma realização amostral organizada na matriz

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

com média observada $\bar{\mathbf{x}}$ e matriz centralizada

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top.$$

A matriz de covariâncias observada foi definida em Definição 8.11 como

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c.$$

A versão amostral da ACP substitui a matriz populacional Σ por $\mathbf{S}$.

Considere a decomposição espectral

$$\mathbf{S} = \widehat{\mathbf{A}} \widehat{\mathbf{\Lambda}} \widehat{\mathbf{A}}^\top,$$

em que

$$\widehat{\mathbf{\Lambda}} = \text{diag}(\hat{\lambda}_1, \dots, \hat{\lambda}_p),$$

com

$$\hat{\lambda}_1 \geq \dots \geq \hat{\lambda}_p \geq 0,$$

e

$$\widehat{\mathbf{A}} = (\hat{\mathbf{a}}_1 \quad \cdots \quad \hat{\mathbf{a}}_p).$$

Os objetos populacionais e amostrais devem permanecer distintos:

Tabela 14.2: Correspondência entre objetos populacionais e amostrais na ACP.

Objeto	População	Amostra observada
Matriz de covariâncias	Σ	$\mathbf{S}$
Direção principal j	$\mathbf{a}_j$	$\hat{\mathbf{a}}_j$
Variância da componente j	λ_j	$\hat{\lambda}_j$
Componente principal	$Y_j = \mathbf{a}_j^\top (\mathbf{X} - \mu)$	definida a partir da direção estimada $\hat{\mathbf{a}}_j$
Coordenada de uma observação	realização de Y_j	escore t_{ij}

A direção $\hat{\mathbf{a}}_j$ é obtida a partir da amostra e estima a direção populacional correspondente quando essa direção é identificável e a estrutura amostral é informativa sobre Σ .

Para a observação i , o escore na componente j é

$$t_{ij} = \hat{\mathbf{a}}_j^\top (\mathbf{x}_i - \bar{\mathbf{x}}).$$

Definição 14.2 (Escore de uma componente principal). O **escore da observação i na componente principal j** é sua coordenada na direção principal amostral:

$$t_{ij} = \hat{\mathbf{a}}_j^\top (\mathbf{x}_i - \bar{\mathbf{x}}).$$

Os escores de todas as observações nas k primeiras componentes são reunidos em

$$\mathbf{T}_k = \mathbf{X}_c \widehat{\mathbf{A}}_k,$$

em que

$$\widehat{\mathbf{A}}_k = (\hat{\mathbf{a}}_1 \quad \cdots \quad \hat{\mathbf{a}}_k).$$

A matriz

$$\mathbf{T}_k \in \mathbb{R}^{n \times k}$$

fornece a representação das n observações no espaço principal de dimensão k .

Os elementos de $\hat{\mathbf{a}}_j$ são os **coeficientes da componente principal**. Os elementos da coluna correspondente de $\mathbf{T}_k$ são os **escores**. Esses objetos desempenham funções diferentes: os coeficientes definem a direção e os escores localizam as observações nessa direção.

A matriz centralizada reconstruída a partir das primeiras k componentes é

$$\widetilde{\mathbf{X}}_{c,k} = \mathbf{T}_k \widehat{\mathbf{A}}_k^\top.$$

Substituindo a definição dos escores,

$$\widetilde{\mathbf{X}}_{c,k} = \mathbf{X}_c \widehat{\mathbf{A}}_k \widehat{\mathbf{A}}_k^\top.$$

Assim, a reconstrução amostral também é uma projeção ortogonal sobre o subespaço principal estimado.

Para retornar às unidades e à localização originais, adiciona-se novamente o vetor de médias:

$$\widetilde{\mathbf{X}}_k = \widetilde{\mathbf{X}}_{c,k} + \mathbf{1}_n \bar{\mathbf{x}}^\top.$$

A centralização remove a localização antes da determinação das direções principais; a reconstrução final restitui essa localização.

14.10 Formulação da ACP pela SVD

A formulação amostral pode ser obtida diretamente da matriz centralizada sem formar previamente $\mathbf{S}$.

Se

$$r = \text{posto}(\mathbf{X}_c),$$

considere a SVD compacta definida em Definição 6.4:

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

em que

$$\mathbf{U}_r \in \mathbb{R}^{n \times r}, \quad \mathbf{D}_r \in \mathbb{R}^{r \times r}, \quad \mathbf{V}_r \in \mathbb{R}^{p \times r}.$$

Os valores singulares são ordenados como

$$d_1 \geq d_2 \geq \dots \geq d_r > 0.$$

Como

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c,$$

a relação entre a SVD da matriz centralizada e a decomposição espectral da covariância, estabelecida em Proposição 6.14, fornece

$$\mathbf{S} = \mathbf{V}_r \frac{\mathbf{D}_r^2}{n-1} \mathbf{V}_r^\top.$$

Portanto,

$$\hat{\mathbf{a}}_j = \mathbf{v}_j$$

e

$$\hat{\lambda}_j = \frac{d_j^2}{n-1}, \quad j = 1, \dots, r.$$

Os vetores singulares à direita da matriz centralizada são as direções principais amostrais. O quadrado de cada valor singular, dividido por $n-1$, é a variância observada da componente correspondente.

A interpretação geométrica da SVD foi apresentada em Figura 6.1. Na ACP amostral, a matriz decomposta passa a ser $\mathbf{X}_c$. Os vetores singulares à direita fornecem as direções no espaço das variáveis, enquanto os produtos dos vetores singulares à esquerda pelos valores singulares fornecem as coordenadas das observações nessas direções.

Essa relação mostra que a decomposição espectral de $\mathbf{S}$ e a SVD de $\mathbf{X}_c$ não constituem duas técnicas diferentes. Elas fornecem duas formas de obter a mesma solução amostral da ACP.

Os escores também são obtidos diretamente pela SVD:

$$\begin{aligned} \mathbf{T}_r &= \mathbf{X}_c \mathbf{V}_r \\ &= \mathbf{U}_r \mathbf{D}_r. \end{aligned}$$

Assim, a SVD separa naturalmente os elementos da representação:

- $\mathbf{V}_r$ contém as direções principais no espaço das variáveis;
- $\mathbf{U}_r \mathbf{D}_r$ contém os escores das observações;
- $\mathbf{D}_r$ determina a magnitude da variabilidade em cada direção.

A centralização também limita o número de componentes com variância positiva. Como

$$\text{posto}(\mathbf{S}) = \text{posto}(\mathbf{X}_c) \leq \min(p, n - 1),$$

existem no máximo

$$\min(p, n - 1)$$

componentes principais com variância amostral positiva.

Quando $p \geq n$, a matriz $\mathbf{S}$ é necessariamente singular. Essa singularidade amostral já foi discutida no Módulo 2 e não impede a obtenção das componentes pela SVD. Ela indica que a nuvem centralizada ocupa um subespaço de dimensão não superior a $n - 1$.

14.11 Aproximação de posto reduzido

A SVD permite conectar diretamente a redução de dimensionalidade ao problema de aproximação matricial.

Mantendo apenas os $k < r$ primeiros termos,

$$\mathbf{X}_{c,k} = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Pelo Teorema de Eckart–Young–Mirsky de Teorema 6.2, $\mathbf{X}_{c,k}$ é uma melhor aproximação de $\mathbf{X}_c$ entre todas as matrizes de posto não superior a k , segundo a norma de Frobenius.

Além disso, pela relação entre projeção e SVD estabelecida em Proposição 6.19,

$$\mathbf{X}_{c,k} = \mathbf{X}_c \mathbf{V}_k \mathbf{V}_k^\top.$$

Como

$$\mathbf{T}_k = \mathbf{X}_c \mathbf{V}_k,$$

também se obtém

$$\mathbf{X}_{c,k} = \mathbf{T}_k \mathbf{V}_k^\top.$$

Essas três expressões representam o mesmo objeto:

$$\mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top = \mathbf{X}_c \mathbf{V}_k \mathbf{V}_k^\top = \mathbf{T}_k \mathbf{V}_k^\top.$$

A primeira expressão mostra a aproximação de posto reduzido; a segunda mostra a projeção sobre o subespaço principal; a terceira mostra a reconstrução a partir dos escores e das direções principais.

O erro quadrático total da aproximação é

$$\|\mathbf{X}_c - \mathbf{X}_{c,k}\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

Como

$$d_j^2 = (n-1)\hat{\lambda}_j,$$

segue que

$$\|\mathbf{X}_c - \mathbf{X}_{c,k}\|_F^2 = (n-1) \sum_{j=k+1}^r \hat{\lambda}_j.$$

A parcela da soma de quadrados preservada pela aproximação é

$$\frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2} = \frac{\sum_{j=1}^k \hat{\lambda}_j}{\sum_{j=1}^r \hat{\lambda}_j}.$$

Essa expressão coincide com a proporção de variância observada representada pelas primeiras k componentes.

A equivalência entre as formulações pode ser resumida pela Tabela 14.3.

Tabela 14.3: Formulações relacionadas da Análise de Componentes Principais.

Formulação	Objeto otimizado ou decomposto	Solução
Variância	$\mathbf{a}^\top \Sigma \mathbf{a}$ ou $\mathbf{a}^\top \mathbf{S} \mathbf{a}$	Autovetores associados aos maiores autovalores

Formulação	Objeto otimizado ou decomposto	Solução
Subespaço	Variância total da projeção em dimensão k	Subespaço gerado pelas primeiras k direções
Reconstrução	Erro quadrático da representação	Projeção sobre o subespaço principal
SVD	Matriz de dados centralizada $\mathbf{X}_c$	Vetores singulares à direita e SVD truncada
Aproximação matricial	$\ \mathbf{X}_c - \mathbf{B}\ _F$ com $\text{posto}(\mathbf{B}) \leq k$	$\mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top$

A ACP pode, portanto, ser compreendida simultaneamente como um problema estatístico de preservação da variabilidade, um problema geométrico de projeção e um problema matricial de aproximação de posto reduzido. Os resultados dos Módulos 1 e 2 mostram por que essas três perspectivas conduzem à mesma solução.

14.12 ACP baseada na matriz de correlações

A formulação anterior utiliza a matriz de covariâncias. Quando as variáveis possuem escalas ou unidades de medida diferentes, pode ser definido outro problema: realizar a ACP após padronizar cada variável para variância unitária.

A matriz de correlações populacional $\mathcal{R}$ foi definida em Definição 8.5, e sua correspondente observada $\mathbf{R}$ em Definição 8.12.

No nível observado,

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2},$$

em que

$$\mathbf{D}_S = \text{diag}(s_{11}, \dots, s_{pp}).$$

O Módulo 2 estabeleceu em Equação 8.71 a relação entre a matriz de correlações e as colunas centralizadas e padronizadas. Para manter essa notação distinta da matriz de delineamento $\mathbf{Z}$ utilizada em Definição 11.3, neste capítulo denotaremos a matriz padronizada por

$$\mathbf{X}_{\text{pad}} = \mathbf{X}_c \mathbf{D}_S^{-1/2}.$$

Assim,

$$\mathbf{R} = \frac{1}{n-1} \mathbf{X}_{\text{pad}}^{\top} \mathbf{X}_{\text{pad}}.$$

Realizar a ACP de $\mathbf{R}$ equivale, portanto, a realizar a ACP sobre as colunas centralizadas e padronizadas de $\mathbf{X}$.

Se

$$\mathbf{R} = \mathbf{A}_R \Lambda_R \mathbf{A}_R^{\top},$$

as direções principais são obtidas no espaço das variáveis padronizadas. Os autovalores

$$\lambda_{R1}, \dots, \lambda_{Rp}$$

representam as variâncias das componentes construídas a partir dessas variáveis.

Como a diagonal de $\mathbf{R}$ é formada por valores iguais a 1,

$$\text{tr}(\mathbf{R}) = p.$$

Logo,

$$\sum_{j=1}^p \lambda_{Rj} = p.$$

A proporção da variância padronizada representada pela componente j é

$$\frac{\lambda_{Rj}}{p},$$

e a proporção acumulada nas primeiras k componentes é

$$\frac{\sum_{j=1}^k \lambda_{Rj}}{p}.$$

A utilização de $\mathbf{S}$ ou $\mathbf{R}$ corresponde a **duas formulações diferentes da ACP**.

Na ACP baseada em $\mathbf{S}$, as variáveis preservam suas escalas e variâncias originais. Uma variável com maior variabilidade pode exercer maior influência sobre as primeiras componentes.

Na ACP baseada em $\mathbf{R}$, todas as variáveis entram na análise com variância unitária. As diferenças de escala marginal são removidas antes da decomposição.

A Tabela 14.4 resume essa distinção.

Tabela 14.4: Diferenças entre a ACP baseada em covariâncias e em correlações.

Aspecto	ACP por covariâncias	ACP por correlações
Matriz de entrada	S	R
Dados equivalentes	Centralizados	Centralizados e padronizados
Variâncias marginais	Mantidas nas unidades originais	Iguais a 1
Variância total	$\text{tr}(\mathbf{S})$	p
Influência da escala	Preservada	Removida pela padronização
Problema resolvido	Representar a variabilidade nas escalas originais	Representar a variabilidade após igualar as escalas marginais

A Figura 14.4 ilustra o efeito da padronização. Os dois painéis representam as mesmas observações, antes e depois da padronização marginal. A mudança das escalas altera a geometria e, conseqüentemente, as direções principais.




Figura 14.4: A ACP baseada em covariâncias preserva as escalas originais, enquanto a ACP baseada em correlações utiliza a geometria das variáveis padronizadas.

A seta vermelha representa a primeira direção principal em cada geometria. A padronização remove as diferenças de escala marginal entre as variáveis e, nesse exemplo, modifica a direção que maximiza a variância.

A escolha entre as duas matrizes faz parte da definição do problema estatístico. Ela não deve ser tratada como uma decisão puramente computacional.

A padronização modifica a geometria da nuvem de dados por meio de um escalonamento diferente em cada eixo. Consequentemente, os autovetores, os autovalores, os escores e o subespaço principal podem mudar.

Essa distinção será importante também no próximo capítulo. A Análise Fatorial pode ser formulada sobre uma matriz de covariâncias ou de correlações, mas seu objetivo será diferente: em vez de decompor a variabilidade total em direções principais, será especificado um modelo para a estrutura de covariação entre as variáveis.

14.13 Interpretação geométrica da ACP

A formulação espectral da ACP possui uma interpretação geométrica direta. A matriz

$$\mathbf{A} = (\mathbf{a}_1 \quad \cdots \quad \mathbf{a}_p)$$

é ortogonal e suas colunas formam uma base ortonormal de $\mathbb{R}^p$. A transformação

$$\mathbf{Y} = \mathbf{A}^\top (\mathbf{X} - \mu)$$

expressa o vetor centralizado em relação a essa nova base.

Quando todas as p componentes são mantidas, não há redução de dimensão nem perda de informação. A transformação corresponde a uma mudança ortogonal de coordenadas. Comprimentos, ângulos e distâncias euclidianas são preservados, conforme as propriedades das transformações ortogonais desenvolvidas no Módulo 1.

A mudança de base possui uma finalidade específica: alinhar os novos eixos às direções de dispersão determinadas pela matriz de covariâncias. No sistema original, a matriz Σ pode possuir elementos fora da diagonal. No sistema das componentes principais,

$$\text{Cov}(\mathbf{Y}) = \Lambda,$$

e a estrutura de covariâncias torna-se diagonal.

Geometricamente, a ACP escolhe os eixos principais da dispersão.

A Figura 14.5 compara a mesma nuvem no sistema das variáveis originais e no sistema das componentes principais. No primeiro, a dispersão está inclinada em relação aos eixos coordenados. No segundo, os eixos coincidem com as direções principais e a matriz de covariâncias é diagonal.




Figura 14.5: A transformação completa para componentes principais representa a mesma nuvem em uma base ortonormal alinhada às direções de dispersão.

A transformação ortogonal completa preserva a geometria da nuvem. A diferença está na orientação dos eixos. No sistema das componentes, a dispersão está alinhada às coordenadas e as covariâncias entre componentes são nulas.

14.13.1 Relação com o elipsoide de covariâncias

A geometria da matriz de covariâncias foi estudada no Módulo 2. O elipsoide definido por Σ possui eixos orientados pelos autovetores e extensões determinadas pelos autovalores, como apresentado em Equação 8.33 e ilustrado em Figura 8.3.

A Figura 8.3, construída no estudo da geometria da matriz de covariâncias, pode agora ser reinterpretada em termos da ACP: seus eixos espectrais são as direções das componentes principais e os quadrados de suas extensões são proporcionais aos respectivos autovalores.

A ACP utiliza exatamente essas direções.

A primeira componente principal está associada ao eixo de maior dispersão do elipsoide. A segunda está associada ao eixo ortogonal de segunda maior dispersão, e assim sucessivamente.

Portanto, a decomposição

$$\Sigma = \mathbf{A}\mathbf{\Lambda}\mathbf{A}^\top$$

possui duas leituras complementares:

- estatisticamente, λ_j é a variância da componente Y_j ;
- geometricamente, $\mathbf{a}_j$ determina uma direção principal da dispersão.

A transformação completa apenas realinha os eixos de coordenadas com os eixos do elipsoide.

14.13.2 Redução de dimensão como projeção

A redução de dimensão foi formalizada em Proposição 14.2 e representada geometricamente em Figura 14.3. Manter as primeiras k componentes equivale a substituir cada observação centralizada por sua projeção ortogonal sobre o subespaço principal $\mathcal{S}_k$.

A variabilidade preservada corresponde às primeiras k direções, enquanto a parcela descartada pertence ao complemento ortogonal. Essa construção reúne os resultados do Módulo 1 sobre projeções, decomposição espectral e aproximação de posto reduzido e lhes atribui uma função específica na ACP.

14.14 Coeficientes e relação das variáveis com as componentes

Os elementos do vetor

$$\mathbf{a}_j = \begin{pmatrix} a_{1j} \\ \vdots \\ a_{pj} \end{pmatrix}$$

são os **coeficientes da j -ésima componente principal**. Eles definem a combinação linear

$$Y_j = \sum_{i=1}^p a_{ij} (X_i - \mu_i).$$

Esses coeficientes determinam a direção da componente no espaço das variáveis. Eles não devem ser confundidos com as correlações entre as variáveis originais e a componente.

A relação entre esses dois objetos pode ser obtida diretamente a partir da matriz de covariâncias.

Para a variável X_i ,

$$\begin{aligned} \text{Cov}(X_i, Y_j) &= \text{Cov} \left[X_i, \mathbf{a}_j^\top (\mathbf{X} - \boldsymbol{\mu}) \right] \\ &= \mathbf{e}_i^\top \boldsymbol{\Sigma} \mathbf{a}_j. \end{aligned}$$

Como

$$\Sigma \mathbf{a}_j = \lambda_j \mathbf{a}_j,$$

segue que

$$\text{Cov}(X_i, Y_j) = \lambda_j a_{ij}.$$

Além disso,

$$\text{Var}(Y_j) = \lambda_j$$

e

$$\text{Var}(X_i) = \sigma_{ii}.$$

Logo,

$$\text{Corr}(X_i, Y_j) = \frac{\sqrt{\lambda_j} a_{ij}}{\sqrt{\sigma_{ii}}}.$$

Proposição 14.3 (Correlação entre uma variável e uma componente principal). *Na ACP populacional baseada na matriz de covariâncias,*

$$\text{Corr}(X_i, Y_j) = \frac{\sqrt{\lambda_j} a_{ij}}{\sqrt{\sigma_{ii}}}.$$

Na ACP baseada na matriz de correlações, considere a variável padronizada $X_{i,\text{pad}}$ e a componente Y_{Rj} construída a partir do autovetor $\mathbf{a}_{Rj}$ de $\mathcal{R}$. Como

$$\text{Var}(X_{i,\text{pad}}) = 1,$$

tem-se

$$\text{Corr}(X_{i,\text{pad}}, Y_{Rj}) = \sqrt{\lambda_{Rj}} a_{R,ij}.$$

A expressão mostra que o coeficiente a_{ij} e a correlação entre X_i e Y_j representam objetos diferentes.

A diferença entre os coeficientes da componente e as correlações com as variáveis pode ser visualizada na Figura 14.6. O exemplo utiliza uma matriz de covariâncias com variâncias marginais diferentes.




Figura 14.6: Os coeficientes definem a direção da componente, enquanto as correlações medem a associação de cada variável com a componente.

Os coeficientes pertencem ao vetor unitário que define a direção principal. As correlações dependem também da variância da componente e da variância de cada variável. Por isso, as duas medidas não são intercambiáveis.

O coeficiente indica a participação da variável na **definição da direção**. A correlação indica a intensidade da **associação linear da variável com a componente construída**.

Essa distinção será importante no capítulo seguinte. Na Análise Fatorial, as cargas fatoriais pertencem ao próprio modelo de covariâncias e terão interpretação diferente dos coeficientes de uma componente principal.

Na formulação amostral baseada em $\mathbf{S}$,

$$\widehat{\text{Corr}}(X_i, Y_j) = \frac{\sqrt{\hat{\lambda}_j} \hat{a}_{ij}}{\sqrt{s_{ii}}}.$$

Quando a ACP é realizada sobre $\mathbf{R}$, cada variável padronizada possui variância observada igual a 1. Denotando por $X_{i,\text{pad}}$ a variável padronizada e por Y_{Rj} a componente correspondente,

$$\widehat{\text{Corr}}(X_{i,\text{pad}}, Y_{Rj}) = \sqrt{\hat{\lambda}_{Rj}} \hat{a}_{R,ij}.$$

A interpretação substantiva das componentes pode utilizar conjuntamente os coeficientes e as associações das variáveis com as componentes. A formulação matemática deve preservar a distinção entre os dois objetos.

14.15 Propriedades da solução

A ACP herda propriedades da matriz de covariâncias e da decomposição espectral. Algumas delas possuem consequências diretas para a interpretação das componentes.

14.15.1 Invariância a translações

Considere uma transformação de localização

$$\mathbf{X}^* = \mathbf{X} + \mathbf{c},$$

com $\mathbf{c} \in \mathbb{R}^p$ constante.

A média passa a ser

$$\mu^* = \mu + \mathbf{c},$$

mas

$$\mathbf{X}^* - \mu^* = \mathbf{X} - \mu.$$

Consequentemente,

$$\text{Cov}(\mathbf{X}^*) = \Sigma.$$

As direções principais e os autovalores não se alteram. A ACP baseada em covariâncias é, portanto, invariante a translações.

A centralização não modifica a dispersão; ela apenas desloca a origem para o centro da nuvem.

14.15.2 Dependência da escala

A invariância a translações não se estende a mudanças individuais de escala.

Considere

$$\mathbf{X}^* = \mathbf{D}\mathbf{X},$$

em que $\mathbf{D}$ é diagonal e contém fatores de escala diferentes para as variáveis.

A nova matriz de covariâncias é

$$\Sigma^* = \mathbf{D}\Sigma\mathbf{D}.$$

Em geral, os autovetores de Σ^* não coincidem com os de Σ . Assim, uma mudança nas unidades de medida pode alterar as componentes principais obtidas a partir da matriz de covariâncias.

Essa propriedade explica a diferença entre ACP por covariâncias e ACP por correlações. A padronização não é uma operação neutra: ela redefine a geometria na qual a variabilidade será medida.

14.15.3 Indeterminação do sinal

Se

$$\Sigma\mathbf{a}_j = \lambda_j\mathbf{a}_j,$$

então

$$\Sigma(-\mathbf{a}_j) = \lambda_j(-\mathbf{a}_j).$$

Portanto, $\mathbf{a}_j$ e $-\mathbf{a}_j$ representam a mesma direção principal.

Se o sinal do vetor de coeficientes for invertido,

$$Y_j = \mathbf{a}_j^\top \mathbf{X}_c$$

passa a ser

$$Y_j^* = -Y_j.$$

Os escores também mudam de sinal, mas a variância, o subespaço gerado e a qualidade da representação permanecem inalterados.

A orientação positiva ou negativa de um eixo principal é, portanto, arbitrária.

Essa propriedade é especialmente importante na comparação de resultados produzidos por diferentes programas ou diferentes decomposições numéricas. Duas soluções podem apresentar sinais opostos e ainda representar exatamente a mesma componente.

14.15.4 Multiplicidade de autovalores

A situação muda quando um autovalor possui multiplicidade maior que um.

Os conceitos de multiplicidade algébrica e geométrica foram definidos em Definição 5.5. Como Σ é simétrica, o Teorema Espectral garante uma base ortonormal em cada autoespaço.

Considere, por exemplo,

$$\lambda_j = \lambda_{j+1}.$$

Nesse caso, qualquer base ortonormal do autoespaço associado pode ser utilizada. Os vetores

$$\mathbf{a}_j \quad \text{e} \quad \mathbf{a}_{j+1}$$

não são individualmente determinados de forma única.

O objeto definido de forma única é o **subespaço associado ao autovalor repetido**.

Essa distinção afeta a interpretação. Quando um autovalor é simples, sua direção principal é determinada até mudança de sinal. Quando há multiplicidade, diferentes rotações ortogonais dentro do autoespaço produzem conjuntos diferentes de autovetores igualmente válidos.

A ACP identifica, nesse caso, o subespaço de variabilidade, e não eixos individuais únicos.

A não unicidade das bases de um autoespaço com multiplicidade foi ilustrada em Figura 5.2. Na ACP, essa propriedade implica que um autovalor repetido identifica o subespaço correspondente, mas não uma direção principal individual única.

14.15.5 Autovalores próximos

Mesmo sem igualdade exata, autovalores muito próximos podem produzir direções amostrais instáveis.

Se duas variâncias principais populacionais são semelhantes, pequenas alterações na matriz de covariâncias observada podem modificar consideravelmente os autovetores estimados, embora o subespaço formado por essas direções permaneça relativamente estável.

A Figura 14.7 compara duas estruturas de covariância. No primeiro painel, a diferença entre os autovalores produz um eixo principal claramente destacado. No segundo, os autovalores próximos produzem uma dispersão quase circular, de modo que a orientação dos eixos individuais é menos determinada pela estrutura da nuvem.




Figura 14.7: Autovalores bem separados determinam direções principais marcadas; autovalores próximos produzem uma geometria em que as direções individuais são menos distintas.

A separação entre os autovalores determina quão distinta é a orientação associada a cada eixo. Quando os autovalores são próximos, pequenas alterações da matriz de covariâncias podem produzir mudanças perceptíveis nos autovetores, mesmo com pouca alteração do subespaço por eles gerado.

Esse comportamento diferencia a estabilidade dos **autovalores**, dos **autovetores individuais** e dos **subespaços principais**. A interpretação de uma componente isolada exige maior cuidado quando não há separação clara entre os autovalores correspondentes (Anderson, 2003).

14.15.6 Singularidade e dimensão efetiva

A matriz de covariâncias pode ser singular. O Módulo 2 relacionou essa situação à existência de combinações lineares com variância zero em Proposição 8.3.

Se

$$\text{posto}(\Sigma) = r < p,$$

então apenas r autovalores são positivos:

$$\lambda_1 \geq \dots \geq \lambda_r > 0$$

e

$$\lambda_{r+1} = \dots = \lambda_p = 0.$$

A variabilidade populacional está inteiramente contida em um subespaço de dimensão r .

As componentes associadas aos autovalores nulos possuem variância zero e não acrescentam uma nova dimensão de variabilidade.

Nesse caso, a redução de p para r dimensões pode ser realizada sem perda de variância.

No nível amostral, a centralização impõe

$$\text{posto}(\mathbf{X}_c) \leq n - 1.$$

Por isso,

$$\text{posto}(\mathbf{S}) \leq \min(p, n - 1).$$

Quando

$$p \geq n,$$

a matriz de covariâncias observada é necessariamente singular. A SVD permite representar diretamente o subespaço de variabilidade observado sem exigir a inversão de $\mathbf{S}$.

14.16 Papel da distribuição probabilística

A definição das componentes principais depende da existência da matriz de covariâncias. Portanto, a formulação populacional exige momentos de segunda ordem finitos.

Não é necessário assumir

$$\mathbf{X} \sim N_p(\mu, \Sigma)$$

para definir

$$Y_j = \mathbf{a}_j^\top (\mathbf{X} - \mu),$$

obter os autovalores de Σ ou construir o subespaço principal.

A ACP é, nesse sentido, uma técnica espectral definida a partir da estrutura de segunda ordem.

A normalidade produz consequências adicionais.

Se

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

então, pela propriedade de transformação afim da normal multivariada apresentada em Proposição 9.5,

$$\mathbf{Y} = \mathbf{A}^\top (\mathbf{X} - \mu)$$

também é normal multivariado:

$$\mathbf{Y} \sim N_p(\mathbf{0}, \Lambda).$$

Como sua matriz de covariâncias é diagonal, o resultado de independência para blocos normais de Proposição 9.7 implica independência entre as componentes.

Assim, sob normalidade,

$$Y_j \perp Y_\ell, \quad j \neq \ell.$$

Sem normalidade conjunta, a ACP garante desconexão,

$$\text{Cov}(Y_j, Y_\ell) = 0,$$

mas não independência.

Essa distinção é importante porque a propriedade definidora da ACP é a organização da variância e da covariância, não a independência probabilística das componentes.

14.17 Formulação descritiva e formulação inferencial

A ACP pode ser utilizada em dois contextos conceitualmente distintos.

Na formulação **descritiva**, a matriz de dados observada é o objeto de interesse. A decomposição procura representar aquela configuração de observações em dimensão menor. Autovalores, direções e escores descrevem a estrutura presente nos dados.

Na formulação **populacional**, existe uma matriz de covariâncias Σ que caracteriza uma população, e as componentes principais populacionais são parâmetros derivados de sua decomposição espectral. A matriz $\mathbf{S}$ fornece então uma estimativa de Σ , e seus autovalores e autovetores são utilizados para estimar as quantidades populacionais correspondentes.

Essa distinção utiliza os conceitos de parâmetro, estimador e estimativa desenvolvidos no Capítulo 10.

Os objetos

$$\lambda_j \quad \text{e} \quad \mathbf{a}_j$$

são características da matriz populacional, enquanto

$$\hat{\lambda}_j \quad \text{e} \quad \hat{\mathbf{a}}_j$$

são obtidos da amostra.

A inferência sobre componentes principais envolve a variabilidade amostral desses objetos. Sob condições adequadas, os autovalores e subespaços estimados convergem para seus correspondentes populacionais. A teoria clássica sob normalidade fornece distribuições e aproximações inferenciais para autovalores e autovetores (Anderson, 2003).

A identificação de uma direção populacional individual exige que seu autovalor esteja separado dos demais. Quando existem autovalores repetidos, a inferência deve ser formulada para o autoespaço correspondente, pois não há um autovetor populacional individualmente identificado.

O desenvolvimento das distribuições específicas de autovalores e autovetores não é necessário para a formulação da técnica. O papel da inferência neste capítulo é estabelecer que a solução amostral pode ser interpretada como estimativa de uma estrutura populacional quando existe um modelo amostral adequado.

14.18 Limites da representação por componentes principais

A ACP resolve um problema definido de forma precisa: encontrar combinações lineares e subespaços que preservem variabilidade segundo uma matriz de covariâncias ou correlações. Os limites da técnica decorrem diretamente dessa formulação e são sintetizados na Tabela 14.5.

Tabela 14.5: Limites decorrentes da formulação clássica da Análise de Componentes Principais.

Aspecto	Consequência para a ACP
Critério de importância	As componentes são ordenadas pela variância. Uma direção de pequena variabilidade pode ser relevante para outro objetivo estatístico.
Estrutura representada	As componentes são combinações lineares e utilizam covariâncias ou correlações. Estruturas essencialmente não lineares podem não ser concentradas em poucas componentes.
Conjunto de variáveis	Inclusão, exclusão, transformação ou mudança de escala altera a matriz analisada e pode modificar toda a solução.
Sensibilidade da matriz de entrada	Valores extremos podem alterar variâncias, covariâncias, correlações e, consequentemente, autovalores e autovetores.
Redução de dimensão	Quando são descartadas direções com autovalores positivos, parte da variabilidade original deixa de ser representada.

Se

$$k < r,$$

a variabilidade descartada é

$$\sum_{j=k+1}^r \lambda_j$$

no nível populacional e

$$\sum_{j=k+1}^r \hat{\lambda}_j$$

no nível observado.

A redução preserva toda a variabilidade somente quando as dimensões excluídas possuem autovalores nulos. Nos demais casos, a ACP controla a perda segundo o critério de máxima variabilidade preservada, equivalentemente ao menor erro quadrático de reconstrução.

14.19 ACP e Análise Fatorial

A Análise de Componentes Principais e a Análise Fatorial aparecem frequentemente próximas porque ambas podem produzir representações de dimensão menor e ambas utilizam matrizes de covariâncias ou correlações. A semelhança da entrada não implica equivalência entre os problemas.

A ACP parte da decomposição espectral

$$\Sigma = \mathbf{A}\mathbf{\Lambda}\mathbf{A}^\top$$

e reorganiza a **variância total** em direções ortogonais.

A Análise Fatorial parte de outro objetivo. Sua formulação básica procura representar a matriz de covariâncias por

$$\Sigma = \Lambda_F \Lambda_F^\top + \Psi,$$

no modelo ortogonal, em que a primeira parcela representa a estrutura comum e Ψ representa variâncias específicas.

A Tabela 14.6 resume a distinção que será desenvolvida no capítulo seguinte.

Tabela 14.6: Distinção inicial entre Análise de Componentes Principais e Análise Fatorial.

Aspecto	Análise de Componentes Principais	Análise Fatorial
Problema central	Representar a variabilidade em poucas direções	Explicar a covariação por fatores latentes
Variabilidade considerada	Variância total	Variância comum e variância específica
Estrutura principal	Decomposição espectral	Modelo de covariâncias
Novas dimensões	Combinações lineares das variáveis observadas	Fatores não diretamente observados
Termo específico	Não integra a formulação básica	Representado por Ψ
Natureza da solução	Algébrica e geométrica	Modelo estatístico latente

A ACP responde ao problema de redução da variabilidade observada. A Análise Fatorial responderá ao problema de explicar a estrutura de covariâncias por fatores latentes.

Essa diferença define a transição para o próximo capítulo.

14.20 Síntese

A Análise de Componentes Principais transforma o problema de redução linear de dimensionalidade em uma decomposição da matriz de covariâncias ou correlações.

Para o vetor centralizado

$$\mathbf{X}_c = \mathbf{X} - \mu,$$

a componente

$$Y_j = \mathbf{a}_j^\top \mathbf{X}_c$$

possui variância

$$\text{Var}(Y_j) = \mathbf{a}_j^\top \Sigma \mathbf{a}_j.$$

A caracterização variacional estudada no Módulo 1 mostra que a maximização sucessiva dessa variância conduz aos autovetores de Σ . Os autovalores correspondentes são as variâncias das componentes:

$$\text{Var}(Y_j) = \lambda_j.$$

A transformação completa

$$\mathbf{Y} = \mathbf{A}^\top \mathbf{X}_c$$

é uma mudança ortogonal de base que diagonaliza a matriz de covariâncias. A redução de dimensão ocorre quando apenas as primeiras k direções são mantidas.

O subespaço principal

$$\mathcal{S}_k = \text{span} \{\mathbf{a}_1, \dots, \mathbf{a}_k\}$$

maximiza a variabilidade projetada em dimensão k . A projeção sobre esse subespaço minimiza a variabilidade descartada.

Na amostra,

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c,$$

e a SVD

$$\mathbf{X}_c = \mathbf{U} \mathbf{D} \mathbf{V}^\top$$

fornece diretamente as direções, os escores e a aproximação de posto reduzido. Pelo Teorema de Eckart–Young–Mirsky, a representação baseada nas primeiras k componentes também é uma melhor aproximação matricial de posto k segundo a norma de Frobenius.

A utilização da matriz de correlações corresponde à aplicação da mesma técnica às variáveis padronizadas. Essa escolha altera a geometria e pode alterar a solução.

A formulação da ACP exige a existência de momentos de segunda ordem, mas não normalidade multivariada. A normalidade acrescenta independência entre componentes e sustenta parte da teoria inferencial clássica. Autovalores simples identificam direções até mudança de sinal; autovalores repetidos identificam subespaços, e não autovetores individuais.

O capítulo utilizou diretamente resultados dos Módulos 1 e 2 sobre combinações lineares, projeções, decomposição espectral, SVD, aproximação de posto reduzido, covariâncias, correlações, normal multivariada e estimação. O próximo capítulo modifica o problema: a matriz de covariâncias deixará de ser apenas decomposta e passará a ser **modelada** por meio de fatores comuns e variâncias específicas.

15 Formulação da Análise Fatorial

A Análise Fatorial procura representar as dependências entre variáveis observadas por meio de um número menor de variáveis latentes, denominadas **fatores comuns**. A técnica parte da hipótese de que uma parcela da covariação entre as variáveis pode ser atribuída a esses fatores, enquanto a variabilidade restante é específica de cada variável (Lawley; Maxwell, 1971).

No capítulo anterior, a Análise de Componentes Principais foi formulada pela decomposição da variabilidade total em direções ortogonais. A distinção inicial entre ACP e Análise Fatorial foi sintetizada em Tabela 14.6. O problema agora é diferente. A matriz de covariâncias deixa de ser apenas decomposta e passa a ser representada por um **modelo estatístico**.

Os fundamentos necessários já foram desenvolvidos nos Módulos 1 e 2. Matrizes e transformações lineares permitem representar a contribuição dos fatores; a matriz de covariâncias descreve a estrutura que será modelada; posto e decomposições matriciais permitem estudar a dimensão da parcela comum; a distribuição normal multivariada fornecerá posteriormente uma formulação probabilística para estimação e inferência.

A estrutura central deste capítulo será

$$\Sigma = \Lambda\Lambda^\top + \Psi,$$

no modelo ortogonal, em que $\Lambda\Lambda^\top$ representa a parcela comum da covariância e Ψ representa a variabilidade específica.

Neste capítulo, Λ será utilizada exclusivamente para a matriz de cargas fatoriais. Quando forem necessárias matrizes diagonais de autovalores, será adotada outra notação.

Essa formulação introduz elementos que não aparecem na ACP: fatores não observados, variâncias específicas, identificação do modelo e indeterminação rotacional. A Análise Fatorial será construída a partir desses elementos e, posteriormente, relacionada à estimação por máxima verossimilhança e à obtenção de escores fatoriais.

15.1 O problema da estrutura latente

Considere o vetor aleatório

$$\mathbf{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_p \end{pmatrix} \in \mathbb{R}^p,$$

com vetor de médias

$$\mu = E(\mathbf{X})$$

e matriz de covariâncias populacional Σ , definida em Definição 8.2.

Os elementos fora da diagonal de Σ registram a associação linear entre pares de variáveis. Na Análise Fatorial, essas covariâncias são interpretadas a partir de uma hipótese estrutural: parte das relações entre as variáveis é produzida pela influência conjunta de um número menor de fatores não diretamente observados.

Considere

$$\mathbf{F} = \begin{pmatrix} F_1 \\ \vdots \\ F_m \end{pmatrix} \in \mathbb{R}^m,$$

com

$$m < p$$

na formulação usual de baixa dimensão.

As componentes de $\mathbf{F}$ são variáveis aleatórias latentes. Elas não correspondem a colunas observadas da matriz de dados. Sua existência é postulada pelo modelo para explicar a estrutura de covariâncias entre as variáveis observadas.

A redução de dimensão na Análise Fatorial possui, portanto, natureza diferente daquela obtida pela ACP. Na ACP, novas variáveis são construídas diretamente como combinações lineares das variáveis observadas. Na Análise Fatorial, as variáveis observadas são representadas como funções lineares de fatores latentes acrescidas de parcelas específicas.

A estrutura pode ser expressa esquematicamente como

$$\text{fatores comuns} \longrightarrow \text{variáveis observadas} \longleftarrow \text{componentes específicas}.$$

Os fatores comuns explicam a dependência compartilhada. As componentes específicas representam a parcela de cada variável que não é atribuída aos fatores comuns.

15.2 Modelo de fatores comuns

O modelo básico representa o vetor observado como a soma de três parcelas:

1. localização média;
2. contribuição dos fatores comuns;
3. contribuição específica.

Definição 15.1 (Modelo de fatores comuns). Considere um vetor aleatório $\mathbf{X} \in \mathbb{R}^p$ e um vetor de fatores comuns $\mathbf{F} \in \mathbb{R}^m$. O **modelo de fatores comuns** é

$$\mathbf{X} = \mu + \Lambda \mathbf{F} + \varepsilon, \quad (15.1)$$

em que

$$\Lambda \in \mathbb{R}^{p \times m}$$

é a matriz de cargas fatoriais e

$$\varepsilon = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_p \end{pmatrix} \in \mathbb{R}^p$$

é o vetor de componentes específicas.

Os elementos do modelo são organizados na Tabela 15.1.

Tabela 15.1: Elementos do modelo de fatores comuns.

Objeto	Dimensão	Função no modelo
$\mathbf{X}$	$p \times 1$	Vetor de variáveis observadas
μ	$p \times 1$	Vetor de médias
$\mathbf{F}$	$m \times 1$	Vetor de fatores comuns latentes
Λ	$p \times m$	Matriz de cargas fatoriais

Objeto	Dimensão	Função no modelo
ε	$p \times 1$	Vetor de componentes específicas
Ψ	$p \times p$	Matriz das variâncias específicas

A i -ésima variável pode ser escrita como

$$X_i = \mu_i + \lambda_{i1}F_1 + \lambda_{i2}F_2 + \cdots + \lambda_{im}F_m + \varepsilon_i. \quad (15.2)$$

A linha i da matriz de cargas será denotada por

$$\lambda_i^\top = (\lambda_{i1} \quad \cdots \quad \lambda_{im}).$$

Assim,

$$X_i - \mu_i = \lambda_i^\top \mathbf{F} + \varepsilon_i.$$

A carga λ_{ij} representa o coeficiente associado ao fator F_j na expressão linear da variável X_i . Sua interpretação depende da escala dos fatores, da escala das variáveis e da parametrização utilizada.

A Figura 15.1 representa a estrutura de um modelo com dois fatores e três variáveis observadas. As setas azuis representam as contribuições dos fatores comuns e as setas vermelhas representam as componentes específicas.

A figura mostra que a associação entre as variáveis pode ser representada por fatores compartilhados no modelo. As componentes específicas atuam individualmente sobre cada variável e, na formulação básica, não produzem covariâncias entre variáveis distintas.

15.3 Hipóteses do modelo ortogonal

A expressão em Equação 15.1 ainda não determina a estrutura de covariâncias. Para isso, são estabelecidas condições sobre os fatores e as componentes específicas.

Na formulação ortogonal padronizada dos fatores,

$$E(\mathbf{F}) = \mathbf{0},$$




Figura 15.1: Estrutura do modelo de fatores comuns: as variáveis observadas recebem contribuições dos fatores latentes e de componentes específicas.

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m.$$

As componentes específicas satisfazem

$$E(\varepsilon) = \mathbf{0}$$

e

$$\text{Cov}(\varepsilon) = \Psi,$$

com

$$\Psi = \text{diag}(\psi_1, \dots, \psi_p), \quad \psi_i \geq 0.$$

Além disso,

$$\text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0}.$$

Essas condições são reunidas na definição seguinte.

Definição 15.2 (Modelo fatorial ortogonal). O modelo de fatores comuns em Equação [15.1](#) é denominado **ortogonal** quando

$$E(\mathbf{F}) = \mathbf{0}, \quad \text{Cov}(\mathbf{F}) = \mathbf{I}_m,$$

$$E(\varepsilon) = \mathbf{0}, \quad \text{Cov}(\varepsilon) = \Psi,$$

com Ψ diagonal, e

$$\text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0}.$$

A condição

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m$$

fixa a escala dos fatores e estabelece covariâncias nulas entre fatores distintos. A ortogonalidade, nesse contexto, refere-se à estrutura de covariâncias dos fatores.

A diagonalidade de Ψ estabelece

$$\text{Cov}(\varepsilon_i, \varepsilon_j) = 0, \quad i \neq j.$$

Consequentemente, a parte específica do modelo não acrescenta covariância entre variáveis distintas.

Essa condição estabelece **não correlação** entre as componentes específicas. Independência entre elas exige hipóteses probabilísticas adicionais. Quando posteriormente for adotado um modelo normal conjunto com componentes específicas independentes, a interpretação poderá ser fortalecida para independência.

A condição

$$\text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0}$$

separa, em termos de covariância, a parcela comum da parcela específica.

Essas hipóteses são suficientes para obter a estrutura de segunda ordem que define o modelo fatorial básico. A normalidade multivariada não é necessária para essa decomposição da covariância. Seu papel aparecerá posteriormente na formulação por máxima verossimilhança e na distribuição condicional dos fatores.

15.4 Estrutura da matriz de covariâncias

A consequência central do modelo pode ser obtida diretamente a partir das propriedades de covariância desenvolvidas no Módulo 2.

De Equação 15.1,

$$\mathbf{X} - \mu = \Lambda \mathbf{F} + \varepsilon.$$

Como

$$E(\mathbf{F}) = \mathbf{0}$$

e

$$E(\varepsilon) = \mathbf{0},$$

segue que

$$E(\mathbf{X}) = \mu.$$

Para a matriz de covariâncias,

$$\begin{aligned} \text{Cov}(\mathbf{X}) &= \text{Cov}(\Lambda \mathbf{F} + \varepsilon) \\ &= \Lambda \text{Cov}(\mathbf{F}) \Lambda^\top + \text{Cov}(\varepsilon) \\ &\quad + \Lambda \text{Cov}(\mathbf{F}, \varepsilon) + \text{Cov}(\varepsilon, \mathbf{F}) \Lambda^\top. \end{aligned}$$

A regra de transformação da covariância utilizada na primeira parcela foi desenvolvida em Proposição 8.6.

Pelas hipóteses do modelo ortogonal,

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m,$$

$$\text{Cov}(\varepsilon) = \Psi$$

e

$$\text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0}.$$

Portanto,

$$\Sigma = \Lambda \Lambda^\top + \Psi. \tag{15.3}$$

Proposição 15.1 (Estrutura de covariâncias do modelo fatorial ortogonal). *Sob as hipóteses de Definição 15.2, a matriz de covariâncias das variáveis observadas é*

$$\Sigma = \Lambda \Lambda^\top + \Psi.$$

A expressão em Equação 15.3 é o núcleo matemático da Análise Fatorial.

A matriz

$$\Lambda\Lambda^\top$$

é a **matriz de covariâncias comuns**. Como

$$\Lambda \in \mathbb{R}^{p \times m},$$

tem-se

$$\text{posto}(\Lambda\Lambda^\top) \leq m.$$

Assim, a estrutura comum é representada por uma matriz de posto limitado pelo número de fatores.

A matriz

$$\Psi = \text{diag}(\psi_1, \dots, \psi_p)$$

contém as variâncias específicas.

A decomposição

$$\Sigma = \underbrace{\Lambda\Lambda^\top}_{\text{estrutura comum}} + \underbrace{\Psi}_{\text{estrutura específica}}$$

mostra a diferença essencial em relação à ACP. A Análise Fatorial não procura uma decomposição espectral completa de Σ . Ela procura explicar sua estrutura por uma matriz comum de baixa dimensão acrescida de uma matriz diagonal de variâncias específicas.

15.4.1 Covariâncias entre variáveis

Considere duas variáveis distintas X_i e X_j . Pelo modelo,

$$X_i - \mu_i = \lambda_i^\top \mathbf{F} + \varepsilon_i$$

e

$$X_j - \mu_j = \lambda_j^\top \mathbf{F} + \varepsilon_j.$$

Sob as hipóteses do modelo ortogonal,

$$\text{Cov}(X_i, X_j) = \lambda_i^\top \lambda_j, \quad i \neq j.$$

Equivalentemente,

$$\sigma_{ij} = \sum_{h=1}^m \lambda_{ih} \lambda_{jh}, \quad i \neq j. \quad (15.4)$$

A covariância entre duas variáveis observadas é reproduzida pelo produto interno entre seus vetores de cargas.

Esse resultado fornece uma interpretação geométrica importante. As linhas de Λ podem ser vistas como vetores em $\mathbb{R}^m$. Variáveis cujos vetores de cargas apresentam grande produto interno positivo possuem covariância comum positiva; vetores com produto interno negativo correspondem a covariância comum negativa; vetores ortogonais possuem covariância comum nula no modelo ortogonal.

Essa geometria será representada mais adiante por meio dos vetores de cargas.

15.4.2 Variâncias das variáveis

Para uma variável X_i ,

$$\begin{aligned} \text{Var}(X_i) &= \text{Var}(\lambda_i^\top \mathbf{F} + \varepsilon_i) \\ &= \lambda_i^\top \lambda_i + \psi_i. \end{aligned}$$

Portanto,

$$\sigma_{ii} = \sum_{h=1}^m \lambda_{ih}^2 + \psi_i. \quad (15.5)$$

A variância de cada variável é decomposta em uma parcela comum e uma parcela específica.

15.5 Comunalidades e especificidades

A decomposição de Equação 15.5 permite definir duas quantidades próprias da Análise Fatorial.

Definição 15.3 (Comunalidade). No modelo fatorial ortogonal, a **comunalidade** da variável X_i é

$$h_i^2 = \lambda_i^\top \lambda_i = \sum_{h=1}^m \lambda_{ih}^2. \quad (15.6)$$

A comunalidade representa a parcela da variância de X_i atribuída aos fatores comuns.

Definição 15.4 (Especificidade). A **especificidade** da variável X_i é

$$\psi_i = \text{Var}(\varepsilon_i).$$

Assim,

$$\text{Var}(X_i) = h_i^2 + \psi_i. \quad (15.7)$$

A comunalidade e a especificidade pertencem à decomposição da variância de **cada variável**. Elas não correspondem à decomposição da variância total em componentes sucessivamente ordenadas, como ocorre na ACP.

Quando as variáveis estão padronizadas,

$$\text{Var}(X_i) = 1,$$

e, portanto,

$$1 = h_i^2 + \psi_i. \quad (15.8)$$

Nesse caso,

$$0 \leq h_i^2 \leq 1$$

e

$$0 \leq \psi_i \leq 1.$$

Uma comunalidade elevada indica que grande parcela da variabilidade da variável é representada pela estrutura comum do modelo. Uma comunalidade pequena indica que a maior parcela da variabilidade permanece específica da variável.

A soma das comunalidades pode ser escrita como

$$\sum_{i=1}^p h_i^2 = \text{tr}(\Lambda\Lambda^\top).$$

Como

$$\text{tr}(\Sigma) = \text{tr}(\Lambda\Lambda^\top) + \text{tr}(\Psi),$$

a variância total também admite a decomposição

$$\text{tr}(\Sigma) = \sum_{i=1}^p h_i^2 + \sum_{i=1}^p \psi_i. \quad (15.9)$$

A interpretação dessa identidade difere daquela utilizada na ACP. Na ACP, os autovalores distribuem a variância total entre componentes principais. Na Análise Fatorial, a decomposição separa a variabilidade atribuída à estrutura comum da variabilidade específica das variáveis.

Exemplo 15.1 (Modelo com um fator comum). Considere três variáveis padronizadas representadas por um único fator comum,

$$\mathbf{X} = \Lambda F + \varepsilon,$$

com

$$\Lambda = \begin{pmatrix} 0,80 \\ 0,70 \\ 0,60 \end{pmatrix}$$

e

$$\Psi = \begin{pmatrix} 0,36 & 0 & 0 \\ 0 & 0,51 & 0 \\ 0 & 0 & 0,64 \end{pmatrix}.$$

As comunalidades são

$$h_1^2 = 0,80^2 = 0,64,$$

$$h_2^2 = 0,70^2 = 0,49$$

e

$$h_3^2 = 0,60^2 = 0,36.$$

Como as variáveis são padronizadas,

$$h_i^2 + \psi_i = 1$$

para cada variável.

A matriz de covariâncias comuns é

$$\Lambda\Lambda^\top = \begin{pmatrix} 0,64 & 0,56 & 0,48 \\ 0,56 & 0,49 & 0,42 \\ 0,48 & 0,42 & 0,36 \end{pmatrix}.$$

Somando as variâncias específicas,

$$\mathcal{R} = \Lambda\Lambda^\top + \Psi = \begin{pmatrix} 1 & 0,56 & 0,48 \\ 0,56 & 1 & 0,42 \\ 0,48 & 0,42 & 1 \end{pmatrix}.$$

As correlações entre variáveis distintas são reproduzidas exclusivamente pelo fator comum. Por exemplo,

$$\text{Corr}(X_1, X_2) = 0,80 \times 0,70 = 0,56.$$

A primeira variável apresenta comunalidade 0,64, de modo que 64% de sua variância padronizada é atribuída ao fator comum e 36% permanece na componente específica. Para a terceira variável, essas parcelas são 36% e 64%, respectivamente.

O exemplo mostra que a Análise Fatorial procura reconstruir simultaneamente as covariâncias entre as variáveis e a decomposição de suas variâncias em parcelas comum e específica.

15.6 Cargas fatoriais e associação com os fatores

A matriz Λ ocupa uma posição central no modelo. Seus elementos aparecem tanto na representação das variáveis quanto na matriz de covariâncias reproduzida.

No modelo ortogonal,

$$\text{Cov}(\mathbf{X}, \mathbf{F}) = \text{Cov}(\Lambda \mathbf{F} + \varepsilon, \mathbf{F}).$$

Como

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m$$

e

$$\text{Cov}(\varepsilon, \mathbf{F}) = \mathbf{0},$$

segue que

$$\text{Cov}(\mathbf{X}, \mathbf{F}) = \Lambda. \quad (15.10)$$

Portanto,

$$\text{Cov}(X_i, F_j) = \lambda_{ij}.$$

Essa igualdade decorre da parametrização em que os fatores possuem variância unitária.

A carga fatorial coincide com a correlação entre X_i e F_j somente quando a variável observada também possui variância unitária. De forma geral,

$$\text{Corr}(X_i, F_j) = \frac{\lambda_{ij}}{\sqrt{\sigma_{ii}}}. \quad (15.11)$$

Para variáveis padronizadas,

$$\sigma_{ii} = 1,$$

e então

$$\text{Corr}(X_i, F_j) = \lambda_{ij}.$$

Essa distinção é semelhante àquela estabelecida no capítulo anterior entre coeficientes das componentes principais e correlações das variáveis com as componentes. Na Análise Fatorial, entretanto, as cargas são parâmetros do próprio modelo de covariâncias.

A formulação construída até este ponto mostra que o problema da estrutura latente pode ser reduzido à representação

$$\Sigma = \Lambda\Lambda^\top + \Psi.$$

O passo seguinte consiste em analisar a geometria da matriz de cargas e uma propriedade que distingue profundamente a Análise Fatorial da ACP: diferentes matrizes de cargas podem produzir exatamente a mesma estrutura de covariâncias. Essa indeterminação conduz ao problema de identificação e às rotações fatoriais.

15.7 Geometria das cargas fatoriais

No modelo ortogonal, cada linha da matriz de cargas

$$\lambda_i^\top = (\lambda_{i1} \quad \cdots \quad \lambda_{im})$$

pode ser representada como um vetor em $\mathbb{R}^m$.

Essa representação reúne duas propriedades obtidas anteriormente:

$$h_i^2 = \lambda_i^\top \lambda_i = \|\lambda_i\|^2$$

e, para $i \neq j$,

$$\sigma_{ij} = \lambda_i^\top \lambda_j.$$

Portanto, o comprimento do vetor de cargas da variável X_i determina sua comunalidade, enquanto o produto interno entre os vetores de cargas de duas variáveis determina a covariância comum reproduzida entre elas.

Escrevendo

$$\lambda_i^\top \lambda_j = \|\lambda_i\| \|\lambda_j\| \cos(\theta_{ij}),$$

a covariância comum depende simultaneamente dos comprimentos dos vetores e do ângulo entre eles.

Vetores próximos em direção produzem produto interno positivo. Vetores orientados em sentidos aproximadamente opostos produzem produto interno negativo. Vetores aproximadamente ortogonais produzem pequena covariância comum.

A Figura 15.2 representa quatro variáveis em um modelo com dois fatores. O comprimento de cada vetor está associado à comunalidade e sua orientação descreve a relação da variável com os fatores.

Os vetores de X_1 e X_2 apresentam orientações semelhantes e, portanto, produto interno positivo. A variável X_3 está mais associada à segunda direção fatorial. A posição de X_4 mostra que uma variável pode apresentar sinais diferentes de associação com os dois fatores.

O círculo unitário fornece uma referência geométrica para variáveis padronizadas. Nesse caso,

$$h_i^2 \leq 1,$$

de modo que os vetores de cargas permanecem no interior ou sobre a circunferência.

Essa representação não transforma os fatores em variáveis observadas. Ela representa os parâmetros que relacionam cada variável observada às dimensões latentes especificadas pelo modelo.

15.8 Matriz de covariâncias comuns

A estrutura fatorial pode ser isolada pela diferença entre a matriz total de covariâncias e a matriz de especificidades.

Defina

$$\Sigma_{\text{com}} = \Sigma - \Psi.$$

Pela Equação 15.3,

$$\Sigma_{\text{com}} = \Lambda \Lambda^\top. \quad (15.12)$$




Figura 15.2: Geometria das cargas em um modelo com dois fatores. O comprimento de cada vetor determina a communalidade e o produto interno entre vetores determina a covariância comum entre as variáveis.

Definição 15.5 (Matriz de covariâncias comuns). No modelo fatorial ortogonal, a **matriz de covariâncias comuns** é

$$\Sigma_{\text{com}} = \Lambda \Lambda^\top.$$

Seus elementos diagonais são as comunalidades e seus elementos fora da diagonal são as covariâncias reproduzidas pelos fatores comuns.

A diagonal de Σ_{com} é

$$\text{diag}(\Sigma_{\text{com}}) = \begin{pmatrix} h_1^2 \\ \vdots \\ h_p^2 \end{pmatrix},$$

enquanto, para $i \neq j$,

$$(\Sigma_{\text{com}})_{ij} = \sigma_{ij}.$$

Na formulação populacional exata do modelo básico, toda covariância entre variáveis distintas é atribuída aos fatores comuns. As variâncias possuem uma parcela adicional representada por Ψ .

Quando as variáveis são padronizadas,

$$\Sigma = \mathcal{R},$$

e a matriz comum possui diagonal formada pelas comunalidades:

$$\mathcal{R}_{\text{com}} = \mathcal{R} - \Psi.$$

Como Ψ é diagonal, $\mathcal{R}_{\text{com}}$ e $\mathcal{R}$ possuem os mesmos elementos fora da diagonal. A diferença ocorre na diagonal: os valores unitários de $\mathcal{R}$ são substituídos pelas comunalidades h_i^2 na matriz comum.

A dimensão da estrutura comum é limitada pelo número de fatores. Como

$$\text{posto}(\Lambda \Lambda^\top) \leq m,$$

a Análise Fatorial procura explicar uma matriz de covariâncias de dimensão p por uma estrutura comum cujo posto é, no máximo, $m < p$.

Essa redução de posto pertence apenas à parcela comum. A matriz total

$$\Sigma = \Sigma_{\text{com}} + \Psi$$

pode continuar apresentando posto completo porque as variâncias específicas acrescentam variabilidade nas direções das variáveis observadas.

Esse ponto distingue novamente a Análise Fatorial da aproximação de posto reduzido utilizada na ACP. Uma aproximação espectral truncada de Σ produz diretamente uma matriz de posto reduzido. O modelo fatorial acrescenta uma matriz diagonal e procura preservar a estrutura específica de cada variável.

15.9 Identificação do modelo fatorial

A equação

$$\Sigma = \Lambda\Lambda^\top + \Psi$$

não determina automaticamente uma única matriz de cargas.

A identificação do modelo envolve determinar quais características dos parâmetros podem ser recuperadas de forma única a partir da distribuição das variáveis observadas.

Três fontes de indeterminação aparecem diretamente na representação fatorial:

1. escala dos fatores;
2. sinal dos fatores;
3. orientação dos eixos fatoriais.

15.9.1 Escala dos fatores

Considere, inicialmente, um único fator:

$$\mathbf{X} = \mu + \lambda F + \varepsilon.$$

Para qualquer constante não nula c ,

$$\lambda F = (c\lambda) \left(\frac{F}{c} \right).$$

Logo, sem uma restrição adicional, a escala da carga e a escala do fator podem ser modificadas simultaneamente sem alterar a parte comum do modelo.

No modelo ortogonal, a condição

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m$$

fixa a variância de cada fator e remove essa indeterminação de escala.

15.9.2 Indeterminação do sinal

Se uma coluna de Λ e o fator correspondente tiverem seus sinais invertidos simultaneamente, o produto permanece inalterado.

Para o fator F_j ,

$$\lambda_{.j}F_j = (-\lambda_{.j})(-F_j).$$

Portanto, o sinal de um fator não é identificado pelo modelo.

Essa propriedade é semelhante à indeterminação de sinal dos autovetores observada na ACP, mas sua origem pertence agora à representação do produto entre carga e fator latente.

15.9.3 Indeterminação rotacional

A indeterminação mais importante ocorre quando

$$m \geq 2.$$

Considere uma matriz ortogonal

$$\mathbf{T} \in \mathbb{R}^{m \times m},$$

definida conforme Definição 2.18, de modo que

$$\mathbf{T}^\top \mathbf{T} = \mathbf{I}_m.$$

Defina

$$\Lambda^* = \Lambda \mathbf{T}$$

e

$$\mathbf{F}^* = \mathbf{T}^\top \mathbf{F}.$$

Então,

$$\begin{aligned}\Lambda^* \mathbf{F}^* &= \Lambda \mathbf{T} \mathbf{T}^\top \mathbf{F} \\ &= \Lambda \mathbf{F}.\end{aligned}$$

Além disso,

$$\begin{aligned}\text{Cov}(\mathbf{F}^*) &= \mathbf{T}^\top \text{Cov}(\mathbf{F}) \mathbf{T} \\ &= \mathbf{T}^\top \mathbf{T} \\ &= \mathbf{I}_m.\end{aligned}$$

A nova representação continua sendo ortogonal.

Para a matriz de covariâncias comuns,

$$\begin{aligned}\Lambda^* \Lambda^{*\top} &= \Lambda \mathbf{T} \mathbf{T}^\top \Lambda^\top \\ &= \Lambda \Lambda^\top.\end{aligned}$$

Portanto,

$$\Lambda^* \Lambda^{*\top} = \Lambda \Lambda^\top. \quad (15.13)$$

Proposição 15.2 (Indeterminação rotacional do modelo fatorial ortogonal). *Se Λ é uma matriz de cargas de um modelo fatorial ortogonal e $\mathbf{T}$ é qualquer matriz ortogonal de ordem m , então*

$$\Lambda^* = \Lambda \mathbf{T}$$

produz a mesma matriz de covariâncias comuns:

$$\Lambda^* \Lambda^{*\top} = \Lambda \Lambda^\top.$$

Assim, a matriz de covariâncias não determina uma orientação ortogonal única para os fatores.

O resultado utiliza diretamente a preservação do produto interno por transformações ortogonais, desenvolvida em Teorema 2.7.

A indeterminação rotacional significa que o modelo identifica a estrutura comum representada por

$$\Lambda\Lambda^\top,$$

mas não determina, sem restrições adicionais, uma única orientação para as colunas de Λ .

15.10 Rotação dos eixos fatoriais

A rotação modifica a representação das cargas em relação aos eixos fatoriais, mas pode preservar exatamente a matriz de covariâncias reproduzida.

A Figura 15.3 compara uma matriz de cargas com uma solução obtida por uma rotação ortogonal. Os vetores mudam de coordenadas em relação aos eixos, mas seus comprimentos e produtos internos são preservados.




Figura 15.3: Uma rotação ortogonal modifica as coordenadas das cargas, mas preserva comprimentos, produtos internos, communalidades e a matriz de covariâncias comuns.

A rotação altera os coeficientes individuais da matriz de cargas. As communalidades permanecem invariantes porque

$$\|\lambda_i^\top \mathbf{T}\|^2 = \|\lambda_i\|^2.$$

As covariâncias comuns também permanecem invariantes porque

$$(\lambda_i^\top \mathbf{T}) (\lambda_j^\top \mathbf{T})^\top = \lambda_i^\top \lambda_j.$$

Assim, a rotação modifica a parametrização das cargas sem alterar o ajuste da estrutura comum no modelo ortogonal.

A variância comum total também permanece inalterada:

$$\text{tr}(\Lambda \Lambda^\top) = \sum_{j=1}^m \|\lambda_{.j}\|^2.$$

A distribuição dessa quantidade entre fatores individuais, entretanto, pode mudar após a rotação. Em geral,

$$\sum_{i=1}^p \lambda_{ij}^2$$

não é preservada separadamente para cada coluna j .

Por isso, fatores rotacionados não devem ser interpretados como uma sequência ordenada de parcelas invariantes da variância total, como ocorre com as componentes principais. A rotação preserva a estrutura comum global, mas redistribui sua representação entre os eixos fatoriais.

A rotação deve ser distinguida da estimação inicial. Primeiro é obtida uma solução que reproduz a estrutura de covariâncias segundo determinado critério. Depois, uma transformação pode ser aplicada às cargas para selecionar outra orientação dentro da classe de soluções equivalentes.

O objetivo de uma rotação interpretativa é escolher, entre representações equivalentes ou relacionadas, uma estrutura de cargas cuja organização seja mais adequada à interpretação. Os critérios computacionais de rotação não fazem parte da formulação desenvolvida neste capítulo.

15.11 Contagem de parâmetros e identificação

A matriz simétrica Σ possui

$$\frac{p(p+1)}{2}$$

elementos distintos.

No modelo ortogonal com m fatores, a matriz de cargas possui

$$pm$$

elementos e a matriz diagonal Ψ possui

$$p$$

variâncias específicas.

Uma contagem direta produziria

$$pm + p$$

parâmetros. Essa contagem inclui, entretanto, diferentes matrizes de cargas relacionadas por rotações ortogonais que produzem a mesma matriz de covariâncias.

Uma matriz ortogonal de ordem m possui

$$\frac{m(m-1)}{2}$$

graus de liberdade associados à rotação. Assim, o número de parâmetros estruturalmente distintos na formulação exploratória ortogonal pode ser contado como

$$pm + p - \frac{m(m-1)}{2}. \quad (15.14)$$

Uma condição necessária de contagem é, portanto,

$$pm + p - \frac{m(m-1)}{2} \leq \frac{p(p+1)}{2}. \quad (15.15)$$

Essa desigualdade é uma condição necessária de disponibilidade de informação, mas não constitui, isoladamente, uma condição suficiente de identificação.

Contagem de parâmetros e identificação

Ter número de elementos observáveis igual ou superior ao número de parâmetros livres não garante, por si só, identificação do modelo. A identificação também depende da estrutura das cargas, das restrições impostas e da posição do parâmetro no espaço paramétrico.

Para produzir uma parametrização única, podem ser impostas restrições adicionais às cargas ou à orientação dos fatores. Essas restrições podem assumir diferentes formas, dependendo do tipo de modelo e do objetivo da análise.

Na Análise Fatorial Exploratória, a indeterminação rotacional é reconhecida como parte da estrutura da técnica. Em modelos fatoriais confirmatórios, restrições previamente especificadas sobre cargas e covariâncias fatoriais passam a desempenhar papel explícito na identificação.

O desenvolvimento completo de condições algébricas de identificação pertence à teoria de modelos de variáveis latentes e não é necessário para a formulação deste capítulo.

15.12 Fatores ortogonais e fatores oblíquos

A formulação desenvolvida até aqui utilizou fatores com matriz de covariâncias

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m.$$

Essa hipótese define o modelo ortogonal.

A estrutura pode ser generalizada permitindo associação entre os fatores.

Definição 15.6 (Modelo fatorial oblíquo). No **modelo fatorial oblíquo**,

$$\mathbf{X} = \mu + \Lambda \mathbf{F} + \varepsilon,$$

com

$$E(\mathbf{F}) = \mathbf{0},$$

$$\text{Cov}(\mathbf{F}) = \Phi,$$

$$E(\varepsilon) = \mathbf{0},$$

$$\text{Cov}(\varepsilon) = \Psi,$$

e

$$\text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0}.$$

A matriz Φ é a matriz de covariâncias dos fatores.

Quando a escala de cada fator é fixada em variância unitária,

$$\text{diag}(\Phi) = \mathbf{1}_m,$$

e Φ passa a ser a matriz de correlações entre os fatores.

A matriz de covariâncias das variáveis observadas torna-se

$$\Sigma = \Lambda\Phi\Lambda^\top + \Psi. \quad (15.16)$$

No caso particular

$$\Phi = \mathbf{I}_m,$$

recupera-se o modelo ortogonal.

A relação entre representações ortogonais e oblíquas pode ser compreendida como uma reparametrização dos fatores. Considere uma matriz não singular

$$\mathbf{T} \in \mathbb{R}^{m \times m}$$

e defina

$$\mathbf{F}^* = \mathbf{T}^{-1}\mathbf{F}.$$

Então,

$$\mathbf{F} = \mathbf{T}\mathbf{F}^*$$

e o modelo pode ser escrito como

$$\mathbf{X} - \mu = \Lambda^* \mathbf{F}^* + \varepsilon,$$

com

$$\Lambda^* = \Lambda \mathbf{T}.$$

A matriz de covariâncias dos novos fatores é

$$\Phi^* = \mathbf{T}^{-1} \Phi \mathbf{T}^{-\top}.$$

Consequentemente,

$$\begin{aligned} \Lambda^* \Phi^* \Lambda^{*\top} &= \Lambda \mathbf{T} \mathbf{T}^{-1} \Phi \mathbf{T}^{-\top} \mathbf{T}^{\top} \Lambda^{\top} \\ &= \Lambda \Phi \Lambda^{\top}. \end{aligned}$$

Proposição 15.3 (Invariância da estrutura comum por reparametrização). *Se $\mathbf{T}$ é não singular e cargas, fatores e covariâncias fatoriais são transformados conjuntamente por*

$$\Lambda^* = \Lambda \mathbf{T},$$

$$\mathbf{F}^* = \mathbf{T}^{-1} \mathbf{F}$$

e

$$\Phi^* = \mathbf{T}^{-1} \Phi \mathbf{T}^{-\top},$$

então

$$\Lambda^* \Phi^* \Lambda^{*\top} = \Lambda \Phi \Lambda^{\top}.$$

A indeterminação rotacional é, portanto, parte de uma classe mais ampla de reparametrizações do espaço fatorial. Uma transformação ortogonal preserva $\Phi = \mathbf{I}_m$; uma transformação não ortogonal pode produzir fatores correlacionados.

A comparação é sintetizada na Tabela [15.2](#).

Tabela 15.2: Estruturas dos modelos fatoriais ortogonal e oblíquo.

Aspecto	Modelo ortogonal	Modelo oblíquo
Covariância dos fatores	$\mathbf{I}_m$	Φ
Associação entre fatores	Covariâncias nulas	Pode haver covariâncias diferentes de zero
Covariância comum	$\Lambda\Lambda^\top$	$\Lambda\Phi\Lambda^\top$
Comunalidade de X_i	$\lambda_i^\top \lambda_i$	$\lambda_i^\top \Phi \lambda_i$
Covariância variável-fator	Λ	$\Lambda\Phi$

No modelo oblíquo, a comunalidade é

$$h_i^2 = \lambda_i^\top \Phi \lambda_i. \quad (15.17)$$

A expressão

$$h_i^2 = \sum_{j=1}^m \lambda_{ij}^2$$

é, portanto, específica do modelo ortogonal com fatores de variância unitária.

15.13 Matriz de padrões e matriz de estrutura

Quando os fatores são correlacionados, duas matrizes passam a desempenhar funções diferentes.

A matriz

$$\Lambda$$

continua contendo os coeficientes que aparecem diretamente no modelo

$$\mathbf{X} - \mu = \Lambda \mathbf{F} + \varepsilon.$$

Ela é denominada **matriz de padrões**.

Por outro lado,

$$\begin{aligned}\text{Cov}(\mathbf{X}, \mathbf{F}) &= \text{Cov}(\Lambda \mathbf{F} + \varepsilon, \mathbf{F}) \\ &= \Lambda \Phi.\end{aligned}$$

Defina

$$\Gamma = \Lambda \Phi. \quad (15.18)$$

Definição 15.7 (Matrizes de padrões e de estrutura). No modelo fatorial oblíquo:

- Λ é a **matriz de padrões**, formada pelos coeficientes das variáveis em relação aos fatores no modelo linear;
- $\Gamma = \Lambda \Phi$ é a **matriz de estrutura**, formada pelas covariâncias entre variáveis e fatores quando os fatores possuem variância unitária.

Se as variáveis observadas também estiverem padronizadas, os elementos de Γ correspondem às correlações entre as variáveis e os fatores.

No modelo ortogonal,

$$\Phi = \mathbf{I}_m,$$

de modo que

$$\Gamma = \Lambda.$$

Por isso, matriz de padrões e matriz de estrutura coincidem na solução ortogonal.

No modelo oblíquo, elas geralmente diferem. Uma associação observada entre uma variável e determinado fator pode resultar tanto do coeficiente direto daquela variável no fator quanto da correlação desse fator com outros fatores.

Essa distinção impede que as cargas de uma solução oblíqua sejam interpretadas da mesma forma que as cargas de uma solução ortogonal.

A representação ortogonal utiliza fatores não correlacionados, enquanto a representação oblíqua permite associações entre os fatores. Em uma Análise Fatorial Exploratória sem restrições adicionais, essas representações podem corresponder a diferentes parametrizações da mesma matriz de covariâncias reproduzida. Quando são impostas restrições específicas às cargas ou à matriz Φ , a parametrização passa a fazer parte da definição do modelo.

O próximo passo consiste em passar da estrutura populacional para a amostra. A matriz Σ será substituída pela informação contida em $\mathbf{S}$ ou $\mathbf{R}$, e o problema passará a ser estimar Λ , Ψ e, quando necessário, Φ de modo que a estrutura fatorial reproduza adequadamente as covariâncias observadas.

15.14 Formulação populacional e amostral

No nível populacional, o modelo fatorial especifica uma estrutura para a matriz de covariâncias. No modelo ortogonal,

$$\Sigma = \Lambda\Lambda^\top + \Psi.$$

Os parâmetros de interesse incluem as cargas fatoriais, as variâncias específicas e, no modelo oblíquo, as associações entre os fatores.

Na prática, Σ é desconhecida. A informação disponível provém de uma amostra

$$\mathbf{X}_1, \dots, \mathbf{X}_n,$$

cujas realizações são organizadas na matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p}.$$

A matriz de covariâncias observada $\mathbf{S}$, definida em Definição 8.11, e a matriz de correlações observada $\mathbf{R}$, definida em Definição 8.12, fornecem as estruturas de segunda ordem utilizadas no ajuste.

A formulação amostral procura parâmetros

$$\widehat{\Lambda}, \quad \widehat{\Psi}$$

e, no caso oblíquo,

$$\widehat{\Phi},$$

de modo que a matriz reproduzida pelo modelo se aproxime da matriz observada.

No modelo ortogonal, a matriz de covariâncias reproduzida é

$$\widehat{\Sigma}_{\text{fat}} = \widehat{\Lambda}\widehat{\Lambda}^\top + \widehat{\Psi}. \quad (15.19)$$

Quando a análise é baseada em correlações,

$$\widehat{\mathcal{R}}_{\text{fat}} = \widehat{\Lambda}\widehat{\Lambda}^\top + \widehat{\Psi},$$

com a parametrização correspondente às variáveis padronizadas.

A escolha entre $\mathbf{S}$ e $\mathbf{R}$ modifica o modelo que está sendo ajustado. Na análise baseada em $\mathbf{S}$, as variâncias e covariâncias permanecem nas escalas originais. Na análise baseada em $\mathbf{R}$, as variáveis são previamente colocadas em variância unitária e as comunalidades e especificidades passam a decompor essa variância padronizada.

Essa distinção é análoga à discutida na ACP, mas seu efeito deve ser interpretado no contexto do modelo fatorial. A padronização modifica as covariâncias que o modelo procura reproduzir e, conseqüentemente, pode modificar cargas, comunalidades e especificidades.

15.15 Matriz reproduzida e resíduos

A qualidade da representação da estrutura de segunda ordem pode ser descrita pela diferença entre a matriz observada e a matriz reproduzida.

Para uma análise baseada em covariâncias, a matriz de resíduos é

$$\mathbf{S} - \hat{\Sigma}_{\text{fat}}.$$

Para uma análise baseada em correlações, a matriz correspondente é

$$\mathbf{R} - \hat{\mathcal{R}}_{\text{fat}}.$$

Os elementos fora da diagonal dessas diferenças representam covariâncias ou correlações que não foram reproduzidas pela estrutura comum estimada.

No modelo populacional exato,

$$\Sigma = \Lambda\Lambda^{\top} + \Psi,$$

e o resíduo matricial é nulo. Na amostra, a igualdade exata não é esperada em geral porque a matriz observada apresenta variabilidade amostral e porque um modelo com poucos fatores pode não reproduzir perfeitamente a estrutura populacional.

A Figura 15.4 representa a decomposição de uma matriz de covariâncias em sua parcela comum e sua parcela específica.

A matriz comum reproduz as covariâncias entre variáveis distintas e contribui também para as variâncias da diagonal. A matriz específica acrescenta somente variabilidade própria a cada variável. A soma das duas parcelas produz a matriz total especificada pelo modelo.




Figura 15.4: Decomposição de uma matriz de covariâncias em estrutura comum, produzida pelas cargas fatoriais, e estrutura específica diagonal.

15.16 O problema de estimação

A Análise Fatorial não fornece uma única solução por decomposição direta da matriz observada. Os parâmetros devem ser escolhidos de acordo com um critério de ajuste.

Em termos gerais, o problema pode ser escrito como

$$\min_{\theta} D[\mathbf{S}, \Sigma(\theta)], \quad (15.20)$$

em que

$$\theta$$

reúne os parâmetros livres e

$$\Sigma(\theta) = \Lambda\Lambda^{\top} + \Psi$$

no modelo ortogonal.

A função

$$D[\mathbf{S}, \Sigma(\theta)]$$

mede a discrepância entre a estrutura observada e a estrutura reproduzida.

Diferentes métodos de estimação correspondem a diferentes maneiras de definir ou resolver esse problema. O objetivo deste capítulo é apresentar a estrutura matemática desses critérios, sem desenvolver os algoritmos iterativos utilizados para calculá-los.

15.16.1 Fatores principais

Uma abordagem procura concentrar a decomposição espectral na parte comum da matriz de covariâncias ou correlações.

No nível populacional,

$$\Sigma_{\text{com}} = \Sigma - \Psi = \Lambda \Lambda^\top.$$

Se Ψ fosse conhecida, a matriz comum poderia ser decomposta espectralmente. Como

$$\text{posto}(\Sigma_{\text{com}}) \leq m,$$

apenas até m direções seriam necessárias para representar sua parte não nula.

Na amostra, entretanto, as especificidades são desconhecidas. Uma matriz reduzida pode ser construída substituindo a diagonal da matriz de correlações por estimativas das comunalidades:

$$\mathbf{R}_{\text{red}} = \begin{pmatrix} \hat{h}_1^2 & r_{12} & \cdots & r_{1p} \\ r_{21} & \hat{h}_2^2 & \cdots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \cdots & \hat{h}_p^2 \end{pmatrix}. \quad (15.21)$$

A decomposição dessa matriz procura representar principalmente a covariância comum, e não a variância total.

Esse procedimento distingue os **fatores principais** da ACP baseada em $\mathbf{R}$. Na ACP, a diagonal da matriz de correlações permanece

$$1,$$

porque toda a variância padronizada participa da decomposição. Na abordagem por fatores principais, a diagonal é substituída por estimativas das comunalidades, pois a parcela específica não pertence à estrutura comum que se pretende representar.

As comunalidades e as cargas dependem umas das outras. Por isso, a obtenção da solução envolve atualização sucessiva dessas quantidades. O algoritmo específico dessa atualização não faz parte da formulação desenvolvida aqui.

15.16.2 Mínimos quadrados

Outra possibilidade é estimar os parâmetros pela minimização direta dos resíduos da matriz de covariâncias.

Uma formulação de mínimos quadrados não ponderados pode ser escrita como

$$F_{\text{MQ}}(\Lambda, \Psi) = \left\| \mathbf{S} - \Lambda\Lambda^\top - \Psi \right\|_F^2. \quad (15.22)$$

A norma de Frobenius mede conjuntamente os desvios entre os elementos da matriz observada e da matriz reproduzida.

Como Ψ é diagonal, os elementos fora da diagonal desempenham papel central na determinação das cargas. Os elementos diagonais são decompostos entre comunalidades e especificidades.

CrITÉRIOS ponderados podem atribuir importâncias diferentes aos resíduos, incorporando a variabilidade amostral dos elementos de $\mathbf{S}$. Essas extensões modificam a métrica do ajuste, mas preservam o mesmo objetivo estrutural: aproximar a matriz observada por uma matriz da forma

$$\Lambda\Lambda^\top + \Psi.$$

15.17 Modelo fatorial normal

A estrutura de segunda ordem desenvolvida até aqui não exige normalidade. Uma formulação probabilística completa pode ser obtida especificando distribuições para os fatores e para as componentes específicas.

Definição 15.8 (Modelo fatorial normal). No modelo fatorial normal ortogonal,

$$\mathbf{F} \sim N_m(\mathbf{0}, \mathbf{I}_m),$$

$$\varepsilon \sim N_p(\mathbf{0}, \Psi),$$

com

$$\mathbf{F} \perp \varepsilon.$$

A variável observada é definida por

$$\mathbf{X} = \mu + \Lambda \mathbf{F} + \varepsilon.$$

Pela estabilidade da normal multivariada sob transformações afins, apresentada em Proposição 9.5,

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

com

$$\Sigma = \Lambda \Lambda^\top + \Psi. \quad (15.23)$$

A normalidade acrescenta ao modelo uma distribuição conjunta completa. A diagonalidade de Ψ passa, nesse caso, a implicar independência entre as componentes específicas, porque elas são conjuntamente normais.

Esse modelo permite utilizar a teoria de verossimilhança desenvolvida no Módulo 2.

15.18 Estimação por máxima verossimilhança

A função de verossimilhança foi definida em Definição 10.11 e o estimador de máxima verossimilhança em Definição 10.12.

Considere uma amostra

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p[\mu, \Sigma(\theta)],$$

em que

$$\Sigma(\theta) = \Lambda \Lambda^\top + \Psi.$$

Para um valor fixado de θ , a maximização em relação à média produz

$$\hat{\mu} = \bar{\mathbf{x}},$$

como no resultado geral de Proposição 10.3.

Defina a matriz de covariâncias com divisor n ,

$$\mathbf{S}_{\text{MV}} = \frac{1}{n} \mathbf{X}_c^\top \mathbf{X}_c. \quad (15.24)$$

Como a matriz $\mathbf{S}$ utilizada descritivamente no livro possui divisor $n - 1$,

$$\mathbf{S}_{\text{MV}} = \frac{n-1}{n} \mathbf{S}.$$

Desconsiderando termos que não dependem de θ , a log-verossimilhança concentrada pode ser escrita como

$$\ell(\theta) = C - \frac{n}{2} \left\{ \log |\Sigma(\theta)| + \text{tr} [\mathbf{S}_{\text{MV}} \Sigma(\theta)^{-1}] \right\}. \quad (15.25)$$

Maximizar a verossimilhança equivale, portanto, a minimizar

$$\log |\Sigma(\theta)| + \text{tr} [\mathbf{S}_{\text{MV}} \Sigma(\theta)^{-1}].$$

Uma forma normalizada da função de discrepância é

$$\begin{aligned} F_{\text{ML}}(\theta) &= \log |\Sigma(\theta)| \\ &\quad + \text{tr} [\mathbf{S}_{\text{MV}} \Sigma(\theta)^{-1}] \\ &\quad - \log |\mathbf{S}_{\text{MV}}| - p. \end{aligned} \quad (15.26)$$

A forma em Equação 15.26 pressupõe

$$\mathbf{S}_{\text{MV}} \succ \mathbf{0},$$

pois contém o termo

$$\log |\mathbf{S}_{\text{MV}}|.$$

Quando a matriz de covariâncias observada é singular, a log-verossimilhança do modelo ainda pode ser expressa pelo termo de Equação 15.25 para matrizes modeladas positivas definidas, mas a comparação com a matriz de covariâncias irrestrita e a função de discrepância normalizada exigem tratamento adicional.

A constante foi escolhida de forma que

$$F_{\text{ML}} = 0$$

quando

$$\Sigma(\theta) = \mathbf{S}_{\text{MV}}.$$

A presença simultânea do log-determinante e da inversa da matriz de covariâncias decorre diretamente da densidade normal multivariada. As ferramentas de cálculo matricial necessárias para diferenciar esse critério já foram desenvolvidas no Capítulo 7, incluindo o diferencial do log-determinante em Proposição 7.12.

A estimação por máxima verossimilhança transforma a Análise Fatorial em um problema paramétrico:

$$\hat{\theta}_{\text{ML}} \in \arg \min_{\theta \in \Theta_{\text{fat}}} F_{\text{ML}}(\theta),$$

em que o espaço paramétrico deve respeitar, entre outras condições,

$$\Psi \succeq \mathbf{0}$$

e

$$\Sigma(\theta) \succ \mathbf{0}.$$

A solução não é obtida, em geral, por uma única decomposição matricial explícita. Métodos numéricos são utilizados para resolver o problema de otimização. O desenvolvimento desses algoritmos pertence à implementação da técnica (Lawley; Maxwell, 1971).

15.18.1 Ajuste e graus de liberdade

A formulação por máxima verossimilhança também permite comparar a estrutura fatorial com uma matriz de covariâncias sem restrições.

Uma matriz simétrica $p \times p$ possui

$$\frac{p(p+1)}{2}$$

elementos distintos.

No modelo fatorial ortogonal exploratório com m fatores, a contagem de parâmetros estruturalmente distintos foi obtida em Equação 15.14:

$$pm + p - \frac{m(m-1)}{2}.$$

A diferença

$$\nu_{\text{fat}} = \frac{p(p+1)}{2} - pm - p + \frac{m(m-1)}{2} \quad (15.27)$$

representa o número de restrições de covariância impostas pelo modelo, quando a parametrização está identificada.

Sob normalidade e condições regulares de identificação e interioridade, a razão de verossimilhanças fornece uma base para avaliar o ajuste global do modelo. Esse resultado pertence à teoria geral de máxima verossimilhança estudada no Módulo 2 e depende das condições regulares do modelo (Anderson, 2003).

O número de fatores modifica diretamente essa estrutura: aumentar m amplia a classe de matrizes que podem ser representadas e reduz o número de restrições impostas pelo modelo.

A determinação prática de m envolve informação estatística, estabilidade e interpretação e será tratada na etapa aplicada. Neste capítulo, m é considerado parte da especificação do modelo.

15.19 Soluções admissíveis e casos de fronteira

As variâncias específicas devem satisfazer

$$\psi_i \geq 0.$$

Uma solução com

$$\psi_i < 0$$

não pertence ao espaço paramétrico do modelo fatorial.

Como

$$\sigma_{ii} = h_i^2 + \psi_i,$$

uma especificidade negativa corresponderia a

$$h_i^2 > \sigma_{ii}.$$

Para variáveis padronizadas, isso produziria

$$h_i^2 > 1.$$

Soluções desse tipo são denominadas **soluções impróprias** ou, em determinados contextos, **casos de Heywood**.

Também podem ocorrer soluções na fronteira,

$$\psi_i = 0.$$

Nesse caso, toda a variância da variável é atribuída à parte comum do modelo.

Fronteira do espaço paramétrico

Uma solução com variância específica nula pertence à fronteira do espaço paramétrico. Resultados inferenciais assintóticos obtidos sob hipóteses de solução interior podem deixar de ser diretamente aplicáveis nessa situação.

Esses casos mostram que a existência de uma solução numérica não garante automaticamente uma solução estatisticamente admissível.

15.20 Escores fatoriais

Os fatores comuns aparecem no modelo como variáveis aleatórias latentes:

F.

Eles não são componentes observadas da matriz de dados e não são obtidos diretamente pela decomposição de uma matriz, como ocorre com os escores da ACP.

Essa diferença produz o **problema dos escores fatoriais**.

Considere uma observação

x.

Depois que os parâmetros do modelo são conhecidos ou estimados, pode-se procurar uma representação da posição dessa observação no espaço dos fatores. Essa representação é denominada **escore fatorial**.

Definição 15.9 (Escore fatorial). Um **escore fatorial** é uma estimativa ou predição da posição de uma observação em relação aos fatores latentes especificados pelo modelo.

O fator e o escore desempenham funções distintas:

Tabela 15.3: Distinção entre fatores, cargas e escores fatoriais.

Objeto	Natureza
$\mathbf{F}$	vetor aleatório latente do modelo
Λ	matriz de parâmetros que relaciona fatores e variáveis
$\mathbf{f}_i$	valor latente associado à unidade i , não diretamente observado
$\hat{\mathbf{f}}_i$	escore utilizado para estimar ou prever a posição da unidade no espaço fatorial

A normalidade fornece uma forma direta de compreender por que os escores constituem um problema de predição.

15.21 Distribuição condicional dos fatores

No modelo fatorial normal ortogonal,

$$\mathbf{F} \sim N_m(\mathbf{0}, \mathbf{I}_m)$$

e

$$\mathbf{X} \sim N_p(\mu, \Sigma).$$

Além disso,

$$\text{Cov}(\mathbf{F}, \mathbf{X}) = \Lambda^\top.$$

Portanto, o vetor conjunto

$$\begin{pmatrix} \mathbf{F} \\ \mathbf{X} \end{pmatrix}$$

possui distribuição normal com média

$$\begin{pmatrix} \mathbf{0} \\ \mu \end{pmatrix}$$

e matriz de covariâncias

$$\begin{pmatrix} \mathbf{I}_m & \Lambda^\top \\ \Lambda & \Sigma \end{pmatrix}. \quad (15.28)$$

Aplicando o resultado de distribuição condicional normal de Proposição 9.8,

$$E(\mathbf{F} \mid \mathbf{X} = \mathbf{x}) = \Lambda^\top \Sigma^{-1} (\mathbf{x} - \mu). \quad (15.29)$$

A matriz de covariâncias condicional é

$$\text{Cov}(\mathbf{F} \mid \mathbf{X}) = \mathbf{I}_m - \Lambda^\top \Sigma^{-1} \Lambda. \quad (15.30)$$

A média condicional fornece uma predição natural dos fatores sob o modelo normal:

$$\hat{\mathbf{f}} = \Lambda^\top \Sigma^{-1} (\mathbf{x} - \mu).$$

No ajuste amostral, os parâmetros são substituídos por suas estimativas.

A expressão mostra uma diferença central em relação à ACP. Os escores de componentes principais são coordenadas determinadas pela projeção de uma observação sobre direções estimadas. Os escores fatoriais são predições de variáveis latentes que permanecem não observadas mesmo depois de conhecido o vetor $\mathbf{x}$.

A matriz em Equação 15.30 geralmente é diferente de zero. Portanto, conhecer exatamente as variáveis observadas não determina necessariamente um único valor do fator.

Essa incerteza condicional expressa a **indeterminação dos escores fatoriais**.

Diferentes critérios podem produzir diferentes estimativas dos fatores para a mesma solução de cargas. Métodos específicos, como predição por regressão ou critérios baseados em mínimos quadrados, serão tratados na etapa aplicada.

15.22 Pressupostos e limites do modelo

Os pressupostos da Análise Fatorial possuem funções diferentes. Alguns definem o próprio modelo; outros são necessários apenas para determinados métodos de estimação ou de inferência.

A Tabela 15.4 organiza essas distinções.

Tabela 15.4: Pressupostos e limites da formulação fatorial.

Aspecto	Papel na formulação
Linearidade	As variáveis observadas são representadas por combinações lineares dos fatores, acrescidas das componentes específicas
Estrutura comum de baixa dimensão	A covariância comum deve ser representável aproximadamente por poucos fatores
Diagonalidade de Ψ	No modelo básico, a dependência entre variáveis distintas deve ser explicada pelos fatores comuns
Não correlação entre fatores e componentes específicas	Separa as parcelas comum e específica da covariância
Identificação	Os parâmetros precisam ser restringidos de modo que características relevantes do modelo possam ser determinadas
Admissibilidade	As variâncias específicas devem ser não negativas e a matriz reproduzida deve ser uma matriz de covariâncias válida
Normalidade	Não é necessária para a decomposição de segunda ordem; sustenta a máxima verossimilhança normal e resultados inferenciais correspondentes
Número de fatores	Define a dimensão da estrutura latente e a classe de matrizes de covariâncias que o modelo pode representar
Conjunto e escala das variáveis	Modificações nas variáveis ou em suas escalas modificam a estrutura de covariâncias modelada

15.22.1 Linearidade e estrutura de segunda ordem

O modelo básico especifica

$$\mathbf{X} - \mu = \Lambda \mathbf{F} + \varepsilon.$$

Consequentemente, a estrutura analisada é essencialmente linear e baseada em momentos de segunda ordem.

Associações que não se manifestam adequadamente por covariâncias podem não ser representadas por uma estrutura fatorial linear simples.

15.22.2 Diagonalidade da estrutura específica

A condição

$$\Psi = \text{diag}(\psi_1, \dots, \psi_p)$$

é um pressuposto definidor do modelo de fatores comuns básico.

Se permanecer associação sistemática entre componentes específicas de diferentes variáveis, a estrutura

$$\Lambda \Lambda^\top + \Psi$$

pode ser insuficiente para representar a matriz de covariâncias.

15.22.3 Número de fatores

Para m pequeno, o modelo impõe uma estrutura mais restritiva à matriz de covariâncias. À medida que m aumenta, cresce a flexibilidade da parcela comum.

Um número insuficiente de fatores pode deixar covariâncias sistemáticas sem representação. Um número excessivo pode reduzir a utilidade da estrutura latente e introduzir parâmetros de difícil identificação.

O número de fatores faz parte da especificação do problema. Critérios operacionais para sua escolha não pertencem à formulação desenvolvida neste capítulo.

15.22.4 Dependência do conjunto de variáveis

Os fatores são definidos em relação ao conjunto de variáveis incluído no modelo.

Adicionar, retirar, transformar ou mudar a escala das variáveis modifica

$$\Sigma$$

ou

$$\mathcal{R}$$

e pode modificar a estrutura fatorial obtida.

Os fatores não devem, portanto, ser interpretados como objetos independentes da forma como o conjunto de variáveis foi definido.

15.23 Análise Fatorial e Análise de Componentes Principais

A distinção introduzida em Tabela 14.6 pode agora ser formulada matematicamente com maior precisão.

Na ACP, a matriz de covariâncias é decomposta como

$$\Sigma = \mathbf{A} \mathbf{D}_{\text{ACP}} \mathbf{A}^{\top},$$

em que

$$\mathbf{D}_{\text{ACP}} = \text{diag}(\lambda_1, \dots, \lambda_p).$$

Os autovetores definem as direções principais e os autovalores representam as variâncias das componentes.

Na Análise Fatorial ortogonal,

$$\Sigma = \Lambda \Lambda^{\top} + \Psi.$$

A matriz Λ contém cargas fatoriais e não autovetores da matriz de covariâncias em geral.

A Tabela 15.5 reúne as diferenças estruturais.

Tabela 15.5: Diferenças matemáticas e estatísticas entre ACP e Análise Fatorial.

Aspecto	ACP	Análise Fatorial
Problema	Preservar variabilidade em poucas direções	Explicar covariâncias por fatores latentes
Objeto populacional	Σ ou $\mathcal{R}$	Σ ou $\mathcal{R}$
Estrutura matemática	Decomposição espectral	Modelo de covariâncias
Formulação	$\Sigma = \mathbf{A}\mathbf{D}_{\text{ACP}}\mathbf{A}^\top$	$\Sigma = \Lambda\Lambda^\top + \Psi$
Variância utilizada	Variância total	Variância comum separada da específica
Dimensões reduzidas	Combinações lineares observáveis das variáveis	Variáveis latentes do modelo
Diagonal da matriz analisada	Participa integralmente da decomposição	É separada entre comunalidade e especificidade
Coeficientes	Autovetores	Cargas fatoriais
Unicidade	Direções simples são determinadas até sinal	Há indeterminação de sinal e rotação
Escores	Coordenadas obtidas por projeção	Predições de fatores latentes
Normalidade	Não necessária para definir a técnica	Não necessária para a estrutura de covariâncias; necessária na formulação normal por ML

Uma decomposição espectral truncada de Σ não resolve, em geral, o problema fatorial.

Na ACP,

$$\Sigma_k = \mathbf{A}_k \mathbf{D}_k \mathbf{A}_k^\top,$$

em que

$$\mathbf{D}_k = \text{diag}(\lambda_1, \dots, \lambda_k).$$

é uma aproximação de posto reduzido da matriz inteira.

Na Análise Fatorial, procura-se

$$\Sigma \approx \Lambda\Lambda^\top + \Psi,$$

em que somente a parcela comum possui posto reduzido e a matriz diagonal Ψ permanece explicitamente no modelo.

Por isso, substituir a Análise Fatorial por uma ACP com o mesmo número de dimensões altera o problema estatístico.

15.24 Relação com outros modelos de variáveis latentes

O modelo de fatores comuns introduz a ideia de representar variáveis observadas por meio de variáveis latentes contínuas.

Essa estrutura pode ser ampliada impondo restrições específicas às cargas, permitindo relações estruturais entre variáveis latentes ou combinando diferentes modelos de mensuração.

A Análise Fatorial Confirmatória e os modelos de equações estruturais desenvolvem essas extensões por meio de estruturas parametrizadas e hipóteses explícitas sobre os elementos das matrizes do modelo.

A formulação deste capítulo permanece concentrada no modelo fatorial exploratório e nos princípios matemáticos necessários para compreender cargas, communalidades, especificidades, identificação, rotação, estimação e escores.

15.25 Síntese

A Análise Fatorial parte da hipótese de que as dependências entre p variáveis observadas podem ser representadas por um vetor de fatores latentes de menor dimensão.

No modelo ortogonal,

$$\mathbf{X} = \mu + \Lambda \mathbf{F} + \varepsilon,$$

com

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m,$$

$$\text{Cov}(\varepsilon) = \Psi,$$

e

$$\text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0}.$$

Essas condições conduzem à estrutura

$$\Sigma = \Lambda\Lambda^{\top} + \Psi.$$

A matriz

$$\Lambda\Lambda^{\top}$$

representa a covariância comum e possui posto não superior ao número de fatores. A matriz diagonal Ψ representa as variâncias específicas.

Para cada variável,

$$\text{Var}(X_i) = h_i^2 + \psi_i,$$

e, no modelo ortogonal,

$$h_i^2 = \sum_{j=1}^m \lambda_{ij}^2.$$

Os vetores de cargas fornecem uma representação geométrica da estrutura comum: seus comprimentos determinam as comunalidades e seus produtos internos determinam as covariâncias reproduzidas.

A solução não possui uma orientação fatorial única. Para qualquer matriz ortogonal $\mathbf{T}$,

$$\Lambda^* = \Lambda\mathbf{T}$$

produz

$$\Lambda^*\Lambda^{*\top} = \Lambda\Lambda^{\top}.$$

A rotação modifica a parametrização das cargas, mas preserva a estrutura comum no modelo ortogonal.

Quando os fatores são correlacionados,

$$\text{Cov}(\mathbf{F}) = \Phi,$$

e a estrutura passa a ser

$$\Sigma = \Lambda \Phi \Lambda^\top + \Psi.$$

Nesse caso, a matriz de padrões Λ e a matriz de estrutura

$$\Gamma = \Lambda \Phi$$

desempenham funções distintas.

No nível amostral, o problema consiste em estimar os parâmetros de modo que a estrutura fatorial reproduza adequadamente $\mathbf{S}$ ou $\mathbf{R}$. Fatores principais, mínimos quadrados e máxima verossimilhança correspondem a diferentes formulações desse problema.

Sob normalidade,

$$\mathbf{X} \sim N_p \left[\mu, \Lambda \Lambda^\top + \Psi \right],$$

e a estimação por máxima verossimilhança utiliza diretamente os resultados dos Módulos 1 e 2 sobre normal multivariada, log-determinantes, inversas, traços e otimização.

Os fatores permanecem latentes após o ajuste. Seus escores são estimativas ou predições e não coordenadas diretamente observadas. No modelo normal, a distribuição condicional mostra que

$$E(\mathbf{F} \mid \mathbf{X} = \mathbf{x}) = \Lambda^\top \Sigma^{-1} (\mathbf{x} - \mu),$$

enquanto a covariância condicional geralmente permanece diferente de zero.

A formulação da Análise Fatorial utiliza os fundamentos anteriores para resolver um problema diferente daquele da ACP. A ACP procura direções que preservem variabilidade. A Análise Fatorial especifica uma estrutura latente capaz de explicar a covariação observada.

O próximo capítulo muda novamente o objeto do problema. Em vez de representar variáveis por dimensões latentes, a Análise de Agrupamentos utilizará medidas de proximidade e critérios de dispersão para construir grupos de objetos sem classes previamente conhecidas.

16 Formulação da Análise de Agrupamentos

A Análise de Agrupamentos reúne métodos destinados a organizar objetos em grupos a partir de suas relações de proximidade. Ao contrário das técnicas estudadas nos dois capítulos anteriores, a definição da solução depende diretamente do critério adotado para representar a semelhança entre os objetos e para caracterizar um grupo (Johnson; Wichern, 2007).

Os fundamentos geométricos necessários já foram estabelecidos no Módulo 1. A matriz de dados foi definida em Definição 1.6, a distância euclidiana em Definição 1.13 e geometrias determinadas por produtos internos e normas induzidas foram desenvolvidas em Definição 3.16 e Definição 3.17. O Módulo 2 acrescentou a decomposição da dispersão total em parcelas intragrupos e entre grupos em Proposição 8.11. Neste capítulo, esses resultados passam a definir critérios específicos para construir agrupamentos.

A formulação da técnica envolve os elementos organizados na Tabela 16.1.

Tabela 16.1: Elementos que definem um problema de Análise de Agrupamentos.

Elemento	Objeto	Papel na análise
Representação dos objetos	matriz de dados $\mathbf{X}$ ou matriz de dissimilaridades Δ	determina a informação disponível para comparar os objetos
Proximidade	distância, dissimilaridade ou similaridade	estabelece o significado de objetos próximos
Organização	partição $\mathcal{P}$ ou estrutura hierárquica	representa os grupos construídos
Critério	função de perda, dispersão ou ligação	permite comparar diferentes organizações
Solução	grupos de objetos	resulta da otimização ou da regra de construção adotada

A mesma coleção de observações pode produzir agrupamentos diferentes quando um desses elementos é alterado. Por isso, a Análise de Agrupamentos não possui uma definição universal de grupo independente da representação, da proximidade e do critério utilizado.

16.1 O problema de formação de grupos

Considere n objetos representados pelas linhas da matriz de dados

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p},$$

conforme Definição 1.6.

Os grupos não são conhecidos previamente. O objetivo é construir uma organização dos índices das observações de modo que a proximidade entre objetos pertencentes ao mesmo grupo seja elevada segundo o critério adotado, enquanto objetos atribuídos a grupos diferentes apresentem maior separação.

Essa formulação distingue a Análise de Agrupamentos da Análise Discriminante, que utilizará grupos previamente conhecidos. Aqui, a própria organização dos objetos faz parte da solução.

A Figura 16.1 mostra uma mesma configuração bidimensional organizada de duas formas. A figura ilustra que os pontos observados, isoladamente, não determinam qual partição deve ser escolhida.




Figura 16.1: Diferentes partições de uma mesma configuração de observações.

As duas organizações mantêm os mesmos pontos e alteram somente a regra utilizada para reuni-los. A figura representa uma característica da técnica: a estrutura de grupos deve ser interpretada em relação ao critério que a produziu.

16.2 Representação dos objetos e proximidade

A matriz de dados não é a única forma de entrada da Análise de Agrupamentos. Quando as coordenadas dos objetos estão disponíveis, a proximidade pode ser calculada a partir das linhas de $\mathbf{X}$. Quando as relações entre os objetos já são fornecidas diretamente, a análise pode partir de uma matriz de dissimilaridades.

A distância euclidiana já foi definida em Definição 1.13. Para duas observações $\mathbf{x}_i$ e $\mathbf{x}_j$, utilizaremos diretamente

$$d_{ij} = \|\mathbf{x}_i - \mathbf{x}_j\|.$$

Não é necessário reconstruir suas propriedades métricas neste capítulo. O resultado será aplicado para definir a geometria de métodos como as K -médias e o método de Ward.

O Módulo 1 também estabeleceu em Definição 3.17 que uma matriz positiva definida pode modificar a geometria utilizada para medir comprimentos e distâncias. Assim, diferentes escolhas de métrica podem atribuir diferentes proximidades ao mesmo conjunto de observações. A distância de Mahalanobis constitui uma aplicação estatística dessa estrutura e já foi definida em Definição 8.9.

A Análise de Agrupamentos também pode receber como entrada uma matriz

$$\Delta = (\delta_{ij}) \in \mathbb{R}^{n \times n},$$

na qual δ_{ij} representa a dissimilaridade entre os objetos i e j .

Definição 16.1 (Dissimilaridade). Uma **dissimilaridade** é uma medida numérica de separação entre objetos na qual valores maiores representam menor proximidade. Uma dissimilaridade não precisa satisfazer todas as propriedades exigidas de uma distância métrica.

A definição de dissimilaridade amplia a formulação para situações em que a proximidade entre os objetos não satisfaz todas as propriedades de uma distância métrica.

Nos métodos hierárquicos desenvolvidos neste capítulo, será considerada uma matriz de dissimilaridades simétrica, com

$$\delta_{ij} \geq 0, \quad \delta_{ii} = 0$$

e

$$\delta_{ij} = \delta_{ji}.$$

A desigualdade triangular não será exigida.

De forma correspondente, uma similaridade atribui valores maiores a objetos considerados mais semelhantes. A transformação entre similaridade e dissimilaridade depende da medida adotada e não constitui uma operação universal.

A distinção entre matriz de atributos e matriz de dissimilaridades é sintetizada na Tabela 16.2.

Tabela 16.2: Formas de representação utilizadas na Análise de Agrupamentos.

Representação	Informação disponível	Consequência para a formulação
$\mathbf{X} \in \mathbb{R}^{n \times p}$	valores das p variáveis para cada objeto	a proximidade é construída a partir das coordenadas
$\Delta \in \mathbb{R}^{n \times n}$	dissimilaridades entre pares de objetos	o agrupamento pode ser formulado diretamente sobre as relações entre objetos

A escolha entre essas representações também delimita os métodos disponíveis. O critério das K -médias, por exemplo, utiliza explicitamente centroides no espaço das variáveis e requer as coordenadas das observações. Métodos hierárquicos podem ser formulados diretamente a partir de uma matriz de dissimilaridades, desde que a regra de ligação seja compatível com a informação disponível.

16.2.1 Efeito da escala

A dependência das distâncias em relação à escala já foi discutida no Módulo 1, e a padronização das variáveis foi formalizada no Módulo 2. A matriz de dados padronizados observada está dada em Equação 8.70. Neste capítulo, esses resultados têm uma consequência específica: modificar a escala modifica as proximidades utilizadas para construir os grupos.

A Figura 16.2 mostra essa consequência para uma configuração bidimensional. A figura não redefine a padronização; ela mostra seu efeito sobre o problema de agrupamento.

A ampliação da segunda coordenada aumenta sua contribuição para as distâncias. Um método baseado nessas distâncias passa a comparar os mesmos objetos segundo outra geometria.




Figura 16.2: Mudanças de escala alteram a geometria utilizada para comparar as observações.

A padronização deve ser entendida da mesma forma. Ela não constitui uma exigência geral da Análise de Agrupamentos. Sua utilização altera a contribuição relativa das variáveis e, portanto, altera o problema geométrico resolvido pelo método.

16.3 Partições

Uma das formas mais comuns de representar um agrupamento é por meio de uma partição rígida do conjunto de objetos.

Seja

$$\mathcal{I} = \{1, \dots, n\}$$

o conjunto dos índices das observações.

Definição 16.2 (Partição em grupos). Uma **partição em K grupos** é uma coleção

$$\mathcal{P} = \{C_1, \dots, C_K\}$$

de subconjuntos não vazios de $\mathcal{I}$ que satisfaz

$$C_k \cap C_\ell = \emptyset, \quad k \neq \ell,$$

e

$$\bigcup_{k=1}^K C_k = \mathcal{I}.$$

As duas condições estabelecem que:

- um objeto não pertence simultaneamente a dois grupos distintos;
- todos os objetos são atribuídos a algum grupo.

O número de elementos do grupo C_k será denotado por

$$n_k = |C_k|,$$

com

$$\sum_{k=1}^K n_k = n.$$

A partição é um objeto combinatório. Ela informa quais observações pertencem ao mesmo grupo, mas não determina sozinha o critério utilizado para obtê-la.

Uma representação equivalente pode ser construída por indicadores de pertinência,

$$g_{ik} = \begin{cases} 1, & i \in C_k, \\ 0, & i \notin C_k. \end{cases}$$

Para uma partição rígida,

$$\sum_{k=1}^K g_{ik} = 1, \quad i = 1, \dots, n. \quad (16.1)$$

16.3.1 Partições rígidas, difusas e probabilísticas

A partição rígida não é a única forma possível de representar agrupamentos.

Em uma estrutura **difusa**, pode-se associar a cada objeto um grau de pertencimento

$$u_{ik} \in [0, 1],$$

geralmente sujeito a

$$\sum_{k=1}^K u_{ik} = 1.$$

Em uma estrutura **probabilística**, podem ser atribuídas probabilidades

$$P(G_i = k \mid \mathbf{x}_i)$$

às diferentes possibilidades de pertencimento.

Essas representações não são equivalentes à partição rígida. Elas correspondem a diferentes definições matemáticas da associação entre um objeto e um grupo.

O desenvolvimento principal deste capítulo utilizará partições rígidas porque elas permitem formular diretamente os critérios geométricos de K -médias e dos métodos hierárquicos. As formulações probabilísticas serão retomadas posteriormente para mostrar outra interpretação possível de grupo.

16.4 Homogeneidade interna e separação

Uma partição só se torna uma solução de agrupamento depois que se estabelece um critério para comparar diferentes partições.

Considere

$$\mathcal{P} = \{C_1, \dots, C_K\}.$$

Um critério baseado em homogeneidade interna deve assumir valores melhores quando objetos pertencentes ao mesmo grupo apresentam pequena dispersão segundo a geometria escolhida.

Um critério baseado em separação deve favorecer grupos suficientemente distintos entre si.

Essas duas propriedades são relacionadas, mas não são equivalentes em qualquer método. A forma exata de medi-las depende da definição de grupo.

Para agrupamentos representados por centroides e distância euclidiana quadrática, a homogeneidade interna pode ser expressa por somas de quadrados. Essa escolha conduz ao critério das K -médias e permite utilizar diretamente a decomposição da dispersão estabelecida no Módulo 2.

O próximo passo consiste, portanto, em atribuir a cada grupo um centro representativo e mostrar por que a média aritmética surge como solução do problema de mínima dispersão quadrática.

16.5 Agrupamento por centroides

Uma partição pode ser representada geometricamente por um ponto que resume cada grupo. Para

$$\mathcal{P} = \{C_1, \dots, C_K\},$$

com

$$n_k = |C_k|,$$

o **centroide** do grupo C_k será denotado por

$$\mathbf{c}_k = \frac{1}{n_k} \sum_{i \in C_k} \mathbf{x}_i. \quad (16.2)$$

A notação $\mathbf{c}_k$ distingue o centro calculado a partir das observações de um vetor de médias populacional μ_k , que será utilizado posteriormente em técnicas formuladas a partir de populações ou grupos previamente definidos.

No agrupamento por centroides, a proximidade entre uma observação e um grupo é determinada por sua distância ao centro correspondente. Essa representação conduz naturalmente a critérios baseados na dispersão das observações em torno dos centroides.

16.5.1 Dispersão dentro e entre grupos

A decomposição da dispersão para grupos já foi estabelecida no Módulo 2. A matriz de dispersão intragrupos foi definida em Definição 8.14, a matriz entre grupos em Definição 8.15, e Proposição 8.11 demonstrou que

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}.$$

Naquele resultado, os grupos eram considerados conhecidos. Na Análise de Agrupamentos, a mesma decomposição adquire outra função: a partição passa a ser desconhecida e deve ser construída.

Para uma partição

$$\mathcal{P} = \{C_1, \dots, C_K\},$$

a matriz intragrupos pode ser escrita, utilizando os centroides de Equação 16.2, como

$$\mathbf{T}_{\text{intra}}(\mathcal{P}) = \sum_{k=1}^K \sum_{i \in C_k} (\mathbf{x}_i - \mathbf{c}_k) (\mathbf{x}_i - \mathbf{c}_k)^\top. \quad (16.3)$$

Tomando o traço,

$$\begin{aligned} \text{tr}[\mathbf{T}_{\text{intra}}(\mathcal{P})] &= \sum_{k=1}^K \sum_{i \in C_k} \text{tr}[(\mathbf{x}_i - \mathbf{c}_k) (\mathbf{x}_i - \mathbf{c}_k)^\top] \\ &= \sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \mathbf{c}_k\|^2. \end{aligned} \quad (16.4)$$

A expressão em Equação 16.4 transforma a matriz de dispersão do Módulo 2 em um critério escalar para comparar partições.

Quanto menores forem as distâncias quadráticas das observações aos centroides de seus grupos, menor será

$$\text{tr}(\mathbf{T}_{\text{intra}}).$$

Como a matriz total $\mathbf{T}$ não depende da partição e

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

segue também que

$$\text{tr}(\mathbf{T}) = \text{tr}(\mathbf{T}_{\text{intra}}) + \text{tr}(\mathbf{T}_{\text{entre}}). \quad (16.5)$$

Para K fixado, reduzir a dispersão intragrupos aumenta a parcela da dispersão atribuída às diferenças entre os centroides. Essa relação fornece a formulação utilizada pelas K -médias.

16.5.2 Formulação das K -médias

O método das K -médias define os grupos pela minimização da soma das distâncias euclidianas quadráticas das observações aos centroides correspondentes (Johnson; Wichern, 2007; MacQueen, 1967).

Definição 16.3 (Critério das K -médias). Para um número fixado de grupos K , considere os indicadores de pertinência g_{ik} e os centros

$$\mathbf{c}_1, \dots, \mathbf{c}_K \in \mathbb{R}^p.$$

O critério conjunto das K -médias é

$$Q_K(\{g_{ik}\}, \mathbf{c}_1, \dots, \mathbf{c}_K) = \sum_{i=1}^n \sum_{k=1}^K g_{ik} \|\mathbf{x}_i - \mathbf{c}_k\|^2, \quad (16.6)$$

sujeito a

$$g_{ik} \in \{0, 1\}$$

e

$$\sum_{k=1}^K g_{ik} = 1, \quad i = 1, \dots, n,$$

e

$$\sum_{i=1}^n g_{ik} \geq 1, \quad k = 1, \dots, K.$$

A primeira condição atribui cada observação a exatamente um grupo. A segunda garante que os K grupos sejam não vazios.

Para uma partição

$$\mathcal{P} = \{C_1, \dots, C_K\},$$

o critério após a minimização em relação aos centros é

$$J_K(\mathcal{P}) = \sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \mathbf{c}_k\|^2, \quad (16.7)$$

em que

$$\mathbf{c}_k = \frac{1}{n_k} \sum_{i \in C_k} \mathbf{x}_i.$$

A propriedade de que esses centroides minimizam o critério para uma partição fixada será estabelecida em Proposição 16.1.

A solução global pode ser representada por

$$\mathcal{P}^* \in \arg \min_{\mathcal{P}} J_K(\mathcal{P}). \quad (16.8)$$

Pela relação em Equação 16.4,

$$J_K(\mathcal{P}) = \text{tr}[\mathbf{T}_{\text{intra}}(\mathcal{P})]. \quad (16.9)$$

Assim, as K -médias utilizam diretamente a estrutura de dispersão introduzida no Módulo 2. A diferença está no papel dos grupos: naquele módulo, a partição era dada; aqui, ela é parte do problema de otimização.

A partir de Equação 16.5,

$$J_K(\mathcal{P}) = \text{tr}(\mathbf{T}) - \text{tr}[\mathbf{T}_{\text{entre}}(\mathcal{P})].$$

Como

$$\text{tr}(\mathbf{T})$$

é constante para a mesma matriz de dados, minimizar o critério das K -médias equivale a maximizar

$$\text{tr} [\mathbf{T}_{\text{entre}}(\mathcal{P})]. \quad (16.10)$$

As duas formulações descrevem o mesmo problema para K fixado: procurar grupos compactos em torno de seus centroides produz, simultaneamente, maior separação quadrática entre esses centroides.

16.5.3 O centroide como minimizador

A presença da média de cada grupo em Equação 16.7 decorre do critério quadrático. Ela é a solução exata do problema de representar um conjunto de observações por um único ponto.

Proposição 16.1 (Centroide e soma de quadrados). *Considere um grupo não vazio C com n_C observações e centroide*

$$\mathbf{c}_C = \frac{1}{n_C} \sum_{i \in C} \mathbf{x}_i.$$

Para qualquer

$$\mathbf{c} \in \mathbb{R}^p,$$

tem-se

$$\sum_{i \in C} \|\mathbf{x}_i - \mathbf{c}\|^2 = \sum_{i \in C} \|\mathbf{x}_i - \mathbf{c}_C\|^2 + n_C \|\mathbf{c} - \mathbf{c}_C\|^2. \quad (16.11)$$

Consequentemente, o centroide é o único minimizador:

$$\arg \min_{\mathbf{c} \in \mathbb{R}^p} \sum_{i \in C} \|\mathbf{x}_i - \mathbf{c}\|^2 = \{\mathbf{c}_C\}.$$

Comprovação. Para cada observação,

$$\mathbf{x}_i - \mathbf{c} = (\mathbf{x}_i - \mathbf{c}_C) + (\mathbf{c}_C - \mathbf{c}).$$

Logo,

$$\begin{aligned} \|\mathbf{x}_i - \mathbf{c}\|^2 &= \|\mathbf{x}_i - \mathbf{c}_C\|^2 + \|\mathbf{c}_C - \mathbf{c}\|^2 \\ &\quad + 2(\mathbf{x}_i - \mathbf{c}_C)^\top (\mathbf{c}_C - \mathbf{c}). \end{aligned}$$

Somando sobre $i \in C$,

$$\sum_{i \in C} (\mathbf{x}_i - \mathbf{c}_C) = \mathbf{0},$$

de modo que os termos cruzados desaparecem. Obtém-se, então, Equação 16.11.

A primeira parcela dessa expressão não depende de $\mathbf{c}$, enquanto

$$n_C \|\mathbf{c} - \mathbf{c}_C\|^2 \geq 0.$$

O valor mínimo ocorre em

$$\mathbf{c} = \mathbf{c}_C.$$

□

O resultado mostra que o uso da média não constitui uma escolha independente do critério. Ele decorre da utilização da distância euclidiana quadrática.

Alterar a medida de perda pode alterar o representante ótimo do grupo. Por isso, o centroide deve ser interpretado em conjunto com a função objetivo que o produz.

16.5.4 Partição para centroides fixados

O critério também possui uma estrutura simples quando os centroides

$$\mathbf{c}_1, \dots, \mathbf{c}_K$$

são considerados fixos.

Para uma observação $\mathbf{x}_i$, sua contribuição ao critério será

$$\|\mathbf{x}_i - \mathbf{c}_k\|^2$$

se ela for atribuída ao grupo C_k .

A menor contribuição possível é obtida escolhendo um grupo pertencente a

$$\arg \min_{1 \leq k \leq K} \|\mathbf{x}_i - \mathbf{c}_k\|^2. \quad (16.12)$$

Assim, para centroides fixados, cada observação é associada a um centroide mais próximo.

Os dois resultados anteriores descrevem duas propriedades do critério, sintetizadas na Tabela 16.3.

Tabela 16.3: Estrutura do critério das K -médias quando se fixa uma das partes do problema.

Elemento fixado	Quantidade determinada pelo critério
Partição $\mathcal{P}$	cada centro ótimo é o centroide das observações do grupo
Centroides $\mathbf{c}_1, \dots, \mathbf{c}_K$	cada observação é atribuída a um centroide de menor distância

Essa estrutura explica a formulação dos procedimentos iterativos utilizados para calcular soluções das K -médias. Os algoritmos, as estratégias de inicialização e os critérios de parada pertencem à implementação da técnica e não serão desenvolvidos neste capítulo.

16.5.5 Geometria das regiões de alocação

Para centroides fixados, a regra em Equação 16.12 divide o espaço em regiões formadas pelos pontos mais próximos de cada centroide.

Para dois centroides $\mathbf{c}_k$ e $\mathbf{c}_\ell$, a fronteira entre suas regiões satisfaz

$$\|\mathbf{x} - \mathbf{c}_k\|^2 = \|\mathbf{x} - \mathbf{c}_\ell\|^2.$$

Expandindo as duas normas,

$$\mathbf{x}^\top \mathbf{x} - 2\mathbf{c}_k^\top \mathbf{x} + \mathbf{c}_k^\top \mathbf{c}_k = \mathbf{x}^\top \mathbf{x} - 2\mathbf{c}_\ell^\top \mathbf{x} + \mathbf{c}_\ell^\top \mathbf{c}_\ell.$$

Os termos

$$\mathbf{x}^\top \mathbf{x}$$

se cancelam, resultando em

$$2(\mathbf{c}_\ell - \mathbf{c}_k)^\top \mathbf{x} = \mathbf{c}_\ell^\top \mathbf{c}_\ell - \mathbf{c}_k^\top \mathbf{c}_k. \quad (16.13)$$

A fronteira é, portanto, um hiperplano.

As regiões definidas simultaneamente por todos os centroides formam uma partição de Voronoi do espaço. Essa geometria explica por que as K -médias favorecem grupos representáveis por regiões convexas associadas a centros.

A Figura 16.3 representa uma solução com três centroides. As regiões de fundo indicam qual centroide é o mais próximo em cada posição do plano, enquanto os símbolos maiores identificam os centroides da solução.




Figura 16.3: Centroides e regiões de alocação definidas pela distância euclidiana.

A figura mostra duas propriedades da formulação. Cada grupo é representado por um centroide, e a alocação é determinada pela geometria euclidiana relativa a esses centros. A forma dos grupos obtidos pelo critério está vinculada a essa representação.

Exemplo 16.1 (Comparação de duas partições). Considere quatro observações unidimensionais,

$$x_1 = 1, \quad x_2 = 2, \quad x_3 = 8, \quad x_4 = 9,$$

e duas partições candidatas com

$$K = 2.$$

Na primeira,

$$\mathcal{P}_1 = \{\{1, 2\}, \{3, 4\}\}.$$

Os centroides são

$$c_1 = 1,5$$

e

$$c_2 = 8,5.$$

Logo,

$$\begin{aligned} J_2(\mathcal{P}_1) &= (1 - 1,5)^2 + (2 - 1,5)^2 \\ &\quad + (8 - 8,5)^2 + (9 - 8,5)^2 \\ &= 1. \end{aligned}$$

Considere agora

$$\mathcal{P}_2 = \{\{1, 3\}, \{2, 4\}\}.$$

Os centroides são

$$c_1 = 4,5$$

e

$$c_2 = 5,5.$$

Nesse caso,

$$\begin{aligned} J_2(\mathcal{P}_2) &= (1 - 4,5)^2 + (8 - 4,5)^2 \\ &\quad + (2 - 5,5)^2 + (9 - 5,5)^2 \\ &= 49. \end{aligned}$$

O critério atribui valor menor à primeira partição porque as observações estão muito mais concentradas em torno dos respectivos centroides.

O exemplo também mostra que o método não procura apenas separar pontos distantes. A solução é definida pela soma global das dispersões quadráticas dentro dos grupos.

16.5.6 Existência e não unicidade da solução

Para uma matriz de dados finita e um valor fixado de

$$1 \leq K \leq n,$$

existe pelo menos uma partição que minimiza Equação 16.7.

O número de partições possíveis das n observações em K grupos não vazios é finito. Como

$$J_K(\mathcal{P}) \geq 0$$

para toda partição admissível, o menor valor do critério é atingido por pelo menos uma delas.

A existência de um mínimo global não implica unicidade.

Podem existir duas partições distintas

$$\mathcal{P}_1 \neq \mathcal{P}_2$$

tais que

$$J_K(\mathcal{P}_1) = J_K(\mathcal{P}_2) = \min_{\mathcal{P}} J_K(\mathcal{P}).$$

Também há uma indeterminação de rótulos. As coleções

$$\{C_1, C_2, \dots, C_K\}$$

e

$$\{C_{\pi(1)}, C_{\pi(2)}, \dots, C_{\pi(K)}\},$$

para qualquer permutação π , representam a mesma partição substantiva.

Essa indeterminação é diferente daquela encontrada na Análise Fatorial. Na Análise Fatorial, diferentes orientações podem representar a mesma estrutura de covariâncias. Nas K -médias,

os rótulos dos grupos são arbitrários e podem ainda existir diferentes partições geométricas com o mesmo valor mínimo.

16.5.7 Natureza do problema de otimização

O problema completo das K -médias combina duas escolhas:

- a atribuição de cada observação a um grupo;
- a posição dos centroides.

Para uma partição fixada, Proposição 16.1 fornece diretamente os centroides ótimos. Para centroides fixados, Equação 16.12 fornece diretamente a melhor atribuição de cada observação.

O problema conjunto permanece combinatório. A função objetivo pode apresentar diferentes soluções localmente estáveis, e procedimentos iterativos podem atingir soluções distintas conforme seu ponto de partida.

Essa propriedade pertence ao problema matemático das K -médias. Estratégias computacionais para inicialização, repetição e comparação de soluções serão tratadas na etapa de implementação.

O valor de K também faz parte da especificação do problema em Equação 16.8. Modificar K altera o conjunto de partições admissíveis e a própria função de otimização considerada. Os critérios utilizados para escolher o número de grupos pertencem à condução aplicada da análise e não serão desenvolvidos neste capítulo.

16.5.8 Formulação populacional do critério das K -médias

A formulação das K -médias também pode ser expressa no nível populacional.

Considere o vetor aleatório

$$\mathbf{X} \in \mathbb{R}^p$$

e K centros

$$\mathbf{c}_1, \dots, \mathbf{c}_K.$$

O risco quadrático de quantização é

$$R_K(\mathbf{c}_1, \dots, \mathbf{c}_K) = E \left[\min_{1 \leq k \leq K} \|\mathbf{X} - \mathbf{c}_k\|^2 \right], \quad (16.14)$$

desde que o segundo momento necessário exista.

Uma solução populacional procura centros pertencentes a

$$\arg \min_{\mathbf{c}_1, \dots, \mathbf{c}_K} R_K(\mathbf{c}_1, \dots, \mathbf{c}_K).$$

Para uma amostra aleatória multivariada, conforme Definição 10.1, a esperança populacional é substituída por sua média empírica:

$$\widehat{R}_K(\mathbf{c}_1, \dots, \mathbf{c}_K) = \frac{1}{n} \sum_{i=1}^n \min_{1 \leq k \leq K} \|\mathbf{x}_i - \mathbf{c}_k\|^2. \quad (16.15)$$

Para centros fixados, a atribuição ao centro mais próximo fornece

$$n\widehat{R}_K(\mathbf{c}_1, \dots, \mathbf{c}_K) = \sum_{i=1}^n \min_{1 \leq k \leq K} \|\mathbf{x}_i - \mathbf{c}_k\|^2.$$

Minimizando também em relação aos centros e utilizando Proposição 16.1, obtém-se

$$\min_{\mathbf{c}_1, \dots, \mathbf{c}_K} n\widehat{R}_K(\mathbf{c}_1, \dots, \mathbf{c}_K) = \min_{\mathcal{P}} J_K(\mathcal{P}). \quad (16.16)$$

A formulação populacional esclarece o significado estatístico do critério: a solução amostral procura uma configuração de centros que minimize empiricamente a distância quadrática ao centro mais próximo.

Essa interpretação também delimita o alcance de resultados de consistência. Resultados de consistência para K -médias referem-se à convergência dos minimizadores empíricos para a solução do problema de quantização populacional, sob condições adicionais sobre a distribuição e a solução (Pollard, 1981). Essa convergência não demonstra, por si só, a existência de classes naturais independentes do critério.

16.5.9 Efeito de transformações sobre as K -médias

A formulação por distância euclidiana permite recuperar diretamente resultados geométricos do Módulo 1.

Uma translação comum

$$\mathbf{x}_i^* = \mathbf{x}_i + \mathbf{b}$$

também desloca cada centroide:

$$\mathbf{c}_k^* = \mathbf{c}_k + \mathbf{b}.$$

Consequentemente,

$$\|\mathbf{x}_i^* - \mathbf{c}_k^*\|^2 = \|\mathbf{x}_i - \mathbf{c}_k\|^2.$$

O critério das K -médias é, portanto, invariante a uma translação comum das observações.

O mesmo ocorre sob uma transformação ortogonal

$$\mathbf{x}_i^* = \mathbf{Q}\mathbf{x}_i.$$

A preservação de produtos internos, normas, ângulos e distâncias por transformações ortogonais foi estabelecida em Proposição 4.10. Aplicada às observações e aos centroides, essa propriedade mantém as distâncias utilizadas pelo critério das K -médias. Os centroides transformados são

$$\mathbf{c}_k^* = \mathbf{Q}\mathbf{c}_k,$$

e

$$\|\mathbf{Q}(\mathbf{x}_i - \mathbf{c}_k)\|^2 = \|\mathbf{x}_i - \mathbf{c}_k\|^2.$$

Assim, rotações e reflexões ortogonais preservam o valor do critério e a estrutura geométrica da solução, salvo a transformação das próprias coordenadas.

Mudanças individuais de escala não apresentam essa propriedade. Como já ilustrado em Figura 16.2, elas modificam as distâncias relativas e podem alterar a partição ótima.

A Tabela 16.4 resume essas consequências.

Tabela 16.4: Efeito de transformações geométricas sobre o critério das K -médias.

Transformação das observações	Efeito sobre as distâncias euclidianas	Efeito sobre o problema das K -médias
translação comum	preservadas	preserva o critério e a partição correspondente
rotação ortogonal	preservadas	preserva o critério e transforma rigidamente a solução

Transformação das observações	Efeito sobre as distâncias euclidianas	Efeito sobre o problema das K -médias
reflexão ortogonal	preservadas	preserva o critério e transforma rigidamente a solução
escala comum por $a \neq 0$	multiplicadas por $ a $	multiplica J_K por a^2 , sem alterar a ordenação das partições
escalas diferentes por variável	alteradas de forma desigual	pode alterar a partição ótima

Essa análise mostra que as propriedades geométricas das transformações estudadas no Módulo 1 têm consequência direta na técnica: somente transformações que preservam ou modificam uniformemente a geometria euclidiana mantêm a mesma organização relativa das partições.

A formulação por centroides representa uma definição específica de grupo: regiões compactas organizadas em torno de centros. Os métodos hierárquicos utilizam outra estrutura. Em vez de procurar diretamente uma única partição que minimize uma função global, eles constroem uma sequência de agrupamentos aninhados a partir de uma regra de proximidade entre conjuntos.

16.6 Estrutura dos métodos hierárquicos

As K -médias procuram diretamente uma partição para um número K previamente fixado de grupos. Os métodos hierárquicos utilizam outra representação: constroem uma sequência de partições relacionadas por inclusão.

Em um procedimento aglomerativo, parte-se da partição formada por n grupos unitários,

$$\mathcal{P}_n = \{\{1\}, \dots, \{n\}\},$$

e, a cada etapa, dois grupos são fundidos. Após uma fusão, obtém-se uma nova partição com um grupo a menos, até chegar a

$$\mathcal{P}_1 = \{\{1, \dots, n\}\}.$$

As partições sucessivas são aninhadas: um grupo formado em determinada etapa permanece contido em algum grupo das etapas posteriores.

Definição 16.4 (Hierarquia de agrupamentos). Uma **hierarquia aglomerativa** é uma sequência de partições

$$\mathcal{P}_n, \mathcal{P}_{n-1}, \dots, \mathcal{P}_1,$$

na qual $\mathcal{P}_{r-1}$ é obtida de $\mathcal{P}_r$ pela fusão de exatamente dois grupos.

A construção da hierarquia exige uma regra para comparar grupos. O Módulo 1 forneceu a distância entre observações em Definição 1.13 e outras geometrias por meio de normas induzidas. No agrupamento hierárquico, essa informação deve ser estendida de pares de observações para pares de conjuntos.

Considere dois grupos não vazios

$$A \subseteq \{1, \dots, n\}$$

e

$$B \subseteq \{1, \dots, n\}.$$

Uma **regra de ligação** define uma dissimilaridade

$$D(A, B)$$

entre esses grupos. Diferentes regras utilizam de maneiras distintas as dissimilaridades entre seus elementos e, por isso, podem produzir hierarquias diferentes a partir da mesma matriz Δ .

16.6.1 Ligações simples, completa e média

Três regras podem ser construídas diretamente a partir das dissimilaridades entre pares de objetos.

Na **ligação simples**,

$$D_{\text{simples}}(A, B) = \min_{\substack{i \in A \\ j \in B}} \delta_{ij}. \quad (16.17)$$

A proximidade entre os grupos é determinada pelo par mais próximo. A fusão pode, portanto, ocorrer quando existe uma conexão curta entre dois conjuntos, mesmo que outros elementos estejam relativamente afastados.

Na **ligação completa**,

$$D_{\text{completa}}(A, B) = \max_{\substack{i \in A \\ j \in B}} \delta_{ij}. \quad (16.18)$$

A comparação é determinada pelo par mais distante. Essa definição favorece fusões nas quais todos os elementos dos dois grupos permanecem relativamente próximos.

Na **ligação média**,

$$D_{\text{media}}(A, B) = \frac{1}{|A||B|} \sum_{i \in A} \sum_{j \in B} \delta_{ij}. \quad (16.19)$$

A dissimilaridade entre os grupos corresponde à média das dissimilaridades entre todos os pares formados por um elemento de A e um elemento de B .

As três regras utilizam a mesma matriz de dissimilaridades, mas representam noções distintas de proximidade entre conjuntos.

A Tabela 16.5 compara as três definições de proximidade entre grupos.

Tabela 16.5: Critérios de ligação construídos a partir das dissimilaridades entre objetos.

Regra de ligação	Dissimilaridade entre A e B	Estrutura privilegiada
simples	menor dissimilaridade entre pares	conexão entre elementos próximos
completa	maior dissimilaridade entre pares	controle da maior separação interna após a fusão
média	média das dissimilaridades entre pares	proximidade média entre os conjuntos

A diferença entre os critérios pode ser observada mesmo com poucos objetos. Considere dois grupos

$$A = \{1, 2\}$$

e

$$B = \{3, 4\},$$

com dissimilaridades entre seus elementos dadas por

$$\delta_{13} = 2, \quad \delta_{14} = 8, \quad \delta_{23} = 3, \quad \delta_{24} = 7.$$

Então,

$$D_{\text{simples}}(A, B) = 2,$$

$$D_{\text{completa}}(A, B) = 8$$

e

$$D_{\text{media}}(A, B) = \frac{2 + 8 + 3 + 7}{4} = 5.$$

Não há contradição entre os três resultados. Cada valor responde a uma definição diferente da distância entre grupos.

A escolha da ligação faz, portanto, parte da definição matemática do agrupamento hierárquico.

16.6.2 Método de Ward e dispersão intragrupos

O método de Ward utiliza uma construção diferente das três ligações anteriores. Na formulação desenvolvida aqui, os objetos possuem coordenadas em um espaço euclidiano e a decisão de fusão é baseada no aumento da dispersão quadrática intragrupos (Ward, 1963).

Essa interpretação depende da estrutura euclidiana que permite definir centroides e somas de quadrados. Uma matriz arbitrária de dissimilaridades não possui, por si só, a mesma interpretação em termos de SSCP.

Essa formulação permite reutilizar diretamente a matriz $\mathbf{T}_{\text{intra}}$ definida em Definição 8.14 e a decomposição de Proposição 8.11.

Considere dois grupos A e B , com tamanhos

$$n_A = |A|, \quad n_B = |B|,$$

e centroides

$$\mathbf{c}_A = \frac{1}{n_A} \sum_{i \in A} \mathbf{x}_i$$

e

$$\mathbf{c}_B = \frac{1}{n_B} \sum_{i \in B} \mathbf{x}_i.$$

Após a fusão,

$$C = A \cup B,$$

o novo centroide é

$$\mathbf{c}_C = \frac{n_A \mathbf{c}_A + n_B \mathbf{c}_B}{n_A + n_B}. \quad (16.20)$$

Antes da fusão, a contribuição desses dois grupos para a dispersão intragrupos é

$$J(A) + J(B) = \sum_{i \in A} \|\mathbf{x}_i - \mathbf{c}_A\|^2 + \sum_{i \in B} \|\mathbf{x}_i - \mathbf{c}_B\|^2.$$

Depois da fusão, a contribuição passa a ser

$$J(A \cup B) = \sum_{i \in A \cup B} \|\mathbf{x}_i - \mathbf{c}_C\|^2.$$

O aumento produzido pela fusão é

$$\Delta_{\text{Ward}}(A, B) = J(A \cup B) - J(A) - J(B). \quad (16.21)$$

O resultado obtido em Proposição 16.1 pode ser aplicado separadamente aos grupos A e B . Para as observações de A ,

$$\sum_{i \in A} \|\mathbf{x}_i - \mathbf{c}_C\|^2 = \sum_{i \in A} \|\mathbf{x}_i - \mathbf{c}_A\|^2 + n_A \|\mathbf{c}_A - \mathbf{c}_C\|^2.$$

Analogamente,

$$\sum_{i \in B} \|\mathbf{x}_i - \mathbf{c}_C\|^2 = \sum_{i \in B} \|\mathbf{x}_i - \mathbf{c}_B\|^2 + n_B \|\mathbf{c}_B - \mathbf{c}_C\|^2.$$

Substituindo essas expressões em Equação 16.21,

$$\Delta_{\text{Ward}}(A, B) = n_A \|\mathbf{c}_A - \mathbf{c}_C\|^2 + n_B \|\mathbf{c}_B - \mathbf{c}_C\|^2.$$

De Equação 16.20,

$$\mathbf{c}_A - \mathbf{c}_C = \frac{n_B}{n_A + n_B} (\mathbf{c}_A - \mathbf{c}_B)$$

e

$$\mathbf{c}_B - \mathbf{c}_C = -\frac{n_A}{n_A + n_B} (\mathbf{c}_A - \mathbf{c}_B).$$

Logo,

$$\Delta_{\text{Ward}}(A, B) = \frac{n_A n_B}{n_A + n_B} \|\mathbf{c}_A - \mathbf{c}_B\|^2. \quad (16.22)$$

Proposição 16.2 (Incremento de dispersão no método de Ward). *A fusão de dois grupos A e B aumenta a soma de quadrados intragrupos em*

$$\Delta_{\text{Ward}}(A, B) = \frac{n_A n_B}{n_A + n_B} \|\mathbf{c}_A - \mathbf{c}_B\|^2.$$

O método de Ward seleciona, em cada etapa, uma fusão com menor aumento em

$$\text{tr}(\mathbf{T}_{\text{intra}}).$$

A expressão em Equação 16.22 apresenta duas componentes. A distância entre os centroides mede a separação geométrica dos grupos, enquanto

$$\frac{n_A n_B}{n_A + n_B}$$

incorpora seus tamanhos.

Ward e K -médias compartilham, portanto, a mesma estrutura de dispersão quadrática. A diferença está na forma como a solução é construída. As K -médias procuram uma partição para um K fixado; Ward constrói sucessivamente uma hierarquia de fusões e controla o aumento local da dispersão intragrupos.

A Figura 16.4 representa a diferença conceitual entre ligação simples, ligação completa e Ward para dois grupos.




Figura 16.4: Diferentes critérios utilizam diferentes características para medir a proximidade entre dois grupos.

Na ligação simples, apenas o par mais próximo determina a comparação. Na ligação completa, utiliza-se o par mais afastado. Em Ward, a distância entre centroides participa de uma expressão ponderada pelos tamanhos dos grupos e representa o aumento produzido na dispersão intragrupos.

A ligação média não aparece na figura porque utiliza simultaneamente todos os pares entre os dois grupos e não pode ser representada por um único segmento.

16.6.3 Dendrograma e níveis de fusão

A sequência produzida por um método hierárquico pode ser representada por um dendrograma.

Cada folha corresponde a um objeto. As uniões representam fusões entre grupos, e a altura associada a uma fusão registra o valor do critério no momento em que ela ocorre.

Definição 16.5 (Dendrograma). Um **dendrograma** é uma representação gráfica de uma hierarquia de agrupamentos na qual as folhas representam os objetos e as alturas das junções registram os níveis em que grupos são fundidos.

O dendrograma representa toda a sequência de partições produzida pelo método. Uma partição específica com K grupos pode ser identificada por uma etapa da sequência hierárquica. Quando

A Figura 16.5 apresenta uma hierarquia simples construída a partir de seis objetos.



16.6.4 Ultramétrica induzida pela hierarquia

A hierarquia também define uma nova dissimilaridade entre objetos.

Para dois objetos i e j , considere a altura em que eles aparecem pela primeira vez no mesmo grupo do dendrograma. Denote essa altura por

$$d_{\text{cop}}(i, j).$$

Essa quantidade é denominada **dissimilaridade cofenética**.

Definição 16.6 (Dissimilaridade cofenética). A **dissimilaridade cofenética** entre dois objetos é o nível da hierarquia no qual eles passam, pela primeira vez, a pertencer ao mesmo grupo.

A estrutura hierárquica impõe uma propriedade mais forte que a desigualdade triangular usual.

Definição 16.7 (Ultramétrica). Uma distância d_U é uma **ultramétrica** quando, para quaisquer três objetos i, j e k ,

$$d_U(i, k) \leq \max \{d_U(i, j), d_U(j, k)\}. \quad (16.23)$$

Quando os níveis de fusão da hierarquia são não decrescentes, a dissimilaridade cofenética definida por essas alturas é ultramétrica.

Para compreender essa propriedade, considere três objetos. Se i e j já pertencem ao mesmo grupo em determinado nível e j e k também pertencem ao mesmo grupo nesse nível, então a estrutura aninhada da hierarquia implica que i e k também pertencem ao mesmo grupo nesse nível ou em um nível inferior. Consequentemente,

$$d_{\text{cop}}(i, k) \leq \max \{d_{\text{cop}}(i, j), d_{\text{cop}}(j, k)\}.$$

Sob essa condição de monotonicidade dos níveis de fusão, o dendrograma pode ser interpretado como uma representação de uma geometria ultramétrica construída a partir das dissimilaridades originais.

Essa geometria não precisa reproduzir exatamente a matriz Δ . O método hierárquico transforma a estrutura inicial de proximidades em uma estrutura aninhada de grupos e, consequentemente, em uma nova relação de proximidade.

16.6.5 Uma partição e uma hierarquia representam objetos diferentes

As K -médias produzem diretamente uma partição

$$\mathcal{P} = \{C_1, \dots, C_K\}.$$

Um método hierárquico produz uma coleção ordenada de partições aninhadas. Essa diferença modifica o tipo de informação fornecida pela técnica e é sintetizada na Tabela 16.6.

Tabela 16.6: Estruturas produzidas por diferentes formulações de agrupamento.

Estrutura	Resultado principal	Critério
K -médias	uma partição para K fixado	minimização da dispersão quadrática intragrupos
ligação simples	uma hierarquia	menor dissimilaridade entre grupos
ligação completa	uma hierarquia	maior dissimilaridade entre grupos
ligação média	uma hierarquia	média das dissimilaridades entre grupos
Ward	uma hierarquia	menor aumento da dispersão intragrupos

A existência de diferentes critérios mostra que “grupo” não corresponde a um único objeto matemático. Nas K -médias, um grupo é representado por proximidade a um centroide. Na ligação simples, a formação de grupos depende da conectividade produzida por pares próximos. Na ligação completa, exige-se controle da maior separação entre os elementos que serão reunidos. Em Ward, a fusão é avaliada por seu efeito sobre a dispersão quadrática interna.

Essa diferença será ampliada na próxima seção ao considerar formulações nas quais grupos são definidos como componentes de uma distribuição probabilística ou como regiões de elevada densidade.

16.7 Diferentes definições matemáticas de grupo

As formulações anteriores mostram que a expressão **grupo** não identifica um único objeto matemático. Nas K -médias, um grupo é organizado em torno de um centroide. Nos métodos hierárquicos, sua formação depende de uma regra de ligação e da sequência de fusões.

Outras formulações podem definir grupos a partir de modelos probabilísticos ou de regiões de concentração das observações. Essas abordagens não constituem versões equivalentes de um mesmo critério. Elas atribuem significados diferentes à estrutura procurada.

A Tabela 16.7 sintetiza algumas dessas definições.

Tabela 16.7: Diferentes definições matemáticas de grupo.

Formulação	Representação de um grupo	Estrutura utilizada
centroides	conjunto de observações próximas de um centro	distância e dispersão quadrática
ligação simples	conjunto conectado por elementos próximos	menor dissimilaridade entre grupos
ligação completa	conjunto cuja maior separação é controlada	maior dissimilaridade entre grupos
Ward	conjunto cuja fusão produz pequeno aumento da dispersão	SSCP intragrupos
modelo de mistura	componente de uma distribuição probabilística	densidades e probabilidades de pertencimento
densidade	região conectada de elevada concentração de observações	densidade e conectividade

A tabela explica por que métodos diferentes podem produzir soluções distintas sem que uma delas seja necessariamente incorreta. Cada método resolve um problema diferente.

16.7.1 Formulação probabilística de grupos

Os critérios estudados até aqui foram formulados principalmente por distâncias, dispersões e relações entre conjuntos. Uma definição diferente pode ser obtida por meio de um modelo probabilístico.

Considere uma variável categórica latente

$$G \in \{1, \dots, K\},$$

com

$$P(G = k) = \pi_k, \quad \pi_k > 0,$$

e

$$\sum_{k=1}^K \pi_k = 1.$$

Condicionalmente ao grupo,

$$\mathbf{X} \mid \mathbf{G} = k$$

possui uma distribuição com densidade

$$f_k(\mathbf{x}; \theta_k).$$

A densidade marginal de $\mathbf{X}$ é

$$f(\mathbf{x}) = \sum_{k=1}^K \pi_k f_k(\mathbf{x}; \theta_k). \quad (16.24)$$

Definição 16.8 (Modelo de mistura para agrupamento). Um **modelo de mistura** representa a distribuição das observações como uma combinação de K componentes,

$$f(\mathbf{x}) = \sum_{k=1}^K \pi_k f_k(\mathbf{x}; \theta_k),$$

em que π_k é a probabilidade de pertencimento à componente k e f_k descreve a distribuição das observações condicionada a essa componente.

Nessa formulação, o grupo é representado por uma variável aleatória categórica não observada. A posição de uma observação em relação aos grupos pode ser descrita pelas probabilidades condicionais

$$P(\mathbf{G} = k \mid \mathbf{X} = \mathbf{x}).$$

Essa estrutura utiliza os fundamentos probabilísticos do Módulo 2, mas resolve um problema diferente daquele da Análise Fatorial. No modelo de fatores comuns de Definição 15.1, as variáveis latentes são contínuas e explicam a estrutura de covariâncias entre variáveis observadas. No modelo de mistura, a variável latente é categórica e representa a componente à qual uma observação está associada.

Os algoritmos utilizados para estimar os parâmetros de uma mistura e calcular probabilidades de pertencimento pertencem à implementação da técnica e não serão desenvolvidos neste capítulo.

A formulação probabilística também não estabelece que toda estrutura encontrada corresponda a uma classe substantiva existente fora do modelo. Os grupos são componentes da distribuição especificada, e sua interpretação depende da adequação dessa representação ao problema analisado.

16.7.2 Grupos definidos por densidade

Uma terceira noção pode ser formulada diretamente a partir da concentração da distribuição no espaço das observações.

Se $\mathbf{X}$ possui densidade

$$f(\mathbf{x}),$$

considere, para um nível

$$\lambda > 0,$$

o conjunto

$$L_\lambda = \{\mathbf{x} \in \mathbb{R}^p : f(\mathbf{x}) \geq \lambda\}. \quad (16.25)$$

As componentes conectadas de L_λ podem representar regiões distintas de elevada densidade.

Essa definição permite considerar grupos com formas que não precisam ser adequadamente representadas por centroides ou regiões de Voronoi. O critério passa a ser a existência de regiões densas separadas por regiões de menor concentração.

A noção de grupo baseada em densidade também explica por que métodos construídos para esse objetivo podem produzir soluções muito diferentes das K -médiãs. Os dois procedimentos não discordam sobre uma mesma função objetivo; eles adotam definições diferentes de estrutura.

Métodos computacionais baseados em densidade serão tratados posteriormente. Neste capítulo, a formulação serve para mostrar que proximidade a um centroide, conectividade e concentração probabilística são conceitos distintos.

16.8 Dependência da solução

Uma solução de agrupamento é condicionada pelas escolhas que definem o problema. Algumas dessas escolhas atuam antes da construção dos grupos; outras pertencem ao próprio critério.

A Tabela 16.8 organiza essas dependências.

Tabela 16.8: Elementos dos quais depende uma solução de agrupamento.

Elemento modificado	Estrutura alterada	Consequência possível
conjunto de variáveis	representação dos objetos	proximidades e grupos podem mudar
escala das variáveis	geometria do espaço	variáveis recebem pesos relativos diferentes
métrica ou dissimilaridade	relação de proximidade	pares considerados próximos podem mudar
número K	conjunto de partições admissíveis	muda o problema das K -médias
regra de ligação	proximidade entre grupos	muda a hierarquia
função objetivo	definição de agrupamento	muda a estrutura procurada
modelo probabilístico	significado da variável latente de grupo	mudam probabilidades e componentes
critério de densidade	definição de região concentrada	mudam forma e conectividade dos grupos

Essa dependência não deve ser tratada como uma deficiência da técnica. Ela decorre do fato de que agrupamento é uma classe de problemas definida por diferentes conceitos de proximidade e organização.

16.8.1 Dependência das variáveis

Cada observação é representada pelo vetor

$$\mathbf{x}_i \in \mathbb{R}^p.$$

Adicionar ou retirar uma variável modifica essa representação e pode alterar as distâncias entre os objetos.

O agrupamento obtido pertence, portanto, ao espaço de variáveis escolhido para representar as unidades.

Essa característica aproxima a técnica das discussões anteriores sobre ACP e Análise Fatorial. Nos três casos, a estrutura encontrada depende do conjunto de variáveis incluído, embora o objeto procurado seja diferente.

16.8.2 Dependência da escala e da métrica

O efeito da escala foi ilustrado em Figura 16.2. A escolha de uma métrica possui efeito mais geral: ela determina a geometria na qual proximidade e separação serão avaliadas.

Os resultados do Módulo 1 sobre normas e geometrias induzidas permitem interpretar essa escolha de forma direta. Alterar a métrica significa alterar comprimentos e distâncias e, portanto, alterar o problema de agrupamento.

16.8.3 Dependência da forma dos grupos

O critério das K -médias representa cada grupo por um centroide e utiliza regiões de Voronoi. Essa estrutura favorece grupos adequadamente descritos por proximidade a centros.

A ligação simples utiliza conectividade entre pares próximos e pode representar estruturas alongadas que não são bem resumidas por um único centroide.

A ligação completa controla separações máximas e tende a privilegiar outra forma de compacidade.

Métodos baseados em densidade definem grupos por regiões concentradas e conectadas.

Não existe, portanto, uma única geometria de grupo compartilhada por todos os métodos.

16.9 Ausência de classes naturais automáticas

A Análise de Agrupamentos é uma técnica não supervisionada: os rótulos dos grupos não são observados previamente.

Esse fato impõe uma diferença importante em relação à Análise Discriminante. Uma partição encontrada nos dados não demonstra automaticamente a existência de populações distintas que tenham gerado as observações.

No caso das K -médias, a solução é aquela que minimiza

$$J_K.$$

No método de Ward, a hierarquia é definida pelo aumento da dispersão intragrupos.

Nas ligações simples, completa e média, a hierarquia decorre das respectivas definições de proximidade entre conjuntos.

Em uma mistura probabilística, os grupos são componentes de um modelo especificado.

Cada conclusão deve ser interpretada relativamente à estrutura que produziu a solução.

Grupos encontrados e grupos substantivos

Uma solução de agrupamento estabelece uma organização dos objetos segundo uma representação e um critério definidos. A correspondência entre essa organização matemática e categorias substantivas do problema exige informação externa aos critérios de agrupamento.

Esse limite distingue a capacidade de encontrar uma estrutura matemática da interpretação substantiva dessa estrutura.

16.10 Relações com outras técnicas multivariadas

A Análise de Agrupamentos reutiliza objetos já presentes nos capítulos anteriores, mas atribui a eles uma nova função.

A Tabela 16.9 compara essas relações.

Tabela 16.9: Relações entre a Análise de Agrupamentos e outras técnicas multivariadas.

Técnica	Objeto relacionado	Função na técnica
ACP	matriz de dados e geometria das observações	construir uma representação de menor dimensão
Análise Fatorial	variáveis observadas e estrutura de covariâncias	modelar dependências por fatores latentes contínuos
Agrupamentos	matriz de dados ou dissimilaridades	construir grupos
MDS	matriz de dissimilaridades	reconstruir uma configuração geométrica
MANOVA	dispersão intragrupos e entre grupos	testar hipóteses sobre diferenças entre grupos conhecidos
Análise Discriminante	médias, dispersões e distâncias entre grupos	construir direções de separação e regras de classificação

16.10.1 Agrupamentos e ACP

A ACP pode produzir novas coordenadas para as observações. Quando são mantidas todas as componentes correspondentes a uma transformação ortogonal da representação utilizada como entrada, as distâncias euclidianas são preservadas por Proposição 4.10.

Quando apenas $k < p$ componentes são mantidas, as observações são projetadas sobre o subespaço principal definido em Definição 14.1, como representado em Figura 14.3. Nesse caso, as distâncias passam a ser calculadas na configuração projetada e podem diferir das distâncias anteriores à redução.

A interpretação também depende da representação utilizada pela ACP. Se a análise foi realizada sobre variáveis padronizadas, a preservação pela transformação ortogonal refere-se à geometria do espaço padronizado, e não à geometria das variáveis em suas escalas originais.

Assim, utilizar ACP antes de um agrupamento modifica o problema sempre que ocorre redução efetiva de dimensão ou mudança prévia da representação dos dados.

16.10.2 Agrupamentos e MDS

Agrupamentos e Escalonamento Multidimensional podem partir da mesma matriz

$$\Delta.$$

A diferença está no objeto procurado.

Na Análise de Agrupamentos, Δ é utilizada para construir partições ou hierarquias.

No MDS, ela será utilizada para obter coordenadas

$$\mathbf{y}_1, \dots, \mathbf{y}_n$$

cujas distâncias representem as dissimilaridades originais.

Essa relação prepara diretamente o próximo capítulo.

16.10.3 Agrupamentos e Análise Discriminante

Na Análise de Agrupamentos, os grupos fazem parte da solução.

Na Análise Discriminante, os grupos serão observados previamente e serão utilizados para construir funções de separação ou regras de classificação.

Na Análise de Agrupamentos, os grupos fazem parte da solução. Na Análise Discriminante, eles pertencem à informação disponível antes da construção da regra. A primeira técnica procura uma organização dos objetos; a segunda utiliza grupos conhecidos para estudar separação e classificar novas observações.

16.10.4 Agrupamentos e MANOVA

A conexão com MANOVA aparece na decomposição

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

já estabelecida em Proposição 8.11.

Nas K -médias, a partição é desconhecida e procura-se reduzir

$$\text{tr}(\mathbf{T}_{\text{intra}}).$$

Na MANOVA, os grupos serão dados pelo delineamento e as matrizes de dispersão serão utilizadas para formular um problema inferencial sobre diferenças entre vetores de médias.

O mesmo objeto matricial assume funções distintas. Nas K -médias, a dispersão intragrupos define um critério de otimização para construir a partição. Na MANOVA, as matrizes de dispersão participam de um problema inferencial para grupos conhecidos. Na Análise Discriminante, elas serão utilizadas para construir direções de separação entre grupos também conhecidos.

Essa comparação reforça uma característica recorrente do Módulo 3: a operação matemática não determina, sozinha, a técnica. O significado estatístico depende do problema ao qual o objeto é aplicado.

16.11 Síntese

A Análise de Agrupamentos procura organizar objetos sem utilizar classes previamente conhecidas. Sua formulação começa pela representação das observações e pela definição da proximidade que será utilizada.

Quando os objetos são representados pelas linhas de

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

distâncias podem ser construídas diretamente no espaço das variáveis. Quando apenas relações entre objetos estão disponíveis, a análise pode partir de uma matriz de dissimilaridades

$$\Delta.$$

Uma partição rígida em K grupos é representada por

$$\mathcal{P} = \{C_1, \dots, C_K\}.$$

No critério das K -médias,

$$J_K(\mathcal{P}) = \sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \mathbf{c}_k\|^2 = \text{tr}(\mathbf{T}_{\text{intra}}).$$

O centroide aparece porque a média de um conjunto é o ponto que minimiza a soma das distâncias euclidianas quadráticas às observações. Para centroides fixados, cada objeto é atribuído a um centroide mais próximo, produzindo regiões de Voronoi.

A decomposição

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

mostra que, para K fixado, minimizar a dispersão intragrupos equivale a maximizar a parcela entre grupos segundo o traço.

Nos métodos hierárquicos, o resultado principal deixa de ser uma única partição e passa a ser uma sequência aninhada de partições. Ligações simples, completas e médias utilizam diferentes definições de proximidade entre conjuntos.

O método de Ward reutiliza a dispersão quadrática e mede o incremento

$$\Delta_{\text{Ward}}(A, B) = \frac{n_A n_B}{n_A + n_B} \|\mathbf{c}_A - \mathbf{c}_B\|^2$$

produzido pela fusão de dois grupos.

A hierarquia pode ser representada por um dendrograma e induz uma estrutura ultramétrica por meio das alturas das fusões.

Outras formulações modificam o significado de grupo. Em modelos de mistura, grupos são componentes de uma distribuição probabilística e o pertencimento é representado por uma variável categórica latente. Em formulações baseadas em densidade, grupos podem ser associados a regiões conectadas de elevada concentração.

A solução depende da representação dos objetos, das variáveis, da escala, da proximidade e do critério de agrupamento. Por isso, uma partição ou hierarquia deve ser interpretada relativamente ao problema matemático que a produziu.

O próximo capítulo mantém a matriz de dissimilaridades como objeto de entrada, mas altera o objetivo da análise. O Escalonamento Multidimensional utilizará as proximidades entre objetos para reconstruir uma configuração geométrica cujas distâncias representem a estrutura contida em Δ .

17 Formulação do Escalonamento Multidimensional

O Escalonamento Multidimensional, ou MDS, procura representar relações de dissimilaridade entre objetos por meio de uma configuração geométrica. O objeto de entrada pode ser a mesma matriz de dissimilaridades utilizada na Análise de Agrupamentos, mas o objetivo da técnica é diferente. Em Agrupamentos, as proximidades são utilizadas para construir partições ou hierarquias. No MDS, elas são utilizadas para construir coordenadas cujas distâncias representem a estrutura observada.

A formulação clássica parte de uma propriedade geométrica desenvolvida no Módulo 1: distâncias euclidianas podem ser relacionadas a produtos internos. A matriz de Gram definida em Definição 3.18 organiza esses produtos internos, enquanto a decomposição espectral fornece as coordenadas de uma configuração correspondente. O MDS clássico combina esses resultados para resolver o problema inverso: recuperar uma representação geométrica quando as coordenadas dos objetos não são conhecidas (Gower, 1966; Torgerson, 1952).

Os elementos principais da formulação são apresentados na Tabela 17.1.

Tabela 17.1: Elementos da formulação do Escalonamento Multidimensional.

Elemento	Objeto matemático	Papel no MDS
Informação de entrada	$\Delta = (\delta_{ij})$	registra as dissimilaridades entre os objetos
Configuração	$\mathbf{X}_{\text{MDS},k} \in \mathbb{R}^{n \times k}$	fornece coordenadas aos objetos
Distâncias configuracionais	d_{ij}	medem a separação entre os pontos reconstruídos
Produtos internos	$\mathbf{G}$	descrevem a geometria da configuração centralizada
Solução clássica	decomposição espectral de $\mathbf{G}$	produz as coordenadas principais

17.1 O problema de reconstrução geométrica

Considere n objetos para os quais estão disponíveis dissimilaridades

$$\delta_{ij}, \quad i, j = 1, \dots, n.$$

A noção de dissimilaridade foi introduzida em Definição 16.1. Neste capítulo, consideraremos inicialmente uma matriz simétrica

$$\Delta = (\delta_{ij}) \in \mathbb{R}^{n \times n},$$

com

$$\delta_{ij} \geq 0,$$

$$\delta_{ii} = 0$$

e

$$\delta_{ij} = \delta_{ji}.$$

A desigualdade triangular não será assumida nesta etapa. Ela se torna relevante quando se deseja interpretar Δ como uma matriz de distâncias métricas.

O objetivo é encontrar pontos

$$\mathbf{x}_1^{(\text{MDS})}, \dots, \mathbf{x}_n^{(\text{MDS})} \in \mathbb{R}^k$$

e reuni-los nas linhas da configuração

$$\mathbf{X}_{\text{MDS},k} = \begin{pmatrix} \mathbf{x}_1^{(\text{MDS})\top} \\ \vdots \\ \mathbf{x}_n^{(\text{MDS})\top} \end{pmatrix} \in \mathbb{R}^{n \times k}. \quad (17.1)$$

A distância euclidiana entre dois pontos da configuração é

$$d_{ij}(\mathbf{X}_{\text{MDS},k}) = \|\mathbf{x}_i^{(\text{MDS})} - \mathbf{x}_j^{(\text{MDS})}\|, \quad (17.2)$$

utilizando a distância já definida em Definição 1.13.

Uma reprodução exata ocorre quando

$$d_{ij}(\mathbf{X}_{\text{MDS},k}) = \delta_{ij}$$

para todos os pares.

Em muitos problemas, essa igualdade não pode ser obtida na dimensão escolhida. A representação passa então a ser aproximada, e o significado dessa aproximação dependerá da formulação adotada.

A distinção entre entrada e saída é sintetizada na Tabela 17.2.

Tabela 17.2: Quantidades de entrada e de saída no Escalonamento Multidimensional.

Quantidade	Natureza	Interpretação
δ_{ij}	observada ou fornecida	dissimilaridade entre os objetos i e j
$\mathbf{x}_i^{(\text{MDS})}$	construída pela técnica	coordenadas do objeto i
d_{ij}	derivada da configuração	distância entre os pontos reconstruídos

O problema do MDS é relacional. Não é necessário conhecer originalmente as variáveis que deram origem às diferenças entre os objetos. Uma matriz de dissimilaridades pode ser calculada a partir de uma matriz de dados, obtida por comparações entre objetos ou fornecida diretamente pelo problema analisado.

Essa característica distingue o MDS da ACP. A ACP parte de coordenadas das observações e constrói uma nova representação. O MDS pode partir somente das relações entre pares e reconstruir coordenadas a partir delas.

17.2 Configuração e indeterminações geométricas

Uma matriz de distâncias não determina a posição absoluta de uma configuração no espaço. Algumas transformações modificam as coordenadas sem modificar as distâncias entre os pontos.

17.2.1 Translação

Considere uma configuração

$$\mathbf{X}_{\text{MDS},k}$$

e um vetor

$$\mathbf{a} \in \mathbb{R}^k.$$

A translação comum de todos os pontos produz

$$\mathbf{x}_i^* = \mathbf{x}_i^{(\text{MDS})} + \mathbf{a}.$$

As diferenças permanecem inalteradas:

$$\mathbf{x}_i^* - \mathbf{x}_j^* = \mathbf{x}_i^{(\text{MDS})} - \mathbf{x}_j^{(\text{MDS})}.$$

Consequentemente,

$$\|\mathbf{x}_i^* - \mathbf{x}_j^*\| = \|\mathbf{x}_i^{(\text{MDS})} - \mathbf{x}_j^{(\text{MDS})}\|.$$

Essa propriedade é um caso da preservação das distâncias por centralização e translação estabelecida em Proposição [4.15](#).

17.2.2 Transformações ortogonais

Considere agora

$$\mathbf{O} \in \mathbb{R}^{k \times k}$$

ortogonal e a configuração transformada

$$\mathbf{X}_{\text{MDS},k}^* = \mathbf{X}_{\text{MDS},k} \mathbf{O}.$$

A diferença entre duas linhas transformadas é

$$\left(\mathbf{x}_i^{(\text{MDS})} - \mathbf{x}_j^{(\text{MDS})} \right)^\top \mathbf{O}.$$

Como transformações ortogonais preservam normas e distâncias por Proposição 4.10,

$$d_{ij}(\mathbf{X}_{\text{MDS},k}^*) = d_{ij}(\mathbf{X}_{\text{MDS},k}). \quad (17.3)$$

rotações e reflexões modificam a orientação da configuração sem modificar sua estrutura de distâncias.

A Figura 17.1 mostra uma configuração e duas representações obtidas por transformações que preservam todas as distâncias entre os objetos.




Figura 17.1: Configurações relacionadas por translação e transformação ortogonal preservam as mesmas distâncias entre os objetos.

A localização e a orientação dos eixos não são determinadas pelas distâncias. O objeto interpretado no MDS é a configuração relativa dos pontos.

No MDS clássico, uma mudança global de escala não constitui a mesma indeterminação. Se

$$\mathbf{X}_{\text{MDS},k}^* = c\mathbf{X}_{\text{MDS},k},$$

então

$$d_{ij}^* = |c|d_{ij}.$$

Quando os valores de Δ possuem escala fixada, essa transformação modifica o problema. A questão da escala assume outra forma em formulações não métricas, nas quais a informação principal pode estar na ordenação das dissimilaridades.

17.2.3 Centralização da configuração

Como a translação não altera as distâncias, pode-se escolher uma origem conveniente sem perda da informação relacional.

No Módulo 2, a matriz de centralização foi utilizada para escrever

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}$$

em Equação 8.59, com

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

No MDS, a mesma matriz será utilizada para fixar o centroide da configuração na origem.

Definição 17.1 (Configuração centralizada no MDS). Uma configuração

$$\mathbf{X}_{\text{MDS},k} \in \mathbb{R}^{n \times k}$$

é **centralizada** quando

$$\mathbf{1}_n^\top \mathbf{X}_{\text{MDS},k} = \mathbf{0}^\top. \quad (17.4)$$

Se uma configuração não satisfaz essa condição, sua versão centralizada é

$$\mathbf{X}_{\text{MDS},k,c} = \mathbf{H}_n \mathbf{X}_{\text{MDS},k}.$$

Pela propriedade de Proposição 4.15, a centralização não modifica as distâncias entre suas linhas.

A condição em Equação 17.4 não cria uma nova geometria. Ela escolhe, entre todas as translações equivalentes, aquela cujo centroide coincide com a origem.

17.3 Da distância ao produto interno

A solução clássica do MDS utiliza a relação entre distâncias euclidianas e produtos internos já preparada no Módulo 1.

Considere uma configuração centralizada

$$\mathbf{X}_{\text{MDS}} \in \mathbb{R}^{n \times r},$$

e sua matriz de Gram

$$\mathbf{G} = \mathbf{X}_{\text{MDS}} \mathbf{X}_{\text{MDS}}^\top, \quad (17.5)$$

conforme Definição 3.18.

O elemento

$$g_{ij} = \mathbf{x}_i^{(\text{MDS})\top} \mathbf{x}_j^{(\text{MDS})}$$

é o produto interno entre os pontos i e j .

A distância quadrática entre esses pontos satisfaz

$$\begin{aligned} d_{ij}^2 &= \|\mathbf{x}_i^{(\text{MDS})} - \mathbf{x}_j^{(\text{MDS})}\|^2 \\ &= \mathbf{x}_i^{(\text{MDS})\top} \mathbf{x}_i^{(\text{MDS})} + \mathbf{x}_j^{(\text{MDS})\top} \mathbf{x}_j^{(\text{MDS})} - 2\mathbf{x}_i^{(\text{MDS})\top} \mathbf{x}_j^{(\text{MDS})} \\ &= g_{ii} + g_{jj} - 2g_{ij}. \end{aligned} \quad (17.6)$$

A matriz de Gram determina, portanto, todas as distâncias euclidianas da configuração.

O MDS clássico resolve o problema inverso: recebe as distâncias e procura recuperar os produtos internos.

17.3.1 Matriz das distâncias quadráticas

Defina

$$\Delta^{(2)} = (\delta_{ij}^2). \quad (17.7)$$

Considere ainda o vetor formado pela diagonal da matriz de Gram,

$$\mathbf{g} = \begin{pmatrix} g_{11} \\ \vdots \\ g_{nn} \end{pmatrix}.$$

A identidade em Equação 17.6 pode ser escrita matricialmente como

$$\Delta^{(2)} = \mathbf{g}\mathbf{1}_n^\top + \mathbf{1}_n\mathbf{g}^\top - 2\mathbf{G}. \quad (17.8)$$

Essa expressão contém os produtos internos desconhecidos e termos associados às normas individuais dos pontos. A centralização permite eliminar esses termos.

Como

$$\mathbf{H}_n \mathbf{1}_n = \mathbf{0},$$

tem-se

$$\mathbf{H}_n \mathbf{g} \mathbf{1}_n^\top \mathbf{H}_n = \mathbf{0}$$

e

$$\mathbf{H}_n \mathbf{1}_n \mathbf{g}^\top \mathbf{H}_n = \mathbf{0}.$$

Além disso, como a configuração é centralizada,

$$\mathbf{1}_n^\top \mathbf{X}_{\text{MDS}} = \mathbf{0}^\top,$$

e, portanto,

$$\mathbf{G}\mathbf{1}_n = \mathbf{X}_{\text{MDS}} \mathbf{X}_{\text{MDS}}^\top \mathbf{1}_n = \mathbf{0}.$$

Da mesma forma,

$$\mathbf{1}_n^\top \mathbf{G} = \mathbf{0}^\top.$$

Consequentemente,

$$\mathbf{H}_n \mathbf{G} \mathbf{H}_n = \mathbf{G}. \quad (17.9)$$

Multiplicando Equação 17.8 à esquerda e à direita por $\mathbf{H}_n$,

$$\begin{aligned} \mathbf{H}_n \Delta^{(2)} \mathbf{H}_n &= \mathbf{H}_n \mathbf{g} \mathbf{1}_n^\top \mathbf{H}_n + \mathbf{H}_n \mathbf{1}_n \mathbf{g}^\top \mathbf{H}_n - 2\mathbf{H}_n \mathbf{G} \mathbf{H}_n \\ &= -2\mathbf{G}. \end{aligned}$$

Logo,

$$\mathbf{G} = -\frac{1}{2} \mathbf{H}_n \Delta^{(2)} \mathbf{H}_n. \quad (17.10)$$

Proposição 17.1 (Reconstrução da matriz de Gram por dupla centralização). *Considere uma configuração euclidiana centralizada e seja*

$$\Delta^{(2)} = (d_{ij}^2)$$

sua matriz de distâncias quadráticas. Então sua matriz de Gram é

$$\mathbf{G} = -\frac{1}{2} \mathbf{H}_n \Delta^{(2)} \mathbf{H}_n.$$

A operação em Equação 17.10 é denominada **dupla centralização**. Ela converte a informação expressa em distâncias quadráticas em uma matriz de produtos internos.

Esse resultado completa a relação que havia sido antecipada no Módulo 1. A matriz de Gram já possuía as propriedades estabelecidas em Proposição 3.9; no MDS, ela passa a ser reconstruída diretamente das dissimilaridades.

Quando Δ contém distâncias euclidianas exatas, a matriz obtida em Equação 17.10 coincide com a matriz de Gram de uma configuração centralizada.

Para uma matriz de dissimilaridades geral, define-se

$$\mathbf{G}_\Delta = -\frac{1}{2} \mathbf{H}_n \Delta^{(2)} \mathbf{H}_n. \quad (17.11)$$

A estrutura espectral de $\mathbf{G}_\Delta$ determinará se as dissimilaridades admitem uma representação euclidiana exata e, quando isso ocorre, fornecerá diretamente as coordenadas da configuração. Esse será o ponto de partida da formulação do MDS clássico.

17.4 Formulação do MDS clássico

A dupla centralização transforma a matriz de dissimilaridades em um objeto ao qual se aplicam diretamente os resultados espectrais do Módulo 1. A matriz

$$\mathbf{G}_\Delta = -\frac{1}{2}\mathbf{H}_n\Delta^{(2)}\mathbf{H}_n$$

é simétrica. Quando as dissimilaridades correspondem a distâncias euclidianas, ela é também semidefinida positiva e pode ser interpretada como a matriz de Gram de uma configuração centralizada.

O MDS clássico utiliza essa matriz para recuperar as coordenadas dos objetos (Gower, 1966; Torgerson, 1952).

17.4.1 Solução espectral

Pelo Teorema Espectral estabelecido em Teorema 5.4, a matriz simétrica $\mathbf{G}_\Delta$ admite uma decomposição

$$\mathbf{G}_\Delta = \mathbf{Q}\mathbf{D}_G\mathbf{Q}^\top, \quad (17.12)$$

em que

$$\mathbf{Q}^\top\mathbf{Q} = \mathbf{I}_n$$

e

$$\mathbf{D}_G = \text{diag}(\lambda_1, \dots, \lambda_n),$$

com os autovalores ordenados de modo que

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n.$$

Considere inicialmente o caso em que

$$\mathbf{G}_\Delta \succeq \mathbf{0}.$$

Se existem r autovalores estritamente positivos,

$$\lambda_1 \geq \dots \geq \lambda_r > 0$$

e

$$\lambda_{r+1} = \dots = \lambda_n = 0,$$

defina

$$\mathbf{Q}_+ = (\mathbf{q}_1 \quad \dots \quad \mathbf{q}_r)$$

e

$$\mathbf{D}_+ = \text{diag}(\lambda_1, \dots, \lambda_r).$$

Uma configuração é então dada por

$$\mathbf{X}_{\text{MDS}} = \mathbf{Q}_+ \mathbf{D}_+^{1/2}. \quad (17.13)$$

De fato,

$$\begin{aligned} \mathbf{X}_{\text{MDS}} \mathbf{X}_{\text{MDS}}^\top &= \mathbf{Q}_+ \mathbf{D}_+^{1/2} \mathbf{D}_+^{1/2} \mathbf{Q}_+^\top \\ &= \mathbf{Q}_+ \mathbf{D}_+ \mathbf{Q}_+^\top \\ &= \mathbf{G}_\Delta. \end{aligned} \quad (17.14)$$

Assim, a construção espectral fornece uma matriz de coordenadas cuja matriz de Gram coincide com aquela reconstruída das distâncias.

Definição 17.2 (Coordenadas principais). As colunas de

$$\mathbf{X}_{\text{MDS}} = \mathbf{Q}_+ \mathbf{D}_+^{1/2}$$

são denominadas **coordenadas principais** da configuração clássica.

A coordenada associada ao autovalor $\lambda_j > 0$ é

$$\sqrt{\lambda_j} \mathbf{q}_j.$$

Como

$$\mathbf{G}_\Delta \mathbf{1}_n = \mathbf{0},$$

o vetor $\mathbf{1}_n$ pertence ao espaço nulo de $\mathbf{G}_\Delta$. Os autovetores associados aos autovalores positivos são ortogonais a esse espaço e, portanto,

$$\mathbf{1}_n^\top \mathbf{Q}_+ = \mathbf{0}^\top.$$

Consequentemente,

$$\mathbf{1}_n^\top \mathbf{X}_{\text{MDS}} = \mathbf{0}^\top.$$

A solução espectral já produz, portanto, uma configuração centralizada.

A posição de cada objeto na dimensão j é determinada pelo elemento correspondente de

$$\sqrt{\lambda_j} \mathbf{q}_j.$$

O autovalor controla a magnitude global das coordenadas ao longo daquele eixo, pois

$$\left\| \sqrt{\lambda_j} \mathbf{q}_j \right\|^2 = \lambda_j. \quad (17.15)$$

Nesse contexto, λ_j quantifica a contribuição quadrática daquele eixo para a geometria centralizada da configuração. Essa interpretação não exige atribuir aos autovalores o significado de variâncias de variáveis aleatórias.

17.4.2 Reprodução euclidiana exata

A construção anterior conduz à condição que determina quando uma matriz de dissimilaridades pode ser representada exatamente por distâncias euclidianas.

Teorema 17.1 (Condição para representação euclidiana). *Considere uma matriz simétrica de dissimilaridades*

$$\Delta = (\delta_{ij}),$$

com

$$\delta_{ij} \geq 0$$

e

$$\delta_{ii} = 0.$$

Defina

$$\mathbf{G}_\Delta = -\frac{1}{2}\mathbf{H}_n\Delta^{(2)}\mathbf{H}_n.$$

Existe uma configuração de pontos em um espaço euclidiano cujas distâncias reproduzem exatamente Δ se, e somente se,

$$\mathbf{G}_\Delta \succeq \mathbf{0}.$$

Nesse caso, uma configuração centralizada é dada por Equação [17.13](#).

Comprovação. Suponha inicialmente que Δ seja produzida por uma configuração euclidiana centralizada

$$\mathbf{X}_{\text{MDS}}.$$

Pela proposição de dupla centralização em Proposição [17.1](#),

$$\mathbf{G}_\Delta = \mathbf{X}_{\text{MDS}}\mathbf{X}_{\text{MDS}}^\top.$$

Pelas propriedades das matrizes de Gram estabelecidas em Proposição [3.9](#),

$$\mathbf{G}_\Delta \succeq \mathbf{0}.$$

Isso estabelece a necessidade.

Considere agora

$$\mathbf{G}_\Delta \succeq \mathbf{0}.$$

Pela decomposição espectral, pode-se construir

$$\mathbf{X}_{\text{MDS}} = \mathbf{Q}_+ \mathbf{D}_+^{1/2},$$

de modo que

$$\mathbf{G}_\Delta = \mathbf{X}_{\text{MDS}} \mathbf{X}_{\text{MDS}}^\top.$$

Denote por

$$\mathbf{g}_\Delta = \text{diag}(\mathbf{G}_\Delta)$$

o vetor formado pelos elementos diagonais de $\mathbf{G}_\Delta$. Como $\Delta^{(2)}$ é simétrica e possui diagonal nula, a dupla centralização admite a relação inversa

$$\Delta^{(2)} = \mathbf{g}_\Delta \mathbf{1}_n^\top + \mathbf{1}_n \mathbf{g}_\Delta^\top - 2\mathbf{G}_\Delta. \quad (17.16)$$

Por outro lado, as distâncias quadráticas da configuração construída a partir de $\mathbf{G}_\Delta$ satisfazem

$$d_{ij}^2 = g_{ii} + g_{jj} - 2g_{ij}.$$

Portanto,

$$d_{ij}^2 = \delta_{ij}^2.$$

Como ambas as quantidades são não negativas,

$$d_{ij} = \delta_{ij}.$$

Logo, a configuração construída reproduz exatamente as dissimilaridades. $\square$

A simetria de Δ é insuficiente para garantir uma representação euclidiana. A compatibilidade com essa geometria é determinada pela semidefinição positiva da matriz de Gram reconstruída.

A Tabela 17.3 resume a interpretação espectral.

Tabela 17.3: Interpretação dos autovalores da matriz de Gram reconstruída.

Estrutura de $\mathbf{G}_\Delta$	Consequência para a representação
todos os autovalores são não negativos	existe representação euclidiana exata

Estrutura de $\mathbf{G}_\Delta$	Consequência para a representação
$\mathbf{G}_\Delta \succeq \mathbf{0}$ possui r autovalores positivos	a dimensão mínima de uma representação euclidiana exata é r
existem autovalores nulos	as direções correspondentes não acrescentam dimensão
existe pelo menos um autovalor negativo	não existe representação euclidiana exata das dissimilaridades na formulação clássica

17.4.3 Dimensão da configuração

Quando

$$\mathbf{G}_\Delta \succeq \mathbf{0},$$

a dimensão mínima de uma representação euclidiana exata é

$$r = \text{rank}(\mathbf{G}_\Delta). \quad (17.17)$$

Para justificar esse resultado, observe que qualquer configuração

$$\mathbf{X}_{\text{MDS}} \in \mathbb{R}^{n \times k}$$

satisfaz

$$\text{rank}(\mathbf{X}_{\text{MDS}} \mathbf{X}_{\text{MDS}}^\top) = \text{rank}(\mathbf{X}_{\text{MDS}}) \leq k.$$

Se

$$\mathbf{G}_\Delta = \mathbf{X}_{\text{MDS}} \mathbf{X}_{\text{MDS}}^\top,$$

qualquer representação exata deve, portanto, ter

$$k \geq \text{rank}(\mathbf{G}_\Delta).$$

Por outro lado, Equação 17.13 constrói uma representação exatamente em

$$r = \text{rank}(\mathbf{G}_\Delta)$$

dimensões.

Como a configuração está centralizada,

$$\mathbf{G}_{\Delta} \mathbf{1}_n = \mathbf{0},$$

e, portanto,

$$\text{rank}(\mathbf{G}_{\Delta}) \leq n - 1.$$

Assim, qualquer conjunto de n objetos cujas dissimilaridades sejam euclidianas admite uma representação exata em no máximo $n - 1$ dimensões.

A Figura 17.2 ilustra a reconstrução de uma configuração bidimensional a partir apenas das distâncias entre os objetos.




Figura 17.2: Reconstrução espectral de uma configuração a partir das distâncias. A orientação pode mudar, mas as distâncias entre os objetos são preservadas.

A configuração reconstruída pode aparecer rotacionada ou refletida em relação à original. Essa diferença não representa erro de reconstrução, pois as transformações ortogonais preservam as distâncias conforme Equação 17.3.

17.4.4 Representação em dimensão reduzida

Uma matriz de distâncias pode admitir representação euclidiana exata em dimensão

$$r,$$

mas o objetivo da análise pode ser construir uma representação com

$$k < r$$

dimensões.

Considere

$$\mathbf{G}_\Delta \succeq \mathbf{0}$$

com decomposição

$$\mathbf{G}_\Delta = \sum_{j=1}^r \lambda_j \mathbf{q}_j \mathbf{q}_j^\top,$$

em que

$$\lambda_1 \geq \dots \geq \lambda_r > 0.$$

A aproximação baseada nas primeiras k dimensões é

$$\mathbf{G}_k = \sum_{j=1}^k \lambda_j \mathbf{q}_j \mathbf{q}_j^\top = \mathbf{Q}_k \mathbf{D}_k \mathbf{Q}_k^\top, \quad (17.18)$$

com

$$\mathbf{Q}_k = (\mathbf{q}_1 \quad \dots \quad \mathbf{q}_k)$$

e

$$\mathbf{D}_k = \text{diag}(\lambda_1, \dots, \lambda_k).$$

A configuração correspondente é

$$\mathbf{X}_{\text{MDS},k} = \mathbf{Q}_k \mathbf{D}_k^{1/2}. \quad (17.19)$$

Como $\mathbf{G}_\Delta$ é semidefinida positiva, seus valores singulares coincidem com seus autovalores positivos. O resultado de Eckart–Young–Mirsky estabelecido em Teorema 6.2 implica que $\mathbf{G}_k$ é uma melhor aproximação de posto no máximo k de $\mathbf{G}_\Delta$, tanto na norma espectral quanto na norma de Frobenius.

Em particular,

$$\|\mathbf{G}_\Delta - \mathbf{G}_k\|_F^2 = \sum_{j=k+1}^r \lambda_j^2 \quad (17.20)$$

e

$$\|\mathbf{G}_\Delta - \mathbf{G}_k\|_2 = \lambda_{k+1}, \quad (17.21)$$

quando

$$k < r.$$

O resultado tem um significado específico no MDS clássico: a redução dimensional aproxima a **matriz de produtos internos reconstruída**.

As distâncias na configuração reduzida são

$$d_{ij}^{(k)} = \|\mathbf{x}_{i,k}^{(\text{MDS})} - \mathbf{x}_{j,k}^{(\text{MDS})}\|.$$

Em geral,

$$d_{ij}^{(k)} \neq \delta_{ij}$$

quando

$$k < r.$$

A aproximação espectral ótima da matriz de Gram não deve ser confundida com a minimização direta de qualquer função de discrepância definida sobre as distâncias originais. O critério otimizado em Equação 17.18 é matricial; outras formulações de MDS podem adotar funções objetivo diretamente baseadas nas distâncias. Essa distinção separa o MDS clássico espectral das formulações métricas baseadas em *stress*. :contentReferenceoaicite:1

A soma dos autovalores positivos é

$$\text{tr}(\mathbf{G}_\Delta) = \sum_{j=1}^r \lambda_j = \|\mathbf{X}_{\text{MDS}}\|_F^2. \quad (17.22)$$

Para uma configuração centralizada,

$$\text{tr}(\mathbf{G}_\Delta) = \sum_{i=1}^n \|\mathbf{x}_i^{(\text{MDS})}\|^2.$$

A razão

$$\frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^r \lambda_j} \quad (17.23)$$

pode, no caso euclidiano, descrever a parcela da soma quadrática da configuração centralizada representada pelas primeiras k coordenadas principais.

Essa quantidade é uma medida da representação espectral da geometria. Sua interpretação não deve ser automaticamente transferida para a noção de variância explicada da ACP, porque o objeto inicial do MDS é uma matriz de dissimilaridades.

17.4.5 Euclideanidade e autovalores negativos

A condição de Teorema 17.1 separa dois problemas que podem produzir perda de fidelidade na representação.

No primeiro,

$$\mathbf{G}_\Delta \succeq \mathbf{0},$$

mas sua dimensão exata é maior que a dimensão escolhida para a representação. A perda decorre da **redução de dimensão**.

No segundo, $\mathbf{G}_\Delta$ possui pelo menos um autovalor negativo. Nesse caso, as dissimilaridades já não admitem uma representação euclidiana exata antes de qualquer redução dimensional.

Considere

$$\lambda_1 \geq \dots \geq \lambda_r > 0$$

e autovalores negativos

$$\lambda_{s+1}, \dots, \lambda_n < 0.$$

A presença desses valores impede escrever

$$\mathbf{G}_\Delta = \mathbf{X}\mathbf{X}^\top$$

para uma matriz real de coordenadas euclidianas, porque qualquer matriz da forma

$$\mathbf{X}\mathbf{X}^\top$$

é semidefinida positiva por Proposição 3.9.

Os autovalores negativos não representam dimensões euclidianas adicionais. Eles registram incompatibilidade entre a estrutura de dissimilaridades e a representação euclidiana procurada pelo MDS clássico.

A Tabela 17.4 distingue as duas situações.

Tabela 17.4: Diferença entre redução dimensional e não euclideanidade das dissimilaridades.

Situação	Estrutura espectral	Origem da discrepância
representação euclidiana exata	$\mathbf{G}_\Delta \succeq \mathbf{0}$ e todas as dimensões positivas são mantidas	não há discrepância
redução dimensional	$\mathbf{G}_\Delta \succeq \mathbf{0}$, mas apenas $k < r$ dimensões são mantidas	truncamento da configuração euclidiana
dissimilaridades não euclidianas	$\mathbf{G}_\Delta$ possui autovalores negativos	incompatibilidade anterior à redução dimensional

Uma forma de construir uma configuração euclidiana aproximada é utilizar somente a parte positiva da decomposição espectral,

$$\mathbf{G}_+ = \sum_{\lambda_j > 0} \lambda_j \mathbf{q}_j \mathbf{q}_j^\top. \quad (17.24)$$

As coordenadas correspondentes são

$$\mathbf{X}_+ = \mathbf{Q}_+ \mathbf{D}_+^{1/2}.$$

Entretanto,

$$\mathbf{G}_+ \neq \mathbf{G}_\Delta$$

quando existem autovalores negativos. Consequentemente, as distâncias produzidas por $\mathbf{X}_+$ não reproduzem exatamente as dissimilaridades originais.

Descartar os autovalores negativos não transforma a matriz original em uma representação exata; produz outra geometria euclidiana aproximada.

Considere, por exemplo,

$$\Delta = \begin{pmatrix} 0 & 1 & 1 \\ 1 & 0 & 3 \\ 1 & 3 & 0 \end{pmatrix}.$$

A desigualdade triangular é violada, pois

$$3 > 1 + 1.$$

A dupla centralização fornece uma matriz de Gram com autovalores

$$4, 5, \quad 0, \quad -\frac{5}{6}.$$

O autovalor negativo confirma, pela condição de Teorema 17.1, que não existe uma configuração euclidiana cujas distâncias sejam exatamente

$$1, \quad 1, \quad 3$$

para os três pares.

A interpretação dos autovalores deve, portanto, considerar o sinal antes da escolha da dimensão. Autovalores positivos fornecem as direções disponíveis para uma representação euclidiana; autovalores nulos não acrescentam dimensão; autovalores negativos indicam que a matriz de dissimilaridades não pertence exatamente à classe de matrizes de distâncias euclidianas considerada pelo MDS clássico.

Procedimentos destinados a modificar dissimilaridades não euclidianas podem ser utilizados em aplicações específicas. Essas correções alteram a matriz de entrada e pertencem à etapa metodológica da análise. Neste capítulo, o ponto necessário é reconhecer a não euclideanidade e distingui-la da simples redução da dimensão.

O MDS clássico pode, assim, ser entendido como uma transformação espectral da matriz de dissimilaridades em coordenadas geométricas. A próxima conexão mostra que, quando essas

dissimilaridades são as próprias distâncias euclidianas entre observações de uma matriz de dados, a construção coincide com uma representação já encontrada por outro caminho na Análise de Componentes Principais.

17.5 MDS clássico e Análise de Componentes Principais

O MDS clássico e a ACP podem produzir representações espectrais muito próximas, mas partem de objetos diferentes. A ACP utiliza uma matriz de dados, de covariâncias ou de correlações. O MDS clássico utiliza uma matriz de distâncias ou dissimilaridades. A relação entre as duas técnicas aparece quando as distâncias fornecidas ao MDS são calculadas a partir das próprias observações em uma geometria euclidiana. :contentReferenceoaicite:0

Considere uma matriz de dados centralizada

$$\mathbf{X}_c \in \mathbb{R}^{n \times p},$$

com decomposição em valores singulares

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top, \quad (17.25)$$

em que

$$r = \text{rank}(\mathbf{X}_c).$$

Essa é a estrutura de SVD já utilizada na formulação da ACP. A relação entre a SVD e os espectros das matrizes de Gram foi estabelecida em Proposição 6.1.

Considere agora a matriz de distâncias euclidianas entre as linhas de $\mathbf{X}_c$. Como a matriz já está centralizada,

$$\mathbf{H}_n \mathbf{X}_c = \mathbf{X}_c.$$

A dupla centralização dessas distâncias recupera a matriz de Gram das observações:

$$\mathbf{G}_\Delta = \mathbf{X}_c \mathbf{X}_c^\top. \quad (17.26)$$

Substituindo Equação 17.25,

$$\begin{aligned} \mathbf{G}_\Delta &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \\ &= \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top. \end{aligned} \quad (17.27)$$

Assim, os autovalores positivos de $\mathbf{G}_\Delta$ são

$$d_1^2, \dots, d_r^2,$$

e os autovetores correspondentes são as colunas de

$$\mathbf{U}_r.$$

Pela formulação do MDS clássico,

$$\mathbf{X}_{\text{MDS}} = \mathbf{U}_r \mathbf{D}_r. \quad (17.28)$$

Os escores das componentes principais foram definidos em Definição 14.2. Considerando as r direções associadas aos valores singulares positivos, sua matriz é

$$\mathbf{T}_r = \mathbf{X}_c \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r. \quad (17.29)$$

Logo,

$$\mathbf{X}_{\text{MDS}} = \mathbf{T}_r, \quad (17.30)$$

até as indeterminações de sinal e, quando existem valores singulares repetidos, até transformações ortogonais nos subespaços correspondentes.

Proposição 17.2 (Relação entre MDS clássico e escores da ACP). *Quando a matriz de entrada do MDS clássico contém as distâncias euclidianas entre as linhas de uma matriz de dados centralizada, as coordenadas principais do MDS coincidem, até transformações ortogonais admissíveis, com os escores da ACP obtidos pela SVD dessa mesma matriz.*

A equivalência decorre do fato de que as duas técnicas chegam ao mesmo produto

$$\mathbf{X}_c \mathbf{X}_c^\top$$

por caminhos diferentes.

Na ACP, as coordenadas são construídas diretamente a partir da matriz de dados.

No MDS clássico, o mesmo produto é reconstruído a partir das distâncias pela dupla centralização.

A relação é resumida na Tabela 17.5.

Tabela 17.5: Relação entre a Análise de Componentes Principais e o MDS clássico.

Aspecto	ACP	MDS clássico
entrada	matriz de dados, covariâncias ou correlações	matriz de distâncias ou dissimilaridades
objeto espectral	covariância, correlação ou produtos cruzados	matriz de Gram reconstruída
informação priorizada	variabilidade das coordenadas	geometria entre os objetos
solução	componentes e escores	coordenadas principais
coincidência	quando a mesma geometria euclidiana das observações é utilizada	quando as distâncias derivam dessa mesma representação

A equivalência exige que as duas técnicas utilizem a mesma geometria de entrada. Se a ACP for realizada sobre variáveis padronizadas, as distâncias correspondentes devem ser calculadas entre as observações também padronizadas para que a relação anterior permaneça válida.

Se a ACP utiliza a matriz original centralizada e o MDS utiliza outra medida de dissimilaridade, os problemas deixam de ser equivalentes.

A diferença de interpretação também permanece. Na ACP, os eixos estão associados a combinações lineares das variáveis originais. No MDS, as coordenadas são construídas para representar relações entre objetos e não precisam corresponder a combinações diretamente interpretáveis das variáveis que eventualmente originaram as dissimilaridades.

O MDS clássico baseado em dupla centralização também é denominado **análise de coordenadas principais** em diversos contextos (Gower, 1966).

17.6 Formulações baseadas diretamente no ajuste das distâncias

O MDS clássico resolve o problema por reconstrução da matriz de Gram. Outras formulações definem a solução diretamente pela discrepância entre as distâncias produzidas por uma configuração e determinadas proximidades-alvo.

Considere novamente uma configuração

$$\mathbf{X}_{\text{MDS},k}$$

e suas distâncias

$$d_{ij} = d_{ij}(\mathbf{X}_{\text{MDS},k}).$$

Para formular o ajuste, é útil distinguir três quantidades.

Definição 17.3 (Dissimilaridade, disparidade e distância). No MDS baseado em ajuste de distâncias:

- δ_{ij} é a **dissimilaridade de entrada** entre os objetos i e j ;
- $\hat{\delta}_{ij}$ é a **disparidade**, isto é, o valor-alvo obtido a partir da dissimilaridade segundo a transformação admitida pela formulação;
- d_{ij} é a **distância configuracional** produzida pelas coordenadas estimadas.

A distinção é importante porque, em geral,

$$\delta_{ij}, \quad \hat{\delta}_{ij} \quad \text{e} \quad d_{ij}$$

não representam o mesmo objeto.

As disparidades podem ser escritas de modo geral como

$$\hat{\delta}_{ij} = f(\delta_{ij}), \quad (17.31)$$

em que as restrições impostas a f definem a informação das dissimilaridades que será preservada.

17.6.1 MDS métrico

No MDS métrico, as magnitudes das dissimilaridades possuem significado quantitativo para o ajuste. A transformação utilizada para obter as disparidades é especificada ou restringida de modo a preservar essa informação métrica.

Uma formulação geral considera pesos

$$w_{ij} \geq 0$$

e procura uma configuração que reduza

$$\sigma(\mathbf{X}_{\text{MDS},k}) = \sum_{i < j} w_{ij} [d_{ij} - \hat{\delta}_{ij}]^2. \quad (17.32)$$

A função em Equação 17.32 mede a discrepância quadrática entre as distâncias da configuração e as disparidades que constituem o alvo do ajuste.

Quando

$$w_{ij} = 1$$

para todos os pares, cada relação entre objetos recebe o mesmo peso.

Pesos diferentes permitem representar formulações em que determinadas proximidades contribuam de forma diferente para o critério. O desenvolvimento da escolha desses pesos pertence à etapa metodológica.

A formulação métrica baseada em *stress* e o MDS clássico não devem ser identificados como o mesmo problema de otimização.

No MDS clássico, a solução espectral aproxima ou reconstrói a matriz de Gram.

No ajuste métrico por Equação 17.32, o critério é definido diretamente sobre diferenças entre distâncias e disparidades.

As duas formulações podem produzir representações relacionadas, mas seus objetivos matemáticos não são idênticos.

17.6.2 MDS não métrico

No MDS não métrico, a informação principal está na **ordenação** das dissimilaridades, e não necessariamente em suas diferenças numéricas (Kruskal, 1964).

Se

$$\delta_{ij} < \delta_{rs},$$

a representação procura manter a ordenação correspondente por meio de disparidades que satisfaçam

$$\hat{\delta}_{ij} \leq \hat{\delta}_{rs}. \quad (17.33)$$

Em seguida, procura-se uma configuração cujas distâncias sejam próximas dessas disparidades.

Assim, a transformação

$$f$$

em Equação 17.31 é restringida a ser monótona não decrescente.

A monotonicidade permite modificar as diferenças numéricas entre as dissimilaridades sem inverter sua ordem.

Por exemplo, considere

$$\delta_{12} = 1, \quad \delta_{13} = 2, \quad \delta_{14} = 10.$$

Uma formulação métrica trata a diferença entre 2 e 10 como informação quantitativa relevante.

Uma formulação não métrica preserva prioritariamente a relação

$$\delta_{12} < \delta_{13} < \delta_{14},$$

permitindo que as disparidades ajustadas assumam espaçamentos diferentes, desde que essa ordenação seja respeitada.

A Tabela 17.6 compara as duas formulações.

Tabela 17.6: Diferença entre formulações métricas e não métricas do MDS.

Aspecto	MDS métrico	MDS não métrico
informação principal	magnitude das dissimilaridades	ordenação das dissimilaridades
transformação f	especificada ou metricamente restringida	monótona não decrescente
alvo do ajuste	reproduzir relações quantitativas	reproduzir relações ordinais
configuração	distâncias próximas das disparidades	distâncias próximas de disparidades monotônicas
indeterminação de escala	depende da parametrização adotada	pode ocorrer quando apenas a ordem é relevante

O MDS não métrico não elimina a geometria euclidiana da configuração. Os pontos continuam sendo representados em

$$\mathbb{R}^k$$

e suas relações continuam sendo medidas por distâncias configuracionais. O que muda é a quantidade de informação exigida da matriz de dissimilaridades.

17.6.3 Função de *stress*

Para pesos $w_{ij} \geq 0$ e uma configuração não degenerada tal que

$$\sum_{i < j} w_{ij} d_{ij}^2 > 0,$$

uma forma normalizada de representar a discrepância entre distâncias e disparidades é (Kruskal, 1964)

$$\text{Stress} = \sqrt{\frac{\sum_{i < j} w_{ij} (d_{ij} - \hat{\delta}_{ij})^2}{\sum_{i < j} w_{ij} d_{ij}^2}}. \quad (17.34)$$

Na expressão, a diferença

$$d_{ij} - \hat{\delta}_{ij}$$

mede a discrepância de cada par, w_{ij} determina sua contribuição para o critério e o denominador normaliza a discrepância pela escala global das distâncias configuracionais.

Valores menores de *stress* indicam maior proximidade, segundo esse critério, entre as distâncias da configuração e as disparidades.

O valor de *stress* não possui interpretação independente da formulação utilizada. Diferentes definições, normalizações, transformações das dissimilaridades e conjuntos de pesos podem produzir valores que não são diretamente comparáveis.

Por isso, o papel da função neste capítulo é estabelecer a diferença entre uma representação espectral baseada na matriz de Gram e uma representação obtida pela minimização direta de discrepâncias entre proximidades.

Os critérios práticos utilizados para avaliar a magnitude do *stress*, escolher a dimensão ou comparar soluções pertencem à etapa aplicada da análise.

17.6.4 Representação métrica e ordinal

A diferença entre as duas formulações pode ser visualizada por meio da relação entre dissimilaridades e distâncias configuracionais.

Na representação métrica, espera-se que diferenças quantitativas entre as dissimilaridades sejam refletidas pelas distâncias.

Na representação não métrica, a condição principal é a preservação da ordem.

A Figura 17.3 apresenta essas duas situações de forma esquemática.




Figura 17.3: Relações entre dissimilaridades e distâncias em representações métrica e não métrica.

No painel métrico, a linha de referência representa igualdade entre dissimilaridades e distâncias. Os pontos permanecem próximos dessa relação quantitativa.

No painel não métrico, o traçado crescente representa a preservação da ordenação. A forma da relação pode ser não linear sem que a ordem dos pares seja invertida.

Essa representação é uma forma simplificada do tipo de relação visualizada em diagramas de Shepard. O diagnóstico detalhado desses diagramas será tratado posteriormente.

17.6.5 Indeterminações nas formulações baseadas em *stress*

As indeterminações por translação, rotação e reflexão permanecem nas formulações baseadas em *stress* sempre que o critério depende apenas das distâncias configuracionais.

Se

$$\mathbf{X}_{\text{MDS},k}^* = \mathbf{1}_n \mathbf{a}^\top + \mathbf{X}_{\text{MDS},k} \mathbf{O},$$

com

$$\mathbf{O}^\top \mathbf{O} = \mathbf{I}_k,$$

então as distâncias entre os pontos permanecem inalteradas.

Consequentemente, o valor de Equação 17.34 também permanece inalterado.

A escala exige tratamento separado.

No MDS métrico, quando as disparidades possuem escala quantitativa fixada, multiplicar todas as coordenadas por uma constante altera as distâncias e, em geral, altera o ajuste.

No MDS não métrico, a escala pode não ser identificada quando a transformação monotônica e a normalização do critério permitem compensar uma mudança global das distâncias.

A identificação da configuração deve, portanto, ser interpretada em relação à formulação específica.

17.7 Dependência da representação

O MDS representa a geometria definida pela matriz de entrada. A configuração não deve ser interpretada independentemente das dissimilaridades que lhe deram origem.

A Tabela 17.7 organiza os principais elementos dos quais a solução depende.

Tabela 17.7: Elementos que definem a representação produzida pelo MDS.

Elemento	Efeito sobre o problema
definição de δ_{ij}	determina quais objetos são considerados próximos
transformação das dissimilaridades	determina a informação quantitativa ou ordinal preservada
dimensão k	limita a complexidade geométrica da configuração

Elemento	Efeito sobre o problema
pesos w_{ij}	modificam a contribuição relativa dos pares
critério de ajuste	define o significado de melhor representação
restrições geométricas	determinam a classe de configurações admissíveis

A dimensão da representação é parte da formulação quando

$$k < r.$$

No MDS clássico, essa escolha determina o posto da aproximação da matriz de Gram.

Nas formulações por *stress*, ela determina o espaço no qual as coordenadas serão procuradas.

Os procedimentos utilizados para escolher operacionalmente essa dimensão serão tratados posteriormente.

17.8 Ausência de um modelo probabilístico universal

A formulação básica do MDS não exige que

$$\Delta$$

seja uma estatística proveniente de uma amostra aleatória multivariada.

As dissimilaridades podem resultar de diferentes processos, incluindo medidas físicas, distâncias calculadas a partir de variáveis, comparações entre objetos ou avaliações de semelhança.

Consequentemente, não existe uma distribuição amostral única associada às coordenadas do MDS.

Quando as dissimilaridades são estimadas ou observadas com erro, resultados inferenciais dependem do modelo probabilístico adotado para seu mecanismo de geração. A formulação básica do capítulo permanece, portanto, geométrica e descritiva. :contentReferenceoacite:1

Essa característica diferencia o MDS de técnicas como a Análise Fatorial de máxima verossimilhança ou a MANOVA, nas quais um modelo probabilístico específico participa diretamente da formulação inferencial.

O próximo passo é relacionar essa estrutura ao capítulo anterior e ao seguinte. Agrupamentos e MDS podem receber a mesma matriz de dissimilaridades, mas constroem objetos distintos. A

Análise de Correspondência também produzirá coordenadas, porém a geometria será determinada por perfis e pela distância qui-quadrado, e não por uma matriz geral de dissimilaridades euclidianas.

17.9 Relações com outras técnicas multivariadas

O Escalonamento Multidimensional compartilha objetos matemáticos com outras técnicas do Módulo 3, mas atribui a eles funções diferentes. A distinção entre as técnicas depende do problema resolvido e do significado da representação obtida.

A Tabela 17.8 sintetiza as relações mais próximas.

Tabela 17.8: Relações entre o MDS e outras técnicas multivariadas.

Técnica	Objeto de entrada relacionado	Estrutura construída
ACP	matriz de dados, covariâncias ou correlações	componentes e escores que representam variabilidade
Agrupamentos	matriz de dados ou dissimilaridades	partições ou hierarquias
MDS	matriz de dissimilaridades	configuração geométrica de objetos
Análise de Correspondência	tabela de contingência	configuração geométrica de perfis segundo a métrica qui-quadrado

17.9.1 MDS e Análise de Agrupamentos

O capítulo anterior mostrou que uma matriz

$$\Delta = (\delta_{ij})$$

pode ser utilizada para construir grupos. No MDS, a mesma matriz pode ser utilizada para construir coordenadas.

A diferença está no objeto procurado.

Na Análise de Agrupamentos, uma solução pode assumir a forma de uma partição

$$\mathcal{P} = \{C_1, \dots, C_K\}$$

ou de uma hierarquia de partições.

No MDS, procura-se uma configuração

$$\mathbf{X}_{\text{MDS},k} \in \mathbb{R}^{n \times k}$$

cujas distâncias representem as relações registradas em Δ .

Os dois resultados também não devem ser confundidos na interpretação. Objetos próximos em uma configuração de MDS apresentam pequena distância segundo a geometria representada, mas essa proximidade não estabelece automaticamente a existência de um grupo. A definição de grupo depende de um critério adicional, como os desenvolvidos no capítulo de Análise de Agrupamentos.

De forma correspondente, uma partição obtida por agrupamento não fornece necessariamente uma representação geométrica de todas as relações entre os objetos. Ela resume as proximidades segundo o critério utilizado para formar os grupos.

17.9.2 MDS e ACP

A relação matemática entre MDS clássico e ACP foi estabelecida em Proposição 17.2. Quando as dissimilaridades são as distâncias euclidianas entre as observações de uma mesma matriz de dados centralizada, a dupla centralização recupera

$$\mathbf{G}_{\Delta} = \mathbf{X}_c \mathbf{X}_c^{\top},$$

e as coordenadas principais do MDS coincidem, até as indeterminações ortogonais admissíveis, com os escores obtidos pela SVD da matriz de dados.

Essa equivalência não elimina a diferença entre as técnicas. A ACP começa com coordenadas das observações e estuda a variabilidade dessas coordenadas. O MDS pode começar apenas com relações entre objetos e procura uma configuração que represente essas relações.

Quando as dissimilaridades do MDS não são as distâncias euclidianas associadas à mesma representação utilizada na ACP, a equivalência deixa de existir.

17.9.3 MDS e Análise de Correspondência

A Análise de Correspondência também produzirá coordenadas para representar objetos em poucas dimensões. A origem da geometria, entretanto, será diferente.

No MDS, a geometria é determinada pela matriz de dissimilaridades fornecida à técnica.

Na Análise de Correspondência, a geometria será construída a partir dos perfis de uma tabela de contingência e de uma distância ponderada pelas massas das categorias. A representação estará associada ao afastamento em relação à independência entre linhas e colunas.

As duas técnicas compartilham o uso de decomposições matriciais para construir representações de baixa dimensão, mas não representam o mesmo tipo de informação.

17.10 Limites da interpretação geométrica

Uma configuração de MDS transforma relações entre objetos em posições geométricas. Sua interpretação deve permanecer condicionada à definição das dissimilaridades e ao critério utilizado para produzir a representação.

17.10.1 Proximidade depende da dissimilaridade

Se dois objetos aparecem próximos na configuração, essa proximidade significa que sua relação é pequena segundo a dissimilaridade utilizada na análise.

Alterar

$$\delta_{ij}$$

por meio de outra definição de proximidade pode modificar a configuração mesmo quando os objetos analisados permanecem os mesmos.

Assim como na Análise de Agrupamentos, a geometria não é uma propriedade absoluta dos objetos. Ela depende da representação escolhida para compará-los.

17.10.2 Os eixos não possuem interpretação substantiva automática

No MDS, rotações e reflexões preservam as distâncias. Consequentemente, a orientação absoluta dos eixos não é identificada pela matriz de dissimilaridades.

Conforme Equação 17.3, multiplicar a configuração à direita por uma matriz ortogonal preserva todas as distâncias. A orientação dos eixos pode, portanto, ser modificada sem alterar a geometria relacional representada.

Por isso, o significado principal da configuração está nas posições relativas, distâncias, direções de contraste entre conjuntos de pontos e estruturas geométricas estáveis sob transformações ortogonais. A interpretação direta de uma coordenada isolada requer informação adicional sobre os objetos ou sobre variáveis externas.

Essa característica distingue o MDS da ACP. Na ACP, os eixos são combinações lineares explicitamente relacionadas às variáveis originais por seus coeficientes e correlações. No MDS construído apenas a partir de uma matriz de dissimilaridades, essa relação com variáveis originais pode não estar disponível.

17.10.3 Representação em baixa dimensão é uma aproximação

Quando

$$k < \text{rank}(\mathbf{G}_\Delta),$$

uma representação em k dimensões não preserva integralmente a geometria euclidiana reconstruída.

No MDS clássico, a representação em dimensão reduzida substitui $\mathbf{G}_\Delta$ pela aproximação de posto reduzido $\mathbf{G}_k$ definida em Equação 17.18.

Nas formulações baseadas em *stress*, a perda é avaliada pela discrepância entre distâncias configuracionais e disparidades.

Uma representação bidimensional deve, portanto, ser interpretada como uma projeção ou aproximação da estrutura considerada. A facilidade de visualizar duas dimensões não constitui evidência de que a estrutura original seja intrinsecamente bidimensional.

17.10.4 Redução dimensional e não euclideanidade são problemas distintos

A presença de autovalores negativos em

$$\mathbf{G}_\Delta$$

não deve ser interpretada como simples consequência da escolha de poucas dimensões.

Quando

$$\mathbf{G}_\Delta \succeq \mathbf{0}$$

e apenas algumas coordenadas principais são mantidas, existe uma geometria euclidiana exata em dimensão maior e a representação reduzida aproxima essa geometria.

Quando existem autovalores negativos, as dissimilaridades originais não admitem representação euclidiana exata na formulação clássica, independentemente da dimensão escolhida.

Essa distinção deve preceder qualquer interpretação da qualidade de uma configuração reduzida.

17.10.5 Estrutura geométrica não implica estrutura de grupos

Regiões visualmente próximas ou separadas em uma configuração podem auxiliar a descrição das relações entre objetos, mas não constituem, isoladamente, evidência de classes ou populações distintas.

O MDS procura representar proximidades. A identificação de grupos exige uma definição adicional de agrupamento ou informação substantiva externa à configuração.

Da mesma forma, posições extremas na representação indicam relações geométricas específicas segundo a matriz de entrada, mas não devem ser automaticamente interpretadas como observações atípicas em um modelo probabilístico.

17.11 Síntese

O Escalonamento Multidimensional parte de relações entre objetos e procura representá-las por meio de coordenadas em um espaço de menor dimensão.

A entrada básica é uma matriz de dissimilaridades

$$\Delta = (\delta_{ij}),$$

enquanto a saída é uma configuração

$$\mathbf{X}_{\text{MDS},k} \in \mathbb{R}^{n \times k}.$$

No MDS clássico, o problema é convertido de distâncias para produtos internos. Para uma configuração centralizada, sua matriz de Gram é

$$\mathbf{G} = \mathbf{X}_{\text{MDS}} \mathbf{X}_{\text{MDS}}^{\top},$$

e as distâncias satisfazem

$$d_{ij}^2 = g_{ii} + g_{jj} - 2g_{ij}.$$

A operação inversa é obtida pela dupla centralização:

$$\mathbf{G}_{\Delta} = -\frac{1}{2} \mathbf{H}_n \Delta^{(2)} \mathbf{H}_n.$$

Essa expressão constitui a ligação entre a matriz de dissimilaridades e a geometria euclidiana da configuração.

Quando

$$\mathbf{G}_{\Delta} \succeq \mathbf{0},$$

as dissimilaridades admitem representação euclidiana exata. Se

$$\mathbf{G}_{\Delta} = \mathbf{Q}_+ \mathbf{D}_+ \mathbf{Q}_+^{\top},$$

as coordenadas principais são

$$\mathbf{X}_{\text{MDS}} = \mathbf{Q}_+ \mathbf{D}_+^{1/2}.$$

A dimensão mínima de uma representação exata é

$$\text{rank}(\mathbf{G}_{\Delta}).$$

Quando uma representação com

$$k < \text{rank}(\mathbf{G}_{\Delta})$$

dimensões é utilizada, o MDS clássico aproxima a matriz de Gram pela retenção das principais componentes espectrais:

$$\mathbf{G}_k = \mathbf{Q}_k \mathbf{D}_k \mathbf{Q}_k^\top.$$

O resultado de Eckart–Young–Mirsky permite interpretar essa construção como aproximação de posto reduzido da matriz de Gram. Esse critério não deve ser confundido com a minimização direta de discrepâncias nas distâncias.

Autovalores negativos de

$$\mathbf{G}_\Delta$$

indicam outra situação: as dissimilaridades não possuem representação euclidiana exata na formulação clássica. A não euclideanidade é uma propriedade da matriz de entrada e deve ser distinguida da perda produzida pela redução dimensional.

Quando as distâncias do MDS clássico são calculadas entre as linhas de uma matriz de dados centralizada, a dupla centralização recupera

$$\mathbf{X}_c \mathbf{X}_c^\top,$$

e as coordenadas principais coincidem, até transformações ortogonais admissíveis, com os escores da ACP na mesma representação.

As formulações baseadas diretamente no ajuste das distâncias distinguem dissimilaridades,

$$\delta_{ij},$$

disparidades,

$$\hat{\delta}_{ij},$$

e distâncias configuracionais,

$$d_{ij}.$$

No MDS métrico, a magnitude das dissimilaridades participa do ajuste. No MDS não métrico, a informação principal está em sua ordenação e as disparidades são restringidas por uma transformação monotônica.

Uma medida de *stress* compara distâncias e disparidades segundo uma função de discrepância. Seu significado depende da normalização, dos pesos e da transformação admitida para as proximidades.

A configuração resultante permanece indeterminada quanto à translação, rotação e reflexão quando o critério depende somente das distâncias. Por isso, sua interpretação se concentra na geometria relativa dos objetos e não na orientação absoluta dos eixos.

O capítulo seguinte mantém a construção de representações geométricas de baixa dimensão, mas modifica o objeto de entrada e a métrica. Na Análise de Correspondência, uma tabela de contingência será transformada em perfis e desvios em relação à independência. A distância qui-quadrado e a SVD fornecerão a estrutura geométrica utilizada para representar simultaneamente linhas e colunas.

18 Formulação da Análise de Correspondência

A Análise de Correspondência representa geometricamente a associação entre as categorias de duas variáveis qualitativas a partir de uma tabela de contingência. O ponto de partida não é uma matriz de covariâncias nem uma matriz geral de dissimilaridades, mas a distribuição conjunta das frequências observadas entre categorias de linhas e colunas.

A técnica compara os perfis observados com a estrutura esperada sob independência. Essa comparação define uma geometria ponderada pelas frequências marginais das categorias. A matriz resultante é então decomposta por SVD, utilizando diretamente os resultados desenvolvidos no Módulo 1. O objetivo deste capítulo é formular essa construção e mostrar como os desvios da independência produzem distâncias, inércia e coordenadas para linhas e colunas (Greenacre, 2017).

Os elementos da formulação são organizados na Tabela 18.1.

Tabela 18.1: Elementos da formulação da Análise de Correspondência.

Elemento	Objeto	Papel na análise
dados observados	tabela de contingência $\mathbf{N}$	registra as frequências conjuntas
distribuição observada	matriz $\mathbf{P}$	expressa frequências relativas
pesos marginais	massas $\mathbf{r}$ e $\mathbf{c}$	determinam a importância relativa das categorias
representação interna	perfis de linhas e de colunas	descreve distribuições condicionais
referência	independência	fornece a estrutura sem associação
geometria	distância qui-quadrado	compara perfis com ponderação pelas massas
estrutura matricial	desvios padronizados $\mathbf{Q}_{CA}$	reúne os desvios da independência
solução	SVD de $\mathbf{Q}_{CA}$	produz inércias e coordenadas

18.1 O problema de associação em uma tabela de contingência

Considere duas variáveis qualitativas, uma com I categorias e outra com J categorias. As frequências observadas são organizadas na tabela

$$\mathbf{N} = (n_{ij}) \in \mathbb{R}^{I \times J},$$

em que

$$n_{ij} \geq 0$$

representa a frequência conjunta da categoria i da variável das linhas com a categoria j da variável das colunas.

O total observado é

$$n = \sum_{i=1}^I \sum_{j=1}^J n_{ij}. \quad (18.1)$$

A Análise de Correspondência trabalha com a matriz de frequências relativas

$$\mathbf{P} = \frac{1}{n} \mathbf{N} = (p_{ij}) \in \mathbb{R}^{I \times J}. \quad (18.2)$$

Assim,

$$p_{ij} = \frac{n_{ij}}{n}$$

e

$$\sum_{i=1}^I \sum_{j=1}^J p_{ij} = 1.$$

A matriz $\mathbf{P}$ descreve a distribuição conjunta observada. A análise procura determinar como essa distribuição se afasta da estrutura correspondente à independência e representar esse afastamento em poucas dimensões.

A tabela possui duas leituras complementares. Comparando as linhas, investigam-se diferenças entre as distribuições das categorias das colunas condicionadas a cada linha. Comparando as colunas, investigam-se diferenças entre as distribuições das categorias das linhas condicionadas a cada coluna.

18.2 Frequências marginais, massas e perfis

Defina

$$\mathbf{r} = \mathbf{P}\mathbf{1}_J = \begin{pmatrix} r_1 \\ \vdots \\ r_I \end{pmatrix} \quad (18.3)$$

e

$$\mathbf{c} = \mathbf{P}^\top \mathbf{1}_I = \begin{pmatrix} c_1 \\ \vdots \\ c_J \end{pmatrix}. \quad (18.4)$$

Cada elemento satisfaz

$$r_i = \sum_{j=1}^J p_{ij}$$

e

$$c_j = \sum_{i=1}^I p_{ij}.$$

Como $\mathbf{P}$ possui soma total igual a 1,

$$\mathbf{1}_I^\top \mathbf{r} = 1$$

e

$$\mathbf{1}_J^\top \mathbf{c} = 1.$$

Definição 18.1 (Massas de linhas e colunas). As **massas das linhas** são as frequências relativas marginais

$$r_i, \quad i = 1, \dots, I,$$

e as **massas das colunas** são

$$c_j, \quad j = 1, \dots, J.$$

As matrizes diagonais associadas são

$$\mathbf{D}_r = \text{diag}(r_1, \dots, r_I)$$

e

$$\mathbf{D}_c = \text{diag}(c_1, \dots, c_J).$$

Na formulação básica, considera-se

$$r_i > 0 \quad \text{e} \quad c_j > 0$$

para todas as categorias ativas. Essa condição garante que os perfis estejam definidos e que as matrizes inversas utilizadas na ponderação existam.

18.2.1 Perfis de linhas e colunas

A Análise de Correspondência compara distribuições condicionais, denominadas perfis.

Definição 18.2 (Perfis de linhas e de colunas). O **perfil da linha** i é

$$\mathbf{p}_{i\cdot} = \begin{pmatrix} \frac{p_{i1}}{r_i} \\ \vdots \\ \frac{p_{iJ}}{r_i} \end{pmatrix} \in \mathbb{R}^J. \quad (18.5)$$

O **perfil da coluna** j é

$$\mathbf{p}_{\cdot j} = \begin{pmatrix} \frac{p_{1j}}{c_j} \\ \vdots \\ \frac{p_{Ij}}{c_j} \end{pmatrix} \in \mathbb{R}^I. \quad (18.6)$$

Cada perfil possui soma unitária:

$$\mathbf{1}_J^\top \mathbf{p}_{i\cdot} = 1$$

e

$$\mathbf{1}_I^\top \mathbf{p}_{\cdot|j} = 1.$$

Os perfis de linhas podem ser reunidos na matriz

$$\mathbf{P}^{(r)} = \mathbf{D}_r^{-1} \mathbf{P} \in \mathbb{R}^{I \times J}, \quad (18.7)$$

enquanto os perfis de colunas são organizados em

$$\mathbf{P}^{(c)} = \mathbf{D}_c^{-1} \mathbf{P}^\top \in \mathbb{R}^{J \times I}. \quad (18.8)$$

O perfil médio das linhas, ponderado pelas massas r_i , é

$$\sum_{i=1}^I r_i \mathbf{p}_{i\cdot} = \mathbf{c}, \quad (18.9)$$

e, de forma dual,

$$\sum_{j=1}^J c_j \mathbf{p}_{\cdot|j} = \mathbf{r}. \quad (18.10)$$

Assim, $\mathbf{c}$ é o centro ponderado da nuvem dos perfis de linhas e $\mathbf{r}$ é o centro ponderado da nuvem dos perfis de colunas.

18.2.2 Independência como referência

Sob independência,

$$p_{ij} = r_i c_j, \quad (18.11)$$

ou, em forma matricial,

$$\mathbf{P} = \mathbf{r} \mathbf{c}^\top. \quad (18.12)$$

Nesse caso,

$$\frac{p_{ij}}{r_i} = c_j,$$

de modo que todos os perfis de linhas coincidem com $\mathbf{c}$. Analogamente, todos os perfis de colunas coincidem com $\mathbf{r}$.

A independência corresponde, portanto, ao colapso de cada nuvem de perfis em seu respectivo centro.

Quando

$$\mathbf{P} \neq \mathbf{r}\mathbf{c}^\top,$$

as diferenças

$$p_{ij} - r_i c_j$$

representam os desvios observados em relação à independência.

18.3 Geometria dos perfis

A Análise de Correspondência compara os perfis utilizando uma geometria ponderada pelas massas marginais.

No Módulo 1, o produto interno induzido e sua norma foram definidos em Definição 3.16 e Definição 3.17. Para os perfis de linhas, a matriz que define essa geometria é

$$\mathbf{D}_c^{-1}.$$

Definição 18.3 (Distância qui-quadrado entre perfis). A distância qui-quadrado entre as linhas i e i' é

$$d_{\chi^2}^2(i, i') = (\mathbf{p}_{i|\cdot} - \mathbf{p}_{i'|\cdot})^\top \mathbf{D}_c^{-1} (\mathbf{p}_{i|\cdot} - \mathbf{p}_{i'|\cdot}). \quad (18.13)$$

Equivalentemente,

$$d_{\chi^2}^2(i, i') = \sum_{j=1}^J \frac{1}{c_j} \left(\frac{p_{ij}}{r_i} - \frac{p_{i'j}}{r_{i'}} \right)^2.$$

Para duas colunas j e j' ,

$$d_{\chi^2}^2(j, j') = (\mathbf{p}_{\cdot|j} - \mathbf{p}_{\cdot|j'})^\top \mathbf{D}_r^{-1} (\mathbf{p}_{\cdot|j} - \mathbf{p}_{\cdot|j'}). \quad (18.14)$$

A distância de uma linha ao centro da nuvem é

$$d_{\chi^2}^2(i, \mathbf{c}) = \left(\mathbf{p}_{i\cdot} - \mathbf{c} \right)^\top \mathbf{D}_c^{-1} \left(\mathbf{p}_{i\cdot} - \mathbf{c} \right), \quad (18.15)$$

ou

$$d_{\chi^2}^2(i, \mathbf{c}) = \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i^2 c_j}. \quad (18.16)$$

18.4 Inércia e afastamento da independência

Definição 18.4 (Inércia total). A **inércia total** da tabela é

$$\mathcal{J} = \sum_{i=1}^I r_i d_{\chi^2}^2(i, \mathbf{c}). \quad (18.17)$$

Equivalentemente,

$$\mathcal{J} = \sum_{j=1}^J c_j d_{\chi^2}^2(j, \mathbf{r}). \quad (18.18)$$

Substituindo Equação 18.16,

$$\mathcal{J} = \sum_{i=1}^I \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i c_j}. \quad (18.19)$$

Sob massas positivas,

$$\mathcal{J} = 0$$

se, e somente se,

$$\mathbf{P} = \mathbf{r}\mathbf{c}^\top.$$

18.5 Matriz de desvios padronizados

Definição 18.5 (Matriz de desvios padronizados). A matriz de desvios padronizados da Análise de Correspondência é

$$\mathbf{Q}_{\text{CA}} = \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r}\mathbf{c}^\top) \mathbf{D}_c^{-1/2}. \quad (18.20)$$

Seu elemento (i, j) é

$$q_{ij} = \frac{p_{ij} - r_i c_j}{\sqrt{r_i c_j}}. \quad (18.21)$$

A matriz $\mathbf{Q}_{\text{CA}}$ representa, em coordenadas ponderadas, os desvios da distribuição observada em relação à independência.

Além disso,

$$\mathbf{Q}_{\text{CA}} \mathbf{D}_c^{1/2} \mathbf{1}_J = \mathbf{0} \quad (18.22)$$

e

$$\mathbf{Q}_{\text{CA}}^\top \mathbf{D}_r^{1/2} \mathbf{1}_I = \mathbf{0}. \quad (18.23)$$

Consequentemente,

$$\text{rank}(\mathbf{Q}_{\text{CA}}) \leq \min(I - 1, J - 1). \quad (18.24)$$

18.5.1 Inércia como norma matricial

Pela norma de Frobenius definida em Definição 6.7,

$$\|\mathbf{Q}_{\text{CA}}\|_F^2 = \sum_{i=1}^I \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i c_j}.$$

Logo,

$$\mathcal{J} = \|\mathbf{Q}_{\text{CA}}\|_F^2. \quad (18.25)$$

Proposição 18.1 (Formas equivalentes da inércia). *A inércia total pode ser expressa pela dispersão ponderada dos perfis de linhas,*

$$\mathcal{J} = \sum_{i=1}^I r_i d_{\chi^2}^2(i, \mathbf{c}),$$

pela dispersão ponderada dos perfis de colunas,

$$\mathcal{J} = \sum_{j=1}^J c_j d_{\chi^2}^2(j, \mathbf{r}),$$

ou pela norma de Frobenius,

$$\mathcal{J} = \|\mathbf{Q}_{CA}\|_F^2.$$

18.6 Relação com a estatística qui-quadrado

A estatística de Pearson é

$$\chi^2 = \sum_{i=1}^I \sum_{j=1}^J \frac{(n_{ij} - nr_i c_j)^2}{nr_i c_j}. \quad (18.26)$$

Como

$$n_{ij} = np_{ij},$$

segue que

$$\chi^2 = n \sum_{i=1}^I \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i c_j}.$$

Portanto,

$$\chi^2 = n\mathcal{J}. \quad (18.27)$$

Neste ponto, a relação é uma identidade algébrica entre a estatística calculada da tabela e a inércia utilizada na representação geométrica. Sua interpretação inferencial exige um modelo amostral.

18.7 Formulação pela decomposição em valores singulares

A matriz

$$\mathbf{Q}_{CA} \in \mathbb{R}^{I \times J}$$

é, em geral, retangular. Sua decomposição utiliza diretamente a SVD já desenvolvida no Módulo 1.

Se

$$K = \text{rank}(\mathbf{Q}_{CA}),$$

a SVD compacta de Definição 6.4 fornece

$$\mathbf{Q}_{CA} = \mathbf{U} \mathbf{D} \mathbf{V}^\top, \quad (18.28)$$

com

$$\mathbf{U}^\top \mathbf{U} = \mathbf{I}_K, \quad \mathbf{V}^\top \mathbf{V} = \mathbf{I}_K,$$

e

$$\mathbf{D} = \text{diag}(d_1, \dots, d_K),$$

em que

$$d_1 \geq \dots \geq d_K > 0.$$

18.7.1 Inércias principais

Definição 18.6 (Inércia principal). A inércia principal da dimensão ℓ é

$$\lambda_\ell = d_\ell^2, \quad \ell = 1, \dots, K. \quad (18.29)$$

Como

$$\mathcal{J} = \|\mathbf{Q}_{\text{CA}}\|_F^2,$$

segue que

$$\mathcal{J} = \sum_{\ell=1}^K \lambda_\ell. \quad (18.30)$$

Consequentemente,

$$\chi^2 = n \sum_{\ell=1}^K \lambda_\ell. \quad (18.31)$$

A proporção da inércia associada à dimensão ℓ é

$$\frac{\lambda_\ell}{\sum_{h=1}^K \lambda_h}. \quad (18.32)$$

Para as primeiras k dimensões,

$$\frac{\sum_{\ell=1}^k \lambda_\ell}{\sum_{\ell=1}^K \lambda_\ell} \quad (18.33)$$

é a proporção acumulada da inércia representada.

18.7.2 Representação em dimensão reduzida

Para

$$k < K,$$

a SVD truncada fornece

$$\mathbf{Q}_{\text{CA},k} = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top. \quad (18.34)$$

Pelo Teorema de Eckart–Young–Mirsky em Teorema 6.2,

$$\mathbf{Q}_{\text{CA},k}$$

é uma melhor aproximação de posto no máximo k de $\mathbf{Q}_{\text{CA}}$ em norma de Frobenius.

O erro é

$$\|\mathbf{Q}_{\text{CA}} - \mathbf{Q}_{\text{CA},k}\|_F^2 = \sum_{\ell=k+1}^K \lambda_\ell. \quad (18.35)$$

A inércia representada é

$$\mathcal{J}_k = \sum_{\ell=1}^k \lambda_\ell. \quad (18.36)$$

O resultado de posto reduzido deve ser interpretado em relação ao objeto decomposto: na Análise de Correspondência, a SVD truncada aproxima a matriz ponderada de desvios da independência.

18.8 Coordenadas da Análise de Correspondência

A geometria dos perfis é ponderada pelas massas. As coordenadas utilizadas na representação incorporam essa ponderação.

18.8.1 Coordenadas padrão

Definição 18.7 (Coordenadas padrão). As coordenadas padrão das linhas são

$$\mathbf{A}_r = \mathbf{D}_r^{-1/2} \mathbf{U}, \quad (18.37)$$

e as coordenadas padrão das colunas são

$$\mathbf{A}_c = \mathbf{D}_c^{-1/2} \mathbf{V}. \quad (18.38)$$

Como

$$\mathbf{U}^\top \mathbf{U} = \mathbf{I}_K,$$

tem-se

$$\mathbf{A}_r^\top \mathbf{D}_r \mathbf{A}_r = \mathbf{I}_K. \quad (18.39)$$

Da mesma forma,

$$\mathbf{A}_c^\top \mathbf{D}_c \mathbf{A}_c = \mathbf{I}_K. \quad (18.40)$$

18.8.2 Coordenadas principais

Definição 18.8 (Coordenadas principais). As coordenadas principais das linhas são

$$\mathbf{F}_r = \mathbf{A}_r \mathbf{D} = \mathbf{D}_r^{-1/2} \mathbf{U} \mathbf{D}, \quad (18.41)$$

e as coordenadas principais das colunas são

$$\mathbf{F}_c = \mathbf{A}_c \mathbf{D} = \mathbf{D}_c^{-1/2} \mathbf{V} \mathbf{D}. \quad (18.42)$$

Para as linhas,

$$\mathbf{F}_r^\top \mathbf{D}_r \mathbf{F}_r = \mathbf{D}^2, \quad (18.43)$$

de modo que

$$\sum_{i=1}^I r_i \left(f_{i\ell}^{(r)} \right)^2 = \lambda_\ell. \quad (18.44)$$

Analogamente,

$$\mathbf{F}_c^\top \mathbf{D}_c \mathbf{F}_c = \mathbf{D}^2 \quad (18.45)$$

e

$$\sum_{j=1}^J c_j \left(f_{j\ell}^{(c)} \right)^2 = \lambda_\ell. \quad (18.46)$$

Cada inércia principal pode, portanto, ser obtida tanto pela dispersão ponderada das coordenadas das linhas quanto pela dispersão ponderada das coordenadas das colunas.

18.8.3 Distâncias entre perfis e coordenadas principais

As coordenadas principais preservam a geometria qui-quadrado quando todas as dimensões não nulas da Análise de Correspondência são mantidas.

Considere a matriz dos perfis de linhas,

$$\mathbf{P}^{(r)} = \mathbf{D}_r^{-1} \mathbf{P}.$$

Como

$$\mathbf{P} - \mathbf{r}\mathbf{c}^\top = \mathbf{D}_r \left(\mathbf{P}^{(r)} - \mathbf{1}_I \mathbf{c}^\top \right),$$

a matriz de desvios padronizados pode ser escrita como

$$\mathbf{Q}_{CA} = \mathbf{D}_r^{1/2} \left(\mathbf{P}^{(r)} - \mathbf{1}_I \mathbf{c}^\top \right) \mathbf{D}_c^{-1/2}. \quad (18.47)$$

Logo,

$$(\mathbf{P}^{(r)} - \mathbf{1}_I \mathbf{c}^\top) \mathbf{D}_c^{-1/2} = \mathbf{D}_r^{-1/2} \mathbf{Q}_{\text{CA}}.$$

Substituindo a SVD de Equação 18.28,

$$\begin{aligned} (\mathbf{P}^{(r)} - \mathbf{1}_I \mathbf{c}^\top) \mathbf{D}_c^{-1/2} &= \mathbf{D}_r^{-1/2} \mathbf{U} \mathbf{D} \mathbf{V}^\top \\ &= \mathbf{F}_r \mathbf{V}^\top. \end{aligned} \quad (18.48)$$

A linha i da matriz à esquerda é

$$(\mathbf{p}_{i|\cdot} - \mathbf{c})^\top \mathbf{D}_c^{-1/2},$$

isto é, o perfil centralizado representado na geometria qui-quadrado.

Para duas linhas i e i' , a diferença entre essas representações é

$$(\mathbf{p}_{i|\cdot} - \mathbf{p}_{i'|\cdot})^\top \mathbf{D}_c^{-1/2}.$$

Sua norma euclidiana ao quadrado é

$$\begin{aligned} (\mathbf{p}_{i|\cdot} - \mathbf{p}_{i'|\cdot})^\top \mathbf{D}_c^{-1} (\mathbf{p}_{i|\cdot} - \mathbf{p}_{i'|\cdot}) \\ = d_{\chi^2}^2(i, i'). \end{aligned}$$

Por Equação 18.48, essa mesma diferença pode ser escrita nas coordenadas principais das linhas. Como as colunas de $\mathbf{V}$ são ortonormais e contêm todas as direções não nulas da representação,

$$d_{\chi^2}^2(i, i') = \|\mathbf{f}_i^{(r)} - \mathbf{f}_{i'}^{(r)}\|^2, \quad (18.49)$$

em que

$$\mathbf{f}_i^{(r)}$$

denota a linha i de $\mathbf{F}_r$.

De modo análogo,

$$d_{\chi^2}^2(j, j') = \|\mathbf{f}_j^{(c)} - \mathbf{f}_{j'}^{(c)}\|^2. \quad (18.50)$$

Proposição 18.2 (Preservação das distâncias qui-quadrado). *Considere uma tabela com massas de linhas e colunas estritamente positivas e as coordenadas principais obtidas da SVD de $\mathbf{Q}_{CA}$. Quando todas as dimensões associadas aos valores singulares positivos são mantidas, as distâncias euclidianas entre as coordenadas principais das linhas reproduzem exatamente as distâncias qui-quadrado entre seus perfis.*

O mesmo resultado vale para os perfis de colunas e suas coordenadas principais.

O resultado explica por que a Análise de Correspondência pode representar uma geometria originalmente ponderada por meio de coordenadas euclidianas. A ponderação pelas massas é incorporada antes da SVD; depois dessa transformação, as distâncias entre os pontos podem ser medidas pela norma euclidiana usual.

Quando apenas as primeiras $k < K$ dimensões são mantidas,

$$\left\| \mathbf{f}_{i,k}^{(r)} - \mathbf{f}_{i',k}^{(r)} \right\|^2 \leq d_{\chi^2}^2(i, i'),$$

pois parte das coordenadas é descartada.

A igualdade é recuperada quando todas as dimensões que contribuem para a diferença entre os dois perfis são mantidas.

18.8.4 Relações baricêtricas

A representação das linhas e das colunas não resulta de duas análises separadas. As duas nuvens estão relacionadas pela mesma matriz $\mathbf{P}$ e pela mesma decomposição em valores singulares.

Partindo de

$$\mathbf{Q}_{CA} \mathbf{V} = \mathbf{U} \mathbf{D},$$

tem-se

$$\mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r} \mathbf{c}^\top) \mathbf{D}_c^{-1/2} \mathbf{V} = \mathbf{U} \mathbf{D}.$$

Como

$$\mathbf{A}_c = \mathbf{D}_c^{-1/2} \mathbf{V},$$

segue que

$$\mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r}\mathbf{c}^\top) \mathbf{A}_c = \mathbf{U}\mathbf{D}.$$

Para os vetores singulares associados aos valores singulares positivos,

$$\mathbf{c}^\top \mathbf{A}_c = \mathbf{0}^\top. \quad (18.51)$$

Logo,

$$\mathbf{D}_r^{-1/2} \mathbf{P} \mathbf{A}_c = \mathbf{U}\mathbf{D}.$$

Multiplicando à esquerda por $\mathbf{D}_r^{-1/2}$,

$$\mathbf{F}_r = \mathbf{D}_r^{-1} \mathbf{P} \mathbf{A}_c. \quad (18.52)$$

De forma dual,

$$\mathbf{F}_c = \mathbf{D}_c^{-1} \mathbf{P}^\top \mathbf{A}_r. \quad (18.53)$$

As equações Equação 18.52 e Equação 18.53 são denominadas **relações baricêntricas** ou relações de transição.

Para a linha i , Equação 18.52 fornece

$$\mathbf{f}_i^{(r)} = \sum_{j=1}^J \frac{p_{ij}}{r_i} \mathbf{a}_j^{(c)}, \quad (18.54)$$

em que

$$\mathbf{a}_j^{(c)}$$

é o vetor de coordenadas padrão da coluna j .

Como

$$\sum_{j=1}^J \frac{p_{ij}}{r_i} = 1,$$

a coordenada principal da linha i é o centro ponderado das coordenadas padrão das colunas, com pesos dados pelo próprio perfil da linha.

Analogamente,

$$\mathbf{f}_j^{(c)} = \sum_{i=1}^I \frac{p_{ij}}{c_j} \mathbf{a}_i^{(r)}, \quad (18.55)$$

em que $\mathbf{a}_i^{(r)}$ contém as coordenadas padrão da linha i .

Assim, cada categoria de uma variável é posicionada em função da distribuição condicional das categorias da outra variável.

Uma linha que concentra grande parte de seu perfil em determinadas colunas tende a ser posicionada na direção das coordenadas correspondentes dessas colunas. O mesmo raciocínio vale para as colunas em relação às linhas.

A Figura 18.1 ilustra essa propriedade para uma tabela simples. As coordenadas principais de uma linha são mostradas no mesmo sistema das coordenadas padrão das colunas utilizadas em sua relação baricêntrica.

A figura não afirma que a distância entre uma linha e uma coluna seja uma distância qui-quadrado. Ela representa a relação de centro ponderado expressa em Equação 18.54.

18.8.5 Reconstrução dos desvios da independência

A SVD também permite reconstruir a matriz de frequências relativas a partir de sua estrutura de independência e dos termos de associação.

De Equação 18.20,

$$\mathbf{P} - \mathbf{rc}^\top = \mathbf{D}_r^{1/2} \mathbf{Q}_{CA} \mathbf{D}_c^{1/2}.$$

Substituindo a SVD,

$$\mathbf{P} - \mathbf{rc}^\top = \mathbf{D}_r^{1/2} \mathbf{U} \mathbf{D} \mathbf{V}^\top \mathbf{D}_c^{1/2}.$$

Como

$$\mathbf{U} = \mathbf{D}_r^{1/2} \mathbf{A}_r$$

e

$$\mathbf{V} = \mathbf{D}_c^{1/2} \mathbf{A}_c,$$




Figura 18.1: Relação baricêntrica entre uma linha e as coordenadas padrão das colunas. A posição da linha é a média ponderada das posições das colunas, com pesos dados pelo perfil da própria linha.

obtém-se

$$\mathbf{P} - \mathbf{r}\mathbf{c}^\top = \mathbf{D}_r \mathbf{A}_r \mathbf{D}_c \mathbf{A}_c^\top \mathbf{D}_c. \quad (18.56)$$

Elemento a elemento,

$$p_{ij} - r_i c_j = r_i c_j \sum_{\ell=1}^K d_\ell a_{i\ell}^{(r)} a_{j\ell}^{(c)}. \quad (18.57)$$

Logo,

$$p_{ij} = r_i c_j \left[1 + \sum_{\ell=1}^K d_\ell a_{i\ell}^{(r)} a_{j\ell}^{(c)} \right]. \quad (18.58)$$

A expressão separa duas estruturas:

$$r_i c_j$$

é a frequência relativa correspondente à independência, enquanto

$$r_i c_j \sum_{\ell=1}^K d_\ell a_{i\ell}^{(r)} a_{j\ell}^{(c)}$$

representa o desvio reconstruído pelas dimensões da associação.

Quando apenas as primeiras k dimensões são utilizadas,

$$\tilde{p}_{ij}^{(k)} = r_i c_j \left[1 + \sum_{\ell=1}^k d_\ell a_{i\ell}^{(r)} a_{j\ell}^{(c)} \right]. \quad (18.59)$$

A expressão fornece a reconstrução de posto reduzido associada à aproximação de $\mathbf{Q}_{CA}$ em Equação 18.34. Quando $k < K$, essa reconstrução é uma aproximação algébrica dos desvios da independência e não impõe, por si só, a não negatividade de todas as células. Por isso, $\tilde{p}_{ij}^{(k)}$ não deve ser interpretado automaticamente como uma nova tabela de probabilidades.

A redução dimensional possui, assim, duas leituras equivalentes: aproximar a matriz de desvios padronizados ou reconstruir a associação observada utilizando apenas as primeiras dimensões.

18.9 Representação conjunta de linhas e colunas

A Análise de Correspondência fornece coordenadas para as duas margens da tabela. Para construir uma representação conjunta, é necessário definir quais sistemas de coordenadas serão exibidos para linhas e colunas.

Três formas são particularmente úteis para compreender a geometria.

Tabela 18.2: Sistemas de coordenadas para representar linhas e colunas na Análise de Correspondência.

representação	linhas	colunas	propriedade principal
métrica das linhas	principais $\mathbf{F}_r$	padrão $\mathbf{A}_c$	preserva a geometria das linhas e explicita sua relação baricêntrica com as colunas
métrica das colunas	padrão $\mathbf{A}_r$	principais $\mathbf{F}_c$	preserva a geometria das colunas e explicita sua relação baricêntrica com as linhas
simétrica	principais $\mathbf{F}_r$	principais $\mathbf{F}_c$	coloca ambas as nuvens em escalas associadas às inércias principais

Na representação métrica das linhas, as distâncias entre pontos de linhas reproduzem as distâncias qui-quadrado quando todas as dimensões são utilizadas. As posições das colunas funcionam como coordenadas padrão associadas às relações baricênticas.

Na representação métrica das colunas ocorre o resultado dual.

A representação simétrica é frequentemente útil para visualizar simultaneamente as duas nuvens, mas exige uma interpretação cuidadosa.

18.9.1 O significado das proximidades

Dentro de uma mesma nuvem, a interpretação é direta:

- linhas próximas possuem perfis de colunas semelhantes segundo a distância qui-quadrado;
- colunas próximas possuem perfis de linhas semelhantes segundo a distância qui-quadrado.

Entre uma linha e uma coluna, entretanto, a distância gráfica não é, em geral, uma distância qui-quadrado definida pela técnica.

Assim, a proximidade visual entre uma categoria de linha e uma categoria de coluna não deve ser interpretada automaticamente como uma medida métrica de associação entre essas duas categorias.

A relação entre linhas e colunas é melhor fundamentada pelas relações baricêntricas, pelos sinais e magnitudes das coordenadas nas dimensões e pela reconstrução dos desvios em Equação 18.57.

Essa distinção é especialmente importante em mapas simétricos, nos quais linhas e colunas são colocadas no mesmo plano para facilitar a leitura, embora pertençam originalmente a espaços de perfis diferentes.

18.9.2 Contribuição para as dimensões

A igualdade em Equação 18.44 mostra que a inércia principal da dimensão ℓ pode ser decomposta entre as categorias de linhas:

$$\lambda_\ell = \sum_{i=1}^I r_i \left(f_{i\ell}^{(r)} \right)^2.$$

Isso permite definir a parcela da dimensão associada a cada categoria.

Definição 18.9 (Contribuição para uma dimensão). A contribuição da linha i para a dimensão ℓ é

$$\text{ctr}_{i\ell}^{(r)} = \frac{r_i \left(f_{i\ell}^{(r)} \right)^2}{\lambda_\ell}. \quad (18.60)$$

A contribuição da coluna j é

$$\text{ctr}_{j\ell}^{(c)} = \frac{c_j \left(f_{j\ell}^{(c)} \right)^2}{\lambda_\ell}. \quad (18.61)$$

Para cada dimensão,

$$\sum_{i=1}^I \text{ctr}_{i\ell}^{(r)} = 1 \quad (18.62)$$

e

$$\sum_{j=1}^J \text{ctr}_{j\ell}^{(c)} = 1. \quad (18.63)$$

A contribuição mede quanto determinada categoria participa da inércia que define o eixo.

Uma categoria pode possuir grande coordenada em uma dimensão e ainda apresentar contribuição moderada se sua massa for pequena. A contribuição combina, portanto, posição geométrica e peso marginal.

O conceito não deve ser confundido com qualidade de representação. Uma categoria pode contribuir fortemente para construir um eixo e, ainda assim, possuir parte relevante de sua própria distância ao centro distribuída por outras dimensões.

18.9.3 Qualidade de representação

Para uma linha i , a distância ao centro satisfaz, na representação completa,

$$d_{\chi^2}^2(i, \mathbf{c}) = \sum_{\ell=1}^K \left(f_{i\ell}^{(r)}\right)^2. \quad (18.64)$$

A parcela dessa distância associada à dimensão ℓ é medida por

Definição 18.10 (Qualidade de representação por dimensão). Para uma linha i com

$$d_{\chi^2}^2(i, \mathbf{c}) > 0,$$

define-se

$$\cos_{i\ell}^2 = \frac{\left(f_{i\ell}^{(r)}\right)^2}{d_{\chi^2}^2(i, \mathbf{c})}. \quad (18.65)$$

Para uma coluna j com distância positiva ao centro,

$$\cos_{j\ell}^2 = \frac{\left(f_{j\ell}^{(c)}\right)^2}{d_{\chi^2}^2(j, \mathbf{r})}. \quad (18.66)$$

Como

$$\sum_{\ell=1}^K \cos_{i\ell}^2 = 1,$$

o valor

$$\cos_{i\ell}^2$$

mede a parcela da distância quadrática da categoria ao centro representada pela dimensão ℓ .

Para as primeiras k dimensões,

$$\sum_{\ell=1}^k \cos_{i\ell}^2 \tag{18.67}$$

mede a parcela da distância da categoria representada pelo subespaço escolhido.

As duas medidas possuem papéis distintos, como sintetiza a Tabela 18.3.

Tabela 18.3: Diferença entre contribuição e qualidade de representação na Análise de Correspondência.

Medida	Numerador	Referência	Interpretação
contribuição	$r_i(f_{i\ell}^{(r)})^2$ ou $c_j(f_{j\ell}^{(c)})^2$	inércia do eixo λ_ℓ	participação da categoria na construção da dimensão
$\cos^2$	$(f_{i\ell}^{(r)})^2$ ou $(f_{j\ell}^{(c)})^2$	distância da própria categoria ao centro	qualidade com que a dimensão representa a categoria

A contribuição distribui a **inércia de uma dimensão entre as categorias**. O $\cos^2$ distribui a **distância de uma categoria entre as dimensões**.

Essa diferença evita duas interpretações frequentes, mas distintas: identificar quais categorias determinam um eixo e avaliar se determinada categoria está bem representada por esse eixo.

CrITÉRIOS operacionais baseados em valores médios de contribuição, limiares de $\cos^2$ ou seleção automática de categorias pertencem à etapa de interpretação aplicada e não são necessários para a formulação matemática da técnica.

18.10 Formulação descritiva e inferencial

A identidade

$$\chi^2 = n\mathcal{J}$$

estabelecida em Equação 18.27 permite distinguir dois usos relacionados da mesma estrutura.

Na Análise de Correspondência, a inércia

$$\mathcal{J}$$

é utilizada para descrever e decompor geometricamente o afastamento da independência observado na tabela. Essa construção pode ser realizada sem atribuir à tabela um modelo probabilístico específico.

Para interpretar

$$\chi^2$$

como estatística de teste, é necessário introduzir um modelo de amostragem. Sob uma formulação apropriada para uma tabela de contingência, a hipótese de independência pode ser escrita como

$$H_0 : \pi_{ij} = \pi_{i.}\pi_{.j}, \quad (18.68)$$

em que π_{ij} representa a probabilidade populacional da célula (i, j) .

Sob um esquema de amostragem multinomial, ou uma formulação clássica equivalente para tabelas de contingência, considere I e J fixos e probabilidades marginais populacionais estritamente positivas. Sob H_0 e quando $n \rightarrow \infty$,

$$\chi^2 \xrightarrow{d} \chi^2_{(I-1)(J-1)}. \quad (18.69)$$

A teoria geral de testes e aproximações assintóticas pertence ao Módulo 2. Neste capítulo, o resultado serve para delimitar a relação entre a decomposição geométrica e o problema inferencial de independência.

A significância do teste global e a interpretação das dimensões da Análise de Correspondência são questões diferentes. Rejeitar

$$H_0$$

fornece evidência de associação entre as variáveis, mas não estabelece, por si só, que cada dimensão obtida pela SVD represente uma estrutura populacional distinta.

Da mesma forma, uma associação estatisticamente detectável pode possuir pequena inércia quando o tamanho amostral é grande, pois

$$\chi^2 = n\mathcal{I}.$$

Essa distinção pode ser vista replicando todas as frequências da tabela por um mesmo fator inteiro positivo a :

$$a \in \mathbb{N}, \quad a \geq 1.$$

$$\mathbf{N}^* = a\mathbf{N}.$$

Nesse caso,

$$n^* = an,$$

mas

$$\mathbf{P}^* = \frac{\mathbf{N}^*}{n^*} = \mathbf{P}.$$

Consequentemente, permanecem inalterados:

$$\mathbf{r}, \quad \mathbf{c}, \quad \mathbf{Q}_{\text{CA}}, \quad \mathcal{I}$$

e todas as coordenadas da representação.

Por outro lado,

$$\chi^{2*} = a\chi^2.$$

A geometria descritiva depende das proporções observadas, enquanto a estatística de teste também incorpora o tamanho total da tabela.

18.11 Relações com a ACP e o MDS

A Análise de Correspondência utiliza estruturas matemáticas que já apareceram em outras técnicas do Módulo 3. A semelhança algébrica permite estabelecer conexões, mas não elimina as diferenças entre os problemas estatísticos.

18.11.1 Relação com a Análise de Componentes Principais

Considere novamente a matriz dos perfis de linhas,

$$\mathbf{P}^{(r)} = \mathbf{D}_r^{-1} \mathbf{P}.$$

A matriz de desvios padronizados pode ser escrita, conforme Equação 18.47, como

$$\mathbf{Q}_{CA} = \mathbf{D}_r^{1/2} (\mathbf{P}^{(r)} - \mathbf{1}_I \mathbf{c}^\top) \mathbf{D}_c^{-1/2}. \quad (18.70)$$

Essa expressão evidencia três operações:

1. os perfis de linhas são centralizados em torno de $\mathbf{c}$;
2. as linhas são ponderadas por suas massas por meio de $\mathbf{D}_r^{1/2}$;
3. as coordenadas dos perfis são reescaladas pelas massas das colunas por meio de $\mathbf{D}_c^{-1/2}$.

A SVD é aplicada à matriz resultante.

A relação com a ACP está na procura de uma representação de posto reduzido a partir de uma matriz centralizada e na decomposição da dispersão entre dimensões ortogonais. Entretanto, a geometria da Correspondência é determinada pelos pesos marginais da tabela.

Na ACP usual, a medida de dispersão é construída a partir da geometria euclidiana das variáveis, ou da geometria correspondente à padronização quando a matriz de correlações é utilizada.

Na Análise de Correspondência, a dispersão é

$$\mathcal{J} = \sum_{i=1}^I r_i d_{\chi^2}^2(i, \mathbf{c}),$$

com

$$d_{\chi^2}^2(i, i') = (\mathbf{p}_{i|\cdot} - \mathbf{p}_{i'|\cdot})^\top \mathbf{D}_c^{-1} (\mathbf{p}_{i|\cdot} - \mathbf{p}_{i'|\cdot}).$$

Assim, a Correspondência pode ser relacionada a uma análise espectral ponderada de perfis, mas não deve ser identificada simplesmente como uma ACP aplicada a dados qualitativos (Greenacre, 2017).

A Tabela 18.4 resume as diferenças.

Tabela 18.4: Relação entre a ACP e a Análise de Correspondência.

Aspecto	ACP	Análise de Correspondência
objeto inicial	matriz de dados quantitativos ou matriz de covariâncias/correlações	tabela de contingência
unidades representadas	observações e/ou variáveis	categorias de linhas e colunas
centro	vetor de médias	perfis marginais $\mathbf{c}$ e $\mathbf{r}$
pesos das unidades	usualmente iguais na formulação básica	massas r_i e c_j
geometria	euclidiana ou padronizada	qui-quadrado
quantidade decomposta	variância	inércia
ferramenta espectral	autovalores ou SVD	SVD dos desvios padronizados

18.11.2 Relação com o Escalonamento Multidimensional

O capítulo anterior mostrou que o MDS procura construir coordenadas que representem uma matriz de dissimilaridades.

Na Análise de Correspondência, as dissimilaridades entre perfis não são fornecidas externamente. Elas são determinadas pela própria tabela por meio da distância qui-quadrado.

Considere os perfis de linhas e defina

$$\Delta_{\chi^2}^{(r)} = (d_{\chi^2}(i, i')).$$

Pela propriedade em Proposição 18.2, as coordenadas principais completas das linhas satisfazem

$$d_{\chi^2}(i, i') = \|\mathbf{f}_i^{(r)} - \mathbf{f}_{i'}^{(r)}\|.$$

Assim, a matriz

$$\Delta_{\chi^2}^{(r)}$$

é uma matriz de distâncias euclidianas quando os perfis são considerados após a transformação determinada por $\mathbf{D}_c^{-1/2}$.

Se o MDS clássico for aplicado a essas distâncias, ele produzirá uma configuração com a mesma geometria entre as linhas, até as indeterminações de translação e transformação ortogonal discutidas no capítulo anterior.

O mesmo resultado pode ser formulado para as colunas.

A diferença está novamente no ponto de partida. No MDS, uma matriz de dissimilaridades é o objeto fornecido à técnica. Na Correspondência, a geometria é derivada de uma tabela de contingência e possui uma ponderação específica determinada pelas massas.

Além disso, a Correspondência constrói duas nuvens relacionadas, uma de linhas e outra de colunas. Essa dualidade não faz parte da formulação geral do MDS.

A relação entre as três técnicas de representação é sintetizada na Tabela 18.5.

Tabela 18.5: Diferentes problemas de representação na ACP, no MDS e na Análise de Correspondência.

Técnica	Estrutura representada	Geometria ou critério
ACP	variabilidade de observações quantitativas	variância e projeção
MDS	relações de dissimilaridade entre objetos	fidelidade das distâncias ou dos produtos internos
Correspondência	associação entre categorias de uma tabela	distância qui-quadrado e inércia

O uso de SVD, autovalores ou aproximações de posto reduzido não caracteriza sozinho uma técnica. A interpretação decorre do objeto que foi transformado e da medida que a decomposição procura representar.

18.12 Pressupostos e limites da representação

A formulação da Análise de Correspondência é predominantemente geométrica, mas algumas condições determinam se os objetos utilizados pela técnica estão bem definidos e como seus resultados podem ser interpretados.

18.12.1 Massas positivas

A formulação utilizada neste capítulo pressupõe

$$r_i > 0$$

e

$$c_j > 0.$$

Essa condição garante a existência de

$$\mathbf{D}_r^{-1}, \quad \mathbf{D}_c^{-1}, \quad \mathbf{D}_r^{-1/2}, \quad \mathbf{D}_c^{-1/2}.$$

Uma linha ou coluna com frequência marginal nula não possui perfil definido e deve ser retirada da tabela ativa.

18.12.2 Categorias de pequena massa

Massas positivas muito pequenas não impedem matematicamente a análise, mas produzem pesos elevados na distância qui-quadrado:

$$\frac{1}{r_i} \quad \text{ou} \quad \frac{1}{c_j}.$$

Uma diferença envolvendo uma categoria rara pode, portanto, exercer influência elevada sobre a geometria.

Essa característica decorre da própria métrica da técnica e deve ser considerada na interpretação da solução. Procedimentos de agregação ou tratamento de categorias raras pertencem à etapa aplicada da análise.

18.12.3 Frequências nulas

Uma frequência celular

$$n_{ij} = 0$$

não impede, por si só, a Análise de Correspondência quando as massas da linha e da coluna correspondentes são positivas.

Nesse caso,

$$p_{ij} = 0$$

representa uma ausência observada naquela combinação de categorias e participa normalmente do cálculo do desvio

$$p_{ij} - r_i c_j.$$

Zeros estruturais, para os quais determinada combinação é impossível por definição do problema, possuem outro significado. Eles modificam a estrutura de comparação com a independência e exigem uma formulação adequada ao mecanismo que gerou a tabela.

18.12.4 Dimensão da representação

A dimensão máxima é

$$K \leq \min(I - 1, J - 1).$$

Quando apenas

$$k < K$$

dimensões são apresentadas, a representação contém somente a parcela

$$\frac{\sum_{\ell=1}^k \lambda_{\ell}}{\sum_{\ell=1}^K \lambda_{\ell}}$$

da inércia total.

Uma representação bidimensional não implica que a associação observada possua exatamente duas dimensões. Ela é uma aproximação de posto reduzido quando existem outras inércias principais positivas.

18.12.5 Sinais e orientação dos eixos

A SVD possui as indeterminações discutidas no Módulo 1. Para cada dimensão, multiplicar simultaneamente os vetores singulares correspondentes por -1 não altera

$$\mathbf{Q}_{CA}.$$

Consequentemente, o sinal absoluto das coordenadas de um eixo não possui significado.

O que permanece interpretável são:

- posições relativas;
- distâncias dentro de cada nuvem;
- oposição entre categorias ao longo de uma dimensão;
- contribuições;
- qualidade de representação;
- relações baricêntricas.

Quando valores singulares são repetidos, a orientação de cada eixo individual dentro do subespaço correspondente também deixa de ser única. Nesse caso, o subespaço é o objeto geometricamente identificado.

18.12.6 Proximidade entre linhas e colunas

As distâncias euclidianas entre linhas em coordenadas principais possuem interpretação como distâncias qui-quadrado entre seus perfis. O mesmo vale entre colunas.

Essa propriedade não se estende diretamente à distância entre um ponto de linha e um ponto de coluna em um mapa conjunto.

A Figura 18.2 ilustra essa distinção.

O mapa permite examinar simultaneamente a estrutura das duas margens, mas a leitura deve respeitar a métrica associada a cada nuvem. A interpretação cruzada é sustentada principalmente pela estrutura dos perfis e pelas relações baricêntricas, e não pela distância gráfica direta entre símbolos de tipos diferentes.




Figura 18.2: Representação conjunta das categorias de linhas e colunas. Distâncias dentro da mesma nuvem possuem interpretação geométrica própria; a distância entre uma linha e uma coluna não corresponde, em geral, a uma distância qui-quadrado.

18.12.7 Associação e causalidade

A Análise de Correspondência descreve a estrutura de associação presente na tabela. A posição das categorias e a decomposição da inércia não estabelecem relações causais entre as variáveis.

Da mesma forma, uma dimensão não constitui automaticamente uma variável latente substantiva. Seu significado depende dos contrastes entre perfis que produzem a inércia correspondente e do conhecimento sobre o problema analisado.

18.13 Síntese

A Análise de Correspondência representa a associação entre as categorias de duas variáveis qualitativas a partir de uma tabela de contingência. A matriz de frequências relativas

$$\mathbf{P} = \frac{1}{n} \mathbf{N}$$

determina as massas e os perfis das linhas e das colunas. Sob independência,

$$\mathbf{P} = \mathbf{rc}^\top,$$

de modo que todos os perfis de cada margem coincidem com seu respectivo perfil médio.

O afastamento dessa estrutura é representado pela matriz

$$\mathbf{Q}_{CA} = \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{rc}^\top) \mathbf{D}_c^{-1/2}.$$

Sua norma de Frobenius ao quadrado é a inércia total,

$$\mathcal{J} = \|\mathbf{Q}_{CA}\|_F^2 = \frac{\chi^2}{n}.$$

A SVD de $\mathbf{Q}_{CA}$ decompõe essa associação em dimensões ortogonais. Os quadrados dos valores singulares são as inércias principais, e as coordenadas resultantes fornecem representações euclidianas das geometrias qui-quadrado dos perfis.

A técnica possui uma estrutura dual: linhas e colunas são construídas pela mesma decomposição e estão relacionadas por relações baricêtricas. Distâncias entre categorias da mesma margem possuem interpretação como distâncias qui-quadrado; a distância gráfica direta entre uma linha e uma coluna não possui, em geral, essa interpretação.

A contribuição descreve a participação de uma categoria na construção de uma dimensão, enquanto o $\cos^2$ descreve quanto da posição dessa categoria é representado pelo eixo ou pelo subespaço escolhido.

A formulação geométrica é predominantemente descritiva. A interpretação de χ^2 como estatística de teste exige um modelo amostral e não transforma automaticamente cada dimensão da representação em um teste inferencial.

O próximo capítulo muda o objeto estatístico. Na MANOVA, o problema deixa de ser representar desvios da independência em uma tabela e passa a ser comparar vetores de médias no modelo linear multivariado. As matrizes de hipótese e erro conduzirão então a um problema de autovalores generalizados.

19 Formulação da MANOVA

A Análise de Variância Multivariada, MANOVA, é utilizada para testar hipóteses sobre vetores de médias ou, de forma mais geral, sobre funções dos parâmetros de um modelo linear com várias respostas. O problema surge quando cada unidade observacional fornece simultaneamente p respostas e o interesse recai sobre diferenças conjuntas associadas a grupos, tratamentos, fatores ou outros termos do modelo.

O modelo linear multivariado já foi definido em Definição 11.3 como

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E},$$

com uma única matriz de delineamento $\mathbf{Z}$ e uma matriz de parâmetros $\mathbf{B}$ cujas colunas correspondem às diferentes respostas.

A MANOVA não introduz um novo modelo para essas respostas. Seu conteúdo específico está na forma como uma hipótese sobre $\mathbf{B}$ é comparada com a variação residual conjunta. Essa comparação conduz às matrizes de hipótese e erro e, a partir delas, a um problema de autovalores generalizados. Os diferentes critérios clássicos de MANOVA são funções das raízes obtidas desse mesmo problema (Anderson, 2003; Rencher; Christensen, 2012).

Os elementos da formulação são resumidos na Tabela 19.1.

Tabela 19.1: Elementos da formulação da MANOVA.

Elemento	Objeto	Papel na MANOVA
respostas	$\mathbf{y}$	reúne as respostas multivariadas
delineamento	$\mathbf{Z}$	representa grupos, tratamentos, covariáveis e demais termos
parâmetros	$\mathbf{B}$	determina os vetores de médias condicionais
hipótese	$\mathbf{CB} = \Theta_0$	especifica a comparação sobre as respostas originais
variação atribuída à hipótese	$\mathbf{H}$	mede o afastamento observado em relação a H_0

Elemento	Objeto	Papel na MANOVA
variação residual	$\mathbf{E}$	mede a variabilidade não explicada pelo modelo
comparação direcional	$\mathbf{a}^\top \mathbf{H} \mathbf{a} / \mathbf{a}^\top \mathbf{E} \mathbf{a}$	compara hipótese e erro para uma combinação das respostas
solução espectral	raízes características	resume as direções de maior efeito relativo
critérios de teste	Wilks, Pillai, Hotelling–Lawley e Roy	agregam as raízes de formas distintas

19.1 O problema de comparação multivariada

Considere inicialmente G grupos e um vetor de p respostas para cada unidade,

$$\mathbf{Y}_i = \begin{pmatrix} Y_{i1} \\ \vdots \\ Y_{ip} \end{pmatrix} \in \mathbb{R}^p.$$

Se o vetor de médias do grupo g é

$$\mu_g = \begin{pmatrix} \mu_{g1} \\ \vdots \\ \mu_{gp} \end{pmatrix},$$

a hipótese de igualdade entre os grupos é

$$H_0 : \mu_1 = \mu_2 = \cdots = \mu_G. \quad (19.1)$$

A alternativa afirma que pelo menos dois desses vetores diferem.

Quando $p = 1$, a hipótese em Equação 19.1 é univariada e a comparação pode ser expressa pela razão entre uma soma de quadrados associada ao efeito e uma soma de quadrados residual.

Quando

$$p > 1,$$

o afastamento entre os grupos possui direção no espaço das respostas. Uma diferença pequena em cada resposta considerada isoladamente pode formar uma combinação linear com separação

relevante, enquanto diferenças marginais aparentemente grandes podem refletir informações redundantes entre respostas correlacionadas.

Por isso, a MANOVA procura avaliar a hipótese levando em conta simultaneamente:

- a magnitude das diferenças entre os vetores de médias;
- a variabilidade residual de cada resposta;
- as covariâncias residuais entre as respostas.

A dependência entre as respostas faz com que o problema não seja equivalente a realizar p análises de variância independentes. A MANOVA considera a estrutura conjunta representada pelas matrizes de somas de quadrados e produtos cruzados.

19.2 A hipótese no modelo linear multivariado

O caso de grupos é uma aplicação do modelo linear multivariado, e não uma formulação separada. Indicadores de grupos, tratamentos, fatores e covariáveis podem ser incorporados à matriz $\mathbf{Z}$.

A hipótese linear geral já foi definida em Definição 11.18:

$$H_0 : \mathbf{CBM} = \Theta_0. \quad (19.2)$$

A matriz

$$\mathbf{C}$$

seleciona ou contrasta os termos do modelo, enquanto

$$\mathbf{M}$$

seleciona ou combina as respostas.

Para testar diretamente efeitos sobre todas as respostas originais, toma-se

$$\mathbf{M} = \mathbf{I}_p,$$

e a hipótese assume a forma

$$H_0 : \mathbf{CB} = \Theta_0. \quad (19.3)$$

Essa será a formulação utilizada no restante deste capítulo. A hipótese mais geral

$$\mathbf{CBM} = \Theta_0$$

já foi desenvolvida no Módulo 2 e conduz à mesma construção quando aplicada às respostas transformadas por $\mathbf{M}$.

No problema de comparação entre G grupos, uma matriz $\mathbf{C}$ adequada pode expressar a igualdade entre seus vetores de médias. Assim, a formulação por grupos é incorporada à hipótese linear geral, permitindo que a mesma estrutura seja utilizada em delineamentos mais amplos.

19.2.1 Matrizes de hipótese e erro

A SSCP associada à hipótese já foi definida em Definição 11.19. Para a hipótese em Equação 19.3, denote essa matriz por

$$\mathbf{H} \in \mathbb{R}^{p \times p}.$$

A matriz

$$\mathbf{H}$$

é simétrica e semidefinida positiva. Sua diagonal reúne parcelas associadas às diferenças da hipótese para cada resposta, enquanto os elementos fora da diagonal contêm produtos cruzados entre essas diferenças.

A SSCP residual observada foi definida em Definição 11.11:

$$\mathbf{E} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}} \in \mathbb{R}^{p \times p}.$$

A matriz

$$\mathbf{E}$$

também é simétrica e semidefinida positiva. Ela reúne a variabilidade residual das respostas e suas covariações residuais na escala de somas de quadrados e produtos cruzados.

No caso de um fator com grupos, essas duas matrizes correspondem às estruturas multivariadas análogas às somas de quadrados entre e dentro dos grupos. Essa relação já foi construída no modelo linear multivariado; aqui, o objetivo é utilizar $\mathbf{H}$ e $\mathbf{E}$ para formular o teste conjunto.

A Tabela 19.2 distingue suas funções.

Tabela 19.2: Funções das matrizes de hipótese e erro na MANOVA.

Matriz	Origem	Interpretação
H	hipótese testada	variação multivariada atribuída ao efeito ou afastamento de H_0
E	resíduos do modelo	variação multivariada residual utilizada como referência

Se

$$\mathbf{H} = \mathbf{0},$$

não existe afastamento amostral da hipótese nas combinações de parâmetros consideradas.

Entretanto, a magnitude de **H** isoladamente não determina se esse afastamento é relevante. Um mesmo valor da hipótese possui significado diferente quando a variabilidade residual é pequena ou grande. A MANOVA deve, portanto, comparar **H** com **E**.

19.3 Hipótese e erro em uma combinação linear das respostas

Considere uma combinação linear das p respostas definida por

$$W = \mathbf{a}^\top \mathbf{Y}, \quad \mathbf{a} \in \mathbb{R}^p. \quad (19.4)$$

Para essa combinação, a parcela da SSCP associada à hipótese é

$$h(\mathbf{a}) = \mathbf{a}^\top \mathbf{H} \mathbf{a}, \quad (19.5)$$

enquanto a parcela residual é

$$e(\mathbf{a}) = \mathbf{a}^\top \mathbf{E} \mathbf{a}. \quad (19.6)$$

As duas expressões são formas quadráticas. A primeira mede o efeito da hipótese na direção definida por $\mathbf{a}$; a segunda mede a variabilidade residual na mesma direção.

Quando

$$\mathbf{E} \succ \mathbf{0},$$

tem-se

$$\mathbf{a}^\top \mathbf{E} \mathbf{a} > 0$$

para todo

$$\mathbf{a} \neq \mathbf{0}.$$

Pode-se então comparar hipótese e erro pela razão

$$\mathcal{R}_{\mathbf{H}, \mathbf{E}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{H} \mathbf{a}}{\mathbf{a}^\top \mathbf{E} \mathbf{a}}. \quad (19.7)$$

A expressão em Equação 19.7 é exatamente o quociente de Rayleigh generalizado definido em Definição 5.12, aplicado ao par

$$(\mathbf{H}, \mathbf{E}).$$

Essa identificação é o ponto em que os fundamentos espectrais do Módulo 1 entram na formulação da MANOVA. Não é necessário reconstruir a teoria do quociente de Rayleigh: o problema estatístico fornece as matrizes às quais aquele resultado geral será aplicado.

A razão é invariante à escala do vetor. Para

$$c \neq 0,$$

$$\mathcal{R}_{\mathbf{H}, \mathbf{E}}(c\mathbf{a}) = \mathcal{R}_{\mathbf{H}, \mathbf{E}}(\mathbf{a}).$$

Portanto, interessa a direção determinada por $\mathbf{a}$, e não seu comprimento.

Uma direção apresenta grande razão hipótese/erro quando a combinação correspondente das respostas evidencia um afastamento expressivo da hipótese relativamente à variabilidade residual nessa mesma combinação.

19.4 Raízes características da MANOVA

O objetivo é identificar as direções que tornam a razão em Equação 19.7 maior.

Pelo resultado geral para o quociente de Rayleigh generalizado, os pontos estacionários do problema

$$\max_{\mathbf{a} \neq \mathbf{0}} \frac{\mathbf{a}^\top \mathbf{H} \mathbf{a}}{\mathbf{a}^\top \mathbf{E} \mathbf{a}} \quad (19.8)$$

satisfazem

$$\mathbf{H} \mathbf{a} = \lambda \mathbf{E} \mathbf{a}. \quad (19.9)$$

Essa é a equação de autovalores generalizados definida em Definição 5.11.

Os valores

$$\lambda$$

obtidos do par

$$(\mathbf{H}, \mathbf{E})$$

são denominados **raízes características da MANOVA**. Eles medem a intensidade da variação associada à hipótese relativamente à variação residual nas direções determinadas pelos autovetores generalizados.

Definição 19.1 (Raízes características da MANOVA). Suponha

$$\mathbf{H} \succeq \mathbf{0}$$

e

$$\mathbf{E} \succ \mathbf{0}.$$

As raízes características da MANOVA são os autovalores generalizados

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p \geq 0$$

do par $(\mathbf{H}, \mathbf{E})$, isto é, os valores para os quais existe um vetor não nulo $\mathbf{a}_j$ satisfazendo

$$\mathbf{H}\mathbf{a}_j = \lambda_j \mathbf{E}\mathbf{a}_j.$$

Se

$$s = \text{rank}(\mathbf{H}),$$

então exatamente s dessas raízes são positivas. Quando $s < p$,

$$\lambda_1 \geq \dots \geq \lambda_s > 0 = \lambda_{s+1} = \dots = \lambda_p.$$

Como

$$s = \text{rank}(\mathbf{H}),$$

o número de raízes características positivas satisfaz

$$s = \text{rank}(\mathbf{H}) \leq p. \quad (19.10)$$

No caso de comparação entre G grupos,

$$\text{rank}(\mathbf{H}) \leq G - 1,$$

e, portanto,

$$s = \text{rank}(\mathbf{H}) \leq \min(p, G - 1). \quad (19.11)$$

Assim, mesmo quando existem muitas respostas, o número de direções distintas em que um efeito de grupos pode aparecer é limitado pelo número de contrastes independentes entre os grupos.

A maior raiz,

$$\lambda_1,$$

é o maior valor possível de Equação 19.7. As raízes subsequentes descrevem direções adicionais de comparação, sujeitas à ortogonalidade definida pela métrica residual. Os autovetores generalizados podem ser escolhidos de modo que

$$\mathbf{a}_j^\top \mathbf{E} \mathbf{a}_\ell = 0, \quad j \neq \ell. \quad (19.12)$$

Essa ortogonalidade não é definida pela geometria euclidiana usual, mas pela matriz de erro $\mathbf{E}$. As direções da MANOVA são, portanto, ortogonais segundo a estrutura de variabilidade residual das respostas.

19.4.1 Padronização pela dispersão residual

A interpretação geométrica torna-se mais direta transformando o espaço das respostas pela métrica definida por $\mathbf{E}$.

Como

$$\mathbf{E} \succ \mathbf{0},$$

a raiz quadrada principal e sua inversa existem. A equação

$$\mathbf{H} \mathbf{a} = \lambda \mathbf{E} \mathbf{a}$$

pode ser transformada definindo

$$\mathbf{z} = \mathbf{E}^{1/2} \mathbf{a}.$$

Assim,

$$\mathbf{a} = \mathbf{E}^{-1/2} \mathbf{z},$$

e

$$\mathbf{E}^{-1/2} \mathbf{H} \mathbf{E}^{-1/2} \mathbf{z} = \lambda \mathbf{z}. \quad (19.13)$$

Defina

$$\mathbf{K}_{\mathbf{HE}} = \mathbf{E}^{-1/2} \mathbf{H} \mathbf{E}^{-1/2}. \quad (19.14)$$

A matriz

$$\mathbf{K}_{\mathbf{HE}}$$

é simétrica e semidefinida positiva. Seus autovalores são as mesmas raízes características do problema generalizado.

A transformação por

$$\mathbf{E}^{-1/2}$$

normaliza a métrica residual. Nesse espaço transformado, a matriz de erro funciona como identidade, e a estrutura atribuída à hipótese é representada por

$$\mathbf{K}_{\text{HE}}.$$

Consequentemente, as raízes

$$\lambda_1, \dots, \lambda_s$$

podem ser interpretadas como magnitudes da hipótese depois que a escala e a dependência residual entre as respostas foram incorporadas à geometria da comparação.

Essa formulação também mostra por que analisar somente os elementos diagonais de $\mathbf{H}$ e $\mathbf{E}$ é insuficiente: as direções relevantes dependem da estrutura completa dessas matrizes, incluindo seus produtos cruzados.

A MANOVA reduz, assim, o problema de uma hipótese matricial a uma coleção ordenada de raízes que resumem a relação entre hipótese e erro. O passo seguinte é mostrar como os quatro critérios clássicos — lambda de Wilks, traço de Pillai, traço de Hotelling–Lawley e maior raiz de Roy — utilizam essa mesma coleção de raízes de maneiras diferentes.

19.5 Critérios multivariados

As raízes características

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_s > 0$$

resumem a relação entre a variação atribuída à hipótese e a variação residual em direções sucessivas do espaço das respostas.

A hipótese multivariada não é avaliada testando separadamente cada raiz. Os critérios clássicos combinam essas raízes em uma única estatística global.

Para facilitar a comparação, defina também as raízes transformadas

$$\theta_j = \frac{\lambda_j}{1 + \lambda_j}, \quad j = 1, \dots, s. \quad (19.15)$$

Como

$$\lambda_j > 0,$$

tem-se

$$0 < \theta_j < 1.$$

A transformação é estritamente crescente, de modo que λ_j e θ_j preservam a mesma ordenação das direções. A vantagem de θ_j é expressar cada razão hipótese/erro em uma escala limitada entre 0 e 1.

19.5.1 Lambda de Wilks

No Módulo 2, a razão de determinantes entre os modelos completo e reduzido foi relacionada à lambda de Wilks. Na notação utilizada neste capítulo,

$$\Lambda_W = \frac{|\mathbf{E}|}{|\mathbf{E} + \mathbf{H}|}. \quad (19.16)$$

Quando

$$\mathbf{E} \succ \mathbf{0},$$

pode-se escrever

$$\begin{aligned} \Lambda_W &= \frac{|\mathbf{E}|}{|\mathbf{E}| |\mathbf{I}_p + \mathbf{E}^{-1} \mathbf{H}|} \\ &= \frac{1}{|\mathbf{I}_p + \mathbf{E}^{-1} \mathbf{H}|}. \end{aligned}$$

Como os autovalores não nulos de $\mathbf{E}^{-1} \mathbf{H}$ são

$$\lambda_1, \dots, \lambda_s,$$

segue que

$$\Lambda_W = \prod_{j=1}^s \frac{1}{1 + \lambda_j}. \quad (19.17)$$

Utilizando Equação 19.15,

$$\Lambda_W = \prod_{j=1}^s (1 - \theta_j). \quad (19.18)$$

Definição 19.2 (Lambda de Wilks). A **lambda de Wilks** é

$$\Lambda_W = \frac{|\mathbf{E}|}{|\mathbf{E} + \mathbf{H}|} = \prod_{j=1}^s \frac{1}{1 + \lambda_j}.$$

Valores menores de Λ_W correspondem a maior afastamento relativo entre hipótese e erro.

Se

$$\mathbf{H} = \mathbf{0},$$

todas as raízes são nulas e

$$\Lambda_W = 1.$$

À medida que uma ou mais raízes aumentam, os fatores

$$\frac{1}{1 + \lambda_j}$$

diminuem e a lambda se afasta de 1.

A estrutura multiplicativa faz com que todas as direções contribuam para o critério. Uma raiz elevada reduz o produto, mas várias raízes moderadas também podem produzir valor pequeno.

No Módulo II, a razão de verossimilhanças para modelos lineares multivariados normais encaixados foi expressa em Equação 12.66 como uma potência da razão de determinantes

$$\frac{|\mathbf{E}_F|}{|\mathbf{E}_F + \mathbf{H}|}.$$

Na MANOVA, essa razão de determinantes define a lambda de Wilks e passa a ser interpretada a partir das raízes características (Wilks, 1932).

19.5.2 Traço de Pillai

Considere a matriz

$$\mathbf{H}(\mathbf{H} + \mathbf{E})^{-1}.$$

As raízes relevantes dessa comparação podem ser expressas por

$$\theta_j = \frac{\lambda_j}{1 + \lambda_j}.$$

A soma dessas raízes produz o traço de Pillai.

Definição 19.3 (Traço de Pillai). O **traço de Pillai** é

$$V = \text{tr} [\mathbf{H}(\mathbf{H} + \mathbf{E})^{-1}] = \sum_{j=1}^s \frac{\lambda_j}{1 + \lambda_j}. \quad (19.19)$$

Portanto,

$$V = \sum_{j=1}^s \theta_j.$$

Se

$$\mathbf{H} = \mathbf{0},$$

então

$$V = 0.$$

Cada raiz contribui por uma quantidade limitada:

$$0 < \frac{\lambda_j}{1 + \lambda_j} < 1.$$

Assim, uma raiz que cresce indefinidamente possui contribuição que se aproxima de 1, em vez de crescer sem limite.

O traço de Pillai agrega de forma aditiva as raízes transformadas e aumenta quando a hipótese se torna mais expressiva relativamente ao erro (Pillai, 1955).

19.5.3 Traço de Hotelling–Lawley

Outro resumo utiliza diretamente as raízes

$$\lambda_j.$$

Definição 19.4 (Traço de Hotelling–Lawley). O **traço de Hotelling–Lawley** é

$$U = \text{tr}(\mathbf{E}^{-1}\mathbf{H}) = \sum_{j=1}^s \lambda_j. \quad (19.20)$$

O critério soma diretamente as razões hipótese/erro das direções não nulas.

Se

$$\mathbf{H} = \mathbf{0},$$

então

$$U = 0.$$

Ao contrário do traço de Pillai, cada contribuição

$$\lambda_j$$

não possui limite superior. Uma direção com razão hipótese/erro muito elevada pode exercer grande influência sobre a soma.

19.5.4 Maior raiz de Roy

O quarto critério utiliza somente a maior razão hipótese/erro.

Definição 19.5 (Maior raiz de Roy). A **maior raiz de Roy** é

$$\Theta_R = \lambda_1 = \max_{1 \leq j \leq p} \lambda_j. \quad (19.21)$$

Como todas as raízes são não negativas, se

$$\mathbf{H} = \mathbf{0},$$

então

$$\lambda_1 = \dots = \lambda_p = 0$$

e, conseqüentemente,

$$\Theta_R = 0.$$

Pela caracterização do quociente de Rayleigh generalizado,

$$\Theta_R = \max_{\mathbf{a} \neq \mathbf{0}} \frac{\mathbf{a}^\top \mathbf{H} \mathbf{a}}{\mathbf{a}^\top \mathbf{E} \mathbf{a}}. \quad (19.22)$$

Logo, a maior raiz de Roy concentra a comparação na direção em que a hipótese é mais expressiva relativamente à dispersão residual.

Esse comportamento difere dos outros três critérios, que utilizam todas as raízes não nulas.

19.6 Uma mesma estrutura, quatro formas de agregação

Os quatro critérios não correspondem a quatro decomposições distintas. Todos são calculados a partir da mesma coleção

$$\lambda_1, \dots, \lambda_s.$$

O que muda é a forma como essa coleção é resumida.

A Tabela 19.3 reúne essas diferenças.

Tabela 19.3: Critérios clássicos da MANOVA como funções das mesmas raízes características.

Critério	Expressão em função das raízes	Forma de agregação	Evidência crescente contra H_0
Wilks	$\prod_{j=1}^s (1 + \lambda_j)^{-1}$	produto das parcelas complementares	valores menores

Critério	Expressão em função das raízes	Forma de agregação	Evidência crescente contra H_0
Pillai	$\sum_{j=1}^s \frac{\lambda_j}{1 + \lambda_j}$	soma das raízes transformadas	valores maiores
Hotelling–Lawley	$\sum_{j=1}^s \lambda_j$	soma direta das raízes	valores maiores
Roy	λ_1	maior raiz	valores maiores

A diferença pode ser examinada considerando duas estruturas hipotéticas de raízes. Uma situação pode apresentar uma única raiz muito elevada e as demais próximas de zero. Outra pode distribuir o efeito entre várias raízes moderadas.

A maior raiz de Roy enfatiza a primeira situação, porque utiliza somente

$$\lambda_1.$$

O traço de Hotelling–Lawley utiliza todas as raízes, mas mantém diretamente suas magnitudes.

O traço de Pillai também utiliza todas as raízes, porém cada contribuição é transformada para o intervalo $(0, 1)$.

A lambda de Wilks combina todas as raízes multiplicativamente.

Essas diferenças explicam por que os quatro critérios podem reagir de maneiras distintas à mesma configuração multivariada. A escolha e a comparação de suas calibrações em situações aplicadas pertencem à etapa metodológica posterior; neste capítulo, o ponto principal é que todos se originam da mesma relação espectral entre $\mathbf{H}$ e $\mathbf{E}$.

19.7 Base probabilística dos critérios

Até aqui, $\mathbf{H}$ e $\mathbf{E}$ foram tratadas como matrizes observadas e as raízes foram construídas algebricamente.

Para transformar os critérios em estatísticas de teste com distribuições de referência, é necessário especificar o modelo probabilístico.

Na formulação clássica, o modelo linear multivariado supõe que as linhas da matriz de erros sejam independentes, com

$$E(\mathbf{e}_i) = \mathbf{0}$$

e matriz de covariâncias comum

$$\text{Cov}(\mathbf{e}_i) = \Sigma.$$

Para a teoria exata usual, acrescenta-se

$$\mathbf{e}_i \sim N_p(\mathbf{0}, \Sigma). \quad (19.23)$$

Sob essas condições, o Módulo 2 estabeleceu as distribuições matriciais das SSCP utilizadas nos testes do modelo linear multivariado. Para distinguir os objetos aleatórios de suas realizações observadas $\mathbf{H}$ e $\mathbf{E}$, denote as SSCP aleatórias por

$$\mathbf{H}$$

e

$$\mathbf{E}_{\text{res}}.$$

Na formulação sobre as p respostas originais, sob H_0 ,

$$\mathbf{H} \mid \mathbf{Z} \sim W_p(g, \Sigma),$$

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(\nu_E, \Sigma),$$

e

$$\mathbf{H} \perp \mathbf{E}_{\text{res}} \mid \mathbf{Z},$$

em que g é o número de restrições paramétricas independentes da hipótese e ν_E são os graus de liberdade residuais. Esses resultados foram estabelecidos em Proposição 12.12 e Proposição 12.10.

A igualdade da matriz de escala Σ e a independência entre as duas SSCP fornecem a base probabilística dos critérios clássicos sob a hipótese nula.

Neste capítulo não serão rederivadas as distribuições exatas ou as aproximações F e χ^2 associadas aos quatro critérios. A formulação da técnica requer identificar:

- quais matrizes são comparadas;
- quais raízes resumem essa comparação;
- como cada critério agrega as raízes;
- quais pressupostos permitem interpretar o resultado como teste inferencial.

19.7.1 Papel da covariância residual comum

A matriz

$$\Sigma$$

define a estrutura de variabilidade conjunta dos erros.

Na comparação entre grupos, assumir a mesma matriz de covariâncias significa que a dispersão residual é descrita por uma única geometria para todas as condições.

Essa hipótese permite reunir a variação residual em uma única matriz $\mathbf{E}$ e utilizar essa matriz como referência comum para medir os efeitos contidos em $\mathbf{H}$.

Se diferentes grupos apresentam matrizes de covariâncias populacionais distintas, uma única matriz residual agregada deixa de representar exatamente a geometria de todos eles. A formulação clássica e sua distribuição nula precisam então ser reavaliadas.

O estudo de testes heterocedásticos, procedimentos robustos ou métodos por permutação não pertence à formulação desenvolvida aqui.

19.7.2 Lambda de Wilks e razão de verossimilhanças

Entre os quatro critérios, a lambda de Wilks possui uma ligação direta com a razão de verossimilhanças no modelo normal multivariado.

No Módulo 2 foi obtido

$$\Lambda_W = \frac{|\mathbf{E}_F|}{|\mathbf{E}_R|} = \frac{|\mathbf{E}_F|}{|\mathbf{E}_F + \mathbf{H}|}.$$

A razão correspondente aparece na formulação da razão de verossimilhanças dos modelos normais encaixados em Equação 12.66.

Na MANOVA, a matriz residual do modelo completo desempenha o papel de $\mathbf{E}$, enquanto a passagem ao modelo restrito acrescenta a parcela correspondente à hipótese:

$$\mathbf{E}_R = \mathbf{E} + \mathbf{H}.$$

Logo,

$$\Lambda_W = \frac{|\mathbf{E}|}{|\mathbf{E} + \mathbf{H}|}.$$

A formulação por determinantes e a formulação pelas raízes em Equação 19.17 são, portanto, duas representações do mesmo critério.

A primeira evidencia sua origem na comparação de modelos encaixados. A segunda evidencia sua relação com as direções de hipótese versus erro.

19.8 Casos particulares

A formulação matricial deve recuperar procedimentos já conhecidos quando a dimensão ou a estrutura da hipótese é reduzida.

19.8.1 Uma única resposta

Considere

$$p = 1.$$

Nesse caso,

$$\mathbf{H} = (H)$$

e

$$\mathbf{E} = (E)$$

são escalares não negativos.

Existe no máximo uma raiz não nula,

$$\lambda = \frac{H}{E}. \quad (19.24)$$

Os quatro critérios tornam-se

$$\Lambda_W = \frac{1}{1 + \lambda},$$

$$V = \frac{\lambda}{1 + \lambda},$$

$$U = \lambda$$

e

$$\Theta_R = \lambda.$$

Todos são funções monotônicas da mesma razão

$$\frac{H}{E}.$$

A estatística usual da ANOVA utiliza as médias quadráticas,

$$F = \frac{H/\nu_H}{E/\nu_E} = \frac{\nu_E}{\nu_H} \lambda, \quad (19.25)$$

em que ν_H e ν_E são, respectivamente, os graus de liberdade da hipótese e do erro.

Assim, quando existe uma única resposta, os quatro critérios multivariados contêm a mesma informação da comparação univariada entre hipótese e erro.

A MANOVA recupera a ANOVA como caso particular, mas a formulação multivariada acrescenta o problema de determinar várias direções quando

$$p > 1.$$

19.8.2 Duas populações

Considere agora a comparação de dois vetores de médias,

$$H_0 : \mu_1 = \mu_2.$$

Há somente um contraste independente entre os dois grupos. Consequentemente,

$$\text{rank}(\mathbf{H}) \leq 1,$$

e existe no máximo uma raiz característica positiva,

$$\lambda_1.$$

Nessa situação,

$$\Lambda_W = \frac{1}{1 + \lambda_1},$$

$$V = \frac{\lambda_1}{1 + \lambda_1},$$

$$U = \lambda_1$$

e

$$\Theta_R = \lambda_1.$$

Os quatro critérios são novamente funções monotônicas de uma única quantidade.

Na comparação clássica de duas populações normais com matriz de covariâncias comum, essa estrutura corresponde ao problema inferencial formulado pelo T^2 de Hotelling, já desenvolvido no Módulo 2.

A relação mostra que o T^2 não é um procedimento isolado da MANOVA. Ele representa o caso em que a hipótese de grupos possui somente uma direção independente de comparação.

Se

$$\mathbf{d} = \bar{\mathbf{y}}_1 - \bar{\mathbf{y}}_2$$

e

$$\mathbf{S}_p$$

é a matriz de covariâncias combinada dentro dos grupos, então

$$\mathbf{E} = (n_1 + n_2 - 2)\mathbf{S}_p$$

e

$$\mathbf{H} = \frac{n_1 n_2}{n_1 + n_2} \mathbf{d} \mathbf{d}^\top.$$

Como $\mathbf{H}$ possui posto no máximo 1, a única raiz potencialmente positiva é

$$\lambda_1 = \frac{n_1 n_2}{n_1 + n_2} \mathbf{d}^\top \mathbf{E}^{-1} \mathbf{d}.$$

A estatística de Hotelling para duas amostras independentes é

$$T^2 = \frac{n_1 n_2}{n_1 + n_2} \mathbf{d}^\top \mathbf{S}_p^{-1} \mathbf{d}.$$

Consequentemente,

$$\lambda_1 = \frac{T^2}{n_1 + n_2 - 2}. \quad (19.26)$$

A direção correspondente é proporcional a

$$\mathbf{E}^{-1} (\bar{\mathbf{y}}_1 - \bar{\mathbf{y}}_2).$$

Com três ou mais grupos, ou com hipóteses de posto superior a 1, várias raízes podem ser positivas. É nesse ponto que as diferentes formas de agregação utilizadas por Wilks, Pillai, Hotelling–Lawley e Roy passam a distinguir-se efetivamente.

19.9 Geometria da MANOVA

A equação generalizada

$$\mathbf{H}\mathbf{a} = \lambda \mathbf{E}\mathbf{a}$$

mostra que a geometria da MANOVA é definida relativamente à variabilidade residual.

Uma forma equivalente de formular o problema consiste em impor a normalização

$$\mathbf{a}^\top \mathbf{E}\mathbf{a} = 1 \quad (19.27)$$

e maximizar

$$\mathbf{a}^\top \mathbf{H}\mathbf{a}.$$

Sob essa restrição, uma direção com valor elevado de

$$\mathbf{a}^\top \mathbf{H} \mathbf{a}$$

é uma combinação das respostas em que o efeito associado à hipótese é grande depois que sua variabilidade residual foi fixada.

Para um autovetor generalizado normalizado por Equação 19.27,

$$\mathbf{H} \mathbf{a}_j = \lambda_j \mathbf{E} \mathbf{a}_j,$$

tem-se

$$\mathbf{a}_j^\top \mathbf{H} \mathbf{a}_j = \lambda_j \mathbf{a}_j^\top \mathbf{E} \mathbf{a}_j = \lambda_j. \quad (19.28)$$

Assim, cada raiz característica pode ser interpretada como a magnitude da hipótese na correspondente direção quando a variabilidade residual dessa combinação foi normalizada para 1.

19.9.1 Geometria após padronização pelo erro

A transformação introduzida em Equação 19.13 permite visualizar essa geometria com maior clareza.

Defina

$$\mathbf{z} = \mathbf{E}^{1/2} \mathbf{a}.$$

Então,

$$\mathbf{a}^\top \mathbf{E} \mathbf{a} = \mathbf{z}^\top \mathbf{z}.$$

Portanto, a restrição

$$\mathbf{a}^\top \mathbf{E} \mathbf{a} = 1$$

transforma-se em

$$\mathbf{z}^\top \mathbf{z} = 1.$$

O elipsoide determinado pela métrica residual é convertido na esfera unitária.

Ao mesmo tempo,

$$\mathbf{a}^\top \mathbf{H} \mathbf{a} = \mathbf{z}^\top \mathbf{K}_{\text{HE}} \mathbf{z},$$

em que

$$\mathbf{K}_{\text{HE}} = \mathbf{E}^{-1/2} \mathbf{H} \mathbf{E}^{-1/2}.$$

O problema da MANOVA torna-se, nesse espaço,

$$\max_{\mathbf{z}^\top \mathbf{z} = 1} \mathbf{z}^\top \mathbf{K}_{\text{HE}} \mathbf{z}. \quad (19.29)$$

A geometria residual foi removida da restrição e incorporada à matriz

$$\mathbf{K}_{\text{HE}}.$$

O problema é então um problema espectral simétrico usual. A primeira direção corresponde ao maior autovalor de $\mathbf{K}_{\text{HE}}$, e as direções seguintes correspondem aos demais autovalores positivos.

Essa transformação mostra que a MANOVA não procura simplesmente direções de grande diferença entre grupos ou grande variação explicada. Ela procura direções em que essa diferença seja grande **relativamente à dispersão residual conjunta das respostas**.

19.10 Invariância a transformações lineares das respostas

Uma propriedade da formulação multivariada é que os critérios não dependem da escolha particular de uma base para representar o espaço das respostas.

Considere uma transformação linear não singular

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e a nova matriz de respostas

$$\mathbf{Y}^* = \mathbf{Y} \mathbf{A}. \quad (19.30)$$

As matrizes de hipótese e erro transformam-se por congruência:

$$\mathbf{H}^* = \mathbf{A}^\top \mathbf{H} \mathbf{A} \quad (19.31)$$

e

$$\mathbf{E}^* = \mathbf{A}^\top \mathbf{E} \mathbf{A}. \quad (19.32)$$

Proposição 19.1 (Invariância das raízes características). *Se $\mathbf{A}$ é não singular, os pares*

$$(\mathbf{H}, \mathbf{E})$$

e

$$(\mathbf{H}^*, \mathbf{E}^*)$$

possuem as mesmas raízes características.

Comprovação. As raízes generalizadas satisfazem

$$\det(\mathbf{H}^* - \lambda \mathbf{E}^*) = 0.$$

Utilizando Equação 19.31 e Equação 19.32,

$$\begin{aligned} \det[\mathbf{A}^\top (\mathbf{H} - \lambda \mathbf{E}) \mathbf{A}] &= \det(\mathbf{A}^\top) \det(\mathbf{H} - \lambda \mathbf{E}) \det(\mathbf{A}) \\ &= \det(\mathbf{A})^2 \det(\mathbf{H} - \lambda \mathbf{E}). \end{aligned}$$

Como

$$\det(\mathbf{A}) \neq 0,$$

os zeros das duas equações características são os mesmos. □

Como os quatro critérios clássicos são funções apenas das raízes

$$\lambda_1, \dots, \lambda_s,$$

eles também permanecem inalterados por transformações lineares não singulares das respostas, desde que a hipótese seja expressa na representação transformada correspondente.

Essa propriedade inclui, por exemplo, mudanças de unidade e mudanças invertíveis de coordenadas no espaço das respostas.

Os coeficientes das combinações lineares, entretanto, mudam com a representação. Se

$$\mathbf{a}_j$$

é uma direção no sistema original, a direção correspondente após Equação 19.30 é

$$\mathbf{a}_j^* = \mathbf{A}^{-1}\mathbf{a}_j.$$

As coordenadas dos vetores mudam, enquanto as raízes que quantificam a relação entre hipótese e erro permanecem as mesmas.

19.11 Existência, posto e identificação das direções

A formulação utilizada até aqui pressupôs

$$\mathbf{E} \succ \mathbf{0}.$$

Essa condição possui papel computacional e geométrico. Ela garante a existência de

$$\mathbf{E}^{-1}, \quad \mathbf{E}^{1/2} \quad \text{e} \quad \mathbf{E}^{-1/2},$$

e torna o denominador

$$\mathbf{a}^\top \mathbf{E} \mathbf{a}$$

estritamente positivo para toda direção não nula.

19.11.1 Posto da matriz de hipótese

Se a hipótese possui q direções independentes no espaço dos parâmetros, então

$$\text{rank}(\mathbf{H}) \leq \min(p, q). \quad (19.33)$$

Consequentemente, o número de raízes características positivas satisfaz

$$s \leq \min(p, q). \quad (19.34)$$

Na MANOVA de um fator com G grupos,

$$q = G - 1,$$

e recupera-se

$$s \leq \min(p, G - 1).$$

Portanto, o número de respostas não determina sozinho a dimensionalidade da hipótese. Uma hipótese de baixo posto produz poucas direções características mesmo quando p é grande.

19.11.2 Não singularidade da matriz de erro

Se

$$\nu_E$$

denota os graus de liberdade residuais, a matriz $\mathbf{E}$ possui posto no máximo

$$\min(p, \nu_E).$$

Assim, uma condição necessária para que $\mathbf{E}$ possa ser positiva definida é

$$\nu_E \geq p. \quad (19.35)$$

Sob o modelo normal clássico, com

$$\Sigma \succ \mathbf{0}$$

e

$$\mathbf{E} \sim W_p(\nu_E, \Sigma),$$

a condição

$$\nu_E \geq p$$

garante não singularidade quase certamente.

Quando

$$p > \nu_E,$$

a matriz residual é necessariamente singular. Nesse caso, a formulação clássica baseada em

$$\mathbf{E}^{-1}$$

e

$$\mathbf{E}^{-1/2}$$

não pode ser aplicada diretamente.

Regularização, pseudoinversas e métodos desenvolvidos especificamente para situações de alta dimensão modificam o problema original e suas distribuições de referência. Essas extensões pertencem ao tratamento metodológico posterior.

19.11.3 Estimabilidade da hipótese

Antes da comparação entre $\mathbf{H}$ e $\mathbf{E}$, a própria hipótese precisa estar identificada pelo delineamento.

No modelo

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E},$$

a condição de posto completo de $\mathbf{Z}$ garante a identificação usual de $\mathbf{B}$. Quando $\mathbf{Z}$ possui posto deficiente, a matriz de parâmetros não é única, mas funções estimáveis continuam podendo ser testadas.

Para

$$H_0 : \mathbf{CBM} = \Theta_0,$$

é necessário que

$$\mathbf{CB}$$

seja estimável. Nesse caso,

$$\mathbf{CBM}$$

também é estimável para uma matriz fixa $\mathbf{M}$, conforme o resultado desenvolvido no capítulo do modelo linear multivariado.

Assim, posto deficiente do delineamento não implica ausência automática de uma MANOVA. O objeto inferencial passa a ser a função estimável especificada pela hipótese, e não uma parametrização particular de $\mathbf{B}$.

19.11.4 Unicidade das direções

Os autovalores generalizados

$$\lambda_1, \dots, \lambda_s$$

são determinados pelo par

$$(\mathbf{H}, \mathbf{E}).$$

Os autovetores possuem as indeterminações usuais de problemas espectrais.

Se λ_j é simples, a direção correspondente é determinada apenas até multiplicação por um escalar não nulo. Utilizando a normalização

$$\mathbf{a}_j^\top \mathbf{E} \mathbf{a}_j = 1,$$

resta a indeterminação de sinal:

$$\mathbf{a}_j \quad \text{e} \quad -\mathbf{a}_j$$

descrevem a mesma direção.

Quando uma raiz possui multiplicidade maior que 1, os autovetores individuais dentro do subespaço correspondente não são únicos. Nesse caso, o objeto geometricamente identificado é o subespaço associado à raiz repetida.

Essa indeterminação não afeta os quatro critérios, pois eles dependem das raízes e não da orientação escolhida para os autovetores.

19.12 Pressupostos e limites

A MANOVA combina uma formulação algébrica com uma formulação probabilística. Algumas condições definem o objeto testado, outras permitem calcular a solução clássica e outras justificam as distribuições inferenciais.

19.12.1 Estrutura correta da média

O modelo pressupõe que

$$E(y) = \mathbf{ZB}.$$

A hipótese testada deve ser expressável como uma função estimável dos parâmetros desse modelo.

Uma especificação inadequada da estrutura de médias modifica tanto a matriz residual quanto a interpretação de $\mathbf{H}$.

19.12.2 Independência entre unidades

Na formulação clássica, as linhas da matriz de erros correspondentes a unidades distintas são independentes.

Dados longitudinais, medidas repetidas, unidades agrupadas ou outras estruturas de dependência exigem uma modelagem específica da covariância entre unidades. A MANOVA clássica descrita neste capítulo não representa automaticamente essas dependências.

19.12.3 Covariância residual comum

As respostas possuem uma matriz de covariâncias residual comum

$$\Sigma.$$

No problema de grupos, essa condição corresponde a utilizar a mesma estrutura de covariância dentro das diferentes populações.

A matriz $\mathbf{E}$ reúne então a informação residual sob uma única geometria comum.

19.12.4 Não singularidade da covariância

A formulação clássica considera

$$\Sigma \succ \mathbf{0}.$$

Isso exclui relações lineares exatas entre as respostas no modelo populacional.

Na amostra, a existência de uma matriz populacional não singular não garante, por si só, que $\mathbf{E}$ seja invertível. O número de graus de liberdade residuais e a estrutura observada dos dados também determinam seu posto.

19.12.5 Normalidade multivariada

A normalidade dos erros,

$$\mathbf{e}_i \sim N_p(\mathbf{0}, \Sigma),$$

não é necessária para calcular $\mathbf{H}$, $\mathbf{E}$, as raízes características ou os quatro critérios a partir de uma amostra.

Ela é necessária para a teoria exata clássica baseada nas distribuições Wishart e para as distribuições de referência derivadas dessa estrutura.

Portanto, deve-se distinguir:

- a **formulação algébrica** da MANOVA;
- a **interpretação inferencial clássica** dos critérios.

Procedimentos robustos, ajustes para heterogeneidade, reamostragem e testes por permutação constituem extensões do problema e serão tratados em etapas posteriores.

19.13 Relações com outras técnicas

19.13.1 ANOVA

A relação com a ANOVA aparece diretamente quando

$$p = 1.$$

Nesse caso, as matrizes de hipótese e erro tornam-se escalares e existe no máximo uma raiz característica. Os quatro critérios passam a ser transformações monotônicas da mesma razão entre variação atribuída à hipótese e variação residual.

A MANOVA preserva, portanto, a lógica da decomposição hipótese versus erro da ANOVA, substituindo somas de quadrados por matrizes de somas de quadrados e produtos cruzados.

19.13.2 Regressão multivariada

MANOVA e regressão multivariada utilizam o mesmo modelo

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E}.$$

A distinção não está na forma matemática do modelo, mas no tipo de hipótese e na interpretação dos termos de $\mathbf{Z}$.

Variáveis indicadoras e contrastes podem representar grupos e fatores. Variáveis quantitativas podem representar covariáveis ou preditores contínuos. Em ambos os casos, hipóteses da forma

$$\mathbf{CBM} = \Theta_0$$

podem ser avaliadas pela mesma estrutura de hipótese e erro.

A MANOVA é, nesse sentido, uma formulação inferencial do modelo linear multivariado para testar simultaneamente conjuntos de coeficientes ou combinações das respostas.

19.13.3 Análise Discriminante

No caso de grupos conhecidos, as matrizes utilizadas pela MANOVA possuem correspondentes diretos na formulação geométrica da Análise Discriminante.

A matriz de hipótese representa a dispersão associada às diferenças entre grupos, enquanto a matriz de erro representa a dispersão dentro dos grupos.

O problema

$$\mathbf{H}\mathbf{a} = \lambda\mathbf{E}\mathbf{a}$$

é, portanto, o mesmo problema espectral que aparecerá na formulação de Fisher para a Análise Discriminante.

A coincidência algébrica não implica igualdade de objetivos.

Na MANOVA, as raízes são utilizadas para construir um teste sobre uma hipótese envolvendo vetores de médias ou parâmetros do modelo.

Na Análise Discriminante, as mesmas estruturas de dispersão podem ser utilizadas para construir direções que separem grupos previamente definidos. A formulação probabilística acrescentará ainda outro problema: construir uma regra para classificar novas observações.

Essa distinção será central no próximo capítulo. A MANOVA utiliza a separação entre grupos como objeto de **inferência**; a Análise Discriminante a utilizará como objeto de **representação e classificação**.

19.14 Síntese

Na formulação sobre as respostas originais utilizada neste capítulo, a MANOVA é construída dentro do modelo linear multivariado

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E},$$

e testa hipóteses da forma

$$H_0 : \mathbf{C}\mathbf{B} = \Theta_0.$$

A formulação mais geral,

$$\mathbf{C}\mathbf{B}\mathbf{M} = \Theta_0,$$

já foi estabelecida no Módulo 2 e conduz à mesma estrutura quando aplicada às respostas transformadas por $\mathbf{M}$.

A hipótese produz uma matriz $\mathbf{H}$, enquanto a variabilidade residual é representada por $\mathbf{E}$. Para uma combinação linear das respostas determinada por $\mathbf{a}$, a comparação entre essas duas fontes é

$$\frac{\mathbf{a}^\top \mathbf{H} \mathbf{a}}{\mathbf{a}^\top \mathbf{E} \mathbf{a}}.$$

A otimização dessa razão conduz ao problema

$$\mathbf{H} \mathbf{a} = \lambda \mathbf{E} \mathbf{a}.$$

As raízes características

$$\lambda_1, \dots, \lambda_s$$

quantificam a intensidade da hipótese relativamente ao erro em direções sucessivas do espaço das respostas.

Os quatro critérios clássicos utilizam essa mesma coleção de raízes:

$$\Lambda_W = \prod_{j=1}^s \frac{1}{1 + \lambda_j},$$

$$V = \sum_{j=1}^s \frac{\lambda_j}{1 + \lambda_j},$$

$$U = \sum_{j=1}^s \lambda_j$$

e

$$\Theta_R = \lambda_1.$$

A transformação por

$$\mathbf{E}^{-1/2}$$

mostra que essas raízes são os autovalores da hipótese depois que a geometria residual foi padronizada. A solução é invariante a transformações lineares não singulares das respostas.

A formulação clássica requer que a hipótese seja estimável e, para a representação baseada em inversas, que $\mathbf{E}$ seja positiva definida. Normalidade, independência e covariância residual comum sustentam a teoria inferencial clássica dos critérios.

A MANOVA recupera a ANOVA quando existe uma única resposta e o T^2 de Hotelling quando a comparação entre grupos possui apenas uma direção independente. Sua ligação com a Análise Discriminante decorre do mesmo problema de autovalores generalizado, embora as duas técnicas tenham objetivos estatísticos distintos.

No próximo capítulo, as matrizes que aqui sustentaram o teste de diferenças entre grupos serão utilizadas para construir direções de separação e, em uma formulação probabilística complementar, regras de classificação.

20 Formulação da Análise Discriminante

A Análise Discriminante estuda problemas em que os grupos de interesse são previamente conhecidos e cada unidade é descrita por um vetor de características quantitativas. Seu objetivo pode assumir duas formas relacionadas: construir representações que evidenciem a separação entre os grupos ou estabelecer uma regra para classificar novas observações.

Esses dois objetivos conduzem a formulações complementares. Na formulação probabilística, as classes são descritas por distribuições condicionais e a classificação é construída como um problema de decisão. Na formulação geométrica de Fisher, procuram-se combinações lineares das variáveis que apresentem grande separação entre os grupos relativamente à dispersão existente dentro deles (Anderson, 2003; Johnson; Wichern, 2007; Rencher; Christensen, 2012).

A distinção entre essas formulações deve ser preservada. Uma direção que separa grupos conhecidos não constitui, por si só, uma regra de classificação, e uma regra de classificação não precisa ser obtida por uma projeção de Fisher. Sob determinadas condições, as duas construções apresentam relações matemáticas diretas.

Os elementos centrais do capítulo são sintetizados na Tabela 20.1.

Tabela 20.1: Formulações complementares da Análise Discriminante.

Formulação	Objeto de partida	Problema	Resultado
probabilística	densidades condicionais, probabilidades a priori e perdas	decidir a classe de uma nova observação	regra discriminante
normal com covariância comum	μ_g, Σ e π_g	comparar probabilidades posteriores	funções discriminantes lineares
normal com covariâncias distintas	μ_g, Σ_g e π_g	comparar probabilidades posteriores	funções discriminantes quadráticas
geométrica de Fisher	dispersões intragrupos e entre grupos	maximizar separação relativa	direções e coordenadas discriminantes

20.1 O problema de discriminação e classificação

Considere uma variável de classe

$$G \in \{1, \dots, G\}$$

e um vetor aleatório de características

$$\mathbf{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_p \end{pmatrix} \in \mathbb{R}^p.$$

Cada grupo g possui uma distribuição condicional para $\mathbf{X}$. Uma observação

$$\mathbf{x} \in \mathbb{R}^p$$

é, portanto, um ponto no espaço das características, enquanto seu rótulo informa a população à qual pertence.

Na etapa de construção da técnica, os rótulos das observações utilizadas para caracterizar os grupos são conhecidos. Essa informação distingue a Análise Discriminante de técnicas de agrupamento, nas quais a própria estrutura de grupos precisa ser construída a partir dos dados.

Há três problemas relacionados.

A **discriminação** procura identificar características ou combinações das variáveis que distingam os grupos.

A **representação discriminante** procura construir coordenadas de menor dimensão nas quais a separação entre grupos seja evidenciada.

A **classificação** procura definir uma regra

$$\psi : \mathbb{R}^p \rightarrow \{1, \dots, G\}.$$

que atribua uma nova observação $\mathbf{x}$ a uma das classes.

Neste capítulo, a avaliação preditiva de uma regra estimada não será confundida com sua formulação. Taxas de erro amostrais, validação cruzada e outros procedimentos de avaliação pertencem à etapa metodológica posterior.

20.2 Classificação como problema de decisão

A classificação pode ser formulada como um problema de decisão. Para cada observação

$$\mathbf{x} \in \mathbb{R}^p,$$

deve-se escolher uma ação

$$a \in \mathcal{A} = \{1, \dots, G\},$$

em que a ação $a = g$ corresponde a classificar a observação na classe g .

A construção da regra depende das distribuições condicionais das características, das probabilidades a priori das classes e das consequências atribuídas às possíveis decisões (Berger, 1985).

Definição 20.1 (Probabilidades a priori das classes). As **probabilidades a priori** são

$$\pi_g = P(G = g), \quad g = 1, \dots, G,$$

com

$$\pi_g > 0$$

e

$$\sum_{g=1}^G \pi_g = 1.$$

Elas representam a distribuição das classes antes da observação das características da nova unidade.

Denote por

$$f_g(\mathbf{x}) = f(\mathbf{x} \mid G = g)$$

a densidade condicional das características na classe g .

Pelo teorema de Bayes,

$$P(G = g | \mathbf{X} = \mathbf{x}) = \frac{\pi_g f_g(\mathbf{x})}{\sum_{h=1}^G \pi_h f_h(\mathbf{x})}. \quad (20.1)$$

A probabilidade posterior combina a ocorrência esperada da classe, representada por π_g , com a compatibilidade de $\mathbf{x}$ com sua distribuição condicional, representada por $f_g(\mathbf{x})$.

A classe de maior probabilidade posterior nem sempre representa a decisão mais adequada. Essa escolha também pode depender das consequências dos diferentes tipos de erro.

Definição 20.2 (Perda de classificação). Se a classe verdadeira é g e a decisão tomada é a , a **perda de classificação**

$$L(a, g) \geq 0$$

quantifica a consequência atribuída a essa decisão.

A diagonal

$$L(g, g)$$

corresponde às decisões corretas, enquanto os elementos

$$L(a, g), \quad a \neq g,$$

correspondem aos diferentes tipos de erro de classificação.

Condicionando na observação das características, as possíveis perdas são ponderadas pelas probabilidades posteriores das classes.

Definição 20.3 (Risco condicional de classificação). O **risco condicional** de atribuir a observação $\mathbf{x}$ à classe a é

$$R(a | \mathbf{x}) = \sum_{g=1}^G L(a, g) P(G = g | \mathbf{X} = \mathbf{x}). \quad (20.2)$$

A decisão de Bayes escolhe a ação de menor risco condicional.

Definição 20.4 (Regra de Bayes para classificação). A **regra de Bayes** atribui a observação $\mathbf{x}$ a uma classe pertencente ao conjunto

$$\psi_B(\mathbf{x}) \in \arg \min_{a \in \{1, \dots, G\}} R(a | \mathbf{x}). \quad (20.3)$$

A regra depende conjuntamente das distribuições condicionais, das probabilidades a priori e da função de perda.

Um caso particular é a perda zero-um,

$$L(a, g) = \begin{cases} 0, & a = g, \\ 1, & a \neq g. \end{cases} \quad (20.4)$$

Nesse caso,

$$\begin{aligned} R(a | \mathbf{x}) &= \sum_{g \neq a} P(G = g | \mathbf{X} = \mathbf{x}) \\ &= 1 - P(G = a | \mathbf{X} = \mathbf{x}). \end{aligned}$$

Minimizar o risco equivale, portanto, a maximizar a probabilidade posterior:

$$\psi_B(\mathbf{x}) \in \arg \max_{g \in \{1, \dots, G\}} P(G = g | \mathbf{X} = \mathbf{x}).$$

Como o denominador de Equação 20.1 é comum a todas as classes,

$$\psi_B(\mathbf{x}) \in \arg \max_{g \in \{1, \dots, G\}} \pi_g f_g(\mathbf{x}). \quad (20.5)$$

Quando as densidades são positivas, a comparação pode ser realizada equivalentemente por

$$\log \pi_g + \log f_g(\mathbf{x}), \quad (20.6)$$

pois o logaritmo preserva a ordenação dos valores positivos.

Com perdas assimétricas, a regra de maior posterior deixa de ser necessariamente ótima. A decisão permanece definida pela minimização de Equação 20.2. Assim, probabilidades a priori e custos pertencem ao problema de decisão e não modificam o critério geométrico de Fisher.

20.3 Discriminação linear sob normalidade

Considere agora o modelo

$$\mathbf{X} \mid G = g \sim N_p(\mu_g, \Sigma), \quad g = 1, \dots, G, \quad (20.7)$$

em que os grupos possuem vetores de médias próprios,

$$\mu_1, \dots, \mu_G,$$

mas compartilham a mesma matriz de covariâncias positiva definida,

$$\Sigma \succ \mathbf{0}.$$

O Capítulo sobre a distribuição normal multivariada já mostrou, em Equação 9.56, que a comparação entre duas log-densidades com covariância comum é uma função afim de $\mathbf{x}$. A formulação discriminante acrescenta a essa comparação as probabilidades a priori e transforma o resultado em uma regra de decisão.

Para a classe g , o logaritmo de

$$\pi_g f_g(\mathbf{x})$$

contém o termo

$$-\frac{1}{2}(\mathbf{x} - \mu_g)^\top \Sigma^{-1}(\mathbf{x} - \mu_g) + \log \pi_g,$$

além de termos que são comuns a todos os grupos.

Expandindo a forma quadrática,

$$\begin{aligned} & -\frac{1}{2}(\mathbf{x} - \mu_g)^\top \Sigma^{-1}(\mathbf{x} - \mu_g) \\ &= -\frac{1}{2}\mathbf{x}^\top \Sigma^{-1}\mathbf{x} + \mathbf{x}^\top \Sigma^{-1}\mu_g - \frac{1}{2}\mu_g^\top \Sigma^{-1}\mu_g. \end{aligned}$$

O primeiro termo,

$$-\frac{1}{2}\mathbf{x}^\top \Sigma^{-1}\mathbf{x},$$

não depende da classe. Ele pode ser retirado da comparação sem alterar a decisão.

Definição 20.5 (Função discriminante linear). Sob o modelo normal em Equação 20.7, a **função discriminante linear** da classe g é

$$\delta_g(\mathbf{x}) = \mathbf{x}^\top \Sigma^{-1} \mu_g - \frac{1}{2} \mu_g^\top \Sigma^{-1} \mu_g + \log \pi_g. \quad (20.8)$$

A regra discriminante linear classifica $\mathbf{x}$ na classe que apresenta maior valor de $\delta_g(\mathbf{x})$:

$$\psi_{\text{LDA}}(\mathbf{x}) = \arg \max_{g \in \{1, \dots, G\}} \delta_g(\mathbf{x}). \quad (20.9)$$

A sigla LDA, de *Linear Discriminant Analysis*, refere-se aqui à regra discriminante obtida sob normalidade e covariância comum.

O termo **linear** decorre da dependência de $\delta_g(\mathbf{x})$ em relação às componentes de $\mathbf{x}$. Os termos

$$-\frac{1}{2} \mu_g^\top \Sigma^{-1} \mu_g + \log \pi_g$$

dependem da classe, mas não da observação a ser classificada.

20.3.1 Fronteiras entre classes

Considere duas classes g e h . A fronteira de decisão é formada pelos pontos nos quais

$$\delta_g(\mathbf{x}) = \delta_h(\mathbf{x}).$$

Utilizando Equação 20.8,

$$\begin{aligned} 0 &= \mathbf{x}^\top \Sigma^{-1} (\mu_g - \mu_h) \\ &\quad - \frac{1}{2} (\mu_g^\top \Sigma^{-1} \mu_g - \mu_h^\top \Sigma^{-1} \mu_h) + \log \frac{\pi_g}{\pi_h}. \end{aligned} \quad (20.10)$$

A equação é afim em $\mathbf{x}$. Consequentemente, a fronteira entre duas classes é um hiperplano.

Seu vetor normal é proporcional a

$$\Sigma^{-1} (\mu_g - \mu_h). \quad (20.11)$$

A separação entre os centroides é, portanto, ajustada pela estrutura de variâncias e covariâncias comum às classes.

As probabilidades a priori modificam o termo independente da fronteira por meio de

$$\log \frac{\pi_g}{\pi_h}.$$

Assim, alterar as probabilidades a priori pode deslocar o hiperplano de decisão sem modificar sua orientação quando os demais parâmetros permanecem fixos.

20.3.2 Relação com a distância de Mahalanobis

A distância de Mahalanobis já foi definida em Definição 8.9. Para a classe g ,

$$d_M^2(\mathbf{x}, \mu_g; \Sigma) = (\mathbf{x} - \mu_g)^\top \Sigma^{-1} (\mathbf{x} - \mu_g).$$

A expressão que determina a regra de Bayes pode ser escrita como

$$-\frac{1}{2}d_M^2(\mathbf{x}, \mu_g; \Sigma) + \log \pi_g. \quad (20.12)$$

Portanto,

$$\psi_{\text{LDA}}(\mathbf{x}) = \arg \min_g \left\{ d_M^2(\mathbf{x}, \mu_g; \Sigma) - 2 \log \pi_g \right\}. \quad (20.13)$$

Se todas as classes possuem a mesma probabilidade a priori,

$$\pi_1 = \cdots = \pi_G,$$

o termo envolvendo π_g é comum a todas elas, e a regra reduz-se a

$$\psi_{\text{LDA}}(\mathbf{x}) = \arg \min_g d_M^2(\mathbf{x}, \mu_g; \Sigma). \quad (20.14)$$

Sob essas condições, classificar pela regra normal linear equivale a escolher o centroide de menor distância de Mahalanobis.

Essa equivalência conecta diretamente a regra discriminante à geometria já construída no Módulo II: a proximidade relevante não é a distância euclidiana aos centroides, mas a distância corrigida pelas variâncias, escalas e correlações representadas por Σ .

20.4 Discriminação quadrática

A estrutura linear depende da hipótese de que todos os grupos compartilham a mesma matriz de covariâncias.

Considere agora

$$\mathbf{X} \mid G = g \sim N_p(\mu_g, \Sigma_g), \quad (20.15)$$

com

$$\Sigma_g \succ \mathbf{0}, \quad g = 1, \dots, G.$$

O Capítulo da distribuição normal multivariada já mostrou em Equação 9.57 que, quando as matrizes de covariâncias diferem, os termos quadráticos em $\mathbf{x}$ não se cancelam.

Aplicando a regra de Bayes à população normal da classe g , os termos que dependem da classe são

$$-\frac{1}{2} \log |\Sigma_g| - \frac{1}{2} (\mathbf{x} - \mu_g)^\top \Sigma_g^{-1} (\mathbf{x} - \mu_g) + \log \pi_g.$$

Definição 20.6 (Função discriminante quadrática). Sob o modelo em Equação 20.15, a **função discriminante quadrática** da classe g é

$$\delta_g^Q(\mathbf{x}) = -\frac{1}{2} \log |\Sigma_g| - \frac{1}{2} (\mathbf{x} - \mu_g)^\top \Sigma_g^{-1} (\mathbf{x} - \mu_g) + \log \pi_g. \quad (20.16)$$

A regra discriminante quadrática é

$$\psi_{\text{QDA}}(\mathbf{x}) = \arg \max_{g \in \{1, \dots, G\}} \delta_g^Q(\mathbf{x}). \quad (20.17)$$

A sigla QDA, de *Quadratic Discriminant Analysis*, decorre da presença de formas quadráticas específicas de cada grupo.

Duas características da função possuem interpretações diferentes.

O termo

$$(\mathbf{x} - \mu_g)^\top \Sigma_g^{-1} (\mathbf{x} - \mu_g)$$

mede o afastamento da observação ao centro da classe segundo a geometria própria daquela população.

O termo

$$\log |\Sigma_g|$$

incorpora o volume associado à dispersão da classe. Duas populações podem produzir a mesma distância de Mahalanobis para determinado ponto e ainda assim receber escores diferentes porque suas concentrações espaciais são distintas.

20.4.1 Fronteiras quadráticas

Entre duas classes g e h , a fronteira satisfaz

$$\delta_g^Q(\mathbf{x}) = \delta_h^Q(\mathbf{x}).$$

Como

$$\Sigma_g^{-1} \neq \Sigma_h^{-1}$$

em geral, a diferença entre as duas funções contém um termo da forma

$$\mathbf{x}^\top (\Sigma_h^{-1} - \Sigma_g^{-1}) \mathbf{x}.$$

A fronteira deixa, portanto, de ser necessariamente um hiperplano e passa a pertencer, em geral, à família das superfícies quadráticas.

Se

$$\Sigma_1 = \dots = \Sigma_G = \Sigma,$$

os termos quadráticos e os log-determinantes comuns cancelam-se. A QDA reduz-se então à estrutura linear de Equação 20.8.

A Figura 9.3, construída no Módulo II, antecipa geometricamente essa diferença: covariância comum produz populações com mesma forma e orientação, enquanto covariâncias distintas permitem que cada classe possua geometria própria.

A consequência dessa diferença para a classificação é mostrada na Figura 20.1. No painel da LDA, as duas classes compartilham a mesma matriz de covariâncias e a igualdade entre as




Figura 20.1: Fronteiras de decisão para duas populações normais. As elipses delimitam regiões de concentração de 75%. Com covariância comum, a LDA produz uma fronteira linear; com covariâncias distintas, a QDA pode produzir uma fronteira quadrática.

funções discriminantes produz uma reta. No painel da QDA, cada classe possui sua própria matriz de covariâncias e a fronteira resultante é curva.

A linha que separa as classes no primeiro painel decorre do cancelamento dos termos quadráticos comuns às duas densidades. No segundo painel, esse cancelamento não ocorre porque $\Sigma_1 \neq \Sigma_2$. A diferença visual entre as fronteiras é, portanto, consequência direta das hipóteses probabilísticas que distinguem LDA e QDA.

20.5 O que as regras probabilísticas resolvem

As funções em Equação 20.8 e Equação 20.16 surgem de um problema de decisão. Seu objetivo é comparar classes para uma observação $\mathbf{x}$ e produzir uma regra de classificação.

A estrutura pode ser sintetizada na Tabela 20.2.

Tabela 20.2: Comparação entre as formulações discriminantes linear e quadrática sob normalidade.

Aspecto	LDA	QDA
modelo condicional	$N_p(\mu_g, \Sigma)$	$N_p(\mu_g, \Sigma_g)$

Aspecto	LDA	QDA
covariância	comum a todas as classes	específica de cada classe
função discriminante	afim em $\mathbf{x}$	quadrática em $\mathbf{x}$
fronteira entre duas classes	hiperplano	superfície quadrática em geral
geometria de distância	uma única métrica de Mahalanobis	uma métrica de Mahalanobis para cada classe
probabilidades a priori	entram por $\log \pi_g$	entram por $\log \pi_g$
resultado imediato	regra de classificação	regra de classificação

A construção probabilística não procura uma direção única que maximize a separação entre os grupos. Ela compara diretamente os modelos condicionais das classes no espaço original das características.

A formulação geométrica de Fisher parte de outro problema. Nela, os rótulos conhecidos são utilizados para decompor a dispersão dos dados em parcelas intragrupos e entre grupos e procurar combinações lineares que maximizem a separação relativa. Essa formulação retoma diretamente as matrizes de dispersão já desenvolvidas no Módulo II e o mesmo problema de autovalores generalizados utilizado no capítulo de MANOVA.

20.6 Formulação geométrica de Fisher

A formulação probabilística produz uma regra para decidir a classe de uma nova observação. A formulação de Fisher parte de outro objetivo: construir combinações lineares das características que evidenciem a separação entre grupos previamente conhecidos.

Considere uma amostra dividida em G grupos, com n_g observações no grupo g . As matrizes de dispersão intragrupos e entre grupos já foram definidas no Módulo II em Definição 8.14 e Definição 8.15:

$$\mathbf{T}_{\text{intra}} = \sum_{g=1}^G \sum_{i=1}^{n_g} (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g) (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g)^{\top}$$

e

$$\mathbf{T}_{\text{entre}} = \sum_{g=1}^G n_g (\bar{\mathbf{x}}_g - \bar{\mathbf{x}}) (\bar{\mathbf{x}}_g - \bar{\mathbf{x}})^{\top}.$$

O Módulo II também estabeleceu em Proposição 8.11 a decomposição

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}.$$

Esses resultados não precisam ser reconstruídos neste capítulo. A Análise Discriminante utiliza as duas parcelas da decomposição para definir um problema de projeção supervisionada.

20.6.1 Dispersão depois de uma projeção

Considere uma direção

$$\mathbf{a} \in \mathbb{R}^p, \quad \mathbf{a} \neq \mathbf{0},$$

e a combinação linear

$$Z = \mathbf{a}^\top \mathbf{X}. \quad (20.18)$$

Depois da projeção, a dispersão existente dentro dos grupos é

$$\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a}, \quad (20.19)$$

enquanto a dispersão entre os centroides projetados é

$$\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}. \quad (20.20)$$

A primeira quantidade será grande quando as observações permanecerem muito dispersas em torno de seus respectivos centroides depois da projeção. A segunda será grande quando os centroides dos grupos permanecerem afastados na direção escolhida.

Uma direção adequada para discriminação deve, portanto, produzir grande separação entre grupos relativamente à dispersão que permanece dentro deles.

Definição 20.7 (Critério de Fisher). Suponha que

$$\mathbf{T}_{\text{intra}} \succ \mathbf{0}.$$

O **critério de Fisher** para uma direção não nula $\mathbf{a}$ é

$$J_F(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}}{\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a}}. \quad (20.21)$$

O numerador mede separação entre grupos; o denominador mede dispersão interna. Assim, maximizar $J_F(\mathbf{a})$ não significa simplesmente procurar uma direção em que os centroides estejam afastados. A distância entre eles é avaliada relativamente à variabilidade observada na mesma direção.

Essa distinção separa Fisher da ACP. Na ACP, a direção é escolhida para explicar grande variabilidade da nuvem total. Em Fisher, a informação dos grupos entra explicitamente na função objetivo.

A Figura 20.2 compara duas projeções das mesmas observações. A primeira utiliza simplesmente a direção que une os centroides. A segunda incorpora a dispersão intragrupos por meio da direção de Fisher. Para tornar comparáveis as duas projeções, seus escores foram expressos relativamente ao desvio-padrão intragrupos.




Figura 20.2: Projeção das mesmas duas classes na direção que une os centroides e na direção de Fisher. A direção discriminante aumenta a separação entre os grupos relativamente à dispersão intragrupos.

Na direção que une os centroides, parte da diferença entre as médias é acompanhada por grande dispersão dentro das classes. A direção de Fisher modifica os pesos das características para reduzir essa sobreposição relativa. A figura representa diretamente o papel do denominador de Equação 20.21: uma separação entre centroides é mais informativa quando ocorre em uma direção de pequena dispersão intragrupos.

20.7 Direções discriminantes

O critério em Equação 20.21 é o quociente de Rayleigh generalizado definido em Definição 5.12, aplicado ao par

$$(\mathbf{T}_{\text{entre}}, \mathbf{T}_{\text{intra}}).$$

A teoria geral já desenvolvida no Módulo I fornece diretamente os extremos desse quociente. Assim, as direções estacionárias satisfazem

$$\mathbf{T}_{\text{entre}} \mathbf{a} = \lambda \mathbf{T}_{\text{intra}} \mathbf{a}. \quad (20.22)$$

A formulação conduz ao mesmo tipo de problema espectral utilizado no capítulo anterior para a MANOVA. A diferença está no uso das soluções: na MANOVA, as raízes são agregadas para testar uma hipótese; na formulação de Fisher, os autovetores são utilizados para construir direções de separação.

Definição 20.8 (Direções discriminantes de Fisher). Suponha

$$\mathbf{T}_{\text{entre}} \succeq \mathbf{0}$$

e

$$\mathbf{T}_{\text{intra}} \succ \mathbf{0}.$$

As **direções discriminantes de Fisher** são os autovetores generalizados

$$\mathbf{a}_1, \dots, \mathbf{a}_s$$

associados às raízes positivas

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_s > 0$$

do problema

$$\mathbf{T}_{\text{entre}} \mathbf{a}_j = \lambda_j \mathbf{T}_{\text{intra}} \mathbf{a}_j.$$

A primeira direção maximiza

$$J_F(\mathbf{a}),$$

e

$$J_F(\mathbf{a}_1) = \lambda_1.$$

As direções subsequentes representam separações adicionais entre os grupos. Pelo resultado de ortogonalidade para autovetores generalizados em Proposição 5.8, elas podem ser escolhidas de modo que

$$\mathbf{a}_j^\top \mathbf{T}_{\text{intra}} \mathbf{a}_\ell = 0, \quad j \neq \ell. \quad (20.23)$$

Essa é uma ortogonalidade definida pela dispersão intragrupos. Duas direções discriminantes não precisam ser ortogonais segundo o produto interno euclidiano usual.

Uma normalização conveniente é

$$\mathbf{a}_j^\top \mathbf{T}_{\text{intra}} \mathbf{a}_j = 1. \quad (20.24)$$

Sob essa normalização,

$$\mathbf{a}_j^\top \mathbf{T}_{\text{entre}} \mathbf{a}_j = \lambda_j. \quad (20.25)$$

Portanto, cada raiz λ_j quantifica a separação entre grupos presente na correspondente direção depois que a dispersão intragrupos nessa direção foi normalizada.

20.7.1 Número de direções discriminantes

O posto da matriz de dispersão entre grupos já foi delimitado no Módulo II:

$$\text{rank}(\mathbf{T}_{\text{entre}}) \leq \min(p, G - 1).$$

Quando

$$\mathbf{T}_{\text{intra}} \succ \mathbf{0},$$

o problema generalizado possui exatamente

$$s = \text{rank}(\mathbf{T}_{\text{entre}})$$

raízes positivas. Assim,

$$s \leq \min(p, G - 1). \quad (20.26)$$

O resultado possui uma consequência direta. Mesmo que a observação original tenha muitas características, a separação entre G grupos pode ser representada por no máximo

$$G - 1$$

direções discriminantes.

Para dois grupos,

$$G = 2,$$

existe no máximo uma direção discriminante.

Para três grupos, existem no máximo duas.

A redução dimensional produzida por Fisher depende conjuntamente da dimensão original p e da estrutura dos grupos, com limite máximo $\min(p, G - 1)$.

20.8 Coordenadas discriminantes

As direções

$$\mathbf{a}_1, \dots, \mathbf{a}_s$$

definem um novo sistema de coordenadas para representar as observações.

Definição 20.9 (Coordenadas discriminantes). A coordenada discriminante j de uma observação $\mathbf{x}$ é

$$z_j(\mathbf{x}) = \mathbf{a}_j^\top (\mathbf{x} - \bar{\mathbf{x}}), \quad j = 1, \dots, s. \quad (20.27)$$

O vetor de coordenadas discriminantes é

$$\mathbf{z}(\mathbf{x}) = \begin{pmatrix} z_1(\mathbf{x}) \\ \vdots \\ z_s(\mathbf{x}) \end{pmatrix}. \quad (20.28)$$

A centralização em torno de $\bar{\mathbf{x}}$ fixa a média global na origem da representação. O uso de

$$\mathbf{a}_j^\top \mathbf{x}$$

sem centralização produz as mesmas diferenças entre observações e entre centroides; altera apenas a origem das coordenadas.

O centróide discriminante do grupo g na dimensão j é

$$\bar{z}_{gj} = \mathbf{a}_j^\top (\bar{\mathbf{x}}_g - \bar{\mathbf{x}}). \quad (20.29)$$

Assim, a representação discriminante transforma a nuvem original em um espaço de dimensão

$$s \leq \min(p, G - 1),$$

construído especificamente para preservar direções de separação entre grupos.

Essa redução é supervisionada: alterar os rótulos dos grupos altera

$$\mathbf{T}_{\text{intra}}, \quad \mathbf{T}_{\text{entre}}$$

e, conseqüentemente, as próprias direções discriminantes.

A interpretação dos eixos deve considerar esse objetivo. Uma variável com coeficiente elevado em determinada direção participa da combinação que separa os grupos naquela dimensão, mas a magnitude isolada dos coeficientes depende da escala e da correlação entre as características. Procedimentos detalhados para interpretar coeficientes, correlações estruturais e contribuições das variáveis pertencem à etapa metodológica posterior.

A Figura 20.3 mostra a transformação de um conjunto com três características e três grupos. O primeiro painel apresenta apenas duas das características originais. O segundo utiliza as duas direções discriminantes disponíveis para esses grupos e incorpora informação das três características.

O primeiro painel utiliza apenas duas das três características e, por isso, não representa toda a informação disponível para distinguir os grupos. As coordenadas discriminantes utilizam combinações das três características e são escolhidas especificamente para aumentar a separação entre os centroides relativamente à dispersão intragrupos.




Figura 20.3: Representação de três grupos em duas características originais e nas duas coordenadas discriminantes de Fisher. As coordenadas são construídas especificamente para representar a separação entre os grupos.

A figura também evidencia uma diferença em relação à ACP: os novos eixos dependem dos rótulos dos grupos. Se os rótulos forem alterados, $\mathbf{T}_{\text{intra}}$, $\mathbf{T}_{\text{entre}}$ e as próprias coordenadas discriminantes também poderão mudar.

20.9 Geometria pela dispersão intragrupos

A formulação pode ser colocada na geometria euclidiana utilizando a mesma transformação empregada para problemas de autovalores generalizados.

Como

$$\mathbf{T}_{\text{intra}} \succ \mathbf{0},$$

defina

$$\mathbf{u} = \mathbf{T}_{\text{intra}}^{1/2} \mathbf{a}.$$

Então,

$$\mathbf{a} = \mathbf{T}_{\text{intra}}^{-1/2} \mathbf{u},$$

e o problema em Equação 20.22 transforma-se em

$$\mathbf{T}_{\text{intra}}^{-1/2} \mathbf{T}_{\text{entre}} \mathbf{T}_{\text{intra}}^{-1/2} \mathbf{u} = \lambda \mathbf{u}. \quad (20.30)$$

Defina

$$\mathbf{K}_F = \mathbf{T}_{\text{intra}}^{-1/2} \mathbf{T}_{\text{entre}} \mathbf{T}_{\text{intra}}^{-1/2}. \quad (20.31)$$

A matriz $\mathbf{K}_F$ é simétrica e semidefinida positiva. Seus autovalores positivos são as raízes discriminantes

$$\lambda_1, \dots, \lambda_s.$$

A transformação

$$\mathbf{T}_{\text{intra}}^{-1/2}$$

remove a anisotropia associada à dispersão dentro dos grupos. Nesse espaço, a comparação passa a ser realizada sobre a dispersão entre os centroides depois de padronizada pela geometria intragrupos.

A interpretação é análoga à utilizada na MANOVA: primeiro se incorpora a variabilidade residual ou intragrupos à métrica; depois se procura a estrutura de separação que permanece.

A coincidência não é acidental. Para a comparação simples entre grupos,

$$\mathbf{E} = \mathbf{T}_{\text{intra}}$$

e

$$\mathbf{H} = \mathbf{T}_{\text{entre}}. \quad (20.32)$$

Portanto, o problema espectral

$$\mathbf{H}\mathbf{a} = \lambda \mathbf{E}\mathbf{a}$$

da MANOVA e o problema

$$\mathbf{T}_{\text{entre}} \mathbf{a} = \lambda \mathbf{T}_{\text{intra}} \mathbf{a}$$

de Fisher possuem as mesmas raízes e os mesmos subespaços discriminantes quando representam o mesmo problema de grupos.

O que muda é o objetivo estatístico. Na MANOVA, as raízes sustentam critérios de inferência sobre diferenças entre os grupos. Em Fisher, os autovetores são utilizados para representar as direções nas quais essas diferenças aparecem.

20.10 O caso de dois grupos

Quando

$$G = 2,$$

a matriz de dispersão entre grupos possui posto no máximo 1. Logo, existe no máximo uma direção discriminante positiva.

Defina

$$\mathbf{d} = \bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2. \quad (20.33)$$

Para dois grupos,

$$\mathbf{T}_{\text{entre}} = \frac{n_1 n_2}{n_1 + n_2} \mathbf{d} \mathbf{d}^\top. \quad (20.34)$$

Substituindo em Equação 20.22,

$$\frac{n_1 n_2}{n_1 + n_2} \mathbf{d} \mathbf{d}^\top \mathbf{a} = \lambda \mathbf{T}_{\text{intra}} \mathbf{a}.$$

O lado esquerdo é proporcional a $\mathbf{d}$. Assim, para a raiz positiva,

$$\mathbf{T}_{\text{intra}} \mathbf{a}_1 \propto \mathbf{d},$$

e, se

$$\mathbf{T}_{\text{intra}} \succ \mathbf{0},$$

segue que

$$\mathbf{a}_1 \propto \mathbf{T}_{\text{intra}}^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2). \quad (20.35)$$

A direção não depende de uma normalização específica, pois multiplicar $\mathbf{a}_1$ por uma constante não altera o subespaço de projeção.

A expressão em Equação 20.35 mostra os dois componentes da solução:

$$\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2$$

fornece a direção bruta de separação entre os centroides, enquanto

$$\mathbf{T}_{\text{intra}}^{-1}$$

corrige essa separação de acordo com a variabilidade e as associações existentes dentro dos grupos.

20.11 Relação entre Fisher e a discriminação linear normal

A formulação probabilística e a formulação de Fisher partem de problemas diferentes, mas se relacionam diretamente em condições específicas.

Considere duas populações normais,

$$\mathbf{X} \mid G = g \sim N_p(\mu_g, \Sigma), \quad g = 1, 2,$$

com matriz de covariâncias comum.

Pela formulação probabilística, o vetor normal à fronteira linear em Equação 20.11 é

$$\Sigma^{-1}(\mu_1 - \mu_2). \quad (20.36)$$

Na formulação populacional de Fisher, a dispersão intragrupos é proporcional a

$$\Sigma,$$

e a dispersão entre grupos possui direção determinada por

$$\mu_1 - \mu_2.$$

Consequentemente, a direção populacional de Fisher satisfaz

$$\mathbf{a}_F \propto \Sigma^{-1} (\mu_1 - \mu_2). \quad (20.37)$$

As equações Equação 20.36 e Equação 20.37 mostram que, para dois grupos com covariância comum, a orientação da fronteira da regra normal linear e a direção de máxima separação de Fisher são determinadas pelo mesmo vetor.

Na amostra, a matriz de covariâncias agrupada dentro dos grupos satisfaz

$$\mathbf{S}_p = \frac{1}{n - G} \mathbf{T}_{\text{intra}}. \quad (20.38)$$

Como a multiplicação por um escalar positivo não altera a direção,

$$\mathbf{S}_p^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2) \propto \mathbf{T}_{\text{intra}}^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2).$$

Assim, o estimador da orientação da fronteira LDA coincide com a direção amostral de Fisher até um fator de escala.

Essa equivalência não torna as duas formulações idênticas.

A regra LDA utiliza ainda:

$$-\frac{1}{2} \mu_g^\top \Sigma^{-1} \mu_g$$

e

$$\log \pi_g$$

para determinar a posição da fronteira e, portanto, a decisão de classificação.

O critério de Fisher, por sua vez, utiliza apenas a separação relativa entre e dentro dos grupos para determinar uma direção.

Probabilidades a priori diferentes podem deslocar a fronteira LDA sem alterar a direção de Fisher. Da mesma forma, custos de classificação podem modificar a regra de decisão sem modificar o problema geométrico de maximização em Equação 20.21.

Para mais de dois grupos, Fisher produz um subespaço de dimensão

$$s \leq \min(p, G - 1),$$

enquanto a LDA compara diretamente as funções

$$\delta_1(\mathbf{x}), \dots, \delta_G(\mathbf{x})$$

para classificar uma nova observação.

A ligação entre as duas construções permanece na utilização da mesma estrutura de covariância intragrupos e das diferenças entre os centroides, mas projeção discriminante e regra de decisão continuam sendo objetos estatísticos distintos.

20.12 Existência e singularidade

As formulações desenvolvidas até aqui utilizam inversas de matrizes de dispersão ou covariância. A existência dessas inversas deve ser distinguida das hipóteses probabilísticas utilizadas para derivar as regras de classificação.

20.12.1 Formulação de Fisher

Na formulação clássica de Fisher foi assumido

$$\mathbf{T}_{\text{intra}} \succ \mathbf{0}.$$

Essa condição garante que

$$\mathbf{T}_{\text{intra}}^{-1}$$

e

$$\mathbf{T}_{\text{intra}}^{-1/2}$$

existam e que

$$\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a} > 0$$

para toda direção não nula.

A matriz intragrupos pode ser escrita como a soma das dispersões internas dos G grupos. Seu posto satisfaz

$$\text{rank}(\mathbf{T}_{\text{intra}}) \leq \min(p, n - G). \quad (20.39)$$

Portanto, uma condição necessária para sua não singularidade é

$$n - G \geq p. \quad (20.40)$$

Essa condição, porém, não é suficiente por si só. Também é necessário que não exista dependência linear exata que reduza o posto das observações centralizadas dentro dos grupos.

Quando

$$\mathbf{T}_{\text{intra}}$$

é singular, a formulação clássica baseada em sua inversa deixa de estar definida. Pseudo-inversas, redução preliminar de dimensão e regularização modificam o problema original e pertencem ao tratamento metodológico posterior.

20.12.2 Formulações LDA e QDA

Na formulação populacional da LDA foi assumido

$$\Sigma \succ \mathbf{0}.$$

Essa condição garante a existência da densidade normal usual em $\mathbb{R}^p$, da distância de Mahalanobis associada à covariância comum e da função discriminante em Equação 20.8.

Na aplicação amostral, a matriz de covariâncias comum é substituída por uma estimativa agrupada. Como

$$\mathbf{S}_p = \frac{1}{n - G} \mathbf{T}_{\text{intra}},$$

sua não singularidade está sujeita às mesmas limitações de posto da matriz intragrupos.

Na QDA, cada população possui sua própria matriz

$$\Sigma_g.$$

A formulação clássica requer

$$\Sigma_g \succ \mathbf{0}, \quad g = 1, \dots, G.$$

Quando essas matrizes são estimadas separadamente, cada grupo precisa fornecer informação suficiente para estimar uma matriz de covariâncias de posto completo. Para a covariância amostral usual do grupo g ,

$$\text{rank}(\mathbf{S}_g) \leq \min(p, n_g - 1),$$

de modo que

$$n_g - 1 \geq p \tag{20.41}$$

é uma condição necessária para a não singularidade de $\mathbf{S}_g$.

A QDA exige, portanto, mais informação por grupo do que a LDA para estimar as matrizes de covariâncias sem regularização.

20.12.3 Identificação das direções discriminantes

As direções de Fisher apresentam as indeterminações próprias do problema de autovalores generalizados.

Se λ_j é uma raiz simples e $\mathbf{a}_j$ satisfaz

$$\mathbf{T}_{\text{entre}} \mathbf{a}_j = \lambda_j \mathbf{T}_{\text{intra}} \mathbf{a}_j,$$

então qualquer múltiplo não nulo de $\mathbf{a}_j$ representa a mesma direção discriminante.

Com a normalização adotada em Equação 20.24,

$$\mathbf{a}_j^\top \mathbf{T}_{\text{intra}} \mathbf{a}_j = 1,$$

permanece a indeterminação de sinal:

$$\mathbf{a}_j \quad \text{e} \quad -\mathbf{a}_j$$

representam o mesmo eixo discriminante. A mudança de sinal altera apenas a orientação da coordenada

$$z_j(\mathbf{x}),$$

sem modificar a separação representada por esse eixo.

Quando uma raiz possui multiplicidade maior que 1, os autovetores individuais associados não são únicos. Diferentes bases ortogonais na métrica de $\mathbf{T}_{\text{intra}}$ podem representar o mesmo autoespaço.

Nesse caso, o objeto identificado é o **subespaço discriminante** associado à raiz repetida, e não uma orientação particular de seus eixos.

20.13 Pressupostos e limites

A Análise Discriminante reúne uma formulação geométrica e formulações probabilísticas. As condições associadas a essas construções não são as mesmas.

A Tabela 20.3 separa os principais requisitos.

Tabela 20.3: Condições associadas às formulações de Fisher, LDA e QDA.

Condição	Fisher geométrico	LDA normal	QDA normal
grupos previamente definidos	necessária	necessária	necessária
normalidade multivariada	não é necessária para definir o critério	utilizada na derivação probabilística	utilizada na derivação probabilística
covariância comum entre grupos	não é requisito do critério geométrico	assumida	não assumida
matriz de dispersão/covariância não singular	$\mathbf{T}_{\text{intra}} \succ \mathbf{0}$ na solução clássica	$\Sigma \succ \mathbf{0}$	$\Sigma_g \succ \mathbf{0}$ para cada grupo
probabilidades a priori	não participam do critério	participam da regra	participam da regra
função de perda	não participa do critério	pode alterar a decisão	pode alterar a decisão

20.13.1 Grupos previamente definidos

A Análise Discriminante utiliza rótulos conhecidos para caracterizar as populações.

Na formulação de Fisher, os rótulos determinam diretamente

$$\mathbf{T}_{\text{intra}}$$

e

$$\mathbf{T}_{\text{entre}}.$$

Na formulação probabilística, eles determinam quais observações são utilizadas para caracterizar cada distribuição condicional.

Assim, a interpretação da técnica depende do significado dos grupos previamente estabelecidos. A Análise Discriminante não fornece, por si só, evidência de que esses rótulos correspondam a classes naturais existentes na população.

20.13.2 Normalidade e estrutura de covariâncias

A normalidade multivariada não é necessária para calcular o critério de Fisher ou obter suas direções a partir das matrizes amostrais de dispersão.

Ela entra na derivação das regras LDA e QDA como regras de Bayes para populações normais.

Na LDA,

$$\Sigma_1 = \cdots = \Sigma_G = \Sigma.$$

Essa igualdade é a razão pela qual os termos quadráticos em $\mathbf{x}$ se cancelam e as fronteiras se tornam lineares.

Na QDA, cada grupo possui

$$\Sigma_g,$$

e os termos quadráticos permanecem na comparação.

Portanto, a diferença entre LDA e QDA decorre diretamente do modelo de covariâncias adotado. A forma algébrica da regra de classificação é consequência dessa estrutura.

20.13.3 Probabilidades a priori e perdas

As probabilidades

$$\pi_g$$

representam a informação disponível sobre a ocorrência das classes antes da observação de $\mathbf{x}$.

Como aparecem nas funções discriminantes por meio de

$$\log \pi_g,$$

elas participam da posição das fronteiras de decisão.

As perdas cumprem outro papel. Quando tipos diferentes de erro possuem consequências distintas, a decisão ótima é aquela que minimiza o risco condicional definido no Módulo II, e não necessariamente a classe de maior probabilidade posterior.

Probabilidades a priori e perdas pertencem, portanto, ao problema de **decisão**. Elas não alteram o critério geométrico de Fisher.

20.13.4 Sobreposição entre as populações

Uma regra de classificação não precisa produzir separação perfeita mesmo quando o modelo populacional e seus parâmetros são conhecidos.

Se duas densidades condicionais atribuem probabilidade positiva a uma mesma região do espaço,

$$f_g(\mathbf{x}) > 0$$

e

$$f_h(\mathbf{x}) > 0$$

podem ocorrer simultaneamente para os mesmos valores de $\mathbf{x}$.

Nessa região, a classe de origem de uma observação não é determinada unicamente por suas características. A regra de Bayes escolhe a decisão de menor risco esperado, mas pode ainda produzir erro.

A existência de erro de classificação não implica, por si só, falha da técnica. Parte desse erro pode decorrer da sobreposição inerente às distribuições das populações.

A avaliação empírica do desempenho de uma regra estimada, por meio de amostras de validação, validação cruzada ou outras estratégias, constitui um problema adicional e não será desenvolvida neste capítulo.

20.14 Relações com outras técnicas

20.14.1 MANOVA

A relação mais direta é com a MANOVA.

No caso de comparação entre grupos,

$$\mathbf{H} = \mathbf{T}_{\text{entre}}$$

e

$$\mathbf{E} = \mathbf{T}_{\text{intra}}.$$

Assim, os dois capítulos utilizam o mesmo problema de autovalores generalizados,

$$\mathbf{T}_{\text{entre}} \mathbf{a} = \lambda \mathbf{T}_{\text{intra}} \mathbf{a}.$$

A diferença está na função atribuída às soluções.

Na MANOVA, as raízes

$$\lambda_1, \dots, \lambda_s$$

são combinadas nos critérios de Wilks, Pillai, Hotelling–Lawley e Roy para avaliar uma hipótese sobre os grupos.

Na Análise Discriminante de Fisher, os autovetores

$$\mathbf{a}_1, \dots, \mathbf{a}_s$$

definem as direções usadas para representar a separação entre esses mesmos grupos.

A MANOVA formula um problema de **inferência sobre diferenças**. Fisher formula um problema de **projeção para separação**.

A formulação probabilística da Análise Discriminante acrescenta ainda um terceiro objeto que não é produzido pela MANOVA: uma regra para classificar novas observações.

20.14.2 Análise de Componentes Principais

ACP e Fisher constroem combinações lineares das variáveis, porém otimizam critérios diferentes.

Na ACP, uma primeira direção $\mathbf{v}$ é escolhida para maximizar a variância total projetada,

$$\mathbf{v}^\top \mathbf{S} \mathbf{v},$$

sob uma normalização apropriada.

Em Fisher, a direção é escolhida para maximizar

$$\frac{\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}}{\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a}}.$$

A ACP não utiliza rótulos de grupos para construir suas direções. Uma direção de grande variância total pode refletir variabilidade existente dentro dos grupos e produzir pouca separação entre seus centroides.

Fisher utiliza os rótulos explicitamente e procura direções nas quais a separação entre grupos seja grande relativamente à dispersão interna.

A distinção é sintetizada na Tabela 20.4.

Tabela 20.4: Diferença entre as projeções da ACP e de Fisher.

Aspecto	ACP	Fisher
informação sobre grupos	não utilizada	utilizada
critério	variância total	separação entre grupos relativa à dispersão intragrupos
tipo de redução	não supervisionada em relação aos grupos	supervisionada
dimensão máxima	determinada pelo posto da matriz de dados/covariâncias	no máximo $\min(p, G - 1)$
interpretação das direções	variabilidade	separação

20.14.3 Análise de Agrupamentos

Análise Discriminante e Análise de Agrupamentos podem utilizar distâncias, centroides e matrizes de dispersão, mas partem de informações diferentes.

Na Análise de Agrupamentos, os rótulos dos grupos não são conhecidos. O objetivo é construir uma partição ou outra representação da estrutura de grupos a partir das características observadas.

Na Análise Discriminante, os grupos já estão definidos e seus rótulos participam da construção da solução.

Essa diferença modifica o próprio problema estatístico:

- Agrupamentos utiliza as características para **construir grupos**;
- Discriminante utiliza grupos conhecidos para **caracterizar separações e construir regras de classificação**.

A proximidade entre as duas técnicas é, portanto, operacional e geométrica, mas não equivale a identidade de objetivos.

20.15 Síntese

A Análise Discriminante reúne dois problemas relacionados.

Na formulação probabilística, cada grupo é caracterizado por uma densidade condicional

$$f_g(\mathbf{x})$$

e uma probabilidade a priori

$$\pi_g.$$

Sob perdas iguais, a regra de Bayes escolhe a classe que maximiza

$$\pi_g f_g(\mathbf{x}).$$

Para populações normais com covariância comum, essa comparação conduz à função discriminante linear

$$\delta_g(\mathbf{x}) = \mathbf{x}^\top \Sigma^{-1} \mu_g - \frac{1}{2} \mu_g^\top \Sigma^{-1} \mu_g + \log \pi_g.$$

Com covariâncias específicas,

$$\Sigma_g,$$

a função discriminante torna-se quadrática.

Na formulação geométrica de Fisher, as dispersões intragrupos e entre grupos já desenvolvidas no Módulo II são combinadas no critério

$$J_F(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}}{\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a}}.$$

Sua maximização conduz ao problema

$$\mathbf{T}_{\text{entre}} \mathbf{a} = \lambda \mathbf{T}_{\text{intra}} \mathbf{a}.$$

Os autovetores generalizados definem as direções discriminantes, e o número de direções com separação não nula satisfaz

$$s \leq \min(p, G - 1).$$

Para dois grupos, a direção de Fisher é proporcional a

$$\mathbf{T}_{\text{intra}}^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2).$$

Sob normalidade e covariância comum, essa direção coincide, até escala, com a orientação determinada pela regra discriminante linear. A coincidência das direções não elimina a diferença entre os problemas: Fisher constrói uma projeção de separação, enquanto a formulação de Bayes constrói uma regra de decisão.

A conexão com a MANOVA decorre das mesmas matrizes de dispersão e do mesmo problema espectral. A conexão com a ACP decorre do uso de combinações lineares, embora os critérios de otimização sejam diferentes. A distinção em relação à Análise de Agrupamentos decorre do conhecimento prévio dos rótulos.

No próximo capítulo, o problema muda novamente. A Correlação Canônica também construirá combinações lineares, mas agora de dois blocos de variáveis, escolhidas para maximizar a associação entre eles.

21 Formulação da Correlação Canônica

A Correlação Canônica estuda a associação linear entre **dois blocos de variáveis quantitativas** observados sobre as mesmas unidades. Em vez de examinar separadamente todas as correlações entre variáveis dos dois conjuntos, a técnica procura combinações lineares de cada bloco cuja correlação seja a maior possível.

Considere dois vetores aleatórios,

$$\mathbf{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_p \end{pmatrix} \in \mathbb{R}^p$$

e

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_q \end{pmatrix} \in \mathbb{R}^q.$$

Os dois blocos desempenham papéis simétricos. A Correlação Canônica não exige que um deles seja previamente definido como conjunto de respostas e o outro como conjunto de preditores. Seu objetivo é identificar a estrutura de associação linear compartilhada pelos dois conjuntos (Anderson, 2003; Johnson; Wichern, 2007; Mardia; Kent; Taylor, 2024).

A técnica constrói pares de variáveis da forma

$$U_j = \mathbf{a}_j^\top (\mathbf{X} - \mu_X)$$

e

$$V_j = \mathbf{b}_j^\top (\mathbf{Y} - \mu_Y),$$

escolhendo os vetores de coeficientes para que

$$\text{Corr}(U_j, V_j)$$

seja grande. O primeiro par produz a maior correlação possível; os pares seguintes representam associações adicionais que não repetem as dimensões já obtidas.

A estrutura geral é resumida na Tabela 21.1.

Tabela 21.1: Elementos da formulação da Correlação Canônica.

Elemento	Objeto	Papel na Correlação Canônica
primeiro bloco	$\mathbf{X} \in \mathbb{R}^p$	conjunto de variáveis do primeiro domínio
segundo bloco	$\mathbf{Y} \in \mathbb{R}^q$	conjunto de variáveis do segundo domínio
associação entre blocos	Σ_{XY}	reúne as covariâncias cruzadas
combinação do primeiro bloco	$\mathbf{U} = \mathbf{a}^\top (\mathbf{X} - \mu_X)$	resume linearmente o primeiro bloco
combinação do segundo bloco	$\mathbf{V} = \mathbf{b}^\top (\mathbf{Y} - \mu_Y)$	resume linearmente o segundo bloco
função objetivo	$\text{Corr}(\mathbf{U}, \mathbf{V})$	mede a associação entre as duas combinações
solução matricial	SVD de uma covariância cruzada branqueada	determina correlações e direções canônicas
resultado	$\rho_1, \dots, \rho_s$	correlações canônicas ordenadas

21.1 O problema de associação entre dois blocos

Considere, por exemplo, um primeiro conjunto de características representado por

$$\mathbf{X} = (X_1, \dots, X_p)^\top$$

e um segundo conjunto representado por

$$\mathbf{Y} = (Y_1, \dots, Y_q)^\top.$$

Uma análise baseada somente nas correlações

$$\text{Corr}(X_h, Y_k), \quad h = 1, \dots, p, \quad k = 1, \dots, q,$$

descreve associações entre pares de variáveis. Entretanto, a relação entre os dois blocos pode estar distribuída simultaneamente por várias variáveis.

Uma combinação

$$U = a_1 X_1 + \cdots + a_p X_p$$

pode concentrar um padrão do primeiro bloco que se associa fortemente a outra combinação,

$$V = b_1 Y_1 + \cdots + b_q Y_q,$$

mesmo quando nenhuma correlação bivariada isolada resume adequadamente essa relação.

A questão estatística passa, portanto, a ser encontrar

$$\mathbf{a} \in \mathbb{R}^p$$

e

$$\mathbf{b} \in \mathbb{R}^q$$

que façam as duas combinações lineares apresentar a maior correlação possível.

Essa formulação diferencia a Correlação Canônica de outras técnicas baseadas em projeções. Na ACP, procura-se uma direção que maximize a variabilidade de um único bloco. Em Fisher, procura-se uma direção que maximize a separação entre grupos relativamente à dispersão intragrupos. Na Correlação Canônica, duas direções são escolhidas simultaneamente, uma em cada bloco, para maximizar a associação entre as combinações resultantes.

21.2 Estrutura de covariâncias em blocos

Sejam

$$E(\mathbf{X}) = \mu_X$$

e

$$E(\mathbf{Y}) = \mu_Y.$$

A matriz de covariâncias do vetor conjunto

$$\begin{pmatrix} \mathbf{X} \\ \mathbf{Y} \end{pmatrix}$$

pode ser particionada como

$$\Sigma = \begin{pmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{pmatrix}. \quad (21.1)$$

Os blocos diagonais,

$$\Sigma_{XX} = \text{Cov}(\mathbf{X})$$

e

$$\Sigma_{YY} = \text{Cov}(\mathbf{Y}),$$

descrevem as estruturas de variância e covariância internas de cada conjunto.

O bloco

$$\Sigma_{XY} = \text{Cov}(\mathbf{X}, \mathbf{Y})$$

é a matriz de covariâncias cruzadas já definida em Definição 8.3. Sua transposta satisfaz

$$\Sigma_{YX} = \Sigma_{XY}^{\top}.$$

A matriz Σ_{XY} contém a informação que conecta os dois blocos, mas sua interpretação depende das estruturas internas representadas por Σ_{XX} e Σ_{YY} . A Correlação Canônica irá separar essas duas funções: primeiro removerá a geometria interna de cada conjunto e depois analisará a associação que permanece entre eles.

21.2.1 Ausência de associação linear entre os blocos

O resultado estabelecido em Proposição 8.4 fornece, para quaisquer vetores

$$\mathbf{a} \in \mathbb{R}^p$$

e

$$\mathbf{b} \in \mathbb{R}^q,$$

a identidade

$$\text{Cov} \left[\mathbf{a}^\top (\mathbf{X} - \mu_X), \mathbf{b}^\top (\mathbf{Y} - \mu_Y) \right] = \mathbf{a}^\top \Sigma_{XY} \mathbf{b}. \quad (21.2)$$

Assim, se

$$\Sigma_{XY} = \mathbf{0}, \quad (21.3)$$

então

$$\text{Cov} (\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{Y}) = 0$$

para **todas** as combinações lineares dos dois blocos.

Nesse caso, nenhuma escolha de $\mathbf{a}$ e $\mathbf{b}$ produz associação linear diferente de zero.

A recíproca também vale: se todas as combinações lineares possuem covariância cruzada nula, então

$$\Sigma_{XY} = \mathbf{0}.$$

Portanto, a matriz de covariâncias cruzadas é o objeto populacional que concentra toda a associação linear entre os dois conjuntos.

Se o vetor conjunto é normal multivariado, o resultado já estabelecido em Proposição 9.7 implica ainda

$$\Sigma_{XY} = \mathbf{0} \iff \mathbf{X} \perp \mathbf{Y}. \quad (21.4)$$

Essa equivalência depende da normalidade conjunta. Fora desse modelo, covariância cruzada nula representa ausência de associação linear, mas não independência em geral.

21.3 Variáveis canônicas e função objetivo

Considere as combinações lineares centradas

$$\mathbf{U} = \mathbf{a}^\top (\mathbf{X} - \mu_X)$$

e

$$\mathbf{V} = \mathbf{b}^\top (\mathbf{Y} - \mu_Y). \quad (21.5)$$

Pela estrutura de covariâncias,

$$\text{Var}(\mathbf{U}) = \mathbf{a}^\top \Sigma_{XX} \mathbf{a}, \quad (21.6)$$

$$\text{Var}(\mathbf{V}) = \mathbf{b}^\top \Sigma_{YY} \mathbf{b} \quad (21.7)$$

e, utilizando Equação 21.2,

$$\text{Cov}(\mathbf{U}, \mathbf{V}) = \mathbf{a}^\top \Sigma_{XY} \mathbf{b}. \quad (21.8)$$

Logo,

$$\text{Corr}(\mathbf{U}, \mathbf{V}) = \frac{\mathbf{a}^\top \Sigma_{XY} \mathbf{b}}{\sqrt{\mathbf{a}^\top \Sigma_{XX} \mathbf{a}} \sqrt{\mathbf{b}^\top \Sigma_{YY} \mathbf{b}}}. \quad (21.9)$$

A expressão em Equação 21.9 é invariante à multiplicação de $\mathbf{a}$ ou $\mathbf{b}$ por constantes não nulas, exceto por uma eventual mudança de sinal. Portanto, os comprimentos dos vetores de coeficientes precisam ser fixados para identificar uma representação conveniente das direções.

A normalização natural é

$$\mathbf{a}^\top \Sigma_{XX} \mathbf{a} = 1 \quad (21.10)$$

e

$$\mathbf{b}^\top \Sigma_{YY} \mathbf{b} = 1. \quad (21.11)$$

Sob essas restrições,

$$\text{Var}(\mathbf{U}) = \text{Var}(\mathbf{V}) = 1$$

e a correlação reduz-se a

$$\text{Corr}(\mathbf{U}, \mathbf{V}) = \mathbf{a}^\top \Sigma_{XY} \mathbf{b}. \quad (21.12)$$

Definição 21.1 (Primeiro par canônico). Suponha

$$\Sigma_{XX} \succ \mathbf{0}$$

e

$$\Sigma_{YY} \succ \mathbf{0}.$$

O **primeiro par canônico** é formado pelas variáveis

$$\mathbf{U}_1 = \mathbf{a}_1^\top (\mathbf{X} - \mu_X)$$

e

$$\mathbf{V}_1 = \mathbf{b}_1^\top (\mathbf{Y} - \mu_Y),$$

em que $\mathbf{a}_1$ e $\mathbf{b}_1$ resolvem

$$\max_{\mathbf{a}, \mathbf{b}} \mathbf{a}^\top \Sigma_{XY} \mathbf{b} \quad (21.13)$$

sujeito a

$$\mathbf{a}^\top \Sigma_{XX} \mathbf{a} = 1$$

e

$$\mathbf{b}^\top \Sigma_{YY} \mathbf{b} = 1.$$

O valor máximo

$$\rho_1 = \text{Corr}(\mathbf{U}_1, \mathbf{V}_1)$$

é a **primeira correlação canônica**.

Como o sinal de um dos vetores pode ser invertido sem alterar as restrições, o primeiro par pode ser orientado de forma que

$$\rho_1 \geq 0.$$

O problema possui, portanto, uma estrutura diferente dos quocientes de Rayleigh utilizados na MANOVA e na Análise Discriminante. Aqui existem **dois vetores de coeficientes**, um para cada bloco, e o numerador é uma forma bilinear:

$$\mathbf{a}^\top \Sigma_{XY} \mathbf{b}.$$

Essa diferença explica por que a decomposição em valores singulares será a formulação mais natural da solução.

21.4 Da normalização ao branqueamento

As restrições

$$\mathbf{a}^\top \Sigma_{XX} \mathbf{a} = 1$$

e

$$\mathbf{b}^\top \Sigma_{YY} \mathbf{b} = 1$$

mostram que as direções dos dois blocos são medidas segundo métricas diferentes.

No primeiro bloco, o comprimento relevante é determinado por

$$\Sigma_{XX},$$

enquanto no segundo é determinado por

$$\Sigma_{YY}.$$

A solução torna-se mais transparente quando essas duas geometrias são transformadas em geometria euclidiana.

Como

$$\Sigma_{XX} \succ \mathbf{0}$$

e

$$\Sigma_{YY} \succ \mathbf{0},$$

a raiz quadrada principal definida em Definição 5.9 é não singular para cada uma dessas matrizes. Portanto,

$$\Sigma_{XX}^{-1/2}$$

e

$$\Sigma_{YY}^{-1/2}$$

existem.

Defina

$$\mathbf{u} = \Sigma_{XX}^{1/2} \mathbf{a} \tag{21.14}$$

e

$$\mathbf{v} = \Sigma_{YY}^{1/2} \mathbf{b}. \tag{21.15}$$

Então,

$$\mathbf{a} = \Sigma_{XX}^{-1/2} \mathbf{u}$$

e

$$\mathbf{b} = \Sigma_{YY}^{-1/2} \mathbf{v}.$$

As restrições tornam-se

$$\mathbf{u}^\top \mathbf{u} = 1$$

e

$$\mathbf{v}^\top \mathbf{v} = 1. \quad (21.16)$$

Ao substituir essas expressões em Equação 21.12, obtém-se

$$\text{Corr}(\mathbf{U}, \mathbf{V}) = \mathbf{u}^\top \left(\Sigma_{XX}^{-1/2} \Sigma_{XY} \Sigma_{YY}^{-1/2} \right) \mathbf{v}. \quad (21.17)$$

A matriz

$$\Sigma_{XX}^{-1/2} \Sigma_{XY} \Sigma_{YY}^{-1/2}$$

será o objeto utilizado na solução. Ela representa a associação cruzada depois que a estrutura de covariâncias interna de cada bloco foi incorporada à transformação.

No próximo passo, o problema canônico torna-se uma maximização bilinear entre vetores de norma unitária. A SVD fornece diretamente suas direções ótimas e mostra que as correlações canônicas são os valores singulares dessa matriz de associação branqueada.

21.5 Solução pela decomposição em valores singulares

A transformação obtida em Equação 21.17 reduz o problema canônico a

$$\max_{\mathbf{u}, \mathbf{v}} \mathbf{u}^\top \mathbf{K}_{\text{CCA}} \mathbf{v} \quad (21.18)$$

sujeito a

$$\mathbf{u}^\top \mathbf{u} = 1$$

e

$$\mathbf{v}^\top \mathbf{v} = 1,$$

em que

$$\mathbf{K}_{\text{CCA}} = \Sigma_{XX}^{-1/2} \Sigma_{XY} \Sigma_{YY}^{-1/2} \in \mathbb{R}^{p \times q}. \quad (21.19)$$

A matriz $\mathbf{K}_{\text{CCA}}$ é a covariância cruzada entre as versões branqueadas dos dois blocos. De fato, definindo

$$\mathbf{X}^* = \Sigma_{XX}^{-1/2} (\mathbf{X} - \mu_X) \quad (21.20)$$

e

$$\mathbf{Y}^* = \Sigma_{YY}^{-1/2} (\mathbf{Y} - \mu_Y), \quad (21.21)$$

obtém-se

$$\text{Cov}(\mathbf{X}^*) = \mathbf{I}_p,$$

$$\text{Cov}(\mathbf{Y}^*) = \mathbf{I}_q$$

e

$$\text{Cov}(\mathbf{X}^*, \mathbf{Y}^*) = \mathbf{K}_{\text{CCA}}. \quad (21.22)$$

Assim, as estruturas internas de variâncias e covariâncias foram removidas de cada conjunto. O problema passa a depender somente da associação linear que permanece entre os dois blocos branqueados.

Seja

$$r = \min(p, q).$$

Pela SVD completa definida em Definição 6.3, a matriz

$$\mathbf{K}_{\text{CCA}} \in \mathbb{R}^{p \times q}$$

possui r valores singulares, contando também aqueles que podem ser nulos. Retendo os vetores singulares associados às r posições da diagonal retangular, escreva

$$\mathbf{K}_{\text{CCA}} = \mathbf{L} \mathbf{D}_\rho \mathbf{R}^\top, \quad (21.23)$$

em que

$$\mathbf{L} = (\mathbf{l}_1 \quad \cdots \quad \mathbf{l}_r) \in \mathbb{R}^{p \times r},$$

$$\mathbf{R} = (\mathbf{r}_1 \quad \cdots \quad \mathbf{r}_r) \in \mathbb{R}^{q \times r},$$

e

$$\mathbf{D}_\rho = \text{diag}(\rho_1, \dots, \rho_r) \in \mathbb{R}^{r \times r},$$

com

$$\rho_1 \geq \rho_2 \geq \cdots \geq \rho_r \geq 0. \quad (21.24)$$

Os vetores singulares satisfazem

$$\mathbf{L}^\top \mathbf{L} = \mathbf{I}_r$$

e

$$\mathbf{R}^\top \mathbf{R} = \mathbf{I}_r.$$

Além disso,

$$\mathbf{K}_{\text{CCA}} \mathbf{r}_j = \rho_j \mathbf{l}_j \quad (21.25)$$

e

$$\mathbf{K}_{\text{CCA}}^\top \mathbf{l}_j = \rho_j \mathbf{r}_j. \quad (21.26)$$

A caracterização variacional da SVD mostra que

$$\max_{\|\mathbf{u}\|=\|\mathbf{v}\|=1} \mathbf{u}^\top \mathbf{K}_{\text{CCA}} \mathbf{v} = \rho_1,$$

e o máximo é atingido por

$$\mathbf{u}_1 = \mathbf{l}_1, \quad \mathbf{v}_1 = \mathbf{r}_1.$$

Consequentemente, o primeiro par de coeficientes canônicos é

$$\mathbf{a}_1 = \Sigma_{XX}^{-1/2} \mathbf{l}_1 \quad (21.27)$$

e

$$\mathbf{b}_1 = \Sigma_{YY}^{-1/2} \mathbf{r}_1. \quad (21.28)$$

A correlação entre as variáveis correspondentes é

$$\text{Corr}(\mathbf{U}_1, \mathbf{V}_1) = \rho_1.$$

Como se trata de uma correlação,

$$0 \leq \rho_1 \leq 1.$$

A mesma construção aplicada aos demais pares de vetores singulares produz as correlações canônicas sucessivas.

Definição 21.2 (Correlações canônicas). As **correlações canônicas** entre os blocos $\mathbf{X}$ e $\mathbf{Y}$ são os valores singulares

$$\rho_1 \geq \cdots \geq \rho_r \geq 0$$

da matriz de covariância cruzada branqueada

$$\mathbf{K}_{\text{CCA}} = \Sigma_{XX}^{-1/2} \Sigma_{XY} \Sigma_{YY}^{-1/2}.$$

A correlação ρ_j corresponde ao par de combinações lineares determinado pelos vetores singulares $\mathbf{l}_j$ e $\mathbf{r}_j$.

A definição mostra que as correlações canônicas não são correlações escolhidas entre pares das variáveis originais. Elas medem a associação entre combinações dos dois blocos depois que as estruturas internas de covariância foram incorporadas à geometria de cada conjunto.

21.6 Pares canônicos sucessivos

Para

$$j = 1, \dots, r,$$

defina

$$\mathbf{a}_j = \Sigma_{XX}^{-1/2} \mathbf{l}_j \quad (21.29)$$

e

$$\mathbf{b}_j = \Sigma_{YY}^{-1/2} \mathbf{r}_j. \quad (21.30)$$

As variáveis canônicas correspondentes são

$$\mathbf{U}_j = \mathbf{a}_j^\top (\mathbf{X} - \mu_X)$$

e

$$\mathbf{V}_j = \mathbf{b}_j^\top (\mathbf{Y} - \mu_Y). \quad (21.31)$$

A ortogonalidade dos vetores singulares produz diretamente a estrutura de covariâncias das variáveis canônicas.

Para dois índices j e ℓ ,

$$\begin{aligned} \text{Cov}(\mathbf{U}_j, \mathbf{U}_\ell) &= \mathbf{a}_j^\top \Sigma_{XX} \mathbf{a}_\ell \\ &= \mathbf{l}_j^\top \mathbf{l}_\ell. \end{aligned}$$

Portanto,

$$\text{Cov}(\mathbf{U}_j, \mathbf{U}_\ell) = \begin{cases} 1, & j = \ell, \\ 0, & j \neq \ell. \end{cases} \quad (21.32)$$

Analogamente,

$$\text{Cov}(\mathbf{V}_j, \mathbf{V}_\ell) = \begin{cases} 1, & j = \ell, \\ 0, & j \neq \ell. \end{cases} \quad (21.33)$$

Entre variáveis pertencentes aos dois blocos,

$$\begin{aligned}\text{Cov}(\mathbf{U}_j, \mathbf{V}_\ell) &= \mathbf{I}_j^\top \mathbf{K}_{\text{CCA}} \mathbf{r}_\ell \\ &= \rho_\ell \mathbf{I}_j^\top \mathbf{1}_\ell,\end{aligned}$$

e, portanto,

$$\text{Cov}(\mathbf{U}_j, \mathbf{V}_\ell) = \begin{cases} \rho_j, & j = \ell, \\ 0, & j \neq \ell. \end{cases} \quad (21.34)$$

Se

$$\mathbf{U} = \begin{pmatrix} \mathbf{U}_1 \\ \vdots \\ \mathbf{U}_r \end{pmatrix}$$

e

$$\mathbf{V} = \begin{pmatrix} \mathbf{V}_1 \\ \vdots \\ \mathbf{V}_r \end{pmatrix},$$

essas propriedades podem ser reunidas como

$$\text{Cov}(\mathbf{U}) = \mathbf{I}_r, \quad (21.35)$$

$$\text{Cov}(\mathbf{V}) = \mathbf{I}_r \quad (21.36)$$

e

$$\text{Cov}(\mathbf{U}, \mathbf{V}) = \mathbf{D}_\rho. \quad (21.37)$$

A transformação canônica produz, portanto, pares ordenados de variáveis unitariamente padronizadas. Dentro de cada bloco, as variáveis canônicas são não correlacionadas; entre os dois blocos, cada $\mathbf{U}_j$ possui correlação não nula apenas com a variável $\mathbf{V}_j$ correspondente.

Esse resultado fornece a interpretação dos pares sucessivos. O primeiro par representa a associação linear máxima entre os blocos. O segundo representa a maior associação adicional possível depois de excluídas as direções utilizadas pelo primeiro par, e assim sucessivamente.

21.6.1 Número de correlações canônicas positivas

Como

$$\Sigma_{XX}^{-1/2}$$

e

$$\Sigma_{YY}^{-1/2}$$

são não singulares,

$$\text{rank}(\mathbf{K}_{\text{CCA}}) = \text{rank}(\Sigma_{XY}). \quad (21.38)$$

Defina

$$s = \text{rank}(\Sigma_{XY}).$$

Então,

$$s \leq \min(p, q) = r. \quad (21.39)$$

Exatamente s valores singulares são positivos:

$$\rho_1 \geq \dots \geq \rho_s > 0,$$

enquanto

$$\rho_{s+1} = \dots = \rho_r = 0$$

quando

$$s < r.$$

Assim, o número de dimensões de associação linear entre os dois blocos é determinado pelo posto da covariância cruzada.

Se

$$\Sigma_{XY} = \mathbf{0},$$

então

$$s = 0$$

e todas as correlações canônicas são nulas.

No extremo oposto, uma correlação canônica igual a 1 indica a existência de combinações lineares unitariamente padronizadas dos dois blocos com associação linear perfeita.

21.7 Formulação equivalente por autovalores

A SVD fornece a formulação mais direta porque o problema envolve simultaneamente dois vetores de coeficientes. Entretanto, a solução também pode ser expressa por problemas de autovalores.

Das relações singulares,

$$\mathbf{K}_{CCA} \mathbf{r}_j = \rho_j \mathbf{l}_j$$

e

$$\mathbf{K}_{CCA}^\top \mathbf{l}_j = \rho_j \mathbf{r}_j,$$

segue que

$$\mathbf{K}_{CCA} \mathbf{K}_{CCA}^\top \mathbf{l}_j = \rho_j^2 \mathbf{l}_j \tag{21.40}$$

e

$$\mathbf{K}_{CCA}^\top \mathbf{K}_{CCA} \mathbf{r}_j = \rho_j^2 \mathbf{r}_j. \tag{21.41}$$

Substituindo Equação 21.19 no primeiro problema,

$$\Sigma_{XX}^{-1/2} \Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{YX} \Sigma_{XX}^{-1/2} \mathbf{l}_j = \rho_j^2 \mathbf{l}_j.$$

Como

$$\mathbf{l}_j = \Sigma_{XX}^{1/2} \mathbf{a}_j,$$

obtém-se

$$\Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{YX} \mathbf{a}_j = \rho_j^2 \Sigma_{XX} \mathbf{a}_j. \quad (21.42)$$

Analogamente,

$$\Sigma_{YX} \Sigma_{XX}^{-1} \Sigma_{XY} \mathbf{b}_j = \rho_j^2 \Sigma_{YY} \mathbf{b}_j. \quad (21.43)$$

As quantidades

$$\rho_j^2$$

são, portanto, autovalores generalizados dos pares matriciais correspondentes.

As equações Equação 21.42 e Equação 21.43 não representam dois conjuntos independentes de soluções. Os coeficientes de cada par estão conectados por

$$\Sigma_{XY} \mathbf{b}_j = \rho_j \Sigma_{XX} \mathbf{a}_j \quad (21.44)$$

e

$$\Sigma_{YX} \mathbf{a}_j = \rho_j \Sigma_{YY} \mathbf{b}_j. \quad (21.45)$$

Para

$$\rho_j > 0,$$

uma direção de um bloco determina a correspondente direção do outro.

A formulação por autovalores conecta a Correlação Canônica aos problemas espectrais já utilizados em MANOVA e Análise Discriminante. A diferença permanece na origem do problema: em CCA, os autovalores surgem depois de eliminar um dos dois vetores de uma maximização bilinear, e seus valores são os **quadrados** das correlações canônicas.

21.8 Geometria da Correlação Canônica

A interpretação geométrica pode ser formulada sem identificar diretamente $\mathbb{R}^p$ e $\mathbb{R}^q$, que podem possuir dimensões diferentes.

Considere o espaço das variáveis aleatórias centradas com variância finita e produto interno

$$\langle \mathbf{A}, \mathbf{B} \rangle = \text{Cov}(\mathbf{A}, \mathbf{B}). \quad (21.46)$$

Para variáveis centradas,

$$\|\mathbf{A}\|^2 = \text{Var}(\mathbf{A}).$$

Defina o subespaço gerado pelas combinações lineares do primeiro bloco,

$$\mathcal{H}_X = \text{span} \{ \mathbf{X}_1 - E(\mathbf{X}_1), \dots, \mathbf{X}_p - E(\mathbf{X}_p) \},$$

e, analogamente,

$$\mathcal{H}_Y = \text{span} \{ \mathbf{Y}_1 - E(\mathbf{Y}_1), \dots, \mathbf{Y}_q - E(\mathbf{Y}_q) \}.$$

Uma variável canônica $\mathbf{U}$ pertence a $\mathcal{H}_X$, enquanto $\mathbf{V}$ pertence a $\mathcal{H}_Y$.

Sob as normalizações

$$\text{Var}(\mathbf{U}) = \text{Var}(\mathbf{V}) = 1,$$

tem-se

$$\text{Corr}(\mathbf{U}, \mathbf{V}) = \langle \mathbf{U}, \mathbf{V} \rangle.$$

O primeiro problema canônico pode então ser escrito como

$$\rho_1 = \max_{\substack{\mathbf{U} \in \mathcal{H}_X, \|\mathbf{U}\|=1 \\ \mathbf{V} \in \mathcal{H}_Y, \|\mathbf{V}\|=1}} \langle \mathbf{U}, \mathbf{V} \rangle. \quad (21.47)$$

Essa é precisamente a construção do menor ângulo entre dois subespaços.

Se

$$\theta_1$$

é o primeiro ângulo principal entre $\mathcal{H}_X$ e $\mathcal{H}_Y$, então

$$\rho_1 = \cos \theta_1. \quad (21.48)$$

Os pares sucessivos produzem os demais ângulos principais:

$$\rho_j = \cos \theta_j, \quad j = 1, \dots, r, \quad (21.49)$$

com

$$0 \leq \theta_1 \leq \theta_2 \leq \dots \leq \theta_r \leq \frac{\pi}{2}.$$

Como o cosseno decresce nesse intervalo,

$$\rho_1 \geq \rho_2 \geq \dots \geq \rho_r.$$

A interpretação é direta:

- ρ_j próximo de 1 corresponde a um pequeno ângulo entre direções dos dois subespaços;
- ρ_j próximo de 0 corresponde a direções próximas da ortogonalidade;
- $\rho_j = 0$ indica ausência de associação linear naquela dimensão canônica.

Quando

$$\rho_j = 1,$$

o ângulo correspondente é zero e existe uma combinação linear de um bloco perfeitamente alinhada com uma combinação linear do outro bloco.

Essa geometria explica o papel do branqueamento. As matrizes

$$\Sigma_{XX}^{-1/2}$$

e

$$\Sigma_{YY}^{-1/2}$$

removem as métricas internas distintas dos dois conjuntos. A SVD de $\mathbf{K}_{\text{CCA}}$ identifica então as direções de maior alinhamento entre os espaços resultantes.

A Correlação Canônica pode, portanto, ser vista como uma análise dos ângulos entre os subespaços lineares gerados pelos dois blocos depois que suas estruturas internas de covariância são incorporadas à geometria.

21.9 Interpretação das variáveis canônicas

As correlações canônicas

$$\rho_1, \dots, \rho_s$$

quantificam a intensidade das associações lineares sucessivas entre os dois blocos. Para compreender quais variáveis originais participam dessas associações, é necessário distinguir os **coeficientes canônicos** das correlações entre as variáveis originais e as variáveis canônicas.

Para o par j ,

$$\mathbf{U}_j = \mathbf{a}_j^\top (\mathbf{X} - \mu_X)$$

e

$$\mathbf{V}_j = \mathbf{b}_j^\top (\mathbf{Y} - \mu_Y).$$

Os elementos de

$$\mathbf{a}_j$$

e

$$\mathbf{b}_j$$

são os **coeficientes canônicos**. Eles determinam como as variáveis de cada bloco são combinadas para formar $\mathbf{U}_j$ e $\mathbf{V}_j$.

Sua magnitude, entretanto, depende da escala das variáveis e da estrutura de dependência existente dentro de cada bloco. Variáveis fortemente correlacionadas podem distribuir entre si a informação necessária para formar uma mesma variável canônica. Por isso, a interpretação de um par canônico não deve se apoiar exclusivamente na magnitude dos coeficientes.

21.9.1 Cargas canônicas

Uma forma complementar de interpretação é examinar a correlação entre cada variável original e a variável canônica construída a partir de seu próprio bloco.

Definição 21.3 (Cargas canônicas). A **carga canônica** da variável X_h sobre a variável canônica U_j é

$$\ell_{hj}^{(X)} = \text{Corr}(X_h, U_j), \quad h = 1, \dots, p. \quad (21.50)$$

Analogamente, a carga da variável Y_k sobre V_j é

$$\ell_{kj}^{(Y)} = \text{Corr}(Y_k, V_j), \quad k = 1, \dots, q. \quad (21.51)$$

Como

$$\text{Var}(U_j) = \text{Var}(V_j) = 1,$$

as cargas do primeiro bloco podem ser escritas como

$$\ell_{hj}^{(X)} = \frac{[\Sigma_{XX} \mathbf{a}_j]_h}{\sqrt{[\Sigma_{XX}]_{hh}}}, \quad (21.52)$$

e, para o segundo bloco,

$$\ell_{kj}^{(Y)} = \frac{[\Sigma_{YY} \mathbf{b}_j]_k}{\sqrt{[\Sigma_{YY}]_{kk}}}. \quad (21.53)$$

As cargas descrevem a associação das variáveis originais com a dimensão canônica construída no próprio bloco. Uma carga de grande magnitude indica que a variável está fortemente associada à correspondente variável canônica.

Coefficientes e cargas respondem, portanto, a perguntas diferentes:

Tabela 21.2: Diferença entre coeficientes e cargas canônicas.

Quantidade	Pergunta respondida
coeficiente canônico	como a variável participa da construção da combinação linear?

Quantidade	Pergunta respondida
carga canônica	quanto a variável original está correlacionada com a combinação obtida?

21.9.2 Cargas cruzadas

Também é possível relacionar uma variável original diretamente à variável canônica construída no **outro bloco**.

Definição 21.4 (Cargas cruzadas). As **cargas cruzadas** do par j são

$$\ell_{hj}^{(X,V)} = \text{Corr}(\mathbf{X}_h, \mathbf{V}_j)$$

e

$$\ell_{kj}^{(Y,U)} = \text{Corr}(\mathbf{Y}_k, \mathbf{U}_j).$$

As relações entre os coeficientes canônicos obtidas em Equação 21.44 e Equação 21.45 implicam

$$\Sigma_{XY} \mathbf{b}_j = \rho_j \Sigma_{XX} \mathbf{a}_j.$$

Consequentemente,

$$\ell_{hj}^{(X,V)} = \rho_j \ell_{hj}^{(X)}. \quad (21.54)$$

De modo análogo,

$$\ell_{kj}^{(Y,U)} = \rho_j \ell_{kj}^{(Y)}. \quad (21.55)$$

As cargas cruzadas combinam, portanto, duas informações:

- a associação da variável original com sua própria dimensão canônica;
- a intensidade da associação entre as duas variáveis canônicas, representada por ρ_j .

Uma variável pode possuir carga elevada em seu próprio bloco e, ainda assim, carga cruzada moderada quando a correlação canônica do par não é elevada.

21.9.3 Associação bivariada e associação canônica

A Figura 21.1 ilustra por que a Correlação Canônica não se reduz ao exame das correlações cruzadas individuais. No exemplo, cada variável dos dois blocos compartilha parte de duas fontes de variação. Nenhum par isolado concentra toda a associação disponível, enquanto as combinações canônicas reúnem essas informações.




Figura 21.1: Comparação entre a maior correlação cruzada individual e a primeira correlação canônica. As combinações lineares podem reunir uma associação distribuída entre várias variáveis dos dois blocos.

O painel da esquerda utiliza o par de variáveis originais com maior correlação cruzada em módulo. O painel da direita utiliza as duas combinações que maximizam a correlação entre os blocos. O aumento da associação decorre da possibilidade de reunir simultaneamente informação distribuída por várias variáveis.

A Correlação Canônica não cria uma associação ausente nos dados. Ela identifica as combinações lineares em que a associação representada por Σ_{XY} se manifesta com maior intensidade relativamente às estruturas internas dos dois blocos.

21.10 Variância extraída e redundância

Uma correlação canônica elevada descreve forte associação entre

$$U_j$$

e

$$V_j.$$

Isso não significa automaticamente que essas duas variáveis canônicas representem grande parte das variáveis originais de seus respectivos blocos.

As cargas canônicas fornecem uma medida resumida dessa representação.

Para o primeiro bloco, defina

$$VE_{X,j} = \frac{1}{p} \sum_{h=1}^p \left(\ell_{hj}^{(X)} \right)^2. \quad (21.56)$$

Para o segundo,

$$VE_{Y,j} = \frac{1}{q} \sum_{k=1}^q \left(\ell_{kj}^{(Y)} \right)^2. \quad (21.57)$$

Essas quantidades representam a média das proporções de variância das variáveis padronizadas de cada bloco associadas à correspondente variável canônica.

Uma medida complementar pergunta quanto dessa representação também está associada ao outro bloco.

Como as cargas cruzadas satisfazem

$$\ell_{hj}^{(X,V)} = \rho_j \ell_{hj}^{(X)},$$

a média de seus quadrados é

$$\begin{aligned} Red_{X|Y,j} &= \frac{1}{p} \sum_{h=1}^p \left(\ell_{hj}^{(X,V)} \right)^2 \\ &= VE_{X,j} \rho_j^2. \end{aligned} \quad (21.58)$$

Analogamente,

$$Red_{Y|X,j} = VE_{Y,j} \rho_j^2. \quad (21.59)$$

Essas medidas são chamadas **índices de redundância**.

Elas distinguem dois aspectos:

- ρ_j^2 mede a intensidade da associação entre as duas variáveis canônicas;
- $VE_{X,j}$ e $VE_{Y,j}$ medem quanto as respectivas variáveis canônicas representam, em média, as variáveis padronizadas dos próprios blocos.

Por isso, uma correlação canônica elevada pode coexistir com redundância pequena. Isso ocorre quando duas combinações lineares estão fortemente correlacionadas, mas cada uma delas representa uma parcela pequena da variabilidade das variáveis originais de seu bloco.

Neste capítulo, variância extraída e redundância são utilizadas apenas como ferramentas conceituais de interpretação. Critérios operacionais para selecionar pares canônicos ou avaliar estabilidade pertencem à etapa metodológica posterior.

21.10.1 Correlação canônica e ângulo

A interpretação geométrica de Equação 21.49 é ilustrada na Figura 21.2. Depois que as estruturas internas dos dois blocos são incorporadas pelo branqueamento, as correlações canônicas podem ser interpretadas como cossenos de ângulos principais.




Figura 21.2: Interpretação geométrica de uma correlação canônica como cosseno de um ângulo principal. Correlações maiores correspondem a direções mais alinhadas entre os dois subespaços.

Cada painel representa, em um plano auxiliar, duas direções unitárias com o mesmo ângulo que o correspondente par de direções principais. Quando ρ_j aumenta, θ_j diminui e o alinhamento entre as duas dimensões canônicas torna-se maior.

A figura não identifica diretamente os espaços de coeficientes $\mathbb{R}^p$ e $\mathbb{R}^q$. O ângulo refere-se aos subespaços de variáveis aleatórias centradas definidos anteriormente, ou, na formulação amostral, aos subespaços correspondentes no espaço das observações.

21.11 Formulação amostral

A formulação populacional depende de

$$\Sigma_{XX}, \quad \Sigma_{XY}, \quad \Sigma_{YY}.$$

Em uma amostra de n unidades observadas simultaneamente nos dois blocos, sejam

$$\mathbf{X} \in \mathbb{R}^{n \times p}$$

e

$$\mathbf{Y} \in \mathbb{R}^{n \times q}$$

as matrizes observadas.

A matriz de covariâncias cruzadas amostral

$$\mathbf{S}_{XY}$$

já foi definida em Definição 10.16. Em conjunto com

$$\mathbf{S}_{XX}$$

e

$$\mathbf{S}_{YY},$$

ela produz a matriz de associação branqueada amostral

$$\widehat{\mathbf{K}}_{CCA} = \mathbf{S}_{XX}^{-1/2} \mathbf{S}_{XY} \mathbf{S}_{YY}^{-1/2}. \quad (21.60)$$

Quando

$$\mathbf{S}_{XX} \succ \mathbf{0}$$

e

$$\mathbf{S}_{YY} \succ \mathbf{0},$$

aplica-se a SVD

$$\widehat{\mathbf{K}}_{\text{CCA}} = \widehat{\mathbf{L}}\widehat{\mathbf{D}}_{\rho}\widehat{\mathbf{R}}^{\top}, \tag{21.61}$$

com

$$\widehat{\mathbf{D}}_{\rho} = \text{diag}\left(\widehat{\rho}_1, \ldots, \widehat{\rho}_r\right).$$

Os valores

$$\widehat{\rho}_j$$

são as correlações canônicas amostrais.

Os coeficientes estimados são

$$\widehat{\mathbf{a}}_j = \mathbf{S}_{XX}^{-1/2}\widehat{\mathbf{l}}_j \tag{21.62}$$

e

$$\widehat{\mathbf{b}}_j = \mathbf{S}_{YY}^{-1/2}\widehat{\mathbf{r}}_j. \tag{21.63}$$

Se

$$\mathbf{X}_c$$

e

$$\mathbf{Y}_c$$

são as matrizes centralizadas, os escores canônicos amostrais são

$$\hat{\mathbf{u}}_j = \mathbf{X}_c \hat{\mathbf{a}}_j \quad (21.64)$$

e

$$\hat{\mathbf{v}}_j = \mathbf{Y}_c \hat{\mathbf{b}}_j. \quad (21.65)$$

Cada vetor contém os escores das n unidades na correspondente dimensão canônica.

A solução amostral substitui, portanto, os momentos populacionais por suas estimativas e conserva a mesma estrutura matemática:

covariância em blocos branqueamento SVD pares canônicos.

As correlações amostrais estimam as correlações canônicas populacionais. Sua variabilidade amostral, seus vieses em pequenas amostras e os testes sobre sua significância pertencem à teoria inferencial posterior.

21.12 Invariância, existência e identificação

21.12.1 Invariância a transformações lineares não singulares

Uma característica estrutural da CCA é sua invariância a mudanças invertíveis de coordenadas realizadas separadamente dentro de cada bloco.

Considere

$$\mathbf{X}^\dagger = \mathbf{P}\mathbf{X}$$

e

$$\mathbf{Y}^\dagger = \mathbf{Q}\mathbf{Y},$$

em que

$$\mathbf{P} \in \mathbb{R}^{p \times p}$$

e

$$\mathbf{Q} \in \mathbb{R}^{q \times q}$$

são não singulares.

Proposição 21.1 (Invariância das correlações canônicas). *Transformações lineares não singulares realizadas separadamente em cada bloco preservam as correlações canônicas.*

Comprovação. Como $\mathbf{P}$ é não singular, toda combinação linear do bloco transformado pode ser escrita como

$$\mathbf{a}_{\dagger}^{\top} \mathbf{X}^{\dagger} = \mathbf{a}_{\dagger}^{\top} \mathbf{P} \mathbf{X}.$$

Para qualquer vetor $\mathbf{a}$ do sistema original, escolha

$$\mathbf{a}_{\dagger} = \mathbf{P}^{-\top} \mathbf{a}.$$

Então,

$$\mathbf{a}_{\dagger}^{\top} \mathbf{X}^{\dagger} = \mathbf{a}^{\top} \mathbf{X}.$$

Portanto, o conjunto de todas as combinações lineares possíveis do primeiro bloco é preservado pela transformação. O mesmo argumento vale para o segundo bloco usando

$$\mathbf{b}_{\dagger} = \mathbf{Q}^{-\top} \mathbf{b}.$$

Como o conjunto de pares de combinações possíveis permanece o mesmo, os máximos sucessivos de suas correlações também permanecem os mesmos. $\square$

Reescalonar uma ou mais variáveis por constantes não nulas é um caso particular dessa propriedade.

Consequentemente, realizar a CCA utilizando variáveis padronizadas não altera as correlações canônicas quando os desvios-padrão são positivos. O que muda são os coeficientes utilizados para expressar as variáveis canônicas na escala escolhida.

Se

$$\mathbf{a}_j$$

é um vetor de coeficientes no sistema original, no sistema transformado o vetor correspondente é

$$\mathbf{a}_j^{\dagger} = \mathbf{P}^{-\top} \mathbf{a}_j.$$

Assim, os valores

$$\rho_j$$

descrevem propriedades da associação entre os espaços lineares gerados pelos blocos, enquanto os coeficientes dependem da representação escolhida para esses espaços.

Essa distinção também explica por que coeficientes calculados com variáveis em unidades diferentes não devem ser comparados diretamente como medidas absolutas de importância.

21.12.2 Existência da solução clássica

A construção por branqueamento pressupõe

$$\Sigma_{XX} \succ \mathbf{0}$$

e

$$\Sigma_{YY} \succ \mathbf{0}.$$

Essas condições garantem a existência de

$$\Sigma_{XX}^{-1/2}$$

e

$$\Sigma_{YY}^{-1/2}.$$

Se uma combinação linear não nula das variáveis de um bloco possui variância zero, a correspondente matriz de covariâncias é singular e a formulação clássica deixa de estar definida nessa representação.

Na amostra,

$$\text{rank}(\mathbf{S}_{XX}) \leq \min(p, n-1) \quad (21.66)$$

e

$$\text{rank}(\mathbf{S}_{YY}) \leq \min(q, n-1). \quad (21.67)$$

Assim,

$$n - 1 \geq p$$

e

$$n - 1 \geq q \tag{21.68}$$

são condições necessárias para que as duas matrizes amostrais possam ter posto completo.

Essas desigualdades não são suficientes quando existem dependências lineares exatas entre as variáveis.

21.12.3 Multicolinearidade

Mesmo quando as matrizes são formalmente invertíveis, autovalores muito pequenos de

$$\mathbf{S}_{XX}$$

ou

$$\mathbf{S}_{YY}$$

tornam suas inversas e raízes inversas sensíveis a pequenas perturbações.

Nesse caso, os coeficientes

$$\hat{\mathbf{a}}_j$$

e

$$\hat{\mathbf{b}}_j$$

podem variar consideravelmente entre amostras próximas, ainda que as combinações canônicas resultantes sejam mais estáveis.

A formulação clássica desenvolvida neste capítulo pressupõe matrizes suficientemente bem condicionadas para que a solução espectral seja interpretável. Regularização, CCA esparsa e procedimentos específicos para alta dimensão modificam essa formulação e serão tratados em etapas metodológicas posteriores.

21.12.4 Identificação das direções canônicas

As correlações canônicas são determinadas pelos valores singulares de

$$\mathbf{K}_{\text{CCA}}.$$

As direções associadas apresentam as indeterminações usuais da SVD.

Se

$$\rho_j$$

é um valor singular positivo e simples, os vetores

$$\mathbf{l}_j$$

e

$$\mathbf{r}_j$$

podem ser substituídos simultaneamente por

$$-\mathbf{l}_j$$

e

$$-\mathbf{r}_j$$

sem alterar

$$\rho_j.$$

Consequentemente,

$$(\mathbf{a}_j, \mathbf{b}_j)$$

e

$$(-\mathbf{a}_j, -\mathbf{b}_j)$$

definem o mesmo par canônico, com orientação invertida nos dois eixos.

Quando um valor singular possui multiplicidade maior que 1, as direções individuais associadas não são únicas. Diferentes bases ortonormais podem representar o mesmo subespaço singular.

Nesse caso, o objeto identificado é o par de **subespaços canônicos** associado ao valor singular repetido, e não uma orientação particular de seus eixos.

21.13 Pressupostos e limites

A formulação da Correlação Canônica utiliza principalmente momentos de segunda ordem. Suas condições algébricas precisam ser distinguidas das condições utilizadas para inferência.

21.13.1 Existência de segundos momentos

As matrizes

$$\Sigma_{XX}, \quad \Sigma_{XY}, \quad \Sigma_{YY}$$

precisam existir.

A técnica descreve associações lineares representadas por essas covariâncias. Dependências não lineares que não se manifestam nos segundos momentos podem não ser capturadas pelas correlações canônicas.

21.13.2 Não singularidade dentro dos blocos

A solução clássica por branqueamento requer matrizes de covariâncias intrablocos positivas definidas.

Dependências lineares exatas reduzem a dimensão efetiva do bloco e impedem a utilização direta das inversas.

21.13.3 Normalidade

A normalidade multivariada conjunta não é necessária para definir

$$\rho_j, \quad \mathbf{a}_j \quad \text{e} \quad \mathbf{b}_j.$$

A formulação populacional depende das matrizes de covariâncias e, portanto, pode ser construída para distribuições não normais que possuam segundos momentos adequados.

A normalidade conjunta passa a desempenhar papel adicional quando se pretende realizar a inferência clássica sobre as correlações canônicas, testar a independência entre os blocos ou derivar distribuições de referência.

Esses procedimentos inferenciais não serão desenvolvidos neste capítulo.

21.13.4 Dimensão amostral

Quando p ou q se aproximam de n , as matrizes amostrais podem tornar-se mal condicionadas mesmo antes de perderem posto.

Há ainda uma consequência geométrica específica da Correlação Canônica. As colunas das matrizes centralizadas

$$\mathbf{X}_c$$

e

$$\mathbf{Y}_c$$

pertencem ao subespaço de $\mathbb{R}^n$ ortogonal a $\mathbf{1}_n$, cuja dimensão é $n - 1$.

Se $\mathbf{S}_{XX}$ e $\mathbf{S}_{YY}$ possuem posto completo, então

$$\dim [\text{Col}(\mathbf{X}_c)] = p$$

e

$$\dim [\text{Col}(\mathbf{Y}_c)] = q.$$

Quando

$$p + q > n - 1,$$

esses dois subespaços possuem necessariamente uma interseção não trivial. Consequentemente, existem combinações lineares dos dois blocos que produzem escores amostrais perfeitamente alinhados, resultando em uma ou mais correlações canônicas amostrais iguais a 1.

Assim, a invertibilidade separada de $\mathbf{S}_{XX}$ e $\mathbf{S}_{YY}$ não impede associações canônicas amostrais degeneradas quando a dimensão conjunta dos blocos é elevada.

Além da existência das inversas, a estimação de muitas covariâncias com uma amostra limitada aumenta a variabilidade da solução canônica.

Assim, a existência algébrica de uma solução amostral não garante que as direções estimadas sejam estáveis.

21.13.5 Observações influentes

Como a técnica é construída a partir de médias, variâncias e covariâncias, observações extremas podem modificar

$$\mathbf{S}_{XX}, \quad \mathbf{S}_{XY} \quad \text{e} \quad \mathbf{S}_{YY},$$

e, consequentemente, as correlações e os coeficientes canônicos.

Diagnóstico, análise de sensibilidade e procedimentos robustos pertencem à etapa aplicada posterior.

21.14 Relações com outras técnicas

21.14.1 Análise de Componentes Principais

ACP e Correlação Canônica constroem combinações lineares, mas seus objetivos são distintos.

Na ACP, uma direção é escolhida para maximizar a variância dentro de um único conjunto:

$$\max_{\|\mathbf{a}\|=1} \mathbf{a}^\top \Sigma \mathbf{a}.$$

Na Correlação Canônica, duas direções são escolhidas simultaneamente para maximizar

$$\text{Corr}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{Y}).$$

Assim:

Tabela 21.3: Diferenças estruturais entre ACP e Correlação Canônica.

Aspecto	ACP	Correlação Canônica
número de blocos	um	dois
função objetivo	variância	correlação entre combinações
informação utilizada	covariância interna	covariâncias internas e cruzadas
decomposição utilizada	autovalores ou SVD	SVD da covariância cruzada
resultado	componentes	branqueada pares canônicos

Uma direção de grande variância não precisa estar fortemente associada ao outro bloco. A CCA privilegia associação entre os conjuntos, mesmo que essa associação não ocorra nas direções de maior variância de cada bloco separadamente.

21.14.2 Regressão e regressão multivariada

A regressão distingue papéis entre preditores e respostas. A Correlação Canônica trata os dois blocos simetricamente.

Essa diferença aparece mesmo quando os mesmos dados são utilizados.

Na regressão multivariada, um bloco é modelado condicionalmente ao outro. Na CCA, procura-se um par de combinações cuja associação seja máxima, sem definir previamente uma direção causal ou preditiva.

Um caso particular evidencia a conexão.

Suponha que o segundo bloco tenha uma única variável,

$$q = 1,$$

e denote sua variância por

$$\sigma_Y^2.$$

Então existe no máximo uma correlação canônica positiva e

$$\rho_1^2 = \frac{\Sigma_{YX} \Sigma_{XX}^{-1} \Sigma_{XY}}{\sigma_Y^2}. \quad (21.69)$$

Essa quantidade é o coeficiente de determinação populacional da projeção linear de Y sobre o bloco $\mathbf{X}$.

Assim, a correlação múltipla aparece como caso particular da Correlação Canônica quando um dos blocos possui dimensão 1.

21.14.3 MANOVA

A relação com MANOVA decorre novamente de problemas espectrais envolvendo dois espaços.

No capítulo de MANOVA, as raízes características foram transformadas por

$$\theta_j = \frac{\lambda_j}{1 + \lambda_j},$$

conforme Equação 19.15.

Em problemas de comparação de grupos representados por um bloco adequado de indicadores ou contrastes, essas raízes transformadas podem ser interpretadas como correlações canônicas quadradas entre o espaço das respostas e o espaço associado ao efeito:

$$\rho_j^2 = \frac{\lambda_j}{1 + \lambda_j}. \quad (21.70)$$

A relação mostra duas representações de uma mesma estrutura de associação entre subespaços.

Na MANOVA, as raízes são utilizadas para testar hipóteses sobre efeitos.

Na Correlação Canônica, as mesmas associações podem ser interpretadas como alinhamentos entre combinações de dois blocos.

21.14.4 Análise Discriminante

Se um dos blocos representa grupos por meio de indicadores ou contrastes e o outro contém variáveis quantitativas, o problema canônico relaciona-se às direções discriminantes.

A matriz entre grupos introduzida na formulação de Fisher descreve justamente a parcela da variabilidade das respostas associada ao espaço definido pelos grupos.

Assim, MANOVA, Fisher e CCA podem compartilhar a mesma estrutura espectral em problemas de grupos, mas atribuem significados diferentes à solução:

Tabela 21.4: Diferentes interpretações de uma estrutura espectral compartilhada.

Técnica	Função da estrutura espectral
MANOVA	testar diferenças entre grupos
Fisher	construir direções de separação
CCA	quantificar associação entre o bloco quantitativo e o espaço que representa os grupos

A equivalência algébrica em situações particulares não elimina a diferença entre os problemas estatísticos formulados por cada técnica.

21.15 Síntese

A Correlação Canônica é formulada para dois blocos de variáveis,

$$\mathbf{X} \in \mathbb{R}^p$$

e

$$\mathbf{Y} \in \mathbb{R}^q,$$

cujas estrutura conjunta de segundos momentos é representada por

$$\Sigma = \begin{pmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{pmatrix}.$$

O objetivo é construir

$$\mathbf{U} = \mathbf{a}^\top (\mathbf{X} - \mu_X)$$

e

$$\mathbf{V} = \mathbf{b}^\top (\mathbf{Y} - \mu_Y)$$

com correlação máxima.

Sob as normalizações

$$\text{Var}(\mathbf{U}) = \text{Var}(\mathbf{V}) = 1,$$

o problema torna-se

$$\max_{\mathbf{a}, \mathbf{b}} \mathbf{a}^\top \Sigma_{XY} \mathbf{b}.$$

O branqueamento de cada bloco produz

$$\mathbf{K}_{\text{CCA}} = \Sigma_{XX}^{-1/2} \Sigma_{XY} \Sigma_{YY}^{-1/2}.$$

Sua decomposição em valores singulares,

$$\mathbf{K}_{\text{CCA}} = \mathbf{L} \mathbf{D}_\rho \mathbf{R}^\top,$$

fornece diretamente as correlações canônicas

$$\rho_1 \geq \dots \geq \rho_s > 0$$

e os coeficientes correspondentes,

$$\mathbf{a}_j = \Sigma_{XX}^{-1/2} \mathbf{l}_j,$$

$$\mathbf{b}_j = \Sigma_{YY}^{-1/2} \mathbf{r}_j.$$

O número de associações lineares não nulas é

$$s = \text{rank}(\Sigma_{XY}) \leq \min(p, q).$$

A mesma solução pode ser expressa por problemas de autovalores generalizados cujas raízes são

$$\rho_j^2.$$

Geometricamente,

$$\rho_j = \cos \theta_j,$$

em que θ_j é um ângulo principal entre os subespaços lineares gerados pelos dois blocos.

Os coeficientes canônicos determinam as combinações lineares. As cargas relacionam as variáveis originais às variáveis canônicas de seus próprios blocos, enquanto as cargas cruzadas relacionam uma variável à dimensão canônica do bloco oposto.

As medidas de redundância acrescentam uma distinção importante: uma correlação canônica elevada indica forte associação entre duas combinações, mas não garante que essas combinações representem grande parcela da variabilidade das variáveis originais.

Na amostra, as matrizes

$$\mathbf{S}_{XX}, \quad \mathbf{S}_{XY}, \quad \mathbf{S}_{YY}$$

substituem as covariâncias populacionais.

A solução clássica requer matrizes intrablocos não singulares. Multicolinearidade e alta dimensão podem tornar os coeficientes instáveis ou impedir diretamente o branqueamento.

A normalidade multivariada não é necessária para definir a técnica. Ela fornece condições adicionais para a inferência clássica sobre as correlações canônicas.

A CCA utiliza várias estruturas desenvolvidas anteriormente no livro: covariância cruzada, transformação por raízes quadradas inversas, SVD, problemas de autovalores, projeções e geometria de subespaços. Sua característica específica é combinar essas estruturas para responder a uma pergunta própria: **quais combinações lineares de dois conjuntos apresentam a maior associação possível?**

No próximo capítulo, o objeto estatístico deixa de ser a associação entre dois blocos de variáveis. A Análise Conjunta parte de alternativas descritas por atributos e procura decompor avaliações, preferências ou escolhas em contribuições associadas aos níveis desses atributos.

22 Formulação da Análise Conjunta

A Análise Conjunta estuda como avaliações, preferências ou escolhas referentes a alternativas podem ser relacionadas às características que descrevem essas alternativas. O problema parte de objetos apresentados como combinações de **atributos** e **níveis** e procura representar a contribuição de cada característica para a preferência global (Green; Rao, 1971; Green; Srinivasan, 1978).

Considere uma alternativa descrita por m atributos. O perfil i pode ser representado por

$$\mathbf{x}_i = \begin{pmatrix} x_{i1} \\ \vdots \\ x_{im} \end{pmatrix},$$

em que x_{ij} indica o nível assumido pelo atributo j no perfil i .

A informação observada sobre esse perfil pode assumir diferentes formas. Um participante pode atribuir uma avaliação quantitativa, ordenar várias alternativas, comparar dois perfis ou escolher uma alternativa entre várias disponíveis.

Embora essas respostas exijam formulações estatísticas diferentes, o objetivo comum é decompor a preferência associada a uma alternativa em contribuições atribuídas às características que a definem.

Na formulação clássica, essa decomposição é representada por uma função de utilidade. Cada nível de cada atributo recebe uma contribuição e a utilidade do perfil resulta da combinação dessas contribuições.

A estrutura da técnica pode ser resumida pela Tabela 22.1.

Tabela 22.1: Elementos da formulação da Análise Conjunta.

Elemento	Representação	Papel
alternativa ou perfil	$\mathbf{x}_i$	combinação específica dos níveis dos atributos
atributo	$j = 1, \dots, m$	dimensão utilizada para descrever a alternativa
nível	x_{ij}	valor ou categoria do atributo j no perfil i

Elemento	Representação	Papel
utilidade parcial	$u_j(x_{ij})$	contribuição do nível para a preferência
utilidade total	U_i	representação global da preferência pelo perfil
delineamento	$\mathbf{Z}$	representação matricial dos níveis presentes nos perfis
parâmetros	β	efeitos ou utilidades parciais associados à codificação
resultado	utilidades e contrastes	decomposição das preferências segundo atributos e níveis

A Análise Conjunta distingue-se das técnicas anteriores deste módulo pelo objeto matemático que ocupa a formulação principal. ACP, Correspondência e Correlação Canônica utilizam decomposições matriciais para encontrar direções. MANOVA e Análise Discriminante utilizam matrizes de dispersão e problemas de autovalores generalizados. Na Análise Conjunta, a estrutura principal é um **modelo para respostas de preferência construído a partir de uma matriz de delineamento**.

22.1 O problema da decomposição de preferências

Considere m atributos,

$$A_1, \dots, A_m,$$

em que o atributo A_j possui um conjunto de níveis

$$\mathcal{L}_j = \{\ell_{j1}, \dots, \ell_{jL_j}\}.$$

Uma alternativa corresponde a uma combinação

$$\mathbf{x}_i = (x_{i1}, \dots, x_{im})^\top \in \mathcal{L}_1 \times \dots \times \mathcal{L}_m. \quad (22.1)$$

Por exemplo, uma alternativa pode ser descrita por três atributos:

Tabela 22.2: Exemplo abstrato de atributos e níveis na formação de perfis.

Atributo	Níveis possíveis
A_1 : tipo	nível 1, nível 2
A_2 : tamanho	pequeno, médio, grande
A_3 : preço	baixo, intermediário, alto

Um perfil específico poderia ser formado por

$$\mathbf{x}_i = (\text{nível 2, médio, baixo})^\top.$$

A resposta dada a esse perfil é global: o participante avalia a alternativa como um todo. Entretanto, o interesse estatístico está em decompor essa avaliação para compreender como os atributos e seus níveis participaram da preferência observada.

Essa passagem distingue duas informações:

- **o perfil apresentado**, determinado pelos níveis dos atributos;
- **a resposta ao perfil**, que contém informação sobre a preferência.

O perfil constitui a estrutura explicativa. A resposta fornece a informação utilizada para estimar como essa estrutura se relaciona à preferência.

22.1.1 Atributos, níveis e perfis

Um **atributo** representa uma dimensão utilizada para diferenciar alternativas. Seus **níveis** são os valores ou categorias considerados no estudo.

Um **perfil** é uma combinação específica de níveis, contendo exatamente um nível de cada atributo.

Definição 22.1 (Perfil). Se os atributos são $A_1, \dots, A_m$, um **perfil** é um elemento do produto cartesiano

$$\mathcal{L}_1 \times \dots \times \mathcal{L}_m.$$

Cada perfil especifica um nível para cada atributo.

Se todos os perfis possíveis forem considerados, o número total de combinações é

$$N_{\text{perf}} = \prod_{j=1}^m L_j. \quad (22.2)$$

Esse crescimento multiplicativo explica por que a construção dos perfis é parte integrante do problema. Mesmo um número moderado de atributos e níveis pode produzir um conjunto de alternativas grande demais para ser apresentado integralmente a cada participante.

A escolha dos perfis determina quais combinações de atributos serão observadas e, posteriormente, quais efeitos poderão ser separados pelo modelo.

22.2 Preferência e utilidade

A preferência estabelece uma comparação entre alternativas. A utilidade fornece uma representação numérica dessa comparação.

Considere dois perfis,

$$\mathbf{x}_i \quad \text{e} \quad \mathbf{x}_h.$$

Uma representação de preferência por utilidade satisfaz

$$U(\mathbf{x}_i) > U(\mathbf{x}_h)$$

quando o perfil $\mathbf{x}_i$ é preferido ao perfil $\mathbf{x}_h$.

A utilidade permite, portanto, substituir comparações entre alternativas por comparações entre números.

Definição 22.2 (Utilidade). A **utilidade** é uma representação numérica da preferência atribuída às alternativas consideradas no problema.

Valores maiores representam alternativas mais preferidas segundo a orientação adotada para a escala.

A utilidade deve ser interpretada relativamente ao problema estudado. Seu valor numérico depende dos atributos, dos níveis, da forma de resposta e da parametrização utilizada.

Por isso, uma afirmação como

$$U(\mathbf{x}_i) = 8$$

não possui, isoladamente, interpretação absoluta. O significado estatístico aparece nas diferenças e comparações, como

$$U(\mathbf{x}_i) - U(\mathbf{x}_h).$$

A forma exata da indeterminação de localização ou escala depende do modelo utilizado. Em avaliações quantitativas, a escala observada impõe uma estrutura diferente daquela de uma resposta puramente ordinal ou de um modelo probabilístico de escolha. Essas situações serão distinguidas posteriormente.

22.3 Utilidades parciais

A Análise Conjunta procura decompor a utilidade total em contribuições relacionadas aos atributos. A representação aditiva possui sua base clássica na teoria de mensuração conjunta (Luce; Tukey, 1964).

Para o atributo j , denote por

$$u_j(x_{ij})$$

a contribuição associada ao nível x_{ij} presente no perfil i .

Definição 22.3 (Utilidade parcial). A **utilidade parcial** de um nível representa sua contribuição para a utilidade de uma alternativa dentro da estrutura de atributos e níveis considerada.

Para o atributo j , essa contribuição é representada por

$$u_j(x_{ij}).$$

A utilidade parcial não descreve um nível isolado de todo o contexto do estudo. Ela é definida em relação:

- aos demais níveis do mesmo atributo;
- aos outros atributos incluídos;
- à codificação utilizada;
- ao tipo de resposta observado.

A comparação entre níveis de um mesmo atributo é especialmente informativa. Para dois níveis a e b do atributo j ,

$$u_j(a) - u_j(b) \quad (22.3)$$

representa a diferença de contribuição atribuída à substituição de b por a , mantida a estrutura prevista pelo modelo.

22.4 Modelo aditivo de utilidade

A formulação clássica supõe que a utilidade sistemática de um perfil pode ser decomposta como soma das contribuições associadas aos seus atributos.

Definição 22.4 (Modelo aditivo de utilidade). Para um perfil

$$\mathbf{x}_i = (x_{i1}, \dots, x_{im})^\top,$$

a estrutura aditiva de utilidade é

$$V_i = \beta_0 + \sum_{j=1}^m u_j(x_{ij}), \quad (22.4)$$

em que:

- β_0 representa uma constante comum aos perfis;
- $u_j(x_{ij})$ representa a contribuição do nível observado no atributo j ;
- V_i representa a parte sistemática da utilidade atribuída ao perfil.

A notação V_i é utilizada para distinguir a parte explicada pela estrutura dos atributos de uma eventual parcela não explicada ou aleatória.

Para uma resposta quantitativa, uma formulação estatística inicial é

$$Y_i = V_i + \varepsilon_i,$$

ou, equivalentemente,

$$Y_i = \beta_0 + \sum_{j=1}^m u_j(x_{ij}) + \varepsilon_i. \quad (22.5)$$

Nesse caso, Y_i é a avaliação observada e ε_i representa a parcela da resposta que não é explicada pela estrutura aditiva incluída no modelo.

A equação Equação 22.5 estabelece a conexão entre o problema de preferência e o modelo linear desenvolvido anteriormente no livro. O conteúdo específico da Análise Conjunta está na forma como os perfis são construídos e como as funções

$$u_j(\cdot)$$

são representadas pelos níveis dos atributos.

22.4.1 Aditividade

A hipótese de aditividade significa que a contribuição total é obtida pela soma das contribuições dos atributos.

Para dois atributos A e B ,

$$V(a, b) = \beta_0 + u_A(a) + u_B(b). \quad (22.6)$$

A diferença produzida pela substituição de a por a' é

$$V(a', b) - V(a, b) = u_A(a') - u_A(a). \quad (22.7)$$

O lado direito não depende do nível b do outro atributo.

Assim, no modelo aditivo, o efeito atribuído à mudança de nível em um atributo é constante em relação aos níveis dos demais atributos.

Essa é uma hipótese **definidora** da formulação aditiva clássica: ela determina o significado da decomposição em utilidades parciais.

22.4.2 Compensação entre atributos

A estrutura aditiva admite que contribuições positivas e negativas ocorram simultaneamente.

Considere dois perfis

$$\mathbf{x}_i \quad \text{e} \quad \mathbf{x}_h.$$

A diferença entre suas utilidades sistemáticas é

$$V_i - V_h = \sum_{j=1}^m [u_j(x_{ij}) - u_j(x_{hj})]. \quad (22.8)$$

Uma alternativa pode possuir menor contribuição em um atributo e, ao mesmo tempo, maior contribuição em outro. A preferência final depende da soma dessas diferenças.

Essa propriedade é denominada **compensação**: uma perda relativa de utilidade em determinada característica pode ser compensada por ganhos em outras características.

A compensação decorre da forma aditiva. Ela não deve ser assumida automaticamente quando a estrutura substantiva do problema impõe restrições, limiares ou características não compensatórias.

22.4.3 Interações entre atributos

A aditividade pode ser insuficiente quando o efeito de um atributo depende do nível assumido por outro.

Para dois atributos, uma extensão é

$$V(a, b) = \beta_0 + u_A(a) + u_B(b) + u_{AB}(a, b), \quad (22.9)$$

em que

$$u_{AB}(a, b)$$

representa uma contribuição específica da combinação dos níveis a e b .

Agora,

$$\begin{aligned} V(a', b) - V(a, b) &= u_A(a') - u_A(a) \\ &\quad + u_{AB}(a', b) - u_{AB}(a, b), \end{aligned}$$

e a diferença pode variar com b .

A interação modifica, portanto, a interpretação das utilidades parciais: a contribuição associada a um nível deixa de ser suficiente para caracterizar seu efeito independentemente dos demais atributos.

A Figura 22.1 ilustra essa diferença. No modelo aditivo, a diferença entre os níveis do primeiro atributo permanece constante para os diferentes níveis do segundo. Com interação, essa diferença se modifica.




Figura 22.1: Aditividade e interação entre dois atributos. Linhas paralelas representam um efeito do atributo A que não depende do nível de B; linhas não paralelas indicam interação.

No painel aditivo, a mudança de A_1 para A_2 produz a mesma diferença de utilidade para B_1 e B_2 . No painel com interação, o efeito de alterar o nível de A depende do nível de B.

A inclusão de interações aumenta o número de parâmetros e modifica as exigências impostas ao conjunto de perfis. O delineamento precisa conter informação suficiente para separar os efeitos que se pretende representar. Por isso, aditividade, codificação, posto e construção dos perfis estão diretamente relacionados.

22.5 Da utilidade à representação matricial

O modelo em Equação 22.5 ainda está escrito em termos das funções

$$u_j(x_{ij}).$$

Para estimar essas contribuições a partir das respostas observadas, os níveis dos atributos precisam ser transformados em colunas de uma matriz.

Essa representação será feita pela **matriz de delineamento**

$\mathbf{Z}$,

na qual cada linha descreve um perfil segundo uma codificação previamente escolhida.

Depois dessa codificação, o modelo aditivo poderá ser escrito como

$$\mathbf{y} = \mathbf{Z}\beta + \varepsilon,$$

conectando a Análise Conjunta diretamente à teoria do modelo linear, do posto e das funções estimáveis desenvolvida no Módulo II.

A particularidade da técnica estará na interpretação de β : seus componentes representarão utilidades parciais ou contrastes entre níveis dos atributos.

22.6 Representação matricial do modelo

A formulação aditiva pode ser escrita como um modelo linear depois que os níveis dos atributos são representados numericamente.

Considere N avaliações quantitativas de perfis. Para o perfil i , seja

$$\mathbf{z}_i^\top$$

o vetor que contém o intercepto e os valores definidos pela codificação dos níveis presentes nesse perfil.

Reunindo as N linhas, obtém-se a matriz de delineamento

$$\mathbf{Z} = \begin{pmatrix} \mathbf{z}_1^\top \\ \vdots \\ \mathbf{z}_N^\top \end{pmatrix} \in \mathbb{R}^{N \times d}, \quad (22.10)$$

em que d é o número de parâmetros da parametrização utilizada.

Se

$$\beta = \begin{pmatrix} \beta_1 \\ \vdots \\ \beta_d \end{pmatrix},$$

a utilidade sistemática dos perfis pode ser reunida em

$$\mathbf{V} = \mathbf{Z}\beta, \quad (22.11)$$

com

$$\mathbf{V} = \begin{pmatrix} V_1 \\ \vdots \\ V_N \end{pmatrix}.$$

Para respostas quantitativas,

$$\mathbf{y} = \mathbf{Z}\beta + \varepsilon. \quad (22.12)$$

A forma em Equação 22.12 é o modelo linear já desenvolvido no Módulo II. A Análise Conjunta não exige uma nova teoria de mínimos quadrados. Sua especificidade está na construção de $\mathbf{Z}$ a partir dos atributos e níveis e na interpretação de β em termos de utilidades parciais e contrastes de preferência.

22.7 Codificação dos níveis

Atributos categóricos com mais de dois níveis precisam ser representados por mais de uma coluna da matriz de delineamento.

Considere um atributo A_j com

$$L_j$$

níveis. A escolha de uma codificação determina como esses níveis são expressos pelos parâmetros, mas não modifica necessariamente as utilidades ajustadas dos perfis.

Duas parametrizações são particularmente úteis para compreender essa distinção:

- codificação por categoria de referência;
- codificação por efeitos.

22.7.1 Categoria de referência

Escolha um dos níveis do atributo como referência. Se A_j possui L_j níveis, são necessárias

$$L_j - 1$$

colunas indicadoras.

Suponha, por exemplo, que o atributo A tenha três níveis,

$$A_1, \quad A_2, \quad A_3,$$

e que A_1 seja a categoria de referência.

Podem ser definidas as colunas

$$z_{A2} = \begin{cases} 1, & A = A_2, \\ 0, & \text{caso contrário,} \end{cases}$$

e

$$z_{A3} = \begin{cases} 1, & A = A_3, \\ 0, & \text{caso contrário.} \end{cases}$$

A contribuição desse atributo para o modelo pode ser escrita como

$$\beta_{A2} z_{A2} + \beta_{A3} z_{A3}.$$

O nível A_1 não possui coluna própria. Sua contribuição está incorporada ao intercepto e às escolhas de referência dos demais atributos.

Nessa parametrização,

$$\beta_{A2}$$

representa a diferença entre as utilidades dos níveis A_2 e A_1 , enquanto

$$\beta_{A3}$$

representa a diferença entre A_3 e A_1 .

Assim,

$$\beta_{A2} = u_A(A_2) - u_A(A_1) \quad (22.13)$$

e

$$\beta_{A3} = u_A(A_3) - u_A(A_1). \quad (22.14)$$

Considere agora dois atributos:

- A , com níveis A_1, A_2, A_3 ;
- B , com níveis B_1, B_2 .

Usando A_1 e B_1 como referências, a matriz de delineamento de todos os seis perfis pode ser representada pela Tabela 22.3.

Tabela 22.3: Exemplo de codificação por categoria de referência para dois atributos.

Perfil	A	B	intercepto	z_{A2}	z_{A3}	z_{B2}
1	A_1	B_1	1	0	0	0
2	A_1	B_2	1	0	0	1
3	A_2	B_1	1	1	0	0
4	A_2	B_2	1	1	0	1
5	A_3	B_1	1	0	1	0
6	A_3	B_2	1	0	1	1

O modelo correspondente é

$$V_i = \beta_0 + \beta_{A2}z_{i,A2} + \beta_{A3}z_{i,A3} + \beta_{B2}z_{i,B2}. \quad (22.15)$$

Para o perfil de referência,

$$(A_1, B_1),$$

tem-se

$$V(A_1, B_1) = \beta_0.$$

Para

$$(A_2, B_1),$$

a utilidade sistemática é

$$V(A_2, B_1) = \beta_0 + \beta_{A_2}.$$

Logo,

$$V(A_2, B_1) - V(A_1, B_1) = \beta_{A_2}.$$

A interpretação do coeficiente está, portanto, vinculada à categoria escolhida como referência.

22.7.2 Codificação por efeitos

Outra possibilidade consiste em representar os níveis de cada atributo por contrastes cuja soma seja zero.

Para um atributo com três níveis, uma codificação possível é

Tabela 22.4: Exemplo de codificação por efeitos para um atributo com três níveis.

Nível	z_1	z_2
A_1	1	0
A_2	0	1
A_3	-1	-1

Nesse caso, a contribuição do atributo é

$$\beta_{A_1} z_1 + \beta_{A_2} z_2.$$

Os níveis possuem utilidades parciais

$$u_A(A_1) = \beta_{A_1},$$

$$u_A(A_2) = \beta_{A_2},$$

e

$$u_A(A_3) = -\beta_{A1} - \beta_{A2}. \quad (22.16)$$

Consequentemente,

$$u_A(A_1) + u_A(A_2) + u_A(A_3) = 0. \quad (22.17)$$

A restrição de soma zero determina uma origem para as utilidades parciais daquele atributo.

O nível codificado pela linha

$$(-1, -1)$$

não possui utilidade zero. Sua utilidade é recuperada a partir da restrição em Equação 22.17.

Essa diferença é importante:

- na codificação por referência, um nível funciona como base de comparação;
- na codificação por efeitos, as utilidades dos níveis são expressas relativamente a uma restrição de soma zero.

Os coeficientes produzidos pelas duas parametrizações não possuem, em geral, os mesmos valores numéricos.

22.8 Identificação do modelo

A necessidade de codificação decorre de um problema de identificação.

Suponha que um atributo possua L_j níveis e que sejam incluídas simultaneamente:

- uma coluna de intercepto;
- uma coluna indicadora para cada um dos L_j níveis.

Para cada perfil, exatamente uma dessas indicadoras é igual a 1. Portanto,

$$\mathbf{1}_N = \mathbf{z}_{j1} + \cdots + \mathbf{z}_{jL_j}, \quad (22.18)$$

em que

$$\mathbf{z}_{j\ell}$$

denota a coluna indicadora do nível ℓ .

A coluna do intercepto é, assim, combinação linear das colunas associadas aos níveis do atributo.

Consequentemente, a matriz de delineamento possui colunas linearmente dependentes.

Essa relação conecta diretamente três conceitos desenvolvidos nos módulos anteriores:

$$\text{posto}(\mathbf{Z}) < d,$$

a matriz

$$\mathbf{Z}^T \mathbf{Z}$$

é singular e os elementos de

$$\beta$$

não são todos identificados individualmente.

O Módulo II já mostrou, no estudo de delineamentos com posto deficiente, que diferentes vetores de parâmetros podem produzir os mesmos valores ajustados. O mesmo princípio aparece aqui com uma interpretação específica de utilidade.

Definição 22.5 (Identificação na Análise Conjunta). Uma parametrização da Análise Conjunta é **identificada** quando as restrições impostas à representação dos níveis permitem determinar unicamente os parâmetros utilizados nessa parametrização a partir da estrutura do modelo.

Quando a matriz de delineamento possui posto deficiente, diferentes vetores de coeficientes podem representar as mesmas utilidades sistemáticas dos perfis.

Considere um vetor

$$\mathbf{d} \neq \mathbf{0}$$

pertencente ao núcleo de $\mathbf{Z}$:

$$\mathbf{Z}\mathbf{d} = \mathbf{0}.$$

Então,

$$\mathbf{Z}(\beta + \mathbf{d}) = \mathbf{Z}\beta. \quad (22.19)$$

Portanto,

$$\beta$$

e

$$\beta + \mathbf{d}$$

produzem exatamente o mesmo vetor de utilidades sistemáticas.

Essa é a versão univariada da equivalência de parametrizações desenvolvida no Módulo II para matrizes de parâmetros em Equação 11.125.

A pseudoinversa pode selecionar uma solução particular em um problema de posto deficiente, mas não transforma parâmetros não identificados em parâmetros identificados. A identificação decorre da estrutura do delineamento e das restrições impostas à parametrização.

22.9 Restrições de identificação

Duas estratégias já apresentadas resolvem a redundância produzida pelos indicadores completos.

22.9.1 Eliminação de uma categoria

Na codificação por referência, uma coluna indicadora de cada atributo é eliminada.

Para o modelo aditivo com intercepto, o número de parâmetros é então

$$d = 1 + \sum_{j=1}^m (L_j - 1). \quad (22.20)$$

O primeiro termo corresponde ao intercepto e cada atributo acrescenta $L_j - 1$ parâmetros independentes.

22.9.2 Restrição de soma zero

Na codificação por efeitos, também são utilizados $L_j - 1$ parâmetros independentes para cada atributo, mas a utilidade do nível restante é obtida impondo

$$\sum_{\ell=1}^{L_j} u_j(\ell) = 0. \quad (22.21)$$

Em ambas as abordagens, o objetivo é representar o mesmo número de graus de liberdade associado ao atributo:

$$L_j - 1.$$

A parametrização determina **como** esses graus de liberdade são expressos, e não quantos efeitos independentes o atributo possui.

22.10 Equivalência entre parametrizações

Considere duas matrizes de delineamento,

$$\mathbf{Z}_1$$

e

$$\mathbf{Z}_2,$$

correspondentes a duas codificações diferentes dos mesmos efeitos.

Se elas geram o mesmo espaço coluna,

$$\mathcal{C}(\mathbf{Z}_1) = \mathcal{C}(\mathbf{Z}_2), \quad (22.22)$$

então representam o mesmo conjunto de vetores de utilidades sistemáticas possíveis.

Os vetores de coeficientes

$$\beta_1$$

e

$$\beta_2$$

podem ser numericamente diferentes, mas um mesmo vetor ajustado pode ser escrito como

$$\mathbf{V} = \mathbf{Z}_1\beta_1 = \mathbf{Z}_2\beta_2. \quad (22.23)$$

Esse resultado é a aplicação, à Análise Conjunta, da propriedade desenvolvida no Módulo II segundo a qual o espaço do modelo e os valores ajustados dependem de

$$\mathcal{C}(\mathbf{Z}),$$

e não de uma base particular utilizada para representá-lo.

Consequentemente, não se deve comparar diretamente coeficientes provenientes de codificações diferentes sem antes considerar o significado atribuído a cada parâmetro.

O objeto substantivo de interesse está nas preferências representadas pelo modelo e nos contrastes entre níveis e perfis que permanecem definidos independentemente da parametrização.

22.11 Diferenças de utilidade e funções estimáveis

Considere dois perfis com vetores de delineamento

$$\mathbf{z}_i$$

e

$$\mathbf{z}_h.$$

A diferença entre suas utilidades sistemáticas é

$$\begin{aligned} V_i - V_h &= \mathbf{z}_i^\top \beta - \mathbf{z}_h^\top \beta \\ &= (\mathbf{z}_i - \mathbf{z}_h)^\top \beta. \end{aligned} \quad (22.24)$$

Essa diferença é uma função linear dos parâmetros.

Mesmo quando uma parametrização redundante impede a identificação de cada coeficiente individual, uma diferença como Equação 22.24 pode permanecer unicamente determinada pelo espaço do modelo.

A definição em Definição 11.16 e a caracterização em Proposição 11.11 mostram que, em delineamentos de posto deficiente, a interpretação deve ser formulada em termos das funções dos parâmetros que permanecem determinadas pelo espaço linha de $\mathbf{Z}$.

Na Análise Conjunta, exemplos naturais são diferenças entre utilidades de níveis, diferenças entre utilidades de perfis e outros contrastes identificados pelo delineamento. As utilidades ajustadas dos perfis observados permanecem unicamente determinadas; para um novo perfil, sua utilidade sistemática é estimável quando o vetor de codificação correspondente pertence ao espaço linha de $\mathbf{Z}$.

Considere, por exemplo, dois níveis a e b do atributo j . O contraste

$$u_j(a) - u_j(b)$$

possui significado de preferência independente da escolha de uma origem arbitrária para as utilidades desse atributo, desde que o contraste seja estimável no delineamento adotado.

Essa propriedade esclarece por que o valor absoluto de uma utilidade parcial não deve ser interpretado isoladamente.

O que permanece substantivamente interpretável são comparações compatíveis com a parametrização e identificadas pela estrutura do delineamento.

22.12 Um exemplo de equivalência entre codificações

Considere novamente o atributo A com três níveis.

Suponha que, sob uma codificação por efeitos, as utilidades parciais sejam

$$u_A(A_1) = 2,$$

$$u_A(A_2) = -0,5$$

e

$$u_A(A_3) = -1,5.$$

A restrição

$$2 - 0,5 - 1,5 = 0$$

é satisfeita.

As diferenças entre os níveis são

$$u_A(A_2) - u_A(A_1) = -2,5,$$

e

$$u_A(A_3) - u_A(A_1) = -3,5.$$

Se A_1 for escolhido como categoria de referência, os coeficientes correspondentes serão

$$\beta_{A2}^{(\text{ref})} = -2,5$$

e

$$\beta_{A3}^{(\text{ref})} = -3,5.$$

Os números mudaram porque o significado dos parâmetros mudou.

Entretanto, a ordenação das contribuições associadas aos níveis permanece:

$$u_A(A_1) > u_A(A_2) > u_A(A_3).$$

Mais precisamente, os contrastes de utilidade entre os níveis são os mesmos nas duas representações.

Esse exemplo ilustra a diferença entre:

- **parâmetro da codificação**, cujo valor depende da base escolhida;
- **contraste estimável de preferência**, que pode permanecer invariável entre parametrizações equivalentes.

22.13 Posto e complexidade do modelo

A identificação também depende de a matriz de delineamento conter informação suficiente para separar todos os efeitos incluídos no modelo.

No modelo aditivo sem interações, o número de parâmetros independentes é dado por Equação 22.20.

Se forem incluídas interações entre dois atributos A_j e A_h , com respectivamente L_j e L_h níveis, essa interação acrescenta

$$(L_j - 1)(L_h - 1) \quad (22.25)$$

graus de liberdade ao modelo quando utilizada uma parametrização identificada.

Assim, ampliar a estrutura de utilidade de

$$V_i = \beta_0 + \sum_j u_j(x_{ij})$$

para

$$V_i = \beta_0 + \sum_j u_j(x_{ij}) + \sum_{j < h} u_{jh}(x_{ij}, x_{ih})$$

aumenta as exigências impostas ao delineamento.

Não basta acrescentar colunas à matriz $\mathbf{Z}$. É necessário que as combinações de perfis observadas permitam separar os novos efeitos.

Essa relação prepara a próxima etapa da formulação: a construção dos perfis não determina apenas quais alternativas serão avaliadas; ela determina o **espaço de efeitos que poderá ser estimado**.

22.14 Do modelo identificado ao delineamento dos perfis

A matriz

$$\mathbf{Z}$$

é determinada por duas decisões distintas:

1. quais efeitos serão incluídos na estrutura de utilidade;

2. quais perfis serão efetivamente apresentados.

A primeira decisão determina as colunas necessárias.

A segunda determina as linhas disponíveis para identificar essas colunas.

Um delineamento adequado precisa, portanto, produzir uma matriz com posto suficiente para os efeitos que se pretende estimar.

No caso mais simples, todos os perfis do produto cartesiano

$$\mathcal{L}_1 \times \cdots \times \mathcal{L}_m$$

são utilizados. Esse é o **delineamento fatorial completo**.

Quando o número de combinações é grande, pode-se utilizar apenas parte dos perfis. Surge então o **delineamento fracionário**, cuja construção precisa preservar a estimabilidade dos efeitos considerados no modelo.

A próxima seção examina essa relação entre número de perfis, posto, ortogonalidade e capacidade de separar utilidades parciais.

22.15 Delineamento dos perfis

A matriz de delineamento depende dos perfis que são apresentados. Assim, o planejamento dos perfis e a identificação dos parâmetros são partes do mesmo problema.

Se o atributo j possui L_j níveis, o conjunto de todos os perfis possíveis contém

$$N_{\text{perf}} = \prod_{j=1}^m L_j$$

combinações, conforme Equação 22.2.

22.15.1 Delineamento fatorial completo

No **delineamento fatorial completo**, todas as combinações possíveis dos níveis dos atributos são utilizadas.

Considere, por exemplo, três atributos com

$$L_1 = 2, \quad L_2 = 3 \quad \text{e} \quad L_3 = 2.$$

O número de perfis é

$$N_{\text{perf}} = 2 \times 3 \times 2 = 12.$$

O delineamento completo contém informação sobre todas as combinações dos níveis. Para um modelo aditivo adequadamente parametrizado, essa estrutura permite separar os efeitos principais dos atributos. Também permite representar interações desde que o modelo e a parametrização sejam compatíveis com os graus de liberdade disponíveis.

Entretanto, o número de perfis cresce multiplicativamente. Com muitos atributos ou muitos níveis, apresentar todas as combinações pode produzir uma tarefa excessivamente extensa.

22.15.2 Delineamento fracionário

No **delineamento fracionário**, utiliza-se apenas um subconjunto dos perfis possíveis.

Se

$$\mathcal{P} = \mathcal{L}_1 \times \cdots \times \mathcal{L}_m$$

é o conjunto completo, escolhe-se

$$\mathcal{P}_F \subset \mathcal{P}.$$

O objetivo é reduzir o número de alternativas apresentadas preservando informação suficiente para os efeitos incluídos no modelo.

A redução do número de perfis possui uma consequência matemática direta: são removidas linhas da matriz de delineamento. Por isso, a escolha do subconjunto não pode ser analisada separadamente do posto de

Z.

Um delineamento fracionário é compatível com determinado modelo somente quando os efeitos de interesse permanecem estimáveis.

Por exemplo, um conjunto de perfis pode permitir estimar todos os efeitos principais e, ao mesmo tempo, não permitir separar determinadas interações. A possibilidade de estimar um efeito depende da relação entre as colunas de $\mathbf{Z}$ produzida pelos perfis escolhidos.

22.15.3 Ortogonalidade

Uma situação particularmente simples ocorre quando as colunas que representam diferentes efeitos são ortogonais.

Para duas colunas centralizadas,

$$\mathbf{z}_h \quad \text{e} \quad \mathbf{z}_k,$$

a ortogonalidade corresponde a

$$\mathbf{z}_h^\top \mathbf{z}_k = 0. \quad (22.26)$$

Nesse caso, a informação utilizada para estimar um efeito não apresenta associação linear com a coluna utilizada para representar o outro efeito.

A ortogonalidade facilita a separação das contribuições dos atributos e simplifica a estrutura de

$$\mathbf{Z}^\top \mathbf{Z}.$$

Ela também evidencia a ligação entre Análise Conjunta e delineamento experimental: os perfis são construídos para produzir informação sobre efeitos definidos previamente.

Ortogonalidade, porém, não substitui identificação. Um delineamento precisa possuir posto suficiente para os parâmetros ou funções que se pretende estimar.

22.15.4 Balanceamento

Outra propriedade útil é o balanceamento dos níveis.

Um atributo está balanceado quando seus níveis aparecem com frequências iguais ou aproximadamente iguais no conjunto de perfis.

Em um delineamento completo, o balanceamento ocorre naturalmente quando todas as combinações são utilizadas. Em delineamentos fracionários, ele depende da seleção realizada.

Balanceamento e ortogonalidade são propriedades relacionadas à distribuição da informação na matriz de delineamento. A construção de delineamentos ótimos ou algoritmos específicos para selecionar perfis pertence à etapa metodológica posterior.

22.16 Estimação das utilidades

Considere inicialmente uma resposta quantitativa,

$$\mathbf{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_N \end{pmatrix},$$

e o modelo

$$\mathbf{y} = \mathbf{Z}\beta + \varepsilon.$$

Quando

$$\text{posto}(\mathbf{Z}) = d,$$

o resultado de Proposição 11.2, aplicado ao caso de uma única resposta, fornece

$$\hat{\beta} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}. \quad (22.27)$$

A Análise Conjunta utiliza, portanto, a teoria de mínimos quadrados já desenvolvida no Módulo II. O conteúdo específico da técnica está na construção da matriz de delineamento a partir dos perfis e na interpretação dos parâmetros como utilidades parciais ou contrastes de preferência.

Os valores ajustados são

$$\widehat{\mathbf{V}} = \mathbf{Z}\widehat{\boldsymbol{\beta}}, \quad (22.28)$$

e o valor ajustado para o perfil i é

$$\widehat{V}_i = \mathbf{z}_i^\top \widehat{\boldsymbol{\beta}}. \quad (22.29)$$

Dependendo da parametrização, os elementos de

$$\widehat{\boldsymbol{\beta}}$$

representam diretamente utilidades parciais ou contrastes entre níveis.

22.16.1 Utilidade estimada de um perfil

Considere um modelo aditivo com três atributos,

$$A, \quad B \quad \text{e} \quad C.$$

Para um perfil

$$(A = a, B = b, C = c),$$

a utilidade sistemática estimada é

$$\widehat{V}(a, b, c) = \widehat{\beta}_0 + \widehat{u}_A(a) + \widehat{u}_B(b) + \widehat{u}_C(c). \quad (22.30)$$

A Figura 22.2 representa essa composição em um exemplo numérico. Cada parcela corresponde à contribuição associada a um elemento da parametrização, e sua soma determina a utilidade estimada do perfil.

A figura evidencia a propriedade compensatória da formulação aditiva. O atributo B reduz a utilidade do perfil no exemplo, enquanto os demais componentes produzem contribuições positivas. A preferência global é determinada pela soma dessas parcelas.

A decomposição também mostra por que uma utilidade parcial deve ser interpretada dentro da parametrização adotada. Alterar a origem das utilidades pode modificar parcelas individuais sem alterar as diferenças entre perfis representadas pelo modelo.




Figura 22.2: Decomposição da utilidade sistemática de um perfil em uma constante e utilidades parciais associadas aos níveis dos atributos. A soma das contribuições determina a utilidade total estimada.

22.17 Interpretação das preferências

A estimação fornece utilidades associadas aos níveis. A interpretação procura converter essas estimativas em comparações entre alternativas e atributos.

22.17.1 Comparação entre níveis

Para dois níveis a e b de um mesmo atributo,

$$\hat{u}_j(a) - \hat{u}_j(b)$$

quantifica a diferença estimada de contribuição entre eles.

Se

$$\hat{u}_j(a) > \hat{u}_j(b),$$

o nível a contribui mais para a utilidade sistemática do que b , mantida a estrutura especificada pelo modelo.

Em um modelo aditivo, essa diferença independe dos níveis assumidos pelos demais atributos. Quando existem interações, essa interpretação precisa incluir os termos correspondentes.

22.17.2 Amplitude das utilidades de um atributo

Na formulação aditiva sem interações, uma medida resumida da variação das contribuições dentro do atributo j é

$$R_j = \max_{\ell} u_j(\ell) - \min_{\ell} u_j(\ell). \quad (22.31)$$

Essa amplitude mede quanto a utilidade sistemática pode variar em razão dos níveis daquele atributo incluídos no estudo, mantendo a estrutura aditiva especificada.

Se

$$\sum_{h=1}^m R_h > 0,$$

a comparação entre atributos pode ser padronizada por

$$I_j = \frac{R_j}{\sum_{h=1}^m R_h}. \quad (22.32)$$

Nesse caso,

$$0 \leq I_j \leq 1$$

e

$$\sum_{j=1}^m I_j = 1.$$

Definição 22.6 (Importância relativa de um atributo). No modelo aditivo, suponha

$$\sum_{h=1}^m R_h > 0.$$

A **importância relativa** do atributo j é a proporção da amplitude total das utilidades parciais atribuída aos níveis desse atributo:

$$I_j = \frac{\max_{\ell} u_j(\ell) - \min_{\ell} u_j(\ell)}{\sum_{h=1}^m \left[\max_{\ell} u_h(\ell) - \min_{\ell} u_h(\ell) \right]}.$$

Se

$$R_1 = \dots = R_m = 0,$$

não existe variação de utilidade entre os níveis considerados e a importância relativa definida por Equação 22.32 não está determinada.

A importância relativa também depende dos níveis incluídos. Se um atributo é observado apenas em uma faixa estreita de valores, sua amplitude de utilidade pode ser pequena. Ampliar o intervalo entre seus níveis pode aumentar

$$R_j$$

sem que tenha ocorrido mudança na estrutura de preferências da população.

Por isso, I_j descreve a participação relativa do atributo **dentro do conjunto específico de níveis considerado no estudo**.

Quando o modelo inclui interações, a contribuição de um atributo pode depender dos níveis dos demais. Nesse caso, a amplitude baseada somente em suas utilidades parciais principais não resume toda a contribuição do atributo, e a interpretação da importância exige considerar a estrutura de interações.

22.18 Preferências individuais e agregadas

Até aqui, o modelo foi escrito para um único vetor de parâmetros

$$\beta.$$

Essa representação pode corresponder a um participante individual ou a uma estrutura comum assumida para um conjunto de participantes.

22.18.1 Modelo individual

Para o participante r , pode-se escrever

$$\mathbf{y}_r = \mathbf{Z}_r \beta_r + \varepsilon_r, \quad (22.33)$$

em que

$$\beta_r$$

representa suas utilidades ou contrastes de preferência.

Participantes diferentes podem possuir

$$\beta_r \neq \beta_{r'}.$$

A heterogeneidade pode ocorrer tanto na intensidade quanto na direção das preferências.

22.18.2 Modelo agregado

Uma formulação agregada assume um vetor comum,

$$\beta,$$

para representar a estrutura média ou compartilhada de preferência.

Essa simplificação pode ser apropriada quando o objetivo é descrever um padrão agregado, mas pode ocultar diferenças entre indivíduos.

Por exemplo, uma utilidade média próxima de zero para determinado nível pode resultar de:

- baixa preferência em todos os participantes;
- forte preferência positiva em parte deles e forte preferência negativa em outra parte.

Essas situações possuem interpretações diferentes, embora possam produzir a mesma média agregada.

Modelos com efeitos aleatórios, classes latentes ou outras estruturas para heterogeneidade constituem extensões da formulação básica e não serão desenvolvidos neste capítulo.

22.19 Diferentes formas de resposta

A estrutura de perfis e utilidades pode ser utilizada com diferentes tipos de resposta.

O tipo de resposta determina qual modelo estatístico conecta a preferência observada à utilidade.

A Tabela 22.5 resume as principais situações.

Tabela 22.5: Formas de resposta na Análise Conjunta.

Resposta observada	Informação fornecida	Estrutura estatística compatível
avaliação quantitativa	intensidade da avaliação	modelo linear
categoria ordinal	posição em uma escala ordenada	modelo ordinal
ordenação de perfis	ordem relativa das alternativas	modelo para postos ou ordenações
comparação pareada	preferência entre duas alternativas	modelo probabilístico de comparação

escolha	alternativa selecionada em um conjunto	modelo de utilidade aleatória
---------	--	-------------------------------

A matriz de atributos descreve os mesmos tipos de perfis, mas o mecanismo que liga utilidade e observação muda.

22.19.1 Avaliação quantitativa

Quando a resposta é uma escala quantitativa tratada como métrica, a formulação linear é

$$Y_i = \mathbf{z}_i^\top \beta + \varepsilon_i.$$

Aqui, as diferenças numéricas da escala observada participam diretamente da estimação.

22.19.2 Resposta ordinal

Em uma resposta ordinal, as categorias possuem ordem, mas suas distâncias não precisam possuir interpretação métrica.

Nesse caso, a informação

$$Y_i > Y_h$$

indica uma ordem entre respostas, mas não autoriza concluir que a diferença numérica entre categorias represente a mesma diferença de utilidade em toda a escala.

A formulação probabilística precisa respeitar essa estrutura ordinal.

22.19.3 Ordenação

Quando vários perfis são ordenados, observa-se informação do tipo

$$\mathbf{x}_{i_1} \succ \mathbf{x}_{i_2} \succ \cdots \succ \mathbf{x}_{i_K}.$$

A resposta fornece a posição relativa das alternativas, e não uma medida métrica direta da distância entre suas preferências.

22.19.4 Comparação pareada

Na comparação entre dois perfis,

$$i \quad \text{e} \quad h,$$

observa-se qual alternativa é preferida.

A resposta está associada à diferença

$$V_i - V_h.$$

Uma formulação probabilística acrescenta termos aleatórios às utilidades e relaciona a probabilidade de preferência a essa diferença.

22.19.5 Escolha

Em uma tarefa de escolha, uma alternativa é selecionada entre várias disponíveis.

A utilidade deixa de ser observada diretamente. O que se observa é a decisão resultante da comparação entre utilidades latentes.

Essa situação conduz aos modelos de utilidade aleatória.

22.20 Utilidade aleatória

Para o participante r e a alternativa i , escreva

$$U_{ir} = V_{ir} + \varepsilon_{ir}, \quad (22.34)$$

em que

$$V_{ir} = \mathbf{z}_{ir}^\top \beta \quad (22.35)$$

é a parcela sistemática e

$$\varepsilon_{ir}$$

é uma parcela aleatória não observada.

A alternativa i é escolhida quando sua utilidade supera a das demais alternativas disponíveis:

$$U_{ir} > U_{hr}$$

para todos os concorrentes h .

Assim,

$$P(i \text{ escolhido}) = P(V_{ir} + \varepsilon_{ir} > V_{hr} + \varepsilon_{hr}, \forall h \neq i). \quad (22.36)$$

A distribuição atribuída aos termos aleatórios determina a forma específica das probabilidades de escolha.

O objetivo neste capítulo é apenas estabelecer a ponte estrutural:

- os atributos e níveis formam $\mathbf{z}_{ir}$;
- os parâmetros determinam a utilidade sistemática;
- a escolha fornece informação indireta sobre as diferenças de utilidade.

Modelos específicos de escolha, suas funções de probabilidade e procedimentos de estimação pertencem ao desenvolvimento metodológico posterior (Green; Srinivasan, 1990).

22.21 Natureza relativa da utilidade

A interpretação da utilidade depende do tipo de resposta.

Em preferências puramente ordinais, uma transformação estritamente crescente preserva a ordenação das alternativas.

Se

$$U_i > U_h$$

e

$$g$$

é estritamente crescente, então

$$g(U_i) > g(U_h).$$

Entretanto, a formulação aditiva e os modelos probabilísticos utilizam estruturas numéricas mais específicas. Nesses casos, não se pode aplicar arbitrariamente qualquer transformação monotônica aos parâmetros e esperar preservar o mesmo modelo.

No modelo linear para avaliações quantitativas, localização e escala estão vinculadas à escala da resposta.

Nos modelos de escolha, apenas diferenças de utilidade determinam comparações entre alternativas, e restrições de localização e escala são necessárias para identificar uma parametrização probabilística.

Assim, a afirmação de que “a utilidade é relativa” precisa ser interpretada segundo a forma de resposta e o modelo utilizado.

22.22 Pressupostos e limites

A Análise Conjunta reúne pressupostos sobre a representação dos perfis, a estrutura da utilidade, o delineamento e o mecanismo probabilístico associado à resposta.

22.22.1 Definição adequada dos atributos

Os perfis precisam ser descritos por atributos e níveis capazes de representar as diferenças relevantes entre as alternativas consideradas.

Se uma característica importante para a preferência não está representada, sua contribuição não pode ser separada pelas utilidades estimadas dos atributos incluídos.

22.22.2 Aditividade

No modelo aditivo,

$$V_i = \beta_0 + \sum_{j=1}^m u_j(x_{ij}),$$

o efeito de um atributo não depende dos níveis dos demais.

Essa é uma hipótese estrutural da formulação.

Quando existem interações relevantes, o modelo aditivo pode representar inadequadamente a forma como as características são combinadas na preferência.

22.22.3 Compensação

A soma das utilidades parciais admite compensação entre atributos.

Essa estrutura pode ser inadequada quando determinados níveis funcionam como requisitos absolutos, limites ou restrições não compensatórias.

22.22.4 Identificação

A parametrização precisa impor restrições suficientes para eliminar redundâncias entre intercepto e indicadores de níveis.

Além disso, os perfis observados precisam produzir uma matriz de delineamento com posto suficiente para os efeitos de interesse.

22.22.5 Compatibilidade entre resposta e modelo

A formulação probabilística deve ser compatível com a escala da resposta.

Uma avaliação métrica, uma ordenação e uma escolha fornecem informações diferentes sobre a preferência e não devem ser tratadas como se fossem observações do mesmo tipo.

22.22.6 Independência e estrutura dos erros

Na formulação linear mais simples, os erros precisam possuir estrutura compatível com o modelo linear adotado.

Quando várias avaliações pertencem ao mesmo participante, pode existir dependência entre respostas da mesma pessoa. A independência entre todas as observações não deve ser assumida automaticamente quando o delineamento produz medidas repetidas por participante.

Modelos que representem explicitamente essa dependência pertencem às extensões metodológicas.

22.22.7 Delineamento e estimabilidade

Um número reduzido de perfis pode diminuir a carga da tarefa, mas também reduz a informação disponível.

A seleção dos perfis precisa preservar os efeitos que serão interpretados.

Adicionar interações ou outras estruturas sem ampliar adequadamente o delineamento pode produzir parâmetros não identificados ou efeitos confundidos.

22.22.8 Generalização

As utilidades estimadas descrevem preferências relativas aos:

- atributos selecionados;
- níveis utilizados;
- perfis apresentados;
- participantes observados;
- mecanismo de resposta adotado.

Alterar esses elementos modifica o problema estatístico. Por isso, utilidades e importâncias relativas não devem ser tratadas como características absolutas e independentes do delineamento.

22.23 Relações com outras formulações estatísticas

22.23.1 Modelo linear

A relação mais direta é com o modelo linear.

Para avaliações quantitativas,

$$\mathbf{y} = \mathbf{Z}\boldsymbol{\beta} + \boldsymbol{\varepsilon}.$$

A matriz de delineamento representa os atributos e seus níveis, e os elementos de

$$\boldsymbol{\beta}$$

recebem interpretação de utilidades parciais ou contrastes.

A teoria de posto, projeções, mínimos quadrados e funções estimáveis já desenvolvida no Módulo II aplica-se diretamente.

A Análise Conjunta acrescenta ao modelo linear uma estrutura substantiva específica: as linhas de $\mathbf{Z}$ são **alternativas** e seus parâmetros descrevem **preferências associadas às características dessas alternativas**.

22.23.2 Delineamento experimental

A matriz $\mathbf{Z}$ também estabelece uma ligação direta com o delineamento experimental.

Os atributos desempenham papel semelhante ao de fatores, os níveis definem condições e os perfis correspondem a combinações dessas condições.

O delineamento controla quais efeitos podem ser separados.

A diferença está no objetivo: na Análise Conjunta, o interesse está em decompor preferências ou escolhas relacionadas a alternativas.

22.23.3 Modelos de escolha

Quando a resposta observada é uma escolha, a formulação linear direta deixa de ser suficiente.

A estrutura

$$U_{ir} = \mathbf{z}_{ir}^\top \beta + \varepsilon_{ir}$$

transforma os mesmos atributos e parâmetros de utilidade em uma variável latente.

A distribuição dos erros converte diferenças de utilidade sistemática em probabilidades de escolha.

Assim, Análise Conjunta e modelos de escolha compartilham:

- representação das alternativas por atributos;
- parâmetros de utilidade;
- comparação entre alternativas.

O mecanismo de observação da resposta determina a formulação probabilística específica.

22.24 Síntese da Análise Conjunta

A Análise Conjunta parte de alternativas descritas por atributos e níveis.

Um perfil é representado por

$$\mathbf{x}_i = (x_{i1}, \dots, x_{im})^\top,$$

e sua preferência é representada por uma utilidade.

Na formulação aditiva,

$$V_i = \beta_0 + \sum_{j=1}^m u_j(x_{ij}).$$

As funções

$$u_j(\cdot)$$

representam utilidades parciais associadas aos níveis.

Depois da codificação dos atributos, a formulação torna-se

$$\mathbf{V} = \mathbf{Z}\beta.$$

Para avaliações quantitativas,

$$\mathbf{y} = \mathbf{Z}\beta + \varepsilon.$$

A matriz de delineamento conecta três elementos:

- os perfis apresentados;
- a parametrização das utilidades;
- os efeitos que podem ser estimados.

Uma parametrização redundante produz perda de posto e não identificação dos coeficientes individuais. Categoria de referência e codificação por efeitos fornecem representações identificadas dos mesmos graus de liberdade.

Parametrizações diferentes podem produzir coeficientes distintos e, ao mesmo tempo, representar o mesmo espaço de utilidades ajustadas. Por isso, contrastes entre níveis e diferenças entre perfis constituem objetos particularmente relevantes para interpretação.

O delineamento completo utiliza todas as combinações dos níveis. Delineamentos fracionários reduzem o número de perfis, mas precisam preservar a estimabilidade dos efeitos pretendidos.

As amplitudes

$$R_j = \max_{\ell} u_j(\ell) - \min_{\ell} u_j(\ell)$$

permitem construir medidas de importância relativa dos atributos,

$$I_j = \frac{R_j}{\sum_h R_h},$$

que devem ser interpretadas relativamente aos níveis incluídos.

A forma de resposta determina o modelo estatístico. Avaliações quantitativas permitem uma formulação linear direta; respostas ordinais, ordenações, comparações e escolhas requerem modelos compatíveis com a informação efetivamente observada.

Nos modelos de escolha,

$$U_{ir} = V_{ir} + \varepsilon_{ir}$$

introduz uma utilidade latente cuja parcela sistemática continua sendo construída a partir dos atributos.

A Análise Conjunta reúne, portanto, conceitos desenvolvidos anteriormente no livro — modelo linear, matriz de delineamento, posto, funções estimáveis e delineamentos fatoriais — para resolver um problema específico: **decompor preferências globais em contribuições associadas às características das alternativas**.

22.25 Síntese do Módulo 3

O Módulo 3 apresentou a formulação matemática e estatística das principais técnicas multivariadas a partir dos fundamentos construídos nos módulos anteriores.

As técnicas diferem quanto ao problema estatístico, ao objeto de entrada e ao critério utilizado, mas compartilham um conjunto relativamente pequeno de estruturas matemáticas.

Na Análise de Componentes Principais, o problema de redução dimensional conduziu à maximização da variância, à decomposição espectral e à aproximação de posto reduzido.

Na Análise Fatorial, a covariância observada foi representada por uma estrutura de fatores comuns e variâncias específicas.

Na Análise de Agrupamentos, distâncias e dispersões foram utilizadas para formalizar o problema de construir grupos sem rótulos previamente conhecidos.

No Escalonamento Multidimensional, dissimilaridades foram convertidas em uma representação geométrica por meio de distâncias, produtos internos e decomposição espectral.

Na Análise de Correspondência, uma tabela de contingência foi transformada em perfis e resíduos padronizados para construir uma representação geométrica das associações entre categorias.

Na MANOVA, o modelo linear multivariado produziu matrizes de hipótese e erro, cujas raízes características permitiram comparar vetores de médias.

Na Análise Discriminante, as mesmas estruturas de dispersão foram utilizadas para construir direções de separação e, sob modelos probabilísticos, regras de classificação.

Na Correlação Canônica, dois blocos de variáveis foram branqueados e relacionados por uma SVD que produziu pares de combinações com associação máxima.

Na Análise Conjunta, a matriz de delineamento e o modelo de utilidade permitiram decompor preferências em contribuições associadas aos atributos e níveis.

Esses capítulos mostram que compreender uma técnica multivariada exige reconhecer quatro elementos:

1. **o problema estatístico** que se deseja resolver;
2. **o objeto matemático** em que os dados são representados;
3. **o modelo, critério ou decomposição** que define a solução;
4. **o significado estatístico e geométrico** atribuído ao resultado.

A Tabela 22.6 reúne essas relações.

Tabela 22.6: Problemas, objetos e estruturas matemáticas das técnicas apresentadas no Módulo 3.

Técnica	Problema estatístico	Objeto principal	Estrutura da solução
ACP	reduzir dimensão preservando variabilidade	matriz de covariâncias/correlações ou dados	autovalores e SVD
Análise Fatorial	representar dependência por fatores latentes	matriz de covariâncias/correlações	modelo de covariâncias
Agrupamentos	formar grupos sem rótulos prévios	dados ou dissimilaridades	distâncias e critérios de dispersão
MDS	representar dissimilaridades geometricamente	matriz de dissimilaridades	matriz de Gram e decomposição espectral
Correspondência	representar associação entre categorias	tabela de contingência	perfis, resíduos padronizados e SVD
MANOVA	comparar vetores de médias	respostas e delineamento	matrizes $\mathbf{H}$ e $\mathbf{E}$ e raízes características
Discriminante	separar grupos e classificar	dados com grupos conhecidos	Fisher ou regras probabilísticas

Técnica	Problema estatístico	Objeto principal	Estrutura da solução
Correlação Canônica	associar dois blocos de variáveis	covariâncias em blocos	branqueamento e SVD
Análise Conjunta	decompor preferências	perfis e respostas de preferência	matriz de delineamento e modelo de utilidade

A recorrência de autovalores, SVD, projeções, distâncias, covariâncias, matrizes de delineamento e modelos probabilísticos não significa que as técnicas resolvam o mesmo problema. O significado de cada estrutura é determinado pela pergunta estatística que deu origem à formulação.

O papel dos fundamentos dos Módulos I e II é justamente permitir reconhecer essa recorrência. Uma vez estabelecidos os resultados gerais sobre espaços vetoriais, transformações, decomposições matriciais, covariâncias, distribuições multivariadas, estimação e modelos lineares, cada técnica pode ser compreendida como uma forma específica de combinar esses elementos.

O Módulo 3 encerra, assim, a formulação das técnicas. Os procedimentos de estimação específicos, decisões operacionais, diagnósticos, validação, implementação computacional e interpretação de estudos aplicados podem ser desenvolvidos posteriormente sem perder de vista a estrutura matemática e estatística que sustenta cada método.

Referências

ANDERSON, Theodore W. [An Introduction to Multivariate Statistical Analysis](#). 3. ed. Hoboken, NJ: John Wiley & Sons, 2003. p. 752

APOSTOL, Tom M. [Calculus, Volume II: Multi-Variable Calculus and Linear Algebra, with Applications to Differential Equations and Probability](#). 2. ed. New York: John Wiley & Sons, 1969.

ARTES, Rinaldo; BARROSO, Lúcia Pereira. [Métodos multivariados de análise estatística](#). 1. ed. São Paulo: Blucher, 2023. p. 534

AXLER, Sheldon. [Measure, Integration & Real Analysis](#). Cham: Springer, 2020. v. 282

BERGER, James O. [Statistical Decision Theory and Bayesian Analysis](#). 2. ed. New York: Springer, 1985. p. 618

BORG, Ingwer; GROENEN, Patrick J. F.; MAIR, Patrick. [Applied Multidimensional Scaling and Unfolding](#). 2. ed. Cham: Springer, 2018. p. 122

BOYD, Stephen; VANDENBERGHE, Lieven. [Convex Optimization](#). Cambridge: Cambridge University Press, 2004.

CASELLA, George; BERGER, Roger L. [Statistical Inference](#). 2. ed. Pacific Grove, CA: Duxbury, 2002.

CHRISTENSEN, Ronald. [Plane Answers to Complex Questions: The Theory of Linear Models](#). 4. ed. New York: Springer, 2011. p. 494

DEMME, James W. [Singular Value Decomposition](#). In: BAI, Zhaojun *et al.* (Orgs.). [Templates for the Solution of Algebraic Eigenvalue Problems: A Practical Guide](#). Philadelphia: Society for Industrial; Applied Mathematics, 2000. p. 135–147.

DRISCOLL, Tobin A.; BRAUN, Richard J. [Fundamentals of Numerical Computation: Julia Edition](#). Philadelphia: Society for Industrial; Applied Mathematics, 2022. p. 614

EATON, Morris L. [Multivariate Statistics: A Vector Space Approach](#). Beachwood,

OH: Institute of Mathematical Statistics, 2007. v. 53 p. 512

GOLUB, Gene H.; VAN LOAN, Charles F. **Matrix Computations**. 4. ed. Baltimore: Johns Hopkins University Press, 2013.

GOWER, John C. **Some Distance Properties of Latent Root and Vector Methods Used in Multivariate Analysis**. **Biometrika**, v. 53, n. 3–4, p. 325–338, 1966.

GREEN, Paul E.; RAO, Vithala R. **Conjoint Measurement for Quantifying Judgmental Data**. **Journal of Marketing Research**, v. 8, n. 3, p. 355–363, 1971.

GREEN, Paul E.; SRINIVASAN, V. **Conjoint Analysis in Consumer Research: Issues and Outlook**. **Journal of Consumer Research**, v. 5, n. 2, p. 103–123, 1978.

GREEN, Paul E.; SRINIVASAN, V. **Conjoint Analysis in Marketing: New Developments with Implications for Research and Practice**. **Journal of Marketing**, v. 54, n. 4, p. 3–19, 1990.

GREENACRE, Michael. **Correspondence Analysis in Practice**. 3. ed. Boca Raton: CRC Press, 2017.

GUPTA, Arjun K.; NAGAR, Daya K. **Matrix Variate Distributions**. Boca Raton: Chapman & Hall/CRC, 1999.

HAIR, Jr., Joseph F. *et al.* **Multivariate Data Analysis**. 8. ed. Andover: Cengage Learning, 2018.

HARVILLE, David A. **Matrix Algebra From a Statistician's Perspective**. New York: Springer, 1997. p. 634

HORN, Roger A.; JOHNSON, Charles R. **Topics in Matrix Analysis**. Cambridge: Cambridge University Press, 1991.

HORN, Roger A.; JOHNSON, Charles R. **Matrix Analysis**. 2. ed. Cambridge: Cambridge University Press, 2013.

HUBERTY, Carl J.; OLEJNIK, Stephen. **Applied MANOVA and Discriminant Analysis**. 2. ed. Hoboken, NJ: John Wiley & Sons, 2006.

JOHNSON, Richard A.; WICHERN, Dean W. **Applied Multivariate Statistical Analysis**. 6. ed. Upper Saddle River, NJ: Pearson Prentice Hall, 2007.

JOLLIFFE, Ian T. **Principal Component Analysis**. 2. ed. New York: Springer, 2002. p. 488

- KRUSKAL, Joseph B. [Multidimensional Scaling by Optimizing Goodness of Fit to a Nonmetric Hypothesis](#). **Psychometrika**, v. 29, n. 1, p. 1–27, 1964.
- LAWLEY, D. N.; MAXWELL, A. E. [Factor Analysis as a Statistical Method](#). 2. ed. London: Butterworths, 1971.
- LEDOIT, Olivier; WOLF, Michael. [A Well-Conditioned Estimator for Large-Dimensional Covariance Matrices](#). **Journal of Multivariate Analysis**, v. 88, n. 2, p. 365–411, 2004.
- LUCE, R. Duncan; TUKEY, John W. [Simultaneous Conjoint Measurement: A New Type of Fundamental Measurement](#). **Journal of Mathematical Psychology**, v. 1, n. 1, p. 1–27, 1964.
- MACQUEEN, James. Some Methods for Classification and Analysis of Multivariate Observations. *In*: Berkeley: University of California Press, 1967. Disponível em: <<https://projecteuclid.org/euclid.bsm/1200512992>>. Acesso em: 3 ago. 2026
- MAGNUS, Jan R.; NEUDECKER, Heinz. [Matrix Differential Calculus with Applications in Statistics and Econometrics](#). 3. ed. Chichester: John Wiley & Sons, 2019. p. 504
- MANLY, Bryan F. J.; NAVARRO ALBERTO, Jorge A. [Métodos Estatísticos Multivariados: Uma Introdução](#). 4. ed. Porto Alegre: Bookman, 2019. p. 254
- MARDIA, Kanti V.; KENT, John T.; TAYLOR, Charles C. [Multivariate Analysis](#). 2. ed. Hoboken, NJ: John Wiley & Sons, 2024. p. 592
- MARONNA, Ricardo A. *et al.* [Robust Statistics: Theory and Methods \(with R\)](#). 2. ed. Hoboken, NJ: John Wiley & Sons, 2019. p. 464
- MEYER, Carl D. [Matrix Analysis and Applied Linear Algebra](#). 2. ed. Philadelphia: Society for Industrial; Applied Mathematics, 2023. p. 991
- MINGOTI, Sueli Aparecida. [Análise de Dados Através de Métodos de Estatística Multivariada: Uma Abordagem Aplicada](#). Belo Horizonte: Editora UFMG, 2005.
- MUIRHEAD, Robb J. [Aspects of Multivariate Statistical Theory](#). New York: John Wiley & Sons, 1982.
- PILLAI, K. C. S. [Some New Test Criteria in Multivariate Analysis](#). **The Annals of Mathematical Statistics**, v. 26, n. 1, p. 117–121, 1955.
- POLLARD, David. [Strong Consistency of \$k\$ -Means Clustering](#). **The Annals of Statistics**,

v. 9, n. 1, p. 135–140, 1981.

RAO, C. Radhakrishna. **Linear Statistical Inference and Its Applications**. 2. ed. New York: John Wiley & Sons, 1973.

RENCER, Alvin C.; CHRISTENSEN, William F. **Methods of Multivariate Analysis**. 3. ed. Hoboken, NJ: John Wiley & Sons, 2012.

SIDI, Avram. **Vector Extrapolation Methods with Applications**. Philadelphia: Society for Industrial; Applied Mathematics, 2017. p. 381

TORGERSON, Warren S. **Multidimensional Scaling: I. Theory and Method**. **Psychometrika**, v. 17, n. 4, p. 401–419, 1952.

VAART, A. W. van der. **Asymptotic Statistics**. Cambridge: Cambridge University Press, 1998. p. 462

WARD, Jr., Joe H. **Hierarchical Grouping to Optimize an Objective Function**. **Journal of the American Statistical Association**, v. 58, n. 301, p. 236–244, 1963.

WILKS, Samuel S. **Certain Generalizations in the Analysis of Variance**. **Biometrika**, v. 24, n. 3–4, p. 471–494, 1932.